

UNED

unidad
didáctica

Métodos, diseños y técnicas de investigación psicológica

M.^a José Navas Ara *(Coordinadora)*

MÉTODOS, DISEÑOS Y TÉCNICAS DE INVESTIGACIÓN PSICOLÓGICA

UNIDADES DIDÁCTICAS

María José Navas Ara
(Coordinadora)

MÉTODOS, DISEÑOS Y TÉCNICAS DE INVESTIGACIÓN PSICOLÓGICA

UNIVERSIDAD NACIONAL DE EDUCACIÓN A DISTANCIA

UNIDADES DIDÁCTICAS (0149001UD01A01)
MÉTODOS, DISEÑOS Y TÉCNICAS
DE INVESTIGACIÓN PSICOLÓGICA

Quedan rigurosamente prohibidas, sin la autorización escrita de los titulares del Copyright, bajo las sanciones establecidas en las leyes, la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la reprografía y el tratamiento informático, y la distribución de ejemplares de ella mediante alquiler o préstamos públicos.

© *Universidad Nacional de Educación a Distancia*
Madrid, 2001

Librería UNED: c/ Bravo Murillo, 38 - 28015 Madrid
Tels.: 91 398 75 60 / 73 73
e-mail: libreria@adm.uned.es

© *María José Navas, Ángel M. Fidalgo, Concepción Gabriel, Juan Carlos Suárez,*
Ángeles Briosó, Guillermo Gil, Rosario Martínez Arias y Encarnación Sarriá

ISBN: 978-84-362-4496-0
Depósito legal: M. 50.216-2009

Primera edición: septiembre de 2001
Séptima reimpresión: noviembre de 2009

Impreso en España - Printed in Spain
Imprime: Fernández Ciudad, S. L.
Coto de Doñana, 10. Pinto (Madrid)

RELACIÓN DE AUTORES

Ángeles Brioso Díez

Facultad de Psicología, Universidad Nacional de Educación a Distancia

Ángel M. Fidalgo Aliste

Facultad de Psicología, Universidad de Oviedo

Concepción Gabriel Esteban

CIMOP, S.A.

Guillermo Gil Escudero

Instituto Nacional de Calidad y Evaluación (INCE), Ministerio de Educación,
Cultura y Deporte

María Rosario Martínez Arias

Facultad de Psicología, Universidad Complutense de Madrid

María José Navas Ara

Facultad de Psicología, Universidad Nacional de Educación a Distancia

Encarnación Sarriá Sánchez

Facultad de Psicología, Universidad Nacional de Educación a Distancia

Juan Carlos Suárez Falcón

Facultad de Psicología, Universidad Nacional de Educación a Distancia

ÍNDICE

PRESENTACIÓN	19
--------------------	----

Parte I

FUNDAMENTOS DE LA METODOLOGÍA CIENTÍFICA

1. LA LÓGICA DE LA INVESTIGACIÓN CIENTÍFICA	
<i>María José Navas Ara</i>	25
1.1. Introducción	25
1.2. Caracterización de la ciencia	27
1.3. El método científico	31
1.4. El estatus científico de la psicología	34
1.5. Las distintas modalidades del método científico en la investigación psicológica	36
1.5.1. <i>Tradiciones de investigación en Psicología</i>	36
1.5.2. <i>La metodología experimental</i>	40
1.5.3. <i>La metodología no experimental</i>	42
1.6. La planificación de una investigación	45
1.7. Puntos básicos	51
1.8. Ejercicios	53
1.9. Soluciones a los ejercicios propuestos	55
1.10. Bibliografía básica recomendada	56
1.11. Lecturas sugeridas	57
1.12. Material complementario	58
2. LA MEDICIÓN DE LO PSICOLÓGICO <i>María José Navas Ara</i> .	
2.1. Introducción	59

2.2.	Necesidad de la medida psicológica	60
2.3.	Posibilidad de la medida psicológicas	62
2.3.1.	<i>La licencia para medir en las Ciencias Sociales</i>	62
2.3.2.	<i>La medición por índices</i>	64
2.3.3.	<i>La teoría de las escalas de medida de Stevens</i>	65
2.4.	Aproximación a la medición psicológica	71
2.4.1.	<i>Definición</i>	71
2.4.2.	<i>Dificultades</i>	74
2.5.	Instrumentos de medida	76
2.5.1.	<i>Clarificación terminológica</i>	76
2.5.2.	<i>Clasificación</i>	78
2.5.3.	<i>Estatus métrico</i>	80
2.6.	Reflexión final	80
2.7.	Puntos básicos	81
2.8.	Ejercicios	83
2.9.	Soluciones a los ejercicios propuestos	84
2.10.	Bibliografía básica recomendada	87
2.11.	Lecturas sugeridas	88
2.12.	Material complementario	88

Parte II

CONSTRUCCIÓN, EVALUACIÓN Y APLICACIÓN DE INSTRUMENTOS DE MEDIDA

3.	LOS INSTRUMENTOS DE MEDICIÓN PSICOLÓGICA I: CONSTRUCCIÓN Y APLICACIÓN <i>María José Navas Ara</i>	95
3.1.	Introducción	95
3.2.	Objetivo del test	97
3.2.1.	<i>Variable de interés</i>	97
3.2.2.	<i>Población diana</i>	98
3.2.3.	<i>Utilización prevista</i>	99
3.3.	Especificación del test	99
3.3.1.	<i>Contenido</i>	101
3.3.2.	<i>Formato</i>	104
3.3.3.	<i>Longitud</i>	112
3.3.4.	<i>Características psicométricas</i>	113
3.4.	Confección de los ítems	115
3.4.1.	<i>Recomendaciones generales</i>	116
3.4.2.	<i>En el dominio cognitivo</i>	119

3.4.3. <i>En el dominio no cognitivo</i>	121
3.4.4. <i>Revisión de los ítems</i>	122
3.5. <i>Confección de la prueba</i>	123
3.5.1. <i>Instrucciones de administración</i>	123
3.5.2. <i>Formato de presentación de la prueba</i>	125
3.5.3. <i>Formato de registro de las respuestas</i>	127
3.6. <i>Aplicación de la prueba</i>	128
3.7. <i>Puntos básicos</i>	130
3.8. <i>Ejercicios</i>	131
3.9. <i>Soluciones a los ejercicios propuestos</i>	133
3.10. <i>Bibliografía básica recomendada</i>	135
3.11. <i>Lecturas sugeridas</i>	136
3.12. <i>Material complementario</i>	137
 4. LOS INSTRUMENTOS DE MEDICIÓN PSICOLÓGICA II: ASIGNACIÓN E INTERPRETACIÓN DE PUNTUACIONES <i>María José Navas Ara</i>	 139
4.1. <i>Introducción</i>	139
4.2. <i>Puntuación del test</i>	141
4.2.1. <i>Puntuación de las respuestas a los ítems</i>	141
4.2.2. <i>Combinación de las puntuaciones a los ítems</i>	145
4.3. <i>Interpretación de las puntuaciones del test</i>	148
4.3.1. <i>Interpretación normativa</i>	150
4.3.1.1. <i>Puntuaciones cronológicas</i>	151
4.3.1.2. <i>Puntuaciones centiles</i>	153
4.3.1.3. <i>Puntuaciones típicas</i>	157
4.3.2. <i>Interpretación criterial</i>	161
4.4. <i>Puntos básicos</i>	164
4.5. <i>Ejercicios</i>	166
4.6. <i>Soluciones a los ejercicios propuestos</i>	168
4.7. <i>Bibliografía básica recomendada</i>	173
4.8. <i>Lecturas sugeridas</i>	174
4.9. <i>Material complementario</i>	174
 5. LAS TEORÍAS DE LOS TESTS <i>María José Navas Ara</i>	 175
5.1. <i>Introducción</i>	175
5.2. <i>El problema del error de medida</i>	177
5.3. <i>La teoría clásica de los tests</i>	180
5.3.1. <i>Modelo</i>	181
5.3.2. <i>Estimación del error de medida</i>	185
5.3.3. <i>Estimación de la característica de interés</i>	187

5.4.	La teoría de respuesta al ítem	194
5.4.1.	<i>Modelo</i>	195
5.4.1.1.	Supuestos	195
5.4.1.2.	La función característica del ítem	197
5.4.2.	<i>Estimación del error de medida</i>	200
5.4.3.	<i>Estimación de la característica de interés</i>	202
5.5.	Puntos básicos	203
5.6.	Ejercicios	204
5.7.	Soluciones a los ejercicios propuestos	206
5.8.	Bibliografía básica recomendada	211
5.9.	Lecturas sugeridas	211
5.10.	Material complementario	212
6.	LA FIABILIDAD COMO CRITERIO MÉTRICO DE LA CALIDAD GLOBAL DEL TEST <i>María José Navas Ara</i>	213
6.1.	Introducción	213
6.2.	Concepción clásica	217
6.2.1.	<i>Fiabilidad como estabilidad temporal</i>	220
6.2.1.1.	Método test-retest	220
6.2.1.2.	Método de las formas paralelas	220
6.2.2.	<i>Fiabilidad como consistencia interna</i>	222
6.2.2.1.	Métodos basados en la división del test en dos mitades	223
6.2.2.2.	Método basado en la covariación de los ítems	227
6.2.3.	<i>Factores que influyen en el coeficiente de fiabilidad</i>	230
6.2.3.1.	Longitud del test	231
6.2.3.2.	Variabilidad de la muestra de sujetos	233
6.2.4.	<i>Crítica a la teoría clásica de los tests</i>	235
6.3.	Concepción de la teoría de respuesta al ítem: Fiabilidad como información	236
6.4.	Fiabilidad interjueces	238
6.4.1.	<i>Estimación de la fiabilidad interjueces</i>	239
6.4.2.	<i>Acuerdo entre jueces</i>	242
6.5.	Fiabilidad como consistencia en las clasificaciones obtenidas a partir del test	246
6.5.1.	<i>Problemática específica en la interpretación criterial</i> ..	246
6.5.2.	<i>Precisión en el punto de corte</i>	247
6.5.3.	<i>Consistencia de las clasificaciones</i>	249
6.6.	Puntos básicos	251

6.7. Ejercicios	253
6.8. Soluciones a los ejercicios propuestos	255
6.9. Bibliografía básica recomendada	260
6.10. Material complementario	261
7. LA VALIDEZ COMO CRITERIO MÉTRICO DE LA CALIDAD GLOBAL DEL TEST <i>María José Navas Ara</i>	263
7.1. Introducción	263
7.2. Caracterización general	266
7.3. Métodos relacionados con la estructura interna del test	269
7.4. Métodos relacionados con el contenido del test	270
7.5. Métodos basados en la relación con otras variables	272
7.5.1. <i>Relación con variables relevantes desde el punto de vista teórico</i>	273
7.5.2. <i>Predicción de un criterio</i>	277
7.5.2.1. Continuo	278
7.5.2.1.1. <i>Cuantificación de los resultados del estudio de validación</i>	279
7.5.2.1.2. <i>Estimación de la puntuación en el criterio</i>	280
7.5.2.1.3. <i>Factores que influyen en la relación test-criterio</i>	282
7.5.2.2. Discreto	287
7.6. La generalización de la validez	290
7.7. Puntos básicos	291
7.8. Ejercicios	293
7.9. Soluciones a los ejercicios propuestos	296
7.10. Bibliografía básica recomendada	301
7.11. Lecturas sugeridas	301
7.12. Material complementario	302
8. EVALUACIÓN DE LA CALIDAD MÉTRICA DE LOS ELEMENTOS DEL TEST: ANÁLISIS DE ÍTEMS <i>Juan Carlos Suárez Falcón</i>	303
8.1. Introducción	303
8.2. Parámetros del ítem	305
8.2.1. <i>Dificultad del ítem</i>	305
8.2.2. <i>Discriminación del ítem</i>	308
8.2.2.1. El índice de discriminación D	309
8.2.2.2. Índice basado en la correlación ítem-test	311
8.2.3. <i>Índice de fiabilidad del ítem</i>	314

8.2.4. Índice de validez del ítem	315
8.2.5. Relación de los parámetros del ítem con los parámetros del test	316
8.3. Análisis de los distractores	317
8.4. Análisis del funcionamiento diferencial del ítem	320
8.4.1. Impacto y funcionamiento diferencial del ítem	320
8.4.2. El procedimiento de Mantel-Haenszel	322
8.5. Puntos básicos	326
8.6. Ejercicios	327
8.7. Soluciones a los ejercicios propuestos	331
8.8. Bibliografía básica recomendada	336
8.9. Lecturas sugeridas	337
8.10. Material complementario	337

Parte III MÉTODOS DE INVESTIGACIÓN

9. METODOLOGÍA EXPERIMENTAL Y CUASI EXPERIMENTAL Ángel M. Fidalgo Aliste	341
9.1. Dioses, filosofía y experimentación	341
9.2. Diez conceptos básicos más un ejemplo	344
9.2.1. El ejemplo	344
9.2.2. Hipótesis experimentales	345
9.2.3. La causalidad práctica	345
9.2.4. Tipos de variables	346
9.2.5. Principios de optimización	348
9.2.6. Control	351
9.2.7. Modelización matemática	353
9.2.8. Fases de una investigación y clases de validez	354
9.2.9. ¿Experimento o cuasi experimento?	356
9.2.10. Diseños	358
9.3. Metodología experimental	358
9.3.1. Diseños completamente aleatorizados	359
9.3.2. Diseños de bloques homogéneos aleatorizados	360
9.3.3. Diseños de medidas repetidas	361
9.3.4. Diseños de sujeto único o $n=1$	363
9.4. Metodología cuasi experimental	367
9.4.1. Diseños con grupo de control no equivalente	368
9.4.2. Diseños de discontinuidad en la regresión	369
9.4.3. Diseños de series temporales interrumpidas	372

9.5.	Lo último es lo primero	374
9.6.	Puntos básicos	375
9.7.	Ejercicios	376
9.8.	Soluciones a los ejercicios propuestos	378
9.9.	Bibliografía básica recomendada	379
9.10.	Material complementario	379
10.	METODOLOGÍA DE ENCUESTAS <i>Guillermo Gil Escudero y Rosario Martínez Arias</i>	381
10.1.	Introducción	381
10.2.	Concepto y delimitación de la metodología de encuestas	383
10.2.1.	<i>Definición</i>	384
10.2.2.	<i>Uso de la metodología de encuestas</i>	386
10.3.	Tipos de encuestas	388
10.3.1.	<i>Encuestas censales y muestrales</i>	389
10.3.2.	<i>Encuestas descriptivas y explicativas</i>	389
10.3.3.	<i>Encuestas transversales y longitudinales</i>	391
10.4.	Fases de una encuesta	394
10.4.1.	<i>Establecimiento del objetivo de la encuesta</i>	394
10.4.2.	<i>Diseño de la encuesta</i>	397
10.4.2.1.	Definición de la información deseada y construcción de los instrumentos de la encuesta	397
10.4.2.2.	Definición de la población y de la muestra	399
10.4.2.3.	Selección del sistema de recopilación de datos y planificación de la obtención de datos	402
10.4.2.4.	Prueba piloto	403
10.4.3.	<i>Obtención de datos</i>	404
10.4.4.	<i>Explotación de la encuesta</i>	404
10.4.4.1.	Codificación, registro y verificación de la información	404
10.4.4.2.	Análisis de datos	406
10.4.4.3.	Presentación de resultados	408
10.5.	Procedimientos de recogida de la información	409
10.6.	Técnicas de muestreo	411
10.6.1.	<i>Los errores en las encuestas</i>	411
10.6.2.	<i>Métodos de muestreo</i>	414

10.6.3. <i>El muestreo probabilístico: muestreo aleatorio simple</i>	415
10.6.4. <i>Los errores de estimación</i>	418
10.6.5. <i>Otros procedimientos de muestreo probabilístico</i> ..	422
10.6.5.1. Muestreo aleatorio estratificado	422
10.6.5.2. Muestreo aleatorio por conglomerados ..	424
10.6.6. <i>Diseños muestrales no probabilísticos: Métodos subjetivos</i>	428
10.7. Puntos básicos	430
10.8. Ejercicios	432
10.9. Soluciones a los ejercicios propuestos	434
10.10. Bibliografía básica recomendada	437
10.11. Lecturas sugeridas	437
10.12. Material complementario	438
 11. METODOLOGÍA OBSERVACIONAL <i>Encarnación Sarriá Sánchez y Ángeles Brioso Díez</i>	 439
11.1. Introducción	439
11.2. Caracterización del método observacional	442
11.3. Categorización	446
11.4. Muestreo y registro	454
11.4.1. <i>Reglas de muestreo</i>	455
11.4.2. <i>Reglas de registro</i>	458
11.5. Métrica de la observación	460
11.6. Control de calidad de los datos	462
11.6.1. <i>Estimación de la fiabilidad</i>	463
11.6.2. <i>Fuentes de error y formas de control en la observación</i>	465
11.7. Diseños y análisis de datos	468
11.8. Puntos básicos	472
11.9. Ejercicios	473
11.10. Soluciones a los ejercicios propuestos	476
11.11. Bibliografía básica recomendada	480
11.12. Lecturas sugeridas	481
11.13. Material complementario	482
 12. METODOLOGÍA CUALITATIVA <i>Concepción Gabriel Esteban</i> ...	 483
12.1. Introducción	483
12.2. Dos miradas complementarias: el enfoque cualitativo y el cuantitativo	484
12.3. La entrevista en profundidad	486

12.3.1.	<i>Caracterización general</i>	486
12.3.2.	<i>Ámbito de aplicación</i>	488
12.3.3.	<i>El investigador y la dinámica de las entrevistas ..</i>	489
12.3.4.	<i>Sobre el número de entrevistas a realizar</i>	492
12.3.5.	<i>La logística de la entrevista</i>	494
12.3.6.	<i>El análisis de la entrevista</i>	495
12.4.	El grupo de discusión	496
12.4.1.	<i>Caracterización general</i>	496
12.4.2.	<i>Ámbito de aplicación</i>	497
12.4.3.	<i>El desarrollo de la dinámica</i>	500
12.4.4.	<i>El investigador y la dinámica en los grupos</i>	501
12.4.5.	<i>Sobre el número de grupos</i>	505
12.4.6.	<i>Diseño de los grupos</i>	506
12.4.7.	<i>Los participantes en los grupos de discusión</i>	508
12.4.8.	<i>La contactación de los asistentes a un grupo de discusión</i>	509
12.4.9.	<i>El lugar de realización</i>	510
12.4.10.	<i>El análisis del grupo de discusión</i>	512
12.5.	El grupo triangular	515
12.5.1.	<i>Caracterización general</i>	515
12.5.2.	<i>Ámbito de aplicación</i>	517
12.5.3.	<i>El diseño de los grupos triangulares</i>	518
12.5.4.	<i>El análisis del discurso</i>	518
12.6.	Puntos básicos	519
12.7.	Ejercicios	521
12.8.	Soluciones a los ejercicios propuestos	522
12.9.	Bibliografía básica recomendada	523
12.10.	Lecturas sugeridas	523
12.11.	Material complementario	524
ANEXO: TABLAS ESTADÍSTICAS		525
REFERENCIAS BIBLIOGRÁFICAS		533
GLOSARIO		543

PRESENTACIÓN

Este libro pretende ofrecer una introducción de carácter general a la investigación científica en el ámbito de la Psicología y la Educación y está dirigido a todo aquel que desee familiarizarse con los fundamentos de la metodología científica, a quien quiera saber cómo se realiza una investigación psicológica, de qué métodos se dispone para llevar a cabo un estudio que permita dar respuesta a un problema de investigación y cómo se construyen y, sobre todo, cómo se evalúan los instrumentos (tests, cuestionarios, escalas, pruebas...) que sirven para medir una determinada característica, variable o atributo.

Este manual está pensado para los alumnos de la titulación de Psicopedagogía de la UNED, para la asignatura *Métodos, Diseños y Técnicas de Investigación Psicológica*. Por ello, aspira a ser un material autosuficiente que permita al alumno preparar el programa de la asignatura. Ahora bien, antes de comenzar su lectura y estudio es imprescindible que el alumno de la UNED acuda a la guía de la carrera o a la página web de la asignatura para conocer cuestiones básicas relativas tanto a la metodología que se va a seguir a lo largo del curso como a su dinámica de trabajo y evaluación.

El libro se estructura en tres partes. El primer bloque temático está dedicado a los fundamentos de la metodología científica. Se abordan las características y principios básicos de la metodología científica en general y las modalidades que adopta el método general de la ciencia en una ciencia en particular, la Psicología. Asimismo, se reflexiona sobre la medición en Psicología, ya que la medición rigurosa de las variables psicológicas ha de constituir siempre el paso previo e ineludible para cualquier uso posterior que se vaya a hacer de ellas, ya sea en el campo de la

investigación científica o en el de la práctica profesional. El segundo bloque temático se encarga precisamente de ver cómo se construyen y evalúan los instrumentos que van a permitir medir esas variables psicológicas y el tercer bloque temático se ocupa de las distintas modalidades que adopta el método científico en la investigación psicológica, dedicando un capítulo a cada una de ellas.

Al final del libro se ofrece un glosario en el que se incluyen definiciones de los conceptos más importantes presentados en cada capítulo, así como de otros términos que no están vinculados tan directamente con la metodología de la investigación psicológica, pero a los que se hace referencia en algún momento de la exposición y que pueden facilitar la lectura. Siempre que se dispone de una entrada en el glosario para uno de estos términos se subraya dicha palabra en el texto, para indicar al lector que puede acudir al glosario si así lo desea.

Todos los capítulos tienen la misma estructura. Comienzan con una introducción que pone en antecedentes al lector de lo que se va a encontrar —y por qué— en los siguientes apartados, indicando cuáles son los objetivos que se pretenden cubrir y proporcionando en la mayor parte de los capítulos un esquema-resumen de los contenidos que se van a exponer. Seguidamente se presentan esos contenidos en un número variable de apartados; se ofrece un resumen de los mismos en forma de puntos básicos con las ideas principales en las que es preciso haber reparado al leer el capítulo; a continuación, se propone un conjunto de ejercicios que le servirán al lector para poner a prueba o reflexionar sobre lo que ha aprendido y se ofrece también la solución a dichos ejercicios. Por último, se incluye una bibliografía básica que proporciona un pequeño número de referencias en castellano que abordan los contenidos expuestos en el capítulo. Finalmente, se proporcionan también unas lecturas sugeridas para aquellos lectores que quieran ir más allá de lo expuesto en este texto de carácter inequívocamente introductorio.

Como tendrá ocasión de comprobar en breve el lector, el material que aquí se presenta incluye un variado contenido gráfico en forma de tablas, gráficos, figuras y cuadros de distinto tipo. La lectura comprensiva de este libro requiere examinar y estudiar cuidadosamente el material gráfico que acompaña al texto en cada capítulo. Hay, sin embargo, dos excepciones.

Primero, todos los cuadros que aparecen sombreados tienen como objetivo explicar algún concepto estadístico que no forma parte del programa de la asignatura pero que es necesario entender (por ejemplo, la media o la varianza de una distribución de frecuencias, el coeficiente de correlación entre dos variables, etc.), de forma que el lector que esté familiarizado con esos conceptos puede continuar la lectura lineal del capítulo

saltando dicho cuadro o, en caso contrario, el cuadro proporciona la información suficiente para que pueda continuar sin dificultad con la lectura del texto. También se han utilizado cuadros sombreados para dar explicaciones, ejemplos o aclaraciones adicionales que de alguna forma interrumpirían la lectura. En resumen, el lector que así lo desee puede ignorar toda la información que aparezca en estos cuadros sombreados.

Segundo, se han incluido a lo largo de todo el texto llamadas a un material complementario que comienzan con las letras MC. El objetivo de este material es ofrecer la posibilidad a quién lo desee de profundizar en algunos de los contenidos expuestos en el libro o de abordar cuestiones que no pueden ser examinadas en un texto de estas características. Este material se encuentra disponible en el CD-Rom de la asignatura¹ y, para los alumnos matriculados en la asignatura, en el curso virtual.

El libro habrá cumplido su objetivo si el lector al terminarlo decide poner a prueba o someter a contrastación empírica su nivel de conocimientos planteándose una investigación real, o si es capaz de leer de forma más crítica los informes de investigación, los artículos en publicaciones especializadas o sencillamente los numerosos productos científicos y pseudocientíficos que se ofrecen a diario en los medios de comunicación, o si se anima simplemente a embarcarse en la lectura de alguno de los excelentes libros que ofrece la literatura al lector ávido de conocimiento.

María José Navas Ara
(Madrid, junio de 2006)

¹ NAVAS, M. J., y RECIO, P. (2006). *Métodos, diseños y técnicas de investigación psicológica. Material de apoyo para el estudio de la asignatura*. Madrid: UNED.

Parte I

FUNDAMENTOS

DE LA METODOLOGÍA CIENTÍFICA

LA LÓGICA DE LA INVESTIGACIÓN CIENTÍFICA

María José Navas Ara

1.1. INTRODUCCIÓN

Desde la prehistoria, la búsqueda de conocimiento ha presidido la conducta del hombre. El hombre *necesita* conocer el mundo en el que vive y ésta ha sido y es una necesidad básica: la necesidad de indagar como forma de adaptarse al medio y sobrevivir. Además, el sentido humano de curiosidad sobre el mundo y sobre sí mismo es, según Laudan (1986), tan compulsivo como su necesidad de vestido y alimento. La antropología cultural apunta a la ubicuidad de elaboradas doctrinas acerca de cómo y por qué funciona el universo, incluso entre culturas *primitivas* que apenas sobreviven en bajos niveles de subsistencia. La universalidad de este fenómeno indica que «encontrar el sentido del mundo y nuestro lugar en él tiene raíces profundas en el alma humana» (*op. cit.* p. 279). En cualquier caso, el hombre siempre ha intentado procurarse un saber objetivo que le indicara, al menos, cómo servirse de las cosas y cómo dominarlas a fin de dar respuesta a sus necesidades.

La aparición de la ciencia moderna en el siglo xvii produjo un acelerado cambio social e hizo obsoleto el tradicional mecanismo de adaptación del hombre al entorno a través de la cultura, las normas y hábitos, sustituyendo éste por la propia ciencia como método de reducción de incertidumbres y de control de la realidad (Lamo de Espinosa, 1996). La ciencia, si bien no es en absoluto la única fuente o modo posible —y utilizado— de conocimiento, sí es la más provechosa, universal y reciente de todas (Bunge, 1989): parece bastante más sensato diseñar un adecuado sistema de regadío y disponer de una buena red de pantanos si se quiere garantizar el riego de una determinada área geográfica que hacer rogativas. El éxito de la ciencia es abrumador por razones prácticas, entre otras. La ciencia es considerada por muchos como el paradigma de la racionalidad a la hora de resolver problemas y a ella se va a dedicar el siguiente apartado del capítulo.

En la sociedad actual se tiene a la ciencia en alta estima y consideración; es más, el elevado respeto que se siente hacia la misma puede ser considerado casi como la moderna religión, que desempeñaría un papel similar al que jugó el cristianismo en Europa en épocas pretéritas (Chalmers, 1987). En la actualidad, la mayor parte de los medios de comunicación cuentan con una sección habitual de ciencia y en la publicidad se apela con demasiada frecuencia y ligereza a la etiqueta de «científicamente probado» para vendernos tal o cual detergente o producto de limpieza, de belleza o de cualquier otro tipo. Sin embargo, a pesar de andar de boca en boca, la ciencia es difícil de definir; no solo para el lego sino también para los propios filósofos de la ciencia. De hecho, éstos han optado por tratar de diferenciar lo que es científico de lo que no lo es (el problema de la demarcación de la ciencia) en lugar de tratar de definirla. La posición tradicional y más difundida al respecto es abordar el problema de la demarcación atendiendo al método que utiliza una disciplina para responder a los problemas que tiene planteados. El siguiente apartado se ocupa justamente de este método, del método científico, haciendo una presentación general de los tres momentos principales en su modo de operar: planteamiento del problema, formulación de hipótesis y contrastación empírica de las hipótesis. Estos tres momentos se explicarán con algo más de detalle a través de un ejemplo psicológico en el último apartado del capítulo *La planificación de la investigación*, tras introducir en el penúltimo apartado las principales modalidades que adopta el método científico en la investigación psicológica, esto es, cómo se adapta el método general descrito en el apartado tercero a las peculiaridades específicas de la Psicología. Ahora bien, antes de ver cómo se aplica el método científico al objeto propio de estudio de la Psicología es preciso abordar previamente una cuestión fundamental y que ha hecho correr ríos de tinta: ¿la Psicología es una ciencia? A esta cuestión se dedica el cuarto apartado *El estatus científico de la Psicología*, donde se examinan las dificultades de ajuste entre el objeto propio de la Psicología y el método general con el que ésta trata de abordar su estudio que está, como veremos, directamente importado de la Ciencia Natural.

Los objetivos que se persiguen en este capítulo son los siguientes:

- conocer los fines que persigue la ciencia;
- comprender los principios que deben caracterizar a la actividad científica;
- saber en qué consiste el problema de la demarcación de la ciencia;
- diferenciar entre el método general de la ciencia y las modalidades que éste adopta en las distintas disciplinas científicas;
- conocer las principales tradiciones de investigación en Psicología;

- comprender la lógica de la investigación científica;
- entender los pasos que hay que dar a la hora de planificar una investigación.

En el diagrama de la figura 1.1 se presenta un esquema-resumen con los contenidos que se van a desarrollar en el capítulo para lograr los objetivos anteriores.




FIGURA 1.1. Esquema-resumen con los contenidos del capítulo 1.

1.2. CARACTERIZACIÓN DE LA CIENCIA

Como se indicó en la introducción, los filósofos de la ciencia decidieron ya hace tiempo no abordar la difícil tarea de definirla y optaron por concentrarse en distinguir entre lo que es o no científico. Pero incluso «definir las fronteras de la ciencia, aunque sea *epistemológicamente*, constituye una labor condenada al fracaso» (Echeverría, 1989, p. 2). En buena lógica, no se va a proponer aquí definición alguna de ciencia. Si acaso, se tratará de realizar una aproximación a la misma a través de los **objetivos** que persigue, de sus **características** y de los principios que deben caracterizarla y, cómo no, del **método** utilizado para lograr sus objetivos.

Lamo de Espinosa (1996) sostiene que solo puede entender la ciencia «como un viaje de exploración y descubrimiento de lo ignoto... [como] un intento de acercarse a la verdad [que]... nunca está seguro de sí mismo» (pp. 7-8). La ciencia sería un estilo de pensamiento y de acción cuyo producto final es el conocimiento científico, que no es más que un tipo de conocimiento humano —igual que el religioso, mítico, ritual o mágico—

caracterizado por el método o procedimiento utilizado en su obtención —el método científico.

Según Hempel (1978), el objetivo primario de la ciencia responde a dos exigencias. La primera, ayudar al hombre en su esfuerzo por controlar su medio. Como ya se señaló, el conocimiento científico es solo una clase de conocimiento que responde a la necesidad del hombre de indagar en su intento de adaptarse al medio y sobrevivir. La ciencia es un sistema de indagación más y su producto —las teorías científicas— pueden ser consideradas como formas de mirar al mundo. En este sentido, se puede afirmar que el conocimiento científico contribuye a la solución de los problemas prácticos que surgen en la vida cotidiana y proporciona el fundamento para los adelantos tecnológicos. La segunda función, íntimamente relacionada con la anterior, consiste en adquirir un conocimiento y una comprensión cada vez más amplios y profundos del mundo. De este modo, los progresos científicos moldean la visión que tiene el hombre de la realidad y su conjunto de supuestos fundamentales acerca de la forma en que *realmente* marcha el mundo y acerca de lo que la gente *realmente* es. Estos efectos de la ciencia son menos tangibles que los tecnológicos pero no por ello menos importantes.

En esta segunda función de la ciencia hay tres niveles o componentes importantes (Babbie, 1990): la descripción, el descubrimiento de regularidades y la formulación de leyes y teorías que generalicen y formalicen las regularidades descubiertas, una vez que los fenómenos han sido convenientemente descritos. Solo cuando un fenómeno ha sido adecuadamente descrito puede ser explicado y, por consiguiente, pronosticado o susceptible de control. Dicho de otro modo, los hechos y los fenómenos deben ser conectados entre sí de una forma lógica y sistemática para construir conocimiento organizado y esta conexión se puede realizar a tres niveles distintos: descriptivo, relacional o explicativo. Por tanto, los fines de la ciencia serían: describir, explicar, predecir y controlar. En dos palabras, la ciencia tiene como objetivo la comprensión (habitualmente, en términos explicativos) del mundo y de lo que en él acontece, ha acontecido y acontecerá y el subsiguiente control que se deriva de dicho conocimiento.

MC Los objetivos de la ciencia

Antes de pasar a examinar el método con el que la ciencia trata de conseguir estos fines, en el cuadro 1.1 se indican las características que hacen que una actividad determinada sea calificada de más o menos científica (Babbie, 1990).

CUADRO 1.1.
Características de la actividad científica

LÓGICA	La ciencia es una tarea basada en la razón lógica: un hecho determinado no puede ser la causa de otro que ha ocurrido con anterioridad, un objeto dado no puede tener características que sean mutuamente excluyentes, ni una característica puede dar lugar a resultados mutuamente excluyentes, etc. Además de esta lógica de sentido común, la actividad científica opera con la lógica deductiva y con la inductiva.
DETERMINISTA	Según los científicos, las cosas no ocurren sin más, siempre hay una razón para todo: la ciencia se basa en el supuesto de que todo hecho tiene causa(s) antecedente(s) que se puede(n) identificar y comprender. Una buena parte de la ciencia se basa en una forma probabilística de determinismo. Por ejemplo, en una encuesta a familias españolas podemos encontrar que un 70% de las mujeres está dispuesta a asumir las tareas domésticas al volver de su trabajo mientras que sólo un 25% de los hombres lo harían. En este caso, el género determina la disposición a asumir el trabajo doméstico pero no lo hace completamente. Para explicar esta discrepancia es necesario introducir otros factores junto con el género.
GENERAL	La ciencia tiene por objeto la comprensión de hechos o fenómenos generales y no tanto la explicación de hechos individuales, ya que trata de llegar a descubrimientos y leyes de aplicación general. Sin ningún género de dudas, para una mujer particular, la cuestión de interés es conocer la disposición de su pareja a la hora de realizar las tareas domésticas en su casa pero eso para la ciencia tiene poco interés, ya que lo que ésta trata es de dilucidar cuáles son los factores que explican la implicación diferencial de varones y mujeres en este tipo de tareas, si bien el conocimiento de los mismos le será de gran utilidad a la mujer en cuestión para pronosticar la ayuda real que tendrá en casa.
PARSIMONIOSA	Cuanto más simple sea una explicación, tanto mejor. Cuanto menor sea el número de factores implicados en una teoría —por supuesto, para una misma capacidad explicativa— más parsimoniosa será la teoría y, por tanto, deberá ser la teoría de elección. El principio de la parsimonia fue formulado por Guillermo de Ockham en el siglo XIV y aboga por una explicación con el menor número posible de excepciones y con el número más limitado posible de argumentos y conceptos.

ESPECÍFICA	En su búsqueda de leyes y conocimientos de aplicación general, la ciencia tiene que proceder con definiciones operativas específicas de los conceptos evaluados. Para examinar la disposición a realizar tareas domésticas tras la jornada laboral, es preciso definir operativamente de forma específica esta disposición, bien a través de un cuestionario en el que se solicite al encuestado que manifieste su grado de acuerdo o desacuerdo con una serie de afirmaciones, bien mediante un listado de tareas domésticas en el que se pide al encuestado que marque con una cruz aquéllas que sí estaría dispuesto a hacer.
CONTRASTABLE EMPÍRICAMENTE	Una teoría solo es útil si permite que se derive de la misma enunciados básicos o predicciones observables cuya adecuación se ha de dirimir acudiendo a datos empíricos. Se han utilizado dos estrategias distintas en la contrastación empírica de una teoría: la inductivista-confirmatoria y la deductivista-falsacionista (véase más adelante el apartado 1.3). Por tanto, una teoría solo es útil si conduce a predicciones observables que se ven confirmadas por la experiencia o que no son falsadas por ésta.
INTERSUBJETIVA	El hallazgo de un determinado descubrimiento científico no depende de qué científico o equipo de investigación haya realizado el experimento: dos equipos distintos de investigación deben llegar a la misma conclusión si realizan el mismo experimento.
ABIERTA A LA REVISIÓN	La siguiente cita ilustra con claridad este punto: Todo lo que «sabemos» hoy se «conocía» antes de otra forma y, en ocasiones, recordamos esas posturas primitivas como ingenuas, absurdas o estúpidas. Sin embargo, no está de más tener en cuenta que todo lo que «sabemos» hoy probablemente se vendrá abajo en algún momento del futuro y esos colegas futuros —nuestros arrogantes descendientes— nos recordarán como ingenuos, absurdos o estúpidos. (Si te preocupa esto, quizá puedas consolarte algo al saber que les espera idéntico destino.) (Babbie, 1990, p. 17). La ciencia asume la innovación como parte rutinaria de su quehacer (Lamo de Espinosa, 1996).

1.3. EL MÉTODO CIENTÍFICO

Vistos los objetivos que persigue la ciencia y los principios que deben caracterizar a la actividad científica, el otro aspecto que falta por abordar para aproximarnos al concepto de ciencia es justamente el método que ésta utiliza para lograr sus objetivos, esto es, el método científico. Dado el papel central que éste juega no solo *per se* sino por ser, además, la respuesta más difundida y tradicional que se ha dado al problema de la demarcación de la ciencia (se diferencia lo científico de lo que no lo es según se utilice o no el método científico en la actividad en cuestión), se ha considerado que el método científico merece por derecho propio un tratamiento de apartado independiente, si bien es solo una dimensión más —de enorme importancia, eso sí— para caracterizar la ciencia, que es lo que se hizo en el apartado anterior.

Francis Bacon fue uno de los primeros en intentar articular lo que es el método de la ciencia moderna. A comienzos del siglo xvii planteó que la finalidad de la ciencia era mejorar la suerte del hombre en la tierra y, según él, eso se podía lograr recogiendo hechos a través de la observación organizada y derivando de ellos teorías (Chalmers, 1987). El método es un camino para alcanzar un objetivo y, como ya señalara Descartes, el método es necesario para investigar la realidad. En particular, el método científico lo que proporciona es una forma de actuar mediante operaciones ordenadas que orientan la investigación hacia los fines de la ciencia, a través de una serie de fases interdependientes entre sí. La figura 1.2 recoge los tres momentos principales en la forma de operar del método científico: el planteamiento de problemas, la formulación de hipótesis como soluciones tentativas al problema que suscitó la investigación y la contrastación empírica de dichas hipótesis con el fin de determinar su plausibilidad como explicación probable del problema en cuestión.




FIGURA 1.2. Modo de operar del método científico.

La investigación científica arranca de problemas: sin problemas, no hay investigación. Y los problemas surgen en el marco del *corpus* previo

de conocimiento, ya sea éste ordinario o científico. Los problemas pueden surgir, por ejemplo, de lagunas en los resultados de la investigación o de resultados contradictorios en distintas investigaciones o, simplemente, cuando no existe información sobre algún particular. Para que el problema resulte fecundo es necesario que sea enunciado de forma precisa y específica.

¿Cuál es el origen de los grandes bloques de hielo (aerolitos) que durante el mes de enero de 2000 cayeron sobre distintos lugares de la geografía española?

Enunciado el problema, el científico ofrecerá una serie de conjeturas como soluciones tentativas. Para ello, procederá bien mediante la inducción y generalización de lo observado, bien mediante la formulación de hipótesis de las que habrá de deducir, posteriormente, implicaciones observables.

Hipótesis formuladas:

- Son minicometas.
- Proceden de un avión.
- Se deben al sobreenfriamiento de las capas altas de la atmósfera.
- Obedecen a una fina depresión de la capa de ozono.

Ya se proceda por la vía inductiva o deductiva, el paso siguiente consiste en contrastar con la experiencia la conjetura ofrecida como solución tentativa. Para ello, se puede optar por la vía inductiva-verificacionista o por la vía deductiva-falsacionista. La primera acepta la falsación de la teoría si alguna de sus predicciones se demuestra falsa, pero orienta la investigación hacia la verificación por la demostración de un número creciente de predicciones verdaderas, hacia la acumulación de resultados consistentes con la teoría, cuyo mantenimiento quedaría, de esta forma, justificado. La segunda vía acepta la corroboración de la teoría por la superación de pruebas experimentales rigurosas, si bien niega que ésta se pueda verificar y orienta la investigación hacia su falsación, deduciendo predicciones que, sometidas a experimentos críticos, demuestren lo único que la ciencia puede saber con *certeza*: la falsedad de sus teorías.

Los análisis hidroquímicos e isotópicos efectuados a los bloques permiten descartar las dos primeras hipótesis.

Mediante modelos teóricos y simulaciones por ordenador, la comisión de investigadores del CSIC demuestra cómo se puede formar un bloque de granizo en condiciones muy determinadas en la alta atmósfera, mostrando así que fue el sobreenfriamiento de las capas altas de la atmósfera lo que favoreció que el vapor de agua se condensara en forma de cristales de hielo microscópicos que, a su vez, actuaron como nucleadores para que el resto del vapor de agua siguiera adhiriéndose hasta formar grandes bloques de hielo.

En caso de confirmarse la hipótesis (ya sea verificada o no falsada) se ha obtenido evidencia favorable que apoya la verosimilitud de dicha conjetura como explicación plausible al problema planteado y, muy probablemente, si la investigación ha sido cuidadosa e imaginativa, la solución del problema inicial hará surgir un nuevo conjunto de problemas (Bunge, 1989). Las explicaciones hipotéticas confirmadas se aceptan y articulan en teorías. En caso contrario, cuando no se obtiene evidencia favorable a la conjetura formulada, hay que dar marcha atrás y formular y contrastar empíricamente nuevas hipótesis.

El Instituto Nacional de Meteorología informa de que no existían durante esos días las condiciones para la generación de los aerolitos (94° bajo cero), sino más bien al contrario (48° a 60° bajo cero).

El método tiene una estructura básica adecuada para todas las ciencias, que responde a los tres momentos recogidos en la figura 1.2.

MC La estructura del método científico-positivo

Sin embargo, cada ciencia se caracteriza por un conjunto abierto (y en expansión) de problemas que exige adaptar, transformar y modificar el método general a las peculiaridades específicas de cada campo del saber. Es decir, todas las disciplinas científicas comparten el método científico pero difieren en las tácticas que usan para la resolución de sus problemas particulares, ya que cada clase de problemas requiere un conjunto de métodos o técnicas especiales. La Psicología no es una excepción, pero antes de abordar la metodología específica con la que trata su objeto

propio de estudio, es necesario que respondamos a una importante cuestión: ¿la Psicología es una ciencia?

1.4. EL ESTATUS CIENTÍFICO DE LA PSICOLOGÍA

En el prólogo que Mariano Yela hace a la obra de Castro (1980) *Teoría de la medida en Psicología y Ciencias Sociales* sostiene que:

el hombre a lo largo de la historia ha perseguido, entre otras ilusiones, la de conocer, explicar y dominar las cosas. Ha solido empezar por las cosas «de fuera», desde las más inmediatas a las más recónditas, desde las tierras de cultivo, de las piezas de caza o la marcha periódica del sol, del alba al ocaso, hasta el código genético, el campo físico unificado y las partículas elementales. Suele continuar, luego, con las «cosas de dentro», con sus propias sensaciones, pensamientos y afectos, con su acción y su experiencia, con su conducta. Y en este empeño suele haber, al menos en la cultura occidental, desde los viejos maestros de la Grecia clásica hasta los físicos y psicólogos de nuestros días, la ambición, más o menos explícita, de aplicar la matemática para alcanzar un conocimiento exactamente formulado y precisamente verificable y, por ello, seguro y poderoso. (P. 8)

La Psicología tampoco ha escapado a este empeño. De hecho, la Psicología surge como disciplina científica solo cuando se demuestra que es posible medir lo mental, que es posible medir los fenómenos psicológicos en condiciones experimentales. No es casualidad que el primer libro de Psicología científica —*Elementos de Psicofísica*, de Fechner (1860)— se ocupe de la medida de los estímulos y de las sensaciones que éstos suscitan en los sujetos, junto con la relación matemática existente entre el estímulo y la sensación (la relación entre el mundo físico y el mundo mental). Se había puesto la primera piedra para construir el edificio científico de la Psicología, pero ¿ésta es realmente una ciencia?

Para dilucidar esta cuestión, hay que examinar la Psicología desde los dos ejes a través de los cuales se ha caracterizado a la ciencia: los objetivos que persigue y los medios que utiliza para lograrlos.

En relación a los **objetivos** de la ciencia —la comprensión del mundo y el subsiguiente control— Fidalgo (1999) plantea que:

la Psicología ha influido en los dos sentidos. Nuestra concepción de lo que es el hombre es muy diferente de la que tenían, por ejemplo, en el siglo XVIII; y una de las disciplinas que más ha modelado el pensamiento del hombre en el siglo XX es, sin lugar a dudas, la Psicología. Sin ir más lejos, podemos objetivarlo, de forma anecdótica pero bien signifi-

cativa, en la influencia que el psicoanálisis tuvo en la pintura (surrealismo), en la literatura o en el cine de los años cuarenta y cincuenta, llegando a convertirse en un ingrediente de lo que podemos denominar la cultura general del siglo xx. El componente tecnológico y económico de la Psicología también ha sido evidente. Se utiliza para la selección de personal y en campañas de propaganda y publicidad, a sus conocedores los poderes estatales les encargan el saneamiento de personas con distintas psicopatologías (desde la psicosis hasta la disidencia política), y un porcentaje elevado de la población acude a ellos para el tratamiento de las pequeñas manías, las queridas neurosis y depresiones de cada día, primavera o década. Éstas son sólo unas pocas, las más conocidas, de las parcelas prácticas que ocupan la Psicología. (Pp. 11-12)

Los **medios** con los que la Psicología trata de lograr los objetivos generales de la ciencia es harina de otro costal: la batalla por la cientificidad de la Psicología se libra en lo relativo al método empleado por ésta para abordar su objeto propio de estudio.

La constitución de la Psicología como ciencia independiente estuvo acompañada de una fuerte polémica o, en palabras de Pinillos (1988), de una grave contradicción fundacional: el *methodenstreit* o disputa del método. Muy brevemente, ésta puede ser resumida como sigue. La inmensa mayoría de los psicólogos pensaron que la ciencia era unitaria en lo relativo al método. Esto es, si la Psicología tenía que ser una ciencia, debía tomar el camino de la única ciencia que existía en ese momento: la Ciencia Natural. La mayoría decidió que lo que había sido bueno para las demás ciencias positivas también lo sería para la Psicología. Ahora bien, si el objeto de estudio propio que la Psicología reclama para sí es el mundo subjetivo, ¿cómo se puede abordar con éxito su estudio utilizando el método de las Ciencias Naturales, el método de la ciencia que es la antítesis de la subjetividad? No deja de ser curioso que justamente para hacer una ciencia de lo subjetivo la Psicología tuviera que decantarse por un modelo de ciencia que es antagónico con todo lo que huele a subjetivo.

En definitiva, la polémica se reduce a trabajar en las Ciencias del Comportamiento según el canon de las Ciencias Naturales (positivismo) o con un modelo distinto, en el que se acentúe la peculiaridad del objeto psicológico, sociohistórico y el modo de aproximación a él (hermeneútica, fenomenología, dialéctica, lingüística, etc.). Esta polémica ha atravesado por distintas etapas a lo largo del tiempo, pero ha conseguido sobrevivir hasta nuestros días.

1.5. LAS DISTINTAS MODALIDADES DEL MÉTODO CIENTÍFICO EN LA INVESTIGACIÓN PSICOLÓGICA

1.5.1. Tradiciones de investigación en Psicología

Acabamos de ver que los objetivos de la Psicología son los mismos que los que persigue la ciencia (describir, explicar, predecir y controlar la realidad) y que aquélla reclama para sí la utilización del método científico para abordar su objeto propio de estudio, la realidad psicológica, ya se conceptúe ésta en términos de estados de conciencia, de respuesta o conducta o de procesos mentales. Pues bien, para explicar la variabilidad de la conducta, para explicar por qué los seres humanos sentimos, percibimos y reaccionamos de forma diferente la Psicología ha apelado a:

- Las condiciones ambientales o estímulares en las que tiene lugar la conducta: no es lo mismo detectar en el radar la señal producida por un avión enemigo durante una contienda que identificar una señal de la misma intensidad durante el período de instrucción de ese mismo soldado.
- Las diferencias individuales, las diferencias que ineludiblemente existen entre los seres humanos: no reaccionarán de la misma forma ante el anuncio publicitario de un coche de lujo una persona con un alto poder adquisitivo y un parado de larga duración.

Según se cargue el acento en unas o en otras, tenemos dos orientaciones bastante diferentes vinculadas a dos tradiciones distintas de investigación en Psicología:

- La tradición manipulativo-experimental, con una clara orientación nomotética, es decir, cargando el acento más en el lado de las condiciones ambientales o estímulares que en las diferencias individuales y preocupada por encontrar leyes generales de la conducta que sean válidas para todos, para lo cual manipula experimentalmente las variables con el fin de ver cuál es el efecto causal que esto produce en otras variables.
- La tradición asociativo-correlacional, con una clara orientación idiográfica, es decir, cargando el acento más en el lado de las diferencias individuales que en las condiciones estímulares, preocupada de hecho por medir y evaluar las diferencias existentes entre personas y grupos y utilizando por vez primera técnicas estadísticas, al buscar fundamentalmente patrones de asociación, variación conjunta o concomitante entre las variables (de ahí la denominación de correlacional).

Este desdoblamiento refleja una dificultad epistemológica clásica que puede formularse como sigue: ¿cómo conciliar el carácter nomológico o legaliforme de los procesos con su irrepetible concreción individual? Murray (1938) refleja magistralmente la radical polivalencia del ser humano al afirmar que cualquier ser humano es:

- en algunos aspectos como todos los demás seres humanos,
- en algunos aspectos como algunos seres humanos,
- en algunos aspectos como ningún otro ser humano.

En suma, la Psicología recoge desde su misma fundación el debate sobre lo nomotético frente a lo idiográfico, si bien en lucha desigual, dado el carácter marcadamente nomotético de las Ciencias Naturales, canon a seguir por la Psicología para poder conseguir el preciado estatus científico.

En ambas orientaciones o tradiciones la medida es un prerequisite. En efecto, podemos medir o cuantificar los estímulos o los sujetos, esto es, podemos medir las propiedades o características de los estímulos tal y como los perciben los sujetos o, por el contrario, podemos medir las diferencias que existen entre los sujetos en determinados atributos o características. En cualquier caso, para poder describir y explicar regularidades entre estas características, sean del tipo que sean, es necesario obtener medidas de estas variables o características.

El capítulo 2 se dedica por completo a la medición en Psicología y el segundo bloque de este texto se ocupa en exclusiva de la construcción de instrumentos que nos permitan obtener medidas de estas variables, de la evaluación de su calidad métrica y de su aplicación y administración efectiva.

Si bien ambas tradiciones comparten el recurso a la medición como requisito previo, las hipótesis que formulan son diferentes y son también distintas sus preferencias por lo que respecta al tipo de diseño que utilizan en la investigación y a las técnicas estadísticas que habitualmente emplean para analizar los datos obtenidos en la misma. La figura 1.3 recoge esquemáticamente el planteamiento de ambas tradiciones, siguiendo de cerca la propuesta de Arnau (1995).

Como señala este autor, la diferencia fundamental entre ambos paradigmas a nivel de hipótesis es la asunción o no de relaciones causales entre las variables consideradas. En el paradigma experimental las hipótesis formuladas plantean la existencia de un efecto causal de una o más variables (denominadas habitualmente *variables independientes* o *causa*)




FIGURA 1.3. Tradiciones de investigación en Psicología.

en una o más variables (denominadas habitualmente *variables dependientes* o *efecto*), supuesto que se controlan adecuadamente todas las *variables extrañas*, con el fin de excluir la posibilidad de que otros factores puedan explicar los resultados obtenidos. Por ejemplo, se trataría de estudiar la eficacia de un programa de entrenamiento (variable independiente) en el nivel de deterioro del funcionamiento cognitivo (variable dependiente) en enfermos de Alzheimer controlando, entre otras variables, la fase de desarrollo de la enfermedad (variable extraña) en los pacientes. En el paradigma correlacional las hipótesis formuladas plantean la existencia de una variación conjunta o concomitante entre las variables, pero no una relación causa-efecto sino únicamente un patrón de variación correlativa entre ellas, un patrón de posibles relaciones de cambio entre las variables. Por ejemplo, se trataría de examinar las características más habituales que presentan los cuidadores/as de enfermos de Alzheimer.

A su vez, cada tipo de hipótesis lleva a trabajar con distintas modalidades del método científico. En particular, las hipótesis causales suponen normalmente el recurso a estudios de laboratorio donde se trabaja con un número reducido de variables en condiciones estrictamente controladas en las que el investigador manipula activamente la variable independiente o causa para ver cómo influye en la variable dependiente o efecto, tratando de controlar todas las posibles variables extrañas. Por consiguiente, las hipótesis causales conducen a la metodología experimental. Por su parte, las hipótesis de covariación llevan a la metodología no experimental; esto es, suponen el recurso a estudios de campo en los que habitualmente se recoge información acerca de un gran número de variables pero donde el grado de intervención del investigador en la

situación estudiada es mucho menor: no manipula variable alguna —simplemente observa y/o registra y mide— y no existe un control activo por parte del investigador de las posibles variables extrañas. En suma, la metodología experimental está especialmente indicada cuando el objetivo de la investigación es establecer relaciones causales mientras que la metodología no experimental es la apropiada cuando se trata de describir una gran cantidad de variables y de estudiar de forma intensiva y global un determinado fenómeno.

En los siguientes subapartados se caracterizan brevemente cada una de estas metodologías que, como puede observarse en la figura 1.3, llevan aparejados unos diseños de investigación específicos: los diseños experimentales y cuasi experimentales en la metodología experimental y los diseños de encuesta y los observacionales y cualitativos en la metodología no experimental.

El bloque tercero del texto se ocupa de las distintas modalidades del método científico en la investigación psicológica, dedicando un capítulo a cada una de estas metodologías.

Por último, no solo difieren las hipótesis formuladas y las metodologías y diseños empleados para someter a prueba dichas hipótesis sino que son también diferentes las técnicas de análisis de datos utilizadas en una y otra orientación o tradición. Habitualmente, los datos obtenidos en estudios que se enmarcan en la tradición experimental suelen ser analizados mediante una técnica conocida como análisis de la varianza, que permite determinar si las diferencias observadas empíricamente entre grupos de sujetos sometidos a distintas condiciones experimentales (distintos valores de la variable independiente) se deben exclusivamente al azar o si, por el contrario, tienen que ver realmente con la variable independiente o causa que el investigador ha manipulado en el estudio. Los datos obtenidos en estudios que se enmarcan en la tradición correlacional suelen ser analizados mediante técnicas correlacionales y mediante análisis de regresión, que nos indican hasta qué punto o en qué medida están relacionadas entre sí un conjunto de variables.

Estas técnicas serán objeto de estudio en la asignatura *Métodos de investigación en Educación*.

1.5.2. La metodología experimental

Como ya se indicó con anterioridad, todas las disciplinas comparten el método científico, si bien difieren en las estrategias concretas que utilizan para resolver los problemas que les son propios. Esto es, el método es común para todas las ciencias, pero éste adopta diferentes modalidades en las distintas disciplinas científicas, adaptándose así a las peculiaridades del objeto propio de estudio de cada disciplina en particular.

En el ámbito de la investigación psicológica se acaba de señalar que se dispone de la metodología experimental y de la no experimental. Tal como se adelantó en el subapartado anterior, la metodología experimental resulta particularmente útil para someter a prueba o contrastar hipótesis causales. ¿Por qué? Básicamente, por dos razones:

- El investigador modifica o manipula directamente la variable independiente o causa: por ejemplo, decide qué dosis va a administrar a distintos pacientes de SIDA de un nuevo fármaco todavía en fase experimental para observar su efecto.
- El investigador controla —o trata de controlar— todas las posibles variables que, sin ser la variable independiente o causa, pueden influir en la variable dependiente o efecto: por ejemplo, trabaja exclusivamente con pacientes que están en la misma fase de la enfermedad. De no ser así, es posible que la mejora experimentada por alguno(s) de los pacientes tenga que ver más con la fase de desarrollo de su enfermedad que con la dosis administrada del nuevo fármaco.

Pero falta por introducir todavía un elemento decisivo en el proceso para caracterizar a la metodología experimental: la aleatorización. Siguiendo con el ejemplo anterior, imaginemos que como investigadores disponemos de un grupo de pacientes con SIDA, todos ellos en la misma fase de la enfermedad, a los que se va a administrar distintas dosis de ese nuevo fármaco en fase experimental, con el fin de determinar cuál es la posología adecuada. Supongamos que se va a trabajar con cuatro dosis distintas: ninguna, baja, media y alta. Por consiguiente, habrá que formar cuatro grupos con el colectivo de pacientes disponibles para el estudio (digamos N). Una posible estrategia es asignar al grupo de dosis nula a los N/4 primeros pacientes que se apuntaron al programa experimental, a los N/4 siguientes en apuntarse los asignamos al grupo de dosis baja, a los N/4 siguientes al grupo de dosis media y a los N/4 últimos al grupo de dosis alta. En el supuesto de que el orden en el que se apuntan los pacientes tenga algo que ver con su motivación para curarse y en el supuesto de que ésta tenga algo que ver con la posible mejoría en el estado del paciente —supuestos ambos más que razonables—, entonces

es posible que el cambio operado en su estado de salud no se deba solo —o incluso no se deba en absoluto— a la dosis o cantidad en la que le ha sido administrado el medicamento sino que dicho cambio puede obedecer también al distinto nivel inicial de motivación que tenían los pacientes de uno y otro grupo. Este problema se puede evitar perfectamente si se asignan los pacientes de forma aleatoria a uno de los cuatro grupos, en lugar de hacerlo atendiendo al orden en el que se apuntan al programa experimental.

En resumen, éstas serían las tres características clave de la **metodología experimental**:

- La manipulación activa por parte del investigador de la variable independiente, causa o de tratamiento.
- El control de las variables extrañas.
- La asignación aleatoria de los sujetos a los grupos definidos por los distintos niveles de la variable independiente.

A pesar del enorme interés y de la conveniencia de asignar aleatoriamente a los distintos sujetos a los grupos de tratamiento, esto no siempre es posible o deseable.

Supongamos ahora que se desea comparar los efectos de este nuevo fármaco —llamémosle X— y del fármaco Y con el que se trata habitualmente a los pacientes. Supongamos también que disponemos ya de datos relativos a un grupo de pacientes tratados con el fármaco Y y que éstos se encuentran en la misma fase de la enfermedad que los pacientes que van a recibir el nuevo fármaco X. En este caso, no tiene sentido asignar aleatoriamente los sujetos a los grupos de tratamiento, ya que la composición de los mismos está ya previamente definida.

Cuando, por la razón que sea, el investigador no puede asignar aleatoriamente a los sujetos a los distintos grupos definidos por los niveles de la variable independiente y se ve abocado a realizar esta asignación atendiendo no al azar sino, por ejemplo, a las características de los sujetos, no se habla de experimento sino de cuasi experimento que, como acabamos de ver, sería sencillamente un experimento en el que la asignación de los sujetos a los grupos no se produce al azar. Es decir, la **metodología cuasi experimental** comparte las dos primeras características señaladas para la metodología experimental pero no la tercera, y la aleatorización constituye un elemento decisivo —no es el único, por supuesto— en el control de las fuentes extrañas de variación de la variable dependiente. Como tendrá ocasión de comprobar el lector en el capítulo 9, para someter a prueba una hipótesis causal es bastante más potente la metodología experimental que la cuasi experimental. De hecho, la función que cumple

la asignación aleatoria es precisamente repartir aleatoriamente entre los distintos grupos los efectos que las variables extrañas pueden tener en nuestra variable dependiente. El azar —como la muerte— sirve para homogeneizar, para eliminar diferencias no pertinentes entre grupos o, como en el caso de la muerte, entre personas.

1.5.3. La metodología no experimental

Como se indicó al hablar de las tradiciones de investigación en Psicología, la metodología no experimental no pone a prueba hipótesis causales. Cambiamos de escenario. Hay que retirar conceptos tales como variable dependiente, independiente, extraña, manipulación, control experimental y aleatorización. Las variables son ahora sencillamente variables que van a ser registradas o medidas por el investigador, sin más: no hay variables independientes que manipular ni variables extrañas que controlar experimentalmente ni tampoco hay asignación aleatoria de los sujetos a los grupos de tratamiento ya que éstos tampoco existen. El atrezo ahora es diferente: ésta es la metodología que se utiliza para describir las características —o, todavía mejor, algunas características— de una determinada población o para realizar un estudio comprensivo y global de un determinado fenómeno. En el primer caso se utiliza la metodología de encuestas y en el segundo básicamente la metodología observacional y cualitativa.

Las **encuestas** apenas si necesitan tarjeta de presentación dada su popularidad. Cuando se utiliza esta metodología, la información se registra o recoge a partir de las respuestas que da una muestra de sujetos o fracción de la población de interés (no se suele encuestar a todos los miembros de la población) a las preguntas formuladas en una entrevista o en un cuestionario. Desde la década de los treinta en los EE.UU. y bastante más recientemente en España, las encuestas se han instalado en nuestra vida cotidiana. ¿Quién no ha sido encuestado alguna vez? Si no es para la Encuesta de Población Activa (EPA), para los índices de audiencia de determinados programas o canales de televisión, o en algún sondeo electoral o de opinión. Si todavía el azar no ha llamado a su puerta y le ha solicitado su colaboración en una encuesta, probablemente sea solo cuestión de tiempo, dado que cada vez es mayor el número de millones de dólares —y de euros— invertido en realizar encuestas. ¿Y para qué? Tradicionalmente se han utilizado en la investigación de mercado para comprender las preferencias e intereses de los consumidores; en sondeos electorales para ver la tendencia al voto y pulsar la opinión y percepciones políticas con el fin de ayudar en las elecciones a los candidatos políticos y también en sondeos de opinión realizados por medios de comunicación

(sobre todo, periódicos y revistas) acerca de todo tipo de cuestiones de más o menos actualidad o supuesto interés general (recientemente, se ha acuñado el término *sondeocracia*). En un campo más próximo profesionalmente es preciso destacar el peso creciente de las encuestas educativas. Sirva como ilustración el hecho de que a mediados de los noventa se llevó a cabo una encuesta¹ en 40 países y a un total de medio millón de estudiantes, administrando cuestionarios no solo a los estudiantes sino también a sus profesores y a los directores de los centros escolares. En el capítulo 10 se presentará con algún detalle esta metodología y se la acercará al ámbito de actuación del futuro psicopedagogo.

A diferencia de las encuestas, la metodología observacional y la cualitativa trabajan con un número mucho menor de sujetos y se centran en el estudio intensivo y en la comprensión global de un determinado fenómeno o cuestión.

La **metodología observacional** se utiliza para describir fenómenos que ocurren en ambientes naturales, esto es, la fuente principal y directa de los datos son las situaciones naturales y el investigador su principal instrumento de recogida (Anguera, 1995); por ejemplo, para describir la conducta agresiva y la conducta cooperativa de los niños en el recreo, la conducta preverbal, las interacciones familiares, etc. Desde la década de los ochenta, los estudios basados en la observación del individuo en contextos naturales están adquiriendo un mayor protagonismo, en parte relacionado con los espectaculares avances tecnológicos, informáticos y audiovisuales que han tenido lugar en estas dos últimas décadas y que facilitan notablemente las tareas de registro sistemático de la conducta. Dentro de la metodología observacional, el método clínico o estudio de casos es de particular relevancia en la investigación psicológica. Consiste en el estudio minucioso y pormenorizado de casos individuales y ha sido utilizado en diversos ámbitos de la Psicología (no solo en la clínica) por investigadores del prestigio de Piaget o de Luria, por no mencionar a Freud. El capítulo 11 se dedica en exclusiva a la metodología observacional.

Como ya se ha ido apuntando a lo largo del capítulo, la Psicología surge como ciencia tratando de emular a la Ciencia Natural y adoptando como propio el método de ésta. Por tanto, a nadie ha de extrañar que los métodos digamos cuantitativos hayan ejercido de forma casi exclusiva el control del monopolio de la producción del conocimiento en la investigación psicológica. A pesar de ello, hay prácticas cualitativas como los

¹ TIMSS *Third International Mathematics and Science Study* (Tercer Estudio Internacional de Matemáticas y Ciencias), realizado bajo los auspicios de la *International Association for the Evaluation of Educational Achievement* (IEA).

grupos de discusión y las entrevistas en profundidad que cuentan con una larga tradición en la investigación social. Bajo la etiqueta de **metodología cualitativa** se encuadra un conjunto de técnicas interpretativas que lo que tratan es de describir, decodificar y traducir un fenómeno que ocurre de forma más o menos natural en el mundo social y que, por lo demás, están más orientadas hacia el significado del fenómeno en cuestión (cualidad) que hacia su frecuencia o cuantificación (cantidad) (van Maanen, 1983). La viñeta adjunta se ha realizado a partir de la situación recreada en la primera página del libro editado por el autor anterior sobre metodología cualitativa: se describe la situación desarrollada en un seminario parodiando la perspectiva adoptada por un cualitativista y por un cuantitativista.



Como tendrá ocasión de comprobar el lector en el capítulo 12, no es que la metodología cualitativa excluya el uso del principio científico del empirismo, pero sí es cierto que los investigadores cualitativos consideran los fenómenos sociales no tanto como algo perfectamente replicable y claramente definido sino como algo más particular, menos delimitado o cerrado: defienden la existencia de relaciones abiertas, no tanto unívocas y denotativas como los cuantitativistas sino multívocas y polisémicas. Cada una de estas metodologías responde a una lógica diferente y produce y analiza informaciones de distinta índole. En el capítulo 12 se abordará la «escisión y división profunda entre las técnicas y técnicos que usan las herramientas cuantitativo-estadísticas y cualitativas en la investigación social» (Conde, 1990, p. 92), defendiéndose la necesaria complementariedad entre ambas metodologías; asimismo, se realizará una presentación general de las técnicas encuadradas dentro de la metodología cualitativa, centrándose fundamentalmente en las dos técnicas anteriores (grupos de discusión y entrevistas en profundidad) y en una técnica mucho más reciente y que se sitúa en un espacio intermedio entre las dos anteriores (los grupos triangulares).

1.6. LA PLANIFICACIÓN DE UNA INVESTIGACIÓN

Como se indicó en el apartado 1.3, el método científico proporciona una forma de actuar mediante operaciones ordenadas que orientan la investigación hacia los fines de la ciencia, a través de una serie de fases interdependientes entre sí. En ese apartado se definieron los tres momentos principales en la forma de operar del método científico —planteamiento de problemas, formulación de hipótesis y contrastación empírica de dichas hipótesis— y en este apartado se van a concretar esas fases interdependientes a través de las que opera el método científico (véase la figura 1.4). Para ilustrar estas fases, vamos a tomar un ejemplo de un campo que desgraciadamente tiene una gran actualidad para los profesionales de la Psicología: la intervención psicológica en desastres.




FIGURA 1.4. Secuencia de fases interdependientes a través de las que opera el método científico.

Desde la riada del camping de Biescas en 1996, la intervención psicológica en desastres ha sido una constante. La revista *Papeles del Psicólogo* dedicó un número monográfico a la cuestión en 1997 (número 68); asimismo, existe desde 1998 un grupo de intervención psicológica en emergencias y desastres en el Colegio Oficial de Psicólogos.

A nadie escapa la importancia que pueden tener en los afectados por este tipo de situaciones las consecuencias psicopatológicas y sociales

que pueden producir las catástrofes. La Organización Mundial de la Salud ya ha identificado varios síndromes, entre ellos, el síndrome del superviviente, caracterizado por irritabilidad, ira y agresión, que aumentan en los años siguientes al desastre, y también por desórdenes físicos como hipertensión, cefaleas tensionales y trastornos gastrointestinales, entre otros. Un aspecto llamativo es que la tasa de mortalidad se incrementa de forma notable entre los supervivientes que son familiares de víctimas mortales, sobre todo, en el año siguiente a la catástrofe. Podríamos plantearnos realizar una investigación sobre este síndrome. Se podría estudiar, por un lado, la incidencia del síndrome y la tasa de mortalidad entre los supervivientes a catástrofes. Por otro lado, se podría investigar si estas dos tasas varían con las características de personalidad de los sujetos. Esta información podría ser de gran interés porque puede orientar o dar pistas acerca del tipo de intervención al que hay que someter a un sujeto tras una situación de emergencia. Por consiguiente, el **problema** a investigar sería la cuantificación y cualificación de la incidencia del síndrome de supervivencia y de la tasa de mortalidad entre los afectados por situaciones de emergencia al año del desastre.

Una vez planteado el problema, hay que tratar de resolverlo. Enunciado el problema, el investigador debe ofrecer una serie de conjeturas como soluciones tentativas en forma de **hipótesis**. En este caso se podrían formular las dos hipótesis siguientes:

HIPÓTESIS 1: La incidencia del síndrome del superviviente entre los afectados por una situación de emergencia o catástrofe varía con las características de personalidad de los sujetos.

HIPÓTESIS 2: La tasa de mortalidad entre los afectados por una situación de emergencia o catástrofe varía con las características de personalidad de los sujetos.

Como podrá observar el lector, las dos hipótesis formuladas se plantean si la incidencia del síndrome del superviviente y la tasa de mortalidad covarían, varían con las características de la personalidad de los afectados por una catástrofe. Es decir, la investigación plantea una hipótesis de covariación y no una hipótesis causal. Esto significa que habrá que optar por la **metodología** no experimental, particularmente adecuada para este tipo de hipótesis (véase el subapartado 1.5.1), mientras que la metodología experimental no sería aplicable (observe el lector que ninguna de las variables de las hipótesis es susceptible ni de manipulación activa por parte del investigador ni tampoco es posible la asignación aleatoria de los sujetos a los grupos). Dentro de la metodología no experimental, se puede optar por la metodología de encuestas, observacional, cualitativa o alguna combinación de ellas. Dado el objetivo que persigue la investigación, se podría utilizar una estrategia com-

binada de metodología de encuestas y cualitativa (la aplicación de la metodología observacional —posible pero costosa— supondría disponer de un conjunto de observadores entrenados que tendrían que observar a una muestra representativa —y numerosa— de supervivientes en distintos momentos del día y situaciones). En particular, se podrían realizar algunas entrevistas en profundidad y grupos triangulares con supervivientes de catástrofes con el fin de ver la forma en la que éstos perciben y valoran su experiencia y para identificar los posibles perfiles y los matices más importantes de la cuestión investigada. El análisis del discurso y de los contenidos surgidos en estos grupos y entrevistas puede servir como fuente de información para diseñar la entrevista o el cuestionario que se utilizará posteriormente en la encuesta a una muestra de supervivientes.

Formuladas las hipótesis, habrá que ver si éstas son o no plausibles, habrá que someterlas a prueba para comprobar su verosimilitud como posible explicación al problema planteado. Para someter a prueba o contrastar empíricamente una hipótesis, lo primero que hay que hacer es **definir de forma operativa las variables implicadas en la hipótesis**, esto es, hay que definir las de modo que podamos trabajar con ellas.

Son tres las variables implicadas en las hipótesis:

— El síndrome del superviviente

Se trata de una variable dicotómica, es decir, con solo dos valores posibles: presencia o ausencia del síndrome.

Para definirla operativamente, podemos atender a las manifestaciones conductuales del síndrome, a sus manifestaciones fisiológicas o a ambas.

Supongamos que nos circunscribimos exclusivamente a las manifestaciones conductuales anteriormente citadas.

— Las características de personalidad

Supongamos que el modelo de personalidad adoptado en la investigación es la teoría de los cinco grandes factores, que define una estructura pentafactorial de la personalidad con los siguientes factores: neuroticismo, extraversión, apertura, amabilidad y responsabilidad.

— La mortalidad

Se trata también de una variable dicotómica con dos valores posibles cuya definición operativa no plantea problema alguno al investigador.

Una vez definidas las variables de forma que podamos operar con ellas, el paso siguiente en la investigación será obtener medidas de esas variables, habrá que proceder a **medir las variables de las hipótesis**:

— El síndrome del superviviente

Se puede medir a través de las respuestas dadas por una muestra de supervivientes a los ítems o preguntas de un cuestionario, test o escala, esto es, de un instrumento de medida diseñado para determinar si un sujeto manifiesta o no las características conductuales a partir de las cuales ha sido definido operativamente este síndrome en la investigación en curso.

El capítulo 3 se dedica en exclusiva a la construcción de instrumentos de medida.

Antes de proceder a la construcción de dicho instrumento de medida, conviene comprobar si en el mercado —o en la literatura— existe ya algún instrumento —comercializado o no— que mida la variable que se desea medir en esta investigación.

La aplicación del cuestionario a la muestra de supervivientes resultará bastante menos gravosa que la entrevista individual a estos sujetos.

— La personalidad

Dado que el modelo adoptado para conceptualizar la personalidad es el de los cinco grandes factores, parece apropiado utilizar el instrumento de medida desarrollado para estos factores: el cuestionario NEO-PI-R (Costa y McCrae, 1992).

— La mortalidad

Para medir esta variable basta con comprobar si se ha producido la defunción en el período de interés.

Cuando ya se han seleccionado o construido los instrumentos —cuestionarios, pruebas, tests, escalas— que nos van a permitir obtener medidas de las variables de las hipótesis, el paso siguiente en el proceso supone garantizar que se está trabajando con instrumentos adecuados, esto es, hay que comprobar que los instrumentos utilizados para medir esas variables cumplen los requisitos mínimos de calidad que todo instrumento científico debe satisfacer para poder ser utilizado con garantía.

¿Cuáles son esos requisitos o criterios métricos de calidad que todo instrumento ha de satisfacer? Son dos: fiabilidad y validez. Se dice que un instrumento es fiable si proporciona medidas precisas de la variable que mide; se dice que un instrumento es válido si proporciona medidas de la variable que pretende medir. En el caso que nos ocupa, tenemos que garantizar que el cuestionario diseñado para medir el síndrome del superviviente mide realmente ese síndrome y no el síndrome de estrés post-traumático o el síndrome de aflicción por catástrofe (validez) y que la medida obtenida para el síndrome del superviviente es una medida precisa y estable, razonablemente libre de error de medida (fiabilidad). Ahora bien, no basta con examinar la calidad métrica **global** de las pruebas utilizadas (su fiabilidad y validez), es preciso también examinar la calidad **individual** de todos y cada uno de los elementos o ítems que integran esas pruebas o cuestionarios. Para ello, hay que realizar el correspondiente análisis de los ítems del test. Por consiguiente, es preciso **evaluar la calidad métrica de los instrumentos** utilizados para medir las variables de las hipótesis y hay que hacerlo considerando tanto el instrumento en su conjunto (fiabilidad y validez del test) como en términos de los ítems o preguntas que lo integran (análisis de ítems).

Los capítulos 6 y 7 abordan los dos indicadores de la calidad métrica global del test. El capítulo 8 se ocupa del análisis de la calidad métrica de cada pregunta del test, del análisis de ítems.

Seleccionados y evaluados los instrumentos con los que medir, habrá que seleccionar a los sujetos a los que hay que aplicar dichos instrumentos para obtener las medidas de las variables de las hipótesis; en nuestro caso, habrá que **seleccionar una muestra** de supervivientes de catástrofes y situaciones de emergencia para pasar seguidamente a la **recogida de datos**, en el marco de un diseño que permita dar respuesta al problema que suscitó la investigación y acorde lógicamente con la hipótesis formulada. El diseño es un plan de acción orientado a la obtención de datos apropiados a las hipótesis de trabajo.

Los capítulos del bloque tercero del texto presentan los diseños más utilizados en cada una de las metodologías.

Una vez recogidos los datos, solo restaría analizarlos: pasaríamos, por tanto, a la fase de **análisis de los datos** que, como no puede ser de otro modo, es también dependiente del problema planteado en la inves-

tigación y de la hipótesis formulada como solución tentativa al problema. Dicho de otro modo, el análisis de los datos obtenidos en una investigación hay que hacerlo siempre en función de los objetivos de la misma. En esta fase suele ser necesario el concurso de la estadística. ¿Por qué? De nuevo son dos las razones:

1. Permite representar las distintas medidas obtenidas por un grupo de sujetos mediante un índice estadístico (por ejemplo, la media, la mediana, la moda) que describe de forma resumida y en un único valor el conjunto de medidas. Éste es el cometido de la estadística descriptiva.

En nuestro caso, para cuantificar la incidencia del síndrome estudiado habría que ver cuál es la proporción de personas que manifiestan las características conductuales propias del síndrome en la muestra examinada de supervivientes de catástrofes, información recabada en las respuestas de estos sujetos al cuestionario que mide este síndrome.

2. Permite decidir si los resultados obtenidos confirman las hipótesis o si, por el contrario, éstos pueden explicarse por variaciones casuales entre los sujetos. Éste es el cometido de la estadística inferencial.

En nuestro caso, podemos encontrarnos con que la proporción de afectados por el síndrome entre los sujetos extrovertidos es del orden de 0,30 mientras que entre los sujetos introvertidos ésta se eleva hasta 0,55. La estadística inferencial nos ayudará a decidir si esa diferencia es real o es fruto simplemente del error aleatorio. Es decir, tras realizar una prueba de significación estadística estaremos en condiciones de afirmar que la diferencia observada entre esas dos proporciones responde a una incidencia significativamente distinta del síndrome del superviviente entre sujetos extrovertidos e introvertidos o de afirmar que esa diferencia desaparecería si se tomara una muestra diferente de sujetos o si se midiera a esos mismos sujetos en otra ocasión.

En la asignatura *Métodos de investigación en Educación* se abordarán las distintas técnicas de análisis de datos.

Una vez analizados los datos, se puede ya proceder a **interpretar los resultados**, es decir, hay que ver si los datos proporcionan o no evidencia favorable a las hipótesis formuladas como soluciones tentativas al pro-

blema que suscitó la investigación. En caso negativo, es necesario proponer soluciones alternativas al problema, formular nuevas hipótesis que deberán ser también empíricamente contrastadas.

El hecho de haber presentado todas las fases a través de las que opera el método científico de forma secuencial y lineal no debe inducir a error al lector. Si bien la distancia más corta entre dos puntos es la línea recta, eso no quiere decir que sea ése siempre el camino recorrido, ni siquiera que sea el mejor camino. El modo de operar en la investigación científica no puede ser concebido como una sucesión ordenada de pasos *fijos* (otra cosa es que una presentación didáctica del asunto suponga hacer una presentación ordenada de una serie consecutiva de pasos) sino como un conjunto de pasos o etapas interdependientes e interrelacionadas por las que se va avanzando y retrocediendo continuamente (Babbie, 1990). Como indica Meliá (1990), «solo en la reflexión sobre el trabajo puede encontrarse tanta linealidad y distinción en las fases y niveles de análisis» (p. 100).

MC Ejemplo de aplicación del método científico

1.7. PUNTOS BÁSICOS

- El problema de la demarcación de la ciencia consiste en diferenciar lo que es científico de lo que no lo es y, para ello, el criterio que se utiliza es si la disciplina en cuestión utiliza o no el método científico a la hora de responder a los problemas que son su objeto propio de estudio.
- Los objetivos de la ciencia son describir, explicar, predecir y controlar.
- Los tres momentos principales en la forma de operar del método científico son el planteamiento de problemas, la formulación de hipótesis como soluciones tentativas al problema que suscitó la investigación y la contrastación empírica de dichas hipótesis con el fin de determinar su plausibilidad como posible explicación al problema en cuestión.
- El método científico proporciona una forma de actuar mediante operaciones ordenadas que orientan la investigación hacia los fines de la ciencia, a través de una serie de fases interdependientes entre sí.

- Todas las disciplinas comparten el método científico, si bien difieren en las estrategias concretas que utilizan para resolver los problemas que les son propios.
- La Psicología surge como disciplina científica solo cuando se demuestra que es posible medir lo mental: surge como ciencia tratando de emular a la Ciencia Natural y adopta como propio el método de ésta.
- Existen dos tradiciones distintas de investigación en Psicología —la tradición experimental y la tradición correlacional— cada una particularmente adecuada para someter a prueba distintos tipos de hipótesis, asociadas a distintas metodologías y diseños de investigación y vinculadas a técnicas diferentes de análisis de datos.
- La metodología experimental se caracteriza por la manipulación activa por parte del investigador de la variable independiente, causa o de tratamiento, el control de las variables extrañas y la asignación aleatoria de los sujetos a los grupos definidos por los distintos niveles de la variable independiente.
- La metodología cuasi experimental comparte con la metodología experimental todas las características anteriores a excepción de la tercera.
- La metodología no experimental se utiliza para describir algunas características de una determinada población o bien para realizar un estudio comprensivo y global de un fenómeno. En el primer caso se utiliza la metodología de encuestas y en el segundo básicamente la metodología observacional y cualitativa.
- En las encuestas la información se registra o recoge a partir de las respuestas que da una muestra de sujetos a las preguntas formuladas en una entrevista o cuestionario.
- En la metodología observacional la fuente principal y directa de los datos son las situaciones naturales y el investigador su principal instrumento de recogida.
- La metodología cualitativa consiste en un conjunto de técnicas interpretativas que tratan de describir, decodificar y traducir un fenómeno que ocurre de forma más o menos natural en el mundo social y están más orientadas hacia el significado del fenómeno en cuestión que hacia su frecuencia o cuantificación.

1.8. EJERCICIOS

1.8.1. Indique mediante flechas qué características se maximizan con cada una de las técnicas metodológicas de la columna de la izquierda:

Experimento	
Observación	Realismo
Encuesta	Representatividad
Cuasi experimento	Control
M. cualitativa	

1.8.2. A continuación se reproduce un artículo publicado por el diario *El País* el día 3 de julio de 2000.

¿Cuál es la variable dependiente? ¿Y la variable independiente? ¿Qué niveles puede adoptar la variable independiente? ¿Qué variables podrían actuar como variables extrañas en esta investigación?

1.8.3. Empareje las técnicas metodológicas de la columna de la izquierda con las características recogidas en la columna de la derecha:

Experimento	Significado
Observación	Situaciones naturales
Encuesta	Control de variables extrañas
Cuasi experimento	Asignación aleatoria
M. cualitativa	Muestra numerosa y representativa de sujetos

1.8.4. En la figura 1.4 se plantea una secuencia con las operaciones ordenadas a través de las cuales opera el método científico cuando se realiza una investigación. Esta secuencia de operaciones o fases no es fija: el investigador no tiene por qué proceder de la primera a la última fase en ese orden necesariamente. Ahora bien, hay algunas fases que siempre deben de aparecer en el orden indicado en la figura.

- ¿Qué fases son esas?
- ¿Qué fases se pueden mover en ese esquema?
- La elección u adopción de una metodología particular condiciona la forma de operar en algunas de las fases posteriores recogidas en la figura. ¿En cuáles?

España participa en un gran ensayo mundial de tratamiento del sida

El estudio parte de los Institutos Nacionales de la Salud (EE UU)

GABRIELA CAÑAS, Madrid

Trescientos enfermos españoles entrarán de aquí a octubre en un gran ensayo mundial que probará los efectos clínicos de la interleukina en personas infectadas. Un especialista del hos-

pital Gregorio Marañón de Madrid, Juan Carlos López Bernaldo de Quirós, será el coordinador español de este estudio que aporta una nueva esperanza a los enfermos mitigando quizá las complicaciones colaterales del sida.

La interleukina-2 es una proteína natural que induce la proliferación de linfocitos CD4, justo los que pierden dramáticamente los enfermos de sida. Ya se ha comprobado que esta proteína ayuda a recuperar el nivel de esos linfocitos, pero es necesario comprobar si su administración a los enfermos tiene efectos positivos. Esto es lo que va a intentar probar el estudio llamado ESPRIT (Evaluation of Subcutaneous Proleukin in a Randomized International Trial) en 4.000 enfermos en todo el mundo, de los cuales 300 serán españoles. Es uno de los ensayos más amplios sobre el sida que se han emprendido hasta ahora.

Dado que la escasez de los linfocitos CD4 en el sistema inmune es lo que facilita que los enfermos de sida sufran las llamadas infecciones oportunistas (neumocistosis, citomegalovirus, candidiasis, neumonía y tuberculosis, entre otras), se espera que la interleukina-2 (IL-2) mejore la situación general de los infectados. Para López Bernaldo de Quirós, el ensayo, en el que participarán 22 hospitales españoles, es entusiasmante. Primero, porque ha habido un largo camino previo hasta recibir la luz verde para participar en el ensayo. Segundo, porque éste no es un ensayo comercial, sino capitaneado por los prestigiosos Institutos Nacionales de la Salud (NIH), centros de investigación pública de EE UU.

"Durante los últimos 15 años varios equipos de investigadores, principalmente del grupo de Clifford Lane, perteneciente a los NIH, han trabajado con éxito en el tratamiento con IL-2 en pacientes con sida", explica López Bernaldo de Quirós. "El siguiente paso es comprobar si esa elevación en los linfocitos CD4 se traduce en un beneficio clínico para el enfermo".

Los pacientes incluidos en el ensayo, que apoya también la



Tratamiento de enfermos del sida en un hospital de Madrid. / GORKA LEJARCEGI

secretaría del Plan sobre el Sida español, seguirán recibiendo su terapia retroviral de siempre, al tiempo que recibirán por vía subcutánea la proteína IL-2 cuya patente tienen los NIH y que sólo se fabrica en EE UU. La IL-2 se suministrará en ciclos de cinco días por semana descansando luego durante siete semanas. El ensayo durará de cuatro a cinco años, aunque los pacientes serán evaluados cada cuatro meses. "En ningún caso", dice el investigador español, "se recomienda la IL-2 sola".

En el ESPRIT interviene también como coordinador Eduardo Fernández-Cruz, igualmente del Gregorio Marañón. Fernández-Cruz ya lleva tres años ensa-

yando en España la vacuna terapéutica (para personas ya infectadas) llamada Remune y, además, va a acometer un subestudio de ESPRIT consistente en probar la IL-2 junto a dicha vacuna para comprobar si de esa manera se logra una vacuna más potente y eficaz (véase EL PAÍS del 19 de mayo pasado).

¿Está España alcanzando el tren de la investigación? No lo cree López Bernaldo de Quirós: "El problema es que no hay dinero para investigar y en sida, desde luego, carecemos de investigación básica. Como mucho, me atrevería a decir que en investigación clínica estamos aportando algo y quizá estamos saliendo del túnel".

1.8.5. Indique mediante flechas qué características definen a la tradición experimental y cuáles a la tradición correlacional:

	Diferencias individuales
	Orientación nomotética
Tradición experimental	Hipótesis de covariación
	Búsqueda de leyes generales
Tradición correlacional	Orientación idiográfica
	Condiciones estimulares
	Hipótesis causales

1.8.6. Piense en una situación relacionada con su propio ámbito laboral, familiar o personal en la que pueda utilizar la metodología experimental para dar respuesta a un problema de su interés y en otra situación en la que tenga que utilizar la metodología no experimental.

1.9. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

1.9.1. Experimento y cuasi experimento → Control. **Observación y M. cualitativa** → Realismo. **Encuesta** → Representatividad.

La potencia de la metodología experimental (experimentos y cuasi experimentos) radica en el control que se ejerce gracias en buena parte a la aleatorización (solo en los experimentos), pero es débil en lo relativo a su representatividad, carece de naturalidad en la medición y no alcanza la profundidad de información que se logra con la metodología observacional y cualitativa. La encuesta enfatiza la generalizabilidad merced a su representatividad de la población de interés pero lo hace en menoscabo del control. Por su parte, la metodología observacional y cualitativa maximizan el realismo del contexto pero disminuye la generalización más allá de la situación específica que se está analizando y, sobre todo, disminuye el control de variables.

1.9.2. Variable dependiente: Efectos o mejoría clínica en el estado del paciente. **Variable independiente:** Administración de la IL-2. **Niveles de la variable independiente:** (1) No se administra la IL-2, (2) se administra la IL-2 y (3) se administra la IL-2 junto con la vacuna terapéutica Remune. **Variables extrañas:** Fase de la enfermedad, tipo de paciente (hospitalizado o externo), número de años con la enfermedad, etc.

1.9.3. Experimento: Asignación aleatoria y Control de variables extrañas. **Observación:** Situaciones naturales. **Encuesta:** Muestra numerosa y representativa de sujetos. **Cuasi experimento:** Control de variables extrañas. **M. Cualitativa:** Significado.

1.9.4.

- A. El planteamiento de un problema, la formulación de una hipótesis y la interpretación de los resultados.
- B. La definición operativa de las variables de la hipótesis (podría subir un nivel) y la selección de la muestra de sujetos (podría ponerse en la figura en paralelo con la definición operativa de las variables de la hipótesis).
- C. La medición de las variables de la hipótesis, la selección de la muestra de sujetos, la recogida y el análisis de los datos.

1.9.5. Tradición experimental → Orientación nomotética, Búsqueda de leyes generales, Condiciones estimulares e Hipótesis causales. **Tradición correlacional** → Diferencias individuales, Hipótesis de covariación y Orientación idiográfica.

1.9.6. A título de ejemplo, se podría utilizar la **metodología experimental** para estudiar la eficacia de un programa de reducción de la ansiedad de los estudiantes ante los exámenes y la **metodología no experimental** para estudiar el perfil del alumnado de la UNED en los centros penitenciarios.

1.10. BIBLIOGRAFÍA BÁSICA RECOMENDADA

ARNAU, J. (1995). Metodología de la investigación psicológica. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.

El capítulo introduce al lector en la lógica de la investigación científica; presenta las dos tradiciones de investigación en Psicología y aborda las distintas metodologías utilizadas en la investigación psicológica.

ATO, M. (1991). *Investigación en Ciencias del Comportamiento. I. Fundamentos*. Barcelona: PPU. Capítulos 3 y 4.

Desarrolla con detalle algunas de las fases de una investigación, en particular, el planteamiento del problema y la formulación de hipótesis.

DELGADO, A. R. y PRIETO, G. (1997). *Introducción a los métodos de investigación de la Psicología*. Madrid: Pirámide.

Libro breve y sencillo que aborda una buena parte de las metodologías introducidas en el capítulo y también la planificación y desarrollo de la investigación científica.

MELTZOFF, J. (2000). *Crítica a la investigación. Psicología y campos afines*. Madrid: Alianza.

Libro claro y didáctico organizado en dos partes. En la primera se revisan todas las fases implicadas en la realización de una investigación. En la segunda se propone un conjunto de 16 artículos ficticios creados por el autor y con errores que el lector debe detectar, si bien cada artículo va seguido de un comentario del autor donde se señalan una buena parte de ellos.

1.11. LECTURAS SUGERIDAS

ARNAU, J. y BALLUERKA, N. (1998). *La Psicología como ciencia: Principales cambios paradigmáticos y metodológicos*. San Sebastián: Erein.

En 100 páginas justas se hace un recorrido por los tres períodos en los que los autores dividen los poco más de 100 años de historia de la Psicología científica y en cada período abordan las principales estrategias de investigación utilizadas —perspectiva metodológica— y su forma particular de concebir la ciencia —perspectiva metateórica— si bien la obra se centra fundamentalmente en los problemas metodológicos de los distintos paradigmas.

CRONBACH, L. J. (1957). The two disciplines of scientific psychology. *American Psychologist*, 12, 671-684. (Traducción española en Alvira, F., Avia, M. D., Calvo, R. y Morales, J. F. (1979). *Los dos métodos de las Ciencias Sociales*. Madrid: CIS.)

CRONBACH, L. J. (1975). Beyond the two disciplines of scientific psychology. *American Psychologist*, 30, 1-14. (Traducción española en Alvira, F., Avia, M. D., Calvo, R. y Morales, J. F. (1979). *Los dos métodos de las Ciencias Sociales*. Madrid: CIS.)

Se trata de dos artículos emblemáticos en los que el autor critica la separación entre las dos tradiciones de investigación en Psicología y señala la necesidad de su integración.

MAYOR, J. (1989). EL método científico en Psicología. En J. Arnau y H. Carpintero (Coords.) *Historia, teoría y método*. Madrid: Alhambra.

Ofrece un tratamiento en profundidad de la cuestión del método en la Psicología. No solo aborda todo lo relativo al método científico positivo sino que plantea alternativas metodológicas a la Psicología como ciencia positiva (el método fenomenológico, el hermenéutico, el estructuralista y el dialéctico) y hace unas interesantes reflexiones acerca de la tensión dialéctica que sufre la Psicología —por lo que respecta al método con el que abordar su objeto propio de estudio— entre la unidad y la diversidad metodológica.

RODRÍGUEZ SUTIL, C. (1998). La metodología de investigación frente a la metodología aplicada. *Papeles del Psicólogo*, 70, 59-63.

El autor realiza en este trabajo un interesante tratamiento de la precisión de la esterilidad, esta vez en el plano de la metodología de la investigación aplicada y de la investigación académica, considerando la difícil situación del psicólogo profesional que se encuentra entre una práctica habitualmente tachada de acientífica y una investigación ortodoxa pero estéril. El autor propone una solución a este conflicto y reivindica el «regreso al caso clínico como fuente primaria de elaboración del conocimiento en Psicología» (p. 60).

SOKAL, A. y BRICMONT, J. (1999). *Imposturas intelectuales*. Barcelona: Paidós.

Este libro supone una llamada de atención para no dejarnos deslumbrar por el sofisticado aparataje científico. En él se desenmascara a figuras notorias del psicoanálisis, la sociología, la filosofía, etc.

YELA, M. (1994). El problema del método científico en Psicología. *Anuario de Psicología*, 60, 3-12.

Es la conferencia inaugural del curso 1993-1994 que pronunció el profesor Yela en la Universidad de Barcelona. Con un lenguaje bastante literario, se plantean las limitaciones generales del método científico y los límites del mismo en el ámbito de la Psicología.

1.12. MATERIAL COMPLEMENTARIO

- Los objetivos de la ciencia.
- Estructura del método científico-positivo.
- La disputa del método.
- Ejemplo de aplicación del método científico.

LA MEDICIÓN DE LO PSICOLÓGICO

María José Navas Ara

2.1. INTRODUCCIÓN

El carácter central que desempeña la medición en la ciencia queda claramente de manifiesto en la siguiente idea de Cattell: la historia de la ciencia es la historia de la medida. De hecho, acabamos de ver que la Psicología surge como ciencia solo cuando demuestra que es posible *medir* lo psicológico, y lo cierto es que la Psicometría (*metría* de la *psique*) está en la base misma del surgimiento de la Psicología como ciencia. Sin embargo, el estatus científico de la Psicología ha sido objeto de un largo y controvertido debate. En el capítulo anterior se examinaba el asunto tomando como ejes el método de la ciencia (el método científico-positivo propio de las Ciencias Naturales) y los objetivos de la ciencia (describir, explicar, predecir y controlar). En este capítulo retomaremos estos dos ejes 1) para mostrar cómo la adopción del método científico-positivo condujo a la Psicología en particular y a las Ciencias Sociales en general a un callejón sin salida, por lo que al tema de la medición se refiere, y 2) para ilustrar el papel absolutamente fundamental que juega la medición en la descripción y explicación (y, por ende, en la predicción y control) de los fenómenos psicológicos.

Para ello, después de revisar rápidamente en el segundo apartado la cuestión de la necesidad de la medición psicológica, esto es, del por qué y para qué es importante medir, se introducirá de lleno al lector en la cuestión de su posibilidad, que nos llevará al callejón del que antes se hablaba y del que se proporcionarán dos salidas diferentes: la medición por índices y la teoría de las escalas de medida de Stevens. Una vez establecida la necesidad y la posibilidad de la medición psicológica, en el cuarto apartado se definirá ésta y se pondrá en relación con los objetivos de la ciencia, realizándose también la presentación de las principales dificultades metodológicas a la que ésta se enfrenta.

Un tercer eje para examinar la madurez científica de una disciplina es el grado en el que se pueden medir de forma precisa y objetiva las varia-

bles relevantes en esa disciplina (Hopkins, 1998). En el último apartado del capítulo se hacen algunas consideraciones en relación al estatus y a la calidad métrica de los instrumentos que nos permiten obtener medidas de variables psicológicas; asimismo, se tratará de introducir algo de luz en la maraña de términos que se utilizan para denominar a los instrumentos de medida psicológica y al proceso mismo de medir y, por último, se proporcionará una clasificación de éstos.

En el siguiente diagrama se presenta un esquema-resumen con los contenidos que se van a desarrollar en el capítulo, que giran en torno a los siguientes interrogantes:

¿Por qué es importante medir?	➔	NECESIDAD
¿Es posible medir lo psicológico?	➔	POSIBILIDAD
¿Qué significa realmente medir lo psicológico?	➔	DEFINICIÓN
¿Con qué se mide lo psicológico?	➔	INSTRUMENTOS DE MEDIDA

Los objetivos que se persiguen en este capítulo son los siguientes:

- reflexionar sobre la necesidad y la posibilidad de medir lo psicológico, lo que no es directamente observable;
- ofrecer una panorámica general sobre distintos enfoques que se han planteado en la teoría de la medición para la medida psicológica;
- introducir la problemática particular de la medición psicológica;
- hacer una presentación general de los instrumentos que se utilizan para medir variables psicológicas.

2.2. NECESIDAD DE LA MEDIDA PSICOLÓGICA

¿Por qué es preciso medir? Tomaremos prestada la respuesta dada por lord Kelvin (1824-1907):

Suelo repetir con frecuencia que solo cuando es posible medir y expresar en forma numérica aquello de lo que se habla, se sabe algo acerca de ello; nuestro saber será deficiente e insatisfactorio mientras no seamos capaces de traducirlo en números. En otro caso, y sea cual fuere el tema que se trate, quizás nos hallemos en el umbral del conocimiento, pero nuestros conceptos apenas habrán alcanzado el nivel de ciencia.

Tomado de Blanco, 1996, p. 4

Esta cita pone claramente de manifiesto que la medida es consustancial a la ciencia, constituye el fundamento mismo de la propia entidad científica de la disciplina. En el capítulo anterior se caracterizó a la ciencia como una fuente de conocimiento; pues bien, las únicas vías de acceso al conocimiento son la *observación* y la *medida*, de forma que todo aquello que no es susceptible de observación directa o indirecta no tiene existencia científica (Ato, 1991). De hecho, parece fuera de toda controversia que una medición rigurosa de las variables psicológicas constituye el paso previo e ineludible para cualquier uso posterior que se vaya a hacer de ellas.

Como investigadores necesitamos obtener medidas de las variables de nuestras hipótesis; como psicólogos y educadores necesitamos evaluar e intervenir y tanto la evaluación como la intervención se apoyan en la medición (Meliá, 1990).

Las tareas habituales que llevan a cabo psicólogos y educadores en el ámbito escolar suponen comparar el rendimiento de un alumno a comienzos y a finales del curso, examinar su nivel de atención en clase, clasificar a los alumnos en función del esfuerzo realizado, diagnosticar posibles problemas de aprendizaje o psicológicos, ordenar a los alumnos de la clase en función de algún criterio, etc. Si nos trasladamos ahora al ámbito penitenciario, los educadores y, sobre todo, los psicólogos llevan a cabo tareas como las anteriores y su juicio tiene un peso considerable a la hora de tomar decisiones importantes acerca, por ejemplo, del régimen penitenciario del recluso.

La medición proporciona información objetiva en la que basarse para tomar decisiones acerca de los sujetos: la medida aumenta la eficiencia en la toma de decisiones por parte de psicólogos y educadores. De hecho, una de las razones que explica el gran éxito que tuvieron inicialmente los tests al comienzo de su andadura en EE.UU. es que representan la posibilidad de juzgar a las personas por sus aptitudes, habilidades o conocimientos, esto es, por méritos propios y no por su nivel socioeconómico, su apariencia o por el juicio subjetivo de sus profesores o supervisores; en suma, los tests pretenden ser dispositivos más objetivos que criterios como la cuna, la familia, la tribu, la apariencia y las opiniones intuitivas basadas en impresiones personales o en cartas de recomendación, criterios que han sido frecuentemente utilizados en situaciones de decisión. Además, la objetividad y la cuantificación (la posibilidad de asignar números a los objetos, hechos o sujetos) facilitan la comunicación de resultados, algo que es de enorme importancia en una actividad de carácter público como la ciencia.

2.3. POSIBILIDAD DE LA MEDIDA PSICOLÓGICA

¿Es posible medir lo psicológico? Resulta evidente que se pueden medir características manifiestas o directamente observables como el color, la longitud, la altura o el peso de un objeto. Ahora bien, ¿se puede medir la sensación que produce un objeto con un peso determinado cuando lo sostengo en una mano? Verdaderamente la sensación que suscita el peso de este objeto no es una variable directamente observable sino una variable latente. ¿Se puede medir esta variable latente? Lo cierto es que si ahora cojo un segundo objeto con un peso distinto probablemente seré capaz de decidir cuál de los dos objetos pesa más (somos capaces incluso de distinguir grados en nuestras sensaciones aun sin saber nada del estímulo físico que produce esa sensación; piense, por ejemplo, el lector en una sensación dolorosa causada no por un estímulo físico externo, visible, sino por uno interno). En suma, se pueden distinguir grados en la sensación que suscitan los objetos: dado que podemos ordenar estas sensaciones (decidir cuál es mayor y cuál es menor), se puede construir al menos una escala ordinal de medida, una escala de medida en la que aparecen *ordenadas* nuestras sensaciones de menor a mayor o al revés.

2.3.1. La licencia para medir en las Ciencias Sociales

Las necesidades de medición psicológica aparecieron muy pronto en la historia de la humanidad, asociadas, por un lado, a cuestiones de percepción subjetiva de objetos (150 años antes de Cristo Hiparco utiliza ya una escala de seis puntos para ordenar las estrellas en función de su brillo percibido) y, por otro, a problemas de selección y clasificación de sujetos (alrededor de 2.000 años antes de Cristo, el gobierno chino convoca las primeras «oposiciones»).

Si bien la medición hunde sus raíces en el tiempo, sus fundamentos lógicos no fueron explícitamente planteados hasta que Hölder en 1901 formulara sus famosos axiomas sobre la medición de la masa que, como tendremos ocasión de comprobar, tan perniciosos resultaron para las Ciencias Sociales.

A la Psicología no le resultó fácil obtener su *licencia para medir*. Como ya se ilustró con anterioridad, la Psicología surgió en un ambiente de corte claramente positivista, con la pretensión de emular el canon de ciencia entonces al uso —la Ciencia Natural— y, consiguientemente, los primeros brotes de medición se desarrollaron en el mismo marco de la medición de las magnitudes físicas, esto es, dentro de lo que Savage y Ehrlich (1990)

denominan como *concepción conservadora* de la medición, formalizada por los axiomas de cantidad de Hölder.

Estos axiomas establecen las condiciones que debe satisfacer una magnitud para poder ser susceptible de medición y éstas se pueden resumir en lo siguiente: se asigna a los objetos números que representan con la mayor precisión posible la cantidad de magnitud que éstos poseen, pero de modo tal que la manipulación matemática de los números se corresponda con la manipulación física de los objetos. Esto es, supongamos que se está midiendo la masa de dos objetos que resultan pesar 10 y 20 kilos cada uno de ellos. Si ahora sumamos el peso de los dos objetos obtenemos un valor de 30, que puede corresponder exactamente al peso de un tercer objeto que es suma de los dos objetos anteriores. Es decir, ha de ser posible replicar con los objetos físicos lo que se hace con los números. En resumen, estos axiomas representan una interpretación empírica de las propiedades de los números reales (Jáñez, 1989). Desde esta perspectiva solo se asignan números a objetos cuando existen operaciones sobre los objetos similares a las operaciones aritméticas sobre los números: solo se puede medir cuando es posible la concatenación o combinación de objetos y ésta se realiza conforme a la adición de los números asignados a los objetos.

La primera exposición completa de los fundamentos lógicos de la medida es realizada por Campbell (1920) en el campo de la Física. Sin embargo, esta obra va a ser muy importante para las Ciencias Sociales puesto que va a proporcionar un marco de referencia para discutir la naturaleza de la medida (Jones, 1971). Campbell propone una distinción importante entre medición fundamental o directa y medición derivada o indirecta, para tratar de acomodar la innegable realidad de que muchas propiedades físicas no poseen la aditividad empírica, es decir, no pueden ser concatenadas como es el caso, por ejemplo, de la densidad. Según este autor, la medición fundamental sería la de las propiedades extensivas (con aditividad empírica) mientras que la medición derivada sería la de las propiedades intensivas (sin aditividad empírica).

Estas ideas resultaron ser ciertamente fructíferas para la Física; no así para la Psicología para la que representaban, más bien, un callejón sin salida. En efecto, los psicólogos carecían de unidades que se pudieran concatenar o combinar para formar un continuo de medida (no todas las operaciones que se pueden llevar a cabo con números corresponden exactamente a las operaciones empíricas que se pueden aplicar a los fenómenos conductuales). Si la mayoría de las variables psicológicas son propiedades intensivas, es decir, no son susceptibles de concatenación alguna, entonces la medición fundamental o directa es inviable en Psico-

logía. Ésta es, justamente, la conclusión a la que llegó la Comisión de la Sociedad Británica para el Avance de la Ciencia en su reunión de 1940, en la que se invitó amablemente a los psicólogos a que renunciaran a su empeño de medir variables subjetivas. Sin embargo, nada más lejos de su intención. A pesar de las tesis de la concepción conservadora, eran muchos los psicólogos que creían que era posible medir características psicológicas. Como indica Guilford (1954), «muchos psicólogos adoptan el *dictum* de Thorndike de «todo lo que existe, existe en cierta cantidad» y adoptan también el corolario de que lo que existe en cierta cantidad se puede medir» (p. 3).

Son varias las salidas que se han ido proponiendo a este callejón a lo largo del tiempo. Una de ellas es, sencillamente, postular un nuevo tipo de medición que se acomode bien a las características peculiares de la medición psicológica: la *medición por índices*. La otra solución es aparentemente simple y directa: si las variables psicológicas no pueden ser concatenadas, se debería sustituir la restricción de la aditividad empírica. Ésta es la opción adoptada por la teoría de las escalas de medida de Stevens, que sustituye la exigencia de la adherencia a las reglas aritméticas por la de asignar números según reglas: se reemplaza la idea de la concatenación por la de las escalas de medida.

2.3.2. La medición por índices

El uso de la medición por índices o indicadores está muy generalizado en el campo de las Ciencias Sociales y se basa simplemente en una definición arbitraria realizada sobre la base de observaciones empíricas, en una definición que relaciona lo que se quiere medir con otras variables. Por ejemplo, se puede medir la personalidad de un sujeto a través de la combinación de las respuestas que éste ha dado a una serie de preguntas o ítems de un conjunto de escalas que en principio son indicadores de distintas dimensiones de la personalidad; se puede medir el nivel socioeconómico de un sujeto atendiendo a indicadores como el nivel de ingresos, el tipo de trabajo desarrollado, el máximo nivel educativo alcanzado, el tipo de barrio en el que vive, etc. De otro modo, se mide la inteligencia por sus obras y el amor por sus manifestaciones, considerando que tanto las unas como las otras son indicadores de los primeros. Parfraseando a Lashley, Yela señala acertadamente en el prólogo a la obra de Castro (1980) que una bofetada expresa mejor la ira que cualquier teoría psicológica, por matemática que ésta sea.

El término *medición por índices* se debe a Dawes (1972) y el término —completamente sinónimo— de *medición por indicadores* es anterior

(Suppes y Zinnes, 1963). Otros términos utilizados en la literatura son *medición por mandato* (Pfanzagl, 1971) y *medición por definición* (Torgerson, 1958) o *especificación*.

2.3.3. La teoría de las escalas de medida de Stevens

Esta teoría constituye otra salida al callejón al que había sido conducida la medición en las Ciencias Sociales y responde a lo que Savage y Ehrlich (1990) denominan *concepción liberal* de la medición. Esta salida consistía sencillamente en admitir que *en Psicología son posibles distintos niveles de medición*. Ésta es la postura defendida por Stevens por vez primera en el Congreso Internacional para la Unidad de la Ciencia en 1941. Cinco años después publica su famoso artículo en *Science* donde acaba de perfilar sus ideas principales, pero es a partir del *Handbook of Experimental Psychology* publicado en 1951 cuando su teoría llegará a ser bien conocida. Como señala Jáñez (1989): «Por esta grieta los psicólogos salieron de las murallas conceptuales impuestas por la Física y se situaron entre los principales impulsores de la moderna teoría de la medición» (p. 423).

Stevens está inmerso de lleno en la tradición instrumentalista-operacionalista de la época, según la cual «el concepto es sinónimo del correspondiente conjunto de operaciones» (Bridgman, 1927, p. 5): las cantidades son creadas por las operaciones utilizadas para medirlas y no existen independientemente de sus operaciones de medida. La propuesta de Bridgman fue purgar a los conceptos científicos de su contenido metafísico, reduciéndolos por completo al tipo de operaciones que utilizan los científicos. En esta perspectiva hay una confusión —deliberada— entre lo que se mide y cómo se mide. Esta postura caló hondo no solo entre los conductistas sino que alcanzó también a los psicómetras que vieron en el operacionalismo y su teoría de medida asociada la tabla de salvación para la espinosa cuestión de la medición de las variables mentalistas: «inteligencia es lo que miden los tests» (Boring, 1945, p. 244).

Según la teoría de las escalas de medida de Stevens, son cuatro los posibles niveles de medida: nominal, ordinal, de intervalo y de razón. Como veremos a continuación, cada uno de ellos otorga un significado diferente a los números asignados a los objetos, sujetos, hechos o conductas en cuestión y soporta un tipo u otro de posibles transformaciones en ese conjunto de números.

Escala nominal

Esta escala representa el nivel de medida más bajo ya que los números se asignan a los objetos con el único fin de designarlos o clasificarlos, no para indicar orden o magnitud sino simplemente para nombrarlos o denominarlos, nada más. Por ejemplo, una escala nominal serían los números que llevan los jugadores de fútbol en las camisetas, que se utilizan exclusivamente para identificarlos en el campo y poder seguir su juego. Otras escalas nominales serían las definidas por variables socio-demográficas como el género (1 = varón, 2 = mujer), el estado civil (1 = soltero, 2 = casado, 3 = separado, 4 = divorciado, 5 = viudo), la raza (1 = blanca, 2 = negra, 3 = otra), etc.

El único tipo de modificación que soporta esta escala es la transformación uno a uno, es decir, cualquiera que a números distintos haga corresponder números también distintos, ya que la única relación válida entre los números de una escala nominal es la relación igualdad— desigualdad: aquí los números no gozan de ninguna de las propiedades aritméticas. Pensemos en el equipo de fútbol del Real Madrid. Si aceptamos que $9 = 5 + 4$ estamos aceptando que Morientes es igual a Redondo más Hierro, lo cual es un auténtico disparate. La única relación posible entre los números es la de igual/diferente: el número 9 es distinto al número 4, pero no mayor ni tampoco implica que se trate de un jugador mejor, simplemente denotan a jugadores distintos para los que podríamos haber utilizado cualesquiera otros números (102, 8, 1001).

Escala ordinal

En esta escala los números asignados a los objetos no solo permiten decidir si un objeto es igual o diferente a otro sino también si un objeto posee en mayor grado que otro la característica de interés. Esto es, una escala ordinal admite como válidas las relaciones igualdad— desigualdad y orden. Examinemos la clasificación general de los equipos de la liga nacional de fútbol de primera división de la temporada 1999-2000 (véase la tabla 2.1). Al equipo mejor clasificado se le asigna el número 1, al segundo mejor clasificado el 2 y así sucesivamente hasta llegar a los colistas, a los que se asignan los números 18, 19 y 20. En este caso, se puede afirmar perfectamente que el Deportivo Alavés (6.º) está mejor clasificado que el Rayo Vallecano (9.º) y éste está a su vez mejor clasificado que el Málaga (12.º), y no solo que se trata de equipos de fútbol diferentes. Otras escalas ordinales serían las definidas por numerosas pruebas de personalidad y de actitud en las que, habitualmente, se le presenta al sujeto una serie de preguntas que constan de un enunciado (por

ejemplo: «Soy tímido en las relaciones sociales») y un conjunto de opciones de respuesta (1 = Totalmente en desacuerdo, 2 = En desacuerdo, 3 = De acuerdo, 4 = Totalmente de acuerdo). Una persona que escoge como respuesta la opción 4 será en principio más tímida que otra que escoge la 2: se puede ordenar a las personas según su timidez (o, mejor dicho, según su percepción subjetiva de la misma) atendiendo a las respuestas que han dado a estas preguntas o ítems de la prueba.

La escala ordinal soporta cualquier transformación monótona creciente que se realice a los números asignados a los objetos, es decir, cualquier transformación que haga corresponder a una sucesión ordenada de números (1, 2, 3, ... , 18, 19, 20) otra sucesión de números ordenados del mismo modo que los primeros (por ejemplo, 101, 102, 103, ... , 118, 119, 120), pero con estos números no se puede operar, *solo se pueden ordenar*. Volviendo al terreno futbolístico, para decidir el lugar que ocupa un equipo en la clasificación general se suman los puntos que va obteniendo

TABLA 2.1
Clasificación final de la Liga Nacional de Fútbol de 1.ª división
en la temporada 1999/2000

Equipos	Orden Clasificación	Puntos	Partidos ganados	Partidos empatados	Partidos perdidos
Deportivo	1	69	21	6	11
Barcelona	2	64	19	7	12
Valencia	3	64	18	10	10
Zaragoza	4	63	16	15	7
Real Madrid	5	62	16	14	8
Dep. Alavés	6	61	17	10	11
Celta Vigo	7	53	15	8	15
Valladolid	8	53	14	11	13
R. Vallecano	9	52	15	7	16
R. Mallorca	10	51	14	9	15
Ath. Bilbao	11	50	12	14	12
Málaga	12	48	11	15	12
R. Sociedad	13	47	11	14	13
Espanyol	14	47	12	11	15
Racing	15	46	10	16	12
Numancia	16	45	11	12	15
R. Oviedo	17	45	11	12	15
R. Betis	18	42	11	9	18
Atco. Madrid	19	38	9	11	18
Sevilla	20	28	5	13	20

el equipo a lo largo de la liga (3 puntos por partido ganado, 1 por partido empatado y 0 por partido perdido). No podemos decir entonces que $9 - 6 = 12 - 9$ ya que eso significaría que la distancia real (en puntos) entre el Rayo Vallecano y el Deportivo Alavés ($61 - 52 = 9$) es la misma que la existente entre el Málaga y el Rayo Vallecano ($52 - 48 = 4$). Del mismo modo, no se puede decir que $4 - 2 = 3 - 1$, ya que eso significaría que la diferencia que existe en timidez entre las personas que optan por las opciones 4 y 2 es la misma que entre las personas que escogen la 3 y la 1: lo único que podemos decir es que la persona que opta por la opción 4 se considera más tímida que la que escoge la alternativa 2 y ésta a su vez más tímida que la que elige la opción 1. Dicho de otro modo, podemos ordenarlas según su timidez pero no cuantificar su timidez. En resumen, idénticas diferencias entre los números de una escala ordinal no equivalen a idénticas diferencias en la característica que se está midiendo; para ello es necesario contar con una escala de intervalo.

Escala de intervalo

En esta escala los números asignados a los objetos no solo permiten decidir si un objeto es igual o diferente a otro o si posee en mayor o menor grado la característica de interés sino que estos números se pueden sumar y restar y, además, las diferencias entre estos números se pueden multiplicar y dividir. Volvamos de nuevo al terreno futbolístico pero esta vez vamos a utilizar como indicador de la calidad de juego de los equipos el número de partidos ganados por cada equipo, no su clasificación general en la liga como en el caso anterior. Como puede observarse, el Deportivo ha ganado tantos partidos como los dos Atlético's juntos ($21 = 12 + 9$); la diferencia de partidos ganados entre el Deportivo y el Barcelona es la misma que entre el Barcelona y el D. Alavés ($21 - 19 = 19 - 17$), mientras que la diferencia entre el Barcelona y el Rayo Vallecano es el doble que la existente entre el Deportivo y el Barcelona ($19 - 15 = 2(21 - 19)$). Otras escalas de intervalo serían, por ejemplo, las definidas por la temperatura medida en grados Celsius o Fahrenheit. En el ámbito psicológico no abundan este tipo de escalas, incluso se discute —en ocasiones, acaloradamente— acerca de la posibilidad de que existan variables psicológicas con un nivel de medida de intervalo. En cualquier caso, asumamos que se mide, por ejemplo, la inteligencia con la escala de Wechsler y que la puntuación estimada para tres sujetos cualesquiera es un Cociente Intelectual (CI) de 150, 125 y 75, respectivamente. En este caso, se puede afirmar que la diferencia entre los dos primeros es la mitad que la existente entre el segundo y el tercero ($150 - 125 = (125 - 75)/2$).

La escala de intervalo soporta cualquier transformación lineal del tipo $y = ax + b$ (donde $a > 0$ y $b \neq 0$) que preserve las relaciones que son

válidas para esta escala (igualdad-desigualdad, orden, suma y resta de los números, multiplicación y división de la diferencia entre los números). Por ejemplo, podemos multiplicar los valores anteriores de CI por 3 ($a = 3$) y restarle 200 ($b = -200$), con lo que la puntuación estimada ahora para la inteligencia de esos tres sujetos sería $y_1 = 3 \times 150 - 200 = 250$, $y_2 = 3 \times 125 - 200 = 175$ e $y_3 = 3 \times 75 - 200 = 25$, respectivamente. Como puede comprobar el lector, los nuevos valores transformados (y) preservan todas las propiedades que cumplían los valores originales (x):

- los tres valores son diferentes: $250 \neq 175 \neq 25$
- los nuevos valores se pueden ordenar en el mismo sentido o dirección que los originales: $250 > 175 > 25$
- la diferencia en inteligencia entre los dos primeros sujetos es la mitad que la existente entre el segundo y el tercero: $250 - 175 = (175 - 25)/2$.

Ahora bien, no se puede decir que el primer sujeto sea el doble de inteligente que el tercero —si atendemos a la escala original ($150 = 2 \times 75$)— o que el primero sea diez veces más inteligente que el tercero —si atendemos a la escala transformada ($250 = 10 \times 25$)— sino solo que la diferencia entre el segundo y el tercero —con cualquiera de las escalas— es el doble que la diferencia entre el primero y el segundo. Para poder concluir lo anterior se necesita disponer de una escala de razón.

Escala de razón

En esta escala los números asignados a los objetos admiten como válidas las relaciones de igualdad-desigualdad, orden, suma, resta, multiplicación y división. Consideremos ahora no la clasificación general de los equipos sino la de los jugadores, para ver qué jugador es el máximo goleador de la liga. Examinemos, por tanto, los goles marcados por cada jugador. Como se puede observar en la tabla 2.2, Salva Ballesta, pichichi de la temporada 1999-2000, ha metido tres veces más goles que Figo mientras que Rivaldo solo consiguió marcar la mitad de los goles metidos por Hasselbaink o Catanha. Otras escalas de razón serían, por ejemplo, el peso, la altura y muchas otras variables físicas. Si escasas son las variables psicológicas con nivel de medida de intervalo, escasas son también las medidas a nivel de razón. Un ejemplo de éstas sería el tiempo de reacción de un sujeto ante la presentación de un estímulo doloroso. Si un sujeto tarda 16 milisegundos en responder a un estímulo de estas características y otro sujeto tarda solo 8 milisegundos se puede decir perfectamente que el tiempo de reacción del primer sujeto es el doble que el del segundo ($16 = 2 \times 8$).

TABLA 2.2
 Tabla de goleadores de la Liga Nacional de Fútbol de 1.ª División
 en la temporada 1999/2000

Número de goles	Goleadores
27	Salva (Racing).
24	Hasselbaink (HOL) (At. Madrid); Catanha (BRA) (Málaga).
22	Roy Makaay (HOL) (Deportivo).
21	Milosevic (YUG) (Zaragoza).
18	Diego Tristán (Mallorca).
17	Raúl (Real Madrid).
15	Kluivert (HOL) Barcelona.
13	Mendieta (Valencia); Víctor (Valladolid).
12	Rivaldo (BRA) (Barcelona); Morientes (Real Madrid); Juan Carlos (Sevilla).
11	Joseba Etxeberria (Athletic); Dani (Barcelona); Dely Valdés (PAN) (Oviedo); Canabal (Rayo); Claudio López (ARG) (Valencia).
10	Alfonso (Betis); Djalminha (BRA) (Deportivo); Bolo (Rayo); Raúl Tamudo (Espanyol); Rubén Navarro (Numancia); Tsartas (GRE) (Sevilla).
9	Figo (POR) (Barcelona); Carlos (Mallorca); De Paula (Real Sociedad); Juanele y Yordi (Zaragoza).
8	Julio Salinas (Alavés); Finidi (NIG) (Betis); McCarthy (RSA) (Celta); Pauleta (POR) y «Turu» Flores (ARG) (Deportivo); Rodrigo (BRA) (Valladolid).
7	Javi Moreno (Alavés); Turdó (Celta); Benítez (PAR) (Espanyol); Pacheta (Numancia); Losada (Oviedo); Ferrón (Rayo Vallecano).
6	Ezquerro y Julen Guerrero (Athletic); Cocu (HOL) (Barcelona); Gustavo López (ARG); Karpin (RUS) y Mostovoi (RUS) (Celta); Toni Velamazán (Espanyol); Barbu (RUM) (Numancia); Munitis y Vivar Dorado (Racing); Guti (Real Madrid); Solari (At. Madrid) y Eto»o (Mallorca).

La escala de razón soporta cualquier transformación del tipo $y = ax$ (donde $a > 0$) que preserve las relaciones anteriores definidas como válidas para esta escala. Por ejemplo, podemos multiplicar los tiempos de reacción anteriores por la constante 10 ($a = 10$) obteniendo los valores transformados 160 y 80. Compruebe el lector a modo de ejercicio que se preservan las relaciones de igualdad-desigualdad, orden, suma, resta, multiplicación y división. Observe el lector que, a diferencia de lo que ocurría en la escala de intervalo, cuando la escala es de razón el cociente entre los valores originales x es el mismo que el cociente entre los valores transformados y ($16/8 = 160/80$), algo que no sucedía en la escala de intervalo ($150/75 \neq 250/25$). La razón es que en la escala de intervalo el origen de la escala de medida es arbitrario (por eso, las transformaciones admisibles adoptan la forma $y = ax + b$) mientras que en la escala de razón el origen de la escala no es arbitrario sino que representa un origen real que corresponde a la ausencia (valor cero) de la característica que se está midiendo (por eso, las transformaciones admisibles adoptan la forma $y = ax$, en las que lo único arbitrario es la unidad de medida — a — pero no el origen de la escala — $b = 0$ —). Retomando el ejemplo del fútbol, la variable *número de goles marcados* tiene un cero real que coincide con el origen de la escala. Del mismo modo, existen ceros reales para variables físicas como el peso, la altura o para variables psicológicas como el tiempo de reacción de un sujeto, que indican en cualquiera de los casos ausencia de la característica medida.

MC Medida y estadística

2.4. APROXIMACIÓN A LA MEDICIÓN PSICOLÓGICA

2.4.1. Definición

Una vez establecida la posibilidad de medir lo psicológico estamos ya en condiciones de definir qué es medir y en qué consiste la medición psicológica.

Tal como se acaba de ver, «medir no significa necesariamente aplicar una unidad extensa a objetos extensos, como el metro a un retal» (Yela, *op. cit.* p. 7). La medición sirve para cuantificar y expresar, normalmente en forma numérica, las características de los estímulos y de las personas, de forma que podamos utilizar los números —mucho más fáciles de manejar y, por tanto, más convenientes— como si se tratase de lo representado.


Medir consiste en estimar la cantidad de atributo presente en un objeto (individuo o estímulo): la medida refleja cuánto de ese atributo o característica está presente en la persona o en el estímulo. Dicho de otro modo, medir es cuantificar observaciones empíricas, medir consiste en definir el conjunto de números o valores posibles (sistema numérico) que se pueden asignar a un conjunto de objetos (sistema empírico) y en establecer la regla de asignación que hace corresponder sistema empírico y numérico.

La teoría de la medición se ocupa justamente del estudio de los modelos mediante los cuales se conocen las reglas para una correcta asignación de los números. En el apartado anterior se introdujo al lector en la teoría de las escalas de medida de Stevens; de esta teoría arranca la teoría representacional que es considerada como una detallada teoría de los tipos de escalas, como una extensión y mejor conceptualización de las escalas de medida (Santisteban, 1990). La obra básica de referencia de esta teoría es el tratado en tres volúmenes *Foundations of Measurement* (Krantz, Luce, Suppes y Tversky, 1971; Suppes, Krantz, Luce y Tversky, 1989 y Luce, Krantz, Suppes y Tversky, 1990).

La medición de lo psicológico introduce una complejidad todavía mayor en un campo que ya de por sí tiene bastantes aristas. Como vimos anteriormente, la referencia a lo psicológico supone la consideración de constructos o características latentes, no directamente observables (la inteligencia, la agresividad, el conservadurismo, la depresión, la propensión a los accidentes, la predisposición a la movilidad laboral, etc.), que han de ser inferidas a partir de una muestra de indicadores indirectos de las mismas (no existen para ellas unidades convencionales de medida como el metro, el kilo o el minuto) y que, en buena lógica, contienen un error de medida mayor que las variables manifiestas o directamente observables (el peso, la altura, la edad, el género, etc.). Según Meliá (1990), la medición en Psicología se ocupa de establecer las condiciones de representación de:

- constructos o características latentes por indicadores empíricos,
- indicadores empíricos por números.

La figura 2.1 ilustra con claridad como se pasa del plano de las variables latentes o constructos —plano teórico— al plano de las respuestas observables, de los indicadores empíricos —plano empírico— mediante una adecuada representación empírica de los constructos, y cómo se pasa del plano de los indicadores empíricos a los números —plano matemático— mediante una adecuada representación numérica de los indicadores empíricos; por supuesto, los constructos o variables latentes de interés pueden formar parte de un modelo teórico que puede ser representado formalmente en un modelo matemático (plano teórico → plano matemático). Por ejemplo, un indicador empírico del conservadurismo de una persona puede ser su tendencia al voto a un partido de derechas o de izquierdas,



Tomado de *Introducción a la medición* (p. 35) de J. L. Meliá, 1990, Valencia, Cristóbal Serrano. Reproducido con permiso.

FIGURA 2.1. Relaciones entre los planos teórico, empírico y matemático desde el punto de vista de la medición.

que se puede expresar numéricamente como el número de veces que en un determinado período de tiempo ha votado a un partido de derechas.

En definitiva, los constructos psicológicos se miden a través de respuestas observables que actúan como indicadores de los atributos de los objetos medidos: medir es relacionar conceptos abstractos con indicadores empíricos que son expresados numéricamente, medir es relacionar un plano de conceptos subyacentes inobservables (conservadurismo) con un plano de respuestas observables (voto del sujeto) que actúan como indicadores empíricos.

Al igual que el resto de los científicos, los científicos sociales tratan de descubrir orden y regularidad en la realidad investigada y los objetivos que persiguen en tanto que disciplina científica son la descripción, explicación, predicción y control de la realidad social. Sin ningún género de dudas, la medición aporta precisión y rigor a las descripciones de los fenómenos sociales y psicológicos, de las conductas de los sujetos, de las situaciones o contextos en las que éstas tienen lugar, etc. A su vez, la explicación, predicción y control de la realidad supone formular modelos o teorías que no son más que una red de proposiciones referidas a un conjunto de constructos o variables latentes que, como acabamos de ver, deben ser apropiadamente representadas por un sistema de indicadores empíricos y éstos, a su vez, han de ser representados por medio de números (véase figura 2.1).

2.4.2. Dificultades

Según Renom (1992), la medición psicológica se enfrenta a tres grandes dificultades metodológicas:

1. Es indirecta.

Según se acaba de exponer, los constructos psicológicos son variables latentes no directamente observables por lo que su medida debe ser necesariamente indirecta: se expresa numéricamente a través de indicadores empíricos relacionados supuestamente con las características latentes o constructos que se desean medir.

2. Es relativa.

En palabras del autor, «el significado de la medida viene referido en unidades arbitrarias casi siempre basadas en la ejecución de un grupo determinado de individuos» (p. 6). Por ejemplo, la medida obtenida para el rendimiento escolar de un alumno al finalizar la enseñanza obligatoria se interpreta o dota de significado comparando la medida obtenida por ese alumno con la medida de otros alumnos que constituyen su grupo normativo o de referencia (por ejemplo, los alumnos de su clase o de su centro escolar, los alumnos de su propia comunidad autónoma o los alumnos de todo el territorio nacional).

El capítulo 4 se ocupa de los distintos mecanismos existentes para interpretar las medidas obtenidas con instrumentos de medida psicológica.

Ahora bien, la existencia de unidades arbitrarias de medida no es privativa de la medición psicológica. No debemos dejarnos engañar por la indudable raigambre e implantación de unidades físicas de medida como el metro patrón, el minuto o el kilogramo. En efecto, el tiempo y el espacio son variables físicas pero las unidades en las que se miden estas variables son invenciones humanas, creaciones de la razón: un kilómetro o un minuto no es un hecho o un fenómeno de la naturaleza sino un mero artificio. La medida —física o psicológica— es una invención humana, es algo inventado por el hombre y para el hombre (Castro, 1980). Lo cierto es que la enorme implantación de algunas unidades físicas de medida hace que lleguemos a confundir los números con las cosas (el peso con un número): los números, considerados por Wright (1997) como el invento más importante del hombre después del lenguaje, «se nos muestran confundidos con las cosas y fenómenos naturales... no advertimos los hechos como tales en su virginidad

física sino como una investidura numérica sometida a leyes aritméticas» (Castro, 1980, p. 29).

MC Números y observables

La diferencia fundamental entre las unidades de medida físicas y psicológicas —arbitrarias en ambos casos— es lo convencional de su uso. Aquí es justamente donde reside la diferencia: hay un consenso generalizado en la utilización de unidades físicas de medida tan convencionales como el metro, el gramo, etc. que no tienen su correspondiente parangón en la medición psicológica —al menos, de momento.

3. Es probabilística.

El error aleatorio de medida es endémico en las Ciencias Sociales, al igual que en cualquier otra área de investigación científica, incluidas las denominadas *ciencias duras* (Carmines y Zeller, 1988). Si se comete error al medir el peso o la estatura de una persona, ¿qué error no se cometerá al tratar de medir su inteligencia? Como ya se señaló con anterioridad, el error de medida de las variables latentes (no directamente observables) es mayor que el error de medida de las variables manifiestas (directamente observables).

Por consiguiente, en cualquier medida hay siempre un componente de error cuya distribución y características es preciso averiguar. Éste es justamente el cometido de las teorías de los tests: examinar el error de medida que de forma inevitable e invariable se introduce siempre que utilizamos un instrumento de medida psicológica para medir una variable o, dicho de otro modo, para determinar la relación existente entre las respuestas observables de un sujeto a las preguntas o ítems de un test y la variable latente que éste pretende medir, con el fin de establecer cuál es la posición del sujeto en esta dimensión inobservable.

El capítulo 5 se ocupa de las principales teorías de los tests que se han ido formulando a lo largo del tiempo.

2.5. INSTRUMENTOS DE MEDIDA

Una vez establecida la necesidad y la posibilidad de medir lo psicológico y visto en qué consiste la medición psicológica y las dificultades a

las que ésta se enfrenta, restaría únicamente por dilucidar con qué se mide, cuáles son los instrumentos utilizados para medir variables psicológicas.

MC Historia de los test: Desde las primeras oposiciones chinas a los tests computatizados

MC Juicio a los tests

2.5.1. Clarificación terminológica

Son muchos los términos que se han empleado para denominar a los instrumentos de medida psicológica: tests, inventarios, cuestionarios, escalas, pruebas, etc. Tradicionalmente se ha utilizado el término *test* para referirse a medidas de variables cognitivas (rendimiento, inteligencia, aptitud) mientras que el término *inventario* aparece más vinculado a la medición de variables no cognitivas, de variables afectivas u oréticas (actitudes, intereses, valores, personalidad), donde no hay respuestas ni verdaderas ni falsas sino formas más o menos habituales de proceder, afirmaciones sobre un acuerdo mayor o menor con determinadas opiniones, etc. Por su parte, los términos *escalas*, *pruebas* y *cuestionarios* se utilizan de forma indistinta para referirse a la medida de cualquier tipo de variable: lo mismo se habla de la escala de inteligencia para adultos de Wechsler que de una escala de actitudes, de una prueba de personalidad que de una de rendimiento en Matemáticas y un cuestionario, a su vez, puede incluir tanto preguntas de información general acerca del sujeto y de su entorno (género, edad, situación laboral, población en la que vive, nivel de estudios, etc.) como una escala de actitud o una prueba de rendimiento académico.

A lo largo de este libro los términos que se van a utilizar normalmente para referirnos a los instrumentos que permiten obtener medidas de las variables psicológicas —del tipo que sea— son los términos *tests* y *pruebas*, por varias razones. Primero, por pura sintonía con la denominación que recibe la teoría que se ocupa 1) del error que contienen las medidas obtenidas con estos instrumentos y 2) de la relación entre las puntuaciones —observables— obtenidas con ellos y la característica o constructo —inobservable— que éstos pretenden medir: *teoría de los tests*. Segundo, *test* es una denominación bastante general que en ocasiones también se aplica al campo no cognitivo; así, es bastante corriente hablar de tests de personalidad. Tercero, el término *prueba* es una palabra autóctona y no adoptada y, además, está libre de otro tipo de connota-

ciones presentes en los términos *cuestionario* —más asociado a información de carácter general y factual— y *escala*.

En relación al término *escala* Meliá (1991) recoge hasta siete significados distintos para el mismo. En este libro se prefiere utilizarlo para referirnos al rango de valores que puede adoptar una variable, al posible conjunto de números que pueden ser asignados a un objeto (sujeto, estímulo, hecho o fenómeno psicológico) en virtud del grado en que éste presente o manifieste la característica o atributo que se desea medir. Dicho de otro modo, una escala representa el continuo de medida en el que se pueden ordenar un conjunto de objetos en relación a la cantidad o calidad de una determinada variable psicológica. Como vimos anteriormente, el proceso mediante el cual esos números son efectivamente asignados a esos objetos se conoce como medición (y también como escalamiento) y el número realmente asignado a una de esas unidades es lo que se conoce como medida, valor de escala o valor escalar (Bartholomew, 1996). El instrumento de medida es la regla o la fórmula mediante la cual se determina ese número: «Un instrumento de medición es como una máquina capaz de absorber alguna dimensión particular de la realidad y arrojar en su lugar una representación formal» (Meliá, 1990, p. 27).

Por último, otros términos que aparecen muy vinculados a la medición, especialmente en el campo educativo, son los de valoración (*assessment*) y evaluación (*evaluation*). Seguramente un profesor no necesita aplicar una prueba de comprensión verbal a uno de sus alumnos para darse cuenta de si éste presenta o no problemas de este tipo: con toda probabilidad le bastará con observar su comportamiento en unas cuantas clases para resolver acerca de esta cuestión. La observación es en sí misma un proceso de valoración (Hopkins, 1998). Sin embargo, si el citado profesor se decide ahora a cuantificar sus observaciones o percepciones y las traduce, por ejemplo, a una escala de 1 a 5 o bien opta por aplicar una prueba de comprensión verbal, el proceso de valoración deviene un proceso de medición puesto que se ha recurrido al lenguaje de los números. Supongamos que examinada su actuación en la prueba y la de sus compañeros de clase resulta que el 75% de sus compañeros tiene un nivel de comprensión verbal más alto que él; de momento, seguimos en el terreno de la medición ya que lo único que hemos hecho ha sido interpretar su puntuación recurriendo, en este caso, a las puntuaciones centiles (serán abordadas en el capítulo 4). Al conocer la puntuación la madre del alumno, se alarma considerablemente y pregunta compungida si eso es tan malo como parece. Cuando el profesor le informa de que no debe inquietarse porque el nivel de la clase es bastante más alto del esperable para la edad de los alumnos y de que su hijo comprende y sigue perfectamente las instrucciones e indicaciones del profesor, hemos pasado del campo de la medición al de la evaluación ya que se han formulado algunos juicios

que incorporan información no contenida en la medida obtenida con la prueba. Por consiguiente, la diferencia básica entre la valoración y la medición supone la introducción de un componente de cuantificación en el proceso, mientras que la diferencia básica entre la medición y la evaluación supone la introducción de juicios que contienen información que no procede del proceso de medición.

2.5.2. Clasificación

En la tabla 2.3 se presenta de forma sumaria una posible clasificación de los tests atendiendo a distintas dimensiones de clasificación y proporcionando una sucinta descripción de las pruebas correspondientes.

TABLA 2.3
Clasificación de los tests

DIMENSIÓN DE CLASIFICACIÓN	TIPO DE PRUEBA	DESCRIPCIÓN
VARIABLE QUE MIDE	COGNITIVA	Prueba que mide rendimiento, inteligencia o aptitudes.
	NO COGNITIVA	Prueba que mide personalidad, actitudes, intereses o valores.
RESPUESTA QUE SE DEMANDA DEL SUJETO	EJECUCIÓN MÁXIMA	Las preguntas de la prueba plantean problemas o situaciones que para su resolución exigen que el sujeto ponga en marcha toda su habilidad.
	EJECUCIÓN TÍPICA	Las preguntas de la prueba plantean situaciones habituales de la vida cotidiana y el sujeto tiene que responder indicando cómo se comporta normalmente en ese tipo de situaciones.
TIPO DE PRUEBA	VELOCIDAD	Prueba con tiempo límite para su aplicación que puede ser realizada correctamente por todos los sujetos si se les diera tiempo suficiente para ello, ya que todas las preguntas o tareas son tan fáciles que pueden ser correctamente respondidas por cualquiera.
	POTENCIA	Prueba cuyas preguntas o tareas varían en dificultad y cuya correcta resolución depende del nivel en que posean los sujetos la habilidad o característica que ésta mide.

CLASE DE PRUEBA	PROYECTIVA	Prueba que presenta tareas muy poco estructuradas, con estímulos vagos y ambiguos y en la que se dan instrucciones muy generales al sujeto, de modo que es la forma en la que éste percibe o interpreta el material del test lo que proporciona información acerca de su funcionamiento psicológico.
	PSICOMÉTRICA	Prueba que presenta tareas muy estructuradas al sujeto, con preguntas claramente definidas y con instrucciones muy específicas y detalladas que permiten obtener información acerca de alguna característica de su funcionamiento psicológico.
TIPO DE APLICACIÓN	INDIVIDUAL	La prueba se aplica a un único individuo cada vez.
	COLECTIVA	La prueba se aplica simultáneamente a un grupo o colectivo de sujetos.
FORMATO DE APLICACIÓN	MANIPULATIVA	La respuesta del sujeto supone la manipulación del material implicado en el problema o tarea a resolver en la prueba.
	ORAL	Las instrucciones y las preguntas de la prueba se formulan oralmente y las respuestas de los sujetos son también orales.
	DE LÁPIZ Y PAPEL	Las instrucciones y las preguntas de la prueba así como las respuestas de los sujetos se presentan y recogen por escrito.
	INFORMATIZADA	Las instrucciones y las preguntas de la prueba se presentan a través de la pantalla de un ordenador y el sujeto utiliza el teclado o el ratón para responder a éstas, quedando registradas en el ordenador las respuestas del sujeto.
CONTENIDO DE LOS ÍTEMS	VERBAL	Prueba cuyos ítems requieren un nivel básico de comprensión verbal, dominio del idioma y escolarización para su correcta resolución.
	NO VERBAL	Prueba que emplea material gráfico en sus ítems.

2.5.3. Estatus métrico

Ato (1991) define un dato científico como una observación cuantificada o simplemente categorizada, esto es, lo que aquí se ha denominado como medida. El valor de los datos científicos depende de la precisión con la que una disciplina o ciencia es capaz de medir sus variables relevantes. Según Hopkins (1998), existe una estrecha correspondencia entre la madurez científica de una disciplina y el grado en el que se pueden medir de forma objetiva y precisa las variables relevantes para esa disciplina.

Como se ha puesto anteriormente de manifiesto, las puntuaciones obtenidas en los tests o pruebas utilizadas para medir variables psicológicas son habitualmente medidas por índice para las que suele asumirse un nivel de medida de intervalo. Sin embargo, esta asunción no está justificada teóricamente (Martínez Arias, 1995a). Por consiguiente, si no se justifica teóricamente las propiedades de escala de las puntuaciones de los tests será necesario apelar a su relevancia práctica para poder justificar su utilización para generar medidas de las variables psicológicas. Es decir, habrá que examinar y probar la calidad métrica de los instrumentos utilizados para obtener medidas de las variables psicológicas: es preciso garantizar que estos instrumentos proporcionan medidas *fiables* y *válidas* de la característica latente o constructo que se pretende medir con dicho instrumento.

Los capítulos 6 y 7 se ocupan en detalle de estos dos criterios métricos de calidad: fiabilidad y validez.

MC Recomendaciones para la evaluación psicológica y educativa

2.6. REFLEXIÓN FINAL

Todos los instrumentos de medida presentados hasta el momento implican el conocimiento y la cooperación del sujeto medido, al igual que sucede con otros procedimientos de recogida de información como son la entrevista, la observación o los registros fisiológicos. Sin embargo, existen también *métodos indirectos* que nos permiten recabar información acerca de la variable psicológica de interés en los que el sujeto permanece totalmente al margen del asunto.

La segunda parte de este libro se ocupa exclusivamente de los *métodos directos* de recogida de información.

Básicamente, se trata de recabar indicios o claves que permitan inferir cuál ha sido la conducta de los sujetos o cómo ha sucedido el fenómeno psicológico en cuestión, o bien de acudir a material documental, a datos disponibles o a investigaciones ya realizadas con el fin de obtener información de interés sobre el aspecto a analizar. Por ejemplo, en el primer caso se pueden obtener medidas de erosión como el desgaste de la moqueta o de las baldosas delante de los distintos expositores de un museo para determinar su popularidad relativa, o medidas de sedimentación como el número de botellas de bebidas alcohólicas recogidas un domingo por la mañana en una zona de copas (Meltzoff, 2000). En el segundo caso se puede recurrir a los editoriales de los principales periódicos de tirada nacional para estudiar la imagen social de la clase política tras un atentado terrorista y llevar a cabo el correspondiente análisis de contenidos, o bien acudir a otras investigaciones realizadas con un propósito diferente pero que podrían proporcionar alguna información sobre esta cuestión.

La tercera parte del libro presenta los distintos métodos de investigación que se utilizan en la Psicología y las Ciencias Sociales en general. Si bien cada uno de estos métodos se caracteriza por la utilización de unos determinados procedimientos de recogida de información, un mismo procedimiento puede ser utilizado perfectamente por distintos métodos de investigación. Por ejemplo, los tests se pueden utilizar en la metodología cuasi experimental y en la de encuestas, la entrevista puede ser utilizada como procedimiento de recogida de información en la metodología de encuesta y en la metodología cualitativa (si bien con formatos diferentes), etc. En suma, es importante no vincular en exclusiva o de forma rígida los procedimientos de recogida de información con un método concreto de investigación.

2.7. PUNTOS BÁSICOS

- La medición rigurosa de las variables psicológicas constituye el paso previo e ineludible para cualquier uso posterior que se vaya a hacer de ellas, ya sea en el campo de la investigación científica o en el de la práctica profesional.
- La medición proporciona información objetiva y permite así combatir la ambigüedad y subjetividad en juicios y afirmaciones difíciles de contrastar.
- La concepción conservadora de la medición sostiene que solo es posible medir cuando se puede replicar con los objetos físicos lo que se hace con los números.

- La concepción liberal de la medición sostiene que en Psicología son posibles cuatro niveles distintos de medida —nominal, ordinal, de intervalo y de razón—, cada uno de los cuales otorga un significado diferente a los números asignados a los objetos y soporta un tipo u otro de posibles transformaciones en ese conjunto de números.
- Se pueden medir variables —tanto físicas como psicológicas— que no posean la aditividad empírica.
- Es posible medir variables manifiestas (directamente observables) y variables latentes (no directamente observables).
- Para medir variables latentes es preciso relacionar éstas con indicadores empíricos y éstos a su vez con números.
- La medición psicológica habitualmente es indirecta, relativa y probabilística.
- La medición es un invento humano, por lo que las unidades de medida —tanto físicas como psicológicas— son siempre arbitrarias, si bien tan convencionales y generalizadas —sobre todo, las físicas— como el metro, el kilo, etc.
- Una prueba o test es el término general que se utiliza para denotar un instrumento de medida psicológica.
- Las puntuaciones obtenidas en los tests o pruebas utilizadas para medir variables psicológicas son habitualmente medidas por índice para las que suele asumirse un nivel de medida de intervalo, asunción que no está justificada teóricamente.
- La medición o escalamiento es el proceso por medio del cual se asigna un número a un objeto y el número asignado es lo que se conoce como medida, valor de escala o valor escalar.
- Una escala representa el continuo de medida en el que se pueden ordenar y situar un conjunto de objetos en virtud del grado en el que éstos presentan o manifiestan la variable psicológica que se desea medir.
- La diferencia básica entre la valoración (*assessment*) y la medición supone la introducción de un componente de cuantificación en el proceso; la diferencia básica entre la medición y la evaluación (*evaluation*) supone la introducción de juicios que incorporan información no contenida en la medición.
- Existen métodos directos e indirectos (con o sin el conocimiento y cooperación del sujeto en la investigación) que permiten recabar información acerca de una variable psicológica.

- No se debe vincular de forma rígida o en exclusiva los procedimientos de recogida de información con un método concreto de investigación.

2.8. EJERCICIOS

2.8.1. Empareje cada término de la columna de la izquierda con un término de la columna de la derecha:

Medición derivada	Concatenación
Constructo	Propiedades intensivas
Aditividad empírica	Plano matemático
Números	Niveles de medida
Stevens	Directamente observables
Medición fundamental	Plano teórico
Variables manifiestas	Propiedades extensivas

2.8.2. A continuación se presenta un conjunto de variables que miden distintas características o aspectos de la vida en un centro penitenciario. Indique cuál es el nivel de medida de estas variables y si se trata de una variable manifiesta o latente, en cuyo caso debe especificar cuál es el constructo medido y el indicador empírico utilizado para ello. Transforme asimismo los valores proporcionados e indique el tipo de transformación realizada en cada caso.

- A) Situación penitenciaria del recluso: 1 (en primer grado), 2 (en segundo grado), 3 (en tercer grado).
- B) Situación judicial del recluso: 1 (preventivo), 2 (penado).
- C) Módulo al que está asignado el recluso: 1, 2, 3, 4, 5, 6, 7, 8, 9, 10.
- D) Puntuación de los reclusos en el factor amabilidad del cuestionario NEO-PI-R: 100, 136, 142, 165 y 200.
- E) Número de funcionarios que trabajan en un centro penitenciario: 200, 300, 600.
- F) Puntuación obtenida en una prueba de comprensión verbal: 3, 10, 15, 25.
- G) Número de episodios violentos en los que participa un interno durante el primer año de reclusión: 0, 2, 4, 8, 10, 16, 30, 50, 100.

2.8.3. A continuación se recogen algunas afirmaciones en torno a la medición. Reflexione acerca de si éstas son o no aplicables a la medición de características físicas y/o a la de características psicológicas.

- A) La medición es indirecta.
- B) La medición es probabilística.
- C) Al medir se modifica lo que se pretendía medir.

2.8.4. Indique mediante flechas qué relaciones definen a las distintas escalas de medida:

	Orden
Escala nominal	Suma y resta de los números
Escala ordinal	Igualdad-desigualdad
Escala de intervalo	Multiplicación y división de las diferencias entre los números
Escala de razón	Multiplicación y división de los números

2.9. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

2.9.1. Medición derivada → Propiedades intensivas; Constructo → Plano teórico; Aditividad empírica → Concatenación; Números → Plano matemático; Stevens → Niveles de medida; Medición fundamental → Propiedades extensivas; Variables manifiestas → Directamente observables.

2.9.2.

A) **Nivel de medida:** Ordinal, ya que estas tres situaciones pueden ser ordenadas de peor a mejor.

Variable manifiesta

Transformación admisible: Cualquier transformación monótona creciente.

Escala resultante: 10, 15, 100.

B) **Nivel de medida:** Nominal, ya que el número únicamente indica si el recluso está o no pendiente de juicio.

Variable manifiesta

Transformación admisible: Cualquier transformación uno a uno.

Escala resultante: 0, 1.

C) **Nivel de medida:** Nominal, ya que el número únicamente designa el módulo en el que está ubicado el recluso.

Variable manifiesta

Transformación admisible: Cualquier transformación uno a uno.

Escala resultante: 10, 20, 15, 5, 25, 100, 30, 38, 4, 200.

D) **Nivel de medida:** Ordinal, si bien habitualmente es tratada estadísticamente como si fuera una variable de intervalo (esto es, con esta variable se utilizan técnicas estadísticas que solo están indicadas cuando se dispone de variables con un nivel de medida de intervalo, que son más poderosas y eficientes que las técnicas que utilizan medidas ordinales y nominales).

Variable latente (amabilidad versus oposicionismo, con las siguientes facetas: confianza, franqueza, altruismo, actitud conciliadora, modestia y sensibilidad a los demás) para la que se utiliza como indicador empírico de la misma las puntuaciones obtenidas por los sujetos en el conjunto de preguntas o ítems que miden cada una de las seis facetas anteriores.

Transformación admisible: Cualquier transformación monótona creciente.

Escala resultante: 20, 36, 40, 44 y 70.

E) **Nivel de medida:** Razón, ya que existe una unidad constante de medida y un cero absoluto, un origen real.

Variable manifiesta

Transformación admisible: Cualquier transformación en la que los valores originales se multiplican por una constante, como $y = 2x$.

Escala resultante: 400, 600, 1200.

F) **Nivel de medida:** Suponiendo que la puntuación en dicha prueba se obtiene sumando el número de preguntas correctamente respondidas, el nivel de medida sería de intervalo, ya que existe una unidad constante de medida pero no un cero real absoluto (una persona que obtenga un cero en la prueba no tiene por qué carecer completamente de comprensión verbal).

Variable latente (comprensión verbal) que se mide utilizando como indicadores las respuestas que dan los sujetos a los ítems o preguntas que forman parte de dicha prueba.

Transformación admisible: Cualquier transformación lineal, como $y = 10x + 50$.

Escala resultante: 80, 150, 200, 300.

G) En este caso cabrían dos posibilidades: 1) considerar la variable tal cual, como el número de episodios violentos en los que participa un interno durante un determinado período de tiempo o 2) considerar su participación en este tipo de episodios como un indicador de la agresividad del interno.

(1) Nivel de medida: Razón, ya que existe un cero absoluto y unidad constante de medida.

Variable manifiesta

Transformación admisible: Cualquier transformación en la que los valores originales se multiplican por una constante, como $y = 10x$.

Escala resultante: 0, 20, 40, 80, 100, 160, 300, 500, 1000.

(2) Nivel de medida: Intervalo, ya que no existe un cero absoluto (el hecho de que un recluso no haya participado en ningún episodio violento durante un determinado período de tiempo no significa necesariamente que su agresividad sea nula).

Variable latente —agresividad del interno— que se mide utilizando como indicador empírico de la misma el número de episodios violentos en los que éste participa durante el primer año de reclusión.

Transformación admisible: Cualquier transformación lineal, como $y = 10x + 20$.

Escala resultante: 20, 40, 60, 100, 120, 180, 320, 520, 1020.

2.9.3

A) Puede ser válido tanto para la medición psicológica como para la física.

En efecto, las características psicológicas suelen ser variables latentes no directamente observables por lo que su medida es indirecta y se expresa numéricamente a través de indicadores empíricos relacionados en principio con esas características latentes o constructos que se desea medir.

A su vez, hay características físicas como la temperatura que no se miden directamente sino a través de indicadores empíricos como, por ejemplo, la dilatación de una columna de mercurio. Es interesante observar que la temperatura también se puede medir a través del juicio subjetivo de un observador; nuestros propios sentidos funcionan como instrumentos de medida que producen medidas o valores escalares en respuesta a los estímulos ambientales (Baird y Noma, 1978). En efecto, para decidir si hace el frío suficiente como para coger una chaqueta al salir de casa no

se necesita un termómetro, si bien el termómetro lógicamente proporcionará una medida mucho más precisa de la temperatura: probablemente bastará con salir al balcón y ver qué tiempo hace. Por el contrario, si se trata de determinar la temperatura de un bebé que presenta respiración agitada será necesario acudir a un instrumento de medida mucho más preciso que nuestros sentidos.

B) Es válida para la medición psicológica y para la física. Ni es legítimo circunscribir las variables latentes o no directamente observables al ámbito de lo psicológico (como indica Caparrós (1984, p. 27), «a los científicos no les preocupa en principio la naturaleza «oculta», «invisible» o «inaccesible a los sentidos» de sus entidades teóricas; ahí están los «átomos», «moléculas», «ondas», «fuerzas gravitatorias», etc.)) ni es lícito tampoco vincular el error de medida a la medición psicológica ya que no hay medida sin error (donde sí se observan diferencias es en la magnitud del error, que suele ser mayor cuando se miden características psicológicas).

C) Puede ser válido tanto para la medición psicológica (por ejemplo, al observar una interacción social podemos estar influyendo en el modo en el que ésta tiene lugar) como para la física (según Heisenberg, no se puede observar ni medir una partícula microfísica sin alterar su estado).

2.9.4. Escala nominal → igualdad-desigualdad; **Escala ordinal** → igualdad-desigualdad, orden; **Escala de intervalo** → igualdad-desigualdad, orden, suma y resta de los números y multiplicación y división de las diferencias entre esos números; **Escala de razón** → igualdad-desigualdad, orden, suma y resta de los números, multiplicación y división de las diferencias entre esos números y multiplicación y división de los números.

2.10. BIBLIOGRAFÍA BÁSICA RECOMENDADA

AMÓN, J. (1980). *Estadística para psicólogos*. Volumen 1. Madrid: Pirámide. Capítulo 2.

Tratamiento muy claro del concepto y tipos de escalas de medida.

CORTADA, N. (2005). *Técnicas psicológicas de evaluación y exploración*. México: Trillas. Capítulos 1 y 2.

Aborda en dos capítulos muy breves y claros la posibilidad y la naturaleza de la medición psicológica, así como el papel de los tests, en un planteamiento próximo al de este texto.

MELIÁ, J. L. (1990). *Introducción a la medición*. Valencia: Cristóbal Serrano Villalba. Capítulo 1.

Recoge la mayor parte de los interrogantes planteados en este capítulo.

MELIÁ, J. L. (1991). *Métodos de escalamiento unidimensional*. Valencia: Cristóbal Serrano Villalba. Capítulo 1.

Se trata de un capítulo muy corto y elemental en el que se abordan los conceptos básicos de la medida.

2.11. LECTURAS SUGERIDAS

FRASER, C. O. (1980). Measurement in Psychology. *British Journal of Psychology*, 71, 23-34. Traducción en Muñiz, J. (1998), *Teoría clásica de los tests*. Madrid: Pirámide (pp. 281-295).

Constituye uno de los escasísimos documentos en castellano en los que se expone de forma razonablemente clara las dos aproximaciones más importantes a la medición: la clásica de Stevens y la axiomática o representacional.

JÁÑEZ, L. (1989). *Fundamentos de Psicología Matemática*. Madrid: Pirámide. Capítulo 18.

Sirve el comentario de Fraser, pero este capítulo se centra básicamente en la exposición de la teoría representacional.

2.12. MATERIAL COMPLEMENTARIO

- Historia de los tests: Desde las primeras oposiciones chinas a los tests computerizados.
- Medida y estadística.
- Estructura típica de una teoría en las ciencias sociales.
- Números y observables.
- Juicio a los tests.
- Recomendaciones para la evaluación psicológica y educativa.

Parte II

CONSTRUCCIÓN, EVALUACIÓN Y APLICACIÓN DE INSTRUMENTOS DE MEDIDA

Tras hacer una pequeña incursión al final de la parte anterior en el arsenal de instrumentos y procedimientos que permiten obtener medidas de las variables psicológicas, se incluye a continuación una parte dedicada justamente al proceso de construcción y evaluación de esos instrumentos de medida, de esas pruebas o tests, de acuerdo con la terminología propuesta en el tema anterior. Es decir, el objetivo que se persigue en esta parte es ver cómo se construyen y evalúan los instrumentos que nos van a permitir medir a un sujeto (o grupo) en la(s) característica(s) psicológica(s) de interés. Para ello, se propone un proceso en dos fases representado esquemáticamente en la figura A.




FIGURA A. Proceso de construcción y evaluación de pruebas o tests.

En la primera fase del proceso —*construcción de un instrumento de medida*— habría que dar los siguientes pasos:

1. Definir el objetivo del test, esto es, decidir qué constructo o característica se va a medir, a quién se va a medir y para qué se va a utilizar ese nuevo test.

2. Especificar las características del test, esto es, decidir acerca de su contenido y longitud así como sobre el formato y características métricas de los ítems o preguntas de la prueba.
3. Confeccionar o redactar los ítems.
4. Confeccionar la prueba, esto es, ensamblar los ítems en la prueba, trabajar en su formato de presentación y en el de registro de las respuestas así como en sus instrucciones de administración.

El producto final obtenido tras la fase de construcción es una *versión preliminar* del test que se puede ya administrar a una muestra de sujetos, con el fin de poder evaluar la prueba en lo que sería la segunda fase del proceso: la evaluación del instrumento de medida. El tema 3 se dedica por completo a esta primera fase, a la construcción y aplicación de instrumentos de medida.

Una vez construido y aplicado el test, hemos dado ya el primer paso en el proceso de medición psicológica (véase figura 2.1), esto es, hemos pasado del *plano teórico* en el que se encuentra el constructo o característica que se desea medir al *plano empírico* —las respuestas de los sujetos a los ítems del test— obteniendo indicadores empíricos a través de los cuales podremos obtener una medida de esa característica o atributo. Si ahora asignamos números —atendiendo a alguna regla— a las respuestas de los sujetos a los ítems del test y combinamos esos números en un único número —la puntuación del sujeto en el test—, hemos pasado del plano empírico al *plano matemático*, hemos obtenido una medida o valor de escala del sujeto en el rasgo o característica evaluado por el test. El tema 4 se ocupa justamente de esta segunda transición en el proceso de medición psicológica, de los procedimientos que nos permiten obtener e interpretar las puntuaciones de los tests, de los procedimientos que posibilitan representar numéricamente los indicadores empíricos mediante los cuales se representan empíricamente los constructos o características que se desea medir.

Sin embargo, estamos trabajando todavía con una versión preliminar de la prueba. Para poder obtener una medida fiable y válida del nivel real en que el sujeto presenta la característica evaluada por la prueba es necesario trabajar con la versión definitiva —no preliminar— de la prueba y, para ello, es menester embarcarse en la segunda fase del proceso ilustrado en la figura A: la *evaluación del instrumento de medida*.

La fase de evaluación del instrumento de medida es absolutamente crucial ya que todas las medidas obtenidas al aplicar una prueba contienen error. La consideración del error de medida inherente a toda medición psicológica hace necesario un planteamiento explícito acerca de hasta qué punto la medida obtenida en un momento determinado pro-

porciona una estimación adecuada del nivel real en que posee el sujeto la característica psicológica que supuestamente se está evaluando. Por tanto, la consideración del error de medida exige el recurso a una *teoría de los tests* que dé cuenta del mismo y proporcione los recursos para una estimación del rasgo o característica evaluada. El tema 5 se ocupa de justificar esta necesidad y de presentar las principales teorías de tests. No queda ahí la cosa. La consideración del error de medida exige, además, evaluar la calidad de los instrumentos de medida, es decir, determinar si éstos cumplen o no los *criterios métricos de calidad* que todo instrumento de medida debe satisfacer para poder ser utilizado con garantía como un instrumento científico (recuerde el lector que las puntuaciones de los tests no siempre están justificadas teóricamente, por lo que su relevancia práctica es en muchas ocasiones el único camino posible para poder justificar su utilización). Esto supone que habrá que estudiar la fiabilidad y validez de la prueba —criterios métricos de la calidad global del test— y proceder a analizar convenientemente los ítems de la misma —para examinar la calidad métrica individual de cada ítem del test—. Los temas 6, 7 y 8 examinan los distintos criterios de calidad tanto para la prueba considerada en su conjunto —temas 6 y 7— como en términos de los ítems que la componen —tema 8—. Si los resultados de esta fase son satisfactorios se obtendría una versión *definitiva* del instrumento.

LOS INSTRUMENTOS DE MEDICIÓN PSICOLÓGICA. I: CONSTRUCCIÓN Y APLICACIÓN

María José Navas Ara

3.1. INTRODUCCIÓN

Este capítulo se ocupa de los instrumentos de medición psicológica, en particular, de la construcción y aplicación de pruebas o tests que nos permitan pasar del plano teórico en el que se encuentran los constructos o características psicológicas que deseamos medir al plano empírico, en el que lo que tenemos ya son conductas o respuestas directamente observables —las respuestas de los sujetos a los ítems del test— que sirven para representar empíricamente a esos constructos que las más de las veces no pueden ser observados directamente (véase figura 2.1).

Cuando un investigador se plantea construir una nueva prueba o test, la primera cuestión a la que debe responder siempre es la siguiente: ¿para qué se va a utilizar el test?, ¿cuál es la finalidad o el objetivo que se pretende conseguir con esta nueva prueba?, ¿a quién se va a aplicar dicha prueba? Como tendrá ocasión de comprobar el lector en las páginas que siguen, la respuesta a esta pregunta servirá para encaminar los pasos del investigador en una u otra dirección. Una vez que sabemos exactamente el *objetivo del test*, para qué se desea construir un nuevo instrumento de medición, es hora de poner manos a la obra y, para ello, lo primero que hay que hacer es especificar de forma clara y explícita las características que ha de tener esa prueba. Eso significa que hay que proceder a representar de forma empírica el constructo o característica que se desea medir, para así poder determinar cuál va a ser el contenido de la prueba que habrá que definir a partir de conductas o respuestas directamente observables; asimismo, hay que tomar decisiones relativas al tipo y número de ítems que conviene incluir en la prueba y a las características métricas que deben presentar éstos. El producto final de esta fase de la construcción de un test -conocida como *Especificación del test*- es un conjunto de directrices o indicaciones generales que constituyen el pilar básico sobre el que se asienta la siguiente fase del proceso de cons-

trucción del test-la *confección de los ítems*-, que debe regirse por las pautas emanadas de la especificación del test. Una vez redactados los ítems, habrá que proceder a su ensamblaje dentro de la prueba, se elaborarán las correspondientes instrucciones de administración de la misma y se tomarán las decisiones pertinentes en relación a la forma de registrar las respuestas de los sujetos. Éstas son básicamente las tareas a desarrollar en la última fase del proceso de construcción del test: la *confección de la prueba*. Los cuatro apartados siguientes del capítulo se ocupan de estas cuatro fases con las que puede caracterizarse el proceso de construcción de instrumentos de medida.

Una vez construida la prueba se puede proceder ya a su administración, a su aplicación efectiva a un sujeto o grupo de sujetos con el fin de ver cuál es su nivel en la característica o atributo evaluado. Como se verá en el sexto apartado, las posibilidades de administración de una prueba son muy variadas: individual o colectiva, de forma personal o directa, a través del teléfono o por correo postal, como prueba de lápiz y papel o a través de la pantalla de un ordenador, etc. La otra decisión que hay que tomar es cómo se llevará a cabo la primera aplicación o aplicación piloto de la prueba, aquella que nos va a servir para pasar de la versión preliminar de la prueba a su versión *definitiva* (véase figura A).

En el diagrama de la figura 3.1 se presenta un esquema-resumen con los contenidos que se van a desarrollar en el capítulo.




FIGURA 3.1. Esquema-resumen de los contenidos del test.

Los objetivos que se persiguen en este capítulo son los siguientes:

- comprender la lógica que permite pasar del plano teórico al plano empírico en el proceso de medición psicológica;
- conocer las etapas para la construcción de un instrumento de medida;

- entender las distintas estrategias que permiten representar empíricamente el constructo o característica que se desea medir;
- conocer los tipos de ítems más frecuentemente utilizados;
- saber cuáles son las reglas básicas que hay que seguir para escribir buenos ítems o preguntas;
- conocer las distintas posibilidades de administración de una prueba;
- saber de qué posibilidades se dispone para pilotar una prueba.

3.2. OBJETIVO DEL TEST

La primera fase en la construcción de un instrumento de medida es la definición clara e inequívoca del objetivo que se persigue con ese nuevo test, lo que supone que habrá que dar respuesta a los siguientes tres interrogantes:

- | | | |
|---------------------------------|---|----------------------|
| ¿Qué se va a medir con el test? | ➡ | VARIABLE DE INTERÉS |
| ¿A quién se va a medir? | ➡ | POBLACIÓN DIANA |
| ¿Qué se pretende? | ➡ | UTILIZACIÓN PREVISTA |

La respuesta al primero de ellos lleva a la variable que se desea medir; la respuesta al segundo a las características de la población a la que se va a administrar el test y la respuesta al tercero al tipo de inferencia que se va a realizar a partir de las puntuaciones del test, esto es, al uso que se va a dar a las puntuaciones obtenidas por los sujetos en el test.

3.2.1. Variable de interés

En el capítulo anterior se hablaba de variables manifiestas y latentes (según que éstas denoten características que son —o no— directamente observables) y se vinculaba la medición psicológica a estas últimas, a características y constructos no directamente observables (como el rendimiento académico, el conservadurismo, la estabilidad emocional, etc.). Pues bien, la primera decisión que hay que tomar es si se va a medir una variable manifiesta o latente y, en este último caso, si se trata de una variable procedente de la esfera cognitiva o afectiva.

Supongamos que las autoridades educativas de un país llevan a cabo una encuesta entre los alumnos de los centros de enseñanza secundaria:

- el absentismo escolar es una **variable manifiesta** de la que se puede desear obtener información;
- el rendimiento académico de los alumnos al finalizar la enseñanza secundaria es una **variable latente cognitiva** que puede tener también mucho interés para las autoridades educativas y para la sociedad en general;
- la actitud de los alumnos hacia grupos minoritarios y socialmente marginados es una **variable latente no cognitiva** o afectiva de indudable importancia en la formación cívica de los alumnos.

3.2.2. Población diana

No se puede evaluar con la misma prueba el rendimiento académico de los niños al comenzar y al finalizar la educación secundaria. Algunas preguntas o ítems podrían coincidir pero todas no, so pena de evaluar al principio del ciclo educativo con una prueba extremadamente difícil o al final del mismo con una prueba extremadamente fácil. En cualquier caso, se estaría operando con una prueba claramente inapropiada para medir el rendimiento académico de los alumnos. Si se procede así, la fotografía que obtendremos de la realidad puede estar bastante distorsionada, encontrando un nivel anómalamente bajo al inicio de la enseñanza secundaria o artificialmente alto al finalizar ésta. Del mismo modo que no se puede medir el peso de hormigas y elefantes con la misma balanza (no existe balanza alguna en el mercado capaz de discriminar entre distintos animales de uno y otro grupo: o discrimina entre distintas hormigas o discrimina entre distintos elefantes, pero nunca entre distintos animales de ambos grupos), es necesario disponer de pruebas apropiadas que permitan obtener medidas precisas del rendimiento académico de los alumnos en uno y otro momento del ciclo educativo y que, además, nos permitan diferenciar entre alumnos con distinto rendimiento en cada uno de esos momentos. Habitualmente, el investigador no solo está interesado en pesar hormigas y elefantes sino que le interesa también observar si existen diferencias de peso entre distintas hormigas y también entre distintos elefantes.

En definitiva, la consideración de la población objetivo a la que va a ir dirigida la prueba es una cuestión decisiva que debe ser claramente explicitada al formular el objetivo de la misma, ya que ésta definirá en parte las características que ha de tener la prueba.

3.2.3. Utilización prevista

Una vez que sabemos qué queremos medir y a quién, hay que ver para qué queremos medir esa característica o constructo en ese colectivo o individuo, es decir, para qué se van a utilizar las puntuaciones obtenidas por los sujetos en ese test. Son muchas las funciones que cumplen los tests. En la actualidad, es incuestionable que los tests forman parte del entramado social del hombre, utilizándose en muchas ocasiones para tomar decisiones que pueden ser muy importantes en la vida de las personas. Normalmente, desde los primeros años de escolarización, los niños comienzan a responder a tests que servirán para medir sus aptitudes intelectuales y su potencial para el aprendizaje; se utilizarán también para certificar su progreso y su nivel de conocimientos, así como para orientarlos vocacionalmente en el futuro. Más tarde, los tests pueden abrir (o cerrar) las puertas a la enseñanza universitaria y, una vez en el mercado laboral, ayudarán a decidir quién deberá cubrir un determinado puesto de trabajo y quién promocionado; además, los tests desempeñarán también un papel importante a la hora de determinar si un sujeto está o no bien adaptado a su entorno, si dispone de recursos suficientes para resolver los problemas que se le plantean en su vida cotidiana o si, por el contrario, necesita algún tipo de terapia para reforzar alguno de estos aspectos. El consumo de tests en nuestra sociedad es grande: son muchos los millones de escolares, trabajadores, opositores y militares que en la actualidad son examinados regularmente con tests.

La tabla 3.1 recoge las principales funciones que suelen desempeñar los tests.

3.3. ESPECIFICACIÓN DEL TEST

Una vez establecido el qué, el a quién y el para qué de la prueba que se va a construir, la siguiente fase del proceso ha de definir o especificar por completo la estructura de dicho test. Utilizando una analogía procedente del mundo de la informática, la fase de especificación del test se corresponde con el trabajo realizado por el analista que, una vez que ha recibido un encargo de un usuario, se dedica a delimitar el ámbito que abarca la aplicación, definir las posibles interrelaciones con otras aplicaciones, estudiar las diversas modalidades de desarrollo, establecer tiempo, recursos y presupuesto del que se dispone... Del mismo modo, el constructor del test debe tomar decisiones importantes que van a condicionar y dirigir totalmente el trabajo en las restantes fases del proceso. En particular, habrá que dar respuesta a las siguientes cuestiones:

TABLA 3.1
Funciones desempeñadas por los tests

Función	Descripción
DIAGNÓSTICO	Los tests se utilizan, por ejemplo, para detectar déficits comportamentales en las personas, puntos fuertes y débiles en el aprovechamiento académico de los estudiantes, con el fin de poner en marcha algún programa de tratamiento o de intervención.
SELECCIÓN	Los tests se utilizan, por ejemplo, para decidir si un trabajador es o no admitido en un departamento de una determinada empresa o si se acepta o no a un estudiante en un programa de estudios universitarios de tercer ciclo.
CLASIFICACIÓN	Los tests se utilizan para asignar a los sujetos a distintas categorías. Por ejemplo, principiante, nivel bajo, nivel medio, nivel alto, perfeccionamiento, etc.
CERTIFICACIÓN	Los tests se utilizan en la acreditación profesional o académica, con el fin de garantizar que un profesional o una persona que ha obtenido una titulación académica es una persona cualificada y competente en su campo de trabajo u ocupación, que posee en grado suficiente los conocimientos y habilidades necesarias para desarrollar su actividad de forma segura y eficiente, esto es, que satisface unos determinados criterios —consensuados— de excelencia.
CONSEJO	Los tests se utilizan para ayudar a los sujetos a examinar distintas opciones educativas, familiares, relacionadas con la carrera profesional del sujeto, con su jubilación o simplemente con su ocio.
DESCRIPCIÓN/ INFORMACIÓN	Los tests se utilizan, por ejemplo, para obtener información acerca del rendimiento académico de un alumno particular, o de los alumnos de una determinada comunidad autónoma, o para saber qué porcentaje de los alumnos españoles muestra un dominio aceptable de los contenidos básicos de Humanidades; para obtener información acerca de la eficacia de una determinada política social; para informar a la población del sentir general de la opinión pública respecto a un tema de actualidad, etc.

¿Cuál va a ser el contenido del test?	➡ CONTENIDO
¿Qué tipo de ítems se van a utilizar en el test?	➡ FORMATO
¿Cuántos ítems debe tener la prueba?	➡ LONGITUD
¿Qué propiedades métricas ha de mostrar ésta?	➡ CARACTERÍSTICAS (PSICO)MÉTRICAS

En definitiva, al finalizar esta fase debemos contar con un conjunto claro de directrices que nos digan exactamente qué y cómo vamos a medir, esto es, con qué tipo de ítems vamos a hacerlo, cómo va a ser de larga la prueba y qué características psicométricas debe poseer. Sin embargo, antes de ponernos a trabajar sobre estas cuestiones es preciso que tengamos muy en cuenta el contexto en el que se va a operar. En la fase anterior se definió claramente qué se va a medir, a quién y para qué. No obstante, hay que tomar también en consideración la situación concreta en la que se va a trabajar para tomar las decisiones correspondientes en esta fase. El analista informático planteará el proyecto de un modo u otro en función del presupuesto asignado, de las personas disponibles con las que cuenta en ese momento en su equipo y de la fecha de entrega de la aplicación. Del mismo modo, habrá que ver, por ejemplo, si hay o no restricciones en el tiempo de aplicación de la prueba. Si se trabaja con niños de educación primaria no es recomendable ir a tiempos de aplicación superiores a la media hora y, qué duda cabe, no es lo mismo plantearse cuál va a ser la longitud de la prueba o incluso el tipo de ítems que se pueden utilizar para un mismo objetivo si el tiempo máximo disponible son 20 minutos o una hora. Lo mismo puede decirse respecto al tipo de aplicación prevista para la prueba: individual o colectiva, a través del teléfono o directamente, etc. Estos y otros factores tan decisivos como el tiempo y los recursos disponibles para la construcción de la prueba, sin ser constitutivos de la estructura interna del test, sí contribuyen en gran manera a decidir cuál va a ser ésta. Por tanto, a la hora de definir o especificar la estructura del test —su contenido, formato, longitud y características psicométricas— es preciso tener siempre en cuenta estos parámetros que definen el marco en el que necesariamente hemos de movernos.

3.3.1. Contenido

Teniendo en cuenta a quién se dirige la prueba y para qué se va a utilizar, lo primero que ha de hacer el constructor del test es representar empíricamente la característica o constructo que se desea medir, es decir, identificar o especificar conductas o respuestas observables que se puedan utilizar como indicadores empíricos de la variable o constructo que

se desea medir. En definitiva, se trataría de pasar del plano teórico al que se hacía alusión al hablar de la medición psicológica en el capítulo anterior al plano empírico (véase figura 2.1). ¿Cómo?

La situación ideal es que dicho constructo forme parte de un modelo teórico de cuya formulación se derive directamente la representación empírica del mismo, que sea la teoría la que delimite la forma en la que se va a representar empíricamente esa característica o constructo. También en este caso lo ideal dista un buen trecho de lo real, ya que en Psicología todavía no son muy frecuentes este tipo de modelos. ¿Qué hacer entonces? Crocker y Algina (1986) proponen seguir alguna de las siguientes estrategias:

— Análisis de contenido.

Para definir empíricamente el constructo lo que se hace es lo siguiente: se plantean preguntas abiertas a los sujetos, sus respuestas son agrupadas por temas y los temas más recurrentes son considerados como las dimensiones principales del constructo.

— Revisión bibliográfica.

El constructo se define a partir de las conductas que han sido estudiadas con más frecuencia en investigaciones anteriores.

— Incidentes críticos.

Se definen mediante una lista de conductas (o incidentes) críticas los extremos del continuo que representa al constructo en cuestión.

— Observación natural.

Para definir el constructo se identifican conductas mediante la observación directa.

— Opinión de expertos.

Se recurre a personas que tienen información de primera mano para definir el constructo.

— Objetivos de la instrucción.

Para pruebas de rendimiento el constructo se define a partir de la especificación de los objetivos que se pretenden cumplir con un determinado curso o programa de instrucción.

— Muestreo del dominio del ítem.

Esta estrategia es característica de situaciones en las que la función desempeñada por el test es la certificación/acreditación académica o profesional del sujeto o la descripción/información (véase tabla 3.1). Consiste en lo siguiente: se trata de definir una

población de ítems de la que se extraerá una muestra o subconjunto de éstos para formar el test. Interesante, pero poco práctico, por lo que se han formulado alternativas como la estrategia de especificación del dominio (Popham, 1975).

Ahora bien, la aproximación más habitual, la que utilizan, por ejemplo, las empresas de tests más importantes en EE.UU. (American College Testing, California Bureau Test, Educational Testing Service) es la conocida como *tabla de especificación* del test. Se utiliza, sobre todo, para construir pruebas que miden variables latentes en el ámbito cognitivo y consiste en construir una tabla de doble entrada como la tabla 3.2 en la que:

- Las columnas indican distintas áreas de contenido relevantes para el constructo en cuestión.

Por ejemplo, si se desea evaluar el rendimiento en Matemáticas, estas áreas podrían ser las siguientes: Geometría, Medición, Números y operaciones, Organización e interpretación de datos, Relaciones, funciones y expresiones algebraicas y Lógica y solución de problemas.

- Las filas indican las distintas operaciones o procesos cognitivos implicados en la resolución de las tareas planteadas por las preguntas o ítems de la prueba.

Bloom (1956) propone quizá el sistema más conocido de categorización jerárquica de estas operaciones cognitivas. En la figura 3.2 se ilustra gráficamente la jerarquía propuesta para el dominio cognitivo.

- Las celdillas indican el porcentaje de ítems que tiene que haber en la prueba que midan el área de contenido de la columna en cuestión y cuya resolución ponga en marcha el proceso cognitivo de la fila correspondiente. Obviamente, este porcentaje lo que está reflejando es el peso que tiene para el constructor del test el área de contenido y el proceso cognitivo asociados con dicha celdilla (atendiendo, por ejemplo, al tiempo que se ha dedicado durante el curso a esas cuestiones, a la importancia que se les atribuye en la formación del alumno, etc.). Observe el lector que no es necesario trabajar con todas las celdillas de una tabla de especificación: el constructor del test puede perfectamente seleccionar unos pocos procesos cognitivos o incluso combinar categorías según sus propias necesidades.

TABLA 3.2
 Ejemplo de una tabla de especificación de una prueba de rendimiento en Matemáticas

	Geometría	Medición	Números y operaciones	Organ. e interpretación de datos	Rel., func. y expres. algebraicas	Lógica y solución de problemas	
CONOCIMIENTO	5	3	10	4	3	10	35
COMPRENSIÓN	3	2	2	7	3	3	20
APLICACIÓN	5	2	1	1	1	5	15
ANÁLISIS	1	2	1	4	1	6	15
SÍNTESIS	1	2	1	1	1	1	7
EVALUACIÓN	2	1	1	2	1	1	8
	17	12	16	19	10	26	




FIGURA 3.2. Taxonomía de Bloom para el dominio cognitivo.

3.3.2. Formato

Ya sabemos cuál va a ser el contenido de la prueba; veamos, a continuación, de qué tipo de ítems o preguntas disponemos para construir una prueba con ese contenido. La primera variable que hay que considerar es el tipo de característica o variable que se va a medir —cognitiva o no cognitiva— ya que ésta determina por completo el tipo de ítem a utilizar y la prueba resultante.

Ámbito cognitivo

De un modo muy general, se pueden considerar dos grandes categorías de ítems (Haladyna, 1994): los que exigen que el sujeto seleccione una (o varias) opción(es) de entre las propuestas y los que requieren que el sujeto construya o elabore la respuesta (ítems de elección *versus* ítems de construcción).

Dentro de los **ítems de elección** se encuentran:

- Los ítems de elección múltiple, en los que el sujeto escoge la respuesta que considera correcta entre tres o más alternativas de respuesta:

El río más caudaloso de España es:

- A) Ebro
- B) Duero
- C) Tajo
- D) Guadiana
- E) Guadalquivir

- Los ítems de elección binaria o alternativa, con solo dos opciones posibles de respuesta:

El Guadalquivir es el río más caudaloso de España V F

El río más caudaloso de España es el:

- A) Duero
- B) Ebro

- Los ítems de emparejamiento, en los que la tarea del sujeto es relacionar lo que aparece en una columna -columna de premisas- con lo que aparece en una segunda columna - columna de respuestas- de acuerdo con las instrucciones que se proporcionan para ello:

Escriba en la línea que aparece a la izquierda de cada río de la columna A la letra correspondiente al país de la columna B en el que se encuentra. Cada país de la columna B solo puede ser utilizado una vez.

	COLUMNA A	COLUMNA B
_____	1. Rhin	A. Francia
_____	2. Volga	B. Rusia
_____	3. Garona	C. Gran Bretaña
_____	4. Támesis	D. Alemania

Dentro de los **ítems de construcción** hay una enorme variedad de formatos que van desde pequeñas adaptaciones de ítems de elección múltiple hasta tareas del tipo de realizar informes orales o escritos, presentaciones, experimentos, revisiones, proyectos, *portfolios*, etc. Este nuevo tipo de ítems se enmarca dentro del denominado movimiento de la *medición auténtica* o *alternativa*. Simplificando considerablemente la cuestión, se pueden distinguir dos grandes categorías:

1. Los ítems de respuesta corta o de completar, que solo requieren del sujeto como mucho unas pocas palabras.

El río más caudaloso de España es _____.

2. Los ítems de respuesta extensa en los que lo que se le pide al sujeto es algo más que escribir unas pocas palabras. Por ejemplo, se le puede pedir que escriba una redacción sobre un tema o que arregle el motor de un coche.

Describe de forma precisa el curso y características del río Ebro, desde su nacimiento hasta su desembocadura.

Cuando los ítems implican tareas muy semejantes a las desarrolladas por el sujeto en su entorno (académico o laboral) se suele hablar de ítems de valoración de la actuación (*performance assessment*): son ítems que tratan de simular o emular el contexto o las condiciones en las que se han de aplicar realmente los conocimientos o las habilidades que se desea evaluar; sirven justamente para saber no tanto si el alumno sabe cómo se hace una cosa sino si de verdad sabe hacerlo. Dentro de éstos está cobrando bastante protagonismo el *portfolio*, que consiste en un conjunto de trabajos o tareas recogidas a lo largo del tiempo (véase, por ejemplo, Archbald y Newman, 1992).

¿Qué tipo de ítem utilizar en cada caso? De nuevo no hay respuestas unívocas. Depende claramente de la variable o constructo que se desee medir y de cómo se haya representado empíricamente dicha variable. Como indicación de carácter general, se suelen utilizar los ítems de elección y de respuesta corta para medir aspectos del contenido que pueden poner en marcha procesos cognitivos relacionados básicamente con los conocimientos adquiridos, con su comprensión y aplicación (los tres niveles más bajos de la jerarquía de la taxonomía de Bloom, ilustrada en la figura 3.2), en tareas más vinculadas con procesos de reconocimiento (ítems de elección) o de recuerdo (ítems de respuesta corta). Por su parte, los ítems de respuesta extensa están más indicados para los procesos cognitivos en los niveles más altos de la jerarquía anterior (análisis, síntesis, evaluación), cuando lo que se pretende es evaluar la capacidad para organizar e integrar ideas, para presentar argumentos lógicos y

defender una determinada postura, etc. Todo ello sin perjuicio de que se pueden utilizar -y, de hecho, se utilizan- ítems de respuesta extensa para evaluar conocimientos y preguntas de elección múltiple para evaluar procesos cognitivos más complejos de los señalados. En cualquier caso, la recomendación general sería trabajar con el tipo de ítem que proporcione la medida más directa de aquello que queremos medir. Si deseamos saber como toca el piano un alumno, nada mejor que pedirle que interprete una partitura. No obstante, en igualdad de condiciones Gronlund (1991) recomienda optar por los ítems de elección, dada su mayor cobertura del contenido.

En la tabla 3.3 se presenta de forma resumida algunas de las características más sobresalientes de los ítems de elección y de construcción.

TABLA 3.3
Características de los ítems de elección y de construcción

Característica	TIPO DE ÍTEM	
	Elección	Construcción
Fácil de construir	No	Sí
Fácil de corregir	Sí	No
Corrección objetiva	Sí	No
Amplia cobertura del contenido	Sí	No
Se puede responder correctamente al azar	Sí	No
Influye la habilidad del sujeto a la hora de escribir	No	Sí
Se necesitan muchas preguntas	Sí	No

En la última década los ítems de construcción (sobre todo, los ítems de respuesta extensa) han suscitado mucho interés y, de hecho, se están utilizando incluso en proyectos de evaluación a gran escala que implican a miles de estudiantes. Las razones hay que buscarlas, por un lado, en la necesidad de evaluar no solo conocimientos sino también habilidades cognitivas de orden superior, los procesos cognitivos que subyacen a la solución de problemas, los cambios dinámicos en las estrategias de los estudiantes, la forma en la que éstos estructuran y representan el conocimiento, etc.; por otro, en el interés creciente de la comunidad educativa

por la evaluación formativa (y no solo sumativa) y la exigencia cada vez más acuciante de vincular adecuadamente la evaluación y la instrucción. Éste es un barco demasiado grande para los tests de elección múltiple que han recibido numerosas y fuertes críticas en los últimos tiempos. Sin embargo, la evidencia en contra no es tan fuerte como se ha pretendido y queda todavía por demostrar la mayor eficiencia de los tests de respuesta construida (Hambleton y Murphy, 1992). No en vano los ítems de elección múltiple constituyen el formato más generalizado en la evaluación psicológica y educativa.

Ámbito no cognitivo

Cuando lo que se pretende evaluar son variables procedentes no del ámbito cognitivo sino del afectivo u orético (personalidad, valores, actitudes, opiniones, intereses, etc.) se pueden utilizar básicamente dos tipos de ítems:

1. Los ítems de respuesta abierta, en los que el sujeto escribe directamente su respuesta.

En su opinión, ¿cuál es el problema más importante al que se enfrenta actualmente la sociedad española? _____

2. Los ítems de respuesta cerrada, en los que el sujeto responde eligiendo (una de) entre las distintas opciones propuestas. Las pruebas no cognitivas formadas por ítems de respuesta cerrada se conocen como *escalas de valoración* (*rating scales*).

En su opinión, ¿cuál es el problema más importante al que se enfrenta actualmente la sociedad española?

- A) El paro
- B) El déficit presupuestario
- C) La delincuencia
- D) El terrorismo
- E) La inflación

Dentro de las escalas de valoración se puede distinguir entre las escalas de categorías y los listados (*checklists*).

Las **escalas de categorías** constan de ítems formados por un enunciado y un conjunto de categorías que pueden estar ordenadas o no (como en el ejemplo anterior). Un ejemplo de un ítem con categorías ordenadas sería el siguiente:

El terrorismo es el problema más importante al que se enfrenta actualmente la sociedad española:

- A) Totalmente de acuerdo
- B) De acuerdo
- C) Ni de acuerdo ni en desacuerdo
- D) En desacuerdo
- E) Totalmente en desacuerdo
- F) No tengo opinión

Cuando las categorías ordenadas utilizadas denotan el grado de acuerdo o desacuerdo con la afirmación contenida en el enunciado del ítem, la escala se suele denominar *escala de actitud* o también *escala Likert*. Ahora bien, las categorías utilizadas pueden expresar otros muchos aspectos de la característica, de las conductas o de los hechos examinados en la prueba, como su frecuencia, intensidad, etc. La tabla 3.4 recoge las escalas de categorías más frecuentemente utilizadas. En cualquier caso, lo que se le pide al sujeto es que se posicione respecto a un objeto, sujeto, hecho o idea, esto es, que considere las categorías proporcionadas y las etiquetas utilizadas, que examine sus opiniones o sentimientos y los sitúe en la categoría apropiada. De esta forma se puede obtener el valor de escala o medida del sujeto en la característica que trata de evaluar esa escala de categorías.

Los **listados** son un tipo de escala de valoración consistente en un conjunto o lista de términos, frases o afirmaciones relativas a un objeto (sujeto, hecho o idea), en los que la tarea del sujeto se reduce a marcar con una cruz los elementos de la lista que en su opinión sean aplicables al objeto que se está valorando.

Marque con una cruz los problemas más importantes a los que en su opinión se enfrenta actualmente la sociedad española:

- ___ A) El paro
- ___ B) El déficit presupuestario
- ___ C) La delincuencia
- ___ D) El terrorismo
- ___ E) La inflación
- ___ F) La educación
- ___ G) La sanidad
- ___ H) El deterioro medioambiental

TABLA 3.4
Escala de categorías más frecuentemente utilizadas

Aspecto considerado	Categorías	Ejemplo
ACUERDO	Totalmente de acuerdo/ De acuerdo/ Ni de acuerdo ni en desacuerdo/ En desacuerdo/ Totalmente en desacuerdo	El submarino nuclear <i>Tireless</i> debe ser reparado en territorio británico.
FRECUENCIA	Diaria/ Casi diaria/ Varias veces por semana/ Varias veces al mes/ Con menor frecuencia	¿Con qué frecuencia consume alcohol?
	Muy a menudo/ Bastante a menudo/ De vez en cuando/ Pocas veces/ Nunca	¿Con qué frecuencia habla de política con sus compañeros de trabajo?
	Casi siempre/ Más de la mitad de las veces/ La mitad de las veces/ Menos de la mitad de las veces/ Pocas veces/ Nunca	¿Con qué frecuencia el dolor menstrual le impide acudir a su lugar de trabajo?
	Ayer/ De 2 a 7 días/ De 8 días a un mes/ Hace más tiempo	Sin contar el día de hoy, ¿cuándo ha sido la última vez que ha escuchado la programación de alguna cadena de radio a través de Internet?
CANTIDAD	Mucho/ Algo/ Solo un poco/ Nada en absoluto	¿Qué cantidad de dolor ha experimentado durante el último mes?
SENTIMIENTOS	Encantado/ Contento/ Satisfecho/ Descontento/ Mal	¿Cómo te sueles sentir tras realizar un examen?
	 A B C D E F G	¿Cómo te sueles sentir después de las vacaciones?
VALORACIÓN	Excelente/ Muy buena/ Buena/ Regular/ Mala	En general, usted diría que su salud es:
	0 1 2 3 4 5 6 7 8 9 10	En una escala de 0 a 10 donde 0 es lo peor y 10 lo mejor indique en qué medida está satisfecho con los transportes públicos de su ciudad.

Marque con una cruz los adjetivos que mejor describan a su profesor de Matemáticas:

- | | |
|---|--|
| ☐ A) Estimulante | ☐ I) Preocupado por los alumnos |
| ☐ B) Considerado | ☐ J) Creativo |
| ☐ C) Paciente | ☐ K) Didáctico |
| ☐ D) Preparado | ☐ L) Motivador |
| ☐ E) Atento | ☐ M) Interesante |
| ☐ F) Organizado | ☐ N) Puntual |
| ☐ G) Conocedor de la materia | ☐ Ñ) Dinamizador |
| ☐ H) Cercano | ☐ O) Elocuente |

Los listados constituyen un procedimiento muy sencillo, barato y bastante preciso para describir o evaluar a una persona. Al igual que las escalas de categorías son fáciles de construir, de administrar y de puntuar y muy versátiles en sus aplicaciones. En efecto, las escalas de valoración —escalas de categorías y listados— se pueden utilizar para evaluarse a uno mismo (autoinformes) o a otras personas para las que nos resultan familiares su personalidad, su conducta o sus capacidades (Aiken, 1996). A pesar de estas indudables ventajas, no siempre es conveniente recurrir a pruebas con ítems de respuesta cerrada. Por ejemplo, si se está interesado en saber qué piensan realmente los sujetos de un tema puede ser más apropiado darles la oportunidad de expresarlo con sus propias palabras y no con las elegidas por el investigador; de esta forma es posible obtener puntos de vista con los que no se contaba *a priori* o pueden surgir aspectos que previamente no se habían anticipado. También es preciso recurrir a este tipo de ítems cuando el rango de posibles respuestas excede con mucho una longitud razonable (¿cuáles son sus aficiones?), cuando es imposible listar todas las posibles respuestas (¿cuál es su canción favorita?), cuando se desea obtener información sobre una situación compleja o delicada, etc. La contrapartida tiene que ver básicamente con las dificultades y costos añadidos en la aplicación y corrección/codificación de las respuestas en la prueba, como tendremos ocasión de ver más adelante. De todas formas, al igual que cuando se trabaja en el ámbito cognitivo, el formato más apropiado para la prueba es siempre el que proporciona una medida más directa de la característica que se desea medir.

3.3.3. Longitud

El camino recorrido hasta ahora indica qué porcentaje de ítems hay que crear para cada celdilla de la tabla de especificación y con qué tipo de ítems se va a trabajar en la prueba, pero ¿cuántos ítems ha de tener en total ésta? De nuevo nos enfrentamos a una cuestión en absoluto baladí y para la que no existe una única respuesta.

En efecto, como podrá comprobar el lector en el capítulo 6 la longitud y la fiabilidad de una prueba están directamente relacionadas, de forma que cuanto más larga es la prueba, más fiable resulta, esto es, proporciona medidas más precisas de la característica que mide. Esto es ciertamente deseable pero hay que tener también presente que en una prueba larga los efectos de la fatiga y de la pérdida de motivación del sujeto pueden introducir más error del que eliminan en la medida obtenida. Es también importante tener en cuenta para qué se va a utilizar el test. Si éste se va a utilizar para tomar una decisión importante en relación al sujeto, las exigencias de precisión son máximas, por lo que la prueba en principio será más larga que la prueba que se utilizaría, por ejemplo, para monitorizar el progreso educativo de un alumno a lo largo del curso. Asimismo, es preciso contar con factores externos a la prueba que condicionan decididamente sus características. Por ejemplo, si solo se dispone de 45 minutos para que los sujetos respondan al test es difícil pensar en pruebas que tengan más de 60 ítems de elección múltiple. Si las preguntas no son de elección múltiple, obviamente el número de ítems del test será menor. Ahora bien, también hay que tener en cuenta las características de la población a la que se dirige la prueba (previamente definidas en el objetivo del test): el ritmo de trabajo no es el mismo en niños de 11 y 17 años de edad o entre alumnos sin dificultades de aprendizaje y alumnos con necesidades educativas especiales. En líneas generales, se recomienda tomar en consideración a los sujetos más lentos a la hora de determinar el número de ítems de la prueba (en pruebas de potencia es preciso dar a todos los sujetos la oportunidad de responder a todos los ítems del test) y se considera que un alumno de bachillerato o universitario puede responder por minuto un ítem de elección múltiple, o tres de respuesta corta o de elección binaria, siempre y cuando esos ítems midan conocimientos; más tiempo sería necesario si el proceso cognitivo implicado es de aplicación o comprensión (Gronlund, 1991). En resumen, no se puede tomar una decisión acerca de la longitud de la prueba sin tener en cuenta muchos factores, tanto de carácter interno como externos al test.

Una posible forma de operar es decidir cuál es el número mínimo deseable de ítems en cada celdilla de la tabla de especificación. Supongamos, por ejemplo, que ese número es tres. Buscamos en la tabla de

especificación la celdilla con el menor porcentaje de ítems (el 1% en la tabla 3.2, que corresponde a un buen número de celdillas de esa tabla). Si sabemos que el 1% de los ítems de la prueba son 3 ítems (o los que se decida en cada caso) podemos calcular directamente la longitud de la misma mediante una sencilla regla de tres:

$$\begin{array}{ccc} 1 & \text{-----} & 3 \\ 100 & \text{-----} & n \end{array}$$

La longitud de la prueba será por tanto $n = 100 \times 3/1 = 300$ ítems. Para determinar el número de ítems del resto de las celdillas habría que realizar otras tantas reglas de tres. Por ejemplo, el número de ítems de organización e interpretación de datos que pongan en juego procesos de análisis que debe haber en la prueba, de acuerdo con la tabla de especificación anterior, es un 4 por 100, esto es, $300 \times 4/100 = 12$ ítems.

Si al proceder de este modo obtenemos una prueba con una longitud excesiva, dadas las condiciones previstas para la aplicación del test y/o los recursos y tiempo disponible para el trabajo, se pueden combinar algunas categorías de las columnas (por ejemplo, medición + organización e interpretación de datos, números y operaciones + relaciones, funciones y expresiones algebraicas) o de las filas (por ejemplo, análisis + síntesis, comprensión + evaluación) y recalcular el número de ítems por celdilla en esa tabla de menor dimensión. Tal como puede observarse en la tabla 3.5, la casilla con un menor número de ítems tiene ahora un 2 por 100, que supondría una longitud para la prueba de $100 \times 3/2 = 150$ ítems, justamente la mitad. Otra posibilidad es decidir el número mínimo de ítems por columna y fila, y no por celdilla. Por ejemplo, se puede establecer un mínimo de 10 ítems por fila y columna. Si acudimos a la tabla 3.5, el porcentaje más bajo corresponde a la fila *aplicación* (15%). Por tanto, la longitud de la prueba será $100 \times 10/15 = 66,6 \approx 67$.

3.3.4. Características psicométricas

Ya sabemos cuántos ítems —y de qué tipo— han de medir cada uno de los indicadores empíricos mediante los cuales se ha representado la característica o constructo que mide el test. La siguiente pregunta es cómo tienen que ser esos ítems. Es decir, cuál es el nivel de dificultad que han de tener —solo en el caso de que se trate de una prueba cognitiva, claro está— y cuál debe ser su capacidad para discriminar entre sujetos que poseen en distinto grado la característica evaluada por la prueba. De nuevo la respuesta es *depende*. ¿De qué? De la utilización prevista para el test.

TABLA 3.5
Reagrupación de las categorías de una tabla de especificación
de una prueba de rendimiento en Matemáticas

	Geometría	Medición + Organ. e interpretación de datos	Números y operaciones + Rel., func. y expr. algebraicas	Lógica y solución de problemas	
CONOCIMIENTO	5	7	13	10	35
COMPRENSIÓN + EVALUACIÓN	5	12	7	4	28
APLICACIÓN	5	3	2	5	15
ANÁLISIS + SÍNTESIS	2	9	4	7	22
	17	31	26	26	

Supongamos que se desea detectar a los alumnos más brillantes de la clase. La prueba a utilizar deberá estar formada por ítems muy difíciles que nos permitan discriminar o diferenciar entre los sujetos situados en el extremo superior de la distribución de frecuencias (véase figura 3.3 parte A). Si a estos alumnos se les aplica una prueba con ítems de dificultad media o baja, responderán a todos correctamente, por lo que todos ellos tendrán la misma puntuación en la prueba y no podremos diferenciar entre alumnos más y menos brillantes.

Por el contrario, si lo que se desea saber es el nivel general de conocimientos en una determinada área de una población de estudiantes, la prueba deberá contener básicamente ítems de dificultad media ya que son éstos los que más discriminan en la zona central de la escala, que es justamente la que suele recoger la mayor parte de la población (véase figura 3.3 parte B).




FIGURA 3.3. Ilustración del objetivo de dos pruebas diferentes.

En definitiva, la dificultad de los ítems de la prueba debe ser apropiada para la población de sujetos a la que ésta va destinada ya que, solo si es así, permitirá el test diferenciar entre sujetos que poseen en distinto grado la característica que estamos midiendo. En el capítulo 8 se entra en detalle en el estudio de las características métricas de los ítems.

En resumen, al finalizar la segunda fase de la construcción de un test hemos detallado por completo su estructura, hemos diseñado los planos para construir el test:

- Se ha trazado un mapa con los contenidos del test, mediante una tabla de especificación o cualquiera de los otros procedimientos descritos que hacen posible pasar del plano teórico, en el que se encuentra la característica o constructo que se desea medir, al plano empírico, en el que se encuentran las conductas o respuestas observables que constituyen los indicadores empíricos del primero.
- Se ha decidido cuántos ítems han de formar la prueba, cuál va a ser el formato de esos ítems y sus características psicométricas.

Estamos pues en disposición de empezar a construir los ítems, los ladrillos del test, auténtica piedra angular sobre la que se asienta el edificio del test.

3.4. CONFECCIÓN DE LOS ÍTEMS

Tradicionalmente, la redacción de ítems ha sido considerada más un arte que una ciencia, un arte más dependiente de la inventiva y creatividad del autor que de la aplicación de reglas; en suma, hasta hace muy pocas décadas la confección de los ítems se ha dejado en manos de la intuición y de la inventiva del autor (Prieto y Delgado, 1996). Esto explica el escaso tratamiento que este tema ha recibido en la literatura científica. Como señala Haladyna (1994), la redacción de ítems carece de la rica tradición teórica observada en el campo de la teoría de los tests, destinado a analizar las puntuaciones obtenidas justamente con esos ítems. Afortunadamente, en los últimos años la tónica está cambiando y se ha asistido a la publicación de algunos trabajos monográficos sobre el tema (véase, por ejemplo, Bennett y Ward, 1993; Converse y Presser, 1986; Gronlund, 1991; Haladyna, 1994; Osterlind, 1989) y a algún que otro intento de sistematización de la cuestión (Haladyna y Downing, 1989).

Lo primero que hay que hacer es seleccionar a las personas que se van a encargar de redactar o construir los ítems. Habitualmente, son expertos en el contenido que va a evaluar la prueba los que se ocupan de confec-

cionar los ítems siguiendo las directrices emanadas de la fase de especificación del test. Es deseable, además, que estén familiarizados con la población de sujetos a la que va destinada la prueba. Lo ideal es que se construyan tres veces más ítems de los necesarios (Bloom, Madaus y Hastings, 1981) o, al menos, un 25 por 100 más de los que se necesitan (Hopkins, 1998), con el fin de poder garantizar que al final se dispondrá del número previsto de ítems y de ítems apropiados. Dado que las personas que se suelen ocupar de la confección de los ítems no son expertos en medición sino expertos en el contenido a evaluar, es conveniente entrenarlos o, en cualquier caso, proveerles con unas directrices o recomendaciones generales que han de seguir a la hora de redactar los ítems.

3.4.1. Recomendaciones generales

Estas sugerencias o recomendaciones generales a la hora de escribir los ítems se basan en esa tradición *artística* colectiva y también en una tradición colectiva de investigación (Converse y Presser, 1986), esto es, en el saber de expertos en tests y medición y en el sentido común, por lo que pueden parecer tan obvias y evidentes que incluso podrían darse por sentadas. Sin embargo, la realidad pone de manifiesto una vez más que el sentido común no es el más común de los sentidos y que lo obvio no siempre es evidente, dada la gran cantidad de ítems o preguntas poco claras y ambiguas que hay en numerosas encuestas de opinión, en exámenes, en pruebas de aptitud y de rendimiento, etc. En muchas ocasiones, uno está tan implicado en lo que está haciendo que lo formulado en una pregunta le resulta muy claro a él pero mucho menos a los que tienen que responder a la misma.

Muy brevemente, las tres reglas de oro para escribir buenos ítems o preguntas serían las siguientes:

- Escribir de forma clara, simple, precisa y concisa.

El ítem ha de ser lo más corto posible, evitando la inclusión de palabras o frases irrelevantes que normalmente solo sirven para complicar innecesariamente la lectura de la pregunta y para incrementar el tiempo que tiene que emplear el sujeto en responder, lo que reduce el número de ítems que se pueden incluir en la prueba. Payne (1951) recomienda que los ítems no contengan más de 20 palabras.

El enunciado del ítem ha de estar perfectamente definido y clara e inequívocamente formulado. Es decir, la pregunta debe proporcionar un marco de referencia común en el que todos los sujetos respondan a lo mismo (términos aparentemente tan claros

como *familia* o *vecindario* pueden significar cosas distintas para distintos sujetos, por lo que conviene definir claramente a qué nos estamos refiriendo exactamente cuando hablamos de familia, vecindario o lo que sea). Es necesario concretar y acotar: una buena pregunta es aquella que es entendida por todos los sujetos de la misma forma y justamente de la forma en la que esperaba el investigador que lo hicieran (Fowler, 1995). Asimismo, hay que evitar cualquier clase de ambigüedad o generalidad que puedan crear algún tipo de confusión. Por ejemplo, conviene no introducir en el enunciado términos como *siempre*, *nunca*, *todo*, *nada*, *completamente*, *exclusivamente*, etc., sobre todo, en ítems de elección binaria de verdadero o falso. En este caso, estos términos pueden producir confusión en el sujeto (no saben muy bien cómo responder) o pueden proporcionar pistas para dar con la respuesta correcta. En efecto, es mucho más probable que un ítem con esos términos sea falso ya que muy pocas cosas ocurren siempre o no ocurren nunca. Por el contrario, cuando se introducen términos como *apenas*, *poco*, *a veces*, *en general*, *solamente*, etc. es mucho más probable que el ítem sea cierto. Este tipo de claves puede poner al sujeto en la pista de la respuesta correcta aun sin éste conocerla, por lo que estos términos deben ser cuidadosamente evitados al redactar los ítems.

— Cuidar el lenguaje.

Es preciso utilizar un lenguaje que sea fácilmente comprensible para todas las personas que vayan a responderlo, hay que construir frases gramaticalmente correctas y el vocabulario debe ser apropiado. Siempre que sea posible, conviene evitar introducir negaciones en el enunciado del ítem. Resulta más difícil responder a este ítem:

No son infrecuentes los novillos entre los alumnos de enseñanza secundaria.

- A) Totalmente de acuerdo
- B) De acuerdo
- C) En desacuerdo
- D) Totalmente en desacuerdo

que al mismo ítem eliminando los términos negativos del enunciado (Son frecuentes los novillos entre los alumnos de enseñanza secundaria). Una norma importante es que a una persona le debe resultar igual de fácil responder SÍ a una pregunta que responder NO (Weisberg, Krosnick y Bowen, 1996).

Puede resultar confuso responder si se está o no de acuerdo con una afirmación que contiene una negación. En el caso de ser necesario formular un ítem de forma negativa, conviene enfatizar el término negativo:

Todos los ríos siguientes son europeos EXCEPTO:

- A) Danubio
- B) Po
- C) Potomac
- D) Sena

— Expresar una única idea por ítem.

Es preciso incluir sola una idea por enunciado y no varias combinadas: hay que evitar preguntar dos cosas al mismo tiempo. A menudo, el investigador pide al sujeto que dé una única respuesta a un ítem que contiene una combinación de preguntas, confundiendo al sujeto que no sabe a qué responder.

La fibra juega un papel importante en la regulación del movimiento intestinal pero no proporciona ningún aporte calórico al organismo V F

¿Está a favor de reducir el consumo de tabaco incrementando los impuestos por cajetilla? SÍ NO

Existe un consenso generalizado en que la habilidad más importante a la hora de escribir buenos ítems es la capacidad del autor para expresarse con claridad y de forma sucinta. Si no somos capaces de utilizar un vocabulario apropiado o redactamos el ítem de forma vaga, de manera que tenga más de una interpretación, ese ítem no está midiendo la habilidad que en principio debería evaluar sino la riqueza de vocabulario del sujeto u otra posible habilidad o procesos que se pueden poner en marcha dada la ambigua formulación del enunciado. En cualquier caso, deficiencias en la redacción de los ítems conducen a obtener medidas inadecuadas de los sujetos que, por ejemplo, pueden llevar a concluir erróneamente que el sujeto no domina adecuadamente un área determinada de contenido cuando lo que sucede en realidad es que el ítem o los ítems no están midiendo lo que deberían.

En el ejercicio 3.8.1 se propone un conjunto de ítems con errores frecuentemente cometidos que el lector debe descubrir o identificar.

3.4.2. En el dominio cognitivo

Además de las recomendaciones generales recogidas en el subapartado anterior, hay que tener también presentes las siguientes recomendaciones específicas a la hora de escribir ítems de elección múltiple:

Para los demás tipos de ítems de elección y para los ítems de construcción véase Gronlund (1991, capítulos 4 y 5) y Mehrens y Lehman (1991, capítulos 5 y 6).

1. El enunciado debe contener la idea central y la mayor parte del texto del ítem, evitando así repetir palabras en las distintas opciones de respuesta.
2. Las opciones de respuesta deben aparecer al final del enunciado y no a la mitad de éste.
3. El ítem debe tener una única respuesta correcta (o una única mejor respuesta), a no ser que las instrucciones de la prueba digan lo contrario.
4. Hay que evitar como alternativas de respuesta *Todas las anteriores* y *Ninguna de las anteriores*, ya que sirven básicamente para confundir a los que responden.
5. Ordenar las opciones de respuesta de forma lógica o secuencial y evitar que las alternativas se solapen.
6. Controlar la posición en la que aparece la opción correcta de respuesta en los ítems de una prueba para evitar un patrón sistemático que puede ser detectado por los sujetos, esto es, variar aleatoriamente la posición de la opción correcta de respuesta en los ítems del test.
7. Evitar dar pistas acerca de la opción correcta de respuesta.

Además de no incluir términos como los comentados anteriormente (nunca, todo, por lo general, a veces, etc.) hay que prestar atención a:

— Indicios gramaticales:

¿Cómo se denomina a un polígono de ocho ángulos y ocho lados?

A) Tetraedro

B) Pentágono

C) Hexágono

D) Octógono

E) Dodecaedro

- Ítems que pueden proporcionar claves para responder a otro ítem de la prueba.
- No hacer sistemáticamente más larga la opción correcta de respuesta.
- La plausibilidad de todas las opciones de respuesta: todas las alternativas de respuesta —la correcta y las incorrectas o distractores— deben parecer razonables a un sujeto que desconoce la respuesta correcta. Si se está preguntando por los afluentes de un río español no se puede poner como opción de respuesta un río chino, ya que esa opción no distrae a nadie, no es una alternativa real o efectiva de respuesta ya que todos los sujetos —incluidos los que desconocen los afluentes del río en cuestión— la descartarían directamente.

MC Taxonomía de reglas para escribir ítems de elección múltiple

Para generar ideas para construir los ítems se puede acudir a textos, manuales, libros de problemas, periódicos, revistas, obras de referencia, o incluso el propio trabajo de los estudiantes puede ser bastante revelador de puntos problemáticos que pueden constituir la base de ítems discriminativos. Para construir los distractores lo más habitual es recurrir a los errores más comunes de los sujetos, a interpretaciones erróneas frecuentes y a respuestas que se obtienen como resultado de errores en el cálculo. También suelen funcionar como distractores eficaces afirmaciones correctas pero que no responden a lo que se plantea en el enunciado del ítem, así como frases técnicas que suenan bien. Para lo que no existe un consenso generalizado es para la respuesta a la pregunta de cuántas opciones de respuesta incluir en el ítem: 3, 4, 5 o más.

3.4.3. En el dominio no cognitivo

Además de las recomendaciones generales recogidas en el subapartado 3.4.1, cuando los ítems tienen por objeto evaluar actitudes, opiniones, valores, intereses o personalidad es conveniente:

- Evitar expresiones coloquiales y procedentes del argot que pueden ser comprendidas únicamente por un segmento específico de la población y en un determinado periodo de tiempo.
- Variar la dirección de la pregunta, incluyendo en la prueba el mismo número de ítems con el enunciado formulado de manera positiva o favorable (por ejemplo, «Los países occidentales desarrollados tienen que poner los medios necesarios para garantizar una integración adecuada de los inmigrantes en el país receptor») y negativa o desfavorable (por ejemplo, «Los inmigrantes ilegales deben ser repatriados a su país nada más pisar territorio español»). Es decir, en la prueba debe haber aproximadamente el mismo número de ítems que denoten una actitud o posición favorable hacia aquello que se esté evaluando y una actitud contraria o desfavorable. Ahora bien, en estos últimos hay que poner especial cuidado en evitar las negaciones en el enunciado. Por ejemplo, en una prueba de satisfacción laboral es mejor incluir el ítem *Odio mi trabajo* en lugar de *No estoy muy satisfecho con mi trabajo*.

Para generar ideas para construir los ítems, el autor puede acudir a estudios empíricos realizados con anterioridad, a modelos teóricos en los que se inscriben las características o constructos a evaluar y, por supuesto, a su propia experiencia personal. Otra fuente importante de ideas se puede obtener acudiendo a pruebas ya construidas y muy contrastadas como, por ejemplo, el cuestionario utilizado en la Encuesta de la Población Activa (<http://www.ine.es/>).

Hay dos cuestiones de interés a las que hay que prestar atención al construir ítems en el ámbito no cognitivo, la primera relativa a las opciones de respuesta entre las que pueden elegir los sujetos y la segunda a los sesgos, tendencias o estilos de respuesta que se pueden observar en algunos sujetos.

Es importante poner etiquetas verbales si no a todas las categorías sí por lo menos a las relativas a los dos extremos, ya que los sujetos responden tanto a la posición ordinal de las categorías como a las descripciones utilizadas. Normalmente es conveniente incluir una categoría de respuesta que represente un punto medio (por ejemplo, *ni de acuerdo ni en desacuerdo* en una escala de actitud; *regular* en una escala de frecuencia, etc.) puesto que esa categoría es la que mejor puede describir los sen-

timientos o la opinión de algunas personas. En ocasiones, cuando se pregunta sobre alguna cuestión con la que algunos sujetos pueden no estar muy familiarizados, conviene también incluir como alternativa de respuesta la opción *No tengo opinión*.

Un sesgo de respuesta es la tendencia sistemática de un sujeto a responder a los ítems de la prueba de una determinada manera, con independencia de cuál sea el contenido de los ítems. Los principales sesgos de respuesta son los siguientes:

- La *deseabilidad social*: consiste en elegir sistemáticamente la opción de respuesta que se considera más deseable socialmente en lugar de la opción que mejor refleja los sentimientos, valores, actitudes o personalidad del sujeto examinado.

Suele ser relativamente frecuente cuando se pregunta acerca de actitudes racistas, conductas sexuales que se desvían de lo que habitualmente es considerado como la norma, conductas deseables, conductas desviadas, etc.

- La *aquiescencia*: consiste en responder sistemáticamente que se está de acuerdo (o en desacuerdo) con lo que se indica en el enunciado, al margen de lo que en él se afirma.
- La *respuesta extrema*: consiste en responder sistemáticamente eligiendo las categorías de respuesta de los extremos, con independencia del contenido del ítem.

Es muy importante que el constructor del test tenga en cuenta estos posibles sesgos de respuesta a la hora de construir los ítems que van a formar dicha prueba. Este ha de evitar incluir ítems con los que cualquier persona se mostraría de acuerdo (o en desacuerdo) y debe hacer todo lo posible para facilitar que el sujeto dé la respuesta real, verdadera y no cualquier otra. Por ejemplo, si queremos saber la edad de un sujeto es más fácil conocerla preguntando su fecha de nacimiento que su edad, o si queremos saber cuáles son los ingresos anuales de una persona es más probable que esta responda si se le proporcionan distintas categorías de respuesta (menos de 1,5 millones, entre 1,5 y 3 millones, entre 3 y 5 millones, más de 5 millones) que si se le pide directamente que indique sus ingresos anuales.

3.4.4. Revisión de los ítems

Antes de pasar a ensamblar los ítems contruidos y dar el formato final a la versión —preliminar— de la prueba, es conveniente revisar los ítems que se acaban de confeccionar. Lo ideal es poder pasar el conjunto

de ítems redactados a un experto ajeno al constructor (o, en su defecto, a un compañero cualificado) y pedirle que los revise atendiendo a su contenido, a la claridad en su redacción, al lenguaje utilizado y, en el caso de trabajar en el ámbito cognitivo, que compruebe la corrección de la respuesta *correcta*. En el caso de que no sea posible recurrir a nadie, se recomienda al menos que el constructor deje pasar un día (o más) y que éste vuelva a examinar todos los ítems revisando su contenido, claridad y lenguaje. Los ítems que pasen este primer control serán ordenados y organizados en la siguiente fase del proceso de construcción de la prueba -confección de la prueba- pero esta revisión es solo una primera comprobación en el proceso de control de calidad al que se va a someter ésta. Tal como se indicó con anterioridad (*véase* figura A en la página 91), el producto final de la fase de construcción es solo una versión preliminar de la prueba, que será cuidadosamente chequeada y examinada en la segunda fase del proceso —evaluación de la prueba— antes de que ésta pueda ser utilizada con garantía para obtener una medida precisa y válida del sujeto (o grupo de sujetos) en la característica o atributo que mide la prueba.

3.5. CONFECCIÓN DE LA PRUEBA

La regla de oro a seguir en esta fase de la construcción de un test es confeccionar la prueba de forma que resulte lo más fácil posible seguir las instrucciones del test, leer los ítems y registrar las respuestas a dichos ítems (Fowler, 1995). En particular, los aspectos a los que hay que atender en esta fase del proceso son los siguientes:

- Las instrucciones dadas a los sujetos para responder a los ítems del test.
- El formato de presentación de la prueba, la organización general de la información.
- El formato de registro de las respuestas de los sujetos a los ítems.

3.5.1. Instrucciones de la administración

El objetivo de las instrucciones de administración de la prueba es proporcionar un marco de referencia común que nos permita asegurarnos de que todos los sujetos comprenden perfectamente la mecánica del test: sirven para familiarizar a los sujetos con el material que constituye el test y para uniformar y estandarizar las condiciones de administración de

la prueba de forma que, una vez realizado el test, las puntuaciones de los distintos sujetos sean comparables y reflejen únicamente diferencias en la característica o atributo que mide el test y no a una mayor o menor comprensión o conocimiento de lo que el sujeto tiene que hacer a la hora de responder a los ítems de la prueba.

Las instrucciones del test deben indicar con un lenguaje claro y sencillo cómo ha de responder el sujeto a los ítems del test (rodeando con un círculo la opción que considere correcta o la alternativa que piense que mejor describe lo que él siente, opina o considera, o respondiendo en el espacio proporcionado a lo que se le pregunta en el ítem, etc.), dónde ha de responder (en el mismo cuadernillo o en una hoja de respuesta), de cuánto tiempo dispone para ello y, en el caso de pruebas cognitivas, si es conveniente responder a todos los ítems (aun sin estar seguro de cuál es la opción correcta de respuesta) o es mejor no responder al azar. En ocasiones, es útil incluir ejemplos o ejercicios de práctica con el fin de clarificar aun más las instrucciones, resolviendo el ejemplo y explicando por qué la opción señalada es la correcta. Adicionalmente, en las instrucciones se le puede indicar también al sujeto cuál es el objetivo del test, cómo van a ser puntuadas sus respuestas, se le puede sugerir cómo distribuir el tiempo de aplicación de la prueba o estrategias en principio no relacionadas con el constructo o rasgo que mide el test pero que pueden contribuir positiva o negativamente a su actuación en la prueba. Normalmente, si la prueba se envía por correo postal a los sujetos para que éstos la respondan y devuelvan, las instrucciones han de ser bastante detalladas y es conveniente proporcionar a los sujetos información acerca del estudio o investigación para el cual se solicita su colaboración. En el caso de una aplicación presencial o directa, suele ser conveniente que el aplicador o encuestador lea en voz alta las instrucciones de la prueba mientras los sujetos las van leyendo para sí mismos.

Las instrucciones a seguir en una prueba de Geografía para 2.º curso de ESO podrían ser las siguientes:

Escribe tu nombre en la parte superior derecha de la hoja de respuesta. No escribas nada en el cuadernillo.

El objetivo de la prueba es determinar tu nivel de comprensión y conocimientos de Geografía.

Hay 50 preguntas y dispondrás de 50 minutos para realizar la prueba.

Para contestar marca en la hoja de respuesta la casilla que hay debajo de la letra correspondiente a la respuesta elegida.

Tu puntuación en la prueba será el número total de preguntas que respondas correctamente. Por tanto, se recomienda que en caso de duda respondas a la pregunta. No dejes ninguna pregunta sin responder.

Si terminas antes de tiempo, por favor, permanece sentado hasta que todo el mundo haya terminado la prueba.

3.5.2. Formato de presentación de la prueba

La forma de organizar las preguntas en una prueba es muy importante ya que un sujeto puede negarse a responder (o responder de cualquier manera) si los primeros ítems le resultan algo embarazosos, irritantes o, sencillamente, difíciles de entender: la simple ordenación de los ítems de un test puede llevar a que un sujeto dé por terminada la prueba antes casi de empezar o, si el formato de presentación no es suficientemente claro, un sujeto puede saltarse inadvertidamente alguna pregunta.

Habitualmente, la prueba suele comenzar solicitando al sujeto los datos de identificación que son relevantes para el control y seguimiento del estudio en cuestión (nombre y apellidos, datos de contacto, etc.) y seguidamente aparecen las instrucciones de administración de la prueba. A continuación se incluyen los ítems del test y se suele dejar para el final las preguntas relativas a datos biográficos y demográficos (edad, género, nivel de estudios alcanzado, situación laboral, nivel de ingresos, preferencias religiosas, políticas, etc.). En el caso de encuestas telefónicas, es bastante habitual incluir al principio de la entrevista preguntas relativas al género, edad, formación, ocupación, rol e incluso composición del hogar ya que éstas pueden ser variables determinantes para la composición de la muestra, dejándose para el final las variables relativas al nivel de ingresos, preferencias religiosas, ideológicas, etc.

Hay que prestar especial atención a las preguntas que aparecen en primer lugar, porque en buena parte de ellas depende que perdamos o que ganemos a un sujeto, que éste adopte una actitud positiva o negativa al realizar el test. En pruebas cognitivas se recomienda empezar con ítems fáciles, que refuerzan positivamente al sujeto, y en pruebas no cognitivas con preguntas de calentamiento, que lo hagan sentirse cómodo. Asimismo, es muy importante que todos los ítems de la prueba —especialmente, estos primeros ítems— respondan al objetivo de la investigación, tal y como ha sido éste enunciado en las instrucciones, para generar un ambiente de confianza que le transmita al sujeto que está colaborando en un estudio serio y riguroso.

Es importante que el orden en el que aparecen las preguntas sea lógico, con el fin de asegurar la cooperación de los sujetos y para eliminar cualquier tipo de confusión o desconcierto. Hay que evitar poner preguntas consecutivas que salten de un tema a otro o que cambien sucesivamente de formato: conviene agrupar por bloques las preguntas que traten del mismo tema, que compartan el mismo enunciado o material de referencia, que tengan las mismas instrucciones o que utilicen el mismo formato. Es más, cuando la prueba es larga o requiere del sujeto que facilite una gran cantidad de información, lo que suele hacerse es separar físicamente los grupos de preguntas y poner un encabezado o un enunciado introductorio para cada bloque (por ejemplo, «A continuación hay una serie de preguntas acerca de cómo son percibidas algunas de las cuestiones objeto de la investigación»). En pruebas largas es también aconsejable utilizar distintos formatos para los ítems con el fin de romper un poco la monotonía o rutina de la prueba. Siempre que sea posible cada grupo de preguntas aparecerá en una única página o en páginas enfrentadas y, dentro de cada grupo, el orden de presentación de las preguntas debe seguir una secuencia lógica o, en el caso de pruebas cognitivas, se debe ir de lo fácil a lo difícil. En la tabla 3.6 se dan algunas recomendaciones generales a tener en cuenta a la hora de determinar el formato de presentación de la prueba.

TABLA 3.6
Recomendaciones para el formato de presentación de la prueba

- Las preguntas generales deben aparecer antes que las preguntas específicas.
- Hay que numerar los ítems.
- No se debe partir un ítem: el ítem debe aparecer en una única página.
- Si un ítem incluye un gráfico o diagrama, éste debe aparecer antes que el enunciado del ítem.
- Cada tipo de ítem debe incluir sus propias instrucciones de administración.

En definitiva, se trata de lograr para la prueba una disposición clara, atractiva, con sentido, fácil de seguir y que haga parecer la prueba lo más corta posible, eso sí, sin merma en la claridad de la presentación de los ítems (en ocasiones, es mejor optar por un formato tipo folleto para evitar cuadernillos con muchas hojas grapadas o utilizar preguntas de matriz múltiple como la de la figura 3.4).

¿Hasta qué nivel de estudios llegaron tus padres? ¿Hasta qué nivel esperas llegar tú? Rodea con un círculo UNA letra en cada columna.			
	Madre	Padre	Tú
a) No han ido a la escuela	A	A	A
b) Sin terminar los estudios primarios	B	B	B
c) Estudios primarios	C	C	C
d) Bachillerato, Formación Profesional o equivalente terminado	D	D	D
e) Carrera universitaria de tres años	E	E	E
f) Carrera universitaria de cinco años	F	F	F
g) No sé	G	G	G

FIGURA 3.4. Ejemplo de una pregunta de matriz múltiple.

3.5.3. Formato de registro de las respuestas

Existen dos posibilidades para registrar las respuestas a los ítems del test:

- Los sujetos responden directamente en el mismo cuadernillo en el que están las preguntas.
- Los sujetos responden en hojas de respuesta que son entregadas por el aplicador junto con el cuadernillo que contiene las preguntas.

La ventaja de esta segunda opción es que permite reutilizar posteriormente el cuadernillo. El inconveniente es que la tarea del sujeto en este caso es algo más complicada que en el primero (hay que buscar el número de la pregunta en la hoja de respuesta, recordar la opción elegida y señalarla en la hoja); de hecho, cuando se trabaja con niños o con personas que no están muy familiarizadas con pruebas de elección múltiple o con escalas de valoración es mejor registrar las respuestas directamente en el cuadernillo del test.

Al lector no se le habrá escapado la complejidad y laboriosidad implícita en la construcción de una nueva prueba o test. Por ello, antes de embarcarse en la construcción de uno nuevo conviene examinar si existe en el mercado alguna prueba o test —comercializada o no— que evalúe aquello que deseamos medir y que cumpla razonablemente con los requisitos métricos exigibles para poder ser utilizado con garantía.

Una forma de rentabilizar el ingente trabajo que supone la construcción de un test es construir en lugar de una única prueba un conjunto o banco de ítems que nos va a permitir poder construir distintas pruebas en distintos momentos con distintos objetivos y para evaluar a distintos sujetos. Obviamente, el número de ítems de un banco es considerablemente superior al número de ítems de una prueba, por lo que el trabajo implicado en la construcción también es mayor. Sin embargo, según sean las necesidades de medición y evaluación puede convenir plantearse la construcción de un banco de ítems a partir del cual se podrán construir distintas pruebas en lugar de limitarse a construir un único test.

3.6. APLICACIÓN DE LA PRUEBA

Las posibilidades de aplicación o administración de una prueba son muy variadas:

1. **Colectiva o individual**, según que ésta pueda o no ser aplicada simultáneamente a un grupo de sujetos.

Razones de economía y de organización aconsejan la aplicación colectiva de pruebas, si bien esto no es posible con conocidos tests de inteligencia (como las escalas de inteligencia de Weschler para adultos y para niños WAIS y WISC) o de personalidad (como el Rorschach).

2. **Como una prueba de lápiz y papel o como un test informatizado.**

En el primer caso la prueba se presenta en formato impreso y el sujeto debe registrar por escrito sus respuestas, respondiendo a lo que se le pregunta o señalando la opción que considere oportuna en el cuadernillo o en una hoja de respuesta.

En el segundo caso los ítems del test se presentan de uno en uno a través de la pantalla del ordenador y el sujeto indica la opción que considera oportuna utilizando el teclado o el ratón.

El avance espectacular que ha experimentado en las últimas décadas la tecnología del ordenador ha propiciado la administración informatizada de los tests, tanto en el ámbito cognitivo como no cognitivo. Las ventajas que ésta presenta respecto a la forma tradicional de aplicación son las siguientes (Olea y Hontangas, 1999): requiere menos tiempo de administración, reduce la posibilidad de copiar y también determinados costes y favorece la similitud de las condiciones de aplicación para todos los sujetos,

además de todas las ventajas relacionadas con las facilidades que el ordenador introduce a la hora de registrar, puntuar e interpretar las respuestas de los sujetos a los ítems del test.

3. Personal, por teléfono o por correo postal.

En el primer caso el aplicador está físicamente presente en el momento de la administración de la prueba, es el que se encarga de repartir y de recoger después los tests, de proporcionar las instrucciones para la realización de la prueba y de asegurar que las condiciones de administración son adecuadas (mínimo ruido ambiental, óptimas condiciones de iluminación, ausencia de interrupciones, tamaño adecuado de la sala donde se realiza la prueba, etc.). La práctica totalidad de las pruebas cognitivas requieren de la presencia de un aplicador.

En el segundo caso el aplicador o encuestador interactúa con el sujeto a través del hilo telefónico, esto es, el aplicador le va haciendo al sujeto las preguntas tal cual aparecen en la prueba y va registrando las respuestas que da el sujeto, con mucha frecuencia introduciéndolas directamente en el ordenador. Este tipo de aplicación es muy común en pruebas no cognitivas, en especial en la investigación de mercado y de opinión pública.

En el tercer caso se trata de una prueba autoadministrada, desaparece la figura del aplicador: se envía la prueba por correo, el sujeto la responde y la devuelve también por correo (postal, electrónico o por fax). Normalmente, se envía junto con la prueba una carta explicativa acerca del estudio y un sobre convenientemente timbrado y con la dirección de envío impresa. Este tipo de aplicación es bastante común en pruebas no cognitivas, cuando lo que se demanda es información que requiere la consulta de documentación (por ejemplo, acerca de la cuenta de resultados o de la plantilla de una empresa), pero presenta algunos problemas, entre ellos, la elevada tasa de no respuesta (más del 50% de los sujetos no devuelven la prueba cumplimentada), la dificultad para controlar que la persona que realmente responde a la prueba es la persona a la que se le envió y que lo hace, además, en el orden en el que aparecen las preguntas en la prueba.

Como ya se indicó en el apartado 3.3, las decisiones que se toman en relación a la forma en la que va a ser aplicada la prueba tienen un impacto directo en el formato de las preguntas y en la propia disposición o formato de la prueba. Por ejemplo, si la aplicación va a ser telefónica, no es conveniente que los ítems tengan más de cinco opciones de respuesta, las primeras preguntas deben conseguir que se establezca una buena relación entre entrevistador y entrevistado para evitar que este último cuelgue el

teléfono nada más empezar; si la aplicación es por correo postal, es preciso poner especial cuidado en la redacción de las instrucciones de la prueba, en proporcionar al sujeto la información suficiente -ni más ni menos- para conseguir su colaboración y cuidar al máximo el formato de presentación de la misma, etc.

La otra decisión que hay que tomar es cómo se llevará a cabo la primera aplicación o aplicación piloto, es decir, la aplicación de la versión preliminar de la prueba (véase figura A en la página 91). Existen dos posibilidades:

1. **Aplicación experimental:** se aplica la prueba tal cual ha sido construida a una muestra de sujetos, normalmente muy poco numerosa pero de características similares a la población de sujetos a los que en principio está destinada la prueba. Es lo que se conoce como la realización de un estudio piloto de la prueba.
2. **Aplicación experimental en una prueba operativa:** se incluyen los ítems de la nueva prueba en una prueba que ya ha sido previamente evaluada y al aplicar ésta se añaden los ítems que se desea pilotar.

En este caso, para determinar la puntuación total del sujeto en la prueba, para estimar su nivel en el rasgo o característica que ésta evalúa solo se tomarán en consideración los ítems de la prueba ya evaluada. Este procedimiento permite pilotar los ítems de la nueva prueba en una muestra numerosa de sujetos, si bien supone un coste añadido en el tiempo de aplicación de la prueba ya contrastada.

3.7. PUNTOS BÁSICOS

- Para construir un test hay que cubrir las cuatro fases siguientes: definición del objetivo del test, especificación del test, confección de los ítems y confección de la prueba.
- La fase de definición del objetivo del test supone responder al *qué, a quién y para qué* de la prueba.
- La fase de especificación del test sirve para diseñar la estructura del test, trazando un mapa con los contenidos del test y decidiendo cuántos ítems han de formar la prueba, cuál va a ser el formato de esos ítems y sus características psicométricas.
- La tabla de especificación del test suele ser la estrategia más utilizada en el ámbito cognitivo para representar empíricamente el constructo o característica que se desea medir.

- Dentro del ámbito cognitivo hay dos tipos de ítems: de elección (emparejamiento, elección múltiple y binaria) y de construcción (de respuesta corta y extensa).
- Dentro del ámbito no cognitivo hay dos tipos de ítems: de respuesta abierta y cerrada. Las pruebas con ítems de respuesta cerrada se conocen como *escalas de valoración* y las hay de dos tipos: escalas de categorías y listados.
- Las reglas a seguir para escribir buenos ítems son las siguientes: escribir de forma clara, simple, precisa y concisa, cuidar el lenguaje y expresar una única idea por ítem.
- Los aspectos a los que hay que atender en la fase final de confección de la prueba son las instrucciones dadas a los sujetos para responder a los ítems del test, el formato de presentación de la prueba y el formato de registro de las respuestas de los sujetos a los ítems.
- Las posibilidades de administración de una prueba son muy variadas: individual o colectiva, de forma personal o directa, a través del teléfono o por correo postal, como prueba de lápiz y papel o a través de la pantalla de un ordenador, etc.
- Para pilotar una nueva prueba se puede optar por una aplicación puramente experimental o por una aplicación experimental dentro de una prueba operativa.

3.8. EJERCICIOS

3.8.1. A continuación se presenta un conjunto de ítems. Todos ellos presentan algún tipo de problema o error. Léalos atentamente e indique de qué problema(s) se trata en cada caso.

3.8.1.1. España no es el único país europeo que no ha cerrado sus fronteras a las oleadas de inmigrantes africanos:

- A) Totalmente de acuerdo
- B) De acuerdo
- C) Ni de acuerdo ni en desacuerdo
- D) En desacuerdo
- E) Totalmente en desacuerdo
- F) No tengo opinión

3.8.1.2. _____ y _____ son los nombres de dos presidentes del Parlamento español.

3.8.1.3. ¿Cuándo se trasladó al barrio en el que vive actualmente?

3.8.1.4. Lope de Vega escribió _____.

3.8.1.5. ¿Qué es Internet?

- A) Una red de redes de ordenadores
- B) Un nuevo sistema de comunicación telemática
- C) Un fondo de inversión
- D) Un protocolo de transferencia de ficheros

3.8.1.6. El rango habitual de variación de las puntuaciones D es entre:

- A) 25 y 75
- B) -50 y 50
- C) 0 y 100
- D) 300 y 800

3.8.1.7. ¿Fueron tus padres a la universidad?

3.8.1.8. El próximo sábado es el cumpleaños de Ignacio. Sus padres van a organizar una gran fiesta y va a invitar a todos sus amigos y compañeros de clase. Su mamá preparará una gran tarta de chocolate. Para ello necesita dos docenas y media de huevos y en la nevera solo tiene dos huevos. ¿Cuántos huevos tendrá que comprar para poder hacer la tarta de cumpleaños?

- A) Media docena
- B) 12
- C) 28
- D) 24

3.8.2. En la columna de premisas se presentan una serie de cuestiones sobre las que el constructor de un test debe decidir cuando se enfrenta a la tarea de construir una nueva prueba. En la columna de respuestas se indican las fases de dicho proceso. Indique mediante flechas a qué fase corresponde cada una de estas cuestiones acerca de las que hay que decidir.

Número de ítems

Redacción de los ítems

Formato de los ítems	Objetivo del test
Formato de la prueba	Especificación del test
Para qué medir	Confección de los ítems
Orden de los ítems	Confección de la prueba
Formato de registro de las respuestas	
A quién medir	
Instrucciones de administración	

3.8.3. A continuación se presenta una relación de distintos tipos de ítems. Indique en cada caso si se trata de un ítem de respuesta abierta o cerrada, rodeando con un círculo una letra en cada fila.

	Respuesta Abierta	Respuesta Cerrada
1. Ítem de emparejamiento	A	C
2. Ítem de una escala de categorías	A	C
3. Ítem de respuesta corta	A	C
4. Ítem de una escala de valoración	A	C
5. Listado	A	C
6. Ítem de elección binaria	A	C
7. Ítem de respuesta extensa	A	C

3.8.4. Escriba un ítem que le permita determinar si un sujeto es o no licenciado universitario, utilizando para ello tres formatos distintos.

3.9. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

3.9.1.1. La redacción del enunciado es muy confusa, el sujeto tiene que sortear varias negaciones antes de tratar de adivinar qué se está preguntando en realidad, además de haber más de una idea en el ítem (¿España ha cerrado sus fronteras a la inmigración africana? ¿Hay más países en Europa que lo hayan hecho?).

3.9.1.2. Conviene colocar los espacios en blanco al final de la frase, para que los sujetos sepan qué tipo de respuesta se espera de ellos cuando llegan al espacio en blanco.

3.9.1.3. Tal como está formulada esta pregunta, la respuesta dada por el sujeto puede no darnos la información que se desea obtener. Por ejemplo, se puede responder *Llevo toda la vida aquí, A los 10 años, Cuando me*

casé, etc. Para saber realmente cuánto tiempo lleva viviendo el sujeto en el barrio tendríamos que conocer su edad, o la fecha en la que se casó... Sería más apropiado preguntar entonces *¿Desde qué año vive usted en este barrio?*

3.9.1.4. Conviene producir ítems que contengan una sola respuesta correcta (por ejemplo, El autor de *El perro del hortelano* es _____), ya que en el ítem anterior el sujeto no sabe si tiene que responder una única obra o la colección completa del autor. El ítem está formulado de manera poco precisa y puede llevar a que distintos sujetos respondan de manera diferente.

3.9.1.5. Hay un distractor que no es tal (C), una opción que se corresponde con la definición más comúnmente aceptada de Internet (A) y dos opciones parcialmente correctas (es un nuevo sistema de comunicación telemática y sirve para transferir ficheros entre distintos equipos informáticos mediante el servicio *ftp*), pero en el enunciado no se indica que puede haber más de una opción correcta o que se señale la opción más correcta de entre las ofrecidas.

3.9.1.6. El orden de presentación de las opciones de respuesta debe ser lógico o secuencial y, además, no conviene que exista solapamiento entre las alternativas. Una ordenación más adecuada sería la siguiente:

- A) -50 y 50
- B) 0 y 100
- C) 25 y 75
- D) 300 y 800

3.9.1.7. Hay que desdoblar la pregunta en dos, no se puede preguntar dos cosas en una única pregunta.

3.9.1.8. El orden de presentación de las opciones de respuesta no es secuencial (la opción C debería ser 24) y, sobre todo, el enunciado del ítem es innecesariamente largo. Un enunciado alternativo podría ser el siguiente:

Para hacer un pastel de cumpleaños se necesitan dos docenas y media de huevos. ¿Cuántos huevos habrá que comprar si solo hay dos huevos en la nevera?

3.9.2. Objetivo del test → Para qué medir, A quién medir

Especificación del test → Número de ítems, Formato de los ítems

Confección de los ítems → Redacción de los ítems

Confección de la prueba → Formato de la prueba, Formato de registro de las respuestas, Orden de los ítems, Instrucciones de administración

3.9.3. 1C; 2C; 3A; 4C; 5C; 6C y 7A.

3.9.4. Indique a continuación los títulos universitarios que posee:

_____.

¿Es usted licenciado universitario?..... SÍ NO

Rodee con un círculo la letra correspondiente al nivel de estudios más alto que ha completado:

- A) Estudios primarios
- B) Bachillerato
- C) Formación Profesional
- D) Diplomatura universitaria
- E) Licenciatura universitaria

De los tres formatos propuestos el primero es el menos indicado, ya que al plantear de ese modo la pregunta se está dando por supuesto que el sujeto al que va dirigida tiene algún título universitario, algo que no tiene porque ser cierto y que puede hacer sentir incómoda a más de una persona.

3.10. BIBLIOGRAFÍA BÁSICA RECOMENDADA

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulo 2

Ofrece un tratamiento breve y sintético del proceso.

MUÑIZ, J., FIDALGO, A. M., GARCÍA-CUETO, E., MARTÍNEZ, R. y MORENO, R. (2005). *Análisis de ítems. Cuadernos de Estadística n.º 30*. Madrid: La Muralla. Capítulo 2.

Capítulo dedicado a la construcción de ítems, en el que se exponen las directrices que han de seguirse para su elaboración, incluyendo todo lo relativo a la traducción y adaptación de los tests, así como algunos aspectos centrales de la fiabilidad y la validez de los mismos.

3.11. LECTURAS SUGERIDAS

AZOFRA, M. J. (1999). *Cuestionarios*. Madrid: CIS.

Texto básico para la construcción de cuestionarios en encuestas sociológicas que incluye, además, tres cuestionarios completos utilizados en estudios realizados por el Centro de Investigaciones Sociológicas para los cuales se presenta también su correspondiente ficha técnica.

DOWNING, S. M. y HADADYNA, T. (2006). *Handbook of Test Development*. Mahwah, NJ: Lawrence Earlbaum Associates.

Se trata de uno de los pocos manuales existentes en el mercado sobre el tema y, sin lugar a dudas, el más completo de todos, tratándose más bien de un auténtico tratado sobre la cuestión. Sus más de 700 páginas se organizan en las seis partes siguientes: fundamentos, contenido, desarrollo de los ítems, diseño del test, producción y administración del test y actividades posttest.

OLEA, J. y HONTANGAS, P. (1999). Tests informatizados de primera generación. En J. Olea, V. Ponsoda y G. Prieto (Eds.), *Tests informatizados*. Madrid: Pirámide.

En este trabajo se realiza una breve presentación histórica de este tipo de tests y se exponen sus ventajas frente a los tests tradicionales de lápiz y papel así como las dificultades que tienen que sortear.

PRIETO, G. y DELGADO, A. (1996). Construcción de los ítems. En J. Muñoz (Coord.), *Psicometría*. Madrid: Universitas.

Magnífico capítulo que —a pesar de su título— se ocupa también de otras fases del proceso, con rigor y de forma amena, incluyendo además un apartado dedicado a las aportaciones de la Psicología Cognitiva a la construcción de ítems.

WESMAN, A. G. (1971). Writing the test item. En R. L. Thorndike (Ed.), *Educational Measurement*. Washington: American Council on Education.

MILLMAN, J. y GREENE, J. (1989). The specification and development of tests of achievement and ability. En R. L. Linn (Ed.), *Educational Measurement*. Washington: Macmillan.

Estas dos referencias comparten además del idioma el libro al que pertenecen sendos capítulos. Se trata de la segunda y tercera edición, respectivamente, del libro *Educational Measurement* que recoge en cada uno de los momentos en que ha sido publicado los avances más significativos y el estado de la cuestión en los aspectos centrales que rodean a la medición educativa, por lo que sería una referencia obligada en temas como la fiabilidad y la validez de los tests, la interpretación de sus puntuaciones... si bien solo se han incluido estas referencias en este capítulo. La razón tiene que ver, por un lado, con la escasez de referencias en castellano y, por otro, por la calidad y el tratamiento detallado y en profundidad que hacen de los contenidos expuestos en este capítulo.

El trabajo de Wesman aporta un buen número de ideas para la redacción de los ítems, así como sugerencias tanto generales como por tipo de ítems y hace una descripción detallada de los distintos formatos disponibles para los ítems.

Las ideas expuestas en este capítulo de la unidad didáctica se basan en buena medida en el trabajo de Millman y Greene, si bien los autores se centran en las pruebas cognitivas, incluyendo también consideraciones relativas a la evaluación y selección de los ítems de la prueba.

3.12. MATERIAL COMPLEMENTARIO

- Taxonomía de reglas para escribir ítems de elección múltiple.

LOS INSTRUMENTOS DE MEDICIÓN PSICOLÓGICA. II: ASIGNACIÓN E INTERPRETACIÓN DE PUNTUACIONES

María José Navas Ara

4.1. INTRODUCCIÓN

Una vez que se ha construido un test y se ha aplicado éste a un grupo de sujetos, el problema al que debe enfrentarse el constructor es el de cómo valorar adecuadamente las respuestas que los sujetos han dado a las preguntas o elementos del mismo, es decir, cómo puntuar el test y los elementos o ítems que lo componen y cómo interpretar o dotar de significado a esas puntuaciones.

La asignación de puntuaciones al test y su posterior interpretación constituyen la fase de cierre del proceso de medición psicológica (véase figura 2.1). En efecto, como se acaba de ilustrar en el capítulo anterior, al construir y aplicar un instrumento de medición pasamos *del plano teórico al empírico*, al proponer una adecuada representación empírica del constructo o característica a evaluar con la prueba y obtener las directrices necesarias —en cuanto a contenido y longitud del test y formato y características psicométricas de los ítems— para construir los ítems, cuyas respuestas —observables— constituyen los indicadores empíricos a través de los cuales podremos obtener una medida de ese constructo o característica latente, no directamente observable. En la fase de puntuación o asignación de puntuaciones, pasamos *del plano empírico al matemático* mediante una adecuada representación numérica de estos indicadores empíricos, esto es, de lo que se trata es de asignar números o puntuaciones a las respuestas —observables— de los sujetos a los ítems utilizando para ello alguna regla y posteriormente combinar las puntuaciones asignadas según esa regla a los ítems en una única puntuación —la puntuación del test— que expresa la medida o valor de escala del sujeto en la característica o atributo que mide la prueba. La figura 2.1 se podría reformular del modo que se ilustra en la figura 4.1.

El siguiente apartado del capítulo se ocupa de cómo se puede asignar puntuaciones a los ítems del test y de cómo combinar éstas para obtener




FIGURA 4.1. El proceso de medición psicológica.

una única puntuación para la prueba, que expresaría el valor de escala del sujeto en el rasgo o característica medida por el test.

Una vez obtenida esa puntuación en el test para un sujeto (o grupo de sujetos), el problema al que hay que enfrentarse ahora es el de cómo interpretar ese valor. ¿Qué significa realmente que un sujeto obtenga una determinada puntuación en una prueba? ¿Qué nos está diciendo ese número acerca del nivel real en que ese sujeto posee el rasgo o característica que evalúa la prueba? El tercer apartado del capítulo se ocupa justamente de dar respuesta a estas cuestiones relativas a la interpretación de las puntuaciones de los tests.

Los objetivos que se persiguen en este capítulo son los siguientes:

- comprender la lógica que permite pasar del plano empírico al plano matemático en el proceso de medición psicológica;
- conocer las reglas que permiten asignar puntuaciones a los distintos tipos de ítems;
- saber determinar la puntuación total en el test a partir de las puntuaciones obtenidas en sus ítems;
- comprender el problema del efecto diferencial en la puntuación total del test de la tendencia de algunos sujetos a responder al azar a los ítems de elección múltiple cuando desconocen la respuesta correcta y conocer los procedimientos disponibles para resolver esta cuestión;
- diferenciar entre una interpretación normativa de las puntuaciones del test y una interpretación criterial;
- calcular e interpretar puntuaciones normativas (centiles, típicas y cronológicas).

4.2. PUNTUACIÓN DEL TEST

La puntuación o asignación de puntuaciones al test hace referencia a la determinación del valor escalar del sujeto, esto es, a la estimación del nivel real en que éste posee la característica o rasgo evaluado con la prueba. Ésta puede ser conceptualizada como un proceso bifásico, con las dos fases siguientes:

- Asignación de puntuaciones a los ítems del test.
- Combinación de las puntuaciones a los ítems para determinar la puntuación en el test.

4.2.1. Puntuación de las respuestas a los ítems

La regla de asignación de números o puntuaciones a los ítems varía según sea el tipo de ítem considerado. La mayoría de las pruebas cognitivas y una buena parte de los tests no cognitivos utilizan **ítems de elección o de respuesta cerrada** (escalas de valoración), entre otras razones, por la simplicidad y economía de su procedimiento de puntuación.

En efecto, en el caso de **pruebas cognitivas**, ésta supone simplemente el recurso a una plantilla de corrección: si la respuesta dada por el sujeto coincide con la indicada como correcta en la plantilla se asigna un uno a la respuesta y si no coincide un cero.

En el caso de **pruebas no cognitivas** la regla consiste en asignar como puntuación al ítem el código numérico correspondiente a la alternativa o categoría elegida por el sujeto. Ahora bien, antes de ello es preciso decidir qué extremo del continuo denotará una actitud/sentimiento/opinión favorable a la característica o cuestión evaluada y si éste se asociará a puntuaciones altas en la prueba. Por ejemplo, supongamos que se desea pulsar la opinión de los padres acerca de la incorporación de niños marroquíes a las aulas donde estudian sus hijos y se les aplica una prueba que tiene entre otros los dos ítems siguientes:

Es conveniente que los niños marroquíes sean escolarizados con niños españoles:

- 1) Totalmente en desacuerdo
- 2) En desacuerdo
- 3) De acuerdo
- 4) Totalmente de acuerdo

Es imposible una integración escolar normal de niños marroquíes en centros españoles:

- 1) Totalmente en desacuerdo
- 2) En desacuerdo
- 3) De acuerdo
- 4) Totalmente de acuerdo

El primer ítem presenta un enunciado positivo, favorable al constructo evaluado —actitud de los padres españoles ante la integración escolar de niños marroquíes en centros españoles— mientras que en el segundo el enunciado denota una actitud contraria a la integración. Si seguimos directamente la regla de asignación propuesta, un sujeto que escoja la tercera opción en el primer ítem recibirá la misma puntuación que otro sujeto que escoja esa misma opción en el ítem segundo. Ambos se han mostrado de acuerdo con el enunciado del ítem, solo que en un caso el enunciado denota una actitud positiva hacia la integración y en el otro una actitud negativa. El problema es que un número debe significar siempre lo mismo, o una actitud favorable o una desfavorable. Por ello, lo primero que hay que hacer es decidir si los números altos de la escala —3, 4— denotan una actitud positiva o negativa. Supongamos que se desea denoten una actitud favorable. En tal caso, antes de asignar la puntuación al segundo ítem —en general, a los ítems con un enunciado desfavorable a la característica evaluada— es preciso dar la vuelta a la escala o recodificar sus valores, de forma que 3, 4 siempre denoten una actitud favorable y 1, 2 una actitud desfavorable, con independencia del enunciado del ítem, por lo que tendremos que transformar el 1 en 4 y el 2 en 3, de modo que si un sujeto escoge la opción 3 en el segundo ítem se le asignará un 2 y si un sujeto escoge la opción 4 se le asignará un 1. De este modo, la puntuación de un sujeto que presente el patrón de respuesta (3 3) será $3 + 2 = 5$.

En la tabla 4.1 se sintetiza la forma de proceder con los distintos tipos de ítems de elección y de respuesta cerrada. Tanto en un caso como en otro, el proceso de puntuación de un test —cognitivo o no— puede ser llevado a cabo no solo de forma manual sino de forma mecánica, mediante un programa de ordenador o, si las respuestas han sido registradas en una hoja de lectura automática mediante una lectora óptica o dispositivo similar.

La puntuación de **ítems de construcción y de respuesta abierta** es harina de otro costal. Si bien el resultado final es el mismo, un valor en una escala dicotómica —de dos valores— o politómica —de más de dos valores—, el camino recorrido hasta llegar a esa puntuación es considerablemente más largo y complejo y su coste mucho más elevado.

TABLA 4.1
Reglas de asignación de puntuaciones a distintos tipos de ítems

Tipo de prueba	Tipo de ítem	Regla de asignación
COGNITIVA	Elección múltiple	1 para la respuesta correcta; 0 en caso contrario
	Elección binaria	1 para la respuesta correcta; 0 para la incorrecta
	Emparejamiento	Número de emparejamientos correctos
NO COGNITIVA	Escala de categorías	Número entero asignado a la categoría escogida
	Listado	1 si marca el término; 0 si no lo hace

La puntuación de ítems de respuesta corta —en pruebas cognitivas— y de ítems de respuesta abierta —en pruebas no cognitivas— no plantea grandes problemas. En el primer caso suele bastar con proporcionar un listado de respuestas aceptables y la regla consiste en asignar un 1 si la respuesta del sujeto está entre las de la lista y un 0 en caso contrario. En los ítems de respuesta abierta el proceso es algo más complejo, ya que antes de poder asignar puntuaciones a los ítems es preciso realizar un trabajo previo de categorización. Habitualmente, lo que se suele hacer es seleccionar una muestra de respuestas del conjunto de las obtenidas al administrar el test y, a partir de esa muestra, se definen posibles categorías de respuesta para el ítem en cuestión. A cada categoría se le asigna un código numérico y ese número será la puntuación de un sujeto que dé una respuesta clasificada en esa categoría.

Cuando las cosas se complican de verdad es cuando se trabaja con ítems de respuesta extensa.

En una convención de profesores, Starch y Elliott (1912, 1913) pidieron voluntarios para corregir una redacción de un alumno. Se utilizó una escala de 0 a 100 puntos para expresar las calificaciones dadas por los profesores. Pues bien, el rango de variación de las puntuaciones que los profesores asignaron a dicha redacción iba de 50 a 98 puntos. A la vista de estos resultados, se argumentó que la gran variabilidad observada en las puntuaciones se podía deber, en gran medida, a las preferencias de los profesores por distintos estilos de redacción. Con el fin de ver hasta qué punto era plausible esta hipótesis, los citados autores pidieron a los

profesores que corrigieran en esta ocasión un examen de geometría. El rango de variación de las puntuaciones en este caso fue considerablemente mayor que en el caso de la redacción: de 28 a 92 puntos. Entre las muchas razones que se pueden citar para explicar estos resultados —claramente decepcionantes— están la valoración diferencial que distintos profesores pueden hacer de respuestas parcialmente correctas, de la claridad y secuenciación lógica en el planteamiento y resolución de los problemas, de los errores de cálculo, etc.

Para eliminar o tratar de mantener en niveles aceptables la subjetividad del calificador a la hora de asignar una puntuación a un ítem de construcción se suelen utilizar dos métodos distintos: el método de puntuación analítica y el método de puntuación holística.

El primer procedimiento se basa en la definición inequívoca de los criterios que se deben utilizar en la corrección y asignación de puntuaciones. Los criterios deben ser definidos de tal modo que no se necesite que las personas que van a puntuar el ítem tengan grandes conocimientos del tema sobre el que éste versa. Este procedimiento se denomina método de puntuación *analítica*, ya que lo que se hace es analizar o aislar las dimensiones que se consideran relevantes en la realización de una determinada tarea, se define qué es lo que se considera como una respuesta correcta en cada una de las dimensiones aisladas y cuántas respuestas correctas, en dichas dimensiones, son necesarias para poder afirmar que la tarea ha sido correctamente realizada. Al definir de este modo los criterios que hay que utilizar en la asignación de puntuaciones se elimina, en gran medida, la subjetividad que puede introducir el calificador. Ahora bien, como señala Muñiz (1998), no es fácil prever todas las posibilidades por lo que siempre quedan zonas donde impera el criterio falible del calificador.

El segundo procedimiento consiste en entrenar a un grupo de personas que conocen en profundidad la materia sobre la que versa el ítem con el fin de que den una única puntuación que evalúe la calidad global de la respuesta que ha dado el sujeto. Por esta razón, este procedimiento recibe el nombre de método de puntuación *holística*. En la medida en que durante el entrenamiento se consiga un alto grado de acuerdo entre los jueces, este procedimiento contribuirá a eliminar la subjetividad del calificador y proporcionará un sistema de puntuación eficiente y fiable.

¿Qué método utilizar? La respuesta depende de cuál haya sido el objetivo planteado al iniciar el proceso de construcción del test en cuestión. Por ejemplo, si la utilización prevista de la prueba tiene que ver con una función diagnóstica o de información/descripción tiene más sentido utilizar el método analítico ya que éste proporciona información sobre un buen número de dimensiones críticas o relevantes del constructo evalua-

do y puede realizar una valiosa contribución. Para funciones de certificación/acreditación se podría utilizar el método holístico ya que puede ser suficiente con un único juicio global.

MC El método de puntuación analítica
El método de puntuación holística

4.2.2. Combinación de las puntuaciones a los ítems

Una vez asignadas las puntuaciones a cada ítem del test hay que proceder a combinarlas para obtener la puntuación total en la prueba (estimación del valor de escala del sujeto), para lo cual se utiliza frecuentemente la siguiente fórmula general, donde la puntuación total — X — se define como la suma ponderada de las puntuaciones obtenidas por el sujeto en los ítems del test:

$$X = \sum_{i=1}^n w_i X_i \quad (4.1)$$

donde:

w_i es el peso asignado al ítem i dentro de una prueba formada por n ítems;

X_i es la puntuación asignada al ítem i dentro de esa prueba.

Así como hay diferencias en los métodos de puntuación de ítems en pruebas cognitivas y no cognitivas, el modo de combinar las puntuaciones para obtener una única puntuación final es el mismo para ambos tipos de tests.

Govindarajulu (1988) presenta una revisión de distintos métodos para combinar las puntuaciones de los ítems en la puntuación del test. Lo más frecuente es que todos los ítems reciban el mismo peso ($w_i = w = 1$) con lo que la fórmula anterior se transforma en las pruebas cognitivas en la conocida fórmula de *puntuación por número de aciertos*:

$$X = \sum_{i=1}^n X_i \quad (4.2)$$

donde X denota ahora el número de ítems que el sujeto ha respondido correctamente, ya que los únicos valores posibles para X_i en ítems de elección múltiple y binaria son 1 o 0.

La norma es la ponderación idéntica, reservándose la ponderación diferencial para cuando existen razones de peso que así lo aconsejen.

Un problema que plantea la determinación de la puntuación total en las pruebas con ítems de elección múltiple y binaria es la tendencia que tienen algunos sujetos a responder al azar cuando no conocen la respuesta correcta a un ítem. El problema que esto plantea es que no todos los sujetos presentan este patrón de respuesta, y los que lo muestran obtienen estimaciones infladas del nivel en que poseen el rasgo o característica evaluada por la prueba, debido a los ítems acertados al azar.

Supongamos que un profesor de Matemáticas pone a los alumnos de su clase un examen que consta de 100 preguntas de elección múltiple con una dificultad similar. Atendiendo a la fórmula 4.2 la puntuación final del alumno será el número de preguntas que haya respondido correctamente. Supongamos que Álvaro y Laura saben cuál es la respuesta correcta a 40 de las preguntas. Álvaro responde sólo a las preguntas cuya respuesta conoce pero Laura decide responder a todas las preguntas del examen.

Si todas las preguntas constan de cuatro alternativas de respuesta con un atractivo similar, de las cuales sólo una es correcta y las tres restantes incorrectas, la probabilidad de escoger al azar entre todas las opciones de respuesta del ítem la opción correcta será $1/4$, una de cada cuatro. Por tanto, si Laura ha respondido al azar a 60 preguntas, es posible que haya acertado en la respuesta de $60 \times 1/4 = 15$ preguntas, por lo que la puntuación final que obtendrá en el examen de Matemáticas será $40 + 15 = 55$. Si el nivel que fija el profesor para aprobar el examen es responder correctamente al menos a la mitad de las preguntas, tendremos que Álvaro suspenderá el examen y Laura lo aprobará, aunque ambos conocían la respuesta correcta al mismo número de preguntas.

Por consiguiente, el criterio establecido para estimar el nivel de conocimientos en Matemáticas —número de preguntas correctamente respondidas— es inadecuado, ya que la puntuación que se obtiene no refleja únicamente los conocimientos matemáticos de los alumnos sino también su tendencia a responder al azar cuando no conocen la respuesta correcta y la suerte que tienen al actuar de esta manera. La discrepancia entre las puntuaciones obtenidas por Álvaro y Laura no se debe a diferencias en su rendimiento en Matemáticas —conocen la respuesta correcta al mismo número de preguntas— sino que obedece a diferencias en su tendencia a responder al azar cuando no saben la respuesta correcta. Esta tendencia hace que la puntuación de Laura se incremente de forma espúrea de 40 a 55 puntos.

Por tanto, parece conveniente eliminar o controlar la influencia que sobre la puntuación final en un test puede tener la tendencia a responder

al azar ya que, al variar ésta de individuo a individuo, introduce una variabilidad sistemática en la variabilidad de las puntuaciones observadas que no se debe a diferencias reales en el rasgo o característica que evalúa el test, sino que es una fuente de variación ajena a la situación de evaluación, por lo que debe ser controlada.

El lector se planteará —no sin razón— que si se les indica a los sujetos en las instrucciones de la prueba que respondan —o no— a todas las preguntas, aun en el caso de no estar seguros de cuál es la respuesta correcta, se puede neutralizar el efecto de esta fuente de variación ajena al constructo o característica que mide la prueba. Sin embargo, Wood (1987) realiza un estudio que pone en tela de juicio el papel uniformizador de las instrucciones para controlar el efecto que tiene en la puntuación total del sujeto su tendencia a responder al azar cuando desconoce la respuesta correcta.

La forma habitual de abordar esta cuestión es aplicando fórmulas de corrección que eliminen el efecto diferencial de este factor. ¿Cómo? Hay dos opciones:

1. Penalizar cada respuesta incorrecta, al asumir que cuando un sujeto responde incorrectamente es porque ha contestado al azar al desconocer la respuesta correcta:

$$X_c = X - A_a = A - \frac{E}{K - 1} \quad (4.3)$$

Es decir, la nueva estimación corregida — X_c — del nivel en que posee el sujeto el constructo o característica evaluada es el resultado de sustraer de la puntuación total — X — definida como el número de aciertos (A) o ítems correctamente respondidos (fórmula 4.2) el número de aciertos aleatorios (A_a) debidos al azar, que se calcula dividiendo el número de errores — E — o ítems incorrectamente respondidos entre el número de opciones incorrectas de respuesta del ítem ($K - 1$).

En el ejemplo anterior, la puntuación corregida para Álvaro es idéntica a la puntuación original ya que solo ha respondido cuando conocía la respuesta correcta, luego no hay ningún error: $X_c = 40 - 0/(4 - 1) = 40$. En el caso de Laura X_c difiere de X y, como no podía ser de otro modo, la puntuación corregida de Laura ahora sí coincide con la de Álvaro, ya que ambos conocían la respuesta correcta al mismo número de ítems: $X_c = 55 - 45/(4 - 1) = 40$.

2. Bonificar cada ítem no respondido u omitido, ya que el hecho de que no existan respuestas incorrectas prueba que el sujeto no con-

jetura al responder a los ítems del test cuando desconoce la respuesta correcta:

$$X_c = X + A_a = A + \frac{O}{K} \quad (4.4)$$

En este caso la nueva estimación corregida $-X_c-$ es el resultado de sumar a la puntuación total $-X-$ definida como el número de aciertos $-A-$ el número de aciertos aleatorios definidos como el número de omisiones $-O-$ o ítems sin responder dividido por el número de opciones del ítem $-K-$.

En el ejemplo anterior, la puntuación corregida para Álvaro es la misma que la puntuación total de Laura: $X_c = 40 + 60/4 = 55$. En el caso de Laura X_c no diferirá de X ya que ésta ha respondido a todos los ítems: $X_c = 55 + 0/4 = 55$. De este modo, son comparables las puntuaciones de los dos alumnos, al estar ahora las dos artificialmente infladas y no solo la puntuación de uno de ellos. Por ello, es más indicado el método anterior ya que se obtienen puntuaciones comparables para todos los sujetos pero no se sobreestima el nivel real en que los sujetos manifiestan o poseen la característica medida por la prueba.

4.3. INTERPRETACIÓN DE LAS PUNTUACIONES DEL TEST

Una vez asignada al sujeto una puntuación final en la prueba, el paso siguiente es interpretar esa puntuación, darle un sentido o interpretación significativa. Lo que se obtiene tras administrar un test a una muestra de sujetos es una escala primaria, una escala de puntuaciones directas (habitualmente de puntuaciones por número de aciertos), normalmente sin origen absoluto y, en ocasiones, sin una unidad constante de medida a lo largo de la escala. Estas puntuaciones pueden ser ordenadas de mayor a menor y, de este modo, se puede ordenar a los sujetos en función de que presenten en mayor o menor grado la característica que evalúa el test. En ocasiones, basta con ordenar a los sujetos. Sin embargo, cuando se trata de interpretar la actuación del sujeto en la prueba las puntuaciones directas dejan bastante que desear ya que ordenar a los sujetos no es suficiente. Para poder dotar de significado a las puntuaciones de los tests se han propuesto dos tipos de interpretaciones: la interpretación normativa o referida a una norma y la interpretación criterial o referida a un criterio.

La **interpretación normativa** se enmarca dentro de la tradición de la Psicología diferencial y enfatiza las diferencias entre los sujetos: la forma de dotar de significado a la puntuación de un sujeto es refiriéndola a una norma, comparando la actuación de ese sujeto en el test con la actuación en esa prueba de un grupo de referencia del sujeto.

La **interpretación criterial** se enmarca dentro de la tradición conductista y enfatiza lo que el sujeto sabe o es capaz de hacer: la forma de dotar de significado a la puntuación de un sujeto en un test es refiriéndola a un criterio que puede ser bien un dominio de conductas o de contenidos perfectamente definido, bien un punto de corte en la escala, que sirve para adscribir al sujeto a una categoría u otra previamente establecidas. La comparación de interés para interpretar las puntuaciones del test ya no tiene un referente normativo externo sino que se realiza en términos de la proporción estimada de ítems del dominio evaluado que el sujeto es capaz de responder correctamente o de la comparación con un criterio definido como un punto de corte en la escala de las puntuaciones del test.

Supongamos que el psicólogo de un centro escolar desea saber qué niños en 2.º curso de ESO presentan dificultades de aprendizaje en la lectura. Para obtener esta información, diseña una prueba que consta de 25 preguntas. Asimismo supongamos que, por ejemplo, Nicolás ha respondido correctamente a 13 de las preguntas y que se le asigna una puntuación de 13. A la vista de esta puntuación, ¿qué podemos concluir acerca de su nivel en lectura?: ¿el rendimiento de Nicolás es el de un alumno medio de 2.º curso de ESO o es diferente y, si lo es, cómo es de diferente?, ¿su nivel en lectura es similar al de sus compañeros en el centro?, ¿debería ser incluido Nicolás en un programa de recuperación que le ayudara a superar sus problemas con la lectura?

Ninguno de estos interrogantes puede ser respondido con la información de que disponemos: el hecho de que la puntuación directa de Nicolás en la prueba sea de 13 puntos únicamente indica que Nicolás ha respondido correctamente a 13 de las 25 preguntas de las que ésta constaba, pero no nos permite concluir nada acerca de su nivel en lectura. Veamos cómo se podría responder a estas cuestiones.

En el primer caso se trata de relacionar el rendimiento de Nicolás en la prueba con el rendimiento de un típico alumno del curso que está realizando Nicolás. El primer paso es obvio y sería determinar cuál es el rendimiento típico en esa prueba de un alumno de 2.º curso. Para ello, hay que elegir una muestra representativa de la población de niños de 2.º curso de ESO, a la que habría que aplicar la prueba diseñada para evaluar las dificultades de aprendizaje en la lectura, con el fin de estudiar, posteriormente, la distribución de frecuencias de las puntuaciones en la prue-

ba de los niños de la muestra. Una vez hecho esto, habría que ver dónde se sitúa la puntuación de Nicolás en esa distribución, si su puntuación se encuentra por debajo o por encima —y cuánto— de la puntuación que representa el comportamiento característico de un alumno medio de ese curso.

El segundo interrogante planteado es similar al anterior. La diferencia estriba en que el grupo de referencia es más reducido y tiene un carácter local, no general. En este caso, de lo que se trata es de comparar o relacionar el nivel de lectura de Nicolás, tal y como es medido por la prueba aplicada, con el de sus compañeros de curso en el centro escolar. Para ello, habría que aplicar la prueba a todos los alumnos de 2.º del centro y estudiar la distribución de sus puntuaciones para examinar, a continuación, la situación dentro de la misma de la puntuación de Nicolás.

El último interrogante formulado —la posible incorporación de Nicolás a un programa de recuperación— requiere un planteamiento muy distinto al de los dos anteriores ya que exige que se establezca, en primer término, cuándo debe incorporarse un alumno al programa y cuándo debe seguir el desarrollo normal del curso. Es decir, para poder interpretar la puntuación en el sentido planteado por la pregunta, es necesario definir un criterio que indique claramente qué características han de tener los alumnos para acceder al programa de recuperación. Una vez definido el criterio, hay que examinar la puntuación de Nicolás en relación al mismo para determinar si es asignado o no al programa de recuperación. Si su puntuación es menor que la puntuación establecida por el criterio, Nicolás deberá incorporarse al programa. Por el contrario, si su puntuación es más alta que la puntuación establecida por el criterio, Nicolás continuará el curso con sus compañeros.

En los dos primeros casos se ha dado a la puntuación de Nicolás una interpretación normativa, al compararla con la de dos grupos de referencia distintos. En el tercer caso se trata de una interpretación criterial.

4.3.1. Interpretación normativa

Como se acaba de señalar, en la interpretación normativa o referida a una norma, la puntuación obtenida por un sujeto en un test se interpreta en relación a las puntuaciones obtenidas en ese test por su grupo de referencia:

- El grupo de referencia del sujeto, también denominado **grupo normativo**, es el grupo con el que se desea comparar al sujeto.

- Las puntuaciones obtenidas en la prueba por el grupo normativo son denominadas **normas**, puntuaciones normativas o tipificadas. Por tanto, cuando se trabaja con una interpretación normativa la forma de dotar de significación a las puntuaciones es comparándolas con normas.

Las primeras normas utilizadas fueron la edad mental y el cociente intelectual, seguidas por otras puntuaciones cronológicas como los equivalentes de curso y de edad, así como por puntuaciones centiles, eneatis y un sinnúmero de puntuaciones típicas.

- La **tipificación** de un test consiste en aplicar el test a una muestra representativa de la población a la que éste va dirigido (grupo normativo) y en transformar las puntuaciones directas obtenidas por esa muestra a normas, a puntuaciones que expresen la posición relativa de un sujeto en el grupo normativo.

Existen tres tipos fundamentales de normas o puntuaciones normativas, a saber:

1. **Puntuaciones cronológicas:** indican la relación que guarda la puntuación en el test con la edad cronológica del sujeto que la ha obtenido.
2. **Puntuaciones centiles:** indican el porcentaje de sujetos del grupo normativo que puntúa por debajo de la puntuación obtenida por un sujeto determinado.
3. **Puntuaciones típicas:** indican la distancia que separa un sujeto de la media del grupo normativo, expresando dicha distancia en unidades de desviación típica.

4.3.1.1. Puntuaciones cronológicas

Las puntuaciones cronológicas refieren la actuación del sujeto a la edad cronológica de los sujetos con una actuación similar a la suya en la prueba, esto es, permiten interpretar la puntuación que un sujeto determinado ha obtenido en la prueba en relación a su edad. Por este motivo, este tipo de normas se ha empleado fundamentalmente en poblaciones infantiles y con tests de inteligencia general.

Básicamente, son dos las puntuaciones cronológicas utilizadas, a saber: la edad mental y el cociente intelectual.

La **Edad Mental** (EM) de un sujeto es la edad cronológica correspondiente a los sujetos cuya puntuación media en la prueba coincide con la del sujeto en cuestión. Por ejemplo, si la puntuación media de los

niños de 8 años en un test de inteligencia es 26 puntos, entonces al sujeto que obtenga una puntuación de 26 en el test se le asignará como puntuación una edad mental de 8 años.

CUADRO 4.1
Media de una variable

La media de una variable es una medida de tendencia central que permite resumir la información contenida en los valores que adopta esa variable en una muestra o población de sujetos en un único valor, que se calcula como la suma de todos esos valores dividida por el número de sujetos en los que se han obtenido valores de dicha variable.

Ejemplo:

Sean 20, 25, 24, 28, 32, 26 y 30 las puntuaciones obtenidas en el test anterior por una muestra de siete niños de 8 años de edad. La media de las puntuaciones en el test sería la siguiente:

$$\hat{\mu} = \bar{X} = \frac{20 + 25 + 24 + 28 + 32 + 26 + 30}{7} = 26,43$$

CUADRO 4.2
Parámetros y estadísticos

Las letras griegas se reservan para denotar los parámetros de la población que estamos interesados en conocer (μ : media; σ : desviación típica; ρ : correlación; α : intercepto; β : pendiente, etc.).

En la mayor parte de los casos, resulta totalmente imposible trabajar con todos los miembros de la población. Por ello, se suele elegir una muestra (un subconjunto de éstos) y en ésta se calculan los estadísticos correspondientes, que se denotan mediante letras latinas ($\bar{x}$: media; s : desviación típica; r : correlación; a : intercepto; b : pendiente, etc.) y se utilizan estos estadísticos como estimadores de los parámetros:

$$(\bar{X} = \hat{\mu}; \quad s = \hat{\sigma}; \quad r = \hat{\rho}; \quad a = \hat{\alpha}; \quad b = \hat{\beta}; \quad \text{etc.})$$

El problema que plantea este tipo de puntuación es que un año de edad mental no significa lo mismo a lo largo del desarrollo, ya que la distancia que va de un año al siguiente disminuye con la edad. Para paliar este inconveniente se utiliza otra norma cronológica: el cociente intelectual.

El **Cociente Intelectual** (CI) elimina el problema anterior al dividir la edad mental por la edad cronológica. El cociente intelectual se define

como la razón entre la edad mental y la Edad Cronológica (EC) multiplicada por 100, con el fin de eliminar los decimales de la escala:

$$CI = \frac{EM}{EC} 100 \quad (4.5)$$

Como ya se señaló, estos dos tipos de puntuaciones cronológicas han sido las primeras puntuaciones normativas utilizadas pero no son en absoluto las más usadas en la actualidad. Por un lado, la elaboración de este tipo de escalas es ciertamente compleja. Por otro, todos los tests poseen una edad tope a partir de la cual carecen de sentido y aplicación los conceptos de edad mental y cociente intelectual. Por consiguiente, las escalas cronológicas plantean el problema de una aplicación limitada: solo son aplicables a características o rasgos que tienen un desarrollo sistemático o que no alcanzan rápidamente la madurez y no deben ser utilizadas en tests destinados exclusivamente a poblaciones adultas.

4.3.1.2. *Puntuaciones centiles*

Las puntuaciones centiles relacionan la actuación del sujeto con la de su grupo de referencia en términos del porcentaje de sujetos que obtienen una puntuación inferior a la del sujeto en cuestión.

Se denomina *centil* o *percentil* (X_c) a aquella puntuación del test que deja por debajo de sí el c por 100 de sujetos del grupo normativo. Es decir, el centil se interpreta como el porcentaje de sujetos del grupo normativo que puntúan por debajo de esa puntuación directa en el test.

La tabla 4.2 es la tabla de conversión de puntuaciones directas a normativas correspondiente a nuestro ejemplo. Esta tabla recoge las puntuaciones obtenidas en la prueba diseñada para detectar dificultades de aprendizaje en el área de lectura por los 150 alumnos que constituyen la muestra extraída de la población de niños de 2.º curso de ESO. La primera columna corresponde a la puntuación directa obtenida por los alumnos en dicha prueba (puntuación por número de aciertos). La siguiente columna — f — indica la frecuencia con la que cada una de esas puntuaciones ha sido observada en dicha muestra (2 alumnos han obtenido una puntuación directa de 11 puntos; 1 alumno una puntuación de 12; 6 alumnos una puntuación de 13, etc.)¹. En la tercera columna — fa —

¹ Las dos primeras columnas — X y f — constituyen lo que se conoce como la distribución de frecuencias de una variable: el conjunto de valores posibles para la variable y el número de veces que cada uno de ellos ha sido observado en el conjunto de la muestra o de la población de sujetos examinada.

TABLA 4.2
Puntuaciones directas, distribución de frecuencias y puntuaciones normativas de un test para el diagnóstico de dificultades de aprendizaje en la lectura

X	f	fa	fa _{pm}	c	z	T	D
11	2	2	1	1	-2,53	25	0
12	1	3	2,5	2	-2,17	28	7
13	6	9	6	4	-1,80	32	14
14	5	14	11,5	8	-1,44	36	21
15	12	26	20	13	-1,07	39	29
16	17	43	34,5	23	-0,71	43	36
17	21	64	53,5	36	-0,34	47	43
18	28	92	78	52	0,02	50	50
19	19	111	101,5	68	0,39	54	58
20	15	126	118,5	79	0,75	58	65
21	10	136	131	87	1,12	61	72
22	5	141	138,5	93	1,48	65	80
23	3	144	142,5	95	1,85	68	87
24	4	148	146	98	2,21	72	94
25	2	150	149	99	2,58	76	100

se acumulan estas frecuencias, es decir, se suman a los sujetos que han obtenido una determinada puntuación los sujetos que obtuvieron la(s) puntuación(es) precedente(s), de forma que el valor que corresponde a la puntuación más alta obtenida en el test ha de ser siempre el número de sujetos de la muestra a la que se administró dicha prueba; así, la frecuencia acumulada para la puntuación 13 serán los 6 sujetos que obtuvieron dicha puntuación, el único sujeto que puntuó 12 y los 2 sujetos con una puntuación de 11 ($2 + 1 + 6 = 3 + 6 = 9$).

Según la tabla anterior, a la puntuación 13 —puntuación obtenida por Nicolás en el test— le corresponde el rango centil 4, lo que significa que solamente un 4 por 100 de los niños de 2.º curso de ESO responden correctamente a menos de 13 preguntas en el test examinado. La tabla 4.2 indica qué centil corresponde a cada una de las puntuaciones directas que se han obtenido realmente en el test. Un modo habitual de presentar las normas centiles es ofrecer, en lugar de la tabla anterior, una tabla en la que se dan las puntuaciones directas correspondientes a los siguientes rangos centiles: 1, 5, 10, 20, 25, 30, 40, 50, 60, 70, 75, 80, 90, 95 y 99.

La propia definición de la puntuación centil indica las operaciones que hay que realizar para determinar su valor. Veamos, por ejemplo, cómo se determinaría el centil que le corresponde a Nicolás, cuya puntuación en el test fue 13.

¿Qué porcentaje de sujetos puntúan en el grupo normativo por debajo de 13? En la columna de las frecuencias acumuladas de la tabla 4.2 vemos que hay 3 sujetos que han obtenido una puntuación inferior a 13 (dos sujetos puntuaron 11 y uno 12). Hay 6 niños que obtuvieron una puntuación de 13. Dado que la variable que mide el test es una variable continua —el nivel de competencia lectora de los alumnos—, cada una de las puntuaciones directas que aparecen en la tabla 4.2, a pesar de parecer puntuaciones o valores discretos, deben ser consideradas como el punto medio de intervalos de puntuación en el continuo de lectura. Estos intervalos tendrían de amplitud el valor uno, la unidad, e irían desde 0,5 unidades por debajo de la puntuación que aparece en la tabla hasta 0,5 unidades por encima de dicha puntuación. De otro modo, la columna relativa a X en la tabla 4.2 lo que representa realmente es el punto medio de los siguientes intervalos de puntuación:

X	Intervalo de puntuación
11	10,5-11,5
12	11,5-12,5
13	12,5-13,5
14	13,5-14,5
15	14,5-15,5
16	15,5-16,5
17	16,5-17,5
18	17,5-18,5
19	18,5-19,5
20	19,5-20,5
21	20,5-21,5
22	21,5-22,5
23	22,5-23,5
24	23,5-24,5
25	24,5-25,5

Se supone que dentro de cada uno de estos intervalos los sujetos se distribuyen de manera uniforme u homogénea a lo largo de dicho intervalo, es decir, de los 6 niños que obtuvieron una puntuación de 13 puntos, 3 se situarían entre el límite inferior de dicho intervalo —12,5— y el

punto medio —13— y los otros 3 entre el punto medio y el límite superior del intervalo —13,5—. Por consiguiente, para determinar el rango centil deseado, tendremos que sumar a los $2 + 1 = 3$ sujetos que obtuvieron puntuaciones inferiores a 13 los $6/2 = 3$ sujetos situados en el tramo 12,5-13, obteniendo así la frecuencia acumulada al punto medio del intervalo (fa_{pm} , cuarta columna de la tabla 4.2). Recuerdese que el centil se ha definido en términos del porcentaje de sujetos que obtienen una puntuación inferior a la del sujeto en cuestión: $2 + 1 + 6/2 = 6$. Por consiguiente, son 6 los sujetos que realmente puntúan por debajo de 13. Para saber qué porcentaje representan estos 6 sujetos dentro del grupo normativo, basta con hacer una simple regla de tres: $c_{13} = 6 \cdot 100/150 = 4$. Por tanto, a la puntuación 13 le corresponde el centil 4. Para obtener el valor del resto de los rangos centiles basta con multiplicar el valor de la columna fa_{pm} por la constante $100/N = 100/150 = 0,67$.

La fórmula siguiente resume la lógica utilizada para determinar el rango centil correspondiente a una puntuación directa X (c_x):

$$c_x = (fa_i + 0,5f_x) \frac{100}{N} = fa_{pm} \frac{100}{N} \quad (4.6)$$

donde:

fa_i es la frecuencia acumulada correspondiente a la puntuación inmediatamente inferior a la puntuación X (columna fa);

f_x es la frecuencia correspondiente a la puntuación X (columna f);

N es el número de sujetos que componen la muestra (valor de la columna fa correspondiente a la puntuación más alta en el test);

fa_{pm} es la frecuencia acumulada al punto medio del intervalo en el que se encuentra la puntuación X .

Para determinar un centil dado (X_c), la lógica es obviamente la misma y la fórmula que debemos aplicar la siguiente:

$$X_c = X_i + \left(\frac{N \cdot c}{100} - fa_i \right) \frac{A}{f_x} \quad (4.7)$$

donde:

X_i es el límite inferior del intervalo en el que se encuentra la puntuación directa que queremos determinar (X_c);

c es el rango centil;

A es la amplitud del intervalo, la diferencia entre el límite superior e inferior del intervalo (en nuestro ejemplo sería la unidad).

Las normas centiles son puntuaciones que se utilizan con mucha frecuencia cuando se desea informar de los resultados de un test a una audiencia no profesional —padres, profesores, autoridades educativas, opinión pública, etc.— ya que son puntuaciones muy fáciles de comprender e interpretar: decir que un sujeto ocupa el centil 20 es lo mismo que decir que supera al 20% de los sujetos de su población. Esta forma de interpretar las puntuaciones es muy clara e intuitiva. Otra característica de estas puntuaciones que hace que resulten muy atractivas es que las normas centiles se pueden usar para comparar los resultados de un mismo sujeto en varios tests: lo mismo significa un centil 20 en un test de aptitud espacial que en una prueba de rendimiento en Matemáticas. En segundo lugar, las normas centiles también se pueden usar para comparar los resultados de distintos sujetos en un mismo test. Supongamos, por ejemplo, que en un test de inteligencia Isabel obtiene 40 puntos y María 60. Las puntuaciones directas nos dicen que, si ambas pertenecen a la misma población, María es más inteligente que Isabel, pero no sabemos exactamente cuánto más, si mucho o poco. Supongamos que pertenecen a poblaciones distintas. Por ejemplo, Isabel pertenece a la población de niños de 12 años y María a la de niños de 14. Supongamos, asimismo, que el rango centil correspondiente a la puntuación de Isabel en su grupo normativo es 65 y el de María 50. A la vista de estos resultados la conclusión es obvia: Isabel es más inteligente que María, a pesar de que su puntuación directa en el test es más baja, ya que Isabel supera al 65 por 100 de los sujetos de su población de referencia y María sólo al 50 por 100. Todavía se puede precisar algo más: María es una alumna media e Isabel es francamente superior a la media. Sin embargo, no podemos afinar más. No se puede decir, por ejemplo, que Isabel sea 15 unidades superior a María ya que estas unidades son rangos centiles y no tienen más significación que la ordinal.

4.3.1.3. Puntuaciones típicas

Las puntuaciones típicas refieren la actuación del sujeto a la media del grupo normativo en términos de unidades de desviación típica, esto es, indican la distancia que separa a un sujeto que ha obtenido una puntuación determinada en el test de la media de su grupo, utilizando como unidad para medir esa distancia la desviación típica del grupo normativo del sujeto.

Hay dos tipos básicos de puntuaciones típicas: la escala típica lineal (Z) y la escala típica normalizada (Z_n).

La escala típica lineal es la más simple de todas las escalas de normas típicas. Esta escala indica a cuántas desviaciones típicas se encuentra una

CUADRO 4.3
Varianza de una variable

La varianza de una variable es una medida de la variabilidad o dispersión mostrada por los valores que adopta dicha variable en una muestra o población de sujetos, es decir, indica si estos valores son muy parecidos (poca variabilidad) o muy diferentes (mucha variabilidad) y se calcula aplicando la siguiente fórmula:

$$\sigma_x^2 = \frac{\sum_{i=1}^N (X_i - \mu_x)^2}{N} = \frac{\sum_{i=1}^N X_i^2}{N} - \mu_x^2 = \frac{\sum_{i=1}^N X_i^2}{N} - \left(\frac{\sum_{i=1}^N X_i}{N} \right)^2$$

Ejemplo:

Sean 4, 6, 8, 10 y 12 los valores que adopta la variable X en una muestra de cinco sujetos. La varianza de esta variable sería la siguiente:

$$\hat{\sigma}_x^2 = s_x^2 = \frac{\sum_{i=1}^5 X_i^2}{5} - \left(\frac{\sum_{i=1}^5 X_i}{5} \right)^2 = \frac{4^2 + 6^2 + 8^2 + 10^2 + 12^2}{5} - \left(\frac{4 + 6 + 8 + 10 + 12}{5} \right)^2 = 8$$

$$\hat{\sigma}_x^2 = s_x^2 = \frac{\sum_{i=1}^5 (X_i - \mu_x)^2}{5} = \frac{(4 - 8)^2 + (6 - 8)^2 + (8 - 8)^2 + (10 - 8)^2 + (12 - 8)^2}{5} = 8$$

Desviación típica de una variable

Es la raíz cuadrada de la varianza de una variable:

$$\sigma_x = \sqrt{\frac{\sum_{i=1}^N X_i^2}{N} - \left(\frac{\sum_{i=1}^N X_i}{N} \right)^2}$$

puntuación de la media del test y se elabora, sencillamente, convirtiendo las puntuaciones directas en puntuaciones típicas, para lo cual hay que aplicar la siguiente fórmula:

$$Z = \frac{X - \mu_X}{\sigma_X} \quad (4.8)$$

Calculemos la puntuación típica de Nicolás. A partir de la distribución de frecuencias de su grupo normativo proporcionada en la tabla 4.2, se calcula la media y desviación típica de las puntuaciones de dicho grupo en el test. Estos valores son, respectivamente, 17,94 y 2,74 (*véase* cuadros 4.1 y 4.3). Por tanto, la puntuación típica de Nicolás será $Z = (13-17,94)/2,74 = -1,80$. Esta puntuación indica que Nicolás se encuentra a una distancia de casi dos desviaciones típicas por debajo de la media de los niños de 2.º curso de ESO. El signo de la puntuación indica la zona en la que se encuentra el sujeto en relación a la media de su grupo (signo positivo, por encima de la media y negativo por debajo) y el valor de la puntuación revela la magnitud de la distancia que lo separa del punto medio de la escala, tomando como unidad de medida la desviación típica del grupo. En la sexta columna de la tabla 4.2 aparecen las puntuaciones típicas correspondientes a las puntuaciones directas en el test.

La gran ventaja que presentan las puntuaciones típicas frente a las directas es que su significación es universal, siempre y cuando las distribuciones de las puntuaciones de los tests que se comparan sean similares. Realicemos este supuesto, supongamos que la distribución de las puntuaciones en el test 1 es similar a la distribución de las puntuaciones en el test 2. Si un sujeto obtiene en el test 1 una puntuación directa de 40 ($X_1 = 40$) y en el test 2 de 70 ($X_2 = 70$) no podemos saber en qué test ha obtenido una puntuación mejor; ya que no conocemos el rango de la escala utilizada en cada test. Transformemos estas puntuaciones directas a típicas. Sean $Z_1 = 1,5$ y $Z_2 = 1,5$ las puntuaciones en la escala típica. Estas puntuaciones sí nos permiten sacar algunas conclusiones sobre la actuación del sujeto en los dos tests: es superior a la media de su grupo en ambos tests y además en la misma cuantía, a pesar de que sus puntuaciones directas difieren considerablemente entre sí.

El inconveniente más importante de esta escala es que tiene el origen —valor 0— en el centro de la escala —lo que significa que existirán valores negativos— y que su recorrido es muy pequeño (básicamente, de -3,0 a 3,0), lo que significa que existirán valores decimales en la escala.

Escalas derivadas de puntuaciones típicas lineales

Una forma sencilla de evitar estos inconvenientes es transformar las puntuaciones típicas en otras de más cómodo manejo. Las escalas típicas derivadas son escalas obtenidas mediante una transformación lineal de las escalas de puntuaciones típicas. La forma general de la transformación lineal es:

$$Y = A + BZ \quad (4.9)$$

donde Y es la puntuación típica derivada y A y B son constantes elegidas de forma arbitraria para obtener la escala más apropiada para el caso en cuestión. El valor elegido para A será la media de las puntuaciones típicas derivadas y el valor elegido para B la desviación típica de su distribución.

Entre las escalas típicas derivadas más frecuentemente utilizadas podemos destacar las siguientes:

— Escala T : $T = 50 + 10Z$ (4.10)

Fue desarrollada por McCall (1939) para informar de los resultados obtenidos por poblaciones infantiles en tests de habilidad mental.

Esta escala tiene ahora no 6 unidades como la escala típica lineal sino $6 \times 10 = 60$, con una media de 50, una desviación típica de 10 y $\approx$ un rango de 20 a 80.

La puntuación de Nicolás en esta escala sería $T = 50 + 10(-1,80) = 31,9$ 32, una puntuación positiva y entera, sin decimales (es preciso redondear siempre al valor entero más próximo) y con un significado mucho más directo e intuitivo que la puntuación típica original.

En la séptima columna de la tabla 4.2 aparecen las puntuaciones T correspondientes a las puntuaciones directas obtenidas en nuestro estudio de tipificación.

— Escala D : $D = 50 + 20Z$ (4.11)

Es muy semejante a la anterior: la única diferencia radica en que se define una desviación típica mayor para las puntuaciones transformadas, por lo que aumenta el rango de variación posible de las mismas.

En la octava columna de la tabla 4.2 aparecen las puntuaciones D correspondientes a las puntuaciones directas obtenidas en nuestro estudio de tipificación.

Las escalas típicas derivadas resuelven el problema de trabajar con decimales y valores negativos pero, al ser una transformación lineal de la escala típica², persiste una de sus características: si son distintas las distribuciones de las puntuaciones de los tests que se desea comparar, la significación de las puntuaciones no es la misma y, por lo tanto, no se pueden comparar. Una forma de evitar el inconveniente anterior consiste en utilizar una escala típica normalizada.

4.3.2. Interpretación criterial

Como se acaba de ver en el subapartado anterior, la interpretación normativa de un test consiste en establecer la equivalencia entre las puntuaciones obtenidas por los sujetos y las normas del test, para expresar así la posición relativa de un sujeto en el grupo normativo. La puntuación de un sujeto se interpreta o dota de significado comparándola con las puntuaciones de otros sujetos, es decir, con las puntuaciones de su grupo normativo o de referencia, mostrando en qué medida ese sujeto puede hacerlo mejor o peor que otros sujetos de su grupo. Sin embargo, en la interpretación criterial la comparación de los sujetos entre sí carece de importancia y lo que sí es fundamental es comparar la actuación del sujeto en el test con un criterio definido *a priori* para áreas o dominios conductuales o de contenido bien especificados; esta comparación nos va a permitir describir la actuación del sujeto en términos de lo que éste sabe o no hacer (con total independencia de lo que saben o no saben hacer los sujetos de su grupo de referencia) o nos va a permitir situar al sujeto en una categoría u otra, al margen de dónde se ubiquen sus iguales. En suma, la forma de interpretar las puntuaciones es comparándolas con un criterio que puede ser definido o conceptualizado de dos formas diferentes.

En primer lugar, el criterio con el que se comparan las puntuaciones puede ser una puntuación de corte, un punto en la escala de las puntuaciones del test que se utiliza para clasificar a los sujetos en dos categorías, que reflejan niveles diferentes de consecución de los objetivos, habilidades o competencias medidas por el test. Estas dos categorías definen dos grupos distintos: un grupo «cualificado», «competente», o «master», que consta de sujetos con un dominio o maestría adecuado o suficiente del material evaluado por el test y un grupo «no cualificado», «no competen-

² Observe el lector que la ecuación (4.8) se puede describir en términos de la ecuación (4.9) del siguiente modo:

$$Z = \frac{-\mu_x}{\sigma_x} + \frac{1}{\sigma_x} X = A + BX$$

te» o «nonmaster», que consta de sujetos con un dominio o maestría inadecuado o insuficiente. Por consiguiente, lo que se hace es utilizar el criterio como una *regla de decisión aplicada a las puntuaciones del test*: si la puntuación del sujeto es igual o superior a la puntuación definida como punto de corte, se considera que el sujeto pertenece al grupo cualificado o competente, pero si su puntuación es inferior al punto de corte, se considera que el sujeto pertenece al grupo no cualificado o no competente.

Como el lector ya habrá imaginado, la cuestión básica a la hora de interpretar de este modo las puntuaciones del test es cómo determinar o establecer esa puntuación de corte, cómo elegir un valor de la escala de puntuaciones del test como punto de corte, a partir del cual clasificar a los sujetos dentro de uno u otro grupo (se accede al programa de recuperación de lectura o se sigue el desarrollo normal del curso, se muestra un repertorio de conductas adecuado o una actuación inapropiada en un determinado dominio conductual, se domina suficientemente —o no— los contenidos básicos de un área particular de conocimiento, etc.). Ésta no es una cuestión baladí, ya que la elección de un determinado punto de corte depende siempre de juicios de valor, por lo que el componente subjetivo es inevitable en algún momento del proceso: no existe una puntuación de corte «verdadera» que pueda ser determinada por un método particular, por lo que sea cual sea el punto de corte finalmente establecido, siempre dará lugar a errores de clasificación (sujetos clasificados dentro del grupo competente cuando en realidad pertenecen al grupo de sujetos con un nivel inadecuado de dominio o maestría y a la inversa).

Son muchos los métodos que se han propuesto para determinar el valor de la puntuación de corte y hay también distintos modos de clasificarlos. Una clasificación habitual (Hambleton y Eignor, 1980; Hambleton, 1985) los divide en los siguientes tres grandes bloques:

1. **Métodos valorativos:** Son métodos en los que se pide a un grupo de jueces expertos que evalúen cómo sería la actuación en el test o en cada uno de sus ítems de un sujeto considerado con un nivel mínimo de competencia.

Entre estos métodos los hay basados en consideraciones relativas al contenido del test, al contenido de los ítems y a características tales como el acierto al azar de los mismos.

2. **Métodos empíricos:** Son métodos en los que es necesario aplicar pruebas y recoger datos del test para establecer la correspondiente puntuación de corte.

Entre estos métodos los hay basados en la teoría de la decisión y en medidas del criterio.

3. **Métodos mixtos:** Son métodos que utilizan datos tanto valorativos como empíricos a la hora de establecer la puntuación de corte.

Entre estos métodos los hay basados en posibles consecuencias educativas, en datos empíricos procedentes de distintos grupos y en métodos bayesianos.

En la tabla 4.3 se presenta una posible clasificación de estos métodos.

Esta suele ser la definición más frecuente y habitual del criterio cuando se realiza una interpretación criterial de las puntuaciones del test: el criterio definido como una puntuación de corte con la que se compara la puntuación obtenida por el sujeto con el fin de adscribirlo a una u otra categoría según que esta última sea mayor o menor que la primera.

La segunda definición posible del criterio nos devuelve al terreno del dominio conductual o de contenidos para cuya evaluación ha sido dise-

TABLA 4.3
Clasificación de los métodos para establecer puntuaciones de corte

VALORATIVOS	EMPÍRICOS	MIXTOS
Contenido del test • Shepard (1976) • Glass (1978)	Medida del criterio • Livingston (1975, 1976) • van der Linden y Mellenbergh (1977)	Empírico-valorativo • Grupo límite (Zwick y Livingston, 1977) • Grupo de contraste (Zwick y Livingston, 1977) • Grupos criterio (Berk, 1976)
Contenido del ítem • Nedelsky (1954) • Angoff (1971) • Jaeger (1978) • Ebel (1979)		Consecuencias educativas • Block (1972)
Acierto al azar • Millman (1973)	Teoría de la decisión • Kriewal (1972) • Hambleton y Novick (1973) • Millman (1974) • Huynh (1976, 1981) • van der Linden (1981, 1990)	Métodos bayesianos • Hambleton y Novick (1973) • Schoon, Gullion y Ferrara (1979)

ñado el test cuyas puntuaciones estamos tratando ahora de interpretar y es que, en este caso, la forma de interpretar la puntuación del sujeto en el test es en términos de la proporción estimada de ítems del dominio evaluado que el sujeto domina o es capaz de responder correctamente. De esta forma es posible describir la actuación del sujeto en el test en términos de lo que sabe y no sabe hacer y se puede determinar el *lugar o status del sujeto respecto a un dominio conductual bien definido* (Popham, 1978). Ahora bien, para ello es condición *sine qua non* que la fase de especificación del test haya sido realizada de forma totalmente rigurosa y pormenorizada, ya que las puntuaciones del test son *interpretadas en relación al dominio especificado para el test*. Por consiguiente, la interpretabilidad de sus puntuaciones se verá maximizada si la especificación del dominio es lo más clara, precisa y detallada posible.

En resumen, se trata de evaluar la actuación del sujeto no en relación a la actuación de otros sujetos en el test (interpretación normativa) sino en relación a un criterio, estándar u objetivo claramente definido, bien con el objeto de describir la actuación del sujeto en términos de lo que sabe o no sabe hacer en el campo o área de conocimiento examinado, bien para tomar decisiones acerca de su competencia, suficiencia, maestría o dominio de la materia evaluada.

4.4. PUNTOS BÁSICOS

- La asignación de puntuaciones al test permite representar numéricamente los indicadores empíricos —las respuestas a los ítems del test— utilizados, a su vez, para representar empíricamente la característica de interés que evalúa el test.
- La asignación de puntuaciones a un test consiste en asignar previamente puntuaciones a los ítems que componen el test para posteriormente combinar esas puntuaciones en una única puntuación —la puntuación del test— que expresa el valor de escala del sujeto en el rasgo o característica medida por la prueba.
- En pruebas cognitivas con ítems de elección la asignación de puntuaciones a los ítems supone el recurso a una plantilla de corrección: si la respuesta dada por el sujeto coincide con la indicada como correcta en la plantilla se le asigna un uno a la respuesta y si no coincide un cero.
- En pruebas no cognitivas con ítems de respuesta cerrada se asigna como puntuación al ítem el código numérico correspondiente a la alternativa o categoría elegida por el sujeto.

- En pruebas no cognitivas con ítems de respuesta cerrada con enunciados positivos y negativos es preciso recodificar apropiadamente las categorías de respuesta con el fin de que un número signifique siempre lo mismo (una actitud/sentimiento/opinión favorable o desfavorable), con independencia de que el enunciado del ítem denote una actitud/sentimiento/opinión favorable o desfavorable hacia la cuestión examinada.
- En pruebas cognitivas con ítems de respuesta corta se confecciona un listado de posibles respuestas aceptables y se asigna un uno si la respuesta dada está en la lista y un cero en caso contrario.
- En pruebas no cognitivas con ítems de respuesta abierta para poder asignar puntuaciones a los ítems es preciso categorizar las respuestas: establecer un sistema de categorías con las posibles respuestas y asignar a cada respuesta el código correspondiente a la categoría de la respuesta en cuestión.
- En pruebas cognitivas con ítems de construcción se puede utilizar el método holístico o el analítico para asignar puntuaciones a los ítems.
- La puntuación total en el test se define como la suma ponderada de las puntuaciones obtenidas por el sujeto en los ítems del test.
- En la puntuación por número de aciertos todos los ítems reciben el mismo peso, la unidad.
- Para controlar la influencia que sobre la puntuación final en un test puede tener la distinta tendencia de los sujetos a responder al azar cuando desconocen la respuesta correcta a un ítem se utilizan fórmulas de corrección, que penalizan las respuestas incorrectas o que bonifican las omisiones.
- Para poder dotar de significado a las puntuaciones de los tests se puede optar por una interpretación normativa o criterial.
- En la interpretación normativa se compara la actuación del sujeto en el test con la actuación en esa prueba de un grupo de referencia del sujeto (grupo normativo), utilizando para ello puntuaciones normativas o tipificadas (cronológicas, centiles o típicas).
- En la interpretación criterial se compara la actuación del sujeto en el test con un criterio que puede ser bien un punto de corte en la escala —que sirve para adscribir al sujeto a una categoría u otra previamente establecidas— bien un dominio de conducta o de contenido perfectamente definido —que sirve para describir la actuación del sujeto en términos de lo que éste sabe o no hacer.

4.5. EJERCICIOS

4.5.1. En la siguiente tabla se presentan los resultados obtenidos en un estudio de tipificación de una batería de tests X , compuesta por cuatro subtests (X_1 , X_2 , X_3 y X_4). Además de la media y la desviación típica de las puntuaciones en los subtests del grupo normativo, en la tabla se presentan las puntuaciones obtenidas por dos sujetos en dichos subtests:

	X_1	X_2	X_3	X_4
$\bar{X}_i$	26	15	22	28
S_{x_i}	7	6	4	8
X_{A_i}	35	26	28	30
X_{B_i}	41	30	15	15

4.5.1.1. Calcule las puntuaciones típicas lineales y las puntuaciones derivadas D y T de los sujetos A y B .

4.5.1.2. Determine la ecuación de conversión para transformar las puntuaciones del subtest X_3 en una escala con media 500 y desviación típica 100.

4.5.1.3. Determine las puntuaciones de los sujetos A y B en la nueva escala.

4.5.2. En la tabla siguiente se presentan las opciones seleccionadas por cinco sujetos en los ítems de un test. Todos ellos son ítems de elección múltiple con cuatro distractores codificados como A, B, C, D o E. El código H se utiliza para denotar un ítem dejado en blanco por el sujeto y la plantilla de corrección es la siguiente:

A B B C A D B A C C A D E E B B B C A A

Calcule la puntuación corregida por azar de dichos sujetos.

1: A B B C A D A A C C C D E E H B B C H H

2: B A B C A D B A C C D D E A B H H H H H

3: A B B E A H B A C C A D E H B B D C A A

4: A B D C H D B H C D A D H E B B B C A H

5: A A B C A H B D C D A H E E B H B H H H

4.5.3. Empareje mediante flechas los términos de la columna izquierda con los de la derecha.

Centil	Medida de variabilidad
Plano matemático	Norma
Puntuación tipificada	Interpretación criterial
Puntuación típica	Puntuación en el test
Plano teórico	Respuestas a los ítems del test
Media	Constructo a evaluar
Punto de corte	Equivalentes de curso y edad
Varianza	Medida de tendencia central
Puntuación cronológica	D, T, Z
Plano empírico	Puntuación directa que deja por debajo de sí un determinado porcentaje de sujetos

4.5.4. Calcule la puntuación corregida por azar de los sujetos cuyas respuestas en un test de elección múltiple han sido las siguientes:

SUJETOS	RESPUESTAS A LOS ÍTEMS
1	1 1 1 0 1 1 1 1 0 9 0 0 1 0 9 9 9 9 9 9
2	1 1 0 1 1 1 0 0 1 0 9 9 1 1 0 1 0 9 9 9
3	1 1 1 1 1 1 1 0 1 1 1 1 9 1 1 1 1 0 0 0
4	1 1 0 0 1 9 0 1 1 0 1 1 9 9 1 0 0 1 9 9
5	1 9 0 1 1 9 1 1 1 0 9 1 1 0 1 1 9 1 1 1

sabiendo que 1 es el código utilizado para una respuesta correcta, 0 el utilizado para una respuesta incorrecta y 9 para una pregunta en blanco y sabiendo, asimismo, que los 10 primeros ítems del test tienen 3 opciones de respuesta, los 5 siguientes, 4 opciones de respuesta y los 5 últimos, 5 opciones de respuesta.

4.5.5. En un centro escolar se realiza una prueba para seleccionar a los alumnos que pueden acceder a un curso avanzado de Informática. La prueba consta de 10 preguntas que tienen distinta dificultad (0,10, 0,15, 0,20, 0,30, 0,40, 0,50, 0,55, 0,60, 0,70 y 0,85, respectivamente). Cada una de las preguntas es puntuada en una escala de 5 puntos, con valores de 1 a 5, ponderando esta puntuación por su dificultad para obtener la puntuación total en el test. En la tabla siguiente se proporcionan las respuestas dadas por siete alumnos al conjunto de ítems de la prueba.

4.5.5.1. ¿Cuál es la puntuación más baja que se puede obtener?, ¿y la más alta?

4.5.5.2. Si solamente hay tres plazas disponibles en ese curso, ¿qué alumnos serán los que finalmente se matriculen en el curso?

4.5.5.3. Si se define como punto de corte un valor de 11, ¿qué alumnos accederán ahora al curso?

	Ítem n.º									
Alumno n.º	1	2	3	4	5	6	7	8	9	10
1	5	5	4	5	3	5	2	3	2	1
2	5	4	4	3	5	3	3	2	1	1
3	5	5	5	5	5	5	4	4	4	3
4	4	5	4	4	5	3	3	2	1	1
5	4	4	3	4	3	2	3	1	1	1
6	3	4	4	5	4	3	3	3	2	3
7	5	4	5	4	4	3	2	2	1	1

4.5.6. A continuación se presentan las calificaciones obtenidas por los alumnos de una clase de 3.º curso de ESO en la asignatura de Idioma Extranjero.

4 6 7 6 8 5 5 8 3 1 9 9 5 7 6 6 3 2 2 7 9 5 3 8

4.5.6.1. Calcule el rango percentil correspondiente a una calificación de notable (7).

4.5.6.2. ¿Cuál es el percentil 50?

4.6. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

4.6.1.1. Para calcular las puntuaciones Z, D y T de los sujetos A y B hay que aplicar las ecuaciones (4.8), (4.10) y (4.11):

$$Z = \frac{X - \mu_x}{\sigma_x}$$

$$D = 50 + 20Z$$

$$T = 50 + 10Z$$

	X_1	X_2	X_3	X_4
Z_A	1,29	1,83	1,50	0,25
Z_B	2,14	2,50	-1,75	-1,62
D_A	76	87	80	55
D_B	93	100	15	18
T_A	63	68	65	52
T_B	71	75	32	34

4.6.1.2. Lo que se nos plantea en este problema es encontrar una ecuación que nos permita transformar las puntuaciones del subtest X_3 en las puntuaciones de una nueva escala con media 500 y desviación típica 100. Es decir, si denominamos Y a las puntuaciones en esta nueva escala, lo que tendremos que hacer será calcular los valores de A y B de la ecuación (4.9): $Y = A + BX_3$.

Tenemos, por tanto, una única ecuación con dos incógnitas. Ahora bien, para hallar el valor de A y B podemos tener en cuenta que lo que sí conocemos es la media y la desviación típica de las puntuaciones en la nueva escala ($\mu_y = 500$ y $\sigma_y = 100$) y en la escala original ($\mu_{x_3} = 22$ y $\sigma_{x_3} = 4$). Al ser definida Y como una combinación lineal de X_3 , el valor de su media y su desviación típica es función de la media y desviación típica de X_3 :

$$\mu_y = A + B\mu_{x_3}$$

$$\sigma_y = B\sigma_{x_3}$$

Si sustituimos μ_y , μ_{x_3} , σ_y y σ_{x_3} por su valor, se obtienen directamente los valores de A y B :

$$500 = A + 22B$$

$$100 = 4B$$

de donde se deduce inmediatamente que $B = 25$ y que $A = -50$.

Por consiguiente, la ecuación de conversión de la escala de puntuaciones directas del subtest X_3 en una escala de media 500 y desviación típica 100 será la siguiente:

$$Y = -50 + 25X$$

$$\mathbf{4.6.1.3.} \quad Y_A = -50 + 25 \times 28 = 650 \quad Y_B = -50 + 25 \times 15 = 325$$

4.6.2. Lo primero que hay que hacer es corregir los tests de los 5 alumnos mediante la plantilla de corrección, indicando un acierto mediante la letra A, un error mediante la E y una omisión con la O:

1: A A A A A A E A A A E A A A O A A A O O

2: E E A A A A A A A A E A A E A O O O O O

3: A A A E A O A A A A A A A O A A E A A A

4: A A E A O A A O A E A A O A A A A A A O

5: A E A A A O A E A E A O A A A O A O O O

A continuación, contaremos el número de aciertos, de errores y de omisiones de cada sujeto:

$$A_1 = 15 \ E_1 = 2 \ O_1 = 3$$

$$A_2 = 11 \ E_2 = 4 \ O_2 = 5$$

$$A_3 = 16 \ E_3 = 2 \ O_3 = 2$$

$$A_4 = 14 \ E_4 = 2 \ O_4 = 4$$

$$A_5 = 11 \ E_5 = 3 \ O_5 = 6$$

Ahora podemos calcular ya la puntuación corregida por azar, aplicando las ecuaciones (4.3) y (4.4):

$$X_{c(e)} = A - E/(K - 1)$$

$$X_{c(o)} = A + O/K$$

Sujetos	$X_{c(e)}$	$X_{c(o)}$
1	14,50	15,60
2	10	12
3	15,50	16,40
4	13,50	14,80
5	10,25	12,20

4.6.3. Centil → Puntuación directa que deja por debajo de sí un determinado porcentaje de sujetos; Plano matemático → Puntuación en el test; Puntuación tipificada → Norma; Puntuación típica → D, T, Z; Plano teórico → Constructo a evaluar; Media → Medida de tendencia central; Punto de corte → Interpretación criterial; Varianza → Medida de variabilidad; Puntuación cronológica → Equivalentes de curso y edad; Plano empírico → Respuestas a los ítems del test.

4.6.4. Para calcular la puntuación corregida por azar de estos alumnos, hay que aplicar las ecuaciones (4.3) y (4.4). Ahora bien, estas fórmulas sólo pueden ser aplicadas si los ítems tienen el mismo número de distractores. Como este test tiene ítems con 3, 4 y 5 alternativas de respuesta, la solución es aplicar las fórmulas anteriores a todos los ítems con 3 opciones de respuesta, aplicarlas después a los ítems con 4 opciones de respuesta y, por último, a los ítems con 5 opciones de respuesta. Calculemos el número de aciertos, errores y omisiones en los tres tipos de ítems de los 5 sujetos:

Sujetos	3 OPCIONES			4 OPCIONES			5 OPCIONES		
	A	E	O	A	E	O	A	E	O
1	7	2	1	1	3	1	0	0	5
2	6	4	0	2	1	2	1	1	3
3	9	1	0	4	0	1	2	3	0
4	5	4	1	3	0	2	1	2	2
5	6	2	2	3	1	1	4	0	1

Una vez obtenidos estos valores, se puede calcular ya la puntuación corregida por azar en cada uno de los tres tipos de ítems, sin más que aplicar las fórmulas anteriores:

$$X_{c(e)} = A - E/(K - 1)$$

$$X_{c(o)} = A + O/K$$

Sujetos	3 OPCIONES		4 OPCIONES		5 OPCIONES	
	$X_{c(e)}$	$X_{c(o)}$	$X_{c(e)}$	$X_{c(o)}$	$X_{c(e)}$	$X_{c(o)}$
1	6	7,33	0	1,25	0	1
2	4	6	1,67	2,50	0,75	1,60
3	8,50	9	4	4,25	1,25	2
4	3	5,33	3	3,50	0,5	1,40
5	5	6,67	2,67	3,25	4	4,20

Para obtener una única puntuación corregida para cada sujeto, simplemente habrá que sumar las puntuaciones obtenidas en cada uno de los tres tipos de ítem:

Sujetos	$X_{c(e)}$	$X_{c(o)}$
1	6	9,58
2	6,42	10,10
3	13,75	15,25
4	6,50	10,23
5	11,67	14,12

4.6.5.1. Dado que la puntuación total en la prueba se define como la suma ponderada de la puntuación de cada ítem, siendo la dificultad del ítem el peso de dicha puntuación, la fórmula que habrá que utilizar para calcular la puntuación será la (4.1) y la puntuación más baja será:

$$X_{\text{masbaja}} = (0,10 \times 1) + (0,15 \times 1) + (0,20 \times 1) + (0,30 \times 1) + (0,40 \times 1) + (0,50 \times 1) + (0,55 \times 1) + (0,60 \times 1) + (0,70 \times 1) + (0,85 \times 1) = 4,35$$

y la puntuación más alta

$$X_{\text{masalta}} = (0,10 \times 5) + (0,15 \times 5) + (0,20 \times 5) + (0,30 \times 5) + (0,40 \times 5) + (0,50 \times 5) + (0,55 \times 5) + (0,60 \times 5) + (0,70 \times 5) + (0,85 \times 5) = 21,75$$

4.6.5.2. Lo primero que hay que hacer es calcular la puntuación obtenida por cada uno de los aspirantes en la prueba mediante la ecuación (4.1).

ÍTEM		PUNTUACIONES DE LOS SUJETOS A LOS ÍTEMS													
n.º	w	X_1	wX_1	X_2	wX_2	X_3	wX_3	X_4	wX_4	X_5	wX_5	X_6	wX_6	X_7	wX_7
1	0,10	5	0,50	5	0,50	5	0,50	4	0,40	4	0,40	3	0,30	5	0,50
2	0,15	5	0,75	4	0,60	5	0,75	5	0,75	4	0,60	4	0,60	4	0,60
3	0,20	4	0,80	4	0,80	5	1,00	4	0,80	3	0,60	4	0,80	5	1,00
4	0,30	5	1,50	3	0,90	5	1,50	4	1,20	4	1,20	5	1,50	4	1,20
5	0,40	3	1,20	5	2,00	5	2,00	5	2,00	3	1,20	4	1,60	4	1,60
6	0,50	5	2,50	3	1,50	5	2,50	3	1,50	2	1,00	3	1,50	3	1,50
7	0,55	2	1,10	3	1,65	4	2,20	3	1,65	3	1,65	3	1,65	2	1,10
8	0,60	3	1,80	2	1,20	4	2,40	2	1,20	1	0,60	3	1,80	2	1,20
9	0,70	2	1,40	1	0,70	4	2,80	1	0,70	1	0,70	2	1,40	1	0,70
10	0,85	1	0,85	1	0,85	3	2,55	1	0,85	1	0,85	3	2,55	1	0,85
TOTAL			12,40		10,70		18,20		11,05		8,80		13,70		10,25

Los tres alumnos que han obtenido las puntuaciones más altas son los alumnos números 3, 6 y 1, en este orden. Por tanto, serán éstos los alumnos que accedan al curso avanzado de Informática.

4.6.5.3. Los alumnos que han obtenido una puntuación total en el test superior al punto de corte marcado (11) son el número 1, 3, 4 y 6. Por tanto, serán estos cuatro alumnos los que realicen el curso avanzado de Informática.

4.6.6. Lo primero que hay que hacer es construir la distribución de frecuencias de esas calificaciones:

X	f_x	f_a
1	1	1
2	2	3
3	3	6
4	1	7
5	4	11
6	4	15
7	3	18
8	3	21
9	3	24

4.6.6.1. Según (4.6),

$$C_x = (fa_i + 0,5f_x)100/N = (15 + 0,5 \times 3)100/24 = 68,75$$

El 68,75 por 100 de los alumnos de esa clase han obtenido calificaciones por debajo del notable en Idioma Extranjero.

4.6.6.2. Según (4.7),

$$X_c = X_i + (Nc/100 - fa_i)A/f_x = 5,5 + (24 \times 50/100 - 11)1/4 = 5,75$$

La mitad de los alumnos obtiene una nota inferior a 5,75.

4.7. BIBLIOGRAFÍA BÁSICA RECOMENDADA

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulo 20.

En este capítulo se abordan básicamente cuestiones relativas a la asignación de puntuaciones y a su interpretación normativa.

MUÑOZ, J. (1998). *Teoría clásica de los tests*. Madrid: Pirámide. Capítulo 5.

El capítulo se ocupa de la interpretación normativa de las puntuaciones de los tests.

4.8. LECTURAS SUGERIDAS

ANGOFF, W. H. (1971). Scales, norms and equivalent scores. En R. L. Thorndike (Ed.), *Educational Measurement*. Washington, DC: American Council on Education.

Este capítulo constituye una referencia obligada y todavía vigente —a pesar de sus tres décadas de existencia— para el tema relativo a la interpretación normativa de las puntuaciones de los tests.

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulo 21.

En este capítulo se realiza una presentación detallada de los tests referidos al criterio, su historia, su caracterización frente a los tests referidos a la norma, la forma de establecer el punto de corte y los criterios métricos de calidad aplicados a este tipo de pruebas.

La revista *Educational Measurement: Issues and Practice* dedicó en 1994 el número 4 del volumen 13 a la medición referida a un criterio, con un total de ocho artículos firmados por los autores más destacados en el campo, donde se realiza un análisis que va desde los orígenes de los tests referidos a un criterio a su situación actual, pasando por las implicaciones que éstos han tenido en el proceso de enseñanza-aprendizaje y otras cuestiones de gran interés.

4.9. MATERIAL COMPLEMENTARIO


- El método de puntuación analítica.
- El método de puntuación holística.

LAS TEORÍAS DE LOS TESTS

María José Navas Ara

5.1. INTRODUCCIÓN

En los dos capítulos anteriores hemos recorrido el camino que nos permite pasar del *plano teórico*, en el que se encuentran las características o constructos psicológicos —no directamente observables— que queremos medir, al *plano empírico* en el que se encuentran los indicadores —directamente observables— que representan empíricamente a esas características —las más de las veces las respuestas de los sujetos a los ítems del test— y de éste al *plano matemático*, en el que estos indicadores son representados numéricamente a través de las puntuaciones en el test.



Es más, en el capítulo 4 hemos visto no solo cómo llegar a esa puntuación, que se *supone* es una estimación del nivel en que el sujeto posee la característica que *en principio* mide ese test sino que, además, se ha visto cómo interpretar o dotar de significado a esa puntuación. Ahora bien, hay una cuestión decisiva a la que todavía no se ha respondido: ¿la suposición anterior es cierta?, ¿esa puntuación en el test constituye realmente una medida adecuada de la característica evaluada por la prueba? En el capítulo 2 se calificó al error de medida de endémico en las Ciencias Sociales, en particular, y en la ciencia en general. Si esto es así, ¿hasta qué punto la puntuación obtenida en el test por un sujeto refleja el nivel en

que éste posee la característica medida por el test, o es más bien producto del error de medida que de forma sistemática e invariable se introduce siempre en cualquier medición —psicológica o física— que hagamos? ¿Qué parte se puede atribuir realmente al error? ¿Qué parte al nivel del sujeto en la característica evaluada? En los capítulos que quedan de este segundo bloque se va a tratar de responder a estas cuestiones y, para ello, lo primero que necesitamos es una *teoría de los tests*, ya que el problema central que aborda cualquier teoría de los tests es precisamente la relación existente entre el nivel del sujeto en la variable —*inobservable*— que se desea estudiar y su puntuación —*observada*— en el test. Observe el lector como en este momento se está pasando de la fase de construcción de la prueba o test a la fase de evaluación de la misma, siguiendo así el esquema propuesto al comenzar este segundo bloque de contenidos en la figura A (página 91).

Si no se produjera ningún tipo de error al medir, no sería necesario embarcarse en esta nueva travesía. El siguiente apartado está dedicado justamente a introducir la problemática relativa al error de medida inherente a toda medición psicológica. A continuación se presentarán las dos teorías de los tests más importantes que han ido surgiendo a lo largo de este siglo, utilizando un esquema similar para su exposición. Se definirán las características básicas de cada teoría y se indicará cómo procede cada una de ellas para dar respuesta a los dos problemas fundamentales a los que se enfrenta toda teoría de los tests: 1) la cuantificación o estimación del error de medida y 2) la determinación o estimación de la característica de interés que supuestamente está midiendo el test.

En el diagrama de la figura 5.1 se presenta un esquema-resumen con los contenidos que se van a desarrollar en el capítulo.




FIGURA 5.1. Esquema-resumen del contenido del capítulo 5.

En resumen, los objetivos que se persiguen en este capítulo son los siguientes:

- comprender el problema del error de medida y su alcance;
- comprender el papel desempeñado por las teorías de los tests:
 - saber la solución que propone cada teoría al problema del error de medida;
 - conocer la ecuación básica y los supuestos en los que se basa la teoría clásica de los tests y la teoría de respuesta al ítem;
 - saber estimar el error de medida que se comete al aplicar un test;
 - saber estimar el nivel en el que los sujetos poseen la característica evaluada por el test.

5.2. EL PROBLEMA DEL ERROR DE MEDIDA

Pocas cosas hay más ciertas: las puntuaciones de los tests contienen error, y error de distinto tipo. En efecto, la repetición de un proceso de medición no suele arrojar casi nunca el mismo resultado; dos personas con idéntica puntuación en el test pueden poseer en muy distinto grado la característica que éste mide y, a la inversa, dos personas con el mismo nivel en el rasgo evaluado pueden obtener puntuaciones sensiblemente diferentes en la prueba. Si estamos en un proceso de selección de personal y una de ellas ha obtenido una puntuación por encima del mínimo fijado por el equipo de recursos humanos y la otra por debajo, el resultado será que la primera pasará a la siguiente fase en el proceso de selección y la otra será descartada, *a pesar de tener idéntico nivel en la característica examinada*. Como puede observarse, la presencia del error en cualquier proceso de medición no solo es ineludible sino que puede tener consecuencias nada triviales. Por ello, el investigador debe extremar al máximo las precauciones para conseguir que el error sea mínimo, de forma que la medida obtenida para un sujeto con una prueba refleje lo más fielmente posible el nivel real en que dicho sujeto posee la característica evaluada, y no sea debida a otro tipo de factores que nada tienen que ver en principio con esa característica, pero que se pueden colar subrepticamente en el proceso de medición y explicar en mayor o menor medida la puntuación obtenida por el sujeto.

Por ejemplo, los sujetos pueden responder a la prueba con más o menos interés o atención, con un grado de ansiedad mayor o menor ante la situación de evaluación, pueden tener más o menos suerte al responder al azar a ítems de elección múltiple cuando desconocen la res-

puesta correcta, o simplemente pueden encontrarse en mejores o peores condiciones físicas o psicológicas. Todos estos factores pueden operar siempre, por muy estricto y cuidadoso que sea el control en las condiciones de administración de la prueba y pueden modificar considerablemente la puntuación obtenida por el sujeto, aun sin tener poco o nada que ver con lo que realmente se desea medir —pongamos, por ejemplo, el rendimiento académico en una determinada materia—. Este tipo de error es totalmente aleatorio e impredecible, es decir, estos errores no presentan un patrón consistente o sistemático, se trata de fluctuaciones internas que varían de forma aleatoria entre los sujetos (pueden conducir a que un sujeto obtenga una puntuación más alta de la debida y otro más baja, por la misma razón) y, por consiguiente, no pueden ser eliminados de las puntuaciones obtenidas en los tests. Hay que convivir necesariamente con ellos pero hay que tenerlos a raya ya que, como se acaba de mostrar, reducen la utilidad de las medidas y limitan seriamente la posibilidad de generalizar los resultados obtenidos a situaciones distintas de las implicadas en dicho proceso de medición, lo que se traduce en una merma en la confianza que podemos depositar en el valor de la medida obtenida en una ocasión concreta.

Por todo ello es necesario llevar a cabo una doble línea de actuación:

1. Hay que analizar la precisión con la que las puntuaciones del test miden la característica o constructo psicológico —fiabilidad del test— y el grado en que éste mide la característica que se desea medir —validez del test. Como tendremos ocasión de comprobar en los capítulos 6 y 7, la fiabilidad se ocupará precisamente de estos errores aleatorios que se introducen siempre en el proceso de medición y la validez de los errores que, a diferencia de los anteriores, sí muestran un patrón sistemático o consistente (afectan a todos los sujetos de la misma forma, no de un modo aleatorio, a unos de una manera y a otros de otra distinta).

En resumen, es menester evaluar la *calidad métrica* de las pruebas con las que se trabaja, hay que ver si el test cumple o no unos criterios mínimos de calidad que nos permitan utilizar con garantía dicha prueba para obtener estimaciones adecuadas de la característica evaluada y esos criterios métricos de calidad son la fiabilidad y la validez del test, que serán examinados en detalle en los capítulos 6 y 7.

2. Hay que recurrir a una *teoría de los tests* que dé cuenta y cuantifique el error de medida y proporcione una estimación del rasgo o característica evaluada. Esto es, se necesita una herramienta que proporcione información acerca de la precisión de las medidas obtenidas con los tests, para así poder determinar la relación exis-

tente entre las respuestas —observables— dadas por el sujeto a los ítems del test y su nivel —inobservable— en la característica medida por éste. Esta relación ha de ser adecuadamente descrita por una función matemática que será diferente en cada teoría. Veamos un ejemplo que ilustre estas ideas.

Supongamos que se construye y aplica a una muestra de 1000 alumnos de enseñanza primaria una prueba diseñada para medir su rendimiento académico en la asignatura *Conocimiento del medio*. La prueba consta de 40 preguntas de elección múltiple con una única opción correcta de respuesta. ¿Qué se puede decir acerca del rendimiento de estos niños en esa asignatura? ¿Cómo se puede relacionar su conocimiento del medio con las respuestas que éstos dan a los ítems de la prueba? Para responder a estas cuestiones se dispone únicamente de un test de $n = 40$ ítems y de las respuestas que han dado a esos ítems $N = 1000$ niños. Tal como se puede observar en la tabla 5.1, se dispone de una matriz de datos de dimensión $N \times n$ (1000×40) pero esta matriz, por sí sola, no puede proporcionar las respuestas deseadas.

TABLA 5.1
Matriz de datos con las respuestas dadas por una muestra de 1000 alumnos a una prueba de 40 ítems (1: acierto y 0: error)

ÍTEMS	1	2	3		40
SS					
1	1	1	0		0
2	0	1	1		0
3	1	1	1		1
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
.	.	.	.		.
1000	1	0	1		1

Lo que proporciona una teoría de los tests es precisamente un modelo, una representación de las puntuaciones de los tests. Este modelo da cuenta de la información contenida en esas matrices de datos $N \times n$, a partir de: 1) la característica de interés que supuestamente está midiendo el test y 2) el error que se introduce en el proceso de medición. El análisis o modelado de estas matrices dará como resultado la obtención de los:

1. Valores escalares de los sujetos, esto es, la estimación del nivel en que poseen los sujetos la característica que mide el test, la medida o valor de escala de los sujetos
2. Valores escalares de los ítems, esto es, la estimación de las características o parámetros de los ítems, que serán abordados en el capítulo 8.

Las tres teorías de los tests que han tenido un peso específico mayor en el campo de la Psicometría han sido la teoría clásica de los tests, la teoría de la generalizabilidad y la teoría de respuesta al ítem.

MC La teoría de la generalizabilidad

A continuación, se realizará una presentación del modelo matemático formulado por la teoría clásica y por la teoría de respuesta al ítem, así como de los conceptos básicos y fundamentales en los que éstas se apoyan y que son necesarios para poder comprender el tratamiento que se da al error y el modo en que se estima la característica de interés. En el subapartado *Estimación del error de medida* se expondrá el modo en que define y caracteriza cada teoría el error de medida y se proporcionarán estimaciones del mismo (en forma de medidas individuales y grupales). En el subapartado *Estimación de la característica de interés* se presentarán los procedimientos que se utilizan en cada teoría para obtener estimaciones del rasgo o constructo que supuestamente mide el instrumento utilizado.

5.3. LA TEORÍA CLÁSICA DE LOS TESTS

El nacimiento formal de la teoría de los tests hay que situarlo en los primeros trabajos de Spearman a comienzos del siglo XX. La teoría de los tests formulada por Spearman y conocida como *Teoría Clásica de los Tests (TCT)* o *modelo lineal de Spearman* nunca tomó forma de un texto

completo e integrado de manos de su progenitor sino que fue formulada a través de un conjunto de trabajos fechados en 1904, 1907, 1910 y 1913 y desarrollada en conjunción con las teorías sobre la inteligencia. No en vano, Spearman no es solo el padre de la TCT sino que es también el primero en enunciar una teoría psicológica de la inteligencia (Spearman, 1923, 1927).

La TCT fue expuesta por vez primera de forma completa en la obra de Guilford (1936) *Psychometric methods*. Durante esta década y la siguiente, se derivan sus fórmulas más conocidas y todo este *corpus* teórico generado será revisado y sistematizado en la obra de Gulliksen (1950) *Theory of mental tests* que rápidamente se convertiría —y nunca ha dejado de ser— una obra clásica y de obligada referencia. La puesta de largo de la TCT, con una formalización matemática más precisa y elegante, vendrá con la obra de Lord y Novick (1968) *Statistical theories of mental test scores* (Meliá, 1993).

5.3.1. Modelo

Según la TCT, la puntuación empírica que obtiene un sujeto cuando se le administra un test — X — es función del nivel real o verdadero en que ese sujeto posee la característica o rasgo que está evaluando dicho test —denominada por esta teoría como *puntuación verdadera* V — y del error de medida que siempre se introduce en cualquier proceso de medición — E —. Formalmente,

$$X = V + E \quad (5.1)$$

Por tanto, según la TCT la función que relaciona la actuación observable en el test — X — y el nivel del sujeto en la variable inobservable — V — es una función lineal, ya que la relación establecida en la ecuación anterior entre X y V es una relación lineal que puede ser descrita gráficamente por medio de una recta.

La figura 5.2 representa gráficamente la relación existente entre las puntuaciones verdaderas y las puntuaciones empíricas obtenidas en la prueba de conocimiento del medio por los 1000 alumnos de la muestra, expresando ambos tipos de puntuaciones en la misma escala, en la escala de las puntuaciones directas en el test (su rango es de 0 a 40 ya que se ha utilizado la puntuación por número de aciertos). La recta dibujada en la figura representa o modela la distribución conjunta de esas dos variables — X y V — y permite expresar la información contenida en esa nube de puntos o, lo que es lo mismo, en la matriz de datos de la tabla 5.1, en una expresión tan simple como la de la ecuación de una recta. Por tanto,

el modelo que utiliza esta teoría para representar la matriz de datos con las puntuaciones de los sujetos a los ítems del test es una recta.




FIGURA 5.2. Relación entre puntuaciones empíricas y verdaderas.

Examinemos ahora a alguno de estos alumnos. Por ejemplo, el alumno A ha respondido correctamente a 25 ítems de la prueba ($X = 25$), si bien su puntuación verdadera es algo diferente ($V = 27$). Por consiguiente, el error cometido al medir con esa prueba su nivel de conocimiento del medio es $25 - 27 = -2$, valor que se obtiene directamente al aplicar la ecuación (5.1). Observe el lector que hay otros alumnos (77 en particular) con la misma puntuación empírica que el alumno A pero con una puntuación verdadera diferente (desde 24 hasta 29). Lo contrario también es cierto. Hay alumnos (83 concretamente) que tienen la misma puntuación verdadera que el sujeto A y, sin embargo, su puntuación empírica difiere (el rango de variación va de 24 a 28). Posiblemente, si volvemos a aplicar esta prueba al alumno A su puntuación empírica no será igual (no así su puntuación verdadera, que seguiría siendo la misma): un simple catarro puede bajar su puntuación a 24 o, si tiene más suerte esta vez al responder al azar a los ítems cuya respuesta desconoce, puede subir su puntuación a 28. ¿Cuál de estas tres puntuaciones empíricas refleja mejor el nivel real de rendimiento del alumno A en la asignatura considerada? ¿25, 24 o 28? La respuesta parece sencilla: la puntuación empírica X que esté más próxima a la puntuación verdadera del sujeto, esto es, la que tenga el menor error de medida ($E = X - V$), es decir, $X = 28$. Ahora bien, el problema es que NUNCA conocemos la puntuación verdadera V , por lo que la solución anterior no es tal. De hecho, en la ecuación (5.1) tenemos tres términos y solo podemos conocer uno de ellos: la puntuación empírica X . ¿Cómo salir de este embrollo?

Lo que plantea la TCT es que la mejor estimación que se puede hacer de:

- el nivel real en que el sujeto manifiesta la característica de interés — V — medida con el test es la media de las puntuaciones empíricas que se obtendrían si se le aplicara dicha prueba al sujeto en las mismas condiciones un número infinito de veces. Formalmente, para nuestro alumno A esto se podría expresar del siguiente modo:

$$\hat{V}_A = \bar{X}_A = \frac{\sum_{i=1}^N X_{A_i}}{N}$$

donde:

$\hat{V}_A$ es el estimador de la puntuación verdadera V del sujeto A ;

$\bar{X}_A$ es la media de los valores obtenidos en la variable X_A en las N veces que ésta se ha medido;

X_{A_i} es la puntuación empírica X obtenida por el sujeto A en la ocasión i ;

N es un valor grande aproximadamente igual a infinito.

Considerando las tres únicas ocasiones en las que se ha aplicado el test al sujeto A tendríamos que:

$$\hat{V}_A = \frac{25 + 24 + 28}{3} = 25,67$$

- el error de medida es examinando la variabilidad de las puntuaciones empíricas obtenidas por un sujeto en ese número infinito de ocasiones en las que se le ha administrado la prueba en cuestión, bien calculando su varianza:

$$\hat{\sigma}_e^2 = \frac{\sum_{i=1}^N (X_{A_i} - \bar{X}_A)^2}{N}$$

bien su desviación típica (véase cuadro 4.3), más conocida como *error típico de medida*:

$$\hat{\sigma}_e = \sqrt{\frac{\sum_{i=1}^N (X_{A_i} - \bar{X}_A)^2}{N}}$$

donde $\hat{\sigma}_e^2$ y $\hat{\sigma}_e$ corresponden respectivamente a los estimadores de la varianza y la desviación típica de los errores de medida E .

Naturalmente, lo anterior solo se puede plantear cuando la prueba se administra exactamente en las mismas condiciones en las N ocasiones suponiendo, además, que el sujeto no cambia a lo largo de las mismas y que lo que ocurre en una determinada aplicación no influye para nada en lo que sucede en otra aplicación posterior de la prueba, es decir, que las repetidas aplicaciones de la prueba son sucesos independientes, de forma que los errores de medida cometidos en las distintas aplicaciones son también independientes, no están *relacionados* los unos *con* los otros, no *correlacionan* entre sí. Por último, dado que los errores de medida son aleatorios, tampoco pueden estar correlacionados con la puntuación verdadera ya que, si así fuera, no serían aleatorios.

En resumen, los supuestos de los que parte esta teoría son los siguientes:

- el nivel real del sujeto en la característica de interés es la media de los valores que se obtendrían de forma empírica en caso de administrar el mismo test al sujeto en idénticas condiciones de medida un número infinito de veces;
- independencia entre los errores de medida obtenidos en las distintas ocasiones;
- independencia entre las puntuaciones verdaderas y los errores de medida.

Estos supuestos son *a priori* perfectamente razonables y sensatos, pero *a posteriori* resulta que no se pueden comprobar empíricamente (recuerde el lector que la puntuación verdadera y el error nunca se conocen). Lo único que se puede hacer es derivar de ellos deducciones y contrastar o someter a prueba éstas para ver si el modelo lineal se confirma o se ve falsado.

MC Deducciones derivadas de los supuestos de la TCT

No es éste el único problema que presenta este modelo, pero de momento no estamos en condiciones de conocer más. Paciencia, lector, habrá que llegar al final de este segundo bloque de contenidos para poder comprender el resto de sus limitaciones. Sin embargo, vaya por delante la siguiente reflexión.

Dejemos temporalmente de lado la medición psicológica y pensemos ahora en la medición de una característica física como la longitud. Si queremos cuantificar o estimar el error de medida de una regla graduada, lo habitual es tomar medidas repetidas de la longitud de un objeto un determinado número de veces y considerar como estimación del error de medida de la regla algún indicador de la variabilidad de las medidas obtenidas para la longitud del objeto en cuestión en los distintos ensayos (por ejemplo, la desviación típica). La mejor estimación que se puede hacer de la longitud del objeto será la media de los valores obtenidos a lo largo de los ensayos. En este caso, estamos suponiendo que la longitud del objeto no se modifica durante los ensayos, que éstos son sucesos independientes y que los errores cometidos en los distintos ensayos nada tienen que ver los unos con los otros. Éstos son los supuestos y la forma de proceder con la que se suele operar en la medición de características físicas. Spearman, plenamente imbuido en la corriente positivista de la época, participaba de la idea de que el método de la Psicología era el de la Física y las Ciencias Naturales y lo que hizo fue simplemente trasladar estas ideas al campo de la medición psicológica. El problema es que estos supuestos se adaptan mucho mejor a la medición física que a la psicológica. Así, por ejemplo, es difícil imaginar que las repetidas aplicaciones de una prueba o test son sucesos realmente independientes (los efectos de la práctica y también de la fatiga pueden influir decisivamente en que así no sea), al margen de que los sujetos se prestan con mucha menos facilidad que los objetos a ser medidos en la forma tan insistente que parece requerir esta teoría.

5.3.2. Estimación del error de medida

La cuantificación o estimación del error de medida que se comete en un proceso de medición con una prueba o test se deriva directamente de la ecuación básica del modelo (5.1) y de sus supuestos y deducciones. En efecto, el **error de medida** de un sujeto i se define simplemente como la diferencia entre la puntuación empírica obtenida y su puntuación verdadera:

$$E_i = X_i - V_i$$

Para el sujeto A ya vimos que $E_A = 25 - 27 = -2$, indicando el signo negativo que en esa ocasión concreta el error de medida le ha afectado adversamente, ya que el sujeto ha obtenido una puntuación más baja que la que corresponde realmente al nivel en que posee la característica evaluada.

Si calculamos el error de medida no solo de este sujeto sino de todos los sujetos de la población de interés y hallamos la desviación típica de las puntuaciones así definidas, habremos obtenido el valor del **error típico de medida** que es, por tanto, la desviación típica de los errores de medida:

$$\sigma_e = \sqrt{\frac{\sum_{i=1}^N (E_i - \mu_e)^2}{N}} = \sqrt{\frac{\sum_{i=1}^N E_i^2}{N}} \quad (5.2)$$

donde:

μ_e se demuestra que es igual a 0;

MC Deducciones derivadas de los supuestos de la TCT

N es el número de sujetos al que se ha administrado el test.

Se demuestra asimismo que el error típico de medida tiene el siguiente valor:

$$\sigma_e = \sigma_x \sqrt{1 - \rho_{xx}} \quad (5.3)$$

donde:

σ_x es la desviación típica de las puntuaciones empíricas en el test:

$$\sigma_x = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu_x)^2}{N}}$$

ρ_{xx} es el coeficiente de fiabilidad del test que, como veremos en el capítulo siguiente, se define como la varianza de las puntuaciones verdaderas y la varianza de las puntuaciones empíricas:

$$\rho_{xx} = \frac{\sigma_v^2}{\sigma_x^2} \quad (5.4)$$

Supongamos que la desviación típica de las puntuaciones empíricas de los 1.000 alumnos en la prueba de conocimiento del medio es 3,5 y que la varianza de sus puntuaciones verdaderas es 10. Entonces,

$$\hat{\sigma}_e = 3,5 \sqrt{1 - \frac{10}{3,5^2}} = 1,5$$

En resumen, el error de medida es una medida **individual** del error (se calcula para cada sujeto e indica hasta qué punto difiere la puntuación que de hecho ha obtenido el sujeto en el test del nivel real en que dicho sujeto posee la característica evaluada por la prueba) y el error típico de medida es una medida **colectiva** del error (se calcula para toda la muestra o población e indica la precisión con que el test mide el constructo en cuestión).

5.3.3. Estimación de la característica de interés

Para estimar el nivel real en que el sujeto posee la característica o rasgo que mide el test se dispone de dos opciones. Se puede obtener:

- un único valor, esto es, una estimación puntual de V : $\hat{V}$;
- un conjunto de valores posibles para V , esto es, una estimación por intervalo, un intervalo de confianza para V .

La estimación por intervalo subsume obviamente a la estimación puntual ya que $\hat{V}$ es solo uno de los puntos definidos por el intervalo de confianza o intervalo confidencial. Un intervalo se define como un conjunto de valores cuyo rango va desde el valor más bajo — $\hat{V}_{\text{inferior}}$ — hasta el valor más alto — $\hat{V}_{\text{superior}}$ —. El intervalo de confianza de V sería por tanto $(\hat{V}_{\text{inferior}}, \hat{V}_{\text{superior}})$. Pues bien, la fórmula general que nos va a permitir obtener este intervalo confidencial es la siguiente:

$$P(\hat{V}_{\text{inferior}} \leq V \leq \hat{V}_{\text{superior}}) \geq NC \quad (5.5)$$

La expresión anterior indica que la probabilidad — P — de que la puntuación verdadera de un sujeto — V — se encuentre dentro del intervalo de confianza $(\hat{V}_{\text{inferior}}, \hat{V}_{\text{superior}})$ es mayor o igual a un determinado valor, el Nivel de Confianza (NC). Obviamente, interesa que este valor sea alto ya que lo que queremos es poder afirmar que es muy alta la probabilidad de que la puntuación verdadera de un sujeto se encuentre en el intervalo definido. El valor del nivel de confianza es fijado o establecido arbitrariamente por el investigador y se suele trabajar con valores

altos, del orden de 0,95 o 0,99. Si $NC = 0,99$, la expresión (5.5) se puede leer del siguiente modo: confiamos en que en el 99% de los casos la puntuación verdadera del sujeto se encontrará dentro del intervalo definido por $\hat{V}_{\text{inferior}}$ y $\hat{V}_{\text{superior}}$. Cuanto menor sea el rango del intervalo confidencial tanto más precisa será la estimación de la característica de interés; convendrá el lector en que resulta bastante más preciso decir que la puntuación verdadera del sujeto A se encuentra en el intervalo (24, 29) que en el intervalo (20, 35).

En la ecuación (5.5) lo único que todavía desconocemos son los límites del intervalo confidencial, que se definen del siguiente modo:

$$\begin{aligned}\hat{V}_{\text{inferior}} &= \hat{V} - E.\text{máximo} \\ \hat{V}_{\text{superior}} &= \hat{V} + E.\text{máximo}\end{aligned}$$

donde:

$\hat{V}$ es la estimación puntual de V ;

$E.\text{máximo}$ es el máximo error que estamos dispuestos a aceptar en nuestras estimaciones y que obviamente se relaciona con el nivel de confianza (NC) que depositamos en ellas.

Son tres los métodos que se pueden utilizar para calcular el valor estimado de V y el del error máximo. La tabla 5.2 recoge los valores que se proponen para $\hat{V}$ y $E.\text{máximo}$ en los tres métodos y los supuestos en los que éstos se basan.

TABLA 5.2
Estimación de la característica de interés en la teoría clásica de los tests

Método basado en	Supuestos	$\hat{V}$	E. máximo
La desigualdad de Chebychev	Ninguno	X	$\sigma_e \sqrt{\frac{1}{1 - NC}}$
La distribución normal de errores	$X/V \equiv N(0, \sigma_e^2) \forall V$	X	$\sigma_e Z_c$
El modelo de regresión	Los del modelo de regresión (véase cuadro 5.2)	$V' = \rho_{xx}(X - \mu_x) + \mu_x$	$\sigma_{v \cdot x} Z_c$

Los métodos aparecen ordenados de menor a mayor precisión en las estimaciones obtenidas o, lo que es lo mismo, de mayor a menor amplitud del intervalo confidencial. Esto tiene que ver directamente con los supuestos que realiza cada uno de ellos. Si no se hacen supuestos de ningún tipo, entonces el método se podrá aplicar a cualquier conjunto de datos pero el resultado obtenido no será muy preciso. Por ejemplo, si no se conocen las medidas de una persona, se puede hacer un traje como para una talla 50; de esta forma, se tendrá la seguridad de que le entra a casi todo el mundo, aunque le quedará bien solo a unos pocos. Si se conoce —o se puede suponer— el peso y la altura de la persona, seguramente se podrá afinar algo más y el traje le quedará bastante mejor. Si no es así, una de dos: o la suposición anterior no era muy atinada o la habilidad del sastre deja bastante que desear. Sabiendo —o suponiendo— la talla de la persona, el resultado puede ser considerablemente mejor. Lo mismo sucede con los métodos de estimación de la puntuación verdadera V : cuanto más fuertes o restrictivos sean los supuestos que realizan sobre los datos con los que trabajan, más precisas serán las estimaciones obtenidas, menor será la amplitud del intervalo confidencial de V . Ahora bien, no conviene olvidar que esto solo será así si se cumplen los supuestos, si éstos son ciertos. Si la talla de una persona es la 42 y suponemos una 38 no podrá abrocharse el traje, por muy bonito que sea. Del mismo modo, si no se cumplen los supuestos en los que se basa el método utilizado en la obtención del intervalo confidencial de V , ese intervalo no será una estimación apropiada de V , por muy pequeño que éste sea: es necesario utilizar otro método que realice supuestos menos fuertes y que sean satisfechos por el conjunto de datos examinado.

El único método que no realiza ningún tipo de supuesto es el **método basado en la desigualdad de Chebychev**, según el cual la ecuación (5.5) puede describirse del siguiente modo:

$$P\left(X - \sigma_e \sqrt{\frac{1}{1 - NC}} \leq V \leq X + \sigma_e \sqrt{\frac{1}{1 - NC}}\right) \geq NC \quad (5.6)$$

En el caso del sujeto A y suponiendo que $NC = 0,99$, tendremos que:

$$P\left(25 - 1,5 \sqrt{\frac{1}{1 - 0,99}} \leq V \leq 25 + 1,5 \sqrt{\frac{1}{1 - 0,99}}\right) \geq 0,99$$

$$P(10 \leq V \leq 40) \geq 0,99$$

la puntuación verdadera del sujeto A se encontrará muy probablemente ($NC = 0,99$) en algún punto del intervalo comprendido entre una pun-

tuación de 10 y una de 40. Dado que el rango posible de las puntuaciones en esta prueba es (0, 40), decir lo anterior no es decir mucho, no resulta particularmente informativo ni preciso.

En el **método basado en la distribución normal de los errores** el supuesto que se hace es justamente ese, que los errores de medida se distribuyen normalmente con media cero y desviación típica el error típico de medida.


CUADRO 5.1
Distribución normal de una variable

La distribución de frecuencias de una variable es el conjunto de valores que ésta adopta en una determinada muestra o población de sujetos (por ejemplo, las puntuaciones obtenidas por una muestra de sujetos en un test).

Para denotar una variable que se distribuye normalmente basta con conocer su media y su varianza: $X \equiv N(\mu, \sigma^2)$.

Se dice que una variable se distribuye normalmente en una muestra o población de sujetos cuando los valores mostrados por éstos en dicha variable presentan las siguientes características:

1. La representación gráfica de dicha distribución de frecuencias es una curva en forma de campana.
2. La curva tiene un único valor máximo que coincide con la media, mediana y moda de la distribución.
3. La curva es simétrica respecto al eje vertical que pasa por la media de la distribución.
4. La mayoría de las frecuencias se encuentran en la zona central de la campana; en particular, en el intervalo $(\mu \pm \sigma)$ se encuentran el 68,26% de los valores de la distribución de frecuencias, en el intervalo $(\mu \pm 2\sigma)$ el 95,44% y en el intervalo $(\mu \pm 3\sigma)$ el 99,72%.



Se supone, además, que el valor de esa desviación típica es el mismo para todas las posibles puntuaciones verdaderas, es decir, que se estima

con la misma precisión la inteligencia de un superdotado, de un deficiente mental y de una persona normal y corriente. Formalmente,

$$f(E) = f(X/V_i) \equiv N(0, \sigma_e^2) \quad \forall i$$

La ecuación (5.5) podría describirse del siguiente modo:

$$P(X - \sigma_e Z_c \leq V \leq X + \sigma_e Z_c) \geq NC \quad (5.7)$$

donde Z_c es la puntuación que corresponde en una distribución normal a la probabilidad expresada en el nivel de confianza ($Z_c = 1,96$ para $NC = 0,95$ y $Z_c = 2,58$ para $NC = 0,99$; véase tabla A del Anexo).

Para el sujeto A tendremos que:

$$P(25 - 1,5 \times 2,58 \leq V \leq 25 + 1,5 \times 2,58) \geq 0,99$$

$$P(21,13 \leq V \leq 28,87) \geq 0,99$$

su puntuación verdadera se encontrará muy probablemente ($NC = 0,99$) en algún punto del intervalo (21,13, 28,87), intervalo que está considerablemente más acotado que el obtenido con el método anterior (10, 40), su amplitud es mucho menor.

Estos dos métodos utilizan la puntuación empírica obtenida por el sujeto en la prueba como estimador de la puntuación verdadera ($\hat{V} = X$). El planteamiento del tercer método —**método basado en el modelo de regresión**— es distinto, ya que el estimador que utilizará para V es la puntuación pronosticada en V por el modelo de regresión — V' — a partir de la puntuación empírica — X — obtenida por el sujeto que, como sabemos, es realmente la única información de la que disponemos ($\hat{V} = V'$).

CUADRO 5.2 Modelo de regresión

El modelo de regresión es un modelo de predicción que permite pronosticar o conocer los valores —desconocidos— de una variable Y a partir de los valores —conocidos— de otra variable X con la que está linealmente relacionada.

La ecuación que nos permite realizar esa predicción es la siguiente:

$$Y' = \alpha + \beta X$$

donde:

Y' es el valor pronosticado en la variable Y mediante la ecuación de regresión;
 α es la ordenada en el origen, esto es, el valor de Y cuando $X = 0$:

$$\alpha = \mu_y - \beta \mu_x$$

donde:

μ_y y μ_x son las medias de las variables Y y X , respectivamente;
 β es la pendiente de la recta mediante la que se representa gráficamente la ecuación de regresión e indica el grado de inclinación que ésta presenta respecto al eje de abscisas (el horizontal):

$$\beta = \rho_{xy} \frac{\sigma_y}{\sigma_x}$$

donde:

ρ_{xy} es el coeficiente de correlación que proporciona una medida de la relación lineal entre las variables X e Y :

$$\rho_{xy} = \frac{N \sum XY - \sum X \sum Y}{\sqrt{[N \sum X^2 - (\sum X)^2][N \sum Y^2 - (\sum Y)^2]}}$$

donde:

N es el número de sujetos para los que se dispone de medidas en las variables X e Y ;

σ_y y σ_x son la desviación típica de las variables Y y X , respectivamente.

Los supuestos en los que se basa el modelo de regresión son los siguientes:

1. Si para cada posible valor de X se calcula la media de los valores obtenidos en la variable Y por esos sujetos con idéntico valor en X y se representan gráficamente esos puntos, el gráfico resultante ha de ser una recta: *Linealidad en la relación entre X e Y* .
2. Los errores cometidos en la estimación o predicción de la variable Y a partir de la variable X , esto es, la diferencia existente entre el valor de Y que realmente mostraría un sujeto con una puntuación X determinada — Y — y el valor que se le pronostica mediante la ecuación de regresión — Y' — se distribuyen normalmente con media 0 y varianza $\sigma_{y.x}^2$: *Normalidad en la distribución muestral de los errores de estimación*

$$f(E) = f(Y/X) \equiv N(0, \sigma_{y.x}^2)$$

donde:


$$\sigma_{y.x}^2 = \frac{\sum_{i=1}^N (E_i - \mu_e)^2}{N} = \frac{\sum_{i=1}^N E_i^2}{N} = \frac{\sum_{i=1}^N (Y_i - Y'_i)^2}{N} = \sigma_y^2 (1 - \rho_{xy}^2)$$

donde:

N es el número de sujetos que ha obtenido una determinada puntuación en la variable X_i ;

μ_e es la media de los errores de estimación que es igual a 0.

3. La varianza de los errores de estimación de Y a partir de X — $\sigma_{y \cdot x}^2$ — es igual para todos los posibles valores de X : *Homocedasticidad*.
4. Los errores de estimación son independientes, no se relacionan los unos con los otros: *Independencia de los errores*.



La ecuación (5.5) podría describirse del siguiente modo:

$$P(V' - \sigma_{v \cdot x} Z_c \leq V \leq V' + \sigma_{v \cdot x} Z_c) \geq NC \quad (5.8)$$

donde:

V' es la puntuación pronosticada en V mediante la ecuación de regresión:

$$V' = (\mu_x - \rho_{xx} \mu_x) + \rho_{xx} X = \rho_{xx} (X - \mu_x) + \mu_x \quad (5.9)$$

$\sigma_{v \cdot x}$ es el error típico de estimación de la puntuación verdadera, que es la desviación típica de los errores de estimación cometidos al estimar V a partir de la ecuación de regresión ($E = V - V'$) cuyo valor es:

$$\sigma_{v \cdot x} = \sigma_e \sqrt{\rho_{xx}} \quad (5.10)$$

Queda como ejercicio para el lector demostrar que cuando se predice V a partir de X $\alpha = \mu_x - \rho_{xx} \mu_x$ y $\beta = \rho_{xx}$.

Suponiendo que $\hat{\mu}_x = 30$ tendremos que:

$$V'_A = \frac{10}{3,5^2} (25 - 30) + 30 = 25,9$$

$$P(25,9 - 1,5\sqrt{0,82 \times 2,58} \leq V \leq 25,9 + 1,5\sqrt{0,82 \times 2,58}) \geq 0,99$$

$$P(22,40 \leq V \leq 29,40) \geq 0,99$$

la puntuación del sujeto A se encontrará muy probablemente ($NC = 0,99$) en algún punto del intervalo (22,4, 29,4) cuya amplitud es todavía menor que en el caso anterior.

Los supuestos en los que se basa este método son obviamente los supuestos del modelo de regresión (véase cuadro 5.2).

5.4. LA TEORÍA DE RESPUESTA AL ÍTEM

Los orígenes de la Teoría de Respuesta al Ítem (TRI) se remontan a los trabajos de Thurstone en la década de los veinte, pero el auténtico padre de la TRI es Frederick M. Lord (1912-2000) que pone en 1952 la primera piedra de esta teoría con su monografía *A theory of test scores* y publica el primer manual de TRI en 1980. Sin embargo, a pesar de que los orígenes de la TRI son solo un poco posteriores a los de la TCT, es en la década de los ochenta cuando la TRI adquiere un peso específico importante en el campo de la teoría de los tests y es que, por un lado, la TRI se desarrolla en un contexto bastante diferente al de la TCT —su desarrollo no se vincula a teorías de la inteligencia sino a problemas técnicos en la construcción de tests y en la estadística matemática (Embretson, 1985)— y, por otro, aunque las ideas no son nuevas, el soporte matemático, tecnológico e informático necesario para ser aplicada sí lo es (Jaeger, 1987). Es decir, solo recientemente se ha dispuesto de la tecnología necesaria de ordenador para implementar los algoritmos que permiten trabajar con esta teoría.

Veamos pues cómo responde la TRI a las dos cuestiones que planteábamos en el apartado 5.2: ¿Qué se puede decir acerca del rendimiento de los 1000 alumnos de enseñanza primaria en la asignatura *Conocimiento del medio*? ¿Cómo relacionar su nivel de conocimiento del medio con las respuestas que éstos han dado a los ítems de la prueba? De nuevo, la única información de la que disponemos es la matriz 1000×40 con las respuestas de los 1000 alumnos a los 40 ítems del test.

5.4.1. Modelo

5.4.1.1. Supuestos

Podemos empezar suponiendo que lo que explica la obtención de esa matriz particular de datos y no otra es exclusivamente el conocimiento del medio que tienen los niños de la muestra: el hecho de que un niño muestre un determinado patrón de respuesta —responda correctamente unos ítems e incorrectamente otros— se debe a que posee en determinado grado la característica latente que evalúa el test, tiene determinado rendimiento en esa asignatura y no se debe, por ejemplo, a su agudeza visual o a su capacidad de comprensión lectora. Esto no quiere decir, de ningún modo, que factores como los mencionados no afecten al rendimiento de los niños en la prueba sino que lo único que se quiere poner de manifiesto es que lo que mide el test no es la comprensión lectora o la agudeza visual de los niños sino *única y exclusivamente* su conocimiento del medio. Partiendo entonces del supuesto de que la prueba mide una única característica o dimensión (supuesto de **unidimensionalidad** del test), se puede formular un modelo que permita responder a las cuestiones anteriores.

Para ello, el modelo ha de ser tal que indique, para cada uno de los patrones de respuesta mostrados por los sujetos de la muestra, cuál es el valor correspondiente en el rasgo o característica latente que mide el test —denominado en la TRI mediante la letra griega theta θ : θ es a la TRI lo que V a la TCT— o, lo que es lo mismo, cuál es el valor θ que hace más probable la aparición de dicho patrón de respuesta. Supongamos que el patrón de respuesta de un alumno cualquiera j de la muestra es $U_j = (111 \dots 0)$. Supongamos que la probabilidad de observar un patrón de respuesta como éste, cuando el alumno tiene un nivel de conocimiento del medio de 1, es 0,52 ($P(U_j/\theta = 1) = 0,52$); si θ es igual a 2, entonces esa probabilidad es 0,70 ($P(U_j/\theta = 2) = 0,70$) y si θ es igual a 3 la probabilidad sube hasta un valor de 0,75 ($P(U_j/\theta = 3) = 0,75$). Así las cosas, el valor θ para el que es más probable que aparezca un patrón de respuesta como el del sujeto j es $\theta = 3$ ($P = 0,75$). Por tanto, 3 será el valor estimado por la TRI para el nivel real de conocimiento del medio de este sujeto: $\hat{\theta}_j = 3$.

En definitiva, lo que se pretende obtener es un modelo en el que sea máxima la probabilidad de que un sujeto tenga un determinado nivel en el rasgo latente (θ), cuando dicho sujeto ha obtenido un determinado patrón U de respuestas en el test ($P(\theta/U)$) o, lo que es lo mismo, un modelo en el que sea máxima la probabilidad de observar un determinado patrón de respuestas U , supuesto un determinado nivel θ en el rasgo latente ($P(U/\theta)$): el mismo valor θ que maximiza una probabilidad maximizará la otra. El valor θ que finalmente se asignará a un sujeto como estimación de su nivel en el rasgo latente será aquel valor θ para el que

sea más alta la probabilidad de observar el patrón de respuestas que el sujeto ha mostrado realmente en el test.

Realicemos un supuesto más. Supongamos que el hecho de que un niño responda correctamente un ítem no influye en la respuesta que da a otro ítem del mismo test, es independiente de la respuesta a los demás ítems, es decir, supongamos que las respuestas de un niño a los distintos ítems del test son estadísticamente independientes.

La verificación de este supuesto, denominado de **independencia local**, supone que la probabilidad de observar un determinado patrón de respuesta (U), dado un determinado nivel en el rasgo latente (θ), puede escribirse como el producto de la probabilidad de ocurrencia de las puntuaciones en cada ítem del test (u_i), dado el nivel anterior en el rasgo latente. De acuerdo con este supuesto, la probabilidad de obtener un patrón de respuesta como el del sujeto j , dado un determinado nivel θ de conocimiento del medio, se puede escribir del siguiente modo:

$$\begin{aligned} P(U_j / \theta) &= P(u_{j1} = 1, u_{j2} = 1, u_{j3} = 1, \dots, u_{j40} = 0 / \theta) = \\ &= P(u_{j1} = 1 / \theta) P(u_{j2} = 1 / \theta) P(u_{j3} = 1 / \theta) \dots P(u_{j40} = 0 / \theta) \\ P(U_j / \theta) &= \prod_{i=1}^{40} P(u_i = u_j / \theta) \end{aligned}$$

Por tanto, si se verifica el supuesto de independencia local la relación básica de interés pasa a ser entre la característica latente y la actuación en el ítem, no en el test, ya que esta última se define en términos de todos y cada uno de los ítems que lo integran. De ahí la denominación de *teoría de respuesta al ítem*.

Se ha dado en llamar *función característica del ítem* a la función que relaciona la actuación en el ítem con el rasgo latente ($P(u = 1/\theta)$) y *función característica del test* a la que lo relaciona con la actuación en el test ($P(U/\theta)$). En cada caso, dicha función indica cuál es la probabilidad de que un sujeto con un determinado nivel en el rasgo latente responda correctamente a un ítem o presente un determinado patrón de respuesta en el test. Por tanto, la función que relaciona en la TRI la actuación —observable— del sujeto en el test con su nivel en la característica —latente— que se desea medir es la función característica del test que, como se verá a continuación, no es una función lineal como es el caso en la TCT.

Llegados a este punto estamos ya en condiciones de responder a los dos interrogantes planteados:

1. ¿Qué se puede decir acerca del nivel de conocimiento del medio de estos alumnos de enseñanza primaria? La respuesta es simple:

- hay que ver cuál es el patrón de respuestas de cada uno de ellos ($U_j, j = 1, 1000$);
 - hay que determinar para cada patrón de respuesta el valor del rasgo latente θ que hace más probable la aparición de ese patrón de respuestas ($\theta_j \rightarrow \max. P(U_j/\theta)$).
2. ¿Cómo relacionar el nivel de conocimiento del medio de estos alumnos con las respuestas que dan a los ítems de la prueba?

La función característica del test es la función matemática que relaciona la actuación observable del sujeto en el test — U — con la característica latente que se desea medir — θ —. Esta función indica la probabilidad de aparición del patrón observado de respuesta supuesto un determinado nivel en el rasgo latente, que será igual al producto de la probabilidad de ocurrencia de las puntuaciones obtenidas en cada uno de los ítems:

$$P(U_j / \theta) = \prod_{i=1}^n P(u_i = u_j / \theta) \quad (5.11)$$

¿Cómo calcular entonces esta probabilidad? ¿Cómo determinar la función característica del ítem?

5.4.1.2. *Funcion característica del ítem*

Como ya se ha indicado, la función característica del ítem es la función matemática que relaciona la actuación observada en un ítem con la característica latente que se supone éste mide e indica cuál es la probabilidad que tiene un sujeto, con un determinado nivel en ese rasgo o característica latente, de responder correctamente al ítem:

$$P(u = 1 / \theta) = \frac{1}{1 + \exp(-1,7\theta)} \quad (5.12)$$

donde:

- u es la respuesta de un sujeto determinado a un ítem, asignando el valor 1 a la respuesta correcta y el 0 a la incorrecta;
- θ es el nivel del sujeto en la característica de interés que mide dicho ítem (y el test correspondiente).

La representación gráfica de la función característica del ítem es una ojiva logística que se denomina genéricamente *curva característica del*

ítem. Esta curva (véase figura 5.3) es estrictamente monótona, es decir, siempre es creciente pero no llega nunca a ser completamente horizontal representando, de este modo, el hecho de que la probabilidad de observar una respuesta correcta siempre es mayor cuanto más alto es el valor de la característica de interés. Esta curva tiene dos asíntotas, una superior —localizada en el eje vertical en el punto 1— y una inferior —localizada en el mismo eje pero de valor variable entre 0 y 1. A medio camino entre las dos asíntotas se encuentra el punto de inflexión de la curva, que es el punto donde es máxima la pendiente o inclinación de la curva y dónde cambia su curvatura (donde pasa de ser cóncava a convexa).




FIGURA 5.3. Curva característica del ítem.

Como puede observar el lector comparando los gráficos de las figuras 5.2 y 5.3, la función matemática que relaciona en la TRI la actuación observable del sujeto y su nivel en la característica latente medida no es una función lineal como en la TCT sino una función logística: el modelo mediante el que se representa las puntuaciones de los sujetos a los ítems del test no es una línea recta sino una línea curva.

Para definir o describir esta curva no basta con conocer solo a los sujetos (θ), tal como recoge la ecuación anterior, sino que es preciso conocer también las características o parámetros del ítem en cuestión, que son tres en la TRI:

1. El parámetro b : indica la dificultad del ítem y se define como la coordenada en el eje de abscisas (eje horizontal) del punto de inflexión de la curva característica del ítem (véase figura 5.3).

El parámetro b se expresa en la misma escala que el rasgo latente y su interpretación es directa: cuanto mayor es el valor de b más difícil es el ítem.

La ecuación (5.12) quedaría, por tanto, modificada del siguiente modo:

$$P(u = 1/\theta) = \frac{1}{1 + \exp(-1,7(\theta - b))} \quad (5.13)$$

Esta es la ecuación básica del *modelo logístico de un parámetro*, también llamado *modelo de Rasch*, donde se expresa la probabilidad de responder correctamente a un ítem como una función de los parámetros de los sujetos —el nivel en que éstos poseen el rasgo latente— y de un parámetro del ítem —su dificultad.

2. El parámetro a : indica la capacidad del ítem para discriminar entre sujetos que poseen en distinto grado la característica latente medida por el ítem y su valor es directamente proporcional a la pendiente de la curva característica del ítem en su punto de inflexión.

Su interpretación es directa: cuanto mayor es el valor de a , mayor es el poder discriminativo del ítem y menor el rango o zona de la escala en la que discrimina.

Por consiguiente, la ecuación (5.12) quedaría modificada del siguiente modo:

$$P(u = 1/\theta) = \frac{1}{1 + \exp(-1,7a(\theta - b))} \quad (5.14)$$

Esta es la ecuación básica del *modelo logístico de dos parámetros*, que expresa la probabilidad de responder correctamente a un ítem como una función de los parámetros de los sujetos —el nivel en que éstos poseen el rasgo latente— y de dos parámetros del ítem: su dificultad y su poder discriminativo.

3. El parámetro c : indica la probabilidad de que aquellos sujetos con un nivel mínimo de habilidad —y que, por tanto, se supone no conocen la respuesta correcta al ítem— respondan correctamente. Esta característica ha recibido varios nombres: parámetro o índice de acierto al azar, de adivinación y de pseudoadivinación. Este último es, quizás, el más adecuado ya que la palabra adivinación sugiere un proceso meramente al azar y no siempre se responde de modo totalmente aleatorio. El parámetro c se define como el valor de la asíntota inferior de la curva característica del ítem (véase figura 5.3).

La ecuación (5.12) quedaría, por tanto, modificada del siguiente modo:

$$P(u = 1/\theta) = c + \frac{(1 - c)}{1 + \exp(-1,7a(\theta - b))} \quad (5.15)$$

Esta es la ecuación básica del *modelo logístico de tres parámetros*, donde se expresa la probabilidad de responder correctamente a un ítem como una función de los parámetros de los sujetos —el nivel en que éstos poseen el rasgo latente— y de tres parámetros del ítem —su dificultad, discriminación e índice de pseudoadivinación.

En la tabla 5.3 se recoge de forma sinóptica el rango posible de variación y los valores que suelen adoptar estos tres parámetros, así como la fórmula que permite estimar su valor.

TABLA 5.3
Parámetros del ítem en los modelos de TRI

Parámetro	Significado	Descripción	Rango	Valores típicos
a	Discriminación	Valor proporcional a la pendiente de la curva en el punto $\theta = b$ (Pendiente $_{\theta=b} = 0,425a(1 - c)$)	$(-\infty, \infty)$	$(0,5, 2)$ se descartan los valores negativos
b	Dificultad	$b = \theta$ donde $P(u = 1/\theta) = (1 + c)/2$	$(-\infty, \infty)$	$(-2,2)$
c	Pseudo-adivinación	Valor de la asíntota inferior	$(0, 0,5)$	Deseable $c \leq 0,2$

5.4.2. Estimación del error de medida

Para cuantificar o estimar el error de medida que se comete en un proceso de medición con una prueba o test, la TRI propone varias medidas individuales, esto es, calculables para cada sujeto individual al que se administra una prueba. La primera de ellas se define a nivel de ítem y se expresa como la diferencia entre la respuesta que ese sujeto ha dado efectivamente al ítem en cuestión — u_i — y la probabilidad que ese sujeto

tiene de responder correctamente a ese ítem, dado su nivel θ en la característica latente evaluada — $P(u_i = 1/\theta)$ —:

$$e_i = u_i - P(u_i = 1/\theta) \quad (5.16)$$

Las dos restantes se definen a nivel de test, a saber:

$$1) \quad e = X - V(\theta) = \sum_{i=1}^n u_i - \sum_{i=1}^n P(u_i = 1/\theta) \quad (5.17)$$

donde $V(\theta)$ es la puntuación verdadera —utilizando la terminología de la TCT— que le corresponde a un sujeto cuyo nivel en la característica latente evaluada es θ , definiéndose esta puntuación verdadera como la suma de la probabilidad de responder correctamente a todos y cada uno de los n ítems que forman la prueba en cuestión.

$$2) \quad \sigma_e = \sigma_{\hat{\theta}/\theta} = \frac{1}{\sqrt{I(\theta)}} \quad (5.18)$$

donde:

σ_e es el error típico de medida del sujeto cuyo nivel en la característica latente evaluada es θ y se define como la desviación típica de las estimaciones que se obtendrían para θ — $\hat{\theta}$ — en distintas ocasiones ($\sigma_{\hat{\theta}/\theta}$);

$I(\theta)$ es la función de información del test, que expresa la cantidad de información que sobre el rasgo latente proporciona el test en ese punto — θ — de la escala latente y se formula como:

$$I(\theta) = \sum_{i=1}^n \frac{(P'(u_i = 1/\theta))^2}{P(u_i = 1/\theta)P(u_i = 0/\theta)} \quad (5.19)$$

donde:

$P'(u_i = 1/\theta)$ es la primera derivada de la función característica del ítem i ($P(u_i = 1/\theta)$);

$P(u_i = 0/\theta)$ es la probabilidad de responder incorrectamente al ítem i , esto es, $(1 - P(u_i = 1/\theta))$ y se suele denotar por $Q_i(\theta)$.

En la tabla 5.4 se recogen las expresiones de la función de información y de la primera derivada de la función característica del ítem para los modelos de uno, dos y tres parámetros.

TABLA 5.4
Función de información en los modelos de TRI

Modelo	$P'_i(\theta)$	$I(\theta)$
1P	$1,7P_i(\theta)Q_i(\theta)$	$\sum_{i=1}^n 2,89P_i(\theta)Q_i(\theta)$
2P	$1,7a_iP_i(\theta)Q_i(\theta)$	$\sum_{i=1}^n 2,89a_i^2P_i(\theta)Q_i(\theta)$
3P	$\frac{1,7a_iQ_i(\theta)(P_i(\theta) - c_i)}{(1 - c_i)}$	$\sum_{i=1}^n \frac{2,89a_i^2Q_i(\theta)(P_i(\theta) - c_i)^2}{(1 - c_i)^2P_i(\theta)}$
donde: $P_i(\theta) = P(u_i = 1/\theta);$ $Q_i(\theta) = 1 - P_i(\theta) = P(u_i = 0/\theta).$		

La expresión (5.17) es un estimador del error de medida paralelo al definido en la TCT; la expresión (5.18) es un estimador equivalente del error típico de medida que, ahora sí, se define *para cada sujeto*, para cada punto de la escala latente, no es una medida colectiva del error —como en la TCT— sino una medida individual. Por consiguiente, en la TRI no se estima con el mismo error la característica de interés en todos los sujetos —como sucedía en la TCT— sino que el error típico de medida varía de sujeto a sujeto, no es el mismo para un sujeto superdotado, para un deficiente mental y para una persona normal y corriente cuando se mide a todos ellos con la misma prueba. Obviamente, tampoco en la TCT, pero esta teoría asume independencia entre las puntuaciones verdaderas y el error. Ahí está el problema y una nueva limitación de la TCT.

5.4.3. Estimación de la característica de interés

Como ya se señaló anteriormente, la característica de interés se denota en la TRI mediante la letra griega θ y no como la puntuación verdadera V de la TCT, si bien es perfectamente posible estimar V en la TRI sin más que sumar las probabilidades de responder correctamente a cada ítem del test (véase la fórmula 5.17).

Tal como se indicó al hablar de los supuestos del modelo, el valor estimado para un sujeto en la característica de interés — $\hat{\theta}$ — es el valor θ que hace más probable o verosímil la observación de un patrón de respuesta a los ítems del test (U) como el que realmente ha mostrado el sujeto cuyo θ se desea estimar. Dicho de otro modo, $\hat{\theta}$ será el valor para el que sea máxima la función $P(U/\theta)$. Para obtener empíricamente estas estimaciones es preciso recurrir a programas de ordenador diseñados a tal fin como, por ejemplo, ASCAL, BILOG, RASCAL, XCALIBRE, etc.

En la tabla 5.5 se presenta de forma esquemática los aspectos más relevantes que definen y caracterizan a la TCT y a la TRI.

TABLA 5.5
Características distintivas de la TCT y de la TRI

	TCT	TRI
Supuestos	$V = \mu_x$ $\rho_{ve} = 0$ $\rho_{e_i e_j} = 0$	Unidimensionalidad Independencia local
Función matemática	Lineal	Logística
Error típico de medida (σ_e)	Medida colectiva: $\sigma_x \sqrt{1 - \rho_{xx}}$	Medida individual: $\sigma_{\hat{\theta}/\theta} = \frac{1}{\sqrt{I(\theta)}}$
Estimación de la característica de interés	$\hat{V} = \bar{X}$	$\hat{V} = \sum_{i=1}^n P(u_i = 1/\theta)$ $\hat{\theta} \rightarrow \text{Max. } P(U/\theta)$

5.5. PUNTOS BÁSICOS

- La presencia ineludible del error en cualquier proceso de medición hace necesario:
 - evaluar la calidad métrica de los tests, para ver si éstos se pueden utilizar o no con garantía para obtener estimaciones adecuadas de la característica evaluada;
 - recurrir a una teoría de los tests.
- El objetivo central de una teoría de los tests es determinar la relación que existe entre el nivel del sujeto en la variable —inobservable— que se desea medir y su puntuación —observada— en el

- test. Esta relación viene definida por una función matemática lineal —en la TCT— y por una logística —en la TRI.
- Los dos problemas básicos a los que se enfrenta toda teoría de los tests son:
 - la cuantificación o estimación del error de medida;
 - la determinación o estimación del nivel en que poseen los sujetos la característica de interés que supuestamente está midiendo el test (V en la TCT y θ en la TRI).
 - En la TCT el error típico de medida es idéntico para todas las puntuaciones del test y se define bien como la desviación típica de los errores de medida de todos los sujetos de la muestra, bien como la desviación típica de las puntuaciones empíricas que corresponden a una misma puntuación verdadera.
 - En la TCT se dispone de tres métodos distintos para estimar la puntuación verdadera: el método basado en la desigualdad de Chebychev, el basado en la distribución normal de los errores y el basado en el modelo de regresión. Estos tres métodos proporcionan intervalos confidenciales para V que van de mayor a menor amplitud y, por ende, de menor a mayor precisión.
 - La función característica del ítem es una función que indica cuál es la probabilidad de que un sujeto con un determinado valor θ en el rasgo o característica evaluada por la prueba responda correctamente a un ítem y la función característica del test cuál es la probabilidad de que dicho sujeto presente un determinado patrón de respuestas en la prueba en cuestión (igual al producto de las funciones características de todos los ítems del test).
 - Para definir la función característica de un ítem es necesario conocer tanto los parámetros de los sujetos evaluados — θ — como los del ítem en cuestión —su dificultad b , su discriminación a y su índice de pseudoadivinación c .

5.6. EJERCICIOS

En la matriz adjunta se presentan las puntuaciones obtenidas por un grupo de diez alumnos en las cinco preguntas de una prueba de Matemáticas, así como sus puntuaciones verdaderas y el nivel de conocimientos de Matemáticas expresado en la escala θ .

El valor 1 indica que el alumno ha respondido correctamente y el 0 que ha seleccionado una de las tres alternativas incorrectas de respuesta de la pregunta en cuestión.

ALUMNOS	PREGUNTAS						V	θ
	1	2	3	4	5			
1	0	0	0	1	1	2	2	1,00
2	0	0	1	0	1	2	2	0,00
3	1	0	0	0	1	3	3	1,50
4	0	0	1	1	0	2	2	-0,50
5	0	1	0	1	0	2	2	1,50
6	1	0	0	1	1	2	2	1,75
7	1	1	0	0	0	1	1	0,50
8	0	1	1	1	0	2	2	2,00
9	1	0	1	1	1	3	3	2,50
10	1	1	1	1	0	3	3	1,75

5.6.1. ¿Cuál es el error de medida del alumno número 3?

5.6.2. ¿Cuál es el error típico de medida del test?

5.6.3. ¿Cuál es el error típico de estimación de la puntuación verdadera?

5.6.4. Estime el intervalo confidencial para la puntuación verdadera del alumno número 3 con un nivel de confianza de 0,95.

5.6.5. Suponiendo que los parámetros de las preguntas de esa prueba son los recogidos en la tabla adjunta, indique cuál es el error de medida del alumno número 3 y el error típico de medida cometido en la estimación del nivel de conocimientos de Matemáticas de dicho alumno.

PREGUNTAS	PARÁMETROS		
	a	b	c
1	1	1	0,00
2	1	1	0,25
3	1	-1	0,25
4	2	1	0,00
5	2	-1	0,25

5.6.6. Construya la curva característica de la pregunta 3.

5.6.7. ¿Qué patrón de respuestas es más probable que presente un sujeto con un valor estimado para su nivel de conocimientos de Matemáticas de $\hat{\theta} = 0$: $U_1 = 10010$ ó $U_2 = 00101$?

5.7. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

En la siguiente tabla se han calculado algunos valores que serán de utilidad para dar respuesta a las cuestiones planteadas.

Alumnos	X	V	E	E^2	X^2	V^2
1	2	2	0	0	4	4
2	2	2	0	0	4	4
3	2	3	-1	1	4	9
4	2	2	0	0	4	4
5	2	2	0	0	4	4
6	3	2	1	1	9	4
7	2	1	1	1	4	1
8	3	2	1	1	9	4
9	4	3	1	1	16	9
10	4	3	1	1	16	9
Totales	26	22	4	6	74	52

5.7.1. $E = X - V = 2 - 3 = -1$

5.7.2. Para resolver esta cuestión se puede trabajar utilizando la fórmula (5.3):

$$\sigma_e = \sigma_x \sqrt{1 - \rho_{xx}} = 0,8 \sqrt{1 - 0,56} = 0,53$$

$$\sigma_x = \sqrt{\frac{\sum_{j=1}^{10} X_j^2}{10} - \left(\frac{\sum_{j=1}^{10} X_j}{10} \right)^2} = \sqrt{\frac{74}{10} - \left(\frac{26}{10} \right)^2} = 0,8$$

$$\rho_{xx} = \frac{\sigma_v^2}{\sigma_x^2} = \frac{0,36}{0,64} = 0,56$$

$$\sigma_v^2 = \frac{\sum_{j=1}^{10} V_j^2}{10} - \left(\frac{\sum_{j=1}^{10} V_j}{10} \right)^2 = \frac{52}{10} - \left(\frac{22}{10} \right)^2 = 0,36$$

5.7.3.

$$\sigma_{v \cdot x} = \sigma_e \sqrt{\rho_{xx}} = 0,53 \sqrt{0,56} = 0,40$$

5.7.4. Según el método basado en la desigualdad de Chebychev (ecuación 5.6):

$$P\left(2 - 0,53 \sqrt{\frac{1}{1-0,95}} \leq V \leq 2 + 0,53 \sqrt{\frac{1}{1-0,95}}\right) \geq 0,95$$

$$P(-0,37 \leq V \leq 4,37) \geq 0,95$$

Según el método basado en la distribución normal de los errores (ecuación 5.7):

$$P(2 - 0,53 \times 1,96 \leq V \leq 2 + 0,53 \times 1,96) \geq 0,95$$

$$P(0,96 \leq V \leq 3,04) \geq 0,95$$

Según el método basado en el modelo de regresión (ecuación 5.8):

$$P(2,26 - 0,40 \times 1,96 \leq V \leq 2,26 + 0,40 \times 1,96) \geq 0,95$$

$$P(1,48 \leq V \leq 3,04) \geq 0,95$$

donde V' se estima de acuerdo a la ecuación (5.9):

$$V' = 0,56(2 - 26/10) + 26/10 = 2,26$$

5.7.5. Según la ecuación (5.17),

$$E = X - V(\theta) = X - \sum_{i=1}^5 P(u_i = 1/\theta = 1,5)$$

Para calcular $P(u_i = 1/\theta = 1,5)$ se aplica la fórmula (5.15) ya que son tres los parámetros de las preguntas de esta prueba:

ÍTEMS	$P(u_i = 1/\theta = 1,5)$
1	$0 + \frac{1 - 0}{1 + \exp(-1,7 \times 1(1,5 - 1))} = 0,70$
2	$0,25 + \frac{1 - 0,25}{1 + \exp(-1,7 \times 1(1,5 - 1))} = 0,78$
3	$0,25 + \frac{1 - 0,25}{1 + \exp(-1,7 \times 1(1,5 - (-1)))} = 0,99$
4	$0 + \frac{1 - 0}{1 + \exp(-1,7 \times 2(1,5 - 1))} = 0,85$
5	$0,25 + \frac{1 - 0,25}{1 + \exp(-1,7 \times 2(1,5 - (-1)))} = 0,99$

$$E = 2 - (0,70 + 0,78 + 0,99 + 0,85 + 0,99) = 2 - 4,31 = -2,31$$

Para calcular el error típico de medida habrá que aplicar la ecuación (5.18):

$$\sigma_e = \frac{1}{\sqrt{I(\theta)}} = \frac{1}{\sqrt{\sum_{i=1}^5 \frac{2,89a_i^2 Q_i(\theta) (P_i(\theta) - c_i)^2}{(1 - c_i)^2 P_i(\theta)}}} = \frac{1}{\sqrt{\sum_{i=1}^5 I(\theta, u_i)}}$$

ÍTEMS	$P(\theta)$	$Q(\theta)$	c	$P(\theta) - c$	a	$I(\theta, u)$
1	0,70	0,30	0,00	0,70	1	0,61
2	0,78	0,22	0,25	0,53	1	0,41
3	0,99	0,01	0,25	0,74	1	0,03
4	0,85	0,15	0,00	0,85	2	1,47
5	0,99	0,01	0,25	0,74	2	0,11

$$\sigma_e = \frac{1}{\sqrt{0,61 + 0,41 + 0,03 + 1,47 + 0,11}} = 0,62$$

5.7.6. La curva característica de un ítem es la representación gráfica de su función característica, es decir, es una curva que indica la probabilidad de observar una respuesta correcta a un ítem, supuesto un determinado valor en la escala θ . Para el caso del modelo de tres parámetros, la fórmula que proporciona el valor de esta función es la (5.15):

$$P(u = 1/\theta) = c + \frac{(1 - c)}{1 + \exp(-1,7a(\theta - b))}$$

En esta ecuación conocemos todos los valores a excepción de θ . Ahora bien, si damos valores en la ecuación anterior a θ y calculamos cuál es el valor correspondiente de $P(u = 1/\theta)$, podemos dibujar ya la curva característica del ítem. Por simplicidad en los cálculos consideraremos exclusivamente los siguientes puntos en la escala θ : -3, -2, -1, 0, 1, 2 y 3.


Veamos, en primer lugar, cuál es la expresión concreta que adopta la función característica de este ítem:

$$P(u_3 = 1/\theta) = 0,25 + \frac{1 - 0,25}{1 + \exp(-1,7 \times 1(\theta - (-1)))} = 0,25 + \frac{0,75}{1 + \exp(-1,7(\theta + 1))}$$

A continuación, daremos valores a θ y calcularemos la probabilidad correspondiente:

θ	$P(u_3 = 1/\theta)$
-3	0,27
-2	0,37
-1	0,62
0	0,88
1	0,98
2	0,99
3	0,99

Una vez obtenidos estos valores, lo único que hay que hacer es construir la curva correspondiente, poniendo los valores de θ en el eje de abscisas y la probabilidad en el eje de ordenadas.



5.7.7. Para determinar cuál de los dos patrones presentados — U_1 o U_2 — es el que con mayor probabilidad puede mostrar un sujeto con $\hat{\theta} = 0$, lo que hay que hacer es calcular $P(U_1/\theta = 0)$ y $P(U_2/\theta = 0)$ y ver cuál de las dos es mayor. Para ello, aplicamos la fórmula (5.11):

$$\begin{aligned}
 P(U_1/\theta = 0) &= P(U_1 = 10010/\theta = 0) = \prod_{i=1}^5 P(u_i = u_i/\theta = 0) = \\
 &= P(u_1 = 1/\theta = 0)P(u_2 = 0/\theta = 0)P(u_3 = 0/\theta = 0)P(u_4 = 1/\theta = 0)P(u_5 = 0/\theta = 0) = \\
 &= P_1(\theta = 0)Q_2(\theta = 0)Q_3(\theta = 0)P_4(\theta = 0)Q_5(\theta = 0) \\
 P(U_2/\theta = 0) &= P(U_2 = 00101/\theta = 0) = Q_1(\theta = 0)Q_2(\theta = 0)P_3(\theta = 0)Q_4(\theta = 0)P_5(\theta = 0)
 \end{aligned}$$

En la siguiente tabla se indica la probabilidad de responder correcta e incorrectamente a cada ítem de la prueba para un sujeto con $\hat{\theta} = 0$. Para obtener el primer valor basta con aplicar la fórmula (5.15) tal como se hizo en el ejercicio 5.6.5.

ÍTEMS	$P(\theta = 0)$	$Q(\theta = 0)$
1	0,15	0,85
2	0,37	0,63
3	0,88	0,12
4	0,03	0,97
5	0,98	0,02

Por tanto, $P(U_1/\theta = 0)$ y $P(U_2/\theta = 0)$ se pueden describir ya del siguiente modo:

$$\begin{aligned}
 P(U_1/\theta = 0) &= 0,15 \times 0,63 \times 0,12 \times 0,03 \times 0,02 = 6,8 \times 10^{-6} \\
 P(U_2/\theta = 0) &= 0,85 \times 0,63 \times 0,88 \times 0,97 \times 0,98 = 0,45
 \end{aligned}$$

Por consiguiente, es mucho más probable que un sujeto con valor estimado de 0 en la característica de interés presente el patrón de respuestas U_2 que el U_1 . En realidad, la probabilidad de observar U_2 es de 0,45 mientras que es casi imposible que un alumno de esas características obtenga como patrón en el test el patrón U_1 ($P(U_1/\theta = 0) \cong 0$).

5.8. BIBLIOGRAFÍA BÁSICA RECOMENDADA

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulos 3 y 7.

En estos capítulos se abordan, entre otras cuestiones, el modelo de la TCT y la estimación de las puntuaciones verdaderas, respectivamente.

MELIÁ, J. L. (2000). *Teoría de la fiabilidad y la validez*. Valencia: Cristóbal Serrano. Capítulos 3 y 8.

Se trata de dos capítulos dedicados, respectivamente, al tratamiento del error de medida y a la estimación de la puntuación verdadera en la TCT.

MUÑIZ, J. (1997). *Introducción a la teoría de respuesta a los ítems*. Madrid: Pirámide.

Libro ameno y de fácil lectura que introduce al lector en la TRI, proporcionando información sobre los puntos del capítulo y también acerca de cuestiones como la estimación y el ajuste del modelo, la métrica y algunas aplicaciones de la TRI.

SANTISTEBAN, C. (1990). *Psicometría. Teoría y práctica en la construcción de tests*. Madrid: Norma. Capítulo 7.

Se trata de un capítulo dedicado por completo a la estimación de la puntuación verdadera en la TCT.

5.9. LECTURAS SUGERIDAS

MUÑIZ, J. (1998). *Teoría clásica de los tests*. Madrid: Pirámide. Capítulo 1.

Se realiza una interesante introducción histórica a los orígenes y desarrollo de la teoría de los tests junto a una breve presentación del modelo de la TCT.

MUÑIZ, J. y Hambleton, R. K. (1992). Medio siglo de teoría de respuesta a los ítems. *Anuario de Psicología*, 52, 41-66.

Revisión detallada del campo de la TRI durante sus primeros cincuenta años de vida.

NAVAS, M. J. (1994). Teoría clásica de los tests *versus* teoría de respuesta al ítem. *Psicológica*, 15, 175-208.

Reflexión acerca del papel que han jugado y juegan ambos modelos en el campo de la medida psicológica y educativa.

5.10. MATERIAL COMPLEMENTARIO

- La teoría de la generalizabilidad.
- Deducciones derivadas de los supuestos de la TCT.

LA FIABILIDAD COMO CRITERIO MÉTRICO DE LA CALIDAD GLOBAL DEL TEST

María José Navas Ara

6.1. INTRODUCCIÓN

En el capítulo anterior vimos cómo el problema del error de medida —el error que de forma invariable e inevitable se introduce siempre en cualquier proceso de medición psicológica (y física)— hace necesario:

1. el recurso a una teoría de los tests, que dé cuenta del mismo, lo cuantifique y proporcione estimaciones de la característica de interés;
2. el examen de la calidad métrica de los instrumentos de medida, para ver si éstos cumplen o no unos criterios mínimos de calidad que nos permitan su utilización con garantía para obtener estimaciones adecuadas de la característica que se desea evaluar.

Estos criterios métricos de la calidad global de la prueba son su fiabilidad y validez; este capítulo está dedicado íntegramente al primero y el siguiente al segundo.

Para examinar la calidad métrica de cada uno de los ítems o preguntas del test es necesario realizar el correspondiente análisis de ítems que será presentado en detalle en el capítulo 8.




FIGURA 6.1. La evaluación de los tests.

La fiabilidad del test es un criterio métrico de calidad que proporciona información acerca de la cantidad de error aleatorio que contiene una medida obtenida al aplicar esa prueba o test a un sujeto o grupo de sujetos. Se refiere al grado en que las puntuaciones de los tests están libres de errores aleatorios de medida o, lo que es lo mismo, al grado en que las puntuaciones del test miden con precisión la característica latente supuestamente evaluada por la prueba (la precisión será mayor cuanto menor sea el error aleatorio contenido en la medida). Dicho de otro modo, la fiabilidad de un test va a proporcionar información acerca de lo próximas o distantes que se encuentran entre sí (1) las estimaciones del nivel en que poseen los sujetos la característica de interés, realizadas a partir de las puntuaciones —observables— obtenidas en dicho test y (2) el nivel real —inobservable— de los sujetos en dicha característica. Se trata, por tanto, de un criterio métrico directamente vinculado a la teoría de los tests cuyo objetivo es, como se recordará, establecer —y formalizar matemáticamente— la relación existente entre ese nivel —inobservable— y la actuación —observable— del sujeto en el test. De hecho, se puede decir que la razón de ser básica de las teorías de los tests, al menos de la teoría clásica de los tests, es proporcionar métodos que permitan determinar o estimar la precisión de las medidas obtenidas con un test. No es en absoluto casual que la paternidad del término *fiabilidad* en el campo que nos ocupa coincida con la de la teoría clásica de los tests: Sir Charles Spearman.

Antes de pasar a ver en los siguientes apartados cómo conciben y formalizan este criterio métrico de calidad las distintas teorías de los tests, es preciso insistir en que éste tiene que ver con un tipo determinado de errores, con los errores *aleatorios*, es decir, con factores en principio no relacionados con la característica que mide el test pero que pueden operar sobre la puntuación del sujeto en el test, tanto en un sentido (↑) como en otro (↓), esto es, con factores que no presentan un patrón sistemático —antes al contrario— en su relación con las puntuaciones en el test. Así, las condiciones físicas de un sujeto pueden subir o bajar espúreamente su puntuación en el test, según que el sujeto haya descansado perfectamente la noche anterior o, por el contrario, haya tenido algo de fiebre. Del mismo modo se podría enumerar un largo etcétera de factores que dan lugar a fluctuaciones aleatorias en las puntuaciones de los sujetos.

En particular, en la teoría clásica de los tests se ha prestado atención básicamente a dos fuentes de error:

1. El error debido a las fluctuaciones aleatorias que ocurren a lo largo del tiempo. La esencia de la ciencia es la replicabilidad, es decir, que se pueda obtener el mismo resultado en distintos ensa-

yos o en distintos momentos a lo largo del tiempo. Desde esta perspectiva se ha conceptualizado la fiabilidad como la *estabilidad temporal* de las puntuaciones del test, como la consistencia de la respuesta que dan los sujetos a los ítems del test en las distintas aplicaciones de la prueba a lo largo del tiempo. Como veremos en el segundo apartado, los procedimientos propuestos para estimarla han sido el test-retest y el método de las formas paralelas.

2. El error debido a las diferencias en el contenido entre los ítems del test. Desde esta perspectiva se ha conceptualizado la fiabilidad como *consistencia interna* de los ítems de la prueba, como congruencia entre las respuestas de cada sujeto en los distintos ítems del test. Como veremos en el segundo apartado los procedimientos propuestos para estimarla han sido los métodos basados en la división del test en dos mitades y el basado en la covariación de los ítems.

La concepción clásica de la fiabilidad presenta problemas importantes. Quizá, el más grave de todos ellos sea que la fiabilidad de una medida depende en este modelo teórico del conjunto particular de ítems que conforman el test en cuestión y del grupo de sujetos al que éste se ha administrado. Las alternativas que se han formulado a esta concepción clásica son la fiabilidad como *generalizabilidad* —en la teoría de la generalizabilidad— y la fiabilidad como *información* —en la teoría de respuesta al ítem—. El tercer apartado del capítulo se dedica a esta última.

MC Fiabilidad como generalizabilidad

Cuando los tests están integrados por ítems de construcción y no de elección, por ítems de respuesta abierta y no cerrada, la asignación de puntuaciones suele exigir el recurso a jueces o calificadores que son los encargados en este caso de traducir a un número la respuesta dada por el sujeto al ítem. Cuando la tarea de jueces o calificadores pueda introducir un componente subjetivo importante en el proceso de asignación de puntuaciones, es conveniente calcular algún coeficiente o índice de acuerdo entre los jueces implicados en el proceso, con el fin de poder determinar hasta qué punto puede estar influyendo la subjetividad del juez en la precisión de las puntuaciones para medir la característica de interés. El cuarto apartado se ocupa de como estimar la fiabilidad inter-jueces.

El último ángulo de la fiabilidad que se examinará en el capítulo es la consistencia de las clasificaciones realizadas a partir de las puntuaciones del test, que tiene una gran importancia cuando se da una interpretación criterial a éstas. Por ejemplo, supongamos que se utiliza una prueba general de rendimiento académico para ayudar a decidir si los alumnos de un curso pasan o no al siguiente ciclo educativo. Se establece una determinada puntuación de corte con arreglo al criterio del claustro de profesores, de modo que el alumno que puntúe por encima de dicha puntuación podría cambiar de ciclo y el que obtenga una puntuación inferior a la fijada por dicho criterio podría permanecer en el mismo. En este caso, lo que interesa no es tanto la precisión de las puntuaciones sino que en los distintos momentos en los que se puede aplicar la prueba, la puntuación obtenida por el alumno le clasifique en la misma categoría (cambio de ciclo o permanencia en el ciclo educativo). El quinto apartado del capítulo aborda las cuestiones relativas a la cuantificación o estimación de la fiabilidad o consistencia de las clasificaciones obtenidas a partir de las puntuaciones de un test.

En la figura 6.2 se presenta un diagrama con un esquema-resumen de los contenidos del capítulo.




FIGURA 6.2. Esquema-resumen del contenido del capítulo 6.

Los objetivos que se persiguen con este capítulo son los siguientes:

- comprender el concepto de fiabilidad de la medida;
- conocer las distintas concepciones de la fiabilidad en las diferentes teorías de los tests;

- saber estimar la fiabilidad de las medidas proporcionadas por un test;
- identificar los factores que afectan a la fiabilidad;
- saber obtener una medida del acuerdo entre los jueces o calificadores que participan en el proceso de corrección/asignación de puntuaciones a los ítems de una prueba;
- comprender las implicaciones que tiene para la fiabilidad de una prueba el hecho de que se dé una interpretación criterial a sus puntuaciones.

6.2. CONCEPCIÓN CLÁSICA

Se ha definido la fiabilidad de un test como un criterio métrico de calidad relacionado con la cantidad de error aleatorio que contienen las medidas obtenidas al aplicar el test a un grupo de sujetos. La fiabilidad sería, por tanto, la precisión con que las puntuaciones del test miden la característica latente que supuestamente examina la prueba.

La fiabilidad constituye el núcleo básico de desarrollo de la Teoría Clásica de los Tests (TCT), que la define formalmente como la correlación al cuadrado entre las puntuaciones verdaderas —el nivel real en que los sujetos poseen la característica o atributo que se desea medir— y las puntuaciones empíricas que han obtenido realmente los sujetos en el test, esto es, como el cociente entre la varianza de las puntuaciones verdaderas y la de las empíricas:

$$\rho_{xx} = \rho_{xv}^2 = \frac{\sigma_v^2}{\sigma_x^2} \quad (6.1)$$

donde:

ρ_{xx} es el coeficiente de fiabilidad del test;

ρ_{xv} es el índice de fiabilidad del test.

CUADRO 6.1
Coeficiente de correlación de Pearson

El coeficiente de correlación de Pearson es un indicador del grado de relación que existe entre dos variables —X e Y— y la fórmula que nos permite obtener su valor es la siguiente:

$$\rho_{xy} = \frac{N \sum XY - \sum X \sum Y}{\sqrt{[N \sum X^2 - (\sum X)^2][N \sum Y^2 - (\sum Y)^2]}}$$

donde:

N es el número de sujetos a los que se ha medido en las variables X e Y;
X e Y son las puntuaciones obtenidas por los sujetos en las variables X e Y.

Este coeficiente sólo puede presentar valores comprendidos entre -1 y +1:

- $\rho_{xy} = 1$: máxima relación positiva entre X e Y, esto es, siempre que X varía en un sentido, Y varía en el mismo sentido (si X sube Y también sube; si X baja, Y también baja).
- $\rho_{xy} = 0$: no tiene nada que ver una variable con la otra, X e Y no están relacionadas en absoluto (cuando X sube, Y puede subir, bajar o no modificar su valor).
- $\rho_{xy} = -1$: máxima relación negativa entre X e Y: siempre que X varía en un sentido Y varía en sentido contrario (si X sube, Y baja y a la inversa).

Ejemplo:

Se desea conocer la relación existente entre la puntuación obtenida por unos alumnos de enseñanza secundaria en una prueba de Lengua —X— y las calificaciones otorgadas a dichos alumnos por sus profesores a finales de curso. Las puntuaciones obtenidas por 10 alumnos de la muestra en la prueba han sido 15, 10, 13, 8, 9, 17, 14, 6, 16 y 13. Las calificaciones fueron las siguientes: 7, 6, 7, 3, 2, 8, 5, 4, 6 y 5. El coeficiente de correlación de Pearson para las variables X e Y sería el siguiente:

X	Y	X ²	Y ²	XY
15	7	225	49	105
10	6	100	36	60
13	7	169	49	91
8	3	64	9	24
9	2	81	4	18
17	8	289	64	136
14	5	196	25	70
6	4	36	16	24
16	6	256	36	96
13	5	169	25	65
121	53	1585	313	689

$$\hat{\rho}_{xy} = \frac{10 \times 689 - 121 \times 53}{\sqrt{(10 \times 1585 - 121^2)(10 \times 313 - 53^2)}} = 0,77$$

Cuanto más precisas sean las puntuaciones obtenidas con el test, tanto más parecidas serán las puntuaciones empíricas y las verdaderas y mayor será el valor de la correlación ρ_{xv} , alcanzando ésta el valor de 1 cuando X y V sean idénticas (o estén linealmente relacionadas), es decir, en el hipotético caso de que no existieran errores de medida (recuerde el lector que la ecuación básica de la TCT es $X = V + E$).

Una forma habitual y bastante clara de interpretar el coeficiente de fiabilidad es viendo la proporción o el porcentaje de la varianza de las puntuaciones empíricas que es explicado o se puede atribuir a la varianza de las puntuaciones verdaderas (σ_v^2 / σ_x^2): si la mayor parte de la variación observada en las puntuaciones empíricas que han obtenido de hecho los sujetos en el test (σ_x^2) se puede atribuir a su variación real en la característica que mide el test (σ_v^2), entonces su coeficiente de fiabilidad (σ_v^2 / σ_x^2) será alto y se puede decir que ese test es fiable, que mide con precisión la característica o rasgo supuestamente evaluado.

Una forma alternativa de interpretar el coeficiente de fiabilidad es sustituyendo el numerador por su valor en la ecuación anterior:

$$\rho_{xx} = \frac{\sigma_v^2}{\sigma_x^2} = \frac{\sigma_x^2 - \sigma_e^2}{\sigma_x^2} = 1 - \frac{\sigma_e^2}{\sigma_x^2} = 1 - \rho_{xe}^2 \quad (6.2)$$

Esta formulación sí relaciona directamente el coeficiente de fiabilidad con el error aleatorio, al expresarlo como la diferencia hasta la unidad de la proporción de la varianza observada en las puntuaciones del test (σ_x^2) atribuible a los errores aleatorios que se cometen en el proceso de medición psicológica (σ_e^2). Observe el lector que, de acuerdo al modelo lineal de Spearman, las únicas fuentes posibles que pueden hacer variar el valor de X son dos: V y E ($X = V + E$).

El problema es que las ecuaciones anteriores, aun teniendo un indudable interés teórico, carecen por completo de relevancia práctica ya que, en definitiva, lo único que podemos conocer realmente es X , las puntuaciones que de hecho han obtenido los sujetos en el test: no conocemos las puntuaciones verdaderas V (ni por supuesto su varianza) y no conocemos tampoco los errores de medida E , por lo que las fórmulas anteriores no nos permiten obtener directamente una medida del coeficiente o del índice de fiabilidad: es necesario arbitrar, por tanto, procedimientos que permitan obtener empíricamente estimaciones del coeficiente de fiabilidad a partir de lo único que conocemos: X .

6.2.1. Fiabilidad como estabilidad temporal

6.2.1.1. Método test-retest

El coeficiente de fiabilidad del test se ha definido como la correlación de las puntuaciones del test consigo mismo: ρ_{xx} . Por tanto, una forma posible de obtener una estimación de su valor sería aplicar el test a una muestra de sujetos en dos ocasiones distintas y calcular la correlación entre las puntuaciones obtenidas en esos dos momentos temporales:

$$\hat{\rho}_{xx} = r_{x_1x_2} = \frac{N \sum X_1X_2 - \sum X_1 \sum X_2}{\sqrt{\left[N \sum X_1^2 - (\sum X_1)^2 \right] \left[N \sum X_2^2 - (\sum X_2)^2 \right]}} \quad (6.3)$$

donde:

X_1 son las puntuaciones obtenidas por los sujetos en la primera ocasión;

X_2 son las puntuaciones obtenidas por los sujetos en la segunda ocasión;

N es el número de sujetos de la muestra.

Al coeficiente de fiabilidad obtenido se le suele denominar *coeficiente de estabilidad* porque proporciona una medida de la estabilidad temporal de las puntuaciones obtenidas al aplicar en distintas ocasiones el mismo test. Al procedimiento utilizado en la obtención de este coeficiente de estabilidad se le denomina *método test-retest*.

El método test-retest es útil para pruebas o tests sensoriales o psicomotores (pruebas de rapidez perceptiva, memoria de listas, discriminación sensorial, verificación rápida de cálculos numéricos, etc.), siempre y cuando el intervalo temporal entre las dos aplicaciones de la prueba sea lo suficientemente largo como para contrarrestar los posibles efectos de la práctica o de la fatiga generados con la primera aplicación, y siempre y cuando no haya un cambio sustancial ni en la actitud que adopta el sujeto al realizar el test ni en el nivel en que posee dicho sujeto el rasgo o característica evaluada con la prueba.

6.2.1.2. Método de las formas paralelas

Otra posibilidad consiste en aplicar en las dos ocasiones no la misma prueba —como en el método anterior— sino dos formas paralelas de la misma.

Las formas paralelas de un test están compuestas por distintos ítems o preguntas que se construyen siguiendo las mismas especificaciones del test (véase el capítulo 3), pero de forma que:

1. La puntuación verdadera de un sujeto sea idéntica en las dos formas A y B: $V_A = V_B$ para todos los sujetos de la muestra o población.
2. La varianza de los errores de medida sea la misma en una y otra forma del test: $\sigma_{e_A}^2 = \sigma_{e_B}^2$.

Para obtener una estimación del coeficiente de fiabilidad bastaría con calcular la correlación entre las puntuaciones obtenidas por una muestra de sujetos en las dos formas del test:

$$\hat{\rho}_{xx} = r_{x_A x_B} = \frac{N \sum X_A X_B - \sum X_A \sum X_B}{\sqrt{\left[N \sum X_A^2 - (\sum X_A)^2 \right] \left[N \sum X_B^2 - (\sum X_B)^2 \right]}} \quad (6.4)$$

donde:

X_A son las puntuaciones obtenidas por los sujetos en la forma A del test;

X_B son las puntuaciones obtenidas por los sujetos en la forma B del test;

N es el número de sujetos de la muestra.

Al coeficiente de fiabilidad obtenido se le suele denominar *coeficiente de equivalencia* porque proporciona una medida de la equivalencia entre las distintas formas administradas del test, definiendo la fiabilidad como el grado en que esas puntuaciones están libres de errores relacionados con la muestra o conjunto específico de ítems utilizado en cada ocasión. Al procedimiento utilizado en la obtención de este coeficiente de equivalencia se le denomina *método de las formas paralelas*.

No es tarea sencilla encontrar formas realmente paralelas de un test. Por un lado, las dos condiciones de paralelismo formuladas anteriormente no se obtienen fácilmente. Por otro, no siempre existen especificaciones claras y detalladas del test que permitan construir con garantías distintas formas del mismo que tengan el mismo contenido y formato, idénticas características psicométricas, etc. Por ello, se han formulado versiones alternativas —más débiles— de esas condiciones de equivalencia, hablándose de *medidas estrictamente tau-equivalentes* (cuando solo se cumple la condición de la igualdad de las puntuaciones verdaderas en

ambas formas del test), de *medidas esencialmente tau-equivalentes* (cuando no se cumplen ninguna de las dos y las puntuaciones verdaderas de ambas formas difieren en una constante aditiva) y de *medidas congenéricas* (cuando no se cumplen ninguna de las dos y la puntuación verdadera en una forma es una transformación lineal de la puntuación verdadera en la otra forma). La tabla 6.1 recoge esquemáticamente todas estas condiciones de equivalencia.

TABLA 6.1
Tipos de medidas y condiciones de equivalencia en la teoría clásica de los tests

Tipos de medidas	Condiciones de equivalencia
Paralelas	$V_A = V_B$ $\sigma_{e_A}^2 = \sigma_{e_B}^2$
Estrictamente tau-equivalentes	$V_A = V_B$ $\sigma_{e_A}^2 \neq \sigma_{e_B}^2$
Esencialmente tau-equivalentes	$V_A = V_B + b$ $\sigma_{e_A}^2 \neq \sigma_{e_B}^2$
Congenéricas	$V_A = aV_B + b$ $\sigma_{e_A}^2 \neq \sigma_{e_B}^2$

Dado que el método de las formas paralelas requiere la aplicación de la prueba en dos ocasiones distintas, son también aplicables para este método las consideraciones realizadas en el método test-retest en torno a la amplitud del intervalo entre aplicaciones y a los posibles cambios en la actitud y nivel del sujeto en la variable medida por el test.

6.2.2. Fiabilidad como consistencia interna

Como se acaba de señalar, no siempre es posible construir formas paralelas de un test, ni siquiera formas con una equivalencia más débil, ni tampoco es posible en muchas ocasiones aplicar la prueba (o una forma alternativa) en dos ocasiones distintas. ¿Cómo obtener entonces una esti-

mación del coeficiente de fiabilidad del test cuando éste se aplica solo una vez? En este caso es imposible plantear la fiabilidad en términos de la estabilidad o congruencia entre las puntuaciones obtenidas en las dos ocasiones en las que se ha administrado el test. La forma de abordarla ahora será en términos de la congruencia entre las respuestas que han dado los sujetos a los distintos ítems (o grupos de ítems) del test. Lo que se busca es la congruencia o la consistencia en la actuación o forma de responder del sujeto a los distintos ítems (o grupos de ítems) del test, de manera que si el sujeto se muestra consistente en su actuación se considera que es posible generalizar sus puntuaciones a otros ítems del dominio evaluado, distintos a los ítems concretos utilizados en el test. Cuando se examina la fiabilidad desde este ángulo, los errores aleatorios tienen que ver con la utilización concreta que se hace en un test de una determinada muestra o conjunto de ítems, esto es, proceden de la variación en el contenido de los ítems, de errores derivados del muestreo de contenido de los ítems del test. Por eso se habla de la fiabilidad como de la *consistencia interna* de los ítems del test y se recomienda adoptar esta óptica para estimar el coeficiente de fiabilidad de un test cuando éste se ha construido para proporcionar un conjunto homogéneo de ítems, desaconsejándose su utilización cuando la especificación del test lo define como una prueba que pretende evaluar un dominio conductual o un área de conocimiento que no tiene porque ser necesariamente homogéneo. Asimismo, la adopción de esta perspectiva supone que todos los sujetos han tenido la oportunidad de responder a todos los ítems del test, esto es, es apropiado para tests de potencia pero no para tests de velocidad.

Todos los coeficientes que estiman la fiabilidad desde esta óptica se basan en la relación existente entre las puntuaciones obtenidas por los sujetos en distintos grupos de ítems o partes del test (métodos basados en la división del test en dos mitades) o en la relación existente entre las puntuaciones obtenidas en los ítems del test (métodos basados en la covariación de los ítems).

6.2.2.1. Métodos basados en la división del test en dos mitades

Como su propio nombre indica, estos métodos consisten en dividir el test en dos mitades y ver si la actuación del sujeto en las dos partes o mitades es consistente o congruente. Según sean estas mitades —paralelas, estricta o esencialmente tau-equivalentes o congenéricas— variará el procedimiento para obtener una estimación del coeficiente de fiabilidad del test. La tabla 6.2 recoge las distintas fórmulas que permiten estimar dichos coeficientes según sea la equivalencia existente entre las dos mitades en las que se ha dividido la prueba.

TABLA 6.2
Estimación del coeficiente de fiabilidad con el método basado en la división del test
en dos mitades

Mitades	$\hat{\rho}_{xx}$
Paralelas	$\frac{2\rho_{12}}{1 + \rho_{12}}$
Estrictamente tau-equivalentes	$2\left(1 - \frac{\sigma_1^2 + \sigma_2^2}{\sigma_x^2}\right) = \frac{4\rho_{12}\sigma_1\sigma_2}{\sigma_x^2}$
Esencialmente tau-equivalentes	$2\left(1 - \frac{\sigma_1^2 + \sigma_2^2}{\sigma_x^2}\right) = \frac{4\rho_{12}\sigma_1\sigma_2}{\sigma_x^2}$
Congénéricas	$\frac{\rho_{12}\sigma_1\sigma_2}{k_1k_2\sigma_x^2}$
donde: ρ_{12} es el coeficiente de correlación entre las puntuaciones obtenidas en las dos mitades (1 y 2); σ_1 es la desviación típica de las puntuaciones obtenidas en la mitad 1; σ_2 es la desviación típica de las puntuaciones obtenidas en la mitad 2; σ_x^2 es la varianza de las puntuaciones obtenidas en el test; $k_1 = n_1/(n_1 + n_2)$ donde n_1 y n_2 son el número de ítems de la mitad 1 y 2, respectivamente; $k_2 = n_2/(n_1 + n_2)$.	

La cuestión o pregunta clave cuando se trabaja con estos métodos es cómo dividir el test en dos mitades equivalentes. Esta no es en absoluto una cuestión trivial y es preciso ser extremadamente cuidadosos al hacerlo. Por ejemplo, en pruebas cognitivas es muy frecuente que los ítems estén ordenados según su grado de dificultad (de menos a más), formato o contenido. Si esto es así y se toma como mitad 1 la mitad compuesta por los primeros $n/2$ ítems del test y como mitad 2 la mitad compuesta por los últimos $n/2$ ítems del test, las mitades 1 y 2 difícilmente serán mitades equivalentes ya que los ítems de la mitad 2 serán considerablemente más difíciles que los de la mitad 1. Es preciso que las dos mitades

Ejemplo 6.1

Calcúlese el coeficiente de fiabilidad de un test de 6 ítems aplicado a los 8 sujetos de una muestra cuyas puntuaciones se recogen en la tabla adjunta, en el supuesto de que es posible formar dos mitades con todos los tipos de equivalencia posibles:

Sujetos	Ítem n.º					
	1	2	3	4	5	6
1	1	1	0	0	1	0
2	1	1	1	1	1	0
3	1	1	1	0	0	0
4	1	0	0	1	0	0
5	1	1	0	0	0	0
6	1	1	1	1	0	0
7	1	0	0	0	0	0
8	1	1	0	0	1	0

Para formar las dos mitades del test se van a considerar, por un lado, los ítems con número par de orden (mitad 1) y, por otro, los ítems con número impar de orden (mitad 2). En la tabla siguiente se han calculado ya para cada sujeto las puntuaciones en el test (suma de las puntuaciones obtenidas en los 6 ítems) y en cada una de las mitades (suma de las puntuaciones en los ítems pares e impares, respectivamente) y se han incluido, además, algunas columnas necesarias para los cálculos posteriores del coeficiente de fiabilidad:

Sujetos	X	P	I	X^2	P^2	I^2	PI
1	3	1	2	9	1	4	2
2	5	2	3	25	4	9	6
3	3	1	2	9	1	4	2
4	2	1	1	4	1	1	1
5	2	1	1	4	1	1	1
6	4	2	2	16	4	4	4
7	1	0	1	1	0	1	0
8	3	1	2	9	1	4	2
Totales	23	9	14	77	13	28	18

Mitades paralelas:

$$\hat{\rho}_{xx} = \frac{2r_{pi}}{1 + r_{pi}} = \frac{2 \times 0,71}{1 + 0,71} = 0,83$$

$$r_{pi} = \frac{N \sum PI - \sum P \sum I}{\sqrt{[N \sum P^2 - (\sum P)^2][N \sum I^2 - (\sum I)^2]}} = \frac{8 \times 18 - 9 \times 14}{\sqrt{(8 \times 13 - 9^2)(8 \times 28 - 14^2)}} = 0,71$$

Mitades estricta o esencialmente tau-equivalentes:

$$\hat{\rho}_{xx} = \frac{4r_{pi}s_p s_i}{s_x^2} = \frac{4 \times 0,71 \times 0,60 \times 0,66}{1,36} = 0,83$$

$$s_p = \sqrt{\frac{\sum P^2}{N} - \left(\frac{\sum P}{N}\right)^2} = \sqrt{\frac{13}{8} - \left(\frac{9}{8}\right)^2} = 0,60$$

$$s_i = \sqrt{\frac{\sum I^2}{N} - \left(\frac{\sum I}{N}\right)^2} = \sqrt{\frac{28}{8} - \left(\frac{14}{8}\right)^2} = 0,66$$

$$s_x^2 = \frac{\sum X^2}{N} - \left(\frac{\sum X}{N}\right)^2 = \frac{77}{8} - \left(\frac{23}{8}\right)^2 = 1,36$$

Mitades congénicas:

$$\hat{\rho}_{xx} = r_{xx} = \frac{r_{pi}s_p s_i}{k_1 k_2 s_x^2} = \frac{0,71 \times 0,60 \times 0,66}{0,5 \times 0,5 \times 1,36} = 0,83$$

$$k_1 = \frac{n_1}{n_1 + n_2} = \frac{3}{3 + 3} = 0,5$$

$$k_2 = \frac{n_2}{n_1 + n_2} = \frac{3}{3 + 3} = 0,5$$

estén formadas por ítems que sean en principio equivalentes en dificultad y contenido. Un procedimiento habitualmente utilizado para obtener mitades equivalentes es asignar a la mitad 1 los ítems con número par de orden en el test y a la mitad 2 los ítems con número impar. Otra posibilidad es asignar los ítems a las mitades 1 y 2 de forma aleatoria, en el supuesto de que la selección aleatoria tenderá a equilibrar los errores y a hacer las mitades más o menos equivalentes.

Por último, es preciso tener en cuenta que cuando una prueba está constituida por bloques de ítems que comparten un mismo material (por ejemplo, un texto en una prueba de comprensión lectora, una gráfica en una prueba de Ciencias, una pirámide de edad en una prueba de Geografía, etc.), a la hora de dividir el test en dos mitades no se puede considerar el número total de ítems sino el número total de bloques de ítems, ya que todos los ítems de un mismo bloque tienen que aparecer siempre en la misma mitad del test. Si la prueba está formada por 50 ítems y cinco ítems se refieren siempre al mismo texto, tendremos que formar dos mitades con cinco bloques de cinco ítems cada uno de ellos.

6.2.2.2. *Métodos basados en la covariación de los ítems*

Sea como fuere, la elección de las dos mitades del test siempre tiene algo de arbitrario. Por ello, se dispone también de procedimientos que hacen uso directamente de la información relativa a la consistencia de la actuación de los sujetos en todos y cada uno de los ítems, no en mitades equivalentes de ítems sino en todos los ítems considerados de forma individual. Para ello, es necesario conocer las varianzas de estos ítems o sus covarianzas, esto es, la variación conjunta o concomitante de las respuestas que dan los sujetos a los distintos ítems del test.

En 1951 Cronbach presenta una fórmula comprensiva —el coeficiente α — que recoge estas ideas y representa una síntesis de los distintos métodos disponibles por aquel entonces para estimar la fiabilidad como consistencia interna:

$$\alpha = \frac{n}{n-1} \left(1 - \frac{\sum_{j=1}^n \sigma_j^2}{\sigma_x^2} \right) = \frac{n}{n-1} \left(\frac{\sum_{j=1}^n \sum_{k \neq j}^n \sigma_{jk}}{\sigma_x^2} \right) \quad (6.5)$$

donde:

n es el número de ítems del test;

σ_j^2 es la varianza de las puntuaciones de los sujetos en el ítem j ;

σ_x^2 es la varianza de las puntuaciones de los sujetos en el test;

σ_{jk} es la covarianza entre las puntuaciones de los sujetos en los ítems j y k .

Como ilustra claramente esta fórmula, la fiabilidad depende de la longitud del test — n — y de la proporción de la varianza del test que se debe a la covariación de los ítems $\left(\frac{\sum \sum \sigma_{jk}}{\sigma_x^2} \right)$, de forma que cuanto más largo es el test y mayor la covariación entre los ítems, más alto será el valor estimado para la fiabilidad de la prueba mediante el coeficiente α , mayor será su consistencia interna.

Si los ítems del test son dicotómicos, la ecuación anterior se puede describir del siguiente modo:

$$\alpha = \frac{n}{n-1} \left(1 - \frac{\sum_{j=1}^n p_j q_j}{\sigma_x^2} \right) \quad (6.6)$$

donde:

p_j es la proporción de respuestas correctas observada en el ítem j , también conocida como *índice p de dificultad* del ítem, tal como se verá en el capítulo 8;

q_j es la proporción de respuestas incorrectas observada en el ítem j , definida como $1 - p_j$.

La expresión anterior fue formulada por Kuder y Richardson en 1937 y se conoce como *ecuación KR20*.

Si los ítems además de dicotómicos presentan la misma dificultad ($p_j = p, j = 1, n$), entonces la ecuación anterior todavía se simplifica más:

$$\alpha = \frac{n}{n-1} \left(1 - \frac{npq}{\sigma_x^2} \right) = \frac{n}{n-1} \left(1 - \frac{\mu_x - \frac{\mu_x^2}{n}}{\sigma_x^2} \right) \quad (6.7)$$

donde μ_x es la media de las puntuaciones obtenidas por los sujetos en el test.

La ecuación anterior también se debe a Kuder y Richardson y se conoce como *ecuación KR21*.

Ejemplo 6.2

Estimemos ahora la consistencia interna del test del ejemplo 6.1 utilizando las fórmulas de α y KR20.

Sujetos	X_1	X_1^2	X_2	X_2^2	X_3	X_3^2	X_4	X_4^2	X_5	X_5^2	X_6	X_6^2
1	1	1	1	1	0	0	0	0	1	1	0	0
2	1	1	1	1	1	1	1	1	1	1	0	0
3	1	1	1	1	1	1	0	0	0	0	0	0
4	1	1	0	0	0	0	1	1	0	0	0	0
5	1	1	1	1	0	0	0	0	0	0	0	0
6	1	1	1	1	1	1	1	1	0	0	0	0
7	1	1	0	0	0	0	0	0	0	0	0	0
8	1	1	1	1	0	0	0	0	1	1	0	0
Total	8	8	6	6	3	3	3	3	3	3	0	0
s_i^2	0		0,19		0,23		0,23		0,23		0	
p_i	8/8		6/8		3/8		3/8		3/8		0/8	
q_i	0/8		2/8		5/8		5/8		5/8		8/8	
$p_i q_i$	0		12/64		15/64		15/64		15/64		0	

$$s_1^2 = \frac{\sum_{i=1}^8 X_{1i}^2}{8} - \left(\frac{\sum_{i=1}^8 X_{1i}}{8} \right)^2 = \frac{1+1+1+1+1+1+1+1}{8} - \left(\frac{1+1+1+1+1+1+1+1}{8} \right)^2 = 0$$

$$\alpha = \frac{6}{6-1} \left(1 - \frac{0,19+0,23+0,23+0,23}{1,36} \right) = 0,42$$

$$KR20 = \frac{6}{6-1} \left(1 - \frac{12+15+15+15}{64} \right) = 0,42$$

El coeficiente α es el estadístico más utilizado para estimar la fiabilidad. No requiere más que una única aplicación del test y salvo que, por alguna razón particular se desee conocer la consistencia interna entre dos partes de un test, es mejor utilizar la información procedente de la covariación de todos los ítems del test que la procedente de la covariación de partes del test y calcular el coeficiente α para obtener así un indicador global de la consistencia interna de la prueba. Además, α se puede interpretar como la media que se obtendría en el caso de dividir el test en todas las mitades posibles y calcular el correspondiente coeficiente de fiabilidad en cada par de todas esas mitades posibles. Asimismo, α se suele interpretar como un estimador del límite inferior del coeficiente de fiabilidad:

$$\alpha \leq \rho_{xx} = \frac{\sigma_v^2}{\sigma_x^2} \leq 1$$

que solo será igual a dicho coeficiente cuando los ítems que forman el test sean ítems paralelos, esto es, satisfagan las dos condiciones de paralelismo formuladas anteriormente (véase tabla 6.1). Como ya se indicó al comienzo de la exposición del coeficiente α , éste representa una síntesis del trabajo realizado con anterioridad en la estimación de la fiabilidad.

6.2.3. Factores que influyen en el coeficiente de fiabilidad

Un test no tiene un único coeficiente de fiabilidad que proporcione una estimación única y definitiva de la precisión con que la prueba mide la característica de interés. Por ejemplo, si se opera con el método test-retest para estimar la fiabilidad seguramente se obtendrán coeficientes distintos al variar el intervalo temporal entre las dos aplicaciones del test. Si se trabaja con el método de las formas paralelas y se dispone de tres o más, probablemente la correlación obtenida entre las formas 1 y 2 no sea exactamente la misma que la correlación observada entre la 1 y la 3 o entre la 2 y la 3. Si se utiliza un método basado en la división del test en dos mitades, el coeficiente variará según cómo se formen las dos mitades en la prueba. Por otro lado, a nadie se le escapa que la precisión de una medida obtenida con una prueba formada solo con tres ítems es mucho menor que si ésta consta de 30 preguntas. Cuántos más ítems tenga un test, mayor será también la muestra obtenida del dominio de conductas o de contenido examinado por la prueba y, por tanto, menor

será el error que se cometa al estimar el nivel del sujeto en la característica de interés y más fiable será el test. Esto es, la longitud de la prueba también es un factor que afecta a su fiabilidad. Por último, el coeficiente de fiabilidad se define como un cociente de varianzas (véase ecuación 6.1). Por tanto, si se calcula la fiabilidad de la prueba en un grupo de sujetos más homogéneo (o más heterogéneo) de lo que era la composición original del grupo, entonces el coeficiente de fiabilidad disminuirá (o aumentará), ya que la varianza de las puntuaciones verdaderas disminuirá (o se incrementará) al modificarse la variabilidad del grupo en cuestión.

6.2.3.1. Longitud del test

La relación entre la fiabilidad y la longitud del test fue formalizada matemáticamente en 1910 de forma simultánea e independiente por Spearman y Brown y se conoce como *ecuación de Spearman-Brown*. Esta ecuación permite determinar la fiabilidad de un nuevo test Y construido a partir de otro test X con fiabilidad conocida:

$$\rho_{yy} = \frac{k\rho_{xx}}{1 + (k-1)\rho_{xx}} \quad (6.8)$$

donde:

ρ_{yy} es el coeficiente de fiabilidad del nuevo test Y;

ρ_{xx} es el coeficiente de fiabilidad del test original X;

k es el número de veces en que se ha modificado la longitud del test inicial:

$$k = \frac{n_y}{n_x} \quad (6.9)$$

donde n_y y n_x son el número de ítems del test final e inicial, respectivamente.

Si $k > 1$, entonces se incrementará la longitud del test ($n_y > n_x$), que es lo más habitual. Si $k < 1$, entonces se reducirá la longitud del test ($n_y < n_x$).

La fórmula anterior solo es posible aplicarla si los ítems que se añaden (o se eliminan) son paralelos en contenido y dificultad a los ítems del

test inicial, eso sí, evitando expresamente la duplicación semántica de ítems (preguntar exactamente lo mismo de dos formas distintas): los ítems que se añaden han de proporcionar nueva información, información útil y distinta, si bien su dificultad y contenido deben ser semejantes a la de los ítems de la prueba original.

Observe el lector que si $k = 2$ la fórmula anterior se simplifica del siguiente modo:

$$\rho_{yy} = \frac{2\rho_{xx}}{1 + \rho_{xx}}$$

que coincide con la fórmula propuesta para estimar el coeficiente de fiabilidad cuando se divide el test en dos mitades paralelas (véase tabla 6.2). En efecto, en este caso ρ_{12} sería el coeficiente de fiabilidad del test inicial, que sería una de las mitades del test en cuestión. En suma, la estimación de la fiabilidad de un test mediante la división del test en dos mitades paralelas es un caso particular de la ecuación general formulada por Spearman y Brown para la relación entre la longitud y la fiabilidad de la prueba.

La figura 6.3 ilustra gráficamente la relación entre la fiabilidad y la longitud de un test para distintos valores de la fiabilidad del test inicial.

Como se observa claramente en el gráfico, las curvas tienen un crecimiento asintótico lo que significa, por un lado, que la ganancia en fiabilidad no es directamente proporcional al número de elementos añadidos (ρ_{yy} se modifica en mayor medida para valores pequeños de k




FIGURA 6.3. Relación entre la fiabilidad y la longitud de un test.

que para valores grandes) y, por otro, si se parte de un test inicial con un coeficiente de fiabilidad razonablemente alto, el valor de ρ_{yy} se aproxima a la unidad, es decir, con infinitos ítems el error sería cero y, como certeramente señala Muñiz (1998), el sujeto también sería cero, habría fenecido de una sobredosis de ítems. Además, en muchos casos los pequeños incrementos que se observan en el coeficiente de fiabilidad no justifican en absoluto el incremento que esto representa tanto en el tiempo de administración como en el costo asociado a la construcción de nuevos ítems. Tiene sentido mejorar la fiabilidad de un test incrementando su longitud cuando el test tiene ya una fiabilidad razonable con no muchos ítems, pero si el test tiene una longitud considerable y su coeficiente de fiabilidad es bajo, mas que pensar en cambiar su longitud conviene pensar en cambiar de ítems, en construir otro test (Muñiz, 1998).

6.2.3.2. Variabilidad de la muestra de sujetos

Al examinar el método de estimación de la puntuación verdadera basado en la distribución normal de los errores (véase el apartado 5.3.3), se puso de manifiesto que el error típico de medida σ_e es homocedástico, esto es, que su valor es idéntico para todas las posibles puntuaciones verdaderas. Pues bien, supongamos ahora que se aplica una prueba que mide el rendimiento en Matemáticas a una muestra de alumnos de ESO, observando una variabilidad en sus puntuaciones en la prueba de $S_{ESO} = 5$ y un valor estimado para la fiabilidad de la misma de $r_{xx_{ESO}} = 0,85$. Si se aplica de nuevo esa prueba a una muestra de alumnos de 3.º de ESO se observa ahora una menor variabilidad en las puntuaciones ($S_{3.ºESO} = 3,87$). ¿Cuál sería en este caso la fiabilidad de la prueba?

Según el principio de homocedasticidad del error típico de medida, $S_{e_{ESO}} = S_{e_{3.ºESO}}$. Sustituyendo ambos por su valor tenemos que:

$$S_{ESO} \sqrt{1 - r_{xx_{ESO}}} = S_{3.ºESO} \sqrt{1 - r_{xx_{3.ºESO}}}$$

$$r_{xx_{3.ºESO}} = 1 - \frac{S_{ESO}^2}{S_{3.ºESO}^2} (1 - r_{xx_{ESO}}) = 1 - \frac{5^2}{3,87^2} (1 - 0,85) = 0,75$$

Se ha pasado, por tanto, de un valor de 0,85 a uno de 0,75 en la muestra de alumnos de tercer curso.

De modo general se puede escribir que:

$$\rho_{22} = 1 - \frac{\sigma_1^2}{\sigma_2^2}(1 - \rho_{11}) \quad (6.10)$$

donde:

σ_1^2 y σ_2^2 son las varianzas de las puntuaciones empíricas obtenidas en las muestras 1 y 2;

ρ_{11} y ρ_{22} son el coeficiente de fiabilidad de la prueba obtenido en las muestras 1 y 2.

Cuando se reduce la variabilidad de las puntuaciones empíricas en una muestra, se produce obviamente una restricción del rango de variación de las puntuaciones en el test y, como acabamos de comprobar, el coeficiente de fiabilidad disminuye y, a la inversa, si se incrementa la variabilidad de las puntuaciones también se incrementará el coeficiente de fiabilidad de la prueba. Así las cosas, para un usuario de un test resulta fundamental saber cuál era la variabilidad de las puntuaciones empíricas en la muestra que se utilizó en el manual del test y ver si la muestra de sujetos a la que se va a administrar ahora la prueba es similar a la anterior en cuanto a su composición y variabilidad, para así poder determinar la adecuación de esa estimación de la fiabilidad a la situación en la que se administra ahora la prueba. Como señala Meliá (2000), al igual que debe evitarse incrementar la fiabilidad de la prueba clonando ítems a partir de los existentes en la prueba inicial, no se puede tratar de mejorar la fiabilidad de la prueba incrementando de forma artificial la heterogeneidad de la muestra de sujetos (por ejemplo introduciendo de manera intencionada sujetos pertenecientes a grupos extremos en la variable medida por el test) ya que la muestra a la que se aplica la prueba debe ser siempre una muestra adecuada para la misma. Resulta bastante claro que no se puede evaluar el rendimiento en Lengua de niños de 2.º curso de enseñanza primaria con una prueba construida para alumnos del último curso de ese ciclo educativo. En este caso también se produciría una restricción del rango en las puntuaciones de la prueba (demasiado difícil para ese colectivo) y el coeficiente de fiabilidad descendería.

Por último, solo restaría por señalar la dificultad que plantea esta relación de dependencia entre la fiabilidad —estimada según el enfoque clásico— y la variabilidad de la muestra cuando se realiza una interpretación criterial de las puntuaciones del test, definiendo un punto de corte que sirve para adscribir a una categoría a los sujetos que han obtenido una puntuación más alta que dicha puntuación y a otra categoría distinta a los que han obtenido una puntuación más baja que el punto de corte.

En este caso, la variabilidad de las puntuaciones empíricas y verdaderas es bastante poco relevante y la única variabilidad que de verdad importa es la que se observa en la zona próxima al punto de corte definido. Cuando se realiza una interpretación normativa, las puntuaciones en el test suelen ser muy variables ya que la prueba normalmente evalúa un sector amplio de la población diana. Sin embargo, cuando la interpretación es criterial la situación es la inversa, por lo que el coeficiente de fiabilidad clásico, debido a la restricción del rango de variación, resultará muy poco informativo. En el apartado 6.5 se analizará con algo de detalle esta importante cuestión.

6.2.4. Crítica a la teoría clásica de los tests

Como acabamos de ilustrar, la fiabilidad del test depende de factores ajenos al test (la variabilidad de la muestra de sujetos a la que éste se aplica, el intervalo temporal transcurrido entre las dos administraciones de la prueba, la forma en la que se divide el test en dos mitades, etc.). Si esto es así, podemos preguntarnos con Meliá (2000), ¿cómo puede sostenerse que se trata de la fiabilidad del *test*? Como mucho, podríamos decir que la fiabilidad en este enfoque teórico es una propiedad de las *puntuaciones del test* en una muestra determinada de sujetos, ya que la fiabilidad del test depende de las características de la muestra a la que se aplicó y, a su vez, la estimación del nivel en que poseen los sujetos el rasgo o constructo que mide la prueba depende asimismo de las características del test (es función de X y de r_{xx}). Dicho de otro modo, las características del instrumento de medida dependen de los sujetos medidos y las medidas de los sujetos del instrumento de medida. Sería algo así como admitir que la longitud de una recta depende de la regla utilizada para medirla.

Aquí radica quizá la dificultad o limitación más seria de la TCT: el carácter dependiente de los parámetros del modelo (tanto del instrumento de medida como de los sujetos medidos). Como señalan Muñiz y Hambleton (1992), «si se aspira a una medición rigurosa y científica, resulta difícil justificar que las mediciones están en función del instrumento utilizado» (p. 44). La Teoría de Respuesta al Ítem (TRI) se caracteriza justamente por la invarianza de los parámetros del test de las características de la muestra de sujetos utilizada en su estimación y por la invarianza de los parámetros de los sujetos de las características del test utilizado en su estimación. Se expondrá a continuación cuál es la perspectiva que adopta esta teoría a la hora de estimar la precisión con la que las puntuaciones de un test miden el nivel en que los sujetos poseen la característica o atributo evaluada por la prueba en cuestión.

6.3. CONCEPCIÓN DE LA TEORÍA DE RESPUESTA AL ÍTEM: FIABILIDAD COMO INFORMACIÓN

La alternativa que ha planteado la TRI a la fiabilidad definida según el modelo clásico es la fiabilidad como información. La información es un índice de precisión que refleja, *en cada nivel del constructo o característica que se está evaluando*, la información que proporciona el test sobre el mismo. En el capítulo anterior se introdujo el concepto de función de información del test (véase ecuación 5.19) al plantear la cuestión relativa a cómo se estima el error de medida en esta teoría de los tests:

$$I(\theta) = \frac{1}{\sigma_e^2} = \sum_{i=1}^n \frac{(P'(u_i = 1/\theta))^2}{P(u_i = 1/\theta)P(u_i = 0/\theta)}$$

Se denomina *función de información del test* a la función que indica, para cada punto de la escala en la que se mide la característica de interés, cuál es la información que sobre esa característica proporciona en ese punto un estimador de la misma¹. La representación gráfica de esta función recibe el nombre de *curva de información del test*. Examinemos ahora con algún detenimiento la fórmula anterior.

El numerador del cociente que aparece en la función de información del test es la pendiente de la curva característica del ítem i y, por consiguiente, está directamente relacionado con el parámetro de discriminación a (véase el apartado 5.4.1.2), de modo que, según la ecuación anterior, cuanto mayor sea el poder discriminativo del ítem, cuanto mayor sea la pendiente de la curva característica del ítem en un punto dado θ de la escala de habilidad, mayor será la información que se suministre sobre el rasgo latente en ese punto de la escala. En efecto, cuando se aplica un test a un grupo de sujetos, lo que se pretende habitualmente es medir el nivel de éstos en el rasgo o característica que evalúa la prueba. Diremos que el test cumple adecuadamente su propósito si sujetos que tienen niveles efectivamente distintos en la característica latente obtienen puntuaciones distintas en el test, tienen probabilidades diferentes de responder correctamente a los ítems que componen el test. Es decir: un test es una medida apropiada del rasgo latente que se supone evalúa si discrimina entre sujetos que poseen en distinto grado la característica evaluada. Por tanto, un test proporciona tanta más información sobre el rasgo latente que evalúa cuanto más discrimina entre sujetos con distinto nivel en el rasgo latente, cuanto más pronunciada sea la pendiente de la curva característica.

¹ La fórmula anterior asume que se está utilizando la estimación máximo-verosímil para determinar el valor $\hat{\theta}$.

El denominador de la expresión anterior es el producto de las probabilidades de ocurrencia de una respuesta correcta e incorrecta al ítem i , dado un nivel determinado en el rasgo latente. Al tratarse de un ítem dicotómico, con sólo dos valores posibles de respuesta —correcta e incorrecta—, ese producto es la varianza de las puntuaciones en el ítem de los sujetos con un valor θ dado en la característica evaluada, esto es, representa la variabilidad de las puntuaciones en el ítem de los sujetos que tienen el mismo nivel θ en el constructo examinado, es decir, la varianza error del ítem en el nivel considerado del rasgo latente.

Cuanto mayores sean las fluctuaciones de las respuestas a dicho ítem de los sujetos con idéntico valor θ , menor será la información que sobre la característica evaluada contenga el estimador en el punto examinado de la escala. Diremos que el ítem (o el test) funciona apropiadamente cuando los sujetos que tienen un nivel θ dado en la característica evaluada responden de la misma forma al ítem (o al test), esto es, cuando la varianza error del ítem para ese valor θ es pequeña. Pasando al plano del test, se puede decir que un test es una medida precisa del rasgo latente que se supone evalúa cuando da lugar a estimaciones estables o consistentes del rasgo latente que mide, cuando es pequeña la variabilidad observada en los valores estimados del rasgo latente para sujetos que tienen un mismo nivel en la característica bajo estudio. Por tanto, la información puede ser interpretada como un índice de precisión de la medida y, por consiguiente, puede ser considerada como una medida de la fiabilidad de la prueba.

En suma, de acuerdo con la formulación anterior, la TRI plantea que un test es fiable si proporciona información sobre la característica que mide, es decir, si:

1. Discrimina entre sujetos con distinto nivel θ en dicha característica (numerador de la expresión anterior).
2. La varianza error de los ítems del test para ese valor θ es pequeña (denominador de la expresión anterior).

Si se observa de nuevo la formulación de la función de información del test se ve fácilmente que ésta viene definida como la suma de n cocientes, cada uno de los cuales expresa a su vez una función de información, la *función de información del ítem*. Por tanto, podemos definir la función de información del test como la suma de las funciones de información de cada uno de los ítems que lo integran ($I(\theta, u_i)$):

$$I(\theta) = \sum_{i=1}^n I(\theta, u_i) = \sum_{i=1}^n \frac{(P'(u_i = 1/\theta))^2}{P(u_i = 1/\theta)P(u_i = 0/\theta)}$$

La definición de la función de información del test como la suma de las funciones de información de los ítems que forman parte del test permite que se pueda determinar la contribución individual de un ítem concreto al total de información del test y esta característica tiene una importancia fundamental en la construcción de tests.

La consideración de la fiabilidad del test en términos de la información que éste suministra representa un planteamiento novedoso que supone como ventaja básica el hecho de que la información es dependiente del punto concreto θ que se considera en la escala de habilidad, es decir, la información varía a lo largo de la escala θ . Esto significa que el error que se comete al estimar el nivel de un sujeto en la característica de interés no es igual en todos los puntos de la escala: el error de estimación varía a lo largo del continuo de la habilidad latente. Esta consideración hace que resulte obsoleto el planteamiento clásico de la fiabilidad del test como un valor único que caracteriza un instrumento de medida (planteamiento falaz, como se vio en el apartado 6.2.3). Un mismo test puede ser muy fiable para evaluar a sujetos que poseen en alto grado la característica latente de interés —si el nivel de información en ese rango de habilidad es alto—, pero muy poco preciso en la evaluación de sujetos con un nivel bajo en dicho rasgo —si el nivel de información en ese rango de habilidad es bajo—. Por tanto, la cuestión pertinente no es si un test es fiable en general sino si es fiable para el objetivo que ha suscitado su aplicación.

6.4. FIABILIDAD INTERJUECES

Al principio del capítulo se ha caracterizado la fiabilidad como un criterio métrico de la calidad global de un test que proporciona información acerca de la cantidad de error aleatorio que contiene una medida obtenida al aplicar dicha prueba a un sujeto o a un grupo de sujetos. Supongamos que la prueba está formada exclusivamente por ítems de construcción —en el caso de tratarse de una prueba cognitiva— o por ítems de respuesta abierta —en el caso de tratarse de una prueba no cognitiva—. En cualquiera de los casos es preciso recurrir a jueces, calificadores o codificadores que transformen la respuesta que ha dado el sujeto en un número, en un código numérico —en el caso de una prueba cognitiva— o en una categoría de respuesta a la que se asignará un determinado código —en el caso de una prueba no cognitiva—. Se remite al lector al apartado 4.2.1 para refrescar estas cuestiones. Supongamos que se trabaja con una prueba cognitiva y que en este proceso de asignación de puntuaciones intervienen cuatro jueces; dos de ellos aplican con todo rigor los criterios previamente establecidos para la corrección de las preguntas, otro

lo hace con una severidad inusitada (asigna casi siempre puntuaciones más bajas que sus colegas) y el restante lo hace con una gran indulgencia (asigna casi siempre puntuaciones más altas que los demás). Así las cosas, la puntuación final que obtendrá un sujeto en la prueba puede variar tanto en un sentido ($\uparrow$) como en otro ($\downarrow$), según quién sea el juez encargado de examinar sus respuestas a los ítems de la prueba. Dicho de otro modo, la puntuación obtenida por el sujeto en la prueba no solo dependerá de su nivel real en la característica evaluada sino también de la persona encargada de puntuar sus respuestas a los ítems del test. Por tanto, a la hora de emitir un juicio acerca de la fiabilidad de esa prueba para medir el área de conocimiento o la aptitud prevista es imprescindible determinar hasta qué punto la actuación de los jueces implicados en el proceso está influyendo en la precisión de las estimaciones de la característica de interés, hay que garantizar que todos los jueces califican o categorizan (razonablemente) de la misma forma, es decir, antes de estimar la fiabilidad de la prueba es preciso estimar previamente la fiabilidad de los jueces, la *fiabilidad interjueces*.

6.4.1. Estimación de la fiabilidad interjueces

Dada la falibilidad del juicio humano, lo ideal es contar con varios jueces que califiquen o categoricen las respuestas de todos los sujetos. Ahora bien, dadas las también inevitables limitaciones de tiempo y de presupuesto, en ocasiones solo es posible contar con un único juez o calificador. Sea como fuere, de lo que se trata siempre es de garantizar que ningún sujeto se verá perjudicado porque su trabajo haya sido asignado a un juez u otro. ¿Cómo garantizar esto?

Para empezar, es necesario proporcionar un entrenamiento adecuado a los jueces, que deben practicar con material similar al de la prueba en cuestión o incluso con una muestra de las respuestas dadas por los sujetos a algunos de sus ítems. Es conveniente que el investigador revise con los jueces su trabajo para asegurarse de que han comprendido perfectamente los criterios que deben utilizar en la corrección/codificación. Seguidamente hay que pasar a comprobar la fiabilidad interjueces.

Según Martínez Arias (1995), la mejor aproximación posible al estudio de la fiabilidad interjueces está representada por la teoría de la generalizabilidad, ya que esta teoría de tests introduce directamente en el modelo básico que explica la actuación del sujeto en la prueba una variable relacionada con el juez encargado de la asignación de puntuaciones a las respuestas de los sujetos a los ítems ($X = V + J + E$) y estima el efecto que esta variable tiene en X . Sin embargo, lo que se suele hacer habitualmente para estimar la fiabilidad interjueces es obtener una medida del acuerdo

existente entre las puntuaciones (o códigos) asignadas por los distintos jueces a las respuestas de los sujetos a cada ítem de la prueba en cuestión.

Dos jueces estarán obviamente de acuerdo si asignan la misma puntuación a la respuesta dada a un ítem por un sujeto determinado. Piense ahora el lector cuál sería el porcentaje de acuerdos que habría si el ítem solo tuviera dos opciones posibles de puntuación y se contara con dos jueces. En este caso, dos jueces que calificaran o categorizaran a ciegas podrían estar de acuerdo en la mitad de las ocasiones. En efecto, solo hay cuatro resultados posibles en esta situación:

1. Ambos jueces optan por la categoría A (acuerdo).
2. Ambos jueces optan por la categoría B (acuerdo).
3. El primer juez opta por la categoría A y el segundo por la B (desacuerdo).
4. El primer juez opta por la categoría B y el segundo por la A (desacuerdo).

Por tanto, la proporción o probabilidad de acuerdo será igual al número de acuerdos (2) dividido por el número de resultados posibles (4): 0,5. Formalmente podemos definir la probabilidad de acuerdos fortuitos o aleatorios entre los jueces del siguiente modo:

$$P_{aa} = \frac{C}{C^J} \quad (6.11)$$

donde:

C es el número de categorías o puntuaciones posibles que se pueden asignar a las respuestas de un ítem y representaría el número máximo posible de acuerdos;

J es el número de jueces implicados en el proceso de asignación de puntuaciones.

La tabla 6.3 recoge la probabilidad de aciertos aleatorios para distintas combinaciones de números de categorías y de jueces.

Como se puede observar claramente en dicha tabla, la probabilidad de encontrar acuerdos fortuitos se reduce drásticamente conforme aumenta el número de jueces que participan en el proceso y cuantos más puntos tiene la escala de puntuación, de modo que con tres categorías y cuatro/cinco jueces nos aproximamos a los habituales niveles de confianza (95 por 100 y 99 por 100). En cualquiera de estos dos casos, si se obtiene empíricamente una alta proporción de acuerdos se puede estar bastante

TABLA 6.3
 Probabilidad de acuerdos fortuitos según el número de categorías
 de respuesta de la escala y el número de jueces que participan
 en el proceso de asignación de puntuaciones

Número de categorías	Número de jueces			
	2	3	4	5
2	$2/4 = 0,5$	$2/8 = 0,25$	$2/16 = 0,12$	$2/32 = 0,06$
3	$3/9 = 0,33$	$3/27 = 0,11$	$3/81 = 0,04$	$3/243 = 0,01$
4	$4/16 = 0,25$	$4/64 = 0,06$	$4/256 = 0,02$	$4/1024 = 0,00$
5	$5/25 = 0,20$	$5/125 = 0,04$	$5/625 = 0,01$	$5/3125 = 0,00$

seguro de que esos acuerdos no son fortuitos (ya que su probabilidad es solo del orden de 0,04 o 0,01).

Hasta el momento se ha decidido el número de jueces que van a participar en un proceso de asignación de puntuaciones, tratando de mantener en el nivel más bajo posible la probabilidad de ocurrencia de acuerdos fortuitos, dado el número de categorías o puntos posibles en la escala de puntuación del ítem, y las limitaciones temporales y presupuestarias del estudio. Seguidamente se ha procedido al entrenamiento de los jueces. Lo que falta ahora es decidir qué grado de acuerdo debe mostrar un juez con el resto de los jueces para que sea aceptado en el proceso efectivo de asignación de puntuaciones a los sujetos de la muestra y proceder entonces a determinar el acuerdo entre cada posible par de jueces. Si el nivel mínimo fijado para la fiabilidad interjueces es 0,70, habrá que identificar a los jueces cuyo índice de acuerdo con todos los demás no alcance ese valor. Se puede optar por sustituir a ese juez o por continuar su entrenamiento y estimar de nuevo la fiabilidad para ver si esta vez alcanza —o no— el nivel mínimo fijado para que pueda actuar como tal en el proceso definitivo de asignación de puntuaciones. Esta forma de proceder garantiza que se trabaje con datos o puntuaciones razonablemente protegidas del acuerdo fortuito (Meltzoff, 2000). De este modo, una vez que se ha garantizado que existe una adecuada fiabilidad interjueces se puede proceder a estimar la fiabilidad de la prueba con cualquiera de los procedimientos descritos en los dos apartados anteriores. La figura 6.4 recoge esquemáticamente todo el proceso que conduce a la estimación de la fiabilidad de una prueba con ítems de construcción o de respuesta abierta.




FIGURA 6.4. Estimación de la fiabilidad de una prueba formada por ítems de construcción o de respuesta abierta.

6.4.2. Acuerdo entre jueces

La única cuestión que queda por dilucidar es cómo se determina realmente el grado de acuerdo existente entre las valoraciones que han hecho los jueces de las respuestas de los sujetos a cada ítem de la prueba en cuestión. Uno de los estadísticos más utilizados para estimar el acuerdo entre dos jueces es el coeficiente κ de Cohen (1960), para cuyo cálculo conviene disponer las valoraciones dadas por los dos jueces en una tabla de contingencia como la tabla 6.4.

El coeficiente κ se define del siguiente modo:

$$\kappa = \frac{F_0 - F_e}{N - F_e} \tag{6.12}$$

TABLA 6.4
Tabla de contingencia para el cálculo del coeficiente κ

		JUEZ 2		
		A	B	
JUEZ 1	A	N_{AA}	N_{AB}	N_{1A}
	B	N_{BA}	N_{BB}	N_{1B}
		N_{2A}	N_{2B}	N

donde:

F_0 es el número o frecuencia de acuerdos observados entre los dos jueces, que será igual a:

$$F_0 = N_{AA} + N_{BB}$$

F_e es el número o frecuencia esperada de acuerdos fortuitos entre los dos jueces, que será igual a:

$$F_e = \frac{N_{1A}N_{2A}}{N} + \frac{N_{1B}N_{2B}}{N}$$

κ es un indicador del grado de acuerdo que existe entre dos jueces más allá del esperable por azar, esto es, κ proporciona una medida del acuerdo una vez corregidos los posibles acuerdos fortuitos que pudieran existir en las valoraciones dadas por dos jueces independientes. El rango de variación de κ oscila entre $-F_e/(N-F_e)$, que denotaría que no existe el más mínimo acuerdo entre los jueces, ni siquiera acuerdos fortuitos ($F_0 = 0$) y 1, que supondría que los dos jueces han asignado exactamente la misma puntuación a todos los sujetos examinados. Los valores próximos a 0 indicarán que el acuerdo real es inexistente ya que, en ese caso, $F_0 = F_e$, esto es, todos los acuerdos observados (F_0) son debidos al azar (F_e), son fortuitos.

En la tabla 6.5 se proporcionan las puntuaciones asignadas por los cuatro jueces del ejemplo anterior a las respuestas de 25 sujetos en uno de los ítems de la prueba.

Para estimar el valor de κ para los jueces 1 y 2 habrá que construir una tabla de contingencia como la tabla 6.4:

		JUEZ 2		
		0	1	
JUEZ 1	0	6	2	8
	1	1	16	17
		7	18	25

Por consiguiente,

$$F_0 = 6 + 16 = 22$$

$$F_e = 7 \times 8/25 + 18 \times 17/25 = 14,48$$

$$\kappa = \frac{22 - 14,48}{25 - 14,48} = 0,71$$

TABLA 6.5
 Valoraciones dadas por cuatro jueces a las respuestas de 25 sujetos
 a un ítem de un test

Sujetos	Juez 1	Juez 2	Juez 3	Juez 4
1	1	1	0	1
2	1	1	1	1
3	0	0	0	1
4	1	1	0	1
5	1	1	1	1
6	1	1	0	1
7	1	1	0	1
8	1	1	0	1
9	1	1	0	1
10	0	1	0	0
11	1	1	1	1
12	1	1	0	1
13	0	0	0	0
14	0	0	0	1
15	0	1	0	1
16	1	1	0	1
17	1	1	1	1
18	1	1	1	1
19	0	0	0	0
20	0	0	0	1
21	0	0	0	1
22	1	1	0	1
23	1	1	1	1
24	1	0	0	1
25	1	1	0	1

A la vista del valor obtenido, si el nivel mínimo fijado para la fiabilidad interjueces es 0,70, estos dos jueces en principio serían aceptables, muestran una fiabilidad adecuada, son consistentes en su actuación, califican razonablemente del mismo modo. Ahora bien, para poder tomar una decisión, es preciso examinar el acuerdo entre todos los posibles pares de jueces implicados en el proceso, que serían $J(J - 1)/2 = 4 \times 3/2 = 6$ pares en este caso. Por tanto, todavía faltan por calcular cinco valores κ . En la tabla 6.6 se encuentran todos los términos necesarios para estimar el valor del coeficiente κ al comparar a todos los posibles pares de jueces del ejemplo, incluyéndose también el valor de κ para cada par de jueces.

Para tomar una decisión acerca de la fiabilidad de los jueces implicados en el proceso, podemos disponer la información relativa a los valores estimados para κ en las comparaciones anteriores en una matriz como la de la tabla 6.7.

TABLA 6.6
Cálculo de κ en una muestra de cuatro jueces

Par de jueces	N_{AA}	N_{BB}	N_{1A}	N_{2A}	N_{1B}	N_{2B}	κ
(1,2)	6	16	8	7	17	18	0,72
(1,3)	8	6	8	19	17	6	0,26
(1,4)	3	17	8	3	17	22	0,45
(2,3)	7	6	7	19	18	6	0,22
(2,4)	2	17	7	3	18	22	0,28
(3,4)	3	6	19	3	6	22	0,08

TABLA 6.7
Matriz con los valores de κ en una muestra de cuatro jueces

	Juez 1	Juez 2	Juez 3	Juez 4
Juez 1		0,72	0,26	0,45
Juez 2	0,72		0,22	0,28
Juez 3	0,26	0,22		0,08
Juez 4	0,45	0,28	0,08	
$\bar{\kappa}$	0,48	0,41	0,19	0,27

A la vista de la información contenida en esta tabla se ve que la actuación de los jueces 1 y 2 es considerablemente mejor, más consistente que la actuación de los jueces 3 y 4: la media de los valores estimados para κ para los dos primeros jueces es sensiblemente más alta que para los dos últimos y, además, el valor de κ para el par formado por los dos primeros jueces es 0,72, estando el resto de los valores de la matriz muy alejados de esta cota². Por tanto, a la vista de los resultados obtenidos y dado que el nivel mínimo de acuerdo fijado para la fiabilidad interjueces era 0,70 se recomienda aceptar a los jueces 1 y 2 para la asignación definitiva de puntuaciones a los ítems de la prueba y se sugiere continuar con el entrenamiento de los jueces 3 y 4 para ver si pueden llegar a esa cota o finalmente deben ser sustituidos en el proceso final de asignación de puntuaciones.

6.5. FIABILIDAD COMO CONSISTENCIA EN LAS CLASIFICACIONES OBTENIDAS A PARTIR DEL TEST

6.5.1. Problemática específica en la interpretación criterial

Cuando se realiza una interpretación criterial de las puntuaciones del test, la comparación de los sujetos entre sí carece de importancia y lo que es fundamental es comparar la actuación del sujeto en el test con un criterio definido *a priori* para áreas o dominios conductuales o de contenido bien especificados; esta comparación nos va a permitir describir la actuación del sujeto en términos de lo que éste sabe o no hacer (con total independencia de lo que saben o no saben hacer los sujetos de su grupo de referencia) o nos va a permitir situar al sujeto en una categoría u otra, al margen de dónde se ubiquen sus iguales (véase el apartado 4.3.2). Puesto que la única actuación en la que estamos interesados es la de un sujeto en particular, sea cual sea la actuación de los sujetos de su grupo de referencia, la estimación de la fiabilidad de la prueba que proporciona la teoría clásica de los tests —en términos del cociente entre la varianza de las puntuaciones verdaderas y empíricas de los sujetos de la muestra a la que pertenece el sujeto en cuestión— tendrá bastante poco sentido. Piense simplemente el lector en el siguiente hecho. Supongamos que el sujeto anterior es examinado con la misma prueba en un segundo momento con un grupo diferente de sujetos y supongamos también que

² Observe el lector que otra posibilidad es que las preguntas cuyas respuestas están valorando los jueces sean lo suficientemente ambiguas como para que no sea posible observar acuerdo alguno entre los jueces. En este caso, lo que hay que eliminar no son los jueces sino la pregunta en cuestión.

responde exactamente igual a todos los ítems de la prueba. En este caso, si se estima el coeficiente de fiabilidad se obtendrán dos valores distintos (al tratarse de sujetos diferentes las puntuaciones empíricas y verdaderas serán distintas en las dos ocasiones y, por tanto, también su variabilidad), que proporcionan muy poca información acerca de la fiabilidad que tiene la medida obtenida para ese sujeto con la prueba para caracterizar su actuación en un dominio bien especificado de contenidos o para adscribirlo a una determinada categoría. ¿Cómo proceder entonces?

En el primer caso, cuando las puntuaciones son interpretadas en relación al dominio especificado para el test, la fiabilidad hay que entenderla en términos de la generalizabilidad de la muestra de contenido en el test respecto al universo o dominio del que han sido extraídos los ítems. Solo así se podrá tener una seguridad razonable de que se ha caracterizado adecuadamente la actuación del sujeto en términos de lo que realmente sabe o no hacer, conoce o no conoce, etc. del dominio en cuestión. En este caso, la fiabilidad se operativiza en forma de un coeficiente de generalizabilidad, denominado en este contexto *coeficiente de dependibilidad* (Martínez Arias, 1995).

MC Fiabilidad como generalizabilidad

En el segundo caso, cuando el criterio se define como una puntuación de corte con la que se compara la puntuación obtenida por el sujeto, con el fin de adscribirlo a una u otra categoría (según que esta última sea mayor o menor que la primera), la fiabilidad hay que entenderla en términos de la consistencia de las clasificaciones realizadas con el test. Es decir, se trata de poder garantizar que las puntuaciones obtenidas por un sujeto en el test le clasificarán siempre en la misma categoría. El resto del apartado se dedica exclusivamente a la situación planteada por este segundo tipo de interpretación, que define el criterio en términos de un punto de corte y no de un dominio conductual o de contenidos bien especificado.

6.5.2. Precisión en el punto de corte

Antes de abordar la cuestión de cómo estimar la consistencia de las clasificaciones realizadas con el test, es preciso señalar un aspecto de

gran interés: la importancia o el impacto que puede tener el error de medida en este caso es muy distinto si se trata de un punto próximo en la escala al punto de corte que si se trata de un punto bastante alejado del mismo. Supongamos la siguiente situación. En una prueba cognitiva de 50 ítems en la que se utiliza la puntuación por número de aciertos se establece como punto de corte el valor $X_c = 35$. Sean $X_1 = 10$ y $X_2 = 36$ las puntuaciones empíricas obtenidas en dicha prueba por los sujetos 1 y 2 y sean $E_1 = -5$ y $E_2 = 2$ los errores de medida que afectan a dichos sujetos, por lo que sus puntuaciones verdaderas serían $V_1 = 15$ y $V_2 = 34$, respectivamente. El sujeto 1 será asignado a una categoría ($X_1 < X_c$) y el 2 a la otra ($X_2 > X_c$). ¿Cuál de los dos errores de medida tendrá una mayor repercusión en la estimación de la fiabilidad? ¿El del sujeto 1 o el del 2? La respuesta es el del sujeto 2, a pesar de que es mayor el error de medida cometido con el sujeto 1 ($E = |5|$) que con el 2 ($E = |2|$). La razón es que, aun en el caso de que el error de medida actuara a favor del sujeto 1, su puntuación empírica seguiría estando por debajo del punto de corte, al estar bastante alejada de él ($(15+5) < X_c$) por lo que se seguiría clasificando en la misma categoría. Sin embargo, las cosas serían distintas para el sujeto 2 si el error de medida actuara ahora en dirección contraria; en este caso, su puntuación empírica pasaría de ser 36 a $34-2 = 32$ y su clasificación variaría, sería adscrito a la otra categoría (por cierto, sería una clasificación más consonante con su nivel real en la característica o área examinada, ya que $V_2 < X_c$).

Por consiguiente, resulta extremadamente importante medir con la mayor precisión posible en la zona próxima al punto de corte. ¿Cómo se puede hacer eso? La teoría de respuesta al ítem pone a nuestra disposición una herramienta de gran ayuda, la función de información que, como acabamos de ver, sirve para estimar la fiabilidad de un ítem o test. Esta función indica la cantidad de información que suministra un ítem o test en cada punto de la escala. Por tanto, si se utiliza esta teoría de los tests sería posible construir, por ejemplo, una prueba que proporcionara la mayor cantidad posible de información en la zona de la escala en la que se encuentra el punto de corte definido (X_c), sin más que seleccionar los ítems para los que su curva de información alcanza un máximo en un punto próximo a X_c ($\text{máx.} I(\theta_c, u_i)$, $i = 1, n$). En cualquier caso, la teoría de respuesta al ítem —a diferencia de la teoría clásica de los tests— permite al menos estimar la precisión en el punto de corte y no considera que el nivel de los sujetos en la característica de interés se estima con la misma precisión en cualquier punto de la escala, ya esté éste próximo o alejado del punto de corte, como hace el enfoque clásico.

6.5.3. Consistencia de las clasificaciones

Diremos que una prueba es fiable o precisa si clasifica a los sujetos en la misma categoría cuando dicha prueba se aplica en distintas ocasiones a los mismos sujetos. Para estimar la consistencia de las clasificaciones se puede calcular el valor del coeficiente κ (ecuación 6.12), que proporcionaría en este caso una medida del acuerdo en las clasificaciones y no del acuerdo entre los jueces, como sucedía al examinar la fiabilidad inter-jueces. La tabla 6.4 se puede describir ahora del siguiente modo:

		OCASIÓN 2		
		A	B	
OCASIÓN 1	A	N_{AA}	N_{AB}	N_{1A}
	B	N_{BA}	N_{BB}	N_{1B}
		N_{2A}	N_{2B}	N

donde:

N_{AA} es el número de sujetos que son clasificados por el test en la categoría A en las dos ocasiones;

N_{AB} es el número de sujetos que son clasificados por el test en la categoría A en la primera ocasión y en la B en la segunda;

N_{BA} es el número de sujetos que son clasificados por el test en la categoría B en la primera ocasión y en la A en la segunda;

N_{BB} es el número de sujetos que son clasificados por el test en la categoría B en las dos ocasiones;

N es el número de sujetos a los que se ha aplicado la prueba en cuestión.

Ahora bien, lo más habitual es aplicar el test en una única ocasión, por razones que pueden tener que ver tanto con las propias características de la prueba y de la muestra de sujetos como con cuestiones de índole práctica, económica o temporal. ¿Cómo estimar entonces la consistencia de las clasificaciones de los sujetos efectuadas a partir de las puntuaciones del test si éste se ha aplicado solo en una ocasión?

Se dispone de distintos métodos entre los que se suelen citar el de Huynh (1976) y el de Subkoviak (1976). Ambos procedimientos asumen implícitamente que todos los ítems del test tienen la misma dificultad (idéntico índice p)³ y permiten estimar el valor de κ , el acuerdo en las clasificaciones que se obtendrían con el test bajo estudio y con una forma

³ Observe el lector que éste es un supuesto bastante restrictivo. Si no se cumple, esto es, si los ítems del test tienen distinta dificultad, se infraestimarán la consistencia de las clasificaciones obtenidas a partir de las puntuaciones en el test.

hipotética del test totalmente intercambiable con la prueba en cuestión, asumiendo asimismo que la distribución conjunta de las puntuaciones en ambas formas —real e hipotética— del test es normal. A continuación se expondrá cómo proceder con una sencilla aproximación al primero de estos métodos, propuesta por Peng y Subkoviak (1980).

En este método el valor de κ se define del siguiente modo:

$$\kappa = \frac{P_{zz} - P_z^2}{P_z - P_z^2} \quad (6.13)$$

donde:

P_z es la probabilidad de obtener un valor igual o inferior a z , al punto de corte expresado en la escala típica lineal:

$$P_z = P\left(z \leq \frac{X_c - \mu_x}{\sigma_x}\right)$$

donde:

X_c es el punto de corte definido;

μ_x es la media de las puntuaciones obtenidas en el test;

σ_x es la desviación típica de las puntuaciones obtenidas en el test.

Para calcular el valor de P_z hay que acudir a la tabla A de la curva normal en el Anexo, buscar en la columna z el valor de la z correspondiente a X_c y ver la probabilidad asociada a dicho valor.

P_{zz} es la probabilidad de que las puntuaciones en una y otra forma del test sean iguales o inferiores al punto de corte expresado en la escala típica, teniendo en cuenta que la correlación entre ambas puntuaciones viene dada por el coeficiente de fiabilidad de la prueba en cuestión, que se estima mediante la ecuación KR21:

$$P_{zz} = P(z_1 \leq z, z_2 \leq z)$$

donde:

z_1 y z_2 son las puntuaciones típicas de las formas del test real e hipotética, respectivamente;

z es la puntuación típica correspondiente al punto de corte.

Para determinar esta probabilidad hay que acudir a la tabla B del Anexo, buscar en la columna z el valor relativo al punto de corte en cuestión y en la primera fila el valor KR21 que se corresponde con el coeficiente de fiabilidad estimado para la prueba.

Ejemplo 6.3

Cálculése la consistencia de las clasificaciones efectuadas con un test formado por 50 ítems, en el que la media y la varianza de las puntuaciones empíricas obtenidas por una muestra de 500 sujetos es 40 y 9, respectivamente, habiéndose fijado el punto de corte en 35.

$$\kappa = \frac{P_{zz} - P_z^2}{P_z - P_z^2} = \frac{0,0030 - 0,0475^2}{0,0475 - 0,0475^2} = 0,02$$

$$P_z = P\left(z \leq \frac{X_c - \bar{X}}{s_x}\right) = P\left(z \leq \frac{35 - 40}{3}\right) = P(z \leq -1,67) = 0,0475$$

Este último valor se obtiene buscando en la tabla A la probabilidad asociada a un valor de $z = -1,67$.

$$P_{zz} = P(z_1 \leq -1,67, z_2 \leq -1,67)$$

Para obtener este valor hay que acudir a la tabla B y saber cuál es la fiabilidad de la prueba estimada mediante la ecuación KR21:

$$KR21 = \frac{n}{n-1} \left(1 - \frac{\bar{X} - \bar{X}^2}{s_x^2} \right) = \frac{50}{49} \left(1 - \frac{40 - \frac{40^2}{50}}{9} \right) = 0,11$$

El valor de la tabla que corresponde a una $z = -1,67$ para un coeficiente de fiabilidad igual a 0,11 es $P_{zz} = 0,0030$.

Por último, repare el lector en que si, por alguna razón, se modifica el punto de corte que sirve para adscribir a los sujetos a la categoría A o B, entonces será necesario volver a calcular la consistencia de las clasificaciones obtenidas a partir de este nuevo punto de corte. Esto es, la consistencia de las clasificaciones de los sujetos realizadas a partir de sus puntuaciones en un test es específica del punto de corte utilizado para realizar dicha clasificación y si éste cambia hay que volver a evaluar la consistencia de las nuevas clasificaciones efectuadas.

6.6. PUNTOS BÁSICOS

- La fiabilidad es un criterio métrico de calidad que proporciona información acerca de la cantidad de error *aleatorio* que contiene una medida obtenida al aplicar esa prueba a un sujeto o grupo de sujetos.

- La TCT conceptualiza la fiabilidad como estabilidad temporal de las puntuaciones del test (el error aleatorio tiene que ver con las fluctuaciones aleatorias que ocurren a lo largo del tiempo) o como consistencia interna de los ítems del test (el error aleatorio obedece a diferencias en el contenido de los ítems).
- La TCT define el coeficiente de fiabilidad como el cociente entre la varianza de las puntuaciones verdaderas y empíricas pero, al no poder conocer nunca las puntuaciones verdaderas, la fórmula anterior no permite obtener una medida del coeficiente de fiabilidad, por lo que es necesario arbitrar procedimientos que permitan obtener empíricamente estimaciones de dicho coeficiente. Estos procedimientos son: test-retest, formas paralelas, división del test en dos mitades y métodos basados en la covariación de los ítems.
- Al considerar la fiabilidad en términos de estabilidad temporal se examina la estabilidad o congruencia entre las puntuaciones obtenidas por los sujetos en dos ocasiones distintas en el test (o en dos formas paralelas del mismo), utilizando el método test-retest o el de las formas paralelas.
- Al considerar la fiabilidad en términos de la consistencia interna se examina la consistencia o congruencia en la forma de responder de los sujetos a los distintos ítems (o grupos de ítems) del test, utilizando el método de la división del test en dos mitades o el basado en la covariación de los ítems.
- Existen distintos tipos de medidas según el grado de equivalencia que éstas muestran: medidas paralelas, estrictamente tau-equivalentes, esencialmente tau-equivalentes y congenéricas.
- El coeficiente de fiabilidad del test no es único sino que depende y varía, entre otros, con factores como su longitud y la variabilidad de la muestra de sujetos a la que se administra en la característica que mide dicho test.
- La mayor limitación de la TCT es la dependencia que muestran los parámetros del test de las características de los sujetos a los que éste se aplica y la dependencia que presentan los parámetros de los sujetos de las características del test; en suma, el carácter dependiente del instrumento de medida respecto a los sujetos medidos y a la inversa.
- La TRI conceptualiza la fiabilidad en términos de la cantidad de información que en cada punto de la escala proporciona el test (o el ítem) acerca del nivel en que un sujeto situado en ese punto posee la característica o atributo evaluado con el test (o con el ítem).

- Antes de estimar la fiabilidad de una prueba compuesta por ítems que exigen el recurso a jueces, calificadores o codificadores es preciso examinar la fiabilidad interjueces, para poder garantizar que la actuación de los jueces encargados de asignar puntuaciones a los ítems del test no está influyendo en la precisión o fiabilidad de las estimaciones obtenidas para los sujetos en la característica de interés que mide el test.
- El coeficiente κ de Cohen (1960) es uno de los estadísticos más utilizados para estimar el grado de acuerdo existente entre las puntuaciones asignadas por dos jueces a las respuestas de los sujetos a un ítem del test.
- Debido a la restricción del rango de variación, el coeficiente de fiabilidad clásico resulta poco útil para los tests interpretados de forma criterial, sobre todo, para asignar a los sujetos a una u otra categoría en función de que sus puntuaciones superen o no una determinada puntuación de corte. En este caso, la fiabilidad hay que entenderla en términos de la consistencia de las clasificaciones realizadas con el test (que se estima mediante el coeficiente κ) y hay que prestar máxima atención a la precisión con que se mide básicamente en la zona de la escala próxima al punto de corte fijado.

6.7. EJERCICIOS

6.7.1. La siguiente matriz representa las respuestas dadas por 10 sujetos a un test compuesto por 8 ítems de construcción valorados como correctos (código 1) o incorrectos (código 0).

SUJETOS	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8
1	1	1	1	0	1	0	0	0
2	1	1	0	0	1	0	1	0
3	1	1	1	1	1	1	0	0
4	1	0	0	1	0	0	0	0
5	1	1	1	1	0	0	0	0
6	1	1	0	0	0	0	1	0
7	1	1	1	1	1	1	1	1
8	1	0	0	0	0	0	0	0
9	1	1	1	1	1	0	1	1
10	1	0	0	1	0	0	0	0

6.7.1.1. ¿Cuál es la fiabilidad interjueces si las puntuaciones asignadas por un segundo juez al ítem número 4 son 0 0 1 1 0 0 1 0 1 1?

6.7.1.2. Estime el coeficiente de fiabilidad del test utilizando dos procedimientos distintos.

6.7.1.3. ¿Cuál sería la fiabilidad de este test si se duplicara su longitud añadiendo ítems paralelos en dificultad y contenido a los iniciales?

6.7.1.4. ¿Cuántos ítems habría que añadir a esta prueba para que mostrara un índice de fiabilidad de 0,98?

6.7.1.5. ¿Cuál sería la fiabilidad de esta prueba si la varianza de las puntuaciones empíricas en la muestra en la que se ha administrado fuera la mitad de la que realmente se ha obtenido?

6.7.1.6. Supongamos que la prueba se va a utilizar para asignar a los sujetos a dos categorías distintas (A y B) y que se adopta como punto de corte un valor de 5, de forma que serán asignados a la categoría A todos los sujetos que hayan obtenido puntuaciones al menos de 5 puntos en el test. ¿Cuál sería la fiabilidad de esta prueba cuando se utiliza de este modo?

6.7.1.7. Transcurrido un mes y medio desde la primera administración de la prueba, ésta se vuelve a aplicar a los mismos sujetos obteniéndose las siguientes puntuaciones: 3, 4, 6, 2, 5, 3, 7, 1, 6, 2. Estime el índice de fiabilidad de esta prueba teniendo en cuenta esta nueva información.

6.7.1.8. ¿Cuál sería ahora la fiabilidad de la prueba utilizada para adscribir a los sujetos a la categoría A o B?

6.7.1.9. Supongamos que se estiman los parámetros de los 8 ítems y de los 10 sujetos con la teoría de respuesta al ítem, en particular, con el modelo de un parámetro. El valor θ que corresponde al punto de corte en el test es 1. Estime la cantidad de información que proporciona el test sobre la característica que evalúa en el punto de corte adoptado para clasificar a los sujetos en una u otra categoría, sabiendo que la probabilidad de responder correctamente a cada uno de los ítems del test para $\theta = 1$ es la siguiente: 0,95, 0,75, 0,55, 0,65, 0,45, 0,30, 0,40, 0,25.

6.7.2. ¿Cuál de los siguientes valores NO puede corresponder a un coeficiente de fiabilidad?

- A) 0,85
- B) 1,25
- C) 0,00
- D) -0,10

6.7.3. Un psicólogo clínico está trabajando en un programa de reducción de la ansiedad. La aplicación de este programa supone tres fases distintas: (1) la obtención de una medida previa del nivel de ansiedad de los pacientes, (2) la realización de la terapia reductora de la ansiedad y (3) la obtención de una medida postratamiento del nivel de ansiedad de los pacientes.

¿Qué método utilizaría para estimar el coeficiente de fiabilidad de la prueba de ansiedad? Razone su respuesta.

6.7.4. Una prueba de comprensión lectora de 40 ítems está formada por distintos textos acerca de los cuales se les hace 5 preguntas a los sujetos. Se desea estimar la fiabilidad de la prueba utilizando el método de la división del test en dos mitades. Señale la opción que indica cómo habría que dividir el test para obtener dos mitades equivalentes:

- A) Mitad 1: Ítems del 1 al 20; Mitad 2: Ítems del 21 al 40.
- B) Mitad 1: Ítems 1-5, 11-15, 21-25 y 31-35; Mitad 2: Ítems 6-10, 16-20, 26-30 y 36-40.
- C) Mitad 1: Ítems pares; Mitad 2: Ítems impares.
- D) Con este tipo de prueba no se puede utilizar este método.

6.8. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

6.8.1.1. Para estimar el valor de κ (ecuación 6.12) para los jueces 1 y 2 habrá que construir una tabla de contingencia como la tabla 6.4:

		JUEZ 2		
		0	1	
JUEZ 1	0	4	0	4
	1	1	5	6
		5	5	10

Por consiguiente,

$$F_0 = 4 + 5 = 9$$

$$F_e = 5 \times 4/10 + 5 \times 6/10 = 5$$

$$\kappa = \frac{9 - 5}{10 - 5} = 0,8$$

6.8.1.2. Dado que el test se ha aplicado en una única ocasión, habrá que optar por un método basado en la división del test en dos mitades y por uno basado en la covariación de los ítems.

Método basado en la división del test en dos mitades

Se van a formar dos mitades con los ítems con número par e impar de orden en el test y se asumirá que se trata de mitades estrictamente tau-equivalentes, por lo que habrá que aplicar la fórmula indicada en la tabla 6.2. Para ello, es necesario calcular previamente la varianza de las puntuaciones en el total del test, en la mitad par y en la mitad impar.

SUJETOS	X	P	I	X^2	P^2	I^2
1	4	1	3	16	1	9
2	4	1	3	16	1	9
3	6	3	3	36	9	9
4	2	1	1	4	1	1
5	4	2	2	16	4	4
6	3	1	2	9	1	4
7	8	4	4	64	16	16
8	1	0	1	1	0	1
9	7	3	4	49	9	16
10	2	1	1	4	1	1
TOTAL	41	17	24	215	43	70

$$s_x^2 = \frac{215}{10} - \left(\frac{41}{10}\right)^2 = 4,69$$

$$s_p^2 = \frac{43}{10} - \left(\frac{17}{10}\right)^2 = 1,41$$

$$s_i^2 = \frac{70}{10} - \left(\frac{24}{10}\right)^2 = 1,24$$

$$r_{xx} = 2 \left(1 - \frac{1,41 + 1,24}{4,69} \right) = 0,87$$

Método basado en la covariación de los ítems

Dado que se trata de ítems dicotómicos, aplicaremos la ecuación KR20 (ecuación 6.6), para lo cual es preciso conocer la proporción de respuestas correctas e incorrectas de cada ítem:

ÍTEM	p	q	pq
1	1,0	0,0	0,0
2	0,7	0,3	0,21
3	0,5	0,5	0,25
4	0,6	0,4	0,24
5	0,5	0,5	0,25
6	0,2	0,8	0,16
7	0,4	0,6	0,24
8	0,2	0,8	0,16
TOTAL			1,51

$$\hat{\alpha} = \frac{8}{8-1} \left(1 - \frac{1,51}{4,69} \right) = 0,77$$

6.8.1.3. La fórmula que relaciona la longitud y la fiabilidad es la fórmula (6.8):

$$r_{yy} = \frac{2 \times 0,77}{1 + 0,77} = 0,87$$

6.8.1.4. Si $r_{xv} = 0,98$, entonces $r_{xx} = r_{xv}^2 = 0,96$. Apliquemos ahora la fórmula (6.8):

$$0,96 = \frac{0,77k}{1 + (k-1)0,77} \Rightarrow k = 7,33$$

Según (6.9), $k = n_y/n_x$. Por tanto, $7,33 = n_y/8$ y $n_y = 58,6 \cong 59$ ítems tendría el test finalmente. Por tanto, los ítems que habría que añadir serían $n_y - n_x = 59 - 8 = 51$ ítems.

6.8.1.5. Se trata de un problema de fiabilidad y variabilidad, por lo que habrá que aplicar la fórmula (6.10):

$$r_{22} = 1 - \frac{4,69}{\frac{4,69}{2}}(1 - 0,77) = 0,54$$

6.8.1.6. En este ejercicio se trata de calcular la consistencia de las clasificaciones de los sujetos en las categorías A y B realizadas a partir de las puntuaciones del test, cuando éste se ha administrado en una única ocasión. Por tanto, la fórmula a aplicar será la (6.13) y habrá que calcular previamente los valores de P_z y P_{zz} acudiendo a las tablas A y B, respectivamente:

$$P_z = P\left(z \leq \frac{5 - \frac{41}{10}}{\sqrt{4,69}}\right) = P(z \leq 0,42) = 0,6628$$

$$P_{zz} = P(z_1 \leq 0,42, z_2 \leq 0,42) = 0,5391$$

$$KR21 = \frac{8}{8-1} \left(1 - \frac{4,1 - \frac{4,1^2}{8}}{4,69}\right) = 0,66$$

$$\kappa = \frac{0,5391 - 0,6628^2}{0,6628 - 0,6628^2} = 0,45$$

6.8.1.7. Para estimar el coeficiente de fiabilidad con el método test-retest habrá que aplicar la fórmula (6.3):

SUJETOS	X_1	X_2	X_1X_2	X_1^2	X_2^2
1	4	3	12	16	9
2	4	4	16	16	16
3	6	6	36	36	36
4	2	2	4	4	4
5	4	5	20	16	25
6	3	3	9	9	9
7	8	7	56	64	49
8	1	1	1	1	1
9	7	6	42	49	36
10	2	2	4	4	4
Total	41	39	200	215	189

$$r_{xx} = \frac{10 \times 200 - 41 \times 39}{\sqrt{(10 \times 215 - 41^2)(10 \times 189 - 39^2)}} = 0,96$$

$$r_{xv} = \sqrt{r_{xx}} = 0,98$$

6.8.1.8. En este caso hay que calcular el coeficiente κ para dos aplicaciones del test, utilizando la fórmula (6.12), si bien previamente conviene disponer los datos en una matriz como la de la tabla 6.4:

		OCASIÓN 2		
		A	B	
OCASIÓN 1	A	3	0	3
	B	1	6	7
		4	6	10

Por consiguiente,

$$F_0 = 3 + 6 = 9$$

$$F_e = 4 \times 3/10 + 6 \times 7/10 = 5,4$$

$$\kappa = \frac{9 - 5,4}{10 - 5,4} = 0,78$$

6.8.1.9. Se trata de calcular la función de información del test para $\theta_c = 1$, por lo que habrá que aplicar la fórmula (5.19). Para determinar el valor de $P'(u_i = 1/\theta_c)$ es necesario acudir a la tabla 5.4 y ver su valor para el modelo de un parámetro.

ÍTEMS	$P(u_i = 1/\theta_c)$	$P(u_i = 0/\theta_c)$	$P'(u_i = 1/\theta_c)$	$I(\theta_c, u_i)$
1	0,95	0,05	0,08	0,14
2	0,75	0,25	0,32	0,54
3	0,55	0,45	0,42	0,72
4	0,65	0,35	0,39	0,66
5	0,45	0,55	0,42	0,72
6	0,30	0,70	0,36	0,61
7	0,40	0,60	0,41	0,69
8	0,25	0,75	0,32	0,54
TOTAL				4,62

Por tanto, $I(\theta_c = 1) = 4,62$.

6.8.2. B) ya que el coeficiente de fiabilidad se define como un coeficiente de correlación (en todos los métodos, excepto en el coeficiente α) y como tal nunca puede superar la unidad (ni α tampoco).

La opción D) al ser un número negativo tampoco es una opción ni habitual ni deseable, si bien podría obtenerse en la práctica un valor negativo. Teóricamente no sería un valor posible ya que el coeficiente de fiabilidad se define en principio como un cociente entre dos varianzas que, por definición, son valores positivos. Sin embargo, ya vimos que esa definición no sirve para obtener una medida de la fiabilidad de una prueba y cuando se utilizan cualquiera de los procedimientos arbitrados para estimar la fiabilidad pudiera ser posible obtener un valor negativo, si bien eso sería un indicador claro de un problema o funcionamiento anómalo de la prueba (los sujetos con puntuaciones altas en la primera aplicación del test obtienen puntuaciones bajas en la segunda; se observan covarianzas negativas entre las puntuaciones de los sujetos a los ítems, etc.).

6.8.3. Pese a disponer de dos aplicaciones de la misma prueba, en la situación planteada es impensable utilizar el procedimiento test-retest (ni el de las formas paralelas, en el caso de que las hubiera), ya que entre las dos aplicaciones del test se ha llevado a cabo la terapia reductora de la ansiedad que, si ha operado en la dirección esperada, habrá modificado el nivel de ansiedad de los pacientes, de modo que no tiene ningún sentido calcular la correlación entre las puntuaciones obtenidas en la prueba en las dos ocasiones como estimación de la fiabilidad de la prueba puesto que el nivel de los sujetos en la variable medida ha cambiado de una ocasión a otra.

En este caso, lo apropiado sería estimar la fiabilidad utilizando un método basado en la división del test en dos mitades o calcular el coeficiente α .

6.8.4. B) ya que no se puede separar los ítems que corresponden a un mismo material estimular y los bloques de ítems se han asignado a las dos mitades de manera alternada (primer bloque a la primera mitad; segundo bloque a la segunda mitad; tercer bloque a la primera mitad, etc.), algo que es importante cuando los ítems (o los bloques) aparecen ordenados según su dificultad.

6.9. BIBLIOGRAFÍA BÁSICA RECOMENDADA

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulos 4, 5 y 6.

Se hace un planteamiento detallado y riguroso de la fiabilidad tal como es concebida en la teoría clásica de los tests.

MELIÁ, J. L. (2000). *Teoría de la fiabilidad y la validez*. Valencia: Cristóbal Serrano.

Tratamiento detallado del método test-retest, del método de las formas paralelas y del basado en la división del test en dos mitades, ilustrado además con un buen número de ejemplos.

MUÑIZ, J. (1996). Fiabilidad. En J. Muñiz (Coord.), *Psicometría*. Madrid: Universitas.

En este capítulo se da un repaso general a los planteamientos que hacen tanto la teoría clásica como la teoría de respuesta al ítem, básicamente de la fiabilidad pero también de algunas otras cuestiones, sobre todo, en el caso de esta segunda teoría.

MUÑIZ, J. (1997). *Introducción a la teoría de respuesta a los ítems*. Madrid: Pirámide. Capítulo 8.

Se trata de un capítulo dedicado por completo a la concepción de la fiabilidad en la teoría de respuesta al ítem.

RENOM, J. (1992). *Diseño de tests*. Barcelona: Engine. Capítulo 6.

Se ocupa del tratamiento de la fiabilidad en la teoría clásica de los tests.

SANTISTEBAN, C. (1990). *Psicometría. Teoría y práctica en la construcción de tests*. Madrid: Norma. Capítulos 3, 4, 5 y 13.

Los tres primeros capítulos se ocupan de la fiabilidad en la teoría clásica y el 13 en la teoría de respuesta al ítem.

Para la parte relativa a la fiabilidad de los tests cuando se realiza una interpretación criterial de sus puntuaciones se puede acudir al trabajo de Martínez Arias (1995), en particular, al apartado 21.8.2 y al trabajo de Muñiz (1998), al apartado 2.10.2.

6.10 . MATERIAL COMPLEMENTARIO

— Fiabilidad como generalizabilidad.

LA VALIDEZ COMO CRITERIO MÉTRICO DE LA CALIDAD GLOBAL DEL TEST

María José Navas Ara

7.1. INTRODUCCIÓN

La validez es el segundo criterio métrico de la calidad global del test (véase figura 6.1). Así como la fiabilidad tiene que ver con la precisión de las medidas obtenidas en el proceso de la medición psicológica y con los errores aleatorios que se introducen en dicho proceso, la validez se ocupa del significado de las medidas obtenidas al aplicar una prueba a un sujeto o grupo de sujetos y de los errores sistemáticos que se pueden producir en esas medidas. La validez trataría, por tanto, de garantizar que las puntuaciones del test se pueden 1) interpretar en términos del constructo psicológico cuya medida puso en marcha el proceso de construcción (o aplicación) del test y 2) utilizar con el fin previsto.

Observe el lector que las consideraciones relativas a la validez nos están devolviendo de nuevo al comienzo del proceso de medición, al plano teórico (véase figura 2.1). En efecto, una vez obtenido un estimador del constructo (habitualmente, las puntuaciones en el test) que ha sido representado empíricamente a través de las respuestas de los sujetos a los ítems de un test, lo que se plantea ahora es examinar las conexiones conceptuales reales entre lo medido (plano matemático) y el constructo (plano teórico), para así poder garantizar que las puntuaciones del test se pueden interpretar verdaderamente en términos de dicho constructo. Por consiguiente, la validez no se puede limitar a las últimas fases en el proceso de construcción y evaluación de un instrumento de medida sino que hay que ampliarla a todo el proceso de construcción del test. Anastasi (1986) señala claramente que el proceso de validación de la prueba comienza con las primeras fases del proceso de construcción del test, con la definición del objetivo del test (qué se mide, a quién y para qué) y la especificación del test (cómo se va a representar empíricamente el constructo que se va a medir, para así definir cuál va a ser el contenido del test, su longitud, el formato y las características psicométricas de los

ítems). Obviamente no es posible examinar las conexiones entre lo medido realmente y el constructo que se deseaba medir si éste no ha sido definido de forma apropiada con anterioridad y, a su vez, cuanto mejor y mayor haya sido la especificación del constructo de interés en las fases iniciales de construcción de la prueba, más abonado estará el camino para poder interpretar realmente las puntuaciones del test en términos de ese constructo psicológico y para utilizar dichas puntuaciones con el fin previsto.

Ahora bien, conviene tener presente que el hecho de que un constructo haya sido cuidadosamente definido en la fase de especificación del test no nos exime en modo alguno de comprobar que las puntuaciones obtenidas de forma empírica se pueden interpretar efectivamente en términos de dicho constructo, esto es, miden esa característica o atributo y se pueden utilizar para el objetivo deseado; sin embargo, sí facilita considerablemente las cosas. Dicho de otro modo, la especificación detallada del constructo no garantiza —solo ayuda— que las puntuaciones obtenidas en los ítems de la prueba construida para medirlo lo estén midiendo realmente, por lo que es necesario realizar esa comprobación posterior; es preciso embarcarse en un proceso de validación de la prueba ya que dichas puntuaciones pueden medir ese constructo y alguna otra característica no prevista inicialmente, que introduzca un error *sistemático* en las puntuaciones obtenidas en el test.

Por ejemplo, supongamos que se utiliza una tabla de especificación construida por expertos en *currículum* en la enseñanza primaria para medir el rendimiento en Matemáticas. Una buena parte de los ítems contruidos para la prueba resulta que tienen una alta carga en contenido verbal, por lo que los alumnos con una buena comprensión lectora y aptitud verbal pueden responder mejor a algunas preguntas de la prueba, simplemente porque comprenden mejor los enunciados de las mismas, al margen de que dominen en mayor o menor medida los contenidos o conceptos implicados en dichos ítems. Es decir, el hecho de haber especificado cuidadosa y detalladamente el constructo a medir —el rendimiento en Matemáticas— no garantiza que los ítems de la prueba lo midan —en este caso, además de dicho constructo se está evaluando también el nivel de comprensión lectora y la aptitud verbal de los alumnos—. Una parte de la variabilidad observada en las puntuaciones de la prueba de Matemáticas se debe a diferencias en la comprensión lectora y en la aptitud verbal de los alumnos y no a diferencias en su rendimiento en Matemáticas, esto es, parte de la variabilidad se puede atribuir a factores o variables que nada tienen que ver con el constructo que se desea medir (perfecta y detalladamente especificado).

En resumen, la especificación clara y detallada del constructo que se desea medir facilita pero no garantiza la interpretación de las puntua-

ciones del test en términos de dicho constructo y su utilización para el fin previsto. Precisamente, lo que se hace al estudiar la validez de la prueba es examinar el éxito con que se mide y se usa el constructo en cuestión, que para la buena marcha debe haber sido previamente especificado de forma clara y detallada. De hecho, se podría decir que la correcta especificación del constructo supuestamente medido por una prueba es una condición necesaria pero no suficiente para su validez.

Al examinar en el capítulo anterior la forma en que conciben la fiabilidad la teoría clásica de los tests y la teoría de respuesta al ítem se concluía que no tiene sentido el planteamiento de la fiabilidad como una propiedad métrica del test (sería en todo caso de las puntuaciones del test obtenidas en una determinada muestra de sujetos) sino más bien si el test es fiable para el objetivo que ha suscitado su aplicación (un test puede ser muy preciso para estimar la inteligencia de niños superdotados pero incapaz de medir con precisión a niños con serias dificultades de aprendizaje). El planteamiento de la validez en este sentido es totalmente paralelo al de la fiabilidad, ya que lo que se valida no es el test sino el significado o la interpretación que se hace de sus puntuaciones en relación al objetivo al que responde el test: ¿validez, para qué? es el interrogante que hay que formularse (Novick, 1984) ya que la validez, al igual que la fiabilidad, tampoco es una propiedad del test sino de la interpretación que se hace de sus puntuaciones, de las inferencias realizadas a partir de las puntuaciones del test (Cronbach, 1971). Es decir, los criterios métricos de calidad global de la prueba han de ser referidos y entendidos siempre en relación al objetivo para el cual se ha planteado su construcción o aplicación, no son propiedades del test sin más sino propiedades métricas vinculadas a una utilización determinada de la prueba.

En el siguiente apartado se tratará de entender un poco mejor qué es la validez y cómo ha de ser el proceso conducente a la obtención de evidencia que justifique la interpretación de las puntuaciones del test en términos del constructo de interés y su utilización con el fin previsto. Esto es, se definirá la validez y el proceso de validación y esto se hará en relación a las dos posibles interpretaciones que se pueden hacer de las puntuaciones de un test (normativa y criterial). En los tres apartados siguientes se describirán distintas estrategias que permiten obtener información relevante en el proceso de validación de una prueba y se terminará el capítulo con una reflexión en torno a la posibilidad de generalizar los resultados obtenidos en la validación de una prueba a poblaciones diferentes de sujetos, a situaciones y tareas distintas de las implicadas en dicho test.

En particular, los objetivos que se persiguen en este capítulo son los siguientes:

- comprender qué es lo que se valida cuando se lleva a cabo un estudio de validación;
- saber diseñar un estudio de validación;
- conocer los distintos métodos que permiten obtener evidencia para la validación;
- conocer la forma de predecir un criterio continuo y uno discreto;
- saber cuantificar e interpretar la evidencia obtenida en un estudio de validación;
- identificar los factores que afectan a la validez.

7.2. CARACTERIZACIÓN GENERAL

La validez es un criterio métrico de calidad que proporciona información acerca de la adecuación de la interpretación de las puntuaciones del test en términos del constructo psicológico que dice medir y de su utilización para el fin previsto. Según se recoge en la última edición de los *Estándares para la evaluación psicológica y educativa* elaborados por tres prestigiosas asociaciones profesionales norteamericanas, la validez se refiere al grado en que tanto los datos como la teoría apoyan la interpretación de las puntuaciones de un test vinculada al uso propuesto para el test (AERA, APA y NCME, 1999). ¿Cómo garantizar entonces la adecuación de la interpretación y del uso previsto para las puntuaciones del test?

En primer lugar, el usuario del test debe acudir al manual del test, a la documentación proporcionada con la prueba (o incluso a la literatura especializada) para ver cuál es la utilización propuesta por el autor para la prueba, ver si coincide con el uso que él pensaba darle y si la situación en la que ahora va a ser aplicada es similar a las situaciones de las que se informa en el manual. De no ser así, el usuario del test tiene la *obligación* de investigar si realmente en el caso particular en el que va a operar es legítimo interpretar las puntuaciones obtenidas en el test en términos del constructo que según el manual mide el test y si realmente ese test es apropiado para lo que el usuario en cuestión desea. Esto es, el usuario del test debe embarcarse en un proceso de validación de la prueba para poder utilizar e interpretar sus puntuaciones en el sentido deseado, ya que la validación de la prueba es una *responsabilidad conjunta* del constructor y del usuario del test. Como ya se indicó en la introducción, la validez no es una propiedad métrica del test sino de la interpretación y utilización de sus puntuaciones. Por consiguiente, si utilizamos una prueba para un propósito distinto del indicado en la documentación de la prueba o con una población diferente, estamos obligados a demostrar, al

igual que hizo el constructor al presentar la prueba, que esa interpretación y utilización son legítimas. ¿Cómo hacerlo?

La validación de un test se puede definir como el proceso mediante el cual el constructor (o el usuario) del test recoge información que apoye (o refute) una determinada interpretación y utilización de sus puntuaciones, que confirme o rechace la adecuación de las inferencias realizadas a partir de las puntuaciones del test. Por tanto, la validación se puede concebir como una investigación científica en la que se va a someter a prueba una hipótesis (la inferencia realizada a partir de las puntuaciones del test, la interpretación de las puntuaciones del test en términos del constructo que éste dice medir) que va a proporcionar información acerca del significado de las puntuaciones de los tests.

El primer paso que hay que dar en el proceso de validación de un test no es por obvio menos importante: definir de forma clara e inequívoca la interpretación que se desea hacer de las puntuaciones del test, en función lógicamente del objetivo que suscitó su aplicación. En el capítulo 4 se introdujo al lector en los dos tipos de interpretaciones que se suelen realizar de las puntuaciones del test —normativa y criterial— según se desee comparar la actuación en el test de un sujeto con la actuación de su grupo de referencia o, por el contrario, se prefiera examinar única y exclusivamente la actuación de ese sujeto con el fin de describir claramente lo que éste sabe o no hacer o para adscribirle a una determinada categoría, en función de cuál haya sido su actuación en la prueba. Por ejemplo, tres posibles inferencias que se podrían realizar a partir de las puntuaciones en una prueba de Matemáticas podrían ser las siguientes:

1. El rendimiento en Matemáticas de F. es superior al del 40% de los alumnos de su curso en todo el territorio nacional.
2. Los puntos fuertes de F. en Matemáticas son los números enteros, las fracciones, porcentajes y la resolución de ecuaciones; sus puntos débiles son las figuras geométricas y el análisis e interpretación de datos en tablas y gráficos.
3. F. debe asistir a clases de recuperación de Matemáticas.

El paso siguiente consistirá lógicamente en diseñar un estudio que permita obtener evidencia favorable (o desfavorable) a cada una de esas interpretaciones. Si se concibe la validación del test como una investigación, como un proceso científico de contrastación de hipótesis, resulta claro entonces que para obtener dicha evidencia se puede utilizar una enorme variedad de métodos procedentes tanto de la tradición experimental como de la correlacional (*véase* figura 1.2). Messick (1989), una de las máximas autoridades sobre validez, es contundente al afirmar que «la

validación de un test abarca todas las cuestiones experimentales, estadísticas y filosóficas por medio de las cuales se evalúan las hipótesis y teorías científicas» (p. 14). Según Silva (1993), no existen más límites en cuanto a procedimientos posibles que los requisitos de científicidad. Ahora bien, según sea la interpretación o la utilización que se desea hacer de las puntuaciones del test será más apropiado utilizar unos métodos determinados en lugar de otros también posibles para obtener dicha evidencia o información.

Así, en el ejemplo anterior la primera interpretación o inferencia propuesta está vinculada a una función de descripción/información del test (véase tabla 3.1) y la hipótesis que hay que someter a prueba en el proceso de validación es que el test mide el rendimiento en Matemáticas. Para ello, se pueden utilizar métodos que proporcionen información acerca de la estructura interna del test —para ver si efectivamente éste mide o no el rendimiento en Matemáticas— o también se puede recurrir a métodos que relacionen esta prueba con otras variables con las que en principio podría estar relacionado el constructo presuntamente medido (las calificaciones escolares, la actitud del alumno hacia las Matemáticas, su aptitud numérica, su nivel de razonamiento abstracto, etc.). La segunda interpretación propuesta está vinculada a una función diagnóstica del test (véase tabla 3.1) y la hipótesis que hay que contrastar en el proceso de validación es que la prueba de Matemáticas constituye una muestra representativa del dominio evaluado. En este caso, es conveniente obtener información utilizando métodos relacionados con el contenido del test. Por último, la tercera interpretación propuesta está vinculada a una función de clasificación del test (véase tabla 3.1) y la hipótesis que hay que someter a prueba en el proceso de validación es que el test sirve para asignar a los sujetos a categorías discretas. En este caso se podría llevar a cabo un estudio cuasi experimental o correlacional para comprobar si las personas finalmente asignadas a cada categoría —atendiendo a sus puntuaciones en el test— son las que realmente deberían haber sido. El resto del capítulo se dedica a presentar de forma necesariamente breve y superficial los métodos que tradicionalmente se han utilizado para obtener evidencia, para recoger información que nos permita validar una interpretación y utilización determinada de las puntuaciones de un test.

El lector sin duda habrá reparado ya en que la validación, como cualquier proceso de comprobación de hipótesis y teorías científicas, es un proceso sin fin, es una historia inacabada por naturaleza (Cronbach, 1971), ya que siempre cabe la posibilidad de encontrar algún hecho que cuestione la hipótesis, por muchas veces que ésta haya sido confirmada por datos empíricos. Lo ideal es obtener líneas múltiples de evidencia empírica procedentes de distintas fuentes o métodos, de forma que haya una acumulación gradual de información que proporcione evidencia

favorable a una determinada interpretación y utilización de las puntuaciones de un test. Por consiguiente, la validación del test hay que entenderla como un proceso de acumulación de evidencias que apoyen dichas inferencias, para así lograr una mejor comprensión del significado de las puntuaciones del test.

7.3. MÉTODOS RELACIONADOS CON LA ESTRUCTURA INTERNA DEL TEST

Al analizar la estructura interna del test se puede obtener información acerca del grado en que las relaciones observadas entre los ítems del test encajan con el constructo en el que se basa la interpretación propuesta para las puntuaciones de la prueba. Se trataría de examinar la relaciones entre los ítems del test con el fin de ver empíricamente qué conceptos se pueden utilizar para interpretar la actuación del sujeto en el test y si éstos coinciden con el constructo que en principio dice medir la prueba (que es justamente lo que estamos comprobando al realizar un estudio de validación). En particular, lo que hay que hacer es determinar de forma empírica la estructura dimensional del test y ver si coincide con la estructura postulada teóricamente al construir la prueba. Una herramienta de indudable valor para ello es el análisis factorial.

El análisis factorial es una técnica que permite reducir la dimensionalidad de una matriz de datos (por ejemplo, las respuestas dadas por N alumnos a los n ítems de una prueba de Matemáticas). Esto es, posibilita pasar de una matriz de dimensión $N \times n$ a una de dimensión $N \times p$, donde $p < n$, eso sí, sin pérdida de información o con una pérdida mínima o tolerable (p es el número de nuevas variables o factores definidos por el análisis a partir de las n variables originales). Ahora bien, ¿cómo pasar de una matriz $N \times n$ a una $N \times p$?, ¿cómo definir esas nuevas variables o factores? Simplificando enormemente la cuestión, esta técnica procede del siguiente modo:

1. Se calcula una matriz $n \times n$ —a partir de la matriz $N \times n$ — cuyas celdillas contienen el coeficiente de correlación entre las puntuaciones obtenidas en cada posible par de ítems del test.
2. Se definen nuevas variables o factores examinando en la matriz anterior qué ítems están más relacionados entre sí (muestran coeficientes de correlación más altos entre sí que con otros ítems).
3. Se calcula una nueva matriz $n \times p$ cuyas celdillas contienen el coeficiente de correlación entre las variables originales y las nuevas variables o factores, denominándose a dichos coeficientes *pesos* o *saturaciones factoriales*.

4. Los factores se definen como combinaciones lineales de las variables originales que presentan las saturaciones más altas en dicho factor.

El lector interesado en conocer en detalle esta técnica puede acudir a Ferrando (1993) o a Martínez Arias (1995a, capítulo 16).

Una vez sometida a análisis factorial la matriz con las puntuaciones de los sujetos a los ítems de la prueba de Matemáticas se trata de ver si los p factores o dimensiones obtenidas empíricamente con esta técnica de análisis coinciden, por ejemplo, con las cuatro áreas de contenido postuladas en la construcción de la prueba (Geometría, Álgebra, Estadística y Cálculo). Es decir, habrá que ver si alguno de esos p factores contiene los ítems que, de acuerdo con la especificación inicial del test, miden Geometría; si otro de los $(p-1)$ factores restantes contiene los ítems postulados teóricamente para el área de Álgebra y así sucesivamente. Si hay coincidencia entre los factores obtenidos empíricamente y los postulados teóricamente en la construcción de la prueba, esto es, si coincide la estructura dimensional empírica y teórica, entonces se obtiene evidencia favorable a la interpretación de las puntuaciones del test en términos del constructo psicológico que efectivamente parece que mide la prueba.

MC La evidencia proporcionada por el análisis factorial

7.4. MÉTODOS RELACIONADOS CON EL CONTENIDO DEL TEST

Al examinar el contenido del test se puede obtener evidencia favorable para la interpretación de sus puntuaciones en términos del constructo deseado y para su utilización con el fin previsto. De lo que se trata es de analizar la relación entre el contenido del test y el constructo que se desea medir. En particular, hay que examinar la relevancia y representatividad del contenido del test, esto es, hay que juzgar:

- la relevancia del dominio especificado para la interpretación propuesta para las puntuaciones del test;

- la adecuación con que el contenido del test representa al dominio conductual o área de conocimiento evaluada.

En resumen, un estudio de validación de contenido tiene por objeto examinar la adecuación con la que el contenido del test muestrea el dominio acerca del cual se van a realizar las inferencias, se pretende interpretar y utilizar las puntuaciones del test.

La forma típica de realizar un estudio de estas características supone reunir a un grupo o panel de expertos en el dominio evaluado por la prueba. Se puede proceder de dos formas distintas (McDonald, 1999):

1. Se les puede proporcionar todo el material con el que trabajó el constructor del test en las fases previas a la confección de los ítems y de la prueba propiamente dicha (objetivo y especificación del test), de forma que éstos dispongan de todo el sustrato teórico y conceptual en el que se ha basado la construcción del test bajo estudio.
2. Se puede optar sencillamente por darles la información relativa al objetivo del test, a la primera fase del proceso (qué se mide, a quién y para qué).

Obviamente, la carga de trabajo de una y otra opción es sensiblemente distinta y la decisión final acerca de qué vía seguir dependerá de la utilización concreta que se desee hacer de la prueba (por ejemplo, si la prueba se va a utilizar para la acreditación profesional puede tener más sentido la opción 1 que si se trata de obtener una mera caracterización general del rendimiento de los alumnos al finalizar un determinado curso) y de las limitaciones de tiempo y de presupuesto. Sea cual sea la vía por la que se opte, la tarea a la que se enfrentan seguidamente los expertos es analizar el contenido del test, de acuerdo a la especificación propuesta por el constructor o a la suya propia, examinando para ello:

1. La relevancia de los ítems: deben indicar para cada ítem del test si éste refleja, en términos de su contenido, el dominio del que deriva.

Por ejemplo, supongamos que para la construcción de un test se utiliza una tabla de especificación como la 3.2. En tal caso, habría que examinar la relevancia de cada ítem en relación al área de contenido y al proceso cognitivo que en principio pretendía medir.

Los jueces o expertos pueden emitir un juicio dicotómico (Sí/No) o bien utilizar una escala de cinco puntos, tal como propone Hambleton (1980), donde el valor 1 indica un ajuste pobre y

el 5 excelente. Una vez que todos los expertos han emitido un juicio acerca del ítem se calcula la media o la mediana de dichos juicios para cada ítem y es el investigador el que ha de decidir cuándo se considera que un ítem es relevante (por ejemplo, cuando la media de los juicios de los expertos en un ítem es mayor o igual a 3,5, o cuando su mediana es como mínimo 3, etc.).

Huelga decir que para poder obtener una estimación precisa de la relevancia de cada ítem hay que garantizar previamente que existe una adecuada fiabilidad interjueces, es decir, que todos los expertos que participan en el estudio realizan sus valoraciones de forma razonablemente unísona, que las características idiosincrásicas de los jueces no están influyendo en sus juicios. En el apartado cuarto del capítulo anterior se hacen reflexiones perfectamente válidas para el caso que ahora nos ocupa. Otro modo de evaluar la precisión de las valoraciones de cada juez consiste en introducir, junto a los ítems del test, otra serie de ítems que no correspondan a ninguna de las celdillas de la tabla de especificación del test. Serán eliminados del análisis aquellos jueces que no consigan detectar un número mínimo —establecido de antemano— de los ítems introducidos como señuelo.

2. La representatividad de los ítems: hay que examinar, a partir de los juicios emitidos por los expertos, el porcentaje de ítems del test que hay en cada una de las casillas definidas por la combinación de las dos dimensiones de la tabla de especificación y ver si ese porcentaje es acorde o no con el peso asignado a cada casilla en el dominio estudiado en la fase de especificación. El grado de concordancia entre estos porcentajes y los pesos asociados a cada casilla en la construcción del test será lo que nos permitirá finalmente hacer consideraciones sobre la representatividad de los ítems del test.

Por último, simplemente señalar que el ámbito en el que se suelen realizar mayoritariamente estudios de validación de contenido es el educativo, si bien ello no significa en modo alguno que la validación de contenido no sea aplicable a tests de aptitud y de personalidad.

7.5. MÉTODOS BASADOS EN LA RELACIÓN CON OTRAS VARIABLES

Al analizar las relaciones que existen entre las puntuaciones del test y otras variables externas relevantes desde el punto de vista teórico o práctico se puede obtener información acerca del grado en el que estas relaciones son consistentes con el constructo que subyace a la interpretación

propuesta para las puntuaciones del test. En efecto, si las relaciones observadas son consonantes con lo que predice el modelo teórico en el que se insertan estas variables y el constructo medido por la prueba, entonces se obtiene evidencia favorable a la interpretación propuesta para sus puntuaciones (e incluso para la teoría en la que se inserta el constructo medido por el test) y se avanza en la investigación acerca del significado de las puntuaciones del test. Por el contrario, si las relaciones observadas empíricamente no son las esperadas hay que empezar a cuestionar no solo la adecuación de la prueba para medir el constructo postulado sino también la adecuación de las medidas de las otras variables o incluso el mismo sistema teórico o, al menos, algunas de sus proposiciones.

Las variables externas relevantes pueden ser, por un lado, medidas del mismo constructo obtenidas con otras pruebas o tests y también medidas de otros constructos, de constructos diferentes insertos en el modelo teórico —más o menos formalizado— en el que se encuadra el constructo supuestamente evaluado por la prueba en proceso de validación. Como se indicó en un apartado anterior, estas variables podrían ser el rendimiento en Matemáticas medido con otras pruebas diferentes o variables tales como la aptitud numérica, el razonamiento abstracto o la misma actitud del alumno hacia las Matemáticas o incluso hacia el colegio en general. Por otra parte, las variables externas pueden ser también un criterio o variable directamente relacionada con el constructo supuestamente medido por la prueba que, por las razones que sea, puede ser difícil o costoso de medir, por lo que se procede a predecir o pronosticar su valor una vez conocido el valor del sujeto en la variable o constructo que mide el test. Por ejemplo, las puntuaciones en una prueba de Matemáticas pudieran servir para conocer el éxito académico del alumno en una carrera de Ciencias. Examinaremos por separado la forma de obtener evidencia favorable a una determinada interpretación de las puntuaciones de un test para uno y otro tipo de variables.

7.5.1. Relación con variables relevantes desde el punto de vista teórico

La significación o importancia de un constructo pasa en buena parte por su integración en un sistema o modelo teórico, más o menos formalizado (normalmente, menos en el ámbito psicopedagógico), de forma que lo que da significado en gran medida a las puntuaciones del test es la red de sus relaciones con otras variables y situaciones de la vida real. Para obtener información relativa a esta red de relaciones se puede llevar a cabo un estudio experimental o correlacional.

Si se opta por un estudio experimental para someter a prueba la hipótesis generada a partir del modelo teórico en el que se inscriben estas variables, es necesario que el investigador manipule una o más de las variables de dicha red para ver cómo influyen, por ejemplo, en la variable que mide el test. Así, se podría manipular activamente el nivel de motivación y la actitud hacia las Matemáticas de algunos de los alumnos y ver si su impacto en la actuación de los alumnos en la prueba de Matemáticas ocurre en la dirección sugerida por la teoría.

Si se opta por un estudio correlacional, habrá que 1) obtener medidas del mismo constructo evaluado con otras pruebas y medidas de otros constructos de dicha red y 2) calcular la correlación entre todas las medidas obtenidas. Las relaciones entre las puntuaciones del test en proceso de validación y las puntuaciones en otras pruebas que miden el mismo constructo proporcionarán información confirmatoria, convergente, mientras que las relaciones entre las puntuaciones del test y las de otras pruebas que miden constructos diferentes proporcionarán información no confirmatoria, discriminante. Campbell y Fiske (1959) desarrollaron un sistema conocido como *Matriz MultiMétodo MultiRasgo* (MMMMR) que permite estudiar todo ese conjunto de relaciones a través de la matriz de intercorrelaciones entre las variables, para obtener así evidencia empírica relativa a la adecuación de la interpretación de las puntuaciones del test en términos del constructo psicológico medido. La MMMMR es la herramienta que se ha utilizado de forma clásica para explorar esta red de relaciones del constructo.

En la tabla 7.1 aparecen los resultados de un estudio correlacional en el que se han medido tres constructos distintos: el rendimiento en Matemáticas (*A*), el razonamiento abstracto (*B*) y la aptitud numérica (*C*). Para medir cada uno de estos constructos se han utilizado tres pruebas distintas: un test de elección múltiple (método 1), una prueba de completar (método 2) y un test de elección binaria (método 3). De este modo, se dispone para cada uno de los constructos de tres medidas distintas, cada una de ellas realizada con un instrumento de medida diferente ($A_1, A_2, A_3; B_1, B_2, B_3; C_1, C_2, C_3$) y se dispone para cada tipo de instrumento de medida de la puntuación obtenida por el mismo grupo de sujetos en tres constructos distintos ($A_1, B_1, C_1; A_2, B_2, C_2; A_3, B_3, C_3$). Una vez obtenidas las puntuaciones de los sujetos en las nueve pruebas, el paso siguiente es calcular todas las posibles correlaciones entre estos conjuntos de puntuaciones. Son éstas las correlaciones que se presentan en la tabla 7.1.

TABLA 7.1
 Ejemplo de una matriz multimétodo-multirrasgo

	MÉTODO 1			MÉTODO 2			MÉTODO 3		
	A	B	C	A	B	C	A	B	C
1. Elección múltiple									
A Rendimiento en Matemáticas	0,95								
B Razonamiento abstracto	0,28	0,86							
C Aptitud numérica	0,58	0,39	0,92						
2. Completar									
A Rendimiento en Matemáticas	0,65	0,32	0,57	0,95					
B Razonamiento abstracto	0,30	0,38	0,40	0,39	0,76				
C Aptitud numérica	0,52	0,31	0,46	0,55	0,26	0,84			
3. Elección binaria									
A Rendimiento en Matemáticas	0,73	0,10	0,43	0,64	0,17	0,37	0,80		
B Razonamiento abstracto	0,10	0,63	0,17	0,22	0,67	0,19	0,15	0,77	
C Aptitud numérica	0,35	0,16	0,52	0,31	0,17	0,56	0,41	0,30	0,90

En esta tabla aparecen tres tipos distintos de coeficientes de correlación:

1. Coeficientes de fiabilidad: Son los valores de la diagonal en la tabla.

Son la correlación entre medidas del mismo constructo cuando se utiliza el mismo procedimiento de medida.

Por ejemplo, 0,95 es el coeficiente de fiabilidad de la prueba de elección múltiple que mide el rendimiento en Matemáticas ($r_{a_1a_1}$); 0,76 es el coeficiente de fiabilidad de la prueba de completar que mide el razonamiento abstracto ($r_{b_2b_2}$) y 0,90 es el coeficiente de fiabilidad del test de elección binaria que mide la aptitud numérica ($r_{c_3c_3}$).

2. Coeficientes de validez convergente: Son los valores en negrita de la tabla.

Son la correlación entre medidas del mismo constructo cuando se utilizan distintos procedimientos de medida.

Por ejemplo, 0,65 es el coeficiente de correlación entre las puntuaciones en la prueba de rendimiento en Matemáticas obtenidas

al aplicar el test de elección múltiple y la prueba de completar ($r_{a_1a_2}$) y es el coeficiente de validez convergente de cualquiera de esos dos instrumentos de medida; 0,67 es el coeficiente de correlación entre las puntuaciones en razonamiento abstracto obtenidas al aplicar la prueba de completar y el test de elección binaria ($r_{b_2b_3}$) y es el coeficiente de validez convergente de cualquiera de esos dos instrumentos de medida, etc.

3. Coeficientes de validez discriminante: Son el resto de los valores que aparecen en la tabla.

Son la correlación entre medidas de distintos constructos cuando se utiliza el mismo procedimiento de medida (también denominado *coeficiente monométodo-heterorasgo*) o la correlación entre medidas de distintos constructos cuando se utilizan distintos procedimientos de medida (también denominado *coeficiente heterométodo-heterorasgo*).

Un ejemplo de un coeficiente monométodo-heterorasgo es $r_{a_1b_1} = 0,28$, la correlación entre el rendimiento en Matemáticas y el razonamiento abstracto cuando éstos son medidos mediante una prueba de elección múltiple; este valor será un índice de la validez discriminante del instrumento de medida.

Un ejemplo de un coeficiente heterométodo-heterorasgo es $r_{a_1c_2} = 0,52$, la correlación entre el rendimiento en Matemáticas medido por una prueba de elección múltiple y la aptitud numérica medida por una prueba de completar; este valor será un índice de la validez discriminante de cualquiera de los dos instrumentos de medida.

Una vez construida la matriz de correlaciones hay que comparar los distintos coeficientes de validez. Se obtiene evidencia favorable a la interpretación de las puntuaciones del test en términos del constructo psicológico en cuestión si los coeficientes de validez convergente son mayores que los coeficientes de validez discriminante. En este caso, el estudio aporta evidencia que apoya la teoría sobre la que se basa el constructo de interés, ya que son mayores las correlaciones entre las medidas de un mismo constructo obtenidas con distintos procedimientos de medida que las medidas de distintos constructos obtenidas con el mismo método. En caso contrario, si los coeficientes de validez discriminante son mayores que los coeficientes de validez convergente, hay que plantearse serias dudas sobre el constructo y/o sobre la teoría en la que éste se asienta, ya que la correlación entre dos variables no debe ser función de la similitud del método utilizado para medirlas sino que debe ser función de su similitud en el contenido.

7.5.2. Predicción de un criterio

Otra forma de obtener evidencia acerca de la interpretación de las puntuaciones del test en términos del constructo psicológico que dice medir es examinando la capacidad predictiva del test para pronosticar el valor de una variable de esa red de variables en la que está inserto el constructo medido por el test, de ese sistema o modelo teórico que predice una determinada red de relaciones entre estas variables. Es decir, en este caso el estudio someterá a prueba una hipótesis predictiva que proporcionará información acerca del grado en que las puntuaciones del test están relacionadas o permiten predecir el valor de otra variable denominada tradicionalmente *criterio* y que no puede ser medido directamente. Por ejemplo, el criterio puede no estar disponible en el momento en el que se realiza la investigación pero sí se puede disponer de él en un futuro más o menos lejano, como cuando se utilizan pruebas de admisión en un centro escolar para predecir el futuro rendimiento académico de los alumnos; o bien, simplemente, la obtención de una medida del criterio puede ser demasiado difícil y/o costosa tanto en tiempo como en dinero haciendo aconsejable, por tanto, el uso de otras variables que permitan obtener información sobre el mismo.

Para llevar a cabo el estudio de validación, los pasos que hay que dar son los siguientes (Crocker y Algina, 1986):

1. Identificar un criterio adecuado o relevante para el test en cuestión y arbitrar un método eficaz para medir dicho criterio.
2. Elegir una muestra apropiada de sujetos que sea representativa de la población a la que normalmente se aplicará el test.
3. Aplicar el test a la muestra elegida.
4. Obtener una medida en el criterio para la muestra elegida de sujetos.
5. Determinar el grado de relación existente entre las puntuaciones obtenidas por los sujetos de la muestra en el test y en el criterio.

Al realizar un estudio de este tipo, se puede utilizar la información obtenida para estimar o predecir el comportamiento o la actuación aproximada en el criterio de interés de sujetos de características similares a los de la muestra de la investigación, siempre y cuando ésta haya revelado una relación adecuada entre el test y el criterio, que permita utilizar al primero de algún modo como un sustituto del segundo.

Para determinar el grado de relación existente entre el test y el criterio, es preciso detenerse a considerar primero qué tipo de variable —con-

tinua o discreta— son tanto el test como el criterio ya que, según sean éstas, variará el procedimiento o modelo a utilizar en la predicción, tal y como se recoge en la tabla 7.2.

TABLA 7.2
Tipología de situaciones de predicción

		CRITERIO	
		V. continua	V. discreta
TEST	V. continua	Regresión lineal	Análisis discriminante Regresión logística
	V. discreta		Modelos logit Modelos probit

Si el criterio que se desea pronosticar es una variable continua —rendimiento académico, satisfacción laboral, etc.— la técnica que se utiliza en la predicción es la regresión lineal (*véase* cuadro 5.2) y si el criterio es una variable discreta, una variable con un conjunto fijo y delimitado de categorías —promoción laboral, admisión a un curso, certificación académica, etc.— se pueden utilizar el análisis discriminante y la regresión logística —en el supuesto de que el test sea considerado como una variable continua— y los modelos logit y probit —en el supuesto de que el test sea considerado como una variable discreta, como cuando sus puntuaciones son interpretadas de forma criterial, para adscribir a los sujetos a una u otra categoría según que sus puntuaciones superen o no un determinado punto de corte.

En el resto del apartado se presentará muy brevemente la forma de proceder en los dos cuadrantes sombreados de la tabla, eso sí, sin entrar en la exposición de los modelos que permiten llevar a cabo dicha predicción y que serán objeto de estudio en la asignatura de 5º curso *Métodos de investigación en Educación*.

7.5.2.1. Continuo

En este subapartado vamos a ver cómo se puede pronosticar la puntuación de un sujeto en un criterio continuo cuando se utiliza como predictor las puntuaciones en un test considerado como una variable también continua, pero antes necesitamos saber cómo cuantificar la información obtenida en el estudio de validación, ya que si el grado de

relación evidenciado entre test y criterio no es suficiente no se podrá utilizar el primero para pronosticar el segundo. Finalmente, veremos qué factores pueden influir en la relación observada entre el test y el criterio.

7.5.2.1.1. *Cuantificación de los resultados del estudio de validación*

Son dos los tipos de índices que se pueden utilizar para interpretar los resultados procedentes de un estudio de validación: medidas correlacionales —como el coeficiente de validez— y medidas del error en la predicción —como el error típico de estimación del criterio.

El **coeficiente de validez** de un test es la medida más frecuente y popular de las utilizadas para resumir los resultados obtenidos en un estudio de validación. Éste se define como el coeficiente de correlación de Pearson entre las puntuaciones obtenidas en el test X y en el criterio Y (véase cuadro 6.1) y proporciona una medida de la relación lineal existente entre test y criterio, indica la fuerza de la relación entre el test que se utiliza como predictor y el criterio que se desea pronosticar reflejando, por tanto, el grado en que el test es empíricamente válido para apreciar, estimar o predecir el criterio:

$$\rho_{xy} = \frac{N \sum XY - \sum X \sum Y}{\sqrt{[N \sum X^2 - (\sum X)^2][N \sum Y^2 - (\sum Y)^2]}} \quad (7.1)$$

donde N es el número de sujetos para los que se dispone de puntuaciones en el test X y el criterio Y .

Si se eleva al cuadrado el coeficiente de validez se obtiene el **coeficiente de determinación** (d) que expresa la proporción de la varianza del criterio que puede ser pronosticada a partir del test. Si el coeficiente de validez de un test es 0,60, entonces es posible predecir o pronosticar el 36% de la varianza de las puntuaciones de los sujetos en el criterio o, dicho de otra manera, hay un 36% de varianza común o asociada entre test y criterio.

Además de interpretar los resultados obtenidos al realizar un estudio de validación mediante medidas del grado de asociación entre predictor y criterio, otra posibilidad es utilizar indicadores que den idea del error que se comete al atribuir al sujeto como puntuación en el criterio no su puntuación real (Y) sino la puntuación pronosticada a partir del predictor mediante la ecuación de regresión (Y'). Este error es el **error de estimación del criterio** y se define sencillamente como la diferencia entre estos

dos valores, de forma totalmente paralela a como se definía en el capítulo 5 el error de estimación de la puntuación verdadera:

$$E = Y - Y' \quad (7.2)$$

Observe el lector que en el capítulo 5 se utiliza el modelo de regresión para predecir, a partir de las puntuaciones en el test X , el nivel real de los sujetos en la variable medida por dicho test, mientras que ahora de lo que se trata es de predecir a partir de X el valor en una variable distinta pero relacionada con lo que mide el test, el valor en el criterio Y .

La desviación típica de la distribución de frecuencias de los errores de estimación del criterio es el **error típico de estimación** del criterio que nos indicará, por tanto, lo dispersas o alejadas que se encuentran las puntuaciones reales en el criterio de las puntuaciones pronosticadas. Cuanto menor sea este valor, mayor será la precisión de la estimación realizada mediante la ecuación de regresión del valor en el criterio. El error típico de estimación describe, por tanto, la precisión con la que se realizan predicciones con la ecuación de regresión:

$$\sigma_{y \cdot x} = \sigma_y \sqrt{1 - \rho_{xy}^2} \quad (7.3)$$

donde:

σ_y es la desviación típica de las puntuaciones en el criterio;
 ρ_{xy} es el coeficiente de validez del test.

7.5.2.1.2. Estimación de la puntuación en el criterio

Para estimar la puntuación que obtendría un sujeto en un criterio, conociendo su puntuación en un test que constituye un predictor adecuado de dicho criterio, es necesario aplicar la siguiente ecuación:

$$P(Y' - E.Máx. \leq Y \leq Y' + E.Máx.) \geq NC \quad (7.4)$$

donde:

Y' es la puntuación pronosticada en el criterio Y mediante la ecuación de regresión (véase cuadro 5.2):

$$Y' = \rho_{xy} \frac{\sigma_y}{\sigma_x} X + \left(\mu_y - \rho_{xy} \frac{\sigma_y}{\sigma_x} \mu_x \right) = \rho_{xy} \frac{\sigma_y}{\sigma_x} (X - \mu_x) + \mu_y$$

donde:

ρ_{xy} es el coeficiente de validez del test;

σ_y es la desviación típica de las puntuaciones en el criterio;

σ_x es la desviación típica de las puntuaciones en el test;

μ_y es la media de las puntuaciones en el criterio;

μ_x es la media de las puntuaciones en el test.

E.Máx. es el máximo error que estamos dispuestos a cometer en nuestras estimaciones:

$$E.Máx. = \sigma_{y \cdot x} z_c$$

donde:

$\sigma_{y \cdot x}$ es el error típico de estimación del criterio;

z_c es la puntuación que corresponde en una distribución normal a la probabilidad expresada en el Nivel de Confianza (NC).

Por consiguiente, la ecuación anterior se podría reescribir como:

$$P\left(\rho_{xy} \frac{\sigma_y}{\sigma_x} (X - \mu_x) + \mu_y - \sigma_{y \cdot x} z_c \leq Y \leq \rho_{xy} \frac{\sigma_y}{\sigma_x} (X - \mu_x) + \mu_y + \sigma_{y \cdot x} z_c\right) \geq NC \quad (7.5)$$

Ejemplo 7.1

Sean 15, 10, 12, 18, 25, 30, 16 y 22 las puntuaciones obtenidas por una muestra de trabajadores en una prueba de razonamiento mecánico y sea 4, 3, 4, 5, 7, 8, 6 y 5 la valoración realizada de su trabajo por su jefe inmediato. ¿Qué valoración se pronostica mediante el modelo de regresión para un trabajador que obtuviera en la prueba una puntuación de 20, si se trabaja con un nivel de confianza del 95%?

Sujetos	X	Y	X ²	Y ²	XY
1	15	4	225	16	60
2	10	3	100	9	30
3	12	4	144	16	48
4	18	5	324	25	90
5	25	7	625	49	175
6	30	8	900	64	240
7	16	6	256	36	96
8	22	5	484	25	110
TOTAL	148	42	3058	240	849

Los valores que hay que conocer para poder aplicar la ecuación (7.5) son los siguientes:

$$r_{xy} = \frac{8 \times 849 - 148 \times 42}{\sqrt{(8 \times 3058 - 148^2)(8 \times 240 - 42^2)}} = 0,91$$

$$s_x = \sqrt{\frac{3058}{8} - \left(\frac{148}{8}\right)^2} = 6,32$$

$$s_y = \sqrt{\frac{240}{8} - \left(\frac{42}{8}\right)^2} = 1,56$$

$$\bar{X} = 148/8 = 18,5$$

$$\bar{Y} = 42/8 = 5,25$$

$$Y' = 0,91 \frac{1,56}{6,32} (20 - 18,5) + 5,25 = 5,59$$

$$s_{y-x} = 1,56 \sqrt{1 - 0,91^2} = 0,65$$

$$P(5,59 - 0,65 \times 1,96 \leq Y \leq 5,59 + 0,65 \times 1,96) \geq 0,95$$

$$P(4,32 \leq Y \leq 6,86) \geq 0,95$$

La probabilidad de que la valoración real que de este trabajador realice su jefe se encuentre en algún punto del intervalo (4,32, 6,86) es muy alta ($P \geq 0,95$).

7.5.2.1.3. Factores que influyen en la relación test-criterio

Son varios los factores que tienen una incidencia directa en la relación test-criterio, tal y como ésta es apresada por el coeficiente de validez. Este coeficiente, al igual que el coeficiente de fiabilidad, es un coeficiente de correlación y, por consiguiente, es muy sensible a las características de la muestra en la que se calculó; en particular, como ya se puso de manifiesto en el capítulo anterior, aumenta cuando existe una gran variabilidad en el grado en el que los sujetos de la muestra manifiestan la característica evaluada y disminuye cuando éstos son muy similares entre sí, esto es, se modifica según sea la variabilidad observada en las puntuaciones de los sujetos. Como tendremos ocasión de comprobar en breve, el problema de

la restricción en el rango de variación de una variable reviste una importancia especial en un estudio de validación. Por otra parte, un factor decisivo a la hora de valorar la cuantía del coeficiente de validez obtenido en un estudio es la fiabilidad de las medidas del test y del criterio, ya que los errores de medida que afectan a estas puntuaciones tienen como consecuencia el rebajar el coeficiente de validez. En efecto, un test poco fiable nunca puede ser un buen predictor: si el coeficiente de fiabilidad de un test es bajo, esto supone que existe una gran cantidad de varianza error (y no de varianza verdadera) en las puntuaciones obtenidas en el test y la parte de error en las puntuaciones del test, al ser aleatorio, nunca correlacionará con el criterio, por lo que cuanto mayor es la varianza error, cuanto menor es la fiabilidad del test, menor es la correlación entre test y criterio y, por tanto, menor es el coeficiente de validez del test. Por último, un factor que también influirá en la validez de un test será su longitud. Como vimos en el capítulo anterior, la longitud y la fiabilidad de un test están estrechamente relacionadas y, como también lo están la fiabilidad y la validez, la longitud de la prueba también influirá en la cuantía del coeficiente de validez obtenido en un estudio de validación.

A) *Variabilidad de la muestra*

La tabla 7.3 presenta las correlaciones obtenidas entre varios tests utilizados para seleccionar a pilotos americanos durante la II Guerra Mundial y una medida obtenida al finalizar su adiestramiento (Thorndike, 1949). La primera columna muestra las correlaciones obtenidas en la muestra total de sujetos ($N = 1036$) y la segunda columna las obtenidas en el grupo constituido por el 13% de los sujetos con mejores resultados en

TABLA 7.3
Coeficientes de validez calculados para el total de la muestra
y para un grupo seleccionado

	Muestra	Grupo seleccionado
Test de principios mecánicos	0,44	0,03
Test de información general	0,46	0,20
Test de coordinación compleja	0,40	-0,03
Test de comprensión de instrumentos	0,45	0,27
Test de razonamiento aritmético	0,27	0,18
Test de destreza manual	0,18	0,00

el proceso de selección ($N = 135$). Como puede observarse en la tabla, los valores obtenidos hablan por sí solos: la correlación test-criterio se reduce drásticamente y en algunos casos llega a desaparecer, cuando se calcula en un grupo reducido y homogéneo de sujetos. El efecto que tiene en la validez esta restricción del rango de variación es claro. Si se define el coeficiente de validez como un coeficiente de correlación entre dos conjuntos de puntuaciones, al disminuir la variabilidad del grupo disminuirá la correlación y, por tanto, el coeficiente de validez será menor.

Pensemos ahora en una situación mucho más próxima o familiar como son las pruebas de admisión a un centro escolar. Si se admite al centro solamente a los alumnos que hayan obtenido una determinada puntuación en el test, la muestra sobre la que se recojan posteriormente las medidas en el criterio no será la misma muestra sobre la que se midió la variable predictora. Ahora, la muestra es más pequeña y homogénea ya que, por un lado, no incluye a los alumnos no seleccionados en base a sus puntuaciones en la prueba de admisión y, por otro, los alumnos que contiene son más parecidos los unos a los otros que los alumnos de la muestra inicial. Si calculamos el coeficiente de validez de la única forma posible, esto es, correlacionando las puntuaciones de los alumnos *admitidos* en el test y en el criterio, el coeficiente de validez que se obtenga no nos indicará la validez del test para predecir el futuro rendimiento escolar de los *solicitantes* en el centro sino que indicará simplemente la capacidad del test para discriminar entre los sujetos que finalmente han sido admitidos, nada más. Por tanto, el coeficiente de validez obtenido —el único posible, ya que solo se dispone de las puntuaciones en el criterio para los alumnos admitidos— no es el coeficiente que se deseaba obtener.

Ésta es una situación hartamente frecuente en la práctica de la evaluación psicológica y educativa: se conoce el coeficiente de validez del test en un grupo que a partir de ahora designaremos mediante letras minúsculas y se desea saber el coeficiente de validez del test en otro grupo que designaremos mediante letras mayúsculas, difiriendo ambos grupos en el tamaño y variabilidad de los sujetos en la característica examinada.

Si se supone que la recta de regresión que relaciona las puntuaciones en el test y en el criterio es la misma en ambos grupos y que el error típico de estimación del criterio es el mismo en los dos grupos, podemos determinar el coeficiente de validez del test en un grupo determinado conociendo su valor en el otro, aplicando las siguientes ecuaciones:

$$B_{y \cdot x} = b_{y \cdot x} \Rightarrow R_{xy} \frac{S_y}{S_x} = r_{xy} \frac{s_y}{s_x} \quad (7.6)$$

$$S_{y \cdot x} = s_{y \cdot x} \Rightarrow S_y \sqrt{1 - R_{xy}^2} = s_y \sqrt{1 - r_{xy}^2}$$

A partir de estas dos ecuaciones y en función de los datos que tengamos se pueden averiguar los que falten.

Ejemplo 7.2

El test X se ha utilizado como prueba de admisión en un determinado centro escolar. Calculemos su coeficiente de validez en el grupo de solicitantes, sabiendo que la varianza de sus puntuaciones en ese grupo es 14 y en el grupo de admitidos 9. En este último grupo, la correlación entre las puntuaciones en el test y un criterio fijado por el centro es 0,68 y la varianza de las puntuaciones en el criterio 8.

Para determinar el coeficiente de validez del test en el grupo de solicitantes hay que sustituir por su valor los términos cuyos datos conocemos en el sistema de ecuaciones (7.6):

$$R_{xy} \frac{S_y}{\sqrt{14}} = 0,68 \frac{\sqrt{8}}{\sqrt{9}}$$

$$S_y \sqrt{1 - R_{xy}^2} = \sqrt{8} \sqrt{1 - 0,68^2}$$

Operando en ambas ecuaciones se obtiene que:

$$R_{xy} S_y = 2,40$$

$$S_y \sqrt{1 - R_{xy}^2} = 2,07 \rightarrow S_y^2 (1 - R_{xy}^2) = 4,30$$

Despejando el valor de S_y en la primera ecuación ($S_y = 2,40/R_{xy}$) y sustituyéndolo en la segunda se obtiene que:

$$\frac{2,40^2}{R_{xy}^2} (1 - R_{xy}^2) = 4,30 \rightarrow R_{xy} = 0,76$$

B) *Fiabilidad de las medidas del test y del criterio*

Existe un teorema fundamental que relaciona la fiabilidad y la validez y que permite, a su vez, establecer hechos importantes:

$$\frac{r_{xy}}{R_{xy}} = \sqrt{\frac{r_{xx} r_{yy}}{R_{xx} R_{yy}}} \quad (7.7)$$

Esta fórmula nos permite calcular el valor del coeficiente de validez de un test (R_{xy}), partiendo de un coeficiente de validez inicial (r_{xy}) obtenido con un test que tenía una fiabilidad r_{xx} y un criterio cuya fiabilidad era r_{yy} ,

después de haber modificado la fiabilidad del test hasta alcanzar un valor R_{xx} y la del criterio hasta R_{yy} .

En el caso de que se eliminaran por completo los errores de medida tanto en el test como en el criterio ($R_{xy} = R_{V_x V_y}$), obtendríamos:

$$\frac{r_{xy}}{R_{V_x V_y}} = \sqrt{\frac{r_{xx} r_{yy}}{R_{V_x V_x} R_{V_y V_y}}} = \sqrt{r_{xx} r_{yy}}$$

o expresado de otro modo:

$$R_{V_x V_y} = \frac{r_{xy}}{\sqrt{r_{xx} r_{yy}}} \quad (7.8)$$

Esta ecuación se debe a Spearman y se conoce como la *fórmula de corrección de los efectos de atenuación*, ya que permite estimar la correlación intrínseca que hay entre dos variables, la correlación que obtendríamos si sus medidas fuesen perfectamente fiables. De acuerdo con esta fórmula, la validez máxima que puede conseguirse mediante la mejora en la precisión del test y del criterio es la razón entre la validez del test y la raíz cuadrada del producto de las fiabilidades de test y criterio.

Supongamos ahora que fuera perfecta la correlación intrínseca entre las puntuaciones verdaderas en un test y las del criterio ($R_{V_x V_y} = 1$). La ecuación anterior se reescribiría del siguiente modo:

$$R_{V_x V_y} = \frac{r_{xy}}{\sqrt{r_{xx} r_{yy}}} = 1 \Rightarrow r_{xy} = \sqrt{r_{xx} r_{yy}} \quad (7.9)$$

Esta nueva ecuación pone de manifiesto que la máxima correlación que puede haber, de hecho, entre dos variables —un predictor y un criterio— es la raíz cuadrada del producto de sus fiabilidades.

C) Longitud del test

La fórmula que relaciona la validez, fiabilidad y longitud de un test es la siguiente:

$$R_{xy} = \frac{r_{xy}}{\sqrt{\frac{1 - r_{xx}}{k} + r_{xx}}} \quad (7.10)$$

donde:

R_{xy} es el coeficiente de validez del nuevo test;

r_{xy} es el coeficiente de validez del test inicial;

r_{xx} es el coeficiente de fiabilidad del test inicial;

k es el número de veces en que se ha modificado la longitud del test inicial:

$$k = \frac{n_f}{n_i} \quad (7.11)$$

donde n_f y n_i son el número de ítems del test final e inicial, respectivamente.

7.5.2.2. *Discreto*

La situación que se plantea ahora es algo diferente. Volvamos al ejemplo de la prueba de admisión a un centro escolar. Cuando se utiliza una prueba (normalmente, un conjunto de pruebas) para decidir qué alumnos serán finalmente admitidos en una determinada institución educativa, lo que se pretende es seleccionar a los alumnos que previsiblemente mostrarán en el futuro el mayor aprovechamiento escolar posible, tomando como base para decidir qué alumnos en particular serán seleccionados las puntuaciones obtenidas por éstos en la(s) prueba(s) de admisión. Por tanto, disponemos como hasta ahora de un predictor continuo —las puntuaciones en una prueba de admisión— y un criterio también continuo —el futuro rendimiento escolar—. Sin embargo, dado que el objetivo particular del test es la selección de los mejores alumnos para entrar en una determinada institución educativa, es necesario variar ligeramente el escenario.

Para que el test pueda cumplir su función es necesario fijar un punto de corte (X_c) a partir del cual los sujetos con puntuaciones por encima de dicho valor serán candidatos a ser admitidos en el centro y los sujetos cuya puntuación esté por debajo del valor fijado para el punto de corte no serán tomados en consideración.

En el capítulo 4 ya se apuntaron algunos métodos que permiten establecer un punto de corte en el test cuando se pretende dar una interpretación criterial a sus puntuaciones. Otra posibilidad sería decidir el valor de X_c de tal forma que la probabilidad de una admisión errónea fuera menor o igual a un valor pequeño previamente acordado ($P(Y < Y_c) \leq P_d$).

Si se conoce el número de sujetos que se desea admitir (N_a), también es posible utilizar el modelo de regresión para pronosticar el valor de Y y formar los grupos en X considerando en una categoría a los N_a sujetos con la puntuación Y' más alta y en la otra categoría a los demás; en este caso, X_c correspondería al valor de X relativo a la puntuación Y' más baja obtenida por los N_a sujetos admitidos.

En tal caso, este predictor sería una variable discreta con solo dos valores posibles: A , candidato a la admisión ($X > X_c$) y B , rechazado ($X < X_c$). Por su parte, el criterio también se puede discretizar del siguiente modo: A , alumno que satisface el criterio del centro acerca de lo que éste considera que es un buen rendimiento académico y B , alumno que no cumple con ese estándar. ¿Cuándo se obtendrá evidencia favorable a la interpretación y utilización deseada de esta prueba de admisión? Sencillamente, cuando las decisiones tomadas a partir de las puntuaciones obtenidas en dicho test coincidan con las decisiones que se tomarían en base al criterio del centro. La tabla 7.4 representa esquemáticamente la situación planteada.

TABLA 7.4
Clasificación de los sujetos atendiendo a sus puntuaciones en el test y en el criterio

		Criterio		
		A	B	
Test	A	N_{AA}	N_{AB}	N_{At}
	B	N_{BA}	N_{BB}	N_{Bt}
		N_{Ac}	N_{Bc}	N

El número de alumnos clasificados del mismo modo por el test y por el criterio es $N_{AA} + N_{BB}$. Hay N_{BA} alumnos que deberían haber sido admitidos y, sin embargo, han sido descartados (falsos negativos) y N_{AB} admitidos que no cumplirán con el estándar fijado por el centro (falsos positivos). Como recordará el lector del capítulo anterior, el **coeficiente κ** de Cohen (1960) es una medida del acuerdo de las clasificaciones obtenidas (en este caso, en base a la información procedente del test y del criterio; en el capítulo anterior, en base a las valoraciones de dos jueces distintos o de los resultados obtenidos en dos aplicaciones distintas de la misma prueba al mismo grupo de sujetos) eliminando las coincidencias que se pueden deber simplemente al azar:

$$\kappa = \frac{F_0 - F_e}{N - F_e} \quad (7.12)$$

donde:

F_0 es el número de sujetos clasificados del mismo modo por el test y por el criterio:

$$F_0 = N_{AA} + N_{BB}$$

F_e es el número de coincidencias fortuitas en las clasificaciones realizadas por el test y el criterio:

$$F_e = \frac{N_{At}N_{Ac}}{N} + \frac{N_{Bt}N_{Bc}}{N}$$

N es el número de sujetos por clasificar.

Otro índice que también se suele utilizar en este tipo de estudio de validación es la **razón de eficacia** del test, esto es, la proporción de predicciones correctas del test en el grupo alto del criterio:

$$R.E. = \frac{N_{AA}}{N_{Ac}} \quad (7.13)$$

Taylor y Russell (1939) construyeron unas tablas conocidas como *tablas Taylor-Russell* (tabla C del Anexo) que permiten determinar cuál es la razón de eficacia del test para distintos valores de su coeficiente de validez y para distintos puntos de corte tanto en el test como en el criterio.

Si se modifica el punto de corte utilizado en el test (X_c) para adscribir a los sujetos a las categorías A y B , entonces se modificará el número de sujetos considerados como candidatos a la admisión (N_{At}), cambiará la proporción de sujetos seleccionados con el test, conocida también como

Razón de Selección $\left(R.S. = \frac{N_{At}}{N}\right)$. Si se modifica el punto de corte utili-

zado en el criterio para definir a un sujeto como perteneciente a la categoría A o a la B , entonces se modificará el número de sujetos considerados como idóneos en el criterio (N_{Ac}), cambiará la proporción de sujetos que habría que seleccionar atendiendo al criterio, conocida también

como *Razón de Idoneidad* $\left(R.I. = \frac{N_{Ac}}{N}\right)$. Pues bien, las tablas de Taylor-

Russell proporcionan una estimación de la razón de eficacia de un test para distintos valores de su coeficiente de validez y para distintas razones de selección y de idoneidad.

Ejemplo 7.3

Estime la razón de eficacia del test del ejemplo 7.2 en la muestra de aspirantes, sabiendo que el número total de solicitantes fue 100, la razón de idoneidad en el centro es de 0,30 y el número de alumnos admitidos fue 60.

Para obtener el valor deseado es preciso acudir a las tablas de Taylor-Russell y para ello es necesario conocer el coeficiente de validez del test ($r_{xy} = 0,76$), la razón de idoneidad (R.I. = 0,30) y la razón de selección (R.S. = $60/100 = 0,60$). Con estos tres valores se acude a la tabla C del Anexo y se obtiene un valor para la razón de eficacia de R.E. = 0,47, que significa que el test sólo selecciona al 47% de los alumnos idóneos en este caso.

7.6. LA GENERALIZACIÓN DE LA VALIDEZ

La validación de una prueba se ha caracterizado como un proceso continuo y gradual de acumulación de evidencia o de información que permita interpretar las puntuaciones del test en términos del constructo psicológico para el que fue creada y utilizar dichas puntuaciones para el fin previsto. A lo largo del capítulo se han ido presentando distintos métodos o estrategias destinadas a obtener este tipo de evidencia. El hecho de disponer de un corpus considerable de información acerca de la validación de una prueba puede facilitar en gran medida el trabajo del usuario de tests, ya que si se ha comprobado reiteradamente la utilidad de las puntuaciones de un test para el objetivo que el usuario se plantea ahora en situaciones relativamente similares a la suya en particular, entonces la evidencia recogida hasta la fecha se podría generalizar a la situación específica en la que se encuentra dicho usuario y éste estaría legitimado a interpretar las puntuaciones en términos del constructo en cuestión, sin necesidad de recabar más información. Es decir, es posible e incluso recomendable aplicar la evidencia de validez obtenida en una o más situaciones a otras situaciones similares. En esto consiste justamente la generalización de la validez, en estimar la relación existente entre el test y el criterio en una nueva situación utilizando para ello la información estadística procedente de estudios previos de validación realizados en situaciones parecidas. Una herramienta de indudable valor para ello es el meta-análisis.

Sin embargo, durante mucho tiempo el punto de vista dominante ha sido el de la especificidad situacional de la validez, esto es, se consideraba que la validez era específica de cada situación concreta examinada y, por consiguiente, cada nueva situación exigía la realización de su correspondiente estudio de validación. La explicación hay que buscarla en la gran variabilidad y en los valores habitualmente bajos que tradicional-

mente se han obtenido para los coeficientes de validez. Schmidt y Hunter (1977) y Schmidt, Hunter y Pearlman (1981) demostraron que una buena parte de la variabilidad observada era, sin embargo, un mero artefacto estadístico debido a la falta de fiabilidad del criterio, al tamaño reducido de las muestras y a la frecuente restricción del rango de variación en el ámbito de aplicación de los tests.

En la actualidad, la importancia que este tema está adquiriendo es creciente. Sirva como ilustración el hecho de que las dos últimas ediciones de los *Estándares para la evaluación psicológica y educativa* (AERA, APA y NCME, 1985, 1999) recogen explícitamente esta cuestión, instando a los usuarios de tests a recoger evidencia local de validación únicamente cuando la generalización resulte limitada.

Habitualmente, cuando se habla de generalización de la validez se suele hacer referencia a los estudios de validación basados en la relación del test con otras variables, sobre todo, en los que se predice un criterio. Ahora bien, conviene tener presente que la generalización no solo hace referencia al grado en que la relación test-criterio se puede generalizar o extender a otras poblaciones o situaciones sino también al grado en que las inferencias realizadas a partir del test en términos del constructo medido se pueden generalizar a otras poblaciones o tareas (Messick, 1995).

7.7. PUNTOS BÁSICOS

- La validez es un criterio métrico de calidad que proporciona información acerca de la adecuación de la interpretación de las puntuaciones del test en términos del constructo psicológico que dice medir y de su utilización para el fin previsto.
- No se valida un test sino una interpretación determinada de sus puntuaciones para dar respuesta al objetivo que suscitó su aplicación.
- La especificación clara y detallada del constructo que se desea medir facilita pero no garantiza la interpretación de las puntuaciones del test en términos de dicho constructo.
- La validación de una prueba es responsabilidad conjunta del constructor y del usuario del test.
- Son dos los pasos que hay que dar en el proceso de validación de una prueba: 1) definir de forma clara e inequívoca la interpretación que se desea hacer de las puntuaciones del test en función del objetivo planteado y 2) diseñar un estudio que permita obtener evidencia favorable a dicha interpretación.

- La validación puede considerarse como una investigación, como un proceso científico de contrastación de hipótesis que tiene como resultado la acumulación gradual de evidencia que apoye la interpretación deseada de las puntuaciones de un test.
- Los métodos que permiten obtener información relevante para la validación de una prueba son los relacionados con la estructura interna y el contenido del test y los basados en su relación con otras variables.
- Los métodos relacionados con la estructura interna del test examinan las relaciones existentes entre los ítems del test con el fin de ver empíricamente qué conceptos se pueden utilizar para interpretar la actuación del sujeto en el test y si éstos coinciden con el constructo que en principio dice medir la prueba. La herramienta más utilizada para ello es el análisis factorial: si coinciden los factores obtenidos empíricamente y los postulados teóricamente en la construcción de la prueba se obtiene evidencia favorable a la interpretación de las puntuaciones del test en términos del constructo en cuestión.
- Los métodos relacionados con el contenido del test examinan la adecuación con la que el contenido del test muestrea el dominio acerca del cual se van a realizar las inferencias, se pretende interpretar y utilizar las puntuaciones del test.
- Los métodos basados en la relación con otras variables proporcionan evidencia favorable a una determinada interpretación y utilización de las puntuaciones del test poniendo a prueba hipótesis que relacionan el constructo supuestamente medido por la prueba con otras variables con las que un sistema o modelo teórico predice que están relacionadas. Para comprobar estas hipótesis se puede realizar un estudio experimental o correlacional.
- La MMMMR es la herramienta que tradicionalmente se ha utilizado cuando se realiza un estudio correlacional para explorar la red de relaciones del constructo en cuestión, obteniéndose evidencia favorable a la interpretación en términos de dicho constructo cuando los coeficientes de validez convergente son mayores que los coeficientes de validez discriminante.
- Los métodos basados en la relación con otras variables también pueden someter a prueba una hipótesis predictiva que proporcione información acerca del grado en que las puntuaciones del test están relacionadas o permiten predecir el valor de otra variable de esa red de variables en la que está inserto el constructo medido por el test y que se denomina tradicionalmente *criterio*.

- Los índices que se suelen utilizar para cuantificar los resultados de un estudio de validación predictiva son el coeficiente de validez del test, el de determinación y el error típico de estimación del criterio (cuando test y criterio son variables continuas) y el coeficiente κ y la razón de eficacia del test (cuando ambas son discretas).
- Los factores que influyen en la relación test-criterio son la variabilidad de la muestra del estudio, la longitud del test y la fiabilidad de las medidas obtenidas para el test y el criterio. Cuando test y criterio son variables discretas, influye también el punto de corte adoptado para uno y otro.
- Hay que aplicar la evidencia de validez obtenida en una situación o más situaciones a otras situaciones similares: solo es preciso recoger evidencia local de validación cuando la generalización resulte limitada.

7.8. EJERCICIOS

7.8.1. En el proceso de selección de alumnos en un determinado centro escolar se utiliza, junto con otro tipo de información, una prueba X de nivel de conocimientos formada por ocho preguntas.

El psicólogo de dicho centro decide realizar un estudio de validación para ver hasta qué punto las puntuaciones obtenidas en dicha prueba son capaces o no de predecir adecuadamente el éxito académico de los alumnos. Para ello, una vez finalizado el curso escolar decide solicitar al profesor correspondiente una valoración global del trabajo realizado por dichos alumnos a lo largo del curso.

En la tabla siguiente se encuentran las puntuaciones obtenidas al comienzo del curso por los alumnos en todos los ítems de la prueba y la valoración global dada por el profesor al finalizar el mismo.

SUJETO	X_1	X_2	X_3	X_4	X_5	X_6	X_7	X_8	Y
1	1	1	1	1	1	0	1	0	16
2	1	1	1	0	1	0	1	0	8
3	1	0	1	0	1	0	0	0	10
4	0	1	0	1	0	1	0	0	11
5	0	0	1	0	0	0	0	1	6
6	1	0	0	0	1	0	0	0	8
7	1	1	0	0	1	0	1	0	10
8	1	1	1	0	1	0	1	0	12
9	1	1	1	1	1	1	1	0	10
10	1	1	0	1	1	0	1	1	18

7.8.1.1. Calcule el coeficiente de validez del test.

7.8.1.2. Calcule el error típico de medida del test y el error típico de estimación del criterio.

7.8.1.3. Calcule el error de estimación que se cometería con el sujeto número 6 en el caso de utilizar el modelo de regresión para pronosticar la valoración global dada por el profesor al finalizar el curso.

7.8.1.4. ¿Cuál sería el coeficiente de validez de la prueba si se eliminan por completo los errores de medida del criterio? La fiabilidad inicial del criterio es 0,90.

7.8.1.5. ¿Cuál sería el coeficiente de validez de la prueba si se incrementara su fiabilidad hasta un valor de 0,85?

7.8.1.6. ¿Cuántos ítems habría que añadir a la prueba para que el coeficiente de validez fuera 0,75?

7.8.1.7. La varianza de las puntuaciones obtenidas en la prueba *X* por los 15 alumnos que solicitaron la entrada en el centro escolar fue 4,5. ¿Cuál es el coeficiente de validez de dicha prueba en el grupo de solicitantes?

7.8.1.8. Según el criterio del centro, un alumno con un perfil adecuado debería tener una valoración de su profesor por encima de 10 puntos. ¿Cuál es la razón de eficacia de esta prueba en el proceso de selección del alumnado si la razón de idoneidad es del 60%? ¿Hasta qué punto son consistentes las decisiones tomadas a partir del test y del criterio del centro?

7.8.2. La siguiente matriz presenta las valoraciones dadas por cinco jueces distintos a los ítems de un cuestionario de estilos en la toma de decisión que en principio debe medir tres objetivos diferentes. La tarea de los jueces consistía en estudiar la adecuación del ítem al objetivo y, para ello, lo que tenían que hacer era sencillamente señalar si el ítem medía o no cada uno de los objetivos definidos. La escala utilizada fue una escala de 5 puntos, con los siguientes valores: (1) pobre, (2) regular, (3) bueno, (4) muy bueno y (5) excelente.

ITEM	OBJETIVO 1					OBJETIVO 2					OBJETIVO 3				
	J_1	J_2	J_3	J_4	J_5	J_1	J_2	J_3	J_4	J_5	J_1	J_2	J_3	J_4	J_5
1	2	2	3	3	2	3	4	3	4	4	1	1	2	1	1
2	4	4	5	4	3	1	1	1	3	1	3	3	2	3	4
3	1	1	2	1	3	5	5	5	4	5	4	4	3	4	5
4	2	2	3	2	1	4	4	4	3	4	5	3	4	3	4
5	3	3	2	3	3	2	2	3	1	3	1	2	1	1	1
6	5	4	5	4	5	3	2	3	3	3	4	3	4	4	4
7	3	2	2	2	1	1	1	1	1	2	3	3	3	3	2
8	2	3	2	2	1	4	4	3	4	5	1	2	2	2	3
9	3	2	3	3	3	1	2	1	1	1	4	4	4	3	4
10	3	3	2	3	4	1	1	2	1	1	3	3	2	2	3
11	5	4	5	4	5	4	4	4	3	4	2	2	3	2	1
12	1	1	1	1	2	5	5	4	5	4	5	4	4	4	3
13	2	2	1	2	3	4	3	4	4	4	3	3	3	2	4
14	1	1	3	1	1	2	2	3	1	3	5	3	4	3	4
15	3	3	3	3	4	5	5	4	5	3	2	2	3	2	2
16	5	5	4	5	3	3	3	2	3	3	4	4	3	4	5
17	2	2	2	2	1	5	5	5	5	3	4	4	4	3	5
18	2	1	3	2	2	3	4	3	4	3	2	2	2	1	2
19	5	5	5	4	5	4	4	4	4	3	3	3	2	3	2
20	1	1	1	2	1	2	2	3	2	2	4	3	4	3	4

7.8.2.1. Si sólo se desea trabajar con ítems cuya adecuación al objetivo sea evaluada al menos como buena por el equipo de jueces que participa en el estudio, ¿qué ítems habrá que eliminar de este cuestionario?

7.8.2.2. ¿Qué ítems miden adecuadamente el objetivo 1?, ¿y el objetivo 2?, ¿y el objetivo 3?

7.8.3. El Departamento de Recursos Humanos de una empresa ha llevado a cabo un estudio de validación predictiva de un test de habilidades sociales, obteniendo un coeficiente de validez de 0,32. El criterio utilizado fue la facturación realizada por cada vendedor durante el primer año de su contrato, con un valor para la mediana de 15,2 millones.

La empresa decide contratar a 50 nuevos empleados. El número total de solicitantes triplica el número de puestos ofertados. ¿Cuántos aspirantes al puesto de trabajo podrían lograr una facturación similar a la obtenida por el 50% de los vendedores de la muestra de validación? De éstos, ¿cuántos aspirantes serán rechazados?

7.9. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

7.9.1.1. Para calcular el coeficiente de validez hay que calcular primero las puntuaciones del sujeto en el test (sumando las puntuaciones obtenidas en sus ítems) y aplicar la fórmula (7.1):

SUJETOS	X	Y	X ²	Y ²	XY
1	6	16	36	256	96
2	5	8	25	64	40
3	3	10	9	100	30
4	3	11	9	121	33
5	2	6	4	36	12
6	2	8	4	64	16
7	4	10	16	100	40
8	5	12	25	144	60
9	7	10	49	100	70
10	6	18	36	324	108
TOTAL	43	109	213	1309	505

$$r_{xy} = \frac{10 \times 505 - 43 \times 109}{\sqrt{(10 \times 213 - 43^2)(10 \times 1309 - 109^2)}} = 0,62$$

7.9.1.2. Las fórmulas que hay que aplicar son la (5.3) y la (7.3):

$$s_e = s_x \sqrt{1 - r_{xx}}$$

$$s_{y \cdot x} = s_y \sqrt{1 - r_{xy}^2}$$

$$s_x = \sqrt{\frac{213}{10} - \left(\frac{43}{10}\right)^2} = 1,68$$

$$s_y = \sqrt{\frac{1309}{10} - \left(\frac{109}{10}\right)^2} = 3,48$$

Para calcular el coeficiente de fiabilidad utilizaremos la ecuación KR20 (6.6) al tratarse de ítems dicotómicos:

ÍTEM N.º	p	q	pq
1	0,8	0,2	0,16
2	0,7	0,3	0,21
3	0,6	0,4	0,24
4	0,4	0,6	0,24
5	0,8	0,2	0,16
6	0,2	0,8	0,16
7	0,6	0,4	0,24
8	0,2	0,8	0,16
TOTAL			1,57

$$\alpha = \frac{8}{8-1} \left(1 - \frac{1,57}{1,68^2} \right) = 0,51$$

$$s_e = 1,68 \sqrt{1 - 0,51} = 1,18$$

$$s_{y \cdot x} = 3,48 \sqrt{1 - 0,62^2} = 2,73$$

7.9.1.3. La ecuación que hay que aplicar es la (7.2):

$$Y' = 0,62 \frac{3,48}{1,68} (2 - 4,3) + 10,9 = 7,95$$

$$\bar{X} = \frac{43}{10} = 4,3$$

$$\bar{Y} = \frac{109}{10} = 10,9$$

$$E = 8 - 7,95 = 0,05$$

7.9.1.4. La fórmula que hay que aplicar es la que relaciona la validez con la fiabilidad (7.7) y en el caso que nos ocupa $R_{yy} = 1$, ya que al no haber errores de medida la fiabilidad es perfecta ($R_{yy} = R_{V_y V_y} = 1$):

$$\frac{0,62}{R_{xy}} = \sqrt{\frac{0,51 \times 0,90}{0,51 \times 1}} \Rightarrow R_{xy} = 0,65$$

7.9.1.5. Hay que aplicar también la fórmula anterior:

$$\frac{0,62}{R_{xy}} = \sqrt{\frac{0,51 \times 0,90}{0,85 \times 0,90}} \Rightarrow R_{xy} = 0,80$$

7.9.1.6. La fórmula que hay que aplicar es la que relaciona la longitud con la validez (7.10):

$$0,75 = \frac{0,62}{\sqrt{\frac{1-0,51}{k} + 0,51}} \Rightarrow k = 2,83$$

Según (7.11), $k = n_f/n_i$ por lo que $2,83 = n_f/8$ de donde $n_f = 22,6 \cong 23$. Por consiguiente habría que añadir $(23 - 8) = 15$ ítems a la prueba para conseguir un coeficiente de validez de 0,75.

7.9.1.7. Este apartado plantea una cuestión relativa a la relación entre la validez y la variabilidad de las muestras. Por consiguiente, habrá que aplicar el sistema de ecuaciones (7.6):

$$R_{xy} \frac{S_y}{\sqrt{4,5}} = 0,62 \frac{3,48}{1,68}$$

$$S_y \sqrt{1 - R_{xy}^2} = 3,48 \sqrt{1 - 0,62^2}$$

Tenemos, por tanto, un sistema de dos ecuaciones con dos incógnitas cuya resolución ofrece el valor buscado:

$$R_{xy} = 0,71 \text{ y } S_y = 3,83$$

7.9.1.8. Para responder a estas dos cuestiones conviene disponer la información en una tabla de doble entrada:

		CRITERIO		
		A	B	
TEST	A	4	6	10
	B	5	0	5
		9	6	15

La razón de eficacia es la proporción de predicciones correctas en el grupo alto del criterio. Si examinamos la distribución de frecuencias de Y veremos que de los 10 alumnos seleccionados por el test hay 6 cuya valoración a final de curso es de 10 puntos o menos (N_{AB}) y 4 superan ese valor (N_{AA}). Por otro lado, al ser la razón de idoneidad igual al 60%, tenemos que $N_{AC} = 15 \times 60/100 = 9$. Por tanto, según (7.13) tendremos que $R.E. = 4/9 = 0,44$.

Para determinar la consistencia entre las decisiones tomadas atendiendo al test y al criterio, se aplicará el coeficiente κ (ecuación 7.12):

$$F_0 = 4 + 0 = 4$$

$$F_e = \frac{9 \times 10}{15} + \frac{6 \times 5}{15} = 8$$

$$\kappa = \frac{4 - 8}{15 - 8} = -0,57$$

A la vista de estos datos se puede concluir que apenas existe coincidencia en las decisiones tomadas con el test y con el criterio. De hecho, es mayor el número de coincidencias fortuitas posibles que el realmente obtenido.

7.9.2.1. Si sólo se desea aceptar los items con una valoración media de la adecuación item-objetivo considerada como buena, habrá que calcular la media o la mediana de las valoraciones dadas por cada juez a cada item en relación a cada uno de los objetivos y ver cuáles son inferiores a 3: ésos serán los items que habrá que eliminar del cuestionario. Calculemos la media de esas valoraciones:

ITEM	OBJETIVO 1	OBJETIVO 2	OBJETIVO 3
1	2,4	3,6	1,2
2	4	1,4	3
3	1,6	4,8	4
4	2	3,8	3,8
5	2,8	2,2	1,2
6	4,6	2,8	3,8
7	2	1,2	2,8
8	2	4	2
9	2,8	1,2	3,8
10	3	1,2	2,6

11	4,6	3,8	2
12	1,2	4,6	4
13	2	3,8	3
14	1,4	2,2	3,8
15	3,2	4,4	2,2
16	4,4	2,8	4
17	1,8	4,6	4
18	2	3,4	1,8
19	4,8	3,8	2,6
20	1,2	2,2	3,6

Los únicos ítems que habría que eliminar con seguridad del cuestionario serían los ítems n.º 5 y 7 ya que, de acuerdo con el criterio fijado, no miden ninguno de los tres objetivos que se supone evalúa el cuestionario. Faltaría por ver ahora si los ítems que evalúan cada objetivo coinciden con los postulados en la construcción del test, pero no se dispone de información para ello en el enunciado.

7.9.2.2. A la vista de los resultados obtenidos se puede decir que el objetivo 1 es adecuadamente medido por los ítems 2, 6, 10, 11, 15, 16 y 19; el objetivo 2 es adecuadamente medido por los ítems 1, 3, 4, 8, 11, 12, 13, 15, 17, 18 y 19 y el objetivo 3 es adecuadamente medido por los ítems 2, 3, 4, 6, 9, 12, 13, 14, 16, 17 y 20.

7.9.3. En este problema lo que se pide es averiguar, por un lado, el número total de sujetos en el grupo alto del criterio, el número de aspirantes que podrían obtener una facturación igual o superior a 15,2 millones y, por otro lado, el número de aspirantes que, pudiendo lograr esa facturación anual, serán rechazados por el test.

Los datos de que disponemos para hallar estos dos valores son el coeficiente de validez del test que se utilizará en el proceso de selección ($r_{xy} = 0,32$), la proporción de sujetos en el grupo alto del criterio (R.I.), que viene dada por la proporción de sujetos que facturan al menos 15,2 millones de pesetas (0,50) y la proporción de sujetos en el grupo alto del predictor, la proporción de sujetos que serán finalmente contratados (R.S.), es decir, el número de plazas ofertadas dividido por el número de aspirantes ($50/150 = 0,33$).

Con estos tres valores buscamos el valor correspondiente a la proporción de predicciones correctas en el grupo alto del criterio en las

tablas de Taylor-Russell. Este valor es 0,64, que indica que serán contratados el 64% de los aspirantes que son potencialmente buenos vendedores (de acuerdo con el criterio fijado). El 36% de los solicitantes que son potencialmente buenos vendedores serán rechazados.

Dado que el punto de corte definido en el criterio ha sido la mediana, el número de aspirantes que puede lograr una facturación de 15,2 millones anuales es $150/2 = 75$. De éstos, $75 \times 36/100 = 27$ aspirantes serán rechazados.

7.10. BIBLIOGRAFÍA BÁSICA RECOMENDADA

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulos 12, 13 y 14.

En el capítulo 12 se ofrece un planteamiento general de la cuestión de la validez y los dos restantes se ocupan de la validación predictiva con tests y criterios considerados como variables continuas.

MUÑIZ, J. (1998). *Teoría clásica de los tests*. Madrid: Pirámide. Capítulo 3.

Se ofrece un planteamiento general del tema, más centrado en la validación predictiva y con una referencia expresa a la utilización de variables discretas en estos estudios y a las funciones específicas de selección y clasificación de los tests.

RENOM, J. (1992). *Diseño de tests*. Barcelona: Engine. Capítulo 7.

En este capítulo se realiza una presentación bastante clara de una buena parte de los contenidos expuestos en el capítulo.

SANTISTEBAN, C. (1990). *Psicometría. Teoría y práctica en la construcción de tests*. Madrid: Norma. Capítulo 9.

Se realiza un tratamiento bastante equilibrado de las estrategias de validación predictiva y de las relacionadas con la estructura interna del test.

7.11. LECTURAS SUGERIDAS

Paz, M. D. (1996). Validez. En J. Muñiz (Coord.), *Psicometría*. Madrid: Universitas.

Se trata de un magnífico trabajo que da un tratamiento más detallado a las cuestiones abordadas en el capítulo. Después de examinar la evolución que ha sufrido el concepto de validez en los últimos 50 años, se centra en las estrategias basadas en la estructura interna y en la relación del test con otras variables relevantes, de cara a obtener evidencia favorable al uso e interpre-

tación de las puntuaciones de los tests. Seguidamente se centra en el examen de la validación de las pruebas en los ámbitos en los que son mayormente utilizadas: la selección de personal y el campo educativo.

7.12. MATERIAL COMPLEMENTARIO

La evidencia proporcionada por el análisis factorial.

EVALUACIÓN DE LA CALIDAD MÉTRICA DE LOS ELEMENTOS DEL TEST: ANÁLISIS DE ÍTEMS

Juan Carlos Suárez Falcón

8.1. INTRODUCCIÓN

En los dos capítulos anteriores se han estudiado los dos criterios métricos de la calidad *global* del test: fiabilidad y validez. En este capítulo se estudiará la calidad métrica *individual* de cada uno de los ítems que componen el test en lo que se ha dado en llamar *análisis de ítems*.

La evaluación de la calidad métrica de los elementos o ítems del test nos informa de las características psicométricas de éstos y de su contribución a la medición del constructo o dominio de interés. De este modo, con este análisis se va a disponer de información relevante para decidir qué ítems se van a utilizar para medir el constructo o dominio y qué ítems se deben desechar por su baja calidad. En definitiva, el análisis de ítems es útil para la construcción y mejora de un test y, como tendremos ocasión de comprobar, para maximizar la fiabilidad y validez del test.

En la fase de construcción del test, estudiada en el capítulo 3, se realizó un primer análisis *cualitativo* de los ítems (véase el apartado 3.4.4). Instalados ahora en la fase de evaluación del instrumento de medida, en este capítulo se va a estudiar lo que podría denominarse el análisis *cuantitativo* de los ítems, en el que se estudian las propiedades psicométricas de los ítems con la finalidad de seleccionar los ítems que presentan una mayor calidad técnica.

En particular, este análisis cuantitativo de los ítems consiste en:

1. la estimación de los parámetros de los ítems, esto es, de su dificultad, poder discriminativo, fiabilidad y validez.

Al presentar la ecuación básica de la Teoría de Respuesta al Ítem (TRI) en el capítulo 5 —la función característica del ítem— se introdujeron los tres parámetros del ítem en ese modelo: el parámetro b (dificultad), a (discriminación) y c (pseudoadivinación).

En este capítulo, el análisis de ítems se va a presentar desde el enfoque de la Teoría Clásica de los Tests (TCT).

2. el análisis de las alternativas incorrectas de respuesta, también conocidas como *distractores*, cuando los ítems son de elección múltiple.

Cuando se trabaja con este tipo de preguntas es importante conocer cómo están funcionando todas las opciones de respuesta, no solo la correcta sino también las incorrectas ya que, como tendrá ocasión de comprobar el lector, las propiedades psicométricas de la alternativa correcta se ven afectadas por la calidad de los distractores, por lo que su estudio resulta imprescindible para la revisión y mejora de la calidad de los ítems.

3. el análisis del posible funcionamiento diferencial de algún ítem del test en distintos grupos de sujetos (niños/niñas, payos/gitanos, centros públicos/privados, etc.).

Por ejemplo, es posible que si en una prueba de comprensión lectora se introduce un texto relacionado con el mundo del fútbol y se hacen preguntas relativas a dicho texto, estos ítems funcionen de forma diferente en el grupo de varones y en el de mujeres; previsiblemente, los varones tendrán una probabilidad más alta que las mujeres de responder correctamente a dichos ítems, aun teniendo ambos un nivel similar de comprensión lectora.

En los tres siguientes apartados se detallan cada uno de estos análisis.

Los objetivos que se persiguen en este capítulo son los siguientes:

- conocer y saber evaluar los criterios métricos de calidad de los ítems de un test;
- conocer y saber estimar los parámetros del ítem en la teoría clásica de los tests;
- conocer la influencia y contribución de las propiedades psicométricas de los ítems en la calidad global del test como instrumento de medida;
- comprender la importancia del análisis de los distractores en ítems de elección múltiple;
- conocer y saber evaluar si los ítems de un test funcionan de forma diferente en grupos distintos de sujetos;
- saber distinguir entre funcionamiento diferencial del ítem e impacto.

8.2. PARÁMETROS DEL ÍTEM

Tal como se ha señalado anteriormente, la calidad de un ítem se puede determinar a partir del análisis de su dificultad, el poder discriminativo, la fiabilidad y la validez del ítem. Con el fin de cuantificar estas propiedades del ítem, se han propuesto una serie de estadísticos que permiten estimar estos parámetros, que posibilitan la medida objetiva de estos aspectos.

A continuación se presentan cada uno de estos parámetros y la forma en la que éstos se estiman en la TCT. El lector interesado en los parámetros del ítem en la TRI puede consultar el apartado correspondiente en el Material Complementario del capítulo 5.

8.2.1. Dificultad del ítem

La dificultad del ítem es un aspecto que se establece *a priori* desde consideraciones teóricas en la fase de especificación del test (véase apartado 3.3.4) y que está en función del contenido y de la complejidad de las operaciones demandadas al sujeto para responder correctamente al ítem. Esta dificultad teórica se ha de contrastar empíricamente y se cuantifica a través del análisis de los ítems. La medida empírica de la dificultad informará de los ítems que presentan una dificultad o facilidad extrema y que deben ser revisados o eliminados debido a que no contribuyen a la medida del constructo. Asimismo, en función del uso previsto del test definitivo, la medida de la dificultad del ítem puede ser un criterio relevante en la selección de ítems para el test final.

Se han propuesto diferentes índices para estimar la dificultad del ítem. El más utilizado y sencillo de calcular es el índice p . Según este parámetro, la dificultad de un ítem es la proporción de sujetos que responden correctamente a ese ítem:

$$p = \frac{A}{N} \quad (8.1)$$

donde:

A es el número de sujetos que responden correctamente al ítem;

N es el número de sujetos que responden al ítem.

Normalmente, el valor p de cada ítem se multiplica por 100 para su interpretación. De esta manera, un ítem con $p = 0,60$ significa que el 60 por 100 de los sujetos de la muestra ha respondido correctamente a ese

ítem. Este parámetro oscila entre un valor mínimo de $p = 0$, lo que implica un ítem muy difícil debido a que ningún sujeto lo ha respondido correctamente, y un valor máximo de $p = 1$, tratándose, en este caso, de un ítem muy fácil que ha sido respondido correctamente por todos los sujetos. Los ítems con estos valores extremos ($p = 0$ y $p = 1$) son descartados debido a que no contribuyen a medir las diferencias existentes entre los sujetos (todos los sujetos responden de la misma manera: incorrecta o correctamente).

Ejemplo 8.1

Un test de rendimiento en Lengua formado por ítems dicotómicos se aplica a 10 alumnos. Al primer ítem responden correctamente 6 alumnos e incorrectamente los cuatro restantes. Calcule el índice de dificultad del ítem.

$$p = \frac{A}{N} = \frac{6}{10} = 0,6$$

Probablemente, el lector ya se ha percatado de que este índice solo tiene sentido calcularlo en ítems de pruebas cognitivas (piense en el sinsentido de calcular el índice de dificultad de un ítem de una prueba no cognitiva en la que se mide el modo habitual de sentir o actuar de un sujeto) y de que debería llamarse, en realidad, índice de facilidad debido a que valores altos implican ítems fáciles mientras que valores bajos ítem difíciles. Debido a que, tanto en los textos clásicos como en los modernos de psicometría se le denomina índice de dificultad, aquí se le sigue llamando de esta manera para no crear confusión en el lector que consulte otros textos de esta disciplina.

Una de las características interesantes del parámetro p es que proporciona una medida de dificultad que permite la comparación de ítems que miden diferentes dominios o constructos, aplicados a los mismos sujetos. Por ejemplo, si se aplica un test de Matemáticas y otro de Lengua a una misma muestra de sujetos, se puede perfectamente comparar los valores de p de cualquier ítem de Matemáticas con otro de Lengua y determinar qué ítem resulta más difícil a esos sujetos. Téngase en cuenta que para esta comparación es necesario utilizar la misma muestra de sujetos. Esto se debe a que la dificultad del ítem medida por el valor de p caracteriza tanto al ítem como a la muestra de sujetos a la que se ha aplicado el test. Por lo tanto, si aplicamos un ítem a dos muestras con diferente nivel en la variable medida, vamos a obtener diferentes valores de p para el mismo ítem. Un ejemplo aclarará este punto.

Supóngase que se ha confeccionado un test de inteligencia general y se aplica a dos muestras independientes, una de alumnos de baja inteligencia y otra de superdotados. A continuación se calcula el valor de p de cada ítem para cada muestra de sujetos. Probablemente, los valores de p de los ítems calculados en el grupo de baja inteligencia serán más bajos que los calculados en el grupo de superdotados. Esto se debe a que los ítems resultarán más fáciles a los superdotados que al grupo de baja inteligencia. Por lo tanto, queda patente que un mismo ítem puede dar un valor diferente en p , dependiendo del nivel medio de la muestra a la que se administra el test. En ese sentido, se dice que el índice de dificultad p depende tanto de las características del ítem como de la muestra de sujetos utilizada.

Esta dependencia de los parámetros del ítem de las características de la muestra de sujetos a los que se aplica el test (en definitiva, de los parámetros de los sujetos) solo se verifica en la TCT y constituye una más de las limitaciones de este modelo a las que se hizo ya alusión en el capítulo 5. Por el contrario, una de las características distintivas de la TRI es justamente la invarianza de los parámetros (de los ítems respecto a los de los sujetos y de los sujetos respecto a los de los ítems).

Corrección de la dificultad en ítems de elección

Cuando los ítems presentan un formato de elección múltiple o binaria, los sujetos con muy poca o nula competencia suelen responder al azar y pueden, por tanto, responder correctamente a los ítems. De este modo, el número de aciertos observados en los ítems será mayor que lo esperado según el nivel de competencia de los sujetos. Por lo tanto, al igual que se debe corregir el azar en la puntuación de los sujetos que responden a ítems de elección múltiple (véase capítulo 4), es necesario llevar a cabo una corrección que controle el efecto del azar en el cálculo de la dificultad del ítem. El ajuste del valor de p se realiza de la siguiente manera:

$$p_c = p - p_{\text{azar}} = \frac{A}{N} - \frac{\frac{E}{k-1}}{N} = \frac{A - \frac{E}{k-1}}{N} \quad (8.2)$$

donde:

p_c es la dificultad del ítem corregida;

p es la dificultad del ítem sin corregir;

p_{azar} es la proporción de respuestas correctas al azar;

E es el número de respuestas incorrectas;

k es el número de alternativas del ítem.

Como se puede apreciar, la dificultad del ítem corregida se obtiene restando la proporción de aciertos que se espera por azar (que se calcula teniendo en cuenta el número de alternativas del ítem) a la proporción de aciertos que se ha observado en el ítem.

Téngase en cuenta que la aplicación de la corrección propuesta implica que estamos suponiendo que:

- Existe un subgrupo de sujetos relativamente numeroso que responden correctamente al ítem por pura adivinación.
- Para este grupo de sujetos de máxima incompetencia, todas las alternativas tienen la misma probabilidad de ser elegidas.

Por lo tanto, si no se tiene sospechas evidentes de la existencia de este tipo de personas, conviene aplicar el índice de dificultad inicial sin la corrección, aunque se trate de ítems de elección múltiple.

Ejemplo 8.2

Las respuestas de 500 alumnos a un ítem de comprensión lectora de cuatro alternativas se muestran en la siguiente tabla. Teniendo en cuenta que la alternativa correcta es la D, calcule la dificultad del ítem.

A	B	C	D
5	200	105	190

$$p_c = \frac{A - \frac{E}{k-1}}{N} = \frac{190 - \frac{5 + 200 + 105}{4-1}}{500} = 0,17$$

8.2.2. Discriminación del ítem

La discriminación del ítem es una propiedad psicométrica fundamental. Se considera que un ítem manifiesta poder discriminativo cuando es capaz de diferenciar adecuadamente a los sujetos con diferentes grados en la característica que evalúa la prueba. A diferencia del índice de dificultad, el índice de discriminación se calcula para ítems de pruebas

cognitivas y no cognitivas: un ítem puede discriminar entre sujetos que tienen un rendimiento alto o bajo en un área de conocimiento, entre sujetos introvertidos y extrovertidos, entre sujetos racistas y no racistas, entre sujetos a favor o en contra de la legalización de las drogas, etc.

Un aspecto a tener en cuenta en la evaluación de la calidad métrica de los ítems es la relación que existe entre el poder discriminativo y la dificultad de un ítem. Los ítems muy fáciles (valores p próximos a 1) o ítems muy difíciles (valores p próximos a 0) son ítems que son respondidos de la misma forma por prácticamente todos los sujetos de la muestra. Por lo tanto, estos ítems no discriminan entre los sujetos con diferentes grados del constructo y su índice de discriminación tiende a cero. Por otra parte, ítems con dificultad intermedia, o próximos a ésta ($p = 0,50$), muestran mayor poder discriminativo y, como consecuencia, valores altos en los índices de discriminación.

Se han propuesto numerosos índices o estadísticos para cuantificar o estimar el poder discriminativo de un ítem. A continuación se van a presentar dos tipos de medidas utilizadas con frecuencia en las aplicaciones psicométricas: el índice de discriminación D y un índice basado en la correlación ítem-test $\rho_{i(x-i)}$.

8.2.2.1. *El índice de discriminación D*

El índice de discriminación D se basa en la información que proporciona la comparación de las respuestas al ítem de dos grupos extremos de sujetos formados atendiendo a su puntuación en el test (baja y alta). La idea subyacente es la siguiente. Supongamos que se aplica un test a una muestra de sujetos y se obtiene la puntuación X de cada uno. A partir de X se forman tres grupos de sujetos de baja, media y alta puntuación en X . El poder discriminativo de un ítem se puede medir a través de la comparación del número de sujetos del grupo alto con los del grupo bajo que responden correctamente a ese ítem. Un ítem presentará un buen índice de discriminación si el número de personas que responden correcta o favorablemente al ítem es mayor en el grupo de alta puntuación que en el grupo de baja.

Para el cálculo del índice D , se forman los grupos extremos de baja y alta puntuación, con el 27 por 100 de los sujetos de más baja puntuación y de más alta puntuación en el test. A continuación se calcula el número de respuestas correctas al ítem en cada grupo, siendo D igual a

$$D = \frac{A_{alto} - A_{bajo}}{N_g} \quad (8.3)$$

donde:

A_{alto} , A_{bajo} son el número de sujetos que han respondido correctamente en los grupos alto y bajo, respectivamente;

N_g es el número de sujetos en el grupo con mayor número de personas.

El índice dará valores positivos altos, lo que implicará poder discriminativo del ítem, cuando los sujetos del grupo alto obtengan sustancialmente más respuestas correctas que los sujetos del grupo bajo. Por otra parte, $D = 0$ se obtendría si A_{alto} y A_{bajo} estuviesen muy próximas entre sí, lo que reflejaría que el ítem no discrimina adecuadamente entre los sujetos de diferentes niveles en la variable medida. Por último, un valor negativo en D indicaría, no sólo que el ítem no contribuye a medir la variable de interés, sino que favorece la disminución de la precisión del instrumento de medida. Un índice de discriminación negativo suele darse en ítems que cubren contenidos complejos en los que los sujetos pueden elegir la respuesta correcta sin conocer lo suficiente acerca de la materia evaluada, o en la que los sujetos más competentes manejan más información a la hora de responder que la que se consideró al construir la pregunta o, sencillamente, puede obedecer a un problema de codificación de las categorías de respuesta en un ítem.

En líneas generales, y como referencia para la toma de decisiones sobre el poder discriminativo de los ítems, se ofrece en la tabla 8.1 los posibles resultados del índice D y la interpretación que le daríamos en cada caso.

TABLA 8.1
Valores e interpretación del índice de discriminación D

Índice de Discriminación	Interpretación
$D \geq 0,40$	El ítem presenta gran poder discriminativo
$0,30 \leq D \leq 0,39$	La discriminación del ítem es aceptable
$0,20 \leq D \leq 0,29$	El ítem discrimina poco y necesita una revisión
$0,0 < D \leq 0,19$	El ítem no es adecuado y debe ser modificado sustancialmente o eliminado del test
$D \leq 0,0$	El ítem debe eliminarse directamente

Ejemplo 8.3

En la siguiente tabla se presentan las respuestas de los sujetos de una muestra a un ítem de cuatro alternativas. De los 126 sujetos se seleccionaron el 27 por 100 superior (34 sujetos) y el 27 por 100 inferior (34 sujetos).

Grupo	Alternativas del ítem			
	A	B	C	D
Superior	2	0	26	6
Inferior	2	10	10	12

Sabiendo que la alternativa correcta es la C, calcule el índice D de discriminación del ítem e interprete los resultados.

$$D = \frac{A_{\text{alto}} - A_{\text{bajo}}}{N_g} = \frac{26 - 10}{34} = 0,47$$

Se trata de un ítem con gran poder discriminativo ($D > 0,40$).

8.2.2.2. Índice basado en la correlación ítem-test

El poder discriminativo que presenta un ítem puede medirse a través del grado de asociación entre las respuestas al ítem y las puntuaciones en el test. Si el test y el ítem miden el mismo constructo o dominio, lo esperable es que los sujetos con alta puntuación en el test tiendan a responder correctamente (o en la misma dirección) al ítem, mientras que aquellos con baja puntuación tiendan a responder incorrectamente (o en dirección contraria). De este modo, un buen ítem es aquel que discrimina entre los sujetos que manifiestan un nivel alto y bajo en la variable que mide el test (rendimiento, aptitud, actitud, personalidad, opinión, etc.). En este caso, el índice de discriminación se puede interpretar como índice de homogeneidad porque expresa el grado de semejanza, de relación o asociación entre las respuestas al ítem y el resto de los ítems medidos a través de la puntuación total en el test.

Este grado de asociación se puede evaluar mediante el coeficiente de correlación de Pearson (véase cuadro 6.1) entre las respuestas al ítem y la puntuación en el test.

Sin embargo, debido a que la puntuación del test se ha calculado considerando al ítem bajo estudio, la correlación de Pearson ítem-test no se puede considerar una medida adecuada de la discriminación del ítem, ya que se está correlacionando una variable —la puntuación en el ítem— con otra variable que la contiene —la puntuación en el test—, por lo que el valor obtenido estará artificialmente inflado. El índice de discriminación del ítem sería la correlación entre las puntuaciones en el ítem y las puntuaciones en el test descontando de ésta la puntuación en el ítem bajo estudio ($\rho_{i(x-i)}$). Para calcular este índice se puede proceder de dos formas distintas que conducen a obtener obviamente el mismo valor:

1. calculando una nueva puntuación total en el test sin el ítem en cuestión ($X - I$) y calculando la correlación entre esa nueva puntuación y el ítem bajo estudio:

$$\rho_{i(x-i)} = \frac{N \sum I(X - I) - \sum I \sum (X - I)}{\sqrt{\left[N \sum I^2 - (\sum I)^2 \right] \left[N \sum (X - I)^2 - (\sum (X - I))^2 \right]}} \quad (8.4)$$

donde:

I es la puntuación obtenida en el ítem i ;

X es la puntuación obtenida en el test;

N es el número de sujetos que responden al test.

2. calculando la correlación sin descontar la puntuación y utilizando la siguiente expresión para estimar el poder discriminativo del ítem:

$$\rho_{i(x-i)} = \frac{\rho_{ix} \sigma_x - \sigma_i}{\sqrt{\sigma_i^2 + \sigma_x^2 - 2\rho_{ix} \sigma_i \sigma_x}} \quad (8.5)$$

donde:

ρ_{ix} es la correlación entre las puntuaciones en el ítem i y en el test X ;

σ_i es la desviación típica de las puntuaciones en el ítem i ;

σ_x^2 es la varianza de las puntuaciones en el test.

En principio, los valores del índice de discriminación pueden oscilar entre -1 y $+1$, al no ser este índice más que un coeficiente de correlación. Pero la realidad es que en el análisis de ítems es muy poco probable que este coeficiente sea inferior a $-0,10$ o superior a $0,75$. Por lo tanto, a la

hora de interpretar el valor de este índice en un ítem se debe tener en cuenta este rango empírico.

La ventaja del uso de este indicador es que, a diferencia del índice D , su cálculo permite considerar a todos los sujetos de la muestra, y no sólo el 54 por 100 (el 27 por 100 del grupo alto más el 27 por 100 del grupo bajo) como ocurre con el índice D .

Ejemplo 8.4

Se ha aplicado un test de aptitud numérica, formado por 6 ítems dicotómicos, a una muestra de 6 alumnos de bachillerato. En la siguiente tabla aparecen las respuestas de los sujetos al ítem 5 y su puntuación en el test. Calcule el índice de discriminación de este ítem por los dos procedimientos propuestos.

Alumno	Ítem 5	X
1	1	4
2	1	2
3	1	5
4	0	3
5	1	5
6	0	1

Datos que necesitamos para calcularlo con los dos procedimientos:

Alumno	Ítem 5 (I)	X	X-I	I(X-I)	I ²	(X-I) ²	IX	X ²
1	1	4	3	3	1	9	4	16
2	1	2	1	1	1	1	2	4
3	1	5	4	4	1	16	5	25
4	0	3	3	0	0	9	0	9
5	1	5	4	4	1	16	5	25
6	0	1	1	0	0	1	0	1
Total	4	20	16	12	4	52	16	80

$$1) \quad \hat{p}_{I(X-I)} = \frac{(6 \times 12) - (4 \times 16)}{\sqrt{[6 \times 4 - 4^2][6 \times 52 - 16^2]}} = 0,38$$

$$\begin{aligned}
 2) \quad \hat{\rho}_{ix} &= \frac{(6 \times 16) - (4 \times 20)}{\sqrt{[6 \times 4 - 4^2][6 \times 80 - 20^2]}} = 0,63 \\
 \hat{\rho}_{i(x-i)} &= \frac{0,63 \times 1,49 - 0,47}{\sqrt{2,22 + 0,22 - 2 \times 0,63 \times 1,49 \times 0,47}} = 0,38 \\
 \hat{\sigma}_x^2 &= \frac{80}{6} - \left(\frac{20}{6}\right)^2 = 2,22 \Rightarrow \sigma_x = 1,49 \\
 \hat{\sigma}_i^2 &= \frac{4}{6} - \left(\frac{4}{6}\right)^2 = 0,22 \Rightarrow \sigma_i = 0,47
 \end{aligned}$$

8.2.3. Índice de fiabilidad del ítem

Un aspecto a evaluar en el análisis de los ítems de un test es el grado de precisión o fiabilidad con el que un ítem mide el constructo de interés. Como se recordará, en el caso de la teoría de respuesta al ítem la función de información del ítem es la función que se utiliza para estimar la fiabilidad con la que el ítem mide la característica de interés (véase el apartado 6.3). En la teoría clásica de los tests, se dispone de un índice denominado *Índice de Fiabilidad*, IF, el cual es función de la variabilidad y de la relación entre el ítem y el test. Se calcula de la siguiente manera:

$$IF = \sigma_i \rho_{ix} \quad (8.6)$$

donde:

σ_i es la desviación típica de las puntuaciones en el ítem i

ρ_{ix} es la correlación entre las puntuaciones en el ítem i y en el test.

Ejemplo 8.5

Calcule el índice de fiabilidad del ítem 5 con los datos del ejemplo 8.4.

$$IF = \hat{\sigma}_i \hat{\rho}_{ix} = 0,47 \times 0,63 = 0,30$$

8.2.4. Índice de validez del ítem

Cuando el test se utiliza para pronosticar una variable relacionada con la característica que mide el test, es preciso examinar hasta qué punto cada uno de los ítems del test contribuye a predecir con éxito el criterio o variable de interés. En esta situación es necesario estudiar la validez de cada ítem en relación con dicho criterio con el fin de seleccionar aquellos ítems que maximicen la validez del test.

El *Índice de Validez* de un ítem, IV , indica la contribución del ítem a la validez referida a un criterio externo al test y se define como:

$$IV = \sigma_i \rho_{iy} \quad (8.7)$$

donde:

ρ_{iy} es la correlación entre las puntuaciones en el ítem i y el criterio externo y ;

σ_i es la desviación típica de las puntuaciones en el ítem i .

El índice de validez se define a partir de la variabilidad de las respuestas al ítem, σ_i , y del grado de asociación entre el ítem y la puntuación de los sujetos en la variable externa, ρ_{iy} .

Ejemplo 8.6

Las calificaciones escolares en Matemáticas de los alumnos del ejemplo 8.4 aparecen en la tabla adjunta. Calcule el índice de validez del ítem 5 para predecir la calificación en Matemáticas.

Alumno	Ítem 5 (I)	Y	IY	I ²	Y ²
1	1	7	7	1	49
2	1	4	4	1	16
3	1	6	6	1	36
4	0	5	0	0	25
5	1	8	8	1	64
6	0	3	0	0	9
Total	4	33	25	4	199

$$\hat{\rho}_{iy} = \frac{(6 \times 25) - (4 \times 33)}{\sqrt{[6 \times 4 - 4^2][6 \times 199 - 33^2]}} = 0,62$$

$$IV = \hat{\sigma}_i \hat{\rho}_{iy} = 0,47 \times 0,62 = 0,29$$

8.2.5. Relación de los parámetros del ítem con los parámetros del test

Los parámetros del ítem descritos guardan una estrecha relación con los parámetros del test estudiados en los capítulos anteriores. Por ese motivo, la calidad métrica de los ítems influye directamente en la calidad del test como instrumento fiable y válido de medida.

En el cuadro 8.1 se exponen las propiedades psicométricas del ítem, la forma en la que se definen los parámetros del ítem y la relación de éstos con los parámetros del test. En la primera fila se presenta el parámetro de dificultad del ítem (p y p_c , el índice corregido) y su relación con la media de las puntuaciones en el test (μ), cuyo valor más o menos alto indicará la

CUADRO 8.1
Relación de las propiedades psicométricas del ítem y del test

Propiedades o Parámetros	Definición	Relación con los parámetros del test
Dificultad	$p = \frac{A}{N}$ $p_c = \frac{A - \frac{E}{k-1}}{N}$	$\mu = \sum_{i=1}^n p_i$
Discriminación	$\rho_{i x-\bar{y}}$	$\sigma_x = \sum_{i=1}^n \sigma_i \rho_{ix} = \sum_{i=1}^n \sqrt{p_i q_i} \rho_{ix}$
Fiabilidad	$\sigma_i \rho_{ix}$	$\alpha = \frac{n}{n-1} \left[1 - \frac{\sum_{i=1}^n \sigma_i^2}{\left(\sum_{i=1}^n \sigma_i \rho_{ix} \right)^2} \right]$
Validez	$\sigma_i \rho_{iy}$	$\rho_{xy} = \frac{\sum_{i=1}^n \sigma_i \rho_{iy}}{\sum_{i=1}^n \sigma_i \rho_{ix}}$

facilidad o dificultad relativa de la prueba. Tal como se puede apreciar, la media en el test es igual a la suma de los índices de dificultad de los ítems del test. Por lo tanto, la dificultad de la prueba depende directamente de la dificultad de los ítems que la componen. Esta relación habrá que tenerla en cuenta en la selección de los ítems si, entre nuestros objetivos, figura la construcción de una prueba definitiva con una dificultad media determinada.

En la segunda fila figura el parámetro de discriminación del ítem y su relación con la desviación típica de las puntuaciones en el test, cuyo valor más o menos alto indicará una capacidad mayor o menor de la prueba para discriminar o diferenciar entre sujetos con distinto nivel en la variable medida. La desviación típica de las puntuaciones del test es igual a la suma de las desviaciones típicas de los ítems multiplicadas por la correlación ítem-test. Asimismo, y teniendo en cuenta que la multiplicación de ambos elementos es igual al índice de fiabilidad, la desviación típica del test también es igual a la suma de los índices de fiabilidad de los ítems. Por otra parte, y dado que en ítems dicotómicos la varianza de un ítem es $\sigma_i^2 = pq$, se puede sustituir este resultado en la ecuación y se obtiene la segunda expresión, en la que queda de manifiesto la influencia directa y conjunta de la dificultad y de la discriminación del ítem en la variabilidad de las puntuaciones en el test.

Por último, en la tercera y cuarta filas se exponen las relaciones de los índices de fiabilidad y de validez del ítem con la fiabilidad y la validez del test, respectivamente. Tal como se ha visto, la suma de los índices de fiabilidad de los ítems no es igual a la fiabilidad del test, como podría pensarse en un principio. Su relación con la fiabilidad del test se concreta a través de la varianza del test que figura en el segundo denominador de la fórmula de la fiabilidad del test. Por su parte, la validez del test referida a un criterio externo se puede expresar como la suma de los índices de validez de los ítems dividida por la suma de los índices de fiabilidad de los ítems del test. De nuevo, queda patente la contribución de las propiedades de los ítems tales como la dificultad, la discriminación y la variabilidad de las respuestas a los ítems en las propiedades psicométricas del test.

8.3. ANÁLISIS DE LOS DISTRACTORES

El análisis de las respuestas a las alternativas incorrectas, también denominado *análisis de distractores*, informa sobre la utilidad de cada alternativa incorrecta en el ítem y de su contribución a la calidad del mismo. Debido a que las propiedades psicométricas de la alternativa correc-

ta se ven afectadas por la calidad de los distractores, su estudio resulta imprescindible en la evaluación de la calidad métrica de los ítems. Por ejemplo, si en un ítem de cuatro opciones de respuesta nadie escoge la opción *C* —indicador claro de un funcionamiento anómalo de dicha opción—, la probabilidad de responder correctamente cuando se desconoce la respuesta correcta no será $1/4 = 0,25$ sino $1/3 = 0,33$ y el índice de dificultad estimado para el ítem estará artificialmente inflado (véase la fórmula 8.2).

El análisis de los distractores es útil para determinar la utilidad y eficacia de las alternativas incorrectas en cada ítem. El objetivo de un distractor es atraer la atención de los sujetos con nivel medio o bajo en el constructo, que no conocen lo suficiente para responder correctamente al ítem.

Las alternativas incorrectas se consideran distractores eficaces si cumplen las siguientes condiciones:

1. Son elegidas por un número suficiente de sujetos.
2. Son aproximadamente igual de atractivas para los sujetos: todas las opciones incorrectas de respuesta son escogidas por un número similar de sujetos.
3. El rendimiento medio en el test de los sujetos que escogen cada distractor debe ser inferior al de los sujetos que han elegido la respuesta correcta y a la media del test general con todos los sujetos.
4. Discriminan entre los sujetos de baja, media y alta puntuación en el test, pero en sentido contrario a como lo hace la alternativa correcta, esto es, son elegidas por un porcentaje mayor de sujetos pertenecientes al grupo de baja puntuación en el test frente a los sujetos que escogen dicha opción en el grupo de puntuación alta en el test.

Para estudiar el poder discriminativo de los distractores se pueden utilizar métodos numéricos como los señalados anteriormente para el parámetro de discriminación del ítem. Para cada alternativa incorrecta se puede calcular un índice *D* o un índice basado en la correlación distractor-test. De esta manera, se considerará que un buen distractor es aquel que presenta un poder discriminativo alto, aunque más bajo que el de la respuesta correcta y, preferiblemente, con un valor negativo. Por lo tanto, se deben revisar minuciosamente los ítems con distractores que presentan valores altos y positivos en el poder discriminativo.

Aquellas alternativas que no resultan elegidas por los sujetos deben revisarse, y si no es posible mejorarlas, conviene eliminarlas porque no aportan información y no cumplen la función de distractor.

Ejemplo 8.7

En la tabla siguiente se muestra un ejemplo del análisis de distractores. En las primeras dos filas figuran los dos grupos extremos de puntuación en el test (27 por 100 superior y 27 por 100 inferior de los sujetos) con los sujetos que han elegido cada una de las alternativas del ítem. En las últimas tres filas se muestran los resultados para la proporción de sujetos que responden a cada alternativa (p), la media en el test de los sujetos que han escogido cada alternativa ($\bar{X}$) y el índice de discriminación de cada alternativa (D). La cuestión que se plantea es, ¿funcionan bien los distractores?

		ALTERNATIVAS DEL ÍTEM				
		A*	B	C	D	E
Nivel de aptitud	Superior	65	11	64	32	28
	Inferior	15	30	20	68	67
Parámetros	p	0,30	0,08	0,19	0,21	0,22
	$\bar{X}$	11,1	8,3	13,2	8,9	7,8
	D	0,25	-0,09	0,22	-0,18	-0,195

(Nota: * significa que es la alternativa correcta)

La alternativa B no funciona como un distractor eficaz debido a que no es elegido por un número suficiente de sujetos ($p = 0,08$, es decir, sólo un 8 por 100 de los sujetos eligen esta respuesta). Asimismo, la alternativa C tampoco presenta un rendimiento satisfactorio por dos motivos: (1) la media de las puntuaciones en el test de los sujetos que han elegido esa alternativa es superior a la media de los que optan por la alternativa A, que es la correcta, y (2) el índice de discriminación es positivo, lo que implica que los sujetos con alto nivel tienden a elegir esta alternativa como la correcta. Por último, las alternativas D y E funcionan como buenos distractores porque resultan igualmente atractivos ($p = 0,21$ y $p = 0,22$), sus medias son inferiores a la media de la alternativa correcta y, finalmente, sus índices de discriminación son negativos y ligeramente inferiores a la discriminación en la alternativa A.

8.4. ANÁLISIS DEL FUNCIONAMIENTO DIFERENCIAL DEL ÍTEM

El último paso a realizar en el análisis de los ítems de un test es la evaluación del funcionamiento de cada ítem en los diferentes grupos sociodemográficos que han participado en el estudio. Por este motivo, cabe preguntarse si estos ítems miden de la misma manera a todos los grupos de sujetos a los que se les ha administrado el test. Por ejemplo, imagínese que se ha aplicado un test de rendimiento en Matemáticas de 50 ítems a alumnos de 6.º de educación primaria y, tras la evaluación de la calidad del test y de los ítems, se ha confeccionado una prueba final con 35 ítems con los que se calculan las puntuaciones de los alumnos. Una cuestión que se puede plantear es si factores tales como el contenido elegido para los enunciados de los problemas pueden determinar que las niñas tengan más posibilidades que los niños de responder correctamente a los ítems. Es decir, si factores ajenos a la variable que se pretende medir están afectando a los resultados y lleva a que niños y niñas con el mismo nivel de competencia en Matemáticas obtengan resultados diferentes en los ítems y en la puntuación final en el test. Al igual que se habla aquí de niños y niñas, se podría perfectamente elegir cualquier otra variable sociodemográfica significativa tales como la etnia, la clase social, la edad, la región, etc.

8.4.1. Impacto y funcionamiento diferencial del ítem

Dos conceptos importantes en el análisis de los ítems de un test que conviene diferenciar son el impacto y el funcionamiento diferencial del ítem. Se dice que un ítem presenta impacto cuando existen diferencias en la puntuación media obtenida en ese ítem por dos grupos distintos de sujetos (por ejemplo, hombres y mujeres). Por otra parte, se dice que un ítem presenta funcionamiento diferencial cuando existen diferencias en la puntuación media obtenida en ese ítem por dos grupos distintos de sujetos pero *con el mismo nivel en el rasgo* o característica evaluada por el test (por ejemplo, hombres y mujeres con idéntica aptitud verbal).

La diferencia entre ambos conceptos estriba en que la presencia de impacto implica diferencias reales entre los sujetos de ambos grupos (siguiendo con el ejemplo anterior, los niños y las niñas difieren en su nivel medio de rendimiento en Matemáticas, tienen un rendimiento diferente), mientras la presencia de funcionamiento diferencial indica que hay diferencias en la actuación en el ítem pero que éstas no se deben a diferencias en la variable medida en el test (difiere la actuación

en el ítem de niños y niñas que tienen *idéntico* rendimiento en Matemáticas). Entonces, ¿por qué funciona un ítem de forma diferente en distintos grupos de sujetos? Antes de tratar de responder a esta cuestión veamos un ejemplo de un caso de impacto y otro de funcionamiento diferencial.

Se ha aplicado un test de comprensión lectora a un grupo de niños y niñas de 5.º curso de educación primaria. Asimismo, se ha aplicado a los niños un pequeño cuestionario sobre sus hábitos de lectura en el que se pone de manifiesto que las niñas leen más libros que los niños. Por otra parte, los resultados del test indican que el promedio de comprensión lectora es superior en las niñas que en los niños. Ante estos resultados, ¿se puede afirmar que existe impacto? La respuesta es que, probablemente, debido a que las niñas han estado más expuestas a tareas de comprensión con las lecturas, esto ha hecho que desarrollen en mayor grado su comprensión lectora y que esto se vea reflejado en los resultados del test aplicado. Por lo tanto, las diferencias son reales y se puede afirmar que existe impacto. Para asegurarse de que las diferencias se deben básicamente al entrenamiento recibido por las niñas y no a otros posibles factores, se calculan y comparan las proporciones de respuesta correcta a cada ítem de los niños y niñas que han obtenido la misma puntuación en comprensión lectora. Si no existiese funcionamiento diferencial, los niños y niñas con el mismo nivel de comprensión lectora deberían tener la misma proporción de respuestas correctas en cada uno de los ítems. En tal caso, el ítem presentaría impacto pero funcionaría del mismo modo en niños y niñas.

Un ejemplo en el que puede existir funcionamiento diferencial es el siguiente. Se ha administrado un test de analogías verbales para medir la inteligencia general a una muestra compuesta de estudiantes universitarios y jóvenes que no han finalizado los estudios primarios. Se calculan las medias de ambos grupos y los universitarios superan claramente en promedio a los que no han estudiado. ¿Son más inteligentes, realmente, los estudiantes universitarios que el otro grupo? ¿Existe impacto? En este caso, la respuesta es que no. Los estudiantes universitarios están más acostumbrados a los exámenes de lápiz y papel, conocen mejor los conceptos empleados en los ítems de analogías; en definitiva, han estado más expuestos a las características de la situación y al contenido del test. Eso explicaría que sus puntuaciones medias en el test fuesen diferentes. Sin embargo, para corroborar que las diferencias no son reales, se calcula para cada ítem la proporción de respuestas correctas para los sujetos con el mismo nivel de inteligencia general de cada subgrupo. Probablemente, sujetos igual de inteligentes presenten grandes diferencias en la probabilidad de responder correctamente el ítem (distintas proporciones de respuestas correctas), a favor del grupo universitario. En

este caso, los ítems sí presentan funcionamiento diferencial: la probabilidad de responder correctamente al ítem no depende solo de la inteligencia del sujeto (ahora están igualados en ella) sino de su formación, siendo más alta en sujetos con mayor formación. Tenga en cuenta el alumno que el propósito del test era medir la inteligencia y, para ello, se ha utilizado un test que favorecía a sujetos con mayor formación (al margen de su inteligencia). Si en lugar de un test de inteligencia, desarrollamos una prueba para medir el grado de conocimiento de una serie de conceptos, las diferencias que se pueden encontrar serían válidas, debido a que los universitarios han estado más expuestos que las personas sin estudios a los conceptos. Una cosa es que se conozcan una serie de conceptos y otra bien distinta que se sea más inteligente. Si la prueba pretende medir la inteligencia, las diferencias encontradas no son válidas o reales ya que lo que reflejan son diferencias en la formación, no en la inteligencia. Si la prueba pretende medir conocimientos, las diferencias encontradas son válidas ya que los grupos difieren realmente en su dominio de esos conocimientos.

La explicación de por qué los ítems funcionan de forma diferente en distintos grupos nos remite a lo que en teoría de los tests se conoce como *sesgo* y se plantea de la siguiente manera: Las diferencias entre grupos encontradas en los resultados de tests de aptitudes y rendimiento, ¿reflejan diferencias reales entre los grupos o están causadas por fuentes sistemáticas de variación ajenas al constructo o característica que mide el test? Existe un consenso generalizado en reservar el término *funcionamiento diferencial* para el análisis estadístico de la cuestión y el término *sesgo* para la inferencia acerca de la naturaleza de las diferencias observadas. Por tanto, solo se puede hablar de sesgo cuando sea posible relacionar el funcionamiento diferencial con el constructo que se pretende medir. El sesgo hay que entenderlo consiguientemente en términos de validez de constructo, mientras que el funcionamiento diferencial solo sería un indicador estadístico que revelaría si un ítem funciona o no de la misma forma en distintos grupos de sujetos.

8.4.2. El procedimiento Mantel-Haenszel

Como hemos visto anteriormente, para analizar el funcionamiento diferencial en un ítem se debe comparar el funcionamiento del ítem en los sujetos con el mismo nivel de habilidad de cada grupo establecido. Existen diferentes procedimientos para realizar su estudio. Uno de los más utilizados en la práctica es el que se basa en el estadístico Mantel-Haenszel. Los pasos a seguir en este procedimiento son los siguientes:

1. Seleccionar la variable externa de agrupamiento que se sospeche que pueda estar generando funcionamiento diferencial en ciertos ítems del test. La variable externa debe generar solo dos grupos a comparar: grupo de referencia (GR) y grupo focal (GF). El primero suele coincidir con el grupo mayoritario o socialmente favorecido y es el que teóricamente se beneficia de la presencia de funcionamiento diferencial. El grupo focal, grupo minoritario, es en el que se centra la atención y el que se piensa que resulta perjudicado por la existencia de funcionamiento diferencial.
2. Subdividir a los sujetos de ambos grupos (GR y GF) en función de la puntuación empírica obtenida en el test en subgrupos de habilidad homogénea.
3. Calcular el número de respuestas correctas e incorrectas por cada grupo (GR y GF) y nivel de habilidad k .

	R. Correctas	R. Incorrectas	
Grupo de Referencia (GR)	A_k	B_k	N_R
Grupo Focal (GF)	C_k	D_k	N_F
	N_1	N_0	N_k

4. Estimar la cantidad de funcionamiento diferencial mediante la siguiente expresión:

$$\alpha_{MH} = \frac{\sum_{k=1}^n \frac{A_k D_k}{N_k}}{\sum_{k=1}^n \frac{B_k C_k}{N_k}} \quad (8.8)$$

5. Interpretar el resultado:

Los valores de α_{MH} oscilan entre cero e infinito. Valores mayores que 1 indican que el ítem favorece al grupo de referencia y menores al focal. Si $\alpha_{MH} = 1$ está próximo a este valor, el ítem no presenta funcionamiento diferencial.

Ejemplo 8.8

Con el fin de descartar la posibilidad de funcionamiento diferencial en contra de las niñas en el test A de Álgebra, se llevó a cabo un análisis del funcionamiento diferencial de los ítems mediante el procedimiento Mantel-Haenszel. Por ese motivo, se formaron cuatro grupos de nivel de aptitud a partir de las puntuaciones en el test. En la siguiente tabla se muestra el número de respuestas correctas (C) e incorrectas (I) en el ítem 25 de los niños y de las niñas en función del nivel de competencia. Analice si existe funcionamiento diferencial e interprete el resultado.

	NIÑOS		NIÑAS	
X	C	I	C	I
0-10	1	8	2	8
11-20	13	58	10	50
21-30	30	51	19	84
31-40	69	15	47	35

En este caso la variable externa es el género. El grupo de referencia (GR) está formado por los niños y el grupo focal (GF) por las niñas.

Se han formado cuatro grupos homogéneos de aptitud, que son los que figuran en la tabla adjunta.

Con el fin de calcular los valores implicados en la fórmula de α_{MH} (fórmula 8.7), se han formado cuatro tablas de doble entrada –una para cada nivel de competencia– a partir de la tabla general:

Tabla 1. Grupo I de habilidad ($0 \leq X \leq 10$)

	Correctas	Incorrectas	
Niños (GR)	1	8	
Niñas (GF)	2	8	
			19

Tabla 2. Grupo II de habilidad ($11 \leq X \leq 20$)

	Correctas	Incorrectas	
Niños (GR)	13	58	
Niñas (GF)	10	50	
			131

Tabla 3. Grupo III de habilidad ($21 \leq X \leq 30$)

	Correctas	Incorrectas	
Niños (GR)	30	51	
Niñas (GF)	19	84	
			184

Tabla 4. Grupo IV de habilidad ($31 \leq X \leq 40$)

	Correctas	Incorrectas	
Niños (GR)	69	15	
Niñas (GF)	47	35	
			166

Grupo de aptitud	Términos de la expresión			
	$A_k D_k$	$\frac{A_k D_k}{N_k}$	$B_k C_k$	$\frac{B_k C_k}{N_k}$
I	$1 \times 8 = 8$	$8 / 19 = 0,42$	$8 \times 2 = 16$	$16 / 19 = 0,84$
II	$13 \times 50 = 650$	$650 / 131 = 4,96$	$58 \times 10 = 580$	$580 / 131 = 4,43$
III	$30 \times 84 = 2520$	$2520 / 184 = 13,70$	$51 \times 19 = 969$	$969 / 184 = 5,26$
IV	$69 \times 35 = 2415$	$2415 / 166 = 14,55$	$15 \times 47 = 705$	$705 / 166 = 4,25$
Total		33,63		14,78

$$\alpha_{MH} = \frac{\sum_{k=1}^n \frac{A_k D_k}{N_k}}{\sum_{k=1}^n \frac{B_k C_k}{N_k}} = \frac{33,63}{14,78} = 2,28$$

Dado que $\alpha_{MH} = 2,28$, podemos concluir que existe funcionamiento diferencial que beneficia al grupo de referencia, es decir, favorece a los niños y perjudica a las niñas.

8.5. PUNTOS BÁSICOS

- El análisis de ítems consiste en la:
 - Estimación de los parámetros del ítem:
 - la dificultad;
 - la discriminación;
 - la validez;
 - la fiabilidad.
 - Estudio de las respuestas a los distractores.
 - Estudio del funcionamiento diferencial de los ítems.
- La dificultad del ítem se puede medir a través del índice p de dificultad que es igual a la proporción de respuestas correctas en el ítem. Los ítems con valores extremos en p se retiran del test debido a que no aportan información y se consideran de muy poca calidad psicométrica.
- La discriminación del ítem indica la capacidad del ítem para distinguir entre sujetos de diferentes niveles en la característica evaluada por el test, midiendo ésta a través de la puntuación en el test. Existen numerosos índices para medir esta propiedad, siendo los más usuales el índice D y el índice basado en la correlación ítem-test.
- Los índices de fiabilidad y validez de un ítem proporcionan información acerca de la precisión con la que el ítem contribuye a la medida del constructo y sobre la capacidad del ítem para pronosticar un criterio externo, respectivamente.
- El análisis de los distractores ofrece información que complementa a la proporcionada por las respuestas a la alternativa correcta.
- Cuando existen sospechas acerca de un posible sesgo en los ítems que puede favorecer más a un grupo de sujetos que a otro, conviene llevar a cabo un estudio del funcionamiento diferencial del ítem.
- Un ítem presenta funcionamiento diferencial cuando observamos que la probabilidad de responder correctamente a un ítem es mayor en un grupo que en otro en sujetos con el mismo nivel de habilidad.
- Un ítem presenta impacto cuando se aprecian diferencias en las puntuaciones medias de los dos grupos. A diferencia del funcio-

namiento diferencial, el impacto indica que las diferencias son reales entre ambos grupos y que sujetos con el mismo nivel en la característica evaluada obtienen las mismas probabilidades de responder correctamente al ítem.

- El procedimiento Mantel-Haenszel permite identificar la presencia de funcionamiento diferencial en ítems dicotómicos.
- Se puede considerar que un ítem presenta calidad psicométrica cuando:
 - no presenta valores extremos de dificultad ($p = 0$ o $p = 1$);
 - muestra un poder discriminativo alto;
 - contribuye a la fiabilidad del test;
 - contribuye a la validez del test referida a un criterio;
 - las alternativas incorrectas son distractores eficaces;
 - no presenta funcionamiento diferencial.

8.6. EJERCICIOS

8.6.1. Se han aplicado dos tests —A y B— que miden conocimientos en Álgebra (resolución de ecuaciones algebraicas) a una muestra de 500 alumnos de 4.º de ESO. El test A está formado por 40 ítems de construcción, es decir, cada ítem se compone de una ecuación que el alumno debe resolver. En el test B, también de 40 ítems, se presentan las mismas ecuaciones y en el mismo orden de presentación pero, a diferencia del anterior, en cada ítem se le presentan cuatro posibles resultados numéricos de la ecuación y el alumno debe elegir el que considera correcto. Todos los alumnos responden a las 40 preguntas de la prueba. En la siguiente tabla se presenta el número de respuestas correctas dadas en los cinco primeros ítems de cada test.

	ÍTEMS				
	IT01	IT02	IT03	IT04	IT05
TEST A	325	355	105	207	275
TEST B	335	362	190	225	305

Calcule la dificultad de los ítems y ordénelos de menor a mayor dificultad en cada test.

8.6.2. En el test A del ejercicio anterior se decidió utilizar el índice D para evaluar el poder discriminativo de los ítems que ocupaban las posiciones 6, 7, 8, 9 y 10 en el test. Para ello los alumnos se agruparon en función de la puntuación en el test en tres grupos: nivel superior, medio y bajo de rendimiento en Álgebra. El grupo superior estaba formado por 135 alumnos, el de nivel medio por 230 y el inferior por 135 alumnos. El número de respuestas correctas (C) e incorrectas (I) de cada grupo a los cinco ítems se muestran en la tabla adjunta.

GRUPO	ÍTEMS									
	IT06		IT07		IT08		IT09		IT10	
	C	I	C	I	C	I	C	I	C	I
SUPERIOR	130	5	110	25	70	65	135	0	115	20
MEDIO	100	130	115	115	90	140	160	70	97	133
INFERIOR	50	85	45	90	74	61	80	55	108	27

Calcule el índice de discriminación de cada ítem, interprete los resultados e indique qué tres ítems seleccionaría para una futura prueba de Álgebra.

8.6.3. En la tabla siguiente se muestran las distribuciones de frecuencias de las respuestas de 500 alumnos a cuatro ítems de elección múltiple con cuatro alternativas que miden el rendimiento en Matemáticas. La alternativa correcta de cada ítem está indicada con un asterisco (*).

Ítem	Alternativas			
	A	B	C	D
1	5	200	105	190*
2	64	250*	80	106
3	5	492*	0	3
4	50	65	350*	35

Calcule la dificultad de cada ítem tanto la corregida como la no corregida y ordénelos de menor a mayor dificultad en función de p y p_c .

8.6.4. En la siguiente tabla se presentan las respuestas de los sujetos de una muestra a un ítem de cuatro alternativas. Los 63 sujetos de la muestra se dividieron en función de la puntuación en el test en tres grupos: grupo superior (el 27 por 100, 17 sujetos), grupo medio de aptitud (el 46 por 100, 29 sujetos) y grupo inferior (el 27 por 100, 17 sujetos).

Grupo	Alternativas del ítem			
	A	B	C*	D
Superior	1	0	13	3
Medio	3	4	10	12
Inferior	2	5	5	5

Nota: * = alternativa correcta.

Calcule el índice de dificultad y el índice D de discriminación del ítem. Interprete los resultados.

8.6.5. En la siguiente tabla se presentan algunos resultados del análisis del primer ítem de un test compuesto por ítems dicotómicos aplicado a una muestra de alumnos de bachillerato. En la primera columna se muestran la dificultad del ítem y la correlación del ítem con el test. En la segunda columna aparecen la media y la varianza de las puntuaciones en el test. Calcule el índice de discriminación del ítem.

ÍTEM	TEST
$p = 0,75$	$\hat{\mu} = 3,25$
$\hat{\rho}_{ix} = 0,62$	$\hat{\sigma}_x^2 = 5,07$

8.6.6. En la tabla que se presenta a continuación se muestran parte de los resultados obtenidos en la evaluación de la calidad psicométrica de diez ítems del test A de Álgebra. En las columnas aparecen para cada ítem, de izquierda a derecha, el nombre, la desviación típica y la correlación entre las puntuaciones en el test y en dicho ítem.

ÍTEM	$\hat{\sigma}_i$	$\hat{\rho}_{ix}$
IT11	0,46	0,55
IT12	0,17	0,07
IT13	0,40	0,10
IT14	0,50	0,64
IT15	0,50	0,70
IT16	0,45	0,43
IT17	0,43	0,25
IT18	0,46	0,40
IT19	0,45	0,35
IT20	0,47	0,52

8.6.6.1. Indique qué dos ítems presentan una capacidad discriminativa muy baja y conviene eliminar en un primer análisis. Razone su respuesta.

8.6.6.2. Calcule los índices de fiabilidad de los ocho ítems restantes.

8.6.6.3. ¿Cuál será la fiabilidad de una subescala formada por los ocho ítems?

8.6.7. Se ha aplicado un test de fluidez verbal a una muestra de alumnos de 2.º de ESO con el fin de disponer de un instrumento válido para predecir las calificaciones de los alumnos en la asignatura de Lengua. En la tabla adjunta figuran las desviaciones típicas de los seis primeros ítems así como la correlación de cada ítem con las calificaciones en Lengua obtenidas al finalizar el curso y con las puntuaciones en el test. Calcule el índice de validez, fiabilidad y discriminación de cada ítem y seleccione a los tres ítems que mayor grado de validez presentan para predecir la calificación en Lengua.

ÍTEM	$\hat{\sigma}_i$	$\hat{\rho}_{iy}$	$\hat{\rho}_{ix}$
IT01	0,47	0,46	0,52
IT02	0,46	0,31	0,48
IT03	0,88	0,53	0,60
IT04	0,52	0,52	0,55
IT05	0,50	0,39	0,40
IT06	0,45	0,38	0,45

8.7. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

8.7.1. Los ítems del test A son de construcción, por lo que podemos estimar la dificultad de los ítems mediante la siguiente fórmula:

$$p = \frac{A}{N}$$

Los ítems del test B son de elección múltiple con cuatro alternativas, por lo que aplicamos el índice de dificultad corregido:

$$p_c = \frac{A - \frac{E}{k-1}}{N}$$

donde k es igual a 4 y N es igual a 500.

Los resultados aparecen en la siguiente tabla:

	Dificultad de los ítems				
	IT01	IT02	IT03	IT04	IT05
Test A	0,65	0,71	0,21	0,41	0,55
Test B	0,56	0,63	0,17	0,27	0,48

La ordenación de los ítems de menor a mayor dificultad sería la siguiente:

Test A: IT02, IT01, IT05, IT04, IT03

Test B: IT02, IT01, IT05, IT04, IT03

8.7.2. Para el cálculo del índice D utilizamos la fórmula:

$$D = \frac{A_{\text{alto}} - A_{\text{bajo}}}{N_g}$$

Los resultados se muestran en la tabla.

Ítems	A _{alto}	A _{bajo}	N _g	D
IT06	130	50	135	0,59
IT07	110	45	135	0,48
IT08	70	74	135	-0,03
IT09	135	80	135	0,41
IT10	115	108	135	0,05

Los ítems IT06, IT07 y IT09 muestran un alto poder discriminativo.

Los ítems IT10 y IT08 presentan muy baja capacidad de discriminación: son respondidos correctamente prácticamente por los mismos sujetos en el grupo de alto y bajo rendimiento.

Claramente, se deben seleccionar los ítems IT06, IT07 y IT09 para la prueba de Álgebra.

8.7.3. Para el cálculo de los índices de dificultad utilizamos las expresiones siguientes:

$$p = \frac{A}{N}$$

$$p_c = \frac{A - \frac{E}{k-1}}{N}$$

ÍTEM	A (aciertos)	E (errores)	<i>p</i>	<i>p_c</i>
1	190	310	0,38	0,17
2	250	250	0,50	0,33
3	492	8	0,98	0,98
4	350	150	0,70	0,60

La ordenación de los ítems de menor a mayor dificultad sería: 3, 4, 2 y 1.

El alumno puede observar como la diferencia entre *p* y *p_c* es mayor en los ítems de mayor dificultad y menor en los ítems más fáciles. Esto se debe a que se supone que en los ítems fáciles no hay tanto grado de adi-

vinación al azar y, por lo tanto, la corrección a realizar debe ser menor. Sin embargo, en los ítems más difíciles (ítems 1 y 2) la corrección es mayor y, como consecuencia, la diferencia entre ambos índices es mayor debido a que supuestamente la adivinación por azar es también mayor.

8.7.4. Para el cálculo de la dificultad, dado que se trata de un ítem de elección múltiple, debemos aplicar la p corregida y considerar la información proporcionada en los tres grupos:

$$p_c = \frac{A - \frac{E}{k-1}}{N} = \frac{28 - \frac{35}{3}}{63} = 0,26$$

Para el cálculo de la discriminación, se utiliza la información de los grupos inferior y superior:

$$D = \frac{A_{\text{alto}} - A_{\text{bajo}}}{N_g} = \frac{13 - 5}{17} = 0,47$$

Se trata de un ítem relativamente difícil con gran poder discriminativo ($D > 0,40$).

8.7.5. Con los datos que proporciona el enunciado del problema, la discriminación del ítem se puede calcular con la expresión:

$$\rho_{i(x-i)} = \frac{\rho_{ix}\sigma_x - \sigma_i}{\sqrt{\sigma_i^2 + \sigma_x^2 - 2\rho_{ix}\sigma_i\sigma_x}}$$

El único dato que se necesita es la desviación típica del ítem. En este caso, al tratarse de ítems dicotómicos la varianza del ítem es:

$$\hat{\sigma}_i^2 = pq = p(1-p) = 0,75 \times (1-0,75) = 0,19$$

Por lo tanto, $\hat{\sigma}_i = \sqrt{0,19} = 0,44$ y $\hat{\sigma}_x = \sqrt{5,07} = 2,25$

La discriminación del ítem es:

$$\begin{aligned} \hat{\rho}_{i(x-i)} &= \frac{\hat{\rho}_{ix}\hat{\sigma}_x - \hat{\sigma}_i}{\sqrt{\hat{\sigma}_i^2 + \hat{\sigma}_x^2 - 2\hat{\rho}_{ix}\hat{\sigma}_i\hat{\sigma}_x}} = \\ &= \frac{0,62 \times 2,25 - 0,44}{\sqrt{0,19 + 5,07 - (2 \times 0,62 \times 0,44 \times 2,25)}} = \frac{0,96}{2,01} = 0,48 \end{aligned}$$

8.7.6.1. Para examinar la capacidad discriminativa de los ítems hay que calcular el índice de discriminación basado en la correlación ítem-test.

$$\rho_{i(x-i)} = \frac{\rho_{ix}\sigma_x - \sigma_i}{\sqrt{\sigma_i^2 + \sigma_x^2 - 2\rho_{ix}\sigma_i\sigma_x}}$$

La aplicación de esta fórmula es directa, ya que disponemos de todos los datos necesarios para ello, a excepción de σ_x , que no la conocemos pero sí podemos estimarla aplicando la fórmula que relaciona la discriminación de los ítems con la del test (véase cuadro 8.1).

$$\sigma_x = \sum_{i=1}^n \sigma_i \rho_{ix} = 1,98 \rightarrow \sigma_x^2 = 3,92$$

ÍTEM	$\hat{\sigma}_i$	$\hat{\rho}_{ix}$	$\hat{\rho}_{i(x-i)}$
IT11	0,46	0,55	0,35
IT12	0,17	0,07	-0,02
IT13	0,40	0,10	-0,10
IT14	0,50	0,64	0,45
IT15	0,50	0,70	0,53
IT16	0,45	0,43	0,22
IT17	0,43	0,52	0,33
IT18	0,46	0,40	0,18
IT19	0,45	0,35	0,13
IT20	0,47	0,52	0,31

A primera vista se observa que los ítems IT12 e IT13 presentan los índices de discriminación más bajos, próximos a cero (lo que indica que no tienen poder discriminativo) y con valor negativo (lo que implica que están funcionando en sentido contrario al esperado). Por este motivo, podríamos considerar la posibilidad de eliminar esos dos ítems.

8.7.6.2. Para el cálculo del índice de fiabilidad de los ítems utilizamos la siguiente expresión:

$$IF = \hat{\sigma}_i \hat{\rho}_{ix}$$

En la siguiente tabla se muestran los resultados con los ocho ítems restantes.

ÍTEM	$\hat{\sigma}_i$	$\hat{\rho}_{ix}$	IF
IT11	0,46	0,55	0,25
IT14	0,50	0,64	0,32
IT15	0,50	0,70	0,35
IT16	0,45	0,43	0,19
IT17	0,43	0,52	0,22
IT18	0,46	0,40	0,18
IT19	0,45	0,35	0,16
IT20	0,47	0,52	0,24

8.7.6.3. Para calcular la fiabilidad de la subescala podemos aplicar la siguiente expresión:

$$\alpha = \frac{n}{n-1} \left[1 - \frac{\sum_{i=1}^n \sigma_i^2}{\left(\sum_{i=1}^n IF_i \right)^2} \right]$$

En la tabla se calculan las sumas necesarias para obtener el coeficiente.

ÍTEM	$\hat{\sigma}_i^2$	IF
IT11	0,21	0,25
IT14	0,25	0,32
IT15	0,25	0,35
IT16	0,20	0,19
IT17	0,18	0,22
IT18	0,21	0,18
IT19	0,20	0,16
IT20	0,22	0,24
Total	1,72	1,93

$$\alpha = \frac{8}{7} \left[1 - \frac{1,72}{(1,93)^2} \right] = 0,62$$

8.7.7. Para el cálculo de los índices solicitados, utilizamos las siguientes expresiones:

$$IV = \sigma_i \rho_{iy}$$

$$IF = \sigma_i \rho_{ix}$$

$$\rho_{i(x-i)} = \frac{\rho_{ix} \sigma_x - \sigma_i}{\sqrt{\sigma_i^2 + \sigma_x^2 - 2\rho_{ix} \sigma_i \sigma_x}}$$

Los resultados se muestran en la siguiente tabla:

ÍTEM	IV	IF	$\rho_{i(x-i)}$
IT01	0,22	0,24	0,27
IT02	0,14	0,22	0,23
IT03	0,47	0,53	0,09
IT04	0,27	0,29	0,28
IT05	0,20	0,20	0,11
IT06	0,17	0,20	0,20
		$\Sigma = \sigma_x = 1,68$	

Los ítems a seleccionar, en función del índice de validez, serían en este orden: IT03, IT04 y IT01.

8.8. BIBLIOGRAFÍA BÁSICA RECOMENDADA

En castellano se han publicado algunos libros de texto de psicometría que abordan el análisis de ítems de una manera acertada y que recomendamos a los alumnos. La consulta de estos capítulos puede resultar muy útil a aquellos alumnos que necesiten ampliar sus conocimientos sobre el análisis de ítems. Las publicaciones por orden alfabético son las siguientes:

MARTÍNEZ ARIAS, M. R. (1995). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis. Capítulo 18.

MUÑOZ, J. (1998). *Teoría Clásica de los Tests*. Madrid: Pirámide. Capítulo 4.

MUÑOZ, J., FIDALGO, A. M., GARCÍA-CUETO, E., MARTÍNEZ, R. y MORENO, R. (2005). *Análisis de ítems. Cuadernos de Estadística n.º 30*. Madrid: La muralla. Capítulo 3.

SANTISTEBAN, C. (1990). *Psicometría*. Madrid: Norma. Capítulo 15.

8.9. LECTURAS SUGERIDAS

Las lecturas que consideramos más apropiadas para el alumno de Psicopedagogía son una serie de informes de evaluación educativa, publicados por el Instituto Nacional de Calidad y Evaluación (INCE). Estos informes presentan resultados de varios estudios nacionales e internacionales sobre la calidad del sistema educativo. Normalmente, estas publicaciones incluyen un capítulo en el que se describe el análisis de ítems y de las pruebas de rendimiento realizadas, así como un apéndice metodológico en el que detallan los aspectos técnicos del análisis estadístico. La lectura de ambas secciones es una manera interesante de familiarizarse con aplicaciones reales del análisis de ítems al campo educativo. Los informes se pueden consultar a través de internet en la dirección: <http://www.ince.mec.es/pub/index.htm>. A continuación se proporciona una relación de los informes que más información acerca del análisis de ítems ofrecen a los lectores:

- Resultados Españoles de Matemáticas en el TIMSS.
- Resultados Españoles de Ciencias en el TIMSS.
- Evaluación de la Educación Primaria (año 1995).
- Evaluación de la Educación Primaria. Datos básicos. Año 1999 (INCE, 2000).
- Evaluación de la Enseñanza y el Aprendizaje de la Lengua Inglesa.

8.10. MATERIAL COMPLEMENTARIO

Otros coeficientes de correlación.

Parte III
MÉTODOS DE INVESTIGACIÓN

METODOLOGÍA EXPERIMENTAL Y CUASI EXPERIMENTAL

Ángel M. Fidalgo Aliste

9.1. DIOSSES, FILOSOFÍA Y EXPERIMENTACIÓN

DIS.DEABVSQUE
QVOS IVSFASQVE EST
PRECARI IN PANTHEO
PAEL.P.F. HILARIANVS
PROC. AVG CVMLIBERIS
PRO SALVTE
AVG

A todos los dioses y las diosas
a los que es de derecho y lícito
invocar en el Panteón.
Publio Aelio, hijo de Publio Hilariano,
procurador de Augusto con sus hijos.
Por la salud de [Commodo]
Augusto [Pío Feliz]

En el «Museo de los Caminos» de Astorga podrán encontrar la estela prismática de mármol blanco en la que el procurador augustal P. Aelio Hilariano pide, junto con sus hijos, a todas las deidades masculinas y femeninas que se pueden invocar dentro del Panteón romano por la salud del emperador Commodo (183-192 d.C.). Esta inscripción votiva, así como los diferentes cultos y rituales de la religión romana, son formas de proceder que buscan acomodar la voluntad de los dioses a los deseos de los dedicantes, ya que como señala Cicerón «todo el mundo y cuanto en él se contiene, se gobierna y administra por la voluntad de los dioses». La citada estela es pues una especie de contrato pétreo entre el dedicante y los dioses invocados, que incluye además de a los dioses mayores como Júpiter, Juno o Minerva, por citar a la triada capitolina, también a los dioses de menor rango como los genios, lares, manes y ninfas, a los dioses locales de origen prerrománico y a dioses orientales como Osiris, Isis o Mitra. Tal multitud de dioses no es azarosa sino que responde a la relación estrictamente funcional o comercial que el romano establece con sus deidades, multiplicando y especificando tantos dioses como necesidades pueda tener. Pero además, y esto es lo realmente importante para el asunto que nos ocupa, en la antigüedad estos y otros dioses sirvieron como explicación de ciertos fenómenos naturales, sociales y psicológicos.

Según la antigua mitología griega en el principio del mundo la naturaleza era caos, hasta que un dios introdujo el orden. Los romanos atribuían los rayos y las tempestades a la ira de Júpiter, en tanto las sacudidas de tierra y los temblores eran provocados por Neptuno. En el antiguo testamento, por cambiar a la cultura semítica, la lepra, la epilepsia y ciertos trastornos mentales, entre otros padecimientos, eran fruto del pecado, esto es, de la violación de la voluntad de Yahvé. Los dioses, pues, tienen una función clarificadora, explican lo que en el mundo ha ocurrido y lo que ocurre y lo que ocurrirá. Además, los dioses también cumplen una función netamente práctica: mediante los rituales y las oraciones nos ofrecen la posibilidad de prever y controlar el futuro.

En el mundo antiguo las explicaciones mitológicas de los fenómenos naturales son las más comunes, pero no son las únicas. En el siglo VI a.C. surge en Grecia con los presocráticos el pensamiento filosófico que intenta explicar el mundo en términos racionales utilizando como armas de desentrañamiento la inteligencia y la reflexión. A la hora de evaluar la explicación de los fenómenos, dicho pensamiento da orden de prioridad al criterio de racionalidad frente a la tradición y a la revelación. De esta forma se desliga de las doctrinas religiosas, que en el caso de las religiones griegas y romanas consiste en creencias que se fundamentan en la transmisión de los mayores, o en la religión judía en principios dogmáticos revelados por una voluntad superior. Otra de las características del pensamiento filosófico es su naturaleza eminentemente especulativa. Por contra, en el siglo XVII se consolida una nueva forma de investigación de la realidad, la ciencia, que utilizará la experimentación como instrumento privilegiado de sus juicios. El objetivo de esta nueva forma de conocimiento no es nuevo ni exclusivo de ella, busca comprender, habitualmente en términos explicativos, lo que en el mundo ha acontecido, acontece y acontecerá. ¿Verdad que eso les sueña? Lo que sí es característico de la ciencia es la obtención de los conocimientos mediante la aplicación de ciertos recursos metodológicos de carácter general (formulación de hipótesis, replicación, control, etc.) que garantizan su validez, aunque ésta sea siempre temporal y sometida a continua revisión.

Esta forma de indagar la realidad denominada *ciencia* se ha ido imponiendo en las parcelas más diversas del conocimiento hasta llegar a convertirse en un rasgo distintivo del mundo moderno. Y si esta forma de conocimiento se ha impuesto con rotundidad a las demás desde hace más de 200 años, es simplemente porque proporciona un mayor control de los fenómenos que las otras estrategias: se curan mejor las infecciones utilizando penicilina que invocando a Esculapio. Como siempre, los resultados actúan como mecanismo de selección y, como siempre, ha sido la experiencia la vía de contrastación de los diferentes resultados (cuando

Germánico muere, hace 1.981 años, el pueblo romano se ensaña contra las estatuas de los dioses a los que había orado y hecho ofrendas por su salvación). Sin embargo ha sido el pensamiento científico el que ha dado carta de validez a la comprobación de los conocimientos de forma empírica. De hecho, una de las acepciones de la palabra experimento es «acción y efecto de experimentar», que no es más que probar y examinar en la práctica la virtud y propiedades de una cosa.

Una peculiaridad más del mundo moderno es haber convertido, gracias a la ciencia, lo inverosímil en cotidiano. Si lo pensamos detenidamente, el hecho de que gran parte de las actividades que realizamos a diario dependan de una fuerza misteriosa que circula por hilos de cobre, o que al apretar un botón se encienda una luz, o que en una caja rectangular aparezcan imágenes y sonidos de personas que están a miles de kilómetros, parece cosa de magia. Cada vez son más y más el número de cosas que, paradójicamente, hacemos funcionar desconociendo absolutamente su funcionamiento, convirtiéndonos, por mor de la ciencia y de los avances tecnológicos, en unos «salvajes dentro de la civilización». Un fenómeno similar se produce respecto de los conocimientos científicos que se transmiten a los estudiantes universitarios. Cuántas teorías, cuántas hipótesis, cuántas explicaciones, todas supuestamente ciertas, se presentan como caídas de un árbol. ¿Cómo surgen? ¿En qué se fundamenta su veracidad? ¿Cómo podemos valorar si lo que se nos dice es cierto? Rara vez se informa de ello. Por este motivo no está de más advertir que buena parte de los contenidos que se ofrecen en las diferentes licenciaturas, diplomaturas y estudios diversos, han sido conseguidos utilizando como recurso de investigación la metodología experimental y la cuasi experimental. El presente capítulo pretende ofrecer una visión general de ambas estrategias de investigación, de forma tal que los conocimientos transmitidos al alumno le permitan una valoración crítica de los informes de investigación, propios o ajenos, que le posibilite discernir la validez y las limitaciones de los enunciados científicos comprendidos en ellos. Un aviso más, en el poco espacio disponible interesa más al autor que se comprenda la lógica clara y precisa, los principios reguladores y las posibilidades y limitaciones de la metodología experimental y cuasi experimental, antes que un catálogo extenso, vacío y muerto, de diseños experimentales y cuasi experimentales.

Investigar es un ejercicio de la inteligencia, y esto es lo único que se requiere para seguir esta empresa paso a paso, entendiendo y encadenando concepto tras concepto, hasta el final.

9.2. DIEZ CONCEPTOS BÁSICOS MÁS UN EJEMPLO

La explicación de los distintos fenómenos que ocurren en el mundo habitualmente es una explicación en términos de sus causas. El conocimiento de las causas de un fenómeno nos permite su control. Así, dentro del ámbito psicológico, hay teorías bien establecidas que afirman que algunas fobias se adquieren por condicionamiento clásico. Un estímulo en principio neutral llega a provocar una respuesta de ansiedad o miedo al asociarse a un estímulo incondicionado que produce una reacción de miedo. Una vez conocido el mecanismo por el que se adquiere el miedo podemos buscar un tratamiento. Una terapia surgida dentro del marco del condicionamiento clásico es la desensibilización sistemática (Wolpe, 1958). El procedimiento consiste en emplear una respuesta incompatible con el miedo, por lo general una profunda relajación, en presencia del estímulo fóbico. Empieza con estímulos que provoquen muy poca ansiedad y gradualmente se va emparejando el relajamiento con señales que provocan mayores respuestas de miedo, hasta conseguir eliminar la capacidad de los estímulos para provocar miedo. Sirva este pequeño ejemplo para demostrar que buena parte de la fuerza de la explicación causal es de naturaleza pragmática, y estriba en que posibilita la predicción y el control de los fenómenos estudiados. No es extraño, por lo tanto, que la metodología más mimada en términos económicos y de prestigio sea aquella que permite el establecimiento de relaciones causales de una manera más fiable, es decir, la metodología experimental.

En lo que sigue se presentarán algunos de los elementos que conforman las investigaciones experimentales y cuasi experimentales (hipótesis experimentales, tipos de variables, formas de control); veremos principios de optimización de dichas investigaciones (principio *MAX-MIN-CON*); se destacará la importancia que tienen las Matemáticas en el análisis de los resultados (modelización matemática), así como los criterios que nos permitirán juzgar la calidad de las mismas (validez teórica, validez de constructo, validez de conclusión estadística, validez interna y validez externa); para terminar definiendo de forma precisa qué es un experimento, qué es un cuasi experimento y a qué nos referimos con el término *diseño*. Esos son los conceptos básicos que veremos, pero ¿y el ejemplo? Como lo prometido es deuda, ahí va.

9.2.1. El ejemplo

Gracias a las campañas de la Dirección General de Tráfico es ampliamente conocido que la capacidad de reacción disminuye conforme aumenta la ingesta de alcohol. Supóngase que un investigador con buenas

bases metodológicas intenta comprobar la hipótesis publicitada por Tráfico. Diseña la investigación de tal forma que un grupo de cinco personas reciben una dosis de 10 cl de alcohol, y otro grupo de otras cinco personas recibe una dosis de 50 cl. A todos ellos, 30 minutos después de la ingestión del alcohol, se les mide su tiempo de reacción (TR). Como cabe esperar, se obtuvieron tiempos de reacción mayores en el segundo grupo que en el primero. Con estos datos tan escuetos, ¿creen ustedes que hay suficientes garantías para concluir que el aumento en el tiempo de reacción está producido por el alcohol? Si lo creen, se equivocan. Es cierto que nada de lo que hay en el planteamiento de la investigación sobra, pero, como veremos, faltan otras muchas cosas.

9.2.2. Hipótesis experimentales

En el inicio de toda investigación se halla siempre el intento de resolución de un problema, que nunca surge en el vacío. Tanto el problema de investigación como sus posibles soluciones están determinadas en buena medida por los conocimientos que hasta la fecha se tengan del fenómeno bajo estudio. Éste es uno de los motivos por los que una buena investigación empieza siempre por una buena documentación. Así se evitará la indagación de problemas ya resueltos (la investigación anterior es un ejemplo de ello), de problemas sin posibilidad de solución o carentes de sentido (¿cuántos ángeles caben de pie en la cabeza de un alfiler?). Cuando se dispone de información suficiente, y en base a la misma se ha elegido y delimitado el problema de investigación, el siguiente paso es la formulación de hipótesis explicativas del mismo. Dichas hipótesis, denominadas *hipótesis experimentales* o sustantivas, constituyen siempre una respuesta tentativa y comprobable sobre la relación entre dos o más fenómenos. Recalquémoslo de nuevo, las hipótesis experimentales deben ser plausibles, aceptables, y sobre todo, comprobables. La hipótesis experimental de la investigación ética es un buen ejemplo ya que cumple los citados requisitos pudiendo formularse en los siguientes términos: si aumentamos la dosis de alcohol ingerido, disminuirá la capacidad de reacción. Hablando en plata, la hipótesis experimental afirma que el alcohol puede *causar* una disminución en la capacidad de reacción. Sin embargo, como veremos a continuación, no es tan sencillo hablar de causas.

9.2.3. La causalidad práctica

Se estableció en el primer capítulo, y se ha reiterado en lo que llevamos de éste, que el objetivo primordial de la metodología experimental y cuasi experimental va a ser la búsqueda de explicaciones causales. No

obstante, desde el siglo XVIII nadie medianamente sensato se debería atrever a decir que un fenómeno es causa de otro. No crean que me he vuelto loco. Como muy bien demostró Hume (1748, 1749) en su excelente, implacable e impecable crítica del principio de causalidad, es imposible el conocimiento necesario de la naturaleza, ya que no es posible ni un conocimiento inmediato de las causas (no existen impresiones de las conexiones necesarias, de las causas), ni demostrativo (ninguna apelación a la regularidad de la experiencia pasada puede garantizar regularidades futuras). Es imposible demostrar que *A* es causa de *B* a partir de premisas que establecen cuestiones de hecho: *B* sigue a *A*. Una manera razonable de salir del atolladero es establecer criterios de causalidad de tipo práctico en lugar de criterios de orden lógico. En primer lugar es aconsejable formular las hipótesis experimentales en la forma condicional de antecedente y consecuente: si *A*, entonces *B*. Formuladas en esta manera, se han propuesto algunas condiciones que se deben cumplir para inferir que *A* es la causa de *B*. Por ejemplo, Cook y Campbell (1979) señalan las siguientes:

1. Covariación. Cambios en las presuntas causas deben estar relacionados con cambios en los posibles efectos.
2. Precedencia temporal. La causa ocurre antes que el efecto.
3. Eliminación de explicaciones alternativas. La presumible causa debe ser la única posible explicación de los cambios acontecidos en el efecto.

Para ser justos, debemos señalar que estos criterios de causalidad no son nada nuevo, y que ya Hume estipuló definiciones de relaciones causales objetivas, al modo de las vistas, en *Las investigaciones sobre el conocimiento humano* (1748) y, sobre todo, en el *Tratado de la naturaleza humana* (1749). Señalamos una vez más la naturaleza práctica de tales principios porque desde un punto de vista lógico nadie, como demostró Hume, puede hacer inferencias causales dado que las implicaciones de tipo lógico (que siempre que ocurra *A* ocurrirá *B*) no se pueden determinar de forma fáctica. Afortunadamente hacemos investigación empírica y no lógica formal, y a ello vamos.

9.2.4. Tipos de variables

Antes de nada, definamos que entendemos por variable. *Variable* es cualquier característica que posee al menos dos valores observables. Por ejemplo, el color del pelo, la altura, la belleza, o el tiempo de reacción, todas ellas son características que varían, es decir, variables. Las variables tienen una importancia extrema desde cualquier punto de vista, empe-

zando por el ontológico. Miren alrededor, los objetos, sus propiedades y las relaciones entre los objetos que conforman el universo son casi siempre variables. Hay muy pocas constantes, las que se conocen son casi siempre de naturaleza física (velocidad de la luz, constante gravitatoria) o matemática (razón entre la longitud de una circunferencia y su diámetro). Y si casi todo varía, raro será que no haya fórmulas matemáticas que nos permitan cuantificar el grado en el que las variables varían. La *varianza* es una de las fórmulas más empleadas para ello (*véase* el cuadro 4.3), de forma tal que podemos decir que cuanto más varíe una variable mayor será su varianza.

Las variables no solo varían dentro de ellas mismas, por decirlo de alguna forma, sino que también varían entre ellas; quiero decir, que las hay de diverso tipo. Así, podemos clasificar a las variables que forman parte de una investigación desde un punto de vista metodológico. Desde esta perspectiva, Kish (1987) distingue entre variables explicativas —aquellas que forman parte de la hipótesis experimental, bien como causas (variables independientes) bien como efectos (variables dependientes)— y variables extrañas, que son todas aquellas variables que pueden influir sobre la variable dependiente pero que no nos interesa estimar sus efectos. Definémoslas de una forma más precisa. *Variable independiente* (VI) es cualquier suceso que sospechamos que pueda ser la causa de otro y que estamos interesados en investigar (en nuestro ejemplo el alcohol). Llamamos *variable dependiente* (VD) a la medida utilizada para determinar los posibles efectos de la variable independiente (el tiempo de reacción). En la elección de la VD, que es una variable indicadora de un posible efecto, es importante considerar aspectos como la validez, la fiabilidad y la sensibilidad. Estos términos pueden ser utilizados en su preciso significado psicométrico. Válida, porque mide lo que pretende medir. Fiable, porque la medida debe estar libre de error. Y sensible, porque debe detectar, en caso de estar relacionada con la VI, los cambios que se produzcan en ella. Si además de esto, la VD fuese medida con facilidad y bajo coste, no podríamos pedir más. La realidad es mucho más compleja, ya que siempre entran en juego otro tipo de variables: las *variables extrañas* (VEs). Denominamos así a todas aquellas variables que pudiendo afectar a la VD no nos interesa estimar su efecto, de ahí el nombre de extrañas. Cuando no se controlan, estas variables pueden confundir los resultados de nuestras investigaciones de forma que consideremos que la VI tiene efectos sobre la VD, o tiene un efecto mayor del que realmente tiene, cuando no es así. Como veremos a continuación, también se puede dar el caso contrario. Supongamos que en la investigación ética las personas que recibían la mayor dosis de alcohol pesaban más que las que recibían la dosis menor. Supongamos además que obtenemos tiempos de reacción similares en ambos grupos. En estas circunstancias, no podemos

concluir que el alcohol no influye sobre la capacidad de reacción, porque dichos resultados están contaminados por la acción de una variable extraña: el peso. Sabemos que a mayor volumen corporal es necesario mayor cantidad de alcohol para provocar los mismos efectos. Ese es el motivo por el que hemos obtenido que la dosis de alcohol no afecta al TR. Si las personas hubieran sido de una corpulencia similar en ambos grupos, entonces encontraríamos, como realmente ocurre, que la dosis de alcohol sí afecta al TR.

También debemos distinguir, utilizando un criterio manipulativo, entre *variables activas*, aquellas que pueden ser manipuladas por el investigador (por ejemplo, dosis de alcohol, tipo de reforzador, número de ensayos, instrucciones) y *variables asignadas*, aquellas que no se pueden manipular. Estas últimas son, por lo general, variables ligadas a características del organismo como el género, la edad, la inteligencia o el temperamento. Pongamos un ejemplo. En la investigación anterior el alcohol, que es la VI, es una variable activa porque podemos elegir los valores que nos parezcan bien (10 cl, 50 cl, 60 cl, etc.) y asignarlos como queramos a las personas que forman parte de la investigación (podemos decidir qué cinco personas tomarán los 10 cl y qué otras los 50 cl). El género de las citadas personas es, sin embargo, una variable asignada porque no podemos variar sus valores a nuestro parecer. Podemos hacer que alguien tome 10 cl o 50 cl, pero no podemos hacer que sea mujer u hombre a nuestro gusto. Con las variables asignadas todo lo más que podemos hacer es seleccionar los valores con los que deseamos trabajar. Adelantamos que estas variables se suelen controlar incorporándolas a la investigación en la forma de variables de bloqueo.

9.2.5. Principios de optimización

Ahora que conocemos los tipos de variables que, de una forma u otra, siempre encontraremos en las investigaciones experimentales y cuasi experimentales, sepamos lo que debemos hacer con cada una de ellas. En primer lugar, ya que nuestro objetivo es determinar qué efecto tiene la VI sobre la VD, nos interesará que la VI tenga el mayor efecto posible sobre la VD. En segundo lugar, para estar seguro de que los cambios en la VD se deben a los cambios en la VI, tenemos que conseguir controlar el efecto de todas aquellas VEs que podamos identificar y manipular de alguna forma. Y en tercer lugar, debemos reducir el efecto que sobre la VD tengan todas aquellas VEs que no podamos controlar directamente.

Podemos expresar lo dicho con anterioridad de forma más precisa en términos de varianzas. Ya sabemos que la variable que se utiliza para esti-

mar los efectos de la VI, la que se mide y la que se registra, es la VD. Por ello, siempre que hablemos de la varianza, hablaremos de la varianza de la VD. Hemos visto que en las investigaciones tenemos siempre tres tipos de variables: la VI, la VD y las VEs. Por consiguiente, la varianza que observemos en la VD estará provocada necesariamente bien por la VI, bien por las VEs. En una situación ideal toda la varianza de la VD estará causada por la única variable que estamos interesados en estudiar, la VI. Volviendo al ejemplo de los tiempos de reacción, supongamos que todas las personas tienen, en condiciones normales, el mismo TR: 0,1 s. (hacemos este supuesto con fines ilustrativos, porque en la realidad sí existen diferencias individuales en los TR):

Grupo A: 0,1; 0,1; 0,1; 0,1; 0,1.

Grupo B: 0,1; 0,1; 0,1; 0,1; 0,1.

Podemos observar como la VD es una constante, su variabilidad es nula y su varianza, por lo tanto, 0. Si ahora suministramos a cada grupo una dosis diferente de alcohol (10 y 50 cl), en el caso de que el alcohol tenga efectos sobre el TR, la VD reflejará la variación de la VI. Veámoslo:

Grupo A (10 cl.): 0,4; 0,4; 0,4; 0,4; 0,4.

Grupo B (50 cl.): 0,9; 0,9; 0,9; 0,9; 0,9.

La VD ahora ya presenta dos valores, muestra una variabilidad que está provocada por la VI y que se denomina *varianza sistemática primaria*. Cuanto mayor sea la varianza sistemática primaria, mayor será el efecto que la VI tendrá sobre la VD. Repárese, sin embargo, en que la VD no varía dentro de cada grupo, ya que dentro de cada grupo todas las personas reciben la misma dosis de alcohol y el efecto es, por lo tanto, constante. Hasta aquí la situación ideal: en nuestra investigación solo existe la VI y la VD. Pongamos en juego a las VEs. Habrán notado algo sumamente extraño en los datos anteriores: dentro de cada grupo todos los sujetos tienen el mismo TR. Esto implica que todos poseen el mismo sistema nervioso, que pesan lo mismo, que tienen el mismo nivel de cansancio, motivación, etcétera. En definitiva, que trabajamos con organismos idénticos en cualquier VE que pueda afectar a los TR, y no con personas. En el mundo real sabemos que existen diferencias individuales en los TR provocadas por la distinta configuración del sistema nervioso, o que el peso de los sujetos modula el efecto que el alcohol tiene sobre el TR. Estas variables, amén de otras muchas, influirán sobre el TR haciendo que varíe de individuo a individuo. En esta situación, si asignamos al azar cinco personas a cada grupo, el efecto

que estas VEs tengan sobre la VD será aleatorio. Tendremos en ambos grupos que unas personas son más rápidas, otras más lentas; unas más pesadas, otras bien delgadas, personas muy motivadas y personas casi aburridas, etcétera. A la variabilidad de naturaleza aleatoria provocada en nuestra VD por todas esas VEs que no hemos controlado se le denomina *varianza error*. De esta forma los datos que el investigador obtendrá serán algo similar a:

Grupo A (10 cl): 0,48; 0,50; 0,39; 0,51; 0,45.

Grupo B (50 cl): 0,93; 1,00; 0,85; 0,92; 0,86.

Por último, veremos como no todas las VEs son tan consideradas como las anteriores, que variaban al azar. Existen VEs cuyos efectos tienen una dirección bien definida, es decir, son sistemáticos. Supóngase ahora que a las personas del Grupo A se les mide el TR en una cabina mal insonorizada, de tal forma que el ruido interfiere con la tarea haciendo aumentar el TR en 0,4 s. Los nuevos datos serán:

Grupo A (10 cl): 0,88; 0,90; 0,79; 0,91; 0,85.

Grupo B (50 cl): 0,93; 1,00; 0,85; 0,92; 0,86.

Como vemos, el efecto de la VI sobre la VD se ve enmascarado por la influencia que el ruido tiene sobre la VD, pudiendo conducirnos a concluir erróneamente que la dosis de alcohol no afecta al TR. A la variabilidad de la VD producida por una VE que actúa sistemáticamente se le denomina *varianza sistemática secundaria*. Nótese como la varianza error reflejaba la variabilidad existente dentro de cada grupo, pudiendo hacer más difícil detectar el efecto de la VI, pero al no actuar diferencialmente entre los grupos, como la varianza sistemática secundaria, no llega a confundir sus efectos con los de la VI. Por lo tanto, de cara a interpretar los resultados la varianza error es mucho menos perniciosa que la varianza sistemática secundaria.

Con fines pedagógicos hemos hecho el camino fácil. Mezclando los distintos componentes (varianza sistemática primaria, secundaria y error) en las dosis precisas hemos conseguido el jarabe buscado (la varianza total de la VD). En las investigaciones el proceso es justamente el contrario, tenemos la VD medida en distintos grupos, y a partir de estos datos, deberemos determinar qué parte de su varianza se debe a la VI y cuál a las VEs. Adelantamos que será misión de los análisis estadísticos diferenciar, a partir de los datos registrados, qué porcentaje de la varianza de la VD se debe a cada una de las fuentes de variación presentes en la investigación.

Una vez que hemos definido las variables que forman parte de una investigación y los tipos de varianza existentes, estamos en disposición de formular un principio de optimización de las investigaciones en términos de las varianzas atribuibles a cada una de las variables. Según Kerlinger (1987, cap. 17) una investigación bien diseñada debe *MAX*imizar la varianza sistemática primaria de la VD (la que es provocada por la VI), *MIN*imizar la varianza error de la VD (que es la variabilidad debida a procesos azarosos) y *CON*trolar la varianza sistemática secundaria de la VD (la que es provocada por alguna VE que actúa por sí sola o junto con la VI), lo que se conoce como el *principio MAX-MIN-CON*. Nótese que decimos minimizar o reducir, y no controlar, la varianza error porque, por definición, la varianza error está provocada por todas aquellas VEs que están afectando a la VD y no podemos controlar. El cumplimiento del principio MAX-MIN-CON maximiza la probabilidad de determinar la relación funcional existente entre la VI y la VD al maximizar la varianza sistemática primaria y minimizar la varianza error. Además, el control de las VEs permitirá la exclusión de explicaciones alternativas a la formulada en la hipótesis experimental.

En el siguiente apartado veremos algunas formas de controlar y/o reducir el efecto de las VEs.

9.2.6. Control

Ya hemos señalado que el ideal de toda investigación es que la única fuente de variación en el experimento sea la VI. Así podremos estar seguros de que los cambios en la VD se deben exclusivamente a los efectos de la VI. Por este motivo el control de las VEs constituye un requisito necesario para establecer inferencias causales con garantías. El **control experimental** de las VEs puede ser un control directo (mediante la eliminación o la constancia) o indirecto (mediante la aleatorización). En el ejemplo anterior la insonorización de la cabina en la que se miden los tiempos de reacción al Grupo A es una forma de control de la VE ruido por eliminación. Cuando no sea posible eliminar directamente una VE, deberemos procurar que su efecto sea constante a través de todas las condiciones experimentales. De esta forma, si existen diferencias entre los grupos se deberán a lo único que varía a través de ellos, es decir, a la VI. Esta forma de control se denomina constancia. Por ejemplo, respecto de la investigación etílica se dijo que el peso corporal modifica el efecto que la dosis de alcohol tiene sobre el TR, y el peso, por muy anoréxicos que sean los tiempos, no se puede eliminar. En esta situación lo que sí podemos hacer es que los dos grupos estén formados por personas de peso similar. Las formas de control expuestas anteriormente nos permiten

controlar de forma directa algunas variables, pero ¿y el resto? En teoría existen multitud de ellas, seríamos unos insensatos si pretendiésemos eliminar o mantener constantes de forma directa a todas las VEs. ¿Qué podemos hacer para controlar incluso aquellas que desconocemos? Aleatorizar, asignar aleatoriamente las unidades experimentales a los niveles de tratamiento, los sujetos a los diferentes grupos. La lógica del asunto es bien sencilla. Debemos conseguir que lo único en lo que varíen las diferentes condiciones experimentales sean los niveles de tratamiento (valores de la VI) y esperamos que, enviando aleatoriamente las unidades experimentales a los diferentes niveles de tratamiento, el azar hará que los grupos sean equivalentes en cualquier VE que pueda afectar a la VD. Que por ejemplo, si enviamos aleatoriamente 100 personas al Grupo A y 100 personas al Grupo B, en ambos grupos, por azar, haya la misma proporción de personas delgadas, de peso medio y de peso alto. Y que ambos grupos, por efecto de la asignación aleatoria, sean equivalentes no sólo en estas VEs sino en cualesquiera otras. Este último procedimiento es especialmente potente porque nos garantiza que cualquier VE que no haya sido controlada de cualquier otra forma no tendrá ningún efecto sistemático sobre la VD, siendo considerados sus efectos como errores aleatorios que incrementarán la varianza error y no la varianza sistemática secundaria. Cuando por algún motivo —un deficiente control experimental directo o aleatorización— alguna VE no ha sido controlada, no podemos garantizar que los cambios en la VD se deban a cambios en la VI, siendo menos válidas las relaciones causales establecidas (existen más explicaciones rivales). En este caso diremos que los efectos de la VI se encuentran *confundidos* (por ejemplo, en el apartado 9.2.5 el ruido confundía el efecto del alcohol).

Nos queda aun por ver una forma de control de las VEs *a posteriori*. Ya lo dice el refrán «mejor es prevenir que curar», pero qué ocurre si una vez realizada la investigación nos damos cuenta de que alguna VE afecta diferencialmente a los grupos, de forma que sus efectos se pueden confundir con los de la VI. En este caso, si disponemos de medidas de la VE y se cumplen ciertos supuestos, todavía podemos eliminar el efecto diferencial que pudiera tener mediante el **control estadístico**. Para ello existe una técnica estadística muy específica, el análisis de la covarianza (ACOVAR). Debemos recalcar que siempre que sea posible es preferible el control de las VEs mediante procedimientos directos porque conlleva una reducción de la varianza error (lo veremos más adelante al tratar los diseños de bloques homogéneos aleatorizados y los de medidas repetidas). En la figura 9.1 se presenta una ilustración de lo dicho hasta aquí.




FIGURA 9.1. Variables y formas de control.

9.2.7. Modelización matemática

¿Qué es un modelo? Fishman (1973), en una buena definición, lo describe como una representación de un sistema real. Dicho así parece algo abstracto, pero estamos rodeados de modelos. Por ejemplo, un mapa es un modelo que representa esquemáticamente lo que hay entre determinadas coordenadas geográficas; una maqueta es una réplica material, un modelo, del edificio o sistema que reproduce; existen también modelos analógicos que utilizan las características propias de otros sistemas para representar las del sistema estudiado: ¿quién no conoce la analogía establecida entre la mente y el software informático? Existen también modelos simbólicos o formales que representan al sistema utilizando funciones simbólicas. Y dentro de estos, los *modelos matemáticos* se caracterizan por emplear en su totalidad operaciones lógico-matemáticas para describir un sistema. No debemos olvidar, sin embargo, que el objetivo de todos los modelos es describir correctamente aquello que pretenden representar. ¿Pero para qué necesitamos modelos matemáticos en nuestras investigaciones? Una vez realizada la investigación tenemos ciertos datos a partir de los cuales debemos decidir si la hipótesis experimental que habíamos planteado se cumple o no. Retomemos los resultados ya presentados:

Grupo A (10 cl.): 0,48; 0,50; 0,39; 0,51; 0,45

Grupo B (50 cl.): 0,93; 1,00; 0,85; 0,92; 0,86

Una inspección visual de los tiempos de reacción indica que el Grupo B tiene TR mayores y que por lo tanto el consumo de alcohol disminuye la capacidad de reacción. Con 5 personas por grupo, podemos realizar este apañó, pero si tuviésemos 100 personas por grupo y las diferencias no fueran tan marcadas, obtener conclusiones sería mucho más difícil.

Una manera fácil de hacerlo es calcular alguna función matemática que nos resuma cuál es el TR más común en cada grupo. Una simple media bastará ($\bar{X}_A = 0,47$ y $\bar{X}_B = 0,91$). Es mucho más fácil llegar a una conclusión si comparamos los TR promedios (0,47 s. frente a 0,91 s.) que comparando entre sí todos los datos. Sin embargo, a no ser que sólo estemos interesados en saber cómo afecta el alcohol a las 10 personas que forman parte de la investigación, esto no es suficiente. Uno de los objetivos de la ciencia es el establecimiento de leyes y principios generales. No basta con probar que determinado fármaco para el insomnio funciona en los 50 pacientes sobre los que se realizaron los ensayos clínicos, hay que poder garantizar que funcionará, dentro de ciertos márgenes de error, en cualquier insomne. En definitiva, cuando hacemos una investigación buscamos generalizar los resultados, y la estadística inferencial, mediante la formulación y ajuste de modelos que reflejen cómo funcionan en la población las variables que forman parte de la investigación, es el instrumento matemático que posibilita dicha generalización. Por ello, las hipótesis experimentales casi siempre se reformulan en términos estadísticos para poder someterlas a comprobación y generalizarlas. Finalizaremos este epígrafe mostrando una posible formulación de la hipótesis experimental de la investigación etílica (si aumentamos la dosis de alcohol ingerido, disminuirá la capacidad de respuesta) en términos estadísticos: el tiempo de reacción promedio en la población que ha ingerido 50 cl. de alcohol es mayor que el de la población que ha ingerido una cantidad de 10 cl. La anterior hipótesis es la hipótesis que se sometería a comprobación, y para comprobarla debemos formular un modelo matemático que refleje lo que acontece en la población. Como podemos observar, las afirmaciones realizadas en la hipótesis estadística se refieren a la población, que es lo que nos interesa conocer, ya que lo que ocurre en el experimento lo conocemos con certeza. Sabemos exactamente qué efecto tiene el alcohol sobre los TR de esas 10 personas, pero eso tiene poco interés en sí. Resumamos lo dicho en forma breve: utilizamos modelos matemáticos para analizar los datos de nuestras investigaciones porque posibilitan establecer algo sobre muchos a partir del estudio de unos pocos. El gran epigramista latino Marco Valerio Marcial (40-101 d.C.), lo habría dicho de otra forma: los modelos matemáticos permiten, a partir del estudio de unos pocos conocidos, establecer algo sobre un gran número de desconocidos. Lo primero es una sentencia, lo segundo casi un epigrama. Valoren la diferencia, camino del siguiente apartado.

9.2.8. Fases de una investigación y clases de validez

La estadística inferencial nos permite generalizar nuestros resultados de forma automática, pero seremos nosotros quienes debamos evaluar la

validez de las conclusiones obtenidas. Ha llegado la hora de juzgar. Los juicios estéticos y éticos suelen ser globales, me gusta o no me gusta, está bien o está mal. La justificación de los mismos suele seguir otro camino, un análisis por partes de la obra o el problema enjuiciado. Si uno afirma que «*La mujer del cuadro*» (1940) de Fritz Lang (doblada bajo el muy adecuado título de «*Perversidad*») es una película infinitamente mejor que «*Acusado*» (1994) de Barry Levinson, la mejor manera de demostrarlo es proceder a un análisis comparativo por partes: guión, actuación, profundidad y matices de la historia, fotografía, lenguaje cinematográfico, etcétera. Esta es la única forma de demostrar que el «*a mí me gusta más*» no impide los juicios objetivos. La valoración de las investigaciones científicas sin ser tan controvertida, no deja de ser un juicio, y como en el anterior caso, la mejor forma de valorar las investigaciones es enjuiciarlas por partes. Así, juzgaremos el grado de confianza que nos merece la información obtenida en una investigación, su *validez*, atendiendo a una serie de aspectos que fueron establecidos por Cook y Campbell (1979) a partir del trabajo inicial de Campbell y Stanley (1966). Como hemos dicho no vamos a juzgar la bondad de las investigaciones a una sola carta, sino que vamos a valorarla atendiendo a los distintos aspectos que las conforman. De esta manera podemos poner en correspondencia, como se muestra en la figura 9.2, los distintos tipos de validez con las etapas de que consta una investigación.

En primer lugar, en la delimitación del problema y la formulación de las hipótesis experimentales está implicada de forma preferente lo que denominamos validez teórica. Decimos que una investigación tiene *validez teórica* (Fidalgo, 1999) cuando el problema investigado y las soluciones planteadas son consistentes, o se derivan, o están estrechamente relacionadas, con teorías bien establecidas. Una vez establecida la hipótesis experimental (por ejemplo, el alcohol disminuye la capacidad de reacción), el siguiente paso en una investigación es la operacionalización de la VI y la VD que forman parte de dicha hipótesis, así como las poblaciones, contextos y ocasiones de interés. Es decir, para qué tipo de per-




FIGURA 9.2. Fases de una investigación y tipos de validez implicados.

sonas, circunstancias y ocasiones deseamos investigar la relación formulada en la hipótesis experimental. En esta fase de la investigación es donde se debe garantizar que los conceptos teóricos investigados se encuentran bien operacionalizados en términos de variables susceptibles de manipulación y/o medida. Ésta es la principal tarea de la *validez de constructo*. Así, tendremos que definir de forma precisa la variable *dosis de alcohol* (puede ser alcohol ingerido o tasa de alcohol en sangre), qué cantidad utilizaremos, etc. También debemos asegurarnos de que los TR son una medida que representa adecuadamente el constructo *capacidad de reacción*. Una vez que las variables han sido operacionalizadas, las hipótesis experimentales se suelen expresar en términos de hipótesis estadísticas que serán sometidas a comprobación mediante la formulación y ajuste de los modelos estadísticos oportunos. La correcta formulación de estas hipótesis y modelos son algunos de los aspectos que tienen que ver con la *validez de conclusión estadística*. El plan experimental determinará las técnicas de control que vamos a utilizar para garantizar unas correctas atribuciones causales, esto es, para garantizar que el cambio en la VD se debe única y exclusivamente a cambios en la VI. Cuanto más se aproxime una investigación a dicho objetivo, mayor será su *validez interna*. El siguiente paso es el análisis estadístico de los datos obtenidos. En esta etapa se procederá a comprobar en qué medida el modelo formulado explica correctamente los datos obtenidos en la investigación, y a la comprobación de las hipótesis estadísticas asociadas. De nuevo la validez de conclusión estadística juega un papel importante. Por último, habrá que determinar el alcance de los resultados obtenidos, si podemos generalizarlos a otras poblaciones, tratamientos, contextos y ocasiones, es decir, cuál es su *validez externa*.

9.2.9. ¿Experimento o cuasi experimento?

No se si se habrán fijado pero hasta el momento siempre nos hemos referido al ejemplo puesto como «la investigación», hasta ahora nunca hemos dicho si es un experimento o un cuasi experimento. Y no lo hemos dicho porque con los datos disponibles no podíamos saberlo. Si al enunciado del apartado 9.2.1 le añadimos que las diez personas que forman parte del experimento fueron asignadas aleatoriamente a las diversas condiciones experimentales (dosis de alcohol), entonces estaríamos en una investigación experimental. Sin embargo, si la decisión sobre qué personas van a cada uno de los grupos no se hizo al azar sino, por ejemplo, atendiendo al orden de llegada a la sala del experimento, o a que se conocieran, estaríamos ante un cuasi experimento. Para establecerlo de una forma clara, diremos que estamos en una investigación experimental cuando se cumplen los siguientes requisitos:

1. Manipulación de la VI.
2. Elevado control de las VEs.
3. La regla de asignación de los sujetos a las condiciones experimentales, o de aplicación de los tratamientos a los sujetos es aleatoria.

En el caso de que no se cumpliera la tercera condición, la aleatorización, estaríamos en una investigación cuasi experimental. Además, cuando no se llega a cumplir ni siquiera la primera condición, esto es, la VI no es una variable activa sino asignada, entonces estaríamos ante un tipo especial de investigación denominado *ex post facto*. Así de fácil. Pero antes de seguir, rebobinemos.

MC Investigaciones *ex post facto*

Juez.—¿Cuál es el objetivo básico de la metodología experimental y cuasi experimental?

Reo.—El establecimiento de relaciones causales.

Juez.—¿Está usted en condiciones de demostrar que esas metodologías de investigación son *a priori* superiores a cualesquiera otras a la hora de conseguir dicho objetivo?

Reo.—Lo estoy.

Juez.—Proceda.

Reo.—Ya sabemos que desde un punto de vista práctico podemos inferir que A es la causa de B siempre y cuando exista covariación entre A y B, precedencia temporal de A sobre B y eliminemos las explicaciones causales alternativas. Por lo tanto, las investigaciones experimentales y cuasi experimentales deben establecer condiciones que permitan el cumplimiento de los citados criterios. A continuación demostraré, señoría, estimados desconocidos, cómo lo hacen. En primer lugar, como se establece en el punto 1, se manipula activamente la VI, de esta forma podemos determinar si existe o no covariación entre ella y la VD. En segundo lugar, en todas estas investigaciones a la introducción de la VI le sigue siempre un registro de la VD (precedencia temporal de la causa). En tercer lugar, y para finalizar, el control de las VEs llevado a cabo en estas metodologías permite la eliminación de buena parte de las explicaciones causales alternativas. Si se me permite, quiero señalar también que dicho control será siempre mayor en la investigación experimental que en la

cuasi experimental, al utilizar la aleatorización la primera de ellas. Y que por lo tanto, será la metodología experimental la que nos ofrezca mayores garantías a la hora de establecer relaciones causales entre fenómenos. Nada más.

Juez.—Absuelto. Se disuelve el apartado.

9.2.10. Diseños

Las diferentes metodologías de investigación se pueden, como hemos hecho aquí, caracterizar de una forma genérica, pero en la práctica dichas estrategias se concretan en planes de acción mucho más definidos denominados *diseños*. Debemos destacar, aunque sea de perogrullo decirlo, que tanto la correcta elaboración del diseño, esto es, el procedimiento metodológico destinado a lograr los objetivos fijados en la investigación, como su correcta ejecución, esto es, todas las decisiones y actividades necesarias para llevarlo a cabo, son condiciones necesarias para realizar una investigación exitosa. Por decirlo en una frase: un buen diseño no mejorará una mala investigación, pero un mal diseño puede limitar seriamente los resultados de una buena investigación. En lo que queda de capítulo se mostrarán algunos de los diseños experimentales y cuasi experimentales más comunes.

9.3. METODOLOGÍA EXPERIMENTAL

Podemos decir en una forma muy general que el objetivo primero de las investigaciones es establecer relaciones entre los objetos de estudio y/o entre los objetos de estudio y las teorías. En algunas investigaciones además se especifica la dirección de la relación entre los fenómenos estudiados en la forma de causa-efecto. Este plus de información exige también un plus de rigurosidad. Como se ha señalado reiteradamente, la metodología experimental al garantizar un elevado control de las VEs y la posibilidad de manipulación de la VI, ofrece el marco idóneo para el establecimiento y comprobación de hipótesis causales. Existen numerosas estructuras de investigación que permiten conseguir el objetivo antedicho. Podemos clasificar los diseños experimentales atendiendo a varios criterios que pueden considerarse bien de forma individual o conjunta. Por ejemplo, atendiendo al número de VIs hablaremos de *diseños unifactoriales* (una VI) y *factoriales* (dos o más VIs), o de diseños *univariantes* y *multivariantes*, si atendemos al número de VDs. También podemos, tomando en consideración la técnica de control de las VEs, clasificarlos en *diseños completamente aleatorizados* (aleatorización), *diseños de blo-*

ques homogéneos aleatorizados (constancia), *diseños de medidas repetidas* (el sujeto como su propio control) y *diseños con covariantes* (control estadístico). Podemos, por último, clasificarlos en función del número de sujetos que forman parte del experimento en *diseños experimentales clásicos* ($N > 1$) y *diseños de sujeto único* ($N = 1$). Éstos son algunos de los criterios clasificatorios más comunes. En la exposición que sigue hablaremos de diseños experimentales clásicos, a los que dedicaremos los tres primeros apartados, y de diseños de sujeto único a los que se dedicará el último apartado. En todos los casos serán diseños unifactoriales y univariantes.

9.3.1. Diseños completamente aleatorizados

Los diseños completamente aleatorizados son planes experimentales que exigen la asignación aleatoria de las unidades experimentales a los diferentes niveles de tratamiento. Es decir, se formarán tantos grupos experimentales como niveles de tratamiento tengamos, procediendo a asignar aleatoriamente los sujetos de cada grupo o condición experimental, de ahí su nombre: diseños completamente aleatorizados o diseños de grupos al azar. Estos diseños son los diseños clásicos más sencillos, pero también los menos eficientes. Veamos con un ejemplo por qué. Un psicólogo educativo está interesado en determinar cuál de los tres métodos de enseñanza de las Matemáticas (clásico, audiovisual e interactivo) da lugar a un mayor rendimiento en dicha asignatura. Para ello, de los 60 alumnos que están en 2.º de ESO, se asignan aleatoriamente 20 alumnos a las distintas condiciones experimentales. Ya sabemos que, mediante la asignación aleatoria de los alumnos a las distintas condiciones experimentales, confiamos en conseguir grupos homogéneos en cualesquiera VEs que puedan afectar al rendimiento en Matemáticas. Así, por ejemplo, confiamos en que la capacidad intelectual de los alumnos será similar en todos los grupos. Esperamos que el azar nos ayude, pero por azar también puede ocurrir que las diez personas más inteligentes hayan ido a parar al método clásico y que esto confunda los resultados. Precisamente, la utilización de la aleatorización como única técnica de control es la principal desventaja de los diseños completamente aleatorizados, ya que exige tamaños de muestra considerables para garantizar la homogeneidad entre los grupos. Cuanto menor sea el tamaño de muestra, mayor será la probabilidad de que la aleatorización sea una técnica de control poco efectiva. Para ilustrarlo, llevemos este principio al extremo. Si sólo tenemos tres alumnos y difieren en su capacidad intelectual, por mucha asignación aleatoria que exista, es imposible configurar grupos homogéneos.

Para demostrar más adelante cómo se puede mejorar la eficiencia de este diseño, vamos a explicitar las fuentes de variabilidad que existen en el mismo:

$$\text{Varianza total} = \text{Varianza sistemática primaria} + \text{Varianza error}$$

La anterior ecuación especifica que toda la variabilidad presente en la VD está provocada por el efecto sistemático de la VI (varianza sistemática primaria) y por los efectos aleatorios de las VEs (varianza error). Como veremos a continuación, podemos reducir la varianza error estableciendo restricciones en la asignación aleatoria de los sujetos a las condiciones experimentales, de forma tal que podamos controlar VEs incorporándolas de forma activa al experimento.

9.3.2. Diseños de bloques homogéneos aleatorizados

Aunque parezca críptico lo dicho en el párrafo anterior, es bastante sencillo. Los diseños completamente aleatorizados pretendían controlar cualquier VE mediante la aleatorización. Ya hicimos notar algunas limitaciones de esa estrategia. Los diseños de bloques homogéneos aleatorizados, para curarse en salud, además de utilizar la aleatorización, intentarán controlar directamente algunas VEs incorporándolas al diseño. Por ejemplo, si sabemos que la capacidad intelectual influye en el rendimiento en Matemáticas podemos asegurarnos de que todos los métodos docentes tengan el mismo número de alumnos con un nivel intelectual alto, medio y bajo, en lugar de confiar que la aleatorización lo logre por nosotros. Para ello formaremos grupos de personas con el mismo nivel en la VE que deseemos controlar. A estos grupos homogéneos se les denomina *bloques* y a la VE a controlar *variable de bloqueo*. Una vez que tenemos formados los bloques lo único que nos resta es asignar aleatoriamente (AA) las unidades experimentales que se encuentran dentro de cada bloque a los niveles de tratamiento.

Bloques			Método docente		
			Clásico	Audiovisual	Interactivo
CI alto (115-130):	18 personas	—AA→	6	6	6
CI medio (100-114):	18 personas	—AA→	6	6	6
CI bajo (85-99):	18 personas	—AA→	6	6	6

Obsérvese cómo en cada método docente tenemos el mismo número de personas con un CI alto, medio y bajo. De esta forma estaremos seguros de que los tratamientos se aplican a grupos homogéneos en la VE que hemos controlado mediante el bloqueo. Además, mediante la asignación

aleatoria de las personas que forman cada bloque a los niveles de tratamiento, intentaremos controlar, dentro de ciertos márgenes probabilísticos, el resto de las VEs.

Veamos en términos de varianzas cómo el diseño de bloques aleatorizados reduce la varianza error respecto del diseño completamente aleatorizado.

$$V. \text{ total} = V. \text{ sistem. primaria} + V. \text{ sistem. secundaria} + V. \text{ error} \quad (9.1)$$

(Métodos de enseñanza) (Variable de bloqueo: CI)

En el diseño de bloques homogéneos aleatorizados la varianza error será menor que en el diseño completamente aleatorizado, porque la variabilidad provocada por la variable de bloqueo se extrae de la varianza error al controlarla directamente mediante el diseño. De esta forma podemos aislar la variabilidad provocada por una VE (la variable de bloqueo) de forma que no afecte ni a los tratamientos ni al error, como se recoge en la ecuación (9.1). En tanto la varianza error en los diseños completamente aleatorizados recoge la variabilidad en la VD provocada por todas las VEs, incluida la provocada por las diferencias en la capacidad intelectual entre los miembros que componen cada grupo. Nótese cómo mediante la homogeneización de los grupos lo que hacemos es reducir la varianza error, y recuérdese que en el apartado 9.2.5 vimos cómo, cuanto menor fuese la varianza error, con más facilidad podíamos apreciar el efecto de la VI. Por eso mismo un diseño de bloques homogéneos aleatorizados es más eficiente que un diseño completamente aleatorizado. A continuación veremos planes de investigación que pretenden llegar más lejos: controlar de forma completa el efecto que pudieran tener las diferencias individuales.

9.3.3. Diseños de medidas repetidas

A estas alturas ya se habrán percatado de que uno de los objetivos básicos al diseñar una investigación es conseguir unidades experimentales lo más similares posibles. Desgraciadamente el hecho de que todos seamos parecidos pero ninguno igual implica que, siempre que apliquemos tratamientos diferentes a personas diferentes, una buena parte de la varianza error estará causada por las diferencias individuales. No obstante, existen diseños experimentales que permiten eliminar de nuestras investigaciones la varianza debida a las diferencias individuales. La estrategia es sencilla, tan sencilla como observar al mismo sujeto bajo todos los niveles de tratamiento. En estos diseños las respuestas a la VI se analizarán ahora dentro de los sujetos, por eso se llaman también *diseños intra sujeto*, y no entre los sujetos, como en los diseños completamente

aleatorizados y los diseños de bloques homogéneos aleatorizados (*diseños entre sujetos*). Retomemos la investigación ética. En dicha investigación existían numerosas VEs vinculadas a las características individuales que podían afectar a los tiempos de reacción: la configuración del sistema nervioso, el peso, el grado de fatiga, etc. Si aplicásemos un diseño completamente aleatorizado, el efecto de todas estas variables iría a formar parte de la varianza error. Como vimos, podemos reducir dicha varianza si homogeneizamos los grupos en alguna de estas VEs utilizándola como variable de bloqueo. Sin embargo, el resto de las VEs que estén ligadas a las diferencias individuales seguirán incrementando la varianza error. Pero si hacemos que cada individuo pase por todos los niveles de tratamiento, lograremos eliminar de la varianza error la variabilidad debida a las diferencias individuales, ya que utilizamos los mismos sujetos en todos los niveles de tratamiento. Ahora ya no podemos decir que las personas que beben los 10 cl de alcohol son más delgadas que las que beben los 50 cl; o más tontas o guapas o feas, o lo que se nos ocurra, pues son las mismas. Veamos el esquema de un diseño de medidas repetidas aplicado a la investigación sobre los efectos del alcohol:

	10 cl.	50 cl.
Sujeto 1	0,40 s.	0,90 s.
Sujeto 2	0,43 s.	0,92 s.
Sujeto 3	0,51 s.	1,00 s.
⋮	⋮	⋮
Sujeto 10	0,39 s.	0,89 s.

Estos diseños presentan como ventaja frente a los diseños entre sujetos el exhaustivo control de la varianza debida a las diferencias individuales. Como podemos apreciar en el diseño de medidas repetidas cada sujeto constituye un bloque, con lo que la varianza debida a las diferencias entre los individuos se extrae del término error. Expresemos lo dicho en términos de varianzas:

$$V. \text{ total} = V. \text{ sistem. primaria} + V. \text{ sistem. secundaria} + V. \text{ error}$$

(Alcohol) (Diferencias individuales)

Otra ventaja adicional de los diseños de medidas repetidas frente a los diseños entre sujetos es que requieren mucho menor tamaño de muestra, resultando muy apropiados en investigaciones cuyo objeto de estudio son poblaciones pequeñas (determinadas psicopatologías, por ejemplo), o en las que el coste por unidad experimental es muy elevado (las investigaciones en Psicología Animal que utilizan primates). Pero no todo van a ser ventajas, presentan algunas limitaciones derivadas de la aplicación secuencial de los niveles de la VI conocidas con los nombres de *efectos del*

orden y residuales. Los primeros resultan del orden particular en que los niveles de tratamiento son administrados. Por ejemplo, si la tarea experimental requiere mucha concentración, es posible que la medida de la VD obtenida en los últimos niveles de la VI refleje, además del efecto de la VI, el efecto de la fatiga. O puede darse el caso de que se produzcan mejoras en los registros que sean efecto de la práctica que adquieren los sujetos conforme avanza el experimento. En ambos casos, si los niveles de la VI se aplican siempre en el mismo orden para todos los sujetos, los citados efectos pueden llegar a confundir los resultados. Precisamente para evitar estos efectos la estrategia más sencilla es asignar los niveles de tratamiento en orden aleatorio e independiente a cada sujeto. Los diseños de medidas repetidas exigen, por lo tanto, la asignación aleatoria a los sujetos del orden en el que éstos pasan por los distintos niveles de tratamiento. Por último, los efectos residuales se producen cuando la acción de un nivel de tratamiento se prolonga más allá de la administración del siguiente. Aumentar el intervalo existente entre la aplicación de los niveles de tratamiento es una forma sencilla de evitar que se produzcan. En la investigación ética, por ejemplo, no se daría la segunda dosis de alcohol hasta que no pasase tiempo suficiente para que los efectos de la primera dosis estuvieran ausentes.

9.3.4. Diseños de sujeto único o $N = 1$

Hemos pasado de diseños en los que cada nivel de tratamiento se aplica a un grupo de sujetos diferentes (diseños entre sujetos) a diseños en los que cada individuo pasa por todos los niveles de tratamiento (diseños intra sujeto), pero en todos ellos la VI se aplicaba a más de un individuo. Pudiera parecer que un elevado número de personas es un requisito necesario para realizar investigaciones experimentales, y no es cierto. Se puede hacer investigación experimental con una sola unidad experimental, que en Psicología suele ser una persona, utilizando diseños de sujeto único. Dichos diseños han sido ampliamente utilizados en el ámbito clínico, donde el interés se centra en el individuo (su mejoría) antes que en la valoración del efecto del tratamiento. Mediante el registro de los síntomas el clínico puede comprobar la evolución del paciente. Sin embargo, la evaluación de los síntomas por sí sola no revela lo que causa el cambio. Reconocemos de antemano que en la práctica clínica la mejoría es lo que importa, pero si se está interesado en demostrar que la causa de la mejoría es el tratamiento y no cualquier otra contingencia que haya podido ocurrir durante la administración del mismo, existen planes de acción que nos ayudarán a ello.

La estructura básica de los diseños de sujeto único puede representarse como una sucesión de fases en las que se toman registros de las respuestas

de un sujeto en distintos puntos de tiempo. En el diseño más sencillo se toman registros de la VD, denominada también *variable de registro*, en ausencia del tratamiento. Es lo que se conoce como *línea base* o fase A. En una segunda fase, llamada *fase de tratamiento* o fase B, se sigue registrando la variable de registro, pero después de haber introducido el tratamiento. Podemos representar dicha estructura de la siguiente manera:

$$\begin{array}{ccccccccc} O_1 & O_2 & O_3 & O_4 & O_5 & O_6 & \text{Tratamiento} & O_7 & O_8 & O_9 & O_{10} & O_{11} & O_{12} \\ \text{Fase A o línea base} & & & & & & & \text{Fase B o fase de tratamiento} & & & & & \end{array}$$

Para poder estar seguro de que los cambios en la variable de registro (representada por una O) se deben a la introducción del tratamiento, es necesario un estricto control de las VEs, además de un punto de comparación de sus efectos, que será proporcionado por la línea base. De esta forma, podemos caracterizar a los diseños de sujeto único como investigaciones en las que una sola unidad de observación es sometida al tratamiento en una situación altamente controlada, utilizando la línea base como punto de comparación y control de las VEs. Al igual que hace Kazdin (1992), consideraremos a este tipo de investigación experimental siempre y cuando se garantice un elevado control de las VEs, si esto no fuese así consideraremos que la investigación es cuasi experimental. ¿De dónde obtienen la fortaleza causal estos diseños? Si tuviésemos que caracterizar de una forma general el mecanismo al que deben la capacidad para establecer relaciones causales los diseños de sujeto único, diríamos que es la *especificidad temporal*. La especificidad temporal es un principio simple, casi una evidencia, que está implícito en las atribuciones causales hechas con estos diseños. Podemos formularlo de la siguiente manera: si puedo introducir el tratamiento en un punto específico del tiempo y observo cambios en la variable de registro a partir de ese punto específico de tiempo, es difícil que los cambios se deban a cualesquiera otros factores, ya que justamente deberían empezar a actuar en ese punto específico de tiempo. Ni antes ni después, justo ahí. Naturalmente, la replicación de las distintas fases de que constan los diseños de sujeto único incrementará la validez interna de los mismos. Si puedo introducir y retirar el tratamiento varias veces, y se observan cambios en la variable de respuesta contingentes con dichas operaciones, será mucho más probable que los cambios observados se deban al tratamiento. Precisamente esa es la estrategia seguida en los *diseños reversibles* o ABAB. Veamos un ejemplo tomado de Kazdin (1978):

En un programa (Kazdin y Klock, 1973) se examinó en un salón de clase de educación especial el efecto del elogio del profesor sobre la conducta de niños retardados. Durante la línea base, se observó a los estudiantes durante nueve días para evaluar la conducta de estudiar (poner

atención al profesor y trabajar en la tarea). Mediante el uso del sistema de registro de intervalos, se observó la aprobación del profesor (verbal y no verbal) a la conducta del estudiante y la atención de este último al trabajo de clase. Después de la línea base se instruyó al profesor para que incrementara el uso de la aprobación no verbal con los estudiantes por medio de sonrisas, dándoles palmaditas en la espalda y aprobando con movimientos verticales de la cabeza cuando le prestaban atención. Cuando el profesor hizo esto, la conducta de estudio se incrementó. El uso de la aprobación del profesor en forma no verbal para controlar la conducta de los estudiantes se interrumpió en la fase reversible para demostrar que el programa era responsable de cambio conductual. Finalmente, se reinstaló la fase experimental y el profesor incrementó el uso de la aprobación no verbal. Los resultados para el grupo de doce estudiantes en conjunto se representan en la figura 9.3.





FIGURA 9.3. Resultados de la aplicación de un programa de aprobación no verbal sobre la conducta de atención en clase, utilizando un diseño reversible ABAB.

Como podemos comprobar, los diseños reversibles requieren que la fase de tratamiento se presente y retire en algún momento. Ésa es su característica principal, que admite algunas variaciones. Algunas veces no es recomendable empezar con una fase de línea base ya que se requiere con urgencia una intervención inmediata (conductas autolesivas, por ejemplo). En estos casos se puede emplear un diseño BABA. La intervención inmediata parece una buena idea en el caso citado, pero quizá no sea tan buena idea retirar el tratamiento para ver si vuelven las conductas autolesivas. En muchas ocasiones, aun cuando la conducta sea tan poco peligrosa como andar mal en una materia académica, no es deseable hacer que la conducta empeore después de haberse obtenido beneficios. En estos casos

podemos utilizar *diseños de línea base múltiple*. Aquí el investigador registra dos o más conductas (variables de registro) y aplica el mismo tratamiento de forma secuencial en el tiempo a cada una de ellas. Se inferirá que el tratamiento es efectivo si el cambio en las variables de registro se produce de forma secuencial y concomitante con la aplicación del tratamiento. Volviendo a los suspensos, si el infante en cuestión anda mal en varias materias académicas y el tratamiento consiste en enseñarle estrategias de estudio, podemos aplicar dicho tratamiento referido primero a las Matemáticas, con posterioridad a las Ciencias Sociales, luego a las Ciencias Naturales, etc. Si el tratamiento fuese efectivo deberíamos observar que se produce un cambio en el rendimiento académico a partir del punto de introducción del tratamiento. Un requisito que deben presentar las variables de registro es que sean independientes entre sí, es decir, que sólo deben presentar cambios a partir del punto en que se aplica el tratamiento. En nuestro ejemplo esto implicaría realizar el dudoso supuesto de que las estrategias de estudio son tan específicas de cada materia que no se puede generalizar sus beneficios de una asignatura a otra.

Finalizaremos este apartado señalando que la generalización de los resultados en este tipo de diseños se consigue bien mediante la replicación del experimento en forma exacta (replicación directa), buscando determinar si el cambio observado se debe al efecto del tratamiento, o bien replicando el experimento modificando alguna variable (replicación sistemática), buscando determinar la posibilidad de generalizar el efecto del tratamiento a otras personas, situaciones y ocasiones. En definitiva, los diseños de sujeto único procuran la suficiente validez interna y externa, variedad y flexibilidad, como para ser una herramienta de primer orden en la investigación psicológica y en la práctica clínica.

A modo de compendio terminaremos con una radiografía esquelética, por lo escueta y descarnada, de las investigaciones experimentales.



9.4. METODOLOGÍA CUASI EXPERIMENTAL

Sabemos que los resultados obtenidos en la investigación cuasi experimental no son tan fiables como los que se podrían obtener, en igualdad de condiciones, en la investigación experimental. Pero es precisamente la inexistencia de igualdad en condiciones lo que exige la investigación cuasi experimental. Existen condicionamientos de todo tipo —desde éticos hasta económicos o institucionales— que hacen en muchas ocasiones inviable la asignación aleatoria de los sujetos a las condiciones experimentales. Piénsese, por ejemplo, en el desbarajuste que supondría en un colegio implementar la investigación sobre los métodos docentes utilizando una regla de asignación aleatoria. Estamos seguros de que la dirección del centro permitiría, todo lo más, aplicar los métodos a grupos escolares ya formados. O es posible que debamos dar preferencia en la aplicación de los tratamientos a personas con ciertas características (las más enfermas, por ejemplo). Es en estas situaciones, harto frecuentes en Psicología, donde los diseños cuasi experimentales procuran esquemas de acción que minimizan los riesgos inherentes a la falta de aleatorización. Los diseños cuasi experimentales son muy útiles y son muy necesarios. Hay diseños mejores, es cierto. Pero hay veces en que lo mejor, simplemente, no puede ser. Y en esas situaciones, lo que puede ser, es lo mejor.

Si recuerdan la característica diferenciadora de los diseños cuasi experimentales frente a los experimentales es que la regla de asignación, el criterio que especifica qué sujetos van a cada condición experimental, nunca es aleatoria, pudiendo ser desconocida (diseños con grupo de control no equivalente) o conocida (diseños de discontinuidad en la regresión y diseños de series temporales interrumpidas). Será el tipo de regla de asignación la que determinará la estrategia de control de las VEs, el tipo de análisis estadístico y la potencia causal de los diseños que veremos a continuación. Pero antes de nada establezcamos algunas convenciones que facilitarán nuestro tránsito por la investigación cuasi experimental. Casi todos los diseños cuasi experimentales cuentan con un *grupo experimental* que recibe el tratamiento y un *grupo de control* que no lo recibe, y que se utiliza para controlar que los cambios observados en el grupo experimental se deben al tratamiento aplicado y no a otras variables, de ahí su nombre, grupo de control. Además, tanto en el grupo experimental como en el grupo de control se registran una serie de medidas de la VD que se denominan *pretest* si se toman antes del tratamiento y *posttest* cuando se toman después. Si utilizamos la letra *O* acompañada de un subíndice para señalar estas medidas y su orden de registro y señalamos la presencia de los tratamientos mediante el símbolo *X*, podemos representar esquemáticamente la estructura de cualquier diseño cuasi experimental al modo en que lo hacen Cook, Campbell y Peracchio (1990).

Así, por ejemplo, la estructura de un *diseño con grupo de control no equivalente con pretest y posttest* se representa en la siguiente forma:

	Pretest		Posttest
Grupo experimental	O ₁	X	O ₂
Grupo de control	O ₁		O ₂

9.4.1. Diseños con grupos de control no equivalente

Los diseños con grupo de control no equivalente son diseños con regla de asignación no aleatoria y desconocida. Veamos un ejemplo. Supongamos que aplicamos un programa para mejorar la habilidad lectora a niños de primaria que asisten al colegio A, sirviendo de grupo de control niños del mismo nivel educativo que asisten al colegio B. En este diseño no sabemos qué variable de asignación es la responsable de que los niños que reciben el tratamiento vayan al colegio A (puede ser la clase social, la zona de residencia, etc.), y los que no lo reciban estén en el B. Dado que no conocemos la variable de asignación es imposible ajustar las probables diferencias entre los grupos debidas a ella. En esta situación, ya que no podemos garantizar la equivalencia entre los grupos, lo que sí podemos hacer es intentar evaluar el grado de discrepancia existente entre ellos y, en el caso de que existan diferencias, intentar eliminarlas de los resultados mediante algún tipo de ajuste estadístico. Las medidas pretest responden a estos dos objetivos: evaluar la equivalencia inicial entre los grupos y posibilitar el ajuste estadístico para hacerlos equivalentes *a posteriori*. Las ventajas de este proceder, aunque importantes, no eliminan buena parte de las amenazas contra la validez interna del diseño. Supongamos que el grupo experimental obtiene en el posttest una puntuación más elevada que el grupo de control y que ambos grupos tienen puntuaciones similares en el pretest. En vista de esos datos resulta tentador concluir que el tratamiento ha sido efectivo. Desgraciadamente existen varias explicaciones alternativas de los cambios observados: que las tasas de maduración sean diferentes entre los grupos (la capacidad lectora es una habilidad altamente mediatizada por la maduración biológica) o que entre la medida del pretest y el posttest aconteciese algo que afectó diferencialmente a los grupos (por ejemplo, unos niños veían «Barrio Sésamo» y otros no). Para incrementar la validez interna del diseño expuesto y disminuir los riesgos señalados, se han propuesto modificaciones que van encaminadas, bien a aumentar el número de grupos de control, bien a incrementar el número de medidas pretest. Esta última estrategia es la que se aplica en el *diseño de grupo de control no equivalente con doble pretest*, que tiene la siguiente estructura:

	Pretest			Posttest
Grupo experimental	O_1	O_2	X	O_3
Grupo de control	O_1	O_2		O_3

Como podemos apreciar es un diseño especialmente adecuado para evaluar el efecto diferencial que la maduración pueda tener. Si no existiesen diferencias entre los grupos en procesos madurativos, deberíamos encontrar tasas de cambio similares entre O_1 - O_2 y O_2 - O_3 . Para que la estimación de este efecto sea correcta, debe procurarse que el intervalo de registro del primer y segundo pretest sea el mismo que el que existe entre el segundo pretest y el posttest.

Queremos terminar señalando que se ha presentado sólo una variante del esquema básico de los diseños con grupos de control no equivalente, pero existen infinitas. Todas ellas se caracterizan, sin embargo, por tener uno o más grupos de control y una o más medidas pretest. Las investigaciones que no cumplen las citadas características (es decir, tienen solo grupo experimental con o sin pretest, o tienen grupo experimental y control pero sin pretest) son investigaciones tan endebles para establecer inferencias causales que se les considera *investigaciones pre experimentales*. Dejamos a la inteligencia y a los conocimientos del lector la justificación de por qué la investigación pre experimental es mucho peor en términos de validez interna que la investigación cuasi experimental. Hecho este inciso, vayamos con nuevos diseños cuasi experimentales.

9.4.2. Diseños de discontinuidad en la regresión

La característica básica de los diseños de discontinuidad en la regresión es la utilización de una regla de asignación no aleatoria, pero conocida. Como podemos observar en la figura 9.4, los sujetos se asignan a las diferentes condiciones experimentales en función de una variable de asignación conocida, que en los diseños de discontinuidad en la regresión suele ser la puntuación en el pretest. En estos diseños, al conocer la variable de asignación, podemos ajustar estadísticamente su efecto sobre la VD eliminando una posible fuente de confundido.




FIGURA 9.4. Representación esquemática de un diseño de discontinuidad en la regresión.

Para llevar a cabo estos diseños debemos dar, en el orden en que se presentan, los siguientes pasos:

1. Obtener una medida pretest de todas las personas que formen parte de la investigación.
2. Asignar a los sujetos a las condiciones experimentales en función de su puntuación en el pretest. Para ello elegimos una puntuación en el pretest que marcará el *punto de corte* a partir del cual unas personas serán enviadas al grupo de control y otras al grupo experimental.
3. Aplicar los diversos niveles de tratamiento.
4. Tomar una medida posttest en ambos grupos para valorar el efecto del tratamiento.

El plan experimental establecido con anterioridad, sin embargo, no nos da ninguna pista sobre el nombre del diseño, y esto es bastante raro. Es una característica peculiar de estos diseños el hecho de que su nombre aluda no a su estructura —como en el caso de diseños anteriores— sino a una de las técnicas estadísticas que puede emplearse para analizarlos, las ecuaciones de regresión. ¿Pero para qué sirve una ecuación de regresión? Como ya se vio en el capítulo 5, las ecuaciones de regresión permiten, una vez establecida la relación entre dos variables, pronosticar con el menor error posible los valores de una de las variables (en nuestro caso el posttest) a partir del conocimiento de los valores de la otra (el pretest). Cuando la relación entre estas variables es lineal, la representación en un plano de los valores pronosticados caen a lo largo de una línea recta (la recta de regresión). Estos diseños se denominan de discontinuidad en la regresión porque el efecto del tratamiento está indicado por una ruptura en la recta de regresión de cada uno de los grupos en el punto de corte que se ha elegido para determinar a qué personas se les aplicará o no el tratamiento. No se asusten, que ahora lo explicaremos con calma. Utilizaremos para ilustrar este diseño un ejemplo hipotético adaptado de Marcantonio y Cook (1994, p. 145). Asumamos que podemos medir la gravedad de una enfermedad y que puntuaciones más altas indican mayor gravedad. Se decidió, por razones éticas, administrar un nuevo medicamento a aquellos pacientes que tuvieran puntuaciones en el pretest mayores o iguales al punto de corte fijado en 50, es decir, a los más enfermos (grupo experimental). Los pacientes que tuvieran puntuaciones inferiores recibirían el tratamiento tradicional (grupo de control). Al final del tratamiento se vuelve a evaluar el grado de enfermedad de los pacientes (medida posttest). En la figura 9.5 se ilustran dos de los posibles resultados.

Nótese que de cada persona tenemos 2 medidas (su puntuación en el pretest y en el posttest) que nos permiten representarla como un punto en




FIGURA 9.5. Resultado de un diseño de discontinuidad en la regresión en el que el tratamiento no ha sido efectivo (gráfico A) y otro en el que el tratamiento ha sido efectivo (gráfico B).

el plano. Por ejemplo, si una persona obtuvo una puntuación de 50 en el pretest y de 50 en el postest, estaría representada mediante un punto en el plano situado justamente donde se cortan las líneas que corresponden a 50 puntos en el pretest y 50 puntos en el postest. Además, en las gráficas podemos observar unas líneas (las rectas de regresión) que representan el valor pronosticado para cada posible puntuación en el pretest de acuerdo a la ecuación de regresión obtenida. Sigamos con el ejemplo: cuando el tratamiento no ha sido efectivo las puntuaciones que tenían en el pretest los enfermos se mantienen en el postest, tanto en el grupo de control como en el grupo experimental (gráfico A de la figura 9.5). Si ajustásemos una ecuación de regresión en cada uno de los grupos, las líneas de ambas ecuaciones coincidirían en el punto de corte utilizado para asignar a los sujetos al grupo de control (pretest < 50) y al grupo experimental (pretest ≥ 50), que es precisamente lo que ocurre en el gráfico A de la figura 9.5. Sin embargo, si el nuevo tratamiento fuese efectivo y el método tradicional no, los sujetos del grupo de control tendrían puntuaciones similares en el pretest y en el postest, en tanto los del grupo experimental tendrían puntuaciones mucho más bajas en el postest (las personas están menos enfermas por efecto del nuevo tratamiento). Esto implica que si ajustásemos una ecuación de regresión en cada grupo observaríamos una discontinuidad entre las líneas de las ecuaciones de regresión en el punto de corte, como se observa en el gráfico B de la figura 9.5.

La capacidad para establecer relaciones causales del diseño de discontinuidad en la regresión se debe a que es muy poco probable que existan explicaciones alternativas del cambio en las rectas de regresión que ocurre en el *punto exacto* definido por la variable de asignación. Existen diseños de discontinuidad en la regresión con múltiples VIs,

múltiples VDs, múltiples variables de asignación, pero todos ellos se basan en el mismo principio. Estos diseños exceden nuestro objetivo, pero si alguien quiere profundizar en esta temática le recomendamos el libro de Trochim (1984).

9.4.3. Diseños de series temporales interrumpidas

Las causas y los efectos tienen lugar en un espacio y un tiempo bien determinado, al menos para los que no trabajamos en física cuántica. Los diseños de series temporales asumen estructuralmente este hecho hasta el punto de poder definirlos como planes de investigación que posibilitan el estudio de las causas y los efectos a través del tiempo. No en vano los diseños de series temporales se realizan sobre una sucesión de observaciones de una variable tomada cronológicamente, lo que se denomina *serie de tiempo*. La mayor parte de las investigaciones que utilizan las series de tiempo interrumpidas son investigaciones cuasi experimentales que usan una regla de asignación no aleatoria pero conocida, que suele ser el tiempo. El investigador decide cuándo introducir el tratamiento y habitualmente lo hace de forma no aleatoria. Otra de las características de este tipo de diseños es que presentan la estructura más adecuada para evaluar intervenciones sobre variables de las que se lleva un registro puntual, tales como la inflación, el número de delitos, los accidentes de tráfico, el número de aprobados, el número de personas que ingresan en un determinado hospital, etc. Pasemos a ver la estructura del *diseño simple de series temporales interrumpidas*, que como su nombre indica es el más sencillo:

$$O_1 O_2 O_3 O_4 O_5 \dots O_{15} \mathbf{X} O_{16} O_{17} O_{18} O_{19} O_{20} \dots O_{30}$$

El esquema anterior se acomoda perfectamente al siguiente ejemplo: En unos grandes almacenes están interesados en determinar si la música ambiental hace que los potenciales consumidores compren más. Deciden utilizar como variable indicadora de las compras el número de artículos vendidos por día. Utilizarán como línea base para evaluar el efecto de la música los 15 primeros días del mes. A partir del día 16 y hasta final de mes se pondrá una suave música ambiente en todo el centro comercial. Durante esos 30 días se registró puntualmente el número de objetos vendidos por día. ¿Qué creen que pasará? En la figura 9.6 se puede observar la gráfica con la evolución de las ventas durante dicho mes.

En los diseños de series temporales interrumpidas el impacto de los tratamientos sobre la VD se evalúa atendiendo a los cambios de nivel (el cambio que se produce en el punto de introducción del tratamiento) y a los cambios de tendencia (el cambio que se produce en la serie conforme transcurre el tiempo) entre las fases pre y post tratamiento. En nuestro




FIGURA 9.6. Serie temporal que refleja la evolución de las ventas durante el mes de junio. El tratamiento (X) se introduce el día 16.

ejemplo tenemos un cambio de nivel, sin cambio en la tendencia. ¿Cómo interpretar estos resultados? La interpretación es bien sencilla. La tendencia descendente que exhibe la serie temporal conforme pasan los días, refleja fielmente el hecho de que se tiene más dinero a principios de mes que a finales, y esto determina la capacidad de compra. De otra parte, podemos concluir que el tratamiento es efectivo ya que cuando se introduce la música se consume más. En este caso la introducción del tratamiento no cambia la tendencia, sólo puede hacer que gasten más del cada vez más escaso dinero, lo que ya es bastante. Pero en otras series temporales podemos obtener otros resultados que nos indiquen también que el tratamiento ha tenido algún efecto: cambio de tendencia sin cambio de nivel, o cambio simultáneo de nivel y de tendencia. Cuando no exista ni cambio de nivel ni de tendencia entre las fases pre y post tratamiento, concluiremos la ineficacia del tratamiento.

Si quisiéramos mejorar la validez interna del anterior diseño podríamos introducir y retirar el tratamiento en más de una ocasión en el mismo grupo (*diseños de series de tiempo interrumpidas con replicaciones múltiples*)


$O_1 O_2 \dots O_5 \mathbf{X} O_6 \dots O_{10} O_{11} O_{12} \dots O_{15} \mathbf{X} O_{16} \dots O_{20} O_{21} O_{22} \dots O_{25} \mathbf{X} O_{26} \dots O_{30}$
Retirada Retirada

o aplicar el tratamiento en un momento temporal diferente en otro grupo (*diseños de series temporales interrumpidas con replicaciones intercambiadas*)

Grupo 1 $O_1 O_2 O_3 O_4 O_5 \dots O_{10} O_{11} O_{12} \dots O_{20} \mathbf{X} O_{21} O_{22} O_{23} O_{24} O_{25} \dots O_{30}$
Grupo 2 $O_1 O_2 O_3 O_4 O_5 \dots O_{10} \mathbf{X} O_{11} O_{12} \dots O_{20} O_{21} O_{22} O_{23} O_{24} O_{25} \dots O_{30}$

De esta forma, aunque sigue siendo posible que los efectos del tratamiento se confundan con los de alguna variable que afecte a la serie temporal, es muy, muy poco probable, que empiece a actuar en los varios y diferentes puntos de tiempo en que se administra el tratamiento. Estas estrategias aumentan de manera considerable las garantías con las que podemos establecer una relación causal entre la VI y la VD, y ése es, en definitiva, el objetivo perseguido por todos y cada uno de los diseños tratados en este capítulo. Como ya saben, en lo que difieren los diferentes planes de investigación es en la forma y el grado en que lo logran.

En el siguiente diagrama se presenta la clasificación de los diseños cuasi experimentales vistos. Ahora ya tienen una idea global de la metodología experimental y cuasi experimental, conocen algunos de sus principales diseños, sus partes y sus lógicas. Conocen muchas cosas, y sólo les falta una.



9.5. LO ÚLTIMO ES LO PRIMERO

En las investigaciones el cumplimiento de las normas y de los controles vistos a lo largo del capítulo no garantizan los resultados deseados, al igual que no los garantizaba en la religión romana la estricta observancia de los rituales. La voluntad de los dioses, el azar, la suerte, como quiera llamársele, también rige el destino de las investigaciones. Si les preguntase a ustedes qué creen que es más importante para realizar una buena investigación, probablemente responderían que el control de las VEs o la operacionalización de la VI o quizá la realización de unos buenos análisis estadísticos. Y es cierto, eso es muy importante, pero hay algo mucho más importante, algo esencial y único: el investigador. Eso es lo más importante en cualquier investigación. Den 200 millones a un tonto para investigar y sólo habrán conseguido hacer una tontada. A veces,

como decía Ortega, los árboles no nos dejan ver el bosque. Espero que a lo largo de este capítulo hayan visto los árboles y hayan visto los bosques.

9.6. PUNTOS BÁSICOS

- Históricamente la ciencia es una forma de conocimiento tardía que ha adquirido una primacía absoluta debido a las posibilidades de control del mundo que ofrece.
- El objetivo básico de la metodología experimental y cuasi experimental es el establecimiento de relaciones causales entre la VI (causa) y la VD (efecto), y para ello es esencial un buen control de las VEs (posibles explicaciones alternativas).
- En términos de varianzas, el objetivo antedicho será más fácilmente lograble si *MAX*imizamos la varianza sistemática primaria, *MIN*imizamos la varianza error y *CON*trolamos la varianza sistemática secundaria.
- Las VEs se pueden controlar antes de realizar el experimento, mediante la planificación adecuada de la investigación (control experimental) o después de haberse realizado el experimento, aplicando técnicas estadísticas (control estadístico). El control experimental puede ser directo (mediante la eliminación o la constancia) o indirecto (mediante la aleatorización).
- Las investigaciones se realizan sobre un número limitado, y casi siempre pequeño, de sujetos. Por ello, para poder generalizar los resultados obtenidos, necesitamos recurrir a los modelos matemáticos, en particular a la estadística inferencial.
- La calidad de una investigación se evalúa atendiendo a una serie de aspectos —validez teórica, de constructo, de conclusión estadística, interna y externa— que pueden darse y mezclarse en muy diverso grado.
- La diferencia entre un experimento (metodología experimental) y un cuasi experimento (metodología cuasi experimental) estriba en el mayor control de las VEs que existe en el primero gracias a utilizar la aleatorización como técnica de control.
- En los diseños experimentales clásicos se produce una reducción de la varianza error conforme aumenta el número de VEs controladas directamente.
- Los diseños experimentales de sujeto único se caracterizan, frente al resto de los diseños experimentales, por no utilizar la aleatorización como técnica de control de las VEs, sino un fuerte control experimental junto con el establecimiento de un periodo de línea base.

- Los diseños cuasi experimentales son planes de investigación en los que la regla de asignación de los sujetos a las condiciones experimentales nunca es aleatoria.

9.7. EJERCICIOS

9.7.1. Indique mediante flechas la palabra que crea que describe mejor las siguientes formas de conocimiento:

Religioso	Especulativo
Filosófico	Experimental
Científico	Revelado

9.7.2. Un pavo ve, día tras día, cómo tras abrirse la puerta del corral se le da de comer. Se abre la puerta y aparecen los granos de maíz. Desde siempre, se abre la puerta y aparecen los granos de maíz. Así, día tras día. Sin embargo, un 24 de diciembre se abre la puerta y no sólo no le echan de comer, sino que se lo comen. ¿Qué principio filosófico se ilustra en este breve cuento de Navidad?

9.7.3. Clasifique, atendiendo a criterios metodológicos y manipulativos, las variables que forman parte del ejemplo expuesto para ilustrar los diseños de bloques homogéneos aleatorizados (Apartado 9.3.2).

9.7.4. Señale brevemente cuál es la finalidad de los análisis estadísticos que se suelen realizar en las investigaciones.

9.7.5. ¿En función de qué clase de validez se clasifica a una investigación como experimental o cuasi experimental?

9.7.6. Ponga en relación los distintos tipos de validez de la columna de la izquierda con los conceptos de la columna de la derecha:

V. teórica	Apoyo teórico
V. de constructo	Control
V. de conclusión estadística	Generalización de resultados a otras situaciones
V. interna	Validez de las variables
V. externa	Formulación y ajuste de modelos matemáticos

9.7.7. ¿Cuál de las tres palabras que forman el lema de la Revolución Francesa (Libertad, Igualdad y Fraternidad) es deseable que cumplan las unidades experimentales? ¿Por qué?

9.7.8. El gerente de una empresa está interesado en determinar el efecto que la música pueda tener sobre el rendimiento laboral en los operarios de una cinta transportadora (su misión es apartar los envases defectuosos). Para ello aplicamos un diseño de medidas repetidas en el que cinco personas escucharán cinco tipos de música diferente (A1 hasta A5), uno por día laborable. Como sabemos, la asignación del orden de aplicación de los tratamientos en este tipo de diseños es aleatoria e independiente para cada sujeto. El resultado de la aleatorización fue el siguiente:

Sujeto	Lunes	Martes	Miércoles	Jueves	Viernes
1	A5	A4	A1	A3	A2
2	A5	A4	A3	A1	A2
3	A3	A1	A4	A5	A2
4	A4	A3	A2	A1	A5
5	A1	A3	A4	A5	A2

¿Qué problema ve usted en este diseño?

9.7.9. Si en una investigación farmacológica se aplicase un diseño de medidas repetidas, ¿cuál de los siguientes efectos cree que es más probable que ocurra? Los efectos del orden, los efectos de la práctica o los efectos residuales.

9.7.10. Señale la verdad o falsedad de las siguientes afirmaciones realizadas sobre los diseños cuasi experimentales:

- Utilizan la aleatorización como estrategia de control de las VEs.
- Se adaptan mejor que los diseños experimentales para la investigación en contextos aplicados (Psicología social, educativa, etc.).
- La VI en ocasiones puede ser una variable asignada.
- Una estrategia para mejorar su validez interna es aumentar el número de grupos, de medidas pretest o de veces que se presenta el tratamiento.

9.8. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

9.8.1. Religioso → Revelado; Filosófico → Especulativo; Científico → Experimental.

9.8.2. El cuento es una ejemplificación de la crítica humeana al principio de causalidad. Regularidades pasadas (que siempre que se abrió la puerta apareció la comida) no permiten realizar implicaciones causales de orden lógico (que siempre que se abra la puerta aparecerá la comida), como bien pudo comprobar el pavo el último día de su vida.

9.8.3. Criterios metodológicos:

Variables explicativas: VI - método docente; VD - rendimiento en Matemáticas; VE controlada (variable de bloqueo): cociente intelectual.

Criterios manipulativos:

Variable activa: método docente.

Variable asignada: cociente intelectual.

9.8.4. El objetivo de los análisis estadísticos que acompañan al experimento es ayudar a extraer la máxima información de los datos de la investigación de una manera válida y fiable y, cuando ello es posible, generalizarla a la población.

9.8.5. La distinción entre una investigación experimental y una cuasi experimental estriba en el mayor control de las VEs que ofrece la primera al incorporar como técnica de control la aleatorización. Dicho de otro modo, y contestando a la pregunta, la investigación experimental tiene mayor validez interna que la investigación cuasi experimental.

9.8.6. V. teórica → Apoyo teórico; V. de constructo → Validez de las variables; V. de conclusión estadística → Formulación y ajuste de modelos matemáticos; V. interna → Control; V. externa → Generalización de resultados a otras situaciones.

9.8.7. La igualdad, porque cuanto más homogéneas sean las unidades experimentales menor será la varianza error. Nótese que esta forma de reducir la varianza error la incorporan de forma activa los diseños de bloques homogéneos aleatorizados y los diseños de medidas repetidas.

9.8.8. Como se puede observar, por azar, hay un tipo de música (A2) que coincide casi siempre el viernes. De esta forma, si el día de la semana

influye en el rendimiento laboral, cosa bastante previsible, la estimación del efecto del tratamiento A2 estará contaminada por el hecho de haberse aplicado casi siempre en viernes.

9.8.9. A falta de más información, el efecto secundario indeseable que es más probable que ocurra es el residual. Cualquier fármaco ingerido tarda un tiempo variable en ser eliminado del organismo, y habrá que respetar estos tiempos en el caso de aplicar un diseño de medidas repetidas.

9.8.10. a) F; b) V; c) F; d) V.

9.9. BIBLIOGRAFÍA BÁSICA RECOMENDADA

ANGUERA, M. T., ARNAU, J., ATO, M., MARTÍNEZ ARIAS, R., PASCUAL, J. y VALLEJO, G. (Eds.) (1998). *Métodos de investigación en Psicología* (1.ª reimpresión). Madrid: Síntesis.

Libro riguroso, de dificultad media-alta, en el que se exponen los principales diseños experimentales y cuasi experimentales, así como los modos de análisis estadístico que llevan asociados más comúnmente.

CAMPBELL, D. T. y STANLEY, J. C. (1966). *Experimental and Quasi-Experimental Designs for Research*. Chicago, Ill.: Rand McNally. (Traducción española: *Diseños experimentales y cuasiexperimentales en la investigación social*. Amorrortu, Buenos Aires, 1973.)

Un libro clásico en la investigación cuasi experimental. Original, breve y ameno.

LEÓN, O. G. y MONTERO, I (2003). *Métodos de investigación en Psicología y Educación* (3.ª edición). Madrid: McGraw-Hill.

Libro muy sencillo escrito en un estilo ágil y lleno de ejemplos. Resulta ideal como primera aproximación a los diseños experimentales y cuasi experimentales.

9.10. MATERIAL COMPLEMENTARIO

Investigaciones *ex post facto*.

Diis deabusque quos ius fasque est precari in Pantheo. Ángel M. Fidalgo, Leoncio filius, dicavit.

METODOLOGÍA DE ENCUESTAS

Guillermo Gil Escudero
María Rosario Martínez Arias

10.1. INTRODUCCIÓN

En el mundo actual la utilización de información específica sobre los temas que afectan a la vida de las personas se ha convertido en un elemento esencial tanto en la vida diaria como en el ámbito profesional. Por ello las encuestas, al constituir un sistema de obtención de información de grupos determinados de individuos, se han establecido como un elemento cotidiano en muy diversos órdenes de la vida de las personas. Los sondeos de opinión en el marco de la actividad política, los estudios de mercado en el ámbito comercial y los estudios de opinión sobre temas de actualidad son algunos ejemplos de campos que utilizan las encuestas como medio de obtención de información que sea relevante para la toma de decisiones.

La Psicología y la Educación, en cuanto disciplinas sociales cuyo elemento fundamental son las personas o los grupos de personas, utilizan de modo habitual la metodología de encuestas tanto para su desarrollo conceptual y teórico como para la obtención de información dirigida a las aplicaciones prácticas. Por tanto, la Psicopedagogía y los psicopedagogos como profesionales que actúan en el mundo educativo pueden asimismo hacer uso de las encuestas como herramienta de trabajo que facilite su labor. Como un ejemplo, supóngase que el equipo directivo de un centro educativo debe planificar las actividades extraescolares para el próximo curso escolar. Su experiencia de años precedentes dice que algunas de las actividades tuvieron poca aceptación por parte de los alumnos y de los padres, mientras que otras actividades extraescolares tuvieron un exceso de demanda, lo que no permitió atender a los intereses de todos los alumnos y sus familias. Unos miembros del equipo directivo piensan que la razón de los desequilibrios que se produjeron fue el escaso interés de las actividades que se ofertaron, otros piensan que los desequilibrios se produjeron por los horarios de las actividades, mientras que otros piensan

que el factor determinante fue el costo económico adicional de las mismas. Parece claro que obtener información sobre las actividades extraescolares preferidas, sobre los horarios más convenientes y sobre la opinión de las familias sobre su costo puede ayudar a una mejor planificación y a comprender qué factores afectan a su éxito.

Supóngase, como segundo ejemplo de encuesta relevante en el mundo educativo, que los medios de comunicación informan sobre los resultados promedio obtenidos en Matemáticas por los alumnos españoles en una encuesta realizada por un organismo internacional. Los resultados de los alumnos españoles se sitúan en el puesto 20 en relación con el resto de los 30 países participantes. Los comentarios de los medios de comunicación hacen hincapié en los malos resultados obtenidos. Sin embargo, no informan de las características de los países que han obtenido mejores y peores resultados ni qué factores afectan a dichos resultados. Para valorar los resultados de dicha encuesta, un lector puede hacerse, entre otras, las siguientes preguntas: ¿son los países con renta *per cápita* más alta los que han obtenido los mejores resultados?, ¿son los que invierten en educación un porcentaje mayor de la riqueza nacional?, ¿son los que tienen un mayor número de días y horas de clase?, ¿son los que tienen, como promedio, un menor número de alumnos por clase?, ¿cuál sería la situación del rendimiento de los alumnos españoles si la riqueza nacional y la inversión en educación fuesen las mismas que en los países con mejores resultados?, ¿hasta qué punto el nivel socioeconómico y cultural de las familias, así como su interés por la educación y la inversión familiar en educación influyen en los resultados de los alumnos? Las respuestas a estas preguntas podrían ayudar a interpretar de modo correcto los resultados de la encuesta y, tal vez, poner de manifiesto que la valoración negativa de los resultados no está justificada, así como a valorar la credibilidad de dichos resultados.

Gran parte de las investigaciones en Psicología y Educación se llevan a cabo mediante la metodología de encuestas, debido a que no es posible —tanto por razones éticas como prácticas— manipular las variables que afectan, o pueden afectar, a la conducta de los sujetos tal y como se puede hacer en las situaciones experimentales de laboratorio con el método experimental. Siguiendo el ejemplo anterior, es claro que para probar que el número de horas de clase es un factor importante en el rendimiento de los alumnos no puede reducirse, o eliminarse, el número de horas de clase de Matemáticas de varios grupos de alumnos para asignarlos a determinados grupos experimentales, a la vez que se incrementa el horario de Matemáticas de otros grupos a costa de otras materias para asignarlos a otros grupos experimentales. ¿Sería ético en este caso producir un posible perjuicio a los alumnos que no hubiesen recibido instrucción en Matemáticas, o a los alumnos que, por haber recibido gran número de clases

en Matemáticas, no las hubiesen recibido en otras materias como Ciencias, Literatura, etc.?

Parece evidente que en el campo de la Psicología y la Educación, la investigación mediante encuestas es un instrumento muy adecuado para desarrollar el conocimiento de la conducta humana y de los procesos educativos, así como para tomar decisiones, al permitir el análisis de la realidad sin intervenir *a priori* en la misma, dado que las encuestas se fundamentan en la obtención de información sobre la realidad, tal y como se presenta en un momento determinado, y en el análisis de las relaciones entre la multitud de variables que configuran la actuación humana.

Los contenidos que se van a desarrollar en este capítulo se centran en torno a cinco cuestiones fundamentales señaladas en el siguiente esquema-resumen que relaciona dichas cuestiones con los siguientes cinco apartados del capítulo:

¿Qué son las encuestas?	➡ Concepto y delimitación de las encuestas
¿Cuáles son los diferentes tipos de encuestas?	➡ Tipos de encuestas
¿Cómo se lleva a cabo una encuesta?	➡ Fases de una encuesta
¿Cómo se puede recopilar la información?	➡ Procedimientos de recogida de la información
¿Cómo se seleccionan los sujetos a encuestar?	➡ Técnicas de muestreo

Con la respuesta a las preguntas anteriores se persiguen dos objetivos generales:

- conocer los aspectos básicos de la metodología de investigación con encuestas de modo que se sea capaz de planificar y llevar a cabo investigaciones de este tipo;
- ser capaz de evaluar críticamente la calidad de investigaciones realizadas mediante encuestas por otros investigadores así como interpretar adecuadamente sus resultados.

Para lograr estos dos objetivos generales será necesario:

- comprender el concepto de la metodología de investigación con encuestas;
- distinguir en qué situaciones es adecuado utilizar las encuestas;

- conocer los diferentes tipos de encuestas;
- analizar las etapas principales en la realización de una encuesta;
- conocer los principales métodos para la definición y obtención de una muestra;
- considerar algunas características importantes de la presentación de resultados;
- reflexionar sobre algunos aspectos relativos a la interpretación y uso de las encuestas.

10.2. CONCEPTO Y DELIMITACIÓN DE LA METODOLOGÍA DE ENCUESTAS

10.2.1. Definición

La metodología de investigación a través de encuestas consiste en un conjunto de procesos para la recopilación de información a partir de un grupo de sujetos sobre aspectos que resultan difícilmente observables directamente por el investigador, bien por ser estos subjetivos o bien porque sería imposible o excesivamente costosa su recopilación a través de la observación directa u otros métodos de observación; la información se recopila mediante un conjunto de preguntas limitado que intenta cubrir las necesidades de información del investigador, bien para describir alguna de las características de dichos sujetos o bien para analizar las relaciones entre algunas de sus características. Se examinan a continuación qué significan cada uno de estos términos en la definición anterior.

En esta descripción, el término «procesos» se refiere a las acciones que es necesario llevar a cabo para obtener la información relevante para el promotor de la encuesta. Estos procesos abarcan desde las tareas más básicas —tales como la definición de la finalidad de la encuesta, la delimitación de la información que se desea obtener, la toma de decisiones sobre el diseño, los recursos a invertir, la planificación de la encuesta y el ámbito de la audiencia a la que se difundirán los resultados— hasta los detalles técnicos —tales como cuál será el formato y redacción de cada pregunta, cómo se codificarán y registrarán las respuestas de los encuestados, qué técnicas estadísticas se utilizarán para analizar las relaciones entre variables y qué tipo de tablas, gráficos y comentarios se utilizarán para presentar los resultados.

La «recopilación de información» hace referencia a la elaboración del instrumento, o instrumentos, de la encuesta que contienen el conjunto de

preguntas a través de las cuáles se pretende obtener la información deseada, así como al conjunto de las acciones necesarias para la recogida y el tratamiento de la misma.

La expresión «grupo de sujetos» se refiere a una población determinada, habitualmente personas consideradas individualmente, aunque en algunos casos los «sujetos» o «unidades básicas» de la encuesta pueden ser grupos de personas o de entidades de otro tipo —por ejemplo, una encuesta puede estar dirigida a recopilar información factual sobre los centros educativos o sobre los servicios psicopedagógicos de los mismos, por lo que en algunos casos puede resultar irrelevante qué persona, o grupo de personas, responde específicamente a la encuesta, dado que lo importante, en este ejemplo, es la información sobre el conjunto del centro o el equipo psicopedagógico.

Al hacerse mención a un «conjunto de preguntas limitado» se quiere enfatizar que, aunque en muchas ocasiones para obtener información sobre un aspecto determinado podrían realizarse múltiples preguntas, el investigador selecciona de entre todas ellas un grupo definido y limitado de preguntas, que proporcionan una información parcial que trata de ser representativa del aspecto a medir, por razones de diversa índole —desde las limitaciones de tiempo para encuestar a los sujetos a razones de privacidad, confidencialidad o legalidad—. Por ejemplo, para analizar el interés e implicación de las familias con el progreso educativo de sus hijos el investigador puede definir algunos ámbitos, y dentro de ellos algunas preguntas, que considere son buenos indicadores de dicho interés (tales como el número de entrevistas de los padres con el tutor de su hijo, la frecuencia con la que le ayudan a hacer los deberes, el conocimiento que tienen de sus calificaciones escolares, los recursos educativos en el hogar —libros, diccionarios, enciclopedias, computadora, etc.—) mientras que deja fuera de la encuesta otras posibles preguntas que podrían aumentar la calidad de la información recopilada, pero también aumentar el tiempo necesario para cumplimentar la encuesta lo que conlleva una mayor probabilidad de que los padres no respondan a la misma.

Por último, la descripción anterior del método de encuesta menciona las «necesidades de información del investigador» que se corresponden con el conjunto de datos que se necesitan para conocer un fenómeno, bien para la toma de decisiones específicas o bien para la acumulación de evidencia que desconfirme o ratifique una teoría o conjunto de ideas sobre los mecanismos de funcionamiento de un determinado fenómeno.

No existe una única definición de la metodología de encuestas. Cada autor en los diversos textos y trabajos sobre el tema proporciona la que

considera más conveniente desde su perspectiva teórica y su campo de aplicación.

MC Definición de la metodología de encuestas

10.2.2. Uso de la metodología de encuestas

La utilización de la metodología de encuestas resulta adecuada cuando el fin primordial de la investigación es el estudio de las características de una población y de las relaciones entre dichas características, dado que su propiedad fundamental es su capacidad para generalizar los resultados obtenidos con una muestra de la población a la población en su conjunto y cuando las características de la población que se desean estudiar no son observables directamente, son difícilmente observables o su observación es muy costosa —p. ej., cuando se quiere obtener información sobre conductas de los sujetos en el pasado, o sobre sus actitudes, sentimientos u opiniones.

Las encuestas tienen la capacidad de analizar las situaciones tal y como se presentan en la vida normal por lo que son la metodología a seguir cuando no es posible, bien por razones éticas o por razones prácticas, asignar los sujetos a grupos experimentales con diferentes tratamientos, dado que los sujetos están afectados de forma natural en la realidad por diferentes variables. Por ejemplo, supóngase que se quiere estudiar el efecto que tiene sobre el rendimiento académico el tiempo que pasan los alumnos de educación primaria en el transporte escolar. Desde un punto de vista puramente experimental se deberían asignar los alumnos aleatoriamente a grupos con diferentes valores de la variable *tiempo de transporte*. Evidentemente, sería dudosamente ético hacer permanecer a algunos alumnos que viven muy cerca del centro escolar circulando en autobús con fines experimentales y, por otro lado, sería imposible asignar aleatoriamente a alumnos que viven lejos de su centro a los grupos experimentales con poco tiempo de transporte o sin transporte en autobús. Sin embargo, la realidad produce por sí misma el que los alumnos estén sometidos a diferentes valores de la variable *tiempo de transporte*, por lo que la utilización de una encuesta para el estudio del efecto de esta variable sobre el rendimiento permite no modificar la realidad, sino analizarla tal y como se presenta —considerando al mundo como un laboratorio natural en el que los sujetos están incluidos en grupos con características diferentes— preguntando a los alumnos por el tiempo que invierten en el

transporte, analizando su rendimiento y controlando estadísticamente *a posteriori* los valores de las variables bajo estudio.

Desde otro punto de vista, la metodología observacional es muy adecuada para el estudio de fenómenos en su entorno natural pero resulta excesivamente costosa, tanto en términos de recursos como de tiempo, para analizar un número de casos que sea representativo de una determinada población. En el ejemplo anterior, sin duda la metodología observacional podría aportar datos e informaciones de alto interés explicativo para el estudio de los efectos del transporte escolar en el rendimiento de los alumnos, al poder observar múltiples variables y la dinámica que se establece entre las mismas en dicha situación específica y para casos determinados.

Resulta claro que la metodología de encuestas puede, y debería en muchos casos, complementarse con las contribuciones de las metodologías observacional y experimental, dado que las encuestas tienen también limitaciones tanto en cuanto al control y manipulación de determinadas variables y al establecimiento de relaciones de causalidad como en cuanto a su capacidad para obtener información detallada y fiable sobre situaciones naturales en muchas ocasiones.

MC Comparación de las encuestas con otros métodos de investigación

Al tomar la decisión de realizar una encuesta, especialmente en el mundo educativo, debe tenerse en cuenta que su realización y sus instrumentos, además de servir para recopilar información, constituyen en sí mismos un mensaje que se transmite a los encuestados y a su entorno. Por ello, siempre que se realice una encuesta deberá tenerse en cuenta el mensaje que transmite la misma y las posibles interpretaciones que pueden hacerse de su realización, métodos y contenidos. Por ejemplo, cuando las autoridades educativas llevan a cabo encuestas a profesores sobre su satisfacción con el sistema de dirección educativa o a alumnos sobre su rendimiento académico, además de obtener un conjunto de informaciones, están transmitiendo de modo general el mensaje de que los temas de la administración escolar y los resultados de los alumnos son de interés prioritario para su política educativa.

Asimismo, los contenidos de los cuestionarios y pruebas constituyen mensajes en sí mismos que deben ser analizados y tenidos en cuenta en el diseño de una encuesta. Por ejemplo, al incluir en un cuestionario sobre la didáctica de los profesores un grupo amplio de preguntas sobre el grado en que los profesores trabajan en grupo y cooperan entre sí en la

programación y desarrollo de la enseñanza, se pueden formular las preguntas de modo que se transmita la idea de que esta práctica es deseable, además de promover la reflexión de los encuestados sobre el papel de la cooperación en su docencia. De modo similar, una prueba de rendimiento académico puede requerir de los alumnos un conocimiento de carácter memorístico mientras que otra prueba puede contener cuestiones que requieran tener la capacidad de extrapolar, generalizar y solucionar problemas, transmitiendo cada una de ellas mensajes diferentes al alumnado y al profesorado sobre lo que se entiende que es un buen rendimiento académico y sobre qué orientación debe darse al proceso de enseñanza.

Por último, es oportuno señalar que al utilizar encuestas deben tenerse en cuenta ciertas consideraciones éticas. En toda encuesta debe informarse explícitamente a los encuestados de quién es el promotor de la encuesta y de cuáles son sus objetivos; debe también asegurarse que la participación de los encuestados sea voluntaria —una participación forzosa lleva en muchas ocasiones a respuestas poco veraces y fiables—, así como garantizar que la información se utilizará exclusivamente para los fines de la encuesta. Por último, debe protegerse a los encuestados de cualquier consecuencia que pueda derivarse de la utilización de los datos o resultados de la encuesta, a través del anonimato y la confidencialidad de la información siempre que sea posible, por lo que deberá definirse previa y claramente quién puede tener acceso a la información obtenida.

10.3. TIPOS DE ENCUESTAS

Existen múltiples modos de clasificar las encuestas en función de sus características más distintivas bien en función del grado de cobertura de la población o bien en función de su objetivo, de su diseño, de la población a la que van dirigidas (p. ej., alumnos, profesores, padres, etc.) y de su unidad de análisis (p. ej. alumnos, clases, cursos, centros, provincias, comunidades, etc.), de su tema o contenidos (p. ej. hechos, opiniones, actitudes, satisfacción, conocimientos, etc.), de la técnica de muestreo utilizada (probabilística o no probabilística), del grado de interacción entre el entrevistador y el encuestado, del grado de definición de la información a recopilar o del procedimiento de recogida de datos. En el apartado 10.5 se introducirá la clasificación correspondiente a esta última variable. En este apartado se describen los rasgos más destacables de las encuestas censales frente a las muestrales, así como de las descriptivas frente a las explicativas y de las transversales frente a las longitudinales, y se mencionan las encuestas de cohortes y retrospectivas. Existen otros muchos diseños de encuestas que se fundamentan en diver-

sas combinaciones de los diseños de encuestas antes mencionados. Los trabajos de Martínez Arias (1995b) y Gómez (1990) presentan con más detalle tales diseños.

10.3.1. Encuestas censales y muestrales

El grado de cobertura de la población diferencia dos tipos importantes de encuestas, los censos o encuestas censales y las encuestas muestrales. En las primeras se intenta obtener datos de todos los elementos de la población bajo estudio. Este tipo de encuestas suele ser caro cuando la población es grande (p. ej. en los censos de habitantes de un país) y suelen recopilar un pequeño número de datos para mantener la tasa de respuesta en niveles muy altos y adaptarse a tiempos de recopilación de datos proporcionalmente muy breves. Desde un punto de vista conceptual unas elecciones o un referéndum son ejemplos de encuestas censales con una única pregunta y realizadas en un único día. Las encuestas censales son también indicadas cuando el número de elementos de la población es relativamente pequeño y sus elementos son bien conocidos y fácilmente localizables. Por ejemplo, una encuesta dirigida a las familias de los alumnos de un centro sobre la satisfacción de los padres con el mismo y con el profesorado puede planificarse como una encuesta censal, aunque no se logre que todas las familias respondan a la misma.

Las encuestas muestrales son aquellas en las que, debido al elevado número de elementos de que consta la población, es preferible encuestar solamente a una parte de la población que sea representativa de la misma, de modo que la diferencia encontrada en los resultados obtenidos con la muestra sea mínima en relación con los que se habrían obtenido al encuestar a la población en su totalidad. Por ejemplo, si se quieren conocer los hábitos de estudio de los estudiantes de educación secundaria en el conjunto del país y analizar si estos hábitos cambian según la edad de los alumnos, el género y el tipo de centro en el que están matriculados, resultaría excesivamente costoso encuestar de modo censal a los millones de estudiantes que conforman dicha población, por lo que en este caso la aproximación más razonable sería extraer una muestra en la que estuviesen suficientemente representados los alumnos de diferentes edades, género y tipos de centro.

10.3.2. Encuestas descriptivas y explicativas

El objetivo de las encuestas ha constituido una dimensión clásica para su diferenciación. De ese modo se ha distinguido entre encuestas

descriptivas y explicativas o analíticas. Una encuesta descriptiva está dirigida a obtener cierta información sobre una población, o sobre subgrupos de la misma, en términos estadísticos descriptivos, es decir, información cuantitativa sobre el verdadero valor de una característica o variable de la misma. Las encuestas explicativas o analíticas tienen por objetivo estudiar las relaciones que se dan entre los fenómenos del mundo real, es decir, analizar las relaciones entre las diferentes características y entre las variables que afectan en diverso grado a los elementos de una población. Para ello, habitualmente se llevan a cabo comparaciones entre subgrupos de la población que poseen diferentes características y que están afectados por diversas variables en varios grados. Desde un punto de vista más operativo las encuestas analíticas recopilan información sobre un conjunto de variables predictoras o explicativas que se supone influyen a las variables criterio de interés. En este tipo de encuestas hay siempre un modelo teórico que especifica las relaciones entre los conceptos y entre las variables que los representan, modelo que los investigadores intentan examinar con el objeto de mejorar la comprensión de la trama de factores que influyen las conductas bajo estudio.

No obstante, hay que señalar que la diferenciación entre encuestas descriptivas y explicativas es más teórica que real en los ámbitos de la Psicología y la Educación, ya que es difícil encontrar una encuesta en estas áreas en la que, una vez descritos los rasgos de una población, no se intente dar una explicación de las causas de la conducta o rasgo bajo estudio, de los contextos que influyen sobre ella o de las razones por las que se encuentran diferencias entre los subgrupos de una población. Las encuestas explicativas, al pretender establecer explicaciones y relaciones de consecuencia entre las variables, están estrechamente unidas a la comprobación de hipótesis así como a los métodos predictivos y de análisis causal que intentan identificar los factores que son el origen de los fenómenos observados. Normalmente los enfoques descriptivo y analítico no son mutuamente excluyentes sino que, por el contrario, se encuentran habitualmente combinados en las encuestas.

Entre los muy diversos tipos de encuestas según su objetivo destacan también los sondeos electorales, que son encuestas muestrales que permiten hacer predicciones sobre la intención de voto de la población total que será encuestada mediante un proceso electoral de tipo censal, los estudios de mercado que pretenden conocer las necesidades y preferencias de los consumidores y los estudios epidemiológicos, que intentan conocer la prevalencia de alguna característica de la población en cuestiones médicas y psicológicas.

10.3.3. Encuestas transversales y longitudinales

En cuanto a su diseño las encuestas se han clasificado básicamente en función de su estructura temporal y poblacional distinguiéndose básicamente entre encuestas transversales y longitudinales (*véase* figura 10.1) Las encuestas transversales constituyen el tipo básico de encuesta y sirven de punto de referencia para la definición de los restantes tipos. Se caracterizan por recoger información una única vez en un periodo delimitado en el tiempo y de una población definida y, en consecuencia, sus resultados son generalizables a dicho momento y dicha población. Ejemplos de este tipo podrían ser una encuesta sobre el uso del alcohol y el tabaco entre los estudiantes de educación secundaria en el año 2000 o una encuesta sobre la satisfacción del profesorado de formación profesional con sus condiciones laborales al final del curso 2000-2001. Los estudios transversales son especialmente adecuados para el estudio de variables estables en el tiempo, dado que la observación se realiza en un determinado momento temporal. Este tipo de diseños puede utilizarse tanto para propósitos descriptivos como para el estudio de relaciones entre variables en el momento del estudio, aunque su principal inconveniente reside en que, a la hora de plantear explicaciones causales, los investigadores solamente pueden basarse en supuestos lógicos y temporales que justifiquen las secuencias entre causas y efectos para definir qué factores son causa de las conductas observadas.

		NÚMERO DE APLICACIONES	SUJETOS ENCUESTADOS
TRANSVERSALES		1	—
	De Panel	2 o más	Los mismos
LONGITUDINALES	De Tendencias	2 o más	Diferentes; Muestras equivalentes en cuanto a las características de los sujetos
	De Series Temporales		
	De Cohortes	2 o más	Diferentes; Muestras equivalentes en cuanto al tiempo

FIGURA 10.1. Tipos de encuestas atendiendo a su estructura temporal y poblacional.

Las encuestas longitudinales están dirigidas al análisis de los procesos de cambio y desarrollo en los que el paso del tiempo es un factor fundamental, mediante la observación repetida de las mismas entidades a lo largo del tiempo. En consecuencia, las encuestas longitudinales recogen datos en dos o más momentos temporales diferentes. Ahora bien, las encuestas longitudinales pueden tener dos objetivos diferentes: medir el cambio producido en los sujetos de la muestra de modo individual a lo largo del tiempo (cambio bruto) o medir el cambio producido en el mismo «tipo de población» a lo largo del tiempo (cambio neto). Para el objetivo de medir el cambio bruto, o individual, el diseño de encuestas de panel es el procedimiento más adecuado, mientras que para evaluar el cambio neto, o cambio en la población, el diseño de series temporales o encuestas poblacionales se ajusta más a este objetivo. Un caso del primer tipo de encuesta de panel estaría constituido por una serie de recogida de datos a lo largo del tiempo para el estudio de la inserción laboral de los alumnos que han estudiado un determinado programa de estudios; en este ejemplo, podría elegirse una población, y subsiguientemente una muestra, de estudiantes de formación profesional en la rama de Electrónica, recoger datos iniciales sobre sus características demográficas y de rendimiento académico, y volver a tomar datos de los mismos sujetos un año más tarde y tres años más tarde sobre las características de su situación laboral. Un caso del segundo tipo de encuesta, o poblacional, puede ejemplificarse con las encuestas que los gobiernos realizan habitualmente para conocer el grado de cambio en el rendimiento escolar de los alumnos al final de las diferentes etapas educativas.

El diseño de encuestas de panel analiza los cambios evaluando a los mismos sujetos en diferentes momentos a lo largo del tiempo, por lo que implica la selección de una muestra, una toma de datos inicial y el seguimiento de sus elementos para las tomas de datos subsiguientes. Este diseño es particularmente adecuado para el estudio del desarrollo individual y, en especial, para el estudio de subpoblaciones con características singulares. Por ejemplo, un diseño de panel resultaría adecuado para el estudio del desarrollo e integración escolar y social de los alumnos con necesidades educativas especiales. Una gran ventaja de las encuestas de panel consiste en que permite el examen de la secuencia temporal en que se producen diferentes cambios en los individuos o unidades bajo estudio, lo que permite la realización de análisis causales de modo más apropiado que con el resto de los diseños de encuestas, por lo que este diseño suele estar asociado con investigaciones con una fuerte orientación analítica más que descriptiva. Este tipo de investigaciones permite superar las limitaciones de las encuestas transversales al controlar los efectos de la maduración de los individuos y el efecto de las variables de una determinada época (Gómez, 1990). No obstante, esta modalidad de

encuesta presenta el inconveniente de que los sujetos que están incluidos en la muestra son conscientes de este hecho y su pertenencia al estudio puede constituir un factor que modifique las conductas observadas, habiéndose denominado a este hecho *condicionamiento de la muestra*. Sin embargo, el principal problema que presenta este tipo de diseño es la mortalidad experimental debida a la reducción del tamaño de la muestra y a la variación en las características de la misma por la imposibilidad de mantener el contacto con los mismos individuos a largo del tiempo o por la falta de cooperación por parte de los mismos.

El diseño de encuestas poblacionales denominado *diseño de tendencias* implica la repetición de encuestas transversales en distintos momentos temporales y con muestras equivalentes de la misma población, aunque con individuos diferentes, lo que implica la repetición del procedimiento de obtención de una muestra para cada recogida de datos. Este tipo de diseño es muy adecuado para el análisis de la variación de alguna característica o variable de una población, el efecto de alguna intervención o tratamiento, o simplemente del paso del tiempo con el subsiguiente desarrollo social de carácter general, sobre una población o sistema determinado. Además, es posible también analizar si las relaciones entre las variables de una muestra se mantienen constantes o varían con el transcurso del tiempo. Por ejemplo, este tipo de estudios es habitual para evaluar la eficacia de las reformas educativas sobre múltiples aspectos de la realidad educativa —desde el rendimiento académico hasta la satisfacción de los padres o el funcionamiento de los servicios de inspección educativa—. Las encuestas de tendencias, al extraer para cada toma de datos una nueva muestra equivalente a la primera muestra utilizada, no plantean los problemas de seguimiento de los individuos, de mortalidad experimental y de condicionamiento de la muestra, pero pueden estar influenciadas por cambios generacionales que afectan a las variables estudiadas.

Los estudios de cohorte se caracterizan por encuestar en diversos momentos temporales a un conjunto de individuos de la misma población definida, aunque las muestras escogidas para cada toma de datos pueden ser diferentes o tener diferentes grados de solapamiento entre ellas. Así como un ejemplo de diseño de tendencias sería el encuestar cada tres años a los alumnos de 15 años, manteniéndose constante la edad en cada toma de datos y, por lo tanto, muestreando cada tres años a nuevos sujetos nacidos tres años después de los sujetos de la primera muestra, un ejemplo de diseño de cohorte sería encuestar cada tres años a la población de alumnos nacidos en 1990, manteniendo constante el rasgo que define la muestra —el año de nacimiento— pero encuestando en cada toma de datos a alumnos de 6 años, 9 años, 12 años y así sucesivamente, es decir, examinando cada vez a la misma cohorte de edad que

se desplaza en el tiempo. Este tipo de diseños es indicado para el estudio de procesos evolutivos dentro de una población. Así como un diseño transversal que incluyese el estudio de varias edades no sería capaz de distinguir qué diferencias en los resultados obtenidos son debidas a la edad o son resultado del hecho de pertenecer a una cohorte de edad o generación determinada, los diseños de cohorte permiten analizar por separado el efecto de la edad —que se mide como la diferencia entre distintos grupos de edad dentro de la misma cohorte— y el efecto generacional o de cohorte —que se estima a través de las diferencias entre distintas cohortes evaluadas a la misma edad— (Gómez, 1990).

10.4. FASES DE UNA ENCUESTA

No existe un único conjunto detallado y ordenado de etapas que pueda describir todas las encuestas, dado que el conjunto de características peculiares de cada una de ellas hará que bien pueda prescindirse o bien deba hacerse más hincapié en determinadas etapas. No obstante, hay tres grandes fases o etapas fundamentales que se dan en todas las encuestas, su diseño, la obtención de los datos y la explotación de la encuesta, que se examinan en los siguientes subapartados.

Debe tenerse en cuenta que las etapas de una encuesta, aunque en teoría puedan ordenarse de un modo secuencial, tienen implicaciones para las etapas posteriores y, en la práctica, se produce retroalimentación de las etapas posteriores para modificar las previas, lo que origina una gran interactividad entre ellas, especialmente en la fase de diseño de la encuesta y de modo notorio en las encuestas que se repiten en el tiempo.

No obstante, como guía que puede contribuir a la comprensión de los elementos esenciales y etapas de una encuesta la figura 10.2 presenta un esquema resumido de las tareas más importantes de las tres fases antes mencionadas: el diseño de la encuesta, la recopilación de datos y la explotación de los mismos.

10.4.1. Establecimiento del objetivo de la encuesta

El punto de partida de toda investigación mediante encuestas es la definición del objetivo que se pretende alcanzar mediante el conocimiento de los resultados de la encuesta, lo que implica ser consciente de qué tipo de decisión se tomará en función de que los resultados sean de un tipo u otro. Es evidente que no es relevante recopilar datos a través de una encuesta si las decisiones en un área determinada, o los pensamientos y conocimientos sobre la misma, van a ser los mismos indepen-




FIGURA 10.2. Fases de una encuesta.

dientemente de los resultados que ofrezca la encuesta. En consecuencia, es fundamental definir la información que se desea obtener para conocer con mayor profundidad un tema o fenómeno o la que se necesita para tomar decisiones con un mejor fundamento basado en dicho conocimiento y, de ese modo, determinar la relevancia de la encuesta. Los temas específicos de investigación, el tipo de encuesta a utilizar y los contenidos y procedimientos de la misma, así como el análisis de datos y su presentación se derivarán posteriormente de los objetivos con los que se ha concebido. Como primer paso, es necesario convertir los objetivos generales del estudio en preguntas concretas de investigación que sean susceptibles de investigación mediante encuesta. Se suele denominar *marco conceptual* al conjunto de ideas, conceptos y relaciones establecidas entre los mismos en un área de investigación que subyacen a los contenidos y objetivos de una encuesta, en el sentido de que dicho conjunto de conceptos no siempre se define o identifica explícitamente como una teoría subyacente a la encuesta. Este marco conceptual en las encuestas explicativas debe definir con precisión las hipotéticas relaciones entre

los conceptos que se van a someter a comprobación y tener en cuenta los hallazgos de las investigaciones previas. En todo caso, se debe ser consciente de que toda encuesta supone de modo implícito una teoría sobre la conducta de los sujetos así como una relación de correspondencia entre las respuestas de los sujetos y su conducta.

Una vez establecidos los objetivos generales del estudio, al esclarecer qué utilidad se dará a los resultados en términos de toma de decisiones o en términos de refinamiento o verificación de una teoría, es necesario definir de forma clara tres elementos fundamentales: qué información se desea obtener, a quién se va a encuestar para obtener dicha información y cómo se va a recopilar dicha información. La respuesta a la primera pregunta sobre qué información se quiere obtener implicará la definición concreta de la información deseada y, por lo tanto, de los contenidos de la encuesta; la respuesta a la segunda requerirá la definición precisa de la población y la respuesta a la tercera supondrá la selección de un sistema de recopilación de información. Asimismo, es muy importante clarificar la naturaleza básica del estudio determinando hasta qué punto su énfasis va a ser descriptivo o explicativo, ya que en los estudios descriptivos se hace hincapié en la precisión de las estimaciones mientras que en las encuestas más analíticas intervienen consideraciones relativas a la potencia estadística para rechazar y aceptar hipótesis.

Es claro que las decisiones sobre los tres elementos anteriores están interrelacionadas y que cada configuración particular de estos elementos da lugar a múltiples tipos de encuestas. Por ejemplo, supóngase que se desea estudiar el grado de desarrollo que adquieren los alumnos al final de la educación infantil, analizar en detalle la influencia de la escolarización temprana sobre dicho desarrollo y obtener datos que sean generalizables al conjunto de la población del país. Resulta evidente, por un lado, que no es aplicable a los niños que atienden a los centros de educación infantil la metodología de responder a un cuestionario, dado que aún no han adquirido en grado suficiente las habilidades de lecto-escritura necesarias para dicha tarea, ni su capacidad de memoria está lo suficientemente desarrollada para proporcionar datos fiables y tampoco sería viable, por otro lado, llevar a cabo un estudio observacional del número suficiente de niños que permitiese una generalización de los resultados a la población completa de alumnos de educación infantil. Una estrategia posible en este caso sería obtener la información sobre el grado de desarrollo de cada niño a partir de las informaciones proporcionadas por sus profesores, que tienen las capacidades necesarias para responder a cuestionarios que recopilen información sobre las habilidades cognitivas, psicomotrices y sociales de cada uno de los alumnos. La elección de esta estrategia como técnica más viable para el estudio frente a la observación directa —por razones presupuestarias y de generaliza-

bilidad— permite mantener la definición de la población (independientemente de que posteriormente se seleccione a los alumnos en función de sus profesores o de sus centros, o a los profesores en función de sus alumnos o de sus centros) y definir los contenidos de la encuesta teniendo en cuenta que los cuestionarios van a ser respondidos por profesores y no por alumnos.

10.4.2. Diseño de la encuesta

10.4.2.1. *Definición de la información deseada y construcción de los instrumentos de la encuesta*

En relación con los contenidos de la encuesta, tras la definición de la información que se quiere recopilar, es necesario definir las variables de interés. Este proceso requiere concretar operacionalmente dichas variables de modo que se determine de modo claro qué informaciones específicas van a componer el conjunto total de preguntas de la encuesta, independientemente del procedimiento de recogida de datos que se utilice en la misma. Es decir, se trata del proceso por el que se pasa de la declaración de intenciones u objetivo de la encuesta a las preguntas concretas a través de las que se va a obtener la información que permita lograr dicho objetivo, tal y como se recoge en el diagrama de la figura 10.3.




FIGURA 10.3. Definición de la información deseada y construcción de los instrumentos de la encuesta.

La operacionalización de los conceptos que se quieren valorar en una encuesta es un elemento crítico de la validez de la misma ya que una inadecuada transformación de los conceptos a medir en preguntas concretas no permitirá una representación adecuada de los mismos y, por lo tanto, los resultados obtenidos no tendrán el significado que se pretendía inicialmente que tuviesen. Hay que tener en cuenta que la operacionaliza-

ción puede significar una reducción excesiva del concepto a medir o introducir un sesgo que distorsione de modo significativo los resultados. Siguiendo con el ejemplo anterior, si se desea medir el concepto *tiempo de escolarización* probablemente bastará con saber a qué edad el alumno empezó a asistir con regularidad a la escuela infantil. Sin embargo, hay veces que los conceptos son muy difíciles de definir y de operacionalizar de un modo suficientemente completo. Por ejemplo, en el caso anterior, la estimación del grado de desarrollo cognitivo de los alumnos no es fácil de operacionalizar. Si se obtuviese solamente información sobre si los alumnos son capaces de distinguir y reconocer las letras del abecedario y sobre si son capaces de escribir correctamente alguna de ellas, esta información sería claramente insuficiente para asignarles un nivel de desarrollo cognitivo determinado y, en consecuencia, los resultados de la encuesta no resultarían ni creíbles ni fiables. Evidentemente, el análisis del desarrollo cognitivo de los niños requeriría recopilar información del máximo número posible de aspectos y capacidades cognitivas —percepción, memoria, atención, aprendizaje, comprensión y expresión del lenguaje escrito y hablado, capacidad espacial, etc.— de modo que la medida de desarrollo cognitivo represente adecuadamente dicho concepto complejo. No obstante, no resultaría factible recopilar información sobre si cada niño es capaz de realizar un número muy grande de tareas concretas y muy específicas ya que ello llevaría a que el cuestionario sobre cada alumno fuese excesivamente largo y, en consecuencia, también sería excesivo el trabajo de respuesta a los mismos por parte de sus profesores, por lo que habría que seleccionar, con acierto, un conjunto de tareas que fuesen significativas y representativas de cada uno de los ámbitos, temas o áreas del desarrollo cognitivo a evaluar. Es decir, sería necesario llevar a cabo un muestreo del conjunto de posibles preguntas que asegurase que en la valoración del desarrollo cognitivo se han tenido en cuenta de modo suficiente sus diferentes dimensiones.

Una vez determinado el conjunto de preguntas que conformarán la encuesta es necesario darles forma concreta en un todo coherente y unificado, tanto en cuanto a su orden de presentación, formato y redacción como en cuanto a sus opciones y modalidades de respuesta. El término *instrumento* se refiere a los cuestionarios, entrevistas, pruebas, tests o escalas que contienen el conjunto de preguntas de la encuesta y que se utilizarán para la recopilación de los datos. El capítulo 3 de este texto se ha dedicado con más profundidad a la construcción de instrumentos de medida y los capítulos 4, 5, 6, 7 y 8 a analizar los temas del error de medida, las propiedades métricas y la interpretación de los mismos. Lo expuesto en dichos capítulos se aplica obviamente a los instrumentos que puedan ser utilizados en una encuesta. Solamente merece la pena señalar aquí que las encuestas suelen incluir entre sus instrumentos

algún conjunto de preguntas dirigidas a recoger información demográfica sobre las características personales y del entorno de los encuestados que más tarde se suelen utilizar para asignarlos a diferentes grupos, con una finalidad descriptiva o comparativa, o para relacionar la información demográfica con otras variables objeto de estudio de la investigación. Debe mencionarse también que existen muchos instrumentos ya desarrollados en encuestas previas y que es aconsejable tenerlos en cuenta, bien como punto de partida para la confección de nuevos instrumentos o bien para utilizarlos en su forma original lo que presenta la ventaja de que el trabajo de desarrollo de los instrumentos ya ha sido realizado por lo que se conocen de antemano sus propiedades y limitaciones. También es conveniente examinar hasta qué punto se dispone de información sobre datos secundarios que pueden obtenerse de otras fuentes o bases de datos —p. ej., en el ámbito educativo, en los registros y expedientes escolares de los alumnos y profesores o en bases de datos públicas de las administraciones educativas— ya que la utilización de información secundaria puede reducir de forma notoria la longitud del cuestionario y el tiempo necesario para su cumplimentación.

10.4.2.2. Definición de la población y de la muestra

La definición de la población y la concreción de hasta qué punto es posible extraer una muestra de la misma de modo que quede adecuadamente cubierta es un proceso al que, en algunas ocasiones, no se presta la debida atención. Muchas encuestas reducen de modo importante la población de la que realmente se extrae la muestra, por lo que sus resultados son muchas veces dudosamente generalizables a la población en su totalidad. Por ello, se distingue entre varios niveles en la definición de una población. La «población inferencial», o «población objetivo deseada», es la población sobre la que se pretende generalizar los resultados —por ejemplo, los alumnos de educación primaria—. Sin embargo, es posible que algunos de ellos sean inaccesibles para el proceso de encuesta —por ejemplo, por residir en núcleos rurales muy aislados con escuelas con muy pocos alumnos, lo que hace muy costosa su inclusión en la muestra, o por ser alumnos con necesidades educativas especiales que, por su discapacidad física, no tienen posibilidad de responder a una encuesta—. Por ello, en una encuesta a veces es necesario determinar unos criterios de exclusión muy definidos —por ejemplo, los alumnos que asisten a centros rurales con menos de ocho alumnos y los alumnos matriculados en centros específicos de educación especial— y estimar cuál es el tamaño y repercusión sobre los resultados de las exclusiones o «población excluida». La «población objetivo» queda entonces definida como la población inferencial menos la excluida. Habitualmente, no suele ser

posible acceder a todos los elementos de la población objetivo —por ejemplo, por errores en los listados de centros y alumnos en los que algunos de ellos han sido omitidos—. El conjunto de elementos de las listas reales —en este caso de alumnos— que se utilizan para extraer la muestra se conoce como la «población marco» o «marco muestral» y en un caso ideal en el que los listados fuesen completos y sin errores la población objetivo sería idéntica al marco muestral. En el caso de las encuestas por muestreo es muy raro que se de en la práctica que todos los elementos de la muestra extraída del marco muestral respondan a la encuesta —por ejemplo, por falta de asistencia el día de la encuesta por enfermedad o absentismo— por lo que el conjunto total de encuestados realmente, o «muestra lograda» suele ser algo menor que la «muestra definida». Tanto en las encuestas censales como en las muestrales, la relación entre la muestra realmente lograda y la población inferencial, es decir, su grado de similitud, es lo que determina la fuerza de las inferencias que pueden hacerse mediante una encuesta. La figura 10.4 representa gráficamente estas ideas.




FIGURA 10.4. Poblaciones y muestras.

Asimismo, al definir la población es importante identificar cuatro características que definen su ámbito de generalización: su contenido —p. ej. los alumnos de educación primaria—, las unidades de análisis —p. ej., alumnos, clases, escuelas, comunidades, etc.—, los conjuntos de elementos que se van a comparar —p. ej. alumnos vs. alumnas, tipos de centro, provincias, etc.— y el periodo temporal al que se aplica la definición de la población —p. ej., el año 2001 o mayo del 2002.

Para el caso en que se ha tomado la decisión de realizar una encuesta por muestreo, en contraposición a una encuesta censal, existen múltiples modos de seleccionar una muestra; más adelante, el apartado 10.6 se dedica a exponer dichos sistemas de muestreo. No obstante, conviene señalar aquí que en la fase de diseño de una encuesta es imprescindible tomar varias decisiones en relación con el muestreo. Las siguientes preguntas ilustran algunas de las principales:

- ¿Qué cantidad de error en las estimaciones es admisible para que los resultados sean útiles, fiables y creíbles?
- ¿Qué diseño muestral se va a utilizar; es decir, qué organización de los elementos de la población y qué sistema de selección de los mismos se usarán para extraer la muestra?
- ¿Las probabilidades de selección de los elementos de la muestra serán iguales o distintas?
- ¿Qué tamaño de muestra es necesario utilizar para cumplir con los objetivos de precisión del estudio?

En definitiva, de lo que se trata es de ver qué grado de precisión se puede obtener con un diseño muestral específico y un tamaño de muestra determinado por las restricciones de tiempo y recursos de la investigación.

Aunque, en principio, siempre sería deseable obtener una muestra del mayor tamaño posible y con un sistema completamente aleatorio en el que todos los elementos de la muestra tuviesen la misma probabilidad de ser seleccionados en la muestra, en la mayoría de los casos esto no es posible bien por razones de tiempo o de limitación de recursos, habiendo casos en que la utilización de una muestra muy grande sería desproporcionada con el objetivo del muestreo. Por ejemplo, para realizar un pre-test de un cuestionario para alumnos de primer curso de educación secundaria en el que se quiere comprobar que las preguntas son bien comprendidas por los alumnos y calcular aproximadamente el tiempo necesario para su cumplimentación para poder planificar la encuesta definitiva, bastaría con elegir un número reducido de sujetos en los que estuviesen incluidos algunos alumnos con buena habilidad lectora y algunos otros con una habilidad baja, de modo que se cubriese un rango razonable de lo que posteriormente será la muestra elegida para la encuesta definitiva.

10.4.2.3. Selección del sistema de recopilación de datos y planificación de la obtención de datos

Son varios los factores que condicionan la selección de un sistema de recogida de datos. La interferencia o sesgo que dicho sistema pueda producir en las respuestas de los encuestados, la capacidad del sistema para recoger datos fiables, los costos de la administración de los instrumentos de la encuesta y la disponibilidad de los encuestados para ser encuestados en grupo de modo simultáneo son factores fundamentales que deben evaluarse con atención a la hora de elegir un procedimiento de recogida de datos. Más adelante, en el apartado 10.5, se presentan con más detalle los procedimientos más habituales de recopilación de información.

Desde un punto de vista práctico la disposición de las operaciones de recogida de datos en situaciones reales, es decir, del trabajo de campo, es un proceso complejo que requiere cierto conocimiento previo sobre los sujetos a encuestar así como la preparación de todos los materiales adicionales e instrumentos de la encuesta (Fernández y Rojas, 1998a). Encuestar a alumnos, profesores o directores de centros educativos es relativamente fácil ya que se sabe de antemano en qué lugar se encontrarán en determinadas fechas y se sabe que los centros disponen de espacios apropiados para realizar encuestas colectivas. Sin embargo, otras muchas situaciones hacen difícil localizar a los sujetos de la muestra, el tiempo que pueden o desean los sujetos dedicar a la encuesta es muy limitado, la administración del instrumento de la encuesta debe ser individualizada o los sujetos de la muestra pueden tener una gran tendencia a no cooperar en la misma. Por ejemplo, las encuestas telefónicas y las entrevistas personales profesionales se programan para realizarse en determinadas horas en las que es más probable que la población se encuentre en sus hogares y no interfiera con los horarios laborales y familiares, reduciendo de ese modo la probabilidad de rechazo a participar en la encuesta. El caso más difícil a este respecto lo constituyen las encuestas de panel en las que el seguimiento de los sujetos a lo largo del tiempo y el mantenimiento de su cooperación requieren la inversión de una cantidad de tiempo y recursos importante; por ello, al diseñar este tipo de encuestas suele hacerse una estimación del tamaño de la muestra necesaria teniendo en cuenta el número de sujetos que probablemente se perderán en el proceso o decidirán no seguir cooperando en la investigación.

En la planificación de los procesos de obtención de datos es necesario preparar de antemano los sistemas que se utilizarán para contactar a los encuestados, las explicaciones que se les darán para solicitar su cooperación y, en su caso, los argumentos y refuerzos para fomentarla. La concreción de los mecanismos para asegurar e incrementar la participa-

ción en una encuesta son un elemento crucial de la misma ya que las tasas de participación afectan directamente a su validez y, sobre todo, a su credibilidad. En las entrevistas personales y en las administraciones colectivas de encuestas es necesario llevar a cabo una planificación en la que se combinen las fechas y horas posibles de encuesta con la disponibilidad de los sujetos de la muestra y de los propios encuestadores, teniendo en cuenta el tiempo necesario para responder a la encuesta y la dificultad para definir un momento específico para su realización. Además, en la mayoría de los casos es preciso contar con encuestadores preparados u organizar sesiones de entrenamiento de los aplicadores específicas para cada encuesta.

10.4.2.4. Prueba piloto

En las encuestas con grandes poblaciones suele ser un requisito imprescindible realizar una prueba piloto que consiste en la aplicación previa en menor escala de todos los procedimientos que se utilizarán en la encuesta final. Una prueba piloto permite probar el sistema de muestreo, verificar la fiabilidad del marco muestral, estimar las probables tasas de respuesta, calcular la dificultad de contactación con los encuestados y su grado de cooperación, detectar dificultades que encuentran los encuestadores en la administración de los instrumentos, comprobar que las preguntas, las opciones y el modo de respuesta se ajustan a los encuestados, constatar la eficacia de los procedimientos organizativos de la administración de la encuesta, así como realizar un ensayo sobre los procesos de codificación de las respuestas y los procedimientos de tratamiento y análisis de datos. Además, las pruebas piloto suelen incluir el pretest de los instrumentos que se utilizarán en la investigación final, lo que permite su revisión y modificación, del mismo modo que permiten la mejora de los procedimientos organizativos del estudio y, en su caso, la adopción de otra estrategia de recopilación de datos si la probada en la prueba piloto se muestra ineficaz o ineficiente.

Para la realización de pruebas piloto no suele ser necesario utilizar muestras representativas, por lo que suelen emplearse técnicas de muestreo no probabilístico que aseguren que en la muestra de la prueba piloto está razonablemente representada la variabilidad máxima de los sujetos a encuestar. Por ejemplo, para realizar una prueba piloto de una encuesta a profesores de educación primaria no es necesario extraer una muestra completamente representativa de la totalidad de la población, pero para asegurar que en la prueba piloto se obtendrá una variabilidad similar a la que se encontrará en el estudio definitivo podrían seleccionarse algunas profesoras y algunos profesores, algunos de ellos sin apenas experiencia y

algunos con mucha experiencia, profesores de zonas rurales y urbanas, así como de zonas marginales y residenciales y profesores que trabajen tanto en centros públicos como privados, de modo que se obtenga en los resultados una variabilidad similar a la esperable en la población.

10.4.3. Obtención de datos

Una vez definido el sistema de recogida de datos, los instrumentos de la encuesta y seleccionada la muestra, la planificación de la encuesta se centra en los múltiples procesos que es necesario llevar a cabo para que la recogida de datos se realice apropiadamente, de modo que la administración de las encuestas se produzca en las mismas condiciones para todos los sujetos, evitando así los sesgos que se podrían originar por parte del encuestador o por causa de situaciones anómalas de administración, además de asegurar que los datos se obtengan en el periodo de tiempo establecido y con las mayores tasas de respuesta y de calidad de los datos posibles.

La estandarización de los procedimientos de administración de la encuesta es importante para asegurar la validez y comparabilidad de los datos, dado que diferentes circunstancias de aplicación podrían conducir a elicitar en los sujetos respuestas condicionadas por la intervención de los aplicadores o por circunstancias externas a los sujetos. Para ello, es conveniente establecer unas normas de aplicación estándar a las que deberán ajustarse todos los encuestadores y realizar sesiones de entrenamiento de los mismos, así como establecer sistemas de control de calidad de la administración de los instrumentos y de los datos recogidos. Una buena organización y seguimiento del trabajo de campo que controle la contactación con los encuestados, las incidencias que pueden surgir, el manejo de los materiales y otros aspectos administrativos son esenciales para una correcta realización de la encuesta definitiva (Fernández y Rojas, 1998a).

10.4.4. Explotación de la encuesta

10.4.4.1. Codificación, registro y verificación de la información

Una vez recopilados los datos brutos se procede a llevar a cabo el proceso de codificación de las respuestas (Rojas y Fernández, 1998). Este proceso, que ya se mencionó anteriormente en el capítulo 4 *Los instrumentos de medición psicológica II: Asignación e interpretación de puntuaciones*, es especialmente importante cuando las preguntas son de

tipo abierto, cuando el sistema de respuesta permite la aparición de un número tan grande de alternativas de respuesta que no resulta útil para su análisis o cuando las preguntas abiertas requieren de una corrección o valoración que puede estar influenciada por factores subjetivos del corrector —p. ej., una pregunta de Matemáticas en la que se pide a los encuestados que expliquen qué procedimiento han utilizado para resolver un problema y por qué es un procedimiento adecuado—, caso en que es necesario realizar correcciones múltiples por varios jueces o correctores y analizar con detalle hasta que punto son homogéneas o discrepantes las puntuaciones otorgadas por los mismos a cada una de las preguntas abiertas. Por ejemplo, en una encuesta a directores escolares se puede preguntar a los mismos sobre el número de años de experiencia en algún equipo directivo de centros; dicha pregunta puede proporcionar respuestas con un rango muy amplio —p. ej., desde directores con sólo un año de experiencia a directores con 30 años de experiencia—; en este caso puede ser útil para el análisis reducir a tres o cuatro categorías de grado de experiencia, es decir, recodificarlas en un número menor de categorías —p. ej., hasta 10 años, de 11 a 20 años y 21 o más años de experiencia—. El libro de códigos es el documento en el que se especifican de antemano los valores permitidos y las recodificaciones para cada una de las variables del estudio.

Aunque puedan parecer de poca importancia relativa, los procesos de grabación y verificación de los datos pueden influir en la calidad de los mismos, que es determinante para tener confianza en la precisión del conjunto de datos. En algunas ocasiones las encuestas ofrecen resultados confusos y contradictorios por la falta de calidad de la base de datos sobre la que se realizan los análisis. A la hora de verificar los datos es importante analizar la plausibilidad y coherencia de los valores registrados en la base de datos para cada variable, para lo que habitualmente se lleva a cabo un control de calidad revisando un determinado porcentaje de cuestionarios. Es habitual que los encuestados malinterpreten el sentido de alguna pregunta, especialmente cuando han respondido a la encuesta de modo muy rápido —p. ej., es habitual que al preguntar por la fecha de nacimiento los encuestados contesten con la fecha del día que se realiza la encuesta o que al preguntar a un alumno por su número de hermanos conteste con el número total de hijos de la familia incluyéndose el mismo—. Estos errores de respuesta y algunos errores de codificación se detectan fácilmente si se utilizan preguntas repetidas en diversos instrumentos —p. ej., un cuestionario para alumnos y otro para padres, o en un cuestionario sobre el entorno del alumno y en un cuestionario sobre actitudes— o en preguntas concatenadas que tienen una lógica interna —p. ej., si se ha preguntado cuanto tiempo un alumno dedica en total cada día a hacer deberes en casa y ha contestado que una

hora, no es coherente que al preguntarle por el tiempo diario dedicado a los deberes de Matemáticas y Ciencias conteste que una hora y media para Ciencias y dos horas para Matemáticas—.

En los tratamientos iniciales de preparación de los datos es importante determinar cómo se van a tratar las omisiones de respuesta, las respuestas ambiguas y otros datos que se pueden haber perdido en las fases anteriores por múltiples causas. En ocasiones, especialmente en las encuestas sobre conocimientos o rendimiento académico, es razonable suponer que la ausencia de respuesta implica una falta de conocimiento, pero en otras ocasiones la ausencia de respuesta a una pregunta puede tener un significado muy concreto en función del contexto en el que se produce dicha «no respuesta» —p. ej., en una encuesta al personal docente de un centro, en el que la tasa de respuesta a la mayoría de las preguntas es del 95 por ciento, el que en una pregunta sobre la satisfacción con la actuación del equipo psicopedagógico sea solamente del 25 por ciento probablemente tiene significado (desde el desconocimiento de su actuación hasta su disconformidad con la misma)—.

Hay veces en las que es conveniente completar la base de datos llevando a cabo procesos de imputación sobre los valores perdidos, es decir, sustituir en determinadas preguntas los valores perdidos por cualquier razón por un valor que represente la respuesta que es más probable que hubiese proporcionado un sujeto de determinadas características —p. ej., sustituyendo los valores perdidos bien por la media o la moda de la muestra o del subgrupo al que pertenece el sujeto o bien por el valor predicho en función de otras variables relacionadas con el dato que falta—. Todos estos procesos están dirigidos a constituir una base de datos precisa y completa sobre la que se llevarán a cabo los análisis de datos posteriores.

MC El problema de la no respuesta

10.4.4.2. Análisis de datos

Los análisis de datos que se llevan a cabo en el ámbito de la investigación con encuestas son los mismos que se utilizan con carácter general en la investigación educativa y, en general, en la investigación en Ciencias Sociales. En la asignatura *Métodos de Investigación en Educación* del plan de estudios de Psicopedagogía se estudiarán con detalle las técnicas estadísticas más comunes utilizadas en la investigación educativa así como sus procedimientos de cálculo y los conceptos que subyacen a las

mismas. En consecuencia, sólo tiene sentido aquí señalar algunos aspectos de importancia específica en las encuestas.

MC Técnicas de análisis de datos en las encuestas

Una vez que los datos han sido verificados y depurados correctamente, conviene efectuar una estimación de la validez del muestreo; para ello se utiliza un conjunto de variables de la población de las que se tienen datos fiables de antemano y se comprueba que su distribución sea similar a la que se ha obtenido en la muestra; dichas variables se conocen como *variables marcadoras*. Por ejemplo, si se conoce de antemano por estadísticas fiables que en la población de alumnos de educación secundaria hay un 51 por ciento de alumnas y un 49 por ciento de alumnos, es de esperar que en una muestra que pretenda ser representativa de la totalidad de los alumnos de educación secundaria la muestra presente una distribución aproximadamente similar de la variable *género* en sus elementos —si se obtuviese una distribución del 52 por ciento de alumnas y del 48 por ciento de alumnos la muestra sería aceptable, pero si la muestra estuviese constituida por más del 56 por ciento de alumnas debería revisarse con cuidado el procedimiento de muestreo para verificar que no se ha producido un sesgo que ha favorecido la selección de alumnas en vez de alumnos y la representatividad de la muestra sería muy dudosa. Cuando las distribuciones de las variables marcadoras obtenidas en la muestra son muy diferentes de las que se conocen fiablemente de la población se invalida la validez del muestreo.

Asimismo, como parte de los primeros análisis de datos de una encuesta, es imprescindible estimar las tasas de respuesta —es decir, el porcentaje de sujetos de la muestra que han respondido realmente— tanto generales a los instrumentos de la encuesta como a cada una de sus preguntas. Obviamente, una baja tasa de respuesta a los instrumentos de una encuesta invalida la misma en su conjunto y una baja tasa de respuesta a una pregunta impide el obtener conclusiones válidas en relación con la información que proporciona dicha cuestión. Cuando se sospecha que las ausencias de respuesta a una encuesta tienen significación, debe analizarse con cuidado si las ausencias de respuesta se derivan de algún sesgo o característica de la población. Por ejemplo, en una encuesta realizada a alumnos y padres de alumnos se descubrió, al analizar el estatus socio-cultural de los padres a partir del cuestionario de los alumnos, que los padres que no respondían al cuestionario pertenecían significativamente a los niveles socio-culturales más bajos de la población —esto puede derivarse de una falta de capacidad o confianza por parte de

dichos padres para responder a la encuesta o un reflejo de una menor valoración del proceso de educación de sus hijos.

En un segundo paso, suele ser necesario o conveniente recodificar la información obtenida y/o resumirla en nuevas variables construidas a partir de los datos. La construcción de nuevas variables puede implicar la simple creación de nuevas categorías de sujetos a partir de otras variables o bien, en el caso de variables similares, por razones de simplicidad y de mayor poder explicativo, su agregación o reducción en índices o escalas que resumen la información obtenida con todas ellas (por ejemplo, en un índice de estatus socio-económico y cultural de los sujetos o en una escala de conocimientos en un área determinada), denominándose habitualmente *elaboración de constructos* este proceso de resumen de la información obtenida. La elaboración de constructos no consiste en la aplicación automática de reglas que tienen en cuenta resultados estadísticos sino en la interacción entre los resultados estadísticos y los supuestos y contenidos teóricos que subyacen a la encuesta de modo que tengan un significado claro y sean relevantes e interpretables.

10.4.4.3. *Presentación de resultados*

El principal determinante del modo en el que se presentan los resultados de una encuesta es la audiencia a la que van dirigidos. El público general, los administradores en los campos de la educación, de la salud, de la política y de las empresas y los investigadores constituyen las audiencias más habituales para las que se preparan los informes de la encuesta. Cada audiencia implica un enfoque diferente a la hora de seleccionar y presentar sus resultados, siendo mucho más extensa y detallada la redacción de informes para los investigadores que para el público general (Buendía, 1997; Fernández y Rojas, 1998b), situándose la cantidad de información para audiencias semiespecializadas en un punto intermedio.

En primer lugar, en los informes, ya sean escritos u orales, debe diferenciarse claramente entre los resultados obtenidos y las interpretaciones que se hacen de ellos, delimitando el ámbito al que pueden generalizarse las conclusiones, bien a toda la población o bien a parte de ella, y distinguiendo entre los hallazgos que tienen un alto nivel de certidumbre y los que son tentativos. Los informes de investigación deben presentar la información suficiente para que los lectores sean capaces de juzgar la relevancia del planteamiento de la encuesta, la validez y fiabilidad de los datos recopilados, la adecuación de los análisis estadísticos a las características de la encuesta y de sus datos y la pertinencia de las conclusiones obtenidas. Por ello, deben incluir información tanto sobre los resultados

como sobre los procesos mediante los que se ha llevado a cabo la encuesta. Habitualmente se prepara una ficha técnica resumida para el público no especializado (Buendía, 1997) e informes de investigación minuciosos para los investigadores (Fernández y Rojas, 1998b). La información sobre los procesos de la encuesta siempre debe incluir la definición de la población y la técnica de muestreo utilizada para extraer la muestra así como su tamaño y las tasas de respuesta. Además, la presentación de resultados descriptivos de una encuesta basada en una muestra debe incluir la estimación del error de muestreo, de modo que pueda conocerse el grado de incertidumbre asociado a los resultados obtenidos. Cuando la muestra se ha obtenido a partir de diseños muestrales complejos (estratificados, por conglomerados, multietápicos, etc.) que se alejan del muestreo aleatorio simple, la estimación del error de muestreo deberá ajustarse para compensar el efecto del diseño, que cuantifica el grado en el que el diseño de muestreo es menos eficiente que el muestreo aleatorio simple. Asimismo, debe especificarse claramente el sistema de recogida de datos y operaciones y la fecha de realización. En cuanto a los resultados obtenidos, es importante concretar la información sobre los márgenes de error de las conclusiones, es decir, el grado de precisión de la medida general y la significación estadística que avala dichas conclusiones. Por último, la discusión de los resultados en relación con las predicciones de la teoría bajo estudio y con las posibles alternativas en la toma de decisiones que originaron la encuesta es el elemento fundamental que justifica y da relevancia a la investigación.

10.5. PROCEDIMIENTOS DE RECOGIDA DE LA INFORMACIÓN

Los distintos sistemas de recopilación de datos implican diferentes grados de interacción entre el encuestador y el encuestado a la hora de presentar el conjunto de preguntas de la encuesta y obtener las respuestas de los encuestados. Habitualmente se ha distinguido entre las entrevistas y los cuestionarios como los dos métodos básicos de recopilación de información implicando las entrevistas, y en especial las entrevistas presenciales, un mayor grado de interacción entre encuestador y encuestado que la cumplimentación de cuestionarios en ausencia de un aplicador.

Un cuestionario es un instrumento de recopilación de información compuesto de un conjunto limitado de preguntas mediante el que un sujeto proporciona información sobre sí mismo y/o sobre su entorno —pudiendo incluir tanto datos sobre sus características personales como datos sobre sus conocimientos, necesidades, intereses, motivaciones,

expectativas, planes, percepciones, creencias, valoraciones, preferencias, opiniones o actitudes, entre otros—, diseñado con el objeto de cubrir las necesidades del investigador. Como norma general se recomienda que siempre que sea posible se realicen pretests o estudios piloto de los cuestionarios para comprobar que pueden ser comprendidos y respondidos adecuadamente y que la información que proporcionan es la que se pretende obtener.

Una entrevista es un procedimiento mediante el que un entrevistador o encuestador realiza un conjunto de preguntas a un sujeto, pudiendo este conjunto de preguntas bien estar totalmente definido de forma previa a la realización de la entrevista o bien estar indefinido en mayor o menor grado, aunque siempre orientado hacia la obtención de información más o menos detallada sobre un tema relacionado con el entrevistado o con su entorno. Las entrevistas permiten clarificar al encuestado el sentido de las preguntas mientras que los procedimientos en que el encuestado contesta a un cuestionario sin la presencia del aplicador no lo permiten. Se puede considerar que, en gran medida, una entrevista en la que sus preguntas están muy estructuradas —al definirse completamente sus preguntas, el orden de presentación y el formato de respuesta— consiste en la presentación oral de un cuestionario que está implícito en las preguntas y en su modo de presentación. No obstante, cuando las entrevistas no están totalmente estructuradas de antemano se tiene la posibilidad de introducir variaciones en el proceso de obtención de datos mientras que los cuestionarios escritos son más cerrados y, en consecuencia, menos flexibles. Tanto los cuestionarios como las entrevistas pueden tener diversos grados de estructuración, siendo habitual que a una mayor estructuración corresponda una mayor facilidad en el procesamiento de los datos, aunque habrá menor capacidad para obtener información no prevista de antemano. Debido a su flexibilidad, las entrevistas poco estructuradas son potencialmente la técnica de encuesta que puede obtener información más detallada y útil, aunque suelen ser más costosas. Además, son adecuadas para todo tipo de sujetos, independientemente de su nivel cultural al leer y explicar el encuestador, en caso necesario, las preguntas.

La obtención de datos puede también ser individual o colectiva. La encuesta individual habitualmente se realiza mediante una entrevista y las encuestas colectivas mediante la utilización de cuestionarios impresos. La administración colectiva es útil en las encuestas en las que es posible congregar a los elementos de la muestra, por lo que es habitual en el mundo educativo cuando los alumnos o profesores son los sujetos de la encuesta, al estar organizados en grupos o localizables en el mismo centro. La aplicación colectiva suele suponer un ahorro muy significativo de costos en la obtención de datos. En las aplicaciones colectivas el cuestio-

nario suele ser presentado por un aplicador, que proporciona a los encuestados las instrucciones adecuadas para su cumplimentación.

Las encuestas individuales pueden ser aplicadas por un administrador o autoadministradas. Las encuestas administradas por un aplicador incluyen las entrevistas presenciales y las entrevistas telefónicas. Dentro de las autoadministradas se distinguen entre las encuestas por correo, por correo electrónico y por internet. Otro sistema que se utiliza en ocasiones es un procedimiento de administración mixto, en el que el aplicador limita su tarea a presentar el cuestionario al encuestado, suministrando las instrucciones adecuadas para su cumplimentación y para su devolución ya sea por correo o por otros medios. Este sistema implica la combinación de algunas características de una entrevista personal breve con las de la autoadministración de un cuestionario.

La selección de uno u otro procedimiento de recogida de información está en función de diversas consideraciones de las que las más importantes son la versatilidad del sistema de recogida de datos, su costo, el tiempo requerido para la obtención de los datos, el control que se tiene sobre la muestra, la cantidad de datos a recopilar, la calidad de la información que se pretende obtener y las tasas de respuesta esperables con cada procedimiento (Martínez Arias, 1995c). También son importantes las consideraciones sobre la accesibilidad a los elementos de la muestra y la sensibilidad de las preguntas de la encuesta.

MC Características de los sistemas de recopilación de información
Para comparar los rasgos fundamentales de las entrevistas personales, las telefónicas y las encuestas por correo.

10.6. TÉCNICAS DE MUESTREO

10.6.1. Los errores en las encuestas

El objetivo principal de las encuestas no censales es obtener estimadores fiables de ciertas características de la población o parámetros. Lógicamente, los valores obtenidos en las muestras nunca serán exactamente iguales a los parámetros o valores verdaderos de las características de la población, ya que siempre cometemos algún tipo de *error*, que se manifiesta en la diferencia entre ambos valores. Este término tiene un significado especializado en la teoría del muestreo y puede provenir de muchas fuentes, que se representan esquemáticamente en la figura 10.5.

Algunas de las fuentes de error, las que se denominan *errores de no muestreo*, pueden actuar también en las encuestas censales. Los *errores de muestreo* son específicos de las encuestas con muestras y son atribuibles al proceso de muestreo, es decir, a la sustitución de la población por una muestra (errores de estimación) y a la selección de ésta (errores de selección). Los tópicos que se desarrollan en este apartado proporcionan procedimientos para corregir estos últimos errores.




FIGURA 10.5. Los errores en las encuestas.

A continuación se presenta un hipotético ejemplo que permitirá caracterizar los distintos errores. Un investigador en el ámbito de la Psicología de la Educación está interesado en el tema de la violencia y la agresión en la ESO en una comunidad autónoma. Para el estudio decide utilizar un cuestionario de conductas agresivas y violentas, con un formato tipo Escala Likert con 5 opciones de respuesta, en el que los sujetos deben expresar su grado de acuerdo con un conjunto de proposiciones o frases de la escala. La población objetivo está formada por todos los adolescentes de 12 a 16 años escolarizados en centros públicos y privados, que cursan estudios de ESO en la comunidad autónoma de interés. Dada la magnitud de la población y los medios de que dispone para realizar el estudio, decide obtener los datos en una muestra para extraer inferencias a la población. El investigador considera que una muestra de $n = 400$ es suficiente para sus objetivos. Puesto que los elementos de la población se encuentran escolarizados en centros educativos, decide seleccionar 4 centros, 2 públicos y 2 privados y 100 alumnos de cada centro, 25 de cada curso, equilibrados en cuanto al género de los alumnos. El investigador solicita la colaboración de 4 centros a los que tiene fácil acceso, porque conoce a algunas personas del equipo directivo, rogán-

doles que le faciliten una clase de cada curso para aplicar los cuestionarios.

Imaginamos que el lector ya habrá captado que el procedimiento seguido por el investigador presenta algunos fallos, que harán que las estimaciones sean poco fiables para caracterizar el problema de la agresión y violencia en la comunidad. Estos fallos pueden situarse fácilmente en la taxonomía de la figura 10.5. En primer lugar, el procedimiento de selección de la muestra parece que plantea algunas cuestiones de representatividad de la misma, ya que el investigador acude a centros conocidos, excluyendo *a priori* a la mayor parte de los centros de la población objetivo. Este tipo de error vinculado a la selección, y caracterizado por utilizar un procedimiento de muestreo subjetivo y no aleatorio, es uno de los denominados *errores de muestreo*, pero no es el único. El investigador decidió también *a priori* que considera suficiente una muestra de $n = 400$ casos, basándose en su propio juicio. Como veremos en este apartado, la muestra deberá cumplir con unos requisitos de tamaño mínimo para proporcionar estimaciones fiables de la población. Este último tipo de error pertenece a la categoría de los *errores de estimación*. Si seguimos analizando el procedimiento del investigador, veremos que además pueden cometerse otros errores, que se enmarcarían en la segunda rama del árbol, como errores de no muestreo. Por ejemplo, el cuestionario puede llevar asociados todos los problemas relacionados con la fiabilidad y validez de la medida, sesgos de respuesta, etc., que se han considerado en otros capítulos del libro, y cubrir inadecuadamente el dominio de las conductas agresivas; algunos de los sujetos pueden negarse a responder; la codificación de los datos puede ser incorrecta y pueden cometerse errores en su grabación.

La teoría de muestras permite responder a las cuestiones relativas a los errores de muestreo y el uso adecuado de sus reglas permitirá al investigador responder de forma mucho más adecuada a las preguntas y objetivos de su investigación. No obstante, para no cometer los otros tipos de error, el investigador deberá contemplar otros muchos aspectos de los que se ocupan específicamente la Psicometría y Estadística.

La teoría de muestras, con sus técnicas asociadas, intenta dar respuesta a las siguientes preguntas:

1. ¿Cómo seleccionar las muestras de modo que reflejen adecuadamente las características de la población? La respuesta a esta pregunta se encuentra en los métodos de muestreo probabilístico, y específicamente en el muestreo aleatorio simple.
2. ¿Hasta qué punto los estadísticos calculados en muestras reflejan de forma segura los valores de los parámetros de la población? El

muestreo aleatorio permite determinar la discrepancia entre los valores obtenidos en las muestras y los parámetros de la población. Estas cuestiones suelen referirse bajo la etiqueta genérica de *errores de estimación*.

3. ¿Cómo influye el tamaño de la muestra? Los errores de estimación están determinados en parte por el tamaño de la muestra y el procedimiento que se sigue en la práctica para su control consiste en determinar el número de elementos necesarios para no superar un nivel de error predeterminado.

MC Cálculo del tamaño de la muestra

4. ¿Cuáles son los métodos más eficaces para extraer muestras de la población (es decir, que minimicen los errores de muestreo) y en qué circunstancias son más adecuados? Aunque el muestreo aleatorio simple es la base de la teoría de muestras, presenta ciertas desventajas. Esto hace que en la práctica real de las encuestas se utilicen otros métodos más complejos, como el muestreo estratificado y el muestreo de conglomerados.
5. ¿Cuáles son los efectos de la no respuesta en los estimadores obtenidos? Aunque no forma parte de los errores de muestreo, la no respuesta tiene importantes implicaciones en la representatividad de las muestras y en la generalización a la población de los estimadores que en ellas se obtienen. Por este motivo este problema suele estudiarse dentro del marco de las técnicas de muestreo.

MC El problema de la no respuesta

El lector interesado puede encontrar también una información básica sobre sus efectos y algunos procedimientos de corrección del problema en Martínez Arias (1995d) y en Sánchez Carrión (2000).

10.6.2. Métodos de muestreo

El término *muestreo* se utiliza normalmente para describir el proceso de selección de una muestra de tamaño n de la población objetivo formada por N elementos. Se denomina *fracción de muestreo* o *muestral* (f) a la razón del tamaño de la muestra al de la población, es decir, $f = n/N$. La

capacidad del investigador para generalizar los resultados más allá de la propia muestra, tiempo y lugar particulares depende completamente del procedimiento seguido en la selección. La elección del método de muestreo siempre es una decisión en la que intervienen consideraciones de seguridad o precisión en la estimación de los parámetros, costo y factibilidad de acceso a los elementos seleccionados. Algunos métodos son más seguros que otros y el investigador deberá elegir uno, o una combinación de varios, teniendo en cuenta las consideraciones anteriores. En general, los métodos disponibles suelen clasificarse en dos grandes categorías: *métodos probabilísticos* y *métodos no probabilísticos*.

Una muestra probabilística es aquella en la que todos los elementos de la población tienen una probabilidad conocida de ser seleccionados para la muestra. Son elementos distintivos:

- la selección aleatoria de los elementos;
- el conocimiento de las probabilidades de selección o de ser incluidos en la muestra de los elementos de la población.

En las muestras no probabilísticas la probabilidad es desconocida, pudiendo seleccionarse los elementos al azar o no, dependiendo del método.

Las muestras probabilísticas tienen considerables ventajas sobre las obtenidas mediante otros métodos, ya que la teoría estadística proporciona procedimientos para obtener estimaciones precisas del error, aunque los valores de la población no sean conocidos. Con las muestras no probabilísticas estos procedimientos no son factibles, por lo que presentan una clara desventaja.

Existe una gran variedad de métodos de muestreo probabilístico, que pueden utilizarse separadamente o en combinación. Una descripción más amplia de los mismos puede verse en Martínez Arias (1995c). A continuación se presenta el procedimiento básico a partir del que se desarrolla toda la teoría de muestras, el muestreo aleatorio simple, dejando para un apartado posterior algunos procedimientos prácticos más utilizados en la realidad.

10.6.3. El muestreo probabilístico: muestreo aleatorio simple

El muestreo aleatorio simple (m.a.s.) es la forma más simple de muestreo: consiste en seleccionar al azar los n elementos de una población, de tal forma que cada una de las múltiples combinaciones de los N elemen-

tos tomados de n en n (${}_N C_n$), tengan la misma probabilidad de ser seleccionadas. Esta definición responde al muestreo denominado *m.a.s. sin reemplazamiento*, ya que un elemento de la población extraído en un momento dado, al no ser incluido de nuevo en la población, no puede volver a ser elegido. La teoría del muestreo introduce una distinción entre esta forma de muestrear y otra teórica cuando se trata de muestras reales denominada *con reemplazamiento*, en la que cada elemento elegido es introducido de nuevo en el marco muestral pudiendo ser reelegido. En la práctica, cuando la población es grande como sucede en las encuestas educativas, no tiene apenas repercusión práctica la distinción.

El principal problema del m.a.s. es que requiere la identificación y listado en el marco muestral de todos los elementos de la población, de modo que éstos puedan ser seleccionados. Los elementos se seleccionan normalmente por medio de tablas de números aleatorios o generando éstos mediante algún programa de ordenador. Todas las unidades en cada extracción tienen la misma probabilidad de selección (excepto por el mínimo efecto ya comentado del no reemplazamiento), todas las muestras son equiprobables y las posibles muestras que constan del mismo número de unidades, aunque formadas por elementos distintos, se consideran idénticas. Para seleccionar una muestra concreta de tamaño n se siguen los siguientes pasos:

1. Se asigna a cada elemento del marco muestral un número único de identificación de 1 a N .
2. Se selecciona un comienzo al azar en una tabla de números aleatorios (semilla, en los realizados con ordenador).
3. Se utiliza un número de dígitos en la tabla que permita que pueda extraerse el número de identificación más alto.
4. Se selecciona el elemento cuya identificación se corresponda con el número extraído.
5. Se descarta cualquier número que no tenga un número correspondiente en la población.
6. Se repite el proceso n veces, hasta que los n sujetos sean seleccionados.

Las fases 2 a 6 pueden realizarse generando números aleatorios mediante un programa de ordenador e identificando los elementos seleccionados por su número en el listado. El siguiente ejemplo representa un proceso de selección mediante muestreo aleatorio simple.

Supongamos por simplicidad que la población objetivo del psicopedagogo de nuestro ejemplo estuviese formada únicamente por $N = 1000$

sujetos. Dispone de un listado de los 1000 sujetos o elementos de la población y decide seleccionar una muestra aleatoria simple de $n = 20$ a partir del listado. Para que la muestra sea probabilística y obtenida mediante el procedimiento aleatorio simple antes descrito, sabe que todas las muestras posibles de 20 elementos tienen la misma probabilidad de ser seleccionadas. Utiliza un programa de generación de números aleatorios y para ello debe asignar un número entre 1 y 1000 a cada uno de los registros del listado. El programa le proporciona los números dados en la tabla siguiente.

69	422	364	802	223
695	809	734	958	20
304	717	745	92	116
16	582	883	244	631

El estudio se realizará sobre los sujetos que tienen en el listado o marco muestral los números coincidentes con los seleccionados, a los que el investigador deberá acceder posteriormente para que cumplimenten el cuestionario.

La selección de casos presentada ha sido realizada con el programa STATS que dispone de un generador de números aleatorios, en el que el usuario puede controlar el número de elementos de la población. Este programa desarrollado por *Statistics Software* puede obtenerse sin costo de la red, en la página www.decisionanalyst.com.

La teoría estadística especifica que el m.a.s es el método más fiable para obtener una muestra representativa. El estadístico obtenido para una variable particular puede generalizarse con un nivel de confianza calculable a la población de la que fue extraída la muestra. La teoría de los errores de estimación está desarrollada dentro de este tipo de muestreo y es el referente para el cálculo del tamaño de la muestra. Aunque es el prototipo de muestreo probabilístico, el m.a.s. se utiliza raramente en la práctica, excepto con poblaciones pequeñas, de las que existan marcos muestrales completos, con elementos completamente identificables. En muchas ocasiones no existen marcos muestrales completos o actualizados. En el caso de poblaciones grandes, aún existiendo un marco completo, presenta muchas dificultades, ya que el proceso de obtención de la muestra es tedioso. La dispersión geográfica de los sujetos seleccionados supone el aumento de los costos en la recogida de los datos y su duración.

En el caso de los 20 sujetos seleccionados en el ejemplo anterior, es muy probable que cada uno de ellos pertenezca a centros educativos diferentes y dispersos por toda la comunidad.

10.6.4. Los errores de estimación

Antes se ha indicado que el principal objetivo de las encuestas por muestreo es calcular mediante los datos de la muestra algún *estadístico* resumen de la característica observada, para inferir el valor «verdadero» de dicha característica en la población, o *parámetro* poblacional. También se ha señalado que la muestra seleccionada es *una* de las muchas muestras posibles y diferentes que se podrían seleccionar por el mismo procedimiento, con un número de elementos n . El proceso de selección de las muestras se considera un experimento aleatorio, ya que puede ser extraída cualquiera de ellas inicialmente y conocerse de antemano sus probabilidades. Esto hace que los valores de los estadísticos muestrales (p.ej., medias, proporciones, etc.) sean valores también aleatorios y no fijados, por lo que pueden describirse como variables aleatorias. Puesto que los casos que componen cada una de las posibles muestras son diferentes, los valores de los estadísticos calculados en ellas también lo serán.

MC Errores de estimación

Se propone un ejemplo desarrollado en el que se explica el proceso de extracción de muestras múltiples de tamaño n de una misma población y los principales conceptos.

Estos valores de los estadísticos obtenidos en las distintas muestras pueden tratarse a su vez mediante procedimientos estadísticos. En primer lugar puede establecerse con ellos la distribución de frecuencias, que recibe el nombre de *distribución muestral del estadístico*, puesto que sus valores son de estadísticos obtenidos en muestras (medias, proporciones ...). Se puede calcular la media de estos valores, así como alguna medida de su variabilidad, tal como la varianza. Si se repitiese el proceso de extracción de muestras infinitas veces, el valor esperado o media de los resultados de la distribución muestral sería igual al valor del parámetro poblacional y su varianza la de la distribución muestral del estadístico. Por lo tanto, los estadísticos muestrales, como media o proporción pueden considerarse como variables aleatorias, con una distribución de probabilidad o de densidad de probabilidad denominada *distribución muestral del estadístico*. Cada uno de los estadísticos diferirá en mayor o menor

grado del valor del parámetro, denominándose esta diferencia *error de estimación*. La variabilidad de los estimadores representada en los errores de estimación puede resumirse mediante la varianza o la desviación típica de la distribución. Estas desviaciones típicas de la distribución muestral de un estadístico se denominan *errores típicos del estadístico* o *estimador* (media, proporción, etc.) puesto que son desviaciones típicas de los errores de estimación. Estos valores representan la magnitud de la incertidumbre en la estimación de los parámetros poblacionales. Cuando se utiliza el m.a.s. pueden calcularse estimaciones de estos errores típicos, ya que la teoría de la probabilidad proporciona una ecuación para calcular el error típico para una muestra única extraída de una población de tamaño muy grande, que básicamente, para el caso de la media o de la proporción se podría escribir como:

$$E.T.(Estadístico) = \sqrt{\frac{Varianza}{n}} \quad (10.1)$$

donde:

Varianza es la varianza de la variable estudiada en la población (normalmente estimada por medio de la muestra);

n el tamaño de la muestra.

La fórmula anterior solamente es correcta cuando la población es infinita o se obtienen las muestras con reposición o reemplazamiento. Si la población es finita debe añadirse otro elemento, ya que la fracción muestral es otro determinante del error de muestreo. Los datos recogidos de una muestra de 500 personas tendrán más error si la población es de 100.000 personas que si es de 1000. Cuando el muestreo se realiza de poblaciones relativamente pequeñas (o la fracción muestral es grande), debe usarse una fórmula alternativa que incluye la fracción muestral:

$$E.T.(Estadístico) = \sqrt{\frac{Varianza}{n} \times \frac{N-n}{N}} \quad (10.2)$$

donde todos los términos tienen significados conocidos.

Suele decirse como regla práctica que la corrección anterior solamente necesita introducirse cuando la muestra contiene más del 5% de todos los casos de la población, es decir, cuando la fracción muestral es $f > 0,05$.

Los errores típicos calculados pueden usarse para construir un intervalo de confianza alrededor del estimador muestral, que indica la preci-

sión de éste para estimar el parámetro. Por ejemplo, el investigador puede querer tener una confianza del 95% de que un estadístico muestral observado (por ejemplo la media de una variable) se encuentre a una distancia de no más de 1,96 desviaciones típicas del verdadero parámetro de la población. Para construir el intervalo, se multiplicaría esta cantidad por el error típico y sumándola y restándola al estimador, se obtendría el intervalo de confianza del 95% para el parámetro de la población, de forma completamente paralela a como se establecía en el capítulo 5 el intervalo confidencial para la puntuación verdadera de un sujeto en el test. Si el error típico es pequeño, el margen de error que establece los límites del intervalo también lo será, indicando que el estadístico muestral proporciona un estimador relativamente preciso del parámetro de la población.

Como puede verse en la ecuación anterior, uno de los determinantes del error muestral es el tamaño de la muestra, que figura en el denominador, lo que implica que a mayor tamaño de la muestra menor será el error. Por este motivo, incrementos en el tamaño de la muestra producen decrementos en el error. No obstante la relación no es lineal, ya que los posteriores incrementos en el tamaño de la muestra producen reducciones cada vez menores del error.

En la expresión anterior puede observarse que el error típico también depende de la varianza de la variable. Si no hubiese varianza, una muestra de $n = 1$ sería suficiente para estimar el valor del parámetro de la población sin errores de muestreo. En la medida en que la varianza aumenta, también lo hace el error típico. Las ecuaciones anteriores para calcular el error típico se basan en el supuesto de que la muestra fue extraída mediante el procedimiento de muestreo aleatorio simple. Cuando se utilizan otros diseños probabilísticos, el error de muestreo puede ser mayor o menor. El grado de desviación dependerá del denominado *efecto del diseño*, definido como la razón de la varianza del estimador obtenido con el otro diseño a la varianza que se obtendría con muestreo aleatorio simple:

$$Ef. \text{ Diseño } (t) = \frac{(Varianza \text{ Estadístico})_t}{(Varianza \text{ Estadístico})_{mas}} \quad (10.3)$$

donde:

t se refiere al tipo de diseño de muestreo probabilístico;

$(Varianza \text{ Estadístico})_t$ es la varianza del estadístico obtenido con dicho diseño, por ejemplo, la de la media obtenida con un muestreo estratificado;

$(Varianza \text{ Estadístico})_{mas}$ es la varianza de ese mismo estimador obtenida mediante el muestreo aleatorio simple.

Como se puede observar, el m.a.s. es el patrón de medida para medir la eficiencia de otros diseños muestrales, que se explican más adelante. El efecto del diseño permite corregir los errores típicos de estimación cuando se usan diseños complejos.

En la práctica, la variabilidad de la variable no se puede controlar y la única forma de reducir los errores de muestreo al alcance de los investigadores para conseguir una precisión determinada es estableciendo el *tamaño de muestra*, *n*, *requerido para no superar un nivel de error*. Este nivel de error se denomina *error máximo*, que es la cantidad que se suma y resta al estimador muestral para construir el intervalo de confianza.

MC Cálculo del tamaño de la muestra

Se presentan las fórmulas para calcular tamaños de muestra en medias y proporciones.

En la tabla 10.1 pueden observarse los cambios en el tamaño de la muestra para la estimación de la proporción según el error máximo admisible, el nivel de confianza fijado para construir el intervalo y la varianza de la población (la varianza de una variable dicotómica es igual a $[p \text{ (proporción de acuerdos, éxitos)} \times q \text{ (proporción de desacuerdos, no-éxitos)}]$).

TABLA 10.1
Cambios en el tamaño de la muestra para la estimación de proporciones según el error máximo admisible, el nivel de confianza y la varianza

VARIANZA	NIVEL DE CONFIANZA							
	0,99				0,95			
	Error Máximo				Error máximo			
	2%(0,02)	5%(0,05)	7%(0,07)	10%(0,1)	2%(0,02)	5%(0,05)	7%(0,07)	10%(0,1)
$0,5 \times 0,5 = 0,25$	3994	661	339	166	2345	383	196	96
$0,3 \times 0,7 = 0,21$	3376	556	285	140	1977	322	165	81
$0,2 \times 0,8 = 0,16$	2594	425	217	107	1514	246	126	62
$0,1 \times 0,90 = 0,09$	1476	239	122	60	857	138	71	35
$0,05 \times 0,95 = 0,05$	784	126	65	32	455	73	38	19

Seguramente el lector se estará preguntando cómo los investigadores pueden determinar la varianza de la variable, que tiene tanto efecto sobre el tamaño de la muestra antes de determinar éste. Efectivamente, la varianza de la variable normalmente se desconoce antes de realizar la encuesta, por lo tanto no se dispone de este dato en el cálculo de n , aunque es necesario. Si el investigador posee datos de otras investigaciones en las que se ha analizado la misma variable, con muestras procedentes de la misma población, puede utilizar estos datos. A veces, con precaución, también pueden usarse estimaciones procedentes de meta-análisis sobre el fenómeno estudiado. No obstante, la opción más frecuente es sobreestimar la varianza esperada, lo que garantiza que no se sobrepasará el error máximo. El lector habrá visto con frecuencia en las fichas técnicas de las encuestas sociológicas que aparece el dato $p = q = 0,50$. Esto quiere decir que han estimado el tamaño de muestra para el error máximo fijado con la varianza máxima posible (el valor mayor de $p \times q = 0,25$, que se obtiene en dicha situación). En la tabla puede verse como en todas las condiciones el mayor tamaño de la muestra requerido es en la situación de $p = q = 0,50$.

El tamaño de la muestra para una precisión fijada se obtiene bajo el supuesto de m.a.s. (n) y para estimar el requerido en otros diseños muestrales (n') se multiplica por el efecto del diseño:

$$n' = n \times \text{Ef.Diseño}(t) \quad (10.4)$$

10.6.5. Otros procedimientos de muestreo probabilístico

10.6.5.1. Muestreo aleatorio estratificado

A veces es conveniente dividir la población en subgrupos homogéneos, mutuamente exclusivos y exhaustivos, denominados *estratos*, extrayendo a continuación una m.a.s. de cada uno de ellos (los estratos se denotan como $N_1, N_2, \dots, N_i$ y son tales que $N = N_1 + N_2 + \dots + N_i$). Este procedimiento de obtención de muestras se denomina *muestreo aleatorio estratificado*. En cada uno de los estratos se calculan los correspondientes estimadores, obteniendo a partir de ellos la estimación global. Normalmente, los sujetos que pertenecen a un estrato se parecen más entre sí que a los de los restantes por lo que la varianza o variabilidad de los datos intraestrato suele ser menor; lo que permite obtener estimadores más precisos en cada estrato. El estimador global, obtenido a partir de los anteriores, también resultará menos variable en este caso y se reducirá su varianza global. Esta es una de las razones de utilizar el muestreo aleatorio estratificado. Además de la mayor precisión, hay otras razones por las que se

puede preferir un muestreo aleatorio estratificado, entre ellas destacan las siguientes:

1. El costo por observación en la encuesta puede reducirse si se estratifican los elementos de la población en estratos convenientes, ya que el tamaño de la muestra requerido puede ser menor.
2. Pueden obtenerse estimaciones de parámetros poblacionales para los diferentes subgrupos o estratos.
3. Pueden cubrirse diferentes necesidades de muestreo en estratos separados. Por ejemplo, si interesa especialmente algún grupo, puede obtenerse para él una muestra mayor con objeto de alcanzar una mayor precisión en sus estimaciones. En la investigación educativa esto se hace con frecuencia cuando alguno de los estratos es de mayor riesgo en la característica estudiada. Por ejemplo, en los estudios sobre consumo de drogas y violencia y agresión en los centros educativos suele sobremuestrearse el estrato correspondiente a la adolescencia (si se hace estratificación por edades), ya que es el sector más vulnerable.

El tamaño de muestra requerido se determina por los procedimientos generales del m.a.s., que puede corregirse si se conoce el efecto del diseño (véase ecuación 10.4). Posteriormente este valor se repartirá entre los j estratos ($n = n_1 + n_2 + \dots + n_j$). Los procedimientos para la asignación de la muestra a los diferentes estratos (N_j) pueden ser *proporcionales* o *no proporcionales*. En el primer caso se mantienen en la muestra las mismas proporciones existentes en la población en los diferentes estratos. Supongamos que en el ejemplo de violencia y agresión en la ESO el investigador decide estratificar según la titularidad de los centros: públicos, concertados y privados. En la comunidad en la que se realiza el estudio, el 65% de los alumnos estudian en centros públicos, el 30% en centros concertados y un 5% en centros privados. Las proporciones de casos en cada estrato son: 0,65, 0,30 y 0,05, respectivamente. Teniendo en cuenta el error máximo admisible fijado supongamos que el investigador debe obtener una muestra de $n = 1000$. En un muestreo proporcional, este valor debe asignarse de forma que se mantengan en la muestra las mismas proporciones que en la población, lo que llevará a seleccionar 650 alumnos del sector público ($1000 \times 0,65 = 650$), 300 alumnos del sector concertado ($1000 \times 0,30 = 300$) y 50 alumnos del sector privado ($1000 \times 0,05 = 50$).

Los diseños aleatorios estratificados no proporcionales, como su nombre indica, no mantienen en las muestras de los estratos las proporciones que éstos tienen en la población. Aunque teóricamente solo los muestreos proporcionales son válidos para mantener idénticas las probabilidades

de selección de los sujetos, existen muchas razones que aconsejan utilizar los no proporcionales. Estas razones tienen que ver fundamentalmente con la variabilidad dentro de cada estrato y con el costo de la recogida de las observaciones. Hay diversas reglas de asignación que tienen que ver con el número de elementos (proporcionalidad), la varianza y el costo de la recogida de una unidad de muestra.

MC Procedimientos de asignación de la muestra en el muestreo aleatorio estratificado

Con frecuencia también se realiza asignación no proporcional para asegurar que las estimaciones muestrales de los parámetros intraestrato tienen la suficiente precisión. Es este el caso en algunas evaluaciones realizadas sobre el sistema educativo español, en la que se consideran estratos las comunidades autónomas, cuyas autoridades educativas están interesadas en obtener estimadores precisos de sus rendimientos educativos. Ya hemos señalado antes el caso de los estratos con mayor riesgo o vulnerabilidad, en los que es frecuente sobremuestrear, rompiendo la proporcionalidad del estrato.

Cuando se siguen reglas de asignación no proporcional, es necesario realizar *a posteriori* una ponderación de los datos, de modo que los estadísticos estimados se correspondan con la distribución en la población de las categorías que se han utilizado para formar los estratos. Los efectos del muestreo no proporcional deben corregirse en los cálculos de estimadores globales de la población (p. ej., el rendimiento educativo para el conjunto de la población española o la proporción de consumo de cannabis); esta corrección se realiza introduciendo los llamados *factores de peso o ponderación*, que se aplican también para mejorar otros aspectos de la calidad de la encuesta.

MC La ponderación en las muestras

10.6.5.2. Muestreo aleatorio por conglomerados

En los métodos de muestreo presentados hasta el momento, las unidades de muestreo eran los elementos individuales de la población. Existen otros procedimientos de muestreo, también probabilísticos, en los que la unidad primaria de muestreo no son los elementos individuales sino conjuntos o colectivos de elementos que constituyen una unidad más amplia. Estos agregados o colectivos de elementos pueden variar en tamaño y naturaleza. Por ejemplo, una población de niños escolarizados puede agru-

parse en un número de aulas o en un número de escuelas. Una muestra de los estudiantes de esta población puede seleccionarse por escuelas, clases o estudiantes, que son los elementos finales de la población.

El método de muestreo que selecciona unidades formadas por grupos de unidades elementales se denomina *muestreo por conglomerados*. Las unidades hospitalarias, los departamentos universitarios, los centros de enseñanza, las secciones del censo electoral, etc., son ejemplos de conglomerados. Existen otros tipos de conglomerados no naturales que pueden recibir el mismo tratamiento, p.ej., las urnas electorales. También se habla de conglomerados como *áreas* o *partes bien definidas del territorio*. En estos casos, en vez de hablar de muestreo por conglomerados suele hablarse de *muestreo de áreas*, aunque la técnica a utilizar y los principios básicos de estimación son los mismos. Definidas las unidades primarias de muestreo, que son los conglomerados, la forma de operar para extraer la muestra depende entre otras cosas de ciertos aspectos de los conglomerados. Cuando éstos son pequeños y las unidades elementales que los componen se parecen poco entre ellas en la característica estudiada, puede procederse realizando la encuesta a todos los elementos de los conglomerados seleccionados, realizando un *muestreo por conglomerados monoetápico*. Por el contrario, si son grandes, o si sus elementos se parecen entre ellos mucho más de lo esperable entre elementos de la población general, resulta poco fiable desde el punto de vista de la estimación. En este caso es conveniente recurrir al submuestreo de elementos dentro de las unidades seleccionadas, llevando a cabo un procedimiento conocido como *muestreo por conglomerados polietápico*. En Educación el más frecuente es el *bietápico*, consistente en seleccionar como unidades primarias los centros educativos en una primera etapa, y sobre las listas de los alumnos de los centros que pertenecen a la población objetivo (p. ej., los alumnos de 14 años) realizar un muestreo aleatorio simple.

El siguiente ejemplo muestra un esquema de muestreo de conglomerados. Imagínese una hipotética población compuesta por $N = 24$ sujetos distribuidos en 3 escuelas, con 2 clases por escuela. El esquema de organización de los conglomerados posibles se presenta en la figura 10.6.




FIGURA 10.6. Muestreo de conglomerados.

El objetivo es seleccionar una muestra de $n = 4$ estudiantes. La fracción muestral es $4/24 = 1/6$. Para la selección de los estudiantes se dispone de diversas posibilidades en el muestreo por conglomerados:

1. Seleccionar aleatoriamente una clase e incluir en la muestra a todos sus alumnos; en este caso sería un muestreo monoetápico y la probabilidad de selección de cada uno de los estudiantes se corresponde con la fracción muestral: $p = 1/6 \times 1/1 = 1/6$
2. Seleccionar aleatoriamente dos clases y a continuación seleccionar una muestra aleatoria de dos alumnos por clase, mediante un muestreo bietápico. Puede calcularse la probabilidad de selección, que también se corresponde con la fracción muestral: $p = 2/6 \times 2/4 = 1/6$.
3. Seleccionar aleatoriamente dos escuelas, a continuación una clase de estas escuelas y seguidamente una muestra aleatoria de dos estudiantes de estas clases, mediante un muestreo en tres etapas. Puede calcularse la probabilidad de selección, que también se corresponde con la fracción muestral: $p = 2/3 \times 1/2 \times 2/4 = 1/6$.

El muestreo por conglomerados es un diseño eficaz para obtener una precisión determinada, bajo alguna de las siguientes condiciones:

1. No se encuentra disponible, o es muy costoso, disponer de un buen marco que enumere todos los elementos de la población, mientras que es fácilmente disponible un marco que liste los conglomerados. Este es frecuentemente el caso en las muestras de escolares.
2. El costo para recoger información se incrementa con la distancia que separa los elementos. En Educación, el muestreo aleatorio simple, aún en el caso de disponer de listados completos de todos los escolares de la población objetivo, sería muy costoso y poco eficiente, ya que los sujetos seleccionados pertenecen a centros diferentes, que suelen estar muy dispersos geográficamente.
3. Los conglomerados serán fáciles de identificar y unívocamente determinables.
4. Los elementos del conglomerado son lo suficientemente diferentes para justificar la inclusión de más de uno de sus elementos en la muestra.

En las encuestas educativas es el diseño más utilizado y su uso se justifica por la disponibilidad de marcos muestrales adecuados de los centros escolares y por la reducción de costos en la recogida de datos, ya que reduce la dispersión geográfica de los sujetos. El muestreo también

es de naturaleza probabilística, como fácilmente se puede comprobar en el ejemplo anterior. La precisión que proporciona una muestra de conglomerados suele ser menor que la obtenida cuando las unidades de muestreo son elementos individuales de la población, ya que los sujetos que pertenecen al mismo conglomerado (p. ej., la misma escuela o la misma clase) suelen parecerse más entre sí que los sujetos de la población general, no cumpliéndose el supuesto de la *independencia* de las unidades. Esta menor precisión se refleja en el error típico y en la varianza de los estimadores obtenidos con este diseño que son mayores que los del m.a.s. El grado en que puede verse afectada la varianza depende de tres factores: el número de conglomerados, el número de unidades seleccionadas en cada uno y el grado de parecido entre sus elementos, que suele denominarse *razón de homogeneidad* (y se estima mediante un procedimiento estadístico denominado *correlación intra-clase*). En general, la eficiencia del diseño es menor que en el muestreo aleatorio simple, obteniéndose valores superiores a 1 en el cálculo del efecto del diseño (véase ecuación 10.3). Esta menor eficiencia puede corregirse aumentando el tamaño de la muestra, por el procedimiento señalado anteriormente. La estimación de este efecto y la corrección a que da lugar puede consultarse en Martínez Arias (1995c). Por el motivo anterior, el muestreo de conglomerados suele requerir tamaños de muestra mucho mayores que el m.a.s. para conseguir estimadores de la misma precisión. No obstante, las reducciones en el costo del muestreo y de la recogida de datos suelen ser suficientemente grandes como para justificar los costos adicionales de una muestra más compleja y de mayor tamaño.

En la práctica de la investigación psicopedagógica suelen combinarse con frecuencia el muestreo estratificado con el de conglomerados mono o polietápico. En una primera fase se divide la población en los estratos de interés (p. ej., por titularidad del centro, tamaño de los centros, tamaño de las localidades, ...) procediendo a continuación al muestreo de conglomerados dentro de cada estrato, con asignación proporcional o no según las características del estudio.

Aunque existen otros muchos diseños muestrales probabilísticos, su uso en las investigaciones psicopedagógicas es raro, por lo que no se describen aquí. En la investigación de encuestas, otro tipo frecuente es el muestreo sistemático.

10.6.6. Diseños muestrales no probabilísticos: métodos subjetivos

Aunque los únicos diseños que garantizan los resultados derivados del método de encuestas son los probabilísticos, con frecuencia en las investigaciones psicopedagógicas se utilizan otros procedimientos de selección de muestras que son no probabilísticos. Las muestras se seleccionan por conveniencia o sobre la base de criterios sistemáticos. Los problemas que restan validez a estos diseños varían según los casos, derivándose normalmente de los siguientes procesos:

- a) se desconocen las probabilidades de selección de los elementos y no son aplicables estrictamente hablando los procedimientos de estimación de parámetros que están basados en el muestreo probabilístico, puesto que los errores típicos pueden estimarse de forma adecuada solamente para diseños probabilísticos, y/o;
- b) la selección no se realiza al azar, influyendo en alguna medida los criterios subjetivos de selección del investigador y/o del encuestador.

Siempre son preferibles los métodos probabilísticos, pero en algunas circunstancias no son factibles y es preciso acudir a los no probabilísticos. Entre los métodos afectados en general solamente por (1) destacan el muestreo empírico o por cuotas y las rutas aleatorias. Estos procedimientos son muy importantes en la investigación de mercados y en la investigación sociológica en general, ya que aunque no son probabilísticos (se desconocen las probabilidades de ser elegidos los elementos de la población), la selección se realiza al azar y pueden obtenerse buenos resultados. No suelen utilizarse en la investigación psicopedagógica, por lo que no se describen aquí.

MC Otros procedimientos de muestreo

Puede encontrarse también una descripción en Martínez Arias (1995c).

Si el lector ha revisado investigaciones publicadas en el ámbito de la Psicopedagogía habrá observado que en la mayor parte los investigadores proceden como el investigador de nuestro ejemplo inicial, es decir, utilizando alguno de los procedimientos denominados genéricamente *métodos subjetivos* y que se describen brevemente a continuación.

Bajo esta denominación se hace referencia a un conjunto de métodos en los que juega un importante papel la subjetividad y los sesgos de selección de los investigadores, ya que la selección de unidades de la muestra no se realiza al azar. Tampoco se realiza la selección a partir de un marco muestral, ni se conocen las probabilidades de selección. La validez de los resultados obtenidos es frecuentemente cuestionable. Aunque hay muchas formas de selección de sujetos que entran en esta categoría, suelen clasificarse en los siguientes tipos:

1. *Muestras de conveniencia.* Se seleccionan los casos sobre la base de su disponibilidad para el estudio. Por ejemplo, sujetos voluntarios para probar un producto, gente que sale del metro y se le pregunta su opinión sobre la LOGSE, estudiantes en colegios a los que tiene acceso el investigador para analizar las actitudes hacia la violencia doméstica, centros de enseñanza también de fácil acceso para establecer los baremos o normas de un test, pacientes que acuden a determinados centros o servicios, etc. El problema con todos estos tipos de muestras es que no hay evidencias de que sean representativas de las poblaciones de interés, sospechándose en muchos casos que no lo son.
2. *Muestras de juicio.* Estos métodos tienen en común que se selecciona la muestra con un propósito en mente. Normalmente el investigador tiene uno o más grupos predefinidos de los que intenta encontrar sujetos. Aunque existen diferentes modalidades en la práctica, se seleccionan sobre la base de lo que algún experto piensa que deben ser los elementos de la muestra. Los casos más frecuentes en Psicopedagogía suelen ser: muestras de casos típicos, o sujetos que se supone que son normales o típicos en alguna variable y muestras de casos críticos, que son casos extremos en alguna característica.
3. *Muestras de poblaciones de difícil localización.* A veces las poblaciones de interés no se encuentran en el marco muestral. Estas situaciones anómalas son frecuentes en investigaciones sobre delincuencia juvenil, drogodependencias, sujetos sin techo, etc. Por ejemplo, se ha encontrado que adolescentes y jóvenes no escolarizados y que no viven con sus familias son poblaciones de riesgo en drogadicción. Uno de los métodos más utilizados para la localización de estos casos es el denominado *muestreo en cadena* o *de bola de nieve*, en el que se identifican algunos casos iniciales y se les pide que identifiquen uno o más casos de su red social. Estos son entrevistados y se les pide que nombren algunos nuevos casos. El proceso continúa hasta que se ha llegado a un número suficiente de casos.

Los procedimientos subjetivos, además de plantear problemas derivados del desconocimiento de las probabilidades de selección, que impiden obtener estimadores adecuados de los errores típicos, presentan otras muchas deficiencias, que suelen dar lugar a muestras escasamente representativas, dado que no existe una población de referencia para establecer inferencias. Es importante al menos intentar establecer de algún modo la representatividad de las muestras comparando sus atributos con atributos conocidos de la población, para aumentar la confianza en la generalización.

10.7. PUNTOS BÁSICOS

- La metodología de investigación con encuestas consiste en un conjunto de procesos dirigidos a obtener información sobre algunas de las características de una muestra, de modo que los resultados obtenidos puedan generalizarse a la población general de la que se ha extraído dicha muestra, bien para tomar decisiones, bien para verificar o falsar las teorías que subyacen a las mismas.
- La metodología de encuestas es especialmente útil y adecuada cuando no es factible manipular determinadas situaciones o variables, y cuando no es posible, o resulta muy difícil o costoso, el estudio de un fenómeno a través de la observación directa.
- Las encuestas se diferencian de los experimentos fundamentalmente porque tienen una mayor capacidad de generalización de sus resultados (al ser la muestra representativa de la población), se realizan en contextos más naturales, no manipulan las variables analizadas, su control y observación son indirectos y la precisión de sus medidas es algo menor, debido a los errores de medida de las encuestas.
- Las encuestas se diferencian de la metodología observacional en que en esta última se intentan utilizar contextos completamente naturales, se observan las variables directamente y su precisión en la medición es menor; además de que su capacidad de generalización es muy inferior, al trabajar habitualmente con un número muy reducido de sujetos.
- Las encuestas están básicamente orientadas a la descripción de las características de la población (encuestas descriptivas) o a la expli-

cación del porqué de las relaciones entre dichas características (encuestas explicativas o analíticas).

- La medición en las encuestas está sujeta a error. El error es la discrepancia entre los resultados obtenidos en la muestra y los parámetros reales de la población. Las dos fuentes principales del error de medida total de una encuesta son, por un lado, el error introducido por el hecho de analizar una muestra y no la población completa (error de muestreo) y el error introducido por la falta de validez y fiabilidad de la información obtenida.
- El diseño de una encuesta implica la definición de la información deseada, la definición de la población y la selección del sistema de recopilación de datos, lo que lleva a la construcción de los instrumentos de la encuesta, a la definición de la muestra y a la planificación de los procesos de obtención de datos.
- La etapa de recogida de datos incluye los procesos dirigidos a llevar a cabo el trabajo de campo de modo que las condiciones de la encuesta sean equivalentes y comparables para todos los sujetos.
- La fase de explotación de la encuesta supone la codificación, registro y verificación de la información, así como el análisis de datos y la presentación de resultados.
- Los cuestionarios y las entrevistas son los dos instrumentos utilizados más habitualmente para la recopilación de datos mediante encuestas. El sistema de recogida de datos puede ser individual o colectivo.
- Las entrevistas personales y telefónicas y las encuestas por correo son las técnicas de administración individuales más utilizadas.
- El muestreo es el proceso mediante el que se selecciona una muestra de la población de modo que sea representativa de la misma. Los muestreos pueden ser probabilísticos y no probabilísticos. Los primeros justifican la inferencia estadística, siendo el diseño básico el muestreo aleatorio simple. Los muestreos aleatorios estratificados y por conglomerados son los más comunes en Psicología y Educación.

10.8. EJERCICIOS

10.8.1. Relacione los tipos de encuesta de la columna de la izquierda con los conceptos de la columna de la derecha.

Encuesta poblacional	Muestra de una población
Encuesta transversal	Estudio de los cambios y el desarrollo
Encuesta muestral	Encuesta longitudinal a los mismos sujetos
Encuesta descriptiva	Recogida de información en una única ocasión
Encuesta longitudinal	Información cuantitativa sobre características de una población
Encuesta censal	Estudio de la relación entre características o variables
Encuesta analítica	Población completa
Encuesta de panel	Encuesta longitudinal a poblaciones de sujetos equivalentes

10.8.2. Señale las características de las siguientes clases de encuestas.

10.8.2.1. Un sondeo electoral es una encuesta:

- ☐ censal
- ☐ muestral
- ☐ descriptiva
- ☐ analítica
- ☐ transversal
- ☐ longitudinal

10.8.2.2. Una elección es una encuesta:

- ☐ censal
- ☐ muestral
- ☐ descriptiva
- ☐ analítica
- ☐ transversal
- ☐ longitudinal

10.8.2.3. Un estudio con 100 sujetos sobre el desarrollo y las causas de una enfermedad común como la gripe en la que se encuesta a los mismos sujetos cada mes durante dos años es una encuesta:

- ☐ censal
- ☐ muestral
- ☐ descriptiva
- ☐ analítica
- ☐ transversal
- ☐ longitudinal

10.8.3. Relacione los conceptos de la columna de la izquierda con los conceptos de la columna de la derecha:

Pretest	Potencia de los estadísticos para falsar hipótesis
Definición de la población	Congruencia de las respuestas
Verificación de los datos	Conversión de la teoría en preguntas concretas
Definición de la muestra	Valores posibles de las variables
Operacionalización	Revisión de los instrumentos
Libro de códigos	Exclusiones
Encuesta analítica	Selección de los encuestados
Validez del muestreo	Estadística descriptiva e inferencial
Análisis de datos	Homogeneidad entre correctores o jueces
Preguntas abiertas	Análisis de variables marcadoras
No respuesta	Audiencia
Presentación de resultados	Imputación de valores perdidos

10.8.4. Explique brevemente cuál de las dos situaciones de recogida de datos sería preferible:

1. Una encuesta censal en una población geográficamente dispersa.
2. Una muestra aleatoria y probabilística de 2000 sujetos, diseñada para lograr una precisión fijada de antemano.

10.8.5. A continuación se presentan una serie de problemas hipotéticos que surgen con frecuencia en las encuestas y que pueden dar lugar a diferentes tipos de errores, que contribuyen al error total. Identifique para cada uno de los problemas el tipo de error al que conduce.

Problemas	Tipos de error
Tamaño muestral insuficiente	Sesgo de no respuesta
Deseabilidad social en las respuestas	Error de procesamiento
Errores de grabación de datos	Error de estimación
Tasa de respuesta del 50%	Error de medida

10.8.6. Un investigador desea conocer el porcentaje de electores que están de acuerdo con la modificación de la enseñanza de las Humanidades propuesta por el Gobierno. Suponiendo que p representa la proporción de electores que están de acuerdo, q la de desacuerdos y que $p + q = 1$, ¿en cuál de las siguientes situaciones debería recoger una muestra mayor para alcanzar un nivel de precisión fijado del estimador?

- 1. $p = 0,10; q = 0,90$
- 2. $p = 0,50; q = 0,50$
- 3. $p = 0,60; q = 0,40$
- 4. $p = 0,20; q = 0,80$.

10.8.7. Los datos de la tabla representan diversos valores de un muestreo aleatorio estratificado para estudiar la edad en la que los sujetos de una población de $N = 10.000$ casos abandonaron los estudios. A partir de la información proporcionada, rellene los datos que faltan en la tabla.

Edad	N	% estrato	Muestreo proporcional		Muestreo no proporcional	
			n	Fracción muestral en el estrato	n	Fracción muestral en el estrato
16	5000	50,0		3/50		1/25
17	3000	30,0		3/50		1/15
18 o más	2000	20,0		3/50		1/10
Total	10000	100,0	600	3/50	600	3/50

10.8.8. Al planificar una encuesta mediante un cuestionario enviado por correo, se ha calculado que $n = 200$ sería el tamaño de muestra requerido para estimar la media de la población, con un error máximo de estimación dado al nivel de confianza del 95%, para las preguntas de mayor interés. El investigador ha realizado encuestas similares en el pasado y espera encontrar una tasa de respuestas del 50%, por lo que decide que el tamaño de la muestra a recoger será de $n = 400$. Con esta medida, ¿qué errores corregirá?

- 1. Errores de estimación.
- 2. Sesgos derivados de la no respuesta.
- 3. Ambos tipos de errores.

10.9. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

10.9.1.

Encuesta poblacional	Encuesta longitudinal a poblaciones de sujetos equivalentes
Encuesta transversal	Recogida de información en una única ocasión
Encuesta muestral	Muestra de una población
Encuesta descriptiva	Información cuantitativa sobre características de una población
Encuesta longitudinal	Estudio de los cambios y el desarrollo
Encuesta censal	Población completa
Encuesta analítica	Estudio de la relación entre características o variables
Encuesta de panel	Encuesta longitudinal a los mismos sujetos

10.9.2.1. Un sondeo electoral es una encuesta muestral, descriptiva y transversal, ya que no se encuesta a toda la población, se pretende describir la intención de voto pero no se pretende analizar sus causas y se realiza una única vez en el tiempo.

10.9.2.2. Una elección es una encuesta censal, descriptiva y transversal ya que se encuesta a toda la población, se describen los votos de los electores y se realiza una única vez.

10.9.2.3. Encuesta muestral, analítica y longitudinal, ya que no se encuesta a todos los enfermos de gripe, se pretende analizar relaciones causales y se realiza múltiples veces en el tiempo.

10.9.3.

pretest	revisión de los instrumentos
definición de la población	exclusiones
verificación de datos	congruencia de las respuestas
definición de la muestra	selección de los encuestados
operacionalización	conversión de la teoría en preguntas concretas
libro de códigos	valores posibles de las variables
encuesta analítica	potencia de los estadísticos para falsar hipótesis

validez del muestreo	análisis de variables marcadoras
análisis de datos	estadística descriptiva e inferencial
preguntas abiertas	homogeneidad entre correctores o jueces
no respuesta	imputación de valores perdidos
presentación de resultados	audiencia

10.9.4. (2). La principal ventaja de la muestra aleatoria de tamaño adecuado y probabilística sobre el censo completo es que reduce los costes de tiempo y dinero y es más fácil de gestionar y analizar. Normalmente mejorará la calidad de los datos recogidos y dará lugar a menos errores de codificación, grabación, etc.

10.9.5.

Problemas	Tipos de error
Tamaño muestral insuficiente	Error de estimación
Deseabilidad social en las respuestas	Error de medida
Errores de grabación de datos	Error de procesamiento
Tasa de respuesta del 50%	Sesgo de no respuesta

10.9.6. (2), puesto que siendo la varianza $p \times q$ es la situación en la que la varianza es mayor.

10.9.7.

Edad	N	% estrato	Muestreo proporcional		Muestreo no proporcional	
			n	Fracción muestral en el estrato	n	Fracción muestral en el estrato
16	5000	50,0	300	3/50	200	1/25
17	3000	30,0	180	3/50	200	1/15
18 o más	2000	20,0	120	3/50	200	1/10
Total	10000	100,0	600	3/50	600	3/50

10.9.8. (1). El aumento de n permitiría mantener el error máximo de la estimación, pero no corrige necesariamente el sesgo derivado de la no respuesta, controla sus efectos pero no lo corrige.

10.10. BIBLIOGRAFÍA BÁSICA RECOMENDADA

BUENDÍA, L. (1997). La investigación por encuesta. En L. Buendía, P. Colás y F. Hernández, *Métodos de Investigación en Psicopedagogía*. Madrid: McGraw-Hill.

Capítulo que revisa una amplia gama de temas propios de la investigación con encuestas. Además de en los procesos de realización de una encuesta, los diseños, el muestreo, el análisis de datos y la presentación del informe de investigación, hace hincapié en el papel de la teoría subyacente a una encuesta.

GÓMEZ, J. (1990). Metodología de encuesta por muestreo. En J. Arnau, M. T. Anguera y J. Gómez, *Metodología de la investigación en Ciencias del Comportamiento*. Murcia: Universidad de Murcia.

Un amplio capítulo de excelente calidad que analiza la metodología de investigación con encuestas con detalle y profundidad. Tras presentar su concepto, analiza las fases de una encuesta y los diferentes tipos de diseño, así como las estrategias de recogida de datos.

MARTÍNEZ ARIAS, R. (1995). El método de encuestas por muestreo: Conceptos básicos. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.

Trabajo que presenta los elementos fundamentales para comprender la metodología de encuestas, desde su concepto hasta los diseños muestrales más comúnmente utilizados, tratando temas de gran relevancia como los tipos y calidad de las encuestas, así como su diseño y los distintos procedimientos de recogida de información y los fundamentos del muestreo.

10.11. LECTURAS SUGERIDAS

BABBIE, E. R. (1990). *Survey research methods*. Belmont: Wadsworth.

Un libro clásico que sitúa las encuestas en el contexto de la lógica de la ciencia y de las Ciencias Sociales. Analiza de modo sencillo los diseños de investigación con encuestas, los procedimientos de recopilación de datos, los análisis básicos más comunes, así como los criterios para evaluar la calidad de las encuestas y los aspectos éticos en este tipo de estudios.

MARTÍNEZ ARIAS, R. (1995). Diseños muestrales probabilísticos. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.

Capítulo dedicado a la presentación de los principales tipos de diseños probabilísticos, desde el muestreo aleatorio simple hasta los muestreos de varias etapas más complejos, analizando los problemas de la estratificación y la utilización de conglomerados.

MARTÍNEZ ARIAS, R. (1995). Las decisiones posteriores al muestreo. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.

Trabajo centrado en los problemas de los errores de muestreo, la ponderación de las muestras y los problemas que plantea la no respuesta.

SANTOS, J., MUÑOZ, A., JUEZ, P. y GUZMÁN, L. (1999). *Diseño y tratamiento estadístico de encuestas para estudios de mercado*. Madrid: Centro Estudios Ramón Areces. Capítulos 2 y 6.

En el capítulo 2 los autores realizan una exposición detallada y pormenorizada de todas las etapas que hay que cubrir al realizar una encuesta. En el capítulo 6 se ofrece al lector el desarrollo de seis casos prácticos de encuestas reales, algunas tan conocidas como la Encuesta de Población Activa (EPA) o la del Índice de Precios al Consumo (IPC).

MC Bibliografía adicional sobre la metodología de encuestas y el muestreo

10.12. MATERIAL COMPLEMENTARIO

- Definición de la metodología de encuestas.
- Comparación de las encuestas con otros métodos de investigación.
- El problema de la no respuesta.
- Técnicas de análisis de datos en las encuestas.
- Características de los sistemas de recopilación de información.
- Cálculo del tamaño de la muestra.
- Errores de estimación.
- Procedimientos de asignación de la muestra en el muestreo aleatorio estratificado.
- La ponderación en las muestras.
- Otros procedimientos de muestreo.
- Bibliografía adicional sobre la metodología de encuestas y el muestreo.

METODOLOGÍA OBSERVACIONAL

Encarnación Sarriá Sánchez

Ángeles Brioso Díez

11.1. INTRODUCCIÓN

La observación se basa en la capacidad de percepción y de decisión del ser humano. Con qué objetivo se apliquen estas capacidades y sobre todo cómo se apliquen nos va a permitir diferenciar la observación ordinaria, que todos utilizamos de forma cotidiana, de la observación científica. La observación ordinaria es útil para la vida y constituye una importante fuente de información que nos ayuda a aprender, a anticipar situaciones, a planificar nuestro comportamiento, y en buena medida a dar sentido a lo que ocurre a nuestro alrededor. Pero la observación científica debe ser capaz de proporcionar conocimiento científico, esto es, conocimiento objetivo, replicable, fiable y válido para responder a la pregunta planteada o dar solución al problema de investigación elegido; conocimiento que además aspira a ser de la mayor generalidad posible, tal como se indica en el capítulo 1.

En este capítulo vamos a caracterizar la observación científica como fuente de datos objetivos, pero lo haremos a través de la consideración del método observacional como una opción metodológica actual de la investigación en Psicología, con sus ventajas y limitaciones y con un ámbito de aplicación idóneo en función de los objetivos y de la naturaleza del problema de estudio. En las últimas décadas, la metodología observacional se ha consolidado como una alternativa metodológica imprescindible para aquellas áreas de la Psicología que tienen como objeto de estudio el comportamiento que se genera de manera espontánea en sus contextos naturales de aparición y en las situaciones de interacción.

Cuando al investigador le interesa conocer cómo es o cómo se modifica el comportamiento del individuo manipulando y controlando ciertas variables de la situación, para así poder llegar a establecer relaciones de causalidad, utiliza la metodología experimental (*véase* capítulo 9). Pero en otras ocasiones al investigador le interesa estudiar ciertos fenómenos tal

y como se presentan de forma natural, sin introducir ningún tipo de modificación o de actuación en el entorno. En estos casos, el interés del investigador está centrado en conocer lo que el niño o el adulto hacen de manera espontánea: cómo es su comportamiento, por qué se caracteriza y qué funciones puede estar desempeñando. A veces, el interés no se centra exclusivamente en el análisis del comportamiento de un solo individuo, sino que interesa conocer cómo los comportamientos se influyen mutuamente en las situaciones de interacción, de forma que se pueda estudiar las relaciones de interdependencia que existen entre ellos. En esta línea, se realizan investigaciones para analizar: las interacciones entre iguales en el aula, las interacciones entre profesor y alumnado, las interacciones comunicativas entre madres (o padres) e hijos, etc. El objetivo de todos estos estudios es detectar patrones de comportamiento para poder hacer predicciones acerca de cuáles son los comportamientos que aparecerán con mayor probabilidad en uno de los participantes de la interacción una vez que el otro participante ha realizado una determinada conducta.

Se podría decir, sin riesgo de equivocarse, que precisamente el entorno educativo en el que se desarrolla la labor profesional del psicopedagogo y la investigación en Psicología del Desarrollo son dos de los ámbitos fundamentales de aplicación de la metodología observacional. Son diversas las razones de esta relación especial. Por una parte, la peculiaridad de la población infantil como sujetos de estudio, especialmente en los primeros años de vida, limita considerablemente la gama de instrumentos de medida aplicables, revalorizando el papel de la observación como fuente de información. Por otra, son muchos los aspectos del proceso educativo que pueden y deben ser tratados con este planteamiento metodológico porque lo relevante está en la conducta espontánea de los sujetos en toda su complejidad y diversidad, tal como se da en las situaciones reales. Son muchos los temas en los que se necesita un estudio observacional como fuente fundamental de información o complementaria de otras (encuestas, diseños experimentales...): las relaciones sociales y su dinámica de funcionamiento, las conductas prosociales o de rechazo y marginación, la interacción entre iguales en el juego libre y en situaciones de aprendizaje, la interacción profesor-alumno, el estudio de la ocupación del espacio, el estudio de las actividades en el aula, las estrategias de aprendizaje, la evaluación de la eficacia de programas de intervención, etc. Pero quizás hay una razón más, si bien hay estudios observacionales de gran complejidad, también es cierto que la metodología observacional puede ser muy útil para alcanzar objetivos sencillos. Las reglas básicas para ser aplicada con rigor y obtener datos válidos y fiables son claras e intuitivas, lo que facilita la colaboración estrecha en la recogida de datos de todas las personas implicadas en el proceso educativo. Las posibilida-

des de graduación de la complejidad de un estudio observacional en todas sus facetas (sistema de categorías, muestreo, sistemas de registro, análisis de datos) permite aplicar la metodología observacional tanto para dar respuesta a preguntas sencillas y muy concretas, pero que necesitan de respuesta rápida como es propio de los entornos aplicados, como para plantear estudios de gran envergadura que nos permitan comprender fenómenos complejos.

En este capítulo se presentan las diferentes fases que caracterizan a la investigación observacional, el proceso de toma de decisiones al que se enfrenta el investigador en cada una de ellas en función de su objeto de estudio, los recursos e instrumentos de recogida de datos y los análisis que le son propios. Esta presentación tiene un nivel muy básico (por razones de espacio obvias), pero pretende ser lo suficiente para que la/el lector pueda llegar a plantear y realizar su propio estudio observacional.

Los objetivos que pretendemos alcanzar en este capítulo son los siguientes:

- caracterizar la observación científica;
- descubrir el doble papel de la observación en la investigación científica, como técnica de recogida de datos y como opción metodológica global;
- descubrir los posibles grados de estructuración de la situación y de participación del observador en el planteamiento de un estudio observacional;
- valorar la importancia del sistema de categorías, conocer su finalidad y las claves para la creación de un buen sistema de categorías;
- valorar la importancia del muestreo de situaciones, lugares, momentos, sujetos, para disponer de una muestra representativa del comportamiento en estudio;
- identificar las distintas alternativas de registro con sus posibilidades y limitaciones;
- considerar las posibles fuentes de error en la observación, sus posibilidades de control en el procedimiento y su cuantificación a través de los análisis de fiabilidad;
- conocer las distintas medidas que se pueden obtener con los datos de observación del comportamiento y las distintas alternativas de análisis de los mismos.

En el diagrama de la figura 11.1 se presenta un esquema-resumen con los contenidos que se van a desarrollar en el capítulo para lograr los objetivos planteados.




FIGURA 11.1. Esquema-resumen con los contenidos del capítulo 11.

11.2. CARACTERIZACIÓN DEL MÉTODO OBSERVACIONAL

Podemos entender la observación científica como una forma de captar la realidad, que puede ser aplicada con rigor y sistematicidad, y que en definitiva posibilita la recogida de información relevante en un estudio científico. Observación sistemática y ciencia están estrechamente relacionadas en la medida en que la contrastación empírica de las hipótesis se basa en el contacto con la realidad de los hechos y esta realidad se capta en muchas ocasiones a través de la observación (a partir de ahora con la expresión «observación» estaremos haciendo referencia a la «observación científica», que es nuestro objeto de interés en este capítulo). Ahora bien,

conviene aclarar que la aportación metodológica de la observación a la investigación científica es doble: como técnica y como método.

La observación como *técnica de recogida de datos* puede estar implicada en cualquier tipo de diseño de investigación: puede ser perfectamente la forma de medida de la variable dependiente de un diseño experimental, o de un cuasi-experimental, o de un *ex post facto*. Actuando como técnica, la observación debe adecuarse a los objetivos generales de la investigación que la implica y cumplir ciertos requisitos de rigor en su planteamiento y aplicación, de manera que la información que proporcione sea útil, válida y fiable.

MC Ejemplo de aplicación de la observación como técnica de recogida de datos

Pero podemos entender la observación como definitoria de un método concreto, que tiene una característica fundamental que lo define y un ámbito de aplicación idóneo y que exige cierta coherencia en las decisiones de planificación y procedimiento, entre sí y con los objetivos del estudio. En este sentido se habla también de *método observacional*. Así como el método experimental se caracteriza por la intervención directa del investigador a través de la manipulación y el control de las variables, con el objetivo de poder establecer relaciones causa-efecto entre las variables en la explicación de un fenómeno, el método observacional se caracteriza por la no intervención del investigador en el fenómeno de estudio y la no restricción de las respuestas de los sujetos a través de las tareas o los instrumentos de evaluación porque el objetivo, en este caso, es el estudio de la conducta generada espontáneamente.

Para poder abordar el análisis de la conducta y de las interacciones espontáneas se requiere una metodología que preserve dicha espontaneidad y esa es precisamente una de las características esenciales que Anguera (1988) propone en su definición de metodología observacional:

...definimos la metodología observacional como un procedimiento encaminado a articular una percepción deliberada de la realidad manifiesta con su adecuada interpretación, captando su significado, de forma que mediante un registro objetivo, sistemático y específico de la conducta generada espontáneamente en un determinado contexto y una vez que se ha sometido a una adecuada codificación y análisis, nos proporcione resultados válidos dentro de un marco específico de conocimiento (pág. 7).

En esa definición se recogen los criterios que son necesarios para poder considerar a la observación como método científico, esto es, como un procedimiento sistemático que:

1. Permite la comprobación de hipótesis.
2. Garantiza la replicabilidad de sus resultados al utilizar procedimientos objetivos, válidos y fiables.
3. Contribuye al desarrollo teórico al proporcionar resultados válidos en marcos específicos de conocimiento.

Ahora bien, no sería muy adecuado entender la realidad de la observación sistemática en Psicología como una contraposición observacional vs experimental, porque como podemos casi intuir a partir de estos dos párrafos, se pueden dar situaciones intermedias (al final, como casi siempre, es una cuestión de grados). Podemos plantear distintos grados de estructuración de la situación y distintos grados de participación del observador.

La situación en la que se observa el comportamiento de los sujetos de estudio puede ser completamente natural, en su entorno o contexto habitual y sin ningún tipo de modificación por parte del investigador; esta es la *observación naturalista*. Por ejemplo, si para el estudio de las primeras formas de conversaciones y juegos de turnos de los neonatos con sus madres grabamos en video los minutos de interacción libre y espontánea madre-hijo después de la alimentación, en sus domicilios y respetando el horario habitual del niño, hemos planteado una situación de observación natural. Pero si quisiéramos poder estudiar comparativamente la interacción madre-hijo de niños normales, con la que se da en el caso de niños diagnosticados de síndrome de Down, es posible que fuera conveniente garantizar unos elementos de constancia de unas situaciones con otras, para lo cual podríamos decidir dar a las madres algunas instrucciones sencillas de postura corporal, comentarios o juguetes que deberían utilizar. En este caso estamos planteando una situación de *observación semiestructurada*, como técnica de recogida de datos de un estudio comparativo o *ex post facto*, ya que comparamos grupos naturales (díadas madre-niño normal, díadas madre-niño con síndrome de Down). La situación de observación se puede hacer más rígida; por ejemplo, la madre puede ser sustituida por el investigador que interactúa con el niño según un guión preestablecido que pretende plantear escenas que motiven a los niños y permitan que sus habilidades sociales y comunicativas se manifiesten. Podemos llegar a crear una situación de *observación estructurada*.

En definitiva, además de la más conocida y prototípica observación naturalista propia de los estudios etológicos, son muchas y diversas las posibilidades de implicación de la observación en la investigación en Psicología y en ciencias afines, a través de los diversos grados de estructuración de la situación de observación en combinación con la posible incorporación de la observación como técnica de recogida de datos en diseños con, a su vez, diversos grados posibles de control e intervención del investigador.

Otra posible taxonomía de formas de observación que podemos utilizar para precisar las características de nuestro estudio se refiere al *grado de participación*. Aunque algunos manuales distinguen sencillamente entre observador participante y no participante, o entre observación interna y observación externa, de nuevo existen otras posibilidades intermedias, porque es cuestión de grados. Tal y como señala Anguera (1990), podemos distinguir entre:

- La *observación externa* o no participante, en la que el observador es ajeno a la situación en estudio, con muy escasa o nula interacción con los sujetos estudiados. Estas condiciones de observación facilitan la objetividad del observador en sus decisiones de registro y evitan los riesgos de interferencia en el fenómeno de estudio.
- La *observación participante*, en la que el observador se integra en la dinámica del fenómeno en estudio, participando en las actividades del grupo o del sujeto para establecer contacto directo con la realidad. Aunque es muy utilizada en ciertos ámbitos como la Antropología, la Sociología o la Pedagogía, con el objetivo de profundizar en la comprensión de los problemas de estudio, plantea riesgos de subjetividad en las decisiones de registro del observador al estar implicado en la situación, y por la posible intervención de éste en los acontecimientos, alterando lo que hubiese sido su curso natural.
- El *participante como observador* u observación por allegados, es otra forma de observación en la que un miembro natural del grupo o de la situación en estudio es el que realiza las funciones de observador. Éste dispone de acceso privilegiado a datos o acontecimientos privados inasequibles a un observador externo, aunque puede ser conveniente aplicar ciertas normas de prudencia ante los riesgos de sesgo subjetivo en los registros.
- La *auto-observación*, en la que se plantea el grado máximo de participación y observación, ya que es el propio sujeto bajo estudio el que registra su conducta. Este sistema es especialmente útil para el registro de conductas encubiertas o con gran implicación de esta-

dos emocionales (decisiones, ansiedad, deseos...). La posible interferencia de ser a la vez sujeto activo y objeto de observación plantea serias dudas sobre la validez de los datos, según cuáles sean los objetivos de la investigación, por lo que su uso es mucho más frecuente como fuente de información para el diagnóstico y la intervención (donde la significación clínica se sobrepone a la significación estadística y a la replicabilidad) que en la investigación.

Una investigación observacional parte del mismo punto que cualquier otra, se comienza por el planteamiento del problema (que es el que, en buena medida, determina la elección de esta metodología) para recorrer todas las etapas señaladas en el capítulo 1: formulación de la hipótesis (o las hipótesis), definición operativa de las variables, elección de los instrumentos de medida y evaluación de su calidad métrica, selección de la muestra de sujetos, recogida de datos, análisis de datos e interpretación de los resultados. Algunas de las decisiones básicas a tomar al plantearse una investigación observacional, en cierta forma, son específicas o particulares de este tipo de metodología (véase figura 11.2). Estas decisiones afectan a aspectos tan esenciales como qué observar, cuestión que resolvemos a través de la elección, adaptación o creación del sistema de categorías; a cuestiones de muestreo, que en esta metodología no sólo se refieren a quién observar sino a cuánto tiempo, dónde y cuándo observar; a cómo observar, que se concreta en la forma de recoger la información y el tipo de registro y codificación que vamos a realizar; a la evaluación de la calidad métrica de los datos que se basa esencialmente en el estudio de la fiabilidad y, por último, al análisis de los datos que se puede realizar con técnicas específicas adecuadas a la naturaleza de los mismos y a los objetivos de la investigación.

Qué	⇒	Sistema de categorías
A quién Cuánto tiempo Dónde Cuándo	⇒	Muestreo
Cómo	⇒	Registro

FIGURA 11.2. Aspectos característicos de la metodología observacional.

11.3. CATEGORIZACIÓN

Una de las decisiones críticas en una investigación observacional se refiere a la selección de aquellos aspectos de la conducta o de la situación que consideramos relevantes para los objetivos del trabajo. Estamos deci-

diendo qué hay que observar. La identificación clara y objetiva de las conductas o elementos a observar, a través de su descripción o definición por parte del investigador, constituye un paso fundamental en el proceso de *categorización*. Y a través de él podemos llegar a crear un potente instrumento para la observación: el sistema de categorías.

La creación del sistema de categorías puede ser una de las tareas más importantes de un estudio observacional. Es un pilar fundamental de la investigación que puede implicar horas de lectura de documentación para el estudio teórico del tema, horas de observaciones informales previas, largas discusiones de equipo (cuando tienes la suerte de tenerlo) y el cambio sucesivo de diferentes versiones que irán siendo revisadas y puestas a prueba hasta llegar a la forma definitiva (que casi nunca lo es completamente). Esta tarea, aunque tiene un componente práctico ineludible, es en gran parte un acto teórico ya que el investigador está decidiendo qué conductas son relevantes y, por tanto, será necesario registrar para dar respuesta a la pregunta de la investigación.

El *sistema de categorías* nos permite enfrentarnos a la tarea de registro teniendo seleccionadas y definidas o descritas las conductas relevantes para nuestro estudio y en las que el observador deberá focalizar su atención. Es muy difícil que un sistema de categorías creado para un estudio sea aplicable directamente a otro. Como poco deberá ser revisado y posiblemente tengan que realizarse adaptaciones al nuevo estudio, aunque es muy frecuente que los investigadores lleguen a crear un sistema de categorías propio y específico para los objetivos de la investigación.

Suponiendo ya definidos los objetivos y las condiciones del estudio y planteada la necesidad de crear un sistema de categorías específico, podemos recurrir a dos vías fundamentales para iniciar el proceso de categorización. La bibliografía existente sobre el tema, tanto sobre los modelos teóricos explicativos como sobre investigaciones anteriores, nos puede ayudar a identificar aspectos relevantes que deberíamos considerar en nuestro sistema como posibles niveles de análisis a desarrollar. La otra vía, que más que alternativa debería verse como complementaria de esta primera, la constituyen las observaciones informales o asistemáticas preliminares. En ellas el investigador se enfrenta a situaciones similares a las definitivas y, teniendo presente el propósito del sistema a crear, anotará las conductas que aparecen y las condiciones en las que ocurren. Con esta información puede elaborar una primera lista de elementos y rasgos, que estudiará en sus posibles agrupamientos o desgloses y someterá a prueba (a través de observaciones semisistematizadas) las veces que considere necesario hasta llegar a un sistema de categorías que resulte completo y claro y que servirá para realizar la observación sistematizada que proporcione los datos del estudio.

En la categorización se seleccionan los episodios y las conductas pertinentes, se toman decisiones en torno a los criterios de inicio y final de los mismos y se definen los términos que formarán parte de una misma categoría (comparten el mismo rótulo y código), especificando cuáles son sus atributos comunes más característicos y cuáles son los diferenciadores de los elementos pertenecientes a otras categorías.

Hablamos de sistema de categorías cuando disponemos o hemos definido dos o más categorías para la observación y el registro de un mismo fenómeno desde un determinado nivel de análisis. Cada sistema de categorías debe responder a las exigencias de Exhaustividad y Mutua Exclusividad (condición EME). La condición de que sea exhaustivo se refiere a que exista una categoría para cada una de las conductas relevantes posibles que puedan aparecer en la situación de observación y en el nivel de análisis del sistema, de forma que éste tenga validez para alcanzar los objetivos del estudio y que no existan vacíos o lagunas en el registro. La condición de mutuamente exclusivas se aplica directamente a las categorías y supone que estas están definidas sin ambigüedades, de manera que cada conducta sólo pueda ser asignada a una categoría o código.

Las categorías se pueden definir atendiendo a aspectos fácilmente perceptibles, que consiguen desmenuzar el flujo conductual en sus «moléculas», o atendiendo a criterios más «molares», más globales, que exigen mayor grado de inferencia por parte del observador. De nuevo el grado de *molecularidad* o *molaridad* (debe entenderse como los dos extremos de un continuo) de las categorías está relacionado y en cierta forma determinado por los objetivos del trabajo. Siendo realistas hay que tener en cuenta que la mayor molaridad de las categorías suele suponer mayor dificultad para su definición y aumentan los riesgos de problemas en la fiabilidad de los datos. Algunos autores abogan e insisten en la necesidad de que las definiciones de las categorías se ajusten a elementos físicos observables directamente y que presenten límites claros y rígidos. Asimismo y casi como consecuencia de lo anterior consideran que aspectos como la intencionalidad o la función de la conducta deben ser evitados en los estudios de observación. Sin embargo, es conveniente plantearse, como sugieren Bakeman y Gottman (1986), que si todos siguiéramos rigurosamente este consejo, ciertos problemas y conductas de interés no llegarían a ser estudiados. La dificultad para delimitar o definir algunas categorías está estrechamente relacionada con su propia naturaleza y más que forzarla de forma artificial a veces es más conveniente contar con estas características e incorporarlas como un reto más dentro del propio proceso de investigación.

MC Sobre la borrosidad de las categorías

Vamos a describir someramente, a modo de ejemplo y para aclarar algunas de estas cuestiones, una investigación realizada por Elena Gaviña (1992, 1994), profesora de la UNED, con niños preescolares de la Comunidad de Madrid.

El *objetivo* del trabajo era estudiar las reglas que regían el intercambio de recursos en niños pequeños (preescolares). Si bien investigaciones experimentales anteriores habían concluido por sus resultados que los niños menores de 7 años en sus intercambios no siguen más regla que la del propio interés o como mucho la igualdad, esta autora cuestiona estos resultados. Se plantea la necesidad de estudiar esta cuestión de una manera más natural, buscando criterios que puedan ser más relevantes para los niños de esta edad que los utilizados en los experimentos. Por ello opta por la metodología observacional para el estudio del juego libre de dos grupos de niños, centrándose en la observación de las conductas de intercambio y de las interacciones que implicaban dominancia y/o subordinación.

Sus *hipótesis* eran:

1. Los intercambios de los niños de preescolar (4-6 años) no necesariamente son egoístas o igualitarios, sino que también pueden ser recíprocos (se da en relación directa con lo que se recibe —ojo por ojo—) y equitativos (dar a unos más que a otros en función del criterio de merecimiento). El criterio de merecimiento de los intercambios de los niños será la posición que ocupe el otro en la jerarquía de dominancia.
2. Los niños insatisfechos por su situación en el grupo en cuanto a la relación entre lo que aportan y lo que reciben mostrarán un menor grado de participación en las interacciones grupales, tal como predice la teoría de la equidad.

El *método* utilizado fue el siguiente. Los datos se recogieron en dos guarderías, observando la conducta de los preescolares en periodos de juego libre en el recreo con compañeros de su edad. En uno de los grupos los niños gozaban de gran libertad (Centro Z), mientras que el otro (Centro A) se caracterizaba por el control de la situación por parte de los educadores. El recinto donde se recogieron los datos se encontraba en ambas guarderías al aire libre y contaba con diversos elementos para el juego físico como barras, columpios..., que eran no obstante insuficientes para todos, dando lugar a frecuentes conflictos por su uso.

La *muestra* estaba compuesta por niños entre 4 y 6 años de edad de ambos sexos (28 del Centro Z y 34 del Centro A). La observación tuvo lugar durante los recreos de los meses de enero a junio, y el muestreo se realizó utilizando como criterio que durante un tiempo prefijado (10 minutos por sesión de observación) se registraban de forma continua y completa todas las conductas de interés de un determinado individuo. Se podían seguir unos cinco niños por sesión. Se trataba de conseguir un tiempo total de observación por individuo relativamente equilibrado. Para el registro de las interacciones se combinó el uso del video, la grabadora de audio y las anotaciones en hojas de registro confeccionadas a tal efecto.

El *sistema de categorías* conductuales que guiaba el proceso de registro está reproducido en el cuadro 11.1.

CUADRO 11.1

Sistema de categorías para el estudio de las relaciones de dominancia y equidad de los niños preescolares (Gaviria, 1992)

AGRESIÓN FÍSICA (AF): golpear, empujar, dar patadas, tirar objetos contra otro, etc., sin que el receptor de estas conductas responda en los mismos términos (es decir, adopta una actitud pasiva, huye o protesta, pero sin llegar a contraagredir).

AGRESIÓN VERBAL (AV): insultar, molestar con comentarios hirientes, hacer burla, ridiculizar sin que el receptor responda en los mismos términos (actitud pasiva, abandono del grupo o protesta, pero sin contraagredir).

AMENAZA (AM): amenaza verbal o física (mirada fija o brazo en alto, amago de patada, etc.) de daño físico o de arrebatar un objeto sin llegar realmente al contacto. El receptor no responde en los mismos términos (actitud pasiva o huida).

ARREBATAR OBJETOS O LUGARES (AR): quitar un objeto o el sitio a otro de forma violenta o no, sin que el otro se oponga mostrando resistencia.

ÓRDENES (OR): decirle a otro lo que tiene que hacer de forma imperativa. El otro puede obedecer (OR) o desobedecer (OR-).

DECISIONES (DC): decirle a otro lo que hay que hacer de forma indirecta, como propuesta. El otro puede acatar la decisión (DC) o no acatarla (DC-).

PERSUASIÓN (PS): tratar de convencer a otro de que haga algo sin obligarle físicamente. El otro puede dejarse persuadir (PS) o no dejarse (PS-).

SEGUIMIENTO (SG): moverse en la misma dirección y detrás de otro niño que inicia la acción. Debe haber desplazamiento físico, no sólo seguimiento en el sentido de aceptar una propuesta (véase la categoría *Decisiones*) o de repetir lo que el iniciador hace (véase la categoría *Imitación*). Tampoco se registra como seguimiento la conducta que se produce en el caso de que el iniciador ordene al sujeto que lo siga. Es simplemente un seguimiento voluntario.

IMITACIÓN (IM): hacer lo mismo que otro niño voluntariamente, ya sea igual o con alguna modificación. No debe confundirse con hacer burla (imitación exagerada, generalmente acompañada de risa), ya que se clasificaría dentro de la categoría *Agresión Verbal*.

CONTACTOS AMISTOSOS (CA): dirigirse a otro niño, estableciendo contacto físico en forma de abrazos, besos, caricias, palmadas en la espalda, dar la mano y en general cualquier contacto físico con otro niño que no sea agresivo ni fortuito (es decir, ha de ser intencionado).

DONACIÓN DE RECURSOS (DR): dar u ofrecer a otro niño un objeto o cederle el sitio voluntariamente. No incluye la respuesta a una orden (véase la categoría *Órdenes*), ni a la conducta de arrebatarse por parte de otro niño (véase la categoría *Arrebatarse*).

PELEAS FÍSICAS (PF): agresiones mutuas con contacto físico entre dos ponentes por la posesión de un objeto o un lugar, o porque un niño responde a la agresión previa de otro en los mismos términos (es decir, sería una reacción de insumisión a las conductas AR o AF de otro).

PELEAS VERBALES (PV): agresiones mutuas sin contacto físico (insultos, burlas, etc.) entre dos oponentes como respuesta a una amenaza previa de uno de ellos (insumisión ante las conductas AV o AM de otro).

Para el *análisis de los datos* se utiliza el recuento de frecuencias de aparición de las distintas conductas seleccionadas y sus frecuencias relativas. Gaviria (1994) aplica diversos índices que informan de la proporción entre lo que da y recibe cada individuo y su posición en la jerarquía del grupo, y que posibilitan el estudio de su relación mediante el análisis estadístico de los datos.

Los *resultados* indican que en los dos grupos se produce un reparto selectivo de los recursos, que reflejaría la aplicación de la norma de la equidad tal y como se predecía en la hipótesis del trabajo. Se utilizan criterios de merecimiento y ese merecimiento está relacionado con el estatus social de los participantes en el intercambio.

Respecto a la segunda hipótesis, los niños de ambos centros proporcionan datos que indican el uso de estrategias para reducir la inequidad, que pueden consistir no solo en el abandono de la situación injusta, como predecía la hipótesis y se manifestaba en el Centro Z, sino también con métodos más activos como oponerse al exceso y compensar el defecto como se manifestaba en el Centro A.

Volviendo a las categorías y utilizando para ello el apoyo del ejemplo descrito, fijémonos por un momento en la definición de la primera categoría del cuadro:

Agresión física (AF): golpear, empujar, dar patadas, tirar objetos contra otro, etc., sin que el receptor de esta conducta responda en los mismos términos (es decir, adopta una actitud pasiva, huye o protesta, pero sin llegar a contraagredir).

Vemos claramente como se hace una lista de posibles conductas que siendo distintas pueden tener un significado común, por el cual se les incluye en una misma categoría y se les aplica la misma etiqueta y el mismo código, «AF». Pero también podemos comprobar como se garantiza la mutua exclusividad de esta categoría con otra cercana y con la que podrían plantearse solapamientos (la categoría de «Peleas físicas») ya que sólo se incluirá en la categoría de «Agresión física» cuando no hay respuesta en los mismos términos por parte del que recibe la agresión. Si una agresión física es respondida con otra, se registra como pelea, indicando quién la inicia y quién responde. Merece la pena leer despacio también las definiciones de las categorías de «Peleas físicas», «Peleas verbales» y «Amenazas», prestando especial atención a cómo se han marcado los límites entre ellas.

La exhaustividad del sistema está estrechamente relacionada con lo que es relevante para el problema de estudio. En este trabajo, por ejemplo, no se categorizan ni se registran las conductas de juego solitario de los niños. Se limita al registro de las conductas dirigidas a otro o como respuesta a otro, que es el objeto de interés. Esta ausencia de categorías que permitan registrar los posibles episodios de comportamientos no interactivos no plantea ningún problema en esta investigación porque sus objetivos se pueden alcanzar a través del análisis de las frecuencias de las conductas interactivas, pero habría planteado problemas de importantes lagunas en el registro si los objetivos hubiesen exigido el análisis de secuencias de conductas. De esta forma, podemos decir que este sistema cumple la condición de exhaustividad si se tiene en cuenta los objetivos originales para los que fue diseñado, ya que esta condición está directamente relacionada con el criterio de relevancia de cada investigación.

La mutua exclusividad es fundamental para obtener datos objetivos y fiables, de manera que una conducta determinada pueda ser inequívocamente asociada a una categoría a partir de las propias definiciones del sistema, independientemente de quien sea el observador. Dicho de otro modo, en una unidad básica de tiempo, pongamos por caso un segundo, sólo debería identificarse una categoría conductual en el comportamiento del individuo. Esto es cierto, pero sólo si estamos pensando en un único *nivel de análisis*.

Vamos a ver esta cuestión más despacio. La conducta es compleja y puede tener muchos componentes que incluso se den al mismo tiempo. Cuando una persona se dirige a otra, puede estar emitiendo una *conducta verbal* con un determinado contenido o función (interrogativa, declarativa, imperativa, vocativa...), a la vez que presenta una determinada *expresión emocional* en su cara (alegría, tristeza, neutra, miedo...), a la vez que realiza una determinada *conducta visual* (mira a la cara, mira a cualquier otro punto de su cuerpo, mirada perdida...), a la vez que utiliza *gestos* de comunicación no verbal (apunta con el dedo, eleva los hombros, levanta los brazos...). Cada uno de estos aspectos de su conducta — verbal, expresivo, visual y gestual— constituye un posible *nivel de análisis* a considerar en un estudio observacional sobre este tipo de comportamiento. Hemos visto como en cada uno de estos aspectos o niveles de análisis se contemplaban varias opciones o posibilidades distintas de manifestación (por ejemplo las distintas expresiones emocionales: alegría, tristeza, miedo, neutra...). Estas diversas manifestaciones posibles podrían llegar a definirse como categorías componentes de un sistema y deberían ser mutuamente excluyentes y exhaustivas para ese determinado nivel de análisis.

Cuando en un mismo estudio queremos observar la conducta teniendo en cuenta simultáneamente varios niveles de análisis, podemos organizar un sistema de categorías más complejo compuesto de distintos *subsistemas*, uno para cada nivel de análisis, de forma que cada uno cumple la condición EME en sí mismo, pero un mismo comportamiento puede ser registrado al mismo tiempo en cada uno de los niveles considerados o desde distintas perspectivas (dimensiones).

MC Ejemplo de sistema de codificación multidimensional

Otros sistemas de categorías complejos pueden estar compuestos por subsistemas de categorías distintos a aplicar al mismo tiempo a los distintos participantes de la interacción. Es fácil imaginar que en el análisis de las secuencias de conductas de una díada madre-hijo puede ser necesario registrar lo que hace cada uno de ellos al mismo tiempo, porque ambos pueden coincidir haciendo algo relevante desde el punto de vista de los objetivos de la investigación. También es fácil imaginar que las categorías conductuales aplicables al bebé no tienen porque ser las mismas que las aplicables a la madre. De nuevo nos podemos encontrar con la necesidad de considerar dos subsistemas, que cumplen por sí mismos la condición EME, pero que al aplicarlos para el análisis de una sesión proporcionan registros simultáneos o co-ocurrentes.

11.4. MUESTREO Y REGISTRO

Por muy amplio que sea un estudio, las observaciones están limitadas a un periodo de tiempo. El investigador trabaja (observa y registra) con una muestra de la conducta del individuo o del grupo en estudio, que debe reflejar las características y la dinámica real de la misma. Es decir, la muestra debe ser representativa.

La representatividad de esta muestra de datos va a depender de diversos factores, entre otros de la validez del sistema de categorías para captar los aspectos más relevantes del problema, pero fundamentalmente dependerá de la adecuación de las decisiones de muestreo y registro y de su coherencia con los objetivos de la investigación.

Muestreo y registro son dos actividades estrechamente relacionadas, especialmente en el proceso de decisión. Las reglas de muestreo que hayamos elegido o decidido para la investigación en desarrollo nos especifican cuándo hay que observar, en función de los criterios de inicio y final de las sesiones (*muestreo intersesional*) y a qué sujetos y cuándo, dentro de cada sesión (*muestreo intrasésilional de sujetos*). Las reglas de registro especifican cómo se debe registrar el comportamiento de ese o esos individuos dentro de cada sesión y qué propiedades de la conducta (ocurrencia, duración y/o orden).

Comencemos por aclarar el concepto de sesión. Partimos de la idea de una *sesión de observación* como un periodo de tiempo continuado durante el cual el observador registra sistemáticamente las conductas objeto de estudio. Las sesiones de observación son, por tanto, fragmentos operativos de tiempo *del periodo de observación*; esto es, del periodo en el que tendría sentido registrar la conducta del sujeto en función de los objetivos del estudio. Como veremos un poco más adelante, el periodo de observación que responde a los criterios teóricos, no siempre es viable en términos prácticos. En la mayoría de los estudios el investigador tiene que aceptar la existencia de sólo ciertos *subperiodos* (partes del periodo de observación) disponibles en función de las posibilidades del sujeto o del observador.

En un artículo clásico y paradigmático sobre el muestreo en metodología observacional, publicado en 1974 por la etóloga Jeanne Altmann, se plantean los distintos tipos de muestreo a partir de la combinación de lo que esta autora denomina *variables de muestreo*. Basándonos fundamentalmente en sus aportaciones, las de Anguera (1989, 1990) y Quera (1991), vamos a exponer esquemáticamente las decisiones fundamentales sobre el muestreo observacional y algunas de las opciones de procedimiento (las más utilizadas).

11.4.1. Reglas de muestreo

Como en cualquier otra investigación empírica en Psicología, en un estudio observacional, una vez delimitado el problema, procedemos a *seleccionar la muestra de sujetos* que será objeto de estudio y que debe ser representativa de la población de interés. Las unidades de estudio o unidades muestrales pueden ser individuos, díadas, grupos, etc. En el capítulo anterior se realizó una exposición de distintas técnicas de muestreo y el libro de Suen y Ary (1989) proporciona amplia información sobre técnicas de selección de sujetos en metodología observacional. Ahora bien, el muestreo en la metodología observacional va más allá de seleccionar a los sujetos o conductas a observar; tiene sus propias peculiaridades a las que es preciso atender y que se recogen esquemáticamente en el cuadro 11.2.

CUADRO 11.2
Decisiones de muestreo en metodología observacional

- | |
|--|
| <ol style="list-style-type: none">1. SELECCIÓN DE LAS UNIDADES MUESTRALES2. MUESTREO INTERSESIONAL: Cuándo observar (inicio y fin de las sesiones)<ul style="list-style-type: none">— Selección fija— Selección aleatoria3. MUESTREO INTRASESIONAL: Qué sujetos y cuándo<ul style="list-style-type: none">— Focal— Multifocal— Combinación de ambos |
|--|

Muestreo interseccional: Criterios de inicio y final de las sesiones de observación

La *selección fija* es el sistema más sencillo para determinar los momentos y lugares de las sesiones de observación y consiste en la aplicación de un criterio fijo (temporal, conductual, situacional o de actividad). Las sesiones de observación son siempre a las mismas horas del día o coincidiendo con determinadas actividades (por ejemplo, en la investigación de Gaviria (1994) las sesiones se realizaban única y exclusivamente en los recreos escolares). Aunque limita la representatividad de los datos a lo ocurrido en esas horas o vinculado a ciertas actividades, en algunas investigaciones el propio problema de estudio determina los

momentos más adecuados para la observación, sea por razones teóricas o por razones prácticas de viabilidad de la manifestación de las conductas objetivo.

Aún cuando no existan estos criterios determinantes de momentos y situaciones, el inicio y final de las sesiones deben programarse para asegurar la representatividad de la conducta registrada. La *selección aleatoria* contribuye a conseguir esta representatividad y se puede aplicar de varias formas, según las restricciones a las que esté sometida la investigación:

- *Muestreo aleatorio simple*: los inicios de las sesiones de observación se seleccionan aleatoriamente en el periodo de observación, de forma que todos los puntos temporales posibles (teniendo en cuenta la duración de la sesión y la distancia entre sesiones determinadas) tienen la misma probabilidad de constituirse en inicios de sesión. Este tipo de muestreo es poco viable en muchas investigaciones en las que los sujetos a observar o los observadores suelen tener limitada su disponibilidad a ciertos periodos de tiempo.
- *Muestreo aleatorio estratificado*: los estratos que se utilizan son precisamente los subperiodos de disponibilidad para la observación. Se fija un número de sesiones a realizar en cada estrato y la selección aleatoria se aplica para seleccionar los momentos de inicio de esas sesiones dentro de cada estrato o subperiodo disponible.
- *Muestreo aleatorio sistemático*: si la disponibilidad está limitada a un único subperiodo continuado (por ejemplo, horario escolar, de 9 a 14:00) se puede seleccionar al azar el momento de inicio de la primera sesión y aplicar una norma sistemática a partir de esta, para iniciar las siguientes, teniendo en cuenta la duración de las sesiones y/o la distancia entre ellas.

Muestreo intrasiesional de sujetos

Además de la selección de sujetos o unidades muestrales y de los criterios de inicio y finalización de las sesiones de observación, cuando en un estudio observacional se plantea la observación de un grupo a través del registro de la conducta de los sujetos que lo componen, será necesario determinar un procedimiento sistemático de reparto de la atención del observador a los distintos miembros del grupo en cada sesión. El procedimiento decidido será una forma de *muestreo intrasiesional de sujetos*, siendo las más utilizadas:

- *Muestreo focal*: Esta regla de muestreo indica que un solo sujeto (o unidad muestral) se convierte en el foco de la atención soste-

nida del observador. La atención del observador se mantiene focalizada en ese individuo durante un periodo de tiempo grande, que en muchas investigaciones llega a ser toda la sesión. Cuando el objetivo del estudio es la observación de grupos, los otros miembros del grupo serán observados (sujetos focales) en otra parte de la sesión o en sesiones posteriores. Se debe especificar de forma previa al registro cuál es o cuáles son los sujetos focales de la sesión y qué hacer si el sujeto focal deja de ser observable. Si la investigación está orientada a obtener datos de sujetos individuales, estén solos en la situación de observación o actuando en diada o en situación de grupo, también se describe como muestreo focal.

- *Muestreo de barrido o multifocal*: El observador va focalizando a cada uno de los individuos en periodos de tiempo muy breves, pasando de un sujeto a otro, en un orden establecido y que se repite varias veces en la sesión. La duración de los intervalos de observación debe ser la misma para todos los sujetos y en todos los barridos de la sesión. El muestreo multifocal genera datos con algunas limitaciones ya que los datos de un individuo están constituidos por periodos discontinuos, que no permiten analizar sus secuencias de conducta.
- *Uso combinado de muestreo focal y muestreo de barrido*, propuesto por Altmann (1974), entre otros autores, de manera que aunque durante la sesión el observador registre la conducta de un solo individuo focal, por ejemplo, cada cierto periodo de tiempo realiza un barrido completo a todos los miembros de grupo para volver luego a su sujeto focal.

Una denominación particular de muestreo que podemos encontrar en la bibliografía sobre observación es el *muestreo ad libitum*. No ha sido incorporado a la clasificación de reglas de muestreo que acabamos de exponer, porque en realidad es la antítesis del muestreo. Esta expresión denomina la ausencia de norma que regule las sesiones de observación, en sus inicios, sus duraciones, los individuos observados y la forma de registro. No sigue más criterio que lo que al investigador le parece en cada momento más interesante. Con frecuencia esto es lo que caracteriza el registro que se efectúa en etapas previas a una investigación, en lo que en otros apartados hemos denominado «observaciones no sistematizadas» o «informales», y puede ser útil como una primera forma de contacto con las situaciones de trabajo. Sin embargo, no se puede considerar como una forma de muestreo orientada a la obtención de datos sistemáticos porque en sí mismo constituye una importante fuente de sesgos e imposibilita la replicabilidad de los mismos.

Determinadas ya las reglas de muestreo que registrarán nuestra investigación, en lo que se refiere a la importante tarea de recogida de datos, tendremos que decidir cuál será la forma de registro, que es el procedimiento que realmente transforma la conducta observada en datos analizables, o dicho de otra forma, es el proceso de cuantificación de la conducta.

11.4.2. Reglas de registro

Si tratamos de imaginarnos a una persona registrando algo, una escena que es probable que aparezca en nuestra mente es a un funcionario/a anotando información sobre ese algo para dejar constancia de su existencia (hay otra escena alternativa quizás más detectivesca y más sugerente pero no nos sirve para esta presentación). El registro observacional consiste exactamente en esa tarea: anotar las conductas para tener constancia de su ocurrencia, sus propiedades y su orden de aparición. Qué propiedades de la conducta registremos y de qué forma lo hagamos va a depender, una vez más, de los objetivos de la investigación y en cierta medida de razones de índole práctica, como veremos en el desarrollo de este apartado.

La acción de registrar la conducta observada puede tener lugar al mismo tiempo (o casi) que ocurre ésta, cuando se realiza observación *in vivo*. Esto es posible por la preparación previa de los observadores, por el diseño de hojas de registro muy prácticas o el uso de aparatos de registro que facilitan la tarea. Sin embargo, actualmente, dada la accesibilidad y la economía del vídeo, la mayoría de las investigaciones se apoyan en la grabación de las sesiones de observación para posteriormente proceder por medio del visionado de las cintas a la tarea de registro, o de codificación de las conductas, propiamente dicha.

Se habla de *codificación* en la medida en que el registro la mayoría de las veces se apoya en una serie de códigos (letras, números, trazos...) que representan a las categorías del sistema, de manera que el proceso de registro constituye al mismo tiempo un proceso de codificación de la conducta y así es denominado en algunos manuales sobre observación.

Volviendo a la aplicación de la tecnología a la observación, ésta puede ser utilizada para captar de forma permanente la información, ya sea a través del vídeo o de grabación de audio, o para facilitar la tarea de registro. A través de estos dispositivos y mediante la aplicación de programas informáticos específicos se puede mejorar la tarea de registro, ya que estos acumulan la información registrada y marcan los vídeos digitalizados en los puntos de registro efectuados, permitiendo la localización

y revisión sistemática de cualquiera de las conductas de estudio identificadas. Por otra parte, la utilización de microordenadores preparados hace viable la tarea de registro completo a tiempo real en situaciones de observación *in vivo*. Información actualizada sobre tecnología para la observación se puede encontrar en el libro de Thomson, Felce y Simons (2000). Sea de una forma u otra, la tecnología ha modificado sustancialmente el patrón de registro dominante, de manera que si hace 20 años la mayoría de los estudios observacionales presentaban datos de registro de muestreo de intervalos de tiempo (RAUT), actualmente constituyen la excepción, siendo claro el predominio del registro continuo (RAT). Ahora veremos por qué.

Registro activado por unidades de tiempo (RAUT)

El observador realiza el registro de las conductas indicadas por el sistema de categorías siguiendo una pauta determinada por periodos de tiempo (intervalos). Sólo se produce el registro de las conductas que están ocurriendo en momentos temporales específicos de la sesión (*muestreo puntual o instantáneo*) o que han ocurrido en los periodos de tiempo establecidos (*muestreo de intervalos*).

Existen varias modalidades de aplicación (véase Anguera, 1983 o Quera, 1991), pero todas ellas proporcionan una información incompleta del comportamiento de los sujetos de estudio y limitan considerablemente las posibilidades de análisis del mismo. Sus virtudes se limitan a cuestiones de índole práctica ya que hacen viable el registro con sistemas de categorías amplios en situaciones de observación *in vivo*, de ahí su gran presencia en los estudios de observación anteriores al desarrollo y abaratamiento de la tecnología informática. Actualmente son muy pocas las situaciones en las que se puede justificar la aplicación de este sistema de registro como forma de obtener los datos definitivos de una investigación (por ejemplo, porque no sea posible la grabación en vídeo), dada la pérdida de información y el riesgo de sesgo que conlleva.

Registro activado por transiciones (RAT)

Si se opta por esta regla de registro, el observador deberá anotar todas las ocurrencias de las categorías conductuales indicadas en el sistema de categorías que se esté aplicando, y el orden en el que ocurren. El orden de aparición de las conductas surge directamente del registro, en la medida en que el observador anota un código cada vez que se produce un cambio, una *transición* de una conducta a otra, de ahí su denominación (Bakeman y Gottman, 1989; Bakeman y Quera, 1996). Este tipo de regis-

tro permite el análisis de secuencias del comportamiento. El registro puede limitarse a las ocurrencias y transiciones de las conductas (registro de *eventos*) o incluir además información sobre la duración de las mismas (registro de *estados*) .

El registro activado por transiciones (RAT) correspondería a lo que otros autores identifican como *registro continuo*, por contraposición a los registros discontinuos o intermitentes en los que se han aplicado criterios temporales para determinar los momentos de registro.

11.5. MÉTRICA DE LA OBSERVACIÓN

En este apartado presentaremos una relación de posibles medidas conductuales que se pueden extraer de un registro observacional. Las medidas conductuales básicas o elementales son la *frecuencia* de aparición de una determinada categoría del sistema de categorías y la *duración* de la ocurrencia de dicha categoría, medidas ambas que se refieren a dos dimensiones diferentes y complementarias del comportamiento y a partir de las cuales se pueden obtener medidas derivadas o secundarias (véase tabla 11.1).

Dicho de otra forma, si en el análisis del registro utilizamos la unidad conductual o unidad de conducta, la *frecuencia* [$f(j)$] de cada categoría ($j = 1, 2, 3..., n$) del sistema aplicado se obtendrá por el recuento del número de veces que ocurre una determinada categoría en una sesión de observación. La frecuencia es una variable cuantitativa discreta que se mide en escala de razón.

La frecuencia tiene su significado asociado a las condiciones concretas de la investigación, y muy especialmente al tiempo de observación o de la sesión en la que se obtuvo. Para trabajar con registros procedentes de sesiones de distinta longitud o para comparar resultados de distintas investigaciones es necesario referirla al periodo de tiempo en el que se obtuvo. La *tasa de la categoría* [$v(j)$] se obtiene dividiendo su frecuencia por el tiempo total de observación (sesión o suma de sesiones) [T] y se puede considerar como una medida de la densidad temporal de la categoría de conducta. La *frecuencia relativa* o proporción relativa [$p(j)$] es el resultado de dividir la frecuencia de la categoría por el total de eventos registrados en ese periodo de observación (la suma de las frecuencias de todas las categorías del sistema), y es una forma de conocer el mayor o menor predominio de las categorías de conducta en determinadas condiciones (las de las sesiones de observación analizadas).

Si el flujo conductual se segmenta en unidades de tiempo (generalmente en segundos o fracciones) en las que se identifica una determinada

categoría, el recuento de estas unidades nos informará del tiempo ocupado por cada ocurrencia individual de la categoría, *duración de ocurrencia* [$d(j)$] y por la suma o acumulación de estas podremos calcular su duración. La *duración* [$D(j)$] de una categoría indica el número total de unidades de tiempo que ocupan todas las ocurrencias de la categoría durante el periodo de observación. La duración es una variable cuantitativa continua (admite valores intermedios) que se mide en escala de razón (tiene cero absoluto en su origen). Entre otros estadísticos, podemos calcular la *duración media* de una categoría [$\bar{d}(j)$], sencillamente dividiendo su duración por su frecuencia. Si queremos tener una medida comparable con otras investigaciones, calcularemos la *duración relativa o prevalencia* [$\pi(j)$], dividiendo la duración de una categoría por el tiempo total de observación.

Si el registro efectuado identifica no sólo las categorías (con o sin información sobre sus duraciones) sino también su orden de aparición podremos obtener medidas de microanálisis como son las frecuencias de transición. La *frecuencia de transición* entre dos categorías [$f(i,j)$] es el número de veces en el tiempo de observación que tras la ocurrencia de la primera (i) ha tenido lugar la segunda (j). A partir de estas pode-

TABLA 11.1
 Medidas conductuales de mayor uso en la investigación observacional

Medidas Primarias	Medidas Secundarias
Frecuencia: $f(j)$	Tasa: $v(j) = f(j)/T$ Frecuencia relativa: $p(j) = f(j)/\sum f(j)$
Duración: $D(j)$ $D(j) = \sum d(j)$	Duración media: $\bar{d}(j) = D(j)/f(j)$ Duración relativa o prevalencia: $\pi(j) = D(j)/T$
Frecuencia de transición: $f(i,j)$	Frecuencia relativa de transición: $p(j/i) = f(i,j)/f(i)$
Intensidad: $I(j)$	

mos obtener las *frecuencias relativas de transición* $[p(j/i)]$, dividiendo la frecuencia de transición $[f(i,j)]$ del par de categorías en estudio por la frecuencia de la categoría de conducta antecedente del par en cuestión $[f(i)]$.

La *intensidad* es una medida menos frecuente en los estudios observacionales ya que exige la aplicación de una escala ordinal que refleje los distintos grados de la presencia de una determinada conducta en un sujeto o de los distintos grados en los que puede manifestarse un determinado rasgo conductual y no todas las categorías conductuales admiten este tratamiento. Por ejemplo, las conductas agresivas podrían ser valoradas en una escala de intensidad que reflejara el grado de agresividad de las mismas, pero la conducta de «dar: proporcionar al otro un objeto deseado» no tiene rasgos fácilmente graduables en intensidad. Por otra parte la graduación de la intensidad por parte de un observador al juzgar una conducta tiene un componente de valoración subjetiva que aumenta los riesgos de sesgos y que exige un entrenamiento de los observadores más difícil que el necesario para el registro de ocurrencias de las conductas.

11.6. CONTROL DE CALIDAD DE LOS DATOS

La fiabilidad y la validez de los datos de observación son características fundamentales y exigibles en todo estudio realizado. Su comprobación garantiza la replicabilidad del estudio y la cientificidad de los conocimientos que aporta para la comprensión del fenómeno de interés. A través del examen de la fiabilidad de los datos podemos valorar el grado de precisión de la medida, independiente del criterio subjetivo del observador que los ha proporcionado. En cierta manera estamos comprobando que el sistema de categorías (el instrumento de medida) está definido y estructurado de manera que los datos obtenidos mediante su aplicación pueden ser independientes de la persona concreta que ejerza como observador.

Si la fiabilidad tiene que ver con la precisión de la medida, la validez es con el significado de la misma (véase capítulo 7). De esta forma, determinar la validez de los datos de un estudio de observación implica valorar si las medidas obtenidas por la aplicación de un determinado sistema de categorías, siguiendo unas determinadas reglas de muestreo y registro, constituyen buenos indicadores de la conducta de interés. La validez de los datos de observación está estrechamente relacionada con la relevancia de las categorías de observación seleccionadas y con la exhaustividad del sistema, que debe ser capaz de incluir de forma completa todos los aspectos necesarios para operativizar el constructo psicológico en estudio.

El conocimiento teórico previo y las comprobaciones empíricas de la adecuación del sistema de categorías para dar respuesta al problema de estudio se complementan en el proceso de juicio evaluativo que supone el análisis de la validez.

El estudio de la fiabilidad de los datos de observación se realiza calculando el índice de acuerdo de los registros proporcionados por dos observadores que han trabajado de forma independiente y es conocido como *fiabilidad interobservadores*. O bien a través del cálculo del índice de acuerdo de los registros proporcionados por un mismo observador que registra ciertas sesiones de observación en dos momentos diferentes (*fiabilidad intraobservador*).

11.6.1. Estimación de la fiabilidad

No existe una norma rígida sobre el procedimiento a seguir en el examen de la fiabilidad de los datos de un estudio observacional pero se pueden realizar algunas recomendaciones a partir de la experiencia acumulada de expertos investigadores. Resulta conveniente poder contar con dos observadores entrenados adecuadamente para poder confrontar sus registros sobre un mismo material y calcular el índice de acuerdo interobservadores. La presencia de dos observadores no significa necesariamente que vayan a repartirse el trabajo, lo más frecuente es que los datos que se lleguen a someter a los análisis estadísticos procedan de un único observador. Tampoco supone que el trabajo se duplique totalmente. En realidad no se duplica el registro de todas las sesiones de observación previstas o ya grabadas sino sólo un porcentaje de ellas (en torno al 30%).

Puede ser recomendable comenzar trabajando la *fiabilidad por consenso*, que supone el ajuste progresivo de los registros de los observadores mediante la aplicación del sistema de categorías de forma conjunta y negociada. Si uno de los observadores implicados en esta tarea de registro común, discutido cuando sea necesario, es el investigador, esta fase de comprobación inicial le dará garantías de que el otro observador registrará y codificará lo que se decidió que debía registrarse. Después deberían confrontarse los registros de los dos observadores sobre algunas sesiones más, pero en las que ya hubiesen trabajado de forma independiente y comprobar que se alcanza un nivel de acuerdo aceptable. Por último, parece que la aplicación de comprobaciones del nivel de acuerdo en algunas otras sesiones elegidas aleatoriamente contribuye a mantener el grado de precisión deseable en los registros del observador.

Decíamos un poco antes que la presencia de dos observadores no significa necesariamente que se repartan el trabajo, pero también es cier-

to que en algunas investigaciones, por sus características o por sus condiciones de realización, trabajan varios observadores que registran sesiones o aspectos distintos, aportando cada uno de ellos información complementaria. En estos casos se debe buscar la forma de duplicar algunos de los registros para poder calcular los índices del acuerdo existente entre ellos. En estas circunstancias la aplicación de estos índices no sólo es necesaria como forma de evaluación de la precisión de la medida sino como comprobación de la homogeneidad de los datos procedentes de distintos observadores pero que van a ser analizados de forma conjunta.

Los índices de acuerdo aplicables son muy diversos. Los más utilizados ya han sido explicados en el capítulo 6, en el estudio de la concordancia de los jueces que participan en el proceso de asignación de puntuaciones a los ítems de construcción de una prueba. Al igual que en la situación planteada en ese punto del capítulo 6 resultaba importante determinar hasta qué punto podría estar influyendo la subjetividad de un juez en la precisión de las puntuaciones asignadas a ese tipo de ítems, en la metodología observacional la información que nos proporcionan estos índices de acuerdo es también fundamental. Necesitamos saber hasta qué punto los datos obtenidos mediante el registro efectuado por un observador son reflejo de su criterio subjetivo o constituyen una medida precisa del comportamiento en estudio.

Uno de los índices de acuerdo de mayor aceptación y uso en metodología observacional es el índice Kappa, por diversas razones. Por su calidad métrica, ya que corrige el posible acuerdo debido al azar. Por su versatilidad: es aplicable tanto con datos obtenidos por registro activado por unidades de tiempo (muestreo de intervalos) como por registro activado por transiciones (registro continuo), sea este sólo registro de eventos o con información sobre las duraciones de las conductas. Y por su capacidad informativa: la matriz de datos necesaria para el cálculo del índice, por sí misma, aporta información sobre las categorías específicas que pueden estar siendo causa sistemática de desacuerdo.

En cualquier caso, dada la importancia del estudio de la fiabilidad de los datos y dado que los resultados pueden ser diferentes según el índice de acuerdo utilizado, es importante que el investigador informe del procedimiento utilizado para su cálculo, el número de sesiones utilizadas, el índice aplicado, el tipo de registro y los criterios de acuerdo o desacuerdo utilizados en la confrontación de los registros.

El observador no es la única fuente posible de variación, de introducción de error en el proceso de medición pero sí constituye una de las amenazas de error más importantes en la observación. Como se vio en el capítulo 6, otra fuente importante de error es la relativa al momento temporal en el que se realizan las observaciones. A continuación se pre-

sentan las principales fuentes de error en la observación y las formas de las que se dispone para controlarlas o mantenerlas en un nivel aceptable.

11.6.2. Fuentes de error y formas de control en la observación

Una fuente importante de sesgos o de error en un estudio observacional está en lo que se puede considerar como *fallos de procedimiento*, que se pueden prevenir y evitar. Estos pueden darse en cualquiera de las distintas fases del estudio observacional, pueden ser errores de decisión (como errores de muestreo o insuficiente definición de las categorías) o problemas concretos en la aplicación (como fallos técnicos en el funcionamiento de los aparatos utilizados, problemas de observabilidad de los sujetos focales o falta de preparación de los observadores). Este tipo de fallos puede y debe prevenirse realizando una cuidadosa planificación del estudio y prestando especial atención a la adecuación de las decisiones tomadas respecto a la naturaleza específica del problema de estudio, los objetivos e hipótesis planteados y las condiciones reales de viabilidad del mismo. Pero hay otras fuentes de error específicas que conviene conocer y anticipar para poder controlar.

El sujeto de estudio: la reactividad

Aunque pueda parecer una gran contradicción hablar de reactividad en estudios observacionales, cuando algunos autores definen este método precisamente por la obtención «no reactiva» de datos, esto es, sin intervención alguna que pueda suponer una influencia sobre el sujeto (Moreno, Martínez y Chacón, 2000), es necesario recordar que aún así existe este riesgo y que puede ser una fuente de error o de variación que afecte a la validez de los datos.

Tanto si estamos en una situación de observación participante como si es de observación externa, si los sujetos se saben observados, existe riesgo de *reactividad*. Esto supone, sencillamente, que el hecho de sentirse observados puede llevar a los sujetos a modificar su conducta, de forma consciente y voluntaria o de forma involuntaria, difiriendo de lo que hubiese sido su comportamiento espontáneo.

En la medida de lo posible, que variará de unos estudios a otros, se trata de minimizar los riesgos de reactividad. Como es evidente, la situación ideal es la observación de sujetos ingenuos (desconocen que están siendo observados) a través del uso de dispositivos ocultos, ya sea la cámara de vídeo, el magnetófono o el propio observador tras un

espejo unidireccional. En este punto conviene recordar la necesidad de seguir las normas éticas de la investigación que garantizan el respeto de los derechos de los participantes en la misma.

Ahora bien, son muchas las ocasiones en las que no se puede ocultar la existencia de un observador y/o su tarea. En estos casos se puede tratar de ser lo más discretos posibles, evitando al máximo la visibilidad del observador, limitando su movilidad y actuando con instrucciones claras de no intervenir. Si además hacemos que la presencia del observador en la situación de observación se produzca un número suficiente de veces antes de comenzar la recogida sistemática de los datos a analizar, se irá produciendo la *habituación* de los sujetos estudiados a la presencia del observador y, por lo tanto, esta tendrá cada vez menos efecto sobre su conducta.

Además de la visibilidad del observador, hay otros factores que pueden provocar interferencias específicas en el comportamiento de los sujetos y que conviene considerar. Determinadas cualidades del observador (edad, género, características físicas o de personalidad...) pueden ser las ideales, por que resulten más armónicas o más cercanas a lo habitual, según las características de los sujetos observados, mientras que otras pueden tener mayor impacto sobre ellos y provocar cambios en su conducta. Es cuestión de considerar la situación y saber elegir.

Por otra parte, qué razones se utilizan para justificar la observación y cómo se les comunica a los sujetos puede ser otro elemento de influencia, pero de nuevo, manejable por el investigador para minimizar su posible efecto negativo. Veamos un ejemplo. En una investigación sobre el desarrollo comunicativo preverbal, que realizamos con niños entre 8 y 12 meses de edad (Sarriá y Brioso, 1999), habíamos decidido grabar en vídeo situaciones de interacción libre de los niños con sus madres (sesiones de veinte minutos). En la justificación que se daba a las madres de los objetivos de la investigación y de la necesidad de contar con ellas, resaltábamos que el foco de interés era el niño, para poder ir viendo como progresaba en su capacidad de comunicación. Insistíamos en la idea de que ella era necesaria para que el niño se sintiera cómodo y seguro, pero que no iba a ser estudiada y que por supuesto el uso de esas cintas de vídeo se limitaba exclusivamente a su codificación por parte de las dos investigadoras. Nos preocupaba conseguir que las madres se relajaran y se centraran en sus juegos familiares con sus hijos y que no estuvieran pendientes o preocupadas por su propia imagen. Se trataba de evitar cualquier tensión anómala en la situación de interacción. La posible reactividad de los niños se trató de evitar a través de la habituación a la presencia de la cámara en su entorno familiar.

El observador

El observador realiza un papel fundamental en un estudio observacional, puede llegar a ser considerado como el instrumento de la observación. Sus posibles errores en la aplicación del sistema de categorías, por la inadecuada interpretación de las mismas, o sus errores en el registro, por falta de atención a determinados elementos, inciden directamente en los datos del estudio (véase Behar y Riba, 1993, para una sistematización más completa de los sesgos del observador). El entrenamiento de los observadores en la aplicación del sistema de categorías específico del estudio es la principal forma de control de estas amenazas de error. El entrenamiento de un observador supone el conocimiento comprensivo del sistema de categorías, su dominio y la práctica directa con grabaciones de vídeo en las situaciones lo más parecidas posible a los problemas y situaciones reales que tendrá que codificar para la investigación.

Estas sesiones de entrenamiento deben durar hasta alcanzar un grado de fiabilidad por consenso que el investigador considere aceptable. Pero es recomendable también, tal como señalábamos al principio de este epígrafe, hacer estudios periódicos de la fiabilidad sobre los registros realizados por los dos observadores de forma independiente y en momentos más avanzados de la investigación, para asegurar la precisión de los datos y para controlar otras posibles fuentes de error como son el efecto deriva y las expectativas del observador.

La *deriva del observador* se puede dar en la medida en que su propia experiencia en la aplicación del sistema le puede llevar a ir desarrollando interpretaciones y adaptaciones idiosincráticas de las definiciones originales de las categorías, desviándose de forma sistemática de ellas en el registro de los datos (Kazdin, 1977). Si en el examen de la fiabilidad, en un momento avanzado de la investigación, se constata una caída en la fiabilidad de los datos, el investigador debe intervenir para analizar la causa de la misma y corregirla. Esta corrección a veces puede suponer retomar el proceso de preparación del observador y aclarar cuantos puntos sean necesarios de la definición de las categorías.

Las *expectativas del observador* acerca de lo que debería ocurrir o aparecer en la situación estudiada puede llevarle a identificar categorías en conductas que no se ajustan correctamente a ellas o a no percibir otras conductas que debería registrar según el sistema planteado. Esta posible fuente de error está relacionada con el grado de conocimiento teórico previo que tenga el observador sobre el fenómeno de estudio y con su conocimiento de las hipótesis de trabajo de la investigación. Además de los controles periódicos de fiabilidad para descubrir las posibles desviaciones del sistema que se pudieran estar produciendo, una estrategia de

control específica para este problema consiste en la utilización de observadores entrenados pero que desconozcan el objetivo y las hipótesis del estudio (*procedimiento ciego*).

El sistema de categorías

A veces es el propio sistema de categorías o el sistema de codificación lo que provoca los errores de los observadores. Problemas de definición de las categorías, una amplitud o complejidad excesiva del sistema o la aplicación de códigos arbitrarios, demasiado alejados del significado de las categorías, pueden ser causa de errores en el registro. La revisión realista del sistema teniendo en cuenta la tarea de registro y la búsqueda de recursos que faciliten el manejo de los códigos contribuirán a evitar estos problemas. Por otra parte, el estudio de la fiabilidad en el proceso de entrenamiento de los observadores nos puede informar de la existencia de estos riesgos y de si es necesario seguir depurando y mejorando el sistema de categorías y de codificación antes de proceder al registro sistemático de los datos.

11.7. DISEÑO Y ANÁLISIS DE DATOS

El análisis de los datos de observación se puede realizar desde distintos modelos y técnicas estadísticas. El tipo de análisis a aplicar depende en primer lugar de los objetivos e hipótesis de la investigación y en segundo lugar, y normalmente como consecuencia de lo primero, de las características métricas y posibilidades informativas de los datos registrados (sólo frecuencia, con datos de tiempo o duraciones, con orden...). Hemos incluido el término *diseño* en la denominación de este epígrafe porque, si el tipo de análisis de datos a aplicar está en relación con los objetivos e hipótesis, la obtención de los datos adecuados depende en buena medida de las decisiones tomadas en la planificación de la investigación, como la inclusión o no de determinadas variables como variables de estudio (por ejemplo, la variable *tiempo*), el tipo de muestreo y el tipo de registro. Y precisamente el plan de trabajo específico en el que se determinan las condiciones en las que se realizará la investigación se denomina *diseño*.

Para tener una visión general de las distintas posibilidades de análisis de datos, utilizaremos los tres grandes criterios propuestos por Quera (1993), que no son excluyentes sino que combinados entre sí abarcan una tipología (véase tabla 11.2). Estos criterios, si bien no agotan todas las posibilidades de especificación de los diseños, definen la mayoría de los estudios realizados con el método observacional.

TABLA 11.2
 Criterios de clasificación del análisis de datos en los estudios observacionales
 (Quera, 2001)

Según las medidas	Según la variable tiempo	Según los objetivos
Macroanálisis	Sincrónico: diseño transversal	Exploratorio Confirmatorio
	Diacrónico: diseño longitudinal	Exploratorio Confirmatorio
Microanálisis	Sincrónico: análisis de sincronía	Exploratorio Confirmatorio
	Diacrónico: análisis de secuencias	Exploratorio Confirmatorio

1. Según los objetivos del análisis: *análisis exploratorio* vs *análisis confirmatorio*. Algunas investigaciones, por la originalidad del tema tratado o el estado inicial de su desarrollo, no parten con hipótesis de trabajo que indiquen qué relaciones específicas debemos buscar y el análisis irá explorando todos los datos hasta encontrar presencias o relaciones significativas. El *análisis exploratorio* puede ser muy útil en las primeras etapas de una investigación pero proporciona menos seguridad que los análisis confirmatorios en los que toda la investigación está orientada de forma coherente a la contrastación de unas hipótesis o predicciones. En el análisis exploratorio el riesgo de encontrar relaciones espúreas (no reflejan un efecto real sino un fenómeno azaroso) es mayor que en el análisis confirmatorio. La existencia de hipótesis en el planteamiento de la investigación permite realizar directamente los análisis pertinentes para la comprobación de las mismas y obtener resultados que confirmen o refuten dichas hipótesis; este es el caso del *análisis confirmatorio*. Las hipótesis identifican las variables relevantes para el fenómeno de estudio y sus relaciones. Dado

que estamos hablando de una investigación realizada con el método observacional, conviene recordar que estas relaciones que predicen las hipótesis no se pueden plantear en términos de causalidad. La no intervención por parte del investigador que caracteriza el método observacional implica que no existe una manipulación directa de una variable que se introduzca como antecedente (causa) de otra (cuyos cambios indican el efecto) y, por tanto, no tenemos garantías de una relación de causalidad unidireccional. La interpretación de los resultados obtenidos puede ser muy rica y concluyente, pero debe ser coherente con estas limitaciones en su alcance explicativo.

2. Según la inclusión de la variable tiempo: *análisis sincrónico vs análisis diacrónico*. Se habla de *análisis sincrónico* cuando se describen y relacionan medidas que han sido tomadas simultáneamente, es decir, se estudian ambas en su ocurrencia en un mismo punto temporal. El concepto de punto temporal es muy relativo, en algunas investigaciones puede referirse a una fracción de segundo y en otras está reflejando un día, una semana, un mes o un año determinado. En el *análisis diacrónico*, sin embargo, se relacionan medidas tomadas en diferentes puntos temporales.
3. Según las medidas conductuales utilizadas: *macroanálisis vs microanálisis*.

Cuando la descripción y el estudio de las relaciones se realiza a través de medidas globales como las frecuencias, las duraciones o sus derivadas hablamos de *macroanálisis*. Si esta relación de medidas globales se realiza con medidas tomadas o procedentes de un mismo momento temporal (análisis sincrónico) se suele denominar diseño o *análisis transversal*. Si estudiamos la relación de medidas globales referidas a puntos o momentos temporales diferentes (análisis diacrónico) entonces suele recibir la denominación de diseño o *análisis longitudinal*. Las técnicas estadísticas aplicables para este tipo de análisis de datos son diversas. Desde los sencillos coeficientes de correlación bivariados hasta los bastante más complejos análisis multivariados para datos categóricos como el análisis de conglomerados o el análisis factorial de correspondencias múltiples, por citar algunos de los más utilizados (el paquete estadístico SPSS proporciona una buena gama de técnicas con amplias posibilidades).

En el *microanálisis* se estudian las relaciones entre las *unidades* de conducta que a modo de eslabones de una cadena describen el comportamiento del individuo o del grupo. Se pretende estudiar las

relaciones de contingencia temporal entre las conductas, tratando de desvelar las reglas que regulan su dinámica interna. La forma más extendida de microanálisis es el análisis secuencial o análisis de secuencias. El análisis de secuencias del comportamiento sólo es posible si se ha realizado un registro continuo, un registro activado por transiciones (RAT). El análisis secuencial tiene en cuenta la variable *tiempo* (es un análisis diacrónico) en la medida en que pretende descubrir como cambian las probabilidades de que ocurran ciertas conductas en función de que previamente hayan ocurrido otras, y encontrar patrones estadísticamente significativos que revelen sus regularidades. Por ejemplo, en la investigación de Gaviria (1994), de haberse planteado como un estudio de microanálisis de las relaciones de dominancia (habiendo adaptado el sistema de categorías a tal efecto y realizando un registro que informara exhaustivamente del orden de aparición de las conductas) podríamos tratar de detectar cuál es la conducta que con mayor probabilidad sigue (como respuesta de otro niño) a una propuesta («decisión») del líder del grupo, y cuál es la más probable en caso de que la «decisión» fuese emitida por un niño de menor posición en la escala de dominancia del grupo. El análisis de secuencias no es una técnica estadística concreta, sino que refiere la posible aplicación a los datos categóricos secuenciales de alguna de las diversas técnicas existentes con tal fin.

Una revisión bastante completa de estas técnicas se encuentra en el libro de Gottman y Roy (1990), y la lógica subyacente está muy bien explicada en el libro de Bakeman y Gottman (1989).

Buena parte de estas técnicas de análisis de secuencias utilizan medidas microanalíticas muy intuitivas como las frecuencias de transición y se basan en tablas de contingencia bidimensionales o multidimensionales.

El programa informático SDIS-GSEQ de Bakeman y Quera (1996) es una potente y flexible herramienta para la aplicación informatizada de estas técnicas. El programa informático que incluye el libro está en formato MS-DOS pero una vez instalado se puede actualizar con la versión para Windows por internet a través de la página www.ub.es/comporta/sg.htm.

En este último caso, podríamos aplicar las técnicas basadas en los modelos loglineal.

El programa ILOG de Bakeman y Robinson (1994) realiza específicamente análisis loglineal y el paquete de programas SPSS incluye módulos con estas técnicas.

En ocasiones el microanálisis se plantea desde una perspectiva sincrónica, porque lo que interesa conocer es la probabilidad de que ciertas conductas se den al mismo tiempo que otras, es decir, qué relaciones existen entre ellas en el mismo punto temporal. En este caso se denomina *análisis de sincronía o de coocurrencias*. El análisis de sincronía se realiza aplicando las mismas técnicas que las disponibles para el análisis de secuencias, pero especificando la coincidencia en el momento temporal como condición de estudio. Para captar de forma intuitiva el sentido de esta forma de análisis convendría que recordásemos que en un estudio observacional podemos registrar la conducta aplicando diversos sistemas (o mejor dicho subsistemas) de categorías, que a su vez corresponden a diversos niveles de análisis o a diversos sujetos en interacción, y que permiten identificar la ocurrencia en un mismo momento temporal de varias conductas o de diversos aspectos de la misma.

Para cerrar este apartado, un último comentario: macro y microanálisis pueden definir investigaciones completas en sí mismas, pero también se pueden plantear como estrategias complementarias, donde cada una aporta un tipo de información particular que en conjunto permite una mejor comprensión del problema de estudio.

11.8. PUNTOS BÁSICOS

- La observación científica puede proporcionar conocimiento objetivo, válido y fiable.
- La observación sistemática puede ser la forma (técnica) de recogida de datos de una investigación planteada con un diseño experimental, cuasi experimental o *ex post facto*.
- El método observacional se caracteriza por la no intervención del investigador y la no restricción de la conducta espontánea del sujeto de estudio.

- En el planteamiento de una investigación observacional se pueden manejar distintos grados de estructuración de la situación de observación y distintos grados de participación del observador.
- La operativización de las variables conductuales de una investigación observacional se realiza a través de la categorización.
- Un sistema de categorías debe ser completo (exhaustivo), ajustado a los objetivos del estudio (válido) y compuesto por categorías mutuamente excluyentes, para cada nivel de análisis.
- En la metodología observacional el muestreo implica la selección de las unidades muestrales (sujetos, grupos, díadas, etc.) y de las sesiones de observación (muestreo intersesional), así como de los sujetos concretos y del momento en particular en el que hay que observar dentro de cada sesión (muestreo intrasiesional).
- Las reglas de registro determinan la forma de anotación de las conductas y sus propiedades y permitirán la obtención de distintos tipos de datos que a su vez condicionan las posibilidades de análisis de los mismos.
- Las medidas conductuales básicas o elementales son la frecuencia de aparición de una determinada categoría del sistema de categorías y la duración de la ocurrencia de dicha categoría.
- El control de la calidad de los datos obtenidos mediante la observación es un requisito necesario para asegurar la precisión de las medidas utilizadas y la validez del estudio. En metodología observacional el estudio de la fiabilidad de los datos se realiza a través del cálculo del índice de acuerdo o concordancia de diferentes registros de una misma situación.
- Las principales fuentes de error en una investigación observacional proceden del sujeto objeto de observación y del propio observador. Estas pueden ser previstas y deben ser controladas o, al menos, mantenidas en un nivel aceptable.
- El análisis de los datos de una investigación observacional se realizará de acuerdo con los objetivos del estudio y se apoyará en diferentes técnicas estadísticas según como se haya implicado la variable *tiempo* (sincrónico vs diacrónico) y las medidas utilizadas (macroanálisis o microanálisis).

11.9. EJERCICIOS

11.9.1. Relacione mediante flechas los conceptos de las dos columnas:

Exhaustividad y mutua exclusividad	Sujetos observados
Grado de molecularidad	Métrica de la observación
No intervención del observador	Sistema de categorías
Riesgo de reactividad	Categoría
Riesgo de subjetividad	Observación externa y naturalista
Relevancia de las categorías	Observación participante
Acuerdo interobservadores	Análisis de datos
Frecuencia, tasa, duración ...	Validez
Exploratorio / confirmatorio	Fiabilidad

11.9.2. Haga una lista doble de las posibles fuentes de error de la observación y los recursos de control de las mismas.

11.9.3. Lea detenidamente esta breve descripción de una investigación ficticia y responda a las preguntas, eligiendo una sola alternativa en cada una de ellas.

Un equipo de psicólogos evolutivos está interesado en conocer el proceso de desarrollo de las expresiones faciales en los niños. Para ello los investigadores decidieron grabar en vídeo a 20 díadas madre-hijo en situaciones de interacción en el hogar, en cuyo transcurso las madres tenían que proponer a los niños una serie de «juegos infantiles» potencialmente elicitadores de las siete emociones básicas. Las sesiones de observación tenían media hora de duración y se realizaban siempre al terminar la merienda de los niños. Las grabaciones se realizaron mensualmente: comenzaron cuando los bebés tenían dos meses de edad y se dieron por terminadas cuando cumplían los dos años.

Los investigadores diseñaron un sistema de categorías referidas al niño, exhaustivo y mutuamente excluyente, en el que las categorías estaban definidas en función de los grupos musculares implicados en las expresiones faciales de cada emoción. Los resultados obtenidos ponen de manifiesto, entre otras cuestiones, que en los niños menores de un año ya se observan las expresiones faciales que corresponden a las emociones adultas de felicidad, miedo, tristeza, sorpresa, asco y desprecio, aunque las emociones positivas son las más frecuentes. El proceso de desarrollo observado confirma la hipótesis de partida de la mayor precocidad de las emociones básicas frente a las emociones complejas. El índice de fiabilidad que aportan los investigadores en su informe es el porcentaje de acuerdo siendo su resultado el 60%.

11.9.3.1. El tipo de observación sistemática que se realiza en este estudio es:

- a) Naturalista
- b) Semiestructurada
- c) Estructurada

11.9.3.2. El muestreo utilizado ha sido:

- a) Por selección fija
- b) De sujeto focal
- c) *a* y *b* son correctas

11.9.3.3. Las categorías de observación podrían considerarse:

- a) Moleculares
- b) Molares
- c) Ambiguas

11.9.3.4. El tipo de medida utilizado es:

- a) Duración
- b) Frecuencias
- c) Prevalencia

11.9.3.5. El índice de fiabilidad aplicado:

- a) No corrige el efecto de coincidencia por azar
- b) Es uno de los más potentes y recomendables
- c) Tiende a dar resultados de acuerdo muy bajos

11.9.3.6. El diseño planteado para el estudio tiene un carácter:

- a) Sincrónico
- b) Diacrónico.
- c) Microanálisis

11.9.4. Vuelva a la descripción de la investigación de Elena Gaviria sobre las relaciones de intercambio entre preescolares, utilizada como ejemplo en el texto.

11.9.4.1. Valore las categorías en términos de su molaridad-molecularidad.

11.9.4.2. Identifique las reglas de muestreo aplicadas

11.9.4.3. Etiquete esta investigación según los tres ejes o criterios de diseño y análisis.

11.9.5. Estime la fiabilidad de las medidas conductuales obtenidas en un estudio observacional en el que dos observadores independientes registran las conductas de interés con un sistema de seis categorías (VO, SE, MI, TO, PA y VE).

OBSERVADOR 1	OBSERVADOR 2
VO	VO
SE	SE
MI	MI
TO	PA
MI	MI
PA	VE
SE	SE
PA	TO
VO	VO
MI	VE
PA	PA
MI	MI
VE	VE

11.10. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

11.10.1. Exhaustividad y mutua exclusividad → Sistema de categorías. Grado de molecularidad → Categorías. No intervención del observador → Observación externa y naturalista. Riesgo de reactividad → Sujetos observados. Riesgo de subjetividad → Observación participante. Relevancia de las categorías → Validez. Acuerdo interobservadores → Fiabilidad. Frecuencia, tasa, duración ... → Métrica de la observación. Exploratorio/confirmatorio → Análisis de datos.

11.10.2.

Fuentes de error de la observación.

Formas de control

— Fallos de procedimiento:

- Adecuación de las decisiones de categorización, muestreo y registro a la naturaleza y objetivos del estudio
- Análisis realista de las condiciones y viabilidad del estudio.
- Revisión y control del funcionamiento de los aparatos

— Reactividad del sujeto observado:

- Evitar la visibilidad del observador
- La habituación
- Elegir observador con características personales armónicas con la situación
- Comunicación inteligente de los propósitos de la investigación a los participantes

— Faltas de atención del observador:

- Entrenamiento de los observadores

— Efecto deriva del observador:

- Estudio periódico de la fiabilidad

— Expectativas del observador:

- Procedimiento ciego

— Sistema de categorías:

- Comprobación de la claridad de definición de las categorías

— Sistema de codificación:

- Revisión del sistema ajustado para el registro

11.10.3. El tipo de observación sistemática que se realiza en este estudio es: *b)* Observación semiestructurada. **El muestreo utilizado ha sido:** *c)* *a* y *b* son correctas. **Las categorías de observación podrían considerarse:** *a)* Moleculares. **El tipo de medida utilizado es:** *b)* Frecuencias. **El índice de fiabilidad aplicado:** *a)* No corrige el efecto de coincidencia por azar. **El diseño planteado para el estudio tiene un carácter:** *b)* Diacrónico.

La introducción de una serie de «juegos infantiles» elicitadores de las emociones por parte de la madre a indicación del investigador es una

forma menor de intervención pero que se aleja discretamente de la observación naturalista y le otorga el carácter de semiestructurada. Las reglas de muestreo utilizadas son la selección fija para el muestreo intersesional (los investigadores determinan que sea siempre después de la merienda, probablemente para «asegurar» el estado de vigilia y satisfacción del niño, y la constancia de unas sesiones a otras a lo largo de los 22 meses); como regla de muestreo intrasesional se puede especificar el muestreo de sujeto focal porque se estudia la conducta de los niños como individuos, ya que aunque se graba la situación de interacción, el registro se limita al niño. La molecularidad de las categorías es evidente en la medida en que se basan en datos claramente objetivables y tan básicos como el movimiento de grupos musculares implicados en cada expresión emocional facial. Por la información que se transmite en el apartado de resultados el único tipo de datos del que tenemos constancia y seguridad de que se haya utilizado es el de la frecuencia de aparición de las distintas categorías. El coeficiente de fiabilidad aplicado, el porcentaje de acuerdo, suele dar más bien valores altos porque no corrige el posible efecto de coincidencia por azar y precisamente por eso no es un índice muy recomendable. En este caso se plantea como un diseño longitudinal (análisis diacrónico) en la medida en que tiene como objetivo el estudio del *proceso de desarrollo*, para lo cual se realizan sesiones mensuales durante 22 meses y los resultados informan de los cambios observados.

11.10.4.1. Las categorías son: molares.

Veamos una de las categorías del sistema para justificar esta valoración de molaridad. «Amenazas (AM): amenaza verbal o física (mirada fija, brazo en alto, amago de patada...) de daño físico o de arrebatar un objeto, sin llegar realmente al contacto. El receptor no responde en los mismos términos....». La mirada fija, el amago de patada..., se interpretan como manifestaciones conductuales de una misma intención, la de amedrentar al contrario. Este aglutinamiento de manifestaciones conductuales distintas bajo un mismo rótulo, por lo que indican del sujeto que las emite, supone un grado de molaridad alto y exige del observador cierto grado de inferencia a partir del análisis del contexto inmediato de la conducta.

11.10.4.2. Las reglas de muestreo utilizadas: muestreo intersesional por selección fija y muestreo intrasesional de sujeto focal.

Se ha utilizado un criterio de selección fija para el muestreo intersesional: las sesiones de observación se realizaban siempre durante los recreos escolares, lo cual refleja la aplicación de un criterio fijo de momento temporal y actividad que determina el inicio y el final de las sesiones de observación.

En cada recreo se seguía de manera sostenida a un niño durante diez minutos, para luego pasar a atender a otro y así hasta los cinco que daba tiempo por sesión, procurando compensar unas sesiones con otras en cuanto a los niños que están siendo seguidos, lo cual responde al patrón de muestreo focal como forma de estudio de un grupo en el muestreo intrasésional.

11.10.4.3. Según los objetivos: análisis confirmatorio. **Según las medidas conductuales utilizadas:** macroanálisis. **Según la inclusión de la variable tiempo:** análisis sincrónico (estudio transversal).

Podemos considerar que se trata de un análisis confirmatorio ya que el estudio se realiza para someter a contrastación empírica hipótesis de trabajo, y los análisis de datos van orientados a su comprobación. También estaremos fácilmente de acuerdo en que en este estudio se realiza un macroanálisis ya que trabaja con frecuencias de comportamientos, proporciones relativas y algunas transformaciones de estas medidas a través de índices específicos que informan de la proporción dado/recibido y su correlación con su grado de participación en el grupo, pero no se entra a analizar la dinámica de la interacción a través de la búsqueda de patrones de comportamiento en el análisis de secuencias de conductas interactivas (microanálisis). Sin embargo es posible que en el tercer punto haya descubierto que tenemos criterios distintos. Si ha sido así, es previsible pensar que lo que le ha llevado al error de considerar este estudio como diacrónico es la prolongación en el tiempo de la tarea de recogida de datos (los recreos escolares desde enero a junio). Es cierto que es mucho tiempo pero, tal como se plantea el estudio y se analizan los datos, esta prolongación no tiene como objetivo el seguimiento del proceso o el estudio del cambio (no se han formulado hipótesis al respecto) sino la acumulación de suficiente tiempo de observación para cada uno de los niños que componían el grupo social estudiado: este es el dato crítico. Los datos son analizados en un conjunto global en el que no se incluye la variable *tiempo* como criterio de organización de los mismos, se ha realizado por tanto, un análisis sincrónico de los mismos.

11.10.5. Para estimar la fiabilidad de las medidas conductuales obtenidas se calculará una medida del acuerdo entre ambos observadores, en particular, el índice Kappa (ecuación 6.12):

$$\kappa = \frac{F_0 - F_e}{N - F_e}$$

Para calcular los valores F_0 y F_e se construye una tabla de doble entrada con los datos de los dos observadores en las filas y las columnas, respectivamente:

		OBSERVADOR 2						
		MI	PA	SE	TO	VO	VE	
OBSERVADOR 1	MI	3	0	0	0	0	1	4
	PA	0	1	0	1	0	1	3
	SE	0	0	2	0	0	0	2
	TO	0	1	0	0	0	0	1
	VO	0	0	0	0	2	0	2
	VE	0	0	0	0	0	1	1
		3	2	2	1	2	3	13

$$Fo = 3 + 1 + 2 + 0 + 2 + 1 = 9$$

$$Fe = (4 \times 3/13) + (3 \times 2/13) + (2 \times 2/13) + (1 \times 1/13) + (2 \times 2/13) + (1 \times 3/13) = 2,31$$

$$\kappa = (9 - 2,31)/(13 - 2,31) = 0,63$$

11.11. BIBLIOGRAFÍA BÁSICA RECOMENDADA

ANGUERA, M. T. (1990). Metodología observacional. En J. Arnau, M. T. Anguera y J. Gómez. *Metodología de la investigación en Ciencias del Comportamiento* (pp. 123-236). Murcia: Universidad de Murcia.

En este capítulo, extenso para ser solo un capítulo, la autora, pionera y primera línea de la metodología observacional en este país, revisa los aspectos conceptuales de la metodología observacional y cuestiones de procedimiento, exponiendo su fundamentado criterio personal en los aspectos más controvertidos del tema.

ANGUERA, M. T. (1988). *Observación en la escuela*. Barcelona: Graó.

Este libro ofrece también estas dos facetas del análisis de la metodología observacional pero haciendo especial énfasis en su papel en el entorno educativo.

BAKEMAN, R. y GOTTMAN, J. M. (1989). *Observación de la interacción: Introducción al análisis secuencial*. Madrid: Morata (versión original: *Observing interaction: An introduction to sequential analysis*. Cambridge: Cambridge University Press, 1986).

El libro, de lectura fácil, entra de lleno en la lógica del análisis de secuencias de conducta como forma de verdadero análisis de la interacción, pero lo hace deteniéndose a tratar con detalle aspectos de interés para cualquier uso

de la observación sistemática, como son la elaboración de un sistema de categorías (esquema de codificación, según su terminología), el registro, la evaluación de la concordancia entre observadores o la representación de datos de observación, entre otros. La vinculación de los autores a Departamentos de Psicología del Desarrollo hace que estos contenidos sean dominantes en los ejemplos y situaciones prácticas planteadas en el texto.

11.12. LECTURAS SUGERIDAS

ANGUERA, M. T. (Coord.) (1999). *Observación en la escuela: Aplicaciones*. Barcelona: Edicions de la Universitat de Barcelona.

ANGUERA, M. T. (Coord.) (1999). *Observación de conducta interactiva en contextos naturales: Aplicaciones*. Barcelona: Edicions de la Universitat de Barcelona.

Ambos libros forman parte de una serie coordinada por M^a Teresa Anguera en la que se recopilan informes de investigaciones observacionales españolas, en distintos ámbitos de aplicación. Además de estos dos, recomendados por su cercanía de contenido al ámbito profesional de la Psicopedagogía, se pueden encontrar volúmenes de aplicaciones en Psicología Clínica, Psicología del Deporte y en Etología. Son libros heterogéneos y sus capítulos son desiguales pero su lectura es muy enriquecedora y sugerente, ya que permite acceder no sólo a los objetivos y los resultados de las investigaciones sino también a la descripción detallada de los sistemas de categorías aplicados y a los criterios de los investigadores en sus decisiones de planificación de la investigación, lo que es poco frecuente encontrar en otro tipo de publicaciones.

MARTIN, P. y BATESON, P. (1991). *La medición del comportamiento*. Madrid: Alianza Universidad.

Este es un libro introductorio por excelencia. Por la sencillez y claridad de lenguaje que utiliza. Por su selección de temas críticos para cualquier investigador del comportamiento, en especial para aquel que se haya planteado una investigación que implique el uso de la observación. Y por el sentido práctico de los autores que, además de tratar los conceptos fundamentales que subyacen a la cuantificación de la conducta, proporcionan recursos operativos con ejemplos muy útiles. Se puede leer en cualquier parte y en cualquier momento.

DE WAAL, F. (1993). *La política de los chimpancés: Sexo y poder en antropoides*. Madrid: Alianza Universidad.

Este libro explica el proceso de una investigación observacional en Etología, y consigue transmitir con una claridad palpable la estrecha relación y el proceso dinámico que lleva de las conjeturas teóricas a los datos y viceversa, a través del estudio de las amistades, enemistades y coaliciones que regulan la vida social de un grupo de chimpancés. Su lectura es muy formativa pero además es divertida y apasionante, tal como corresponde a un tema de eterna actualidad como es descubrir la importancia de los vínculos y las alianzas para acceder al poder o mantenerse en él.

11.13. MATERIAL COMPLEMENTARIO

- Ejemplo de aplicación de la observación como técnica de recogida de datos.
- Ejemplo de investigación con situación de observación estructurada.
- Sobre la borrosidad de las categorías.
- Ejemplo de sistema de codificación multidimensional.

METODOLOGÍA CUALITATIVA

Concepción Gabriel Esteban

12.1. INTRODUCCIÓN

Las personas mayores aman las cifras. Cuando les habláis de un nuevo amigo, no os interrogan jamás sobre lo esencial.

Jamás os dicen: «¿Cómo es el timbre de su voz?, ¿cuáles son los juegos que prefiere?, ¿colecciona mariposas?» En cambio, os preguntan: «¿qué edad tiene?, ¿cuántos hermanos tiene?, ¿cuánto pesa?, ¿cuánto gana su padre?» Sólo entonces creen conocerlo. Si decís a las personas mayores: «He visto una hermosa casa de ladrillos rojos con geranios en las ventanas y palomas en el tejado...», no acertarán a imaginarse la casa. Es necesario decirles: «He visto una casa de cien mil francos.» Entonces exclaman: «¡Qué hermosa es!».

En *El Principito*, A. de Saint Exupéry muestra de esta forma tan sencilla y hermosa dos formas de aproximarse a una misma realidad. Ni mejor ni peor una que otra, únicamente diferentes. La realidad se mantiene invariable se mire de una u otra forma: el amigo sigue siendo el mismo se sepa de él su edad o bien se conozca su timbre de voz, al igual que la casa no varía. Lo que se modifica en función de la mirada que se dirija es lo que se conoce de la realidad. Si sólo se mira la *cifra* se llegará a conocer la cantidad de francos invertidos, «desestimando» la información de que es roja o que tiene geranios... Exupéry presenta la mirada de los adultos y de los niños como dos perspectivas, dos posturas ante la realidad enfrentadas, casi excluyentes. Pero ¿qué ocurre con la investigación social?

A la realidad social le ocurre algo semejante a lo que sucede con la descripción de la casa en *El Principito*. Toda realidad social, cualquier fenómeno u objeto social puede ser mirado desde distintas posiciones, y desde cada una de ellas será posible alcanzar a ver facetas diferentes de un mismo objeto. La mirada que se dirija al objeto social determina, como no podía ser de otra forma, el tipo de conocimiento que podamos

obtener. Dependiendo de qué es lo que se quiere conocer, a qué cara de la realidad desea aproximarse, se fijará el «lugar» desde el que mirar. Por ejemplo, si se quiere conocer la penetración de la práctica del turismo verde en nuestro país o cuál es el nivel de apoyo entre la población al Plan Hidrológico Nacional, entonces interesa la *cifra*, mirar la realidad desde un enfoque cuantitativo. Pero si lo que interesa es conocer por qué el turismo verde es en los últimos años una práctica que está de moda, o bien saber qué motivaciones o razones están tras la resistencia al Plan Hidrológico Nacional, interesa el *discurso*. Un discurso al que se llega desde una mirada cualitativa.

En los temas anteriores se ha realizado un recorrido por distintas técnicas que trabajan alrededor de la *cifra* (la metodología de encuesta, la experimental y cuasiexperimental y, en menor medida, la metodología observacional). Este tema justamente va a centrarse en conocer como es esta mirada cualitativa en investigación social, qué ofrece respecto a un enfoque cuantitativo, qué puede aportar al investigador social y de forma también muy breve dar algunos apuntes prácticos sobre como desarrollar desde un enfoque cualitativo investigación social. Una aportación que si hubiera que resumir sintéticamente podría ser la posibilidad de llegar directamente al *habla* de los sujetos, un habla no sólo construida en lo social sino expresión del contexto social del sujeto.

12.2. DOS MIRADAS COMPLEMENTARIAS: EL ENFOQUE CUALITATIVO Y EL CUANTITATIVO

La particularidad de la mirada cualitativa en investigación social es su potencialidad para llegar al discurso de los sujetos. La encuesta no puede atrapar el discurso espontáneo y libre de los sujetos, capta o muestra finalmente expresiones —más que discursos— estandarizadas. Recoge de forma limitada y cerrada lo que se piensa sobre el fenómeno estudiado, en tanto que demanda la adhesión a categorías de respuesta prefijadas. El cuestionario estructurado permite *reducir* la realidad a cifras. Las técnicas cuantitativas transforman los hechos en registros que pueden ser tratados estadísticamente de forma distributiva.

La posibilidad de interpretación de los datos producidos en la encuesta está basada en la univocidad de las categorías de respuestas a las que debe adherirse el encuestado/a. Resulta imposible analizar correctamente unos datos si las categorías propuestas son ambiguas (véase el capítulo 3). Es preciso que el sentido de las respuestas sea necesariamente único, que no dejen espacio a la *interpretación*, a la existencia de diversos sentidos en la adhesión a cada categoría concreta planteada. La limita-

ción del método cuantitativo surge justamente de lo que le hace posible: reducir a un código circunstancias únicas de cada uno de los sujetos encuestados. Una reducción que da lugar a una reificación de los fenómenos sociales. Por su parte, el enfoque cualitativo se aproxima a la opinión del sujeto sin delimitarla, es él quien organiza y jerarquiza su percepción, su opinión acerca de la realidad social.

En un cuestionario no se recoge tanto una opinión como la adhesión —según la cercanía/lejanía de identificación personal— de un sujeto al estado de opinión dominante. En este sentido, es habitual encontrarse con la idea de que el enfoque cuantitativo ofrece una fotografía de la realidad. Una fotografía fija, en la que no existe explicación o interpretación de las distintas «poses» o posiciones que en ella toman los actores sociales sino descripción.

El enfoque cuantitativo se acerca especialmente al espacio de las intenciones. Domina ante todo la racionalidad. En la encuesta los ítems y las categorías de respuesta que se ofrecen configuran un sistema de opiniones-expresiones más o menos estereotipadas. Así, el sujeto encuestado se adhiere «individualmente» a una idea-idea-opinión estereotipada que *cree* es la más aceptada en su medio. La investigación cualitativa permite acercarse sin *a priori*s a la ideología dominante en un medio social al hacerse expresa en el propio discurso del sujeto.

La encuesta, las técnicas cuantitativas permiten llegar a saber cómo se distribuyen los fenómenos, conocer las frecuencias, cifrar los hechos sociales. Mientras que desde el enfoque cualitativo se alcanza la estructura que existe tras los fenómenos, tras los procesos sociales. La investigación cualitativa permite conocer la percepción que los propios sujetos tienen de la realidad social, y como a partir de ésta organizan su relación con su entorno.

La aproximación cualitativa posibilita acercarse a la aprehensión que el propio sujeto hace de los fenómenos sociales, de cómo los interpreta. A través de las técnicas cualitativas se alcanza a conocer las motivaciones, las determinaciones sociales que están tras el comportamiento de los sujetos.

En demasiadas ocasiones en investigación social estas dos formas de mirar la realidad —el enfoque cualitativo y el enfoque cuantitativo— se han presentado como miradas enfrentadas, excluyentes, como la mirada de los *adultos* y la de los *niños*. Desde este capítulo lo que se pretende no es mostrar el enfoque cualitativo enfrentado al cuantitativo sino mostrar la complementariedad de ambos. No existe exclusión o enfrentamiento sino la adecuación de unas u otras técnicas a los interrogantes planteados. Igual que un fontanero utiliza distintas herramientas en función de la acción que precise realizar, el investigador social deberá tomar la

herramienta más adecuada para los objetivos de la investigación, en función de la faceta o dimensión que quiera conocer. Asumiendo que con su elección no será posible dar respuesta a todas las preguntas que puedan plantearse en la diversidad de niveles en los que se articula el objeto investigado.

Sería pretencioso por parte del investigador social pensar que su acercamiento al objeto de estudio será completo. Al término de una investigación siempre quedan cuestiones por resolver, y afortunadamente la propia investigación abre nuevas incógnitas. Un acercamiento únicamente cualitativo o cuantitativo ofrecerá una respuesta todavía más parcial. El uso complementario de estas técnicas permite aproximarse al ideal de *conocimiento completo*. Se contaría con la cifra explicada por el discurso, o si se prefiere el discurso con el apoyo de la cifra.

En las páginas que siguen se recorren brevemente tres técnicas de investigación cualitativa. Dos de ellas muy conocidas y utilizadas —la entrevista en profundidad y el grupo de discusión— y una tercera más novedosa y desconocida —el grupo triangular—. Cada una de ellas, aun compartiendo su aproximación directa al discurso del sujeto, cuenta con características particulares en función, fundamentalmente, del marco desde el que se genera *su* discurso. Diferentes espacios discursivos que las convierten en prácticas complementarias entre sí. Mientras que la entrevista en profundidad permite llegar al plano de lo concreto, de lo específico, el grupo de discusión se inscribe en un marco más general y estructural de la percepción de la realidad social por parte de los sujetos, situándose el grupo triangular en una posición intermedia.

Además de detenernos en algunas consideraciones teóricas —mínimas— sobre cada una de las técnicas, se recogen también algunas pautas que pueden servir al estudiante para poner en práctica estas técnicas de investigación social.

12.3. LA ENTREVISTA EN PROFUNDIDAD

12.3.1. Caracterización general

La entrevista en profundidad o entrevista abierta es una situación de interacción entre entrevistador y entrevistado/a, y en este sentido es una conversación entre ambos.

De las técnicas de investigación cualitativa, la entrevista es la de una puesta en marcha más sencilla. Su sencillo desarrollo y la gran cantidad de información que puede ofrecer —en caso de realizarla adecuadamen-

te— la convierten en una técnica muy eficaz (y rentable en términos económicos).

Dentro de la investigación social desde un enfoque cualitativo, la entrevista en profundidad puede considerarse la técnica pionera. Su sencillez lleva a que pueda incluso aparecer como algo no premeditado, una situación de entrevista puede ser *simplemente* escuchar, interesarse por la situación de determinados sujetos. Así, no es extraño que los precursores del trabajo social vieran en la entrevista en profundidad, el estudio de casos, una eficaz fuente de información, no ya sólo para estudiar o analizar casos particulares sino para poder hacer extrapolaciones, llegar a conocer lo que de común, lo que de *social* existía en situaciones concretas de individuos.

En la actualidad la versatilidad y buenos resultados de la entrevista en profundidad hacen de ella una técnica bastante utilizada tanto en la investigación más pura y estrictamente sociológica (temas de educación, consumo de drogas, colectivos marginados...) como en investigación de mercados (consumidores de productos...).

Tal vez, al escuchar «entrevista en profundidad» lo primero en lo que se piensa es en la práctica de entrevista más «conocida» o visible, que es la entrevista periodística. Ciertamente ambas prácticas comparten parte de la puesta en escena, pero no los objetivos o intereses. En la entrevista periodística se busca, se persiguen interlocutores con nombre y apellidos, interesa la particularidad del *personaje*. El interlocutor lo es por su individualidad, se trata de conocer su opinión, su posición personal ante los temas planteados, o su propia y personal experiencia. En cambio, en la entrevista en profundidad, y ésta es la particularidad de la entrevista como práctica de investigación social, no se busca la individualidad (el caso atípico, lo extraño...), la particularidad del discurso del interlocutor sino que interesa un interlocutor *arquetípico* de una situación, interesa lo que de social existe en la posición discursiva del entrevistado. De esta forma, esta técnica es adecuada para analizar el discurso arquetípico que puede existir en distintas posiciones sociales.

La entrevista en profundidad toma como interlocutores a sujetos anónimos. Cuando se realiza una entrevista en profundidad a un alto directivo de una empresa, su opinión, su posición no interesa o es buscada por ser quien es, por su nombre, sino que interesa por su condición de ser alto directivo. El interlocutor de una entrevista en profundidad se convierte en actor de la investigación en tanto que es una *persona típica* dentro de su grupo de referencia o del colectivo objeto de la investigación.

En investigación social a través de la entrevista, de la expresión individual, expuesta por el sujeto desde el yo, se trata de alcanzar lo social, lo

que su discurso tiene de común con el de otros sujetos en su misma posición social. Sus situaciones, motivaciones, comportamientos... percibidos por el sujeto como particulares, propios, están determinados socialmente. Toda expresión individual no es sino la expresión de una individualidad socializada.

12.3.2. **Ámbito de aplicación**

El espacio desde el que el partícipe en la entrevista enuncia su discurso, YO, hace que esta técnica sea especialmente adecuada para estudios de «casos desviados» o extremos, en los que la percepción de carácter único de los sujetos se supone mayor, que en situaciones medias y/o mayoritariamente compartidas. La adecuación y utilidad de la entrevista abierta no se agota ni mucho menos en su uso en investigaciones próximas al estudio de casos extremos...

Las características de la entrevista en profundidad la convierten en una buena práctica para llegar a un nivel de información detallado sobre objetos concretos. En la entrevista en profundidad, la percepción de hecho particular que está presente en el sujeto facilita al investigador preguntar o profundizar en el plano de lo concreto, llegar al detalle del objeto investigado. Nivel de profundización que no es posible alcanzar en el grupo de discusión al mantenerse su discurso en un plano más general. La posibilidad de acceder a lo específico hace de la entrevista una técnica bastante utilizada en investigación de mercado. Por ejemplo, y poniendo en práctica la complementariedad de las técnicas cualitativas, en un estudio sobre la imagen de una revista un posible diseño de investigación podría ser la combinación de reuniones de grupo y entrevistas en profundidad. A partir de las reuniones de grupo se podría conocer la imagen que de la revista tienen sus lectores, sobre qué factores o elementos se articula dicha imagen... y de forma general cuáles son las secciones de mayor y menor interés. Por su parte, la realización de entrevistas a lectores muy fieles de la revista (lectores arquetipo) facilitará detenerse en aspectos concretos de la revista, secciones, contenidos, en la maquetación... La entrevista ofrece la posibilidad de indagar por aspectos que en un grupo de discusión no generarían discurso a su alrededor, o que caso de plantearlos convertirían el grupo en una entrevista grupal. Cuanto más concreto o limitado sea el objeto de estudio más adecuado sería utilizar la entrevista en profundidad antes que otras técnicas cualitativas.

Igualmente es interesante recurrir a la técnica de la entrevista en profundidad cuando el grupo o colectivo social al que se dirige el estudio aparece fragmentado o muy disperso, lo que no hace sino reforzar la posible percepción de los sujetos de casos particulares, de situaciones

propias... En general, la entrevista en profundidad aparece como una técnica adecuada en casos en los que se prevé que los interlocutores se fijarán antes en lo que supuestamente les diferencia que en aquello que les une.

La atención en lo concreto que permite la entrevista hace de ésta una técnica útil para conseguir información acerca de comportamientos. En las dinámicas de las entrevistas suelen ser preguntas enriquecedoras para la investigación las que se interesan por conocer el comportamiento, la respuesta dada por el sujeto a una situación concreta. En la entrevista no sólo se pregunta por opiniones sino también por acciones, por aquello que se ha hecho, que se ha puesto en práctica o por lo que no se ha hecho. Interesa conocer las motivaciones que están tras estos comportamientos. En la entrevista se obtienen respuestas concretas a actuaciones, a tomas de decisión.

En el discurso construido de la entrevista converge o se hace presente lo objetivo y lo subjetivo (Alonso, 1998); lo que se hace y lo que se cree hacer (y también por qué se cree que se hace). La entrevista, por tanto, es útil para obtener información de carácter pragmático sobre las prácticas individuales y a partir de estas experiencias «individuales» extraer lo común, lo que de social existe en ellas.

La versatilidad de la entrevista frente a otras técnicas no debe llevar a su sobreutilización, a un uso inadecuado, sino que debe utilizarse cuando sea la técnica más adecuada, y no sólo la más fácil de realizar. Cada técnica permite acercarse de la forma más adecuada a un tipo de información, a un nivel discursivo. El criterio que debe dominar a la hora de elegir una técnica u otra es la pertinencia de este nivel discursivo con los objetivos de la investigación.

A modo de resumen, la entrevista en profundidad es una técnica adecuada para:

- el estudio de casos extremos;
- el estudio sobre comportamientos, hábitos...
- abordar el estudio de colectivos fragmentados en los que difícilmente se puede llegar a generar un discurso grupal;
- dar respuesta a aspectos muy concretos y específicos.

12.3.3. El investigador y la dinámica de las entrevistas

De las técnicas de investigación cualitativa la entrevista en profundidad es en la que lógicamente el entrevistador-coordinador está más pre-

sente. Es un tú a tú. Ciertamente la entrevista en profundidad es una técnica sencilla, pero se trata de algo más que de seguir fielmente un guión de preguntas. El entrevistador tiene en la dinámica de la entrevista un papel más activo que el de simple lector de enunciados.

Para la realización de entrevistas es difícil ofrecer reglas o pautas fijas como si se tratara de un manual. Tal vez, la única regla a cumplir sería la de *adaptarse* a la persona entrevistada. En el escenario creado en cada entrevista debe ponerse en juego una estrategia adecuada a la figura entrevistada, de forma que la entrevista pueda ser lo más provechosa posible. De esta forma, al entrevistador se le demanda sensibilidad e intuición para captar rápidamente cuál es la posición en la que se sitúa su interlocutor; al tiempo que debe comunicar y generar empatía con la persona a entrevistar; generar un marco de confianza y credibilidad para que la interacción se desarrolle en los términos más equilibrados y adecuados.

En la entrevista, como en toda interacción social, desde sus prolegómenos se establece un juego de poderes, que se hace patente en pequeños gestos o detalles: el tiempo de espera, el intercambio de tarjetas de visita (primer posicionamiento de los futuros interlocutores), el lugar donde se realiza la entrevista... Por ejemplo, entre directivos de empresas, profesionales, etc, no es extraño que antes de iniciar la entrevista «comuniquen» el escaso tiempo del que disponen, poniendo así un límite antes de comenzar —límite que la mayoría de las veces el interlocutor es el primero en olvidar—. El sujeto entrevistado intenta situarse respecto al investigador demandante de información, en una posición de poder; se sabe poseedor del saber y pretende o busca ser quién domine la situación. Como es lógico, en investigación social el interlocutor no siempre se autoposicionará en una situación de poder sino que, por el contrario, habrá quien no perciba o entienda el valor que sus comentarios, su opinión... pueden tener para el entrevistador que es percibido como el poder. Esto es lo que tiende a ocurrir en colectivos como el de amas de casa, ancianos, grupos pseudomarginales..., grupos en general sin voz en lo social. Estos casos tienden a situarse en una posición de dependencia hacia el *poder* del investigador, buscando casi su aprobación. El entrevistador debe saber manejar estos juegos de poder, no situarse en una posición de subordinación frente a «expertos» formales, pero tampoco en la de control absoluto y total en el caso de los colectivos no centrales, sino ofrecer y fomentar un espacio intermedio, tendente a la igualdad.

En el intento de lograr un espacio de comunicación es importante que el entrevistador sepa adaptar su lenguaje a su interlocutor; que se muestre sencillo en los enunciados o comentarios o que muestre un suficiente

nivel de conocimientos cuando el entrevistado sea un experto, de tal forma que éste reconozca su posición. Para ello el entrevistador debe aportar más que la rígida y fiel lectura de enunciados. Debe establecer una relación dinámica, en la que las dos partes participen de forma activa e interesada. De poco sirve a los objetivos de una investigación un entrevistado desmotivado y resistente al diálogo, resistente a entablar una conversación, o un sujeto que diga únicamente aquello que cree interesa o desea escuchar quien está frente a él.

El entrevistador debe ser un oyente activo y también un activo interlocutor. En el diálogo que debe establecerse se produce un proceso de retroalimentación entre investigador y entrevistado. El primero debe ser un interlocutor empático capaz de mantener un diálogo interesante para el entrevistado, que éste se sienta valorado, que perciba que su voz, sus palabras tienen interés para el investigador, que está aportando algo a la investigación. El discurso construido es ante todo enunciado por el entrevistado, pero en él también deben considerarse las intervenciones del entrevistador. En la interacción que se establece entre los dos sujetos, el investigador es un agente activo, un sujeto dinámico que está en proceso de descubrimiento relativo del objeto investigado. La posición dinámica que el investigador desarrolla durante la entrevista en profundidad es fundamental, es una característica particular de esta técnica cualitativa. Posición dinámica del entrevistador que no debe nunca ocupar o suplantar el protagonismo que tiene la palabra del entrevistado. El encuestado es el que debe organizar, a partir del estímulo inicial, la conversación alrededor del objeto de la investigación. En la posición activa del entrevistador no se trata de que este analice y menos que conduzca el habla del entrevistado, sino que reformule lo dicho por éste, siendo un nuevo impulso, de tal forma que se avance en la conversación.

Dentro del proceso de descubrimiento en el que se encuentra el entrevistador tiene cabida la «improvisación», salirse del guión e intentar abrir nuevos caminos en función de lo dicho por el entrevistado. Una apertura y entrada de nuevas consideraciones y dimensiones sobre el objeto de estudio que no es posible realizar en la encuesta cuantitativa, en la que el cuestionario establece unos límites invariables y a los que el entrevistado debe atenerse. En la entrevista abierta seguir un orden riguroso de preguntas no haría sino desprestigiar las posibles nuevas vías o dimensiones no consideradas con anterioridad que puedan surgir al calor de la conversación. Además de desmotivar al entrevistado, ya que parecería que el investigador no tiene en cuenta o no considera su organización u ordenación, la reflexión que realiza sobre el tema planteado. Es decir, que en esos casos sería fácil que se percibiera al investigador como un sujeto que trata de «imponer» su poder en la situación de comunicación que es la entrevista.

El entrevistador debe estar atento, tener la suficiente sensibilidad para localizar las intervenciones más interesantes para la investigación y detener al entrevistado en ellas. Así mismo debe contar con habilidad para introducir en la entrevista las preguntas que tengan un sentido más adecuado para cada situación que vaya surgiendo. Puede decirse que una buena entrevista es aquella en la que no existe ruptura, que los temas objeto de la investigación surgen de forma hilvanada, en continuidad. Una continuidad organizada-ordenada por el entrevistado y no por el entrevistador.

No debe confundirse el hecho de que es adecuado que la entrevista se desarrolle sin una sucesión rígidamente ordenada de preguntas con que no exista, por parte del entrevistador, un marco mínimo de referencia o en el que éste delimita las intervenciones del interlocutor. Este marco mínimo sería el guión temático. Un guión que vendrá determinado por los objetivos de la investigación. No habría por tanto un guión cerrado de preguntas sino una serie de temas por los que el entrevistado debería pasar.

En este recorrido no existiría una ordenación estricta sino que vendría dada por el propio sujeto entrevistado y los impulsos que le devuelve el investigador. En ocasiones el entrevistado se sorprende ante la inexistencia de un guión cerrado de preguntas y que la entrevista se desarrolle como una conversación que se articula y transcurre en función de su propia ordenación.

Las intervenciones del entrevistador se dirigen sobre todo a solicitar una mayor exhaustividad al entrevistado, subrayar sus palabras, contrastar algo de lo dicho, reflexionar sobre el contenido del discurso del encuestado... En ningún caso estas intervenciones deben dirigir o sesgar las respuestas del entrevistado, y aun menos contener la respuesta. Se debe evitar plantear las preguntas en términos cerrados, lo que no haría sino fomentar respuestas cerradas, sin discurso. Deben plantearse abiertas, de tal forma que invite a la explicación por parte del entrevistado, a la ampliación o matización de lo ya apuntado.

12.3.4. Sobre el número de entrevistas a realizar

La aparente sencillez de la entrevista (entrevistado-entrevistador) no debe llevar a infravalorar su potencial informativo. El poner en cuestión o minimizar su capacidad informativa puede llevar a proponer un número exagerado de entrevistas, lo que no significaría necesariamente un incremento de información. Como ocurre con el resto de las técnicas cualitativas, el número ideal de entrevistas a realizar estará en función del

nivel de concreción de los objetivos planteados y la diversidad social que existe alrededor del objeto a estudiar. Cuanta mayor diversidad o fragmentación exista mayor será el número de entrevistas abiertas a realizar. La *regla* para fijar el número concreto de entrevistas será el principio de *saturación* que está presente en las técnicas cualitativas. Es decir, realizar el suficiente número de entrevistas que permita *cubrir* las distintas posiciones discursivas que pueden existir respecto al objeto investigado. En el diseño de las entrevistas a realizar no se trata solo de fijar un número, sino también de determinar el perfil del interlocutor, es decir, *construir* el arquetipo dominante o presente en el colectivo o grupo social al que se dirige la investigación. Esta construcción del arquetipo no es sino señalar las categorías que el investigador cree relevantes para el objeto de estudio.

El diseño de las entrevistas —y del resto de técnicas cualitativas— supone unas hipótesis de partida por parte del investigador. En este sentido una de las ventajas de las técnicas cualitativas frente a la metodología de encuestas es la posibilidad que existe durante el trabajo de campo de introducir modificaciones en la propuesta inicial, en función de que se «confirman» o no las hipótesis de partida. Así, si surge a partir de la realización de las entrevistas o de los grupos, ya sean de discusión o triangulares, alguna variable o aspecto que no hubiera sido considerado en el diseño inicial es posible incorporarlo *a posteriori*.

En cuanto al número de entrevistas a realizar, en definitiva se trata de fijar las entrevistas que se crean oportunas para cada una de las categorías relevantes o consideradas en la investigación. Así, plantear una entrevista por categoría sería incorrecto, en tanto que impide discriminar lo que de particular o atípico tiene el discurso del entrevistado y aprehender lo social, lo arquetípico (arquetipo que se confirmaría por la repetición). En el extremo contrario, un planteamiento excesivo de entrevistas no haría sino alargar y encarecer la investigación sin aportar un incremento informativo significativo. De forma muy general, tres entrevistas para cada una de las categorías consideradas tiende a aparecer como un número ajustado, con cuatro entrevistas es fácil caer en una repetición ya conocida. Ciertamente la *repetición* es lo que permite extraer de las entrevistas la componente social que existe en el comportamiento o en la posición del sujeto, pero cuando esta repetición es ya redundante y está claro el discurso, la realización de más entrevistas no resulta práctico al no aportar o significar un *plus* informativo. En este sentido no es extraño que en investigación social no se realice la totalidad de la propuesta sino que se pare antes, una vez que en las entrevistas —o en los grupos de discusión o triangulares— se producen discursos redundantes.

La llegada a una saturación discursiva antes de finalizar el trabajo de campo podría estar indicando, como primer aspecto a analizar, una

menor diversidad de posiciones de lo que se preveía, es decir, que alrededor del objeto investigado existe una cierta homogeneidad discursiva, o si se prefiere un cierto consenso en el que las posibles categorías que hubieran podido ser consideradas (estatus, edad, género, consumo...) no determinan una posición discursiva diferenciada.

Vinculada a esta idea de la diversidad, de la existencia de distintas posiciones ante el objeto investigado y también asociado al número de entrevistas planteado, nos encontramos con que la cantidad, la riqueza de información que aportan las primeras entrevistas —ocurriría lo mismo en el caso de los grupos— es mucho mayor que la que ofrecen las últimas. Mientras que con las primeras se *descubre* el objeto estudiado, los aspectos más centrales, las relaciones que se establecen..., a medida que se desarrolla el trabajo de campo, las entrevistas tomarían una función de *confirmación*, teniendo un menor aporte informativo, al comenzar a escucharse un discurso ya conocido. Para evitar un posible «cansancio» que impida aprovechar la riqueza de cada entrevista, es positivo que en investigaciones con un alto número de entrevistas intervengan distintos entrevistadores, de esta forma el *descubrimiento* de información es en cierta forma alargado, desplazando la posibilidad de escuchar lo «ya conocido».

12.3.5. La logística de la entrevista

De las técnicas cualitativas utilizadas en investigación social, la entrevista en profundidad es la más sencilla de poner en práctica. Al contrario de lo que sucede con los grupos de discusión o con los triangulares, en los que el participante debe adaptarse al lugar y hora propuesta para su realización, en el caso de la entrevista el entrevistador puede adaptarse a las posibles demandas o necesidades que la persona entrevistada tenga en este sentido. A la hora de la aceptación por parte del entrevistador de la propuesta de tiempo y lugar en el que se desarrollará la entrevista, el aspecto a preservar será la posibilidad de contar con un espacio tranquilo en el que poder desarrollar de forma correcta y sin interrupción la entrevista.

En los momentos previos a la celebración de la entrevista, y de cualquier otra técnica de investigación cualitativa, es fundamental la comprobación del correcto funcionamiento de los sistemas de grabación que se van a utilizar. En el caso de la celebración de grupos, ya sean triangulares o de discusión, se recomienda utilizar un doble sistema de grabación (dos grabadoras, video y audio) de tal forma que se asegure la grabación. En la entrevista en profundidad la presencia de dos grabadoras puede incomodar a la persona entrevistada, por lo que una es suficiente.

En cuanto a la duración de las entrevistas es muy variable, dependerá del interlocutor, del tema investigado, de la presentación o no de material... El tiempo medio suele estar alrededor de 30-40 minutos.

12.3.6. El análisis de la entrevista

El punto de partida, el soporte a partir del cual realizar el análisis del discurso generado en la entrevista suele ser su transcripción literal, al igual que en el caso del grupo triangular y el de discusión. La transcripción permite analizar con detalle lo dicho en la entrevista, volver a reconstruir su dinámica. En el acercamiento a los discursos, la guía del recorrido deben ser lógicamente los objetivos de la investigación.

En esta fase del análisis es en la que el investigador se hace realmente presente, su mirada, su sensibilidad es la que posibilitará finalmente el acercamiento a las posiciones discursivas que puedan existir. Por ello, es difícil dar reglas para analizar, todo lo más, mínimas pautas, puntos o aspectos a los que hay que prestar atención. Aunque tal vez suene a tópico el mejor aprendizaje es la experiencia. A medida que se realicen más entrevistas y análisis, el investigador irá aumentando su sensibilidad analítica, aprenderá a mirar y discriminar lo importante de lo superfluo o secundario.

En el comienzo de este apartado dedicado a la entrevista en profundidad decíamos que el sujeto entrevistado interesa en tanto que es una individualidad socializada, que es representativo de un grupo social. Participa en la entrevista como arquetipo del perfil *tipo* de los sujetos de un colectivo. En el momento del análisis este punto debe estar siempre presente.

En el análisis del discurso de la entrevista el investigador debe discriminar lo particular (atípico) que existe en la relación del sujeto con el tema investigado de lo que en dicha relación hay de social; lo que responde no a la particularidad del sujeto sino lo que está determinado por su posición social. Desde las situaciones descritas por el interlocutor enunciadas de forma dominante desde el YO, se trata de filtrar, casi cribar lo que de común existe en su discurso con el de otros que comparten una misma situación social. En los discursos creados en cada una de las entrevistas realizadas surgen con claridad *coincidencias* en la relación con el objeto de estudio de interlocutores que habían expresado, descrito dicha relación como algo «particular». El surgimiento de la reiteración, de la repetición es lo que confirma al investigador en su análisis. Estas posiciones, motivaciones, actitudes... repetidas que se encuentran entre los discursos son los puntos sobre los que debe articularse y desarrollar-

se el análisis. El investigador debe *extraer* estos elementos sociales, para poder ofrecer finalmente una visión de la relación de los sujetos del colectivo analizado con el objeto de estudio.

El investigador se fijará en las expresiones, en las asociaciones que el entrevistado establece alrededor del tema de la investigación. Se detendrá en el análisis o percepción que el propio interlocutor tiene de su relación con el objeto investigado.

Durante la dinámica de las entrevistas —y también en el resto de técnicas cualitativas— es frecuente que surjan espontáneamente el relato de anécdotas, de experiencias personales..., que sirven para ejemplificar o apoyar lo dicho. Es positivo que el propio entrevistador fomente o estimule este tipo de relato. En dicho relato el interlocutor está de alguna forma jerarquizando, ordenando su percepción sobre el tema estudiado, lo que ayuda al investigador a situar al entrevistado en un marco discursivo. En el análisis no deben subestimarse estos relatos, al contrario se les debe prestar atención ya que pueden ayudar al investigador a clarificar la posición discursiva del sujeto.

12.4. EL GRUPO DE DISCUSIÓN

12.4.1. Caracterización general

El grupo de discusión o la reunión de grupo es una de las técnicas de investigación cualitativa más utilizadas en la actualidad en investigación social, y de forma muy especial en investigación de mercado. Fue justamente en este ámbito donde comenzó a utilizarse en la década de los 50, para pasar posteriormente al ámbito de la investigación social. Antes de conocer con mayor detalle qué es un grupo de discusión, apuntar que su puesta en escena consiste en una reunión de 7 o 8 personas (algunos investigadores incluso prefieren 9 participantes) más la persona encargada de la coordinación de la reunión, de una duración aproximada de 1h 30m-2h, en la que los asistentes hablan de un tema.

El grupo de discusión parte de la idea o del supuesto de que los asistentes a él, en su participación no sólo se representan a sí mismos, sino que son representantes preconscientes de los distintos grupos sociales a los que pertenecen. Es decir, actúan como representantes de los roles sociales con los que participan en la sociedad y reflejan o expresan el discurso dominante en su posición social. Se parte del supuesto de la existencia de un discurso dominante, correspondiente o asociado a cada posición social. Esta *estabilidad discursiva* fundamenta el grupo de discusión como práctica de investigación social.

Los sujetos, en tanto que están en una sociedad, comparten y se identifican con categorías sociales que determinarán su comportamiento. Un comportamiento que se vive y experimenta desde la «naturalidad», sin que exista reflexión sobre él, y sobre el que se conforma «el sentido común», o la idea de «lo normal». Con el grupo de discusión lo que se pretende es que los participantes en él, a partir del impulso que les ofrece el coordinador de la reunión, generen o construyan un discurso en el que se reproduzca-refleje su posición ante el objeto investigado. Una posición sobre la que los propios participantes en la reunión posiblemente no hayan reflexionado como sujetos sociales. La reflexión o análisis sobre las determinaciones sociales de sus motivaciones, actitudes... es labor del investigador.

En el discurso generado en los grupos los participantes expresan, muestran su contexto desde su «normalidad» y es esta normalidad la que interesa recoger.

El grupo de discusión es un *artificio* puesto en marcha en una investigación social, dispuesto para explicar o conocer la forma en la que los sujetos-los grupos sociales construyen y dan sentido a los fenómenos sociales que les rodean. El grupo de discusión permite observar cómo es la recepción y construcción de los discursos ideológicos que están latentes, que están en la base del comportamiento de los sujetos. La gran ventaja del grupo de discusión es que permite acercarse o conocer las motivaciones que están en el trasfondo del comportamiento, más que proporcionar conocimiento sobre los comportamientos en sí, para lo que resulta más adecuada la entrevista en profundidad. A través del discurso que se genera en el grupo, el investigador tiene la posibilidad de aproximarse a través de su propio decir o habla, a la opinión y percepción que del tema investigado existe en el grupo social de referencia.

Si en el caso de la entrevista en profundidad, el discurso se enuncia predominantemente desde el yo, la posición dominante en el discurso grupal es el *nosotros* social. El grupo muestra una percepción compartida de la realidad. Percepción situada en el plano de lo general, de lo estructural, tendiendo a la vez a alejarse de lo puramente referencial, de lo específico. La inscripción del discurso del grupo en el plano de lo general determina el tipo de investigación, o más correctamente de objetivos, para los que esta técnica resulta adecuada.

12.4.2. Ámbito de aplicación

El grupo de discusión aparece como una técnica especialmente útil para analizar las ideologías dominantes, la forma de pensar, las actitu-

des... con las que se identifican (y a partir de las cuales actúan) los sujetos de los distintos colectivos sociales. El grupo de discusión posibilita conocer la percepción que un grupo social tiene sobre el objeto investigado, y como en función de dicha percepción interactúa con él. De forma tal vez demasiado reduccionista, el discurso grupal informa de cómo «se cree» que es la realidad, y no «sobre la realidad». El comportamiento de los sujetos no responde a la realidad sino a *como creen los sujetos que es dicha realidad*.

El hecho de que el grupo de discusión genere un discurso abierto y espontáneo hace de esta técnica una magnífica vía para conocer las ideologías, las opiniones existentes sobre los más variados temas sociales, políticos... Saber cuál es la interpretación que los ciudadanos hacen de su realidad cotidiana, de todo aquello que de una u otra forma está presente en su día a día y a partir de la cual actuar. En un grupo de discusión, tal y como se apuntaba anteriormente, no se busca ni se analiza si la percepción que los sujetos tienen de la realidad es «correcta». El grupo de discusión posibilita aproximarse a la interpretación que el sujeto hace de la realidad, y sobre la que articula su propia relación con su entorno. Por ejemplo, en el caso de la actitud de la población española ante la inmigración, «poco» importa que los datos estadísticos muestren que los puestos ocupados por los trabajadores extranjeros son en su mayoría empleos no cubiertos por españoles, si buena parte de la sociedad percibe (o cree) que se trata de puestos sí queridos por nacionales.

El discurso grupal se inscribe, por tanto, en el espacio de lo simbólico, en un plano que permite conocer o comprender las motivaciones que están tras los comportamientos y/o actitudes de los sujetos. Este espacio discursivo hace que el grupo de discusión sea una técnica adecuada para estudiar, por ejemplo, las representaciones sociales que pueden existir alrededor de los más diversos fenómenos sociales. Representaciones sociales a partir de las cuales los sujetos organizan sus comportamientos, construyen sus opiniones...

De forma muy básica y sintética el grupo de discusión aparece como una técnica adecuada cuando los objetivos de la investigación se dirigen a conocer la imagen, la percepción, el posicionamiento... que un determinado grupo social muestra o tiene sobre un objeto social. Los grupos de discusión construyen un marco explicativo estructural, es decir, permiten conocer la estructura, las determinaciones sociales que están tras el comportamiento de los sujetos. Si la entrevista en profundidad es adecuada para conocer los comportamientos, los hábitos... el grupo de discusión permite llegar a conocer y explicar las razones que están tras estos comportamientos. Es posible explicar (o cuando menos comprender mejor) la respuesta del sujeto, contextualizándola socialmente. El

plano explicativo en el que se inscribe el grupo de discusión convierte a esta técnica en fuente de información para los temas más variados, desde los objetos de consumo más cotidiano hasta cuestiones políticas.

La capacidad explicativa que tiene el discurso generado en los grupos de discusión permite conocer a fondo el tema investigado, la relación o vinculación que mantiene con él cada uno de los colectivos sociales a los que se dirige la investigación. El conocimiento de las motivaciones, de las determinaciones o razones que están tras el comportamiento o forma de pensar del sujeto permite construir estrategias de actuación para intentar conseguir unos resultados, un cambio en las respuestas de los sujetos. Esta aplicabilidad práctica hace del grupo de discusión una herramienta básica en investigación de mercados —no en vano ese fue el ámbito en el que surgió—. La comunicación publicitaria es un buen ejemplo. Si se conoce la imagen, las expectativas... que los consumidores de un determinado producto tienen de éste, resultará más fácil crear un mensaje publicitario que llegue de forma eficaz a su público objetivo. En el mismo ámbito publicitario el grupo de discusión es una técnica apropiada para conocer la «recepción» del mensaje (postest publicitarios) o en general conocer como se ha percibido cualquier tipo de iniciativa. Mientras que en el caso publicitario una encuesta estadística ofrecerá información de la penetración o de la notoriedad de las campañas publicitarias, el enfoque cualitativo, el grupo de discusión permite aproximarse al mensaje percibido, a la interpretación que se ha realizado de la comunicación, y así saber hasta que punto la forma en la que se ha transmitido el mensaje ha sido la adecuada o no.

La propia televisión también se *aprovecha* de la riqueza de esta técnica cualitativa. En ocasiones, los programadores además de no perder de vista los todo poderosos datos de audiencia, realizan desde un enfoque cualitativo estudios que les ofrezcan información acerca de las relaciones que los telespectadores establecen con un determinado programa o con la cadena en su conjunto, cuál es su imagen, su posicionamiento, qué cambios pueden ser bien recibidos o, por el contrario, qué cambios significarían un riesgo...

De forma general, la aproximación abierta a los temas que permite el grupo de discusión hacen que esta técnica sea adecuada para acercarse por primera vez a un fenómeno social. Su gran capacidad informativa ayudará al investigador a conocer cuál es el espacio de referencia, el marco en el que se sitúa un determinado colectivo en su relación con el objeto de estudio y a partir de este primer contacto poder dirigirse de forma más adecuada en posteriores fases de la investigación. En este sentido una de las utilidades que siempre se le han reconocido al grupo de dis-

cusión es la importante aportación que ofrece de cara al diseño de un cuestionario, para el que la celebración de una fase preliminar cualitativa posibilita un acercamiento directo al objeto estudiado.

12.4.3. El desarrollo de la dinámica

En el desarrollo de la dinámica de un grupo de discusión podrían diferenciarse de forma muy básica tres fases:

1. Presentación del coordinador/a y de la técnica.
2. Fase abierta-espontánea.
3. Fase delimitada. En esta fase, aun dominando lo espontáneo, la intervención del coordinador es mayor que en los momentos previos de la dinámica.

Ahora de forma muy sintética nos fijaremos en qué puntos o aspectos deben recogerse en la presentación del coordinador ante el grupo.

MC Ejemplo de presentación

El investigador en los primeros momentos de la dinámica debe resolver las posibles incertidumbres, dudas o temores que puedan tener los asistentes a la reunión: qué me van a «vender», para qué estoy aquí, por qué yo... ¿Cómo hacerlo? Es preciso contextualizar adecuadamente la reunión dentro de un ámbito de investigación más amplio, explicar que se van a celebrar distintos grupos con interlocutores diferentes, explicitar qué se espera de ellos (su opinión, críticas...) e indicar cómo se va a desarrollar la reunión (sin turno de palabra, «ellos tienen la voz»).

Tras la presentación, el coordinador/a ofrecerá al grupo el *impulso* de la dinámica, es decir, planteará al grupo el tema de la investigación, aquello de lo que quiere que hablen entre ellos; a partir de este momento el grupo tiene la palabra. Cesión de la palabra que traslada la incertidumbre al coordinador: ¿hablarán? Se teme el silencio del grupo. Un silencio que es preciso señalar nunca se produce, pero que no evita que los primeros segundos se hagan muy largos.

El impulso de la dinámica es clave. Sin duda, ésta es una de las cuestiones sobre las que el investigador más ha reflexionado con anterioridad

al inicio del grupo y cuida en su presentación ante el grupo, calibrando las posibles relaciones o caminos que puede seguir el grupo y llevarle a recorrer unos temas y no otros.

El inicio de la dinámica debe situarse en un contexto próximo al objeto investigado. No debe ofrecerse un impulso excesivamente dirigido, pero tampoco uno tan alejado que dificulte que el grupo espontáneamente incorpore al discurso el objeto central investigado. Por ejemplo, en un estudio entre telespectadores de un programa televisivo emitido en la franja nocturna, puede proponerse como tema de la investigación: *qué programas de televisión suelen ver, cuáles son los que más le gustan, ...* Este impulso planteado en términos generales permite en la fase del análisis conocer qué otros programas están en un espacio próximo en cuanto a gustos televisivos, al tiempo que permite posicionar el programa concreto dentro del actual sistema de programación, así como asegurar que el programa sea mencionado de forma espontánea.

El impulso inicial debe ser lo suficientemente abierto como para permitir a los sujetos construir su propio sistema o mapa de asociaciones. Seguir sus propios *itinerarios* para llegar al objeto investigado. Es decir, que sea el grupo el que contextualice y jerarquice el tema a investigar, y no que el contexto se dé por supuesto.

En ocasiones, ante un impulso planteado en términos generales los participantes demandan una mayor concreción, una delimitación a un tema que ellos perciben muy amplio o en el que «cabén muchas interpretaciones». Ante esta demanda, el investigador les devolverá nuevamente la pregunta: *«Como tú lo entiendas, desde donde quieras...»*. El investigador no explicará o cerrará el impulso sino que lo mantendrá abierto y que sean los asistentes quienes comiencen a delimitarlo, a situarlo en su contexto.

Dentro de una investigación es importante que el inicio de los distintos grupos de discusión sea el mismo, es decir, que el coordinador de la reunión ofrezca siempre el mismo estímulo, de tal forma que posteriormente puedan analizarse las posibles diferencias que existan en los grupos en los itinerarios o asociaciones que surgen en los mismos a partir del impulso, en el camino elegido por el grupo.

12.4.4. El investigador y la dinámica en los grupos

La posición que toma el coordinador en el grupo de discusión no debe ocupar un lugar central en el discurso, aunque éste represente el poder. El coordinador no forma parte del grupo, por lo que no debe intervenir en la construcción de su discurso. El papel básico del coordi-

nador es crear y facilitar las condiciones necesarias para que el grupo genere su discurso y ofrezca así información.

Tras ofrecer el impulso o estímulo al grupo, el coordinador tiende en la primera fase del grupo a desaparecer, no toma una posición activa. Las primeras intervenciones de los asistentes habitualmente se desarrollan de forma muy rápida, cumpliendo ante todo la función de primer contacto, de presentación. Esta primera ronda de intervenciones o de presentación es habitual que no se complete, pues enseguida se establece el diálogo, el intercambio de ideas u opiniones entre los asistentes, comenzando entonces realmente la dinámica. Una dinámica en la que de ser el impulso correcto, enseguida surgirá el tema investigado. El grupo se desarrollará por el camino «elegido» por los participantes. Comienza la parte más espontánea de la dinámica.

La posición no activa del coordinador en esta fase no debe interpretarse como ausencia, al contrario, el investigador debe prestar —y mostrar— en todo momento gran atención a lo que se dice y al cómo se dice en el grupo. Debe seguir el desarrollo del grupo con una *atención flotante* que permita reintroducir, devolver al grupo nuevos estímulos a partir de lo ya dicho por ellos, retomar ideas que lleven a profundizar en el objeto de estudio. La introducción de nuevos estímulos debe ayudar al investigador a cubrir el guión temático del que se parte, es decir, debe servir para avanzar en los objetivos.

¿Cuándo debe intervenir, introducir nuevos estímulos el coordinador? La sensibilidad —y la experiencia— del coordinador será la que determine el momento más adecuado. La *entrada del coordinador* debe aparecer en continuidad con el propio desarrollo de la reunión, no es una interrupción, no es una ruptura o un nuevo comienzo. La intervención del coordinador no debe significar un desplazamiento en el discurso construido sino facilitar o fomentar su desarrollo. De ahí la importancia de que los participantes perciban que es una demanda de una reflexión sobre algo ya dicho, es un paso adelante, no comenzar un nuevo itinerario. Es importante que en la devolución que el investigador hace al grupo de sus propias reflexiones, de sus comentarios... éstos se recuperen en su literalidad, sin introducir nuevos significantes que puedan influir en la articulación y creación de su discurso, del itinerario o itinerarios seguidos. Por ejemplo, si en un estudio sobre la integración de población inmigrante en la sociedad española un grupo de padres habla de la presencia de «sudacas» en las aulas de sus hijos, el coordinador no preguntará sobre «sudamericanos» —la valoración que subyace en cada una de las expresiones es diferente, y es necesario considerarlo en el análisis—, sino que continuará utilizando las expresiones del grupo; o si en el caso de un estudio sobre una guía informativa el grupo dice que es un «tocho» no se

preguntará que «por qué se dice que es gorda» sino que se mantendrá el calificativo de «tocho». La participación o intervención del coordinador debe buscar la ampliación, la matización... de lo dicho, en definitiva, el enriquecimiento del discurso ya enunciado.

En general, la intervención del investigador se producirá cuando el discurso del grupo decaiga, se haya detenido o bien se haya desviado excesivamente del tema central. En esos momentos la entrada de un nuevo estímulo tomado de lo ya dicho reactiva la discusión. El coordinador debe administrar el tiempo del grupo, sin llegar al extremo de preasignar los minutos, pero tampoco debe dejar que el grupo se detenga, sin avanzar, en algún aspecto o faceta del objeto investigado sino que debe ayudarlo a avanzar, cuidar que se produzca la necesaria confrontación de ideas.

Además de la participación expresa, de la puesta sobre la mesa de comentarios, el investigador también puede solicitar la ampliación de lo dicho, o hacer que el grupo se detenga en algún aspecto interesante sobre el tema de estudio de una forma más sutil o indirecta, como puede ser repetir —como si se hubiera escuchado mal— alguna frase o palabra dicha, o con una pregunta-muletilla como es *¿en qué sentido?* De forma sencilla y casi siempre eficaz, esta pregunta lleva a una reflexión, a la matización de lo dicho, actuando o cobrando una función de estímulo interesante para la dinámica del grupo.

Las intervenciones del coordinador deben ser lo menos intrusivas posible en la conformación del discurso grupal. Su función es, tal y como se ha estado apuntando, generar las condiciones necesarias para el desarrollo del grupo, fomentando la participación de todos los sujetos. Para ello debe motivar a los que se muestran más tímidos o más pasivos, al tiempo que *frenar* a quienes monopolizan la dinámica. El discurso tiene valor en tanto que es construido por y en el grupo, no cuando es la opinión de *un* asistente al grupo. La figura del coordinador actúa de referencia, es de quien se tiende a buscar la confirmación, la aprobación. Una aprobación que se busca con la mirada. Por ello, la mirada se convierte en una herramienta de «control» del grupo para el investigador. El coordinador puede buscar la mirada de aquellos participantes que se muestran más reacios a participar, estimulándoles, mientras que para acortar la participación de algún asistente que busca un liderazgo excesivo, el coordinador puede evitar mantener su mirada, evitando así la confirmación que busca el otro.

El grupo, la formación de su discurso es un proceso dinámico. Existe una evolución dentro de él. Como ya se indicó anteriormente, la fase espontánea del grupo es seguida de una fase más delimitada, en la que el coordinador comienza (a partir de lo ya expresado) a cerrar, a delimitar el

espacio de referencia del discurso (tercera fase: fase que hemos denominado *delimitada*). Es decir, poco a poco, en continuidad con el discurso grupal, el coordinador se irá centrando en aspectos concretos del tema investigado.

La presencia del coordinador tiende a ir en aumento a medida que la dinámica se desarrolla; poco a poco va tomando una posición más directiva. Así, no es extraño que en la parte final del grupo, cuando éste ya ha construido y delimitado su discurso el coordinador lance al grupo algunas reflexiones, que ponga sobre la mesa posibles contradicciones que hubiera podido localizar, o bien que pregunte por cuestiones que no han surgido en la ordenación realizada por el grupo y que el coordinador considere de interés conocer la posición de los sujetos.

Uno de los aspectos que en la práctica más marca la diferencia entre los profesionales que trabajan con la técnica del grupo de discusión es la posición o presencia que el coordinador ocupa a lo largo de la dinámica. En este sentido, incluso puede hablarse de distintas técnicas (o al menos prácticas) en función, entre otros aspectos, de la mayor o menor presencia directiva que tome el coordinador. Mientras que en las posiciones más ortodoxas el grupo de discusión debe desarrollarse de forma lo más abierta posible, tanto en el impulso inicial como en la dinámica —en la que el coordinador estaría poco presente— dejando la iniciativa al grupo, otras posiciones (próximas a la práctica del *focus group*), muestran su preferencia por una línea más directiva, con una mayor presencia del coordinador, dirigiendo en gran medida el discurso del grupo. Ciertamente en algunos estudios, más allá de la mayor o menor proximidad a posiciones que puedan considerarse ortodoxas, es cierto que el objeto de estudio cuando es muy concreto y específico casi *obliga* a una presencia directiva del coordinador.

La mayor o menor presencia del coordinador en la dinámica del grupo, su papel más o menos directivo no sólo es una cuestión de estilo personal, sino que tiene su reflejo en el análisis. Una menor presencia del coordinador dejando un mayor espacio a la espontaneidad del grupo, a la jerarquización que este haga alrededor del tema investigado otorga en el momento del análisis una importancia central a la génesis del discurso, a las asociaciones o vinculaciones que el grupo establece alrededor del objeto de estudio, dónde es posicionado y en relación a qué otros objetos sociales... El grupo es el que sitúa, delimita el marco en el que inscriben o perciben el fenómeno social objeto del estudio.

Frente a una posición del coordinador que lo que hace es facilitar las condiciones para que se produzca la discusión de la forma más abierta y espontánea posible, una presencia más directiva del coordinador limita necesariamente la construcción del discurso grupal, al delimitar el espa-

cio discursivo, el marco de referencia en el que inscribir el discurso. En estos casos el análisis del proceso de creación del discurso, de los itinerarios seguidos por los sujetos hasta llegar a los significantes centrales no sería posible. Se tendería entonces a hacer un análisis más descriptivo, más centrado en el propio texto, con una menor contextualización social. Lo que se busca (o interesa) es lo que se dice acerca del fenómeno social investigado, importando menos el cómo, el dónde o el porqué.

12.4.5. Sobre el número de grupos

En cualquier investigación social el establecer cuál es el universo o la población que se va a investigar constituye sin duda una de las grandes cuestiones que el investigador social debe resolver antes de diseñar la investigación. En una encuesta se trata de saber a quién debe preguntarse, o determinar quién es y quién no sujeto «válido» para responder al cuestionario. Una vez conocido este sujeto de la investigación, el problema será diseñar el muestreo que mejor se adapte a las necesidades de la investigación y se adecue a la siempre existente limitación presupuestaria y temporal. En la investigación cualitativa la fase análoga al diseño de la muestra sería el diseño de los grupos de discusión a realizar.

Para determinar el número de grupos de discusión a celebrar habrá que fijarse en la amplitud de los objetivos planteados y en la diversidad o fragmentación social que pueda existir alrededor del objeto de estudio, sin olvidar la cuestión presupuestaria que de forma muy frecuente es la razón que determina el número de grupos a realizar.

El criterio que debe seguirse en el diseño del mapa de los grupos es intentar cubrir los distintos espacios que se piensa pueden existir en torno al tema investigado. Si en el caso de la entrevista es necesario la realización de varias con perfiles muy próximos para poder contar con seguridad en el análisis, en el caso del diseño de los grupos de discusión se trataría más de conformar un mapa completo, en el que no queden espacios sin cubrir. Más que la repetición de espacios se trataría de conseguir la intersección, de forma que fuera posible *dibujar* las posiciones discursivas en un continuo. No es preciso realizar varios grupos con un diseño idéntico, uno es suficiente. Se trata de «jugar» con las variables más destacables hasta cubrir todos o la mayor parte de los subtipos de sujetos situados en el universo estudiado.

12.4.6. Diseño de los grupos

Al hablar del diseño de las entrevistas en profundidad se decía que el propio diseño ya significa la existencia de unas hipótesis. Unas hipótesis que pueden ser o no confirmadas por la propia investigación. A la hora de diseñar los grupos, de perfilar a los sujetos que participarán en ellos se está trabajando con una serie de supuestos al pensar que las categorías o variables consideradas en la propuesta de dichos perfiles y no otras pueden determinar o generar posiciones discursivas diferentes.

Las variables que se consideran o que intervienen en el diseño particular de cada grupo lógicamente variarán en función del objeto investigado, pero sí se pueden destacar algunas variables sociodemográficas que siempre están presentes en la planificación de los grupos que conforman una investigación: edad, género, situación laboral y estatus socioeconómico serían las variables básicas a las que se incorporarían las categorías específicas para cada investigación.

En cuanto al diseño concreto de cada uno de los grupos que conforman la propuesta global de investigación, éste recogerá variables, facetas, roles específicos de los sujetos, para construir perfiles prototípicos. En el intento de construir un perfil prototípico también ha de considerarse el municipio en el que se propone realizar el grupo. Por ejemplo, se podrá diferenciar entre ciudades más tradicionales o «conservadoras» o más modernas, con distinto nivel socioeconómico...

En la consideración de las variables que intervienen en el diseño de los grupos no ha de perderse de vista que se trata de construir microsituaciones representativas dentro del universo al que se dirige la investigación. No se trata de diseñar grupos únicos con una presencia periférica o tangencial en el tema centro de la investigación. Diseñar grupos muy delimitados y minoritarios no tendría mucho sentido operativo, en tanto que no se podría extrapolar a una situación macro.

A la hora de «construir», de perfilar a los sujetos participantes en cada dinámica es importante cuidar la homogeneidad de cada uno de los grupos frente al resto, es decir, los participantes en cada uno de los grupos comparten una serie de características que marcan o señalan diferencias con los sujetos participantes en los otros. Esta homogeneidad grupal frente al exterior está acompañada de diversidad en el interior de cada grupo: distintas edades, diferencias en las variables secundarias como pueden ser el número de hijos, estado civil... La diversidad interna del grupo aporta mayor representatividad al grupo, al microuniverso construido.

En cuanto a la idea de la homogeneidad de los grupos lo que se busca es que los participantes compartan procesos o momentos experienciales próximos entre sí en relación con el objeto de estudio. Así, por ejemplo, a la hora de fijar la edad de los participantes en los grupos no interesa tanto la diferencia absoluta como la idea de generación. En este sentido, el caso extremo sería cuando se realizan grupos de discusión con niños. El estadio evolutivo en el que se encuentran es clave, por lo que las franjas de edad con las que se trabajan son mínimas, casi de año en año: 7-8, 9-10...

A modo de ejemplo, se recoge en el cuadro 12.1 el diseño de los grupos propuestos para el estudio «Las representaciones sociales sobre la salud en la población activa masculina madrileña» de la Dirección General de Salud Pública de la Comunidad Autónoma de Madrid.

CUADRO 12.1
Ejemplo de propuesta de investigación. Diseño de grupos

- | | |
|-------|---|
| RG.1. | Hombres de 40 a 50 años. Empleados y administrativos trabajando en banca, administraciones públicas, grandes compañías, seguros, etc. Clases medias o medias bajas. Madrid capital. |
| RG.2. | Hombres de 50 a 60 años. Agricultores. Pequeños propietarios agrícolas. Clases medias. Chinchón. |
| RG.3. | Hombres de 26 a 33 años. Solteros y casados. Trabajadores con contratos temporales y empleo irregular. Torrejón de Ardoz. |
| RG.4. | Hombres de 29 a 36 años. Solteros y casados. Técnicos medios en empresas relacionadas con la informática, la programación, ... vinculados a un sector con una cierta expansión social y crecimiento económico. Clases medias socialmente ascendentes. Madrid capital. |
| RG.5. | Hombres de 48 a 60 años. Padres de familias numerosas y de familias nucleares. Pequeños propietarios de empresas y comercios. Clases medias y medias altas. Madrid capital. |
| RG.6. | Hombres de 40 a 50 años. Trabajadores industriales en activo. Grandes empresas del sur de Madrid. Getafe. |
| RG.7. | Hombres de 30 a 38 años. Parados. Parla. |
| RG.8. | Hombres de 32 a 40 años. Profesionales liberales y ejecutivos en empresas privadas. Clase media alta. Madrid capital. |

Como se ve, para el diseño estructural de los grupos se tuvieron en cuenta como variables básicas las siguientes: edad, hábitat, situación laboral, ocupación laboral, estatus socioeconómico y de forma tangencial estado civil y número de hijos. Se pensaba que estas variables, y de forma muy especial la cultura socioprofesional existente en distintos sectores productivos, podía determinar la concepción o representación sobre la salud. En este diseño estructural cada uno de los grupos está pensado en el intento de recoger la posición discursiva de un colectivo de trabajadores concreto, que se supone comparten una misma cultura socioprofesional. De esta forma, el conjunto de grupos intenta cubrir las distintas culturas profesionales que pueden existir entre los varones.

Cada grupo de dicha investigación es homogéneo frente al resto, sería totalmente contraproducente e incorrecto reunir en un único grupo a parados y profesionales liberales, aun estando próximos en edad, ya que lo primordial y central del diseño grupal es la posición que se ocupa en el mercado laboral, y en este caso serían posiciones muy alejadas entre sí, cuando no enfrentadas. El grupo de discusión no es un espacio para la confrontación de ideas de distintos colectivos, sino un espacio para conocer las ideas dominantes en un colectivo concreto por separado. Será en el análisis que realice el investigador cuando las posiciones discursivas se confronten o comparen.

12.4.7. Los participantes en los grupos de discusión

Entre las recomendaciones o normas más consensuadas referidas a la celebración de los grupos está la de que los participantes en los grupos no se conozcan entre sí. La existencia de relaciones anteriores al grupo puede hacer que exista un conocimiento previo de las posiciones de los individuos, o que haya una reflexión anterior sobre el objeto investigado en otro entorno, lo que no es lo más adecuado para el grupo. Además, es posible que de haber una relación previa, en determinados temas se produzca una «autocensura», es decir, que no se produzca un completo sinceramiento de los asistentes.

¿Qué motiva a los participantes a asistir a los grupos? Realmente podría hacerse un estudio sobre ello. Lo habitual en la celebración de los grupos es que los participantes sean obsequiados con un regalo. Cada vez es más frecuente que este regalo sea un «cheque regalo». Este obsequio no se hace desde la dimensión de pago por un servicio sino desde la lógica del agradecimiento, como una atención por el tiempo dedicado. Si bien esta es la lógica, resulta ingenuo pensar que los participantes lo interpretan como tal: para buena parte de los participantes aparece como un pago. Además del mayor o menor atractivo y motivación que puede

ser para los potenciales participantes el ser obsequiados, sí parece existir cierta motivación por participar en una investigación social, por ser sujetos activos en un estudio del que se supone pueden derivarse cambios, cuando no mejoras.

Una de las preguntas que con mayor frecuencia han de responder los profesionales que en investigación social o de mercados desarrollan investigación cualitativa es la siguiente: ¿de dónde salen las personas que participan en los grupos? La profesionalidad de los contactadores es la respuesta.

12.4.8. La contactación de los asistentes a un grupo de discusión

Una de las pautas más seguidas es que la persona que realice la contactación de los participantes sea alguien diferente a quien va a coordinar la reunión. En investigación social y de mercados lo habitual es que quien realiza la búsqueda de personas sea un contactador profesional. Éstos cuentan con una importante red de contactos que se pone en marcha hasta llegar a localizar a personas que respondan al perfil solicitado. Aunque lo ideal es que los asistentes a un grupo lo sean por primera vez, es decir, que no tengan experiencia de cómo se desarrolla la dinámica, resulta ingenuo pensar que es así siempre. En grandes ciudades, en las que es muy frecuente la realización de investigaciones de mercado (Madrid, Barcelona, Sevilla, Bilbao y Valencia principalmente), existe por desgracia cierta *profesionalización* de participantes en reuniones.

A la hora de realizar la contactación, es muy importante «cuidar» la información que se ofrece a los potenciales asistentes a los grupos. Se ofrecerá una información general de lo que se hablará en la reunión o el tema de la investigación a realizar, de tal forma que el sujeto no llegue a la reunión con una reflexión articulada y trabajada sobre el tema sino que tenga únicamente una noción muy general del objeto investigado. No se trata de que los participantes se construyan una idea equivocada sobre el tema de la reunión, lo que podría ser perjudicial para la investigación, sino que no sepan por completo el tema exacto de la investigación, de modo que no lleguen a la reunión con ideas u opiniones preestablecidas. Por ejemplo, si para la investigación fuera preciso que el asistente consumiera un determinado producto, o una determinada marca, no se le planteará abiertamente esta condición, sino que se le preguntará por su consumo de cigarrillos, por ejemplo, dentro de un contexto más amplio de consumo de otros productos: bebidas alcohólicas, refrescos... Marco más amplio que permite que los participantes en los grupos de discusión lleguen lo más «vírgenes» posibles.

Igualmente es importante que desde el primer momento el potencial asistente al grupo conozca la duración aproximada de la reunión, que suele estar entre hora y media y dos horas.

Una contactación excesivamente directiva en la que el contactador ha explicado o explicitado de forma cerrada el tema de la investigación puede llevar a que el grupo no responda al impulso abierto que les propone el coordinador/a sino que se dirijan directamente al tema que creen central de la investigación. En estos casos, cuando se trata de resituar a los sujetos en el objeto investigado, intentando que partan de una posición más abierta es habitual que el grupo interpele al coordinador y que muestre su creencia de que el tema del que *debían* hablar era otro al propuesto. Interpelación que interrumpe la creación discursiva del grupo. El hecho de que el grupo inicie su discurso en el punto dado por el contactador/a de forma errónea en el proceso de localización de sujetos recorta en gran medida la capacidad analítica del investigador; al recortar el discurso y, sobre todo, al no conocer la génesis del mismo, no se conocen las relaciones y/o asociaciones sobre las que el grupo construye su discurso, cuáles son los itinerarios que les llevan al objeto investigado.

La correspondencia o adecuación del perfil de los asistentes al diseño teórico del grupo es lógicamente la base sobre la que se sustentan las conclusiones o el análisis que se hace del discurso generado en el grupo. El análisis parte de la suposición de que los asistentes cumplen realmente las condiciones del diseño, lo que hace de la correcta contactación de los participantes una condición imprescindible. En el caso en el que las características de los participantes (de todos o de parte de ellos) no responda al diseño teórico será preciso su repetición.



12.4.9. El lugar de realización

El lugar elegido para la realización del grupo debe ser lo menos connotado o marcado posible y, en todo caso, que no esté cargado simbólicamente con los valores del grupo. El ejemplo clásico y tópico es lo poco adecuado y acertado que sería celebrar una reunión de parados en un hotel de lujo. En cambio, sí sería un lugar adecuado para reunir a un grupo de altos directivos de empresa.

Además de la adecuación simbólica del local, éste no deberá estar vinculado al tema de estudio o al contexto cotidiano de los participantes en la reunión. Así, si se trata de hacer una investigación sobre una marca concreta no es pertinente metodológicamente celebrar la reunión en locales de ésta, como tampoco lo es celebrar un grupo de trabajadores en la sede de la empresa.

En general, debe intentarse que en el lugar de celebración de la reunión pueda ofrecerse a los asistentes algún refresco o bebida preferiblemente no alcohólica, o en todo caso de baja graduación, como la cerveza.

En ocasiones no se otorga la suficiente importancia a la forma y al tamaño de la mesa o a las sillas. Muchas veces una mesa inadecuada o unas sillas incómodas en exceso pueden «enfriar» la dinámica del grupo. Como también puede hacerlo una sala que no esté bien climatizada. Siempre y cuando sea posible se tratará de que la mesa alrededor de la cual van a sentarse los asistentes sea redonda u ovalada. A los asistentes no se les asignará ningún lugar sino que ellos mismos serán quienes elijan donde sentarse. En una mesa redonda no existen posiciones que señalen *a priori* una posición destacada —ni siquiera para el investigador— como sí ocurre con las mesas rectangulares, en las que la cabecera apunta a una posición de autoridad. Las mesas ovaladas aun teniendo cabecera se ven atenuadas y, al igual que la redonda, permiten una buena visión de todos los asistentes, visión que se ve dificultada en mesas rectangulares y cuadradas.

	
Perfecta visibilidad. Igualdad de posiciones. El coordinador no ve reforzada su posición de poder.	No hay una visibilidad correcta. Las cabeceras aparecen como posiciones destacadas. Tendencia a reforzar la presencia del coordinador, reforzando su posición de poder. De forma espontánea el grupo tiende a dejar una de las cabeceras al coordinador.

Las sillas obviamente deben ser cómodas, de no ser así la hora y media o dos horas que suele durar una reunión se harían muy largas a los asistentes, que de forma más o menos inconsciente «recortarían» sus discursos. Por su parte, unas sillas que lleven a reclinarsse en exceso en su respaldo —tipo sillón— tampoco son las más adecuadas en tanto que llevan al asistente a alejarse de la mesa, del grupo, lo que se traduciría en una menor participación y en un «enfriamiento» de la propia dinámica.

En cuanto a la grabación de la reunión se recomienda utilizar dos grabadoras para recoger mejor lo dicho en el grupo y además asegurarse de que ésta se produce. Nunca debe olvidarse comprobar el perfecto funcionamiento de las grabadoras. La grabación de las características del grupo a celebrar es un buen momento.

12.4.10. El análisis del grupo de discusión

Una vez que el grupo ha construido su discurso corresponde actuar al investigador, localizando las claves, los elementos que le ayuden a conocer y comprender las motivaciones de los sujetos ante un comportamiento o respuesta concreta, cuáles son y de qué modo actúan las determinaciones sociales.

A la hora de analizar un discurso grupal lo más usual es contar con sus textos: su transcripción literal. Por lo tanto, una fiel y correcta transcripción es clave para poder realizar un adecuado análisis. En las transcripciones debe recogerse fielmente el habla de los participantes, sus posibles lapsus... La correcta transcripción del grupo de discusión permite al investigador volver, detenerse en lo dicho.

La mirada del analista sobre lo dicho en el grupo no debe limitarse a ser un mero acercamiento descriptivo sino interpretar lo que en él se dice, para explicar lo que sucede fuera de él. El analista debe enfrentarse a los textos de los discursos sin prejuicios, no dejándose arrastrar por sus *a priori* sino a la inversa: son los discursos los que hacen su interpretación y no los discursos los que deben adaptarse a su mirada.

El análisis del discurso no es sistematizar u ordenar lo dicho en el grupo, esto sería mantenerse en el texto, en su estructura interna. No se trata tampoco de realizar un análisis de contenido, o buscar su coherencia o estructura interna. El análisis debe superar el propio texto. Lo dicho en el grupo es el punto de partida, el de llegada está en el espacio social. El análisis del texto debe inscribir lo que en él se dice dentro del contexto social de quien lo dice. Se parte del texto para salir de él. Se realiza un análisis social externo al propio texto. Esta salida del discurso es posible en tanto que el grupo de discusión parte de la idea de la estabilidad del discurso ya apuntada con anterioridad. Esta estabilidad social es la que permite pasar de la microsituación social que es el grupo de discusión a la situación macro de la sociedad.

Tal y como se ha apuntado, en la base del grupo de discusión como práctica de investigación social está la idea de la existencia de posiciones discursivas distintas para diferentes posiciones sociales. De esta forma, con la microsituación creada en el grupo de discusión lo que se persigue

es aproximarse a la posición discursiva dominante en cada grupo social al que pueda dirigirse la investigación. El análisis de los discursos debe, en definitiva, identificar o exponer estas posiciones discursivas y cómo están determinadas socialmente. El investigador social debe interpretar qué determinaciones sociales están tras los discursos y comportamientos de los diferentes colectivos que han estado representados en los grupos de discusión realizados durante la investigación, dando pautas para una mejor comprensión de los comportamientos de los sujetos sociales.

El análisis de los textos producidos es un intento de reconstruir el discurso prototípico existente en las posiciones sociales a las que se dirige la investigación, para así conocer el discurso representativo que puede haber en distintos colectivos sociales. La reconstrucción e interpretación social del discurso grupal es a lo que debe llegar el análisis, pero ¿cómo se llega a esta reconstrucción?

Uno de los aspectos en los que es interesante fijarse es en el *itinerario* de asociaciones, de relaciones que los sujetos establecen en la dinámica desde el impulso inicial del investigador hasta la *aparición* del objeto investigado (de los significantes centrales). Para este tipo de análisis, en el que se otorga gran importancia al proceso de génesis del discurso, es preciso que la dinámica se haya iniciado de forma abierta, no centrando al grupo en el objeto de estudio sino dejando el suficiente espacio para que los sujetos, el grupo organice o construya su propio itinerario hasta llegar al objeto. En este sentido es interesante fijarse, por ejemplo, en la primera mención al objeto central del estudio, en qué entorno se ha producido, resultado de qué relación, cómo se hace referencia a él...

En el análisis de los discursos interesa tanto lo que se dice como aquello que se silencia o no se nombra. O bien que sin mencionarse de forma expresa está implícitamente presente. Igualmente puede ser significativo interpretar por qué ante la propuesta del coordinador/a de la reunión para hablar de un tema el grupo se sitúa en otro, o por qué tras intentar reintroducirlo el grupo se resiste a hablar, a detenerse en él. Por lo tanto, en el recorrido del texto el investigador debe fijarse también en *lo ausente, en lo no nombrado*.

En el acercamiento que el investigador realiza de lo dicho por los sujetos, el discurso espontáneo es especialmente interesante al ser éste en el que se muestra o se refleja de forma más intensa y clara la posición del grupo. En esta fase el grupo jerarquiza su percepción, introduce sus propios significantes, realiza las principales asociaciones y/o contextualizaciones... El investigador tiene en este desarrollo espontáneo de la dinámica su principal fuente de información.

Los asistentes, en el proceso dinámico que es el grupo, pueden modificar (aparentemente) su posición, o introducir nuevas matizaciones a su

percepción. Este tipo de *cambios* o incluso posibles contradicciones que surgen en el discurso es básico analizarlas, detenerse en ellas. En su análisis el investigador debe tener en cuenta en qué momento, en qué fase del proceso de creación del discurso se ha producido una relación o asociación concreta o ha sido incorporado un nuevo significante vinculado al objeto analizado. Y en este sentido, el valor analítico, si se permite la expresión, es mayor cuanto más en espontáneo surge, cuanto más pertenece al grupo.

En el análisis es importante identificar la *posición dominante* desde la que los sujetos construyen su discurso. Por ejemplo, en una investigación sobre salud y calidad de vida entre las mujeres, en uno de los grupos de discusión propuestos en la investigación en el que participaban mujeres con hijos y que ocupaban puestos de responsabilidad, la posición dominante, el rol desde el que construían su discurso era el de «profesional», es decir, desde su posición en el ámbito laboral, con muy pocas intervenciones desde su rol de madre. Por su parte, en esta misma investigación en otro grupo con mujeres de edad próxima al anterior pero con puestos de trabajo sin responsabilidad, el rol de madre era el que dominaba su discurso, sus intervenciones se hacían ante todo como madres que trabajan fuera del hogar. Así, en el recorrido del texto es interesante identificar estas posiciones que son, en definitiva, las que permiten reconstruir el mapa discursivo existente en la sociedad (de lo micro llegar a lo macro), identificar los discursos prototípicos presentes en distintas posiciones alrededor de un fenómeno social.

Un grupo de discusión no se analiza de forma autónoma o independiente sino que parte importante del análisis es a partir de la comparación de un texto de un discurso con el discurso de otro grupo; de esta forma, el investigador puede construir o delimitar el marco o el espacio en el que se inscriben las distintas posiciones discursivas que pueden existir torno al tema investigado, cuáles son los ejes sobre los que se articulan estas posiciones y *dibujar* un mapa delimitado de situaciones ante un mismo objeto.

Sin embargo, el investigador también debe estar atento y *descubrir* las posibles situaciones o «matizaciones» discursivas que pueden existir *dentro* de un mismo grupo, con el fin de perfilar mejor las distintas posiciones que pueden existir alrededor del objeto social analizado. En efecto, en un grupo de discusión, aunque se tiende al consenso, es posible que aparezcan distintas posiciones discursivas, es lo que se llama *fracciones*. Fracciones que pueden mostrar una opinión distinta en cuestiones concretas del tema investigado o en general. Por ejemplo, los participantes de más edad de un grupo se suelen mostrar más críticos con los hábitos de consumo de bebida de los jóvenes que aquellos otros de menor edad, o en

otro grupo los participantes que se muestran más próximos a posiciones ideológicas de izquierda se oponen en mayor medida que otros al Plan Hidrológico Nacional.

MC Ejemplo de un grupo de discusión

Se ofrece la transcripción literal de un grupo de discusión, a la que se han incorporado algunos comentarios analíticos y se han destacado los comentarios o hitos más importantes sobre los que se podría articular su análisis.

12.5. EL GRUPO TRIANGULAR

12.5.1. Caracterización general

El grupo triangular es sin duda la técnica cualitativa más desconocida. En la actualidad puede decirse que es una técnica naciente, que muchos investigadores sociales desconocen por completo.

El grupo triangular se sitúa en un espacio intermedio entre el grupo de discusión y la entrevista en profundidad. Se trata de una reunión con tres participantes más el coordinador/a de la misma. El desarrollo de la dinámica es en apariencia muy similar o igual que el del grupo de discusión. Los asistentes se muestran más participativos, el hecho de ser únicamente tres parece *obligar* a ello. La diferencia fundamental con el grupo de discusión no estaría tanto en su desarrollo sino en el tipo de discurso que se genera durante la reunión.

El discurso que se construye durante la dinámica se articularía, según Ortí (1993), sobre los tres puntos que caracterizan el grupo triangular como técnica de investigación: las características de los asistentes, las ideologías sociales de referencia y la personalidad del coordinador como representante de lo social general. La interacción de estos tres elementos lleva a inscribir el discurso generado en un espacio intermedio al que se construye en las otras dos técnicas ya revisadas. En el caso del grupo triangular se trata de un espacio más inestable, o si se prefiere, un espacio que se desplaza desde el «yo» al «otros».

Fernando Conde (1996) sitúa el discurso que se genera en el grupo triangular en el espacio intermedio del «yo» de la entrevista en profundidad y el «nosotros» del grupo de discusión. La reflexión teórica que este sociólogo realiza del grupo triangular parte del concepto de *espacio transicional* utilizado por el pediatra y psicoanalista inglés D. Winnicott. De

una forma muy sintética, éste define el espacio transicional como el espacio o zona potencial que se sitúa entre la «realidad psíquica interna» y el «mundo exterior» tal como es percibido por dos personas en común. Esto llevado y matizado para el espacio de producción del discurso del grupo triangular sitúa la producción, la articulación del discurso en un espacio de transición entre el «yo» (interior) y la «experiencia de los otros» (Conde, 1996).

El espacio intermedio de enunciación se hace explícito en la siguiente intervención, tomada de un grupo triangular¹:

— Y EL TEMA QUE OS PROPONGO PARA QUE CHARLÉIS ES LA EVOLUCIÓN UN POCO DE LA FORMA DE VIDA, DEL TIEMPO LIBRE, EL TRABAJO, CÓMO OS LO MONTÁIS, QUÉ HACÉIS, LO QUE QUERÁIS, PARA EMPEZAR POR DONDE QUERÁIS Y LUEGO YA, A MEDIDA QUE EMPEZAMOS...

— *¿Empezamos a nivel personal o como lo vemos en el ámbito de los jóvenes?*

Las jóvenes que participaban en el grupo preguntaban expresamente a la moderadora del mismo si se situaban en el «yo» o en el «otros».

— *Yo tengo 24 años, entonces es un poco una edad que hay gente que aún está estudiando la carrera y gente que ya tiene trabajo, es un poco la edad así tonta, ¿no? y en esa edad, yo tengo amigos que ya te digo, que tienen 24 años y se comportan como lo que nosotros llamamos críos, porque van a vinos y se mueven pues de chupitos, la borrachera de fin de semana y cogen unas moñas increíbles y están vomitando en un portal pues a la vuelta de la esquina, que yo no digo que no beba, eh? vamos a ver...*

Un «yo» y un «otros» que aparecen de forma paralela pero que tiende a fijarse más en el exterior que en el interior, a enunciarse más desde el «otros» que desde el «yo» enunciativo de la entrevista en profundidad.

— *No, no, yo paraba en un bar que venían unos ejecutivos, "El solo miras", que tenían dinero y los ves en la semana y de coca todos y decir, por la semana verlos y decir ostra me parece increíble sabes, de verlos fin de semana todos... a verlos día de semana todos con su traje, con su carpetita y tal*

¹ Las citas que aparecen en este punto dedicado al grupo triangular están tomadas de la transcripción de un grupo de mujeres de 23-27 años, celebrado en Vigo para la investigación «Los hijos de la desregulación. Jóvenes, usos y abusos en los consumos de drogas». Investigación realizada por la fundación CREFAT y dirigida por F. Conde en 1999.

Aunque la tendencia es situarse preferentemente en el «otros», en el grupo triangular se produce una situación de cierta «intimidad» que facilita que puedan darse situaciones de confidencialidad, situaciones de intimidad, que sin llegar a ser como en la entrevista en profundidad, son enunciadas desde el «yo».

12.5.2. **Ámbito de aplicación**

A partir de las experiencias de investigación en las que se ha trabajado con grupos triangulares, el uso combinado o complementario de éstos con los grupos de discusión o con las entrevistas en profundidad resulta de una gran eficacia, ofreciendo una información de gran riqueza y ayuda a la hora del análisis.

Al hablar de la entrevista abierta se decía que es una técnica versátil en su puesta en práctica; a nivel discursivo, el grupo triangular es la que muestra mayor versatilidad.

El espacio desde el que se enuncia el discurso posibilita acercarse al plano general de la ideología dominante en un discurso (con menor intensidad y seguridad que en el caso del grupo de discusión) al tiempo que permite aproximarse a aspectos concretos o específicos del objeto investigado. Frente al caso de la entrevista que ofrece un acercamiento «unilateral», el grupo triangular posibilita una puesta en común entre varios sujetos de elementos o factores concretos del fenómeno social estudiado.

En el grupo triangular, a diferencia de la estabilidad presente en el grupo de discusión y en la entrevista, el sujeto desplaza su marco discursivo, situándolo tanto en el «yo» como en «los otros». Esta *inestabilidad* conlleva que sea más difícil alcanzar la saturación discursiva a través de esta técnica, en tanto que tiende a mantenerse abierto y dinámico. De ahí lo positivo de combinar esta práctica con el desarrollo de grupos de discusión. El grupo triangular aporta al discurso del grupo de discusión un mayor nivel de concreción del tema. De esta forma, el grupo triangular aparece como una técnica muy adecuada para aquellos estudios en los que es preciso trabajar con algún tipo de material como fotografías, revistas, vídeos... La mayor implicación y participación de los sujetos facilita el trabajo con este tipo de material. Un material que al presentarse lleva al grupo (y lo mismo ocurre en el caso de presentarse en una entrevista en profundidad) a detenerse más en lo concreto, fomentando las relaciones, asociaciones, relatos asociados, etc.

El pequeño número de participantes facilita que entre los asistentes se genere una cierta intimidad (o complicidad) que es más difícil que surja

en la dinámica de un grupo de discusión. El ambiente de mayor intimidad promueve un mayor sinceramiento entre los asistentes, incluso en temas que pueden ser en un primer momento más personales o íntimos. De esta forma, el grupo triangular permite abordar con mayor facilidad determinados temas, que en un grupo de discusión tal vez se mantendría excesivamente en el plano de lo general.

12.5.3. El diseño de los grupos triangulares

Ya se ha apuntado que en la experiencia de trabajo con el grupo triangular donde tal vez se ha mostrado más eficaz es en su uso combinado y complementario con el grupo de discusión y la entrevista en profundidad. Una propuesta en la que estén presentes varias técnicas garantiza el acercamiento a distintos planos informativos. Además, dada la mayor dificultad para alcanzar la saturación discursiva a través del grupo triangular, su combinación con el grupo de discusión permite cubrir las posiciones discursivas que pudieran existir alrededor del objeto de estudio. En este sentido es habitual que la propuesta de realización de grupos triangulares o en todo caso su diseño definitivo, sea *a posteriori* de la realización de parte o de la totalidad de los grupos de discusión propuestos inicialmente, de tal forma que con nuevos grupos triangulares se cubran aspectos o variables que no habían sido suficientemente cubiertas en el diseño de los grupos de discusión, o bien profundizar en aspectos en los cuales apenas se ha detenido o fijado el discurso de los grupos.

En cuanto a la caracterización concreta de los grupos, los criterios o pautas a tener en cuenta son las mismas que las ya apuntadas para el grupo de discusión. En este caso, se pide —si cabe— una mayor adecuación del perfil de los asistentes al diseño teórico de partida. Por ejemplo, en un supuesto estudio sobre una revista en el que los asistentes son lectores, lo más acertado sería que fueran grandes conocedores de la revista, es decir, en este sentido el perfil de los asistentes a un grupo triangular estaría muy próximo al perfil prototípico que se busca para las entrevistas en profundidad.

12.5.4. El análisis del discurso

En el caso del grupo de discusión el objetivo del análisis de los textos generados es la reconstrucción del discurso tipo del grupo de referencia, es decir, reconstruir el discurso representativo de dicho grupo social. El análisis del discurso del grupo triangular ofrece una faceta distinta a la que ofrece la entrevista o el grupo de discusión: el espacio intermedio al

que se accede con esta técnica permite profundizar en aspectos concretos del objeto investigado, al acercarse a él desde una doble perspectiva, desde el «dentro» del *yo* y el «afuera» del *otros*. El que el discurso se enuncie desde el *yo* en lugar del *nosotros* del grupo de discusión supera la generación más codificada del discurso social dominante (representativo) que finalmente se construye en la dinámica del grupo de discusión, introduciendo un enfoque más personalizado y próximo. Lo general se personaliza.

En opinión de Conde (1996), en el análisis de un grupo triangular lo importante no sería tanto lo que analiza posteriormente el investigador sino lo que es capaz de llevar a cabo conjuntamente con los asistentes en y a lo largo de la dinámica del grupo triangular. Así, la propia reflexión que los participantes puedan hacer durante la dinámica del discurso dominante, su propia toma de conciencia ante el objeto de estudio aparece como clave en el grupo triangular.

Esta autorreflexión lleva a que el papel jugado por el moderador en el grupo triangular sea distinto al que toma en el grupo de discusión. Mientras que en este último debe tratar de estar poco presente, de no interferir en el proceso de construcción discursiva, tomando, por el contrario, protagonismo en la fase posterior como analista, en el grupo triangular «el moderador debe entrar y salir en la dinámica grupal, para poder jugar, entre otros, el papel de facilitador de la explicitación y posible toma de conciencia por parte de los asistentes al grupo triangular del discurso social, del código social dominante al respecto del tema que se investiga de modo que a partir de esta toma de conciencia dicho grupo tenga la capacidad de sortearlo, de modificarlo, de trastocarlo si lo estima o cree necesario en función de las tareas que esté acometiendo el grupo» (Conde, 1996, p. 306).

12.6. PUNTOS BÁSICOS

- Los enfoques cualitativo y cuantitativo son complementarios. Cada uno de ellos se aproxima a facetas diferentes de la realidad social. Frente al conocimiento de la cifra, de la distribución de los fenómenos que facilitan las técnicas cuantitativas, la mirada cualitativa permite el conocimiento del discurso dominante en los grupos sociales.
- Los sujetos que participan en investigaciones realizadas con metodología cualitativa no lo hacen a título individual sino como representantes de su grupo de referencia o de su situación social en relación a un objeto de estudio.

- El análisis de los discursos contruidos por los sujetos en las distintas técnicas cualitativas permite interpretar o conocer las motivaciones que están tras el comportamiento de los sujetos sociales: se trata de llegar a conocer-reconstruir la percepción que éstos tienen de la realidad social, y como a partir de ella se relacionan con su entorno o de forma más concreta con el objeto estudiado.
- Tres de las principales técnicas que se utilizan en la metodología cualitativa son la entrevista en profundidad, los grupos de discusión y los grupos triangulares.
- Existe una complementariedad entre estas técnicas que hace posible cubrir desde un enfoque cualitativo distintos planos o niveles de información. La entrevista en profundidad, lo más específico y concreto frente al nivel más general y estructural del grupo de discusión, ocupando el grupo triangular un espacio intermedio.
- Cada técnica cualitativa se caracteriza por su propio espacio discursivo dominante: el *yo* (en la entrevista en profundidad), el *nosotros* (en el grupo de discusión) y un espacio de transición entre el *yo* y los *otros* (en el grupo triangular).
- La entrevista en profundidad es una técnica adecuada para el estudio de casos desviados o para acercarse a colectivos en los que se piensa que sus individuos pueden tener una fuerte percepción de particularidad. Igualmente aparece adecuada para cubrir objetivos muy específicos o concretos y, en este sentido, para estudiar comportamientos, hábitos...
- En el análisis de la entrevista el investigador debe discriminar lo particular que existe en el discurso del sujeto de lo que en él hay de social, lo que está determinado por su posición social. Filtro que vendrá dado por la repetición del discurso en los sujetos entrevistados.
- El grupo de discusión es una reunión de siete u ocho personas, más un coordinador que construyen un discurso social a partir del impulso dado por el investigador.
- El grupo de discusión se fundamenta en el supuesto de una estabilidad discursiva en las distintas posiciones sociales, es decir, existe un discurso dominante asociado a cada posición social.
- Al final del análisis de los textos grupales, el investigador debe poder ofrecer un «mapa» con las posiciones discursivas que existen alrededor del objeto estudiado.

- En una investigación el diseño de los grupos de discusión debe recoger y cubrir todas o casi todas las variables que se piensan pueden estar actuando en la configuración de los discursos dominantes.
- El grupo de discusión es la técnica adecuada para conocer la imagen, percepción, posicionamiento... de un objeto o fenómeno social.
- El coordinador de la reunión debe dejar que el grupo sea quien organice y jerarquice su discurso. Sus intervenciones deben producirse en continuidad con el proceso de génesis del discurso grupal.
- El grupo triangular es una técnica muy adecuada para estudios en los que se trabaja con material y en aquellos en los que, además del marco social más general, interesa conocer aspectos más concretos y específicos. Por ello, aparece como una técnica complementaria al grupo de discusión.

12.7. EJERCICIOS

12.7.1. ¿Cuál es la particularidad del enfoque cualitativo en investigación social?

12.7.2. Empareje cada una de las técnicas cualitativas con su espacio discursivo dominante:

Grupo de discusión	Yo-Otros
Entrevista en profundidad	Nosotros
Grupo triangular	Yo

12.7.3. Piense en posibles investigaciones, con un tema próximo a su ámbito laboral y/o social, en el que crea adecuado utilizar cada una de las tres técnicas cualitativas expuestas en el capítulo.

12.7.4. Suponga que debe realizar una investigación sobre las expectativas laborales de los universitarios madrileños. ¿Cuáles cree que serían las variables más destacables o que deberían considerarse a la hora de definir el perfil de los asistentes a los grupos de discusión?

12.7.5. Si tuviera que realizar una investigación sobre la maquetación del material didáctico de la UNED, ¿qué técnica cualitativa propondría?, ¿por qué?

12.7.6. Y si tuviera que hacer una investigación sobre el sistema de educación a distancia, ¿qué técnica utilizaría?, ¿por qué?

12.8. SOLUCIONES A LOS EJERCICIOS PROPUESTOS

12.8.1. Poder acceder directamente al habla de los sujetos, pudiéndose aproximar al discurso que los propios sujetos construyen alrededor de un fenómeno social. La mirada cualitativa permite conocer las relaciones, vinculaciones... que los sujetos establecen en torno a un objeto social concreto, posibilitando así entender e interpretar la percepción que los sujetos tienen de la realidad, y sobre la cual organizan su comportamiento.

12.8.2. Grupo de discusión: Nosotros; **Entrevista en profundidad:** Yo; **Grupo triangular:** Yo-Otros.

12.8.3. Entrevista en profundidad: Una investigación sobre la convivencia en el hogar con niños autistas. (Para casos en los que se tiende a la fragmentación, en casos extremos.)

Grupo de discusión: La opinión de padres y estudiantes ante la propuesta ministerial de suprimir la Selectividad. (Para conocer la imagen o la representación social de un fenómeno.)

Grupo triangular: Los estilos de vida de los jóvenes. (Para conocer algunos aspectos con cierto detalle, además de un acercamiento a la ideología dominante.)

12.8.4. Tipo de licenciatura (letras, ciencias, técnicas,...); titularidad de la universidad (pública, privada); género; estatus social y curso en el que se encuentra (primeros cursos-últimos cursos).

12.8.5. Entrevista en profundidad y/o grupo triangular, ya que a través de estas técnicas es más fácil llegar a lo específico, a aspectos concretos.

12.8.6. Grupo de discusión, ya que es la técnica idónea para conocer el marco general de la cuestión a examinar.

12.9. BIBLIOGRAFÍA BÁSICA RECOMENDADA

ORTÍ, A. (1986). La apertura y el enfoque cualitativo o estructural: La entrevista abierta semidirectiva y la discusión de grupo. En M. García Ferrando, J. Ibáñez y F. Alvira (Comp.), *El análisis de la realidad social. Métodos y técnicas de investigación*. Madrid: Alianza.

Capítulo en el que de forma breve se recogen consideraciones teóricas sobre el grupo de discusión y la entrevista en profundidad, sobre el discurso de los sujetos, al tiempo que se ofrecen pautas para la celebración de los grupos de discusión.

RABADÁN, E. y ATO, M. (2003). *Técnicas cualitativas para investigación de mercados*. Madrid: Pirámide.

En este texto se aborda en detalle la metodología cualitativa desde una óptica psicológica, bastante infrecuente en un campo con un carácter marcadamente sociológico. Contiene numerosos ejemplos y prácticas que ilustran la aplicación de esta metodología, pero sin olvidar la fundamentación teórica.

VALLÉS, M. S. (1997). *Técnicas cualitativas de investigación social*. Madrid: Síntesis.

Se abordan las principales técnicas de recogida de datos en la investigación social y se realiza una introducción al análisis de datos cualitativos. En la primera parte de la obra se realizan algunas consideraciones de carácter histórico, técnico y metodológico sobre este tipo de investigación.

12.10. LECTURAS SUGERIDAS

ALONSO, L. E. (1998). *La mirada cualitativa en Sociología*. Madrid: Fundamentos. Capítulos 1-3 y 6.

El libro es un interesante acercamiento a la investigación cualitativa, a lo que puede aportar a la Sociología la mirada cualitativa. En los capítulos destacados se recogen las particularidades de la investigación cualitativa frente al enfoque cuantitativo, así como algunas consideraciones teóricas sobre la entrevista en profundidad, grupos de discusión y el análisis de los discursos. Incorpora además una bibliografía muy amplia para quienes están interesados en profundizar en estos temas.

ÁLVAREZ-GAYOU, J. L. (2003). *Cómo hacer investigación cualitativa: Fundamentos y metodología*. México: Paidós.

Se analizan los orígenes y cuestiones básicas de la investigación cualitativa y se describen los principales procedimientos utilizados en la recogida de datos, así como los marcos teóricos/referenciales más importantes para explicar o comprender los fenómenos bajo estudio.

CALLEJO, J. (2001). *El grupo de discusión: Introducción a una práctica de investigación*. Barcelona: Ariel Practicum.

Libro eminentemente práctico sobre el grupo de discusión. El autor recoge de su propia experiencia investigadora algunos ejemplos de estudios y de

su trabajo de campo. Al final del libro se incorpora una transcripción de una reunión de grupo.

CONDE, F. (1996). Los grupos triangulares como espacios transicionales para la producción discursiva (Anexo C). En F. Conde, *La vivienda en Huelva. Culturas e identidades urbanas* (pp. 275-307). Sevilla: Junta de Andalucía-Fundación El Monte.

En este anexo metodológico se recoge la complementariedad de las tres técnicas cualitativas y el diferente espacio discursivo que se genera en cada una de ellas. Es el texto en que más desarrollada está la reflexión teórica sobre el grupo triangular. Cuenta con ejemplos de cada una de las técnicas que ejemplifican claramente sus particularidades. El conjunto del libro es resultado de una investigación en la que se trabajó con la metodología de encuestas y con la cualitativa (entrevista en profundidad, grupo triangular y grupo de discusión).

FLICK, U. (2004). *Introducción a la investigación cualitativa*. Madrid: Morata.

Es una obra muy reciente y actualizada que proporciona numerosos ejemplos, si bien va más allá de las cuestiones abordadas en el presente texto, tanto por lo que se refiere a técnicas de recogida de datos como a los análisis de los mismos.

IBÁÑEZ, J. (1986). Perspectivas de la investigación social, el diseño de la perspectiva estructural. En M. García Ferrando, J. Ibáñez y F. Alvira (Comp.), *El análisis de la realidad social. Métodos y técnicas de investigación*. Madrid: Alianza.

Jesús Ibáñez ha sido quien ha analizado más profundamente en España el grupo de discusión, construyendo gran parte de su sustento teórico y aportándole un carácter propio en su puesta en práctica. En este capítulo se recoge brevemente su aproximación a la metodología cualitativa.

VALLÉS, M. S. (2002). *Entrevistas cualitativas*. Madrid: CIS.


Monografía dedicada en exclusiva a las entrevistas en profundidad. Después de un recorrido histórico y de la presentación de distintas perspectivas y posturas acerca de éstas, se abordan aspectos del diseño de las entrevistas, del trabajo de campo y de su posterior análisis.

12.11. MATERIAL COMPLEMENTARIO

- Ejemplo de presentación.
- Ejemplo de un grupo de discusión.

ANEXO:
TABLAS ESTADÍSTICAS


Tabla A

Distribución normal $P(Z \leq z)$

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
-3,5	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002
-3,4	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0002
-3,3	0,0005	0,0005	0,0005	0,0004	0,0004	0,0004	0,0004	0,0004	0,0004	0,0003
-3,2	0,0007	0,0007	0,0006	0,0006	0,0006	0,0006	0,0006	0,0005	0,0005	0,0005
-3,1	0,0010	0,0009	0,0009	0,0009	0,0008	0,0008	0,0008	0,0008	0,0007	0,0007
-3,0	0,0013	0,0013	0,0013	0,0012	0,0012	0,0011	0,0011	0,0011	0,0010	0,0010
-2,9	0,0019	0,0018	0,0018	0,0017	0,0016	0,0016	0,0015	0,0015	0,0014	0,0014
-2,8	0,0026	0,0025	0,0024	0,0023	0,0023	0,0022	0,0021	0,0021	0,0020	0,0019
-2,7	0,0035	0,0034	0,0033	0,0032	0,0031	0,0030	0,0029	0,0028	0,0027	0,0026
-2,6	0,0047	0,0045	0,0044	0,0043	0,0041	0,0040	0,0039	0,0038	0,0037	0,0036
-2,5	0,0062	0,0060	0,0059	0,0057	0,0055	0,0054	0,0052	0,0051	0,0049	0,0048
-2,4	0,0082	0,0080	0,0078	0,0075	0,0073	0,0071	0,0069	0,0068	0,0066	0,0064
-2,3	0,0107	0,0104	0,0102	0,0099	0,0096	0,0094	0,0091	0,0089	0,0087	0,0084
-2,2	0,0139	0,0136	0,0132	0,0129	0,0125	0,0122	0,0119	0,0116	0,0113	0,0110
-2,1	0,0179	0,0174	0,0170	0,0166	0,0162	0,0158	0,0154	0,0150	0,0146	0,0143
-2,0	0,0228	0,0222	0,0217	0,0212	0,0207	0,0202	0,0197	0,0192	0,0188	0,0183
-1,9	0,0287	0,0281	0,0274	0,0268	0,0262	0,0256	0,0250	0,0244	0,0239	0,0233
-1,8	0,0359	0,0351	0,0344	0,0336	0,0329	0,0322	0,0314	0,0307	0,0301	0,0294
-1,7	0,0446	0,0436	0,0427	0,0418	0,0409	0,0401	0,0392	0,0384	0,0375	0,0367
-1,6	0,0548	0,0537	0,0526	0,0516	0,0505	0,0495	0,0485	0,0475	0,0465	0,0455
-1,5	0,0668	0,0655	0,0643	0,0630	0,0618	0,0606	0,0594	0,0582	0,0571	0,0559
-1,4	0,0808	0,0793	0,0778	0,0764	0,0749	0,0735	0,0721	0,0708	0,0694	0,0681
-1,3	0,0968	0,0951	0,0934	0,0918	0,0901	0,0885	0,0869	0,0853	0,0838	0,0823
-1,2	0,1151	0,1131	0,1112	0,1093	0,1075	0,1056	0,1038	0,1020	0,1003	0,0985
-1,1	0,1357	0,1335	0,1314	0,1292	0,1271	0,1251	0,1230	0,1210	0,1190	0,1170
-1,0	0,1587	0,1562	0,1539	0,1515	0,1492	0,1469	0,1446	0,1423	0,1401	0,1379
-0,9	0,1841	0,1814	0,1788	0,1762	0,1736	0,1711	0,1685	0,1660	0,1635	0,1611
-0,8	0,2119	0,2090	0,2061	0,2033	0,2005	0,1977	0,1949	0,1922	0,1894	0,1867
-0,7	0,2420	0,2389	0,2358	0,2327	0,2296	0,2266	0,2236	0,2206	0,2177	0,2148
-0,6	0,2743	0,2709	0,2676	0,2643	0,2611	0,2578	0,2546	0,2514	0,2483	0,2451
-0,5	0,3085	0,3050	0,3015	0,2981	0,2946	0,2912	0,2877	0,2843	0,2810	0,2776
-0,4	0,3446	0,3409	0,3372	0,3336	0,3300	0,3264	0,3228	0,3192	0,3156	0,3121
-0,3	0,3821	0,3783	0,3745	0,3707	0,3669	0,3632	0,3594	0,3557	0,3520	0,3483
-0,2	0,4207	0,4168	0,4129	0,4090	0,4052	0,4013	0,3974	0,3936	0,3897	0,3859
-0,1	0,4602	0,4562	0,4522	0,4483	0,4443	0,4404	0,4364	0,4325	0,4286	0,4247
0,0	0,5000	0,4960	0,4920	0,4880	0,4840	0,4801	0,4761	0,4721	0,4681	0,4641

Los valores interiores representan la probabilidad de obtener valores de Z menores o iguales que la puntuación típica, z , definida por el cruce de la fila con la columna indicativa del segundo decimal. Así, la probabilidad de obtener puntuaciones menores o iguales que $-2,04$ es $0,0207$. Es decir: $P(Z \leq -2,04) = 0,0207$.

Tabla A (continuación)

Distribución normal $P(Z \leq z)$

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998

Los números interiores representan la probabilidad de obtener valores de Z menores o iguales que la puntuación típica, z, definida por el cruce de la fila con la columna indicativa del segundo decimal. Así, la probabilidad de obtener puntuaciones menores o iguales que 2,04 es 0,9793. Es decir: $P(Z \leq 2,04) = 0,9793$.

Tabla B

Probabilidad de que las puntuaciones típicas en dos formas del test sean iguales o inferiores a z , supuesto que la correlación entre ambas es igual a KR21.

$$P(z_1 \leq z, z_2 \leq z)$$

z	KR21 = 0,10	0,20	0,30	0,40	0,50	0,60	0,70	0,80	0,90
-2,00	0,0009	0,0014	0,0020	0,0029	0,0041	0,0055	0,0074	0,0098	0,0134
-1,90	0,0013	0,0020	0,0030	0,0041	0,0056	0,0075	0,0098	0,0129	0,0173
-1,80	0,0020	0,0030	0,0042	0,0058	0,0077	0,0100	0,0130	0,0168	0,0221
-1,70	0,0030	0,0043	0,0059	0,0079	0,0104	0,0133	0,0170	0,0216	0,0281
-1,60	0,0044	0,0061	0,0083	0,0108	0,0139	0,0175	0,0220	0,0276	0,0353
-1,50	0,0063	0,0086	0,0113	0,0145	0,0183	0,0228	0,0282	0,0349	0,0440
-1,40	0,0090	0,0119	0,0154	0,0193	0,0239	0,0293	0,0357	0,0436	0,0543
-1,30	0,0126	0,0163	0,0205	0,0254	0,0309	0,0374	0,0449	0,0541	0,0664
-1,20	0,0173	0,0219	0,0271	0,0329	0,0396	0,0471	0,0559	0,0665	0,0806
-1,10	0,0234	0,0291	0,0353	0,0423	0,0500	0,0587	0,0688	0,0809	0,0969
-1,00	0,0313	0,0381	0,0455	0,0536	0,0625	0,0725	0,0840	0,0976	0,1155
-0,90	0,0413	0,0492	0,0578	0,0671	0,0773	0,0887	0,1015	0,1167	0,1365
-0,80	0,0536	0,0628	0,0726	0,0832	0,0947	0,1073	0,1216	0,1383	0,1600
-0,70	0,0685	0,0791	0,0902	0,1020	0,1147	0,1286	0,1442	0,1625	0,1860
-0,60	0,0865	0,0983	0,1106	0,1237	0,1376	0,1527	0,1696	0,1893	0,2145
-0,50	0,1078	0,1207	0,1342	0,1483	0,1633	0,1796	0,1976	0,2186	0,2453
-0,40	0,1324	0,1464	0,1609	0,1760	0,1920	0,2092	0,2282	0,2503	0,2784
-0,30	0,1606	0,1755	0,1908	0,2067	0,2235	0,2415	0,2614	0,2843	0,3135
-0,20	0,1924	0,2079	0,2239	0,2404	0,2577	0,2763	0,2968	0,3204	0,3504
-0,10	0,2276	0,2435	0,2598	0,2767	0,2944	0,3134	0,3343	0,3583	0,3888
0,00	0,2659	0,2821	0,2985	0,3155	0,3333	0,3524	0,3734	0,3976	0,4282
0,10	0,3072	0,3232	0,3395	0,3564	0,3741	0,3930	0,4139	0,4379	0,4684
0,20	0,3509	0,3664	0,3824	0,3989	0,4162	0,4348	0,4553	0,4789	0,5089
0,30	0,3965	0,4113	0,4288	0,4426	0,4593	0,4773	0,4972	0,5202	0,5493
0,40	0,4433	0,4573	0,4718	0,4869	0,5028	0,5200	0,5391	0,5612	0,5893
0,50	0,4907	0,5036	0,5171	0,5312	0,5462	0,5625	0,5805	0,6015	0,6283
0,60	0,5380	0,5498	0,5621	0,5752	0,5891	0,6042	0,6211	0,6408	0,6660
0,70	0,5846	0,5951	0,6062	0,6181	0,6308	0,6447	0,6603	0,6786	0,7021
0,80	0,6298	0,6391	0,6489	0,6595	0,6710	0,6836	0,6979	0,7146	0,7363
0,90	0,6731	0,6811	0,6897	0,6990	0,7092	0,7205	0,7334	0,7486	0,7684
1,00	0,7140	0,7208	0,7282	0,7363	0,7452	0,7552	0,7667	0,7803	0,7982
1,10	0,7521	0,7577	0,7640	0,7709	0,7787	0,7874	0,7975	0,8096	0,8255
1,20	0,7872	0,7918	0,7970	0,8028	0,8094	0,8169	0,8257	0,8363	0,8504
1,30	0,8190	0,8227	0,8269	0,8318	0,8373	0,8438	0,8513	0,8605	0,8728
1,40	0,8475	0,8504	0,8538	0,8578	0,8624	0,8678	0,8742	0,8821	0,8928
1,50	0,8727	0,8750	0,8777	0,8809	0,8847	0,8892	0,8946	0,9012	0,9103
1,60	0,8948	0,8965	0,8987	0,9012	0,9043	0,9079	0,9124	0,9180	0,9257
1,70	0,9139	0,9152	0,9168	0,9188	0,9212	0,9242	0,9279	0,9325	0,9389
1,80	0,9302	0,9311	0,9324	0,9339	0,9358	0,9382	0,9411	0,9449	0,9503
1,90	0,9439	0,9446	0,9455	0,9467	0,9482	0,9500	0,9524	0,9555	0,9598

Tabla C
Tablas de Taylor-Russell

Razón de idoneidad = 0,05

<i>r</i>	<i>Razón de selección</i>										
	0,05	0,10	0,20	0,30	0,40	0,50	0,60	0,70	0,80	0,90	0,95
0,00	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05
0,05	0,06	0,06	0,06	0,06	0,06	0,05	0,05	0,05	0,05	0,05	0,05
0,10	0,07	0,07	0,07	0,06	0,06	0,06	0,06	0,05	0,05	0,05	0,05
0,15	0,09	0,08	0,07	0,07	0,07	0,06	0,06	0,06	0,05	0,05	0,05
0,20	0,11	0,09	0,08	0,08	0,07	0,07	0,06	0,06	0,06	0,05	0,05
0,25	0,12	0,11	0,09	0,08	0,08	0,07	0,07	0,06	0,06	0,05	0,05
0,30	0,14	0,12	0,10	0,09	0,08	0,07	0,07	0,06	0,06	0,05	0,05
0,35	0,17	0,14	0,11	0,10	0,09	0,08	0,07	0,06	0,06	0,05	0,05
0,40	0,19	0,16	0,12	0,10	0,09	0,08	0,07	0,07	0,06	0,05	0,05
0,45	0,22	0,17	0,13	0,11	0,10	0,08	0,08	0,07	0,06	0,06	0,05
0,50	0,24	0,19	0,15	0,12	0,10	0,09	0,08	0,07	0,06	0,06	0,05
0,55	0,28	0,22	0,16	0,13	0,11	0,09	0,08	0,07	0,06	0,06	0,05
0,60	0,31	0,24	0,17	0,13	0,11	0,09	0,08	0,07	0,06	0,06	0,05
0,65	0,35	0,26	0,18	0,14	0,11	0,10	0,08	0,07	0,06	0,06	0,05
0,70	0,39	0,29	0,20	0,15	0,12	0,10	0,08	0,07	0,06	0,06	0,05
0,75	0,44	0,32	0,21	0,15	0,12	0,10	0,08	0,07	0,06	0,06	0,05
0,80	0,50	0,35	0,22	0,16	0,12	0,10	0,08	0,07	0,06	0,06	0,05
0,85	0,56	0,39	0,23	0,16	0,12	0,10	0,08	0,07	0,06	0,06	0,05
0,90	0,64	0,43	0,24	0,17	0,13	0,10	0,08	0,07	0,06	0,06	0,05
0,95	0,73	0,47	0,25	0,17	0,13	0,10	0,08	0,07	0,06	0,06	0,05
1,00	1,00	0,50	0,25	0,17	0,13	0,10	0,08	0,07	0,06	0,06	0,05

Razón de idoneidad = 0,10

<i>r</i>	<i>Razón de selección</i>										
	0,05	0,10	0,20	0,30	0,40	0,50	0,60	0,70	0,80	0,90	0,95
0,00	0,10	0,10	0,10	0,10	0,10	0,10	0,10	0,10	0,10	0,10	0,10
0,05	0,12	0,12	0,11	0,11	0,11	0,11	0,11	0,10	0,20	0,10	0,10
0,10	0,14	0,13	0,13	0,12	0,12	0,11	0,11	0,11	0,11	0,10	0,10
0,15	0,16	0,15	0,14	0,13	0,13	0,12	0,12	0,11	0,11	0,10	0,10
0,20	0,19	0,17	0,15	0,14	0,14	0,13	0,12	0,12	0,11	0,11	0,10
0,25	0,22	0,19	0,17	0,16	0,14	0,13	0,13	0,12	0,11	0,11	0,10
0,30	0,25	0,22	0,19	0,17	0,15	0,14	0,13	0,12	0,12	0,11	0,10
0,35	0,28	0,24	0,20	0,18	0,16	0,15	0,14	0,13	0,12	0,11	0,10
0,40	0,31	0,27	0,22	0,19	0,17	0,16	0,14	0,13	0,12	0,11	0,10
0,45	0,35	0,29	0,24	0,20	0,18	0,16	0,15	0,13	0,12	0,11	0,10
0,50	0,39	0,32	0,26	0,22	0,19	0,17	0,15	0,13	0,12	0,11	0,11
0,55	0,43	0,36	0,28	0,23	0,20	0,17	0,15	0,14	0,12	0,11	0,11
0,60	0,48	0,39	0,30	0,25	0,21	0,18	0,16	0,14	0,12	0,11	0,11
0,65	0,53	0,43	0,32	0,26	0,22	0,18	0,16	0,14	0,12	0,11	0,11
0,70	0,58	0,47	0,35	0,27	0,22	0,19	0,16	0,14	0,12	0,11	0,11
0,75	0,64	0,51	0,37	0,29	0,23	0,19	0,16	0,14	0,12	0,11	0,11
0,80	0,71	0,56	0,40	0,30	0,24	0,20	0,17	0,14	0,12	0,11	0,11
0,85	0,78	0,62	0,43	0,31	0,25	0,20	0,17	0,14	0,12	0,11	0,11
0,90	0,86	0,69	0,46	0,33	0,35	0,20	0,17	0,14	0,12	0,11	0,11
0,95	0,95	0,78	0,49	0,33	0,25	0,20	0,17	0,14	0,12	0,11	0,11
1,00	1,00	1,00	0,50	0,33	0,25	0,20	0,17	0,14	0,13	0,11	0,11

Tabla C
Tablas de Taylor-Russell (continuación)

Razón de idoneidad = 0,30

<i>r</i>	<i>Razón de selección</i>										
	0,05	0,10	0,20	0,30	0,40	0,50	0,60	0,70	0,80	0,90	0,95
0,00	0,30	0,30	0,30	0,30	0,30	0,30	0,30	0,30	0,30	0,30	0,30
0,05	0,34	0,33	0,33	0,32	0,32	0,31	0,31	0,31	0,31	0,30	0,30
0,10	0,38	0,36	0,35	0,34	0,33	0,33	0,32	0,32	0,31	0,31	0,30
0,15	0,42	0,40	0,38	0,36	0,35	0,34	0,33	0,33	0,32	0,31	0,31
0,20	0,46	0,43	0,40	0,38	0,37	0,36	0,34	0,33	0,32	0,31	0,31
0,25	0,50	0,47	0,43	0,41	0,39	0,37	0,36	0,34	0,33	0,32	0,31
0,30	0,54	0,50	0,46	0,43	0,40	0,38	0,37	0,35	0,33	0,32	0,31
0,35	0,58	0,54	0,49	0,45	0,42	0,40	0,38	0,36	0,34	0,32	0,31
0,40	0,63	0,58	0,51	0,47	0,44	0,41	0,39	0,37	0,34	0,32	0,31
0,45	0,67	0,61	0,55	0,50	0,46	0,43	0,40	0,37	0,35	0,32	0,31
0,50	0,72	0,65	0,58	0,52	0,48	0,44	0,41	0,38	0,35	0,33	0,31
0,55	0,76	0,69	0,61	0,55	0,50	0,46	0,42	0,39	0,36	0,33	0,31
0,60	0,81	0,74	0,64	0,58	0,52	0,47	0,43	0,40	0,36	0,33	0,31
0,65	0,85	0,78	0,68	0,60	0,54	0,49	0,44	0,40	0,37	0,33	0,32
0,70	0,89	0,82	0,72	0,63	0,57	0,51	0,46	0,41	0,37	0,33	0,32
0,75	0,93	0,86	0,76	0,67	0,59	0,52	0,47	0,42	0,37	0,33	0,32
0,80	0,96	0,90	0,80	0,70	0,62	0,54	0,48	0,42	0,37	0,33	0,32
0,85	0,99	0,94	0,85	0,74	0,65	0,56	0,49	0,43	0,37	0,33	0,32
0,90	1,00	0,98	0,90	0,79	0,68	0,58	0,49	0,43	0,37	0,33	0,32
0,95	1,00	1,00	0,96	0,85	0,72	0,60	0,50	0,43	0,37	0,33	0,32
1,00	1,00	1,00	1,00	1,00	0,75	0,60	0,50	0,43	0,38	0,33	0,32

Razón de idoneidad = 0,50

<i>r</i>	<i>Razón de selección</i>										
	0,05	0,10	0,20	0,30	0,40	0,50	0,60	0,70	0,80	0,90	0,95
0,00	0,50	0,50	0,50	0,50	0,50	0,50	0,50	0,50	0,50	0,50	0,50
0,05	0,54	0,53	0,53	0,52	0,52	0,51	0,51	0,51	0,51	0,50	0,50
0,10	0,58	0,57	0,56	0,55	0,54	0,53	0,53	0,52	0,51	0,51	0,50
0,15	0,63	0,61	0,58	0,57	0,56	0,55	0,54	0,53	0,52	0,51	0,51
0,20	0,67	0,64	0,61	0,59	0,58	0,56	0,55	0,54	0,53	0,52	0,51
0,25	0,70	0,67	0,64	0,62	0,60	0,58	0,56	0,55	0,54	0,52	0,51
0,30	0,74	0,71	0,67	0,64	0,62	0,60	0,58	0,56	0,54	0,52	0,51
0,35	0,78	0,74	0,70	0,66	0,64	0,61	0,59	0,57	0,55	0,53	0,51
0,40	0,82	0,78	0,73	0,69	0,66	0,63	0,61	0,58	0,56	0,53	0,52
0,45	0,85	0,81	0,75	0,71	0,68	0,65	0,62	0,59	0,56	0,53	0,52
0,50	0,88	0,84	0,78	0,74	0,70	0,67	0,63	0,60	0,57	0,54	0,52
0,55	0,91	0,87	0,81	0,76	0,72	0,69	0,65	0,61	0,58	0,54	0,52
0,60	0,94	0,90	0,84	0,79	0,75	0,70	0,66	0,62	0,59	0,54	0,52
0,65	0,96	0,92	0,87	0,82	0,77	0,73	0,68	0,64	0,59	0,55	0,52
0,70	0,98	0,95	0,90	0,85	0,80	0,75	0,70	0,65	0,60	0,55	0,53
0,75	0,99	0,97	0,92	0,87	0,82	0,77	0,72	0,66	0,61	0,55	0,53
0,80	1,00	0,99	0,95	0,90	0,85	0,80	0,73	0,67	0,61	0,55	0,53
0,85	1,00	0,99	0,95	0,94	0,88	0,82	0,76	0,69	0,62	0,55	0,53
0,90	1,00	1,00	0,99	0,97	0,92	0,86	0,78	0,70	0,62	0,56	0,53
0,95	1,00	1,00	1,00	0,99	0,96	0,90	0,81	0,71	0,63	0,56	0,53
1,00	1,00	1,00	1,00	1,00	1,00	1,00	0,83	0,71	0,63	0,56	0,53

REFERENCIAS BIBLIOGRÁFICAS

- AIKEN, L. R. (1996). *Rating scales and checklists: Evaluating behavior, personality, and attitudes*. Nueva York: John Wiley & Sons, Inc.
- ALONSO, L. E. (1998). *La mirada cualitativa en Sociología*. Madrid: Fundamentos.
- ALTMANN, J. (1974). Observational study of behavior: Sampling methods. *Behaviour*, 49, 227-267.
- AMERICAN EDUCATIONAL RESEARCH ASSOCIATION, AMERICAN PSYCHOLOGICAL ASSOCIATION y NATIONAL COUNCIL ON MEASUREMENT IN EDUCATION (1985). *Standards for educational and psychological testing*. Washington, DC: American Psychological Association.
- (1999). *Standards for educational and psychological testing*. Washington, DC: American Educational Research Association.
- ANASTASI, A. (1986). Evolving concepts of test validation. *Annual Review of Psychology*, 37, 1-15.
- ANGUERA, M. T. (1983). *Manual de prácticas de observación*. México: Trillas.
- (1988). *Observación en la escuela*. Barcelona: Graó.
- (1989). *Metodología de la observación en las Ciencias Humanas*. (4.^a ed.). Madrid: Cátedra.
- (1990). Metodología observacional. En J. Arnau, M. T. Anguera y J. Gómez. *Metodología de la investigación en Ciencias del Comportamiento* (pp. 123-236). Murcia: Universidad de Murcia.
- (1995). Metodología cualitativa. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez, J. Pascual y G. Vallejo (Eds.), *Métodos de investigación en Psicología*. Madrid: Síntesis.
- ANGUERA, M. T., ARNAU, J., ATO, M., MARTÍNEZ, R., PASCUAL, J. y VALLEJO, G. (1995). *Métodos de investigación en Psicología*. Madrid: Síntesis.
- ARCHBALD, D. A. y NEWMANN, F. M. (1992). Approaches to assessing academic achievement. En H. Berlak, F. M. Newmann, E. Adam, D. A. Archbald, T. Burgess, J. Raven y T. A. Romberg (Eds.), *Toward a new science of educational testing and assessment*. Albany: State University of New York Press.
- ARNAU, J. (1995). Metodología de la investigación psicológica. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.
- ATO, M. (1991). *Investigación en Ciencias del Comportamiento. I. Fundamentos*. Barcelona: PPU.

- BABBIE, E. (1990). *Survey research methods*. Belmont: Wadsworth.
- BAIRD, J. C. y Noma, E. (1978). *Fundamentals of scaling and psychophysics*. Nueva York: John Wiley & Sons.
- BAKEMAN, R. y GOTTMAN, J. M. (1989). *Observación de la interacción: Introducción al análisis secuencial*. Madrid: Morata (versión original: *Observing interaction: An introduction to sequential analysis*. Cambridge: Cambridge University Press, 1986).
- BAKEMAN, R. y QUERA, V. (1996). *Análisis de la interacción: Análisis secuencial con SDIS y GSEQ*. Madrid: Ra-Ma. (versión original: *Analyzing Interaction: Sequential Analysis with SDIS y GSEQ*. Cambridge: Cambridge University Press, 1995).
- BAKEMAN, R. y ROBINSON, B. F. (1994). *Understanding log-linear analysis with ILOG: An interactive approach*. Hillsdale, NJ: Erlbaum.
- BARTHOLOMEW, D. J. (1996). *The statistical approach to social measurement*. San Diego: Academic Press.
- BEHAR, J. y RIBA, C. (1993). Sesgos del observador y de la observación. En M. T. Anguera (Ed.), *Metodología observacional en la investigación psicológica*. Vol 2. *Fundamentación* (pp. 15-128). Barcelona: PPU.
- BENNETT, R. E. y WARD, W. C. (Eds.) (1993). *Construction versus choice in cognitive measurement*. Hillsdale, NJ: Lawrence Earlbaum Associates.
- BLANCO, M. J. (1996). *Psicofísica*. Madrid: Universitat.
- BLOOM, B. S. y col. (1956). *Taxonomy of educational objectives I: Cognitive domain*. Nueva York: McKay.
- BLOOM, B. S., Madaus, G. F. y Hastings, J. T. (1981). *Evaluation to improve learning*. Nueva York: McGraw-Hill.
- BORING, E. G. (1945). The use of operational definitions in science. *Psychological Review*, 52, 243-245.
- BRIDGMAN, P. W. (1927). *The logic of modern physics*. Nueva York: Macmillan.
- BROWN, W. (1910). Some experimental results in the correlation of mental abilities. *British Journal of Psychology*, 3, 296-232.
- BUENDÍA, L. (1997). La investigación por encuesta. En L. Buendía, P. Colás y F. Hernández, *Métodos de investigación en Psicopedagogía*. Madrid: McGraw-Hill.
- BUNGE, M. (1989). *La investigación científica*. Barcelona: Ariel.
- CAMPBELL, N. R. (1920). *Physics. The elements*. Cambridge: Cambridge University Press.
- CAMPBELL, D. T. y FISKE, D. W. (1959). Convergent and discriminant validation by the multitrait-multimethod matrix. *Psychological Bulletin*, 56, 81-105.
- CAMPBELL, D. T. y STANLEY, J. C. (1966). *Experimental and quasi-experimental designs for research*. Chicago, IL: Rand McNally. (Traducción española: *Diseños experimentales y cuasi experimentales en la investigación social*. Amorrortu, Buenos Aires, 1973).
- CAPARRÓS, A. (1984). *La Psicología y sus perfiles. Introducción a la cultura psicológica*. Barcelona: Barcanova.
- CARMINES, E. G. y ZELLER, R. A. (1988). *Reliability and validity assessment*. Sage.
- CASTRO, C. DE (1980). *Teoría de la medida en Psicología y Ciencias Sociales*. Caracas, Universidad Central de Venezuela: Ediciones de la Facultad de Humanidades y Educación.
- CHALMERS, A. F. (1987). *¿Qué es esa cosa llamada ciencia?* Madrid: Siglo XXI.

- COHEN, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20, 37-46.
- CONDE, F. (1990). Las perspectivas cuantitativa y cualitativa en la investigación social. *Revista Española de Investigaciones Sociológicas*, 51, 91-117.
- (1996). Los grupos triangulares como espacios transicionales para la producción discursiva. Anexo C. En F. Conde, *La vivienda en Huelva. Culturas e identidades urbanas* (pp. 275-307). Sevilla: Junta de Andalucía-Fundación El Monte.
- CONVERSE, J. M. y PRESSER, S. (1986). *Survey questions. Handcrafting the standardized questionnaire*. Beverly Hills: Sage.
- COOK, T. D. y CAMPBELL, D. T. (1979). *Quasi experimentation: Design and analysis for field experiments*. Boston: Houghton Mifflin.
- COOK, T. D., CAMPBELL, D. T. y PERACCHIO, L. (1990). Quasi experimentation. En M. D. Dunnette y L. M. Hough (Eds.), *Handbook of industrial and organizational psychology* (Vol. I, 2.^a ed., pp. 491-576). Palo Alto, CA: Consulting Psychologist Press, Inc.
- COSTA, P. T. y MCCRAE, R. R. (1992). *NEO-PI-R. Professional Manual*. Odessa, FL: Psychological Assessment Resources.
- CROCKER, L. y ALGINA, J. (1986). *Introduction to classical and modern test theory*. Nueva York: Holt, Rinehart and Winston.
- CRONBACH, L. J. (1951). Coefficient alpha and the internal structure of test. *Psychometrika*, 16(3), 297-334.
- (1971). Test validation. En R. L. Thorndike (Ed.), *Educational Measurement*. Washington: American Council on Education.
- DAWES, R. M. (1972). *Fundamentals of attitude measurement*. Nueva York: Wiley.
- ECHEVERRÍA, J. (1989). *Introducción a la metodología de la ciencia*. Barcelona: Barcanova.
- EKMAN, P. W. y FRIESEN, W. (1978). *Manual for the facial action coding system*. Palo Alto, CA: Consulting Psychologist Press.
- EMBRETSON, S. (1985). Studying intelligence with test theory models. *Current Topics in Human Intelligence*, 1, 98-140.
- FERNÁNDEZ, J. S. y ROJAS, A. J. (1998a). El informe de investigación. En A. J. Rojas, J. S. Fernández y C. Pérez (Eds.), *Investigar mediante encuestas: Fundamentos teóricos y aspectos prácticos*. Madrid: Síntesis.
- (1998b). Trabajo de campo. En A. J. Rojas, J. S. Fernández y C. Pérez (Eds.), *Investigar mediante encuestas: Fundamentos teóricos y aspectos prácticos*. Madrid: Síntesis.
- FERRANDO, P. J. (1993). *Introducción al análisis factorial*. Barcelona: PPU.
- FIDALGO, A. M. (1999). *Proyecto Docente de Diseños de Investigación*. Universidad de Oviedo.
- FISHMAN, G. S. (1973). *Concepts and methods in discrete event digital simulation*. Nueva York: John Wiley & Sons. (Traducción española: Conceptos y métodos en la simulación digital de eventos discretos. México: Limusa, 1978).
- FOWLER, F. (1995). *Improving survey questions: Design and evaluation*. Thousand Oaks: Sage.
- GAVIRIA, E. (1992). *Relaciones de dominancia y equidad en niños de edad preescolar*. Tesis Doctoral no publicada. UNED.
- (1994). Aproximación naturalista a la conducta social infantil: El intercambio de recursos en preescolares. *Revista de Psicología Social*, 9, 2, 115-128.

- GÓMEZ, J. (1990). Metodología de encuesta por muestreo. En J. Arnau, M. T. Anguera y J. Gómez, *Metodología de la investigación en Ciencias del Comportamiento*. Murcia: Universidad de Murcia.
- GOTTMAN, J. M. y ROY, A. K. (1990). *Sequential analysis. A guide for behavioral scientists*. Nueva York: Cambridge University Press.
- GOVINDARAJULU, Z. (1988). Alternative methods for combining several test scores. *Educational and Psychological Measurement*, 48, 53-60.
- GRONLUND, N. E. (1991). *How to construct achievement tests*. New Jersey: Prentice-Hall.
- GUILFORD, J. P. (1936/1954). *Psychometric methods*. Nueva York: MacGraw-Hill.
- GULLIKSEN, H. (1950). *Theory of mental tests*. Hillsdale, NJ: Lawrence Ealbaum Associates.
- HALADYNA, T. M. (1994). *Developing and validating multiple-choice test items*. Hillsdale, NJ: Lawrence Earlbaum Associates.
- HALADYNA, T. M. y DOWNING, S. M. (1989). A taxonomy of multiple-choice item-writing rules. *Applied Measurement in Education*, 2(1), 37-50.
- HAMBLETON, R. K. (1980). Test score validity and standard setting methods. En R. A. Berk (Ed.), *Criterion-referenced measurement: The state of the art*. Baltimore: Johns Hopkins University Press.
- (1985). Criterion-referenced assessment of individual differences. En C. Reynolds y V. L. Willson (Eds.), *Methodologies and statistical advances in the study of individual differences*. Nueva York: Plenum.
- HAMBLETON, R. K. y EIGNOR, D. R. (1980). Competency test development, validation and standard setting. En R. M. Jaeger y C. K. Tittle (Eds.), *Minimum competency testing: Motives, models, measures and consequences*. Berkely, CA: McCutchan.
- HAMBLETON, R. K. y MURPHY, E. (1992). A psychometric perspective on authentic measurement. *Applied Measurement in Education*, 5(1), 1-16.
- HEMPEL, C. G. (1978). *Filosofía de la Ciencia Natural*. Madrid: Alianza Universidad.
- HOPKINS, K. D. (1998). *Educational and psychological measurement and evaluation*. Boston: Allyn & Bacon.
- HUME, D. (1748). *An enquiry concerning human understanding*. Amhrest, NY: Prometheus, 1966. (Traducción española: *Investigaciones sobre el conocimiento humano*. Madrid: Alianza, 1997).
- (1749). *A treatise of human nature*. Oxford: Clarendon Press, 1965. (Traducción española: *Tratado de la naturaleza humana* (Vol. I y II). Madrid: Ediciones Orbis, 1984).
- HUYNH, H. (1976). Statistical considerations of mastery scores. *Psychometrika*, 41, 65-78.
- JAEGER, R. M. (1987). Two decades of revolution in educational measurement? *Educational Measurement: Issues and Practice*, 4, 6-14.
- JAÑEZ, L. (1989). *Fundamentos de Psicología Matemática*. Madrid: Pirámide.
- JONES, L. V. (1971). The nature of measurement. En R. L. Thorndike (Ed.), *Educational Measurement*. Washington: American Council on Education.
- KAZDIN, A. E. (1977). Artifact, bias and complexity of assessment: The ABCs of reliability. *Journal of Applied Behavior Analysis*, 10(1), 141-150.
- (1978). *Modificación de la conducta y sus aplicaciones prácticas*. México: El manual moderno.

- (1992). *Research design in clinical psychology* (2.^a ed.). Boston: Allyn & Bacon.
- KAZDIN, A. E. y KLOCK, J. (1973). The effect of nonverbal teacher approval on student attentive behavior. *Journal of Applied Behavior Analysis*, 6, 643-654.
- KERLINGER, F. N. (1987). *Investigaciones del comportamiento. Técnicas y metodología* (2.^a ed.). México: Editorial Interamericana.
- KISH, L. (1987). *Statistical design for research*. Nueva York: John Wiley & Sons.
- KRANTZ, D. H., LUCE, R. D., SUPPES, P. y TVERSKY, A. (1971). *Foundations of measurement*. Nueva York: Academic Press.
- KUDER, G. F. y RICHARDSON, M. W. (1937). The theory of estimation of test reliability. *Psychometrika*, 2, 151-160.
- LAMO DE ESPINOSA, E. (1996). *Sociedades de cultura, sociedades de ciencia*. Oviedo: Nobel.
- LAUDAN, L. (1986). *El progreso y sus problemas. Hacia una teoría del crecimiento científico*. Madrid: Encuentro ediciones.
- LORD, F. M. (1952). A theory of test scores. *Psychometric Monograph*, 7.
- (1980). *Applications of item response theory to practical testing problems*. Hillsdale, NJ: Lawrence Earlbaum Associates.
- LORD, F. M. y NOVICK, M. R. (1968). *Statistical theories of mental test scores*. Nueva York: Addison Wesley.
- LUCE, R. D., KRANTZ, D. H., SUPPES, P. y TVERSKY, A. (1990). *Foundations of measurement*. Nueva York: Academic Press.
- MAANEN, J. VAN (1983). *Qualitative methodology*. Sage.
- MANZANO, V. (1997). *SOTAM: Sistema de Optimización para el Tamaño de la Muestra*. V Congreso de Metodología de las CC. Humanas y Sociales. Sevilla, Septiembre de 1997.
- (1998). La calidad del muestreo en las investigaciones sociales. *Revista Electrónica de Metodología Aplicada*, 3(1). Disponible en Internet: <http://www.uniovi.es/~Psi/v3n1/>
- MARCANTONIO, R. J. y COOK, T. D. (1994). Convincing quasi-experiments: The interrupted time series and regression-discontinuity designs. En J. S. Wholey, H. P. Hartry y K. E. Newcomer (Eds.), *Handbook of practical program evaluation* (pp. 147-169). San Francisco, CA: Jossey-Bass.
- MARTÍNEZ ARIAS, M. R. (1995a). *Psicometría: Teoría de los tests psicológicos y educativos*. Madrid: Síntesis.
- (1995b). Diseños muestrales probabilísticos. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.
- (1995c). El método de encuestas por muestreo: Conceptos básicos. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.
- (1995d). Las decisiones posteriores al muestreo. En M. T. Anguera, J. Arnau, M. Ato, R. Martínez Arias, J. Pascual y G. Vallejo, *Métodos de investigación en Psicología*. Madrid: Síntesis.
- MCCALL, W. A. (1939). *Measurement*. Nueva York: Macmillan.
- MCDONALD, R. P. (1999). *Test theory: A unified treatment*. Mahwah, NJ: Lawrence Earlbaum Associates.
- MEHRENS, W. A. y LEHMANN, I. J. (1991). *Measurement and evaluation in education and psychology*. Chicago: Holt, Rinehart and Winston, Inc.

- MELIÁ, J. L. (1990). *Introducción a la medición*. Valencia: Cristóbal Serrano.
- (1991). *Métodos de escalamiento unidimensional*. Valencia: Cristóbal Serrano.
- (1993). *Apuntes sobre teoría clásica de textos*. Valencia: Cristóbal Serrano.
- (2000). *Teoría de la fiabilidad y la validez*. Valencia: Cristóbal Serrano.
- MELTZOFF, J. (2000). *El pensamiento crítico en la investigación*. Madrid: Alianza.
- MESSICK, S. (1989). Validity. En R. L. Linn (Ed.), *Educational measurement*. Nueva York: Macmillan.
- (1995). Standards of validity and the validity of standards in performance assessment. *Educational Measurement: Issues and Practice*, 14(4), 5-8.
- MORENO, R., MARTÍNEZ, R. J. y CHACÓN, S. (2000). *Fundamentos metodológicos en Psicología y Ciencias afines*. Madrid: Pirámide.
- MUÑIZ, J. (1998). *Teoría clásica de los tests*. Madrid: Pirámide.
- MUÑIZ, J. y HAMBLETON, R. K. (1992). Medio siglo de teoría de respuesta a los ítems. *Anuario de Psicología*, 52, 41-66.
- MURRAY, H. A. (1938). *Explorations in personality*. Nueva York: Oxford University Press.
- NOVICK, M. R. (1984). Importance of professional standards for fair and appropriate test use. En C. W. Dawes (Dir.), *The uses and misuses of tests*. San Francisco: Jossey-Bass.
- OLEA, J. y HONTANGAS, P. (1999). Tests informatizados de primera generación. En J. Olea, V. Ponsoda y G. Prieto (Eds.), *Tests informatizados*. Madrid: Pirámide.
- ORTÍ, A. (1993). El proceso de investigación de la conducta como proceso integral, complementariedad de las técnicas cuantitativas y de las prácticas cualitativas en el análisis de las drogodependencias. En *Drogodependencias. Perspectivas sociológicas*. Madrid: Colegio de Doctores y Licenciados en Ciencias Políticas y Sociología.
- OSTERLIND, S. J. (1989). *Constructing test items*. Boston: Kluwer Academic Publishers.
- PAYNE, S. (1951). *The art of asking questions*. Princeton, NJ: Princeton University Press.
- PENG, C. J. y SUBKOVIAK, M. J. (1980). A note on Huynh's normal approximation procedure for estimating criterion-referenced reliability. *Journal of Educational Measurement*, 17, 359-368.
- PFANZAGL, J. (1971). *Theory of measurement*. Würzburg: Physica-Verlag.
- PINILLOS, J. L. (1988). *Psicología y Psicohistoria. Escritos seleccionados*. Universidad de Valencia.
- POPHAM, W. J. (1975). *Educational evaluation*. Englewood Cliffs, NJ: Prentice-Hall.
- (1978). *Criterion-referenced measurement*. Englewood Cliffs, NJ: Prentice-Hall.
- PRIETO, G. y DELGADO, A. (1996). Construcción de los ítems. En J. Muñiz (Coord.), *Psicometría*. Madrid: Universitas.
- QUERA, V. (1991). Muestreo y registro observacional. En M. T. Anguera (Ed.), *Metodología observacional en la investigación psicológica. Vol 1. Fundamentación*. Barcelona: PPU.
- (1993). Análisis secuencial. En M. T. Anguera (Ed.), *Metodología observacional en la investigación psicológica. Vol 2. Fundamentación*. Barcelona: PPU.
- RENOM, J. (1992). *Diseño de tests*. Barcelona: Engine.

- ROJAS, A. J. y FERNÁNDEZ, J. S. (1998). Introducción al tratamiento de datos. En A. J. Rojas, J. S. Fernández y C. Pérez (Eds.), *Investigar mediante encuestas: Fundamentos teóricos y aspectos prácticos*. Madrid: Síntesis.
- SÁNCHEZ-SARRIÓN, J. J. (2000). *La bondad de la encuesta: El caso de la no respuesta*. Madrid: Alianza.
- SANTISTEBAN, C. (1990). *Psicometría. Teoría y práctica en la construcción de tests*. Madrid: Norma.
- SARRIÀ, E. y BRIOSO, A. (1999). Categorización y observación de las funciones, morfología y características espacio-temporales de la comunicación intencional preverbal. En M. T. Anguera (Coord.), *Observación de conducta interactiva en contextos naturales: Aplicaciones*. Barcelona: Edicions de la Universitat de Barcelona.
- SAVAGE, L. W. y EHRLICH, P. (Eds.) (1990). *Philosophical and foundational issues in measurement theory*. Hillsdale, NJ: Lawrence Earlbaum Associates.
- SCHMIDT, F. L. y HUNTER, J. E. (1977). Development of a general solution to the problem of validity generalization. *Journal of Applied Psychology*, 62, 529-540.
- SCHMIDT, F. L., HUNTER, J. E. y PEARLMAN, K. (1981). Task differences as moderators of aptitude test validity in selection: A red herring. *Journal of Applied Psychology*, 66, 166-185.
- SILVA, R. (1993). *Evaluación conductual y criterios psicométricos*. Madrid: Pirámide.
- SPEARMAN, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15, 72-101.
- (1907). Demonstration of formulae for true measurement of correlation. *American Journal of Psychology*, 18, 161-169.
- (1910). Correlations calculated from faulty data. *British Journal of Psychology*, 3, 271-295.
- (1913). Correlations of sums and differences. *British Journal of Psychology*, 5, 417-426.
- (1923). *The nature of intelligence and the principles of cognition*. London: Macmillan.
- (1927). *The abilities of man*. Nueva York: Macmillan.
- STARCH, D. y ELLIOTT, E. C. (1912). Reliability of grading high school work in English. *School Review*, 20, 442-457.
- (1913). Reliability of grading high school work in Mathematics. *School Review*, 21, 254-259.
- SUBKOVIAK, M. J. (1976). Empirical investigation of procedures for estimating reliability for mastery tests. *Journal of Educational Measurement*, 15, 111-116.
- SUEN, H. K. y ARY, D. (1989). *Analyzing quantitative behavioral observation data*. Hillsdale, NJ: LEA.
- SUPPES, P., KRANTZ, D. M., LUCE, R. D. y TVERSKY, A. (1989). *Foundations of measurement*. San Diego: Academic Press.
- SUPPES, P. y ZINNES, J. L. (1963). Basic measurement theory. En R. D. Luce, R. R. Bush y E. Galanter (Eds.), *Handbook of mathematical psychology*. Nueva York: Wiley.
- TAYLOR, H. C. y RUSSELL, J. T. (1939). The relationship of validity coefficients to the practical effectiveness of tests in selection: Discussion and tables. *Journal of Applied Psychology*, 23, 565-578.

- THOMSON, T., FELCE, D. y SIMONS, F. J. (Eds.) (2000). *Behavioral observation: Technology and applications in developmental disabilities*. Baltimore: Brookes.
- THORNDIKE, R. L. (1949). *Personnel selection*. Nueva York: Wiley.
- TORGERSON, W. S. (1958/1985). *Theory and methods of scaling*. Nueva York: John Wiley & Sons.
- TROCHIM, W. M. K. (1984). *Research design for program evaluation: The regression-discontinuity approach*. Newbury Park, CA: Sage.
- WEISBERG, H. F., KROSNICK, J. A. y BOWEN, B. (1996). *An introduction to survey research, polling and data analysis*. Thousand Oaks, CA: Sage.
- WOLPE, J. (1958). *Psychoterapy by reciprocal inhibition*. Stanford, CA: Stanford University Press.
- WOOD, R. (1987). *Measurement and assessment in education and psychology*. Lewes, Sussex: Falmer Press.
- WRIGHT, B. D. (1997). A history of social science measurement. *Educational Measurement: Issues & Practice*, 16(4), 33-45.

GLOSARIO

α . Medida de la consistencia interna de la prueba que se basa en la covariación entre sus ítems.

Aleatorio. Que obedece al azar, no responde a ningún patrón sistemático de variación sino que varía sin ningún orden conocido.

Análisis de conglomerados. Técnica estadística dirigida a agrupar n elementos (las filas de una matriz) en k grupos relativamente homogéneos, teniendo en cuenta la distancia entre los mismos en un espacio de tantas dimensiones como variables medidas o la similitud de sus perfiles en dichas variables.

Análisis de covarianza. Técnica estadística que permite determinar el efecto que la variable independiente tiene sobre la variable dependiente, una vez eliminada la influencia que sobre la variable dependiente pueda tener una variable extraña conocida con el nombre de covariante.

Análisis de ítems. Estudio de la calidad métrica de cada uno de los ítems del test, que consiste en la estimación de los parámetros del ítem (dificultad, poder discriminativo, fiabilidad y validez), en el estudio del posible funcionamiento diferencial de los ítems y en el análisis de distractores (en ítems de elección múltiple).

Análisis discriminante. Técnica de clasificación en la que la variable dependiente es cualitativa y las independientes cuantitativas.

Análisis factorial. Técnica estadística que permite reducir la dimensionalidad de una matriz de datos (por ejemplo, las respuestas dadas por N sujetos a los n ítems de una prueba): posibilita pasar de una matriz de dimensión $N \times n$ a una de dimensión $N \times p$, donde $p < n$ y las n variables están medidas a nivel de intervalo.

Análisis factorial de correspondencias múltiples. Técnica estadística que se utiliza para describir las relaciones entre más de dos variables categóricas en función de la distancia entre las mismas en un espacio de pocas dimensiones. Equivalente no paramétrico del análisis factorial.

Análisis secuencial. Técnicas de análisis de datos de observación del comportamiento que permiten detectar la existencia de relaciones de contingencia tem-

poral en las ocurrencias de las categorías de conducta y descubrir la existencia de patrones sistemáticos en la dinámica del comportamiento.

Aquiescencia. Sesgo o estilo de respuesta consistente en responder sistemáticamente que se está de acuerdo (o en desacuerdo) con lo que se indica en el enunciado, al margen de lo que en él se afirma.

Asignación aleatoria. Método para asignar las unidades experimentales (habitualmente sujetos) a las condiciones experimentales (niveles de la variable independiente), que garantiza que todas las unidades experimentales tienen la misma oportunidad de aparecer en cualquier condición experimental.

Asíntota. Límite teórico al que se aproxima una curva pero que nunca llega a alcanzar.

Banco de ítems. Conjunto numeroso de ítems que miden un mismo rasgo, campo o área de conocimiento, que es almacenado en un ordenador, habitualmente en forma de una base de datos o estructura similar y que posibilita la construcción de distintas pruebas o tests.

Bloques. Agrupaciones de sujetos con valores similares en una variable extraña cuya influencia deseamos controlar.

Característica. Propiedad que manifiestan los objetos o los sujetos. Así, por ejemplo, las personas manifiestan, entre otras características, el peso, la inteligencia, la altura, la candidez, etcétera.

Categorización. Proceso de selección y definición de aquellos aspectos de la conducta o de la situación que se consideran relevantes para la investigación. La meta de este proceso consiste en diseñar un sistema de categorías.

CATI (Computer Assisted Telephone Interviewing). Sistema estructurado que facilita la realización de entrevistas telefónicas con la ayuda del ordenador. Puede incluir los procesos de selección de la muestra, la presentación del cuestionario, la grabación y el análisis de los datos.

Causa. Fundamento u origen de algo. Desde una postura empirista, el antecedente constante de un fenómeno.

Censo. Recopilación de todos los miembros de una población que poseen una determinada característica (p. ej., tener una determinada nacionalidad, haber cursado unos estudios específicos, ejercer una determinada profesión, etc.), en la que se recogen algunas de las características de todos los elementos de dicha población (p. ej., género, edad, dirección, etc.).

Centil. Puntuación del test que deja por debajo de sí un determinado porcentaje de sujetos.

Cociente Intelectual. Razón entre la edad mental y la edad cronológica multiplicada por 100.

Codificación. Proceso por el que las respuestas de los sujetos se transforman en un conjunto discreto de valores, o códigos, de modo que puedan ser analizados numéricamente.

Código. Signo o conjunto de signos que se utilizan para representar los valores de una variable o las categorías de un sistema.

Conductismo. Corriente de la Psicología que asume un principio general de mecanicismo biológico en el que la conducta se explica como producto del condicionamiento (asociaciones con estímulos a los que reacciona o que aparecen como consecuencia de ella) y que descarta la consideración (en su explicación) de procesos mentales no observables.

Confusión. Efecto sistemático provocado sobre la variable dependiente por una variable extraña que imposibilita garantizar que los cambios en la variable dependiente se deben exclusivamente a la manipulación de la variable independiente.

Congénéricas (medidas). Medidas que no satisfacen ninguna de las condiciones de paralelismo y en las que la puntuación verdadera relativa a una medida es una transformación lineal de la puntuación verdadera de la otra.

Conglomerado. Agrupación natural de elementos, personas, cosas o entidades, que poseen una característica común.

Constancia. Forma de controlar una variable extraña que se consigue haciendo que tenga el mismo nivel en todas las condiciones experimentales.

Constante. Característica que se presenta bajo un solo valor. Contrario de variable.

Constructo. Construcción teórica que hace referencia a entidades o cualidades no observables o detectables directamente.

Control estadístico. Procedimiento para controlar fuentes de varianza sistemática secundaria mediante la aplicación de correcciones estadísticas a las medidas de la variable dependiente. El análisis de la covarianza es una de las técnicas estadísticas empleadas con tal fin.

Correlación (coeficiente de). Medida de la relación conjunta o concomitante entre dos variables que indica hasta qué punto la variación de una de ellas conduce a la obtención de valores más altos (o más bajos) en la segunda.

Covariación. Cambios en una variable que coinciden sistemáticamente con cambios en otra variable.

Covarianza. Medida de la covariación de dos variables que se define como la media del producto cruzado de los valores obtenidos por una muestra de sujetos en las dos variables menos el producto de las medias en dichas variables.

Criterio. Variable directamente relacionada con el constructo que mide una prueba y que ésta trata de predecir.

Cuasi experimento. Véase Metodología cuasi experimental.

Cuestionario. Véase Prueba.

Curva característica del ítem. Representación gráfica de la función característica del ítem que adopta la forma de una ojiva logística.

Curva de información del ítem. Representación gráfica de la función de información del ítem.

Curva de información del test. Representación gráfica de la función de información del test.

Deseabilidad social. Sesgo o estilo de respuesta consistente en elegir sistemáticamente la opción de respuesta que se considera más deseable socialmente, en lugar de la opción que mejor refleja los sentimientos, valores, actitudes o personalidad del sujeto examinado.

Desviación típica (σ). Medida de la variabilidad mostrada por los valores que adopta una variable, que se define como la raíz cuadrada de la varianza de una variable.

Determinación (coeficiente de). Coeficiente de validez elevado al cuadrado, que expresa la proporción de varianza del criterio que puede ser pronosticada a partir del test.

Dicotómico. Con solo dos valores posibles.

Dificultad de un ítem. Propiedad psicométrica de un ítem que se refiere a las demandas exigidas al sujeto para responderlo correctamente. La forma más frecuente y sencilla de cuantificar esta característica es mediante el índice p en la teoría clásica de los tests y mediante el parámetro b en la teoría de respuesta al ítem.

Discriminación de un ítem. Propiedad psicométrica del ítem que hace referencia a la capacidad de éste para diferenciar o discriminar entre sujetos que presentan diferentes niveles o grados en el constructo medido por el test. Los estadísticos propuestos para estimar este parámetro en la teoría clásica de los tests son el índice D y un índice basado en la correlación ítem-test, sin incluir al ítem bajo estudio (también conocido como *índice de homogeneidad*). En la teoría de respuesta al ítem esta propiedad se conoce como el parámetro a .

Diseño. Plan estructurado de acción que, en función de unos objetivos básicos, está orientado a la obtención de información o datos relevantes a los problemas planteados.

Diseño completamente aleatorizado. Diseño experimental en el que se asignan aleatoriamente los sujetos a cada nivel de la variable independiente, formándose tantos grupos de sujetos distintos como niveles tenga la variable independiente.

Diseño con grupo de control no equivalente. Diseño cuasi experimental con regla de asignación no aleatoria y desconocida en el que se aplican los niveles de tratamiento a dos o más grupos ya formados de los que tenemos una o varias medidas pretest y una medida posttest.

Diseño con grupo de control no equivalente con doble pretest. Diseño cuasi experimental con grupo de control no equivalente caracterizado por tener dos medidas pretest que le hacen especialmente indicado para controlar el efecto de la maduración.

Diseño de bloques homogéneos aleatorizados. Diseño experimental en el que se forman bloques homogéneos de sujetos en una variable extraña (variable de bloqueo), para luego asignar aleatoriamente los sujetos clasificados dentro de cada bloque a las diferentes condiciones experimentales.

Diseño de cohortes. Diseño de encuesta en el que algún grupo específico se estudia a lo largo del tiempo, aunque los datos pueden obtenerse de miembros diferentes, si bien pertenecen a la misma cohorte en cada recopilación de datos.

Diseño de discontinuidad en la regresión. Diseño cuasi experimental caracterizado por utilizar las puntuaciones en el pretest como variable de asignación de los sujetos a las condiciones experimentales y porque sus resultados suelen analizarse empleando ecuaciones de regresión.

Diseño de línea base múltiple. Diseño experimental de sujeto único donde varias conductas se registran simultáneamente interviniendo sobre ellas con el mismo tratamiento de forma escalonada en el tiempo.

Diseño de medidas repetidas. Véase Diseños intra sujeto.

Diseño de N = 1. Véase Diseños de sujeto único.

Diseño de panel. Diseño longitudinal en el que se recopilan datos de los mismos elementos de la muestra varias veces a lo largo del tiempo.

Diseño de series temporales interrumpidas con replicaciones intercambiadas. Diseño cuasi experimental en el que se evalúa el efecto del tratamiento en grupos de similares características, pero en momentos temporales diferentes.

Diseño de series temporales interrumpidas con replicaciones múltiples. Diseño cuasi experimental en el que se compara el efecto que sobre una serie de tiempo tiene la introducción y retirada del tratamiento en más de un momento temporal.

Diseño de sujeto único. Diseño de investigación que mide los efectos de un tratamiento sobre un solo sujeto.

Diseño entre sujetos. Diseño de investigación en el que cada nivel de la variable independiente se administra a un grupo diferente de sujetos.

Diseño factorial. Diseño de investigación que implica el uso simultáneo de dos o más variables independientes.

Diseño intra sujeto. Diseño de investigación en el que el mismo grupo de sujetos recibe todos los niveles de la variable independiente. Es decir, cada sujeto pasa por todos los niveles de tratamiento.

Diseño longitudinal. Diseño que implica la recogida de datos de la misma población en diferentes momentos temporales.

Diseño multivariable. Diseño de investigación en el que se toman medidas de dos o más variables dependientes.

Diseño observacional. Plan de acción específico en el que se determinan las condiciones y etapas que van a configurar el proceso de observación que se lleva-

rá a cabo, con el objeto de estructurar y sistematizar la recogida de datos y su análisis posterior, en coherencia con los objetivos de la investigación.

Diseño reversible ABAB. Diseño experimental de sujeto único en el que se introduce y retira el tratamiento varias veces.

Diseño simple de series temporales interrumpidas. Diseño cuasi experimental en el que se compara una serie de tiempo antes y después de introducir el tratamiento.

Diseño transversal. Diseño basado en observaciones recogidas de una muestra específica en un único periodo determinado en el tiempo.

Distractor. Alternativa incorrecta de respuesta en ítems de elección múltiple.

Distribución de frecuencias de una variable. Conjunto de valores posibles para la variable y número de veces que cada uno de ellos ha sido observado en el conjunto de la muestra o de la población de sujetos examinada.

Distribución muestral del estadístico. Distribución de frecuencias de los valores obtenidos para un estadístico (media, proporción, etc.) en distintas muestras del mismo tamaño y tipo.

División del test en dos mitades (método basado en). Procedimiento de estimación empírica del coeficiente de fiabilidad que consiste en dividir el test en dos mitades equivalentes, y ver si la actuación del sujeto en las dos partes o mitades es consistente o congruente.

Edad mental. Edad cronológica correspondiente a los sujetos cuya puntuación media en la prueba coincide con la del sujeto en cuestión.

Efecto de la fatiga y efecto de la práctica. Variación de la variable dependiente entre las distintas condiciones experimentales producida por la repetición de la tarea en los diseños de medidas repetidas. Se le considera variables extrañas que deben ser controladas.

Efecto del diseño. Cuantificación del grado en el que un diseño muestral específico es menos eficiente que el muestreo aleatorio simple.

Efecto del orden. Variación de la variable dependiente entre las distintas condiciones experimentales producida por el orden en el que son presentados los diferentes niveles de tratamiento en los diseños de medidas repetidas. Se le considera una variable extraña que debe ser controlada.

Elemento muestral. Individuos pertenecientes a una población que han sido seleccionados en una muestra.

Eliminación de una variable extraña. Procedimiento de control consistente en suprimir la variable extraña de la situación experimental.

Encuestas. Véase Metodología de encuestas.

Entrevista. Procedimiento mediante el que un entrevistador realiza un conjunto de preguntas a un sujeto, orientado hacia la obtención de información sobre un tema definido.

Entrevista en profundidad (o abierta). Técnica de investigación cualitativa en la que interactúan entrevistador y entrevistado —este último en calidad de sujeto social prototípico dentro del tema de estudio y no a título individual— que se desarrolla a partir de un guión temático y no de un esquema cerrado y rígido de preguntas.

Epistemología. Rama de la Filosofía que se ocupa de la teoría del conocimiento, siendo uno de sus temas fundamentales el estudio del origen del conocimiento humano.

Error de estimación. Diferencia entre el valor del estadístico y el del parámetro.

Error de medida. Diferencia que existe entre la puntuación empírica que ha obtenido el sujeto en un instrumento de medida y el nivel real en el que posee la característica que mide dicho instrumento.

Error de muestreo. Medida en que un estadístico varía con respecto a un parámetro por razones debidas al grado de representatividad de la muestra elegida.

Error típico del estadístico. Desviación típica de la distribución muestral del estadístico o, lo que es lo mismo, desviación típica de los errores de estimación.

Error típico de estimación de la puntuación verdadera ($\sigma_{u,x}$). Desviación típica de los errores de estimación de la puntuación verdadera.

Error típico de estimación del criterio ($\sigma_{y,x}$). Desviación típica de los errores de estimación del criterio.

Error típico de medida (σ_e). Desviación típica de los errores de medida.

Escala. Continuo de medida en el que se pueden ordenar y situar un conjunto de objetos o sujetos en virtud del grado en el que éstos presentan o manifiestan la variable psicológica que se desea medir.

Escala D. Escala derivada de la escala típica lineal con media 50 y desviación típica 20.

Escala de categorías. Escala de valoración formada por un enunciado y un conjunto de categorías que pueden estar ordenadas o no.

Escala de intervalo. Escala de medida con origen arbitrario e igual distancia entre sus unidades, de forma que los números asignados a los objetos se pueden sumar y restar y las diferencias entre estos números se pueden multiplicar y dividir. Soporta cualquier transformación lineal del tipo $y = ax + b$, con $a > 0$ y $b \neq 0$.

Escala Likert. Escala de categorías ordenadas que denota el grado de acuerdo o desacuerdo con la afirmación contenida en los enunciados de los ítems.

Escala de razón. Escala de medida con origen absoluto e igual distancia entre sus unidades, de forma que los números asignados a los objetos se pueden sumar, restar, multiplicar y dividir. Soporta cualquier transformación del tipo $y = ax$ donde $a > 0$.

Escala de valoración. Prueba no cognitiva formada por ítems de respuesta cerrada.

Escala nominal. Escala de medida en la que los números se asignan a los objetos con el único fin de designarlos o clasificarlos, no para indicar orden o magnitud sino simplemente para nombrarlos o denominarlos, siendo la transformación uno a uno el único tipo de transformación que soporta este tipo de escala.

Escala ordinal. Escala de medida en la que los números asignados a los objetos permiten decidir si un objeto posee en mayor grado que otro la característica de interés. Soporta cualquier tipo de transformación monótona creciente.

Escala T. Escala derivada de la escala típica lineal con media 50 y desviación típica 10.

Escalamiento. Véase Medición.

Estadística inferencial. Parte de la estadística que, basándose en el cálculo de probabilidades, se ocupa de hacer inferencias sobre la población a partir de los datos obtenidos en las muestras.

Estadístico. Valor que representa o mide una característica de una muestra y que, a su vez, intenta representar el valor verdadero del parámetro de una población.

Estratificación. Proceso de agrupación de elementos que componen una población en grupos homogéneos (o estratos) previamente al muestreo, que supone una mejora de la representatividad de la muestra en términos de las variables utilizadas para la estratificación.

Estudio de casos. Estrategia de investigación basada en el estudio descriptivo de un sujeto individual que ha cumplido un papel importante en la Psicología aplicada, especialmente en la Psicología clínica desde sus orígenes.

Estudio descriptivo. Estudio diseñado para determinar los valores de las características de una población.

Estudio explicativo. Estudio diseñado para descubrir relaciones entre variables, de las que algunas pueden ser relaciones de causalidad.

Estudio piloto. Estudio realizado a pequeña escala con el propósito de probar el funcionamiento de todos los aspectos de una investigación, incluyendo los instrumentos y los procedimientos de obtención de datos, así como de su codificación y análisis.

Etología. Estudio biológico y evolutivo del comportamiento animal.

Experimento. Véase Metodología experimental.

Ex post facto (investigación). Investigación caracterizada por utilizar variables asignadas como variable independientes de tal manera que las personas que forman parte de dichas investigaciones habrán sido seleccionadas por haber estado sometidas a determinadas condiciones o por exhibir determinadas características.

Fiabilidad. Criterio métrico de calidad que proporciona información acerca de la cantidad de error aleatorio que contiene una medida.

Fiabilidad (coeficiente de). Cociente entre la varianza de las puntuaciones verdaderas y la varianza de las puntuaciones empíricas obtenidas en un test.

Fiabilidad (índice de). Correlación entre las puntuaciones verdaderas y las puntuaciones empíricas obtenidas en un test.

Fiabilidad interjueces. Precisión de las valoraciones realizadas por un juez, observador o calificador que se suele definir en términos del acuerdo mostrado entre las valoraciones proporcionadas por el juez y el resto de los jueces implicados en el proceso.

Fiabilidad por consenso. Ajuste progresivo de los registros de dos o más observadores que se realiza por trabajo conjunto y negociado en la aplicación del sistema de categorías en algunas sesiones de observación. Suele formar parte del proceso de preparación del observador y sirve además para poner a prueba y depurar el sistema de categorías.

Focus group. Técnica de investigación cualitativa consistente en un grupo de discusión en el que el coordinador toma una posición más directiva y presente que en el grupo de discusión ordinario, tendiendo sus intervenciones a dirigir a los participantes en el grupo directamente hacia el objeto de estudio.

Formas paralelas (método de las). Procedimiento de estimación empírica del coeficiente de fiabilidad que consiste en aplicar en dos ocasiones distintas a los mismos sujetos dos formas paralelas de un test.

Fracción muestral. Razón del tamaño de la muestra al de la población.

Frecuencia. Número de ocurrencias del valor de una variable o de una categoría de conducta.

Frecuencia de transiciones. Número de veces que una determinada categoría de conducta es seguida de otra durante la misma sesión de observación.

Frecuencia relativa de conductas. Cociente entre la frecuencia de una categoría de conducta y la suma de las frecuencias de todas las categorías del sistema.

Frecuencia relativa de transiciones. Cociente entre la frecuencia de transición del par de categorías en estudio y la frecuencia de la categoría de conducta antecedente.

Función característica del ítem. Función que indica cuál es la probabilidad de que un sujeto con un determinado valor en el rasgo o característica evaluada por la prueba responda correctamente a un ítem.

Función característica del test. Función que indica cuál es la probabilidad de que un sujeto con un determinado valor en el rasgo o característica evaluada por la prueba presente un determinado patrón de respuestas en la prueba en cuestión. Es igual al producto de las funciones características de todos los ítems del test.

Función de información del ítem. Función que indica para cada punto de la escala en la que se mide la característica de interés cuál es la información que sobre esa característica proporciona el ítem en cuestión.

Función de información del test. Función que indica para cada punto de la escala en la que se mide la característica de interés cuál es la información que sobre esa característica proporciona un estimador de la misma.

Funcionamiento diferencial del ítem. Un ítem presenta funcionamiento diferencial cuando la probabilidad de responder correctamente a ese ítem difiere para sujetos que pertenecen a diferentes grupos (hombres/mujeres, blancos/negros, etc.) pero que tienen el mismo nivel en la característica medida por el test.

Grupo de control. Grupo que no recibe el tratamiento, o dicho en otros términos, que recibe un nivel nulo de la variable independiente.

Grupo de discusión. Técnica de investigación cualitativa consistente en una reunión de grupo con 7-8 asistentes más el coordinador; que se fundamenta en el supuesto de una estabilidad discursiva en las distintas posiciones sociales existentes respecto al objeto de estudio investigado.

Grupo experimental. Grupo que recibe un nivel no nulo de la variable independiente.

Grupo normativo. Grupo de referencia con el que se desea comparar la actuación del sujeto en un test.

Grupo triangular. Técnica de investigación cualitativa consistente en una reunión de tres personas más el coordinador; que se encuentra en un espacio discursivo intermedio o de transición entre la entrevista en profundidad y el grupo de discusión.

Habitución. Fenómeno que se refiere a la falta de efecto que produce el observador sobre los observados a consecuencia de su presencia continua o prolongada.

Hipótesis. Conjetura que se formula como solución tentativa a un problema, a la que se puede llegar bien mediante la inducción y la generalización de lo observado, bien mediante la deducción de implicaciones observables de un modelo teórico. Ya se proceda por la vía inductiva o por la deductiva, es necesario siempre contrastar empíricamente con la experiencia la hipótesis ofrecida como solución tentativa.

Hipótesis estadística. Aseveración referida a funciones matemáticas (media, varianza, correlación, etc.) definidas sobre la población, que rechazaremos o no en base al cálculo de probabilidades, asumiendo *a priori* cierta probabilidad de equivocarnos.

Hipótesis experimental. Explicación tentativa y comprobable sobre la relación entre dos variables que constituye una posible solución a un problema de investigación. Suelen formularse en la forma de antecedente y consecuente «si..., entonces...».

Idiográfico. Basado en la descripción de acontecimientos o hechos particulares.

Impacto. Un ítem presenta impacto cuando la probabilidad de responderlo correctamente sea mayor para un grupo que para otro, reflejando una diferencia real entre ambos grupos en la variable medida por el ítem.

Índice *D* de discriminación. Medida del poder discriminativo de un ítem que se basa en la información proporcionada por la comparación de la actuación en el ítem de los grupos extremos de puntuación en la prueba. Generalmente, los grupos se forman con el 27 por 100 de los sujetos con más baja puntuación y con el 27 por 100 de más alta puntuación.

Índice *p* de dificultad. Proporción de sujetos que responden correctamente a un ítem.

Interpretación criterial. Comparación de la actuación del sujeto en el test con un criterio que puede ser bien un punto de corte en la escala —que sirve para adscribir al sujeto a una categoría u otra previamente establecidas— bien un dominio de conducta o de contenido perfectamente definido —que sirve para describir la actuación del sujeto en términos de lo que éste sabe o no hacer—.

Interpretación normativa. Comparación de la actuación del sujeto en el test con la actuación en esa prueba de un grupo de referencia del sujeto (grupo normativo), utilizando para ello puntuaciones normativas o tipificadas (cronológicas, centiles o típicas).

Intervalo confidencial. Rango de valores entre los que se encuentra probablemente (con un determinado nivel de confianza) un parámetro.

Intervalo de muestreo o de selección. Distancia numérica, definida en función de la razón de muestreo, entre los elementos que se seleccionan mediante un muestreo sistemático.

Ítem de construcción. Ítem que requiere que el sujeto construya o elabore la respuesta.

Ítem de elección. Ítem que requiere que el sujeto seleccione una (o varias) opción(es) de entre las propuestas.

Ítem de elección binaria. Ítem de elección con dos alternativas de respuesta.

Ítem de elección múltiple. Ítem de elección con tres o más alternativas de respuesta.

Ítem de emparejamiento. Ítem en el que la tarea del sujeto consiste en relacionar lo que aparece en una primera columna con lo que aparece en una segunda columna.

Ítem de valoración de la actuación. Ítem que trata de simular o emular el contexto o las condiciones en las que se han de aplicar realmente los conocimientos o las habilidades que se desea evaluar.

Kappa. Medida del acuerdo entre jueces, calificadores u observadores que tiene en cuenta los acuerdos que pueden obedecer al azar y se define como el cociente entre la proporción de acuerdos eliminando los acuerdos aleatorios y el complemento a la unidad de los acuerdos aleatorios.

Libro de códigos. Documento en el que se registra la situación de las distintas variables en un fichero de datos y el significado de los códigos utilizados para representar los diferentes valores de dichas variables, para facilitar el procesamiento y análisis de los datos.

Listado. Escala de valoración consistente en un conjunto o lista de términos, frases o afirmaciones relativas a un objeto (sujeto, hecho o idea), en los que la tarea del sujeto se reduce a marcar con una cruz los elementos de la lista que en su opinión sean aplicables al objeto que se está valorando.

Logit. Logaritmo neperiano del cociente entre la probabilidad de un suceso (por ejemplo, responder correctamente a un ítem de un test) y del contrario (responder incorrectamente).

Maduración biológica. Cambios producidos en el organismo del sujeto como consecuencia del paso del tiempo. Estos cambios pueden mediatizar el efecto que la variable independiente tiene sobre la variable dependiente y, en el caso de no controlarse, constituyen una seria amenaza contra la validez interna del diseño.

Mantel-Haenszel (procedimiento de). Método sencillo y de uso frecuente para la detección del posible funcionamiento diferencial del ítem, basado en la construcción de tablas bidimensionales para grupos de habilidad homogénea.

Marco muestral. Listado real de los individuos o fenómenos que componen la población a partir del cual se selecciona la muestra.

Matriz multimétodo-multirasgo. Matriz que contiene las correlaciones entre las medidas de un constructo obtenidas con distintas pruebas y las medidas de distintos constructos (relacionados con el anterior) obtenidas también con pruebas diferentes.

Media (μ). Medida de tendencia central que permite resumir la información contenida en los valores que adopta una variable en un único valor, que se define como la suma de todos esos valores dividida por el número de valores sumados.

Mediana. Valor de una variable que deja por debajo y por encima de sí el 50 por 100 de las observaciones en la distribución de frecuencias.

Medición. Proceso por medio del cual se asigna un número a un objeto o sujeto en virtud del grado en el que éste presenta o manifiesta la variable que se desea medir.

Medida. Número asignado a un objeto o sujeto en virtud del grado en el que presenta o manifiesta la característica o constructo que se desea apreciar con un determinado instrumento de medida.

Meta-análisis. Conjunto de procedimientos dirigidos a combinar los resultados de diversos estudios, una vez que sus resultados han sido reducidos a una métrica común.

Método. Camino para alcanzar un objetivo.

Método científico. Forma de actuar mediante operaciones ordenadas que orientan la investigación hacia los fines de la ciencia a través de una serie de fases interdependientes entre sí.

Método clínico. Véase Estudio de casos.

Metodología. Método científico general adaptado a las peculiaridades del objeto propio de estudio de una disciplina científica en particular.

Metodología cualitativa. Metodología de investigación que se acerca de forma directa y abierta a los discursos de los sujetos, tratando de aproximarse, de dar respuesta a las motivaciones, a las determinaciones sociales que están tras el comportamiento de los sujetos, y no a cómo se distribuye en la sociedad un determinado fenómeno.

Metodología cuasi experimental. Metodología de investigación que compartiendo el mismo objetivo que la metodología experimental (establecimiento de relaciones causales) lo logra en menor medida, al no existir asignación aleatoria de las unidades experimentales a los niveles de la variable independiente, lo que da lugar a un deficiente control de las variables extrañas.

Metodología de encuestas. Metodología de investigación dirigida a la recopilación de información mediante un conjunto de preguntas que intenta cubrir las necesidades de información del investigador, bien para describir alguna de las características de la población de sujetos bajo estudio o bien para analizar las relaciones entre algunas de sus características.

Metodología experimental. Metodología de investigación que permite establecer con garantías relaciones causales entre los fenómenos objeto de estudio, al tener como principios constitutivos la manipulación de la variable independiente y el estricto control de las variables extrañas.

Metodología observacional. Metodología de investigación que mediante el registro sistemático y objetivo de la conducta que se genera espontáneamente permite la contrastación de hipótesis, la replicabilidad de sus resultados y contribuye al desarrollo teórico al proporcionar resultados válidos en un ámbito específico de conocimiento.

Moda. Valor que más se repite en una distribución de frecuencias.

Modelo logit. Modelo loglineal con una función de distribución logística y en el que se distingue entre variable dependiente e independiente(s).

Modelo loglineal. Modelo que analiza las relaciones entre un conjunto de variables categóricas mediante la descomposición lineal de los logaritmos naturales de las frecuencias esperadas de cada celdilla de las correspondientes tablas de contingencia.

Modelo matemático. Representación de un sistema real mediante operaciones lógico-matemáticas.

Modelo probit. Modelo loglineal con una función de distribución normal y en el que se distingue entre variable dependiente e independiente(s).

Muestra. Subconjunto de elementos de una población, seleccionado de modo que sirva para representar las características de dicha población.

Muestra de conveniencia. Muestra no probabilística en la que sus elementos se escogen por la facilidad de acceso a los mismos.

Muestra de juicio. Muestra no probabilística en la que se escogen los elementos sobre la base de un juicio, a veces del experimentador o de expertos, sobre qué elementos de una población son más útiles o representativos.

Muestra no probabilística. Muestra seleccionada de modo que no se tiene en cuenta la probabilidad de selección de cada uno de los elementos de la población.

Muestra por cuotas. Muestra no probabilística en la que los elementos se seleccionan sobre la base de un conjunto de características prefijadas, de modo que la muestra contenga dichas características que se asumen en la población.

Muestra probabilística. Muestra seleccionada de modo que se conoce y tiene en cuenta la probabilidad de selección de cada uno de los elementos de la población.

Muestreo. Proceso de selección de una muestra a partir de una población definida.

Muestreo aleatorio simple (m.a.s). Muestreo probabilístico en el que a cada unidad de la población se le asigna un número y, en un segundo paso, se seleccionan aquellas unidades que tengan asignados los mismos números que contiene una lista de números generados aleatoriamente del tamaño de la muestra deseada.

Muestreo con probabilidad proporcional al tamaño. Muestreo en el que los elementos muestrales se seleccionan en función de su proporción en relación al tamaño de la población.

Muestreo de barrido. Véase Muestreo multifocal.

Muestreo en cadena o de bola de nieve. Muestreo no probabilístico en el que cada persona entrevistada sugiere otras personas a encuestar en función de una característica común a ambos.

Muestreo estratificado. Procedimiento de obtención de muestras consistente en dividir la población en estratos o subgrupos homogéneos, mutuamente exclusivos y exhaustivos, extrayendo a continuación una muestra aleatoria simple de cada uno de ellos.

Muestreo focal. Muestreo intrasiesional en el que la atención del observador se mantiene focalizada en un único individuo durante un periodo de tiempo grande, que en muchas investigaciones llega a ser toda la sesión.

Muestreo intersiesional. Muestreo de las sesiones de observación para el que se puede utilizar un criterio de selección fija o aleatoria.

Muestreo intrasiesional. Muestreo de sujetos dentro de una sesión de observación para el que se puede optar por un muestreo focal, de barrido o multifocal o por la combinación de ambos.

Muestreo multifocal. Muestreo intrasiesional en el que la atención del observador va pasando de un sujeto a otro, en un orden establecido y que se repite varias

veces en la sesión, esto es, el observador focaliza a cada uno de los individuos en periodos de tiempo muy breves.

Muestreo por conglomerados. Muestreo en el que se seleccionan unidades formadas por grupos de unidades elementales.

Muestreo por rutas aleatorias. Procedimiento aleatorio y no probabilístico de obtención de muestras consistente en seleccionar a los encuestados siguiendo rutas aleatorias (por ejemplo, se instruye al encuestador sobre un plano para que camine 100 metros hacia el noroeste y entre en la primera casa a la derecha; si hay varios pisos que vaya al segundo y si hay varias viviendas que seleccione la tercera desde la izquierda).

Muestreo sistemático. Muestreo probabilístico en el que los elementos de la población, una vez numerados secuencialmente, son seleccionados sistemáticamente a partir de un determinado número aleatorio y con un intervalo de muestreo definido en función de la razón de muestreo.

Nivel de confianza. Probabilidad de que el parámetro caiga dentro del intervalo cuyos límites están definidos por el valor del estadístico más/menos el error máximo de estimación.

Nomotético. Basado en la búsqueda de leyes generales.

Normas. Puntuaciones obtenidas en una prueba o test por el grupo normativo, que ayudan a expresar la posición relativa de un sujeto en el grupo normativo.

Número de muestras posible. Número de combinaciones posibles de los elementos de una población con un tamaño igual al de la muestra.

Observación. Véase Metodología observacional.

Observación estructurada. Observación en la que el investigador interviene de forma sistemática o realiza modificaciones sustanciales en la situación de observación. La conducta a observar ya no se genera espontáneamente sino que puede ser un efecto de la intervención del investigador.

Observación naturalista. Observación que tiene lugar en el entorno o contexto habitual en el que ocurre el comportamiento de los sujetos objeto de estudio, sin ningún tipo de modificación por parte del investigador.

Observación no participante. Observación caracterizada porque el observador no se integra en la situación que está siendo observada.

Observación participante. Observación caracterizada porque el observador forma parte de la propia situación de observación al participar en las actividades que están siendo observadas.

Observación semiestructurada. Observación en la que el investigador introduce algún tipo de modificación en la situación de observación, para poder garantizar la manifestación de las conductas de interés o elementos constantes que permitan realizar comparaciones posteriores.

Observación sistematizada. Proceso planificado y organizado para el registro y la codificación de comportamientos o fenómenos que constituyen el objeto de la investigación.

Operacionalizar. Acción de definir claramente conceptos teóricos en términos concretos que posibiliten su observación empírica. Así, las variables se describen, se operacionalizan a través de las operaciones necesarias para su producción o medida.

Paralelas (medidas). Medidas con idéntica varianza error e idéntica puntuación verdadera para todos los sujetos de la muestra o de la población.

Parámetro. Característica del conjunto de la población que suele ser estimada habitualmente mediante un estadístico calculado en una muestra extraída de la misma.

Parámetro *a*. Parámetro de discriminación del ítem en la teoría de respuesta al ítem, que es directamente proporcional a la pendiente de la curva característica del ítem en su punto de inflexión.

Parámetro *b*. Parámetro de dificultad del ítem en la teoría de respuesta al ítem, que se define como la coordenada en el eje de abcisas del punto de inflexión de la curva característica del ítem.

Parámetro *c*. Parámetro de pseudoadivinación del ítem en la teoría de respuesta al ítem, que se define como la probabilidad de que aquellos sujetos con un nivel mínimo de habilidad —y que, por tanto, se supone que no conocen la respuesta correcta— respondan correctamente al ítem.

Pendiente de una recta. Grado de inclinación de la recta definido como el cociente entre la distancia vertical entre dos puntos cualesquiera de la recta y la distancia horizontal entre ellos.

Percentil. Véase Centil.

Población. Conjunto de todos los objetos que cumplen una definición bien determinada. Por ejemplo, la población «españoles varones mayores de 50 años» estará compuesta por todos los hombres que cumplen la citada definición.

Politómico. Con más de dos valores posibles.

Portfolio. Conjunto de trabajos o tareas recogidas a lo largo del tiempo.

Positivismo. Escuela filosófica que pretende atenerse a lo dado y no salir de ello: se niega a admitir otra realidad que no sean los hechos y a investigar otra cosa que no sean las relaciones entre los hechos, exigiendo criterios y procedimientos de verificación empírica para establecer, al menos provisionalmente, la verdad o la falsedad de los hechos.

Potencia. Probabilidad de encontrar resultados significativos en la investigación, esto es, de que los resultados de la investigación lleven a rechazar la hipótesis nula cuando es falsa.

Pretest de una encuesta. Proceso de prueba de una parte del conjunto de procedimientos e instrumentos de una encuesta, habitualmente las pruebas iniciales para la construcción de los cuestionarios.

Prueba. Instrumento de recogida de información compuesto de un conjunto de preguntas o ítems que permite obtener medidas de una variable psicológica

(rendimiento, inteligencia, aptitud, actitud, personalidad, intereses, etc.) que proporcione información sobre el sujeto y/o su entorno.

Prueba de lápiz y papel. Prueba que se presenta en formato impreso en la que el sujeto debe registrar por escrito sus respuestas, respondiendo a lo que se le pregunta o señalando la opción que considere oportuna en el cuadernillo del test o en una hoja de respuesta.

Psicología Diferencial. Estudio de las diferencias que se observan en la conducta de individuos diferentes o de grupos de individuos que comparten entre sí características personales o de situación pero diferentes de otros grupos.

Psicometría. Disciplina científica directamente implicada en la medición psicológica que se ocupa, por un lado, de la fundamentación teórica de la medida y, por otro, de la construcción, evaluación y aplicación de instrumentos de medida para medir las características o constructos psicológicos de interés.

Puntuación centil. Véase centil.

Puntuación cronológica. Puntuación que indica la relación que guarda la puntuación en el test con la edad cronológica del sujeto que la ha obtenido.

Puntuación del test. Estimación del valor escalar del sujeto que se define como la suma ponderada de las puntuaciones obtenidas en los ítems del test.

Puntuación normativa. Véase Normas.

Puntuación típica. Puntuación que indica la distancia que separa un sujeto de la media del grupo normativo, expresando dicha distancia en unidades de desviación típica.

Puntuación típica derivada. Puntuación obtenida mediante una transformación lineal de las puntuaciones típicas.

Puntuación tipificada. Véase Normas.

Puntuación verdadera. Nivel real en que el sujeto manifiesta la característica de interés medida con una prueba o test en la teoría clásica de los tests.

Razón de eficacia. Proporción de predicciones correctas del test en el grupo alto del criterio.

Razón de idoneidad. Proporción de sujetos que habría que seleccionar atendiendo al criterio.

Razón de muestreo. Véase Fracción muestral.

Razón de selección. Proporción de sujetos seleccionados con el test.

Reactividad. Cambios que se producen, voluntaria o involuntariamente, en los sujetos por el simple hecho de sentirse observados.

Recodificación. Cambio de los códigos o números asignados inicialmente a las categorías de respuesta de un ítem, normalmente con el fin de que un mismo número signifique siempre lo mismo (una opinión/actitud/sentimiento favorable o desfavorable hacia la cuestión examinada), al margen de que el

enunciado del ítem denote una opinión/actitud/sentimiento favorable o desfavorable.

Registro. Anotaciones que se realizan de la conducta observada, frecuentemente a través de códigos que representan a cada una de las categorías del sistema.

Registro activado por transiciones (RAT). Registro de todas las ocurrencias de las conductas relevantes (registro de eventos) y con información de su duración (registro de estados).

Registro activado por unidades de tiempo (RAUT). Registro de las conductas indicadas por el sistema de categorías siguiendo una pauta determinada por periodos de tiempo (intervalos). Sólo se produce el registro de las conductas que están ocurriendo en momentos temporales específicos de la sesión (*muestreo puntual o instantáneo*) o que han ocurrido en los periodos de tiempo establecido (*muestreo de intervalos*).

Regresión. Predicción del valor de una variable realizada a partir del valor conocido de otra(s) variable(s).

Regresión logística. Modelo de regresión con un logit como variable dependiente y variable(s) independiente(s) cualitativas y cuantitativas.

Relación causal. Tipo de relación por la que se establece a la variable independiente como causa de la variable dependiente, siempre y cuando la medición de la variable independiente preceda a la de la variable dependiente, exista covariación entre las variables y se puedan descartar otras explicaciones de causación alternativas.

Representatividad. Propiedad por la que las características de una muestra tienen la misma distribución que las características de la población de la que forman parte y de la que se han muestreado. La representatividad implica que las descripciones y explicaciones adecuadas para la muestra representan de modo fiable y son aplicables al conjunto de la población.

Respuesta extrema. Sesgo o estilo de respuesta consistente en responder sistemáticamente eligiendo las categorías de respuesta de los extremos, con independencia del contenido del ítem.

Restricción del rango. Disminución de la variabilidad observada en los valores de una variable mostrados en una muestra de sujetos.

Reunión de grupo. Véase Grupo de discusión.

Selección aleatoria. Selección de elementos para conformar una muestra realizada mediante la utilización de métodos probabilísticos, conociendo la probabilidad de selección de cada uno de los elementos en la población que debe ser mayor que cero.

Sensibilidad. Propiedad de la variable dependiente que le permite detectar, en caso de estar relacionada con la variable independiente, las manipulaciones realizadas por el investigador sobre la variable independiente.

Serie de tiempo. Sucesión de observaciones tomadas cronológicamente.

Sesgo. Característica de un sistema de medida que produce resultados que no representan de modo adecuado lo que se pretende medir, al modificar los resultados en una dirección específica.

Sesgo de respuesta. Tendencia sistemática de un sujeto a responder a los ítems de la prueba de una determinada manera, con independencia de cuál sea el contenido de los ítems.

Significante. Palabra o expresión que ocupa un lugar central en el discurso que construyen los sujetos en las diferentes técnicas de la metodología cualitativa.

Sistema de categorías. Definición de dos o más categorías para la observación y registro de un mismo fenómeno que cumple las condiciones de exhaustividad y mutua exclusividad.

Tabla de contingencia. Tabla de doble entrada en la que en las filas se suelen indicar los valores o categorías de una variable y en las columnas los valores o categorías de otra variable, indicando las celdillas de la tabla la frecuencia o número de casos en los que se observan simultáneamente un valor de una variable y otro de la otra.

Tabla de especificación del test. Tabla de doble entrada utilizada para especificar el contenido del test, en la que las columnas indican distintas áreas de contenido relevantes para el constructo en cuestión y las filas operaciones o procesos cognitivos implicados en la resolución de las tareas planteadas por las preguntas o ítems de la prueba.

Tasa de respuesta. Razón entre los elementos de los que se ha obtenido finalmente información en una encuesta y la muestra de la que debería haberse obtenido información; es decir, el número de personas que responden realmente a la encuesta dividido por el número de personas que habían sido seleccionadas en la muestra.

Tau-equivalentes (medidas). Medidas que no satisfacen la condición de paralelismo relativa a la igualdad de la varianza error. Si se satisface la condición de la igualdad de las puntuaciones verdaderas, se habla entonces de medidas estrictamente tau-equivalentes. Si las puntuaciones verdaderas difieren en una constante aditiva, se habla entonces de medidas esencialmente tau-equivalentes.

Tendencia. Patrón común que subyace a la evolución de los registros de una serie de tiempo.

Teoría de los tests. Teoría que se ocupa de determinar la relación que existe entre el nivel del sujeto en la variable —inobservable— que se desea medir y su puntuación —observada— en el test. Esta relación viene definida por una función matemática lineal —en la TCT— y por una logística —en la TRI—.

Test. Véase Prueba.

Test informatizado. Test que se administra a los sujetos utilizando un ordenador, de modo que las preguntas del test se presentan de una en una a través de la pantalla del ordenador y el sujeto indica la opción que considera oportuna utilizando el teclado o el ratón.

Test-retest (método del). Procedimiento de estimación empírica del coeficiente de fiabilidad que consiste en aplicar el test en dos ocasiones distintas a la misma muestra de sujetos.

Tiempo de reacción (TR). Tiempo que transcurre entre la presentación del estímulo y la emisión de una respuesta.

Tipificación. Proceso consistente en establecer normas que posibiliten la interpretación de los resultados del test.

Tratamiento. Término por el que se nombra a veces a la variable independiente en la metodología experimental y cuasi experimental.

Universo. Véase Población.

Validación. Investigación o proceso científico de contrastación de hipótesis que tiene como resultado la acumulación gradual de evidencia que apoye la interpretación deseada de las puntuaciones de un test.

Validez (coeficiente de). Coeficiente de correlación entre las puntuaciones obtenidas en el test y en el criterio.

Validez convergente (coeficiente de). Coeficiente de correlación entre medidas del mismo constructo cuando se utilizan distintos procedimientos de medida.

Validez de conclusión estadística. Propiedad de la investigación que nos garantiza que es correcta la utilización de los datos muestrales para establecer relaciones entre las variables explicativas en la población.

Validez de constructo. Propiedad de la investigación que nos garantiza que los constructos objeto de estudio están adecuadamente operativizados de forma que las relaciones que encontremos entre las variables podamos extenderlas a ellos.

Validez de un test. Criterio métrico de calidad que proporciona información acerca de la adecuación de la interpretación de las puntuaciones del test en términos del constructo psicológico que dice medir y de su utilización para el fin previsto.

Validez discriminante (coeficiente de). Coeficiente de correlación entre medidas de distintos constructos cuando se utiliza el mismo procedimiento de medida (coeficiente monométodo-heterorasgo) o entre medidas de distintos constructos cuando se utilizan distintos procedimientos de medida (coeficiente heterométodo-heterorasgo).

Validez externa. Propiedad de la investigación que garantiza la generalización de los resultados obtenidos a otras poblaciones, tratamientos, contextos y ocasiones.

Validez interna. Propiedad de la investigación por la que podemos atribuir con garantías los cambios de la variable dependiente a la influencia de la variable independiente.

Validez teórica. Propiedad de la investigación que garantiza que el problema investigado y las hipótesis formuladas son consistentes con los conocimientos que hasta la fecha se tienen en ese campo de estudio.

Valor de escala o escalar. Véase Medida.

Variable. Cualquier característica susceptible de cambiar, que presenta al menos dos valores distintos. Contrario de constante.

Variable activa. Variable que puede ser manipulada por el investigador. En la investigación experimental y cuasi experimental las variables independientes son siempre variables activas.

Variable asignada. Variable que no puede ser manipulada por el experimentador por estar en cierta medida determinada. Por ejemplo, la edad, el género, la raza, etcétera. En la investigación *ex post facto* las variables independientes son siempre variables asignadas.

Variable categórica. Variable que puede manifestarse según dos o más niveles no susceptibles de ser ordenados (varón/mujer, casado/soltero/separado/divorciado/viudo, etc.).

Variable continua. Variable cuantitativa que puede presentar un número infinito de valores entre dos valores cualesquiera.

Variable dependiente (VD). Variable cuyos cambios, una vez medidos, se atribuyen a los cambios de la variable independiente.

Variable discreta. Variable cuantitativa que no admite valores intermedios entre dos valores consecutivos.

Variable extraña (VE). Variable que sin tener interés directo para el investigador puede afectar a la variable dependiente. El efecto de estas variables sobre la variable dependiente debe ser, cuando se pueda, eliminado; cuando no se pueda eliminar, controlado y, cuando no se pueda ni eliminar ni controlar, reducido.

Variable independiente. Cualquier suceso que sospechamos que pueda ser la causa de otro. En la investigación experimental y cuasi experimental es una variable activa, manipulada por el experimentador. En la investigación *ex post facto* es una variable asignada. A la variable independiente también se la denomina a veces *tratamiento*.

Variables marcadoras. Variables de la población conocidas de antemano con suficiente precisión de modo que se puedan utilizar para comprobar que la muestra es equivalente a la población, al menos, en cuanto a dichas características.

Varianza (σ^2). Medida de la variabilidad mostrada por los valores que adopta una variable, que se define como la media de las diferencias cuadráticas entre dichos valores y su media.

Varianza error. Variaciones aleatorias de la variable dependiente provocadas por el efecto de variables extrañas.

Varianza sistemática primaria. Variación de la variable dependiente provocada por la variable independiente.

Varianza sistemática secundaria. Variación de la variable dependiente provocada por la acción de variables extrañas que afectan de forma sistemática a dicha variable.

Esta obra pretende ofrecer una introducción de carácter general a la investigación científica en el ámbito de la Psicología y la Educación. Está dirigida a todo el que desee familiarizarse con los fundamentos de la metodología científica, a quien quiera saber cómo se realiza una investigación psicológica, de qué métodos se dispone para llevar a cabo un estudio que permita dar respuesta a un problema de investigación y cómo se construyen y, sobre todo, cómo se evalúan los instrumentos (tests, cuestionarios, escalas, pruebas...) que sirven para medir una determinada característica, variable o atributo.

El texto está coordinado por María José Navas, responsable de la docencia de la asignatura de idéntico título en la titulación de Psicopedagogía de la UNED. Se ha contado con la colaboración de un conjunto de profesores de esta y otras universidades, así como de profesionales procedentes de centros de investigación e institutos de opinión pública, todos ellos con una dilatada experiencia docente y/o profesional, que facilita un acercamiento muy provechoso de los contenidos de cada tema a la realidad del futuro psicólogo, pedagogo o psicopedagogo.

