

PRUEBAS Y EVALUACIÓN PSICOLÓGICAS

Introducción a las pruebas y a la medición • SEXTA EDICIÓN



1860

El fisiólogo alemán Gustav Fechner publica *Elements of Psychophysics*, donde explora la forma en que las personas responden a estímulos tales como la luz y el sonido. La obra genera ideas y experimentos en el área de la percepción humana y animal.

1869

Sir Francis Galton, primo segundo de Charles Darwin, publica un estudio sobre la herencia y el genio, siendo pionero en la técnica estadística que Karl Pearson luego llamaría *correlación*. Luego, Galton hace numerosas contribuciones a la medición a través de varios inventos e innovaciones.

1879

Wilhelm Max Wundt funda el primer laboratorio experimental de psicología, en Leipzig, Alemania. El acontecimiento fue memorable porque a partir de entonces la psicología es tratada como ciencia y no como una rama de la filosofía. Wundt, un estructuralista, confía en una herramienta de evaluación llamada *introspección*, en la cual los sujetos tratan de describir fielmente su experiencia consciente de un estímulo. En Leipzig, los investigadores y sus discípulos se concentran en la medición de las capacidades relacionadas con los sentidos, tiempo de reacción, y otras semejantes, pero su tendencia era a no medir otros aspectos como serían la capacidad cognoscitiva o el juicio social.

1890

El psicólogo norteamericano James McKeen Cattell acuña el término *prueba mental* en una publicación. Cattell estudió con Wundt en Leipzig y fue inspirado por Galton en Cambridge. Una vez de regreso en Estados Unidos, Cattell fue relevante para el lanzamiento de las pruebas mentales. Fundó varias publicaciones (sobresalen *Science* y *Psychological Review*) y en 1921 puso en marcha Psychological Corporation, una organización cuya meta era lograr “la aplicación práctica de la psicología”.

1892

El psiquiatra Emil Kraepelin, que estudió con Wundt, publica su trabajo que trata del uso de una prueba que comprende la asociación de palabras.

1895

Alfred Binet y Victor Henri publican artículos que hablan de la medición de capacidades cognoscitivas como la memoria, así como otras capacidades humanas como la comprensión social. Es interesante, asimismo, que Binet haya especulado sobre la posibilidad de usar manchas de tinta para estudiar la personalidad.

1896

Lightner Witmer establece la primera clínica de psicología en Estados Unidos, en la Universidad de Pensilvania. Después, en 1907, Witmer funda un diario llamado *Psychological Clinic*. El primer artículo fue escrito por Witmer y se titulaba *Clinical Psychology*. Ahí, Witmer no anticipa la administración de cuidados.

1904

Charles Spearman, un estudiante de Wundt en Leipzig, sienta las bases para el concepto de la confiabilidad de las pruebas.

También comienza a construir un marco matemático para el análisis de factores o factorial.

1905

Alfred Binet y Theodore Simon publican una “escala de medición de la inteligencia” con 30 reactivos, diseñada para ayudar a identificar a los niños escolares con retraso mental en la ciudad de París. La idea de la medición de la inteligencia es de gran atractivo mundial, y la prueba Binet-Simon inicia la nueva era en la medición.

1913

El psiquiatra suizo Hermann Rorschach, hijo de un maestro de arte, publica ensayos sobre cómo las obras de arte de los pacientes pueden ofrecer percepciones valiosas sobre la personalidad. En 1921, su ahora famosa monografía, *Psychodiagnosics*, evolucionaría en una prueba que en la mente del público se ha vuelto sinónimo de las pruebas psicológicas, la Prueba de manchas de tinta de Rorschach.

1913

John Watson publica *Psychology as the Behaviorist Views It* que se conoce como el “manifiesto conductista”. Y como los conductistas lo ven, la observación de la conducta se vuelve una herramienta clave en la evaluación.

1914

La Primera Guerra Mundial sirve de bonanza a las pruebas psicológicas pues hay miles de reclutas que deben ser rápidamente estudiados para evaluar su funcionamiento intelectual, así como su estabilidad emocional.

1916

Tras años de investigación, Lewis M. Terman, quien trabaja en la Universidad de Stanford, publica la *Revisión Stanford de la escala de inteligencia de Binet-Simon*. Esta adaptación y revisión estadounidense de la prueba desarrollada originalmente en Francia pronto se volvería conocida como la Stanford-Binet.

1926

El consejo de dirección universitario patrocina el desarrollo del Scholastic Aptitude Test (SAT) y administra la prueba por primera vez ese mismo año. Quince años después se puso en marcha para esta prueba un sistema de calificación con base en un grupo de referencia fija que sumó un total de 11000 pruebas SAT realizadas en 1941, hecho que inmortalizó a dicha prueba como estándar que se usaría para evaluar los datos crudos de las pruebas futuras. Años después, los datos de más de 2 millones de pruebas hechas en 1990 se usarían para crear los datos de un nuevo grupo de referencia fija, que entraría en servicio en 1995.

1927

Carl Spearman publica una teoría de la inteligencia de dos factores, en la cual postula la existencia de un factor general de capacidad intelectual (g) y la presencia de componentes específicos (s) en dicha capacidad general. Ese mismo año, el neurólogo alemán Kurt Goldstein inicia el desarrollo de pruebas de neurodiagnóstico con base en la investigación de soldados que sufrieron lesiones cerebrales durante la Primera Guerra Mundial.

Pruebas y evaluación psicológicas

Pruebas y evaluación psicológicas

Introducción a las pruebas y a la medición

SEXTA EDICIÓN

Ronald Jay Cohen

Mark E. Swerdlik

ILLINOIS STATE UNIVERSITY

Traducción

María de los Ángeles Izquierdo Castañeda

Susana Pontón Becerril

Gloria Estela Padilla Sierra

Susana Margarita Olivares Bari

María Isabel Pérez de Lara Choy

Traductoras profesionales

Revisión técnica

Gabriela Sánchez Pérez

Universidad Iberoamericana

María del Carmen Montenegro Núñez

Universidad Nacional Autónoma de México

Enrique de Guadalupe Murguía Díaz Muñoz

Universidad Iberoamericana



MÉXICO • BOGOTÁ • BUENOS AIRES • CARACAS • GUATEMALA • LISBOA • MADRID • NUEVA YORK
SAN JUAN • SÃO PAULO • SANTIAGO • AUCKLAND • LONDRES • MILÁN • MONTREAL • NUEVA DELHI
SAN FRANCISCO • SINGAPUR • SAN LUIS • SIDNEY • TORONTO

Director Higher Education & Professional: Miguel Ángel Toledo Castellanos
Director editorial Higher Education: Ricardo A. del Bosque Alayón
Editor Sponsor: Noé Islas López
Supervisor de producción: Zeferino García García

Pruebas y evaluación psicológicas. Introducción a las pruebas y a la medición
Sexta edición

Prohibida la reproducción total o parcial de esta obra,
por cualquier medio, sin la autorización escrita del editor.



DERECHOS RESERVADOS © 2006, respecto a la segunda edición en español por
McGRAW-HILL/INTERAMERICANA EDITORES, S.A. DE C.V.

A Subsidiary of The McGraw-Hill Companies, Inc.

Prolongación Paseo de la Reforma 1015, Torre A
Piso 17, Colonia Desarrollo Santa Fe
Delegación Álvaro Obregón
C.P. 01376, México, D.F.

Miembro de la Cámara Nacional de la Industria Editorial Mexicana, Reg. Núm. 736

ISBN 970-10-5704-X

(ISBN 970-10-2936-4 primera edición)

Traducido de la sexta edición de: PSYCHOLOGICAL TESTING AND ASSESSMENT: AN
INTRODUCTION TO TESTS AND MEASUREMENT

Copyright © MMV by The McGraw-Hill Companies, Inc. All rights reserved.

Previous editions © 1988, 1992, 1996, 1999, and 2002.

0-07-288767-2

Imagen de la portada: *Naomi Shea*

1234567890

09875432106

Impreso en México

Printed in Mexico

Este libro está dedicado a la memoria de Edith y Harold Cohen.



Prefacio xix

PARTE I | *Una visión general*

1 Pruebas y evaluación psicológica 1

PRUEBAS Y EVALUACIÓN 1

Definición de pruebas psicológicas y evaluación 1

Las herramientas de la evaluación psicológica 5

¿QUIÉNES, QUÉ, POR QUÉ Y DÓNDE? 16

¿Quiénes son las partes involucradas? 16

¿En qué tipos de escenarios se conducen las evaluaciones y por qué? 20

Dónde buscar información autorizada y actualizada: fuentes de referencia 26

CLOSE-UP Tipos de informes psicológicos generados por computadora 13

PSICOMETRÍA COTIDIANA “La siguiente película se ha clasificado como PG-13...” Pero, ¿quién?, ¿cómo?
y ¿por qué? 19

AUTOEVALUACIÓN 30

UN VISTAZO A LA RED 30

2 Consideraciones históricas, culturales y ético/legales 31

UNA PERSPECTIVA HISTÓRICA 31

De la antigüedad al siglo XIX 31

El siglo XIX 32

El siglo XX 35

CULTURA Y EVALUACIÓN 37

Desarrollo del interés en asuntos relacionados con la cultura 38

Algunos aspectos respecto a la cultura y la evaluación 40

Pruebas y pertenencia a un grupo 43

CONSIDERACIONES LEGALES Y ÉTICAS 45

Las preocupaciones del público 45

Las preocupaciones de la profesión 49

Los derechos de los evaluados 57

CLOSE-UP Evaluación, admisiones y acción afirmativa: *Grutter contra Bollinger et al.* (2003) 50

PSICOMETRÍA COTIDIANA Evaluación psicológica de vida o muerte 55

AUTOEVALUACIÓN 60

UN VISTAZO A LA RED 61

3 Un repaso de estadística 62

ESCALAS DE MEDICIÓN 63

Escalas nominales 64

Escalas ordinales 65

Escalas de intervalo 66

Escalas de razón 66

Escalas de medición en psicología 66

DESCRIPCIÓN DE LOS DATOS 68

Distribuciones de frecuencia 69

Medidas de tendencia central 74

Medidas de variabilidad 77

Asimetría o sesgo 81

Curtosis 82

LA CURVA NORMAL 83

El área bajo la curva normal 83

PUNTUACIONES ESTÁNDAR 86

Puntuaciones z 87

Puntuaciones T 87

Otras puntuaciones estándar 88

PSICOMETRÍA COTIDIANA ¡Alerta, consumidor (de datos gráficos)! 73

CLOSE-UP La curva normal y las pruebas psicológicas 84

AUTOEVALUACIÓN 90

UN VISTAZO A LA RED 91

4 Sobre las pruebas psicológicas y su aplicación 92

ALGUNOS SUPUESTOS SOBRE PRUEBAS Y EVALUACIÓN

PSICOLÓGICA 92

Supuesto 1: Existen rasgos psicológicos y estados 92

Supuesto 2: Los rasgos psicológicos y los estados pueden cuantificarse y medirse 94

Supuesto 3: La conducta relacionada con la prueba predice la conducta
no relacionada con la prueba 95

Supuesto 4: Las pruebas y otras técnicas de medición tienen fortalezas y debilidades 96

Supuesto 5: El proceso de evaluación está sujeto a diversas fuentes de error 96

Supuesto 6: Las pruebas y la evaluación pueden conducirse de una manera justa
y sin prejuicios 97

Supuesto 7: Las pruebas y la evaluación benefician a la sociedad 97

¿QUÉ ES UNA “BUENA PRUEBA”? 98

Confiabilidad 98

Validez 98

Otras consideraciones 99

NORMAS 99

Estandarización, muestreo y normalización 103

Tipos de normas 106

Sistema de calificación con un grupo de referencia fijo 109

Evaluación con referencia a la norma *versus* evaluación con referencia al criterio 110

CORRELACIÓN E INFERENCIA 114

El concepto de correlación 114

La r de Pearson 115

La rho de Spearman 117

Representaciones gráficas de la correlación 118

Regresión 122

INFERENCIA A PARTIR DE LA MEDICIÓN 125

Metaanálisis 125

Cultura e inferencia 125

PSICOMETRÍA COTIDIANA Poniendo a prueba las pruebas 100

CLOSE-UP Las viejas y queridas normas y el GRE 111

AUTOEVALUACIÓN 127

UN VISTAZO A LA RED 128

5 Confiabilidad 129

EL CONCEPTO DE CONFIABILIDAD 129

Fuentes de varianza de error 130

ESTIMACIONES DE CONFIABILIDAD 132

Estimaciones de confiabilidad de prueba y postprueba 132

Estimaciones de confiabilidad de formas paralelas y formas alternas 133

Estimaciones de la confiabilidad de dividir en mitades 135

Otros métodos de estimación de la consistencia interna 137

Medidas de confiabilidad entre evaluadores 140

USO E INTERPRETACIÓN DEL COEFICIENTE DE CONFIABILIDAD 141

El propósito del coeficiente de confiabilidad 141

La naturaleza de la prueba 142

Alternativas para el modelo de puntuación real 146

CONFIABILIDAD Y PUNTUACIONES INDIVIDUALES 149

El error estándar de medición 149

El error estándar de la diferencia entre dos puntuaciones 153

CLOSE-UP Confiabilidad de las escalas Bayley-II 143

PSICOMETRÍA COTIDIANA La defensa de la confiabilidad y la prueba del alcoholímetro 147

AUTOEVALUACIÓN 155

UN VISTAZO A LA RED 155

6 Validez 156

EL CONCEPTO DE VALIDEZ 156

Validez aparente 158

VALIDEZ DE CONTENIDO	159
Cuantificación de la validez de contenido	159
La cultura y la relatividad de la validez de contenido	161
VALIDEZ RELACIONADA CON EL CRITERIO	163
¿Qué es un criterio?	163
Validez concurrente	164
Validez predictiva	164
VALIDEZ DE CONSTRUCTO	175
Evidencia de la validez de constructo	176
VALIDEZ, SESGO E IMPARCIALIDAD DE LA PRUEBA	181
Sesgo de la prueba	181
Imparcialidad de las pruebas	184
CLOSE-UP Tasa base y validez predictiva	172
PSICOMETRÍA COTIDIANA Ajuste de las calificaciones de pruebas de acuerdo a la pertenencia a un grupo:	
¿imparcialidad en la prueba o juego sucio?	186
AUTOEVALUACIÓN	188
UN VISTAZO A LA RED	189

7 Desarrollo de pruebas 190

CONCEPTUALIZACIÓN DE LA PRUEBA	190
Algunas cuestiones preliminares	191
Estudio piloto	193
CONSTRUCCIÓN DE LA PRUEBA	194
Elaboración de escalas	194
Redacción de reactivos	201
Calificación de reactivos	210
ENSAYO DE LA PRUEBA	211
¿Qué es un buen reactivo?	212
ANÁLISIS DE REACTIVOS	212
Índice de dificultad del reactivo	212
Índice de confiabilidad del reactivo	214
Índice de validez del reactivo	214
Índice de discriminación de reactivos	215
Características del reactivo	217
Otras consideraciones en el análisis de reactivos	220
Análisis cualitativo de los reactivos	222
REVISIÓN DE LA PRUEBA	225
Revisión de la prueba como una etapa en el desarrollo de una prueba nueva	225
Revisión de prueba en el ciclo de vida activa de una prueba existente	226
PSICOMETRÍA COTIDIANA La psicometría en el salón de clases	195
CLOSE-UP Diseño de un banco de reactivos	207
AUTOEVALUACIÓN	231
UN VISTAZO A LA RED	231



8 La inteligencia y su medición 232

¿QUÉ ES LA INTELIGENCIA? 232

Definición de inteligencia: puntos de vista del público lego 233

Definición de inteligencia: puntos de vista de expertos y profesionales de las pruebas 234

Teorías de análisis factorial acerca de la inteligencia 236

La perspectiva del procesamiento de la información 241

MEDICIÓN DE LA INTELIGENCIA 243

Tipos de tareas utilizadas en las pruebas de inteligencia 243

La teoría en el desarrollo e interpretación de pruebas de inteligencia 244

INTELIGENCIA: ALGUNOS PUNTOS DE DISCUSIÓN 246

Naturaleza contra crianza 246

La estabilidad de la inteligencia 249

Otros puntos de discusión 251

UNA PERSPECTIVA 261

PSICOMETRÍA COTIDIANA Ser dotado 252

CLOSE-UP Culturalmente imparciales/culturalmente cargadas 258

AUTOEVALUACIÓN 262

UN VISTAZO A LA RED 263

9 Pruebas de inteligencia 264

LAS ESCALAS DE INTELIGENCIA STANFORD-BINET 265

Las escalas de inteligencia Stanford-Binet: quinta edición 268

LAS ESCALAS WECHSLER 273

La escala de inteligencia Wechsler para adultos: tercera edición (WAIS-III) 275

La escala de inteligencia Wechsler para niños, cuarta edición (WISC-IV) 279

La escala de inteligencia Wechsler para niños en edad preescolar y primaria, tercera edición (WPPSI-III) 282

Wechsler, Binet y la versión abreviada 284

Las escalas Wechsler en perspectiva 286

OTRAS MEDIDAS DE INTELIGENCIA 286

Otras pruebas diseñadas para aplicación individual 286

Pruebas diseñadas para aplicación en grupo 291

CLOSE-UP Análisis factorial 287

PSICOMETRÍA COTIDIANA Batería vocacional de aptitudes de servicios de la Armada (Armed Services Vocational Aptitude Battery, ASVAB):

una prueba que puede contestar 293

Medidas de capacidades intelectuales específicas 296

AUTOEVALUACIÓN 298

UN VISTAZO A LA RED 298

10 Evaluación preescolar y educativa 300

EVALUACIÓN PREESCOLAR 300

Herramientas de evaluación preescolar 301

PRUEBAS DE RENDIMIENTO 305

Medidas de rendimiento general 306

Medidas de rendimiento en áreas específicas de conocimiento 307

PRUEBAS DE APTITUD 311

El nivel de educación básica 313

El nivel de educación media 314

El nivel universitario y más allá 316

PRUEBAS DE DIAGNÓSTICO 318

Pruebas de lectura 319

Pruebas de matemáticas 320

Otras pruebas de diagnóstico 321

BATERÍAS DE PRUEBAS PSICOEDUCATIVAS 321

La batería de evaluación para niños de Kauffman (K-ABC) 322

Las escalas de habilidades diferenciales (DAS) 324

La Woodcock-Johnson III (WJ III) 327

OTRAS HERRAMIENTAS DE EVALUACIÓN EN ESCENARIOS EDUCATIVOS 329

Desempeño, portafolios y evaluación auténtica 329

Técnicas de valoración de pares 331

Medición de hábitos de estudio, intereses y actitudes 332

PSICOMETRÍA COTIDIANA Primeras impresiones 302

CLOSE-UP Pruebas de capacidad mínima 309

AUTOEVALUACIÓN 333

UN VISTAZO A LA RED 333

PART E IV *La evaluación de la personalidad*

11 Evaluación de la personalidad: un perfil general 335

DEFINICIÓN Y EVALUACIÓN DE LA PERSONALIDAD 335

Personalidad 335

Evaluación de la personalidad 336

Rasgos, tipos y estados 336

EVALUACIÓN DE LA PERSONALIDAD: ALGUNAS CUESTIONES BÁSICAS 340

¿Quién? 341

¿Qué? 345

¿Dónde? 347

¿Cómo? 347

DESARROLLO DE INSTRUMENTOS PARA EVALUAR LA PERSONALIDAD 355

Lógica y razón 356

Teoría	356
Métodos de reducción de datos	357
Grupos criterio	359
EVALUACIÓN DE LA PERSONALIDAD Y CULTURA	369
Aculturación y consideraciones relacionadas	370
PSICOMETRÍA COTIDIANA	Algunos formatos para reactivos 350
CLOSE-UP	Evaluación de la aculturación y variables relacionadas 372
AUTOEVALUACIÓN	374
UN VISTAZO A LA RED	375

12 Métodos de evaluación de la personalidad 376

MÉTODOS OBJETIVOS	376
MÉTODOS PROYECTIVOS	378
Manchas de tinta como estímulos proyectivos	379
Ilustraciones como estímulos proyectivos	384
Palabras como estímulos proyectivos	391
Sonidos como estímulos proyectivos	394
Elaboración de dibujos	395
Los métodos proyectivos en perspectiva	399
MÉTODOS DE EVALUACIÓN CONDUCTUAL	402
El quién, qué, cuándo, dónde, por qué y cómo	404
Acercamientos a la evaluación conductual	407
Cuestiones relacionadas con la evaluación conductual	414
UNA PERSPECTIVA	417
PSICOMETRÍA COTIDIANA	Confesiones de un calificador conductual 408
CLOSE-UP	Personalidad, éxitos en la vida y las fotografías del anuario universitario 415
AUTOEVALUACIÓN	418
UN VISTAZO A LA RED	418

PARTE V *Pruebas y evaluación en acción*

13 Evaluación clínica y de orientación psicológica 419

SINOPSIS	419
Evaluación clínica y atención administrada	421
Diagnóstico de trastornos mentales	421
LA ENTREVISTA	423
Tipos de entrevista	424
Aspectos psicométricos de la entrevista	428
Aspectos culturales de la entrevista	429
DATOS DE LA HISTORIA CLÍNICA	434

PRUEBAS PSICOLÓGICAS	435
Batería de pruebas psicológicas	435
APLICACIONES ESPECIALES DE MEDICIONES CLÍNICAS	436
Evaluación de adicción y abuso de sustancias	436
Evaluación psicológica forense	438
Evaluaciones de la custodia	446
Abuso y descuido infantil	448
EL REPORTE PSICOLÓGICO	452
El efecto Barnum	452
Predicción clínica contra mecánica	455
CLOSE-UP	La evaluación de la peligrosidad y el Servicio Secreto 440
PSICOMETRÍA COTIDIANA	Elementos de un informe característico de evaluación psicológica 453
AUTOEVALUACIÓN	457
UN VISTAZO A LA RED	457

14 Evaluación neuropsicológica 458

EL SISTEMA NERVIOSO Y EL COMPORTAMIENTO	458
Daño neurológico y el concepto de organicidad	459
EL EXAMEN NEUROPSICOLÓGICO	462
Obtención de antecedentes, historia clínica y estudios de casos	464
La entrevista	466
El examen físico	467
Pruebas neuropsicológicas	469
Baterías de pruebas neuropsicológicas	482
Otras herramientas de evaluación en neuropsicología	485
CLOSE-UP	Baterías de pruebas neuropsicológicas establecidas en oposición a las flexibles y la legislación 483
PSICOMETRÍA COTIDIANA	Auxiliares médicos para el diagnóstico y la evaluación neuropsicológica 486
AUTOEVALUACIÓN	488
UN VISTAZO A LA RED	488

15 Evaluación a personas con discapacidad 490

SINOPSIS	490
Definición de discapacidad	491
Evaluación y adaptación	497
Discapacidad, evaluación y el sitio de trabajo	500
EVALUACIÓN Y DISCAPACIDADES ESPECÍFICAS	504
Discapacidades visuales	504
Discapacidades auditivas	507
Discapacidades visuales-auditivas	510
Discapacidades motoras	507
Discapacidades cognoscitivas	512
EVALUACIÓN BIOPSIOSOCIAL	516
La discapacidad como cuestión de diversidad	517

PSICOMETRÍA COTIDIANA	La Ley Pública 105-17 y el ejercicio profesional cotidiano	493
CLOSE-UP	El testimonio de los expertos	502
AUTOEVALUACIÓN		518
UN VISTAZO A LA RED		519

16 Evaluación, profesión y negocios 520

ELECCIÓN VOCACIONAL Y TRANSICIÓN PROFESIONAL	520
Pruebas de intereses	521
Pruebas de capacidad y aptitud	524
Pruebas de personalidad	531
Otras pruebas	534
DETECCIÓN, SELECCIÓN, CLASIFICACIÓN Y COLOCACIÓN	536
El currículum y la carta de solicitud	537
El formato de solicitud	537
Cartas de recomendación	538
Entrevistas	538
Evaluación del portafolios	539
Pruebas de desempeño	539
Pruebas físicas	541
PRODUCTIVIDAD, MOTIVACIÓN, ACTITUD Y CULTURA ORGANIZACIONAL	544
Pruebas de capacidad cognitiva	544
Productividad	546
Motivación	547
Actitud	551
Cultura organizacional	552
OTRAS APLICACIONES DE LAS HERRAMIENTAS DE EVALUACIÓN	553
Psicología del consumidor	553
La medición de actitudes	556
Métodos de investigación de la motivación	559
CLOSE-UP	Generalización de la validez y la GATB 527
PSICOMETRÍA COTIDIANA	Evaluación de la cultura corporativa y organizacional 554
AUTOEVALUACIÓN	564
UN VISTAZO A LA RED	564

Referencias R-1

Créditos C-1

Índice onomástico I-1

Glosario/índice G-1

Recuerdo haber caminado con algunos compañeros internistas de psicología clínica en el Hospital Bellevue, entrar a un edificio en el complejo del Centro Médico Bellevue-NYU y oír a alguien que señalando a un hombre en la distancia decía: “¡Ahí está David Wechsler!” Ciertamente, ahí estaba una de las leyendas vivientes en el campo de la psicología. Como un estudiante graduado, yo había aprendido a administrar cada una de las pruebas de inteligencia Wechsler e incluso tuve el privilegio de servir como examinador en la reestandarización de una de ellas. Al ver por primera vez a este psicólogo en persona, como un compañero trabajador en Bellevue, me inspiró un sentido de asombro.

Fue durante mi año de interno en Bellevue que por primera vez pensé en escribir un libro de texto acerca de las pruebas, evaluaciones y mediciones en psicología. Estaba obteniendo mucha experiencia clínica en el área de evaluación, completaba una disertación doctoral que involucraba evaluación e impresión administrativa y tenía acceso a algunos de los más renombrados recursos humanos en el campo de la psicología clínica. En ambientes tan diversos como los servicios en Bellevue para pacientes infantiles/adolescentes/adultos, cuarto de emergencia psiquiátrica, servicio de prisión, clínica de pacientes adultos deambulatorios y en salón de juzgados en hospital, la instrucción académica se complementaba con experiencia supervisada con una amplia variedad de dilemas y soluciones relacionadas con la evaluación. Este creciente cuerpo de conocimiento y experiencia reforzó mis ideas en desarrollo sobre la necesidad de un nuevo libro de texto acerca de la evaluación. Este nuevo libro de texto estaría escrito por gente con experiencia práctica y real. No sólo abordaría lo esencial de la psicometría, también tocaría varias áreas de interés para los estudiantes de evaluación que se han preguntado acerca de diversos aspectos de la tarea.

Mi educación y experiencia en el área de pruebas y valoración continuó después de mi año de interno con mi designación como psicólogo senior en el personal de NYU-Bellevue. Manejaba un flujo regular de casos de evaluación y daba instrucciones y supervisaba a los internos de psicología. El trabajo implicaba inmersiones diarias en todas las fases de la evaluación clínica, incluyendo presentaciones de casos de rutina a mis colegas. Un día, mientras charlaba con David Wechsler —la luminaria que había llegado a conocer como colega—, contó una historia de cuando Dan Rather y su equipo de televisión de CBS se habían instalado en su departamento del lado Este. Habían llegado para hacerle una entrevista a fondo sobre el reactivo de la inteligencia, para usarla en su programa de *CBS Reports*. El doctor Wechsler bromeó que no fue sino hasta ese día cuando la gente en su edificio tuvo la noción de que debía ser alguna persona importante; ¡debía de serlo, si Dan Rather lo iba a entrevistar! Incluso mientras el doctor Wechsler hablaba, visualicé el tiempo cuando yo, también, pediría una entrevista formal con él, para brindar mejores conocimientos de alguien de “adentro” para este libro. Pero la entrevista no pudo ser. La muerte del doctor Wechsler precedió a la petición.

Aunque todavía no tuvimos el beneficio de la información personal del doctor Wechsler para la primera edición de este libro, hemos sido, a través del más de un cuarto de siglo en que este libro ha evolucionado, lo bastante afortunados para obtener la información de docenas de otras autoridades en áreas tales como inteligencia, personalidad, estadísticas y cultura. Durante ese periodo, los autores colectivamente ganamos no sólo más experiencia y conocimiento sobre cómo comunicar más efectivamente los principios esenciales de medición en un ambiente organizacional, clínico y escolar, verdaderamente amplio. En estas páginas usted tendrá la oportunidad de cosechar los beneficios de esta experiencia y conocimientos acumulados, así como de incontables horas de investigación diligente para darle a este trabajo la mayor actualidad posible.

Los reseñadores de las ediciones previas de este trabajo tienden a alabar su amplitud y profundidad, que me atrevo a decir han mejorado con la edad. Más allá de la cobertura, creo que encontrarán el estilo y nivel de este libro en algún punto entre “muy accesible” y “bastante atractivo”. Como

ha sido nuestra costumbre, hemos interpuesto elementos de humor en varias formas (caricaturas originales, ejemplos y viñetas) a lo largo del texto. El uso juicioso de los ejemplos humorísticos para capturar y mantener el interés del estudiante es algo novedoso entre los libros de texto de mediciones. ¿Dónde más podría uno buscar una pedagogía que empleara un ejemplo utilizando una distribución bimodal de calificaciones de pruebas de una nueva escuela de oficios llamada *La escuela de estudios en casa de imitadores de Elvis Presley*? ¿Qué hay del uso de ecuaciones de regresión para predecir el promedio en la *Escuela para dentistas de Sade*? Mientras los lectores aprenden sobre el valor nominal, descubren por qué “no obtienen respeto” y cómo eso se ha caracterizado como las “variables psicométricas de Rodney Dangerfield”. Podríamos enumerar más ejemplos, pero reservemos esas sonrisas para una agradable sorpresa cuando se las encuentre en el texto.

También, en aras de atrapar y mantener el interés de los estudiantes, hemos tomado varios ejemplos de la cultura popular, incluyendo los medios populares. Tome nota, por ejemplo, cuando encuentre menciones de programas como *Cambiando espacios*, *Wild On...*, *Iron Chef*, *South Park*, y *Sobreviviente*. Éstos son programas de televisión que los estudiantes ven, y una (sorpresa) referencia a uno de ellos para ilustrar un punto de valoración está diseñada para provocar una agradable sensación de reconocimiento, todo en el contexto de involucrar a los estudiantes con el material. Mientras aprendemos a escribir algún buen reactivo de interés relacionado, por ejemplo, los estudiantes son retados a identificar qué tienen en común actores como Pierce Brosnan, Sean Connery, Timothy Dalton, George Lazenby, David Niven y Roger Moore.

A lo largo, hemos tratado de incorporar material ilustrativo que sea intrigante, relevante y de actualidad. Por ejemplo, en el recuadro de Psicometría cotidiana del capítulo 1, hemos introducido el reactivo de evaluación y ratings al sistema de calificaciones de la sociedad fílmica Motion Picture Association of America's. En el nuevo recuadro de *Close-up* en el capítulo 2 vemos en detalle el caso de la Suprema Corte de Justicia, de *Grutter versus Bollinger et al.* (2003). En ese caso, la corte lidió con reactivos de diversidad en cómo afectan la selección y evaluación de los solicitantes para su admisión en las universidades públicas.

El material novedoso y provocador relacionado con el reactivo ha sido una especie de tradición en cada edición del libro. Discusiones intrigantes se han dado sobre reactivos tan diversos como la Prueba de imágenes Szondi (primera edición), evaluaciones maritales y familiares (segunda edición), evaluación en casa de las respuestas del consumidor a los comerciales de televisión (tercera edición), evaluación asistida por computadora en ambientes institucionales (cuarta edición), y evaluación psicológica de “vida o muerte” (quinta edición). La tradición continúa en el presente libro. Por ejemplo, en el capítulo 12, muchos lectores se sorprenderán al descubrir el coqueteo de B. F. Skinner con las pruebas proyectivas (sí, *ese* B. F. Skinner).

Más allá de los laterales relacionados con la evaluación, hay mucho que es nuevo en esta edición, y nuevo en sí. Por supuesto, hemos actualizado el texto con respecto a las nuevas pruebas que se han publicado desde nuestra última edición. La actualización incluye descripciones de Wechsler, Stanford-Binet, Bender-Gestalt, GRE, y pruebas SAT, entre otras. Por supuesto, hemos actualizado el texto con las nuevas leyes, decisiones judiciales y regulaciones administrativas relacionadas que se han establecido desde la última edición. La cobertura expandida y actualizada se presenta en una variedad de reactivos y áreas, incluyendo

- reactivos culturales relacionados, incluyendo recomendaciones específicas para la evaluación psicológica culturalmente informada
- el modelo médico de discapacidad comparado con el nuevo paradigma de discapacidad
- redacción de reactivos de prueba, incluyendo redacción de reactivos ramificados y banco de reactivos
- evaluación geriátrica
- evaluación en la milicia
- evaluación para cambio de carrera y transición de carrera
- evaluación dinámica
- evaluación biopsicosocial

- las Cinco Grandes, las “Cinco Grandes” de Catell y las “Tres Grandes” de Tellegen
- críticas recientes a los métodos proyectivos, junto con los rebates a esas críticas
- métodos de confirmación de calidad durante el proceso de revisión de pruebas, incluyendo la introducción de nuevos términos como protocolo ancla y corriente de puntuación.

En aras de conservar espacio mientras damos a los estudiantes una forma de referencia rápida y fácil, hemos colocado más material en forma tabular. Nuevas tablas en esta edición incluyen información respecto a

- pros y contras de varias fuentes de información acerca de las pruebas
- ventajas y desventajas del formato de varios reactivos
- pros y contras del grupo tradicional de prueba
- legislación importante, litigio y regulaciones administrativas
- principales exámenes de admisión para profesionales o entrenamiento ocupacional
- los “qué hacer” y “qué no hacer” esenciales en la evaluación con sensibilidad cultural

Complementando todo este nuevo material hay un glosario expandido. Más de 100 nuevos términos se han añadido al glosario en esta edición. Con toda esta nueva y realzada cobertura, el volumen de este libro pudo haberse incrementado con facilidad. En cambio, a través de cuidadoso análisis y redacción, así como una cuidadosa edición, y el uso liberal de Tablas para resumir la información, el tamaño del libro es casi el mismo de las ediciones anteriores. El material inicial de introducción se ha reducido para que el estudiante pueda obtener una rápida visión general del campo. A través del libro, el tamaño de los párrafos se ha reducido en comparación con ediciones anteriores. Material esencial del capítulo 17, “Pruebas y evaluación psicológica asistida por computadora”, se transfirió como apropiado para otros capítulos a lo largo del libro. En verdad, *menos puede ser más*.

Una cosa que *no* ha cambiado en esta edición es nuestra decidida resolución a desarrollar libro de texto de mediciones líder, que aunque muchas veces imitado nunca ha sido igualado ya que

- introduce a los estudiantes a la tarea de evaluar y les da las visiones generales de un amplio rango de herramientas y procedimientos que podrá encontrar en su vida profesional
- familiariza a los estudiantes con el razonamiento detrás de la construcción de pruebas y el racional de varios enfoques a la evaluación
- da al estudiante un sentido del uso apropiado de las pruebas
- da al estudiante un sentido del uso inapropiado de las pruebas
- compele a los estudiantes a pensar en forma activa sobre reactivos relacionados con las pruebas y la evaluación

En el camino se ha hecho un esfuerzo concertado para humanizar el material, para involucrar mejor a los estudiantes. Semejante humanización del material puede verse en la redacción y las ilustraciones, como cuando incluimos interesantes hechos biográficos sobre figuras históricas en la evaluación. Véase, por ejemplo, la nueva declaración y foto del MMPI autor principal James Butcher (figura 11-4). A través del texto se ha hecho un intento para realmente involucrar a los estudiantes vía una intrigante y real ilustración de algunos puntos. Unos ejemplos:

- evaluación psicológica de “vida o muerte” y reactivos relacionados (pp. 55-56)
- emociones humanas en el contexto de cortes categóricos (p. 7)
- el alcoholímetro como punto de partida para una discusión de confiabilidad (p. 147)
- las confesiones de un calificador de conducta (pp. 408-409)

- evaluación a través de medios como evaluación del anuario fotográfico de la escuela (p. 415)
- la utilidad de pruebas para medir la agresividad (p. 338) y peligrosidad (pp. 440-441)

La primera propuesta para este libro fue enviada a los editores a mediados de la década de 1970. En ese documento imaginaba un texto de medición que fuera diferente en puntos clave de cualquier libro existente. Como ocurrió, la primera edición de este texto comenzaría en la forma tradicional en términos de establecer el estándar y luego elevar la barra para la medición de los libros que le siguieran. Sería un texto que sobresaldría en contraste con cualquier otro de la época en términos de contenido, organización, estilo, originalidad y pedagogía, entre otras variables. En cuanto a contenido, por ejemplo, contenía material que no había visto antes —por ahora estándar— en libros de texto de medición. Contrario a las creencias vigentes, pensaba que reactivos como evaluación forense, evaluación neuropsicológica y evaluación de custodia ameritaban cobertura en un libro de texto de mediciones. Habiendo actuado como consultor para empresas y negocios que desarrollaban pruebas comerciales, tales como servicio de pruebas educacionales, apreciaba qué tan valioso sería cubrir aplicaciones relacionadas con los negocios, incluyendo evaluaciones de los consumidores. También había trabajado tiempo completo en la clínica administrando pruebas, quería escribir un capítulo sobre evaluación clínica que impartiera un sentido de primera mano de qué se trata la evaluación clínica. Había enseñado prueba y evaluación, y sabía que muchos estudiantes entraban sintiéndose inseguros en cuanto a estadística básica, de ahí el capítulo 3, Un recordatorio de estadísticas.

El estilo del libro, de alguna manera en tono informal, complementaba también el nuevo contenido. Puesto que había encontrado que mi sentido del humor era una herramienta valiosa en mis clases, intenté intercalar algo de “personalidad” e ilustraciones humorísticas en el escrito. Como siempre había disfrutado leer aspectos históricos de la tarea, incluí fotos de figuras históricas en la evaluación, completadas con interesantes datos biográficos. De ésta y muchas otras maneras, la primera edición representaba una partida importante de lo que había disponible en libros de texto de medición. Nuestra nueva forma de definir qué podría ser un libro de texto de medición puede caracterizarse como mágica, juzgando por la abrumadora respuesta positiva que desató por parte de los maestros que enseñaban cursos de medición.

Tras la publicación de la primera edición, aprendí que mucha gente en el campo encontraba los aspectos únicos de este libro muy atractivos. Una de estas personas era Lee J. Cronbach, que compartía conmigo, cuando nos conocimos en una junta del APA, cuánto había disfrutado el libro. Estaba tan agradecido con Lee por su aliento, y me sentí tan entusiasmado por nuestro encuentro, que a continuación le pedí una foto que se publicó en la siguiente edición, a pesar de que entonces Lee tenía un libro de medición que podía considerarse competencia directa. Aun así, quería que el lugar relevante de Lee fuera reconocido, y le quería agradecer en mi propio estilo por sus amables palabras y “sello de aprobación”.

Más allá del contenido y estilo, este libro era único en términos de su organización. Aquí, realmente no había magia, sólo lógica. Comenzamos con unos pocos capítulos para tener una visión general del campo, le dimos una perspectiva histórica, y le proveímos con un importante soporte en lo relacionado a reactivos legales, éticos y culturales. Después del recordatorio de estadística, procedimos con varios capítulos diseñados para impartir las bases esenciales de la medición. La lógica dictaba que antes que cualquier discusión sobre la evaluación de la inteligencia, personalidad o lo que fuera, alguna información preliminar respecto de la definición y reactivos relacionados debería precederla. Lo que siguió fueron varios capítulos diseñados para ilustrar diversos aspectos de la medición aplicada en varios contextos. Había servido como consultor para muchas empresas, y era fundador y editor en jefe de la revista profesional *Psychology & Marketing* que regularmente presentaba artículos que detallaban la aplicación profesional de la medición, y sentí que tenía información valiosa y única para ofrecerle a los estudiantes tomando un curso en la materia.

Resultó que la organización de nuestro libro ha sido tan atractiva que casi todos los libros de texto sobre el tema publicados desde entonces, siguen la misma fórmula o una similar. De hecho, los reseñadores algunas veces se han referido a estos libros similares como “clones de Cohen” o

“aspirantes a Cohen”. Mi propia caracterización se inclinaría más hacia la última definición, pues clon implica una réplica exacta; todas las copias de los “aspirantes” son pálidas imitaciones.

La imitación es la forma más sincera de la admiración, y vemos con un sentido de gratificación que otros traten de capitalizar sobre nuestro éxito. Pero mientras que los aspirantes pueden imitar nuestra organización e incluso algunas ilustraciones o partes, hay mucho que no pueden copiar. No pueden (o son incapaces de) copiar nuestro estilo. No humanizan el material como lo hacemos. No pueden copiar nuestro contenido líder porque son, por su propia naturaleza, seguidores. Les tomará una edición o dos, por ejemplo, incorporar el nuevo material de esta edición. Para algunos reactivos, como las mediciones y las relaciones culturales, los aspirantes tienen un largo camino que recorrer para alcanzarnos. Algunos aspirantes se separan de nuestra organización de capítulos cubriendo los aspectos ético/legales al final y no al principio. En lo personal veo esto mal, pues estos asuntos nos ayudan a ubicar la discusión sobre medición, evaluación y prueba en perspectiva. También, a menos que los capítulos finales se asignen rápidamente en el curso, existe la posibilidad de que muchos estudiantes no estén expuestos a esta información tan importante.

Otra manera clave en la que este libro se separa de los libros comparables está en la forma en que los reactivos de prueba y evaluación se distinguen. En un tiempo anterior existían múltiples razones para titular a un libro como este Prueba psicológica y proceder a amontonar todos los reactivos de prueba y evaluación juntos en la discusión. Actualmente es importante distinguir entre prueba y evaluación, por ello creemos que semejante título sería anacrónico, si no es que confuso, en términos del material que se cubre. Creemos que es importante que los autores nuevos hagan una distinción clara entre ambos términos. Nosotros hacemos eso en las primeras páginas en un esfuerzo para orientar al estudiante en todo lo que sigue. También pensamos que es una sólida práctica de enseñanza mantener la distinción de la definición de esos términos a lo largo del libro. De corazón alentamos a los instructores a ejercitar un pensamiento crítico con respecto a qué tan bien hacen esta separación los libros de texto que compiten con éste, empezando por el título, y que mantienen esa distinción todo el tiempo. Y hablando de pensamiento crítico...

Pensamiento crítico puede definirse como “el uso activo de las capacidades de juicio y capacidades de evaluación en el proceso del pensamiento” (Cohen, 1994, p. 12). El pensamiento generativo puede definirse como “la producción intelectual orientada hacia la meta de ideas nuevas o creativas” (Cohen, 1994, p. 13). El ejercicio de ambos procesos, creo, ayuda a optimizar las oportunidades de éxito en el mundo académico, así como en otros campos profesionales. En ediciones anteriores se plantearon preguntas para estimular el pensamiento crítico y el generativo “al estilo antiguo”. Esto es, estaban bien en el texto, y usualmente como parte de un párrafo. Siguiendo el consejo de nuestros reseñadores, hemos hecho aún más especial esta sección especial de nuestro libro, al escribir más preguntas y colocarlas en los márgenes. Ahora corresponde a nuestros estudiantes motivados hacer su parte y de hecho pensar en las preguntas de Sólo piense... En este contexto, los maestros pueden considerar si dar puntos extra por escribir respuestas a las preguntas de Sólo piense... motivará a los estudiantes.

Además de las preguntas para el pensamiento crítico y el pensamiento generativo que se plantean en el texto, otras ayudas pedagógicas en este libro incluyen caricaturas e imágenes originales creadas por los autores (incluyendo el modelo de memoria en el capítulo de evaluación neuropsicológica) y acrónimos originales creados por los autores.

Hemos ofrecido un libro de texto para los estudiantes, un manual para los maestros y un banco de reactivos de pruebas como parte del paquete de enseñanza con cada edición de este libro desde la primera. Ediciones recientes han incrementado este excelente paquete de enseñanza con ayudas para el estudiante por medio de Internet, así como consejos para los maestros y un foro de discusión para maestros.

Los autores se han enfocado con diligencia en sus esfuerzos por ofrecerle un libro de texto de medición líder que involucre a los estudiantes en la materia y que imparte un cúmulo de conocimientos académicos y de información aplicada esencial para entender las pruebas psicológicas y su evaluación. Mark Swerdlik perseveró en estos objetivos bajo condiciones retadoras desde la última edición. Durante ese periodo Mark perdió a su madre Edna (1912-2003); su padre Al (1910-2002), y su tío Aaron Swerdlik (1917-2002), quien tiene la distinción de ser un lego en la materia que leyó el libro de cabo a rabo. Mark dedica sus contribuciones en esta edición a la memoria de estos queridos miembros de su familia.

Cuando estábamos por terminar el trabajo en esta edición, recibí la noticia inesperada de que mi madre había sufrido un derrame. No sobrevivió. Es imposible expresar la sensación de tristeza y pérdida que experimenté junto con mi hermano y mi hermana, así como las incontables personas que conocieron a estas gentiles, amables y amadas personas. Extrañaremos su consejo, su sentido del humor, y el sólo saber que estaba ahí para nosotros. La extrañaremos con la genuina excitación que nos provocaba verla con sus brazos estirados cuando íbamos a visitarla. Sus hijos eran su vida, y la memoria de su rostro sonriente, que nos hacía sentir tan especiales a cada uno de nosotros, sobrevive como una fuente privada de paz y confort para todos nosotros. Ella mantenía orgullosa una copia de este libro sobre su mesa de café; uno no necesita ser un experto en evaluación para entender el significado de eso. Mi dedicatoria en este libro es sólo una de las pequeñas formas en que puedo reconocer qué tan especial era ella para mí. Viendo las fotos del álbum familiar busqué una para incluirla, quizá no sea sorprendente que pocas fotos existieran de ella sola. Por esa razón decidí usar la foto de la boda de mis padres. Eran tan buenos juntos. Así están ahora, reunidos. Eso es algo que la haría muy feliz.

Nuestro agradecimiento también va al profesional y maravilloso personal editorial, de producción y mercadotecnia de McGraw-Hill, incluyendo a John Wannemacher, Jane Acheson, Jen Mills, Melissa Caughlin, Courtney Cooney, y a la siempre grandiosa free lancer April Wells-Hayes. Gracias al asistente graduado Adam Godfrey por la cuidadosa investigación de biblioteca que excedió nuestras expectativas. Gracias a Rajan Natarajaan por las consultas cuantitativas cada vez que había una plétora de letras griegas en las fuentes de referencia. Finalmente, los autores agradecen a los miembros de sus familias: yo agradezco a mi esposa Susan y mi hijo Harrison; Mark agradece a su esposa Peggy, su hijo Danny y su hija Jenny, junto con su esposo John, por su apoyo durante las muchas horas, días, meses y años que hemos dedicado a esta tarea de amor.

Ronald Jay Cohen, Ph.D., ABAP

Pruebas y evaluación psicológica

En todos los campos del esfuerzo humano se utilizan medidas de una u otra forma, y cada campo posee su propio sistema, compuesto por herramientas y unidades de medición. Si se acaba de comprometer en matrimonio o piensa hacerlo, tal vez haya oído sobre la unidad de medida llamada *quilate*; Si usted compró una computadora, es posible que haya escuchado sobre la unidad de medida llamada *byte*. Y si necesita aire acondicionado, seguramente querrá saber sobre el BTU (unidad térmica británica). Otras unidades de medición con las que se puede o no estar familiarizado son la *milla*, la *milla náutica*, la *milla por hora* y los *ciclos por segundo*. Los profesionales en los campos que utilizan estas unidades, conocen sus usos potenciales, beneficios y limitaciones en las mediciones que realizan con ellas. Por ende, también los usuarios actuales y potenciales de las mediciones psicológicas necesitan familiarizarse en el trabajo con las unidades de medida comúnmente utilizadas, los fundamentos teóricos que las contextualizan y las herramientas empleadas según los objetivos de la medición.

Pruebas y evaluación

Las raíces del surgimiento de las pruebas psicológicas y la evaluación tal y como se concibe hoy en día, datan de principios del siglo XX en Francia. En 1905, Alfred Binet y un colega publicaron una prueba diseñada para asignar el grado escolar apropiado para niños parisinos. La prueba de Binet tendría consecuencias más allá del distrito escolar de París. Al paso de una década se utilizó una versión en inglés de la prueba estructurada por Binet para escuelas de Estados Unidos.

Cuando Estados Unidos declaró la guerra a Alemania y participó en la primera guerra mundial en 1917, el ejército necesitaba una forma para evaluar rápidamente a grandes cantidades de reclutas para descartar problemas intelectuales y emocionales. Las pruebas psicológicas aportaron esta metodología necesaria para lograrlo. Durante la segunda guerra mundial, el ejército se apoyó aún más en las pruebas psicológicas para evaluar a los reclutas interesados en el servicio militar. Después de la guerra se desarrollaron y utilizaron un mayor número de pruebas que pretendían medir una amplia gama de variables psicológicas.

Definición de pruebas psicológicas y evaluación

La apertura que el mundo tuvo con respecto a las pruebas desarrolladas por Binet a principios del siglo XX no sólo produjo más herramientas de este tipo, también surgieron más autores, publicadores y usuarios de pruebas también emergiendo por lógica, lo que a la fecha se conoce como “la industria de las pruebas”. *Pruebas* fue el término utilizado para referirse a todo lo relacionado

con la aplicación de una prueba (como “Prueba en progreso”) y la interpretación de la puntuación y resultados obtenidos de la misma (“Las pruebas indicaron que...”). Durante la primera guerra mundial, el proceso de las pruebas determinó de manera óptima un grupo experimental obtenido mediante la evaluación de miles de reclutas militares. Se sospecha que esto sucedió al mismo tiempo en que las *pruebas* lograron el reconocimiento e inserción en el vocabulario de los profesionales y de la gente en general. El uso del término *pruebas* para denotar todo, desde la aplicación hasta la interpretación de una prueba, puede encontrarse no sólo en libros de texto de la posguerra (como Chapman, 1921; Hull, 1922; Spearman, 1927), sino en muchos otros escritos relacionados con el tema publicados décadas posteriores. Sin embargo, en la segunda guerra mundial, inicia el surgimiento de una distinción semántica entre pruebas y un término más inclusivo, *evaluación*.

Durante la segunda guerra mundial, la Oficina de Servicios Estratégicos de Estados Unidos (OSS) utilizó diversos procedimientos y herramientas de medición, entre ellos pruebas psicológicas, en la selección de personal militar para puestos especializados que involucraban actividades tales como espionaje, manejos de inteligencia militar y otros procesos similares. Como se resume en “Evaluación humana” (OSS, 1948) y en otras fuentes (Murray y Mackinnon, 1946), los datos generados por la evaluación, estaban sujetos a la integración e interpretación por parte de personal altamente capacitado, provenientes de centros de evaluación. El modelo de la OSS, el cual utilizó diversas herramientas innovadoras de evaluación, así como la interpretación de los datos obtenidos por personas altamente capacitadas, inspiró más tarde lo que ahora se conoce como **enfoque del centro de evaluación** para la evaluación de personal o Assessment Center (Bray, 1982).

Escenarios militares, clínicos, educativos y de negocios son algunos de los muchos contextos que implican observaciones conductuales y la integración activa de pruebas y otros datos por parte de evaluadores. En esas situaciones es preferible el término *evaluación* al de *pruebas*. El término *evaluación* implica que las pruebas son sólo un tipo de herramienta utilizada por evaluadores profesionales y que la valoración de los datos arrojados, está íntimamente ligada al conocimiento, habilidad y experiencia del evaluador. Como observaron Sundberg y Tyler (1962), “*Las pruebas son herramientas. En manos de alguien torpe o de una persona sin escrúpulos, se convierten en perversiones pseudocientíficas*” (p. 131, énfasis en el original). En la mayoría de los contextos de evaluación, es el proceso en sí mismo el que da vida y significado a las puntuaciones obtenidas en las pruebas.

Evaluación psicológica, un libro de texto sobre medición de Maloney y Ward (1976), hizo eco sobre la dificultad que tienen los psicólogos en el uso anacrónico de “pruebas psicológicas” para describir sus tan variadas actividades relacionadas con la evaluación. Al articular varias diferencias entre pruebas y evaluación, Maloney y Ward clarificaron la compleja estructura de los minuciosos procesos de resolución de problemas involucrados en la evaluación psicológica —diferenciándolos de aquellas tareas más sistematizadas y relacionadas a la calificación de las pruebas—.

Maloney y Ward concibieron la evaluación como un proceso de resolución de problemas que podía tomar diferentes formas. La conducción de una evaluación depende de muchos factores, no sólo de aquel que constituye la razón para la evaluación. Diferentes herramientas de evaluación, entre ellas distintas pruebas psicológicas, deben estar presentes en el proceso de la evaluación, determinadas por los objetivos particulares, las personas y circunstancias específicas en el momento de la misma, así como otras variables únicas, generadas por el contexto y ambiente. Por el contrario, se consideró que las pruebas psicológicas tenían un alcance mucho más reducido, ya que sólo se refería al “proceso de aplicar, calificar e interpretar las pruebas psicológicas” (Maloney y Ward, 1976, p. 9). El examinador es un punto clave en el proceso de evaluación, en el que las decisiones, predicciones, o ambas, se realizan a partir del mayor número de fuentes de información (incluidas las pruebas).

Maloney y Ward también distinguieron entre pruebas y evaluación en función de sus objetivos. Al realizar una prueba, un objetivo típico es el medir la magnitud de algún atributo o rasgo psicológico. Por ejemplo, se puede hablar de *pruebas de inteligencia* si el propósito de aplicar una prueba es obtener una cuantificación del funcionamiento intelectual del individuo o grupo de individuos a quienes se aplica la prueba. En la evaluación, la cual se realiza de forma personalizada, el objetivo suele extenderse más allá de la obtención de una cifra o de un coeficiente

intelectual. En este contexto, no es de sorprenderse que el uso del término *prueba de inteligencia* sea obsoleto. De hecho, ésta parece ser la tendencia entre los autores que crearon y desarrollaron los principales instrumentos para medir la inteligencia.

Publicada en 2002, la tercera edición de la *Escala Wechsler de inteligencia para preescolares y niños en edad escolar* (WPPSI-III, Wechsler, 2002) se introdujo en el manual de aplicación como “un instrumento clínico aplicado de manera individual para evaluar la inteligencia de los niños” (p. 1). Gale H. Roid (2003b, p. 2) presentó la quinta edición de la *Escala Stanford-Binet* (SB5, Roid, 2003a) como “una evaluación individual de la inteligencia y habilidades cognitivas”. La cuarta edición de la *Escala Wechsler de inteligencia para niños* (WISC-IV, Wechsler, 2003) se presentó como “un instrumento de uso y manejo clínico de aplicación individual para evaluar la inteligencia de los niños” (p. 1). En cada una de estas descripciones introductorias *evaluación* o *evaluar* es una palabra clave y la palabra *prueba* queda eliminada.

En diversas situaciones de evaluación, se prefiere el término *evaluación* al de *pruebas*. Considere, por ejemplo, una evaluación de la inteligencia de un estudiante diseñada para responder preguntas referentes a su habilidad para desenvolverse en un salón de clases regular. Tal evaluación debe explorar no sólo las fortalezas y debilidades intelectuales del estudiante, sino también las habilidades sociales y de juicio lógico-práctico. Por el contrario, las pruebas “podrían aplicarse sin tomar en cuenta preguntas específicas para cuantificar las actitudes mencionadas e incluso sin que el examinador tenga contacto directo con el cliente o examinado” (Maloney y Ward, 1976, p. 9).

En las pruebas, el aplicador agregará por lo general “la cantidad de respuestas correctas o de cierto tipo de respuestas... con muy poca o ninguna atención sobre los mecanismos empleados para la obtención de la información” (Maloney y Ward, 1976, p. 39). La evaluación es más apta para enfocarse en la forma en la que el individuo procesa más que en los *resultados* de ese proceso. Por tanto, sirve para metas y propósitos variados.

En relación con el conjunto de datos de la evaluación psicológica, Maloney y Ward (1976) afirmaron que, más allá del uso de las pruebas psicológicas por sí mismas, “literalmente, cualquier método que pueda utilizar el examinador para hacer observaciones relevantes es apropiado” (p. 7). Años más tarde, Roberts y Magrab (1991) argumentaron que la evaluación no era una actividad que debía confinarse a un consultorio. Para ellos, la evaluación implicaba menos énfasis en la medición y cuantificación de los rasgos y más énfasis en el entendimiento de los problemas dentro del contexto social. Para lograr ese entendimiento, la evaluación debe incluir observaciones de las actividades diarias o dentro de los contextos-ambientes en los cuales se desenvuelve el evaluado.

La distinción semántica entre *pruebas psicológicas* y *evaluación psicológica* es confusa, incluso muchos libros de texto hacen poca distinción entre los dos términos. No obstante, la diferenciación es importante. Se sirve mucho mejor a la sociedad al hacer una definición clara y una distinción entre estos dos términos así como entre términos relacionados, tales como *usuario de una prueba psicológica* y *evaluador psicológico*. En la sección “Características del usuario de pruebas”, en el capítulo 2, se puntualiza que las claras distinciones entre esos términos no sólo sirven al bien general, también ayudan a evitar competencia desleal entre los psicólogos y diferentes usuarios de pruebas psicológicas. Es cierto que la línea entre lo que constituye las pruebas y lo que constituye la evaluación, no siempre es tan clara como se quisiera. Sin embargo, al reconocer que existe tal ambigüedad, se puede trabajar para afinar la definición y el uso de los términos; negar o ignorar sus diferencias no ofrece esperanzas de un remedio satisfactorio.

Evaluación psicológica se define como la recolección e integración de datos relacionados con la psique individual con el propósito de hacer una evaluación psicológica, concretada mediante el uso de herramientas como pruebas, entrevistas, estudio de caso, observación conductual, así como equipos y procedimientos diseñados específicamente para la medición de ésta. **Pruebas psicológicas** se define como el proceso para medir variables relacionadas con la psique mediante instrumentos o procedimientos diseñados para obtener rasgos de comportamientos definidos como conductas.

SÓLO PIENSE...

Describa una situación en la que las pruebas sean más apropiadas que la evaluación. Después describa un caso contrario.

El proceso de evaluación En general, el proceso de evaluación comienza con una sugerencia de evaluación proveniente de fuentes específicas como son un profesor, un psicólogo escolar, un consejero, un juez, un médico o un analista de recursos humanos. Por lo general, se proponen una o más preguntas de referencia sobre el individuo a evaluar. Algunos ejemplos de preguntas de referencia son: “¿Este niño puede desenvolverse de forma adecuada en un salón de clases regular?” “¿Este acusado es capaz de entender las implicaciones del juicio que se le sigue?” y “¿Cómo sería el desempeño de este empleado si se le asciende a un puesto ejecutivo?”

El evaluador puede reunirse con la persona que será evaluada y/o con aquellas personas relacionadas con el proceso de evaluación antes de la misma, con el fin de clarificar aspectos sobre la razón o razones por las que fue referida. Después viene la evaluación formal, durante la cual el evaluador empleará, por lo general, pruebas y otras herramientas que le ayuden a responder las preguntas de referencia; después de eso, el evaluador escribe un informe de los resultados obtenidos. También pueden programarse más sesiones de retroalimentación personal con el evaluado o con terceros involucrados (como los padres del evaluado o el profesional que refiere a la persona).

Diferentes evaluadores pueden enfocar la tarea de evaluación de muchas maneras. Algunos evaluadores enfocan la evaluación con un mínimo de datos aportados por parte de los evaluados. En este enfoque, el objetivo principal del evaluador está en las puntuaciones de las pruebas, en los datos obtenidos en las entrevistas e historia de desarrollo, así como otros datos disponibles derivados de la evaluación formal. Otros evaluadores ven el proceso de evaluación más como una colaboración entre el evaluador y el evaluado. Por ejemplo, en el proceso de la **evaluación psicológica colaborativa**, descrita por Constance Fischer (1978), el evaluador y el evaluado pueden trabajar como “socios” desde el contacto inicial hasta la retroalimentación final. En este enfoque se considera al evaluado como “un experto en sus perspectivas actuales y en los eventos que recuerda de su vida” (Fischer, 2004, p. 14).

Otra variedad de evaluaciones colaborativas puede incluir un elemento de terapia como parte del proceso. Stephen Finn y sus colegas (Finn, 2003; Finn y Martin, 1977; Finn y Tonsager, 2002) describieron la **evaluación psicológica terapéutica** como un enfoque que promueve un autodescubrimiento terapéutico y lograr una mayor comprensión de determinados aspectos de la conducta a través del proceso de evaluación. Un término cada vez más usado relacionado con las pruebas y la evaluación en las escuelas es *evaluación dinámica*. La **evaluación psicológica dinámica** puede definirse como un modelo y filosofía de una evaluación interactiva que implica diversos tipos de intervención del evaluador durante el proceso de la evaluación. Por ejemplo, un evaluador puede intervenir con sugerencias, retroalimentación o consejos mucho más explícitos, no sólo para evaluar lo que ya sabe el evaluado, sino también para modificar de manera efectiva y con ello cambiar la perspectiva de aproximación del evaluado hacia el problema o tema por el cual es referido. Aunque se han escrito aspectos del modelo de evaluación dinámica al menos desde la década de 1920 (Lidz, 1987), no fue sino hasta las décadas de 1970 y 1980 cuando se publica un gran número de herramientas que incorporaban este enfoque (Lidz, 1991, 1996).

Evaluaciones alternativas Las enmiendas a la *Declaración de los individuos con discapacidades educativas* (IDEA, por sus siglas en inglés), PL 105-17, se transformó en ley a partir de 1997. Muchas de las disposiciones de las enmiendas de IDEA se exponen en otras partes de este libro. Por ahora, sólo se hará referencia a una sección de esta ley que introduce el término *evaluación alternativa*. Esta sección establece que el Estado o la agencia educativa local “(i) debe desarrollar guías para la participación de niños con capacidades diferentes en evaluaciones alternativas, haciendo hincapié en aquellos niños que no pueden participar en programas de evaluación distritales y estatales; con el fin de (ii) desarrollar y... conducir las evaluaciones alternativas”.

La PL 105-17 no define “evaluaciones alternativas”. Sin embargo, un análisis de las prácticas de evaluadores hechas con anterioridad, donde participaron estudiantes con necesidades educativas especiales, ilustrará el concepto. Por ejemplo, a un estudiante que tiene dificultad para leer la letra pequeña de una prueba en particular, se le puede dar una versión de la misma prueba con letra más grande, o se le puede adecuar un ambiente iluminado especialmente para la prueba. A un estudiante con debilidad auditiva se le puede aplicar la prueba usando el lenguaje

de señas. Un niño con trastorno por déficit de atención (TDA) podría tener extensiones en los tiempos de la evaluación, con descansos frecuentes durante el proceso.

Hasta ahora, el proceso de la evaluación alternativa podría parecer muy simple y directo; sin embargo, en la práctica no es así. Considere, por ejemplo, el caso de un estudiante con debilidad visual, a quien se le cita para aplicarle una prueba escrita de opción múltiple con un procedimiento alternativo. Existen muchos procedimientos alternativos posibles, por ejemplo, la prueba podría traducirse al Braille y aplicarse en esa forma, o mediante un audiocasete. El hecho de que la prueba se administre en Braille o en audiocasete puede afectar la puntuación de la prueba; a algunos estudiantes se les puede facilitar la aplicación con el sistema Braille y a otros con el audiocasete. Los estudiantes con habilidad para mantener la atención selectiva a corto plazo y con un buen desempeño de la memoria para estímulos auditivos parecerían estar en ventaja con la versión en audiocasete. Los estudiantes con un sentido del tacto superior y habilidades motoras perceptivas podrían tener ventaja con la prueba en sistema Braille.

Algunos métodos alternativos pueden tomar la forma de tareas basadas en el desempeño y no de tareas mecánicas (a lápiz y papel). Por ejemplo, los estudiantes cuyas habilidades matemáticas no puedan evaluarse mediante preguntas a lápiz y papel, pueden realizar tareas como dar cambio o hacer compras en un contexto real y con ello hacer una medición de dichas habilidades. Otro método alternativo implica la evaluación de un conjunto de muestras del trabajo del evaluado a través del tiempo.

Pueden surgir muchas preguntas importantes sobre la equivalencia de varias evaluaciones alternativas y tradicionales. ¿Hasta qué punto cada método mide en realidad lo mismo? ¿Qué tan equivalente es la prueba alternativa con la original? ¿De qué manera, la modificación del formato original de una prueba, de los manejos de tiempos o de cualquier otro aspecto relacionado con el diseño original de la prueba, afecta las puntuaciones de la misma? Y después de contemplar situaciones tan complejas, ¿cómo se podría definir la *evaluación alternativa*?

Sin perder de vista las complejidades implicadas, a continuación se propone la siguiente definición de este proceso un tanto alusivo: **evaluación alternativa** es un proceso o procedimiento de evaluación o diagnóstico que varía en la forma de aplicación usual, normativa o estandarizada para obtener una medición, ya sea en virtud de una adecuación determinada hecha para el evaluado, o con métodos alternativos diseñados para medir la(s) misma(s) variable(s). Esta definición evita la espinosa cuestión de la equivalencia de métodos. A menos que los procedimientos alternativos hayan sido investigados a profundidad, no hay ninguna razón para esperar que sean equivalentes. En la mayoría de los casos, como los procedimientos alternativos han sido adaptados de manera individual, rara vez se realizan investigaciones que apoyen la equivalencia. Lineamientos gubernamentales para la evaluación alternativa evolucionarán para incluir maneras de trasladar procedimientos de medición de un formato a otro.

Toda esta plática sobre la evaluación puede conducir a la pregunta ¿cómo se conducen de manera típica las evaluaciones y qué herramientas se utilizan? No obstante, antes de continuar, intente realizar el ejercicio “Sólo piense...”

SÓLO PIENSE...

Mencione algunas herramientas de la evaluación psicológica distintas a las pruebas. Para cada herramienta, describa una situación en la que su aplicación sea ideal.

Las herramientas de la evaluación psicológica

La prueba Una **prueba** puede definirse tan sólo como un instrumento o procedimiento de medición. Cuando la palabra *prueba* está acompañada por un modificador, se refiere a un instrumento o procedimiento diseñado para medir una variable relacionada con ese modificador. Considere, por ejemplo, el término *prueba médica*, la cual se refiere a un instrumento o procedimiento diseñado para medir alguna variable relacionada con la práctica de la medicina (incluido un amplio rango de herramientas y procedimientos como los rayos X, pruebas de sangre, y prueba de reflejos). De una manera similar, el término **prueba psicológica** se refiere a un instrumento o procedimiento diseñado para medir variables relacionadas con la psicología (por ejemplo, inteligencia, personalidad, aptitudes, intereses, actitudes y valores). Y mientras que una prueba médica puede

implicar el análisis de una muestra de sangre, de un tejido, etcétera, una prueba psicológica generalmente implica el análisis de una forma de comportamiento. La forma de comportamiento puede variar desde las respuestas de un cuestionario por escrito, respuestas orales a preguntas, hasta el desempeño de alguna tarea. La muestra del comportamiento puede ser originada por el estímulo de la prueba misma o puede ser un comportamiento que ocurre de manera natural (bajo observación).

Las pruebas psicológicas y otras herramientas de evaluación pueden diferir en un gran número de variables como contenido, formato, procedimientos de aplicación, puntuación, contextos de interpretación y calidad técnica. El *contenido* (o los temas) de la prueba, por supuesto, variarán de acuerdo al enfoque teórico que la prueba maneje. Pero aun cuando dos pruebas psicológicas tienen el propósito de medir lo mismo —por ejemplo, la *personalidad*— pueden diferir de una manera amplia en los contenidos debido a factores como la definición de personalidad que el autor de la prueba maneje, así como el marco teórico de referencia. Por ejemplo, los reactivos de la prueba de la personalidad orientada a partir de la teoría psicoanalítica, deben tener muy poco parecido a las pruebas de personalidad orientadas desde un enfoque existencial, y sin embargo, ambas son pruebas de personalidad.

El término **formato** le pertenece a la forma, al plan, a la estructura, arreglo o disposición de los reactivos de la prueba, así como a las consideraciones específicas, como los límites de tiempo establecidos. *Formato* también se utiliza para referirse a la forma en que se aplica una prueba: computarizada, con lápiz y papel o alguna otra forma. Cuando se hace referencia específica a una prueba computarizada, el *formato* también puede referirse a la forma del software: IBM o compatible con Apple. El término *formato* no sólo se destina a las pruebas; también se utiliza para denotar la forma o estructura de otras herramientas y procesos de evaluación, como los procedimientos específicos usados para obtener un tipo particular de ejecución.

Las pruebas difieren en sus *procedimientos de aplicación*. Algunas pruebas, en particular aquellas diseñadas para aplicarse en forma individual, pueden requerir de un aplicador muy activo y con mucho conocimiento. La aplicación de una prueba puede implicar la demostración de varios tipos de tareas por parte del evaluado, así como la observación del desempeño del evaluado. De manera alternativa, algunas pruebas, en particular aquellas diseñadas para aplicarse en grupos, tal vez no requieran que el aplicador de la prueba esté presente mientras los que la contestan, lo hagan de forma individual.

Las pruebas difieren en los *procedimientos de calificación e interpretación*. Para entender mejor cómo y por qué, es preciso definir *puntuación* y *calificación*. Los aficionados a los deportes están familiarizados con estos términos. Para ellos, se refieren al número de puntos que acumulan los competidores y el proceso o forma en la que acumulan esos puntos. En las pruebas y la evaluación, se puede definir formalmente la puntuación como un código o proceso sumatorio de puntos, por lo general, aunque no necesariamente de naturaleza numérica, el cual refleja una evaluación del desempeño en una prueba, tarea, entrevista u otras formas de conducta. **Calificación** es el proceso de asignar esos códigos o puntajes evaluativos al desempeño en las pruebas, tareas, entrevistas u otras formas de conducta. Algunas puntuaciones resultan de la simple suma de respuestas (como la suma de respuestas correcto/incorrecto o de acuerdo/en desacuerdo) y algunas puntuaciones resultan de la aplicación de procedimientos más elaborados.

Las puntuaciones mismas pueden describirse y categorizarse de muchas maneras. Aquí se considerará una categoría de calificación: la **puntuación de corte** (también llamada *corte*), que es un punto de referencia, por lo general numérico, determinado a través de juicios lógicos y utilizado para dividir una serie de datos en dos o más clasificaciones. Algunas acciones serán determinadas o algunas inferencias se realizarán a partir de la base de esta clasificación. Las puntuaciones de corte en las pruebas, generalmente relacionadas con otros datos, se utilizan en las escuelas en diversos contextos, tales como para establecer el grado, programa o clase en el cual será asignado un niño en particular. Las personas encargadas de la contratación laboral, utilizan las puntuaciones de corte como una ayuda en la toma de decisiones para elegir a los candidatos y el desarrollo organizacional de su personal. Las oficinas gubernamentales utilizan las puntuaciones de corte para determinar a quién se le dará licencia como profesional en un campo determinado. Es probable que existan más de 20 métodos diferentes que pueden usarse de manera formal para derivar puntuaciones de corte (Dwyer, 1996).



Figura 1-1
Emoción generada por cortes categóricos

De acuerdo con la investigación realizada por Victoria Husted Medvec et al. (Medvec et al., 1995; Medvec y Savitsky, 1997), las personas que sólo hacen algún corte categórico pueden sentirse mejor sobre su cumplimiento que aquellas que hacen el corte por un margen importante. Pero los que pierden el corte por un mínimo de error pueden sentirse peor que aquellos que lo pierden por un margen sustancial. En una investigación con atletas olímpicos se presentó evidencia consistente con esta visión. Los medallistas de bronce estuvieron, de manera paradójica, más felices con el resultado que los medallistas de plata. Los ganadores de bronce podrían decirse a sí mismos, “Al menos gané una medalla” y estar felices al respecto. En contraste, los medallistas de plata se podrían sentir frustrados por haber ido a ganar la medalla de oro y haberla perdido.

En ocasiones, no se utilizan métodos formales para llegar a una puntuación de corte. Algunos profesores usan un método informal, según su percepción, para certificar, por ejemplo, que una puntuación de 65 o más en una prueba significa “aprobado”, y una puntuación de 64 o menos significa “reprobado”. Ya sean derivados de manera formal o informal, las puntuaciones de corte típicamente toman en cuenta, por lo menos hasta cierto grado, los valores de quienes las establecen. Además, existe otro lado de la ecuación humana que se relaciona con las puntuaciones de corte, uno del que rara vez se escribe en los textos de mediciones. El juicio humano tiene un lugar importante no sólo en el establecimiento de puntuaciones de corte, sino también en la forma de reaccionar ante ellas. Se han explorado en formas de investigación innovadora, algunas consecuencias relacionadas con haber sido excluido por puntuaciones de corte, véase la figura 1-1.

Las pruebas difieren de manera considerable en términos de las pautas para calificar e interpretar. Algunas pruebas están diseñadas para ser calificadas por los que las contestan, otras

están diseñadas para ser calificadas por examinadores capacitados y las terceras, pueden ser calificadas e interpretadas íntegramente y en segundos por la computadora. Algunas pruebas, como la mayoría de las utilizadas para medir inteligencia, vienen con manuales de aplicación muy explícitos no sólo acerca de los criterios de calificación, sino también sobre la naturaleza de las interpretaciones que pueden hacerse a partir de la puntuación obtenida. Otras pruebas, como la de las manchas de tinta de Rorschach (expuesta en el capítulo 12), se venden sin ningún manual. El comprador (personal calificado) adquiere los materiales de estímulo y después selecciona y utiliza una de muchas guías disponibles para la administración, calificación e interpretación.

Las pruebas difieren respecto a su *calidad técnica*. Cada vez es más común que se hagan referencias a lo que se llama *sondeo psicométrico* de una prueba. La **psicometría** puede definirse como la ciencia de la medición de la psique.¹ El adjetivo *psicométrico* se refiere a la medición de naturaleza psicológica. Y el *sondeo psicométrico* de una prueba es una referencia de qué tan consistente y precisa es la medición de una prueba psicológica con respecto a lo que se propone medir.

Existen muchos otros aspectos a ser tomados en cuenta sobre lo que constituye la calidad en una prueba u otra herramienta de evaluación. En este libro, de forma consistente con la práctica común, a veces se emplea la palabra prueba (al igual que términos relacionados como *puntuación de una prueba*) en un sentido genérico para explicar principios generales aplicables a varios procedimientos de medición. Estos procedimientos de medición varían desde aquellos ampliamente etiquetados como pruebas (como las exámenes con lápiz y papel) hasta procedimientos que los expertos en medición puedan etiquetar con términos más específicos (como *mediciones de desempeño situacional*). A continuación se hará referencia a las herramientas de evaluación y se presentará una que, como suele decirse, “no necesita presentación”.

La entrevista Otra herramienta en gran medida utilizada en la evaluación psicológica es la entrevista, una palabra que tal vez remita a imágenes de una plática frente a frente. Pero la entrevista como una herramienta de evaluación psicológica implica más que una plática. Si la entrevista es

conducida frente a frente, es probable que el entrevistador se percate de una conducta verbal y no verbal, como la ropa que usa el entrevistado, su conducta y el contacto visual que establece. Una entrevista puede realizarse por teléfono, en cuyo caso el entrevistador puede hacer inferencias sobre lo que se dice en función de los cambios en la calidad y tono de voz del entrevistado. No es necesario que las entrevistas impliquen el habla, como cuando se conducen en lenguaje de señas. Las entrevistas pueden conducirse

a través de medios electrónicos, como el correo electrónico. En su sentido más amplio, entonces, la **entrevista** se puede definir como un método para reunir información mediante una comunicación directa, la cual implica un intercambio recíproco.

Las entrevistas difieren con respecto a muchas variables como son su propósito, extensión y otras restricciones bajo las cuales son conducidas, así como la disposición por parte del entrevistado de proporcionar información de una manera abierta y directa. Las entrevistas pueden ser usadas por los psicólogos y otros especialistas en escenarios clínicos, de consejería, forenses y neuropsicológicos para ayudar a la toma de decisiones diagnósticas o de tratamiento. Los psicólogos escolares y otros profesionales en escenarios educativos pueden usar entrevistas para ayudarse a tomar decisiones sobre lo apropiado que resultarían las variadas intervenciones educativas o asignaciones de grado. Una entrevista puede ayudar a los profesionales de recursos humanos para hacer recomendaciones sobre la contratación, el despido y el desarrollo organizacional del personal. En algunos casos, el proceso toma la forma de una **entrevista de panel**, en donde participa más de un entrevistador en la evaluación del perso-

SÓLO PIENSE...

¿Cuáles son las fortalezas y debilidades de la entrevista como una herramienta de evaluación?

1. Las variantes de esta palabra incluyen el adjetivo *psicométrico* y los sustantivos *psicometrista* y *psicomeatra*. En forma tradicional un psicometrista tiene un grado de maestría y está calificado para administrar pruebas específicas. Un psicomeatra tiene un grado doctoral en psicología o algún campo relacionado (como educación) y se especializa en áreas como las diferencias individuales, psicología cuantitativa, o teoría de la evaluación.



Figura 1-2
Sobre entrevistar y ser entrevistado

Los entrevistadores tienen distintos estilos para realizar entrevistas. ¿Cómo podría caracterizar el estilo de entrevistar de Howard Stern contra el de Jay Leno?

nal. Se presume que una ventaja de la entrevista de panel (a veces llamada también *entrevista de consejo*) es que la idiosincrasia reflejada en las preguntas de uno de los entrevistadores, puede ser minimizada por las aproximaciones que los otros entrevistadores realicen (Dipboye, 1992). Una desventaja de la entrevista de panel es el costo adicional de emplear a múltiples entrevistadores, en especial cuando se cuestiona la recuperación de la inversión (Dixon *et al.*, 2002).

Los psicólogos que estudian el comportamiento del consumidor utilizan estas entrevistas para responder las preguntas corporativas acerca del mercado para varios productos y servicios y de cómo publicitarlos y promoverlos mejor. Los investigadores de la psicología y otros campos relacionados utilizan las entrevistas para explorar otros miles de temas. Una encuesta informal sobre literatura revela investigaciones recientes en las que se emplea la entrevista para explorar temas tan diversos como la negociación en la elección de comida en las parejas recién casadas (Bove *et al.*, 2003), la experiencia de escuchar voces desde la perspectiva de aquellos que las escuchan (Jones *et al.*, 2003), y la concepción de lo que constituye la “masculinidad” desde la perspectiva de varones adolescentes (Pascoe, 2003).

La popularidad de la entrevista como método para reunir información se extiende más allá de la psicología. Sólo piense en un día en el que *no* estuvo expuesto a una entrevista en la televisión, la radio, o Internet. Sin tomar en cuenta el foro, la calidad, más no la cantidad, de información útil que proporciona una entrevista, depende en cierto grado del entrevistador. Una entrevista es un encuentro recíproco. El entrevistado reacciona ante el entrevistador y el entrevistador reacciona ante el entrevistado. Los entrevistadores varían de muchas maneras; por ejemplo, el ritmo de las entrevistas, la penetración con los entrevistados, y su habilidad para conjuntar el ser genuinos, empáticos y con

SÓLO PIENSE...

¿Qué tipos de habilidades debe tener el anfitrión de un programa de entrevistas en la televisión para ser considerado un entrevistador eficaz? ¿Estas habilidades difieren de las que necesita un profesional en el campo de la evaluación psicológica?

sentido del humor. Tomando en cuenta estas diferencias entre los entrevistadores, vea la figura 1-2. Piense en cómo los atributos de estas conocidas celebridades pueden afectar las respuestas de los entrevistados. De manera más general, piense en otras dimensiones en las que pueda caracterizar a los entrevistadores que ha visto y conocido en los medios de comunicación. “Juvenil *vs* adulto” y “hábil para hablar *vs* hábil para escuchar” son sólo dos aspectos que puede tener en mente.

El portafolio En años recientes, ha crecido la popularidad de la evaluación del **portafolio** (muestra de trabajo) en muchos campos (incluido el de la educación). Algunos han argumentado, por ejemplo, que la mejor forma para evaluar las habilidades de redacción de un estudiante puede

SÓLO PIENSE...

¿Cuáles son las fortalezas y debilidades del portafolio como una herramienta de evaluación?

llevarse a cabo no sólo mediante la aplicación de una prueba, sino también pidiéndole una recopilación de muestras de escritura. Desde la perspectiva de los administradores de la educación, la evaluación del portafolio tiene también distintas ventajas para medir la efectividad del profesor. Al examinar los portafolios de los profesores, y ver de qué manera cubren los distintos temas, los evaluadores educativos tienen otra herramienta para ayudarse a construir juicios acerca de diversas formas de trabajo.

Datos de historia de caso En un sentido general, los **datos de la historia de desarrollo** (historia clínica en su caso), se refieren a registros, transcripciones y otros instrumentos escritos, pictóricos o de otra forma, y en cualquier medio, que preserve la información de archivos, registros formales e informales y otros datos y documentos importantes en relación al evaluado. Los datos de historia de la historia del desarrollo pueden incluir archivos o extractos de archivos que se conservan en instituciones y agencias tales como escuelas, hospitales, empleos, instituciones religiosas y agencias de justicia criminal. Otros ejemplos de datos de historias del desarrollo o historia clínica son las cartas y la correspondencia por escrito; fotos y álbumes familiares, recortes de periódicos y revistas, videos caseros, películas y audiocasetes. Muestras de trabajo, arte, garabatos e ilustraciones que muestren los intereses y pasatiempos son aún más ejemplos.

Los datos de la historia del desarrollo pueden ser una herramienta de gran utilidad en una amplia variedad de contextos de evaluación. En una evaluación clínica, por ejemplo, los datos de la historia de desarrollo, pueden aportar información sobre el pasado de un individuo y su adaptación actual, al igual que los sucesos y circunstancias que pudieron haber contribuido a los cambios

SÓLO PIENSE...

¿Cuáles son las fortalezas y debilidades de la historia de desarrollo como una herramienta de evaluación?

en la adaptación. Los datos de la historia de desarrollo pueden ser de un valor incalculable para las evaluaciones neuropsicológicas, en donde proporcionan información sobre el funcionamiento neuropsicológico previo al suceso traumático u otro evento que resulte en un déficit. Los psicólogos escolares confían en los datos de la historia de desarrollo, entre otras cosas, para responder preguntas acerca del proceso de la historia educativa del estudiante.

Otro uso del término *historia del desarrollo*, sinónimo de *estudio de caso*, está relacionado con la recolección de los datos de historia del caso en un informe ilustrativo. Por ejemplo, un estudio de caso detalla cómo un número de aspectos de la personalidad del individuo, combinado con las condiciones del ambiente produce a un líder mundial exitoso. Un estudio de caso de un individuo que intentó asesinar una figura política de renombre puede aportar información sobre los tipos de individuos y condiciones que puedan conducir a tentativas similares en el futuro. Un ahora clásico en el tema de **pensamiento de grupo** contiene un basto material sobre historias de casos en los que la toma de decisiones colectiva, no siempre resultó en las mejores decisiones (Janis, 1972).

Observación conductual Para saber cómo se comporta alguien en una situación particular, es necesario observar su comportamiento en esa situación. Esa sabiduría “en el lugar exacto” sugiere al menos un enfoque de evaluación. La **observación conductual**, como lo emplean los profesionales de la evaluación, puede definirse como el monitorear las acciones de otros y de uno mismo a través de medios electrónicos o visuales, mientras se registra información cuantitativa y/o cualitativa con respecto a dichas acciones. La observación conductual puede utilizarse en diferentes



Figura 1-3
Verificación de precio (y juicio) en el pasillo 5

Hamera y Brown (2000) describieron el desarrollo de una prueba basada en el contexto, Prueba de habilidad para la compra de comestibles. Diseñada de manera primordial para su uso en personas con desórdenes psiquiátricos, esta herramienta de evaluación puede ser útil en la valoración de una aptitud necesaria para la vida independiente.

escenarios para una variedad de objetivos de evaluación. Puede ser usada, por ejemplo, como un auxiliar diagnóstico en un contexto clínico o como un medio para recolectar información en una investigación básica. Las observaciones deben hacerse en el laboratorio o en escenario estructurados. Un ejemplo de esto es la observación que hace un investigador a un niño a quien se le pide que realice algunas tareas como parte de un experimento. La observación también puede ocurrir en un escenario natural el cual propicia la aparición natural del comportamiento o en el que se espere que éste ocurra. Para este tipo de observación conductual, se hace referencia al término **observación naturalista**.

La observación conductual como un auxiliar para diseñar intervenciones terapéuticas ha demostrado ser en extremo útil en escenarios institucionales, como escuelas, hospitales, prisiones y hogares de grupo. Con el uso de listas de comportamientos específicos a observar, sean autoconstruidas o publicadas, el personal puede observar de primera mano, el comportamiento de la persona observada y con ello diseñar sus intervenciones terapéuticas de una manera coherente. En un contexto escolar, por ejemplo, la observación naturalista en un patio de juegos de un niño con una cultura diferente al resto, del cual se sospecha que tiene problemas lingüísticos, puede revelar que el niño tiene las habilidades para hablar el idioma del lugar donde se encuentra, pero no es capaz —por razones de timidez, cultura, etcétera— de demostrar esas habilidades frente a los adultos.

A pesar del valor potencial de la observación conductual, se tiende a usarla cada vez con menos frecuencia fuera de los escenarios institucionales. Para los profesionales privados, no es económicamente factible emplear horas fuera del consultorio para observar a los clientes. Sólo piense en el tiempo que tomaría administrar una prueba sobre las habilidades para comprar en una tienda si el evaluado/comprador utilizará algunos cupones de descuento (véase figura 1-3).

SÓLO PIENSE...

¿Cuáles son las fortalezas y debilidades de la observación conductual como una herramienta de evaluación?

Pruebas de representación de papeles Si alguna vez ha disfrutado del programa de televisión *Whose Line Is It Anyway?* de seguro habrá apreciado qué tan entretenida puede ser la improvisación. Más allá del entretenimiento, sin embargo, el acto de improvisar tiene un lugar en el contexto de la evaluación psicológica. En este contexto, la **representación de papeles** puede definirse como la actuación de un papel improvisado o en parte improvisado en una situación simulada. Una **prueba de representación de papeles** es una herramienta de evaluación en donde a los evaluados se les dirige para que actúen como si estuvieran en una situación en particular. Los evaluados entonces, pueden ser percibidos con respecto a sus pensamientos, comportamientos, habilidades y otras variables manejadas.

A un individuo que está siendo evaluado en un contexto corporativo, industrial, organizacional o militar para su habilidad de liderazgo gerencial, se le puede pedir que sea el mediador de una disputa hipotética entre el personal de su sitio de trabajo. El contexto de la representa-

ción de papeles debe ser creado con técnicas que manejen desde actores en vivo hasta estímulos generados por computadora. Las mediciones de los resultados para esas pruebas deben incluir puntuaciones relacionadas con varios aspectos relacionados con la habilidad del individuo para resolver conflictos, con la efectividad de su proceder, la calidad de sus decisiones y el número de minutos para llegar a una resolución.

SÓLO PIENSE...

¿Cuáles son las fortalezas y debilidades de la representación de papeles (*rol planning*) como una herramienta de evaluación?

La representación de papeles como herramienta de la evaluación puede utilizarse en varios contextos clínicos. Por ejemplo, se emplea de manera rutinaria en muchas intervenciones con los adictos a sustancias. Los profesionistas clínicos pueden intentar obtener la medición de una línea base de abuso, ansia y habilidades de resistencia, al administrar una prueba de representación de papeles de manera previa a la intervención terapéutica y después de ella, al completar el tratamiento.

Las computadoras como herramientas Los profesionales que se especializan en la evaluación psicológica y educativa han reconocido el valor de las computadoras en la administración, calificación e interpretación de las pruebas. Desde 1930, se disponía de al menos una prueba psicológica de puntuación electromagnética, los Inventarios de intereses vocacionales de Strong (SVIB, por sus siglas en inglés) (Campbell, 1971). En 1946, gracias a los esfuerzos de un ingeniero de Minneapolis, llamado Elmer Hankes, el perfil de los SVIB pudo realizarse a máquina. Y al final de la década de 1950, las computadoras no sólo se usaron para calificar y obtener un perfil, sino también para la interpretación de pruebas y la obtención de un perfil psicológico (Rome *et al.*, 1965). Con el advenimiento de la computadora personal en la década de 1970, la administración, calificación e interpretación de pruebas se convirtió en una realidad. A medida en que ha florecido la tecnología, el uso de computadoras ha prosperado.

En la actualidad, las computadoras, ya sean de escritorio, laptop o palm-held, son parte esencial de las oficinas de personal clínico, de consulta y otros usuarios de pruebas. Desde el punto de vista de los usuarios de pruebas, la **evaluación psicológica asistida por computadora (CAPA)**, por sus siglas en inglés) se refiere a la conveniencia y economía de tiempo al administrar, calificar e interpretar pruebas. Por tanto, el término “asistencia” en relación a la *evaluación asistida por computadora* se refiere a la ayuda para los usuarios de pruebas, no para quien la resuelve. La CAPA le permite a los que contestan la prueba, trabajar de una manera independiente, mientras responden los reactivos presentados en una pantalla de video. La computadora entonces puede calificar la prueba, analizar los patrones de respuesta, y hasta proporcionar un tipo de informe (véase el recuadro *Close-up*).

Para muchos usuarios de pruebas, la CAPA representa un gran avance sobre el pasado, no tan distante, en el que se tenían que administrar las pruebas de manera personal y hasta poner las respuestas en algún otro formato para efectuar el análisis (como utilizar de manera manual una plantilla de respuestas u otro instrumento) antes de comenzar la laboriosa tarea de calificar e interpretar los datos resultantes. La CAPA abrió un mundo de posibilidades para los usuarios de pruebas, lo que permitió la construcción de éstas con base en puntuaciones complejas y estrategias de combinaciones de datos que de otra manera no pudieran ser prácticas. La CAPA también ha permitido la medición de habilidades que no podrían ser medidas con métodos más tradicionales

Tipos de informes psicológicos generados por computadora

¿Alguna vez ha contestado un examen cuyos resultados le hayan sido entregados en un informe generado por una computadora? ¿Qué tipo de informe fue? Y, ¿cómo lo obtuvo?

Los informes psicológicos generados por computadora pueden categorizarse como informes de calificación, informes interpretativos e integración de resultados. Aquí se define cada uno de los formatos de informes y se describe el tipo de información que puede encontrarse en ellos.

Informes de calificación

En general, un **informe de calificación** puede definirse como un documento formal u oficial generado por una computadora, que por lo general se presenta en forma numérica. Un tipo de informe de calificación, un **informe de calificación simple**, tan sólo hace una lista de las puntuaciones de la prueba. Otro tipo de informe de calificación es el **informe de calificación extendida**. Más allá de una simple lista de puntuaciones de la prueba, un informe de calificación extendida puede incluir información más detallada, como un análisis estadístico de cómo se desempeñaron los evaluados en aspectos individuales.

Informes interpretativos

En general, un **informe interpretativo** es una constancia generada a computadora del desempeño de una prueba, presentada de manera numérica y narrativa, que incluye una explicación de los hallazgos.

Existen tres variedades del informe interpretativo: el informe descriptivo, el informe de selección y el informe consultivo.

El **informe descriptivo** es un tipo de informe interpretativo que se caracteriza por tener resúmenes narrativos breves. De hecho, la “descripción” en un informe descriptivo puede ser tan breve como el comentario de un enunciado en donde una puntuación particular se origina desde una perspectiva normativa. Los informes descriptivos pueden ayudar al usuario de pruebas o evaluador a determinar en cuál de las muchas puntuaciones de una prueba se debe centrar.

Un **informe de selección** proporciona más información que un informe descriptivo, pero menos que un informe consultivo. Ofrece información narrativa, al igual que análisis o comentarios sobre relaciones entre las puntuaciones. Como su nombre lo indica, un informe de selección es útil en particular para propósitos de selección. En el software están programados varios criterios que se

deben seguir antes de que el programa produzca que una línea de texto narrativo se imprima de manera automática sobre el informe.

Más que un informe descriptivo y menos tentativo en sus conclusiones que el informe de selección, está el informe consultivo. Un **informe consultivo** ofrece un análisis detallado de los datos de la prueba en un lenguaje apropiado para la comunicación entre la evaluación y los profesionales. Ofrece la opinión experta de un individuo o grupo de individuos quienes han dedicado años de estudio a la interpretación de un instrumento en particular.

Informes de integración

Un **informe de integración** proporciona un nivel de descripción y análisis encontrado en informes interpretativos, pero se conforma a partir de datos de otras fuentes, como observaciones conductuales o registros de medicación. A partir de un informe que integre datos de una observación conductual con registros de medicación, por ejemplo, un profesional clínico puede recibir ayuda valiosa relacionada con medicaciones y dosis óptimas para un cliente.

Procesamiento CAPA

Sin importar su naturaleza, un informe puede ser creado de muchas maneras en diferentes sitios web. Aquí está un “breve curso” sobre el procesamiento CAPA.

El término **procesamiento central** se utiliza para referirse al hecho de mandar los protocolos de pruebas contestadas en papel u otro formato de una locación a alguna otra con el fin de ser calificado e interpretado por dicho protocolo. Los resultados entonces pueden ser regresados al usuario de la prueba por correo electrónico, disco, correo, fax o teléfono.

Una variedad del procesamiento central es el *teleprocesamiento*. El **teleprocesamiento** se refiere a la calificación computarizada, interpretación u otra conversión de datos de pruebas que han sido enviadas para su procesamiento, a través de medios como el teléfono, la Web u otros. Dicha información se procesa en la institución que maneja la prueba y no en el lugar de aplicación.

Procesamiento local puede definirse tan sólo como la calificación, interpretación, u otra conversión de datos de una prueba. Con el hardware y software apropiados, el usuario de la prueba puede utilizar la misma computadora para administrar una prueba y luego calificarla. En una era de un hardware de computación relativamente barato, hoy en día la mayoría de las pruebas son procesadas de manera local.

SÓLO PIENSE...

¿Cuáles son los pros y contras de los distintos tipos de procesamiento de la CAPA?




Figura 1-4
Método para cuantificar la tensión en la espalda

La aplicación innovadora de la tecnología computacional ha facilitado la medición de características o capacidades por medio de técnicas que no podrían medirse mediante métodos más tradicionales. Por ejemplo, Mirka et al. (2000) describieron una metodología de evaluación que emplea video, computadoras y otros componentes para obtener una evaluación continua de la tensión en la espalda. Implica la captura de una imagen con una cámara de video (en esta ilustración, el acto de podar al nivel del suelo) la representación computarizada de la acción y la simulación en laboratorio.



(figura 1-4). Por supuesto, cada rosa tiene sus espinas; en la tabla 1-1 se presentan algunos de los pros y contras de la CAPA.

Otras herramientas Pueden aplicarse varios instrumentos como herramientas de evaluación. Los psicólogos y otros profesionales que las emplean para evaluar a las personas con capacidades diferentes y miembros de otras poblaciones específicas, han sido muy innovadores. Por ejemplo, Wilson *et al.* (1982) desarrollaron un mecanismo para proporcionar respuestas a pruebas, el cual implicaba una placa para la dentadura que se activaba con la lengua. Para aquellos que contestan la prueba y no tienen la capacidad del habla o del control de sus miembros, este instrumento permite cinco tipos de respuesta.

SÓLO PIENSE...

En general, ¿cuándo es una buena idea la utilización de video en la evaluación? ¿Cuáles son las desventajas, si existen, de utilizar video en la evaluación?

La próxima vez que vaya a rentar un DVD, tómese un momento para pensar en el papel que puede tener un video en la evaluación. De hecho, una gran variedad de videos son utilizados en los contextos de capacitación y evaluación. Por ejemplo, al personal de una corporación se le puede pedir que considere las

posibles reacciones ante una variedad de incidentes de acoso sexual en el lugar de trabajo presentados a través de un video. Al personal de policía se le puede preguntar cómo respondería ante diferentes tipos de emergencia, que se presentan ya sea en forma de actuación o por medio de la grabación de situaciones reales. A los psicoterapeutas se les puede pedir que respondan con un diagnóstico y un plan de tratamiento para varios clientes presentados en videocasete. Esta lista de aplicaciones potenciales del video para la evaluación no tiene fin.

Tabla 1-1
CAPA: algunos pros y contras

Pros	Contras
CAPA ahorra tiempo laboral en la administración, calificación e interpretación de la prueba.	Los profesionales todavía tienen que invertir un tiempo significativo en leer documentación sobre el software y hardware y aún libros complementarios sobre pruebas y su interpretación.
CAPA obtiene un mínimo de errores en la calificación que son producto del error humano o de lapsos de atención o juicio.	Con CAPA, la posibilidad de errores de software o hardware está siempre presente, estas fuentes de error son difíciles de encontrar como interrupciones en el software o mal funcionamiento del hardware.
CAPA obtiene una correcta aplicación de la prueba, tomando en cuenta los procesos de estandarización para todos los evaluados, habiendo muy poca variación, si es que existe, en los procedimientos de administración de la prueba para cada individuo.	CAPA deja en desventaja a los evaluados quienes no tienen oportunidad de emplear estrategias comunes en las pruebas (revisión previa de la prueba, saltarse preguntas, regresar a una pregunta anterior, etcétera).
CAPA obtiene una interpretación de resultados estandarizada debido a la eliminación de la no confiabilidad surgida a los diversos puntos de vista en el juicio profesional que cada profesional pueda hacer de los resultados.	La interpretación estandarizada de resultados de la CAPA, basada en una perspectiva conjunta, unitaria puede no ser óptima; la interpretación podría ser mejor desde puntos de vista alternativos.
La capacidad de las computadoras de combinar datos de acuerdo con las reglas es más exacta que la de los humanos.	Las computadoras carecen de la flexibilidad de los humanos para reconocer la excepción a la regla en el contexto de la "visión global".
Se pueden utilizar asistentes no profesionales en el proceso de administración de la prueba, y puede ser administrada de manera general a grupos de evaluados en un solo sitio.	La utilización de no profesionales, disminuye, o desaparece, la oportunidad de que los profesionales observen la conducta de los evaluados durante la realización de la prueba e identifiquen cualquier condición inusual o variable "extraña" que pueda afectar las respuestas de la persona.
Grupos profesionales como VPA desarrollan directrices y normas para utilizar productos de CAPA.	Los no profesionales interesados en las ganancias pueden también crear y distribuir pruebas con poco apego a las directrices y normas profesionales.
Las pruebas en papel y lápiz pueden convertirse en productos de CAPA con las ventajas consecuentes, como un tiempo más corto entre la administración de la prueba y su calificación e interpretación.	El uso de pruebas a papel y lápiz que han sido convertidas para su administración en computadora hacen que surgan dudas sobre la equivalencia entre la prueba original y su forma convertida.
La seguridad en los productos de CAPA se puede mantener no sólo por los medios tradicionales (como gabinetes cerrados) sino por productos electrónicos de alta tecnología (como los firewalls).	La seguridad de los productos CAPA puede ser violada por hackers de computadoras, y la integridad de los datos puede ser alterada o destruida por eventos inesperados como la introducción de virus computacionales.
Las computadoras pueden adaptar de manera automática el contenido y la longitud de la prueba con base en las respuestas de los evaluados.	No todos los evaluados realizan la misma prueba o tienen la misma experiencia de aplicación durante la realización de la prueba.

La lista de herramientas utilizadas al servicio de la evaluación psicológica incluye, por ejemplo, muchas herramientas que de manera tradicional se asocian con la salud médica o física, como termómetros para medir la temperatura corporal y calibradores para medir la presión sanguínea. A veces se usa equipo de biorretroalimentación para obtener mediciones de reacciones corporales (como tensión muscular o respuesta galvánica de la piel) a varios tipos de estímulos. Un instrumento llamado pletismógrafo penil, que mide la manifestación sexual masculina, puede ser muy útil en el diagnóstico y tratamiento de agresores sexuales. La inhabilidad para identificar olores es común en muchos trastornos en los que está implícito el sistema nervioso central, y la administración de simples pruebas de olfato puede ayudar a determinar si esa inhabilidad está presente. En general, no ha habido escasez de innovación por parte de los psicólogos en el manejo y diseño de herramientas de medición, o en la adaptación de herramientas existentes, para su uso en la evaluación psicológica.

Hasta este punto, la introducción de este libro se ha centrado en algunas definiciones básicas y en la mirada a algunas "herramientas del negocio". A continuación se hará referencia a algunas preguntas fundamentales respecto al quién, qué, por qué y dónde de las pruebas y la evaluación.

¿Quiénes, qué, por qué y dónde?

¿Quiénes son los que participan en la empresa de la evaluación? ¿En qué tipo de escenarios se conducen las evaluaciones? ¿Por qué se conduce la evaluación? ¿Dónde se puede buscar información o tutoría para el manejo de pruebas? Piense en las respuestas a cada una de estas importantes preguntas antes de continuar con esta lectura. Después compare sus ideas con las que a continuación se expresan.

¿Quiénes son las partes involucradas?

Las partes involucradas en la empresa de la evaluación incluyen a los desarrolladores y los editores, a los usuarios y a las personas que son evaluadas mediante una prueba. Una cuarta parte que con frecuencia no es tomada en cuenta es la sociedad misma.

El desarrollador de las pruebas Los desarrolladores de las pruebas y los editores crean pruebas y otros métodos de evaluación. La **APA (American Psychological Association)**, estima que más de 20 000 pruebas psicológicas nuevas se desarrollan cada año (APA, 1993). Entre estas pruebas, hay algunas que fueron creadas para un caso específico de investigación, algunas que fueron creadas con la esperanza de ser publicadas, y algunas que representan refinamientos, revisiones o modificaciones de pruebas existentes. Los creadores de las pruebas aportan una gran variedad de nociones e intereses al proceso de desarrollo. Para un vistazo interesante a información bibliográfica de algunos desarrolladores de pruebas, visite la sección “Perfiles de desarrolladores de pruebas” en nuestro sitio: www.mhhe.com/cohentesting6.

Los desarrolladores y los editores aprecian el impacto significativo que los resultados de las pruebas pueden tener en la vida de las personas. De acuerdo con esto, un gran número de organizaciones profesionales han publicado estándares de comportamiento ético que refieren, de manera específica, aspectos del desarrollo y uso de pruebas en forma ética y responsable. Tal vez el documento más detallado que refiere esos aspectos es uno escrito hecho de manera conjunta por la AERA (American Educational Research Association), la APA (American Psychological Association) y el NCME (National Council on Measurement in Education). Referidos por muchos psicólogos tan sólo como “los estándares”, los *Estándares para las pruebas psicológicas y educativas* cubren aspectos relacionados con la construcción y estandarización de pruebas, administración y usos, y aplicaciones especiales de las pruebas, tales como adecuaciones especiales en la aplicación de pruebas a minorías lingüísticas. Publicadas de manera inicial en 1954, las revisiones de los *estándares* fueron publicadas en 1966, 1974, 1985 y 1999. Los *Estándares* es una obra de referencia indispensable no sólo para los desarrolladores de pruebas, sino también para los usuarios de las mismas.

El usuario de las pruebas Las pruebas son utilizadas por un amplio rango de profesionales, incluidos los profesionales clínicos, los consejeros, el personal de recursos humanos, profesores y personal escolar. Los *Estándares*, al igual que las guías y pautas de aplicación oficiales de varias organizaciones profesionales, tienen mucho que impartir a los usuarios de las pruebas sobre el cómo, por qué y bajo qué condiciones deben usarse las pruebas. Por ejemplo, los principios de la ética profesional, promulgados por la Asociación Nacional de Psicólogos Escolares, ANPE (National Association of School Psychologists, NASP), (Jacob-Timm & Hartshorne, 1998) enfatizan que los psicólogos escolares deben seleccionar y usar la o las pruebas que sean las más apropiadas para cada alumno en lo particular. La ANPE (2000) además enfatiza que las preguntas que sirvan para agilizar la evaluación psicológica de los estudiantes deben ser respondidas de la manera más comprensible; es decir, con tanta información y datos como sea posible, incluidas las inferencias y descripciones fenomenológicas de las observaciones conductuales.

Sin importar qué tan sólida sea una prueba, su propósito será fallido si el usuario falla en el manejo y aplicación competente de todas las fases de las pruebas o del proceso de evaluación. Por esta razón, el responsable de una prueba tiene obligaciones de carácter ético y estructural antes, durante y después de la administración de la prueba. Las guías éticas dictan que antes de que una



Figura 1-5
Condiciones no óptimas para las pruebas

En 1917, los nuevos reclutas de la Armada se sentaban en el suelo mientras se les realizaba la primera prueba grupal de inteligencia no eran condiciones ideales para las pruebas según los estándares actuales.

prueba sea administrada, ésta debe guardarse de tal manera que se asegure de manera razonable que los contenidos específicos no se harán saber por adelantado. Otra obligación del usuario antes de la administración de la prueba, es asegurarse de que una persona capacitada y preparada realice la aplicación de manera adecuada. El administrador de la prueba (o examinador) debe estar familiarizado con los materiales y procedimientos y debe tener en el sitio correspondiente, todos los materiales necesarios para administrar la prueba de manera apropiada. Los materiales necesarios pueden ser un reloj cronómetro, lápices y un número suficiente de *protocolos* de la prueba.²

Además de tener los suplementos suficientes, el examinador también se asegura de que la habitación en donde se llevará a cabo la evaluación o prueba, sea cómoda y apropiada (figura 1-5). Deben evitarse hasta donde sea posible, condiciones de distracción como ruido excesivo, calor, frío, interrupciones, luz del Sol en exceso, sobrepoblación o ventilación inadecuada.

2. En la vida cotidiana, en una conversación que no esté relacionada con las pruebas, protocolo se refiere a una etiqueta diplomática. Un uso menos común de la palabra es un sinónimo de la primera copia o el documento en sucio de un tratado u otro documento oficial antes de su ratificación. Este segundo significado está más cerca de la manera en que la palabra se utiliza con referencia a las pruebas psicológicas. **Protocolo** se refiere a la forma u hoja en la cual se han introducido las respuestas de quien aplica el examen. Los protocolos son de manera típica hojas individuales o panfletos de papel.

Durante la administración de las pruebas, en especial cuando se administran de manera individual o en un grupo pequeño, una buena relación entre el examinador y el examinado es de vital importancia. En el contexto de una situación de pruebas, la **compenetración** o **rapport** puede definirse como una relación de trabajo entre el examinador y el examinado. Esa relación de trabajo a veces puede lograrse con unas cuantas palabras o con una pequeña plática mientras se conocen el examinador y el examinado. Lo que también puede ser útil, si se hace de manera apropiada, son algunas referencias sobre la naturaleza de las pruebas y por qué es importante que los examinadores hagan su mejor esfuerzo. En otros casos, por ejemplo, con un niño asustado, el logro de la compenetración, puede implicar técnicas más elaboradas, como hacer participar al niño en algún juego o en alguna otra actividad hasta que éste se aclimate al examinador y a su entorno. Es importante que los esfuerzos por establecer rapport con el examinado no incluyan ninguna regla sobre las instrucciones de la administración de la prueba o sobre las formas de aplicación.

Después de la administración de la prueba, los evaluadores siguen teniendo otras obligaciones. Éstas deben ir desde salvaguardar los protocolos de las pruebas para transferir los resultados a un medio entendible y claro. Al realizar esto, existen otras obligaciones como aquéllas relacionadas con la calificación. Si la prueba va a ser calificada por personas, los que la califiquen deben ponerse de acuerdo sobre los criterios de evaluación —aun cuando eso no sea el caso, como en aquellas situaciones de evaluación sin pruebas (véase *Psicometría diaria*). Interpretar los resultados y manejar los datos obtenidos de acuerdo con los procedimientos estandarizados y éticos, son obligaciones adicionales para los evaluadores.

El evaluado Los evaluados tienen diferentes aproximaciones a la situación de evaluación, y los usuarios o aplicadores, deben ser sensibles ante la diversidad de respuestas posibles ante dicha evaluación. El día de aplicación de la prueba, los evaluados pueden variar de forma continua y de acuerdo con numerosas variables, incluidas:

- El estado de ansiedad que están experimentando y el grado en que la ansiedad puede afectar de manera significativa los resultados de la prueba.
- Su capacidad y disposición para cooperar con el examinador o para comprender las instrucciones de la prueba escrita.
- El grado de dolor físico o angustia emocional que estén sintiendo.
- El grado de incomodidad física por no haber comido lo suficiente, haber comido en exceso u otras condiciones físicas.
- El estado en que están alertas y despiertos en contraposición al estado de somnolencia.
- La predisposición que tienen a estar de acuerdo o en desacuerdo cuando se les presentan estímulos para provocar una reacción.
- El grado de preparación e información que han recibido antes de la evaluación.
- La importancia que le hayan atribuido al verse situados en un buen o mal lugar.
- El grado en que son, por falta de un término mejor, “afortunados” y pueden “acertar” en una prueba de opción múltiple (aun cuando quizá no hayan aprendido el tema en cuestión).

En el sentido más amplio en el que se ha utilizado el término “evaluado”, cualquier persona que sea sujeto de una evaluación o prueba puede ocupar el papel de evaluado. Por más increíble que parezca, esto significa que un individuo que ha fallecido puede considerarse como evaluado. Ciertamente, es la excepción de la regla, pero existe algo llamado *autopsia psicológica*. Una **autopsia psicológica** puede definirse como una reconstrucción del perfil psicológico del individuo fallecido con base en registros de archivos, artefactos y entrevistas conducidas con anterioridad con el evaluado o con gente que lo conoció. Para los lectores interesados en este tema, Neagoe (2000) presenta un fascinante estudio de casos en el que se empleó la técnica de la autopsia psicológica.

“La siguiente película se ha clasificado como *PG-13*”... Pero ¿quién?, ¿cómo? y ¿por qué?

PG-13 RECOMENDACIÓN EXTREMA PARA PADRES
Alguna parte de este material puede ser inapropiada para niños menores de 13 años

La Asociación Estadounidense de Películas (Motion Picture Association of America, MPAA) hace clasificaciones de éstas; todos hemos escuchado: “La siguiente película tiene clasificación *PG-13*.” *PG-13* está dirigido a que los “padres extremen precauciones” respecto a permitirles a los niños menores de trece años ver la película. También existe una *G* para el “público general”, *PG* para “se sugiere guía de los padres” y *NC-17* para “no se admiten menores de 17 años”.

¿Alguna vez se ha preguntado quién evalúa en realidad las películas y las sitúa en una de estas cinco clasificaciones? De hecho, es un grupo de 8 a 13 padres de familia, a quienes la MAAP emplea de tiempo completo para ver y evaluar las películas. En el sitio de la MAAP, <http://www.mpa.org> se publican algunos criterios para clasificar las películas desde *PG*, hasta *NC-17*. Ahí se encuentra, por ejemplo, que “un filme clasificado como *R* puede incluir lenguaje fuerte o violencia, desnudos en las escenas sensuales, abuso de drogas u otro o una combinación de los elementos anteriores, por tanto, se les aconseja a los padres, por anticipado, que tomen este anuncio de clasificación de una manera seria”.

El grupo de padres que hace la clasificación ve la película que propone un productor, debate sobre ella y después vota por una clasificación. Gana el voto mayoritario. Además de esa descripción, se proporcionan unos cuantos detalles respecto al proceso de clasificación real en la red. Se sabe que sin tomar en cuenta los votos del consejo de padres, sus clasificaciones pueden cambiar por el voto de dos tercios de un consejo que esté constituido de 14 a 18 miembros de la industria del entretenimiento.

Si existe algún misterio sobre el proceso de clasificación de las películas, eso es sólo la punta del iceberg respecto al misterio en la industria del entretenimiento en general. Existen sistemas de clasificación representadas con recomendaciones de rango de edades y resúmenes de contenido en forma de icono. Existen sistemas de clasificación para la música, software electrónico y juegos de video. Hasta existe un sistema de clasificación para contenidos

de Internet promulgados por la Asociación de Clasificación de Contenidos en Internet (Internet Content Rating Association). Al revisar estos sistemas y la literatura disponible sobre ellos, un equipo de investigación concluyó:

Los esfuerzos de varias industrias de un medio independiente han resultado en una serie de clasificaciones, iconos, definiciones y procedimientos confusos que son, en muchos casos, difíciles de entender y recordar. Casi todos estos sistemas de clasificación han sido agilizados por la amenaza de la intervención del gobierno, y cada industria ha intentado balancear el hacer accesible esa información contra sus propios intereses económicos. Aunque la creación de un sistema de clasificación que funcione bien para los padres no es una tarea sencilla, está claro que las preferencias de los padres con frecuencia no han prevalecido (Bushman & Cantor, 2003, pp. 138-139).

Mientras usted aprenda más sobre las pruebas psicológicas y la evaluación, piense en la descripción de la evaluación en la industria del entretenimiento. Contraste la evaluación en esa industria con la evaluación en la psicología. Piense en los reactivos. Por ejemplo, piense en los reactivos respecto a la definición de términos en la evaluación psicológica. ¿Qué tan claro es lo que se mide con una prueba psicológica definida? Piense en el proceso de evaluación. Por ejemplo, piense en las diferencias entre clasificadores y calificación definitiva. Piense también en la utilidad de las evaluaciones. En la industria del entretenimiento, el “usuario final” es un padre o guardián que toma una decisión respecto a una elección relacionada con el entretenimiento para un menor. ¿Quiénes son los “usuarios finales” potenciales en las evaluaciones educativas y psicológicas? ¿Qué tipo de decisiones tendrían que tomarse con base en tal información? ¿Qué tan útil es la información desarrollada en la toma de estas decisiones?

La sociedad en general

El que un individuo sea único es uno de los hechos característicos más fundamentales de la vida... En todos los periodos de la historia humana, el hombre ha observado y descrito las diferencias entre los individuos... Pero los educadores, políticos y administradores han sentido una necesidad por organizar o sistematizar de alguna manera, la complejidad de muchas facetas de las diferencias individuales (Tyler, 1965, p. 3).

La necesidad de la sociedad para “organizar” y “sistematizar” se ha manifestado de manera histórica en preguntas tan variadas como “¿qué es una bruja?”, “¿qué es esquizofrénico?” y “¿quién está calificado?” Las preguntas específicas tienen relevancia social. Los métodos utilizados para contestar esas preguntas han variado a través de la historia como una función de factores como la sofisticación intelectual y la preocupación religiosa. La quiromancia, la podoscopía, la astrología y la frenología, entre otras formas de respuesta, han tenido estudiosos y representantes, quienes argumentaban que los mejores medios para entender y predecir el comportamiento humano eran mediante el estudio de las palmas de la mano, los pies, las estrellas, las protuberancias de la cabeza, las hojas del té, etcétera. A pesar de esas búsquedas, la empresa de la evaluación tiene sus raíces en la ciencia. A través de formas de aplicación sistematizadas y validadas, que pueden producir una serie de evidencias, las actividades de evaluación responden a lo que Tyler (1965, p. 3) se refería como la “necesidad de la sociedad para organizar o sistematizar de alguna manera, las muchas facetas de la complejidad de las diferencias individuales”.

Otras personas involucradas Además de las cuatro partes primarias a las que se ha enfocado este apartado, de manera breve se tomará nota de personas que pueden participar de alguna manera en las actividades relacionadas a las pruebas y la evaluación. Las organizaciones, compañías y agencias gubernamentales apoyan el desarrollo de pruebas por varias razones, una de ellas podría ser la certificación del personal. Existen compañías que ofrecen la calificación e interpretación de pruebas. En algunos casos, estas compañías y servicios son extensiones de editores de pruebas, y en otros casos son independientes. Hay personas cuya única responsabilidad es la mercadotecnia y venta de las pruebas. A veces a estas personas las emplean los editores; a veces no. Hay académicos quienes revisan las pruebas y evalúan la solidez psicométrica. Todas estas personas, al igual que muchas otras, son también partes, que contribuyen en mucho o poco a la actividad y empresa que implica la evaluación, una empresa que es clara que tiene pocas fronteras en términos de los escenarios en donde puede encontrarse.

¿En qué tipos de escenarios se conducen las evaluaciones y por qué?

Escenarios educativos Es probable que usted conozca los muchos tipos de pruebas que se administran en el salón de clases. Como lo demanda la ley, las pruebas se administran desde edades escolares tempranas para ayudar a los niños a identificar quién necesita un nuevo o diferente grado escolar o adecuaciones curriculares. Además de las **pruebas de habilidad escolar**, ahora usted se familiarizará con las **pruebas de logro**: evaluaciones de los conocimientos adquiridos o el grado de aprendizaje que ha tomado lugar. Algunas de las pruebas de logro que usted ha contestado en la escuela fueron conducidas por sus profesores; otras fueron construidas por otros educadores o profesionales de la evaluación para dar un uso más amplio a las mismas. En la última categoría, los acrónimos como SAT y GRE podían hacer sonar la campana (y si no, sonará después de haber leído el capítulo 10).

A partir de su propia experiencia, usted sabe que un **diagnóstico** puede definirse como una descripción o conclusión obtenida con base en la evidencia y en la opinión. De manera típica, esa conclusión se obtiene mediante un proceso para distinguir la naturaleza y origen de algo y para guiar nuestras conclusiones y alternativas. Como su nombre lo implica, una **prueba diagnóstica** es una herramienta de evaluación usada para delimitar e identificar áreas de déficit que deben ser dirigidas a procesos de intervención. Las pruebas diagnósticas de lectura, matemáticas y otras materias académicas pueden ser administradas en escenarios educativos por profesores, consejeros escolares, y psicólogos escolares para evaluar la necesidad de intervención y adecuación educativa, al igual que la elección de programas de educación especial.

Los niños en edad escolar, reciben calificaciones en sus boletas, las cuales no se basan en una evaluación formal. Por ejemplo, la calificación que se le asigne en el espacio “Trabaja y juega bien con sus compañeros” probablemente se base más en la *evaluación informal* que el maestro hace dentro del salón de clases que en puntuaciones o calificaciones obtenidas a partir de cualquier cuestionario publicado para la medición de interacción social. **Evaluación informal** puede definirse como una evaluación no sistematizada de manera típica o con base

en procedimientos metodológicos científicos, que conduce a la formación de una opinión o actitud.

La evaluación informal, por supuesto, no se limita a escenarios educativos; es parte de la vida diaria. De hecho, muchos de los tipos de pruebas de las que se saben son administradas en escenarios educativos (pruebas de logro, pruebas diagnósticas, etc.) son elaboradas y aplicadas en otros escenarios. Algunos tipos de pruebas, las cuales se explican en el contexto de escenarios mencionados a continuación, también son administradas en escenarios educativos. Por tanto, es importante recordar que las herramientas que se exponen en un contexto pueden aplicarse o exponerse en otro. En este punto tan sólo se hace referencia de los tipos de pruebas que se utilizan en diferentes escenarios, sin proporcionar una lista extensa que permita la delimitación del contexto.

Escenarios geriátricos En Estados Unidos, más de 12 millones de adultos se encuentran ahora en un rango de edad entre 75 a 84 años; eso es, 16 veces más personas que aquellas cuantificadas en 1900. Cuatro millones de adultos en Estados Unidos tienen ahora 85 años de edad o más; lo que significa un incremento de 33 veces, en comparación a 1900 (Administración de envejecimiento, 1999). Es claro que la gente de Estados Unidos está siendo más longeva y la población general está envejeciendo.

Los estadounidenses mayores quizá vivan en casa, en casas especiales diseñadas para vivir de manera independiente, en casas diseñadas para una vivienda asistida o en instituciones de cuidados a largo plazo, como hospitales y asilos. Sin importar dónde residan los individuos mayores, en algún momento requerirán de una evaluación psicológica que establezca el funcionamiento cognitivo, psicológico, adaptativo y algún otro, relacionado con su desempeño general.

Escenarios de consejería (*counseling*) La evaluación en un contexto de *counseling* puede ocurrir en ambientes tan diversos como escuelas, prisiones, o instituciones de carácter privado o público. Sin importar las herramientas particulares empleadas, el objetivo primordial de esas evaluaciones es el mejor desempeño del evaluado, en términos de adaptación, productividad, calidad de vida o alguna variable relacionada. Las mediciones de las habilidades sociales y académicas, así como aquellas relacionadas a la personalidad, intereses, actitudes y valores están entre los muchos tipos de pruebas que un consejero puede administrar a su cliente. Las preguntas de referencia a ser contestadas, pueden abarcar diferentes aspectos, desde: “¿cómo puede este niño concentrarse mejor en las tareas a realizar?”, hasta “¿para qué carrera es más competente este cliente?”, o “¿qué actividades se recomiendan para el retiro?”. Debido a que el evaluado es en muchos casos el depósito primario y usuario de los datos de una prueba administrada por un consejero, es imperativo que éste, entienda la importancia y limitaciones de sus hallazgos y sea capaz de transmitir al cliente, de una manera competente, los resultados de la evaluación.

SÓLO PIENSE...

Las pruebas se utilizan en el ámbito clínico y el de consulta para ayudar a mejorar la calidad de vida. Pero ¿existen algunos aspectos que una prueba psicológica no pueda medir?

Escenarios clínicos Las pruebas y muchas otras herramientas de evaluación son usadas en escenarios clínicos como hospitales públicos, privados y militares, clínicas de pacientes internos y externos, consultorios de práctica privada, escuelas y otras instituciones. Estas herramientas son utilizadas para ayudar a diagnosticar o descartar problemas de conducta. ¿Qué tipos de situaciones agilizarían el empleo de esas herramientas? Aquí hay una pequeña muestra.

- Un cliente de psicoterapia privada desea realizar una prueba para ver si se le puede proporcionar algún indicio no obvio respecto a su inadaptación.
- Un psicólogo escolar evalúa de manera clínica a un niño que experimenta dificultades de aprendizaje para determinar qué factores son las principales causas de su problema.
- Un investigador de la psicoterapia utiliza procedimientos de evaluación para determinar si un método psicoterapéutico en particular, es efectivo en el tratamiento de algún problema.

- Un consultor en psicología es contratado por una compañía de seguros para dar su opinión respecto a los problemas psicológicos de un cliente; ¿el cliente en realidad está experimentando esos problemas o se está fingiendo enfermo?
- A un psicólogo a quien se le ha citado en la corte se le pide que dé su opinión sobre lo competente que es el inculcado para entender el juicio.
- A un psicólogo con experiencia en reclusorios, se le pide que dé su opinión respecto a la extensión de la rehabilitación de un prisionero violento.

Las pruebas empleadas en escenarios clínicos pueden ser pruebas de inteligencia, personalidad, neuropsicológicas, u otros instrumentos especializados, según el área del problema que se requiere evaluar. El sello distintivo del uso de pruebas en los escenarios clínicos es que la prueba o la técnica de medición se emplea sólo con un individuo a la vez. Las pruebas en grupo se usan como método para la selección de grupos de investigación; es decir, para identificar aquellos individuos que requieren una evaluación diagnóstica posterior. En el capítulo 13, además de otras secciones, se observa la naturaleza, los usos y beneficios de la evaluación tanto en escenarios clínicos como en consejería (*counseling*).

Escenarios militares y de negocios En los negocios, así como en el ejército, a las pruebas psicológicas se les conceden diversos usos, tal vez de manera más notable es aquel para la toma de decisiones sobre las carreras del personal. Como se verá en el capítulo 16, se emplea un amplio rango de pruebas de logro, aptitud, interés, motivacionales y otras para la toma de decisiones de contratación, al igual que en decisiones relacionadas con promociones, transferencias, satisfacción en el trabajo y elección de una capacitación futura. Para un candidato a controlador de tráfico aéreo un desempeño en una prueba de atención prolongada hacia los detalles puede ser un requerimiento para el puesto. Para una promoción al rango de oficial para el ejército, un desempeño exitoso en una serie de tareas de liderazgo puede ser esencial.

Otra aplicación de las pruebas psicológicas implica la ingeniería y el diseño de productos y ambientes. Los psicólogos de la ingeniería emplean una variedad de pruebas existentes y en especial inventadas en una investigación diseñada para ayudar a la gente en casa, en su lugar de trabajo y en el ejército. Productos que van desde computadoras de casa, muebles de oficina, hasta paneles de control para jets, se benefician del trabajo de tales esfuerzos de investigación.

Mediante el uso de pruebas, entrevistas y otras herramientas de evaluación, los psicólogos que se especializan en marketing y en la venta de productos están interesados en tomar el pulso a los consumidores; es decir, ayudar a predecir la receptividad del público de un producto nuevo, una nueva marca o una campaña de propaganda o marketing.

Credencialización gubernamental u organizacional Una de las muchas aplicaciones de la medición se encuentra en la obtención de licencias y permisos gubernamentales, la certificación o la credencialización general de los profesionales. Antes de recibir un título legal para practicar la medicina, los médicos deben pasar por un examen. Los graduados de la escuela de leyes no pueden presentarse a los juicios, sino hasta que pasen el examen profesional y obtengan su cédula. Los psicólogos también deben pasar un examen que los titule antes de poder presentarse ante el público ostentando el título de “psicólogo”.

Los miembros de algunas profesiones han formado organizaciones con requerimientos para la membresía que van más allá de los requisitos para la licencia o la certificación. Por ejemplo, los médicos pueden recibir capacitación especializada o una examinación de la especialidad para obtener la distinción de “certificado por el Consejo” en un área de especialización de la medicina. Los psicólogos especializados en ciertas áreas deben ser evaluados para obtener un diploma del **American Board of Professional Psychology (ABPP)** para reconocer la excelencia en la práctica educativa. Otra organización, el **American Board of Assessment Psychology (ABAP)**, premia con su diploma basándose en la utilización, manejo e integración de resultados obtenidos en evaluaciones, en desarrollo de pruebas y a aquellas personas que se distinguen en el campo de la evaluación.

Otros escenarios Distintos tipos de procedimientos de medición encuentran su aplicación en una gran variedad de escenarios. Por ejemplo, la corte se basa en los datos de las pruebas psico-

lógicas y el testimonio de un experto como una fuente de información para ayudar a responder preguntas importantes como “¿El acusado es competente para entender las implicaciones del juicio?” y “¿El acusado sabía lo que estaba bien y lo que estaba mal en el momento en que cometió el acto criminal?”

La medición puede jugar un papel importante en la evaluación de programas, ya sea un programa gubernamental a pequeña o gran escala. ¿Está funcionando el programa? ¿Cómo puede mejorarse? ¿Los fondos se están empleando de la manera en que deberían? ¿Qué tan sólida es la teoría en la que se basa el programa? Éstos son los tipos de preguntas generales que las pruebas y los procedimientos de medición utilizados en la evaluación de programas deben responder.

Las herramientas de evaluación pueden utilizarse en investigación y práctica de todas las áreas de especialización dentro de la psicología. Por ejemplo, considérese la **psicología de la salud**, un área de especialidad que se centra en entender el papel de las variables en el comienzo, curso, tratamiento y prevención de padecimientos, enfermedades y discapacidad (Cohen, 1994). Los psicólogos de la salud están interesados en actividades relacionadas con la enseñanza, la investigación y el servicio a los usuarios, diseñadas para promover la buena salud. Las entrevistas individuales, las encuestas y las pruebas con lápiz y papel son sólo algunas de las herramientas que pueden ser empleadas para ayudar a evaluar el estado actual y los compromisos fisiológicos con respecto a una enfermedad o condición, para evaluar el progreso del tratamiento, así como evaluar los resultados de la intervención.

Un enfoque de investigación en la psicología de la salud incluye el informe de la naturaleza de la adaptación psicológica, la naturaleza de las mediciones, o la naturaleza de la calidad de vida de miembros de grupos específicos. Varias mediciones de adaptación, resistencia, y calidad de vida pueden ser empleadas en la investigación con una amplia variedad de poblaciones, desde mujeres de edad media, quienes acaban de dar a luz, hasta hombres mayores que se sientan afligidos por el debilitamiento de condiciones médicas. Otra línea de investigación general en la psicología de la salud se centra en aspectos de la personalidad, la conducta o el estilo de vida a medida que se relacionan con aspectos que van desde la buena salud física y la longevidad hasta una muerte repentina por ataque al corazón. Por ejemplo, Hill y Pargament (2003) revisaron avances en la medición de la espiritualidad y las posibles implicaciones de esos avances en la salud mental y física. Con el uso de una prueba llamada “Medición de los motivos para beber” (MMB), Martens *et al.* (2003) estudiaron las motivaciones de los atletas escolares para el uso del alcohol. De manera consistente con investigaciones previas, estos investigadores concluyeron que los atletas que estaban implicados en deportes intercolegiales podían ser susceptibles de manera particular al uso del alcohol, al igual que otras drogas, como un mecanismo de resistencia, debido a estrés elevado. Los investigadores concluyeron que la MMB era efectiva en la predicción del consumo del alcohol y, por tanto, podría tener una aplicación en la integración de programas de prevención.


¿Qué rasgos de la personalidad, si existen algunos, podrían predecir la iniciación y el abandono de hábitos como fumar? ¿La obediencia o desobediencia a las instrucciones de los médicos? ¿La fortaleza o el compromiso ante el funcionamiento inmune en los pacientes con sida? Estas preguntas son representativas de los tantos cuestionamientos que se hacen los psicólogos de la salud. Todas estas preguntas requieren de técnicas sólidas de evaluación si se esperan respuestas correctas.

Por supuesto, las pruebas psicológicas y la evaluación no se confinan a la psicología de la salud. Esto es, por mucho, parte de *todas* las áreas de especialidad dentro de psicología y la educación. Además, lo que constituye una “prueba” puede tomar muchas y diferentes formas que van desde papel y lápiz, hasta... bueno, sólo mire la figura 1-6. Ahí encontrará una pequeña muestra de las decenas de miles de métodos de medición que han sido utilizados en una u otra situación. No están presentados aquí para mostrar los procedimientos de evaluación más típicos, sino para ilustrar la diversidad en las herramientas de medición que han sido creadas para usos variados. En resumen, si existe una necesidad de medir una variable particular, se inventará una manera de medir esa variable.


Después de considerar algunos aspectos de la evaluación como el *quiénes, qué y por qué*, lo que queda por hacer es contestar la pregunta de ¿a dónde ir en busca de más información? De hecho,



Por lo menos desde inicios del siglo diecinueve, las unidades militares alrededor del mundo han confiado en pruebas psicológicas y de otros tipos para la selección de personal, validación de programas y aspectos relacionados (Hartmann et al., 2003). En algunas culturas, donde el servicio militar tiene un alto valor, los estudiantes toman cursos preparatorios con la esperanza de ser aceptados en las unidades militares de élite. Éste es el caso de Israel, donde el entrenamiento riguroso como el que se muestra en la fotografía prepara a los estudiantes de educación media para las pruebas físicas y de tipos relacionados que sólo uno de cada sesenta reclutas pasarán.



Existe evidencia que sugiere que algunas personas con desórdenes de alimentación pueden tener en realidad un desorden de autopercepción; es decir, ellas se ven a sí mismas más pesadas de lo que en realidad son (Thompson y Smolak, 2001). J. Kevin Thompson et al. diseñaron el aparato de rayo de luz ajustable para medir la distorsión de la imagen del cuerpo. Los evaluados ajustan cuatro rayos de luz para indicar lo que ellos creen es el ancho de sus mejillas, cintura, cadera y muslos. Después se obtiene una medida de la exactitud de estas estimaciones.



Herman Witkin y sus asociados (Witkin y Goodenough, 1977) estudiaron variables relacionadas con la personalidad en algunas formas muy innovadoras. Por ejemplo, identificaron a personas dependientes del campo (o contexto) e independientes del campo por medio de un dispositivo especialmente diseñado, llamado cuarto inclinado/silla inclinada. A los evaluados se les hicieron preguntas diseñadas para evaluar su dependencia o independencia de las referencias visuales.

Figura 1-6
El amplio mundo de la evaluación



Pinturas como las de esta muestra del Meier Art Judgement Test podrían usarse para evaluar la percepción estética de las personas. ¿Cuál de estas dos representaciones es más agradable en el sentido estético? La diferencia entre las dos pinturas tiene que ver con la posición de los objetos en el tocador.



El deterioro de ciertas funciones sensoriales puede indicar déficit neurológico. Para propósitos de diagnóstico, así como para medir progresos en el tratamiento, la pelota de entrenamiento en neurodesarrollo puede ser útil en la evaluación del sentido de balance en las personas.

creemos que este libro será más útil cuando surjan nuevas preguntas.³ Pero además de un libro como éste, ¿en dónde se consulta información actualizada sobre pruebas y evaluación?

Dónde buscar información autorizada y actualizada: fuentes de referencia

Existen muchas fuentes de referencia para aprender más sobre las pruebas publicadas y objetos relacionados con la evaluación. Estas fuentes varían respecto a sus detalles: algunas tan sólo ofrecen descripciones de pruebas, mientras que otras proporcionan información muy detallada sobre los aspectos técnicos.

Catálogos de pruebas Quizá una de las fuentes de información más accesible sobre una prueba sea un catálogo distribuido por el editor de la prueba. Debido a que la mayoría de los editores de pruebas tienen catálogos de sus inventarios disponibles, esta fuente de información sobre las pruebas pueda conseguirse con una simple llamada telefónica, un correo electrónico o una nota. Como podrá esperarlo, sin embargo, los catálogos de los editores por lo general, contienen sólo una breve descripción de la prueba y muy rara vez incluye el tipo de información técnica detallada que el posible futuro usuario de la prueba puede requerir. Además, el objetivo del catálogo es vender la prueba. Por esta razón es raro encontrar, si es que se encuentra, una exploración altamente crítica y detallada en el catálogo de pruebas de las editoriales.

Manuales de pruebas En el manual de la prueba misma se debe encontrar información detallada respecto al desarrollo de una prueba en particular e información técnica relacionada con ésta. Los manuales de las pruebas por lo general están disponibles en las editoriales que las publican. Sin embargo, como propósito de seguridad, el editor de la prueba de manera típica requerirá documentación de la capacitación del profesional antes de llenar una orden de entrega del manual de la prueba. Además de adquirir un manual del editor, hay grandes posibilidades de que en algún lugar de la universidad (ya sea en la biblioteca o el centro de consejo), se conserve una colección de manuales de pruebas populares. Si el manual de pruebas que usted esté buscando no está disponible ahí, pregúntele a su profesor cómo se puede obtener una copia de referencia.

Volúmenes de referencia El Instituto Buros de Mediciones Mentales ofrece una “tienda rápida” con una gran cantidad de información relacionada con las pruebas. La versión inicial de lo que evolucionaría en el *Anuario de mediciones mentales* (AMM) fue recopilado por Oscar Buros (figura 1-7) en 1933. En este escrito, se utilizó la última edición de la recopilación autorizada de revisiones de pruebas realizada en el 15o. *Anuario de mediciones mentales* (Plake et al., 2003), aunque el 16o. no puede estar muy lejos. El Instituto Buros también publica *Pruebas a ser editadas* (Murphy et al., 2002) al igual que un gran número de obras de referencia relacionadas con pruebas. Para una lista de sus últimos ofrecimientos, al igual que algunas ligas a varias bases de datos relacionadas al tema, se puede visitar el sitio del instituto en <http://www.unl.edu/buros/index/simm.html>.

Artículos de publicaciones periódicas Los artículos de publicaciones periódicas, pueden contener reseñas de las pruebas actualizadas, de estudios independientes para la verificación de su solidez psicométrica, o ejemplos de cómo fue usado el instrumento, ya sea en la investigación o en un contexto aplicado. Esos artículos pueden aparecer en una gran cantidad de publicaciones periódicas sobre la ciencia conductual como *Psychological Bulletin*, *Psychological Review*, *Professional Psychology: Research and Practice*, *Journal of Personality and Social Psychology*, *Psychology & Marketing*, *Psychology in the Schools*, *Schools Psychology Quarterly* y *School Psychology Review*. También existen publicaciones que se enfocan de manera más específica en cuestiones relacionadas con las pruebas y la evaluación. Por ejemplo, pueden revisarse las publicaciones como *Journal of Psychoeducational Assessment*, *Psychological Assessment*, *Educational and Psychological Measurement*,

3. Esperamos sinceramente que este pensamiento llegue a usted cuando haya terminado su trabajo en curso y se encuentre a usted mismo yendo hacia una librería para vender los libros de texto usados.



Figura 1-7
Oscar Krisen Buros (1906-1978)

Buros es recordado como el creador del Mental Measurements Yearbook (Anuario de mediciones mentales), MMY, un tipo de Informe del consumidor para pruebas y una muy necesaria fuente de "políticas psicométricas" (Peterson, 1997, p. 718). Su trabajo continúa en el "Buros Institute of Mental Measurements" en la Universidad de Nebraska, en Lincoln. Además del MMY, que se actualiza de manera periódica, el instituto publica una variedad de textos relacionados con pruebas psicológicas.

Applied Measurement in Education, y el *Journal of Personality Assessment*. Las publicaciones como *Psychology, Public Policy and Law* y *Law and Human Behavior*, a menudo contienen artículos altamente informativos sobre cuestiones legales y éticas así como controversias que se relacionan con las pruebas psicológicas y la evaluación.

Además de artículos relevantes sobre pruebas específicas, las publicaciones periódicas son una rica fuente de información en las nuevas tendencias de las pruebas y evaluaciones. Por ejemplo, con respecto a la evaluación psicológica clínica, el impacto negativo del cuidado de la salud y la mala disposición de los usuarios a pagar servicios de evaluación han incitado en gran medida la autoevaluación por parte de aquellos que pertenecen al negocio de la evaluación (Camara *et al.*, 2000; Sanchez & Turner, 2003). Mientras que los críticos de la evaluación clínica argumentan que las pruebas y la evaluación son demasiado caras, consumen demasiado tiempo y tienen muy poco valor (Griffith, 1997), más revisiones en desacuerdo con estas cuestiones encuentran abundante apoyo empírico para el valor de esa tarea y actividad (Kubiszyn *et al.*, 2000).

Bases de datos en línea Una de las bases de datos bibliográficas más extensa de la publicaciones relacionadas con pruebas es la mantenida por el Educational Resources Information Center (ERIC). Fundado por el Departamento de Educación de Estados Unidos y operado fuera de la Universidad de Maryland, el sitio de ERIC en www.eric.ed.gov/researchdb/index.html contiene noticias y fuentes valiosas sobre pruebas y evaluación. Hay extractos de artículos, artículos originales y ligas a otros sitios web útiles. ERIC busca promover información balanceada sobre evaluación educativa y promocionar recursos para determinar el uso responsable y ético de pruebas.

La American Psychological Association (APA) mantiene un número considerable de bases de datos útiles para localizar información relacionada con la psicología, en artículos de publicaciones periódicas, capítulos de libros y disertaciones doctorales. **PsycINFO** es una base de datos de extractos que datan desde 1887. ClinPSYC es una base de datos derivada de PsycINFO que se centra en extractos de naturaleza clínica. PsycSCAN: Psicofarmacología, contiene resúmenes de artículos que tienen relación con la psicofarmacología. PsycARTICLES es una base de datos de artículos con una amplia extensión que datan desde 1988. Health and Psychosocial Instruments (HAPI) contiene un listado de medidas creadas o modificadas para estudios específicos de investigación, pero que no están disponibles en forma comercial. Está disponible en muchas bibliotecas de universidades a través de BRS Information Technologies, y también disponible en CD-ROM (actualizado dos veces por año). PsycLAW es una base de datos gratuita y disponible, que contiene discusiones sobre temas selectos relacionados con la psicología y la ley. Se puede

Tabla 1-2
Algunos sitios web de editores de pruebas

Academic Therapy www.academictherapy.com	Lafayette Instruments www.lafayetteinstrument.com	Scholastic Testing Service www.ststesting.com
American Guidance Service www.agsnet.com	Multi-Health Systems www.mhs.com	Slosson Educational Publications www.slosson.com
CPP www.cpp.com	Pearson Assessments www.pearsonassessments.com	Sopris West www.sopriswest.com
CTB McGraw-Hill www.ctb.com	Pro-Ed www.proedinc.com	Stoelting www.stoeltingco.com
Educator Publishing Service www.epsbooks.com	Psychological Assessment Resources www.parinc.com	Vort www.vort.com
Harcourt Assessment, Inc. www.hbem.com	The Psychological Corporation www.psychcorp.com.au	
James Stanfield Company www.stanfield.com	Riverside Publishing www.riverpub.com	

acceder a él en <http://www.apa.org/psyclaw>. Para más información sobre cualquiera de estas bases de datos visite el sitio web de APA en <http://www.apa.org>.

El Servicio de Pruebas Educativas (SPE), “la organización de pruebas más grande del mundo y con más influencia” (Frantz & Nordheimer, 1997), mantiene su propio sitio web en <http://www.ets.org>. El sitio contiene valiosa información sobre pruebas de colocación y admisión de alumnos universitarios, al igual que muchos recursos relacionados. En caso de que usted quiera responder personalmente preguntas de práctica de un examen como el Examen de registro para graduados (Graduate Record Examination, GRE), por ejemplo, éste es el lugar indicado. Para más información, el SPE puede ser contactado por correo electrónico en etsinfo@ets.org. En la tabla 1-2 se presenta una lista de sitios web de editoriales y otras pruebas psicológicas y educativas. Existen muchos otros sitios más que pueden ser de interés para los estudiantes de la psicología y la práctica de la evaluación, por lo que se ha enlistado una muestra de ellos en la tabla 1-3.

Otras fuentes Las bibliotecas escolares contienen un gran número de otras fuentes que pueden utilizarse para adquirir información sobre pruebas y temas relacionados con ellas. Por ejemplo, dos fuentes para explorar el mundo de pruebas y mediciones no publicadas son el *Directory of Unpublished Experimental Measures* (Goldman & Mitchell, 1977) y *Test in Microfiche*, disponible en Test Collections. La APA dispone del *Finding Information About Psychological Tests* (1995), su propia guía para localizar información relacionada con la utilización y aplicación de pruebas. Y ahora, como sitio de referencia sobre estas muchas fuentes de información... véase la tabla 1-4.

Después de indagar sobre una cantidad considerable de información acerca de pruebas y otras herramientas de evaluación, en el siguiente capítulo se explorarán los aspectos históricos, culturales, ético/legales de la actividad y desempeño de la evaluación.

Tabla 1-3
Sitios web relacionados con las pruebas y la evaluación

Direcciones de los sitios web	Razón para visitarlos
http://edres.org/scripts/cat	Para obtener más experiencia de primera mano con la evaluación computarizada, aprender su lógica y observarla “tras bambalinas”.
www.apa.org/science/lag-findtests.htm	Valiosa información general sobre cómo encontrar información sobre pruebas psicológicas publicadas e inéditas
www.apa.org/journals/pas.html	Esta es la página principal de la publicación periódica de la APA, <i>Psychological Assessment</i> . Ahí encontrará tablas de contenidos sobre información actual y podrá tener acceso a los artículos.
www.gre.org	El examen de registro para graduados (Graduate Record Examination, GRE) es una prueba en el futuro de muchos lectores de este libro. Es el sitio oficial de información autorizada para el GRE.
http://edres.org/irt	Después de leer el capítulo 7 de este libro, tal vez desee leer este material avanzado y profundo sobre un enfoque de medición llamado <i>item response theory</i> .
http://edres.org/mdt	Después de leer el capítulo 7 de este libro, tal vez desee leer este material avanzado y profundo sobre un enfoque para clasificar a los examinados con base en una teoría de decisión estadística.

Tabla 1-4
Fuentes de información sobre las pruebas: Algunas ventajas y desventajas

Fuentes de información	Ventajas	Desventajas
Catálogos de pruebas disponibles del editor de las pruebas y distribuidores afiliados de la prueba	Contiene una descripción general de la prueba, incluyendo para lo que está diseñada y para quién está diseñada. Disponible para casi todos los que soliciten el catálogo.	Diseñada de manera primaria para vender la prueba a los usuarios de pruebas o evaluadores y rara vez contiene reseñas críticas. La información no está lo suficientemente desarrollada para poder tomar una decisión de aplicación y uso del instrumento.
Manuales de pruebas	Por lo general, la fuente más detallada disponible para información relacionada con la muestra de estandarización y las instrucciones para la administración de la prueba. También puede contener información útil respecto a la teoría en la que se basa la prueba, si ése es el caso. Es típico que contenga al menos algo de información respecto a la solidez psicométrica de la prueba.	Los detalles con respecto a la solidez psicométrica de la prueba por lo general están disponibles y escritos con base en estudios conducidos por el autor y/o editor de la prueba. El manual de la prueba misma puede ser difícil de obtener para los estudiantes, puesto que su distribución está restringida a profesionales calificados.
Volúmenes de referencia como el <i>Anuario de mediciones mentales</i> , disponible en libro impreso o en línea.	Muy parecido a los <i>Informes de Consumidor</i> para las pruebas, contiene descripciones y reseñas críticas de pruebas escritas por terceras partes quienes presumiblemente no tienen nada que perder o ganar al apremiar o criticar el instrumento, su muestra de estandarización y su solidez psicométrica.	Pocas desventajas si el que la revisa intenta de manera genuina ser objetivo y encaminado al conocimiento, pero, como con cualquier otra reseña, puede proporcionar una visión equivocada, si éste no es el caso. También, para cuestiones muy detalladas de la muestra de estandarización y otros aspectos relacionados, lo mejor es consultar el manual de la prueba.
Artículos de publicaciones periódicas	Fuentes actualizadas de reseñas y estudios de solidez psicométrica. Proporciona ejemplos prácticos de cómo se usa un instrumento en la investigación o en contextos aplicados.	Al igual que con los volúmenes de referencia, las reseñas son valiosas porque contienen información y, hasta donde es posible, no son tendenciosas. El lector debe investigar tantos artículos como le sea posible en su intento por aprender cómo se usa el instrumento en realidad: un artículo sólo puede proponer una visión atípica.
Bases de datos en línea	Ampliamente conocidas y respetadas en las bases de datos del ERIC, son las “minas de oro” virtuales de información útil que contiene aspectos a detalle. Aunque algunas pruebas psicológicas legítimas puedan estar disponibles para la autoadministración y la calificación en línea, la vasta mayoría no lo está.	¡Atención! Algunos sitios web se disfrazan de bases de datos para pruebas psicológicas, cuando en realidad están diseñados para entretener o vender algo, en vez de informar. Es común que estos sitios ofrezcan pruebas que se puedan contestar en línea. A medida en que aprenda más sobre las pruebas, será más crítico del valor de estas “pruebas psicológicas” autocalificadas y autoadministradas.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo al ver si puede explicar cada uno de los siguientes términos, expresiones y abreviaciones:

Asociación Psicológica Estadounidense (APA)	evaluación psicológica colaborativa	portafolio
autopsia psicológica	evaluación psicológica dinámica	procesamiento central
calificación	evaluación psicológica terapéutica	procesamiento local
catálogo de pruebas	evaluado	protocolo
Compenetración o rapport	formato	prueba
Consejo Estadounidense de la Psicología de Evaluación (ABAP)	informe de calificación	prueba de logro
Consejo Estadounidense de Psicología Profesional (ABPP)	informe de calificaciones	prueba de prueba de habilidades escolares
datos de historia del desarrollo	informe de calificación simple	prueba de representación de papeles
desarrollador de pruebas	informe de resultados o Integración de resultados	prueba diagnóstica
diagnóstico	informe de selección	prueba psicológica
énfoque del centro de evaluación	informe descriptivo	pruebas psicológicas
entrevista	informe integrador	psicología de la salud
entrevista de panel	informe interpretativo	psicométrico
evaluación alternativa	Ley Pública 94-142	PsycINFO
evaluación informal	Ley Pública 99-457	puntuación
evaluación psicológica	manual de pruebas	puntuación de corte
evaluación psicológica asistida por computadora (CAPA)	medición	representación de papeles o rol playing
	observación conductual	teleprocesamiento
	observación naturalista	usuario de pruebas o evaluador
	pensamiento grupal	

Un vistazo a la red

Revise los siguientes sitios web para más información sobre temas de este capítulo:

Standards for Educational and Psychological Testing
www.apa.org/science/standards.html

National Council on Measurement in Education
www.ncme.org

American Educational Research Association (AERA)
www.aera.net

Illinois State Board of Education-Alternative Assessment
www.isbe.net/assessment/lAA.htm
www.isbe.net/assessment/default.htm

IDEA
www.ed.gov/offices/OSERS/Policy/IDEA/index.html
www.ideapractices.org/law/index.php

American Board of Professional Psychology (ABPP)
www.abpp.org

American Board of Assessment Psychology (ABAP)
www.assessmentpsychologyboard.org

American Academy of School Psychology
<http://espse.ed.psu.edu/spsy/aasp/aasp.ssi>

National Association of School Psychologists (NASP)
www.nasponline.org/index2.html

PsycLAW
www.apa.org/psyclaw

Consideraciones históricas, culturales y ético/legales

Continúa nuestra revisión profunda del campo de las pruebas y la evaluación psicológica con una mirada retrospectiva para lograr apreciar mejor el contexto histórico de lo que estas actividades implican. Además, se presenta conocimiento que invita a la reflexión respecto a cuestiones culturales y ético/legales. Considere este “alimento” sólo como un aperitivo; material sobre consideraciones históricas, culturales y ético/legales están entrelazadas con otros textos a lo largo de este libro, cuando esto es apropiado.

Una perspectiva histórica

De la antigüedad al siglo XIX

Una forma primitiva de pruebas de destreza existió en China en el año 2200 a. C. (DuBois, 1966, 1970), en donde el emperador chino conducía un programa de pruebas que implicaban alguna forma de examen para los funcionarios públicos cada tercer año. Se sabe mucho más sobre los exámenes para el servicio civil existentes en China, los cuales comenzaron durante la dinastía Chan en 1115 a. C. y terminaron en el año de 1905, cuando una medida de reforma abolió el sistema. Durante tres mil años, el sistema abierto y competitivo de exámenes que prevaleció en China atendió la valoración de las destrezas en áreas como música, arquería, equitación, escritura y aritmética. También se examinaba la destrezas en relación a la habilidad para manejar los ritos y ceremonias de la vida pública y social, leyes civiles, asuntos militares, agricultura, rentas públicas y geografía (figura 2-1).

¿Por qué se introdujeron por primera vez los exámenes para el servicio civil? Muy bien pudo haber sido como resultado de la influencia de las enseñanzas de Confucio, quien enseñó que la autoperfección es algo que se busca alcanzar. La utilización de exámenes para seleccionar a los empleados de gobierno pudo haber sido una extensión de la filosofía “sé todo lo que puedas ser” para gobernar; el gobierno también debía buscar alcanzar todo lo que pudiera ser. Cuando Confucio habló sobre el servicio civil, lo hizo en el contexto del “deber social y moral” para asegurar la búsqueda de la perfección en el gobierno (Li, 2003).

El significado histórico del programa de pruebas en la antigua China es que, hace miles de años existió una civilización que mostró evidencias de una preocupación por algunos de los mismos principios básicos de la psicometría que interesan y se manejan en la actualidad. En un periodo de la historia en que

SÓLO PIENSE...

¿De qué manera las enseñanzas de Confucio podrían incorporarse en Estados Unidos en la evaluación de los aspirantes a un empleo en la oficina postal?



Figura 2-1
Puestos de pruebas en China

Aquí se retratan cientos de cubículos de examinación de servicio civil en Nanking. Las pruebas duraban días y los examinados en ocasiones morían por la tensión generada. Esta fotografía fue tomada alrededor de veinte años después de que cesaran estas pruebas en 1905.

el nepotismo sin duda era cosa común, es admirable ver a una sociedad donde el empleo se basaba en exámenes competitivos y abiertos. Los lectores modernos podrían notar con fascinación que actividades como la arquería y la equitación estaban incluidas dentro de estas pruebas. Sin embargo, los usuarios de las pruebas de aquel entonces consideraban que los servidores civiles debían ser diestros en la aplicación de esas habilidades.

SÓLO PIENSE...

Una pregunta "diagnóstica" de suma importancia durante la Edad Media era: "¿Quién está aliado con el demonio?" ¿Cuál cree usted que es la pregunta más importante para hacer en un diagnóstico en la actualidad?

Son fascinantes desde el punto de vista histórico, los escritos grecolatinos que propusieron diversas bases fisiológicas para la construcción y por tanto para el análisis de la personalidad y del temperamento. También pueden ser intrigantes, los intentos que se dieron en la Edad Media para responder cuestiones diagnósticas de importancia crítica para la sociedad de la época, como "¿Quién está poseído por el demonio?" Sin embargo, no fue sino hasta el Renacimiento cuando comenzó a surgir la medición en las ciencias conductuales, tal y como la reconocemos en la actualidad. Para el siglo XVIII, Christian von Wolff (1732, 1734) había anticipado que la

psicología pudiese ser una ciencia y concibió a la medición psicológica como un área de especialización dentro de esa ciencia.

El siglo XIX

En 1859 se publicó un libro titulado *Del origen de las especies por medio de la selección natural* escrito por **Charles Darwin** (1809-1882). En esta importante obra de consecuencias trascendentales, Darwin afirmaba que la variación azarosa en las especies sería seleccionada o rechazada por la naturaleza de acuerdo con el valor adaptativo y de supervivencia determinado en cada especie. Más tarde argumentaba que los humanos descendían del mono como resultado de esas variaciones genéticas dadas al azar. Esta idea revolucionaria despertó interés, admiración y una gran cantidad de enemistades; ésta sobre todo de los miembros de la comunidad religiosa, los cuales interpretaron las ideas de Darwin como una afrenta para el relato bíblico de la creación

del hombre, escrito en el Génesis. Sin embargo, fue de vital importancia para la ciencia la idea de un vínculo evolutivo entre los seres humanos y los animales, el cual logró conferir una nueva respetabilidad científica a la experimentación con animales. También planteó interrogantes sobre la forma en que se comparaban los animales y los humanos con respecto a los estados de conciencia; cuestiones que clamaban por respuestas en los laboratorios de los futuros científicos conductuales.¹

La historia registra que fue Darwin quien incitó el interés científico en las diferencias individuales. Darwin (1859) escribió:

Las muchas y ligeras diferencias que aparecen en la descendencia de los mismos padres [...] pueden llamarse diferencias individuales [...] Estas diferencias individuales son de la mayor importancia [...] [ya que ellas] proporcionan los materiales sobre los que actúa la selección natural (p. 125).

De hecho, los escritos de Darwin sobre las diferencias individuales despertaron el interés en la investigación de la herencia en su primo, **Francis Galton**. En el curso de sus esfuerzos por explorar y cuantificar las diferencias individuales entre personas, Galton contribuyó ampliamente en el campo de la medición (Flugel y West, 1964; Forrest, 1974; Murphy, 1949). Galton (1869) aspiraba a clasificar a la gente “de acuerdo con sus dotes naturales” (p. 1) y averiguar su “desviación de un promedio” (p. 11). De paso, Galton recibiría el crédito de diseñar o contribuir al desarrollo de muchas herramientas contemporáneas de evaluación psicológica incluyendo cuestionarios, escalas de estimación e inventarios de rasgos personales.

El trabajo inicial de Galton sobre la herencia fue realizado con chícharos, en parte porque tenía a haber menos variaciones entre los chícharos provenientes de una sola vaina. En este trabajo Galton sentó las bases del uso de un concepto estadístico que es central para la experimentación y las pruebas psicológicas: el coeficiente de correlación. Aunque **Karl Pearson** (1857-1936) desarrolló la técnica de correlación producto-momento, las raíces de esta técnica pueden rastrearse directo hasta el trabajo de Galton (Magnello y Spies, 1984). El interés de Galton pasó de la herencia en los chícharos, a la herencia en humanos y a las diversas formas en que se podían medir aspectos individuales de las personas y sus capacidades.

En una exhibición en Londres en 1884, Galton mostró su laboratorio antropométrico donde, por tres o cuatro peniques, dependiendo de si se estaba registrado o no, cualquiera podía ser medido en variables como estatura (de pie), estatura (sentado), alcance del brazo, peso, capacidad pulmonar, fuerza de tracción, fuerza de presión, velocidad del soplo, agudeza visual, memoria de formas geométricas, discriminación de colores y la firmeza del pulso en las manos. A través de sus propios esfuerzos y su exhortación a las instituciones educativas para que llevaran registros antropométricos de sus estudiantes, Galton provocó un interés general en las variables relacionadas con la evaluación psicológica.

La evaluación también fue una actividad importante en el primer laboratorio de psicología experimental, fundado en la Universidad de Leipzig en Alemania por **Wilhelm Max Wundt** (1832-1920), un médico cuyo título en la universidad era “profesor de Filosofía”. Wundt y sus estudiantes trataron de formular una descripción general de las capacidades humanas con respecto a variables como el tiempo de reacción, la percepción y la duración de la atención. A diferencia de Galton, el interés de Wundt no estaba relacionado en las diferencias de los individuos sino en sus semejanzas. De hecho, Wundt consideraba las diferencias individuales como una frustrante fuente de error en la experimentación. Wundt intentaba controlar todas las variables extrañas en un esfuerzo por reducir el error al mínimo. Como se verá más tarde, el intento de controlar variables

SÓLO PIENSE...

¿Qué orientación en la investigación de la evaluación le parece mejor, la de Galton (investigar cómo difieren los individuos) o la de Wundt (investigar en qué los individuos son iguales)? ¿Por qué?

1. La influencia del pensamiento de Darwin también es evidente en la teoría de la personalidad formulada por Sigmund Freud. Desde una perspectiva darwiniana, serían las personas más fuertes con los impulsos sexuales dominantes las que habrían tenido mayor responsabilidad en la contribución a la reserva del gene humano. En este contexto, puede entenderse mejor la noción de Freud de la importancia primordial de los impulsos sexuales, instintivos y agresivos.




Figura 2-2
Los Cattell, James McKeen y Psyche

El psicólogo que acuñó el término prueba mental, James McKeen Cattell (1860-1944), a menudo ha recibido crédito por error (junto con otro psicólogo, Raymond B. Cattell, sin parentesco) como el autor de una medida de inteligencia infantil llamada Escala de inteligencia infantil de Cattell (Cattell Infant Intelligence Scale; CIIS). En realidad, fue Psyche (1893-1989), la tercera de siete hijos de Cattell y su esposa, Josephine Owen, quien creó la CIIS. De 1919 a 1921, Psyche asistió a su famoso padre en los análisis estadísticos para la tercera edición de American Men of Science. En 1927, obtuvo su título de doctora en educación en Harvard. En 1931, adoptó un hijo, convirtiéndose en una de las primeras mujeres solteras en hacerlo (Sokal, 1991). Más adelante en esa misma década adoptó una hija. Su libro The Measurement of Intelligence in Infants and Young Children se publicó en 1940 y fue en ese libro donde se introdujo la CIIS. Más tarde en su carrera, escribió un libro popular, Raising Children with Love and Limits, el cual refutaba la tolerancia que era manejada por las autoridades en la crianza de los niños como Benjamin Spock.

extrañas con el propósito de minimizar el error es un componente rutinario en la aplicación de pruebas psicológicas contemporáneas. La idea es asegurar que las diferencias observadas entre las personas sean en realidad diferencias y no que provengan de variables extrañas, por tanto, las condiciones y los valores de estandarización se manejan para asegurar que las diferencias en las puntuaciones obtenidas por cada individuo, sean el resultado de verdaderas diferencias.

A pesar de la orientación de la investigación prevaleciente que se enfocaba en la forma en que las personas tendían a ser iguales, uno de los estudiantes de Wundt en Leipzig, un estadounidense llamado **James McKeen Cattell** (figura 2.2) manejó un concepto en su tesis doctoral que trataba sobre las diferencias individuales, de manera específica, diferencias individuales en el tiempo de reacción. Después de recibir su grado de doctor en Leipzig, Cattell regresó a Estados Unidos y enseñó en Bryn Mawr y después en la Universidad de Pennsylvania antes de salir a Europa para enseñar en Cambridge. Ahí, Cattell se puso en contacto con Galton, a quien Cattell describió más tarde como “el hombre más grande que he conocido” (Roback, 1961, p. 96).

Inspirado por su contacto con Galton, Cattell regresó a la Universidad de Pennsylvania en 1888 y acuñó el término *prueba mental* en una publicación de 1890. Boring (1950, p. 283) ha señalado que “Cattell más que ninguna otra persona fue responsable de que las pruebas mentales se abrieran paso en Estados Unidos, y es evidente que su motivación fue similar a la de Galton y que fue influida, o al menos reforzada por él”. Cattell aceptó el puesto de profesor y presidente del departamento de psicología en la Universidad de Columbia y durante los 26 años que estuvo ahí no

sólo capacitó a muchos psicólogos, sino que también fundó diversas publicaciones (*Psychological Review*, *Science* y *American Men of Science*, entre otras). En 1921, Cattell contribuyó a la fundación de la Psychological Corporation, la cual nombró a 20 de los psicólogos más eminentes del país como sus directores. La meta de la corporación era “el avance de la psicología y la promoción de las aplicaciones útiles de la psicología”. Originalmente, las acciones de la corporación las poseían 170 psicólogos. En la actualidad la Psychological Corporation se encuentra muy activa dentro del campo de suministro de servicios relacionados con las pruebas psicológicas y la evaluación.

Otros estudiantes de Wundt en Leipzig incluyen a Charles Spearman, Victor Henri, Emil Kraepelin, E. B. Titchener, G. Stanley Hall y Lightner Witmer. A Spearman se le atribuye haber sido el creador del concepto psicométrico de la confiabilidad de la prueba, así como la construcción del marco para el análisis de factores. Victor Henri es el francés que colaboraría con Alfred Binet en artículos que sugerían la forma en la que las pruebas mentales podían ser utilizadas para medir procesos cognitivos superiores (por ejemplo, Binet y Henri, 1895a, 1895b, 1895c). El psiquiatra Emil Kraepelin fue uno de los primeros que experimentó con la técnica de la libre asociación de palabras como una forma de prueba psicológica formal (Kraepelin, 1892, 1895). **Lightner Witmer** recibió su doctorado en Leipzig y fue el sucesor de Cattell como director del laboratorio de psicología en la Universidad de Pennsylvania. Witmer ha sido citado como el “fundador no muy conocido de la psicología clínica” (McReynolds, 1987), título que debe, al menos en parte, al hecho de haber sido desafiado para proporcionar una solución en el caso de una persona con “mala ortografía crónica” en marzo de 1896 (véase Brotemarkle, 1947). Más adelante en ese año, Witmer fundó la primera clínica psicológica en Estados Unidos en la Universidad de Pennsylvania. En 1907, fundó la revista *Psychological Clinic* con el primer artículo titulado “Clinical Psychology” (Witmer, 1907).

El siglo XX

Los comienzos del siglo XX atestiguaron el nacimiento de las primeras pruebas formales de inteligencia. Como se verá en el resto de esta sección, al inicio hubo una gran receptividad para los instrumentos que supuestamente podían medir características mentales; al principio, inteligencia y más adelante otras características como aquellas relacionadas con la personalidad, intereses, actitudes y valores.

La medición de la inteligencia Gran parte de las pruebas del siglo XIX que podrían describirse como de naturaleza psicológica implicaban la medición de capacidades sensoriales, tiempo de reacción y cosas por el estilo. Una persona que tuvo la visión de ampliar las pruebas para incluir la medición de capacidades cognoscitivas fue **Alfred Binet** (1857-1911). Ya desde 1895, Binet y su colega Victor Henri publicarían varios artículos en los que abogaban por la medición de capacidades como la memoria y el manejo de habilidades sociales. Diez años después, Binet y su colaborador Theodore Simon publicarían una “escala de medición de la inteligencia” que constaba de 30 reactivos diseñados para ayudar a identificar a niños en edad escolar con deficiencia mental en París (Binet y Simon, 1905). La prueba de Binet pasaría por muchas revisiones y traducciones, y en el proceso generaría tanto el movimiento de las pruebas de inteligencia como el movimiento de las pruebas clínicas. En breve, las pruebas psicológicas fueron utilizadas en escenarios tan diversos como tribunales para menores, reformatorios, prisiones, orfanatos y escuelas (Pintner, 1931).

En 1939, **David Wechsler**, un psicólogo clínico del Hospital Bellevue en la ciudad de Nueva York, introdujo una prueba diseñada para medir la inteligencia de los adultos, definida como “la capacidad agregada o global del individuo para actuar en forma propositiva, para pensar en forma racional y para enfrentarse en forma efectiva con su ambiente” (p. 3). La prueba, originalmente llamada Escala de inteligencia Wechsler-Bellevue, fue revisada y se le cambió el nombre a Escala Wechsler de inteligencia para adultos (Wechsler Adult Intelligence Scale; WAIS). La prueba llamada WAIS ha sido revisada

SÓLO PIENSE...

A principios del siglo XX, la prueba de Binet fue utilizada en todo el mundo con varios propósitos además de identificar a los niños excepcionales en las escuelas de París. ¿Cuál cree usted que fueron otros usos que se le dieron a la prueba? ¿Qué tan apropiado cree que fue utilizar la prueba para estos otros propósitos?

desde entonces, de manera periódica. En capítulos posteriores se examinará la definición de inteligencia dada por Wechsler según se refleja en la serie de pruebas de inteligencia para adultos, niños y niños en edad preescolar que llevan su nombre.

Una consecuencia natural de la prueba de inteligencia administrada en forma individual diseñada por Binet fue la prueba de inteligencia *grupal*. Las pruebas de inteligencia grupales aparecieron en Estados Unidos en respuesta a la necesidad del ejército por obtener un método eficiente para explorar la capacidad intelectual de los reclutas en la primera guerra mundial. Debido a las capacidades necesitadas en los soldados durante la segunda guerra mundial, psicólogos fueron reclutados en el servicio gubernamental para elaborar, administrar e interpretar datos de pruebas psicológicas grupales.

SÓLO PIENSE...

¿Cuáles cree que son las ventajas de una prueba de inteligencia grupal? ¿Cuáles cree que son las desventajas de una prueba de inteligencia grupal?

Después de la guerra, los psicólogos que regresaron del servicio militar trajeron consigo una riqueza de habilidades en la aplicación de pruebas que serían útiles no sólo para el servicio del gobierno sino también en escenarios tan diversos como la industria privada, hospitales y escuelas. Las pruebas entonces, serían desarrolladas para medir no sólo distintas habilidades e intereses, sino también la personalidad.

La medición de la personalidad La gran acogida que tuvieron las pruebas de capacidad intelectual fomentó la elaboración de una diversidad de pruebas utilizadas para medir variados conceptos psicológicos (Garrett y Schneck, 1933; Pintner, 1931) por tanto, ocho años después de la publicación de la escala de Binet, el campo de la psicología era severamente criticado por estar demasiado orientado hacia el manejo de las pruebas (Sylvester, 1913). Para finales de la década de 1930, aproximadamente cuatro mil diferentes pruebas psicológicas estaban disponibles (Buros, 1938) y el término “psicología clínica” era sinónimo de “pruebas mentales” (Institute for Juvenile Research, 1937; Tulchin, 1939).

La primera guerra mundial no sólo trajo la necesidad de explorar el funcionamiento intelectual de los reclutas sino también la relacionada con la necesidad de explorar sus posibles problemas de personalidad, entonces, al Comité sobre Salud Emocional (Committee on Emotional Fitness) del gobierno, presidido por el psicólogo **Robert S. Woodworth**, se le asignó la tarea de elaborar una medida de adaptación y estabilidad emocional que pudiera administrarse con rapidez y eficiencia a grupos de reclutas. El Comité elaboró diversas versiones experimentales de lo que en esencia eran entrevistas psiquiátricas transcritas. Para disfrazar el propósito verdadero de la prueba, el cuestionario fue denominado Hoja de datos personales (Personal Data Sheet). Se les pedía a los reclutas y voluntarios que indicaran “sí” o “no” a una serie de preguntas que demostraban la existencia de varias clases de psicopatología. Por ejemplo, una de las preguntas en la prueba era: “¿Le preocupa la idea de que la gente lo esté observando en la calle?”

La Hoja de datos personales elaborada por Woodworth y sus colegas nunca pasó de las etapas experimentales, ya que el armisticio que dio fin a la guerra precedió a la forma final de la prueba. Después de la guerra, Woodworth elaboró una prueba de personalidad para uso civil basada en la Hoja de Datos Personales y la llamó Inventario psiconeurótico de Woodworth (Woodworth Psychoneurotic Inventory). Este inventario fue la primera prueba de personalidad basada en un **informe personal**, usada en forma extensa, un método de evaluación que pronto sería empleado de diversas formas en sucesivas pruebas de personalidad.

SÓLO PIENSE...

Describe al candidato ideal para la evaluación de la personalidad a través de un auto-reporte.

Las pruebas de personalidad que emplean metodologías de informe personal tienen ventajas y desventajas. Por una parte, se afirma que la persona que responde la pregunta es la más calificada para proporcionar respuestas sobre sí misma. Por otra parte, existen argumentos en contra de las personas que proveen tal información. Por ejemplo, éstas pueden tener un vago conocimiento sobre sí mismas. Es decir, pueden honestamente creer algo sobre sí mismas que en realidad no es cierto. Sin importar la calidad del conocimiento que tengan sobre sí mismas, algunas personas no están dispuestas a revelar información muy personal o que los haga quedar en una posición negativa. Dadas las deficiencias de la evaluación de la personalidad basadas en el método de informe personal (autoinforme), existía una necesidad para crear pruebas de personalidad alternas.

Hubo varios métodos que cubrieron la necesidad de medir la personalidad, sin basarse en el informe personal. Uno de esos métodos o enfoques para evaluar la personalidad se describió como de naturaleza *proyectiva*. Como se revisará mas adelante en este libro, la **prueba proyectiva** es aquella en la que se asume que un individuo “proyecta” en algún estímulo ambiguo sus propias e individuales necesidades, temores, esperanzas y motivaciones . El estímulo ambiguo podría ser una mancha de tinta, un dibujo, una fotografía o alguna otra cosa.

Quizá la prueba proyectiva más conocida es el Rorschach, una serie de manchas de tinta, elaborada por el psiquiatra suizo **Hermann Rorschach**. El uso de imágenes como estímulos proyectivos fue popularizado a fines de la década de 1930 por **Henry A. Murray**, **Christiana D. Morgan** y sus colegas en la Clínica Psicológica de Harvard. Además de las pruebas proyectivas, se han elaborado y continúan elaborándose pruebas de personalidad que no estén basadas en el informe personal (autoinforme). En los capítulos 11 y 12 se presentará una muestra de estos instrumentos y una discusión general acerca de la evaluación de la personalidad.

SÓLO PIENSE...

¿Qué problemas potenciales cree que pueda traer el uso de métodos proyectivos para evaluar la personalidad?

La tradición académica y la aplicada Al igual que el desarrollo de la psicología que es su campo de origen, el desarrollo de la medición psicológica puede concebirse a través de dos tendencias distintas: la académica y la aplicada. En la tradición de Galton, Wundt y otros estudiosos, las pruebas y la evaluación psicológicas se practican en la actualidad en los laboratorios de psicología de las universidades como un medio para fomentar el conocimiento respecto a la naturaleza de la experiencia humana. También existe una muy firme tradición aplicada; la cual se remonta en la era moderna, al trabajo de gente como Binet y en los tiempos antiguos a China, a la competente aplicación de exámenes para el servicio civil. ¿Qué niño debería colocarse en cuál clase? ¿Qué persona es el mejor candidato para el empleo? La sociedad requiere respuestas a interrogantes como éstas y las pruebas y medidas psicológicas, usadas de una manera competente pueden ayudar a proporcionar tales respuestas.

Quizá hoy, más que nunca, existe una gran apreciación por el papel de la cultura en la experiencia humana. Por tanto, ya sea en escenarios académicos o aplicados, los profesionales de la evaluación reconocen la necesidad de la sensibilidad y apertura multicultural en el desarrollo y uso de pruebas psicológicas. A continuación se revisarán, a grandes rasgos, algunos de los principales aspectos que engloba tal sensibilidad. Éstos, junto con otros temas, se contemplan y exploran a lo largo del libro y en el momento en el que se relacionan directamente con conceptos tales como pruebas y evaluación psicológica.

Cultura y evaluación

Cultura puede definirse como “los patrones de comportamiento, creencias y productos del trabajo de una población, comunidad o grupo de personas particular transmitidos en forma social” (Cohen, 1994, p. 5). Tal como nos es enseñada por nuestros padres, nuestros grupos de pares e instituciones sociales tales como las escuelas, la cultura preescribe muchos comportamientos y formas de pensamiento. El lenguaje hablado, las actitudes hacia los ancianos y las técnicas de crianza de los hijos son sólo algunas manifestaciones críticas de la cultura. La cultura enseña rituales específicos que han de realizarse en el nacimiento, matrimonio, muerte y otras ocasiones trascendentales. Asimismo, comunica mucho sobre lo que debe valorarse o apreciarse, y lo que debe rechazarse o despreciarse. La cultura enseña un punto de vista respecto a lo que significa nacer con uno u otro género, raza o antecedentes étnicos. La cultura nos enseña algo sobre lo que podemos esperar de otras personas y lo que podemos esperar de nosotros mismos. En efecto, la influencia de la cultura sobre los

SÓLO PIENSE...

¿Puede pensar una o dos formas en que usted es un producto de su cultura? ¿De qué manera esto se puede verificar en una prueba psicológica?

pensamientos y el comportamiento de un individuo puede ser mucho más fuerte de lo que la mayoría de nosotros reconocemos a primera vista.

Los profesionales que participan en la tarea de la evaluación han mostrado evidencias de una creciente sensibilidad en la importancia y la función de la cultura en torno a varios aspectos de la medición. Esta sensibilidad se manifiesta en una mayor consideración de las cuestiones culturales en relación a cada aspecto de la elaboración y uso de pruebas, incluyendo la toma de decisiones con base en los datos de éstas. Por desgracia, no siempre fue así.

Desarrollo del interés en asuntos relacionados con la cultura

Poco después de que Alfred Binet introdujo las pruebas de inteligencia en Francia, el Servicio de Salud Pública de Estados Unidos comenzó a usar dichas pruebas para medir la inteligencia en personas que buscaban inmigrar a Estados Unidos (figura 2-3). **Henry H. Goddard** fue el investigador en jefe asignado al proyecto y un especialista en el campo del retraso mental. Con anterioridad, había abierto un laboratorio psicológico en la escuela de capacitación en Vineland, Nueva Jersey y apoyó el uso de la prueba de inteligencia Binet-Simon para determinar qué alumnos requerían de escuelas de educación especial. No mucho tiempo después, se cuestionó acerca de qué tan significativas eran esas pruebas cuando se utilizaban con personas de diversos antecedentes culturales y lingüísticos. Goddard (1913) usó intérpretes en la administración de las pruebas, empleó a un psicólogo bilingüe y administró pruebas a inmigrantes seleccionados por los observadores entrenados al parecerles retrasados mentales (Goddard, 1917). En 1914, Goddard introdujo pruebas de inteligencia a los juzgados con el propósito de argumentar en contra de la pena de muerte para los “idiotas” sin embargo, a pesar que se oponía a la pena de muerte, en aquel momento Goddard creía en la **eugenesia**. Estaba a favor de la institucionalización o esterilización de los débiles mentales para prevenir futuras generaciones de individuos dañados. La reputación de Goddard al final sería empañada por la publicación de un libro en 1912, en donde sus métodos de investigación eran considerados precarios y a partir de ellos establecía que los defectos mentales eran hereditarios.

El impacto del lenguaje y la cultura en los resultados de las calificaciones en las pruebas de capacidad mental fue reconocido por los psicólogos ya desde principios del siglo XX. Una forma para que los primeros elaboradores de pruebas abordaran este hecho psicométrico de la vida fue elaborar **pruebas específicas para culturas definidas**, es decir, pruebas diseñadas para ser usadas con personas de una cultura pero no de otra. Las primeras versiones de algunas de las pruebas de inteligencia más conocidas son representativas de este enfoque para la elaboración de pruebas. Por ejemplo, la versión de 1937 de la Escala de Inteligencia Stanford-Binet, la cual disfrutó de un amplio campo de aplicación hasta que fue revisada en 1960, no incluía niños de minorías en la muestra de estandarización. Del mismo modo, la *Escala de inteligencia Wechsler-Bellevue*,

precursora de una medida de inteligencia para adultos, usada en forma amplia, no contenía a miembros de minorías en los datos de muestra de estandarización publicados. El autor de la prueba, David Wechsler (1944), señaló que “una gran cantidad” de negros fueron examinados durante los ensayos de estandarización pero que esos datos fueron omitidos del manual de la prueba final “debido a que no sentimos que las normas obtenidas de mezclar a las poblaciones, pudieran ser interpretadas sin salvedades y reservas especiales”. Por tanto, Wechsler (1944) afirmó desde el inicio de sus investigaciones, que las normas de la *Escala Wechsler-Bellevue* no podían ser aplicadas para las “poblaciones de color de Estados Unidos”. De manera similar, la edición inaugural de la *Escala*

Wechsler de inteligencia para niños (WISC), publicada por primera vez en 1949 y no revisada hasta 1974, no contemplaba niños pertenecientes a minorías en su muestra de estandarización.

Aun cuando muchas pruebas publicadas eran, en esencia, específicas para una cultura, pronto se hizo evidente que las pruebas eran aplicadas, de manera inapropiada, a personas de culturas diferentes. Quizá no es difícil de imaginar que los evaluados, pertenecientes a culturas

SÓLO PIENSE...

Intente crear un reactivo de prueba específico de una cultura sobre cualquier tema. ¿Los evaluados de qué cultura es probable que respondan de un modo correcto el reactivo? ¿Los evaluados de qué cultura no lo harían bien?



Figura 2-3
Pruebas psicológicas en la Isla Ellis

Los inmigrantes que llegaban a Estados Unidos por la Isla Ellis no sólo eran recibidos por la estatua de la libertad sino también por funcionarios de inmigración listos para evaluarlos con respecto a variables físicas, mentales y de otra índole. Aquí, una prueba de diseño de bloques, una prueba de inteligencia, es administrada a un inmigrante. Quienes eran descalificados en las pruebas físicas, mentales o de otra índole eran repatriados a su país de origen a costa de la compañía naviera que los había traído. Los críticos señalarían más adelante que al menos algunos de los inmigrantes a los que les había ido mal en las pruebas mentales fueron enviados lejos de las costas estadounidenses no debido a que fueran deficientes mentales sino tan sólo porque no entendían el inglés lo bastante bien como para ejecutar las instrucciones. Además, el criterio contra el cual eran evaluados estos inmigrantes de muchas tierras fue cuestionado.

minoritarias, tuvieran tendencia a obtener calificaciones inferiores como grupo, que las personas del grupo o cultura para la que se elaboró y estandarizó la prueba. Como un ejemplo específico, considere este reactivo de la escala WISC publicada en 1949: “Si tu madre te manda a la tienda por una hogaza de pan y no hay ninguna, ¿qué haces?” El que usted perciba o no algún problema con este reactivo, podría depender de su bagaje cultural. De hecho, el reactivo podría ser problemático para niños de origen Hispano, muchos de los cuales podrían haber sido enviados en forma rutinaria a la tienda a comprar tortillas. Supuestamente, muchos de ellos podrían NO conocer el significado de la frase “hogaza de pan”.

La traducción de los materiales de prueba para personas que hablan un idioma diferente de aquel en el que la prueba se escribió inicialmente, comúnmente plantea varios problemas. Algunos reactivos pueden ser más fáciles o más difíciles de lo que se pretendía originalmente cuando se traducen en forma directa a otro idioma. Por ejemplo, el viejo reactivo de vocabulario *mofeta* de la Stanford-Binet habría sido cambiado para su administración en Puerto Rico, donde no existen las mofetas. Algunos reactivos de vocabulario pueden cambiar de significado o tener diferentes significados o aplicaciones cuando se traducen. Por ejemplo, considérese el reactivo de la WISC “¿Por qué la mayor parte de los puestos del gobierno deberían cubrirse por medio de exámenes?” En algunos idiomas y culturas, la palabra *exámenes* se refiere de manera típica a exámenes médicos. En esos casos, una mejor forma de plantear la pregunta del reactivo sería: “¿Por qué la mayoría de los puestos de gobierno deben cubrirse mediante exámenes de habilidades y actitudes de servicio?”

En la actualidad, los elaboradores de pruebas por lo general siguen muchos pasos para asegurar que una prueba determinada y elaborada para uso nacional sea en efecto adecuada para ser usada de tal forma. Estos pasos podrían implicar llevar a cabo la aplicación de una versión preliminar de la prueba en una muestra poblacional o grupo piloto. Los datos de esta muestra se analizan comúnmente de muchas formas. Los reactivos considerados como parciales o dirigidos a minorías o grupos en relación a raza, género u otros factores serán eliminados. Además, puede pedírsele a un panel de revisores independientes que examinen los reactivos de la prueba para encontrar posibles prejuicios. A los examinadores que administran la prueba puede pedírseles que relaten sus impresiones u observaciones en cuanto a varios aspectos de la aplicación. Por ejemplo, pueden señalarse impresiones subjetivas como serían, las percepciones del examinador de la reacción del grupo piloto ante los materiales de la prueba, opiniones respecto a la claridad de las instrucciones y el diseño de los materiales. Puede realizarse una estandarización nacional de la prueba con una muestra de participantes que refleje los datos del censo estadounidense más reciente (como grupos de edad por sexo, región geográfica de Estados Unidos, raza o grupo étnico y posición socioeconómica). La información obtenida a partir de la aplicación de la prueba a gran escala, será utilizada para determinar y excluir cualquier reactivo que sea una posible fuente de prejuicio. En el capítulo 7 se presentarán más detalles respecto al proceso contemporáneo de elaboración de pruebas.

Algunos aspectos respecto a la cultura y la evaluación

La comunicación entre el evaluado y el evaluador es una de las partes fundamentales de la evaluación. Los evaluadores deben ser sensibles a cualquier diferencia entre el vocabulario o el idioma que le sean familiares a los evaluados y el lenguaje en que se conduce la evaluación. Los evaluadores también deben ser sensibles al grado en el que los evaluados hayan sido expuestos a la cultura dominante y al grado en que hayan elegido conscientemente ser parte de ésta. A continuación se considerarán aspectos relacionados con la evaluación y la comunicación, tanto verbal como no verbal, en un contexto cultural.

Comunicación verbal El *lenguaje*, el medio por el cual se comunica información, es una variable clave, aunque a veces se ha pasado por alto en el proceso de evaluación. Lo que es más obvio, el examinador y el examinado deben hablar el mismo idioma. Esto es necesario no sólo para que tenga lugar la evaluación, sino también para que las conclusiones del evaluador respecto al evaluado y su ejecución, sean lo más precisas posibles. Si una prueba se presenta en forma escrita con instrucciones completas, es obvio que quien responde la prueba debe ser capaz de leer y comprender lo que está escrito. Cuando el idioma en que se realiza la evaluación no es el idioma natal del evaluado, pueden surgir dudas respecto al grado de comprensión de las instrucciones o reactivos que el examinado tenga. El peligro de ese malentendido puede aumentar a medida que se use vocabulario, expresiones o idioma inusual. Aun cuando la evaluación se pueda conducir con ayuda de un traductor, también quedan dudas respecto a la comprensión y al manejo de matices sutiles del significado de los reactivos que podrían perderse de alguna manera en la traducción. En ocasiones, los evaluados pueden intentar propositivamente manipular deficiencias en el lenguaje para afectar los esfuerzos y resultados de la evaluación (Stephans, 1992).

El dialecto hablado de un idioma también puede influir en los resultados de la prueba. Aunque, por ejemplo, en Estados Unidos se emplee el inglés americano estándar, en muchas comunidades a lo largo del país se utilizan variantes y dialectos del inglés americano (Wolfram, 1971). En entrevistas u otras situaciones en las que se hace una valoración con base en un intercambio oral entre dos partes, un examinador capacitado puede detectar a través de medios verbales o no verbales que el dominio que el examinado tiene del idioma es deficiente. Esto no sucede con las pruebas escritas. Se supone que todos aquellos a los que se les administra una prueba escrita son capaces de leerla y comprenderla. De otro modo, la evaluación iría mas en relación a la destreza en el uso del dialecto o lenguaje en lugar de cualquier habilidad, capacidad o rasgo de la personalidad que sea la que se pretende medir a través de la prueba.

Cuando se evalúa a un individuo cuya destreza en el idioma necesario o socialmente manejado es limitada o inexistente, surgen una serie de interrogantes y problemas: ¿qué nivel de destreza y manejo en el idioma utilizado se requiere para la aplicación de la prueba? y el evaluado en cuestión, ¿tiene esa destreza? ¿Puede tener lugar una evaluación significativa por medio de un intérprete capacitado para tal eventualidad? ¿Puede diseñarse un procedimiento de evaluación alternativo y más apropiado para cumplir con los objetivos de la misma?

Comunicación no verbal y conducta Los humanos no sólo se comunican por medios verbales sino también a través de medios no verbales. Expresiones faciales, señas con los dedos y las manos además de cambios en la posición o postura corporal del individuo pueden transmitir mensajes. Por supuesto, los mensajes transmitidos por dicho lenguaje corporal pueden ser diferentes de una cultura a otra. Por ejemplo, en la cultura estadounidense, alguien que no mira a los ojos a otra persona cuando habla puede ser visto como signo de deshonestidad o como si se tuviera algo que ocultar. Sin embargo, en otras culturas, esta falta de contacto ocular cuando se habla puede ser una señal de respeto.

Si ha realizado o le han realizado una entrevista de trabajo, puede tener una idea de primera mano del valor de la comunicación no verbal en un escenario de evaluación. Los entrevistados que muestran entusiasmo e interés tienen una ventaja sobre quienes parecen estar soñolientos o aburridos. En escenarios clínicos, un evaluador experimentado puede plantear hipótesis para probarlas en la entrevista a partir del comportamiento no verbal del entrevistado. Por ejemplo, una persona que anda con los hombros caídos, se mueve despacio y exhibe una expresión facial triste puede estar deprimida. Pero por otro lado, este individuo puede estar experimentando malestar físico como resultado de un espasmo muscular o un ataque de artritis. Será labor del evaluador determinar cuál de estas hipótesis, si es que hay alguna, explica mejor el comportamiento observado.

Ciertas teorías y sistemas en el campo de la salud mental van más allá de las interpretaciones más tradicionales del lenguaje corporal. Por ejemplo, en el **psicoanálisis**, una teoría de la personalidad y de tratamiento psicológico desarrollada por Sigmund Freud, se le asigna significado simbólico a muchos actos no verbales. Desde una perspectiva psicoanalítica, el que un entrevistado juegue nervioso con su anillo de bodas durante una entrevista puede interpretarse como un mensaje relacionado con un matrimonio inestable. Como se evidencia en las ideas concebidas sobre “las primeras acciones azarosas” de un paciente durante una sesión de terapia, Sigmund Freud (1913) creía que podía inferir mucho sobre la motivación de la persona, a partir de la conducta y el comportamiento no verbal:

Las primeras... acciones azarosas del paciente... revelarán uno de los complejos que rigen la neurosis... Una joven... se apresura a tirar del dobladillo de su falda sobre su tobillo expuesto; ella ha revelado el meollo de lo que el análisis descubrirá más adelante; el orgullo narcisista por su belleza corporal y sus tendencias al exhibicionismo (p. 359).

Por cierto, esta cita de Freud también es útil para ilustrar la influencia de la cultura en las opiniones terapéuticas y de diagnóstico. Freud vivió en Viena en la época victoriana. En ese momento y en ese lugar, el sexo no era tema para discusión pública. En muchas formas, las opiniones de Freud respecto a la base sexual de diversos pensamientos y comportamientos eran producto de la cultura sexualmente reprimida en la que vivía.

Un ejemplo de un comportamiento no verbal en el que difieren las personas, es la velocidad con la que se mueven de manera característica para completar tareas. El ritmo de vida general en un área geográfica, por ejemplo, es más rápido que en otra. En un estilo parecido, hay diferencias en el ritmo de vida entre culturas y estas diferencias pueden servir para aumentar o disminuir las puntuaciones obtenidas en pruebas que impliquen o manejen reactivos cronometrados (Gopaul-McNicol, 1993; Knapp, 1960). En un sentido más general, Hoffman (1962) cuestionó el valor de las pruebas de habilidad cronometrada, particularmente, aquellas en donde se manejaban reactivos de opción múltiple. Él creía que este tipo de pruebas, se apoyaba más en la rapidez de respuesta del evaluado y por tanto, no se tomaban en cuenta ni se medían, aquellas características

SÓLO PIENSE...

Represente el papel de Sigmund Freud como se ilustra en el extracto y cite un ejemplo de conducta que crea que diga mucho sobre la motivación del individuo.

individuales de “profundidad en el análisis de pensamiento”, discriminando a los individuos considerados como reflexivos. Por cierto, como se verá en el capítulo 9, la tendencia actual en la evaluación de inteligencia está lejos del manejo y aplicación de pruebas cronometradas.

Los examinadores, de manera ideal, deben ser conocedores de los aspectos relevantes de la cultura del evaluado. Por ejemplo, un niño puede parecer no comunicativo y tener habilidades del lenguaje mínimas cuando se le examine de forma verbal. Esto puede deberse al hecho de que

SÓLO PIENSE...

¿Qué tipo de prueba es la mejor para ser administrada a gente que tiene “pensamientos profundos”? ¿Qué tan práctica sería dicha prueba en una administración grupal?

pertenece a una cultura en donde los adultos mandan y los niños hablan con los adultos sólo cuando se les pregunta algo y respondiendo con frases cortas. Además de las barreras lingüísticas, los contenidos de las pruebas de una cultura en particular, están cargados con reactivos y material —algunos obvios, otros más sutiles— derivados de tal cultura. El desempeño de una prueba debe, al menos en parte, reflejar no sólo las variables a medir, sino también una variable adicional, el grado en que el evaluado ha asimilado la cultura a la cual pertenece o en la cual se desarrolla.

Normas de evaluación Supóngase que los principales jefes de cocina de más de cien naciones participan en una competencia efectuada para descubrir la mejor sopa de pollo del mundo. ¿Quién cree que ganaría? La respuesta a esta pregunta depende de las normas de evaluación empleadas. Si el único juez de la competencia fuera el dueño de una tienda *kosher* de platos preparados en el lado este de Manhattan, el participante que se aproximara más a la variedad “casera y preparada al estilo judío” bien podría ser declarado ganador. Sin embargo, otros jueces podrían tener otros estándares y preferencias. Por ejemplo, los conocedores de sopas de las culturas árabes bien podrían tener preferencia por una variedad de sopa de pollo que incluya jugo de limón fresco en la receta. Los jueces de India podrían inclinarse por dar su voto a una sopa de pollo condimentada con pimienta de India y otras especias exóticas. Para otros jueces asiáticos, la salsa de soya podría ser vista como un ingrediente indispensable, y cualquier sopa preparada sin ella podría perder por omisión. En última instancia, es probable que el caso no sea determinar cual sopa es superior al resto ya que juzgar o determinar cuál sopa es mejor será una cuestión de preferencia personal y de la norma de evaluación empleada.

Del mismo modo, los juicios relacionados con ciertos rasgos psicológicos también pueden ser relativos desde un punto de vista cultural. Por ejemplo, el que patrones específicos de comportamiento sean considerados como apropiados para los hombres o para las mujeres dependerá de las normas sociales prevalecientes respecto a la masculinidad y la feminidad. Por ejemplo, hay algunas sociedades en las que se considera apropiado para las mujeres pelear en las guerras y procurar el alimento mientras que los hombres se ocupan de actividades más domésticas.

El que patrones específicos de comportamiento sean considerados psicopatológicos dependerá de las normas sociales prevalecientes. En Sudán, por ejemplo, hay tribus que viven entre el ganado porque consideran sagrados a los animales. Los juicios respecto a quién podría ser el mejor empleado, gerente o líder, pueden diferir como una función de la cultura, así también los juicios o la valoración y definición que se haga con respecto a la inteligencia, sabiduría, valor y otras variables psicológicas.

Un reto inherente en la tarea de evaluar tiene que ver con mediar y equilibrar los resultados arrojados por la prueba y evaluación con los juicios o conceptos derivados de la cultura en torno a dichas habilidades o resultados obtenidos. En la práctica, esto significa plantear interrogantes sobre la aplicabilidad de los hallazgos relacionados con la evaluación a individuos específicos. Por tanto, además de intentar responder cuestiones como “¿qué tan inteligente es esta persona?” o “¿qué tan asertivo es este individuo?”, por medio de pruebas psicológicas, también deben plantearse algunas interrogantes adicionales. ¿Qué tan apropiadas al contexto y cultura son las normas u otros estándares que se usarán para hacer la evaluación?, ¿en qué medida se ha asimilado el individuo en la cultura de la que se extrajo la prueba y qué influencia podría tener dicha asimilación (o ausencia de ella) en los resultados obtenidos?, ¿se han hecho investigaciones que avalen su aplicabilidad en la valoración de este individuo en particular? De manera creciente, se están planteando estas cuestiones no sólo entre los usuarios meticolosos de pruebas sino también en los manejos éticos de las mismas.

Pruebas y pertenencia a un grupo

Las pruebas y otras medidas de valoración administradas en el contexto vocacional, educativo y de orientación vocacional, así como en otros escenarios, dejan poca duda de que las personas difieren, no sólo entre sí con una base individual sino de un grupo a otro con una base colectiva. Frente a esto, surgen de manera directa preguntas como ¿qué estudiante está mejor preparado para ser admitido en esta escuela? o ¿cuál de los candidatos evaluados para el puesto debe obtenerlo? Por otra parte, no sólo individuos, sino grupos de individuos con ciertas preocupaciones sociales han hecho de las respuestas a tales preguntas verdaderos debates acalorados, si no es que litigios y desobediencia civil.

En el área de evaluación vocacional, los usuarios de pruebas son sensibles a los mandatos legales y éticos que requieren del uso de pruebas para contratar o despedir al personal así como para la toma de ciertas decisiones. Si se utiliza una prueba para evaluar la habilidad que tiene un candidato para realizar un trabajo, un punto de vista es que la prueba debe hacer exactamente eso, a pesar del grupo al que pertenezca el evaluado. De acuerdo con esta visión, las puntuaciones de las pruebas para medir la capacidad para realizar un trabajo, deben ser influidas sólo por variables relacionadas con el trabajo. Es decir, las puntuaciones no deben ser afectadas por variables como el largo del cabello, color de ojos, grupo al que pertenece el individuo o cualquier otra variable extraña a la capacidad de realizar el trabajo. Aunque esta visión del papel que desempeñan las pruebas en la selección de personal parecería ser consistente con principios de igualdad de oportunidades, tiene una carga de injusticia y demandas por discriminación. ¿Por qué?

Las demandas por discriminación contra editores de pruebas estadounidenses pueden entenderse mejor como evidencia de la gran complejidad que implica la tarea de evaluación más que como alguna conspiración para usar las pruebas de manera sistemática con el fin de discriminar. En el área de la evaluación vocacional, por ejemplo, pueden surgir conflictos a partir de desacuerdos concernientes a los criterios considerados necesarios para realizar un trabajo particular. El potencial para la controversia aparece sobre casi todos los criterios de selección que establezca un patrón, sin importar si éstos son de naturaleza física, educativa, psicológica o de experiencia.

La cuestión primaria con respecto a la contratación, promoción y otras decisiones de selección de personal en casi cualquier escenario laboral puede expresarse como: “¿Qué criterios deben cumplirse para hacer este trabajo?” Un departamento de policía estatal puede tener el requisito de que todos los aspirantes al puesto de oficial de policía deben cumplir con ciertos requerimientos físicos, incluyendo una estatura mínima de 1.60 m. Una persona que mide 1.55 m y proviene de un antecedente racial donde la estatura promedio de los adultos es menor de 1.60 m es excluido al solicitar el empleo. Debido a que las políticas de evaluación de las fuerzas policíacas tienen el efecto de excluir de manera sistemática a los miembros de un grupo cultural específico, el resultado puede ser una demanda por discriminación. Si el requisito de estatura del departamento de policía es razonable y se relaciona con el empleo, y si de hecho ocurrió la discriminación, son cuestiones muy complejas que tendrán que ser consideradas por un tribunal. Ambas partes pueden presentar argumentos muy convincentes, ya que personas imparciales, eruditas y bien intencionadas pueden tener diferencias bien fundadas sobre la necesidad del requisito de estatura prevaleciente para el trabajo de oficial de policía en un estado en particular.

Más allá de la variable de la altura, parecería que variables como la apariencia y religión tuvieran poca relación con las cualidades que se necesitan para realizar un trabajo. Sin embargo, son precisamente esos factores los que hacen que miembros de algún grupo no entren a muchos empleos y carreras. Considérese en este contexto, a judíos observantes. Su apariencia y atuendos no son los más modernos. Los alimentos que comen deben ser *kosher*. No pueden trabajar o viajar los fines de semana. Dados los criterios de selección establecidos para muchos puestos en corporaciones estadounidenses, los candidatos que son miembros de un grupo conocido como judíos observantes en efecto son excluidos sin importar su habilidad para realizar el trabajo (Korman, 1988; Mael, 1991; Zweigenhaft, 1984).

SÓLO PIENSE...

Desarrolle su propia versión de un proceso justo y de equidad para determinar la altura, si es que se requiere, para los oficiales de policía en su comunidad.

Diferencias generales entre grupos de personas también se extienden a atributos psicológicos como la inteligencia. Por desgracia, la sola sugerencia de que existan tales diferencias en variables psicológicas, despierta con facilidad el escepticismo, si no es que acusaciones de discriminación, prejuicio o algo peor. Esto es en especial cierto cuando las diferencias del grupo observado son las responsables de obstaculizar o excluir a uno u otro grupo del trabajo o de oportunidades educativas.

¿Qué pasaría si se encontrara que existen diferencias sistemáticas en las puntuaciones de las pruebas de habilidad para un empleo derivadas de la pertenencia a un grupo? ¿Qué debería hacerse, si ese es el caso? Un punto de vista es que no se necesita hacer nada. De acuerdo con esta visión, la prueba fue diseñada para medir la habilidad para un trabajo y cumple la meta para la que estaba diseñada. La evidencia que apoya esta visión sugiere que las diferencias de grupo en puntuaciones de pruebas desarrolladas de manera profesional reflejan diferencias en el desempeño dentro del mundo real (Gottfredson, 2000; Halpern, 2000; Hartigan & Wigdor, 1989; Kubiszyn *et al.*, 2000; Neisser *et al.*, 1996; Schmidt, 1988; Schmidt & Hunter, 1992).

Un punto de vista contrastante, es aquel que considera que deben realizarse esfuerzos para “nivelar el campo de juego” entre los diversos grupos de personas. El término **acción afirmativa** es empleado para referirse a esfuerzos voluntarios y gubernamentales realizados por el estado,

SÓLO PIENSE...

¿Qué piensa de la manipulación de las puntuaciones de la prueba como una función de los miembros del grupo para favorecer ciertas metas sociales?

los gobiernos y las empresas del sector privado así como por parte de las escuelas, para combatir la discriminación y promover igualdad de oportunidades o educación para todos (APA, 1996, p. 2). La acción afirmativa busca crear igualdad de oportunidades de forma activa y no pasiva, inherente a este enfoque se encuentran perspectivas tales como “políticas que parecieran neutrales con respecto a la etnia o al género de pertenencia pueden tomarse en cuenta de forma que procuren ventajas para los individuos de un grupo sobre los de otro” (Crosby *et al.*, 2003, p. 35).

En la evaluación, una manera de implementar acción afirmativa es mediante la alteración de procedimientos de calificación de las pruebas de acuerdo con guías establecidas. Por ejemplo, el puntaje que obtenga un individuo en una prueba puede ser contextualizado según su grupo de pertenencia (McNemar, 1975). Mientras que los que proponen esos remedios los ven como necesarios para combatir las inequidades del pasado, otros condenan esa manipulación en las puntuaciones de pruebas como “inequidad en la igualdad” (Benbow y Stanley, 1996).

Por muy comprometidos que puedan estar con los principios de la igualdad y el juego justo, los elaboradores y administradores de pruebas a final de cuentas, deben contemplar a la sociedad en conjunto y —de manera más específica— a las leyes, reglamentos administrativos y otras reglas y códigos profesionales de conducta, como guía en la utilización y manejo de pruebas y resultados.

Psicología, pruebas y políticas públicas Poca gente se opondría a usar pruebas psicológicas en contextos académicos y específicos que busquen el bienestar humano. Del mismo modo, poca gente está enterada del uso cotidiano que se les da a las pruebas psicológicas. De manera más típica, los miembros del público en general están familiarizados con el uso de pruebas psicológicas en contextos de alto perfil, como cuando un individuo o grupo tiene mucho que ganar o perder como resultado de la puntuación de una prueba. En esas situaciones, las pruebas y otras herramientas de evaluación son vistas como instrumentos que pueden tener un impacto momentáneo e inmediato en la vida de una persona. En dicho momento, las personas pueden percibir las pruebas como herramientas utilizadas para negarle a la gente cosas que necesita o desea. El rechazo de un avance educativo, la oportunidad de trabajo, la libertad bajo palabra o la custodia, son algunas de las consecuencias más amenazantes que el público en general, puede asociar con pruebas psicológicas y los procedimientos de evaluación.

La sociedad civil pide a los legisladores y el personal involucrado en políticas públicas, que los protejan de tales amenazas. Los legisladores aprueban leyes, las agencias administrativas o secretarías hacen reglamentos, los jueces anuncian decisiones y los ciudadanos exigen referéndums ya sea para reflexionar y aplicar las políticas públicas prevalecientes o para modificarlas. En la siguiente sección, se amplía la visión de la tarea de la evaluación para incluir no sólo los intereses de la profesión, sino los intereses del público en general.

Consideraciones legales y éticas

Las **leyes** son reglas que deben obedecer los individuos por el bien de la sociedad en general, o reglas pensadas para el bienestar de la sociedad en general. Algunas leyes son y han sido relativamente poco controvertidas. Por ejemplo, la ley que obliga a conducir del lado derecho del camino casi nunca ha sido sometida a debate ni ha sido motivo de búsqueda emocional, ni representa un estímulo para la desobediencia civil. Por seguridad y por el bien común, la mayoría de las personas están dispuesta a renunciar a su libertad de conducir por cualquier lado del camino que les plazca. Pero, ¿qué tal las leyes relativas al aborto?, ¿a la pena de muerte?, ¿a la eutanasia?, ¿a la segregación de los integrantes de cultos religiosos?, ¿a la acción afirmativa en el empleo? Las formas exactas en que deben redactarse e interpretarse las leyes que regulan cuestiones como éstas, son materia de controversias acaloradas, como lo son algunas de las leyes que se refieren a la medición psicológica.

Mientras que un cuerpo de leyes es un cuerpo de reglas, un cuerpo **ético** es un cuerpo de principios de conducta correcta, apropiada o buena. Por tanto, por ejemplo, una ética del viejo oeste era “nunca dispaes por la espalda”. Dos principios bien conocidos aceptados por los marinos establecen que “las mujeres y los niños son los primero en una emergencia” y “un capitán se hunde con su barco”.² La ética del periodismo dicta que los reporteros deben presentar todos los ángulos de un asunto controvertido. Un principio de la investigación ética es que el investigador nunca debe inventar datos, todos los datos deben reportarse con precisión. ¿Qué clase de lineamientos éticos piensa que deben regir el comportamiento profesional de los psicólogos implicados en las pruebas y la evaluación psicológicas? En la medida en que es reconocido y aceptado un **código de ética profesional** por los miembros de una profesión, se definen las normas de cuidado esperadas por los miembros de esa profesión.

En la actualidad, los miembros del público y los de una determinada profesión, a veces han estado en lados diferentes de la cerca respecto a cuestiones legales y de ética. Ahora se explorará cómo y por qué ha sido ese el caso.

Las preocupaciones del público

La tarea de la evaluación nunca ha sido entendida muy bien por el público en general. Incluso en la actualidad, es desafortunado que podamos escuchar afirmaciones sintomáticas de conceptos erróneos con respecto a las pruebas (por ejemplo, “lo único que miden las pruebas es la capacidad de responder pruebas”). Las consecuencias posibles de la mala comprensión del público incluyen temor, enojo, legislación, litigios y regulaciones administrativas.

Quizá la primera vez que el público estadounidense manifestó una preocupación general sobre las pruebas psicológicas fue al término de la primera guerra mundial. En esa época, varios profesionales (al igual que personas que no eran profesionales) buscaban adaptar las pruebas grupales elaboradas por el ejército para reclutar soldados, para uso civil en las escuelas y la industria. Muchos artículos en los periódicos reflejaban la incomodidad del público en general generado por la creciente industria de las pruebas, con títulos como “The Abuse of Tests” (véase Haney, 1981). Menos conocidas fueron las voces de la razón que ofrecieron caminos constructivos para corregir lo que estaba mal en las prácticas de la evaluación.

Anticipándose a los *estándares* de la actualidad, Ruch (1925), un especialista en medición, propuso varias normas y lineamientos para el desarrollo de pruebas. También escribió sobre “la necesidad urgente de crear un organismo de investigación que emprendería evaluaciones imparciales, experimentales y estadísticas de las pruebas” (Ruch, 1933). La historia registra que un equipo de expertos en medición tomó la ambigua tarea de intentar jerarquizar todas las pruebas publicadas para el uso en escenarios educativos. El resultado fue un libro pionero (Kelley, 1927), que proporcionaba a los usuarios de pruebas, información necesaria para comparar los méritos y las ventajas de cada una de las pruebas publicadas hasta ese momento. Sin embargo, dada la

2. Dejamos el problema de lo que se debe hacer cuando el capitán del barco es una mujer para referirnos a un tomo dedicado a la exploración a fondo de la ética de los marinos.




Figura 2-4

El lanzamiento de un satélite... y un interés renovado en las pruebas

El 4 de octubre de 1957, los científicos del país conocido entonces como la Unión de Repúblicas Socialistas Soviéticas lanzaron al espacio un satélite (que llamaron Sputnik). El evento fue recibido con sorpresa e incluso como un impacto por los estadounidenses. El prospecto de enemigo en una guerra fría que tenía a un satélite en órbita sobre la Tierra veinticuatro horas al día era un acontecimiento sin precedentes. El lanzamiento causó una amplia preocupación acerca de la capacidad de Estados Unidos para competir en la nueva frontera del espacio. Se debía poner un mayor énfasis en la educación, en particular en materias como matemáticas, ciencias, ingeniería y física. Y se harían esfuerzos más grandes para identificar a los niños dotados que algún día aplicarían ese conocimiento en la carrera espacial.

velocidad en la que se estaban publicando los instrumentos, esta fuente requería de una actualización constante. Por tanto, Oscar Bueros no fue el primer profesional de la medición que emprendió una evaluación general de las pruebas. Sin embargo, fue el más tenaz en la actualización y revisión de la información.

La difusión que se dio a las pruebas militares durante la década de 1940 como resultado de la segunda guerra mundial no despertó tanto interés popular como lo hicieron las pruebas que se llevaron a cabo durante la primera guerra mundial. En vez de eso, hubo un evento en una tierra lejana que tendría un efecto momentáneo en las pruebas de Estados Unidos: el lanzamiento de un satélite al espacio (véase figura 2-4).

Alrededor de un año después del lanzamiento del *Sputnik*, el Congreso de Estados Unidos aprobó la Ley de Educación para la Defensa Nacional (National Defense Education Act), la cual proporcionaba dinero federal a las escuelas locales con el propósito de realizar pruebas de capacidad y aptitud en un esfuerzo por identificar estudiantes sobresalientes y talentosos desde el punto de vista académico. Este evento provocó la proliferación subsecuente de programas de pruebas a gran escala en las escuelas. Al mismo tiempo, el uso de pruebas de capacidad al igual que de personalidad para la selección de personal aumentó en el gobierno, el ejército y las empresas. El amplio y creciente uso de pruebas reanudó la preocupación pública, reflejada en artículos de revista como: "Testing: Can Everyone be Pigeonholed?" (*Newsweek*, 20 de julio de 1959) y "What the Tests Do Not Test" (*New York Times Magazine*, 2 de octubre de 1960). El resultado del aumento en la preocupación del público fue la realización de audiencias legislativas sobre el tema de la evaluación (Amrine, 1965).

En 1969, los medios masivos de comunicación concedieron una gran atención a la publicación de un artículo en la prestigiada publicación *Harvard Educational Review*. El artículo se titulaba “How Much Can We Boost IQ and Scholastic Achievement?” en donde su autor, Arthur Jensen, afirmaba que “los factores genéticos están implicados en gran medida en la diferencia de la inteligencia promedio entre negros y blancos” (1969, p. 82). Lo que siguió a eso fue un aumento significativo en la atención pública y profesional dada a las cuestiones de la naturaleza contra la crianza, al igual que un creciente escepticismo respecto a lo que en realidad estaban midiendo las pruebas de inteligencia. En 1972, el Comité Selecto Estadounidense sobre Igualdad de Oportunidades en la Educación (United States Select Committee on Equal Education Opportunity) estaba preparando audiencias sobre esa cuestión. No obstante, de acuerdo con Haney (1981), las audiencias “fueron canceladas debido a que prometían ser demasiado controvertidas” (p. 1026).

El alcance de la preocupación del público sobre la evaluación psicológica se refleja en la extensa participación del gobierno en muchos aspectos del proceso de evaluación a partir de décadas recientes. La evaluación se ha visto afectada en numerosas e importantes formas por actividades de las ramas legislativa, ejecutiva y judicial de los gobiernos federal y estatales. La tabla 2-1 resume legislación y litigio.

Legislación Aunque la legislación resumida en la tabla 2-1 fue decretada a nivel federal, los estados también aprobaron legislaciones que afectaron la tarea y actividad de la evaluación. En la década de 1970, numerosos estados decretaron **programas de pruebas de competencia mínima**, que se refieren a programas basados en pruebas formales y diseñados para tomarse en cuenta en las decisiones alrededor de varios aspectos de la educación de los estudiantes. Los datos de esos programas fueron utilizados en la toma de decisiones acerca de promociones de grado, premios de diplomas e identificación de áreas para la instrucción de niños atrasados. Estas leyes surgieron de la idea de que los graduados del bachillerato debían tener, al menos, “competencias mínimas” en áreas como lectura, redacción y aritmética.

La **legislación sobre la verdad en las pruebas** también fue aprobada en el nivel estatal, comenzando en la década de 1980. El objetivo principal de estas leyes es proporcionar a quienes responden las pruebas un medio para conocer los criterios contra los que se les está comparando. Para alcanzar este objetivo, algunas leyes ordenan la revelación de preguntas y respuestas de las pruebas de admisión a la educación secundaria y en el nivel profesional dentro de los 30 días posteriores a la publicación de las calificaciones de la prueba. Algunas leyes requieren que se conserve en el expediente información relevante acerca de la elaboración de la prueba y su solidez psicométrica. Algunas leyes sobre la verdad en las pruebas requieren que se proporcionen descripciones de 1) el propósito de la prueba y la materia de que trata, 2) el conocimiento y capacidades que pretende medir la prueba, 3) los procedimientos para asegurar la precisión en la calificación, 4) los procedimientos para notificar a quienes respondieron la prueba de los errores en la calificación y 5) los procedimientos para asegurar la confidencialidad de quienes respondieron la prueba, así como de los resultados obtenidos. Las leyes sobre la veracidad de las pruebas crean especiales dificultades para los elaboradores y editores de pruebas, quienes afirman que es esencial que puedan mantener en secreto los reactivos de las pruebas. Señalan que puede haber una reserva limitada de reactivos para algunas pruebas y que es prohibitivo el costo en cuanto a recursos económicos, materiales, humanos y de tiempo, el elaborar un conjunto nuevo de reactivos para cada administración sucesiva de la misma.

Algunas leyes ordenan la participación de la rama ejecutiva del gobierno en su aplicación. Por ejemplo, el título VII de la Ley de Derechos Civiles de 1964 creó la Comisión de Igualdad de Oportunidades de Empleo (Equal Employment Opportunity Commission; EEOC) para aplicar la ley. La EEOC ha publicado series de lineamientos relativos a las normas que se deben cumplir al construir y usar pruebas para seleccionar a sus empleados. En 1978, la EEOC, la Comisión del Servicio Civil (Civil Service Commission), la Secretaría del Trabajo (Department of Labor) y la Secretaría de Justicia (Department of Justice) publicaron en forma conjunta una guía de procedimientos para la selección titulada, *Uniform Guidelines on Employee Selection Procedures*. Una muestra de uno de sus lineamientos es el siguiente:

El uso de cualquier prueba que afecte de manera adversa la contratación, promoción, transferencia o cualquier otra oportunidad de empleo o de ingreso de las clases protegidas por el título VII

Tabla 2-1
Algunas legislaciones y leyes significativas

Legislación	Significado
Ley de Estadounidenses con Discapacidades de 1990	El empleo de materiales y procedimientos de pruebas debe ser esencial para el trabajo y no como forma de discriminación para las personas con discapacidades.
Ley de Derechos Civiles de 1964 (enmendada en 1991). También conocida como Ley de Igualdad en la Oportunidad de Empleo	Constituye un delito y práctica fuera de la ley el hecho de ajustar las puntuaciones, el uso de diferentes cortes en las puntuaciones ya sea antes de la prueba o ya finalizada así como la manipulación de los resultados dentro de la evaluación con fines de selección de personal si se hace para ello un manejo con base en la raza, religión, sexo u origen o nacionalidad.
Ley de Derechos e Intimidad de la Educación Familiar (1974)	Dicta que a los padres y estudiantes se les dé acceso a registrarse en la escuela. También se les garantice el derecho a revisar sus registros por medio de una auditoría o juicio.
Ley de Responsabilidad y Portabilidad de Seguro de Vida (1996 HIPAA)	Proporcionado para los estándares privados que limitan la manera en que los proveedores de salud y otros puedan usar la información personal del paciente.
Ley de Educación para todos los Niños Minusválidos (PL 94-142) (1975 y enmendada varias veces desde entonces, incluyendo IDEA de 1997)	Dicta la evaluación de niños con sospecha de capacidades físicas o mentales disminuidas. Una vez identificado, el individuo debe ser evaluado por un equipo profesional calificado para determinar cuáles son esas necesidades educativas especiales. El niño debe ser reevaluado en forma periódica. Enmendada en 1986 para ampliar la protección relacionada con la discapacidad en niños y bebés recién nacidos o en las primeras etapas de la infancia.
Ley de la Educación para Individuos con Discapacidades (IDEA) Enmiendas en 1997 (PL 105-17)	Ubicación inapropiada en programas de educación especial debido a diferencias culturales. Promueve el manejo de instrumentos y pruebas existentes así como otros medios alternativos de evaluación con el propósito de estimar el proceso de los estudiantes de nivel medio de educación especial a través de las evaluaciones del estado y el distrito.
Ley de No Dejar a los Niños Atrás (NCLB, por sus siglas en inglés) de 2001	Conocida como la NCLB, la reautorización de la Ley de Educación Elemental y Secundaria de 2001 fue diseñada para "cerrar los espacios de logro entre estudiantes minoritarios y no minoritarios y entre niños con desventajas y sin desventajas", entre otras cosas, al establecer normas estrictas de responsabilidad en las escuelas así como la programación de evaluaciones periódicas para medir el progreso de los distritos escolares y con ello mejorar el logro académico. La consigna de esta legislación fue: "¡La demografía no es destino!"
Litigios	
<i>Hobson v. Hanson</i> (1967)	La Suprema Corte dictó que las pruebas de habilidad desarrolladas para blancos no podrían usarse para calificar a estudiantes negros en el sistema escolar. Hacer eso podría resultar en la segregación de escuelas no segregadas.
<i>Tarasoff v. Regentes de la Universidad de California</i> (1974)	Los terapeutas (y evaluadores psicológicos) deben revelar información privilegiada si una tercera persona está en peligro. En palabras de la Corte: "El privilegio de ser protegido termina donde comienza el peligro público".
<i>Larry P. v. Riles</i> (1979 y reafirmada por el mismo juez en 1986)	El juez de California dictó que el uso de pruebas de inteligencia para colocar a los niños negros en clases especiales tenía un impacto discriminatorio porque las pruebas estaban hechas bajo un "prejuicio cultural y racial".
<i>Debra P. v. Turlington</i> (1981)	La corte federal dictó que la prueba de competencia mínima en Florida era inconstitucional porque perpetuaba los efectos de la discriminación en el pasado.
<i>Griggs v. Duke Power Company</i> (1971)	Empleados negros declararon contra una compañía privada por prácticas de contratación discriminatorias. La Suprema Corte encontró problemas con los "instrumentos de pruebas generales" y dictó que las pruebas deben "medir de una manera justa, el conocimiento o las destrezas requeridas para un trabajo particular".
<i>Albamarle Paper Company v. Moody</i> (1976)	El psicólogo industrial de una compañía papelería encontró que las puntuaciones en una prueba de habilidades generales predijo mediciones de desempeño en el trabajo. Sin embargo, como grupo, los blancos tuvieron mejores puntuaciones que los negros en las pruebas. La Corte Distrital de Estados Unidos encontró que el uso de la prueba era suficiente para el trabajo. Una corte de apelación no. Dictó que se había llevado a cabo una discriminación, aunque sin intención.
<i>Regentes de la Universidad de California v. Bakke</i> (1978)	Cuando Alan Bakke supo que las puntuaciones de sus exámenes eran más altas que algunos estudiantes de minorías que habían sido admitidos en la escuela de medicina en Davis, la Universidad de California, presentó una demanda. Una Suprema Corte altamente dividida acordó que Bakke debía ser admitido, pero no tuvo efecto en el uso de las consideraciones de diversidad en las decisiones de admisión.
<i>Allen v. Distrito de Columbia</i> (1993)	Los negros tuvieron puntuaciones menores que los blancos en una prueba de promoción en un departamento de bomberos, la cual estaba basada en aspectos específicos en la labor de apagar el fuego. La corte estuvo a favor del departamento de bomberos y dictó que "el examen promocional... fue una medida válida de las habilidades y el posible éxito futuro de aquellos individuos que respondieron la prueba".
<i>Adarand Constructors, Inc. v. Peña et al.</i> (1995)	Una empresa constructora que competía por un contrato federal declaró en contra del gobierno por perder una oferta frente a un competidor controlado por una minoría, a la cual el gobierno había retenido en el interés de una acción afirmativa. La Suprema Corte, en una decisión muy cerrada (5-4), estuvo a favor del demandante y dictó que las políticas de la acción afirmativa del gobierno violaron la cláusula de protección de igualdad de la 14a. enmienda. La Corte dictó: "El gobierno puede tratar a la gente de manera diferente por su raza, sólo por las razones más apremiantes".
<i>Jaffee v. Redmond</i> (1996)	La comunicación entre el psicoterapeuta y el paciente (y de manera presumible, un evaluador psicológico y un cliente) es privilegiada en las cortes federales.
<i>Gutter v. Bollinger</i> (2003)	En una decisión altamente dividida, la Suprema Corte aprobó el uso de la raza en decisiones para admisiones educativas en una base de tiempo limitado a favor de beneficios educativos que fluyen desde un cuerpo estudiantil diverso (véase sección <i>Close-up</i>).

constituye una forma de discriminación a menos que: a) la prueba haya sido validada y muestre evidencias de un alto grado de utilidad como se describe más adelante y b) la persona que aplica o actúa en base a los resultados individuales de la prueba puede demostrar que no se dispone de otro tipo de procedimientos de contratación, transferencia o promoción adecuados y/o alternativos para... su uso.

Nótese que en este extracto coexiste una definición de discriminación como excluyente con el provisto de que, una prueba válida que evidencia “un alto grado de utilidad” (entre otros criterios) no será considerada como discriminatoria. Sin embargo, por lo general, el público rápidamente ha etiquetado una prueba como injusta y discriminatoria sin importar su utilidad. Como consecuencia, ahora coexisten una gran demanda pública de proporcionalidad y equiparabilidad en la contratación entre los miembros de un grupo y su admisión a universidades, con una alta escasez de proporcionalidad en cuanto a las habilidades manejadas por los miembros del mismo. Gottfredson (2000) señaló que mientras que las normas de selección a menudo podían mejorar, la manipulación de esas normas “sólo produciría frustración, no soluciones permanentes”. Recomendó que las soluciones permanentes fueran buscadas refiriéndose al problema de las diferencias entre las deficiencias de habilidades en los grupos. Sugirió no tratar el problema reduciendo las contrataciones y las normas de admisión o mediante una legislación diseñada para hacer de la contratación y la admisión cuestiones de características específicas para cada grupo en particular. Es en la última dirección a donde se está yendo esta cuestión, al menos según la última legislación y las decisiones de la corte.

En Texas, la ley del estado ahora dicta que los alumnos que se encuentren en 10% superior a todos los alumnos de todas las preparatorias de Texas sean admitidos en la Universidad estatal, sin tomar en cuenta las puntuaciones SAT. Esto significa que sin importar la calidad de la educación en cualquier preparatoria particular de Texas, a cualquier graduado que se encuentre entre 10% de los mejores alumnos, se le garantiza la admisión a la universidad sin importar qué puntuación haya obtenido en una medición estandarizada a nivel nacional. Se han escrito informes de que en algunas preparatorias de Texas, 25% de los estudiantes pertenecen a un rango que los sitúa en el 10% más alto de su grupo (Kronholz, 1998). En California, el uso de las pruebas de habilidad en el sector público ha disminuido como resultado de la aprobación de la Proposición 209, la cual prohibió las preferencias raciales (Rosen, 1998). Una consecuencia ha sido la disminución del énfasis de la Prueba de admisiones para la escuela de leyes (the Law Admissions Test, LSAT) como un criterio de admisión a la carrera de leyes en Berkeley, California. Además, la escuela de leyes ha dejado de tomar en cuenta los promedios generales de las escuelas dentro de sus criterios de admisión, de modo que “4.0 del estado de California tendría el mismo valor que 4.0 de un estudiante en Harvard” (Rosen, 1998, p. 62).

Gottfredson (2000) argumentó que aquellos que estaban a favor de regresar a las normas de logro obtendrían “ningún valor duradero al eliminar las pruebas válidas”. Para ella, disminuir las normas equivale a dificultar el proceso “mientras sólo se tiene la ilusión del progreso”. En vez de regresar a las normas de logro, la sociedad se beneficia más al realizar acciones para cambiar tendencias desafortunadas en la estructura familiar. Frente a desventajas consistentes entre los miembros de varios grupos, Gottfredson enfatizó la necesidad de capacitación en habilidades, no en el hecho de bajar los estándares de logro o en un ataque infundado hacia las pruebas.

Las legislaturas estatales y federales, los cuerpos ejecutivos y los juzgados han estado interesados en muchos aspectos de las pruebas y la evaluación. Ha existido poco consenso acerca de si las pruebas validadas en las que existen diferencias raciales pueden ser utilizadas para apoyar las decisiones relacionadas con el empleo. Los juzgados también han estado aferrados con el papel de la diversidad en los criterios para la admisión a universidades y escuelas profesionales (véase *Close-Up*). Por supuesto, el público no tiene un monopolio en el impacto y manejo de aspectos relacionados con las pruebas y la evaluación.

Las preocupaciones de la profesión

Ya en 1895, la naciente Asociación Psicológica Americana (APA) había formado su primer comité sobre medición mental. El comité estaba a cargo de investigar varios aspectos de la práctica relativamente nueva de las pruebas. Otro comité de la APA para el manejo de mediciones, se

Evaluación, admisiones y acción afirmativa: *Grutter contra Bollinger et al.* (2003)

Barbara Grutter, residente de raza blanca en Michigan, hizo una solicitud a la Escuela de Leyes en la Universidad de Michigan (UML) en 1996. Tenía un promedio de 3.8, entre otros requisitos. En respuesta a su solicitud, la UML le notificó que estaba en una lista de espera. Sin embargo, cuando más tarde se le negó la admisión, entabló una demanda judicial en contra de Lee Bollinger (el decano de la escuela de leyes) y otros, en donde alegó que la UML la había discriminado por su raza. En la demanda se alegó que la UML había dado a los solicitantes que pertenecían a ciertos grupos minoritarios *una oportunidad significativamente mayor de admisión que a estudiantes con credenciales similares de grupos raciales desfavorecidos*.^{*} El tribunal estuvo a favor de la demandante, Grutter. Un tribunal de apelación cambió el juicio, y estuvo a favor del demandado, UML. Se llevó a cabo una apelación con la Suprema Corte para escuchar y decidir el caso.

La última vez que la Suprema Corte tuvo una cuestión similar fue hace más de veinticinco años, en el caso de los *regentes de la Universidad de California contra Bakke*. En *Bakke*, una Suprema Corte dividida de manera tajante dictó que *un Estado tiene un interés sustancial que debe ser servido de manera legítima por un programa de admisiones aplicado de una manera propia que implicara la consideración competitiva de raza y origen étnico*. Un “programa de admisiones aplicado de una manera propia” era uno que, en parte, permitiera una evaluación en verdad individualizada de los solicitantes, mientras se emplearan criterios raciales de forma flexible y no mecánica. Es más, el juez Powell, al escribir la opinión en *Bakke*, había advertido: *La garantía de una protección igualitaria no puede significar una cosa cuando se aplica a un individuo y otra cuando se aplica a una persona de otro color. Si a ambos no se les ofrece la misma protección, entonces no es igualdad* (*Bakke*, 438 U. S., en 289).

La Suprema Corte acordó escuchar a Grutter. Antes de presentar la decisión, aquí se exponen algunos datos basados en la evidencia presentada. La UML recibe 3 500 solicitudes, en donde sólo habrá 350 lugares. Al igual que otras instituciones de nivel superior, la UML ha desarrollado procedimientos de evaluación para determinar quiénes, entre todos los solicitantes, serán aceptados y quiénes no. La universidad utiliza varios criterios para la evaluación, como promedios de calificaciones, puntuación en la prueba de admisión para la Escuela

de Leyes (LSAT), el entusiasmo con el que los solicitantes escriben cartas para apoyar su solicitud, y un ensayo en donde puntualizan cómo contribuirán ellos mismos a la vida y la diversidad de la escuela de leyes. Aunque se espera que ningún solicitante tenga problemas académicos, un alto promedio de calificaciones y la puntuación de la prueba son insuficientes para asegurar la admisión. Las políticas de la escuela dictan que deben tomarse en cuenta otros criterios, como *las contribuciones que podría hacer el solicitante a la vida social e intelectual de la institución*, incluida una evaluación en la decisión de la admisión.

Las políticas de la UML pretendían aceptar a una *concur-rencia significativa* de una minoría no representativa de estudiantes. “Concurrencia significativa” no se refería a un número o porcentaje particular de estudiantes, sino a un número tal de estudiantes, en el que los que pertenecían a minorías no se sintieran aislados o como portavoces de su raza. Un testigo de la UML testificó que *cuando existe una concurrencia significativa de estudiantes que pertenecen a minorías, los estereotipos raciales pierden fuerza porque los estudiantes que no pertenecen a minorías aprenden que no hay “un punto de vista de la minoría”, sino que existe una variedad de puntos de vista dentro de las minorías*. Otro testimonio sugirió que la admisión de la UML tenía el efecto de hacer que los debates de clase fueran más vívidos, con más espíritu y más brillantes porque los estudiantes pertenecían a una variedad de contextos diferentes. Compañías como 3M y General Motors solicitaban gente egresada de la UML, porque, según argumentaban, las habilidades que se requieren en el mercado global de hoy se adquieren de la exposición a diversa gente y culturas.

Los testigos de la UML nunca consideraron lo que significaba “concurrencia significativa” al aceptar a estudiantes que pertenecían a minorías. Estos testigos negaron que ellos mantuvieran lo que, de alguna forma, podría caracterizarse como un **sistema de cuotas**. En este contexto, el sistema de cuotas puede definirse como un procedimiento de selección en el que un número fijo o porcentaje de aspirantes que pertenecían a ciertos contextos debían ser seleccionados. La UML, sin embargo, admitió haber monitoreado reportes diarios que seguían la pista de la composición racial y étnica de la clase.

Haciendo eco de las opiniones divididas y la falta de consenso general visto en *Bakke*, la Suprema Corte estuvo a favor de la UML. Los disidentes se preguntaron si el Estado tenía un interés por proteger la diversidad y si las políticas de la UML reflejaban un intento por lograr un balance racial. Uno de los disidentes hizo referencia a la consulta de reportes diarios de

^{*} El texto en itálicas representa la transcripción textual de la opinión escrita para la Suprema Corte por el juez O'Connor con fecha 23 de junio, 2003.



Los jueces de la Suprema Corte de Estados Unidos acordaron escuchar el caso de Grutter, enmarcando la pregunta que tenían frente a ellos en términos de “si la diversidad es un interés que puede justificar el utilizar la raza, adaptada de manera estrecha, en la selección de aspirantes a universidades públicas.”

la UML con referencia a la “conurrencia significativa”, y escribió que durante las etapas finales del proceso de admisión, *no hubo un intento por una exploración individual, excepto por la raza misma*. Esta justicia de disenso más adelante especuló que la raza quizá era el factor determinante para *muchos miembros de grupos minoritarios quienes no caían dentro del rango superior de las puntuaciones y grados del LSAT*.

Aún así, la corte estableció: *Hoy, sostenemos que la Escuela de Leyes tiene un interés convincente en obtener un cuerpo estudiantil diverso*. La Corte aceptó los argumentos de la UML, incluyendo el argumento de que no se utilizaba un sistema de cuotas. La Corte notó que entre 1993 y 2000 el número de estudiantes afroamericanos, latinos y americanos nativos en cada clase variaba de 13.5% a 20.1%, un rango que la Corte encontró inconsistente con una cuota. La Corte rechazó el argumento de Grutter de que los medios raciales-neutrales existían para crear la diversidad buscada por la UML. La Corte reconoció, como también lo hizo en *Bakke*, que *existen problemas serios de justicia conectados con la idea de preferencia misma*. Aún así, al igual que en *Bakke*, la mayoría concluyó que mientras un programa de admisiones consciente en la raza utilice a ésta como un factor adicional en el contexto de una consideración individualizada, un aspirante rechazado

no ha agotado todas sus posibilidades de tener un lugar tan sólo porque tenía el color equivocado o porque tenía el apellido incorrecto... Sus cualidades pudieron haber sido sopesadas de una manera

justa y competitiva, y no hubiera tenido las bases para quejarse de un trato desigual en la enmienda catorce. (438 U. S., et al. 318)

La Corte advirtió que los programas de admisión basados en la raza, deben tener limitaciones de tiempo. *El hecho de englobar una justificación permanente para las preferencias raciales ofendería el principio fundamental de la protección igualitaria*. El requisito del límite de tiempo podría cumplirse a través de medidas “temporales” (lineamientos que indiquen cuándo se dará por concluido) o por revisiones periódicas para determinar *si aún son necesarias las preferencias raciales para conseguir la diversidad en el cuerpo estudiantil*. Al citar decisiones anteriores y artículos de revisión de la ley, la Corte observó que

Sería un día triste cuando Estados Unidos se convierta en una sociedad sostenida por cuotas, y a cada minoría identificable se le asigne una representación proporcional para cada paso que desee dar en la vida. Pero eso no es racional para los programas de trato preferencial. La prueba ácida de su justificación será la eficacia para eliminar de tajo la necesidad de preferencias étnicas o raciales.

En resumen, la Suprema Corte dictó en el caso Grutter que la cláusula de protección a la igualdad *no prohíbe el uso de razas, adaptado de manera estrecha [y con límite de tiempo] en las decisiones concernientes a aquellas encaminadas a promover un interés por obtener los beneficios educativos que fluyan desde un cuerpo estudiantil diverso*.

formó en 1906 con el objetivo de estudiar más a fondo las cuestiones y problemas relacionados con las pruebas. En 1916 y de nuevo en 1921, se patrocinaron simposios que trataron diversas cuestiones que rodeaban la difusión del uso de las pruebas (*Mentality Tests*, 1916; *Intelligence and Its Measurement*, 1921). En 1954, APA publicó sus *Technical Recommendations for Psychological Tests and Diagnostic Tests*, un documento que enunciaba normas de pruebas y recomendaciones técnicas. Al año siguiente, otra organización profesional, la Asociación Nacional Educativa (National Educational Association) (trabajando en colaboración con el Consejo Nacional sobre Mediciones Usadas en Educación (National Council on Measurements Used in Education) ahora conocido como el Consejo Nacional de Medición (National Council on Measurement) publicó sus *Technical Recommendations for Achievement Tests*. La colaboración entre estas organizaciones profesionales condujo a la elaboración de las normas de validez y estandarización de las pruebas y a lineamientos que serían actualizados años más tarde.

En la actualidad, la APA y otras organizaciones profesionales en Estados Unidos han hecho que diversas publicaciones y obras de referencia, diseñadas para delinear la práctica sólida y la ética en el campo de las pruebas y la valoración psicológicas, estén disponibles.³ Por el camino, estas organizaciones profesionales se han enfrentado con una variedad de preguntas espinosas como: ¿a quién se le debe privar de datos sobre el manejo o resultados de las pruebas?, ¿a quién se le debe permitir adquirir materiales para pruebas psicológicas?, ¿quién está calificado para administrar, calificar e interpretar las pruebas psicológicas?, ¿qué nivel de experiencia en la psicometría requiere alguien para administrar qué tipo de prueba? A continuación se observarán estas cuestiones de un modo más cercano.

Características del usuario de pruebas ¿Debe permitirse a cualquiera que compre y use materiales de pruebas psicológicas? Si no, ¿a quién se le permitiría usar pruebas psicológicas? Ya desde 1950, el Comité sobre Normas Éticas para la Psicología (Committee on Ethical Standards for Psychology) de la APA publicó un reporte llamado *Ethical Standards for the Distribution of Psychological Tests and Diagnostic Aids*. Este reporte definió tres niveles de pruebas en función del grado en el que su uso y aplicación, requiere conocimiento de las técnicas de aplicación específicas para cada una, así como de materias relacionadas con la psicología:

Nivel A: Pruebas o auxiliares que pueden administrarse, calificarse e interpretarse de manera adecuada con la ayuda del manual y una orientación general de la clase de institución u organización en la que el administrador está trabajando (por ejemplo, pruebas de logro o destreza).

Nivel B: Pruebas o auxiliares que requieren algún conocimiento técnico en la elaboración y uso de pruebas, de campos de apoyo como estadística dentro de contextos psicológicos y educativos, diferencias individuales, psicología de la adaptación, psicología de lo laboral y en orientación (por ejemplo, pruebas de aptitudes, inventarios de adaptación aplicables a poblaciones normales).

Nivel C: Pruebas y auxiliares que requieren una comprensión considerable de las técnicas de aplicación de las pruebas y campos psicológicos de apoyo, junto con experiencia supervisada en el uso de estos dispositivos (por ejemplo, pruebas proyectivas, pruebas mentales individuales).

El reporte incluía descripciones de los niveles generales de capacitación correspondientes a cada uno de los tres niveles de pruebas. Aunque algunos editores continúan usando esta clasificación de tres niveles, otros ya no. En general, las normas profesionales promulgadas por la APA (AERA, 1999), NASP (2000; Jacob-Timm & Hartshorne, 1998) y otras organizaciones profesionales establecen que las pruebas psicológicas deben ser usadas sólo por personas calificadas. Además, existe un mandato ético para tomar las medidas pertinentes con el fin de prevenir el mal uso de pruebas y la información que proporcionan. Las obligaciones que tienen los profesionales respecto a los evaluados se establecen en un documento llamado *Código de Prácticas de Pruebas Justas en la Educación* (Code of Fair Testing Practices in Education). En conjunto con autores y/o

3. Por desgracia, a pesar de que las organizaciones en muchos otros países han expresado de manera verbal su preocupación sobre la ética y los estándares en la aplicación de pruebas y su evaluación, son relativamente pocas las organizaciones fuera de Estados Unidos las que en realidad han llevado a cabo acciones significativas y eficaces (Gregoire, 1999).

patrocinadores del Joint Committee of Testing Practices (una coalición de APA, AERA, NCME, la American Association for Measurement and Evaluation in Counseling and Development y la American Speech-Language-Hearing Association), este documento presenta normas para los desarrolladores de pruebas educativas en cuatro áreas: 1) desarrollo y selección de pruebas, 2) interpretación de puntuaciones, 3) procuración de la equidad y 4) retroalimentación para quienes responden las pruebas. Este documento se presenta como referencia junto con el sitio web de este libro de texto en www.mhhe.com/cohentesting6.

Además de promover normas éticas elevadas en las pruebas y evaluación entre los profesionales, la APA ha ayudado en los litigios que han servido para limitar el uso de las pruebas psicológicas a personal calificado. Los escépticos clasifican esta acción legal de la APA relacionada con la medición como “sintomática de maniobras turbias, hecha sólo con el fin de una ganancia financiera”. Una visión más caritativa, quizá más realista, es que tales acciones benefician a la sociedad en general. Es esencial, para que subsista la actividad de la evaluación, que ciertas evaluaciones sean conducidas por personas calificadas en virtud de su educación, capacitación y experiencia profesional.

Una ley de licencia psicológica diseñada para servir como modelo para las legislaturas estatales ha estado disponible en la APA desde 1987. La ley no contiene una definición de prueba psicológica. Procurando el interés del público, de la profesión de la psicología y de otras profesiones que emplean pruebas psicológicas, puede ser momento para que se redacte de nuevo este modelo de legislación, con términos como “prueba psicológica” y “evaluación psicológica” definidos y diferenciados con claridad. Términos como “requisitos del administrador de la prueba” y “requisitos del evaluador psicológico” también deben definirse y diferenciarse con claridad. Al parecer, parte del problema que rodea a los conflictos legales relativos al uso de pruebas psicológicas se deriva de la confusión de los términos *prueba psicológica* y *evaluación psicológica*. Personas que no son consideradas por la sociedad como profesionales pueden estar calificadas para usar pruebas psicológicas (aplicar pruebas psicológicas). Sin embargo, estas mismas personas pueden no estar calificadas para realizar evaluaciones psicológicas. Como se afirmó en el capítulo anterior, la evaluación psicológica requiere de ciertas habilidades, talentos, pericia y capacitación en psicología y medición además de las que se requieren para realizar pruebas psicológicas. En el pasado, los psicólogos han sido descuidados en la diferenciación de los dos términos. Sin embargo, el descuido continuo puede resultar una costosa indiferencia dadas las tendencias legislativas y judiciales actuales.

En medio de las batallas legales, las guerras de manipulación y otros conflictos potenciales respecto a las pruebas y la evaluación, al menos hay un desarrollo que muchos expertos en medición en el campo de la psicología han encontrado gratificador. En 1993, se fundó el Consejo Estadounidense de Psicología de la Evaluación (American Board of Assessment Psychology; ABAP) con el objetivo de identificar a los psicólogos de la evaluación más competentes. Los aspirantes al diplomado en Psicología de la Evaluación del ABAP deben cumplir con sus normas propuestas en función de requisitos generales (incluyendo excelencia académica, carácter moral, integridad científica y capacitación y experiencia relevantes) y conocimiento aplicado (que se evidencia con un producto de trabajo como una prueba publicada y un examen oral o escrito). Los profesionales de la evaluación a los que se les concede el diplomado del ABAP se vuelven miembros de la Academia Estadounidense de Psicología de la Evaluación (American Academy of Assessment Psychology), la rama de educación y capacitación del ABAP.⁴

Evaluando a personas con discapacidades Dificultades análogas a las concernientes a aquellos de minorías lingüísticas y culturales se presentan cuando se hacen pruebas a personas con condiciones incapacitantes. De manera específica, estas dificultades pueden incluir 1) transformar la prueba en una forma que pueda ser respondida por la persona, 2) transformar las respuestas de quien responde la prueba de modo que se puedan calificar y 3) interpretar de manera significativa los datos de las pruebas.

4. Para más información sobre el ABAP, escriba a esta organización en 1000 Brickell Avenue, Suite 910, Miami, Florida 33131.

La naturaleza de la transformación de la prueba como forma para su administración al individuo en condiciones de discapacidad dependerá, por supuesto, de la naturaleza de la discapacidad. Entonces, también algunos estímulos de prueba no se traducen con facilidad. Por ejemplo, si un aspecto importante de un reactivo de prueba contiene ilustraciones que deben ser analizadas, puede no haber una forma adecuada para presentar este reactivo a personas con discapacidad visual. Con respecto a cualquier prueba presentada para su uso con miembros de una población a la que la prueba no estaba destinada originalmente, deben hacerse diversas elecciones de manera inevitable respecto a la forma exacta en que se modificarán los materiales, qué normas de evaluación se aplicarán y cómo se interpretarán los resultados con el fin de mantener la validez y la confiabilidad de los mismos. Como podría esperarse, los evaluadores profesionales no siempre están de acuerdo en las respuestas a estas interrogantes.

Otro aspecto en que existe poco consenso entre los evaluadores profesionales tiene que ver con la petición de un individuo con una enfermedad terminal quien solicita ayuda para morir. Debido a que esa petición sólo puede ser garantizada con los hallazgos de una evaluación psicológica, la vida o la muerte depende, de manera literal, en el balance de esas evaluaciones. En el presente, sólo Oregon, Estados Unidos, tiene una ley sobre los libros que tratan con este complejo escenario. Sin embargo, si otros estados adoptan una legislación similar, sin duda esos escenarios serán más comunes y muchos más evaluadores psicológicos serán llamados para que sean parte de éstos. Algunas cuestiones éticas relacionadas con este fenómeno se exponen en este capítulo dentro del tema *Psicometría cotidiana*.

Administración, calificación e interpretación de pruebas por medio de computadora La amplia disponibilidad de computadoras relativamente baratas ha tenido un gran impacto y la evaluación psicológica asistida por computadora (CAPA) es un ejemplo de ello. Un número cada vez mayor de pruebas psicológicas pueden adquirirse en disco y su administración, calificación e interpretación son tan simples como oprimir un teclado. En muchos aspectos, la simplicidad relativa, conveniencia y rango de actividades de prueba potenciales que brinda la tecnología de las computadoras a la industria de la evaluación, ha sido un gran acontecimiento. Los administradores de pruebas tienen bajo un mismo techo los medios por los que pueden administrar, calificar e interpretar con rapidez una amplia gama de pruebas. Sin embargo, si la creciente industria de las pruebas asistidas por computadora de inicio se observa tranquila, una mirada más cuidadosa revela una madeja de áreas de oportunidad.

Para los profesionales en la evaluación, algunos aspectos importantes respecto a CAPA son

- *Acceso al software de la administración, calificación e interpretación de la prueba*
A pesar de las restricciones de software y seguros tecnológicos para evitar el copiado no autorizado, el software aún puede copiarse. A diferencia de los paquetes de pruebas, que pueden contener objetos manipulables, manuales y otras cosas, una prueba que se administra por computadora puede copiarse con facilidad en un disco compacto.
- *Comparación de la versión escrita y la computarizada de las pruebas*
Muchas pruebas que antes sólo se disponían en un formato escrito en papel, ahora también están disponibles por computadora. En varios casos, no se han investigado, al menos no a profundidad, las implicaciones que tienen la forma tradicional y la forma en computadora.
- *El valor de las interpretaciones de las pruebas por computadora*
Muchas pruebas disponibles para ser administradas en computadora también vienen con puntuación y procedimientos de interpretación por este mismo sistema. Miles de palabras arrojadas cada día en la forma de los resultados de interpretación pero, el valor de estas palabras es cuestionable en varios casos.
- *"Pruebas psicológicas" poco profesionales, irregulares y en línea*
Un número creciente de sitios en Internet ofrecen, por lo general de manera gratuita, pruebas psicológicas en línea. Sin embargo, la vasta mayoría de las pruebas que se ofrecen no cumplen las normas de los psicólogos. Los profesionales en la evaluación se preguntan sobre el efecto a largo plazo de los sitios de "pruebas psicológicas" no profesionales e irregulares.

Evaluación psicológica de vida o muerte

El estado de Oregon tiene la distinción (dudosa para algunos, según los valores de cada quién) de haber promulgado la primera ley de ayuda para la muerte a lo largo de la nación. La Ley de la Muerte con Dignidad en Oregon (Oregon's Death with Dignity Act, ODDA) permite que un paciente, del cual se piensa que vivirá seis meses o menos, solicite de manera voluntaria una dosis letal de medicamento. La ley requiere que dos médicos corroboren el diagnóstico terminal y que uno de ellos solicite una evaluación psicológica del paciente hecha por un psicólogo o psiquiatra con licencia del estado para asegurar que el paciente es competente para tomar la decisión de acabar con su vida y que su juicio no está dañado debido a un trastorno psiquiátrico. Se le negará la ayuda para morir a las personas "que sufren de un trastorno psicológico, psiquiátrico o de una depresión que genere algún tipo de daño o disminución en la capacidad de juicio" (ODDA, 1997).

La ODDA fue parte de un debate acalorado antes de ser aprobada por el referéndum, y aún es un tema de mucha controversia. Los críticos de la ley cuestionan si el suicidio es una elección racional bajo cualquier circunstancia y temen que esa ayuda para morir condonada por el estado servirá para borrar la estigmatización del suicidio en general (Callahan, 1994; véase también Richman, 1988). Se argumenta que el primer deber que tienen los profesionales de la salud y la salud mental es no hacer daño (Jennings, 1991). Algunas personas temen que los profesionales poco éticos y capaces de testificar cualquier cosa (los llamados **asesinos a sueldo**) corromperán el proceso y acomodarán las cosas de manera que aquellos que pueden pagar su cuenta tengan la opinión profesional que desean. Los críticos también señalan la experiencia de la legislación holandesa de Muerte con dignidad. En Holanda, en realidad muy pocos de los individuos que solicitan el suicidio-asistido por parte de un médico, reciben una evaluación psicológica. Además, la Suprema Corte holandesa determina que "en raros casos, el suicidio-asistido por un médico es posible aún para los individuos que únicamente sufran de problemas mentales en vez de enfermedades físicas" (Abeles y Barleve, 1999, p. 233). En lo que respecta a terrenos morales y religiosos, se ha argumentado que la muerte debe verse como una decisión de intervención divina, no humana.

La gente que apoya la legislación de "muerte con dignidad" argumenta que los equipos y métodos que sostienen la vida pueden extenderla en el tiempo cuando esto sea significativo y que la primera obligación de los profesionales de la salud física y mental es aliviar el sufrimiento (Latimer, 1991; Quill *et al.*, 1992; Weir, 1992). De manera adicional, deben señalar que la determinación de la gente por intentar morir así como las historias de cuántas personas con enfermedades terminales han fracasado en sus intentos por terminar con sus vidas al usar métodos poco seguros, provoca un mayor sufrimiento en el proceso. En marcados contrastes con esas historias de horror, se dice que el primer paciente en morir bajo la ODDA había descrito cómo sus familiares "pudieron tranquilizarse y decir lo maravilloso que había sido



Sigmund Freud (1856-1939)

Se ha dicho de Sigmund Freud que tomó una "decisión racional" para terminar con su vida. Con el sufrimiento de un cáncer terminal en la garganta, por el cual tenía mucha dificultad para hablar y cada vez mayor dificultad para respirar, el fundador del psicoanálisis le pidió a su médico una dosis letal de morfina. Por años se ha debatido si la decisión de morir, aun por parte de un paciente con una enfermedad terminal, puede en verdad ser "racional". Hoy, de acuerdo con la legislación de muerte con dignidad, la responsabilidad de evaluar qué tan racional es esa decisión recae en los profesionales de la salud mental.

su vida. Pudimos mirar en retrospectiva todas las cosas bellas porque sabíamos que por fin había una respuesta" (citado en Farrenkopf & Bryan, 1999, p. 246).

Las asociaciones profesionales como la Asociación Psiquiátrica Estadounidense (American Psychiatric Association) y la Asociación Psicológica Estadounidense (American Psychological Association) han

(continúa)

Evaluación psicológica de vida o muerte (continuación)

logrado promulgar en gran medida, códigos de ética que requieren la previsión del suicidio. La promulgación de la ley en Oregon ha puesto a los trabajadores clínicos de ese estado en una posición única, si no es que difícil. Por años, muchos de estos profesionales clínicos han dedicado sus esfuerzos a la prevención del suicidio. Frecuentemente, han sido designados para ser parte activa, si no es que facilitadores de suicidio-asistido por un médico, independientemente de cómo se designe legislativamente al proceso de ayuda para morir. Nótese que la ley de Oregon niega de manera escrupulosa que su objetivo sea la legalización del suicidio asistido por un médico. De hecho, el lenguaje del artículo manda que cualquier acción tomada bajo él “no debe, por ningún motivo, constituir ningún tipo de suicidio, suicidio asistido, asesinato u homicidio por piedad, bajo la ley”. Los marcos de la legislación lo percibieron como un medio por el cual un individuo con una enfermedad terminal podría ejercer algún control sobre el proceso de muerte. Expresado en estos términos, el sobrio deber del médico en el proceso debe hacerse más aceptable, si es que no más ennoblecido.

El proceso de evaluación de la ODDA

1. Revisión de los registros e historia del caso

Con el consentimiento del paciente, el evaluador recopilará los registros de todas las fuentes relevantes, incluidos los registros médicos y de salud mental. Una de las metas es entender el funcionamiento actual del paciente en el contexto de muchos factores, desde el diagnóstico y condición, hasta la mediación y el uso de sustancias.

2. Consulta con profesionales que ofrecen tratamiento

Con el consentimiento del paciente, el asesor puede consultar a los médicos del paciente y otros implicados en el caso, para entender mejor el funcionamiento y la situación actual del paciente.

3. Entrevistas con el paciente

De una manera sensible y a través de entrevistas con el paciente, se explorarán las razones por las cuales se solicita la ayuda para morir, entre ellas se incluyen las presiones y valores que motivaron esa petición. Otras áreas a explorar incluyen: a) el entendimiento del paciente en cuanto a su condición médica, el pronóstico y los tratamientos alternativos; b) la experiencia que tiene el paciente respecto al dolor físico, las limitaciones en el funcionamiento y los cambios a lo largo del tiempo en el funcionamiento cognitivo, emocional y perceptivo; c) la caracterización del paciente en su calidad de vida, incluida la exploración de factores relacionados, como la identidad personal, los roles que desempeña y la autoestima; y d) presiones externas del paciente, como la imposibilidad personal o familiar para pagar un tratamiento continuo.

4. Entrevista con los miembros de la familia y otras personas significativas

Con la autorización del paciente, deben conducirse entrevistas, por separado, con los familiares del paciente y otras personas significativas. Uno de los objetivos es explorar, desde su perspectiva, de qué manera el paciente ha reaccionado ante la adversidad en el pasado y de qué manera ha cambiado y superado su situación actual.

Los psicólogos y psiquiatras a los que se les llama para hacer evaluaciones para conocer qué tan competente es la decisión con respecto a la muerte con dignidad pueden aceptar o negar dicha responsabilidad (Haley y Lee, 1998). A juzgar por una encuesta de 423 psicólogos en práctica clínica en Oregon (Fenn & Ganzini, 1999) muchos de ellos a quienes se les pedía hacer esas evaluaciones de vida o muerte se negaron a hacerlo. Un tercio de la muestra respondió que una evaluación de la ODDA estaría fuera del margen de su práctica. Otro 53% de la muestra dijo que se negaría a desempeñar la evaluación y no realizarían ninguna acción o se negarían a realizar la evaluación por ellos mismos, por tanto, referirían al paciente con un colega.

Aunque ya tienen que establecerse lineamientos firmes respecto a lo que la evaluación de la ODDA va a contener, Farrenkopt y Bryan (1999) ofrecieron varias y útiles sugerencias (que se resumen en la tabla siguiente).

5. Evaluación de competencia

Al igual que los otros elementos de este panorama, este aspecto de la evaluación es complicado y aquí sólo se pueden presentar los lineamientos principales. En general, el evaluador busca entender el razonamiento y el proceso de toma de decisiones del paciente, incluida toda la información relevante para la decisión y sus consecuencias. Se dispone de algunas pruebas formales de competencia (Appelbaum & Grisso, 1995a, 1995b; Lavin, 1992), pero la aplicabilidad legal y clínica de esas pruebas para una evaluación de la ODDA aún no se ha establecido.

6. Evaluación de una psicopatología

¿Hasta qué punto la decisión de quitarse la vida es parte de una función de depresión patológica, ansiedad, demencia, delirio, psicosis y otras condiciones patológicas? Ésta es una pregunta que el evaluador hace no sólo en entrevistas, también en pruebas formales. Algunos ejemplos de posibles instrumentos que el evaluador puede emplear incluyen pruebas de inteligencia, pruebas de personalidad, pruebas neuropsicológicas, listas para reportar los síntomas así como escalas de ansiedad y depresión; para una lista completa de estas pruebas, consulte el Apéndice en Farrenkopt y Bryan (1999).

7. Reporte de hallazgos y recomendaciones

Los hallazgos, incluidos aquellos relacionados con la competencia y el estado mental del paciente, el apoyo y presiones de la familia y cualquier otra cosa relevante para la petición de ayuda para morir por parte del paciente, deben reportarse. Si se encontraran condiciones que pueden ser tratables, se harían recomendaciones de tratamiento relevantes a esas condiciones. Las recomendaciones que se hacen cuando no existe tratamiento pueden incluir recomendaciones legales, planeación del estado y otros recursos. En Oregon, debe completarse una forma de conformidad de una consulta psiquiátrica y psicológica (Psychiatric/Psychological Consultant's Compliance Form), junto con las recomendaciones del consultor y ésta debe enviarse a la División de Salud en Oregon.

¿Contribuirán, por ejemplo, a un escepticismo del público en general, respecto a las pruebas psicológicas?

Quizá el derecho principal que deben tener los que resuelven las pruebas es saber que la prueba psicológica que están respondiendo, es una con la que la mayoría de los psicólogos estarían de acuerdo que es “una prueba psicológica”. A continuación se expondrán algunos otros derechos de quienes responden pruebas.

Los derechos de los evaluados

Como lo prescriben las *Normas*, y en algunos casos las *Leyes*, algunos de los derechos que los administradores de pruebas conceden a quienes las responden son el derecho a dar su consentimiento informado para la prueba, el derecho a ser informado de los resultados, el derecho a su privacidad y confidencialidad y el derecho a la clasificación menos estigmatizadora.

El derecho a dar consentimiento informado Las personas que responden las pruebas tienen el derecho a saber por qué se les están aplicando, cómo se usarán los datos de la prueba y qué información, si es que hay alguna, será revelada y a quién. Con amplio conocimiento de esa información, los que responden las pruebas dan su **consentimiento informado** a ser evaluados. La revelación de esta información debe estar, por supuesto, en un lenguaje que el individuo que responde la prueba pueda entender. Por tanto, para una persona de dos o tres años de edad o un individuo con deficiencia mental con una capacidad lingüística limitada, una información dada antes de la prueba se expresaría como sigue: “Voy a pedirte que trates de hacer algunas cosas para que pueda ver lo que sabes hacer y para qué cosas podrías necesitar algo más de ayuda” (APA, 1985, p. 85).

Si la persona que va a responder una prueba es incapaz de proporcionar un consentimiento informado, dicho consentimiento puede obtenerse por medio de alguno de los padres, tutor o representante legal. El consentimiento debe ser por escrito en lugar de oral y éste debe especificar: 1) el propósito general de la prueba; 2) la razón específica que se persigue en el presente caso y 3) el tipo general de instrumentos que se administrarán. Muchos distritos escolares envían ahora de manera rutinaria a los hogares dichas formas antes de examinar a los niños. Tales formas incluyen de manera típica la opción de hacer que el niño sea evaluado en forma privada si el padre así lo desea. En casos donde las pruebas son ordenadas en forma legal (como en una situación determinada por el tribunal o juzgado), la obtención del consentimiento informado para la prueba puede considerarse más una cortesía (realizado en parte por razones de establecimiento de una buena empatía) que una necesidad.

Un área gris con respecto al derecho del consentimiento informado de forma completa para quien responde la prueba, implica proveer por parte del evaluador, de información basada en investigaciones y situaciones experimentales donde la revelación de los hechos pertinentes a la prueba (incluyendo la hipótesis del experimentador y cosas por el estilo) lo que podría contaminar en forma irrevocable los datos de la prueba y los resultados obtenidos a través de la misma. En algunos casos excepcionales, se maneja cierto grado de decepción para generar situaciones específicas. Por ejemplo, puede crearse una decepción para evaluar cómo reaccionaría un trabajador de emergencias bajo esas condiciones. A veces la decepción incluye el uso de cómplices para simular condiciones sociales que son comunes o poco comunes en una situación particular.

En situaciones en las que es aconsejable no obtener un consentimiento informado para la evaluación, se ordena la discreción profesional. A los que resuelven la prueba se les debe dar una cantidad de información mínima antes de comenzar. Por ejemplo: “Esta prueba se va a llevar a cabo como parte de un experimento sobre la obediencia a la autoridad”. Después de la prueba se debe dar una explicación amplia y completa. Varias organizaciones profesionales han creado políticas y lineamientos respecto a la decepción en la investigación. Por ejemplo, los *Principios éticos de los psicólogos y el código de conducta* (*Ethical Principles of Psychologists and Code of Conduct*, 2002) de la APA promueven que los psicólogos a) no utilicen la decepción a menos que sea absolutamente necesario,

SÓLO PIENSE...

Utilice algún buscador de Internet para encontrar algunos sitios que pretendan administrar pruebas psicológicas de una manera rápida y fácil. Vea si puede decir por qué un psicólogo seguramente consideraría que la prueba tiene más propósitos de entretenimiento que psicológicos. Repita el ejercicio después de que haya leído el capítulo 7 de este libro.

b) no utilicen de ninguna manera la decepción si esto causará a los participantes tensión emocional y c) informar de manera amplia a los participantes los objetivos y modelos de evaluación.

El derecho a ser informado de los hallazgos de la prueba En épocas pasadas, la inclinación de muchos evaluadores psicológicos, en particular de muchos clínicos, era informar lo menos posible a quienes respondían una prueba sobre la naturaleza de su desempeño en una prueba en particular o en el conjunto de pruebas aplicadas. En ningún caso revelaban conclusiones diagnósticas que pudieran causar ansiedad o precipitar una crisis. Esta orientación se reflejaba al menos en un texto autorizado donde se les aconsejaba a los examinadores que mantuvieran la información sobre los resultados de la prueba en un nivel superficial y se centraran sólo en los hallazgos “positivos”. Esto se hacía para que el examinando dejara la sesión de prueba sintiéndose “complacido y satisfecho” (Klopfer *et al.*, 1954, p. 15). Pero todo esto ha cambiado, y dar información realista sobre el desempeño en la prueba a los examinados no sólo es obligatorio desde el punto de vista ético y legal, sino que también puede ser útil desde una perspectiva terapéutica. Las personas que responden pruebas tienen el derecho a ser informadas, en un lenguaje que puedan comprender, de la naturaleza de los hallazgos con respecto a los resultados obtenidos. También tienen derecho a saber qué recomendaciones se hacen como consecuencia de los datos de ésta. Si los resultados, hallazgos o recomendaciones hechos con base en los datos de la prueba son inválidos por cualquier razón (como irregularidades en la administración de la prueba), quienes respondieron tienen derecho a saber esto también.

Debido a la posibilidad de consecuencias adversas como resultado de proporcionar a los individuos información sobre ellos mismos —como su capacidad, su falta de capacidad, su personalidad, sus valores— la comunicación de los resultados de una prueba psicológica es una de las partes más importantes del proceso de evaluación. Con una sensibilización adecuada para cada situación, el administrador de la prueba informará a quien la respondió (y al padre, tutor o representante legal) el propósito de la prueba, el significado de la puntuación con relación a la de otros que la han respondido y las posibles limitaciones y márgenes de error. Y, sin importar si este informe se hace en persona o por escrito, deberá estar disponible un psicólogo calificado para responder cualquier pregunta que tenga quien respondió la prueba (o sus padres) acerca de las calificaciones, puntuaciones o resultados. De manera ideal, debería estar disponible el recurso de orientación para quienes reaccionaron de una manera adversa al enterarse de la información presentada.

El derecho a la privacidad y a la confidencialidad El concepto de **derecho a la privacidad** “reconoce la libertad del individuo para escoger por sí mismo el momento, las circunstancias y en particular el grado en que desea compartir u ocultar a otros, sus actitudes, creencias, comportamiento y opiniones” (Shah, 1969, p. 57). Cuando las personas en los procesos judiciales “se amparan con la quinta” y se rehúsan a responder una pregunta cuya respuesta podría ser incriminatoria para sí mismos, están haciendo valer un derecho a la intimidad previsto en la quinta enmienda de la Constitución de Estados Unidos. La información ocultada de esta manera se denomina *privilegiada*, es información que está protegida por la ley y no puede revelarse en un proceso legal. Los estatutos estatales han extendido el concepto de **información privilegiada** a partes que se comunican entre sí en el contexto de ciertas relaciones, incluyendo la relación entre abogado y cliente, entre doctor y paciente, entre sacerdote y pecador y la relación entre cónyuges. En la mayor parte de los estados, también se concede privilegio a la relación existente entre psicólogo y cliente.

El privilegio se extiende a las partes en estas relaciones profesionales, debido a que se ha considerado que el derecho a la intimidad de las partes sirve a un interés público mayor que el que se serviría haciendo que sus comunicaciones fueran vulnerables a una revelación durante procesos legales. Planteado de otra forma, es para bien de la sociedad si las personas se sienten confiadas de que pueden hablar con libertad con sus abogados, sacerdotes, médicos, psicólogos y cónyuges. Los profesionales como los psicólogos que son parte de estas relaciones especiales, tienen el deber legal y ético de mantener confidenciales las conversaciones de sus clientes.

La **confidencialidad** se distingue de *privilegio* en que mientras “la confidencialidad se refiere a cuestiones de comunicación fuera de los tribunales, el privilegio protege a los clientes de la revelación en procesos judiciales” (Jagim *et al.*, 1978, p. 459). El privilegio no es absoluto; hay

ocasiones en que un tribunal puede considerar necesaria la revelación de cierta información y ordenar que sea divulgada o revelada. Si tras una orden así el psicólogo u otro profesional se rehúsa a hacer la revelación ordenada, lo hace bajo la amenaza de ir a la cárcel, de ser multado o de ambas cosas.

El privilegio en la relación entre psicólogo y cliente pertenece al cliente, no al psicólogo; el cliente competente puede instruir al psicólogo para que revele información a algún tercero (como un abogado o un agente de seguros) y el psicólogo está obligado a hacer la revelación. En algunos casos raros, el psicólogo puede verse obligado desde el punto de vista ético (si no es que legal) a revelar información si ésta prevendrá un daño ya sea al cliente o a algún tercero que esté en peligro. Un caso ilustrativo sería la situación donde un cliente detalla un plan para cometer un suicidio o un homicidio. En tal caso, el psicólogo estaría obligado desde el punto de vista ético y legal a emprender una acción razonable para prevenir este suceso. Aquí, la preservación de la vida sería considerada como un objetivo más importante que la ocultación de información privilegiada.

Un mal juicio por parte del profesional clínico respecto a la revelación de comunicación confidencial puede conducir a un proceso judicial o a algo peor. Un caso muy sonado en los tribunales en 1974 fue el de *Tarasoff contra los regentes de la Universidad de California*. En ese caso, un paciente que asistía a terapia le había hecho saber a su psicólogo su intención de matar a una chica cuyo nombre no reveló, pero a quien se le podía localizar con facilidad dos meses antes del asesinato. La corte determinó que “el privilegio de protección termina donde comienza el peligro público”, por tanto, el terapeuta tenía el deber de advertirle a la chica acerca de aquel peligro. El personal clínico tiene el deber de advertirle a terceras personas que se encuentren en peligro, no sólo de una violencia potencial, sino también de una posible infección de sida por parte de un cliente VIH positivo (Buckner & Firestone, 2000; Melchert y Patterson, 1999).

Los usuarios de las pruebas deben tomar precauciones razonables para salvaguardar los registros de las pruebas. Si estos datos están guardados en un archivero, éstos deben estar bajo llave y de preferencia el archivero debe estar hecho de acero. Si tales datos están almacenados en una computadora, deben ponerse contraseñas para asegurar que se entre sólo con acceso autorizado. Es preciso mencionar aquí que no es una buena idea que individuos o instituciones almacenen registros de una manera perpetua. En vez de eso, el individuo o la institución debe tener una política razonable que incluya: 1) el almacenaje de los resultados obtenidos —cuando estos registros serán desechados, invalidados o utilizados sólo desde un punto de vista académico— y 2) cuando se cumplan las condiciones bajo las cuales se podrán liberar o revelar los registros a una tercera parte involucrada.

Relevante a la liberación de información relacionada con la evaluación está el Decreto de 1996 sobre la portabilidad y responsabilidad del seguro de salud (HIPAA, por sus siglas en inglés) que tomó efecto en abril de 2003. Estas normas de privacidad federal limitaron las formas en que promotores del cuidado de la salud, los planes de salud, las farmacias y los hospitales pueden utilizar la información médica personal de sus paciente. Por ejemplo, la información relacionada con la salud personal no debe ser utilizada para propósitos no relacionados con el cuidado de la salud.

En parte debido a la decisión de la Suprema Corte de Estados Unidos en el caso de *Jaffee contra Redmon* (1996), la HIPAA obtuvo “notas de psicoterapia”, puesto que requería de más protección que la ofrecida por otros registros. La decisión en *Jaffee* afirmó que las comunicaciones entre un psicoterapeuta y un paciente eran privilegiadas en cortes federales. La regla de privacidad de HIPAA citó a *Jaffee* y definió notas de privacidad como las “notas registradas (por cualquier medio) por un proveedor del cuidado médico que sea un profesional de la salud mental que documenta o analiza el contenido de la conversación durante una sesión de asesoramiento privada, de grupo, conjunta o familiar que deben ser separadas del resto del expediente médico del individuo”. Aunque los “resultados de pruebas clínicas” fueron *excluidos* específicamente en esta definición, advertiríamos a profesionales de la apreciación que obtuvieran el consentimiento específico de los afectados antes de dar a conocer información relacionada con los mismos. Esto es esencial particularmente con respecto a los datos que se recopilaron usando herramientas de apreciación tales como la entrevista, la observación de comportamiento, y la representación de papeles.

El derecho a la clasificación menos estigmatizadora Las *Normas* aconsejan que siempre deben asignarse las clasificaciones menos estigmatizadoras cuando se reporten los resultados de las pruebas. Para apreciar mejor la necesidad de esta norma, considérese el caso de Jo Ann Iverson.⁵ Jo Ann tenía nueve años de edad y sufría de claustrofobia cuando su madre la llevó a un hospital estatal en Blackfoot, Idaho, para una valoración psicológica. Arden Frandsen, un psicólogo empleado de medio tiempo en el hospital, realizó una valoración de Jo Ann, durante la cual aplicó una prueba de inteligencia Stanford-Binet. En su reporte, Frandsen clasificó a Jo Ann como “débil mental, en el nivel de imbecilidad de alto grado de capacidad mental general”. Tras una solicitud del orientador vocacional de la escuela de Jo Ann, fue enviada una copia del reporte psicológico a la escuela, y comenzaron a circular rumores embarazosos respecto a la condición mental de Jo Ann.

La madre de Jo Ann, Carmel Iverson, presentó una demanda por calumnias (difamación) contra Frandsen a nombre de su hija.⁶ La señora Iverson perdió la demanda, dictaminando el tribunal en parte que, la valoración psicológica “era un reporte profesional hecho por un servidor público de buena fe, representando su mejor juicio”. Pero aunque la señora Iverson no triunfó en su demanda, de seguro podemos simpatizar con su angustia ante la idea de que su hija iría por la vida con una denominación como “imbécil en alto grado”, esto a pesar del hecho de que es probable que el psicólogo sólo haya copiado esta designación del manual de la prueba. Se podría agregar también que, en retrospectiva, podría haberse ganado una demanda contra el orientador vocacional por violar la confidencialidad, ya que al parecer había testimonios incuestionables de que fue de la oficina del orientador de donde surgieron los rumores respecto a Jo Ann.

En materia de los derechos de quienes resuelven las pruebas, es decir, de los evaluados, es importante no olvidarse de sus derechos. Después de conocer varios aspectos acerca de la tarea de la evaluación, usted tiene el derecho de aprender más acerca de los aspectos técnicos de la medición. Ejerza ese derecho en los siguientes capítulos.

Autoevaluación

Pruebe su entendimiento de los elementos de este capítulo, viendo si es capaz de explicar cada uno de los siguientes términos, expresiones, abreviaciones, sucesos o nombres en términos de su significado en el contexto de pruebas y evaluación psicológicas:

acción afirmativa	confidencialidad	<i>Griggs v. Duke Power Company</i>
<i>Albemarle Paper Company v. Moody</i>	consentimiento informado	información privilegiada
asesino a sueldo	cultura	HIPAA
Autoevaluación	Darwin, Charles	<i>Hobson v. Hansen</i>
Binet, Alfred	<i>Debra P. v. Turlington</i>	<i>Jaffee v. Redmond</i>
Cattell, James McKeen	derecho a la privacidad	<i>Larry P. v. Riles</i>
<i>Code of Fair Testing Practices in Education</i> ; <i>Código de Prácticas de Pruebas Justas en la Educación</i>	ética	legislación sobre la verdad en las pruebas
código de ética profesional	eugenesia	ley pública
	Galton, Francis	leyes
	Goddard, Henry H.	

5. Véase *Iverson vs. Frandsen*, 237 F. 2d 898 (Idaho, 1956) o Cohen (1979, pp. 149-150).

6. Un aspecto interesante aunque tangencial de este caso fue el argumento expuesto por Iverson de que “ella había llevado a su hija a consulta por claustrofobia y que, dado este hecho, la administración de una prueba de inteligencia no estaba autorizada y se encontraba fuera del alcance de la consulta”. Sin embargo, el demandado probó a satisfacción del tribunal que la administración de la Stanford-Binet era necesaria para determinar si Jo Ann tenía la capacidad mental para responder a la psicoterapia.

Morgan, Cristiana D.
Murray, Henry A.
ODDA
Pearson, Karl
primera guerra mundial
programas de pruebas de competen-
cia mínima

prueba de informe personal
prueba proyectiva
pruebas específicas para una cultura
psicoanálisis
Rorschach, Hermann
segunda guerra mundial
sistema de cuotas

Sputnik
Tarasoff v. Regentes de California
Wechsler, David
Witmer, Lightner
Woodworth, Robert S.
Wundt, Wilhelm Max

Un vistazo a la red

Revise los siguientes sitios web para más información sobre temas de este capítulo:

Affirmative Action
www.affirmativeaction.org

Eugenics
[www.pbs.org/wgbh/aso/databank/entries/
dh23eu.html](http://www.pbs.org/wgbh/aso/databank/entries/dh23eu.html)

HIPAA
www.hhs.gov/ocr/hipaa
www.hhs.gov/ocr/hipaa/privacy.html
www.hipaa.com

Un repaso de estadística

Desde el primer número con tinta roja encerrado en un círculo en la parte superior de su primera prueba de ortografía hasta la impresión por computadora de sus resultados del examen de admisión a la universidad, se ha encontrado con pruebas y calificaciones durante su vida. Éstas parecen salir del papel y estrechar su mano cuando lo hace bien y son como un puñetazo cuando falla. Pueden guiarlo o alejarlo de alguna escuela o plan de estudios en particular. Pueden ayudarlo a identificar los puntos fuertes y débiles en sus capacidades físicas y mentales. Pueden acompañarlo a entrevistas laborales e influir en la elección de un empleo o una carrera.

Durante su etapa de estudiante, es probable que haya encontrado que la naturaleza de su relación con las pruebas ha sido sobre todo la de aceptar responderlas. Pero como psicólogo,

SÓLO PIENSE...

Para la mayoría de las personas, las puntuaciones en las pruebas son un hecho importante en la vida. Pero, ¿qué hace tan significativos esos números?

maestro, investigador o empleador, podría percatarse de que la naturaleza primordial de su relación con las pruebas es la de evaluador, la persona que le da vida y significado a las calificaciones de la prueba cuando aplica su conocimiento y habilidad para interpretarlas de manera apropiada. Puede ser que el lector algún día elabore una prueba, ya sea en un contexto académico o de negocios, y entonces tendrá la responsabilidad de calificarla e interpretarla. En esa situación, o aún desde la perspectiva del evaluado, es esencial la comprensión de la teoría que subyace al uso de las pruebas y en

los principios de interpretación de sus resultados.

Las puntuaciones de las pruebas con frecuencia se expresan en números, y para describirlos, hacer inferencias y obtener conclusiones de ellos se usan herramientas estadísticas.¹ En este repaso de estadística se incluyen escalas de medición, representaciones de datos a través de tablas y gráficas, medidas de tendencia central, correlación y regresión, medidas de variabilidad (o dispersión) y puntuaciones estándar. Si estos términos relacionados con la estadística le parecen dolorosamente familiares, se apela a su comprensión y se le pide recordar que el sobreaprendizaje es la clave de la retención. Sin embargo, si estos términos le son desconocidos, lo exhortamos a leer un buen texto de estadística elemental e invertir mucho tiempo en su estudio. La revisión breve de conceptos estadísticos que se ofrece en este capítulo está diseñada sólo para complementar un curso introductorio de estadística.

1. Por supuesto, una puntuación de prueba puede ser expresada en otras formas, como con una calificación asignada con letras o una designación de aprobado o reprobado. A menos que se establezca de otra manera, a lo largo de este libro se usarán los términos puntuación de la prueba, datos de la prueba, resultados de la prueba y puntuaciones de la prueba para hacer referencia a descripciones numéricas acerca del desempeño en una prueba.

Escalas de medición

La **medición** es definida de manera formal como el acto de asignar números o símbolos a características de los objetos (personas, eventos o lo que sea) de acuerdo a ciertas reglas. Las reglas usadas al asignar números son lineamientos para representar la magnitud (o alguna otra característica) del objeto que se mide. Un ejemplo de una regla de medición es *asignar el número 30 a todas las longitudes que tienen exactamente el mismo largo que una regla de 30 centímetros*. Una **escala** es un conjunto de números (u otros símbolos) cuyas propiedades modelan propiedades empíricas de los objetos a los que se asignan los números.² Existen varios tipos de escalas.

Una forma de asignar una categoría a una escala es de acuerdo al tipo de variable que se mide. Por tanto, a una escala utilizada para medir una variable continua la podríamos categorizar como una *escala continua*, mientras que una escala usada para medir una variable discreta la podemos denominar *escala discreta*. Si, por ejemplo, dos sujetos a investigar fueran a clasificarse como mujer u hombre, se diría que la escala de clasificación es de naturaleza discreta debido a que no sería significativo clasificar a un sujeto como algo más que hombre o mujer.³ Por el contrario, existe una escala continua cuando es posible desde el punto de vista teórico dividir cualquiera de los valores de la escala. Debe hacerse una distinción, sin embargo, entre lo que es posible en lo teórico y lo que es deseable en lo práctico; de hecho, las unidades en las que se divide una escala continua pueden depender del propósito de la medición y de su practicidad. Por ejemplo, en las mediciones para instalar persianas venecianas es posible, desde el punto de vista teórico, medir en milímetros o incluso en micrómetros; pero, ¿es necesaria tanta precisión? La mayoría de los instaladores realizan bien el trabajo con mediciones en pulgadas.

La medición siempre implica **error**. En el lenguaje de la evaluación, el error se refiere a la influencia total de los factores en la calificación de una prueba, o en cualquier medición, más allá de los que se miden en forma específica por esta prueba o medición. Como se verá, existen muchas fuentes de error en la medición. Por ejemplo, considere la puntuación que alguien obtuvo en una prueba sobre historia de Estados Unidos. Se podría concebir que una parte de la calificación refleja el conocimiento de esa persona acerca de la historia del país en cuestión, y que otra refleja el error. La parte de error en la calificación de la prueba puede deberse a muchos factores diferentes. Una fuente de error bien puede haber sido la distracción ocasionada por una tormenta eléctrica que ocurría en el momento en que se efectuaba la prueba. Otra fuente de error es la selección particular de las preguntas que el instructor utilizó en la prueba; si se hubiera cambiado alguna o más de ellas, la calificación del evaluado podría haber sido más alta o más baja.

SÓLO PIENSE...

Quizá la *escala* con la que más estamos familiarizados es con la escala de la báscula del baño. ¿En qué se parecen esta escala y la escala de una prueba psicológica? ¿En qué son diferentes? Su respuesta puede cambiar conforme lea este capítulo y los siguientes.

SÓLO PIENSE...

Asuma el papel de un creador de pruebas. Ahora, redacte algunas instrucciones para los usuarios de su prueba, diseñada para reducir al mínimo absoluto el error asociado con las puntuaciones en las pruebas. Asegúrese de incluir instrucciones relativas a la preparación del sitio en el que será administrada la prueba.

2. David L. Streiner reflexionó recientemente: “Se han usado muchos términos para describir una colección de reactivos o preguntas —*escala, prueba, cuestionario, lista de indicadores (index), inventario* y otros— sin consistencia de un autor a otro” (2003a, p. 217, énfasis en el original.) Streiner propuso referirse a los cuestionarios con preguntas parecidas en teoría o relacionadas como escalas; y a los reactivos no relacionados, en teoría, como listas de indicadores (*index*). Fácilmente reconoció que, como se sostiene hasta ahora, se pueden encontrar con facilidad ejemplos contrarios para cada término.

3. Reconocemos que si todas las mujeres fueran denominadas “1” y todos los hombres fueran denominados “2”, algunas personas —por ejemplo los individuos nacidos con una anomalía genética relacionada con el género— podrían parecer que califican como 1.5. Sin embargo, aparte de tales excepciones, todos los casos en una escala discreta deben encontrarse en un punto en la escala, y es imposible desde el punto de vista teórico que un caso se encuentre entre dos puntos de la escala.

El error es en gran medida un elemento de todas las mediciones. Y es un componente que debe ser tomado en cuenta por cualquier teoría de medición.

Las mediciones que utilizan escalas continuas siempre implican error. Para ejemplificar por qué, considere el escenario de la colocación de persianas venecianas. El largo de una ventana que se deseaba fuera de 35.5 pulgadas, podría medir en realidad 35.7 pulgadas. La escala de medición está marcada de manera conveniente en gradaciones de medición más gruesas. La mayoría de las escalas usadas en las pruebas psicológicas son de naturaleza continua y por consiguiente puede esperarse que contengan error. El número o puntuación usada para caracterizar el rasgo que se mide en una escala continua debería considerarse como una aproximación al número “real”. Así, por ejemplo, una puntuación de 25 en alguna prueba de ansiedad no debería considerarse como una medida precisa de la ansiedad, sino más bien como una aproximación a la puntuación de ansiedad real que se habría obtenido si el instrumento de medición se hubiera calibrado para producir dicha puntuación. En tal caso, quizá la puntuación de 25 sea una aproximación a una puntuación real de 24.7 o 25.44.

Por lo general, se ha convenido en que hay cuatro niveles diferentes o escalas de medición. Los números en diferentes niveles o escalas de medición transmiten diferentes clases de información. En las pruebas y en la investigación en general, es importante saber cuáles escalas de medición se emplean, puesto que la clase de escala será un factor en la determinación de cuáles manipulaciones estadísticas de los datos serán apropiadas o no.⁴

La palabra francesa para negro es *noir* (se pronuncia “nuar”). Se menciona aquí esto sólo para llamar la atención al hecho de que esta palabra es un acrónimo y un recurso mnemotécnico útil para recordar los nombres de los cuatro niveles o escalas de medición; cada letra de *noir* es la primera letra de cada uno de los niveles más rigurosos en forma sucesiva. La *n* significa *escala nominal*, la *o* *ordinal*, la *i* de *intervalo* y la *r* de *razón*.

Escalas nominales

Las **escalas nominales** son la forma más simple de medición. Estas escalas implican la clasificación o asignación de categorías basada en una o más características distintivas donde deben colocarse todos los objetos medidos en categorías mutuamente excluyentes y exhaustivas. Por ejemplo, las personas pueden ser caracterizadas por género en un estudio diseñado para comparar el desempeño de hombres y mujeres en alguna prueba específica. En un estudio así todos los hombres podrían ser denominados “hombres”, “1”, “B” o algún otro símbolo, y todas las mujeres podrían denominarse “mujeres”, “2” o “A”. En el área de especialidad de la psicología clínica, una escala nominal usada a menudo es el *Manual diagnóstico y estadístico de trastornos mentales IV* (*Diagnostic and Statistical Manual of Mental Disorders IV*; [DSM-IV]). A cada trastorno enumerado en el manual se le asigna su propio número. Así, por ejemplo, el número 303.00 identifica la intoxicación con alcohol y el número 307.00 designa el tartamudeo. Pero estos números son usados de manera exclusiva con propósitos de clasificación y no pueden sumarse, restarse, jerarquizarse o promediarse de manera significativa (el número 305 *no* es igual a un tartamudo intoxicado o viceversa).

Algunas preguntas individuales también pueden emplear escalas nominales. Los reactivos encontrados en una solicitud de empleo son ejemplos comunes:

Instrucciones: Responda *sí* o *no*.

¿Está usted contemplando el suicidio en forma activa? _____

4. Para los propósitos de este repaso sobre estadística, presentamos lo que Nunnally (1978) llamó la perspectiva “fundamentalista” de las escalas de medición; una perspectiva que “sostiene que 1) hay distintos tipos de escalas de medición en las que pueden clasificarse todas las medidas posibles de atributos, 2) cada medida tiene algunas características ‘reales’ que permiten su clasificación apropiada, y 3) una vez que una medida es clasificada, la clasificación especifica los tipos de análisis matemáticos que pueden emplearse con la medida” (p. 24). Nunnally y otros han afirmado que también pueden ser viables alternativas a la perspectiva “fundamentalista”.

¿En la actualidad, está bajo atención profesional por algún trastorno psiquiátrico? _____

¿Alguna vez ha sido condenado por un delito grave? _____

En cada caso, una respuesta *sí* o *no* resulta en su inclusión en alguno de los conjuntos de grupos mutuamente excluyentes: suicida o no, bajo atención por un trastorno psiquiátrico o no, y criminal o no. Las operaciones aritméticas que se pueden realizar en forma legítima con datos nominales incluyen contar con el propósito de determinar cuántos casos caen en cada categoría y alguna determinación consecuente de proporción o porcentajes.⁵

Escalas ordinales

Al igual que las escalas nominales, las **escalas ordinales** permiten la clasificación. Sin embargo, además de la clasificación, con las escalas ordinales también es permisible un ordenamiento por rangos con base en alguna característica. En el campo industrial y de las organizaciones, los solicitantes de empleo pueden ser clasificados en rangos de acuerdo con su conveniencia para un puesto. En el escenario clínico, las personas en lista de espera para psicoterapia pueden ser clasificadas en categorías de acuerdo con su necesidad de tratamiento. En estos ejemplos, los individuos son comparados con otros y se les asigna un rango (quizá 1 para el mejor solicitante o el cliente en lista de espera más necesitado, 2 para el siguiente, etcétera).

Aunque es probable que Alfred Binet, el creador de la prueba de inteligencia que hoy lleva su nombre, nunca haya usado el término *escala ordinal*, estaba convencido de que los datos derivados de una prueba de inteligencia eran ordinales por naturaleza. Binet enfatizaba que lo que trató de hacer en la prueba no fue *medir* a la gente, como se mide la altura de una persona, sino sólo *clasificar* (y ubicar en un rango) a las personas con base en su desempeño en las tareas. Escribió:

No he buscado... diseñar un método de medición, en el sentido físico de la palabra, sino sólo un método de clasificación de individuos. Los procedimientos que he indicado llegarán, si se perfeccionan, a clasificar a ninguna persona antes o después de otra persona, o una serie de personas; pero no creo que sea posible medir una de las aptitudes intelectuales en el sentido en que se mide una longitud o una capacidad. Así, cuando una persona examinada puede retener siete cifras después de escucharlas una sola vez, se le puede clasificar, desde el punto de vista de su memoria para las cifras, después del individuo que retiene ocho cifras bajo las mismas condiciones, y antes de aquellos que retienen seis. Es una clasificación, no una medición... no medimos, clasificamos (Binet, citado en Varon, 1936, p. 41).

Los instrumentos de evaluación aplicados al sujeto individual también pueden usar una forma ordinal de medición. La *Encuesta de valores de Rokeach* (Rokeach Value Survey) usa un enfoque así con quienes aceptan responder la prueba al colocar una lista de valores personales (como libertad, felicidad y sabiduría) en orden de acuerdo con la importancia percibida por quien responde la prueba (Rokeach, 1973). Si una serie de diez valores es ordenada en rangos, quien responde la prueba puede asignar un valor de “1” al más importante y “10” al menos importante.

Las escalas ordinales no implican nada respecto a cuánto más grande es una categoría que otra. Aun cuando las escalas ordinales generalmente emplean números o “puntajes” para representar el ordenamiento de las categorías, los números no indican unidades de medición. Así, por ejemplo, la diferencia entre el mejor solicitante y el segundo puede ser muy pequeña, pero puede haber una gran diferencia entre ellos y un tercero. Del mismo modo, una persona que completa la Encuesta de valores de Rokeach puede ser capaz de identificar con facilidad la característica clasificada con “1” como el valor más importante, sin embargo, ordenar los siguientes valores puede dificultársele hasta el punto de ser casi arbitrario.

5. Existen otras formas de analizar datos nominales (Gokhale y Kullback, 1978; Kranzler y Moursund, 1999). Sin embargo, esos métodos van más allá del alcance de este libro.

Las escalas ordinales no tienen un punto cero absoluto. En el caso de una prueba de capacidad de desempeño en el trabajo, para cualquier evaluado, sin importar su resultado en la prueba, se asume que tiene alguna capacidad. Se supone que ningún evaluado tiene capacidad cero. El cero carece de significado en esta prueba porque el número de unidades que separa la calificación de un evaluado de la de otro simplemente no se conoce. Las calificaciones se ordenan por rango, pero la cantidad real de unidades que separa una calificación de la siguiente podrían ser muchas, unas cuantas o prácticamente ninguna. Debido a que en las escalas ordinales no hay un punto cero, las formas en que pueden tratarse los datos de estas escalas desde el punto de vista estadístico son limitadas. No es posible promediar las calificaciones de los solicitantes de empleo clasificados en los lugares primero y tercero, por ejemplo, y esperar la obtención de las calificaciones del solicitante clasificado en segundo lugar.

Escalas de intervalo

Además de las características de las escalas nominales y ordinales, las **escalas de intervalo** contienen intervalos iguales entre números; cada unidad en la escala es exactamente igual a cualquier otra unidad en la escala. Pero, al igual que las escalas ordinales, las escalas de intervalo no contienen un punto cero absoluto. Con las escalas de intervalo se ha llegado a un nivel de medición en el que es posible obtener el promedio de un conjunto de mediciones y obtener un resultado significativo.

Las puntuaciones en muchas pruebas tales como las de inteligencia son analizadas de manera estadística en formas adecuadas para datos en el nivel de medición de intervalo. La diferencia entre la capacidad intelectual representada por un CI de 80 y uno de 100, por ejemplo, se considera parecida a la existente entre los CI de 100 y 120. Sin embargo, si un individuo obtuviera un CI de 0 (algo que no es siquiera posible debido a la manera en que se estructura la mayoría de las pruebas de inteligencia), esto no significaría una inteligencia cero (ausencia total de la misma). Como las escalas de intervalo no contienen un punto cero absoluto, una suposición inherente en su utilización es que ningún evaluado posee cero capacidad o cualidad (o cualquier característica) que se mida.

Escalas de razón

Además de tener las mismas propiedades de las escalas nominales, ordinales y de intervalo, la **escala de razón** tiene un punto cero verdadero. Todas las operaciones matemáticas pueden realizarse de manera significativa en este tipo de escala porque existen intervalos iguales entre los números en ella, así como un punto cero verdadero o absoluto.

En psicología, la medición en el nivel de razón se emplea en algunos tipos de prueba y reactivos, quizá de manera más notable en aquellas que tienen que ver con la evaluación del funcionamiento neurológico. Un ejemplo es la prueba de la presión del apretón de una mano, en el cual la variable medida es la cantidad de presión que alguien puede ejercer con una extremidad (véase la figura 3-1). Otro ejemplo es una prueba de la capacidad perceptomotriz, cronometrada, la cual requiere que el evaluado ensamble un rompecabezas. En esta situación, el tiempo requerido para completar de manera exitosa el rompecabezas es la medida que se registra. Como en esta escala hay un cero absoluto (esto es, 0 segundos), es útil decir que un evaluado que completó el rompecabezas en 30 segundos requirió la mitad del tiempo que un evaluado que tardó 60 segundos en realizar la misma actividad. En este ejemplo, es posible hablar de manera significativa de un punto cero real en la escala, pero sólo en teoría. ¿Por qué? *Sólo piense...*

Ningún evaluado podría obtener una puntuación de 0 en esta tarea de ensamblaje. Dicho de otra manera, ningún evaluado, ni siquiera Flash (un superhéroe de historietas cuyo superpoder es la habilidad de moverse a velocidad sobrehumana) podría ensamblar el rompecabezas en 0 segundos.

Escalas de medición en psicología

El nivel ordinal de medición es el que se usa con mayor frecuencia en psicología. Como lo señaló Kerlinger (1973, p. 439): “Las puntuaciones de las pruebas de inteligencia, aptitud y personalidad




Figura 3-1
Medición del nivel de razón en la palma de la mano

En la figura se muestra un dinamómetro, instrumento que se usa para medir la fuerza del apretón de una mano. Se le pide al evaluado que apriete la empuñadura tan fuerte como sea posible. El apretón ocasiona que la aguja se mueva en la escala, indicando la cantidad de libras de presión ejercida. El punto más alto alcanzado por la aguja es la puntuación. Esta medida emplea la medición del nivel de razón. Alguien que pueda ejercer 10 libras de presión (y obtenga una puntuación de 10) habrá realizado el doble de presión que alguien que sólo ejerza 5 libras de presión (y haya obtenido una puntuación de 5). En esta prueba es posible lograr una puntuación de cero, lo cual indica una ausencia total de presión ejercida. Pero en tanto sea significativo hablar de una puntuación cero en esta prueba, desearíamos conocer el significado de este resultado. ¿Tal puntuación es indicativa de una incapacidad total para ejercer presión con la mano? Cabría esperar esta puntuación de un evaluado que sufriese de alguna condición incapacitante como parálisis de la mano. De manera alternativa, ¿una puntuación cero será indicativa de algo más, de una disposición nula para cooperar con el examinador, de fingirse enfermo o de mentir en la prueba? Las escalas de razón pueden proporcionar números “sólidos” para trabajar con ellos, pero los evaluadores deben realizar los cálculos matemáticos antes de obtener conclusiones.

son, hablando en forma básica y estricta, ordinales. Indican con más o menos precisión no la cantidad de inteligencia, aptitud y rasgos de personalidad de los individuos, sino más bien las posiciones ordenadas en categorías de los individuos.” Kerlinger admitía que “la mayoría de las escalas psicológicas y educativas se aproximan bastante a un nivel de intervalo”, aunque advertía que si las mediciones ordinales eran tratadas como si fueran mediciones de intervalo, el usuario de la prueba debía “estar alerta en forma constante ante la posibilidad de una desigualdad gruesa de los intervalos” (pp. 440-441).

¿Por qué desearían los psicólogos tratar sus datos de evaluación como de intervalo cuando esos datos se describen mejor como ordinales? ¿Por qué no sólo decir que son ordinales? El atractivo de la medición de intervalo para los usuarios de pruebas psicológicas se encuentra en

Tabla 3-1
Datos de la prueba de su clase de medición

Estudiante	Puntuación (número de aciertos)
Jude	78
Joe	67
Lee-Wu	69
Miriam	63
Valerie	85
Diane	72
Henry	92
Esperanza	67
Paula	94
Martha	62
Bill	61
Homer	44
Robert	66
Michael	87
Jorge	76
Mary	83
"Mousey"	42
Barbara	82
John	84
Donna	51
Uriah	69
Leroy	61
Ronald	96
Vinnie	73
Bianca	79

la flexibilidad con que estos datos pueden ser manejados en forma estadística. El lector se podrá preguntar de qué tipo de manejo estadístico se trata.

En este capítulo se revisan las diferentes formas en que los datos de las pruebas pueden describirse o transformarse para hacer dichos datos más manejables y comprensibles. Algunas de las técnicas que se describirán, como el cálculo de un promedio, pueden usarse si los datos pertenecen a los niveles de intervalo o de razón, pero no si son ordinales o nominales. Otras técnicas, como aquellas que implican la creación de gráficas o tablas, se pueden emplear con datos del nivel ordinal o incluso del nominal.

Descripción de los datos

Suponga que por arte de magia ha cambiado de lugar con el profesor que enseña este curso y que acaba de aplicar un examen que consta de 100 reactivos de opción múltiple (donde se concede un punto por cada respuesta correcta). La distribución de las puntuaciones para los 25 estudiantes inscritos en su clase podría oscilar en un rango teórico de 0 (ninguna correcta) a 100 (todas correctas). Una **distribución** se puede definir como un conjunto de puntuaciones de prueba ordenadas para su registro o estudio. Las 25 puntuaciones en esta distribución son llamadas *puntuaciones crudas*. Como lo implica su nombre, una **puntuación cruda** es una cuantificación directa del desempeño, sin modificaciones, usualmente numérica. Una puntuación cruda puede reflejar una simple cuenta, como el *número de reactivos respondidos en forma correcta en una prueba de resultados*. Como se verá después en este capítulo, las puntuaciones crudas se pueden convertir en otro tipo de puntuaciones. Por ahora, suponga que es el día posterior al examen y se encuentra usted sentado en su oficina con los datos enumerados en la tabla 3-1. ¿Qué haría en seguida?

Tabla 3-2
Distribución de frecuencia de las puntuaciones
de su prueba

Puntuación	f (frecuencia)
96	1
94	1
92	1
87	1
85	1
84	1
83	1
82	1
79	1
78	1
76	1
73	1
72	1
69	2
67	2
66	1
63	1
62	1
61	2
51	1
44	1
42	1

Una tarea inmediata sería comunicar los resultados de la prueba a su clase. Usted desearía hacerlo de forma que ayude a cada estudiante a comprender su desempeño en la prueba comparado con el de los demás. Quizá, el primer paso sea organizar los datos, transformándolos de un listado aleatorio de puntuaciones crudas en algo que de inmediato proporcione un poco más de información. Después, como se verá, podría ser deseable transformar los datos de otras maneras.

Distribuciones de frecuencia

Los datos de la prueba se pueden organizar en una distribución de las puntuaciones crudas. Una forma en que podrían distribuirse es por la frecuencia con que ocurren. En una **distribución de frecuencia**, todas las puntuaciones se enlistan al lado del número de veces que ocurrió cada puntuación. Las puntuaciones podrían enlistarse en forma tabular o gráfica. En la tabla 3-2 se enlista la frecuencia de ocurrencia de cada puntuación en una columna y la puntuación en sí en la otra columna.

A menudo, se hace referencia a esta distribución de frecuencia como una *distribución de frecuencia simple* para indicar que se han empleado puntuaciones individuales y que los datos no se han agrupado. Otro tipo de distribución de frecuencia empleada para resumir datos es la *distribución de frecuencia agrupada*. En una **distribución de frecuencia agrupada**, los intervalos de las puntuaciones de prueba, también llamados *intervalos de clase*, reemplazan a las puntuaciones de prueba reales. El número de intervalos de clase usados y el tamaño o *amplitud* de cada uno de ellos (es decir, el rango de las puntuaciones de prueba contenidas en cada intervalo) es una decisión que el usuario de la prueba tiene que tomar. Pero ¿cómo?

En la mayor parte de los casos, la decisión en cuanto al tamaño de un intervalo de clase en una distribución de frecuencia agrupada se toma con base en la conveniencia y con el conocimiento de que casi cualquier decisión representará un trueque. Un resumen conveniente de los datos, fácil de leer, implica la pérdida de detalles. ¿Hasta qué grado deben resumirse los datos? ¿Qué tan importante es el detalle? Estos tipos de preguntas deben tenerse en consideración. En la

Tabla 3-3
Distribución de frecuencia agrupada

Intervalo de clase	f (frecuencia)
95-99	1
90-94	2
85-89	2
80-84	3
75-79	3
70-74	2
65-69	5
60-64	4
55-59	0
50-54	1
45-49	0
40-44	2


distribución de frecuencia agrupada de la tabla 3-3 las puntuaciones de prueba han sido agrupadas en 12 intervalos, donde cada uno de ellos es igual a cinco puntos.⁶ El intervalo más alto (95 a 99) y el intervalo más bajo (40 a 44) se denominan respectivamente los límites superior e inferior de la distribución. Aquí, la necesidad de facilidad en la lectura de los datos es mayor que la necesidad de muchos detalles, de forma que los agrupamientos de datos parecen lógicos.

Las distribuciones de frecuencia de las puntuaciones de prueba también pueden ilustrarse en forma gráfica. Una **gráfica** es un diagrama o esquema compuesto de líneas, puntos, barras u otros símbolos que describen e ilustran los datos. Con una buena gráfica, la ubicación de una sola puntuación con relación a la distribución de las puntuaciones de prueba puede captarse con facilidad. Tres clases de gráficas usadas para ilustrar distribuciones de frecuencia son el histograma, la gráfica de barras y el polígono de frecuencia (figura 3-2). Un **histograma** es una gráfica con líneas verticales trazadas en los límites verdaderos de cada puntuación de prueba (o intervalo de clase) que forma una serie de rectángulos contiguos. Es usual colocar las puntuaciones de la prueba (ya sea sólo las puntuaciones o los puntos medios de los intervalos de clase) a lo largo del eje horizontal de la gráfica (también conocido como *abscisa* o eje X) y los números que indican la frecuencia de ocurrencia se colocan a lo largo del eje vertical de la gráfica (también denominado *ordenada* o eje Y). En una **gráfica de barras**, los números que indican frecuencia también aparecen en el eje Y, y la referencia a alguna categorización (sí/no/tal vez, hombre/mujer, etcétera) aparecen en el eje X; aquí, por lo general, las barras rectangulares no son contiguas. Los datos ilustrados en un **polígono de frecuencia** se expresan por medio de una línea continua que conecta los puntos donde se intersecan las puntuaciones de prueba o los intervalos de clase (indicados en el eje X) con las frecuencias (indicadas en el eje Y).


Las representaciones gráficas de las distribuciones de frecuencia pueden asumir cualquiera de varias formas diferentes (figura 3-3). Sin importar la forma de los datos graficados, para el usuario de la información contenida en la gráfica resulta una buena idea examinarla con cuidado, y si se requiere, de manera crítica. Considere en este contexto la sección *Psicometría cotidiana*.

Como se expone con mayor detalle más adelante en este capítulo, una representación gráfica de datos es de particular interés para los profesionales en medición: la *curva normal* o en *forma de campana*. Pero, antes de llegar a esto regresemos al tema de las distribuciones: cómo pueden describirse y caracterizarse. Una manera de describir una distribución de puntuaciones de pruebas es mediante una medida de tendencia central.

6. Desde el punto de vista técnico, cada número en una escala de este tipo ocuparía un rango desde 0.5 por debajo de él, hasta 0.5 por arriba de él. Por ejemplo, la amplitud “verdadera” pero hipotética del intervalo de clase que va de 95 a 99 sería la diferencia entre 99.5 y 94.5, o sea, 5. Los límites reales superior e inferior de los intervalos de clase respectivos presentados en la tabla deberían ser 99.5 y 39.5.



a)




b)

Figura 3-2
Gráficas de datos de la tabla 3-3

Un histograma a), una gráfica de barras b) y un polígono de frecuencia c), todas pueden usarse para comunicar información en forma gráfica sobre la ejecución de la prueba. Por supuesto, la denominación de la gráfica de barras y la naturaleza específica de los datos transmitidos por ella dependen de las variables de interés; en b) la variable de interés es el número de estudiantes que aprobaron la prueba (se supone, para el propósito de esta ilustración, que una puntuación cruda de 65 o más había sido designada por adelantado, de manera arbitraria, como una calificación aprobatoria).

De regreso a la pregunta planteada con anterioridad, aquella en la que usted representa el papel de instructor y debe comunicar los resultados de la prueba a sus estudiantes, ¿qué tipo de gráfica serviría mejor para su propósito? ¿Por qué?

En tanto continuamos con la revisión de la estadística descriptiva, tal vez quiera regresar a su papel de profesor y formular su respuesta a desafiantes preguntas relacionadas, como “¿Cuál o cuáles medidas de tendencia central usaría para transmitir esta información?” y “¿Cuál o cuáles medidas de variabilidad transmitirían mejor la información?”



c)




Figura 3-3
Formas que pueden adoptar las distribuciones de frecuencia

¡Alerta, consumidor (de datos gráficos)!

Una imagen vale más que mil palabras, y uno de los propósitos de representar datos en forma gráfica es transmitir información de un solo vistazo. Sin embargo, aunque dos gráficas pueden ser precisas con respecto a los datos que representan, sus imágenes —y la impresión que dejan luego de verlas— pueden ser muy diferentes. Como ejemplo, considérese el siguiente caso hipotético, la cadena de restaurantes de hamburguesas llamada “La casa chamuscada”.


En esta cadena se sirven hamburguesas demasiado asadas al carbón, microscópicamente delgadas, con forma de pequeñas casas triangulares. En un periodo de 10 años, desde que se fundó en 1993, la compañía ha vendido, en promedio, 100 millones de hamburguesas por año. En su décimo aniversario esta compañía distribuye un boletín de prensa anunciando con orgullo: “Más de mil millones servidas”.

Los reporteros de dos publicaciones de negocios se deciden a investigar y escribir un artículo sobre esta empresa. Con base sólo en las cifras de ventas recopiladas de los reportes anuales a los accionistas, el reportero 1 enfoca su historia en las diferencias en las ventas anuales. Su artículo se titula “Mil millones servidas, pero las ventas de ‘La casa chamuscada’ fluctúan de un año a otro”, y su ilustración gráfica se reimprime aquí.


Un panorama bastante diferente de la compañía surge de la historia del reportero 2, titulada “Mil millones servidas, y las ventas de ‘La casa chamuscada’ son más estables que nunca”, gráfica anexa. Esta última historia se basa en un análisis diligente de datos comparables para la misma cantidad de cadenas de restaurantes de hamburguesas en las mismas áreas del país durante el mismo periodo. Mientras investigaba la historia, el reportero 2 aprendió que las fluctuaciones anuales en las ventas son comunes en la industria entera y que las fluctuaciones anuales observadas en las cifras de “La casa chamuscada” eran insignificantes en relación a otras cadenas.

Compare las gráficas que acompañan a cada historia. Aunque ambos son precisos en la medida en que se basan en cifras correctas, la impresión que nos dejan es probable que sea totalmente distinta.

A propósito, la costumbre dicta que en una gráfica la intersección de los dos ejes sea en 0 y que todos los puntos sobre el eje Y se distribuyan en intervalos iguales y proporcionales a partir de cero. Esta costumbre es seguida por la historia del reportero 2, donde el primer punto sobre la ordenada está en 10 unidades más que 0, y cada punto sucesivo también se aleja diez puntos más de 0. Sin embargo, la costumbre no



a) Ventas de “La casa chamuscada” en un periodo de diez años



b) Ventas de “La casa chamuscada” en un periodo de diez años

es respetada en la historia del reportero 1, donde el primer punto sobre la ordenada está en 95 unidades más que cero, y cada punto sucesivo aumenta sólo 1 punto. El hecho de que la costumbre no haya sido respetada en la gráfica que acompaña a la historia del reportero 1, debería servir como una advertencia para evaluar esta ilustración de los datos en forma más crítica.

Medidas de tendencia central

Una **medida de tendencia central** es un estadístico que indica el promedio o el punto medio entre las puntuaciones extremas de una distribución. El centro de una distribución puede definirse en formas diferentes. Quizá la medida de tendencia central usada de manera más común es la *media aritmética* (o simplemente **media**), conocida en el lenguaje cotidiano como el “promedio”. La media toma en cuenta el tamaño matemático real de cada puntuación. En casos especiales, como cuando sólo hay unas cuantas puntuaciones y una o dos de ellas son extremas en relación con las restantes, puede ser deseable una medida de tendencia central distinta de la media. Otras medidas de tendencia central que se revisarán incluyen la *mediana* y la *moda*. Nótese que en las fórmulas que siguen se usa la abreviatura estadística normal llamada “notación sumatoria” (*sumatoria* significa “la suma de”). La letra griega mayúscula sigma, Σ , es el símbolo usado para significar “suma”; si X representa una puntuación de prueba, entonces el símbolo ΣX significa “sumar todas las puntuaciones de prueba”.

La media aritmética Denotada por el símbolo $\bar{X}$ (que se denota “media”) la **media aritmética** es igual a la suma de las observaciones (o a las puntuaciones de prueba en este caso) dividida entre el número de observaciones. Escrita en forma simbólica, la fórmula para la media aritmética es $\bar{X} = \Sigma X/n$, donde n es igual al número de observaciones o puntuaciones de prueba. Por lo general, la media aritmética es la medida más apropiada de tendencia central para datos de intervalo o razón cuando se cree que las distribuciones son cercanas a la normal. Una media aritmética también puede calcularse a partir de una distribución de frecuencia. La fórmula para hacerlo es

$$\bar{X} = \frac{\Sigma fX}{n}$$

donde ΣfX significa “multiplicar la frecuencia de cada puntuación por su correspondiente puntuación y suma”. También se puede obtener una estimación de la media aritmética a partir de una distribución de frecuencia agrupada usando la misma fórmula, donde X es igual al punto medio de cada intervalo de clase. En la tabla 3-4 se ilustra un cálculo de la media para una distribución de frecuencia agrupada. Realice los cálculos y encontrará que si se utilizan los datos agrupados se obtendrá una media de 71.8 (la cual puede redondearse a 72). Si se utilizan las puntuaciones crudas se calculará una media de 72.12 (la cual también se puede redondear a 72). Con frecuencia, la elección del estadístico dependerá del grado de precisión requerido en la medición.

SÓLO PIENSE...

Imagine que alrededor de mil ingenieros realizaron una prueba extremadamente difícil para solicitar empleo. Un puñado de los ingenieros tuvo puntuaciones muy altas, pero la gran mayoría obtuvo puntuaciones pobres. Dado este escenario, ¿cuáles son los pros y los contras de usar la media como una medida de tendencia central?

La mediana Definida como la puntuación intermedia en una distribución, la **mediana** es otra medida de tendencia central que se usa de manera común. Determine la mediana de una distribución de puntuaciones ordenando éstas de acuerdo a su magnitud en

una lista, ya sea en orden ascendente o descendente. Cuando el número total de puntuaciones ordenadas sea un número impar, la mediana será la puntuación que está exactamente en el centro, de tal forma que la mitad de las puntuaciones restantes estará por encima de ella y la otra mitad de las puntuaciones restantes por debajo. Cuando el número total de puntuaciones ordenadas sea un número par, la mediana puede calcularse al determinar la media aritmética de las dos puntuaciones intermedias. Por ejemplo, supóngase que diez personas respondieron una prueba de procesamiento de palabras cuando solicitaron empleo en la corporación The

Tabla 3-4
Cálculo de la media aritmética en una distribución de frecuencia agrupada

Intervalo de clase	f (frecuencia)	X (punto medio de intervalo de clase)	fX
95-99	1	97	97
90-94	2	92	184
85-89	2	87	174
80-84	3	82	246
75-79	3	77	231
70-74	2	72	144
65-69	5	67	335
60-64	4	62	248
55-59	0	57	000
50-54	1	52	52
45-49	0	47	000
40-44	2	42	84
$\Sigma f = 25$			$\Sigma (fX) = 1795$

Para estimar la media aritmética de esta distribución de frecuencia agrupada,

$$\bar{X} = \frac{\Sigma (fX)}{n} = \frac{1795}{25} = 71.80$$

Para calcular la media de esta distribución a partir de las puntuaciones crudas,

$$\bar{X} = \frac{\Sigma X}{n} = \frac{1803}{25} = 72.12$$

Rochester Wrenchworks (TRW) y obtuvieron las siguientes puntuaciones, presentadas aquí en orden descendente:

66
65
61
59
53
52
41
36
35
32

La mediana en estos datos se puede calcular obteniendo el promedio (es decir, la media aritmética) de las dos puntuaciones intermedias, 53 y 52 (la cual sería igual a 52.5). La mediana es una medida de tendencia central apropiada para datos ordinales, de intervalo y de razón. La mediana puede ser una medida de tendencia central particularmente útil en los casos donde hay relativa-

mente pocas puntuaciones que caen en el extremo más alto de la distribución o pocas puntuaciones en el extremo inferior de la distribución.

Suponga que no fueron diez, sino miles las personas que solicitaron empleo en Rochester Wrenchworks. Sería poco práctico encontrar la mediana por medio de un simple ordenamiento de los datos para después encontrar las puntuaciones en el centro de la distribución. Entonces, ¿cómo identificar la mediana? Para los propósitos de este estudio, la respuesta de manera simple es que existen métodos avanzados para hacerlo. También hay técnicas para identificar la mediana en otros tipos de distribución, como una distribución de frecuencia agrupada y una distribución donde varias puntuaciones son idénticas. Sin embargo, en lugar de irrumpir en este territorio nuevo y complejo, resulta más útil regresar a la exposición de las medidas de tendencia central y considerar otra medida distinta.

La moda Dentro de una distribución de puntuaciones, aquella puntuación que se repite con mayor frecuencia es conocida como **moda**.⁷ Como ejemplo, determine la moda para las siguientes puntuaciones obtenidas por Bruce, otro de los solicitantes para un puesto de procesador de palabras en la corporación TRW. Las puntuaciones indican el número de palabras que Bruce procesó en siete intentos de un minuto cada uno.

43 34 45 51 42 31 51

La política de TRW es que los nuevos contratados deben ser capaces de procesar al menos 50 palabras por minuto. Ahora colóquese en el papel del titular de la oficina de personal. ¿Contrataría a Bruce? La puntuación que aparece con mayor frecuencia en esta distribución de puntuaciones es 51. Si sus lineamientos de contratación le dan la libertad de usar cualquier medida de tendencia central para tomar decisiones sobre las contrataciones, sería su decisión contratarlo o no. Podría contratarlo y justificar esta decisión con base en su puntuación modal (51). Podría no contratarlo y justificar la decisión basado en su puntuación media (por debajo de las 50 palabras por minuto requeridas). En última instancia, si Rochester Wrenchworks será el nuevo segundo hogar para Bruce dependerá de otros factores relacionados con el trabajo, como las condiciones del mercado de trabajo en Rochester y las puntuaciones de los aspirantes competidores. Por supuesto, si los lineamientos de la compañía dictan que sólo se use la puntuación media para tomar las decisiones de contratación, el futuro inmediato de Bruce no incluye una carrera en TRW.

Cuando en una distribución se presentan dos o más “puntuaciones que se repiten con mayor frecuencia”, es decir, que están empatadas, puede esta distribución tener más de una moda. Considérense las siguientes puntuaciones —acomodadas sin ningún orden particular— obtenidas por 20 estudiantes en el examen final de una nueva escuela comercial llamada “Escuela de estudio en casa para imitadores de Elvis Presley”:

51 49 51 50 66 52 53 38 17 66
33 44 73 13 21 91 87 92 47 3

Se dice que la distribución de estas puntuaciones es **bimodal** debido a que contiene dos puntuaciones (51 y 66) que ocurren con la frecuencia más alta (una frecuencia de dos). Con excepción de su uso con datos nominales, la moda tiende a no ser una medida de tendencia central muy usada. A diferencia de la media aritmética, la cual tiene que calcularse, el valor de la puntuación modal no se calcula; sólo se cuenta y se determina qué puntuación ocurre con mayor frecuencia. Debido a la forma en que se llega a la moda, la puntuación modal puede ser una puntuación completamente atípica —una en el extremo final de la distribución— sin embargo, ocurre con mucha frecuencia. De hecho, es posible desde el punto de vista teórico que una distribución bimodal tenga dos modas que caigan una en el extremo superior y otra en el extremo inferior de la distribución, lo que viola la expectativa de que una medida de tendencia central debería indicar un punto en medio de la distribución.

7. Si puntuaciones adyacentes ocurren con igual frecuencia y más a menudo que otras puntuaciones, la costumbre dicta que se haga referencia a la moda como el *promedio*.

Aun cuando la moda no es obtenida a través de un cálculo, tal como se hace en la media, y aun cuando tampoco señala necesariamente un punto único en una distribución (ya que una distribución puede tener dos, tres o incluso más modas), ésta puede ser útil para transmitir cierto tipo de información. La moda es útil en el análisis de materia cualitativa o verbal. Por ejemplo, cuando se evalúa por medio de entrevistas cómo un consumidor recuerda un comercial, un investigador puede estar interesado en la palabra o palabras que hayan sido más utilizadas por los entrevistados.

La moda transmite información útil, *adicional* a la media. Por ejemplo, suponga que desea estimar el número de artículos que fueron publicados el año pasado en Estados Unidos por psicólogos clínicos. Para llegar a esta cifra, se podría obtener el total del número de artículos publicados por cada psicólogo clínico en Estados Unidos, dividir entre el número de psicólogos y llegar a la media aritmética. Con este cálculo se obtendría la indicación del número promedio de artículos publicados. Cualquiera que sea el número, podemos decir con certeza que será más alto que la moda. Es bien sabido que la mayoría de los psicólogos clínicos no suelen publicar artículos en revistas científicas. La moda para las publicaciones de los psicólogos clínicos en cualquier año es cero. En este ejemplo, la media aritmética proporcionaría una medición precisa del número promedio de artículos publicados por los profesionales en psicología clínica. Lo que estaría perdido en esa medida de tendencia central, sin embargo, es el hecho de que, proporcionalmente, muy pocos de los psicólogos clínicos publican la mayoría de los artículos. La moda (en este caso, cero) proporciona información útil a primera vista. Nos dice que, sin importar cuál sea la cifra para el número promedio de publicaciones, la mayoría de los psicólogos clínicos no publica.

Debido a que la moda no se calcula en un sentido verdadero, es una estadística nominal y no podrá usarse de manera legítima en cálculos posteriores. La mediana es una estadística que toma en cuenta el orden de las puntuaciones y es, en sí misma, de naturaleza ordinal. La media es la medida de tendencia central más estable y por lo general la más útil, y es una estadística de intervalo.

SÓLO PIENSE...

Proyecte su propio ejemplo para ilustrar cómo la moda y no la media puede ser la medida de tendencia central más útil.

Medidas de variabilidad

La **variabilidad** es un indicador de la forma en que las puntuaciones en una distribución están esparcidas o dispersas. Como se ilustra en la figura 3-4, dos o más distribuciones de puntuaciones de prueba pueden tener la misma media, aunque las diferencias en la dispersión de las puntuaciones alrededor de la media pueden ser amplias. En ambas distribuciones, A y B, las puntuaciones de prueba podrían variar de 0 a 100. En la distribución A, se observa que la puntuación




Figura 3-4
Dos distribuciones con diferencias en variabilidad

media fue 50 y las puntuaciones restantes estaban distribuidas en forma amplia alrededor de la media. En la distribución B, la media también fue 50, aunque pocas personas, si es que algunas, calificaron con más de 60 o menos de 40.

Medidas de variabilidad (o dispersión) —estadísticas que describen la cantidad de variación en una distribución— incluyen el rango, el rango intercuartilar, el rango semiintercuartilar, la desviación media, la desviación estándar y la varianza.

El rango El **rango** de una distribución es igual a la diferencia entre las puntuaciones mayor y menor. Se podría describir que la distribución *b* de la figura 3-3, por ejemplo, tiene un rango de 20, si se sabe que la puntuación mayor en esta distribución fue 60 y la menor fue 40 ($60 - 40 = 20$).

Con respecto a la distribución *a*, si se sabe que la puntuación menor fue 0 y la puntuación mayor fue 100, el rango sería igual a $100 - 0$ o 100. El rango es la medida de variabilidad más simple de calcular, pero su uso potencial es limitado. Debido a que el rango se basa por completo en el valor de las dos puntuaciones extremas, una puntuación extrema puede alterar de manera radical el valor del rango. Supóngase, por ejemplo, que hubo una puntuación igual a 90 en la distribución *b*. El rango de esta distribución ahora sería igual a $90 - 40$ o 50. Pero al observar los datos en la gráfica para la distribución *b*, es claro que la gran mayoría de las puntuaciones tiende a estar entre 40 y 60.

SÓLO PIENSE...

Planee dos distribuciones de puntuaciones de prueba para ilustrar cómo el rango puede minimizar o sobreestimar el grado de variabilidad en las puntuaciones.

Como una estadística descriptiva de variación, el rango proporciona una descripción rápida pero gruesa de la dispersión de las puntuaciones. Cuando su valor se basa en puntuaciones extremas en una distribución, la descripción resultante de la variación puede minimizarse o exagerarse. Mejores medidas de variación incluyen el rango intercuartilar y el rango semiintercuartilar.

El rango intercuartilar y el rango semiintercuartilar Una distribución de puntuaciones de prueba (o de cualesquier otros datos a este respecto) puede dividirse en cuatro partes, de tal manera que 25% de las puntuaciones de prueba ocurran en cada cuarto. Como se ilustra en la figura 3-5, los puntos divisorios entre los cuatro cuartos de la distribución son los **cuartiles**; hay tres de ellos y se denominan respectivamente “*Q*₁”, “*Q*₂” y “*Q*₃”. Nótese que un *cuartil* se refiere a un punto específico, mientras que un *cuarto* denota un intervalo; una puntuación individual puede, por ejemplo, caer *en* el tercer cuartil o *dentro* del tercer cuarto (pero *no* “dentro” del tercer cuartil o “en” el tercer cuarto). No debe sorprender que *Q*₂ y la mediana sean exactamente iguales. Y al igual que la mediana es el punto medio en una distribución de puntuaciones, así los cuartiles *Q*₁ y *Q*₃ son *puntos específicos en los cuartos* de una distribución de puntuaciones. Pueden emplearse fórmulas para determinar el valor exacto de estos puntos.

El **rango intercuartilar** es una medida de variabilidad igual a la diferencia entre *Q*₃ y *Q*₁. Al igual que la mediana, es una estadística ordinal. Una medida de variabilidad relacionada es el **rango semiintercuartilar**, que es igual al rango intercuartilar dividido entre dos. Conocer las distancias relativas de *Q*₁ y *Q*₃ respecto a *Q*₂ (la mediana) proporciona al intérprete de pruebas experimentado información inmediata en cuanto a la forma de distribución de las puntuaciones. En una distribución perfectamente simétrica, *Q*₁ y *Q*₃ estarán exactamente a la misma distancia de la mediana. Si estas distancias son desiguales, habrá una falta de simetría. A esta falta de simetría se le denomina *asimetría* o *sesgo*, que se comentará más adelante en este capítulo.

La desviación media Otra herramienta que puede usarse para describir la cantidad de variabilidad en una distribución es la **desviación media** o *DM*, para abreviar. Su fórmula es

$$DM = \frac{\sum |x|}{n}$$

La *x* cursiva/minúscula en la fórmula significa una desviación de la puntuación respecto a la media; su valor se obtiene restando la media respecto a la puntuación ($X - \text{media} = x$). Las barras a cada lado de la *x* indican que es el valor absoluto de la puntuación de la desviación total (igno-




Figura 3-5
Una distribución dividida en cuartos

rando el signo positivo o negativo y considerando toda puntuación de desviación como positiva). Luego, se suman todas las puntuaciones de la desviación y se dividen entre el número total de puntuaciones (n) para obtener la desviación media. Como ejercicio, calcule la desviación media en la siguiente distribución de puntuaciones de una prueba:

85 100 90 95 80

Comience calculando la media aritmética. Después obtenga el valor absoluto de cada una de las cinco puntuaciones de la desviación y súmelas. Mientras las esté sumando, note lo que sucedería si hiciera caso de los signos algebraicos: todas las desviaciones de las puntuaciones sumarían 0. Divida la suma de las puntuaciones de la desviación entre el número de mediciones (5). ¿Obtuvo una *DM* de 6? La *DM* indica que las cinco puntuaciones en esta distribución variaron, en promedio, seis puntos de la media.

La desviación media rara vez se usa. Esto quizá se debe a que al suprimir los signos algebraicos se vuelve una medida inútil con respecto a cualquier otra operación. Entonces, ¿por qué considerarla aquí? Una comprensión clara de lo que mide la desviación media proporciona un fundamento sólido para entender la base conceptual de otra medida mucho más empleada, la *desviación estándar*. Teniendo en mente lo que es una desviación media, lo que indica y de dónde se deriva, consideremos ahora a la desviación media más comúnmente utilizada “prima”, la desviación estándar.

La desviación estándar Recuerde que al calcular la desviación media, se presentaba el problema de que al sumar todas las puntuaciones de desviación el resultado era igual a cero y que esto fue resuelto sumando sólo el valor absoluto de las desviaciones de las puntuaciones. Al calcular la desviación estándar, surge el mismo problema. Pero aquí el problema se trata de una forma diferente; en lugar de usar el valor absoluto de cada una de las desviaciones de las puntuaciones, cada puntuación se eleva al cuadrado; con esto, el signo de las desviaciones negativas se vuelve positivo. Debido a que todas las desviaciones de las puntuaciones se elevan al cuadrado, sabe-

mos que antes de terminar con nuestros cálculos, debemos regresar y obtener la raíz cuadrada de cualquier número que obtengamos.

La **desviación estándar** se puede definir como una medida de variabilidad igual a la raíz cuadrada del promedio de las desviaciones cuadradas con respecto a la media. De manera más sucinta, es igual a la raíz cuadrada de la *varianza*. La **varianza** es igual a la media aritmética de los cuadrados de las diferencias entre las puntuaciones en una distribución y su media. La fórmula usada para calcular la varianza (s^2) usando la desviación de las puntuaciones es

$$s^2 = \frac{\sum x^2}{n}$$

Planteada en forma simple, la varianza se calcula elevando al cuadrado y sumando todas las desviaciones de las puntuaciones y dividiéndolas entre el número total de puntuaciones. La varianza también puede calcularse de otras maneras. Por ejemplo, a partir de las puntuaciones crudas calculando primero la sumatoria de las puntuaciones crudas al cuadrado, dividiendo entre el número de puntuaciones y luego restando la media al cuadrado:

$$s^2 = \frac{\sum X^2}{n} - \bar{X}^2$$

La varianza es una medida usada en forma amplia en la investigación psicológica. Para lograr interpretaciones significativas, la distribución de las puntuaciones de la prueba deberá ser aproximadamente normal. Más adelante, en este capítulo se expondrá más acerca de las distribuciones “normales”. En este punto, piense en ella como una distribución, en donde la mayor frecuencia de puntuaciones ocurre cerca de la media aritmética. De manera correspondiente, cada vez menos puntuaciones relativas a la media se presentan a ambos lados de ésta.

Para obtener algo de experiencia práctica en los conceptos de varianza y desviación estándar, así como una sensación de dominio de los mismos, ¿por qué no dedica los siguientes 10 o 15 minutos a calcular la desviación estándar de las puntuaciones de prueba contenidas originalmente en la tabla 3-1? Use ambas fórmulas para verificar que producen los mismos resultados. Usando desviaciones de puntuaciones, sus cálculos deberán ser similares a éstos:

$$\begin{aligned} s^2 &= \frac{\sum x^2}{n} \\ s^2 &= \frac{\sum (X - \text{media})^2}{n} \\ s^2 &= \frac{[(78 - 72.12)^2 + (67 - 72.12)^2 + \dots (79 - 72.12)^2]}{25} \\ s^2 &= \frac{4972.64}{25} \\ s^2 &= 198.91 \end{aligned}$$

Usando la fórmula para puntuaciones crudas, sus cálculos deberán ser similares a éstos:

$$\begin{aligned} s^2 &= \frac{\sum X^2}{n} - \bar{X}^2 \\ s^2 &= \frac{[(78)^2 + (67)^2 + \dots (79)^2]}{25} - 5201.29 \\ s^2 &= \frac{135005}{25} - 5201.29 \\ s^2 &= 5400.20 - 5201.29 \\ s^2 &= 198.91 \end{aligned}$$

En ambos casos, la desviación estándar es la raíz cuadrada de la varianza (s^2). De acuerdo con nuestros cálculos, la desviación estándar de las puntuaciones de prueba es 14.10. Si $s = 14.10$, 1 unidad de desviación estándar es aproximadamente igual a 14 unidades de medición, o con referencia a nuestro ejemplo y redondeando a un número entero, 14 puntos de calificación. Los datos de la prueba no proporcionan una buena aproximación a una curva normal. Los profesionales de las pruebas describirían estos datos como “asimetría positiva”. La *asimetría* o sesgo, al igual que otros términos relacionados, como *asimetría negativa* o sesgo negativo y *asimetría positiva* o sesgo positivo, se estudian en la siguiente sección. Una vez que se sienta familiarizado con estos términos, apreciará aún más la sección que se incluye más adelante en este mismo capítulo titulada “El área bajo la curva normal”. Ahí encontrará abundante información sobre la interpretación de las puntuaciones de las pruebas en caso de que las puntuaciones *no* sean asimétricas o sesgadas; es decir, cuando las puntuaciones de las pruebas se aproximan a la distribución normal.

El símbolo para la desviación estándar se ha representado de manera variada como s , S , SD y la letra griega minúscula sigma (σ). Un uso, al que nos adherimos, distingue a s como la desviación estándar y a σ como la desviación estándar de la población. El número de observaciones en la muestra es n y el denominador $n - 1$ se usa en ocasiones para calcular lo que se conoce como una “estimación sin sesgo” del valor de la población; en realidad sólo es menos *sesgada* (véase Hopkins y Glass, 1978). A menos que n sea 10 o menos, el uso de n o $n - 1$ tiende a no hacer una diferencia significativa.

Si el denominador más apropiado es n o $n - 1$ ha sido cuestión de debate. Lindgren (1983) ha argumentado en favor del uso de $n - 1$, en parte debido a que este denominador tiende a hacer más simple la correlación de las fórmulas. Por el contrario, la mayor parte de los textos recomiendan el uso de $n - 1$ sólo cuando los datos constituyen una muestra; n es preferible cuando los datos constituyen una población. Para Lindgren no importa si los datos son de una muestra o de una población. Quizá la convención más razonable sea usar n , ya sea cuando la población total ha sido evaluada o cuando no se pretende hacer inferencias sobre la población. Entonces, cuando se consideran las puntuaciones del examen de una clase de estudiantes, incluidas todas las personas sobre quienes haremos inferencias, parece apropiado utilizar n .

Después de haber aclarado (eso esperamos) la controversia respecto a la n contra $n - 1$, a continuación sigue nuestra fórmula para la desviación estándar poblacional. En esta fórmula, $\bar{X}$ representa una media de la muestra, M (mu) la media poblacional:

$$\sigma = \sqrt{\frac{\sum (X - M)^2}{n}}$$

La desviación estándar es una medida de variación muy útil, en vista de que la distancia de cada puntuación individual a la media de la distribución se emplea en su cálculo. Se la encontrará con mucha frecuencia en el estudio de la medición.

Asimetría o sesgo

Las distribuciones pueden caracterizarse por su **asimetría** o **sesgo**, es decir, la naturaleza y grado en que está ausente la simetría. La asimetría es un indicador de la forma en que están distribuidas las mediciones en una distribución. Se dice que una distribución tiene **asimetría positiva** cuando relativamente pocas de las puntuaciones caen en el extremo positivo de la distribución. Los resultados de un examen con asimetría positiva pueden indicar que la prueba fue demasiado difícil; en este caso, habría sido deseable tener más reactivos que fueran más fáciles para discriminar mejor los datos del extremo inferior de la distribución de las puntuaciones de la prueba. Se dice que una distribución tiene **asimetría negativa** cuando relativamente pocas de las puntuaciones caen en el extremo negativo de la distribución. Los resultados de un examen con asimetría negativa pueden indicar que la prueba fue demasiado fácil. En tal caso, habría sido deseable tener más reactivos de un nivel de mayor dificultad de modo que pudiera hacerse una mejor discriminación entre las puntuaciones con respecto al extremo superior de la distribución de puntuaciones. (Véase la figura 3-3 para ejemplos gráficos de distribuciones asimétricas.)

El término *asimetría* tiene implicaciones negativas para muchos estudiantes. Quizá debido a que lo *asimétrico* se asocia con *anormal*, dado que una distribución asimétrica se desvía de una distribución simétrica o normal. Sin embargo, la presencia o ausencia de simetría en una distribución es tan sólo una característica con la que se puede describir esa distribución. De suyo, la asimetría no es de manera inherente ni mala ni buena, normal o anormal. Considérese en este contexto una hipotética prueba de aptitud y resistencia de la Flota de la Marina aplicada a todos los civiles aspirantes a enlistarse en la Marina de Estados Unidos. Ahora observe de nuevo las gráficas de la figura 3-3. ¿Qué gráfica cree usted que describiría mejor la distribución resultante de las puntuaciones de las pruebas? No lea el siguiente párrafo sin antes haber respondido a esta pregunta.

Nadie puede decirlo con exactitud, pero si tuviéramos que conjeturar, diríamos que la prueba de aptitud y resistencia de la flota de la marina se vería como en la gráfica *c*, la distribución con asimetría positiva en la figura 3-3. Decimos esto suponiendo que un nivel de dificultad estaría diseñado para garantizar que sólo unos cuantos califiquen en el nivel más alto de la distribución. Es probable que la mayoría de los aspirantes califiquen en la parte más baja de la distribución. Todo esto es consistente con el objetivo anunciado por la Marina de Estados Unidos, de acuerdo con su anuncio. No está buscando muchos hombres capacitados, en lugar de eso está buscando sólo unos *cuantos*. Ahora, una pregunta respecto a la distribución con asimetría positiva. Esta asimetría ¿Es buena? ¿Es mala? ¿Es algo anormal? En realidad es probable que no sea ninguna de estas cosas, tan sólo *es*. Por cierto, aunque este hecho no lo anuncian, la marina está buscando también una cantidad desconocida de mujeres capacitadas. Pero aquí nos estamos desviando del tema de la asimetría.

Existen varias fórmulas para medir la asimetría. Una forma de estimarla en una distribución es por medio del examen de las distancias relativas de los cuartiles a la mediana. En una distribución con asimetría positiva, $Q_3 - Q_2$ será mayor que la distancia de $Q_2 - Q_1$. En una distribución con asimetría negativa, $Q_3 - Q_2$ será menor que la distancia de $Q_2 - Q_1$. En una distribución simétrica, las distancias de Q_1 y Q_3 a la mediana serán iguales.

Curtosis

El término que usan los profesionales de las pruebas para referirse a la pendiente de una distribución en su centro es **curtosis**, y el sufijo descriptivo *cúrtico* se agrega ya sea a *plati*, *lepto* o *meso* para describir lo agudo o plano de tres tipos generales de curvas (figura 3-6). Las distribuciones




Figura 3-6
La curtosis de las curvas

se describen por lo general como **platicúrticas** (relativamente planas), **leptocúrticas** (relativamente puntiagudas) o en alguna parte intermedia, **mesocúrticas**. Existen muchos métodos para medir la curtosis. Algunos programas de cómputo contienen un índice de asimetría con un rango de -3.00 a $+3.00$. De muchas maneras, sin embargo, los aspectos técnicos relacionados con la medición e interpretación de la curtosis son materia de controversia entre los especialistas, así que vayamos a revisar la distribución que ha sido establecida como el estándar frente a todas las otras distribuciones, incluidas las cúrticas: la distribución normal.

SÓLO PIENSE...

Al igual que la asimetría, la referencia a la curtosis de una distribución puede proporcionar un tipo de descripción “taquigráfica” de la distribución de las puntuaciones de una prueba. Imagine y describa el tipo de pruebas que permitan una distribución que forme una curva platicúrtica.

La curva normal

Antes de profundizar en los aspectos estadísticos, es preciso mencionar en forma breve algunos datos históricos. El desarrollo del concepto de una curva normal comenzó a mediados del siglo XVIII con el trabajo de Abraham DeMoivre y, más tarde, con los del marqués de Laplace. A principios del siglo XIX, Karl Friedrich Gauss hizo algunas contribuciones considerables. A principios del siglo XIX, los científicos se referían a ella como la “Curva Laplace-Gaussiana”. Karl Pearson es a quien se le acredita haber sido el primero en referirse a esta distribución como *curva normal*, quizá en un esfuerzo por ser diplomático ante toda la gente que contribuyó a desarrollarla. No obstante, el nombre de *curva normal* se quedó, pero no se sorprenda si algún día, en alguna reunión científica, escucha que se refieren a esta distribución o curva como de *Gauss*.

Desde el punto de vista teórico, la **curva normal** es una curva en forma de campana, uniforme, definida en forma matemática con su máxima altura en el centro. A partir del centro disminuye en forma gradual hacia ambos lados aproximándose al eje X de manera *asintótica* (lo que significa que se acerca al eje, pero nunca lo toca). En teoría, la distribución de la curva normal va desde el infinito negativo hasta el infinito positivo. La curva es perfectamente simétrica, sin sesgo, de modo que si se dobla a la mitad en la media, un lado quedaría en forma exacta encima del otro. Debido a que es simétrica, la media, la mediana y la moda tienen el mismo valor exacto.

¿Por qué es importante la curva normal para entender las características de las pruebas psicológicas? El apartado *Close-up*, en este capítulo, ofrece algunas respuestas.

El área bajo la curva normal

La curva normal puede dividirse de manera conveniente en áreas definidas en unidades de desviación estándar. Una distribución hipotética de las puntuaciones de una “Prueba nacional de ortografía” con una media de 50 y una desviación estándar de 15 se ilustra en la figura 3-7. En este ejemplo, una puntuación igual a 1 desviación estándar por encima de la media sería igual a 65 ($\bar{X} + 1s = 50 + 15 = 65$).

Antes de continuar con la lectura, tómese un minuto o dos para calcular a qué equivaldría una puntuación exactamente ubicada tres desviaciones estándar por debajo de la media. ¿Cuál sería una puntuación exactamente a tres desviaciones estándar por encima de la media? ¿Sus respuestas fueron 5 y 95, respectivamente? La gráfica nos dice que el 99.74% de todas las puntuaciones en estos datos de la prueba de ortografía distribuidos en forma normal se encuentran entre ± 3 desviaciones estándar. Planteado de otra manera, el 99.74% de todas las puntuaciones de la prueba de ortografía caen entre 5 y 95. Esta gráfica también ilustra otras características de todas las distribuciones normales:

- 50% de las puntuaciones ocurre por encima de la media, y el otro 50% ocurre por debajo de la media.
- Aproximadamente 34% de todas las puntuaciones ocurre entre la media y 1 desviación estándar por encima de la media.

La curva normal y las pruebas psicológicas

Las puntuaciones en muchas pruebas psicológicas a menudo están distribuidas en forma normal, en particular cuando las pruebas son administradas a grandes cantidades de sujetos. Pocas pruebas psicológicas, si es que hay alguna, producen distribuciones precisamente normales de las puntuaciones de la prueba (Micceri, 1989). Como regla general, con amplias excepciones, entre más grande es el tamaño de la muestra y más amplio el rango de capacidades medidas por una prueba particular, más se aproximará la gráfica a la curva normal de las puntuaciones de la prueba. Una ilustración clásica de esto fue proporcionada por E. L. Thorndike y sus colegas (1927). Thorndike y su equipo recopilaron puntuaciones de una prueba de inteligencia de entre varias muestras de estudiantes. Como se puede ver en la figura 1, la distribución de las puntuaciones se aproxima mucho a la curva normal.

Lo siguiente es una muestra de ejemplos más recientes y variados de la amplia gama de características que los psicólogos han encontrado que se aproximan a una distribución normal:

- La fuerza de la tendencia a usar una mano más que la otra en individuos diestros, medida con el Cuestionario de lateralidad Waterloo (Waterloo Handedness Questionnaire) (Tan, 1993).
- Las puntuaciones en el Cuestionario de salud de mujeres (Women's Health Questionnaire), una escala que mide una variedad de problemas de salud en las mujeres a lo largo de una amplia gama de edades (Hunter, 1992).
- Las respuestas de estudiantes universitarios y adultos que trabajan a una medida de motivación intrínseca y extrínseca hacia el trabajo (Amabile *et al.*, 1994).
- Las puntuaciones en una escala de inteligencia de niñas y mujeres con trastornos alimenticios, medidos con la Escala Wechsler de inteligencia para adultos, revisada (Wechsler Adult Intelligence Scale-Revised) y la Escala Wechsler de inteligencia para niños, revisada (Wechsler Intelligence Scale for Children-Revised) (Ranseen y Humphries, 1992).
- El funcionamiento intelectual de niños y adolescentes con fibrosis quística (Thompson *et al.*, 1992).
- La declinación de las capacidades cognitivas en el periodo de un año en personas con la enfermedad de Alzheimer (Burns *et al.*, 1991).
- La tasa de desarrollo de la habilidad motora en preescolares con retraso en el desarrollo, según fue medido en la Escala Vineland de comportamiento adaptativo (Vineland Adaptive Behavior Scale) (Davies y Gavin, 1994).
- Las puntuaciones en la traducción sueca de la Escala del síndrome positivo y negativo (Positive and Negative Syndrome Scale), la cual evalúa la presencia de síntomas positivos y negativos en personas con esquizofrenia (Von Knorring y Lindstrom, 1992).
- Las puntuaciones de los psiquiatras en la Escala del tratamiento de integración de personas con diagnóstico dual (Scale for Treatment Integration of the Dually Diagnosed) (personas con problemas de adicción y otro trastorno mental). La escala examina opiniones acerca del tratamiento farmacológico para este grupo de pacientes (Adelman *et al.*, 1991).
- Respuestas al Cuestionario tridimensional de la personalidad (Tridimensional Personality Questionnaire), una medida de tres características distintas de la personalidad (Cloninger *et al.*, 1991).
- Las puntuaciones en una medida de autoestima entre estudiantes de licenciatura que no se han graduado (Addeo *et al.*, 1994).

En cada caso, los investigadores hicieron un señalamiento especial al establecer que la escala bajo investigación producía algo cercano a una distribución normal de puntuaciones. ¿Por qué? Uno de los beneficios de una distribución normal es que simplifica la interpretación de las puntuaciones individuales en la prueba. En una distribución normal, la media, la mediana y la moda toman el mismo valor. Por ejemplo, si sabemos que la puntuación promedio para la capacidad intelectual de los niños con fibrosis quística es un valor particular, y que las puntuaciones están distribuidas en forma normal, sabemos mucho más. Sabemos que el promedio

- Aproximadamente 34% de todas las puntuaciones ocurre entre la media y 1 desviación estándar debajo de la media.
- Aproximadamente 68% de todas las puntuaciones ocurre entre la media y ± 1 desviación estándar.
- Aproximadamente 95% de todas las puntuaciones ocurre entre la media y ± 2 desviaciones estándar.

Una curva normal tiene dos *colas*. Al área sobre la curva normal entre 2 y 3 desviaciones estándar encima de la media se le conoce como una **cola**. Al área entre -2 y -3 desviaciones estándar por debajo de la media también se le conoce como una cola. Hagamos aquí una digresión




Figura 1
Representación gráfica de los datos de Thorndike *et al.*

es la puntuación más común, así como la puntuación que marca el punto central de la distribución, y que divide todas las demás puntuaciones que se ubican arriba y abajo de ella. Conociendo la media y la desviación estándar de una escala, y que ésta guarda una distribución normal aproximadamente nos dice que alrededor de dos tercios de todas las puntuaciones de quienes responden

la prueba están dentro de una desviación estándar de la media. Aproximadamente 95% de las puntuaciones caen dentro de dos desviaciones estándar de la media.

Las características de la curva normal proporcionan un modelo listo para interpretar puntuaciones que puede aplicarse a una amplia gama de resultados de las pruebas.

momentánea hacia un cuento de la “vida real” de las colas a considerar junto con nuestra explicación más bien abstracta de conceptos estadísticos.

Como se observa en el sugestivo artículo titulado “Las dos colas de la curva normal”, la puntuación de una prueba de inteligencia que cae dentro de los límites de cualquier cola puede tener consecuencias trascendentales en el cuento de la vida de una persona:

Los individuos con retraso mental o los superdotados comparten la carga de desviarse de la norma, en sentido estadístico y de desarrollo. En términos de habilidad mental, según es manejada por las pruebas de inteligencia, el desempeño que está aproximadamente dos desviaciones estándar de la media (es decir, CI de 70–75 o más bajo; o CI de 125–130 o más alto) es un elemento clave en la




Figura 3-7
El área bajo la curva normal

identificación. El éxito en las tareas de la vida cotidiana o su ausencia también juegan un papel definitorio, sin embargo, el rasgo primario de clasificación de los grupos superdotados y los grupos con retraso es la desviación intelectual. Estas personas están fuera de sincronía con la gente promedio, tan sólo por la diferencia de lo que se espera de ellos a su edad y bajo sus circunstancias. Esta falta de sincronía tiene consecuencias altamente significativas para ellos y para quienes comparten sus vidas. No se aplica ninguna de las normas familiares, y se requieren de ajustes sustanciales en las expectativas de los padres, en el contexto escolar y en actividades sociales y recreativas. (Robinson *et al.*, 2000, p. 1413)

Como es ilustrado (de manera muy dramática) por Robinson y colaboradores, el conocimiento de las áreas bajo la curva normal puede ser muy útil para el intérprete de los datos de las pruebas. Este conocimiento no sólo puede decirnos algo acerca de dónde cae la puntuación entre una distribución de puntuaciones, sino incluso algo acerca de una *persona*, quizá hasta de la gente que comparte la vida de esa persona. Este conocimiento también puede darnos información sobre qué tan hábil, promedio o deficiente es el individuo respecto a una disciplina o habilidad. Por ejemplo, considere a un estudiante de bachillerato cuya puntuación en una prestigiada prueba nacional de ortografía estuvo cerca de 3 desviaciones estándar por encima de la media. Podríamos apostar a que el estudiante sabría escribir palabras como *asintótico* y *leptocúrtico*.

Del mismo modo en que el conocimiento de las áreas bajo la curva normal puede transmitir de manera instantánea información útil acerca de una puntuación de prueba en relación con otras puntuaciones. Así también sucede con el conocimiento de puntuaciones estándares.

Puntuaciones estándar

Expuesto en forma simple, una **puntuación estándar** es una puntuación cruda que ha sido convertida de una escala a otra, siendo la última la que tiene una media y una desviación estándar establecidas de manera arbitraria. ¿Por qué convertir las puntuaciones crudas en puntuaciones estándares?

Las puntuaciones crudas pueden ser convertidas en puntuaciones estándares porque éstas pueden interpretarse con mayor facilidad que las crudas. Con una puntuación estándar, la posición del desempeño de un examinado en relación con la de los otros que respondieron la prueba, es claramente evidente.

Existen diferentes sistemas para las puntuaciones estándar, cada uno es singular con respecto a su media y a sus desviaciones estándar. A continuación se describen brevemente las puntuaciones z , las puntuaciones T , los “estanueves” y algunas otras puntuaciones estándar. En principio, revisaremos la escala de puntuaciones estándar, la cual se puede concebir como la *escala cero más o menos uno*. Esto se debe a que tiene una media establecida en cero y una desviación estándar colocada en uno. Las puntuaciones crudas convertidas en puntuaciones estándar en la *escala cero más o menos uno* son conocidas de manera más popular como puntuaciones z .

Puntuaciones z

Una **puntuación z** resulta de la conversión de una puntuación cruda en un número que indique a cuántas unidades de desviación estándar está la puntuación cruda por debajo o por encima de la media de la distribución. Usemos un ejemplo de los datos distribuidos en forma normal de la “Prueba nacional de ortografía” en la figura 3-7 para demostrar cómo una puntuación cruda se convierte en una puntuación z . A continuación convirtamos una puntuación cruda de 65 en una puntuación z . Para hacer esto se utilizará la siguiente fórmula:

$$z = \frac{X - \bar{X}}{s} = \frac{65 - 50}{15} = \frac{15}{15} = 1$$

En esencia, una puntuación z es igual a la diferencia entre una puntuación cruda particular y la media dividida entre la desviación estándar. En el ejemplo anterior, una puntuación cruda de 65 resultó en una puntuación z de + 1. Saber que alguien obtuvo una puntuación cruda de 65 en una prueba de ortografía da contexto y significado a la puntuación. Basándonos en nuestro conocimiento de las áreas bajo la curva normal, por ejemplo, sabríamos que sólo alrededor del 16% de los demás que respondieron la prueba obtuvieron puntuaciones mayores. Como contraste, el saber que alguien obtuvo una puntuación cruda de 65 en una prueba de ortografía prácticamente no comunica información útil, debido a que falta información sobre el contexto de esta prueba.

Además de ofrecer un contexto conveniente para comparar las puntuaciones en la misma prueba, las puntuaciones estándar también proveen un contexto conveniente para comparar las puntuaciones entre pruebas diferentes. Por ejemplo, considere la puntuación cruda de Crystal, 24, en la supuesta “Prueba de lectura en la calle Principal” y que su puntuación cruda en la, igualmente supuesta, “Prueba de aritmética en la calle Principal” fue 42. Sin saber nada más que estas puntuaciones crudas, podemos concluir que Crystal tuvo un mejor desempeño en la prueba de aritmética comparada con la de lectura. Hubieran sido más informativas las dos puntuaciones z que las dos puntuaciones crudas.

Al convertir las puntuaciones crudas de Crystal en puntuaciones z , con base en el desempeño de otros estudiantes de la clase, supongamos que encontramos que su puntuación z en la prueba de lectura fue 1.32 y su puntuación z en la prueba de aritmética fue -0.75 . Por tanto, aunque su puntuación cruda en aritmética fue mayor que en lectura, las puntuaciones z dan una imagen completamente diferente. Las puntuaciones z dicen que en relación con otros estudiantes de su clase (y asumiendo que la distribución de puntuaciones es relativamente normal), Crystal se desempeñó por encima del promedio en la prueba de lectura y por debajo del promedio en la prueba de aritmética. Una interpretación de exactamente cuánto mejor se desempeñó podría obtenerse haciendo referencia a tablas que detallan distancias bajo la curva normal, y el porcentaje resultante de casos que podría esperarse cayeran por encima o debajo de un punto de desviación estándar particular (o puntuación z).

Puntuaciones T

Si la escala usada en el cálculo de las puntuaciones z se llama *escala cero más o menos uno*, entonces la escala usada en el cálculo de las **puntuaciones T** se llama *escala cincuenta más o menos diez*; es de-




Figura 3-8
Los estanueves y la curva normal

cir, una escala que tiene una media establecida en 50 y una desviación estándar establecida en 10. Planeada por W. A. McCall (1922, 1939) y nombrada puntuación *T* en honor de su profesor E. L. Thorndike, este sistema de puntuación estándar se compone de una escala que va desde 5 desviaciones estándar por debajo de la media hasta 5 desviaciones estándar por arriba de la media. Así, por ejemplo, una puntuación cruda que caiga exactamente en 5 desviaciones estándar por debajo de la media sería igual a una puntuación *T* de 0; una puntuación cruda que caiga en la media sería igual a una *T* de 50, y una puntuación cruda que caiga en un punto que está 5 desviaciones estándar por encima de la media sería igual a una *T* de 100. Una ventaja de usar las puntuaciones *T* es que ninguna de las puntuaciones es negativa. Por el contrario, en una distribución de puntuaciones *z*, las puntuaciones pueden ser positivas y negativas, haciendo que sea incómodo hacer mayores cálculos en algunos casos.

Otras puntuaciones estándar

Existen otros sistemas estándar de calificación. Durante la segunda guerra mundial los investigadores elaboraron una puntuación estándar con una media de 5 y una desviación estándar de aproximadamente 2. Dividida en nueve unidades, la escala fue bautizada como **estanueve**, que se deriva de la contracción de las palabras *estándar* y *nueve* (en inglés, *stanine*).

La puntuación estanueve puede ser familiar para muchos estudiantes que han presentado pruebas de rendimiento aplicadas en las escuelas elementales y en secundaria, donde a menudo las puntuaciones de las pruebas son representadas como estanueves. Las estanueves son diferentes de otras puntuaciones estándar porque toman valores enteros de 1 a 9, los cuales representan un rango de desempeño que tiene $\frac{1}{2}$ desviación estándar de ancho (figura 3-8). La quinta estanueve indica un desempeño en el rango promedio, desde $\frac{1}{4}$ de desviación estándar por debajo de la media a $\frac{1}{4}$ de desviación estándar por encima de la media, captando 20% intermedio de las puntuaciones en una distribución normal. La cuarta y sexta estanueves también tienen $\frac{1}{2}$ desviación estándar de ancho, y captan 17% de los casos por debajo y por arriba de la quinta estanueve, respectivamente.

Otro tipo de puntuación estándar se emplea en pruebas como la Prueba de aptitudes escolares (Scholastic Aptitude Test; SAT) y el Examen de registro para graduados (Graduate Record Examination; GRE). Las puntuaciones crudas sobre estas pruebas son convertidas a puntuaciones estándar de tal modo que la distribución resultante tenga una media de 500 y una desviación estándar de 100. Si se usa la letra *A* para representar una puntuación estándar de una prueba de admisiones para la universidad cuya distribución tiene una media de 500 y una desviación estándar de 100, entonces lo siguiente es verdadero:

$$(A = 600) = (z = 1) = (T = 60)$$

¿Alguna vez ha escuchado el término *CI* usado como sinónimo de la puntuación que se puede obtener en una prueba de inteligencia? Por supuesto que sí. Lo que es probable que desconozca es




Figura 3-9
Alunos equivalentes de resultados estándar

Nótese que los valores presentados aquí para los resultados de CI asumen que los valores de las pruebas de inteligencia consideran una media de 100 y una desviación estándar de 1.5. Esto es cierto para muchas pruebas de inteligencia, pero no para todas. Si una prueba de inteligencia en particular arrojará resultados con una media distinta a 100 y/o una desviación estándar diferente a 15, los valores mostrados para los resultados de CI deberían de ajustarse de acuerdo con esto.

que distintos términos tales como CI, desviación del CI o desviación del cociente de inteligencia hacen referencia de hecho, a otro tipo de puntuación estándar. Para la mayoría de las pruebas de CI, la distribución de las puntuaciones crudas se convierte en puntuaciones CI, cuya distribución de manera típica tiene una media establecida en 100 y una desviación estándar establecida en 15. Enfatizaremos la expresión de *manera típica* porque existe alguna variación en los sistemas de calificaciones estándar dependiendo de la prueba que se utilice. La media y la desviación estándar típicas para los resultados de las pruebas de CI es aproximadamente 95% de desviación CI, en un rango desde 70 hasta 130. Esto significa dos desviaciones estándar por arriba y por debajo de la media, respectivamente. En el contexto de una distribución normal, la relación de las puntuaciones de desviación del CI con las otras puntuaciones estándar que se han expuesto hasta el momento (puntuaciones z , T y A) se ilustra en la figura 3-9.

Las puntuaciones estándar convertidas a partir de puntuaciones crudas pueden implicar transformaciones lineales o no lineales. Una puntuación estándar obtenida por una **transformación lineal** es aquella que conserva una relación numérica directa con la puntuación cruda original. La magnitud de las diferencias entre tales puntuaciones estándar guarda una relación paralela con las diferencias entre las puntuaciones crudas correspondientes. En ocasiones las puntuaciones pueden sufrir más de una transformación. Por ejemplo, los creadores de la SAT hicieron una segunda transformación lineal en sus datos para convertir las puntuaciones z en una nueva escala que tiene una media de 500 y una desviación estándar de 100.

Una **transformación no lineal** puede requerirse cuando los datos considerados no están distribuidos de manera normal y se necesita hacer comparaciones con distribuciones normales. En una transformación no lineal, la puntuación estándar resultante no tiene de manera necesaria una relación numérica con la puntuación cruda original. Como resultado de una transformación no lineal, se dice que la distribución original ha sido *normalizada*.

Puntuaciones estándar normalizadas La mayoría de los diseñadores de pruebas esperan que el instrumento en el que están trabajando tenga una distribución normal en sus puntuaciones. Sin embargo, sucede que después de aplicar la prueba a una muestra muy amplia, los resultados que se obtienen presentan una distribución asimétrica. ¿Qué debe hacerse en este caso?

Una alternativa de la que dispone quien desarrolla las pruebas es **normalizar la distribución**. Desde el punto de vista conceptual, la normalización de una distribución implica “estirar” la curva asimétrica para que adopte la forma de una curva normal y crear una escala correspondiente de puntuaciones estándar; una escala a la que se hace referencia en forma técnica como **escala de puntuaciones estándar normalizadas**.

La normalización de puntuaciones con una distribución asimétrica también puede ser aconsejable con propósitos de comparación. Una de las ventajas primarias de una puntuación estándar en una prueba es que puede compararse con facilidad con una puntuación estándar de otra prueba. Sin embargo, la comparación de puntuaciones estándar sólo es apropiada cuando las distribuciones de las que se derivan son parecidas. En la mayoría de los casos es así debido a que las dos distribuciones son aproximadamente normales. Pero si, por ejemplo, la distribución A era normal y la distribución B era muy asimétrica, las puntuaciones z en estas distribuciones representarían diferentes cantidades de área incluidas bajo la curva. Una puntuación z de -1 con respecto a los datos distribuidos en forma normal nos dice, entre otras cosas, que alrededor del

84% de las puntuaciones en esta distribución fueron mayores que esta puntuación. Una puntuación z de -1 con respecto a los datos que fueron muy asimétricos en forma positiva podría significar, por ejemplo, que sólo el 62% de las puntuaciones fueron mayores.

Para los diseñadores de pruebas que intentan elaborar instrumentos que produzcan mediciones distribuidas en forma normal, por lo general es preferible afinar la prueba con respecto al grado de dificultad o bien a otras variables relevantes, de modo que la distribución resultante se aproxime a la curva normal. Por lo general, esto es mejor que intentar normalizar distribuciones originalmente asimétricas o sesgadas. Esto es así porque hay riesgos técnicos que deben tomarse en cuenta antes de intentar la normalización. Por ejemplo, sólo deben hacerse transformaciones cuando hay una buena razón para creer que la muestra de la prueba fue lo bastante grande y representativa y que la falla para obtener puntuaciones distribuidas en forma normal es debida al instrumento de medición.

Hablando de transformaciones, es tiempo de cambiar hacia el capítulo 4. Puede ser útil en este momento hacer una revisión de este repaso de estadística para asegurarse de que en efecto lo ha comprendido y está listo para continuar. Seguiremos aumentando su conocimiento de los principios básicos de la estadística en los capítulos siguientes, y es importante que dichos conocimientos tengan fundamentos sólidos.

SÓLO PIENSE...

Aplique todo lo que ha aprendido sobre distribuciones de frecuencia, gráficas de distribuciones de frecuencia, medidas de tendencia central, medidas de variabilidad, la curva normal y las puntuaciones estándar a la pregunta de los datos enlistados en la tabla 3-1. ¿De qué manera comunicaría los datos de esta tabla al grupo? ¿Qué tipo de distribución de frecuencia utilizaría? ¿Qué tipo de gráfica? ¿Qué medida de tendencia central? ¿Qué medida de variabilidad? ¿Puede ser útil la referencia a una curva normal o a puntuaciones estándares? ¿Por qué sí o por qué no?

Autoevaluación

Pruebe su entendimiento de los elementos de este capítulo viendo si puede explicar cada uno de los siguientes términos, expresiones y abreviaturas:

asimetría

asimetría positiva

asimetría negativa

cola

cuartil

curtosis

curva normal

desviación estándar

desviación media

dinamómetro

distribución

distribución bimodal

distribución de frecuencia

distribución de frecuencia

agrupada

error

escala

escala de intervalo

escala de puntuación estándar normalizada	media aritmética mediana medición	puntuación T puntuación z rango
escala de razón	medida de tendencia central	rango intercuartilar
escala nominal	medida de variabilidad	rango semiintercuartilar
estadística	mesocúrtico	transformación lineal
gráfica	moda	transformación no lineal
gráfica de barras	platicúrtico	variabilidad
histograma	polígono de frecuencia	varianza
leptocúrtico	puntuación cruda	
media	puntuación estándar	

Un vistazo a la red

Revise los siguientes sitios web para más información sobre los temas revisados en este capítulo.

Statistics review

www.statsoftinc.com/textbook/stathome.html

Measures of central tendency

<http://simon.cs.vt.edu/SoSci/Site/MMM/mmm.html>

<http://davidmlane.com/hyperstat/A5185.html>

Normal distribution

http://davidmlane.com/hyperstat/normal_distribution.html

Bar graphs, histograms, and charts

www.visualmining.com/examples/styles

"Real-life" statistics

www.fedstats.gov/qf/states/17000.html

Sobre las pruebas psicológicas y su aplicación

¿Es competente esta persona para enfrentar un juicio?

¿Quién debe ser contratado, transferido, promovido o despedido?

¿Quién debe entrar en este programa especial o a quién se le debe otorgar una beca?

¿Cuál de los padres debe obtener la custodia de los hijos?

C

ada día, en todo el mundo, se formulan preguntas de vital importancia concernientes al uso de las pruebas. Es probable que la respuesta a este tipo de preguntas tenga un impacto significativo en la vida de muchas personas.

SÓLO PIENSE...

¿Qué es una “buena prueba”? Bosqueje algunos elementos o características que considere como esenciales para una buena prueba antes de continuar con la lectura.

Si los profesionales de la evaluación desean dormir bien por la noche, deben tener confianza en las pruebas y otras herramientas que emplean. Necesitan saber, por ejemplo, cuáles son los elementos que constituyen una “buena prueba” y cuáles no.

El objetivo de este capítulo es ofrecer un resumen de esos elementos. Como antecedente, se comenzará con la lista de algunos supuestos básicos sobre la evaluación. Algunos aspectos de éstos se detallarán más adelante en este capítulo y en posteriores.

Algunos supuestos sobre pruebas y evaluación psicológica

Supuesto 1: Existen rasgos psicológicos y estados

Un **rasgo** se define como “cualquier manera distinguible y relativamente duradera en que un individuo se diferencia de otro” (Guilford, 1959, p. 6). Los **estados** también distinguen a una persona de otra, pero son relativamente menos duraderos (Chaplin *et al.*, 1988). El término rasgo que un observador aplica, así como la fuerza o magnitud del rasgo que se presume está presente, se basan en la observación de una muestra de comportamiento. Las muestras de comportamiento pueden obtenerse de varias maneras que van desde la observación directa al análisis de lo establecido en los informes personales, hasta las respuestas en las pruebas de lápiz y papel.

La expresión *rasgo psicológico*, de manera similar al término *rasgo* en sí mismo, abarca un rango amplio de características posibles. En inglés, por ejemplo, pueden encontrarse miles de términos que se refieren a rasgos psicológicos. (Allport & Odbert, 1936). Entre ellos se encuentran rasgos psicológicos que se relacionan con la inteligencia habilidades intelectuales específicas, es-



Figura 4-1
Midiendo la búsqueda de sensaciones

El rasgo psicológico de búsqueda de sensaciones se ha definido como “la necesidad de variadas, nuevas y complejas sensaciones y experiencias y el deseo de enfrentar riesgos físicos y sociales en función de encontrar tales experiencias” (Zuckerman, 1979, p. 10). Una escala de búsqueda de sensaciones (EBS) de 22 preguntas trata de identificar a las personas que tienen un nivel alto o bajo en relación a este rasgo. Si se supone que la EBS en realidad mide lo que pretende medir, ¿cómo esperaría que fuera la puntuación en esta prueba obtenida de una muestra aleatoria escogida entre personas que esperan en fila para saltar con una cuerda elástica (bungee), en comparación con la obtenida por una muestra de personas de la misma edad, seleccionadas mientras hacían sus compras en el centro comercial local? ¿Cuáles son las ventajas comparativas entre usar pruebas de lápiz y papel, como la EBS, y utilizar otras medidas basadas en el desempeño, como la que se presenta aquí?

tilo cognoscitivo, adaptación, intereses, actitudes, orientación y preferencias sexuales, psicopatología, personalidad en general y rasgos específicos de la personalidad. Los nuevos conceptos y descubrimientos en la investigación pueden aportar nuevos términos acerca de los rasgos. Por ejemplo, un término relacionado con los rasgos, y que cada vez se escucha con más frecuencia en la literatura profesional sobre sexualidad humana, es *andrógino* (que se refiere a la ausencia de primacía de las características masculinas o femeninas). La evolución cultural puede traer nuevos términos de rasgos al lenguaje común, como sucedió en la década de 1960, cuando la gente comenzó a hablar del grado de *liberación* de las mujeres (o liberadas de las restricciones de las expectativas sociales dependientes del género). Un ejemplo más reciente es la expresión rasgos *New age*, que se usa en la cultura popular para referirse a una orientación particular hacia la espiritualidad y la salud, sin adoptar una corriente definida.

Poca gente niega que existan rasgos psicológicos. Sin embargo, hay demasiada controversia respecto a cómo es que existen. Por ejemplo, ¿tienen una existencia física los rasgos, tal vez como un circuito dentro del cerebro? Aunque algunos están a favor de tal concepción de los rasgos psicológicos (Allport, 1937; Holt, 1971), ha sido difícil obtener evidencias contundentes que apoyen esta visión. Para nuestros propósitos, un rasgo psicológico existe sólo como un **constructo** —un concepto científico informado, desarrollado o *construido* para describir o explicar un comportamiento—. Los constructos no se pueden ver, oír o tocar, pero se puede inferir su existencia a partir del *comportamiento evidente*. En este contexto, el **comportamiento evidente** se refiere a una acción observable o al producto de una acción observable, incluyendo las pruebas o las respuestas relacionadas con la evaluación. Uno de los retos que enfrentan los diseñadores de pruebas es desarrollar éstas de modo tal que sean tan descriptivas como un comportamiento observable, similar al que se ilustra en la figura 4-1.

La frase *relativamente duradera*, en nuestra definición de *rasgo*, es un recordatorio de que no debe esperarse que el rasgo en cuestión se manifieste mediante el comportamiento el 100% del tiempo. Por tanto, es importante estar pendiente del contexto o situación en que se presenta un

comportamiento particular. Se presume que el hecho de que un rasgo se haga evidente a través de una conducta observable, y el grado en el que se manifieste, depende no sólo de la fuerza del rasgo en el individuo, sino también de la índole de la situación. Dicho de otro modo, la manera exacta en que un rasgo particular se manifiesta, al menos en cierta medida, depende de la situación. Por ejemplo, alguien muy violento que está en libertad condicional puede ser propenso a comportarse de una manera muy dócil ante un oficial, y mucho más violento con su familia y amigos. John puede mostrarse aburrido y empequeñecido ante los ojos de su esposa, pero encantador y extravagante ante sus socios de negocios, a quienes desea impresionar.

El contexto en que ocurre el comportamiento también juega un papel importante, al ayudarnos a seleccionar los términos apropiados para definir el rasgo observado a través de la conducta.

SÓLO PIENSE...

Dé otro ejemplo de cómo el mismo comportamiento en dos contextos diferentes puede ser considerado en términos de dos rasgos distintos.

Considere cómo etiquetaríamos el proceder de alguien que está arrodillado hablando con Dios. Esta conducta puede ser vista ya sea como religiosa o como un trastorno, según el contexto en el que ocurra. Una persona que esté arrodillada platicando con Dios dentro de una iglesia o frente a un altar puede ser descrita como *religiosa*, mientras que otra persona en la misma actitud en un sanitario público podría calificarse como trastornada o *paranoica*.

Las definiciones de *rasgo* y *estado* usadas aquí también se refieren a la *manera en que varía un individuo de otro*. La atribución de un rasgo o estado es un fenómeno relativo. Por ejemplo, al describir a una persona como *tímida* o al usar gradaciones como *muy tímida* o *no tímida*, la mayoría de las personas realizan una comparación acerca del grado de timidez que se podría esperar razonablemente que una persona promedio mostrara bajo circunstancias iguales o similares. En la evaluación psicológica, los evaluadores también pueden hacer comparaciones respecto a la persona promedio hipotética. Igualmente los evaluadores pueden hacer comparaciones entre personas que, debido a su pertenencia a algún grupo, o por muchas otras razones, se encuentran indudablemente, fuera del promedio.

SÓLO PIENSE...

¿La fuerza de un rasgo psicológico particular es la misma en todas las situaciones o entornos? ¿Cuáles son las implicaciones de la propia respuesta a esta pregunta en el contexto de la evaluación?

Como usted podrá suponer, el grupo de referencia respecto al cual se hacen las comparaciones puede influir en gran medida en nuestras conclusiones o juicios. Por ejemplo, suponga que un psicólogo administra una prueba de timidez a un hombre de 22 años de edad, quien se gana la vida como bailarín exótico. La interpretación de los datos de la prueba seguramente diferirá en función del

grupo de referencia con el que se compare al evaluado; es decir, otros hombres en su grupo de edad u otros bailarines exóticos en su grupo de edad.

Supuesto 2: Los rasgos psicológicos y los estados pueden cuantificarse y medirse

Una vez que se ha admitido la existencia de rasgos y estados psicológicos es necesario definir con cuidado los rasgos y estados específicos que habrán de medirse y cuantificarse. Los diseñadores de pruebas e investigadores, así como la mayoría de la gente tienen muchas maneras diferentes de observar y definir el mismo fenómeno. Sólo piense, por ejemplo, en los diversos modos en que es utilizado el término *agresivo*. Se habla de un vendedor agresivo, de un asesino agresivo, de un bailarín agresivo, por mencionar sólo algunos contextos. En cada uno de esos diferentes contextos, *agresivo* tiene un significado diferente. Si una prueba de personalidad arroja una puntuación que ofrece información sobre qué tan agresivo es el evaluado, el primer paso para entender el significado de esa puntuación es saber cómo ha sido definido el término *agresivo* por el creador de la prueba. De manera más específica, ¿qué tipos de comportamientos se presume son indicativos de que alguien es agresivo? ¿Cómo se define esto en la prueba?

Una vez definido el rasgo, estado, o constructo que será medido, el diseñador de pruebas considera el tipo de contenido para las preguntas que podría proporcionar un conocimiento al respecto. A partir de un universo de conductas que se presume son indicativas del rasgo busca-

do, un diseñador de pruebas tiene todo un universo de preguntas posibles que pueden escribirse para medir la fuerza de ese rasgo en los evaluados.¹ Por ejemplo, si el autor de la prueba considera que la historia de Estados Unidos es un componente de la inteligencia de un adulto, entonces en la prueba podría aparecer la pregunta: *¿Quién fue el segundo presidente de Estados Unidos?* De modo similar, si se cree que el juicio social es un indicador de la inteligencia de los adultos, entonces sería razonable preguntar *¿Por qué las armas que se tienen en casa deben estar siempre fuera del alcance de los niños?*

Suponga que estamos de acuerdo en que una pregunta acerca de la historia de Estados Unidos y otra acerca del juicio social son apropiadas para una prueba de inteligencia en el adulto. Entonces surge otra interrogante: ¿Deben ambas preguntas tener el mismo peso? Es decir, ¿se debe dar la misma importancia (y otorgarle mayor puntuación) a una respuesta “correcta” en alguna de estas dos preguntas? Quizá una respuesta correcta a la pregunta sobre el juicio social debiera tener más crédito que una respuesta correcta a la pregunta sobre la historia de Estados Unidos. El ponderar el valor comparativo de cada uno de los reactivos de una prueba ocurre como resultado de una compleja interrelación entre varios factores, incluyendo consideraciones técnicas, la manera en que se ha definido un constructo para los propósitos de la prueba y los valores que la sociedad asigna a los comportamientos evaluados.

La medición de los rasgos y estados mediante una prueba implica desarrollar no sólo reactivos apropiados para la prueba, sino también maneras apropiadas para calificarla e interpretar los resultados. Para muchas variedades de pruebas psicológicas, un número que representa la puntuación de la prueba se deriva de las respuestas del examinado. Se presume que la puntuación de la prueba representa la fuerza de la habilidad, rasgo o estado a evaluar, y a menudo se basa en una **calificación acumulativa**.² Inherente a la calificación acumulativa está la hipótesis de que mientras más responda el evaluado en una dirección particular que el manual de la prueba considere como correcto o consistente con un rasgo particular, más posibilidades tiene el evaluado de tener una habilidad o rasgo específico. Es posible que usted haya tenido su primer contacto con un puntaje acumulativo en la escuela primaria, cuando observó que su calificación en la prueba semanal de ortografía estaba relacionada con la cantidad de palabras que escribió de manera correcta o incorrecta. La calificación refleja la extensión en la cual dominó con éxito la tarea de ortografía de la semana. Con base en esa puntuación podemos predecir que usted escribiría correctamente esas palabras si se le pidiera que lo hiciera. Esto lleva al siguiente supuesto.

SÓLO PIENSE...

¿A qué tipo de reactivo se le debe dar más peso en una prueba de inteligencia para adultos? ¿A qué tipo de reactivo se le debe dar un menor peso?

Supuesto 3: La conducta relacionada con la prueba predice la conducta no relacionada con la prueba

Muchas pruebas implican tareas como rellenar pequeños óvalos con un lápiz del número 2, o sólo presionar teclas en una computadora. De manera característica, el objetivo de tales pruebas tiene poco que ver con predecir el futuro rellenando óvalos o con la conducta de oprimir teclas. Más bien, es ofrecer una indicación de otros aspectos del comportamiento del examinado. Por ejemplo, los patrones de respuestas a las preguntas de falso/verdadero, en una prueba de personalidad usada de manera amplia se usan en la toma de decisiones acerca de trastornos mentales.

1. En el lenguaje de las pruebas y la evaluación psicológica, la palabra *dominio* se sustituye por *universo* en este contexto. Por ejemplo, los profesionales de la evaluación hablan de **muestreo del dominio**, lo cual puede hacer referencia ya sea: 1) a una muestra de comportamientos a partir de todos los comportamientos posibles que podrían concebirse como indicadores de un constructo particular, o 2) a una muestra de reactivos de prueba a partir de todos los reactivos posibles que podrían concebirse como útiles para medir un constructo particular.

2. En el capítulo 7 se exponen otros modelos de puntuación.

Las tareas en algunas pruebas imitan los comportamientos reales que el evaluador de la prueba intenta entender. Sin embargo, por su naturaleza, estas pruebas proporcionan sólo una muestra del comportamiento que cabría esperar fuese emitido bajo condiciones fuera de prueba. La muestra de comportamiento obtenida se usa de manera característica para hacer predicciones sobre el comportamiento futuro, como el desempeño en el trabajo de un candidato a un puesto. En algunas cuestiones forenses (legales), las pruebas psicológicas pueden usarse no sólo para predecir el comportamiento, sino para explicarlo con posterioridad; es decir, para ayudar a entender el comportamiento que ya ha tenido lugar. Por ejemplo, tal vez exista la necesidad de entender el estado mental de un criminal en el momento en que cometió un delito. Está más allá de la capacidad de cualquier prueba o procedimiento de evaluación conocido, reconstruir el estado mental de alguien. Aun así, las muestras de comportamiento tomadas

SÓLO PIENSE...

Se ha comprobado en la práctica que las pruebas son mejores predictoras de ciertos tipos de comportamientos a diferencia de otros. Por ejemplo, las pruebas *no* han demostrado ser tan buenas como se desearía para predecir la violencia. En su opinión, ¿por qué ocurre esto?

en algún punto, pueden arrojar luz, bajo ciertas circunstancias, sobre el estado mental de alguna persona en algún punto en el pasado. Además, otras herramientas de evaluación, como los datos históricos del caso o el diario personal del acusado durante el periodo en cuestión pueden ser de gran valor para tal evaluación.

Supuesto 4: Las pruebas y otras técnicas de medición tienen fortalezas y debilidades

Los evaluadores competentes entienden mucho sobre las pruebas que utilizan. Entienden, entre otras cosas, cómo se desarrolló la prueba, las circunstancias bajo las cuales es apropiado administrarla, cómo debe administrarse la prueba y a quién, y cómo deben interpretarse los resultados. Los evaluadores competentes entienden y aprecian las limitaciones de las pruebas que usan y cómo éstas pueden ser compensadas con datos de otras fuentes. Todo esto puede parecer de absoluto sentido común. Es probable que así sea. No obstante, este supuesto, tan simple en apariencia, acerca de que los evaluadores conocen las pruebas que usan y están conscientes de sus limitaciones se enfatiza de manera repetida en los códigos de ética de asociaciones de profesionales de la evaluación.

Supuesto 5: El proceso de evaluación está sujeto a diversas fuentes de error

En la conversación cotidiana, utilizamos la palabra *error* para referirnos a errores de cálculo y cosas por el estilo. En el contexto de la evaluación, un error no necesariamente se refiere a una desviación, una omisión o algo que de algún modo viole las expectativas. Por el contrario, *error*, de manera tradicional, se refiere a algo que está más allá de lo que se espera; de hecho, es un componente del proceso de medición. De manera más específica, *error* se refiere a una persistente suposición de que otros factores, además de los que se pretenden medir, influirán en el desempeño de la prueba. Las puntuaciones de las pruebas siempre están sujetas a preguntas sobre el grado en que el proceso de medición incluye el error. Por ejemplo, la puntuación de una prueba de inteligencia podría estar sujeta a debate con respecto al grado en que la puntuación obtenida en verdad refleje la inteligencia del examinado y el grado en que se haya debido a otros factores no relacionados con la inteligencia. Debido a que el error es una variable que debe tomarse en cuenta en cualquier evaluación, a menudo se habla de la **varianza de error**; es decir, el componente de la puntuación de un examen atribuible a fuentes distintas al rasgo o habilidad medida.

Existen muchas fuentes potenciales de la varianza de error. El hecho de que el evaluado esté resfriado en el momento de contestar la prueba es una fuente de varianza. En un sentido más general, entonces, los evaluados mismos son fuente de una varianza de error. Por ejemplo, algunos evaluadores son más profesionales que otros en la manera en que siguen las instrucciones que determinan cómo y bajo qué circunstancias debe administrarse una prueba. Además de los eva-

luadores y evaluados, los instrumentos de medición mismos son otra fuente de varianza de error. Algunas pruebas simplemente son mejores que otras para medir lo que pretenden medir.

Los instructores que imparten cursos estudiantiles sobre medición, en ocasiones habrán escuchado a algún estudiante comentar que un error está “interfiriendo” o “contaminando” el proceso de medición. No obstante, los profesionales de la medición tienden a ver el error tan sólo como un elemento que está presente en el proceso de medición, para el cual ninguna teoría de medición cuenta. En lo que se conoce como **teoría de puntuación verdadera o clásica**, se ha establecido el supuesto de que cada evaluado tiene una puntuación verdadera que podría obtener de no ser por la acción aleatoria del error de medición.

Supuesto 6: Las pruebas y la evaluación pueden conducirse de una manera justa y sin prejuicios

Si de los siete supuestos tuviéramos que elegir el que fuese más controvertido, éste sería el elegido. Décadas de desafíos en los juzgados a varias pruebas y programas de pruebas han sensibilizado a diseñadores de pruebas y a los evaluadores frente a la demanda social de pruebas justas usadas de manera justa. Hoy, la mayoría de los editores de pruebas se esfuerzan en diseñar instrumentos que sean justos cuando sean utilizados de acuerdo con los principios del manual de la prueba. Una fuente de problemas relacionados con la justicia, es el evaluador que intenta usar una prueba particular con gente cuya historia personal y experiencias son distintas a las de la gente a la que la prueba está destinada. En esos casos, es útil enfatizar que las pruebas son herramientas. Y al igual que cualquier otra herramienta doméstica (martillos, picahielos, llaves) pueden ser usadas de una manera apropiada o puede abusarse de ellas.

Algunos problemas potenciales relacionados con la imparcialidad de una prueba son más políticos que psicométricos. Por ejemplo, algunos programas de acción afirmativa en selección, contratación y acceso o negación del acceso a varias oportunidades, a menudo se ven enmarcados en acalorados debates. En muchos casos, la cuestión real a debatir no es: “¿Es justa esta prueba o procedimiento de evaluación?” sino, “Como sociedad, ¿Qué deseamos lograr con el uso de esta prueba o procedimiento de evaluación?”

SÓLO PIENSE...

¿Cree usted que las pruebas se pueden realizar de una manera justa y sin sesgos?

Supuesto 7: Las pruebas y la evaluación benefician a la sociedad

A primera vista, la idea de un mundo desprovisto de pruebas y evaluaciones parece seductora, en especial desde la perspectiva de un estudiante apurado preparándose para una semana de exámenes de fin de semestre. Sin embargo, un mundo sin pruebas sería más parecido a una pesadilla que a un sueño. En semejante mundo, las personas se presentarían como cirujanos, constructores de puentes, pilotos de avión, sin importar su preparación, habilidad o credenciales profesionales. En un mundo sin pruebas u otros procedimientos de evaluación, el personal sería contratado en base en el nepotismo, en vez de por méritos documentados. En un mundo sin pruebas, los profesores y administradores de escuelas colocarían a los niños de manera arbitraria en diferentes tipos de clases especiales tan sólo porque ahí es donde supondrían que pertenecen los niños. En un mundo sin pruebas, existiría una gran necesidad de instrumentos que diagnosticaran dificultades educativas en lectura y matemáticas y que apuntaran el camino a un remedio. En un mundo sin pruebas, no existirían instrumentos para diagnosticar y señalar áreas de tratamiento para un impedimento neuropsicológico. En un mundo sin pruebas, para el ejército no existiría una manera práctica de seleccionar a tantos reclutas teniendo en cuenta tantas variables clave.

Al considerar las muchas decisiones significativas que se fundamentan en pruebas y procedimientos de evaluación, podemos de manera fácil apreciar la necesidad de pruebas, en especial de las buenas pruebas. Y eso, por supuesto, origina una pregunta importante...

SÓLO PIENSE...

¿En qué forma un mundo sin pruebas u otros procedimientos de evaluación sería diferente al mundo actual?

¿Qué es una “buena prueba”?

Es obvio que los criterios para una buena prueba deberían incluir instrucciones claras para su aplicación, calificación e interpretación. Una ventaja extra sería que la prueba ofreciera economía con respecto al tiempo que toma administrar, calificar e interpretar la misma. Más que nada, una buena prueba sería la que mide lo que pretende medir.

Más allá de la simple lógica, existen criterios técnicos que los profesionales de la evaluación utilizan para calificar la calidad de las pruebas y otros criterios de valoración. Los evaluadores a menudo hablan de la *solidez psicométrica* de las pruebas, de la cual se desprenden dos aspectos clave que son la *confiabilidad* y la *validez*.

Confiabilidad

Una buena prueba o, de modo más general, una buena herramienta o procedimiento de evaluación, es confiable. Como se explicará en el capítulo 5, el criterio para la confiabilidad está relacionado con la consistencia de una herramienta de medición; es decir, la precisión con la que la prueba mide y el grado en que se presenta el error en estas mediciones. En teoría, la herramienta de medición perfectamente confiable mide consistentemente siempre de la misma manera.

Para ejemplificar la confiabilidad, visualice tres básculas digitales denominadas como A, B y C. Para determinar si son herramientas confiables de medición, utilizaremos un lingote de oro de 1 libra, certificada por los expertos de que en efecto pesa una libra, sin ninguna fracción de onza más ni menos. Ahora, dejemos que comiencen las pruebas.

Al pesar varias veces el lingote de una libra con la báscula A, se registra una lectura de 1 libra cada vez. Sin duda alguna, la báscula A es una herramienta confiable de medición. En la báscula B, al pesar varias veces el lingote con ella, se obtiene una lectura de 1.3 libras. ¿Es confiable esta báscula? Por supuesto que lo es. Es posible que no sea preciso de manera consistente por tres décimas de una libra, pero no se descarta el hecho de que sea confiable. Por último, en la báscula C, luego de pesar varias veces con ella el lingote, se registran distintos pesos cada vez. Una de las veces, el lingote de oro pesa 1.7 libras y en la siguiente, 0.9 libras. En resumen, los pesos registrados se encuentran por toda la escala. ¿Es confiable esta báscula? Difícilmente. Ésta no es confiable ni precisa. Contrástela con la báscula B, que tampoco fue muy precisa. Aunque imprecisa, la báscula B fue muy consistente en términos de cuánto se desviaba el peso registrado del peso verdadero. Como contraste, el peso registrado por la báscula C se desviaba del peso verdadero del lingote de una manera aleatoria.

Ya sea que midamos lingotes de oro, el comportamiento, o cualquier otra cosa, debemos evitar la medición poco confiable. Queremos estar, razonablemente, seguros de que la herramienta de medición o la prueba que estamos usando es consistente. Es decir, queremos saber si produce la misma medición numérica cada vez que se mide el mismo objeto bajo las mismas condiciones. Las pruebas psicológicas, al igual que otras pruebas e instrumentos, son confiables en varios grados. En el capítulo 5, se ofrece más información sobre el tema de la confiabilidad; por el momento, es útil saber que la confiabilidad es un elemento necesario, pero no suficiente, de una buena prueba. Además de ser confiables, las pruebas deben ser precisas de una manera razonable. En el lenguaje de la psicometría, las pruebas deben ser *válidas*.

Validez

Una prueba se considera válida para un propósito específico si en realidad mide lo que pretende medir. En el ejemplo anterior del lingote de oro, la báscula que indicó de manera consistente el peso del lingote en 1 libra, es una escala válida. De ese modo, una prueba de tiempo de reacción es válida si mide de manera precisa el tiempo de reacción. Una prueba de inteligencia es válida si en realidad mide la inteligencia. Bueno sí, pero...

Aunque existe poca controversia acerca de la definición de un término como tiempo de reacción, hay mucha controversia acerca de la definición de inteligencia. Debido a esa controversia acerca de la definición de inteligencia, la validez de cualquier prueba que pretenda medir esta

variable seguramente estará bajo el escrutinio de los críticos. Si la definición de inteligencia en la que se basa la prueba es diferente de la definición de inteligencia de otras pruebas aceptadas, entonces la prueba puede estar condenada a no medir lo que pretende medir.

Los cuestionamientos sobre la validez de una prueba pueden centrarse en las preguntas que de manera colectiva constituyen la prueba. ¿Los reactivos representan una muestra adecuada del rango de áreas que deben muestrearse en una prueba para medir el constructo de una manera adecuada? Los reactivos individuales también estarán bajo el escrutinio en una investigación sobre la validez de una prueba. ¿De qué manera las preguntas individuales aumentan o disminuyen la validez de la prueba? La validez de la prueba también debe ser cuestionada en aspectos relacionados con la interpretación de los resultados. ¿Qué dicen estas puntuaciones sobre el constructo señalado? ¿De qué manera se relacionan las puntuaciones altas de la prueba con el comportamiento del evaluado? ¿De qué manera se relacionan las puntuaciones bajas? ¿De qué manera las puntuaciones de esta prueba se relacionan con puntuaciones de otra prueba que pretenden medir el mismo constructo? ¿De qué manera las puntuaciones de esta prueba se relacionan con puntuaciones de otras pruebas que pretenden medir tipos opuestos de constructos?

Cabría esperar que la puntuación de una persona en una prueba válida que mida introversión esté inversamente relacionada con la puntuación de esa misma persona en una prueba válida que mida extroversión; es decir, mientras más alta sea la puntuación en la prueba de introversión, más baja será la puntuación de la prueba de extroversión y viceversa. Como se verá en el capítulo 6, cuando se explique con mayor detalle la validez, pueden surgir preguntas relacionadas con la validez de una prueba particular en cada etapa de la elaboración de una prueba. Desde su desarrollo inicial, hasta la etapa de uso con miembros de diferentes poblaciones, los profesionales de la evaluación pueden formularse preguntas respecto al grado en el que una prueba está midiendo lo que pretende medir.

SÓLO PIENSE...

¿Por qué puede una prueba mostrar ser válida para su uso con un propósito particular con los miembros de una población y no ser válida para su utilización con el mismo propósito, pero con los miembros de otra población?

Otras consideraciones

Una buena prueba es aquella que los examinadores capacitados pueden administrar, calificar e interpretar con un mínimo de dificultad. Una buena prueba es aquella que es útil, una que produzca resultados procesables que al final beneficie a quienes la responden, de manera individual y a la sociedad en general. En el apartado “Poniendo a prueba las pruebas” existen varias y diferentes maneras de evaluar cómo es en realidad una buena prueba (véase *Psicometría cotidiana*).

Si el propósito de una prueba es comparar el desempeño del evaluado con el de otros evaluados, una buena prueba sería aquella que contenga *normas* adecuadas. También conocidos como *datos normativos*, las normas proporcionan un estándar con el cual se pueden comparar los resultados de medición. A continuación se explorará el importante tema de las normas con mayor detalle.

Normas

La **evaluación con normas de referencia** consiste en un método de evaluación y una manera de derivar significado de las puntuaciones de las pruebas al evaluar la puntuación individual de un evaluado y compararla con las puntuaciones de un grupo de evaluados. En este enfoque, el significado de una puntuación individual en una prueba se entiende al relacionarla con otras puntuaciones en la misma prueba. Un objetivo común de las pruebas con normas de referencia es proporcionar información acerca de la posición o el rango que ocupa un evaluado con respecto a un grupo de comparación.

Poniendo a prueba las pruebas

Para los expertos en el campo de las pruebas y la evaluación, surgen ciertas preguntas de manera casi reflexiva al evaluar una prueba o una técnica de medición. Quizá usted aún no sea un experto en medición, pero el hecho de considerar las siguientes preguntas es el primer paso significativo para ir en esa dirección. Intente pensar en esas preguntas cuando encuentre una mención acerca de las diversas pruebas en este libro, en otros libros y artículos de revistas especializadas y en la vida. Estas preguntas le ayudarán a evaluar la solidez psicométrica de las pruebas y otras herramientas de medición.

¿Por qué usar este instrumento o método en particular?

Es común que se dé una elección de instrumentos de medición cuando es necesario medir una variable psicológica o educativa particular, y el aplicador de la prueba debe, por tanto, escoger entre varias herramientas disponibles. La información publicada, como los catálogos de pruebas, manuales de pruebas y reseñas de pruebas, pueden ser de gran valor para decidir si utilizar o no una prueba en particular. Las fuentes de información no publicadas, como la que se obtiene al escribirle de manera directa al creador o editor de una prueba, también es una posibilidad. Algunas de las preguntas anticipadas del aplicador de una prueba se relacionan con los objetivos de la prueba y la cualidad de haber entre esos objetivos y los objetivos de la prueba o la evaluación. ¿Qué tipo de información resultará de la aplicación de esta prueba? ¿Existen formas alternativas de esta prueba y, si es así, cómo pueden utilizarse? ¿Cuánto tiempo toma administrar esta prueba? ¿Cuál es el rango de edad recomendado para esta prueba y qué nivel de lectura se requiere? ¿Cómo será aplicada la información resultante para responder las preguntas originalmente referida a la prueba? ¿Qué tipos de decisiones pueden tomarse o no con base en la información que surge a partir del uso de esta prueba? ¿Qué otra información será requerida para responder de manera adecuada la pregunta originalmente referida a la prueba?

¿Se ha publicado alguna guía para el uso de esta prueba?

Los profesionales de la medición están al tanto de las guías que han sido publicadas por asociaciones profesionales y organizaciones relacionadas con el uso de pruebas y técnicas de medición. Por ejemplo, suponga que usted es un psicólogo a quien se le ha pedido que proporcione ayuda en un juzgado en la decisión sobre la custodia de un niño. De manera más específica, se le ha pedido su opinión profesional sobre la capacidad parental de uno de los progenitores. ¿De qué manera procedería? Muchos psicólogos que realizan esas evaluaciones utilizan pruebas psicológicas como parte del proceso de valoración. Sin embargo, el psicólogo que hace esa evaluación está, o debe estar, consciente de las guías publicadas por el Comité de Prácticas y Estándares Profesionales de la Asociación Psicológica

Estadounidense (APA, 1994a). Estas guías describen tres tipos de evaluaciones relevantes sobre la decisión de la custodia de un(a) niño(a): 1) evaluación de la capacidad de ser padre, 2) evaluación de las necesidades psicológicas y de desarrollo del niño(a) y 3) evaluación del ajuste adecuado entre la capacidad del progenitor y las necesidades del niño(a). De manera clara, la evaluación de uno de los padres, incluso de los dos, no le ofrece al evaluador información suficiente para expresar una opinión sobre la custodia. Únicamente una evaluación de los padres o de otras personas que busquen obtener la custodia del niño(a) y de la adecuación entre las necesidades y las capacidades de cada una de las partes puede ofrecer información relevante para una opinión instruida sobre la custodia del niño(a).

Existen varias pruebas psicológicas y procedimientos de medición que se utilizan para obtener información sobre la capacidad de ser padre (Holden & Edwards, 1989; Lovejoy *et al.*, 1999; Toulaitos *et al.*, 1991). Algunos instrumentos utilizados de manera común son las Escalas para la Evaluación de custodia para Padres, de Ackerman-Schoendorf. Las Escalas perceptuales de Bricklin, la Prueba de percepción de relaciones de Bricklin, el Inventario de abuso infantil potencial (CAP, por sus siglas en inglés) y la Lista de indicadores de estrés parental (PSI, *idem*). Sin importar qué prueba se haya empleado, el psicólogo utilizará otras fuentes de información, como entrevistas, observación conductual y análisis de documentos, en la evaluación de la capacidad de ser padres. Esto es consistente con la práctica profesional aceptada y con las guías publicadas que promueven que los psicólogos utilicen “múltiples métodos para la recolección de datos” (APA, 1994a, p. 679). Los datos de múltiples fuentes pueden ofrecer un soporte variado para una opinión, conclusión, o recomendación profesional.

El área de la evaluación acerca de la custodia de un(a) niño(a) proporciona una ilustración útil de por qué el mero conocimiento de la evaluación de una prueba no provee de una manera adecuada al evaluador para evaluar. Quienes aceptan hacerse cargo de una evaluación sobre la custodia de un(a) niño(a) deben trabajar de manera familiar no sólo con las herramientas específicas que utilizan y la literatura actual sobre la evaluación psicológica en general, sino también con las leyes siempre cambiantes y las guías profesionales aplicables a esas evaluaciones, así como con la literatura actual en áreas como el desarrollo del niño(a), dinámica familiar y divorcio. Ejecutar una evaluación competente de la custodia de un niño no es una cuestión simple, y existen muchos medios publicados diseñados para ayudar a los profesionales que deseen involucrarse más en este tipo de trabajo (por ejemplo, Ackerman, 1995; Bushard & Howard, 1994; Schultz *et al.*, 1989; Stahl, 1995).

¿Es confiable este instrumento?

Antes, le hemos introducido al concepto psicométrico de confiabilidad y le hemos señalado que tiene que ver con la

consistencia de la medición. La confiabilidad en la medición no siempre es una cuestión directa. Como ejemplo, considere una de las pruebas que puede ser utilizada en la evaluación de la capacidad de ser padre. Las Escalas perceptuales de Bricklin, (BPS, por sus siglas en inglés); Bricklin, 1984). La BPS fue diseñada para explorar la percepción que un niño tiene de su padre y de su madre. Una medida de un tipo de confiabilidad, llamada *confiabilidad test-retest* indicaría qué tan consistente es la percepción de un niño acerca de su padre y de su madre a través del tiempo. Sin embargo, el manual de la prueba BPS no contiene datos de confiabilidad porque, como lo indicó Bricklin (1984, p. 42), “no existen razones para esperar que las mediciones reportadas aquí muestren algún grado particular de estabilidad, puesto que éstas pueden variar de acuerdo con los cambios en las percepciones de los niños”. Tal aseveración no ha evitado que otros (como Speth, 1992) exploren la confiabilidad test-retest de la prueba del BPS. Pero sea aceptada o no la afirmación de Bricklin en relación con la necesidad de confiabilidad en los datos, estas opiniones ilustran la complejidad de las preguntas sobre confiabilidad, así como la necesidad de múltiples fuentes de datos para fortalecer los argumentos relacionados con la confirmación o el rechazo de una hipótesis.

¿Es válido este instrumento?

La validez, como usted ha aprendido, se refiere al grado en que una prueba mide lo que pretende medir. Igual que en el caso de la confiabilidad, las cuestiones relacionadas con la validez de una prueba pueden ser complejas y estar coloreadas con tonos grises más que en blanco o negro. Por ejemplo, aunque los datos de una prueba como la BPS fueran válidos para el propósito de obtener las percepciones de los niños con respecto a sus padres, los datos no serían necesariamente válidos como la única fuente sobre la cual se basa una opinión relativa a la custodia del niño (Brodzinsky, 1993). En este contexto, Heinze y Grisso (1996) lamentaron lo que ellos vieron como una tendencia de los expertos a confiar en los datos concernientes a las percepciones acerca de qué tan convenientes son los padres:

Las cuestiones acerca de la conveniencia de los padres no pueden responderse sin hacer referencia a las características, necesidades y demandas del niño específico que tiene la necesidad de ser cuidado. Sospechamos que ningún instrumento que sólo evalúe a los padres (ya sea mediante las percepciones de los niños o por medio de observaciones de los mismos padres) nunca alcanzará los estándares científicos básicos para hacer juicios acerca de “los padres preferidos” o para hacer comparaciones entre los padres, que justificarían la sugerencia de que las capacidades de un padre son más deseables que las del otro (p. 310).

Los instrumentos diseñados para medir variables tales como las reacciones de estrés parental (como el PSI) y el potencial para

el abuso de menores (como el CAP), han producido datos valiosos que podrían ser muy útiles a la corte cuando ésta evalúa todos los elementos necesarios para un juicio informado sobre la custodia de un niño (Heinze y Grisso, 1996). Sin embargo, en la corte y más allá, las preguntas concernientes a cuál prueba o combinación de pruebas es válida, para qué propósito y bajo qué condiciones, algunas veces estimula el debate y la controversia.

¿Qué inferencias se pueden hacer de manera razonable a partir de la calificación de esta prueba, y qué tan generalizables son los hallazgos?

La *raison d'être* (o “razón de ser”) de muchas pruebas psicológicas y otras herramientas de evaluación psicológica es hacer inferencias acerca del comportamiento. Por tanto, en la evaluación de una prueba resulta crítico considerar las inferencias que se pueden hacer de manera razonable como un resultado de administrar esa prueba. ¿Aprenderemos algo de qué tan dispuestos están los niños para entrar al primer grado? ¿Qué tan preparado está un estudiante para el primer año de universidad en una institución particular? ¿Alguien puede ser peligroso para sí mismo o para otros? Estas preguntas representan sólo una pequeña muestra de todas las preguntas críticas cuyas respuestas pueden ser inferidas sobre la base de las puntuaciones de pruebas y otros datos derivados de las distintas herramientas de evaluación.

Las consideraciones relativas a cuán generalizables son los hallazgos están relacionadas de manera íntima con las consideraciones acerca de las inferencias que pueden ser realizadas. De su lectura a nuestro estudio de las normas, usted sabe que los datos normativos proporcionan un contexto en el cual es posible interpretar y generalizar los resultados de la prueba. Con esto como base, considere que la muestra para la Lista de Indicadores de Estrés Parental (PSI) consistió en 2 633 padres escogidos principalmente del estado de Virginia. La mayoría de los niños en la muestra eran menores a 5 años de edad y caucásicos. ¿Usted podría preguntar qué tan generalizables serían los hallazgos de la aplicación del PSI respecto a los padres no caucásicos? Si esta pregunta se le ocurrió a usted, tiene buena compañía (por ejemplo, vea Krauss, 1993; McBride, 1989; Teplin *et al.*, 1991; Younger, 1991). A propósito, desde su publicación el PSI se ha adaptado para incluir padres de diferentes culturas (Abidin, 1990; Beebe *et al.*, 1993; Black *et al.*, 1993).

Además de la aplicabilidad de las normas, otros factores distintos pueden dar lugar a preguntas acerca de la generalizabilidad de una prueba o de la aplicación específica de una prueba. La redacción de las preguntas de la prueba puede, de algún modo, sesgar las puntuaciones. Por ejemplo, si todos los factores se conservan igual, el BPS se puede sesgar hacia

(continúa)

Poniendo a prueba las pruebas (*continuación*)

percepciones más favorables para las madres. Padres y madres pueden tener puntuaciones similares en todas las subpruebas excepto en la subescala de apoyo, donde las madres tienden a tener puntuaciones más altas (Heinze y Grisso, 1996).

La pregunta de qué tan generalizables son los hallazgos puede surgir también en relación con la administración particular de una prueba. La mayoría de las pruebas publicadas tienen instrucciones muy específicas que los aplicadores de la prueba —o una computadora, si la prueba es aplicable por una

computadora— deben seguirse al pie de la letra. Si la realización de la prueba se pone en riesgo de algún modo, ya sea por diseño, negligencia, o cualquier otra razón, los datos derivados de la prueba estarán también en peligro de no ser generalizables.

Y así, aunque usted aún no sea un experto en medición, ahora está armado con un conocimiento práctico de los tipos de preguntas que hacen los expertos cuando evalúan cualquier prueba o técnica de medición.

Norma en singular se usa en la literatura académica para referirse al comportamiento que es usual, promedio, normal, estándar, esperado o típico. La referencia a una variedad particular de norma puede especificarse por medio de modificadores como *edad*, como en *norma de edad*. *Normas* es la forma plural de norma, como en el término *normas de género*. En un contexto psicométrico, **normas** son los datos de desempeño en una prueba de un grupo particular de evaluados las cuales han sido diseñadas para utilizarse como referencia en la evaluación e interpretación de puntuaciones de prueba individuales. Como se usa en esta definición, el “grupo particular de evaluados” puede definirse con amplitud (por ejemplo, “una muestra representativa de la población adulta en Estados Unidos”) o en forma más limitada (por ejemplo, “las internas del Hospital Comunitario del Bronx con un diagnóstico primario de depresión”). Una **muestra normativa** es el grupo de personas cuyo desempeño en una prueba particular se analiza como referencia para evaluar el desempeño individual de los evaluados.

Ya sea que tengan un alcance amplio o limitado, los miembros del grupo serán típicos con respecto a alguna característica o características de las personas para quienes se diseñó la prueba particular. La aplicación de la prueba a esta muestra representativa de evaluados produce una distribución (o distribuciones) de puntuaciones. Estos datos constituyen las normas para la prueba y de manera típica se utilizan como fuente de referencia para evaluar y poner en contexto las puntuaciones obtenidas en la prueba por los evaluados de manera individual. Los datos pueden estar en forma de puntuaciones crudas o puntuaciones convertidas.

El verbo *normalizar*, al igual que términos relacionados como **normalización**, se refiere al proceso de derivar las normas. La *normalización* puede modificarse para describir un tipo particular de derivación de una norma. Por ejemplo, *normalización racial* es la controvertida práctica de normalizar con base en la raza o etnia. La **normalización racial** fue una vez compromiso de algunas oficinas de gobierno y organizaciones privadas, y la práctica resultó en el establecimiento de diferentes puntuaciones para contratar por grupo cultural. Los miembros de un grupo cultural tendrían que obtener cierta puntuación para ser contratados, mientras que los miembros de otro grupo cultural tendrían que obtener una puntuación distinta. Aunque en un inicio se instituyó en el servicio de objetivos de acción afirmativa, (Greenlaw & Jensen, 1996), la práctica fue declarada ilegal por la Ley de los Derechos Civiles de 1991. La ley dejó sin aclarar algunos aspectos, no obstante, incluyendo “si, y bajo qué circunstancias, en el desarrollo de un procedimiento de evaluación es legal ajustar el contenido de los reactivos para minimizar las diferencias de grupo” (Kehoe & Tenopir, 1994, p. 291).

La normalización de una prueba, en especial con la participación de una muestra nacional normativa representativa, puede ser un propósito muy costoso. Por esta razón, algunos manuales de prueba proporcionan lo que se conoce de manera variada como **normas de usuario** o **normas de programa**, que “consisten de estadísticas descriptivas basadas en un grupo de personas que responden una prueba en un periodo determinado, en lugar de normas obtenidas con métodos de muestreo formales” (Nelson, 1994, p. 283).

Estandarización, muestreo y normalización

Estandarización El proceso de aplicar una prueba a una muestra representativa de personas que la responden con el propósito de establecer normas se conoce como **estandarización**. Se dice que una prueba está *estandarizada* cuando tiene procedimientos definidos en forma clara para su administración y calificación, lo que incluye datos normativos. Pero, para entender cómo se obtienen las normas es necesario comprender el muestreo.

Muestreo En el proceso de desarrollo de las pruebas, quien las elabora ha especificado algún grupo como la población para la cual se ha diseñado la prueba. Esta población es el universo completo o conjunto de individuos con al menos una característica observable en común. *La característica o características observables comunes podrían variar desde estudiantes del último año de bachillerato que aspiran a asistir a la universidad hasta los 16 niños y niñas en el centro de atención diurna de la señora Pérez, o todas las amas de casa con la responsabilidad primaria de hacer compras domésticas que han adquirido medicamentos que no requieren receta médica para el dolor de cabeza durante los últimos dos meses.*

Para obtener una distribución de las puntuaciones, quien elabora la prueba podría aplicarla a cada persona en la población objetivo; y si la población total a la que se dirige consiste en algo así como los 16 niños y niñas en el centro de atención diurna de la señora Pérez, sería posible y factible administrar la prueba a cada uno de los miembros de dicha población. Sin embargo, con pruebas elaboradas para ser usadas en poblaciones numerosas o de gran amplitud, por lo general, es imposible, poco práctico o tan sólo demasiado costoso aplicar la prueba a todos, además de no ser necesario.

Quien elabora la prueba puede obtener una distribución de respuestas al aplicarla a una **muestra** de la población —una porción del universo de personas considerada representativa de la población entera. El tamaño de la muestra podría ser tan pequeño como una persona, aunque conformen la medida en que el tamaño de la muestra se aproxima al tamaño de la población, disminuyen las posibles fuentes de error como resultado de un tamaño de muestra insuficiente. El proceso de seleccionar la parte del universo definida como representativa de toda la población se conoce como **muestreo**.

Los subgrupos dentro de una población definida pueden diferir con respecto a algunas características, y en ocasiones es esencial tener estas diferencias representadas de manera proporcional en la muestra. Así, por ejemplo, si usted diseñara una prueba de opinión pública y desea hacer un muestreo de las opiniones de los residentes de Manhattan con este instrumento, sería deseable incluir en su muestra personas que representen diferentes subgrupos (o estratos) de la población, como negros, blancos, asiáticos, otros que no son blancos, hombres, mujeres, personas pobres, de clase media, ricas, profesionales, gente de negocios, oficinistas, obreros calificados y no calificados, desempleados, amas de casa, católicos, judíos, miembros de otras religiones, etcétera —todos en proporción a la ocurrencia de estos estratos de la población que reside en la isla de Manhattan—. Este muestreo, denominado **muestreo estratificado**, ayudaría a prevenir el sesgo en el muestreo y al final ayudaría en la interpretación de los resultados. Si dicho muestreo fuera *aleatorio* (es decir, si cada miembro de la población tuviera la misma oportunidad de ser incluido en la muestra), entonces el procedimiento se denominaría **muestreo aleatorio estratificado**.

SÓLO PIENSE...

El muestreo realmente aleatorio es relativamente raro. En su opinión, ¿por qué ocurre esto?

Otros dos tipos de procedimientos de muestreo son el *muestreo intencional* y el *muestreo incidental*. Si alguna muestra se selecciona en forma arbitraria, pues consideramos que será representativa de la población, la muestra seleccionada se denominará **intencional**. Los fabricantes de productos usan con frecuencia el muestreo intencional cuando prueban el atractivo de un nuevo producto en una ciudad o mercado y luego hacen suposiciones sobre cómo se vendería a escala nacional dicho producto. Por ejemplo, el fabricante podría probar un artículo en un mercado como Cleveland debido a que, en base a la experiencia con esta particular mercancía, “como va Cleveland, así va toda la nación”. El peligro de usar esta muestra intencional es que la muestra, en este caso los residentes de Cleveland, puede ya no ser representativa de la nación. De manera alterna, esta muestra puede simplemente no ser representativa de las preferencias nacionales con respecto al producto particular cuyo mercado se está probando.

Con frecuencia, las decisiones del evaluador respecto al muestreo terminan por enfrentar lo que es ideal frente a lo que es práctico. Por ejemplo, sería ideal utilizar como muestra en un experimento a 50 jefes ejecutivos de cualquiera de las compañías de *Fortune 500* (esto es, las 500 compañías con ingresos más altos). Sin embargo, las condiciones podrían indicar que únicamente es práctico utilizar sólo 50 voluntarios reclutados de la cámara local de comercio. Esta importante distinción entre lo que es *ideal* y lo que es *práctico* en el muestreo trae a discusión lo que hemos referido como una *muestra incidental* o *muestra de conveniencia*.

Cuando los autores pensamos en este tipo de muestra, nos acordamos del viejo chiste del borracho que busca de noche bajo el farol un dinero que perdió; puede ser que no lo haya perdido allí, pero lo busca en ese lugar tan sólo porque ahí hay luz. Como el borracho que busca su dinero bajo el farol, algunas veces, un investigador puede emplear una muestra que no sea necesariamente la más apropiada sino, más bien, la más conveniente. A diferencia del borracho, el investigador que emplea este tipo de muestra no lo hace como resultado de un juicio deficiente, sino debido a limitaciones presupuestales u otras restricciones. Una **muestra incidental** o **muestra por conveniencia** es una que es conveniente o que está disponible para su uso. Puede ser que usted haya sido parte de un muestreo incidental si alguna vez ha sido colocado en un grupo de experimentación con estudiantes de introducción a la psicología. No es que los estudiantes en esas reservas de sujetos sean necesariamente los más apropiados para los experimentos, es sólo que son los más disponibles. La generalización de hallazgos hechos con respecto a muestras incidentales debe hacerse con precaución.

Si las muestras incidentales o por conveniencia fueran clubes, éstos no se considerarían muy exclusivos. En contraste, existen muchas muestras que son exclusivas, en un sentido, puesto que contienen muchos criterios de exclusión. Por ejemplo, considere el grupo de niños y adolescentes que sirvieron como muestra normativa para la Escala de inteligencia para niños de Wechsler-IV (WISC-IV, Wechsler, 2003). La muestra se seleccionó para reflejar variables demográficas clave, representativas de la población de Estados Unidos de acuerdo con los datos del último censo disponible. No obstante, algunas personas fueron excluidas de participar. Por ejemplo, se excluyeron las personas que habían participado en alguna prueba de medición de la inteligencia en los seis meses previos a la estandarización. Asimismo, se descartaron las personas que no hablaban un inglés fluido, que tuvieran pocas habilidades verbales o fueran poco comunicativas, así como personas con ciertas discapacidades. De manera más específica se excluyeron los miembros de los siguientes grupos:

- Personas con problemas visuales no corregidos o con limitaciones auditivas.
- Personas con discapacidad en los miembros superiores que afectara el desempeño motor.
- Personas que se encontraran recluidas en un hospital o en una institución mental o psiquiátrica.
- Personas que en la actualidad estuvieran tomando algún medicamento que pudiera afectar su desempeño en la prueba.
- Personas previamente diagnosticadas con alguna enfermedad o condición física que pueda afectar su desempeño en la prueba (como apoplejía, epilepsia o meningitis).

Quienes desarrollaron el WISC-IV reportaron que “una proporción representativa de niños del grupo especial de estudios se agregó a la muestra normativa (aproximadamente 5.7%) para representar de manera precisa la población de niños que asisten a la escuela” (Wechsler, 2003, p. 23). En el capítulo 9 se dan más detalles sobre cómo se normalizaron ésta y otras pruebas de inteligencia ampliamente utilizadas.

Desarrollo de normas para una prueba estandarizada Después de obtener una muestra, quien elabora la prueba la administra de acuerdo con el conjunto estándar de instrucciones con las que será utilizado posteriormente. El diseñador de la prueba también proporcionará un escenario para quienes la responden, que será el escenario recomendado para aplicarla. Esto puede ser tan simple como asegurarse de que el salón esté en silencio y bien iluminado, o tan complejo como proporcionar un conjunto específico de juguetes que serán usados para probar las habilidades cognitivas de un bebé. El establecer un conjunto estándar de instrucciones y condiciones bajo las cuales se administre la prueba hace que las puntuaciones de la muestra normativa sean más comparables con las puntuaciones de quienes respondan la prueba en el futuro. Por ejemplo, si una prueba de capacidad de concentración se administra a una muestra normativa en verano, con las ventanas abiertas, con personas podando el césped y discutiendo respecto a si los setos necesitan recortarse, es probable que la muestra normativa no se concentre bien. Si después, una persona completa la prueba de concentración bajo condiciones de quietud y comodidad, esa persona podrá hacerlo mucho mejor que el grupo normativo, lo que redundará en una puntuación estándar alta. Esta puntuación alta no sería muy útil para entender la capacidad de concentración de quien responde la prueba porque reflejará las condiciones tan distintas bajo las cuales fue respondida la prueba. Este ejemplo ilustra cuán importante es que la muestra normativa responda la prueba bajo un conjunto estándar de condiciones, las cuales se repetirán después con la mayor similitud posible cada vez que se aplique la prueba.

Luego de que se han reunido y analizado todos los datos de la prueba, el diseñador de la misma describirá tales datos mediante el uso de estadísticas descriptivas que incluyen medidas de tendencia central y variabilidad. Además, le incumbe al elaborador de la prueba proporcionar una descripción precisa de la muestra de estandarización en sí. La buena práctica dicta que las normas se desarrollen con datos derivados de un grupo de personas que se supone serán representativas de la gente que realice la prueba en el futuro. Con la intención de ayudar a los futuros aplicadores de la prueba, se alienta a quien elabora las pruebas a “describir la o las poblaciones representadas por cualesquiera norma o grupos de comparación, las fechas en que se recopilaron los datos y el proceso usado para seleccionar las muestras de personas que respondieron la prueba” (*Code of Fair Testing Practices in Education*, 1988, p. 3).

En la práctica, las descripciones de muestras normativas varían en forma amplia en los detalles. No es sorprendente que los autores de las pruebas deseen presentarlas bajo la luz más favorable posible. En concordancia, los defectos en el procedimiento de estandarización, o en cualquier otra parte del proceso de elaboración de la prueba, pueden pasarse por alto o bien ignorarse por completo en el manual de la prueba. En ocasiones, aunque la muestra sea definida de manera escrupulosa, es cuestionable el grado de generalizabilidad de las normas a un grupo o individuo particular. Por ejemplo, una prueba normalizada en forma meticulosa para niños en edad escolar que residen dentro del distrito escolar de Los Ángeles puede ser relevante sólo en grado menor para los niños en edad escolar que residen dentro del distrito escolar de Dubuque, Iowa. ¿Cuántos niños en la muestra de estandarización hablaban inglés? ¿Cuántos eran de origen hispano? ¿En qué difiere el plan de estudios de la escuela primaria de Los Ángeles del plan de estudios de Dubuque? Éstos son los tipos de preguntas que deben plantearse antes de decidir que las normas de Los Ángeles son generalizables a los niños de Dubuque. Los manuales de las pruebas en ocasiones suministran a los administradores de pruebas lineamientos para establecer *normas locales*, una de las múltiples formas en que pueden clasificarse las normas. (Las cuales serán revisadas más adelante.)

Antes de continuar es necesario hacer una anotación respecto a la terminología. Cuando las personas en la muestra normativa son las mismas sobre las cuales se estandarizó la prueba, las frases *muestra normativa* y *muestra de estandarización* a menudo se utilizan de manera intercambiable. Sin embargo, cada vez se desarrollan nuevas normas para pruebas estandarizadas para

grupos específicos de evaluados algún tiempo después de la estandarización original. Esto es, la prueba permanece estandarizada con base en los datos de la muestra de estandarización original; sólo se desarrollan nuevos datos normativos con base en una aplicación de la prueba a una nueva muestra normativa. En esta nueva muestra normativa pueden estar incluidos grupos de personas que estuvieron subrepresentados o no tuvieron ninguna representación en los datos originales de estandarización. Por ejemplo, si desde que se realizó la estandarización original hubiera habido una gran inmigración de potenciales evaluados provenientes de la República Checa, la nueva muestra normativa debería incluir una proporción de ciudadanos checos. En tal escenario, la muestra normativa para las nuevas normas no será idéntica a la prueba de estandarización, y resultaría inexacto emplear los términos *muestra de estandarización* y *muestra normativa* de manera intercambiable.

Tipos de normas

Algunas de las muchas formas diferentes en que se pueden clasificar las normas son las siguientes: *normas de edad*, *normas de grado*, *normas nacionales*, *normas nacionales ancladas*, *normas locales*, *normas de un grupo de referencia fijo*, *normas de subgrupo* y *normas de percentil*. Iniciaremos con una explicación detallada del término percentil debido a que las normas para muchas pruebas son expresadas como normas de percentil. Las *normas de percentil* son los datos crudos de una muestra de estandarización de una prueba convertidos a una forma percentil.

Percentiles En la exposición de la mediana, se vio que una distribución podía dividirse en cuartiles donde la mediana era el segundo cuartil (Q_2), el punto en el que se encuentra, o por debajo del cual está, 50% de las puntuaciones y el restante 50% se encuentra por encima. En lugar de dividir una distribución de puntuaciones en cuartiles, se podría desear dividir la distribución en *deciles*, o diez partes iguales. De manera alternativa, se podría dividir una distribución en 100 partes iguales, 100 *percentiles*. En una distribución así, el percentil x -ésimo es igual a la puntuación en o debajo de la cual se encuentra el $x\%$ de las puntuaciones. Por tanto el percentil decimoquinto es la puntuación en, o debajo de, la cual cae 15% de las puntuaciones en la distribución; el percentil nonagesimonoveno es la puntuación en o debajo de la cual cae 99% de las puntuaciones en la distribución. Si 99% de una muestra de estandarización particular respondió menos de 47 preguntas en una prueba de manera correcta, entonces podríamos decir que una puntuación cruda de 47 corresponde al percentil 99 en esta prueba. Puede verse que un percentil es una clasificación que transmite información sobre la posición relativa de una puntuación dentro de una distribución de puntuaciones.

Un **percentil** es una expresión del porcentaje de personas cuya puntuación se encuentra por debajo de una puntuación cruda particular. Una descripción más familiar del desempeño en una prueba, el concepto de *porcentaje correcto*, debe distinguirse del concepto de un percentil. Un percentil es una puntuación convertida que se refiere a un porcentaje de evaluados. El **porcentaje correcto** se refiere a la distribución de puntuaciones crudas; más específicamente, el número de preguntas que fueron respondidas en forma correcta multiplicado por 100 y dividido entre el número total de preguntas.

Como los percentiles se calculan con facilidad, son una forma popular de organizar los datos de una prueba, ya sean datos de la muestra de estandarización o de otra índole. Además, son muy adaptables para su uso con una amplia gama de pruebas. Un problema con el uso de los percentiles con puntuaciones distribuidas de manera normal es que las diferencias reales entre las puntuaciones crudas pueden minimizarse cerca de los extremos de la distribución y exagerarse en medio de ésta. El problema de distorsión incluso puede ser peor con datos muy asimétricos (sesgados). En la distribución normal, la frecuencia más alta de puntuaciones crudas ocurre en medio. Siendo éste el caso, las diferencias entre todas aquellas puntuaciones que se agrupan en el centro en realidad podrían ser bastante pequeñas, no obstante, hasta la más pequeña diferencia aparecerá como desigualdad en percentiles. En los extremos de las distribuciones sucede lo contrario, donde las diferencias entre puntuaciones crudas pueden ser grandes, aunque no habría forma de saber esto a partir de las diferencias relativamente pequeñas en los percentiles.

Normas de edad También conocidas como **puntuaciones equivalentes de edad**, las **normas de edad** indican el desempeño promedio en diferentes muestras de quienes responden la prueba que tenían diversas edades en el momento en que se aplicó la prueba. Si la medición bajo consideración es la estatura en centímetros, por ejemplo, sabemos que las “puntuaciones” (estaturas) de los niños se incrementarán en forma gradual en diferente medida como una función del crecimiento hasta la mitad o al final de la adolescencia. Con el envejecimiento en Estados Unidos, se ha incrementado el interés por el desempeño en varios tipos de pruebas psicológicas, de manera particular las pruebas neuropsicológicas, como una función de la edad avanzada.

Las tablas de normas de edad construidas en forma meticulosa para características físicas como la estatura disfrutaban de una extensa aceptación y de hecho no son controversiales. Sin embargo, éste no es el caso respecto a las tablas de normas de edad para características psicológicas como la inteligencia. Durante muchos años los psicólogos han hecho referencia a las “edades mentales” de quienes responden pruebas. Se decía que el niño de cualquier edad cronológica cuyo desempeño en una prueba válida de capacidad intelectual indicaba que tenía una capacidad intelectual similar a la del niño promedio de alguna otra edad, tenía la edad mental de la norma de grupo en la que caía su puntuación de prueba. El razonamiento aquí era que, sin tomar en cuenta la edad cronológica, podía esperarse que los niños con la misma edad mental leyeran el mismo nivel de material, resolvieran la misma clase de problemas matemáticos, razonaran con un nivel similar de juicio, etcétera. Pero hay quienes se han quejado de que el concepto de edad mental es demasiado amplio y que aunque un niño de 6 años de edad podría, por ejemplo, desempeñarse en forma intelectual como un niño de 12 años de edad, el de 6 años podría no asemejarse en absoluto al niño de 12 años de edad promedio desde el punto de vista social, psicológico y de otra índole. Además de estas consideraciones intuitivas, el concepto de edad mental también ha sido criticado en el aspecto técnico.³

Normas de grado Diseñadas para indicar el desempeño promedio de los evaluados en un grado escolar determinado, las **normas de grado** son desarrolladas cuando se aplica la prueba a muestras representativas de niños en un rango de niveles de grado consecutivos (de primero a sexto grados, por ejemplo). A continuación, se calcula la puntuación media o mediana para los niños en cada nivel de grado. Debido a que el año escolar comúnmente va de septiembre a junio, diez meses, las fracciones en la media o mediana son expresadas con facilidad como decimales. Por tanto, por ejemplo, un alumno de sexto grado que se desempeñe exactamente como el promedio en una prueba normalizada por grado administrada durante el cuarto mes del año escolar (diciembre) lograría una puntuación equivalente de grado de 6.4. Como las normas de edad, las normas de grado tienen una extensa aplicación en niños en edad escolar elemental, el razonamiento consiste en que los niños aprenden y se desarrollan con ritmos variables, pero en formas que en algunos aspectos son predecibles.

Un alumno de doceavo grado obtuvo una puntuación de 6 en una prueba de ortografía con normas de grado. ¿Esto significa que el estudiante tiene las mismas capacidades ortográficas que el alumno promedio que obtuvo seis de calificación? La respuesta es no. Si se interpreta con precisión, lo que este hallazgo significa es que este estudiante y un hipotético promedio de quienes obtuvieron 6 respondieron la misma fracción de reactivos en forma correcta en esa prueba. Las normas de grado no proporcionan información sobre el contenido o tipo de reactivos que un estudiante pudo o no responder en forma correcta. Quizá el uso primario de las normas de grado sea como el de un indicador conveniente, comprensible con facilidad, de la forma en que el desempeño de un estudiante se compara con el de sus compañeros de grado.

SÓLO PIENSE...

Algunos expertos en pruebas han solicitado una moratoria en cuanto al uso de puntuaciones equivalentes por grado, así como equivalentes por edad debido a que dichas puntuaciones pueden ser malinterpretadas con facilidad. ¿Cuál es su opinión sobre este tema?

3. Durante muchos años, las puntuaciones del CI (cociente intelectual) en pruebas como la Stanford-Binet eran calculadas dividiendo la edad mental (indicada por la prueba) entre la edad cronológica. El cociente luego sería multiplicado por 100 para eliminar la fracción. La distribución de las puntuaciones del CI tenía una media establecida en 100 y una desviación estándar aproximada de 16. Un niño de 12 años de edad con una edad mental de 12 tendría un CI de 100 ($12/12 \times 100 = 100$). El problema técnico aquí es que las desviaciones estándar del CI no eran constantes con la edad. A una cierta edad, un CI de 116 podría ser indicativo de un nivel de desempeño localizado a una desviación estándar por encima de la media, mientras que en otra edad un CI de 121 podría ser indicativo de un nivel de desempeño localizado a una desviación estándar por encima de la media.

Una desventaja de usar normas de grado es que sólo son útiles respecto a los años y meses de escolaridad completados. Tienen poca o ninguna aplicabilidad en niños que todavía no están en la escuela o que se encuentran fuera de ella. Las normas de edad también son limitadas a este respecto, en vista de que, para muchas pruebas, el valor de dichas normas es limitado con una población adulta.

Normas nacionales Como lo indica su nombre, las **normas nacionales** se derivan de una muestra normativa que fue representativa de la población a nivel nacional durante el tiempo en que el estudio de normalización fue realizado. En los campos de la psicología y la educación, por ejemplo, pueden obtenerse normas nacionales por medio de la prueba de grandes cantidades de estudiantes representativos de diferentes variables de interés como edad, género, grupo racial, estrato socioeconómico, ubicación geográfica (como norte, este, sur, oeste, medio oeste), y los diferentes tipos de comunidades dentro de las diversas partes del país (como rural, urbana, suburbana).

Si la prueba fue diseñada para su uso en escuelas, las normas se podrían obtener de los estudiantes en cada grado en el que se buscó fuese aplicable la prueba. Factores relacionados con la representatividad de la escuela de la cual fueron obtenidos los miembros de la muestra normativa, podrían ser criterios para incluirlos o excluirlos de la muestra. Por ejemplo, ¿la escuela a la que asiste el estudiante es pública, privada, de orientación religiosa, de orientación militar u otra? ¿Qué tan representativas son las proporciones entre alumnos y profesores en las escuelas consideradas? ¿Tiene biblioteca la escuela?, de ser así, ¿cuántos libros tiene? Éstas son sólo una muestra de los tipos de preguntas que podrían plantearse para armar una muestra de estandarización con el fin de ser usadas en el establecimiento de normas nacionales. La naturaleza precisa de las preguntas que se planteen cuando se desarrollen las normas nacionales dependerá de para quién esté diseñada la prueba y para qué fue diseñada.

Las normas de muchas pruebas diferentes pueden pretender ser consideradas en su totalidad para tener una representatividad nacional. Sin embargo, un escrutinio cuidadoso de la descripción de la prueba empleada puede revelar que la prueba difiere en muchos aspectos importantes de otras pruebas que también se consideran basadas en muestras representativas a escala nacional. Por esta razón, siempre es buena idea verificar el manual de las pruebas bajo consideración para observar con exactitud qué tan comparables son las pruebas. Existen dos preguntas importantes que deben realizar los usuarios de la prueba como consumidores de información relacionada con aquella: “¿Cuáles son las diferencias entre las pruebas bajo consideración, en términos de sus muestras normativas?” y “¿Qué tan comparables son estas muestras normativas con la muestra de evaluados en la que se usará la prueba?”

Normas nacionales ancladas Incluso la inspección más casual de los catálogos de varios editores de pruebas revelará que, con respecto a casi cualquier característica o capacidad humana, existen muchas pruebas diferentes que pretenden medir la característica o capacidad. Existen docenas de pruebas, por ejemplo, que pretenden medir la lectura. Supóngase que se selecciona una prueba de lectura diseñada para ser usada en tercero a sexto grado, a la cual, para el propósito de este ejemplo hipotético, se le llamará “Prueba de mejor lectura” (PML). Supóngase además que ahora se desea comparar los hallazgos obtenidos en otra prueba nacional de lectura diseñada para ser usada en los grados tercero a sexto, la “Prueba de Lectura XYZ”, con la PML. Una tabla de equivalencia para las puntuaciones en las dos pruebas o **normas nacionales ancladas** podría proporcionar la herramienta para dicha comparación. Del mismo modo en que un ancla proporciona alguna estabilidad a un barco, así las normas nacionales ancladas proporcionan alguna estabilidad a las puntuaciones de prueba al anclarlas con otras puntuaciones de prueba.

El método por el cual se establecen dichas tablas de equivalencia o normas nacionales ancladas comienza, de manera general, con el cálculo de las normas percentiles para cada una de las pruebas que se van a comparar. Por medio del **método equipercantil**, se calcula la equivalencia de las puntuaciones en diferentes pruebas con referencia a las puntuaciones percentiles correspondientes. Así, si el percentil 96 corresponde a una puntuación de 69 en la PML, y si el percentil 96 corresponde a una puntuación de 14 en la XYZ, es posible decir que una puntuación PML de 69 es equivalente a una puntuación XYZ de 14. Debemos señalar que las normas nacionales ancladas para las pruebas PML y XYZ deben haberse obtenido en la misma muestra, cada miembro de la muestra respondió ambas pruebas y luego se calcularon las tablas de equivalencia con base

en estos datos.⁴ Aunque las normas nacionales ancladas proporcionan un indicador de la equivalencia de las puntuaciones en varias pruebas, sería un error, debido a consideraciones técnicas, tratar estas equivalencias como igualdades precisas (Angoff, 1964, 1966, 1971).

Normas de subgrupo Una muestra normativa puede dividirse en segmentos mediante cualquiera de los criterios utilizados inicialmente para seleccionar sujetos de la muestra. Lo que resulta de tal división son más **normas de subgrupo** definidos en forma más reducida. Así, por ejemplo, suponga que los criterios utilizados para seleccionar niños para su inclusión en la muestra de estandarización de la “Prueba de lectura XYZ” fueron edad, nivel educativo, nivel socioeconómico, región geográfica, tipo de comunidad y lateralidad (si el niño era diestro o zurdo). El manual de la prueba o un complemento podría reportar información normativa para cada uno de estos subgrupos. Un integrante del consejo escolar comunitario podría encontrar que las normas regionales son más útiles, mientras que un psicólogo que realiza una investigación exploratoria en el área de la lateralización cerebral y las puntuaciones en lectura podría encontrar más útiles las normas de lateralidad.

Normas locales Elaboradas generalmente por los mismos administradores de la prueba, las **normas locales** proporcionan información normativa respecto al desempeño de la población local en alguna prueba. Un director de personal de una compañía local podría encontrar útil alguna prueba estandarizada en forma nacional para tomar decisiones de selección, pero podría considerar que las normas publicadas en el manual de la prueba están muy lejanas de las distribuciones de puntuaciones de los solicitantes locales de empleo. Las escuelas preparatorias privadas pueden desear elaborar sus propias normas escolares (normas locales) para las puntuaciones de los estudiantes en algún examen que se administra en todo el estado. Un centro de orientación escolar puede encontrar que las normas derivadas en forma local para una prueba particular, por ejemplo, una encuesta de valores personales, son más útiles para orientar a los estudiantes que las normas nacionales impresas en el manual.

Sistema de calificación con un grupo de referencia fijo

Las normas proporcionan un contexto para interpretar el significado de la puntuación de una prueba. Otro tipo de auxiliar que proporciona un contexto para la interpretación se denomina **sistema de calificación con un grupo de referencia fijo**. Aquí, la distribución de puntuaciones obtenidas en la prueba de un grupo de individuos que la respondieron, al que se hace referencia como el *grupo de referencia fijo*, se usa como base para el cálculo de las puntuaciones de prueba para aplicaciones futuras de la prueba. Quizá la prueba más familiar para los estudiantes universitarios estadounidenses que ejemplifica el uso de un sistema de calificación con un grupo de referencia fijo, es la SAT. Esta prueba fue aplicada por primera vez en 1926. Sus normas se basaban entonces en la media y la desviación estándar de las personas que en esa época respondían la prueba. Con el paso de los años, más universidades (en Estados Unidos), se hicieron miembros del Consejo de Universidades (College Board), el organismo patrocinador de la prueba. Pronto se hizo evidente que las puntuaciones de la SAT tendían a variar un poco en función de la época del año en que la prueba era aplicada. En un esfuerzo por asegurar la comparabilidad permanente y la continuidad de las puntuaciones, en 1941 se utilizó un sistema de calificación con un grupo de referencia fijo.

La distribución de puntuaciones de las 11 000 personas que respondieron la SAT en 1941 fue inmortalizada como un estándar para ser usado en la conversión de las puntuaciones crudas en aplicaciones futuras de la prueba.⁵ Un nuevo grupo de referencia fijo, los más de dos millones de personas que respondieron la SAT en 1990, comenzó a usarse en 1995. Una puntuación de 500 en

4. Cuando dos pruebas son normalizadas utilizando la misma muestra, el proceso de normalización se conoce como *conormalización*.

5. En el sentido conceptual, la idea de un grupo de referencia fijo es análoga a la idea de un *pie de referencia fijo*, el pie del rey de Inglaterra que también se inmortalizó como una medida estándar (Angoff, 1962).

la SAT corresponde a la media obtenida por la muestra de 1990, una puntuación de 400 corresponde a una puntuación que está a 1 desviación estándar por debajo de la media de 1990, y así de manera sucesiva. Como ejemplo, supóngase que John presentó la SAT en 1995 y respondió 50 preguntas en forma correcta en una escala particular. Y supóngase que Mary respondió la prueba en 1996 y, al igual que John, respondió 50 reactivos en forma correcta. Aunque John y Mary pueden haber logrado la misma puntuación cruda, no necesariamente lograron la misma puntuación en la escala. Si, por ejemplo, la versión de 1996 de la prueba que se comenta fue juzgada como más sencilla que la versión de 1995, las puntuaciones en escala para quienes respondieron la prueba en 1996 se habrían calibrado en forma descendente de modo que las puntuaciones logradas en 1996 fueran comparables con las puntuaciones obtenidas en 1995.

Los reactivos de prueba comunes a cada versión nueva y cada versión previa de la SAT son empleados en un procedimiento (denominado *anclaje*) que permite la conversión de las puntuaciones crudas en la versión nueva de la prueba en lo que en forma técnica se conoce como *puntuaciones del grupo de referencia fijo*. Como otras puntuaciones de grupos de referencia fijos, incluyendo las puntuaciones del examen de registro para graduados (Graduate Record Examination) (véase el recuadro *Close-up*), las puntuaciones de la SAT son interpretadas de manera más frecuente con respecto a normas locales. Por tanto, los funcionarios de admisión de las universidades, por ejemplo, comúnmente se basan en sus propias normas recopiladas de forma independiente para tomar decisiones de selección. Ellos comparan las puntuaciones de la SAT obtenidas por los candidatos, con las puntuaciones de la SAT obtenidas por sus estudiantes, tanto con los de aquellos que completaron con éxito el programa de estudios, como con las de quienes lo abandonaron. Por supuesto, las decisiones de admisión casi nunca se realizan sólo sobre la base de las puntuaciones de la SAT (o cualquier otra prueba). Por lo general, se evalúan varios criterios para tomar las decisiones de admisión.

Evaluación con referencia a la norma versus evaluación con referencia al criterio

Una forma de derivar un significado de las puntuaciones de prueba es evaluar la puntuación de la prueba con relación a otras puntuaciones en la misma prueba. Como ya se ha dicho, este enfoque de las pruebas se establece con referencia a la norma. Otra forma de obtener significado de la puntuación de una prueba es evaluarla con base en el cumplimiento o no de algún criterio. Un **criterio** se puede definir como un estándar sobre el cual puede estar basado un juicio o una decisión. La **prueba y evaluación con referencia a un criterio** se define como un método de evaluación y una forma de derivar significado de las puntuaciones de las pruebas, mediante la evaluación de una puntuación individual con referencia a un conjunto estándar. Algunos ejemplos son:

- Los estudiantes deben demostrar al menos un nivel de lectura de sexto grado como un requisito para obtener un diploma de bachillerato.
- Para obtener el privilegio de conducir un vehículo los aspirantes deben tomar una prueba de manejo y ser aprobados por un examinador designado por las autoridades.
- Para ser licenciado en psicología, el aspirante deberá obtener una puntuación que iguale o exceda la puntuación regulada por el estado.

El criterio en las evaluaciones con referencia al criterio, de manera general, se deriva de los valores o estándares de un individuo u organización. Por ejemplo, para obtener un cinturón negro en karate, los estudiantes deben demostrar un nivel de desempeño suficiente para alcanzar ese grado y satisfacer los criterios relacionados, como la autodisciplina y la concentración. Cada estudiante se evalúa en forma individual para ver cuáles de estos criterios cumple. Sin importar el nivel de desempeño de todos los evaluados, sólo los estudiantes que satisfagan todos los criterios saldrán del *dojo* (sala de entrenamiento) con un nuevo cinturón negro.

Las pruebas y la evaluación con referencia a un criterio se han denominado en forma variada. Como el interés en este enfoque no son las puntuaciones individuales con relación a las puntuaciones de otras personas, sino las puntuaciones con relación a un área de contenido o a un domi-

Las viejas y queridas normas y el GRE

Algún tiempo antes o después de su graduación, el Examen de registro para graduados (GRE) puede estar en su lista de "pendientes". Como es sabido que las calificaciones de prueba del GRE influirán en las opciones de escuelas de graduados que le abran sus puertas y, por extensión, en su carrera y en su vida en general, es probable que lea los resultados de su prueba con avidez pero también con un poco de temor. Asumiendo que ha presentado la prueba general del GRE, tendrá tres puntuaciones, una para capacidad verbal, una para capacidad cuantitativa y una para capacidad analítica. ¿Cómo interpretará estas puntuaciones?

Usted ya sabe algo acerca de las normas, y también que el GRE tiene una media de 500 y una desviación estándar de 100. Sin embargo, aquí hay algo que tal vez usted no sepa: Esa media de 500 y la desviación estándar de 100 fueron aplicadas a las puntuaciones obtenidas por personas que presentaron el GRE en 1952; sus puntuaciones fueron inmortalizadas como un grupo normativo o un grupo de referencia fijo. Para entender el significado de una puntuación obtenida hoy requiere de tablas normativas actuales suministradas por el aplicador de la prueba, el Servicio de Exámenes Educativos (Educational Testing Service, ETS).

A modo de explicación, considere el caso de Dexter, un licenciado en literatura inglesa. Apenas la semana pasada, Dexter recibió las siguientes puntuaciones en el GRE: 640 en capacidad verbal, 700 en capacidad cuantitativa y 520 en capacidad analítica. Dexter sabía que el GRE tiene una media de 500 y una desviación estándar de 100, y sin tomarse el tiempo para aprender mucho más acerca del significado real de las puntuaciones, obtuvo algunas conclusiones inmediatas sobre sus capacidades.

Dexter concluyó que la capacidad cuantitativa era su fuerte. Después de todo, su puntuación cuantitativa estaba 2 desviaciones estándar sobre la media, una puntuación que excedía las puntuaciones de más del 97% de quienes respondieron la prueba. "Quizá literatura inglesa era la carrera equivocada", pensó en voz alta. Luego pasó a analizar su puntuación en capacidad analítica. "Promedí un poco por arriba del promedio comparado con aquellos con los que estaré compitiendo para ingresar en la escuela de graduados". Hasta aquí, ¿es correcto el análisis de Dexter?

En una palabra, no. Dexter supone en forma errónea que el GRE, entre quienes responden la prueba en la actualidad, tiene una media de 500 y una desviación estándar de 100. De manera obvia, no está enterado de que el GRE usa un sistema de calificación de grupo de referencia fijo. El grupo de referencia para las partes verbal y cuantitativa de la prueba se basa en personas que presentaron el GRE en 1952. En esa ocasión, la puntuación media de las personas que presentaron la prueba se estableció en 500, con una desviación estándar de 100. En los más de 50 años que han pasado desde que el grupo de referencia fija fue examinado, ha habido cambios significativos en la población que presenta el GRE. Estos cambios en la población han necesitado cambios en la forma en que se interpreta un reporte de puntuaciones.

El Servicio de Exámenes Educativos, ETS, tiene disponibles las normas actuales del GRE para estudiantes individuales e instituciones. La información se presenta en forma de percentiles, con el porcentaje de examinados que calificaron por debajo de una puntuación particular reportado a lo largo de la distribución de puntuaciones del GRE. El reporte de puntuaciones enviado a quienes respondieron la prueba incluye esta información percentil para las puntuaciones obtenidas por esa persona. Si Dexter se hubiera tomado el tiempo de leer esta información, podría haber interpretado con más precisión sus puntuaciones con relación a los estudiantes de último grado universitario y a los graduados universitarios que presentaron la prueba en el mismo periodo que él. En este ejemplo hipotético, se hará referencia a este periodo simplemente como "ahora".

Suponga, para efectos de este ejemplo, que las puntuaciones de capacidad verbal de 640 se ubican en el percentil 87, las de capacidad cuantitativa de 700 están en el 79 y las de capacidad analítica de 520 están en el 35. Con esta información, surge un panorama diferente de Dexter y sus capacidades.

Con relación a quienes respondieron la prueba "ahora", en el área de capacidad verbal, Dexter obtuvo una puntuación mayor que el 87% de los otros evaluados. Su ejecución en capacidad cuantitativa fue mejor que el 79% de los demás, y está claramente por encima de la mediana pero no es tan sobresaliente como su ejecución verbal. En realidad, el rendimiento analítico de Dexter se encuentra por debajo de la mediana, con sólo el 35% de quienes respondieron la prueba al obtener una puntuación menor que la de él. Después de revisar su reporte de calificaciones con un miembro del personal del centro de orientación de su escuela, Dexter queda con la confianza restablecida de que después de todo la literatura inglesa fue una buena elección.

Al aprender sobre la derivación e interpretación de las puntuaciones del GRE, puede preguntarse sobre los beneficios de perpetuar lo que puede parecer un sistema innecesariamente complicado y anticuado. ¿Por qué conservar datos con décadas de antigüedad como un grupo de norma de referencia fijo? ¿Por qué la necesidad de cambiar los valores de percentiles correspondientes a puntuaciones específicas del GRE? ¿Por qué el ETS no ha reajustado la media del GRE en 500 y su desviación estándar en 100 para cada nuevo año, si no es que para cada aplicación de la prueba? De manera cierta este reajuste simplificaría la interpretación de puntuaciones individuales.

La renormalización frecuente del GRE haría en extremo difíciles, si no es que imposibles, las comparaciones significativas entre personas que presentaron el examen en diferentes épocas. Por el contrario, el sistema garantiza que pueden hacerse comparaciones significativas entre personas y a lo largo del tiempo. En efecto, el GRE se encuentra vigente con el propósito de asistir a las instituciones en la toma de decisiones sobre cuestiones como la admisión a las escuelas de graduados y la asignación de becas. La capacidad de la prueba para hacer comparaciones significativas

(continúa)

Las viejas y queridas normas y el GRE (continuación)

se conserva con el sistema actual. Una puntuación del GRE de 500 en la prueba cuantitativa (o verbal) significa que quien respondió la prueba se ha desempeñado en el nivel promedio de las personas que presentaron el GRE en 1952. Para ésta o cualquier otra puntuación específica, la puntuación representa un nivel establecido de desempeño sin importar cuándo se presentó la prueba.

Cuando los miembros del grupo de referencia fijo presentaron la prueba en 1952, las puntuaciones del GRE fueron establecidas con una media de 500 y una desviación estándar de 100. Si se supone una distribución normal de puntuaciones, los valores de percentiles para una muestra de puntuaciones específica sería la siguiente:

Puntuación GRE	Valor percentil en 1952
700	98
600	84
500	50
400	16
300	2

En este ejemplo hipotético para “ahora”, los patrones de las puntuaciones de la prueba cambiaron un poco:

Puntuación GRE	Valor percentil en 1952	Valor percentil “ahora”	
		Verbal	Cuantitativo
700	98	95	79
600	84	79	56
500	50	51	31
400	16	19	11
300	2	3	2

Según se compara con la de 1952, la distribución de puntuaciones en la prueba de capacidad verbal no es muy diferente. Aunque las puntuaciones parecen haberse dispersado un poco más en años recientes, la mediana en esencia es la misma. Una proporción ligeramente mayor de personas obtiene puntuaciones en los extremos inferior y superior de la escala. Por ejemplo, 16% de los estudiantes obtuvo puntuaciones mayores de 600 en 1952 y 21% obtuvo más de 600 “ahora”.

La distribución de puntuaciones en la prueba de capacidad cuantitativa es diferente de modo considerable para los dos períodos. En este caso, una mayor proporción de personas está obteniendo puntuaciones superiores que en 1952. En ese año, los estudiantes que obtenían una puntuación mayor de 700 constituían sólo alrededor del 2% de la población de quienes respondían la prueba. En la muestra de “ahora”, estos estudiantes constituyeron 21% del grupo.

Un factor que contribuyó al cambio en la distribución de las puntuaciones cuantitativas es que ahora más estudiantes extranjeros presentan el GRE que en 1952. Muchos de estos estudiantes tienen mejor capacidad matemática que los estudiantes estadounidenses, lo que causa una elevación en la mediana del nivel de capacidad entre todos aquellos que responden la prueba.

De regreso a la cuestión de renormalizar el GRE con más frecuencia, ¿puede imaginar cómo serían las cosas si ese fuera el caso? Si el nivel de capacidad que se examina en la población fuera a cambiar, como parece haber sucedido con la capacidad cuantitativa, entonces el significado de puntuaciones específicas también cambiaría. Esto puede ilustrarse con el caso de dos estudiantes que presentan el GRE con cinco años de diferencia. Los dos estudiantes solicitan su admisión en el mismo programa competitivo para graduados. Durante el periodo de cinco años que separa a las pruebas, una creciente proporción de personas con buena capacidad cuantitativa se matriculó y presentó el GRE. El primer estudiante presentó el GRE con relativamente pocas personas que tenían altas habilidades cuantitativas y obtuvo una puntuación de 660 en la prueba cuantitativa. El segundo estudiante presentó el GRE con muchas personas con altas habilidades cuantitativas y también obtuvo una puntuación de 660 en el examen cuantitativo.

Bajo el sistema actual, en el cual la prueba no se renormaliza cada año, se concluiría que los dos estudiantes con puntuaciones similares tienen niveles similares de desempeño cuantitativo; una comparación directa sería válida. Sin embargo, si la prueba se renormalizara cada año, la puntuación del segundo estudiante descrita antes en realidad representaría una mejor habilidad cuantitativa debido a que el estudiante fue comparado con personas con más habilidad cuantitativa. Es evidente que la renormalización disminuiría la comparabilidad de las puntuaciones a través de diferentes pruebas.

En esta exposición, se han tocado problemas relacionados con las puntuaciones de las pruebas verbal y cuantitativa del GRE. Como usted podrá sospechar, hay problemas adicionales relacionados con las normas en lo concerniente a las puntuaciones de la capacidad analítica y las puntuaciones de la Prueba temática (Subject Test). Una consideración de estos problemas, más complejos relacionados con las normas, le aguarda después de que haya presentado el GRE y obtenido un lugar en un programa de posgrado en psicometría. También puede contactar al Servicio de Exámenes Educativos (Educational Testing Service) a su sitio en la red o escribir a su correo postal P.O. Box 6000, Princeton, Nueva Jersey, 08541-6000, para más información respecto al GRE o a cualquiera de sus otras pruebas. Los estudiantes interesados también podrían desear escribir para obtener los valores percentiles actuales que corresponden a las puntuaciones del GRE, puesto que los datos de “ahora” aquí presentados fueron sólo hipotéticos.

nio particular, también son conocidas como **pruebas y evaluación con referencia al dominio o contenido**.⁶ Mientras que las interpretaciones con referencia a una norma de los datos de prueba proporcionan información sobre el desempeño de un individuo en relación con el de otras personas, las interpretaciones con referencia a un criterio proporcionan información de lo que la gente puede hacer. Debido a que las pruebas con referencia a un criterio se usan con frecuencia para estimar el rendimiento o dominio, en ocasiones son llamadas pruebas de dominio. El enfoque con referencia a un criterio ha tenido una amplia aceptación en el campo de los programas de educación asistidos por computadora. En tales programas, el dominio de segmentos de materiales se evalúa antes de que el usuario del programa pueda continuar hacia el siguiente nivel.

“¿Esta fémina que está siendo entrenada para volar, domina el material que necesita para ser piloto de una aerolínea?” Éste es el tipo de pregunta que el jefe de personal de una compañía de aviación intentaría responder con una prueba de dominio en un simulador de vuelo. Si una norma, o criterio, para pasar una “Prueba de piloto de aerolínea” (PPA) hipotética se ha establecido en el 85% correcto, entonces los aprendices que obtengan 84% correcto o menos no aprobarán; no importa si obtuvieron 84 o 42%. Por el contrario, los aprendices que hayan obtenido 85% o superior en la prueba, habrán calificado sin importar si obtuvieron 85 o 100%; se dice que todo aquel que obtuvo 85% o mejor domina las habilidades y el conocimiento necesarios para ser un piloto de aerolínea. Llevando este ejemplo un paso más adelante, otra aerolínea podría hallar útil establecer tres categorías de resultados basadas en la interpretación de las puntuaciones de una prueba con referencia a un criterio:

85% correcto o mejor = aprobado

75 a 84% correcto = volver a presentar la prueba después de un curso de repaso de dos meses

74% o menos = reprobado

¿Cómo se deben determinar las puntuaciones limítrofes en las pruebas de dominio? ¿Cuántas y qué clase de preguntas son necesarias para demostrar el dominio en un campo determinado? Las respuestas a estas preguntas y otras relacionadas han sido abordadas en diversas formas (Ferguson y Novick, 1973; Glaser y Nitko, 1971; Panell y Laabs, 1979), todas ellas fuera del alcance de este libro.

Los críticos del enfoque con referencia a un criterio afirman que si se sigue en forma estricta, se pierde información potencialmente importante sobre el desempeño del individuo con respecto a otros que han respondido la prueba. Otra crítica es que aunque este enfoque puede tener valor con respecto a la evaluación del dominio de conocimientos o habilidades básicas o ambos, tiene poca o ninguna aplicación significativa en el extremo superior del continuo de conocimiento y habilidad. Aunque podría ser significativo usar pruebas orientadas hacia un criterio para ver si los alumnos han dominado la lectura, la escritura y la aritmética básicas, el valor de dichas pruebas en el mejor de los casos sería cuestionable para estimar el progreso de un estudiante en un nivel de doctorado avanzado en su área de especialización; la originalidad única y la capacidad analítica brillante no son el material del que están hechas las pruebas con referencia a un criterio. Por el contrario, la brillantez y las capacidades superiores son reconocibles en pruebas que emplean interpretaciones con referencia a una norma; son las puntuaciones que se observan a todo lo largo a la derecha de la curva normal, después de la tercera desviación estándar.

SÓLO PIENSE...

¿Qué tipo de evaluación considera usted sería la adecuada para que su estado otorgara licencias para ejercer su profesión a médicos, psicólogos, ingenieros y otros profesionistas, una evaluación con referencia al criterio o una evaluación con referencia a la norma? ¿Por qué?

6 Aunque se reconozca que las interpretaciones “con referencia al contenido” pueden considerarse como interpretaciones “con referencia a un criterio”, la edición de 1974 de los *Estándares* también señaló una distinción técnica entre las interpretaciones así designadas: “Las interpretaciones *con referencia al contenido* son aquellas donde la puntuación es interpretada en forma directa en términos del desempeño en cada punto del continuo de ejecución que se está midiendo. Las interpretaciones *con referencia a un criterio* son aquellas donde la puntuación es interpretada en forma directa en términos del desempeño en cualquier punto dado en el continuo de una variable *externa*. Una variable de criterio externo puede ser graduada por los promedios de calificaciones o los niveles del desempeño en un trabajo” (p. 19; nota al pie de página omitida en el original).

En cierto sentido, todas las pruebas son normativas en realidad, incluso si las puntuaciones son aparentemente referidas a un criterio como aprobado/reprobado. Esto es así debido a que aun en una puntuación aprobado/reprobado, hay un reconocimiento inherente de un continuo de habilidades. En algún punto de este continuo ha sido aplicado un corte dicotómico.

Ahora procedamos a examinar otra de aquellas palabras que, junto con *impugnar* y *percentil*, encabezarían con facilidad una lista nacional de la terminología usada con mayor frecuencia, pero menos comprendida. La palabra es *correlación*, un término que disfruta de una amplia confusión con el concepto de causalidad. Afirmemos en principio que correlación *no* es sinónimo de causalidad. Pero, ¿qué significa *correlación*? ¿Y qué significa *regresión*? A continuación contestaremos estas preguntas.

Correlación e inferencia

Es fundamental para las pruebas y la evaluación psicológicas hacer inferencias (deducir conclusiones) acerca de cómo algunas cosas (como rasgos, capacidades o intereses) se relacionan con otras cosas (como el comportamiento). Un **coeficiente de correlación** es un número que nos proporciona un índice de la fuerza de la relación entre dos cosas. Por consiguiente, una comprensión del concepto de correlación y una habilidad para calcular un coeficiente de correlación son un punto central para el estudio de las pruebas y la medición.

El concepto de correlación

Planteado en forma simple, correlación es una expresión del grado y dirección de correspondencia entre dos cosas. Un coeficiente de correlación (r) expresa una relación lineal entre dos (y sólo dos) variables. Refleja el grado de variación concomitante entre la variable X y la variable Y . El *coeficiente de correlación* es el índice numérico que expresa esta relación. Nos indica el grado en que X y Y están “correlacionadas”.

El significado de un coeficiente de correlación se interpreta por su signo y su magnitud. Si un coeficiente de correlación fuera una persona a la que se le preguntara “¿cuál es tu signo?”, ésta no contestaría nada como “Leo” o “Piscis”. Podría responder “más” (para una correlación positiva) o “menos” (para una correlación negativa), o “ninguno” (en el extraño caso de que el coeficiente de correlación fuera exactamente igual a cero). Si se le pidiera que proporcione información acerca de su magnitud, respondería con algún número entre -1 y $+1$. Y aquí se presenta otro hecho incomprensible en cierto grado acerca de la magnitud de un coeficiente de correlación: se juzga por su valor absoluto. Esto significa que en la medida en que estamos impresionados por coeficientes de correlación, una correlación de $+0.99$ es tan impresionante como una correlación de -0.99 . Para entender por qué, necesita saber un poco más sobre correlación.

“Ahh... ¡una correlación perfecta!, contemos las formas”.

Bueno, en realidad existen sólo *dos*. Las dos formas de describir una correlación perfecta entre dos variables pueden resumirse ya sea como $+1$ o -1 . Si un coeficiente de correlación es $+1$ o -1 , esto significa que la relación entre las dos variables es perfecta, sin error en el sentido estadístico. Las correlaciones perfectas en el trabajo psicológico, u otro trabajo en lo que a esto respecta, son difíciles de encontrar (al igual que la perfección en casi cualquier cosa tiende a ser difícil de encontrar). Quizá ésta sea la razón por la que planteamos esa pregunta al margen.

SÓLO PIENSE...

Mencione dos variables psicológicas que estén perfectamente correlacionadas.
Mencione dos variables psicológicas que estén casi perfectamente correlacionadas.

Si dos variables se incrementan o disminuyen de manera simultánea, entonces se dice que esas dos variables están correlacionadas en forma *positiva* o directa. La estatura y el peso de los niños sanos normales con un rango de edad entre el nacimiento y los diez años tienden a estar correlacionadas en forma positiva o directa. Por lo general, conforme aumenta la edad de los niños, su estatura y su peso, se incrementan de manera simultánea. También existe una correla-

ción positiva cuando dos variables disminuyen de manera simultánea (por ejemplo, entre menos preparado esté un estudiante para un examen, será menor la calificación que obtenga). Una correlación *negativa* (o inversa) ocurre cuando una variable se incrementa mientras la otra variable disminuye. Por ejemplo, tiende a haber una relación inversa entre el número de kilómetros en el odómetro (indicador de kilometraje) de su automóvil y el valor que está dispuesto a darle un comprador de autos usados para recibírselo a cuenta de uno nuevo; si todo lo demás es igual, conforme aumenta el kilometraje, disminuye la cantidad ofrecida por un automóvil.

Si una correlación es cero, entonces no existe absolutamente ninguna relación entre dos variables. Y así como en el trabajo psicológico es casi imposible identificar dos variables que tengan una correlación perfecta, asimismo es casi imposible identificar dos variables que tengan una correlación cero. La mayoría de las veces, dos variables estarán relacionadas en forma fraccional. Con frecuencia, la correlación fraccional será pequeña pero pocas veces será cero.

Como afirmamos en la introducción a este tema, a menudo la correlación se confunde con la causalidad. Debe enfatizarse que un coeficiente de correlación tan sólo es un índice de la relación entre dos variables, *no* un índice de la relación causal entre dos variables. Si se le dijera, por ejemplo, que desde el nacimiento hasta los cinco años de edad hay una alta correlación positiva entre el tamaño del sombrero y la capacidad de deletrear, ¿sería apropiado inferir que el tamaño del sombrero es causa de la capacidad de deletrear? Por supuesto que no. El periodo del nacimiento hasta la edad de nueve años es una época de maduración en todas las áreas, incluyendo el crecimiento en tamaño físico y el desarrollo de las capacidades cognoscitivas como el habla. El desarrollo intelectual es paralelo al desarrollo físico durante estos años y de manera clara existe una relación entre el crecimiento físico y el mental; no obstante, la relación entre el tamaño del sombrero y la habilidad del habla no necesariamente es causal.

Aunque correlación no implica causalidad, *hay* una implicación de predicción. Planteado de otra forma, si se sabe que hay una alta correlación entre X y Y , deberíamos ser capaces de predecir —con varios grados de precisión, dependiendo de otros factores— el valor de una de esas variables si conocemos el valor de la otra.

SÓLO PIENSE...

Mencione dos variables psicológicas que tengan una correlación de cero, y dos variables psicológicas que tengan una correlación casi igual a cero.

La r de Pearson

Se han desarrollado muchas técnicas para medir la correlación. La más utilizada de todas es la **r de Pearson**, también conocida como el *Coeficiente de correlación de Pearson* y el *coeficiente de correlación producto-momento de Pearson*. La r , desarrollada por Karl Pearson (figura 4-2), puede ser la herramienta estadística de elección cuando la relación entre las variables es lineal y cuando las dos variables que se están correlacionando son continuas (es decir, pueden tomar cualquier valor desde el punto de vista teórico). Pueden emplearse otras técnicas correlacionales con datos que son discontinuos y donde su interrelación no es lineal. La fórmula para la r de Pearson toma en cuenta la posición relativa de cada puntuación de prueba o medida con respecto a la media de la distribución.

Pueden usarse varias fórmulas para calcular una r de Pearson. Una de estas fórmulas necesita convertir cada puntuación cruda a una puntuación estándar y luego multiplicar cada par de puntuaciones estándar. Se calcula una media para la suma de los productos y esa media es el valor de la r de Pearson. Aun a partir de esta conceptualización verbal simple de lo que es una r de Pearson, puede verse que el signo de la r resultante sería una función del signo y de la magnitud de las puntuaciones estándar que se utilicen; si, por ejemplo, los valores de las puntuaciones estándares negativas para las mediciones de X siempre se corresponden con valores de puntuaciones estándar negativos para las puntuaciones Y , la r resultante será positiva (debido a que el producto de dos valores negativos es positivo).

De manera similar, si los valores de las puntuaciones positivas estándar en X siempre se corresponden con valores de puntuaciones positivas estándar en Y , la correlación resultante también sería positiva. Sin embargo, si los valores de las puntuaciones positivas estándar para X se

Figura 4-2
Karl Pearson (1857-1936)

Karl Pearson y su hija. El nombre de Pearson se ha convertido en un sinónimo de correlación. Sin embargo, la historia registra que en realidad fue sir Francis Galton quien debería recibir el crédito por el desarrollo del concepto de correlación (Magnello y Spies, 1984). Galton experimentó con muchas fórmulas para medir la correlación, incluso con una que etiquetó como r . Pearson, un contemporáneo de Galton, modificó la r de Galton y, como se dice comúnmente, el resto es historia. Con el paso del tiempo, la r de Pearson se convirtió en la medida de correlación más ampliamente usada.



corresponden con valores de puntuaciones negativas estándar para Y , y viceversa, existiría una relación inversa y resultaría una correlación negativa. Podría resultar una correlación de cero o cercana a cero cuando algunos productos sean positivos y algunos, negativos.

La fórmula usada para calcular una r de Pearson a partir de puntuaciones crudas es como sigue:

$$r = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{[\sum (X - \bar{X})^2] [\sum (Y - \bar{Y})^2]}}$$

Esta fórmula ha sido simplificada con el propósito de abreviar. Una fórmula abreviada es una fórmula en relación a la desviación que emplea “ x minúscula”, o x , en lugar de $X - \bar{X}$ y “ y minúscula”, o y , en lugar de $Y - \bar{Y}$:

$$r = \frac{\sum xy}{\sqrt{(\sum x^2) (\sum y^2)}}$$

Otra fórmula para calcular una r de Pearson es la siguiente:

$$r = \frac{N \sum XY - (\sum X)(\sum Y)}{\sqrt{N \sum X^2 - (\sum X)^2} \sqrt{N \sum Y^2 - (\sum Y)^2}}$$

Aunque esta fórmula parece más complicada que la anterior fórmula en relación a las desviaciones, es más fácil de usar. N representa el número de pares de puntuaciones; $\sum XY$ es la suma del producto de las puntuaciones X y Y emparejadas; $\sum X$ es la suma de las puntuaciones X ; $\sum Y$ es la suma de las puntuaciones Y ; $\sum X^2$ es la suma de las puntuaciones X al cuadrado y $\sum Y^2$ es la suma de las puntuaciones Y al cuadrado. Se obtienen resultados similares usando cualquiera de las fórmulas.

La siguiente pregunta lógica se refiere a qué hacer con el número obtenido para el valor de r . La respuesta es que se plantean más preguntas, como: “¿Es significativo este número desde el punto de vista estadístico, dado el tamaño y la naturaleza de la muestra?” o “¿Este resultado podría haber ocurrido por azar?” En este punto, necesitará consultar las tablas de significancia para la r de Pearson, las cuales probablemente encontrará al final de su viejo texto de estadística. En esas tablas encontrará, por ejemplo, que una r de Pearson de .899 con $N = 10$ es significativa en el nivel .01 (usando una prueba de dos colas). De su curso de estadística recordará que un nivel de significancia de .01 le indica, con referencia a estos datos, que podía haberse esperado que ocurriera una correlación como ésta sólo por azar una vez o menos en cien si X y Y no están correlacionadas en la población. También recordará que un nivel de significancia de .01 o de .05 (algo menos riguroso), proporciona una base para inferir que, en efecto, existe una correlación. Un nivel de significación de .05 expresa que el resultado podría haberse esperado que ocurriera por azar cinco veces o menos en cien.

El valor obtenido para el coeficiente de correlación puede interpretarse más adelante, al derivar de él lo que se conoce como **coeficiente de determinación** o r^2 . El coeficiente de determinación es un indicio de cuánta varianza es compartida por las variables X y Y . El cálculo de r^2 es bastante directo; tan sólo se eleva al cuadrado el coeficiente de correlación, se multiplica por 100 y se expresa el resultado como el porcentaje de la variación calculada. Si, por ejemplo, calculó que una r era .9, entonces r^2 sería igual a .81; se supone que la variación restante, igual a 100 ($1 - r^2$), o 19%, podría explicarse por azar, error o por factores de alguna otra manera no fueran medidos o no explicados.⁷

Antes de continuar con el estudio de otros índices de correlación, se abordará una pregunta muy lógica que en ocasiones realizan los estudiantes cuando escuchan que se hace referencia a la r de Pearson como el *coeficiente de correlación producto-momento*. ¿Por qué se le llama así? La respuesta es un poco complicada, pero se ofrece a continuación.

En el lenguaje de la psicometría, un *momento* describe una desviación con respecto a la media de una distribución. Las desviaciones individuales con respecto a la media de una distribución se conocen como *desviaciones*, vocablo con el que se alude a los *primeros momentos* de la distribución. Los *segundos momentos* de la distribución son los momentos al cuadrado. Los *terceros momentos* son los momentos al cubo y así sucesivamente. El cálculo de la r de Pearson en una de sus múltiples fórmulas implica la multiplicación de las puntuaciones estándar correspondientes a dos mediciones. Una forma de conceptualizar las puntuaciones estándar es en los primeros momentos de una distribución. Esto se debe a que las puntuaciones estándar son desviaciones respecto a una media de cero. Por tanto, una fórmula que implica la multiplicación de dos puntuaciones estándar correspondientes se puede entonces conceptualizar como una que involucra el cálculo del *producto* de los *momentos* correspondientes. Y ésta es la razón por la que la r es llamada *correlación producto-momento*. Probablemente esta explicación es materia de una trivía de psicometría más que cualquier otra cosa, pero se consideró correcto presentarla.

La rho de Spearman

La r de Pearson disfruta de un uso y aceptación tan extendidos como un índice de correlación que si, por alguna razón, no se usa para calcular un coeficiente de correlación, se hace mención de la estadística que se usó. Existen muchas formas alternativas de derivar un coeficiente de correlación. Una estadística que se usa comúnmente es llamada de manera indistinta **coeficiente de correlación por rasgos ordenados**, **coeficiente de correlación por diferencia de rango** o tan sólo **rho de Spearman**.

7. En una nota técnica, Ozer (1985) advirtió que la estimación real de un coeficiente de determinación debe hacerse con una consideración escrupulosa respecto a las suposiciones operativas en el caso particular. Evaluar un coeficiente de determinación sólo en función de la varianza estimada puede conducir a interpretaciones que subestimen la magnitud de una relación.



¡USTEDES, PUNTUACIONES ESTÁNDAR,
SON UN MONTÓN DE DESVIADOS
ALREDEDOR DE UNA MEDIA DE CERO!

Desarrollado por Charles Spearman, un psicólogo inglés (figura 4-3), este coeficiente de correlación se usa con frecuencia cuando el tamaño de la muestra es pequeño (menos de 30 pares de mediciones) y en especial cuando ambos conjuntos de mediciones se encuentran en forma ordinal (o en orden de rango). Se usan tablas especiales para determinar si un coeficiente *rho* obtenido es significativo o no lo es.

Representaciones gráficas de la correlación

Un tipo de descripción gráfica de correlación es la **gráfica de dispersión** o **diagrama de dispersión**. Una gráfica de dispersión es tan sólo una gráfica de los puntos coordinados para los valores de la variable *X* (colocados a lo largo del eje horizontal de la gráfica) y de la variable *Y* (colocados a lo largo del eje vertical de la gráfica). Las gráficas de dispersión son útiles porque proporcionan un indicio rápido de la dirección y magnitud de la relación, si es que la hay, entre las dos variables. Las figuras 4-4 y 4-5 ofrecen un curso rápido y a simple vista acerca de la naturaleza y grado de la correlación por medio de gráficas de dispersión. Al distinguir las correlaciones positivas de las negativas, nótese la dirección de la curva. Y al estimar la fuerza de la magnitud de la correlación, nótese el grado en que los puntos forman una línea recta.

Las gráficas de dispersión son útiles para revelar la presencia de una relación curvilínea. Recuerde que una *r* de Pearson debe usarse sólo si la relación entre las variables es lineal; si la gráfica no parece tomar la forma de una línea recta, son buenas las probabilidades de que la relación no sea lineal (figura 4-6). Cuando la relación no es lineal, pueden emplearse otras herramientas y técnicas estadísticas.⁸

8. La prueba estadística específica que debe ser utilizada dependerá en parte de aquello que se considere como la posible razón de la no linealidad. Por ejemplo, si se cree que la no linealidad se debe a una distribución que es demasiado asimétrica o sesgada debido a un instrumento de medición muy limitado, la distribución asimétrica puede ser normalizada en forma estadística y el resultado puede ser una corrección de la curvilinearidad. Si aún después de hacer una gráfica de los datos, persiste una interrogante respecto a la linealidad de la correlación, puede usarse una estadística llamada "eta cuadrada" (η^2) para calcular el grado exacto de curvilinearidad.




Figura 4-3
Charles Spearman (1863-1945)

Charles Spearman es conocido como el creador de la prueba estadística rho de Spearman y de la fórmula de la profecía de Spearman-Brown, que se utiliza para “profetizar” la precisión de pruebas de diferentes tamaños. Spearman también recibe el crédito como el padre de un método estadístico llamado análisis factorial, que se estudia más adelante en este texto.

Una gráfica también facilita el reconocimiento de los desplazados. Un **dato desplazado** es un punto en extremo atípico localizado a una distancia relativamente grande —una distancia desplazada— del resto de los puntos coordinados en una gráfica de dispersión (figura 4-7). Los datos desplazados estimulan a los intérpretes de los datos de prueba a especular acerca de la razón para la puntuación atípica. Por ejemplo, considere un dato atípico en una gráfica de dispersión que refleja una correlación entre el tiempo que cada miembro de un grupo de quinto grado le dedicó al estudio y la calificación obtenida en un examen de 20 reactivos. Ahora suponga que un estudiante le dedicó 10 horas al estudio y recibió una nota de reprobado. Este dato atípico en la gráfica de dispersión puede ser una indicación de alerta y conducir al usuario de la prueba a hacerse algunas preguntas importantes, como: “¿Qué tan eficaces son las actividades y hábitos de estudio del alumno?” o “¿Cuál era el estado mental de este estudiante durante el examen?”

En algunos casos, los datos desplazados son tan sólo el resultado de aplicar la prueba a una muestra muy pequeña de evaluados. En el ejemplo anterior, si el examen se hubiera aplicado a todos los alumnos de quinto grado del estado y el tamaño de la muestra hubiera sido mucho más grande, quizá se habrían identificado muchos más estudiantes con puntuaciones bajas que dedicaron grandes cantidades de tiempo al estudio.

Como en el caso de puntuaciones crudas muy bajas o incluso iguales a cero, los datos atípicos pueden ayudar algunas veces a identificar a un evaluado que no entendió las instrucciones, que no fue capaz de seguirlas, o que simplemente se mostró renuente y no aceptó seguir las instrucciones. En otros casos, un desplazado puede proporcionar una pista respecto a alguna deficiencia en los procedimientos de prueba o de calificación.

Las personas que tienen la ocasión de usar o hacer interpretaciones de datos graficados necesitan saber si el rango de puntuaciones ha sido restringido de alguna manera. Para entender por qué es así, obsérvese la figura 4-8. Digamos que la gráfica A describe la relación entre las puntuaciones de la prueba de admisión a la Universidad Pública para 600 aspirantes (todos los cuales fueron admitidos después) y sus promedios de calificaciones al final del primer semestre. La gráfica de dispersión indica que la relación entre las puntuaciones de la prueba de admisión y el promedio de calificaciones es lineal y positiva. Pero, ¿qué tal si el funcionario de admisión sólo




Figura 4-4
Gráficas de dispersión y correlaciones para valores positivos de r









Figura 4-5
Gráficas de dispersión y correlaciones para valores negativos de r




Figura 4-6
Gráficas de dispersión que muestra una correlación no lineal




Figura 4-7
Gráficas de dispersión que muestra un dato desplazado

hubiera aceptado las solicitudes de estudiantes que obtuvieron puntuaciones poco más o menos dentro de la mitad superior en el examen de admisión? Para un ojo entrenado, esta gráfica de dispersión (gráfica B) parece indicar una correlación más débil que la indicada en la gráfica A —un efecto atribuible en forma exclusiva a la restricción del rango—. La gráfica B es menos una línea recta que la gráfica A, y su dirección no es tan obvia.

Regresión

En el lenguaje cotidiano, la palabra regresión es sinónimo de “reversión a algún estado anterior”. En el lenguaje de la estadística, *regresión* también describe una clase de reversión, una reversión a la media en el tiempo o en generaciones (o al menos eso era lo que significaba de manera original).

Regresión se puede definir en forma amplia como el análisis de las relaciones entre variables con el propósito de entender cómo una variable puede predecir a otra. La **regresión simple** implica una variable independiente (X), referida de manera típica como *variable predictora*, y una variable dependiente (Y), llamada comúnmente *variable resultante*. El análisis de regresión simple da como resultado una ecuación para una recta o línea de regresión. La **línea o recta de regresión** es la *línea de mejor ajuste*, la línea recta que, en un sentido, se acerca más a la mayor cantidad de puntos en la gráfica de dispersión de X y Y .

¿La siguiente ecuación le parece familiar?

$$Y = a + bX$$

En álgebra de bachillerato, es probable que le enseñaran que ésta es la ecuación para una línea recta. También es la ecuación para una línea de regresión. En la fórmula, a y b son **coeficientes de regresión**; b es igual a la pendiente de la línea, y a es la **intersección**, una constante que indica dónde cruza la línea el eje Y . La línea de regresión representada por valores específicos de a y b se ajusta precisamente a los puntos en la gráfica de dispersión, de tal modo que la suma de las distancias verticales al cuadrado desde los puntos hasta la línea será menor que para cualquier otra línea que pudiera trazarse en la misma gráfica de dispersión. Aunque podría parecer difícil hallar la ecuación para la línea de regresión, los valores de a y b pueden determinarse por medio de cálculos algebraicos simples.




Figura 4-8
Dos gráficas de dispersión que ilustran el uso de rango no restringido y de un rango restringido

El uso principal de una ecuación de regresión en las pruebas es predecir una puntuación o variable a partir de otra. Por ejemplo, supóngase que el director de la “Escuela de Odontología De Sade” desea predecir qué promedio de calificaciones podría tener un aspirante después del primer año en De Sade. El director acumularía datos sobre las puntuaciones de los estudiantes actuales en el examen de admisión al colegio de odontología y sobre el promedio de calificaciones al final de su primer año. Estos datos se usarían entonces para ayudar a predecir el promedio de calificaciones (Y) a partir de la puntuación en la prueba de admisión al colegio de odontología (X). Los estudiantes de odontología están representados de manera individual por puntos en la gráfica de dispersión en la figura 4-9. La ecuación para la línea de regresión se calcula a partir de estos datos. Esto significa que se calculan los valores de a y b . En este caso hipotético:

$$\text{Promedio de calificaciones} = 0.82 + 0.03 (\text{examen de admisión})$$

Esta línea se ha trazado en la gráfica de dispersión en la figura 4-9.

Si se usa la recta de regresión, el valor probable de Y (el promedio de calificaciones) puede predecirse con base en valores específicos de X (el examen de admisión) al insertar el valor de X en la ecuación. Se esperaría que un estudiante con una puntuación de 50 en el examen de admisión tuviera un promedio de calificaciones de 2.3. Asimismo, un estudiante con una puntuación de 85 en el examen de admisión se esperaría que obtuviera un promedio de 3.7. Esta predicción también podría hacerse en forma gráfica al trazar un valor particular en el eje X (la puntuación en el examen de admisión) hasta la línea de regresión y luego en línea recta hasta cruzar el eje Y, donde se encuentra el promedio de calificaciones predicho.

Por supuesto, no todos los estudiantes que obtienen una puntuación de 50 en el examen de admisión obtienen el mismo promedio de calificaciones. Esto puede verse en la figura 4-8 al trazar una línea desde cualquier puntuación específica del examen de admisión en el eje X hasta la nube de puntos que rodea a la línea de regresión. Esto es lo que se quiere significar con error en la predicción: para cada uno de estos estudiantes se habría predicho que obtendrían el mismo promedio de calificaciones en base al examen de admisión, pero de hecho obtuvieron promedios de calificaciones diferentes. Este error en la predicción de Y a partir de X está representado por el




Figura 4-9
Representación gráfica de la línea de regresión

La correlación entre X y Y es 0.76. La ecuación para esta línea de regresión es $Y = 0.82 + 0.03(X)$; por cada unidad de incremento en X (la puntuación en el examen de ingreso a la escuela dental), el valor predicho de Y (el promedio de calificaciones en el primer año) se incrementa en .03 unidades. El error estándar estimado para esta predicción es de 0.49.

error estándar de estimación. Como usted podría esperar, entre mayor es la correlación entre X y Y, mayor será la precisión de la predicción, y menor el error estándar de estimación.

Regresión múltiple Supóngase que el director sospecha que la predicción del promedio de calificaciones mejorará si se usa también como pronosticador otra puntuación de prueba, por ejemplo, una puntuación en una prueba de habilidades motoras finas. El uso de más de una puntuación para predecir Y requiere el uso de una ecuación de *regresión múltiple*.

La ecuación de **regresión múltiple** toma en cuenta las intercorrelaciones entre todas las variables implicadas. La correlación entre cada una de las puntuaciones predictoras y lo que se predice se refleja en el peso que se le da a cada predictor. En este caso, lo que se pretende predecir es la correlación del examen de admisión y la prueba de habilidades motoras finas, con el promedio de calificaciones en el primer año de la escuela de odontología. A los predictores que se correlacionan altamente con la variable predicha por lo general se les da más peso, lo que significa que sus coeficientes de regresión (denominados valores *b*) son más grandes. Esto es lógico, porque se esperaría que los aplicadores de pruebas pusieran mayor atención a aquellos predictores que pronosticaron mejor a Y.

La ecuación de regresión múltiple también toma en cuenta las correlaciones entre las puntuaciones predictoras. En este caso, toma en cuenta la correlación entre las puntuaciones en la prueba de admisión a la escuela de odontología y las puntuaciones en la prueba de habilidades motoras finas. Si se usan muchos predictores, y uno no está correlacionado con ninguno de los otros predictores pero está correlacionado con la puntuación predicha, entonces a ese predictor

puede dársele relativamente más peso debido a que proporciona información única. En contraste, si dos puntuaciones predictoras están altamente correlacionadas entre sí, podrían estar proporcionando información redundante. Si ambas se conservaran en la ecuación de regresión, cada una podría tener menos peso, de modo que “compartirían” la predicción de Y .

El hecho de contar con más predictores no es necesariamente mejor. Si dos predictores proporcionan la misma información, la persona que usa la ecuación de regresión puede decidir usar sólo uno de ellos en aras de la eficiencia. Si el director de la escuela De Sade observó que las puntuaciones de la prueba de admisión de la escuela de odontología y las puntuaciones en la prueba de habilidades motoras finas estaban muy correlacionadas entre sí, y que cada una de estas puntuaciones se correlacionaba más o menos igual con el promedio de calificaciones, el director podría decidir usar sólo un predictor debido a que no se gana nada al agregar un segundo predictor.

Inferencia a partir de la medición

La correlación, la regresión y la regresión múltiple son todas herramientas estadísticas usadas para ayudar a asegurarse de que las predicciones o inferencias extraídas de los datos de una prueba son razonables y, en la medida en que sea posible desde el punto de vista técnico, precisos. Otra herramienta estadística que puede ser útil para lograr estos objetivos es el metaanálisis.

Metaanálisis

Por lo general, la mejor estimación de la correlación entre dos variables no proviene de un estudio aislado, sino del análisis de los datos de varios estudios. Sin embargo, es probable que los datos provenientes de diferentes estudios contengan coeficientes de correlación y otros estadísticos que difieran de un estudio a otro. Una opción para facilitar la comprensión de la investigación a través de distintos estudios, es presentar el rango de valores estadísticos que aparecen en varios estudios: “La correlación entre la variable X y la variable Y varía de .73 a .91”. Otra opción es combinar estadísticamente la información a través de varios estudios. Esta combinación estadística de información entre estudios se denomina **metaanálisis**. El metaanálisis produce una sola estimación de la estadística que está en estudio. Por ejemplo, véase el metaanálisis de Kuncel *et al.* (2001) para el Examen de registro para graduados (Graduate Record Examination o GRE). Mediante el uso de cierta cantidad de estudios publicados, estos investigadores exploraron el valor predictivo del GRE y el promedio de calificaciones obtenidos durante la licenciatura para predecir el desempeño de los estudiantes en la escuela de posgrado.

Una ventaja clave del metaanálisis sobre el simple reporte de un rango de hallazgos es que en el metaanálisis se confiere más peso a los estudios que tienen cantidades mayores de sujetos. Este proceso de ponderación da como resultado estimaciones más precisas (Hunter y Schmidt, 1990). A pesar de este hecho y de otras ventajas (Hall y Rosenthal, 1995), el metaanálisis se considera, en cierto grado, tanto un arte como una ciencia. El valor de la investigación metaanalítica depende mucho de la habilidad y capacidad del metaanalista (Kavale, 1995).

Cultura e inferencia

En una serie de experimentos sobre conformidad, Solomon Asch (1951, 1955, 1957a, 1957b) demostró la profunda influencia de las opiniones de los miembros de un grupo acerca de un individuo. En una versión del experimento, los sujetos estaban sentados alrededor de una mesa y se les dijo que su tarea sería seleccionar en forma verbal una de tres líneas que eran de la misma longitud que una línea de estímulo. En realidad, sólo uno de los miembros del grupo era un sujeto verdadero; todos los demás integrantes del grupo eran confederados (cómplices) del experimentador que, luego de una señal, nombrarían en forma unánime la misma línea equivocada.

Asch encontró que bajo tales circunstancias el 76% de los sujetos se conformaron con la elección del grupo que era incorrecta en forma obvia al menos una vez. Desde mediados de la década de 1950, 133 estudios en 17 países han empleado el paradigma del juicio de la línea de Asch para estudiar el conformismo. Un metaanálisis de dichos estudios sacó a la luz diferencias en los resultados como una función de si la cultura en la que se realizó el estudio es colectivista o individualista. Bond y Smith (1996) concluyeron que los países colectivistas mostraron evidencias de niveles superiores de conformidad que los países identificados como de naturaleza más individualista.

El metaanálisis de la investigación internacional de Bond y Smith (1996) en el que se utilizaron tareas sobre juicios de tipo de línea de Asch proporciona un punto de partida útil para enfatizar el papel de la cultura y el contexto en la medición y el proceso de hacer inferencias. Al describir a las personas en términos de rasgos como, por ejemplo, “conformista” contra “no conformista”, es necesario ser claros respecto a las normas de comparación; en este caso, ¿conformista o no conformista con referencia a qué o a quién?

Considere en este contexto a un individuo que procede de un país colectivista como China, quien se muda a un país muy individualista como Estados Unidos. En China, la persona puede haber sido vista como no conformista dada la norma de conformidad en China. Sin embargo, en Estados Unidos, el comportamiento de esta persona podría ser visto como conformista. Con toda probabilidad, el rasgo relacionado con el conformismo de la personalidad de este individuo no se invirtió por sí solo como resultado de abordar un avión hacia Estados Unidos. Lo que cambió fue el ambiente o contexto que enmarcaba el comportamiento bajo escrutinio. En la relación figura-fondo, se sabe que un cambio de fondo puede afectar de manera marcada la percepción que se tiene de la figura.

Además de la cultura, podemos observar otras variables para obtener claves contextuales útiles con los cuales interpretar y analizar los datos de evaluación. Una de tales claves contextuales es lo que se conoce de manera variada como la era, la generación, o los “tiempos” en que un individuo nació y creció. Al recordar su propia juventud, la antropóloga Margaret Mead (1978, p. 71) escribió, “Nosotros crecimos bajo cielos que nunca habían sido surcados por satélites”. Al interpretar datos de evaluación de personas de diferentes generaciones, podría parecer útil tener en mente si los satélites habían surcado o no el cielo. De manera más general, Rogler (2002) ha subrayado la necesidad de dar importancia al contexto histórico en la evaluación.

SÓLO PIENSE...

Mencione un evento en la historia reciente que pueda ser relevante al interpretar datos provenientes de una evaluación psicológica.

Ahora volveremos brevemente al tema de las normas, con lo que se pasará del enfoque de las evaluaciones a un aspecto metodológico más amplio, en la práctica cotidiana de las pruebas y la evaluación. Por lo general las normas de la prueba proporcionan el ambiente y los antecedentes para enmarcar el comportamiento bajo escrutinio. En la mayor parte de los casos, como en el caso

de la gran mayoría de las pruebas estandarizadas, las normas de la prueba vienen en forma de tablas, publicadas en el manual de la prueba.⁹ Los aplicadores de las pruebas y los profesionales de la evaluación tienen la obligación de usar las normas apropiadas cuando intenten derivar un significado y hacer inferencias a partir de los datos derivados de las pruebas, entrevistas y otras herramientas de evaluación psicológica. En reconocimiento a esta obligación profesional, cada vez es más común leer acerca de evaluaciones publicadas sobre las normas existentes para su uso en poblaciones particulares. Además, es cada vez más común leer sobre proyectos de normalización realizados después de la publicación de una prueba particular, por lo general con grupos que no se incluyeron en la muestra normativa original o que se cree están subrepresentados en

9. Con menos frecuencia, como en el caso de una prueba proyectiva usada por un clínico de manera idiosincrásica, las normas son más subjetivas e intuitivas. Esto es, no son el producto de una investigación normativa formal sino de la propia educación, entrenamiento y experiencia clínica y del usuario de la prueba.

Tabla 4-1
Evaluación culturalmente informada: Algunos “qué hacer” y “qué no hacer”

Qué hacer	Qué no hacer
Estar informado de las suposiciones culturales sobre las que se basa una prueba	Dar por sentado que una prueba se basa en suposiciones que impactan a todos los grupos de la misma forma
Considerar una consulta con miembros de comunidades culturales particulares en relación con lo apropiado que resultan determinadas técnicas de evaluación, pruebas o reactivos	Dar por hecho que los miembros de todas las comunidades culturales considerarán de manera automática que las técnicas, las pruebas o los reactivos en las pruebas particulares son apropiados para su uso
Esforzarse por incorporar métodos de evaluación que complementen la visión del mundo y el estilo de vida de los evaluados que provengan de una población cultural y lingüística particular	Adoptar la visión de “un tamaño se ajusta a todos” cuando se realiza una evaluación a personas de variadas poblaciones culturales y lingüísticas
Informarse de las muchas pruebas o procedimientos alternativos de medición que pueden usarse para alcanzar los objetivos de la evaluación	Seleccionar pruebas u otras herramientas de evaluación con poca o ninguna consideración del grado en que dichas herramientas son apropiadas para ser usadas con los evaluados
Estar actualizado en los aspectos de equivalencia entre culturas, lo que incluye la equivalencia de lenguaje y los constructos medidos	Suponer de manera simple que una prueba traducida a otro idioma es, en forma automática, equivalente a la original en todos los aspectos.
Calificar, interpretar y analizar los datos de la evaluación en su contexto cultural, con la debida consideración de las hipótesis culturales como posibles explicaciones de los hallazgos	Calificar, interpretar y analizar la evaluación en un vacío cultural

esa muestra.¹⁰ También, en años recientes se ha dado una atención creciente a las cuestiones técnicas y multifacéticas respecto a la adaptación de una prueba estandarizada y normalizada con miembros de una cultura, para su uso con miembros de otra cultura.

A lo largo de todo este libro está implícita la discusión acerca de la importancia de la cultura en el campo de la evaluación. En este punto, resulta apropiado introducir algunos “qué hacer” y “qué no hacer” en relación con la *evaluación culturalmente informada* (este término se desarrolla en el capítulo 11). Considere los lineamientos que se presentan en la tabla 4-1 como una lista de temas que podrían ser repetidos en diferentes formas mientras se continúa aprendiendo acerca del campo de la evaluación. Para complementar esta lista, se recomienda al lector interesado consultar los lineamientos publicados en 2003 por la Asociación Psicológica Americana (American Psychological Association). Por ahora, continuemos en la construcción de un cimiento sólido en el tema de la evaluación y la medición con una exposición acerca del concepto psicométrico de confiabilidad en el siguiente capítulo.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo al intentar explicar cada uno de los siguientes términos, expresiones y abreviaturas:

coeficiente de correlación	constructo	estado
coeficiente de correlación de orden de rango/diferencia de rango	correlación	estandarización
coeficiente de determinación	criterio	gráfica de dispersión
coeficiente de regresión	desplazados	intercepción
	error estándar de estimación	metaanálisis

10. Hay otras situaciones que pueden promover una evaluación de la pertinencia de las normas existentes o estimular la elaboración de nuevas normas. Estas situaciones incluyen sustituir una subprueba por otra subprueba, abreviar una prueba de alguna forma o hacer cualquier desviación de las instrucciones de administración de la prueba en el manual (Lyons y Scotti, 1994; McCusker, 1994; Reynolds *et al.*, 1996).

método equipercantil	normas de programa	puntuación del grupo de referencia
muestra	normas de subgrupo	fijo
muestra de conveniencia	normas del usuario	puntuaciones equivalentes de edad
muestra incidental	normas locales	r de Pearson
muestra normativa	normas nacionales	rasgo
muestreo	normas nacionales ancladas	recta o línea de regresión
muestreo aleatorio estratificado	percentil	regresión
muestreo de dominio	porcentaje correcto	regresión múltiple
muestreo estratificado	prueba y evaluación con referencia a	regresión simple
muestreo intencional	un criterio	rho de Spearman
norma	prueba y evaluación con referencia a	teoría de puntuación verdadera
normalización	una norma	varianza del error
normalización de carrera	prueba y evaluación con referencia al	$Y = a + bX$
normas de edad	contenido	
normas de grado	puntuación acumulativa	

Un vistazo a la red

Consulte los siguientes sitios en la red para obtener más información acerca de los temas discutidos en este capítulo.

Supuesto 7: las pruebas y la evaluación son benéficas para la sociedad

<http://chiron.valdosta.edu/mawhatley/3900/testmeas.htm>

Sitio de la APA en la red: Cómo encontrar información sobre "buenas" pruebas psicológicas

www.apa.org/science/faq-findtests.html

Pruebas con referencia a un criterio contra pruebas con referencia a una norma (tabla básica)

<http://chiron.valdosta.edu/whuitt/col/measeval/crnmref.html>

Coefficiente de correlación de Pearson

www.texasoft.com/winkpear.html

Confiabilidad y validez

www.sportsci.org/resource/stats/precision.html

Correlación

www.stat.uiuc.edu/courses/stat100/java/guess/GCApplet.html

<http://noppa5.pc.helsinki.fi/koe/corr/cor7.html>

<http://stat-www.berkeley.edu/users/stark/java/Correlation.htm>

Regresión

www.stat.sc.edu/~west/javahtml/Regression.html

www.math.csusb.edu/faculty/stanton/m262/regress/regress.html

www.stat.uiuc.edu/courses/stat100/java/guess/PPApplet.html

Confiabilidad

En lenguaje cotidiano, *confiabilidad* es *sinónimo* de *seguridad o consistencia*. En Estados Unidos, por ejemplo, se dice: “El tren es tan confiable que puedes sincronizar tu reloj con él”. “Si somos afortunados, tendremos un amigo de confianza que siempre estará cuando se le necesite.”

En sentido amplio, en el *lenguaje de la psicometría*, *confiabilidad* se refiere al atributo de *consistencia en la medición*. Mientras que en la conversación cotidiana *confiabilidad* siempre denota algo que es valorado en forma positiva, *en sentido psicométrico tan sólo denota algo que es consistente, sin que sea de modo necesario bueno o malo, tan sólo consistente*.

Es importante para nosotros, como usuarios de pruebas y consumidores de información sobre ellas, saber qué tan confiables son, al igual que con otros métodos de medición. *Pero la confiabilidad no es una cuestión de todo o nada*. En cierto contexto, podemos tener confianza en una prueba y en otro, desconfiar de ella. *Hay diferentes tipos y grados de confiabilidad*. Un *coeficiente de confiabilidad* es un *índice de confianza*, una proporción que *indica la razón entre la varianza de la puntuación verdadera en una prueba y la varianza total*. En este capítulo, exploraremos diferentes clases de coeficientes de confiabilidad, incluyendo aquellos para medir la confiabilidad de la aprobación de la prueba y postprueba, la confiabilidad de formas alternativas, la confiabilidad de dividir en mitades y la confiabilidad entre evaluadores.

El concepto de confiabilidad

De nuestra revisión de la *teoría clásica de “prueba”*, en el capítulo 1, recordará que la *puntuación en una prueba de capacidad, se supone, refleja la verdadera puntuación del evaluado en cuanto a la habilidad que se está midiendo*, así como el *error que presenta*.¹ En su sentido más amplio, *error* se refiere al *componente mismo de la puntuación en la prueba que no tiene nada que ver con la aptitud de quien la responde*. Si utilizamos *X* para representar una *puntuación observada*, *T* para una *puntuación verdadera* y *E* para el *error*, entonces el hecho de que una puntuación observada sea igual a la puntuación verdadera más el error, puede expresarse como sigue:

$$X = T + E$$

1. Con propósitos de ilustración, con frecuencia se usa la capacidad como un rasgo a medir. Sin embargo, a menos que se declare de otra manera, los principios referidos con respecto a las pruebas de capacidad también son ciertos con respecto a otro tipo de pruebas, como las de personalidad. Por tanto, de acuerdo con el modelo de puntuación verdadera, también es cierto que la magnitud de la presencia de un rasgo psicológico (como la extroversión) medido con una prueba de extroversión se deberá a 1) la cantidad “verdadera” de extroversión y 2) otros factores.

Una estadística útil para describir fuentes de variabilidad en las puntuaciones de una prueba es la **varianza** (σ^2), la desviación estándar al cuadrado. Esta estadística es útil debido a que puede fragmentarse en sus componentes. La varianza de las diferencias reales es la **varianza verdadera** y la **varianza de fuentes aleatorias irrelevantes es la varianza de error**. Si (σ^2) representa la **varianza total**, (σ_{tr}^2) representa la **varianza verdadera** y (σ_e^2) representa la **varianza de error**, entonces la relación de las varianzas puede expresarse como:

$$\sigma^2 = \sigma_{tr}^2 + \sigma_e^2$$

En esta ecuación, la varianza total observada en una distribución de puntuaciones de prueba (σ^2) es igual a la suma de la **varianza verdadera** (σ_{tr}^2) más la **varianza de error** (σ_e^2). El término **confiabilidad** se refiere a la **proporción de la varianza total atribuida a la varianza verdadera**. Entre mayor es la **proporción de la varianza total atribuida a la varianza verdadera**, más **confiable es la prueba**. Debido a que **se supone que las diferencias reales son estables**, se presume que **producen puntuaciones consistentes en aplicaciones repetidas de la misma prueba al igual que en formas equivalentes de ésta**. Debido a que la **varianza de error puede incrementar o disminuir en cantidades variables una puntuación de alguna prueba**, se vería afectada la consistencia en la puntuación y por tanto en la **confiabilidad**.

SÓLO PIENSE...

¿Cuál podría ser una fuente de error sistemático inherente a todas las pruebas que un evaluador aplica en su privado?

Subrayemos aquí que una **fuentes sistemática de error no afectaría la consistencia de la puntuación**. Si un instrumento de medición, como una báscula, marcara de modo consistente 2.5 kilogramos menos a todos los individuos que se pesaran en ella, entonces el peso relativo de las personas permanecería sin cambio. Por supuesto, los pesos registrados como suyos variarían en forma consistente 2.5 kilogramos del peso real. Una escala que indique 2.5 kilogramos menos de peso a todos los que la usan es análoga a una constante que se resta (o se suma) de cada puntuación. **Una fuente de error sistemática no cambia la variabilidad de la distribución ni afecta la confiabilidad.**

Fuentes de varianza de error

Las fuentes de error de varianza **incluyen la construcción, administración, calificación y/o interpretación de la prueba.**

Construcción de pruebas Una **fuentes de varianza durante la construcción de pruebas es el muestreo de reactivos o muestreo de contenido**, términos que **se refieren a la variación entre reactivos contenidos en una prueba**, así como a la **variación entre los reactivos de diversas pruebas**. Considere **dos o más pruebas diseñadas para medir una habilidad, atributo de personalidad o conjunto de conocimientos específicos**. **Es seguro que se encontrarán diferencias en la forma en que están redactadas las preguntas y en el contenido exacto usado como muestra**. Es probable que todos hayamos entrado a un salón en donde se iba a aplicar una prueba de rendimiento, pensando: "Ojalá hagan esta pregunta" o "Espero que no hagan esta otra". Con suerte, sólo aparecerán en el examen las preguntas que deseamos nos hagan. En tales situaciones, un evaluado conseguiría una puntuación más alta en una prueba, en oposición a otra que intente medir lo mismo. **La puntuación más alta podría deberse al contenido usado como muestra, a la forma en que se redactaron los reactivos y así en forma sucesiva**. **El grado en que la puntuación de un evaluado es afectada sólo por el contenido de la prueba así como por la forma en que es manejado dicho contenido (es decir, la forma en que está construido el reactivo) es una fuente de varianza de error**. Desde la **perspectiva de un desarrollador o creador de pruebas**, un desafío en la elaboración de éstas, es **maximizar la proporción de la varianza total que es la varianza verdadera y minimizar la proporción de la varianza total que se le considera varianza de error**.

Administración de pruebas Las **fuentes de varianza de error que ocurren durante la aplicación de la prueba pueden influir en la atención o motivación de quien responde la prueba**; por tanto, sus reacciones ante estas influencias son la fuente de una clase de varianza de error. **Ejemplos**

de influencias desfavorables que operan durante la aplicación de una prueba incluyen factores relacionados con el ambiente durante la prueba: la temperatura de la habitación, el nivel de iluminación y la cantidad de ventilación y ruido, por ejemplo. La cara de un examinado puede ejercer una atracción tenaz sobre una mosca; una goma de mascar sobre la silla, que delata su presencia sólo hasta que un examinado se ha sentado encima de ella, etc. Otras variables relacionadas con el ambiente incluyen desde el instrumento usado para escribir las respuestas, hasta la superficie sobre la que se escribe. Un lápiz con la punta gastada o rota puede impedir el llenado de las respuestas. La superficie sobre la que está escribiendo el evaluado puede estar marcada con corazones grabados, legado de estudiantes de años anteriores que se sintieron obligados a expresar su devoción eterna a alguien a quien es probable que ahora hayan olvidado.

Otras fuentes potenciales de varianza de error durante la aplicación de la prueba incluyen variables del examinado. Los problemas emocionales, la incomodidad física, la carencia de descanso y el efecto de drogas y medicamentos, todos pueden ser fuentes de varianza de error. Una persona que responde una prueba puede, por cualquier razón, cometer un error al dar una respuesta. Por ejemplo, el examinado pudo haber rellenado el óvalo “b” cuando quería rellenar el “d”; un examinado podría equivocarse al leer una pregunta. Por ejemplo, pudo haber leído “¿cuál sería una causa de la varianza de error?”, en lugar de “¿cuál no sería una causa de varianza de error?”. Otras omisiones simples pueden tener consecuencias directamente proporcionales en la puntuación o calificación. Por ejemplo, al responder el quinto reactivo en un examen de opción múltiple, el examinado pudo haber rellenado el círculo de la sexta pregunta. El simple hecho de saltarse una pregunta hará que cada respuesta subsecuente esté fuera de lugar. Las experiencias de aprendizaje formales, las experiencias casuales de la vida, terapias, enfermedades y otros acontecimientos parecidos también serán fuentes de la varianza de error relacionadas con el examinado.

Las variables relacionadas con el examinador son fuentes potenciales de varianza de error. La apariencia física y comportamiento del examinador y hasta la presencia o ausencia de un examinador, son factores a considerar. En algunas situaciones de prueba, algunos examinadores pueden apartarse a sabiendas, o sin darse cuenta, del procedimiento prescrito para aplicar una prueba en particular. En un examen oral, sin querer, algunos examinadores podrían proporcionar claves planteando preguntas que enfatizan diversas palabras. Pueden transmitir información de manera inadvertida sobre la corrección de una respuesta por medio de asentimientos de cabeza, movimientos oculares u otros gestos no verbales. De manera clara, el nivel de profesionalismo mostrado por los examinadores es una fuente de la varianza de error.

Calificación e interpretación de pruebas El advenimiento de la calificación computarizada y una creciente dependencia de reactivos objetivos calificables por computadora han eliminado la varianza de error causada por diferencias de los evaluadores en muchas pruebas. Sin embargo, no todas las pruebas pueden calificarse con óvalos rellenos con lápices del número 2. Las pruebas de inteligencia administradas en forma individual, algunas de personalidad, de creatividad, diversas medidas conductuales y otras innumerables pruebas todavía requieren ser calificadas en forma manual por personal capacitado.

Los manuales para las pruebas de inteligencia individuales tienden a ser muy explícitos sobre los criterios de calificación para que la inteligencia medida de los examinados no varíe como una función de quien está aplicando y calificando la prueba. En algunas pruebas de personalidad, se les pide a los examinados que suministren respuestas abiertas ante estímulos como dibujos, palabras, oraciones y manchas de tinta y es el examinador quien luego debe calificar, o quizá sea más apropiado decir evaluar/interpretar, las respuestas. En una prueba de creatividad, se les podría asignar a los evaluados la tarea de crear tantas cosas como puedan con un conjunto de bloques. Aquí, la tarea del examinador es determinar a cuáles construcciones de bloques se les daría crédito y a cuáles no. Para una medida conductual de habilidades sociales en un paciente interno en algún hospital psiquiátrico, a los calificadores o evaluadores podría pedírseles que estimaran a los pacientes con respecto a la variable asignada como “relación social”. Dicha medida conductual podría requerir que el evaluador marcara “sí” o “no” en reactivos como: *El paciente dijo “Buenos días” al menos a dos integrantes del personal.*

SÓLO PIENSE...

¿Puede usted concebir un reactivo de prueba en una escala de medición que requiera el juicio humano de que todos los evaluados obtendrán la misma puntuación el 100% de las veces?

Las personas que califican y los sistemas de calificación son fuentes potenciales de la varianza de error. Una prueba puede emplear reactivos de tipo objetivo que se pueden someter a una calificación computarizada confiable. Pero aún así, existe la posibilidad de una falla técnica que contamine los datos. Si la subjetividad está relacionada en la calificación, el calificador (o evaluador) puede ser una fuente de varianza de error. En efecto, a pesar del establecimiento riguroso de criterios de calificación en muchas de las pruebas de inteligencia más conocidas, el examinador y los calificadores en ocasiones encontrarán situaciones donde la respuesta de un examinando caiga en un área gris. El elemento de la subjetividad en la calificación puede ser mucho mayor en la aplicación de ciertas pruebas no objetivas del tipo de personalidad, exámenes de creatividad (como la prueba de bloques, descrita con anterioridad) y ciertas pruebas académicas como pruebas de ensayo. La subjetividad en la calificación también puede entrar en la evaluación del comportamiento. Considere el caso de dos observadores de la conducta, encargados de evaluar a un paciente psiquiátrico en la variable de “adaptación social”. En un reactivo que sólo pregunta si dos miembros del personal fueron saludados en la mañana, un evaluador podría juzgar que el contacto ocular del paciente y el hecho de haber masculado algo a dos miembros del personal califican como una respuesta *sí*. El otro observador podría considerar que un *no* es la respuesta apropiada. Tales problemas sobre el acuerdo en la calificación pueden abordarse por medio de una capacitación rigurosa diseñada para hacer que la consistencia, o confiabilidad, de varios calificadores sea lo más perfecta posible.

Otras fuentes de error Ciertos tipos de situaciones de evaluación se prestan a variedades particulares de error sistemático y no sistemático. Por ejemplo, considérese la evaluación del grado de acuerdo entre parejas respecto a la calidad y cantidad de abuso físico y psicológico en su relación. Como Moffitt *et al.* (1997) observaron: “Debido a que el abuso de la pareja por lo general ocurre en privado, sólo hay dos personas que ‘en realidad’ saben lo que sucede detrás de sus puertas cerradas: los dos miembros de la pareja” (p. 47). Las fuentes potenciales de error no sistemático en la evaluación de una situación así incluyen: olvido, dejar de notar el comportamiento abusivo y entender mal las instrucciones respecto al reporte. Varios estudios (O’Leary y Arias, 1988; Riggs *et al.*, 1989; Straus, 1979) han sugerido que la escasez de reportes o una demasía de ellos respecto a la perpetración de abuso pueden contribuir a un error sistemático. Las mujeres, por ejemplo, pueden reportar menos los abusos debido al temor, vergüenza o factores de conveniencia social y reportar más abuso si están buscando ayuda. Los hombres pueden reportar menos abuso debido a vergüenza y factores de conveniencia social y reportar más abuso si están intentando justificar el reporte.

SÓLO PIENSE...

Recuerde la puntuación del examen más reciente que haya tomado. ¿Qué porcentaje de esa puntuación considera usted que representa su capacidad “verdadera” y qué porcentaje, el error? Ahora, haga una suposición de cuáles fueron los tipos de error implicados.

Así como es probable que nunca sepamos la cantidad de abuso que en realidad sufre una persona a manos de su pareja, así puede ser que nunca conozcamos la cantidad de la varianza verdadera relativa al error. Una supuesta puntuación verdadera, como lo planteó Stanley (1971, p. 361), “no es el último hecho en el libro del ángel que lleva el registro”. Además, la utilidad de los métodos actuales para estimar la varianza verdadera en contraposición a la varianza de error es una cuestión que se debate en forma acalorada

(véase, por ejemplo, Collins, 1996; Humphreys, 1996; Williams y Zimmerman, 1996a, 1996b). Veamos con más detalle estas estimaciones y el proceso para derivarlas.

Estimaciones de confiabilidad

Estimaciones de confiabilidad test-retest

Una regla hecha con el acero de la mejor calidad puede ser un instrumento de medición muy confiable; cada vez que se mide algo que tiene exactamente 12 centímetros de largo, por ejemplo, la regla indicará que lo que se está midiendo tiene exactamente 12 centímetros de largo. También puede decirse que la confiabilidad de este instrumento de medición es estable en el tiempo. Ya

sea que se midan los 12 centímetros hoy, mañana o el próximo año, la regla aún medirá los 12 centímetros como tal. Por el contrario, una regla construida de masilla podría ser un instrumento de medición muy poco confiable. En cierto momento podría medir algún objeto de 12 centímetros de largo como 12 centímetros, en otro podría medirlo como 14 y una semana después, como 18. Una forma de estimar la confiabilidad de un instrumento de medición es usar ese mismo instrumento para medir lo mismo en dos momentos aislados en el tiempo. En el lenguaje psicométrico, este enfoque de la valoración de la confiabilidad se llama *método test-retest* y el resultado de dicha evaluación es una estimación de la *confiabilidad test-retest*.

La *confiabilidad test-retest* es una estimación de la confiabilidad obtenida al correlacionar pares de puntuaciones de las mismas personas en dos aplicaciones diferentes de la misma prueba. La medida test-retest es apropiada cuando se valora la confiabilidad de una prueba que pretende medir algo relativamente estable a lo largo del tiempo, como un rasgo de personalidad. Si se supone que la característica que se está midiendo fluctúa con el tiempo, tendría poco sentido evaluar la confiabilidad de una prueba usando el método test-retest.

Conforme pasa el tiempo, las personas cambian, pueden, por ejemplo, aprender cosas nuevas, olvidar otras y adquirir nuevas habilidades. Por lo general, aunque hay excepciones, conforme se incrementa el intervalo de tiempo entre las aplicaciones de las mismas pruebas, disminuye la correlación entre las puntuaciones obtenidas en cada una. El paso del tiempo puede ser una causa de la varianza de error. Entre más tiempo pase, es más probable que el coeficiente de confiabilidad sea menor. Cuando el intervalo entre las pruebas es mayor a seis meses, a menudo se hace referencia a la estimación de la confiabilidad test-retest como *coeficiente de estabilidad*.

Una estimación de la confiabilidad test-retest de un examen de matemáticas podría ser baja si quienes respondieron la prueba tomaron un curso de matemáticas antes de que se les aplicara ésta por segunda vez. Una estimación de la confiabilidad test-retest de un perfil de personalidad podría ser baja si quien la responde sufrió algún trauma emocional o recibió orientación durante el periodo intermedio. Puede encontrarse una estimación baja en la confiabilidad test-retest aun cuando el intervalo entre ellas sea relativamente breve. Éste bien puede ser el caso cuando las pruebas ocurren durante un tiempo de grandes cambios en el desarrollo referente a las variables para cuya evaluación fueron diseñadas. Por consiguiente, la evaluación de un coeficiente de confiabilidad test-retest debe extenderse más allá de la significación del coeficiente obtenido. Si lo que se pretende es obtener conclusiones propias sobre la confiabilidad de un instrumento de medición, el evaluar la estimación de la confiabilidad test-retest debe ampliarse a una consideración de los posibles factores que intervienen entre las aplicaciones del examen.

Una estimación de la confiabilidad test-retest puede ser más apropiada para calibrar la confiabilidad de exámenes que emplean como medidas de resultados el tiempo de reacción o juicios perceptivos (como discriminaciones de brillantez, sonoridad o gusto). Sin embargo, incluso al medir variables como éstas y aun cuando el periodo entre las dos aplicaciones de la prueba sea relativamente pequeño, nótese que pueden intervenir diversos factores (como experiencia, práctica, memoria, fatiga y motivación) y alterar una medida de confiabilidad obtenida.²

Estimaciones de confiabilidad de formas paralelas y formas alternas

Si alguna vez usted ha presentado un segundo examen en el que las preguntas no eran iguales a las de la prueba inicial, ha experimentado con formas diferentes de una prueba. Y si alguna vez se ha preguntado si en realidad las dos formas de la prueba eran equivalentes, habrá cuestionado

2. Aunque nos podemos referir a un número como una declaración sumaria de confiabilidad en las herramientas de medición individuales, cualquiera de estos índices de confiabilidad sólo puede interpretarse de manera significativa en el contexto del proceso de medición —las circunstancias únicas que rodean al uso de la regla, la prueba o algún otro instrumento de medición en una aplicación o situación particular—. Se analizará más de este tema en capítulos posteriores.

la confiabilidad de las *formas alternas* o *formas paralelas* de la prueba. El grado de la relación entre varias formas de una prueba puede evaluarse por medio de un coeficiente de confiabilidad de *formas alternas* o *equivalentes*, al cual a menudo se le denomina **coeficiente de equivalencia**.

Aunque con frecuencia se usan de manera indistinta los términos *formas alternas* y *formas paralelas*, existe una diferencia entre ellos. Existen **formas paralelas** de una prueba cuando, para cada forma del examen, las medias y las varianzas de las puntuaciones de la prueba observada son iguales. En teoría, las medias de las puntuaciones obtenidas en formas paralelas se correlacionan de manera igual con la puntuación verdadera. De manera más práctica, las puntuaciones obtenidas en pruebas paralelas se correlacionan de modo igual con otras medidas.

Las **formas alternas**, de modo simple, son versiones diferentes de una prueba que se han construido para que sean paralelas. Aunque no cumplen con los requisitos para la designación legítima de “paralelas”, las formas alternas de una prueba generalmente están diseñadas para ser equivalentes con respecto a variables como contenido y nivel de dificultad.

SÓLO PIENSE...

Usted perdió el examen de mitad del semestre y tiene que hacer uno de reposición. Sus compañeros de clase le han dicho que el examen les pareció difícil de resolver. Su profesor le dice que usted tomará una forma alternativa, no una forma paralela, de la prueba original. ¿Cómo se sentiría al respecto?

La obtención de las estimaciones de **confiabilidad de las formas paralelas** y de las **alternas** es similar en dos formas a la obtención de un estimado de la confiabilidad test-retest: 1) Se requieren dos aplicaciones de la prueba con el mismo grupo y 2) Las puntuaciones obtenidas pueden ser afectadas por factores como la motivación, la fatiga o eventos que intervienen en el manejo personal como la práctica, el aprendizaje o la terapia (aunque no tanto como cuando la misma prueba se administra dos veces). Una fuente adicional en la varianza de error, el **muestreo de reactivos**, es inherente al cálculo de un coeficiente de confiabilidad de formas alternas o paralelas. Quienes responden las pruebas pueden salir mejor o

peor en una forma específica de la prueba, no como una función de su capacidad verdadera, sino tan sólo debido a los reactivos particulares que se seleccionaron para ser incluidos.³

El desarrollo de formas alternas de pruebas puede consumir mucho tiempo y ser muy costoso. Piense en todo lo que implicaría crear conjuntos de preguntas equivalentes y hacer que las mismas personas acudan a repetidas aplicaciones de una prueba experimental. Por otra parte, una vez que se ha desarrollado una forma alterna o paralela de un examen, se obtienen ventajas de muchas maneras para el usuario de la prueba.

SÓLO PIENSE...

Desde la perspectiva del evaluador, ¿cuáles son otras posibles ventajas de tener formas alternas o paralelas de la misma prueba?

Se presume que ciertos rasgos son relativamente estables en la gente a través del tiempo y se puede esperar que las pruebas que midan esos rasgos sean formas alternas, equivalentes o de algún otro tipo y que reflejen esa estabilidad. Como ejemplo, esperaríamos que hubiera y de hecho hay, un grado razonable de estabilidad en las puntuaciones en las pruebas de inteligencia.

A la inversa, podríamos esperar que hubiera relativamente poca estabilidad en las puntuaciones obtenidas en una medida del estado de ansiedad (ansiedad experimentada en el momento).

Se puede obtener un estimado de la confiabilidad de una prueba sin elaborar una forma alterna de la misma y sin tener que administrarla dos veces a las mismas personas. La derivación de este tipo de estimado implica una evaluación de la *consistencia interna* de las preguntas de la prueba. De manera lógica, se le conoce como una **estimación de la confiabilidad de la consistencia interna** o como una **estimación de la consistencia entre reactivos**. Existen diferentes métodos para obtener estimaciones de confiabilidad de la consistencia interna. Uno de dichos métodos es la *estimación de dividir en mitades*.

3. De acuerdo con el modelo clásico de puntuación verdadera, el efecto de tales factores en las puntuaciones de las pruebas se supone que es de hecho, un error de medición. Hay modelos alternativos en los que el efecto de dichos factores en puntuaciones fluctuantes de prueba no sería considerado error (Atkinson, 1981).

Estimaciones de la confiabilidad de dividir en mitades

Una estimación de la **confiabilidad de dividir en mitades** se obtiene correlacionando dos pares de puntuaciones obtenidas de mitades equivalentes de una sola prueba aplicada una sola vez. Es una útil medida de confiabilidad cuando es poco práctico o indeseable evaluar la confiabilidad con dos pruebas o hacer dos aplicaciones de una misma prueba (debido a factores como tiempo o costo). El cálculo de un coeficiente de confiabilidad de dividir en mitades por lo general implica tres pasos:

Paso 1. Dividir la prueba en mitades equivalentes.

Paso 2. Calcular una r de Pearson entre las puntuaciones en las dos mitades de la prueba.

Paso 3. Ajustar la confiabilidad de una mitad de la prueba usando la fórmula de Spearman-Brown (discutida en breve).

Cuando se trata de calcular los coeficientes de confiabilidad de división por mitades, existe más de una forma de dividir una prueba, pero hay varias formas en las que ésta *nunca* se debe dividir. No se recomienda tan sólo dividir la prueba en mitades, debido a la probabilidad de que este procedimiento eleve o disminuya en forma falsa el coeficiente de confiabilidad. Deben considerarse factores como diferentes grados de fatiga en la primera parte de la prueba, en contraposición a la segunda parte, cantidades diferentes de ansiedad y diferencias en la dificultad de los reactivos como una función de su ubicación dentro de la prueba.

Una forma aceptable de dividir una prueba es asignar al azar las preguntas a una u otra mitad de la prueba. Una segunda forma aceptable de dividir una prueba es asignar las preguntas con números nones a una mitad de la prueba y las identificadas con números pares a la otra mitad. Este método produce una estimación de la confiabilidad de dividir en mitades, a la que también se le llama **confiabilidad non-par**.⁴ Aún otra manera es dividir la prueba por contenido de modo que cada mitad de la prueba contenga reactivos equivalentes con respecto al contenido y la dificultad. En general, un objetivo primario al dividir una prueba en mitades con el propósito de obtener una estimación de la confiabilidad de dividir en mitades es crear lo que podría denominarse “mini formas paralelas”, con cada mitad siendo igual a la otra o lo más cercano posible a esto, en aspectos de formato, estilísticos, estadísticos y otros relacionados.

El paso 2 del procedimiento implica el cálculo de una r de Pearson, lo cual requiere poca explicación en este punto. Sin embargo, el tercer paso requiere el uso de la fórmula de Spearman-Brown.

La fórmula de Spearman-Brown La fórmula de Spearman-Brown permite a quien elabora la prueba o al usuario de la misma, estimar la confiabilidad de su consistencia interna a partir de la correlación de las dos mitades. Es una aplicación específica de una fórmula más general para estimar la confiabilidad de una prueba que se ha alargado o acortado en cualquier cantidad de reactivos. Debido a que la confiabilidad de una prueba es afectada por su longitud, es necesaria una fórmula para estimar la confiabilidad de un examen que se ha acortado o alargado. La fórmula general de Spearman-Brown (r_{SB}) es

$$r_{SB} = \frac{nr_{xy}}{1 + (n-1)r_{xy}}$$

donde r_{SB} es igual a la confiabilidad ajustada por la fórmula de Spearman-Brown, r_{xy} es igual a la r de Pearson en la prueba con la longitud original y n es igual al número de reactivos en la versión revisada dividido entre el número de reactivos en la versión original.

4. Precaución: con respecto a un grupo de reactivos en una prueba de rendimiento que enfrenta un solo problema, por lo general es deseable asignar el grupo entero de reactivos a una mitad de la prueba. De otra manera, si una sección del grupo estuviera en una mitad y la otra sección en la otra mitad, la semejanza de la mitad de las puntuaciones estaría inflada en forma falsa; un solo error de comprensión, por ejemplo, podría afectar los reactivos de ambas mitades de la prueba.

Tabla 5-1
Coefficientes de confiabilidad non-par antes
y después del ajuste con Spearman-Brown*

Grado	Correlación de la mitad de la prueba (r sin ajustar)	Estimación de la prueba (r_{SB})
K	.718	.836
1	.807	.893
2	.777	.875

*Para puntuaciones en una prueba de capacidad mental.

Para determinar la confiabilidad de la mitad de una prueba, un desarrollador de pruebas, puede entonces usar la fórmula de Spearman-Brown para estimar la confiabilidad de la prueba completa. Debido a que ésta es del doble de largo que su mitad, n se convierte en 2 en la fórmula de Spearman-Brown para el ajuste de la confiabilidad de dividir en mitades. El símbolo r_{hh} significa la r de Pearson de las puntuaciones en las dos mitades de la prueba:

$$r_{SB} = \frac{2r_{hh}}{1 + r_{hh}}$$

Por lo general, aunque no siempre, la confiabilidad se incrementa conforme aumenta la longitud de la prueba. De manera ideal, los reactivos adicionales son equivalentes respecto al contenido y rango de dificultad de los reactivos originales. Las estimaciones de confiabilidad basadas en la consideración de la prueba entera por consiguiente tenderán a ser mayores que aquellas basadas en la mitad. En la tabla 5-1 se muestran las correlaciones de la mitad de una prueba junto con estimaciones de confiabilidad ajustadas para la prueba entera. Puede verse que todas las correlaciones ajustadas son mayores que las correlaciones sin ajustar. Esto se debe a que las estimaciones de Spearman-Brown se basan en una prueba que es el doble de largo que la mitad de la original. Para los datos de alumnos de jardín de niños, por ejemplo, una confiabilidad de la mitad de una prueba de .718 puede estimarse que será equivalente a una confiabilidad de la prueba entera de .836.

Si los creadores o usuarios de las pruebas desean acortarla, la fórmula de Spearman-Brown puede ser usada para estimar el efecto del acortamiento en la confiabilidad de la prueba. La reducción en el tamaño de la prueba para disminuir el tiempo de su aplicación es una práctica común en ciertas situaciones. Por ejemplo, el administrador de la prueba puede tener sólo un tiempo limitado con quien o quienes la responden. La reducción del tamaño puede ser indicada en situaciones donde el aburrimiento o la fatiga podrían producir respuestas con significación cuestionable.

SÓLO PIENSE...

Mencione otras situaciones en las que sería deseable una reducción del tamaño de una prueba o del tiempo necesario para su aplicación, ¿cuáles serían los argumentos en contra de reducir el tamaño?

También podría usarse una fórmula de Spearman-Brown para determinar el número de reactivos necesarios para alcanzar un nivel deseado de confiabilidad. Al agregar preguntas para incrementar la confiabilidad de la prueba hasta un nivel deseado, la regla es que los reactivos nuevos deben ser equivalentes en contenido y dificultad de modo que la prueba más larga aún mida lo que la prueba original midió. Si la confiabilidad de la prueba original es relativamente baja, puede ser poco práctico incrementar

el número de reactivos para alcanzar un nivel de confiabilidad aceptable. Otra alternativa sería abandonar este instrumento relativamente poco confiable y localizar o elaborar una alternativa adecuada. La confiabilidad del instrumento también podría elevarse de alguna manera. Por ejemplo, la confiabilidad del instrumento podría elevarse mediante la creación de nuevos reactivos, aclarando las instrucciones de la prueba o simplificando las reglas de calificación.

Las estimaciones de confiabilidad de consistencia interna, como las obtenidas usando la fórmula de Spearman-Brown, son inapropiadas para medir la confiabilidad de pruebas heterogéneas y pruebas de velocidad. El impacto de las características de la prueba en la confiabilidad se estudia con mayor detalle más adelante en este capítulo.

Otros métodos de estimación de la consistencia interna

Además de la fórmula de Spearman-Brown, otros métodos que se usan para estimar la confiabilidad de la consistencia interna incluyen fórmulas desarrolladas por Kuder y Richardson (1937) y Cronbach (1951). **Consistencia entre reactivos** es un término que se refiere al grado de correlación entre todas las preguntas en una escala. Una medida de consistencia entre reactivos se calcula a partir de la sola aplicación de una forma única de una prueba. Un **índice de consistencia entre reactivos** es útil, a su vez, para evaluar la **homogeneidad** de la prueba. Se dice que las pruebas son **homogéneas** si contienen reactivos que midan un solo rasgo. Como un adjetivo usado para describir reactivos de prueba, **homogeneidad** (derivada de las palabras griegas *homos*, que significa “misma”, y *genos*, que significa “clase”) es el grado en que una prueba mide un solo factor; o sea, el grado en que los reactivos en una escala son unifactoriales.

En contraste con la homogeneidad de la prueba, la **heterogeneidad** describe el grado en que una prueba mide factores diferentes. Una **prueba no homogénea o heterogénea** se compone de reactivos que miden más de un rasgo. Podría esperarse que una prueba que sólo evalúe la habilidad de reparar televisores a color tuviera un contenido más homogéneo que una prueba de reparaciones electrónicas en general. La primera prueba sólo evalúa un área y la última, varias, como el conocimiento no sólo de televisores, sino también de reproductores de DVD, cámaras digitales, radios, videgrabadoras, reproductores de discos compactos, radio satélite, etcétera.

Entre más homogénea sea una prueba, más consistentes se espera que sean las preguntas. Debido a que una prueba homogénea ejemplifica un área de contenido relativamente reducida, tendrá más consistencia entre reactivos que una heterogénea. La homogeneidad de la prueba es deseable debido a que permite una interpretación relativamente directa de la puntuación de la prueba. Es probable que aquellos que obtengan la misma puntuación en una prueba homogénea posean capacidades parecidas en el área examinada. Aquellos que obtienen la misma puntuación en una prueba más heterogénea pueden tener capacidades bastante diferentes.

Aunque una prueba homogénea sea deseable debido a que se presta fácilmente a una clara interpretación, a menudo es una herramienta insuficiente para medir variables psicológicas multifacéticas como inteligencia o personalidad. Una forma de evitar esta fuente potencial de dificultad ha sido la aplicación de una serie de pruebas homogéneas, cada una diseñada para medir algún componente de una variable heterogénea.⁵

Las fórmulas de Kuder-Richardson La insatisfacción con los métodos existentes de dividir en mitades para estimar la confiabilidad llevó a G. Frederic Kuder y M. W. Richardson (1937; Richardson y Kuder, 1939) a **desarrollar sus propias medidas para estimar la confiabilidad**. La más conocida de las muchas fórmulas en las que colaboraron es su fórmula **20 Kuder-Richardson o KR-20** (llamada así debido a que fue la vigésima fórmula desarrollada en una serie). En caso de que los reactivos de la prueba sean demasiado homogéneos, la KR-20 y la estimación de la confiabilidad de dividir en mitades serán similares. Sin embargo, la KR-20 es la estadística a elegir para **determinar la consistencia entre reactivos de tipo dicotómicos**, sobre todo aquellos que pueden ser calificados como correctos o incorrectos (como los de opción múltiple). Si los reactivos de la prueba son más heterogéneos, la KR-20 producirá estimaciones de confiabilidad inferiores al **método de dividir en mitades**. En la tabla 5-2 se resumen los reactivos en una prueba heterogénea de muestra. Suponiendo que el nivel de dificultad de todos los reactivos en la prueba sea el mismo, ¿esperaría que una estimación de la confiabilidad de dividir en mitades (mitad nones-mitad pares) fuera bastante alta o baja?

5. Como se verá a lo largo de este libro, las decisiones importantes rara vez se toman en base a una sola prueba. Los psicólogos con frecuencia se basan en una **batería de pruebas** —una colección selecta de pruebas y procedimientos de evaluación— en el proceso de valoración. Una batería de pruebas se compone típicamente de pruebas diseñadas para medir variables diferentes.

Tabla 5-2
Áreas de contenido ejemplificadas para 18
reactivos de la Prueba hipotética de repa-
raciones electrónicas (PHRE)

Número de reactivo	Área de contenido
1	Televisión a color
2	Televisión a color
3	Televisión en blanco y negro
4	Televisión en blanco y negro
5	Radio
6	Radio
7	Videograbadora
8	Videograbadora
9	Computadora
10	Computadora
11	Reproductor de discos compactos
12	Reproductor de discos compactos
13	Receptor estereofónico
14	Receptor estereofónico
15	Cámara de video
16	Cámara de video
17	Reproductor de DVD
18	Reproductor de DVD

¿Cómo sería la estimación de confiabilidad de la KR-20 en comparación con la estimación de la confiabilidad non-par?, ¿sería mayor o menor?

Podríamos suponer que debido a que las áreas de contenido ejemplificadas para los 18 reactivos de esta “Prueba hipotética de reparaciones electrónicas” están ordenadas de manera que los reactivos impares y pares se conecten en la misma área de contenido, es probable que la estimación de la confiabilidad non-par sea bastante alta. A causa de la gran heterogeneidad de las áreas de contenido cuando se consideran en conjunto, sería razonable predecir que la estimación de confiabilidad de la KR-20 sería menor que la confiabilidad de la non-par. ¿Cómo puede calcularse la KR-20? Puede usarse la siguiente fórmula:

$$r_{KR20} = \left(\frac{k}{k-1} \right) \left(1 - \frac{\sum pq}{\sigma^2} \right)$$

donde r_{KR20} representa el coeficiente de confiabilidad de la fórmula 20 de Kuder-Richardson, k es el número de reactivos de la prueba, σ^2 es la varianza del total de las puntuaciones de la prueba, p es la proporción de evaluados que aprobaron el examen, q es la proporción de reprobados y $\sum pq$ es la suma de los productos pq de todos los reactivos. Para este ejemplo particular, k es igual a 18. En base a los datos de la tabla 5-3, puede calcularse que $\sum pq$ es 3.975. La varianza del total de las puntuaciones de la prueba es 5.26. Por tanto, $r_{KR20} = .259$.

Podemos obtener una aproximación de la KR-20 usando la vigésima primera fórmula de las series desarrolladas por Kuder y Richardson, una fórmula conocida como —lo adiviné— KR-21. La KR-21 puede utilizarse si hay razón para suponer que todos los reactivos de la prueba tienen aproximadamente el mismo grado de dificultad. Es necesario agregar que esta suposición rara vez es justificada. La fórmula KR-21 tiende a ser anticuada en una época de calculadoras y computadoras. (Recordemos, la KR-21 algunas veces se utilizaba para estimar la KR-20 sólo porque requería menos cálculos.)

Se han propuesto numerosas modificaciones a las fórmulas de Kuder-Richardson a lo largo de los años. La única variante de la fórmula KR-20 que ha tenido mayor aceptación y hoy día está en su más amplio uso es una estadística llamada coeficiente alfa. Quizá haya escuchado referirse a ella como coeficiente α -20. Esta expresión incorpora tanto la letra griega alfa (α) como el número veinte, al cual se refiere la KR-20.

Tabla 5-3
Desempeño por reactivo de 20 examinados
en la PHRE

Número de reactivo	Número de personas que respondieron en forma correcta
1	14
2	12
3	9
4	18
5	8
6	5
7	6
8	9
9	10
10	10
11	8
12	6
13	15
14	9
15	12
16	12
17	14
18	7

Coefficiente alfa Desarrollado por Cronbach (1951) y detallado subsecuentemente por otros (como Kaiser y Michael, 1975; Novick y Lewis, 1967), el **coeficiente alfa** puede considerarse como la media de todas las correlaciones posibles al dividir en mitades, corregida con la fórmula de Spearman-Brown. En contraste con la KR-20, la cual se usa en forma apropiada sólo en pruebas con reactivos dicotómicos, el **coeficiente alfa** también puede utilizarse en pruebas con reactivos no dicotómicos. La fórmula para el coeficiente alfa es:

$$r_{\alpha} = \left(\frac{k}{k-1} \right) \left(1 - \frac{\sum \sigma_i^2}{\sigma^2} \right)$$

donde r_{α} es el coeficiente alfa, k es el número de reactivos, σ_i^2 es la varianza de un reactivo, $\sum \sigma_i^2$ es la suma de las varianzas de cada reactivo y σ^2 es la varianza del total de las puntuaciones de la prueba.

El coeficiente alfa es la estadística preferida para obtener una estimación de la confiabilidad de la consistencia interna. Se ha desarrollado una variación para ser usada en la obtención de una estimación de la confiabilidad test-retest (Green, 2003). De manera esencial, esta fórmula produce una estimación de la media de todos los posibles coeficientes test-retest y de divisiones por mitades. El coeficiente alfa se utiliza de manera amplia como una medida de confiabilidad, debido, en parte, al hecho de que requiere sólo una administración de la prueba.

A diferencia de una r de Pearson, que puede fluctuar en su valor de -1 a $+1$, el coeficiente alfa de manera típica varía en valor de 0 a 1 . Esto se debe a que de manera conceptual, el coeficiente alfa, al igual que otros coeficientes de confiabilidad, se calcula para ayudar a responder preguntas sobre qué tan similares son los conjuntos de reactivos. Aquí, en esencia, la similitud se estima en una escala de 0 (no similar en absoluto) hasta 1 (perfectamente idéntico). Sin embargo, es posible concebir un conjunto de datos que podría producir un valor negativo de alfa (Streiner, 2003b). Aun así, debido a que los valores negativos de alfa son imposibles de manera teórica, se recomienda que bajo circunstancias especiales, el coeficiente alfa se reporte como cero (Henson, 2001). Además, un mito sobre alfa es el que dice “más grande siempre es mejor”. Como señaló Streiner (2003b), un valor de alfa mayor que .90 puede ser “demasiado alto” e indicar redundancia en los reactivos.

En contraste con el coeficiente alfa, una r de Pearson puede ser imaginada como “tratando, de manera conceptual con lo semejante y lo disímil”. Así, una r con un valor de -1 puede concebirse

como un indicativo de “la perfecta desigualdad”. En la práctica, la mayoría de los coeficientes de confiabilidad, sin importar el tipo específico de confiabilidad que se está midiendo, se encuentran dentro de un rango de valor de 0 a 1. Por lo general esto es cierto, aunque es posible concebir casos excepcionales, cuyos conjuntos de datos producirían una r con un valor en el rango negativo.

Antes de proseguir, enfatizamos que todos los índices de confiabilidad, entre ellos el coeficiente alfa, proporcionan un índice que es característico de un grupo particular de puntuaciones de prueba, no de la prueba misma (Caruso, 2000; Yin & Fan, 2000). Las medidas de confiabilidad son estimaciones y las estimaciones están sujetas al error. La cantidad precisa de error inherente a la estimación de la confiabilidad variará con la muestra de evaluados, de quienes fueron extraídos los datos. Un índice de confiabilidad publicado en un manual de pruebas puede parecer muy impresionante; sin embargo, debe tenerse en mente que la confiabilidad reportada se consiguió con un grupo particular de examinados. Si un nuevo grupo es lo suficientemente diferente del grupo de evaluados al que se le hicieron los estudios de confiabilidad, el coeficiente de confiabilidad quizá no sea tan impresionante, incluso podría ser inaceptable.

Medidas de confiabilidad entre evaluadores

Cuando estamos siendo evaluados, normalmente, nos gustaría creer que seremos evaluados en la misma forma, sin importar quién esté haciendo la evaluación.⁶ Por ejemplo, si usted presenta un examen de manejo para obtener su licencia, le gustaría pensar que si aprueba o reprueba será sólo cuestión de su desempeño detrás del volante y no una función de quién está sentado en el asiento del pasajero. Por desgracia, en algunos tipos de pruebas bajo algunas condiciones, la puntuación puede ser más una función del evaluador que de ninguna otra cosa. Esto fue demostrado en 1912 cuando unos investigadores presentaron la composición en inglés de un alumno a una convención de maestros y fue calificada por voluntarios con calificaciones que variaron desde un mínimo de 50% hasta un máximo de 98% (Starch y Elliott, 1912).

Denominada en forma diversa como *confiabilidad del evaluador*, *confiabilidad del juez*, *confiabilidad del observador* y *confiabilidad entre evaluadores*, la **confiabilidad entre evaluadores** es el grado de acuerdo o consistencia que existe entre dos o más evaluadores (o jueces o calificadores). Las referencias a los niveles de confiabilidad entre evaluadores para una prueba particular pueden publicarse en el manual de la prueba o en alguna otra parte. Si el coeficiente de confiabilidad es muy alto, el futuro usuario de la prueba sabe que las puntuaciones pueden ser derivadas en forma consistente y sistemática por varios evaluadores con capacitación suficiente. Un creador de pruebas responsable que sea incapaz de crear un examen que pueda ser calificado con un grado razonable de consistencia por evaluadores capacitados regresará al pizarrón para descubrir la razón

de este problema. Si, por ejemplo, el problema es que falta claridad en los criterios de calificación, entonces el remedio sería redactar de nuevo la sección de criterios de calificación del manual para incluir las reglas de calificación redactadas con mayor claridad. Se puede estimular la consistencia entre evaluadores suministrando jueces que promuevan la participación en discusiones de grupo junto con ejercicios prácticos e información sobre la precisión del evaluador (Smith, 1986).

Quizá la forma más simple de determinar el grado de consistencia que existe entre evaluadores en cuanto a la calificación de una prueba sea mediante el cálculo de un coeficiente de correlación. A este coeficiente se le denomina **coeficiente de confiabilidad entre evaluadores**.

SÓLO PIENSE...

¿Puede usted pensar en una medida en la que podría ser deseable para diferentes jueces, evaluadores o calificadores tener *diferentes* puntos de vista de lo que se juzga, califica o mide?

6. Decimos “normalmente” debido a que existen excepciones. Así, por ejemplo, si acude a una entrevista de trabajo y el patrón o entrevistador es un padre o algún otro pariente amoroso, podría esperar de manera razonable que la naturaleza de la valoración que reciba *no* sería la misma si el evaluador fuera alguna otra persona. Por otra parte, si el patrón o entrevistador es alguien con quien ha tenido un mal rato, puede ser tiempo de revisar de nuevo los anuncios de empleo.

Uso e interpretación de un coeficiente de confiabilidad

Hemos visto, respecto a la prueba en sí, que básicamente hay tres enfoques para la estimación de la confiabilidad: 1) prueba y pos-prueba, 2) formas alternas o paralelas y 3) consistencia interna o entre reactivos. El método o métodos empleados dependerán de diversos factores, siendo primordial entre ellos el propósito de obtener una medida de confiabilidad y la forma en que se usará esta medida.

Otra pregunta vinculada con el propósito de la prueba, y no es una pregunta trivial, es: ¿Qué tan alto debe ser el coeficiente de confiabilidad? Quizá la mejor “respuesta breve” a esta pregunta sea: “En la medida de continuidad relativa al propósito e importancia de las decisiones que han de tomarse en base a las puntuaciones de la prueba”. La confiabilidad es un atributo imperativo en todas las pruebas que utilizamos. Sin embargo, en algunas pruebas necesitaremos más confiabilidad y en otras admitiremos menos. Si la puntuación de una prueba tiene implicaciones de vida o muerte, debemos tener esa prueba en un estándar alto, así como estándares relativamente altos respecto a los coeficientes de confiabilidad. Si la puntuación de una prueba se usa de manera rutinaria en combinación con muchas otras puntuaciones y, de manera característica cuenta sólo para una pequeña parte del proceso de decisión, entonces la prueba podría no tener los estándares más altos de confiabilidad. Como regla práctica, es útil pensar en los coeficientes de confiabilidad como comparables a muchos sistemas de calificación. En los .90, se determina una calificación de MB, en los .80, una B y a partir de .65 hasta .70, se determinaría una S, lo cual estaría dentro del territorio de una calificación aprobatoria, pero en el borde de una calificación reprobatoria o inaceptable. Ahora, pongámonos un poco más técnicos respecto al propósito del coeficiente de confiabilidad.

El propósito del coeficiente de confiabilidad

Si se diseña una prueba específica que será usada varias veces en el transcurso del periodo laboral de una persona con el fin de evaluar su desempeño, sería razonable esperar que muestre confiabilidad a lo largo del tiempo. Sería deseable tener una estimación de la confiabilidad de la prueba y la postprueba del instrumento. En una prueba diseñada para una sola aplicación, una estimación de la consistencia interna sería la medida de confiabilidad a elegir. Si el propósito de determinar la confiabilidad es analizar la varianza de error en sus partes, como se muestra en la figura 5-1, entonces tendrían que calcularse varios coeficientes de confiabilidad.




Figura 5-1

Fuentes de varianza en una prueba hipotética

En esta situación hipotética, 5% de la varianza no ha sido identificada por el evaluador. Es posible, por ejemplo, que esa parte de la varianza se deba al error transitorio, una fuente de error atribuible a variaciones en los sentimientos, en el humor o en el estado mental del evaluado a través del tiempo. Entonces, de nuevo, este 5% del error puede deberse a otros factores que aún no se identifican.

Tabla 5-4

Resumen de tipos de confiabilidad

Tipo de confiabilidad	Número de sesiones de prueba	Número de formas de prueba	Fuentes de varianza de error	Procedimientos estadísticos
Test-retest	2	1	Aplicación	r de Pearson o rho de Spearman
Formas alternas	1 o 2	2	Construcción o aplicación de la prueba	r de Pearson o rho de Spearman
Consistencia interna	1	1	Construcción de la prueba	r de Pearson entre mitades de prueba equivalentes con corrección de Spearman-Brown o Kuder-Richardson para reactivos dicotómicos o Coeficiente alfa para reactivos de opción múltiple
Entre evaluadores	1	1	Calificación e interpretación	r de Pearson o rho de Spearman

Observe que no todos los tipos de coeficientes de confiabilidad reflejan las mismas fuentes de varianza de error. De esta manera, un coeficiente de confiabilidad individual puede proporcionar un índice de error de la construcción de la prueba, de la aplicación de la prueba o de la calificación e interpretación. Un coeficiente de confiabilidad entre evaluadores, por ejemplo, proporciona información sobre el error como resultado de la calificación de la prueba. De manera específica, puede usarse para responder preguntas de cuán consistentemente dos evaluadores califican los mismos reactivos de una prueba. En la [tabla 5-4 se resumen](#) las diferentes clases de varianza de error que se reflejan en diferentes coeficientes de confiabilidad.

La naturaleza de la prueba

Relacionadas en forma muy estrecha con las consideraciones relativas al propósito y uso de un coeficiente de confiabilidad están las [consideraciones relacionadas con la naturaleza de la prueba en sí](#). Aquí se incluyen consideraciones acerca de si 1) los reactivos de prueba son de naturaleza homogénea o heterogénea, 2) la característica, capacidad o rasgo que se está midiendo se considera como dinámica o estática, 3) el rango de puntuaciones de la prueba está restringido o no, 4) la prueba es de velocidad o de poder y, 5) la prueba es o no con referencia a un criterio. Algunas pruebas presentan problemas especiales respecto a la medición de su confiabilidad (véase la sección *Close-up* de este capítulo).

Homogeneidad contra heterogeneidad de los reactivos de la prueba Recuerde que [se dice que una prueba es homogénea](#) en sus reactivos si, de manera funcional, es uniforme de un extremo a otro. De las pruebas diseñadas para medir un factor, como una capacidad o un rasgo, [se espera que tengan un alto grado de consistencia interna](#). En contraste, [si la prueba fuera heterogénea](#) entre sus reactivos, una estimación de la consistencia interna podría ser baja en relación con una estimación más apropiada de la confiabilidad de la prueba y su repetición.

Características dinámicas contra estáticas Ya sea que lo que la prueba intente medir sea *dinámico* o *estático* también es una consideración para obtener una estimación de confiabilidad. Una [característica dinámica](#) es un rasgo, estado o aptitud que, se presume, está siempre cambiando como una función de experiencias situacionales y cognoscitivas. Si, por ejemplo, cada hora tuviéramos que tomar mediciones de la característica dinámica de ansiedad que manifiesta un corredor de bolsa a lo largo de un día de trabajo, podríamos encontrar que el nivel medido de esta característica cambia de una hora a otra. Tales cambios podrían incluso estar relacionados con la magnitud del promedio Dow Jones. Debido a que la cantidad verdadera de ansiedad que se supone existe variaría con cada evaluación, una [medida test-retest](#) sería de poca ayuda para [estimar la confiabilidad del instrumento de medición](#). La mejor estimación de la confiabilidad podría obtenerse a

Confiabilidad de las escalas Bayley-II

Las escalas Bayley para el desarrollo infantil (Bayley Scales of Infant Development, BSID; Bayley 1969) fueron diseñadas para muestras de ciertos aspectos del desarrollo mental, motor y del comportamiento en los niños. Después de alrededor de dos décadas de ser usadas, estas escalas tendían a elevarse (Schuler *et al.*, 2003), por lo que la prueba se revisó en 1993.

Muy parecida a la prueba original, las escalas Bayley para el desarrollo infantil, segunda edición (BSID-II; Bayley, 1993), fueron diseñadas para evaluar el nivel de desarrollo de niños de entre un mes y tres años y medio de edad. Se usan sobre todo para ayudar a identificar niños con desarrollo lento y que podrían beneficiarse con una intervención cognoscitiva. Las BSID-II incluyen tres escalas. Los reactivos en la escala motora están centrados en el control y habilidad empleados en los movimientos corporales. Los reactivos en la escala mental se enfocan en capacidades cognoscitivas. La escala de estimación del comportamiento evalúa problemas conductuales, como la falta de atención.

¿Las BSID-II son una medida confiable? Debido a que se espera que las escalas mental, motora y de estimación del comportamiento midan cada una un conjunto homogéneo de capacidades, la confiabilidad de consistencia interna de cada una de estas escalas es una medida apropiada. Bayley (1993) reportó coeficientes alfa que variaban de .78 a .93 para la escala mental (existen variaciones a lo largo de los grupos de edad), .75 a .91 para la escala motora y .64 a .92 para la de estimación del comportamiento. A partir de estos estudios de confiabilidad, Bayley (1993) concluyó que las BSID-II son consistentes en lo interno.

Sin embargo, considere un problema único para los instrumentos utilizados en la evaluación de los infantes. Sabemos que el desarrollo cognoscitivo es rápido y desigual durante los primeros años de vida. Los niños a menudo crecen repentinamente, cambiando de modo dramático en unos cuantos días (Hetherington y Parke, 1993). Los niños examinados justo antes y después de un avance en su desarrollo pueden desempeñarse de manera muy diferente en las BSID-II para las dos pruebas. En tales casos, un cambio en la puntuación de la prueba podría no ser resultado del error en la prueba misma o en su aplicación; en su lugar, tales cambios podrían reflejar una variación real en las habilidades del niño. Desde luego, no todas las diferencias del desempeño del niño en la prueba aplicada dos veces deben ser resultado de cambios en las habilidades. El desafío al medir la confiabilidad test-retest de las BSID-II es hacerlo de tal manera que no sea falsamente disminuido por los cambios reales de desarrollo del examinado en el lapso de aplicación de las pruebas.

La solución de Bayley a este dilema implicó examinar la confiabilidad test-retest durante periodos cortos. El intervalo



Nancy Bayley, Ph.D.

mediano entre éstas era de sólo cuatro días. Las correlaciones entre los resultados de las dos sesiones de prueba fueron convincentes para la escala mental (.83 a .91) y la motora (.77 a .79). La escala de la estimación del comportamiento demostró una confiabilidad de prueba y pos-prueba inferior: .48 a .70 al mes de edad, .57 a .90 a los 12 meses de edad y .60 a .71 de 24 a 36 meses de edad (Bayley, 1993).

La confiabilidad entre evaluadores es una preocupación importante para las BSID-II, debido a que muchos reactivos requieren juicio de parte del examinador. El manual de prueba proporciona criterios claros para la calificación del desempeño del niño, pero por su naturaleza muchas tareas implican alguna subjetividad en la calificación. Por ejemplo, uno de los reactivos de la escala motora es "Mantener las manos abiertas... Para calificar: dar crédito si el niño mantiene sus manos abiertas la mayor parte del tiempo cuando es libre de seguir sus propios intereses" (Bayley, 1993, p. 147). Las causas de error del examinador en este reactivo

(continúa)

Confiabilidad de las escalas Bayley-II (continuación)

pueden surgir de una variedad de fuentes: diferentes examinadores pueden observar la posición de las manos del niño en diferentes momentos. Los examinadores pueden definir en forma diferente cuándo un niño es “libre de seguir sus propios intereses” y pueden estar en desacuerdo respecto a lo que constituye “la mayor parte del tiempo”.

No existe una forma alterna o equivalente de las BSID-II, así que no puede evaluarse la confiabilidad de las formas alternas. Sería útil tener una forma alterna de la prueba, en especial en casos en los que el examinador comete un error en la aplicación de la primera versión. Aun así, casi es seguro que la creación de una forma alternativa de esta prueba implicaría una gran inversión de tiempo, dinero y esfuerzo. Si usted fuera el editor de la prueba, ¿haría esa inversión? Al considerar la respuesta a esta pregunta, no olvide que el nivel de capacidad de quien responde la prueba cambia con rapidez.

Nellis y Gridley (1994) señalaron que una meta primordial en la revisión era fortalecer la prueba desde el punto de vista psico-

métrico. Basados en los datos proporcionados en el manual de la prueba, Nellis y Gridley concluyeron que esta meta se logró: las BSID-II parecen ser más confiables que las Escalas Bayley originales. Sin embargo, todavía hay algunos puntos débiles importantes. Por ejemplo, el manual está enfocado en la calidad psicométrica de las BSID-II aplicadas a niños sin problemas de desarrollo significativos. Se desconoce si se habrían obtenido los mismos niveles de confiabilidad con niños con algún tipo de retraso en el desarrollo. Quizá una incógnita más intrigante es la cuestión de por qué hubo un deslizamiento hacia arriba en las calificaciones después de dos décadas de uso de la primera. ¿Este fenómeno de deslizamiento se repetirá por sí mismo después de un tiempo similar de aplicación de la segunda edición? El tiempo lo dirá.

Para un vistazo rápido de cómo han utilizado la prueba de Bayley practicantes e investigadores, el lector interesado puede revisar Alessandri *et al.* (1998), Drotar *et al.* (1999), Levy-Shift *et al.* (1998), Nelson *et al.* (2000) y Raz *et al.* (1998).

partir de una medida de consistencia interna. Compare esta situación con una en la cual las evaluaciones en intervalos de una hora de este mismo corredor de bolsa se hicieran sobre otro rasgo, estado o habilidad que, se presume, permanece relativamente sin cambios (una característica estática) como la inteligencia. En este caso, no se esperaría que la medición obtenida varíe de manera significativa como una función del tiempo; y ya sea el método de test-retest o el de formas alternas, cualesquiera podría ser apropiado.

SÓLO PIENSE...

Dé otro ejemplo de una característica dinámica que una prueba psicológica pueda medir, así como una característica estática.

Restricción o inflación del rango Al usar e interpretar un coeficiente de confiabilidad, es importante el tema al que en forma alternativa se hace referencia como **restricción del rango o restricción de la varianza** (o, a la inversa, **inflación del rango o inflación de la varian-**

za). Si la varianza de cualquier variable en un análisis correlativo es restringida por el procedimiento de muestreo usado, entonces el coeficiente de correlación resultante tenderá a ser menor. Si la varianza de cualquier variable en un análisis correlativo es inflada por el procedimiento de muestreo, entonces el coeficiente de correlación resultante tenderá a ser mayor. Véase la figura 4-8 (p. 123) del capítulo anterior (dos gráficas de dispersión que ilustran rangos sin restricciones y restringidos) para una ilustración gráfica.

También es de vital importancia si el rango de las varianzas empleadas es apropiado para el objetivo del análisis correlativo. Por ejemplo, considere en el último contexto una prueba educativa publicada, diseñada para usarse con niños de primero a sexto grado de primaria. De manera ideal, el manual de esta prueba no contendría un valor de confiabilidad que incluyera a todos los que la respondieron en los grados de primero a sexto, sino valores de confiabilidad para quienes la respondieron en cada grado. El encargado de personal de una corporación que emplea cierta prueba de reconocimiento en el proceso de contratación debe mantener datos confiables con respecto a puntuaciones obtenidas por los solicitantes de empleo —en oposición a los empleados

contratados— si no se quiere restringir el rango de mediciones (esto se debe a que las personas que fueron contratadas, generalmente, obtuvieron en la prueba puntuaciones superiores a cualquier otro grupo comparable de aspirantes).

Pruebas de velocidad contra pruebas de poder Cuando un límite de tiempo es lo bastante largo como para permitir a los examinados responder todos los reactivos y si algunos de éstos fuesen tan difíciles que ningún participante lograra obtener una puntuación perfecta, entonces la prueba es una **prueba de poder**. Por el contrario, una **prueba de velocidad**, de manera general, contiene reactivos con un nivel de dificultad uniforme (en este caso, normalmente bajo) de modo que cuando se dan límites de tiempo generosos, quienes participan deberían ser capaces de contestar la totalidad de las preguntas en forma correcta. Sin embargo, en la práctica, el límite de tiempo en una prueba de velocidad se establece de modo que pocos, si es que alguno, de quienes la responden sean capaces de responderla en su totalidad. Por tanto, las diferencias de puntuación en una prueba de velocidad de este tipo, se basan en la velocidad del desempeño, debido a que los reactivos respondidos tienden a ser respondidos correctamente.

Una estimación de confiabilidad de una prueba de velocidad debería estar basada en el desempeño de dos periodos de prueba independientes usando uno de los siguientes aspectos: 1) confiabilidad test-retest, 2) confiabilidad de las formas alternas o equivalentes o 3) confiabilidad de dividir en dos o partir en dos mitades la prueba y *cronometrarlas por separado*. Si se usa el procedimiento de dividir en mitades, el coeficiente de confiabilidad obtenido es para una mitad de la prueba y deberá ajustarse usando la fórmula de Spearman-Brown.

Debido a que una medida de la confiabilidad de una prueba de velocidad debería reflejar la consistencia de la velocidad de respuesta, la confiabilidad de una prueba de velocidad no debería calcularse a partir de una sola aplicación con un límite de tiempo único. Si se aplica una prueba de velocidad una vez y se calcula alguna medida de consistencia interna, como la de Kuder-Richardson o una correlación de dividir en mitades, el resultado será un coeficiente de confiabilidad falsamente alto. Para explicar cómo ocurre esto, considere el siguiente ejemplo.

Cuando un grupo de examinados completa una prueba de velocidad, casi todos los reactivos respondidos serán correctos. Si se examina su confiabilidad usando la división non-par y si quienes la respondieron completaron los reactivos en orden, estarán cerca de tener el mismo número de reactivos pares e impares. Podría esperarse que una persona que respondiese 82 reactivos obtuviera aproximadamente 41 reactivos pares y 41 reactivos impares correctos. Una persona que contestase 61 reactivos podría obtener 31 reactivos pares y 30 pares correctos. Cuando el número de preguntas pares y pares están correlacionados a través del grupo de evaluados, la correlación será cercana a 1.00. Este impresionante coeficiente de correlación de hecho no nos dice nada sobre la consistencia de la respuesta.

Usando el mismo escenario arriba descrito, un coeficiente de confiabilidad de Kuder-Richardson produciría un coeficiente similar. Recuérdese que la confiabilidad de la KR-20 se basa en la proporción de quienes pasaron el examen (p) y la proporción de quienes lo reprobaron (q). En el caso de una prueba de velocidad, es concebible que p fuese igual a 1.0 y q igual a 0 para muchos de los reactivos. Hacia el final de la prueba —cuando muchos reactivos ni siquiera habrían sido contestados debido al límite de tiempo impuesto— p podría ser igual a 0 y q igual a 1.0. Entonces, para muchos, si no es que para la mayoría de los reactivos, el producto de pq sería igual o aproximado a 0. Cuando se sustituye 0 en la fórmula KR-20 para Σpq , el coeficiente de confiabilidad es 1.0 (un coeficiente insignificante en este caso).

Pruebas con referencia a un criterio Una prueba con **referencia a un criterio** está diseñada para proporcionar un indicio de la posición de quien responde la prueba con respecto a algún criterio, como un objetivo educativo o vocacional. A diferencia de las pruebas con referencia a una norma, las pruebas con referencia a un criterio tienden a contener material cuyo dominio se ha logrado en forma jerárquica; los aspirantes a pilotos dominan las habilidades en tierra antes de intentar dominar las habilidades del vuelo. Las puntuaciones en pruebas con referencia a un criterio tienden a ser traducidas como aprobar/reprobar (o, quizá de manera más precisa, **dominar o fallar**) y cualquier escrutinio del desempeño en reactivos individuales tiende a darse con propósitos de diagnóstico y remedio.

Las técnicas tradicionales para estimar la confiabilidad emplean medidas que toman en cuenta las puntuaciones de la prueba entera. Recuerde que una estimación de la confiabilidad test-retest, se basa en la correlación entre las puntuaciones totales de las dos aplicaciones de la misma prueba. En la confiabilidad de formas alternas, una estimación de confiabilidad se basa en la correlación entre las dos puntuaciones totales de las dos formas. En la confiabilidad de dividir en mitades, una estimación de confiabilidad se basa en la correlación entre las puntuaciones en las dos mitades de la prueba y luego se ajusta usando la fórmula de Spearman-Brown para obtener una estimación de confiabilidad de la prueba entera. Aunque hay excepciones, esos procedimientos tradicionales para estimar la confiabilidad son inapropiados para usarse en pruebas con referencia a un criterio. Para entender por qué, recuérdese que la confiabilidad se define como la proporción de la varianza total (σ^2) atribuible a la varianza verdadera (σ_e^2). La varianza total en una distribución de puntuaciones de una prueba es igual a la suma de la varianza verdadera más la varianza de error (σ_e^2):

$$\sigma^2 = \sigma_{tr}^2 + \sigma_e^2$$

Por consiguiente, una medida de confiabilidad depende de la variabilidad de las puntuaciones de la prueba: cuán diferentes son entre sí. En las pruebas con referencia a un criterio y en particular en las pruebas de dominio, el hecho de cuán diferentes son entre sí es pocas veces un punto de interés. De hecho, las diferencias individuales entre los examinados en las puntuaciones de prueba totales pueden ser mínimas. La cuestión clave para el usuario de una prueba de dominio es si se ha alcanzado o no alguna puntuación criterio.

Conforme disminuyen las diferencias individuales (y la variabilidad) también disminuirá una medida tradicional de confiabilidad, sin importar la estabilidad del desempeño individual. Por consiguiente, las formas tradicionales de estimar la confiabilidad no siempre son apropiadas para pruebas con referencia a un criterio, aunque puede haber casos en los que es posible adoptar estimaciones tradicionales. Un ejemplo de ello puede ser una situación en la que la misma prueba se use en diferentes etapas en algún programa, capacitación, terapia o cosas por el estilo y la variabilidad en las puntuaciones sería, de manera razonable, esperada. Las técnicas estadísticas útiles para determinar la confiabilidad de las pruebas con referencia a un criterio se explican a detalle en varias fuentes (por ejemplo, Hambleton y Jurgensen, 1990) y están más allá del alcance de un texto introductorio de medición.

¿Existen otros modelos de medición además del modelo de puntuación verdadera? Como veremos a continuación, la respuesta a esa pregunta es afirmativa. Sin embargo, antes de proceder, nos tomaremos un momento para reseñar una aplicación en la “vida real” de la confiabilidad de la medición dentro de este capítulo de *Psicometría cotidiana*.

Alternativas para el modelo de puntuación real

Hasta ahora, y a lo largo de este libro a menos que se especifique de otra manera, el modelo que hemos asumido como operativo es el modelo de puntuación real o clásico. Éste es el modelo más usado y aceptado en la literatura psicométrica actual. Desde el punto de vista histórico, desde principios de la década de 1900 hasta la década de 1940 el modelo de puntuación real de la confiabilidad de la medición disfrutó de una aceptación indiscutible en la práctica. La década de 1950 vio el desarrollo de un modelo teórico alternativo, uno conocido originalmente como *teoría del dominio de muestreo* y mejor conocido hoy como *teoría de la generalización*.

Como fue enunciada por Tryon (1957), la teoría del dominio de muestreo se rebela contra el concepto de una puntuación verdadera existente con respecto a la medición de constructos psicológicos. Mientras que aquellos que suscriben la *teoría de la puntuación verdadera* buscan estimar la porción de la puntuación de una prueba atribuible al error, los defensores de la teoría del dominio de muestreo buscan estimar la medida en que las fuentes específicas de variación bajo condiciones definidas contribuyen a la puntuación de la prueba. En la teoría del dominio de muestreo, la confiabilidad de una prueba es concebida como una medida objetiva de con cuánta precisión la puntuación de la prueba evalúa el dominio del atributo evaluado dentro de la población evaluada (Thorndike, 1985). Un *dominio de comportamiento*, o el universo de reactivos que

La defensa de la confiabilidad y la prueba del alcoholímetro

Alcoholímetro es el nombre genérico de varios tipos diferentes de instrumentos usados por los organismos de aplicación de la ley para determinar si un sospechoso, generalmente el operador de un vehículo de motor, está ebrio desde el punto de vista legal. Se requiere que el conductor sople en un tubo conectado al alcoholímetro. Entonces la muestra de aliento se mezcla con una sustancia química que se agrega al aparato para cada nueva prueba. La mezcla resultante es analizada en forma automática para determinar el contenido de alcohol en el aliento. El valor del contenido de alcohol en el aliento es convertido luego en un valor para el nivel de alcohol en la sangre. Si quien es sometido a la prueba es considerado ebrio desde el punto de vista legal variará de un estado a otro como una función de la ley estatal respecto al nivel de alcohol en la sangre necesario para ser declarado intoxicado.

En el estado de Nueva Jersey, el nivel de alcohol en la sangre requerido para ser declarado ebrio desde el punto de vista legal es una décima de 1% (.10%). Los conductores en Nueva Jersey encontrados culpables por un primer delito de conducir en estado de ebriedad enfrentan multas que ascienden a más o menos 3500 dólares, detención obligatoria en un Centro de Recursos para Conductores Intoxicados, suspensión del privilegio de conducir por un mínimo de seis meses y un máximo de 30 días de encarcelamiento. Dos modelos del alcoholímetro (el modelo 900 y el modelo 900A, fabricados por National Draeger, Inc.) se han usado en Nueva Jersey desde la década de 1950. La confiabilidad test-retest bien documentada respecto a los alcoholímetros 900 y 900A indica que los instrumentos tienen un margen de error de alrededor de una centésima de punto porcentual. Esto significa que una administración de la prueba a una persona que en realidad tenía un nivel de alcohol en la sangre de .10% (una "puntuación verdadera", si se quiere) podría producir una puntuación de prueba donde quiera a partir de una baja de .09% hasta una alta de .11%.

Un conductor en el estado de Nueva Jersey que fue encontrado culpable de conducir en estado de ebriedad apeló la decisión con fundamento en la confiabilidad test-retest del alcoholímetro. El alcoholímetro había indicado que el nivel de alcohol en la sangre del conductor era de .10%. El conductor argumentaba que la ley no tomaba en cuenta el margen de error inherente en el instrumento de medición. Sin embargo, la Suprema Corte estatal falló contra el conductor, al encontrar que la legislatura debe haber tomado en consideración dicho error cuando redactó la ley.

Otra cuestión relacionada con el uso de alcoholímetros tiene que ver con el lugar y el momento en que son aplicados. En algunos estados, la prueba se aplica generalmente en las estaciones de policía, no en la escena del arresto. En cierta ocasión se contrató a testigos expertos de parte de los acusados para calcular



Un sospechoso al que se le aplica una prueba con el alcoholímetro

cuál era el nivel de alcohol en la sangre de los acusados en el momento real del arresto. Trabajando en retrospectiva desde el momento en que se aplicó la prueba y suponiendo valores para variables como cuánto había bebido el acusado y cuándo, así como el peso del acusado, pudieron calcular un nivel de alcohol en la sangre en el momento del arresto. Si ese nivel era inferior al nivel requerido para ser declarado ebrio desde el punto de vista legal, el caso podría haber sido desestimado. Sin embargo, en algunos estados, como Nueva Jersey, esta defensa no sería aceptada. En estos estados, los tribunales superiores han fallado que debido a que estaban enterados de que las pruebas con el alcoholímetro no serían aplicadas en la escena del arresto, la legislatura pretendía que la medición del nivel de alcohol en la sangre se hiciera en la estación de policía.

Un asunto final relacionado con la confiabilidad, relevante para el uso de alcoholímetros tiene que ver con la confiabilidad entre evaluadores. Cuando se usan los modelos 900 y 900A, el oficial de policía que realizó el arresto también registra el nivel de alcohol medido en la sangre. Aunque la gran mayoría de oficiales de policía son honestos respecto a dicho registro, hay una posibilidad de abuso. Un oficial de policía que quisiera salvar las apariencias en el arresto de un conductor ebrio o incluso un oficial de policía que tan sólo deseara aumentar un expediente de arrestos de conductores ebrios, podría registrar un valor incorrecto del alcoholímetro para asegurar una condena. En 1993, un oficial de policía en el condado de Camden, Nueva Jersey, fue condenado y enviado a prisión por registrar lecturas incorrectas del alcoholímetro (Romano, 1994). Un incidente como éste es representativo de los "errores" extremadamente atípicos que ingresan al proceso de evaluación.

podrían medir de manera concebible ese comportamiento, puede considerarse como un constructo hipotético: uno que comparte ciertas características con (y es medido por ella) la muestra de reactivos que forman la prueba. En teoría, se considera que los reactivos en el dominio tienen las mismas medias y varianzas que aquellos que son una muestra del dominio. De los tres tipos de estimaciones de confiabilidad, las medidas de consistencia interna quizá sean las más compatibles con la teoría del dominio de muestreo.

La **teoría de la generalización** puede verse como una extensión de la teoría de la puntuación verdadera en la que el concepto de un universo de puntuaciones reemplaza al de una puntuación verdadera (Shavelson *et al.*, 1989). Desarrollada por Lee J. Cronbach (1970) y sus colegas (Cronbach *et al.*, 1972), esta teoría se basa en la idea de que las puntuaciones obtenidas por una persona varían de una prueba a otra debido a variables en la situación de aplicación. En lugar de concebir como error toda la variabilidad en las puntuaciones de una persona, Cronbach alienta a los planificadores de pruebas e investigadores a describir los detalles de la situación de aplicación de una prueba en particular o el **universo** que conduce a una puntuación específica dentro de una prueba. Este universo se describe en función de sus **facetas**, las cuales incluyen aspectos como el número de reactivos, la cantidad de capacitación que han tenido los evaluadores y el propósito de la aplicación de la prueba. De acuerdo con la teoría de la generalización, dadas las mismas condiciones exactas de todas las facetas en el universo, se obtendría la misma puntuación exacta en la prueba. Esta puntuación de prueba es la **puntuación universo** y es, como lo señaló Cronbach, análoga a la puntuación verdadera en el modelo de puntuación verdadera. Cronbach lo explica con sus propias palabras:

“¿Cuál es la capacidad de mecanografía de Mary?” Esto debe interpretarse como, “¿Cuál sería la puntuación de Mary si se recopilara y se promediara una gran cantidad de mediciones?” La puntuación de prueba particular que obtuvo Mary es sólo una de un *universo* de observaciones posibles, en cualquiera de las cuales el investigador estaría dispuesto a basar su conclusión o decisión. Si una de estas puntuaciones es tan aceptable como la siguiente, entonces la media, llamada la *puntuación universo*, simbolizada aquí con M_p (media para la persona p), sería la declaración más apropiada del desempeño de Mary en el tipo de situación que representa la prueba.

El universo es una colección de medidas posibles “de la misma clase”, pero los límites de la colección están determinados por el propósito del investigador. Si éste necesita conocer la capacidad de mecanografía de Mary el 5 de mayo (por ejemplo, de modo que pueda trazar una curva de aprendizaje que incluya un punto para ese día), el universo incluiría observaciones en ese día y sólo en ese día. Es probable que desee generalizar respecto a aprobaciones, examinadores y evaluadores, es decir, le gustaría conocer la capacidad de Mary el 5 de mayo sin referencia a cualquier aprobación, examinador o evaluador...

La persona tendrá de ordinario una puntuación universo diferente para cada universo. La puntuación universo de Mary que incluye las pruebas del 5 de mayo no concordará a la perfección con su puntuación universo para el mes de mayo completo... Algunos examinadores llaman al promedio de una gran cantidad de observaciones comparables una “puntuación verdadera”; por ejemplo, “la velocidad de mecanografía verdadera de Mary en pruebas de tres minutos”. En lugar de ello, hablamos de una “puntuación universo” para enfatizar que la puntuación que se desea depende del universo que se esté considerando. Para cualquier medida hay muchas “puntuaciones verdaderas”, cada una correspondiente a un universo diferente.

Cuando usamos una sola observación como si ésta representara el universo completo, estamos generalizando. Generalizamos sobre evaluadores, sobre selecciones mecanografiadas, quizá sobre días. Si las puntuaciones observadas de un procedimiento concuerdan en forma estrecha con la puntuación universo, podemos decir que la observación es “precisa” o “confiable” o “generalizable”. Y en vista de que las observaciones concuerdan luego también entre sí, decimos que son “consistentes” y que “tienen poca varianza de error”. Tener tantos términos es confuso, pero no es tan grave. El término usado con más frecuencia en la literatura es “confiabilidad”. El autor prefiere “generalización” debido a que el término implica de inmediato la pregunta “¿generalización de qué?”... Hay un grado diferente de generalización para cada universo. Los métodos de análisis más antiguos no separan las fuentes de variación. Tratan con una sola o dejan dos o más fuentes enredadas (Cronbach, 1970, pp. 153-154).

¿Cómo pueden aplicarse estas ideas? Cronbach y sus colegas sugirieron que las pruebas fueran desarrolladas con la ayuda de un **estudio de generalización** seguido por un **estudio de de-**

cisión. Un estudio de generalización analiza qué tan generalizables son las puntuaciones de una prueba particular, si la prueba es aplicada en situaciones diferentes. Planteado en el lenguaje de la teoría de la generalización, un estudio de esta índole analiza cuánto impacto tienen diferentes facetas del universo en la puntuación de la prueba. ¿La puntuación de la prueba es afectada por una aplicación grupal en oposición a una aplicación individual? ¿La puntuación de la prueba es afectada por la hora del día en que es aplicada? La influencia de facetas particulares en la puntuación de la prueba se representa con coeficientes de generalización. Estos coeficientes son similares a los coeficientes de confiabilidad bajo el modelo de puntuación verdadera.

Después que se realizó el estudio de generalización, Cronbach *et al.*, recomendaron que los planificadores de pruebas hicieran un estudio de decisión, el cual implica la aplicación de información del estudio de generalización. En el estudio de decisión, los elaboradores analizan la utilidad de las puntuaciones de prueba para ayudar al administrador a tomar decisiones. En la práctica, las puntuaciones de prueba se usan para guiar una variedad de decisiones, desde colocar a un niño en educación especial hasta contratar empleados nuevos y dar de alta del hospital a pacientes psiquiátricos. El estudio de decisión está diseñado para indicar al administrador de la prueba cómo deberían emplearse las puntuaciones de prueba y qué tan fiables son esas puntuaciones como base para las decisiones, dependiendo del contexto de su uso. ¿Por qué es tan importante esto? Cronbach (1970) lo explicó:

La decisión de que un estudiante ha completado un curso o que un paciente está listo para la terminación de la terapia no debe ser influida en forma seria por errores aleatorios, variaciones temporales en el desempeño o la elección de preguntas del examinador. Una decisión favorable errónea puede ser irreversible y puede dañar a la persona o a la comunidad. Aun cuando sea reversible, una decisión desfavorable errónea es injusta, trastorna la moral de la persona y quizá retardará su desarrollo. La investigación, también, requiere una medición fiable. Un experimento no es muy informativo si una diferencia observada pudiera explicarse por una variación aleatoria. Es probable que una gran varianza de error enmascare un resultado importante desde el punto de vista científico. Tomar mejor una medida incrementa la sensibilidad de un experimento en la misma forma en que lo hace el incremento en el número de sujetos (p. 152).

La generalización no ha reemplazado al modelo de puntuación verdadera. Aún así, tiene un gran atractivo debido a su mensaje de que “la confiabilidad de una prueba no reside dentro de la misma. Más bien, la confiabilidad es con mucho una función de las circunstancias bajo las cuales es elaborada, aplicada e interpretada”.

Otra alternativa al modelo de puntuación verdadera es la teoría de respuesta al reactivo (Lord, 1980), a la que también se le conoce por el acrónimo IRT (por sus siglas en inglés, Item Response Theory) o teoría del rasgo latente. Este modelo se enfoca en la medida en la cual reactivos individuales de pruebas son útiles para evaluar a individuos que se supone poseen cierta cantidad de un rasgo particular o una aptitud. La IRT es cada vez más usada por los planificadores de pruebas comerciales y editores de pruebas a gran escala en el desarrollo de éstas.

Confiabilidad y puntuaciones individuales

El coeficiente de confiabilidad ayuda al creador de la prueba a construir un instrumento adecuado de medición y al usuario a seleccionar una prueba adecuada. Sin embargo, la utilidad del coeficiente de confiabilidad no termina con la construcción y selección de la prueba. Al emplear el coeficiente de confiabilidad en la fórmula para el error estándar de medición, el usuario ahora tiene otra estadística descriptiva relevante para interpretarla, la cual es útil para describir la cantidad de error en una prueba o una medida.

El error estándar de medición

El error estándar de medición, abreviado SEM o SE_M (por sus siglas en inglés) proporciona una medida de la precisión en la puntuación observada dentro de una prueba. Establecido de otra

forma, proporciona un estimado de la cantidad de error inherente en una puntuación o medición observada. En general, la relación entre el SEM y la confiabilidad de una prueba es inversa; entre más alta sea la confiabilidad de una prueba (o subprueba individual dentro de una prueba), más bajo será el SEM.

Para ilustrar la utilidad del SEM, visitemos de nuevo “The Rochester Wrenchworks” (TRW) presentando otra vez a Mary, (del extracto de Cronbach manejado con anterioridad en este capítulo), quien ahora solicita un trabajo como capturista. Para ser contratado en TRW como capturista, un candidato debe ser capaz de procesar palabras con precisión a una tasa de 50 por minuto. En un periodo de siete días hábiles, el personal de oficina administra un total de siete pruebas breves de procesamiento de palabras a Mary. Sus puntuaciones, en palabras por minuto, obtenidas en cada una de las siete pruebas son las siguientes:

52 55 39 56 35 50 54

Si usted estuviera a cargo de las contrataciones en TRW y tuviera en sus manos estas siete puntuaciones, de manera lógica se preguntaría, “¿cuál de estas puntuaciones es la mejor medida de la ‘verdadera’ capacidad de Mary para procesar palabras?” Y de manera más exacta, “¿cuál es su ‘verdadera’ puntuación?”

La “verdadera” respuesta a la pregunta formulada con anterioridad es que, a partir de los datos con los que contamos, no se puede concluir con absoluta certidumbre cuál es, de manera exacta, la verdadera capacidad de Mary para procesar palabras. Podemos hacer una conjetura educada. Ésta sería que su capacidad verdadera para procesar palabras es igual a la media de la distribución de sus puntuaciones en las pruebas, más o menos un número de puntos cuantificados por error en el proceso de medición. Desconocemos cuántos puntos fueron contabilizados por error en el proceso de medición; lo mejor que se puede hacer es estimar cuánto error se introdujo en la puntuación de una prueba en particular.

El **error estándar de una medición** es la herramienta que se usa para estimar o inferir la distancia hasta la cual una puntuación observada se desvía de una puntuación verdadera. El error estándar de una medición se puede definir como la desviación estándar de una distribución que, en teoría, se comporta normalmente, formada por las puntuaciones de prueba obtenidas por una persona en pruebas equivalentes. También conocido como el **error estándar de una puntuación** y denotado por el símbolo σ_{med} , el error estándar de una medición es un índice del grado en que las puntuaciones individuales varían sobre pruebas que se supone son paralelas. De acuerdo con el modelo de puntuación verdadera, una puntuación de prueba obtenida representa un punto en la distribución teórica de las puntuaciones que el evaluado pudo haber obtenido. Además, el usuario de la prueba no tiene forma de conocer la puntuación verdadera de quien la responde. Sin embargo, si se conoce (o puede calcularse) la desviación estándar para la distribución de puntuaciones de la prueba y si se conoce (o puede calcularse) una estimación de la confiabilidad de la prueba, puede determinarse una estimación del error estándar de una puntuación particular (es decir, el error estándar de la medición) con la siguiente fórmula:

$$\sigma_{\text{med}} = \sigma \sqrt{1 - r_{xx}}$$

donde σ_{med} es igual al error estándar de medición, σ es igual a la desviación estándar de las puntuaciones de la prueba por el grupo de personas que la respondieron, y r_{xx} es igual al coeficiente de confiabilidad de la prueba. El error estándar de medición permite estimar el rango en que es probable que exista la puntuación verdadera, con un nivel de confianza específico.

Si, por ejemplo, una prueba de ortografía tiene un coeficiente de confiabilidad de .84 y una desviación estándar de 10, entonces:

$$\sigma_{\text{med}} = 10 \sqrt{1 - .84} = 4$$

Para usar el error estándar de medición en la estimación del rango de la puntuación verdadera, se hace una suposición: si el individuo fuera a presentar una gran cantidad de pruebas equivalentes, las puntuaciones en esas pruebas tenderían a estar distribuidas de manera normal con la

puntuación verdadera del individuo como la media. Debido a que el error estándar de medición funciona como una desviación estándar en este contexto, podemos emplearlo para predecir qué sucedería si un individuo presentara pruebas equivalentes adicionales:

- Se esperaría que aproximadamente el 68% (en realidad, 68.26%) de las puntuaciones ocurra dentro de $\pm 1\sigma_{\text{med}}$ de la puntuación verdadera.
- Se esperaría que aproximadamente el 95% (en realidad, 95.44%) de las puntuaciones ocurra dentro de $\pm 2\sigma_{\text{med}}$ de la puntuación verdadera.
- Se esperaría que aproximadamente el 99% (en realidad, 99.74%) de las puntuaciones ocurra dentro de $\pm 3\sigma_{\text{med}}$ de la puntuación verdadera.

Por supuesto, desconocemos la puntuación verdadera de cualquier individuo que responda la prueba, así que debemos estimarla. La mejor estimación disponible respecto a la puntuación verdadera del individuo en la prueba es la puntuación general ya obtenida en la prueba. Por tanto, si un estudiante lograra una puntuación de 50 en una prueba de ortografía y si la prueba tuvo un error estándar de medición de 4, entonces mediante el uso de 50 como el punto estimado, podría decirse que:

- Se puede estar 68% (en realidad, 68.26%) seguro de que la puntuación verdadera cae dentro de $50 \pm 1\sigma_{\text{med}}$ (o entre 46 y 54, incluyendo 46 y 54).
- Se puede estar 95% (en realidad, 95.44%) seguros de que la puntuación verdadera cae dentro de $50 \pm 2\sigma_{\text{med}}$ (o entre 42 y 58, incluyendo 42 y 58).
- Se puede estar 99% (en realidad, 99.74%) seguros de que la puntuación verdadera cae dentro de $50 \pm 3\sigma_{\text{med}}$ (o entre 38 y 62, incluyendo 38 y 62).

El error estándar de medición, como el coeficiente de confiabilidad, es una forma de expresar la confiabilidad de la prueba. Si la desviación estándar se mantiene constante, entre menor sea la σ_{med} , más confiable será la prueba; conforme se incrementa r_{xx} la σ_{med} disminuye. Por ejemplo, cuando un coeficiente de confiabilidad es igual a .64 y σ es igual a 15, el error de medición estándar es igual a 9:

$$\sigma_{\text{med}} = 15\sqrt{1 - .64} = 9$$

Con un coeficiente de confiabilidad igual a .96 y σ todavía igual a 15, el error estándar de medición disminuye a 3:

$$\sigma_{\text{med}} = 15\sqrt{1 - .96} = 3$$

En la práctica, el error estándar de medición se usa con más frecuencia en la interpretación de puntuaciones de prueba individuales. Por ejemplo, las pruebas de inteligencia se aplican como parte de la evaluación de individuos para determinar discapacidad intelectual. Uno de los criterios para determinar la discapacidad intelectual, es una puntuación de CI igual a 70 o menor (cuando la media es 100 y la desviación estándar es 15) en una prueba de inteligencia aplicada en forma individual (Asociación de Psiquiatría Estadounidense, 1994). Una pregunta que podría plantearse sobre estas pruebas es ¿cómo deberían tratarse las puntuaciones que se encuentran cerca del valor límite de 70? De manera específica, ¿qué tan arriba de 70 debe estar una puntuación para concluir con confianza que es improbable que el individuo tenga discapacidad intelectual?, ¿72 está claramente encima del rango de discapacidad intelectual, de modo que si la persona respondiera una forma paralela de la prueba, podría haber seguridad de que la segunda puntuación estaría por arriba de 70? ¿Qué hay de una puntuación de 75? ¿Y de una de 79?

Para responder a estas preguntas resulta útil una estimación de la cantidad de error en una puntuación de prueba observada. El error estándar de medición proporciona dicha estimación. Además, el error estándar de la estimación es útil para establecer lo que se ha llamado intervalo de

Tabla 5-5

Errores estándar de la medición de puntuaciones para el CI SB5 en las edades de 5, 10, 15 y 80+ años

Tipo de CI	Edad (en años)			
	5	10	15	80+
Escala completa de CI	2.12	2.60	2.12	2.12
CI no verbal	3.35	2.67	3.00	3.00
CI verbal	3.00	3.35	3.00	2.60
CI abreviado	4.24	5.20	4.50	3.00

confianza; es decir, un rango o banda de puntuaciones de prueba que es probable que contengan la puntuación verdadera.

A continuación, presentamos una aplicación en la “vida real” de un intervalo de confianza con la Escala Wechsler de inteligencia para adultos-III (Wechsler Adult Intelligence Scale-III; WAIS-III), una prueba ampliamente usada, diseñada para medir la inteligencia de los adultos (véase el capítulo 9). El manual técnico para esta prueba proporciona una gran cantidad de información relevante para la confiabilidad de la prueba en su totalidad, así como información más específica relacionada con la confiabilidad para cada una de las subpruebas. Como se reporta en el manual, la desviación estándar es 3 para las puntuaciones en escala de subpruebas y 15 para el CI y las puntuaciones índice. A lo largo de todos los grupos de edad en la muestra normativa, el coeficiente de confiabilidad promedio para el CI de la Escala general (Full Scale IQ; FSIQ) es .98 y el error estándar promedio de medición para el FSIQ es 2.3. El manual también proporciona información mucho más específica, incluyendo datos del error estándar de medición por subprueba individual y grupo de edad.

Al conocer la puntuación FSIQ de un individuo que respondió la prueba completa y su edad cronológica, es posible calcular un intervalo de confianza. Por ejemplo, supóngase que una persona de 22 años de edad ha respondido la prueba y obtenido un FSIQ en la WAIS-III de 75. El usuario puede estar seguro en un 95% de que el FSIQ verdadero de esta persona caerá en el rango de 70 a 80. Esto se debe a que el intervalo de confianza del 95% se establece tomando la puntuación observada de 75, más o menos 1.96, multiplicado por el error estándar de medición. Como se reporta en la página 54 del manual técnico de la WAIS-III, el error estándar de medición de la FSIQ para un individuo de 22 años de edad que responda la prueba es 2.37. Con esta información a la mano, el intervalo de confianza del 95% se calcula de la siguiente manera:

$$75 \pm 1.96 \sigma_{\text{med}} = 75 \pm 1.96(2.37) = 75 \pm 4.645$$

El intervalo calculado de 4.645 se redondea al número entero más cercano, 5. Por consiguiente, se puede tener la seguridad en un 95% de que la FSIQ verdadera de esta persona que respondió la WAIS-III se encuentra en alguna parte dentro del rango de la puntuación observada de 75 + o – 5, o en alguna parte dentro del rango de 70 a 80.

Con la intención de incrementar el “nivel de confort” del lector con el SEM, considérense los datos que se presentan en la tabla 5-5. Éstos son SEM para rangos de edad seleccionados y tipos de medición del CI, según se reporta en el Manual técnico para las escalas de inteligencia, de Stanford-Binet, quinta edición (SB5). Cuando se presentan éstos y otros datos relacionados, Roid (2003b, p. 65) observó: “Las puntuaciones que son más precisas y consistentes tienen diferencias más pequeñas entre las puntuaciones verdaderas y las observadas, lo que resulta en SEM más bajos”. Dado esto, *sólo piense*: ¿Qué hipótesis le vienen a la mente en relación con las puntuaciones de CI SB5 a la edad de 5, 10, 15 y 80+?

El error estándar de medición puede usarse para establecer el intervalo de confianza para una puntuación particular o para determinar si una puntuación es diferente, de manera significativa, de un criterio (como la puntuación limítrofe de 70 descrita antes). **El error estándar de medición no puede emplearse para comparar puntuaciones.** Entonces, ¿cómo comparan puntuaciones los usuarios de las pruebas?

El error estándar de la diferencia entre dos puntuaciones

El error relacionado con cualquier cantidad de variables operativas posibles en una situación de prueba puede contribuir a un cambio en la puntuación lograda en la misma, o en una prueba paralela, de una administración de una prueba a la siguiente. La cantidad de error en una puntuación de prueba específica está expresada en el error estándar de medición. Pero las puntuaciones pueden cambiar de una prueba a la siguiente por razones distintas al error.

Las diferencias en la característica que se va a medir también pueden afectar a las puntuaciones de la prueba. Estas diferencias pueden ser de gran interés, como en el caso del encargado de personal, que debe decidir a cuál de los muchos aspirantes contratará. En efecto, pueden esperarse tales diferencias, como en el caso de un investigador de psicoterapia que espera demostrar la efectividad de un enfoque teórico en particular dentro de un proceso terapéutico. Las comparaciones entre puntuaciones se llevan a cabo mediante el uso del error estándar de la diferencia, una medida estadística que puede ayudar al usuario de una prueba a determinar qué tan grande debería ser una diferencia antes de que sea considerada estadísticamente significativa. Como es probable que lo haya aprendido en su curso de estadística, la costumbre en el campo de la psicología dicta que si la probabilidad es mayor al 5%, probablemente la diferencia haya ocurrido por azar, entonces en la práctica se supone que no hubo diferencia. Una norma más rigurosa es el estándar del 1%; con este criterio, no se consideraría que exista alguna diferencia significativa desde el punto de vista estadístico, a menos que la diferencia observada pudiera haber ocurrido sólo por azar menos de una vez en cien.

El error estándar de la diferencia entre dos puntuaciones puede ser la herramienta estadística apropiada para abordar tres tipos de interrogantes:

1. ¿Cómo se compara el desempeño de este individuo en la prueba 1 con su desempeño en la prueba 2?
2. ¿Cómo se compara el desempeño de este individuo en la prueba 1 con el desempeño de alguien más en la prueba 1?
3. ¿Cómo se compara el desempeño de este individuo en la prueba 2 con el desempeño de alguien más en la prueba 2?

Como podría esperarse, cuando se comparan puntuaciones obtenidas en pruebas diferentes, es esencial que las puntuaciones sean convertidas a la misma escala. La fórmula para el error estándar de la diferencia entre dos puntuaciones es:

$$\sigma_{\text{dif}} = \sqrt{\sigma_{\text{med } 1}^2 + \sigma_{\text{med } 2}^2}$$

donde σ_{dif} es el error estándar de la diferencia entre dos puntuaciones, $\sigma_{\text{med } 1}^2$ es el error estándar de medición al cuadrado para la prueba 1 y $\sigma_{\text{med } 2}^2$ es el error estándar de medición al cuadrado para la prueba 2. Si se sustituyen los coeficientes de confiabilidad para los errores estándar de medición de las puntuaciones separadas, la fórmula se convierte en

$$\sigma_{\text{dif}} = \sigma \sqrt{2 - r_1 - r_2}$$

donde r_1 es el coeficiente de confiabilidad de la prueba 1, r_2 es el coeficiente de confiabilidad de la prueba 2, y σ es la desviación estándar; ambas pruebas tienen la misma desviación estándar, debido a que tendrían que haber estado en la misma escala (o haberse convertido a la misma escala) antes de que se pudiera hacer la comparación.

El error estándar de la diferencia entre dos puntuaciones será mayor que el error estándar de medición para cualquier puntuación sola debido a que el primero es afectado por el error de medición en ambas. Esto también tiene sentido: si dos puntuaciones contienen error en cada una, de tal manera que en cada caso la puntuación verdadera podría ser superior o inferior, se desearía que las dos puntuaciones estuvieran más separadas antes de concluir que hay una diferencia significativa entre ellas.

El valor obtenido cuando se calcula el error estándar de la diferencia se usa en forma muy parecida a la del error estándar de la media. Si se desea tener una seguridad de 95% de que las dos puntuaciones son diferentes, se desearía que estuvieran separadas por dos errores estándar de la diferencia. Una separación de sólo un error estándar de la diferencia proporcionaría una confianza del 68% de que las dos puntuaciones verdaderas serán diferentes.

Como una ilustración del uso del error estándar de la diferencia entre dos puntuaciones, considere la situación de un gerente corporativo de personal que busca a una persona altamente responsable para el puesto de vicepresidente de seguridad. El gerente de personal en esta situación hipotética decide usar una nueva prueba publicada llamada “Prueba de disposición para la seguridad” (PDS) para seleccionar aspirantes para el puesto. Después de colocar un anuncio en la sección de empleos del periódico local, el jefe de personal examina a 100 aspirantes para el puesto; si se usa la PDS, el funcionario de personal reduce la búsqueda del vicepresidente a los dos que hayan obtenido las puntuaciones más altas en la escala: Moe, quien obtuvo una puntuación de 125 y Larry, quien obtuvo una puntuación de 134. Si se supone que la confiabilidad medida de esta prueba es de .92 y su desviación estándar es de 14, ¿el jefe de personal debería concluir que Larry se desempeñó mejor que Moe de manera significativa? Para responder esta pregunta, primero se calcula el error estándar de la diferencia:

$$\sigma_{\text{dif}} = 14 \sqrt{2 - .92 - .92} = 14 \sqrt{.16} = 5.6$$

Observe que en esta aplicación de la fórmula, los dos coeficientes de confiabilidad de la prueba son iguales debido a que las dos puntuaciones que se están comparando son derivadas de la misma prueba.

¿Qué significa este error estándar de la diferencia? Para cualquier error estándar de la diferencia, podría establecerse que:

- Se puede estar 68% seguro de que dos puntuaciones que difieren por una σ_{dif} representan diferencias en la puntuación verdadera.
- Se puede estar 95% seguro de que dos puntuaciones que difieren por dos σ_{dif} representan diferencias de puntuación verdadera.
- Se puede estar 99.7% seguro de que dos puntuaciones que difieren por tres σ_{dif} representan diferencias de puntuación verdadera.

Al aplicar esta información al error estándar de la diferencia que se acaba de calcular para la “Prueba de disposición para la seguridad”, se observa que el funcionario de personal puede estar:

- 68% seguro de que dos puntuaciones que difieren por 5.6 representan diferencias de puntuación verdadera.
- 95% seguro de que dos puntuaciones que difieren por 11.2 representan diferencias de puntuación verdadera.
- 99.7% seguro de que dos puntuaciones que difieren por 16.8 representan diferencias de puntuación verdadera.

La diferencia entre las puntuaciones de Larry y Moe es sólo de 9 puntos, no es una diferencia

lo bastante grande para que el encargado de personal concluya con una confianza del 95% que los dos individuos en realidad tienen puntuaciones verdaderas que difieren en esta prueba. Planteado de otra forma, si Larry y Moe presentaran una forma paralela de la “Prueba de disposición para la seguridad”, el funcionario de personal no podría estar seguro en un 95% de que, en la siguiente prueba, Larry superaría de nuevo a Moe. El jefe de personal en este ejemplo tendría que recurrir a otros medios para decidir si Moe, Larry o alguien más sería el mejor candidato para el puesto (Curly ha esperado con paciencia).

SÓLO PIENSE...

Por favor, díganos que no se ha olvidado de Mary. Usted sabe, *Mary*, la de la cita del extracto de Cronbach en la página 148; sí, *esa* Mary. ¿Debe ella obtener el trabajo en TRW? Si su profesor lo considera útil, realice los cálculos necesarios antes de responder.

Como un comentario al ejemplo anterior, supóngase que Larry obtuvo el empleo principalmente con base en los datos de la hipotética PDS. Y supongamos, además, que pronto se hace demasiado evidente que Larry resultó ser sin lugar a dudas el peor vicepresidente de seguridad que la compañía haya tenido. Larry pasaba gran parte de su tiempo jugándoles bromas a sus colegas funcionarios corporativos y dedicaba muchas de sus horas de descanso a su pasatiempo favorito: sentarse al pie del asta bandera. El encargado de personal podría entonces tener muy buenas razones para cuestionar qué tan bien había medido en realidad la disposición para la seguridad el instrumento llamado “Prueba de disposición para la seguridad”. O, dicho de otra manera, podría cuestionar la *validez* de la prueba. No es una coincidencia que el tema de la validez de las pruebas se aborde en el siguiente capítulo.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaciones:

característica dinámica	consistencia entre reactivos	intervalo de confianza
características estáticas	consistencia interna	IRT
coeficiente alfa	error estándar de la diferencia	muestreo de contenido
coeficiente de confiabilidad	error estándar de la medición	muestreo de reactivos
coeficiente de confiabilidad entre evaluadores	error estándar de una puntuación	prueba con referencia a un criterio
coeficiente de equivalencia	error transitorio	prueba de poder
coeficiente de generalización	estudio de decisión	prueba de velocidad
coeficiente de estabilidad	estudio de generalización	puntuación universo
confiabilidad	faceta	restricción del rango
confiabilidad de dividir en mitades	formas alternas	teoría de generalización
confiabilidad test-retest	formas paralelas	teoría de la puntuación verdadera
confiabilidad de las formas paralelas	fórmula de Kuder-Richardson	universo
confiabilidad en las formas alternas	fórmula de Spearman-Brown	varianza
confiabilidad entre evaluadores	heterogeneidad	varianza verdadera
confiabilidad non-par	homogeneidad	varianza de error
	inflación de rango	

Un vistazo a la red

Consulte los siguientes sitios en la red para obtener más información acerca de los temas discutidos en este capítulo.

Coeficiente alfa

www.geolog.com/msmnt/malpha.htm

Prueba interactiva de confiabilidad

<http://chiron.valdosta.edu/mawhatley/3900/reliablec.htm>

Teoría de la generalización

www.psychology.sdsu.edu/faculty/matt/Pubs/GThtml/GTheory_GEMatt.html

Confiabilidad

www.socialresearchmethods.net/kb/reltypes.htm

Validez

En el lenguaje cotidiano, decimos que algo es válido cuando es firme, significativo o tiene un fundamento sólido en principios o evidencia. Por ejemplo, hablamos de una teoría válida, un argumento válido o una razón válida. En terminología legal, los abogados dicen que algo es válido si se “ejecuta de acuerdo con los procedimientos adecuados” (Black, 1979), como lo serían un contrato y un testamento válidos. En cada una de estas instancias, las personas hacen juicios en base a la evidencia de lo significativo o relevante así como de la veracidad de algo. De igual forma, en el lenguaje de la evaluación psicológica, el término *validez* se emplea de manera conjunta con lo significativo o relevante de la puntuación obtenida en una prueba, es decir, lo que en verdad significa o representa la puntuación.

El concepto de validez

La *validez*, aplicada a una prueba, es un juicio o una estimación acerca de qué tan bien una prueba mide lo que pretende medir en un determinado contexto. De manera más específica, es la elaboración de un juicio en base a la evidencia sobre lo apropiado de las inferencias realizadas a partir de las puntuaciones de una prueba.¹ Una *inferencia* es un resultado o deducción lógicos. Las definiciones de la validez de las pruebas y de las calificaciones a menudo son descritas como “aceptables” o “débiles”. Estos términos reflejan un juicio sobre qué tan adecuada es la medición que la prueba hace de aquello que intenta medir.

Inherente a todo juicio sobre la validez de un instrumento es la apreciación sobre su utilidad para un determinado propósito con un grupo de personas en particular. De manera estenográfica, los evaluadores pueden referirse a una prueba como una “prueba válida”. Sin embargo, lo que en realidad se quiere decir es que la prueba ha demostrado su validez para un uso particular con una población específica de examinados en un tiempo determinado. Ninguna prueba ni técnica de medición es “universalmente válida” para todo tiempo, para todo uso, ni con todo tipo de poblaciones de examinados. Más bien las pruebas, pueden haber mostrado ser válidas dentro de lo que puede ser definido como los *límites razonables* de un uso previsto. Si dichos límites son rebasados podría ponerse en duda la validez de la prueba. Además, en la me-

SÓLO PIENSE...

¿Por qué el término *prueba válida* es a veces engañoso?

1. Recuerde que en el capítulo 1 la palabra *prueba* se usa en el sentido más amplio posible. Por consiguiente, también se puede aplicar a procedimientos de medición y procesos que, estrictamente hablando, no se denominarían en forma coloquial como “pruebas”.

dida en que la validez de una prueba disminuye debido a cambios en la cultura o en la época, esa validez debe ser probada de nuevo en diferentes periodos.

Validación es el proceso de recopilar y evaluar la validez de la evidencia. Tanto el creador de la prueba como el usuario de la misma pueden desempeñar una función en la validación de una prueba para un propósito específico. Es responsabilidad del diseñador de la prueba suministrar evidencia de la validez en el manual de la misma. En ocasiones puede ser apropiado para los usuarios de la prueba realizar sus propios estudios de validación local con sus propios grupos de examinados. Estos estudios de validación local pueden producir información valiosa respecto a una población de evaluados en particular, comparados con la muestra normativa descrita en el manual de la prueba. Los estudios de validación local son absolutamente necesarios cuando el usuario de la prueba planea alterar de alguna manera el formato, las instrucciones, el lenguaje o el contenido de la prueba. Por ejemplo, un estudio de validación local sería necesario si el usuario necesita transformar una prueba estandarizada a nivel nacional al lenguaje Braille para ser administrada a examinados ciegos o débiles visuales. Los estudios de validación local también podrían ser necesarios cuando un usuario desee utilizar la prueba con un grupo de evaluados que difiera de manera significativa de la población con la que fue estandarizada.

Una manera en que los especialistas de la medición tradicionalmente han conceptualizado la validez es de acuerdo con tres categorías:

- validez de contenido
- validez relacionada con el criterio
- validez de constructo

En este concepto clásico de validez, denominado percepción trinitaria (Guion, 1980), puede ser útil visualizar la validez de constructo como una “validez de sombrilla” puesto que cualquier otro tipo de validez cae dentro de ella. Por qué la validez de constructo es la validez preponderante, es una cuestión que se irá aclarando conforme analicemos qué es lo que le da validez a una prueba así como los métodos y procedimientos utilizados para hacer la validación. En efecto, hay muchas formas diferentes de aproximarse al proceso de validación de una prueba y estos diferentes planes de aproximación son frecuentemente denominados estrategias. Hablamos, por ejemplo, de estrategias de validación de contenido, estrategias para lograr la validez relacionada con el criterio y estrategias de validación de constructo.

Son tres los enfoques para evaluar la validez asociada respectivamente con la validez de contenido, la validez relacionada con el criterio y la validez de constructo:

1. Examinar el contenido de la prueba.
2. Relacionar las calificaciones obtenidas en la prueba con otras puntuaciones u otras medidas.
3. Realizar un análisis general de:
 - a. La forma en que las puntuaciones de la prueba se relacionan con otras medidas y calificaciones (otras pruebas).
 - b. La forma en que las puntuaciones de la prueba pueden ser entendidas dentro de un contexto teórico para comprender el constructo a medir y por el cual la prueba fue diseñada.

Estos tres enfoques sobre la validez de la evaluación no son mutuamente excluyentes; cada uno debe ser considerado como un tipo de evidencia que, junto con otras, contribuye a elaborar un juicio sobre la validez de la prueba. Si bien los tres tipos de evidencia ayudan a tener una imagen unificada de la validez de la prueba, el usuario podría no necesitar conocer los tres tipos.

SÓLO PIENSE...

Los estudios de validación local requieren tanto del tiempo de profesionales como de saber hacerlo y ambos pueden ser costosos. Por estos motivos a veces no se llevan a cabo aun cuando sean deseables o necesarios. ¿Qué le recomendaría a un usuario de prueba que no pudiera efectuar ese estudio de validación local pero que, no obstante, necesita emplear una prueba que en realidad requiere de dicho estudio?

Dependiendo del uso que se le vaya a dar a la prueba, los tres tipos de evidencias con respecto a la validez pueden no ser relevantes de la misma manera.

El **modelo trinitario de la validez** no carece de críticas (Landy, 1986). Messick (1995), por ejemplo, condenó este enfoque como fragmentado e incompleto. Él clamaba por un punto de vista unitario de la validez, uno que tomara en cuenta todo, desde las implicaciones de las puntuaciones de la prueba en términos de valores sociales, hasta las consecuencias del uso de la prueba. Pocas personas podrían negar que sea preferible contar con un punto de vista unitario de la validez que con el que considera las tres partes. Sin embargo, incluso bajo el llamado punto de vista unitario, diferentes elementos de validez podrían destacarse para su escrutinio y así una comprensión de esos elementos aislados sería necesaria.

En este capítulo, analizaremos la validez de contenido, la validez relacionada con el criterio y la validez de constructo. Conforme usted aprenda más sobre la *validez clásica relacionada con un criterio*, la *validez tradicional de contenido* y otras concepciones clásicas de la validez, estará en una mejor posición para valorar la utilidad de cada una por sí mismas, incluso dentro del contexto total de una conceptualización unitaria.

Observemos al principio que aunque el modelo trinitario se enfoca únicamente en tres tipos de validez, es muy probable que en sus lecturas encuentre otros tipos de validez. Por ejemplo, podría hallar términos como *validez predictiva* y *validez concurrente*. De hecho, encontrará estos términos más adelante en este capítulo cuando abordemos la *validez relacionada con el criterio*. Otro término que podrá encontrar en la literatura es *validez aparente*. Este tipo de validez ha sido descrita como la “Rodney Dangerfield de las variables psicométricas” pues ha recibido poca atención —y aún menos respeto— por parte de los investigadores que examinan la validez de constructo de las pruebas psicológicas y sus medidas” (Bornstein *et al.*, 1994, p. 363). Sin más preámbulos, exploremos la...

Validez aparente

La **validez aparente** está relacionada más con lo que una prueba parece medir en la persona examinada que con lo que mide en realidad. La validez aparente es un juicio concerniente a cuán relevantes parecen ser los reactivos de la prueba. Dicho de otra manera, si una prueba definitivamente parece medir lo que pretende medir “de cara a ello”, se podría decir que tiene una alta validez aparente. Una prueba escrita de personalidad denominada “Prueba de introversión/extroversión” contiene reactivos que preguntan a los evaluados si han actuado de manera introvertida o extrovertida en situaciones particulares y podría ser percibida por quienes la responden, como una prueba con alta validez aparente. Por otra parte, una prueba de personalidad a través de la cual se les solicite a los respondientes describir lo que ven en unas manchas de tinta, posiblemente sea percibida como una prueba con baja validez aparente. Sin duda, muchos de los examinados quedarían preguntándose cómo se relaciona lo que dijeron ver en las manchas de tinta con la personalidad.

A diferencia de los juicios sobre la confiabilidad de una prueba y la validez de contenido y de constructo o la validez relacionada con el criterio, los juicios concernientes a la validez aparente a menudo son considerados desde la perspectiva de quien responde la prueba, no de quien la aplica. La carencia de validez aparente puede coadyuvar a la falta de confianza en la efectividad observada de la prueba, con una consecuente disminución en la actitud y deseo de cooperación o motivación del respondiente para hacer su mejor esfuerzo. De manera similar, los padres podrían objetar que sus hijos sean examinados con instrumentos que carecen de validez evidente. Esta preocupación podría originarse de la idea de que el uso de tales pruebas resultará en conclusiones inválidas.

SÓLO PIENSE...

Desde la perspectiva del usuario de la prueba, ¿cuál es la utilidad de la validez aparente?

En realidad, una prueba que carece de validez aparente puede ser útil y relevante. Sin embargo, si no es percibida como tal por examinados, padres, legisladores y otros, su aplicación puede tener consecuencias nefastas, las cuales pueden fluctuar desde una actitud negativa por parte del evaluado hasta una demanda presentada por partes disgustadas contra quien la aplica y contra el editor de la prueba. Por último, la validez aparente es más una cuestión de relaciones públicas que de solidez psicométrica, no obstante parece importante.

Validez de contenido

La **validez de contenido** describe un juicio de cuán adecuadamente una prueba es una muestra de la conducta representativa dentro del universo de conductas que la prueba fue diseñada para ejemplificar. Por ejemplo, el universo de comportamiento calificado como *asertivo* tiene un rango muy amplio. Una prueba de asertividad, escrita, de contenido válido, será la que represente adecuadamente este amplio rango. Podríamos esperar que dicha prueba contenga reactivos que sean una muestra de situaciones hipotéticas en el hogar (tales como si el respondiente tuviera dificultad para dar a conocer sus opiniones a otros miembros de la familia), en el trabajo (como sería si quien responde tuviera dificultad para pedir a sus subordinados que hagan lo que se requiere de ellos) y hasta en situaciones sociales (tal como si quien responde devolviera un filete que no está cocinado de la forma en la que él ordenó en un restaurante de lujo).

Respecto a las pruebas de rendimiento educativo, es usual considerar una prueba como una medida de contenido válido cuando la proporción del material cubierto por la prueba se aproxima a la proporción del material que se cubrió en el curso. Un examen final acumulativo sobre introducción a la estadística se consideraría válido en cuanto a su contenido, si la proporción y el tipo de problemas sobre ese tema abarcados en la prueba, se aproximan a la proporción y el tipo de problemas que se abordaron durante dicho curso.

Las primeras etapas de una prueba desarrollada para ser administrada en el salón de clases —ya sea en uno solo o en todos los salones de clases de cualquier Estado o nación— de manera característica implican una investigación del universo de los objetivos posibles de enseñanza del curso respectivo. Incluidos entre las muchas fuentes de información sobre dichos objetivos están los cursos del programa de estudio, los cursos de los libros de texto, los maestros de los cursos, los especialistas que elaboran el plan de estudios, así como los profesores y supervisores que capacitan a los maestros en un área temática en particular. A partir de la información reunida (junto con el juicio del autor), surgirá un proyecto para la estructura de la prueba. Este proyecto representa la culminación de los esfuerzos que permitirán ejemplificar de manera adecuada el universo de las áreas contenidas y susceptibles a ser evaluadas a través de la prueba.²

Para que una prueba de reclutamiento laboral tenga un contenido válido, debe ser una muestra representativa de las habilidades requeridas para el empleo y relacionadas con el desempeño de un trabajo. La observación conductual es una técnica utilizada de manera frecuente al elaborar el proyecto de las áreas de contenido que deben ser cubiertas en ciertos tipos de pruebas de reclutamiento laboral. El creador de pruebas observará a veteranos exitosos en el trabajo y diseñará una prueba que incluya una muestra representativa de dichas conductas. Luego, los mismos trabajadores observados (al igual que sus supervisores y otros) podrían ser llamados para actuar como expertos o jueces para estimar el grado en que el contenido de la prueba es una muestra representativa de las habilidades que exige la realización del trabajo. En ese punto, el diseñador querrá saber la medida en la cual los expertos o jueces están de acuerdo. Éste es un método para cuantificar el grado de conformidad que existe entre dichos evaluadores.

SÓLO PIENSE...

Un desarrollador de pruebas trabaja en el diseño de un breve instrumento de selección para predecir el éxito de los estudiantes en una prueba psicológica y un curso de evaluación. Usted es el consultor llamado para elaborar el proyecto de las áreas de contenido cubiertas. ¿Cuáles serían sus recomendaciones?

Cuantificación de la validez de contenido

La **medición de la validez de contenido** es importante en los escenarios laborales donde las pruebas utilizadas para contratar y promover al personal son meticulosamente examinadas por su

2. La aplicación del concepto de *proyecto y elaboración del proyecto* no se limita, por supuesto, a las pruebas de rendimiento. La elaboración de proyectos puede ser usada en el diseño de una prueba de personalidad, una medida de actitud o cualquier otra prueba, empleando en ocasiones los juicios de expertos en el campo.

relevancia respecto al trabajo a desempeñar. Puesto que los tribunales suelen requerir evidencias de que las pruebas de empleo están relacionadas con el trabajo, se han desarrollado diversos métodos para determinar la cantidad de validez de contenido (por ejemplo, James *et al.*, 1984; Lindell *et al.*, 1999; Tinsley y Weiss, 1975). Un método para medir la validez de contenido, elaborado por C. H. Lawshe, es esencialmente un método para determinar el consenso entre evaluadores o jueces respecto a cuán esencial puede ser un reactivo en particular. Lawshe (1975) propuso que cada evaluador responda a la siguiente pregunta para cada uno de los reactivos: “¿La habilidad o conocimiento medido por este reactivo es

- esencial
- útil pero no esencial
- no necesaria

para el desempeño del trabajo?” (p. 567). Para cada reactivo, se anota el número de expertos afirmando que el reactivo es esencial. De acuerdo con Lawshe, si más de la mitad de los expertos indica que un reactivo es esencial, ese reactivo tiene al menos cierta validez de contenido. Cuanto mayor sea el número de expertos que concuerdan en que un reactivo particular es esencial, existirán mayores niveles de validez de contenido. Con base en estos supuestos, Lawshe desarrolló una fórmula denominada **razón de validez de contenido (CVR)**, por sus siglas en inglés):

$$CVR = \frac{n_e - (N/2)}{N/2}$$

donde **CVR = razón de validez de contenido (content validity ratio)**, n_e = número de expertos que indican “esencial” y N = número total de expertos. Suponiendo un jurado de diez expertos, los siguientes tres ejemplos ilustran el significado que adquiere la CVR cuando es negativa, cero y positiva.

1. **CVR negativa:** cuando menos de la mitad de los expertos indican “esencial”, la CVR es negativa. Supongamos que cuatro de los diez expertos indicaron “esencial”:

$$CVR = \frac{4 - (10/2)}{10/2} = -0.2$$

2. **CVR cero:** cuando exactamente la mitad de los expertos indica “esencial”, la CVR es cero:

$$CVR = \frac{5 - (10/2)}{10/2} = .00$$

3. **CVR positiva:** cuando más de la mitad, pero no todos los expertos indican “esencial”, la CVR oscila entre .00 y .99. Supongamos que nueve de diez indicaron “esencial”:

$$CVR = \frac{9 - (10/2)}{10/2} = .80$$

Para validar una prueba, es necesario calcular la “razón de validez de contenido” para cada reactivo. Lawshe recomienda que el reactivo debe eliminarse si la cantidad de acuerdo observado tiene más de 5 por ciento de probabilidad de ocurrir al azar. Los valores mínimos de CVR correspondientes a este nivel del 5 por ciento se presentan en la tabla 6-1. En el caso de diez expertos, un reactivo necesitaría una CVR mínima de .62. En nuestro tercer ejemplo (en el cual nueve de diez expertos estuvieron de acuerdo), la CVR de .80 es significativa; por tanto el reactivo podría conservarse. De manera subsecuente, en nuestra exposición sobre la validez en relación al criterio, nuestra atención cambia a un índice de validez basado no en el contenido de la prueba sino en las calificaciones. Pero antes, una perspectiva sobre la cultura en cuanto está relacionada con la validez de una prueba.

Tabla 6-1

Valores mínimos de la razón de validez de contenido para asegurar que es improbable que el acuerdo sea debido al azar

Número de expertos	Valor mínimo
5	.99
6	.99
7	.99
8	.75
9	.78
10	.62
11	.59
12	.56
13	.54
14	.51
15	.49
20	.42
25	.37
30	.33
35	.31
40	.29

Fuente: Lawshe (1975)

La cultura y la relatividad de la validez de contenido

A menudo las pruebas son consideradas como válidas o no válidas. Una prueba de historia, por ejemplo, mide o no mide con precisión nuestro conocimiento sobre un hecho histórico. Sin embargo, también es cierto que lo que constituye un hecho histórico depende, en algunos casos, de quién escribe la historia. Considérese, por ejemplo, un evento trascendental en la historia del mundo, uno que sirvió como catalizador para la primera guerra mundial. El 28 de junio de 1914, el archiduque Franz Ferdinand, presunto heredero al trono de Austria y Hungría, fue asesinado por un serbio llamado Gavrilo Princip (figura 6-1). Ahora piense en cómo respondería el siguiente reactivo de opción múltiple en una prueba de historia:

Gavrilo Princip fue

- a) Un poeta
- b) Un héroe
- c) Un terrorista
- d) Un nacionalista
- e) Todo lo anterior

En varios libros de texto que circulan en la región Bosnia, la opción “e” —es decir, todo lo anterior— es la respuesta “correcta”. De acuerdo con Hedges (1997), en las áreas de Bosnia y Herzegovina que están bajo el control de distintos grupos étnicos se imparte una amplia variedad de caracterizaciones del asesino. En la región del país controlada por los serbios, los libros de historia, y probablemente los libros para medir el aprendizaje de los estudiantes, consideran a Princip como un “héroe y poeta”. Por el contrario, los estudiantes croatas aprenden que Princip fue un asesino entrenado para cometer un acto terrorista; mientras que a los musulmanes de la región se les enseña que Princip fue un nacionalista cuya hazaña desencadenó los disturbios antiserbios.

Por increíble que pueda parecer a los occidentales, a los estudiantes en Bosnia y Herzegovina en la actualidad se les enseñan diferentes versiones de la historia, del arte y del lenguaje dependiendo de su origen étnico. Esta situación ilustra en rígido relieve la influencia de la cultura en lo que se enseña a los estudiantes, así como aspectos de la construcción, calificación, interpretación y validación de pruebas. De esta manera, **la influencia de la cultura se extiende a los juicios de valor relacionados con la validez de las pruebas y de los reactivos.** Las diferencias en los juicios



Figura 6-1
Relatividad cultural, historia y validez de la prueba

El archiduque austro-húngaro Franz Ferdinand y su esposa Sofía aparecen retratados (izquierda) cuando salían del Ayuntamiento de Sarajevo el 28 de junio de 1914. Momentos después, Ferdinand sería asesinado por Gavrilo Princip, mostrado bajo custodia (derecha). Este asesinato sirvió como catalizador para la primera guerra mundial y es discutido y analizado en los libros de texto de historia en todos los idiomas del mundo. No obstante, las descripciones —y los reactivos en las pruebas de capacidad basados en dichas descripciones— del asesino en esos libros varían en función de la cultura.

concernientes a la validez de las pruebas y la validez de los reactivos de las pruebas pueden ser diferentes de un país a otro a lo largo del mundo y, a veces, incluso de un salón de clases a otro. Una prueba de historia que es considerada válida en un salón de clases no será considerada así en otro. Además, las interpretaciones hechas en base a las respuestas de quien responde la prueba variarán como una función de la cultura. Así, por ejemplo, los estudiantes croatas de Bosnia que seleccionen la opción “b” (héroe) para el reactivo de prueba sobre Gavrilo Princip pueden hacer algo más que disminuir sus calificaciones en la prueba de historia; pueden atraerse un escrutinio

indeseable, si no es que una investigación formal, respecto a sus lealtades políticas. Estos escenarios dan nuevo significado al término *políticamente correcto* cuando se aplica a pruebas, reactivos y las respuestas dadas por los examinados.

La región Bosnia difícilmente es única al respecto. En este contexto, imagine un segmento del programa *60 Minutos* (noticiero de la televisión estadounidense) titulado “Hermano contra hermano”, transmitido por primera vez el 7 de diciembre de 1997. El corresponsal Ed Bradley reportó el caso de un profesor palestino que había incluido en un examen algunas preguntas sobre la corrup-

ción en el gobierno. La respuesta de las autoridades palestinas fue interrogar, confinar y torturar al profesor, todo en aras de mantener aprobada por el gobierno la “validez de contenido” en los exámenes universitarios.

SÓLO PIENSE...

National, creadores de pruebas comerciales que publican pruebas de inteligencia ampliamente utilizadas, deben mantener la validez de contenido de sus pruebas. ¿Cómo imagina usted que lo logran?

Validez relacionada con el criterio

La **validez relacionada con el criterio** es un juicio de cuán adecuadamente puede ser utilizada la puntuación de una prueba para inferir la posición más probable de un individuo con respecto a cierta medida de interés —siendo el criterio esa medida de interés—. Dos tipos de evidencias de validez se encuentran asumidas bajo el rubro de *validez relacionada con el criterio*. La **validez concurrente** es un índice del grado en que se relaciona la puntuación de una prueba con alguna medida de criterio obtenida al mismo tiempo (de manera concurrente) que la puntuación; la **validez predictiva** es un índice del grado en que la puntuación de una prueba predice alguna medida de criterio. Antes de analizar a detalle cada uno de estos tipos de evidencia de la validez, parece apropiado plantear (y responder) una pregunta importante.

¿Qué es un criterio?

Un **criterio** puede ser definido en forma amplia como el **modelo contra el cual se compara y evalúa una prueba o la puntuación de una prueba**. Desde el punto de vista operativo, un criterio puede ser casi cualquier cosa: *el desempeño de un piloto al volar un Boeing 767, la calificación en un examen de ondulación del cabello, el número de días de permanencia en hospitalización psiquiátrica* y la lista podría ser interminable. **No hay reglas precisas de lo que constituye un criterio**; puede ser la calificación de una prueba, una conducta específica o un grupo de comportamientos, una cantidad de tiempo, una estimación, un diagnóstico psiquiátrico, un costo de capacitación, un índice de ausentismo, un índice de intoxicación alcohólica, etcétera. Cualquiera que sea el criterio, de manera ideal es relevante, válido y sin contaminación.

Características de un criterio Un criterio adecuado es *relevante*. Con ello queremos decir que **es pertinente o aplicable al tema de interés**. Esperaríamos, por ejemplo, que una prueba que pretenda asesorar a los examinados si acaso comparten los mismos intereses que actores exitosos haya sido validada utilizando los intereses de actores exitosos como criterios.

Una medida de criterio adecuada debe también ser *válida* para el propósito para el que está siendo usada. Si una prueba (X) es usada como el criterio para validar una segunda prueba (Y), entonces debe existir evidencia de que la prueba X es válida. Si el criterio es usado para la estimación hecha por un juez o un grupo de expertos, entonces debe existir evidencia de que dicha estimación es válida. Suponga, por ejemplo, que de una prueba de personalidad con la que se pretende medir la depresión se dice que ha sido validada usando como criterio los diagnósticos hechos por un panel reconocido de eminentes psicólogos. Un usuario de la prueba podría desear probar en definitiva, variables tales como las acreditaciones del “panel de eminencias” (esto es, sus antecedentes educativos, capacitación y experiencia) así como de los procedimientos utilizados para validar un diagnóstico de depresión. Las respuestas a estas preguntas ayudarán a abordar la cuestión de si el criterio (en este caso el diagnóstico hecho por los miembros del panel) era en verdad válido.

En forma ideal, un criterio debe estar *libre de contaminación*. El **término contaminación del criterio** se aplica a las medidas de criterio que se han basado, al menos en parte, en medidas de predicción. Suponga que un equipo de investigación de una compañía llamada Investigación Psiquiátrica Internacional de Ventura (VIPR, por sus siglas en inglés) acaba de completar un estudio sobre la precisión con la cual una prueba denominada MMPI-2 hizo el pronóstico de un diagnóstico psiquiátrico en la población psiquiátrica del sistema de hospitales del estado de Minnesota. Como veremos en la capítulo 11, el MMPI-2 es, en efecto, una prueba ampliamente usada. En este estudio, el instrumento de predicción es el MMPI-2 y el criterio es el diagnóstico psiquiátrico que existe en el expediente clínico de cada paciente. Supongamos además que, mientras se efectúa el proceso del análisis de datos, una persona de la oficina matriz de VIPR informa al grupo de investigadores que el diagnóstico de los pacientes del sistema de hospitales del estado de Minnesota fue determinada, al menos en parte, por una calificación de la prueba MMPI-2. ¿Deberían proseguir con el análisis? La respuesta es no, debido a que la medida de pronóstico contaminó la medida

de criterio, sería de poco valor averiguar en esencia, que el elemento de predicción puede, en efecto, predecirse a sí mismo.

Ahora, veamos más de cerca lo que se quiere decir con validez concurrente y validez predictiva.

Validez concurrente

Si las calificaciones de la prueba se obtienen más o menos al mismo tiempo que las medidas de criterio, entonces las medidas de la relación entre las calificaciones de la prueba y el criterio proporcionan evidencia de la *validez concurrente*. Las *declaraciones de validez concurrente* indican el grado en que las puntuaciones de una prueba pueden servir para estimar la posición actual de un individuo frente a un criterio. Si, por ejemplo, las puntuaciones (o clasificaciones) hechas en base a una prueba de psicodiagnóstico debieran validarse contra un criterio de pacientes psiquiátricos ya diagnosticados, el proceso a seguir sería uno de *validación concurrente*. En general, una vez que se ha establecido la validez de la inferencia de las calificaciones, la prueba puede proporcionar una forma más rápida y menos costosa para ofrecer un diagnóstico o una decisión de clasificación. Una prueba con validez concurrente demostrada en forma satisfactoria puede, por tanto, ser muy atractiva para futuros usuarios porque ofrece el potencial de ahorrar dinero y tiempo profesional.

Algunas veces la validez concurrente de una prueba particular (llamémosla prueba A) es explorada en relación con otra prueba (que llamaremos prueba B). En dichos estudios, una investigación previa ha demostrado en forma satisfactoria la validez de la prueba B, por lo cual, ahora la pregunta que se genera es “¿qué tan bien se compara la prueba A con la B?” En este caso, la prueba B se usa como *criterio de validación*. En algunos estudios la prueba A se considera o bien una nueva prueba o una prueba que se está usando para cierto propósito nuevo, quizá con una nueva población.

Aquí presentamos un ejemplo de la “vida real” de un estudio de validez concurrente, en el cual un grupo de investigadores exploró si una prueba validada para su uso con adultos podría ser usada con adolescentes. El Inventario de depresión de Beck (BDI, Beck Depression Inventory; Beck *et al.*, 1961, 1979; Beck y Steer, 1993) y su revisión, el Inventario de depresión de Beck-II (BDI-II; Beck *et al.*, 1996) son medidas de autorreporte que sirven para identificar síntomas de depresión y cuantificar su gravedad. Aun cuando el BDI había sido ampliamente usado con adultos, surgieron preguntas con respecto a que si su uso era apropiado con adolescentes. Ambrosini *et al.* (1991) realizaron un estudio de validez concurrente para explorar la utilidad del BDI con adolescentes.

SÓLO PIENSE...

¿Qué más podrían haber hecho los investigadores para examinar la utilidad del inventario BDI con adolescentes?

También buscaban determinar si la prueba podía diferenciar con éxito a pacientes con depresión de aquellos sin depresión en una población de pacientes externos adolescentes. Los diagnósticos generados de la administración concurrente de un instrumento previamente validado para su uso con adolescentes se utilizaron para validar el criterio. Los hallazgos obtenidos sugirieron que el BDI es un instrumento válido para ser usado con adolescentes.

Ahora volvamos nuestra atención a otra forma de validez de criterio, una en la cual la medida del criterio no se obtiene en forma concurrente (simultáneo) sino en algún momento posterior.

Validez predictiva

Las calificaciones de la prueba pueden obtenerse en un cierto momento y las medidas de criterio en uno posterior, usualmente después de que algún evento mediador ha ocurrido, dicho evento podría ser la capacitación, la experiencia, alguna terapia, alguna medicación o tan sólo el paso del tiempo. Las medidas de la relación que existe entre las puntuaciones de la prueba y una medida de criterio obtenida en un momento futuro nos dan un indicio de la *validez predictiva* de la prueba; es decir, con cuánta precisión las puntuaciones predicen alguna medida de criterio. Por ejemplo, las medidas de la relación entre las pruebas de admisión a la universidad y los promedios de calificación de un estudiante universitario de primer año, son evidencia de la validez predictiva de las pruebas de admisión.

En escenarios donde las pruebas pueden tener utilidad, como en una agencia de colocaciones, una oficina de admisión a la universidad o en la oficina administrativa de un reclusorio, una prueba con un alto nivel de validez predictiva puede ser un auxiliar muy útil para quienes toman las decisiones en la selección de los mejores estudiantes, de los trabajadores más productivos o los riesgos de otorgar la libertad condicional a un candidato equivocado. Lo valioso del resultado de una prueba para tomar una decisión dependerá de cómo dicho resultado mejore las decisiones de selección en comparación con las que se hubieran tomado sin conocerlo. En un medio industrial donde los volúmenes de producción son importantes, si el uso de una prueba de selección de personal puede mejorar la productividad incluso en un grado mínimo, el mejoramiento en la productividad producirá ganancias anuales lo cual se traducirá en un incremento de las utilidades en millones de pesos. En un contexto clínico, sería invaluable una prueba que pudiera salvar más vidas del suicidio o que proporcione una predicción exacta por encima de cualquier otra prueba en lo referente a tal opción. Por desgracia, las dificultades inherentes al desarrollo de estas pruebas son numerosas y multifacéticas (Mulvey y Lidz, 1984; Murphy, 1984; Petrie y Chamberlain, 1985).

Los juicios sobre la validez relacionada con el criterio, ya sea concurrente o predictiva, se basan en dos tipos de evidencia estadística: el coeficiente de validez y los datos de contingencia.

El coeficiente de validez El coeficiente de validez es un coeficiente de correlación que proporciona una medida de la relación entre las calificaciones de una prueba y las de medida del criterio. Un ejemplo de coeficiente de validez es la correlación del coeficiente de validez calculado a partir de una calificación (o clasificación) de una prueba de diagnóstico psicológico y la calificación (o clasificación) del criterio asignada por especialistas en diagnósticos psicológicos. De manera característica, el coeficiente que se utiliza para determinar la validez entre las dos medidas es el coeficiente de correlación de Pearson. Sin embargo, dependiendo de variables como el tipo de datos, el tamaño de la muestra y la forma de la distribución, podrían utilizarse otros coeficientes de correlación. Por ejemplo, al correlacionar nuestro rango de desempeño en algún trabajo, con los rangos establecidos por los supervisores del trabajo, se emplearía la fórmula para la correlación de orden de rango rho de Spearman.

Como el coeficiente de confiabilidad y otras medidas de correlación, el coeficiente de validez es afectado por la restricción o la inflación del rango. Y como en otros estudios correlacionales, una cuestión clave es si el rango de puntuaciones empleado es adecuado para el objetivo del análisis correlacional. En situaciones donde, por ejemplo, se registra una disminución en el número de sujetos en el transcurso del estudio, el coeficiente de validez podría verse afectado en forma adversa.

El problema de un rango restringido también puede ocurrir a través del proceso de autoselección en la muestra empleada en el estudio de validación. Así, por ejemplo, si la prueba pretende medir algo tan técnico o tan peligroso como la capacidad para combatir incendios en una embarcación petrolera, bien puede ser que las únicas personas que respondan a un anuncio para un puesto de bombero en un barco petrolero sean aquellas que en realidad sean altamente calificadas para el puesto. Por consiguiente, el rango de la distribución de calificaciones en esta prueba de capacidad para combatir incendios en un barco petrolero sería restringido. Para puestos menos técnicos o peligrosos, un factor de autoselección podría influir si el desarrollador de la prueba selecciona a un grupo de empleados recién contratados para examinarlos (con la esperanza de que estén disponibles medidas de criterio para este grupo en alguna fecha subsiguiente). Sin embargo, debido a que es probable que los empleados recién contratados ya hayan pasado por alguna valoración formal o informal en el proceso de contratación, hay una buena probabilidad de que la capacidad en este grupo sea mayor que en una muestra aleatoria de aspirantes comunes al empleo. En consecuencia, las calificaciones en la medida de criterio que será administrada luego tenderán a ser más altas en el primer grupo que las obtenidas en la muestra aleatoria de los aspirantes comunes. Dicho de otra manera, las calificaciones tendrán un rango restringido.

Mientras que es responsabilidad del autor de la prueba reportar datos de validación en el manual de la misma, es responsabilidad de los usuarios leer cuidadosamente la descripción del estudio de validación y evaluar la conveniencia de la prueba para sus propósitos específicos. ¿Cuáles fueron las características de la muestra usada en el estudio de validación? ¿Cómo se

equiparan estas características con las personas para quienes se contempla una aplicación de la prueba? ¿Son más apropiadas algunas de las subpruebas para un propósito específico dentro de la prueba, que la prueba misma?

¿Qué tan alto debe ser un coeficiente de validez para el usuario como para que el autor de una prueba pueda inferir que la prueba es válida? No hay reglas para determinar la magnitud mínima aceptable de un coeficiente de validez. De hecho, Cronbach y Gleser (1965) advirtieron contra el establecimiento de tales reglas. Argumentaron que los coeficientes de validez no necesitan ser demasiado elevados para permitir al usuario tomar decisiones precisas dentro del contexto único en el cual una prueba está siendo usada. De manera esencial, el coeficiente de validez debería ser lo bastante alto para que permita la identificación y diferenciación de los examinados con respecto a un atributo o atributos buscados, como empleados que probablemente sean más productivos, oficiales de policía que tengan menos probabilidad de usar mal sus armas y estudiantes con mayor probabilidad de tener éxito en un curso o materia a estudiar.

Validez de incremento Los usuarios de las pruebas involucrados en la predicción de algún criterio a partir de calificaciones obtenidas en la prueba, suelen interesarse en la utilidad de pronosticadores múltiples. El valor de incluir más de un pronosticador depende de dos factores. Primero, por supuesto, cada medida utilizada como pronosticador deberá tener validez predictiva en relación con un criterio. Segundo, los pronosticadores adicionales deberían poseer **validez de incremento**, definida aquí como el grado en que un pronosticador adicional explica algo de la medida de criterio que no había sido explicado por otros pronosticadores ya en uso.

La validez de incremento puede ser usada para predecir algo como el éxito académico en la universidad. El promedio de calificaciones al final del primer año puede emplearse como una medida del éxito académico. Un estudio de pronosticadores potenciales del promedio de calificaciones podría revelar que el tiempo pasado en la biblioteca y el dedicado al estudio están altamente correlacionados con el promedio de calificaciones. La cantidad de descanso que un compañero de cuarto le permite tener a un estudiante durante los periodos de exámenes está correlacionado en menor grado con el promedio de calificaciones. ¿Cuál es la forma más precisa y eficiente de predecir el promedio de calificaciones? Una aproximación, que emplea los principios de la validez de incremento, es comenzar con el mejor pronosticador, el que esté correlacionado de manera más alta o directa con el promedio de calificaciones. Éste puede ser el tiempo dedicado al estudio. Entonces, usando técnicas de regresión múltiple, se analizaría la utilidad de los otros pronosticadores.

Aun cuando el tiempo de estudio en la biblioteca está correlacionado de manera alta con el promedio de calificaciones, puede no poseer validez de incremento si se superpone demasiado al primer pronosticador, el tiempo dedicado al estudio. Dicho de otra manera, si el tiempo dedicado al estudio y el pasado en la biblioteca están correlacionados de manera tan alta entre sí como para reflejar en esencia lo mismo, entonces sólo uno de ellos debe incluirse como pronosticador. Incluir ambos proporcionaría poca información nueva. En contraste, la variable que es la cantidad de descanso que el compañero de dormitorio le permite tener a un estudiante durante los exámenes puede tener una buena validez de incremento. Esto es así debido a que refleja un aspecto diferente de la preparación para los exámenes (el descanso) que el primer pronosticador (el estudio). La validez de incremento ha sido empleada para mejorar el pronóstico del desempeño laboral para los mecánicos del Cuerpo de la Marina (Carey, 1994) y la predicción del abuso infantil (Murphy-Berman, 1994). En ambos casos, las medidas de predicción fueron incluidas sólo cuando éstas demostraban que podían explicar algo de la medida de criterio que en ese momento no se había conocido a partir de los otros pronosticadores.

SÓLO PIENSE...

A partir de su experiencia personal, ¿cuál sería un pronosticador poco obvio del promedio de calificaciones y que probablemente no esté correlacionado con el tiempo que se utiliza para estudiar?

Datos de expectativas Los datos de expectativas proporcionan información que puede ser usada para valorar la validez de una prueba relacionada con un criterio. Usando una calificación obtenida en alguna(s) prueba(s) o medida(s), las tablas de expectativas ilustran la probabilidad de que el examinado obtenga una calificación dentro de algún intervalo de calificaciones en una medida

de criterio —un intervalo que puede considerarse como “aprobatorio”, “aceptable”, etcétera. Una tabla de expectativas muestra el porcentaje de personas dentro de intervalos específicos de puntuaciones de pruebas que de manera subsiguiente fueron colocados en diversas categorías del criterio (por ejemplo, colocados en la categoría de “aprobado” o en la de “reprobado”). Una tabla de expectativas puede ser creada a partir de una gráfica de dispersión de acuerdo con los pasos enumerados en la figura 6-2. Una tabla de expectativas que muestra la relación entre puntuaciones en una subprueba de la “Prueba de aptitudes diferenciales” (*Differential Aptitude Test*, DAT) y las calificaciones del curso de historia estadounidense para estudiantes del undécimo grado se presenta en la tabla 6-2. Podemos ver que de los estudiantes que lograron calificaciones entre 40 y 60, 83% obtuvo una calificación de 80 o más en ese curso.

Para ilustrar cómo podría ser usada una tabla de expectativas por una oficina corporativa de personal, supongamos que en base a varias puntuaciones de pruebas y entrevistas personales, los expertos en reclutamiento de personal calificaron a todos los solicitantes a un puesto de trabajo manual que implicaba trabajo a destajo como *excelente*, *muy bueno*, *promedio*, *por debajo del promedio* y *malo*. En este ejemplo, entonces, la puntuación en la prueba es en realidad una estimación hecha por expertos en capital humano, basada en varias puntuaciones de la prueba y en una entrevista personal. Supongamos además que debido a una severa escasez de mano de obra en ese momento, todos los solicitantes fueron contratados —lo cual, por cierto, sería un sueño convertido en realidad para un investigador interesado en llevar a cabo un estudio de validación del procedimiento de evaluación—. Los supervisores de piso no fueron informados de la puntuación compuesta obtenida por los trabajadores recién contratados y estos supervisores proporcionan la medida de criterio al calificar el desempeño de cada empleado como *satisfactorio* o *insatisfactorio*. La figura 6-3 es la **gráfica de expectativas** o representación gráfica de una tabla de expectativas resultante.

Como se ilustra en la gráfica de expectativas, de todos los solicitantes originalmente calificados como *excelentes*, 94% fue considerado como *satisfactorio* en el trabajo. Por el contrario, de los aspirantes calificados originalmente como *malos*, sólo 17% fue considerado *satisfactorio*. En general, esta gráfica de expectativas nos dice que entre mayor sea la calificación inicial, será mayor la probabilidad de éxito en el trabajo. Planteado de otra manera, nos dice que entre más baja sea la calificación inicial, será mayor la probabilidad de fracaso en el trabajo. La compañía que experimente con este método de calificación podría esperar de manera razonable que mejore su productividad al utilizar dicho sistema. De manera específica, los solicitantes que hayan obtenido calificaciones *promedio* o superiores serían los únicos contratados.

Las tablas que podrían ser usadas como un auxiliar para los directores de recursos humanos en sus tareas de toma de decisiones fueron publicadas por H. C. Taylor y J. T. Russell en la *Gaceta de Psicología Aplicada* (*Journal of Applied Psychology*) en 1939. Conocidas por los nombres de sus autores, las **tablas Taylor-Russell** proporcionan un estimado de la medida en que la inclusión de una prueba particular en el sistema de selección mejorará dicha selección. De manera más específica, las tablas proporcionan una estimación del porcentaje de empleados contratados, mediante el uso de una prueba particular, que serán exitosos en sus trabajos, dadas diferentes combinaciones de tres variables: la validez de la prueba, la razón de selección usada y la tasa base.

El valor asignado por la validez de la prueba es el **coeficiente de validez calculado**. La **razón de selección** es un valor numérico que refleja la relación entre el número de personas que serán contratadas y el número disponible para la contratación. Por ejemplo, si hubiera 50 puestos y 100 aspirantes, la razón de selección sería 50/100, o .50. Como la utilizamos aquí, la **tasa base** se refiere al **porcentaje de personas contratadas bajo el sistema existente para un puesto en particular**. Si, por ejemplo, una empresa empleara 25 programadores de computación y 20 fueran considerados exitosos, la tasa base sería .80. Conociendo el coeficiente de validez de una prueba particular, junto con la razón de selección, la referencia a las tablas Taylor-Russell le proporcionarían al funcionario de recursos humanos una estimación de cuánto mejoraría la selección usando la prueba en comparación a los métodos existentes.

Una tabla Taylor-Russell se presenta en la tabla 6-3 (p. 170). Esta tabla es para la tasa base de .60, lo que significa que el 60% de los contratados bajo el sistema existente son exitosos en su trabajo. Abajo del lado izquierdo están los coeficientes de validez para una prueba que podría ser usada para ayudar a seleccionar empleados. A lo largo de la parte superior están las diversas




Figura 6-2
Siete pasos para elaborar una tabla de expectativas

Fuente: Del *Manual de pruebas de aptitud diferencial (Manual of Differential Aptitude Tests)*, quinta edición, Forms S & T. Derechos reservados © 1973, 1974 por The Psychological Corporation, una Compañía de Evaluación Harcourt. Reproducida con autorización. Todos los derechos reservados. "Differential Aptitude Tests" y "DAT" son marcas registradas por The Psychological Corporation, en Estados Unidos de América y /u otras jurisdicciones.

1. *Elabore una gráfica de dispersión de tal modo que cada punto en la gráfica represente una combinación particular de calificaciones obtenidas en la prueba-combinación de calificación de criterio. El criterio debe representarse en el eje Y.*
2. *Dibuje una cuadrícula que le permita resumir el número de personas que obtuvieron calificaciones que caen dentro de un intervalo particular.*
3. *Cuente el número de puntos en cada celda (n_i) como se muestra en la figura.*
4. *Cuente el número total de puntos dentro de cada intervalo vertical (N_v). Este número representa el número de personas que obtuvieron calificaciones dentro de un intervalo particular de calificación en la prueba.*
5. *Convierta la frecuencia de cada celda a un porcentaje (n_i/N_v). Este número representa el porcentaje de personas que obtuvieron una combinación particular de calificación en la prueba-combinación de calificación de criterio. Escriba los porcentajes en las celdas. Encierre los porcentajes entre paréntesis para distinguirlos de las frecuencias.*
6. *En una hoja separada, escriba los encabezados y subencabezados de la tabla y copie los porcentajes en las celdas apropiadas de la tabla como se muestra en la tabla 6-2. Tenga cuidado de escribir los porcentajes en las celdas correctas de la tabla. (Observe que es fácil cometer errores en esta etapa debido a que los porcentajes de personas dentro de los intervalos particulares de calificación están colocados de manera horizontal en la tabla y de manera vertical en la gráfica de dispersión.)*
7. *Si lo desea, anote el número y el porcentaje de casos de intervalo por calificación en la prueba. Si el número de casos es muy pequeño en cualquiera de las celdas, es muy probable que fluctúe en gráficas subsecuentes. Si el tamaño de las celdas es pequeño, el usuario podría incorporar menos celdas o acumular datos sobre varios años.*

Tabla 6-2

Calificaciones de una subprueba del DAT de 171 niños del onceavo grado en el uso del lenguaje y del conocimiento sobre la historia de Estados Unidos (se muestra el porcentaje de estudiantes que obtuvieron calificaciones del curso en el intervalo mostrado)

Calificación en la prueba	Intervalo de calificación en el curso				Casos por intervalo de calificación en la prueba	
	0-69	70-79	80-89	90-100	N _v	%
40 y más alta	0	17	29	54	52	100
30-39	8	46	29	17	48	100
0-29	15	59	24	2	41	100
menos de 20	37	57	7	0	30	101*

*La suma total excede del 100% debido al redondeo.

Fuente: *Manual de Pruebas de aptitud diferencial (Manual of Differential Aptitude Tests)*, quinta edición, Derechos Reservados © 1973, 1974 por The Psychological Corporation, una Compañía de Evaluación Harcourt. Reproducido con autorización. Todos los derechos reservados. "Differential Aptitude Tests" y "DAT" son marcas registradas por The Psychological Corporation, en Estados Unidos de América y/u otras jurisdicciones.




Figura 6-3

Gráfica de expectativas para estimaciones de prueba y desempeño en el trabajo

Fuente: Tomado del Boletín de servicio para las pruebas (*Test Service Bulletin*), "¿Qué tan efectivas son sus pruebas?" (*How effective are your tests?*), The Psychological Corporation, San Antonio, Texas. Reproducido con autorización del editor.

razones de selección. Éstas reflejan la proporción de personas solicitando empleo que serán contratadas. Si se introduce una nueva prueba para ayudar a seleccionar empleados en una situación específica con una razón de selección de .20, y si la prueba nueva tiene un coeficiente de validez de predicción de .55, la tabla muestra que la tasa base se incrementará hasta .88. Esto significa que, en lugar del 60% de los empleados contratados de los que se espera se desempeñen con éxito, puede preverse que lo haga un total de 88%. Cuando las razones de selección sean bajas, como cuando sólo el 5% de los aspirantes sea contratado, aun las pruebas con coeficientes de validez bajos, como .15, pueden resultar en tasas base mejoradas.

Una limitación de las tablas Taylor-Russell es que la relación entre el pronosticador (la prueba) y el criterio (la calificación del desempeño en el trabajo) debe ser lineal. Si, por ejemplo, hay algún punto en el cual el desempeño en el trabajo se nivele, sin importar qué tan alta sea la puntuación obtenida en la prueba, sería inapropiado usar las tablas Taylor-Russell. Otra limitación de las tablas Taylor-Russell es la dificultad potencial para identificar un criterio de calificación que separe a los empleados "exitosos" de los "no exitosos".

Tabla 6-3
Tabla Taylor-Russell para una tasa base de .60

Validez (ρ_{xy})	Razón de selección										
	.05	.10	.20	.30	.40	.50	.60	.70	.80	.90	.95
.00	.60	.60	.60	.60	.60	.60	.60	.60	.60	.60	.60
.05	.64	.63	.63	.62	.62	.62	.61	.61	.61	.60	.60
.10	.68	.67	.65	.64	.64	.63	.63	.62	.61	.61	.60
.15	.71	.70	.68	.67	.66	.65	.64	.63	.62	.61	.61
.20	.75	.73	.71	.69	.67	.66	.65	.64	.63	.62	.61
.25	.78	.76	.73	.71	.69	.68	.66	.65	.63	.62	.61
.30	.82	.79	.76	.73	.71	.69	.68	.66	.64	.62	.61
.35	.85	.82	.78	.75	.73	.71	.69	.67	.65	.63	.62
.40	.88	.85	.81	.78	.75	.73	.70	.68	.66	.63	.62
.45	.90	.87	.83	.80	.77	.74	.72	.69	.66	.64	.62
.50	.93	.90	.86	.82	.79	.76	.73	.70	.67	.64	.62
.55	.95	.92	.88	.84	.81	.78	.75	.71	.68	.64	.62
.60	.96	.94	.90	.87	.83	.80	.76	.73	.69	.65	.63
.65	.98	.96	.92	.89	.85	.82	.78	.74	.70	.65	.63
.70	.99	.97	.94	.91	.87	.84	.80	.75	.71	.66	.63
.75	.99	.99	.96	.93	.90	.86	.81	.77	.71	.66	.63
.80	1.00	.99	.98	.95	.92	.88	.83	.78	.72	.66	.63
.85	1.00	1.00	.99	.97	.95	.91	.86	.80	.73	.66	.63
.90	1.00	1.00	1.00	.99	.97	.94	.88	.82	.74	.67	.63
.95	1.00	1.00	1.00	1.00	.99	.97	.92	.84	.75	.67	.63
1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	.86	.75	.67	.63

Fuente: Taylor y Russell (1939)

Los problemas potenciales de las tablas Taylor-Russell fueron evitados por un conjunto alternativo de tablas (Naylor y Shine, 1965) que proporcionaron un indicio de la diferencia en las calificaciones del criterio promedio para el grupo seleccionado comparado con el grupo original. El uso de las tablas Naylor-Shine implica obtener la diferencia entre las medias de los grupos seleccionados y no seleccionados para obtener un índice de lo que la prueba (o alguna otra herramienta de evaluación) está agregando a procedimientos ya establecidos. Tanto las tablas Taylor-Russell como las Naylor-Shine pueden ayudar a juzgar la utilidad de una prueba en particular, las primeras al determinar el incremento sobre procedimientos actuales y las últimas, el incremento en la calificación promedio en alguna medida de criterio. Con ambas tablas, el coeficiente de validez usado debe ser el obtenido por medio de procedimientos de validación concurrente, un hecho que no debe ser sorprendente debido a que es obtenido con respecto a los actuales empleados contratados mediante el proceso de selección que funcionaba al momento del estudio.

SÓLO PIENSE...

Además de administrar las pruebas, ¿qué otros tipos de procedimientos de evaluación podrían utilizar los empleadores para tomar decisiones razonables sobre la selección de personal?

Si las decisiones de contratación se tomaran sólo en base a variables como la validez de una prueba de desempeño y a la razón de selección prevaleciente, entonces tablas como las ofrecidas por Taylor y Russell, y Naylor y Shine podrían ser usadas en forma amplia en la actualidad. El hecho es que muchas otras clases de variables podrían entrar en las decisiones de contratación y de otra clase (incluyendo decisiones relativas al ascenso, transferencias, remociones y despidos). Algunas variables adicionales podrían incluir, por ejemplo, posición minoritaria de los solicitantes, la salud física o mental general o el uso de drogas. Dado que muchas variables pueden afectar una decisión de selección de personal (incluyendo la contratación) ¿de qué utilidad sería una prueba determinada y aplicada a lo largo del proceso de decisión?

Después de la publicación de las tablas Taylor-Russell, comenzó a aparecer un cierto número de artículos indagando formas de determinar lo adecuado de una prueba determinada con respecto a diferentes tipos de procedimientos de evaluación (Brogden, 1946, 1949; Smith, 1948), y una **literatura concerniente a la teoría de la utilidad de las pruebas comenzó a crecer**. También durante este periodo, estadísticos como Wald (1947, 1950) estuvieron implicados en la identificación de reglas estadísticas para desarrollar un análisis secuencial de un problema que condujera a una decisión óptima. **Había nacido la teoría de la decisión y sería aplicada para responder las interrogantes respecto a la utilidad de las pruebas psicológicas.**

Teoría de la decisión y utilidad de las pruebas Quizás la **aplicación citada con más frecuencia de la teoría de la decisión estadística en el campo de las pruebas psicológicas sean las *Pruebas psicológicas y decisiones sobre selección de personal* (Psychological Tests and Personnel Decisions, 1957, 1965) de Cronbach y Gleser.** La idea de aplicar la teoría de la decisión estadística a cuestiones como la utilidad de las pruebas era, de manera conceptual, atractiva y prometedora y un libro de texto reconocido en la época refleja el gran entusiasmo con el que se recibió este matrimonio de empresas:

La aproximación básica de la teoría de la decisión para la selección y colocación... tiene cierto número de ventajas sobre el enfoque más clásico basado en el modelo de correlación... No hay duda de que es un mejor modelo y más general para manejar esta clase de tareas de decisión, por tanto predecimos que en el futuro los problemas de selección y colocación serán tratados en este contexto con más frecuencia, quizá hasta la eventual exclusión del modelo correlativo más estereotipado. (Blum y Naylor, 1968, p. 58).

Planteado en forma general, Cronbach y Gleser (1965) presentaron 1) una clasificación de problemas de decisión, 2) varias estrategias de selección que varían desde procesos aplicados en una sola etapa hasta análisis secuenciales, 3) un análisis cuantitativo de la relación entre la utilidad de la prueba, la razón de selección, el costo del programa de aplicación de la prueba y el valor esperado del resultado y 4) La recomendación de que en algunos casos los requerimientos o exigencias del trabajo sean diseñados a la capacidad del solicitante en lugar de a la inversa (un concepto al que se le conoce como *tratamiento adaptativo*).

Antes de ilustrar la teoría de la decisión en acción, definiremos en forma breve (y un poco imprecisa) cinco términos encontrados con frecuencia en los debates de la teoría de la decisión aplicada a las pruebas y la medición psicológica: *tasa base*, *índice de aciertos*, *índice de fallas*, *falso positivo* y *falso negativo*.

De manera general, una **tasa base** es la **medida en la cual un rasgo, comportamiento, característica o atributo particular existe en la población (expresado como una proporción)**. Como se ilustra en el *Close-up* de este capítulo, debe darse la consideración debida a la tasa base de un atributo señalado en la muestra de personas que se está estudiando en la investigación de validez predictiva, comparada con la tasa base del mismo atributo en la población total. En lenguaje psicométrico, un **índice de aciertos** puede ser definido como la **proporción de personas que una prueba identifica con precisión como poseedoras o que exhiben un rasgo, comportamiento, característica o atributo particular**. Por ejemplo, el *índice de aciertos* podría referirse a la proporción, pronosticada con precisión, de personas capaces de desempeñar un trabajo en un nivel de licenciatura, o la proporción, identificada con precisión, de pacientes neurológicos que tienen un tumor cerebral. De igual modo, un **índice de fallas** puede ser definido como la **proporción de personas que una prueba falla en identificar como poseedoras o no, de una característica o atributo particular**. Aquí, una **falla equivale a una predicción imprecisa**. La categoría de *fallas* puede ser subdividida más adelante. Un **falso positivo** es una falla en la cual la prueba pronosticó que el examinado poseía la característica o atributo particular que estaba siendo medido cuando en realidad no lo poseía. Un **falso negativo** es una falla en la cual la prueba predijo que el examinado no poseía la característica o atributo particular que estaba midiendo cuando en realidad sí la poseía.

Suponga que usted desarrolló un procedimiento de medición al que llamó Prueba de vapor (PV), la cual fue diseñada para determinar si sujetos vivos y con buena salud están respirando realmente. El procedimiento para la PV implica que el examinador sostenga un espejo bajo la nariz y la boca del sujeto por un minuto o más y observe si el aliento del sujeto empaña el espejo.

Tasa base y validez predictiva

Para evaluar la validez predictiva de una prueba, ésta puede ser administrada de forma que señale un atributo en particular a una muestra de sujetos de investigación en la cual aproximadamente la mitad de éstos posea o exhiba el atributo señalado y la otra mitad no. De manera subsecuente, pueden surgir preguntas sobre lo apropiado del uso de una prueba así, en la cual la tasa base de ocurrencia del atributo determinada en la población que se está examinando es considerablemente menor del 50%. Estas interrogantes surgen, por ejemplo, con respecto al uso de una prueba llamada “Inventario potencial de abuso infantil” (*Child Abuse Potential Inventory*, CAP; Milner, 1986).

La CAP fue diseñada para ser un auxiliar en la identificación de adultos con un alto riesgo de cometer abuso físico con niños. Una calificación alta en la CAP, especialmente en combinación con evidencia confirmatoria de otras fuentes, podría inducir al usuario de la prueba a indagar más a fondo respecto a la historia del evaluado o sus objetivos presentes respecto al abuso infantil. Otro uso de la CAP es como una medida de resultados en programas diseñados para prevenir el abuso físico en los niños (Milner, 1989). A los participantes se les podría aplicar la CAP en cuanto entren al programa y de nuevo antes de salir.

La investigación de la validez de predicción realizada con la CAP ha “demostrado un extraño índice de aciertos (alrededor de 90%) al diferenciar a los abusadores de los no abusadores” (Melton y Limber, 1989, p. 1231). No obstante, como ha señalado el autor de la CAP, “el índice de aciertos de 90% reportado fue determinado en estudios que usaron grupos que consistían en cantidades iguales de abusadores y de no abusadores que por diseño contienen tasas base de 50% las cuales son óptimas para propósitos de clasificación” (Milner, 1991, p. 80). De esta manera, conforme disminuye la tasa base del abuso infantil, el número de falsos positivos en el grupo señalado como abusadores se incrementará, mientras que el número de falsos negativos en el grupo indicado como no abusadores disminuirá. Si estos hechos relacionados con las tasas base y la validez predictiva no son conocidos y apreciados por el usuario de la prueba, podría existir el riesgo potencial de mal uso de pruebas como la CAP.

Tabla 1
Aplicación de la CAP a una población con una tasa base alta en cuanto a abuso infantil

	Situación real		Totales por filas
	Abusador	No abusador	
<i>Los resultados de la CAP indican:</i>			
Abusador	91	13	104
No abusador	19	97	116
Totales por columnas	110	110	220

La tasa base para el abuso infantil en la población general es de alrededor de 2-3% anual (Finkelhor y Dziuba-Leatherman, 1994). Esta tasa base es relativamente baja para la tasa base de 50% que prevaleció en los estudios de validez predictiva con la CAP. Este hecho, por tanto, debe ser considerado en cualquier uso de la CAP con miembros de la población general.

Con estos antecedentes, considere un estudio realizado por Milner *et al.* (1986) con 220 adultos, incluyendo 110 abusadores conocidos y 110 no abusadores. Todos los sujetos completaron la CAP y la prueba fue calificada. Un total de 82.7% de los abusadores y 88.2% de los no abusadores fueron clasificados en forma correcta usando la CAP (Tabla 1). Descendiendo por las columnas de la tabla 1, observe que de los 110 abusadores conocidos, 19 fueron clasificados en forma incorrecta como no abusadores. De los 110 no abusadores conocidos, 13 fueron identificados en forma incorrecta como abusadores. Por supuesto, en la mayor parte de las aplicaciones de la CAP, uno podría ignorar si la persona que se está examinando fue realmente un abusador de niños; probablemente esa podría ser la razón para la aplicación de la prueba. Para obtener una comprensión de los errores que pudieran cometerse, observe de nuevo la tabla 1, pero esta vez a lo largo de las filas. Cuando la CAP indica que una persona es abusadora, el hallazgo es correcto el 87.5% de las veces (91 de 104 casos). Cuando la CAP indica que una persona no es abusadora, es correcto el 83.6% de las veces (97 de 116 casos).

Digamos que la PV fue administrada a 100 estudiantes de Introducción a la Psicología y se concluyó que, de hecho, 89 estaban respirando (mientras que 11 se consideró, en base a la PV, que no lo estaban haciendo). ¿Es una buena prueba la PV? Es obvio que no. Debido a que la tasa base es del 100% de la población (viva y con buena salud), en realidad ni siquiera necesitamos una prueba para medir la característica *respirando*. Si por alguna razón necesitáramos tal procedimiento de medición, es probable que no usáramos uno que fuera impreciso en aproximadamente 11% de los casos. Es obvio que una prueba carece de valor si el índice de aciertos es más alto *sin ser*

Tabla 2
Aplicación de la CAP a una población con una
tasa base baja en cuanto a abuso infantil

	Situación real		Totales por filas
	Abusador	No abusador	
<i>Los resultados de la CAP indican:</i>			
Abusador	41	112	153
No abusador	9	838	847
Totales por columnas	50	950	1 000

Sin embargo, en un ambiente de tasa baja el panorama cambia en forma dramática. Para los propósitos de este ejemplo, digamos que el abuso físico infantil ocurre en 5% de la población. En un estudio hipotético, investigamos a 1 000 personas usando la CAP. Debido a que el abuso físico infantil ocurre en 5% de la población, esperaríamos que 50 o más de los investigados fueran abusadores. Y digamos además que al igual que en el estudio de Milner *et al.* (1986), 82.7% de los abusadores y 88.2% de los no abusadores fueron identificados en forma correcta en nuestro estudio (tabla 2). Descendiendo por las columnas en la tabla 2, si 82.7% de los abusadores fueron identificados en forma correcta, 41 serán identificados como abusadores y los 9 restantes como no abusadores. Si la prueba tiene un índice de precisión de 88.2% para los no abusadores, 838 de los no abusadores serán identificados en forma correcta y los restantes 112 serán identificados como abusadores.

Ahora observe de nuevo la tabla 2, esta vez a lo largo de las filas. Si la calificación en la CAP indica que el individuo es un abusador, es probable que sea *incorrecto*. La mayoría de las personas (73.2% de ellas, en este ejemplo) con calificaciones CAP indicando que son abusadoras, en realidad no lo son. Esta imprecisión es el producto de trabajar con una muestra total de tasa base baja. Incluso si la CAP fuera más exacta, debido a que el abuso es un fenómeno de tasa base baja, utilizando los resultados de la prueba para identificar abusadores resultaría que muchos de los identificados como

abusadores habrían sido clasificados en forma errónea. Planteado de otra manera, cuando la población que no comete abusos es mucho mayor que la población que sí los comete, los riesgos son que la mayor parte de los errores se cometerán al clasificar a la población que no comete abusos.

Colóquese en el lugar del juez o del jurado que atiende un caso de abuso físico infantil. Un psicólogo testifica que la CAP, que tiene un índice de precisión de 85-90%, indica que el acusado es un abusador físico. El psicólogo intenta dar una explicación de las tasas base de la población y la posibilidad de error. Aun así, ¿qué se fijaría en su mente acerca del testimonio del psicólogo? Muchas personas razonarían que, si la CAP es correcta en más de 85% de las veces y si el acusado es *identificado* como un abusador de niños, debe haber al menos una probabilidad del 85% de que el acusado sea realmente un abusador de niños. Esta conclusión, como ahora lo sabe, sería incorrecta y podría resultar en que se cometa una injusticia (Melton y Limber, 1989).

Este ejemplo ilustra que el uso proyectado para la prueba por su autor debe ser respetado. Careciendo de cualquier evidencia psicométrica contundente para desviarse del uso para el que la prueba fue designado, tales desviaciones pueden dar como resultado un daño para el examinado. El ejemplo sirve además como un recordatorio de que cuando los datos sobre la precisión y la consistencia de una prueba son recolectados, los datos se recopilan usando una muestra de personas de una población particular. Las conclusiones extraídas de esos datos psicométricos sólo son aplicables a grupos de personas con características generales similares (población equiparable).

Joel Milner, el autor de la CAP, ha exhortado a los usuarios de la prueba a que tomen en cuenta que es inapropiado usar cualquier prueba psicológica aislada como un único criterio de diagnóstico. Milner (1991) continúa recordando a los lectores que “los datos de múltiples fuentes, como varias pruebas, entrevistas con el cliente, entrevistas colaterales, observaciones directas e historias de caso deberían emplearse para tomar decisiones respecto al abuso infantil y su tratamiento” (p. 81).

usada. Una medida del valor de una prueba radica en el grado en el cual su uso mejora el índice de aciertos existente en comparación a cuando ésta no es utilizada.

Como una simple ilustración de la teoría de la decisión aplicada a las pruebas, supóngase que una prueba es administrada a un grupo de 100 solicitantes de empleo y se aplica alguna puntuación límite para distinguir a los solicitantes que serán contratados (solicitantes que se ha juzgado han aprobado la prueba) de los aspirantes cuya solicitud de empleo será rechazada (aspirantes que se ha juzgado que reprobaban la prueba). Y supongamos además que alguna

medida de criterio será aplicada algún tiempo después para asegurarse de que la persona recién contratada fue considerada como con éxito o fracaso en el trabajo. En tal situación, si la prueba es un pronosticador perfecto (si su coeficiente de validez es igual a 1, pueden identificarse dos tipos distintos de resultados: 1) Algunos aspirantes calificarán en o por encima de la puntuación límite en la prueba y serán exitosos en el trabajo, y 2) Algunos aspirantes calificarán por debajo de la puntuación límite y no habrán tenido éxito en el trabajo.

En realidad, pocas pruebas de empleo, si es que alguna, son pronosticadores perfectos con validez de coeficientes igual a 1, en consecuencia, son posibles dos tipos de resultados adicionales: 3) Algunos solicitantes obtendrán calificaciones iguales o mayores de la puntuación límite, serán contratados y fallarán en el trabajo (el criterio de selección) y 4) Algunos solicitantes que hayan obtenido puntuaciones por debajo de la puntuación límite y no fueron contratados podrían haber sido exitosos. Las personas que caigan en la tercera categoría podrían clasificarse como *falsos positivos* y aquellas que caigan en la cuarta podrían clasificarse como *falsos negativos*.

En esta ilustración, la sola lógica nos dice que si la razón de selección es digamos, del 90% (nueve de diez aspirantes serán contratados), es probable que la puntuación límite haya sido establecida menor a que si la razón de selección fuera del 5% (sólo cinco de los 100 aspirantes serán contratados). Además, si la razón de selección es del 90%, es una buena suposición que el número de falsos positivos (personas contratadas que fallarán en la medida criterio) será mayor que en un caso donde la razón de selección sea sólo del 5%. A la inversa, si la razón de selección fuera sólo del 5%, sería una buena suposición pensar que el número de falsos negativos (personas no contratadas que podrían haber tenido éxito en la medida de criterio) será mayor que en el caso donde la razón de selección es del 90%.

La teoría de la decisión proporciona lineamientos para establecer puntuaciones o calificaciones límites óptimas. Al establecer dichas puntuaciones, con frecuencia se toma en cuenta la gravedad relativa de tomar decisiones de selección de falsos positivos o falsos negativos. De esta manera, por ejemplo, sería una política prudente para una oficina de personal dentro de una aerolínea comercial establecer puntuaciones límite en pruebas para pilotos que pudieran resultar en un falso negativo (un piloto que en verdad esté capacitado y sea rechazado) en oposición a una puntuación límite que permita un falso positivo (la contratación de un piloto que en realidad no esté capacitado).

En manos de investigadores altamente capacitados, los principios de la teoría de la decisión aplicados a problemas de utilidad de la prueba han conducido a algunos instructivos e impresionantes hallazgos. Por ejemplo, Schmidt, Hunter, McKenzie y Muldrow (1979) demostraron en dólares y centavos cómo la utilidad de un programa de selección de una compañía (y el coeficiente de validez de las pruebas usadas en ese programa) puede desempeñar una función crítica en la rentabilidad de la compañía. Enfocándose en la población de programadores de computadoras de un empleador, estos investigadores pidieron a los supervisores que estimaran, en dólares, el valor de los buenos programadores, los que están dentro del promedio y los malos programadores. Esta información se usó junto con otra, incluyendo estos hechos: 1) Cada año el empleador contrataba 600 programadores nuevos, 2) El programador promedio permanecía en el empleo durante unos diez años, 3) La Prueba de aptitud del programador que se utilizó como parte del proceso de contratación tenía un coeficiente de validez de .76, 4) Cuesta alrededor de 10 dólares por solicitante aplicar la prueba y 5) La empresa tenía en ese momento, más de 4 000 programadores a su servicio.

Schmidt *et al.* (1979) hicieron cierto número de cálculos usando valores diferentes para algunas de las variables. Por ejemplo, sabiendo que algunas de las pruebas usadas con anterioridad en el proceso de contratación tenían coeficientes de validez que variaban de .00 a .50, cambiaron el valor del coeficiente de validez de la prueba (junto con otros factores aplicados como razones de selección que se habían estado utilizando) y examinaron la eficiencia relativa de las diversas condiciones. Entre sus hallazgos estaba el hecho de que la razón de selección existente y el proceso de selección proporcionaron un gran aumento en la eficiencia sobre una situación anterior (cuando la razón de selección era del 5% y el coeficiente de validez de la prueba usada en la contratación era igual a .50). La ganancia fue igual a casi 6 millones de dólares al año. Multiplicado, digamos, por diez años, eso equivale a 60 millones de dólares. La razón y el proceso de selección existentes proporcionaron una ganancia aún mayor en términos de la eficiencia sobre una situación preexistente

en la que la prueba no tenía validez en absoluto y la razón de selección era de .80. Aquí, en un año, se estimó que la ganancia en la eficiencia era igual a más de 97 millones de dólares.

Por cierto, en el estudio anterior el empleador era el gobierno de Estados Unidos. Hunter y Schmidt (1981) aplicaron el mismo tipo de análisis a la fuerza laboral nacional y utilizaron un argumento convincente con respecto a la relación crucial entre pruebas y procedimientos de medición válidos con la productividad nacional estadounidense. En un estudio subsecuente, Schmidt, Hunter y sus colegas encontraron que mediante el uso de medidas de capacidad cognoscitiva válidas en lugar de procedimientos que no incluyeran pruebas, resultarían en incrementos considerables en la producción laboral o reducciones en los costos de nómina (Schmidt *et al.*, 1986).

Los empleadores son renuentes a usar estrategias basadas en la teoría de la decisión en sus prácticas de contratación debido a la complejidad de su aplicación y al riesgo de enfrentar demandas legales. De esta manera, aunque los enfoques de la teoría de la decisión para la evaluación pueden ser una gran promesa, ésta todavía no se ha cumplido.

SÓLO PIENSE...

¿Qué va a ocurrir en la sociedad como un todo, si la promesa de la teoría de la decisión en la selección de personal debe satisfacerse?

Validez de constructo

La **validez de constructo** es un juicio acerca de lo apropiado de las inferencias realizadas a partir de las puntuaciones o calificaciones obtenidas en la prueba, respecto a posiciones individuales en una variable llamada *constructo*. Un **constructo** es una idea informada, científica, desarrollada como una hipótesis para describir o explicar el comportamiento. *Inteligencia* es un constructo que puede ser citado para describir por qué un estudiante se desempeña bien en la escuela. *Ansiedad* es un constructo al que se puede recurrir para describir por qué un paciente psiquiátrico va y viene por la habitación. Otros ejemplos de constructos son *satisfacción en el trabajo*, *personalidad*, *intolerancia*, *aptitud administrativa*, *depresión*, *motivación*, *autoestima*, *ajuste emocional*, *peligrosidad potencial*, *creatividad* y *comprensión mecánica*, por mencionar unos cuantos.

Los constructos son rasgos inobservables, supuestos (subyacentes) a los que un desarrollador de pruebas puede recurrir para describir el comportamiento de la prueba o el desempeño del criterio evaluado. El investigador que analiza la validez de constructo de una prueba debe formular varias hipótesis acerca del comportamiento esperado en quienes obtienen puntajes altos y en quienes obtienen puntajes bajos en la prueba. Estas hipótesis darán origen a una teoría tentativa sobre la naturaleza del constructo para cuya medición fue diseñada la prueba. Si la prueba es una medida válida del constructo, quienes obtuvieron puntajes altos y quienes obtuvieron puntajes bajos se comportarán como lo predice la teoría. Si quienes obtuvieron puntuaciones altas y los que obtuvieron puntuaciones bajas no se comportan como se ha predicho, el investigador necesitará volver a examinar la naturaleza del constructo o las hipótesis acerca del mismo. Una posible razón de obtener resultados contrarios a los pronosticados por la teoría es que la prueba simplemente no mide ese constructo. Una explicación alternativa podría residir en la teoría que generó las hipótesis acerca del constructo. Sería necesario entonces volver a examinar la teoría.

En algunos casos, la razón de obtener resultados contrarios puede buscarse en los procedimientos estadísticos utilizados o en la manera en que los procedimientos fueron ejecutados. Un procedimiento puede ser más adecuado que otro, dadas las suposiciones particulares. Por tanto, aunque la evidencia confirmatoria contribuye a elaborar un juicio acerca de que una prueba es una medida válida de determinado constructo, la evidencia de lo contrario puede también ser útil.

En forma creciente, la validez de constructo ha sido considerada como el concepto unificador para toda evidencia de la validez (AERA, APA y NCME, 1999). Como observamos al principio, todos los tipos de evidencia de la validez, incluyendo la evidencia a partir del contenido y las variedades de validez de contenido, caen bajo la sombra de la validez de constructo. Veamos los tipos de evidencia que podrían reunirse.

Evidencia de la validez de constructo

Pueden emplearse cierto número de procedimientos para proporcionar diferentes tipos de evidencia de que una prueba tiene validez de constructo. Las diversas técnicas de validación del constructo pueden proporcionar evidencia de que, por ejemplo:

- La prueba es homogénea, midiendo un solo constructo.
- Las calificaciones de la prueba aumentan o disminuyen como una función de la edad o del paso del tiempo o de una manipulación experimental como se predijo de manera teórica.
- Las calificaciones obtenidas en la prueba luego de algún evento o por el simple paso del tiempo (es decir, calificaciones de posprueba) difieren de las calificaciones de preprueba como se predijo de manera teórica.
- Las calificaciones obtenidas en la prueba por personas de grupos distintos varían como fue pronosticado por la teoría.
- Las calificaciones de la prueba se correlacionan con las de otras pruebas de acuerdo con lo que se predeciría a partir de una teoría que cubra la manifestación del constructo en cuestión.

A continuación presentamos una breve exposición de cada tipo de evidencia de validez de constructo y de los procedimientos usados para obtenerla.

Evidencia de homogeneidad En la descripción de una prueba y sus reactivos, la **homogeneidad**, se refiere a cuán uniforme es una prueba para medir un solo concepto. Un creador de pruebas puede incrementar la homogeneidad en varias formas. Considere, por ejemplo, una prueba de rendimiento académico que contenga subpruebas en áreas como matemáticas, ortografía y comprensión de la lectura. Podría usarse la *r* de Pearson para correlacionar las calificaciones promedio de la subprueba con el promedio total de la calificación de la prueba. Las subpruebas que a juicio del elaborador no se correlacionen muy bien con la prueba completa podrían tener que reconstruirse (o eliminarse) por temor a que la prueba en su totalidad, no mida el constructo de rendimiento académico. Las correlaciones entre las calificaciones de las subpruebas y la calificación total por lo general se reportan en el manual técnico como evidencia de homogeneidad.

Una forma en que un creador de pruebas puede mejorar la homogeneidad de una prueba que contiene reactivos que son calificados en forma dicotómica (por ejemplo, verdadero/falso) es eliminando aquellos reactivos que no muestren coeficientes de correlación significativos con las puntuaciones totales de la prueba. Si todos los reactivos muestran correlaciones positivas significativas con las calificaciones totales y quienes obtuvieron calificaciones altas tienden a aprobar cada reactivo más que quienes obtuvieron calificaciones bajas, entonces es probable que cada reactivo esté midiendo el mismo constructo que aquel que mide la prueba en su totalidad. Cada reactivo está contribuyendo a la homogeneidad de la prueba.

La homogeneidad de una prueba en la que los reactivos son calificados en una escala de puntuación múltiple también puede ser mejorada. Por ejemplo, algunos cuestionarios de actitud y opinión requieren que quienes respondan indiquen el nivel de acuerdo con afirmaciones específicas respondiendo, por ejemplo, *firmemente de acuerdo, de acuerdo, en desacuerdo o firmemente en desacuerdo*. A cada respuesta se le asigna luego una calificación numérica y son eliminados los reactivos que no muestran significativos coeficientes de correlación de orden del rango de Spearman. Si todos los reactivos de la prueba muestran correlaciones positivas significativas con las puntuaciones totales, entonces cada reactivo tiene mayor probabilidad de estar midiendo el mismo constructo que la prueba en conjunto (y de ese modo contribuyendo a su homogeneidad). También puede usarse el coeficiente alfa para estimar la homogeneidad de una prueba compuesta de reactivos de opción múltiple (Novick y Lewis, 1967).

Como un estudio de caso que ilustra cómo puede mejorarse la homogeneidad de una prueba, considere la Escala de satisfacción matrimonial (*Marital Satisfaction Scale*, MSS; Roach et al., 1981), diseñada para evaluar varios aspectos de las actitudes de las personas casadas hacia su relación matrimonial, la MSS contiene un número aproximadamente igual de reactivos que expresan sentimientos positivos y negativos respecto al matrimonio. Por ejemplo, *Mi vida parecería vacía sin mi matrimonio* y *Mi matrimonio ha “sofocado” mi personalidad*. En una etapa del desarrollo de esta prueba,

los sujetos indicaron cuánto concordaban o estaban en desacuerdo con los diversos sentimientos en cada uno de los 73 reactivos marcando una escala de cinco puntos que variaba desde *fírmemente de acuerdo hasta fírmemente en desacuerdo*. Basados en las correlaciones entre las puntuaciones de los reactivos y la puntuación total, los diseñadores de la prueba eligieron conservar 48 reactivos con coeficientes de correlación mayores de .50, creando así un instrumento más homogéneo.

En la búsqueda de la homogeneidad de una prueba también se han utilizado procedimientos de análisis de reactivos. Un **procedimiento de análisis de reactivos** se enfoca en la **relación entre las calificaciones de los examinados en reactivos individuales y su calificación en la prueba entera**. Cada reactivo es analizado con respecto a cómo lo respondieron quienes obtuvieron puntuaciones altas en oposición a quienes obtuvieron puntuaciones bajas. Si se trata de una prueba académica y quienes obtuvieron una puntuación alta en la prueba entera, por alguna razón tendieron a equivocarse en algún reactivo en particular y quienes obtuvieron puntuaciones bajas en la prueba en conjunto, tendieron a responder correctamente el mismo reactivo, es obvio que dicho reactivo no es bueno. De hecho, dicho reactivo debería ser eliminado en interés de lograr la homogeneidad de la prueba, entre otras consideraciones. Si la prueba es de, digamos, satisfacción matrimonial y los individuos que **calificaron alto en la prueba en conjunto** responden a **un reactivo en particular en una forma que indicara que no están satisfechos**, mientras que las personas que tienden a no estar satisfechas responden al reactivo de forma que señalen que están satisfechas, entonces de nuevo es probable que el reactivo debería ser eliminado o al menos analizado de nuevo con respecto a la claridad de vocabulario en implicación que maneja.

Aunque la homogeneidad de la prueba es deseable debido a que esto nos asegura que todos los reactivos tienden a medir lo mismo, no es “todo lo que importa” de la validez de constructo. Saber que una prueba es homogénea no contribuye con ninguna información acerca de qué modo el constructo que se está midiendo se relaciona con otros constructos. Por consiguiente, es importante que la evidencia de la homogeneidad de una prueba sea reportada junto con otras evidencias de la validez de constructo.

SÓLO PIENSE...

¿Será posible que una prueba sea demasiado homogénea en el contenido de sus reactivos?

Evidencia de cambios con la edad Es de esperarse que algunos constructos cambien con el tiempo.

El *índice de lectura*, por ejemplo, tiende a incrementarse de manera dramática año con año desde los seis años de edad hasta principios de la adolescencia. Si una calificación de prueba pretende ser una medida de un constructo que pudiera esperarse cambie con el tiempo, también debería mostrar los mismos cambios progresivos con la edad para ser considerada una medida válida del constructo. Esperaríamos, por ejemplo, que si los niños de los grados 6, 7, 8 y 9 se sentaran a responder una prueba de habilidades de lectura para octavo grado, el número total de reactivos calificados como correctos en todos los protocolos de la prueba incrementaría como una función refleja y directa del grado escolar más alto de los evaluados.

Algunos constructos se prestan con más facilidad a predicciones de cambios con el tiempo que otros. De esta manera, aunque podamos predecir, por ejemplo, que las calificaciones de un niño sobredotado en una prueba de habilidades de lectura se incrementarían en el transcurso de los años de educación elemental y secundaria; puede ser que no seamos capaces de predecir con la misma confianza las calificaciones que obtendrá una pareja de recién casados a través de los años en una prueba de satisfacción matrimonial. Este hecho no relega a un constructo como *satisfacción matrimonial* a una categoría menor que la de *capacidad de lectura*. Más bien, sólo significa que las medidas de satisfacción matrimonial pueden ser menos estables con el tiempo o más vulnerables a eventos o situaciones (como las suegras que llegan de visita y se rehúsan a marcharse durante tres meses) que la “capacidad de lectura” en casos específicos. La evidencia de cambio con el tiempo, como la evidencia de homogeneidad de la prueba, no proporciona por sí misma información sobre la forma en que el constructo se relaciona con otros constructos.

Evidencia de cambios mediante preprueba/postprueba La evidencia de que las calificaciones de prueba cambian como resultado de alguna experiencia entre una preprueba y una postprueba puede ser evidencia de la validez de constructo. Algunas de las experiencias intermedias participantes más características responsables de los cambios en las calificaciones de una prueba, son la **educación**

formal, un proceso de terapia o medicación y las experiencias de trabajo. Por supuesto, dependiendo del constructo que se esté midiendo, podría predecirse que casi cualquier experiencia que intervenga en la vida producirá cambios en la calificación desde la preprueba a la postprueba. Leer un libro sugestivo, ver un programa de entrevistas en la televisión, experimentar una cirugía, cumplir una sentencia en prisión o el simple paso del tiempo pueden resultar ser una eficaz variable participante.

Regresando a nuestro ejemplo respecto al uso de la Escala de satisfacción matrimonial, un investigador citado en Roach *et al.* (1981) comparó calificaciones de ese instrumento antes y después de un programa de tratamiento de terapia sexual. Las calificaciones mostraron un cambio significativo entre la preprueba y la postprueba. Una segunda postprueba aplicada ocho semanas después mostró que las puntuaciones se mantenían estables (sugiriendo que el instrumento era confiable) mientras que las medidas de preprueba y postprueba todavía eran diferentemente significativas. Tales cambios en las calificaciones en la dirección pronosticada y después del programa de tratamiento, contribuyeron a la evidencia de la validez de constructo para esta prueba.

SÓLO PIENSE...

¿Habría sido aconsejable aplicar pruebas simultáneas a un grupo equiparado de parejas que no pasaron por terapia sexual, así como pruebas simultáneas a un grupo equiparado de parejas que no consultaron a sus abogados de divorcio? En ambos casos, ¿habría habido alguna razón para esperar cambios significativos en las calificaciones de la prueba de estos dos grupos testigo?

Esperaríamos una disminución en las calificaciones de satisfacción matrimonial si se aplicara una preprueba a una muestra de parejas poco después de que hayan contraído nupcias y se les administrara una postprueba poco después de que los miembros de las parejas hayan consultado a sus respectivos abogados para solicitar el divorcio en algún momento, dentro de los primeros cinco años de matrimonio. El grupo experimental en este estudio consistiría de parejas que hayan consultado a un abogado para el divorcio dentro de los primeros cinco años

de matrimonio. El diseño de esta investigación de preprueba y postprueba debería incluir de manera ideal un grupo testigo para descartar explicaciones alternativas de los hallazgos.

Evidencia de grupos distintos También conocido como el método de grupos contrastados, una forma de proporcionar evidencia de la validez de una prueba es demostrar que las calificaciones en la prueba varían en una forma predecible en función de la pertenencia a algún grupo. El razonamiento aquí es que si una prueba es una medida válida de un constructo en particular, entonces las puntuaciones de prueba de grupos de personas que se supone difieren con respecto a ese constructo deberán tener calificaciones diferentes de manera correspondiente. En este contexto considere una prueba diseñada para medir la depresión en la cual entre más alta sea la calificación más deprimido se supone estará el evaluado. Esperaríamos que los individuos hospitalizados en psiquiatría por depresión debieran obtener calificaciones más altas en esta medida que en una muestra aleatoria de clientes de Wal-Mart.

Ahora, suponga que su intención era proporcionar evidencia de la validez de constructo para la Escala de satisfacción matrimonial al mostrar las diferencias en las calificaciones entre grupos distintos. ¿Cómo podría hacer esto?

Roach *et al.* (1981) procedieron mediante la identificación de dos grupos de parejas de casados, una relativamente satisfecha con su matrimonio, la otra no tan satisfecha. Los grupos fueron identificados por medio de la valoración de otras parejas y de consejeros matrimoniales profesionales. Una prueba *t* de la diferencia entre la calificación media de la prueba fue significativa ($p < .01$) —evidencia que apoya la noción de que la Escala de satisfacción matrimonial es en efecto una medida válida del constructo *satisfacción matrimonial*—.

En épocas pasadas, el método empleado por muchos autores de pruebas para crear grupos distintos era el engaño. Por ejemplo, si se había pronosticado que podría conocerse más sobre el constructo en la prueba en cuestión si el sujeto se sintiera muy ansioso, podría diseñarse una situación experimental para hacerlo sentir demasiado ansioso. De manera virtual, casi cualquier estado emocional que la teoría requiera podría ser inducido mediante un escenario experimental que de manera característica implicara proporcionar al sujeto examinado alguna información falsa. Sin embargo, dadas las restricciones éticas de los psicólogos contemporáneos combinadas con el hecho de que las instituciones académicas y otros patrocinadores de la investigación tienden a no permitir

el engaño en la investigación humana, el método para obtener distintos grupos creándolos mediante la diseminación de información engañosa rara vez es permitido en la actualidad.

Evidencia convergente La evidencia de la validez de constructo de una prueba particular puede converger de diversas fuentes, como otras pruebas o medidas diseñadas para evaluar el mismo constructo (o uno similar). De esta manera, si las calificaciones en la prueba pasan por una validación de constructo tenderán a correlacionarse de forma elevada en la dirección predicha, con las calificaciones de pruebas anteriores, más establecidas y ya validadas, diseñadas para medir el mismo constructo (o uno similar), éste sería un ejemplo de **evidencia convergente**.³

La **evidencia convergente de validez** puede provenir no sólo de correlaciones con pruebas que pretenden medir un constructo idéntico, sino también de **correlaciones con medidas que pretenden medir constructos relacionados**. Considere, por ejemplo, una nueva prueba diseñada para medir el constructo *prueba de ansiedad*. En general, podríamos esperar correlaciones positivas altas entre esta nueva prueba y otras más antiguas y más establecidas medidas de pruebas de ansiedad. Sin embargo, también podríamos esperar correlaciones más moderadas entre esta nueva prueba y medidas de ansiedad general.

Roach *et al.* (1981) proporcionaron evidencia convergente de la validez de constructo de la Escala de satisfacción matrimonial calculando un coeficiente de validez entre las calificaciones de ésta y de la Prueba de adaptación matrimonial (*Marital Adjustment Test*; Locke y Wallace, 1959). El coeficiente de validez de .79 proporcionó evidencia adicional de la validez de constructo del instrumento.

Evidencia discriminante Un coeficiente de validez que muestra poca (es decir, estadísticamente insignificante) relación entre las calificaciones de la prueba y/u otras variables con las que las puntuaciones en la prueba que se está sometiendo a validez de constructo **no debería correlacionarse** desde el punto de vista teórico, proporciona **evidencia discriminante** de la validez de constructo (también conocida como *validez discriminante*). En el curso del desarrollo de la Escala de satisfacción matrimonial (MSS), sus autores correlacionaron calificaciones de este instrumento con calificaciones de la Escala de aceptabilidad social de Marlowe-Crowne (*Marlowe-Crowne Social Desirability Scale*; Crowne y Marlowe, 1964). Roach *et al.* (1981) plantearon la hipótesis de que las correlaciones altas entre estos dos instrumentos sugerirían la probabilidad de que los evaluados no hayan sido completamente honestos al responder los reactivos en la MSS, sino que hayan respondido en formas que fueran socialmente aceptables. Pero la correlación entre la MSS y la medida de aceptabilidad social no demostró ser significativa y quienes elaboraron la prueba concluyeron que podía descartarse la aceptabilidad social como un factor primario para explicar el significado de las puntuaciones de la prueba MSS.

En 1959, una técnica experimental útil para examinar tanto la evidencia de validez convergente como la discriminante fue presentada en las páginas del *Boletín de Psicología* (*Psychological Bulletin*). Este procedimiento bastante técnico, llamado **matriz multirrasgo-multimétodo**, se presenta en nuestro libro de trabajo que acompaña a este libro de texto. Aquí, tan sólo señalaremos que *multirrasgo* significa “dos o más rasgos” y que *multimétodo* significa “dos o más métodos”. La matriz multirrasgo-multimétodo (Campbell y Fiske, 1959) es la matriz o tabla que resulta de correlacionar variables (rasgos) dentro de y entre los métodos. Los valores para cualquier número de rasgos (como agresividad o extroversión) obtenidos por varios métodos (como observación conductual o una prueba de personalidad) están insertos en la tabla y la matriz de correlaciones resultante proporciona una idea respecto a la validez convergente y la validez discriminativa de los métodos usados.⁴

3. Los datos que indican que una prueba mide el mismo constructo que otras pruebas, también son denominados como **evidencia de validez convergente**. Una cuestión que puede plantearse aquí atañe a la **necesidad de una nueva prueba si la actual sólo duplica las ya existentes que miden el mismo constructo**. La **respuesta**, de manera general, es una afirmación de que la **nueva prueba tiene alguna ventaja** sobre la ya establecida. Por ejemplo, la nueva **puede ser más breve y susceptible de ser aplicada en menos tiempo sin una pérdida significativa de confiabilidad o validez**. En un nivel práctico, puede ser menos costosa.

4. Para una interesante aplicación en la vida real de la técnica multirrasgo-multimétodo, véase la revisión de la validez de constructo *consumido*, de Meier (1984). En un estudio subsecuente de la validez de constructo, Meier (1991) utilizó una alternativa a la matriz multirrasgo-multimétodo para analizar otro constructo, la *fatiga ocupacional*.

Análisis factorial La evidencia convergente y discriminativa de la validez de constructo puede obtenerse por medio del uso del análisis factorial. El **análisis factorial** es un término singular, abreviado, que es usado para describir una clase de procedimientos matemáticos diseñados para identificar factores o variables específicas que de manera particular son atributos, características o dimensiones en las que es posible diferir. En la investigación psicométrica, el análisis factorial es empleado con frecuencia como un método de reducción de datos en el que son analizados varios conjuntos de puntuaciones y las correlaciones entre ellas. En dichos estudios, el propósito del análisis factorial puede ser identificar el factor o factores en común entre las puntuaciones de la prueba, en subescalas dentro de una prueba particular, o los factores en común entre puntuaciones obtenidas en una serie de pruebas. En general, el análisis factorial se realiza ya sea en una base exploratoria o en una base confirmatoria. El **análisis factorial exploratorio** implica de manera característica la “estimación o extracción de factores, la decisión de cuántos factores conservar y la rotación de éstos a una orientación interpretable” (Floyd y Widaman, 1995, p. 287). Por el contrario, en el **análisis factorial confirmatorio**, “se plantea la hipótesis de una estructura factorial en forma explícita y se prueba su ajuste con la estructura de la covarianza observada en las variables medidas” (Floyd y Widaman, 1995, p. 287).

Un término comúnmente empleado en el análisis factorial es **factor de carga**, la cual es “una especie de metáfora; se piensa en cada prueba como un vehículo que lleva una cierta cantidad de una o más capacidades” (Tyler, 1965, p. 44). Al cargar un factor en una prueba se transmite información del grado en que el factor determina la puntuación o puntuaciones de la prueba. Una nueva prueba que pretenda medir la bulimia, por ejemplo, puede ser analizada factorialmente con otras medidas conocidas de bulimia, así como con otras clases de medidas (como medidas de inteligencia, autoestima, ansiedad general, anorexia o perfeccionismo). Las cargas factoriales altas en la nueva prueba en un “factor de bulimia” proporcionarían evidencia convergente de la validez de constructo. Las cargas de moderadas a bajas en la nueva prueba respecto a medidas de otros trastornos en la alimentación como la anorexia proporcionarían evidencia discriminativa de la validez de constructo.

El análisis factorial con frecuencia implica procedimientos técnicos tan complejos que pocos investigadores contemporáneos intentarían llevar a cabo uno en forma rutinaria sin la ayuda de un programa prefabricado de computadora. Pero aunque el análisis de los datos reales se ha convertido en trabajo para las computadoras, los humanos todavía tienden a participar ampliamente en la denominación de los factores una vez que la computadora los ha identificado. Así, por ejemplo, supongamos que un análisis factorial identificó un factor común que es medido por dos instrumentos hipotéticos, una “Prueba de bulimia” y una “Prueba de anorexia”. A este factor común tendría que adjudicársele un nombre. Una analista factorial que observara los datos y los reactivos de cada prueba podría bautizar al factor común como un *factor de trastorno alimentario*. Otro analista factorial que examinara exactamente los mismos materiales podría denominar al factor común factor de *preocupación por el peso corporal*. Un tercer analista podría nombrarlo *factor de trastorno de la autopercepción*. ¿Cuál de ellos sería correcto?

Desde una perspectiva estadística, simplemente es imposible decir que el factor común debe nombrarse. La denominación de factores que surgen de un análisis factorial tiene más que ver con el conocimiento, el juicio y la abstracción verbal que con la destreza matemática. No hay reglas específicas para designar factores. Los analistas factoriales ejercen su propio juicio concerniente a qué nombre del factor comunica mejor su significado. Además, incluso los criterios usados para identificar un factor común, así como cuestiones técnicas relacionadas, pueden ser materia de debate, si no es que de una controversia acalorada (véase, por ejemplo, Bartholomew, 1996a, 1996b; Maraun, 1996a, 1996b, 1996c; McDonald, 1996a, 1996b; Mulaik, 1996a, 1996b; Rozeboom, 1996a, 1996b; Schönemann, 1996a, 1996b; Steiger, 1996a, 1996b).

El análisis factorial es un tema rico en complejidad técnica. Sus usos y aplicaciones pueden variar como una función de los objetivos de investigación, así como de la naturaleza de las pruebas y los constructos bajo estudio. El análisis factorial es el tema de nuestro *Close-up* en el capítulo 9. Si usted está interesado en aprender más sobre las ventajas (y trampas) del análisis factorial se le aconseja visitar el sitio web correspondiente a este libro de texto y consultar alguno de los muchos libros instructivos (Comrey, 1992) y artículos (Floyd y Widaman, 1995; Gorsuch, 1997; Panter *et al.*, 1997) sobre el tema.

Validez, sesgo e imparcialidad de la prueba

A los ojos de muchos legos, las cuestiones concernientes a la validez de una prueba están vinculadas de manera íntima con cuestiones relacionadas al uso válido de la prueba y al problema del sesgo y la imparcialidad. Apresurémonos a señalar que la validez, la imparcialidad en el uso de una prueba y el sesgo de ésta son tres asuntos separados. Por ejemplo, es posible que una prueba válida sea usada en forma parcial o imparcial.

SÓLO PIENSE...

¿Cuál sería un ejemplo de una prueba válida utilizada de manera parcial?

Sesgo de la prueba

Para el público en general, el término sesgo aplicado a las pruebas psicológicas o educacionales, puede recurrir a muchos significados que tienen que ver con un prejuicio o trato preferencial (Brown *et al.*, 1999). Para los jueces federales, el término *sesgo* en tanto está relacionado con los reactivos en las pruebas de inteligencia para niños, es sinónimo de “muy difícil para un grupo en comparación con otro” (Sattler, 1991). Para los psicómetras, **sesgo es un factor inherente a una prueba que de manera sistemática impide la medición absolutamente precisa e imparcial.**

Los psicómetras han desarrollado un medio técnico para identificar y remediar el sesgo, cuando menos en el sentido matemático. Como simple ilustración, considere una prueba que llamaremos “prueba de lanzamiento de una moneda” (PLM). El “equipo” necesario para efectuar esta prueba sería una moneda con dos caras. Un lado tiene la imagen de un perfil (“caras”) y el otro lado no (“cruces”). La PLM se consideraría sesgada si el instrumento (la moneda) estuviera cargada de modo que las caras o cruces aparecieran con más frecuencia de lo que ocurriría sólo por azar. Si la prueba en cuestión fuera de inteligencia, ésta se consideraría sesgada si estuviera elaborada de modo que las personas que tuvieran ojos cafés obtuvieran de manera consistente y sistemática calificaciones más altas que las de ojos verdes —asumiendo, por supuesto, que en realidad las personas con ojos cafés por lo general no son más inteligentes que las de ojos verdes—. **Sistemático es una palabra clave en nuestra definición de sesgo de la prueba.** Con anterioridad hemos visto fuentes de *variación aleatoria* o fortuita en las calificaciones de la prueba. **El sesgo implica una variación sistemática.**

Otra ilustración: Supongamos que necesitamos contratar 50 secretarías, por lo que colocamos un anuncio en un periódico. En respuesta al anuncio, se presentan 200 personas, incluyendo 100 que resultan tener ojos cafés y otras 100 con ojos verdes. A cada una de las 200 aspirantes se le aplica de manera individual una prueba hipotética que llamaremos “Prueba de habilidades secretariales” (PHS). La lógica nos dice que es probable que el color de ojos no sea una variable relevante con respecto al desempeño de las labores de una secretaria, por consiguiente, no tendríamos razón para creer que las personas con ojos verdes serán mejores secretarías que las de ojos cafés o viceversa. Podríamos esperar de manera razonable que después de que las pruebas hayan sido calificadas y completado el proceso de selección, habrá sido contratada una cantidad aproximadamente igual de personas con ojos cafés y de personas con ojos verdes (es decir, aproximadamente 25 con ojos cafés y 25 con ojos verdes). Pero, ¿qué tal si resulta que se contrató a 48 personas con ojos verdes y sólo a dos con ojos cafés? ¿Sería esto evidencia de que la PHS es una **prueba sesgada?**

Aunque la respuesta a esta pregunta parece simple ante los hechos —“¡Sí, la prueba está sesgada pues se deberían haber contratado 25 y 25!”— una respuesta en verdad responsable a esta pregunta implicaría una localización estadística de problemas en la prueba y en el procedimiento de selección entero (véase Berk, 1982). Para comenzar, tendrían que haberse examinado las tres características de las líneas de regresión (figura 6-4) usadas para predecir el éxito en el criterio: **1) la pendiente, 2) la intersección, 3) el error de estimación.** Y debido a que estos tres factores de regresión son funciones de otras dos estadísticas (el coeficiente de validez y el de confiabilidad tanto para la prueba como para el criterio) que podrían variar respecto a los dos grupos en cuestión, **un total de cinco características deben ser analizadas desde el punto de vista estadístico.** Una prueba de significación podría indicar que nuestros grupos de ojos cafés y ojos verdes serían iguales o diferentes con respecto a cualquiera de estas cinco características. Esta elección binaria (es decir, igual o diferente) elevada a la quinta potencia (lo que significa que, de manera concebi-

ble, hay cinco formas en las que podrían diferir los dos grupos) significa que la localización del problema general implicaría el examen de un total de 32 ($2^5 = 32$) formas posibles en que podría encontrarse que la prueba está sesgada.

Si, por ejemplo, de manera sistemática una prueba predice por debajo o por arriba el nivel de desempeño de los miembros de un grupo particular (como las personas con ojos verdes) respecto a un criterio (como una estimación de supervisión), esto mostraría lo que se conoce como *sesgo de intersección*. El **sesgo de intersección** es un término derivado del punto donde la línea de regresión se cruza con el eje Y. Si de manera sistemática una prueba produce coeficientes de validez significativamente diferentes para miembros de grupos diferentes, existe lo que se conoce como **sesgo de la pendiente**, llamado así debido a que la pendiente de la línea de regresión de un grupo es diferente en una forma estadísticamente significativa a la línea de regresión de otro grupo.

Stone (1992) identificó sesgos de pendiente y de intersección en la Escala de capacidades diferenciales (*Differential Abilities Scale*, DAS; Elliot, 1990a, 1990b). La DAS está diseñada para medir la capacidad y el rendimiento relacionados con la escolaridad de niños y adolescentes. La prueba produce una calificación de la Capacidad Conceptual General (*General Conceptual Ability*), la cual es una medida de capacidad general, y calificaciones de rendimiento en una diversidad de áreas, incluyendo Habilidades básicas numéricas (*Basic Number Skills*) y Lectura de Palabras (*Word Reading*). Stone (1992) calculó líneas de regresión para dos grupos raciales: estadounidenses blancos y asiático-estadounidenses. Cuando se predijeron las calificaciones de Lectura de palabras a partir de la Capacidad conceptual general, las líneas de regresión para las dos razas tenían distintas pendientes, lo que indica sesgo de pendiente. Cuando se predijeron las Habilidades básicas numéricas a partir de la Capacidad conceptual general, las líneas de regresión para las dos razas cruzaron el eje Y en diferentes lugares, lo que indica sesgo de intersección.

La presencia de sesgo en la pendiente y en la intersección en la DAS tiene implicaciones prácticas importantes para los examinados. Veremos de manera específica el sesgo en la pendiente que encontró Stone con relación a la subprueba de rendimiento Lectura de palabras. Para entender el impacto de este sesgo, dibuje una gráfica, usando la figura 6-4 como guía. Coloque la Capacidad conceptual general en el eje X y la Lectura de palabras en el eje Y. Luego trace dos líneas de regresión con pendientes diferentes. Ambas líneas deberán tener una pendiente positiva y deberán cruzar el eje Y en el mismo lugar. La línea con la pendiente más pronunciada representa a los niños estadounidenses de origen asiático y la otra línea representa a los niños blancos.

En su dibujo, examine la posición relativa de las líneas de regresión en cada gráfica para los valores del eje X que están en el rango intermedio, representando calificaciones realistas de la prueba. Deberá encontrar que la línea de regresión para los niños estadounidenses de origen asiático es mayor que la línea de regresión para los niños blancos. Esto significa que, por lo general, los niños estadounidenses de origen asiático, en un nivel particular de rendimiento, tienen puntuaciones generales de capacidad menores al rendimiento de los estudiantes blancos en el mismo nivel. Para ver cómo es esto, seleccione un punto relativamente alto en el eje Y, representando un nivel alto de rendimiento. Luego trace una línea horizontal a través de las dos líneas de regresión y dibuje una línea vertical hasta el eje X desde el punto donde cruzó cada línea de regresión (como se hizo en la figura 6-4). Los puntos resultantes en el eje X representan los niveles de capacidad promedio para el nivel de rendimiento en lectura, seleccionado en el eje Y. Debió cruzar primero la línea para los estudiantes estadounidenses de origen asiático, lo que significaría que dichos estudiantes tienen un valor de X más bajo, lo que corresponde a un nivel de capacidad inferior al de los estudiantes blancos en el mismo nivel de desempeño.

Ahora supongamos que los maestros seleccionaron a algunos estudiantes para un programa de individuos talentosos en base a su rendimiento en el salón de clases. Sin embargo, el ingreso a dicho programa se basa en la capacidad. Éste es el enfoque adoptado en muchos programas para estudiantes sobresalientes. A los estudiantes nominados se les aplica una prueba de capacidad y son admitidos aquellos que están por encima de una calificación específica. El ejercicio que acaba de completar indica que un porcentaje menor de estudiantes de origen asiático seleccionados sería aceptado dentro del programa. Los estudiantes de origen asiático bien podrían sentirse discriminados. Lo estaban haciendo tan bien en el salón de clases como sus contrapartes blancos, pero les fue negado un lugar en un programa especial en el que podrían haber recibido atención adicional y realizado un trabajo más desafiante. Observe además que, debido a la naturaleza no paralela de las




Figura 6-4
Calificaciones PHS y estimaciones de un supervisor para dos grupos

Observe los distintos puntos de intersección de Y que corresponden a una calificación PHS de 50 para un grupo de examinados con ojos color verde y para otro grupo con examinados con ojos color café. Si la PHS fuese una prueba sin sesgo, cualquier calificación dada en ella correspondería exactamente al mismo criterio de calificación para los dos grupos.

líneas, esto se convertirá en un problema mayor en niveles más altos de rendimiento. Éste es sólo uno de varios resultados de sesgos de pendiente e intersección analizados por Stone (1992). Remitimos a los estudiantes interesados al artículo original para una exposición más detallada.

Una razón que se ha encontrado para explicar el porqué algunas pruebas están sesgadas tiene más que ver con el diseño del estudio de investigación que con el de la prueba; si hay muy pocos individuos que responden la prueba en uno de los grupos (como en el caso del, literalmente, grupo minoritario), este problema metodológico hará parecer como si la prueba estuviera sesgada cuando en realidad puede no estarlo. Una situación en la que una prueba puede considerarse sesgada de manera justificada es aquella en la que alguna porción de su varianza surge de algún factor o factores irrelevantes para el desempeño en la medida de criterio; como consecuencia, un grupo de individuos que respondan la prueba de manera sistemática se desempeñarán de forma diferente del otro. La prevención durante el desarrollo de la prueba es la mejor cura para el sesgo, aunque un procedimiento llamado transformaciones estimadas de calificación verdadera representa uno de muchos remedios subsecuentes disponibles (Mueller, 1949; véase también Reynolds y Brown, 1984).⁵

Error de estimación Una estimación es un juicio numérico o verbal (o ambos) que coloca a una persona o a un atributo a lo largo de un continuo identificado por una escala de descriptores numéricos o de palabras, conocido como **escala de estimación**. Planteado en forma simple, un **error de estimación** es un juicio resultante del mal uso intencional o no intencionado de una escala de estimación. Así, por ejemplo, un **error de lenidad** (también conocido como **error de generosidad**) es, como su nombre lo implica, un error de estimación que surge de la tendencia por parte del evaluador a ser benevolente al calificar, marcar y/o graduar. De su propia experiencia durante la inscripción a los cursos, usted podría identificar o puede ser que se haya percatado de que una sección de un curso o materia en particular se llenará muy rápido si ésta es enseñada por un profesor con una reputación de cometer errores benevolentes al establecer las calificaciones de fin de semestre.

5. Para evitar que usted piense que hay algo que no está del todo correcto respecto a la transformación de los datos bajo tales circunstancias, agregaríamos que aun cuando transformación es sinónimo de cambio, el cambio al que aquí nos referimos es sólo de forma, no de significado. Los datos pueden ser transformados para exponerlos en una forma más útil, no para cambiar su significado.

En el otro extremo se encuentra el **error de severidad**. Los críticos de cine que critican duramente casi todo lo que revisan pueden ser culpables de errores de severidad. Por supuesto, esto sólo es verdad si ellos han revisado una amplia gama de películas que podrían ser consideradas, de manera consensual, como buenas y malas.

Otro tipo de error podría denominarse **error de tendencia central**. Aquí, el evaluador, por cualquier razón, muestra una renuencia general y sistemática a hacer evaluaciones en el extremo positivo o negativo. En consecuencia, todas las evaluaciones tienden a agruparse en medio de un continuo de estimación.

Una forma de superar lo que podría llamarse **restricción del rango de errores de estimación** (errores de tendencia central, de lenidad y de severidad) es usar **categorías**, un procedimiento que requiere que quien lleve a cabo la estimación mida a los individuos comparándolos entre sí en lugar de hacerlo contra una escala absoluta. Mediante el uso de categorías en lugar de estimaciones, el evaluador (ahora categorizador) está obligado a seleccionar la primera, la segunda o la tercera opción y así sucesivamente.

SÓLO PIENSE...

¿Cuál factor cree usted que explicaría el fenómeno de los evaluadores cuyas calificaciones casi siempre parecen ser víctimas del error de tendencia central?

El **efecto de halo** describe el hecho de que, para algunos evaluadores, algunos de los evaluados no pueden equivocarse. De manera más específica, un efecto de halo también puede ser definido como una tendencia a dar a una persona evaluada una estimación superior de la que merece en forma objetiva debido a la falla del evaluador para discriminar entre aspectos distintos desde el punto de vista conceptual y potencialmente independientes del comportamiento del evaluado. Sólo por dar un ejemplo —y no del momento pues pensamos que incluso está dentro de lo posible— supongamos que Britney Spears consintió en escribir y pronunciar un discurso sobre el análisis de multivariedad. Es probable que su discurso obtendría evaluaciones más altas si fuese pronunciado ante la sección fundadora del Club de fans de Britney Spears que si fuese pronunciado y evaluado por los miembros de, digamos, la Real Sociedad de Estadística. Esto sería verdad aun en la circunstancia altamente improbable de que los integrantes de cada grupo fueran igual de entendidos en lo que se refiere al análisis de multivariedad. Esperaríamos que el efecto de halo estuviera operando en todo su esplendor mientras Spears habla ante su club de admiradores.

Los datos de criterio también pueden ser influidos por el conocimiento del evaluador respecto a la raza o género del evaluado (Landy y Farr, 1980). Se ha demostrado que los hombres reciben evaluaciones más favorables que las mujeres en ocupaciones consideradas masculinas por tradición. Excepto en situaciones de integración muy alta, los evaluados tienden a recibir calificaciones más elevadas por parte de evaluadores de la misma raza (Landy y Farr, 1980). Regresando a nuestra situación de la PHS, un evaluador puede haber tenido con anterioridad magníficas —o angustiosas— experiencias en lo particular con personas de ojos verdes (o cafés) y llevar a cabo evaluaciones extraordinariamente altas (o bajas) sobre esa base irracional.

Los programas de capacitación para familiarizar a los evaluadores con errores de evaluación comunes y fuentes de prejuicio del evaluador han mostrado ser promisorios para reducir los errores e incrementar las medidas de confiabilidad y validez. Conferencias, representación de papeles, discusiones, la observación de uno mismo en grabaciones de video y simulaciones computarizadas de diferentes situaciones son algunas de las muchas técnicas que podrían ser utilizadas en dichos programas de capacitación. Volveremos al tema de la evaluación y el error al evaluar en nuestro tema de la evaluación de la personalidad dentro del capítulo 11. Ahora abordaremos cuestiones relacionadas con la imparcialidad de la prueba.

Imparcialidad de las pruebas

En contraste con las cuestiones de sesgo en las pruebas, las cuales pueden ser consideradas como problemas estadísticos técnicamente complejos, las cuestiones de imparcialidad tienden a estar más arraigadas en temas complicados que implican valores (Halpern, 2000). De esta manera, mientras que las cuestiones del sesgo de la prueba algunas veces pueden responderse con precisión y determinación matemática, las cuestiones de la imparcialidad pueden intentar ser resueltas por infinidad de personas bien intencionadas que sostienen puntos de vista contrarios. Con

esa advertencia en mente y desde luego con excepciones en perspectiva, definiremos **imparcialidad en un contexto psicométrico** como el **grado en el cual una prueba es utilizada de manera imparcial, justa y equitativa**.⁶

Algunos usos de las pruebas son imparciales de manera evidente, según el juicio de cualquier persona razonable. Durante la guerra fría, el gobierno de lo que entonces era conocida como la Unión Soviética, utilizó pruebas psiquiátricas para suprimir a los disidentes políticos. Muchas personas fueron encarceladas o confinadas en alguna institución por expresar su oposición al gobierno. Aparte de tales usos evidentemente imparciales de las pruebas, lo que constituye un uso justo o injusto de las pruebas es un tema que se deja a las partes encargadas de la evaluación. **De manera ideal, el creador de la prueba se esfuerza porque ésta sea justa durante el proceso de desarrollo y en el manual técnico de la misma, así como en el apego a sus principios.** El usuario de la prueba se esfuerza por la parcialidad en la manera en que la prueba es usada en la práctica. La sociedad se esfuerza en la imparcialidad a través de la legislación del uso de la prueba, las decisiones judiciales y los ordenamientos administrativos.

La imparcialidad como es aplicada a las pruebas es un tema complicado. Sin embargo, es posible examinar algunos malentendidos bastante comunes respecto a lo que en ocasiones es percibido como pruebas parciales o incluso sesgadas. **Algunas pruebas, por ejemplo, han sido denominadas “injustas” debido a que discriminan entre grupos de personas.**⁷ El razonamiento aquí sería algo como: **“Aunque existen diferencias individuales, es una verdad obvia que todas las personas son creadas iguales. Por consiguiente, cualesquiera diferencia encontrada entre grupos de personas, en cualquier rasgo psicológico, debe ser artífice de una prueba parcial o sesgada”.** Debido a **que esta creencia está arraigada en la fe, en oposición a la evidencia científica —de hecho, desafía la evidencia científica— es casi imposible refutarla.**

A todos nos gustaría creer que las personas son iguales en todos sentidos y que todas son capaces de elevarse a las mismas alturas si se les da una oportunidad igual. **Un punto de vista más realista consistiría en que cada persona es capaz de alcanzar un potencial personal.** Debido a que las personas difieren en forma tan obvia con respecto a los rasgos físicos, a uno se le dificultaría creer que las diferencias psicológicas que existen entre los individuos —y grupos de individuos— son tan sólo una función de pruebas inadecuadas. Una vez más, **aunque una prueba no sea de manera inherente parcial o sesgada simplemente porque es una herramienta con la cual se descubren las diferencias entre los grupos, el uso de los datos de la prueba, como el uso de cualesquiera datos, puede ser parcial.**

Otro malentendido de lo que constituye una prueba parcial o sesgada es que es injusto aplicar una prueba estandarizada a una población particular que no incluya a miembros de esa población en la muestra de estandarización. De hecho, la prueba bien puede estar sesgada, pero eso debe ser determinado por medios estadísticos u otros medios. **El mero hecho de no haber incluido a ningún miembro de un grupo particular en la muestra de estandarización, por sí solo no invalida la prueba para su uso con ese grupo.**

Una fuente final de malentendidos es el complejo problema de remediar situaciones en las cuales se ha encontrado que se lleva a cabo un empleo parcial o sesgado de una prueba. En el área de selección de personal, puestos en universidades y escuelas profesionales y similares, se ha intentado aplicar un cierto número de medidas preventivas y remedios diferentes. Mientras lee acerca de las herramientas usadas en estos intentos en la sección *psicometría cotidiana* de este capítulo, elabore sus propias opiniones respecto a lo que constituye un uso imparcial de las pruebas para contratación y de otros tipos en un proceso de selección.

6. En una nota un poco más técnica, Ghiselli *et al.* (1981, p. 320) observaron que “la imparcialidad se refiere a si una diferencia en el procedimiento para predecir calificaciones entre dos grupos representa una distinción útil para la sociedad, en relación con una decisión que deba tomarse o bien si tal diferencia representa un sesgo que es irrelevante para los objetivos en mente”. Para más lineamientos prácticos respecto a la imparcialidad, al menos como están estructurados por los cuerpos legislativos y los tribunales, véase Russell (1984).

7. El verbo discriminar es usado aquí en el sentido psicométrico, que significa, *mostrar una diferencia estadísticamente significativa entre individuos o grupos con respecto a la medición*. Esta gran diferencia entre esta definición científico-estadística y otras definiciones coloquiales (como *tratar en forma diferente y/o parcial debido a la pertenencia a un grupo*) debe ser tenida en cuenta con mucha firmeza en las exposiciones de sesgo e imparcialidad.

Ajuste de las calificaciones de pruebas de acuerdo a la pertenencia a un grupo: ¿imparcialidad en la prueba o juego sucio?

Cualquier prueba, sin importar su solidez psicométrica, puede ser usada, en forma deliberada o sin advertirlo, de manera que tenga un impacto adverso en uno u otro grupo. Si se encuentra que existe dicho impacto adverso y si la política social demanda algún remedio o un programa de acción afirmativa, entonces los psicómetras tienen diversas técnicas a su disposición para hacer un cambio. La siguiente tabla enumera algunas de estas técnicas.

Aunque los psicómetras tienen las herramientas a su disposición para instituir políticas especiales por medio de manipulaciones en la elaboración, calificación e interpretación de una prueba, hay pocos lineamientos claros en esta controvertida área (Brown, 1994; Gottfredson, 1994, 2000; Sackett y Wilk, 1994). Las aguas son turbias aún más por el hecho de que algunos de los lineamientos parecen tener implicaciones contradictorias. Por ejemplo, aunque la preferencia racial en la selección de empleados (impacto dispar) es ilegal, el uso de procedimientos de selección válidos y sin sesgo garantiza de manera virtual el impacto dispar. Esta situación cambiará sólo cuando se minimicen las disparidades raciales en las habilidades y capacidades relacionadas con el trabajo (Gottfredson, 1994).

En 1991, el Congreso promulgó una legislación que negaba de manera efectiva a los patrones o empleadores, la posibilidad de ajustar las puntuaciones de las pruebas de los examinados con el propósito de tomar decisiones de contratación o promoción. La Sección 106 de la Ley de Derechos Civiles de 1991 hizo ilegal para los empleadores “en relación con la selección o envío de aspirantes o candidatos para empleo o promoción, ajustar las calificaciones, usar límites diferentes o alterar de alguna u otra manera los resultados de las pruebas relacionadas con la contratación en base a la raza, color, religión, género u origen nacional”.

Esa ley estimuló la preocupación de parte de muchos psicólogos que creyeron que esto podría afectar en forma adversa a varios grupos sociales y que también pudiera revertir las ganancias sociales que se habían logrado. Brown (1994, p. 927) pronosticó que “las ramificaciones de la ley tienen un alcance mayor del que imaginó el Congreso cuando consideró la enmienda y podría significar que muchas pruebas de personalidad y de capacidad física que dependen de la calificación separada para hombres y mujeres sean declaradas ilegales en la selección de personal”. Los argumentos a favor del ajuste de la puntuación de la prueba relacionada con el grupo han sido apoyados con fundamentos filosóficos al igual que técnicos. Desde una perspectiva filosófica, un incremento en la representación de las minorías es valuada desde el punto de vista social hasta el punto en que se garantiza la preferencia por la minoría en las puntuaciones de la prueba. En el mismo tenor, la preferencia por la minoría es vista como un remedio a errores sociales pasados y como una garantía contemporánea

de representación proporcional en los lugares de trabajo entre varios grupos. Desde una perspectiva más técnica, se afirma que algunas pruebas requieren ajustar las puntuaciones debido a que: 1) las pruebas están sesgadas y una puntuación determinada en ellas no necesariamente tiene el mismo significado para todos los que la responden y/o 2) “una forma particular de usar una prueba está en desigualdad con una posición adoptada respecto a lo que constituye un uso imparcial” (Sackett y Wilk, 1994, p. 931).

En contraste con los defensores del ajuste de las puntuaciones de pruebas se encuentran aquellos que ven dichos ajustes como parte de una agenda social para el tratamiento preferencial de ciertos grupos. Estos oponentes del ajuste de las puntuaciones de pruebas rechazan la subordinación del esfuerzo y las capacidades individuales a la pertenencia a un grupo como criterios en la asignación de calificaciones de pruebas (Gottfredson, 1988, 2000). Hunter y Schmidt (1976, p. 1069) describieron las consecuencias desafortunadas para todas las partes involucradas en una situación de selección en una universidad en la que fueron aceptados aspirantes de bajo riesgo con base en ajustes de calificaciones o cuotas. En lo que se refiere al escenario del empleo, Hunter y Schmidt (1976) describieron un caso en el que los estándares para el ingreso fueron reducidos a fin de contratar más miembros de un grupo particular. Sin embargo, muchos de estos recién contratados no aprobaron las pruebas de ascenso, y como resultado, la compañía fue demandada por una práctica de ascenso discriminatorio. No obstante, otra consideración tiene que ver con los sentimientos de “minorías solicitantes que fueron seleccionadas bajo un sistema de cuota pero que también tendrían que haber sido seleccionadas bajo un individualismo incompetente y por consiguiente deben de pagar el precio, con una disminución del prestigio y de la autoestima” (Jensen, 1980, p. 398).

Se han presentado y debatido en la literatura erudita cierto número de modelos psicométricos de imparcialidad en las pruebas (Hunter y Schmidt, 1976; Petersen y Novick, 1976; Schmidt y Hunter, 1974; Thorndike, 1971). A pesar de una riqueza de investigaciones y debates, continúa una antigua interrogante en el campo de la psicología laboral: “¿Cómo pueden reducirse las diferencias de grupos en las pruebas de capacidad cognoscitiva mientras se conservan los actuales altos niveles de confiabilidad y de validez relacionada con el criterio?”

De acuerdo con Gottfredson (1994), es probable que la respuesta no provenga de la investigación relacionada con la medición debido a que las diferencias en las calificaciones en muchas de las pruebas en cuestión surgen principalmente de las diferencias en las capacidades relacionadas con el trabajo. Para Gottfredson (1994, p. 963), “a la larga, la mayor contribución que

Técnicas psicométricas para prevenir o remediar el impacto adverso y/o instituir un programa de acción afirmativa

Algunas de estas técnicas pueden ser preventivas si son empleadas en el proceso del desarrollo de la prueba y otras pueden emplearse con pruebas ya establecidas. Algunas de estas técnicas implican la manipulación directa de la calificación; otras, como hacer bandas, no. La preparación de este cuadro se benefició de Sackett y Wilk (1994) y su trabajo deberá consultarse para una consideración más detallada de los complejos temas implicados.

Técnica	Descripción
Adhesión de puntos	Se agrega un número constante de puntos a la calificación de la prueba de los miembros de un grupo en particular. El propósito de la adhesión de puntos es reducir o eliminar diferencias observadas entre grupos.
Calificación diferencial de reactivos	Esta técnica incorpora información de la pertenencia a un grupo, no para ajustar una puntuación cruda en una prueba, sino para derivar la calificación en primer lugar. La aplicación de la técnica puede implicar la calificación de algunos reactivos de prueba para miembros de un grupo, pero no para calificar los mismos reactivos para miembros de otro grupo. Esta técnica también se conoce como <i>codificación empírica por grupo</i> .
Eliminación de reactivos en base al funcionamiento diferencial de los reactivos	Este procedimiento implica eliminar de una prueba cualesquier reactivos que se perciba que favorecen de manera inapropiada el desempeño en la prueba de un grupo sobre otro. De manera ideal, el intento de eliminar ciertos reactivos de la prueba no es para hacerla más fácil para cualquier grupo, sino tan sólo más imparcial. Sackett y Wilk (1994) lo plantearon de esta manera: "De modo conceptual, en lugar de preguntar '¿Este reactivo es más difícil para los miembros del grupo X que para los del grupo Y?', esta aproximación pregunta '¿Este reactivo es más difícil para los miembros del grupo X con una calificación Z verdadera que para los miembros del grupo Y con una calificación Z verdadera?'"
Límites diferenciales	Se establecen límites diferentes para miembros de grupos diferentes. Por ejemplo, una calificación aprobatoria para los miembros de un grupo es 65, mientras que una puntuación aprobatoria para los miembros de otro grupo es 70. Como con la adhesión de puntos, el propósito de los límites diferenciales es reducir o eliminar las diferencias observadas entre grupos.
Listas separadas	Se establecen listas de calificaciones diferentes para los examinados de acuerdo a sus grupos de pertenencia. Para cada lista, el desempeño de los evaluados en la prueba es jerarquizado de manera descendente. Las personas que utilizarán las calificaciones de la prueba con propósitos de selección pueden alternar partes de las diferentes listas. Dependiendo de factores como las reglas de asignación en efecto y la equivalencia de la desviación estándar dentro de los grupos, la técnica de las listas separadas puede producir efectos similares a los de otras técnicas, como la adhesión de puntos y los límites diferenciales. En la práctica, las listas separadas son populares en los programas de acción afirmativa donde la intención es la sobreselección de grupos excluidos con anterioridad.
Normalización dentro de un grupo	Usada como un remedio para el impacto adverso si los miembros de diferentes grupos tienden a desempeñarse en forma diferencial en una prueba particular, la normalización dentro de un grupo implica la conversión de todas las calificaciones crudas en percentiles o puntuaciones estándar basadas en el desempeño que se tuvo en la prueba en relación al grupo de pertenencia. En esencia, un solo examinando es comparado únicamente con otros miembros de su propio grupo. Cuando la raza es el criterio primario de la pertenencia a un grupo y se establecen normas separadas por raza, esta técnica se conoce como <i>normalización por raza</i> .
Hacer bandas	El efecto de hacer bandas de las calificaciones de una prueba es hacer equivalentes todas las calificaciones que caen dentro de un rango o banda particular. Por ejemplo, miles de puntuaciones crudas en una prueba pueden transformarse a un <i>stanine</i> teniendo un valor de 1 a 9. Todas las calificaciones que caen dentro de cada uno de los límites del <i>stanine</i> serán tratadas por el usuario de la prueba ya sea como equivalentes o sujetas a algunos criterios de selección adicionales. Una <i>banda deslizando</i> (Cascio <i>et al.</i> , 1991) es un procedimiento modificado para hacer bandas en el cual, una banda es ajustada ("deslizada") para permitir la selección de más miembros de algún otro grupo en los que serían seleccionados de otras formas.
Políticas de preferencia	En interés de la acción afirmativa, la discriminación inversa o alguna otra política que se considere vaya en vías del interés de la sociedad en su conjunto, un administrador de pruebas podría establecer una política de preferencia basada en la pertenencia a un grupo. Por ejemplo, si un departamento municipal de bomberos busca incrementar la representación del personal femenino en sus filas, podría instituir una política relacionada con la prueba diseñada para hacer esto. Una disposición clave en esta política podría ser que cuando un hombre y una mujer obtengan calificaciones iguales en la prueba utilizada en la contratación, se contratará a la mujer.

(continúa)

Ajuste de las calificaciones de pruebas de acuerdo a la pertenencia a un grupo: ¿imparcialidad en la prueba o juego sucio? (continuación)

pueden hacer los psicólogos laborales tal vez sea insistir de manera colectiva y franca que sus herramientas de medición no son la causa ni el remedio para las diferencias raciales en las habilidades laborales y las desigualdades consecuentes en el empleo”.

Más allá del lugar de trabajo y de la psicología laboral, ¿Qué papel, si hubiera alguno, deberían jugar las mediciones para promover la diversidad? Y como Haidt *et al.* (2003) reflexionaron, hay

algunas variedades de diversidad, unas se perciben como más valiosas que otras. ¿Necesitamos desarrollar por tanto, medidas más específicas diseñadas, por ejemplo, para desalentar la “diversidad moral” mientras se estimula la “diversidad demográfica”? Este tipo de preguntas tienen implicaciones en una cierto número de áreas que van desde la admisión académica hasta las de políticas de inmigración.

SÓLO PIENSE...

¿Cuál es su opinión acerca del uso de varios procedimientos para ajustar las calificaciones de una prueba en base a la pertenencia a un grupo? ¿Sería mejor dejar estos problemas a los expertos en medición?

Si en una prueba válida y confiable con propósitos de selección se encontraran diferencias de desempeño entre grupos identificados de personas, algunas preguntas difíciles podrían estar relacionadas con el hecho de si se debe continuar empleando la prueba. ¿El problema se debe a alguna deficiencia técnica en la prueba o en realidad la prueba es demasiado buena para identificar a personas con diferentes niveles de capacidad? Sin tener en cuenta esto, ¿la prueba se está empleando en forma imparcial? De ser así, ¿qué podría hacer la sociedad en conjunto para remediar la disparidad de habilidades entre grupos diferentes y que se ve reflejada en la prueba?

Nuestra exposición de las cuestiones de la imparcialidad de las pruebas y el sesgo de las mismas parece habernos llevado muy lejos del aparentemente trivial y relativamente poco emotivo tema de la validez de la prueba. Sin embargo, las complejas cuestiones que acompañan las discusiones de la validez de la prueba, incluyendo los problemas de imparcialidad y sesgo, deben ser abordados por todos nosotros. Para consideraciones posteriores de los problemas filosóficos implicados puede usted recurrir a la soledad de sus propios pensamientos y a la lectura de su propia conciencia.

Autoevaluación

Compruebe su comprensión de los elementos de este capítulo, tratando de explicar cada uno de los siguientes términos, expresiones y abreviaturas:

análisis factorial
análisis factorial confirmatorio
análisis factorial exploratorio
calificación
categorización
coeficiente de validez
constructo

contaminación del criterio
criterio
datos de expectativas
efecto de halo
error de estimación
error de generosidad
error de lenidad (benevolencia)
error de severidad

error de tendencia central
escala de estimación
estudio de validación
estudio de validación local
evidencia convergente
evidencia discriminante
factor de carga
falso negativo

falso positivo	sesgo	validez aparente
gráfica de expectativas	sesgo de intersección	validez concurrente
homogeneidad	sesgo de la pendiente	validez convergente
imparcialidad	tabla de expectativas	validez de constructo
índice de aciertos	tablas Naylor-Shine	validez de contenido
índice de errores	tablas Taylor-Russell	validez del incremento
interferencia	tasa base	validez predictiva
matriz multirrasgo multimétodo	teoría de la utilidad de la prueba	validez relacionada con el criterio
método de grupos contrastados	validación	
razón de validez de contenido	validez	

Un vistazo a la red

Para mayor información sobre algunos de los temas que abordamos en este capítulo, visite los siguientes sitios web.

Validez

www.socialresearchmethods.net/kb/measval.htm

www.psychol.ucl.ac.uk/edpsych/courses/rmstats/measurement_theory/typesofvalidity.htm

www.socialresearchmethods.net/tutorial/driebe/tweb1.htm

¿Es válida la validez de contenido?

www.rasch.org/rmt/rmt111j.htm

Tablas Taylor-Russell

<http://luna.cas.usf.edu/~mbrannic/files/ttnm/taylor.htm>

Eventos clave en la medición psicológica

www.wku.edu/~sally.kuhlenschmidt/mttmln.htm

El efecto de halo

www.aft.org/parentpage/discipline/halo.html

Validez de predicción de SAT

www.fairtest.org/facts/satvalidity.html

bernard.pitzer.edu/~hfairchi/courses/Spring2001/LATonSAT022601.html

Sesgo de la prueba

www.questia.com/popularSearches/test_bias.jsp

www.leadersunlimited.co.za/html/PressRoom/suntimes1.html

Desarrollo de pruebas

No todas las pruebas son creadas de la misma forma. La creación de una buena prueba no es una cuestión fortuita, sino el producto de la aplicación concienzuda y sólida de los principios establecidos para su elaboración.

En este capítulo, presentaremos las bases de su desarrollo, exploraremos los fundamentos para elaborarlas y examinaremos cierta cantidad de técnicas diseñadas para la construcción y selección de preguntas adecuadas. Aunque nos enfocamos en pruebas publicadas de una variedad estandarizada, mucho de lo que tenemos que decir también se aplica a pruebas hechas a la medida, como aquellas creadas por maestros, investigadores y empleadores.

El proceso de elaboración de una prueba contempla cinco etapas:

1. Conceptualización de la prueba
2. Construcción de la prueba
3. Ensayo de la prueba
4. Análisis de reactivos
5. Revisión de la prueba

Una vez que se concibe la idea para una prueba (conceptualización), se hace un borrador de los reactivos que contendrá (construcción). Luego, este primer borrador se ensaya en un grupo muestra de personas que la van a responder (ensayo). Una vez que se tienen los datos del ensayo, se analiza el desempeño de quienes la respondieron en su totalidad y cada uno de los reactivos. Se emplearán procedimientos estadísticos, a los que nos referimos en forma colectiva como *análisis de reactivos*, para ayudar a hacer juicios respecto a cuáles son convenientes tal como están, cuáles necesitan ser revisados y cuáles deben descartarse. El análisis de los reactivos de la prueba puede incluir un estudio acerca de su confiabilidad, su validez y diferenciación, y, dependiendo del tipo de prueba que sea, su nivel de dificultad. Con base en el análisis de los reactivos y en consideraciones relacionadas, se hará una revisión o segundo borrador de la prueba. Esta versión revisada será ahora ensayada en una nueva muestra de evaluados; se analizarán los resultados, si es necesario se revisará de nuevo la prueba, y así se continúa (figura 7-1). En algún punto, quien elabora la prueba la finalizará o regresará al redactor para revisar su trabajo.

Conceptualización de la prueba

Es probable que la gestación de cualquier prueba publicada pueda rastrearse en las ideas o en la charla interna con uno mismo, en términos conductuales. Quien elabora la prueba se habrá




Figura 7-1
Proceso de desarrollo de la prueba

dicho algo así como: “Debería haber una prueba diseñada para medir [llene con su propuesta el espacio en blanco] en [tal y tal] forma”. El estímulo para una idea así podría ser casi cualquier cosa. Una revisión de la literatura disponible sobre las pruebas existentes diseñadas para medir un constructo particular podría indicar que tales pruebas dejan mucho que desear en cuanto a solidez psicométrica. El surgimiento de algún fenómeno social o patrón de comportamiento podría servir como estímulo para el desarrollo de una nueva prueba. Por ejemplo, si el celibato se convirtiera en un estilo de vida practicado en forma extensa, podríamos ser testigos de la elaboración de pruebas de celibato que podrían medir variables como las razones para adoptar un estilo de vida célibe, el compromiso para un estilo de vida acorde, y el grado de celibato según comportamientos específicos de quienes pretendan practicarlo. La analogía con el campo de la medicina es sencilla. Una vez que una enfermedad nueva (como el síndrome de inmunodeficiencia adquirida [sida], la enfermedad del legionario o el síndrome de intoxicación) atrae la atención de los investigadores en medicina, éstos intentarán elaborar pruebas diagnósticas para evaluar su presencia o ausencia así como la gravedad de sus manifestaciones en el cuerpo.

La elaboración de una nueva prueba puede surgir como respuesta a una necesidad de evaluar el dominio en una ocupación o profesión recién creada. Por ejemplo, pueden elaborarse nuevas pruebas para evaluar el dominio en campos como la ingeniería ambiental, las comunicaciones inalámbricas y las redes computacionales.

SÓLO PIENSE...

¿En qué tema de actualidad deberían estar trabajando los diseñadores de pruebas psicológicas? ¿Qué aspectos de este tema podrían explorarse por medio de una prueba psicológica?

Algunas cuestiones preliminares

Sin importar cuál sea el estímulo para la elaboración de una nueva prueba, el futuro constructor de pruebas enfrenta de inmediato diversas interrogantes. Aquí mostramos algunas:

- **¿Qué es lo que va a medir la prueba según su diseño?** Ésta es una pregunta engañosamente simple; su respuesta está ligada en forma muy estrecha a la forma en que el elaborador de la prueba define el constructo que va a ser medido, y en qué es similar o diferente esta definición de otras pruebas que pretenden medir el mismo constructo.
- **¿Cuál es el objetivo de la prueba?** ¿Al servicio de qué propósito será empleada? ¿En qué forma o formas es similar o diferente el objetivo de esta prueba de otras con objetivos parecidos?
- **¿Existe una necesidad para esta prueba?** ¿Hay alguna otra que pretenda medir lo mismo? ¿En qué formas será mejor o diferente la nueva prueba de las existentes? ¿Habrà una evidencia firme para su confiabilidad o validez? ¿Tendrá un alcance más amplio? ¿Su aplicación requerirá menor tiempo? ¿En qué aspectos no será mejor que las ya existentes?

- *¿Quién usará esta prueba?* ¿Educadores? ¿Otros? *¿Para qué propósitos será usada?*
- *¿Quién tomará esta prueba?* ¿Para quién es? *¿Quién necesita responderla?* *¿Quién encontraría deseable responderla?* ¿Para personas de qué rango de edad está diseñada? *¿Qué nivel de lectura se requiere para que una persona responda esta prueba?* *¿Qué factores culturales podrían influir en las respuestas de la persona?*
- *¿Qué contenido cubrirá la prueba?* *¿Por qué debería cubrir este contenido?* *¿Esta cobertura es diferente de otras con los mismos objetivos o parecidas?* *¿Cómo y por qué es diferente el área de contenido?* *¿En qué medida este contenido es específico para una cultura?*
- *¿Cómo se aplicará la prueba?* ¿Será aplicada en forma individual o grupal? ¿Será susceptible de ser aplicada tanto en forma grupal como individual? *¿Qué diferencias existirán en su aplicación ya sea en forma individual o grupal?* *¿Estará diseñada para aplicarse por medio de computadoras?* *¿Cómo se reflejarán en las puntuaciones las diferencias entre las versiones de la prueba?*
- *¿Cuál será el formato ideal de la prueba?* ¿Debería ser en forma de verdadero o falso, ensayo, opción múltiple, o alguna otra? *¿Por qué la opción seleccionada sería la mejor para esta prueba?*
- *¿Debería elaborarse más de una forma de la prueba?* ¿En base a un análisis de costo y beneficio, deberían crearse formas alternativas o paralelas de esta prueba?
- *¿Qué capacitación especial se requerirá de los usuarios de la prueba para aplicarla o interpretarla?* ¿Qué antecedentes y títulos deberá tener el probable usuario de los datos derivados de la aplicación de esta prueba? *¿Qué restricciones, si es que hay alguna, deberían imponerse a los distribuidores de la prueba y a su uso?*
- *¿Qué clase de respuestas se requerirán de los posibles evaluados?* *¿Qué tipo de discapacidad podría impedir que alguien fuese capaz de responder esta prueba?* *¿Qué clase de arreglos o adaptaciones son recomendados para personas con discapacidades?*
- *¿Quién se beneficia con la aplicación de esta prueba?* ¿Qué aprendería el examinado o cómo podría beneficiarse con la aplicación de esta prueba? ¿Qué aprendería el usuario de la prueba o cómo podría beneficiarse con la aplicación de ésta? *¿Qué beneficio social, si es que hay alguno, se derivaría de su aplicación?*
- *¿Hay algún daño potencial como resultado de una aplicación de esta prueba?* ¿Qué protecciones se incorporan en el procedimiento recomendado para prevenir cualquier clase de daño a cualquiera de las partes implicadas en el uso de esta prueba?
- *¿Cómo se asignará significado a las puntuaciones de esta prueba?* ¿La puntuación de un participante será comparada con la de otros que la respondan al mismo tiempo? *¿Será comparada con otros en un grupo de criterio?* *¿La prueba valorará el dominio de un área de contenido particular?*

Esta última pregunta proporciona un punto de partida para ahondar en cuestiones relacionadas con la elaboración de la prueba respecto a las pruebas con referencia a una norma en contraposición a las pruebas con referencia a un criterio.

Pruebas con referencia a una norma o pruebas con referencia a un criterio: Problemas del desarrollo de reactivos Serán necesarios diferentes enfoques para la elaboración de la prueba y para los análisis de los reactivos individuales dependiendo de si la prueba terminada está diseñada con referencia a una norma o a un criterio. Por ejemplo, por lo común, un buen reactivo en una prueba de rendimiento con referencia a una norma es aquel en el que quienes respondieron en forma correcta obtuvieron puntuaciones altas; en tanto que quienes obtuvieron puntuaciones bajas lo respondieron en forma incorrecta. En una prueba con referencia a un criterio puede ocurrir el mismo patrón de resultados: quienes hayan logrado puntuaciones altas es porque contestaron de manera correcta un reactivo particular, mientras que quienes obtengan puntuaciones bajas será porque se equivocaron en ese mismo reactivo. Sin embargo, esto no es lo que hace que un reactivo sea bueno o aceptable desde una perspectiva orientada hacia un criterio. De manera ideal,

cada reactivo en una prueba orientada hacia un criterio aborda la cuestión de si el examinado —un futuro médico, ingeniero, estudiante de piano o quienquiera que sea— ha cumplido ciertos criterios. En síntesis, cuando se trata de una evaluación orientada hacia un criterio, no cuenta ser “el primero de la clase” e incluso con demasiada frecuencia es irrelevante. Aunque podemos imaginar excepciones a esta regla general, las comparaciones con referencia a una norma generalmente son insuficientes e inapropiadas cuando lo que requiere el usuario es el conocimiento o dominio respectivo.

Las pruebas y evaluaciones con base en un criterio se emplean por lo común en el contexto de la concesión de una licencia ya sea para practicar la medicina o para conducir un automóvil. Los enfoques con referencia a un criterio también se emplean en contextos educativos en los que se debe demostrar el dominio del material particular antes de que el estudiante pase a un material avanzado estructurado, desde un punto de vista conceptual, en base a conocimientos o habilidades existentes, o ambos.

En contraste con las técnicas y principios aplicables a la elaboración de pruebas con referencia a una norma (muchos de los cuales se exponen en este capítulo), la elaboración de instrumentos en base a un criterio se deriva de una conceptualización del conocimiento o habilidades que han de ser dominadas. Las habilidades cognoscitivas o motoras requeridas pueden ser analizadas en sus componentes para su evaluación. Quien elabora la prueba puede intentar un muestreo del conocimiento relacionado con un criterio con respecto a principios generales relevantes para el criterio evaluado. El estudio piloto con diferentes reactivos, pruebas, formatos o procedimientos de medición, ayudará al diseñador de la prueba a descubrir la mejor medida del dominio de las habilidades o del conocimiento que son su objetivo.

En general, la elaboración de una prueba o técnica orientada hacia un criterio puede implicar un trabajo exploratorio al menos en dos grupos de evaluados: un grupo que sea sabido domina el conocimiento o habilidad que se está midiendo y otro que no lo domine. Por ejemplo, al elaborar una prueba escrita con base en un criterio para obtener una licencia de conducir, puede aplicarse una versión preliminar a un grupo de personas que hayan conducido alrededor de 24 000 kilómetros por año durante diez años, y tengan un expediente limpio (sin accidentes y sin infracciones de tránsito). El segundo grupo podría ser de adultos que sean correspondientes en demografía y aspectos relacionados con el primero, pero que nunca hayan tenido ninguna instrucción ni experiencia en conducir.

Los reactivos que diferencien mejor entre estos dos grupos se considerarían “buenos” reactivos. El trabajo exploratorio de experimentación realizado durante el desarrollo de la prueba no tiene nada que ver en absoluto con volar, pero usted no podría saber eso sólo a partir de su nombre...

SÓLO PIENSE...

Suponga que le pidieran desarrollar una prueba con referencia a un criterio para medir su dominio del capítulo 7 de este libro. Explique, con todos los detalles que considere necesarios, cómo lo haría. Le sugerimos seguir leyendo antes de responder.

Estudio piloto

En el contexto de la elaboración de pruebas, términos como **trabajo piloto**, *estudio piloto* e *investigación piloto* se refieren, en general, a la investigación preliminar en torno a la creación de un prototipo de la prueba. Los reactivos de ésta pueden ser estudiados en el piloto (o *pilotados*), para valorar si deben ser incluidos en la forma final del procedimiento. Al elaborar una entrevista estructurada, por ejemplo, para medir la introversión y la extroversión, el estudio piloto puede implicar entrevistas abiertas con personas que por alguna razón (quizá en base a una prueba existente) se supone son introvertidas o extrovertidas. Además, también podrían concertarse entrevistas con padres, maestros, amigos y otras personas que conozcan al sujeto. Otro tipo de estudio piloto podría implicar la verificación fisiológica de los sujetos (como vigilar su ritmo cardíaco) como reacción al haber sido expuestos a diferentes tipos de estímulos.

En el estudio piloto, generalmente, quien elabora la prueba intenta determinar cómo medir mejor el constructo que tiene como objetivo. El proceso puede implicar la creación, revisión y eliminación de muchos reactivos de la prueba; al igual que reseñas literarias y experimentación, entre otros. Una vez completado el estudio piloto, comienza el proceso de elaboración de la prueba.

ba. Sin embargo, téngase en cuenta que dependiendo de la naturaleza de ésta, y en particular de su necesidad de actualizaciones y revisiones, **siempre existe la posibilidad de requerir estudios piloto adicionales.**

Construcción de la prueba

El **estudio piloto**, como muchos de los otros elementos de conceptualización y construcción de pruebas que analizamos en este capítulo, **es una necesidad a incluir dentro de la elaboración de pruebas u otros instrumentos de medición para su publicación y amplia distribución.** Por supuesto, para la construcción de las pruebas que se aplican en el salón de clases, no es necesario el estudio piloto (véase *Psicometría cotidiana*). En la medida que lea más sobre los aspectos formales de la construcción de pruebas profesionales, piense cuál (si existe alguno) procedimiento técnico podría prestarse a ser modificado para su uso en el salón de clases.

Elaboración de escalas

Anteriormente, definimos **medición** como la **asignación de números de acuerdo con reglas.** La **elaboración de escalas** puede ser explicada como **el proceso para establecer reglas y con ello lograr la asignación numérica en la medición realizada con base en el constructo.** Dicho de otra manera, **la elaboración de escalas es el proceso por el cual se diseña y calibra un dispositivo de medición, y la forma en que se asignan números (u otros índices), valores de escala, a diferentes cantidades del rasgo, atributo o característica que se esté midiendo.**

Históricamente, se acredita al prolífico L. L. Thurstone (figura 7-2) de estar a la vanguardia en los esfuerzos para instrumentar métodos sólidos, en sentido metodológico, para la elaboración de escalas. Adaptó los métodos de elaboración de escalas psicofísicas al estudio de variables psicológicas, como actitudes y valores (Thurstone, 1959; Thurstone y Chave, 1929). El artículo de Thurstone (1925) “Un método de elaboración de escalas para pruebas psicológicas y educativas” “A Method of Scaling Psychological and Educational Tests” introdujo, entre otras cosas, la noción de elaboración de **escalas absolutas** —un procedimiento para obtener una medida de la dificultad

Figura 7-2
L. L. Thurstone (1887-1955)

Entre sus muchos logros en el área de la elaboración de escalas está su influyente artículo sobre la “ley del juicio comparativo” (1927), una de las pocas “leyes” en psicología. Esta ley fue uno de los logros más satisfactorios de Thurstone (Nunnally 1978, pp. 60-61), pero tenía muchos logros para escoger. Su adaptación de métodos para elaborar escalas para su uso en la investigación psicofisiológica y el estudio de actitudes y valores han servido como modelo para generaciones de investigadores (Bock y Jones, 1968). También es considerado como uno de los principales arquitectos del análisis factorial moderno.



La psicometría en el salón de clases

Muchas inquietudes que profesores y estudiantes comparten respecto a las pruebas son de naturaleza psicométrica. Los profesores desean aplicar y los estudiantes desean presentar, mediciones confiables y válidas del conocimiento. Incluso los estudiantes que no han tomado un curso de pruebas y evaluación psicológica parecen entender cuestiones psicométricas relativas a las pruebas que les son aplicadas en el salón de clases. Como ejemplo a esto, considere cada una de las siguientes afirmaciones presentadas en pares. La primera es una crítica a una prueba que puede haber escuchado (o dicho usted mismo) dentro del salón de clases. La segunda afirmación es esa crítica traducida a lenguaje psicométrico.

"¡Me pasé toda la noche estudiando el capítulo 3 y en la prueba no hubo ninguna pregunta sobre ese capítulo!"
Traducción: "¡Cuestiono la validez del contenido del examen!"

"Las instrucciones en esta prueba de ensayo no eran claras y creo que eso afectó mi calificación."
Traducción: "Hubo excesiva varianza de error relacionada con los procedimientos de administración de la prueba".

"Contesté igual que mi amiga en esta pregunta de respuesta breve, ¿por qué ella obtuvo crédito completo y a mí el profesor me quitó tres puntos?"
Traducción: "Tengo serias preocupaciones respecto a la tasa de error que afecta la confiabilidad."

"No tuve tiempo suficiente para terminar; ¡esta prueba no midió lo que sé, sino lo rápido que puedo escribir!"
Traducción: "¡Desearía que la persona que redactó esta prueba hubiera puesto más atención a cuestiones vinculadas con la validez del criterio y la eficacia comparativa de las pruebas de velocidad en oposición con las de dominio!"

Como sus estudiantes, los profesores tienen preocupaciones sobre las pruebas que aplican. Desean que sus preguntas de examen sean claras, relevantes y representativas del material cubierto. En ocasiones se preguntan sobre la extensión de sus exámenes. Su inquietud es abarcar cantidades voluminosas de material a la vez que proporcionar suficiente tiempo a los estudiantes para que mediten sus respuestas.

En la mayor parte de las pruebas psicológicas publicadas, este tipo de preocupaciones psicométricas habrían sido abordadas de manera formal durante el proceso de elaboración. En el salón de clases, sin embargo, es poco práctica la valoración psicométrica rigurosa del número de pruebas que cualquier profesor puede aplicar en el transcurso de un semestre. Las pruebas en el salón de clases generalmente son creadas con el

propósito de examinar a un solo grupo de estudiantes durante un semestre. Asimismo, las pruebas varían para reflejar los cambios en las cátedras y lecturas conforme evoluciona el curso. Además, si las pruebas fueran reutilizadas, correrían el riesgo de volverse medidas para quienes han visto o escuchado sobre el examen antes de presentarlo, en lugar de medir lo bien que los estudiantes han aprendido el material del curso. Por supuesto, aunque la valoración psicométrica formal de las pruebas en el salón de clases puede ser poco práctica, con frecuencia en su lugar, se utilizan métodos informales.

Las preocupaciones sobre la validez del contenido son abordadas por los profesores de manera rutinaria, por lo general de manera informal, en el proceso de elaboración de la prueba. Por ejemplo, supóngase que un examen que contiene 50 preguntas de opción múltiple y cinco ensayos breves cubrirá el material de lectura y cátedra de cuatro amplios temas. El profesor podría incluir de manera sistemática 12 o 13 preguntas de opción múltiple y al menos un ensayo breve sobre cada área temática. También podría extraer un determinado porcentaje de las preguntas de las lecturas y de la cátedra. Este enfoque deliberado de cobertura del contenido bien podría favorecer la validez del contenido de la prueba, aunque no se realice una valoración formal de la validez de contenido. Asimismo el profesor puede hacer un esfuerzo para informar a los estudiantes que tanto los recuadros y apéndices del libro de texto así como todos los medios de instrucción utilizados en clase (como videgrabaciones) pueden estar incluidos en la evaluación.

La validez relacionada con un criterio es difícil de establecer en muchas de las pruebas que se generan dentro del salón de clases debido a que ningún criterio obvio refleja el nivel de conocimiento del material que tienen los estudiantes. Pueden existir excepciones para estudiantes en un programa técnico o aplicado que presenten un examen para titularse u obtener un certificado. La evaluación informal de algo afín a la validez de criterio puede efectuarse sobre la base individual de una plática entre el profesor y el estudiante. El hecho de que un estudiante haya obtenido la puntuación más baja en la clase puede significar para el profesor una inequívoca carencia de comprensión del material. También es cierto que con el mismo método puede cuestionarse la validez de criterio de la prueba. Por ejemplo, una plática con el estudiante que haya obtenido la puntuación más alta podría revelar también que éste no tiene idea del material que se buscaba explorar en el diseño de la prueba. Este hallazgo haría vacilar al profesor.

La validez de constructo de las pruebas en el salón de clases también a menudo se evalúa de manera informal, como

(continúa)

La psicometría en el salón de clases (continuación)

cuando una anomalía en el desempeño de una prueba llama la atención hacia cuestiones relacionadas con la validez del constructo. Por ejemplo, considere un grupo de estudiantes cuyo historial de desempeño está en un nivel por encima del promedio en los exámenes. Ahora suponga que en un examen, todos los estudiantes en ese grupo tienen un mal desempeño. Si todos esos estudiantes reportan que no estudiaron para la prueba o que no comprendieron el material del texto, entonces hay una explicación adecuada para sus bajas puntuaciones. Sin embargo, si reportan que estudiaron y comprendieron el material, como de costumbre, entonces uno podría cuestionar la validez de constructo de la prueba como una explicación del resultado.

Los aspectos de la confiabilidad de una prueba elaborada en el salón de clases también pueden ser evaluados de manera informal. Por ejemplo, una discusión con estudiantes puede arrojar luz sobre la consistencia interna de la prueba. Entonces de nuevo, si la prueba fue diseñada para ser de naturaleza heterogénea, podría ser deseable una consistencia de bajas calificaciones internas. En las pruebas de ensayo, la confiabilidad entre evaluadores puede explorarse proporcionando a un grupo de voluntarios los criterios usados para calificar los ensayos y permitirles que califiquen algunos. Este ejercicio podría arrojar luz sobre la claridad de los criterios de calificación. En el caso excepcional de que por alguna razón la misma prueba sea aplicada dos veces o de manera alternativa en el salón de clases, puede

llevarse a cabo una discusión de la confiabilidad de la prueba y su repetición o de la confiabilidad de las formas alternativas. En la práctica, sin embargo, es raro que las pruebas sean aplicadas dos veces o en formas alternativas en el salón de clases.

¿Alguna vez ha presentado un examen en el cual un estudiante haya pedido en voz baja una aclaración sobre una pregunta específica, y el profesor anuncia entonces a la clase entera la respuesta a la pregunta del estudiante? Este profesor está intentando reducir el error de administración (e incrementar la confiabilidad) al proporcionar la misma experiencia para todos los que responden la prueba. Cuando califican preguntas de respuesta breve o de ensayo, los profesores pueden tratar de reducir el error del evaluador mediante varias técnicas. Por ejemplo, pueden pedir a un colega que descifre la mala caligrafía de un estudiante o que califique de nuevo un conjunto de ensayos (sin saber las calificaciones originales). Los profesores también tratan de reducir el error de administración e incrementar la confiabilidad, eliminando reactivos que muchos estudiantes no entienden o entienden mal.

Las pruebas elaboradas para ser administradas en el salón de clases pueden no ser perfectas; pocas de ellas lo son, si es que alguna lo es. Aún así, la mayoría de los profesores siempre está en busca de maneras —formales e informales— para hacer que las pruebas que aplican sean lo más sólidas posible desde el punto de vista psicométrico.

que presentaba cada reactivo, a través del estudio de muestras de los evaluados cuya capacidad era variada.

Tipos de escalas En el lenguaje común, las escalas son instrumentos que se usan para medir algo, como el peso. En psicometría, las escalas también pueden concebirse como instrumentos usados para medir algo; siendo ese algo generalmente un rasgo, una característica o un atributo psicológico. Cuando pensamos en tipos de escalas, pensamos en las distintas maneras en que las escalas pueden ser clasificadas. En el capítulo 3, por ejemplo, vimos que las escalas pueden clasificarse de manera significativa a lo largo de un continuo en el nivel de medición y definirse, por su naturaleza como nominal, ordinal, de intervalo o de razón. Pero también podríamos caracterizar las escalas de otras maneras.

Si el principal interés es el desempeño del examinado en función de la edad, entonces la prueba podría denominarse *escala de edad*. Si el principal interés es el desempeño del examinado en función del grado, entonces la prueba podría denominarse *escala de grado*. Si todas las puntuaciones crudas en la prueba van a ser transformadas en puntuaciones del 1 al 9, entonces la prueba podría denominarse *escala de estaninas*. Una escala podría clasificarse en otras formas, como *unidimensional* en oposición a *multidimensional* y *comparativa* en oposición a *categorica*. Éstas son tan sólo ejemplos de las muchas formas en que las escalas pueden categorizarse.

Escala de clasificación del reactivo A

¿Cómo te sentiste con lo que viste en la televisión?



Escala de clasificación del reactivo B

Creo que me gustaría trabajar como guardafaro.

Verdadero Falso (encierre en un círculo su respuesta)

Escala de clasificación del reactivo C

Por favor, clasifique al empleado según su disposición para cooperar y relacionarse con sus compañeros de trabajo:

Excelente ____ / ____ / ____ / ____ / ____ / ____ / ____ / Insatisfactorio

Figura 7-3

Los muchos rostros de las escalas de clasificación

Las escalas de clasificación pueden adoptar muchas formas. Las caritas sonrientes como las ilustradas aquí en el reactivo A se han usado en la investigación sociopsicológica con niños y adultos con alguna discapacidad en torno al lenguaje. Las caritas se usan en vez de palabras como positivo, neutral y negativo.

Puesto que las escalas pueden clasificarse de muchas maneras, es razonable suponer que existen muchos métodos distintos para construirlas. No hay un método único para su elaboración; pueden hacerse de varias maneras. Ninguno de los tipos de escalas es “la mejor”. Quienes elaboran las pruebas diseñan el método de medición que creen se adapta mejor a la conceptualización de la medición del rasgo (o lo que sea) que se desee medir.

Métodos para elaborar escalas En general, se supone que quien responde una prueba tiene en mayor o menor grado la característica medida por una prueba (válida) como una función de la puntuación; cuanto mayor o menor sea la puntuación, tanto menor o mayor será la característica que supone el sujeto posee. Pero, ¿de qué forma se asignan valores numéricos a las respuestas para poder calcular la puntuación de la prueba? Esto se lleva a cabo mediante la elaboración de una escala basada en los reactivos de la prueba, usando cualquiera de los varios métodos disponibles.

Por ejemplo, considere una medida de opinión sobre cuestiones morales llamada “Escala revisada de comportamientos moralmente debatibles” (*Morally Debatable Behaviors Scale-Revised*; MDBS-R; Katz *et al.*, 1994). Elaborada para ser “un medio práctico de evaluar lo que las personas creen, la fuerza de sus convicciones, al igual que las diferencias individuales en cuanto a tolerancia moral” (p. 15), la MDBS-R consta de 30 reactivos. Cada uno contiene una breve descripción de una cuestión o comportamiento moral sobre la cual el examinado expresa su opinión por medio de una escala de 10 puntos que va desde *nunca se justifica* hasta *siempre se justifica*. He aquí una muestra:

Haría trampa en el pago de impuestos si tuviera la oportunidad:

1	2	3	4	5	6	7	8	9	10
nunca									siempre
se justifica									se justifica

La escala MDBS-R es un ejemplo de una **escala de estimación**, la cual puede definirse como el agrupamiento de palabras, afirmaciones o símbolos a través de los cuales el evaluado indica

la intensidad de sus juicios relativos a un rasgo, actitud o emoción particular. Las escalas de estimación pueden ser usadas para registrar juicios personales o de otros individuos, experiencias u objetos y pueden adoptar formas diversas (figura 7-3).

En la MDBS-R, las estimaciones del examinado respecto de cada uno de los 30 reactivos se suman para obtener una puntuación final. Las puntuaciones varían desde aquella considerada como baja de 30 pts (si quien responde indica que los 30 comportamientos nunca se justifican) hasta una alta de 300 (si quien responde indica que las 30 situaciones siempre se justifican). Debido a que la puntuación final de la prueba se obtiene sumando las estimaciones de todos los reactivos, ésta se denomina **escala sumatoria**.

Un tipo de escala de estimación sumatoria, la **escala Likert** (Likert, 1932), se usa en forma extensa dentro de la psicología, por lo general para escalas de actitud. Las escalas Likert son relativamente fáciles de elaborar. Cada reactivo ofrece cinco alternativas de respuesta (a veces siete), usualmente en algún tipo de sucesión entre acuerdo y desacuerdo o aprobación y desaprobación. Si Katz *et al.*, hubieran usado una escala Likert en su prueba, un reactivo podría lucir así:

Haría trampa en el pago de impuestos si tuviera la oportunidad (marque una opción)

nunca se justifica	rara vez se justifica	a veces se justifica	usualmente se justifica	siempre se justifica
-----------------------	--------------------------	-------------------------	----------------------------	-------------------------

Las escalas Likert suelen ser confiables, lo cual puede explicar su amplia popularidad. Likert (1932) experimentó con diferentes ponderaciones de las cinco categorías, pero concluyó que en general funcionaba mejor asignando valores de 1 (para la aprobación de reactivos en un extremo) a 5 (para la aprobación de reactivos en el otro extremo).

SÓLO PIENSE...

Es debatible pero, ¿cuál de las formas de la escala de comportamientos moralmente debatibles funcionó mejor para usted? ¿Por qué?

El uso de escalas de estimación de cualquier tipo da como resultado datos en el nivel ordinal. Con referencia al reactivo en la escala Likert, por ejemplo, si a la respuesta *nunca se justifica* se le asigna el valor de 1; a *rara vez se justifica*, el valor de 2, y así en forma sucesiva, entre mayor sea la puntuación, la respuesta será más indicativa de la tolerancia con respecto al engaño en la declaración

de impuestos. Quienes responden podrían incluso, clasificarse respecto a dicha tolerancia. Sin embargo, la diferencia en tolerancia entre las opiniones de un par de personas que obtuvieron puntuaciones de 2 y 3 en esta escala, no necesariamente es igual que la diferencia entre las opiniones de un par de personas que obtuvieron puntuaciones de 3 y 4.

Las escalas de estimación difieren en el número de dimensiones que subyacen en las estimaciones hechas. Algunas escalas de estimación son **unidimensionales**, lo que significa que se supone que sólo una dimensión subyace en las estimaciones. Otras escalas de estimación son **multidimensionales**, lo que significa que más de una dimensión guía las respuestas de los examinados. En este contexto piense en un reactivo de la MDBS-R respecto al uso de la marihuana. Las respuestas a este reactivo, en particular, las que se ubican en un rango de bajo a medio, pueden interpretarse de muchas maneras distintas. Dichas respuestas pueden reflejar la opinión de que las personas a) no deberían realizar actividades ilegales, b) no deberían correr riesgos con su salud, o c) deberían evitar actividades que pudieran conducirlos a relacionarse con pandilleros. Las respuestas a este reactivo pueden reflejar otras actitudes y creencias, como aquellas relacionadas con el uso benéfico de la marihuana como adjunto en la quimioterapia para pacientes con cáncer. Cuando se abarca más de una dimensión con un reactivo, se usan técnicas de elaboración de escalas multidimensionales para identificar las dimensiones.

Otro método de elaboración de escalas que produce datos ordinales es el **método de comparación por pares**. A los examinados se les presentan pares de estímulos (dos fotografías, dos objetos, dos afirmaciones) y se les pide que los comparen. Luego deben seleccionar uno de ellos de acuerdo con una regla; por ejemplo, la regla de que están más de acuerdo con una afirmación

que con la otra o la regla de que encuentran un estímulo más atractivo que el otro. Si Katz *et al.*, hubieran usado el método de comparación por pares, un reactivo en su escala podría verse como éste:

Seleccione el comportamiento que considere más justificado:

- a) Hacer trampa en la declaración de impuestos si tiene la oportunidad.
- b) Aceptar un soborno durante el cumplimiento de nuestros deberes.

Por cada par de opciones los evaluados recibirían una mayor puntuación si seleccionaran la opción considerada más justificable por la mayoría de un grupo de jueces. A los jueces se les habría pedido que estimaran los pares de opciones antes de distribuir la prueba y junto con las pruebas, se habrían proporcionado las instrucciones y claves de respuestas para la calificación, así como una lista de las opciones seleccionadas por los jueces. Si como jueces usamos la muestra de estandarización de Katz *et al.* (1994), la opción más justificable es hacer trampa en la declaración de impuestos. Alguien que seleccione la opción a) podría recibir un punto más en la calificación total del examen, pero ninguno si selecciona la opción b). Una ventaja del método de comparación por pares, es que obliga a quienes responden la prueba, a hacer una elección entre varios reactivos disponibles.

Otra forma de derivar información ordinal por medio de un sistema de elaboración de escalas implica tareas de clasificación. En estos enfoques usualmente se presentan a quienes responden la prueba, tarjetas impresas, dibujos, fotografías, objetos u otros estímulos parecidos para que los evalúen. Un método de clasificación es la elaboración de escalas comparativas, el cual implica juicios de un estímulo en comparación con todos los demás estímulos de la escala. Una versión del MDBS-R que emplea las escalas comparativas podría presentar 30 reactivos, cada uno impreso en una tarjeta separada. A quienes responden se les solicitaría que clasificaran las tarjetas de la más justificable a la menos justificable. También podría lograrse una escala comparativa proporcionando a quienes responden la prueba una lista de 30 reactivos y pidiéndoles que jerarquicen la justificabilidad de los reactivos, clasificándolos del 1 al 30.

Otro sistema de elaboración de escalas con base en la clasificación es la elaboración de escalas categóricas. Los estímulos se colocan en una de dos o más categorías alternas que difieran en forma cuantitativa respecto a una continuidad. En nuestro ejemplo de la MDBS-R, podría dársele a los examinados 30 tarjetas, cada una con uno de los 30 reactivos impresos. Luego se les pediría que clasificaran las tarjetas en tres montones: aquellos comportamientos que nunca se justifican, aquellos que algunas veces se justifican y los que siempre se justifican.

Una escala Guttman (1944, 1947) es otro método de elaboración de escalas que produce medidas en el nivel ordinal. Los reactivos en ella varían en forma secuencial, de las expresiones más débiles a las más fuertes, todas ellas basadas en la actitud, creencia o sentimiento que se mide. Una característica de las escalas Guttman es que están diseñadas para que quienes están de acuerdo con las afirmaciones más fuertes de la actitud también estarán de acuerdo con afirmaciones más moderadas. Usando la escala MDBS-R como ejemplo, considere las siguientes afirmaciones que reflejan actitudes hacia el suicidio.

Está de acuerdo o en desacuerdo con cada una de las siguientes:

- a) Todas las personas deberían tener derecho a decidir si desean terminar con su vida.
- b) Las personas con enfermedades terminales y que sufren dolor deberían tener la opción de que un médico les ayude a terminar con su vida.
- c) Las personas deberían tener la opción de rechazar el uso de equipo para mantener la vida en forma artificial antes de enfermarse más gravemente.
- d) Las personas tienen derecho a una vida confortable.

Si ésta fuera una escala Guttman perfecta, todos los examinados que estuvieran de acuerdo con a (la postura más extrema) también estarían de acuerdo con b, c y d. Quienes responden que

SÓLO PIENSE...

¿Por qué puede ser ventajoso obligar a los examinados a elegir entre dos reactivos?
¿Cómo podría generar desventajas esta estrategia?

están en desacuerdo con *a*, pero están de acuerdo con *b*, también estarían de acuerdo con *c* y *d*, y así en forma sucesiva. Las escalas Guttman se elaboran mediante la aplicación de diversos reactivos a un grupo objetivo. Luego, los datos resultantes se analizan a través del **análisis del escalograma**, un procedimiento de análisis de reactivos y enfoque para la elaboración de pruebas que implica el mapeo gráfico de las respuestas del examinado. El propósito para el diseñador de una prueba de medición de actitudes es obtener un arreglo de los reactivos en el cual la aprobación de un reactivo implica de manera automática la aprobación de posturas menos extremas. No siempre es posible hacer esto. Más allá de la medición de actitudes, la elaboración de escalas Guttman o análisis del escalograma (los dos términos se usan de manera indistinta) es atractiva para quienes elaboran pruebas de psicología del consumidor, donde el objetivo puede ser descubrir si el consumidor que compra un producto compraría otro.

Todos los métodos precedentes producen datos ordinales. El **método de intervalos aparentemente iguales**, por primera vez descrito por Thurstone (1929), es un **método de elaboración de escalas para obtener datos que se supone ocurren a intervalos**. De nuevo con el ejemplo de lo justificable del suicidio, delineemos los pasos requeridos para crear una escala con el método de intervalos aparentemente iguales de Thurstone.

1. Se recopila una cantidad razonablemente grande de afirmaciones que refleja actitudes positivas y negativas hacia el suicidio, como *la vida es sagrada; las personas nunca deberían atentar contra sus propias vidas, y una persona con intenso dolor físico o emocional puede decidir en forma racional que el suicidio es su mejor opción*.
2. Los jueces (o los expertos en algunos casos) evalúan cada afirmación en relación al grado en que aceptan que el suicidio está justificado. Cada juez es instruido para evaluar cada afirmación en una escala como si ésta fuera de intervalo por naturaleza. Por ejemplo, la escala podría variar de 1 (la afirmación indica que el suicidio nunca se justifica) a 9 (indicando que el suicidio siempre se justifica). A los jueces se les señala que la escala de 1 a 9 se usa como si hubiera una distancia igual entre cada uno de los valores; es decir, como si fuera una escala de intervalo. También se les aconseja que enfoquen sus estimaciones en las afirmaciones, no en sus propias opiniones sobre la materia.
3. Se calcula una media y una desviación estándar de las evaluaciones de los jueces para cada afirmación. Por ejemplo, si 15 jueces evalúan 100 afirmaciones en una escala del 1 al 9, entonces para cada una de estas 100 afirmaciones, las 15 evaluaciones de los jueces se promediarían. Suponga que cinco de los jueces evaluaron un reactivo particular como 1. Otros cinco, como 2, y los restantes cinco jueces, como 3. La estimación promedio sería 2 (con una desviación estándar de 0.816).
4. Los reactivos son seleccionados para su inclusión en la escala final con base en varios criterios, incluyendo el grado en que un reactivo contribuye a una medición general de la variable en cuestión y el grado de confianza del creador de la prueba en que los reactivos, en efecto, se han clasificado en intervalos iguales. Las medias y las desviaciones estándar de los reactivos también se estiman. Los reactivos deberán representar una amplia gama de actitudes reflejadas en una variedad de medias. Una desviación estándar baja es señal de un buen reactivo; los jueces estuvieron de acuerdo acerca del significado del reactivo respecto a la forma en que refleja las actitudes hacia el suicidio.
5. La escala está lista para su administración. La forma en que se use depende de los objetivos de la situación de prueba. Normalmente, se les pide a quienes la responden que seleccionen las afirmaciones que reflejen con mayor precisión sus propias actitudes. Los valores de los reactivos seleccionados (con base en las estimaciones de los jueces) por quienes responden se promedian, produciendo una puntuación en la prueba.

El método de intervalos aparentemente iguales, es ejemplo de un método de elaboración de escalas de la variedad de evaluación directa. En contraste con los métodos que implican evaluación indirecta, no hay necesidad de transformar las respuestas de quienes respondieron en alguna otra escala.

El método particular de elaboración de escalas que se emplea en la elaboración de una nueva prueba depende de muchos factores, incluyendo las variables que van a ser medidas, el grupo al que va dirigida (los niños pueden requerir un método de elaboración de escalas menos complicado que los adultos, por ejemplo) y las preferencias de quien prepara la prueba.

Redacción de reactivos

En el proyecto completo de la construcción de una prueba, las consideraciones relacionadas con la redacción final de los reactivos de la prueba van de la mano con las consideraciones de la elaboración de escalas. Tres preguntas que el futuro productor de pruebas o redactor de reactivos enfrenta de inmediato son:

- ¿Qué rango de contenido deben cubrir los reactivos?
- ¿Cuál de los muchos tipos diferentes de formatos de reactivo debe emplearse?
- ¿Cuántos reactivos deben redactarse?

Cuando se diseña una prueba estandarizada usando un formato de opción múltiple, por lo general es aconsejable que el número de reactivos para el primer borrador contenga aproximadamente el doble del número que contendrá la versión final de la prueba.¹ Si, por ejemplo, una prueba llamada “Historia de Estados Unidos: 1940 a 1990” tuviera 30 preguntas en su versión final, sería útil tener una reserva de 60 reactivos. En forma ideal, los reactivos en reserva serán una muestra adecuada del dominio de la prueba. Una **reserva de reactivos** es el depósito o provisión de donde se seleccionarán o descartarán los reactivos para la versión final a utilizar.

Un muestreo inclusivo proporciona una base para la validez del contenido de la versión final de la prueba. Debido a que aproximadamente la mitad de estos reactivos serán eliminados en la versión final de la prueba, el elaborador necesita asegurarse de que la versión final contenga los reactivos que representen el dominio del contenido a evaluar, de una forma adecuada. Por tanto, si se determina que todas las preguntas sobre la guerra del Golfo Pérsico, derivadas de los 60 reactivos originales, están mal redactadas, incumbirá a quien elabora la prueba redactar de nuevo el muestreo de este periodo o crear nuevos reactivos para lograrlo. Los reactivos nuevos o reescritos se someterían a prueba, al igual que los primeros, para no poner en peligro la validez de contenido de la prueba. Igual que en las versiones anteriores de la prueba, se debe hacer un esfuerzo para asegurar que la versión final contenga un muestreo adecuado para medir el dominio del conocimiento deseado. Una consideración adicional es aquella que va en relación a si se crearán o no formas alternas de la prueba y si la respuesta es positiva, cuántas. Multiplique el número de reactivos requeridos en la reserva para una forma de la prueba por el número de formas planeadas y obtendrá el número de reactivos que se necesitan para la reserva inicial.

¿Cómo se elabora la reserva de reactivos? Quien elabora la prueba puede redactar una gran cantidad de reactivos con base en su experiencia personal o en el conocimiento académico del tema. También puede buscar la ayuda de otros, incluyendo expertos. Para las pruebas psicológicas diseñadas para escenarios clínicos, se puede entrevistar a médicos clínicos, pacientes, familiares de los pacientes, personal clínico y otros, en busca de ideas que puedan servir en la redacción de los reactivos. Para las pruebas psicológicas diseñadas para el uso de los psicólogos laborales, quizá sea útil entrevistarse con los integrantes de la industria u organizaciones que hayan sido elegidas. Para pruebas psicológicas diseñadas para el uso de psicopedagogos, las entrevistas con maestros, personal administrativo, psicólogos educativos y otros pueden ser invaluableles. También puede rendir frutos la búsqueda en la literatura de investigación, así como la búsqueda en otro tipo de literatura.

1. El sentido común y las demandas prácticas de la situación podrían sugerir que se escribieran menos reactivos para el primer borrador de una prueba. Si, por ejemplo, la prueba final fuese a contener 1 000 reactivos, sería una carga indebida intentar crear una reserva de 2 000. Pero si el creador de la prueba es una persona muy inteligente y experta en la redacción de reactivos, sólo le sería necesario escribir alrededor de 1 200.

Consideraciones relacionadas con variables tales como el propósito de la prueba y el número de examinados a quienes se va a administrar, se incluyen en las decisiones respecto al formato en el que se presentarán los reactivos.

Formato de reactivos A las variables tales como la forma, plan, estructura, arreglo y disposición de los reactivos de pruebas individuales, se les llama en forma colectiva **formato de reactivos**. Los dos tipos de formato de reactivos que analizaremos a fondo son el *formato de respuesta seleccionada* y el *formato de construcción de respuesta*. Los reactivos presentados con el **formato de selección de respuesta** requieren que quienes respondan la prueba elijan una respuesta entre una serie de alternativas. Los reactivos con formato de construcción de respuesta requieren que los examinados no solamente seleccionen la respuesta correcta, sino que la proporcionen o la creen.

Si una prueba está diseñada para medir el rendimiento, y los reactivos se redactan en el formato de selección de respuesta, entonces los examinados deben seleccionar la respuesta que se considera correcta. Si una prueba está diseñada para medir la fuerza de un rasgo particular y los reactivos están redactados en el formato de selección de respuesta, entonces los examinados deben seleccionar la alternativa que responda mejor a la pregunta con respecto a ellos mismos. Como más adelante estudiaremos los formatos de los reactivos, por simplicidad, limitaremos nuestros ejemplos a las pruebas de rendimiento. Quizá el lector quiera sustituir de manera mental otros términos apropiados para palabras como *correcto* en pruebas de personalidad u otros tipos de pruebas que no sean de rendimiento.

Tres tipos de pruebas con formatos de selección de respuesta son las de *opción múltiple*, *de reactivos de correlación* y *de verdadero/falso*. Una **prueba estructurada con el formato de opción múltiple** tiene tres elementos: 1) un tronco, 2) una alternativa u opción correcta y 3) varias alternativas u opciones incorrectas a las que se denomina en forma variada *distractores* u *hojas*. Es importante analizar dos ilustraciones (a pesar de que usted debe estar muy familiarizado con los formatos de opción múltiple).

Reactivo A

Tronco —————→ Una prueba psicológica, una entrevista y un estudio de caso son:
Alternativa correcta —→ a) Herramientas de evaluación psicológica
Distractores —→

b)	Muestras conductuales estandarizadas
c)	Instrumentos confiables de evaluación
d)	Medidas vinculadas con la teoría

Ahora considere el reactivo B:

Reactivo B

Un buen reactivo de opción múltiple en una prueba de rendimiento:

- a) Tiene una alternativa correcta
- b) Tiene alternativas paralelas desde el punto de vista gramatical
- c) Tiene alternativas de longitud similar
- d) Tiene alternativas que concuerdan desde el punto de vista gramatical con el tronco
- e) Incluye tanto como sea posible del reactivo en el tronco para evitar repeticiones innecesarias
- f) Evita distractores ridículos
- g) No es demasiado largo
- h) Todos los anteriores
- i) Ninguno de los anteriores

Si respondió “h” al reactivo B, está en lo correcto. Mientras usted leía la lista de alternativas, puede habersele ocurrido que ¡el reactivo B violaba muchas de las reglas enunciadas!

En un **reactivo de relación** se le presentan dos columnas de respuestas al examinado, *premisas* a la izquierda y *respuestas* a la derecha. La tarea de quien presenta el examen es **determinar cuál**

respuesta se asocia mejor con cuál premisa. Para los examinados muy jóvenes las instrucciones son trazar una línea de una premisa a una respuesta. De manera usual, a los mayores se les pide que escriban una letra o un número. He aquí un ejemplo de un reactivo de evaluación que podríamos encontrar en una prueba de una clase de historia del cine:

Instrucciones: Relacione los nombres de los actores en la columna X con el papel que interpretaron en alguna película de la columna Y. Escriba la letra del papel en la película junto al número del actor correspondiente. Cada papel en la columna Y puede usarse una o más veces.

Columna X	Columna Y
_____ 1. Anthony Hopkins	a) Ace Ventura
_____ 2. Jim Carrey	b) El Chacal
_____ 3. Wesley Snipes	c) Capitán Jack Aubrey
_____ 4. Mike Myers	d) Hannibal Lecter
_____ 5. Dustin Hoffman	e) Austin Powers
_____ 6. Jack Black	f) Blade
_____ 7. George Lazenby	g) Yu Shu
_____ 8. Robin Williams	h) Dewey Finn
_____ 9. Sigourney Weaver	i) Profesor Brainard
_____ 10. Michelle Yeoh	j) Benjamín Braddock
_____ 11. Russell Crowe	k) James Bond
	l) Ellen Ripley
	m) John Book

Quizás haya notado que las dos columnas contienen una cantidad diferente de reactivos. Si el número de reactivos en las dos columnas fuese el mismo, entonces una persona insegura del personaje de uno de los actores podría deducirlo relacionando primero todas las otras opciones. Resultaría entonces una puntuación perfecta, aun cuando quien responda la prueba no conozca en realidad todo el material. El proporcionar más opciones de las necesarias minimiza dicha posibilidad. Otra manera de disminuir la probabilidad de respuestas al azar o de adivinación como un factor en la puntuación de la prueba es incluir en las instrucciones que cada respuesta puede ser utilizada de forma correcta una o más veces.

Debemos tomar en cuenta dos directrices al redactar los reactivos de relación que se aplicarán en el salón de clases. La redacción de las premisas y las respuestas deben ser muy breves y directas. No debe incluirse más de una docena de premisas, de lo contrario, algunos estudiantes olvidarán lo que andan buscando al revisar el listado. Las listas de respuestas y premisas deben ser homogéneas, es decir, de la misma clase. Nuestro ejemplo de la clase de cine tiene una lista homogénea de premisas (nombres de actores) y una lista homogénea de respuestas (nombres de personajes de películas). Debe ponerse especial cuidado en que una y sólo una de las premisas se relacione con una y sólo una de las respuestas. No sería aconsejable que a la lista de premisas se agregaran más nombres de actores como Sean Connery, Roger Moore, David Niven, Timothy Dalton o Pierce Brosnan, como ocurre en nuestro ejemplo. ¿Sabe por qué?

En uno u otro tiempo, Connery, Moore, Niven, Dalton y Brosnan, todos interpretaron a James Bond (respuesta k). Tal como aparecen las listas de premisas y respuestas, la relación con la respuesta k es la premisa 7 (este actor australiano interpretó al agente 007 en la película *Al servicio secreto de su majestad*). Si en el futuro el elaborador de pruebas quisiera sustituir el nombre de otro actor, digamos, Pierce Brosnan por el de George Lazenby, sería prudente revisar las columnas

para asegurarse de que Brosnan no ha interpretado ninguno de los otros personajes en la columna de respuestas y que James Bond tampoco ha sido actuado por ningún actor de la lista de premisas, además de Brosnan.²

Un reactivo de opción múltiple que sólo contiene dos respuestas posibles se llama **reactivo de selección binaria**. Quizá el más común de estos reactivos sea el **reactivo falso/verdadero**. Como usted sabe, éste tipo de reactivo de selección de respuesta suele tomar la forma de una oración en donde el examinado indicará si la afirmación es o no un hecho. Otra variedad de reactivos de selección binaria incluyen oraciones a las que el examinado pueda dar una de dos respuestas, tales como *acuerdo/desacuerdo*, *si/no*, *correcto/incorrecto* y *hecho/opinión*.

Un buen reactivo binario debe contener una sola idea, no ser largo en exceso y no estar sujeto a debate; es decir, la respuesta correcta deberá ser sin duda una de las dos. Al igual que los reactivos de opción múltiple, los de selección binaria tienen la ventaja de ser aplicables con facilidad en una amplia gama de áreas temáticas. A diferencia de los reactivos de opción múltiple, los de selección binaria no necesitan contener una lista de alternativas distractoras. Por consiguiente,

tienden a ser más fáciles de redactar que los reactivos de opción múltiple. Una desventaja de los reactivos de selección binaria es que la probabilidad de obtener una respuesta correcta con base sólo en el azar (adivinando) en cualquier reactivo es .5, o 50%.³ Por el contrario, la probabilidad de obtener una respuesta correcta adivinando en una pregunta de opción múltiple con cuatro alternativas es .25, o 25%.

Pasemos del análisis de formato de selección de respuesta al de la variedad de construcción. Los tres tipos de reactivos de construcción de respuesta son: *reactivo de completar una respuesta*, *de respuesta breve* y *de ensayo*.

Un **reactivo de completar** requiere que el examinado proporcione una palabra o frase que complete una oración, como en el siguiente ejemplo:

Por lo general, la desviación estándar se considera la medida más útil de _____.

Un **buen reactivo de completar** debe ser redactado de modo que la respuesta correcta sea específica. Los reactivos de completar que pueden responderse en forma correcta de muchas maneras pueden conducir a problemas de calificación. La respuesta para completar de manera correcta el reactivo anterior es *variabilidad*. Una forma alternativa de redactar este reactivo sería uno de respuesta breve:

¿Qué estadística descriptiva es considerada por lo general como la medida más útil de variabilidad?

Un reactivo de completar también puede ser denominado de **respuesta breve**. Sería deseable que los reactivos de completar o de respuesta breve estuvieran redactados con la suficiente claridad para que el examinado pueda contestar en forma sucinta, es decir, con una respuesta breve. No hay reglas precisas que especifiquen qué tan corta debe ser una respuesta para que sea considerada breve; una palabra, un término, una oración o un párrafo pueden ser suficientes. Más allá de un párrafo o dos, el reactivo podría considerarse en forma más apropiada como un reactivo de ensayo. Podemos definir un **reactivo de ensayo** como una prueba que maneja reactivos y que

2. Ésta es la clave completa de respuestas: 1-d, 2-a, 3-f, 4-e, 5-j, 6-h, 7-k, 8-i, 9-l, 10-g, 11-c.

3. Sin embargo, hemos observado que aunque la probabilidad de adivinar de manera correcta en un reactivo individual de elección binaria con base sólo en el azar puede ser .5, la probabilidad de adivinar correctamente en una *secuencia* de dichos reactivos decrece en tanto que el número de reactivos aumenta. La probabilidad de adivinar correctamente en dos de tales reactivos es igual a .5² o 25%. La probabilidad de adivinar correctamente en diez de dichos reactivos es igual a .5¹⁰ o .001. Por tanto, hay una oportunidad en mil de que quien responde adivine de manera correcta diez reactivos en el formato falso/verdadero (u otra elección binaria) sólo en base a la probabilidad.

SÓLO PIENSE...

Responda verdadero o falso, de acuerdo a su opinión como estudiante: *En el campo de la educación son preferibles los reactivos de selección de respuesta a los de construcción de respuesta*. Vuelva a responder, ahora desde la perspectiva de un educador y usuario de prueba. Explique sus razonamientos.

requiere que el examinado responda escribiendo una composición, por lo general, una que demuestre que hay rememoración de hechos, entendimiento, análisis o interpretación.

He aquí un ejemplo de un reactivo de ensayo:

Compare y contraste las definiciones y técnicas del condicionamiento clásico y operante. Incluya ejemplos de la forma en que se han aplicado los principios de cada uno en escenarios clínicos y educativos.

Un ensayo es un tipo de reactivo útil cuando el elaborador de la prueba desea que el examinado demuestre la profundidad del conocimiento que tenga sobre un solo tema. En contraste con los reactivos de selección de respuesta y los de construcción de respuesta, como es el de respuesta breve, la pregunta de ensayo no sólo permite el replanteamiento del material aprendido sino también la integración creativa y la expresión del material en palabras propias del examinado. Las habilidades requeridas por los reactivos tipo ensayo son diferentes de las requeridas por reactivos del tipo de falso/verdadero y de relación. Mientras que un ensayo requiere memoria, organización, planeación y capacidad de redacción, los otros tipos de reactivos sólo requieren reconocimiento. Un inconveniente de los reactivos de ensayo es que tienden a enfocarse en un área más limitada que puede cubrirse en el mismo tiempo utilizando una serie de reactivos de selección de respuesta o de completarlas. Otro problema potencial con los ensayos es que hay un grado de subjetividad en la calificación. Un repaso de las ventajas y desventajas de estos formatos de diferentes reactivos, en especial los utilizados en el ambiente académico, se presenta en la tabla 7-1.

Redacción de reactivos para ser administrados por computadora Existe un amplio número de programas de computación disponibles diseñados para facilitar la construcción de pruebas, así como su administración, calificación, e interpretación. Éstos suelen utilizar dos ventajas de CAPA: la capacidad de almacenar reactivos en un banco de datos y la capacidad para individualizar las pruebas a través de una técnica llamada ramificación de reactivos.

Un banco de datos específico para reactivos es un conjunto relativamente grande y accesible de preguntas de prueba. Los maestros que en general imparten una clase particular a veces crean sus bancos de las preguntas que han encontrado útiles en sus exámenes. Una de las muchas ventajas potenciales de un banco de datos de reactivos es la accesibilidad a un gran número de reactivos de prueba convenientemente clasificados por temas u otras variables. Así como en un banco se pueden retirar los fondos, aquí se pueden añadir o retirar reactivos de un banco e, incluso, modificarlos (véase la sección *Close-up* de este capítulo).

El término **administración de pruebas adaptadas a computadora** (Computerized Adaptive Testing, CAT) se refiere al proceso interactivo de administrar pruebas por computadora donde los reactivos presentados al examinado tienen como base el desempeño del examinado en reactivos anteriores. Como en las pruebas administradas tradicionalmente, el examen puede iniciar con una muestra de reactivos de práctica. Sin embargo, la computadora puede impedir que el examinado continúe con la prueba hasta que responda correctamente a los reactivos de práctica y demuestre que ha entendido el procedimiento. Una prueba puede ser diferente para cada examinado, dependiendo del desempeño individual en los reactivos presentados. Por ejemplo, cada reactivo en una prueba de rendimiento puede tener un nivel de dificultad conocido. Este hecho, así como otros datos (tales como la valoración estadística en caso de respuestas por adivinanza) pueden ser integrados cuando llegue el momento de derivar la puntuación final de los reactivos administrados. Observe que no decimos “puntuación final de la prueba” porque lo que constituye la “prueba” es finalmente diferente para los distintos examinados.

Las ventajas de CAT han sido bien documentadas desde hace tiempo (Weiss y Vale, 1987). Sólo una muestra del número total de reactivos de la reserva de éstos es administrada a cada uno de los examinados. Con base en patrones anteriores de respuesta, no se presentan los reactivos que tienen alta probabilidad de ser contestados en una forma particular (correctamente en una

SÓLO PIENSE...

Hay quienes argumentan que si un banco de datos formado por reactivos es lo suficientemente grande, tiene sentido publicarlo antes de la prueba, usted ¿qué opina?

Tabla 7-1

Algunas ventajas y desventajas de ciertos formatos de reactivos

Formato del reactivo	Ventajas	Desventajas
Opción múltiple	- Pueden muestrear una gran cantidad de contenido en relativamente poco tiempo. - Permiten una interpretación precisa y poco “blofeo” más allá de respuestas al azar. Esto, a su vez, puede determinar mayor validez de contenido a la interpretación de la calificación de la prueba que algunos otros formatos. - Puede ser calificada por máquina o computadora.	- No permite la expresión de pensamiento creativo u original. - No todos los temas se prestan para reducir a una y sólo una respuesta considerada como correcta. - Puede consumir mucho tiempo para construir series de buenos reactivos. - Las ventajas de este formato pueden nulificarse si el reactivo está mal redactado o si un patrón de alternativas correctas es discernido por el examinado.
Reactivos de selección binaria (tales como verdadero/falso)	- Puede muestrear gran cantidad de contenido en relativamente poco tiempo. - El generar pruebas con este tipo de reactivos es relativamente fácil en cuanto a construcción y calificación. - Puede ser calificado por máquina o computadora.	- La susceptibilidad de adivinar es alta, en especial para estudiantes con experiencia en pruebas que puedan detectar pistas para rechazar una elección u otra. - Algún tipo de redacción, incluyendo el uso de adverbios como <i>habitualmente</i> o <i>usualmente</i> puede ser interpretado de diferentes maneras por distintos examinados. - Puede ser usado solamente cuando la elección de respuestas dicótomas pueda hacerse sin calificación.
Correspondencia	- Pueden ser usados de manera eficaz y eficiente para evaluar la memoria de evocación o de hechos relacionados en el examinado. - Útil en particular cuando hay gran número de hechos en un solo tema. - Puede ser divertido o como un juego para quienes toman la prueba (en especial para los que están bien preparados). - Puede ser calificada por máquina o computadora.	- Como con otros reactivos del formato de selección de respuesta, los examinados sólo necesitan <i>reconocer</i> una respuesta correcta y no recordarla o proyectarla. - Una de las elecciones puede ayudar a eliminar una de las otras elecciones como la respuesta correcta. - Requiere una reserva de información relacionada y es de menor utilidad con ideas particulares.
De completar o de respuesta breve (llenar el espacio en blanco)	- Provee una amplia área de contenido, sobre todo en preguntas que requieren memorización de datos, puede ser administrada en relativamente corto tiempo. - Este tipo de pruebas es relativamente fácil de construir. - Útil para obtener una idea de lo que el examinado es capaz de generar como opuesto a meramente reconocer, puesto que el examinado debe generar una respuesta.	- Útil sólo con respuestas de una palabra o unas cuantas palabras. - Puede demostrar sólo el recuerdo de hechos circunscritos o fragmentos de conocimiento. - Potencial para problemas de confiabilidad entre calificadores cuando la prueba es calificada por más de una persona. - No puede ser calificada por máquina o computadora.
Ensayo	- Útil para medir respuestas que requieren complejas, imaginativas u originales soluciones o demostraciones. - Útil para medir que tan capaz es el examinado para comunicar sus ideas por escrito. - Requiere que el examinado genere una respuesta completa y no que simplemente la reconozca o suministre una o dos palabras.	- No sirve tan bien como otras pruebas para muestrear un área amplia de contenido. - Un examinado con conocimiento limitado puede intentar “blofear” con respuestas largas, elaboradas y confusas diseñadas para ser lo más ambiguas o amplias posibles. - Calificarlo puede consumir mucho tiempo y está lleno de trampas. - Cuando más de una persona está calificando, puede cuestionarse la confiabilidad entre los calificadores. - Puede depender demasiado de las habilidades de redacción al grado de confundir la capacidad de redactar con lo que pretende medir. - No puede ser calificado por máquina o computadora.

prueba de capacidad) brindando así economía en términos de tiempo de prueba y el número total de reactivos presentados. Se ha encontrado que las pruebas adaptadas a computadora reducen la necesidad de número de reactivos hasta en 50%, a la vez que reducen los errores de medición en 50%.

La capacidad de una computadora para confeccionar el contenido y el orden de presentación de los reactivos de la prueba con base en la respuesta a reactivos anteriores se llama **ramificación de reactivos**. Una computadora puede tener un banco de datos compuesto por reactivos de

Diseño de un banco de reactivos

Desarrollar un banco de datos conformado por reactivos es más laborioso que sólo redactar los reactivos para una prueba. Necesitan resolverse muchas preguntas y problemas en relación al desarrollo de dicho banco además de tener una reserva numérica y satisfactoria de reactivos. Estas preguntas y problemas tienen relación con los reactivos, la prueba, el sistema, el uso para el cual servirá el banco de reactivos y el costo.

I. Reactivos

A. Adquisición y desarrollo

1. ¿Desarrollar y usar su propio banco de reactivos o usar el de otros?
 - a) Si desarrollara su propio banco, ¿qué procedimientos seguiría?
 - b) Si usara el banco de otros, ¿compraría o copiaría los reactivos? ¿El esquema de clasificación está lo suficientemente documentado y las especificaciones del formato del reactivo pueden transferirse y usarse con facilidad?
2. ¿Qué tipo de reactivos serán permitidos?
 - a) ¿El banco incluiría reactivos abiertos y finalizados de (construcción de respuesta), preguntas de opinión, objetivos de instrucción o descripciones de tareas por desempeñar?
 - b) ¿Todos los reactivos estarán hechos para ajustarse a un formato común? (por ejemplo, todas las opciones múltiples con "a", "b", "c" y "d")
 - c) ¿Los reactivos deberán calibrarse, validarse o llevar información adicional?
3. ¿Qué tamaño tendrá el banco de datos conformado por reactivos?
 - a) ¿Cuántos reactivos necesita por objetivo o subtema (profundidad de la colección)?
 - b) ¿Cuántos temas diferentes (amplitud de la colección)?
4. ¿Qué revisión, ensayo y procedimientos de edición usaría?
 - a) ¿Quién hará la revisión y la edición?
 - b) ¿Habrá un campo de ensayo, y si es así, qué estadísticas reunirá y qué criterios usarán para incluir en el banco?

B. Clasificación

1. ¿Cómo se harán las clasificaciones de los temas?
 - a) La clasificación por temas, ¿usará categorías fijas, palabras clave o alguna combinación de ambas?
 - b) ¿Quién será el responsable de preparar, ampliar y refinar la clasificación?
 - c) ¿Qué tan detallada será la clasificación? ¿Será ordenada de manera jerárquica o no?

d) ¿Quién asignará los índices de clasificación a cada reactivo y cómo se verificará esta tarea?

2. ¿Qué otra información asignada acerca de los reactivos se almacenará en el banco de datos?
3. ¿Qué información medida y cuantificada sobre los reactivos se almacenará en el banco? ¿Cómo se calcularán los reactivos medidos?*

C. Administración

1. ¿Se tomarán medidas para realizar actualizaciones de los reactivos y del esquema de calificación? En su caso:
 - a) ¿A quién se le permitirá hacer revisiones, adiciones y eliminaciones?
 - b) ¿Qué procedimientos de revisión se seguirán?
 - c) ¿Cómo se distribuirán los cambios?
 - d) ¿Cómo se detectarán o eliminarán los reactivos duplicados o semejantes?
 - e) ¿Cuándo será poco importante la revisión de un reactivo como para que las estadísticas de una versión anterior puedan agregarse a revisiones de la versión actual?
 - f) ¿Se almacenarán estadísticas de cada uso o del último uso de los reactivos o bien serán agregadas en cada uno de los usos?
2. ¿Cómo se manejarán los reactivos que requieran fotos, imágenes, caracteres diferentes u otro tipo de impresión especial?
3. ¿Cómo se manejarán los reactivos que deben acompañar a otros tales como una serie de preguntas acerca de la lectura de un mismo pasaje?

II. Pruebas

A. Ensemble

1. Los desarrolladores de pruebas, ¿deben señalar los reactivos específicos o éstos serán seleccionados por computadora?
2. Si los reactivos son seleccionados por computadora:
 - a) ¿Cómo se seleccionará un reactivo de entre varios que correspondan a la especificación buscada (al azar, por el tiempo desde su último uso, frecuencia del uso previo)?
 - b) ¿Qué pasaría si ningún reactivo satisficiera las especificaciones?
 - c) ¿El elaborador de pruebas tendría la opción de rechazar un reactivo seleccionado?, y de ser así, ¿cuál sería el mecanismo para hacerlo?
 - d) ¿Qué precauciones se tomarán para asegurar que los examinados que han sido evaluados más de una vez no reciban los mismos reactivos?

* Esta pregunta es objeto de una considerable controversia o discusión en la literatura de medición técnica.

(continúa)

Diseño de un banco de reactivos (continuación)

3. ¿Qué reactivos o parámetros de prueba pueden especificarse para la construcción de la prueba (restricciones de formato de reactivos, límites de los niveles de dificultad, distribución esperada de la puntuación, confiabilidad esperada de la prueba, etcétera)?
 4. ¿Qué procedimientos de construcción estarán disponibles (reactivos de opción múltiple ordenados al azar, diferentes reactivos para cada prueba)?
 5. ¿El sistema imprimirá las pruebas o sólo especificará qué reactivos usar? Si las imprime, ¿cómo las imprimirá o duplicará y dónde se mostrarán las respuestas?
- B. *Administración, calificación y reporte*
1. ¿El sistema será capaz de administrar pruebas en línea? De ser así:
 - a) ¿Cómo se manejará el acceso a ellas?
 - b) ¿La administración de la prueba será adaptado según las necesidades?, y si es así, ¿qué procedimientos se usarán para ello?
 2. ¿El sistema proveerá los mecanismos para la puntuación de la prueba? Si es así:
 - a) ¿Qué fórmula de puntuación empleará (sólo las correctas, corrección para las conjeturadas, crédito parcial para algunas respuestas, ponderación para discriminación de valores)?
 - b) ¿Cómo serán evaluados los reactivos de construcción de respuesta (en línea, fuera de línea, por los examinadores, comparando las respuestas con una guía de claves o en línea por computadora, utilizando o no un algoritmo ortográfico)?
 3. ¿El sistema proporcionará un reporte de la prueba? De ser así:
 - a) ¿Qué registros se llevarán (las pruebas mismas, las respuestas individuales de los estudiantes, las calificaciones individuales de las pruebas, por escuela o la calificación de otros grupos) y por cuánto tiempo se podrá acceder a ellas? ¿Las nuevas puntuaciones de individuos y de grupos reemplazarán o complementarán las calificaciones anteriores?
 - b) ¿Qué opciones de reporte (contenido y formato) estarán disponibles?
 - c) ¿A quién se enviarán los reportes?
- C. *Evaluación*
1. ¿Se recolectarán los datos de confiabilidad y validez? Si es así, ¿qué datos serán recolectados, por quién y cómo se usarán?
 2. ¿Qué normas estarán disponibles? De ser así, ¿con base en qué medidas de referencia a una norma?
- III. Sistema
- A. *Adquisición y desarrollo*
1. ¿Quién será responsable de su adquisición y desarrollo, con qué recursos y bajo qué restricciones operará?
 2. ¿El sistema será operable en otros sistemas? ¿Qué niveles y clasificaciones de documentación estarán disponibles?
- B. *Software y hardware*
1. ¿Qué aspectos del sistema serán asistidos por computadora?
 - a) ¿Dónde se almacenarán los datos (en computadora, en papel, tarjetas de archivo)?
 - b) ¿Las solicitudes serán llenadas en serie, en línea o en forma manual?
 2. ¿Se usará una microcomputadora?, de ser así, ¿qué límites especiales establece esta opción en el texto de los reactivos, en el tamaño del banco de reactivos y las opciones de desarrollo de la prueba?
 3. ¿Los reactivos se almacenarán como una gran colección o se mantendrán archivos separados para cada usuario?
 4. ¿Cómo se construirá el sistema de almacenamiento de los reactivos (a partir de cero o juntando diversos programas como un procesador de palabras, un administrador de bases de datos u otros programas con objetivos generales; adoptando sistemas de almacenamiento existentes)?
 5. ¿Qué equipo será necesario (para almacenar, recuperar e interactuar con el sistema, etcétera)?
 6. ¿Qué tan favorables serán el equipo y los programas de apoyo para el usuario y para el mantenimiento?
 7. ¿Quién será el responsable del mantenimiento del equipo?
- C. *Monitoreo y entrenamiento*
1. ¿Qué características del sistema serán monitoreadas (número de reactivos por categoría de clasificación, uso por grupo de usuarios, número de revisiones hasta que un usuario esté satisfecho, distribución de longitudes de prueba u otras características)?
 2. ¿Quién monitoreará el sistema, entrenará a los usuarios y dará soporte técnico (al inicio y sobre la marcha)?
 3. ¿Cómo se distribuirá la información sobre los cambios de procedimiento en el sistema?
- D. *Acceso y seguridad*
1. ¿Quién tendrá acceso a los reactivos y otra información en el banco (autores/propietarios, maestros, estudiantes)? ¿Quién podrá solicitar pruebas?
 2. ¿Los usuarios tendrán acceso directo al sistema o tendrán que hacerlo a través de un intermediario?

3. ¿Qué procedimientos se seguirán para asegurar el contenido del banco de reactivos (si se desea que éstos estén seguros)?
 4. ¿Dónde se almacenará el contenido del banco (de manera central o cada usuario tendrá una copia)?
 5. ¿Quién tendrá acceso a los reportes de calificación?
- IV. Uso y aceptación
- A. *General*
1. ¿Quién decide a que usos se destinará el banco de datos constituido por reactivos? ¿Estos usos serán los que los usuarios de las pruebas quieren y necesitan?
 2. ¿Quién desarrollará las pruebas y a quién se le permitirá usar el sistema? ¿Estas personas serán aceptables para los examinados y receptores de la información de las pruebas?
 3. ¿El sistema podrá manejar la demanda de uso esperada?
 4. ¿Los resultados del sistema serán adecuados para usarse y serán usados como fue planeado?
 5. ¿Cómo se aumentará la aceptación y credibilidad del banco de datos formado por reactivos?
- B. *Mejora de instrucciones*. Si éste es el uso pensado:
1. ¿El banco de reactivos será parte de un sistema más amplio de instrucción o de toma de decisiones?
 2. ¿Qué libros de texto, directrices de currículo y otros materiales se relacionarán por clave al banco de reactivos? ¿Quién tomará esa decisión y cómo se validarán las asignaciones?
 3. ¿Qué reactivos estarán disponibles para ejercicios y pruebas?
 4. ¿La información estará disponible para los usuarios que ayudarán en el diagnóstico de las necesidades educativas?
- C. *Pruebas adaptativas*. Si ésta es una opción:
1. ¿Cómo se programarán las administraciones de pruebas?
 2. ¿Cómo se seleccionarán los reactivos para asegurar la eficiencia de las pruebas y aún seguir manteniendo la representación de contenido y evitar la duplicidad entre administración de pruebas sucesivas?
 3. ¿Qué criterios se usarán para terminar las pruebas?
 4. ¿Qué procedimientos de calificación se usarán?
- D. *Certificación de competencia*. Si éste es un uso intencional:
1. ¿El banco de datos contendrá medidas para cubrir todos los componentes de las habilidades importantes de la competencia que es evaluada?
 2. ¿Cuántos intentos se permitirán para pasar la prueba? ¿Cuándo? ¿Cómo se monitorearán?
- E. *Programa y evaluación de currículo*. Si éste es un uso intencional:
1. ¿Será posible implementar un sistema que proporcione medidas confiables de los logros de los estudiantes en un gran número de áreas específicas de desempeño?
 2. ¿El banco de reactivos contendrá medidas que cubran todos los objetivos importantes establecidos por el currículo?
 3. ¿El banco de reactivos producirá datos conmensurables que permitan comparaciones válidas a través del tiempo?
- F. *Requerimientos de prueba y reportes impuestos por agencias externas*. Si la reunión de dichos requerimientos son intencionales:
1. ¿El sistema será capaz de manejar los requerimientos para un programa de evaluación, selección de estudiantes para programas con financiamiento especial, evaluación de necesidades educativas y su reporte?
 2. ¿El sistema podrá acomodar modificaciones menores en los requerimientos de pruebas y reportes?
- V. Costos
- A. *Factibilidad de costos*
1. ¿Cuáles son los costos (fijos y variables; financieros, de tiempo, espacio, equipo, y suministros) para crear y mantener el sistema?
 2. ¿Son asequibles estos costos?
- B. *Comparación de costos*
1. ¿Cómo se comparan los costos del sistema del banco de reactivos con los de otros sistemas de prueba que alcanzan las mismas metas?
 2. ¿La ampliación de capacidades justifica el costo adicional? ¿La restricción de capacidades está equilibrada con el ahorro de costos?

Fuente: Millman y Arter (1984).

prueba de rendimiento con distintos niveles de dificultad. Puede programarse para presentar reactivos de acuerdo a alguna regla. Por ejemplo, una regla podría ser no presentar un reactivo del siguiente nivel de dificultad hasta que dos reactivos consecutivos del nivel previo hayan sido contestados correctamente. Otra regla podría ser terminar la prueba cuando se hayan contestado de manera incorrecta cinco reactivos consecutivos con cierto nivel de dificultad. De manera alternativa, el patrón de reactivos a los cuales se expone al examinado puede basarse no sólo en la respuesta a los reactivos precedentes, sino también a un registro aleatorio de la reserva total de los reactivos de prueba. La presentación al azar de reactivos reduce la facilidad con la que los examinados pueden memorizar reactivos para dárselos a otros futuros examinados.

La tecnología para la ramificación de reactivos no sólo puede aplicarse en la elaboración de pruebas de rendimiento, sino también en pruebas de personalidad. Por ejemplo, si un examinado contesta a un reactivo a manera que sugiera que está deprimido, la computadora puede explorar en forma automática síntomas y comportamientos relacionados con la depresión. El siguiente reactivo presentado puede estar diseñado para indagar los patrones de sueño del examinado o la existencia de ideaciones suicidas.

La tecnología para la ramificación de reactivos puede usarse en pruebas de personalidad para reconocer respuestas imprecisas o inconsistentes. Por ejemplo, en una prueba computarizada de falso o verdadero, si el examinado responde *verdadero* a un reactivo como, *El año pasado celebré la Navidad en Beirut*, habría razón para sospechar que el examinado está respondiendo de manera imprecisa, al azar, o de alguna otra forma no auténtica. Y si más adelante el mismo examinado responde falso a un reactivo idéntico en la prueba, podemos deducir que es inconsistente. Si la computadora reconoce un patrón indeterminado de respuestas puede programarse para que se responda de manera precisa, por ejemplo, advirtiéndole al examinado que responda con más cuidado o incluso negándose a continuar hasta obtener una respuesta coherente.

SÓLO PIENSE...

Intente redactar un par de reactivos falso/verdadero que podrían ser usados para detectar respuestas imprecisas o al azar en una prueba de personalidad.

Calificación de reactivos

Se han elaborado muchos modelos diferentes de calificación de pruebas. En las pruebas psicológicas, el modelo acumulativo es el más común, quizá debido a su lógica y simplicidad. Generalmente, la regla en una prueba calificada en forma acumulativa es que entre mayor sea la puntuación en la prueba, mayor es el dominio del examinado en la capacidad, rasgo o alguna otra característica que pretenda medir la prueba. Por cada respuesta de esa persona a reactivos determinados hecha en una forma particular, acumula mayor crédito respecto a un constructo particular.

En pruebas que emplean una clase o categoría de calificación, las respuestas del evaluado le otorgan un crédito para ubicarlo en una clase o categoría particular en relación con otros examinados cuyos patrones de respuesta se presume son semejantes de alguna manera. Este enfoque se usa en algunos sistemas de diagnóstico, en donde los individuos deben exhibir una determinada cantidad de indicios para calificar por un diagnóstico específico. Un tercer modelo de calificación, la calificación ipsativa, se aparta radicalmente dentro de lo razonable tanto del modelo acumulativo como del de clase. Un objetivo típico en la calificación ipsativa es la comparación de la puntuación de un examinado en una escala dentro de una prueba con otra escala dentro de esa misma prueba.

Considere, por ejemplo, una prueba de personalidad llamada Inventario de preferencias personales de Edwards (*Edwards Personal Preference Schedule*; EPPS), que fue diseñada para medir la intensidad relativa de diferentes necesidades psicológicas. El sistema de calificación ipsativa de la EPPS provee información sobre la intensidad de varias necesidades en relación con la intensidad de otras necesidades de quien responde. La prueba no proporciona información acerca de la intensidad de las necesidades de un examinado en relación con la intensidad supuesta de esa

necesidad en la población general. Edwards construyó su prueba con 210 pares de afirmaciones de tal forma que los evaluados se ven obligados a contestar *verdadero o falso* o *sí o no* a una sola de las dos afirmaciones. Una investigación anterior de Edwards indicaba que las dos afirmaciones son equivalentes en términos de qué tan socialmente deseables sean las respuestas. He aquí el ejemplo de un reactivo de selección forzada tipo EPPS, al cual quienes responden deben indicar qué es más cierto para ellos:

Me siento deprimido cuando fallo en algo.

Me siento nervioso cuando hablo ante un grupo.

Con base en este tipo de prueba de personalidad calificada de manera ipsativa, sería posible obtener sólo conclusiones intraindividuales acerca del examinado. He aquí un ejemplo: “La necesidad de logro de Juan es mayor que su necesidad de adhesión”. No sería apropiado inferir comparaciones interindividuales con base en una prueba calificada de modo ipsativo. Sería inapropiado, por ejemplo, comparar a dos examinados con una afirmación como “La necesidad de logro de Juan es mayor que la necesidad de logro de Juana”.

Una vez que el elaborador de pruebas se ha decidido sobre un modelo de calificación y ha hecho todo lo necesario para tener listo el primer borrador para su administración, el paso siguiente es el ensayo.

Ensayo de la prueba

Habiendo creado una reserva de reactivos a partir de la cual se elaborará la versión final de la prueba, el elaborador la pondrá a prueba. La prueba debe ser probada con personas similares en aspectos críticos a la gente para la que fue diseñada. De esta manera, por ejemplo, si una prueba está diseñada para ayudar en las decisiones respecto a la selección de empleados corporativos con potencial ejecutivo en un determinado nivel, sería apropiado probarla con empleados corporativos del nivel al cual está dirigida.

De igual importancia es la cuestión respecto al número de personas sobre quienes será probada. Un principio general no formal es que no deberían ser menos de cinco sujetos, de preferencia hasta diez para cada reactivo contemplado en la prueba. En general, entre más sujetos se tengan, será mejor para probarla. Un riesgo definitivo al usar pocos sujetos durante la probanza de la prueba surge durante el análisis factorial de los resultados, cuando pueden emerger lo que podríamos llamar *factores fantasmas* —factores inexistentes que en realidad son consecuencia del tamaño pequeño de la muestra—.

La probanza de la prueba deberá llevarse a cabo bajo condiciones lo más idénticas posible a las condiciones bajo las cuales la prueba estandarizada será administrada; todas las instrucciones, desde los límites de tiempo asignados para completar la prueba hasta la atmósfera en el sitio de su aplicación, deberán ser lo más parecidos posible. Como lo expresó Nunnally (1978, p. 279) de manera tan apropiada: “Si los reactivos para un inventario de personalidad son aplicados en una atmósfera que fomente la franqueza y la prueba final fuera administrada en una atmósfera donde los sujetos sean reacios a decir cosas negativas de sí mismos, el análisis de los reactivos reflejará una historia defectuosa”. En general, el elaborador de la prueba se esfuerza por asegurar que las diferencias en las respuestas a los reactivos se deban de hecho a los reactivos, no a factores extraños.

En el capítulo 4 tratamos en detalle la importante pregunta “¿Qué es una buena prueba?” Ahora parece un buen momento para plantear una pregunta relacionada.

SÓLO PIENSE...

Qué tan apropiado sería probar esta prueba en una muestra conveniente de estudiantes de psicología de nuevo ingreso.

¿Qué es un buen reactivo?

En el mismo sentido en que una buena prueba es confiable y válida, podemos decir que un buen reactivo de prueba es confiable y válido. Además, un buen reactivo de prueba ayuda a diferenciar a los examinados, es decir, un buen reactivo de prueba es aquel que otorga una calificación alta como un total correcto obtenido. Un reactivo que otorga una calificación alta como un total correcto no obtenido probablemente no sea un buen reactivo. También podemos describir un buen reactivo de prueba como uno que da una calificación baja como un total correcto obtenido. Un

reactivo que otorga bajas calificaciones como un total correcto conseguido tal vez no sea un buen reactivo.

¿Cómo identifica los buenos reactivos quien elabora la prueba? Después de que el primer borrador de la prueba ha sido aplicado sobre un grupo representativo de examinados, el desarrollador de la prueba analiza las puntuaciones y las respuestas a reactivos individuales. A los diferentes tipos de escrutinio estadístico que pueden sufrir de manera potencial los datos de la prueba en este punto se les conocen en forma colectiva como **análisis de reactivos**. Obsérvese que aunque el análisis de reactivos tiende a considerarse como una tarea cuantitativa, puede ser también cualitativa, como veremos.

SÓLO PIENSE...

Bien, haga un poco más que pensar: *redacte* un buen reactivo en cualquier formato, junto con una breve explicación de por qué cree usted que es un buen reactivo. El reactivo será para una nueva prueba que está usted desarrollando llamada Prueba de la historia de Estados Unidos para ser administrada a estudiantes de segundo de secundaria.

Análisis de reactivos

Los procedimientos estadísticos utilizados para analizar los reactivos pueden volverse bastante complejos y el tratamiento que daremos a este tema deberá considerarse sólo como introductorio. Revisaremos en forma breve algunos procedimientos usados por los elaboradores de pruebas en sus esfuerzos por seleccionar los mejores reactivos de una reserva de reactivos ensayados. Los criterios acerca de los mejores reactivos pueden diferir en función de los objetivos del elaborador de la prueba. De esta manera, por ejemplo, quien diseña las pruebas podría considerar que los mejores reactivos son aquellos que contribuyen en forma óptima a la confiabilidad interna de la prueba. Otro elaborador de pruebas podría querer diseñar una prueba con la mayor validez posible relacionada con un criterio y seleccionar sus reactivos en consecuencia. Entre las herramientas que podrían emplear los elaboradores de pruebas para analizar y seleccionar reactivos se encuentran:

SÓLO PIENSE...

Aplice estas estadísticas de análisis de reactivos en una prueba de personalidad. Haga traducciones de la fraseología en tanto piensa acerca de cómo las estadísticas tales como un índice de dificultad de reactivo o como un índice de validez pueden ser usados para ayudarlo a identificar los mejores reactivos, no para una prueba de rendimiento, sino para una de personalidad.

- índice de la dificultad del reactivo
- índice de la confiabilidad del reactivo
- índice de la validez del reactivo
- índice de la diferenciación de un reactivo

Suponga por un momento que llevó a cabo el ejercicio previo de *Sólo piense...* y ahora es usted el orgulloso autor de 100 reactivos para una Prueba de la historia de Estados Unidos (PHEU) para alumnos de segundo de secundaria y que posteriormente esta prueba (borrador) de 100 reactivos se aplicó en 100 alumnos de segundo de secundaria. Esperando a la larga estandarizar la prueba y distribuirla por medio de un editor

comercial de pruebas, usted tiene una meta más inmediata a corto plazo: seleccionar los 50 mejores reactivos de los 100 que creó originalmente. ¿Cómo podría lograr esta meta a corto plazo? Como veremos, la respuesta se encuentra en los procedimientos de análisis de reactivos.

Índice de dificultad del reactivo

Suponga que todos los examinados tuvieron correcto el reactivo 1 de la PHEU. ¿Podríamos decir que el reactivo 1 es bueno? ¿Y si nadie tuviera correcto el reactivo 1? En cualquier caso, el reactivo

1 no sería un buen reactivo. Si todos tuvieran correcto el reactivo, éste sería demasiado fácil. Si todos lo tuvieron mal, es porque el reactivo es demasiado difícil. Del mismo modo que la prueba entera está diseñada para proporcionar un índice del grado de conocimiento sobre la historia estadounidense, así cada reactivo deberá ser aprobado de forma individual (calificado como correcto) o reprobado (calificado como incorrecto) en base al conocimiento diferencial sobre historia estadounidense de quienes responden la prueba.⁴

Un índice de la dificultad de un reactivo se obtiene calculando la proporción del número total de quienes respondieron la prueba que tuvieron correcto el reactivo. Se usa una *p* cursiva minúscula (*p*) para denotar la dificultad del reactivo y un subíndice hace referencia al número de reactivo (p_1 se lee “índice de dificultad de, y para, el reactivo 1”). Desde un punto de vista teórico, el valor del índice de dificultad de un reactivo puede variar de 0 (si nadie lo tuvo correcto) a 1 (si todos lo tuvieron). Si 50 de los 100 examinados tuvieron correcto el reactivo 2, entonces el índice de dificultad del reactivo sería igual a 50 dividido entre 100, o .5 ($p_2 = .5$). Si 75 de los examinados tuvieron correcto el reactivo 3, p_3 sería igual a .75 y podríamos decir que el reactivo 3 fue más fácil que el 2. Observe que entre mayor es el índice de dificultad del reactivo éste es más fácil. Debido a que *p* se refiere al porcentaje de personas que responden correctamente a un reactivo, entre mayor sea *p* para un reactivo, más fácil será éste. En estadística, aquello conocido como **índice de dificultad del reactivo** en el contexto de las pruebas de rendimiento en otros contextos puede ser un **índice de aprobación del reactivo**, como es el caso de las pruebas de personalidad. Aquí, la estadística no proporciona una medida del porcentaje de personas que aprueban el reactivo, sino una medida del porcentaje de personas que dijeron sí, que estuvieron de acuerdo con él o que de alguna otra manera lo aprobaron.

Podemos calcular un índice promedio de la dificultad de los reactivos para una prueba en particular al promediar los índices de dificultad de cada reactivo con todos los reactivos de la prueba. Esto se logra sumando los índices de dificultad de cada reactivo y dividiendo la suma entre el número total de reactivos que constituyen la prueba. Para obtener una diferenciación máxima entre las capacidades de quienes responden la prueba, la dificultad promedio óptima de los reactivos es aproximadamente .5, con una variación de dificultad individual entre los reactivos de la prueba de .3 a .8. Observe, sin embargo, que es importante tomar en cuenta el posible efecto que puede tener el adivinar al considerar reactivos de la variedad de selección de respuesta. En este tipo de reactivos, la dificultad promedio óptima es, por lo general, el punto medio entre 1.00 y la proporción de probabilidad de éxito al responder al azar, definida como la probabilidad de responder correctamente cuando se utiliza el azar. En un reactivo verdadero/falso, la probabilidad de adivinar en forma correcta sólo en base al azar es de 1/2, o .50. Por consiguiente, la dificultad óptima del reactivo está en el punto intermedio entre .50 y 1.00 o .75. En general, el punto medio que representa la dificultad óptima del reactivo se obtiene sumando la proporción del éxito al azar y 1.00 y luego dividiendo la suma entre 2 o

$$.50 + 1.00 = 1.5$$

$$\frac{1.5}{2} = .75$$

Para un reactivo de opción múltiple con cinco opciones, la probabilidad de adivinar en forma correcta en cualquier reactivo con base sólo en el azar es igual a 1/5 o .20. Por consiguiente, la dificultad óptima del reactivo es .60:

$$.20 + 1.00 = 1.20$$

$$\frac{1.20}{2} = .60$$

4. Una excepción aquí puede ser un **reactivo intencionalmente revelado**. Un reactivo como éste podría insertarse casi al principio de una prueba de rendimiento para alentar la motivación y actitud positiva en los examinados, así como para disminuir su ansiedad en relación con la prueba. En general, sin embargo, si el análisis de los reactivos sugiere que un reactivo en particular es demasiado fácil o demasiado difícil, dicho reactivo debe ser reescrito o descartado.




Figura 7-4
Maximizando la confiabilidad de consistencia interna

(Fuente: Allen y Yen, 1979)

Índice de confiabilidad del reactivo

El **índice de confiabilidad del reactivo** proporciona un indicio de la **consistencia interna** de una prueba (figura 7-4); **entre mayor sea este índice, mayor será la consistencia interna**. Este índice es igual al producto de la desviación estándar de la puntuación del reactivo (s) y la correlación (r) entre la puntuación del reactivo y la puntuación total de la prueba.

Análisis factorial y consistencia entre reactivos Una herramienta estadística útil para determinar si los reactivos de una prueba parecen medir el mismo o los mismos objetos es la técnica del análisis del factor. **Mediante el uso razonable del análisis del factor, los reactivos que no están “cargados” con el elemento para el que fueron redactados (es decir, aquellos que no parecen estar midiendo lo que fueron diseñados para medir) pueden ser revisados o eliminados.** Si muchos de ellos parecen estar tocando un área particular, pueden eliminarse los más débiles. Además, el análisis del factor puede ser útil en el proceso de interpretación de la prueba, en especial cuando se compara la constelación de respuestas con los reactivos de dos o más grupos. De este modo, por ejemplo, si una prueba de personalidad particular es aplicada a dos grupos de pacientes psiquiátricos hospitalizados, cada uno con un diagnóstico diferente, podrá descubrirse que los mismos reactivos cargan factores diferentes en los dos grupos. Esta información obligará al responsable de la elaboración de la prueba a revisar o eliminar ciertos reactivos o a describir los hallazgos diferenciales en el manual.

Índice de validez del reactivo

El **índice de validez del reactivo** es una estadística diseñada para dar una indicación del grado en el que una prueba mide lo que se supone debe medir; **mientras mayor sea el índice de validez del reactivo, mayor será la validez en relación al criterio de la prueba.** El índice de validez del reactivo puede ser calculado una vez que se conocen las siguientes dos estadísticas:

- la desviación estándar de la puntuación del reactivo
- la correlación entre la puntuación del reactivo y la puntuación criterio




Figura 7-5
Maximizando la validez relacionada con el criterio

(Fuente: Allen y Yen, 1979)

La desviación estándar de la puntuación del reactivo para el reactivo 1 (denotada con el símbolo s_1) puede calcularse usando el índice de dificultad del reactivo (p_1) en la siguiente fórmula:

$$s_1 = \sqrt{p_1(1 - p_1)}$$

La correlación entre la puntuación en el reactivo 1 y una puntuación en la medida criterio (denotada con el símbolo r_{1C}) se multiplica por la desviación estándar de la puntuación del reactivo para el reactivo 1 (s_1) y el producto es igual al índice de la validez de un reactivo ($s_1 r_{1C}$). El cálculo del índice de validez del reactivo será importante cuando la meta del elaborador sea maximizar la validez de la prueba en relación con un criterio. Puede lograrse una representación visual de los mejores reactivos en una prueba trazando una gráfica del índice de validez y de confiabilidad para cada uno de ellos (si el objetivo es maximizar la validez relacionada con un criterio) figura 7-5.

Índice de discriminación de reactivos

Las medidas de discriminación de reactivos indican qué tan adecuadamente separa o diferencia un reactivo entre quienes obtienen puntuaciones altas y quienes obtienen puntuaciones bajas en una prueba completa. En este contexto, un reactivo de opción múltiple en una prueba de rendimiento es un buen reactivo si la mayoría de los que obtienen puntuaciones altas lo responden en forma correcta y la mayoría de los que obtienen puntuaciones bajas lo hacen en forma incorrecta. Si la mayoría de los que obtienen puntuaciones altas fallan en un reactivo particular, estas personas puedan estar haciendo una interpretación alternativa de una respuesta que se pretende sirva como distractor. En tal caso, el elaborador de la prueba haría bien en entrevistar a los examinados para entender mejor la base para la elección y luego de manera apropiada revisar (o eliminar) el reactivo. El sentido común dicta que un reactivo en una prueba de rendimiento no está haciendo su trabajo si es respondido en forma correcta por quienes entienden menos la materia. Del mismo modo, un reactivo en una prueba que pretende medir un rasgo de personalidad particular no está haciendo su trabajo si las respuestas indican que las personas que, por ejemplo, obtienen puntuaciones muy bajas en la prueba en su totalidad (lo que indicaría una ausencia de o bajos niveles del rasgo en cuestión) tienden a obtener una puntuación muy alta en el reactivo (lo que indica que están muy altos en ese rasgo, contrario a lo que indica la prueba total).

Tabla 7-2
Índices de diferenciación de reactivos para cinco reactivos hipotéticos

Reactivo	<i>S</i>	<i>I</i>	<i>S-I</i>	<i>n</i>	$d[(S-I)/n]$
1	20	16	4	32	.13
2	30	10	20	32	.63
3	32	0	32	32	1.00
4	20	20	0	32	0.00
5	0	32	-32	32	-1.00

El **índice de diferenciación de reactivos** es una medida de distinción de preguntas simbolizada por una letra cursiva minúscula *d* (*d*). Esta estimación de la diferenciación del reactivo, en esencia, compara el desempeño de un reactivo particular con el desempeño de las regiones superior e inferior de una distribución continua de puntuaciones de la prueba. Las líneas límite óptimas para demarcar a lo que nos referimos como áreas “superior” e “inferior” de una distribución de puntuaciones son las puntuaciones dentro del 27% superior e inferior del total de la distribución de puntuaciones, a condición de que la distribución sea normal (Kelley, 1939). Conforme la distribución de puntuaciones de prueba se vuelve más platicúrtica (plana), la línea óptima para definir los límites de las áreas superior e inferior se hace mayor y se aproxima al 33% (Cureton, 1957). Allen y Yen (1979, p. 122) nos aseguran que “para la mayor parte de las aplicaciones, cualquier porcentaje entre 25 y 33 producirá estimaciones similares”.

El índice de diferenciación de reactivos es una medida de la diferencia entre la proporción de altos puntajes obtenidos al contestar un reactivo correctamente y la proporción de bajos puntajes al contestar también correctamente el reactivo; entre mayor sea el valor de *d*, mayor será el número de puntuaciones altas al responder el reactivo correctamente. Un valor *d* negativo en un reactivo en particular es una bandera roja pues indica que los examinados que obtienen puntuaciones bajas tienen mayor probabilidad de responder el reactivo en forma correcta que los que obtienen puntuaciones altas. Esta situación exige alguna acción tal como sería la revisión del reactivo o su eliminación.

Suponga que un maestro de historia aplicó una prueba sobre la historia estadounidense a un total de 119 estudiantes que estaban a semanas de completar segundo de secundaria. El maestro aisló 27% superior (*S*) e inferior (*I*) de los exámenes respondidos con un total de 32 documentos en cada grupo. Los datos y los índices de diferenciación de reactivos asignados al reactivo 1 y al 5 se presentan en la tabla 7-2. Observe que 20 de las personas que respondieron la prueba en el grupo *S* respondieron el reactivo 1 en forma correcta y 16 de las personas en el grupo *I* lo respondieron en forma correcta. Con un índice de discriminación de reactivos igual a .13, es probable que el reactivo 1 sea un reactivo razonable debido a que más integrantes del grupo *S* que del grupo *I* lo respondieron en forma correcta. Entre mayor sea el valor de *d*, más adecuada será la diferenciación que hace el reactivo entre quienes obtienen puntuaciones altas y quienes obtienen puntuaciones bajas. Por esta razón, el reactivo 2 es un reactivo mejor que el reactivo 1; su índice de discriminación es .63. El valor más alto posible de *d* es +1.00. Este valor indica que todos los miembros del grupo *S* respondieron el reactivo en forma correcta y todos los miembros del grupo *I* lo hicieron de manera incorrecta.

Si la misma proporción de miembros del grupo *S* y del *I* aprueban el reactivo, éste no se encuentra en absoluto diferenciando entre los evaluados y *d*, de manera bastante apropiada, sería igual a 0. El valor más bajo que puede tomar un índice de discriminación de reactivos es -1. Una *d* igual a -1 es una pesadilla para el elaborador de pruebas. Indica una situación donde todos los miembros del grupo *S* fallaron en el reactivo y todos los miembros del grupo *I* lo pasaron. Frente a esta situación, un reactivo así es del peor tipo posible y necesita con urgencia una revisión o su eliminación. Sin embargo, de una investigación posterior de este hallazgo no previsto, el diseñador de la prueba podría aprender o descubrir algo nuevo acerca del constructo que se está midiendo.

Análisis de alternativas de reactivo La calidad de cada alternativa dentro de un reactivo de opción múltiple puede evaluarse con facilidad en relación al desempeño comparativo de quienes obtienen puntuaciones superiores e inferiores. Aquí en realidad no son necesarias fórmulas ni es-

tadísticas. Elaborando una tabla del número de examinados en los grupos *S* e *I* que eligieron cada alternativa, el elaborador de la prueba puede tener idea de la efectividad de un distractor por medio de una simple “mirada a ojo de buen cubero”. Para ilustrarlo, analizaremos las respuestas a cinco reactivos en una prueba hipotética, asumiendo que hubo 32 puntuaciones en el nivel superior (*S*) de la distribución y 32 en el inferior (*I*) de la distribución. Comencemos por observar el patrón de respuestas al reactivo 1. En cada caso, ★ denota la alternativa correcta.

Reactivo 1	Alternativas				
	★a	b	c	d	e
<i>S</i>	24	3	2	0	3
<i>I</i>	10	5	6	6	5

El patrón de respuestas al reactivo 1 indica que es bueno. Respondieron el reactivo en forma correcta más integrantes del grupo *S* que del *I* y cada uno de los distractores atrajo a algunos de los evaluados.

Reactivo 2	a	b	c	d	★e
<i>S</i>	2	13	3	2	12
<i>I</i>	6	7	5	7	7

El reactivo 2 indica una situación en la que una cantidad relativamente grande de miembros del grupo *S* eligieron una opción distractora particular (en este caso, “b”). Probablemente este reactivo podría ser mejorado en la revisión, de preferencia después de una entrevista con algunos o todos los estudiantes del grupo *S* que eligieron “b” como respuesta.

Reactivo 3	a	b	★c	d	e
<i>S</i>	0	0	32	0	0
<i>I</i>	3	2	22	2	3

El reactivo 3 indica un patrón más deseable de respuestas de los estudiantes. Todos los miembros del grupo *S* respondieron el reactivo en forma correcta y cada distractor atrajo a uno o más miembros del grupo *I*.

Reactivo 4	a	★b	c	d	e
<i>S</i>	5	15	0	5	7
<i>I</i>	4	5	4	4	15

El reactivo 4 es más difícil que el 3 —menos examinados lo respondieron en forma correcta—. Aún así, este reactivo proporciona información útil sobre la diferenciación pues distingue en forma efectiva a los examinados que obtienen puntuaciones altas de aquellos que obtienen bajas. Por alguna razón, una de las alternativas (“e”) fue efectiva en particular como distractor, quizá demasiado, para los estudiantes en el grupo de puntuaciones bajas. El creador de pruebas podría desear explorar más a fondo por qué sucedió esto.

Reactivo 5	a	b	c	★d	e
<i>S</i>	14	0	0	5	13
<i>I</i>	7	0	0	16	9

El reactivo 5 es malo pues más miembros del grupo *I* que del *S* lo respondieron en forma correcta. Además, ninguno de los examinados eligió los distractores “b” o “c”.

Características del reactivo

Podemos hacer una representación gráfica de la dificultad y diferenciación en una **curva característica del reactivo (CCR)**. Como se muestra en la figura 7-6, una CCR es una gráfica en la que la capacidad se traza en el eje horizontal y la probabilidad de una respuesta correcta, en el eje




Figura 7-6
Algunos ejemplos de curvas características de los reactivos

(Fuente: Ghiselli *et al.*, 1981)

Para simplificar hemos omitido los valores de las escalas en los ejes. El eje vertical en esta gráfica muestra la probabilidad de respuesta correcta en valores que van de 0 a 1. Los valores para el eje horizontal que simplemente hemos llamado “capacidad” son las puntuaciones totales de la prueba. En otras fuentes usted podrá encontrar el eje vertical de una curva característica del reactivo etiquetada con algo así como “proporción de examinados que respondieron correctamente al reactivo” y el eje horizontal llamado “puntuación total de la prueba”.

vertical. Observe que la medida en que un reactivo diferencia a los examinados que obtienen puntuaciones altas de aquellos que obtienen puntuaciones bajas es aparente desde la pendiente de la curva; entre más inclinada sea la pendiente, mayor será la diferenciación del reactivo. También observe que si la pendiente es positiva, más personas que obtienen puntuaciones altas tienen correcto el reactivo a diferencia de quienes obtienen puntuaciones bajas; si la pendiente fuese negativa, sucedería lo contrario.

Ahora enfoquémonos en la curva característica del reactivo A ¿Usted piensa que éste es un buen reactivo? La respuesta es que no lo es. La probabilidad de que el examinado tenga una respuesta correcta es alta para quienes tienen baja capacidad y menor para quienes tienen capacidad alta. Qué hay del reactivo B, ¿será un buen reactivo? Una vez más, la respuesta es no. La curva nos dice que los examinados con capacidad moderada tienen la mayor probabilidad de responder el reactivo en forma correcta; los evaluados con la mayor capacidad —así como sus contrapartes en el otro extremo del espectro de capacidad— es poco probable que respondan de manera correcta a este reactivo. El reactivo B puede ser uno de esos en los que es probable que las personas que saben mucho o piensan demasiado respondan en forma incorrecta.

El reactivo C es un buen reactivo. La probabilidad de responderlo en forma correcta se incrementa con la capacidad. ¿Qué hay del reactivo D? Esta curva característica del reactivo perfila un reactivo el cual sólo discrimina en un punto específico dentro del continuo de la capacidad. La probabilidad de que los evaluados respondan en forma correcta al reactivo en este punto o por encima de él es muy alta. También podemos decir que es muy alta la probabilidad de una respuesta incorrecta para quienes caen por debajo de ese punto de capacidad en particular. Un reactivo como el D tiene una excelente capacidad para diferenciar y sería útil en una prueba diseñada, por ejemplo, para seleccionar aspirantes con base en alguna calificación límite. Sin embargo, un reactivo así podría no ser deseable en una prueba diseñada para proporcionar información detallada sobre la capacidad del examinado a lo largo de todos los niveles de capacidad. Éste podría ser el caso, por ejemplo, en un diagnóstico de lectura o en una prueba de aritmética.

Teoría de respuesta al reactivo Como recordará cuando hablamos de la teoría de respuesta al reactivo (IRT) en el capítulo 5, IRT no es una sola teoría; más bien se refiere a un número de modelos de desarrollo de pruebas, a los que de manera colectiva se les conoce por nombre como *Teoría del rasgo latente*, *Modelo del rasgo latente* y *Modelo Rasch*, entre otros, además de *Teoría de respuesta al reactivo*. Esta familia de modelos de desarrollo de pruebas y procedimientos depende de complejos modelos matemáticos para evaluar cómo es interpretado el desempeño de quienes toman la prueba en relación con el desempeño de una predicción de la prueba. Por ejemplo, una variedad de la IRT fue desarrollada por el matemático danés Georg Rasch. El **Modelo Rasch**, ahora ampliamente utilizado en evaluación educacional, ofrece una forma de modelar la probabilidad de que una persona con X capacidad se desempeñe en el nivel Y . Dicho en términos de evaluación de personalidad, modela la probabilidad de que una persona con X cantidad de un rasgo particular en su personalidad mostrará una cantidad Y de ese rasgo en una prueba de personalidad diseñada para medirlo. Aunque suele verse como un modelo más sofisticado de desarrollo de pruebas que una teoría clásica de pruebas (Mitchell, 1999), los modelos de rasgos latentes parecen haber tenido mayor aceptación entre los usuarios de pruebas en gran escala que entre investigadores de pequeñas empresas y clínicas. Quizá la razón más convincente por la que la teoría del rasgo latente no es usada más ampliamente en aplicaciones cotidianas tiene que ver con cuestiones demasiado técnicas y complejas que deben ser abordadas para determinar si los datos acumulados encajarán en las matemáticas del modelo (véase, por ejemplo, el capítulo 12 de Bond y Fox, 2001).

Dejando de lado por un momento las cuestiones sobre su uso, una de las preguntas más frecuentes es ¿por qué a este modelo se le llama de *rasgo latente*? Para entender por qué, considere que ésta es una prueba generalmente diseñada para proporcionar una estimación de la cantidad de conocimiento o capacidad, o la intensidad de un rasgo particular⁵ que posee un examinado.

5. Véase el capítulo 12 en Bond y Fox (2001).

La variable de la que se supone depende el desempeño en la prueba —ya sea conocimiento, capacidad, un rasgo de la personalidad o algún otro aspecto— nunca es medible en forma directa. Por medio de la prueba podemos obtener una estimación de la cantidad de la variable. De esta manera, los rasgos latentes son como los factores en el análisis factorial, no se miden en forma directa sino que se reflejan a través de los reactivos de la prueba. De acuerdo con la teoría del rasgo latente, esta subyacente, inobservable variable —este rasgo latente— es unidimensional. Se presupone por tanto que todos los reactivos en una prueba, están midiendo este rasgo.

Una aplicación del modelo de rasgo latente puede encontrarse en la Escala de causalidad de enfermedades (Illness Causality Scale), una medida de la comprensión de las enfermedades para niños (Sayer *et al.*, 1993). Al investigar la validez de la prueba, los autores esperaban poder encontrar tres rasgos latentes los cuales fueron etiquetados como *inteligencia verbal*, *nivel de desarrollo cognoscitivo* y *comprensión de las enfermedades*. Los autores buscaban demostrar la presencia de cada uno de estos rasgos latentes mediante un estudio de correlación. La Escala de causalidad de enfermedades fue correlacionada con otras escalas, cada una de las cuales representaba una medida de alguno de los rasgos latentes. Por ejemplo, los autores encontraron que la Escala de causalidad de enfermedades se correlacionaba en forma moderada con una escala que mide la inteligencia verbal, presumiblemente porque las dos escalas comparten el rasgo latente de inteligencia verbal.

Los modelos de rasgo latente difieren en algunas formas importantes de la teoría clásica de la “puntuación verdadera” de la prueba. Por ejemplo, en la teoría clásica de la puntuación verdadera de la prueba no se hacen suposiciones de la distribución de frecuencia en las puntuaciones de la prueba. En contraste, tales suposiciones son inherentes a los modelos de rasgo latente. Como Allen y Yen (1979, p. 240) lo señalan, “Las teorías de rasgo latente proponen modelos que describen cómo influye el rasgo latente en el desempeño en cada reactivo de la prueba. A diferencia de las puntuaciones de prueba o de las puntuaciones verdaderas, los rasgos latentes pueden adoptar, en teoría, valores de $-\infty$ a $+\infty$ [de menos infinito a más infinito]”.

La extensa aplicabilidad de los modelos de rasgo latente a las pruebas psicológicas ha sido cuestionada por algunos teóricos. Se ha argumentado, por ejemplo, que la suposición de la unidimensionalidad de la prueba se viola cuando son consideradas muchas pruebas psicológicas. Se ha discutido, además, que incluso el mismo reactivo en una prueba psicológica puede estar explorando diferentes capacidades de la persona que responde la prueba, dependiendo de sus experiencias personales. A pesar de cuestiones teóricas persistentes, los modelos de rasgo latente parecen estar desempeñando un creciente y dominante papel en el diseño y desarrollo de nuevas pruebas y programas de pruebas.⁶

Otras consideraciones en el análisis de reactivos

Adivinación En las pruebas de rendimiento, el problema de cómo manejar el que las personas adivinen la respuesta ha eludido cualquier solución aceptable en forma universal. Es cierto que se han publicado varios procedimientos diferentes que pretenden ser correcciones para esto pero ninguno ha demostrado ser completamente satisfactorio. La razón es que el problema de responder al azar es más complejo de lo que parece a primera vista. Para entender por qué, considere los siguientes tres criterios que debe reunir cualquier corrección para esto, así como los problemas interactuantes que deben abordarse.

1. Una corrección para las respuestas al azar debe reconocer que cuando la persona adivina una respuesta en una prueba de rendimiento, generalmente no lo hace completamente al azar. Es más razonable suponer que la adivinación de quien responde se basa en algún conocimiento de la materia y en la capacidad de descartar una o más de las alternativas distractoras. Sin

6. Los obstáculos para el uso de estas técnicas en aplicaciones de evaluación más “cotidianas” han sido analizados por Reise y Henson (2003).

embargo, la cantidad de conocimiento sobre la materia que tiene variará de un reactivo al siguiente.

2. Una corrección para las respuestas al azar también debe abordar el problema de los reactivos omitidos. En ocasiones, en lugar de adivinar, quien responde la prueba tan sólo omite responder al reactivo. ¿Deberá ser calificado como “erróneo” el reactivo omitido? ¿El reactivo omitido debería excluirse del análisis de los reactivos? ¿El reactivo omitido debe ser calificado como si quien respondió la prueba hubiera respondido al azar? Exactamente ¿cómo debería manejarse el reactivo omitido?
3. Del mismo modo en que algunas personas pueden tener más suerte que otras en las máquinas tragamonedas de Las Vegas, así algunas personas que responden una prueba pueden tener más suerte que otras para adivinar las opciones codificadas como correctas. Cualquier corrección para la adivinación puede subestimar o sobrestimar notoriamente los efectos de la adivinación para quienes tuvieron suerte y para quienes no.

Se han propuesto soluciones diferentes al problema de las respuestas al azar. Además de las intervenciones propuestas en el nivel de la calificación de la prueba por medio del uso de correcciones para la adivinación (conocidas como *fórmula de las puntuaciones*), también se ha propuesto intervenir en el nivel de las instrucciones. Los respondientes pueden ser instruidos para que proporcionen una respuesta sólo cuando estén seguros de ella (sin adivinar) o para que completen todos los reactivos y que adivinen sólo cuando tengan duda. Las diferencias individuales en la disposición de los examinados a correr riesgos dan como resultado problemas para este enfoque de la adivinación (Slakter *et al.*, 1975). Algunas personas a las que no les importa correr riesgos pueden adivinar incluso cuando se les instruye para que no lo hagan. Otras, que tienden a ser reacias a correr riesgos, se rehúsan a adivinar bajo cualquier circunstancia. Esto crea una situación en la que la predisposición personal a correr riesgos puede afectar la propia calificación en la prueba.

Hasta la fecha, ninguna solución a este problema se ha considerado satisfactoria por completo. El constructor o desarrollador de pruebas responsable abordará el problema de la adivinación incluyendo en el manual de la prueba 1) instrucciones explícitas en relación con este punto para que el examinador las transmita a los examinados y 2), instrucciones específicas para calificar e interpretar los reactivos omitidos.

La adivinación a las respuestas en pruebas de personalidad y pruebas psicológicas relacionadas no se considera un gran problema; aunque en ocasiones puede ser difícil elegir la alternativa más apropiada en una prueba de personalidad con formato de selección de respuesta (en particular en una con reactivos de elección obligada), la suposición es que el examinado en verdad hace la mejor elección.

SÓLO PIENSE...

La lógica prevaleciente entre los profesionales de la medición es que cuando los examinados adivinan la respuesta de una prueba de personalidad en un formato de selección de respuesta el examinado está haciendo la mejor elección. ¿Por qué los profesionales deben seguir creyendo esto? ¿Por qué podrían modificar su punto de vista?

Imparcialidad del reactivo Así como hablamos de pruebas sesgadas, podemos hablar de reactivos sesgados. Un **reactivo de prueba sesgado** es un reactivo que favorece a un grupo particular de examinados en relación con otro cuando las diferencias de capacidad del grupo están controladas (Camilli y Shepard, 1985). Se pueden usar muchos métodos diferentes para identificar pruebas sesgadas. De hecho, la evidencia sugiere que la elección del método de análisis de reactivos puede afectar las determinaciones de sesgos en los reactivos (Ironson y Subkoviak, 1979).

Las curvas características del reactivo pueden usarse para identificar reactivos sesgados. Reactivos específicos son identificados como sesgados en un sentido estadístico si exhiben un funcionamiento diferencial. El funcionamiento diferencial del reactivo se ejemplifica con formas distintas de curvas características del reactivo para grupos diferentes (digamos, hombres y mujeres) aun cuando los dos grupos no difieran en la puntuación de la prueba total (Mellenbergh, 1994). Si un reactivo es considerado imparcial para diferentes grupos de personas que responden la prueba, las curvas características del reactivo no deberían diferir de manera significativa de los diferentes grupos:

El fundamento racional de este criterio de la CCR del sesgo del reactivo es que cualquier persona que muestre la misma capacidad tal y como es medida por la prueba entera debería tener la misma probabilidad de contestar correctamente cualquier reactivo que mida esa capacidad, sin importar su raza, clase social, género o cualesquiera otras características antecedentes. En otras palabras, la misma proporción de personas de cada grupo debería pasar cualquier reactivo dentro de la prueba, a condición de que todas las personas hayan obtenido la misma puntuación total en la prueba. (Jensen, 1980 p. 444)

Para determinar la presencia del funcionamiento diferencial del reactivo se requiere una prueba estadística de la hipótesis nula de “ninguna diferencia” entre las curvas características del reactivo dentro de los dos grupos. Las ventajas y problemas de diferentes pruebas estadísticas para detectar el funcionamiento diferencial del reactivo continúan en debate (Raju *et al.*, 1993). Los reactivos que muestran una diferencia significativa en las curvas características del reactivo deberán ser revisados o eliminados de la prueba. Si una cantidad relativamente grande de reactivos sesgados a favor de un grupo coexiste con aproximadamente el mismo número de reactivos sesgados a favor de otro grupo, no puede afirmarse que la prueba está midiendo las mismas capacidades en los dos grupos. Esto es verdad aunque las calificaciones totales de todos los individuos que contestaron la prueba puedan no ser significativamente diferentes en los dos grupos (Jensen, 1980).

Pruebas con límite de tiempo Los análisis de reactivos de pruebas presentadas bajo condiciones de límite de tiempo producen resultados engañosos o poco interpretables; entre más próximo está un reactivo al final de la prueba, más difícil parece ser. Esto tan sólo porque puede ser que una persona que respondió la prueba no haya llegado a él.

De manera similar, las medidas de diferenciación del reactivo pueden ser altas de manera artificial para los reactivos enlistados al final debido a que los examinados que conocen mejor el material pueden trabajar más rápido y tendrán mayor probabilidad de responder los últimos reactivos. Por tanto, los reactivos que aparecen al final en una prueba con límite de tiempo tienen mayor probabilidad de mostrar correlaciones positivas entre el reactivo y el total debido al selecto grupo de examinados que contestan esos reactivos.

Dados estos problemas, ¿cómo pueden ser analizados los reactivos en una prueba con límite de tiempo? Quizá la solución obvia para este tipo de problemas sea restringir el análisis de los reactivos sólo a los que fueron respondidos por los examinados. Sin embargo, esta solución *no* se recomienda al menos por tres razones: 1) los análisis de reactivos de los últimos incisos se basarían en cantidades cada vez menores de individuos que completen la prueba, lo que produciría resultados cada vez menos confiables; 2) si los examinados con más conocimientos alcanzan a contestar los últimos reactivos, una parte del análisis se basará en todos los que respondieron la prueba y la otra parte, en una muestra selecta; y 3) debido a que aquellos examinados que poseen más conocimientos tienen mayor probabilidad de obtener una puntuación correcta, su desempeño hará que los reactivos ubicados al final de la prueba parezcan más fáciles de lo que pudieran ser en realidad.

Si la velocidad no es un elemento importante de la capacidad que se está midiendo y debido a que produce información engañosa acerca del desempeño del reactivo, quien elabora las pruebas, de manera ideal, debería aplicar la prueba para ser analizada por reactivos con límites generosos de tiempo para completarla. Una vez que se ha completado el análisis de reactivos, deben establecerse normas aplicando las condiciones de velocidad indicadas para usarse con la prueba en la práctica real.

Análisis cualitativo de los reactivos

Los usuarios de pruebas han mantenido un constante interés por entender el desempeño de los participantes desde esta perspectiva (Fiske, 1967; Mosier, 1947). El cálculo de la validez y confiabilidad del reactivo y otros índices cuantitativos representan un enfoque para entender a los examinados. A otro tipo general de métodos de investigación se le conoce como *cualitativo*. A diferencia de los métodos cuantitativos, los **métodos cualitativos** son técnicas de generación y aná-

Tabla 7-3

Áreas de exploración potencial para efecto del análisis cualitativo de los reactivos

Esta tabla enumera temas muestra y posibles preguntas de interés para los usuarios de las pruebas. Las preguntas pueden plantearse en forma oral o escrita poco después de la administración de la prueba. Además, dependiendo de los objetivos del usuario de la prueba las preguntas podrían exponerse en otro formato tales como falso/verdadero o de opción múltiple. Dependiendo de las preguntas específicas que se hagan y el número de examinados, los usuarios de las pruebas quizá deseen garantizar el anonimato de quienes las contestan.

Tema	Preguntas muestra
<i>Sensibilidad cultural</i>	¿Sintió usted que algún reactivo o aspecto de esta prueba fue discriminatorio respecto de algún grupo de personas? De ser así, ¿por qué?
<i>Validez aparente</i>	¿Le pareció que la prueba medía lo que usted esperaba midiera? Si no, ¿qué fue contrario a sus expectativas?
<i>Administrador de pruebas</i>	¿De alguna manera, el comportamiento de quien administró la prueba afectó su desempeño? Si es así, ¿cómo?
<i>Ambiente de la prueba</i>	¿Alguna condición en el salón afectó de cualquier forma su desempeño en esta prueba? Si es el caso, ¿cómo?
<i>Imparcialidad de la prueba</i>	¿Pensó que la prueba era imparcial en lo que buscaba medir? ¿Por qué sí o por qué no?
<i>Lenguaje de la prueba</i>	¿Hubo algunas instrucciones u otros aspectos escritos de la prueba que no hayan sido fáciles de entender?
<i>Longitud de la prueba</i>	¿Cómo se sintió acerca de la extensión de la prueba respecto al a) tiempo que le tomó terminarla, b) al número de reactivos?
<i>Respuestas al azar</i>	¿Adivinó en alguno de los reactivos de la prueba? ¿Qué porcentaje de reactivos trató de adivinar? ¿Empleó alguna estrategia particular para adivinar o fue básicamente al azar?
<i>Integridad del examinado</i>	¿Considera que alguien hizo trampa durante la prueba? En su caso, describa el método que cree haya sido empleado.
<i>Estado físico/mental del examinado al entrar</i>	¿Cómo describiría su estado mental cuando se dirigía a la prueba? ¿Cree que su estado mental de alguna manera afectó el resultado de la prueba? Si es el caso, ¿cómo? ¿Cómo describiría su estado físico cuando se dirigía a la prueba? ¿Cree que su estado físico de alguna manera afectó el resultado de la prueba? Si esto es un hecho, ¿cómo?
<i>Estado físico/mental del examinado durante la prueba</i>	¿Cómo describiría su estado mental durante la prueba? ¿Cree que su estado mental durante la prueba afectó de alguna manera el resultado? De ser así, ¿cómo? ¿Cómo describiría su estado físico durante la prueba? ¿Cree que su estado físico durante la prueba afectó de alguna manera el resultado? Si esto es así, ¿cómo?
<i>Impresión general del examinado</i>	¿Cuál es su impresión de esta prueba en su totalidad? En función de mejorarla, ¿qué sugerencias le haría a quien la desarrolló?
<i>Preferencias del examinado</i>	¿Encontró alguna parte de la prueba educativa, entretenida o provechosa de alguna manera? Específicamente, ¿qué le gustó o desagradó de la prueba? ¿Encontró alguna parte que le provocara ansiedad, que fuera condescendiente o le generara molestia de alguna manera? ¿Por qué?
<i>Preparación del examinado</i>	¿Cómo se preparó para esta prueba? Si quisiera aconsejar a otros sobre cómo prepararse para ella, ¿qué les diría?

lisis de datos que dependen sobre todo de procedimientos verbales más que de los matemáticos o estadísticos. Alentar a los participantes, de manera individual o en grupos, para que analicen su experiencia como examinados es, en esencia, obtener o generar “datos” (palabras). Estos datos luego pueden ser usados por los diseñadores de pruebas, usuarios y editores para mejorar sus diversos aspectos.

Análisis cualitativo de reactivos es un término general para diversos procedimientos no estadísticos diseñados para explorar cómo funcionan los reactivos de las pruebas en forma individual. El análisis compara uno con otro los reactivos individuales de la prueba y a la prueba como un todo. En contraste con los procedimientos basados de manera estadística, los métodos cualitativos involucran la exploración de los temas a través de medios verbales como entrevistas y discusiones de grupo conducidas con examinados y otras personas relevantes para el proceso. Algunos de los temas que los investigadores querrían explorar de forma cualitativa se resumen en la tabla 7-3.

Una observación precautoria; es verdad que en algunos casos dar a los examinados la oportunidad de describir la prueba, es comparable a dar a los estudiantes la oportunidad de describir a sus maestros. En ambos casos, puede haber un abuso del proceso, en especial por examinados que tienen intereses personales más allá de la prueba (o más allá del maestro). Quienes responden pueden estar descontentos por diferentes razones, que pueden ser desde la falta de preparación

adecuada para la prueba hasta la decepción por su desempeño en ella. En tales casos, la oportunidad de evaluar la prueba es equivalente a la oportunidad de lanzar indirectas. La prueba, el administrador de la prueba y la institución, dependencia o corporación responsable de su aplicación pueden volverse objetos de crítica. Los cuestionarios para el examinado, al igual que otras herramientas de investigación cualitativas, deben ser interpretados tomando en cuenta el contexto total de la experiencia de quienes responden.

Administración de una prueba tipo “pensar en voz alta” Un enfoque innovador para la evaluación cognoscitiva implica hacer que los respondientes verbalicen sus pensamientos conforme éstos les llegan. Aunque diferentes investigadores usan distintos procedimientos (véase, por ejemplo, Davison *et al.*, 1997; Hurlburt, 1997; Klinger, 1978), este enfoque general se ha empleado en una variedad de contextos de investigación incluyendo estudios de adaptación (Kendall *et al.*, 1979; Sutton-Simon y Goldfried, 1979), solución de problemas (Duncker, 1945; Montague, 1993), enmienda educativa (Randall *et al.*, 1986) e intervención clínica (Gann y Davison, 1997; Haaga *et al.* 1993; White *et al.*, 1992).

Cohen *et al.* (1988) propusieron la **aplicación de una prueba para “pensar en voz alta”** como una herramienta de investigación cualitativa diseñada para arrojar luz sobre el proceso de pensamiento de los examinados durante la aplicación de ésta. Con aplicación individual para cada individuo con un examinador, se pide a los examinados que respondan una prueba, pensando en voz alta mientras responden a cada reactivo. Si la prueba está diseñada para medir el rendimiento, tales verbalizaciones pueden ser útiles para evaluar no sólo si ciertos estudiantes (como los que obtuvieron puntuaciones bajas o altas en exámenes previos) están interpretando un reactivo particular, sino también por qué y cómo están interpretando mal el reactivo. Si la prueba está diseñada para medir la personalidad o algún aspecto de ella, la técnica de “pensar en voz alta” también puede proporcionar conocimiento valioso respecto a la forma en que los individuos perciben, interpretan y responden a los reactivos.

Paneles de expertos Además de entrevistar en forma individual o en grupo a quienes responden las pruebas, también puede entrevistarse a **paneles de expertos** para que proporcionen análisis cualitativos de los reactivos de una prueba. La **revisión de sensibilidad** es un estudio de los reactivos de pruebas que suele hacerse durante el proceso del desarrollo de las mismas, en el cual, los reactivos son estudiados en cuanto a su imparcialidad para todos los posibles examinados así como para detectar el uso de lenguaje ofensivo, estereotipos o situaciones adversas. Las revisiones de sensibilidad se han vuelto parte del desarrollo contemporáneo de pruebas (Reckase, 1996). Por ejemplo, en un esfuerzo por desarraigar cualquier posible sesgo en la Serie de pruebas de rendimiento de Stanford (*Stanford Achievement Test Series*), el editor de la prueba integró un panel consultivo con 12 miembros de grupos minoritarios, cada uno parte prominente de la comunidad educativa. Los integrantes del panel se reunieron con el editor para tener una comprensión de la historia y la filosofía de la batería de pruebas y para discutir y definir el problema del sesgo (Stanford Special Report, 1992). Algunas posibles formas de sesgo de contenido que pueden infiltrarse en cualquier prueba de rendimiento fueron identificadas como sigue:

Estado: ¿Los miembros de un grupo particular son mostrados en situaciones que no implican autoridad o liderazgo?

Estereotipo: ¿Los miembros de un grupo particular son representados de manera uniforme como poseedores de ciertas: 1) aptitudes, 2) intereses, 3) ocupaciones o 4) características de personalidad?

Familiaridad: ¿Hay una mayor oportunidad de parte de un grupo para: 1) estar familiarizado con el vocabulario o 2) experimentar la situación presentada en un reactivo?

Elección de palabras ofensivas: 1) ¿Se ha aplicado alguna denominación degradante o 2) se ha usado un término masculino cuando pudo haberse sustituido por uno neutro?

Otros: Se les pidió a los miembros del panel que fueran específicos respecto a cualquier otro indicio de sesgo que detectarían. (Stanford Special Report, 1992, pp. 3-4)

Con base en la información cualitativa de un panel de expertos o de los mismos examinados, un usuario o un elaborador de pruebas puede elegir modificarla. La modificación podría adoptar muchas formas diferentes, incluyendo la eliminación de reactivos existentes y la adición de otros o cambiar su redacción. Observe que hay otro significado para *revisión de pruebas* más allá del asociado con un escenario del desarrollo de una nueva prueba. Muchas pruebas existentes están programadas para su re-edición en nuevas versiones luego de cierto periodo. El proceso de desarrollo que experimenta una prueba conforme se modifica y revisa se llama, de manera obvia, *revisión de prueba*. El tiempo, esfuerzo y gasto que implica esta última variedad de “revisión de prueba” puede ser bastante costoso. Por ejemplo, la revisión puede implicar una extensión de edad de la población para la cual fue diseñada la prueba —hacia arriba para los examinados mayores y/o hacia abajo para los más jóvenes— y una nueva validación de los estudios correspondientes.

Revisión de la prueba

Consideremos ahora los aspectos de la revisión de prueba como una etapa en el desarrollo de una nueva. Luego, consideraremos los aspectos de la revisión en el contexto de modificar una prueba existente para hacer una nueva edición. Mucho de nuestro razonamiento sobre la revisión de la prueba en el desarrollo de una nueva también puede ser aplicado al desarrollo de ediciones futuras de pruebas existentes, dependiendo de qué tan a fondo sea dicha revisión.

Revisión de la prueba como una etapa en el desarrollo de una prueba nueva

Una vez conceptualizada la prueba nueva, construida, ensayada y con sus reactivos analizados de manera cuantitativa y cualitativa, lo que resta es actuar juiciosamente con toda la información y moldear la prueba para su forma final. Una tremenda cantidad de información es generada en la etapa del análisis de los reactivos, en particular debido a que una prueba en desarrollo puede tener cientos de ellos. Con base en esta información, algunos reactivos de la reserva original serán eliminados y otros redactados de nuevo. ¿Cómo se integra y se usa esta información para revisar la dificultad, validez, confiabilidad, discriminación y sesgo de los reactivos de la prueba, junto con la información de las curvas características del reactivo?

Es probable que existan tantas formas de enfocar la revisión de la prueba como diseñadores de pruebas existen. Un enfoque sería caracterizar cada reactivo de acuerdo con sus puntos fuertes y débiles. Algunos reactivos pueden ser muy confiables, pero carecen de validez de criterio, mientras que otros pueden estar totalmente sin sesgo, pero son demasiado fáciles. Se encontrará que algunos reactivos tienen muchos defectos, por lo cual son candidatos perfectos para su eliminación o revisión. Por ejemplo, los reactivos muy difíciles tienen un rango restringido, todos o casi todos aquellos que responden la prueba los responden mal. Los reactivos muy difíciles tenderán a carecer de confiabilidad y validez debido a lo restringido de su rango. Lo mismo sucederá con reactivos muy fáciles.

Quienes elaboran las pruebas tal vez encontrarán que deben equilibrar los puntos fuertes y débiles a lo largo de los reactivos. Por ejemplo, si muchos de ellos, clasificados como buenos, tienden a ser algo fáciles, quien elabora la prueba puede incluir a propósito algunos reactivos más difíciles incluso si los reactivos tuvieran otros problemas. Esos reactivos más difíciles pueden ser seleccionados específicamente para hacerles una nueva redacción. El propósito de la prueba también influye en la forma en que se hace la revisión. Si la prueba va a influir en las decisiones importantes concernientes a la ubicación educativa o al empleo, el creador de la prueba tendrá que interesarse de manera escrupulosa por los problemas de sesgo en los reactivos. Si hay necesidad de identificar a los individuos más experimentados de entre quienes están siendo examinados, debe ser prioritario seleccionar los reactivos que muestren una mejor diferenciación y que conduzcan a la mejor discriminación de los individuos en base a los resultados de la prueba.

En tanto procedemos con la revisión, la ventaja de haber redactado una gran reserva de reactivos se vuelve obvia, los reactivos malos pueden ser eliminados a favor de aquellos que mostraron ser buenos en el periodo de probanza de la prueba. Incluso cuando se trabaja con una gran reserva de reactivos, quien elabora la revisión de la prueba debe estar consciente del dominio que la prueba debe ejemplificar. Para algunos aspectos del dominio, podría ser particularmente difícil redactar buenos reactivos para ello y la eliminación indiscriminada de todos los reactivos que funcionan mal podría causar que esos aspectos del dominio quedaran sin ser medidos.

Habiendo equilibrado todas estas inquietudes, quien elabora la prueba sale de la etapa de revisión con una prueba mejorada. El siguiente paso es aplicar la prueba revisada bajo condiciones estandarizadas a una apropiada segunda muestra de examinados. Con base en un análisis de los reactivos de los datos derivados de esta aplicación del segundo borrador de la prueba, el constructor puede considerar que la prueba está en su forma final, en cuyo caso, las normas pueden ser elaboradas a partir de los datos y, diremos que la prueba ha sido “estandarizada” en esta (segunda) muestra.

La **estandarización** puede verse como “el proceso empleado para introducir objetividad y uniformidad en la administración, calificación e interpretación de la prueba” (Robertson, 1990, p. 75). Una muestra de estandarización es representada por el grupo o grupos de individuos con quienes se comparará el desempeño de los examinados. Para las pruebas con referencia a

SÓLO PIENSE...

¡Sorpresa! Un editor internacional está interesado en publicar su prueba sobre la Historia de Estados Unidos y acaba de preguntar cuáles son las características que usted cree son más importantes acerca de la población demográfica, para tenerlas representadas en su muestra de estandarización internacional. ¿Qué respondería?

una norma, es importante que esta muestra sea representativa de la población en aquellas variables que podrían afectar el desempeño. Las pruebas de capacidad, por ejemplo, son elaboradas de modo que el grupo de estandarización sea representativo de la población en cuanto a características como edad, género, región geográfica, tipo de comunidad, grupo étnico y educación de los padres. Para asegurarse que la muestra de estandarización se relaciona de manera cercana con la población con estas características demográficas, por lo general, se utilizan los datos del censo más reciente.

Cuando el análisis de los reactivos de los datos derivados de la aplicación de una prueba indica que todavía no está finalizada, los pasos de revisión, ensayo y análisis de reactivos se repiten hasta que la prueba sea satisfactoria y pueda llevarse a cabo la estandarización. Una vez que los reactivos de la prueba se han finalizado, los

procedimientos de la elaboración profesional de pruebas dictan que las conclusiones sobre la validez de la prueba aguardan una *validación cruzada* de los hallazgos. Más adelante examinaremos la validez cruzada, por ahora, consideremos brevemente algunos de los problemas que rodean el desarrollo de una nueva edición de alguna prueba existente.

Revisión de prueba en el ciclo de vida activa de una prueba existente

El tiempo no espera a nadie. Todos envejecemos y las pruebas también. Al igual que la gente, algunas pruebas envejecen con más gracia que otras. Por ejemplo, como veremos cuando estudiemos técnicas proyectivas en el capítulo 12, las “Manchas de tinta de Rorschach” parecen haberse mantenido bastante bien a lo largo del tiempo. En contraste, los materiales de estímulo para otras técnicas proyectivas, la “Prueba de Apercepción Temática” (TAT, por sus siglas en inglés) ya muestran su edad. Llega un momento en la vida de la mayoría de las pruebas en que deben ser revisados de alguna manera o su publicación se discontinuará. ¿Cuándo llega ese momento?

No hay reglas precisas para cuándo revisar una prueba. La APA (1996, Standard 3.18), ofrece la sugerencia general de que una prueba se mantenga en su forma presente mientras siga siendo “útil” y que se revise “cuando ocurran cambios significativos en el dominio representado o cuando surjan nuevas condiciones en el uso e interpretación de la prueba y que éstas la hayan vuelto inapropiada”.

En términos prácticos, muchas pruebas son consideradas listas para revisión cuando existe cualquiera de las siguientes condiciones:

1. Los materiales de estímulo lucen anticuados y los examinados actuales no pueden relacionarlos.
2. El contenido verbal de la prueba, incluyendo las instrucciones para su administración y los reactivos de la misma, contienen un vocabulario anticuado que no es fácilmente comprendido por los examinados actuales.
3. En la medida en que cambia la cultura popular y las palabras adquieren nuevos significados, algunas palabras o expresiones en los reactivos o instrucciones de la prueba pueden percibirse inapropiados u ofensivos para un grupo en particular y por tanto deben ser cambiados.
4. Las normas de las pruebas ya no son adecuadas como resultado de cambios en la membresía de grupo (cohesión grupal) dentro de la población de examinados potenciales.
5. Las normas de las pruebas ya no son adecuadas como resultado de cambios relacionados con la edad en las capacidades medidas con el paso del tiempo y es necesaria una extensión de edad en las normas hacia arriba, hacia abajo o en ambas direcciones.
6. La confiabilidad o la validez de la prueba, así como la efectividad de los reactivos de prueba individuales puede ser significativamente mejorada mediante una revisión.
7. La teoría en la cual se basaba la prueba originalmente ha sido mejorada de modo sustancial y los cambios deben reflejarse en el diseño y contenido de la prueba.

Los pasos para revisar una prueba existente son comparables a aquellos para crear una nueva. En la fase de conceptualización el constructor o desarrollador debe pensar de manera completa en los objetivos de la revisión y la mejor forma en que pueden lograrse. En la fase de construcción se efectúan los cambios propuestos. Los pasos siguientes son la etapa de revisión o probanza de la prueba, el análisis de los reactivos y la última revisión (en el sentido de hacer refinamientos finales). Mientras que todo esto suena relativamente fácil y directo, crear una edición revisada de una prueba existente puede ser una tarea muy ambiciosa. Por ejemplo, recordando la revisión de una prueba llamada “Prueba de interés vocacional prioritario”, Campbell (1972) reflexionaba que el proceso de concebir la revisión comenzó 10 años antes de iniciarse el trabajo de revisión, el cual en sí mismo duró otros 10 años. Butcher (2000) hacía eco de estas ideas en un artículo que proporcionaba una detallada “visión interna” del proceso de revisión de una prueba de personalidad ampliamente popular llamada la MMPI. Otros también han notado las diversas consideraciones que deben tenerse en mente cuando se contempla la revisión de un instrumento existente (Adams, 2000; Okazaki y Sue, 2000; Reise *et al.*, 2000; Silverstein y Nelson, 2000).

Una vez que el sucesor de una prueba existente se publica surgen preguntas sobre la equivalencia de las dos ediciones. Por ejemplo, ¿Un CI de 110 medido en la escala completa en la primera edición de una prueba de inteligencia significa exactamente lo mismo que un CI de 110 medido en la escala completa en la segunda edición? Cierta número de investigadores han aconsejado precaución al hacer interpretaciones a partir del original y una versión revisada de una prueba, a pesar de las aparentes similitudes (Reitan y Wolfson, 1990; Strauss *et al.*, 2000). Aun si el contenido de los reactivos individuales no cambia, el contexto en el cual éstos aparecen, puede cambiar abriendo así la posibilidad de diferencias elocuentes en la interpretación de los examinados del significado de los reactivos. Tan sólo elaborar una versión computarizada de una prueba puede hacer una diferencia, al menos en términos de las calificaciones alcanzadas por los miembros de diferentes poblaciones (Ozonoff, 1995).

Deben emplearse los métodos formales de análisis de reactivos para evaluar la estabilidad de los reactivos entre revisiones de la misma prueba (Knowles y Condon, 2000). Por último, las puntuaciones de una prueba y su versión actualizada pueden no ser directamente comparables. Como lo resumieron Tulskey y Ledbetter (2000) en el contexto de las versiones originales y revisadas de las pruebas de capacidad cognoscitiva, “cualquier mejoría o decremento en el desempeño entre las dos no puede ser visto automáticamente como un cambio en el desempeño del examinado” (p. 260).

Un paso clave en el desarrollo de todas las pruebas —nuevas o ediciones revisadas— es la validación cruzada. A continuación analizaremos ese importante proceso por consiguiente, así como una más reciente tendencia en la publicación de pruebas, la *convalidación*.

Validación cruzada y convalidación El término **validación cruzada** se refiere a una revalidación de una prueba en una muestra de examinados diferentes de aquellos en quienes el desempeño de la prueba mostró ser un medio válido para pronosticar algún criterio. Se espera que los reactivos seleccionados para la versión final de la prueba (en parte debido a sus altas correlaciones con una medida de criterio) tengan una validez menor cuando se administren en una segunda muestra de personas. Esto ocurre debido a la intervención de factores aleatorios. La disminución en la validez de los reactivos que ocurre de manera inevitable después de la validación cruzada de los resultados se conoce como **reducción de la validez**. Dicha reducción es esperada y vista como parte integral del proceso de desarrollo de la prueba. Además, dicha reducción es infinitamente preferible a un escenario en donde los reactivos con validez alta son publicados (de manera ilegítima) en un manual de prueba como un resultado del uso inapropiado de muestras idénticas de individuos que respondieron la prueba para su estandarización y validación cruzada de los resultados. Cuando ocurren tales escenarios, los usuarios de las pruebas quedarán, como es usual, un poco decepcionados por la validez de la misma, más baja de lo esperado. El manual de prueba que acompaña a las pruebas manejadas en forma comercial debe delinear los procedimientos usados en su desarrollo. Información confiable que incluya la confiabilidad del proceso test-re-test y las estimaciones de consistencia interna, deben reportarse junto con la evidencia de la validez de la prueba. Los artículos que examinan la validación cruzada de las pruebas a menudo se publican en revistas académicas. Por ejemplo, Bank *et al.* (2000) proporcionaron un detallado recuento de la validación cruzada de un instrumento utilizado para detectar la disfunción cognoscitiva en adultos mayores.

Para no confundirla con la “validación cruzada”, la **convalidación** puede ser definida como el proceso de validación de una prueba en base a dos o más pruebas y utilizando la misma muestra de examinados. Cuando se usa en conjunto con la creación de normas o la revisión de normas existentes, este proceso también puede llamarse **connormar**. Una tendencia actual entre los editores de pruebas que publican más de una prueba diseñada para usarse con la misma población es la de convalidar y/o connormar las pruebas. La convalidación de pruebas nuevas y la revisión de las existentes puede ser benéfica en varios sentidos para todos los que participan en la actividad de la evaluación. La convalidación es benéfica para los editores porque es económica. Durante el proceso de validación, deben primero ser identificados muchos de los posibles examinados. En varias instancias, después de haber identificado a los posibles participantes en el estudio de validación, se seleccionará una persona representativa de ese grupo por medio de una entrevista cara a cara o por teléfono. Esto cuesta dinero, el cual se carga al presupuesto para el desarrollo de la prueba. Se ahorra tiempo y dinero si la misma persona es considerada adecuada en la validación de estudios para múltiples pruebas y puede ser programada para participar con un mínimo de preliminares administrativos. Examinadores calificados para administrar la prueba así como personal que los asista en la calificación, interpretación y análisis estadístico deben también ser identificados, retenidos y programados para participar en el proyecto. El costo por retener este personal profesional en base a una prueba se mantiene bajo cuando este trabajo es hecho de manera simultánea en muchas pruebas.

Más allá de los beneficios para el editor, la convalidación puede contener beneficios potencialmente importantes para los usuarios de pruebas y los examinados. Muchas pruebas que tienden a usarse juntas son publicadas por el mismo editor, por ejemplo la tercera edición de la Escala Wechsler de inteligencia para adultos (WAIS-III, por sus siglas en inglés) y la tercera edición de la Escala Wechsler de memoria (WMS-III, por sus siglas en inglés) pueden usarse juntas en la evaluación clínica de un adulto. Y supongamos que después de una evaluación usando estas dos pruebas surjan diferencias en la medida de la capacidad de memoria como una función de la prueba usada. Si estas dos pruebas hubieran sido normalizadas sobre muestras diferentes, el error de muestreo habría sido una posible razón para las diferencias observadas en la medición de la memoria. Sin embargo, debido a que estas dos pruebas fueron normalizadas sobre la misma población, el error de muestreo como factor causal ha sido minimizado en gran cantidad, si no es que eliminado por completo. Un médico clínico puede prestar atención a factores tales como las diferencias en la forma en que las dos pruebas miden la memoria. Una prueba, por ejemplo, puede medir la memoria a corto plazo a través de secuencias de números. La otra puede medir la misma variable a través de la comprensión de la lectura de pequeños pasajes. La forma en que

cada prueba mide la variable en estudio puede proporcionar información importante para el diagnóstico.

Por otra parte, considere dos pruebas conormadas que son casi idénticas en la forma en que miden la variable en estudio. Con el error de muestreo minimizado mediante el proceso de conormar, el usuario de la prueba podrá confiar más en que las puntuaciones de las dos pruebas son comparables.

Confirmación de calidad durante la revisión de la prueba Hace mucho tiempo en Manhattan, el decano autor de este texto (Cohen) tenía el título de psicólogo decano del Hospital Bellevue. Entre otras obligaciones los psicólogos decanos debían supervisar a los internos de psicología clínica en todas las fases de su desarrollo profesional incluyendo la administración de pruebas psicológicas:

Un día, en el transcurso de revisar el protocolo de una prueba que me entregó un interno, algo muy peculiar captó mi atención. En una subprueba que tenía varias tareas calificadas en base al número de segundos para responderla, todos los tiempos registrados en el protocolo eran múltiplos de cinco (5, 10 o 15 segundos, etcétera). Nunca había visto un protocolo semejante. En general, todos los protocolos terminados que había visto antes tenían registrados tiempos completos sin un patrón identificable (12, 17, 9 segundos, etcétera) Incitado por la curiosidad acerca de cómo había sido calificado el protocolo le hablé al interno para platicarlo.

Resultó que la interna no se proveyó de un reloj con segundero o con un cronómetro. Ignoró este pequeño detalle obligatorio de preparación previo a la administración de una prueba. Careciendo de cualquier medio para registrar el número exacto de segundos que le tomó completar cada tarea, la interna dijo que había “calculado” el número de segundos. Calcular en tales circunstancias no es permisible, puesto que viola los procedimientos estandarizados establecidos en el manual. Más allá de eso, la estimación podría fácilmente resultar en que el examinado gane o deje escapar puntos adicionales por la (inexacta) calificación del tiempo. La interna fue orientada acerca del error en sus procedimientos y al paciente se le administró una nueva prueba.

Bueno, éste es un ejemplo “cercano y personal” del control de calidad de las pruebas psicológicas en un gran hospital municipal. Pero, ¿qué mecanismos para asegurar la calidad son establecidos por los editores al estandarizar una nueva prueba o re-estandarizar una existente? Echemos un vistazo a algunos de los mecanismos de control de calidad para los examinadores, protocolos de calificación e ingreso de datos. Con el propósito de ilustrar, extraeremos algunos ejemplos de los procedimientos seguidos por quienes desarrollaron la Escala de inteligencia Wechsler para niños, cuarta edición, o WISC-IV (Wechsler, 2003) una prueba que es analizada más detalladamente en el capítulo 9.

El examinador es la persona que está al frente en el desarrollo de pruebas y es de importancia crucial que los examinadores se apeguen a los procedimientos estandarizados. Al desarrollar una nueva prueba o al re-estandarizar o normalizar una existente, quienes las desarrollan buscan emplear examinadores que tengan experiencia estudiando a miembros de la población seleccionada para la prueba. Por ejemplo, quienes desarrollaron la WISC-IV buscaban

...reclutar examinadores con amplia experiencia en la aplicación de pruebas a niños y adolescentes. Los potenciales examinadores, contestaron un cuestionario proporcionando información sobre su educación y experiencia profesional, su experiencia en administración con varias medidas intelectuales, su certificación y la vigencia de su licencia de actividad profesional. Quienes fueron seleccionados como examinadores de estandarización potencial estaban muy familiarizados con la práctica de evaluación infantil. (Wechsler, 2003, p. 22)

Si bien sería deseable que todo examinador tuviera un doctorado, eso simplemente no es posible, dado que son miles las pruebas que tal vez deban ser administradas de manera individual. El tiempo profesional de un examinador con doctorado tiende a cotizarse muy alto, sin mencionar sus honorarios. Sin importar la educación o experiencia, todos los examinadores deberán estar entrenados para administrar el instrumento. El entrenamiento, como es característico, tomará la forma de directrices redactadas y puede implicar todo desde la instrucción en el salón de clases hasta practicar la administración in situ de las pruebas, incluyendo demostraciones video-grabadas para ser estudiadas en casa. Los editores pueden evaluar a los posibles examinadores

mediante una prueba u otros medios para determinar qué tan bien han aprendido lo que necesitan saber. Durante la estandarización de la WISC-IV se les requirió a los examinadores presentar un caso a revisión previo a las pruebas adicionales a los niños. Y durante el curso de la estandarización de la prueba todos los seleccionados como examinadores recibieron un boletín periódico orientándoles sobre problemas potenciales en la administración de la prueba. El boletín estaba diseñado para proporcionar un medio constante para mantener segura la calidad en la administración de la prueba.

En el transcurso del desarrollo de la prueba los examinadores pueden estar involucrados en menor o mayor grado en la calificación final de los protocolos. Independientemente de si se trata de un examinador o de un “dedicado calificador” todas las personas que tengan la responsabilidad de calificar los protocolos tendrán que pasar, de manera característica, por un entrenamiento. De igual forma, el entrenamiento para los calificadores puede incluir desde las instrucciones en clase hasta videograbaciones.

La seguridad en la calidad en la re-estandarización de la WISC-IV, se mantuvo en parte al tener a dos calificadores competentes calificando nuevamente cada protocolo recolectado durante el ensayo a nivel nacional y las etapas de estandarización del desarrollo de la prueba. En caso de haber discrepancias en la calificación, éstas eran resueltas por, incluso, otro calificador llamado el *solucionador*. De acuerdo con el manual “los solucionadores fueron seleccionados en base a la demostración de una excepcional precisión para calificar así como su experiencia previa en la materia” (Wechsler, 2003, p. 22).

Otro mecanismo para asegurar la consistencia en la calificación es el *protocolo ancla*. Un **protocolo ancla** es una prueba de protocolo calificada por un calificador de elevada autoridad, diseñada como un modelo para calificar y un mecanismo para resolver discrepancias en la calificación. Un término usado para reflejar una discrepancia entre la calificación en un protocolo ancla y la calificación de otro protocolo es la **desviación de la calificación**. En el desarrollo de la WISC-IV se usaron protocolos ancla para asegurar la calidad:

Si dos calificadores independientes cometieran el mismo error de calificación en un protocolo, la comparación con la calificación ancla revelaría la desviación de la calificación. Para prevenir la repetición del error y corregir la desviación de la calificación, los calificadores recibían de inmediato información actualizada (Wechsler, 2003, p. 23).

Una vez que los protocolos han sido calificados, estos datos deben ser guardados en una base de datos. Para asegurar la calidad durante la fase del ingreso de los datos del desarrollo de la prueba, los elaboradores pueden utilizar programas de computadora para buscar e identificar cualquier irregularidad en los reportes de calificación. Por ejemplo, si la calificación en una subprueba particular puede oscilar de 1 a 10, cualquier calificación reportada fuera de ese rango deberá ser identificada por la computadora. De manera adicional, una porción de los protocolos puede elegirse al azar para asegurar que los datos ingresados correspondan fielmente a la información original.

Y ahora para algún “control personal de calidad” de estudiantes de evaluación, póngase a prueba usted mismo, en las palabras contenidas en este capítulo de *Autoevaluación* antes de pasar al siguiente capítulo.

Autoevaluación

Compruebe su comprensión de los elementos de este capítulo, viendo si puede explicar cada uno de los siguientes términos, expresiones y abreviaturas:

adaptación de las pruebas en computadora (APC)	elaboración de escalas absolutas	panel de expertos
adivinación o respuestas dadas al azar	elaboración de escalas categóricas	probanza o periodo de prueba de la prueba
administración de prueba de “pensar en voz alta”	elaboración de escalas comparativas	protocolo ancla
análisis cualitativo de reactivos	Escala Guttman	puntuación por clase (puntuación por categoría)
análisis de escalograma	Escala Likert	ramificación de reactivos
análisis de reactivos	escala de clasificación	reactivo de ensayo
banco de datos de reactivos	escala sumatoria	reactivo de opción múltiple
calificación ipsativa	escalas	reactivo de prueba sesgada
conormar	estudio piloto	reactivo de respuesta breve
conceptualización de la prueba	formato de construcción de respuesta	reactivo de selección binaria
consistencia interna	formato de selección de respuesta	reactivo falso/verdadero
construcción de la prueba	formato del reactivo	reactivos para completar
convalidación	imparcialidad de reactivo	reducción de la validez
correspondencia de reactivos	índice de aprobación del reactivo	reserva de reactivos
curva característica del reactivo (CCR)	índice de confiabilidad de los reactivos	revisión de la prueba
desviación de la calificación	índice de diferenciación del reactivo	revisión de sensibilidad
elaboración de escalas	índice de dificultad del reactivo	teoría del rasgo latente (modelo del rasgo latente)
	índice de validez de los reactivos	validación cruzada
	métodos cualitativos	
	modelo Rasch	

Un vistazo a la red

Visite los siguientes sitios en la Red para mayor información sobre los temas analizados en este capítulo.

Escala Likert

<http://education.uncc.edu/rfalgozz/ADMN8699/likerttips.pdf>

www.socialresearchmethods.net/kb/scallik.htm

Reactivos de prueba

<http://siop.org/workplace/employment%20testing/testformats.htm>

www.edtech.vt.edu/edtech/id/assess/items.html

Análisis de reactivos

www.statsoftinc.com/textbook/streliab.html

www.ericfacility.net/databases/ERIC_Digests/ed398237.html

Análisis de reactivos del estado de Michigan

www.msu.edu/dept/soweb/itanhand.html#guide

Calificación Guttman y análisis de escalograma

www.socialresearchmethods.net/scalgutt.htm

Diseño y construcción de pruebas del estado de Pennsylvania

www.uts.psu.edu/Test_constructuion_frame.htm

Útil guía de campo PDF para el enfoque de la prueba y el formato

www.aea11.k12.ia.us/assessment/docs/dwafielddguide.pdf

PDF relacionado con la adaptación de pruebas por computadora

www.teamrees.com/training/comptia_adptive.pdf

Teoría de la respuesta al reactivo

<http://edres.org/irt/>

Análisis cualitativo de reactivos: perspectiva del profesor

<http://faculty.mansfield.edu/rfeil/201/item-analysis-explained.htm>

Reducción de la validez

www.testconstruction.com/comp_28.htm

Sitio web de construcción de pruebas (del vínculo anterior)

www.testconstruction.com/contents.htm

La inteligencia y su medición

Desde que la psicología existe como disciplina, los psicólogos han tenido diferencias acerca de la definición de la inteligencia así como del mejor método para medirla.

En este capítulo, analizaremos las variadas maneras en que la inteligencia ha sido definida e inspeccionaremos los modos en que ha sido medida. Concluiremos con el estudio acerca de algunos de los principales aspectos en torno a la práctica de la medición de la inteligencia, incluyendo la relación entre cultura e inteligencia. En el capítulo 9 examinaremos con mayor detalle los aspectos esenciales de las pruebas de inteligencia, enfocándonos en algunas pruebas representativas. La medición de la inteligencia y otros constructos relacionados con la capacidad y el

rendimiento en escenarios preescolares y educativos es el tema del capítulo 10. Sin embargo, comenzaremos planteando una pregunta que, de manera lógica, precede a cualquier consideración con respecto a la medición de la inteligencia.

SÓLO PIENSE...

¿Cómo define *usted* la inteligencia?

¿Qué es la inteligencia?

La **inteligencia** puede ser definida como una capacidad multifacética que se manifiesta de diferentes maneras a lo largo del ciclo vital. En general, la inteligencia incluye las habilidades de:

- adquirir y aplicar el conocimiento
- razonar de manera lógica
- planear de modo efectivo
- hacer inferencias a partir de la percepción
- realizar juicios sólidos y resolver problemas
- comprender y visualizar conceptos
- poner atención
- ser intuitivo
- encontrar con facilidad las palabras y pensamientos correctos
- enfrentar, ajustarse, y aprovechar situaciones nuevas

Todo lo que se ha dicho, por favor, no lo interprete como la última palabra para definir la inteligencia. Más bien, considere esta descripción como un punto de partida para reflexionar acerca

del significado de uno de los términos psicológicos más intrigantes, un término que como veremos, es, de manera paradójica, simple a la vez que complejo.

La mayoría de la gente considera que puede reconocer la inteligencia cuando ésta se manifiesta a través de conductas observables; sin embargo, una definición que sea ampliamente aceptada sigue siendo elusiva (Neisser, 1979). En realidad es importante tal definición (Neisser *et al.*, 1996), si vamos a utilizar el constructo, a diseñar pruebas para medirlo y a actuar con base en los resultados de la prueba. Más allá de intentar crear una definición que incorpore “todas las palabras correctas”, la búsqueda de una definición ampliamente aceptable y adecuada ha inspirado la realización de estudios sobre el metabolismo de la glucosa cerebral (Haier, 1993) y otras investigaciones sobre fisiología cerebral (Vernon, 1993). No obstante, concebir una definición ampliamente aceptada de la inteligencia sigue siendo un reto.

¿Cómo es definida la inteligencia por una persona lego? Y ¿cómo contrastan estas definiciones sobre la inteligencia con las de los estudiosos del tema? A continuación consideraremos estas interrogantes.

Definición de inteligencia: puntos de vista del público lego

La investigación realizada por Sternberg y sus asociados (Sternberg, 1981, 1982; Sternberg y Detterman, 1986; Sternberg *et al.*, 1981) buscaban arrojar luz sobre cómo definen la inteligencia legos y psicólogos. En un estudio, a un total de 476 personas (estudiantes, viajeros, compradores en supermercados, personas que hubieran respondido algún anuncio de los periódicos y otras seleccionadas al azar en directorios telefónicos) se les pidió que enumeraran los comportamientos que asociaran con “inteligencia”, “inteligencia académica”, “inteligencia cotidiana” y “falta de inteligencia”. Después de que se generó una lista de varios comportamientos que caracterizan la inteligencia, se les solicitó a 28 personas, no psicólogos, en el área de New Haven que en una escala de 1 (baja) a 9 (alta) evaluaran qué tan característico era cada uno de los comportamientos para la persona “inteligente” ideal, para la “inteligente académicamente” ideal y para la “inteligente cotidianamente” ideal. También se solicitaron las opiniones de 140 psicólogos investigadores con nivel de doctorado, expertos en el área de la inteligencia. Estos mismos expertos estaban involucrados en investigaciones sobre la inteligencia en importantes universidades y centros de investigación en Estados Unidos.

Todas las personas encuestadas en el estudio de Sternberg tenían ideas definidas sobre lo que era la inteligencia y la carencia de ésta. Para las personas que no eran psicólogos, los comportamientos asociados en forma más común con la inteligencia fueron “razonar con lógica y bien”, “leer mucho”, “mostrar sentido común”, “mantener una mente abierta” y “leer con gran comprensión”. Encabezando la lista de los comportamientos mencionados con mayor frecuencia asociados con la “carencia de inteligencia” fueron “no tolerar la diversidad de opiniones”, “no mostrar curiosidad” y “comportarse con falta de consideración hacia los demás”.

Sternberg y sus colegas agruparon la lista de 250 comportamientos que caracterizan la inteligencia y la falta de inteligencia en subconjuntos que se relacionaban con mayor fuerza entre sí. El análisis indicó que las personas que no eran psicólogos y los expertos, en general, concebían la inteligencia como: habilidad práctica para solucionar problemas (por ejemplo: “escucha todos los puntos de vista de un argumento”); habilidad verbal (“muestra un buen vocabulario”), y competencia social (“llega a tiempo a sus citas”). Cada tipo específico de inteligencia fue caracterizado por varios descriptores. La “inteligencia académica” incluía habilidad verbal, habilidad para la resolución de problemas y competencia social, así como comportamientos específicos asociados con la adquisición de capacidades académicas (como “estudiar duro”). La “inteligencia cotidiana” incluía capacidad práctica de solución de problemas, competencia social, carácter e interés por aprender y cultivarse. En general, los investigadores encontraron un grado de semejanza sorprendente entre las concepciones acerca de la inteligencia de los expertos y de los legos. Sin embargo, respecto a la inteligencia académica, los expertos tendían a enfatizar la motivación (“es persistente”, “muy dedicado y motivado en la elección de metas”), mientras que los legos acentuaban los aspectos interpersonales y sociales de la inteligencia (“sensibilidad

a las necesidades y deseos de otras personas”, “es franco y honesto consigo mismo y con los demás”).

En otro estudio (Siegler y Richards, 1980), a los estudiantes universitarios inscritos en la clase de psicología del desarrollo se les pidió que enumeraran comportamientos asociados con la inteligencia en la infancia, la niñez y la edad adulta. Quizá no de manera sorprendente, se observaron diferentes concepciones de la inteligencia como una función de la etapa del desarrollo. En la infancia, la inteligencia se asoció con la coordinación física, el tener conciencia de las personas, la producción verbal y el apego. En la niñez, fueron enumeradas con mayor frecuencia la destreza verbal, la comprensión y características del aprendizaje. La destreza verbal, el uso de la lógica y la solución de problemas fueron asociados con mayor frecuencia con la inteligencia adulta.

Un estudio efectuado en alumnos de primero, tercero y sexto grados (Yussen y Kane, 1980) sugirió que los niños de primer grado ya tienen nociones de la inteligencia. Las concepciones de los niños más pequeños tendieron a destacar las habilidades interpersonales (ser agradable, ser amable, ser cortés), mientras que los niños mayores subrayaron las académicas (ser bueno en lectura).

Definición de inteligencia: puntos de vista de expertos y profesionales de las pruebas

En un simposio publicado en la *Revista de Psicología Educativa* (Journal of Educational Psychology) en 1921, diecisiete de los principales psicólogos de Estados Unidos abordaron las siguientes cuestiones: 1) ¿qué es inteligencia?, 2) ¿cómo puede medirse mejor en pruebas grupales? y 3) ¿cuáles deberían ser los siguientes pasos en la investigación? No hubo dos psicólogos que hayan estado de acuerdo (véase Thorndike *et al.*, 1921). Seis años después, Spearman (1927, p. 14) reflexionaba:

“En verdad, la inteligencia se ha vuelto... una palabra con tantos significados que al final no tiene ninguno”. Y décadas después de que se realizó el simposio, Wesman (1968, p. 267) concluyó que al parecer “en la actualidad no había más acuerdo general en cuanto a la naturaleza de la inteligencia o a los medios más válidos para medirla de lo que lo hubo hace 50 años”.

SÓLO PIENSE...

¿La mayoría de los profesionales están de acuerdo con una definición de inteligencia?

Como observó Neisser (1979), aunque la *Revista* consideró que el simposio generaría una vigorosa discusión, éste generó más calor que luz y condujo a un incremento general de la exasperación respecto a este tema. Fue sintomática de esta exasperación una declaración desafortunada de un historiador de la psicología y psicólogo experimental —no psicómetra—, Edwin G. Boring (1923, p. 5), quien intentó calmar la discusión declarando que “inteligencia es aquello que la prueba evalúa”. Aunque dicha opinión no carece de mérito por completo (véase Neisser, 1979, p. 225), es una definición insatisfactoria, incompleta y circular. A continuación presentamos las ideas de algunos otros científicos de la conducta a lo largo de la historia, al igual que opiniones más contemporáneas.

Francis Galton Entre otros logros, sir Francis Galton es recordado como la primera persona que publicó algo sobre la heredabilidad de la inteligencia, enmarcando así el debate contemporáneo entre la naturaleza y la crianza (McGue, 1997). Galton (1883) creía que las personas más inteligentes eran aquellas equipadas con las mejores capacidades sensoriales. Esta posición era interesante

SÓLO PIENSE...

¿Cuál fue el error en la lógica de Galton al definir a las personas más inteligentes?

de manera intuitiva debido a que, como observó Galton, “la única información que nos llega concerniente a los eventos exteriores parece que pasa por las vías de nuestros sentidos; y entre mejor perciban los sentidos las diferencias mayor será el campo sobre el que pueden actuar nuestro juicio e inteligencia” (p. 27). Siguiendo esta lógica, las pruebas de agudeza visual o de capacidad auditiva son, en cierto sentido, pruebas de inteligencia. Galton intentó medir

esta clase de inteligencia en muchas de las pruebas sensoriomotrices y otras, relacionadas con la percepción, que él diseñó. En este sentido, precedió la investigación fisiológica más contempo-

ránea que examina, por ejemplo, la relación entre la inteligencia y la velocidad de la conducción nerviosa (Reed y Jensen, 1992, 1993).

Alfred Binet Aunque su prueba, a principios del siglo xx, tuvo el efecto de iniciar el movimiento de evaluación psicológica, tanto sobre inteligencia como sobre otras materias, Alfred Binet no dejó una definición explícita de inteligencia. Escribió que los componentes de la inteligencia incluyen razonamiento, juicio, memoria y abstracción (Varon, 1936). En algunos artículos críticos del enfoque de Galton hacia la evaluación intelectual, Binet y un colega exigieron mediciones más complejas de la capacidad intelectual (Binet y Henri, 1895a, 1895b, 1895c). A diferencia de Galton, Binet estaba motivado por la muy demandante y desafiante tarea de elaborar un procedimiento para identificar a niños escolares parisienses con limitaciones intelectuales, que no podrían obtener beneficios dentro de un programa de instrucción regular, y por tanto con requerimientos de educación especial. Galton consideraba la inteligencia como varios procesos o capacidades distintos que sólo podían evaluarse con pruebas separadas. Por el contrario, Binet afirmaba que cuando uno resuelve un problema particular, las distintas capacidades empleadas no pueden ser separadas, sino más bien, éstas interactúan para producir la solución. Por ejemplo, cuando a un sujeto se le pide que repita los dígitos que se le presentan en forma verbal la memoria y la concentración interactúan. Cuando se analiza su respuesta a dicha tarea, es difícil determinar la contribución relativa de la memoria y de la concentración para la solución exitosa. Esta dificultad es la razón por la que Binet exigía mediciones más complejas de la capacidad intelectual.

David Wechsler La conceptualización de inteligencia de David Wechsler quizá sea mejor resumida en sus propias palabras:

La inteligencia, definida en forma operacional, es la capacidad integral o global del individuo para actuar con determinación; de pensar en forma racional y de tratar de manera efectiva con su medio ambiente. Es integral o global debido a que está compuesta de elementos o capacidades que, aunque no son independientes por completo, son diferenciables desde el punto de vista cualitativo. Al medir estas capacidades, finalmente estamos evaluando la inteligencia. Pero la inteligencia no es idéntica a la simple suma de estas capacidades, sin embargo... La única manera en que podemos evaluarla en forma cuantitativa es por la medición de los diversos aspectos de esas capacidades (1958, p. 7).

En otra parte, Wechsler agregó que hay factores no intelectuales que deben tomarse en cuenta cuando se evalúa la inteligencia (Kaufman, 1990). Entre estos factores se incluyen “capacidades que son más de la naturaleza de la conación, de la afectividad o de rasgos de personalidad [los cuales] incluyen rasgos tales como el impulso; la persistencia, y la conciencia de un objetivo [así como] el potencial del individuo para percibir, y responder a, valores sociales, morales y estéticos” (Wechsler, 1975, p. 136). Binet también había observado que un estudio comprensivo de la inteligencia asimismo implicaba el estudio de la personalidad.

SÓLO PIENSE...

¿Cuál es el papel de la personalidad en la medición de la inteligencia?

Jean Piaget Desde principios de la década de 1960, la investigación teórica del psicólogo suizo del desarrollo Jean Piaget (1954, 1971) ha recibido una atención creciente. La investigación de Piaget está enfocada en el desarrollo de la cognición en los niños: cómo piensan, cómo se entienden a sí mismos y al mundo que los rodea, y cómo razonan y solucionan problemas. Para Piaget, la inteligencia puede concebirse como un tipo de capacidad biológica evolutiva de adaptación al mundo exterior; conforme se desarrollan las habilidades cognoscitivas, la adaptación (en un nivel simbólico) se incrementa y el ensayo y error mental reemplazan al ensayo y error físico real. Pero, según Piaget, se considera que el proceso de desarrollo cognoscitivo no ocurre sólo por medio de la maduración ni sólo por medio del aprendizaje. Creía que las estructuras psicológicas se reorganizan como consecuencia de la interacción con el medio ambiente. Piaget describió cuatro etapas del desarrollo cognoscitivo por las cuales todos atravesamos durante nuestra vida, según su teoría. Aunque los individuos pueden pasar por estas etapas a diferente velocidad y edad,

Piaget creía que su orden era inmutable. Piaget veía el despliegue de estas etapas de desarrollo cognoscitivo como el resultado de la interacción de factores biológicos y del aprendizaje.

De acuerdo con esta teoría, los aspectos biológicos del desarrollo mental están regidos por mecanismos inherentes de maduración. Conforme el niño va alcanzando y atravesando cada una de estas etapas, también va teniendo experiencias dentro de su medio ambiente. Cada nueva experiencia, según Piaget, requiere alguna forma de organización cognoscitiva o de una reorganización en una estructura mental llamada *esquema*. De manera más específica, Piaget usó el término **esquema** para referirse a una acción organizada o estructura mental que, cuando se aplica al mundo, conduce al conocimiento o comprensión. Los bebés nacen con varios **esquemas** simples, incluyendo succionar y agarrar. Al aprender inicialmente a agarrar y llevarse casi cualquier cosa a la boca, los bebés usan estos esquemas para entender y apreciar su mundo. Conforme crece el bebé, los esquemas se vuelven más complicados y están menos ligados a la acción abierta que a transformaciones mentales. Por ejemplo, cuando se suma una serie de números, éstos son transformados mentalmente para llegar al resultado correcto. Los bebés, los niños y los adultos continúan aplicando esquemas a los objetos y eventos para lograr una comprensión, y estos esquemas se reajustan en forma constante.

Piaget suponía que el aprendizaje ocurre por medio de dos operaciones mentales básicas: **asimilación** (organizar en forma activa la nueva información de modo que se adapte a lo que ya se percibe y se piensa), y **adaptación** (cambiar lo que se percibe o se piensa para adaptarlo a la nueva información). Por ejemplo, un niño que ve una mariposa y la llama “pájaro” ha asimilado la idea de mariposa en una estructura mental ya existente, pájaro. Sin embargo, cuando es creado el concepto nuevo de “mariposa”, separado de “pájaro”, se ha empleado

la operación mental de acomodación. Piaget también subrayó la importancia de las actividades físicas y la interacción social entre semejantes para promover un desequilibrio que representa el proceso por el cual las estructuras mentales cambian. El desequilibrio causa que el individuo descubra nueva información, percepciones y habilidades de comunicación.

SÓLO PIENSE...

Proporcione un ejemplo reciente y personal de asimilación y acomodación referente a su propia mente.

Los cuatro periodos del desarrollo cognoscitivo, cada uno representando una forma más compleja de organización cognoscitiva, están delineados en la tabla 8-1. Las etapas van del periodo sensorio-motor, en el que los pensamientos de los bebés están dominados por sus percepciones, hasta el periodo de las operaciones formales, en el que un individuo tiene la capacidad de construir teorías y hacer deducciones lógicas independientemente de la experiencia directa.

Un hilo que conecta las teorías de Binet, Wechsler y Piaget es su enfoque sobre el interaccionismo. El **interaccionismo** se refiere a un concepto complejo que supone que tanto la herencia como el ambiente interactúan para influir en el desarrollo de la inteligencia de cada individuo. Como veremos, otros teóricos se han enfocado sobre otros aspectos de la inteligencia. En las **teorías del análisis factorial**, el enfoque está puesto en identificar de manera precisa la habilidad o grupos de habilidades que constituyen la inteligencia. En las **teorías del procesamiento de información** el objetivo es identificar los procesos mentales específicos que constituyen la inteligencia.

Teorías de análisis factorial acerca de la inteligencia

El análisis factorial es un grupo de técnicas estadísticas diseñadas para determinar la existencia de relaciones subyacentes entre conjuntos de variables, incluyendo las puntuaciones de pruebas. En la búsqueda de una definición de inteligencia, los teóricos han empleado el análisis factorial para estudiar las correlaciones entre diferentes pruebas que miden diversas habilidades, las cuales se presume reflejan un aspecto subyacente de la inteligencia. Ya en 1904, el psicólogo británico Charles Spearman establecía nuevas técnicas para medir las intercorrelaciones entre las pruebas. Encontró que las mediciones de la inteligencia tendían a correlacionarse entre sí en mayor o menor grado. Spearman (1927) formalizó estas observaciones en una influyente teoría acerca de

Tabla 8-1
Etapas del desarrollo cognoscitivo, según Piaget

Etapas	Intervalo de edad	Características del pensamiento
Periodo sensoriomotor	Nacimiento a los 2 años de edad	El niño desarrolla la capacidad de exhibir un comportamiento intencional orientado a una meta; desarrolla la capacidad de coordinar e integrar lo que percibe con sus cinco sentidos; adquiere la capacidad de reconocer el mundo y sus objetos como entidades permanentes (es decir, el bebé desarrolla la "permanencia del objeto").
Periodo preoperacional	2 a 6 años de edad	La comprensión de los conceptos del niño se basa en gran medida en lo que ve; la comprensión del niño de una situación, un evento o un objeto se basa de modo peculiar en un solo aspecto perceptivo del estímulo, por lo común el más obvio; el pensamiento es irreversible (el niño se enfoca en estados estáticos de la realidad y no puede entender las relaciones entre estados; por ejemplo, cree que la cantidad de un conjunto de cuentas cambia si las cuentas se juntan o se dispersan); pensamiento animista (atribuye cualidades humanas a objetos y eventos que no son humanos).
Periodo de operaciones concretas	7 a 12 años de edad	Ahora aparece la reversibilidad del pensamiento; conservación de pensamiento (ciertos atributos del mundo permanecen estables a pesar de alguna modificación aparente); ahora puede solucionar problemas entre las partes y el todo y las tareas de ordenar en serie (capaz de poner sus ideas en orden jerárquico); puede tratar sólo con relaciones y cosas con las que ha tenido experiencia directa; es capaz de observar más de un aspecto de un problema y de establecer con claridad diferencias entre el presente y el tiempo histórico.
Periodo de operaciones formales	12 años de edad en adelante	Incremento en su capacidad de abstraer y de tratar con ideas independientemente de su propia experiencia; mayor capacidad para generar hipótesis y probarlas de un modo sistemático (declaraciones de "si entonces", más alternativas); es capaz de pensar sobre diversas variables que actúan juntas y sus efectos combinados; puede evaluar su propio pensamiento; aplica el aprendizaje a problemas nuevos de una manera deductiva.

la inteligencia general que postulaba la existencia de un factor general de inteligencia (representada con la letra *g* minúscula cursiva), el cual se encuentra conectado de manera parcial a otras habilidades mentales. A esta teoría algunas veces se le llama **teoría bifactorial de inteligencia**, en donde *g* representa la porción de varianza que todas las pruebas de inteligencia tienen en común. Y las fracciones restantes de varianza están determinadas ya sea por algún componente específico (*s*), o por componentes del error (*e*) de este factor general (figura 8-1). Se consideraba que las pruebas que mostraban correlaciones altas y positivas tenían una alta saturación de *g*, mientras que las pruebas con bajas o moderadas correlaciones con otras pruebas de inteligencia eran consideradas como posibles medidas de factores específicos (como la habilidad visual o motriz). Mientras más grande fuese la magnitud de *g* en una prueba de inteligencia, mejor se suponía predeciría la inteligencia en su conjunto.

Spearman (1927) concebía la base del factor *g* como algún tipo de energía mental electroquímica general disponible para que el cerebro solucionara problemas. Además, se le asociaba con la facilidad para pensar en la experiencia individual, y hacer observaciones y extraer principios. Era *g* en lugar de *s* el que se suponía proporcionaba la mejor predicción de la inteligencia en conjunto. Se consideraba que los problemas de razonamiento abstracto eran las mejores medidas de *g* en las pruebas formales. Conforme Spearman y sus estudiantes continuaron su investigación, reconocieron la existencia de una clase intermedia de factores comunes a un grupo de actividades, pero no a todas. Esta clase de factores, llamada **factores de grupo**, no es tan general como *g* ni tan específica como *s*. Ejemplos de estos extensos factores grupales incluyen las capacidades lingüísticas, mecánicas y aritméticas.

Otros teóricos intentaron "cavar más profundo", intentando ser aún más específicos en la identificación y descripción de otros factores además de *g* en la inteligencia. El número de factores




Figura 8-1
Teoría bifactorial de inteligencia de Spearman

Aquí, g representa un factor general de inteligencia y s , un factor específico de inteligencia (específico para una sola actividad intelectual).

enlistados para definir la inteligencia en una teoría de análisis factorial acerca de la inteligencia, en parte, puede depender de qué tan específica sea la teoría para definir habilidades cognitivas discretas. Estas habilidades pueden concebirse de muchas maneras, desde muy generales hasta muy específicas. Como un ejemplo, considere que un investigador ha identificado una habilidad “para repetir una cadena de números presentados de manera verbal” a la que ha denominado “Factor R”. Otra investigadora analiza el Factor R en tres “habilidades facilitantes” o subfactores,

SÓLO PIENSE...

¿Es posible desarrollar una prueba de inteligencia que no esté relacionada con g ?

a los que ha etiquetado como “habilidad para procesar el sonido” (“R1”), “habilidad para retener estímulos presentados de manera verbal” (“R2”) y “rapidez para procesar estímulos presentados de manera verbal” (“R3”). Ambos investigadores presentan evidencia analítica factorial para apoyar sus respectivas posiciones.¹ ¿Cuál de los dos modelos prevalecerá? Si todo lo demás permanece igual, probablemente será el modelo que pudiera tener una mayor aplicación en el mundo real, el que despierte mayor interés intuitivo en términos de cómo debe ser definida la inteligencia, y el que tenga una mayor cantidad de apoyo empírico.

Han sido propuestos muchos modelos de factor múltiple acerca de la inteligencia algunos de ellos, como el desarrollado por Guilford (1967), han intentado explicar las actividades mentales,

1. Recuerde que el análisis factorial puede tomar muchas formas. En un análisis factorial exploratorio, el investigador explora, de manera esencial, qué relaciones existen. En un análisis factorial confirmatorio, es característico que el investigador pruebe la viabilidad de un modelo o teoría propuesta. Algunos estudios de análisis factorial son conducidos en las subescalas de una sola prueba (como la prueba Wechsler), mientras que otros estudios son aplicados en subescalas de dos (o más) pruebas (como las versiones finales de las pruebas de Wechsler y Binet. El tipo de análisis factorial empleado por un teórico bien puede ser la herramienta que presente las conclusiones de ese teórico bajo la mejor luz posible.

disminuyendo el énfasis, si no es que eliminándolo, sobre cualquier referencia a *g*. De manera inicial Thurstone (1938) concibió la inteligencia como compuesta de siete “habilidades primarias”. Sin embargo, después de diseñar pruebas para medir estas habilidades y observar que existía una correlación moderada entre las pruebas, se convenció de que era difícil, si no es que imposible, desarrollar una prueba de inteligencia que no involucrara a *g*. Gardner (1983, 1994) desarrolló una teoría de inteligencias múltiples (de hecho, siete): lógica-matemática, kinestésica-corporal, lingüística, musical, espacial, interpersonal e intrapersonal. Gardner (1983) describió las dos últimas de la siguiente manera:

La inteligencia interpersonal es la habilidad para entender a otras personas: qué las motiva, cómo trabajan, cómo trabajar de manera cooperativa con ellas. Es muy probable que los vendedores, políticos, profesores clínicos y líderes religiosos exitosos sean individuos con un alto grado de inteligencia interpersonal. La inteligencia intrapersonal, un séptimo tipo de inteligencia es una habilidad correlativa, volcada hacia el interior. Es la capacidad de formar un modelo de sí mismo preciso y verídico y ser capaz de utilizarlo para operar de manera efectiva en la vida.

Algunos aspectos del trabajo de Gardner, en particular sus descripciones de **inteligencia interpersonal** e **inteligencia intrapersonal**, han encontrado un medio de expresión en libros populares escritos por otros sobre el tema de la así llamada **inteligencia emocional**. Pero ha sido un tema de debate si los constructos relacionados con la empatía y el autoentendimiento califican más para el estudio de la emoción y la personalidad que para el estudio de la inteligencia. (Davies *et al.*, 1998).

En años recientes, una teoría de la inteligencia primero propuesta por Raymond B. Cattell (1941, 1971) y posteriormente modificada por Horn (Cattell y Horn, 1978; Horn y Cattell, 1966, 1967) ha recibido mucha atención por parte de creadores y usuarios de pruebas. Como lo concibió Cattell originalmente, la teoría postulaba la existencia de dos tipos principales de habilidades cognoscitivas: inteligencia cristalizada e inteligencia fluida. Las habilidades que constituyen la **inteligencia cristalizada** (simbolizada como *Gc*) incluyen habilidades y conocimientos adquiridos, dependientes de su exposición a una cultura particular, así como a la educación formal e informal (vocabulario, por ejemplo). La recuperación de información y la aplicación de un conocimiento general se conciben como elementos de la inteligencia cristalizada. Las habilidades que constituyen la **inteligencia fluida** (simbolizada como *Gf*) son no verbales, relativamente independientes de la cultura, así como de cualquier tipo de instrucción específica (como la memoria para los dígitos). A través de los años, Horn (1968, 1985, 1988, 1991, 1994) propuso la adición de varios factores: procesamiento visual (*Gv*), procesamiento auditivo (*Ga*), procesamiento cuantitativo (*Gq*), velocidad del procesamiento (*Gs*), facilidad para la lectura y la escritura (*Grw*), memoria a corto plazo (*Gsm*), y almacenaje y recuperación de información (*Glr*). Según Horn (1989; Horn y Hofer, 1992) algunas de las habilidades (como el *Gv*) son **habilidades vulnerables** en el sentido de que se debilitan con la edad y, después de un daño cerebral, por lo general no recuperan el nivel que tenían antes de la lesión. Otras de estas habilidades (como *Gq*) son **habilidades mantenidas**; no tienden a debilitarse con la edad, y podrían recuperar el nivel que tenían antes de alguna lesión.

Otro modelo influyente de inteligencias múltiples basado en estudios de análisis factorial es la **teoría de los tres estratos de las habilidades cognoscitivas** (Carroll, 1997). En geología, un estrato es una capa de formación de roca que tiene la misma composición de uno a otro extremo. Los estratos se ilustran en la figura 8-2, junto con la representación de cada uno de los tres estratos en la teoría de Carroll. El estrato o nivel superior en el modelo de Carroll es *g*, o la inteligencia general. El segundo estrato está compuesto de ocho habilidades y procesos: inteligencia fluida (*Gf*), inteligencia cristalizada (*Gc*), memoria y aprendizaje general (*Y*), amplia percepción visual (*V*), amplia percepción auditiva (*U*), amplia capacidad de retención (*R*), amplia velocidad cognoscitiva (*S*), y velocidad de procesamiento/decisión (*T*). Debajo de cada una de las habilidades, en el segundo estrato, se encuentran varios “factores de nivel” y/o “factores de velocidad”, cada uno diferente, según el estrato del segundo nivel al que están vinculados. Por ejemplo, tres factores de nivel vinculados con *Gf* son el razonamiento general, el razonamiento cuantitativo y el razonamiento Piagetiano. Un factor de velocidad vinculado con *Gf* es la velocidad de razonamiento.




Figura 8-2

Los estratos en geología y la teoría de los tres estratos de Carroll

La erosión puede descubrir múltiples niveles de estratos en un acantilado. En psicología, una teoría puede descubrir los estratos de una estructura y función mental hipotética. En la teoría de los tres estratos de Carroll, el primer nivel es g, seguido de un estrato constituido de ocho habilidades y procesos, al que sigue otro estrato que contiene lo que Carroll llama de manera indeterminada “factores de nivel” y “factores de velocidad”.

Cuatro factores de nivel vinculados con Gc son el desarrollo del lenguaje, la comprensión y la habilidad para deletrear, así como la habilidad para la comunicación. Dos factores de velocidad vinculados con Gc son la fluidez oral y la habilidad para escribir. La teoría de los tres estratos es un **modelo jerárquico**, lo que significa que todas las habilidades enlistadas en un estrato son incorporadas en los estratos inferiores.

SÓLO PIENSE...

Cambiando de una analogía basada en la geología a una basada en la química, piense en la tabla periódica, la cual enlistas todos los elementos conocidos. ¿Algún día será posible desarrollar una “tabla periódica”, que sea aceptada de modo general, acerca de todas las habilidades humanas?

El deseo de una conceptualización comprensiva y aceptada de las habilidades cognoscitivas humanas ha llevado a algunos investigadores a intentar extraer elementos de modelos existentes para crear uno nuevo y más completo. Con el uso del análisis factorial y otras herramientas estadísticas, estos investigadores han intentado modificar y reconfigurar los modelos existentes que mejor se ajusten a la evidencia empírica. Una de esas modificaciones que ha ganado una creciente atención es la combinación de la teoría de Cattell-Horn y la de los tres estratos de Carroll. Aunque esta combinación no la inició Cattell, ni Horn ni Carroll, se le conoce como el **modelo** de las habilidades cognoscitivas de Cattell-Horn-Carroll (CHC).

El modelo CHC Los modelos de Cattell-Horn y Carroll son similares en varios aspectos; entre ellos, la designación de amplias habilidades (nivel del segundo estrato en la teoría de Carroll), el cual incluye varias habilidades específicas (nivel del primer estrato en la teoría de Carroll). Aun así, cualquier probable integración de los modelos de Cattell, Horn y Carroll debe explicar las diferencias entre estos dos modelos. Una diferencia tiene que ver con la existencia de un factor general de inteligencia (g). Para Carroll, g es el factor del tercer estrato, que incluye a Gf, Gc y las seis amplias habilidades restantes del segundo estrato. Por contraste, g no tiene lugar en el modelo Cattell-Horn. Otra diferencia entre los dos modelos tiene que ver con si las habilidades denominadas “conocimiento cuantitativo” y “habilidad para leer y escribir” deben ser consideradas una amplia habilidad diferente como lo son en el modelo Cattell-Horn. Para Carroll, todas estas habilidades son habilidades específicas del primer estrato.

Otras diferencias entre los dos modelos tienen que ver con la notación, las definiciones específicas de las habilidades y el agrupamiento de factores específicos relacionados con la memoria.

Kevin S. McGrew (1997) propuso una integración de los modelos Cattell-Horn y Carroll. Con base en un análisis factorial adicional, McGrew y Flanagan (1998) modificaron el modelo inicial CHC de McGrew. En su forma actual, el modelo CHC McGrew-Flanagan muestra diez habilidades “de un amplio estrato” y más de setenta “de un estrato estrecho”, en donde cada una de las habilidades del estrato amplio incluye dos o más de las del estrato estrecho. Las diez habilidades del estrato amplio con sus “nombres clave” en paréntesis se etiquetan como sigue: inteligencia fluida (*Gf*), inteligencia cristalizada (*Gc*), conocimiento cuantitativo (*Gq*), habilidad para leer/escribir (*Grw*), memoria a corto plazo (*Gsm*), procesamiento visual (*Gv*), procesamiento auditivo (*Ga*), almacenamiento y retención a largo plazo (*Glr*), velocidad de procesamiento (*Gs*) y tiempo o velocidad de decisión/reacción (*Gt*).

El modelo CHC de McGrew-Flanagan no toma en cuenta el factor general de inteligencia (*g*). Para entender la razón de esta omisión, es importante entender en primer lugar por qué los autores se dieron a la tarea de crearlo. El modelo fue el producto de esfuerzos diseñados para mejorar la práctica de la evaluación psicológica en la educación (a veces llamada **evaluación psicoeducativa**) al identificar pruebas de diferentes baterías que podrían utilizarse para ofrecer una evaluación comprensiva de las habilidades de un estudiante. Después de haber identificado las habilidades clave, los autores hicieron recomendaciones para la **evaluación de baterías cruzadas** de estudiantes, o una evaluación que empleara pruebas de diferentes baterías e implicaran la interpretación de datos de subpruebas específicas para proporcionar una evaluación comprensiva. De acuerdo con estos autores, *g* no fue empleada en su modelo CHC porque carecía de utilidad en las evaluaciones psicoeducativas. Ellos explicaron que:

La exclusión de *g* no significa que el modelo integrado no se suscriba a una habilidad humana general separada o que *g* no exista. McGrew (1997) la omitió, al igual que fue omitida en el modelo actual integrado, puesto que tiene poca relevancia práctica para la evaluación e interpretación de la batería cruzada (McGrew y Flanagan, 1998, p. 14).

Otras diferencias entre los modelos de Cattell-Horn y Carroll fueron resueltas más con base en estudios del análisis factorial que a juicios concernientes a la relevancia práctica para la evaluación de la batería cruzada. Las habilidades etiquetadas como “conocimiento cuantitativo” y “leer/escribir” fueron concebidas como habilidades amplias distintas, tanto como lo fueron para Horn y Cattell. McGrew y Flanagan se basaron en los escritos de Carroll (1993) para las definiciones de muchas de las habilidades amplias y específicas enlistadas, así como en los nombres clave para estas habilidades.

Como mínimo, la teoría de CHC, como es formulada por McGrew y Flanagan tiene un gran valor desde un punto de vista heurístico. Obliga a practicantes e investigadores por igual a pensar acerca de cómo necesitan ser medidas las muchas habilidades humanas y cuán estrecho o amplio es un enfoque óptimo en términos de su utilidad clínica. Además, estimula a los investigadores a consultar otras teorías las cuales pueden estar maduras para su reexaminación mediante métodos estadísticos como el análisis factorial. Las mejores características de estas teorías pueden entonces combinarse con la meta de desarrollar un modelo de habilidades humanas clínicamente útil y práctico.

SÓLO PIENSE...

¿Está de acuerdo en que *g* tiene poca relevancia práctica en el ámbito educativo?

La perspectiva del procesamiento de la información

Otro enfoque para conceptualizar la inteligencia se deriva del trabajo del neuropsicólogo ruso Aleksandr Luria (1966a, 1966b, 1970, 1973, 1980). Este enfoque se centra en los mecanismos que procesan la información —cómo se procesa la información, en lugar de *qué* se procesa—. Se han distinguido dos tipos básicos de estilos de procesamiento de la información, simultáneo y su-

cesivo (Das *et al.*, 1975; Luria, 1966a, 1966b). En el **procesamiento simultáneo** (o **paralelo**), la información es integrada toda al mismo tiempo. En el **procesamiento sucesivo** (o **secuencial**), cada fragmento de información es procesado de manera individual en forma secuencial. Como su nombre lo indica, el procesamiento secuencial es de naturaleza lógica y analítica; pieza por pieza y una después de otra, la información es ordenada y reordenada de modo que tenga sentido. Cuando trata de anticipar quién es el asesino mientras mira la serie televisiva *La ley y el orden*, por ejemplo, su pensamiento podría ser caracterizado como de naturaleza secuencial; como espectador está integrando en forma constante fragmentos de información que lo llevarán a la solución del problema de “¿quién lo hizo?” La memorización de un número telefónico o el aprendizaje de la ortografía de una nueva palabra es característico de las tareas que implican la adquisición de información por medio del procesamiento sucesivo.

Por el contrario, el procesamiento *simultáneo* puede ser descrito como “sintetizado”; la información es integrada y sintetizada en seguida y como un conjunto. Mientras se detiene frente a una obra de arte en un museo para apreciarla, la información transmitida por ésta es procesada de tal manera que, al menos para la mayoría de nosotros, puede razonablemente ser descrita como simultánea. Por supuesto, los críticos de arte y los conocedores pueden ser excepciones a esta regla general. Las tareas que implican las representaciones mentales simultáneas de imágenes o información implican procesamiento simultáneo. La lectura de mapas es una tarea típica de tal procesamiento.

Algunas pruebas, como la Batería de evaluación para niños de Kaufman (*Kaufman Assessment Battery for Children*; Kaufman y Kaufman, 1983a; 1983b), la cual se estudia en el capítulo 10, se basan en este concepto de una distinción entre procesamiento de información sucesivo y simultáneo. La fuerte influencia de una perspectiva del procesamiento de información también es evidente en el trabajo de otros autores (Das, 1972; Das *et al.*, 1975; Naglieri, 1989, 1990; Naglieri y Das, 1988) quienes han elaborado el **modelo PASS** del funcionamiento intelectual; siendo PASS el acrónimo para planeación, atención, simultáneo y sucesivo. En este modelo, *planeación* se refiere al desarrollo de una estrategia para la solución de problemas, *atención* (también mencionada como *excitación*) se refiere a la receptividad para la información y *simultáneo* y *sucesivo* al tipo de procesamiento de información empleado. Los proponentes del modelo PASS han afirmado que las pruebas de inteligencia existentes no evalúan la planeación de manera adecuada. Naglieri y Das (1997) desarrollaron un Sistema de evaluación cognoscitiva (*Cognitive Assessment System*; CAS), una prueba de habilidad cognoscitiva diseñada expresamente para integrar los factores de PASS. Aunque estos autores de pruebas presentaron evidencias para apoyar la validez de constructo de CAS, otros investigadores han cuestionado si la prueba en realidad está midiendo lo que pretende medir (Keith y Kranzler, 1999; Kranzler y Keith, 1999).

Robert Sternberg propuso otro enfoque del procesamiento de la información para la inteligencia, argumentando que “la esencia de la inteligencia es que provee un medio para goberarnos a nosotros mismos de modo que nuestros pensamientos y acciones sean organizados, coherentes y sensibles tanto a nuestras necesidades internas como a las necesidades del medio ambiente” (Sternberg, 1986, p. 141). Propuso una teoría triádica de la inteligencia con tres elementos principales: metacomponentes, componentes de desempeño y componentes de adquisición de conocimiento. Los metacomponentes están implicados en la planeación de lo que se va a hacer, supervisar lo que se está haciendo y evaluar lo hecho una vez que se ha completado. Los componentes de desempeño administran las instrucciones de los metacomponentes. Los componentes de adquisición de conocimiento están involucrados con “aprender cómo hacer algo en primera instancia” (Sternberg, 1994, p. 221).

Ahora que tiene un antecedente de los distintos modos en que la inteligencia ha sido conceptualizada, observemos con brevedad algunas maneras en que los diseñadores de pruebas han intentado medirla. En los dos siguientes capítulos, analizaremos pruebas específicas con mayor detenimiento.

Medición de la inteligencia

La medición de la inteligencia implica hacer un muestreo del rendimiento de un examinado en diferentes tipos de pruebas y tareas como una función del nivel de desarrollo. En todos los niveles de desarrollo, el proceso de evaluación intelectual también proporciona una situación estandarizada desde la cual puede observarse de cerca el enfoque de un examinado hacia varias tareas. Por consiguiente, ofrece una oportunidad para una evaluación que en sí misma puede tener gran utilidad clínica.

Tipos de tareas utilizadas en las pruebas de inteligencia

En la infancia (el periodo desde el nacimiento hasta los 18 meses de edad), la evaluación intelectual consiste de manera principal en la medición del desarrollo sensorio-motor. Esto incluye, por ejemplo, la medición de respuestas motoras no verbales como voltear, levantar la cabeza, sentarse, seguir con los ojos un objeto en movimiento, imitación de gestos y alcanzar un grupo de objetos (figura 8-3). El examinador que intenta evaluar las capacidades intelectuales y otras relacionadas de los infantes debe ser hábil para establecer y mantener el rapport con los examinados que todavía no conocen el significado de palabras como *cooperación* y *paciencia*. De manera característica, las medidas de inteligencia infantil dependen en gran parte de la información obtenida de una entrevista estructurada con los padres, tutores u otros cuidadores de los examinados.

El enfoque en la evaluación del niño mayor se cambia a las habilidades de desempeño y verbales. De modo más específico, durante el curso de una prueba puede pedírsele al niño que realice tareas diseñadas para producir una base general de información, vocabulario, juicio social, lenguaje, razonamiento, conceptos numéricos, memoria auditiva y visual, atención, concentración y



Figura 8-3
Prueba de la respuesta de alerta

Una técnica de evaluación común en las pruebas de desarrollo infantil es una prueba de la respuesta de alerta. Una **respuesta de alerta** indica la capacidad de respuesta de un bebé y se considera que está presente cuando los ojos del bebé se animan y se ensanchan, esto en contraste con el término **respuesta de orientación**, el cual define la respuesta de voltear en la dirección de un estímulo. Aquí el niño está exhibiendo una respuesta de alerta ante el sonido de la campana.

visualización espacial. La administración de muchos de los reactivos puede ser precedida, como lo prescribe el manual de la prueba, por la enseñanza de reactivos diseñados para proporcionar práctica al examinado en lo que es requerido para un reactivo en particular.

En épocas pasadas, muchas pruebas de inteligencia eran calificadas e interpretadas con referencia al concepto de **edad mental**. La edad mental es un índice que se refiere a la edad cronológica equivalente al propio desempeño en una prueba o subprueba. Este índice se derivó de manera peculiar de referencias a las normas que indican la edad en la que la mayoría de los sujetos son capaces de pasar o, de otro modo, alcanzar el criterio de desempeño.

De manera especial, las pruebas administradas a los niños, cuando son aplicadas en forma individual por un profesional capacitado, al igual que las pruebas administradas individualmente a los adultos, proporcionan al evaluador una oportunidad única para observar las reacciones del niño ante el éxito, el fracaso y la frustración. El examinador puede ver, de primera mano, el enfoque general del examinado en la solución de problemas y la situación de prueba con sus variadas demandas. La observación aguda del comportamiento verbal y no verbal del niño durante la prueba puede producir una riqueza de ideas que en muchos casos arrojarán luz sobre los logros y déficits hasta ahora no identificados y ayudarán a aclarar las ambigüedades que surjan en los datos de la prueba. Para los niños en edad escolar, esa información puede ser útil para una variedad de objetivos que van desde el ajuste individual de un programa de enseñanza hasta decisiones de ubicación en una clase.

De acuerdo con Wechsler (1958, p. 7), las escalas de inteligencia para adultos deben explorar capacidades como retención de información general, razonamiento cuantitativo, lenguaje expresivo y memoria, y juicio social. Los tipos específicos de tareas usados para alcanzar estos objetivos en la escala Wechsler para adultos son iguales que muchas de las tareas empleadas con niños, aunque puede variar el contenido de reactivos específicos. El hecho de que se utilicen materiales-estímulo similares en niños y adultos ha motivado el cuestionamiento de si los niños tienden a estar más motivados cuando se les presentan esos materiales (Marquette, 1976; Schaie, 1978), y si las tareas logran o no obtener una adecuada muestra de las habilidades adquiridas por los adultos (Wesman, 1968). Los editores de pruebas de inteligencia tienen disponibles series de pruebas que pueden ser usadas a lo largo de un periodo que no completamente, pero casi, abarca desde la cuna hasta la tumba.

Las pruebas de inteligencia rara vez son administradas a adultos con propósitos de ubicación escolar. En cambio, se utilizan para obtener información clínica relevante o alguna medida de aprendizaje potencial y adquisición de habilidades.

Un factor más importante que la edad a considerar cuando se desarrolla una prueba de inteligencia es el fundamento o marco teórico de la prueba. Consideremos el papel de la teoría en el desarrollo e interpretación de datos en las pruebas de inteligencia.

La teoría en el desarrollo e interpretación de pruebas de inteligencia

La manera en que medimos la inteligencia tiene que ver en mucho con la idea que tenemos de ella. Un capítulo de *El genio hereditario* (*Hereditary Genius*), de Galton (1869), titulado “Clasificación de los hombres de acuerdo a sus dones naturales” (*Classification of Men According to Their Natural Gifts*) examina las diferencias sensoriales y otras diferencias entre la gente, las cuales creía eran heredadas. Quizá, y no de manera sorprendente, muchas medidas galtonianas de habilidad cognoscitiva eran perceptuales o sensoriomotrices por naturaleza. Alfred Binet escribió de manera extensa sobre qué es la inteligencia, aunque la teoría formal con la que quizá mejor se asocia la prueba de Binet es con la “unidad universal de la función intelectual” de Carl Spearman (1904), con *g* como su pieza central.

David Wechsler también escribió de manera extensa sobre qué es la inteligencia y a menudo enfatizó que es multifacética, es decir, que consiste no sólo en habilidades cognoscitivas, sino también en factores relacionados con la personalidad. Sin embargo, debido a que su prueba original, la Escala Wechsler-Bellevue (W-B, así como todas las pruebas subsecuentes de Wechsler), estipula el cálculo de un CI verbal y un CI de ejecución, algunos han malinterpretado su posición como el representante de una teoría de dos factores de la inteligencia: habilidades verbales y ha-

bilidades de ejecución. Al comentar el desarrollo de W-B y las subpruebas verbales (numeradas de la 1 a la 6) y las subpruebas de ejecución (numeradas de la 7 a la 11), Matarazzo explicó:

Mientras el agrupamiento de las subpruebas en verbales (de la 1 a la 6) y de desempeño (de la 7 a la 11) intenta enfatizar una dicotomía respecto a todos los tipos posibles de habilidades citadas en las pruebas individuales, *no* implica que éstas sean las únicas habilidades involucradas en las pruebas. Tampoco presupone que existan diferentes tipos de inteligencia, por ejemplo, verbal, de manipulación, etcétera. Tan sólo implica que éstas son diferentes maneras en que la inteligencia se manifiesta. Las subpruebas son medidas diferentes de inteligencia, no de diferentes tipos de inteligencia, y la dicotomía en áreas verbales y de ejecución es sólo una de las muchas maneras en las que las pruebas se podrían agrupar (Matarazzo, 1972, p. 196, énfasis en el original).

En una nota al pie de página que acompaña el extracto anterior, Matarazzo señala que las áreas verbales y de ejecución presumiblemente coincidan con los llamados factores primarios de la habilidad mental, postulados primero por Thurstone (1938). A pesar de todo, décadas de investigación mediante el análisis factorial en las pruebas de Wechsler han señalado la existencia de más de dos factores que se conectan. Exactamente cuántos factores son conectados por las varias pruebas de Wechsler y cómo deben ser denominados son cuestiones de acalorados debates. Y eso nos conduce a un punto importante acerca de la teoría y las pruebas de inteligencia. Distintos teóricos con ideas diferentes sobre qué factores son clave en una teoría de la inteligencia pueden buscar (y es posible que encuentren) sus factores preferidos en las pruebas de inteligencia más utilizadas.

Una prueba de inteligencia de Wechsler, o cualquier otra prueba importante, podría ser analizada factorialmente con el objeto de identificar subpruebas que conecten las habilidades cognitivas que se consideran como dominantes en una teoría particular. Como consecuencia, los practicantes e investigadores que se sientan atraídos por el modelo de inteligencia de Cattell-Horn pueden hacer interpretaciones de los datos de la prueba de Wechsler (u otros datos de pruebas de inteligencia) con referencia a ese modelo. Los practicantes e investigadores que encuentren más atractiva la teoría de los tres estratos de Carroll pueden hacer interpretaciones con referencia a ese modelo. Los practicantes e investigadores que encuentren más atractiva la integración de los modelos Cattell-Horn y Carroll pueden hacer interpretaciones con referencia a un modelo Cattell-Horn-Carroll (CHC), como el que propusieron McGrew y Flanagan (1998).

Más allá de establecer un nuevo modelo relacionado con la interpretación sobre pruebas existentes, deben desarrollarse nuevas pruebas para medir las habilidades y factores relacionados descritos en una teoría. Imagine lo que resultaría de desarrollar una prueba de inteligencia a partir de una teoría de la inteligencia. De hecho, no lo imagine; intente hacerlo. Como un ejercicio de convertir una teoría de la inteligencia en una prueba de inteligencia, considere la teoría multifactorial de la inteligencia, desarrollada por un precursor de la psicometría, E. L. Thorndike. De acuerdo con Thorndike (Thorndike *et al.*, 1909; Thorndike *et al.*, 1921), la inteligencia se puede concebir en términos de tres conjuntos de habilidades: inteligencia social (trato con las personas), la inteligencia concreta (trato con objetos), y la inteligencia abstracta (trato con símbolos verbales y matemáticos). Thorndike también incorporó un factor general de habilidad mental (*g*) en la teoría, definiendo *g* como el número total de conexiones nerviosas modificables o “enlaces” disponibles en el cerebro. Para Thorndike, la habilidad personal para aprender está determinada por el número y velocidad de los enlaces que pueden ser ordenados. Ninguna prueba importante de inteligencia que se haya desarrollado se basó en la teoría de factores múltiples de Thorndike. ¡Ésta es su oportunidad! Complete el ejercicio de *Sólo piense...* en esta página antes de continuar leyendo.

SÓLO PIENSE...

Mencione un factor que usted considere es común a todas las pruebas de inteligencia. Explique por qué sería un factor común.

SÓLO PIENSE...

Esboce notas para su propia versión de “La Prueba de inteligencia de Thorndike”. ¿Cómo agruparía los reactivos de la prueba? ¿Qué tipos de reactivos se encontrarían en cada agrupación? ¿Qué tipo de resúmenes de puntuaciones deben reportarse para cada evaluado? ¿Qué tipos de interpretaciones se harían a partir de los datos de las pruebas?

Durante el transcurso del ejercicio *Sólo piense...*, quizá se haya encontrado con algunas preguntas o cuestionamientos sobre cómo una teoría de inteligencia puede en verdad ser aplicada en el desarrollo de una prueba de inteligencia. Bueno, bienvenido al “mundo real” en donde los diseñadores de pruebas han intentado resolver muchas preguntas y puntos de discusión relacionadas con la inteligencia en la teoría y en la práctica.

Inteligencia: algunos puntos de discusión

Naturaleza contra crianza

Aunque en la actualidad la mayoría de los científicos de la conducta cree que la capacidad intelectual medida representa una interacción entre 1) la capacidad innata y 2) las influencias ambientales, dicha creencia no siempre fue popular. Ya desde el siglo XVII, el *preformacionismo* comenzó a ganar terreno, en tanto los científicos de aquella época hacían descubrimientos que parecían apoyar esta doctrina. El **preformacionismo** sostiene que todos los organismos vivos están preformados al nacer. Todas las estructuras de un organismo, incluida la inteligencia, están preformadas al nacer y, por tanto, no es posible hacer mejoras al respecto. En 1672, un científico reportó que las mariposas estaban preformadas dentro de sus capullos y que su maduración era resultado de un desdoblamiento. En ese mismo año, otro científico, estudiando los embriones de pollo, generalizó a partir de sus estudios para extraer una conclusión similar respecto a los humanos (Malphigi, *De Formatione Pulli in Ovo*, 1672, citado en Needham, 1959, p. 167).

La invención del microscopio compuesto a finales del siglo XVII proporcionó una nueva herramienta con la que los preformacionistas podían intentar reunir evidencia que los apoyara. Los científicos confirmaron sus expectativas observando semen bajo el microscopio. Varios investigadores “afirmaron haber visto un caballo microscópico en el semen de un caballo, un animalculo con orejas muy largas en el semen de un burro y gallos diminutos en el semen de un gallo” (Hunt, 1961, p. 38; figura 8-4).

La influencia de la teoría preformacionista se desvaneció poco a poco conforme se produjo evidencia inconsistente con ella. Por ejemplo, la teoría no pudo explicar la regeneración de los miembros en el cangrejo de río y otros organismos. Con el progreso en el área de la genética, el preformacionismo, como la teoría dominante del desarrollo, fue reemplazado poco a poco por el *predeterminismo*. El **predeterminismo** es la doctrina que sostiene que las habilidades de un individuo están predeterminadas por la herencia genética y que ninguna cantidad de aprendizaje o cualquier otra intervención pueden mejorar lo que ya está codificado genéticamente y que se desplegará con el tiempo.

El trabajo experimental con animales fue citado a menudo para apoyar la postura predeterminista. Por ejemplo, un estudio de Carmichael (1927) mostró que las salamandras y sapos recién nacidos, los cuales habían sido anestesiados y privados de la oportunidad de nadar, nadaron más o menos al mismo tiempo que los del grupo control, sin anestesia. El trabajo de Carmichael no tomó en consideración la influencia del medio ambiente en el comportamiento natatorio de las salamandras y los sapos. En estudios paralelos con humanos, Dennis y Dennis (1940) observaron el desarrollo del comportamiento del caminar en niños de la tribu hopi. Se hicieron comparaciones entre niños que pasaron gran parte de su primer año de vida en una cuna y niños que habían pasado ese tiempo sin ser restringidos. Su conclusión fue que no hubo diferencia significativa entre los dos grupos de niños en el momento que comenzaron a caminar y que caminar no es una habilidad que pudiera ser mejorada con la práctica. Se había “demostrado” que caminar es una actividad humana que se desarrolla con la maduración.

Otro exponente de la perspectiva predeterminista fue Arnold Gesell. Generalizando a partir de los primeros estudios con gemelos que mostraron que la práctica tenía poco efecto en tareas como subir escaleras, cortar con tijeras, construir con cubos y abrochar botones, Gesell (con Helen Thompson, 1929) concluyó que “el entrenamiento no trasciende la maduración”. Para Gesell, era, de manera principal, la maduración de mecanismos nerviosos y no el aprendizaje o la experiencia




Figura 8-4
Una célula espermática humana según
un preformacionista

Así es como un científico dibujó una célula de esperma humano cuando la vio por medio de un microscopio, dramático testimonio de la forma en que las creencias de un individuo pueden afectar su percepción (tomado de Hartsoeker, 1694, citado en Needham, 1959, p. 20).

lo más importante en el desarrollo de lo que podría ser definido como inteligencia. Gesell describió el desarrollo mental como una “morfogénesis progresiva de patrones de comportamiento” (Gesell *et al.*, 1940, p. 7) y argumentó que los patrones de comportamiento están determinados por “procesos innatos de crecimiento” que él veía como sinónimo de maduración (Gesell, 1945). Gesell (1954, p. 335) describió la infancia como “el periodo en que el individuo se da cuenta de su herencia racial” y ha razonado que esta herencia “es el producto final de procesos evolutivos que se pueden rastrear hasta una antigüedad en extremo remota”.

¿Está codificada en forma genética la inteligencia y se desarrolla con la maduración? ¿O el ambiente de aprendizaje explica nuestra inteligencia? ¿Naturaleza o crianza? Cuestiones como éstas se han planteado desde que existen conceptos de inteligencia y pruebas para medir estos conocimientos —en ocasiones en medio de gran publicidad y controversia—. Galton creía con firmeza que el genio era hereditario, creencia que fue expresada en trabajos como *El genio hereditario* (*Hereditary Genius*, 1869) y *Hombres de ciencia ingleses* (*English Men of Science*, 1874). Galton obtuvo estas conclusiones no con base en pruebas de inteligencia (las cuales todavía no se habían inventado), sino con base en historias familiares de personas eminentes. Al hacer eso, minimizó en gran medida el papel del enriquecimiento ambiental.

Richard Dugdale, otro predeterminista, argumentó que la degeneración, como el genio, también era heredada. Dugdale (1877) rastreó el linaje inmoral y libertino de la infame familia Jukes y planteó la hipótesis de que el rastro de pobreza, prostitución y holgazanería observado era cuestión de herencia. Complementando el trabajo de Dugdale estaba el libro de Henry Goddard, *La familia Kallikak* (*The Kallikak Family*, 1912). Goddard trazó el linaje de la familia resultante de las uniones legítimas e ilegítimas de un hombre al que nombró con el seudónimo de “Martín Kallikak” (el apellido es una combinación de las palabras griegas para “bueno” y “malo”). Kallikak había procreado hijos con una amante con deficiencias mentales y con otra mujer descrita como normal, con la que se casó. Goddard documentó cómo los descendientes ilegítimos de Kallikak fueron mucho menos aceptables desde el punto de vista social que los legítimos.

La investigación de Goddard fue atacada por imperfecta y con el tiempo fue desacreditada por varias razones:

- La precisión del diagnóstico de los descendientes fue cuestionada. Se había diagnosticado como imbéciles o no a los miembros de la familia a partir de una diversidad de fuentes, desde registros médicos hasta conversaciones con vecinos. El trabajo de campo fue hecho por personas con relativamente poca capacitación, en quienes se delegó la decisión diagnóstica. Aún así, fue sobre estos diagnósticos donde se cimentaron las conclusiones del estudio.
- Los genetistas de la época refutaron la idea de que la imbecilidad era el producto de un solo gen. La experimentación con organismos simples, como los mosquitos de la fruta, había sugerido que la herencia era una cuestión muy compleja, inclusive en los rasgos simples.
- Un defecto básico en el argumento de Goddard radica en el hecho de que conceptualizó la imbecilidad como un gen recesivo. Aún si esto fuera verdad, un hijo o hija imbecil hubiera tenido que haber heredado el gen de *ambos* padres.
- El psiquiatra Abraham Myerson atacó el estudio Kallikak y, en general, al movimiento eugenésico, como pseudociencia. Analizó de nuevo los datos de los estudios que pretendían apoyar la idea de que varias condiciones físicas y mentales podrían ser hereditarias, y criticó aquellos estudios del ámbito estadístico. En especial atacó a Goddard de hacer generalizaciones extensivas sin fundamento a partir de datos cuestionables.

A mediados de la década de 1920, el mismo Goddard se alejó de las teorías sobre los defectos mentales basadas en la herencia y se orientó hacia una postura que se enfocaba en el entorno. Aun así, no se olvidó su trabajo, el cual es citado por eugenistas para apoyar sus causas.

SÓLO PIENSE...

Los eugenistas permanecen bastante vivos en el siglo XXI. ¿Qué explica su éxito? ¿Cómo pueden los profesionales de la evaluación arrojar luz sobre estas cuestiones?

Basado en sus pruebas con una muestra de niños mexicanos y de indios americanos, el padre de la versión estadounidense de la prueba de Binet, Lewis M. Terman, concluyó que las personas de estas culturas eran genéticamente inferiores. El notable estadístico inglés Karl Pearson escribió que, en comparación con los británicos de nacimiento, los judíos inmigrantes eran “un tanto inferiores psicológica y mentalmente” (Pearson y Moul, 1925, p. 126). Esas observaciones parecen incorrectas, incluso prejuiciosas —si no es

que racistas— según las normas actuales, sin embargo, tendían a reflejar las creencias prevalentes de la época.

Aunque los textos de muchos científicos de la conducta de inicios del siglo XX carecen de una consideración erudita acerca del papel de los factores ambientales y culturales (sin mencionar las barreras del lenguaje), subsecuentemente se empezó a promover una literatura de investigación que arrojó luz sobre la cuestión herencia/ambiente. Se descubrió, por ejemplo, que cuando gemelos idénticos son educados por separado, en las pruebas de inteligencia siguen mostrando puntuaciones notablemente similares, aunque no tan similares como si hubieran sido criados juntos (Johnson, 1963; Newman *et al.*, 1937). Los niños nacidos de padres afectados por la pobreza, que fueron dados en adopción a una edad temprana a familias de clase media mejor educadas, tienden a obtener puntuaciones superiores en las pruebas de inteligencia con respecto a las de sus contrapartes quienes no fueron adoptados por familias de una posición socioeconómica más alta, aunque las madres naturales con CI más altos tienden a tener hijos con CI más altos, sin importar en qué familia haya sido criado el niño adoptado (Leahy, 1932, 1935).

En general, los proponentes del lado de la “crianza” en la controversia naturaleza/crianza enfatizan la importancia crucial de factores como el ambiente prenatal y postnatal, la posición socioeconómica, las oportunidades educativas y el modelamiento parental en relación con el desarrollo intelectual. Los defensores de esta perspectiva sospechan de manera característica que los argumentos opuestos que defienden la función de la naturaleza en la controversia se basan más en factores como las inclinaciones políticas que en investigaciones y análisis sólidos e imparciales. En alguna parte entre la retórica que argumenta que la herencia *no* desempeña ningún papel en la inteligencia (Kamin, 1974) y aseveraciones como “La naturaleza ha codificado con colores a grupos de individuos para que, de manera estadísticamente confiable, puedan hacerse predicciones acerca de su adaptabilidad a vidas efectivas e intelectualmente recompensantes y



Figura 8-5
¿Cuánto cuesta ganar?

Durante las Olimpiadas de invierno en Nagano, Japón (1998), el mundo observaba cómo Tara Lipinski se convertía en la figura más joven del patinaje en la historia olímpica al ganar el oro. ¿Cuánto cuesta hacer eso? ¿Hasta qué punto ese logro es cuestión de genes, entrenamiento, motivación y otros factores?

ser usadas en forma provechosa por el pragmático hombre de la calle” (Shockley, 1971, p. 375), se encuentra el terreno medio correspondiente a la postura interaccionista: que la inteligencia, medida por las pruebas de inteligencia, es el resultado de la interacción entre la herencia y el ambiente.

Herencia e interaccionismo Las personas difieren en los niveles de inteligencia del mismo modo en que difieren en los niveles de presión sanguínea, en los niveles de líquido cefalorraquídeo, en la sensibilidad al dolor (Sheffield *et al.*, 2000) y en muchas otras características. Una vez que esto es comprendido, es natural preguntarse por qué las personas difieren en sus capacidades intelectuales. De acuerdo con la perspectiva interaccionista, las personas heredan un determinado potencial intelectual. Exactamente cuánto de este potencial genético es desarrollado depende en parte de la naturaleza del ambiente en el que se han criado. Nadie hasta la fecha ha heredado la capacidad de volar o de tener visión de rayos X. Usted podría pasarse la vida entera en bibliotecas o en cumbres montañosas visitando gurús, pero todos esos estudios no resultarán en la adquisición de la capacidad para volar o ver a través de las cosas porque estas habilidades no han sido codificadas en su estructura genética.

La perspectiva interaccionista en el desarrollo intelectual puede considerarse como muy optimista. De acuerdo con ella, somos libres de convertirnos en todo lo que podemos ser. La idea de que podemos usar el entorno para impulsar nuestro potencial genético hasta el límite puede ser ilustrada de manera gráfica con la referencia a dedicados atletas (figura 8-5).

La estabilidad de la inteligencia

Aunque la investigación sobre la estabilidad de la inteligencia medida en niños pequeños ha producido resultados variados (Dougherty y Haith, 1997; Lamp y Krohn, 1990; Smith, Bolin y Stovall, 1988; Wesman, 1968), la inteligencia parece ser estable durante gran parte de la vida

adulta del individuo (Birren y Schaie, 1985; Shock *et al.*, 1984; Youngjohn y Crook, 1993). Utilizando el archivo de datos de pruebas de inteligencia de la segunda guerra mundial, Gold *et al.*, (1995) aplicaron la misma prueba de inteligencia a una muestra de 326 veteranos, unos 40 años después. En general, los datos señalaron una estabilidad en la inteligencia medida a través del tiempo. Se notaron incrementos en el vocabulario, así como disminuciones en aritmética, analogías verbales y otras habilidades no verbales. Los investigadores concluyeron que la inteligencia del adulto joven fue el factor más determinante del desempeño cognoscitivo como adulto mayor.

La investigación longitudinal sobre la inteligencia adulta, en especial en sujetos mayores, puede complicarse por muchos factores como el grado en que el individuo permanece activo desde el punto de vista mental (Kaufman, 1990), la condición de la salud física (Birren, 1968; Palmore, 1970) y miríadas de otros factores que en potencia pueden confundir (que van desde la medicación hasta la personalidad). También es importante distinguir entre semejanzas y diferencias *grupales* en las capacidades cognoscitivas a lo largo del tiempo y semejanzas y diferencias *intraindividuales*. Puede parecer que la escala completa de CI permanece igual a través del tiempo, aunque las capacidades individuales evaluadas pueden cambiar en forma significativa (Smith *et al.*, 2000).

Ivnik y colegas (Ivnik *et al.*, 1995; Malec *et al.*, 1993) observaron que en muchos estudios efectuados a través del tiempo, las medias de grupo y las desviaciones estándar parecían apuntar a la conclusión de que las habilidades cognoscitivas son notablemente estables en el curso de la vida adulta. Sin embargo, al estudiar los efectos del envejecimiento en una muestra de adultos normales, la variabilidad de las habilidades cognitivas observadas de manera intraindividual puede llevar a conclusiones diferentes. Ivnik *et al.* (1995) encontraron que las habilidades intelectuales verbales son muy estables a través del tiempo, siendo la capacidad de recordar la información recién aprendida la menos estable de las capacidades cognoscitivas que estudiaron. Los investigadores concluyeron: “Estos datos desafían la suposición de que las capacidades cognoscitivas de las personas normales son estables durante largos periodos. En realidad, ninguna de las capacidades cognoscitivas generales medidas en este estudio es estable en absoluto, aunque algunas son más estables que otras” (p. 160).

En la edad adulta tardía, en especial después de los 75 años de edad, se ha observado una declinación en las capacidades cognoscitivas (Nettelbeck y Rabbit, 1992; Ryan *et al.*, 1990; Storandt, 1994). Un estudio comparó el desempeño de médicos mayores de 75 años de edad con el desempeño de colegas más jóvenes en medidas de capacidad cognoscitiva. Los datos resultantes indicaron que el desempeño de los médicos mayores fue alrededor del 26% menor que el del grupo más joven (Powell, 1994).

Un estereotipo popular que alguna vez existió sobre los niños muy brillantes afirmaba que “el que madura pronto se pudre pronto”. Un estudio longitudinal iniciado por Terman en la Universidad de Stanford en 1921 expondría subsecuentemente esta creencia como un mito. Terman y sus colegas identificaron 1 528 niños (con edad promedio de 11 años) cuya inteligencia medida los colocó en el 1% superior del país en funcionamiento intelectual.² Terman dio seguimiento a estos niños por el resto de su propia vida, y los midió en relación con sus logros, desarrollo físico y social, libros leídos, rasgos de carácter e intereses recreativos. Realizó entrevistas con padres, maestros y los propios niños. Algunos de los resultados fueron publicados cuatro años después de comenzado el estudio (Terman *et al.*, 1925), aunque otros investigadores continuaron con la

2. Los niños a los que se les dio seguimiento en el estudio de Terman fueron denominados en tono humorístico como “**Termitas**”. Un Termita, Lee Cronbach, se ganaría más tarde su lugar como una luminaria en el campo de la psicometría. Sin embargo, como reportó Hirsch (1997), Cronbach expresó su creencia de que se cometieron serios errores en la calificación de las pruebas de protocolo de inteligencia de las Termitas. Cronbach (citado en Hirsch, 1997, p. 214) reflexionaba que, “Terman estaba buscando CI altos y sus asistentes se los proporcionaron... Sears [un colega de Terman en Stanford] ha calculado y recalculado mi propio CI y resulta que he vivido con un CI más alto por 10 puntos”.

recolección y el análisis de datos (Oden, 1968; Sears, 1977; Holahan y Sears, 1995). En general, los estudios de Terman sugirieron que los niños dotados tienden a mantener una superior capacidad intelectual.

En contraste con las conclusiones de Terman existe un trabajo más reciente que sugiere que puede haber un punto en el que los niños dotados dejan de proseguir o explotar su don. Winner (2000) escribe que los niños prodigio se pueden quedar “congelados en el conocimiento”. Con esto queremos decir que la aclamación pública obtenida por estos prodigios puede hacer que les sea cada vez más difícil romper con su reconocida habilidad. También, después de padecer duras exigencias por parte de sus familias y otras personas para obtener logros a una edad muy temprana, los niños dotados pueden perder motivación cuando son adultos (Winner, 1996).

De los estudios de Terman también se sabe que los niños dotados tienden a tener tasas de mortalidad más bajas y de mejor salud física y mental que sus contrapartes no dotados. Tienden a tener visiones políticas y sociales moderadas y a tomar decisiones educativas y vocacionales exitosas. Cometan menos delitos que los no dotados. Todo esto suena bien. Sin embargo, existen otras implicaciones de haber sido dotado —véase *Psicometría cotidiana*—.

SÓLO PIENSE...

¿Cómo podría la vida ser diferente para usted si creyera que su CI medido es significativamente más alto de lo que es en realidad? A propósito, como estímulo para este ejercicio, lea la nota al pie de página número 2 de este capítulo.

Otros puntos de discusión

La medición de la inteligencia puede variar como un resultado de factores relacionados con el proceso de medición. Algunos de los muchos factores que pueden afectar la medición de la inteligencia pueden ser la definición de inteligencia del autor de la prueba, la diligencia del examinador, la cantidad de retroalimentación que el examinador proporcione al evaluado (Vygotsky, 1978), la práctica previa a la prueba que ha tenido el evaluado y la capacidad de la persona que interpreta los datos.

Otro factor que puede afectar la medición de la inteligencia es el que se conoce como el efecto Flynn. James R. Flynn, del Departamento de Estudios Políticos de la Universidad de Otago en Dunedin, Nueva Zelanda, publicó algunos hallazgos que fueron tomados en cuenta por aquellos que estudian y utilizan las pruebas de inteligencia en Estados Unidos. En su artículo titulado “El CI medio de los estadounidenses: ganancias masivas de 1932 a 1978”, Flynn (1984) presentó evidencia suficiente de lo que podríamos llamar “inflación de la inteligencia”. Descubrió que la inteligencia medida parecía elevarse en promedio, anualmente a partir del año en que la prueba es normalizada. El crecimiento en el CI medido no se ve acompañado con algún dividendo académico, por lo que no se puede pensar que sea debido a alguna elevación en la “inteligencia verdadera”. Desde entonces el fenómeno ha sido bien documentado no sólo en Estados Unidos, sino también en otros países (Flynn, 1988). La cantidad exacta de la elevación en los CI variará como una función de cierto número de factores, como qué tan específicos a la cultura sean los reactivos y si la medida utilizada es de inteligencia fluida o cristalizada (Flynn, 2000).

El efecto Flynn no es sólo de interés académico, tiene implicaciones y consecuencias en el mundo real. Flynn (2000) observó de manera sarcástica que el estado actual de las cosas le brinda poder a los psicólogos y educadores que examinan a los niños para colocarlos en clases especiales. Aconsejó a los examinadores que, si deseaban que los niños evaluados fueran elegibles para servicios especiales, utilizaran la versión más recientemente normalizada de una prueba de inteligencia. Por otro lado, instó a aquellos examinadores que querían que los niños examinados escaparan del estigma de una etiqueta, utilizaran “la prueba más antigua con la que pudieran liberarlos”, lo que, de acuerdo con Flynn, permite un margen de al menos 10 puntos en la medición de la inteligencia. Debido al bien documentado efecto Flynn, se recomienda extremar las precauciones al tomar decisiones importantes

SÓLO PIENSE...

¿Cuál es su opinión respecto a la ética del consejo de Flynn a los psicólogos y educadores que examinan a niños para su colocación en clases especiales?

Ser dotado

¿Quién es dotado?

Una respuesta informal a esta pregunta podría ser: “alguien cuyo rendimiento se destaca consistentemente en forma positiva” en cualquier área valorada (Witty, 1940, p. 516). Los criterios para **determinar lo dotado**, citados en la legislación como PL 95-561, incluyen la capacidad intelectual (“consistentemente superior”), pensamiento creativo, capacidad de liderazgo, habilidad para realizar actividades artísticas, mecánicas y otras aptitudes psicomotoras. A esa lista, se han agregado muchas otras variables que van de la diversidad de intereses hasta el amor por las metáforas, las ideas abstractas y la novedad. El origen de lo dotado es materia de debate, pero factores como la herencia, la organización atípica del cerebro (O’Boyle *et al.*, 1994; Hassler y Gupta, 1993), y las influencias ambientales, que incluyen al ambiente familiar (Gottfried *et al.*, 1994) son citados con frecuencia.

Identificación del dotado

Las pruebas de inteligencia pueden ayudar a la identificación de miembros de poblaciones especiales en todos los puntos del rango posible de las capacidades humanas —incluso ese grupo de personas excepcionales que son llamadas de manera colectiva “los dotados”—. Como usted podrá sospechar, la identificación exacta de alguien como dotado puede variar en ocasiones, en función del instrumento de medición que se utilice. Las pruebas de inteligencia de Wechsler se usan de manera común. Éstas contienen subescalas etiquetadas como “verbales” y “de ejecución”. En algunos casos, para identificar a los dotados, se ha utilizado una escala compuesta o completa pensada para reflejar la inteligencia global (algunas veces junto con otras medidas).

La puntuación total de la escala de Wechsler ha sido cuestionada porque oscurece el rendimiento superior en las subescalas individuales si el registro total no es superior. La puntuación de la escala completa oculta además una discrepancia significativa, si existiera alguna, entre las puntuaciones verbales y las de ejecución. De modo adicional, cada una de las subescalas no contribuye de igual manera a la inteligencia total. En un estudio que incluía estudiantes dotados como sujetos, Malone *et al.* (1991) advirtieron que sus resultados podrían ser afectados por un **efecto de techo**. Esto es, algunos de los reactivos de la prueba no fueron suficientemente desafiantes —tenían un “techo” demasiado bajo— para medir las capacidades de los estudiantes dotados. Sería preferible tener un rango más amplio de reactivos en el extremo superior del continuo de dificultad. Malone *et al.* (1991, p. 26) previeron que “el uso de la puntuación total del CI para



Cualquiera que haya visto el programa de televisión de El, Misterios y Escándalos sabe que la fama no siempre es todo lo que parece. En cada episodio de esta serie, el conductor A. J. Benza lleva a los espectadores a través de un viaje por lo que él llama “el lado fresco del paseo de la fama en Hollywood”. La moraleja inevitable de cada historia es que cada don puede tener un precio. Aquí, luego de algunos antecedentes acerca de lo que es tener un don y cómo identificarlo, consideraremos su precio.

clasificar a los estudiantes como dotados, o como un criterio de aceptación en programas especiales avanzados, podría contribuir a la falta de reconocimiento de las capacidades de algunos estudiantes”.

De manera ideal, la identificación de los dotados debería hacerse no sólo con base en una prueba de inteligencia, sino también en base a las metas del programa para el que la prueba es aplicada. Así, por ejemplo, si se llevara a cabo un programa de evaluación para identificar a escritores dotados, el sentido común

indica que un componente del programa de evaluación debe ser una muestra de un texto escrito por el examinado y evaluada por una autoridad en la materia. Sin embargo, es verdad que el instrumento más eficaz y más comúnmente usado para identificar niños dotados es una prueba de inteligencia.

Los sistemas escolares en busca de candidatos a programas para dotados podrían emplear una prueba de aplicación grupal por motivos de economía. Una prueba grupal empleada con frecuencia para este propósito es la Prueba de capacidad escolar de Otis-Lennon. Cuando se buscan capacidades o aptitudes sociales, se pueden administrar pruebas como la Prueba de aptitud diferencial o la Prueba sobre la estructura del intelecto (EDI) de Guilford *et al.* (1974). La creatividad se podría evaluar mediante el uso del EDI, por medio de inventarios de personalidad o estudios biográficos o a través de medidas de pensamiento creativo (Davis, 1989).

Otras herramientas de evaluación para identificar a los dotados incluyen estudios de caso, escalas de medición del comportamiento, y técnicas de nominación. Una **técnica de nominación** es un método de búsqueda por apreciación entre iguales en el que se pide a los miembros de una clase, equipo, unidad de trabajo, u otro tipo de grupo que seleccionen (o nominen) personas en respuesta a una pregunta o enunciado. A los miembros de una clase, a los padres o a los maestros se les podría hacer preguntas tales como “¿Quién tiene la mayor capacidad de liderazgo?” “¿Quién tiene las ideas más originales?”, y “¿Quién te gustaría más para que te ayudara con este proyecto?” Aunque la selección del maestro es un método usado ampliamente para identificar niños dotados, no es necesariamente el más confiable (French, 1964; Gallagher, 1966; Jacobs, 1970; Tuttle y Becker, 1980). El niño dotado puede tener un mal comportamiento en el salón de clases, el cual puede ser debido al aburrimiento con el bajo nivel del material presentado. El niño dotado puede hacer preguntas o comentarios que el maestro no entiende o malinterpreta como presuntuosos. Clark (1988) bosquejó los comportamientos específicos que los niños dotados pueden desplegar en el salón de clases.

Los pros y los contras de ser dotado

La mayoría de las personas fácilmente pueden apreciar y enumerar muchos beneficios de ser dotado. Según la naturaleza

de sus dotes, los niños dotados, por ejemplo, pueden leer a una edad en la que sus pares apenas están aprendiendo el alfabeto, hacer álgebra a una edad en la que los no dotados están aprendiendo a sumar, o tocar un instrumento musical con la calidad de un experto a una edad en la que los no dotados batallan con las lecciones introductorias. Los niños dotados pueden obtener admiración y respeto, y los adultos dotados pueden agregar a eso cierto nivel de libertad financiera.

El lado negativo de ser dotado no es tan evidente. Como Plucker y Levy (2001) nos lo recuerdan,

...muchas personas talentosas no son felices, sin importar si se convierten en expertos en sus campos. La literatura contiene un número creciente de estudios de personas con logros por abajo del promedio que fallaron al desarrollar sus talentos y en el cumplimiento de una realización personal. Aún más, incluso los individuos más felices y con mayor talento deben enfrentar considerables obstáculos personales y profesionales derivados de su propio talento. El proceso de lograr éxito profesional, felicidad personal y adaptación implica superar muchos desafíos comunes interrelacionados (p. 75).

Plucker y Levy (2001) citaron la suposición ampliamente mantenida de que “el dotado lo hará bien” como un desafío a ser superado. Otros retos que los individuos dotados deben enfrentar con frecuencia incluyen depresión y sentimientos de soledad (Jacobsen, 1999), algunas veces hasta el punto de idear, planear o cometer suicidio (Weisse, 1990). Estos sentimientos negativos pueden surgir, al menos en parte, como resultado de la presión cultural para ser promedio o “normal” e incluso del estigma asociado con el talento y el ser dotado (Cross *et al.*, 1991, 1993). Plucker y Levy agregan a esto que hay presiones autoimpuestas, lo que con frecuencia conduce a largas horas de estudio o práctica, no sin consecuencias:

Ser talentoso, o excepcional en casi cualquier otra forma, implica una serie de sacrificios personales. Estos sacrificios no son fáciles, en especial cuando el problema es mantener relaciones, tener una familia, o conservar una calidad de vida deseable. A todos nos gustaría creer que una persona puede trabajar duro y desarrollar su talento con pocas ramificaciones, pero esto simplemente no es realista. (Plucker y Levy, 2001, p. 75)

al utilizar una prueba de inteligencia al inicio o al final de su ciclo de normalización (Kanaya *et al.*, 2003).

Consideremos de modo breve otros factores que en mayor o menor grado pueden desempeñar un papel en la medición de la inteligencia: personalidad, género, ambiente familiar y cultura.

Personalidad Sensible a las manifestaciones de la inteligencia en la totalidad del comportamiento humano, Alfred Binet concebía el estudio de la inteligencia como sinónimo del estudio de la personalidad. David Wechsler (1958) también creía que todas las pruebas de inteligencia miden rasgos de temperamento y personalidad, como pulsiones, nivel de energía, impulsividad, persistencia y conciencia de la meta. Investigadores más contemporáneos han expresado opiniones similares respecto a la gran superposición entre la inteligencia y la personalidad (Ackerman y Heggstad, 1997; Sternberg *et al.*, 2003).

Estudios longitudinales y transversales en niños han explorado la relación entre varias características de la personalidad y la medición de la inteligencia. Agresividad hacia los compañeros, iniciativa, alta necesidad de logro, competitividad, curiosidad, seguridad en sí mismo y estabilidad emocional son algunos factores de la personalidad que se asocian con ganancias en la inteligencia medida a través del tiempo. Pasividad, dependencia e inadaptación son algunos de los factores presentes en los niños cuya capacidad intelectual medida no se ha incrementado con el tiempo.

En las discusiones del papel de la personalidad en la medición de la inteligencia de los bebés, se emplea de manera peculiar el término *temperamento* (en lugar de *personalidad*). En este contexto, **temperamento** puede ser definido como la manera distintiva de las acciones y reacciones observables del niño. La evidencia sugiere que los bebés difieren de forma bastante marcada en su temperamento en relación con cierto número de dimensiones, incluyendo el vigor de la respuesta, rango de actividad general, agitación durante el sueño, irritabilidad y capacidad de ser abrazados (Chess y Thomas, 1973). El temperamento de un bebé puede afectar su capacidad intelectual medida en el hecho de que los niños intranquilos e irritables que no disfrutaban ser cargados tienen una influencia recíproca negativa en sus padres —y quizá también en los administradores de pruebas—. Los padres serán menos propensos a cargar a estos niños y pasar más tiempo con ellos; por tanto, también serán menos propensos a participar con ellos en actividades que es sabido estimulan el desarrollo intelectual, como platicar con ellos (White, 1971). Un estudio longitudinal que comenzó con la evaluación del temperamento a la edad de 3 años y siguió a los sujetos hasta la evaluación de la personalidad a los 21 años concluyó que las diferencias en el temperamento estaban asociadas con diferencias en comportamientos relacionados con riesgos en la salud como conducción peligrosa, dependencia del alcohol, sexo sin protección, y delitos violentos (Caspi *et al.*, 1997).

Género Se ha efectuado una gran cantidad de investigación sobre las diferencias cognoscitivas entre hombres y mujeres. Aunque algunas diferencias han sido encontradas en forma consistente, su significancia exacta ha sido materia de controversia. Para concluir su revisión de la bibliografía existente en esta área, Halpern (1997) intentó colocar el problema en perspectiva: “Es igual de significativo preguntar ‘¿Cuál es el sexo más listo?’ o ‘¿Cuál tiene el mejor cerebro?’, que preguntar ‘¿Cuál tiene los mejores genitales?’” (p. 1092). Las razones propuestas para explicar las diferencias de género observadas han sido de naturaleza psicosocial (Eccles, 1987) así como fisiológica (Hines *et al.*, 1992; Shaywitz *et al.*, 1995).

Ambiente familiar ¿Hasta qué punto contribuye el ambiente familiar a la inteligencia medida? La respuesta a esta pregunta relativamente directa es complicada, en parte debido a que se involucran cuestiones acerca de naturaleza/crianza o aspectos del ambiente familiar contra la herencia genética (Baumrind, 1993; Jackson, 1993; Scarr, 1992, 1993). Un nuevo escollo surge en la controversia con la afirmación de que el “ambiente familiar” comienza en el útero y que un

“modelo de efectos maternos” puede integrar datos de manera más satisfactoria que un modelo de efectos familiares (Devlin *et al.*, 1997). A este respecto, se ha reportado que los “gemelos, y en especial gemelos monocigóticos, pueden experimentar diferentes ambientes intrauterinos en forma radical aun cuando compartan el útero al mismo tiempo” (B. Price, citado en McGue, 1997, p. 417).

Cuando menos, podemos comenzar afirmando lo que esperamos sea lo obvio: los niños prosperan en un hogar amoroso donde su seguridad y bienestar son la máxima preocupación y se les da amplia oportunidad para aprender y crecer. Fuera de esto, otros factores ambientales pueden afectar la inteligencia medida, como la presencia de recursos (Gottfried, 1984), el uso paterno del lenguaje (Hart y Risley, 1992), la expresión paterna de interés por el rendimiento (Honzik, 1967) y una explicación paterna sobre las políticas de disciplina en un ambiente hogareño cálido y democrático (Baldwin *et al.*, 1945; Kent y Davis, 1957; Sontag *et al.*, 1958).

SÓLO PIENSE...

¿Qué papel atribuiría a su propio ambiente familiar en relación con sus propias capacidades intelectuales?

Cultura Gran parte de nuestro análisis de la relación entre cultura y evaluación psicológica se aplica, en general, a cualquier consideración de la función de la cultura en la inteligencia medida. Una cultura proporciona modelos específicos para las formas de pensar, actuar y sentir; permite a las personas sobrevivir tanto desde el punto de vista físico como social y dominar y controlar el mundo que los rodea (Chinoy, 1967). Debido a que los valores pueden diferir en forma radical entre grupos culturales y subculturales, personas de diferentes grupos culturales pueden tener opiniones radicalmente diferentes sobre lo que constituye la inteligencia (Super, 1983; Wober, 1974). Debido a que diferentes grupos culturales valoran y promueven diferentes tipos de capacidades y ocupaciones, puede esperarse que examinados de diferentes grupos culturales traigan a la situación de prueba diferentes niveles de capacidad, rendimiento y motivación. Estos niveles diferenciales pueden incluso encontrar expresión en la percepción medida y en las habilidades perceptomotrices. Por ejemplo, trabajando con niños que eran miembros de una comunidad rural en el este de Zambia, Serpell (1979) examinó a sujetos zambianos e ingleses en una tarea que implicaba la reconstrucción de modelos usando lápiz y papel, barro o alambre. Los niños ingleses salieron mejor en las reconstrucciones de lápiz y papel, debido a que éstos eran los materiales con los que estaban más familiarizados. Por el contrario, los niños zambianos salieron mejor usando alambre, debido a que era el medio con el que estaban más familiarizados. Ambos grupos de niños salieron más o menos igual usando barro.

Los reactivos en una prueba de inteligencia tienden a reflejar la cultura de la sociedad donde se emplean dichas pruebas. En la medida en que una puntuación en dicha prueba refleja el grado en que quienes la responden han sido integrados en la sociedad y la cultura, se esperaría que los miembros de las subculturas (así como otros quienes, por cualquier razón, deciden no identificarse con la corriente principal de la sociedad) obtengan puntuaciones inferiores. De hecho, los negros (Baughman y Dahlstrom, 1968; Dreger y Miller, 1960; Lesser *et al.*, 1965; Shuey, 1966), los hispanos (Gerry, 1973; Holland, 1960; Lesser *et al.*, 1965; Mercer, 1976; Simpson, 1970) y los nativos estadounidenses (Cundick, 1976) tienden a obtener puntuaciones más bajas en las pruebas de inteligencia que los blancos o asiáticos (Flynn, 1991). Estos hallazgos son controversiales en muchos aspectos, fluctuando desde la gran diversidad de personas que están agrupadas bajo cada una de estas categorías hasta diferencias en el muestreo. (Zuckerman, 1990). Además, la importancia de dichos hallazgos puede ser cuestionada posteriormente cuando se hagan afirmaciones de diferencias genéticas, debido a la complejidad para separar los efectos de los genes de los efectos del ambiente. Para una compilación autorizada y de valiosa lectura sobre los complejos temas implicados al hacer tales separaciones, el lector interesado debe remitirse a Neisser *et al.* (1996).

Alfred Binet compartió con muchos otros el deseo de desarrollar una medida de inteligencia lo menos contaminada posible por factores como la educación previa y las ventajas económicas. La prueba Binet-Simon fue diseñada para separar “la inteligencia natural de la instrucción

haciendo caso omiso, en la medida de lo posible, del grado de instrucción que el sujeto posee” (Binet y Simon, 1908, p. 93 traducido por Kite). Este deseo de crear lo que podría denominarse una prueba de inteligencia **libre de la cultura** ha resurgido con varios grados de fervor a lo largo de la historia. Una suposición inherente al desarrollo de dichas pruebas es que si los factores culturales pudieran ser controlados, se disminuirían las diferencias entre grupos culturales. Otra teoría relacionada es que el efecto de la cultura podría ser controlado mediante la eliminación de reactivos verbales y confiando exclusivamente en reactivos de desempeño no verbales. Es-

SÓLO PIENSE...

¿Es posible crear una prueba de inteligencia libre de la cultura? ¿Es deseable crear una?

tos reactivos fueron pensados para representar los mejores medios disponibles para determinar la capacidad cognoscitiva de niños y adultos en grupos minoritarios. Por más lógica que pueda parecer esta suposición, no ha sido comprobada en la realidad (Véase, por ejemplo, Cole y Hunter, 1971, y McGurk, 1975).

Las pruebas de inteligencia exclusivamente no verbales no han logrado las altas expectativas de sus creadores. No han demostrado tener el mismo nivel de validez predictiva que las pruebas con una mayor carga verbal. Esto puede deberse al hecho de que los reactivos no verbales no son una muestra de los mismos procesos psicológicos que aquellos con una carga verbal, como los de una prueba de inteligencia convencional. Cualquiera que sea la razón, las pruebas no verbales tienden a no ser buenas para predecir el éxito en diversos ambientes académicos y de negocios. Quizá esto es así debido a que dichos ambientes requieren al menos alguna capacidad verbal.

La idea de desarrollar una prueba de verdad libre de la cultura ha tenido un gran interés intuitivo, pero ha demostrado ser una imposibilidad práctica. Todas las pruebas de inteligencia, en mayor o menor grado, reflejan la cultura en la que fueron diseñadas y en la que serán usadas. Dicho de otro modo, las pruebas de inteligencia difieren en la medida de su *carga cultural*.

La **carga cultural** puede definirse como la magnitud en la cual una prueba incorpora el vocabulario, los conceptos, las tradiciones, el conocimiento y los sentimientos asociados con una cultura particular. Por ejemplo, un reactivo como: “Mencione tres palabras para nieve” tiene una carga cultural elevada, ya que se basa en gran medida en la cultura esquimal en la que existen muchas palabras para nieve. Por el contrario, para examinados de Brooklyn sería muy difícil saber más de una palabra para nieve (bueno, tal vez dos si consideramos *aguanieve*).

Poco después de que se hizo evidente que ninguna prueba podría llamarse en forma legítima “libre de cultura”, comenzaron a publicarse un cierto número de pruebas denominadas culturalmente imparciales. Podemos definir una **prueba culturalmente imparcial** como una prueba o proceso de evaluación diseñado para minimizar la influencia de la cultura en relación con los diferentes aspectos de los procedimientos de evaluación, tales como la administración de las instrucciones, el contenido de los reactivos, respuestas que se requieren de los examinados e interpretaciones realizadas a partir de los datos resultantes. En la tabla 8-2 se enumeran algunas técnicas utilizadas para reducir la carga cultural en las pruebas. Observe que, en contraste con el concepto de *carga de factor* del análisis factorial, el cual puede ser cuantificado, la *carga cultural* de una prueba tiende más a ser un juicio subjetivo, cualitativo y no numérico.

En general, la razón para elaborar reactivos de prueba culturalmente imparciales fue el incluir sólo aquellas tareas que parecían reflejar experiencias, conocimiento y habilidades comunes a todas las diferentes culturas. Además, la totalidad de las tareas fueron diseñadas para que motivaran a todos los grupos (Samuda, 1982). Se hizo un intento por minimizar la importancia de factores como las habilidades verbales que se consideraban responsables de las puntuaciones medias más bajas de varios grupos minoritarios. Por consiguiente, las pruebas culturalmente imparciales tendían a ser de naturaleza no verbal, con instrucciones simples y claras, administradas en forma oral por el evaluador. De manera característica, las tareas no verbales consistían en ensamblar, clasificar, seleccionar o manipular objetos, y en dibujar o identificar diseños geométricos. Algunos reactivos de muestra de la Prueba culturalmente imparcial de Cattell (Cattell Culture Fair Test) se ilustran en el *Close-up* de este capítulo.

En general, si bien se ha reducido la carga cultural en las pruebas de inteligencia culturalmente imparciales, lo mismo sucede con su valor como pruebas de inteligencia. Se encontró que las pruebas culturalmente imparciales carecían de lo que ha sido el sello de las pruebas de inteligencia tradicionales: validez predictiva. Y, aún así, en estas pruebas los miembros de los grupos

Tabla 8-2
Modos de reducir la carga cultural en las pruebas

Cargadas culturalmente	Con carga cultural reducida
Pruebas de lápiz y papel	Pruebas de ejecución
Instrucciones impresas	Instrucciones orales
Instrucciones orales	Instrucciones por medio de mímica
Sin práctica preliminar	Reactivos de práctica preliminar
Lectura requerida	Sólo pictórica
Pictórica (objetos)	Figurativa abstracta
Respuesta escrita	Respuesta oral
Hoja de respuestas separada	Respuestas escritas en la misma prueba
Lenguaje	Sin lenguaje
Pruebas de velocidad	Pruebas de poder
Contenido verbal	Contenido no verbal
Conocimiento objetivo específico	Razonamiento abstracto
Habilidades escolares	Habilidades no escolares
Recuerdo de información aprendida	Solución de problemas novedosos
Contenido graduado de lo familiar a lo aprendido de memoria	Todo el contenido de los reactivos altamente familiar
Dificultad basada en la rareza del contenido	Dificultad basada en la complejidad de la relación de educación

Fuente: Jensen (1980)

minoritarios tendían a obtener puntuaciones más bajas que los miembros de los grupos mayoritarios. Se ha conjeturado que varias características subculturales penalizan de manera injusta a algunos miembros de grupos minoritarios que presentan pruebas de inteligencia, cargadas culturalmente con valores de la raza blanca estadounidense de clase media. Algunos han afirmado, por ejemplo, que los estadounidenses que viven en barrios raciales urbanos comparten creencias y valores comunes que son bastante diferentes de los de la corriente principal en Estados Unidos. Entre estas creencias y valores comunes se incluyen, por ejemplo, una orientación hacia “el vivir al día” y una dependencia de la jerga idiomática para la comunicación verbal. Los indígenas estadounidenses también comparten una subcultura común con valores centrales que pueden influir de manera negativa en su inteligencia medida. El núcleo de estos valores es la creencia de que los individuos deberían ser juzgados con respecto a su contribución en relación con el grupo en lugar de por sus logros individuales. Los indígenas de la Unión Americana también valoran su estilo de vida como relativamente pausado y orientado hacia el presente (Foerster y Little Soldier, 1974).


Frustrados por su aparente incapacidad para elaborar pruebas culturalmente imparciales equivalente a las pruebas tradicionales de inteligencia, algunos diseñadores de pruebas intentaron desarrollar equivalentes de las pruebas tradicionales de inteligencia que fueran específicas para una cultura. Elaboradas en forma expresa para miembros de un grupo cultural o subcultural, se consideró que tales pruebas podían producir una medida más válida del desarrollo mental. Una prueba de inteligencia específica para una cultura elaborada en forma expresa para ser usada con negros fue la Prueba de inteligencia de homogeneidad cultural para negros (*Black Intelligence Test of Cultural Homogeneity*; Williams, 1975), una prueba con 100 reactivos de opción múltiple.

CLOSE-UP

Culturalmente imparciales/ culturalmente cargadas


¿Qué tipos de reactivos de prueba se consideran “culturalmente imparciales”, o al menos más imparciales culturalmente que otros reactivos con mayor carga cultural? Los reactivos de la Prueba de inteligencia culturalmente imparcial (Catea, 1940) reimpresos abajo son una muestra. Mientras observa los reactivos, piense en lo culturalmente imparciales que son en realidad.

Laberintos




Clasificación

Escoja los dos reactivos que no correspondan en cada una de las hileras de figuras.




Series

Escoja una figura de las seis de la derecha que continúe de manera lógica la secuencia de las tres figuras de la izquierda.



Matrices de figuras

De entre las seis alternativas, elija aquella que de manera más lógica complete el patrón que se encuentre arriba de ella.



Reactivos de la Prueba de inteligencia culturalmente imparcial (Cattell, 1940).



En contraste con los reactivos diseñados para ser culturalmente imparciales, considere los reactivos en la Prueba de entendederas de la corteza superior cultural/regional (*Cultural/Regional Uppercrust Savvy Test*; CRUST; Herlihy, 1977). Esta graciosa prueba de inteligencia fue diseñada de manera intencional para ilustrar que está cargada culturalmente. Los miembros de la corteza superior de la sociedad no deberían tener ningún problema para lograr una puntuación perfecta.

1. Cuando usted es "boletinado" en el club campestre, *a*) cabalga con habilidad, *b*) es electo para el consejo administrativo, *c*) se anuncia públicamente que no ha pagado sus deudas, *d*) se le reserva una mesa en el comedor, la use o no.
2. Un arabesco en ballet es *a*) un salto intrincado, *b*) una postura en la que el bailarín se para en una pierna, con la otra extendida hacia atrás, *c*) una serie de pasos ejecutados por una pareja de bailarines hombre y mujer, *d*) un saludo parecido a una reverencia.
3. El Libro Azul es *a*) los lineamientos para la recaudación de impuestos, *b*) una guía de precios de automóviles usados, *c*) un folleto empleado para redactar exámenes de ensayo, *d*) un registro social que enumera a 400 familias prominentes.
4. Brookline se localiza *a*) en los suburbios de Boston, *b*) en Cape Cod, *c*) entre Miami Beach y Fort Lauderdale, *d*) en la costa norte de Chicago.

5. El bístec Wellington es *a*) el rosbif del rey, *b*) filete cubierto de pasta y pâté, *c*) un entremés sazonado con cereza, *d*) carne asada con salsa béarnaise.
6. Choate es *a*) un potro castrado usado en la cacería del zorro, *b*) una escuela preparatoria, *c*) un brandy importado, *d*) el curador del Museo Metropolitano de Arte.
7. El atuendo más formal para los hombres es *a*) corbata blanca, *b*) corbata negra, *c*) smocking, *d*) décolletage
8. *El extranjero* es *a*) la... familia que se mudó al vecindario, *b*) Howard Hughes, *c*) una novela de Camus, *d*) un restaurante elegante en San Francisco.
9. Waterford es *a*) un balneario de salud para la gente con posibilidades, *b*) una "granja" de control de peso *c*) cristal cortado a mano, de Irlanda, *d*) la finca de la familia Rockefeller en el Alto Nueva York.
10. Cenar *alfresco* significa *a*) a la luz de las velas, *b*) una cena bufete, *c*) en un café en la acera, *d*) al aire libre.

De acuerdo con Herlihy (1977), las respuestas calificadas como correctas son 1c), 2b), 3d), 4a), 5b), 6b), 7a), 8c), 9c), 10d).

Teniendo en mente que muchos de los reactivos de esta prueba son actualmente anticuados, aquí tiene tres muestras.³

1. *Día de las madres* significa
 - a) el día de la independencia de los negros
 - b) el día en que se honra a las madres
 - c) el día en que llegan los cheques de la beneficencia
 - d) cada primer domingo en la iglesia
2. *Sangre* significa
 - a) un vampiro
 - b) un individuo dependiente
 - c) una persona lesionada
 - d) un hermano de color
3. Las siguientes son marcas comerciales populares. ¿Cuál de ellas no corresponde?
 - a) Murray's
 - b) Dixie Peach
 - c) Royal Crown
 - d) Preparation H

Mientras usted leía los reactivos anteriores, es probable que haya sonreído y se haya preguntado “¿En realidad esto es una prueba de inteligencia?” o “¿Debo tomar esto en serio?” Si pensó tales cosas, no está solo; es probable que muchos psicólogos se hayan planteado las mismas interrogantes. De hecho, una especie de parodia de la BITCH (las siglas en inglés de la prueba) fue publicada en el número de mayo de 1974 del *Psychology Today* (p. 101) y se llamó prueba “S. O.B. (Son of the Original BITCH; Hija de la BITCH original)”. Sin embargo, la prueba de Williams (1975) pretendía ser una prueba de inteligencia específica para una cultura genuina, la cual fue estandarizada con 100 estudiantes de bachillerato negros en el área de Saint Louis. A Williams se le otorgaron 153 000 dólares por medio del Instituto Nacional de Salud Mental (*National Institute of Mental Health*) por elaborar la BITCH.

En el que probablemente fue uno de los pocos estudios publicados diseñado para explorar la validez de la prueba, la Escala Wechsler de inteligencia para adultos (WAIS), y la BITCH, ambas fueron administradas a solicitantes de empleo en el departamento de policía de Portland, Oregon, sujetos negros ($n = 17$) y sujetos blancos ($n = 116$). Los sujetos negros se desempeñaron mucho mejor en la prueba que los sujetos blancos, con una puntuación media que excedía a la de los blancos en 2.83 desviaciones estándar. El CI medio de los sujetos blancos medido por la WAIS excedía al CI medio de los negros en alrededor de 1.5 desviaciones estándar. Ninguna de las correlaciones entre la puntuación en la BITCH y cualquiera de las variables siguientes para los negros o para los blancos que respondieron la prueba difirió significativamente de cero: el CI Verbal de la WAIS, el CI de ejecución de la WAIS, el CI Total de la WAIS y los años de educación. Aunque la muestra de sujetos negros en este estudio tenía un promedio de más de 2½ años de educación universitaria, y aun cuando su media total en la WAIS fue alrededor de 20 puntos mayor que la de los sujetos negros en general, sus puntuaciones en la BITCH cayeron por debajo del promedio de la muestra de estandarización (alumnos de bachillerato con un rango de edad de 16 a 18 años). ¿Qué mide entonces, la BITCH? Los autores del estudio, Matarazzo y Wiens (1977) concluyeron que la prueba estaba midiendo “sabiduría callejera”.

3. Las respuestas calificadas como correctas son las siguientes: 1(c), 2(d) y 3(d).

Aunque muchas de las pruebas culturalmente imparciales produjeron puntuaciones medias más altas para el grupo minoritario para el que estaban diseñadas en forma específica, carecieron de validez predictiva y proporcionaban poca información útil y práctica.⁴ El conocimiento que se requiere para obtener una puntuación alta en todas las pruebas específicas para una cultura y reducidas para una cultura no ha sido visto como algo relevante para propósitos educativos dentro de una sociedad plural. Tales pruebas tienen validez predictiva baja para el criterio de éxito en ámbitos académicos así como en ambientes vocacionales.

En las diferentes fases del desarrollo de una prueba de inteligencia, incluyendo su elaboración, aplicación e interpretación, pueden emplearse diversos enfoques para reducir el sesgo cultural. Paneles de expertos pueden valorar el sesgo potencial inherente de una prueba recién elaborada, y aquellos reactivos que se juzgue están sesgados pueden ser eliminados. La prueba puede diseñarse de modo que sean relativamente pocas las instrucciones verbales para aplicarla o proporcionar demostraciones de cómo responder, todo en un esfuerzo por minimizar cualquier sesgo posible del lenguaje. Puede llevarse a cabo un ensayo o prueba piloto con muestras de sujetos mixtas desde el punto de vista étnico. Si surgen diferencias en las puntuaciones sólo como función de la pertenencia a un grupo étnico, los reactivos individuales pueden ser estudiados con más meticulosidad en busca de un posible sesgo.

Las principales pruebas de inteligencia han soportado una gran cantidad de escrutinio en busca de sesgos en muchas investigaciones. Los procedimientos abarcan desde el análisis de los reactivos individuales hasta el análisis de la validez predictiva de la prueba. Sólo cuando puede concluirse de manera razonable que una prueba es libre, tanto como puede estarlo, de cualquier sesgo sistemático está disponible para ser usada. Naturalmente, aún si una prueba está libre de sesgo, es importante recordar que pueden existir otras fuentes potenciales de sesgo. Esas fuentes pueden referirse desde el criterio utilizado para hacer una recomendación de evaluación, hasta la conducción misma de la evaluación, e incluso la calificación de los reactivos (en particular aquellos que son un poco subjetivos) y, por último, la interpretación de los resultados.

Una perspectiva

Muchas décadas después de la publicación del Simposio de 1921, los profesionales todavía debaten sobre la naturaleza de la inteligencia y la forma en que debería ser medida. Tras el controvertido libro *La curva de campana* (*The Bell Curve*, Herrnstein y Murray, 1994), la Asociación Psicológica Estadounidense comisionó a un grupo de expertos para que redactara un reporte sobre la inteligencia que llevaría el imprimátur oficial de la psicología. El reporte de los expertos reflejó un amplio desacuerdo respecto a la definición de inteligencia, pero señaló que “Dichos desacuerdos no son causa de desaliento. La investigación científica rara vez comienza con definiciones en las que todos están de acuerdo, aunque con el tiempo pueda conducir a ello” (Neisser *et al.*, 1996, p. 77). Al parecer los expertos ignoraron el hecho de que, en términos de la relativa juventud de la psicología como disciplina (en contraste, por ejemplo, con la geología, la arqueología o la física), la investigación sobre la inteligencia apenas había comenzado. El grupo de expertos también pasó por alto varios de los enfoques más recientes acerca de la inteligencia, así como algunas evidencias y puntos de vista controversiales con respecto a las diferencias entre los grupos con respecto a la medición de la inteligencia (Frumkin, 1997; Lynn, 1997; Reed, 1997; Velden, 1997).

No ha habido escasez de controversias en lo que se refiere al tema de la inteligencia, comenzando con la forma en que la palabra es definida. Una tendencia en años recientes ha sido la de ser mucho más liberales cuando se define y reconoce el comportamiento que se supone es indicativo

4. Quizá el más sólido de los instrumentos desde el punto de vista psicométrico que ha sido diseñado en forma especial para ser usado con sujetos negros fue la Prueba de comprensión de lo que se escucha (*Listening Comprehension Test*; Carver, 1968-1969, 1969; Orr y Graham, 1968). En esta prueba, sin embargo, los negros tendían a obtener puntuaciones inferiores a las de los blancos aun cuando los grupos fueron igualados con respecto a la posición socioeconómica.

de la inteligencia en el mundo real (Detterman, 1986). Así, por ejemplo, leemos exposiciones de “inteligencia gerencial” nada menos que por una autoridad como Robert Sternberg (1997). Dicho trabajo también refleja una tendencia hacia una orientación de contexto al definir la inteligencia. Parece haber más interés en tipos específicos de inteligencia, en oposición a *g* (factor general de inteligencia). Aún así, el desacuerdo sobre “el problema del uno contra los muchos” (Sternberg y Berg, 1986, p. 157) no muestra señales de abatimiento.

Otro problema que no va a desaparecer tiene que ver con las diferencias de grupo en la medición de inteligencia. Aunque es cierto que los seres humanos difieren en tamaño, forma y color —y por consiguiente es razonable considerar que también hay una base física para las diferencias en la capacidad intelectual— discernir dónde y cómo la naturaleza puede diferenciarse de la crianza es una búsqueda académica loable. Aún así, dicha diferenciación permanece no sólo como un asunto muy complejo, sino como uno, de manera potencial, lleno de consecuencias sociales, políticas e incluso legales. Las afirmaciones respecto a las diferencias de grupo pueden ser usadas y se han usado como herramientas políticas y sociales para oprimir a miembros de grupos religiosos, étnicos u otros grupos minoritarios. Esto es de lo más desafortunado, debido a que

SÓLO PIENSE...

En un mercado laboral competitivo de la “vida real”, ¿qué papel, si es que hay alguno, desempeña la “media del grupo de referencia” en la toma de decisiones para otorgar empleos?

como observó Jensen (1980), la varianza atribuible a las diferencias de grupo es mucho menor que la imputable a diferencias individuales. Haciendo eco de este sentimiento está el punto de vista de que “lo que importa para la siguiente persona que usted conozca (en la medida en que las puntuaciones de prueba importan) es la puntuación particular propia de esa persona, no la media de algún grupo de referencia al que pertenezca” (Neisser *et al.*, 1996, p. 90).

La relación entre la inteligencia y un amplio rango de éxitos sociales ha sido bien documentada. Las puntuaciones en pruebas de inteligencia, en especial cuando se usan con otros indicadores,

tienen valor para predecir resultados como el desempeño escolar, los años de educación, incluso la posición social y el ingreso. La inteligencia medida está correlacionada en forma negativa con resultados socialmente indeseables como la delincuencia juvenil (Moffitt *et al.*, 1981). Por éstas y otras razones relacionadas, sería conveniente concentrar la atención de la investigación en el extremo ambiental del espectro de la herencia contra el ambiente. Necesitamos encontrar caminos para fomentar de manera efectiva la medición de la inteligencia por medio de intervenciones ambientales, esto sería lo mejor para engendrar esperanza y optimismo.

Calumniada injustamente por algunos y adorada indebidamente por otros, la inteligencia ha perdurado, y continuará perdurando, como un constructo clave en la psicología y en la evaluación psicológica. Por esta razón, los profesionales que aplican pruebas de inteligencia tienen una gran responsabilidad para la cual es necesario estar preparados a conciencia. Dicho esto, apuramos el siguiente capítulo para examinar algunas de las pruebas de inteligencia usadas en forma más extensa.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo tratando de explicar cada uno de los siguientes términos, expresiones y abreviaturas:

acomodación
asimilación
capacidades mantenidas
capacidades vulnerables
carga cultural
edad mental
efecto de techo
efecto Flynn

esquema
evaluación de batería cruzada
evaluación psicoeducativa
factor *g*
factor *s*
factores de grupo
Gf-Gc
inteligencia

inteligencia cristalizada
inteligencia emocional
inteligencia fluida
inteligencia interpersonal
inteligencia intrapersonal
interaccionismo
modelo jerárquico
modelo PASS

procesamiento paralelo
predeterminismo
preformacionismo
procesamiento secuencial
procesamiento simultáneo
procesamiento sucesivo
prueba culturalmente imparcial
prueba libre de cultura

respuesta de alerta
respuesta de orientación
ser dotado
técnica nominativa
temperamento
teoría CHC
teoría de los tres estratos de las habilidades cognoscitivas

teoría bifactorial de la inteligencia
teorías del análisis factorial de la inteligencia
teorías del procesamiento de información de la inteligencia
“Termitas”

Un vistazo a la red

Consulte los siguientes sitios en la red para obtener más información acerca de los temas analizados en este capítulo.

Definición de inteligencia

www.wilderdom.com/personality/L1-6StudentDefinitions.html

Inteligencia

<http://nicologic.free.fr/GeneralIntelligence.htm>

Asimilación y acomodación de Piaget

www.dmu.ac.uk/~jamesa/learning/assimacc.htm

Teoría CHC

www.iapsych.com/CHCPP/map.htm

http://media.wiley.com/product_data/excerpt/47/04713826/0471382647.pdf

Terman y sus estudios

www.indiana.edu/%7Eintell/terman.shtml

El efecto Flynn

www.indiana.edu/%7Eintell/flynnfrect.shtml

<http://pespmc1.vub.ac.be/FLYNNEFF.html>

<http://home.online.no/~itlandm/Flynn.html>

Charles Spearman y la teoría bifactorial (g)

www.indiana.edu/~intell/spearman.shtml

Puntos de vista sobre la inteligencia

<http://socsci.uwosh.edu/IntroPsych/Ansfield/Sessions/Index/index8.htm>

<http://sq.4mg.com/IQbasics.htm>

www.angelfire.com/hi/psychoedservices/page6.html

Alfred Binet

www.indiana.edu/~intell/binet.shtml

David Wechsler

www.indiana.edu/~intell/wechsler.shtml

Teoría de Gardner de las inteligencias múltiples

www.ericfacility.net/ericdigests/ed410226.html

www.pz.harvard.edu/PIs/HG.htm

www.thomasarmstrong.com/multiple_intelligences.htm

www.swopnet.com/ed/TAG/7_intelligences.html

www.cio.com/archive/031596_qa.html

Artículo sobre inteligencia “inteligente”

www.apa.org/monitor/feb03/intelligent.html

Pruebas de CI en línea (para su posible uso en un ejercicio sobre cómo no elaborar una prueba de inteligencia)

www.queendom.org/tests/iq/classical_iq_r2_access.html

www.iqtest.com/iq-test.html#TEST

Pruebas de inteligencia culturalmente imparciales

www.findarticles.com/cf_dls/g2699/0004/2699000434/p1/article.jhtml

Pruebas de inteligencia

El concepto de inteligencia de alguien que desarrolla pruebas es, en algún sentido, el punto inicial y final en el desarrollo de una prueba de inteligencia. Hasta el grado en que el creador conciba la inteligencia en términos de estructuras mentales, la prueba estará diseñada para ilustrar dichos procesos.

El concepto fundamental de inteligencia manejado para la prueba es una fuerza orientadora, una que se refleja en las decisiones sobre casi cualquier aspecto de la misma, primero, en las consideraciones iniciales sobre el contenido y el formato de los elementos, luego, en los aspectos sobre el puntaje y la interpretación, así como en los procesos para revisar, estandarizar y normalizar los datos obtenidos. Esto es evidente en la forma final de la prueba y en las aplicaciones que se le darán.

En este capítulo se analizan muestras de pruebas individuales y grupales de inteligencia.¹ Como lo atestiguan los textos de referencia como *Tests in Print*, existen muchas y diferentes pruebas de inteligencia. Desde el punto de vista del usuario, se consideran diversos aspectos en el diseño de una prueba:

- la teoría en la que se fundamenta (si existe)
- la facilidad con que se puede administrar
- la facilidad con que se puede calificar
- la facilidad con que pueden interpretarse los resultados para un propósito en particular
- la adecuación y pertinencia de las normas
- la aceptación de los índices de confiabilidad y validez publicados

Algunas pruebas de inteligencia se diseñaron con base en una teoría. Por ejemplo, Louis L. Thurstone consideraba que la inteligencia estaba compuesta por aquello que él nombró *habilidades mentales primarias* (HMP). Thurstone (1938) desarrolló y publicó la Prueba de habilidades mentales primarias, que consistía en pruebas separadas, cada una de las cuales estaba diseñada

1. Nuestro objetivo en éste y en capítulos posteriores, es aportar una descripción breve de una pequeña, aunque representativa, muestra de pruebas en varias categorías. Se seleccionaron sólo algunas pruebas para analizarlas con propósitos ilustrativos. Se le pide al lector no hacer conclusiones sobre el valor de alguna en particular a partir de su inclusión u omisión en dicho análisis.

para medir una HMP: significado verbal, velocidad de percepción, raciocinio, facilidad con los números, memoria mecánica, fluidez verbal y relaciones espaciales. Aunque la prueba no se usó ampliamente, este modelo anticipado de habilidades múltiples inspiró a otros teóricos y creadores de pruebas a explorar diversos componentes de la inteligencia y a medirlos.

Una prueba de inteligencia se puede desarrollar con base en una teoría, pero replantearse en términos de otra. Por ejemplo, se ha escrito mucho sobre una teoría de la inteligencia que contiene características del modelo Cattell-Horn y del Carroll de tres estratos. Esta teoría se ha vuelto conocida como la teoría Cattell-Horn-Carroll (CHC). Conforme ha aumentado la receptividad hacia el modelo Cattell-Horn-Carroll, se han publicado libros y manuales que ilustran cómo se puede usar este modelo para complementar los hallazgos de otras pruebas de habilidad conocidas.

A lo largo de la historia, parece que algunas pruebas se han desarrollado más como algo necesario que como alguna otra cosa. Al inicio del siglo XX, por ejemplo, se le asignó a Alfred Binet la responsabilidad de crear una prueba para detectar a los niños discapacitados en aspectos del desarrollo en las escuelas parisinas. Binet colaboró con Theodore Simon para crear la primer prueba formal de inteligencia en el mundo en 1905. Pronto aparecieron adaptaciones y traducciones del trabajo de Binet en varios países alrededor del mundo. La escala original Binet-Simon ya estaba en uso en Estados Unidos en 1908 (Goddard, 1908, 1910). Para 1912 se había publicado una versión modificada que extendía el rango de edad de la prueba hasta 3 meses (Kuhlmann, 1912). Sin embargo, fue la obra de Lewis Madison Terman en Stanford University, la que culminó en el antecedente de lo que ahora conocemos como la Escala de Inteligencia Stanford-Binet.

En 1916, Terman publicó una traducción y “extensión” de la Escala de Inteligencia Binet-Simon, que incluía nuevos elementos que había distinguido en años de investigación, así como un enfoque metodológico que incluía estudios normativos. Los esfuerzos de Terman ayudaron a acumular reconocimiento y éxito en todo el mundo para la prueba de Binet (Minton, 1988). A continuación se analiza más de cerca la prueba a lo largo del tiempo (véase la tabla 9-1) y en su versión actual.

SÓLO PIENSE...

En la vida cotidiana, las habilidades mentales tienden a operar al unísono y no en forma aislada. Entonces, ¿cuán útil es intentar aislar y medir las “habilidades mentales primarias”?

Las escalas de inteligencia Stanford-Binet

Aunque la primera edición de la prueba **Stanford-Binet** ciertamente tuvo faltas importantes (como la falta de representatividad de la muestra de estandarización), también contenía algunas innovaciones importantes. Fue la primera prueba publicada que proporcionaba instrucciones organizadas y detalladas sobre la aplicación y el puntaje. También fue la primera prueba estadounidense que empleó el concepto de CI y en introducir el concepto de un **reactivo alternativo**, un reactivo para usarse sólo bajo ciertas condiciones. Por ejemplo, podría usarse si el reactivo regular no se hubiera aplicado apropiadamente por el examinador.

En 1926, Lewis Terman inició una colaboración con un colega de Stanford, Maude Merrill, en un proyecto para revisar la prueba que tomó 11 años finalizar. Las innovaciones en la escala de 1937 incluyeron el desarrollo de dos formas equivalentes, nombradas *L* (por Lewis) y *M* (por Maude, de acuerdo con Becker, 2003), así como nuevos tipos de tareas para usarse con personas de nivel preescolar y adultos.² El manual contenía muchos ejemplos para ayudar al examinador en la evaluación. Los autores de la prueba llegaron a extremos entonces sin precedentes para alcanzar una muestra adecuada de estandarización (Flanagan, 1938), y la prueba recibió elogios

2. L. M. Terman no habría dejado indicio alguno de lo que significaban las iniciales de las Formas *L* y *M* si el nombre de su coautor no hubiera empezado con la letra *M*.

Tabla 9-1
Características y posibles limitaciones de la prueba Stanford-Binet a través del tiempo

Año	Ventajas	Limitaciones
1916	Contiene reactivos alternativos en la mayoría de los niveles de edad Comparte reactivos para mantener la continuidad con las versiones anteriores Enfatiza la abstracción y la solución de problemas Extiende el rango de reactivos relativos a la Binet-Simon Se basa en una investigación exhaustiva de la literatura Se realizó una exhaustiva estandarización	Mide inadecuadamente la capacidad mental adulta Tiene puntuaciones y procedimientos administrativos inadecuados en algunos puntos Mide sólo un factor (<i>g</i>) No tiene una desviación estándar de CI no uniforme Tiene sólo una versión Está cargada a la evaluación de habilidades verbales
1937	Contiene reactivos alternativos en la mayoría de los niveles de edad Comparte reactivos para mantener la continuidad con las versiones anteriores Extiende el rango de reactivos Se basa en una investigación exhaustiva de la literatura Contiene más pruebas de desempeño en niveles de edad más tempranos Contiene más normas representativas Incluye una versión paralela Utiliza juguetes para hacer la prueba más atractiva a los niños pequeños Los reactivos verbales permiten a los sujetos mostrar fluidez, imaginación, conceptos poco usuales o avanzados, y uso lingüístico complejo	Algunos reactivos tienen reglas de puntuación ambiguas A la forma M le falta vocabulario Su tiempo de administración es mayor que la versión de 1916 Mide sólo un factor (<i>g</i>) Tiene una desviación estándar de CI no uniforme Los CI no son comparables entre edades La muestra tuvo rangos de edad más altos y un porcentaje mayor de niños urbanos que de población en general Tiene una cobertura desigual de las diferentes capacidades en distintos niveles Está cargada hacia las funciones verbales
1960-1973	Administra diversas y variadas pruebas a cada evaluado para mantener a los niños interesados Conserva los mejores reactivos de las versiones L y M Tiene un mejor diseño que las versiones anteriores El manual presenta reglas claras de puntuación Contiene reactivos alternativos en cada nivel de edad Comparte reactivos para mantener la continuidad con versiones anteriores Elimina reactivos que ya no son apropiados Se basa en una investigación exhaustiva de la literatura Presenta material de estímulo en un librito encuadernado Tiene una desviación estándar de CI uniforme Utiliza juguetes para hacer la prueba más atractiva a los niños pequeños	Tiene un techo inadecuado para los adolescentes y para evaluados muy dotados Sólo mide un factor (<i>g</i>) Separa los estándares de puntuación de los reactivos Se encuentra cargada hacia las funciones y habilidades verbales
1986	Contiene una puntuación compuesta general y varias puntuaciones de factores Comparte reactivos para conservar la continuidad con versiones anteriores El formato es de caballete, con instrucciones, criterios de puntuación y estímulos lo cual facilita la aplicación Enfatiza la abstracción y la solución de problemas; enfatiza menos el razonamiento verbal, comparado con versiones anteriores El manual técnico reporta estudios de validez extensos Tienen procedimientos de aplicación flexibles Contiene techos más altos para adolescentes avanzados que la forma L-M Los conceptos básicos en las pruebas de nivel preescolar se comparan favorablemente con otras pruebas para el mismo rango de edad Contiene instrucciones comprensibles según la edad, en especial para los niños pequeños Utiliza pruebas adaptativas (de encaminamiento) para economizar el tiempo de aplicación y reducir la frustración del examinado Utiliza un marco teórico explícito como guía para el desarrollo de los reactivos y para alinear las subpruebas dentro de la jerarquía diseñada Tiene un rango más amplio de edad que las versiones anteriores (2-0 hasta 23) Extiende en forma creativa muchos tipos de reactivos considerados clásicos	Tiene menor semejanza a un juego que las versiones anteriores; proporciona menos información sobre estilos y estrategias, debido a la menor interacción entre examinado y examinador No contiene juguetes La muestra normativa sobrerrepresenta adultos de nivel gerencial, profesional y con educación universitaria y a sus hijos Tiene una posible falta de comparabilidad en el contenido de puntuaciones de área, en diferentes edades, debido a la variación de las subpruebas usada para la calificación Tiene un énfasis psicométrico y no de desarrollo Tiene una desviación estándar de 16 y no de 15 para las puntuaciones compuestas; $M = 50$, $DE = 8$ para las subpruebas Contiene subjetividad (preferencia del examinador) al determinar las subpruebas utilizadas para calcular la puntuación compuesta No puede diagnosticar el retraso ligero antes de la edad de 4, ni el moderado antes de la edad de 5

Tabla 9-1
(continuación)

Año	Ventajas	Limitaciones
2003	Mayor semejanza a un juego que las versiones anteriores, con gráficos coloridos, juguetes y cosas para manipular Satisface las normas del censo de 2000 en Estados Unidos Contiene una prueba de encaminamiento no verbal y otra verbal Contiene una puntuación general compuesta y diversas puntuaciones de factores Comparte reactivos para conservar la continuidad con versiones anteriores Cubre el rango de edad de 2 años hasta 85+ Las puntuaciones sensibles al cambio permiten la evaluación del desempeño extremo Tiene un formato de caballete con instrucciones, criterios de puntuación y estímulos para facilitar la aplicación El contenido verbal y no verbal en todos los factores está equilibrado Contiene CI no verbal Tiene una desviación estándar de 15 para puntuaciones compuestas, lo que permite una fácil comparación con otras pruebas; $M = 10$, $DE = 3$ para las subpruebas Utiliza pruebas adaptativas (de encaminamiento) para economizar el tiempo de administración y reducir la frustración del examinado Utiliza un marco teórico explícito como guía para el desarrollo de los reactivos y la alineación de las subpruebas dentro de la jerarquía diseñada Extiende los reactivos base, lo que permite una identificación más pronta de los individuos con retardos o con dificultades cognitivas Extiende los reactivos techo/tope para examinar a los adolescentes y a los adultos dotados	No citada

Fuente: Becker, K. A. (2003) *History of the Stanford-Binet Intelligence Scales: Content and Psychometrics* (Stanford-Binet Intelligence Scales, quinta edición, Assessment Service Bulletin No. 1). Itasca, IL., Riverside Publishing. Usado con permiso.

por su logro técnico en las áreas de validez y especialmente, en la confiabilidad. Sin embargo, se mantuvo una seria crítica a la prueba: la falta de representación de los grupos minoritarios en las muestras utilizadas.

Otra revisión de la Stanford-Binet ya estaba en camino en el momento de la muerte de Terman en 1956, a la edad de 79. Esta edición de la prueba, la de 1960, consistió sólo en una forma (nombrada *L-M*), compuesta de los reactivos que se consideraban como los mejores de las dos formas de la prueba de 1937, y no se añadió ningún reactivo a la prueba. Sin embargo, una innovación importante fue el uso de las tablas de **desviación de CI** en lugar de las tablas de razón de CI. Las versiones anteriores de la Stanford-Binet habían empleado la *razón de CI*, que se basaba en el concepto de la edad mental (el nivel de edad en el que un individuo parece funcionar intelectualmente). La **razón de CI** es el cociente resultante de la edad mental de la persona dividida entre su edad cronológica, multiplicada por 100 para eliminar los decimales. Como se ilustra en la fórmula, por su cálculo, aquellos fueron los días cuando un **CI** (entendido como **coeficiente intelectual**) era realmente un cociente.

$$\text{razón de CI} = \frac{\text{edad mental}}{\text{edad cronológica}} \times 100$$

Si la edad mental del niño era igual a su edad cronológica, su CI equivaldría a 100. Comenzando con la tercera edición de la Stanford-Binet, la desviación de CI se usó en lugar de la razón de CI. La desviación de CI refleja una comparación del desempeño del individuo en comparación con el de otras personas de la misma edad dentro de la muestra de estandarización. Esencialmente, el desempeño en la prueba se convierte en una puntuación estándar con una media de 100 y una desviación estándar de 16. Si un individuo se desempeña al mismo nivel que la persona promedio de la misma edad, la desviación de CI es 100. Si el desempeño es una desviación estándar por encima de la media para el grupo de edad del examinado, la desviación de CI es 116.

Se publicó otra revisión de la Stanford-Binet en 1972. Como en las revisiones anteriores, se criticó la calidad de la muestra de estandarización. Específicamente, el manual era vago en cuanto a la cantidad de individuos pertenecientes a minorías en la muestra de estandarización, ya que sólo decía que se había incluido “una porción sustancial” de individuos afroamericanos e hispanos. Es posible que las normas de 1972 también hayan sobrerrepresentado a las grandes comunidades urbanas occidentales (Waddell, 1980).

La cuarta edición de la Escala de inteligencia Stanford-Binet (SB:FE, por sus siglas en inglés; Torndike *et al.*, 1986) representaron una desviación significativa de las versiones anteriores de la Stanford-Binet en la estructuración teórica, en la organización, aplicación, evaluación e interpretación de la prueba. Previamente, se agruparon diferentes reactivos por edad, por lo que se llamó a la prueba **escala de edad**. La SB:FE era una *escala de puntos*. Al contrario de una escala de edad, una **escala de puntuación** es una prueba organizada en subpruebas por categoría de reactivo, no por edad, en la cual se presume que la mayoría de las personas que la toman son capaces de responder correctamente. El manual de la SB:FE contenía un análisis explícito del modelo teórico de inteligencia que condujo la revisión. El modelo estaba basado en el modelo de inteligencia Cattell-Horn (1966). También se podía obtener una *prueba compuesta*, llamada anteriormente una desviación de CI. En general, una **prueba compuesta** puede definirse como una puntuación o índice derivado de la combinación y/o la transformación matemática de una o más puntuaciones de subpruebas. Este breve repaso nos coloca en el punto donde se publicó la edición actual, que se analizará con cuidado a continuación.

Las escalas de inteligencia Stanford-Binet: quinta edición

La quinta edición de la Stanford-Binet (SB5; Roid, 2003a) fue diseñada para aplicarse en evaluados de 2 hasta 85 años (o mayores). La prueba proporciona diversas puntuaciones compuestas, incluyendo una Escala completa de CI, derivada de la aplicación de 10 subpruebas. Todas las puntuaciones de las subpruebas tienen una media de 10 y una desviación estándar de 3. Otras puntuaciones compuestas son un conjunto abreviado de puntuaciones para obtener un CI en diversas escalas, una puntuación de CI verbal, y una de CI no verbal. Todas las puntuaciones compuestas tienen una media en 100 y una desviación estándar de 15. Además, la prueba determina las cinco puntuaciones del Factor índice, correspondientes a cada uno de los cinco factores que se supone mide la prueba (véase la tabla 9-2).

La SB5 está basada en la teoría Cattell-Horn-Carroll (CHC) de las habilidades intelectuales. De hecho, de acuerdo con Roid (2003b), con base en un análisis de factores de las primeras Formas L y M, “los factores CHC se reconocían claramente en las primeras ediciones de las escalas Binet” (Roid, *et al.*, 1997, p. 8). La SB5 mide cinco factores CHC mediante diferentes tipos de tareas y subpruebas en diferentes niveles. La tabla 9-2 resume los cinco nombres de los factores CHC y sus abreviaturas, junto con sus equivalentes en la SB5. También proporciona una definición breve

de la habilidad cognitiva a medir en la SB5, así como las pruebas ilustrativas SB5 verbal y no verbal, diseñadas para medir la habilidad.

Al diseñar la SB5, se hizo un intento por obtener un balance igual entre las tareas que requerían facilidad con el lenguaje (expresivo y receptivo) y tareas que minimizan demandas de uso del lenguaje. En la última categoría hay subpruebas que usan elementos pictóricos con pocas instrucciones vocales que administra el examinador. La respuesta del examinado a tales reactivos puede ser en forma de señalamiento no verbal, con gestos o manipulaciones.

SÓLO PIENSE...

Una crítica sobre dicho equilibrio podría implicar que viviéramos en una sociedad donde la capacidad para expresarse con el lenguaje sea muy valorada y que, por tanto, se le deba dar más peso en cualquier medición de la capacidad general. ¿Cuál es su respuesta?

Estandarización Después de aproximadamente cinco años en el desarrollo y análisis exhaustivo sobre las posibles objeciones relacionadas con las tendencias de género, raciales/étnicas, culturales o religiosas, se desarrolló la edición final de estandarización. Cerca de 500 examinadores de los 50 estados, se capacitaron para administrar la prueba. Los examinados en la muestra norma-

Tabla 9-2
CHC y factores SB5 correspondientes

Nombre del factor CHC	Nombre del factor SB5	Definición breve	Subprueba muestra SB5
Inteligencia fluida (<i>Gf</i>)	Razonamiento fluido (FR)	Solución de problemas; comprensión de las relaciones que no están vinculadas culturalmente	Serie de objetos/matrices (no verbal) Analogías verbales (verbal)
Conocimiento cristalizado (<i>Gc</i>)	Conocimiento (KN)	Habilidades y conocimiento adquiridos mediante educación formal e informal	Absurdos gráficos (no verbal) Vocabulario (verbal)
Conocimiento cuantitativo (<i>Gq</i>)	Razonamiento cuantitativo (QR)	Conocimiento del pensamiento matemático, incluyendo conceptos numéricos, estimación, solución de problemas y medición	Razonamiento cuantitativo verbal (verbal) Razonamiento cuantitativo no verbal (no verbal)
Procesamiento visual (<i>Gv</i>)	Procesamiento visual-espacial (VS)	Capacidad para ver patrones, relaciones y orientación espacial así como la gestalt entre diversos estímulos visuales	Posición y dirección (verbal) Forma de los bordes (no verbal)
Memoria de corto plazo (<i>Gsm</i>)	Memoria funcional (WM)	Proceso cognitivo de almacenamiento temporal y luego la transformación o clasificación de la información en la memoria	Memoria para frases (verbal) Respuesta retrasada (no verbal)

tiva fueron 4 800 sujetos de 2 a 85 años. La muestra fue representativa en términos nacionales de acuerdo con los datos del censo de 2000 en Estados Unidos, estratificada conforme a las edades, razas, etnias, regiones geográficas y nivel socioeconómico. No se hicieron acomodos para personas con necesidades especiales en la muestra de estandarización, aunque tales acomodos se hicieron en estudios por separado. Se excluyó a personas de la muestra de estandarización (aunque se incluyeron en otros estudios de validez), si tenían un dominio limitado del inglés, condiciones médicas severas, severo déficit sensitivo o de comunicación o una severa alteración emocional o de conducta (Roid, 2003b).

Validez psicométrica Para determinar la confiabilidad de la escala completa de CI SB5 con la muestra normativa, se empleó una fórmula de confiabilidad de la consistencia interna diseñada para diversas pruebas (Nunnally, 1967, p. 229). Los coeficientes calculados para la escala completa de CI SB5 fueron consistentemente altos (.97 a .98) en los grupos de edad, así como la confiabilidad de la Batería abreviada de CI (promedio de .91). Los coeficientes de confiabilidad en el intervalo test-retest reportados en el manual también fueron altos. El intervalo test-retest fue entre 5 y 8 días —menor por 20 a 25 días que el intervalo empleado en otras pruebas comparables—. Los coeficientes de confiabilidad interpuntuaciones reportados en el manual técnico de la SB5 fueron de .74 a .97 con una media general de .90. Los reactivos que mostraron especialmente poco acuerdo interpuntuaciones se eliminaron durante el proceso de desarrollo de la prueba.

La evidencia de validez relacionada con el contenido de los reactivos de la SB5 se estableció en varias formas, desde la aportación experta al análisis empírico de los reactivos. La evidencia relacionada con el criterio se presentó en forma de datos congruentes y predictivos. Para los estudios de congruencia, Roid (2003b) estudió las correlaciones entre la SB5 y la SB:FE, así como entre la SB5 y las entonces tres principales baterías Wechsler (WPPSI-R, WISC-III y WAIS-III). Las correlaciones fueron altas al comparar la SB5 con la SB:FE y, tal vez, como se esperaba, menores en promedio con las escalas de Wechsler. Roid (2003b) atribuyó la diferencia en parte a los diversos grados en que se presumía que las pruebas SB5 y las de Wechsler evaluaban el factor *g*. Para establecer la evidencia de validez predictiva, se emplearon correlaciones con pruebas de logro (Prueba de logro de Woodcock Johnson III y la Prueba individual de logro de Wechsler, entre otras) y los hallazgos se reportaron en el manual. Roid (2003) también presentó diversos estudios sobre el análisis de los factores para apoyar la validez de constructo de la SB5.

Administración de la prueba Los elaboradores de pruebas de inteligencia, y en particular quienes elaboran pruebas de inteligencia para niños, de manera tradicional han sido sensibles a la necesidad de **pruebas adaptativas**. Las pruebas adaptativas son aquellas que se adaptan de manera individual a quien responde la prueba. Otros términos usados para referirse a estas pruebas incluyen *pruebas adaptadas a la medida*, *pruebas secuenciales*, *pruebas ramificadas* y *pruebas de respuesta contingente*. Según se emplean en las pruebas de inteligencia, las adaptativas podrían plantear a quien responde la prueba, una pregunta en el rango medio de dificultad. Si el individuo responde en forma correcta al reactivo, se plantea a continuación un reactivo de dificultad mayor. Si el individuo responde en forma incorrecta el reactivo, se plantea un reactivo de menor dificultad. Las pruebas adaptativas en esencia están diseñadas para “imitar en forma automática lo que haría un evaluador sensato” (Wainer, 1990, p. 10).

Las pruebas adaptativas ayudan a asegurar que los primeros reactivos de una prueba o subprueba no sean tan difíciles como para frustrar a quien responde la prueba pero tampoco tan fáciles como para que quien responde la prueba tenga una falsa sensación de seguridad o un estado mental en el que la tarea no se tomará con la seriedad necesaria. Otras tres ventajas de empezar una prueba o subprueba de inteligencia en un nivel óptimo de dificultad son éstas: 1) permite que el usuario de la prueba recopile la cantidad máxima de información en la cantidad mínima de tiempo, 2) facilita la empatía y 3) minimiza el potencial de fatiga del examinado como resultado de aplicar demasiados reactivos.

Después de que el administrador ha establecido empatía con quien responde la prueba, comienza el examen de manera formal con un reactivo de lo que se conoce como *prueba de encaminamiento*. Una **prueba de encaminamiento** se puede definir como una tarea usada para dirigir o encaminar al examinado a un nivel particular de preguntas. Un propósito de la prueba de encaminamiento, entonces, es guiar al niño a reactivos de prueba que tienen una alta probabilidad de tener un nivel óptimo de dificultad. Se seleccionó Vocabulario como la prueba de encaminamiento porque el conocimiento general de palabras está muy correlacionado con la capacidad intelectual general. Existen dos pruebas de encaminamiento en la SB5, cada una de las cuales se puede llamar por su nombre de actividad (Series de objetos/Matrices y Vocabulario) o por sus nombres relacionados con los factores (Razonamiento fluido no verbal y Conocimiento verbal). Por cierto, estos dos nombres de subpruebas, y sólo éstos, se administran con el propósito de obtener la puntuación de la Batería abreviada de CI.

Las pruebas de encaminamiento, así como muchas de las otras subpruebas, contienen **reactivos de muestra**, diseñados para ilustrar la tarea requerida y asegurar al examinador que el examinado entiende. Los aspectos cualitativos del desempeño de un examinado a lo largo de los reactivos de muestra pueden registrarse en forma de observaciones del examinador dentro del protocolo de la prueba. Sin embargo, el desempeño en los reactivos de muestra no se registra formalmente, y el desempeño en tales reactivos de ninguna forma entra en los cálculos de cualquier otra puntuación.

Para hacer un muestreo de los pormenores sobre administrar la SB5. Todos los reactivos de la prueba SB5 están contenidos en tres cuadernos de aplicación. El libro 1 contiene las primeras dos subpruebas (de encaminamiento). Después de que la segunda subprueba se ha administrado, el examinador ha registrado las puntuaciones de habilidad estimada, diseñadas para identificar un punto de partida apropiado en los libros de aplicación 2 y 3. El examinador administra las siguientes cuatro subpruebas no verbales desde un nivel apropiado del libro 2. Estas subpruebas se llaman de Conocimiento, Razonamiento cuantitativo, Procesamiento visual-espacial, y Memoria funcional. El examinador administra entonces las cuatro subpruebas verbales del libro 3, de nuevo inicia en un punto apropiado. Las cuatro subpruebas verbales se llaman Razonamiento fluido, Razonamiento cuantitativo, Procesamiento visual-espacial y Memoria funcional.

Aunque muchas de las subpruebas de las escalas verbales y no verbales comparten el mismo nombre, incluyen diferentes tareas. Por ejemplo, una *medida verbal* de Memoria funcional es una llamada Memoria para frases, donde la tarea del examinado es repetir frases y enunciados breves. Una *medida no verbal* de la Memoria funcional, Respuesta retrasada, implica una tarea completamente distinta, una reminiscencia del juego de las conchas o de la jugada de tres cartas (cuando se juega con cartas), que suele jugarse en muchas calles (véase la figura 9-1). Tales juegos callejeros, así como la tarea más estandarizada de la SB5, requieren de la memoria visual y de una




Figura 9-1
Mantenga su ojo en el premio

Los jugadores del juego de los vasos saben que deben seguir el objeto escondido conforme su posición cambia bajo uno de tres vasos o tazas. En la nueva subprueba SB5 llamada Reacción retardada, el examinador coloca objetos bajo tazas y luego manipula la posición de éstas. La tarea del examinador es localizar el objeto escondido después de una breve pausa. En el SB5, el “premio” al desempeño exitoso se presenta en la forma de puntuación que entra en el cálculo de la inteligencia medida, no como en la fotografía, como una remuneración monetaria a un apostador.

posible mediación verbal. Se presume que el último proceso ocurre durante el retraso, el examinado (o espectador del juego) *subvocaliza* (verbaliza en el pensamiento, no en voz alta) el nombre del objeto escondido y el camino que sigue mientras se le manipula.

Algunas maneras en que los reactivos de una subprueba en pruebas de inteligencia u otras habilidades, son descritos por profesionales de la evaluación, tienen similitudes en su hogar. Por ejemplo, existe el *piso*. En la jerga de las pruebas de inteligencia, **piso** se refiere al nivel más bajo de los reactivos de una subprueba. Entonces, por ejemplo, si los reactivos de una subprueba en particular abarcaran el rango de habilidad que va desde *retrasado en el desarrollo* en un extremo del espectro hasta *intelectualmente sobredotado* en el otro, el reactivo de nivel más bajo del extremo anterior se consideraría el *piso* de la subprueba. El reactivo de nivel más alto es el **techo**. En la escala Binet, otro término útil, éste para describir una subprueba en referencia a un desempeño específico del examinado, es el *nivel basal*. Muchas subpruebas de la escala Binet tienen reglas para establecer un **nivel basal**, o un nivel base de criterio que debe satisfacerse para que la subprueba continúe. Por ejemplo, una regla para establecer un nivel basal podría ser “El examinado contesta dos reactivos consecutivos correctamente”. Cuando, y si los examinados se equivocan en cierta cantidad de reactivos en una columna, se dice que se ha alcanzado un **nivel techo**, y se suspende la subprueba.³

3. Los examinadores experimentados que han tenido ocasión de probar los límites de un examinado le dirán que esta suposición no siempre es correcta. **Probar los límites** es un procedimiento que implica la aplicación de reactivos de prueba más allá del nivel en que el manual dicta la interrupción o discontinuación. El procedimiento puede ser empleado cuando un examinador tiene razones para creer que un examinado puede responder en forma correcta los reactivos en el nivel superior. En una prueba de capacidad estandarizada como la SB:FE, se deben respetar las pautas, por lo menos en términos de puntuación. Los examinados no ganan créditos formales por pasar los reactivos más difíciles, en su lugar, el examinador simplemente anotará en el protocolo que la prueba de los límites se condujo en relación con una subprueba en particular y luego deberá registrar los hallazgos.

Para cada sup prueba en la SB5, existen reglas explícitas sobre dónde *comenzar*, dónde *regresar* y dónde *parar* (o *descontinuar*). Por ejemplo, un examinador podría comenzar en el nivel de habilidad actual estimado del examinado. El examinador podría regresar si el examinado obtiene 0 en los primeros dos reactivos a partir del punto de inicio. El examinador podría descontinuar la prueba (detenerse) después de cierta cantidad de fallas después de regresar. El manual también proporciona reglas específicas para motivar a los examinados. Si se da una respuesta vaga o ambigua en algunos reactivos verbales en subpruebas como vocabulario, absurdos verbales o analogías verbales, se pide que el examinador de al examinado pautas como “Dime más”.

SÓLO PIENSE...

¿En qué forma(s) podría un examinador dar mal uso o abusar de la obligación para motivar a los examinados? ¿Cómo se podría prevenir ese mal uso o abuso?

Aunque a algunas de las subpruebas se les toma el tiempo, a la mayoría de los reactivos de la SB5, no. La prueba se hizo de esta forma para adecuarse a aquellos evaluados con necesidades especiales o capacidades diferentes, y al modelo teórico de respuesta a reactivos usado para calibrar la dificultad de los reactivos.

Calificación e interpretación El manual de la prueba contiene instrucciones explícitas para aplicar, calificar e interpretar la prueba, al igual que numerosos ejemplos de respuestas correctas e incorrectas útiles en la calificación de reactivos individuales. Las calificaciones en los reactivos individuales de las diversas subpruebas son registradas para producir puntuaciones crudas en cada una. El evaluador emplea luego tablas que se encuentran en el manual para convertir cada una de las puntuaciones crudas de las subpruebas en una puntuación estándar. A partir de estas puntuaciones estándar puede derivarse una puntuación compuesta.

Cuando el evaluador tiene amplia experiencia en el uso y manejo de la prueba, una administración de la SB5 puede proporcionar mucho más que una cifra específica de CI y sus puntuaciones compuestas relacionadas. La prueba puede proporcionar una buena cantidad de información valiosa relacionada con las fortalezas y debilidades del examinado en relación con el funcionamiento cognitivo. Esta información la pueden usar profesionales clínicos y académicos en intervenciones diseñadas para hacer una diferencia significativa en la calidad de vida del examinado. Se han descrito diversos métodos de análisis del perfil para ser utilizados con las principales pruebas de habilidad cognitiva (véase, por ejemplo, Kaufman & Lichtenberger, 1999). Estos métodos tienden a tener en común, la identificación de diferencias significativas de puntuaciones en las diversas subpruebas, en la puntuación compuesta y otros tipos de puntuaciones, así como un análisis detallado de los factores que evalúan dichas diferencias. Al identificar estas diferencias significativas el usuario de la prueba depende no sólo de los cálculos estadísticos (o tablas, si se proporcionan en el manual), sino también en los datos normativos descritos en el manual técnico. La magnitud de las diferencias entre las puntuaciones bajo análisis puede ser poco común o no frecuente. El manual técnico de la SB5 contiene diversas tablas diseñadas para apoyar al usuario de la prueba en el análisis. Por ejemplo, una de esas tablas es “Diferencias entre las puntuaciones de CI de la SB5 y las puntuaciones índice de la SB5 requeridas para determinar relevancia estadística en el nivel .05 por edad”.

Además de la calificación formal, la aplicación individual de una prueba permite al administrador tener la oportunidad para la observación conductual. En forma más específica, el evaluador está alerta a la **conducta fuera de la prueba** del evaluado. La forma en que el examinado afronta la frustración, cómo reacciona ante reactivos considerados muy fáciles, la cantidad de apoyo que parece requerir, el enfoque general de la tarea, lo ansioso, fatigado, cooperativo, distraíble o compulsivo que parece estar, son los tipos de observaciones conductuales que complementarán las puntuaciones formales. La forma de puntuación de la SB5 incluye una lista de verificación de las conductas relevantes del examinado, así como un breve cuestionario del tipo si/no con reactivos como *el manejo del inglés del examinado fue adecuado para la prueba*, y *el examinado fue adecuadamente cooperativo*. También hay espacio para registrar notas y observaciones relacionadas con la apariencia física del examinado, su humor y nivel de actividad, tratamientos médicos actuales y variables relacionados. Los examinadores también pueden anotar observaciones específicas

durante la evaluación. Por ejemplo, al administrar Memoria para las frases, por lo general no hay necesidad de registrar la respuesta del evaluado al pie de la letra. Sin embargo, si el examinado produjo resultados poco usuales en las oraciones estímulo, el sentido común del examinador determinará si es importante que se registren las respuestas al pie de la letra. Las respuestas poco usuales en esta subprueba también pueden dar la pauta al examinador para pensar en posibles problemas auditivos o de discurso.

Una costumbre muy antigua en relación con las puntuaciones de la Escala completa Stanford-Binet, es convertirlas en categorías nominales designadas por ciertas fronteras arbitrarias para fines de referencia rápida. A lo largo de los años, estas categorías han tenido diferentes nombres. Para la SB5 existen las fronteras con sus correspondientes categorías nominales:

Rango determinado de CI	Categoría
145 – 160	Muy dotado o muy avanzado
130 – 144	Dotado o muy avanzado
120 – 129	Superior
110 – 119	Superior al promedio
90 – 109	Promedio
80 - 89	Debajo del promedio
70 – 79	Ligeramente débil o retrasado
55 – 69	Medianamente débil o retrasado
40 – 54	Moderadamente débil o retrasado

Con referencia a esta lista, Roid (2003c) afirmó que “el aspecto importante es describir las habilidades del examinado con detalle, más allá de la etiqueta en sí misma” (p. 150). El valor fundamental de estas etiquetas es una referencia rápida en algunos reportes psicológicos. Por ejemplo en un reporte sumario al final de una SB5 detallada, el psicólogo escolar podría escribir “En resumen, Teodoro se presenta como un estudiante del quinto grado bien educado y comprometido, que se desempeña en el nivel alto de habilidad intelectual”.

SÓLO PIENSE...

No hace mucho, retrasado mental, un término con connotaciones peyorativas, era una de las categorías en uso. ¿Qué pueden hacer, de ser posible, los desarrolladores de pruebas para protegerse del uso de categorías con connotaciones peyorativas?

Las escalas Wechsler

David Wechsler diseñó una serie de pruebas de inteligencia aplicadas en forma individual para evaluar las capacidades intelectuales de personas desde preescolar hasta la edad adulta. Una descripción general de los diversos tipos de tareas medidas tanto en las escalas actuales como en las ediciones anteriores de estas escalas se presenta en la tabla 9-3.

En forma tradicional, bien fuera la escala Wechsler para adultos, la escala para niños o la escala para preescolares, un examinador familiarizado con las escalas de Wechsler no tendría grandes dificultades para utilizar cualquier otra de estas pruebas. Aunque probablemente todavía esto sea cierto, las escalas de Wechsler han mostrado una clara tendencia a alejarse de esa uniformidad. Por ejemplo, recientemente todas las escalas Wechsler proporcionaban, entre otras puntuaciones compuestas posibles, una escala completa de CI (una medida de inteligencia general), un CI verbal (calculado con base en las puntuaciones de las subpruebas consideradas como verbales), y un CI de ejecución (calculado con base en las puntuaciones las subpruebas consideradas como no verbales). Todo eso cambió en 2003 con la publicación de la cuarta edición de la escala para

Tabla 9-3
Tipos generales de reactivos usados en las escalas Wechsler

Una lista de las subpruebas específicas para cada una de las escalas Wechsler presentadas en la tabla 9-6.

Subprueba	Descripción
Información	<i>¿En qué continente está Brasil?</i> Éste es el tipo de pregunta que se hace en las subpruebas de Información en las escalas de Wechsler. En general, las preguntas exploran conocimiento general y en parte evalúan aprendizaje y memoria. Los intereses, educación, antecedentes culturales y habilidades de lectura son algunos factores que influyen en la puntuación alcanzada.
Comprensión	En general, estas preguntas exploran la comprensión social, la capacidad para organizar y aplicar el conocimiento y lo que se denomina en forma coloquial como “sentido común”. Una pregunta ilustrativa es <i>¿Por qué los niños deben evitar hablar con extraños?</i>
Semejanzas	<i>¿En qué se parecen una pluma y un lápiz?</i> Ésta es una forma ilustrativa del tipo general de pregunta que aparece en esta subprueba; se presentan pares de palabras al examinando y la tarea es determinar en qué se parecen. La capacidad para analizar relaciones y llevar a cabo un pensamiento lógico-abstracto son dos de las funciones intelectuales exploradas por en este tipo de subprueba.
Aritmética	Los problemas de aritmética se presentan y se resuelven en forma verbal. En los niveles inferiores, esta subprueba puede implicar un simple conteo. El aprendizaje de la aritmética, la alerta, la concentración y la memoria auditiva a corto plazo son algunas de las funciones intelectuales exploradas.
Vocabulario	La tarea es definir palabras. Esta prueba está pensada para ser una buena medida de la inteligencia general, aunque la educación y la oportunidad cultural ciertamente contribuyen a tener éxito en ella.
Vocabulario receptivo	La tarea es seleccionar una de cuatro imágenes que el examinador ha dicho en voz alta. Esta subprueba explora la discriminación auditiva y el procesamiento, la memoria auditiva y la integración de la percepción visual así como la información auditiva.
Nombramiento de imágenes	La tarea es nombrar una imagen mostrada en un libro de dibujos para estímulos. Esta subprueba explora el lenguaje expresivo y la capacidad para buscar palabras.
Retención de dígitos	El examinador presenta verbalmente una serie de números y la tarea del examinado es repetirlos en la misma secuencia o en secuencia inversa. Esta subprueba explora la memoria de corto plazo, la codificación y la atención.
Sucesión de letras y números	Se presentan letras y números en forma oral en un orden mezclado. La tarea es repetir la lista con los números en orden ascendente y las letras en orden alfabético. El éxito en esta subprueba requiere atención, capacidad de seguir secuencias, manipulación mental y velocidad de procesamiento.
Figuras incompletas	La tarea del sujeto aquí es identificar qué parte importante de un dibujo falta. Por ejemplo, se le podría mostrar a quien responde la subprueba un dibujo de una silla a la que le falta una pata. Está basada en capacidades de percepción visual, alerta, memoria, concentración, atención a los detalles y capacidad para diferenciar los detalles esenciales de los que no lo son. Debido a que quienes responden pueden señalar la parte faltante, esta prueba proporciona una buena estimación no verbal de la inteligencia. Sin embargo, el desempeño exitoso en una prueba como ésta todavía tiende a estar muy influido por factores culturales.
Ordenamiento de dibujos	En el género de una tira cómica, esta subprueba requiere que quien responde reordene un conjunto revuelto de tarjetas con dibujos en ellas para formar una historia que tenga sentido. Debido a que quien responde debe entender la historia completa antes de que ocurra un reordenamiento exitoso, se considera que esta subprueba explora la capacidad para comprender o evaluar una situación entera. Además, se exploran la atención, concentración y capacidad para ver relaciones temporales y de causa-efecto.
Diseño con cubos	Un diseño con cubos de colores se ilustra ya sea con los mismos cubos o con una ilustración con el diseño ya terminado, y la tarea del examinando es reproducir el diseño. Esta prueba se basa en habilidades perceptivo-motoras, velocidad psicomotriz y en la capacidad para analizar y sintetizar. Los factores que pueden influir en el desempeño en esta subprueba incluyen la visión de color del examinado, su tolerancia a la frustración y la flexibilidad o rigidez en la solución de problemas.
Ensamble de objetos	La tarea aquí es armar, lo más rápido posible, un dibujo cortado de un objeto familiar. Algunas de las capacidades necesarias aquí incluyen reconocimiento de patrones, habilidades de armado y velocidad psicomotriz. También puede obtenerse aquí información cualitativa útil pertinente a los hábitos de trabajo del examinando por medio de la observación cuidadosa de la manera en que enfoca la tarea. Por ejemplo, ¿el examinado se rinde con facilidad o persiste frente a la dificultad?
Claves	Si se le dieran equivalentes a los puntos y guiones de varias letras en clave Morse y luego tuviera que escribir letras en este código tan rápido como pudiera, estaría realizando una tarea de codificación. El trabajo de codificación de las escalas de Wechsler incluye el uso de un código a partir de una clave impresa. La prueba se pensó para explorar factores como la atención, la capacidad de aprendizaje, la velocidad psicomotora y la capacidad de concentración.
Búsqueda de símbolos	La tarea es explorar en forma visual dos grupos de símbolos, un grupo de búsqueda y un grupo objetivo, y determinar si el símbolo que es el blanco aparece en el grupo de búsqueda. Se presume que la prueba explora la velocidad de procesamiento cognoscitivo.
Razonamiento de matrices	Una tarea no verbal tipo analogía diseñada para explorar las capacidades de organización perceptual y el razonamiento.
Razonamiento verbal	Se trata de identificar el concepto común descrito con una serie de claves. Esta prueba explora la capacidad de abstracción verbal y la capacidad para generar conceptos alternativos.
Concepto de gráficos	La tarea es seleccionar un gráfico en dos o tres filas de ellos para formar un grupo con una característica común. Está diseñada para explorar la capacidad de abstracción, así como la capacidad de razonamiento categórico.
Dígitos y símbolos	La tarea es explorar un arreglo estructurado o no estructurado de estímulos visuales y marcar imágenes indicadas dentro de un límite de tiempo específico. Esta subprueba explora la atención visual selectiva y las capacidades relacionadas.

niños (expuesta con gran detalle más adelante), una prueba que aplicada junto con la largamente establecida Weschler es una dicotomía de subpruebas verbales y de ejecución. Se esperan más cambios en ediciones futuras de estas pruebas.

Sin considerar los cambios hechos a la fecha, sigue existiendo una gran cantidad de factores en común entre las escalas. Las pruebas Wechsler son escalas de puntuación que proporcionan la desviación de CI con una media de 100 (interpretada como promedio) y una desviación estándar de 15. En cada una de las escalas Wechsler, el desempeño de un evaluado se compara con las puntuaciones obtenidas por otros evaluados pertenecientes al mismo grupo de edad. Las pruebas tienen en común manuales escritos claramente que proporcionan descripciones de cada una de las subpruebas, incluyendo el razonamiento para su inclusión. Los manuales también contienen instrucciones claras y explícitas para administrar las subpruebas, así como diversas aproximaciones para manejar algunas preguntas, comentarios, u otras contingencias. Existen pautas similares para el inicio, suspensión y discontinuación de las subpruebas e instrucciones explícitas de puntuación con ejemplos claros. Para la interpretación de la prueba, todos los manuales Wechsler tienen tablas estadísticas que pueden ser muy útiles cuando llegue el momento de que el evaluador haga recomendaciones con base en la evaluación y datos obtenidos. Además, diversas publicaciones en el mercado cuyos autores son diversos profesionales de la evaluación, también están disponibles para apoyar las pautas presentadas en los manuales de la prueba.

En general, las pruebas Wechsler han sido evaluadas favorablemente desde un punto de vista psicométrico. Aunque los coeficientes de confiabilidad variarán como una función del tipo específico de confiabilidad evaluada, las estimaciones reportadas de confiabilidad para las escalas Wechsler en varias categorías (consistencia interna, confiabilidad test-retest, confiabilidad de interpuntuaciones), tienden a ser satisfactorias, incluso más que satisfactorias en muchos casos. Los manuales Wechsler también contienen por lo general una gran cantidad de información sobre estudios de validez, en la forma de estudios correlacionales o estudios analíticos de los factores.

Las tres pruebas de inteligencia Wechsler en uso al momento de la publicación de este libro son la Escala de inteligencia para adultos Wechsler, tercera edición (WAIS-III), para edades de 16 a 89; la Escala de inteligencia para niños Wechsler, cuarta edición (WISC-IV), para edades de 6 a 16 años 11 meses; y la Escala de inteligencia para niños en edad preescolar y primaria Wechsler, tercera edición (WPPSI-III), para edades de 3 a 7 años 3 meses. Hemos escrito brevemente cada una de estas pruebas aquí. Como usted verá en nuestra exposición sobre la escala para adultos, mucho antes de que la “W-B” se convirtiera en canal de televisión, esta abreviatura se usaba para referirse a la primera de lo que evolucionaría en una gran gama de escalas Wechsler.

La escala de inteligencia Wechsler para adultos, tercera edición (WAIS-III)

La **WAIS-III** es la última escala de una serie de instrumentos diseñados para medir la inteligencia de adultos. Sus predecesoras fueron WAIS-R, WAIS, W-B II (Wechsler-Bellevue II) y W-B I (Wechsler-Bellevue I). Ahora, algo de historia.

A principios de la década de 1930, el empleador de Wechsler, el Hospital Bellevue en Manhattan, necesitaba un instrumento adecuado para evaluar la capacidad intelectual de clientes políglotas, multinacionales y multiculturales que eran enviados ahí. Wechsler estaba insatisfecho con las pruebas de inteligencia existentes cuando las empleó con una población con dichas características y comenzó a experimentar con varias pruebas para encontrar la más apropiada para medir la inteligencia adulta. El resultado final fue la W-B I, publicada en 1939. Esta prueba nueva adoptó el formato, aunque no el contenido, de las pruebas existentes.

A diferencia de la más popular de las pruebas de inteligencia aplicadas en forma individual en aquella época, la Stanford-Binet, la W-B I era una escala de puntos en lugar de una escala de edad; los reactivos fueron clasificados por subpruebas en vez de por edad. La prueba fue organizada en seis subpruebas verbales y cinco subpruebas de ejecución, y todos los reactivos en cada subprueba fueron organizados en orden creciente de dificultad. Otra forma de la prueba diseñada para ser una alternativa equivalente, la W-B II, fue publicada en 1942, aunque nunca fue estandarizada en forma minuciosa (Rapaport *et al.*, 1968). A menos que se haga una referencia específica a la W-B II, la referencia utilizada aquí (y en la literatura en general) a la “Wechsler-Bellevue” es a la W-B I.

Aunque la investigación ha sugerido que la W-B en efecto estaba midiendo algo comparable a lo que medían otras pruebas de inteligencia, la prueba tenía los siguientes problemas: 1) la muestra de estandarización estaba bastante restringida, 2) algunas subpruebas carecían de suficiente confiabilidad entre reactivos, 3) algunas de las subpruebas estaban constituidas por reactivos que eran demasiado fáciles, 4) los criterios de calificación para ciertos reactivos eran demasiado ambiguos. Dieciséis años después de la publicación de la forma I de la W-B, se publicó una revisión con un nuevo nombre, la Escala Wechsler de inteligencia para adultos (WAIS; Wechsler, 1955).

Como su predecesora, la WAIS estaba organizada en escalas denominadas “Verbal” y “Ejecución”. La calificación producía un CI verbal, un CI de ejecución y un CI total. La prueba fue elaborada y estandarizada en forma meticulosa y pronto se convirtió en el “estándar contra el cual pueden compararse otras pruebas para adultos” (Lyman, 1972, p. 429). La necesidad de un grupo normativo más contemporáneo se hizo evidente pronto, y en 1981 se publicó una revisión de la prueba llamada WAIS-R, poco después de la muerte de Wechsler. Además de nuevas normas y materiales actualizados, la WAIS-R exigía un cambio en las instrucciones de aplicación en la que se alternaran las pruebas verbales y de ejecución. En 1997, la tercera edición de la prueba (WAIS-III) se publicó, y su autoría se acreditó a David Wechsler.

La WAIS-III contiene materiales actualizados y en color, junto con normas que ahora incluyen el rango de edad de 74 a 89 años (debido a que la esperanza de vida ha aumentado). En algunos casos los reactivos se hicieron de mayor tamaño para facilitar que sean vistos por los adultos mayores. Se agregaron algunos reactivos a cada una de las subpruebas para ampliar el “fondo” de la prueba (más de tres desviaciones estándar por debajo del promedio) y hacerla más útil para evaluar a personas con deficiencias intelectuales extremas. Se realizaron análisis para detectar y reemplazar cualquier reactivo de la WAIS-R que se encontrara sesgado. La prueba fue normalizada junto con otra edición nueva de las pruebas de Wechsler, la Escala de memoria Wechsler-tercera edición (*Wechsler Memory Scale-Third Edition*; WMS-III). El manual técnico, que contiene datos tanto para la WAIS-III como para la WMS-III (Tulsky *et al.*, 1997), facilita las comparaciones de la memoria con otros índices de funcionamiento intelectual cuando se aplican ambas escalas.


Se añadieron tres nuevas subpruebas a la WAIS-III fundamentalmente diseñadas para abordar los dominios limitados del funcionamiento cognoscitivo explorados en muchas pruebas de inteligencia. En la figura 9-2 se ilustran y explican reactivos de muestra de dos de estas nuevas subpruebas, Búsqueda de Símbolos y Secuencias de Letras y Números. Búsqueda de Símbolos es una subprueba de desempeño diseñada para medir la velocidad de procesamiento. Secuencias de Letras y Números es una subprueba verbal diseñada para medir la atención y la memoria de trabajo. La tercera subprueba nueva es Razonamiento de matrices, una tarea no verbal que maneja tipos de analogías, diseñada para explorar las capacidades de organización perceptiva y el razonamiento. Debido a que es una subprueba de desempeño sin límite de tiempo, reduce la contribución de la velocidad de percepción a las puntuaciones de las pruebas de desempeño.

Una guía amplia para la aplicación se presenta en el *Manual de aplicación y calificación WAIS-III* (*WAIS-III Administration and Scoring Manual*). Además, la prueba incluye un video que repasa los cambios en la prueba, revisa sus nuevas características e ilustra varios aspectos de la aplicación, calificación e interpretación de la prueba.

Estandarización y normas La muestra de estandarización de la WAIS-III consistió de 2 450 adultos con edades entre 16 a 89 años, dividida en 13 bandas de edad que van desde 16-17 años en un extremo del espectro, hasta 85-89 años en el otro. La muestra fue estratificada con base en los datos del censo de 1995 de Estados Unidos con respecto a variables como edad, sexo, raza o etnicidad, nivel educativo y región geográfica. En forma consistente con los datos censales, hubo más mujeres que hombres en las bandas referidas a aquellos con mayor edad.

Siguiendo una tradición de Wechsler, la mayor parte de las puntuaciones crudas de las subpruebas para cada grupo de edad fueron convertidas a percentiles y luego a una escala con una media de 10 y una desviación estándar de 3. Hubo, sin embargo, un rompimiento con la tradición en función de la derivación de las puntuaciones por escala. En la WAIS-R, las puntuaciones por escala para cada subprueba se habían basado en el desempeño de un grupo de referencia de individuos sin impedimentos que respondieron la prueba y tenían entre 20 y 34 años de edad. Esto se hizo debido a que Wechsler creía que “el desempeño óptimo tiende a ocurrir en

Búsqueda de símbolos



Secuencia de letras y números

Reactivo	Respuesta
Q-3	3-Q
T-9-1	1-9-T
M-3-P-6	3-6-M-P
F-7-K-2-8	2-7-8-F-K
5-J-4-A-1-S	1-4-5-A-J-S
C-6-4-W-O-7-D	4-6-7-C-D-O-W

Figura 9-2

Reactivos muestra de la WAIS-III

En la subprueba *Búsqueda de símbolos*, se presenta a los examinados grupos de pares de estímulos, un grupo indicado (dos símbolos) y un grupo de búsqueda. El examinado marca un cuadro para indicar cuál de los dos símbolos indicados aparece en el grupo de búsqueda. En la subprueba *Sucesión de letras y números*, el examinador verbaliza una lista de letras y números, y la tarea del examinado es repetir la lista en una forma reordenada, como números en orden ascendente, seguido de letras en orden alfabético.

Fuente: Reactivos simulados similares a los de la Wechsler Adult Intelligence Scale: Third Edition, Copyright © 1997 por The Psychological Corporation, una compañía Harcourt Assessment. Reproducido con permiso. Todos los derechos reservados. Wechsler Adult Intelligence Scale y WAIS son marcas registradas de The Psychological Corporation, del Catalog for Psychological Assessment and Intervention Products, 1998. Copyright © 1998 por The Psychological Corporation, una compañía Harcourt Assessment. Reproducido con permiso. Todos los derechos reservados.

estas edades" (Tulsky *et al.*, 1997, p. 40). Sin embargo, esta creencia ha sido desafiada (Kaufman *et al.*, 1989) y el uso del grupo de referencia para el cálculo de las puntuaciones por escala contribuyó a resolver diversos problemas en la interpretación de la WAIS-R, en especial con las personas mayores que respondían la prueba (Ivnik *et al.*, 1992; Ryan *et al.*, 1990; Tulsky *et al.*, 1997). En la WAIS-III, las puntuaciones obtenidas por el grupo normativo de la misma edad de quien responde la prueba sirven como base para la puntuación por escala.

SÓLO PIENSE...

¿Qué cree usted que sea más útil, comparar el desempeño en una prueba de un examinado con respecto al desempeño óptimo general o con respecto a alguien de su propio grupo de edad? ¿Por qué?

Aspectos psicométricos El *manual técnico WAIS-III* presenta datos de diversos estudios que verifican la confiabilidad, validez y solidez psicométrica general de la prueba. Sin embargo, lo que encontramos un poco sorprendente son los tamaños relativamente pequeños de las muestras que se emplearon al conducir algunos de los estudios. Así, por ejem-

plo, para ayudar a documentar la validez de criterio de la WAIS-III, se analizaron las correlaciones entre puntuaciones en esta prueba y en la SB:FE en un estudio que empleó a 26 adultos. Estos mismos 26 adultos sirvieron como muestra para un estudio similar de validez de criterio que comparó las puntuaciones de la WAIS-III con puntuaciones en las Matrices Progresivas, escala general (*Standard Progressive Matrices*) de Raven (1976). El uso del mismo grupo de sujetos relativamente pequeño en la investigación para la validación de la prueba plantea interrogantes sobre el efecto de la práctica en el desempeño. Se emplearon muestras mayores en estudios similares de validez de criterio para la WISC-III ($n = 184$ jóvenes de 16 años de edad) y la WAIS-R ($n = 192$ adultos con edades de 16 a 74 años).

La evaluación de la validez de constructo de la prueba procede con la suposición de que se sabe con anticipación exactamente qué se supone que mide la prueba. Para las pruebas de inteligencia, es esencial saber con anticipación cómo definió la inteligencia su autor. Si en una prueba específica la inteligencia fue definida como “*g* de Spearman”, por ejemplo, entonces habría que esperar que un análisis factorial de dicha prueba produjera un solo gran factor común. El gran factor común único indicaría que las diferentes preguntas o tareas en la prueba reflejaban en gran medida la misma característica subyacente (inteligencia o *g*). Por el contrario, si inteligencia fue definida por un elaborador de pruebas de acuerdo con la teoría de Guilford, no era de esperar que dominara ningún factor. En vez de ello, habría que anticipar muchos factores diferentes que reflejaran un conjunto de capacidades diversas. Recuérdese que desde la perspectiva de Guilford, no hay una sola inteligencia subyacente que se refleje para los diferentes reactivos de las pruebas. Por consiguiente, no habría base para un gran factor común.

En cierto sentido, un compromiso entre Spearman y Guilford es Thorndike. La teoría de la inteligencia de Thorndike nos lleva a buscar un factor central, que refleje *g*, junto con tres factores adicionales que representan las inteligencias social, concreta y abstracta. En este caso, el análisis tendría que sugerir que las respuestas de las personas a reactivos específicos reflejaban en parte una inteligencia general, pero también tipos diferentes de inteligencia: social, concreta y abstracta.

Wechsler definió la inteligencia como de naturaleza general (“la capacidad global del individuo”) pero con orígenes en distintos componentes (“compuesta de... capacidades que... son diferenciables en forma cuantitativa”). Recuérdese que Wechsler (1974) dijo que había dos de estos componentes, verbal y de ejecución. Desde el punto de vista histórico, los administradores de las escalas Wechsler han hecho interpretaciones a partir de los datos obtenidos con referencia a puntuaciones en cada subprueba, a puntuaciones en escalas Verbal, de Ejecución y Total, además del CI calculado con base en estos índices. Los psicólogos clínicos fueron capacitados para detectar discrepancias significativas y con ello llevar a cabo el diagnóstico dentro y entre estos muchos índices, pero todos tomando en cuenta la estructura Verbal/Ejecución. Sin embargo, ya desde principios de la década de 1950, había evidencias de modelos multifactoriales alternativos de lo que la Wechsler-Bellevue (Cohen, 1952a, 1952b) y la WAIS (Cohen, 1957a, 1957b) parecían estar midiendo.

En los años que siguieron, los aplicadores de pruebas y los teóricos de las mismas, comenzarían a preguntarse si los datos derivados de las escalas Wechsler podrían ajustarse mejor desde el punto de vista conceptual con modelos alternativos derivados en forma factorial de capacidad cognoscitiva (Hishinuma y Yamakawa, 1993; Kaufman, 1990, 1994; Sattler, 1992; Shaw *et al.*, 1993; Smith *et al.*, 1993). La pregunta “¿cuántos factores hay en *realidad* en las escalas Wechsler?”, parece haberse transformado de una pregunta de interés académico pasajero a una de obsesión para los aplicadores. Los editores de las escalas Wechsler salieron a la palestra en su revisión de la prueba para niños (que se comentará en breve). La pregunta también se abordó en la elaboración de la WAIS-III, como se evidencia en extensas investigaciones analítico-factoriales exploratorias y confirmatorias descritas en el manual técnico de la prueba. Un resultado de estas investigaciones, junto con la adición de subpruebas nuevas, fue que además de la dicotomía tradicional Verbal/Ejecución, los administradores de la WAIS-III serían capaces de agrupar los datos de la prueba en cuatro factores: Comprensión verbal, Memoria de trabajo, Organización perceptual y Velocidad de procesamiento. Basadas en estos cuatro factores, pueden derivarse a partir de los datos de la prueba cuatro *puntuaciones índice*, cada una con una media establecida en 100 y una desviación estándar establecida en 15. En la tabla 9-4 se presenta un listado de las subpruebas usadas para derivar cada una de estas puntuaciones índice.

Tabla 9-4
Subpruebas WAIS-III agrupadas de acuerdo con los índices

Comprensión verbal	Memoria de trabajo	Organización perceptual	Velocidad de procesamiento
Vocabulario	Aritmética	Figuras incompletas	Símbolo dígitos
Similitudes	Retención de dígitos	Diseño de cubos	Búsqueda de símbolo
Información	Sucesión de letras y números	Matrices	

Fuente: The Psychological Corporation

Las nuevas adaptaciones a la escala Wechsler para adultos dieron la pauta para una “extensión de la rama”, la escala Wechsler para niños.

La escala de inteligencia Wechsler para niños, cuarta edición (WISC-IV)

Antecedentes La Escala Wechsler de inteligencia para niños (WISC) fue publicada por primera vez en 1949. Representó una extensión ulterior de la W-B y en realidad incorporó muchos reactivos contemplados para ser usados en la W-B II (nunca publicada). “Un instrumento estable, bien estandarizado, que se correlaciona bien con otras pruebas de inteligencia” (Burstein, 1972, p. 844), la WISC no careció, sin embargo, de defectos. La muestra de estandarización sólo contenía niños blancos, y algunos de los reactivos de prueba se vieron como perpetuadores de estereotipos de género y culturales. Además, partes del manual de la prueba eran tan poco claras que condujeron a ambigüedades en su aplicación y calificación. Una revisión de la WISC, llamada Escala Wechsler de inteligencia para niños-revisada (WISC-R), se publicó en 1974. La WISC-R incluía a niños que no eran blancos en la muestra de estandarización. Las ilustraciones que son material para la prueba también fueron más equilibradas desde el punto de vista cultural. El lenguaje de la prueba fue modernizado e “infantilizado”. La palabra *cigarros*, en un reactivo de aritmética, por ejemplo, fue reemplazado por *dulces*. También hubo innovaciones en su aplicación y calificación. Por ejemplo, las pruebas Verbal y de Ejecución fueron aplicadas alternativamente, una práctica que también se extendería a WAIS-III y a WPPSI-R.

La revisión de la WISC-R produjo la Escala Wechsler de inteligencia para niños-tercera edición, publicada en 1991. Esta revisión se llevó a cabo para actualizar y mejorar los reactivos de la prueba, así como las normas. Por ejemplo, se añadieron reactivos más fáciles en la escala aritmética con el fin de evaluar la habilidad para contar. En el otro extremo de la escala, se añadieron problemas relativamente difíciles los cuales consisten en varios pasos. Una subprueba nueva, Búsqueda de símbolos (similar a la descrita en nuestra exposición de la WAIS-III) se introdujo en la WISC-III. La subprueba fue agregada como resultado de la investigación sobre atención controlada, y se pensó que exploraba *carencia de distractibilidad*.

La prueba hoy Publicada en 2003, la WISC-IV representa la culminación de un programa de investigación de cinco años que incluyó muchas etapas, tres de las cuales fueron de desarrollo conceptual hasta un compendio final y evaluación. Tal vez lo más relevante en la introducción de la cuarta edición es una notoria “calidez” del modelo CHC de inteligencia, calificado por un recuerdo de que Carroll (1997), así como Wechsler y otros, consideraban que el factor *g* estaba vivo y dentro de los principales instrumentos diseñados para medir la inteligencia:

Basado en las más comprensivas investigaciones analítico-factoriales en cuanto a las mediciones de la habilidad cognitiva hechas hasta la fecha, Carroll (1993, 1997) concluyó que la evidencia de

SÓLO PIENSE...

La última *C* en el modelo CHC pertenece a Carroll, y Carroll es un firme creyente del factor *g*. Cattell y Horn, la primera *C* y *H* de CHC, no son fanáticos del factor *g*. Esto es para mostrar la extraña combinación que puede resultar cuando una teoría nombrada por tres personas, no fue desarrollada por las tres. ¿Qué piensa sobre esto?

un factor general de inteligencia era abrumadora. Entonces, la tendencia hacia el énfasis de habilidades múltiples, definidas con mayor precisión dentro de las habilidades cognitivas, no ha resultado en el rechazo de un aspecto global de la inteligencia general subyacente. A pesar de un debate continuo en torno a la existencia de un solo y subyacente constructo de la inteligencia, los resultados de las investigaciones analítico-factoriales convergen en la identificación de entre 8 y 10 amplios dominios de la inteligencia... (Wechsler, 2003, p. 2).

También se encuentra enfatizado en el manual el hecho de que las funciones cognitivas están interrelacionadas, lo que hace difícil, sino imposible, obtener la medida “pura” de una función. Una prueba que mide *velocidad de procesamiento*, por ejemplo, puede involucrar varias habilidades, tales como discriminación visual y coordinación motora. Mas allá de todo esto, se realizaron cuestionamientos con base en cómo aislar habilidades específicas para su medición, ya que en la vida real, las tareas cognitivas rara vez se desempeñan en forma aislada. Este punto fue establecido por el propio Wechsler (1975):


...los atributos y factores de la inteligencia, al igual que las partículas elementales en física, presentan al mismo tiempo propiedades colectivas e individuales; es decir, parece que se comportan en forma diferente cuando están solas que cuando actúan en conjunto (p. 138).

De acuerdo con lo anterior, los desarrolladores de la WISC-IV revisaron la prueba para que ahora proporcione una medida del desempeño intelectual general (una Escala completa de CI, así como cuatro puntuaciones índice: un índice de comprensión verbal, un índice de razonamiento perceptivo, un índice de memoria funcional, y un índice de velocidad de procesamiento. Cada uno de estos está basado en las puntuaciones escalares de tres a cinco subpruebas. Son las puntuaciones de cada índice, basadas en las escalares, que se combinan para dar la puntuación de la escala completa con la que se obtiene el CI. También es posible obtener hasta siete *puntuaciones de proceso* usando tablas proporcionadas en el manual de aplicación y puntuación. Una **puntuación de proceso** se puede definir de manera general como un índice diseñado para ayudar a comprender la manera en que el evaluado procesa diversas clases de información. En lo que muchos podrían ver como una desviación momentánea de las versiones anteriores de la prueba, la WISC-IV *no* proporciona puntuaciones separadas en las escalas Verbal y de Ejecución.

Los examinadores familiarizados con las versiones anteriores de esta escala podrían sorprenderse con las innovaciones de esta edición. La subpruebas conocidas como Ordenamiento de figuras, Ensamble de objetos y Laberintos se han eliminado. Ahora se presentan normas separadas para Diseño con cubos, con y sin bonos por tiempo. En parte, estas normas separadas representan aproximaciones a ciertas culturas las cuales valoran la velocidad en la ejecución de las tareas. Las subpruebas Información, Aritmética y Completamiento de Dibujos, una vez *subpruebas centrales*, ahora son *subpruebas suplementarias*. En la WISC-IV y otras pruebas, una **subprueba central** mide la habilidad que contribuye a una puntuación compuesta como sería la escala completa de CI, o una puntuación índice. Una **subprueba suplementaria** se usa ya sea para extender el rango de habilidades medidas o para sustituir una subprueba central cuando es necesario. En la WISC-IV existen 10 subpruebas centrales y cinco complementarias.

Después del trabajo piloto y de intentos nacionales usando versiones preliminares de la nueva escala, se creó una visión estandarizada de la WISC-IV y se administró en una muestra estratificada de 2 200 sujetos, con edades de 6 a 16 años y 11 meses. La muestra se ratificó de acuerdo con la información del censo del año 2000 en Estados Unidos, en relación con las variables clave como edad, género, raza/etnia, nivel educativo de los padres, y región geográfica (figura 9-3). Se excluyeron de la participación en la muestra de estandarización, personas cuyo inglés no fuera fluido o que presentaran diversas condiciones físicas o mentales que pudieran limitar su desempeño (véase Wechsler, 2003, p. 24, para ver una lista completa de criterios de exclusión). Los procedimientos de aseguramiento de calidad se establecieron para calificar a los examinadores, para establecer procedimientos de puntuación y de manejo de datos. Todos los reactivos se revisaron cualitativamente para buscar posibles sesgos, así como cuantitativamente con el objetivo de realizar análisis metodológicos IRT.

El manual de la WISC-IV presenta diversos estudios como evidencia de la viabilidad psicométrica de la prueba. En términos de confiabilidad, se presenta evidencia para apoyar la consis-



^aLos datos sobre la población de Estados Unidos son de la encuesta de población de marzo de 2000: School Enrollment Supplemental File [CD-ROM], por U. S. Bureau of the Census, 2000, Washington, DC.: U. S. Bureau of the Census (Productor/distribuidor).

Figura 9-3

Características demográficas de la muestra de estandarización de la WISC-IV, comparadas con la población de Estados Unidos

Estas gráficas, reimpresas del manual técnico de la prueba, ilustran la correspondencia cercana entre las características demográficas de la muestra de estandarización de la WISC-IV y aquellas del censo de 2000 en Estados Unidos.

tencia interna y su estabilidad test-retest. Además, se presenta evidencia de una excelente complementariedad de interpuntaciones (.90s).

Evidencia para la validez de la prueba se presentó en forma de diversos estudios correlacionales que se enfocaban en las puntuaciones de la WISC-IV, comparados con las puntuaciones alcanzadas en otras pruebas, así como diversos estudios analítico-factoriales. Se presentan datos detallados en el manual de la prueba.

La WISC-IV comparada con la SB5 Aunque la SB5 se puede usar con evaluados mucho menores y mucho mayores que los evaluados a los que se puede examinar con la WISC-IV, las comparaciones entre la Binet y la WISC se han convertido en algo propio de la tradición entre los evaluadores de los niños. Ambas pruebas se publicaron en 2003, y no existían revisiones formales al momento de publicar este libro. Sin embargo, es útil revisar cómo estas dos pruebas se compaginan en diversas variables.

Ambos instrumentos son administrados en forma individual en los que la aplicación toma cerca de una hora para proporcionar una escala completa de CI basada en la aplicación de 10 subpruebas. La WISC-IV también contiene cinco subpruebas complementarias (añada cerca de 30 minutos para la aplicación de la “batería extendida”); la SB5 no contiene ninguna. Con la SB5, se puede obtener un CI a partir de una batería abreviada aplicando 2 subpruebas. La WISC-IV no contiene formalmente esas versiones abreviadas, pero este hecho no detuvo a muchos evaluadores de utilizar su propia “versión abreviada” o para encontrar una manera de construirla a partir

Tabla 9-5
Factores cognitivos y no verbales en la WISC-IV comparados con la Stanford-Binet 5

	WISC-IV	SB5
Factores cognitivos	Memoria de trabajo Velocidad de procesamiento Comprensión verbal Organización perceptual	Memoria de trabajo Procesamiento visual-espacial Conocimiento Razonamiento fluido Razonamiento cuantitativo
Factores no verbales	Memoria de trabajo Velocidad de procesamiento Organización perceptual	Memoria de trabajo Procesamiento visual-espacial Razonamiento fluido Razonamiento cuantitativo Conocimiento

de la publicación de la prueba. Ambas pruebas contienen materiales apropiados para los niños, y ambas tienen software opcional disponible para obtener las puntuaciones y los reportes.

La muestra normativa para los evaluados de 6 a 16 años fue de 2 200 en ambas pruebas. La WISC-IV, incluyó la educación de los padres como una variable estratificante, la SB5 no. La SB5 incluía el estrato socioeconómico y la educación del evaluado como variables estratificantes, la WISC-IV no. Los desarrolladores de ambas pruebas incluyeron criterios de exclusión en la mues-

SÓLO PIENSE...

La SB5 y la WISC-IV son similares en muchos aspectos, a excepción de los criterios de exclusión y las poblaciones donde se condujeron estudios separados de validez. ¿Por qué piensa usted que sucede eso? ¿Cuáles son las implicaciones de esas diferencias para los usuarios que evalúan a los miembros de poblaciones específicas?

tra normativa, y se realizaron por separado estudios de validez con algunas de estas muestras excepcionales para ambas pruebas. Consulte los manuales respectivos para ver las diferencias entre las dos pruebas en términos de estos estudios de validez ya que, de hecho, emplean diferentes tipos de muestras.

Los desarrolladores de ambas pruebas eran, evidentemente, partidarios del modelo de inteligencia CHC. Incluso, ambos parecían aceptar el modelo sólo hasta el grado en que podían encontrar un lugar para *g* en la parte superior de las jerarquías. Las dos pruebas emplean algunas clases similares y diferentes de subpruebas. Como un todo, ambas pruebas pueden interpretarse con respecto a diversos índices cognitivos y no verbales, obtenidos en mayor o menor grado, del modelo CHC. Sin embargo, es aquí que surgen

algunas diferencias interesantes (véase la tabla 9-5). Futuros investigadores podrán explorar con mayor profundidad el grado en que ambas pruebas miden en realidad diferentes variables.

La escala de inteligencia Wechsler para niños en edad preescolar y primaria, tercera edición (WPPSI-III)

El proyecto Head Start al igual que otros programas de la década de 1960 para niños preescolares que eran diferentes desde el punto de vista cultural o por su excepcionalidad (definidos en este contexto como atípicos en capacidad: sobresalientes o retardados) fomentaron el interés en la elaboración de pruebas nuevas (Zimmerman y Woo-Sam, 1978). La Stanford-Binet había sido por tradición la prueba de elección para el uso con preescolares, aunque los administradores de la prueba estaban abiertos a experimentar con métodos alternativos. Aunque algunos proponían una reestandarización de la WISC para niños menores de 6 años, Wechsler (1967) había decidido que debería elaborarse y estandarizarse una prueba nueva de manera especial para estos niños. La prueba nueva fue la WPPSI (Escala Wechsler de Inteligencia para niños en edad Preescolar y Primaria), pronunciada por lo general como “uipsi”, y con su publicación en 1967 la serie de pruebas de inteligencia creada por Wechsler se extendió en forma descendente en el rango de edad hasta los 4 años.

La WPPSI fue la primera prueba de inteligencia importante que “hacía un muestreo adecuado de la población total de Estados Unidos, incluyendo a las minorías raciales” (Zimmerman y Woo-Sam, 1978, p. 10), un factor que contribuyó al éxito de la WPPSI, en especial en una época en que

Tabla 9-6
Las escalas Wechsler *grosso modo**

	WPPSI-III	WISC-IV	WAIS-III
Información	X	X	X
Comprensión	X	X	X
Semejanzas	X	X	X
Aritmética	—	X	X
Vocabulario	X	X	X
Vocabulario receptivo	X	—	—
Nombramiento de imágenes	X	—	—
Retención de dígitos	—	X	X
Sucesión de letras y números	—	X	X
Figuras incompletas	X	X	X
Ordenamiento de dibujos	—	—	X
Diseño con cubos	X	X	X
Composición de objetos	X	—	X
Claves	X	X	—
Búsqueda de símbolos	X	X	X
Razonamiento de matrices	X	X	X
Dígitos y símbolos	—	—	X
Razonamiento verbal	X	X	—
Nombramiento de imágenes	X	X	—
Cancelación	—	X	—

* Consulte los manuales individuales de cada escala para ver si una subprueba en particular es central, suplementaria/complementaria u opcional. En la WPPSI-III, algunas subpruebas funcionan como un tipo de subprueba en un nivel de edad, y como otro tipo en otro nivel de edad. Por ejemplo, vocabulario receptivo es una prueba verbal *central* para los examinados hasta 3 años 11 meses, y es *opcional* para las edades de 4 años en adelante. Nombramiento de imágenes es una subprueba verbal *suplementaria* para los evaluados hasta 3 años 11 meses, y una *opcional* para aquellos con edades de 4 años en adelante.

las pruebas estandarizadas estaban bajo ataque por no tener una representación adecuada de las minorías en la muestra de estandarización. Se publicó una revisión de la WPPSI, la WPPSI-R, publicada en 1989 y está diseñada para evaluar la inteligencia de niños de 3 a 7 años 3 meses de edad. Se desarrollaron nuevos reactivos para extender el rango de la prueba hacia arriba y hacia abajo.

Publicada en 2002, la WPPSI-III amplió el rango de niños que podían examinarse con este instrumento hacia abajo hasta los 2 años 6 meses. El manual técnico de este instrumento contenía la misma clase de introducción histórica a las pruebas de inteligencia como la WISC-IV. Sin embargo, en lugar de llegar a la conclusión de que era tiempo de dejar a un lado la tradicional dicotomía Verbal/Ejecución de Wechsler, como se hizo con la WISC-IV, la utilidad de la dicotomía se reafirmó en el manual de la WPPSI-III. De conformidad, se pueden obtener tres puntuaciones compuestas: CI Verbal, CI de Ejecución y CI Total.

La WPPSI-III cambió en muchas formas de su edición anterior. Se eliminaron cinco subpruebas (Aritmética, Casa de animales, Diseños geométricos, Laberintos y frases). Se añadieron siete nuevas subpruebas: Razonamiento de matrices, Conceptos pictóricos, Razonamiento verbal, Claves, Búsqueda de símbolos, Vocabulario receptivo y Nombramiento de dibujos. En la WPPSI-III, las subpruebas se llaman *centrales*, *complementarias* u *opcionales* y algunas subpruebas tienen diferentes nombres en diferentes niveles de edad (por ejemplo, *complementaria* en un nivel de edad y *opcional* en otro). Se requieren subpruebas centrales para el cálculo de puntuaciones compuestas. Las subpruebas complementarias se utilizan para proporcionar una muestra más amplia del funcionamiento intelectual; también sustituyen a una subprueba central cuando por alguna razón ésta no se aplicó, o se aplicó pero no fue útil. Las subpruebas complementarias también se usan para obtener puntuaciones adicionales, como el *cociente de velocidad de procesamiento*. No se pueden usar **subpruebas opcionales** para sustituir otras centrales, pero se pueden usar en la obtención de puntuaciones opcionales, como en *Índice de lenguaje general*. Se presenta una lista completa de todas las subpruebas en todas las escalas Wechsler, incluyendo la WPPSI-III, la WISC-IV y la WAIS-III, en la tabla 9-6.

La estructura de la WPPSI-III refleja el interés de los desarrolladores de la prueba en mejorar medidas de razonamiento fluido y de velocidad de procesamiento. Tres de las nuevas subpruebas (Razonamiento de matrices, Conceptos pictóricos y Razonamiento verbal) se diseñaron para

SÓLO PIENSE...

David Wechsler consideraba que los factores de la inteligencia, al igual que las partículas elementales en física, tienen propiedades colectivas e individuales. Casi siempre, las escalas Wechsler parecen tener como meta la medición de las propiedades colectivas o de "actuación en grupo". Sin embargo, con la incorporación de Búsqueda de símbolos y Claves en la WPPSI-III, parece que los desarrolladores de pruebas buscan una medida "más pura" de la velocidad de procesamiento. ¿Qué piensa sobre la mezcla aparente de las mediciones de características colectivas e individuales de los factores en la capacidad intelectual?

explorar el razonamiento fluido, las subpruebas de Búsqueda de símbolos y claves fueron creadas para explorar la velocidad de procesamiento. En un esfuerzo por reducir los efectos confusos que genera la velocidad en torno a las habilidades cognitivas, los desarrolladores de la prueba discontinuaron la práctica de otorgar puntos adicionales en las puntuaciones de Diseño con cubos y Ensamble de objetos para que el desempeño fuera rápido y exitoso. Los desarrolladores esperaban que la incorporación de las subpruebas Búsqueda de símbolos y claves proporcionara una medida menos confusa de la velocidad de procesamiento.

Si alguna vez ha visto *Trading Spaces*, *While You Were Out*, *This Old House*, o cualquier otro programa de televisión, que trate sobre remodelación de casas, sabrá que siempre se le pone atención a los pisos y a los techos. Lo mismo sucede cuando se remodelan pruebas de inteligencia. Los diseñadores de la WPPSI-III agregaron reactivos más sencillos así como algunos más difíciles a cada una de las subpruebas. Concluyeron que la subprueba mejorada en cuanto a los pisos y los techos hacía que la WPPSI-III fuera "una medida más precisa del funcionamiento cognitivo para niños con retrasos significativos en el desarrollo, así como para niños de los cuales se sospecha sean intelectualmente superdotados" (Wechsler, 2002, p. 17).

Después del trabajo piloto y de una prueba nacional de la WPPSI-III en desarrollo, se creó una edición estandarizada. La prueba se aplicó a una muestra estratificada de 1 700 niños entre

SÓLO PIENSE...

¿Por qué es importante para los investigadores independientes verificar algunos de los hallazgos relacionados con la viabilidad psicométrica de las principales pruebas?

las edades de 2 años 6 meses y 7 años 3 meses, así como en muestras de niños de grupos especiales. La muestra se seleccionó en proporción a la información del censo de 2000 en Estados Unidos y las muestras fueron estratificadas según las variables de edad, sexo, raza/etnia, nivel de educación de los padres y región geográfica. Según la costumbre al revisar las principales escalas de inteligencia, se tomaron diversos pasos para protegerse contra los sesgos en los reactivos. Se incluyeron métodos estadísticos así como revisiones por expertos en sesgos. Se pusieron en práctica diversos procedimientos para asegurar la calidad, incluyendo protocolos de

anclaje para asegurar que las pruebas se calificaran y que los datos se introdujeran adecuadamente. Como también se ha vuelto costumbre, se presentan diversos estudios que comprueban la viabilidad psicométrica de la escala en el manual técnico.

Wechsler, Binet y la versión abreviada

Un problema relacionado con las escalas Wechsler, pero de seguro no exclusivo de esta familia de pruebas, es el desarrollo de versiones abreviadas. El término **versión abreviada** se refiere a una prueba cuya longitud se ha abreviado, generalmente para reducir el tiempo necesario para la aplicación, calificación e interpretación de la prueba. En ocasiones, en particular cuando se cree que quien responde la prueba tiene un lapso de atención atípicamente corto u otros problemas que imposibilitarían la aplicación de la prueba completa, se aplica una muestra de subpruebas representativas. Se hicieron razonamientos para este uso de las escalas Wechsler con referencia a la población general de evaluados (Kaufman *et al.*, 1991), al igual que para personas de la tercera edad (Paolo y Ryan, 1991) y para poblaciones psiquiátricas (Benedict *et al.*, 1992; Boone, 1991; Grossman *et al.*, 1993; Hayes, 1999; Randolph *et al.*, 1993; Sweet *et al.*, 1990). Los profesionales clínicos utilizan algunas veces una versión abreviada de 7 subpruebas de la WAIS-III, y parece demostrar características aceptables en términos psicométricos (Ryan & Ward, 1999; Schoop, *et al.*, 2001).

Las versiones abreviadas de las pruebas de inteligencia no son nada nuevo. De hecho, han existido durante tanto tiempo como las versiones originales. Poco después de que la Binet-Simon llegó a Estados Unidos, una versión abreviada de ella se desarrolló (Doll, 1917). Hoy en día, los psicólogos escolares con largas listas de espera para realizar evaluaciones, los psicólogos forenses que trabajan en el sistema judicial, y las aseguradoras de salud que buscan pagar menos por los servicios de evaluación, son algunos de los grupos para los cuales es atractiva la versión abreviada.

En 1958, el mismo David Wechsler describió el uso de versiones abreviadas como apropiadas a condición de que sean usadas sólo con propósitos de exploración. Pero años después, quizá en respuesta a posibles abusos de las versiones abreviadas, adoptó la perspectiva de reducir la cantidad de subpruebas para ahorrar tiempo. Aconsejó a aquellos que afirmaban que no tenían tiempo suficiente para aplicar la prueba completa, que “encontraran el tiempo” (Wechsler, 1967, p. 37).

Las revisiones subsecuentes de la literatura sobre versiones abreviadas han confirmado la sabiduría de este último consejo de Wechsler. Watkins (1986) concluyó que las versiones abreviadas pueden ser usadas sólo con propósitos de exploración, y no para tomar decisiones de colocación o educativas. Desde una perspectiva histórica, Smith *et al.* (2000) calificaron las opiniones sobre la transferencia de validez de la forma completa a la abreviada como “demasiado optimistas”. En contraste con algunos críticos que han solicitado la abolición de las versiones abreviadas, Smith *et al.* (2000) argumentaron que los estándares de validez de una versión abreviada deben ser altos. Sugirieron una serie de procedimientos en el desarrollo de versiones abreviadas válidas. Silverstein (1990) proporcionó una revisión incisiva de la historia de las versiones abreviadas, enfocándose en cuatro cuestiones: 1) cómo abreviar la prueba original, 2) cómo seleccionar sujetos, 3) cómo estimar las puntuaciones en la prueba original y 4) los criterios que se aplicarán cuando se compare la versión abreviada con la original. Ryan y Ward (1999) aconsejaron que cuando se utilice una versión abreviada, esto debe ser estipulado en el registro oficial con la abreviación “Est” en seguida, para indicar que el valor reportado sólo es un estimado.

Desde un punto de vista psicométrico, es importante tener en cuenta que la validez de una prueba es afectada por la confiabilidad, y en cierto modo depende de ella. Por consiguiente, los cambios en una prueba que disminuyan su confiabilidad también pueden disminuir su validez. Reducir el número de reactivos en una prueba generalmente reduce la confiabilidad de la prueba y, por consiguiente, también su validez. Por esta razón, no deben tomarse decisiones importantes con base en versiones abreviadas de las pruebas de inteligencia (Nagle y Bell, 1993). De hecho, cuando la versión abreviada indica la necesidad de intervención o colocación, la mejor práctica puede ser “encontrar el tiempo” para administrar la forma completa de la prueba.

La escala Wechsler de inteligencia en forma abreviada Al contrario de muchos practicantes que consideraban a las versiones abreviadas como deseables, y de las advertencias de muchos profesionales de la psicometría sobre su uso, se publicó la escala Wechsler de inteligencia en forma abreviada (WASI) en 1999. Debido a que muchos usuarios de la prueba encontraron irresistible la versión abreviada, muchas de estas pruebas se han hecho informalmente a partir de las versiones completas, formas con diversos grados de viabilidad psicométrica y rara vez con datos normativos. La WASI está diseñada para responder a la necesidad de un instrumento corto para explorar la habilidad intelectual en los evaluados de 6 a 89 años. La prueba se presenta con dos subpruebas (Vocabulario y Diseño con cubos) que toma 15 minutos administrar y en otra versión con cuatro subpruebas que toma 30 minutos administrar. Las cuatro subpruebas (Vocabulario, Diseño con cubos, Semejanzas y Razonamiento de matrices) son del tipo de las WISC y WAIS, que tienen altas correlaciones con la escala completa de CI en esas pruebas. Se pensaron para explorar un amplio rango de habilidades cognitivas. La WASI proporciona mediciones de CI verbal, de ejecución y de CI total. De acuerdo con muchas otras pruebas de inteligencia, la escala completa de CI se estableció en 100 con una desviación estándar de 15.

La WASI se estandarizó con 2 245 casos, incluyendo 1 100 niños y 1 145 adultos. El manual presenta evidencia de viabilidad psicométrica satisfactoria, aunque algunos revisores de esta prueba no estuvieron completamente satisfechos con la forma en que se condujo y reportó la investigación de validez (Keith *et al.*, 2001). Otros revisores, sin embargo, encontraron que las

cualidades psicométricas de la WASI, así como su utilidad general, excedían por mucho aquellas medidas breves de inteligencia que podían ser comparables (Lindskog & Smith, 2001).

Las escalas Wechsler en perspectiva

Léase el manual de una prueba de inteligencia Wechsler elaborada en fechas recientes y hay buenas probabilidades de que encontrará ilustraciones de prácticas ejemplares en la elaboración de la prueba. Los administradores calificados pueden aprender a aplicar las pruebas con relativa rapidez, y los examinados tienden a encontrar atractivos los materiales de ésta. Se dispone de una variedad de auxiliares interpretativos y de calificación asistidos por computadora para cada una de las pruebas, al igual que diversos manuales y guías. Es más, es evidente que los elaboradores de la prueba están haciendo esfuerzos para mantener frescas la calificación y la interpretación de las pruebas, mientras extienden el modelo Wechsler verbal/ejecución tradicional a uno conducente al análisis por medio de la conceptualización de la inteligencia a partir de factores múltiples que es más contemporánea.

Al familiarizarse con las escalas Wechsler, así como con las SB5, probablemente haya notado que la técnica estadística del análisis factorial tiene un papel clave en el proceso de desarrollo de la prueba. Para aumentar su comprensión de esta importante, aunque algunas veces complicada técnica estadística, solicitamos a un “colega del tipo analista factorial” que preparara una descripción que fuera “tan poco complicada como fuera posible”. La descripción es la sección *Close-up* de este capítulo.

Otras medidas de inteligencia

Otras pruebas diseñadas para aplicación individual

En años recientes, un número creciente de pruebas que pretenden medir la inteligencia han quedado disponibles para su aplicación. Algunas de éstas fueron elaboradas por Alan y Na-deen Kaufman. Este matrimonio elaboró la Prueba Kaufman de Inteligencia para Adolescentes y Adultos (*Kaufman Adolescent and Adult Intelligence Test*, KAIT, Kaufman y Kaufman, 1993) y la Prueba breve de Inteligencia de Kaufman (*Kaufman Brief Intelligence Test*, K-BIT, (Kaufman y Kaufman, 1990). Su primera prueba representativa fue la Batería de evaluación para niños de Kaufman (*Kaufman Assessment Battery for Children*, K-ABC, Kaufman y Kaufman, 1983a, 1983b). La K-ABC se apartó de las pruebas de inteligencia publicadas con anterioridad desde el punto de vista conceptual por su enfoque en el procesamiento de la información y de manera más específica en la distinción entre el procesamiento secuencial y simultáneo. Los Kaufman se basaron en los escritos teóricos de A. R. Luria (1966a) en el diseño de la K-ABC, como lo hicieron J. P. Das y Jack Naglieri en la elaboración de su Sistema de evaluación cognoscitivo (*Cognitive Assessment System*). Otra batería de pruebas que se desvió en muchas formas de las medidas anteriores de la capacidad cognoscitiva son las Escalas de capacidad diferencial (*Differential Ability Scales*, DAS). Éstas y otras pruebas usadas en forma extensa en escenarios educativos se comentarán con más detalle en el capítulo 10.

De acuerdo con algunos investigadores y psicólogos clínicos la estimación de la inteligencia de un evaluado puede realizarse a partir de la interpretación que se haga de una figura humana y otros dibujos (Bardos, 1993; Buck, 1948; Holtzman, 1993; Naglieri, 1993). Se han propuesto muchos métodos para obtener dichas estimaciones, siendo la más conocida de éstas el sistema de calificación de Goodenough-Harris (Harris, 1963). Una cuestión de controversia de muchos años, sin embargo, es si el sistema Goodenough en efecto es lo bastante bueno. Aunque hay evidencias de que el sistema es confiable (Kamphaus y Pleiss, 1993; Scott, 1981), sigue habiendo dudas respecto a su validez (Aikman *et al.*, 1992; Motta *et al.*, 1993a, 1993b; Sattler, 1992). Los dibujos de figuras conllevan la expectativa de una reducción en el tiempo dedicado a la valoración y la evaluación psicológica, en especial cuando pueden ser usados los mismos

Análisis factorial*

Al medir las características de los objetos físicos, puede haber algún desacuerdo sobre los mejores métodos a usar, pero hay poco desacuerdo sobre cuáles dimensiones se miden. Sabemos, por ejemplo, que medimos la longitud cuando usamos una regla, y sabemos que medimos la temperatura cuando usamos un termómetro. Tal certidumbre no siempre está presente al medir las dimensiones psicológicas como los rasgos de la personalidad, actitudes y capacidades cognitivas.

Los psicólogos pueden estar en desacuerdo sobre como llamar a las dimensiones o constructos que se están midiendo y sobre la cantidad de dimensiones o constructos medidos.

Considere un rasgo de la personalidad al que un investigador se refiere como *lindura*; otro investigador considera éste como un término vago y expone dos rasgos relacionados pero independientes llamados *amabilidad* y *cortesía*. Otro investigador afirma que *cortesía* es demasiado general y que debe separarse en *cortesía con los amigos* y *cortesía con los extraños*. ¿Quién tiene razón? ¿Todos? Si los investigadores van a hacer constructos con base en los hallazgos, necesita haber alguna manera de alcanzar el consenso sobre lo que se está midiendo. Con ese propósito, el análisis factorial puede ser útil.

Un supuesto del análisis factorial es que las cosas que ocurren tienden a tener una causa común. Note que “tienden a” no significa “siempre”. Las fiebres, gargantas irritadas, narices congestionadas, tos y estornudos *tienden a* ocurrir al mismo tiempo en la misma persona, pero no siempre co-ocurren. Cuando estos síntomas sí co-ocurren, pueden ser causados por una cosa: el virus que causa el resfriado común. Aunque el virus es una cosa, sus manifestaciones son bastante diversas.

En la investigación sobre la evaluación psicológica, se mide un conjunto diverso de capacidades, conductas y síntomas, y se pretende deducir cuáles dimensiones subyacentes causan o representan las variaciones en la conducta y los síntomas que observamos en grandes grupos de personas. Se miden las relaciones entre varias conductas, síntomas y puntuaciones de pruebas con coeficientes correlacionales. Entonces se usa el análisis factorial para descubrir los patrones de los coeficientes de correlación que sugieren la existencia de dimensiones psicológicas subyacentes.

Si todo lo demás permanece igual, una teoría simple es mejor que una complicada. El análisis factorial ayuda a descubrir la más pequeña cantidad de dimensiones psicológicas (o factores) que pueden contribuir a las diversas conductas, síntomas y puntuaciones de pruebas que observamos. Por ejemplo, imagine que creamos cuatro diferentes pruebas para medir el

conocimiento en las personas acerca del vocabulario, gramática, multiplicación y geometría. Si las correlaciones entre todas estas pruebas fuera cero (v.gr., no es más probable que aquellos con puntuaciones elevadas en una prueba obtengan puntuaciones elevadas en otras, que aquellos con bajas puntuaciones), entonces el análisis factorial podría sugerir que hemos medido cuatro capacidades distintas.

Por supuesto, es probable que reconozca que es muy probable que las correlaciones entre estas pruebas sean cero. Entonces, imagine que la correlación entre las pruebas de vocabulario y gramática fuera bastante alta (v.gr., los que obtuvieron puntuaciones elevadas en vocabulario tendían a tenerlas también en gramática y aquellos con bajas puntuaciones en vocabulario, tendían a tenerlas también en gramática). La correlación entre la multiplicación y geometría también fue alta. Además, las correlaciones entre las pruebas verbales y las de matemáticas fue cero. En análisis factorial sugeriría que se hubieran medido no cuatro capacidades distintas, sino dos. El investigador que interprete los resultados del análisis factorial tendría que usar su mejor juicio para decidir cómo llamar a estas dos capacidades. En este caso, parecería razonable llamarlas *capacidad de lenguaje* y *capacidad matemática*.

Ahora imagine que las correlaciones entre las cuatro pruebas son igualmente altas, por ejemplo, que vocabulario estuvo fuertemente correlacionado con geometría, al igual que con gramática. En este caso, el análisis factorial sugiere que la explicación más simple para este patrón de correlaciones es que existe sólo un factor que causa que todas estas pruebas estén igualmente correlacionadas. Podríamos llamar a este factor *capacidad académica general*.

En realidad, si fuera a medir en verdad estas cuatro capacidades, los resultados no serían tan claros. Es probable que todas las correlaciones fueran positivas y estuvieran sustancialmente por encima de cero. Es probable que todas las subpruebas verbales se correlacionaran con más fuerza entre ellas que con las de matemáticas. Es probable que el análisis factorial sugiriera que las capacidades de lenguaje y matemáticas son distintas entre ellas, pero no completamente independientes, es decir, que las capacidades de lenguaje y las de matemáticas están sustancialmente correlacionadas, lo que sugiere que una capacidad académica general (o intelectual) influye en el desempeño en todas las áreas académicas.

El análisis factorial puede ayudar a los investigadores a decidir cómo resumir mejor grandes cantidades de información sobre las personas al usar unas cuantas puntuaciones. Por ejemplo, cuando solicitamos a los padres completar cuestionarios sobre los problemas de conducta de sus hijos, los cuestionarios

* Preparado por W. Joel Schneider

(continúa)

Análisis factorial (continuación)

pueden tener cientos de reactivos. Podría tomar demasiado tiempo y sería confuso revisar cada uno. El análisis factorial puede simplificar la información mientras minimiza la pérdida de detalles. Aquí se presenta un ejemplo de un cuestionario breve que se puede usar en el análisis factorial para resumir.

En una escala del 1 al 5, comparado con otros niños de su edad, mi hijo:

1. se involucra en peleas en la escuela con frecuencia
2. desafía a los adultos
3. es muy impulsivo
4. tiene dolores de estómago con frecuencia
5. está ansioso por muchas cosas
6. parece triste la mayor parte del tiempo

Si damos este cuestionario a una muestra grande y representativa de padres, podremos calcular las correlaciones entre los reactivos. La tabla 1 ilustra lo que podríamos encontrar.

Observe que todas las correlaciones perfectas de 1.00 en esta tabla se usan para enfatizar el hecho de que cada reactivo se correlaciona perfectamente consigo mismo. En el análisis de datos, el software ignorará estas correlaciones y analizará sólo aquellas bajo esta diagonal “línea de demarcación” de correlaciones de 1.00.

Si se usa el conjunto de coeficientes de correlación presentados en la tabla 1, el análisis factorial sugiere que existen dos factores medidos por esta escala de puntuación de la conducta. La lógica del análisis factorial sugiere que la razón por la cual los reactivos del 1 al 3 tienen altas correlaciones entre sí es que cada uno tiene una alta correlación con el primer factor. En forma similar, los reactivos del 4 al 6 tienen correlaciones elevadas entre sí porque tienen altas correlaciones con el segundo factor. Las correlaciones de los reactivos con los factores hipotéticos se llaman *cargas factoriales*. Las cargas factoriales de este ejemplo hipotético se presentan en la tabla 2.

El análisis factorial nos dice cuáles reactivos cargar en cuáles factores, pero no puede interpretar el significado de éstos. Los investigadores suelen observar todos los reactivos que se cargan en un factor y usan su intuición o conocimiento de la teoría para identificar qué tienen en común los reactivos. En este caso, el factor 1 podría recibir cualquier cantidad de nombres, como *Problemas de conducta*, *Actuación*, o *Conductas de externalización*. El factor 2 podría también tener varios nombres, como *Problemas de humor*, *Afectividad negativa* o *Conductas de internalización*. Entonces, los problemas en esta

Tabla 1
Una tabla de correlaciones muestra

	1	2	3	4	5	6
1. se involucra en peleas en la escuela con frecuencia	1.00					
2. desafía a los adultos	.81	1.00				
3. es muy impulsivo	.79	.75	1.00			
4. tiene dolores de estómago con frecuencia	.42	.38	.36	1.00		
5. está ansioso por muchas cosas	.39	.34	.34	.77	1.00	
6. parece triste la mayor parte del tiempo	.37	.34	.32	.77	.74	1.00

Tabla 2
Cargas factoriales de nuestro ejemplo hipotético

	Factor 1	Factor 2
1. se involucra en peleas en la escuela con frecuencia	.91	.03
2. desafía a los adultos	.88	-.01
3. es muy impulsivo	.86	-.01
4. tiene dolores de estómago con frecuencia	.02	.89
5. está ansioso por muchas cosas	.01	.86
6. parece triste la mayor parte del tiempo	-.02	.87

escala de puntuación de la conducta se pueden resumir con suficiente eficiencia con sólo dos puntuaciones. En este ejemplo, la reducción de seis puntuaciones a dos, puede no parecer muy útil. En las escalas reales de puntuación de la conducta, el análisis factorial puede reducir la complejidad abrumadora de cientos de diferentes problemas de conducta a una cantidad de puntuaciones más manejable que ayude a los profesionales a conceptualizar con más facilidad los casos individuales.

El análisis factorial también calcula la correlación entre factores. Si una gran cantidad de factores se identifica y existen correlaciones sustanciales entre los factores, esta nueva matriz de correlaciones también se puede analizar por factores individuales para obtener factores de segundo orden. Estos factores, a su

vez, se pueden analizar para obtener *factores de tercer orden*. En teoría, es posible tener factores de órdenes superiores, aunque la mayoría de los investigadores rara vez encuentra necesario ir más allá de los de tercer orden. El factor *g* a partir de los datos de pruebas de inteligencia es un ejemplo de un factor de tercer orden que surge porque todas las pruebas de capacidades cognitivas están relacionadas positivamente. En nuestro ejemplo anterior, los dos factores tienen una correlación de .46, lo que sugiere que los niños que han externalizado problemas también están en riesgo de tener problemas de internalización. Por tanto, es razonable calcular un factor de segundo orden que mida el nivel general de problemas de conducta.

Este ejemplo ilustra el tipo más común de análisis factorial: *análisis factorial de exploración*. Este análisis es útil cuando se desea resumir datos con eficiencia, cuando no se está seguro de cuántos factores están presentes en nuestros datos o cuándo no se está seguro cuáles reactivos cargar en cuáles factores. En resumen, cuando se explora o se buscan factores, se puede usar el análisis factorial de exploración. Cuando se piensa que se han encontrado factores y se busca *confirmarlo*, se puede usar otra variedad de análisis factorial.

Los investigadores pueden usar el *análisis factorial confirmatorio* para probar hipótesis muy específicas. Por ejemplo, un investigador podría querer saber si los dos tipos de reactivos en la subprueba Retención de dígitos de la WISC-IV, miden la misma capacidad o dos diferentes. En el tipo de reactivo de dígitos en orden directo, el niño debe repetir una serie de dígitos en el mismo orden en que los oyó. En el tipo de reactivo de dígitos en orden inverso, el niño debe repetir la serie de dígitos al revés de cómo los oyó. Algunos investigadores consideran que la repetición de números al pie de la letra mide la memoria auditiva a corto plazo y que la repetición de números al revés, mide el control ejecutivo, la capacidad de asignar recursos de atención con eficiencia para resolver problemas de varios pasos. Por lo general, los clínicos suman las puntuaciones netas de ambos tipos de reactivos para producir una sola puntuación. Si los dos tipos de reactivos miden diferentes capacidades, la suma de ambas puntuaciones es como sumar manzanas y naranjas, duraznos y peras... ¿es claro? Sin embargo, si los dos reactivos miden la misma capacidad, la suma de puntuaciones puede proporcionar una puntuación más confiable que cada una por separado.

El análisis factorial confirmatorio puede usarse para determinar si los dos tipos de reactivo miden diferentes capacidades. Se necesitaría identificar o inventar diversas pruebas adicionales que pudieran medir las dos capacidades por separado que consideramos miden los dos tipos de reactivos de

Retención de dígitos. Por lo general, son suficientes tres pruebas por factor. Llamaremos a las pruebas de memoria de corto plazo STM1, STM2 y STM3. Asimismo, podemos llamar a las pruebas de control ejecutivo, EC1, EC2 y EC3.

A continuación, se especifican las hipótesis o modelos que deseamos probar. Existen tres de ellos:

1. *Todas las pruebas miden la misma capacidad.* Una representación gráfica de una hipótesis en el análisis factorial confirmatorio, se llama *diagrama de flujo*. Las pruebas se dibujan con rectángulos y los factores hipotéticos con óvalos. Las correlaciones entre las pruebas y factores se dibujan con flechas. El diagrama de flujo de esta hipótesis se presenta en la figura 1.





Figura 1

Este diagrama de flujo es una representación gráfica de la hipótesis de que Todas las pruebas miden la misma capacidad.

(continúa)


Análisis factorial (continuación)

2. **Dígitos en orden directo y a la inversa miden la memoria de corto plazo y son distintos del control ejecutivo.** El diagrama de flujo de esta hipótesis se presenta en la figura 2.
3. **Dígitos en orden directo y a la inversa miden capacidades diferentes.** El diagrama de flujo de esta hipótesis se presenta en la figura 3.

**Figura 2**

Este diagrama de flujo es una representación gráfica de la hipótesis de que Dígitos en orden directo y a la inversa miden la memoria de corto plazo y son distintos del control ejecutivo. Observe que la flecha curva indica la posibilidad de que los dos factores puedan correlacionarse.

El análisis factorial confirmatorio produce una cantidad de estadísticas llamadas **estadísticas de adecuación**, que nos dicen cuál de los modelos o hipótesis que probamos están más de acuerdo con los datos. Al estudiar los resultados, podemos seleccionar el modelo que proporciona la mejor correspondencia con los datos o, tal vez, incluso genera un nuevo modelo. En realidad, el análisis factorial se puede volver mucho más complicado con rapidez, de lo que se describe aquí, pero por ahora, esperamos que esto sea útil.

**Figura 3**

Este diagrama de flujo es una representación gráfica de la hipótesis de que Dígitos en orden directo y a la inversa miden capacidades diferentes.

SÓLO PIENSE...

El uso de dibujar una figura humana para estimar la inteligencia ha sido controvertido en muchos aspectos. Comente la práctica en relación con la validez normativa de tal medida (considere todos los sentidos de esta palabra).

dibujos para evaluar la personalidad. Sin embargo, su uso para dar un aproximado de la inteligencia, aun como un dispositivo de exploración, sigue siendo controvertido.

Pruebas diseñadas para aplicación en grupo

La revisión Stanford de la prueba Binet-Simon se publicó en 1916, y un año más tarde muchos psicólogos se vieron impulsados a pensar cómo adaptar una prueba como esa a la aplicación en grupo. Para entender por qué, necesitamos hacer una breve revisión histórica sobre las pruebas en la milicia.

Pruebas grupales en la milicia El 6 de abril de 1917, Estados Unidos entró en la primera guerra mundial. El 7 de abril, el presidente de la Asociación Psicológica Estadounidense, Robert R. Yerkes, inició esfuerzos para movilizar a los psicólogos a ayudar en el proceso de la guerra. A finales de mayo, el comité de la APA que desarrollaría pruebas para grupos en la milicia, tuvo su primera reunión. Existía poco debate entre los participantes sobre la naturaleza de la inteligencia, tan sólo un claro sentido de urgencia en desarrollar instrumentos para que la milicia identificara a los “inadaptados” y a aquellos con “habilidad excepcionalmente superior”.

Aún en la actualidad el desarrollo de una prueba de inteligencia o de habilidades cognitivas podría tomar de tres a cinco años, sin embargo, el comité tuvo dos pruebas listas en cuestión de semanas y una forma final de dichas pruebas estuvo lista el 7 de julio. Una de las pruebas se conoció como la **Prueba alfa para la armada**. Esta prueba se aplicaría a los reclutas de la armada que pudieran leer; contenía tareas así como preguntas de información general, analogías y frases revueltas para organizar. La otra prueba era la **Prueba beta para la Armada**, diseñada para aplicarse en reclutas extranjeros con poco conocimiento del inglés o en analfabetas (definidos como “alguien que no puede leer un periódico o escribir una carta a sus familiares”). Contenía tareas como laberintos, claves y completar dibujos (donde la tarea del examinado era hacer el elemento faltante en el dibujo). Ambas pruebas se administraron con rapidez en los campos de la armada por equipos oficiales y hombres enlistados. En 1919 se habían evaluado a casi 2 millones de reclutas, a 8 000 de los cuales se había recomendado ser descartados con base en los resultados de la prueba. A otros reclutas se les asignó a varias unidades en la armada con base en los resultados de las pruebas Alfa o Beta. Por ejemplo, los reclutas con puntuaciones bajas pero en un rango aceptable eran colocados en alguna tarea que implicará cavar pozos o tareas similares.

Si un sueño llevó al desarrollo de las pruebas Alfa y Beta para la armada, fue para que el ejército, otras organizaciones y la sociedad como un todo, fluyeran suave y eficientemente como resultado de la asignación adecuada de recursos humanos, todo gracias a los datos obtenidos en las pruebas. Algunos escrutinios psicométricos de las pruebas Alfa y Beta apoyaron su uso. Éstas eran lo suficientemente confiables y parecían correlacionarse en una forma aceptable con los criterios externos como las puntuaciones en las escalas completas de CI de Binet así como las evaluaciones hechas por los oficiales a los hombres sobre “el valor práctico del soldado”. Yerkes (1921) dio esta explicación de lo que pensó que la prueba medía en realidad:

La prueba proporciona un índice confiable de la capacidad de un hombre para aprender, pensar rápido y con precisión y entender instrucciones. No miden la lealtad, coraje, dependencia con los rasgos emocionales que hacen que un hombre “continúe”. El valor de un hombre para el servicio se mide mediante esta inteligencia más otras calificaciones necesarias (p. 424).

Un objetivo original de las pruebas Alfa y Beta era medir la habilidad de un buen soldado. Sin embargo, después de la guerra, ese objetivo parecía perdido ya que las pruebas se utilizaban en diversos aspectos de la vida civil para medir la inteligencia en general. Una prueba Alfa o Beta era más fácil de obtener, aplicar e interpretar que una Stanford-Binet, y también menos costosa. Miles de librillos sin usar de las pruebas Alfa y Beta se volvieron un excedente que casi cualquiera podía comprar. Las pruebas se administraron, calificaron e interpretaron por muchas personas que no tenían los antecedentes y la capacitación para usarlas adecuadamente. La visión utópica de una sociedad en donde los individuos contribuyan de acuerdo con sus capacidades, según determinan las pruebas, probablemente nunca se materialice. Al contrario, el mal uso de las pruebas entristeció a muchos miembros del público y a la profesión sobre el uso de las pruebas, particularmente aquellas diseñadas para su aplicación a grupos.

El interés de la milicia en las pruebas psicológicas durante las décadas de 1920 y 1930 fue mínimo, sólo ante la amenaza de la segunda guerra mundial fue que resurgió el interés en las pruebas de inteligencia para grupos. La Prueba de clasificación general para la armada (*Army General Classification Test*, AGCT) fue desarrollada. Durante el curso de la segunda guerra mundial, esta prueba se administró a más de 12 millones de reclutas. Los psicólogos militares también desarrollaron otras pruebas más especializadas. Una unidad de evaluación nombrada discretamente la Oficina de Servicios Estratégicos (*Office of Strategic Services*) desarrolló medidas innovadoras para seleccionar espías y agentes secretos que trabajaran fuera del país.

Hoy en día, las pruebas grupales se siguen administrando a candidatos a reclutas, fundamentalmente para propósitos de evaluación. En general, se puede definir una **herramienta de**

evaluación como un instrumento o procedimiento utilizado para identificar un rasgo en particular o conjunto de ellos en un nivel amplio y poco preciso. Los datos obtenidos a partir del proceso de evaluación se puedan explorar con mayor profundidad mediante métodos de evaluación más individualizados. Diversos tipos de instrumentos de evaluación se utilizan en diferentes escenarios. Por ejemplo, en el siguiente capítulo revisaremos herramientas de evaluación como las listas de verificación de la conducta utilizadas en escenarios preescolares para identificar a niños pequeños

que requieran ser evaluados con procedimientos más profundos e individualizados.

En la milicia, la antigua tradición de utilizar datos a partir de las herramientas de evaluación como una ayuda en las tareas y en las asignaciones de capacitación, está vigente hoy día. Tales datos sirven también para moldear la naturaleza de las experiencias de capacitación. Por ejemplo, los datos obtenidos en pruebas grupales han indicado una tendencia a la baja en cuanto a la inteligencia media de los reclutas desde que se inició la armada formada por voluntarios. En respuesta a tales hallazgos, la milicia ha desarrollado nuevas armas y programas de capacitación que incorporan por ejemplo, vocabulario más sencillo dentro de las instrucciones programadas.

Entre las pruebas grupales utilizadas en la armada de Estados Unidos hoy en día, se encuentra la Prueba de cualificación de oficiales (*Officer Qualifying Test*); (una prueba de 115 reactivos de opción múltiple utilizada en la marina como prueba de admisión para la Escuela de candidatos a oficiales); El Examen de cualificación para pilotos (*Airman Qualifying Exam*) (una prueba con 200 reactivos de opción múltiple aplicada a los voluntarios de la fuerza aérea de Estados Unidos), y la Batería de aptitudes vocacionales para los servicios armados (*Armed Services Vocational Aptitude Battery*, ASVAB). Esta última prueba se aplica a precandidatos a reclutas en todos los servicios de la armada; también está disponible para los estudiantes de bachillerato y otros adultos jóvenes que buscan asesoría sobre su educación futura y sus planes de carrera.

Cada año, cientos de miles de personas toman esta prueba, lo que la hace tal vez la más usada de las pruebas de opción múltiple en Estados Unidos. La aplican consejeros escolares así como diversos centros sin ningún costo para los examinados. En el contexto de un programa de exploración de carrera, la ASVAB está diseñada para ayudar a los evaluados a aprender sobre sus intereses, habilidades y preferencias personales en relación con las oportunidades de carrera en ambientes militares y civiles. En la sección *Psicometría cotidiana* de este capítulo se presentan reactivos ilustrativos de las 10 subpruebas que maneja la prueba.

A través de los años, diversas versiones de la ASVAB se han producido, algunas para uso exclusivo en escuelas y algunas otras en la milicia. Un conjunto de 100 reactivos seleccionados incluidos en las subpruebas de Razonamiento aritmético, operaciones numéricas, Conocimiento verbal y Comprensión de párrafos, conforman una medición dentro de la ASVAB, llamada Prueba de calificación para las fuerzas armadas (*Armed Forces Qualification Test*, AFQT). Esta prueba es una medida de la habilidad general usada en la selección de los reclutas. Los diferentes servicios de la armada utilizan distintas puntuaciones para tomar decisiones de aceptación o rechazo del servicio, con base en consideraciones como sus puntuaciones establecidas para grupos demográficos específicos. Además, en esta última prueba, también se exploran diez áreas de aptitud en la ASVAB, incluyendo técnica general, mecánica general, electricidad, mecánica para motores,

SÓLO PIENSE...

Considerando a James Bond, ¿qué cualidades cree que un agente secreto real necesita tener? ¿Cómo podría medir esas cualidades en un solicitante?

Batería vocacional de aptitudes de servicios de la Armada
(*Armed Services Vocational Aptitude Battery, ASVAB*),
una prueba que puede contestar



Si usted quisiera tener una experiencia de primera mano en la realización de una prueba de capacidad útil en la guía vocacional, haga lo que aproximadamente 900 000 personas hacen cada año, y conteste la ASVAB. El Tío Sam pone a su disposición esta prueba sin costo alguno, junto con otros elementos de un paquete de guía de carrera, incluyendo un libro de trabajo y otros materiales impresos y la calificación e interpretación de la prueba. Aunque un objetivo es lograr que quienes responden la prueba “se pongan las botas” (es decir, entren en el ejército), responder la prueba no implica la obligación de hacer el servicio militar. Para obtener más información sobre cómo puede presentarla, póngase en contacto con la oficina de orientación vocacional de su escuela o con un reclutador militar (en Estados Unidos). Mientras, puede desear ejercitar con los siguientes diez reactivos de muestra que representan cada una de las diez subpruebas de la ASVAB.

I. Ciencia general

Aquí se presentan preguntas de ciencia general, incluyendo preguntas de las áreas de biología y física.

1. Un eclipse de Sol proyecta la sombra de
 - a) la Luna en el Sol.
 - b) la Luna en la Tierra.
 - c) la Tierra en el Sol.
 - d) la Tierra en la Luna.

II. Razonamiento aritmético

La tarea aquí es solucionar problemas aritméticos. A quienes responden la prueba se les permite usar papel (suministrado por el gobierno).

2. Impermeabilizar una lona cuesta \$0.50 por yarda cuadrada.
¿Cuánto costará impermeabilizar la lona de un camión que mide 15' × 24'?
- a) \$ 6.67
- b) \$ 18.00
- c) \$ 20.00
- d) \$180.00

III. Conocimiento de palabras

¿Cuál de las cuatro posibles definiciones define mejor a la palabra subrayada?

3. Rudimentos significa de manera más aproximada
 - a) política.
 - b) detalles menudos.
 - c) oportunidades de promoción.
 - d) métodos y procedimientos básicos.

IV. Comprensión de párrafos

Una prueba de comprensión de la lectura y razonamiento.

4. 25% de todos los asaltos a casas puede atribuirse a ventanas o puertas abiertas. El crimen es el resultado de la oportunidad sumada al deseo. Para prevenir el crimen, es responsabilidad de cada individuo...
 - a) proporcionar el deseo.
 - b) proporcionar la oportunidad.
 - c) prevenir el deseo.
 - d) prevenir la oportunidad.

V. Operaciones numéricas

Esta prueba de velocidad contiene problemas de aritmética simples que quien responde la prueba debe realizar rápido; es una de dos pruebas de velocidad en la ASVAB.

5. $6 - 5 =$
 - a) 1
 - b) 4
 - c) 2
 - d) 3

VI. Velocidad de codificación

Esta subprueba contiene reactivos de codificación que miden la velocidad perceptiva y motora entre otros factores.

CLAVE

verde...2 715	hombre...3 451	sal...4 586
sombrero...1 413	cuarto...2 864	árbol...5 927
	a) b) c) d) e)	
6. cuarto	1 413 2 715 2 864 3 451 4 586	


(continúa)

PSICOMETRÍA COTIDIANA

Batería vocacional de aptitudes de servicios de la Armada
(*Armed Services Vocational Aptitude Battery, ASVAB*),
una prueba que puede contestar
(*continuación*)

VII. Información automotriz y de compras

Esta prueba evalúa el conocimiento de los automóviles, la práctica en las compras y el uso de herramientas.



7. ¿Qué herramienta se muestra arriba?

- a) broca
- b) sierra de calar
- c) afiladora
- d) esmeriladora

VIII. Conocimiento matemático


Ésta es una prueba de capacidad para solucionar problemas usando matemáticas de nivel de bachillerato. Está permitido el uso de papel.

8. Si $3X = -5$, entonces $X =$

- a) -2
- b) $-5/3$
- c) $-3/5$
- d) $3/5$

IX. Comprensión mecánica

El conocimiento y comprensión de mecánica general y principios de física son sondeados por esta prueba.




9. El líquido se está transfiriendo del tonel al cubo por

- a) acción capilar.
- b) fuerzas gravitacionales.
- c) presión del líquido en la manguera.
- d) presión del agua en el tonel.

X. Información de electrónica

Aquí se evalúa el conocimiento de información de electricidad, radio y electrónica.



10. ¿Cuál de los anteriores es el símbolo para un transformador?

- a) A
- b) B
- c) C
- d) D

Clave de las respuestas

- | | |
|----------------------------------|-------|
| 1. b | 6. c |
| 2. c | 7. a |
| 3. d | 8. b |
| 4. d | 9. b |
| 5. ¿Por qué está revisando ésta? | 10. a |

ciencia, operaciones de combate, y habilidad técnica. Éstas se combinan para evaluar la actitud en cinco áreas de ejercicio profesional, incluyendo religiosa, electrónica, mecánica, habilidad técnica (medicina, computadoras) y operaciones de combate.

La batería de pruebas se revisa y mejora continuamente con base en los datos sobre puntuaciones predictivas del desempeño real en diversas ocupaciones así como en los programas de

capacitación militar. Se ha encontrado que la ASVAB predice el éxito dentro de las actividades de programación y operación de computadoras (Besetsny *et al.*, 1993), así como en los grados que pueden obtenerse en las escuelas técnicas militares dentro de una variedad de ramas (Earles y Ree, 1992; Ree y Earles, 1990). Una revisión de los estudios de validez apoya el constructo, el contenido y la validez relacionada con el criterio de la ASVAB como una herramienta para guiar las decisiones de capacitación y selección (Welsh *et al.*, 1990). En general, se ha catalogado a la prueba como una herramienta de gran utilidad para la selección y colocación relacionada con el personal en las fuerzas armadas (Chan *et al.*, 1999).

Pruebas grupales de inteligencia en las escuelas Quizá hace no más de una década o dos, aproximadamente dos tercios de todos los distritos escolares en Estados Unidos usaba pruebas de inteligencia aplicadas en forma grupal y rutinaria para explorar al 90% de sus estudiantes; al otro 10% se le aplicaban pruebas de inteligencia individuales. Los litigios y la legislación que rodea al uso rutinario de pruebas de inteligencia grupales han alterado un poco este panorama, aunque las pruebas de inteligencia grupales, ahora también conocidas como *pruebas de capacidad escolar*, por ningún motivo se han extinguido. En muchos estados, existen mandatos legales que prohíben el uso exclusivo de datos de inteligencia con propósitos de seguimiento intraescolar. Sin embargo, los datos de pruebas de inteligencia grupales, combinados con otros datos, pueden ser en extremo útiles para elaborar un perfil de las ventajas intelectuales de un niño.

Los resultados de las pruebas de inteligencia de grupo proporcionan al personal escolar información de valor para actividades relacionadas con la instrucción y una mayor comprensión del alumno como individuo. Una función primaria de los datos de una prueba de inteligencia grupal es alertar a los educadores sobre los estudiantes que requieren evaluaciones más extensas con pruebas de CI aplicadas en forma individual, y la posible colocación en una clase o programa especial. Los datos de las pruebas de inteligencia grupales también pueden ayudar a un distrito escolar a planear metas educativas para todos los niños.

Las pruebas de inteligencia de grupo en las escuelas se usan en formas especiales ya desde el nivel de jardín de niños. Las pruebas son aplicadas a grupos de 10 a 15 niños, cada uno de los cuales recibe un folleto de prueba que incluye ilustraciones y diagramas impresos. En su mayor parte, se requieren respuestas motoras simples para responder los reactivos, los cuales podrían aparecer en las páginas con un gran tamaño y en forma de ilustraciones en una prueba de opción múltiple, y el trabajo del niño es encerrar en un círculo o colocar una "X" en la ilustración que represente la respuesta correcta al reactivo presentado en forma oral por el administrador. A lo largo de tales evaluaciones, se debe vigilar con cuidado a los evaluados con el fin de asegurar que están siguiendo las instrucciones.

La Prueba de madurez mental de California, las Pruebas de inteligencia de Kuhlmann-Anderson, las Pruebas Henmon-Nelson de capacidad mental y la Prueba de capacidades cognoscitivas son algunas de las muchas pruebas de inteligencia grupales disponibles para ser usadas en escenarios escolares. La primera prueba de inteligencia de grupo que se usó en las escuelas de Estados Unidos, es la Prueba de capacidad escolar de Otis-Lennon, antes Prueba de capacidad mental de Otis. En su edición actual, la prueba está diseñada para medir el pensamiento abstracto y la habilidad de razonamiento, y para asistir en la evaluación y colocación escolar. Esta prueba estandarizada a nivel nacional proporciona índices de puntuaciones verbales y no verbales, así como un índice general de habilidad escolar (SAI, por sus siglas en inglés).

En general, las pruebas de aplicación grupal son herramientas útiles para la exploración cuando se debe evaluar a una gran cantidad de personas en forma simultánea o en un periodo breve. En la tabla 9-7 se muestran ventajas y desventajas más específicas de las pruebas tradicionales aplicadas en forma grupal. Hemos calificado estas pruebas como *tradicionales* porque a las versiones más contemporáneas, especialmente cuando se coloca a los evaluados ante una computadora, les va mejor el nombre *evaluación individual aplicada en forma simultánea a un grupo* en lugar de *prueba en grupo*.

Tabla 9-7

Los pros y contras de las pruebas tradicionales aplicadas en forma grupal

Ventajas de las pruebas grupales	Desventajas de las pruebas grupales
Se puede evaluar a grandes cantidades de personas al mismo tiempo, ofreciendo un uso eficiente del tiempo y los recursos.	Todos los evaluados, sin importar la capacidad, por lo general comienzan en el mismo reactivo, terminan en el mismo reactivo y se les expone a todos los reactivos de la prueba. Se minimiza la oportunidad de pruebas adaptativas.
Los evaluados trabajan independientemente a su propio paso.	Los evaluados deben ser capaces de trabajar independientemente y de comprender lo que se espera de ellos, con poca o ninguna oportunidad de preguntas o de clarificación una vez que la prueba ha comenzado.
Los reactivos de la prueba se encuentran por lo general en un formato fácil de calificar por una computadora o máquina.	Puede que los reactivos de la prueba no estén en formatos innovadores o en cualquier formato que implique que el examinador manipule los materiales o la interacción entre examinador y examinado.
Quien aplica la prueba no necesita mucha capacitación, ya que la tarea podría requerir tan sólo leer las instrucciones, medir el tiempo y supervisar a los evaluados.	El evaluador pierde la oportunidad de observar el comportamiento extratest del evaluado.
Quien aplica la prueba puede tener menos efecto en la puntuación del evaluado que otro en una situación de uno a uno.	Se pierde la oportunidad de aprender acerca del evaluado por medio de la interacción evaluador-evaluado.
Las pruebas en grupo son menos costosas que las individuales.	La información de una prueba grupal puede no ser tan detallada y práctica como aquella que se obtiene de la aplicación de una prueba individual.
Las pruebas en grupo han probado tener valor para propósitos de exploración.	Los instrumentos diseñados expresamente para explorar se usan ocasionalmente para tomar decisiones momentáneas.
Las pruebas en grupo pueden estar normalizadas con base en grandes cantidades de personas con más facilidad que una prueba individual.	En cualquier situación relacionada con la aplicación de una prueba, se supone que los evaluados están motivados para desempeñarse y seguir las instrucciones. La oportunidad de verificar esos supuestos puede minimizarse en los programas de pruebas a gran escala. El evaluado que "marcha al ritmo de otro son" está en un mayor riesgo de obtener una puntuación que no se aproxime con precisión a su verdadera puntuación.
Las pruebas en grupo funcionan bien con personas que pueden leer, seguir instrucciones, tomar un lápiz y que no requieren mucha asistencia.	Puede que las pruebas grupales no funcionen muy bien con personas que no pueden leer, que no pueden sostener un lápiz (como niños muy chicos), que "marchan al ritmo de otro son" o que tienen necesidades o requerimientos especiales.

Medidas de capacidades intelectuales específicas

SÓLO PIENSE...

Después de leer la tabla 9-7, cree su propia tabla en dos columnas, nombre a una columna Pruebas individuales y a la otra, Pruebas grupales. Entonces, escriba algunos de sus propios pensamientos en donde compare las pruebas individuales y grupales. Siéntase libre para expresar sus propias experiencias al tomar ambas clases de pruebas.

Las medidas mas usadas para la inteligencia general dan muestra sólo de una parte de la amplia gama de capacidades humanas que se puede considerar, contribuyen a la inteligencia de un individuo. Existen muchas capacidades y talentos intelectuales que no se evalúan (o que se evalúan de forma indirecta) en las pruebas más utilizadas para medir el funcionamiento intelectual. Existen, por ejemplo, pruebas disponibles para medir capacidades muy específicas como puede ser el pensamiento crítico, la música o la apreciación artística. Un área que, comprensiblemente ha recibido mucha atención es la creatividad. Es interesante, a pesar de que la mayoría de las pruebas no miden la creatividad, que aquellas diseñadas para hacerlo, pueden medir variables relacionadas con la inteligencia. Por ejemplo, se piensa que algunas capacidades que componen la

creatividad son la originalidad para resolver problemas, en la percepción y en la abstracción. En el grado en que las pruebas de inteligencia exploren estos componentes, se deberá considerar entonces a las medidas y componentes de la creatividad también como herramientas para evaluar la inteligencia.

Se encuentran disponibles diversas pruebas y baterías para medir la creatividad en los niños y adultos. De hecho, algunas universidades como la Universidad de Georgia y la Universidad Estatal de Nueva York en Búfalo, poseen bibliotecas que contienen varios cientos de estas pruebas. ¿Qué clase de tareas incluyen?, y ¿qué miden en realidad?

Cuatro términos comunes en muchas medidas de la creatividad son *originalidad*, *fluidez*, *flexibilidad* y *elaboración*. *Originalidad* se refiere a la capacidad para producir algo innovador o no obvio; puede ser algo abstracto como una idea, o algo tangible y visible como una obra artística o un poema. La *fluidez* se refiere a la facilidad con la cual las respuestas se producen, y por lo general se mide mediante la cantidad total de respuestas producidas. Por ejemplo, un reactivo en una prueba de fluidez verbal podría ser *tienes treinta segundos para mencionar cuantas palabras puedas que comiencen con la letra c*. La *flexibilidad* se refiere a la variedad de ideas presentadas y la capacidad para cambiar de un enfoque a otro. La *elaboración* se refiere a la riqueza y detalle en una explicación verbal o en una descripción pictórica.

Una crítica dirigida con frecuencia a las pruebas de inteligencia estandarizadas aplicadas en forma grupal (al igual que a otras pruebas de capacidad y rendimiento) es que la valoración del desempeño de la prueba se enfoca demasiado en si la respuesta es correcta. Este énfasis demasiado pronunciado en la respuesta correcta no deja oportunidad para evaluar los procesos como la originalidad, la fluidez, flexibilidad y elaboración. Dicho de otra forma, en la mayoría de las pruebas de rendimiento la habilidad que se requiere se llama *pensamiento convergente*. El **pensamiento convergente** es un proceso de razonamiento deductivo que incluye el recuerdo y la consideración de hechos, así como una serie de juicios lógicos para reducir la cantidad de posibles soluciones y finalmente llegar a una sola. En su estructura de modelo intelectual, Guilford (1967) hizo una distinción entre los procesos intelectuales de los tipos de pensamiento *convergente* y *divergente*. El **pensamiento divergente** implica un proceso de razonamiento en el cual al pensamiento se le permite la libertad de moverse en muchas y diferentes direcciones, haciendo posibles varias soluciones. El pensamiento divergente requiere flexibilidad, originalidad e imaginación. Hay mucho menos énfasis en el recuerdo de hechos que en el pensamiento convergente. El modelo de Guilford ha servido como estímulo para enfocar la atención de la investigación no sólo en los productos del pensamiento creativo sino también en el proceso de éste.

Guilford (1954) describió tareas como consecuencias (“Imagine lo que sucedería si...””) y usos poco frecuentes (por ejemplo, “Nombre tantos usos como pueda imaginar para una liga de hule”) como formas de evaluar la creatividad. Incluidas en la batería de pruebas de Guilford *et al.* (1974), Estructuras de habilidades intelectuales (*Structure-of-Intellect Abilities*), se encuentran subpruebas de orientación verbal (Fluidez verbal) y otras de orientación no verbal (como hacer dibujos).

Basada en el trabajo de Mednick (1962), la Prueba de asociaciones remotas (*Remote Associates Test*, RAT) presenta a quien responde la prueba tres palabras, y la tarea es encontrar una cuarta palabra que se asocie con las otras tres. Las Pruebas de pensamiento creativo de Torrance (*Torrance Tests of Creative Thinking*, 1966, 1987a, 1987b) consisten en materiales de prueba basados en palabras, al igual que en ilustraciones y en sonidos. En una subprueba de sonidos diferentes, por ejemplo, la tarea del examinado es responder qué pensamientos evoca cada sonido. Cada subprueba está diseñada para medir algunas características consideradas importantes en el proceso del pensamiento creativo.

Es interesante que muchas pruebas de creatividad no dan buenos resultados cuando se utilizan procedimientos psicométricos tradicionales. Por ejemplo, los estimados de la confiabilidad test-retest tienden a quedar en el límite del rango inaceptable en algunas de ellas. Algunos estudiosos de la evaluación, han considerado si las pruebas de creatividad deben juzgarse según estándares diferentes de otras pruebas.

SÓLO PIENSE...

Con base en esta breve descripción de la prueba RAT y de las pruebas Torrance, demuestre su propia creatividad y cree un nuevo reactivo para una de las dos esperando que éste sea indudablemente, un reactivo del siglo XXI.

Después de todo, la creatividad puede diferir de otras habilidades en que puede ser muy susceptible a la salud emocional o física, a la motivación y a los factores relacionados, incluso más que otras capacidades. Este hecho explica las débiles estimaciones de confiabilidad y validez.

SÓLO PIENSE...

¿Las pruebas de creatividad deberían depender de diferentes estándares psicométricos que cualquier otra prueba de capacidad?

Según ha leído sobre las diversas capacidades humanas, y sobre cómo pueden estar relacionadas con ese constructo intangible llamado *inteligencia*, es posible que haya pensado ¿por qué nadie ha creado una prueba que mida todos los diferentes aspectos de la inteligencia?

Aunque nadie ha emprendido ese ambicioso proyecto, en años recientes las baterías de evaluación psicológica se han desarrollado para examinar no sólo la inteligencia sino las habilidades relacionadas en escenarios educativos. Estos paquetes de pruebas, llama-

dos *baterías psicoeducativas*, se exponen en el capítulo 10, junto con otras pruebas usadas para medir las capacidades académicas.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo tratando de explicar cada uno de los siguientes términos, expresiones y abreviaturas:

AFQT	pensamiento divergente	Stanford-Binet
ASVAB	probar los límites	subprueba central
Binet, Alfred	prueba Alfa de la armada	subprueba opcional
CI	prueba Beta de la armada	subprueba suplementaria
conducta fuera de la prueba	prueba compuesta	techo
desviación de CI	prueba de encaminamiento	Terman, Lewis
escala de puntos	pruebas adaptativas	versión abreviada
fondo	puntuación del proceso	WAIS-III
herramienta de exploración	RAT	Wechsler, David
nivel basal	razón de CI	WISC-IV
nivel techo	reactivo alternativo	WPPSI-III
pensamiento convergente	reactivos de muestra	

Un vistazo a la red

Visite los siguientes sitios Web para obtener más información sobre los temas expuestos en este capítulo.

Prueba de Stanford Binet 5a edición

www.reverpub.com/products/clinical/sbis5/home.html

<http://assess.nelson.com/nelson/assess/test-ind/stan-b5.html>

www.nelson.com/nelson/assess/test/ind/stan-b5.html

http://alpha.fdu.edu/psychology/SB5_index.htm

La WISC-IV

<http://marketplace.psychorp.com/PsychCorp.com/Cultures/en-US/dotCom/WISC-IV.com.htm>

http://alpha.fdu.edu/psychology/WISCIV_Substitution.htm

<http://marketplace.psychorp.com/PsychCorp.com/Cultures/en-US/dotCom/WISC-IV.com/Product+Information.htm>

Pruebas preliminares del test—WISC-IV

www.psychcorp.com.au/WISC-IV%20report%201.pdf

Propiedades psicométricas de la WISC-IV

www.psydicorp.com.au/WISC-IV%20report%202.pdf

La WISC-IV

<http://marketplace.psychcorp.com/PsychCorp.com/Cultures/en-US/dotCom/WISC-IV.com.htm>

Dumont/Willis y la WISC-IV

http://alpha.fdu.edu/psychology/WISCIV_Index.htm

Valuaciones de la WISC-IV

www.unl.edu/buros/

La WAIS-III

<http://marketplace.psychcorp.com/PsychCorp/Images/resource/library/ppt/waispres.ppt>

La WPPSI-III

<http://marketplace.psychcorp.com/PsychCorp.com/Cultures/en-US/dotCom/WPPSI-III.com.htm>

<http://alpha.fdu.edu/psychology/WPPSIIII.htm>

La WASI

www.psychcorp.com.au/wasi.html

Literatura acerca de las pruebas de la armada para adultos Alpha y Beta

www.nald.ca/fulltext/adlitUS/Index.htm

Evaluación preescolar y educativa

¿Cuáles son algunas de las ideas que asocia con la palabra *escuela*? Si la palabra prueba viene a su mente, de seguro no será el único que lo piense, debido a la gran diversidad de tipos de pruebas que se aplican en las escuelas públicas y privadas. Los educadores están interesados en las respuestas a interrogantes tan diversas como *¿qué tan buena es su capacidad de lectura?* y *¿qué tan lejos puede saltar?* En este capítulo, examinamos pruebas diseñadas para facilitar el proceso educativo como aquellas que evalúan el rendimiento y la aptitud, al igual que pruebas de diagnóstico. Comenzaremos, sin embargo, con un breve repaso de las pruebas relacionadas con la educación que pueden ser aplicadas a un niño mucho antes de que éste ponga un pie en un salón de clases.

Evaluación preescolar

Los primeros cinco años de vida —etapa conocida como *periodo preescolar*— son de cambios profundos en los cuales se desarrollan los reflejos humanos básicos y el niño atraviesa por una diversidad de importantes eventos sensorio-motores en su desarrollo como son gatear, sentarse, pararse, caminar, correr, agarrar objetos, etcétera. Por lo común, entre los 18 y los 24 meses, el niño ya es capaz de pensar en forma simbólica y ha desarrollado las habilidades lingüísticas. A los dos años de edad, un niño promedio ya tiene un vocabulario de más de doscientas palabras. Por supuesto, todas estas observaciones sobre el desarrollo de los niños tienen una importancia mayor que simplemente la académica para los profesionales encargados oficialmente de la responsabilidad de la evaluación.

A mediados de la década de 1970, el Congreso de Estados Unidos promulgó la Ley Pública (LP) 94-142, la cual ordenaba que los niños mayores de tres años que padecieran discapacidades físicas o intelectuales fueran evaluados en forma profesional para determinar sus necesidades educativas especiales. Esa ley también proporcionó fondos federales para ayudar a los estados de la Unión Americana a satisfacer esas necesidades educativas. En 1986, un conjunto de enmiendas a la LP 94-142, conocidas como LP 99-457, hizo retroactiva la obligación de los estados hacia los niños con discapacidades considerando para esto desde el momento del nacimiento. Además, se ordenó que comenzando el año escolar 1990-1991, se proporcionara educación gratuita apropiada a todos los niños discapacitados con edades de entre tres y cinco años. En 1997 se amplió el alcance de la ley con la aprobación de la LP 105-17. Esta ordenanza fue proyectada, entre otras cosas, para dar mayor atención a una diversidad de asuntos, principalmente como un factor en la valoración y asignación de servicios especiales. La ley también ordena que los bebés y niños con discapacidades reciban servicios en el hogar o en otros medios naturales, y que tales servicios se continúen proporcionando dentro de los programas preescolares. En 1999, el trastorno por déficit de atención con hiperactividad (*attention deficit hyperactivity disorder*, ADHD) fue agregado a la lista de condiciones de discapacidad,

permitiendo que un niño sea elegible para recibir servicios especiales. Esto, combinado con una legislación federal y un creciente movimiento hacia las “escuelas de servicio completo” que ofrecen servicios psicológicos y de salud además de los de educación (Reeder *et al.*, 1997) en conjunto, indica una creciente confianza social en las técnicas de evaluación a los bebés y niños en edad preescolar.

Herramientas de evaluación preescolar

Las herramientas de evaluación preescolar son, con ciertas variaciones y adecuaciones apropiadas para cada edad, del mismo tipo que las utilizadas para evaluar a niños y adultos en edad escolar. Estas herramientas incluyen, entre otras, listas de verificación y escalas de medición, pruebas y entrevistas.

Listas de verificación y escalas de medición Las listas de verificación y las escalas de medición son herramientas de evaluación utilizadas comúnmente con niños en edad preescolar, aunque es cierto que su uso no es exclusivo en esta población. En general, una **lista de verificación** es un cuestionario en el que una persona responde algunos reactivos para indicar la presencia o ausencia de una conducta, una opinión, un evento, o alguna circunstancia específica. Las listas de verificación pueden cubrir extensas áreas, pueden ser económicas y fáciles de administrar. Estos atributos pueden hacerlas parecer muy atractivas para los atareados profesionales clínicos (Kamphaus *et al.*, 2000). Una escala de medición es muy similar en su definición y a veces es idéntica en la forma. Por lo general, una **escala de medición** es una forma completada por un evaluador (un calificador, juez o examinador) para hacer un juicio sobre una situación relativa respecto a una o más variables específicas. Al igual que con las listas de verificación, las variables pueden reflejar, por ejemplo, la frecuencia, magnitud o presencia/ausencia de un comportamiento o evento observable o una opinión verbalizada. En la actualidad, es apropiado que en las salas de alumbramiento el equipo médico reciba a los recién nacidos con una lista de verificación o una escala de medición (véase *Psicometría cotidiana*).

Dos listas de verificación y escalas de medición usadas de manera común son la Lista de verificación de conducta infantil de Achenbach (*Achenbach Child Behavior Checklist*, CBCL) y las Escalas revisadas de medición de Connors (*Connors Rating Scales-Revised*, CRS-R). La CBCL viene en versiones apropiadas para usarse con niños de 1½ a 5 años (CBCL/1½–5), así como con niños y hasta con adultos jóvenes, con edades de entre 4 hasta 18 años (CBCL/4-18). Los padres y otros familiares cercanos al sujeto proporcionan información para los reactivos correspondientes que cubren las actividades del sujeto, sus relaciones sociales y su desempeño escolar. La lista de verificación también contiene reactivos que describen una conducta específica y problemas emocionales, así como reactivos sin restricciones para reportar problemas adicionales. Los protocolos se califican a mano, a máquina o por computadora, y producen calificaciones de suficiencia así como lo hacen las escalas clínicas. La CRS-R está diseñada principalmente para ayudar a evaluar el trastorno por déficit de atención con hiperactividad, además de localizar otros problemas de conducta. El instrumento se presenta en varias versiones, cada una de ellas tiene una forma larga (con un tiempo de administración de 15 a 20 minutos) y una forma corta (con un tiempo de administración de 5 a 10 minutos). Existe una versión para padres y una versión para maestros, las cuales pueden ser usadas con niños de 3 a 17 años. Una versión de autorreporte para adolescentes está diseñada para ser utilizada en individuos de 12 a 17 años. Este instrumento se califica a mano y tiene normas basadas en más de ocho mil niños con edades entre 3 y 17 años.

La mayoría de las listas de verificación y escalas de medición sirven para clasificar las herramientas. En la evaluación preescolar, la clasificación de las herramientas puede utilizarse como un primer paso para identificar a niños que podría considerarse que están *en riesgo*. Este término surgió como una alternativa para determinar las clasificaciones que pudieran tener efectos nocivos (Smith y Knudtson, 1990). Hoy, el riesgo que un niño corre puede variar no sólo en términos del contexto del análisis, sino del estado emocional en el que se encuentre el niño. El término *en riesgo* ha sido utilizado para referirse a los niños en edad preescolar que quizá no estén listos para el primer grado y a los que no estén funcionando dentro de los límites considerados como normales. En un sentido más general, **en riesgo** se refiere a los niños que han evidenciado dificultades en una o más áreas, ya sea psicológica, social o académica y que pueden requerir de algún

Primeras impresiones

Se ha dicho que cada persona en la sociedad contemporánea es un número. Estamos representados por un número del Seguro Social, un número de licencia de conducir y muchos otros. Sin embargo, antes de éstos estamos representados por uno que se conoce como el **número de la prueba de Apgar**. En realidad, la prueba de Apgar es una calificación en una escala de medición desarrollada por la doctora Virginia Apgar (1909-1974), una obstetra anestesióloga que vio la necesidad de un método simple y rápido para evaluar a los recién nacidos y determinar qué acción inmediata, si es que alguna, es necesaria.

Como fue presentada por primera vez a principios de la década de 1950, la prueba de Apgar, es efectuada un minuto después del nacimiento para evaluar qué tan bien toleró el bebé el proceso del nacimiento. La evaluación se realiza de nuevo cinco minutos después del nacimiento para evaluar cómo se adapta el bebé al entorno. Cada evaluación se realiza con respecto a las mismas cinco variables; cada variable puede ser calificada en un rango de 0 a 2; y cada calificación (al minuto y a los cinco minutos) puede fluctuar desde 0 hasta 10. Las cinco variables son ritmo cardíaco, respiración, color, tono muscular e irritabilidad refleja. La última medida se obtiene en respuesta a un estímulo como un pellizco suave. Respecto a la variable de irritabilidad refleja, por ejemplo, el bebé obtendrá una calificación de 2 por un llanto vigoroso en respuesta al estímulo, de 1 por un gesto de dolor y de 0 si no muestra irritabilidad refleja. Son pocos los bebés que obtienen un "10 perfecto" en la prueba realizada al minuto; muchos obtienen 7, 8 y 9. Una calificación Apgar por abajo de 7 u 8 puede indicar la necesidad de asistencia pediátrica para estabilizar al bebé. Una calificación muy baja, en el rango de 0 a 3, puede indicar un problema más severo como déficit neurológico. Por cierto, un acrónimo útil para recordar las cinco variables es el mismo nombre "APGAR": A representa la actividad (o tono muscular); P, el pulso (o ritmo cardíaco); G, el gesto (o la irritabilidad refleja); A, la apariencia (o color); y R, la respiración.

Cambiando del ámbito médico al psicológico, otra evaluación tiene lugar poco después del nacimiento, una mucho menos formal, realizada por la madre del niño. Judith Langlois y algunos



Bienvenido al mundo de la evaluación

Sólo segundos después del nacimiento, un bebé recién nacido recibe su primera evaluación formal por parte del personal del hospital. La siguiente evaluación del bebé, realizada por la madre, puede ser no menos importante en sus consecuencias.

colegas (1995) estudiaron la relación entre el atractivo físico o apariencia del bebé y la conducta y las actitudes maternas utilizando una muestra de 173 madres y sus primogénitos (86 niñas y 87 niños). Aproximadamente una tercera parte de la muestra fue identificada como blanca, una tercera parte como afro-estadounidense y una tercera parte como mexicana-estadounidense. Para el registro, la media de la primera calificación obtenida en el Apgar para los bebés del estudio fue 8.36, y la media de la segunda calificación de Apgar fue 9.04.

Para estimar la apariencia física, los investigadores utilizaron valoraciones de jueces en base a fotografías tomadas a una distancia estándar del rostro de cada bebé mientras éste se encontraba dormido o tenía alguna otra expresión neutral. La

tipo de intervención. La necesidad de una intervención puede decidirse a partir de una evaluación más completa, que a menudo implica pruebas psicológicas.

Pruebas psicológicas Pruebas como la WPPSI-III, la SB5 y otras, pueden utilizarse para estimar las áreas fuertes y débiles en el desarrollo al tomar muestras del desempeño de los niños en áreas de contenido cognoscitivo, motor y social/conductual.

En los niveles primarios, las habilidades cognitivas y sociales son estimadas mediante escalas que evalúan la presencia o ausencia de varios logros relacionados con el desarrollo a través de

conducta materna durante la alimentación y los juegos fue observada directamente por evaluadores entrenados del hospital.

Un segundo conjunto de observaciones fue registrado a los tres meses del nacimiento del bebé. Una medida desarrollada por Parke y Sawin (1975) llamada Cuestionario de la actitud de los padres fue utilizada para evaluar las actitudes maternas en el hospital y aproximadamente tres meses después fuera de él. Los investigadores encontraron que aunque todos los infantes estudiados recibieron un cuidado adecuado, los bebés atractivos recibieron un tratamiento y actitudes más positivas por parte de sus madres que los bebés menos atractivos. Las madres de los bebés atractivos fueron más afectuosas y juguetonas. Las madres de los pequeños menos atractivos eran más propensas a estar atentas a otras personas en lugar de a sus hijos. Estas madres también se inclinaron a desarrollar una rutina de cuidados más que una conducta afectiva. Las actitudes de las madres de los bebés menos atractivos, en particular durante la primera evaluación, también fueron más negativas que las de las madres de los bebés más atractivos. En el momento de la primera evaluación las madres de niños menos atractivos tendieron más a expresar la creencia de que sus hijos estaban interfiriendo en sus vidas. Aproximadamente tres meses después, las madres de los niños menos atractivos, comparadas con las madres de los bebés más atractivos, fueron más propensas a sostener la creencia de que sus hijos requerían más estimulación, aunque ya no hubo diferencia en relación con las creencias acerca de la interferencia en sus vidas.

Estos resultados son consistentes con investigaciones previas que sugerían que los niños atractivos eran tratados con menos rudeza por los adultos que los niños no atractivos (Berkowitz y Frodi, 1979; Dion, 1979; Elder *et al.*, 1985) y que las madres de niños con anomalías físicas se pueden comportar de una manera menos deseable con sus hijos que las madres cuyos niños no tienen dichas anomalías (Allen *et al.*, 1990; Barden *et al.*, 1989; Field y Vega-Lahr, 1984). También los padres se pueden comportar de manera diferente en función del atractivo físico de su descendencia. Parke *et al.* (1977) encontraron que la calidad del cuidado de los padres con los niños de tres meses de edad

estaba correlacionada en forma significativa y positiva con el atractivo físico (apariencia) de los bebés.

Langlois *et al.* (1995) advirtieron que los resultados correlacionales no deberían interpretarse como indicativos de causa y efecto; los resultados no deben utilizarse para apoyar enunciados que indiquen que el atractivo o la apariencia física causa o afecta el comportamiento y las actitudes maternas. Sin embargo, parece ser el caso que, por alguna razón, la apariencia física de los bebés tiende a predecir el comportamiento y las actitudes de las madres. Los investigadores también deseaban saber si los resultados de su estudio se podrían generalizar a familias de otros niveles de ingreso, o qué efecto podría tener el nacimiento de otros hijos en los resultados principales. Puede ser que la relativa inexperiencia de las madres con el rango de las conductas infantiles las condujera a estar más influenciadas por la apariencia de sus hijos en comparación con las madres que han tenido otros hijos.

Desde el momento del nacimiento en adelante, la evaluación —tanto formal como informal— es un importante factor de la vida. Podemos definir la **evaluación informal** como una valoración típicamente no sistemática, relativamente breve, y “confidencial” que conduce a la formación de una opinión o actitud, efectuada por cualquier persona, de cualquier modo, por cualquier razón, en un contexto no oficial que no está sujeto a la ética u otros estándares de la evaluación realizada por un profesional. El proceso de la evaluación informal no ha recibido mucha atención en la literatura de evaluación psicológica. En consecuencia, la naturaleza y extensión de la influencia de evaluaciones informales realizadas por la gente (como padres, maestros, supervisores, personal del sistema de justicia criminal y otros) se desconoce ampliamente. Por un lado, considerando la necesidad de privacidad, quizá sea mejor que esas evaluaciones privadas permanezcan de esa manera. Por otro lado, las investigaciones como la realizada por Langlois *et al.*, traen a la luz las implicaciones cotidianas de dichas evaluaciones informales —implicaciones que finalmente pueden ayudar a mejorar la calidad de vida de muchas personas—.

medios como la observación y de entrevistas con los padres (o tutores). A la edad de dos años, el niño entra en un periodo de desafío para los evaluadores psicológicos. Las habilidades del lenguaje y conceptuales comienzan a emerger, no obstante el tipo de pruebas verbales y de desempeño que se usan de manera tradicional con niños mayores y adultos son inadecuadas para ellos ya que el periodo de atención del niño en etapa preescolar es corto. De manera ideal, los materiales de las pruebas son coloridos, atractivos, y captan su atención. Una hora es un tiempo límite adecuado de sesión para los procedimientos de evaluación con una prueba determinada para un niño en edad preescolar, aunque sería preferible un tiempo menor. En la medida en que se incrementa el tiempo




Figura 10-1
Un formato de doble caballete en la aplicación de pruebas

El formato de caballete en el contexto de la aplicación de pruebas se refiere a materiales de prueba, por lo general alguna clase de libro que contiene materiales de estímulo de la prueba y que puede doblarse y colocarse sobre un escritorio; el examinador da vuelta a las páginas para revelar al examinado, por ejemplo, objetos que éste debe identificar o diseños que deberá copiar. Cuando las instrucciones u observaciones para la aplicación de la prueba correspondiente están impresas en el lado opuesto de las páginas de la prueba de estímulo para comodidad del examinador durante la aplicación de la prueba, en ocasiones se denomina de doble caballete.

de la prueba, también aumenta la posibilidad de fatiga y distracción. Y con la fatiga y distracción del evaluado hay una mayor posibilidad de subestimar su habilidad. La motivación del menor puede variar de una sesión de prueba a otra, y esto es algo que el examinador debe tomar en cuenta. Las pruebas más aceptadas por los examinadores que de manera regular trabajan con niños de preescolar son aquellas que son relativamente fáciles de administrar, que tienen reglas simples para comenzar y detenerse, y que permiten al examinador una amplia oportunidad de hacer observaciones respecto a la conducta del niño. El formato de doble caballete para administrar la prueba (figura 10-1), las muestras y los reactivos de enseñanza para cada subprueba así como la evaluación dicotómica (por ejemplo, correcto/incorrecto), facilitan la administración de las pruebas.

SÓLO PIENSE...

"El establecimiento de la confiabilidad de una prueba y su repetición con un intervalo de mediación tan pequeño como un mes puede ser un problema, en especial para los niños muy pequeños". ¿Está de acuerdo con esto? ¿Por qué sí o por qué no?

Los datos de las pruebas de inteligencia para niños, en especial cuando se combinan con otra información (como la historia del nacimiento, la historia emocional y social, la historia de salud, los datos sobre la calidad del ambiente emocional y físico y las medidas de conducta adaptativa) han demostrado ser útiles para los profesionales de la salud cuando surgen indicios acerca de una discapacidad en el desarrollo y de algún déficit relacionado. Las pruebas también han demostrado ser útiles para ayudar a definir las habilidades así como el nivel de discapacidad en niños con trastornos psíquicos mayores. Además, las pruebas han sido usadas durante varios años por muchas agencias de adopción las cuales revelan e interpretan esa información a los candidatos a ser padres adoptivos. Las pruebas para infantes también tienen una amplia aplicación en el área de investigación y pueden representar un papel importante en la selección

de niños para las primeras experiencias educativas especializadas o para medir el resultado de las intervenciones del cuidado educativo, terapéutico o prenatal.

¿Cuál es el significado de la calificación en una prueba de inteligencia para niños? Mientras que algunos de los creadores de pruebas para niños (como Cattell, 1940; Gesell *et al.*, 1940) afirman que esas pruebas pueden predecir la futura habilidad intelectual, debido a que éstas miden los precursores del desarrollo de tal habilidad, otros han insistido en que el desempeño de esas pruebas cuando mucho reflejan la integridad física y neuropsicológica del infante. La literatura de investigación apoya un punto intermedio entre esas posturas extremas. En general, no se ha encontrado evidencia de que la efectiva predicción en el desempeño de un niño o de un adulto en cuanto a pruebas de inteligencia —pruebas que se relacionan con diferentes tipos de habilidades y procesos de pensamiento—. La capacidad de predicción de las pruebas de inteligencia infantil tiende a incrementarse con los extremos del desempeño infantil. El intérprete de la prueba puede decir, sin temor a equivocarse, más acerca del futuro desempeño de un niño cuyo desempeño ha sido muy por debajo de lo esperado para su edad o significativamente mayor en comparación a otros niños de su edad. Sin embargo, la infancia es un periodo de desarrollo con muchos impulsos y retrasos, y los niños que son lentos o precoces en esta etapa pueden emparejarse o retroceder en años posteriores. Quizá el valor más importante de las pruebas en la etapa preescolar radica en su habilidad para ayudar a identificar a niños que se encuentran en un rango inferior o muy por debajo del funcionamiento y desarrollo esperado para su edad y que necesitan de algún tipo de intervención.

Otras medidas Muchos otros instrumentos y técnicas de evaluación están disponibles para ser utilizados con niños en etapa preescolar, incluidas las entrevistas, los métodos que utilizan la historia personal y familiar (historia del desarrollo), la evaluación de portafolio y los métodos conocidos como *rol-playing*. Hay instrumentos, por ejemplo, que miden el temperamento (Fullard *et al.*, 1984; McDevitt y Carey, 1978), habilidades de lenguaje (Smith *et al.*, 2000), el ambiente familiar en general (Moos y Moos, 1994), y aspectos específicos del papel de los padres o los tutores (Arnold *et al.*, 1993; Lovejoy *et al.*, 1999). Algunas técnicas, como dibujar figuras para evaluar la personalidad, se estudian en el capítulo 12. Algunas técnicas son muy especializadas y podrían ser utilizadas sólo bajo condiciones extraordinarias o en el contexto de una investigación enfocada en una cuestión específica. Un ejemplo de esta última es el Inventario de la conducta sexual del niño (Friedrich *et al.*, 2001), la cual a través de 38 reactivos realiza un listado de verificación de la conducta para identificar posibles víctimas de abuso sexual y puede ser utilizada a partir de los dos años de edad. En resumen, se dispone de un creciente número de instrumentos que pueden utilizarse con niños en etapa preescolar para ayudar a evaluar, entender mejor y lograr intervenciones apropiadas (si es posible) en una amplia variedad de áreas relacionadas con su desarrollo personal, social y académico.

A partir de este punto del capítulo, nos enfocaremos en los niños en edad escolar y en los adultos jóvenes, así como en varios tipos de pruebas y evaluaciones efectuadas en contextos educativos. Comenzamos con las pruebas de rendimiento, tema con el que muchos estudiantes afirman estar (demasiado) familiarizados.

Pruebas de rendimiento

Las **pruebas de rendimiento** están diseñadas para medir avances y logros. Una prueba de rendimiento para un alumno en primer año podría tener como tema el alfabeto inglés, mientras que una prueba de rendimiento para alguien más podría contener preguntas relacionadas con los principios de la evaluación psicológica. En resumen, las pruebas de rendimiento están diseñadas para medir el grado de aprendizaje que ha tenido lugar como resultado de la exposición a una experiencia de aprendizaje relativamente definida. La “experiencia de aprendizaje relativamente definida” puede ser tan amplia como el *aprendizaje adquirido durante cuatro años en la universidad*, o algo tan limitado como la *preparación de masa para hacer pizza*. Una prueba de rendimiento puede estandarizarse a nivel nacional, regional o local, o no estandarizarse en absoluto. Una prueba informal sorpresiva sobre la anatomía de una rana aplicada por un maestro de biología de bachillerato califica como una prueba de rendimiento al igual que un examen de biología a nivel estatal.

Así como otras pruebas, las de rendimiento varían en forma extensa respecto a su solidez psicométrica. Una prueba de rendimiento sólida es aquella que ejemplifica de forma adecuada un tema seleccionado y estima en forma confiable el grado de aprendizaje que han tenido todos los examinados.

Las calificaciones en las pruebas de rendimiento pueden ser utilizadas de varias maneras. Pueden ayudar al personal de la escuela a tomar decisiones relativas a la colocación de un estudiante en un grupo en particular, a su aceptación en un programa específico o su avance a un nivel más alto. Las pruebas de rendimiento también pueden ser útiles para estimar la calidad de enseñanza dentro de un salón de clases, una escuela, un distrito escolar o un estado. Las pruebas de rendimiento en ocasiones se utilizan para detectar dificultades, y en esos casos se puede determinar la administración de pruebas de diagnóstico más específicas diseñadas para identificar las áreas que deben ser corregidas.

Las pruebas de rendimiento juegan un papel esencial en la identificación de niños con discapacidades en el aprendizaje. A pesar de que hace más de un cuarto de siglo se publicó una definición en la ley federal (véase la Ley de Educación para Todos los Niños Discapacitados, de 1975, Ley pública 94-142, Sección 5b, 4), y aunque había un procedimiento para la evaluación (Procedimientos para evaluar discapacidades específicas en el aprendizaje, 1977), un consenso entre los profesionales respecto a una definición de *discapacidad en el aprendizaje* ha permanecido elusivo. En consecuencia, se han empleado una gran variedad de métodos de evaluación en un esfuerzo por cumplir con dicha ley. Para los propósitos de este libro, definiremos **discapacidad en el aprendizaje** como “un trastorno que implica una discrepancia entre la habilidad y el logro la cual puede manifestarse en sí misma como déficit de atención, déficit emocionales, de percepción y/o motores, así como problemas relacionados con la elaboración de cálculos matemáticos, la lectura, la escritura, la ortografía y con el uso o el entendimiento del lenguaje sea hablado o escrito.

El término no se aplica a personas con problemas académicos de origen económico o cultural, ni a personas que tengan problemas de aprendizaje debidos principalmente a discapacidades visuales, auditivas, motoras o por discapacidad intelectual.

Dado un mandato federal para identificar a niños con “discrepancia severa entre logros y habilidad intelectual” (Procedimientos para evaluar discapacidades específicas para el aprendizaje, 1977, p. 65083), puede apreciarse con facilidad cómo las pruebas de rendimiento, al igual que las de inteligencia y otras medidas de habili-

dad cognoscitiva y de aptitud pueden desempeñar un papel importante en el diagnóstico de una discapacidad para el aprendizaje (o una *discapacidad específica para el aprendizaje*, como es llamada en la legislación). Un enfoque común para el diagnóstico es administrar pruebas de rendimiento y habilidad cognoscitiva y luego determinar mediante alguna fórmula si existe una discrepancia significativa. Por ley, un(a) niño(a) será diagnosticado(a) como discapacitado(a) para el aprendizaje y por tanto con derecho a obtener servicios escolares especiales sólo si existe una discrepancia significativa entre su rendimiento real y el nivel de rendimiento esperado en una o más de las siguientes áreas: expresión oral, comprensión para escuchar, expresión escrita, habilidades básicas de lectura, comprensión de lectura, cálculo o razonamiento matemático. Como veremos a continuación, en años recientes los editores de pruebas han buscado proporcionar pruebas del tipo “todo en uno” que suministren los medios para determinar si un niño debe ser diagnosticado como discapacitado para el aprendizaje.

SÓLO PIENSE...

¿A qué cree que se deba el hecho de que haya tanta controversia acerca de la definición del término *discapacidad para el aprendizaje*?

Medidas de rendimiento general

Las medidas de rendimiento general pueden evaluar el aprendizaje en una o más áreas académicas. Las pruebas que abarcan diversas áreas académicas están divididas de manera típica en varias subpruebas y son conocidas como *baterías de rendimiento*. Tales baterías pueden aplicarse en forma individual o en grupo. Pueden consistir en unas cuantas subpruebas, como la “Prueba de Rendimiento de Espectro Amplio-3” (Wilkinson, 1993) con sus medidas de lectura, ortografía y aritmética. Pueden ser tan inclusivas como las series STEP, que incluyen subpruebas de lectura, vocabulario, matemáticas, habilidades de redacción, habilidades de estudio, ciencia y estudios

sociales; un inventario de comportamiento; un cuestionario sobre el ambiente educativo, y un inventario de actividades.

Algunas baterías, como las Pruebas de rendimiento de California SRA, abarcan desde el jardín de niños hasta el doceavo grado, es decir, hasta preparatoria, mientras que otras son para un grado o curso específico. Algunas baterías son elaboradas para proporcionar análisis con referencia a una norma y con referencia a un criterio. Otras son normalizadas en forma concurrente con pruebas de aptitud escolar para permitir una comparación entre logro y aptitud. Algunas baterías son elaboradas con pruebas de práctica que pueden ser aplicadas varios días antes de la prueba real y sirven para ayudar a los estudiantes a familiarizarse con los procedimientos de la administración de la prueba. Otras baterías contienen un localizador o pruebas de itinerario; pruebas previas aplicadas para determinar el nivel más apropiado para la aplicación de la prueba real.

Un instrumento popular idóneo para ser utilizado con personas de 4 años en adelante, es decir, hasta con adultos, es la Prueba de rendimiento individual de Wechsler, Segunda Edición, conocida también como la WIAT-II (Psychological Corporation, 2001). Este instrumento se utiliza no sólo para estimar el rendimiento, sino también para elaborar hipótesis acerca del rendimiento en oposición a la habilidad. Se caracteriza por tener nueve subpruebas que son una muestra del contenido en cada una de las siete áreas requeridas por la Ley de Educación para Individuos con Discapacidades: expresión oral, comprensión al escuchar, expresión escrita, habilidad de lectura básica, comprensión de lectura, cálculo matemático y razonamiento matemático. La prueba fue diseñada para facilitar la comprensión de los procesos para la resolución de problemas así como las estrategias utilizadas por los evaluados para ello. El manual técnico suministra información estándar de puntuaciones en base a la edad y al grado del evaluado. Las calificaciones de la prueba toman en cuenta un análisis detallado de las habilidades y especifican la intervención de objetivos para planes de educación individualizada. La calificación puede hacerse de manera manual o mediante un programa de computación opcional capaz de crear un reporte básico que se puede exportar a un procesador de palabras.

De la gran variedad de baterías de rendimiento disponibles, la prueba más apropiada para ser usada deberá ser la más consistente con los objetivos educativos del maestro o del sistema educativo en lo individual. Para un propósito particular puede ser preferible una batería que se enfoque en el rendimiento de unas cuantas áreas seleccionadas a una que intente ser una muestra del rendimiento en varias áreas. Por otra parte, una prueba que ejemplifique muchas áreas puede ser ventajosa cuando es deseable una comparación individual del desempeño a lo largo de áreas temáticas. Si una escuela o un distrito escolar local emprende el seguimiento del progreso de un grupo de estudiantes medido por una batería de rendimiento particular, la elección será aquella que comprenda las áreas temáticas que se pretenden alcanzar en todos los grados que se van a examinar. Si el interés principal es la capacidad para distinguir áreas individuales de dificultad, se elegirán las pruebas de rendimiento con firmes características de diagnóstico.

Aunque las baterías de rendimiento ejemplifican una amplia categoría de áreas en todos los grados, han sido estandarizadas a gran escala y grandes muestras de estudiantes a nivel nacional tienen muchos motivos para recomendarlas, también tienen ciertos inconvenientes. Por ejemplo, estas pruebas por lo general requieren de muchos años para su desarrollo, en el ínterin los reactivos, en especial en áreas como estudios sociales y ciencias, pueden volverse anticuados. Además, cualquier instrumento estandarizado a nivel nacional sólo es conveniente en la medida en que cumple con los objetivos de los usuarios (locales) de la prueba.

Medidas de rendimiento en áreas específicas de conocimiento

Mientras que las baterías de rendimiento tienden a ser instrumentos estandarizados, la mayor parte de las medidas de rendimiento en áreas específicas de conocimiento son pruebas elaboradas por cada profesor. Cada vez que un maestro aplica una prueba informal sorpresiva, una prueba formal o un examen final en un curso, se origina una prueba en un área temática específica. No obstante, hay varios instrumentos estandarizados diseñados para estimar el rendimiento en áreas específicas.

En el nivel de enseñanza elemental, se enfatiza la adquisición de habilidades básicas como la lectura, escritura y aritmética. Las pruebas para medir el avance en la lectura tienen muchas

formas diferentes. Por ejemplo, existen pruebas para ser administradas en forma individual o en grupo, y de lectura en silencio o en voz alta. Las pruebas pueden variar en la teoría de la habilidad cognoscitiva en que se basen (véase, por ejemplo, Vanderwood *et al.*, 2001) y en el tipo de datos y subpruebas que manejan. En general, las pruebas presentan al examinado palabras, oraciones o párrafos para ser leídos en silencio o en voz alta y la capacidad de lectura se evalúa mediante variables como comprensión y vocabulario. Cuando el material sea leído en voz alta, se medirán la precisión y la velocidad. Las pruebas de comprensión de la lectura también varían respecto a las demandas intelectuales puestas en el examinado en y por arriba de la simple comprensión de las palabras leídas. Así, algunas pruebas podrían requerir que el examinado tan sólo recuerde hechos de un pasaje, mientras que otras podrían requerir que interprete y haga deducciones.

En el nivel de enseñanza secundaria, una batería popular es la Prueba de rendimiento cooperativo. Ésta consiste de una serie de ejercicios de rendimiento, separadas en áreas tan diversas como inglés, matemáticas, literatura, estudios sociales, ciencias y un idioma extranjero. Cada prueba fue estandarizada en poblaciones diferentes y adecuadas al nivel de enseñanza; en general, cada una de las estandarizaciones tienden a ser instrumentos sólidos desde un punto de vista técnico. Por ejemplo, el componente de historia estadounidense de la serie de estudios sociales fue estandarizada en alumnos de séptimo y octavo grados que representaron a 44 secundarias y 73 bachilleratos. La muestra fue seleccionada al azar y estratificada de acuerdo con escuelas públicas, religiosas y privadas. La evaluación del rendimiento en los estudiantes de educación media puede implicar la evaluación de competencias mínimas, como un requisito para el diploma de bachillerato (véase el *Close-up* de este capítulo).

En el nivel universitario, en años recientes se ha observado un creciente interés de parte de las legislaturas estatales para hacer obligatoria la evaluación de los resultados al finalizar la licenciatura en colegios y universidades estatales. Al parecer, los contribuyentes quieren confirmar que el dinero que pagan en términos de impuestos para la educación se está invirtiendo adecuadamente. Así, por ejemplo, los estudiantes de psicología a nivel licenciatura que asistan a una institución sostenida por el estado, podría pedírseles que en el último año presenten un examen final —en sentido literal— que abarque una serie de materias que podría ser descrita como “todo lo que un aspirante a la licenciatura en psicología debería saber”. Y si esto le parece excesivo, confíe en nosotros cuando le advertimos que la tarea de elaborar este tipo de exámenes es mucho mayor.

Otra utilidad de las pruebas de rendimiento en la universidad al igual que para niveles propios de adultos es con el fin de la colocación. El “programa de colocación anticipada” elaborado por el Consejo de Exámenes de Admisión a la Universidad ofrece a los estudiantes de bachillerato la oportunidad de lograr crédito universitario por el trabajo realizado mientras cursan el bachillerato. La culminación exitosa del programa, puede dar como resultado una posición privilegiada, créditos anticipados por diversos cursos, o ambos, dependiendo de la política del colegio. Desde su inicio, el programa de colocación anticipada ha dado como resultado un crédito o una posición de privilegios para más de cien mil estudiantes de bachillerato en aproximadamente dos mil universidades de Estados Unidos.

Otro tipo de prueba que puede ser aplicada con propósitos de colocación, particularmente en áreas del país donde el inglés puede ser hablado como un segundo idioma para un segmento relativamente grande de la población (como partes de California, Florida y Texas) es una prueba de eficiencia en el idioma inglés. Los datos de una prueba de eficiencia en el inglés son utilizados en la actualidad en el programa de colocación de aspirantes universitarios en el nivel apropiado según el dominio del inglés como segundo idioma. Sin embargo, pueden preverse otros usos para los datos de la medición de eficiencia en este idioma. En una era en la que un número creciente de estadounidenses nativos e inmigrantes con una eficiencia limitada en el manejo del idioma inglés, y en un clima social que mantiene a los legisladores redactando proyectos de ley proclamando que éste es el idioma oficial del estado, uno puede prever la creciente importancia de cuestiones relacionadas con las pruebas de eficiencia en torno al uso y dominio de este idioma.

Las pruebas de rendimiento en la universidad o para adultos, también pueden evaluar si debe concederse un crédito universitario por el aprendizaje adquirido fuera de un salón de clases universitario. Se han diseñado una gran cantidad de programas para evaluar en forma sistemática si se ha adquirido el conocimiento suficiente para calificar por un crédito en algún curso. El Programa de exámenes de nivel universitario (College Level Examination Program, CLEP) se basa en la premisa de que el conocimiento puede ser obtenido por medio del estudio independiente y

Pruebas de capacidad mínima

Poco después de que Estados Unidos se convirtiera en una nación independiente, un ciudadano comentó en un libro titulado *Letters from an American Farmer* (*Cartas de un granjero estadounidense*) que una “agradable uniformidad de capacidad honesta ronda por todas nuestras habitaciones” (Crèvecoeur, 1782, citado en Lerner, 1981). Más de doscientos años después, se ha vuelto evidente una insatisfacción general por la falta de capacidad en este país. Hacia el año de la celebración del bicentenario de Estados Unidos, comenzó a tomar forma un movimiento popular dirigido a erradicar el analfabetismo y el desconocimiento de los números. Para 1980, 38 estados habían aprobado leyes requiriendo que las escuelas aplicaran una prueba para determinar si los graduados de educación secundaria habían desarrollado una “capacidad mínima necesaria”. Exactamente qué es lo que constituye la capacidad mínima variaba de una jurisdicción a otra, pero en general se refería a algún conocimiento básico de lectura, escritura y aritmética. El movimiento ganó impulso con la comprensión de que los iletrados y quienes desconocen los números a menudo terminan siendo no sólo desempleados sino también inempleables. La desafortunada consecuencia es que la mayor parte de estos individuos requieren de la asistencia pública o, alternativamente, se vuelven delincuentes —y algunos acaban en la cárcel.

Un programa de prueba de capacidad mínima está diseñado para asegurar que el estudiante galardonado con un diploma de bachillerato ha adquirido al menos las habilidades mínimas necesarias para volverse un miembro productivo de la sociedad. Esas habilidades mínimas incluyen llenar una solicitud de empleo, expedir cheques, hacer el balance de una chequera e interpretar un estado de cuenta bancario.

Como ejemplo de una prueba de capacidad mínima, enfoquemos nuestra atención en el Examen de graduación del bachillerato de Alabama (*Alabama High School Graduation Exam*, AHSGE). Una publicación del Departamento Estatal de Educación de Alabama (Alabama State Department of Education; Teague, 1983) expresó especificaciones muy detalladas para los reactivos que serán usados en el AHSGE. Las habilidades que son examinadas están basadas en habilidades mínimas de noveno grado en las áreas de Lectura, Lenguaje y Matemáticas. Algunas de las habilidades enumeradas en el área de Lenguaje son:

- *Observar la concordancia entre el pronombre y el antecedente.* El estudiante escoge el pronombre que concuerde con su antecedente.
- *Uso correcto de formas de sustantivos y verbos.* El estudiante escoge la forma correcta de los sustantivos (singular y/o plural) y de los verbos (regular y/o irregular) y selecciona los verbos que concuerden con los sujetos.

- *Incluir en un mensaje o en una solicitud toda la información necesaria (quién, qué, cuándo, dónde, cómo o por qué).* El estudiante demuestra su conocimiento acerca de la información necesaria en un mensaje o solicitud.
- *Determinar qué información falta en un mensaje, un anuncio o en la explicación de un proceso, o qué información es irrelevante.*
- *Identificar signos de interrogación, puntos finales y signos de admiración para enfatizar enunciados.*
- *Identificar palabras usadas con frecuencia en actividades diarias.* El estudiante reconoce palabras usadas con frecuencia que están escritas en forma incorrecta.
- *Completar una forma común, como una solicitud de licencia para conducir o una forma para notificar un cambio de domicilio.*
- *Identificar el formato apropiado para una carta amistosa.*
- *Identificar el formato apropiado para una carta de negocios.* El estudiante demuestra su conocimiento del formato apropiado de una carta comercial, lo cual incluye la puntuación y el uso correcto de las mayúsculas. Las preguntas de la prueba se refieren a cartas comerciales reproducidas en el folleto de la prueba. Un ejemplo aparece al final de este *Close-up*.

Aunque la capacidad mínima puede parecer una buena idea, no ha pasado sin ser desafiada en los tribunales. ¿Quién debe determinar las habilidades involucradas en la capacidad mínima y la carencia de ésta? ¿Qué consecuencia habrá para aquellos carentes de la capacidad mínima necesaria? ¿El requerimiento de capacidad mínima para obtener un diploma de bachillerato motivaría a quienes carecen de motivación académica? En 1979, un juez federal del estado de Florida consideró anticonstitucional la aplicación del programa de la Ley de Capacidad Mínima en ese estado. Condenando la decisión del juez, Lerner (1981) escribió que “las disputas sobre cuestiones empíricas no pueden ser resueltas por un decreto judicial” y prosiguió documentando que 1) cantidades considerables de estadounidenses están fallando en el dominio de las habilidades básicas, como la lectura, 2) las consecuencias de tales déficits justifican la acción y 3) las acciones recomendadas por los defensores de la capacidad mínima necesaria ofrecen una esperanza razonable para producir el cambio deseado (véase también Lerner, 1980). Los críticos de tales programas (como Airasian *et al.*, 1979; Haney y Madaus, 1978; Tyler, 1978) objetan principalmente en base al potencial para el abuso inherente a tales programas, aunque también se han expresado algunas críticas respecto a la solidez psicométrica de los instrumentos.

(continúa)

CLOSE-UP

Pruebas de capacidad mínima
(continuación)

120 Drewry Road
Monroeville Alabama 36460

Srita. Ann Andrews,
Directora de Parques y recreación
Monroeville, Alabama 36460

Estimada señorita Andrews:

A nuestro grupo escolar le gustaría usar la Casa comunitaria para nuestro baile de graduación. La fecha tentativa para el baile es el 30 de abril de 2005. Por favor hágame saber si el salón de fiestas estará disponible en esa fecha y el costo por el uso de esta instalación.

atentamente,

Jan Austin

- | | |
|--|---|
| 1. ¿Qué parte de la carta es el saludo?
a) Jan Austin
*b) Estimada señorita Andrews:
c) Atentamente,
d) Srita. Ann Andrews | 3. ¿Qué parte de la carta tiene un error en las mayúsculas?
*a) La despedida
b) El cuerpo
c) La dirección interior
d) El encabezado |
| 2. ¿Qué parte de la carta tiene un error de puntuación?
a) El saludo
b) La despedida
c) La firma
*d) El encabezado | 4. ¿Qué parte de esta carta comercial se ha omitido?
*a) La fecha de la carta
b) El saludo
c) La despedida
d) La dirección interior |

Reactivos de muestra diseñados para evaluar el conocimiento del examinado del formato para una carta comercial

de otras fuentes distintas a la enseñanza formal. El programa incluye exámenes en temas que van desde historia afroamericana hasta pruebas y medición. El Programa de examen de proeficiencia (PEP) ofrecido por el Programa Estadounidense de pruebas universitarias (*American College Testing Program*) es otro servicio diseñado para evaluar el rendimiento y las habilidades adquiridas fuera de un salón de clases.

SÓLO PIENSE...

¿Para qué experiencia de la vida fuera de un programa de ciclo escolar regular le darían crédito en la escuela? ¿Cómo sería una prueba para medir lo que aprenda de esa experiencia?

Las necesidades especiales de los adultos con una amplia variedad de antecedentes educativos son abordadas en pruebas como "Examen de aprendizaje básico para adultos" (*Adult Basic Learning Examination, ABLE*), una prueba planeada para ser usada con examinados de 17 años de edad y mayores que no han completado

ocho años de escolaridad formal. La prueba está diseñada para evaluar el rendimiento en las áreas de vocabulario, lectura, ortografía y aritmética; fue elaborada consultando con expertos en el campo de la educación para adultos.

Las pruebas de rendimiento usadas a nivel nacional pueden examinar información o conceptos que no son enseñados dentro de un programa específico de estudios escolares. De cualquier forma, algunos niños resolverán bien estos reactivos, habiendo estado expuestos a los conceptos o información en forma independiente. Por consiguiente, el desempeño en una prueba de rendimiento escolar no depende por completo de la formación académica. La preocupación por estas cuestiones ha conducido a un interés en la **evaluación basada en el plan de estudios (EBPE)**, un término utilizado para referirse a la evaluación de la información adquirida de lo aprendido en la escuela. La **medición basada en el plan de estudios (MBPE)**, un tipo de EBPE, se caracteriza por el uso de procedimientos de medición estandarizados para derivar normas locales que pueden utilizarse en la evaluación del desempeño de un estudiante en tareas basadas en el plan de estudios.

Antes de dejar el tema de las pruebas de rendimiento, señalaremos en forma breve que hay al menos dos tipos de reactivos diferentes en las pruebas de rendimiento. Un tipo demanda sólo memoria de rutina. Un ejemplo de un reactivo así en un examen diseñado para medir el dominio del material de este capítulo podría ser como éste:

1. Un tipo de reactivo que podría ser utilizado en una prueba de rendimiento es un reactivo que requiere

- a) Memoria remota.
- b) Memoria de rutina.
- c) Pérdida de memoria.
- d) Pérdida nemotécnica.

De manera alternativa, los reactivos en las pruebas de rendimiento podrían requerir que quien responde la prueba, no sólo conozca y entienda el material sino que también sea capaz de aplicarlo. En una prueba de proeficiencia en el idioma inglés, por ejemplo, podría ser importante para el examinado conocer más el vocabulario o las reglas gramaticales; los reactivos que estiman la capacidad del examinado para entender o hablar el inglés en una conversación podrían ser de mucha mayor importancia.

Cambemos —pero no demasiado— del tema de las pruebas de rendimiento al de las pruebas de aptitud. Pero antes de hacerlo, ejerce su escritura (y su mente) resolviendo el apartado *Sólo piense...*

SÓLO PIENSE...

“Las pruebas de rendimiento miden el conocimiento aprendido, mientras que las pruebas de aptitud miden el potencial innato.”
¿Por qué esta creencia es un mito?

Pruebas de aptitud

Constantemente estamos adquiriendo información a través de las experiencias cotidianas de la vida y las del aprendizaje formal (como el trabajo en un curso escolar). La diferencia primaria entre las pruebas de rendimiento y las de aptitud es que las **pruebas de aptitud** tienden a enfocarse más en el aprendizaje informal o en las experiencias cotidianas, mientras que las pruebas de rendimiento tienden a enfocarse en el aprendizaje que ha tenido lugar como resultado de la adquisición relativamente estructurada de información. Manteniendo esta distinción en mente, considere los siguientes dos reactivos, el primero proveniente de una prueba hipotética de rendimiento y el segundo de una prueba hipotética de aptitud.

1. ¿Qué porcentaje de la varianza justifica una correlación de .7 entre las variables X y Y en un estudio de validez de predicción?

- a) 7%
- b) 70%
- c) .7%
- d) 49%
- e) 25%

2. o es a O como x es a...

- a) /
- b) %
- c) X
- d) Y

Al menos de forma aparente, el reactivo 1 parece más dependiente de las experiencias del aprendizaje formal que el reactivo 2. La respuesta correcta al reactivo 1 depende de la familiaridad con el concepto de correlación y del conocimiento de que la varianza justificada por un coeficiente de correlación es igual al cuadrado del coeficiente (en este caso, $.72^2$ o $.49$, la opción *d*). La respuesta correcta al reactivo 2 requiere de la experiencia con el concepto de tamaño así como de la capacidad para comprender el concepto de analogías. Las habilidades del segundo reactivo tienden a ser recolectadas de las experiencias de la vida (observe con qué rapidez determinó que la respuesta correcta es la opción *c*).

También debe tener en cuenta que la denominación *rendimiento* o *aptitud* para una prueba depende totalmente del *uso* que se pretende dar a ésta y no sólo del tipo de reactivos que contiene.

SÓLO PIENSE...

Realice un reactivo para una prueba de aptitud que obligue a los evaluados a recurrir a la experiencia de la vida en vez de al aprendizaje en el salón de clases para responderlo.

Es posible que dos pruebas contengan algunos reactivos iguales y que una de ellas sea llamada prueba de aptitud, mientras que a la otra se le denomine prueba de rendimiento. Aunque seleccionamos un reactivo con una analogía no verbal para representar un reactivo de una prueba de aptitud, bien podría haber sido un reactivo de una prueba de rendimiento —un reactivo administrado para probar el conocimiento adquirido, por ejemplo, en un seminario o a través de un pensamiento conceptual—. De modo similar, el primer reactivo, presentado como un reactivo ilustrativo de una prueba de rendimiento, bien podría ser utilizado para evaluar la

aptitud (por ejemplo, en estadística o en psicología) si se incluyera en una prueba que no haya sido diseñada en forma expresa para medir el rendimiento en esta área.

Las pruebas de aptitud, también denominadas como **pruebas de pronóstico**, son generalmente usadas para hacer predicciones. Algunas pruebas de aptitud se han usado para medir la disposición:

- para entrar a la escuela primaria
- para completar de manera exitosa un curso específico en secundaria
- para hacer un trabajo de nivel universitario
- para hacer un trabajo a nivel de postgrado, incluyendo un curso de estudio en una escuela profesional o de comercio

Las pruebas de rendimiento también pueden utilizarse para propósitos de predicción. Por ejemplo, un individuo que se desempeñe bien en una prueba de rendimiento sobre un idioma extranjero realizada para primer semestre podría considerarse un buen candidato para el trabajo del segundo semestre. La suposición que opera aquí es que debido a que el individuo fue capaz de dominar ciertas habilidades básicas, será capaz de dominar habilidades más avanzadas. Cuando esos supuestos son eficaces, las pruebas de rendimiento, al igual que los reactivos de las pruebas que se enlazan con el rendimiento, son utilizados de manera análoga a las pruebas de aptitud.

De manera típica, cuando las medidas de las pruebas de rendimiento se usan para hacer predicciones, las medidas tienden a deducir experiencias de aprendizaje más formales y más limitadas que las pruebas de aptitud. Por ejemplo, una medida de rendimiento en un curso nombrado Francés conversacional básico puede usarse como una medida que prediga el rendimiento para un curso titulado Francés conversacional avanzado. Las pruebas de aptitud tienden a derivar un fundamento más amplio de información y habilidades y pueden ser utilizadas para predecir una variedad más amplia de variables.

En las siguientes secciones estudiaremos algunas pruebas de aptitud usadas en las escuelas desde el nivel de ingreso hasta el de licenciatura y en instituciones profesionales. Observe que en el nivel de ingreso, “una regla no escrita” conocida para evaluaciones profesionales es para refe-

irse por otro nombre a lo que de manera esencial es una prueba de aptitud: una **prueba de disposición**. Quizá esto se deba a que el propósito principal de estas pruebas es evaluar la disposición del niño para el aprendizaje. Sin embargo, conforme aumenta el nivel de educación, el término *disposición* es abandonado en favor del término *aptitud*, aunque la disposición sigue teniendo mucha importancia en todos los niveles. Así, por ejemplo, el Examen de registro para graduados (*Graduate Record Examination*, GRE), aplicado en la universidad y que se usa para pronosticar la capacidad para hacer trabajos a nivel de postgrado, podría haber sido llamado “Examen de disposición para la escuela de postgrado”.

El nivel de educación básica

La edad en la que por decreto un niño debe entrar a la escuela varía de un país a otro. No obstante, de manera individual puede variar en forma amplia la disposición de los niños de la misma edad cronológica para separarse de sus padres y comenzar su aprendizaje académico. Los niños que ingresan en el sistema educativo provienen de una amplia gama de orígenes y experiencias, y sus índices de desarrollo fisiológico, psicológico y social también varían en forma amplia. Las pruebas de disposición escolar proporcionan a los educadores un criterio con el que pueden evaluar las capacidades de los alumnos en áreas tan diversas como información general y habilidades sensorio-motorices. Uno de los muchos instrumentos diseñados para evaluar la disposición y aptitud de los niños para la educación formal son las Pruebas metropolitanas de disposición (*Metropolitan Readiness Tests*, MRT).

SÓLO PIENSE...

Más allá de medir la disposición para participar en la educación superior, pruebas como el SAT y la GRE han sido elogiadas como “niveladores” que “emparejan el campo de juego”. Las calificaciones de estas pruebas no toman en cuenta en absoluto de qué escuela proviene el individuo ni qué grados alcanzó ahí. ¿Está de acuerdo en que estas pruebas ayudan a “emparejar el área de juego” para los evaluados?

Tabla 10-1
Las pruebas metropolitanas de disposición

Nivel I

- Memoria auditiva:* Se presentan cuatro ilustraciones que contienen objetos familiares. El examinador lee en voz alta varias palabras. El niño debe seleccionar la ilustración que corresponda a la misma secuencia de palabras que fueron presentadas en forma oral.
- Rima:* El examinador suministra los nombres de cada una de las ilustraciones presentadas y luego proporciona una quinta palabra que rima con una de ellas. El niño debe seleccionar la ilustración que rime con la palabra dada por el examinador.
- Reconocimiento de letras:* El examinador nombra diferentes letras y el niño debe identificar cada una de las series presentada en el folleto de la prueba.
- Correspondencia visual:* Se presenta una muestra y el niño debe seleccionar la opción que corresponda con la muestra.
- Lenguaje escolar y atención:* El examinador lee una oración y el niño debe seleccionar la ilustración que describe lo que se ha leído. La tarea implica hacer algunas inferencias y percatare de la relevancia del detalle.
- Lenguaje cuantitativo:* Se evalúan la comprensión de términos cuantitativos y el conocimiento de números ordinales y operaciones matemáticas simples.

Nivel II

- Consonantes al comienzo:* En el folleto de la prueba se presentan cuatro ilustraciones representando objetos familiares y son nombrados por el examinador. Éste suministra luego una quinta palabra (no presentada) y el niño debe seleccionar la ilustración que comience con el mismo sonido.
- Correspondencia entre sonido y letra:* Se presenta una ilustración seguida por una serie de letras. El examinador nombra la ilustración y el niño selecciona la opción que corresponde con el sonido inicial del reactivo ilustrado.
- Correspondencia Visual:* Como en la prueba correspondiente al nivel I, se presenta un modelo y el niño debe seleccionar la opción que corresponda con el modelo.
- Encontrar patrones:* Se presenta un estímulo consistente en varios símbolos seguido por una serie de opciones representativas. El niño debe seleccionar la opción que contenga la misma secuencia de símbolos, aun cuando estén presentados en un agrupamiento mayor con más distracciones.
- Lenguaje escolar:* Como en la prueba de lenguaje escolar y atención del nivel I, el niño debe seleccionar la ilustración que corresponda con una oración presentada en forma oral.
- Atención:* El material se presenta en forma oral, y el niño debe seleccionar la ilustración que refleje su comprensión de la herramienta, y extraer conclusiones acerca del estímulo material.

Conceptos cuantitativos	}	Ambas son pruebas opcionales que, como la de lenguaje cuantitativo del nivel I, evalúan la comprensión de conceptos y operaciones matemáticas básicos.
Operaciones cuantitativas		

Pruebas metropolitanas de disposición (MRT) Las MRT son una batería aplicada en forma colectiva que evalúa el desarrollo de habilidades para la lectura y las matemáticas, importantes en las primeras etapas del aprendizaje escolar formal. La prueba está dividida en dos niveles: el Nivel I, para ser usada con alumnos principiantes e intermedios de jardín de niños, y el Nivel II, que abarca desde el final del jardín de niños hasta el primer grado (tabla 10-1). Hay dos formas de la prueba para cada nivel. Las pruebas se aplican en varias sesiones en forma oral y no tienen límite de tiempo, aunque generalmente requieren de aproximadamente 90 minutos para su aplicación. Una prueba de práctica (especialmente útil con pequeños que han tenido una experiencia mínima o que no han tenido ninguna experiencia previa respondiendo pruebas) puede ser aplicada varios días antes de la prueba real para ayudar a los niños a familiarizarse con los procedimientos y el formato implicados en la aplicación de esta prueba.

Los datos normativos para la edición actual de la MRT se basan en una muestra nacional de aproximadamente treinta mil niños. La muestra de estandarización fue estratificada de acuerdo con regiones geográficas, factores socioeconómicos, experiencia escolar previa y orígenes étnicos. Los datos se obtuvieron de escuelas públicas y religiosas, así como de escuelas grandes y pequeñas. Los coeficientes de confiabilidad divididos en mitades para ambas formas en los dos niveles de la MRT, al igual que las medidas de consistencia interna de Kuder-Richardson estuvieron en un rango alto aceptable. La validez de contenido fue desarrollada por medio de una revisión extensa de la literatura, del análisis de las habilidades relacionadas en el proceso de lectura y de la elaboración de reactivos para la prueba que reflejaran esas habilidades. Los reactivos fueron revisados por asesores de minorías en un intento por reducir, si no es que eliminar, cualquier sesgo étnico potencial. La validez de predicción de las puntuaciones MRT ha sido examinada con referencia a los más recientes índices de rendimiento escolar y los coeficientes de validez obtenidos han sido altos en un nivel aceptable.

El nivel de educación media

Quizá el ejemplo más evidente de una prueba de aptitud usada ampliamente en las escuelas en el nivel de enseñanza media es el SAT, la cual a partir de 1993 se conoce con el nombre de “Prueba de aptitudes escolares” (SAT, por sus siglas en inglés). La prueba no sólo ha sido de valor en el proceso de selección para la universidad, sino también como auxiliar para la orientación vocacional a nivel bachillerato y para los consejeros en colocación de empleos con el fin de asesorar a los estudiantes sobre aquellas actividades y desempeños que podrían ser los más adecuados para ellos. Además del SAT, la evaluación ACT (*American College Testing*, anteriormente conocido como Programa estadounidense de pruebas universitarias) sirve para propósitos similares.

¿Cuánto dependen en realidad las universidades de criterios como las calificaciones del SAT o de la ACT para tomar decisiones de admisión? Es probable que menos de lo que la mayoría de las personas cree. Las instituciones de educación superior en Estados Unidos difieren en forma amplia respecto a sus criterios de admisión. Incluso entre las escuelas que requieren de las calificaciones obtenidas en el SAT o la ACT, se acordaron diferentes grados de importancia para la información obtenida a través de las pruebas respecto a las decisiones de admisión. Las instituciones muy selectivas pueden admitir grandes cantidades de estudiantes con calificaciones inferiores en la prueba y rechazar grandes cantidades de estudiantes con calificaciones altas. Con este preámbulo, describiremos en forma breve la evaluación SAT y la ACT.

La Prueba de aptitud escolar (SAT) Esta prueba, cuyo nombre en inglés es Scholastic Assessment Test (SAT), fue introducida por primera vez como un examen objetivo en 1926. Hasta 1995, el SAT era una prueba de tres horas dividida en dos partes: Verbal y Matemática. La parte Verbal consistía en secciones que incluían Analogías, Comprensión de la lectura, Antónimos y Completar oraciones. La sección Comprensión de la lectura consistía en leer pasajes con un gran contenido de material temático en una variedad de áreas académicas tales como ciencias, estudios sociales y humanidades. La sección Completar oraciones consistía en frases o párrafos individuales en los que se habían omitido una o dos palabras, y la tarea del examinado era seleccionar la opción que mejor completara la idea expresada. El conocimiento de vocabulario era medido por el desempeño en los reactivos de Antónimos y Analogías.

En 1974 fue introducida por primera vez una Prueba de escritura de inglés intermedio para evaluar la capacidad del estudiante para comprender el tipo de lenguaje utilizado en la mayor parte de los libros de texto universitarios. Consistía de 50 preguntas de opción múltiple y requería de 30 minutos para completarla. La calificación de comprensión de la lectura también se calculaba con base en las secciones de completar oraciones y comprensión de la lectura. La sección de Matemáticas del SAT evaluaba la comprensión y aplicación de principios matemáticos, así como la capacidad de razonamiento numérico. El contenido de las preguntas en esta sección suponía algún conocimiento de las operaciones aritméticas básicas como adición, sustracción, multiplicación, división, promedios, porcentajes, números enteros pares y impares, así como conceptos geométricos y algebraicos, incluyendo ecuaciones lineales y cuadráticas, exponentes y factorización.

Los cambios principales en el formato del SAT y la base normativa fueron establecidos a principios de la década de 1990. Los cambios del formato fueron diseñados para hacer la prueba más “relevante en términos educativos” respecto a su objetivo de predecir el desempeño en la universidad (Moses, 1991). De manera esencial, el cambio de formato implicó una dicotomización del SAT en dos componentes principales y el renombrar los componentes de la prueba. El SAT I (razonamiento) era una prueba de tres horas que medía las habilidades verbales y matemáticas. El SAT II (pruebas sobre temas específicos) era una prueba de una hora de duración que medía el conocimiento en un área sobre un tema en particular y la habilidad del evaluado para aplicar ese conocimiento. Las pruebas sobre temas específicos se relacionan de manera más directa con el trabajo de un curso de bachillerato y se enfocan en áreas con varios temas como historia mundial, biología y química.

Los reactivos de prueba para el SAT son elaborados por expertos en el campo y probados previamente en muestras nacionales durante el examen real. Los reactivos experimentales son colocados por separado en secciones cronometradas del examen. Dicho procedimiento de hacer una prueba previa en una muestra de examinados que son representativos del grupo que adoptará las formas futuras de la prueba proporciona a sus creadores información útil respecto al valor de los reactivos propuestos. Las respuestas de los estudiantes son analizadas estadísticamente para determinar el porcentaje que respondió en forma correcta cada pregunta, el porcentaje que escogió cada uno de los reactivos distractores y el porcentaje que omitió el reactivo. Se calcula un índice de la respuesta para cada reactivo con la calificación total en la prueba (es decir, una clasificación de la dificultad en cada reactivo). La prueba se somete a una revisión continua y el tiempo total para elaborar un reactivo puede rebasar los 18 meses.

La calidad técnica del SAT es buena. La confiabilidad de las formas recientes de la prueba medida por estimaciones de consistencia interna ha dado como resultado coeficientes de confiabilidad en un rango de .90 para las escalas Verbal y de Matemáticas. La investigación concerniente a la validez del SAT se ha enfocado de manera principal en las correlaciones entre las calificaciones obtenidas en la prueba y el grado universitario, o en una combinación de las calificaciones del SAT y el grado de bachillerato con los grados universitarios. En general, se ha encontrado que los grados del bachillerato se correlacionan más con los grados universitarios que las calificaciones del SAT. Cuando se combinan las calificaciones del SAT y el promedio de calificación del bachillerato, se incrementa la correlación con el desempeño universitario. Por ejemplo, en un estudio, las calificaciones en el primer año de universidad se correlacionaron en .20 con las puntuaciones del SAT y en .30 con la posición del estudiante en cuanto a desempeño y calificaciones comparado con su grupo de bachillerato. Juntas, las puntuaciones del SAT y la posición en la clase de bachillerato se correlacionaron en .34 con las calificaciones universitarias, explicando 11.3% de la varianza en las calificaciones universitarias (Baron y Norman, 1992). Las correlaciones entre las partes Verbal y de Matemáticas del SAT han estado en el punto superior de .60, un hallazgo que sugiere que la superposición de habilidades, probablemente de naturaleza verbal, enlaza ambas partes del examen.

Cuando el SAT fue estandarizado en 1941, el desempeño promedio se reflejó en una puntuación de 500. Desde 1941, las calificaciones de cada año del SAT han disminuido, de modo que el promedio de los evaluados en 1993 recibió una calificación verbal del SAT de 424 y una calificación de 478 en matemáticas. Debido a que las normas se mantuvieron ancladas, las puntuaciones conservaron el mismo significado en 1993 como lo tenían en 1941. Es decir, una calificación de 500 en 1993 significa que el evaluado se desempeñó en el nivel promedio de los examinados en 1941. Esto hizo posible la comparación con los estudiantes que han respondido la prueba durante diferentes años. Un cambio similar ocurrió en las calificaciones de la GRE (véase *Psicometría cotidiana* del capítulo 4).

En abril de 1995, las normas del SAT fueron ajustadas, de modo que una puntuación de 500 indicara un desempeño promedio entre los evaluados en 1995. A los usuarios de las pruebas, al igual que a los oficiales encargados de las admisiones a universidades, se les proporcionaron tablas para convertir las viejas puntuaciones del SAT (basadas en las normas de 1941) en las puntuaciones basadas en las normas de 1995 con propósitos de comparación (Q y A, 1994). A menos que ocurra un reajuste en la interinidad, una calificación del SAT de 500 indica un nivel promedio de desempeño relativo al desempeño perpetuado de la gente que respondió la prueba en 1995.

El SAT se aplica varias veces al año bajo condiciones controladas en forma meticulosa a todo lo largo de Estados Unidos y en otros países. Hay ediciones disponibles de la prueba en idiomas extranjeros, al igual que ediciones especiales para estudiantes con discapacidades. Una forma especial, la “Prueba preliminar de aptitud escolar” (*Preliminary Scholastic Aptitude Test*, PSAT), está disponible para su aplicación como examen de práctica y herramienta para orientadores. Debido a que la PSAT es copatrocinada por la Corporación de Becas al Mérito Nacional (National Merit Scholarship Corporation), ahora se le conoce de manera formal como el “SAT Preliminar/Nacional calificadora para becas al mérito nacional” (Preliminary SAT/National Merit Scholarship Qualifying Test, PSAT/NMSQT). El hecho de aceptar esta prueba hace a los estudiantes elegibles para las becas al Mérito Nacional. Otras razones por las que los estudiantes presentan la PSAT/NMSQT incluyen obtener un reaprovechamiento de la información sobre las habilidades que requerirán para el SAT y para ver cómo se comparan sus puntuaciones con la de otros estudiantes que son evaluados con la misma prueba.

Tanto la PSAT como el SAT han experimentado cambios recientes en un esfuerzo por alinear mejor la prueba al plan de estudios y las prácticas del bachillerato contemporáneo. Se le hicieron cambios a la PSAT en el otoño del 2004, y al SAT en la primavera del 2005. Se agregó una nueva sección de redacción, la cual incluía preguntas de opción múltiple sobre gramática y uso del idioma, así como un ensayo para estudiantes. En la sección de Lectura crítica, (llamada de manera formal Verbal), se han eliminado los reactivos de analogías y se han agregado fragmentos cortos de lecturas a pasajes largos. En la sección de matemáticas, se han eliminado las comparaciones cuantitativas y el contenido ha sido ampliado para incluir temas de matemáticas de tercer año de preparatoria. En general, lo que es medido por el SAT en su versión revisada está más orientado al rendimiento; es decir, el contenido de la prueba ha cambiado para estar en línea con lo que los estudiantes esperan aprender de la instrucción formal en el salón de clases. Un importante competidor del SAT, la evaluación ACT, ha estado desde un principio más orientada al rendimiento.

La evaluación ACT (ACT) Conocida comúnmente por sus tres siglas iniciales (*la A-C-T*) fue desarrollada en la Universidad de Iowa. Este tipo de prueba era utilizada para el ingreso a la universidad y es

el resultado de la unificación de las Pruebas de desarrollo educativo de Iowa. La prueba se apoya en el plan de estudios, con preguntas basadas de manera directa en las típicas enseñanzas escolares de inglés, ciencias y matemáticas; está dividida en cuatro secciones: escritura, lectura, matemáticas y razonamiento científico. Además, existe una medida diseñada para explorar las áreas de interés del evaluado. Las calificaciones se calculan en cada una de las cuatro pruebas y el promedio, redondeado al número entero más cercano, es la prueba compuesta. El tiempo real para su aplicación es de tres horas aproximadamente, aunque la sesión de manera característica dura tres horas y media incluyendo descansos. Todas las universidades de Estados Unidos aceptan los resultados de la ACT como válidos.

SÓLO PIENSE...

Una prueba compuesta ACT, muy parecida a las otras calificaciones de pruebas que se examinan en este libro, puede considerarse como una escala de calificaciones en vez de un punto preciso en el universo de calificaciones posibles. Explique por qué es cierta esta aseveración con referencia al error estándar de medición.

El nivel universitario y más allá

Si usted es un estudiante universitario que planea continuar sus estudios después de su graduación, es probable que esté familiarizado con las siglas G, R y E (que juntas forman el acrónimo que está muy presente en la mente de los estudiantes a punto de graduarse).

Examen de registro para graduados (*Graduate Record Examination*, GRE) Este antiguo rito de admisión para los estudiantes que desean ser aceptados en un postgrado se presenta en forma de Prueba

general al igual que como prueba sobre temas específicos. La Prueba general contiene secciones verbales y cuantitativas además de secciones de redacción analítica. Las subpruebas verbales miden, entre otras cosas, la habilidad para reconocer relaciones entre conceptos. Las subpruebas cuantitativas miden, entre otras cosas, el conocimiento de conceptos matemáticos básicos y la habilidad para razonar de manera cuantitativa. Las subpruebas de redacción analítica miden, entre otras cosas, la habilidad para articular y argumentar ideas de manera efectiva en un inglés estándar escrito, así como pensamiento crítico. La Prueba general puede ser resuelta utilizando lápiz y papel o puede resolverse por computadora en un centro de pruebas. Si el examen se responde por computadora, los evaluados utilizan un “procesador elemental de palabras” proporcionado por el creador de la prueba, para evitar que las personas familiarizadas con uno u otro programa de procesamiento de palabras tengan alguna ventaja. Los ensayos escritos por los evaluados pueden mandarse de manera íntegra a las instituciones para graduados y recibirán reportes de la prueba GRE.

Quizá debido a la potencialmente trascendental importancia de los resultados de la prueba GRE, un gran número de investigadores independientes han examinado de manera crítica la prueba en relación con algunas variables psicométricas. Un meta-análisis amplio de la literatura relevante se centra en el uso de la GRE junto con la calificación promedio de los no graduados como un instrumento para predecir del éxito del graduado. Los investigadores concluyeron que la GRE podía predecir de manera válida varios criterios importantes (desde el promedio de calificación del graduado hasta la clasificación del profesorado) en las diferentes disciplinas (Kuncel *et al.*, 2001).

La experiencia nos dice que muchos lectores de este libro tienen un interés enfocado en una prueba sobre un tema específico de la GRE: la psicología. Una pregunta común es: “¿Cómo me preparo para la prueba?”. He aquí un programa de preparación de tres pasos que usted puede considerar:

- **Paso 1:** Visite el sitio oficial web de la GRE en <http://www.gre.org>. Primero seleccione la opción *Subject Tests* y luego *Psicología*. Utilice esta fuente para conseguir toda la información que pueda sobre la forma actual de la prueba, incluso una muestra práctica de la misma.
- **Paso 2:** Desempolve su libro de texto de introducción a la psicología y reléalo; repáselo, haga lo necesario para aprenderlo de nuevo. Si por alguna razón ya no tiene ese libro de texto, o si hace ya muchos años que tomó una introducción a la psicología, pídale a su instructor que le recomiende un texto actual que le facilite un repaso comprensible en ese campo. Después, léalo con atención de principio a fin.
- **Paso 3:** Muchos estudiantes tienen un buen concepto de muchos libros comerciales de repaso que se encuentran disponibles. De manera característica, estos libros contienen una cierta cantidad de muestras de pruebas que pueden ser muy útiles para señalar las áreas que requieren de mayor estudio. Dos libros de repaso que tal vez desee consultar son *Cracking the GRE Psychology*, (Jay, 2002) y *Graduate Record Examination Psychology* (Raphael y Halpert, 1999).

Después de que haya hecho su mayor esfuerzo en el estudio para presentar la prueba, sepa que el autor de este libro le desea la mejor de las suertes. O, en términos psicológicos y psicométricos, que el contenido mostrado en la prueba corresponda con el contenido de lo que ha aprendido en su preparación para ella, y que la información sea de fácil acceso.

La prueba de analogías de Miller (*Miller Analogies Test*, MAT) Otro examen usado de manera amplia es la prueba de analogías de Miller. Ésta es una prueba de analogías con 100 reactivos de opción múltiple que no sólo recurre a la capacidad del examinado para percibir relaciones sino también a la inteligencia en general, al vocabulario y al aprendizaje académico. Como ejemplo, complete la siguiente analogía:

Condicionamiento clásico es a Pavlov, como condicionamiento operante es a

- a) Freud
- b) Rogers
- c) Skinner
- d) Jung
- e) Westheimer

La respuesta correcta a este reactivo no sólo demanda capacidad para entender la relación entre el condicionamiento clásico y Pavlov sino también saber que es B. F. Skinner (opción c de la lista de nombres) quien se asocia correctamente con el condicionamiento operante.

Otras pruebas de aptitud Los solicitantes a ser capacitados en ciertas profesiones y ocupaciones quizá requieran presentar exámenes de admisión especializados, (véase la tabla 10-2). Por ejemplo, los estudiantes interesados en hacer una carrera en medicina, incluyendo podiatría y osteopatía, deberán presentar la Prueba de admisión al Colegio de Medicina (*Medical College Admission Test*, MCAT). Una considerable cantidad de desgaste entre estudiantes de medicina en la década de 1920 fue el estímulo para desarrollar esta prueba en 1928. Desde ese momento, la prueba ha pasado por muchas revisiones. Las distintas versiones “demuestran que la definición de aptitud hacia la educación médica refleja las costumbres y valores profesionales y sociales de la época” (McGaghie, 2002, p. 1085). En su forma actual, la MCAT consta de cuatro secciones: Razonamiento verbal, Ciencias físicas, Muestra de escritura y Ciencias biológicas.

Se han elaborado numerosas pruebas para evaluar tipos específicos de aptitudes académicas y/o ocupacionales. Algunas de las pruebas usadas con mayor frecuencia se describen en forma breve en la tabla 10-2. También existen varias pruebas de aptitud menos conocidas (y usadas con menor frecuencia). Por ejemplo, las Medidas de talentos musicales de Seashore (Seashore, 1938)

SÓLO PIENSE...

Un verdadero artista “excéntrico” (por falta de un mejor término) toma la subprueba Imágenes, del Inventario de aptitud artística de Horn, como un requisito de admisión para la escuela de arte. Simon, el oficial de admisión de la escuela, encuentra las producciones del evaluado “fuera de la norma” y muy abstractas pues están más allá de su comprensión. ¿Este artista tiene aptitud para el arte?

es una medición clásica de aptitud musical aplicada con la ayuda de una grabación o cinta pregrabada. Las seis subpruebas miden aspectos específicos del talento musical (por ejemplo, comparar diferentes notas y ritmos en variables como volumen, tono, compás y timbre). El Inventario de aptitud artística de Horn (*Horn Art Aptitude Inventory*) es una medida de aptitud artística que se divide en dos secciones. La sección Garabatos y bocetos contiene reactivos diseñados para medir variables como claridad de pensamiento y originalidad. Los reactivos en la sección Imágenes contienen líneas clave o “bocetos” de obras maestras de arte para ser incorporados en la producción artística del examinado. Las categorías para calificar la sección Imágenes incluyen Diseño, Imaginación y Ámbito de intereses.

Pruebas de diagnóstico

A principios del siglo XX, se reconoció que las pruebas de inteligencia podrían usarse para otros propósitos, además de medir la habilidad cognoscitiva. Binet y Simon (1908) escribieron acerca de su concepto de “ortopedia mental”, según el cual los datos de las pruebas de inteligencia podrían utilizarse para mejorar el aprendizaje. En la actualidad hay una distinción entre las pruebas y los datos arrojados por éstas y que se usan con propósitos *evaluativos* así como las pruebas y los datos arrojados por éstas y que se usan principalmente con propósitos de *diagnóstico*. El término **evaluativo**, usado en frases como *propósitos evaluativos* o *información evaluativa* de manera característica se aplica a pruebas o datos arrojados por éstas y utilizados para tomar decisiones (como aprobado/reprobado y admitido/rechazado). Por el contrario, el término **diagnóstico**, usado en contextos educativos y frases como *propósitos diagnósticos* o *información diagnóstica* es típico que se aplique a pruebas o datos obtenidos a través de éstas para indicar alguna dificultad de un estudiante, por lo general con propósitos de solucionarla o trabajar con ella.

Una prueba de diagnóstico de lectura, por ejemplo, contiene varias subpruebas. Cada una está diseñada para analizar un conocimiento específico o una habilidad requerida para la lectura y para resolver problemas específicos, si es que existen, con el propósito de que el evaluado adquiera un nivel de lectura apropiado. Por cierto, la información diagnóstica también puede usarse con propósitos evaluativos. Con base en el desempeño de un niño en una prueba de diagnóstico de lectura, por ejemplo, un profesor o un administrador de pruebas pueden tomar una decisión acerca de colocarlo en una clase específica. Asimismo, una prueba de diagnóstico no necesariamente proporciona información que responda a preguntas relacionadas con *por qué* existe una

Tabla 10-2
Algunas pruebas de admisión para capacitación profesional y ocupacional

Examen de admisión y sitios web para obtener más información	Descripción breve
Prueba de admisión a la Facultad de Medicina (Medical College Admission Test- MCAT) www.aamc.org	Diseñada para evaluar la solución de problemas, el pensamiento crítico, y las habilidades de redacción, así como el conocimiento de conceptos científicos requeridos para el estudio de medicina.
Prueba de admisión a la Facultad de Leyes (Law School Admission Test-LSAT) www.lsac.org	Una medida estandarizada de las habilidades adquiridas de lectura y de razonamiento verbal. Incluye medidas de comprensión de lectura, razonamiento analítico y lógico, así como una muestra de redacción.
Prueba de admisión a la Facultad de Veterinaria (Veterinary College Admission Test-VCAT) www.tpcweb.com (siga los enlaces)	Evalúa 5 áreas de contenido: biología, química, habilidad verbal, habilidad cuantitativa y comprensión de lectura.
Prueba de admisión a la Facultad de Odontología (Dental Admission Test-DAT) www.ada.org	Efectuada por la Asociación Dental Estadounidense (DAT), esta prueba puede aplicarse por computadora casi en cualquier día del año. Incluye cuatro secciones: Ciencias naturales (biología, química general, química orgánica), Habilidad perceptiva (incluye tareas de discriminación de ángulos), Comprensión de lectura y Razonamiento cuantitativo (incluyendo álgebra, varias conversiones, probabilidad y estadística, geometría, trigonometría y matemáticas aplicadas).
Prueba de admisión a la Facultad de Farmacología (Pharmacy College Admission Test-PCAT) http://marketplace.psychorp.com (siga los enlaces)	Contiene cinco subpruebas: Verbal (incluyendo vocabulario con analogías y antónimos), Cuantitativa (aritmética, fracciones, decimales, porcentajes, álgebra y razonamiento), Biología, Química (orgánica básica e inorgánica), Comprensión de lectura (analizar e interpretar pasajes).
Prueba de admisión a la Facultad de Optometría (Optometry Admission Test-OAT) www.opted.org	Contiene cuatro subpruebas: Ciencias naturales (incluyendo el conocimiento sobre biología, química general y química orgánica), Comprensión de lectura, Física y Razonamiento cuantitativo.
Prueba de admisión a la Facultad de Ciencias de la Salud (Allied Health Professions Admission Test-AHPAT) www.tpcweb.com (siga los enlaces)	Evalúa la habilidad en cinco áreas de contenido: biología, química, habilidad verbal, habilidad cuantitativa y comprensión de lectura. Diseñada para aplicarse con aspirantes a terapeutas físicos y ocupacionales, asistentes médicos, y otros miembros de profesiones relacionadas con la salud.
Examen para la admisión de la Escuela de Enfermería (Entrance Examination for Schools of Nursing-RNEE) www.tpcweb.com (siga los enlaces)	Elegida por los autores de este libro como la "prueba con el acrónimo más ingenioso", la RNEE evalúa la habilidad en cinco áreas de contenido: ciencias físicas, habilidad numérica, ciencias de la vida, habilidad verbal y comprensión de lectura.
Prueba de admisión a la Facultad de Contaduría (Accounting Program Admission Test-APAT) www.tpcweb.com (siga los enlaces)	Mide el rendimiento del estudiante en contaduría elemental mediante 75 preguntas de opción múltiple, 60% de las cuales están relacionadas con contaduría financiera, y el restante 40%, con contaduría gerencial.
Prueba de admisión a la Escuela de Graduados en Administración (Graduate Management Admission Test) www.mba.com	Mide habilidades verbales básicas, matemáticas y de redacción analítica, mediante tres subpruebas: Evaluación escrita analítica, la sección Cuantitativa y la sección Verbal.

dificultad para el aprendizaje. Se necesitan otros exámenes educativos, psicológicos y quizá médicos para responder a esa pregunta. En general, las pruebas de diagnóstico se administran a los estudiantes que han demostrado tener un problema en un área sobre un tema específico obteniendo un bajo desempeño ya sea en el salón de clases o en alguna prueba de aprovechamiento. Por tanto, es comprensible que las pruebas de diagnóstico tiendan a contener reactivos más simples que las pruebas de rendimiento, diseñadas para ser usadas con miembros del mismo grado.

Pruebas de lectura

La capacidad para leer prácticamente es integral para casi todo el aprendizaje en el salón de clases, así, no sorprende que se disponga de muchas pruebas de diagnóstico para ayudar a de-

terminar con precisión las dificultades en la adquisición de esta habilidad. Algunas de las muchas pruebas disponibles para determinar con precisión las dificultades para la lectura incluyen la Prueba de diagnóstico de lectura de Stanford (*Stanford Diagnostic Reading Test*), las Pruebas metropolitanas de instrucción de lectura (*Metropolitan Reading Instructional Tests*), las Escalas de diagnóstico de lectura (*Diagnostic Reading Scales*) y la Prueba de análisis de la lectura de Durrell (*Durrell Analysis of Reading Test*). Con propósitos ilustrativos describimos en forma breve una de estas baterías de diagnóstico, las Pruebas de dominio de la lectura de Woodcock (*Woodcock Reading Mastery Tests*).

Las pruebas revisadas de dominio de la lectura de Woodcock (WRMT-R) Esta batería de pruebas es adecuada para niños de cinco años en adelante y para adultos de 75 años de edad y mayores. En resumen, parece ser una de esas pruebas que se caracterizan por estar dirigidas a *todo público*. A continuación se incluye una lista de subpruebas de las pruebas así como una breve descripción de los tipos de tareas en cada una:

Identificación de letras. Esta subprueba contiene reactivos que miden la capacidad para nombrar letras presentadas en formas diferentes. Se presentan letras cursivas o manuscritas y mayúsculas o minúsculas.

Identificación de palabras. Esta subprueba consiste en palabras aisladas acomodadas en orden creciente de dificultad. Se le pide al estudiante que lea cada palabra en voz alta.

Ataque de palabras. Esta subprueba consiste en sílabas sin sentido que incorporan habilidades de análisis fonético al igual que estructural. Al estudiante se le pide que pronuncie cada sílaba sin sentido.

Comprensión de palabras. Esta subprueba consiste en reactivos que evalúan el significado de las palabras usando un formato de analogía en cuatro partes.

Comprensión de pasajes. Esta subprueba consiste en frases, oraciones o párrafos cortos en los que falta una palabra y se leen en silencio. El estudiante debe agregar la palabra faltante.

Las pruebas se aplican en forma individual y están diseñadas para medir habilidades inherentes a la lectura. Las pruebas se presentan en dos formas denominadas *G* y *H*, y cada forma contiene las cinco subpruebas enumeradas antes. La forma *G* también contiene una prueba llamada Aprendizaje visual auditivo. Una cinta grabada es incluida con las pruebas y sirve como guía para la pronunciación apropiada de los reactivos de ataque de palabras y de identificación de palabras.

Las calificaciones de prueba pueden combinarse para formar lo que se conoce como grupos; grupo de Disposición (las pruebas de Aprendizaje visual auditivo y de identificación de letras), grupo de habilidades básicas (las pruebas de identificación de palabras y de ataque de palabras), grupo de comprensión de la lectura (las pruebas de comprensión de palabras y comprensión de pasajes), un grupo de escala completa de lectura total (las pruebas de identificación de palabras, ataque de palabras, comprensión de palabras y comprensión de pasajes) y un grupo de escala corta de lectura total (las pruebas de identificación de palabras y comprensión de pasajes). Cada conjunto de pruebas por lo general toma de 10 a 30 minutos en ser administrada. La última escala puede usarse para una exploración rápida y toma alrededor de 15 minutos para administrarse. Un programa de cómputo también está disponible para la conversión de calificaciones y el almacenamiento de las calificaciones previas y posteriores a la prueba.

El manual de la prueba para la WRMT-R sugiere que la prueba mide dos factores respecto a la lectura: habilidades básicas y comprensión de lectura. La investigación de factores analíticos efectuada por investigadores independientes fue incapaz de confirmar esta estructura de dos factores. En vez de ello, un análisis factorial sugirió que la WRMT-R medía sólo un factor de “lectura total”, como lo refleja la puntuación de la escala completa en la prueba.

Pruebas de matemáticas

La Prueba de diagnóstico de matemáticas de Stanford (*Stanford Diagnostic Mathematics Test*), las Pruebas metropolitanas de instrucción de matemáticas (*Metropolitan Mathematics Instructional*

tests), el Inventario diagnóstico de matemáticas (*Diagnostic Mathematics Inventory*) y la KeyMath revisada: un inventario diagnóstico de matemáticas esenciales (*KeyMath Revised: A Diagnostic Inventory of Essential Mathematics*) ejemplifican algunas de las muchas pruebas que se han elaborado para ayudar a diagnosticar dificultades en torno a los conceptos aritméticos y matemáticos. Los reactivos en dichas pruebas generalmente analizan las habilidades y el conocimiento necesarios para separar las partes de las operaciones matemáticas. La prueba “KeyMath revisada”, por ejemplo, contiene 13 subpruebas diseñadas para evaluar áreas como conceptos básicos (incluyendo conocimiento de símbolos, números y fracciones), operaciones (incluyendo la habilidad en adición, sustracción, multiplicación, división y cálculo mental) y aplicaciones (problemas numéricos empleando variables como dinero y tiempo).

La información de diagnóstico se obtiene de una valoración del desempeño del examinado en las diversas áreas, subpruebas y reactivos. Las calificaciones totales de la prueba son convertidas a grados equivalentes. El desempeño en el área puede convertirse en un patrón general de desempeño matemático y el resultado de la subprueba puede traducirse en un perfil que ilustra ventajas y limitaciones. El manual enumera una descripción de la habilidad implicada y un objetivo de conducta correspondiente para cada reactivo de la prueba —información útil para determinar las habilidades que deben incluirse en un programa correctivo—. Un programa de calificación computarizada convierte las calificaciones crudas en derivadas, resume el desempeño del examinado y ofrece sugerencias para la instrucción correctiva.

Otras pruebas de diagnóstico

Además de las pruebas de diagnóstico aplicadas en forma individual como la KeyMath revisada, se han elaborado varias pruebas de diagnóstico diseñadas para ser aplicadas en grupo. Dos ejemplos de pruebas de diagnóstico de grupo son la Prueba de diagnóstico de lectura de Stanford (*Stanford Diagnostic Reading Test*, SDRT) y la Prueba de diagnóstico de matemáticas de Stanford (*Stanford Diagnostic Mathematics Test*, SDMT). Aunque elaborados independientemente y estandarizados en poblaciones separadas, los dos instrumentos comparten ciertas características relacionadas con el diseño y el formato de la prueba. Ambos están disponibles en dos formas, y éstas se dividen en cuatro niveles superpuestos que evalúan el desempeño desde el primer grado escolar hasta el bachillerato. Ambos son considerados instrumentos útiles para identificar a los niños que requieren de una evaluación más detallada e individualizada.

La SDRT consiste en diez subpruebas que reflejan las habilidades requeridas en tres áreas principales de lectura: decodificación, vocabulario y comprensión. La SDMT consiste en tres subpruebas aplicadas en todos los niveles. En el manual de la prueba se proporciona información con referencia a una norma así como con referencia a un criterio para cada una de esas pruebas. Las normas fueron actualizadas por última vez en 2002 y son presentadas como categorías percentiles, staninas, equivalentes de grado y calificaciones en escala. Se proporciona información con referencia a un criterio para cada habilidad mediante el uso de un “indicador de progreso”, una calificación límite que muestra si el estudiante es lo bastante competente en esa habilidad para pasar a la siguiente etapa del programa de instrucción. Los manuales para ambos instrumentos incluyen un índice de objetivos conductuales útiles para prescribir estrategias de enseñanza. La SDRT también contiene medidas informales diseñadas para probar las actitudes de los estudiantes hacia la lectura, intereses y hábitos de lectura así como la capacidad para volver a contar una historia leída.

Baterías de pruebas psicoeducativas

Las **baterías de pruebas psicoeducativas** son grupos de pruebas que por lo general contienen dos tipos de pruebas: aquellas que miden capacidades relacionadas con el éxito académico y las que miden el aprovechamiento educativo en áreas como lectura y aritmética. Los datos derivados de estas baterías permiten hacer comparaciones normativas (cómo se compara el estudiante con otros estudiantes en el mismo grupo de edad), al igual que una evaluación de los puntos fuertes y débiles de quien responde la prueba —todo lo mejor para planear intervenciones educativas.

Una batería psicoeducativa es la Batería Kaufman de evaluación para niños (K-ABC).

La batería de evaluación para niños de Kaufman (K-ABC)

Desarrollada por un matrimonio de psicólogos, la K-ABC fue diseñada para ser usada con niños normales y excepcionales de 2½ hasta 12½ años de edad. Se incluyen subpruebas que miden tanto la inteligencia como el rendimiento. Las subpruebas de inteligencia de la K-ABC se dividen en dos grupos, que reflejan las dos clases de habilidades de procesamiento de la información identificadas por Luria y sus estudiantes (Das *et al.*, 1975; Luria, 1966a, 1966b): *habilidades simultáneas* y *habilidades secuenciales* (véase la página 242). En la tabla 10-3 se presentan los estilos de aprendizaje y enseñanza particulares que reflejan los dos tipos de inteligencia medidos por la K-ABC. Las calificaciones de las subpruebas simultánea y secuencial se combinan en un Compuesto de procesamiento mental, el cual es análogo a la medida del CI calculada en otras pruebas.

Los estudios de factores analíticos de la K-ABC han confirmado la presencia de un factor que los investigadores han etiquetado como procesamiento simultáneo y un factor llamado *procesamiento secuencial*. Quizá, de modo sorprendente, es un factor de rendimiento que los investigadores han tenido dificultad para encontrar. Kaufman (1993) encontró evidencia de la presencia de un factor de rendimiento, pero investigadores independientes tienen ideas diferentes sobre cuál es el tercer factor. Good y Lane (1988) identificaron el tercer factor de la K-ABC como *comprensión verbal* y *rendimiento en la lectura*. Kaufman y McLean (1986) lo identificaron como *rendimiento y capacidad de lectura*. Keith y Novak (1987) lo identificaron como *rendimiento en lectura y razonamiento verbal*. Cualquiera que sea el factor, la Escala de rendimiento ha demostrado predecir el rendimiento (Lamp y Krohn, 2001). Además de las preguntas relacionadas con lo que en realidad mide el elusivo tercer factor, también han surgido preguntas sobre si el aprendizaje secuencial y el simultáneo son independientes o no en su totalidad (Bracken, 1985; Keith, 1985).

Pueden derivarse recomendaciones para la enseñanza basadas en el concepto de la *fuerza del procesamiento* de Kaufman y Kaufman (1983a, 1983b) a partir de los resultados de la K-ABC.

SÓLO PIENSE...

¿Qué tan realista sería esperar que a los niños su profesor les pueda enseñar una variedad de temas de tal manera que éstos se ajusten individualmente a la capacidad de procesamiento única para cada niño como si fuera medido por una prueba?

Es recomendable, por ejemplo, que un estudiante cuya fuerza está en procesar de manera secuencial sea instruido por medio de los lineamientos de enseñanza para aprendices secuenciales. Los estudiantes que no tienen ninguna fuerza de procesamiento particular pueden ser instruidos por medio de métodos que emplean una combinación de éstos. Este modelo de interpretación de la prueba y la intervención consecuente pueden generar un gran entusiasmo en base a su potencial predictivo. Sin embargo, los resultados de la investigación relacionada con este enfoque han sido variados (Ayres y Cooley, 1986; Good *et al.*, 1989; McCloskey, 1989; Salvia y Hritcko, 1984). Good *et al.* (1993) concluyeron que las decisiones

educativas basadas en el estilo de procesamiento del niño, en la forma en las que son definidas por la K-ABC, no mejoran de ninguna manera la calidad de estas decisiones.

La segunda edición de la K-ABC fue publicada en 2004 con un rango de edad más extenso (de los 3 hasta los 18 años) para ampliar la posibilidad de hacer comparaciones entre habilidad y rendimiento con la misma prueba hasta el bachillerato. La KABC-II ha sido promovida como la prueba psicoeducativa más flexible porque los resultados pueden interpretarse con el modelo de Luria o CHC. La manera exacta en que se interpretan los resultados en la práctica depende de diferentes variables como las preferencias del usuario de la prueba y la razón para su referencia. La KABC-II fue normalizada junto con la segunda edición de la Prueba de rendimiento educativo de Kaufman (KTEA-II). En el momento en que este libro se imprimía en el idioma original, ambas pruebas eran demasiado nuevas como para una descripción y evaluación amplias. No obstante, el lector interesado encontrará información detallada sobre estos dos instrumentos en el sitio en Internet del editor de la prueba, American Guidance Service (www.agsnet.com).

Otras dos baterías de pruebas psicoeducativas ampliamente conocidas que explicaremos de manera breve con propósitos de contraste son las Escalas de habilidades diferenciales y la Woodcock-Johnson III.

Tabla 10-3

Características y lineamientos de enseñanza para aprendices secuenciales y simultáneos

Características del aprendiz	
El aprendiz secuencial	El aprendiz simultáneo
El aprendiz secuencial soluciona mejor los problemas ordenando en forma mental pequeñas cantidades de información en un orden lineal, consecutivo y paso a paso. Se siente más a gusto con las instrucciones y señales verbales, debido a que su capacidad de interpretar el lenguaje hablado depende en gran medida de la secuencia de las palabras. El procesamiento secuencial es especialmente importante en: • aprender y retener hechos aritméticos básicos • memorizar listas de palabras deletreadas • hacer asociaciones entre las letras y sus sonidos • aprender las reglas de la gramática, la cronología de eventos históricos • recordar detalles • seguir un conjunto de reglas, instrucciones, pasos • solucionar problemas dividiéndolos en sus componentes o pasos Los aprendices secuenciales que son débiles en el procesamiento simultáneo pueden tener dificultad con: • el reconocimiento visual de palabras • la comprensión de lectura • la comprensión de principios matemáticos o científicos • el uso de materiales directos concretos • el uso de diagramas, gráficas, mapas • resumir, comparar y evaluar	El aprendiz simultáneo soluciona mejor los problemas integrando y sintetizando al mismo tiempo en forma mental muchas piezas de información paralelas. Se siente más a gusto con instrucciones y señales visuales, debido a que su capacidad para interpretar el ambiente de manera visual depende de percibir e integrar muchos detalles a la vez. El procesamiento simultáneo es especialmente importante en: • reconocer la forma y la apariencia física de letras y números • interpretar el efecto general o el significado de ilustraciones y otros estímulos visuales, como mapas y gráficas • entender el significado general de una historia o poema • resumir, comparar, evaluar • comprender principios matemáticos o científicos • resolver problemas visualizándolos en forma completa Los aprendices simultáneos que son débiles en el procesamiento secuencial pueden tener dificultad con: • el ataque de palabras, desciframiento, fonética • separar en partes problemas de ciencias o aritmética • interpretar las partes y características de un diseño o dibujo • la comprensión de las reglas de juegos • la comprensión y seguimiento de instrucciones orales • recordar detalles específicos y la secuencia de una historia
Lineamientos de enseñanza	
Para el aprendiz secuencial	Para el aprendiz simultáneo
1. Presentar el material paso por paso, aproximándose en forma gradual al concepto o habilidad general. Dirigirse a la gran interrogante con una serie de interrogantes menores. Separar la tarea en partes. 2. Haga que el niño verbalice lo que está aprendiendo. Cuando le enseñe una palabra nueva, haga que la repita, en voz alta o en silencio. Enfatique las claves verbales, instrucciones y estrategias de memorización. 3. Enseñe y ensaye los pasos requeridos para resolver un problema o completar una tarea. Continúe refiriéndose a los detalles o pasos ya mencionados o dominados. Ofrezca una estructura o procedimiento lógicos apelando a la orientación verbal y temporal del niño. Por ejemplo, el aprendiz secuencial puede captar uno o dos detalles de una ilustración pero perder la imagen visual del conjunto. Para ayudar a dicho estudiante a tener una apreciación general de la ilustración, inicie con las partes tendiendo hacia el todo. En lugar de comenzar con “¿Qué muestra la ilustración?” o “¿Cómo te hace sentir la ilustración?”, primero pregunte sobre los detalles: “¿Qué está haciendo el niño pequeño en la esquina?” “¿Dónde está el perro?” “¿Qué expresión observas en el rostro de la mujer?” “¿Qué colores se usaron en el cielo?” Diríjalo hacia preguntas sobre la interpretación o apreciación general: “¿De qué forma todos estos detalles te dan claves de lo que está sucediendo en esta ilustración?” “¿Cómo te hace sentir esta ilustración?” El aprendiz secuencial prefiere un enfoque de enseñanza paso a paso, que pueda enfatizar la acumulación gradual de detalles.	1. Presentar el concepto o interrogante general antes de pedir al niño que resuelva el problema. Continúe refiriéndose de nuevo a la tarea, pregunta o resultado deseado. 2. Haga que el niño visualice lo que ha aprendido. Cuando le enseñe una palabra nueva, haga que la escriba y se forme una representación mental, que la visualice en la página con el ojo de la mente. Enfatique las claves visuales, instrucciones y estrategias de memorización. 3. Haga tareas concretas siempre que sea posible proporcionando materiales manipulables, ilustraciones, modelos, diagramas, gráficas. Ofrezca una sensación de un todo apelando a la orientación visual y espacial del niño. El aprendiz simultáneo puede reaccionar ante una ilustración como un todo pero perder los detalles. Para ayudar a un estudiante con estas características destaque las partes que contribuyen a la imagen visual total, comience estableciendo una interpretación o reacción general: “¿Qué muestra la ilustración?” “¿Cómo te hace sentir esta ilustración?” Luego considere los detalles: “¿Cuál es la expresión en el rostro de la mujer?” “¿Qué está haciendo el niño pequeño en la esquina?” “¿Qué colores se usaron en el cielo?” Relacione los detalles con la interpretación inicial del estudiante: “¿Cómo explican estos detalles la razón por la cual la ilustración te hizo sentir de ese modo?” El aprendiz simultáneo responde mejor a un enfoque de enseñanza holística que se enfoca en grupos de detalles o imágenes y enfatiza el significado global o configuración de la tarea.

Fuente: Kaufman, A. S., Kaufman, N. L., & Goldsmith, B. (1984). *Kaufman Sequential or Simultaneous (K-SOS)*. Circle Pines, MN: American Guidance Service. Utilizado con permiso.

Las escalas de habilidades diferenciales (DAS)

Las escalas de habilidades diferenciales (*Differential Ability Scales*, DAS; Elliott, 1990a, 1990b) son en realidad una adaptación estadounidense de las Escalas de habilidades británicas (*British Ability Scales*, BAS), las cuales, a su vez, son las sucesoras de una prueba conocida como la BIT (*British Intelligence Test*) Prueba de inteligencia británica. La BAS fue publicada por primera vez en Gran Bretaña en 1979, y una revisión fue editada en 1983. El desarrollo de la versión estadounidense de la DAS comenzó en 1984, y la prueba fue publicada alrededor de seis años después (Elliott, 1990a, 1990b). Apropia para utilizarse con individuos de 2 años 6 meses de edad hasta 17 años 11 meses, la DAS no sólo es una medida de capacidad (como podría esperarse por su nombre) sino también de rendimiento. Como se resume en la tabla 10-4, la batería total consiste en 17 subpruebas cognoscitivas y tres subpruebas de rendimiento (explorando el rendimiento en habilidades numéricas básicas, ortografía y lectura de palabras), aunque nunca se han aplicado más de 12 subpruebas a ningún examinado. En palabras de quien desarrolló la prueba, el psicólogo escolar Colin Elliott (1990b), la DAS fue creada “para obtener y evaluar perfiles de fuerzas y debilidades. Las pruebas de rendimiento fueron normalizadas en forma conjunta con la batería cognoscitiva para posibilitar el análisis directo de la discrepancia entre capacidad y rendimiento” (p. 1).

El concepto de inteligencia (un término que Elliott evita continuamente) que subyace en la DAS puede describirse mejor como un modelo jerárquico del desarrollo de capacidades cognoscitivas con tres niveles: capacidad conceptual general (CCG, también conocida como *g*) en la cúspide de esta jerarquía, seguida por las capacidades verbales y no verbales generales (determinadas a través de la agrupación de las puntuaciones del grupo de subpruebas), seguidas por las capacidades verbales y no verbales individuales específicas (determinadas de forma individual por las subpruebas, figura 10-2). La CCG es una medida de inteligencia compuesta, es decir, una medida compuesta por capacidades conceptuales y de razonamiento derivadas de las puntuaciones obtenidas en las subpruebas centrales que forman el fundamento de la batería. De modo adicional, las subpruebas de diagnóstico miden habilidades cognoscitivas específicas como la memoria auditiva a corto plazo y la discriminación visual. Desde el punto de vista del desarrollo, se supone que sólo ciertas capacidades están presentes en determinadas edades, y la estructura real de la batería varía con la edad.




Figura 10-2

Un modelo jerárquico de tres niveles de las habilidades cognoscitivas

La teoría en la cual se basa la DAS postula que las habilidades están en el primer nivel, y los grupos de habilidades individuales se encuentran en el segundo. En el tercero y más alto nivel de este modelo está la habilidad conceptual general (CCG).

Tabla 10-4
Las subpruebas de la DAS

Subprueba	Descripción	Capacidades medidas
<i>Subpruebas centrales</i>		
Construcción con bloques (edades de 2-6 hasta 3-5)	Copiar un diseño bidimensional o tridimensional con bloques.	Capacidad perceptiva-motora
Comprensión verbal (edades de 2-6 hasta 5-11)	Señalar ilustraciones y manipular juguetes u objetos en respuesta a las instrucciones del examinador.	Conocimiento verbal receptivo
Semejanzas pictóricas (edades de 2-6 hasta a 5-11)	Se le muestra al niño una fila de cuatro ilustraciones (como diseños geométricos u objetos cotidianos) y se le da una tarjeta con una quinta ilustración, la cual debe colocarse debajo de la ilustración que comparta un elemento o concepto.	Razonamiento no verbal
Nombrar el vocabulario (edades de 2-6 hasta 5-11)	Nombrar objetos e ilustraciones.	Conocimiento verbal expresivo
Construcción de patrones (edades de 3-6 hasta 17-11)	Construir un diseño con cuadrados de hule espuma o bloques de plástico para igualar patrones descritos en tarjetas.	Razonamiento espacial, no verbal
Conceptos numéricos iniciales (edades de 3-6 hasta 5-11)	Responder a preguntas sobre número, tamaño y otros conceptos numéricos usando fichas de colores o ilustraciones.	Conocimiento no verbal y verbal
Copiado (edades de 3-6 hasta 5-11)	Copiar dibujos hechos por el administrador o mostrados en una ilustración.	Capacidad perceptiva-motora
Recuerdo de diseños (edades de 6-0 hasta 17-11)	Reproducir un diseño geométrico abstracto después de haber sido mostrado al niño.	Memoria visual espacial a corto plazo
Definiciones de palabras (edades de 6-0 hasta 17-11)	Definir palabras presentadas en forma oral o visual.	Definir palabras presentadas en forma oral o visual.
Matrices (edades de 6-0 hasta 17-11)	Se le muestra al examinado una matriz incompleta de figuras abstractas para que seleccione la figura (de entre cuatro o seis opciones) que completen la matriz.	Razonamiento no verbal
Semejanzas (edades de 6-0 hasta 17-11)	Decir cómo se parecen las cosas o qué similitudes encuentra.	Razonamiento verbal
Razonamiento secuencial y cuantitativo (edades de 6-0 hasta 17-11)	La subprueba se presenta en dos partes. Primero se le muestra al examinado una serie de figuras abstractas para que las complete. En la segunda parte, identifica una relación dentro de cada par de dos pares de números y luego proporciona el número faltante en un par incompleto.	Detección de patrones secuenciales en figuras o números
<i>Subpruebas de diagnóstico</i>		
Recuerdo de objetos -inmediato (edades de 4-0 hasta 17-11)	Tres ensayos de recuerdo inmediato en los que el examinado observa una tarjeta con ilustraciones de 20 objetos durante 20 a 60 segundos y luego trata de recordar tantos objetos como le sea posible.	Memoria verbal a corto plazo
Recuerdo de objetos -demorado (edades de 4-0 hasta 17-11)	El examinado recuerda tantos objetos como le es posible a partir de la subprueba Recuerdo de objetos -Inmediato. La aplicación ocurre de 10 a 30 minutos después de la presentación inicial de los objetos.	Memoria verbal intermedia
Correspondencia entre formas parecidas a letras (edades de 4-6 hasta 5-11)	Elegir una figura (de entre seis opciones) que se corresponda con una figura abstracta.	Correspondencia visual perceptiva
Recuerdo de dígitos (edades de 3-0 hasta 17-11)	Repetir una secuencia de dígitos presentada en forma oral a un ritmo de dos dígitos por segundo.	Memoria auditiva a corto plazo
Reconocimiento de ilustraciones (edades de 3-0 hasta 7-11)	Después de mostrar ilustraciones en blanco y negro de objetos comunes durante 5 o 10 segundos, se muestra una segunda ilustración con los mismos objetos así como distractores (objetos que no estaban en la primera ilustración), y la tarea es señalar el o los objetos que aparecen en la primera ilustración.	Memoria visual a corto plazo
Velocidad de procesamiento de la información (edades de 6-0 hasta 17-11)	Al examinado se le presentan reactivos consistentes en filas de figuras (círculos que contienen pequeños cuadros o números). En cada fila la tarea es marcar el círculo con la mayor cantidad de cuadros o con el número más alto.	Rapidez para ejecutar operaciones mentales
<i>Subpruebas de rendimiento</i>		
Habilidades numéricas básicas (edades de 6-0 hasta 17-11)	Habilidades aritméticas básicas, que van desde identificar números hasta resolver problemas que requieren adición, sustracción, multiplicación o división. Para niveles superiores de edad, los problemas son planteados.	Cálculo numérico
Ortografía (edades de 6-0 hasta 17-11)	Escribir palabras dictadas por el examinador.	Ortografía
Lectura de palabras (edades de 6-0 hasta 17-11)	Leer en voz alta palabras presentadas en una tarjeta.	Habilidades para descifrar la lectura

La muestra de estandarización de las DAS consistió de 3 475 sujetos, divididos en grupos de 175 personas por cada seis meses de edad a partir de 2 años 6 meses hasta 4 años 11 meses, y 200 sujetos por grupo por cada año adicional a partir de 5 y hasta 17 años. La muestra fue estratificada en cada nivel en base al género, raza o grupo étnico, educación de los padres, región geográfica e inscripción en preescolar usando como criterio datos del censo de 1988. En la muestra de estandarización se incluyeron niños inscritos en clases de educación especial. Los niños de áreas metropolitanas más pequeñas y de áreas no metropolitanas estuvieron subrepresentados.

SÓLO PIENSE...

¿Cuáles son las implicaciones prácticas de algunas poblaciones a quienes se les representa de manera inferior en una prueba nacional estandarizada?

Las estimaciones, generalmente satisfactorias de la consistencia interna y la confiabilidad de la prueba y su repetición son reportadas en el manual de la prueba. Los coeficientes de confiabilidad y repetición de la prueba para la CCG varían de .85 a .94. Los coeficientes de confiabilidad y repetición de la prueba para los grupos varían de .79 a .90 para 393 niños, seleccionados al azar, de tres niveles de edad y examinados dos veces en intervalos de dos a siete semanas. La consistencia interna fue establecida por medio de un procedimiento que, en palabras del creador de la prueba, “se

basa puramente en los reactivos que se espera sean respondidos por un individuo y no se hacen suposiciones sobre el desempeño de la persona en reactivos no aplicados” (Elliott, 1990b, p. 175). Para las subpruebas que implican una calificación subjetiva (Copiado, Recuerdo de diseños, Semejanzas y Definiciones de palabras), las estimaciones de confiabilidad media entre evaluadores para cada subprueba fueron bastante altas, variando de .90 a .96.

Con base en la investigación analítica factorial reportada en el manual, ésta comprende un factor (CCG) en edades de 2 años 6 meses a 3 años 5 meses y dos factores (uno verbal y otro no verbal) en edades de 3 años 6 meses hasta 5 años 11 meses. Las Escalas diferenciales de habilidad (DAS) comprenden tres factores (uno de razonamiento verbal, uno de razonamiento no verbal y uno de capacidad espacial) en edades de 6 años 0 meses hasta 17 años 11 meses.

Varios estudios de validez que comparan las DAS con otras medidas de capacidad y rendimiento valiéndose de niños no discapacitados así como niños excepcionales se reportan en el manual de aplicación. Aunque los estudios son limitados en cuanto al tamaño de la muestra y la región del país, tienden a apoyar la validez de la DAS como una medida de capacidad y rendimiento.

Las instrucciones para su aplicación se presentan con claridad en el manual, con puntos de inicio y de culminación basados en la edad cronológica de los examinados y en el número de éxitos y fracasos. Las subpruebas centrales se aplican en un orden prescrito, mientras que existen algunos criterios de administración para la secuencia de aplicación de las subpruebas de Diagnóstico y Rendimiento. Algunas subpruebas 1) proporcionan reactivos de muestra, reactivos de enseñanza y una demostración de reactivos para el administrador, 2) pueden ser aplicados por medio de gestos en lugar de instrucciones verbales para producir una calificación compuesta no verbal y/o 3) tienen un “rango fuera de nivel” que permiten su aplicación a niños con alta o baja capacidad —siendo el efecto neto una extensión del rango de edad y capacidad de estas subpruebas—. La investigación independiente sugiere que la prueba puede ser traducida al español y produce datos comparables con una versión no traducida (Sandoval *et al.*, 2002).

La calificación se hace en dos formas de registro que son proporcionadas, una para el nivel preescolar y una para el escolar. Las formas de registro son entendibles para el administrador ya que marcan reactivos de inicio y de culminación señalados con claridad al igual que las instrucciones para la calificación. La mayor parte de los reactivos de la prueba son calificados como correctos (1 punto) o incorrectos (0 puntos), aunque algunos proporcionan puntajes de 0, 1 o 2 ya que se conceden puntos extra por responder rápido y correctamente sobre todo, los reactivos cronometrados. Las calificaciones crudas se enumeran y se convierten en puntuaciones de subprueba, las cuales, a su vez se convierten en puntuaciones estándar (con una media de 50 y una desviación estándar de 10 para las subpruebas cognoscitivas y una media de 100 y una desviación estándar de 15 para las subpruebas de rendimiento). A partir de las puntuaciones estándar se derivan las puntuaciones CCG y de grupo, las cuales tienen una media de 100 y una desviación estándar de 15.

La interpretación de la DAS es similar en muchas maneras a la interpretación de otras baterías de capacidad y rendimiento. Las puntuaciones compuestas y de grupo se comparan y eva-

lúan al igual que con las puntuaciones de cada subprueba, todo en un esfuerzo por perfilar los puntos débiles y fuertes del examinado. Además, se analiza el comportamiento a lo largo de la aplicación junto con otros resultados relacionados con la misma y éstos pueden ser incluidos en la interpretación general de los resultados.

Para niños de preescolar y de escolar por igual, los materiales de la DAS tienden a ser atractivos. Una variedad de objetos coloridos que el examinado puede manipular sirven para atraer su interés y mantenerlos dedicados a la tarea. Debido a que la prueba se puede ajustar o adaptar, el tiempo global de la misma se reduce. El tiempo de aplicación para la batería completa varía de 35 minutos para la edad de 2 años 6 meses, hasta cerca de 90 minutos para examinados en edad escolar.

Niños dentro de un rango amplio de capacidades pueden ser evaluados por la DAS, debido al extenso rango de las normas que fueron desarrolladas. En general, las propiedades psicométricas de la batería están en un rango aceptable al igual que su confiabilidad y validez, y la estructura factorial ha sido confirmada en estudios reportados en el manual de la prueba. Sin embargo, debemos advertir que las muestras con que se realizó la investigación de validez tendieron a ser relativamente pequeñas y no fueron diversas en lo geográfico. Durante el desarrollo de la prueba, se emplearon procedimientos para reducir o eliminar cualquier sesgo posible de raza o género, aunque el manual no reporta ningún dato comparativo para examinados de razas blanca, negra o de origen hispano.

SÓLO PIENSE...

Sobre la base de lo que acaba de leer y lo que pueda saber de otras fuentes sobre la DAS, describa al evaluado que usted crea que pudiera obtener el mayor beneficio al tomar esta batería.

La Woodcock-Johnson III (WJ III)

La WJ III (Woodcock *et al.*, 2000) es un paquete de pruebas psicoeducativas que consiste en dos baterías normalizadas por sí mismas y en conjunto: Pruebas de rendimiento y Pruebas de habilidades cognoscitivas, ambas basadas en la teoría de habilidades cognoscitivas de Cattell-Horn-Carroll (CHC). La WJ III fue diseñada para usarse con personas tan jóvenes como aquellas de 2 años de edad hasta con personas de edad avanzada como “las de 90 o más”, de acuerdo con el manual. La WJ III produce una medida de la habilidad intelectual general (g), así como medidas específicas de habilidades cognoscitivas, rendimiento, aptitud escolar y lenguaje oral. Puede utilizarse para diagnosticar discapacidades para el aprendizaje, determinar discrepancias entre la habilidad y el rendimiento, y para planear programas e intervenciones educativos. Las Pruebas de rendimiento están empaquetadas en formas paralelas designadas como A y B, cada una dividida en una batería estándar (12 subpruebas) y una batería ampliada (10 subpruebas adicionales). Como se ilustra en la tabla 10-5, la interpretación de una prueba de rendimiento se basa en el desempeño del examinado a lo largo de grupos de pruebas en áreas específicas del currículo escolar.

Las Pruebas de habilidades cognoscitivas pueden dividirse en una batería estándar (10 subpruebas) y una batería ampliada (10 subpruebas adicionales). Como se ilustra en la tabla 10-6, las subpruebas que comprenden habilidades cognoscitivas se conceptualizan en términos de amplios factores cognoscitivos, habilidades estrechas primarias y grupos de desempeño cognitivo.

Cuando se utilicen ya sean las pruebas de rendimiento o las de habilidades cognoscitivas, la batería estándar puede ser apropiada para clasificaciones o reevaluaciones breves. La batería extendida probablemente sea útil para proporcionar una evaluación más amplia y detallada, complementada con la información de diagnóstico. En cualquier caso, las calificaciones de grupo son útiles para ayudar a evaluar el nivel de desempeño, estimar el progreso educativo e identificar los puntos fuertes y débiles individuales.

De acuerdo con el manual de la prueba, la WJ III fue normalizada en una muestra de 8818 sujetos con edades desde los 24 meses hasta los “90 años o más”, que representaban a la población de Estados Unidos. Las normas basadas en la edad son proporcionadas a partir de los 24 meses hasta los 19 años, por mes, y después de eso, por año. Las normas basadas en el grado escolar son proporcionadas desde el preescolar hasta el doceavo grado, dos y cuatro años de universidad,

Tabla 10-5
Pruebas de rendimiento de WJ III

Área del plan de estudios	Grupo	Batería estándar-Formas A y B	Batería extendida-Formas A y B
Lectura	Habilidades básicas Fluidez Comprensión Amplitud	Prueba 1 Identificación de letras y palabras Prueba 2 Fluidez en la lectura Prueba 9 Comprensión de pasajes Pruebas 1, 2, 9	Prueba 13 Ataque de palabras Prueba 17 Lectura de vocabulario
Lenguaje oral	Expresión oral Comprensión al escuchar	Prueba 3 Recordar una historia Prueba 4 Entender instrucciones	Prueba 14 Ilustrar vocabulario Prueba 15 Comprensión oral
Matemáticas	Habilidades de cálculo Fluidez Razonamiento Amplitud	Prueba 5 Cálculo Prueba 6 Fluidez en matemáticas Prueba 10 Problemas aplicados Pruebas 5, 6, 10	Prueba 18 Conceptos cuantitativos
Lenguaje escrito	Habilidades Básicas Fluidez Expresión Amplitud	Prueba 7 Ortografía Prueba 8 Fluidez en la redacción Prueba 11 Muestras de redacción Pruebas 7, 8, 11	Prueba 16 Edición
Conocimiento complementario		Prueba 12 Recordar una historia - retardado Escala de legibilidad en la escritura	Prueba 19 Conocimiento académico Prueba 20 Deletreo de sonidos Prueba 21 Percepción del sonido Prueba 22 Puntuación y uso de mayúsculas

Tabla 10-6
Pruebas de habilidades de WJ III*

Factor cognoscitivo amplio	Prueba (estándar y extendida)	Habilidad estrecha primaria	Desempeño cognoscitivo
Comprensión-Conocimiento (<i>Gc</i>)	Prueba 1 Comprensión verbal Prueba 11 Información general	Conocimiento del léxico, desarrollo del lenguaje Información general (verbal)	Habilidad verbal
Recuperación a largo plazo (<i>Glr</i>)	Prueba 2 Aprendizaje visual-auditivo Prueba 12 Fluidez de recuperación <i>Prueba 10 Aprendizaje visual-auditivo —retardado</i>	Memoria asociativa Fluidez de la formación de ideas <i>Memoria asociativa</i>	Habilidad de pensamiento
Pensamiento espacial-visual (<i>Gv</i>)	Prueba 3 Relaciones espaciales Prueba 13 Reconocimiento de ilustraciones <i>Prueba 19 Planeación (Gv/Gf)</i>	Visualización, relaciones espaciales Memoria visual <i>Exploración espacial, razonamiento secuencial general</i>	Habilidad de pensamiento
Procesamiento auditivo (<i>Ga</i>)	Prueba 4 Combinación de sonidos Prueba 14 Atención auditiva <i>Prueba 8 Palabras incompletas</i>	Conversión fonética, síntesis Discriminación de sonidos en el habla, resistencia a la distorsión de estímulos auditivos <i>Conversión fonética, análisis</i>	Habilidad de pensamiento
Razonamiento fluido (<i>Gf</i>)	Prueba 5 Formación de conceptos Prueba 15 Análisis-síntesis <i>Prueba 19 Planeación (Gv/Gf)</i>	Inducción Razonamiento secuencial general <i>Exploración espacial, razonamiento secuencial general</i>	Habilidad de pensamiento
Velocidad de procesamiento (<i>Gs</i>)	Prueba 6 Correspondencia visual Prueba 16 Velocidad de decisión <i>Prueba 18 Nominación rápida de ilustraciones</i> <i>Prueba 20 Cancelación de pares</i>	Velocidad de percepción Velocidad de procesamiento semántico <i>Facilidad para nombrar</i> <i>Atención y concentración</i>	Eficiencia cognoscitiva
Memoria a corto plazo (<i>Gsm</i>)	Prueba 7 Regresión de números Prueba 17 Memoria para las palabras <i>Prueba 9 Memoria de trabajo auditivo</i>	Memoria de trabajo Alcance de la memoria <i>Memoria de trabajo</i>	Eficiencia cognoscitiva

* Las pruebas que aparecen en *italicas* no son parte del factor o grupo de desempeño cognoscitivo.

incluyendo la escuela de graduados. Los procedimientos para el análisis de confiabilidad para cada subprueba fueron apropiados, dependiendo de la naturaleza de las pruebas aplicadas. Por ejemplo, la confiabilidad de las pruebas que no fueron respondidas de manera rápida y que no tuvieron sistemas de calificación de puntos múltiples fue analizada mediante el método de dividir en mitades, y se corrigió la extensión con la fórmula de corrección Spearman-Brown. El manual de la prueba también presenta datos de validez concurrentes. Además, investigadores independientes apoyan la validez de varios aspectos. Por ejemplo, Floyd *et al.* (2003) encontraron que ciertos grupos cognoscitivos se relacionaban de manera significativa con el rendimiento académico en una muestra grande representativa de Estados Unidos de niños y adolescentes.

La calificación de la WJ III se obtiene con ayuda de un programa de cómputo que se incluye en el equipo de la prueba. Se introducen los datos de las calificaciones, y un programa produce un reporte (en inglés o en español) y una tabla de calificaciones, incluyendo todas las puntuaciones derivadas de las pruebas administradas y grupos de pruebas. El programa también ofrece perfiles de grado por edad y perfiles estándares de rango percentil por calificación. También se dispone de un programa opcional interpretativo (Riverside Publishing, 2001). Este programa ofrece principalmente protocolos de listas de verificación (una lista de verificación para los maestros y una para los padres, otra para el informe personal, así como una forma para las observaciones en la clase) de forma que se integran resultados con listas de verificación en un reporte. El editor de la prueba también cuenta con materiales opcionales de capacitación, incluyendo CD-ROM y videos, que son de ayuda para la administración y uso de la batería.

Otras herramientas de evaluación en escenarios educativos

Más allá de los instrumentos de rendimiento, aptitudes y diagnóstico tradicionales se encuentra un universo amplio de otros instrumentos y técnicas de evaluación que pueden ser usadas al servicio de los estudiantes y de la sociedad en su conjunto. Echemos un vistazo a una muestra de esos enfoques, comenzando con el desempeño, el portafolio y una evaluación auténtica.

Desempeño, portafolios y evaluación auténtica

Durante muchos años, la amplia denominación *evaluación del desempeño* se ha referido de manera vaga a cualquier tipo de evaluación que requiere del examinado algo más que elegir la respuesta correcta de entre un grupo pequeño de alternativas. Así, por ejemplo, las preguntas de ensayo y el desarrollo de un proyecto artístico serían ejemplos de tareas de desempeño. Por el contrario, las preguntas cierto/falso y los reactivos de prueba de opción múltiple no se considerarían tareas de desempeño.

Entre los profesionales de la psicometría y la evaluación, el uso contemporáneo de términos relacionados con el desempeño se enfoca menos en el tipo de reactivo o tarea implicada y más en el conocimiento, habilidades y valores que el examinado debe ordenar y exhibir. Además, hay una tendencia creciente a hablar de tareas de desempeño y evaluación del desempeño en el contexto de un particular campo de estudio, siendo requeridos de manera característica expertos en ese particular campo de estudio para establecer las normas de evaluación. Por ejemplo, una tarea de desempeño para un estudiante de arquitectura podría ser realizar un plano de una casa contemporánea. La calidad general del trabajo del estudiante, al igual que el conocimiento, habilidad y valores inherentes a él, serán juzgados de acuerdo con normas establecidas por arquitectos reconocidos en la comunidad de arquitectos como poseedores de experiencia en la construcción de casas contemporáneas. De acuerdo con las tendencias actuales, en particular en ámbitos educativos y laborales, definiremos una **tarea de desempeño** como una muestra de trabajo diseñada para obtener conocimientos, habilidades y valores representativos de un particular campo de estudio. La **evaluación del desempeño** será definida como una valoración de las tareas de desempeño de acuerdo con criterios desarrollados por expertos del área de estudio comprendida en esas tareas.

Uno de los muchos tipos posibles de evaluación del desempeño es la evaluación de portafolios. La palabra *portafolios* tiene diversos significados en diferentes contextos. Puede referirse a

un maletín portátil, generalmente usado para trasladar obras de arte, dibujos, mapas y cosas por el estilo. Los banqueros e inversionistas lo emplean como referencia estenográfica a las acciones financieras individuales. En el lenguaje de la evaluación psicológica y educativa, **portafolios** es sinónimo de *muestra de trabajo*. La **evaluación de portafolios** se refiere a la evaluación de muestras de trabajo personales. En muchos escenarios educativos, la insatisfacción con algunos métodos más tradicionales de evaluación ha conducido a exigir valoraciones que se basen en mayor medida en el desempeño. La *evaluación auténtica* (que se examinará después) es un nombre que se da a esta tendencia hacia una evaluación basada más en el desempeño. Cuando se usa en el contexto de programas educativos con similar opinión, la evaluación de portafolios y la evaluación auténtica son técnicas diseñadas para designar enseñanzas académicas a escenarios del mundo real externos al salón de clases.

Considere, por ejemplo, cómo los estudiantes podrían usar los portafolios para estimar su progreso en un curso de álgebra de bachillerato. Los estudiantes podrían ser enseñados a diseñar sus propios portafolios personales para ilustrar todo lo que han aprendido sobre esta materia. Un aspecto importante de la evaluación de portafolios es la libertad de la persona evaluada para seleccionar su contenido. Algunos estudiantes podrían incluir explicaciones narrativas de la comprensión que lograron de varios principios algebraicos. Otros podrían reflexionar por escrito sobre las formas en que puede emplearse el álgebra en la vida diaria. Incluso otros más podrían intentar crear una situación convincente de cómo pueden resolver algunos tipos de problemas de álgebra que no podrían haber resuelto antes de tomar el curso. De principio a fin, el portafolio puede ser ilustrado con registros como recibos de gasolina (completados con fórmulas algebraicas para calcular el kilometraje), recibos de nómina (completados con fórmulas usadas para calcular un salario por hora y los impuestos) y otros índices limitados sólo por la imaginación del estudiante. Las ilustraciones pueden ser desde muy simples hasta cada vez más complejas —que proporcionen evidencia convincente respecto a la comprensión del material por parte del estudiante.

SÓLO PIENSE...

¿Cómo sería un portafolio personal, incluyendo con detalle todo lo que ha aprendido sobre pruebas psicológicas y evaluación hasta este momento?

El innovador método del portafolio para evaluar el talento (Hadaway y Marek-Schroer, 1992) y la lectura (Henk, 1993), entre muchas otras características, puede ser hallado en la literatura académica. Los portafolios también tienen su aplicación en el nivel universitario y de postgrado como dispositivos para ayudar a los estudiantes en sus decisiones respecto a una carrera (Bernhardt *et al.*, 1993). Los beneficios del manejo del portafolio incluyen involucrar a los estudiantes en el proceso de evaluación, dándoles la oportunidad de pensar en forma creativa y alentándolos a pensar

sobre el aprendizaje como un proceso continuo e integrado. Sin embargo, una desventaja clave es la penalidad que una técnica así puede imponer al estudiante no creativo. De manera característica, los portafolios excepcionales son esfuerzos creativos. Una persona cuya fuerza no reside en la creatividad puede haber aprendido el material del curso pero puede ser incapaz de demostrar en forma adecuada el aprendizaje con ese medio. Otra desventaja, que encontramos al otro lado del escritorio del instructor, se refiere a la valoración de los portafolios. Normalmente, debe dedicarse una gran cantidad de tiempo y meditación para su evaluación. En una clase de 300 personas, por ejemplo, la evaluación de portafolios sería poco práctica. Además, sería difícil elaborar criterios confiables dada la gran diversidad de productos de trabajo. Por consiguiente, en la evaluación del portafolio la confiabilidad entre evaluadores puede convertirse en un problema.

Una forma de evaluación relacionada es la **evaluación auténtica**, también conocida como *evaluación basada en el desempeño* (Baker *et al.*, 1993) entre otros nombres. Podemos definir la evaluación auténtica en contextos educativos como la evaluación de tareas relevantes y significativas que pueden ser efectuadas para examinar el aprendizaje de alguna materia académica de forma que se demuestre la relación y aplicación del conocimiento adquirido por parte del estudiante a las actividades del mundo real. La evaluación auténtica de las habilidades de redacción, por ejemplo, de los estudiantes estaría por tanto basada en muestras de redacción en lugar de en las respuestas a exámenes de opción múltiple. La evaluación auténtica de la capacidad de lectura de los estudiantes se basaría en tareas que tengan que ver con la lectura —de preferencia lectura “auténtica”, como un artículo en un periódico local opuesto a una obra planeada especialmente para propósitos de evaluación. A los estudiantes en un curso de psicopatología de nivel universi-

tario se les podría pedir que identificaran los diagnósticos psiquiátricos de pacientes basándose en entrevistas grabadas en video.

Se considera que la evaluación auténtica incrementa el interés del estudiante y la transferencia del conocimiento a escenarios externos al salón de clases. Un inconveniente es que se podría evaluar el conocimiento y la experiencia previos, no sólo de lo que se ha aprendido en el salón de clases. Por ejemplo, los estudiantes provenientes de hogares donde ha habido un interés permanente en las actividades legislativas pueden salir mejor en una evaluación auténtica de habilidades de lectura que emplee un artículo sobre éstas. Además, la habilidad auténtica puede implicar en forma inadvertida la evaluación de algunas habilidades que tienen poco que ver con el aprendizaje en el salón de clases. Por ejemplo, la evaluación auténtica del aprendizaje de una lección escolar de cocina para filetear pescado puede ser confundida con una evaluación de las habilidades perceptivo-motoras del aspirante a cocinero.

Técnicas de valoración de pares

Un método para obtener información sobre un individuo es pedir al grupo de compañeros de esa persona que hagan la valoración. Las técnicas empleadas para obtener dicha información se denominan métodos de **valoración de pares**. Un maestro, un supervisor o algún otro líder de grupo pueden estar interesados en las evaluaciones de pares por una gran variedad de razones. Pueden ayudar a llamar la atención necesaria hacia un individuo que está experimentando dificultades académicas, personales, sociales o relacionadas con el trabajo, dificultades que por cualquier razón no han captado la atención de la persona encargada de ello. Permiten que el responsable vea a los individuos de un grupo desde una perspectiva diferente, la perspectiva de personas que trabajan, juegan, socializan, almuerzan y acompañan a casa al individuo que está siendo evaluado. Además de proporcionar información acerca de un comportamiento que rara vez es observable, las valoraciones de pares suministran información sobre la dinámica del grupo: quién adopta cuáles funciones bajo qué condiciones. El conocimiento del lugar de un individuo dentro del grupo es un auxiliar importante para guiar a los participantes o involucrados en el proceso hacia una eficiencia óptima.

Las técnicas de valoración de pares pueden ser útiles en escenarios universitarios al igual que en grados escolares, industriales y en escenarios militares. Dichas técnicas tienden a ser más útiles en ambientes donde los individuos que llevan a cabo la estimación han funcionado como un grupo el tiempo suficiente como para ser capaces de evaluarse el uno al otro en variables específicas. La naturaleza de las valoraciones de los semejantes puede variar como una función de los cambios en la situación de evaluación y la pertenencia al grupo. Así, por ejemplo, un individuo que es estimado como el más tímido en el salón de clases puede ser, en teoría, sumamente gregario —y quizá incluso ser calificado como el más presumido— en la valoración de un semejante realizada en un centro diferente de la escuela.

Un método de valoración de pares que puede ser empleado en ambientes de la escuela elemental (al igual que en otros) es denominado técnica de adivinar quién. Breves oraciones descriptivas (como “Esta persona es la más amigable”) son leídas o entregadas a la clase en forma de cuestionarios y a los niños se les instruye para que adivinen quién es. Si se deben incluir atributos negativos en la valoración de los pares (por ejemplo, “Esta persona es la menos amigable”) debe ser decidido sobre una base individual considerando las consecuencias negativas potenciales que una valoración así podría tener en un miembro del grupo.

La técnica nominativa es un método de valoración de pares en la que se pide a los individuos que seleccionen o nominen a otros para varios tipos de actividades. A un niño que es entrevistado en una clínica psiquiátrica puede preguntársele “¿Con quién te gustaría más ir a la Luna?” como un medio para determinar cuál de los padres u otro individuo es más importante para el niño. A los miembros del departamento de policía podría preguntárseles “¿Quién es el que más te gustaría como pareja en tu siguiente ronda de vigilancia y por qué?” como un medio para averiguar cuáles oficiales de policía son vistos por sus compañeros como especialmente competentes o incompetentes.

Los resultados de una valoración de pares pueden ilustrarse en forma gráfica. Un método gráfico para organizar estos datos se llama **sociograma**. En él se dibujan figuras como círculos

o cuadrados para representar a diferentes individuos, y se trazan líneas y flechas para indicar varios tipos de interacción. Con una sola mirada, el sociograma puede proporcionar información sobre quién es popular, quién tiende a ser rechazado y quién es relativamente neutral en la opinión del grupo. Las técnicas de nominación han sido ampliamente investigadas dentro de las técnicas de la valoración de pares, y por lo general han resultado ser muy confiables y válidas. No obstante, los usuarios deben tener cuidado en el uso y aplicación de estas técnicas ya que las percepciones individuales dentro de un grupo cambian en forma constante. Cualquiera que haya visto alguna de las llamadas representaciones reales por televisión (*reality shows*), como *Survivor*, seguramente ha observado esas dinámicas de grupo. Conforme algunos miembros dejan el grupo y otros se unen a él, cambian las posiciones y funciones de los miembros dentro del mismo. Se forman nuevas alianzas y, como resultado, los integrantes pueden verse bajo una nueva perspectiva. Por tanto, es importante actualizar y verificar la información en forma periódica.

Medición de hábitos de estudio, intereses y actitudes

El desempeño académico es el resultado de una interacción compleja de diversos factores. La capacidad y la motivación son compañeros inseparables en la búsqueda de éxito académico. Se han publicado diversos instrumentos diseñados para indagar más allá de la capacidad, dirigiéndose hacia factores como hábitos de estudio, intereses y actitudes. Por ejemplo, la Lista de verificación de hábitos de estudio (*Study Habits Checklist*), diseñada para su aplicación con estudiantes del noveno hasta el catorceavo grado (último año de preparatoria o bachillerato), consiste en 37 reactivos que evalúan hábitos de estudio respecto a toma de apuntes, lectura del material y prácticas de estudio generales. Durante el desarrollo de la prueba, se presentaron reactivos potenciales para examinar a 136 miembros de la sociedad Phi Beta Kappa (sociedad honoraria estadounidense fundada en 1776, cuyos miembros son escogidos, para una membresía de por vida, comúnmente de entre alumnos universitarios a punto de graduarse con altas distinciones honoríficas) en tres universidades. Este procedimiento está basado en la premisa de que los buenos estudiantes son los mejores jueces de técnicas de estudio importantes y efectivas (Preston, 1961). Se les pidió a los jueces que evaluaran los reactivos de acuerdo con su utilidad para estudiantes que tenían dificultades con el material de los cursos universitarios. Aunque los jueces admitieron que no siempre participan en estas prácticas, identificaron las técnicas que consideraron más útiles en las actividades de estudio. La estandarización de la Lista de verificación tuvo lugar en 1966, y las normas/percentiles se basaron en una muestra de varios miles de estudiantes de bachillerato y universidad residentes en Pennsylvania. En un estudio de validez, 302 estudiantes de primer año en la universidad que habían demostrado dificultades en el aprendizaje y tuvieron que ser enviados a un centro de habilidades de aprendizaje fueron evaluados por medio de la Lista de verificación. Como se predijo, se encontró que estos estudiantes demostraron prácticas de estudio deficientes, en particular en las áreas de toma de apuntes y del uso apropiado del tiempo de estudio (Bucofsky, 1971).

Si un maestro conoce las áreas de interés de un niño, puede emplear actividades instructivas que involucren dichos intereses. El inventario de intereses de lo que me gusta hacer (*What I Like to Do Interest Inventory*) consiste en 150 reactivos de elección forzada que evalúan cuatro áreas: intereses académicos, intereses artísticos, intereses ocupacionales e intereses en actividades recreativas (juegos). En los materiales de la prueba se incluyen sugerencias para diseñar actividades instructivas que sean acordes con las áreas de interés designadas.

Los inventarios de actitudes usados en escenarios educativos evalúan las actitudes de los estudiantes hacia una variedad de factores relacionados con la escuela. El interés en las actitudes del estudiante se basa en la premisa de que las “reacciones positivas hacia la escuela pueden incrementar la probabilidad de que los estudiantes permanezcan en la escuela, desarrollen un compromiso duradero con el aprendizaje y empleen el ambiente escolar para su beneficio” (Epstein y McPartland, 1978, p. 2). Algunos instrumentos evalúan actitudes en un área temática específica, mientras que otros, como la Encuesta de actitudes escolares (*Survey of School Attitudes*) y las Escalas de calidad de la vida escolar (*Quality of School Life Scales*) son más generales en su alcance.

La Encuesta de hábitos de estudio y actitudes (*Survey of Study Habits and Attitudes, SSHA*) y la Encuesta de actitudes y métodos de estudio (*Study Attitudes and Methods Survey*) combinan la evaluación de actitudes con la evaluación de métodos de estudio. La SSHA, proyectada para ser usada a partir del séptimo grado hasta la universidad, consiste en 100 reactivos que exploran habilidades de estudio y malas actitudes que podrían afectar el desempeño académico. Está disponible de dos formas, la Forma H para grados séptimo a doceavo y la Forma C para la universidad, cada una requiere de 20 a 25 minutos para ser completada. Los estudiantes responden a reactivos en la siguiente escala de cinco puntos: *rara vez, en ocasiones, con frecuencia, por lo general o casi siempre*. Los reactivos de la prueba se dividen en seis áreas, las cuales incluyen: Elusión de la demora, Métodos de trabajo, Hábitos de estudio, Aprobación del maestro, Aceptación de la educación y Actitudes de estudio. La prueba produce una calificación de habilidades de estudio, una calificación de actitudes y una calificación total de orientación.

En tanto usted *sólo piense* en las preguntas que surgen respecto al estudio y la personalidad, *sólo sepa* que en los siguientes dos capítulos aprenderá sobre la personalidad y su evaluación.

SÓLO PIENSE...

En tanto permanecemos en el tema de los hábitos de estudio, habilidades y actitudes, éste parece un momento apropiado para plantear una interrogante sobre la forma en que se relacionan estas variables con otra más global: la personalidad. ¿Nuestros hábitos de estudio, habilidades y actitudes son parte de nuestra personalidad? ¿Por qué podría ser útil pensar sobre ellos de esta manera?

Autoevaluación

Compruebe su comprensión de los elementos de este capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaturas:

batería de pruebas psicoeducativas
calificación de Apgar
DAS
discapacidad para el aprendizaje
en riesgo
escala de medición
evaluación auténtica
evaluación basada en el plan de
estudios (EBPE)
evaluación del desempeño

evaluación de portafolios
evaluación informal
información diagnóstica
información evaluativa
K-ABC
lista de verificación
medición basada en el plan de
estudios (MBPE)
portafolios
prueba de aptitud

prueba de disposición
prueba de pronóstico
prueba de rendimiento
prueba de localización
sociograma
tarea de desempeño
valoración de pares
WJ III

Un vistazo a la red

Consulte los siguientes sitios en la red para obtener más información acerca de los temas estudiados en este capítulo.

Ley Pública 94-142
www.scn.org/~bk269/94-142.html

Escala de Clasificación Connors
www.widerange.com/connors.html

Evaluación basada en el currículo educativo
<http://education.umn.edu/research/ResearchWorks/CBM.htm>

www.interventioncentral.org/htmldocs/interventions/cbmwarehouse.shtml

www.lefthandlogic.com/htmldocs/tools/cbaprobe/cba.shtml
www.nasponline.org/publications/cq276cba.html
www.nasponline.org/certification/ss_module6.html
http://alpha.fdu.edu/psychology/extended_links.htm

Servicio de Evaluación Educativa
www.ets.org

Junta de Consejo Universitario (College Board) (SAT)
www.collegeboard.com

PSAT
www.collegeboard.com/student/testing/psat/about.html

GRE
www.gre.org/splash.html

Programa americano de evaluación Colegial (American College Testing Program-ACT)
www.act.org/aap/

Prueba de analogías de Miller (The Miller Analogies Test-MAT)
<http://marketplace.psychcorp.com/PsychCorp.com/Cultures/en-US/dotCom/milleranalogies.com.htm>

Prueba de admisión a la Facultad de Medicina (The Medical College Admissions Test-MCAT)
www.aamc.org/students/mcat/start.htm

WRMT-R
www.thecoo.edu/~jknutson/woodcock_reading_mastery_tests.htm

K-ABC II
www.agsnet.com/group.asp?nGroupinfoID=a21000

DAS
www.psychcorp.com.au/das.html
<http://alpha.fdu.edu/psychology/DAS.html>

WJ III
http://alpha.fdu.edu/psvchology/woodcock_index.htm

www.riverpub.com/products/clinical/wj3/home.html
<http://assess.nelson.com/test-ind/wj-3.html>

Evaluación de portafolio
www.eduplace.com/rdg/res/literacy/assess6.html

Sociogramas
http://maxweber.hunter.cuny.edu/pub/eres/EDSPC715_MCINTYRE/Sociogram.html

Evaluación de la personalidad: un perfil general

En una melodía de rock and roll de la década de 1950 llamada “Personalidad”, el cantante Lloyd Price utilizó palabras como *camina, habla, sonrío y encanta* para describir al personaje de su canción. Al hacerlo, Price utilizó el concepto de personalidad en la misma forma en que la mayoría de las personas tienden a usarlo. Para los legos, *personalidad* se refiere a los componentes del carácter de un individuo que pueden provocar reacciones positivas o negativas en otros. Se considera que un individuo que tiende de manera consistente a provocar reacciones positivas en los demás tiene una “buena personalidad”; mientras que un individuo que de la misma manera tiende a provocar reacciones desagradables en los demás se considera que tiene una “personalidad nociva” o, quizá peor aún, que “no tiene personalidad”. También escuchamos hablar de personas siendo descritas de diferentes maneras con adjetivos como *agresiva, cálida o fría*. Para los profesionales en el ámbito de las ciencias conductuales, los términos empleados tienden a ser bien definidos, sino es que a ser más descriptivos.

SÓLO PIENSE...

A pesar de grandes esfuerzos, una definición de la personalidad, de manera muy parecida a la definición de inteligencia, ha sido un tanto elusiva. ¿Por qué cree que esto sea así?

Definición y evaluación de la personalidad

Personalidad

En la literatura psicológica existen docenas de definiciones diferentes para el término personalidad. Algunas definiciones parecen ser comprensivas. Por ejemplo, McClelland (1951, p. 69) definió personalidad como “la conceptualización más adecuada del comportamiento de una persona en todos sus detalles”. Menninger (1953, p. 23) la definió como “el individuo en su totalidad: su estatura y su peso; sus afectos y aversiones; su presión sanguínea y sus reflejos; sus sonrisas y sus esperanzas; sus piernas arqueadas y sus amígdalas dilatadas. Significa todo lo que cualquiera es y en lo que está tratando de convertirse”. Algunas definiciones se enfocan de manera reducida en un aspecto particular de la persona (Goldstein, 1963a) mientras que otras describen al individuo en el contexto de la sociedad (Sullivan, 1953). Algunos teóricos evitan en absoluto cualquier definición. Por ejemplo, Byrne (1974, p. 26) ha caracterizado el área psicológica completa de la personalidad como “el cesto de basura de la psicología en la que cualquier investigación que no tenga cabida en otras categorías existentes puede ser etiquetada ‘personalidad’”.

En su ampliamente leído y autorizado libro de texto *Teorías de la personalidad*, Hall y Lindzey (1970, p. 9) escribieron: “Estamos convencidos de que *ninguna definición sustantiva de personalidad puede ser aplicada a cualquier generalidad*” y la “*personalidad es definida por los conceptos empíricos particulares que son una parte de la teoría de la personalidad empleada por el observador*” [cursivas en el original]. Al observar que había diferencias teóricas importantes en muchas teorías de la perso-

nalidad, Hall y Lindzey animaron a sus lectores a seleccionar una definición de personalidad de entre las muchas presentadas y adoptarla como propia.

Usted muy bien podría preguntar, “Si respetables autoridades en el estudio de la personalidad como Hall y Lindzey no la definen, ¿quiénes son Cohen y Swerdlik para pensar que ellos pueden hacerlo?”. En respuesta, humildemente ofrecemos nuestra definición de **personalidad** como “una constelación única de rasgos y estados psicológicos del individuo”. Consideramos que esta definición tiene la ventaja de la parquedad, no obstante aún es lo bastante flexible como para incorporar una amplia diversidad de variables. En nuestra definición se incluyen además variables en las que los individuos pueden diferir unos de otros, tales como valores, intereses, actitudes, perspectiva del mundo, aculturación, identidad personal, sentido del humor y estilos cognoscitivos y conductuales.

Evaluación de la personalidad

La **evaluación de la personalidad** puede ser definida como la medida y valoración de rasgos psicológicos, estados, valores, intereses, actitudes, perspectiva del mundo, aculturación, identidad personal, sentido del humor, estilos cognoscitivos y conductuales y/o características individuales relacionadas. En este capítulo ofrecemos un resumen del proceso de evaluación de la personalidad, incluyendo enfoques diferentes para la elaboración de pruebas de personalidad. En el capítulo siguiente, nos enfocamos en varios métodos de evaluación de la personalidad, incluyendo métodos objetivos, proyectivos y conductuales. Antes de todo esto, sin embargo, son necesarios algunos antecedentes respecto al uso de los términos *rasgo*, *tipo* y *estado*.

Rasgos, tipos y estados

Rasgos de personalidad Así como no existe un consenso universal respecto a la definición de personalidad, tampoco hay ninguno respecto a la definición de *rasgo*. Teóricos como Gordon Allport (1937) han tendido a considerar los rasgos de personalidad como entidades físicas reales que son “estructuras mentales auténticas de cada personalidad” (p. 289). Para Allport, un rasgo es un “sistema neuropsíquico generalizado y determinado (peculiar al individuo) con la capacidad para explicar muchos estímulos funcionalmente equivalentes, así como para iniciar y guiar formas consistentes (equivalentes) de comportamiento adaptativo y expresivo” (p. 295). Robert Holt (1971) señaló que “hay estructuras reales dentro de las personas que determinan su comportamiento en formas legítimas” (p. 6), y prosiguió a conceptualizar esas estructuras como cambios en la química cerebral que pueden ocurrir como resultado del aprendizaje: “El aprendizaje causa cambios estructurales submicroscópicos en el cerebro por tanto, de manera probable también lo hará en la organización de su sustancia bioquímica” (p. 7). Raymond Cattell (1950) también definió los rasgos como estructuras mentales pero para él *estructura* no necesariamente implica un estado físico real.

Nuestra preferencia personal es evitar las definiciones que elevan el *rasgo* a la categoría de existencia física. Consideramos los rasgos psicológicos como atribuciones asignadas en un esfuerzo por identificar cadenas de consistencia en patrones conductuales. En este contexto, una definición de **rasgo de personalidad** ofrecida por Guilford (1959, p. 6) tiene gran atractivo: “Cualquier forma distinguible, relativamente perdurable, en la que un individuo varía de otro”.

Esta definición relativamente simple tiene algunos aspectos en común con los escritos de otros teóricos de la personalidad como Allport (1937), Cattell (1950, 1965) y Eysenck (1961). La palabra *distinguible* indica que los comportamientos clasificados mediante diferentes conceptos de rasgo en realidad son diferentes entre sí. Por ejemplo, un comportamiento denominado “amigable” debería distinguirse de un comportamiento clasificado “descortés”. El *contexto*, o la situación en la que se exhibe el comportamiento, es importante al asignar términos definidos como rasgo a los comportamientos. Una conducta presente en un contexto puede clasificarse con un término definido como rasgo, pero la misma conducta exhibida en otro contexto puede describirse mejor usando otro término de rasgo. Por ejemplo, si observamos a alguien ocupado en una conversación larga, aparentemente interesante, debemos contemplar el contexto antes de sacar

alguna conclusión de los rasgos de la persona. Un individuo que habla con un amigo durante el almuerzo puede demostrar amistad, mientras que esa misma persona hablando con el mismo amigo mientras se celebra una ceremonia nupcial puede ser considerada grosera. De esta manera, el término con el que se defina el rasgo seleccionado por un observador depende del comportamiento en sí y del contexto en el que se manifiesta ese comportamiento.

Una medición del comportamiento en un contexto particular puede obtenerse usando varias herramientas de evaluación psicológica. Por ejemplo, recurriendo a la observación natural un observador podría contemplar cómo interactúa el evaluado con sus compañeros de trabajo durante el momento de descanso. De manera alternativa, se podría pedir al evaluado que responda un cuestionario individual a manera de autoexamen y que describa varios aspectos de su interacción con sus compañeros durante el descanso.

En su definición de rasgo, Guilford no afirmó que los rasgos representen formas perdurables en las cuales los individuos varían de uno a otro; más bien, los definió como *relativamente perdurables*. *Relativamente* enfatiza cuán exactamente un rasgo particular manifiesta en sí mismo depender de la situación, al menos en cierto grado. Por ejemplo, una persona “violenta” bajo libertad condicional, por lo general puede ser propensa a comportarse en una forma bastante sumisa con el oficial encargado de vigilarlo durante su liberación y en forma mucho más violenta en presencia de su familia y amigos. Allport (1937) abordó la cuestión de la consistencia de los rasgos entre situaciones, o la falta de ésta, como sigue:

La consistencia perfecta nunca se encontrará y no debe esperarse [...] Las personas pueden ser autoritarias y sumisas, sumisas quizá sólo hacia aquellos individuos que portan símbolos tradicionales de autoridad y prestigio, y hacia todos los demás, agresivos y dominantes [...] El ambiente siempre cambiante eleva ahora un rasgo y luego otro a un estado de tensión activa (p. 330).

Por años, los evaluadores y teóricos de la personalidad han asumido que los rasgos de la personalidad son duraderos de forma relativa en el transcurso de nuestras vidas. Roberts y DelVecchio (2000) exploraron la duración de los rasgos mediante un metaanálisis de 152 estudios longitudinales. Estos investigadores concluyeron que la consistencia de los rasgos aumenta en un patrón gradual hasta que cumplimos 50 a 59 años de edad, periodo en el que esa consistencia alcanza el punto más alto. Sus hallazgos pueden interpretarse como un incontestable testimonio de la relativamente perdurable naturaleza de los rasgos de personalidad en el transcurso de nuestras vidas. ¿Cree usted que los estudiantes físicamente agresivos de bachillerato de la figura 11-1 conservarán ese rasgo cuando se acerquen a la edad de jubilarse?

Regresando a nuestra descripción de la definición de Guilford, observe que *rasgo* se describe como una forma en la que un individuo varía de otro. Enfatizamos aquí que la atribución de un término de rasgo siempre es un fenómeno *relativo*. Por ejemplo, un comportamiento descrito como “patriótico” puede diferir en gran medida de otra conducta también descrita como “patriótica”. No hay normas absolutas. Al describir a un individuo como patriota, estamos haciendo, en esencia, una comparación no declarada con el grado de comportamiento patriótico que podría esperarse fuera exhibido bajo las mismas o similares circunstancias y de manera razonable y consistente.

La investigación tradicional sobre el tema de la consistencia entre situaciones ha señalado una falta de solidez en lo referente a rasgos como la honestidad (Hartshorne y May, 1928), puntualidad (Dudycha, 1936), conformismo (Hollander y Willis, 1967), actitud hacia la autoridad (Burwen y Campbell, 1957) y la introversión/extroversión (Newcomb, 1929). Éstos son los tipos de estudios citados de manera típica por Mischel (1968, 1973, 1977, 1979) y otros que han mantenido una actitud crítica hacia el predominio del concepto de los rasgos en la teoría de la personalidad. Esta actitud crítica puede aludir también al hecho de que alguna porción indeterminada del comportamiento que se exhibe en público puede estar regida más por las expectativas sociales y las restricciones impuestas por la cultura que por los rasgos de personalidad de un individuo (Barker, 1963; Goffman, 1963). La investigación diseñada para arrojar luz sobre la preponderancia de las diferencias individuales en oposición a factores situacionales en el comportamiento es compleja desde el punto de vista metodológico (Golding, 1975), y un veredicto definitivo referente a la primacía del rasgo o de la situación simplemente no se ha dado.



Figura 11-1
Rasgo de agresividad y altercados sobre hielo

Bushman y Wells (1988) administraron una medida de autodescripción del rasgo de agresividad (la Subescala de agresión física, del Cuestionario de agresión) a 91 jugadores del equipo estudiantil de hockey, antes de que comenzara la temporada. Los jugadores respondieron a reactivos como “Algunas veces no puedo controlar mi deseo de pegarle a otra persona” presentado en el formato de la escala de Likert que fluctúa de 1 a 5 (donde 1 correspondía a “extremadamente no característico en mí” y 5 a “extremadamente característico en mí”). Al final de la temporada, las calificaciones de los rasgos de agresividad fueron evaluadas de acuerdo con las minutas depositadas en la caja de sanciones por agresividad como castigos por pelear, derribar, atacar y obstruir. La medición del rasgo de agresividad durante la pretemporada pronosticaba castigos por agresión según las minutas depositadas. Este estudio es particularmente significativo porque los datos de la prueba fueron utilizados para predecir la agresión en la vida real, no en un laboratorio análogo de agresión como la administración de choques eléctricos. Los autores recomendaron que las posibles aplicaciones del “Cuestionario de agresión” fueran exploradas en otros escenarios en donde la agresión es una conducta problemática.

Tipos de personalidad Una vez definida la personalidad como una constelación única de rasgos y estados, podríamos definir un **tipo de personalidad** como una constelación de rasgos y estados que es similar en cuanto al modelo a una categoría de personalidad identificada dentro de una taxonomía de personalidades. Mientras que los rasgos con frecuencia se examinan como si fueran *características* poseídas por un individuo, los tipos son en forma más clara *descripciones* de personas. Así, por ejemplo, describir a un individuo como “deprimido” tiene un significado diferente que describirlo como “de tipo deprimido”. El último término tiene implicaciones de más largo alcance respecto a los aspectos característicos del individuo, como sus puntos de vista acerca del mundo, su nivel de actividad, su capacidad para disfrutar la vida y su nivel de interés social.

SÓLO PIENSE...

¿Cuáles son los posibles beneficios de clasificar a la gente en tipos? ¿Qué posibles problemas pueden surgir de esto?

Al menos desde la clasificación de las personas hecha por Hipócrates la cual diferencia cuatro tipos (melancólicas, flemáticas, coléricas y sanguíneas) no ha habido escasez de tipologías de

la personalidad a través del tiempo. Una tipología concebida por Carl Jung (1923) se convirtió en la base para el Indicador de tipos de Myers-Briggs (MBTI; *Myers-Briggs Type Indicator*; Myers y Briggs, 1943/1962). Una suposición para conducir el desarrollo de esta prueba fue que las personas exhiben preferencias definidas en la forma en que perciben o se vuelven conscientes de, y juzgan o llegan a conclusiones acerca de personas, eventos, situaciones e ideas. De acuerdo con Myers (1962, p. 1), estas diferencias de percepción y juicio resultan en “diferencias correspondientes en sus reacciones, intereses, valores, necesidades y motivaciones, en lo que hacen mejor y en lo que les gusta hacer”. Por ejemplo, en un estudio diseñado para entender mejor la personalidad de los jugadores de ajedrez, el Indicador de tipos de Myers-Briggs fue aplicado a 2165 jugadores de ajedrez, incluyendo jugadores en el nivel de maestros y grandes maestros. Se encontró que los jugadores de ajedrez eran significativamente más introvertidos, intuitivos y reflexivos (en oposición al sentimiento) que los miembros de la población general. El investigador también descubrió que los maestros son más juiciosos de lo que se esperaría en la población general (Kelly, 1985).

John Holland (1973, 1985, 1999) argumentó que la mayoría de la gente puede ser categorizada dentro de uno de los seis siguientes tipos de personalidad: artística, emprendedora, investigadora, social, realista o convencional. Su prueba de Búsqueda autodirigida (*Self Directed Research*; SDR; Holland *et al.*, 1994) es un auxiliar autoadministrado, autoevaluado y autointerpretado que se utiliza para clasificar a la gente de acuerdo con este sistema y ofrecer una guía vocacional. Otra tipología de la personalidad, la cual tiene sólo dos categorías, fue planeada por los cardiólogos Meyer Friedman y Ray Rosenman (1974; Rosenman *et al.*, 1975). Ellos concibieron una **personalidad tipo A**, cuyas características son: competitividad, apresuramiento, inquietud, impaciencia, sensación de estar presionados por el tiempo y fuertes necesidades de logro y dominio. Una **personalidad Tipo B** tiene los rasgos opuestos al tipo A: afable o despreocupado. Un inventario a modo de autoevaluación llamado Muestra de actividades de Jenkins (JAS; Jenkins *et al.*, 1979) ha sido utilizado para clasificar a los respondientes como personalidades tipo A o tipo B.

La tipología de la personalidad que más ha atraído la atención de los investigadores y practicantes por igual está asociada con las calificaciones de una prueba llamada MMPI, y su sucesor, el MMPI-2 (las cuales estudiaremos luego). Los datos de la administración de estas pruebas, junto con otros, a menudo se discuten en términos de un patrón de calificaciones que surge de las subescalas. Este patrón es mencionado como *perfil*. En general, un **perfil** es una descripción narrativa, gráfica, en forma de tabla o mediante otra representación, de la medida en que una persona ha demostrado ciertas características sugeridas como resultado de la administración o aplicación de una herramienta (o herramientas) de evaluación.¹ En el término **perfil de la personalidad**, las características seleccionadas son de manera común rasgos, estados o tipos. Con referencia específica al MMPI, distintos perfiles de calificaciones están asociados con diferentes patrones de comportamiento. Así, por ejemplo, un perfil particular del MMPI designado como “2-4-7” está asociado con un tipo de individuo que tiene un historial de abuso de alcohol alternado con estados de sobriedad y autorreproche (Dahlstrom, 1995).

Estados de personalidad La palabra **estado** ha sido utilizada al menos en dos formas notablemente diferentes en la literatura de la evaluación de la personalidad. En uno de los usos, un estado de personalidad es una disposición psicodinámica inferida, designada para transmitir la cualidad dinámica del ello, yo y superyó en conflicto perpetuo. La evaluación de estas disposiciones psicodinámicas puede efectuarse mediante el uso de varias técnicas psicoanalíticas como la libre asociación, la asociación de palabras, el análisis simbólico del material de las entrevistas, el análisis de los sueños y el análisis de los errores de lengua, accidentes, bromas y olvidos (lapsus).

1. El verbo *perfilar* se refiere a la creación de tal descripción. El término **análisis del perfil** se refiere a la interpretación de patrones de calificaciones en una prueba o en una batería de prueba. El análisis del perfil se usa con frecuencia para generar hipótesis diagnósticas a partir de los datos de pruebas de inteligencia. El sustantivo **perfilador** se refiere a una ocupación: alguien que genera perfiles de personalidad de sospechosos de crímenes para ayudar al personal encargado de la aplicación de la ley en la captura de sospechosos.

En la actualidad, un uso más popular del término *estado* —y el único que utilizamos en el análisis que sigue— se refiere a la exhibición transitoria de algún rasgo de personalidad. Planteado en otra forma, el uso de la palabra *rasgo* presupone una predisposición conductual relativamente perdurable, mientras que el término *estado* es indicativo de una predisposición relativamente temporal (Chaplin *et al.*, 1988). Así, por ejemplo, podemos decir que Sally se halla “en un estado de ansiedad” antes de sus exámenes semestrales, aunque probablemente nadie que conozca bien a Sally la describiría como “una persona ansiosa”.

Medir los estados de personalidad equivale, en esencia, a una búsqueda y una evaluación de la fuerza de los rasgos que son de naturaleza relativamente transitoria o completamente específicos respecto a una situación. De modo relativo, pocas pruebas de personalidad existentes

buscan distinguir los rasgos de los estados. Un trabajo innovador en esta área fue realizado por Charles D. Spielberger y sus asociados (Spielberger *et al.*, 1980). Estos investigadores desarrollaron cierto número de inventarios de personalidad diseñados para distinguir varios estados de los rasgos. En el manual del Inventario de estado-rasgo de ansiedad (*State-Trait Anxiety Inventory*, STAI), por ejemplo, encontramos que *estado de ansiedad* se refiere a una experiencia transitoria de tensión debida a una situación particular. Por el contrario, *rasgo de ansiedad* o *tendencia a la ansiedad* se refiere a una característica de la personalidad relativamente estable o perdurable.

Los reactivos de la prueba STAI consisten en breves afirmaciones descriptivas y los sujetos son instruidos para que indiquen 1) cómo se sienten ahora o en este momento (y la intensidad del sentimiento) o 2) cómo se sienten en lo general (y que registren la frecuencia del sentimiento). Los coeficientes de confiabilidad de la prueba y la repetición de la misma reportados en el manual son consistentes con la premisa teórica de que el rasgo de ansiedad es la característica más perdurable, mientras que el estado de ansiedad es transitorio.

SÓLO PIENSE...

¿Considera los rasgos y los estados como dos entidades diferentes o considera los estados como “minimanifestaciones” de los rasgos?

Evaluación de la personalidad: algunas cuestiones básicas

¿Para qué tipo de empleo sería más adecuada una persona con este tipo de personalidad?

¿Este individuo está bien adaptado de manera suficiente para el servicio militar?

¿Qué factores emocionales y otros relacionados con la adaptación pueden ser responsables del nivel de rendimiento académico de este estudiante?

¿Qué patrón de rasgos y estados hace patentes este paciente de psicoterapia, y hasta qué grado puede ser considerado patológico este patrón?

¿Cómo afecta la personalidad de este paciente un trauma o compromiso neurológico?

Éstas son un ejemplo de la clase de preguntas que podrían conducir a la recomendación de una evaluación de la personalidad. De manera colectiva, estos tipos de casos de recomendación proporcionan una percepción hacia una pregunta más general en un contexto clínico, ¿por qué evaluar la personalidad?

Podríamos plantear la misma pregunta en el contexto de la investigación básica y encontrar otras posibles aplicaciones, a nivel mundial, de la evaluación de la personalidad. Por ejemplo, los aspectos de la personalidad podrían explorarse para identificar determinantes del conocimiento acerca de la salud (Beier y Ackerman, 2003), para categorizar distintitos tipos de compromiso en las relaciones de pareja (Frank y Brandstaetter, 2002), o para determinar la respuesta de un jugador a los vínculos más débiles de su equipo (Jackson y LePine, 2003). La evaluación de la personalidad es un elemento esencial en la investigación del desarrollo, ya sea para conocer el desarrollo de los rasgos a lo largo del tiempo (McCrae *et al.*, 2002) o para que estudie algunas características que son exclusivamente humanas como sería emitir un juicio moral (Eisenberg *et al.*, 2002). En el mundo empresarial, la evaluación de la personalidad es una herramienta clave del departamento de recursos humanos, en la cual se confía para contratar, despedir, promover, transferir y tomar otras decisiones relacionadas. Quizá en tanto han existido pruebas para medir

los intereses de las personas, han existido preguntas respecto a cómo esos intereses se relacionan con la personalidad (Larson *et al.*, 2002). En las organizaciones militares alrededor del mundo, el liderazgo es un rasgo buscado, y las pruebas de personalidad ayudan a identificar quién lo tiene (véase, por ejemplo, Bradley *et al.*, 2002; Handler, 2001). En un sentido más global, la investigación básica que implica la evaluación de la personalidad ayuda a validar o invalidar teorías de conducta y a generar nuevas hipótesis.

Más allá del *porqué* de la evaluación de la personalidad, hay otras cuestiones básicas que deben ser abordadas en cualquier reconocimiento de la tarea que esto implica. Las propuestas para la evaluación de la personalidad difieren en función de *quién* está siendo evaluado, *qué* se está evaluando, *dónde* se realiza la evaluación y *cómo* se efectúa. Veamos con mayor detenimiento estas cuestiones.

¿Quién?

¿Quién está siendo evaluado en realidad? ¿El examinado puede ser alguien distinto al sujeto de la evaluación?

Algunos métodos de evaluación de la personalidad dependen de la autodescripción del propio evaluado. Las personas evaluadas pueden responder preguntas durante una entrevista y cuestionarios por escrito, rellenar cuadros en formas de respuesta computarizadas o separar tarjetas con varios términos en ellas —todo con el objetivo final de proporcionar al evaluador una descripción relacionada con la personalidad—. Por el contrario, otros métodos de evaluación de la personalidad dependen de informantes distintos a la persona que está siendo evaluada para que proporcionen datos relacionados con la personalidad. Así, por ejemplo, se puede pedir a los padres o maestros que participen en la evaluación de la personalidad de un niño proporcionando descripciones, valoraciones, juicios, opiniones e impresiones relevantes de la personalidad del niño. Estas dos diferentes propuestas para la evaluación de la personalidad varían respecto al referente primario del respondiente. En el caso de la autodescripción, el yo es el referente primario.

El yo como el referente primario Las personas, de manera característica, vivencian la evaluación de la personalidad de modo que ellas, al igual que el evaluador, puedan aprender algo acerca de quiénes son. En muchos casos, la evaluación, o algún aspecto de ella, requiere de la **autodescripción** o de un proceso en el que la información del evaluado sea proporcionada por los mismos evaluados. La información de la autodescripción puede ser obtenida mediante los diarios personales que lleven los evaluados o de las respuestas a preguntas o reactivos en forma escrita o verbal. En algunos casos, la información buscada por el evaluador es tan privada que sólo las mismas personas evaluadas son capaces de proporcionar. Por ejemplo, cuando los investigadores indagaron acerca de la consistencia psicométrica de la Escala de búsqueda de sensación sexual con una muestra de estudiantes universitarios, sólo los estudiantes mismos pudieron proporcionar la información sumamente personal que se requería. Los investigadores consideraron su dependencia al informe personal como una posible limitación del estudio, pero observaron que esta metodología “ha sido la práctica normal en esta área de investigación porque no existe una regla de oro para verificar los reportes de conductas sexuales de los participantes” (Gaither y Sellbom, 2003, p. 165).

Los métodos de autodescripción son utilizados de manera común para explorar el *autoconcepto* de un evaluado. El **autoconcepto** puede ser definido como “nuestras actitudes personales, así como las creencias, opciones y pensamientos relacionados que tenemos sobre nosotros mismos”. Podemos derivar inferencias acerca del autoconcepto de una persona evaluada a partir de muchas herramientas de evaluación. Sin embargo, la herramienta de elección es de manera común una **medida de autoconcepto**, un instrumento diseñado para producir información relevante sobre cómo un individuo se percibe respecto a otras variables psicológicas elegidas. Los datos de ese instrumento son, por lo general, interpretados en el contexto de cómo otros se aprecian a sí mismos teniendo las mismas u otras variables similares a las del evaluado. En la Prueba de autoconcepto de Beck (Beck Self-Concept Test, BST; Beck y Stein, 1961), por ejemplo, a quienes responden se les pide que se comparen con otras personas respecto a variables como apariencia, conocimiento y capacidad para contar chistes.

Se han elaborado varias medidas de autoconcepto para los niños. Algunas pruebas representativas incluyen la Escala de autoconcepto de Tennessee (*Tennessee Self-Concept Scale*) y la Escala de autoconcepto de Piers-Harris (*Piers-Harris Self-Concept Scale*). La última, contiene 80 autoafirmaciones (como “No tengo ningún amigo”) a las que alumnos del tercero al doceavo grados responden “sí” o “no” dependiendo de si la afirmación se aplica a ellos. El análisis factorial de la prueba indicó que los reactivos abarcan seis áreas generales de autoconcepto: comportamiento, condición intelectual y escolar, apariencia física y atributos, ansiedad, popularidad, y felicidad y satisfacción.

Algunas medidas de autoconcepto están basadas en la idea de que los estados y los rasgos relacionados con el autoconcepto son en gran medida dependientes del contexto, es decir, siempre cambian como resultado de la situación particular (Callero, 1992). El término **diferenciación de autoconcepto** se refiere al grado en que una persona tiene autoconceptos diferentes en distintas funciones (Donahue *et al.*, 1993). Es probable que las personas caracterizadas como *sumamente diferenciadas* se perciban a sí mismas en formas bastante diferentes en varias funciones. Por ejemplo, un hombre de negocios sumamente diferenciado, mayor de cuarenta años, puede percibirse como motivado y muy trabajador en su papel profesional, conformista y complaciente con las

personas en su carácter de hijo, y emotivo y apasionado como esposo. Por el contrario, las personas cuyo concepto del yo no es muy diferenciado tienden a percibirse de manera equivalente en sus diferentes funciones sociales. De acuerdo con Donahue *et al.* (1993), las personas con bajos niveles de diferenciación de autoconcepto tienden a ser más sanas desde el punto de vista psicológico, quizá debido a su sentido del yo más unificado y coherente.

Si asumimos que los evaluados tienen de manera razonable una idea exacta de su propio pensamiento y comportamiento, y que están motivados para responder los reactivos de la prueba de modo honesto, las medidas de autodescripción pueden ser muy valiosas. Una autodescripción sincera y precisa por parte del evaluado puede mostrar lo que ese individuo está pensando, sintiendo y haciendo. Por desgracia, algunos evaluados pueden de manera intencional o no, elaborar imágenes distorsionadas de sí mismos en las mediciones autodescriptivas.

Considere lo que pasaría si los empresarios confiaran en las descripciones de los solicitantes de empleo respecto a su personalidad y capacidad para realizar un trabajo en particular. Los patrones podrían ser inducidos a creer que han encontrado un sinnúmero de aspirantes

perfectos. Muchos solicitantes de empleo, al igual que personas en contextos tan diversos como reuniones de bachillerato, bares para solteros y audiencias para obtener la custodia de un hijo, intentan “hacerse pasar por buenos” cuando se presentan ante otra gente.

El otro lado de la moneda de “hacerse pasar por buenos” es “hacerse pasar por malos”. Los litigantes en acciones civiles que alegan daños pueden buscar altas adjudicaciones económicas

como compensación por el supuesto dolor, sufrimiento y angustia emocional padecidos, todo lo cual puede ser exagerado y dramatizado para convencer al juez y al jurado. El acusado de una acción criminal puede que prefiera ser recluido en una institución mental que en una prisión (o que a ser sentenciado a la pena capital), y elegir de manera estratégica una defensa por demencia —acompañada por comportamientos y alegatos que hagan que la defensa sea lo más convincente posible—. Una persona indigente que prefiere el ambiente de un hospital mental al de la calle puede intentar hacerse pasar por malo en las pruebas y entrevistas, pero si fracasa en ese intento sería dado de alta. En los días de reclutamiento militar es común que quienes se niegan a ser seleccionados intenten hacerse pasar por malos frente a las evaluaciones psiquiátricas en sus esfuerzos por ser excluidos del reclutamiento.

Algunos examinados pueden en realidad estar incapacitados para responder de manera precisa a las preguntas de la autodescripción. Quizá carezcan de comprensión, por ejemplo, debido a ciertas condiciones médicas o psicológicas en el momento de la evaluación. Por el contrario, otros individuos que responden la prueba tal vez hayan sido favorecidos con una abundancia

SÓLO PIENSE...

Sumamente diferenciado o no muy diferenciado en el autoconcepto. ¿Cuál cree usted que sea preferible? ¿Por qué?

SÓLO PIENSE...

¿Alguna vez ha intentado “hacerse pasar por bueno” en su comportamiento, dentro o fuera de un contexto de evaluación?

de autopercepciones por tanto pueden transmitir las con facilidad y destreza en las mediciones de autodescripción. Para este último grupo de individuos, dichas mediciones, de acuerdo con Burisch (1984), no revelarán nada que el evaluado no sepa ya. Por supuesto, Burisch (1984) puede haber exagerado el caso. Aún las personas con abundancia de autopercepción pueden beneficiarse del aprendizaje de sí mismas a partir de la perspectiva de otros.

Otra persona como referente En algunas situaciones, el mejor método disponible para la evaluación de la personalidad, el comportamiento o ambos, implica descripciones hechas por terceros como pueden ser los padres, maestros, compañeros, supervisores, el o la cónyuge o un observador capacitado. Considere, por ejemplo, la evaluación de un niño con dificultades emocionales. El niño puede ser incapaz o no estar dispuesto a completar ninguna prueba (autodescripción, desempeño o cualquier otra) que sería de valor para hacer una determinación válida respecto a su estado emocional. Incluso los datos de su historia clínica pueden ser de valor mínimo, debido a que los problemas pueden ser tan sutiles en cuanto que sólo se hacen evidentes después de una observación cuidadosa y sostenida. En tales casos, puede ser valioso el uso de una prueba en la que el examinado sea un informante y no el sujeto de estudio.

El Inventario de personalidad para niños (*Personality Inventory for Children*, PIC), así como su edición revisada, el PIC-2 son ejemplos de una clase de entrevista estandarizada dirigida a los padres de un niño. Aunque el niño es el sujeto de la prueba, el respondiente es alguno de los padres (normalmente la madre), el tutor u otro adulto calificado para responder preguntas con referencia al comportamiento característico del niño.² La prueba consiste en una serie de reactivos verdadero/falso diseñados para que estén libres de sesgo racial y de género. Los reactivos pueden ser aplicados por medio de computadora o por escrito. Los resultados de la prueba producen calificaciones que arrojan luz sobre la validez de los patrones de respuesta del examinado, así como información clínica. Diversos estudios atestiguan la validez del PIC en cuanto al propósito deseado (Kline *et al.*, 1992, 1993; Lachar y Wirt, 1981; Lachar *et al.*, 1985; Wirt *et al.*, 1984). Sin embargo, como con cualquier prueba que confía en las observaciones y el juicio de un evaluador, también se han expresado algunas preocupaciones acerca de este instrumento (Achenbach, 1981; Cornell, 1985).

En general, existen varias observaciones que deben considerarse cuando una persona se encarga de evaluar a otra. Estas observaciones de ninguna manera están limitadas al área de la evaluación de la personalidad. En vez de eso, en cualquier situación en la que un individuo se encarga de evaluar a otro, es importante entender la dinámica de la situación. Aunque el reporte de un estimador puede proporcionar información valiosa sobre el evaluado, también puede ser valioso examinar el origen de esa información.

Algunos evaluadores pueden tender a ser favorablemente condescendientes y generosos, rigurosamente severos o relativamente neutrales en sus evaluaciones. Los sesgos generalizados para evaluar en una dirección particular son conocidos por las expresiones **lenidad** o **error de generosidad** y **error de severidad**. La tendencia general a situar a todos los evaluados cercanos al punto medio o media en una escala de evaluación se denomina **error de tendencia central**. En algunas situaciones, un conjunto particular de circunstancias puede crear un sesgo determinado. Así, por ejemplo, un maestro podría estar dispuesto a juzgar a un alumno en forma muy favorable, debido a que la hermana mayor del alumno fue la favorita del maestro en una clase anterior. Esta variedad de sesgo de respuesta favorable en ocasiones se le conoce como **efecto de halo**.

2. El PIC fue publicado originalmente en 1958, aunque no se publicó un manual formal de la prueba sino hasta 1977. Cinco años después, se publicó un manual complementario con revisión del formato (Lachar, 1982). Desde entonces persistentemente la prueba ha sido denominada como la PIC. Esta nota pretende corregir la confusión creada por referencias erróneas al PIC como el "PIC-R" y el "PIC-Revisado" (Kline *et al.*, 1985, 1993; Kline y Lachar, 1992; Lachar *et al.*, 1985, 1986; LaCombe *et al.*, 1991; Wirt *et al.*, 1984) anterior a la publicación del Inventario de personalidad para niños, segunda edición (PIC-2) en 2001. Por cierto, en el curso de una llamada telefónica al editor de la prueba nos enteramos de que ésta es conocida en toda la oficina como el "PIC", que se pronuncia como la palabra inglesa *pick*.




Figura 11-2
Estimaciones del propio
autointerés personal

“Los monstruos y los gritones siempre han funcionado bien para mí; yo le doy mi aprobación, Roger”.

Los evaluadores pueden hacer juicios sesgados, en forma consciente o inconsciente, simplemente porque es por su propio interés hacerlo así (véase la figura 11-2). Los terapeutas que creen apasionadamente en la eficacia de una propuesta terapéutica particular pueden estar más dispuestos que otros a considerar los beneficios de esa propuesta. Quienes promueven proposiciones alternativas pueden estar más dispuestos a ver los aspectos negativos de ese mismo tratamiento.

Otros numerosos factores pueden contribuir al sesgo en las evaluaciones realizadas por un examinador. Éste puede sentir que está compitiendo con, que es atraído físicamente hacia, o rechazado físicamente por el sujeto evaluado. Éste, puede también no tener los antecedentes apropiados, la experiencia y el entrenamiento necesarios para la tarea particular, por tanto sus juicios pueden estar limitados por su nivel general de meticulosidad y disposición a dedicar el tiempo y esfuerzo requeridos para hacer el trabajo en forma apropiada. El evaluador puede albergar predilecciones concernientes a varios estereotipos. La subjetividad basada en las preferencias subjetivas y gusto propios del evaluador también puede influir en sus juicios. Los características que se califican con un “10 perfecto” en la opinión de una persona pueden más bien representar un “mediocre 5” ante los ojos de otra persona. Si esa marcada diferencia de opiniones ocurre con frecuencia respecto a un instrumento en particular, podríamos esperar que esto se reflejara en bajos coeficientes de confiabilidad entre evaluadores. Probablemente sea deseable hacer una revisión de los criterios utilizados para hacer estimaciones y ver cuán específicos son.

Otro factor a considerar respecto a las evaluaciones cuando otra persona es el referente, es el contexto de la evaluación. Diferentes evaluadores pueden tener perspectivas distintas sobre el individuo a quien están evaluando en virtud del contexto en el que lo consideran de manera característica. Un padre podría indicar en una escala de estimación que un niño es hiperactivo,

mientras que el maestro del mismo niño podría señalar utilizando la misma escala de estimación que el nivel de actividad del niño está dentro de los límites normales. ¿Pueden ambos estar en lo correcto?

La respuesta es afirmativa de acuerdo con un metaanálisis de 119 artículos en la literatura académica (Achenbach *et al.*, 1987). Diferentes informantes pueden tener diferentes perspectivas sobre los sujetos de la valoración. Estas diferentes perspectivas se derivan de la observación e interacción con los sujetos en diferentes contextos. El estudio también observó que los evaluadores tendían a estar más de acuerdo acerca de las dificultades de los niños pequeños (6 a 11 años de edad) que respecto a las de los niños mayores y adolescentes y a mostrar un mayor acuerdo sobre un niño exhibiendo problemas de autocontrol (como hiperactividad y maltrato a otros niños) en contraste con los problemas de “control excesivo” (como ansiedad o depresión). Los investigadores exhortaron a los profesionales a considerar en la evaluación las diferencias que surgen a partir de diversas perspectivas como algo más que un error en el proceso de valoración; los alentaron a emplear las diferencias dentro de un contexto específico en la planeación del tratamiento. Muchas de sus ideas respecto a la evaluación dependiente del contexto y el tratamiento fueron incorporadas en el Sistema de evaluación multiaxial basado empíricamente (*Multiaxial Empirically Based Assessment System*) de Achenbach (1993). Este sistema es una propuesta para la evaluación de niños y adolescentes que incorpora evaluaciones cognoscitivas y físicas del sujeto, una autodescripción del mismo y evaluaciones realizadas por padres y maestros. Además, pueden incluirse medidas de desempeño del niño solo, con la familia o en el salón de clases.

Sin tomar en cuenta si él mismo u otra persona es el sujeto de estudio, un contexto importante de la evaluación que el estimador debe tener en mente es el contexto cultural.

SÓLO PIENSE...

¿Cómo podría ser evaluado de manera diferente con la misma variable en diversos contextos?

Los antecedentes culturales de los evaluados En años recientes, los creadores y los administradores de pruebas han evidenciado una creciente sensibilidad hacia las cuestiones de la diversidad cultural. Ha surgido un cierto número de preocupaciones respecto al uso de las pruebas de personalidad y otras herramientas de evaluación con miembros de poblaciones diversas desde el punto de vista cultural y lingüístico (Anderson, 1995; Campos, 1989; Greene, 1987; Hinkle, 1994; Irvine y Berry, 1983; Lonner, 1985; López y Hernández, 1987; Sundberg y González, 1981). ¿Qué tan imparcial o generalizable es un instrumento o técnica de medición en particular con algún miembro de un grupo cultural específico? Cómo se desarrolló una prueba, cómo es aplicada y cómo son interpretadas las calificaciones en ella, son todas interrogantes que deben ser planteadas cuando se considere lo apropiado de aplicar una prueba específica de personalidad a miembros de poblaciones diversas desde el punto de vista cultural y lingüístico. Posteriormente continuaremos explorando más a fondo estas y otras preguntas relacionadas en este capítulo y a lo largo de todo el libro. En el capítulo 13, por ejemplo, consideramos en detalle el significado de una *evaluación psicológica culturalmente informada*.

¿Qué?

¿Qué se valora cuando se realiza una evaluación de la personalidad? Para muchas pruebas de personalidad, es significativo responder a esta pregunta con referencia al área primaria de contenido ejemplificada por la prueba, así como a la porción destinada a medir aspectos del estilo de respuesta general del examinado.

Muestreo del área primaria de contenido Las mediciones de personalidad son herramientas usadas para obtener una mayor comprensión sobre una amplia gama de pensamientos, sentimientos y comportamientos asociados con todos los aspectos de la experiencia humana. Algunas pruebas están diseñadas para medir rasgos particulares (como la introversión) o estados (como la ansiedad provocada por las pruebas), mientras que otras se enfocan en descripciones de comportamiento, por lo general en contextos particulares. Por ejemplo, una lista de verificación basada en

Tabla 11-1
Una muestra de estilos de respuesta a una prueba

Nombre del estilo de respuesta	Explicación: una tendencia a...
Respuesta socialmente deseable	Presentarse uno mismo bajo una luz favorable (socialmente aceptable o deseable)
Aquiescente	Estar de acuerdo con cualquier cosa que se le presente
No aquiescente	Estar en desacuerdo con cualquier cosa que se le presente
Desviante	Dar respuestas inusuales o poco comunes
Extrema	Hacer evaluaciones extremas, en oposición a intermedias, en una escala de estimación
Arriesgada/cautelosa	Conjeturar —o no conjeturar— cuando tiene dudas
Demasiado positiva	Afirmar una virtud extrema describiéndose a sí mismo de una manera superlativa (Butcher y Han, 1995)

la observación puede concentrarse en los comportamientos en el salón de clases asociados con el movimiento con el fin de evaluar la hiperactividad en un niño. En el siguiente capítulo se presenta un estudio más amplio de las medidas conductuales.

Muchas pruebas contemporáneas de personalidad, en especial las que pueden ser calificadas e interpretadas por medio de una computadora, están diseñadas para medir no sólo el rasgo seleccionado u otra variable de personalidad, sino algún aspecto del estilo de respuesta del examinado. Por ejemplo, además de las escalas clasificadas como *Introversión* y *Extroversión*, una prueba de introversión/extroversión podría contener otras escalas. Estas otras escalas podrían estar diseñadas para arrojar luz sobre la honestidad con que las personas respondieron la prueba, lo consistente de sus respuestas a las preguntas y otros asuntos relacionados con la validez de los hallazgos y resultados obtenidos. Estas medidas del patrón de respuesta también son conocidas como *medidas de clase de respuesta* o *estilo de respuesta*. Veamos algunos de estos estilos de respuesta diferentes de quienes responden las pruebas, así como las escalas usadas para identificarlos.

Estilos de respuesta del examinado El **estilo de respuesta** se refiere a una tendencia a responder a un reactivo de alguna prueba o a una pregunta de entrevista de alguna manera característica sin importar el contenido del reactivo o pregunta. Por ejemplo, un individuo puede ser más inclinado a responder *sí* o *verdadero* en lugar de *no* o *falso* en una prueba de respuestas breves. Este particular modo de responder se caracteriza como condescendiente. La tabla 11-1 muestra un listado de otros estilos de respuesta identificados.

Manejo de la impresión es un término usado para describir la intención de manipular las impresiones de otros por medio de “la exposición selectiva de alguna información (que podría ser información falsa)... junto con la supresión de [otra] información” (Braginsky *et al.*, 1969, p. 51). En el proceso de evaluación de la personalidad, es posible que los evaluados empleen cualquier cantidad de estrategias para manipular la impresión por cualquier número de razones. Paulhus (1984, 1986, 1990; Paulhus y Levitt, 1987) y sus colegas han explorado el manejo de la impresión al responder las pruebas, así como los fenómenos relacionados para realizarla (la afirmación de atributos positivos), negación (el rechazo de atributos negativos) y el autoengaño (“la tendencia a dar autodescripciones sesgadas en forma favorable pero sostenidas en forma honesta”) (Paulhus y Reid, 1991, p. 307). Los examinados implicados en el manejo de la impresión están exhibiendo, en el sentido más amplio, un estilo de respuesta (Jackson y Messick, 1962).

Algunas pruebas de personalidad contienen reactivos diseñados para detectar diferentes tipos de estilos de respuesta. Así, por ejemplo, responder *verdadero* a un reactivo como “Pasé el verano en Bagdad” plantearía diversas interrogantes, como: ¿El examinado entendió las instrucciones? ¿Tomó en serio la prueba? ¿Respondió *verdadero* a todos los reactivos? ¿Respondió al azar? ¿Manipula otros reactivos con poca frecuencia? El análisis del protocolo entero ayudará a responder estas interrogantes.

Responder a una prueba de personalidad de manera inconsistente, contraria o aleatoria, así como intentar hacerse pasar por bueno o malo puede afectar la validez de las interpretaciones de los datos de la prueba. Debido a que un estilo de respuesta puede afectar la validez del resulta-

do, a un particular tipo de medida de respuesta se le conoce como *escala de validez*. La **escala de validez** puede ser definida como la subescala de una prueba diseñada para ayudar en los juicios respecto a qué tan honesto fue el evaluado en sus respuestas y si las respuestas observadas fueron producto de un conjunto de respuestas descuidadas, de esfuerzos deliberados por engañar o de un malentendido no intencional. Las escalas de validez pueden proporcionar un tipo de indicación estenográfica de la medida de honestidad, prontitud y meticulosidad con que el examinado respondió a los reactivos de la prueba. Algunas pruebas, como el MMPI y su edición revisada (que estudiaremos en breve), contienen múltiples escalas de validez. Aunque hay quienes cuestionan la utilidad de evaluar de manera formal los estilos de respuesta (Costa y McCrae, 1997; Rorer, 1965), quizá la opinión más común es que éstos son importantes en sí mismos por lo que revelan acerca de los examinados. Como observó Nunnally (1978, p. 660), “En la medida en que dichas variables estilísticas pueden ser medidas en forma independiente del contenido relacionado con variables no estilísticas o en la medida en que de algún modo pueden separarse a partir de la varianza de otros rasgos, podrían demostrar su utilidad como medidas de rasgos de personalidad”.

¿Dónde?

¿Dónde se efectúan las evaluaciones de la personalidad? De manera tradicional, la evaluación de la personalidad, al igual que otras variedades de evaluación, se ha llevado a cabo en lugares como escuelas, clínicas, hospitales, laboratorios de investigación académica, centros de orientación laboral y vocacional, y en las oficinas de psicólogos y orientadores. Además de estos escenarios tradicionales, los evaluadores contemporáneos pueden encontrarse observando el comportamiento y haciendo evaluaciones en medios naturales que varían del propio hogar del evaluado (Marx, 1998; McElwain, 1998; Polizzi, 1998) hasta la celda de un encarcelado en alguna prisión (Glassbrenner, 1998). Como veremos en la exposición de la evaluación conductual en el capítulo siguiente, la observación conductual puede efectuarse casi en cualquier parte.

¿Cómo?

¿Cómo se estructuran y efectúan las evaluaciones de la personalidad? Observemos varias facetas de esta cuestión multidimensional, comenzando con los temas relacionados con el alcance y la teoría. Después se examinarán los procedimientos y los formatos de los reactivos empleados, el marco de referencia de la evaluación y la calificación e interpretación.

Alcance y teoría Una dimensión del *cómo* de la evaluación de la personalidad se relaciona con su alcance. La esfera de acción de una evaluación puede ser muy amplia, buscando obtener una especie de inventario general de la personalidad de un individuo. El “Inventario Psicológico de California” (*California Psychological Inventory, CPI*) es un ejemplo de un instrumento con un alcance relativamente amplio. Esta prueba contiene 434 reactivos con formato de verdadero/falso y está diseñada para producir información de muchas variables relacionadas con la personalidad como responsabilidad, autoaceptación y dominio.

En contraste con los instrumentos y procedimientos diseñados para inventariar varios aspectos de la personalidad, existen aquellos que tienen un alcance mucho más estrecho. Estos instrumentos pueden haber sido diseñados para enfocarse de manera limitada en tan sólo un pequeño y particular aspecto de la personalidad. Como un ejemplo, considere las pruebas diseñadas para medir una variable de la personalidad llamadas *locus de control* (Rotter, 1966; Wallston *et al.*, 1978). **Locus** (que significa “lugar” o “sitio”) **de control** es la percepción que tienen las personas sobre el origen de las cosas que les suceden. En general, se dice que las personas que se ven a sí mismas como responsables en gran medida de lo que les sucede tienen un *locus de control interno*. Y de las personas que tienden a atribuir lo que les sucede a factores externos (como el destino o la acción de otros) se dice que tienen un *locus de control externo*. Así, por ejemplo, se esperaría que una persona que confía en el valor de los cinturones de seguridad, en oposición a la contraparte que no utiliza el cinturón de seguridad, obtenga una calificación

cercana al extremo interno en oposición al externo del continuo en una medida válida de sitio de control. La investigación con medidas diferentes para ubicar el sitio de control ha producido implicaciones intrigantes respecto a la utilidad de este constructo, en especial respecto a la salud y el estilo de vida.

SÓLO PIENSE...

Suponga que desea aprender tanto como sea posible sobre la personalidad de un evaluado a partir de una prueba de personalidad que es limitada en su alcance. ¿En qué aspecto único de la personalidad cree que sea más importante enfocarse?

¿Hasta qué punto una prueba de personalidad está basada en una teoría o está relativamente desprovista de una? Los instrumentos usados en las pruebas y la evaluación de la personalidad varían en la medida en que se basan en una teoría de la personalidad. Algunas están basadas por completo en una teoría y otras relativamente carecen de una. Un ejemplo de un instrumento basado en una teoría es la Prueba de dibujos de Blacky (*Blacky Pictures Test*; Blum, 1950). Esta prueba consiste en una especie de dibujos animados de Blacky, un perro, en varias situaciones, en la que cada imagen fue diseñada para evocar fantasías asociadas con varios temas psicoanalíticos. Por ejemplo, una tarjeta describe a Blacky con un cuchillo abalanzándose sobre su rabo, una escena que, de acuerdo

con el autor de la prueba, fue diseñada para rememorar material relacionado con el concepto psicoanalítico de ansiedad por castración. La tarea del respondiente es elaborar historias en respuesta a dichas tarjetas, y luego las historias son analizadas de acuerdo con los lineamientos establecidos por Blum (1950). En la actualidad la prueba es pocas veces utilizada, pero la citamos aquí como una ilustración particularmente dramática y gráfica de cómo una teoría de la personalidad (en este caso, la teoría psicoanalítica) puede saturar una prueba.

La otra cara de la moneda de la saturación de una prueba es la prueba de personalidad que relativamente carece de una teoría. Una prueba que presenta ese rasgo es la prueba de personalidad más popular utilizada en estos días: el Inventario multifásico de la personalidad Minnesota (*Minnesota Multiphasic Personality Inventory*, MMPI), tanto en su versión original como en la edición revisada, la cual analizaremos luego en toda su amplitud en este capítulo. Streiner (2003a) se refirió a esta prueba como “el epítome de un ateuórico ‘plato polvoriento de empirismo’” (p. 218). Más tarde explicaremos por qué. Por ahora tan sólo señalaremos una ventaja de una herramienta ateuórica de la evaluación de la personalidad: permite a los usuarios de pruebas, en caso de que así lo deseen, imponer sus preferencias teóricas personales en la interpretación de los resultados obtenidos.

Prosiguiendo con otro aspecto del cómo en la evaluación de la personalidad, desviémonos a un aspecto básico de los métodos utilizados.

Procedimientos y formatos de reactivos La personalidad puede ser evaluada por muchos métodos diferentes como entrevistas cara a cara, pruebas aplicadas por medio de computadora, observación conductual, pruebas a lápiz y papel, valoración de datos aportados por la historia clínica, valoración de datos de portafolio y registro de respuestas fisiológicas. El equipo requerido para la evaluación varía en gran medida dependiendo del método empleado. En una técnica, por ejemplo, todo lo que puede requerirse es una hoja de papel en blanco y un lápiz. Al evaluado se le pide que dibuje a una persona y el evaluador hace inferencias sobre la personalidad del evaluado a partir del dibujo. Otras propuestas para la evaluación, ya sea en interés de la investigación básica o para propósitos más complicados pueden ser mucho más elaboradas respecto al equipo que requieren (figura 11-3).

Las mediciones de la personalidad varían en función del grado de *estructura* incorporada en ellas. Por ejemplo, la personalidad puede ser medida mediante una entrevista, pero también por medio de una **entrevista estructurada**. En el último método, el entrevistador generalmente debe seguir una guía y tiene poca libertad para plantear preguntas que no se encuentren en esa guía. La variable de estructura también es aplicable a las tareas que se le ordena realizar al evaluado. En algunas propuestas para la evaluación de la personalidad, las tareas son directas, altamente estructuradas y sin ambigüedades. He aquí un ejemplo de una de esas tareas: *Responda sí o no a las siguientes preguntas*.

En otras aproximaciones a la personalidad, lo que se requiere del evaluado no es tan directo, ni muy estructurado e intencionalmente ambiguo. He aquí un ejemplo de una tarea poco estruc-



Figura 11-3
Aprendizaje acerca de la personalidad en el campo de manera literal

Durante la segunda guerra mundial, el personal de evaluación de la Oficina de Servicios Estratégicos (Office of Strategic Services, OSS) seleccionó agentes secretos estadounidenses utilizando varias medidas. Una de ellas fue utilizada para evaluar la habilidad de liderazgo y la estabilidad emocional en el medio ambiente, incluía una simulación que implicaba la reconstrucción de un puente caído. A los candidatos se les proveyó en forma deliberada con insuficiente material para reconstruir el puente. En algunos casos, los “asistentes”, quienes en realidad formaban parte del experimento, frustraron los esfuerzos de los candidatos.

turada: Entregue al evaluado una serie de manchas de tinta y pregúntele: *¿Qué podría ser esto?*

El mismo rasgo o constructo de la personalidad puede ser medido con diferentes instrumentos en distintas formas. Considere las muchas formas posibles para determinar cuán agresiva es una persona. La medición de este rasgo podría hacerse con diversos métodos, entre ellos la aplicación de una prueba con papel y lápiz, mediante computadora, una entrevista con el evaluado, una entrevista con los familiares, amigos y otras personas relacionadas con él, análisis de los expedientes oficiales y otros datos de su historia personal y familiar, una prueba computarizada, observación acerca de la conducta y experimentación en el laboratorio. Por supuesto, los criterios de lo que constituye el rasgo medido, en este caso el de agresión, tendrían que ser definidos en forma rigurosa con anticipación. Después de todo, los rasgos y constructos psicológicos pueden ser, y han sido, definidos en muchas formas diferentes y de manera aparente casi todas estas definiciones tienden a ser dependientes del contexto. Por ejemplo, *agresivo* puede ser definido en formas que varían desde hostil y violento (como en el “recluso agresivo”) hasta audaz y emprendedor (como en el “vendedor agresivo”). Este rasgo de la personalidad, al igual que muchos otros, puede o no ser deseable desde el punto de vista social; eso depende por completo de su contexto.

En la evaluación de la personalidad, así como en la de otras áreas, la información puede ser recabada y las preguntas ser respondidas de distintas maneras. Por ejemplo, un investigador o un practicante interesado en aprender sobre el grado en el que los respondientes dependen del medio ambiente que les rodea, pueden construir un complicado artefacto que funciona a la vez como silla y cuarto reclinable, el mismo que usted recordará del capítulo 1 (figura 1-6). En beneficio de tiempo y gasto, un proceso equivalente administrado mediante lápiz y papel o computadora, puede ser más práctico para uso cotidiano. En la sección *Psicometría cotidiana* de este capítulo, explicamos algunos de los formatos de reactivos más comunes empleados en el estudio de la personalidad y las variables psicológicas relacionadas. Tenga en mente que aunque estamos utilizando estos formatos para ilustrar las distintas maneras en que se ha estudiado la personalidad, algunos también se han empleado en otras áreas de evaluación.

Marco de referencia Otra variable relevante del *cómo* de la medición de la personalidad, tiene que ver con el *marco de referencia* de la evaluación. En el contexto del formato de reactivo y la evaluación en general, el **marco de referencia** puede ser definido como los aspectos del núcleo de exploración, como el marco de tiempo (el pasado, el presente o el futuro), así como otras cuestiones

SÓLO PIENSE...

¿Directo o ambiguo? Como evaluador, ¿cuál de los dos enfoques en la evaluación de la personalidad le atrae más? ¿Por qué?

Algunos formatos comunes para reactivos

¿Cómo puede ser evaluada la personalidad? Aquí incluimos algunos de los tipos de formatos de reactivos más característicos.

REACTIVO 1

Disfruto salir y estar entre la gente. VERDADERO FALSO

Este reactivo ilustra el formato verdadero/falso. ¿Su reacción fue algo como “he pasado por eso, he hecho eso” cuando vio este reactivo?

REACTIVO 2

Trabajar con compañeros de su comunidad en la organización y la realización de un paseo acostumbrado. ME GUSTA ME DISGUSTA

Este reactivo de dos opciones está diseñado para rememorar información acerca de lo que al respondiente le gusta y lo que le disgusta . Es un formato común de los inventarios de intereses, en particular en aquellos utilizados por los consejeros vocacionales.

REACTIVO 3

Cómo me siento entre otras personas cuando estoy fuera

Cálido(a)	___:___:___:___:___:___	Frío(a)
Tenso(a)	___:___:___:___:___:___	Relajado(a)
Débil	___:___:___:___:___:___	Fuerte
Traje de Brooks Brothers	___:___:___:___:___:___	Camisa hawaiana

Este formato de reactivo, llamado de **diferencial semántico** (Osgood *et al.*, 1957), se caracteriza por adjetivos bipolares separados por una escala de puntuación de 7 en donde los respondientes seleccionan un punto para indicar su respuesta. Este tipo de reactivo es útil para estimar la fuerza, el grado o la magnitud de la dirección de una respuesta particular y tiene aplicaciones que varían desde descripciones de autoconcepto hasta estudios de opinión.

REACTIVO 4

Disfruto salir y estar entre la gente.

0

Me interesa aprender sobre arte.

REACTIVO 5

Estoy deprimido la mayor parte del tiempo.

0

Estoy ansioso la mayor parte del tiempo.

Éstos son dos ejemplos de reactivos escritos en un **formato de opción forzada**, en donde de manera ideal cada una de las dos opciones (puede haber más de dos opciones) es igual en atractivo social. El Inventario de preferencias personales de Edwards (*Edwards Personal Preference Schedule*; Edwards, 1953) es una prueba clásica de opción forzada. Edwards (1957a, 1957b, 1966) describió en detalle cómo determinó los reactivos de esta prueba para que fueran equivalentes en atractivo social.

REACTIVO 6

- desobediente
- necesitado
- negativo
- new age
- irritante
- ágil
- improductivo
- imposibilitado

Aquí se ilustra un reactivo escrito en un formato de lista de verificación de adjetivos. Los respondientes marcan los rasgos que se aplican a ellos.

contextuales que tienen que ver con personas, lugares y acontecimientos. Quizá para la mayor parte de las medidas de personalidad, el marco de referencia para el evaluado puede ser descrito con frases como *qué es* o *cómo estoy en este momento*. Sin embargo, algunas técnicas de medición se adaptan con facilidad para utilizar marcos de referencia alternativos, como *qué podría ser (yo) de manera ideal, cómo soy en la oficina, cómo me ven los demás, cómo veo a los demás*, etcétera. Obtener información de la autodescripción a partir de diferentes marcos de referencia es, en sí misma, una forma de elaborar información relacionada con estados y rasgos. Por ejemplo, al comparar la autopercepción en el presente contra lo que se anticipa para el futuro, los evaluados que afirman que se convertirán en mejores personas pueden suponerse más optimistas que los evaluados que reportan una tendencia inversa.


REACTIVO 7

Complete esta oración.

Me siento como si _____.

A los respondientes se les ordena terminar la oración con “sentimientos reales”, en lo que se conoce como un reactivo de completar la frase. La Oración incompleta de Rotter (The Rotter Incomplete Sentence; Rotter y Rafferty, 1950) es una prueba estandarizada que emplea este tipo de reactivos y el manual muestra datos normativos (Rotter *et al.*, 1992).

REACTIVO 8




¿Puede distinguir la figura *b* dentro de la figura *a*? Este tipo de reactivo se encuentra en pruebas de figuras escondidas e incrustadas. Reconocer figuras escondidas es una habilidad de la mente que utiliza la misma variable de campo dependencia/independencia, utilizada por aparatos más complejos como la silla reclinable/habitación reclinable de la figura 1-6.

REACTIVO 9



Éste es un reactivo que recuerda una de las manchas de tinta de Rorschach. Tenemos mucho más que decir sobre Rorschach en el siguiente capítulo.

REACTIVO 10



Al igual que la prueba de Rorschach, la cual utiliza manchas de tinta como un estímulo ambiguo, muchas otras pruebas piden al evaluado que se “proyecte” en un estímulo ambiguo. Este reactivo es reminiscencia de una prueba proyectiva llamada Prueba de las manos. Se pide a los evaluados que digan al examinador lo que piensen que están haciendo las manos.

La técnica llamada **clasificación Q** es representativa de las metodologías que pueden ser aplicadas con facilidad en la exploración de variados marcos de referencia. Desarrollada originalmente por Stephenson (1953), la clasificación Q es una técnica de evaluación en la que la tarea del evaluado es escoger un grupo de afirmaciones, por lo general en un orden de variación observada que fluctúa desde *más descriptiva* hasta *menos descriptiva*. Las afirmaciones, presentadas en forma tradicional en fichas, pueden ser clasificadas en formas diseñadas para reflejar diversas percepciones. Por ejemplo, pueden reflejar la forma en que los examinados se ven a sí mismos o cómo les gustaría verse. Algunas afirmaciones ilustrativas son: *Estoy seguro de mí mismo*, *Me esfuerzo por complacer a los demás* y *Me siento incómodo en situaciones sociales*.

Una de las aplicaciones mejor conocidas de la metodología de clasificación Q en escenarios clínicos y de orientación fue defendida por el teórico de la personalidad y psicoterapeuta Carl Rogers. Rogers (1959) usó la clasificación Q como un método para determinar la discrepancia entre el yo real percibido y el yo ideal. En los comienzos de la psicoterapia era posible pedir a los pacientes que clasificaran dos veces unas tarjetas, la primera de acuerdo con la forma en que se percibían a sí mismos y la otra de acuerdo a cómo les gustaría ser finalmente. Entre mayor fuera la discrepancia de las clasificaciones, mayores objetivos se tendrían que establecer en la terapia. De manera probable, la repetición de la prueba a los pacientes que hubieran completado con éxito un curso de psicoterapia revelaría mucho menor discrepancia entre el yo actual y el idealizado.

Más allá de su aplicación en la evaluación inicial y en la reevaluación de un paciente en terapia, la técnica de clasificación Q también ha sido usada en forma extensa en la investigación básica en el área de la personalidad y en otras áreas. Algunas de las clasificaciones Q altamente especializadas incluyen Prueba Q de liderazgo (*Leadership Q-Test*; Cassel, 1958) y el Sistema de clasificación vocacional de Tyler (*Tyler Vocational Classification System*; Tyler, 1961). La primera prueba fue diseñada para ser usada en escenarios militares y contiene tarjetas con declaraciones las cuales se pide al evaluado que clasifique respecto a la importancia observada para el liderazgo efectivo. La clasificación Q de Tyler contiene tarjetas en las que se enumeran ocupaciones; estas tarjetas son clasificadas en función del atractivo observado de cada ocupación. Un rasgo deseable de la metodología de clasificación Q es la facilidad con la que pueden ser adaptadas para usarse en un amplio rango de población con variados propósitos clínicos y de investigación. DeMulder *et al.* (2000) describieron cómo la metodología de clasificación fue utilizada con niños en edad preescolar para medir la variable objetos de seguridad o transicionales.

Otros dos formatos de presentación de reactivos fácilmente adaptables a diferentes marcos de referencia son el de *listas de verificación de adjetivos* y el de *completar oraciones* (que se examinan en el capítulo 12). Con el método de lista de verificación de adjetivos, los respondientes sólo marcan en una lista de adjetivos los que son aplicables a sí mismos (o a las personas a quienes están estimando). Usando la misma lista de adjetivos, el marco de referencia puede ser cambiado con facilidad modificando las instrucciones. Por ejemplo, para evaluar varios estados, se puede pedir a los evaluados que verifiquen los adjetivos que indican cómo se sienten *ahora*. De modo alternativo, para estimar varios rasgos, se les pide que clasifiquen los adjetivos que indiquen cómo se han sentido en el último año o poco más o menos. Una prueba llamada de modo

demasiado simple Lista de revisión de adjetivos (*Adjective Check List*; Gough, 1960; Gough y Heilbrun, 1980) es un instrumento que ha sido usado como herramienta en una amplia serie de investigaciones para examinar las percepciones que los evaluados tienen de ellos mismos o de otros. Por ejemplo, el instrumento ha sido utilizado para estudiar las autopercepciones de los gerentes (Hills, 1985), las percepciones de los padres respecto a sus hijos (Brown, 1972) y las de los pacientes respecto a sus terapeutas (Reinehr, 1969).

SÓLO PIENSE...

Imagine y describa un escenario de evaluación en el que sea muy importante obtener la percepción de otros acerca del evaluado.

Como su nombre lo indica, la tarea de un evaluado al responder a un reactivo escrito en el formato de completar oraciones es concluir una oración incompleta. Los reactivos pueden indicar cómo se sienten los evaluados respecto a ellos mismos, como en *Describiría mis sentimientos hacia mí* _____. Los reactivos pueden indicar cómo se sienten los evaluados con respecto a otros, como en la oración *Mis compañeros de clase* _____. En el siguiente capítulo hablaremos más sobre los métodos de completar oraciones; por ahora, resumamos de manera breve sobre cómo se califican e interpretan las pruebas de personalidad.

Calificación e interpretación Las medidas de personalidad difieren respecto a la forma en que se infieren conclusiones a partir de los datos que proporcionan. Para algunas medidas tomadas con papel y lápiz, se supone que un simple conteo de las respuestas a los reactivos previstos proporciona de manera supuesta una medida de la intensidad de un rasgo particular. Para otras medidas, se requiere una computadora programada para aplicar manipulaciones demasiado técnicas de los datos con propósitos de calificación e interpretación. No obstante, otras medidas pueden

requerir que un profesional clínico altamente capacitado revise la transcripción, palabra por palabra, de lo que dijo el evaluado en sus respuestas a ciertos estímulos como manchas de tinta o ilustraciones.

También es útil hacer una dicotomía de las medidas con respecto a la variable *nomotético/ideográfico*. El **método nomotético** para la evaluación se caracteriza por los esfuerzos para aprender cómo relativamente un limitado número de rasgos de personalidad pueden ser aplicados a todas las personas. Por el contrario, el **método ideográfico** se caracteriza por los esfuerzos para aprender acerca de la constelación única de rasgos de personalidad en cada individuo, sin intentar caracterizar a cada persona de acuerdo a cualquier conjunto particular de rasgos. Una prueba como el “16 PF” (Cattell *et al.*, 1993), la cual intenta medir a los examinados en base a 16 *factores de personalidad* (*Personality Factors*, que es lo que significa “PF”), es representativa de la orientación nomotética de la evaluación. La orientación ideográfica es evidente en los procedimientos de evaluación que son más flexibles no sólo respecto a la enumeración de los rasgos observados, sino también para nombrar nuevos términos en cuanto a rasgo.³ El método ideográfico para la evaluación de la personalidad fue descrito en detalle por Allport (1937; Allport y Odbert, 1936).

Otra dimensión relacionada con la cuestión de cómo se asocia el significado con las calificaciones de la prueba tiene que ver con el aspecto de si las comparaciones interindividuales o intraindividuales fueron hechas con relación a las calificaciones de la prueba. El método más común en la evaluación de la personalidad es el normativo, mediante el cual las respuestas del examinado y la intensidad supuesta de un rasgo medido son interpretadas en relación con la intensidad de ese rasgo en una muestra poblacional amplia. Sin embargo, usted puede recordar del capítulo 7 una alternativa al método normativo en la interpretación de las pruebas. En el método ipsativo, las respuestas de un examinado así como la intensidad supuesta de un rasgo medido se interpretan en relación con la intensidad de los rasgos medidos en ese mismo individuo. En una prueba que emplea procedimientos de calificación ipsativos, dos personas con la misma calificación para un rasgo particular o característica de personalidad pueden diferir en forma marcada respecto a la magnitud de dicho rasgo o característica relacionada con los miembros de una población específica.

Para concluir nuestro resumen sobre el *cómo* de la evaluación de la personalidad, y una preparación para examinar la manera en que se desarrollan las pruebas de personalidad, repasemos algunas cuestiones en el desarrollo y uso de las pruebas de personalidad.

SÓLO PIENSE...

Imagínese en el departamento de Recursos Humanos de una gran aerolínea. Como parte del proceso de evaluación, a todos los pilotos se les aplicará una prueba de personalidad. Le preguntan a usted si la prueba debe ser ipsativa o normativa en su naturaleza. ¿Cuál sería su respuesta?

Cuestiones sobre el desarrollo y uso de las pruebas de personalidad Muchas de las cuestiones inherentes al proceso de desarrollo de las pruebas reflejan las preguntas básicas que se acaban de examinar acerca de la evaluación de la personalidad en general. ¿Para quién será diseñado el uso de esta prueba? ¿La prueba implicará una autodescripción? O ¿requerirá del uso de evaluadores o jueces? Si requiere de evaluadores o jueces, ¿qué capacitación especial o qué otras características deberán tener éstos? ¿Cómo se puede asegurar un nivel razonable de confiabilidad entre evaluadores? ¿Qué área de contenido será ejemplificada por la prueba? ¿Qué acciones se tomarán con los flujos de los conjuntos de respuestas del evaluado? ¿Qué formato de reactivo deberá emplearse, y cuál sería un marco de referencia óptimo? ¿Cómo será calificada e interpretada la prueba?

3. Considere en este contexto la expresión *new age* utilizada como un rasgo de personalidad (como referencia a una creencia en la espiritualidad). Una evaluación de la personalidad realizada con una orientación ideográfica que sea lo bastante flexible para caracterizar al evaluado como *new age* debe considerar aplicable este rasgo. Los instrumentos nomotéticos desarrollados antes del uso de ese nuevo término de rasgo que incluyan las características cognoscitivas y conductuales del nuevo término de rasgo dentro de cualquier rasgo o rasgos existentes en el sistema nomotético serían considerados apropiados. Así, por ejemplo, un sistema nomotético que incluyera *espiritual* como uno de sus rasgos centrales podría incluir *new age* dentro de “espiritual”. En algún punto, si las tendencias y el uso lo justifican, un instrumento nomotético existente podría ser revisado para incluir un nuevo término de rasgo.

Como se puntualizó con anterioridad, la evaluación de la personalidad que confía de manera exclusiva en el informe personal es un arma de dos filos. Por una parte, la información surge de “la fuente”. La mayoría de las veces los respondientes presumen de conocerse a sí mismos mejor que cualquiera y por tanto deberían ser capaces de proporcionar respuestas confiables sobre ellos mismos. Por otra parte, el usuario de tal información no tiene modo de saber con exactitud qué parte de la autodescripción es completamente verdadera, cuál es verdad de manera parcial y cuál es mentira. Considere una respuesta a un solo reactivo en un inventario de personalidad escrito en un formato de verdadero/falso. El reactivo dice: *Tiendo a disfrutar el conocer a gente nueva*. La persona responde *verdadero*. En realidad no sabemos si el respondiente 1) disfruta conocer a gente nueva; 2) cree de manera honesta que disfruta conocer a gente nueva, pero en realidad no es así (en cuyo caso la respuesta es más el producto de la falta de percepción que una descripción de la realidad); 3) no disfruta conocer a gente nueva, pero le gustaría que la gente pensara que es así; o 4) ni siquiera se molestó en leer el reactivo, no está tomando la prueba con seriedad y está respondiendo *verdadero* o *falso* de un modo aleatorio a cada reactivo.

Una de las maneras en que los creadores de inventarios de personalidad han intentado tratar los problemas de la autodescripción es incorporando en sus pruebas las así llamadas escalas de validez. En años recientes ha habido debates acerca de si las escalas de validez deben ser incluidas en las pruebas. Al argumentar el caso a favor de la inclusión, se ha afirmado que “la detección de un intento de proporcionar información equivocada es un componente vital y absolutamente necesario de la interpretación clínica en los resultados de la prueba” y que el uso de cualquier instrumento sin escalas de validez “va en contra de los principios básicos de la evaluación clínica” (Ben-Porath y Waller, 1992, p. 24). Por el contrario, los autores del ampliamente usado Inventario de personalidad NEO Revisado (*Revised NEO Personality Inventory*, NEO PI-R), Paul T. Costa, Jr. y Robert R. McCrae, no vieron la necesidad de incluir ninguna escala de validez en su instrumento y han sido menos entusiastas acerca del uso de tales escalas en otras pruebas (McCrae y Costa, 1983; McCrae *et al.*, 1989; Piedmont y McCrae, 1996; Piedmont *et al.*, 2000). Al referirse a las escalas de validez como escalas SD —de atractivo social— (*social desirability*), Costa y McCrae (1997) opinaron:

Las escalas SD de manera característica consisten en reactivos que tienen una respuesta deseable. Sabemos que las personas que están tratando falsamente de aparentar que tienen buenas cualidades aprobarán muchos de estos reactivos, y los creadores de las escalas SD desean inferir a partir de esto que quienes aprueban muchos reactivos SD están tratando de crear una buena impresión. Ese argumento de manera apropiada es idéntico a afirmar que los candidatos a la presidencia saludan de mano, y por consiguiente es probable que quienes saludan de mano sean candidatos a la presidencia. De hecho, hay muchas más razones comunes para saludar de mano, y también hay una razón más común que el manejo de la impresión para aprobar los reactivos SD —a saber, debido a que los reactivos son razonablemente autodescripciones precisas (p. 89).

De acuerdo con Costa y McCrae, los evaluadores pueden afirmar que la información en la autodescripción es razonablemente precisa mediante una consulta a fuentes externas como la estimación de sus pares. Por supuesto, el uso de evaluadores necesita de otras precauciones para prevenir errores y prejuicios por parte del estimador.

SÓLO PIENSE...

Después de haber leído algo acerca de los pros y los contras de usar escalas de validez en la evaluación de la personalidad, ¿a qué conclusión ha llegado? Siéntase libre de revisar su opinión a medida que aprenda más.

La educación respecto a la naturaleza de varios tipos de error y prejuicios por parte del estimador ha sido el arma principal en la lucha contra las imprecisiones intencionales o no intencionales en las estimaciones. Se pueden diseñar sesiones de capacitación para lograr varios objetivos, como hacer más clara la terminología para aumentar la confiabilidad de la evaluación. Un término como *satisfactorio*, por ejemplo, puede tener diferentes significados para diferentes evaluadores. Durante la capacitación, los nuevos evaluadores pueden observar y trabajar con evaluadores más experimentados para que se familiaricen con aspectos de la

prueba que quizá no estén descritos en el manual del evaluador, para comparar sus estimaciones con evaluadores más experimentados, y para examinar el razonamiento empleado en sus estimaciones.

El hecho de incluir o no una escala de validez en una prueba de personalidad es, de manera definitiva, una cuestión que debe ser tratada. ¿Qué hay acerca del lenguaje utilizado para efectuar la evaluación? A primera vista esto parecería no tener importancia. Bueno, sí y no. Si el evaluado proviene de una cultura diferente a la cultura en la que se utilizó y desarrolló la prueba, o si el evaluado tiene fluidez en uno o más idiomas, el idioma bien podría convertirse en un problema. Las palabras tienden a perder —o a ganar— algo con la traducción y algunas palabras y expresiones no son fácilmente traducibles a otros idiomas. Considere el siguiente reactivo del tipo verdadero/falso de una popular prueba de personalidad: *Soy conocido por mi prudencia y sentido común*. Si usted es un estudiante bilingüe, ahora traduzca esa afirmación como ejercicio en un reactivo de prueba de traducción antes de seguir leyendo.

Una traducción al francés de este reactivo es bastante cercana, añadiendo sólo un pronombre posesivo de primera persona (“par ma prudence et *mon* bon sens”; McCrae *et al.*, 1998, p. 176). Sin embargo, la traducción al filipino de este reactivo es *Puedo ser confiado para decidir con cuidado y bien en los asuntos* (McCrae *et al.*, 1998, p. 176).

Además de las diferencias algunas veces importantes en el significado de los reactivos individuales, los rasgos medidos por las pruebas de personalidad también en ocasiones tienen diferente significado. Al reconocer este hecho, McCrae *et al.* (1998, p. 183) advirtieron que “las relaciones entre personalidad y rasgo reportadas en estudios occidentales deberían ser consideradas como promisorias hipótesis que deben ser probadas en nuevas culturas”.

El problema más amplio, relevante para el desarrollo y uso de las pruebas de personalidad con miembros de una cultura diferente a la cultura en la que la prueba fue estandarizada está relacionado con la aplicabilidad de las normas. Por ejemplo, varios estudios del MMPI efectuados con miembros de grupos de diversas culturas produjeron resultados en los cuales miembros de culturas minoritarias tienden a presentar mayor psicopatología que los miembros de grupos mayoritarios (véanse, por ejemplo, Montgomery y Orozco, 1985; Whitworth y Unterbrink, 1994). Tales diferencias han rememorado preguntas respecto a lo apropiado del uso de la prueba con miembros de poblaciones diferentes (Dana, 1995; Dana y Whatley, 1991; Malgady *et al.*, 1987).

Una prueba bien puede ser apropiada para ser usada con miembros de poblaciones culturalmente diferentes. Como observó López (1988, p. 1096): “Para argumentar que el MMPI tiene prejuicios culturales, necesitamos ir más allá de sólo reportar que los grupos étnicos difieren en sus perfiles de grupo”. López observó que muchos de los estudios que muestran diferencias entre los grupos no controlan la psicopatología. Por consiguiente, bien puede haber verdaderas diferencias de psicopatología en los grupos. El tamaño de la muestra utilizada en la investigación, así como lo apropiado del análisis estadístico, son otros factores extra culturales que se deben tomar en cuenta al evaluar la investigación que combine más de dos culturas. Por supuesto, si la cultura y los “significados aprendidos” (Rohner, 1984, pp. 119-120), en oposición a la psicopatología, están fundados para explicar las diferencias en la psicopatología medida en miembros de un particular grupo cultural, debe cuestionarse el uso continuo de las medidas con miembros de ese grupo.

Provistos con alguna información de los antecedentes referentes a la naturaleza de la personalidad y su evaluación, observemos de cerca el proceso de desarrollo de los instrumentos diseñados para evaluar la personalidad.

Desarrollo de instrumentos para evaluar la personalidad

Las herramientas como la *lógica*, la *teoría* y los *métodos de reducción de datos* (como el análisis factorial) se emplean con frecuencia en el proceso de desarrollo de las pruebas de personalidad. Otra herramienta en el proceso de elaboración de las pruebas puede ser un *grupo criterio*. Como veremos, la mayor parte de las pruebas de personalidad emplean dos o más de estas herramientas durante su desarrollo.

Lógica y razón

A pesar de las quejas de los escépticos, hay un lugar para la lógica y la razón en la psicología, al menos cuando se trata de redactar reactivos para una prueba de personalidad. La lógica y la razón pueden dictar qué contenido es cubierto por los reactivos. En efecto, al uso de la lógica y la razón en la elaboración de los reactivos de prueba en ocasiones se le menciona como el enfoque de *contenido* u *orientado al contenido* para la elaboración de pruebas.

Como ejemplo del enfoque de contenido para el desarrollo de una prueba, supongamos que usted desea crear la Prueba de evaluación de tendencias anoréxicas (PETA), cuyo propósito es identificar personas con alto riesgo de desarrollar anorexia nerviosa. De manera lógica, el contenido de los reactivos de la prueba relacionaría lo que ya es sabido sobre este trastorno de la alimentación. El redactar los reactivos para la prueba, podría depender de lo que sepa sobre la anorexia nerviosa por sus lecturas, experiencias personales y los relatos de otros. El fruto de sus esfuerzos podría dar como resultado una lista de preguntas con el formato sí/no, de la cual una muestra podría ser la siguiente:

1. ¿Su peso actual es al menos 85% del peso corporal esperado para su edad y estatura?
2. ¿Teme subir de peso?
3. ¿Percibe su cuerpo como anormal de alguna manera?

El fragmento de la PETA presentado arriba contiene reactivos basados en los criterios del *Manual diagnóstico y estadístico* (DSM IV) de la Asociación de Psiquiatría Estadounidense para un diagnóstico de anorexia nerviosa. Si su prueba orientada al contenido disfruta o no de un amplio uso dependerá de varios factores, sin que el menos importante de ellos sea qué tan bien mide las tendencias anoréxicas (o cualquier cosa que sea lo que pretenda medir).

Los esfuerzos para desarrollar tales reactivos orientados al contenido con validez aparente pueden rastrearse en retrospectiva al menos hasta un instrumento usado para evaluar reclutas con problemas de personalidad y adaptación en la primera guerra mundial. La Hoja de datos personales (*Personal Data Sheet*; Woodworth, 1917), conocida después como el Inventario psico-neurótico de Woodworth (*Woodworth Psychoneurotic Inventory*), contenía reactivos diseñados para evocar la autodescripción de temores, trastornos del sueño y otros problemas considerados sintomáticos de neurosis. Se suponía que entre mayor fuera el número de problemas reportados, más neurótico tendía a ser el respondiente.

Puede recopilarse una gran cantidad de información clínicamente procesable en relativamente poco tiempo utilizando los instrumentos de autodescripción, con la condición, por supuesto, de que el examinado llene el requisito de poseer percepción y de responder con sinceridad. No se requiere de un profesional altamente capacitado para aplicar la prueba, y puede disponerse de un reporte computarizado de los resultados en minutos. Por otra parte, tales instrumentos son muy adecuados de manera particular para escenarios clínicos en ambientes de atención regulada, en donde drásticas reducciones de costos han conducido a la disminución de solicitudes de evaluación y los administradores se muestran renuentes para autorizar evaluaciones por el costo económico que esto conlleva. En tales ambientes, el uso preferido de las pruebas psicológicas es identificar condiciones de “necesidad médica”, y entre más rápida y menos costosa sea la prueba, más le agradará al administrador.

Compañeros característicos de la lógica, la razón y la intuición en el desarrollo de reactivos son la investigación, la experiencia clínica, o ambas. Otro posible auxiliar en el proceso de desarrollo de la prueba es la interacción con expertos en la materia de la prueba. Y aún otra posible herramienta —incluso en ocasiones la fuerza rectora— es la teoría psicológica.

Teoría

Como observamos antes, las medidas de personalidad difieren en la extensión en que dependen de una teoría de la personalidad particular para su elaboración, así como en su interpretación. Por ejemplo, si en lugar de lógica y razón, la teoría psicoanalítica fuera la fuerza rectora detrás del desarrollo de la hipotética “PETA”, los reactivos podrían ser completamente diferentes. Por ejem-

plo, en base a la noción psicoanalítica de que las personas con anorexia nerviosa están intentando de manera inconsciente desvanecerse en la oscuridad, los reactivos de la PETA podrían intentar evaluar esta posibilidad. Dado que se considera que los sueños revelan motivaciones inconscientes, he aquí un reactivo en forma de sí/no que podría ser encontrado en una versión de la PETA derivada de la teoría psicoanalítica:

1. ¿Alguna vez ha soñado que se está desvaneciendo?

Una prueba basada en una teoría ahora de uso corriente es la Búsqueda autodirigida (*Self-Directed Search*, SDS) la cual es una medida de los intereses propios así como de las capacidades percibidas individualmente. Creada por John Holland y sus asociados, la prueba se basa en la teoría de Holland de la *personalidad vocacional*. En el núcleo de esta teoría se encuentra la visión de que la elección ocupacional tiene que ver en gran medida con la personalidad y la autopercepción de las habilidades. La SDS es, en muchos aspectos, una rareza entre las pruebas más usadas. Esto es debido a que se autoadministra, se autocalifica y se autointerpreta. Las puntuaciones de la prueba señalan a los evaluados la dirección de temas ocupacionales específicos. A partir de ahí, los examinados siguen las instrucciones para enterarse de diversas ocupaciones o profesiones que son consistentes con el patrón de intereses y capacidades manifestado.

SÓLO PIENSE...

Las pruebas autoadministradas, autocalificadas y autointerpretadas como la SDS tienen sus ventajas, pero también pueden tener sus desventajas. ¿Cuáles son algunas de las desventajas de las pruebas ampliamente autodirigidas?

Métodos de reducción de datos

Los métodos de reducción de datos representan otra clase de herramienta muy difundida en el desarrollo contemporáneo de pruebas. Los métodos de reducción de datos incluyen varios tipos de técnicas estadísticas conocidas en forma colectiva como análisis factorial o análisis de grupos. Un uso de los métodos de reducción de datos en el diseño de medidas de personalidad es ayudar en la identificación de la cantidad mínima de variables o factores que explican las correlaciones en los fenómenos observados.

Ilustremos el proceso de la reducción de datos con un ejemplo simple relacionado con la pintura de su departamento. Quizá no tiene idea clara del color exacto que complementa mejor su decoración de “estudiante de licenciatura”. Su inversión en una suscripción al *Architectural Digest* (*Selecciones arquitectónicas*) resultó ser de no mucha utilidad. Va a la tienda de pinturas local en su área y obtiene muestrarios gratuitos de todos los tonos de pintura conocidos por la humanidad, miles de muestras de colores. Suponga además que lleva a cabo un análisis factorial de estas miles de muestras de colores. Intenta identificar el número mínimo de variables o factores que expliquen las correlaciones entre todos estos colores. En seguida se encarga de un análisis factorial informal de esas miles de muestras; luego intenta identificar la mínima cantidad de variables o factores que expliquen las intercorrelaciones entre todos esos colores. Descubrirá que existen tres factores (los cuales podrían clasificarse como factores “primarios”) y cuatro factores más (que podrían etiquetarse como factores “secundarios” o de “segundo orden”), siendo el último conjunto de factores combinaciones del primero. Debido a que todos los colores pueden ser reducidos a tres colores primarios y sus combinaciones, los tres factores primarios corresponderían a los tres colores primarios, rojo, amarillo y azul (los cuales podría nombrar factor *R*, factor *Y* y factor *B*) y los cuatro factores secundarios o de segundo orden corresponderían a todas las combinaciones posibles que podrían hacerse con los factores primarios (factores *RY*, *RB*, *YB* y *RYB*).

Podría ser útil tener en mente la ilustración del ejemplo de la pintura mientras revisamos cómo se usa el análisis factorial en la elaboración de pruebas y en la evaluación de la personalidad. En una forma análoga a la elaboración de todos esos tonos de pintura en tres colores primarios, piense en todos los rasgos de personalidad siendo factorizados en lo que un psicólogo denominó “las diferencias individuales más importantes en las transacciones humanas” (Goldberg, 1993, p. 26). Después de haber terminado con la factorización y que el polvo se ha asentado,

¿cuántos términos relacionados con la personalidad piensa que quedarán? Dicho de otro modo, ¿cuántos factores *primarios* de la personalidad existen?

Como resultado de un programa precursor de investigación en la década de 1940, la respuesta de Raymond Bernard Cattell a la pregunta planteada antes fue “16”. Cattell (1946, 1947, 1948a, 1948b) revisó la investigación previa de Allport y Odbert (1936), la cual sugería que había más de 18 000 nombres de rasgo de personalidad y términos en el idioma inglés. De los cuales, sin embargo, sólo alrededor de una cuarta parte eran “rasgos de personalidad reales” o palabras y términos que designaban “tendencias determinantes generalizadas y personalizadas, modos consistentes y estables de la adaptación de un individuo a su ambiente... no... tan sólo comportamiento temporal y específico” (Allport, 1937, p. 306).

Cattell agregó a la lista algunos nombres y términos de rasgos empleados en la psicología profesional y en la literatura psiquiátrica y luego hubo jueces que estimaron las diferencias “apenas distinguibles” entre todas las palabras (Cattell, 1957). El resultado fue una reducción del tamaño de la lista a 171 nombres y términos de rasgos. Se pidió a estudiantes universitarios que valoraran a sus amigos con respecto a estos nombres y términos de rasgo, y los resultados del análisis factorial de la estimación redujeron aún más el número de nombres y términos a 36, a los cuales Cattell se refirió como *rasgos superficiales*. Todavía una mayor investigación indicó que podían destilarse 16 dimensiones básicas o *rasgos de origen*. En 1949, la investigación de Cattell culminó en la publicación de una prueba llamada Cuestionario de dieciséis factores de personalidad (*Sixteen Personality Factor Questionnaire*, 16 PF). Se publicaron ediciones revisadas de la prueba en 1956, 1962, 1968 y 1993. En 2002, se publicaron normas complementarias y actualizadas. (Maraist y Russell, 2002).

A lo largo de los años, se han planteado muchas interrogantes respecto a 1) si los 16 factores identificados por Cattell en efecto ameritan la descripción de “rasgos de origen” de la personalidad y 2) si, de hecho, el 16 PF mide 16 factores distintos. Aunque algunas investigaciones apoyan las afirmaciones de Cattell, agregar o quitar un factor o dos dependiendo de la muestra (Cattell y Krug, 1986; Lichtenstein *et al.*, 1986), también se han expresado serias reservas respecto a estas aseveraciones (Eysenck, 1985, 1991; Goldberg, 1993). Algunos han argumentado que el 16 PF puede estar midiendo algo menos de los 16 factores, debido a que varios de éstos se encuentran intercorrelacionados en forma sustancial.

Con los colores de la tienda de pinturas, podemos estar seguros de que hay tres que son primarios. Pero respecto a los factores de la personalidad, la certeza no parece estar en el catálogo. Algunos teóricos han argumentado que los factores primarios de la personalidad pueden reducirse a tres (Eysenck, 1991), o quizá a cuatro, a cinco o a seis (Church y Burke, 1994). Existen al menos cuatro modelos diferentes de cinco factores (Johnson y Ostendorf, 1993; Costa y McCrae, 1992a), Waller y Zavala (1993) hicieron un ejemplo para un modelo de siete factores. El modelo de cinco factores de Costa y McCrae (con factores que llegaron a conocerse de manera simple como los “cinco grandes”) ha obtenido el más grande seguimiento. De manera interesante, con el uso del análisis factorial en la década de 1960, Raymond Cattell había derivado también cinco factores de sus “16 primarios” (H. Cattell, 1996). Una comparación de uno junto al otro, de los “cinco de Cattell” con los Cinco grandes muestra una fuerte similitud entre los dos conjuntos de factores derivados (tabla 11-2). Pero Cattell creía con firmeza en la primacía de los 16 factores que había identificado originalmente.

Los cinco grandes El Inventario de personalidad NEO revisado (NEO PI-R; Costa y McCrae, 1992a) se usa en forma amplia en aplicaciones clínicas y en un amplio campo de investigación que implica la evaluación de la personalidad. Basado en un modelo de personalidad de cinco dimensiones (o factores), el NEO PI-R es una medida de cinco dimensiones principales (o “dominios”) de la personalidad y un total de 30 elementos o *facetas* que definen cada dominio.

La versión original de la prueba se llamó Inventario de personalidad NEO (NEO-PI; Costa y McCrae, 1985), en donde NEO era un acrónimo de los tres primeros dominios que se medían: Neuroticismo, Extraversión y Apertura (*Neuroticism, Extraversion, and Openness*). El NEO PI-R proporciona la medición de dos dominios adicionales: Compatibilidad y Conciencia. Dicho de manera breve, el dominio del neuroticismo utiliza aspectos de la adaptabilidad y estabilidad emocional. El dominio de la extraversión utiliza aspectos de la sociabilidad y asertividad. La

Tabla 11-2
Los cinco grandes comparados con los cinco de Cattell

Los cinco grandes	Los cinco de Cattell (alrededor de 1960)
Extraversión	Introversión/Extraversión
Neuroticismo	Baja ansiedad /Alta ansiedad
Apertura	Dureza mental/Receptividad
Compatibilidad	Independencia/Acomodo
Escrupulosidad	Bajo autocontrol/Alto autocontrol

Cattell expresó lo que él consideraba como el origen de los rasgos de personalidad en términos de dimensiones bipolares. Los 16 factores de la personalidad medidos por la prueba en la actualidad son: Cordial (Reservado *vs.* Cálido), Racional (Concreto *vs.* Abstracto), Estabilidad emocional (Reactivo *vs.* Emocionalmente estable), Predominio (Respetuoso *vs.* Dominante), Viveza (Serio *vs.* Animado), Conciencia de reglas (Oportuno *vs.* Consciente de las reglas), Osadía social (Tímido *vs.* Atrevido socialmente), Sensibilidad (Utilitario *vs.* Sensible), Vigilancia (Confiado *vs.* Vigilante), Abstracción (Asentado *vs.* abstraído), Privacidad (Abierto *vs.* privado), Aprehensión (Confiado *vs.* Aprehensivo), Apertura al cambio (Tradicional *vs.* Abierto al cambio), Confianza en sí mismo (Orientado a un grupo *vs.* Confía en sí mismo), Perfeccionismo (Tolera el desorden *vs.* Perfeccionista) y Tensión (Relajado *vs.* Tenso).

apertura se refiere a la apertura a la experiencia, así como a la imaginación activa, la sensibilidad estética, la atención a los sentimientos internos, la preferencia por la variedad, la curiosidad intelectual y la independencia de juicio. La compatibilidad, de manera principal, es una dimensión de tendencias interpersonales que incluyen el altruismo, la compasión por otros, y la creencia de que otros tienen inclinaciones similares. La escrupulosidad, es una dimensión de la personalidad que está relacionada con los procesos de planeación, organización y seguimiento. Cada una de estas dimensiones principales o dominios de la personalidad puede subdividirse en rasgos o facetas individuales medidas por la NEO PI-R.

La NEO PI-R está diseñada para utilizarse con personas de 17 años en adelante, y esencialmente es autoadministrable. Se dispone de una forma de calificación y una interpretación por computadora. Los datos de la validez y confiabilidad se presentan en el manual.

Comenzamos nuestra exposición de las herramientas de elaboración de pruebas con una observación: muchas pruebas de personalidad han usado dos o más de estas herramientas en el proceso de su desarrollo. En este punto usted puede comenzar a apreciar cómo, además de por qué, pudieron emplearse dos o más de estas herramientas. Podría crearse una reserva de reactivos para una medida de personalidad objetiva, por ejemplo, sobre la base de la lógica o la teoría, o de ambas. Luego, los reactivos son ordenados en escalas de acuerdo con un análisis factorial. La versión en borrador de la prueba podría aplicarse a un grupo criterio y a un grupo control, para observar si las respuestas a los reactivos difieren como una función de la pertenencia a un grupo. Pero aquí nos estamos adelantando un poco; necesitamos definir, exponer e ilustrar lo que significa *grupo criterio* en el contexto de la elaboración de una prueba de personalidad.

Grupos criterio

Un **criterio** puede ser definido como una norma sobre la que puede hacerse un juicio o tomarse una decisión. Respecto al desarrollo de escalas, un **grupo criterio** es un grupo de referencia de examinados que comparten características específicas y cuyas respuestas a los reactivos de la prueba sirven como una norma de acuerdo a la cual los reactivos serán incluidos o desechados en la versión final de una escala. El proceso de usar grupos criterio para elaborar los reactivos de la prueba se denomina **codificación empírica de criterios** porque ha sido demostrado de manera empírica que la calificación o codificación de los reactivos cambia entre grupos de examinados. La característica compartida del grupo criterio que se va a investigar —un diagnóstico psiquiátrico, una habilidad o capacidad única, una aberración genética, o lo que sea— variará como una función de la naturaleza y alcance de la prueba. El desarrollo de una prueba por medio de la codificación empírica de reactivos puede resumirse como sigue:

1. Crear una gran reserva preliminar de reactivos de prueba de los cuales se seleccionarán los que será incluidos en la forma final.
2. Aplicar la reserva preliminar de reactivos al menos a dos grupos de personas:

Grupo 1: Un grupo criterio compuesto por personas que se sepa posean el rasgo que se desea medir.

Grupo 2: Un grupo de personas seleccionado al azar (que pueden poseer o no el rasgo que se desea medir).
3. Llevar a cabo un análisis de reactivos con el propósito de seleccionar los que indiquen la pertenencia al grupo criterio. Los reactivos en la reserva preliminar que discriminen entre la pertenencia a los dos grupos de una manera estadísticamente significativa serán conservados e incorporados en la forma final de la prueba.
4. Obtener datos sobre el desempeño en la prueba a partir de una muestra de estandarización de examinados que sean representativos de la población de la que provendrán los futuros examinados. Los datos de desempeño en la prueba para los miembros del Grupo 2 en reactivos incorporados en la forma final pueden ser usados para este propósito, si se considera apropiado. El desempeño de los miembros del Grupo 2 se convertirá entonces en la norma contra la cual serán evaluados los futuros examinados. Después de que se ha identificado el desempeño promedio de los miembros del Grupo 2 en los reactivos (o escalas) individuales de la prueba, los futuros examinados serán evaluados en función de la medida en que sus puntuaciones se desvíen en cualquier dirección de la media del Grupo 2.

En este punto podrá preguntarse “¿Pero qué hay acerca de la reserva inicial de reactivos?, ¿Cómo fue hecha?” La respuesta es que el creador de la prueba puede haber encontrado inspiración para cada uno de los reactivos en revistas especializadas y libros, entrevistas con pacientes o consultas con colegas. Asimismo, puede haber dependido de la lógica o únicamente de la razón para redactar los reactivos, o también en otras pruebas. De manera alternativa, el desarrollador de la prueba puede no haber confiado en nada de esto y tan sólo dejó volar la imaginación y puso en el papel todo lo que pensó. Un aspecto interesante del desarrollo de la prueba por medio del principio de codificación empírica de reactivos es que el contenido de los reactivos no tiene que relacionarse de manera lógica, racional, directa o con validez aparente con el objetivo de la medición. Burisch (1984, p. 218) captó la esencia del criterio empírico de la codificación de reactivos cuando afirmó de manera llana: “Si el tamaño del calzado como un pronosticador mejora su capacidad para predecir el desempeño como piloto aviador, úselo”.⁴ Burisch siguió adelante al ofrecer esta descripción irónica de la forma en que podrían usarse grupos criterio para desarrollar una prueba “M-F” para diferenciar a los hombres de las mujeres:

Presuntamente al no saber dónde estaban las diferencias, él o ella nunca soñarían con usar un reactivo como “Puedo dejarme crecer la barba si lo deseo” o “En un restaurante tiendo a preferir el sanitario de mujeres al de hombres”. Más bien, una reserva heterogénea de reactivos sería ensamblada y administrada a una muestra de hombres y mujeres. A continuación, las muestras serían comparadas reactivo por reactivo. Cualquier reactivo que discriminara lo suficientemente bien calificaría para incluirlo en la prueba M-F (p. 214).

Ahora imagine que es la década de 1930. Un equipo de investigadores está muy interesado en diseñar una prueba escrita que mejorará la confiabilidad en el diagnóstico psiquiátrico. Su idea es usar el criterio empírico de codificación de reactivos para crear el instrumento. Una versión

4. No debería sorprendernos, sin embargo, el hecho esperado de que cualquier escala que sea el producto de tales procedimientos empíricos extravagantes, sea extremadamente alta en heterogeneidad de contenido de reactivo y profundamente baja en las medidas de consistencia interna.

preliminar será aplicada a 1) varios grupos criterio de pacientes adultos internados, cada grupo es homogéneo respecto al diagnóstico psiquiátrico, y a 2) un grupo de adultos normales seleccionado en forma aleatoria. Usando el análisis de reactivo, para elaborar la forma final de la prueba se conservarán los reactivos útiles para diferenciar a miembros de los varios grupos clínicos de entre los miembros del grupo normal. Los investigadores imaginan que los futuros usuarios de la prueba publicada serán capaces de derivar percepciones diagnósticas al comparar un patrón de respuestas de un examinado con el de los examinados del grupo normal.

Y aquí tiene los comienzos de una idea relativamente simple que, con el tiempo, ganaría una aprobación extendida de los clínicos de todo el mundo. Fue una idea para una prueba que estimuló la publicación de miles de estudios de investigación, una idea que ha llevado al desarrollo de una prueba que puede servir como modelo para otros innumerables instrumentos diseñados por medio del uso de la investigación de un grupo criterio. La prueba, denominada originalmente *Inventario médico y psiquiátrico* (*Medical and Psychiatric Inventory*; Dahlstrom y Dahlstrom, 1980), es el MMPI. Años después de sus comienzos experimentales, el autor principal de la prueba recordaba que “fue difícil persuadir a un editor para que aceptara el MMPI” (Hathaway, citado en Dahlstrom y Welsh, 1960, p. vii). Sin embargo, es obvio que convencieron al departamento editorial de la Universidad de Minnesota, porque en 1943 publicó la prueba bajo un nuevo nombre, el *Inventario multifásico de la personalidad de Minnesota* (*Minnesota Multiphasic Personality Inventory*, MMPI). El resto, como dicen, es historia.

En las próximas páginas describiremos el desarrollo del MMPI original, así como su generación más contemporánea, el MMPI-2 y el MMPI-A. Observemos al principio que esta prueba ocupa un lugar prominente en la psicometría y ha servido como modelo para muchas otras pruebas, además de que ha ganado la distinción de ser la prueba psicológica más ampliamente utilizada en el mundo.

El MMPI El MMPI fue el producto de una colaboración entre el psicólogo Starke R. Hathaway y el psiquiatra y neurólogo John Charnley McKinley (Hathaway y McKinley, 1940, 1942, 1943, 1951; McKinley y Hathaway, 1940, 1944). Contenía 566 reactivos verdadero/falso y fue diseñado como un auxiliar en el diagnóstico psiquiátrico de adolescentes y adultos de 14 años de edad en adelante. La investigación que precedió a la selección de los reactivos de la prueba incluyó la revisión de libros de texto, reportes psiquiátricos y reactivos de pruebas de personalidad publicados con anterioridad. En este sentido, los comienzos del MMPI pueden ser rastreados hasta un enfoque basado en la lógica y la razón con un énfasis en el contenido de los reactivos.

La tabla 11-3 presenta una lista de las diez escalas clínicas del MMPI junto con una descripción del grupo criterio correspondiente. Cada una de las categorías de diagnóstico enumeradas para las diez escalas clínicas fueron categorías de diagnóstico populares en la década de 1930. Se dio por hecho que los integrantes del grupo criterio clínico habían reunido los criterios para su inclusión en la categoría mencionada en la escala. Los reactivos de las escalas clínicas del MMPI fueron obtenidos de manera empírica mediante su administración a grupos criterio clínicos y grupos control de gente sin diagnóstico psiquiátrico alguno. Los reactivos que se diferenciaban con éxito entre los dos grupos fueron conservados en la versión final de la prueba (Welsh y Dahlstrom, 1956). Bueno, en realidad es un poco más complicado que eso, y usted debe conocer algunos de los detalles...

Para entender el significado de *grupo normal de control* en este contexto, piense en un experimento. En la investigación experimental, se manipula la situación de modo que el grupo experimental es expuesto a algo (la variable independiente), no así el grupo control. En la elaboración del MMPI, los miembros del grupo criterio fueron extraídos de una población de personas que presuntamente pertenecían a un grupo que compartía una clasificación diagnóstica. Comparando un experimento con la situación del desarrollo de esta prueba, es como si el tratamiento experimental para los miembros del grupo criterio fuera por su pertenencia a la categoría mencionada. Por el contrario, los miembros del **grupo control** fueron personas normales (sin diagnóstico) quienes ostensiblemente no recibieron dicho tratamiento experimental.

El grupo normal de control, al que también se conoce como la muestra de estandarización, consistía en aproximadamente 1 500 personas. En ella estuvieron incluidas 724 que resultó estaban visitando a amigos o familiares en los hospitales de la Universidad de Minnesota, 265 graduados

Tabla 11-3
Los grupos criterio clínicos para las escalas del MMPI

Escala	Grupo criterio clínico
1. Hipocondriasis (Hs)	Pacientes que mostraban preocupaciones exageradas sobre su salud física
2. Depresión (D)	Pacientes con depresión clínica; infelices y pesimistas sobre su futuro
3. Histeria (Hi)	Pacientes con reacciones de conversión
4. Desviación psicopática (Dp)	Pacientes que habían tenido historias de delincuencia y otros comportamientos antisociales
5. Masculino-Femenino (Mf)	Reclutas de Minnesota, azafatas de líneas aéreas y estudiantes universitarios homosexuales masculinos de la comunidad de la Universidad de Minnesota
6. Paranoia (Pa)	Pacientes que exhibían sintomatología paranoide como ideas de referencia, suspicacia, delirios de persecución y delirios de grandeza
7. Psicastenia (Pt)	Pacientes ansiosos, obsesivos-compulsivos, agobiados por la culpa y con dudas sobre sí mismos
8. Esquizofrenia (Sc)	Pacientes que fueron diagnosticados como esquizofrénicos (varios subtipos)
9. Hipomanía (Ma)	Pacientes, en su mayoría diagnosticados como maniaco-depresivos, que exhibían sintomatología maniaca como estado de ánimo elevado, actividad excesiva y con fácil capacidad de distracción
0. Introversión social (Si)	Estudiantes universitarios que habían obtenido calificaciones en los extremos de una prueba de introversión/extroversión

Observe que estas mismas diez escalas formaron el núcleo no sólo del MMPI original, sino también del de su edición revisada de 1989, el MMPI-2. Las escalas clínicas sufrieron algunas modificaciones en el MMPI-2, como edición y reordenamiento, y nueve reactivos fueron eliminados. No obstante, el MMPI-2 conserva el nombre de las diez escalas clínicas originales, aunque algunas de ellas (como “Desviación psicopática”) ahora son reliquias de una época pasada. Quizás eso explica por qué la costumbre ha hecho que se aluda a esas escalas sólo por números en lugar de por nombres.

de bachillerato que buscaban orientación previa a su ingreso a la universidad en la Oficina de Pruebas de la Universidad de Minnesota, 265 obreros calificados que participaban en un programa local de Administración del progreso en el trabajo y 243 pacientes (no psiquiátricos) médicos.

El grupo criterio clínico para el MMPI fue constituido en su mayor parte por pacientes psiquiátricos del hospital de la Universidad de Minnesota. Decimos “en su mayor parte” debido a que la escala 5 (Masculino-Femenino) y la escala 0 (Introversión social) no fueron derivadas de este modo. El número de personas incluidas en cada categoría de diagnóstico fue relativamente bajo para los estándares contemporáneos. Por ejemplo, el grupo criterio para la escala 7 (Psicastenia) contenía sólo 20 personas, todas diagnosticadas como psicasténicas (obseso-compulsas). Dos de las escalas “clínicas” (Escala 0 y Escala 5) ni siquiera incluyeron miembros de una población clínica en el grupo criterio. Los miembros de la escala 0 (Introversión Social) del grupo criterio

SÓLO PIENSE...

Para que aplique sus conocimientos acerca de la estandarización de pruebas, ¿qué piensa acerca de la estandarización del MMPI original?, ¿sobre la composición de los grupos criterio clínicos?, ¿acerca del grupo testigo normal?

clínico eran estudiantes universitarios que habían obtenido calificaciones extremas en una medida de introversión-extroversión. La escala 5 ni siquiera fue diseñada originalmente para medir la masculinidad o la femineidad; más bien, originalmente fue diseñada para diferenciar a los varones heterosexuales de los homosexuales. Debido a la carencia de reactivos que diferenciaban de manera eficiente a las personas en esta variable, los creadores de la prueba ampliaron la definición de la escala 5 y agregaron reactivos que discriminaban entre varones normales (soldados) y mujeres normales (personal de aerolíneas). Algunos de los reactivos agregados se obtuvieron de la Escala de interés y actitud (Terman y Miles,

1936). Hathaway y McKinley también habían intentado desarrollar una escala para diferenciar lesbianas de mujeres heterosexuales, sin lograrlo.

Para la década de 1930, la investigación sobre la Hoja de datos personales (Woodworth, 1917) y otros instrumentos con validez aparente, derivados en forma lógica había hecho evidentes los problemas inherentes a los métodos de autodescripción. Hathaway y McKinley (1943) mostraron un profundo conocimiento de dichos problemas e integraron dentro del MMPI tres escalas de

validez: la escala L (la escala Mentira), la escala F (la escala de Frecuencia, o quizá de manera más precisa, de Infrecuencia) y la escala K (Corrección). Observe que esas escalas no fueron diseñadas para medir la validez en el sentido técnico, psicométrico. Después de todo, inherentemente hay algo de autogratificante, si no es que de sospecha, acerca de una prueba que pretende estimar ¡su propia validez! Más bien aquí, *validez* era la referencia a un indicador incorporado de cómo opera el examinado en los conjuntos de respuestas y patrones de respuestas relacionadas (descuido, esfuerzos deliberados por engañar o una mala interpretación no intencional) que podrían afectar los resultados de la prueba.

La escala L contiene 15 reactivos que son un poco negativos, pero que se aplican a la mayoría de las personas. Dos ejemplos: “No siempre digo la verdad” o “A veces chismorreo un poco” (Dahlstrom *et al.*, 1972, p. 109). La disposición del examinado para revelar *cualquier cosa* negativa sobre sí mismo será cuestionada si la calificación en la escala L no se encuentra dentro de ciertos límites.

Los 64 reactivos en la escala F, 1) son aprobados con poca frecuencia por miembros de poblaciones no psiquiátricas (es decir, personas normales) y 2) no encajan en ningún patrón conocido de desviación. Una respuesta de *verdadero* a un reactivo como el siguiente sería calificada en la escala F: “Sería mejor si casi todas las leyes fueran desechadas” (Dahlstrom *et al.*, 1972, p. 115). Una calificación F elevada puede significar que el examinado no tomó la prueba en serio y sólo estaba respondiendo los reactivos al azar. De manera alternativa, el individuo con una puntuación F alta puede ser un individuo muy excéntrico o alguien que está intentando “hacerse pasar por malo”. Quienes se fingen enfermos en los servicios armados, las personas que intentan cometer fraude en relación con los seguros de salud y los criminales que intentan ganar un alegato psiquiátrico son algunos de los grupos de personas de quienes podría esperarse obtuvieran calificaciones elevadas en la escala F.

Como la calificación L y la calificación F, la calificación K es un reflejo de la franqueza en la autodescripción del examinado. Una puntuación K elevada se asocia con una actitud defensiva y con el deseo de presentar una impresión favorable. Una calificación K baja se asocia con una autocrítica excesiva, un deseo de detallar una desviación o un deseo de hacerse pasar por malo. Una respuesta *verdadero* al reactivo “Sin duda a veces me siento inútil” y una respuesta *falso* a “A veces me siento pleno de energía” (Dahlstrom *et al.*, 1972, p. 125) sería calificada en la escala K. Esta escala se usa para corregir puntuaciones en cinco de las escalas clínicas; las calificaciones son corregidas estadísticamente por una disposición excesiva o muy poca disposición del individuo para admitir una patología.

Otra escala que está relacionada con la validez de aplicación de una prueba es la escala *No puedo decir*, también conocida como la escala ? (signo de interrogación). Esta escala es un simple conteo de la frecuencia en el número de reactivos a los que el examinado respondió *no puedo decir* o en los que no marcó ninguna respuesta. Los reactivos pueden ser omitidos o marcados *no puedo decir* por muchas razones, que incluyen indecisión, actitud defensiva, descuido y falta de experiencia relevante para el reactivo. De manera tradicional, la validez de una hoja de respuestas con una cuenta de 30 o mayor de *no puedo decir* se pone en duda y se considera que no es interpretable (Dahlstrom *et al.*, 1972). Incluso para pruebas con un conteo de 10 *no puedo decir*, se exhorta para tener precaución en la interpretación de la prueba. Las calificaciones altas con *no puedo decir* pueden ser evitadas con el énfasis de un aplicador en las instrucciones iniciales para responder *todos* los reactivos.

El MMPI contiene 550 reactivos cierto/falso, 16 de los cuales están repetidos en algunas formas de la prueba (para un total de 566 reactivos aplicados). Las calificaciones en cada escala MMPI se reportan en la forma de puntuaciones *T* las cuales, como usted recordará, tienen una media establecida en 50 y una desviación estándar de 10. Una calificación de 70 en cualquier escala clínica MMPI está 2 desviaciones estándar por arriba de la calificación media de los miembros de la muestra de estandarización, y una calificación de 30 está 2 desviaciones estándar por debajo de la calificación media.

Además de las escalas clínicas y las escalas de validez, existen las escalas de contenido, las escalas complementarias y las subescalas Harris-Lingoes. Según lo implica su nombre, las escalas

SÓLO PIENSE...

Escriba un buen reactivo de la escala L.

de contenido, denominadas en ocasiones como Escalas de Contenido de Wiggins (en honor de Wiggins, 1966), están compuestas por grupos de reactivos con contenido similar. Ejemplos de las escalas de contenido en el MMPI incluyen las escalas clasificadas Depresión y Problemas familiares.

Escalas complementarias es una frase que cubre una amplia variedad de situaciones para los cientos de diferentes escalas MMPI que se han desarrollado desde la publicación inicial de la prueba. Estas escalas han sido planeadas por diferentes investigadores usando una variedad de métodos y procedimientos estadísticos, de manera más notable el análisis factorial. Hay escalas complementarias que son bastante consistentes con los objetivos originales del MMPI, como las escalas diseñadas para arrojar luz sobre cuestiones como alcoholismo y fuerza del yo. Y luego hay docenas de otras escalas complementarias, creadas por investigadores independientes. Las cuales fluctúan desde una llamada Éxito en el béisbol hasta, bueno, ¡usted nómbrela!⁵

SÓLO PIENSE...

Si usted tuviera que desarrollar una escala MMPI complementaria, ¿cuál sería?, y ¿por qué tendría que diseñarla?

El editor del MMPI tiene disponible para una calificación computarizada sólo una selección limitada de los muchos cientos de escalas complementarias que se han elaborado y discutido en la literatura profesional. Las subescalas Harris-Lingoes, a menudo mencionadas simplemente como las Escalas Harris, son un conjunto de escalas complementarias disponibles de manera amplia para los usuarios de pruebas. Las Escalas Harris son reactivos agrupados en subescalas (con clasificaciones como Preocupado y Enajenación social) que fueron diseñadas para tener más consistencia

interna que la escala que les dio origen.

Históricamente administrado mediante papel y lápiz, en la actualidad el MMPI es aplicado por muchos métodos. Mediante una red de computadoras, por un disco en una computadora independiente o por reactivos impresos en fichas. También hay disponible una versión para individuos semianalfabetas con las instrucciones grabadas en casete. Quienes presentan la prueba responden los reactivos contestando *cierto* o *falso*. Los reactivos que se dejan sin responder se traducen como *no puedo decir*. En la versión aplicada usando reactivos individuales impresos en fichas, se indica a los examinados que las dividan en tres pilas clasificadas como *verdadero*, *falso* y *no puedo decir*. Se requiere de al menos un nivel de lectura de sexto grado para entender todos los reactivos. No hay límites de tiempo, y el tiempo requerido para aplicar los 566 reactivos generalmente se encuentra entre 60 y 90 minutos.

Es posible calificar en forma manual las hojas de respuestas del MMPI, pero este proceso es laborioso. La calificación computarizada de los protocolos se logra mediante programas de cómputo en computadoras personales, por transmisión electrónica a un servicio de calificación vía módem o enviando físicamente por correo la forma completada a un servicio de calificación computarizado. El resultado de la calificación computarizada puede variar desde una simple presentación numérica y gráfica de las calificaciones hasta un completo reporte narrativo bien detallado con análisis de las calificaciones en escalas complementarias seleccionadas.

Poco después de que se publicó el MMPI, se hizo evidente que la prueba no podía ser usada para clasificar en forma clara a los examinados en categorías diagnósticas; cuando éstos tenían elevaciones en el rango patológico de dos o más escalas, surgían dilemas diagnósticos. Hathaway y McKinley (1943) habían exhortado a los usuarios de su prueba para que optaran por *interpretaciones configurativas* de las puntuaciones, es decir, interpretaciones basadas no sólo en las calificaciones de una sola escala, sino en el patrón, perfil o configuración de las calificaciones de todas las escalas. Sin embargo, el método propuesto para la interpretación del perfil era complicado en extremo, como lo fueron también muchos de los procedimientos adicionales y alternativos.

5. Aquí, sagaz lector, usted puede comenzar a detectar cuán lejos se ha desviado el MMPI de su propósito original. De hecho, el MMPI, y en fechas más recientes el MMPI-2, se ha usado en una escala extraordinariamente amplia de experiencias relacionadas con el diagnóstico psiquiátrico de una manera tangencial, en el mejor de los casos.

Paul Meehl (1951) propuso un código de 2 puntos derivado de los números de las escalas clínicas en las cuales los examinados hubieran conseguido las calificaciones más altas (más patológicas). Si un examinado obtenía la calificación más alta en la Escala 1 y la segunda calificación más alta en la Escala 2, ese tipo de código de 2 puntos del examinado sería 12. El tipo de código de 2 puntos para una calificación más alta en la Escala 2 y una segunda calificación más alta en la Escala 1 sería 21. Debido a que cada dígito en el código es intercambiable, un código de 12 sería interpretado exactamente de la misma manera que un código de 21. Por cierto, un código de 12 (o 21), por ejemplo, sería indicativo de un individuo con dolor físico. Una suposición aquí es que cada calificación en el tipo de código de 2 puntos, es esperado que presenta una elevación de $T = 70$. Si la calificación en la escala no excede de 70, esto se indica mediante el uso de una prima (') después del número de la escala. El sistema de Meehl tenía un gran atractivo para muchos usuarios del MMPI. Poco después, se disponía de una abundante investigación basada en los significados interpretativos de los 40 tipos de código que podían derivarse usando diez escalas y dos dígitos intercambiables.⁶

Otro enfoque popular para la calificación e interpretación apareció en la forma de **claves de Welsh**, llamadas así porque fueron creadas por Welsh (1948, 1956), no porque estén escritas en galés (aunque para el aprendiz pueden ser igual de incomprensibles). He aquí un ejemplo de una clave de Welsh:

6*78'''1-53/4:2#90 F'L-/K.

Para el usuario experimentado de las claves de Welsh, esta expresión proporciona información de las puntuaciones de un examinado en el MMPI clínico y en las escalas de validez.⁷

Los estudiantes interesados en aprender más sobre el MMPI no necesitan invertir una gran cantidad de esfuerzo para buscar las fuentes. Es probable que la biblioteca de su universidad esté provista con libros y artículos de revistas especializadas escritos sobre o acerca de este instrumento multifásico (muchas facetas). Por supuesto, usted también querrá ir más allá de esta introducción histórica para estar más familiarizado con las revisiones más contemporáneas de la prueba, el MMPI-2 y el MMPI-A. He aquí un breve resumen.

El MMPI-2 Mucho de lo que ya se ha dicho sobre el MMPI respecto a su estructura general así como a su aplicación, calificación e interpretación es aplicable al MMPI-2. La diferencia más importante entre las dos pruebas es su muestra (grupo de control normal) de estandarización más representativa usada en la normalización del MMPI-2 (que luego examinaremos). Aproximadamente el 14% de los reactivos del MMPI fueron redactados de nuevo para corregir errores gramaticales y actualizar el lenguaje, sin prejuicios de sexo y más legible. Los reactivos que se consideraron objetables para los examinados actuales fueron eliminados. Se agregaron reactivos que abordan temas como el abuso de las drogas, el potencial de suicidio, la adaptación matrimonial, las actitudes hacia el trabajo y los patrones de comportamiento Tipo A.⁸ En total, el MMPI-2 contiene 567 reactivos verdadero/falso, incluyendo 394 que son idénticos a los del MMPI original, 66 reactivos que fueron modificados o redactados de nuevo y 107 nuevos. El rango de edad sugerido para los examinados por el MMPI-2 es de 18 años de edad en adelante en comparación con el de 14 años de edad en adelante sugerido por el MMPI. El nivel de lectura requerido (sexto grado) es el mismo que para el MMPI. El MMPI-2, como su predecesor, puede aplicarse mediante una red de cómputo, en una computadora solamente, con papel y lápiz o por medio de un casete grabado, y su aplicación requiere más o menos el mismo tiempo.

6. Además de los sistemas de codificación de 2 puntos, se ha propuesto al menos un sistema de código de tres puntos. En este sistema, el primer número es la puntuación más alta, el segundo número es la segunda puntuación más alta y el tercer número es la tercera puntuación más alta.

7. Con la aprobación del instructor, el estudiante motivado puede traducir esta clave para obtener un punto extra.

8. Recuerde a partir del análisis de los tipos psicológicos realizada con anterioridad en este capítulo (página 339) lo que constituye un comportamiento Tipo A y uno Tipo B.

Las diez escalas clínicas del MMPI son idénticas a las del MMPI-2, al igual que la política de referirse a ellas esencialmente por su número. Al MMPI-2 se le agregaron escalas de componente de contenido para proporcionar índices más enfocados. Por ejemplo, el contenido de Problemas Familiares ahora fue subdividido en contenido de Discordia familiar y Enajenación familiar. Las tres escalas de validez originales del MMPI fueron incluidas en el MMPI-2, así como tres escalas adicionales de validez: Infrecuencia de páginas anteriores (Fb), Inconsistencia de respuesta verdadera (TRIN) e Inconsistencia de respuesta variable (VRIN). La escala de Infrecuencia de páginas anteriores contiene reactivos que rara vez son aprobados por examinados que son francos, reflexivos y cuidadosos en su enfoque de la prueba. Por supuesto, algo del cuidado de los examinados mengua a medida que avanza la prueba, así que para las “páginas anteriores” de la prueba es evidente un patrón de respuestas aleatorio o inconsistente. La escala Fb está diseñada para detectar dicho patrón.

SÓLO PIENSE...

Para mantener continuidad con la prueba original, el MMPI-2 utilizó los mismos nombres para las escalas clínicas. Algunos de estos nombres de escala, como psicastenia, ya no se usan. ¿Recomendaría usted la actualización de los nombres de las escalas? ¿Habría alguna otra recomendación para realizar cambios en las escalas o en la prueba misma?

La escala TRIN se elaboró para identificar patrones de respuesta con aquiescencia o sin ella. Contiene 23 pares de reactivos redactados en formas opuestas; la consistencia en las respuestas prescribe que, por ejemplo, una respuesta *verdadera* al primer reactivo en el par sea seguida por una respuesta falsa al segundo reactivo en el par.

La escala VRIN está diseñada para identificar patrones de respuesta indiscriminados. También está compuesta por pares de reactivos, cada reactivo del par está redactado ya sea en formas opuesta o similar. El autor principal del MMPI-2, James Butcher (figura 11-4), desarrolló incluso otra escala más de validez después de la publicación de la prueba.⁹ La escala S es una escala de validez diseñada para detectar autopresentación en una manera superlativa (Butcher y Han, 1995; Lanyon, 1993a, 1993b; Lim y Bu-

tcher, 1996).

Una crítica persistente del MMPI consistía en la falta de representación de la muestra de estandarización respecto a la población de Estados Unidos. Esta crítica fue abordada en la estandarización del MMPI-2. Los 2 600 individuos (1 462 mujeres, 1 138 hombres) de siete estados que conformaban la muestra de estandarización del MMPI-2 han sido comparados con los datos del Censo de Estados Unidos de 1980 en las variables de edad, género, posición minoritaria, clase social y educación (Butcher, 1990). Mientras que el MMPI original no contenía ninguna persona que no fuera blanca en la muestra de estandarización, la muestra del MMPI-2 incluía 81% de blancos y 19% no blancos. La edad de los sujetos en la muestra fluctuaba entre 18 y 85 años. La educación formal variaba de 3 a 20 años o más, con personas más preparadas y gente que trabajaba en las profesiones sobrerrepresentadas en la muestra. El ingreso familiar anual promedio para las mujeres de la muestra era de 25 000 a 30 000 dólares. El ingreso familiar anual promedio para los hombres de la muestra era de 30 000 a 35 000 dólares.

Como con el MMPI original en el MMPI-2, los datos de la muestra de estandarización proporcionaron la base para convertir las calificaciones crudas obtenidas por los evaluados en puntuaciones *T*. Sin embargo, se consideró necesario un ajuste técnico. Las puntuaciones *T* usadas para estandarizar las escalas clínicas del MMPI y las escalas de contenido eran puntuaciones *T* lineales. Para el MMPI-2, también fueron utilizadas puntuaciones *T* lineales para la estandarización de las escalas de validez, las escalas complementarias y las escalas 5 y 0 de las escalas clínicas. Sin embargo, se usó una puntuación *T* diferente para estandarizar las ocho escalas clínicas restantes, así como todas las escalas de contenido; estas escalas fueron estandarizadas con puntuaciones *T* uniformes (calificaciones *UT*). Las puntuaciones *UT* fueron usadas en un esfuerzo por hacer que las puntuaciones *T* correspondientes a puntuaciones en percentiles pudieran ser comparables a lo largo de las escalas del MMPI-2 (Graham, 1990; Tellegen y Ben-Porath, 1992).

9. Retratado a la derecha de James Butcher está su amigo, Dale Moss, quien murió en la guerra. Los autores hacen una pausa en esta coyuntura para recordar y expresar su gratitud a todas las personas en todas las ramas de la milicia y del gobierno que se han sacrificado por Estados Unidos de América.



Figura 11-4
James Butcher (1933-) y un amigo

Éste es Jim, mejor conocido en la actualidad como el principal autor del MMPI-2, identificado a la derecha como un soldado de infantería de la armada en el destacamento de Yoke en Corea del Sur en 1953. De regreso a la vida civil, Jim intentó varias ocupaciones, incluyendo la de agente de ventas e investigador privado. Después obtuvo un doctorado por la Universidad de Carolina del Norte, donde tuvo oportunidad de trabajar con W. Grant Dahlstrom y George Welsh (como en el “código Welsh” del MMPI). El primer empleo de Butcher como profesor fue en la Universidad de Minnesota, donde intentó trabajar con Starke Hathaway y Paul Meehl. Pero se decepcionó al saber que “Hathaway había cambiado en búsqueda de la investigación psicoterapéutica y característicamente rechazaba cualquier incumbencia en la prueba... Hathaway siempre rechazó permanecer involucrado en instruir a las personas acerca de la prueba. También Meehl de la misma manera se había movido a otras áreas” (Butcher, 2003, p. 233).

El MMPI-A Aunque sus creadores habían recomendado el MMPI original para ser usado con adolescentes, los usuarios de la prueba habían manifestado cierto escepticismo sobre esta recomendación a lo largo de los años. Desde un principio se había observado que los adolescentes como grupo tendían a obtener calificaciones un tanto superiores en las escalas clínicas en comparación con los adultos, un resultado que dejó a los adolescentes como grupo en la nada envidiable posición de parecer que experimentaban más psicopatología que los adultos. En parte por esta razón, se elaboraron normas del MMPI separadas para adolescentes. En la década de 1980, con la revisión del MMPI en proceso, los creadores de la prueba tenían la opción de sencillamente volver a normalizar el MMPI-2 para adolescentes o crear un nuevo instrumento. Optaron por desarrollar una nueva prueba que fuera en muchos aspectos clave, una extensión descendente del MMPI-2.

El Inventario multifásico de la personalidad de Minnesota para adolescentes (*Minnesota Multiphasic Personality Inventory-Adolescent*, MMPI-A; Butcher *et al.*, 1992) es una prueba con 478 reactivos verdadero/falso diseñada para ser usada en escenarios clínicos, de orientación vocacional y escolares con el propósito de evaluar la psicopatología e identificar problemas personales, sociales y conductuales. Los reactivos individuales del MMPI-A son muy parecidos a las escalas clínicas y de validez y semejantes en gran medida al MMPI-2, aunque tiene 88 reactivos menos. Algunos de los reactivos del MMPI-2 fueron descartados, otros se volvieron a redactar y algunos nuevos fueron agregados. En su forma escrita (en oposición a la grabada en casete), la prueba está diseñada para su aplicación a individuos en un rango de edad de 14 a 18 años, que tengan al menos una capacidad de lectura de sexto grado. Al igual que con el MMPI-2, están disponibles versiones para su aplicación por medio de computadora, por papel y lápiz y por medio de casete grabado. El tiempo requerido para la aplicación de todos los reactivos generalmente es de entre 45 y 60 minutos.

El MMPI-A contiene 16 escalas básicas incluyendo diez Escalas clínicas (idénticas en nombre y número a las del MMPI-2) y seis escalas de validez (de hecho, un total de ocho escalas de validez dado que la escala F está subdividida en las escalas F₁ y F₂). Las escalas de validez son Inconsistencia de respuesta variable (VRIN), Inconsistencia de respuesta verdadera (TRIN), Infrecuencia (F), Infrecuencia 1 (F₁; específicamente aplicable a las escalas clínicas), Infrecuencia 2 (F₂; específicamente aplicable a las escalas de contenido y complementarias), Mentira (L), Actitud defensiva (K) y No puedo decir (?).

Además de las escalas clínicas y de validez básicas, el MMPI-A contiene seis Escalas complementarias (que tratan con áreas como uso de alcohol y drogas, inmadurez, ansiedad y represión), 15 Escalas de contenido (incluyendo áreas como Problemas de conducta y Problemas escolares), 28 escalas Harris-Lingoes y tres escalas clasificadas como Introversión social. Al igual que con el MMPI-2, se emplearon puntuaciones *T* uniformes (*UT*) para ser usadas con todas las Escalas de contenido y ocho de las Escalas clínicas (excluyendo las escalas 5 y 0), para hacer comparables las puntuaciones en percentiles a lo largo de las escalas.

La muestra normativa para el MMPI-A consistía en 805 hombres adolescentes y 815 mujeres adolescentes, extraídos de escuelas de California, Minnesota, Nueva York, Carolina del Norte, Ohio, Pennsylvania, Virginia y Washington. El objetivo era obtener una muestra que fuera representativa a nivel nacional en función de variables demográficas como orígenes étnicos, región geográfica de Estados Unidos y residencia urbana/rural. Coincidente con la normalización del MMPI-A, una muestra clínica de 713 adolescentes fue examinada con el propósito de obtener datos de validez. Sin embargo, no se hizo ningún esfuerzo por asegurar la representatividad de la muestra clínica; todos los sujetos fueron extraídos del área de Minneapolis, la mayoría de centros de rehabilitación por adicción a las drogas y al alcohol.

En general, el MMPI-A ha ganado altas puntuaciones de los revisores de pruebas y bien puede ser que pronto se convierta en la medida de psicopatología en adolescentes más utilizada. Las escalas de contenido del MMPI-A ofrecen un incremento en la validez por encima de las escalas clínicas de las pruebas y podrían usarse como un anexo en dichas escalas (McGrath *et al.*, 2002). Existe alguna evidencia que sugiere que cuando esta prueba se usa con personas de 18 años de edad, tiende a subestimar el grado de psicopatología que podría estar presente (Osberg y Poland, 2002).

SÓLO PIENSE...

¿Cuál sería su comentario sobre las normas del MMPI-A?

El MMPI y sus revisiones en perspectiva Podríamos establecer una analogía del MMPI original con un automóvil clásico. En su núcleo tiene un motor (las diez escalas clínicas) que, aunque claramente anticuado, sigue siendo lo bastante familiar y servicial como para mantener un gran atractivo. Muchos de los componentes del motor fueron nombrados usando un vocabulario de una época pasada. Por esta razón, en la actualidad se hace referencia a estas partes con un número en lugar de un nombre. Pero aunque su motor pueda ser anacrónico desde el punto de vista tecnológico, el automóvil es de calidad reconocida y respetada, con una fuerte herencia de marca. Éste ha sido el tema de miles de estudios de investigación desde su introducción a principios de la década de 1940. Más aún, se han agregado al vehículo accesorios como campanas, silbatos y opciones (en cuanto a escalas adicionales y una nueva muestra normativa), lo cual atrae a los compradores a la sala de exhibición.

Los procesos de revisión del MMPI-2 y del MMPI-A tuvieron dos objetivos aparentemente contrarios. Un objetivo era mantener tan parecida como fuera posible la revisión al original, esto con el propósito de conservar la aplicabilidad y relevancia de los muchos estudios de investigación que empleó el MMPI. El segundo objetivo era cambiar la prueba original en respuesta a las muchas críticas constructivas que se habían hecho al original a lo largo de los años. De muchas maneras, los creadores del MMPI-2 y del MMPI-A consiguieron este delicado equilibrio aunque, como podría esperarse, no todos están completamente felices con los medios utilizados para ese fin.

El problema más sobresaliente del MMPI era la falta de normas representativas, una crítica tratada tanto en el MMPI-2 como en el MMPI-A. Sin embargo, sólo fue en el MMPI-A, y no en el MMPI-2, en el que de manera concurrente se examinó una muestra clínica con propósitos comparativos y de validación. Datos comparables del MMPI-2 sobre una muestra clínica contempo-

ránea, representativa a nivel nacional hubieran ido mucho más allá para infundir nueva vida y significado a las agotadas pero recicladas escalas clínicas. También es un misterio el hecho de que en el estudio del MMPI-A se haya utilizado una muestra clínica que no es representativa a nivel nacional. Una vez que se tomó la decisión de emplear una muestra clínica, ¿por qué no se hizo un esfuerzo por hacer que esa muestra fuera representativa a nivel nacional? Todos los sujetos de la muestra clínica citados en el manual del MMPI-A eran de Minnesota. Respecto a esto, el MMPI-A conservó una característica del MMPI original que habría sido mejor cambiar.

A finales de la década de 1930 y principios de 1940, cuando Hathaway y McKinley estaban experimentando la necesidad de elaborar un nuevo instrumento de diagnóstico, podría haberse pasado por alto la falta de representatividad de los sujetos clínicos. Debemos admitir que obtener dicha muestra, examinar a todos los sujetos y analizar en forma minuciosa todos los datos resultantes, es una empresa difícil y costosa. Por otra parte, dada la posición contemporánea del MMPI (una verdadera institución entre las pruebas psicológicas), y la gran frecuencia con que se usa en todo el mundo, ¿por qué los creadores de la prueba actual habrán querido hacer menos? Nuestra opinión es que la presentación de datos a partir de una muestra clínica representativa a nivel nacional hubiera sido una adición sumamente valiosa —y mucho más manejable— en los manuales de las dos revisiones del MMPI.

Cada una de las escalas clínicas del MMPI exhiben de manera relativamente baja consistencia entre reactivos, lo que no es de sorprender, dada la naturaleza empírica de su desarrollo. Al mismo tiempo, las correlaciones entre las escalas clínicas son altas. Esta combinación de hechos, de manera natural, hace que surjan preguntas como, ¿qué es lo que en realidad miden las escalas clínicas? Las interrogantes respecto a la manera exacta en que deben ser interpretadas las calificaciones en las escalas clínicas persisten incluso con respecto al MMPI-2 y al MMPI-A. En gran parte, estas cuestiones han sido examinadas con referencia al uso de otras escalas (como las escalas de validez, de contenido, Harris y complementarias) como auxiliares de interpretación. Por supuesto, las escalas distintas a las escalas clínicas llevan su propio bagaje relacionado con la interpretación. Por ejemplo, aunque una escala F elevada pueda reflejarse en la validez del protocolo, también puede reflejar una psicopatología severa. Aquí, una vez más, necesitamos evaluar otras escalas para obtener conclusiones acerca del significado de una escala en particular.

En general, una profusión de confiabilidad y estudios de validez apoyan el uso continuo del MMPI-2. Cuán útil es el MMPI-2, de manera exacta, para poblaciones no caucásicas es una pregunta que ha recibido mucha atención desde la publicación de la prueba. El MMPI original fue estandarizado entre caucásicos, pero el MMPI-2 usó una muestra normativa más amplia. La investigación ha apoyado la pertinencia del MMPI-2 y sus normas para individuos afroamericanos (Timbrook y Graham, 1994) y estadounidenses de origen hispano (Whitworth y Unterbrink, 1994). Sin embargo, existe alguna evidencia que sugiere que el MMPI-2 puede predecir una psicopatología menor a la real en los afroamericanos (Arbisi *et al.*, 2002).

Como hemos enfatizado a lo largo de este libro, los profesionales de la evaluación deben ser sensibles a las diferencias culturales cuando realizan evaluaciones. Las pruebas pueden tener una profunda influencia en un ambiente cultural, pero producir efectos cuestionables en otro. Por ejemplo, aunque la idea de Holland de una personalidad vocacional y su teoría asociada de seis temas ocupacionales ha sido recibida con entusiasmo en Estados Unidos, han surgido cuestionamientos respecto a su aplicabilidad en otras culturas (Fouad y Dancer, 1992; Hansen, 1987; Khan *et al.*, 1990; Swanson, 1992). Juni (1996) caracterizó el modelo de cinco factores del NEO PI-R como “vinculado de manera intrínseca con la cultura y el idioma que lo generaron”, aunque McCrae *et al.* (1998) han objetado esta afirmación. Ahora, examinemos más de cerca algunos asuntos relacionados con la cultura en la evaluación de la personalidad.

Evaluación de la personalidad y cultura

Todos los días, a todo lo largo de Estados Unidos, en forma rutinaria se recurre a los profesionales de la evaluación para evaluar la personalidad y variables relacionadas desde una perspectiva cultural y lingüística, de diversas poblaciones. No obstante, la evaluación de la personalidad es

todo excepto rutina con niños, adolescentes y adultos de culturas nativas estadounidenses, hispanas, asiáticas, afroamericanas y otras que pueden haber estado representadas de manera inferior en el desarrollo, estandarización e interpretación de los protocolos de las medidas usadas. En especial con miembros de poblaciones diversas desde el punto de vista cultural y lingüístico sería inapropiado, si no es que irresponsable, un enfoque rutinario y habitual respecto a las pruebas psicológicas. Lo que se requiere es un evaluador capacitado profesionalmente capaz de llevar a cabo una evaluación significativa, que sea sensible a la forma en que se relacionan las culturas con las conductas y los conocimientos que van a ser medidos (López, 2000).

Antes de poder emplear cualquier herramienta de evaluación de la personalidad —una entrevista, una prueba, un protocolo para la observación conductual, un portafolios o cualquier otra cosa— y antes de que los datos derivados de un intento de medición puedan ser imbuidos de significado, de manera ideal el evaluador considerará algunas cuestiones importantes con respecto a un evaluado en particular. Muchos de estos temas se relacionan con el nivel de aculturación, valores, identidad, perspectiva del mundo y el idioma del evaluado. La exploración profesional de estas áreas es capaz de producir no sólo la información necesaria como un prerrequisito para la evaluación formal de la personalidad también con una riqueza de información relacionada con la personalidad en sí misma. Examinemos estas cuestiones con más detenimiento.

Aculturación y consideraciones relacionadas

La **aculturación** es un proceso progresivo por el que los pensamientos, conductas, valores, perspectiva del mundo e identidad de un individuo se desarrollan con relación al pensamiento, comportamiento y valores generales de un particular grupo cultural. El proceso de aculturación comienza con el nacimiento, un periodo en el cual los familiares o quienes se hagan cargo del recién nacido funcionarán como agentes de la cultura.¹⁰ En los años siguientes, otros miembros de la familia, maestros, semejantes, libros, películas, teatro, periódicos, programas de radio y televisión así como otros medios masivos de comunicación servirán también como agentes de aculturación. A través de ese proceso, el individuo desarrollará formas de pensamiento, sentimientos y comportamientos aceptados por la cultura.

En los años recientes se ha desarrollado una serie de pruebas y cuestionarios para obtener una comprensión de los niveles de aculturación de los evaluados en relación en su cultura nativa o su cultura dominante. En la tabla 11-4 se presenta una muestra de la medida de esos niveles. Cuando examine esa lista, tenga en mente que la cantidad de investigación psicométrica realizada sobre estos instrumentos varía. Algunos de estos instrumentos pueden tener poco contenido válido, si es que lo tienen. En tales casos, debe tener cuidado. Si debe usar cualquiera de estas medidas, sería conveniente que buscara más información acerca de ellas en algún recurso como el Anuario de mediciones mentales (*Mental Measurements Yearbook*). Quizá el uso más apropiado de muchas de estas pruebas sería el de derivar hipótesis para futuras pruebas por medio de otras herramientas de evaluación. A menos que exista evidencia suficiente para legitimar el uso de un instrumento particular con miembros de una población específica, los datos derivados de cualquiera de estas pruebas y cuestionarios no deben usarse por sí solos para hacer una selección, tratamiento, colocación o cualquier otra decisión importante. Algunas de nuestras propias opiniones acerca de la evaluación de la aculturación y variables relacionadas se presentan en la sección *Close-up*.

El aprendizaje de los *valores* está íntimamente entrelazado con la aculturación. **Valor**, es aquello que un individuo aprecia o los ideales en los que cree. Un tratamiento inicial sistemático de este tema estaba incluido en un libro titulado *Tipos de Personas* (*Types of Men*, Spranger, 1928), el

10. El proceso de aculturación puede comenzar antes del nacimiento. Parece razonable suponer que la nutrición y otros aspectos del cuidado prenatal de la madre pueden tener implicaciones en el gusto y otras preferencias del recién nacido.

Tabla 11-4
Algunas medidas de aculturación publicadas

Fuente	Descripción
Cuestionario de aculturación (Smither y Rodríguez-Giegling, 1982)	Diseñado para ser usado con miembros de varias poblaciones de refugiados, este cuestionario comprende la disposición del evaluado para aculturarse.
Escala de estimación de aculturación para mexicanos-estadounidenses (Acculturation Rating Scale for Mexican Americans; Cuéllar, 1980)	Una prueba diseñada para ser usada con mexicanos-estadounidenses como una medida de aculturación mexicana.
Aculturación afroamericana (African American Acculturation; Snowden y Hines, 1999)	Comprende las preferencias culturales relacionadas con la cultura y los medios, el grado de comodidad con la interacción social interracial y las actitudes respecto a la confianza en los parientes así como el atractivo de un matrimonio interracial.
Escala africana de autoconocimiento (African Self-Consciousness Scale; Baldwin y Bell, 1985)	Una prueba diseñada para ser usada en conjunción con una teoría personal afrocéntrica (Baldwin, 1984). Incluye componentes diseñados para medir diversas variables, como aquellas relacionadas con la oposición a la opresión. La validez de la teoría de la que se deriva y de la prueba en sí permanece en espera de ser documentada.
Medida de aculturación india-asiática (Asian Indian Acculturation Measure; Sodowsky y Carey, 1988)	Este cuestionario publicado en el contexto de un artículo periodístico puede tener valor exploratorio en función de los conocimientos que produce respecto a la aculturación india-asiática.
Escala de valores asiáticos (Asian Values Scale; Kim, 1999)	Desarrollada para ayudar en la provisión de servicios psicológicos culturalmente relevantes y sensibles al enfocarse en la evaluación de valores.
Medida de asimilación para indios spokane (Assimilation Measure for Spokane Indians; Roy, 1962)	Una medida diseñada para evaluar el grado de asimilación, entre otros factores.
Escala de aculturación para niños (Children's Acculturation Scale; Franco, 1983)	Diseñada para ser usada como una herramienta para aprender sobre los niños mexicanos-estadounidenses, este es un cuestionario de diez reactivos que debe ser contestado por el maestro del niño.
Medidas de aculturación chinas (Chinese Acculturation Measures; Yao, 1979)	Dos pruebas, una de cultura china tradicional y la otra de asimilación china-estadounidense, las cuales pueden ser de valor para propósitos exploratorios con personas que han emigrado de China a Estados Unidos.
Cuestionario de identidad conductual cubana (Cuban Behavioral Identity Questionnaire; García y Lega, 1979)	Una escala sucinta para medir la aculturación de los cubanos-estadounidenses.
Cuestionario cultural de atributos de salud (Cultural Health Attributions Questionnaire; Murguía, 2000)	Desarrollada en respuesta a la necesidad de una medida que capturara el rango completo de creencias sobre la salud entre latinos y su visión del mundo que incluye complejas creencias acerca de la etiología, expresión de síntomas y tratamiento de las enfermedades.
Inventario de estilo de vida cultural (Cultural Life Style Inventory; Mendoza, 1989)	Desarrollada para ser usada con adolescentes y adultos mexicanos-estadounidenses, esta prueba mide varios aspectos de la aculturación.
Cuestionario de identidad étnica (Ethnic Identity Questionnaire; Masuda, 1970)	Un cuestionario diseñado para ser usado con japoneses-estadounidenses.
Versión de la escala adolescente para la cultura hawaiana (Hawaiian Culture Scale-Adolescent Version (Hishinuma, 2000)	Fuentes de medidas de aprendizaje acerca del estilo de vida hawaiano y la extensión en que se valoran las creencias hawaianas y no hawaianas.
Escala de asimilación india (Indian Assimilation Scale; Howe Chief, 1940)	Desarrollada para ser usada con mujeres jóvenes, esta prueba explora actitudes hacia la asimilación, el linaje nativo americano y factores relacionados.
Escalas de contacto intercultural e identificación occidental (Intercultural Contact and Western Identification Scales; Chance, 1965)	Diseñada para ser usada con poblaciones esquimales.
Escala de aculturación multicultural (Multicultural Acculturation Scale; Wong-Rieger y Quintana, 1987)	Diseñada para ser usada con personas con diversos antecedentes culturales.
Inventario de experiencia multicultural (Multicultural Experience Inventory; Ramírez, 1984).	Desarrollada para su uso con mexicanos-estadounidenses, esta prueba se enfoca en varios aspectos de aculturación, biculturalismo y participación multicultural.
Inventario de autoidentidad (Self-Identity Inventory; Seving y otros, 2000)	Desarrollada para ayudar a entender la forma en que los miembros de grupos minoritarios difieren dentro de, y entre, los grupos en sus percepciones y reacciones a la opresión.
Escala de tensión social, de actitudes, familiar y ambiental acultural (Social, Attitudinal, Familial, and Environmental Acculturative Stress Scale; Padilla, 1985)	Mide la tensión de adaptarse a una nueva cultura, incluyendo la discriminación percibida y las barreras a la adaptación, así como variables relacionadas. Se desarrolló para usarse con examinados japoneses, pero puede ser utilizada en una amplia variedad de poblaciones (véase, por ejemplo, Joiner y Walker, 2002).
Escala de aculturación de autoidentidad asiática de Suinn-Lew (Suinn-Lew Asian Self-Identity Acculturation Scale; Suinn, 1987)	Diseñada para ser usada con personas de varias ascendencias asiáticas.

Evaluación de la aculturación y variables relacionadas

Pueden plantearse diversas interrogantes importantes concernientes a la aculturación y variables relacionadas respecto a evaluados de poblaciones diversas desde el punto de vista cultural. Muchos tipos generales de preguntas de entrevista pueden producir conocimientos ricos respecto a áreas superpuestas de aculturación, valores, visión del mundo e identidad. A continuación presentamos una muestra de dichas preguntas. Antes de plantear en realidad éstas u otras preguntas a los evaluados, algunas advertencias son apropiadas. Tenga en cuenta la importancia crítica de la empatía cuando se realiza una entrevista. Sea sensible a las diferencias culturales en la disposición a participar en una autorrevelación respecto a la familia u otros asuntos que pueden percibirse como demasiado personales para analizarlos con un extraño. Esté dispuesto y sea capaz de cambiar la redacción de estas preguntas si necesita proporcionar al evaluado una mayor comprensión acerca de ellas y a cambiar el orden de estas preguntas, para evitar que un evaluado responda a más de una pregunta con la misma respuesta. Escuche con atención y no dude en investigar por más información si percibe que vale el esfuerzo hacerlo. Por último, observe que la relevancia de cada una de esas preguntas variará de acuerdo con los antecedentes y experiencias únicas de socialización de cada evaluado.

- Describese usted mismo.
- Describa a su familia. ¿Quiénes viven en su hogar?
- Describa las funciones en su familia, como el papel de la madre, el papel del padre, el papel de la abuela, el papel del hijo, y así en forma sucesiva.
- ¿Qué tradiciones, rituales o costumbres le fueron transmitidos por los miembros de su familia?
- ¿Qué tradiciones, rituales o costumbres piensa que es importante transmitir a la siguiente generación?
- Con respecto a su situación familiar, ¿qué obligaciones considera tener usted?
- ¿Qué obligaciones tiene su familia con usted?
- ¿Qué papel representa su familia en la vida cotidiana?
- ¿Cómo difiere la responsabilidad de los hombres y las mujeres desde su propia perspectiva cultural?
- ¿Qué clase de música le gusta?
- ¿Qué clase de alimentos ingiere en forma rutinaria?
- ¿Qué cosas considera divertido hacer? ¿Cuándo hace estas cosas?
- Describese a sí mismo en la forma en que piensa que la mayoría de las demás personas lo describirían a usted. ¿Cómo considera que difiere su propia autodescripción de esa descripción?
- ¿Cómo respondería a la pregunta “¿Quién es usted?” con referencia a su propio sentido de identidad personal?
- ¿Con cuál grupo o cuáles grupos culturales se identifica más? ¿Por qué?
- ¿Qué aspecto de la historia del grupo con el que se identifica es más significativo para usted? ¿Por qué?
- ¿Quiénes son algunas de las personas que han influido más en usted?
- ¿Cuáles son algunas de las cosas que le han sucedido en el pasado que más han influido en usted?

cual enumeraba diferentes tipos de personas basado en si éstas valoraban cosas como la verdad, el sentido práctico y el poder. El libro sirvió como inspiración para un tratamiento aún más sistemático del tema (Allport *et al.*, 1951). Casi de inmediato, se habían publicado diversos sistemas para enumerar y clasificar valores.

Rokeach (1973) estableció una diferencia entre lo que él llamó valores *instrumentales* de los *terminales*. Los **valores instrumentales** son principios rectores para ayudar a alguien a alcanzar algún objetivo. La honestidad, la imaginación, la ambición y la alegría son algunos ejemplos de valores instrumentales. Los **valores terminales** representan los principios rectores y un modo de comportamiento que los hacen un objetivo final. Una *vida confortable*, una *vida emocionante*, una *sensación de logro* y *autorrespeto* son algunos ejemplos de valores terminales. Otros sistemas de cla-

- ¿Qué fuentes de satisfacción se asocian con su forma de ser?
- ¿Qué fuentes de insatisfacción o conflicto se asocian con su forma de ser?
- ¿Cómo se designa usted cuando se le pregunta acerca de su etnicidad?
- ¿Cuáles son sus sentimientos respecto a su identidad racial y étnica?
- Describa su recuerdo más agradable cuando niño.
- Describa su recuerdo menos agradable cuando niño.
- Describa las formas en que generalmente aprende nuevas cosas. ¿En qué formas podrían haber influido los factores culturales en este estilo de aprendizaje?
- Describa las formas en que de manera característica resuelve los conflictos con otras personas. ¿Qué influencia podrían tener los factores culturales en esta manera de resolver conflictos?
- ¿Cómo describiría su visión general del mundo?
- ¿Cómo caracterizaría la naturaleza humana en general?
- ¿Cuánto control cree usted tener sobre las cosas que le suceden? ¿Por qué?
- ¿Cuánto control cree usted tener sobre su salud? ¿Sobre su salud mental?
- ¿Cuáles son sus pensamientos respecto al papel del trabajo en la vida diaria? ¿Su identidad cultural ha influido de alguna manera en sus opiniones respecto al trabajo? De ser así, ¿cómo?
- ¿Cómo caracterizaría el papel de los doctores en el mundo que le rodea?
- ¿Cómo caracterizaría el papel de los abogados en el mundo que le rodea?
- ¿Cómo caracterizaría el papel de los políticos en el mundo que le rodea?
- ¿Cómo caracterizaría el papel de la espiritualidad en su vida diaria?
- ¿Cuáles son sus sentimientos acerca del uso de drogas ilegales?
- ¿Cuál es el papel del juego en la vida diaria?
- ¿Cómo caracterizaría la relación ideal entre los seres humanos y la naturaleza?
- ¿Qué define a una persona que tiene poder?
- ¿Qué sucede cuando uno muere?
- ¿Tiende a vivir su vida más en el pasado, el presente o el futuro? ¿Qué influencias en usted piensa que le ayudaron a moldear esta forma de vida?
- ¿Cómo caracterizaría sus actitudes y sentimientos sobre las personas mayores en su familia? ¿Sobre las personas mayores en la sociedad en general?
- Describa sus pensamientos sobre la policía local y el sistema de justicia criminal.
- ¿Cómo se ve a sí mismo dentro de diez años?

sificación de acuerdo a los valores se enfocan sobre los valores en contextos específicos, como escenarios de empleo. La recompensa financiera, la seguridad en el empleo o el prestigio pueden influir de manera prominente en las decisiones de empleo o en los sentimientos de satisfacción por el trabajo.

Desde una perspectiva antropológica y cultural, Kluckhohn (1954, 1960; Kluckhohn y Strodtbeck, 1961) concibió los valores como respuestas a preguntas clave con las que deben lidiar las civilizaciones. Así, por ejemplo, a partir de las interrogantes respecto a cómo debe relacionarse el individuo con el grupo, surgen valores sobre las prioridades individuales contra las grupales. En

SÓLO PIENSE...

¿Qué valores figura de manera sobresaliente en la elección de su propia carrera?

una cultura, las respuestas a estas preguntas podrían adoptar la forma de normas y sanciones que fomentan la conformidad estricta y la poca competencia entre los miembros del grupo. En otra cultura, las normas y sanciones pueden fomentar la individualidad y la competencia entre miembros del grupo. En este contexto, podemos comenzar a apreciar cómo los miembros de diferentes grupos culturales pueden crecer con valores totalmente diferentes, que fluctúan desde las opiniones sobre diversos “ismos” (como individualismo contra colectivismo) hasta las opiniones sobre lo que es trivial y aquello por lo que vale la pena morir. Los diferentes valores en las personas de diversas culturas llevados a la posición de evaluación pueden traducirse en una amplia variedad de sistemas motivacionales y de incentivo. Comprender los valores de un individuo es una parte integral de la comprensión de la personalidad.

También íntimamente vinculado con el concepto de aculturación está el concepto de identidad personal. **Identidad** en este contexto puede ser definida como un conjunto de características cognoscitivas y conductuales mediante las cuales los individuos se definen a sí mismos como miembros de un grupo particular. Levine y Padilla (1980) definieron **identificación** como un proceso por el que un individuo adopta un patrón de comportamiento característico de otras personas y se refiere a éste como uno de los “temas centrales con los que un grupo definido como minoría étnica debe tratar” (p. 13). Haciendo eco de este sentimiento, Zúñiga (1988) sugirió que la pregunta “¿Cómo se define a sí mismo cuando se le pregunta por su etnicidad?” podría ser usada como un rompehielos para esta área de la evaluación. Ella continúa:

La forma en que el cliente de una minoría maneja su respuesta ofrece evidencia de la comodidad con su identidad. Un cliente mexicano-estadounidense que responde diciendo “Soy un estadounidense y soy como todos los demás”, exhibe una defensividad que demanda una amable investigación. Una cliente declaró avergonzada que siempre se había hecho pasar por española. Ella usaba esta autodesignación desde que consideró que el término “mexicana” era sucio (p. 291).

Otra variable clave de la personalidad relacionada con la cultura se refiere a la forma en que un evaluado tiende a ver el mundo. Como implica su nombre, **visión del mundo** es la forma única en que las personas interpretan y dan sentido a sus percepciones como consecuencia de sus experiencias de aprendizaje, antecedentes culturales y variables relacionadas.

Nuestro perfil general de la personalidad comenzó con una consideración de algunas perspectivas superficiales, establecidas acerca de esta materia con muchas facetas. Hicimos referencia a la ahora clásica tonada del rock clásico “Personalidad” y su “definición” de personalidad en lo referente a las variables observables como *caminar, hablar, sonreír y cautivar*. Aquí, al final del capítulo, hemos andado un largo camino al considerar muchos elementos más personales, no observables de la personalidad, en forma de constructos como *visión del mundo, identificación, valores y aculturación*. En el siguiente capítulo, haremos un análisis más cercano de las herramientas usadas para evaluar la personalidad.

Autoevaluación

Pruebe su comprensión de los elementos de este capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaturas:

aculturación
 aquiescencia
 análisis del perfil
 autoconcepto
 autodescripción
 Cinco grandes

claves de criterio empíricas
 código Welsh
 criterio
 diferenciación de autoconcepto
 diferencial semántico
 efecto de halo

entrevista estructurada
 error de generosidad (lenidad)
 error de tendencia central
 error de severidad
 escala de validez
 estado

estilo de respuesta	medida de autoconcepto	personalidad
evaluación de la personalidad	método ideográfico	personalidad Tipo A
formato de opción forzada	método nomotético	personalidad Tipo B
grupo control (para el MMPI)	MMPI	rasgo
grupo criterio	MMPI-A	técnica de clase Q
identidad	MMPI-2	tipo de personalidad
identificación	NEO PI-R	valores
locus de control	perfil	valores instrumentales
manejo de la impresión	perfil de la personalidad	valores terminales
marco de referencia	perfilador	visión del mundo

Un vistazo a la red

Consulte los siguientes sitios en la red para obtener más información acerca de los temas examinados en este capítulo.

NEO PI-R

www.psychpage.com/objective/neopir.html

www.rpp.on.ca/neopir.htm

MMPI

http://alpha.fdu.edu/psychology/horror_evaluation.htm

www.aaml.org/MMPI.htm

www.falseallegations.com/mmpi-bw.htm

MMPI-2

www.pearsonassessments.com/tests/mmpi_2.htm

www.falseallegations.com/mmpi-bw.htm

MMPI-A

www.pearsonassessments.com/tests/mmpia.htm

La búsqueda autodirigida

www.self-directed-search.com/Holland.html

Pruebas de personalidad clasificadas en la red (se aplican las precauciones usuales)

http://psychology.about.com/library/jv/bljv_pers.htm?once=true&

www.od-online.com/app/profiler-intro.asp

www.outofservice.com/bigfive

Métodos de evaluación de la personalidad

Algunas personas ven al mundo como un sitio lleno de amor y bondad, mientras que otras lo consideran lleno de odio y maldad. Algunas personas equiparan la *vida* con los excesos conductuales, mientras que otras se esfuerzan por alcanzar la moderación en todo. Algunas personas tienen percepciones relativamente realistas de sí mismas, en tanto que otras funcionan conforme a autoimágenes burdamente distorsionadas así como percepciones imprecisas acerca de la familia, amigos y conocidos. Para los psicólogos y otros investigadores interesados en explorar las

diferencias entre las personas con respecto a éstas y otras dimensiones existen muchas herramientas disponibles. En este capítulo analizaremos algunas de las herramientas para la evaluación de la personalidad, incluyendo los métodos proyectivos de evaluación y la evaluación conductual. Comenzaremos con los métodos objetivos.

SÓLO PIENSE...

¿Qué tan objetivos son los métodos objetivos de evaluación?

Métodos objetivos

Comúnmente asociados con las pruebas de lápiz y papel y con aquellas que son aplicadas por computadora, los **métodos objetivos de evaluación de la personalidad** contienen de manera característica reactivos de respuesta breve en los que la tarea de la persona evaluada consiste en seleccionar una respuesta de entre dos o más opciones proporcionadas y la calificación se realiza según procedimientos establecidos que implican poco o ningún juicio por parte del calificador. Como ocurre con las pruebas de capacidad, los métodos objetivos de evaluación de la personalidad pueden incluir reactivos escritos en formato de opción múltiple, de verdadero/falso o de relacionar columnas.

Mientras que una respuesta particular en una prueba objetiva de capacidad puede ser calificada como correcta o incorrecta, una respuesta en una prueba objetiva de personalidad es calificada con referencia a las características de personalidad que están siendo medidas o de acuerdo a la validez del patrón de respuestas de la persona evaluada. Por ejemplo, en una prueba de personalidad en la que una respuesta de *verdadero* es considerada indicativa de la presencia de un rasgo particular, varias respuestas *verdadero* a los reactivos de *verdadero/falso* serán interpretadas con referencia a la probable fuerza con que presenta ese rasgo la persona evaluada. Bueno, tal vez.

Si el individuo evaluado también respondió verdadero a los reactivos que indican *ausencia* del rasgo así como a los reactivos que rara vez son ratificados como tales por los examinados en general, la validez de ese protocolo estará en duda. El escrutinio del protocolo puede sugerir una irregularidad de cierto tipo. Por ejemplo, es posible que se haya respondido de manera inconsis-

tente a los reactivos, en forma aleatoria, o contestando *verdadero* a todas las preguntas. Como vimos en el capítulo anterior, algunas pruebas objetivas de personalidad se construyen con escalas de validez u otros mecanismos (como un formato de opción forzada), diseñados para detectar o evitar los patrones de respuesta que pondrían en duda el valor de las calificaciones.

Las pruebas objetivas de personalidad comparten muchas ventajas con las pruebas objetivas de capacidad. Los reactivos pueden ser respondidos con rapidez, permitiendo la aplicación de muchos de ellos de modo que cubran diversos aspectos del rasgo o rasgos para cuya evaluación fue diseñada la prueba. Si los reactivos de una prueba objetiva están bien redactados, requerirán de poca explicación; esto los hace muy adecuados para aplicaciones tanto grupales como computarizadas. En general, los reactivos objetivos se pueden calificar de manera rápida y confiable por diversos medios, desde la calificación a mano (generalmente con la ayuda de una plantilla que se coloca sobre el protocolo de prueba) hasta la calificación por computadora. El análisis e interpretación de tales pruebas puede ser casi tan rápido como la calificación, en especial si es realizado mediante computadora y con los programas adecuados.

Aunque los reactivos de las pruebas objetivas de personalidad comparten muchas características con las medidas objetivas de capacidad, nos apresuramos a añadir que el adjetivo *objetivo* es un tanto inapropiado cuando se aplica a las pruebas y a la evaluación de la personalidad. Para los reactivos de respuesta breve en una prueba de *capacidad*, se prefirió el término *objetivo* porque todos los reactivos contenían únicamente una respuesta correcta. Bueno, eso tampoco siempre fue cierto, pero así fue como se diseñaron.

En contraste con la calificación, por ejemplo, de las pruebas de ensayo, la calificación de las pruebas objetivas de capacidad, de opción múltiple, daba poco lugar para la emoción, el prejuicio o el favoritismo por parte del calificador de la prueba. La calificación era desapasionada y —a falta de un mejor término— objetiva. Pero a diferencia de las pruebas objetivas de capacidad, las pruebas objetivas de personalidad de manera característica no contienen ninguna respuesta correcta. Más bien, la selección de una opción particular de entre los reactivos de opción múltiple proporciona información relacionada con algún aspecto del examinado, tal como la presencia, ausencia o intensidad de una variable relacionada con la personalidad. Sí, la calificación de tales pruebas puede aún seguir siendo desapasionada y objetiva. Sin embargo, la “objetividad” de la puntuación derivada de una supuesta prueba objetiva de la personalidad puede estar sujeta a debate. Consideremos, por ejemplo, una prueba de personalidad, escrita con un formato objetivo, diseñada para detectar la existencia de un conflicto edípico no resuelto. El grado en que esos resultados de prueba serán considerados “objetivos” está vinculado de manera inextricable con los puntos de vista personales acerca de la validez de la teoría psicoanalítica y, de manera más específica, del constructo *conflicto edípico*.

Otro asunto relacionado con el uso del adjetivo *objetivo* para determinar el significado del término *prueba de personalidad* tiene que ver con el autorreporte y la notoria falta de objetividad que puede estar asociada a éste. Los autoreportes de los examinados acerca de lo que les agrada o les desagrada, con lo que están de acuerdo o en desacuerdo, de lo que hacen o dejan de hacer, etcétera, puede ser cualquier cosa menos “objetiva” por muchas razones. Es posible que algunos examinados carezcan de la autopercepción necesaria para contestar de una manera que pudiésemos considerar objetiva. Algunos responderán de acuerdo a lo que ellos consideren que los colocará en la mejor o la peor de las apariencias posibles, dependiendo de sus propósitos. En otras palabras, es posible que intenten manejar las impresiones haciéndose pasar por buenos o por malos.

En última instancia, el término *objetivo*, de la manera en que es aplicado a la mayoría de las pruebas de personalidad, puede ser mejor considerado como una descripción abreviada de un formato de prueba. Las pruebas objetivas de personalidad son objetivas en el sentido de que emplean un formato de respuesta breve, característicamente de opción múltiple, que deja poco espacio, si es que deja alguno, para el sentido común respecto a la calificación. Describir una prueba de personalidad como objetiva sirve más bien para distinguirla de las pruebas proyectivas y de otros métodos de medición que para transmitir información sobre la realidad, tangibilidad u objetividad de las calificaciones derivadas de ella. No obstante, como veremos en nuestro análisis de los métodos proyectivos, las pruebas pueden ser objetivas en su formato y también proyectivas.

Métodos proyectivos

Suponga que las luces de su salón de clases fueran atenuadas y a todos se les pidiera que observaran el pizarrón limpio durante un minuto o dos. Y suponga que después se les sugiriera que sacaran un cuaderno para escribir lo que imaginaron haber visto en el pizarrón, además del pizarrón en sí. Si usted examinara lo que escribió cada uno de sus compañeros, podría encontrar tantas cosas diferentes como el número de estudiantes que respondieron. Podría suponer que los estudiantes vieron en el pizarrón —o, de manera más precisa, *proyectaron*— algo que no estaba realmente allí, sino en (o dentro de) sus propias mentes. Podría suponer además que la respuesta de cada estudiante sobre el pizarrón en blanco reflejó algo muy descriptivo acerca de la estructura de la personalidad del estudiante.

La **hipótesis proyectiva** sostiene que un individuo proporciona estructura a los estímulos desestructurados de una manera consistente con su propio patrón único de necesidades, temores, deseos, impulsos, conflictos y maneras de percibir y responder, tanto conscientes como inconscientes. En forma similar, podemos definir al **método proyectivo** como una técnica de evaluación de la personalidad en el cual se hace cierto juicio sobre la personalidad del evaluado en base al desempeño de una tarea que implica proveer algún tipo de estructura a estímulos relativamente desestructurados o incompletos. Casi cualquier estímulo relativamente desestructurado serviría para este propósito. En una escena de la obra de Shakespeare, *Hamlet*, Polonio y Hamlet discuten qué puede verse en las nubes. Efectivamente, las nubes pueden ser utilizadas como estímulo proyectivo.¹ Pero los psicólogos, siendo como son, esclavos del sentido práctico (y de los métodos científicos), han desarrollado medidas proyectivas de la personalidad más confiables que las nubes y más portátiles que los pizarrones. Manchas de tinta, imágenes, palabras, dibujos y otras cosas han sido utilizadas como estímulos proyectivos.

SÓLO PIENSE...

Nombre alguna otra cosa que pueda ser utilizada como estímulo proyectivo con propósitos de evaluación de la personalidad. Describa brevemente cómo podría validar esta nueva prueba.

A diferencia de los métodos de autorreporte o autodescripción, las pruebas proyectivas son métodos indirectos de evaluación de la personalidad. La tarea del examinado puede ser hablar sobre algo o acerca de otra persona y a partir de sus respuestas se hacen inferencias acerca de su personalidad. En una tarea de este tipo, la capacidad —y posiblemente la tendencia— de los examinados para simular es reducida grandemente. También, en algunas tareas proyectivas se reduce en cierto grado la necesidad de que la persona evaluada posea un gran dominio del idioma. Se requieren mínimas habilidades lingüísticas para responder a un dibujo o para crearlo.

Por esa razón, y debido a que algunos métodos proyectivos pueden estar menos vinculados con la cultura que otras medidas de la personalidad, los defensores de las pruebas proyectivas creen que existen ventajas todavía inexploradas en cuanto a la utilidad de estas pruebas entre culturas diferentes. Los defensores de las medidas proyectivas también argumentan que una de las principales ventajas de estas medidas es que acceden a material inconsciente, así como consciente. De acuerdo a los mismos términos utilizados por el hombre que acuñó el término *métodos proyectivos*, “las cosas más importantes acerca de un individuo son aquellas que no puede decir o que no dirá” (Frank, 1939, p. 395).²

Las pruebas proyectivas nacieron del espíritu de rebelión contra los datos normativos y a través de los intentos de los investigadores de la personalidad por transformar el estudio de la personalidad en el estudio de rasgos específicos con intensidades variables. Esta orientación está

1. En la realidad, las nubes *han* sido utilizadas como estímulos proyectivos. La Prueba de imágenes con nubes de Wilhelm Stern, en la que a los sujetos se les pide que describan las imágenes que ven en las nubes, fue una de las primeras medidas proyectivas.

2. El primer uso publicado del término *métodos proyectivos* del que tenemos noticia apareció en un artículo titulado “Métodos proyectivos en el estudio psicológico de los niños” de Ruth Horowitz y Lois Barclay Murphy (1938). Sin embargo, estas autoras habían leído el manuscrito de Lawrence K. Frank (1939), que no se había publicado hasta ese momento, y le concedieron el crédito de haber “aplicado el término ‘métodos proyectivos’”.

ejemplificada en el trabajo de Frank (1939), quien reflexionaba, “Es interesante ver la manera en que los estudiosos de la personalidad han intentado resolver el problema de la individualidad con métodos y procedimientos diseñados para estudiar las uniformidades y las normas que ignoran o subordinan la individualidad, considerándola como una desviación problemática que se aleja de la verdadera, superior y única tendencia central, moda, promedio, etcétera” (pp. 392-393).

Contrarias a los métodos de evaluación de la personalidad que se enfocaban en el individuo desde una perspectiva normativa, basada en las estadísticas, las técnicas proyectivas fueron en alguna época la técnica a elegir por enfocarse en el individuo desde una perspectiva meramente clínica, una perspectiva que examinaba la manera única en que un individuo proyecta sobre un estímulo ambiguo “su manera única de ver la vida, sus propósitos, su importancia, sus normas y, especialmente sus sentimientos” (Frank, 1939, p. 403). Sin embargo, como veremos, los años de experiencia clínica con estas pruebas y un creciente volumen de datos de investigación han hecho que la interpretación de las respuestas a los estímulos proyectivos se realice cada vez más con referencia a una norma.

Manchas de tinta como estímulos proyectivos

Derrame un poco de tinta en el centro de una hoja de papel en blanco y dóblela. Deje que seque. Ésta es la receta para una mancha de tinta. Las manchas de tinta no sólo son un elemento que utilizan los profesionales de la evaluación como estímulos proyectivos, sino que en la mente del público están asociadas en gran medida con la psicología en sí. La prueba más famosa de manchas de tinta es, por supuesto...

La prueba de Rorschach Herman Rorschach (figura 12-1) desarrolló lo que él llamó una “prueba de interpretación de formas” utilizando manchas de tinta como las formas a interpretar. En 1921 publicó su monografía sobre la técnica, *Psicodiagnósticos (Psychodiagnostics)*. En la última sección de esa monografía, Rorschach propuso las aplicaciones de su prueba a la evaluación de la personalidad. Proporcionó 28 estudios de caso en los que empleó a sujetos normales (mejor dicho, no diagnosticados) y a personas con diversos diagnósticos psiquiátricos (incluyendo neurosis, psicosis y enfermedad maniaco-depresiva) para ilustrar su prueba. Rorschach murió en forma repentina e inesperada a los 38 años de edad, justo un año después de la publicación de su libro. Un artículo de Rorschach, que escribió en colaboración con Emil Oberholzer titulado “La aplicación de la prueba de interpretación de formas” fue publicado de manera póstuma en 1923.



Figura 12-1
Herman Rorschach (1884-1922)

Rorschach fue un psiquiatra suizo cuyo padre había sido maestro de arte, cuyos intereses incluían el arte al igual que el psicoanálisis; en particular el trabajo de Carl Jung, quien había escrito ampliamente sobre los métodos para sacar a la luz el material inconsciente. En 1913, Rorschach publicó artículos sobre la manera en que el análisis de la producción artística de un paciente podría proporcionar una comprensión acerca de su personalidad. La prueba de manchas de tinta de Rorschach se publicó en 1921 y no tuvo éxito de inmediato. Rorschach murió de peritonitis al año siguiente, a la edad de 38 años, sin saber el enorme legado que dejaba. Para más información sobre Herman Rorschach, lea su Perfil de un autor de pruebas (Test Developer Profile) en nuestro sitio asociado en Internet en www.mhhe.com/cohentesting6.



Figura 12-2
Una mancha de tinta similar a las de la prueba de Rorschach

Al igual que Rorschach, nos referiremos a esta prueba tal como eso, una prueba. Sin embargo, los estudiantes deberían tener presente la controversia acerca de si en realidad es una prueba, un método, una técnica o algo más. Por ejemplo, Goldfried y *et al.* (1971) consideran a la prueba de Rorschach como una entrevista estructurada, y Korchin y Schuldberg (1981) la consideran “no tanto una prueba” sino más “un campo abierto y flexible para el estudio de las transacciones interpersonales” (p. 1151). También ha habido debate acerca de si es o no apropiado considerar a la prueba de Rorschach como un instrumento proyectivo (Acklin, 1995; Aronow *et al.*, 1995; Moreland *et al.*, 1995b; Ritzler, 1995). Por ejemplo, John Exner, una autoridad en todo lo relacionado con Rorschach, argumentaba que las manchas de tinta “no son totalmente ambiguas”, que la tarea no necesariamente “obliga a la proyección” y que “por desgracia, durante mucho tiempo la prueba de Rorschach ha sido clasificada de manera errónea como una prueba proyectiva” (1989, pp. 526-527; véase también Exner, 1997). A pesar de ello, la *prueba de Rorschach* continúa siendo poco más o menos sinónimo de *prueba proyectiva* entre los profesionales de la evaluación.

La prueba de Rorschach consiste en diez manchas de tinta bilateralmente simétricas (es decir, imágenes de espejo si se les dobla por la mitad), impresas en láminas separadas. Cinco manchas de tinta son acromáticas (lo cual quiere decir que no tienen color o que son en blanco y negro). Dos manchas de tinta son negras, blancas y rojas, y las tres restantes son multicolores. La prueba sólo incluye las láminas; no contiene algún manual o instrucción sobre su aplicación, calificación o interpretación. No existe ninguna explicación acerca de por qué algunas de las manchas son acromáticas y otras cromáticas (con color). A diferencia de la mayoría de las pruebas psicológicas que actualmente se publican y que trae consigo un manual de prueba e incluso un estuche opcional para transportarlo, esta prueba contiene 10 láminas empacadas en una caja de cartón; eso es todo.

Para satisfacer la necesidad de un manual de prueba y de instrucciones para la aplicación, calificación e interpretación, existen diversos manuales y compendios en donde se establecen una variedad de métodos (como Aronow y Reznikoff, 1976, 1983; Beck, 1944, 1945, 1952, 1960; Exner, 1974, 1978, 1986; Exner y Weiner, 1982; Klopfer y Davidson, 1962; Lerner, 1991, 1996a, 1996b; Piotrowski, 1957). El sistema que se utiliza de manera más generalizada es el “sistema comprensivo” diseñado por Exner. En breve analizaremos el sistema de Exner, pero primero ofrecemos una descripción muy general del proceso de aplicación, calificación e interpretación de la prueba de Rorschach.

Las láminas con manchas de tinta (figura 12-2) de manera inicial se presentan a la persona examinada, una a la vez, en orden numérico del 1 al 10. Se instruye al examinado para que diga qué hay en cada una de las láminas con una pregunta como “¿Qué podría ser esto?” Las personas examinadas tienen un enorme grado de libertad con la prueba de Rorschach. Por ejemplo, pueden girar las láminas y variar el número y extensión de sus respuestas a cada una de ellas. El examinador anota toda la información pertinente, incluyendo las respuestas literales del examinado, sus ademanes no verbales, el tiempo que tarda antes de dar la primera respuesta a cada

lámina, la posición de la lámina y así sucesivamente. El examinador no se involucra en ningún tipo de discusión concerniente a las respuestas del examinado durante la aplicación inicial de las láminas. Se realizan todos los esfuerzos posibles para darle a la persona evaluada la oportunidad de *proyectarse*, libre de cualesquiera distracciones externas.

Después de que el conjunto completo de láminas ha sido aplicado una vez, se realiza una segunda aplicación, llamada **interrogatorio**. Durante el interrogatorio, el examinador intenta determinar cuáles características de la mancha de tinta desempeñaron un papel en la articulación del **percepto** (percepción de una imagen) del examinado. Se hacen preguntas como “¿Qué hace que esto parezca (cualquier cosa)?”, y “¿Cómo es que usted ve (cualquier cosa que el examinado haya informado haber visto)?”, con la intención de aclarar lo que se ha visto y qué aspectos de la mancha de tinta tuvieron mayor influencia para formar la percepción. El interrogatorio proporciona información útil para calificar e interpretar las respuestas. El examinador también descubre si el examinado recuerda las respuestas anteriores, si sigue viendo el percepto original y si ahora es percibida alguna nueva respuesta.

También puede incluirse un tercer componente de la aplicación, conocido como **prueba de límites**. Este procedimiento permite que el examinador reestructure la situación haciendo preguntas específicas que proporcionen información adicional sobre el funcionamiento de la personalidad. Si, por ejemplo, el examinado ha utilizado la mancha de tinta completa al formar los perceptos a lo largo de toda la prueba, el examinador podría querer determinar si se llevó a cabo una elaboración a partir de los detalles en la mancha de tinta. Bajo tales condiciones, el examinador podría decir “A veces las personas usan parte de la mancha para ver algo”. De manera alternativa, el examinador podría señalar un área específica de la lámina y preguntar “¿A qué se parece esto?”

Otros objetivos de los procedimientos de la prueba de límites son 1) identificar cualquier confusión o error de comprensión acerca de la tarea, 2) ayudar al examinador a determinar si la persona evaluada es capaz de volver a enfocar los perceptos dado un nuevo marco de referencia y 3) ver si un examinado que haya sentido ansiedad por la naturaleza ambigua de la tarea puede desempeñarse mejor dada esta estructura añadida. Al menos un investigador de la prueba de Rorschach ha defendido la técnica de tratar de obtener una última respuesta de los examinados que consideran que ya han dado todas las respuestas que podían dar (Cerney, 1984). El razonamiento fue que los finales tienen muchos significados y que la última respuesta puede proporcionar una fuente de preguntas e inferencias aplicables a las consideraciones del tratamiento.

Las hipótesis acerca del funcionamiento de la personalidad se harán con base en todas las variables que hemos delineado (como el contenido de la respuesta, la localización de la misma, la cantidad de tiempo tomada para responder), además de muchas variables adicionales. En general, los protocolos de la prueba de Rorschach son calificados de acuerdo a varias categorías, incluyendo la ubicación, los determinantes, el contenido, la popularidad y la forma. La *ubicación* es la parte de la mancha de tinta que fue utilizada al formar el percepto. Los individuos pueden utilizar toda la mancha, una sección grande, una sección pequeña, un detalle diminuto o los espacios en blanco. Los *determinantes* son las características de la mancha de tinta que provocan aquello que el individuo percibe. Se consideran como determinantes la forma, el color, el sombreado o el movimiento que el individuo atribuye a la mancha de tinta. El *contenido* es la categoría de contenido de la respuesta. Los diferentes sistemas de calificación varían en algunas de las categorías calificadas. Algunas áreas características de contenido incluyen figuras humanas, figuras de animales, partes anatómicas, sangre, nubes, radiografías y respuestas sexuales. La *popularidad* se refiere a la frecuencia con la que se descubre que una cierta respuesta está correlacionada con una mancha de tinta específica o con una sección particular de una mancha. Una respuesta popular es aquella que se obtiene de manera frecuente de la población general. Una respuesta original es la que se observa de manera poco frecuente entre la población general. La *forma* de una respuesta se refiere a la precisión con la que la percepción del individuo encaja o se adecúa a la parte correspondiente de la mancha de tinta. La forma puede evaluarse como adecuada o inadecuada, o como buena o deficiente.

SÓLO PIENSE...

Para algunos, la prueba de Rorschach es más una entrevista estructurada que una prueba en sí. ¿Qué argumentos habrá en favor de este punto de vista?

Se considera que las categorías de calificación corresponden a diversos aspectos del funcionamiento de la personalidad. Las hipótesis acerca de los aspectos de la personalidad se basan tanto en el número de respuestas que caen dentro de cada categoría así como en la interrelación de las categorías. Por ejemplo, el número de las respuestas globales (que utilizan toda la mancha de tinta) en un protocolo de Rorschach está asociado típicamente con un proceso de pensamiento conceptual. El nivel de la forma está asociado con la prueba de realidad. De acuerdo con ello, se esperaba que los pacientes psicóticos lograran bajas calificaciones en el nivel de la forma. El movimiento humano ha sido asociado con la imaginación creativa. Las respuestas de color han sido asociadas con la reactividad emocional.

Los patrones de respuesta, los temas recurrentes y las relaciones recíprocas entre las diferentes categorías de calificación son consideradas al llegar a una descripción final del individuo a partir de un protocolo de Rorschach. Los datos relacionados con las respuestas de diversos grupos clínicos y no clínicos de adultos, adolescentes y niños se han recopilado en varios libros y publicaciones científicas.

La prueba de interpretación de formas de Rorschach estaba en su infancia al momento de morir su creador. Esta obra, huérfana en progreso, encontró un hogar receptivo en Estados Unidos, en donde fue nutrida por diferentes escuelas, cada una con su propia visión de la manera en que debía ser aplicada, calificada e interpretada. En este sentido, la prueba de Rorschach resulta ser, tal como fue definida por McDowell y Acklin (1996, p. 308), “una anomalía en el campo de la medición psicológica cuando se le compara con las pruebas objetivas y otras técnicas proyectivas”.

Aunque a la prueba en general se le conoce como “el Rorschach”, como si fuera un instrumento estandarizado, los profesionales e investigadores han empleado durante muchos años una variedad de sistemas Rorschach —eligiendo u optando en algunas ocasiones por los criterios interpretativos de uno o más sistemas—. Considere en este contexto un estudio de Saunders (1991), que se enfocó en los indicadores de abuso infantil en la prueba de Rorschach. Saunders (1991, p. 55) escribió: “Los protocolos de Rorschach fueron calificados utilizando el sistema de Rapaport *et al.* (1945-1946) como la estructura básica, pero se añadieron calificaciones especiales de cuatro tipos diferentes. Tomé prestadas dos de estas medidas adicionales de otros investigadores... y desarrollé las otras dos específicamente para este estudio”. Dada la variación que existía en la terminología y en las prácticas de aplicación y calificación, fácilmente se aprecia qué tan difícil podría ser reunir evidencia consistente y creíble sobre la solidez psicométrica de la prueba.³

En un libro que reseñó varios sistemas para la prueba de Rorschach, Exner escribió sobre lo recomendable de enfocar “el problema de la prueba de Rorschach mediante una integración de la investigación de los sistemas” (1969, p. 251). De manera subsiguiente, Exner desarrollaría esa integración, un “sistema comprensivo” como él lo definió (Exner, 1974, 1978, 1986, 1990, 1991, 1993; Exner y Weiner, 1982, 1995; véase también Handler, 1996), para la aplicación, calificación e interpretación de la prueba. El sistema de Exner ha sido bien recibido entre los clínicos y es probable que sea el sistema de mayor uso y que más se enseña en la actualidad.

Antes del desarrollo del sistema de Exner y de su adopción generalizada por clínicos e investigadores, las evaluaciones de la solidez psicométrica de la prueba de Rorschach tendían a ser mixtas, en el mejor de los casos. El sistema de Exner trajo cierto grado de uniformidad al uso de la prueba de Rorschach y con ello facilitó la comparación de “manzanas con manzanas” (o “murciélagos con murciélagos”) en los estudios de investigación. Sin embargo, sin importar el sistema de calificación utilizado, hubo varias razones por las que la evaluación de la solidez psicométrica de la prueba de Rorschach fue un asunto complicado. Por ejemplo, debido a que se considera que cada mancha de tinta tiene una cualidad única como estímulo, la evaluación de la confiabilidad

3. Una prueba llamada la Técnica de manchas de tinta de Holtzman (HIT, por sus siglas en inglés; Holtzman *et al.*, 1961) fue diseñada para tener mayor solidez psicométrica que cualquier prueba de manchas de tinta existente. Una descripción de la HIT, así como una especulación acerca de por qué nunca logró la popularidad y aceptación de la prueba de Rorschach.

con el método de división por mitades (*split-half*) sería inapropiada. De importancia histórica a este respecto, es el trabajo de Behn, quien, bajo la dirección de Sigmund Freud, intentó desarrollar una forma similar pero no alterna de la prueba llamada Behn-Rorschach (Buckle y Holt, 1951; Eichler, 1951; Swift, 1944).

Los procedimientos tradicionales de confiabilidad test-retest también eran inapropiados para ser usados con la prueba de Rorschach. Esto se debe al efecto de la familiaridad con las respuestas a las láminas y debido a que las respuestas pueden reflejar estados transitorios en lugar de rasgos perdurables. Es pertinente para el análisis sobre la confiabilidad del Rorschach la consideración de Exner (1983) de que “algunas calificaciones del Sistema comprensivo desafían el axioma de que algo no puede ser válido a menos que sea confiable” (p. 411).

La aceptación generalizada del sistema de Exner ha impulsado la causa de la confiabilidad de la prueba de Rorschach. Bueno, de la confiabilidad entre calificadores, de cualquier modo. Exner, al igual que otros, ha proporcionado amplia evidencia de que se pueden obtener niveles aceptables de confiabilidad entre los calificadores con la prueba de Rorschach. Utilizando el sistema de Exner, McDowell y Acklin (1996) reportaron un porcentaje medio total de concordancia de 87% entre los calificadores de la prueba de Rorschach. Sin embargo, como advirtieron estos investigadores, “la complejidad de los datos desarrollados por la prueba de Rorschach introducen obstáculos formidables para la aplicación de procedimientos y reglas estándares en el desarrollo de la prueba” (pp. 308-309). Bastante más pesimistas acerca de tales “obstáculos formidables” y mucho menos sutiles en sus conclusiones fueron Hunsley y Bailey (1999). Después de revisar la literatura sobre la utilidad clínica de la prueba de Rorschach escribieron acerca del “escaso apoyo de las miles de publicaciones” y expresaron dudas de que alguna vez se obtenga evidencia de que la prueba de Rorschach o de que el Sistema comprensivo puedan “contribuir, en la práctica clínica rutinaria, a una evaluación psicológica científicamente informada” (p. 274).

Hay otras reseñas de la literatura mucho más favorables a esta prueba que contradicen tal pesimismo (Bornstein, 1998, 1999; Ganellen, 1996; Meyer y Handler, 1997; Viglione, 1999). En su metaanálisis diseñado para comparar la validez de la prueba de Rorschach con la del MMPI, Hiller *et al.* (1999) concluyeron que “en promedio, ambas pruebas funcionan igualmente bien cuando se les utiliza para los propósitos que los expertos consideran apropiados” (p. 293). En un estilo similar, Stricker y Gold (1999, p. 240) reflexionaron que:

una prueba no es válida o inválida; más bien, existen tantos coeficientes de validez como propósitos para los que es empleada la prueba. La prueba de Rorschach puede demostrar su utilidad para varios propósitos y puede ser deficiente para varios otros.

Ellos fueron más allá al argumentar a favor de una aproximación para la evaluación que incorporase muchos tipos de métodos:

Sin duda, uno de los mejores poemas de Walt Whitman es el titulado “Canto a mí mismo”. Consideramos que todo lo que es hecho por la persona que es evaluada es un canto a sí misma. La prueba de Rorschach es un instrumento disponible para el clínico, quien tiene la tarea de escuchar toda la música (Stricker y Gold, 1999, p. 249).

Hace décadas, Jensen (1965, p. 509) opinó que “la tasa del progreso científico en la psicología clínica bien podría medirse por la rapidez y totalidad con la que se supere a la prueba de Rorschach”. Si esta afirmación fuese cierta, entonces, se puede considerar que la tasa de progreso científico en la psicología clínica va a paso de tortuga. La prueba de Rorschach sigue siendo una de las pruebas psicológicas de uso más constante y enseñada con mayor frecuencia. Es ampliamente utilizada en el trabajo forense y generalmente aceptada en los tribunales. Como concluyó Weiner (1997) en su evaluación sobre la posición de la prueba de Rorschach en su 75 aniversario, “la prueba es ampliamente utilizada y sumamente apreciada por los clínicos e

SÓLO PIENSE...

¿Es posible que las calificaciones de una prueba puedan desafiar el axioma de que la calificación no puede ser válida a menos que sea confiable?

SÓLO PIENSE...

“Si la prueba de Rorschach tiene algo que valga la pena es su enorme atractivo intuitivo.” Explique esto.




Figura 12-3
Ilustración ambigua utilizada en la tarea proyectiva de narración de historias

investigadores en muchos países del mundo, parece que a pesar de su fama no ha recibido aún el respeto académico que merece y que, esperemos, disfrute algún día” (p. 17).

Ilustraciones como estímulos proyectivos

Observe la figura 12-3. Ahora elabore una historia acerca de ella. Su historia deberá tener un principio, una parte media y un final. Escríbala, utilizando tanto papel como necesite. Comparta su historia con la clase y compárela con la historia de algún otro alumno. ¿Qué revela la historia acerca de sus necesidades, temores, deseos, control de impulsos, maneras de ver al mundo, su personalidad? ¿Qué revela la historia escrita por el otro estudiante acerca de él o ella?

Este ejercicio le introduce al uso de ilustraciones como estímulos proyectivos. Las ilustraciones que se emplean como estímulos proyectivos pueden ser fotografías de personas, animales, objetos o cualquier otra cosa real. Pueden ser pinturas, dibujos, bosquejos o cualquier otro tipo de imagen.

Uno de los primeros usos de imágenes como estímulos proyectivos se dio al inicio del siglo veinte. Mucho antes de todo ese asunto de si los hombres son de Marte y las mujeres de Venus, se reportaron diferencias de género en las historias que narraban los niños en respuesta a nueve ilustraciones (Brittain, 1907). El autor señaló que las niñas estaban más interesadas que los varones en los temas religiosos y morales. Otro de los primeros experimentos que utilizó ilustraciones y una técnica de narrar historias, investigó la imaginación en niños. Se observaron diferencias en los temas en función de la edad (Libby, 1908). En 1932, un psiquiatra que trabajaba en la Clínica de Investigación Juvenil de Detroit, desarrolló la Prueba de ilustraciones de situaciones sociales (Schwartz, 1932), un instrumento proyectivo que contenía imágenes apropiadas para delincuentes juveniles. En 1935, mientras trabajaban en la Clínica Psicológica de Harvard Christiana D. Morgan (figura 12-4) y Henry Murray (figura 12-5) publicaron la Prueba de apercepción temática —que comúnmente se denomina por sus iniciales en inglés (TAT)— el instrumento que ha llegado a ser el más ampliamente utilizado de todas las pruebas proyectivas con ilustraciones/narración de historias.



Figura 12-4
Christiana D. Morgan (1897-1967)


En la cubierta de la caja de la ampliamente utilizada TAT y en otros numerosos libros y artículos relacionados con la medición, la autoría de la TAT aparece como "Henry A. Murray, PhD., y el Personal de la Clínica Psicológica de Harvard". Sin embargo, los primeros artículos que describieron la TAT fueron escritos por Christiana D. Morgan (Morgan, 1938) o Morgan y Murray, con Morgan considerada como autora principal (Morgan y Murray, 1935, 1938). En un manuscrito mimeografiado en los archivos de la Universidad de Harvard, una primera versión de la prueba fue titulada "Prueba de apercepción temática de Morgan-Murray" (Morgan-Murray Thematic Apperception Test; White et al., 1941). Wesley G. Morgan (1995) hizo notar que debido a que Christiana Morgan "ha sido la autora principal de las publicaciones anteriores, surge la pregunta respecto a la razón por la cual su nombre fue omitido como uno de los autores en la versión de 1943" (p. 238). W. G. Morgan (1995) expuso esta pregunta y otras relacionadas en un breve pero fascinante recuento del origen e historia de las imágenes de la TAT. Más acerca de la vida de Christiana Morgan puede encontrarse en Aclara esta oscuridad: la vida de Christiana Morgan (Translate This Darkness: The Life of Christiana Morgan; Douglas, 1993). Puede encontrar su Perfil de un creador de pruebas (Test Developer Profile) en nuestro sitio en Internet: www.mhhe.com/cohentesting6.

La Prueba de apercepción temática (TAT) La TAT (*Thematic Apperception Test*) originalmente fue diseñada como un auxiliar para provocar material fantasioso en pacientes de psicoanálisis (Morgan y Murray, 1935). Los materiales de estímulo consistían, como en la actualidad, de 31 láminas, una de las cuales está en blanco. Las 30 láminas con ilustraciones, todas en blanco y negro, contienen una variedad de escenas diseñadas para presentar a la persona examinada "ciertas situaciones humanas clásicas" (Murray, 1943). Algunas de las imágenes contienen individuos solitarios, unas contienen un grupo de personas y otras no incluyen personas. Algunas de las imágenes parecen ser tan reales como una fotografía y otras son dibujos surrealistas. A los examinados se les presenta ésta con el pretexto de que es una prueba de imaginación en la que su tarea consiste en narrar qué sucesos condujeron a la escena en la ilustración, qué está pasando en ese momento y cuál será el resultado. También se les pide que cuenten qué están pensando y sintiendo las personas representadas en las láminas. Cuando se aplica la lámina en blanco, se les pide a los examinados que imaginen que hay una ilustración en la lámina y que luego procedan a narrar una historia sobre ella.

En el manual de la TAT, Murray (1943) también aconsejó a los examinadores que intentaran descubrir la fuente de la historia narrada por la persona evaluada. Vale la pena mencionar que

Figura 12-5
Henry A. Murray (1893-1988)

Es posible que Henry Murray sea mejor conocido por la influyente teoría de la personalidad por él desarrollada, así como por su carácter de autor de la Prueba de apercepción temática. Anderson (1990) y Robinson (1992) han escrito algunas biografías de Murray. El Perfil de un Creador de Pruebas de Murray lo puede encontrar en Internet en www.mhhe.com/cohentesting6.



el sustantivo *apercepción* se deriva del verbo **apercibir**, que puede ser definido como *percibir en términos de las percepciones pasadas*. La fuente de la historia puede ser una experiencia personal, un sueño, un suceso imaginado, un libro, un episodio de una serie televisiva —en realidad, casi cualquier cosa—.

En la práctica clínica, los examinadores tienden a tomarse libertades con diversos elementos relacionados con la aplicación, calificación e interpretación de la TAT. Por ejemplo, aunque el número recomendado para su presentación es de 20 láminas, en la práctica un examinador podría aplicar sólo una o dos láminas o incluso las 31. Si un clínico está evaluando a un paciente que tiene una inclinación a contar historias como para llenar una gran cantidad de cuadernos de apuntes del clínico, sería acertado suponer que se aplicarán menos láminas. Por otro lado, si un paciente cuenta historias breves de una o dos oraciones, se pueden aplicar más láminas en un intento por obtener una mayor cantidad de datos en bruto con los cuales trabajar. Se sugiere que algunas de las láminas sean utilizadas con varones adultos, mujeres adultas, o con ambos, y algunas se sugiere que sean usadas con niños. Esto es así debido a que ciertas representaciones pictóricas se prestan más que otras para la identificación y proyección de los miembros de estos grupos. En un estudio en el que participaron 75 varones (25 de cada grupo de 11, 14 y 17 años de edad), Cooper (1981) identificó las 10 láminas más productivas para utilizarse con varones adolescentes. No obstante, en la práctica, cualquier lámina —ya sea que esté recomendada para utilizarla con varones, mujeres o niños— puede aplicarse a cualquier sujeto. El clínico que aplica la prueba selecciona las láminas que, a su consideración, provocarán respuestas apropiadas para el objetivo de la evaluación.

SÓLO PIENSE...

Y sólo imagine... describa una ilustración en una tarjeta que realmente lo hiciera ponerse a hablar. ¿Qué diría usted?

El material en bruto utilizado para sacar conclusiones acerca del individuo evaluado con la TAT es, 1) las historias como fueron narradas por el examinado, 2) las observaciones del clínico acerca del modo o la manera en que la persona examinada respondió a las láminas y 3) las notas del clínico acerca del comportamiento y verbalizaciones externas a la prueba. Las últimas dos categorías de

los datos en bruto (comportamiento en la prueba y fuera de ella) son fuentes de interpretación clínica para casi cualquier prueba de aplicación individual. El análisis del contenido de las historias requiere de un entrenamiento especial. Sugarman (1991, p. 140) nos proporciona un ejemplo de la manera en que el comportamiento de un examinado durante la prueba puede influir en las

Tabla 12-1
Una descripción de la muestra de la TAT alterna como ilustración

Descripción del autor

Un hombre y una mujer están sentados en un sofá cerca el uno de la otra. La mujer está hablando por teléfono. Hay una mesa lateral con una revista sobre ella junto al sofá.

Requerimientos manifiestos sobre el estímulo

Se requiere de alguna explicación sobre la naturaleza de la relación entre ambas personas y alguna razón para que la mujer esté hablando por teléfono. La revista sobre la mesa y su papel en esta escena no son notados de manera frecuente.

Requerimientos sobre la forma

Los dos detalles importantes, la mujer y el hombre, deben ser integrados. Los detalles pequeños son la revista y el teléfono.

Requerimientos latentes sobre el estímulo

Esta imagen tiene la probabilidad de evocar las actitudes hacia la heterosexualidad y, dentro de ese contexto de que surja material respecto al lugar en que se ubica el examinado en los continuos de optimismo-pesimismo, seguridad-inseguridad, dependencia-independencia, pasividad-asertividad y otros relacionados. De manera alternativa, es posible que evoquen las actitudes hacia la familia y amigos, en donde las dos figuras primarias pueden ser consideradas como hermano y hermana, la mujer hablando por teléfono con un miembro de la familia, y así sucesivamente.

Tramas frecuentes

No se ha aplicado esta tarjeta a suficientes personas como para elaborar juicios acerca de lo que sería una "trama frecuente". Sin embargo, hemos proporcionado una muestra de tramas (tabla 12-2).

Variaciones significativas

De la misma manera en que no podemos proporcionar información sobre las tramas frecuentes, no podemos reportar datos sobre variaciones significativas. Sin embargo, podemos suponer que la mayoría de los estudiantes universitarios que vean esta ilustración percibirán que los dos individuos representados están involucrados en una relación heterosexual. Si ese fuera el caso, una variación significativa podría ser una historia en la cual los personajes no estén implicados en una relación heterosexual (por ejemplo, son empleador/empleado). También se debería prestar atención clínica inmediata a la naturaleza de la relación de los personajes con alguna "figura agregada" (personas no representadas en la tarjeta, pero que el examinado introduce en la historia). El "arrastre" de esta tarjeta está en introducir al personaje con quien está hablando la mujer. ¿De qué se trata la llamada telefónica? ¿Cómo se resolverá la historia?

interpretaciones del examinador acerca de los hallazgos. Este investigador cuenta acerca de un "paciente sumamente narcisista [quien] demostró desprecio y devaluación hacia el examinador (y presumiblemente hacia otras personas) al dictar las historias de la TAT completas con ortografía y puntuación, como si el examinador fuera un estenógrafo".

Existen varios sistemas para interpretar los datos de la TAT (por ejemplo, Thompson, 1986; Westen *et al.*, 1988). La mayoría de estos sistemas interpretativos incorporan o se basan en cierto grado en los conceptos de **necesidad** de Henry Murray (determinantes del comportamiento que surgen del interior del individuo), de **presión** (determinantes del comportamiento que surgen del interior del ambiente) y de **tema** (una unidad de interacción entre necesidades y presiones). En general, el principio conductor para interpretar las historias de la TAT es que el examinado se identifica con alguien (el protagonista) en la historia y que las necesidades, demandas ambientales y conflictos del protagonista en la historia se relacionan de alguna manera con las preocupaciones, esperanzas, temores o deseos de la persona evaluada.

En su análisis de la TAT desde su perspectiva como clínico, William Henry (1956) examinó cada una de las láminas de la prueba respecto a variables tales como *demanda manifiesta de estímulo*, *demanda de la forma*, *demanda latente de estímulo*, *tramas frecuentes* y *variaciones significativas*. Para tener una idea de la manera en que estos términos son utilizados, observe de nuevo la figura 12-3 —una ilustración que *no* es una lámina de la TAT— y después lea las tablas 12-1 y 12-2, que son descripciones de la lámina y algunas respuestas a la lámina dadas por examinados universitarios.

Tabla 12-2
Algunas respuestas para la ilustración muestra

Respondiente	Historia
1. (Varón)	Este chico ha estado involucrado con la muchacha por algunos meses. Las cosas no han ido muy bien. Él sospecha que ella ha estado saliendo con un montón de tipos. Ésta es sólo una escena de una tarde completa en la que el teléfono no ha dejado de sonar. En un momento, él simplemente se levantará y se irá.
2. (Mujer)	Estas dos personas han estado saliendo como novios. No tienen ningún plan para esa tarde y se preguntan qué podrían hacer. Ella está llamando a otra pareja para preguntar si quieren salir con ellos. Saldrán con la otra pareja y se divertirán.
3. (Varón)	La chica cree estar embarazada y está llamando al doctor para saber los resultados de su prueba. El tipo está bastante preocupado porque tiene planes de terminar la universidad y seguir con un postgrado. Él teme que ella querrá casarse y no quiere quedar atrapado. El doctor le dirá que no está embarazada y él se sentirá muy aliviado.
4. (Mujer)	Esta pareja ha estado saliendo durante cerca de dos años y están muy enamorados. Ella está confirmando por teléfono los planes para apartar el salón para la boda. La revista sobre la mesa es un catálogo de vestidos para novias. Parecen realmente enamorados. Creo que las cosas les saldrán bien aunque tienen probabilidades en contra, las tasas de divorcio y todo eso.
5. (Varón)	Estos son dos amigos muy cercanos. El muchacho tiene un verdadero problema y necesita hablar con alguien. Se siente muy deprimido, como si no tuviera a nadie en el mundo. Cada vez que comienza a contarle cómo se siente, suena el teléfono. En poco tiempo se irá, pensando que nadie tiene tiempo para él y se sentirá aún más solo. No sé qué sucederá con él, pero no parece estar muy bien.

Aunque un clínico puede obtener trozos de información de las historias narradas para cada lámina individual, en general las impresiones finales del clínico provendrán de una consideración de los patrones generales de los temas que surjan.

Como ocurre con la prueba de Rorschach y con muchas otras técnicas proyectivas, a lo largo de los años ha habido un incesante debate entre académicos y profesionales en cuanto a la solidez psicométrica de la TAT. Debido a la falta general de estandarización y uniformidad con la que se tienden a dirigir los procedimientos de aplicación, calificación e interpretación en la práctica clínica cotidiana, la preocupación en el aspecto psicométrico está claramente justificada.

SÓLO PIENSE...

¿Por qué las medidas de confiabilidad de dividir en mitades, de test-retest, y otras alternas no son apropiadas para su uso en la TAT?

Sin embargo, en las pruebas experimentales donde los examinadores capacitados utilizan los mismos procedimientos y sistemas de calificación, los coeficientes de confiabilidad entre los calificadores pueden fluctuar desde adecuados hasta impresionantes (Stricker y Healy, 1990).

La investigación sugiere que los factores situacionales, incluyendo quién es el examinador, la manera en que la prueba es administrada y las experiencias de la persona examinada antes y durante la aplicación de la prueba, pueden afectar las respuestas.

Además, los estados transitorios relacionados con las necesidades internas como el hambre, la sed, la fatiga y los niveles de tensión sexual superiores a los normales pueden afectar las respuestas de la persona evaluada. Diferentes láminas de la TAT tienen distintos “arrastres” de estímulo (Murstein y Mathes, 1996). Por ejemplo, algunas imágenes tienen mayor probabilidad que otras de evocar historias con temas de desesperación. Dado que las imágenes tienen diferentes “arrastres” de estímulo, dicho en términos más técnicos, diferentes demandas latentes de estímulo, se vuelve difícil, si no es que imposible, determinar la confiabilidad entre reactivos (léase “entre láminas”) de la prueba. La lámina 1 podría de manera confiable evocar temas de necesidad de logro, mientras que la lámina 16, por ejemplo, de manera característica podría no evocar temas de este tipo. La posibilidad de que la extensión de las historias-respuesta varíe ampliamente presenta otro desafío en la documentación de la confiabilidad entre los reactivos.

Tabla 12-3
Algunas pruebas de historias a partir de imágenes

Prueba de historias a partir de imágenes	Descripción
Thompson (1949), modificación de la TAT original	Diseñada específicamente para utilizarse con evaluados afroamericanos, con imágenes que incluyen protagonistas negros y blancos.
TEMAS (Malgady <i>et al.</i> , 1984)	Diseñada para ser utilizada con niños urbanos de origen hispano, con ilustraciones de escenas apropiadas para su experiencia.
Prueba de apercepción para niños (CAT, por sus siglas en inglés; Bellak, 1971) (publicada por primera vez en 1949)	Diseñada para utilizarse con niños de 3 a 10 años en base a la idea de que utilizar ilustraciones de animales realizando diversas actividades estimula las narraciones proyectivas de los niños.
Prueba de apercepción con figuras humanas para niños (CAT-H; por sus siglas en inglés, Bellak y Bellak, 1965)	Una versión de la CAT, basada en la idea de que, dependiendo de la madurez del niño, podría obtenerse una respuesta más valiosa en términos clínicos si se utilizan seres humanos en lugar de animales en las ilustraciones.
Prueba de apercepción para ancianos, (SAT; por sus siglas en inglés, Bellak y Bellak, 1973)	Prueba de narración de historias a partir de ilustraciones que representan temas adecuados para los adultos mayores.
La Prueba de historias a partir de imágenes (The Picture Story Test; Symonds, 1949)	Para usarse con adolescentes, con ilustraciones diseñadas para evocar temas relacionados con la adolescencia, como el llegar tarde a casa y dejar el hogar.
Prueba de apercepción educativa (Thompson y Sones, 1973) y Método de apercepción escolar (Solomon y Starr, 1968)	Dos pruebas independientes que aquí incluimos juntas porque ambas fueron diseñadas para examinar temas relacionados con la escuela.
Prueba de ilustraciones de Michigan (Andrew <i>et al.</i> , 1953)	Para edades de 8 a 14 años, contiene imágenes diseñadas para evocar diversos temas que fluctúan del conflicto con la autoridad hasta los sentimientos de inadecuación personal.
Prueba de apercepción para niños, de Roberts (RATC; McArthur y Roberts, 1982)	Diseñada para evocar una variedad de temas sobre el desarrollo como la confrontación familiar, el conflicto paternal, el afecto paternal, las actitudes hacia la escuela y la actitud de los compañeros.
Prueba de apercepción de narración de historias, para niños (CAST; Schneider, 1989)	Prueba basada en el trabajo de Alfred Adler.
Prueba de imágenes de Blacky (Blum, 1950)	Esta prueba con un marco teórico psicoanalítico presenta reactivos a manera de dibujos animados que presentan al perro Blacky.
Método de composición de historias a través de imágenes (Shneidman, 1952)	Para edades de 6 años en adelante, los individuos evaluados construyen sus propias ilustraciones a partir de recortes incluidos en el equipo de la prueba y después narran una historia.

En la literatura académica están presentes opiniones conflictivas acerca de la validez de la TAT, incluyendo la validez de sus suposiciones y de las diversas aplicaciones (Barends *et al.*, 1990; Cramer, 1996; Gluck, 1955; Hibbard *et al.*, 1994; Kagan, 1956; Keiser y Prather, 1990; Mussen y Naylor, 1954; Ronan *et al.*, 1995; Worchel y Dupree, 1990). Aunque la relación entre la expresión de historias fantasiosas y el comportamiento en la vida real es tentativa en el mejor de los casos, y aunque la TAT es sumamente susceptible a la simulación, los profesionales la utilizan ampliamente. No obstante, en contraste con el uso aparentemente generalizado de la prueba están los resultados de una encuesta de directores de capacitación de los programas de psicología clínica aprobados por la APA: la mayoría de estos programas ponen muy poco énfasis en la prueba y típicamente dependen de los escritos psicoanalíticos cuando la enseñan (Rossini y Moretti, 1997).

La justificación para la TAT, y muchas otras pruebas similares que utilizan ilustraciones para la narración de historias (tabla 12-3), es que tienen gran atractivo intuitivo. Tiene sentido que las personas proyecten su propia motivación cuando se les pide que construyan una historia a partir de un estímulo ambiguo. Otro atractivo para los usuarios de esta prueba consiste en que es el clínico quien diseña a la medida la aplicación de la prueba, seleccionando las

SÓLO PIENSE...

¿Todas las pruebas deberían ser medidas con la misma "vara psicométrica"?



Figura 12-6
Muestra de un reactivo del estudio de la frustración
por medio de ilustraciones de Rozenzweig

láminas y la naturaleza de las preguntas —una característica que sin duda es bien recibida en esta época de estandarización, pruebas adaptadas para computadora y resúmenes narrativos generados por computadora—. Pero, como ocurre con muchas pruebas proyectivas, parece que la TAT finalmente debe ser juzgada por una norma diferente, más orientada de manera clínica que psicométrica si se desea apreciar completamente su contribución a la evaluación de la personalidad.

Otras pruebas que utilizan ilustraciones como estímulo Una técnica proyectiva denominada la Prueba de la mano (Wagner, 1983), consiste en nueve láminas con ilustraciones de manos y una décima en blanco. Al examinado se le pregunta qué podrían estar haciendo las manos en cada lámina. Cuando se le presenta la lámina en blanco, se instruye a la persona para que imagine un par de manos y después describa qué podrían estar haciendo. Es posible que los examinados den varias respuestas a cada lámina pero todas son anotadas. Las respuestas se interpretan según 24 categorías como afecto, dependencia y agresión.

Otra técnica proyectiva, el Estudio de la frustración por medio de ilustraciones de Rosenzweig (Rosenzweig, 1945, 1978), emplea caricaturas que representan situaciones frustrantes (figura 12-6). La tarea de la persona evaluada consiste en llenar la respuesta de la figura de la caricatura que aparenta estar frustrada. La prueba, que se basa en la suposición de que el individuo se identificará con la persona frustrada, está disponible en formatos para niños, adolescentes y adultos. Los niños pequeños responden de manera verbal a las ilustraciones, mientras que los examinados mayores pueden responder ya sea en forma verbal o escrita. Después de la aplicación de todas las láminas se sugiere un periodo de preguntas para aclarar las respuestas.

Las respuestas son calificadas en función del tipo de la reacción provocada y de la dirección de la agresión expresada. La dirección de la agresión puede ser *intropunitiva* (agresión volcada hacia el interior), *extrapunitiva* (expresada hacia el exterior) o *apunitiva* (se evade la agresión para evitar la situación o disfrazarla). Las reacciones son agrupadas en categorías como *dominio de obstáculos* (en la que la respuesta se concentra en la barrera frustrante), *defensa del yo* (en la que la atención se enfoca en proteger a la persona frustrada) y *persistencia de la necesidad* (en la que la atención se enfoca en resolver el problema frustrante). Para cada categoría de calificación, se calcula el porcentaje de respuestas y se compara con datos normativos. Se deriva una calificación de conformidad grupal (GCR, por sus siglas en inglés) que representa el grado en que las respuestas del individuo se conforman o son características de aquellas obtenidas en el grupo de

estandarización. La prueba ha capturado durante décadas la imaginación de los investigadores, aunque existen dudas acerca de cómo se relacionan las reacciones ante las caricaturas que representan situaciones que provocan frustración con las situaciones de la vida real.

Una variación del método de historias mediante el uso de ilustraciones puede atraer a los clínicos de la “vieja escuela”, así como a los clínicos que desarrollan los datos normativos con todas sus estadísticas acompañantes. La Prueba aperceptiva de la personalidad (*Apperceptive Personality Test*, APT; Karp *et al.*, 1990) representa un intento por responder algunas viejas críticas a la TAT como instrumento proyectivo, al tiempo que introduce objetividad dentro del sistema de calificación. La prueba consiste en ocho láminas de estímulo “que representan personas reconocibles en entornos cotidianos” (Holmstrom *et al.*, 1990; p. 252), incluyendo hombres y mujeres de diferentes edades, al igual que miembros de grupos minoritarios. Por cierto, esto contrasta con las láminas estímulo de la TAT, algunas de las cuales representan tipos de escenas fantásticas o irreales.⁴ Otra diferencia entre la APT y la TAT es el tono emocional de las láminas y su dibujo. Una antigua crítica a las láminas de la TAT ha sido su tono negativo o sombrío, que podría restringir el rango de afecto proyectado por la persona examinada (Garfield y Eron, 1948; Ritzler *et al.*, 1980). Después de narrar, en forma oral o escrita, una historia acerca de cada una de las ilustraciones de la APT, los examinados responden a una serie de preguntas de opción múltiple. Además de proporcionar información cuantitativa, el segmento del cuestionario de la prueba fue diseñado para llenar los vacíos de información a partir de las historias que son demasiado breves o crípticas para calificarlas de otro modo. De este modo, las respuestas se someten tanto a una interpretación clínica y numérica y pueden, de hecho, calificarse e interpretarse con un programa para computadora.

Cada imagen cuenta una historia —bueno, eso esperamos, en beneficio del clínico o investigador que intenta recolectar datos— de otra manera puede ser el momento para introducir otro tipo de prueba, quizás una en la que las palabras mismas sean empleadas como estímulos proyectivos.

Palabras como estímulos proyectivos

Las técnicas proyectivas que emplean palabras o frases y oraciones incompletas se conocen como técnicas *semiestructuradas* porque, aunque dan lugar a una variedad de respuestas, siguen proporcionando una estructura dentro de la cual debe operar el sujeto. Quizás los dos ejemplos más conocidos de las técnicas proyectivas verbales sean las *pruebas de asociación de palabras* y las *técnicas de frases incompletas*.

Pruebas de asociación de palabras En general, una prueba de asociación de palabras puede ser definida como una técnica proyectiva semiestructurada, de aplicación individual para la evaluación de la personalidad, que implica la presentación de una lista de palabras estímulo a la que la persona evaluada responde de manera verbal o escrita con lo primero que surja en su mente al escucharlas. Después las respuestas se analizan en base al contenido y otras variables. El primer intento por investigar la asociación de palabras fue realizado por Galton (1879). El método de Galton consistía en presentar una serie de palabras estímulo, no relacionadas e indicar al sujeto que respondiera con la primera palabra que apareciera en su mente. El continuo interés en el fenómeno de la asociación de palabras dio por resultado estudios adicionales. Se desarrollaron métodos precisos para anotar las respuestas proporcionadas y la cantidad de tiempo transcurrido antes de obtener una respuesta (Cattell, 1887; Trautscholdt, 1883). Cattell y Bryant (1889) fueron los primeros en utilizar láminas con palabras estímulo impresas en ellas. Kraepelin (1896) estudió el efecto de los estados físicos como el hambre y la fatiga, así como el efecto de la práctica en la asociación de palabras. La evidencia experimental acumulada condujo a los psicólogos a creer que las asociaciones individuales hechas con las palabras no eran sucesos aleatorios, sino más bien el resultado de la interacción entre las propias experiencias vitales, actitudes y características únicas de la personalidad.

4. Murray *et al.* (1938) creían que los tipos de estímulos fantásticos o irreales podrían ser particularmente efectivos para tener acceso a los procesos inconscientes.

Jung (1910) sostenía que, al seleccionar ciertas palabras clave que representaban posibles áreas de conflicto, las técnicas de asociación de palabras podrían emplearse con propósitos psicodiagnósticos. Los experimentos de Jung sirvieron de inspiración para los creadores de pruebas como la Prueba de asociación de palabras desarrollada por Rapaport, Gill y Schafer (1946) en la Clínica Menninger. Esta prueba consistía en tres partes. En la primera se aplicaba cada palabra estímulo a la persona examinada, a quien se le pedía que respondiera rápidamente con la primera palabra que surgiera en su mente. El examinador anotaba la cantidad de tiempo que requería el sujeto para responder a cada reactivo. En la segunda parte de la prueba, cada palabra estímulo se presentaba de nuevo a esa persona, a quien se le solicitaba que reprodujera las respuestas originales. Cualquier desviación entre la respuesta original y esta segunda respuesta era registrada, al igual que la cantidad de tiempo de reacción. La tercera parte de la prueba era la indagación. Aquí el examinador hacía preguntas para aclarar la relación que existía entre la palabra estímulo y la respuesta (por ejemplo, “¿En qué estaba pensando?” o “¿Qué estaba pasando por su mente?”). En algunos casos, la relación pudo haber sido obvia; en otros, sin embargo, la relación entre ambas palabras pudo haber sido sumamente idiosincrásica o incluso bizarra.

La prueba consistía en 60 palabras, algunas consideradas neutras por los autores de la prueba (por ejemplo, *silla, libro, agua, baile, taxi*) y algunas consideradas *traumáticas*. En esta última categoría estaban “palabras que tienen probabilidad de tocar material personal sensible de acuerdo con la experiencia clínica, y también palabras que atraen perturbaciones asociativas” (Rapaport *et al.*, 1968, p. 257). Ejemplos de palabras designadas de este modo eran *amor, novia, novio, madre, padre, suicidio, fuego, seno y masturbación*.

Las respuestas para la Prueba de asociación de palabras se evaluaban con respecto a variables como popularidad, tiempo de reacción, contenido y la variación de las respuestas entre las dos aplicaciones de la prueba. Se proporcionaban datos normativos relacionados con el porcentaje en que ocurrían ciertas respuestas entre estudiantes universitarios y grupos de personas con esquizofrenia. Por ejemplo, a la palabra *estómago*, 21% del grupo universitario respondió “dolor”; 13% “úlceras”. Diez por ciento del grupo con esquizofrenia respondió “úlceras”. A la palabra *boca*, 20% de la muestra universitaria respondió “beso”; 13%, “nariz”, 11%, “lengua”; 11%, “labios” y 11%, “comer”. En el grupo con esquizofrenia, 19% respondió “dientes” y 10% respondió “comer”. La prueba en la actualidad no disfruta de amplio uso clínico, pero es más probable que se le encuentre en la aplicación ocasional para investigación.

SÓLO PIENSE...

En comparación con la década de 1940, ¿qué tan adecuadas para despertar emociones son los estímulos *traumáticos* de la Prueba de asociación de palabras de acuerdo a las normas de la actualidad? ¿Por qué?

La Prueba de asociación libre, de Kent-Rosanoff (1910) representó uno de los primeros intentos por desarrollar una prueba estandarizada utilizando palabras como estímulos proyectivos.⁵ La prueba consistía en 100 palabras estímulo, todas de uso común y consideradas neutras respecto a impacto emocional. La muestra de estandarización incluyó a 1 000 adultos normales que variaban en cuanto a localización geográfica, nivel de escolaridad, ocupación, edad y capacidad intelectual. Se desarrollaron tablas de frecuencia en base a las respuestas de estos 1 000 casos. Estas tablas se emplearon para evaluar las respuestas de las personas examinadas de acuerdo a un juicio clínico sobre psicopatología. Se encontró que

los pacientes psiquiátricos tenían una menor frecuencia de respuestas populares que los sujetos normales en el grupo de estandarización. Sin embargo, a medida que se hizo evidente que la individualidad de la respuesta puede estar bajo la influencia de muchas variables aparte de la psicopatología (como la creatividad, edad, escolaridad y factores socioeconómicos), la popularidad de la prueba Kent-Rosanoff como instrumento de diagnóstico diferencial, disminuyó. También

5. El término **asociación libre** se refiere a la técnica de hacer que los sujetos relaten todos sus pensamientos tal como ocurren y es utilizada con más frecuencia en psicoanálisis; la única estructura impuesta es proporcionada por los mismos sujetos. La técnica empleada en la prueba de Kent-Rosanoff se refiere a la de **asociación de palabras** y no a la libre asociación, en la cual el examinado dice la primera palabra que le viene a la mente como respuesta a una palabra estímulo. Por tanto, el término *asociación libre* en el título de la prueba es erróneo.

resultó dañina la investigación que indicaba que las puntuaciones en la prueba Kent-Rosanoff no se relacionaban con otras medidas de pensamiento psicótico (Ward *et al.*, 1991). Aún así, la prueba ha perdurado como instrumento estandarizado de las respuestas de asociación de palabras y más de noventa años después de su publicación continúa siendo utilizada en investigación experimental y en la práctica clínica.

SÓLO PIENSE...

Rápido... el primer pensamiento que le venga a la mente... ¿listo? *Asociación de palabras.*

Pruebas de frases incompletas Otras técnicas proyectivas que utilizan material verbal como estímulos proyectivos son las pruebas de frases incompletas. ¿Cómo completaría usted las siguientes oraciones?

- Me gusta _____ .
- Algún día yo _____ .
- Siempre recordaré la ocasión en que _____ .
- Me preocupa acerca de _____ .
- Me siento más atemorizado(a) cuando _____ .
- Mis sentimientos son lastimados _____ .
- Mi madre _____ .
- Quisiera que mis padres _____ .

Las pruebas de frases incompletas pueden contener reactivos que, tal como los presentados anteriormente, son bastante generales y apropiados para aplicarse en una amplia variedad de contextos. De manera alternativa, el **tronco de una frase incompleta** (la primera parte del reactivo) puede desarrollarse para su uso en tipos específicos de ambientes (como escuelas o empresas) o para propósitos determinados. Las pruebas de frases incompletas pueden ser relativamente ateóricas o estar vinculadas de manera muy estrecha con alguna teoría. Como ejemplo de estas últimas, la Prueba de completar oraciones de la Universidad de Washington (Loevinger *et al.*, 1970) está basada en los escritos de Loevinger y sus colaboradores en el área del desarrollo del yo.

Loevinger (1966; Loevinger y Ossorio, 1958) considera que la madurez conlleva una transformación en nuestra propia imagen desde una esencialmente estereotipada y aceptable en el sentido social hasta una más personalizada y realista. La Prueba de completar oraciones de la Universidad de Washington fue construida para evaluar el autoconcepto según la teoría de Loevinger. Cierta evidencia sobre la validez de esta prueba proviene de su capacidad para pronosticar las actitudes sociales de manera consistente con la teoría de Loevinger (Browning, 1987). Con esta prueba es posible obtener otros índices psicométricos tradicionales. Por ejemplo, se ha estimado que la confiabilidad entre los calificadores para esta prueba fluctúa de .74 a .88; la consistencia interna está arriba del rango de .80 y la confiabilidad test-retest varía de .67 a .76 o de .88 a .92, dependiendo de la manera en que se califique la prueba (Weiss *et al.*, 1989).

El clínico tiene a su disposición varias pruebas estandarizadas de frases incompletas. Una de tales pruebas, la prueba de Frases incompletas en blanco de Rotter⁶ (Rotter y Rafferty, 1950) es la más popular de todas. La prueba de Rotter se desarrolló para su uso con una población a partir del noveno grado de educación hasta la adultez y está disponible en tres niveles: educación media (grados 9 al 12), universidad (grados 13 al 16) y adultos. A las personas evaluadas se les señala que respondan a cada uno de los 40 reactivos que contienen oraciones incompletas de un modo que expresen sus “verdaderos sentimientos”. El manual sugiere que las respuestas dadas a la prueba se interpreten según varias categorías: actitudes familiares, actitudes sociales y sexuales,

6. La pronunciación original de la *o* de Rotter corresponde a *ou*.

actitudes generales y rasgos de carácter. Cada respuesta es evaluada en una escala de 7 puntos que varía de *necesita terapia* hasta *adaptación sumamente buena*.

El manual contiene datos normativos para una muestra de 85 mujeres y 214 varones de recién ingreso a la universidad, pero no tiene normas para poblaciones de educación media y adultos. En el manual también se presentan muestras de las respuestas de varios sujetos junto con información sobre los antecedentes de los mismos. Según los estudios psicométricos citados en su manual, la prueba de Rotter es un instrumento confiable y válido. Se reporta que las estimaciones de confiabilidad entre los calificadores se encuentran en el rango de .90. Independientemente de los estudios originales sobre la validez, se han utilizado técnicas sociométricas para demostrar la validez de la prueba de Rotter como una medida de adaptación (Lah, 1989).

En general, una prueba de frases incompletas puede ser útil para obtener información diversa sobre los intereses de un individuo: sobre sus aspiraciones educativas, metas futuras, temores, conflictos, necesidades, etcétera. Las pruebas tienen un alto grado de validez aparente. Sin embargo, junto con este elevado grado de validez aparente existe un cierto grado de transparencia sobre el objetivo de la prueba. Por esta razón, las pruebas de frases incompletas son, quizá, de entre todos los métodos proyectivos las más vulnerables a la simulación por parte de un examinado que intenta dar una buena —o mala— impresión.

Sonidos como estímulos proyectivos

Queremos aclarar desde un principio que esta sección se incluye más como una nota fascinante en la historia de los instrumentos proyectivos que como una descripción de pruebas muy utilizadas. La historia del uso del sonido como estímulo proyectivo es fascinante debido a sus orígenes en el laboratorio de quien entonces era un joven estudiante en la Universidad de Harvard. Quizá le sorprenda enterarse de que fue un conductista, cuyo nombre rara vez es pronunciado en la misma oración que el término *prueba proyectiva* por cualquier psicólogo contemporáneo: B. F. Skinner (figura 12-7). El artefacto era algo así como unas “manchas de tinta auditivas” (Skinner, 1979, p. 175).

La época era a mediados de la década de 1930. Los colegas de Skinner, Henry Murray y Christiana Morgan, trabajaban en la TAT en la Clínica de Psicología de Harvard. La teoría psicoanalítica estaba muy de moda. Incluso los conductistas sentían curiosidad acerca del enfoque de Freud y algunos se estaban sometiendo a psicoanálisis. Cuando encendía el equipo en su laboratorio en el edificio de biología, el ruido rítmico le servía a Skinner como estímulo para crear palabras que iban junto con el sonido. Esto inspiró a Skinner a pensar en una aplicación del sonido, no sólo en términos conductuales sino en la evocación del comportamiento verbal “latente” que era significativo “en el sentido freudiano” (Skinner, 1979, p. 175). Skinner creó una serie de sonidos grabados muy parecidos a vocales pronunciadas de manera encubierta ante las cuales se les pedía a las personas que asociaran. Los sonidos, acomodados como un dispositivo al que Skinner llamó *sumador verbal*, supuestamente actuarían como estímulo para que la persona verbalizara cierto material inconsciente. Por cierto, a Henry Murray le interesó esta idea y le proporcionó a Skinner una habitación en la clínica para que examinara a los sujetos. A Saul Rosenzweig también le atrajo la idea y él y David Shakow cambiaron el nombre del instrumento por el de *tautófono* (del griego *tauto*, que significa “repetir lo mismo”) y realizaron investigaciones con él (Rutherford, 2003). Sus instrucciones para los sujetos eran las siguientes:

Éste es un fonógrafo. En él está grabada la voz de un hombre que dice diferentes cosas. Habla de manera muy poco clara, de modo que reproduciré varias veces lo que él dice. Tendrá que escuchar atentamente. En cuanto tenga alguna idea de lo que está diciendo, repítalo de inmediato (Shakow y Rosenzweig, 1940, p. 217).

Tal como Rutherford (2003) refiere en detalle, había poca evidencia contundente que mostrara que el instrumento podía diferenciar entre los miembros de grupos clínicos y de los no clínicos.



Figura 12-7
B. F. Skinner, precursor de las pruebas proyectivas... ¿Qué?!

Mientras trabajaba en la Clínica de Psicología de Harvard con la aprobación (e incluso con cierto apoyo económico) de Henry Murray, B. F. Skinner (quien hoy día es un icono del conductismo) mostró gran entusiasmo por una prueba proyectiva auditiva de su propia creación. Creía que la técnica tenía la posibilidad de ser “un dispositivo para atrapar los complejos” (Skinner, 1979, p. 176). Varios reconocidos psicólogos de esa época estuvieron de acuerdo, en apariencia. Por ejemplo, Joseph Zubin, en su correspondencia con Skinner, escribió que la técnica de éste era prometedora “como un medio para arrojar luz sobre los aspectos menos objetivos del experimento de Rorschach” (Zubin, 1939). Por supuesto, si la prueba realmente hubiese sido tan prometedora, es probable que Skinner hubiera obtenido el mismo crédito en este capítulo junto con Murray y Rorschach.

Sin embargo, se desarrollaron varias técnicas proyectivas auditivas. Estaba la Prueba de apercepción auditiva (Stone, 1950), en la que la tarea del sujeto era responder creando una historia basada en tres sonidos reproducidos en una grabación fonográfica. Otros investigadores produjeron pruebas similares, una que se llamó prueba auditiva de asociación de sonidos (Wilmer y Husni, 1951) y otra conocida como prueba de apercepción auditiva (Ball y Bernardoni, 1953). Henry Murray también participó en estos experimentos con su prueba Azzageddi (Davids y Murray, 1955), llamada así por un personaje de Herman Melville. A diferencia de otras pruebas auditivas proyectivas, la Azzageddi presentaba párrafos hablados a los sujetos.

Así, ¿por qué en la actualidad los editores de pruebas no están grabando CD con sonidos proyectivos a una velocidad comparable a la de la publicación de láminas con manchas de tinta e ilustraciones? Rutherford (2003) especuló que una combinación de factores conspiró para provocar la desaparición de los métodos proyectivos auditivos. Las pruebas no diferenciaban entre los diversos grupos de sujetos que se sometían a ellas. Las respuestas a los estímulos auditivos carecían de la complejidad y riqueza de las respuestas a las manchas de tinta, ilustraciones y otros estímulos proyectivos. Ninguno de los sistemas disponibles de calificación era muy satisfactorio. Excepto para utilizarlas con personas ciegas, las pruebas auditivas proyectivas se consideraban redundantes en relación con la TAT, pero no tan buenas como ésta.

Elaboración de dibujos

Una técnica proyectiva relativamente rápida y de fácil aplicación es el análisis de dibujos. Los dibujos pueden darle al experto en psicodiagnóstico una multitud de hipótesis clínicas que se pueden confirmar o descartar como resultado de otros hallazgos (figura 12-8). El uso de los dibujos en los contextos clínicos y de investigación ha ido más allá del área de la evaluación de la personalidad. Se han hecho intentos por utilizar las producciones artísticas como una fuente



Dibujo hecho por una maestra de 25 años poco después de haberse comprometido en matrimonio. Antes, había ingresado a psicoterapia debido a problemas relacionados con los hombres y a un bloqueo contra el matrimonio. La posición de las manos indica que permanece el temor a las relaciones sexuales.



Dibujo realizado por un hombre con complejo de "Don Juan" —un hombre que tenía una aventura tras otra—. El cuello levantado para proteger la garganta y el sombreado excesivo en las nalgas sugieren temor a sufrir un ataque por atrás. Es posible que el donjuanismo de este hombre sea una defensa en contra de una falta de masculinidad —incluso sentimientos de afeminamiento— contra los que puede estar luchando en su interior.



Dibujo de un hombre autoritario y sádico que había sido el principal encargado de imponer la disciplina en un reformatorio para varones antes de ser suspendido por maltrato infantil. Su descripción de esta imagen fue que "parecía como un general prusiano o Nazi".



Tomados en conjunto, las manos encadenadas, los pies atados, las nalgas expuestas y el pie grande dibujado a un lado del dibujo reflejan, según Hammer, necesidades homosexuales, masoquistas y exhibicionistas.



Este dibujo de un hombre psicótico, con paranoia aguda fue descrito por Hammer (1981, p. 170) de la siguiente manera: "La boca salvaje expresa las proyecciones llenas de ira que están libres dentro del individuo. El énfasis en los ojos y orejas, con ojos que casi emanan rayos mágicos, reflejan las alucinaciones visuales y auditivas que el paciente está experimentando en la actualidad. La serpiente en el estómago apunta a su delirio de un reptil interno, que se lo come y genera veneno y maldad".

Figura 12-8

Algunas muestras de interpretaciones hechas a partir de dibujos de la figura humana

Fuente: Hammer, 1981.

de información sobre inteligencia, integridad neurológica, coordinación visomotora, desarrollo cognoscitivo e, incluso, problemas de aprendizaje (Neale y Rosal, 1993). Los dibujos de figuras son una atractante fuente de datos diagnósticos debido a que su aplicación puede ser individual o grupal y puede ser realizada por personas no especializadas, tales como maestros, y no requieren de otros materiales más que lápiz y papel.

Pruebas de dibujo En general, una **prueba de dibujo** puede ser definida como un método proyectivo de evaluación de la personalidad que implica la producción de un dibujo por parte del evaluado el cual se analiza en base a su contenido y a otras variables relacionadas. La obra clásica acerca del uso de los dibujos de figuras como estímulo proyectivo es un libro titulado *Proyección de la personalidad en el dibujo de la figura humana: Un método para la investigación de la personalidad*, de Karen Machover (1949). Machover escribió que

...la figura humana dibujada por un individuo al que se le indica que “dibuje una persona” está relacionada de manera íntima con los impulsos, ansiedades, conflictos y compensaciones características de dicho individuo. En cierto sentido, la figura que se dibuja es la persona misma, y el papel corresponde a su ambiente (p. 35).

Las instrucciones para aplicar la prueba de la figura humana (*Draw A Person* DAP; en inglés) son bastante sencillas. Al examinado se le proporcionan un lápiz y una hoja en blanco de 21.5 × 28.0 cm (8 ½ × 11 pulgadas) y se le dice que dibuje una persona. Las preguntas por parte del examinado respecto a cómo debe dibujar la figura se responden con afirmaciones tales como “Hágala como usted cree que debería de ser” o “Haga lo mejor que pueda”. Inmediatamente después de terminado el primer dibujo, se le da una segunda hoja de papel y se le indica que dibuje una persona del sexo opuesto a la que acaba de dibujar.⁷ A continuación, muchos clínicos harán preguntas acerca de los dibujos, como “Cuénteme una historia acerca de la figura”, “Dígame algo acerca del niño/niña, hombre/mujer”, “¿Qué está haciendo la persona?” “¿Cómo se siente la persona?” “¿Qué es agradable o desagradable de la persona?” Las respuestas a estas preguntas se utilizan para formular diversas hipótesis e interpretaciones acerca del funcionamiento de la personalidad.

De manera tradicional, los dibujos generados en la prueba de la figura humana han sido evaluados de manera formal mediante el análisis de varias características del dibujo. Se ha prestado atención a factores tales como el tiempo requerido para terminar el dibujo, la colocación de las figuras, el tamaño de la figura, la presión que se ejerce sobre el lápiz, simetría, calidad de la línea, sombreado, presencia de borraduras, expresiones faciales, postura, ropa y apariencia general. Se han generado diversas hipótesis en base a estos factores (Knoff, 1990a). Por ejemplo, la colocación de la figura en el papel es considerada como una representación de la manera en que el individuo funciona dentro del ambiente. La persona que dibuja una pequeña figura en la parte inferior de la página podría tener un autoconcepto deficiente, o podría sentirse insegura o deprimida. El individuo que dibuja una imagen que no puede ser contenida en una sola hoja y que se sale de la página se considera como impulsivo. Una presión inusualmente ligera sugiere trastornos en el carácter (Exner, 1962). Según Buck (1948, 1950), colocar el dibujo a la derecha de la página sugiere una orientación hacia el futuro; colocarla a la izquierda sugiere una orientación hacia el pasado. La colocación en la parte superior derecha sugiere un deseo de reprimir un pasado desagradable, además de un optimismo excesivo en cuanto al futuro. La colocación en la parte inferior izquierda sugiere depresión y un deseo de huir hacia el pasado.

Otra variable de interés para aquellos que analizan los dibujos de figuras son las *características* del individuo dibujado. Por ejemplo, ojos inusualmente grandes u orejas de gran tamaño sugiere suspicacia, ideas de referencia u otras características paranoides (Machover, 1949; Shneidman, 1958). El hecho de que un hombre dibuje senos inusualmente grandes se puede interpretar como problemas edípicos no resueltos, con dependencia materna (Jolles, 1952). Las corbatas largas y sobresalientes sugieren una agresividad sexual que posiblemente sea una sobrecompensación por temor a la impotencia (Machover, 1949). El énfasis en los botones sugiere una personalidad dependiente, infantil e inadecuada (Halpern, 1958).

7. Cuando a la mayoría de la gente se le pide de manera simple que “dibuje una persona”, dibujará una persona de su mismo sexo. Se considera clínicamente significativo que el individuo dibuje a una persona del sexo opuesto cuando se le dan estas instrucciones. Rierdan y Koff (1981) encontraron que en algunos casos, los niños no están seguros del sexo de la figura que han dibujado. La hipótesis que plantean es que en tales casos “el niño tiene una idea indefinida o mal definida de identidad sexual” (p. 257).

La prueba de la casa-árbol-persona (*House-Tree-Person test*, HTP; Buck, 1948) es otra prueba proyectiva de dibujo de figuras. Como su nombre lo indica, la tarea del examinado es realizar el dibujo de una casa, de un árbol y de una persona. De forma muy similar a la que se supone los diferentes aspectos de la figura humana reflejan el funcionamiento psicológico, se considera

SÓLO PIENSE...

Dibuje una persona. Reflexione sobre lo que el dibujo dice acerca de usted mismo.

significativamente simbólica la manera en que un individuo representa una casa y un árbol. Otra prueba que se considera de valor particular para analizar al individuo en relación con su familia es la del Dibujo cinético de la familia (*Kinetic Family Drawing*, KFD). Derivado de la Prueba de dibujo de la familia (*Family Drawing Test*) de Hulse (1951, 1952), la aplicación de la KFD (Burns y Kaufman, 1970, 1972) se inicia con la presentación de una hoja de papel de

21.5 × 28.0 cm (8 ½ × 11 pulgadas) y de un lápiz con goma. Al examinado, que por lo general es un niño aunque no necesariamente tiene que serlo, se le dan las siguientes instrucciones:

Haz un dibujo de todas las personas en tu familia, incluyéndote a ti, HACIENDO algo. Trata de dibujar personas completas, no caricaturas ni figuras con palitos. Recuerda, dibuja a cada uno HACIENDO algo, algún tipo de acción (Burns y Kaufman, 1972, p. 5).

Además de producir representaciones gráficas de cada miembro de la familia para su análisis, este procedimiento puede proporcionar una enorme cantidad de información en forma de verbalizaciones por parte del examinado mientras ejecuta el dibujo. Después de que el examinado ha completado el dibujo, se realiza un interrogatorio bastante detallado. Se le pide al examinado que identifique a cada una de las figuras, que hable acerca de su relación y detalle lo que están haciendo dentro del dibujo y por qué razón. Existe un cierto número de sistemas formales de calificación disponibles para la KFD. Algunas otras técnicas relacionadas incluyen una adaptación escolar llamada dibujo escolar cinético (*Kinetic School Drawing*, KSD; Prout y Phillips, 1974); una prueba que combina aspectos de la KFD y la KSD llamada sistema de dibujo cinético (*Kinetic Drawing System*, KDS; Knoff y Prout, 1985), y la técnica de dibujo en colaboración (*Collaborative Drawing Technique*, Smith, 1985), una prueba que proporciona la ocasión para que los miembros de la familia colaboren en la creación de un dibujo —probablemente con la mejor intención de ponerlos a “dibujar juntos”.

La prueba del dibujo de una persona: procedimiento de detección de trastornos emocionales (*Draw a Person: Screening Procedure for Emotional Disturbance*, DAP:SPED; Naglieri *et al.*, 1991) presenta la aplicación de una prueba estandarizada y un sistema de calificación cuantitativo diseñado para detectar problemas emocionales en los examinados (de 6 a 17 años de edad). Basada en la suposición de que la representación de características inusuales en los dibujos de las figuras indica problemas emocionales, se califica con un punto cada característica de este tipo. Una vez tomadas en cuenta la edad y la información normativa, las puntuaciones elevadas indican la necesidad de hacer una evaluación más detallada. Dentro del manual de la prueba se presentan datos acerca de su validez, pero tanto una evaluación independiente de la prueba (Motta *et al.*, 1993a, 1993b) como un estudio realizado por dos de los autores de la prueba (McNeish y Naglieri, 1993) hicieron surgir inquietudes que pueden existir identificaciones erróneas (tanto falsos positivos como falsos negativos) que podrían resultar del uso de la prueba aun cuando se utiliza como herramienta de detección.

Al igual que otras técnicas proyectivas, las pruebas de dibujo de figuras, aunque se considera que tienen cierta utilidad clínica, han tenido una historia conflictiva en relación con su solidez psicométrica (Joiner y Schmidt, 1997). En general, las técnicas son vulnerables en cuanto a la suposición de que, en esencia, los dibujos son representaciones o descripciones personales (Tharinger y Stark, 1990) y que simbolizan más que la capacidad para dibujar (Swensen, 1968). A pesar de que se ha diseñado un cierto número de sistemas para calificar los dibujos, no se ha encontrado un fundamento sólido respecto a la validez de estos enfoques (Watson *et al.*, 1967). La experiencia y la destreza no necesariamente se correlacionan con la mayor precisión clínica en la interpretación de los dibujos. Karen Machover (citada en Watson, 1967) según informes, ella misma expresó tener “serias dudas” (p. 145) acerca del mal uso que se podía hacer de su prueba para propósitos de diagnóstico.

Sin duda, el uso clínico de los dibujos de figuras tiene sus defensores académicos (Riethmiller y Handler, 1997a, 1997b). Waehler (1997), por ejemplo, advirtió que las pruebas no son infalibles y que una persona que se presenta con numerosas patologías durante una entrevista bien puede parecer

saludable en una prueba psicológica. Él mismo declaró que los dibujos “pueden ser considerados más que ‘pruebas’; dichas pruebas implican tareas que también pueden servir como puntos de partida para que los evaluados y los examinadores discutan y hagan aclaraciones acerca del dibujo” (p. 486).

Los métodos proyectivos en perspectiva

Utilizados de manera entusiasta por muchos clínicos y criticados severamente por muchos académicos, los métodos proyectivos siguen ocupando un medio más bien único en el terreno de la psicología. Lilienfeld *et al.* (2000) plantearon serias interrogantes en relación a si es digno de ser conservado ese medio. Estos autores centraron sus críticas en los sistemas de calificación de la prueba de Rorschach, de la TAT y de los dibujos de figuras. Concluyeron que existía soporte experimental sólo para un número relativamente pequeño de índices de la prueba de Rorschach y de la TAT. Encontraron incluso menos razones de peso para justificar que se siguiesen utilizando los dibujos de figuras. Algunas de sus afirmaciones respecto a la prueba Rorschach y la TAT, así como la respuesta de un usuario y defensor de las pruebas proyectivas, Stephen Hibbard (2003), se presentan en la tabla 12-4. Hibbard hizo comentarios únicamente acerca de la prueba de Rorschach y de la TAT, debido a su mayor experiencia con estas pruebas que con los dibujos de figuras.

En general, los críticos han atacado los métodos proyectivos por razones relacionadas con las suposiciones inherentes a su uso, con las *variables situacionales* que lo acompañan y con algunas *consideraciones psicométricas*, de manera más notable, con la escasez de datos para apoyar su confiabilidad y validez.

Tabla 12-4
Argumentos en contra y en favor (o refutación a los argumentos en contra) sobre los métodos proyectivos

Lilienfeld <i>et al.</i> (2000), argumentos en contra	Hibbard (2003), refutación
Las técnicas proyectivas no proporcionan una validez progresiva superior a la de las mediciones más estructuradas, como argumentan los proponentes de la hipótesis proyectiva, esto afirmado por Dosajh (1996).	Lilienfeld <i>et al.</i> , presentaron una caricatura anticuada acerca de la proyección y luego prosiguieron a atacarla. Dosajh no ha publicado nada acerca de los sistemas de codificación criticados. Ninguno de los autores que desarrollaron los sistemas de codificación atacados ha adoptado un punto de vista acerca de la proyección que sea similar al atacado por Dosajh. Algunos de ellos incluso han definido sus sistemas como no proyectivos.
Las normas del Sistema Comprensivo de Exner (CS) son erróneas. Pueden sobrepatologizar a individuos normales e incluso pueden dañar a ciertos clientes.	La evidencia en cuanto al error en las normas no es concluyente. Las discrepancias observadas pueden tener una diversidad de explicaciones. La sobrepatologización puede ser el resultado de un “desplazamiento” similar al que se observa en la medición de la inteligencia (efecto Flynn).
Existe un apoyo limitado para la generalizabilidad del CS en diferentes culturas.	Se necesitan llevar a cabo más estudios interculturales, pero lo mismo se podría decir de la mayoría de las pruebas importantes.
Se citan cuatro estudios para apoyar la deficiencia de la confiabilidad test-retest del CS.	Sólo tres de los cuatro estudios citados se encuentran en <i>publicaciones objetivas</i> (en las que los manuscritos entregados se someten a una revisión crítica y pueden ser rechazados o seleccionados para su publicación) y ninguno de estos tres estudios son genuinos estudios de confiabilidad.
Respecto a la TAT, no tiene caso agregar calificaciones dentro de una escala en ausencia de la aplicación de criterios de confiabilidad de consistencia interna.	Esta afirmación es incorrecta ya que “cada subunidad de un grupo de predictores que se agrega perteneciente a un constructo podría no tener relación con otro, pero cuando se encuentran en combinación bien podrían predecir una importante varianza en el constructo” (p. 264).
Las estimaciones de confiabilidad test-retest de la TAT han sido “notablemente problemáticos” (p. 41).	“...podría incrementarse el nivel de confiabilidad del retest para estimular las mediciones si las instrucciones del retest permitieran a los participantes contar historias con el mismo contenido que en la primera aplicación” (p. 265).
Diversos estudios de validez con diferentes sistemas de calificación para la TAT pueden ser imperfectos debido a su metodología.	Lilienfeld <i>et al.</i> (2000) malinterpretaron algunos de los estudios que citaron y no mencionaron otros. Por ejemplo, no fueron citados varios estudios pertinentes de validez en apoyo a Cramer (1991) en su sistema de codificación del Manual de mecanismos de defensa del TAT.

Se exhorta a los lectores interesados a leer el texto completo de Lilienfeld *et al.* (2000) y el de Hibbard (2003), ya que los argumentos planteados por ambos aparecen mucho más detallados que los breves ejemplos que se presentan aquí.

Suposiciones Murstein (1961) examinó diez suposiciones de las técnicas proyectivas y argumentó que ninguna de ellas era científicamente convincente. Diversas suposiciones están relacionadas con el material de estímulo. Por ejemplo, se supone que mientras más ambiguo sea el estímulo, más revelará acerca de la personalidad de los sujetos. Sin embargo, Murstein describe el material de estímulo como sólo un aspecto de la “situación total del estímulo”. Las variables ambientales, la tendencia de la respuesta, las reacciones hacia el examinador y los factores relacionados todos contribuyen a los patrones de respuesta. Además, en las situaciones en que las propiedades de estímulo del material proyectivo estaban diseñadas para ser poco claras o vagas, o que están

SÓLO PIENSE...

Suponga que una lámina de la prueba de Rorschach o del TAT evocara respuestas muy similares en la *mayoría* de las personas. ¿Esto sería un argumento en favor o en contra del uso de dicha lámina?

presentadas con líneas incompletas —con lo que se aumenta la ambigüedad— no se encontró que aumentara la proyección por parte del sujeto.

Otra conjetura se refiere a la naturaleza supuestamente idiosincrásica de las respuestas evocadas por los estímulos proyectivos. De hecho, las similitudes en los temas de respuesta de diferentes sujetos a las mismas láminas de estímulo sugieren que existe la posibilidad de que el material de estímulo no sea tan ambiguo y subordinado a la proyección como antes se había supuesto. Por tanto se indica cierta consideración a las propiedades del estímulo y las

maneras en que afectan las respuestas de los sujetos. También ha resultado cuestionable la suposición de que la proyección sobre el material de estímulo es mayor si éste es similar al sujeto (en apariencia física, género, ocupación y demás).

Murstein planteó algunas dudas acerca de la manera en que se interpretan las pruebas proyectivas. Cuestionó numerosas suposiciones, incluyendo aquellas que afirman que

- cada respuesta proporciona un significado para el análisis de la personalidad
- existe una relación entre la intensidad de una necesidad y su manifestación en los instrumentos proyectivos
- los examinados no están conscientes de lo que están revelando acerca de sí mismos
- un protocolo proyectivo refleja suficientes datos relacionados con el funcionamiento de la personalidad para formular juicios
- existe un paralelismo entre la conducta obtenida con un instrumento proyectivo y la conducta mostrada en situaciones sociales

Murstein descartó estas afirmaciones como “creencias apreciadas” aceptadas “sin el apoyo de una suficiente validación mediante la investigación” (p. 343).

Podríamos añadir a la lista de Murstein una suposición fundamental para la evaluación proyectiva: que existe algo denominado “el inconsciente”. Aunque el término *inconsciente* es utilizado ampliamente como si su existencia fuese un hecho establecido, algunos académicos han cuestionado si, en realidad, el inconsciente existe de la misma manera en que existe, digamos, el hígado. Los estudios científicos que de manera característica son mencionados para sustentar la existencia del inconsciente (o, tal vez de manera más precisa, la eficacia del constructo *inconsciente*) han utilizado una amplia variedad de metodologías —véase, por ejemplo, Diven (1937), Erdelyi (1974), Greenspoon (1955) y Razran (1961)—. Las conclusiones de cada uno de estos tipos de estudio están sujetas a explicaciones alternativas. También, han sido indefinidas las conclusiones acerca de la existencia del inconsciente que se basan en pruebas experimentales de las predicciones derivadas de fenómenos hipnóticos, de la teoría de la detección de señales y de teorías específicas de la personalidad (Brody, 1972).

Variables situacionales Los proponentes de las técnicas proyectivas han afirmado que estas pruebas tienen la capacidad de iluminar los recovecos de la mente del mismo modo en que los rayos X iluminan al cuerpo. Frank (1939) conceptualizó las pruebas proyectivas como un sondeo de los patrones de personalidad sin la alteración de los patrones sondeados. Si eso fuera cierto, entonces las variables relacionadas con la situación de prueba no tendrían efecto alguno sobre los

datos obtenidos. No obstante, las variables situacionales tales como la presencia o ausencia del examinador han afectado de manera significativa las respuestas de sujetos experimentales. Es probable que las historias de la TAT escritas en privado sean menos cautelosas, menos optimistas y más implicadas con los sentimientos que aquellas que se escriben en presencia de un examinador (Bernstein, 1956). Es probable que la edad del examinador afecte los protocolos proyectivos (Mussen y Scodel, 1955), así como las instrucciones específicas (Henry y Rotter, 1956) y las sutiles señales de reforzamiento que proporciona el examinador (Wickes, 1956).

Masling (1960) hizo una reseña de la literatura sobre la influencia de las variables situacionales e interpersonales en la evaluación proyectiva y concluyó que existía una sólida evidencia de la actuación de influencias situacionales e interpersonales en la proyección. Masling concluyó que los sujetos utilizaban toda señal disponible en la situación de prueba, incluyendo los indicios relacionados con las acciones y la apariencia del examinador. Más aún, Masling argumentó que los examinadores también dependían de las señales situacionales, en algunos casos más allá de lo que se les había enseñado. Los examinadores parecían interpretar los datos proyectivos basándose en sus propias necesidades y expectativas, en sus propios sentimientos subjetivos acerca de la persona evaluada, y en sus propias construcciones acerca de la situación total de la prueba. Masling (1965) demostró de manera experimental que por medio de señales posturales, gestuales y faciales, los examinadores que utilizan la prueba de Rorschach son capaces de evocar las respuestas que esperan sin darse cuenta de ello.

En cualquier situación clínica dada, muchas variables pueden estar incluidas en la combinación. La interacción de estas variables puede tener influencia en los juicios clínicos. Así es que las investigaciones han sugerido que incluso en situaciones que implican pruebas objetivas (no proyectivas) o el simple registro de la historia clínica, el efecto de la capacitación del clínico (Chapman y Chapman, 1967; Fitzgibbons y Shearn, 1972) la perspectiva del rol (Snyder *et al.*, 1976), la clase social del paciente (Hollingshead y Redlich, 1958; Lee, 1968; Routh y King, 1972) y la motivación por manejar una impresión deseada (Edwards y Walsh, 1964; Wilcox y Krasnoff, 1967) son capaces, en su totalidad, de influir en las valoraciones de la patología (Langer y Abelson, 1974) y conclusiones relacionadas (Batson, 1975). A éstas y a otras variables se les da una mayor independencia en la situación de prueba proyectiva, donde el examinador puede tener la libertad de escoger no sólo la prueba y los datos adicionales a ésta sobre los cuales centrará su interpretación, sino también el sistema de calificación que utilizará para llegar a esa interpretación.

Consideraciones psicométricas Todavía queda por ser demostrada la solidez psicométrica de muchos instrumentos proyectivos ampliamente utilizados. Los críticos de las técnicas proyectivas han llamado la atención hacia variables tales como las modificaciones no controladas en la extensión del protocolo, las muestras de sujetos inapropiadas, grupos control inadecuados y los deficientes criterios externos como factores que contribuyen a las estimaciones de validez engañosamente elevadas. Existen obstáculos metodológicos para la investigación de técnicas proyectivas, ya que muchos métodos de test-retest, o de dividir en mitades (*split-half*) son inadecuados. En el mejor de los casos, es un reto diseñar y llevar a cabo estudios de validez que de manera efectiva descarten, limiten o tomen en cuenta estadísticamente las variables situacionales únicas que acompañan la aplicación de estas pruebas.

El debate entre los académicos que argumentan que las pruebas proyectivas no son instrumentos técnicamente sólidos y los clínicos que encuentran útiles estas pruebas ha sido muy acalorado desde que las pruebas proyectivas empezaron a utilizarse de manera amplia. Frank (1939) respondió a aquellos que rechazaban los métodos proyectivos debido a su carencia de rigor técnico:

SÓLO PIENSE...

Las pruebas proyectivas han estado en uso durante mucho tiempo debido al atractivo que tienen para muchos clínicos. ¿Cuáles son sus ventajas? ¿Por qué se deberían de seguir utilizando durante mucho más tiempo?

Estas guías para el estudio de la personalidad han sido rechazadas por muchos psicólogos debido a que no reúnen los requerimientos psicométricos de validez y confiabilidad, pero están siendo empleadas junto con estudios de la personalidad tanto clínicos como de otro tipo en donde están encontrando una creciente validación en la consistencia de resultados para el mismo sujeto cuando son analizadas de manera independiente por medio de cada uno de estos procedimientos...

Si enfrentamos el problema de la personalidad, en toda su complejidad, como un proceso dinámico activo que debe ser estudiado como un *proceso* en lugar de como una entidad o un agregado de rasgos, como factores o como una organización estática, entonces estos métodos proyectivos ofrecen muchas ventajas para la obtención de datos en el proceso de organizar la experiencia que es individual para cada personalidad y que tiene una utilidad de por vida (Frank, 1939, p. 408; las cursivas aparecen en el original).

Métodos de evaluación conductual

Los rasgos, estados, motivos, necesidades, pulsiones, defensas y otros constructos psicológicos relacionados no tienen una existencia tangible. Son constructos cuya existencia se debe inferir a partir de la conducta. En el enfoque tradicional de la evaluación clínica, se emplean pruebas así como otras herramientas de evaluación para recolectar datos. A partir de estos datos, se hacen diagnósticos e inferencias acerca de la existencia y solidez de estos constructos psicológicos. Por lo tanto, el enfoque tradicional de la evaluación podría ser clasificado como un enfoque de *señales*, debido a que las respuestas a la prueba se consideran como señales o claves de la personalidad o capacidad subyacente. Contraria a este enfoque tradicional hay una filosofía alterna de evaluación que podríamos denominar enfoque de *muestra*. El enfoque de muestra se centra en la conducta misma. La conducta emitida es considerada no como una señal de algo, sino más bien como una muestra que debe ser interpretada por su propio derecho.

El énfasis en la **evaluación conductual** reside en “lo que una persona hace en ciertas situaciones en lugar de residir en las inferencias acerca de los atributos que aquélla posea de manera más global” (Mischel, 1968, p. 10). Predecir lo que una persona hará se considera que implica una comprensión del evaluado con respecto tanto a las condiciones antecedentes como a las consecuencias de una situación en particular (Smith e Iwata, 1997). Sin embargo, luego de un detallado escrutinio, el concepto del rasgo sigue aún presente en muchas mediciones conductuales, aunque definido de manera más limitada y mucho más ligado a situaciones específicas (Zuckerman, 1979).

Para ilustrar la observación conductual como una estrategia de evaluación, considere el conflicto en que se encuentra una dama soltera que acude a solicitar ayuda al centro universitario de orientación. Se queja de que aun cuando todos sus amigos le dicen que es muy atractiva, tiene grandes dificultades para relacionarse con los hombres —tantas que ya ni siquiera quiere intentarlo—. Un orientador, frente a una cliente como ella, podría, entre otras cosas, 1) entrevistarla acerca de su problema, 2) aplicarle una prueba apropiada, 3) pedirle que lleve un diario detallado acerca de los pensamientos y conductas relacionadas con los diversos aspectos de sus esfuerzos por conocer hombres, incluyendo sus expectativas, y 4) acompañarla a una típica noche en un bar para solteros o algún sitio similar para observar su conducta. Las últimas dos estrategias caen bajo el rubro de observaciones conductuales. En cuanto al diario, la mujer estará ocupada en una autoobservación. En el escenario de la noche fuera, el orientador estará efectuando la observación real.

La aplicación más tradicional de una prueba o batería de pruebas psicológicas a alguien como esta mujer soltera podría producir señales que inferencialmente podrían relacionarse con el problema. Por ejemplo, si varias de las historias de la TAT de la cliente incluyeran temas de encuentros heterosexuales degradantes, hostiles o de otra manera insatisfactorios como resultado de salir a la calle, un orientador podría hacer una interpretación a un nivel más profundo o de segundo nivel de inferencia. Por ejemplo, un orientador, en especial si tiene una orientación psicoanalítica, podría llegar a una conclusión similar a ésta:

El temor expresado de la persona de salir a la calle y, en última instancia, su temor a conocer hombres, podría de alguna manera estar relacionado con un temor inconsciente a la promiscuidad, al temor de convertirse en mujer de la calle.

Tal conclusión, por consiguiente, tendría implicaciones para un tratamiento. Podrían dedicarse varias horas de tratamiento para descubrir el temor “real” de modo que se torne evidente para la mujer misma y finalmente pueda enfrentarlo de manera efectiva.

En contraste con el enfoque de señales, el clínico que empleara el enfoque de muestra o conductual para la evaluación podría examinar el diario conductual de la mujer para diseñar un programa adecuado de terapia basado en dicho registro. Así, por ejemplo, las condiciones antecedentes bajo las cuales ella se sienta más perturbada y poco motivada a hacer algo acerca del problema podrían ser delineadas y trabajadas en las sesiones de orientación. Al analizar el diario, el clínico podría encontrar, por ejemplo, que la mujer ve de manera regular el programa de televisión por cable *Wild On...* de la cadena *E!* Las expectativas que este programa pudo haber suscitado en ella se podrían analizar en una sesión en la que el clínico revisara todos estos hallazgos.

Una ventaja del enfoque de señales sobre el enfoque de muestra es que, en manos de un clínico hábil y perceptivo, la cliente podría ser puesta en contacto con sentimientos de los cuales no había tenido conocimiento antes de la evaluación. Es posible que esa persona haya estado evitando ciertos pensamientos e imágenes (por ejemplo, aquellos relacionados con la expresión de su sexualidad) de manera consciente (o inconsciente) y que esta incapacidad para enfrentarse a esos pensamientos e imágenes realmente haya sido un factor contribuyente para su ambivalencia acerca de su relación con los hombres.

Es poco frecuente que los evaluadores conductuales hagan inferencias con este nivel de profundidad. Por ejemplo, si la persona no plantea la sexualidad como un área de dificultad (en una entrevista, en su diario, en una lista de verificación o por medio de otra técnica de evaluación conductual), el problema en esta área bien podría ser ignorado o darse por terminado en seguida. Aún así, los evaluadores conductuales sí tienden a ser más empíricos en su enfoque, ya que evalúan el problema presentado por el cliente de manera sistemática tanto desde la perspectiva del cliente como desde la perspectiva del que lo observa en situaciones sociales y del ambiente en general. El evaluador conductual no busca en la prueba de Rorschach o en otros protocolos pistas acerca del tratamiento. Más bien, el consejero o clínico orientado hacia la conducta depende mucho más de lo que el cliente hace o ha hecho a fin de encontrar guías respecto al tratamiento. En este sentido, la aproximación conductual no requiere tanta creatividad clínica como el enfoque por señales. Tal vez por esa razón es que el enfoque conductual puede ser considerado más una ciencia que un arte.

En un inicio, el distanciamiento de los clínicos de orientación conductual de las pruebas psicológicas tradicionales obligó a que se hiciera un llamado para integrar tales pruebas en las evaluaciones conductuales. Este punto de vista está tipificado por el deseo de que “las pruebas psicológicas deberían tener la capacidad de proporcionar al terapeuta conductual información valiosa para llevar a cabo una terapia conductual. Esta opinión se basa en la suposición de que la conducta en cualquier prueba psicológica debería ser legítima” (Greenspoon y Gersten, 1967, p. 849). En consecuencia, por ejemplo, las pruebas psicológicas podrían ser útiles para ayudar al terapeuta conductual a identificar el tipo de estímulos contingentes que serían de mayor eficacia con un paciente dado. Por ejemplo, los pacientes con altos porcentajes de respuestas en las manchas de tinta con color o con color/forma en la prueba de Rorschach y con un CI por encima de 90 podrían ser más receptivos a contingencias verbales positivas (tales como *bueno*, *excelente* y demás), mientras que los pacientes con altos porcentajes de respuestas de movimiento o de vista (tridimensionales) en la prueba de Rorschach y con CI por arriba de 90 podrían ser más receptivos a contingencias verbales negativas (tales como *no* o *incorrecto*). Estos esfuerzos innovadores por reducir el cisma creciente en el campo de la evaluación clínica han fracasado en alentar el entusiasmo experimental, tal vez porque existen maneras más directas para evaluar la responsividad a diversas contingencias. Las diferencias entre los enfoques de evaluación tradicionales y conductuales tienen que ver con las diversas suposiciones acerca de la naturaleza de la personalidad y de las causas de la conducta. Los datos obtenidos de la evaluación tradicional se utilizan de manera principal para describir, clasificar o diagnosticar, mientras que los datos de una evaluación conductual típicamente están relacionados de manera más directa con la formu-

SÓLO PIENSE...

¿Existe alguna manera de integrar la evaluación psicológica tradicional y la evaluación conductual?

Tabla 12-5
Diferencias entre los enfoques conductuales y tradicionales en la evaluación psicológica

	Conductual	Tradicional
<i>Suposiciones</i>		
Concepción de la personalidad	Los constructos de personalidad se utilizan de manera principal para resumir patrones específicos de conducta, si los hay.	La personalidad es un reflejo de estados subyacentes y perdurables o rasgos.
Causas de la conducta	Mantener las condiciones buscadas en el ambiente actual.	Intrapsíquicas o al interior del individuo.
<i>Implicaciones</i>		
Papel de la conducta	Importante como una muestra del repertorio de la persona en una situación específica.	La conducta supone importancia sólo en la medida que indica las causas subyacentes.
Papel de la historia	Relativamente no importante excepto, por ejemplo, para proporcionar una pauta retrospectiva.	Decisiva debido a que las condiciones actuales se consideran producto del pasado.
Consistencia de la conducta	Se considera que la conducta es específica de cada situación.	Se espera que la conducta sea consistente a través del tiempo y en escenarios diversos.
<i>Usos de los datos</i>		
	Para describir conductas específicas y mantener condiciones. Para seleccionar el tratamiento adecuado. Para evaluar y revisar el tratamiento.	Para describir el funcionamiento de la personalidad y su etiología. Para diagnosticar o clasificar. Para realizar un pronóstico; para predecir.
<i>Otras características</i>		
Nivel de inferencias	Bajo	Medio a alto
Comparaciones	Mayor énfasis en lo intraindividual o ideográfico.	Mayor énfasis en lo interindividual o nomotético.
Métodos de evaluación	Mayor énfasis en métodos directos (p. ej., observaciones de la conducta en un ambiente natural).	Mayor énfasis en métodos indirectos (p. ej., entrevistas y autodescripciones).
Momentos de la evaluación	Más continuo; antes, durante y después del tratamiento.	Antes y tal vez después del tratamiento, o estrictamente para diagnosticar.
Alcance de la evaluación	Mediciones específicas y con mayor número de variables (p. ej., de conductas específicas en diversas situaciones, de efectos colaterales, del contexto, de las intensidades así como de las deficiencias).	Mediciones más globales (p. ej., de curación, o mejoría), pero sólo del individuo.

Fuente: Hartmann, Roper y Bradford (1979).

lación de un programa específico de tratamiento. Algunas de las otras diferencias entre los dos enfoques se resumen en la tabla 12-5.

El quién, qué, cuándo, dónde, por qué y cómo

El nombre lo dice todo: la *conducta* es el núcleo a valorar en la evaluación conductual; no rasgos, estados ni otros constructos se espera que estén presentes en diversas intensidades, sólo conducta. Esto se verá con mayor claridad a medida que consideremos el *quién, qué, cuándo, dónde, por qué y cómo* de la evaluación conductual.

¿Quién? ¿A *quién* se evalúa? Es posible que la persona evaluada sea, por ejemplo, un paciente en un pabellón psiquiátrico restringido, una persona que solicita ayuda en un centro de orientación, o un sujeto en un experimento académico. Independientemente de si la evaluación se realiza con propósitos de investigación, clínicos o de otro tipo, el sello distintivo de la evaluación conductual es el estudio intensivo de los individuos. Esto contrasta con la evaluación masiva de grupos de personas a fin de obtener datos normativos relacionados con algún rasgo o estado hipotético.

¿*Quién* es el evaluador? Dependiendo de la evaluación específica, el evaluador puede ser un profesional altamente capacitado, o un técnico/asistente entrenado para llevar a cabo una evaluación específica. Es frecuente emplear técnicos que registren el número de veces que una conducta específica es emitida. En este contexto, también es posible que el evaluador sea un maestro de

salón de clases que registre, por ejemplo, el número de veces que un alumno abandona su asiento. En la evaluación conductual, el evaluador también puede ser el evaluado. Es frecuente solicitar al evaluado que lleve un diario conductual, que conteste listas de verificación conductual o que participe en otras actividades diseñadas para monitorear sus propias conductas.

¿Qué? ¿Qué se mide en la evaluación conductual? Tal vez de manera poco sorprendente, la conducta o conductas que se han especificado para evaluarse variarán en función de los objetivos de la evaluación. Lo que constituye una conducta estudiada deberá ser descrita de manera inconfundible con lujo de detalle, previo a cualquier evaluación. Para propósitos de la evaluación, la conducta especial debe ser medible —cuantificable de algún modo—. Ejemplos de tales conductas medibles pueden variar desde el número de segundos que pasan antes de que un niño salga de sus clases hasta el número de grados en que cambia la temperatura corporal. Observe que las descripciones de las conductas específicas en la evaluación conductual de modo característico comienzan con la frase *el número de*.

¿Cuándo? ¿Cuándo se realiza una evaluación de la conducta? Una respuesta a esta pregunta es que, de manera habitual, la evaluación de la conducta se hace en los momentos en que existen mayores probabilidades de que se presente la conducta problema. Así, por ejemplo, si es más probable que Valeria se involucre en altercados verbales y físicos durante el almuerzo, un evaluador conductual podría enfocarse en la hora del almuerzo como un momento clave para evaluar la conducta de Valeria.

Otra manera de responder la pregunta *cuándo* se relaciona con los diversos programas con los que puede ser realizada una evaluación conductual. Por ejemplo, un programa de evaluación se denomina *registro de frecuencia* o *de ocurrencia*. La conducta estudiada se registra cada vez que ocurre. Otro programa de evaluación se denomina *registro de intervalo*. La evaluación de acuerdo con este programa sucede sólo durante intervalos de tiempo predefinidos (por ejemplo, cada tercer minuto, cada 48 horas, cada tercera semana). Además de sólo contar el número de veces que una conducta en particular es emitida, es posible para el evaluador también llevar un registro de la *intensidad* de la conducta. La intensidad de la conducta puede ser estimada por medio de sucesos observables y cuantificables como su *duración*, registrada por número de segundos, minutos, horas, días, semanas, meses o años. De manera alternativa, se puede registrar en términos de alguna razón o porcentaje del tiempo en que ocurre la conducta en un intervalo de tiempo especificado. Un método ampliamente utilizado para registrar la frecuencia e intensidad de una conducta estudiada es la **metodología de seguimiento cronológico inverso** (*timeline followback methodology*, TLFB; Sobell y Sobell, 1992, 2000). Un caso de la aplicación de la TLFB con conductas de apuesta se puede encontrar en Weinstock (2004).

SÓLO PIENSE...

Usted es un terapeuta conductual a quien recurre un apostador compulsivo. Su recomendación es que lleve un registro de su conducta. ¿Usted recomendaría que este automonitoreo se efectuara con base en la frecuencia o de acuerdo a un programa de intervalo?

¿Dónde? ¿Dónde se efectúa la evaluación? A diferencia de la aplicación de pruebas psicológicas, la evaluación conductual se puede realizar casi en cualquier lugar, de preferencia dentro de un ambiente en donde existan mayores probabilidades de que en forma natural se presente la conducta estudiada. Por ejemplo, es posible que un evaluador conductual que está estudiando los hábitos obsesivo-compulsivos de un paciente desee visitarlo en su casa a fin de observar de primera mano la variedad e intensidad de las conductas exhibidas. Por ejemplo, ¿el paciente revisa el horno para ver si dejó abierto el gas? De ser así, ¿cuántas veces ocurre en una hora? ¿El paciente se ocupa de manera excesiva en lavarse las manos? De ser así, ¿hasta qué grado? Éstas y otras preguntas relacionadas pueden surgir y ser contestadas de manera efectiva por medio de la observación directa del paciente en su hogar.

¿Por qué? ¿Por qué llevar a cabo una evaluación conductual? En general, los datos derivados de una evaluación conductual pueden tener diversas ventajas sobre los datos obtenidos por otros medios. Los datos derivados a partir de una evaluación conductual se pueden utilizar

- para proporcionar datos conductuales básicos contra los cuales se compararán otros datos conductuales (acumulados en el tiempo, después de un tratamiento, o de algún otro suceso)
- proporcionar un registro de las fortalezas y debilidades conductuales de un evaluado dentro de varias situaciones
- para ubicar con precisión las condiciones ambientales que actúan como disparadores, para mantener o extinguir ciertas conductas
- buscar patrones conductuales específicos para modificarlos por medio de intervenciones
- crear representaciones gráficas útiles para estimular métodos de tratamiento innovadores o más efectivos

En esta era de cuidado administrado y de frugales pagos a terceros, también debemos señalar que las compañías aseguradoras tienden a favorecer las evaluaciones conductuales por encima de las evaluaciones más tradicionales. Esto se debe a que, normalmente, la evaluación conductual no está vinculada de manera representativa con ninguna teoría de la personalidad en particular y a que el progreso de los pacientes se estima en base a sucesos conductuales documentados.

¿Cómo? ¿Cómo se efectúa una evaluación conductual? Por supuesto, la respuesta a esta pregunta variará dependiendo del propósito de la evaluación. En algunas situaciones, el único equipo especial requerido es un observador capacitado, papel y lápiz. En otro tipo de situaciones, puede ser necesario un sofisticado equipo de grabación.

Otra cuestión clave del *cómo*, está relacionada con el análisis de los datos obtenidos de la evaluación conductual. La medida en que los patrones psicométricos son considerados aplicables

SÓLO PIENSE...

Imagine ser un psicólogo de la NASA que está estudiando los efectos psicológicos y conductuales de los viajes espaciales en los astronautas. ¿Qué tipos de mediciones conductuales emplearía y qué equipo especial necesitaría —o diseñaría— para obtener tales mediciones?

en la evaluación conductual es una cuestión polémica, con dos bandos opuestos. Uno de los bandos podría caracterizarse por aceptar las tradicionales suposiciones psicométricas acerca de la evaluación conductual, incluyendo los supuestos acerca de la medición de la confiabilidad (Russo *et al.*, 1980) y de la validez (Haynes *et al.*, 1979, 1981). Representativas de esta posición son afirmaciones como las expresadas por Bellack y Hersen (1988) de que “la confiabilidad, validez y utilidad de cualquier procedimiento debería ser de primordial importancia, independientemente de su desarrollo conductual o no conductual” (p. 614).

Cone (1977) defendió el enfoque tradicional de la evaluación conductual en un artículo titulado “Pertinencia de la confiabilidad y la validez en la evaluación conductual”. No obstante, conforme pasaron los años, Cone (1986, 1987) llegó a ser el primer proponente de una postura alternativa, en la cual los estándares psicométricos tradicionales son rechazados como normas inadecuadas para la evaluación conductual. Por ejemplo, Cone (1981) escribió que “un punto de vista verdaderamente conductual de la evaluación está basado en una aproximación al estudio de la conducta tan radicalmente distinto con respecto al modelo usual de las diferencias individuales que se debería adoptar un enfoque igualmente distinto en la adecuación de los procedimientos de evaluación conductual” (p. 51).

SÓLO PIENSE...

¿Los estándares psicométricos tradicionales son aplicables a la evaluación conductual?

Otros también han cuestionado la utilidad de los enfoques tradicionales a la confiabilidad de las pruebas en la evaluación conductual, señalando que “la herramienta de evaluación puede ser precisa, pero la conducta medida puede haber cambiado” (Nelson *et al.*, 1977, p. 428). Con base en el concepto de que cada evaluación conductual es un experimento por derecho propio, Dickson (1975)

escribió: “Si uno supone que cada objetivo en la evaluación representa un experimento singular, entonces lo que se requiere es el método científico de experimentación e investigación, más que un programa formalizado para la evaluación... Dentro de esta estructura, cada situación es considerada única, y la confiabilidad de este enfoque no es una función de las técnicas de estanda-

rización... más bien es una función del seguimiento del método experimental en la evaluación” (pp. 376-377).

Acercamientos a la evaluación conductual

La evaluación conductual se puede lograr por varios medios, incluyendo observaciones conductuales y escalas de calificación conductual, estudios análogos, automonitoreo y métodos de desempeño situacional. Examinemos de manera breve cada uno de éstos, así como otros métodos relacionados.

Observación conductual y escalas de estimación *Un psicólogo infantil observa a un niño en un cuarto de juegos a través de un espejo unidireccional. Un terapeuta familiar ve la grabación en video de una familia en problemas tratando de resolver un conflicto. Un psicólogo escolar observa a un adolescente interactuando con sus compañeros en la cafetería de la escuela.* Todos estos son ejemplos del uso de una técnica de evaluación denominada **observación conductual**. Como su nombre lo indica, esta técnica involucra observar las actividades de las personas o sujetos de investigación específicos y llevar de manera habitual algún tipo de registro de dichas actividades. De suyo, los investigadores, clínicos u orientadores pueden servir ellos mismos como observadores, o pueden designar como observadores a asistentes capacitados u otras personas (como padres, hermanos, maestros y supervisores). Incluso, la persona observada puede ser ella misma el observador conductual, aunque en esos casos el término *autoobservación* sería más adecuado que *observación conductual*.

En algunos casos, la observación conductual implica el uso de medios mecánicos, tales como la grabación en video de un suceso. Grabar los eventos conductuales libera al clínico, al investigador o a cualquier otro observador de la necesidad de estar físicamente presente en el momento en que sucede el evento y permite un análisis detallado del acontecimiento en un momento más conveniente. De manera usual, los factores advertidos en la observación conductual incluirán la presencia o ausencia de las conductas específicas estudiadas, de excesos conductuales, de deficiencias conductuales, de ventajas conductuales y de los antecedentes y consecuencias situacionales de las conductas emitidas. Por supuesto, debido a que las personas que observan y califican también son humanas, la observación conductual no siempre es tan inequívoca como puede parecer (véase *Psicometría cotidiana*).

La observación conductual puede tomar diversas formas. El observador puede registrar, siguiendo la tradición naturalista, una narrativa continua de los sucesos, utilizando herramientas tales como lápiz y papel, cámaras de video, películas o fotografía fija, o una grabadora de audio. Mehl y Pennebaker (2003), por ejemplo, utilizaron este enfoque naturalista en su estudio de la vida social de estudiantes. Registraron las conversaciones de 52 pasantes universitarios por periodos de dos días mediante una grabadora computarizada de audio.

Otra forma de observación conductual emplea lo que se conoce como *escala de estimación conductual*, una hoja preimpresa en la que el observador anota la presencia o intensidad de las conductas estudiadas, generalmente al seleccionar casillas o al rellenar pequeños cuadros codificados. En ocasiones, el usuario de una forma de calificación conductual escribe descripciones codificadas de diversas conductas. El código es preferible a un maratón narrativo porque toma mucho menos tiempo ingresar los datos. El código libera al observador familiarizado de tener que ingresar los datos relacionados con cualquiera de cientos de conductas posibles, no sólo las que están consideradas en las formas impresas. Por ejemplo, existen diversos sistemas de codificación para observar las conductas de parejas y familias. Dos sistemas como éstos son el Sistema de codificación de interacción marital (Weiss y Summers, 1983) y el Sistema de calificación de interacción de parejas (Notarius y Markman, 1981). En la actualidad, es frecuente el uso de pequeños dispositivos manuales para ingresar los datos facilitando así el trabajo del observador.

Planteados como acercamientos a la evaluación conductual, en general, las escalas y sistemas de calificación conductual se pueden categorizar de diferentes formas. Un continuo, que va desde *directo* a *indirecto*, tiene que ver con el medio en el que ocurre la conducta observada y qué tan cercano es este medio al medio en el que la conducta sucede de manera natural. Mientras

Confesiones de un calificador conductual

En las discusiones acerca de la evaluación conductual, con frecuencia la atención se centra de manera directa sobre el individuo que es evaluado. Sólo en raras ocasiones, si es que en alguna, se hace referencia a los pensamientos y sentimientos de la persona responsable de evaluar la conducta de otro. A continuación, presentamos los pensamientos hipotéticos de un calificador conductual. Decimos que son hipotéticos porque, en realidad, estas ideas no son los pensamientos de una sola persona, sino una recopilación de los pensamientos de muchas personas responsables de llevar a cabo evaluaciones conductuales.

Todos los calificadores conductuales entrevistados para este cometido formaban parte del personal de un centro comunitario de pacientes internos y externos en Brewster, Nueva York. Uno de los objetivos de este centro es preparar a sus miembros adolescentes y adultos para vivir de una manera constructiva e independiente. Los miembros son alojados en habitaciones que cuentan con diversos grados de supervisión, y su conducta es monitoreada las 24 horas del día. Todos los días, a los miembros se les proporciona un formato de calificación conductual de ocho páginas denominado registro de datos clínicos (RDC), el cual se remite al personal de supervisión para que lo califique en el transcurso del día. El personal registra información conductual referente a variables tales como actividades, habilidades sociales, apoyo necesario y conducta disfuncional.

Sobre la base de los datos conductuales, es posible recomendar ciertas intervenciones médicas o de otros tipos. Debido a que el monitoreo conductual de los pacientes es cotidiano y constante, los cambios conductuales que se presentan en función a la medicación, actividades u otras variables son detectados de inmediato y se hace un ajuste a las estrategias de intervención. En resumen, los datos conductuales pueden afectar de manera significativa el curso de la estancia del paciente en la institución; todo, desde la cantidad de supervisión cotidiana,

hasta los privilegios de fijar la fecha de alta está bajo la influencia de los datos conductuales. Tanto los pacientes como el personal están conscientes de este hecho de la vida institucional; así, tanto los pacientes como el personal toman muy en serio el llenado del RDC. Dados estos antecedentes, presentamos los pensamientos privados de un calificador conductual:

Hago el registro de los datos conductuales en presencia de los pacientes y por lo general, éstos están muy interesados en lo que estoy haciendo. Después de que terminé de codificar los RDC de los pacientes durante el tiempo que se encuentran conmigo, otros miembros del personal los codifican en cuanto al tiempo que ellos pasan con el paciente. Y así se hace. Es como si cada paciente llevara un diario detallado de su vida; sólo que somos nosotros, el personal, los que lo llevamos por ellos.

En ocasiones, especialmente para el personal nuevo, se siente raro estar calificando las conductas de otros seres humanos. Una mañana, tal vez porque empaticé con el paciente, le arrojé un formato del RDC sin llenar y le dije en broma que calificara mi conducta. Para la cena, mucho después de que había olvidado ese incidente, me percaté de que el paciente me estaba codificando por malos modales en la mesa. Por fuera, me reí, pero por dentro, en realidad estaba un poco ofendido. Más adelante, conté un chiste a los que estaban allí que, en retrospectiva, probablemente no era del mejor gusto. El paciente me codificó como socialmente ofensivo. Ahora genuinamente estaba tomando conciencia de mí mismo. Luego, esa noche, nos fuimos en coche a devolver una cinta de video que habíamos rentado, y el paciente codificó que yo estaba conduciendo de manera imprudente. Mi nivel de incomodidad había aumentado a tal grado que pensé que era momento de terminar la broma. En retrospectiva, me di cuenta que había experimentado de primera mano la inhibición e incomodidad que algunos pacientes

más natural sea el entorno, más directa será la medición; mientras más alejado se encuentre del entorno natural, menos directa será esta medición (Shapiro y Skinner, 1990). De acuerdo con esta categorización, por ejemplo evaluar las acciones y reacciones de un bombero mientras él o ella se enfrentan a un incendio real proporcionaría una medida *directa* de sus capacidades para combatir incendios. Pedirle a un bombero que demuestre la manera en que él o ella reaccionarían ante los eventos que ocurren durante un incendio constituiría una medida *indirecta* de sus capacidades para combatir incendios. Shapiro y Skinner (1990) también hacen una distinción entre *instrumentos de banda ancha*, diseñados para medir una amplia variedad de conductas, e *instrumentos de banda corta*, que pueden enfocarse en conductas relacionadas con constructos singulares y específicos tales como hiperactividad, timidez o depresión.

Automonitoreo El **automonitoreo** puede definirse como el acto de la observación y registro sistemáticos de la propia conducta, de los sucesos relacionados con la misma, o de ambos. El automonitoreo es diferente al autoinforme. Como lo señala Cone (1999, p. 411), el automonitoreo

experimentan cuando cada uno de sus movimientos es monitoreado por los miembros del personal cada día.

Aunque los pacientes no siempre se sienten cómodos al ser calificada su conducta —y en verdad, muchos pacientes han tenido exabruptos con los miembros del personal que de una u otra manera están relacionados con el sistema de calificación— también es cierto que el sistema parece funcionar. En ocasiones, lo que se necesita es tener esta experiencia de autoconciencia para que la gente sea mejor. Aquí, recuerdo a Sandy, un joven brillante que poco a poco comenzó a estar fascinado con el RDC y pronto empezó a pasar gran parte del día preguntando a los miembros del personal acerca de él. Después de poco tiempo, Sandy pidió se le permitiera codificar su propio RDC. Nunca nadie había pedido eso con anterioridad y se realizó una junta de personal para meditar acerca de las consecuencias de dicha acción. Como un experimento, se decidió que a este paciente se le permitiría codificar su propio RDC. El experimento tuvo excelentes resultados. La autocodificación de Sandy lo mantuvo relativamente “sobre la pista” en cuanto a sus metas conductuales y encontró que cada vez se esforzaba más por ponerse bien a medida que mostraba señales de mejoría. Al ser dado de alta, Sandy dijo que extrañaría supervisar su progreso por medio del RDC.

Instrumentos como el RDC pueden y probablemente han sido usados como armas o recompensas por el personal. El personal puede amenazar a los pacientes con una mala evaluación conductual. Evaluaciones excesivamente negativas en respuesta a una conducta disfuncional que sea particularmente molesta para el personal es una posibilidad siempre presente. No obstante, todo el tiempo estás agudamente consciente de que el sistema funciona mejor cuando el personal codifica la conducta de los pacientes de manera consistente e imparcial.



Una participante recibe entrenamiento en habilidades culinarias para una vida independiente mientras que un miembro del personal monitorea su conducta con el RDC.

...depende de las observaciones de *la* conducta que reviste interés clínico... en el *tiempo...* y *lugar...* de su ocurrencia real. Por contraste, el autoinforme utiliza suplentes o sustitutos (descripciones verbales, informes) de la conducta de interés que son obtenidos en un momento y lugar diferentes al momento y lugar de ocurrencia real de la conducta [cursivas en el original].

El automonitoreo puede ser utilizado para registrar pensamientos, sentimientos o conductas específicos. La utilidad del automonitoreo depende en gran medida de la competencia, diligencia y motivación del evaluado, aunque se han diseñado diversos métodos ingeniosos para ayudar al proceso o para garantizar su conclusión (Barton *et al.*, 1999; Bornstein *et al.*, 1986; Wilson y Vitousek, 1999). Por ejemplo, se han programado computadoras portátiles para emitir un sonido que sirva como señal para observar y registrar la conducta (Shiffman *et al.*, 1997).

El automonitoreo es tanto una herramienta de evaluación como una de intervención. En algunos casos, el mismo acto del automonitoreo (por ejemplo, del fumar, comer o sentir ansiedad o pánico) puede ser terapéutico. Las cuestiones prácticas que deben ser consideradas son la

metodología empleada, el establecimiento de los pensamientos, sentimientos o conductas por observar, el establecimiento de los procedimientos de muestreo, los dispositivos y procedimientos de automonitoreo, así como la capacitación y la preparación (Foster *et al.*, 1999).

SÓLO PIENSE...

Desarrolle un ejemplo que sea original para ilustrar cómo el automonitoreo puede ser una herramienta de evaluación, así como de intervención.

También se deben considerar las cuestiones psicométricas (Jackson, 1999), incluyendo el problema potencial de la *reactividad*. La **reactividad** se refiere a los posibles cambios en la conducta, pensamientos o desempeño del evaluado que pueden surgir como respuesta al hecho de ser observado, evaluado o medido. Por ejemplo, si usted está en un programa para bajar de peso y automonitoreando su consumo de alimentos, puede tender más a abstenerse del pastel de queso que a consumirlo. La educación, la capacitación y la preparación adecuada son algunas de las herramientas que se utilizan para contrarrestar los efectos de la reactividad en el auto-

monitoreo. Además, las entrevistas acerca de los efectos de la reactividad, posteriores al automonitoreo, pueden proporcionar indicios adicionales acerca de la emisión de los pensamientos o conductas en observación.

Estudios análogos El acercamiento conductual hacia la evaluación y el tratamiento clínicos se ha comparado con el acercamiento de un investigador hacia la experimentación. El evaluador conductual se comporta de manera muy similar a un investigador; el problema del cliente es la variable dependiente y el o los factores responsables de ocasionar o de mantener la conducta problema es la variable o variables independientes. De manera habitual, los evaluadores conductuales utilizan la frase **análisis funcional** de la conducta para denominar al proceso de identificar las variables dependientes e independientes respecto al problema presentado. Sin embargo de la misma manera en que los experimentadores deben emplear variables dependientes e independientes que imiten las variables del mundo real, así deben actuar los evaluadores conductuales.

Un **estudio análogo** es una investigación experimental en la que una o más variables se asemejan o son análogas a la variable real que el investigador quiere analizar. Se debe admitir que esta definición es muy amplia, y que el término *estudio análogo* ha sido utilizado en varias formas. Por ejemplo, se ha utilizado para describir investigaciones realizadas con ratas blancas cuando en realidad el investigador quiere saber algo acerca de los seres humanos. Se ha usado para describir investigaciones efectuadas con estudiantes de tiempo completo cuando el interés real del investigador es aprender acerca de los empleados de tiempo completo que trabajan en un contexto empresarial. Se ha empleado para describir investigaciones acerca de la agresión, definiendo a ésta como la aplicación experimental de choques eléctricos, cuando en realidad el experimentador quiere aprender acerca de la agresión en el mundo real, fuera del laboratorio.

Un término más específico que *estudio análogo* es el de **observación conductual análoga** que, como indica Haynes (2001a), se puede definir como la observación de una persona o personas en un ambiente diseñado para aumentar la probabilidad de que el evaluador pueda observar las conductas estudiadas y sus interacciones. La persona o personas de esta definición pueden ser las que

solicitan ayuda profesional (incluyendo niños y adultos, familias o parejas) o sujetos de investigación (incluyendo estudiantes, compañeros de trabajo, o cualquier otra muestra experimental). Por supuesto, la conducta a estudiar depende del objetivo de la investigación. En el caso de una persona que evita las caminatas en el campo a causa de un temor a las serpientes, la conducta objetivo de la evaluación (y sujeta a cambio) es la reacción de temor a las serpientes, que surge comúnmente al realizar una caminata por el campo. Esta conducta se puede evaluar (y tratar) de manera análoga dentro de la oficina del clínico mediante el empleo de fotografías y videos de serpientes, serpientes vivas dentro de una jaula y serpientes vivas fuera de la jaula.

Se han empleado varios ambientes diseñados para aumentar las probabilidades de que el evaluador observe la conducta investigada (véase, por ejemplo, Heyman, 2001; Mori y Armendáriz, 2001; Norton y Hope, 2001; y Roberts, 2001). Han surgido pre-

SÓLO PIENSE...

A consecuencia de un accidente automovilístico, el cliente de un terapeuta conductual afirma que perdió la capacidad para conducir un automóvil. El terapeuta desea evaluar esta queja por medio de una observación conductual análoga. ¿Cómo debería proceder el terapeuta?

guntas acerca de qué tan análogos son los estudios análogos en realidad, así como interrogantes en cuanto a su verdadera utilidad (Haynes, 2001b).

Tanto las mediciones situacionales de desempeño como las mediciones en la interpretación de un papel pueden ser consideradas como acercamientos de evaluación análogos.

Mediciones de desempeño situacional Si usted en alguna ocasión ha solicitado un empleo de oficina de medio tiempo y se le requirió hacer una prueba de mecanografía, ya ha experimentado de primera mano lo que son las *mediciones de desempeño situacional*. Definido de manera amplia, una **medición de desempeño situacional** es un procedimiento que permite observar y evaluar a un individuo bajo un conjunto estándar de circunstancias. Una medición de desempeño situacional usualmente implica llevar a cabo cierta tarea bajo condiciones reales o simuladas. La prueba práctica de manejo para obtener una licencia de conducir constituye una medición de desempeño situacional que supone una evaluación de las habilidades de manejo en un automóvil verdadero, en una calle verdadera, entre tráfico verdadero. Por otra parte, las mediciones de desempeño situacional que se utilizan para evaluar las habilidades en viajes espaciales de los futuros astronautas se realizan en simuladores de vuelo de cohetes dentro de laboratorios que se encuentran firmemente plantados en la Madre Tierra. Lo que todas las mediciones de desempeño situacional tienen en común es que se considera que el constructo que miden puede ser evaluado de manera más precisa mediante el análisis directo de la conducta que si se le pide al sujeto que describa su conducta. En algunos casos, los sujetos pueden estar motivados a describirse de manera engañosa, como cuando se les pregunta acerca de su conducta moral. En otros casos, sencillamente es posible que los sujetos no sepan cómo responderían bajo circunstancias particulares, como en el caso de una prueba de estrés.

La **técnica del grupo sin líder** es un procedimiento de evaluación situacional en el que varias personas son organizadas en grupo con el propósito de llevar a cabo una tarea, al tiempo que un observador registra la información relacionada con la iniciativa, cooperación y liderazgo, entre otras variables, de cada uno de los integrantes del grupo. De manera habitual, todos los miembros del grupo saben que se les está evaluando y que su conducta está siendo observada y registrada. De modo intencional se proporcionan instrucciones vagas al grupo y no se coloca a nadie en una posición de autoridad o liderazgo. El grupo determina la manera en que se efectuará la tarea y quién será responsable de cuáles deberes. La situación del grupo sin líder proporciona la oportunidad de observar el grado de cooperación que exhibe cada individuo del grupo y la medida en que cada uno de ellos puede funcionar como parte de un equipo.

La técnica del grupo sin líder se ha utilizado en contextos militares y empresariales. Su uso en la milicia surgió de los intentos de la Oficina de Servicios Estratégicos de Estados Unidos (U. S. Office of Strategic Services; OSS, 1948) para evaluar el liderazgo, así como otros rasgos de personalidad. El procedimiento fue diseñado como un auxiliar en la creación de unidades militares cohesionadas —tripulaciones de aeronaves, tanques y demás— en los que los miembros trabajarían bien en conjunto y en la que cada uno pudiera hacer una contribución significativa. De manera similar, este procedimiento se puede aplicar en escenarios industriales y organizacionales para identificar personas que trabajen bien unas con otras y personas con habilidades gerenciales elevadas que cuenten con “potencial ejecutivo”.

El método de grupos de trabajo autoadministrados desafía los conceptos tradicionales de administrador y empleado. ¿Cómo puede alguien manejar a un grupo que supuestamente se administra a sí mismo? Una manera es tratar de identificar a los *no líderes*, quienes actúan de manera principal como facilitadores en el sitio de trabajo y que tienen la capacidad de equilibrar un estilo administrativo no participativo con un estilo de orientación más directiva cuando se requiere (Manz y Simms, 1984).

SÓLO PIENSE...

Usted es un consultor empresarial que trabaja para una corporación importante a quien le han asignado una tarea: crear una medición de desempeño situacional diseñada para identificar a un *no líder*. Esboce su plan de manera breve.

Representación de roles La técnica de **representación de roles**, o de actuar en una situación improvisada o parcialmente improvisada, se puede utilizar en la educación, en terapia y en la evaluación. Por ejemplo, de manera rutinaria, los departamentos de policía preparan a sus novatos para situaciones de urgencia pidiéndoles que representen papeles,

tales como los de un oficial que se enfrenta a un delincuente que tiene sujeto a un rehén a punta de pistola. Parte de la evaluación final de un futuro oficial de policía puede consistir en el desempeño exitoso en una tarea de representación de roles. Un terapeuta puede utilizar la técnica de representación de roles para ayudar a una pareja con problemas a fin de evitar enfrentamientos dolorosos y que aprendan métodos más efectivos de resolución de conflictos. El que esa misma pareja resuelva ciertas cuestiones mediante la exitosa representación de un rol puede ser uno de los criterios para dar por terminado un tratamiento.

Existe una amplia y creciente literatura acerca de la representación de roles como herramienta de evaluación. En general, la representación de roles puede proporcionar un medio relativamente económico y altamente adaptable para evaluar varias conductas “potenciales”. Con gran

SÓLO PIENSE...

Describa un referente para la evaluación que se prestaría de manera ideal para el uso de la interpretación de un rol como herramienta de evaluación.

cautela decimos “potenciales” debido a la falta de certeza de que la conducta en la representación de roles se presente en una situación natural (Kern *et al.*, 1983; Kolotkin y Wielkiewicz, 1984). Bellack *et al.* (1990) emplearon la representación de roles tanto para propósitos de evaluación como de instrucción con pacientes psiquiátricos internos que estaban siendo preparados para vivir de manera independiente. Al mismo tiempo que reconocieron los beneficios de la representación de roles en la evaluación de la preparación de los pacientes para su reintegración a la comunidad, estos autores

advirtieron que “el último criterio de validez para cualquier evaluación realizada de manera experimental o clínica es la observación de la conducta estudiada, de manera no intrusiva, dentro de la comunidad” (p. 253).

Métodos psicofisiológicos La búsqueda de pistas para poder comprender y predecir la conducta humana ha llevado a los investigadores al estudio de índices fisiológicos como el ritmo cardíaco y la presión sanguínea. Se sabe que éstos y otros índices pueden estar influenciados por factores psicológicos, de allí el término **psicofisiológico** para describir estas variables así como los métodos utilizados para su estudio. Es discutible si estos métodos son realmente de naturaleza *conductual*. No obstante, tienden a estar asociados con clínicos e investigadores orientados de manera conductual.

Tal vez el más conocido de todos los métodos psicofisiológicos utilizados por los psicólogos sea la *biorretroalimentación*. **Biorretroalimentación** es un término genérico que puede ser ampliamente definido como un tipo de técnicas de evaluación psicofisiológica diseñadas para estimar, exhibir y registrar un continuo monitoreo de procesos biológicos específicos tales como el pulso y la presión arterial. Dependiendo de la manera en que haya sido diseñado el equipo de biorretroalimentación, pueden monitorearse muchos diferentes procesos biológicos tales como la tasa de respiración, la resistencia eléctrica de la piel y las ondas cerebrales, para después retroalimentar al evaluado por medio de presentaciones visuales, como luces y escalas, o por medio de estímulos auditivos, como campanas y timbres.

El uso de la biorretroalimentación con humanos fue inspirado por informes sobre animales que al ser recompensados (y así, retroalimentados) por la emisión de ciertas respuestas involuntarias (como el ritmo cardíaco) podían modificar de manera exitosa dichas respuestas (Miller, 1969). La experimentación inicial con humanos ha demostrado que existe la capacidad para producir ciertos tipos de onda cerebral a voluntad (Kamiya, 1962, 1968). Desde entonces, la biorretroalimentación ha sido utilizada en un amplio rango de aplicaciones terapéuticas y relacionadas con la evaluación (French *et al.*, 1997; Hazlett *et al.*, 1997; Hermann *et al.*, 1997; Zhang *et al.*, 1997).

El **pletismógrafo** es un instrumento que registra los cambios en el volumen de alguna parte del cuerpo que ocurren por variaciones en el suministro de sangre. Los investigadores han utilizado este dispositivo para explorar los cambios en el flujo sanguíneo como variable dependiente. Por ejemplo, Kelly (1966) encontró diferencias significativas en el suministro de sangre entre grupos de sujetos normales, ansiosos y psiconeuróticos (donde el grupo con ansiedad tuvo la media más elevada) por medio del uso de un pletismógrafo para medir el suministro de sangre al antebrazo.

El **pletismógrafo peneano** también es un instrumento diseñado para medir cambios en el flujo sanguíneo, de manera más específica, el flujo de sangre en el pene. Debido a que el volumen de

sangre en el pene se incrementa con la excitación sexual masculina, al pletismógrafo peneano se le ha hallado una aplicación en la evaluación de delincuentes sexuales masculinos. En un estudio, sujetos que eran violadores convictos, mostraron mayor excitación sexual ante descripciones de violaciones y menor excitación ante historias de sexo mutuamente aceptado, comparados con sujetos control (Quinsey *et al.*, 1984). Los criminales que persisten en negar una elección desviada de objetos sexuales pueden ser confrontados con los resultados de los estudios para obligarlos a hablar de manera más sincera acerca de sus pensamientos y conductas (Abel *et al.*, 1986). Los **datos falométricos**, como se les denomina, también tienen aplicaciones en programas de tratamiento y evaluación. Mediante una evaluación de este tipo, el infractor —violador, pederasta, exhibicionista u otro tipo de delincuente sexual— se ve expuesto a estímulos visuales y/o auditivos, que muestran escenas de conductas normales y desviadas mientras se mide su tumescencia peneana.

Normalmente, la más popular de todas las herramientas de medición psicofisiológica es la comúnmente conocida como *detector de mentiras* o **polígrafo** (de manera literal, “más de una gráfica”). Aunque de manera común no se le asocia con la evaluación psicológica, la industria de la detección de mentiras, dada la frecuencia con la que esta prueba es administrada y sus consecuencias potenciales, puede ser descrita como “una de las más importantes ramas de la psicología aplicada” (Lykken, 1981, p. 4). Con base en la suposición de que cuando un sujeto miente suceden cambios físicos detectables, el polígrafo proporciona un registro impreso continuo (que se conoce de formas diversas como *trazado*, *gráfica*, *diagrama* o *poligrama*) de distintos índices fisiológicos (habitualmente respiración, respuesta galvánica de la piel y volumen sanguíneo/pulso) mientras que un entrevistador y operador del instrumento (conocido como *poligrafista*) le hace al evaluado una serie de preguntas a contestar con *sí* o *no*. Los juicios acerca de la veracidad de las respuestas se hacen ya sea de manera informal, mediante el análisis de las gráficas, o de manera más formal por medio de un sistema de calificación.

La confiabilidad de los juicios realizados por los poligrafistas es una cuestión polémica (Iacono y Lykken, 1997). Existen diversos métodos para realizar las valoraciones poligráficas (Lykken, 1981) y el equipo poligráfico no está estandarizado (Abrams, 1977; Skolnick, 1961). Un problema con este método es la elevada tasa de falsos positivos en las mentiras. El procedimiento “puede clasificar a más del 50% de sujetos inocentes como culpables” (Kleinmuntz y Szucko, 1984, p. 774). A la luz de los juicios que se pide realicen los poligrafistas, los requisitos educativos, la capacitación y los antecedentes parecen mínimos. Después de tan sólo seis semanas de entrenamiento, uno puede calificar para ser poligrafista. A partir de los datos psicométricos y otros relacionados, parece razonable concluir que la promesa de una máquina que pretende detectar la falta de honestidad todavía no se ha cumplido (Alpher y Blanton, 1985).

SÓLO PIENSE...

La evidencia poligráfica no es admisible en la mayoría de los tribunales; sin embargo, las agencias de justicia y la milicia continúan utilizándola como herramienta de evaluación. ¿Qué piensa al respecto?

Mediciones no intrusivas Un tipo de medición totalmente diferente de lo que hemos analizado hasta el momento es la de tipo *no reactiva* o **no intrusivo** (Webb *et al.*, 1966). En muchos casos, una medición no intrusiva es un trazo o registro físico revelador. En un estudio, era la basura literalmente (Cote *et al.*, 1985). Debido a su naturaleza, las mediciones no intrusivas no necesariamente requieren de la presencia o cooperación de los evaluados cuando se realizan éstas. En el libro ya clásico que a punto estuvo de ser titulado *La barba del torero*,⁸ Webb *et al.* (1966) citaron numerosos ejemplos de mediciones no intrusivas, incluyendo las siguientes:

8. Webb *et al.* (1966) explicaron que el provocativo, aunque poco descriptivo título *La barba del torero* fue “extraído de la observación de que las barbas de los toreros son más largas el día de la corrida que en cualquier otro. Nadie parece saber si en realidad ese día la barba del torero crece con mayor velocidad a causa de la ansiedad o sencillamente se debe a que aquél no se habrá querido rasurar con la navaja en una mano temblorosa. De cualquier forma, no encontramos suficientes aficionados taurinos estadounidenses que explicaran el punto” (p. v). El título finalmente escogido fue Mediciones no intrusivas: investigación no reactiva en las ciencias sociales (*Unobtrusive Measures: Nonreactive Research in the Social Sciences*).

- La popularidad de un objeto exhibido en un museo puede ser medida al comparar la erosión del piso a su alrededor con la erosión alrededor de otros objetos en la exposición.
- La cantidad de licor consumido en un pueblo puede medirse contando el número de botellas vacías en los botes de basura.
- El grado de temor inducido por una sesión de historias de fantasmas puede medirse por la reducción en el diámetro del círculo de niños sentados.

Hace poco tiempo, las envolturas dejadas sobre las charolas de restaurantes de comida rápida fueron utilizadas para calcular el consumo de calorías en los clientes (Stice *et al.*, 2004). En otro innovador uso de un “registro descriptivo”, los investigadores utilizaron un anuario fotográfico universitario para estudiar la relación entre expresiones emocionales positivas y otras variables, como personalidad y resultados en la vida (véase el *Close-up* del presente capítulo).

SÓLO PIENSE...

Stice *et al.* (2004) idearon diversas mediciones no intrusivas para calcular el consumo de calorías en personas que están a dieta; sin embargo, no pudieron crear una manera éticamente aceptable para estimar el consumo de calorías en el hogar. ¿Puede usted pensar en alguna forma de lograr este objetivo?

Cuestiones relacionadas con la evaluación conductual

La solidez psicométrica de las herramientas de la evaluación conductual puede ser evaluada, pero encontrar la mejor manera de hacerlo puede ocasionar algún debate. De manera más específica, surgen dudas acerca de cuál de los diversos modelos de medición es el más apropiado. Del capítulo 5 recordará que la teoría clásica de pruebas y la teoría de la generalizabilidad conciben las variaciones en las calificaciones de prueba de maneras un poco diferentes. En la teoría de la generalizabilidad, en lugar de tratar de estimar una calificación verdadera única, se presta atención a cómo se esperaría que variaran las calificaciones de prueba en diversas situaciones como resultado de los cambios en la característica medida. Es por ésta y otras razones relacionadas que la teoría de la generalizabilidad parece aplicable de manera particular a la evaluación conductual, en oposición a la medición de los rasgos de personalidad. La conducta cambia en cada situación, lo que hace necesario una aproximación a la cuestión de la confiabilidad que pueda explicar tales cambios. Por contraste, los rasgos de personalidad son considerados por muchos como relativamente estables en diferentes situaciones. Por tanto, se asume que los rasgos de personalidad son medidos de manera más adecuada por medio de instrumentos basados en supuestos congruentes con el modelo de puntuación real.

Sin importar si las mediciones conductuales son evaluadas de acuerdo a la teoría clásica de pruebas, a la teoría de la generalizabilidad, o a alguna otra (como un análisis experimental Skinneriano),

parecen existir algunos puntos en los cuales todos pueden estar de acuerdo. Uno de ellos es que debe existir un nivel aceptable de confiabilidad entre calificadores y entre observadores o calificadores de las conductas. Una fuente potencial de error en las mediciones conductuales puede surgir en la situación en la que exista una diferencia entre dos o más de las conductas observadas o de cualquier otro elemento medido y que conduzca a una estimación más favorable o desfavorable de la que se hubiera obtenido de no haber existido esta diferencia (Maurer y Alexander, 1991). Una valoración conductual puede ser excesivamente positiva (o negativa) debido a que una valoración anterior haya sido excesivamente negativa (o positiva). Esta fuente de error se denomina **efecto de contraste** (figura 12-9).

Se han observado efectos de contraste en entrevistas (Schuh, 1978), en diarios y listas de verificación conductuales (Maurer *et al.*, 1993), en valoraciones basadas en el desempeño en el laboratorio (Smither *et al.*, 1988) y en valoraciones en base a su desempeño en el campo (Ivancevich, 1983). En un estudio de entrevistas de contratación, se consideró que hasta 80% de la varianza total era debida a los efectos de contraste (Wexley *et al.*, 1972).

SÓLO PIENSE...

Webb *et al.* (1966) argumentaron que las mediciones no intrusivas pueden de manera útil complementar otras técnicas de investigación, como entrevistas y cuestionarios. ¿Qué medición no intrusiva cree que se utilizaría para complementar un cuestionario acerca de los hábitos de estudio de los alumnos?

Personalidad, éxitos en la vida y las fotografías del anuario universitario

Pocas personas se asombrarían al saber que las diferencias individuales en las emociones están asociadas con diferencias en la personalidad. Sin embargo, es probable que muchas personas se sorprendan al averiguar que las diferencias personales en las emociones bien pueden tener un efecto significativo en el curso de nuestras vidas. En un estudio, se observó que la tendencia a expresar ira incontrolada durante la niñez temprana estaría asociada con el mal humor a lo largo de la vida y con diversos resultados negativos en la vida, tales como deficientes logros educativos, empleos de menor nivel, patrones erráticos de trabajo, obtención de rangos militares inferiores y divorcio (Caspi *et al.*, 1987). Resultados tan sugerentes como éstos han instado a otros investigadores a preguntarse acerca de los posibles efectos de las emociones positivas sobre la personalidad y los éxitos en la vida.

Las emociones positivas tienen muchos efectos benéficos, que van desde una amplitud de pensamiento y de repertorios de acción (Cunningham, 1988; Frederickson, 1998; Isen, 1987) hasta la capacidad para acercarse a otras personas (Berry y Hansen, 1996; Frijda y Mesquita, 1994; Ruch, 1993). Una sonrisa puede enviar el mensaje de que uno es amistoso y no amenazador (Henley y LaFrance, 1984; Keating *et al.*, 1981) y puede conducir a atribuciones positivas acerca del grado en que una persona es sociable, amable, agradable y estable (Borkenau y Liebler, 1992; Frank *et al.*, 1993; Matsumoto y Kudoh, 1993). Con base en estos hallazgos y en otras investigaciones similares, Harker y Keltner (2001) hipotetizaron que las expresiones emocionales positivas podrían predecir mayores niveles de bienestar a lo largo de la adultez. Sometieron a prueba esta hipótesis examinando la relación de las diferencias individuales en la expresión emocional positiva, con la personalidad y otras variables.

Se obtuvo una medida de expresión emocional positiva al codificar las calificaciones hechas por jueces sobre las fotografías contenidas en un anuario universitario, de mujeres que habían participado en un estudio de investigación longitudinal (Helson, 1967; Helson *et al.*, 1984). Estos juicios codificados fueron analizados con respecto a datos de personalidad existentes en archivos (tales como las respuestas de los sujetos a la Lista de verificación de adjetivos a las edades de 21, 27, 43 y 52 años) y con datos de éxito en la vida (incluyendo el bienestar tal como es medido por el Inventario psicológico de California, el estado civil y la Lista de verificación de tensiones matrimoniales).

Consistente con la hipótesis de los investigadores, de acuerdo a lo que se evidenciaba en las fotografías del anuario universitario, la expresión emocional positiva resultó estar correlacionada de manera positiva con los éxitos de vida tales como satisfacción matrimonial y sentido de bienestar personal. Esto fue así, incluso, cuando algunas variables que podían originar confusiones en los resultados, tales como el atractivo físico o la deseabilidad social, fueron controlados al analizar los datos. Sin embargo, los investigadores advirtieron que la medición de la expresión emocional utilizada en el estudio (la fotografía del anuario) consistía



¿Existe alguna relación entre la emoción expresada en las fotografías del anuario universitario, la personalidad y el éxito en la vida? De acuerdo con un estudio, la respuesta es sí. Los investigadores encontraron que la expresión emocional positiva mostrada en las fotografías de mujeres universitarias predijeron resultados favorables en el matrimonio y en el bienestar personal hasta 30 años después.

en un solo índice de comportamiento muy limitado. Exhortaron a los investigadores futuros a considerar el uso de diferentes medidas de expresión emocional obtenidas en diferentes contextos. Los investigadores también advirtieron que sus resultados se limitaban a la investigación con mujeres. Una sonrisa puede tener implicaciones distintas en la vida de los hombres (Stoppard y Gruchy, 1993). De hecho, las sonrisas estuvieron correlacionadas de manera negativa con resultados positivos en la vida en una muestra de cadetes militares en West Point (Mueller y Mazur, 1996).

Este estimulante estudio fue, de acuerdo con Harker y Keltner (2001), "uno de los primeros en documentar que las diferencias individuales en la expresión se relacionan con la personalidad y pueden ser aspectos estables de la misma" (p. 121).

Figura 12-9
El efecto de contraste en la pista de patinaje

Los jueces del patinaje artístico, así como otros calificadores conductuales, son sólo humanos. Es posible que los patinadores que realizan ejecuciones merecedoras de puntajes extremadamente altos no reciban lo que merecen sencillamente porque el patinador que se presentó antes que ellos por contraste fue excelente. Las calificaciones podrían ser más favorables cuando la ejecución anterior a la suya haya sido muy deficiente. Debido a un efecto de contraste, los puntos que obtenga un patinador en una ejecución de patinaje artístico pueden depender hasta cierto grado de la calidad de la ejecución del patinador inmediatamente anterior.



Para combatir los posibles efectos de contraste y otros tipos de error de estimación, es necesaria una rigurosa capacitación para los calificadores. Sin embargo, este tipo de capacitación puede resultar costosa en términos de tiempo y trabajo. Por ejemplo, enseñar a un grupo de profesionales a utilizar la observación conductual y el Sistema de codificación de interacción matrimonial tomó de “dos a tres meses de instrucción y práctica semanales para aprender a utilizar sus 32 códigos” (Fredman y Sherman, 1987, p. 28). Otra aproximación para minimizar errores y para mejorar la confiabilidad entre los calificadores conductuales es utilizar un **juicio compuesto** que es, en esencia, el promedio de una multitud de juicios.

Algunos tipos de sesgo del observador prácticamente no tienen o no son de fácil remedio. Por ejemplo, en la observación conductual que implica el uso de equipos de video, en muchas ocasiones sería ventajoso que se pudieran utilizar diversas cámaras y grabadoras para cubrir diversos ángulos de la acción que se está presentando, hacer acercamientos y demás. La factibilidad económica de la situación (aparte de otros factores, como el número de horas que requeriría el ver las grabaciones tomadas desde diferentes ángulos) es que pocas veces es posible tener más de una cámara en una posición fija para grabar la acción. La cámara está, en cierto sentido, sesgada hacia esa posición fija porque en muchos casos está registrando información que puede ser muy diferente a la que se obtendría si se hubiera colocado en una posición distinta, o si se hubiesen hecho múltiples grabaciones.

Como habíamos observado ya en el contexto del automonitoreo, la reactividad es otro posible problema referente a la evaluación conductual. Este término se refiere al hecho de que las personas reaccionan de manera diferente en situaciones experimentales en oposición a como reaccionarían en situaciones naturales. Los micrófonos, cámaras y espejos unidireccionales pueden por ellos mismos alterar la conducta de las personas observadas. Por ejemplo, algunos pacientes bajo observación grabada en video pueden intentar minimizar la cantidad de psicopatología que están dispuestos a dejar registrada para la posteridad. Otras personas bajo las mismas condiciones pueden intentar exagerar dicha psicopatología. Una posible solución al problema de la reactividad es el uso de observadores ocultos o de técnicas clandestinas de grabación, aunque tales métodos plantean serias interrogantes éticas. Muchas veces, todo lo que se necesita para resolver el problema de la reactividad es un periodo de adaptación. Las personas observadas pueden adaptarse a la idea y comenzar a comportarse de manera habitual. La mayoría de los clínicos saben, por experiencia personal, que una grabadora de audio en el consultorio donde se realiza una terapia, al principio, puede incomodar a los pacientes, pero existen buenas probabilidades de que la ignoren en unos cuantos minutos.

Una perspectiva

Hace más de medio siglo, la importante obra de Theodor Reik, *Escuchando con el tercer oído* (*Listening with the Third Ear*), interesó a los clínicos por las posibilidades de evaluación e intervención mediante una entrevista realizada con destreza, de una atención activa y de una interpretación ingeniosa, con tendencia a profundizar. En una viñeta, una paciente de terapia narraba una visita al dentista, lo que implicó una inyección y la extracción de un diente. Mientras hablaba, hizo una observación sobre un libro que estaba “parado de cabeza” en el estante de Reik, a lo que Reik contestó: “¿Pero por qué no me dijo que había tenido un aborto?” (Reik, 1948, p. 263). Al reflexionar acerca de esta asombrosa exhibición de intuición clínica, Masling (1997) escribió: “A todos nos hubiese gustado haber tenido el toque mágico de Reik, la capacidad para discernir lo que está oculto y secreto, que nos sirviera como oráculo” (p. 259).

Históricamente, la sociedad ha solicitado la ayuda de los profesionales de la salud mental para obtener juicios diagnósticos y recomendaciones de intervención, frecuentemente sobre la base de relativamente poca información. En un principio, las pruebas psicológicas, específicamente del área de evaluación de la personalidad, prometían otorgar a los clínicos —simples mortales— el poder de representar el papel de oráculos que la sociedad imponía y anticipaba. Pronto, surgieron dos filosofías muy diferentes en cuanto al diseño y uso de las pruebas. El enfoque clínico dependía en gran medida del juicio e intuición del clínico y se caracterizaba por una carencia de reglas preestablecidas y aplicadas de manera uniforme para inferir conclusiones clínicas y predicciones. En contraste, el enfoque estadístico o actuarial dependía en gran medida de la estandarización, de las normas y de reglas y procedimientos preestablecidos y aplicados de manera uniforme. Los duelos entre los diversos miembros de estos dos bandos fueron comunes durante muchos años y han sido reseñados de manera detallada en otras fuentes (Marchese, 1992).

Parece justo afirmar que en aquellas situaciones en que los datos sean insuficientes como para formular reglas para la toma de decisiones y la elaboración de predicciones, el enfoque clínico supera al enfoque estadístico. Sin embargo, en muchos sentidos, es el enfoque estadístico el que ha sido acogido con mayor entusiasmo por los profesionales contemporáneos. Esto es así por varias razones, entre ellas la principal: el deseo apasionado por hacer que la evaluación sea más una ciencia que un arte. Y es posible que ese deseo surja del hecho de que la mayoría de nosotros no somos oráculos. Sin buenas herramientas, es difícil, si no es que imposible, ver, de forma espontánea y consistente, a través de lo que Reik caracterizó como “el yo secreto”. Incluso con buenas herramientas, es un desafío.

El enfoque estadístico permite conservar las hipótesis y predicciones que se ha descubierto son útiles, mientras las hipótesis y predicciones insostenibles pueden ser descubiertas y rechazadas con rapidez (Masling, 1997). Por supuesto, en muchos casos, la habilidad en la evaluación clínica puede ser conceptualizada como una versión internalizada, menos formal y más creativa del enfoque estadístico.

El enfoque estadístico en la evaluación de la personalidad se está volviendo cada vez más común. Incluso los instrumentos proyectivos, que alguna vez fueron el “baluarte” del enfoque clínico de la “vieja escuela”, cada vez con mayor frecuencia se publican con normas y se están investigando por medio del uso de métodos estadísticos rigurosos. Incluso se han hecho esfuerzos —muy respetables— por aplicar sofisticados modelos de IRT (teoría de respuesta al reactivo) a los datos del TAT, entre otros. (Tuerlinckx, 2002). Pero los académicos, en general, se han visto poco impresionados: “En psicología académica, el clima de opinión acerca de las pruebas proyectivas sigue como si nada hubiera cambiado y los clínicos todavía siguieran leyendo las hojas del té” (Masling, 1997, p. 263).

Si la orientación clínica, a semejanza de un oráculo, está caracterizada como el *enfoque del tercer oído*, podríamos caracterizar la orientación contemporánea como un *enfoque Van Gogh*; en cierto sentido, un oído ha sido eliminado. Los días del oráculo que todo lo sabe ya han pasado. Hoy día, es obligatorio para los clínicos responsables depender de las normas, de la estadística inferencial y de los elementos esenciales relacionados con el enfoque estadístico. Aún sigue siendo deseable, si no es que obligatorio, el juicio clínico sólido. No obstante, es requerido en menor medida para hacer interpretaciones y predicciones a la ligera y más para el propósito de organizar e

interpretar la información proveniente de diferentes herramientas de evaluación. Abundaremos más sobre este punto al avanzar al capítulo 13, Evaluación clínica y de orientación psicológica.

Autoevaluación

Evalúe su comprensión de los elementos del presente capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaturas:

análisis funcional	juicio compuesto	prueba de límites (en la prueba de Rorschach)
apercibir	medición de desempeño situacional	prueba de Rorschach
asociación libre	medición no intrusiva	psicofisiológicos (métodos de evaluación)
automonitoreo	método proyectivo	reactividad
bioretroalimentación	metodología de seguimiento cronológico inverso	representación de roles
conceptos de necesidad, presión y tema, de Murray	métodos objetivos de evaluación de la personalidad	sistema comprensivo de Exner
datos falométricos	observación análoga conductual	sistema de calificación de la prueba de Rorschach
efecto de contraste	observación conductual	TAT
estudio análogo	pletismógrafo	técnica del grupo sin líder
evaluación conductual	pletismógrafo peneano	tronco de frases incompletas
hipótesis proyectivas	percepto	
HIT (Holtzman Inkblot Technique)	polígrafo	
interrogatorio	prueba de asociación de palabras	
interrogatorio de la prueba de Rorschach	prueba de dibujo	

Un vistazo a la red

Consulte los siguientes sitios de la red para mayor información acerca de los temas que se analizaron en el presente capítulo.

La prueba de Rorschach

www.phil.gu.se/fu/ro.html

www.deltabravo.net/custody/rorschach.htm

<http://skeptdic.com/inkblot.html>

Técnica de manchas de tinta de Holtzman

www.cps.nova.edu/~cpphelp/HIT.html

TAT

www.ehendrick.org/healthy/002188.htm

www.pearsonassessments.com/tests/tat.htm

<http://web.utk.edu/~wmorgan/tat/tattxt.htm>

Pruebas proyectivas en línea (aplican precauciones usuales)

<http://similarminds.com/word>

Técnicas proyectivas

www.wermany.org/reading/projections.htm

Técnicas psicofisiológicas: el pletismógrafo peneano

<http://skeptdic.com/penilep.html>

Dibujos proyectivos: ¿Qué tan válidas son las interpretaciones de estos dibujos?

www.psychpage.com/projective/p_roj_draw_notes.html

El grupo sin líder

www.people.vcu.edu/~rsleeth/Tasktips99L.html#THE GROUP DECISION

El efecto de contraste

http://changingminds.org/explanations/theories/perceptual_contrast.htm

Evaluación clínica y de orientación psicológica

La **psicología clínica** es la rama de la psicología que tiene como interés principal la prevención, diagnóstico y tratamiento de la conducta anormal. Los psicólogos clínicos reciben capacitación en evaluación psicológica y en psicoterapia, y trabajan en hospitales, centros de salud mental públicos y privados, en consultas privadas y en el ámbito académico. A semejanza de la psicología clínica la **orientación psicológica** es una rama de la psicología que se preocupa por prevenir, diagnosticar y tratar la conducta anormal. Los psicólogos clínicos tienden más a enfocar sus esfuerzos de investigación y tratamiento hacia las formas más severas de patología en la conducta, mientras que los psicólogos orientadores se centran más en problemas cotidianos como dificultades en la comunicación marital y familiar, en las decisiones para elegir una profesión y en los problemas relacionados con los hábitos de estudio. Los miembros de ambas disciplinas se esfuerzan por alentar el crecimiento personal de sus clientes. Las herramientas empleadas en el proceso de evaluación se superponen de manera notable.

Es pertinente que analicemos en este capítulo todas las pruebas y mediciones que hemos cubierto hasta aquí —de inteligencia, de personalidad, de auto concepto y estilo cognoscitivo—, pues todas tienen aplicaciones potenciales en el contexto clínico y en el de orientación psicológica. También aquí podríamos analizar otros instrumentos especializados, como las herramientas diseñadas para evaluar las variables relacionadas con el sitio de trabajo. Sin embargo, en un texto introductorio como éste, se deben hacer elecciones en cuanto a amplitud y organización.

En los dos capítulos anteriores, hemos estudiado varios enfoques sobre la evaluación de la personalidad y la conducta. En el presente capítulo, examinaremos diversas herramientas de evaluación psicológica en el contexto de su aplicación clínica y de orientación psicológica, así como su relación con diversos usos y aplicaciones. En el camino, encontrará información importante acerca de la *evaluación culturalmente informada*: el significado de este término y algunas estrategias para lograrla. El capítulo concluye con una consideración acerca de cuestiones relacionadas con la evaluación clínica en oposición a la actuarial. Después de leer esa consideración, usted estará mejor preparado para decidir si el título (y tema) del presente capítulo en el futuro debería cambiarse por algo así como “Evaluación actuarial”.

Sinopsis

La evaluación clínica puede ser requerida por diferentes razones. Para el psicólogo clínico que labora en un hospital, u otro ámbito clínico, las herramientas de evaluación frecuentemente se utilizan para clarificar el problema psicológico, hacer un diagnóstico, y/o diseñar un programa de tratamiento, o para todo lo anterior. “¿Este paciente padece un trastorno mental?” y, de ser así, “¿cuál es el diagnóstico?”, son preguntas habituales que requieren respuestas. En muchos casos, las herramientas de evaluación, incluyendo una entrevista, una prueba y los datos de la historia

clínica o de caso, pueden proporcionar esas respuestas. Exploremos de manera breve la forma en que estas herramientas pueden ser utilizadas en escenarios clínicos.

Es posible que el clínico, antes o después de entrevistar a un paciente, le administre algunos exámenes como una prueba de inteligencia de Wechsler y el MMPI-2 para obtener estimados del funcionamiento intelectual del paciente y de su nivel de psicopatología. Los datos obtenidos pueden proporcionarle al clínico una hipótesis inicial acerca de la naturaleza de las dificultades del individuo, las cuales, después, servirán como guía para la entrevista. De manera alternativa, los datos de la prueba pueden confirmar o refutar las hipótesis hechas en base a la entrevista. La entrevista y los resultados arrojados por la prueba serán complementados con los datos de la historia del desarrollo, en especial si el paciente no puede o no quiere cooperar. El clínico puede en-

trevisitar a personas que conozcan al paciente, como miembros de su familia, compañeros de trabajo y amigos, para obtener registros e información pertinente al caso.

“¿Cuál es el nivel actual de funcionamiento de esta persona? ¿Cómo se compara con el de otras personas de la misma edad?” Considere el ejemplo de un individuo de quien se sospecha sufre demencia ocasionada por la enfermedad de Alzheimer. El paciente ha experimentado una constante y progresiva pérdida de habilidades cognitivas en un periodo de varios meses. Un diagnóstico de demencia puede involucrar rastrear el desempeño del individuo mediante la administración repetida de pruebas de capacidad cognoscitiva, incluyendo de memoria. Si hay demencia, se observará un descenso progresivo en el desempeño de la prueba. Las pruebas periódicas mediante diversos instrumentos también pueden proporcionar información acerca del tipo de actividades que se deben recomendar para que el paciente, así como los tipos de actividades

que se le sugeriría abreviar o abandonar por completo. De manera ideal, los datos de la historia clínica o de desarrollo proporcionarán alguna manera de estimar el nivel de **funcionamiento premórbido** (que significa “anterior a la enfermedad o trastorno”) del paciente.

“¿Qué tipo de tratamiento se deberá ofrecer a este paciente?” Las herramientas de evaluación pueden ayudar a guiar las decisiones relacionadas con el tratamiento. Pacientes que poseen una elevada inteligencia tienden a ser buenos candidatos para los métodos orientados a la percepción que requieren altos niveles de capacidad de abstracción. A una persona que se queja de sentirse deprimida se le puede pedir que se someta de manera periódica a una medición de la depresión. Si esta persona es un paciente interno, las tendencias de profundidad de la depresión como son medidas por los instrumentos elaborados para ello, pueden contribuir a tomar decisiones críticas respecto al nivel de supervisión dentro de la institución, al tipo y administración de medicamentos y a la fecha de su alta.

“¿Cómo puede describirse mejor la personalidad de esta persona?” Lograr un conocimiento del individuo no necesariamente implica enfocarse en la psicopatología. Personas que no padecen ningún trastorno mental buscan la psicoterapia para un crecimiento personal o como apoyo para manejar un conjunto difícil de circunstancias en la vida. En estos casos, se pueden utilizar entrevistas y pruebas de personalidad orientadas a la salud mental.

Es posible que los investigadores planteen una amplia variedad de otras preguntas relacionadas con la evaluación, tales como “¿Qué enfoque terapéutico será el más adecuado?” o “¿Qué tipos de cliente tienden a beneficiarse más con un tipo particular de tratamiento?” Por ejemplo, es posible que un investigador piense que las personas con un estilo cognoscitivo dependiente al medio ambiente tendrían mayores probabilidades de beneficiarse de un enfoque cognoscitivo conductual como forma de tratamiento y que las personas con un estilo cognoscitivo independiente del exterior o medio tendrían mayores probabilidades de beneficiarse de un enfoque humanista. El investigador podría utilizar varias herramientas de evaluación para combinar sujetos en grupos de tratamiento y luego medir los resultados en psicoterapia.

Los psicólogos que realizan orientación laboral pueden utilizar una amplia variedad de herramientas de evaluación que le ayuden a determinar no sólo qué tipos de trabajos podría disfrutar una persona, sino también qué ocupaciones le serían lo suficientemente retadoras sin serle tan abruma-

SÓLO PIENSE...

Los clínicos abordan la evaluación en diferentes formas. Algunos prefieren poco más que el envío de los resultados de una prueba para comenzar (de modo que sus hallazgos no se vean influidos de ninguna manera por las impresiones de otros o por los datos de la historia del caso), mientras que otros clínicos prefieren obtener la mayor información posible antes de entrevistar al paciente y de aplicar cualquier prueba. ¿Qué preferiría usted?

doras. Los psicólogos escolares y orientadores que trabajan en ámbitos educativos pueden ayudar a los estudiantes que se enfrentan a una amplia variedad de problemas, incluyendo los relacionados con el estudio. Aquí, se podrían utilizar las medidas conductuales, incluyendo el automonitoreo, para comprender de manera exacta cómo, cuándo y dónde el alumno se ocupa del estudio de la conducta. Respuestas a preguntas relacionadas como “¿Por qué no lo estoy haciendo bien en la escuela?”, pueden encontrarse, en parte, en las pruebas de diagnóstico educativo, como las diseñadas para identificar áreas problemáticas en lectura y comprensión de lectura. Otra parte de la respuesta puede encontrarse mediante otras herramientas de evaluación, incluyendo la entrevista, que puede orientarse a los aspectos de la motivación en el estudiante y a otras circunstancias de su vida.

SÓLO PIENSE...

Cite otro ejemplo o dos para ilustrar la manera en que una herramienta de evaluación podría ser utilizada en un contexto clínico o de orientación psicológica.

Evaluación clínica y atención administrada

La mayor parte de la asistencia a la salud en Estados Unidos es proporcionada por medio del sistema de administración de cuidados (Sánchez y Turner, 2003). Debido a esto, cualquier sinopsis de la evaluación clínica contemporánea no estaría completa sin mencionar la atención administrada y el profundo efecto que su institución generalizada ha tenido en la evaluación clínica. En general, el **cuidado administrado** puede ser definido como un sistema de atención a la salud donde los productos y servicios proporcionados a los pacientes por una red de proveedores de cuidados para la salud participantes son mediados por una agencia administrativa determinada por el consejo directivo, la cual mantiene bajos costos estableciendo programas de reembolso para los prestadores de servicios.

La administración de cuidados se convirtió en una realidad nacional por primera vez con la aprobación del Acta de 1973 como Ley de la Organización para el Mantenimiento de la Salud (Health Maintenance Organization, HMO), la cual consiste en un plan para la prestación comprensiva de servicios de salud para sus empleados, prepagados por un particular o una compañía, que proporciona tratamiento, cuidado preventivo y hospitalización para cada uno de sus miembros en un centro de salud), la cual proveyó un fondo federal para ese fin. Las subsecuentes enmiendas a dicha ley, así como los explosivos aumentos en los costos de la atención a la salud, crearon un ambiente fértil para la industria del cuidado administrado. Desafortunadamente, las compañías administradoras de cuidados no han estado dispuestas a destinar una parte de los escasos recursos para el cuidado de la salud al pago por servicios de evaluación psicológica. En consecuencia, a pesar de la contundente evidencia que sustenta la efectividad de los servicios de evaluación en ámbitos de asistencia a la salud (Kubiszyn *et al.*, 2000), tales servicios han sido reducidos de manera drástica (Cushman y Guilford, 2000; Eisman *et al.*, 2000). Las restricciones basadas en los pagos por el tiempo y la selección de pruebas pueden crear conflictos de interés en los usuarios de las pruebas (Lezak, 2002). En una gran medida, tanto el destino de la evaluación clínica en escenarios de cuidados a la salud como la naturaleza de la práctica de la evaluación han estado ligadas a los dictados de la realidad económica y a las decisiones de terceros respecto a la atención administrada (Piotrowski *et al.*, 1998).

SÓLO PIENSE...

Argumente el caso en el que el cuidado administrado podría ser conveniente para la tarea de la evaluación.

Una función clave de la evaluación clínica, ya sea dentro o fuera del ambiente de la administración de cuidados, es el diagnóstico de trastornos mentales. Nuestra sinopsis continúa con un análisis de este aspecto de la evaluación clínica.

Diagnóstico de trastornos mentales

De manera frecuente, un objetivo de la evaluación clínica es diagnosticar trastornos mentales. La fuente de referencia utilizada para hacer esos diagnósticos es la versión actual del *Manual Diagnóstico y Estadístico* (DSM, por sus siglas en inglés) de la Asociación Psiquiátrica Estadounidense (American Psychiatric Association) que en la actualidad es el **DSM-IV-TR** (donde IV significa “cuarta

edición” y TR “texto revisado”). El DSM-IV fue publicado en 1994, y su edición revisada se publicó en el 2000. El DSM-IV-TR nombra y describe todos los trastornos mentales conocidos y además incluye una categoría denominada *Condiciones no atribuibles a trastornos mentales que son un foco de atención o tratamiento*. Un diagnóstico del DSM-IV-TR transmite de inmediato una gran cantidad de información descriptiva acerca de la naturaleza de la desviación, déficit o exceso conductual de la persona diagnosticada.

Algunos psicólogos clínicos, de manera más abierta los de orientación conductista, han expresado su insatisfacción con el DSM-IV-TR por varias razones. Quizá su preocupación principal sea que el manual está firmemente arraigado en el modelo médico. Los patrones de pensamiento y conducta no se describen en el DSM-IV-TR sólo como eso —patrones de pensamiento y conducta— sino más bien en formas que se asemejan a la descripción de una enfermedad. También

se ha criticado al sistema de diagnóstico por ser relativamente poco confiable. Diferentes clínicos que entrevistan al mismo paciente bien pueden obtener diagnósticos diferentes. Además, aun cuando todos los clínicos puedan concordar en cuanto a un diagnóstico, el DSM-IV-TR no proporciona indicación alguna en cuanto a qué método de tratamiento tendría una efectividad óptima. Desde una perspectiva cultural, es posible que el DSM-IV-TR se haya construido con una sensibilidad insuficiente para ciertas culturas, en especial si se trata acerca de la discusión de los trastornos disociativos (Lewis-Fernández, 1998).

SÓLO PIENSE...

¿Debería un manual diagnóstico proporcionar a los clínicos alguna indicación acerca de cuál método de tratamiento sería efectivo de manera óptima?

Los proponentes del DSM-IV-TR consideran que este sistema de diagnóstico es útil debido a la abundancia de información que transmite un diagnóstico psiquiátrico. Discuten sobre la imposibilidad de lograr una confiabilidad perfecta entre diagnósticos debido a la naturaleza del tema. En respuesta a la crítica al modelo médico, los defensores del DSM-IV-TR sostienen que el sistema de diagnóstico es útil independientemente de si alguna categoría de diagnóstico es realmente una enfermedad o no. Cada uno de los trastornos mencionados está asociado con dolor, sufrimiento o discapacidad. Se discute si el sistema de clasificación proporciona temas de encabezados útiles bajo los cuales los investigadores puedan buscar (o añadir a) en la literatura de investigación respecto a las diferentes categorías de diagnóstico.

En el DSM-IV-TR, los diagnósticos están codificados de acuerdo con cinco *ejes* (dimensiones). Los tipos de trastornos incluidos en cada eje son los siguientes:

Eje I: Trastornos de la infancia, niñez y adolescencia; demencias como las ocasionadas por la enfermedad de Alzheimer; trastornos causados debido al uso de drogas; trastornos en el estado de ánimo y de ansiedad; y esquizofrenia. También aquí se incluyen padecimientos que pueden ser susceptibles de tratamiento (como problemas académicos o sociales) pero no atribuibles a trastornos mentales.

Eje II: Retraso mental y trastornos de la personalidad.

Eje III: Aquí se incluyen condiciones físicas que pueden afectar el funcionamiento mental, desde migrañas hasta alergias.

Eje IV: Diferentes problemas o fuentes de tensión pueden ocurrir en la vida de un individuo en cualquier momento dado. Problemas económicos, legales, maritales, ocupacionales, o de otro tipo que pueden precipitar conductas que van desde volver al hábito de fumar después de que se había abandonado, hasta intentos de suicidio. La presencia de tales problemas se señala en este eje.

Eje V: Este eje proporciona una evaluación global de funcionamiento general. En el extremo elevado de esta escala están los valores indicativos de ausencia de síntomas y de preocupaciones cotidianas. El extremo bajo de la escala contiene los valores que indican que la persona está en un peligro claro y presente para sí mismo o para los demás y que, por tanto, debe ser internada en una institución segura.

Los diagnósticos del DSM-IV-TR son descriptivos y no teóricos. Esto es adecuado para un texto de referencia fidedigno diseñado para proporcionar un lenguaje común a clínicos e investigadores con variadas orientaciones teóricas hacia la etiología y tratamiento de los trastornos

mentales (Widiger y Clark, 2000). Los primeros dos ejes contienen todas las categorías diagnósticas de los trastornos mentales y los tres restantes proporcionan información adicional relacionada con el nivel de funcionamiento del individuo y de su situación actual de vida. Es posible una multiplicidad de diagnósticos. Por ejemplo, se puede diagnosticar que un individuo presenta conductas indicativas de trastornos que se incluyen tanto en el Eje I como en el Eje II.

Al momento de redactar el presente texto, la quinta edición del DSM está programada para un futuro cercano. En un esfuerzo por contestar a los críticos del DSM-IV-TR, han surgido una variedad de cuestiones interesantes relacionadas con la categorización de los trastornos mentales (Kupfer *et al.*, 2002). Tal vez, una de las preguntas más básicas sea “¿Qué es un trastorno?” Esta pregunta engañosamente sencilla ha generado un acalorado debate (Clark, 1999; Spitzer, 1999). La tercera edición del DSM fue la primera edición de ese manual que contenía una definición de trastorno mental, y la definición ofrecida recibió muchas críticas. Como alternativa, Jerome C. Wakefield (1992a) conceptualizó trastorno mental como una “disfunción perjudicial”. Para Wakefield, un trastorno es la falla perjudicial de los mecanismos internos para ejecutar sus funciones naturalmente seleccionadas. La postura de Wakefield es una **opinión evolucionista del trastorno mental** porque considera que los mecanismos internos que fallan o fracasan han sido adquiridos mediante el proceso darwiniano de selección natural. Para Wakefield, atribuir un trastorno implica dos cosas: 1) un juicio científico de que existe este fracaso evolutivo y 2) un juicio de valor de que este fracaso es perjudicial para el individuo (Wakefield, 1992b).

En contraste con el punto de vista evolucionista acerca del trastorno, existe una infinidad de opiniones diferentes. Klein (1999) argumentó que no se sabe cuál es la “función evolucionista adecuada” y que la conducta clasificada como “trastornada” puede ser el producto de diversas causas involuntarias (como una enfermedad) o incluso voluntarias (como representar un papel o fingirse enfermo). Otros han participado en este asunto polémico señalando el papel de la cultura (Kirmayer y Young, 1999) y defendiendo posiciones estratégicas alternativas, tales como enfocarse en el problema a nivel neuronal (Richters y Hinshaw, 1999). Algunos han indicado que el concepto de trastorno es tan amplio que no necesita tener propiedades definitorias de cualquier tipo (Lilienfeld y Marino, 1995, 1999).

SÓLO PIENSE...

Entonces, ¿qué es un trastorno?

Independientemente de cómo se defina un trastorno, una herramienta esencial para identificarlo es la entrevista. Y si se impusiera el método de Jonathan Shedler, los trastornos serían identificados por los mismos pacientes mediante una computadora de mano. Shedler desarrolló una herramienta de diagnóstico diseñada para ser auto aplicada por pacientes médicos en cuidados primarios. A los pacientes se les plantean preguntas en la pantalla integrada y responden sí o no en el teclado. El médico puede obtener un informe de resultados generado por la computadora que incluye diagnósticos específicos del DSM. Por supuesto, las entrevistas con pacientes aún pueden realizarse a la antigua, y es hacia este tipo de diálogo a los que ahora volvemos nuestra atención.

La entrevista

Excepto en raras ocasiones, como cuando el evaluado es completamente comunicativo, es probable que la entrevista sea parte de una evaluación individual de cada clínico u orientador. Por ejemplo, dentro de una situación clínica, es posible que la entrevista se efectúe para llegar a un diagnóstico, para determinar con exactitud las áreas que se deben atender en psicoterapia o para determinar si un individuo se dañará a sí mismo o a otros. En una aplicación característica de orientación vocacional, la entrevista es realizada para ayudar al entrevistado a saber más acerca de sí mismo para que pueda hacer mejores elecciones respecto a una profesión u otras opciones de vida. De las entrevistas, al ser efectuadas cara a cara de manera habitual, el entrevistador obtiene información de los entrevistados no sólo de lo *que* dicen, sino también de *cómo* lo dicen y de la manera en que se presentan a sí mismos durante la entrevista.

Con frecuencia, una entrevista orientará las decisiones acerca de qué otra cosa puede hacerse para evaluar a un individuo. Si el entrevistado describe sus síntomas o quejas de manera vaga o

inconsistente, es posible que lo indicado sea una prueba diseñada para la detección general de psicopatología. Si el entrevistado se queja de problemas de memoria, se le puede aplicar una prueba estandarizada de memoria. En caso de que el entrevistado no pueda describir la frecuencia con la que ocurre un problema en particular, quizá lo adecuado sea un periodo de automonitoreo. Las entrevistas se utilizan con frecuencia desde un principio en escenarios de la práctica independiente para consolidar el **contrato terapéutico**, un acuerdo entre el cliente y el terapeuta en el que se determinan las metas, expectativas y obligaciones mutuas respecto al curso de la psicoterapia.

Los entrevistadores expertos se esfuerzan por crear un ambiente positivo y de aceptación para conducir la entrevista. Es posible que utilicen preguntas abiertas al principio y más adelante preguntas cerradas para obtener información específica. Un entrevistador efectivo transmite comprensión al entrevistado, ya sea de manera verbal o no verbal. Las maneras de transmitir esa comprensión incluyen una postura atenta y la expresión facial, así como frecuentes afirmaciones para reconocer o resumir lo que el entrevistado está tratando de decir. En ocasiones, los entrevistadores transmiten que están prestando atención al afirmar con la cabeza y con vocalizaciones tales como “um-hmm”. Sin embargo, el entrevistador debe ejercitar la cautela en este caso. Se ha observado que estas vocalizaciones y asentimientos con la cabeza actúan como reforzadores que aumentan la emisión de ciertas vocalizaciones por parte del entrevistado (Greenspoon, 1955). Por ejemplo, si el terapeuta dijo “um-hmm” cada vez que el entrevistado trajo a colación material relacionado con el tema de su madre, entonces —de no intervenir otros factores— es posible que el entrevistado pase más tiempo hablando acerca de su madre que si no se le hubiese reforzado al mencionar ese tema.

Existen muchos tipos de entrevista; el *tono* de una entrevista puede variar notablemente de otra en función del propósito de la entrevista. Ahora, veamos los diferentes tipos de entrevista.

Tipos de entrevista

Las entrevistas se pueden catalogar respecto a un cierto número de variables diferentes. Una de estas variables es el contenido. El contenido de algunas entrevistas, como la entrevista general para conocer a alguien, puede tener un rango amplio. Por contraste, otras entrevistas se centran de manera estrecha en un contenido específico. Otra variable en la que difieren las entrevistas es la *estructura*. Una entrevista altamente estructurada es una en la que todas las preguntas que se plantean son preparadas de antemano. En una entrevista poco estructurada, son pocas o ninguna las preguntas preparadas de antemano, dándole la libertad al entrevistador de profundizar en algunos temas según lo indique su juicio. Una ventaja de la entrevista estructurada es que proporciona un método uniforme de exploración y evaluación. Una entrevista estructurada, de manera muy semejante a una prueba, puede por tanto ser utilizada como una medida de antes y después de los resultados. En realidad, muchos estudios de investigación que exploran la eficacia de un nuevo medicamento, de un enfoque en la terapia o de alguna otra intervención, emplean entrevistas estructuradas como medidas de resultados.

Existen muchas entrevistas estructuradas disponibles para el uso de los profesionales de la evaluación. Por ejemplo, la Entrevista clínica estructurada para trastornos disociativos (*Structured Clinical Interview for Dissociative Disorders*) (SCID-D) está diseñada para ayudar en el diagnóstico de trastornos disociativos (Steinberg *et al.*, 1993). El Programa para trastornos afectivos y esquizofrenia (*Schedule for Affective Disorders and Schizophrenia*, SADS; Endicott y Spitzer, 1978) es una entrevista estandarizada diseñada para la detección de esquizofrenia y trastornos del afecto. La Entrevista estructurada de síntomas reportados (*Structured Interview of Reported Symptoms*, SIRS; Rogers, 1986; Rogers *et al.*, 1992) es utilizada en los esfuerzos por detectar la simulación de estar enfermo.

Además del contenido y la estructura, las entrevistas pueden diferir en cuanto al *tono*. En un tipo de entrevista —no muy común— de manera intencional el entrevistador hace sentir tenso al entrevistado. **Entrevista de tensión** es el término general que se aplica a cualquier entrevista en la que uno de sus objetivos es poner al entrevistado en un estado de tensión por alguna razón en particular. La tensión puede ser inducida para someter a prueba algún aspecto de la personalidad (tal como agresividad u hostilidad) que puede obtenerse sólo bajo ese tipo de condiciones. La fuente de tensión varía en función del propósito de la evaluación; las fuentes posibles pueden emanar del entrevistador en forma de expresiones faciales desaprobatorias, comentarios críticos,

reafirmaciones condescendientes, sondeos implacables o evidente incompetencia. Otras fuentes de tensión pueden emanar de las “reglas del juego”, como límites de tiempo irrazonables para cumplir las demandas.

El *estado de conciencia* del entrevistado es otra variable relacionada con el tipo de entrevista. La mayoría de las entrevistas se efectúan cuando el entrevistado se encuentra en un estado de conciencia normal, cotidiana y alerta. Sin embargo, en ocasiones, una situación específica puede requerir de una entrevista altamente especializada en la cual el estado de conciencia del entrevistado sea alterado de manera deliberada. La **entrevista hipnótica** es la que es efectuada mientras el sujeto está bajo hipnosis. Las entrevistas hipnóticas se pueden realizar como parte de una evaluación o intervención terapéutica cuando el entrevistado ha sido testigo ocular de un crimen o situación relacionada. En todos estos casos, la creencia prevaleciente es que el estado hipnótico hará que el entrevistado enfoque su concentración para intensificar sus recuerdos (McConkey y Sheehan, 1996; Reiser, 1980, 1990; Vingoe, 1995).

Los críticos de la entrevista hipnótica sugieren que cualquier ganancia en los recuerdos puede verse contrabalanceada por las pérdidas en la precisión y otros posibles resultados negativos (Kebbell y Wagstaff, 1998). Es posible que de manera inadvertida, los procedimientos de la entrevista hipnótica hagan que el entrevistador se sienta más confiado en cuanto a sus recuerdos, independientemente de la fidelidad con la que los evoque (Dywan y Bowers, 1983; Sheehan *et al.*, 1984). Comparados con los entrevistados no hipnotizados, existe la posibilidad de que los entrevistados hipnotizados sean más sugestionables ante preguntas tendenciosas y, así, más vulnerables a la distorsión de los recuerdos (Putnam, 1979; Zelig y Beidleman, 1981). Algunos investigadores creen que hipnotizar a los testigos puede producir de manera inadvertida una distorsión irreversible en la memoria (Diamond, 1980; Orne, 1979). Como resultado, es posible que se prohíba que declaren los testigos que hayan sido hipnotizados para intensificar su memoria (Laurence y Perry, 1988; Perry y Laurence, 1990).

Fisher y algunos colegas (Fisher y Geiselman, 1992; Fisher *et al.*, 1989; Fisher *et al.*, 1987; Mello y Fisher, 1996) han desarrollado un procedimiento de entrevista diseñado para conservar las mejores características de la entrevista hipnótica sin inducir la hipnosis. En la **entrevista cognoscitiva**, se establece el acuerdo y se alienta al entrevistado a utilizar la imaginación y la recuperación enfocada para recordar alguna información. Si el entrevistado es testigo ocular de un crimen, es posible que se le pida que cambie de perspectiva y que describa los sucesos desde el punto de vista del perpetrador. De manera muy parecida a lo que usualmente sucede durante la hipnosis, gran parte del control de la entrevista se desplaza hacia el entrevistado. Y, a diferencia de muchas entrevistas policiacas, las preguntas abiertas se enfatizan más que las cerradas, y se permite que el entrevistado hable sin interrupción (Kebbell y Wagstaff, 1998).

La **entrevista participativa** permite al entrevistado una gran amplitud para interactuar con el entrevistador. Es como si la frontera entre evaluador profesional y evaluado lego se hubiese reducido y ambos fueran participantes trabajando —colaborando— juntos de manera cercana en una misión común de descubrimiento, clarificación e iluminación. En un contacto inicial previo a la evaluación formal mediante pruebas y otros medios, se podría invitar al entrevistado a que ayude a estructurar los objetivos. ¿Qué debe lograrse mediante la evaluación? El entrevistado es un participante muy activo dentro de la evaluación participativa. Se pueden encontrar descripciones de un proceso esencialmente de evaluación participativa en los escritos de Dana (1982), Finn (1996), Fischer (1994) y otros. Lo que tienen en común es el “empoderamiento de la persona a través de un papel participativo y de colaboración en el proceso de evaluación” (Allen, 2002, p. 221).

Independientemente del tipo específico de entrevista que se lleve a cabo, existen ciertas preguntas “modelo” que de manera característica surgen respecto a las siguientes áreas. Estas preguntas son seguidas por interrogatorios adicionales según lo demande el juicio clínico:

Datos demográficos: Nombre, edad, sexo, religión, número de personas en la familia, raza, ocupación, estado civil, nivel socioeconómico y cultural, dirección, números de teléfono.

SÓLO PIENSE...

¿De qué manera innovadora le gustaría a usted participar o colaborar en su propia entrevista clínica o de orientación psicológica?

Motivos de la recomendación: ¿Por qué este individuo está solicitando o se le está enviando a evaluación psicológica? ¿Quién es la fuente de recomendación?

Antecedentes médicos: ¿Qué eventos son significativos en la historia médica de este individuo?

Condición médica actual: ¿Qué padecimientos médicos actuales presenta el individuo? ¿Qué medicamentos está utilizando en la actualidad?

Antecedentes médicos familiares: ¿Qué tipos de enfermedad crónica o hereditaria se encuentran en los antecedentes familiares?

Antecedentes psicológicos: ¿Qué eventos traumáticos ha sufrido este individuo? ¿Qué problemas psicológicos (tales como trastornos del estado de ánimo o trastornos del contenido de pensamiento) lo han aquejado?

Antecedentes con profesionales médicos o psicológicos: ¿Qué contactos similares para evaluación o intervención ha tenido? ¿Estos contactos fueron satisfactorios en la opinión del evaluado? De no ser así, ¿por qué no lo fueron?

Condición psicológica actual: ¿Qué problemas psicológicos aquejan a esta persona en la actualidad? ¿Durante cuánto tiempo han persistido estos problemas? ¿Qué es lo que ocasiona estos problemas? ¿Cuáles son las fortalezas psicológicas de este individuo?

A lo largo de la entrevista, el entrevistador puede anotar sus impresiones subjetivas acerca de la apariencia general del sujeto (¿apropiada?); de su personalidad (¿sociable?, ¿suspica?, ¿tímido?); de su estado de ánimo (¿eufórico?, ¿deprimido?); de su reactividad emocional (¿apropiada?, ¿aplanada?); del contenido de pensamiento (¿alucinaciones?, ¿delirios?, ¿obsesiones?); de su habla (¿conversación normal?, ¿lenta y divagante?, ¿con rimas?, ¿sonsonete?, ¿gritos?), y de su juicio (respecto a cuestiones como conducta anterior y planes a futuro). Durante la entrevista, se debe anotar cualquier acción fortuita que realice el paciente y que pueda ser utilizada para el propósito de la evaluación.¹

Una variedad de entrevista clínica utilizada con frecuencia, en especial en escenarios médicos, es el examen del estado mental.

Examen del estado mental Un equivalente del examen físico general que efectúa el médico es el **examen del estado mental** que lleva a cabo un clínico. Este examen, utilizado para detectar los déficit intelectuales, emocionales y neurológicos, de manera característica incluye interrogatorios u observaciones respecto a cada área analizada en la siguiente lista.

Apariencia: ¿Son apropiadas la manera de vestir y la apariencia general en cuanto a imagen e higiene del paciente?

Conducta: ¿Hay algo notablemente extraño en la manera de hablar o en la conducta general en el momento de la entrevista? ¿El paciente presenta tics faciales, movimientos involuntarios, dificultades en la coordinación o en el modo de andar?

Orientación: ¿El paciente está orientado como persona?, es decir, ¿sabe quién es? ¿Está orientado respecto al lugar?, es decir, ¿sabe dónde está? ¿Está orientado respecto al tiempo?, es decir, ¿sabe el año, el mes y el día?

1. De manera tangencial, anotamos la experiencia del escritor *senior* (RJC) mientras conducía una entrevista en el Servicio de Urgencias Psiquiátricas del Hospital Bellevue. A lo largo de la entrevista de ingreso, el paciente esporádicamente guiñaba su ojo izquierdo. En cierto momento durante la entrevista, el entrevistador dijo: “Noto que usted constantemente guiña su ojo izquierdo” —a lo que el entrevistado respondió: “Ah, esto...” mientras procedía a sacarse el ojo (de vidrio). Una vez que recuperó el aliento, el entrevistador anotó esta escena en la hoja de admisión.

Memoria: ¿Cómo se encuentra la memoria del paciente respecto a sucesos recientes y muy antiguos?

Sentidos: ¿Existe algún problema relacionado con los cinco sentidos?

Actividad psicomotora: ¿Parece haber cualquier retraso o aceleración anormales en la actividad motora? ¿Existe alguna disfunción orgánica o motora evidente?

Estado de conciencia: ¿La conciencia parece ser clara o el paciente se encuentra perplejo, confuso o aturdido?

Afecto: ¿Es apropiada la expresión emocional del paciente? Por ejemplo, ¿el paciente se ríe (de manera inapropiada) al hablar sobre la muerte de un miembro inmediato de la familia?

Estado de ánimo: A lo largo de la entrevista, ¿el paciente, en general, ha estado enojado? ¿Deprimido? ¿Ansioso? ¿Aprehensivo?

Personalidad: ¿Con qué términos se podría describir mejor al paciente? ¿Sensible? ¿Obstinado? ¿Aprehensivo?

Contenido del pensamiento: ¿El paciente está alucinando, viendo, oyendo o experimentando de alguna otra manera cosas que en realidad no existen?, ¿presenta delirios, expresa creencias falsas o infundadas (como el delirio de que alguien lo sigue a dondequiera que va)? ¿Aparenta ser obsesivo, parece tener los mismos pensamientos una y otra vez?

Procesos de pensamiento: ¿Existe una producción reducida o excesiva de ideas? ¿Parece que las ideas le llegan de manera anormalmente lenta o rápida? ¿Existe evidencia de debilitamiento en las asociaciones? ¿Las producciones verbales del paciente son erráticas o inconexas?

Recursos intelectuales: ¿Cuál es la inteligencia estimada del entrevistado?

Percepción: ¿El paciente aprecia de manera realista su situación y la necesidad de ayuda profesional en caso que esa ayuda sea necesaria?

Juicio: ¿Qué tan adecuada ha sido la toma de decisiones del paciente respecto a sucesos pasados y planes futuros?

El examen del estado mental comienza en el momento en que el entrevistado entra en la habitación. El examinador toma nota de la apariencia, la manera de caminar, etcétera, del examinado. La **orientación** se evalúa por medio de preguntas directas como, “¿Cuál es su nombre?”, “¿dónde se encuentra usted?” y “¿cuál es la fecha de hoy?”. Si el paciente realmente está orientado como persona y con respecto a lugar y tiempo, el evaluador puede anotar en el protocolo de evaluación “Orientado x 3” (léase “**orientado en tres aspectos**”).

Se harán diferentes tipos de preguntas en base a las preferencias individuales del examinador para evaluar distintas áreas en el escrutinio. Por ejemplo, para evaluar los recursos intelectuales, las preguntas pueden variar desde las de información general (como “¿Cuál es la capital de Nueva York?”), a cálculos de aritmética (como “¿Cuánto es 81 entre 9?”), hasta la interpretación de proverbios (como “¿Qué significa el dicho: Más vale pájaro en mano que ciento volando?”). La percepción puede evaluarse, por ejemplo, sencillamente preguntándole al entrevistado las razones por las que se le está entrevistando. El entrevistado que tiene poca o ninguna apreciación de las razones por las que se le entrevista indicará poca percepción. Sin embargo, una explicación alternativa podría ser que el entrevistado esté simulando sentirse enfermo.

Como resultado de un examen del estado mental, el clínico estará mejor capacitado para diagnosticar al entrevistado, si, en realidad, el propósito de la entrevista es el diagnóstico. El resultado de este tipo de examen podría ser, por ejemplo, tomar la decisión de hospitalizar o no o una solicitud para practicarle una evaluación psicológica o neurológica más profunda.

SÓLO PIENSE...

Un entrevistador clínico realiza un examen del estado mental y determina que el entrevistado se encuentra profundamente deprimido, posiblemente al grado de representar un peligro para sí mismo. ¿Cómo se podría validar esta impresión clínica?

Aspectos psicométricos de la entrevista

Por lo general, después de la entrevista, el entrevistador llega a ciertas conclusiones acerca del entrevistado. Esas conclusiones, como las calificaciones de la prueba, pueden ser evaluadas respecto a su confiabilidad y validez.

Si más de un entrevistador realiza una entrevista con el mismo individuo, la confiabilidad de intercalificadores de los datos de la entrevista puede ser representada por el grado de acuerdo entre las conclusiones de los diferentes entrevistadores. Un estudio exploró los diagnósticos de esquizofrenia por medio de dos tipos diferentes de entrevista, una estructurada y otra no estructurada. Tal vez de manera poco sorprendente, Lindstrom *et al.* (1994) encontraron que las entrevistas más estructuradas arrojaban una mayor confiabilidad intercalificadores, aun cuando el contenido de ambos tipos de entrevista era similar.

Consistente con los resultados de Lindstrom *et al.* (1994), la confiabilidad intercalificadores de los datos de la entrevista puede ser incrementada cuando diferentes entrevistadores abordan asuntos específicos de manera sistemática. La consideración sistemática y específica de diversos temas de la entrevista puede ser promovida de diversas maneras. Una de ellas implica hacer que los entrevistadores completen una escala para que califique al entrevistado según variables fijas al concluir la entrevista. En un estudio, varios psicólogos entrevistaron a los miembros de una familia con el propósito de diagnosticar depresión. El contenido mismo de las entrevistas se dejó a juicio de los entrevistadores, aunque todos completaron la misma escala de calificación al final de la entrevista. El completar la escala de calificación posterior a la entrevista mejoró la confiabilidad intercalificadores (Miller *et al.*, 1994).

En general, cuando se lleva a cabo una entrevista con propósitos de diagnóstico, es probable que aumenten la confiabilidad y validez de las conclusiones diagnósticas realizadas con base en los datos de la entrevista cuando los criterios de diagnóstico son claros y precisos. Los esfuerzos por aumentar la confiabilidad intercalificadores para propósitos de diagnóstico son evidentes en la tercera edición del *Manual diagnóstico y estadístico* (DSM-III), publicado en 1980. Aunque su predecesor, el DSM-II (1968), proporcionaba información descriptiva de los trastornos enumerados, dichas descripciones eran inconsistentes respecto a sus detalles específicos y en algunos casos podían ser bastante vagas. Por ejemplo, ésta es la descripción de personalidad paranoide del DSM-II.

Este patrón conductual se caracteriza por hipersensibilidad, rigidez, suspicacia injustificada, celos, envidia, engreimiento excesivo, y una tendencia a culpar a los demás y a atribuirles malas intenciones. Con frecuencia, estas características interfieren con la capacidad del paciente para sostener relaciones interpersonales satisfactorias. Por supuesto, la presencia de suspicacia en sí no justifica el diagnóstico, puesto que la suspicacia puede estar justificada en algunos casos (American Psychiatric Association, 1968, p. 42).

Una descripción como ésta podría ser útil para comunicar la naturaleza del trastorno, pero debido a su falta de especificidad y a lo amplio de su interpretación, es de un valor mínimo para propósitos de diagnóstico. En un esfuerzo por reforzar la confiabilidad y validez de los diagnósticos psiquiátricos, el DSM-III (American Psychiatric Association, 1980) proporcionó pautas específicas de diagnóstico que incluían un número mínimo y específico de síntomas que tenían que estar presentes para hacer el diagnóstico. Por ejemplo, los criterios de diagnóstico para el trastorno de personalidad paranoide, incluían ocho maneras en que se podría presentar la suspicacia, de las cuales al menos tres tenían que estar presentes para que el diagnóstico fuera hecho. Enumeraba cuatro formas en que se podía presentar la hipersensibilidad, dos de las cuales eran requeridas para realizar el diagnóstico. Enumeraba cuatro maneras en que se podía manifestar la restricción del afecto, dos de las cuales eran necesarias para que se hiciera el diagnóstico (American Psychiatric Association, 1980). Esta tendencia hacia una especificidad incrementada en las descripciones diagnósticas continuó con una revisión del DSM-III (publicada en 1987 y denominada DSM-III-R), así como en las revisiones más recientes, el DSM-IV (American Psychiatric Association, 1994) y en el DSM-IV-TR.

Evaluar la consistencia de las conclusiones obtenidas a partir de dos entrevistas separadas por un periodo determinado produce un coeficiente de confiabilidad que de manera conceptual

es equivalente al coeficiente de confiabilidad test-retest. Como ejemplo, considere un estudio de la confiabilidad de una entrevista semiestructurada para el diagnóstico de alcoholismo así como trastornos que de manera común son simultáneos (como dependencia a sustancias, abuso de sustancias, depresión y trastorno antisocial de la personalidad). Bucholz *et al.* (1994) encontraron que algunos trastornos (dependencia de sustancias y depresión) eran diagnosticados con mayor confiabilidad test-retest que otros trastornos (abuso de sustancias y trastorno de personalidad antisocial).

La validez de criterio de las conclusiones realizadas en base a las entrevistas preocupa a los psicómetras tanto como la validez de criterio de las conclusiones hechas en base a los datos arrojados por la prueba. El grado en que los hallazgos o conclusiones de un entrevistador concuerdan con otros resultados de pruebas u otro tipo de evidencia conductual afecta la validez relacionada con el criterio de las conclusiones. En este contexto, considere un estudio que compara la precisión de dos diferentes herramientas de evaluación para predecir las conductas de personas en libertad condicional: una prueba objetiva y una entrevista estructurada. Harris (1994) concluyó que la entrevista estructurada era más precisa en la predicción del criterio (conducta posterior de las personas en libertad condicional) que la prueba. En otro estudio, que tenía como criterio el reporte exacto sobre el uso de drogas del sujeto, también fueron confrontadas una prueba de papel y lápiz con una entrevista. La prueba escrita resultó tener mayor validez de criterio que la entrevista, quizá debido a que las personas pueden estar más dispuestas a admitir por escrito que utilizan drogas de manera ilegal que en una entrevista cara a cara (McElrath, 1994).

Una entrevista es una interacción dinámica entre dos o más personas. En ocasiones, podría parecer que las entrevistas adquieren una vida propia. En última instancia, la naturaleza y forma de cualquier entrevista está determinada por muchos factores, como

- la cuestión por la que se refiere a la entrevista
- el contexto y ambiente de la entrevista (clínica, prisión, oficina del profesional, etcétera)
- la naturaleza y calidad de la información de los antecedentes disponibles para el entrevistador
- límites de tiempo, si existen, así como otros factores limitantes
- la experiencia previa del entrevistador, si la tiene, con tipos similares de entrevista
- la motivación, disposición y capacidades del entrevistado
- la motivación, disposición y capacidades del entrevistador
- aspectos culturales de la entrevista

¿A qué nos referimos con este último punto? Siga leyendo.

Aspectos culturales de la entrevista

Cuando una entrevista se lleva a cabo como preparación para orientación psicológica o psicoterapia, puede ser útil explorar un número de asuntos relacionados con la cultura. ¿En qué medida el cliente se siente distinto a los demás y esto en qué grado es un problema? ¿Qué conflictos, si los hay, son evidentes respecto a la motivación para asimilarse, en contra de comprometerse con una cultura en particular? ¿Hasta qué grado el cliente se siente distinto como individuo en relación con el grupo cultural con el que más se identifica? ¿Qué papel, si alguno, representa el prejuicio o el racismo como obstáculo para la adaptación del cliente? ¿Qué papel, si alguno, representan los patrones dominantes de la cultura (como el atractivo físico) en la adaptación del cliente? ¿De qué manera los factores culturales han afectado los sentimientos de autoestima del cliente? ¿Qué posibilidades existen de pérdida cultural o de sentimientos de desarraigo y de pérdida de herencia nativa como función de los esfuerzos por asimilarse? También pueden ser adecuadas las preguntas respecto a la salud física, de manera especial si el cliente pertenece a un grupo cultural que

tiene una tendencia documentada a expresar la angustia emocional a través de síntomas físicos (Cheung y Lau, 1982; Kleinman y Lin, 1980).

El acrónimo **EDREPOHOG** (como una traducción y adaptación de las siglas en inglés ADRESSING) es fácil de recordar y puede ayudar al evaluador a memorizar las diversas fuentes de influencia cultural al evaluar a sus clientes. Como fue propuesto por Pamela Hays (Hays, 1996; Hays y LeVine, 2001), las letras de EDREPOHOG representan *edad*, *discapacidad*, *religión*, *etnia*, *posición social* (incluyendo variables como ingresos, ocupación y nivel académico), *orientación sexual*, *herencia nativa*, *origen nacional* y *género*. ¿De qué manera podría, por ejemplo, una discapacidad afectar la visión del mundo de una persona en un contexto particular? ¿Por qué podría una persona profundamente religiosa tener un fuerte sentimiento acerca de una cuestión en particular? Éstos son los tipos de preguntas que podrían surgir al considerar el acrónimo EDREPOHOG en la evaluación de los clientes.

Ya sea que se utilice una entrevista, una prueba o algún otro tipo de herramienta de evaluación con un evaluado de una cultura diferente, el evaluador necesita estar consciente de las respuestas ostensiblemente psicopatológicas que pueden ser bastante comunes dentro de una cultura en particular. Por ejemplo, las afirmaciones que indican la participación de espíritus pueden ser una costumbre legítima entre ciertos grupos de nativos estadounidenses deprimidos (Johnson y Johnson, 1965), así como en otros grupos étnicos (Matchett, 1972). Las conclusiones e hipótesis diagnósticas deberían intentar distinguir entre problemas psicológicos y conductuales fidedignos y conductas que pueden ser anormales para los estándares de la cultura dominante, pero que son habituales según los estándares de la cultura del evaluado. Para que tengan un valor óptimo, los informes de evaluación deben ir mucho más allá de las determinaciones diagnósticas. Los informes deberían proporcionar una narración altamente detallada del problema, así como qué tipos específicos de intervención son recomendados. A lo largo de la entrevista y, desde luego a lo largo de la evaluación completa, el profesional sirve a los mejores intereses del cliente con sensibilidad cultural. Discutamos aún más este punto importante antes de proseguir.

Evaluación psicológica culturalmente informada Podemos definir la **evaluación psicológica culturalmente informada** como un enfoque a la evaluación que es agudamente consciente y responsivo a las cuestiones de aculturación, valores, identidad, comprensión del universo, idioma y otras variables relacionadas con la cultura, y en cuanto al impacto que éstos pueden tener sobre el proceso de evaluación o la interpretación de los datos obtenidos. Ofrecemos esta definición no como la última palabra sobre el tema, sino como un primer paso diseñado para promover el diálogo constructivo y académico acerca de lo que realmente constituye una evaluación psicológica culturalmente sensible, y todo lo que ésta pueda ser.

Cuando se planea una evaluación en la que existen ciertas dudas acerca del impacto proyectado de la cultura, del idioma o de alguna variable relacionada con la validez de la evaluación, el evaluador culturalmente sensible puede hacer varias cosas. Una es leer con cuidado los datos de alguna historia clínica o de caso particular existente. Estos datos pueden proporcionar respuestas a preguntas esenciales respecto al nivel de aculturación del evaluado y de otros factores útiles para saber por adelantado de alguna evaluación formal. Los familiares, amigos, clérigos, profesionales y otros que conozcan al evaluado pueden proporcionar información valiosa acerca de las variables relacionadas con la cultura antes de la evaluación. En algunos casos, puede resultar útil incluir la ayuda de algún asesor cultural local como preparación para la evaluación. Aquí una nota administrativa: si alguno de estos informantes es utilizado, será necesario haber firmado los formatos de permiso que autoricen el intercambio de información relacionada con el evaluado.

También debemos señalar que los mismos expertos en evaluación pueden no estar de acuerdo en cuestiones clave de evaluación respecto a individuos que pertenezcan a grupos particulares. Considere por ejemplo, la opinión de dos expertos respecto a una prueba de personalidad ampliamente utilizada, el MMPI-2. En un artículo titulado “Evaluación culturalmente competente de poblaciones hispanas con el MMPI” (*Culturally Competent MMPI Assessment of Hispanic Populations*), Dana (1995, p. 309) advierte que “el MMPI-2 no es ni mejor ni peor que [su predecesor] el MMPI para hispanos”. Por el contrario, Velásquez *et al.* (1997, p. 111) escribieron, “*Los orientadores deberían aplicar siempre el MMPI-2 y no el MMPI a sus clientes chicanos*” (cursivas en el original). En base a su experiencia clínica, Velásquez *et al.* (1997) concluyeron que en comparación con el

MMPI, el MMPI-2 “reduce las probabilidades de la patologización exagerada de los chicanos” (p. 111).

Podríamos considerar que los desacuerdos objetivos como los antes citados son sólo la punta del iceberg cuando se trata de la posibilidad de desacuerdo acerca de lo que constituye una evaluación culturalmente competente. Pensamos que es mejor y más realista aspirar a la evaluación culturalmente informada o a una evaluación psicológica culturalmente sensible. Refiriéndonos de manera específica al desacuerdo citado con anterioridad, sería útil estar informado, o contar con cierta sensibilidad, acerca de la posibilidad de patologización exagerada de los resultados obtenidos en las pruebas aplicadas.

Antes de una evaluación formal, el evaluador puede considerar una entrevista de exploración con el evaluado en la cual se establecerá el rapport y se plantearán diversas cuestiones relacionadas con la cultura.

En el *Close-up* del capítulo 11 se enumeran algunas de las preguntas que se podrían plantear en una entrevista de este tipo. Durante la evaluación, el evaluador tiene en mente toda la información cultural que ha adquirido, incluyendo cualquier costumbre relacionada con el espacio personal, contacto visual y demás. Después de la evaluación, el evaluador culturalmente sensible podría reevaluar sus datos y conclusiones para detectar cualquier posible impacto adverso de los factores culturales. Así, por ejemplo, mentalizando las advertencias de Velásquez *et al.* (1997), un evaluador que haya aplicado a un cliente chicano el MMPI y no el MMPI-2 podría volver a revisar el protocolo y su interpretación tratando de identificar cualquier sobrepatologización posible.

Los traductores son utilizados con frecuencia en las salas de urgencias de clínicas, en casos de intervención en crisis y en otras situaciones similares. Cuando sean utilizados los servicios de un traductor, el entrevistador debe ser cauteloso no sólo de la traducción de las palabras del entrevistado, sino también de su intensidad (Draguns, 1984). Miembros de la familia del entrevistado son frecuentemente alistados para que sirvan como traductores, aunque esta práctica puede no ser deseable bajo ciertas circunstancias. Por ejemplo, dentro de ciertas culturas, el que una persona más joven traduzca las palabras de una persona mayor, en especial respecto a ciertos temas (como cuestiones sexuales), puede ser considerado muy incómodo, sino es que irrespetuoso (Ho, 1987). Los datos provenientes de la historia clínica y de la observación conductual se deben interpretar con sensibilidad hacia el significado de los datos históricos o conductuales en un contexto cultural (Longabaugh, 1980; Williams, 1986). Finalmente, un aspecto clave de la evaluación psicológica culturalmente informada implica el planteamiento de preguntas importantes relacionadas con la capacidad de generalización e idoneidad de las medidas de evaluación utilizadas.

Si acaso está reflexionando sobre la pregunta recién planteada en *Sólo piense...*, es probable que no esté solo. Con frecuencia, los estudiantes sienten curiosidad acerca de cómo se adquiere un enfoque culturalmente informado a la evaluación. Aunque no existen reglas estrictas, nuestra opinión personal es que cuando se enseña de manera formal, se hace en el contexto de un plan de estudios que cuenta con tres componentes principales: un principio en evaluación básica, un principio en cuestiones culturales de la evaluación, y capacitación supervisada así como adquisición de experiencia. En la tabla 13-1 se presenta un modelo más detallado de este enfoque. La información para este modelo se obtuvo a partir de la lectura de las descripciones de diversos planes de estudio de evaluación existentes como los describen Allen (2002), Hansen (2002), López (2002) y Dana *et al.* (2002), así como en los escritos de Sue y Sue (2003), entre otros.

Observe que en nuestro modelo, un subcomponente de los dos componentes —Bases sólidas en cuestiones culturales relacionadas con la evaluación, y Capacitación supervisada y experiencia— del plan de estudios es el Cambio de lentes culturales (Kleinman y Kleinman, 1991). Steven Regeser López, que enseña un curso esencial en evaluación culturalmente informada en la UCLA,

SÓLO PIENSE...

¿La competencia cultural es una meta realista posible de lograr? De ser así, ¿cuáles son los criterios para lograrla?, ¿un evaluador culturalmente competente es capaz de evaluar a personas de cualquier cultura o sólo de la cultura en la que él es “competente”? ¿usted se consideraría culturalmente competente para evaluar a alguien perteneciente a su misma cultura?

SÓLO PIENSE...

¿Cómo puede enseñarse la evaluación culturalmente informada?

Tabla 13-1
Un modelo para enseñar una evaluación psicológica culturalmente informada

I. Bases sólidas en principios generales de evaluación

Estadística básica	- Escalas de medición - Descripción de datos - La curva normal - Correlación - Calificaciones estándar - Muestreo
Psicometría básica	- Estandarización - Normas - Confiabilidad - Validez - Desarrollo de pruebas - Análisis de reactivos - Prejuicio/imparcialidad de la prueba - Interpretación - Cultura e inferencia
Historia de las pruebas y de la evaluación	- Sinopsis de la evolución de la tarea de la evaluación - Cuestiones de interés histórico para el público - Cuestiones de interés histórico para la profesión
Cuestiones ético/legales/ en evaluación	- Litigios que tienen un impacto sobre la evaluación - Legislación que tiene un impacto sobre la evaluación - Reglamentos administrativos que tienen un impacto sobre la evaluación - Cuestiones éticas prominentes, incluyendo los derechos de los examinados
Consideraciones culturales en la evaluación	- Cultura y normas de prueba - Nociones de pruebas y reactivos de prueba "culturalmente imparciales" y "libres de cultura" - Aculturación y evaluación - Cultura y diversas herramientas de evaluación - Cuestiones de pertenencia a un grupo y de interpretación de prueba - Idioma y evaluación - Evaluación psicológica culturalmente informada
Evaluación de capacidad, incluyendo pruebas de CI	- Definición de inteligencia - Teorías de la inteligencia - Cuestiones relacionadas con la naturaleza de la inteligencia - Cuestiones culturales en la evaluación de la capacidad
Evaluación de aprovechamiento y aptitudes	- Definición de aprovechamiento y de aptitudes - Medición del aprovechamiento y de las aptitudes
Evaluación de la personalidad	- Definición de personalidad - Teorías de la personalidad - Desarrollo de las pruebas de personalidad - Métodos objetivos - Métodos proyectivos - Métodos conductuales - Cuestiones culturales en la evaluación de la personalidad
Evaluación clínica y de orientación psicológica	- Sinopsis - Uso de las herramientas de evaluación en aplicaciones clínicas y de orientación psicológica - Aplicaciones especiales de mediciones clínicas - El reporte psicológico - Cuestiones culturales en evaluación e interpretación
Evaluación neuropsicológica	- Sinopsis - El sistema nervioso y la conducta - El examen neuropsicológico - Herramientas para la evaluación neuropsicológica

Tabla 13-1
(continuación)

La evaluación en ámbitos empresariales, organizacionales e industriales	Sinopsis Exploración, selección, clasificación y colocación Orientación profesional Productividad, motivación y actitudes Cultura organizacional Áreas relacionadas, como psicología del consumidor
Evaluación de personas discapacitadas	Sinopsis La evaluación y la ley Acomodación y evaluación Evaluación y discapacidades específicas La discapacidad como cuestión de diversidad

II. Bases sólidas en las cuestiones culturales relacionadas con la evaluación

Cuestiones de diversidad	Lecturas de la literatura pertinente como Castro (2003), Hall (1997), Illovsy (2003), Nilsson <i>et al.</i> (2003) y Taylor (2002) Discusión e interpretación de un papel por parte de los estudiantes Autoexamen por medio de una autobiografía cultural
Evaluación multicultural	Lecturas de la literatura pertinente como Hornby (2003), López (1989), Sue y Sue (2003) y Suzuki <i>et al.</i> (2000) Crítica de informes psicológicos disponibles, desde una perspectiva multicultural Comprensión de los beneficios y limitaciones de las pruebas específicas a la cultura Comprensión de la sensibilidad cultural a través de lecturas como Edwards y Kumru (1999), Hansen <i>et al.</i> (2000) y Lewis-Fernández y Díaz (2002) Cambio de lentes culturales
Evaluación de colaboración	Lecturas de la literatura pertinente como Chinman <i>et al.</i> (1999) y Fischer (1994)
Evaluación terapéutica	Lecturas de la literatura pertinente como Finn (1996), y Finn y Tonsager (2002)
Evaluación en la investigación	Lecturas de literatura pertinente como Okazaki y Sue (1995)
Uso de recursos comunitarios	Recurrir a conferencistas invitados para reforzar otros aprendizajes Asesores culturales como socios en la evaluación

III. Capacitación supervisada y experiencia

Antes de la evaluación	Consultar con un asesor cultural Comprensión de la pregunta de remisión Comprensión del evaluado respecto a la cultura, preferencias de idioma y otras consideraciones pertinentes Comprensión de las posibles parcialidades del clínico Valoración de las herramientas de evaluación respecto a la idoneidad de las normas existentes Obtención del consentimiento informado para la evaluación
Conducción de una evaluación	Comprensión de los aspectos culturales de la evaluación, incluyendo cuestiones potenciales tales como el espacio personal y el contacto visual Aplicación de un modelo de colaboración Establecimiento de armonía en formas culturalmente sensibles y adecuadas Monitoreo de la competencia multicultural personal
Interpretación de los datos	Cambio de lentes culturales Generación y prueba de hipótesis alternativas
Comunicación de los resultados	Observación de costumbres Comprensión del impacto de la cultura en el proceso de comunicar los resultados
Redacción del reporte	Redacción con sensibilidad cultural para evitar el alejamiento del evaluado o la perpetuación de prejuicios

ha explicado e ilustrado este término de manera memorable. En su curso, López (2002) utiliza sus experiencias de manejo en las carreteras públicas de México, la mayoría de las cuales sólo cuentan con dos carriles, uno en cada dirección. Con frecuencia, el tráfico se agolpa en uno de los carriles a causa de un vehículo que transita lentamente. Los conductores que desean rebasar a los vehículos que transitan lentamente pueden recibir la asistencia de los conductores que se encuentran adelante de ellos, quienes utilizan sus luces direccionales para indicar el momento en que es seguro rebasar. El parpadeo de la luz direccional derecha indica que *no* es seguro rebasar ya que se avecina tráfico o porque la visibilidad no es buena en el carril opuesto. El parpadeo de la luz direccional izquierda indica que se puede rebasar con seguridad. Los camiones grandes suelen tener impresas en la defensa trasera las palabras *sig* junto a la direccional izquierda o *alto* junto a la direccional derecha. Además de señalar a los otros conductores cuándo es seguro rebasar, las direccionales tienen el mismo significado que en Estados Unidos, como indicación de la intención de dar vuelta.

En un ejercicio en la clase que utiliza diapositivas de escenas en carretera así como acercamientos de luces direccionales, López pide a sus estudiantes que interpreten el significado del parpadeo de las luces direccionales en diversos escenarios viales: ¿Significan rebasar, no rebasar o dar vuelta? Los estudiantes rápidamente se percatan de que el significado del parpadeo de la luz direccional sólo puede ser interpretado de manera correcta a partir de las señales en un contexto específico. A continuación, López agrega a la lección:

Entonces, traduzco este ejemplo concreto en términos más conceptuales. Para discernir el significado adecuado, primero uno debe considerar ambos conjuntos de significados o aplicar ambos tipos de “lentes culturales”. Después, uno reúne la información para someter a prueba ambas ideas. Finalmente, uno pondera la evidencia disponible y aplica el significado que parezca ser más adecuado. Es importante señalar que cualquiera que sea la decisión que se tome, por lo general existe cierto grado de incertidumbre. Mediante la recopilación de evidencia para probar los dos significados posibles, el psicólogo intenta reducir la incertidumbre. Con una multiplicidad de evaluaciones en el tiempo, se puede obtener una mayor certeza (2002, pp. 232-233).

La idea de cambiar los lentes culturales está ligada de manera íntima al pensamiento crítico y a la prueba de la hipótesis establecida. Por ejemplo, los datos de la entrevista pueden sugerir que el cliente está padeciendo cierto tipo de psicopatología que implica pensamientos delirantes. Sin embargo, un cambio de lentes culturales le permite al clínico someter a prueba una hipótesis alternativa: que la conducta observada es específica de una cultura y que surge a partir de creencias familiares añejas. El proceso de la evaluación psicológica culturalmente informada demanda este cambio de lentes culturales para todo tipo de datos de evaluación, incluyendo, por ejemplo, los datos de la historia clínica.

Datos de la historia clínica

Los datos biográficos y otros relacionados con el evaluado pueden obtenerse entrevistando al evaluado, y/o con otros hechos significativos dentro de la vida del mismo o por medio de ambos. Las fuentes adicionales de datos para la historia del caso incluyen registros hospitalarios, registros escolares, registros militares, registros laborales y documentos relacionados. Todos estos datos se combinan en un esfuerzo por obtener una comprensión del evaluado, incluyendo percepciones acerca de los patrones de conducta observados.² Los datos provenientes de la historia clínica pueden ser invaluable para ayudar al terapeuta a desarrollar un contexto significativo dentro del cual pueda

2. Para un ejemplo del estudio de un caso de la literatura psicológica, el lector interesado se puede referir a “Obsesiones socialmente reforzadas: etiología de un trastorno en una científica cristiana” (*Socially Reinforced Obsessing: Etiology of a Disorder in a Christian Scientist*; Cohen y Smith, 1976), donde los autores sugieren que la exposición de una mujer a la ciencia cristiana la predispuso a un trastorno obsesivo. El artículo ocasionó cierta polémica y produjo un número de comentarios (por ejemplo, Coyne, 1976; Halleck, 1976; London, 1976; McLemore y Court, 1977), incluyendo uno de un representante de la Iglesia de la ciencia cristiana (Stokes, 1977), todos refutados por Cohen (1977, 1979, pp. 76-83).

interpretar datos provenientes de otras fuentes, como transcripciones de la entrevista e informes de pruebas psicológicas.

SÓLO PIENSE...

¿Cómo podría el contenido de la videoteca particular del entrevistado ser una fuente útil de información para armar la historia clínica?

Pruebas psicológicas

Es posible que los clínicos y orientadores tengan ocasión de utilizar muchas y diferentes pruebas en el curso de sus prácticas, y casi todas las pruebas que hemos descrito podrían ser utilizadas en la evaluación u orientación clínica. Algunas pruebas están diseñadas primordialmente para auxiliar a los clínicos en el diagnóstico. Una de estas pruebas es el Inventario multiaxial clínico de Millon-III (*Millon Clinical Multiaxial Inventory-III*, MCMI-III; Millon *et al.*, 1994), una prueba de verdadero/falso con 175 reactivos que arroja puntuaciones relacionadas con características perdurables de personalidad, así como con síntomas agudos. Como está implícito en el nombre multiaxial, esta prueba puede proporcionar información que ayude al clínico a hacer diagnósticos con el DSM, que también es multiaxial.

Además de las pruebas que son utilizadas para propósitos generales de diagnóstico, existen miles de pruebas que se enfocan en rasgos, estados, intereses, actitudes y variables relacionadas. La depresión es quizá el problema de salud mental más común y una causa de hospitalización psiquiátrica. Un diagnóstico de depresión es una cuestión seria, en tanto este padecimiento es un factor clave de riesgo para el suicidio. Dada la importancia crítica de la depresión, se han desarrollado muchos instrumentos para su medición y para proporcionar discernimientos respecto a ella.

Es posible que la prueba más utilizada para medir la gravedad de la depresión sea el Inventario de depresión de Beck-II (*Beck Depression Inventory-II*, BDI-II; Beck *et al.*, 1996). Ésta es una medida de autodescripción que consta de 21 reactivos, cada uno de los cuales sondea un síntoma o actitud específicos asociados con la depresión. En cada reactivo, el examinado encierra en un círculo una de cuatro afirmaciones que describa mejor sus sentimientos a lo largo de las dos últimas semanas. Las afirmaciones reflejan distintas intensidades de sentimiento y sus calificaciones se ponderan de acuerdo a ello. Beck *et al.* (1996) presentaron datos para documentar su aseveración de que en promedio, los pacientes con trastornos de estado de ánimo obtienen calificaciones mayores en el BDI-II que los pacientes con trastornos de ansiedad, de adaptación o de otro tipo. De manera adicional, presentaron datos para apoyar la afirmación de que, en promedio, los pacientes con trastornos depresivos más graves obtienen calificaciones más elevadas en el BDI-II que los pacientes con formas de depresión menos grave. Sin embargo, debido a que los reactivos son tan transparentes y a que los resultados de la prueba son fáciles de manipular por el examinado por regla, se recomienda que el BDI-II sea utilizado sólo con pacientes que no tienen motivaciones conocidas para aparentar estar sanos o enfermos. Además, debido a que el BDI-II no contiene escalas de validez, es probable que sea recomendable aplicarlo junto con otras pruebas que sí tengan escalas de validez, como el MMPI-2.

Ya sea que la evaluación se efectúe con propósitos generales u otros más específicos de diagnóstico, en general es una buena idea utilizar más de una herramienta de evaluación para satisfacer los objetivos. Con frecuencia, se administra más de una prueba al evaluado. La frase utilizada para describir al grupo de pruebas aplicadas es *batería de pruebas* o *batería psicométrica*.

SÓLO PIENSE...

¿Por qué es una buena idea de manera usual, no depender de una sola prueba para tomar algún tipo de decisión clínica o de orientación psicológica?

Batería de pruebas psicológicas

Si usted es un aficionado de la cocina, o si es fanático del *Chef de Hierro* en el canal del gourmet, entonces sabrá que en inglés la palabra inglesa *batter* (raíz de la palabra *battery*) se refiere a la mezcla de un líquido batido que característicamente contiene una cierta cantidad de ingredientes. En México, uno de los significados de la palabra *batería* se refiere al conjunto de utensilios de cocina que se utilizan para cocinar. Un significado un tanto similar en psicometría es la definición de

la palabra batería: una colección o agrupamiento de objetos parecidos que serán utilizados en conjunto. Cuando los evaluadores en psicología hablan de una **batería de pruebas**, se están refiriendo a un grupo de pruebas que se administran en conjunto para recabar información acerca de un individuo a partir de una variedad de instrumentos.

Una *batería de pruebas de personalidad* se refiere a un grupo de pruebas de personalidad. El término *batería de pruebas proyectivas* también se refiere a un grupo de pruebas de personalidad, aunque este término es más específico ya que de manera adicional nos dice que la batería se limita a técnicas proyectivas (como Rorschach, TAT y la de dibujar figuras). En el vocabulario especializado entre clínicos, si no se especifica el tipo de batería a la que se está haciendo referencia, o si el clínico se refiere a una batería de pruebas como **batería estándar**, generalmente se está hablando de un grupo de pruebas que incluye una prueba de inteligencia, al menos una prueba de personalidad y una prueba diseñada para detectar deficiencias neurológicas (que son analizadas en el siguiente capítulo).

Cada prueba dentro de la batería estándar proporciona al clínico información que va más allá del área específica que la prueba pretende detectar. Así, por ejemplo, una prueba de inteligencia puede producir no sólo información acerca de la inteligencia, sino también información acerca de la personalidad y del funcionamiento neurológico. De manera recíproca, pueden extraerse datos acerca de la inteligencia y del funcionamiento neurológico a partir de los datos obtenidos en una prueba de personalidad (y aquí nos referimos de manera específica a las pruebas proyectivas más que a los inventarios de personalidad). La insistencia en utilizar una batería de pruebas y no una sola prueba fue una de las muchas contribuciones del psicólogo David Rapaport en su ya clásica obra, *Evaluación psicológica diagnóstica* (Rapaport *et al.*, 1945-1946). En una época en que utilizar una batería de pruebas podía significar usar más de una prueba proyectiva, Rapaport argumentó que la evaluación sería incompleta si no hubiera “respuestas correctas o incorrectas” en al menos una de las pruebas aplicadas. Aquí, Rapaport se refería a la necesidad de incluir al menos una prueba de capacidad intelectual.

Aplicaciones especiales de mediciones clínicas

Las mediciones clínicas tienen aplicaciones en un amplio rango de escenarios: de las clínicas de rehabilitación para adictos a las drogas a los tribunales, de la investigación acerca de la relación entre la adaptación a la salud general, en el funcionamiento del sistema inmunológico y la longevidad. A continuación, proporcionamos una muestra de las aplicaciones especiales de las mediciones clínicas.

Evaluación de adicción y abuso de sustancias

La evaluación por adicción a las drogas, por abuso de alcohol y/o a otras sustancias se ha vuelto rutinaria en una variedad de escenarios. Ya sea que un individuo solicite servicios de psicoterapia como paciente externo, busque ser admitido para servicios como paciente interno o incluso que esté buscando un empleo, un prerrequisito puede ser someterse a un examen para detectar el uso de drogas. Este tipo de examen puede tomar diversas formas, desde pruebas físicas directas que implican el análisis de muestras de orina o sangre hasta procedimientos de laboratorio mucho más elaborados que implican el análisis de respuestas psicofisiológicas (Carter y Tiffany, 1999; Lang *et al.*, 1993; Sayette *et al.*, 2000).

La exploración de la historia personal con las drogas y el alcohol se puede lograr por medio de cuestionarios o de entrevistas cara a cara. Sin embargo, este tipo de procedimiento directo está altamente sujeto al manejo de la impresión y a todos los demás inconvenientes potenciales de un instrumento de auto descripción. Se han desarrollado varias pruebas y escalas para ayudar en la evaluación de abuso y adicción. Por ejemplo, el MMPI-2 contiene tres escalas que proporcionan información acerca de la posibilidad del abuso de sustancias. La más antigua de estas tres escalas es la Escala de alcoholismo, de MacAndrew (MacAndrew, 1965), que desde entonces se ha revisado y por lo general se conoce sencillamente como la **MAC-R**. Originalmente, esta escala fue construida para ayudar a diferenciar entre pacientes psiquiátricos alcohólicos y no alcohólicos.

Otro cierto número de pruebas se enfocan en diversos aspectos del abuso de drogas. La Escala de posibilidad de adicción (*Addiction Potential Scale*, APS; Weed *et al.*, 1992) contiene 39 reactivos que los abusadores de sustancias tendían a aprobar de manera diferente ya fueran pacientes psiquiátricos o muestras no clínicas. La Escala de reconocimiento de adicción (*Addiction Acknowledgment Scale*, AAS; Weed *et al.*, 1992) contiene 13 reactivos que indican un reconocimiento abierto y evidente del abuso de sustancias. Por tanto, la AAS es una escala con mucha mayor validez evidente para la evaluación del abuso de sustancias que la MAC-R o la APS. Esto se debe a que la ratificación de los reactivos transparentes de la AAS equivale a una admisión abierta de abuso de sustancias. Por contraste, la MAC-R y la APS “no miden el abuso de sustancias de manera directa, sino que miden rasgos de personalidad que con frecuencia conducen al abuso de sustancias” (Rouse *et al.*, 1999, p. 106).

El Índice de severidad de adicción (*Addiction Severity Index*, McDermott *et al.*, 1996; McLellan *et al.*, 1980) es una de las pruebas ampliamente utilizada en el campo del abuso de sustancias (Alterman *et al.*, 2000), con aplicaciones para evaluaciones de ingreso y seguimiento, así como para la identificación de subgrupos de pacientes en investigaciones. Los calificadores evalúan la gravedad de la adicción dentro de siete áreas problema: condición médica, funcionamiento laboral, uso de drogas, uso de alcohol, actividades ilícitas, relaciones familiares/sociales, y funcionamiento psiquiátrico. Los reactivos detectan los diversos problemas experimentados dentro de estas áreas en los últimos 30 días, así como problemas de la vida del sujeto. Se derivan los estimados de la gravedad de los problemas a partir de las calificaciones.

La conducta asociada con el abuso de sustancias o su posibilidad también ha sido explorada por medios análogos, como es la interpretación de un papel o rol playing. La Prueba de competencia situacional (*Situational Competency Test*, Chaney *et al.*, 1978), la Prueba de interpretar un papel específico al alcohol (*Alcohol Specific Role Play Test*, Abrams *et al.*, 1991), y la Prueba de respuesta al riesgo de la cocaína (*Cocaine Risk Response Test*, Carroll, 1998; Carroll *et al.*, 1999) son todas pruebas en audio cinta que contienen mediciones a través de la interpretación de un papel. En la última prueba mencionada, se pide a los evaluados que respondan de manera oral con una descripción de lo que harían bajo ciertas condiciones, condiciones que se sabe inducen al uso de cocaína en usuarios habituales de la misma. Un escenario tiene que ver con haber tenido una semana difícil, seguida por el deseo de cocaína como recompensa para uno mismo. Otro escenario sucede en una fiesta en que unas personas están utilizando cocaína en la habitación contigua. Se solicita a los evaluados que expliquen de manera franca y en detalle sus pensamientos y conductas en respuesta a estas y otras situaciones. Por supuesto, el valor de la información rememorada variará en función de muchos factores, entre ellos el propósito del evaluador y la franqueza con la que contesten los evaluados. Uno podría esperar que los evaluados sean honestos en sus respuestas si ellos mismos hubieran recurrido a un tratamiento para su adicción. Por otra parte, es posible que los evaluados sean menos que directos si, por ejemplo, hubiesen sido asignados por un tribunal por sospechas de violar su libertad condicional.

Los esfuerzos por reducir el abuso generalizado de sustancias han conducido a los investigadores a considerar la manera en que la cultura puede contribuir al problema y cómo las intervenciones culturalmente informadas pueden ser parte de la solución. Utilizando una amplia variedad de medidas, los investigadores han explorado el abuso de sustancias en el contexto de variables tales como identidad cultural y situación generacional (Ames y Stacy, 1998; Chappin y Brook, 2001; Duclos, 1999; Kail y DeLaRosa, 1998; Karlsen *et al.*, 1998; Lessinger, 1998; O'Hare y Van Tran, 1998; Pilgrim *et al.*, 1999), creencias religiosas (Corwyn y Benda, 2000; Klonoff y Landrine, 1999) y orientación sexual (Kippax *et al.*, 1998). La recuperación de la adicción a las drogas en sí ha sido conceptualizada como un proceso socialmente mediado de **reaculturación** que puede resultar en un nuevo sentido de identidad (Hurst, 1997).

Una importante preocupación ética al evaluar a las personas que abusan de sustancias, especialmente en los contextos de investigación, tiene que ver con obtener el consentimiento totalmente

SÓLO PIENSE...

En su opinión, ¿cuáles serían los rasgos de personalidad que “con frecuencia conducen al abuso de sustancias”?

SÓLO PIENSE...

¿Por qué es útil conceptualizar una recuperación en cuanto al abuso de sustancias en base a una reaculturación?

informado para la evaluación. McCrady y Bux (1999) señalaron que las personas que abusan de sustancias pueden estar drogadas o intoxicadas al momento de dar el consentimiento, por lo que su capacidad para prestar atención y para entender los requisitos de la investigación podría estar comprometida. Además, debido a que su hábito puede haberlos puesto en dificultades económicas, cualquier pago ofrecido a estas personas por participar en un estudio de investigación podría parecer coercitivo. Los procedimientos para maximizar la comprensión del consentimiento y para minimizar la apariencia de coerción son elementos necesarios en el proceso de consentimiento.

Evaluación psicológica forense

La palabra *forense* significa “perteneciente a o utilizada en procesos legales” y el término **evaluación psicológica forense** se puede definir en un sentido amplio como la teoría y aplicación de la evaluación y medición psicológicas en un contexto legal. Los psicólogos, psiquiatras y otros profesionales de la salud pueden ser requeridos en los tribunales, por el personal de corrección y libertad bajo palabra, abogados y otros involucrados en el sistema de justicia para que den sus opiniones expertas. Por ejemplo, respecto a los procedimientos penales, la opinión puede tener que ver con la capacidad de un individuo para enfrentar un juicio o su responsabilidad criminal (es decir, cordura) al momento de cometer un delito. Respecto a un procedimiento civil, la opinión puede estar relacionada con cuestiones tan diversas como el grado de tensión emocional sufrida en una demanda de daños personales, la idoneidad de uno u otro padre en un procedimiento para determinar una custodia, o la capacidad testamentaria (capacidad para hacer un testamento) de una persona antes de su muerte.

Antes de analizar algunos de los aspectos relacionados con la evaluación en algunas de las muchas áreas de la psicología forense, es importante señalar que existen diferencias importantes entre la práctica de la psicología forense y de la psicología clínica general. Tal vez, la diferencia más importante es que en la situación forense, el clínico puede ser el cliente de una tercera persona (como un tribunal) y no el evaluado. Este hecho, así como sus implicaciones respecto a asuntos como la confidencialidad, se deben aclarar al evaluado. Otra diferencia entre la práctica clínica forense y la general es que el paciente puede haber sido obligado a someterse a la evaluación. Por ejemplo, a diferencia del cliente característico que busca terapia, el evaluado en casos forenses, no está altamente motivado para ser veraz. Como resultado, es imperativo que el evaluador dependa no sólo de las representaciones del evaluado, sino también de toda la documentación disponible, como informes policíacos y entrevistas con personas que puedan tener información conducente. El profesional de la salud mental que desempeñe trabajo forense haría bien en educarse en el idioma de la ley:

Entrar a un tribunal y dar la opinión de que una persona no es responsable de un crimen debido a que es psicótica es no decir nada de valor para el juez y el jurado. Sin embargo, entrar al mismo tribunal y afirmar que un hombre no es responsable debido a que, como resultado de un trastorno mental, a saber, esquizofrenia paranoide, “carecía de la capacidad sustancial para conformar sus conductas a los requisitos de la ley” —porque escuchaba voces que le decían que debía cometer el crimen para proteger a su familia de un daño futuro— sería de gran valor para el juez o el jurado. No es debido a la psicosis que el hombre no es responsable; es la manera en que la enfermedad afectó su conducta y su capacidad para formar la intención criminal necesaria o para tener la *mens rea*, o mente culpable, lo que importa (Rappeport, 1982, p. 333).

En ocasiones, se coloca a los asesores forenses en el papel de psiquiatras, en especial en casos que implican cuestiones como capacidad para testificar. En estos casos, es posible que se le pida a los asesores que ofrezcan sus opiniones acerca de personas que nunca han entrevistado u observado de manera personal —una situación que surge rara vez, si en alguna, en las evaluaciones no forenses—. Con frecuencia, la evaluación forense impone dar opiniones acerca de cuestiones de gran importancia como si una persona es competente para enfrentar un juicio, penalmente responsable o lista para quedar en libertad bajo palabra. Algunas personas han objetado el papel de los profesionales de la salud mental en estas y otras cuestiones relacionadas, citando la falta de confiabilidad de los diagnósticos psiquiátricos y la invalidez de diversas herramientas de evaluación para ser utilizadas con estos objetivos (Faust y Ziskin, 1988a, 1988b; véase también

Matarazzo, 1990, para una respuesta). Aún así, jueces, jurados, fiscales de distrito, policías y otros miembros del sistema de justicia dependen de los profesionales de la salud mental para proporcionarles su mejor juicio en cuanto a estos temas esenciales. Una de las cuestiones que surge con frecuencia se refiere a la predicción de la peligrosidad (Lally, 2003).

Peligrosidad para uno mismo o para los demás La determinación oficial de que una persona es peligrosa para sí misma o para los demás es causa legal suficiente para privar a ese individuo de su libertad o de algunos privilegio. El individuo así considerado se someterá, de manera voluntaria o involuntaria, a una intervención psicoterapéutica, de manera representativa dentro de instalaciones de tratamiento seguras, hasta el momento en que se juzgue que ya no representa un peligro. Esto es así debido a que el estado tiene el deber coercitivo de proteger a sus ciudadanos del peligro. Este deber se extiende para proteger a los individuos suicidas (de quienes se supone sufren un trastorno mental) de actuar sobre sus impulsos autodestructivos. Los profesionales de la salud mental desempeñan un papel clave en las decisiones acerca de quién es considerado peligroso o no.

De manera ideal, la determinación de la peligrosidad se hace en base a múltiples fuentes de datos, incluyendo datos de entrevista, datos de la historia clínica o de desarrollo y de la evaluación formal. Cuando se está tratando con evaluados potencialmente homicidas o suicidas, el evaluador profesional debe tener conocimiento de los factores de riesgo asociados con esos actos violentos. Los factores de riesgo pueden incluir un historial de intentos previos para cometer el acto, abuso de drogas y/o alcohol y desempleo. Si se tiene una oportunidad de entrevistar al individuo potencialmente peligroso, el evaluador de manera singular, explorará la ideación, motivación y las fantasías que se asocien con la violencia considerada y por parte del evaluado. De manera adicional, surgirán preguntas relacionadas con la disponibilidad y letalidad del método y los medios mediante los cuales se realizaría el acto violento. El profesional evaluará qué tan específico y detallado es el plan, si es que existe. También es posible que el evaluador explore el grado en el que los recursos de ayuda tales como familia, amigos o compañeros de cuarto puedan prevenir que ocurra el acto violento. Si el evaluador determina que un homicidio es inminente, tiene el **deber legal de advertir** a la tercera persona en peligro, un deber que anula las comunicaciones privilegiadas entre psicólogo y cliente. Como se afirma en el histórico caso de *Tarasoff contra los Regentes de la Universidad de California* (Tarasoff v. Regents of the University of California) de 1974, “El privilegio amparado finaliza donde inicia el peligro público” (véase Cohen, 1979, para una ampliación de éste y otros principios relacionados).

La peligrosidad se manifiesta a sí misma de diversas maneras en una variedad de escenarios, desde el patio escolar hasta la recepción de la oficina de correos. Por medio del trabajo conjunto, los miembros de las comunidades legales y de la salud mental se empeñan por conservar a las personas relativamente seguras de sí mismas y de otros sin privar de manera indebida a cualquier ciudadano de su derecho a la libertad. Para ese fin ha surgido una amplia literatura que se ocupa de la evaluación de la peligrosidad, incluyendo el suicidio (véase, por ejemplo, Baumeister, 1990; Blumenthal y Kupfer, 1990; Catalano *et al.*, 1997; Copas y Tarling, 1986; Gardner *et al.*, 1996; Jobes *et al.*, 1997; Lewinsohn *et al.*, 1996; Lidz *et al.*, 1993; Monahan, 1981; Olweus, 1979; Rice y Harris, 1995; Steadman, 1983; van Praag *et al.*, 1990; Wagner, 1997; Webster *et al.*, 1994) a través de un número de pruebas (Beck *et al.*, 1989; Eyman y Eyman, 1990; Linehan *et al.*, 1983; Patterson *et al.*, 1983; ; Reynolds 1987; Rothberg y Geer-Williams, 1992; Williams *et al.*, 1996) y pautas de entrevista clínica (Sommers-Flanagan y Sommers-Flanagan, 1995; Truant *et al.*, 1991; Wollersheim, 1974).

A pesar de los esfuerzos de muchos académicos, en la actualidad la predicción de la peligrosidad se debe considerar más un arte que una ciencia. De manera histórica, los clínicos no han sido muy precisos en sus predicciones de peligrosidad. Pero el lado positivo es que muchas personas y organizaciones están trabajando para mejorar las probabilidades de predecir de manera exitosa la peligrosidad. Como se señala en el *Close-up* del presente capítulo, entre las organizaciones comprometidas en la aplicación de las ciencias de la conducta a las cuestiones de peligrosidad se encuentra el Servicio Secreto de Estados Unidos.

SÓLO PIENSE...

Durante el curso de una evaluación de orientación psicológica, el orientador se enteró de que un paciente infectado por VIH está planeando sostener relaciones sexuales sin protección con un tercero identificado. ¿Tiene el orientador el deber de advertir al tercero?

La evaluación de la peligrosidad y el Servicio Secreto

El Servicio Secreto de Estados Unidos tiene a su cargo, de acuerdo con la ley federal, cierto número de responsabilidades, incluyendo la investigación de los delitos de falsificación, adulteración y fraude que involucren computadoras e instituciones financieras. Quizá sea mejor conocido por sus funciones protectoras y su deber de resguardar a las siguientes personas y a sus familias: al Presidente de Estados Unidos, al vicepresidente, a presidentes y vicepresidentes anteriores, a los candidatos importantes o sucesores a estos puestos y a jefes de estado extranjeros que visitan al país.

Los organismos encargados del cumplimiento de la ley han hecho patente un gran interés en las formas en que las ciencias de la conducta y, de manera más específica, el conocimiento de la peligrosidad, pueden aplicarse en la prevención del delito. En Los Ángeles, donde el acecho a las celebridades se ha convertido en un problema ampliamente publicitado, el departamento de policía estableció una unidad de manejo de amenazas (Lane, 1992). Cuando algún miembro del Congreso o su personal reciben amenazas, el asunto puede remitirse a una unidad policíaca similar establecida por la Policía del Capitolio de Estados Unidos. De manera adicional, "el Servicio de Alguaciles de Estados Unidos ha iniciado esfuerzos sistemáticos por formular una función investigativa de protección para analizar comunicaciones inadecuadas para evaluar y manejar las amenazas potenciales en contra de los oficiales judiciales federales" (Coggins *et al.*, 1998, p. 53).

El Servicio Secreto ha sido persistente en sus esfuerzos por integrar la investigación conductual y la experiencia clínica en sus políticas y prácticas, incluyendo la evaluación de riesgo y actividades protectoras. En el curso de los intentos por prevenir que un delito altamente específico suceda, algunas de las cosas que debe hacer el Servicio son 1) identificar e investigar a personas que puedan representar un riesgo a un protegido; 2) determinar el nivel de riesgo que las personas identificadas representan; y 3) implementar un programa de manejo del caso para aquellos identificados como posibles representantes de un riesgo genuino. Para lograr éstos y otros objetivos relacionados con un máximo de efectividad, el Servicio estableció un programa de investigación conductual. La persona que encabeza dicho programa es Margaret Coggins, Ph.D., y mucho de lo que aquí decimos acerca del programa se deriva de la publicación de Coggins *et al.* (1998).

Encargados de los deberes que implican una evaluación muy especializada de la peligrosidad de manera regular, el Servicio Secreto tiene el historial de recibir la aportación de opiniones provenientes de profesionales y clínicos y forenses. En 1980, la agencia estableció un acuerdo con el Institute of Medicine (Instituto de Medicina) para patrocinar una conferencia de clínicos y científicos de la conducta que abordara temas como la predicción de la peligrosidad, el manejo de casos de personas peligrosas y las necesidades de capacitación de sus agentes (Takeuchi *et al.*, 1981). Otra conferencia en 1982, amplió la agenda a cuestiones tales como el desarrollo de un programa interno de investigación acerca de la evaluación de personas que amenazarán a los protegidos, la capacitación de agentes en la evaluación y cómo manejar a los amenazadores mentalmente enfermos (Institute of Medicine, 1984). El programa de investigación conductual del Servicio Secreto fue desarrollado a partir de estas conferencias. Ahora, el programa de investigación estudia asuntos diversos como cuestiones de evaluación de riesgos, factores en la toma de decisiones de los agentes, y actitudes de los profesionales de la salud mental hacia el Servicio Secreto en relación con su efecto de reportar las amenazas hechas a los protegidos por el Servicio. Para lograr los objetivos del programa, se formó una alianza entre investigadores y profesionales:

Los agentes especiales e investigadores, tanto los que pertenecen al personal interno del Servicio Secreto, como los asesores externos, trabajan en conjunto para identificar preguntas prácticas de estudio, priorizar áreas de averiguación, diseñar metodologías de estudio, recolectar y analizar datos, y diseminar los resultados de la investigación. Los agentes desempeñan un papel clave para garantizar que la pertinencia de la investigación, la evaluación de riesgos y las preocupaciones del manejo de casos estén por delante para su estudio, y su participación en el diseño de la investigación y en la recolección de datos otorga una credibilidad interna a la importancia de incorporar los hallazgos de estudio a la práctica. De manera semejante, el personal de investigación y los estudiosos de las comunidades académica y científica garantizan que los principios de integridad científica guíen el proceso de investigación y son instrumentos para proteger la validez externa de los datos y de los resultados de acuerdo a los

Competencia para ser sometido a juicio En un sentido legal, *competencia* tiene muchos significados diferentes. Por ejemplo, podemos hablar de competencia para hacer un testamento, para establecer un contrato, para cometer un delito, para renunciar a los derechos constitucionales, para consentir al tratamiento médico... la lista puede continuar. Antes de que el asesino convicto Gary Gilmore fuese ejecutado en Utah, se le sometió a un examen diseñado para determinar si era o no



El Servicio Secreto depende de la investigación sobre la evaluación de la peligrosidad para el cumplimiento de su misión protectora.

estándares rigurosos de la revisión de sus colegas. (Coggins *et al.*, 1998, p. 61)

El estudio del caso es una herramienta de evaluación e investigación potencialmente útil, en especial en los esfuerzos por identificar los factores relacionados con el potencial de violencia de un individuo contra un protegido del Servicio Secreto. El Proyecto de estudio de casos excepcionales (Exceptional Case Study Project, ECSP) del Servicio Secreto fue diseñado para estudiar personas ya sea que hayan atacado o se hayan acercado con medios letales o a un individuo elegido en base a su posición pública. Las variables seleccionadas para su estudio incluyen conducta, pensamiento, planeación, estado mental, motivación y patrones de comunicación. Un hallazgo notable de tal investigación podría ser parafraseado con el aforismo "las acciones hablan más fuerte que las palabras". Desde luego, la conducta anterior ha resultado tener precedencia sobre

las afirmaciones amenazantes como factor relacionado al potencial de violencia (Vossekuil y Fein, 1997). Este resultado es consistente con los hallazgos del psiquiatra Park Dietz en su investigación con sujetos que acechan a celebridades de Hollywood. Dietz *et al.* (1991) concluyeron que había poca relación entre escribir una carta amenazadora a una celebridad e intentar acercarse físicamente a dicha celebridad. Las personas que escribieron tales cartas no tenían ni más ni menos probabilidades de intentar acercarse a la celebridad que las personas que no hacen amenazas.

La ciencia conductual, y en especial la investigación relacionada con la evaluación, tiene mucho que ofrecer al Servicio Secreto y a otras organizaciones involucradas en el reforzamiento de la ley y la prevención del delito. Esto es así a pesar de que, para el Servicio Secreto, "las misiones operativas siempre tienen precedencia sobre el interés académico o científico" (Coggins *et al.*, 1998, p. 68).

competente para ser ejecutado. Esto se debió a que la ley ordena que exista cierta propiedad respecto a las ejecuciones ordenadas por el estado y porque moralmente no sería adecuado ejecutar a personas dementes.

La **competencia para ser sometido a juicio** en gran parte tiene que ver con la capacidad del acusado para comprender los cargos que se le imputan y para asistir o colaborar en su propia defensa. Como lo afirmó la resolución de la Suprema corte de Estados Unidos en *Dusky contra Estados Unidos*,

Tabla 13-2
Criterios de Georgetown respecto
a la competencia para ser sometido
a juicio

Reactivos objetivos

Capacidad del acusado para:

1. comprender su situación legal actual
2. comprender los cargos que se le imputan
3. comprender las cuestiones y procedimientos legales del caso
4. comprender las posibles disposiciones, declaraciones y penas
5. comprender los hechos relevantes al caso
6. identificar y localizar testigos

Reactivos inferenciales

Capacidad del acusado para comunicarse con su asesor legal y para:

7. comprender instrucciones y recomendaciones
8. tomar decisiones después de que se le aconseje
9. atender el testimonio para descubrir contradicciones o errores
10. mantener una relación de colaboración con su abogado(a)
11. testificar, de ser necesario, y ser interrogado por la parte contraria
12. tolerar la tensión durante el juicio o mientras espera el mismo
13. abstenerse de conductas irracionales durante el juicio

Fuente: Bukatman *et al.* (1971).

un acusado debe tener “suficiente capacidad presente para consultar con su abogado con un grado razonable de comprensión racional... (y) objetiva de los procedimientos en su contra”. Este requerimiento de “comprender y asistir”, como se le ha llegado a llamar, es, en efecto, una extensión de la prohibición constitucional en contra de los juicios *in absentia*; el acusado no sólo debe estar físicamente presente durante su juicio, también mentalmente presente.

El requerimiento de competencia protege el derecho de un individuo a elegir y ayudar en su asistencia legal, el derecho a actuar como testigo en beneficio propio, y a confrontar a los testigos de la parte contraria. El requerimiento también aumenta las probabilidades de que se descubra la verdad del caso, puesto que un acusado competente puede monitorear las declaraciones de los testigos en forma constante y ayudar en llamar la atención de la corte sobre las discrepancias en el testimonio. En general, son personas con discapacidad intelectual, psicosis o que sufren de un trastorno neurológico debilitante las que son consideradas incompetentes para ser sometidas a juicio. Sin embargo, no podemos hacer suficiente énfasis en que cualquiera de estos tres diagnósticos no es suficiente en sí para que se juzgue que una persona es incompetente. Dicho de otra manera: existe la posibilidad de que una persona padezca de discapacidad intelectual, psicosis o de un trastorno neurológico debilitante —o todo lo anterior— y que aún se juzgue competente para someterla a juicio. Se dictaminará que la persona es incompetente para someterla a juicio si y sólo si no puede comprender los cargos que se le imputan o no puede asistir en su propia defensa.

Se han desarrollado un cierto número de instrumentos para asistir en la evaluación para que un acusado satisfaga el requisito de comprender y asistir. Por ejemplo, investigadores de la Escuela de Leyes de la Universidad de Georgetown (Bukatman *et al.*, 1971) enumeraron 13 criterios de competencia para ser sometido a juicio (tabla 13-2). Una muestra de las preguntas que se utilizan en conjunto con estos criterios incluye las siguientes:

- ¿Cuál es el trabajo de su abogado?
- ¿Qué propósito tiene el juez?
- ¿Qué es lo que hace el jurado?
- ¿Qué hará el fiscal?
- ¿Con qué coartada o defensa cree usted contar en este momento?
- Para usted, ¿qué significa “incompetente para ser sometido a juicio”?
- ¿Cree usted que exista alguna razón para considerar que usted es incompetente?

Tabla 13-3
La prueba de detección de competencia

1. El abogado le dijo a Bill que _____.
2. Cuando yo vaya al tribunal, el abogado _____.
3. Jack sintió que el juez _____.
4. Cuando Phil fue acusado del delito, él _____.
5. Cuando me prepare para ir al tribunal con mi abogado, _____.
6. Si el jurado dictamina que soy culpable, _____.
7. La manera en que se decide un juicio es _____.
8. Cuando al jurado se le presentó la evidencia en el caso de George, _____.
9. Cuando el abogado interrogó a su cliente en el tribunal, el cliente dijo _____.
10. Si Jack tuviera que juzgar su propio caso, él _____.
11. Cada vez que el fiscal me hacía una pregunta, yo _____.
12. Mientras escuchaba a los testigos declarar en mi contra, yo _____.
13. Cuando el testigo que declaraba en contra de Harry dio una evidencia incorrecta, él _____.
14. Cuando Bob estuvo en desacuerdo con su abogado acerca de su defensa, él _____.
15. Cuando fui formalmente acusado del delito, pensé para mis adentros _____.
16. Si el abogado de Ed le sugiere que se declare culpable, él _____.
17. Lo que más preocupa a Fred de su abogado es _____.
18. Cuando dicen que un hombre es inocente hasta que se pruebe lo contrario, _____.
19. Cuando pienso en ser enviado a prisión, yo _____.
20. Cuando Phil piensa acerca de lo que lo acusan, él _____.
21. Cuando los miembros del jurado oigan mi caso, ellos _____.
22. Si tuviera la oportunidad de hablar con el juez, yo _____.

Fuente: Lipsitt *et al.* (1971)

De acuerdo con Bukatman *et al.*, una evaluación minuciosa de la competencia implicaría responder a preguntas “con información suficiente acerca de cada punto para indicar si existe, o si podría existir en lo futuro, un problema en esa área” (p. 1226).

Una medida alternativa de la competencia, la Prueba de detección de competencia (*Competency Screening Test*, Lipsitt *et al.*, 1971) utiliza un formato para completar oraciones (tabla 13-3) en la que cada uno de los 22 reactivos se relaciona con un criterio legal de competencia para ser sometido a juicio. La prueba se califica por medio de una escala de 3 puntos que varía de 0 a 2, donde las respuestas correctas se califican con 2, las respuestas marginalmente adecuadas se califican con 1 y las respuestas claramente inapropiadas se califican con 0. Por ejemplo, considere el siguiente reactivo: “Cuando vaya al tribunal, el abogado_____”. Una respuesta de dos puntos sería “me defenderá”. Esta respuesta indica que el evaluado tiene una clara comprensión del papel del abogado. Por contraste, una respuesta de 0 puntos podría ser “hará que me guillotinen”, lo cual indicaría que existe una percepción inadecuada del papel del abogado. Lipsitt *et al.*, informaron que la confiabilidad de intercalificadores entre evaluadores capacitados con esta prueba es de $r = .93$. También informaron que su prueba fue exitosa para discriminar entre hombres gravemente trastornados hospitalizados por el estado y grupos control integrados por estudiantes, adultos de la comunidad, miembros de clubes y pacientes hospitalizados en forma particular comprometidos civilmente.

Responsabilidad criminal “Inocente por razón de demencia” es la excusa a un cargo criminal que todos hemos oído. Pero deténgase a pensar en el significado que tiene el término legal de **demencia** para los profesionales de la salud mental y en los procesos de evaluación por medio de los cuales los evaluadores psicológicos podrían identificar a una persona demente. La defensa por demencia tiene sus raíces en la idea de que sólo se debería castigar a las personas culpables (es decir, aquellas con mente criminal). Por tanto, quienes pueden estar libres de culpa son los niños, incompetentes mentales; otros que pueden ser irresponsables son los que carecen de control sobre sus acciones o que no tienen idea alguna de que lo que hacen puede ser criminal. Ya desde el siglo dieciséis, en la corte inglesa se argumentaba que un acto ofensivo no debería ser considerado un delito grave si el infractor no tenía un concepto del bien y el mal. Para el

siglo dieciocho, el enfoque se había desplazado del bien y el mal como un criterio para evaluar la responsabilidad penal a la cuestión de si el acusado “no sabe más que... una bestia salvaje lo que está haciendo”.

En la Inglaterra del siglo diecinueve se hizo historia jurídica cuando, en 1843, se encontró que Daniel M’Naghten era inocente por razón de demencia después de intentar asesinar al primer ministro británico. (Por equivocación le disparó y asesinó al secretario del primer ministro). Pero M’Naghten fue absuelto. De acuerdo con la corte, no se le podía responsabilizar del delito si, “al momento de cometer el acto, la parte acusada obraba bajo tal defecto de la razón a causa de una enfermedad de la mente que no pudiera entender la naturaleza y calidad del acto que cometía o, de lograr entenderla, no sabía que lo que hacía estaba mal”.

La decisión en el caso M’Naghten ha llegado a ser conocida como la *prueba de bien o mal*, o como el **estándar M’Naghten**. Hasta el presente, esta prueba de cordura es la que se utiliza en Inglaterra así como en un número de jurisdicciones de Estados Unidos. Sin embargo, un problema con la prueba de bien o mal es que no proporciona ninguna disposición en el caso de la absolución de personas que conocen el bien y el mal, no obstante no son capaces de controlar sus impulsos para cometer actos criminales. En 1954, una opinión redactada por el Tribunal de Apelaciones del Distrito de Columbia en el caso de *Durham contra Estados Unidos* sostuvo que el acusado no podía ser responsabilizado de un acto criminal “si el acto delictivo era el producto de una enfermedad o defecto mental” (el **estándar Durham**). Sin embargo, otro estándar más de demencia legal fue establecido en 1956 por el Instituto de Leyes de Estados Unidos (American Law Institute, ALI). El **estándar ALI** se ha vuelto uno de los más ampliamente utilizados a lo largo de Estados Unidos (Weiner, 1980). Con ligeras variaciones de una jurisdicción a otra, esta prueba legal de cordura sostiene lo siguiente:

Una persona no es responsable de un acto delictivo, es decir, demente, si al momento de ese comportamiento, como resultado de una enfermedad o defecto mental, carece de la capacidad sustancial ya sea para apreciar la criminalidad (ilegalidad) de su conducta o para conformar su conducta a los requerimientos de la ley.

Como se utilizan en este artículo, los términos “enfermedad o defecto mental” no incluyen una anormalidad manifestada sólo por la repetida conducta criminal o de otra manera antisocial.

En la práctica clínica, es probable que los acusados mentalmente discapacitados, psicóticos o que sufren un deterioro neurológico sean a los que se juzgue como inocentes por razón de demencia. Sin embargo, como fue en el caso en las consideraciones acerca de la competencia para ser sometido a juicio, el mero hecho de que se juzgue que una persona sufre de discapacidad intelectual, psicosis o deterioro neurológico no es garantía en sí de que el individuo sea declarado no culpable. Se deben satisfacer otros criterios, tales como el estándar ALI.

Para ayudar a determinar si se están satisfaciendo los estándares ALI, se han desarrollado instrumentos como la Escala de evaluación de responsabilidad criminal de Rogers (Roger Criminal Responsibility Assessment Scale, RCRAS). El psicólogo Richard Rogers y sus colegas (Rogers y Cavanaugh, 1980, 1981; Rogers *et al.*, 1981) diseñaron la RCRAS como un enfoque sistemático y empírico a las evaluaciones de demencia. Este instrumento consta de 25 reactivos que sondean variables tanto psicológicas como situacionales. Los reactivos son calificados de acuerdo con cinco escalas: confiabilidad (que incluye simulación), factores orgánicos, psicopatología, control cognoscitivo y control conductual. Después de calificar la prueba, el evaluador emplea un modelo jerárquico de decisiones para llegar a una

determinación respecto a la cordura del evaluado. Los estudios de validez que se han efectuado con esta escala (por ejemplo, Rogers *et al.*, 1983; Rogers *et al.*, 1984) han mostrado que es útil para discriminar entre pacientes/acusados cuerdos y dementes.

SÓLO PIENSE...

¿Deberían los profesionales de la salud mental involucrarse en la tarea de determinar quién no es culpable por razón de demencia?

Preparación para la libertad bajo palabra o condicional Algunas personas que han sido convictas por un delito pagarán sus deudas a la sociedad y procederán a tener vidas satisfactorias y productivas después de su encarcelamiento. En el extremo opuesto se encuentran los criminales de carrera que violarán la ley a la primera oportunidad una vez que hayan sido liberados —o esca-

pado— de la prisión. Predecir quién está listo para la libertad bajo palabra o condicional y cuál podría ser el resultado de dicha liberación ha probado ser una tarea más que difícil. No obstante, se han hecho intentos por desarrollar medidas que sean útiles en la toma de decisiones para otorgar la libertad bajo palabra o condicional.

Una persona con un diagnóstico de psicopatía (un **psicópata**) tiene cuatro veces más probabilidades de reincidir después de su liberación que alguien que no lo es (Hart *et al.*, 1988). Una obra clásica de Cleckley (1976) proporcionó un detallado perfil de los psicópatas. Son personas con pocas inhibiciones que pueden buscar placer o dinero con una falta absoluta de consideración por el bienestar de los demás. Basado en un estudio del análisis factorial de la descripción de personas con psicopatía elaborada por Cleckley, Robert D. Hare (1980) desarrolló la Lista de verificación de psicopatía (*Psychopathy Checklist*, PCL) con 22 reactivos que reflejan características de personalidad según las estima el evaluador (como insensibilidad, impulsividad y empatía), así como los antecedentes obtenidos de los registros que se tienen del evaluado (tales como “versatilidad delictiva”). En la versión revisada de la prueba, la Lista de verificación de psicopatía revisada (*Revised Psychopathy Checklist PCL-R*; Hare, 1985), se omitieron dos reactivos de la PCL original a causa de su relativamente baja correlación con el resto de la escala y se modificaron los criterios de calificación para algunos de los reactivos restantes. Hare *et al.* (1990) reportan que ambas formas son equivalentes.

En un estudio que empleó una muestra psiquiátrica de máxima seguridad, el PCL identificó de manera correcta un 80% de los reincidentes violentos (Harris *et al.*, 1989). Una versión de la PCL especialmente modificada para usarse con jóvenes infractores masculinos produjo calificaciones que se correlacionaron de manera significativa con variables como el número de síntomas de trastornos de la conducta, delitos violentos anteriores, reincidencia violenta y conducta violenta dentro de la institución de máxima seguridad en que se llevó a cabo el estudio (Forth *et al.*, 1990). En otro estudio, se encontró que las calificaciones de psicopatía predecían resultados tanto para ausencia temporal como para libertad bajo palabra. Los psicópatas fueron reencarcelados cuatro veces más frecuentemente que los no psicópatas (Serin *et al.*, 1990).

Diagnóstico y evaluación del daño emocional El **daño emocional** o el agravio o perjuicio psicológico, es un término que en ocasiones se utiliza como sinónimo de sufrimiento mental, dolor, sufrimiento y perjuicio emocional. En casos que involucran acusaciones tales como discriminación, acoso, negligencia médica, acecho y despido no justificado, los evaluadores psicológicos pueden ser responsables de evaluar un presunto daño emocional. Tal evaluación tendrá la intención de poner en claro el funcionamiento del individuo antes y después del supuesto daño (Melton *et al.*, 1997). El tribunal evaluará los resultados a la luz de toda la evidencia y tomará una determinación respecto a si existe el presunto daño y, si es el caso, la magnitud del mismo.

Se pueden utilizar diversas herramientas de evaluación, incluyendo la entrevista, la historia clínica y las pruebas psicológicas durante el proceso de evaluación y diagnóstico de las afirmaciones de daño emocional. Las entrevistas pueden llevarse a cabo con la persona que declara el daño, así como con otros que tengan conocimientos relevantes a la declaración. Los materiales para la historia clínica incluyen documentos tales como registros médicos o terapéuticos, registros escolares, militares, laborales e informes policíacos. Las pruebas psicológicas utilizadas en una evaluación de daño emocional variarán de acuerdo a las preferencias del evaluador. En un estudio en el que 140 psicólogos forenses respondieron a una encuesta relacionada con sus hábitos de evaluación, se encontró que ningún par de profesionales utilizaba exactamente la misma combinación de pruebas de manera rutinaria para la evaluación de daño emocional (Boccaccini y Brodsky, 1999). Las razones que se dieron para el uso específico de pruebas y baterías de pruebas con frecuencia se relacionaban con las normas establecidas, experiencia clínica personal, amplitud de aceptación del instrumento, apoyo de investigación y contenido. Sería deseable que existiera una mayor consistencia en la selección de pruebas. Tal consistencia se lograría mediante el estudio del incremento de validez que cada prueba añade a la tarea de evaluar los diferentes tipos de daño emocional en contextos específicos.

SÓLO PIENSE...

¿Por qué sería deseable una mayor consistencia en los instrumentos utilizados para evaluar el daño emocional?

Evaluaciones de la custodia

A medida que sigue aumentando el número de divorcios, así también aumenta el número de procesos legales por la custodia del o de los hijos. Antes de la década de 1920, era bastante común que al padre se le otorgara la custodia de los hijos (Lamb, 1981). Sin embargo, esta situación se revirtió con la amplia adopción de lo que se denominó la doctrina de los “años tiernos” y de la creencia de que los intereses del niño serían atendidos de mejor forma si se le otorgaba la custodia a la madre. Pero con la llegada de la edad del hogar de doble turno, los tribunales han comenzado a mostrarse más equitativos en sus decisiones para otorgar la custodia (McClure-Butterfield, 1990). Las cortes han reconocido que los mejores intereses del niño pueden ser atendidos al otorgar la custodia al padre, a la madre o a ambos de manera conjunta. Los evaluadores psicológicos pueden ayudar al tribunal en su toma de decisiones mediante el uso de la **evaluación de la custodia**, una evaluación psicológica de los padres o tutores y sobre su capacidad paternal, y/o de los niños, de sus necesidades y preferencias hacia los padres; dichas evaluaciones por lo general son efectuadas para ayudar a los jueces a otorgar la custodia por medio de los reportes. De manera ideal, un experto imparcial en el campo de la salud mental es quien debería ser el responsable de evaluar a *todos* los miembros de la familia y de entregar su reporte a los tribunales (Gardner, 1982). Sin embargo, la mayoría de las veces, el marido tiene a su experto y la esposa tiene al suyo, con lo que se inicia una batalla que con frecuencia es muy amarga (Benjamin y Gollan, 2003).

Evaluación del progenitor De manera característica, la evaluación de la capacidad paternal implica una entrevista detallada que se enfoca de manera primordial en los diversos aspectos de la crianza infantil aunque es posible que se empleen pruebas de inteligencia, personalidad y adaptación si persisten las dudas después de la entrevista. Es posible que el evaluador inicie con preguntas abiertas diseñadas para dejar que el progenitor ventile algunos de sus sentimientos y que después proceda con preguntas más específicas que exploren una amplia variedad de áreas, que incluyen

- la propia infancia del progenitor: ¿feliz?, ¿de abuso?
- la propia relación del progenitor con sus padres, hermanos, hermanas y pares
- las circunstancias que condujeron al matrimonio y el grado de planeación que hubo para tomar la decisión de tener (o adoptar) hijos
- la idoneidad del cuidado prenatal y actitudes hacia el embarazo
- la descripción de los padres hecha por el niño
- la evaluación propia de los progenitores sobre ellos mismos como padre o madre, respecto a fortalezas y debilidades
- evaluación de cada progenitor acerca de su cónyuge respecto a fortalezas y debilidades como padre o madre
- la cantidad y calidad del tiempo que se pasa cuidando o jugando con los hijos
- el enfoque del progenitor respecto a la disciplina
- la receptividad de los progenitores a las relaciones que el niño tiene con sus compañeros

Durante el curso de la entrevista, es posible que el evaluador encuentre evidencia de que en realidad el entrevistado no desea la custodia del niño, pero ha entablado la batalla legal por alguna otra razón. Por ejemplo, la custodia puede ser nada más que otra cuestión mediante la cual establecer un convenio para el divorcio. De manera alternativa, por ejemplo, existe la posibilidad de que el progenitor esté avergonzado de admitir ante sí mismo y los demás observadores del proceso que en realidad no quiere tener la custodia de los hijos. En ocasiones, un progenitor emocionalmente lastimado por todo lo sucedido antes del divorcio puede estar utilizando la batalla por la custodia como una forma de venganza, amenazando con llevarse lo que su cónyuge más



Figura 13-1
Técnicas proyectivas utilizadas en evaluaciones de la custodia

La imagen de la izquierda es de la Prueba H de apercepción infantil (Children's Apperception Test–H; Bellak y Bellak, 1965) y la de la derecha es del Libro Sobre el Divorcio, para Niños y Niñas (The Boys and Girls Book About Divorce; Gardner, 1971). Éstas, así como del TAT y otras imágenes que se utilizan como estímulos proyectivos, pueden ser de utilidad al evaluar las preferencias paternas de los niños.

quiere y adora. El clínico que se encarga de esta evaluación debe apreciar que bajo este tipo de motivaciones mal intencionadas sí pueden subyacer algunas batallas por la patria potestad. En el mejor interés de los niños, es obligación del clínico reportar estos hallazgos.

En ciertos casos, existe la posibilidad de que el evaluador considere que sea deseable evaluar alguna de las muchas variables relacionadas con la vida matrimonial y familiar. Para este fin hay disponible una amplia variedad de instrumentos, incluyendo aquellos diseñados para medir la adaptación (Beier y Sternberg, 1977; Epstein *et al.*, 1983; Locke y Wallace, 1959; McCubbin *et al.*, 1985a, 1985b; Spanier, 1976; Spanier y Filsinger, 1983; Udry, 1981), las cualidades (Olson *et al.*, 1985), preferencias (Price *et al.*, 1982), manejo de la intimidad (Waring y Reddon, 1983), los celos (Bringle *et al.*, 1979); la comunicación (Bienvenu, 1978); los sentimientos (Lowman, 1980), la satisfacción (Roach *et al.*, 1981; Snyder, 1981), la estabilidad (Booth y Edwards, 1983), la confianza (Larzelere y Huston, 1980), las expectativas (Notarius y Vanzetti, 1983; Sabatelli, 1984), las capacidades paternas (Bavolek, 1984), el enfrentamiento como manejo del enojo (McCubbin *et al.*, 1985a, 1985b; Straus, 1979), fortaleza de los lazos familiares (Bardis, 1975), ambiente interpersonal familiar (Kinston *et al.*, 1985; Moos y Moos, 1981; Robin *et al.*, 1990), actitudes de los niños hacia los padres (Hudson, 1982) y calidad general de la vida familiar (Beavers, 1985; Olson y Barnes, 1985).

Evaluación del niño El tribunal estará interesado en saber si el niño en un proceso de custodia tiene alguna preferencia respecto a su vida futura y los arreglos de las visitas. Para ese fin, el evaluador psicológico puede ser de ayuda mediante una amplia variedad de pruebas y técnicas. La mayoría de las autoridades concuerdan en que las preferencias de los niños menores de cinco años de edad son demasiado poco confiables y que están demasiado influidas por las experiencias recientes como para darles mucho peso. Sin embargo, si los datos de una prueba de inteligencia indican que un niño que cuenta con una edad cronológica de cinco años se encuentra funcionando a un nivel superior, entonces es posible que se le dé una mayor importancia a sus preferencias. Esto es especialmente cierto si la calificación en la subprueba de Comprensión de alguna de las escalas de Wechsler se encuentra elevada. Algunos métodos que pueden ser de utilidad para evaluar la preferencia paternal de un niño incluyen ejercicios de juego estructurado con muñecos que representan al niño y a otros miembros de la familia, dibujos de figuras de los miembros de la familia seguidos de narración de historias, y el uso de técnicas proyectivas tales como el TAT y otras pruebas relacionadas (figura 13-1).

En ocasiones, es posible que se requiera de alguna innovación improvisada por parte del examinador. Al realizar la evaluación de la custodia con un niño de 5 años de edad, el autor principal del presente texto (RJC) observó que un niño parecía identificarse de manera profunda con el personaje principal de la película *E. T., el extraterrestre*. El niño había visto la cinta tres veces, llegó a la prueba trayendo consigo dos tarjetas de E.T. obtenidas de una goma de mascar, e identificó como “E. T.” a la figura que dibujó cuando se le indicó que realizara el dibujo de una persona. Para obtener una medida de su preferencia paternal, el examinador tomó cuatro figuras y las representó como “E. T.”, la “mamá de E. T.”, el “papá de E. T.” y la “hermana de E. T.” Después, a una caja de cartón vacía la etiquetó como “la nave espacial” y le dijo al niño que E. T. (abandonado en el planeta Tierra y añorando regresar a su planeta de origen) tenía la oportunidad de regresar, pero que la nave espacial sólo tenía espacio suficiente para dos pasajeros adicionales. El niño hizo que abordaran la mamá y la hermana además de “E. T.” El niño le dijo al examinador que el papá de E. T. se “despediría de ellos agitando la mano”.

Los reactivos de completar oraciones contruidos de manera especial también pueden ser de utilidad en la evaluación de preferencias paternas. Por ejemplo, los siguientes reactivos podrían ser de valor para examinar las distintas percepciones que el niño tiene de cada progenitor:

- Las mamás _____ .
- Si hago algo equivocado, mi papá _____ .
- Lo mejor para los niños es que vivan con _____ .
- Los papás _____ .
- Las mamás se portan mal cuando _____ .
- Me gusta abrazar a _____ .
- No me gusta abrazar a _____ .
- Los papás se portan mal cuando _____ .
- La última vez que lloré _____ .
- Mis amigos creen que mi mamá _____ .
- Mis amigos creen que mi papá _____ .

El proceso de recolección de datos para una evaluación se inicia en el momento en que el niño y su(s) progenitor(es) entran en la habitación. El evaluador cuidadosamente toma nota de la calidad de la interacción entre el (los) progenitor(es) y el niño. Entonces, se entrevista sólo al niño y se le pregunta acerca de la naturaleza y calidad de la relación. Si el niño expresa una fuerte preferencia por alguno de los padres, el evaluador debe valorar qué tan significativa es dicha preferencia. Por ejemplo, un niño que ve a su padre, un ganadero, sólo cada dos fines de semana, posiblemente se la pase de lo mejor en las breves ocasiones en que están juntos y exprese una preferencia por vivir ahí, sin darse cuenta de que la vida en el campo pronto se volvería tan rutinaria como la vida con mamá en la ciudad. Si los niños no expresan una preferencia, se pueden discernir sus sentimientos por medio del uso

SÓLO PIENSE...

¿Cómo se podrían utilizar los títeres como herramienta de evaluación con niños muy pequeños implicados en una disputa de custodia?

de las pruebas ya descritas, en combinación con una entrevista habilidosa. Incluidos entre los temas a discusión estará la descripción física que el niño haga de sus padres, así como del lugar en que vive. Se les plantearán preguntas acerca de los aspectos rutinarios de la vida (tales como “¿Quién te prepara el desayuno?”), preguntas acerca de esparcimiento, visitas paternas, la implicación de los padres con su educación, su bienestar general y sus hermanos y amigos.

Abuso y descuido infantil

En casi todos los estados de Estados Unidos existe un mandato legal para muchos profesionales con licencia de informar sobre el *abuso infantil* y el *descuido infantil* cuando tienen conocimiento de

ello. Las definiciones legales de abuso infantil y descuido infantil varían en cada estado. De manera característica, las definiciones de **abuso** se refieren a la creación de condiciones que puedan dar lugar al abuso de un niño (una persona, definida por el estado, debajo de la mayoría de edad). El abuso se puede presentar en la forma de 1) ocasionar o permitir que se ocasione un daño físico o menoscabo emocional que no sea accidental, 2) crear o permitir que se genere un riesgo sustancial de daño físico o menoscabo emocional que no sea accidental, o 3) cometer o permitir que se cometa un delito sexual en contra de un niño. Las definiciones típicas de **descuido** se refieren al fracaso del adulto responsable del cuidado del niño en ejercitar un grado mínimo de atención en el suministro de alimento, vestido, vivienda, educación, atención médica y supervisión para el niño.

En la actualidad, están disponibles varias fuentes generales excelentes para el estudio del abuso y descuido infantil (véase, por ejemplo, Board of Professional Affairs, 1999; Cicchetti y Carlson, 1989; Ellerstein, 1981, Fischer, 1999; Fontana *et al.*, 1963; Helfer y Kempe, 1988; Kelley, 1988; Reece y Groden, 1985). También hay recursos disponibles para ayudar a los profesionales a reconocer formas específicas de abuso infantil como lesiones de la cabeza (Billmire y Myers, 1985), lesiones oculares (Gammon, 1981), lesiones en la boca (Becker *et al.*, 1978), trauma emocional (Brassard *et al.*, 1986), quemaduras (Alexander *et al.*, 1987; Lung *et al.*, 1977), mordeduras (American Board of Forensic Odontology, 1986), fracturas (Worlock *et al.*, 1986), envenenamiento (Kresel y Lovejoy, 1981), abuso sexual (Adams-Tucker, 1982; Faller, 1988; Friedrich *et al.*, 1986; Sanfilippo *et al.*, 1986; Sebold, 1987) y síndrome del niño golpeado (Dykes, 1986). A continuación se proporcionan algunas breves y muy generales pautas para la evaluación de señales de abuso infantil físico y emocional.

Señales físicas de abuso y descuido Aunque los psicólogos y otros profesionales de la salud mental sin acreditación médica no tienen oportunidad de llevar a cabo un examen físico que de manera inconfundible los lleve a un diagnóstico, es importante tener conocimiento de las señales físicas de abuso y descuido.

Muchas de las señales físicas de abuso toman la forma de lesiones físicas. Durante una evaluación, es posible que el niño abusado o los progenitores abusadores describan las lesiones como resultado de un accidente. El profesional experto necesita estar bien familiarizado con los diversos tipos de lesión que puedan indicar causas más ominosas. Por ejemplo, considere el caso de las lesiones en la cara. En la mayoría de los accidentes auténticos, sólo se lastima un lado de la cara. Por tanto, podría ser significativo que el niño presente lesiones en ambos lados de la cara, ambos ojos y ambas mejillas. Las marcas en la piel pueden decir mucho. Las marcas que deja una mano adulta al asir al niño y las marcas que forman un patrón reconocible (como las puntas de un tenedor, una cuerda o sogas, o los dientes humanos) pueden ser especialmente reveladoras. Las quemaduras de un cigarrillo o de un encendedor pueden ser evidentes como marcas en las plantas de los pies, en las palmas de las manos, en la espalda o en las nalgas. Las quemaduras de agua hirviendo pueden evidenciarse como un enrojecimiento similar a un guante en manos o pies. Se debe investigar cualquier fractura o dislocación de huesos, así como lesiones en la cabeza, en especial cuando parece faltar un manojo de cabello. En algunos casos, una lesión en la cabeza puede haber sido el resultado de haber jalado del cabello al niño.

Las señales físicas que pueden indicar o no descuido incluyen ropa inadecuada para la estación del año, higiene deficiente y un retraso en el desarrollo físico. En la mayoría de los casos no existen señales físicas del abuso sexual. En muchos casos no hay penetración o sólo hay penetración parcial por parte del adulto abusador, sin heridas físicas. En niños pequeños, las señales físicas que pueden o no indicar un abuso sexual incluyen dificultades para sentarse o caminar; informes de comezón o dolor en el área genital; ropa interior manchada, sangrada o desgarrada, y objetos extraños en los orificios. En niños mayores, la presencia de enfermedades transmitidas sexualmente o el embarazo pueden indicar o no abuso sexual.

Señales emocionales y conductuales por abuso y descuido Los indicadores emocionales y conductuales pueden reflejar algo más que abuso y descuido infantiles. El abuso y descuido infantil es sólo una de varias explicaciones posibles subyacentes a la aparición de estas señales. El miedo de regresar a casa o el temor a los adultos en general y la renuencia a quitarse la ropa exterior pueden ser señales de abuso. Otras posibles señales emocionales y conductuales de abuso incluyen:

- reacciones inusuales o aprehensión en respuesta al llanto de otros niños
- baja autoestima
- estados de ánimo extremos o inapropiados
- agresividad
- aislamiento social
- morderse las uñas, chuparse un dedo u otros trastornos en torno a los hábitos

Las posibles señales emocionales o conductuales de descuido incluyen retrasos o faltas frecuentes a la escuela, fatiga o hambre crónica. Las conductas inapropiadas para la edad también pueden ser señales de descuido. De manera más característica, esto se considera el resultado de que un niño adopte muchos roles adultos con niños más jóvenes a causa de la ausencia de alguien que provea los cuidados en casa.

Las posibles señales emocionales y conductuales de abuso sexual en niños menores de 8 años de edad pueden incluir un temor a dormir solos, trastornos en los hábitos de alimentación, enuresis, encopresis, simulación sexual abierta, cambios en la conducta escolar, berrinches, ataques de llanto, tristeza y pensamientos suicidas. Estas señales también se pueden presentar en niños mayores, junto con otras señales posibles como problemas de memoria, aplanamiento emocional, fantasías violentas, alerta extrema, auto mutilación y preocupaciones o inquietudes sexuales, que pueden ir acompañadas de culpabilidad o vergüenza.

Entrevistas, observación conductual y pruebas psicológicas son utilizadas en su totalidad para identificar el abuso infantil. Sin embargo, los profesionales no concuerdan respecto a las herramientas adecuadas para tal evaluación, en especial cuando se refiere a la identificación del abuso sexual. Una técnica implica observar a los niños cuando juegan con *muñecos anatómicamente detallados (MAD)*. Los **MAD** son muñecos con una representación precisa de los genitales. En promedio, los niños que han padecido de abuso infantil tienden a involucrar a los MAD en actividades más sexualmente orientadas que otros niños, pero las diferencias entre grupos de niños abusados y niños no abusados tienden a no ser significativas. Muchos niños que no han sufrido abuso juegan de manera explícitamente sexual con los MAD, de modo que este tipo de juego no es necesariamente indicativo de abuso sexual (Elliott *et al.*, 1993; Wolfner *et al.*, 1993).

Los dibujos de figuras humanas también son utilizados para evaluar el abuso físico y sexual, aunque su precisión para distinguir entre los niños que han padecido de abuso de los que no lo han sido está sujeta a debate (Burgess *et al.*, 1981; Chantler *et al.*, 1993; Kelley, 1985). Se han explorado algunos cuestionarios diseñados para ser aplicados a un niño que puede haber sufrido abuso (Mannarino *et al.*, 1994) o a adultos tales como maestros o padres que conocen bien al niño (Chantler *et al.*, 1993), aunque aún no existe ningún instrumento bien desarrollado y minuciosamente validado. En resumen, no existe un conjunto válido, confiable y ampliamente aceptado de técnicas para la evaluación de abuso sexual. A los profesionales que

han tenido ocasión de llevar a cabo evaluaciones de abuso sexual se les ha aconsejado que integren la información de muchas herramientas de evaluación y que seleccionen tales herramientas caso por caso.

SÓLO PIENSE...

¿Qué obstáculos cree usted que enfrenten los creadores de pruebas cuando intentan desarrollar instrumentos psicométricamente sólidos para la evaluación del abuso sexual infantil?

Cuestiones relacionadas con los reportes de abuso y descuido infantil El abuso infantil, cuando sucede, es una tragedia. Una afirmación de abuso infantil cuando en realidad tal abuso no ha ocurrido también es una tragedia, una que puede dejar cicatrices irreversibles de por vida en un individuo acusado pero que es inocente. Es obligación de los profesionales que tienen a su cargo la crucial empresa de evaluar a un niño respecto a un abuso potencial no comenzar su tarea con alguna idea preconcebida, ya que tales ideas pueden ser transmitidas al niño y pueden ser percibidas como las respuestas correctas a ciertas preguntas (King y Yuille, 1987; White *et al.*, 1988). Los niños entre los 2 y 7 años de edad son altamente sugestionables y su memoria no está tan bien desarrollada como la de niños mayores. Es posible que los sucesos que hayan ocurrido después

del supuesto incidente —incluyendo sucesos a los que sólo se ha hecho referencia en conversaciones— puedan confundirse con el incidente real (Ceci *et al.*, 1987; Goodman y Reed, 1986; Loftus y Davies, 1984). Consideraciones relacionadas respecto al examen psicológico de un niño por abuso infantil han sido analizadas en detalle por Weissman (1991). Comprender los derechos de todas las partes implicadas en un proceso por abuso infantil, incluyendo los derechos del acusado, es decisivo para estar seguros de que se está haciendo justicia.

Evaluación de riesgo En un esfuerzo por prevenir el abuso infantil, los diseñadores de pruebas han buscado crear instrumentos útiles para identificar a padres y otras personas que representen un posible riesgo de abuso para el niño. El Inventario del potencial de abuso infantil (*Child Abuse Potential Inventory, CAP*; Milner *et al.*, 1986; Milner, 1991) ha mostrado una impresionante validez en la identificación de abusadores. Otra prueba, el Índice de tensión en la paternidad (*Parenting Stress Index, PSI*; Loyd y Abidin, 1985), mide la tensión asociada con el papel de educar a los hijos. Se pide a los padres que reflexionen acerca de su relación con cada uno de sus hijos a la vez. Algunos de los reactivos se enfocan en las características del niño que podrían generar tensión, como el nivel de actividad y el estado de ánimo. Otros reactivos del PSI reflejan aspectos potencialmente llenos de tensión en la vida del progenitor, como falta de apoyo social y problemas maritales (Gresham, 1989). Los autores de la prueba reportan coeficientes de confiabilidad de consistencia interna que varían de .89 a .95 para las calificaciones de los factores y calificaciones totales. Los coeficientes de confiabilidad de prueba y posprueba fluctúan de .71 a .82 en un periodo de tres semanas y de .55 a .70 en el intervalo de un año (Loyd y Abidin, 1985). Respecto a la validez de la prueba, los padres que abusan físicamente de sus hijos tienden a obtener calificaciones más elevadas en el PSI que los padres que no abusan (Wantz, 1989).

¿Cuáles son los usos adecuados de las medidas como el CAP y el PSI? Aunque sí existen relaciones positivas entre el abuso infantil y las calificaciones de prueba, estos instrumentos no se pueden utilizar para identificar o enjuiciar abusadores infantiles en un contexto legal (Gresham, 1989). Debido a que el abuso infantil es un fenómeno con una tasa base baja, incluso el uso de instrumentos altamente confiables producirá muchos falsos positivos. En este caso, un falso positivo es la identificación errónea de un evaluado como abusador cuando en realidad no lo es. Para algunos progenitores, los altos niveles de tensión, como son medidos por el PSI, pueden conducir realmente el abuso físico. Sin embargo, en el caso de la mayoría de los padres, no será así. Algunas relaciones padre-hijo, como aquellas que involucran a niños con discapacidades, son inherentemente tensas; Innocenti *et al.*, 1992; Orr *et al.*, 1993). No obstante, la mayoría de los progenitores logra arreglárselas dentro de la relación sin ocasionar daño alguno. Algunos padres que experimentan elevados niveles de tensión como resultado de su relación con el niño pueden sufrir daño ellos mismos —y más tensión todavía— si alguna autoridad en salud mental les indica que están en riesgo de abusar de sus hijos. Por esa razón, se requiere de gran cautela al interpretar y tomar acciones en base a los resultados de una prueba diseñada para evaluar el riesgo de abuso infantil.

Por otra parte, las calificaciones altas en el CAP o en el PSI bien pueden estar señalando una situación de abuso y deben alertar a los profesionales preocupados a estar pendientes de la aparición de señales de abuso. Un segundo uso adecuado de tales pruebas se refiere a la distribución de recursos diseñados para reducir la tensión paterna. A los padres que hayan obtenido calificaciones elevadas en el CAP o en el PSI se les podría dar prioridad para ser colocados en clases de habilidades paternas, capacitación paterna individualizada, asistencia en cuidados infantiles, y otros programas del mismo tipo. Si reducir la tensión de un progenitor reducirá el riesgo de abuso infantil, se debería intentar cualquier cosa que se deba para reducir la tensión paterna.

Como hemos visto a lo largo del presente texto, existen diferentes herramientas de evaluación y muchas formas distintas en que se pueden utilizar. Si es que todas estas herramientas tienen algo en común, es que su uso en manos de un profesional culminará en alguno u otro momento en un reporte escrito. Dentro de los ámbitos clínicos y de orientación psicológica, tal reporte se conoce de manera sencilla como **reporte psicológico**.

SÓLO PIENSE...

Además de hacerlo por medio de la aplicación de una prueba psicológica, ¿de qué otra manera un profesional puede identificar a los padres que están bajo una tensión extrema?

El reporte psicológico

Un componente decisivo de cualquier procedimiento de evaluación es el informe de los hallazgos. La elevada confiabilidad o validez de una prueba o proceso de evaluación se pueden perder por completo si el reporte de la evaluación no se redacta de manera organizada y legible. Por supuesto, lo que constituye un reporte organizado y legible variará en función del objetivo de la evaluación y del público al que está destinado. El reporte de un psicoanalista que está explorando el conflicto edípico no resuelto de un paciente y que está diseñado para su presentación a la Sociedad Psicoanalítica de Nueva York se verá y sonará muy distinto al reporte del psicólogo escolar a un maestro respecto a la conducta hiperactiva del niño en el salón de clases.

Los reportes psicológicos pueden ser tan diferentes como las razones para llevar a cabo una evaluación. Los reportes pueden diferir en cuanto a un número de variables, como la medida en que las conclusiones dependen de uno u otro procedimiento de evaluación y de la especificidad de las recomendaciones que se hagan, si es que se hace alguna. Aún así, existen ciertos elementos básicos en común entre la mayoría de los informes clínicos. Enfocaremos nuestra atención hacia esos elementos en la sección de *Psicometría cotidiana* del presente capítulo. Sin embargo, debe quedar claro que la redacción de informes es una capacidad necesaria en entornos educativos, organizacionales y otros, en cualquier medio en que se lleve a cabo una evaluación psicológica.

El efecto Barnum

Al director de espectáculos P. T. Barnum, se le atribuye haber dicho: “Cada minuto nace un tonto”. Los psicólogos, entre otros, han tomado muy en serio las palabras de P. T. Barnum acerca de la ingenuidad generalizada de las personas. En realidad, *Efecto Barnum* debería de ser un término conocido para cualquier psicólogo al que se le pida redactar un informe psicológico. Pero antes de continuar leyendo para averiguar exactamente lo que es el efecto Barnum, imagínesse que acaba de finalizar una prueba computarizada de personalidad y que el impreso que describe los resultados indica lo siguiente:

Usted tiene una fuerte necesidad de que otras personas lo quieran y admiren. Tiene una tendencia a ser autocrítico. Cuenta con grandes capacidades que no utiliza y de las que no ha sacado provecho. Al mismo tiempo que tiene algunas debilidades de personalidad, usted puede compensarlas en la mayoría de los casos. Su adaptación sexual le ha ocasionado algunos problemas. Aunque es disciplinado y controlado en el exterior, en su interior tiende a preocuparse y a ser inseguro. En ocasiones tiene serias dudas en cuanto a si ha hecho lo correcto o si ha tomado la decisión acertada. Prefiere cierta cantidad de cambio y variedad y se siente insatisfecho cuando se ve sujeto por restricciones y limitaciones. Se precia de ser un pensador independiente y no acepta las opiniones de los demás sin que le den pruebas satisfactorias. Ha encontrado que no es sabio ser demasiado franco al revelarse ante los demás. En ocasiones es extrovertido, afable y sociable, pero en otros momentos es introvertido, cauto y reservado. Algunas de sus aspiraciones tienden a ser poco realistas.

Aun imaginando que los resultados de pruebas aplicadas se refieren a usted de manera específica, por favor califique la precisión de la descripción respecto si a se aplica o no a usted personalmente.

Me parece que la interpretación fue:

excelente

buena

promedio

mala

muy mala

Ahora que ha terminado el ejercicio, podemos decirle: “Bienvenido a las filas de los que han estado sujetos al efecto Barnum”. Este perfil psicológico es, como sin duda habrá notado, vago y general. El mismo párrafo (en ocasiones con algunas ligeras modificaciones) ha sido utilizado

Elementos de un informe característico de evaluación psicológica

No existe un solo estilo o forma aceptados de manera general para un informe psicológico. La mayoría de los evaluadores desarrollan una forma y estilo que ellos creen se adapta mejor a los objetivos específicos de la evaluación. Sin embargo, en general, la mayoría de los informes clínicos contienen los elementos incluidos en la lista y que examinamos brevemente a continuación.

Datos demográficos

Aquí se incluyen todos o algunos de los siguientes: nombre del paciente, dirección, número telefónico, nivel educativo, ocupación, religión, estado civil, fecha de nacimiento, pertenencia étnica, nacionalidad, fecha de la evaluación. El nombre del examinador también se debe considerar como parte del material de identificación del informe.

Motivo de la evaluación

¿Por qué fue asignado este paciente a una evaluación psicológica? En ocasiones, esta sección del informe puede constar de una sola oración (por ejemplo, “Johnny fue enviado a evaluación psicológica para descubrir si su falta de atención se debe a dificultades de personalidad, neurológicas o de otro tipo”). De manera alternativa esta sección del informe, puede ser ampliada con toda la información antecedente pertinente (por ejemplo, “Johnny se quejaba de dificultades auditivas en su clase de cuarto año, según se lee en una nota dentro de sus registros”). Si no se cubre toda la información antecedente relacionada en la sección de “Motivo de la evaluación” del informe, se puede cubrir en una sección separada etiquetada “Antecedentes” o en una sección clasificada como “Resultados”.

Pruebas aplicadas

Aquí, el examinador sencillamente hace una lista de los nombres de las pruebas que fueron aplicadas. Así, por ejemplo, esta sección del informe puede ser tan breve como la siguiente:

- Escala Wechsler de inteligencia para niños-IV (8/1/05-12/1/05)
- Test Gueústaltico visomotriz de Bender (8/1/05)
- Prueba Rorschach (12/1/05)
- Prueba de apercepción temática (12/1/05)
- Prueba de frases incompletas (8/1/05)
- Dibujo de figuras (8/1/05)

Observe que la fecha de aplicación de la prueba se ha incluido junto al nombre de cada una de las pruebas aplicadas.

Ésta es una buena idea bajo cualquier circunstancia y es de especial importancia si la evaluación se efectuó durante el curso de varios días, semanas o periodos más largos. En la sección de muestra anterior, la WISC-IV fue aplicada en el curso de dos sesiones de prueba en dos días diferentes. El Bender, la Prueba de frases incompletas y los dibujos de figuras fueron aplicadas el 8 de enero del 2005; Rorschach y la Prueba de apercepción temática fueron aplicadas el 12 de enero del 2005.

También en esta sección el examinador puede colocar los nombres y fechas de pruebas que se sabe han sido administradas al examinado en momentos anteriores. Si el examinador cuenta con un registro de los resultados (o aún mejor, con los protocolos de prueba originales) de la evaluación anterior, puede integrar esta información a la siguiente sección del informe, “Resultados”.

Resultados

Aquí, el examinador no sólo informa de los resultados (por ejemplo, “En la WISC-IV, Johnny obtuvo un CI verbal de 100 y un CI de ejecución de 110, lo que da un CI total de 106”) sino también de cualquier consideración adicional a las pruebas, como observaciones respecto a la motivación del examinado (“el examinado parecía/no parecía estar motivado para desempeñarse bien en las pruebas”), el nivel de fatiga del mismo, la naturaleza de la relación y la armonía con el examinador, índices de ansiedad y métodos para abordar la tarea. La sección clasificada “Resultados” puede comenzar con una descripción del examinado que sea lo suficientemente detallada como para que el lector del informe casi lo visualice. Por ejemplo:

John es un estudiante universitario de 20 años de edad con fibroso cabello castaño hasta los hombros y barba completa. Se presenta a la evaluación usando una camisa “psicodélica”, pantalones cortos deshilachados y sandalias. Se sentó hundido en su silla durante la mayoría de las sesiones, tendía a hablar únicamente cuando se le hablaba y lo hacía de manera lenta y aletargada.

En esta sección también se incluye la alusión a cualquiera de las variables extrínsecas que hubiesen podido afectar los resultados de las pruebas en alguna forma. ¿La evaluación en una escuela fue interrumpida a causa de un suceso como un simulacro de incendios, un temblor de tierra o alguna otra perturbación? ¿Algún ruido fuerte o poco común dentro o fuera del sitio de prueba afectó la concentración del examinado? ¿Un paciente hospitalizado recibió alguna visita justo antes de la evaluación y ésta pudo haber afectado los resultados? Las respuestas a este tipo de pregunta pueden resultar invaluable en la interpretación de los datos de la evaluación.

(continúa)

Elementos de un informe característico de evaluación psicológica (continuación)

La sección “Resultados” del informe es donde se integran todos los antecedentes, las observaciones conductuales y los datos de prueba para proporcionar una respuesta al tema de la asignación. Si el examinador hace o no referencia a los datos de prueba actuales es cuestión de preferencia personal. Así, por ejemplo, un examinador podrá sencillamente afirmar, “A partir de los resultados obtenidos, hay evidencia de déficit neurológico” y detenerse allí. Otro examinador podría documentar exactamente por qué fue afirmado esto:

Hay evidencia de un déficit neurológico como lo indican los errores de rotación y perseveración en el registro de la prueba de Bender; Además, en el TAT, este examinado no logró comprender la situación en su totalidad y sencillamente se dedicó a enumerar detalles aislados. En adición a lo anterior, tuvo dificultades de abstracción —una indicación más de déficit neurológico— como lo muestra la puntuación inusualmente baja en la subprueba de Semejanzas de la WISC-IV.

La sección “Resultados” deberá conducir en forma lógica a la sección “Recomendaciones”.

Recomendaciones

En base a la evaluación psicológica y prestando especial atención a factores como los aspectos personales y deficiencias del examinado, se dan las recomendaciones dirigidas a un mejoramiento del problema presente. Se puede recomendar psicoterapia, una consulta con un neurólogo, colocación en un curso especial, terapia familiar de corto plazo dirigida hacia un problema en particular, cualquier cosa que el examinador considere sea requerida para mejorar la situación se describe.

Resumen

La sección “Resumen” incluye una afirmación “en forma breve” del motivo de la evaluación, los resultados y la recomendación. En general, esta sección sólo consiste en uno o dos párrafos y debe proporcionar una descripción concisa de quién es el paciente, por qué fue solicitada la evaluación, lo que se encontró y lo que se necesita hacer.

en una variedad de estudios psicológicos (Forer, 1949; Jackson *et al.*, 1982; Merrens y Richards, 1970; Sundberg, 1955; Ulrich *et al.*, 1963) con hallazgos similares: las personas tienden a aceptar descripciones de personalidad vagas y generales como específicamente aplicables a ellos mismos sin darse cuenta de que la misma descripción se podría aplicar prácticamente a cualquiera.

SÓLO PIENSE...

Escriba en un párrafo —una descripción vaga y generalizada de personalidad— que pueda ser utilizado para estudiar el efecto Barnum. Una sugerencia: puede utilizar la sección de los horóscopos de su periódico local como una ayuda para encontrar las palabras adecuadas.

El hallazgo de que las personas tienden a aceptar las descripciones vagas de personalidad como descripciones precisas de sí mismos vendría a ser conocido como el **efecto Barnum** después de que el psicólogo Paul Meehl (1956) desaprobó la “descripción de la personalidad a la manera de P. T. Barnum”.³ Meehl sugirió que se utilizara el término **efecto Barnum** para “estigmatizar los procedimientos clínicos pseudo-exitosos en los que las descripciones de la personalidad a partir de las pruebas son hechos para que se ajusten

al paciente en una gran medida o totalmente en virtud de su trivialidad”. El reconocimiento de este efecto y de los factores que pueden aumentarlo o disminuirlo es necesario si los evaluadores psicológicos han de evitar hacer interpretaciones a la manera de P. T. Barnum.

3. Meehl dio el crédito a D. G. Patterson como el primero en utilizar el término *efecto Barnum*. El mismo fenómeno también ha sido caracterizado como *el efecto de la Tía Fanny*. Tallent (1958) acuñó este término al deplorar la generalidad y vaguedad que plagaban a muchos informes psicológicos. Por ejemplo, respecto al hallazgo de que un evaluado tenía “impulsos inconscientes hostiles”, Tallent escribió: “¡También mi Tía Fanny los tiene!”

Predicción clínica contra mecánica

¿Deberían los clínicos revisar los resultados de pruebas, datos de evaluación relacionados y después derivar conclusiones, hacer recomendaciones y tomar acciones que estén basados en su propia educación, capacitación y experiencia clínica? De manera alternativa, ¿deberían los clínicos revisar los resultados de pruebas y datos de evaluación relacionados y después derivar conclusiones, hacer recomendaciones y tomar acciones en base a las probabilidades estadísticas conocidas, de forma muy parecida a un actuuario o estadístico cuya labor es evaluar riesgos? Un debate referente a los méritos respectivos de lo que se ha llegado a conocer como *predicción clínica contra actuarial* o *evaluación clínica contra actuarial* comenzó a surgir hace más de medio siglo a raíz de la publicación de una monografía sobre el tema, de Paul Meehl (1954; véase también Dawes *et al.*, 1989; Garb, 1994; Holt, 1970; Marchese, 1992).⁴

La creciente popularidad de la evaluación psicológica asistida por computadora (CAPA, por sus siglas en inglés) y de la interpretación de pruebas generada por computadora ha reavivado el debate clínico-contraactuarial. El campo de batalla se ha desplazado a las fronteras de la nueva tecnología y los temas acerca de la evaluación actuarial comparada con el juicio clínico. Los académicos y profesionales contemporáneos tienden a no debatir si los clínicos deberían estar utilizando métodos tipo actuarial para hacer juicios clínicos. Es de más *actualidad* debatir si los clínicos deberían estar utilizando programas de cómputo que emplean métodos tipo actuarial para realizar juicios clínicos.

Aquí puede ser útil una aclaración y definición de términos. En el contexto de la toma de decisiones clínicas, **evaluación actuarial** y **predicción actuarial** han sido utilizadas como sinónimos para referirse a la aplicación de reglas y probabilidades estadísticas empíricamente demostradas como un factor determinante en el juicio y acciones clínicas. Como observaron Butcher *et al.* (2000), la *evaluación actuarial* no es sinónimo de *evaluación computarizada*. Citando a Sines (1966), Butcher *et al.* (2000, p. 6) señalaron que “un sistema de interpretación computarizada de pruebas (CBTI, por sus siglas en inglés) es actuarial sólo si su salida de información interpretativa está totalmente determinada por reglas estadísticas que, ha sido demostrado de manera empírica, existen entre los datos de salida y los de entrada”. Existe la posibilidad de que la salida de información interpretativa de un sistema CBTI esté determinada por otros factores que no sean reglas estadísticas. Por ejemplo, la salida de información puede estar basada no en algunas fórmulas estadísticas o cálculos actuariales, sino más bien en el juicio, opiniones y conocimientos del creador del programa. En tal caso, la *evaluación computarizada* equivaldría a una aplicación computarizada de una opinión clínica; es decir, la aplicación de los juicios, opiniones y conocimientos de un clínico (o grupo de clínicos) a un conjunto particular de datos procesado por el programa de la computadora.

La **predicción clínica** se refiere a la aplicación de la capacitación y experiencia clínica como factor determinante en el juicio y acciones psicológicas. La predicción clínica depende del juicio clínico, que Grove *et al.* (2000) caracterizaron como:

[...] el procedimiento característico durante largo tiempo utilizado por aplicados psicólogos y médicos, en el cual el juez reúne sus datos utilizando métodos informales subjetivos. Los clínicos difieren en cuanto a cómo efectuar esto: la misma naturaleza del proceso tiende a imposibilitar una especificación precisa (p. 19).

Grove *et al.* (2000) procedieron a comparar el juicio clínico con lo que denominaron **predicción mecánica**, o la aplicación de reglas y probabilidades estadísticas empíricamente demostradas, así como algoritmos de cómputo, a la generación computarizada de resultados y recomendaciones.

4. Aunque este debate de manera tradicional ha sido expresado en relación con la evaluación (o predicción) clínica en comparación con la evaluación (o predicción) estadística o actuarial, un debate comparable podría confrontar otras áreas aplicadas de evaluación (incluyendo evaluaciones educativas, de personal u organizacionales, por ejemplo) contra los métodos de base estadística. Existen asuntos concernientes a la utilidad de un enfoque más bien subjetivo para la evaluación, que esté basado en la propia capacitación y experiencia, en comparación con un enfoque más objetivo y sofisticado estadísticamente que esté de manera estricta basado en reglas preestablecidas para realizar el análisis de datos.

Estos autores reportaron los resultados de un metaanálisis de 136 estudios que confrontaron la precisión de la predicción clínica contra la predicción mecánica. En algunos estudios, los dos enfoques de evaluación parecieron tener una precisión aproximadamente equivalente. Sin embargo, en promedio, Grove *et al.*, concluyeron que el enfoque mecánico era cerca de 10% más exacto que el enfoque clínico. El enfoque clínico fue el menos adecuado cuando los factores de predicción incluían los datos de entrevista clínica. Quizá esto fue así porque, a diferencia de los programas de cómputo, los clínicos humanos cometen errores de juicio; por ejemplo, al no tomar en cuenta las tasas base u otros mediadores estadísticos de evaluación exacta. Los investigadores también señalaron que el costo de la predicción mecánica probablemente era menor al costo de la predicción clínica, puesto que la vía mecánica obviaba la necesidad de profesionales con sueldos elevados y las juntas de equipo.

Varios estudios han apoyado el uso de la predicción estadística sobre la predicción clínica. Una razón es que algunos de los métodos utilizados en la investigación de comparación parecen inclinar la balanza en favor del enfoque estadístico. Como observó Karon (2000), los “datos clínicos” en muchos de los estudios no fueron definidos en relación con la información cualitativa obtenida por un clínico, sino más bien respecto a las puntuaciones del MMPI o del MMPI-2. Tal vez muchos clínicos sigan renuentes a poner demasiada confianza en los resultados CAPA porque, como argumentó Karon (1981), las variables en el estudio de la personalidad, de la conducta anormal y de otras áreas de la psicología son verdaderamente infinitas. Exactamente cuáles variables necesitan ser enfocadas en una situación específica puede ser un asunto muy individual. Combine estas variables con las muchas otras variables posibles que pueden estar operando en una situación en la que se requiere de un juicio clínico (como el conocimiento del idioma, capacidad de cooperación y antecedentes culturales del evaluado) y el tamaño de la base de datos de los programas de cómputo necesarios para realizar predicciones precisas comienza a crecer con rapidez. Si tal es el caso, muchos clínicos siguen dispuestos a aventurar su propio juicio en lugar de depender de interpretaciones preprogramadas.

Las computadoras tienen una larga y reconocida historia como herramientas útiles cuando se trata de calificar protocolos de prueba y organizar los datos de prueba. Su valor, cuando se trata de interpretar los datos y de imprimir los reportes, es un poco más polémico. En el lado positivo, las computadoras aplican de manera confiable las reglas de decisión para lo cual fueron programadas. A diferencia de la confiabilidad en intercalificadores, la confiabilidad “inter-computadoras” es perfecta, excluyendo posibles errores de programa, fallas en el suministro de la corriente eléctrica y demás. Las computadoras no tienen prejuicios respecto a raza, clase social, género u orientación sexual. Y a diferencia de algunos clínicos, no recurren a su teoría favorita de personalidad cuando surgen dudas acerca de tomar una decisión relacionada con una prueba. Más bien, las computadoras de manera diligente juegan de acuerdo a las reglas con las que fueron programadas. Es sólo cuando esas reglas son defectuosas que su salida de información muestra errores. Y esto da lugar a que surjan cuestiones cruciales acerca de la falta de validación o de la inadecuada validación de muchos programas de cómputo.

Los autores de la presente obra comparten con otros (por ejemplo, Garb, 2000a, 2000b; Marks, 1999) la opinión de que las computadoras serán cada vez más un factor importante en la evaluación psicológica.

Sin embargo, para que esta profecía se convierta en una realidad benéfica para los clientes, se deben seguir desarrollando soluciones bien meditadas para diferentes obstáculos (Drasgow y Olson-Buchanan, 1999), y los usuarios de programas relacionados con la evaluación deben convertirse en consumidores más selectivos (Snyder, 2000). Con optimismo, tal vez los usuarios también se conviertan en mejores clínicos. De manera ideal, el desarrollo, intensificación y agudeza de las habilidades clínicas seguirá un curso paralelo al del desarrollo de las nuevas tecnologías. Después de todo, es en manos humanas en las que se colocan incluso las más

elocuentes narraciones computarizadas. Es el juicio humano el que procesa e interpreta estos informes. Finalmente, no existe sustituto para el juicio clínico, y en todo tipo de tarea de predicción se debe identificar la combinación óptima de los métodos actuariales y el juicio clínico.

SÓLO PIENSE...

¿Los clínicos que dependen de las computadoras para la calificación e interpretación de las pruebas llegarán a ser mejores o peores clínicos?

Autoevaluación

Evalúe su comprensión de los elementos del presente capítulo probando si puede explicar cada uno de los siguientes términos, expresiones y abreviaturas:

abuso	entrevista de tensión	orientación psicológica
batería de pruebas	entrevista hipnótica	orientado en tres aspectos
batería estándar	entrevista participativa	predicción actuarial
competencia para ser sometido a juicio	Escala de Alcoholismo MacAndrew (MAC-R)	predicción clínica
contrato terapéutico	estándar ALI	predicción mecánica
cuidado administrado	estándar Durham	psicología clínica
daño emocional	estándar M'Naghten	psicópata
deber de advertir	examen del estado mental	reaculturación
demenia	evaluación actuarial	reporte psicológico
descuido	evaluación de custodia	señales emocionales y conductuales de abuso y descuido
DSM-IV-TR	evaluación psicológica culturalmente informada	señales físicas de abuso
EDREPOHOG	evaluación psicológica forense	señales físicas de descuido
efecto Barnum	funcionamiento premórbido	
enfoque evolucionista del trastorno mental	muñecos anatómicamente detallados (MAD)	
entrevista	orientación	
entrevista cognoscitiva		

Un vistazo a la red

Consulte los siguientes sitios de la red para mayor información acerca de los temas que se analizaron en el presente capítulo.

División APA 12 (Psicología clínica)

www.apa.org/divisions/div12/homepage.html

División APA 17 (Orientación psicológica)

www.div17.org

Atención administrada

www.themcic.com

www.ncpamd.com/mcjokes.htm

www.nepsy.com/leading/0211_ne_reform.html

www.managedcareinfo.com

DSM-IV-TR

www.behavenet.com/capsules/disorders/dsm4TRclassification.htm

www.behavenet.com/capsules/disorders/dsm4tr.htm

Índice de gravedad de la adicción

www.niaaa.nih.gov/publications/asi.htm

Evaluación de abuso de sustancias en línea

www.drug-rehabilitation.com/online_assessment.htm

Psicología forense

www.unl.edu/ap-ls

<http://members.optushome.com.au/dwillsh/forensic.htm>

El deber de advertir

www.ncrel.org/sdrs/areas/issues/envrnmnt/css/cs31k1.htm

Lista de verificación de psicopatía

www.swin.edu.au/victims/resources/assessment/personality/psychopathy_checklist.html

Demencia en el contexto legal

<http://dictionary.law.com>

Abuso y descuido infantil

<http://nccanch.acf.hhs.gov/index.cmf>

www.ifapa.org/Brochures/ca_assessment.pdf

www.state.sd.us/social/CPS/Services/signs.htm

http://home.nyc.gov/html/acs/html/getinvolved/abuseprevent_signs.html

Muñecos anatómicamente detallados

www.ipt-forensics.com/library/special_problems5.htm

www.secasa.com.au/index.php/workers/17/41/8

Efecto Barnum

<http://skepdic.com/forer.html>

Evaluación neuropsicológica

La rama de la medicina que se enfoca en el sistema nervioso y sus trastornos es la **neurología**. La rama de la psicología que se enfoca en la relación entre el funcionamiento del cerebro y el comportamiento es la **neuropsicología**. La neuropsicología, que antes era un área de especialidad dentro de la psicología clínica, ha evolucionado para convertirse en una especialidad en sí misma. Los neuropsicólogos estudian el sistema nervioso y su relación con la conducta, utilizando diversas herramientas, incluyendo la *evaluación neuropsicológica*. La **evaluación neuropsicológica** puede definirse como la valoración del funcionamiento cerebral y del sistema nervioso de acuerdo a la relación con el comportamiento.

En este capítulo estudiamos algunas de las herramientas y procedimientos que utilizan los clínicos y los neuropsicólogos para detectar y diagnosticar los trastornos neuropsicológicos. Comenzamos con una breve introducción a las relaciones cerebro-conducta. Este material se presenta para establecer un principio que permita comprender la manera en que los resultados de pruebas, al igual que otros comportamientos, pueden ser valorados para formar hipótesis acerca de los niveles de integridad y funcionamiento cerebral.

El sistema nervioso y el comportamiento

El sistema nervioso está formado por diversos tipos de **neuronas** (células nerviosas) y puede dividirse en el **sistema nervioso central** (que consta del cerebro y la médula espinal) y el **sistema nervioso periférico** (que incluye a las neuronas que transmiten mensajes desde el resto del cuerpo y hacia él). Visto de arriba, la parte grande y redondeada del encéfalo (llamada cerebro) puede dividirse en dos secciones, o hemisferios.

SÓLO PIENSE...

Actividades cotidianas como caminar son algo que damos por sentado, pero imaginemos la complejidad mecánica de ese sencillo acto respecto al fenómeno del control contralateral.

Algunas correlaciones entre el cerebro y la conducta se resumen en la tabla 14-1. Cada uno de los dos hemisferios cerebrales recibe información sensorial del lado opuesto del cuerpo y también controla respuestas motoras de esta misma forma —un fenómeno denominado **control contralateral**. Debido al control contralateral del cerebro sobre el cuerpo, una lesión en el hemisferio derecho puede causar deficiencias sensoriales o motoras en el lado izquierdo del cuerpo. El punto de unión entre los dos hemisferios es el cuerpo calloso, aunque un hemisferio, con más frecuencia el izquierdo, es el dominante. Debido a lo anterior, la mayoría de las

personas son diestras. El hemisferio dominante controla actividades como leer, escribir, hacer operaciones aritméticas y hablar. El hemisferio no dominante controla las tareas relacionadas con

Tabla 14-1
Algunas características del cerebro y la conducta en sitios específicos del sistema nervioso

Sitio	Características
Lóbulos temporales	Estos lóbulos contienen áreas de recepción auditiva así como ciertas áreas para el procesamiento de información visual. Un daño al lóbulo temporal puede afectar la diferenciación, reconocimiento y comprensión del sonido; la apreciación musical; el reconocimiento de la voz, y el almacenamiento auditivo o visual en la memoria.
Lóbulos occipitales	Estos lóbulos contienen las áreas de recepción visual, un daño en ellos puede resultar en ceguera total o parcial del campo visual o menoscabo en el reconocimiento de objetos, escrutinio visual, integración visual de los símbolos en un todo y memorización de imágenes visuales.
Lóbulos parietales	Estos lóbulos contienen las áreas de recepción para el sentido del tacto y el sentido de la posición corporal. Un daño en esta área puede dar por resultado una disminución en el sentido del tacto, desorganización y distorsión en la percepción de uno mismo.
Lóbulos frontales	Estos lóbulos participan de manera integral en la ordenación de la información y la clasificación de los estímulos. Un daño a los lóbulos frontales puede afectar la concentración y la atención, la capacidad de abstracción, la capacidad para elaborar conceptos, la previsión, la capacidad de solución de problemas y el habla, así como la capacidad motora burda y fina.
Tálamo	El tálamo es una especie de estación de retransmisión de las comunicaciones para toda la información sensorial transmitida a la corteza cerebral. Un daño al tálamo puede resultar en la alteración de los estados de excitación, deficiencias en la memoria, deficiencias en el habla, apatía y desorientación.
Hipotálamo	El hipotálamo participa en la regulación de funciones corporales como la alimentación, la ingestión de líquidos, regulación de la temperatura corporal, el comportamiento sexual y las emociones. Es sensible a los cambios ambientales que requieren una respuesta de "enfrenta o escapa" del organismo. Un daño en esta área puede provocar una diversidad de síntomas que varían desde la ingestión incontrolable de alimento y líquido así como alteraciones leves en los estados de ánimo.
Cerebelo	Junto con la protuberancia anular (otro sitio cerebral en el área cerebral conocida como cerebro posterior), el cerebelo participa en la regulación del equilibrio, la respiración y la postura, entre otras funciones. Un daño al cerebelo puede manifestarse en problemas de control y coordinación motora fina.
Formación reticular	En el núcleo del tallo cerebral, la formación reticular contiene fibras que ingresan y salen de la corteza. Debido a que un estímulo en esta área puede provocar que un organismo dormido despierte y que un organismo despierto esté aún más alerta, en ocasiones se conoce como sistema activador reticular. Un daño en esta área puede provocar que el organismo duerma por largos períodos.
Sistema límbico	Está compuesto por la amígdala, la corteza cingulada, el hipocampo y las áreas septales del cerebro; el sistema límbico es esencial para la expresión de emociones. Dañar esta área puede afectar profundamente el comportamiento emocional.
Médula espinal	Muchos reflejos necesarios para la supervivencia (como alejarse de una superficie caliente) se efectúan al nivel de la médula espinal. Además de su papel en la actividad refleja, la médula espinal es esencial para la coordinación de los movimientos motores. Las lesiones en la médula espinal pueden ocasionar diversos grados de parálisis u otras dificultades motoras.

el reconocimiento espacial y las texturas, así como con la apreciación artística y musical. En el individuo normal, íntegro en el aspecto neurológico, un hemisferio complementa al otro.

Daño neurológico y el concepto de organicidad

Los investigadores actuales que exploran la relación entre el cerebro y el cuerpo utilizan diversas herramientas y procedimientos en su trabajo. Más allá de las herramientas comunes de evaluación psicológica (pruebas, historias clínicas, etcétera), los investigadores utilizan equipos de imagen de alta tecnología, experimentación que incluye la estimulación eléctrica o química de diversos sitios del cerebro en humanos y animales, experimentación que implica la alteración del cerebro de sujetos animales mediante cirugía, pruebas de laboratorio y observación de campo de víctimas de traumatismo cerebral, y autopsias de sujetos humanos y animales, normales y anormales. Mediante estos métodos, los investigadores han aprendido mucho acerca del funcionamiento neurológico sano y patológico.

El **daño neurológico** puede presentarse como una lesión en el cerebro o en cualquier otro sitio dentro de los sistemas nerviosos central o periférico. Una **lesión** es una alteración patológica del tejido, como la que puede ocurrir por un traumatismo o una infección. La naturaleza de las lesiones neurológicas puede ser física o química y éstas se clasifican como *focales* (relativamente circunscritas a un sitio) o *difusas* (diseminadas en diversos sitios). Debido a que los diferentes

Tabla 14-2
Nombres técnicos de diversos tipos de
déficit sensoriales y motores

Nombre	Descripción del déficit
acalculia	Incapacidad para ejecutar cálculos aritméticos
acopia	Incapacidad para copiar diseños geométricos
agnosia	Déficit para reconocer estímulos sensoriales (por ejemplo, la <i>agnosia auditiva</i> es la dificultad para reconocer estímulos auditivos)
agrafia	Déficit en la capacidad para la escritura
acinesia o aquinesia	Déficit en movimientos motores
alexia	Incapacidad para la lectura
amnesia	Pérdida de la memoria
amusia	Déficit en la capacidad para producir o apreciar la música
anomia	Déficit asociado con encontrar palabras para nombrar las cosas
anopia	Déficit de la visión
anosmia	Déficit en el sentido del olfato
afasia	Déficit en la comunicación debido a la dificultad para hablar o en la capacidad para escribir
apraxia	Trastorno de los movimientos voluntarios en ausencia de parálisis
ataxia	Déficit en la capacidad motora y la coordinación muscular

sitios del cerebro controlan varias funciones, las lesiones focales y difusas en varias partes del cerebro, se manifestarán en diferentes formas de déficits conductuales. En la tabla 14-2 se presenta una lista parcial de los nombres técnicos para las muchas variedades de déficit sensoriales y motores.

Es posible que una lesión focal tenga ramificaciones difusas respecto a los déficit conductuales. Dicho de otro modo, una lesión circunscrita a un área del cerebro puede afectar varios y diferentes tipos de conductas. Es posible que una lesión difusa afecte una o más áreas de funcionamiento de modo tan grave que parezca una lesión focal. Conociendo estas posibilidades, en

ocasiones los neuropsicólogos “trabajan en sentido inverso” a medida que a partir de la conducta intentan determinar dónde podría estar la lesión neurológica, en caso de que ésta exista.

La evaluación neurológica también puede representar un papel crucial en la determinación del grado de deficiencia conductual que ha ocurrido o que puede esperarse ocurra como resultado de un trastorno o lesión neurológica. Tal información diagnóstica es útil no sólo para diseñar los programas terapéuticos, sino también para evaluar las consecuencias de los tratamientos farmacológicos, el entrenamiento físico y otro tipo de terapia.

Por desgracia, los términos *daño cerebral*, *daño neurológico* u *organicidad* han sido empleados de manera intercambiable en gran parte de la literatura psicológica. El término *daño neurológico* es el

más inclusivo porque abarca no sólo el daño cerebral sino también el daño a la médula espinal y a todos los componentes del sistema nervioso periférico. El uso del término *organicidad* se deriva de una investigación posterior a la primera guerra mundial realizada por el neurólogo alemán Kurt Goldstein. Los estudios con soldados que presentaban lesiones cerebrales llevaron a Goldstein a la conclusión de que los factores que diferenciaban a los individuos con daños orgánicos de las personas normales incluían la pérdida de la capacidad de abstracción, déficit en la capacidad de razonamiento e inflexibilidad en las tareas encaminadas a la solución de problemas. De acuerdo con esto, Goldstein (1927, 1939, 1963a) y sus colegas desarrollaron pruebas psicológicas que se enfocaban en estos factores y que fueron diseñados para ayudar a diagnosticar el *síndrome cerebral orgánico* u **organicidad**. Aunque actualmente la prueba de Goldstein ya no se publica sigue siendo útil para ilustrar algunos de los tipos de tareas que se siguen empleando hoy día para detectar un déficit neurológico (figura 14-1).

SÓLO PIENSE...

Un paciente se queja de problemas para mantener el equilibrio. En qué sitio del cerebro podría el neuropsicólogo “trabajar en sentido inverso” a partir de esta queja para localizar la fuente del problema. Es posible que usted quiera “trabajar en sentido inverso” y consultar de nuevo la tabla 14-1.




Figura 14-1
Las pruebas Goldstein-Scheerer
de pensamiento abstracto y concreto*

a) La Prueba de palitos es una medida de la memoria reciente. La tarea del sujeto es reproducir de memoria los diseños utilizando palitos. b) La Prueba de cubos desafía al sujeto a que reproduzca con ellos un diseño impreso en un cuadernillo. Esta subprueba fue la antecesora de la tarea de Diseño con cubos de las escalas de inteligencia de Wechsler. Se emplea para medir la capacidad de abstracción no verbal. c) La Prueba de clasificación de color y forma contiene 12 objetos, incluyendo 4 triángulos, 4 círculos y 4 cuadrados (cada pieza en uno de cuatro colores). Los objetos se presentan en orden aleatorio y se le indica al sujeto que los clasifique de acuerdo a su pertenencia. Una vez que los ha clasificado, a continuación se le pide que los ordene de una manera diferente. Se anota la flexibilidad del sujeto para cambiar de un principio de clasificación a otro. d) La Prueba de clasificación de objetos consiste en 89 objetos, que el sujeto debe agrupar. El pensamiento abstracto y la lesión orgánica pueden ser inferidos si el sujeto clasifica los objetos, por ejemplo, en base al color en lugar de por su función. e) La Prueba de clasificación de colores emplea varias madejas de estambre de diversos colores. La tarea en este caso es clasificar las madejas de acuerdo con la muestra de un boceto que presenta el examinador.

* Estas pruebas ya no son publicadas.

(Fuente: Copyright © 1945, renovado en 1972 por The Psychological Corporation. Reproducido con autorización. Derechos reservados.)

En la tradición de Goldstein y sus asociados, dos psicólogos alemanes, Heinz Werner y Alfred Strauss, examinaron las correlaciones entre el cerebro y la conducta en niños con lesiones cerebrales y discapacidad intelectual (Werner y Strauss, 1941; Strauss y Lehtinen, 1947). Al igual que sus predecesores que habían trabajado con adultos con lesiones cerebrales, estos investigadores intentaron delimitar las características comunes a *todas* las personas con lesión cerebral, incluyendo niños. Aunque su trabajo condujo a una mejor comprensión de las consecuencias conductuales de la lesión cerebral en los niños, también llevó a la suposición de que todos los niños con daños orgánicos, sin importar la naturaleza o sitio específicos de su lesión, compartían un patrón similar de déficit cognoscitivos, conductuales, sensoriales y motores. El concepto unitario de organicidad que surgió de su trabajo en la década de 1940 prevaleció a través de la mayor parte del decenio de 1950. Pero para esa época, investigadores como Birch y Diller (1959) estaban comenzando a cuestionar lo que consideraban como la “ingenuidad del concepto de ‘organicidad’”:

Es bastante claro que “daño cerebral” y “organicidad” son términos que, aunque se superponen, no son idénticos y sirven para designar sucesos interdependientes. “Daño cerebral” se refiere al

hecho de una destrucción anatómica, mientras que “organicidad” representa una de las variedades de consecuencias funcionales que pueden acompañar esa destrucción (p. 195).

De hecho, la opinión de que la organicidad y el daño cerebral no son unitarios es respaldada por diversas observaciones:

- Personas que tienen lesiones idénticas en el cerebro pueden presentar síntomas notablemente diferentes.
- La interacción de muchos factores, como el funcionamiento premórbido del paciente, el sitio y la difusión de la lesión, la causa de la misma y su tasa de dispersión pueden hacer que un individuo con una lesión orgánica parezca totalmente diferente a otro con el mismo diagnóstico en un contexto clínico.
- Puede existir una semejanza considerable en los síntomas exhibidos por personas que tienen tipos de lesiones totalmente diferentes. Además, es posible que estos tipos diferentes de lesiones provengan de una variedad de causas, como un traumatismo, con o sin pérdida de conciencia, alguna infección, deficiencias de nutrición, un tumor, un accidente cerebrovascular, una degeneración neuronal, toxinas, fuerza cardíaca insuficiente y una variedad de perturbaciones metabólicas.
- Muchos padecimientos no ocasionados por algún daño cerebral producen síntomas que se asemejan a los producidos por un daño cerebral. Por ejemplo, en un examen, un individuo psicótico, deprimido o simplemente fatigado puede producir datos de daño cerebral orgánico que son característicamente diagnósticos de un deterioro neuropsicológico.
- Otros factores además del daño cerebral (como psicosis, depresión, fatiga) influyen en las respuestas de las personas con daño cerebral. Algunos tipos de respuesta son consecuencia (en vez de una correlación) del daño cerebral. Por ejemplo, si los niños con daño cerebral, como grupo, tienden a ser descritos como más agresivos que los niños normales, esto puede reflejar más la manera en que tales niños han sido tratados por sus padres, maestros y compañeros que por los efectos de alguna lesión.
- Las personas que en realidad tienen daño cerebral en ocasiones, pueden compensar sus déficit a grado tal que, de hecho, otras partes no afectadas del cerebro se hacen cargo de algunas funciones.

SÓLO PIENSE...

¿Se le ocurren otras etiquetas diagnósticas que sean utilizadas de manera rutinaria como si fueran unitarias pero en realidad no lo son? ¿Qué sucede con la etiqueta diagnóstica de *psicótico*?

Con esta breve introducción a la neuropsicología como antecedente, examinemos el examen neuropsicológico y las diversas herramientas de evaluación que se pueden emplear para llevarlo a cabo.

El examen neuropsicológico

Es posible que los clínicos que realizan valoraciones rutinarias no sean neuropsicólogos, aunque estén entrenados para detectar los signos y síntomas de un déficit neurológico. Los neuropsicólogos hacen una distinción entre *signos severos* y *signos ligeros*. Un **signo severo** puede definirse como un indicador de un déficit neurológico definitivo. Los reflejos anormales son un ejemplo de un signo severo. Un **signo ligero** es un indicador que tan sólo sugiere un déficit neurológico. Un ejemplo de un signo ligero es una discrepancia de 15 puntos entre las escalas verbal y de desempeño en una escala Wechsler de inteligencia. Los signos (severos y ligeros) y los síntomas pueden presentarse al momento de recabar los antecedentes, como cuando la persona evaluada informa haber perdido la conciencia en alguna ocasión. Las áreas que requieren estudio adicional pueden ser detectadas durante la entrevista, como cuando la persona evaluada se queja de cefaleas

fuertes y duraderas. Los signos o síntomas pueden ser percibidos por los entrevistadores durante una entrevista o durante la aplicación de una prueba. Los signos que indican déficit neurológico pueden ser evidentes en las puntuaciones de las pruebas.

En casos donde los signos o síntomas conducen a una sospecha de déficit neurológico, es característico que un neurólogo recomiende a la persona un examen neurológico o la envíe con un neuropsicólogo para que le realice una valoración neuropsicológica. El objetivo de una valoración neuropsicológica típica es “derivar inferencias sobre las características estructurales y funcionales del cerebro de una persona valorando el comportamiento de ese individuo en situaciones definidas de estímulo-respuesta” (Benton, 1994, p. 1).

Muchas de las herramientas de la evaluación neuropsicológica son instrumentos con los que los psicólogos que realizan evaluaciones están bastante familiarizados, como las pruebas, la historia clínica y la entrevista. Algunas herramientas, como el equipo de imágenes, son modernas maravillas de la tecnología cuyo funcionamiento es conocido para un número relativamente pequeño de profesionales médicos. Nuestra atención está dirigida a las herramientas de la variedad más familiar, aunque también haremos un breve resumen de algunas de estas maravillas actuales.

Las herramientas de evaluación que se utilizan en un examen neuropsicológico varían en función de diversos factores; por ejemplo, el propósito del examen, la integridad neurológica de la persona examinada y la minuciosidad del examen. En cierto sentido, cualquier aplicación rutinaria de una prueba o batería de pruebas psicológicas en un ámbito clínico también puede satisfacer el propósito de una detección neuropsicológica. En el curso de una evaluación de inteligencia, personalidad u otras variables, es posible que el clínico se percate de hallazgos que permitan establecer las sospechas o que indiquen la necesidad de un examen neuropsicológico más profundo. En ocasiones, a un paciente se le envía con un psicólogo con el propósito de detectar problemas neurológicos. En tal caso se aplicará, de manera peculiar, una batería de pruebas. Como mínimo, esta batería incluirá una prueba de inteligencia, una de personalidad y otra perceptiva-motora de memoria.¹ Si se descubren signos neurológicos sospechosos durante la evaluación, se recomienda a la persona evaluada una valoración posterior y más detallada.

Más allá de los propósitos generales de detección, se podría enviar al evaluado a una valoración neuropsicológica minuciosa debido a la naturaleza del problema específico que presente, como una queja de pérdida de memoria. Un neurólogo que busque averiguar más acerca de las consecuencias cognoscitivas y conductuales de una lesión supuesta o reconocida puede ordenar un examen neuropsicológico. En tales casos, la nota de recomendación de un neurólogo, dirigida al neuropsicólogo, podría decir lo siguiente:

Mi examen fue negativo, pero pienso que podría haber omitido algo. Este paciente sufrió una lesión en la cabeza hace cerca de seis meses y sigue quejándose de cefaleas. No encontré signos severos, sólo algunos signos ligeros como un temblor en la mano derecha (posiblemente por ansiedad) y un patrón de datos de pruebas de laboratorio que van de negativos a dudosos. Por favor, evalúe a este paciente y hágame saber si usted encuentra que las cefaleas y otras dolencias imprecisas tienen un origen orgánico o funcional.

Además de solicitar que se confirme si los déficit observados son **orgánicos** (con base física/fisiológica) o **funcionales** (con base psicológica), la nota de recomendación también podría plantear

SÓLO PIENSE...

Describa un hallazgo como resultado de la aplicación de una prueba de inteligencia que podría disponer a un evaluador a recomendar a la persona evaluada una valoración neuropsicológica minuciosa.

1. Aquí hemos elaborado una lista de lo que consideramos es la cantidad mínima de pruebas para una exploración neuropsicológica adecuada. Sin embargo, no es raro que algunos clínicos sólo apliquen una prueba perceptiva-motora de memoria, una práctica contra la cual algunos se han manifestado de manera firme. Véanse, por ejemplo, Bigler y Ehrenfurth (1981), y Kahn y Taft (1983).

otro tipo de preguntas al neuropsicólogo, como “¿el padecimiento es agudo o crónico?”, “¿este individuo está listo para regresar a la escuela o el trabajo?”, “¿qué áreas requieren terapia de apoyo?”.

El examen neuropsicológico variará ampliamente en función del motivo de la recomendación. Los temas relacionados con el origen funcional u orgánico de un comportamiento observado requerirán de un examen más profundo de los antecedentes de personalidad y psiquiátricos.

El contenido y naturaleza del examen también variarán en función de la integridad neurológica de la persona evaluada. Los neuropsicólogos evalúan a personas que exhiben un amplio rango de discapacidades físicas y psicológicas. Es sabido, por ejemplo, que algunos individuos tienen deficiencias visuales o auditivas, problemas de concentración y atención, dificultades del habla y del lenguaje, y así sucesivamente. Esos déficit deben ser tomados en consideración y se debe encontrar una manera de aplicar las pruebas apropiadas de modo que puedan obtenerse resultados significativos. Con frecuencia, los neuropsicólogos aplicarán de manera preliminar exámenes visuales, auditivos y de otro tipo para establecer la integridad total del funcionamiento sensorial y motor antes de proseguir con pruebas más especializadas. Por ejemplo, un déficit olfatorio (del sentido del olfato) puede ser sintomático de una gran variedad de problemas neurológicos y no neurológicos tan diversos como la enfermedad de Alzheimer (Serby *et al.*, 1991); enfermedad de Parkinson (Serby *et al.*, 1985) y sida (Brody *et al.*, 1991). El descubrimiento de ese déficit mediante una prueba como la Prueba de identificación de olores de la Universidad de Pennsylvania

SÓLO PIENSE...

Usted es un neuropsicólogo que evalúa a un paciente de quien se sospecha tiene un déficit olfatorio. Usted no posee un ejemplar de la UPSIT. ¡Improvise! Describa lo que haría.

la integridad total del funcionamiento sensorial y motor antes de proseguir con pruebas más especializadas. Por ejemplo, un déficit olfatorio (del sentido del olfato) puede ser sintomático de una gran variedad de problemas neurológicos y no neurológicos tan diversos como la enfermedad de Alzheimer (Serby *et al.*, 1991); enfermedad de Parkinson (Serby *et al.*, 1985) y sida (Brody *et al.*, 1991). El descubrimiento de ese déficit mediante una prueba como la Prueba de identificación de olores de la Universidad de Pennsylvania

(*University of Pennsylvania Smell Identification Test, UPSIT*; Doty *et al.*, 1984) sería un estímulo para continuar con la evaluación diagnóstica.

Es común para todos los exámenes neuropsicológicos minuciosos la obtención de los antecedentes clínicos y médicos, un examen del estado mental y la aplicación de pruebas y procedimientos diseñados para descubrir cualquier tipo de problemas en el funcionamiento neuropsicológico. A lo largo del examen, los conocimientos del neuropsicólogo acerca de la neuroanatomía, neuroquímica y neurofisiología son esenciales para la interpretación óptima de los resultados. Además de orientar las decisiones respecto a qué debe ser examinado y cómo hacerlo, tal conocimiento también será utilizado para tomar las decisiones en relación a *cuándo* debe ser efectuado el examen. Así, por ejemplo, sería atípico que un neuropsicólogo aplicara pruebas psicológicas a la víctima de un accidente cerebrovascular inmediatamente después de que éste haya ocurrido. Debido a que puede ocurrir una recuperación espontánea de las funciones en las semanas y meses posteriores a dicho evento, examinar de inmediato al paciente después del suceso produciría, por tanto, una imagen errónea de la magnitud del daño.

Obtención de antecedentes, historia clínica y estudios de casos

Los neuropsicólogos prestan atención cuidadosa a los antecedentes de los pacientes según su propia narración y de acuerdo a cómo se detallan en los registros médicos. Los neuropsicólogos también estudian los hallazgos de casos similares, para comprender mejor a las personas a quienes evalúan.

Un examen neuropsicológico característico comienza con una obtención cuidadosa de los antecedentes. Las áreas de interés para el examinador incluyen las siguientes:

- Antecedentes médicos del paciente
- Antecedentes médicos de la familia inmediata y otros familiares del paciente. Un ejemplo de una pregunta en este caso sería: “¿Tiene o ha tenido familiares que hayan experimentado mareo, desmayos, pérdida temporal de la conciencia o la visión, espasmos, etcétera?”
- La presencia o ausencia de ciertos **hitos en el desarrollo**, una parte particularmente decisiva en el proceso para obtener los antecedentes cuando se examina a niños pequeños. En la tabla 14-3 aparece una lista de algunos de estos hitos
- Antecedentes psicosociales, incluyendo el nivel de aprovechamiento académico y el nivel estimado de inteligencia; un nivel estimado de adaptación en el hogar, en el trabajo o en la

Tabla 14-3
Algunos hitos en el desarrollo

Edad	Desarrollo
16 semanas	Se emociona, ríe a carcajadas Sonríe de manera espontánea en respuesta a las personas Anticipa la alimentación al ver la comida Se sienta de manera apropiada durante 10 a 15 minutos
28 semanas	Sonríe y vocaliza ante un espejo y toca la imagen del espejo Emite muchos sonidos vocales Se sienta sin apoyo durante un breve periodo y después se inclina sobre las manos Ingiere bien los sólidos Cuando está acostado sobre su espalda, se lleva los pies a la boca Toma objetos y los transfiere de una mano a otra Cuando se le sostiene en pie, apoya la mayoría de su peso
12 meses	Camina cuando se le sostiene de una mano Dice "mamá" o "papá" y quizás otras dos palabras Da un juguete cuando se le pide verbalmente o con ademanes Coopera mientras se le viste Juega a esconderse detrás de sus manos
18 meses	Tiene un vocabulario de cerca de diez palabras Camina bien, rara vez se cae, puede correr de manera rígida Ve las ilustraciones de un libro Se alimenta sólo, aunque derrama el alimento Puede jalar un juguete o abrazar un muñeco Puede sentarse en una silla pequeña o en una silla para adulto Garabatea con un crayón o lápiz
24 meses	Sube y baja escaleras por sí solo Corre bien, sin caerse Puede construir una torre con seis o siete cubos Usa pronombres personales ("yo" y "tú") y utiliza oraciones de tres palabras. Identifica por nombre imágenes sencillas y se identifica a sí mismo por su nombre Verbaliza sus necesidades de manera bastante consistente Puede pasar la noche sin orinarse Puede colocarse una prenda sencilla
36 meses	Alterna los pies al subir escaleras y salta del último escalón Monta en triciclo Puede copiar un círculo e imitar una cruz con un crayón o lápiz Comprende y responde preguntas Se alimenta sólo derramando poco Puede aprender y repetir rimas sencillas
48 meses	Puede lavarse y secarse las manos así como cepillarse los dientes Ata las correas de los zapatos, se viste y desviste bajo supervisión Puede realizar juegos cooperativos con otros niños Puede dibujar la figura de una persona con, cuando menos, dos partes claras del cuerpo
60 meses	Conoce y nombra los colores, cuenta hasta 10 Salta con ambos pies Puede escribir unas cuantas letras y hacer dibujos identificables

Fuente: Gesell y Amatruda (1947).

escuela; observaciones acerca de la personalidad (por ejemplo, ¿este individuo es hipocondríaco?), procesos de pensamiento y motivación (¿esta persona está dispuesta y es capaz de responder con precisión a estas preguntas?).

- El carácter, gravedad y progreso de cualquier antecedente de dolencias que impliquen perturbaciones en la vista, el oído, el olfato, el tacto, el gusto o el equilibrio; alteraciones en el tono, fortaleza y movimiento muscular; perturbaciones en las funciones autónomas como

respiración, excreción y control de la temperatura corporal; perturbaciones del habla, del pensamiento y de la memoria; dolor (en particular cefalea y dolor facial) y diversos tipos de trastornos del pensamiento

Es crucial para la precisión de la evaluación la recopilación cuidadosa de los antecedentes. Considere, por ejemplo, a un paciente que exhibe un afecto insulso, es indiferente y no parece saber qué día u hora es. Tal individuo podría estar sufriendo de un padecimiento de origen neurológico (como una demencia). Sin embargo, en lugar de ello la causa de este problema podría ser un trastorno funcional (como una depresión grave). La obtención correcta de los antecedentes aclarará si el comportamiento observado es el resultado de una demencia genuina o un producto de lo que se conoce como *pseudodemencia* (un padecimiento que se presenta *como si* fuera demencia, pero no lo es). Cuando se evalúa a un paciente de este tipo, pueden resultar útiles varias preguntas relacionadas con la historia clínica. Por ejemplo: ¿Cuánto tiempo ha estado el paciente en

SÓLO PIENSE...

¿Qué otra cosa querría saber usted acerca de este paciente indolente, con afecto, insulso que no sabe el día de la semana o la hora del día en que vive?

esta situación y qué trauma emocional o traumatismo neurológico pudo haberlo precipitado? ¿El paciente tiene antecedentes personales o familiares de depresión y otros trastornos psiquiátricos? ¿Qué factores parecen estar operando para mantener al paciente en este estado?

La entrevista para obtener los antecedentes puede ayudar a aclarar las preguntas sobre el origen orgánico o funcional de un problema observado y si el problema es *progresivo* (es probable que se disemine o empeore) o *no progresivo*. Los datos de la entrevista para la recopilación de los antecedentes también pueden conducir

al entrevistador a sospechar que el problema mostrado tiene más que ver con la simulación que con un déficit neurológico.

Más allá de la entrevista, el conocimiento de la historia clínica de una persona evaluada también se puede obtener de los registros existentes. Los expedientes clínicos son recursos valiosos para todos los evaluadores psicológicos, pero son particularmente valiosos en la evaluación neuropsicológica. En muchos casos, el motivo de la recomendación tiene que ver con la magnitud del daño que ha sido soportado en relación con el estado preexistente del paciente. El evaluador debe determinar el nivel de funcionamiento del paciente y la integridad neuropsicológica anterior a cualquier traumatismo, enfermedad u otro factor discapacitante. Para tomar tal determinación sobre el funcionamiento premórbido, el evaluador debe basarse en una amplia variedad de datos de la historia clínica, desde registros de archivo hasta las grabaciones en video hechas por los familiares.

Además de la entrevista para la obtención de los antecedentes y de los registros históricos en forma de datos para la historia clínica, los estudios de casos publicados sobre personas que han sufrido el mismo tipo o tipos similares de déficit neurológicos pueden ser una fuente de útiles discernimientos. El material de estudio del caso puede proporcionar indicios acerca de las áreas de valoración que se han de explorar a profundidad y también puede sugerir el curso que seguirá una enfermedad o déficit particular y cómo las fortalezas o debilidades observadas pueden cambiar a través del tiempo. Además, el material del estudio del caso puede ser valioso para formular planes para la intervención terapéutica.

La entrevista

Existe una variedad de entrevistas estructuradas y formatos de calificación que sirven como auxiliares para la exploración neurológica y el proceso de valoración. Los instrumentos para la exploración neuropsicológica indican el camino hacia áreas adicionales de investigación con métodos más amplios de evaluación. Tales instrumentos pueden utilizarse de manera económica con miembros de poblaciones diversas que pueden estar en riesgo de padecer una alteración neuropsicológica, como los pacientes psiquiátricos, ancianos y alcohólicos. Algunas de estas medidas, como el Cuestionario portátil breve del estado mental (*Short Portable Mental Status Questionnaire*), deben ser completadas por un evaluador; otras, como la Escala de daño neuropsicológico (*Neuropsychological Impairment Scale*), son instrumentos de autodescripción.

El Miniexamen de condición mental (*Mini-Mental State Exam*; Folstein *et al.*, 1975) tiene más de un cuarto de siglo de historia siendo utilizada como herramienta clínica y de investigación para detectar daño cognoscitivo. La investigación analítico-factorial sugiere que esta prueba mide principalmente concentración, lenguaje, orientación, memoria y atención (Baños y Franklin, 2003; Jones y Gallo, 2000). También en la categoría de las medidas estructuradas breves está la Exploración en 7 minutos (*7 Minute Screen*), un instrumento desarrollado para ayudar a identificar a pacientes con síntomas característicos de la enfermedad de Alzheimer (Solomon *et al.*, 1998). Las tareas en esta prueba detectan orientación, fluidez verbal y diversos aspectos de la memoria. Tanto el Mini examen de condición mental como la Exploración en 7 minutos son instrumentos valiosos para identificar a individuos con deterioro cognoscitivo no detectado con anterioridad (Lawrence *et al.*, 2000). Sin embargo, ninguno de estos instrumentos de detección debe ser utilizado con propósitos diagnósticos.

Además de las entrevistas estructuradas diseñadas para una exploración rápida, existe el examen neuropsicológico cuya finalidad es detallar el funcionamiento y estado mental. Demos un breve vistazo a este examen.

El examen neuropsicológico del estado mental En el capítulo 13 hemos presentado el esbozo de un examen general del estado mental. El examen neuropsicológico del estado mental se superpone al examen general respecto a cuestiones relacionadas con la conciencia, estado emocional, contenido y claridad de pensamiento, memoria, percepción sensorial, desempeño de actividad, lenguaje, habla, escritura y la tendencia a usar una mano más que la otra de la persona evaluada. El examen del estado mental aplicado con el propósito específico de valorar el funcionamiento neuropsicológico puede ahondar de manera más extensiva en áreas de interés determinadas. Por ejemplo, durante un examen rutinario del estado mental, el examinador podría solicitar a la persona que interprete el significado de sólo uno o dos proverbios. En el examen neuropsicológico del estado mental, pueden presentarse muchos proverbios para obtener una imagen más amplia de la capacidad de pensamiento abstracto del paciente.

A lo largo del examen del estado mental, al igual que en otros aspectos de la valoración (incluyendo la obtención de antecedentes y la aplicación de pruebas), el clínico observa y toma nota de aspectos del comportamiento de la persona evaluada relativos al funcionamiento neuropsicológico. Por ejemplo, el clínico anota la presencia de movimientos involuntarios (como tics faciales), dificultades en la marcha y otros problemas sensoriales y motores. Por ejemplo, es posible que el clínico se percate de que una comisura de la boca es más lenta para curvarse cuando el paciente sonríe, un hallazgo que sugiere un daño al séptimo (facial) nervio craneal. El conocimiento sobre las relaciones entre el cerebro y la conducta resultan útiles en todas las fases de la valoración, incluyendo el examen físico.

El examen físico

La mayoría de los neuropsicólogos llevan a cabo algún tipo de examen físico con los pacientes, pero la extensión de este examen varía ampliamente en función de los conocimientos, competencia y confianza del examinador. Algunos neuropsicólogos han tenido un amplio entrenamiento en realización de exámenes físicos bajo la supervisión de neurólogos en hospitales de enseñanza. Estos psicólogos se sienten seguros para desempeñar muchos de los mismos **procedimientos no intrusivos** (procedimientos que no implican ninguna invasión al cuerpo de la persona examinada) que los neurólogos llevan a cabo como parte de su examen neurológico. En el curso del siguiente análisis, damos una lista de algunos de estos procedimientos no intrusivos. Precedemos este análisis con la advertencia de que es el médico, y no el neuropsicólogo, quien siempre es el árbitro final respecto a las cuestiones médicas.

Además de hacer observaciones sobre la apariencia de la persona evaluada, el examinador también puede examinar físicamente el cuero cabelludo y cráneo en busca de protuberancias o depresiones inusuales. Se pueden inspeccionar los músculos para detectar su tono (¿suave?, ¿rígido?), su fortaleza (¿débil o cansada?) y su tamaño en relación con otros músculos. Respecto a este último rasgo, el examinador pudiera encontrar, por ejemplo, que el bíceps derecho del paciente

Tabla 14-4
Muestras de pruebas utilizadas para evaluar la coordinación muscular

Caminar-correr-saltar

Si el examinador no ha tenido oportunidad de observar de lejos la manera de caminar del paciente entonces, como parte del examen, puede pedir al paciente que camine. Caminar es algo que tendemos a dar por sentado pero, en el aspecto neurológico, es una actividad sumamente compleja que implica la integración adecuada de muchos y diversos componentes del sistema nervioso. En ocasiones, las anomalías en el modo de andar pueden deberse a causas no neurológicas; por ejemplo, si se sospecha un caso grave de juanetes como la causa del problema, el examinador puede pedir al paciente que se quite los zapatos y los calcetines para poder examinar físicamente los pies. Los examinadores altamente capacitados además son sensibles a las anomalías sutiles, como por ejemplo, los movimientos de los brazos mientras el paciente camina, corre o salta.

Ponerse de pie, quieto (técnicamente, la prueba Romberg)

Se pide al paciente que permanezca de pie y quieto con los pies juntos, la cabeza erecta y los ojos abiertos. Si los pacientes deben extender los brazos al frente o mantenerlos a los lados del cuerpo o que conserven los zapatos u otras prendas de vestir, depende de la preferencia del examinador. A continuación se pide al paciente que cierre los ojos. La variable decisiva es la cantidad de oscilación exhibida por el paciente una vez que ha cerrado los ojos. Debido a que las personas normales pueden oscilar un poco cuando tienen los ojos cerrados, se requiere de experiencia y entrenamiento para determinar cuándo la cantidad de oscilación es indicativa de una patología.

Nariz-dedo-nariz

La tarea del paciente es tocar su nariz con la punta del dedo índice, después debe tocar el dedo del examinador y luego tocarse de nuevo la punta de la nariz. La secuencia se repite muchas veces con cada mano. Esta prueba, al igual que muchas similares (como las pruebas dedo del pie-dedo de la mano, dedo-nariz, y talón-rodilla), está diseñada para evaluar, entre otras cosas, el funcionamiento del cerebelo.

Movimiento de los dedos

El examinador modela los movimientos de los dedos (es decir, tocar un piano imaginario o simular que mecanografía en un teclado) y después le pide al paciente que mueva sus propios dedos. De manera característica los dedos de la mano no dominante no se pueden mover tan rápido como los de la mano dominante, pero se requiere de entrenamiento para detectar una diferencia significativa en la tasa de movimiento. El examinador experimentado también observará las anomalías en la precisión y ritmo de los movimientos, "movimientos de espejo" (movimientos similares no controlados en la otra mano cuando se ha pedido mover únicamente los dedos de una mano) y otros movimientos involuntarios anormales. Como en la prueba nariz-dedo, el movimiento de los dedos proporciona información relacionada con la calidad del movimiento involuntario y la coordinación muscular. Una tarea relacionada implica movimientos con la lengua.

es mucho más grande que el bíceps izquierdo. Ese hallazgo podría indicar una distrofia muscular en el brazo izquierdo. Pero también puede reflejar el hecho de que el paciente haya estado trabajando como zapatero durante los últimos 40 años, un trabajo en el que debido al constante martilleo de clavos ha fortalecido el músculo del brazo derecho. La presentación del caso de este paciente subraya la importancia de ubicar los hallazgos físicos en el contexto histórico; no se puede exagerar la importancia de la recopilación cuidadosa de los antecedentes.

SÓLO PIENSE...

¿Está usted de acuerdo en que los neuropsicólogos deberían realizar exámenes físicos no intrusivos? ¿O piensa que es mejor dejar cualquier examen físico al médico?

Además del examen físico del cráneo y la musculatura, también se pueden examinar los reflejos simples. Los **reflejos** son respuestas motoras involuntarias ante los estímulos. Muchos reflejos tienen el valor de la supervivencia para los lactantes, pero después desaparecen a medida que el niño crece. Uno de esos reflejos es el de la masticación. Hacer un sonido con la lengua o con los labios evocará la conducta de masticación en un lactante normal; sin embargo, la evocación de ese reflejo en un niño de más edad o en un adulto indica un déficit neurológico. Además de examinar la presencia o ausencia de diversos reflejos, el examinador podría evaluar

la coordinación muscular utilizando medidas como las de la lista de la tabla 14-4.

El rubro del examen físico en el examen neuropsicológico está diseñado para evaluar no sólo el funcionamiento del cerebro sino también aspectos del funcionamiento de los nervios, músculos y otros órganos y sistemas. Algunos procedimientos utilizados para aclarar la suficiencia y funcionamiento de algunos de los 12 nervios craneales están resumidos en la tabla 14-5. En lo que resta del capítulo se presentarán procedimientos adicionales de evaluación y medición, de igual forma revisaremos varias herramientas más especializadas para la evaluación neuropsicológica.

Tabla 14-5
Ejemplos de pruebas utilizadas por los neurólogos para evaluar la integridad de algunos de los 12 nervios craneales

Nervio craneal	Prueba
I (nervio olfatorio)	Cerrando una narina con el dedo, el examinador coloca alguna sustancia odorífera bajo la narina evaluada y pregunta si el olor es percibido. A continuación, se pide a los sujetos que perciben un olor que lo identifiquen. La incapacidad para percibir un olor cuando éste es presentado puede indicar lesiones en el nervio olfatorio, un tumor cerebral u otros padecimientos médicos. Por supuesto, la incapacidad puede deberse a otros factores, como tendencias de resistencia por parte del paciente o una enfermedad intranasal y tales factores deben descartarse como la causa.
II (nervio óptico)	La evaluación de la integridad del segundo nervio craneal es un procedimiento muy complicado, pues éste es un nervio sensorial cuyo funcionamiento se relaciona con la agudeza visual y la visión periférica. El cartelón visual de Snellen es una de las herramientas que utiliza el médico para evaluar el funcionamiento del nervio óptico. Si el sujeto puede leer los números y letras pequeños en la línea etiquetada "20" alejado a una distancia de 6 metros del cartelón, entonces se dice que el sujeto tiene una visión 20/20 en el ojo que se está evaluando. Éste es sólo un estándar. Aunque muchas personas pueden leer únicamente las letras más grandes en los números superiores del cartelón (es decir, un individuo que lee las letras en la línea "40" se consideraría que tiene una visión a distancia de 20/40), algunas personas tienen una mejor visión que 20/20. Un individuo que puede leer la línea "15" del cartelón visual de Snellen tendría una visión 20/15.
V (nervio trigémino)	El nervio trigémino proporciona información sensorial a partir del rostro así como información motora de y hacia los músculos utilizados en la masticación. La información acerca del funcionamiento de este nervio se examina a través de pruebas de dolor facial (el médico aplica pinchazos con un alfiler), sensibilidad facial a diferentes temperaturas y otras sensaciones. Otra parte del examen implica hacer que el sujeto apriete la mandíbula. Entonces, el médico sentirá e inspeccionará los músculos faciales para determinar si existe debilidad u otras anomalías.
VIII (nervio acústico)	El nervio acústico tiene funciones relacionadas con el sentido del oído y el sentido de equilibrio. La capacidad auditiva se examina formalmente con un audiómetro. Sin embargo, es más frecuente que la evaluación rutinaria del oído involucre un reloj de bolsillo. Siempre y cuando la habitación sea silenciosa, un individuo con audición normal debería ser capaz de escuchar el tic-tac de un reloj de bolsillo a una distancia de alrededor de 1 metro de cada oreja (76 centímetros si la habitación no es muy silenciosa). Otras pruebas rápidas auditivas implican colocar un diapason en diversas partes del cráneo. En el caso de individuos que se quejan de mareo, vértigo, perturbaciones del equilibrio y cosas similares, se puede realizar un examen del sistema vestibular mediante pruebas más específicas.

Pruebas neuropsicológicas

Una amplia variedad de pruebas son utilizadas por los neuropsicólogos, así como por otros profesionales encargados de encontrar respuestas a las cuestiones de recomendación relacionadas con la neuropsicología. Los investigadores pueden emplear las pruebas neuropsicológicas para estimar el cambio en el estado mental u otras variables como resultado de la administración de medicamentos o el inicio de una enfermedad o trastorno. Los evaluadores forenses pueden utilizar las pruebas para tener una percepción del efecto de los factores neuropsicológicos en asuntos como responsabilidad criminal o capacidad para presentarse a juicio.

Pruebas de la capacidad intelectual general Las pruebas de capacidad intelectual, en particular las escalas de Wechsler, ocupan una posición prominente entre las herramientas diagnósticas disponibles para el neuropsicólogo. La naturaleza diversa de las tareas en las escalas de Wechsler y la amplia variedad de respuestas requeridas hacen de éstas, herramientas potencialmente útiles en la exploración neuropsicológica. Por ejemplo, una señal de la existencia de un déficit podría ser evidenciada por las dificultades en la concentración durante una de las subpruebas. Debido a que ciertos patrones de respuesta en la prueba indican déficit particulares, el examinador observa más allá del desempeño en las subpruebas para estudiar el patrón de puntuaciones en el perfil general, un proceso denominado **análisis de patrones**. Así, por ejemplo, un desempeño extremadamente pobre en el Diseño con cubos y otras subpruebas de ejecución podría ser revelador en un registro que contiene puntuaciones relativamente altas en todas las subpruebas verbales. En combinación con un patrón conocido de otros datos, el desempeño deficiente en el Diseño con cubos puede indicar un daño en el hemisferio derecho.

Varios investigadores que intentan desarrollar un indicador definitivo de daño cerebral han diseñado diversas proporciones y cocientes en base a los patrones de las puntuaciones en la subprueba. El mismo David Wechsler se refirió a uno de esos patrones, llamado **cociente de deterioro** o CD (también conocido por algunos como *índice de deterioro*). Sin embargo, ni el CD de

Wechsler ni ningún otro índice basado en la WAIS ha tenido un desempeño lo suficientemente satisfactorio para ser considerado como medida única de daño neuropsicológico.

Ya hemos señalado la necesidad de aplicar pruebas estandarizadas en estricto apego a las instrucciones del manual de aplicación. Sin embargo, debido a la capacidad limitada del examinado, tales aplicaciones “al pie de la letra” de la prueba no siempre son posibles o deseables cuando se examina a miembros de la población con problemas neurológicos. Debido a diversos problemas reales o potenciales (como el reducido periodo de atención de algunos individuos con deterioro

neurológico), es posible que el examinador experimentado necesite modificar la aplicación de la prueba para acomodarse a las deficiencias del examinado y, sin embargo, obtener información útil en sentido clínico. El examinador que aplica una escala de Wechsler puede desviarse del orden predeterminado de aplicación cuando la prueba es aplicada a un individuo que se fatiga con rapidez. En tales casos, las subpruebas más demandantes serán aplicadas al inicio del examen. Con el propósito de abreviar el tiempo de aplicación de la prueba, el examinador entrenado podría omitir ciertas subpruebas que, de acuerdo con sus sospechas, no proporcionarán

información adicional a la ya obtenida. Reiteremos que los neuropsicólogos entrenados y experimentados son quienes pueden hacer —e interpretar de manera significativa— tales desviaciones en la aplicación de las pruebas estandarizadas como las escalas de Wechsler. Para el resto de nosotros debe ser ¡al pie de la letra!

SÓLO PIENSE...

¿Por qué las desviaciones de las instrucciones estandarizadas de cualquier prueba deberían hacerse de manera razonable, si acaso se hacen?

Pruebas para medir la capacidad de abstracción Un síntoma de manera común asociado con un déficit neurológico, sin importar el sitio o causa exactos del problema, es la incapacidad, o disminución de la capacidad, para pensar de manera abstracta. Una medida tradicional de la capacidad de abstracción verbal ha sido la subprueba de Semejanzas de las escalas de Wechsler, la cual debe manejarse en la versión apropiada para la edad del sujeto y la escala de Wechsler apropiada. La tarea en esta subprueba consiste en identificar en qué se parecen dos objetos (por ejemplo, una pelota y una naranja).

Otro tipo de tarea utilizada para evaluar la capacidad de pensamiento abstracto es la interpretación de proverbios. Por ejemplo, interprete el siguiente proverbio:

Una puntada con calma ahorra nueve.

Si su interpretación de este proverbio transmitió la idea de que el apuro provoca la pérdida de tiempo, entonces usted habrá demostrado capacidad para pensar de manera abstracta. Por el contrario, algunas personas con deficiencias neurológicas podrían haber interpretado el proverbio de manera más concreta (es decir, con menos abstracción). He aquí un ejemplo de una interpretación concreta: Cuando cosas, da una puntada a la vez, esto te ahorrará hacerlo nueve veces. Este tipo de respuesta podría (o no, dependiendo de otros factores) revelar un déficit de abstracción. La Prueba de proverbios, un instrumento específicamente diseñado para examinar la abstracción y la capacidad relacionada, contiene varios proverbios junto con las instrucciones estandarizadas de aplicación y datos normativos. En una forma de esta prueba, al sujeto se le pide que escriba una explicación del proverbio. En otra forma de la prueba, en este caso de opción múltiple, cada proverbio tiene cuatro opciones, tres de las cuales pueden ser errores comunes de interpretación o respuestas concretas.

Las pruebas no verbales de abstracción incluyen algunas de las diversas pruebas de clasificación, pruebas que requieren que la persona examinada clasifique objetos de alguna manera lógica. Una instrucción común en la mayoría de las pruebas de clasificación es “Reúne todos los objetos que pertenecen al mismo grupo”, seguida de preguntas como: “¿Por qué agrupaste esos objetos?”. La Prueba de clasificación de objetos (*Object Sorting Test*; véase la figura 14-1) es representativa de tales pruebas, así como la Prueba de clasificación por el color y la forma (*Color-Form Sorting Test*) también conocida como Prueba de Weigl (*Weigl's Test*), la cual requiere que los examinados clasifiquen objetos de diferentes formas y colores. Otra manera en que son aplicadas las tareas de clasificación es agrupando algunos de los objetos estímulo y solicitar al examinado que, a) explique por qué esos objetos van juntos o b) seleccione el objeto que no pertenece al resto.



Figura 14-2
La Torre de Hanoi

Esta versión del rompecabezas de la Torre de Hanoi se presenta con tres clavijas y ocho anillos. El rompecabezas comienza con todos los anillos en una de las clavijas, ordenados de abajo hacia arriba en orden decreciente. Para resolverlo, deben transferirse todos los anillos a otra clavija siguiendo tres reglas: 1) sólo se puede mover un anillo a la vez; 2) el anillo se mueve de una clavija a otra y 3) ningún anillo puede colocarse sobre un anillo más pequeño.

La Prueba de clasificación de tarjetas de Wisconsin-Versión con 64 tarjetas (*Wisconsin Card Sorting Test-64 Card Version, WCST-64*; Kongs *et al.*, 2000) requiere que el examinado clasifique un mazo de 64 tarjetas que contienen diferentes figuras geométricas impresas en diferentes colores. Las tarjetas pueden clasificarse de acuerdo con reglas de correspondencia que deben inferirse y que cambian a medida que avanza la prueba. El desempeño exitoso en esta prueba requiere de diversas capacidades asociadas con el funcionamiento del lóbulo frontal, incluyendo concentración, planificación, organización, flexibilidad cognoscitiva para cambiar de dirección, funcionamiento de la memoria e inhibición de la respuesta impulsiva. La prueba puede ser útil para explorar el daño neurológico con o sin sospecha de lesión en el lóbulo frontal. Se sugiere precaución al utilizar esta u otras pruebas similares, ya que cierta evidencia sugiere que la prueba puede indicar erróneamente un deterioro neurológico cuando en realidad la persona examinada tiene esquizofrenia o un trastorno del estado de ánimo (Heinrichs, 1990). Por ende, es importante que los clínicos descarten las explicaciones alternativas del desempeño en la prueba que indique déficit neurológico.

Pruebas de la función ejecutiva Las pruebas de clasificación miden un elemento de la **función ejecutiva**, que puede definirse como la organización, planificación, flexibilidad cognoscitiva e inhibición de los impulsos y actividades relacionadas asociadas con los lóbulos frontales y pre-frontales del cerebro. Una prueba utilizada para medir la función ejecutiva es la Torre de Hanoi (figura 14-2), un acertijo que hizo su primera aparición en París en 1883 (Rohl, 1993). La torre se levanta apilando anillos de varios tamaños en una de las estaquillas, comenzando con el anillo de mayor diámetro y sin colocar ninguno de los anillos sucesivos sobre uno de menor tamaño. Es probable que debido a que la apariencia de estos anillos apilados unos sobre otros recuerda a una pagoda, el acertijo fue nombrado *La Tour de Hanoi*. La Torre de Hanoi, ya sea en forma sólida para ser manipulada físicamente o adaptada para su aplicación por computadora en forma gráfica, ha sido utilizada por muchos investigadores para medir diversos aspectos de la función ejecutiva (Aman *et al.*, 1998; Arnett *et al.*, 1997; Butters *et al.*, 1985; Byrnes y Spitz, 1977; Glosser y Goodglass, 1990; Goel y Grafman, 1995; Goldberg *et al.*, 1990; Grafman *et al.*, 1992; León-Carrión *et al.*, 1991; Mazzocco *et al.*, 1992; Miller y Ozonoff, 2000; Minsky *et al.*, 1985; Schmand *et al.*, 1992; Spitz *et al.*, 1985).

El desempeño en los laberintos es otro tipo de tarea utilizada para medir la función ejecutiva. Desde la década de 1930, el psicólogo Stanley D. Porteus quedó fascinado por el potencial para la evaluación psicológica de la aparentemente sencilla tarea de identificar el camino correcto en un laberinto y después trazar una línea hasta la salida del mismo. Este tipo de tarea fue introducida originalmente para producir un estimado cuantitativo de la “prudencia, previsión, alerta



Figura 14-3
“¿Hacia dónde nos dirigimos desde aquí, Charly?”

La mujer de la bata blanca ejemplifica una tarea parecida a los laberintos de Porteus al actor Cliff Robertson, quien caracteriza a “Charly” en la película ya clásica del mismo nombre.

mental y facultad de atención sostenida” (Porteus, 1942). Porteus exhortó a sus colegas a utilizar los laberintos en diversos propósitos de investigación que varían desde la exploración de las diferencias culturales (Porteus, 1933), incluyendo el estudio de la incapacidad social (Porteus, 1955),

SÓLO PIENSE...

¿Cómo podría un análisis cualitativo del desempeño en una tarea de laberintos ser revelador respecto a la personalidad de una persona examinada?

hasta el estudio de los rasgos de personalidad por medio del análisis cualitativo del desempeño de la persona examinada (Porteus, 1942). Actualmente, las pruebas de laberintos como la Prueba de laberintos de Porteus (figura 14-3) se utilizan principalmente como medidas de la función ejecutiva (Daigneault *et al.*, 1992; Krikorian y Bartok, 1998; Mack y Patterson, 1995). Aunque es útil para medir ese funcionamiento en los adultos, su utilidad para ese propósito con los niños ha sido cuestionada. Shum *et al.* (2000) no observaron un impacto adverso en el desempeño en la Prueba de laberintos de


Porteus en niños con lesiones cerebrales.

Los reactivos representativos de otros cuatro tipos de tareas que pueden ser utilizadas en la evaluación neuropsicológica se ilustran en la figura 14-4. La parte *a*) ilustra un **reactivo de seguir una pista**. La tarea consiste en conectar los círculos de manera lógica. Se considera que este tipo de tareas detecta muchas capacidades, incluyendo capacidades de formación de conceptos visuales, motoras-visuales, de planificación y otras capacidades cognoscitivas, aunque exactamente cuáles capacidades son detectadas ha sido cuestión de antiguos debates (Stanczak *et al.*, 1998). Las pruebas de trazar una pista en la Batería neuropsicológica Halstead-Reitan (*Halstead-Reitan Neuropsychological Battery*: una batería fija que analizaremos luego) se encuentran entre las medidas de daño cerebral más ampliamente utilizadas (Salthouse *et al.*, 2000; Thompson *et al.*, 1999) y han sido empleadas en una variedad de estudios (Bassett, 1999; Beckham *et al.*, 1998; Compton *et al.*, 2000; King *et al.*, 2000; Nathan *et al.*, 2001; Ruffolo *et al.*, 2000; Sherrill-Pattison *et al.*, 2000; Wecker *et al.*, 2000).

Figura 14-4
Muestras de reactivos utilizados
en la evaluación neurológica


a) Prueba de rastreo

La tarea de la persona evaluada es conectar los puntos de manera lógica.




b) Campo de búsqueda

Después de que le fue presentado un estímulo muestra, la tarea del examinado es localizar uno equiparable con la mayor rapidez posible.




c) Tarea de identificación

Una tarea que implica lo que se conoce como nombramiento de confrontación.



d) Una imagen absurda

La persona examinada responde a preguntas como "¿Qué cosa es incorrecta o disparatada en este dibujo?"



La ilustración *b*) de la figura 14-4 es un ejemplo de **reactivo de campo de búsqueda**. Se exhibe una muestra o estímulo que será localizado (generalmente algún tipo de forma o diseño) y la persona evaluada debe explorar el campo en busca de diversos estímulos que se asemejen a la muestra. En general, este tipo de reactivo es cronometrado. Las personas con lesiones en el hemisferio derecho pueden presentar déficit en la capacidad de exploración visual y una prueba de la capacidad del campo de búsqueda puede ser valiosa para descubrirlos. Las capacidades del campo de búsqueda tienen un fuerte valor adaptativo y pueden tener consecuencias de vida o muerte para el depredador y la presa. La investigación sobre el campo de búsqueda ha encontrado muchas aplicaciones. Por ejemplo, nos ayuda a entender mejor algunas actividades cotidianas como conducir un automóvil (Crundall *et al.*, 1998; Duchek *et al.*, 1998; Guerrier *et al.*, 1999; Recarte y Nunes, 2000; Zwahlen *et al.*, 1998) al igual que actividades más especializadas como pilotear una aeronave (Seagull y Gopher, 1997) y monitorear el tráfico aéreo (Remington *et al.*, 2000).

La ilustración *c*) es un ejemplo de un dibujo lineal simple que recuerda el tipo de reactivos que aparecen en instrumentos como la Prueba de nombramiento de Boston (*Boston Naming Test*). La tarea de la persona evaluada en la Boston (como a menudo se le llama de manera abreviada) es el **nombramiento de confrontación**; es decir, nombrar cada estímulo que se presenta. Esta tarea aparentemente sencilla implica tres operaciones componentes: uno perceptual (percibir las características visuales del estímulo), uno semántico (acceder a la representación conceptual subyacente o significado esencial de aquello que se representa en la ilustración) y uno de vocabulario (encontrar el nombre apropiado y expresarlo). Por ende, la dificultad con la tarea de nombramiento puede deberse a déficit en cualquiera o en todos estos componentes. Es típico que las personas que presentan un trastorno neurológico como resultado de la enfermedad de Alzheimer u otra demencia experimenten dificultades con las tareas de nombramiento.

SÓLO PIENSE...

Por tradición, los reactivos de las imágenes absurdas se han utilizado en las pruebas de inteligencia o las pruebas neuropsicológicas. Describa un reactivo original, creado por usted mismo, con una ilustración absurda que considere que pudiese ser valioso para evaluar la personalidad.

La ilustración *d*) en la figura 14-4 es lo que se conoce como **reactivo de imágenes absurdas**. Es el equivalente pictórico del reactivo con absurdos verbales, la tarea en este caso es identificar aquello que es incorrecto o disparatado acerca de la imagen. Es similar a los reactivos de ilustraciones con absurdos en la prueba de inteligencia de Stanford-Binet. Al igual que con los reactivos de la subprueba

de Comprensión, como los que aparecen en las escalas Wechsler, este tipo de reactivos pueden proporcionar juicios acerca de la comprensión social y capacidades de razonamiento del individuo examinado.

Pruebas de las funciones perceptiva, motora y motora-perceptiva El término **prueba perceptiva** es una referencia general a cualquiera de muchos instrumentos y procedimientos utilizados para evaluar diversos aspectos del funcionamiento sensorial, incluyendo los relacionados con la visión, audición, tacto, gusto y equilibrio. De manera similar, **prueba motora** es una referencia general a cualquiera de los muchos instrumentos y procedimientos empleados para valorar diversos aspectos de la capacidad y movilidad del individuo, incluyendo el movimiento de las extremidades, los ojos u otras partes del cuerpo. El término **prueba motora-perceptiva** es una referencia general a cualquiera de muchos instrumentos y procedimientos utilizados para valorar la integración o coordinación de las capacidades motoras y perceptivas. Por ejemplo, armar un rompecabezas se relaciona con la capacidad perceptiva-motora, de manera más específica, con la coordinación ojo-mano. Se han diseñado miles de pruebas para medir diversos aspectos del funcionamiento perceptivo, motor y motor-perceptivo. Por ejemplo, ¿el nombre *Ishihara* le suena familiar? La Prueba Ishihara (Ishihara Test; 1964) se utiliza para descartar la presencia de daltonismo. Se dispone de instrumentos más especializados —y menos famosos— que son utilizados si se sospecha de formas menos comunes de deficiencia en la percepción del color.

Entre las pruebas disponibles para la medición del déficit en el funcionamiento auditivo está la Prueba Wepman de discriminación auditiva (*Wepman Auditory Discrimination Test*). Esta prueba breve y fácil de aplicar requiere que el examinador lea una lista de 40 pares de palabras monosilábicas con significado (como *más/mal*) pronunciadas mientras se cubren los labios (sin murmurar, por favor), ya sea con una pantalla o con una mano. La tarea del examinado es determinar si ambas



Figura 14-5
Laurretta Bender (1896-1987)

Bender (1970) reflexionaba que el objetivo de su prueba viso-motriz no era obtener una reproducción perfecta de las figuras de la prueba, sino “un registro de la experiencia motora-perceptiva, una experiencia viva, singular y que nunca es igual, incluso en el mismo individuo...” (p. 30).

palabras son iguales o diferentes. Es una prueba bastante sencilla, siempre y cuando el examinador no sufra de un defecto del habla, no tenga un fuerte acento y no susurre. La muestra de estandarización para la prueba representó a un amplio rango dentro de la población, pero existe poca información disponible acerca de la confiabilidad y validez. El manual del instrumento tampoco delinea las condiciones estandarizadas de aplicación, que son particularmente esenciales para la prueba, dada la naturaleza de los estímulos (Pannbacker y Middleton, 1992).

Una prueba diseñada para evaluar las habilidades motoras gruesas y finas es la Prueba de habilidad motora de Bruininks-Oseretsky (*Bruininks-Oseretsky Test of Motor Proficiency*). Diseñada para ser empleada con niños entre 4½ años y 14½ años, este instrumento incluye subpruebas que evalúan velocidad y agilidad para correr, equilibrio, fortaleza, velocidad de respuesta y destreza. Haciendo un comentario menos serio, la tapa del estuche de la prueba puede ser utilizada como un instrumento informal de escrutinio para medir la capacidad de lectura pidiendo a los colegas que pronuncien el nombre de la prueba de manera correcta. Una prueba diseñada para medir la destreza manual es la Prueba de tablero de estaquillas Purdue (*Purdue Pegboard Test*). Esta prueba fue desarrollada originalmente en el decenio de 1940 como auxiliar para la selección de personal y el objeto es colocar estaquillas dentro de unos orificios utilizando primero una mano, después la otra y luego ambas manos. Cada uno de estos tres segmentos de la prueba tiene un límite de tiempo de 30 segundos y la calificación es igual al número de estaquillas colocadas correctamente. Los datos normativos están disponibles y vale la pena mencionar que, en esta tarea en una población sin lesiones cerebrales, en general las mujeres tienen un desempeño ligeramente mejor que los hombres. En sujetos con lesiones cerebrales, esta prueba puede ayudar a responder preguntas relacionadas con la lateralización (organización funcional de los hemisferios del cerebro) de la lesión.

Quizá uno de los instrumentos neuropsicológicos más ampliamente utilizados sea la **Prueba Gestalt visual-motora de Bender** (*Bender Visual-Motor Gestalt Test*), conocida de manera simple como la Bender Gestalt o incluso sólo como la “Bender”. De acuerdo a como fue originalmente concebida por su autora, Laurretta Bender (figura 14-5), la prueba consistía en nueve tarjetas, cada una con un diseño impreso. Los diseños fueron utilizados por el psicólogo Max Wertheimer (1923) en su estudio sobre la percepción de las *gestalten* (palabra alemana para “configuraciones integrales”).

Bender (1938) creía que estos diseños podrían ser utilizados para evaluar la maduración perceptiva y el daño neurológico. A las personas evaluadas se les mostró cada una de las tarjetas por turno y a cada uno se le dijo “cópiala lo mejor que pueda”. Aunque no había límite de tiempo, los tiempos inusualmente largos o cortos de prueba fueron considerados como de importancia diagnóstica. El tiempo promedio de aplicación de los nueve diseños era cercano a los cinco minutos, un hecho que también contribuyó a su gran atractivo entre los usuarios de la prueba.

Bender (1938, 1970) pretendía que la prueba fuera calificada mediante el juicio clínico. Fue publicada con pocas pautas de calificación y sin información normativa. Sin embargo, varios sistemas cuantitativos de calificación para esta, de manera interesante, sencilla prueba pronto estuvieron disponibles para adultos (Brannigan y Brunner, 2002; Hutt, 1985; Pascal y Suttell, 1951; Reichenberg y Raphael, 1992) y protocolos para niños (Koppitz, 1963, 1975; Reichenberg y Raphael, 1992). En la figura 14-6 se presenta una selección de muestras de la terminología de calificación común en muchos de estos sistemas. Además, se propusieron varias modificaciones, como la adición de una fase de memoria. Después de que los nueve diseños fueron copiados, se le daba a la persona examinada una hoja en blanco con estas instrucciones: “Ahora, por favor, dibuje todos los diseños que pueda recordar.” Gobetz (1953) propuso este procedimiento como una manera de probar una hipótesis acerca del desempeño diferencial en la Bender en función de la personalidad. Su hipótesis era que, debido a la presión de la inesperada segunda prueba, los sujetos diagnosticados con

neurosis podrían recordar menos figuras en la parte de memoria que los sujetos normales. Sin embargo, el procedimiento de memoria adquirió amplio uso, no como un medio de proporcionar datos relacionados con la personalidad, sino más bien como un medio de proporcionar datos neuropsicológicos adicionales.

La Prueba Gestalt visual-motora de Bender, segunda edición (*Bender-Gestalt II*; Brannigan y Decker, 2003) añadió siete reactivos nuevos, ampliando el rango de capacidad evaluada por su antecesor. Cuatro de los reactivos son utilizados exclusivamente con niños de 4 a 7 años con 11 meses de edad y tres de los nuevos reactivos se utilizan de manera exclusiva con individuos de 8 hasta 85 años o mayores. Una fase de memoria fue incorporada a la prueba, así como dos pruebas suplementarias denominadas Prueba motora y Prueba

SÓLO PIENSE...

Es posible que los autores de pruebas, Lauretta Bender entre ellos, tengan el propósito de que su instrumento sea calificado e interpretado únicamente en base al juicio clínico. Pero los usuarios de pruebas demandan otras formas de interpretación. ¿Por qué?

de percepción. Las subpruebas suplementarias fueron diseñadas para detectar déficit en el desempeño o en las habilidades motoras que pudieran afectar de manera adversa el desempeño. La tarea en la Prueba motora consiste en dibujar una línea entre los puntos sin tocar los bordes. La tarea en la Prueba de percepción es encerrar en un círculo o indicar un diseño que sea lo más parecido al diseño estímulo. La prueba se realiza aplicando una fase de copiado (copiado de diseños), una fase de memoria (recreación de los diseños dibujados de memoria), la Prueba motora y, después, la Prueba de percepción. Las fases de copiado y memoria tienen límite de tiempo. En todas las fases se proporcionan pautas específicas de calificación. Por ejemplo, durante la fase de copiado, las discrepancias entre el diseño de la tarjeta estímulo y la respuesta de la persona evaluada se califican de la siguiente manera:

- 0 = sin semejanza, dibujo aleatorio, garabateado, falta de diseño
- 1 = semejanza ligera-vaga
- 2 = semejanza parcial-moderada
- 3 = semejanza fuerte-cercana, reproducción precisa
- 4 = casi perfecto

La Bender-Gestalt II fue estandarizada con 4 000 individuos de 4 a 85 años de edad o más, comparados con el Censo de Estados Unidos del año 2000. Fueron incluidos miembros de poblaciones especiales, incluso individuos con discapacidad intelectual, trastornos para el aprendizaje, trastornos por déficit de atención con hiperactividad, autismo, enfermedad de Alzheimer y personas con capacidades sobresalientes. En el manual se presentan numerosos estudios que confirman la confiabilidad y validez de la prueba. Los tipos de estudios de confiabilidad informados fueron de las variedades prueba y postprueba, consistencia interna e intercalificadores. Los estudios de validez fueron interpretados como apoyo para la opinión de que la prueba mide aquello que pretende medir. Los autores concluyeron que






Estímulo Bender	Reproducción	Tipo de error
		Rotación
		Angulación
		Integración
		Perseverancia
		Distorsión de forma
		Desproporción

Figura 14-6
Muestra de errores tipificados en la prueba Gestalt de Bender

Estos tipos de errores pueden sugerir daño orgánico. No todos los errores mostrados son signos de alteración orgánica para todas las edades.

La prueba mide un solo constructo subyacente que es sensible a la maduración y/o al desarrollo, y las calificaciones de las fases de Copiado y Memoria están sumamente influidas y son muy sensibles a los padecimientos clínicos. Esta generalización añade utilidad a los resultados obtenidos (Brannigan y Decker, 2003, p. 67).

Por supuesto, como reconocen los autores, las determinaciones en cuanto a la solidez psicométrica de la nueva prueba son un proceso continuo. Se aconseja a los estudiantes interesados que consulten las publicaciones actuales respecto a reseñas independientes de esta prueba a medida que se vayan publicando.

Pruebas de funcionamiento verbal En ocasiones, las lesiones al cerebro afectan la fluidez verbal y la fluidez en la escritura y hay pruebas que evalúan la medida del déficit en esas habilidades. En la Prueba controlada de asociación de palabras (antes conocida como Prueba de fluidez verbal asociativa), el examinador dice una letra del alfabeto y la tarea del sujeto es decir todas las palabras que se le ocurran, que comiencen con esa letra. Cada uno de los tres ensayos emplea tres

letras diferentes como estímulo y dura un minuto; la puntuación final de la persona examinada refleja el número total de palabras correctas producidas, ponderada de acuerdo a factores como género, edad y educación del sujeto. Las puntuaciones en la Prueba controlada de asociación de palabras están relacionadas con la predicción que se tiene de que los pacientes con demencia ven alterada la capacidad para realizar tareas de la vida diaria, como hablar por teléfono o escribir un cheque (Loewenstein *et al.*, 1992). Y aunque las personas con demencia tienden a tener un desempeño deficiente en la prueba en comparación con las controladas, las diferencias observadas no han sido lo suficientemente significativas como para justificar el uso de la prueba como indicador de demencia (Nelson *et al.*, 1993).

El Inventario secuencial de desarrollo de la comunicación (*Sequenced Inventory of Communication Development*, SICD) es una prueba diseñada para evaluar el desarrollo de la comunicación receptiva y expresiva en niños de 4 meses hasta 4 años de edad. La prueba contiene varios procedimientos de observación y prueba diseñados para evaluar diversos aspectos de la conciencia y comprensión del niño pequeño. Para apoyar la validez del constructo medido, dos estudios mostraron que las infecciones crónicas del oído medio en los niños pequeños producen un retraso en el desarrollo del lenguaje, medido de acuerdo con el SICD (Friel-Patti y Finitzo, 1990; Wallace *et al.*, 1988).

La **afasia**, que no debe ser confundida con la *afagia*, se refiere a una pérdida de la capacidad para expresarse o para comprender el lenguaje hablado o escrito debido a algún déficit neurológico.² Se han desarrollado varias pruebas para medir aspectos de la afasia. Por ejemplo, la Prueba Reitan-Indiana de detección de Afasia (*Reitan-Indiana Aphasia Screening Test*, AST), disponible en formas tanto para niños como para adultos, contiene una variedad de tareas como nombrar objetos comunes, seguir instrucciones verbales y escribir palabras familiares. El análisis factorial ha sugerido que estas tareas se basan en dos factores: capacidades del lenguaje y la coordinación implícita en la escritura de palabras o en el dibujo de objetos (Williams y Shane, 1986). Ambas formas de la prueba fueron diseñadas para ser instrumentos de detección que puedan ser aplicados en 15 minutos o menos. La AST, utilizada por sí sola como instrumento de detección (Reitan, 1984a, 1984b; Reitan y Wolfson, 1992) o en combinación con otras pruebas (Tramontana y Boyd, 1986), puede ser valiosa para distinguir a los examinados que tienen daño cerebral de quienes no lo tienen. Para los individuos de origen hispano, un instrumento culturalmente más adecuado podría ser el Examen multilingüístico de la Afasia (*Multilingual Aphasia Examination*). Rey *et al.* (1999) encontraron que las normas publicadas eran comparables a sus propios datos utilizando una muestra de examinados de origen hispano. También analizaron los problemas específicos que encontraron en la investigación neuropsicológica con los hispanos y sugirieron pautas e instrucciones para futuras investigaciones.

Pruebas de la memoria La memoria es una función cognitiva compleja y multifacética que ha desafiado una explicación simple. Para apreciar su grado de complejidad, considere lo siguiente:

Los seres humanos poseen aproximadamente 1 trillón de neuronas, más 70 trillones de conexiones sinápticas entre ellas... Una sola neurona puede tener hasta 10 000 sinapsis, pero durante el proceso de formación de la memoria quizá sólo 12 sinapsis serán fortalecidas mientras que otras 100 serán debilitadas. La suma de estos cambios, multiplicados por cada neurona, crea un circuito ponderado que equivale a la memoria (Hall, 1998, p. 30).

Diferentes modelos de la memoria compiten por el reconocimiento en la comunidad científica y ninguno ha obtenido aceptación universal. Para nuestros propósitos, en la figura 14-7 presentamos un modelo muestra —con la advertencia de que es relativamente simple—, que ha sido formado con base en varias fuentes, que es incompleto en el mejor de los casos y *no* ha sido aceptado de manera universal. Por otra parte, el modelo contiene elementos que siguen siendo en gran medida un asunto de debate entre los investigadores contemporáneos.

2. La **afagia** es un padecimiento en el que se pierde o disminuye la capacidad para comer.




Figura 14-7
Un modelo de la memoria

De acuerdo con nuestro modelo, la memoria es el resultado del procesamiento de información realizado por el sistema nervioso de los datos sensoriales externos (presentes), a través de la vista, el sonido, el olfato y el gusto. La imagen del rostro de un ser amado que usted ha almacenado, la canción que nunca olvidará y el olor del césped recién podado son ejemplos de recuerdos formados a partir de datos sensoriales reales. La memoria de tipo indefinido también puede ser resultado de lo que uno produce internamente, en ausencia de una sensación real. Lo que uno imagina, sueña o percibe de manera incorrecta son ejemplos de esta última definición de la memoria. Por supuesto, el dominio de los recuerdos de alguna manera imaginados o fabricados puede volverse asunto de importancia clínica. La línea entre el canal de los datos sensoriales y el conocimiento consciente se rompe para indicar que no todos los datos sensoriales llegan de manera automática al conocimiento consciente. La atención, la concentración y los factores relacionados representan un papel clave para determinar cuáles datos llegan en realidad al conocimiento consciente.

Contrario a la imagen popular de la memoria como un depósito ordinario, la memoria es un proceso muy activo que, se supone, implica procesos tanto a corto como a largo plazo (Atkinson y Shiffrin, 1968). La información recibida es procesada en la memoria a corto plazo, donde es almacenada de manera temporal desde tan sólo unos segundos hasta un minuto o dos. La memoria a corto plazo también ha sido caracterizada por algunos investigadores como casi idéntica a la *memoria operativa* (Daneman y Carpenter, 1980; Newell, 1973). El concepto más tradicional de la memoria a corto plazo es como la de un protector pasivo en el que la información es transferida a la memoria a largo plazo o disipada (es decir, olvidada). Nuestro modelo toma en cuenta tanto los componentes pasivos como los activos de la memoria a corto plazo, con la codificación de la memoria a largo plazo realizada a partir del componente activo, “operativo”, de la memoria a corto plazo.

En nuestro modelo, observe que la ruta entre la memoria a corto plazo y el conocimiento consciente es de dos vías. Los estímulos del conocimiento consciente pueden ser suministrados a la memoria a corto plazo y, a su vez, ésta puede suministrar los estímulos de regreso al conocimiento consciente. También observe que la ruta de la memoria a largo plazo está ilustrada con una línea discontinua — esto indica que no toda la información en la memoria a corto plazo es codificada en la memoria a largo plazo.

SÓLO PIENSE...

Visualice alguna imagen o acontecimiento que recuerde. Ahora, después de consultar nuestro modelo de la memoria, defina cómo pudo haber llegado allí ese recuerdo.

Respecto a la memoria a largo plazo, los investigadores han distinguido entre memoria metodológica y declarativa. La **memoria metodológica** es el recuerdo de cosas como conducir un automóvil, ingresar datos por medio de un teclado o montar en bicicleta. La mayoría de nosotros podemos extraer información de la memoria metodológica con poco esfuerzo y concentración. La **memoria declarativa** se refiere al recuerdo de material objetivo,

como las diferencias entre la memoria metodológica y la declarativa. Hemos dividido los componentes metodológicos y declarativos de la memoria a largo plazo con propósitos ilustrativos.

También se ilustran de manera seccionada lo que en general son considerados como los dos componentes de la memoria declarativa: la memoria semántica y la episódica. La **memoria semántica** es, en sentido estricto, el recuerdo de hechos. La **memoria episódica** es el recuerdo de hechos en un contexto o situación particulares. Un ejemplo de memoria episódica o dependiente del contexto podría ser el recuerdo del nombre de un compañero de clase mientras que se está en la clase, pero no en un encuentro casual durante un evento social. Otro ejemplo de memoria episódica es cuando a la persona se le pide repetir dígitos en el contexto de una prueba de memoria porque esto está vinculado de manera muy particular al contexto (de la evaluación).

Como lo indica la ruta de una vía de la memoria a largo plazo al conocimiento consciente, es posible recuperar la información almacenada en la memoria a largo plazo. La duda acerca de si la información recuperada se puede volver a almacenar directamente en la memoria a largo plazo o si, en lugar de ello, debe ser procesada de nuevo a través de la memoria a corto plazo es cuestión de debate.

Las pruebas neuropsicológicas diseñadas para evaluar la memoria conectan los diferentes componentes de la memoria según se describe en nuestro modelo. Una de las pruebas de la memoria más utilizada, la Escala de la memoria de Wechsler (WMS-III), incluye principalmente la memoria declarativa episódica. Como se afirma en el manual técnico de la prueba, “la información presentada es novedosa y contextualmente determinada por la situación de prueba y requiere que el examinado aprenda y recupere información” (Tulsky *et al.*, 1997, p. 3). Muy parecida a su antecesora (la WMS-R), la WMS-III es una prueba de la memoria que se aplica de manera individual diseñada para ser utilizada con adolescentes y adultos. Sin embargo, hay muchas diferencias significativas entre ambas versiones respecto a las subpruebas de la misma y las escalas, el desarrollo de normas, la estructura y calificación de los índices, y a los factores relacionados (véase Tulsky *et al.*, 1997).

La WMS-III requiere que los examinados realicen tareas como volver a relatar una historia leída en voz alta, hacer una secuencia de letras y números (similar a la tarea de hacer una sucesión de letras y números descrita anteriormente en el WAIS-III) y aprender pares de palabras que, de manera aparente, no están relacionadas. También existen subpruebas que implican el reconocimiento de imágenes de rostros. Primero se les presenta a los examinados un arreglo de rostros utilizados como objetivo. Después debe identificar cuáles de estos rostros están incluidos en un segundo agrupamiento que incluyen tanto los utilizados como objetivo como otros rostros. Otras





Figura 14-8
Dos herramientas utilizadas en la medición de la memoria táctil

a) En una prueba táctil de la memoria inmediata se pueden utilizar cuatro trozos de alambre doblados que son, en esencia, “figuras táctiles sin sentido”. Se puede indicar a la persona examinada que con su mano derecha o izquierda (o con ambas manos) palpe una de las figuras y después localice una figura que se parezca a ella. b) Lo que se muestra aquí es un modelo del Tablero de figuras de Seguin-Goddard (Seguin-Goddard Formboard). A los examinados se les vendan los ojos y se les pide que coloquen cada uno de los diez cubos de madera en el espacio apropiado del tablero de figuras con cada mano por separado y después con ambas manos. Después, se les puede pedir que, de memoria, dibujen el tablero de figuras. Todas las figuras tienen límite de tiempo y se califican de acuerdo a la precisión.

pruebas opcionales incluyen aquellas que involucran tareas como reproducir diseños presentados en tarjetas y tareas múltiples (es decir, hacer más de una cosa a la vez, como decir el alfabeto mientras se cuenta en sentido inverso a partir de 30).

Los estudios del análisis factorial realizados con la WMS-III sustentaron diversas soluciones factoriales en función de las edades en el grupo. No obstante, en general, los resultados fueron interpretados por los creadores de la prueba para apoyar tres factores comprendidos en la misma: memoria auditiva inmediata y retardada, memoria visual inmediata y retardada y memoria operativa.

Otros dos enfoques a las pruebas de la memoria se ilustran en la figura 14-8. En un enfoque diseñado por Milner (1971), se emplean figuras táctiles sin significado para medir la memoria táctil (o háptica) inmediata. Otra prueba de la memoria táctil implica una adaptación del Tablero de figuras de Seguin-Goddard (Seguin-Goddard Formboard). Halstead (1947a) sugirió que el tablero de figuras podía ser utilizado para evaluar la memoria táctil si a los examinados se les vendaban los ojos durante la prueba y se añadía un ensayo de rememoración.

Un esfuerzo para hacer más reales las pruebas de la memoria es integrar en ellas tareas que las personas deben realizar todos los días. Una batería de pruebas por computadora, desarrollada por Thomas Crook y descrita por Hostetler (1987), utiliza varias tareas reales (como marcar un número telefónico y asociar un rostro). La batería ha sido empleada como una medida de resultados en estudios sobre la eficacia de diversos fármacos en el tratamiento de la enfermedad de Alzheimer.

SÓLO PIENSE...

¿Cuáles son algunas de las tareas reales que usted recomendaría fueran incluidas en la prueba de memoria de Crook?

Baterías de pruebas neuropsicológicas

Con base en el examen del estado mental, el examen físico y los datos de la historia clínica, es típico que el neuropsicólogo aplique una batería de pruebas para estudios clínicos adicionales. Los neuropsicólogos entrenados pueden aplicar una **batería fija** formada por pruebas predeterminadas o pueden modificar una batería fija para el caso que tengan que estudiar. Es posible que elijan aplicar una **batería flexible**, que incluye un conjunto de instrumentos elegidos para algún propósito pertinente a los aspectos únicos del paciente y del problema expuesto.

El clínico que aplica una batería flexible no sólo tiene la responsabilidad de seleccionar las pruebas que van a ser utilizadas, sino también la carga de integrar todos los resultados obtenidos en cada prueba, lo cual no es una tarea sencilla, porque cada una pudo haber sido normalizada con poblaciones diferentes. Otro problema inherente al uso de una batería flexible es que las pruebas aplicadas con frecuencia coinciden en parte respecto a algunas de las funciones examinadas y el resultado es cierto desperdicio de herramientas y de tiempo de aplicación. Sin importar todo esto y otros inconvenientes, la preferencia de la mayoría de los neuropsicólogos sumamente capacitados ha sido adaptar una batería de pruebas a las demandas específicas de una situación particular de prueba. Por supuesto, todo esto puede cambiar como resultado de una acción judicial (véase el *Close-up* de este capítulo).

Las baterías neuropsicológicas fijas están diseñadas para elaborar, de manera inclusiva, una muestra del funcionamiento neuropsicológico del paciente. La batería fija es atractiva para los clínicos, en especial para quienes son relativamente novatos en la evaluación neuropsicológica, porque tiende a ser menos demandante en muchos sentidos. Mientras que para diseñar una batería flexible que responda de manera adecuada al motivo de la recomendación se requiere de una gran cantidad de conocimientos y habilidades, una batería previamente establecida representa una alternativa no hecha a la medida, pero comprensiva. En la batería se incluyen diversas pruebas que ofrecen una muestra de varias áreas y cada una de estas pruebas posee métodos claros de calificación. No obstante, una de las principales desventajas de las pruebas preestablecidas es que la discapacidad específica del paciente puede influir en gran medida —y de manera adversa— en su desempeño en la prueba. De este modo, un individuo que, por ejemplo, tenga un problema visual, tendrá un desempeño deficiente en muchas de las otras pruebas de una batería que requieran ciertas habilidades visuales.

Quizá la batería de pruebas neuropsicológicas establecida más utilizada sea la **Batería neuropsicológica Halstead-Reitan** (*Halstead-Reitan Neuropsychological Battery*). Ward C. Halstead (1908-1969) fue un psicólogo experimental cuyo interés en las correlaciones del cerebro y la conducta lo condujo a establecer en 1935 un laboratorio para ese propósito en la Universidad de Chicago. El suyo fue el primer laboratorio de su tipo en el mundo. Durante el curso de 35 años de investigación, Halstead estudió a más de 1 100 personas con daños cerebrales. De sus observaciones, Halstead (1947a, 1947b) derivó una serie de 27 pruebas diseñadas para evaluar la presencia o ausencia de daño cerebral orgánico, la Batería de pruebas neurológicas de Halstead (*Halstead Neurological Test Battery*). Ralph M. Reitan, un alumno de Halstead, con posterioridad perfeccionaría los descubrimientos de su maestro. En 1955, Reitan publicó dos artículos que trataban sobre los efectos intelectuales diferenciales de las lesiones en diversos sitios del cerebro (Reitan, 1955a, 1955b). Luego de catorce años y de muchas investigaciones, Reitan (1969) publicaría de manera privada un libro titulado *Manual para la aplicación de baterías de pruebas neuropsicológicas para adultos y niños* (*Manual for Administration of Neuropsychological Test Batteries for Adults and Children*), el predecesor de la Batería neuropsicológica Halstead-Reitan (H-R; véase también Reitan y Wolfson, 1993).

La aplicación de la H-R requiere de un examinador altamente capacitado, experto en los procedimientos de aplicación de las diversas subpruebas (tabla 14-6). Incluso con esta clase de examinador, en general se requiere de todo un día para efectuar la prueba completa. Las calificaciones de las subpruebas se interpretan no sólo respecto a lo que significan por sí mismas, sino también por su relación con las calificaciones en otras subpruebas. La interpretación adecuada de los datos requiere del ojo clínico de un neuropsicólogo entrenado, aunque hay disponible un programa para su interpretación por computadora de la H-R —que no sustituye el juicio clínico sino que es un auxiliar de éste—. La calificación produce un número conocido como Índice Halstead de Deterioro, y un índice de .5 o superior, el punto de corte, es indicativo de un problema

Baterías de pruebas neuropsicológicas establecidas en oposición a las flexibles y la legislación

Los tribunales tienen alguna preferencia respecto a las pruebas específicas administradas por los evaluadores que fungen como testigos expertos en los litigios? En lo referente a la evaluación neuropsicológica, ¿importa si el evaluador aplicó una batería fija o una flexible? La resolución de una corte federal en el caso *Chapple vs Ganger* es esclarecedora respecto a estas preguntas. En el caso *Chapple*, el tribunal aplicó el estándar *Daubert* respecto a la admisión de evidencia científica.

El caso *Chapple*

Este caso se originó por un accidente automovilístico en el que un niño de 10 años sufrió lesiones internas en la cabeza. El demandante afirmó que estas lesiones alteraban el funcionamiento cerebral y eran permanentes, mientras que el demandado negaba esta declaración. El niño fue sometido a tres exámenes neuropsicológicos por tres diferentes examinadores en tres ocasiones diferentes. El primero lo realizó un psicólogo clínico, quien aplicó una batería flexible de pruebas que incluía la Prueba de detección de Afasia (*Aphasia Screening Test*), la Prueba de retención visual de Benton (*Benton Visual Retention*), el Cubo Knox (*Knox Cube*), la Prueba de una figura compleja de Rey (*Rey Figure Complex Test*), la Prueba de aptitud musical de Seashore (*Seashore Rhythm Test*), la Prueba de trazar pistas (*Trails Test*), y la Prueba de clasificación de tarjetas de Wisconsin (*Wisconsin Card Sorting Test*). Además, la batería flexible incluyó otras pruebas como dibujar una bicicleta, dibujar un reloj, dibujar una familia y dibujar una persona; completar oraciones, dominio lateral, la Prueba manual rítmica de dedos (*Manual Finger Tapping Test*), la Prueba de vocabulario de imágenes de Peabody y subpruebas de la Woodcock-Johnson, WISC-R y WRAT-R.

El segundo examen neuropsicológico, aproximadamente un año después, incluyó también la aplicación de una batería flexible y en esta ocasión la realizó un neuropsicólogo. Las pruebas aplicadas fueron trazo de pistas, imitación de oraciones, secuencia de palabras y dirección oral (subpruebas de la Prueba Detroit de aptitud para el aprendizaje [*Detroit Test of Learning Aptitude*]); la Prueba Taylor de figuras complejas (*Taylor Complex Figure Test*); la Prueba Hooper de organización visual (*Hooper Visual Organization Test*), capacidad de atención (una subprueba de la Prueba de aprendizaje auditivo verbal [*Auditory Verbal Learning Test*]), Prueba de recordar sonidos y símbolos visuales, (*Sound and Visual Symbol Recall Test*), Prueba de copiado de párrafos (*Paragraph Copy Test*), Prueba breve de inteligencia de Kaufman (*Kaufman Brief Intelligence*), la Prueba de aprovechamiento individual (*Individual Achievement Test*) y la Prueba Wechsler de comprensión de lectura y comprensión auditiva (*Wechsler Reading Comprehension and Listening Comprehension Test*).

El tercer examen neuropsicológico, encargado por el acusado y realizado por el neuropsicólogo Ralph Reitan, implicó la aplicación de la mayoría de las subpruebas de la Batería de pruebas neuropsicológicas Halstead-Reitan para niños mayores (*Halstead-Reitan Neuropsychological Test Battery for Older Children*).

En los dos primeros exámenes, los hallazgos indicaban cierto grado de traumatismo cerebral como resultado del accidente que, a su vez, dejaría al niño con cierto grado de daño permanente. Por el contrario, en los resultados del tercer examen, Reitan concluyó que el niño había obtenido calificaciones dentro del rango normal en la mayoría de las pruebas de su batería establecida. Sin embargo, Reitan admitió que existía la posibilidad de cierto deterioro leve atribuible a cierta disfunción cerebral menor. Reitan formó su opinión en base al desempeño del niño en la prueba así como en la evaluación de los registros del caso. Los otros dos psicólogos también revisaron los registros y los datos históricos del niño para obtener sus conclusiones.

Recurriendo al estándar *Daubert*, el tribunal dictaminó a favor del acusado, por no haber encontrado evidencia que apoyara el daño cerebral orgánico permanente. Aunque no se hizo referencia explícita al valor de las baterías flexibles en comparación con las establecidas, la corte pareció encontrar más convincentes los resultados de la aplicación de una batería establecida. La corte determinó que "el aspecto esencial se encuentra en la metodología de los expertos y no en las conclusiones que generan". Por tanto, en el caso *Chapple*, el tribunal aceptó como evidencia médica el testimonio relativo a la aplicación de una batería establecida, mientras que no aceptó el testimonio relativo a la aplicación de baterías flexibles.

Implicaciones de los casos *Daubert* y *Chapple*

En apariencia, las implicaciones del caso *Daubert* parecen vagas y abiertas a múltiples interpretaciones (Black *et al.*, 1994; Faigman, 1995; Larvie, 1994). Sin embargo, puede haber una lección a considerar en el caso *Chapple*, por lo menos respecto a la aceptabilidad de la evidencia obtenida como resultado de baterías neuropsicológicas establecidas en oposición a las baterías flexibles. Aunque la aplicación de baterías flexibles generalmente es aceptada por la comunidad profesional, un tribunal puede considerar de manera más favorable las conclusiones obtenidas como resultado de una batería establecida, estandarizada. La decisión del tribunal en el caso *Chapple* también sugirió que los resultados de pruebas individuales estandarizadas pueden ser aceptados como evidencia, puesto que estos resultados fueron utilizados para complementar los hallazgos de una batería establecida de pruebas neuropsicológicas.

Tabla 14-6

Subpruebas de la batería Halstead-Reitan

Categoría

Ésta es una medida de la capacidad de abstracción en la cual se proyectan de manera intermitente figuras estímulo de diversos tamaños, formas, número, intensidad, color y localización sobre una pantalla opaca. Los sujetos deben determinar qué principios vinculan entre sí a las figuras estímulo (como el color) e indicar sus respuestas entre cuatro opciones oprimiendo la tecla apropiada en un teclado simple. Si la respuesta es correcta suena una campana y si es incorrecta, suena un timbre. La prueba detecta principalmente el funcionamiento del lóbulo frontal del cerebro.

Desempeño fácil

Se vendan los ojos de las personas examinadas y éstas resuelven así el Tablero de figuras Seguin-Goddard (véase la figura 14-8) con la mano dominante y la no dominante y después con ambas manos. Se registra el tiempo que tomó realizar cada una de las tareas. Después se retira el tablero de figuras, se quita la venda de los ojos y se le dan lápiz y papel a la persona para que dibuje de memoria el tablero de figuras. Del dibujo se obtienen dos calificaciones: la calificación de los dibujos hechos de memoria, que incluye el número de figuras reproducidas con una cantidad adecuada de precisión, y la calificación de localización, que es el número total de cubos dibujados en relación exacta con los otros cubos y el tablero. La interpretación de los datos incluye la consideración del tiempo total en que se completó esta tarea, el número de figuras dibujadas de memoria y el número de cubos dibujados en relación exacta con los otros cubos.

Ritmo

Publicada inicialmente como subprueba de la Prueba de talento musical, de Seashore (*Seashore Test of Musical Talent*) e incluida de manera subsecuente en la batería original de Halstead (1947a), aquí, la tarea del sujeto es discriminar entre pares de fragmentos musicales iguales y diferentes. La dificultad en esta tarea ha sido asociada con daño en el lóbulo temporal derecho del cerebro (Milner, 1971).

Percepción de sonidos del habla

Esta prueba consiste en 60 palabras sin significado, aplicadas mediante una cinta de audio ajustada al volumen preferido del examinado. La tarea consiste en discriminar una sílaba hablada, seleccionando entre cuatro alternativas que se presentan en un formato impreso. El desempeño en esta subprueba está relacionado con el funcionamiento del hemisferio izquierdo.

Prueba rítmica de dedos

Denominada originalmente "prueba de oscilación de los dedos", esta prueba de destreza manual mide la velocidad del golpeteo con el dedo índice de cada mano sobre una tecla. El número de golpes de cada mano se cuenta con la ayuda de un contador automático a lo largo de cinco ensayos consecutivos de 10 segundos, con un breve periodo de descanso entre ensayos. La calificación total en esta subprueba representa el promedio de los cinco ensayos con cada mano. Una calificación normal típica es aproximadamente de 50 golpes por 10 segundos para la mano dominante y 45 golpes para la mano no dominante (se espera una tasa de rapidez 10% mayor con la mano dominante). Las lesiones corticales pueden afectar de manera diferencial la tasa de golpeteo con los dedos de ambas manos.

Sentido del tiempo

El examinado observa las manecillas de un reloj mientras avanzan sobre la carátula y después tiene la tarea de reproducir ese movimiento luego de haberlo visto. Esta prueba detecta la habilidad viso-motora al igual que la capacidad para estimar el paso del tiempo.

Otras pruebas

En la batería se incluye también una Prueba de seguir una pista (véase la figura 14-4), en la que la tarea del individuo examinado es conectar de manera correcta círculos con números y letras. Asimismo, se incluye una prueba de fuerza en la mano; la fuerza de agarre se puede medir de manera informal a través de un apretón de manos y de modo más científico por medio de un dinamómetro (véase el capítulo 3, figura 3-1).

Para determinar cuál ojo es el preferido, u ojo dominante, se aplica la Prueba ABC de predominio ocular de Miles (*Miles ABC Test of Ocular Dominance*). También se recomienda la aplicación de una escala de inteligencia de Wechsler, el MMPI (útil en este contexto para aclarar las dudas acerca del posible origen funcional de un comportamiento anormal) y una prueba de detección de afasia, adaptada a partir del trabajo de Halstead y Wepman (1959).

También se pueden incluir diversas pruebas sensorio-motrices. Una prueba llamada prueba de fusión crítica de destellos alguna vez formó parte de esta batería, pero la mayoría de los examinadores la han discontinuado. Si usted ha estado alguna vez en una discoteca y ha observado cómo funciona una luz estroboscópica, podrá entender lo que significa hablar de destellos de luz. En la prueba de fusión de destellos, se enciende un aparato que emite destellos de luz a diversas velocidades y al examinado se le pide ajustar la tasa de los destellos hasta que la luz parezca estar fija o fusionada.

neuropsicológico. Para establecer el punto de corte se utilizaron los datos de más de 10000 pacientes en la muestra de estandarización. También se ha publicado información normativa respecto a poblaciones especiales. Los factores culturales también deben considerarse cuando se aplica esta batería (Evans *et al.*, 2000).

Realizar estudios de confiabilidad de prueba y postprueba con la H-R es un esfuerzo prohibitivo en vista de la cantidad de tiempo que se requeriría para completar una aplicación de la batería, así como otros factores (como los efectos de la práctica y los efectos de la memoria). No obstante, la prueba en general es considerada confiable. Un creciente conjunto de literaturas confirma la validez del instrumento para diferenciar a los sujetos con daño cerebral de los sujetos no dañados y para ayudar en la elaboración de juicios relacionados con la gravedad de un déficit y su posible localización (Reitan, 1994; Reitan y Wolfson, 2000). La batería también ha sido utilizada para identificar el deterioro neuropsicológico asociado con las incapacidades para el aprendizaje (Batchelor *et al.*, 1990, 1991), así como los déficit cognitivos, perceptivos, motores y conductuales asociados con lesiones neurológicas particulares (Guilmette y Faust, 1991; Guilmette *et al.*, 1990; Heaton *et al.*, 2001).

Otra batería neuropsicológica establecida es la Batería neuropsicológica Luria-Nebraska (*Luria-Nebraska Neuropsychological Battery*, LNNB). Los escritos del neuropsicólogo ruso Aleksandr Luria sirvieron de inspiración para un grupo de pruebas estandarizadas (Christensen, 1975) que subsecuentemente serían revisadas (Golden *et al.*, 1980, 1985) y luego conocidas como la LNNB. En sus diversas formas publicadas, la LNNB contiene escalas clínicas diseñadas para evaluar los procesos y funciones cognitivas. El análisis de las puntuaciones en estas escalas puede conducir a juicios acerca de la existencia de un posible deterioro neuropsicológico y, si es el caso, cuál es el área cerebral afectada. La LNNB requiere alrededor de una tercera parte del tiempo que se necesita para la aplicación de la batería Halstead-Reitan. Sin embargo, al juzgar por el uso de estas pruebas, la Halstead-Reitan sigue siendo la batería preferida de los evaluadores neuropsicológicos experimentados. Una batería de pruebas neuropsicológicas para niños, también derivada en parte en base al trabajo de Luria, es la NEPSY (Korkman *et al.*, 1997) y la inspiración de este instrumento ha sido detallada por su autor principal (Korkman, 1999).

Muchas baterías de pruebas neuropsicológicas publicadas y sin publicar están diseñadas para investigar a profundidad un área del funcionamiento neuropsicológico en lugar de medir un posible déficit conductual en una variedad de áreas. Existen baterías de prueba que se enfocan en problemas visuales, sensoriales, de memoria y de comunicación. El Examen comprensivo de afasia del centro neurosensorial (*Neurosensory Center Comprehensive Examination of Aphasia*, NCCEA) es una batería de pruebas que se enfoca en el déficit de comunicación. La Batería del Instituto Neurológico de Montreal (Montreal Neurological Institute Battery) es particularmente útil para los neuropsicólogos entrenados respecto a la localización de tipos específicos de lesiones. Las Pruebas de integración sensorial del sur de California (*Southern California Sensory Integration Tests*) forman una batería diseñada para evaluar el funcionamiento de integración sensorial y motor en niños de 4 a 9 años de edad.

Una batería neuropsicológica llamada Batería de deterioro grave (*Severe Impairment Battery*, SIB; Saxton *et al.*, 1990) está diseñada para ser utilizada en sujetos con un serio deterioro que de otra manera podrían tener un desempeño cercano al, o en el, límite inferior en las pruebas existentes. La batería se divide en seis subescalas: atención, orientación, lenguaje, memoria, percepción visual y construcción. Otra batería especializada es el Inventario cognoscitivo conductual del conductor (*Cognitive Behavioral Driver's Inventory*) la cual fue diseñada específicamente para ayudar a determinar si los individuos con daño cerebral tienen la capacidad para conducir un vehículo automotor (Lambert y Engum, 1992).

SÓLO PIENSE...

Por un momento, asuma el papel de un neuropsicólogo que pasa la mayor parte de muchos días laborales aplicando una sola batería de pruebas neuropsicológicas a un solo individuo evaluado. ¿Qué le gustaría más de su trabajo? ¿Qué sería lo que menos le gustaría?

SÓLO PIENSE...

El inventario conductual cognitivo del conductor es una batería neuropsicológica diseñada especialmente para ayudar a determinar si la persona evaluada debería conducir un vehículo automotor. ¿Cuál sería otra batería neuropsicológica especializada que necesite ser desarrollada?

Otras herramientas de evaluación en neuropsicología

Quizás los mayores avances en el campo de la evaluación neuropsicológica hayan aparecido en la forma de alta tecnología y esto ha dado lugar a una relación mutuamente benéfica entre los

Auxiliares médicos para el diagnóstico y la evaluación neuropsicológica

Los datos de la evaluación neuropsicológica, combinados con los datos derivados de diversos procedimientos médicos pueden producir, en algunos casos, una comprensión más minuciosa de un problema neurológico. Por ejemplo, ciertos índices conductuales evidentes en las pruebas neuropsicológicas pueden dar por resultado la recomendación de una exploración adicional de un sitio particular del cerebro. Es posible que la sospecha se confirme a través de un procedimiento diagnóstico que proporciona imágenes transversales del sitio y que revela con claridad la presencia de lesiones.

El neuropsicólogo entrenado está familiarizado, a través de su práctica, con el conjunto de procedimientos médicos que pueden requerirse cuando se estudian problemas neuropsicológicos.

Aquí examinaremos más de cerca una muestra de estos procedimientos. Comencemos con una breve descripción del procedimiento médico y del aparato que quizá sea el más familiar para nosotros, ya sea por haberlo experimentado en el sillón del dentista o en otros sitios: la radiografía.

Para el radiólogo, las diversas sombras en una fotografía de rayos X transmiten información acerca de la densidad correspondiente de los tejidos a través de los cuales han pasado estos rayos. Con las radiografías frontales, laterales, traseras y de otro tipo tomadas al cerebro y la médula espinal, frecuentemente se pueden hacer diagnósticos de tumores, lesiones, infecciones y otras anormalidades. Existen muchos y diferentes tipos de procedimientos neurorradiológicos. Éstos incluyen desde la radiografía simple de cráneo hasta procedimientos más complicados. Uno de éstos es la **angiografía cerebral**, que implica una inyección de un elemento rastreador dentro del torrente sanguíneo antes de tomar una radiografía del área cerebral.

Quizás usted haya escuchado o leído acerca de otro procedimiento de imagen, el rastreo **TAC (tomografía axial computarizada)**, también conocido como "TC" (figura 1). La TAC es superior a las radiografías tradicionales debido a que es posible representar las estructuras cerebrales en una serie sistemática de vistas tridimensionales, una característica sumamente importante para evaluar padecimientos como las anormalidades espinales. El **rastreo TEP (tomografía por emisión de positrones)** es una herramienta de la medicina nuclear particularmente útil para diagnosticar lesiones bioquímicas en el cerebro. La **TCEFU (tomografía computarizada por la emisión de un fotón único)**, relacionada conceptualmente con la TEP, es una tecnología




Figura 1

La TC es útil para determinar la localización exacta de tumores, quistes, tejido degenerativo u otras anormalidades, y su uso puede eliminar la necesidad de cirugía exploratoria o de dolorosos procedimientos diagnósticos utilizados en los estudios de cerebro y la médula espinal.

que registra el curso de un líquido rastreador radioactivo (yodo), que produce fotografías excepcionalmente claras de los órganos y tejidos (figura 2).

El término *rastreo de isótopos radioactivos* o, simplemente, **rastreo cerebral**, describe un procedimiento que también implica la introducción de un material radioactivo en el cerebro a través de una inyección. Después se explora la superficie craneal con una cámara especial para seguir el trayecto del material. También se observan las alteraciones en la irrigación de sangre al cerebro, incluyendo las alteraciones que pueden estar asociadas con enfermedades, como tumores.

El **electroencefalógrafo (EEG)** es una máquina que mide la actividad eléctrica del cerebro por medio de electrodos adheridos al cuero cabelludo. La actividad EEG variará en función de la edad, el nivel de excitación (alerta, sopor, sueño) y otras variables, además de las anormalidades cerebrales. La electroencefalografía es un procedimiento seguro, indoloro y no intrusivo que puede tener un valor significativo para el diagnóstico y tratamiento de los trastornos convulsivos y de otro tipo.

La información acerca del daño a los nervios y las anormalidades relacionadas se puede obtener a través de la estimulación eléctrica directa de los nervios y del análisis del movimiento o falta del mismo en el tejido muscular



Figura 2

La tecnología de TCEFU ha resultado ser prometedora para la valoración de padecimientos como la enfermedad vascular cerebral, enfermedad de Alzheimer y trastornos convulsivos.

correspondiente. El **electromiógrafo (EMG)** es una máquina que registra la actividad eléctrica de los músculos a través de un electrodo insertado directamente en el músculo. Las anomalías encontradas en el EMG pueden ser utilizadas con otros datos clínicos y antecedentes como un auxiliar para hacer el diagnóstico final. El **ecoencefalógrafo** es una máquina que transforma la energía eléctrica en energía de sonido (sónica). La energía sónica ("ecos") que atraviesa el área de tejido que se está analizando se convierte de nuevo en energía eléctrica y se registra en una impresión. Esta impresión es utilizada como un auxiliar en otros procedimientos para ayudar a quien elabora el diagnóstico a determinar la naturaleza y localización de ciertos tipos de lesiones en el cerebro. Las ondas de radio, en combinación con un campo magnético, también pueden ser utilizadas para crear imágenes anatómicas detalladas, como se ilustra en la figura 3.

Los análisis de laboratorio de los líquidos corporales como la sangre y la orina pueden proporcionar indicios no sólo de problemas neurológicos, sino también de otros problemas




Figura 3

El sistema de resonancia magnética utiliza un campo magnético y ondas de radio para crear imágenes detalladas del cuerpo. Éstas y otras técnicas relacionadas de imagen pueden emplearse no sólo en el estudio del funcionamiento neuropsicológico, sino también en el estudio del comportamiento anormal; véase, por ejemplo, el estudio de Kellner et al. (1991) sobre el trastorno obsesivo-compulsivo.

físicos que tengan la apariencia de problemas neurológicos. El examen del líquido cefalorraquídeo en busca de sangre y otras anomalías puede proporcionar datos diagnósticos esenciales. La muestra de líquido se obtiene a través de un procedimiento denominado **punción lumbar** o punción espinal. Este procedimiento implica la inserción de una aguja especial dentro del espacio más amplio entre vértebras después de haber aplicado un anestésico local. Además de proporcionar información relativa a la normalidad química del líquido, la prueba permite que el experto estime la normalidad de la presión intracraneal.

En una labor conjunta, los neuropsicólogos y los profesionales médicos pueden ayudar a mejorar la calidad de vida de muchas personas con problemas neurológicos.

psicólogos y el personal médico. Por ejemplo, los avances recientes en la investigación genética han conducido a la estimulante y sugerente evidencia respecto a los orígenes del autismo. Las mutaciones en un gen esencial para el desarrollo del cerebro pueden pronosticar el principio de este trastorno debilitante del desarrollo (O'Connor, 2001). Más allá del nivel de los genes, se han logrado más prodigios “cotidianos” en el diagnóstico y tratamiento con el uso de la tecnología de imágenes y la tecnología relacionada, lo cual se analiza en el apartado *Psicometría cotidiana* de este capítulo.

Las herramientas de la evaluación neuropsicológica, semejantes en gran medida a otros instrumentos de medición utilizados por los psicólogos, pueden ayudar a mejorar la calidad de vida de las personas que son evaluadas con ellas. En el siguiente capítulo examinaremos la manera en que las herramientas de evaluación psicológica pueden ser modificadas para adaptarse a las necesidades especiales de las personas con padecimientos discapacitantes. También examinaremos muchos temas relativos a la evaluación de personas con padecimientos discapacitantes, incluyendo cuestiones legales. El capítulo 15 concluye con un provocativo análisis de la discapacidad como un asunto de diversidad.

Autoevaluación

Examine su comprensión de los elementos de este capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaturas:

afagia	función ejecutiva	pruebas motoras
afasia	funcional	pruebas perceptivas-motoras
análisis de patrones	herramientas de evaluación	pruebas perceptuales
angiograma cerebral	neuropsicológica	punción lumbar
antecedentes neuropsicológicos	hitos en el desarrollo	rastreo cerebral
batería fija	lesión	rastreo TAC
batería flexible	memoria declarativa	rastreo TEP
batería neuropsicológica Halstead-Reitan (H-R)	memoria episódica	reactivo de campo de búsqueda
cociente de deterioro	memoria metodológica	reactivo de imágenes absurdas
control contralateral	memoria semántica	reactivo de seguir una pista
daño cerebral	NEPSY	reflejo
daño neurológico	neurología	relaciones entre el cerebro y la conducta
ecoencefalógrafo	neurona	signo ligero
electroencefalógrafo (EEG)	neuropsicología	signo severo
electromiógrafo (EMG)	nombramiento de confrontación	sistema nervioso central
examen físico	orgánico	sistema nervioso periférico
examen neuropsicológico del estado mental	organicidad	TCEFU
examen neuropsicológico físico	procedimientos no intrusivos	
evaluación neuropsicológica	Prueba Gestalt Visual-Motora de Bender	
	pruebas de la memoria	

Un vistazo a la red

Consulte los siguientes sitios de la red para mayor información sobre los temas examinados en este capítulo.

APA División 40 (Neuropsicología)

www.div40.org

www.apa.org/about/division/div40.html

Batería Neuropsicológica Halstead-Reitan

<http://web.lemoyne.edu/~hevern/psy448/448document/hrmtb.html>

La Torre de Hanoi (interactivo)

www.mazeworks.com/hanoi

Prueba de clasificación de tarjetas de Wisconsin

www.tvtc.com/publications/testprod.asp?testid=38

Prueba Bender Gestalt-II

www.riverpub.com/products/clinical/bg/home.html

<http://assess.nelson.com/test-ind/bender.html>

www.pearsonassessments.com/tests/bender.htm

WMS-III

http://marketplace.psychcorp.com/PsychCorp.com/cultures/en-Us/Products/Product+Detail.htm?CS_ProductID=015-8981-28&CS_Category=Adults&Cs_Catalog=TPC-USCatalog

Minexamen de la condición mental mínima

www.minimental.com

Prueba de discriminación auditiva

<http://courses.smsu.edu/jjm095f/Red/WepSPPT41AX.PDF>

Sistema nervioso

<http://faculty.washington.edu/chudler/introb.html>

<http://faculty.washington.edu/chidler/lobe.html>

Hitos en el desarrollo

www.med.umich.edu/1libr/yourchild/devmile.htm

Afasia

www.aphasia.org

Aspectos neuropsicológicos de la capacidad para conducir vehículos automotores

www.nanonline.org/nandistance/mtbi/modules/suppl/driving.html

Aspectos neuropsicológicos de la memoria

www.crossroadsinstitute.org/memory.html

Evaluación a personas con discapacidad

Después de que el huracán Andrew azotó el sur de Florida, dejó tras de sí muerte, destrucción y una gran cantidad de angustia emocional. Alguien que quedó traumatizado por este desastre natural fue Neil Tugg. Tugg era un hombre de 40 años de edad, sordo, que recibía orientación por parte del Departamento de Servicios para Sordos (Deaf Services Bureau, DSB) con una orientadora experta en el lenguaje de señas estadounidense (American Sign Language, ASL). Tugg aún requería de asesoría después de que el contrato del estado de Florida con el DSB había expirado, así que fue remitido con un nuevo proveedor. Este nuevo proveedor no contaba con un orientador experto en ASL, por lo que se tuvo que recurrir a un intérprete. Basándose en la Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades (*Americans with Disabilities Act*, ADA), Tugg entabló una demanda, afirmando que “la presencia de un intérprete en un medio terapéutico [lo privaba] de la igualdad de oportunidades para obtener los mismos resultados que un individuo con capacidad auditiva” (*Tugg vs Towey*, 1994, p. 1001). En la acción legal, los demandantes argumentaron que además —o incluso en lugar de— conceptualizar la sordera como una discapacidad médica, podía ser considerada como una distinción cultural. Además, advirtieron que este grupo culturalmente particular, así como otros grupos culturalmente particulares, podían sufrir estigmatizaciones o prejuicios injustos.

El caso *Tugg* fue adjudicado y tenemos más qué decir sobre el mismo y las cuestiones que suscitó, más adelante en este capítulo. El caso, que de manera racional podemos suponer, es ilustrativo de muchos otros parecidos, es una dramática evidencia de la fuerza con la que están irrumpiendo en los tribunales los reclamos sobre las violaciones a la ADA. También sirve como un punto de partida útil para pensar acerca de cuestiones más amplias respecto a los conceptos de *discapacidad*, los derechos de las personas con discapacidades y, más acorde con el tema de este capítulo, sobre los derechos de las personas con discapacidad ante la evaluación psicológica.

Sinopsis

Hace más de una década se estimaba que uno de cada siete estadounidenses tenía alguna discapacidad que interfería en sus actividades cotidianas (O’Keefe, 1993). En años recientes, la sociedad ha reconocido más que nunca las necesidades especiales de los ciudadanos que enfrentan discapacidades físicas, mentales, o ambas. Los efectos de este reconocimiento, cada vez mayor, son sumamente evidentes en hechos como la colocación de rampas especiales de acceso junto a las escaleras para abordar aviones; autobuses especialmente diseñados y equipados para dar cabida a pasajeros en sillas de ruedas; periódicos, libros y revistas impresos con caracteres grandes para las personas con discapacidades visuales; programas televisivos con subtítulos así como la utilización de señas y pantomima para interpretar los discursos importantes a personas con

Tabla 15-1
Dos paradigmas para la investigación de la discapacidad

Paradigma 1	Paradigma 2
Se basa en el modelo médico de la discapacidad	Se basa en un modelo social o en el nuevo paradigma de discapacidad
Está orientado hacia la patología	Se desplaza hacia una perspectiva sistemática y social
Considera que las diferencias ocasionadas por la discapacidad son deficiencias o aberraciones en el desarrollo	Adopta un enfoque de un ciclo de vida
Generalmente es de corte transversal	Utiliza el concepto de “respuesta” a la discapacidad como un proceso cambiante
Considera a las personas con discapacidades y a sus familias en alto riesgo de dificultades	Promueve la salud y la capacidad de recuperación
Se enfoca de manera primordial en las características intrapsíquicas personales o en las variables interpersonales	Normalmente se enfoca en las fases crónicas de la discapacidad
Tiende a enfocarse en las fases agudas al inicio de la discapacidad o en su exacerbación	Es más probable encontrarlo en ambientes comunitarios
Es más probable hallarlo en escenarios de internamiento o tratamiento	Valora la historia y cultura de la discapacidad
Utiliza el concepto de “ajuste” o “adaptación” a la discapacidad	Incorpora a quienes son investigados en el proceso de investigación
Utiliza normas de comparación basadas en individuos sanos	Considera que los principales problemas de la discapacidad son sociales, políticos, económicos y legales
Es acerca de, pero rara vez hecho por, personas discapacitadas	Se basa en la creencia de que a las personas con discapacidad se les han negado sus derechos civiles
Perpetúa el modelo nosotros-ellos	Busca la corrección en políticas públicas, legislación y cambios programáticos sistémicos
	De manera general no sólo es acerca de, sino hecho por, personas con discapacidades

Fuente: Olkin y Pledger (2003).

discapacidades auditivas.¹ En general, la tendencia ha sido hacia la modificación de los medios para hacer que los individuos con discapacidades se sientan menos limitados. A esta tendencia, consistente con lo que cada vez con mayor frecuencia se denomina **nuevo paradigma de discapacidad**, también se le conoce como *modelo social de discapacidad* (Pledger, 2003).

Definición de discapacidad

Se pueden distinguir dos paradigmas, o modelos, de discapacidad. El **modelo médico de discapacidad** conceptúa la discapacidad como un padecimiento o deficiencia física que impide la participación en actividades. El **modelo social de discapacidad** incluye una perspectiva médica, pero se enfoca más en el ambiente y en los factores externos al cuerpo respecto a la manera en que se relacionan con la experiencia de la discapacidad. El Departamento de Educación de Estados Unidos (U.S. Department of Education, 2000) describió al nuevo paradigma como “integrador y holístico” y enfocado a “la persona total funcionando en un contexto ambiental” (p. 9). Los aspectos de los dos paradigmas han sido analizados por Gill *et al.* (2003), Tate y Pledger (2003) y Melia *et al.* (2003) . Tal vez la descripción más detallada de ambos paradigmas es la realizada por Olkin y Pledger (2003), en el contexto de la investigación de las discapacidades. Sus puntos se presentan en la tabla 15-1.

SÓLO PIENSE...

¿Qué factores pueden haber contribuido a la necesidad percibida de enfocarse más hacia el contexto total de las discapacidades, en oposición a los aspectos médicos de las mismas?

1. Al igual que la palabra *mimo*, la *pantomima* tiene que ver con la comunicación mediante la gesticulación. De acuerdo a la manera en que se utiliza en el contexto de las pruebas psicológicas, la pantomima es algo que la persona que aplica una prueba a un examinado que esté sordo o con discapacidad auditiva puede hacer como una ayuda para transmitirle el significado de alguna instrucción, pregunta o respuesta.

La *Clasificación internacional de funcionamiento, discapacidad y salud (International Classification of Functioning, Disability and Health)*, publicada por la Organización Mundial de la Salud (2001), toma en cuenta los factores ambientales y contextuales en su definición de discapacidad. Sin embargo, la mayoría de las definiciones de discapacidad que se escriben para su integración a la legislatura en Estados Unidos están más orientadas desde una perspectiva médica que una social.

En 1973, el Congreso de Estados Unidos aprobó la Ley de Rehabilitación (*Rehabilitation Act*), una ley que ha sido llamada la “Declaración de Derechos de los Ciudadanos Discapacitados” porque está dirigida a atender muchas de las necesidades especiales de las personas con discapacidades y penaliza la discriminación laboral, por parte de las agencias del gobierno federal y de entidades que reciben fondos federales, basada en las discapacidades. Esta protección fue ampliada a las personas con discapacidades relacionadas con empresas privadas, por medio de la Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades (ADA) de 1990 (Ley Pública 101-336). También se han otorgado protecciones similares a los niños. En 1975, el Congreso de Estados Unidos aprobó la Ley Pública 94-142, la Ley de Educación para Todos los Niños Discapacitados (*Education for All Handicapped Children Act*), que ordenaba una evaluación educativa adecuada y programas para satisfacer las necesidades de niños discapacitados de 3 a 18 años de edad. Esta ley fue reformada en 1991 (Ley Pública 101-476) para ampliar la categoría de edades cubiertas determinándose desde el momento del nacimiento hasta los 18 años. La enmienda de 1991 a la misma ley (Ley Pública 101-476) especificaba el amplio rango de padecimientos cubiertos por la ley: “discapacidad intelectual, daños auditivos incluyendo la sordera, deficiencias en el habla o en el lenguaje, daños visuales incluyendo la ceguera, trastornos emocionales graves, problemas ortopédicos, autismo, lesiones traumáticas en el cerebro, otras alteraciones de la salud o incapacidades específicas para el aprendizaje” (Sección 101).

Los psicólogos encargados de evaluar a los individuos con esos padecimientos discapacitantes fueron obligados por la ley a “utilizar pruebas y otros materiales de evaluación que hayan sido validados para los propósitos para los que están siendo utilizados” (Departamento de Salud, Educación y Bienestar, 1977a, 1977b), esto en vista de la escasez de pruebas psicológicas estandarizadas con poblaciones discapacitadas.

La Ley de Educación para todos los Niños Discapacitados de 1975 (LP 94-142), fue reformada cerca de 27 años después por la Ley Pública 105-17 (véase *Psicometría cotidiana* en este capítulo). Citada también como Ley de Reformas Educativas de 1997 para Individuos con Discapacidades (*Individuals with Disabilities Education Act Amendments of 1997*, IDEA), esta ley definió los términos *infante o menor de edad con discapacidad* y *niño con discapacidad*. Un **infante o menor de edad con discapacidad** fue definido como

un individuo menor de 3 años de edad que necesite servicios de intervención temprana debido a que el individuo i) experimenta retrasos en el desarrollo, medido de acuerdo a los instrumentos y procedimientos adecuados de diagnóstico en una o más áreas del desarrollo cognoscitivo, del desarrollo físico, del desarrollo de comunicación, del desarrollo social o emocional y del desarrollo de adaptación; o ii) que tenga un diagnóstico físico o un estado mental que conlleven una alta probabilidad de ocasionar un retraso en el desarrollo, y... también puede incluir, a juicio del Estado, menores de edad o infantes en riesgo (p. 108).

El término **infante o menor de edad en riesgo** fue definido por la ley como “un individuo menor de 3 años de edad que esté en riesgo de experimentar un retraso sustancial en su desarrollo si a dicho individuo no le son proporcionados a tiempo servicios de intervención” (p. 106). La IDEA define a un *niño con discapacidad* de dos maneras: una considerando al niño en general; y la otra, sólo a los niños de entre 3 y 9 años de edad. En general, un **niño con discapacidad** se refiere a un niño

con discapacidad intelectual, daños auditivos (incluyendo sordera), deficiencias en el habla o en el lenguaje, daños visuales (incluyendo ceguera), trastornos emocionales graves... problemas ortopédicos, autismo, lesiones traumáticas en el cerebro, otras alteraciones de la salud o incapacidades específicas para el aprendizaje (p. 43).

Para un niño de 3 a 9 años de edad, el término *niño con discapacidad* puede, a juicio del estado o de la agencia educativa local, incluir a un niño que

La Ley Pública 105-17 y el ejercicio profesional cotidiano

La Ley Pública (LP) 105-17 es la Ley de Reformas Educativas de 1997 para los individuos con discapacidades. Esta ley contiene un número de disposiciones relativas al ejercicio cotidiano de los profesionales que tienen la oportunidad de evaluar a niños en edad escolar. Esta ley afecta no sólo la manera en que los niños son evaluados, sino las recomendaciones de intervención hechas como resultado de la evaluación. Las estipulaciones de la LP 105-17 incluyen requisitos relativos a lo siguiente:

- *Un “ambiente menos restrictivo” para el aprendizaje*
“Al máximo grado adecuado, los niños con discapacidades, incluyendo a aquellos niños en instituciones públicas o privadas de cuidado o de otro tipo, serán educados con niños que no tienen discapacidades, y las clases especiales, educación separada, u otra remoción del ambiente educativo habitual de los niños con discapacidades tendrá lugar sólo cuando la naturaleza o gravedad de la discapacidad del niño sea tal que la educación en las clases regulares con el uso de materiales y servicios complementarios no se pueda lograr de manera satisfactoria” (p. 61).
- *Un programa educativo individualizado*
“Un programa educativo individualizado o un plan de servicios familiares individualizado... debe ser desarrollado, estudiado y revisado para cada niño con alguna discapacidad” (p. 61).
- *Materiales de evaluación que sean adecuados culturalmente*
“Los materiales y procedimientos de prueba y evaluación utilizados para los propósitos de evaluación y colocación educativa para niños con discapacidad serán seleccionados y aplicados de tal manera que no sean discriminatorios en el aspecto racial o cultural. Tales materiales o procedimientos serán proporcionados y aplicados en el idioma o modo de comunicación nativo del niño, a menos que sea claro que no es factible hacerlo de esa manera, y ningún procedimiento aislado será el único criterio para determinar el programa educativo apropiado para un niño” (p. 62).
- *Evaluaciones de desempeño establecidas por el estado y por todo un distrito, incluyendo “evaluaciones alternas” cuando sea necesario*
“Los niños con discapacidad serán incluidos en los programas generales de evaluación estatal y de distrito, con las adecuaciones pertinentes, cuando así sea necesario. Según sea conveniente, la agencia educativa estatal o local *i*) desarrollará pautas para la participación de los niños con discapacidad en evaluaciones alternas para aquellos niños que no puedan participar en los programas de evaluación estatales y de distrito, y *ii*) desarrollará y, a partir del 1 de julio de 2000, llevará a cabo dichas evaluaciones alternas” (p. 67)
- *Participación de los padres en la educación del niño, incluyendo el consentimiento paterno para la evaluación*
“La agencia que proponga conducir una evaluación inicial para determinar si el niño califica como niño con discapacidad... deberá obtener el consentimiento informado del progenitor del niño antes de que la evaluación sea realizada. El consentimiento paterno no debe

ser interpretado como el consentimiento para la reubicación con el fin de recibir educación especial y servicios relacionados... Si los padres de ese niño se rehúsan a dar su consentimiento para la evaluación, la agencia puede continuar procurando que se realice dicha evaluación utilizando los procesos de mediación y procedimientos legales establecidos... excepto en la medida en que sean inconsistentes con las leyes Estatales referentes al consentimiento paterno” (p. 81).

- *Manejo de las evaluaciones*
“Al efectuar la evaluación, la agencia educativa local deberá, A) utilizar una variedad de herramientas y estrategias de evaluación para obtener la información pertinente funcional y de desarrollo, incluyendo la información proporcionada por los padres, que pueda ayudar a determinar que el niño es un niño con discapacidad y que el contenido del programa educativo individualizado, incluyendo la información relacionada, permita al niño participar y progresar dentro del plan de estudios general o, en el caso de los niños en edad preescolar, participar en actividades adecuadas; B) no utilizar ningún procedimiento aislado como criterio único para determinar que un niño es un niño con discapacidad o para determinar un programa educativo adecuado, y C) utilizar instrumentos técnicamente sólidos que puedan evaluar la contribución relativa de los factores cognoscitivos o conductuales, además de los factores físicos o de desarrollo... Cada agencia educativa local deberá asegurarse de que A) las pruebas y otros materiales de evaluación utilizados para evaluar al niño bajo esta sección *i*) sean seleccionados y aplicados de modo que no sean discriminatorios en el aspecto racial o cultural; *ii*) sean proporcionados y aplicados en el idioma u otro modo de comunicación nativa del niño, a menos que sea claro que no es factible hacerlo de ese modo; y B) cualquier prueba estandarizada que sea aplicada al niño *i*) haya sido validada para el propósito específico para el cual sea utilizada; *ii*) sea aplicada por personal capacitado y con conocimientos, y *iii*) sea aplicada de acuerdo con cualesquiera instrucciones proporcionadas por el fabricante de esa prueba; C) el niño sea evaluado en todas las áreas de supuesta discapacidad, y D) sean proporcionadas las herramientas y estrategias de evaluación que faciliten información pertinente que ayude de manera directa a las personas para determinar las necesidades educativas del niño” (pp. 81-82)
- *Revisión de los datos existentes*
“Como parte de una evaluación inicial (si es adecuado) y como parte de cualquier reevaluación... los profesionales calificados, según sea apropiado, A) revisarán los datos de evaluación existentes del niño, incluyendo las evaluaciones e información proporcionadas por los padres del niño, las evaluaciones y observaciones actuales basadas en su desempeño dentro del salón de clases y las observaciones del maestro y de otros proveedores de servicio relacionados y B) con base en esa revisión y en la información proporcionada por los padres, identificarán los datos adicionales, si es el caso, que sean necesarios para determinar *i*) si el niño presenta una categoría específica de discapacidad, como lo describe la sección 602(3) o, en el caso de una reevaluación al niño, si el niño continúa teniendo esa discapacidad;

(continúa)

La Ley Pública 105-17 y el ejercicio profesional cotidiano (continuación)

ii) los niveles actuales de desempeño y necesidades educativas especiales del niño; iii) si el niño necesita educación especial y servicios relacionados o, en el caso de la reevaluación del niño, si continúa necesitando educación especial y servicios relacionados, y iv) si son necesarias cualesquiera adiciones o modificaciones a la educación especial y servicios relacionados para permitir que el niño satisfaga las metas anuales mensurables especificadas en el programa educativo individualizado y que participe, según sea adecuado, en el plan de estudios general” (pp. 82-83).

■ *Resolución de la elegibilidad*

“La resolución acerca de si el niño es un niño con discapacidad... deberá ser realizada por un equipo de profesionales calificados y por los padres del niño... Para efectuar la resolución de elegibilidad... el niño no deberá ser considerado como un niño con discapacidad si el factor determinante para esa resolución es la falta de capacitación en la lectura o en matemáticas o un dominio limitado de su idioma” (p. 82).

■ *Evaluación de infantes y menores de edad con discapacidad y desarrollo de planes individualizados de servicios familiares*

“Un sistema en todo el estado... deberá proporcionar, como mínimo, a cada infante o menor de edad con alguna discapacidad... 1) una evaluación multidisciplinaria de las fortalezas y necesidades únicas del infante o menor de edad y la identificación de los apoyos, adecuaciones y servicios necesarios para satisfacer esas necesidades; 2) una evaluación de los recursos dirigida a la familia en cuanto a prioridades y preocupaciones familiares y la identificación de los apoyos y servicios necesarios para enriquecer la capacidad de ésta para satisfacer las necesidades de desarrollo del infante o menor de edad, y 3) un plan individualizado de servicios familiares por escrito, desarrollado por un equipo multidisciplinario que incluya a los padres, como lo requiere la subsección e). b) Revisión periódica. El plan individualizado de servicios familiares deberá ser evaluado una vez al año y se deberá realizar una revisión al plan con intervalos de 6 meses (o con mayor frecuencia cuando sea apropiado en base a las necesidades del infante o menor

de edad y de la familia). c) Prontitud después de la evaluación. El plan individualizado de servicios familiares deberá ser desarrollado dentro de un tiempo razonable después de que la evaluación requerida por la subsección a) 1) se haya completado. Con el consentimiento de los padres, se pueden comenzar los servicios de intervención oportuna antes de finalizar la evaluación. d) Contenido del plan. El plan individualizado de servicios familiares deberá presentarse por escrito y contendrá 1) un informe del nivel actual del infante o menor de edad, con base en criterios objetivos, respecto a su desarrollo físico, desarrollo cognoscitivo, desarrollo de comunicación, desarrollo emocional o social y desarrollo de adaptación; 2) un informe de los recursos, prioridades y preocupaciones de la familia relacionados con el mejoramiento del desarrollo del infante o menor de edad con discapacidad; 3) un informe de los principales resultados que se espera sean logrados por el infante o menor de edad y la familia, así como los criterios, procedimientos y periodos utilizados para determinar el grado en el que se está progresando para lograr los resultados y, si son necesarias algunas modificaciones o revisiones a los resultados o servicios; 4) un informe de los servicios de intervención oportuna necesarios para satisfacer las necesidades únicas del infante o menor de edad y de la familia, incluyendo la frecuencia, intensidad y método de provisión de servicios; 5) un informe de los medios naturales en los que deberán proporcionarse de manera adecuada los servicios de intervención oportuna, incluyendo una justificación de la medida, si la hay, en la que los servicios no serán proporcionados en un medio natural; 6) las fechas proyectadas para el inicio de los servicios y la duración anticipada de los mismos; 7) la identificación del coordinador del servicio a partir de la profesión más inmediatamente relacionada con las necesidades especiales del infante o menor de edad y de la familia (o quien de otro modo esté calificado para llevar a cabo todas las responsabilidades aplicables bajo este apartado) quien será el responsable de la implementación del plan y coordinación con otras agencias y personas, y 8) los pasos a seguir para apoyar la transición del infante con discapacidad a la educación preescolar o a otros servicios adecuados” (pp. 111-112).

experimente retraso en el desarrollo, como es definido por el Estado y medido de acuerdo con los instrumentos y procedimientos adecuados de diagnóstico, en una o más de las siguientes áreas: desarrollo físico, desarrollo cognoscitivo, desarrollo de comunicación, desarrollo emocional o social, o desarrollo de adaptación (p. 43).

Después de haber leído estas definiciones, así como la sección *Psicometría Cotidiana* de este capítulo, usted puede haber inferido que lo que constituye una discapacidad es una cuestión propiamente definida. Sin embargo, en la práctica, la aplicación de esas definiciones puede no ser tan directa. La *discapacidad* en sí ha sido definida de diferentes maneras (Walkup, 2000), y las legislaciones federales han dado a los estados un considerable margen de flexibilidad para definir

quién está discapacitado y quien puede ser autorizado para la obtención de servicios. Una fuente de este margen de flexibilidad es el término *retraso en el desarrollo*, que puede ser definido de distintas maneras por los diferentes estados. Nosotros definimos **retraso en el desarrollo** como el progreso más lento de lo esperado, por lo general sobre la base de las normas de edad, respecto a la manifestación física, cognoscitiva, social, emocional, de adaptación o de la expresión relacionada con la comunicación de la capacidad o potencial propio.

Aún con las definiciones legales correctas, las personas razonables, así como los profesionales experimentados pueden diferir en cuanto a si un individuo realmente cabe en una categoría diagnóstica. El proceso de realizar determinaciones oficiales respecto a quién necesita servicios adicionales en el salón de clases o arreglos especiales en el sitio de trabajo puede, en ocasiones, ser fuente de acalorados debates.

Definición de discapacidad en la escuela y en otros medios En la práctica cotidiana, la determinación de si un estudiante debe ser considerado discapacitado y por tanto con derecho a recibir servicios especiales la realiza un comité multidisciplinario, a menudo con la participación de los padres. En los casos evidentes de discapacidad (como es el caso de la ceguera, sordera y demás), todas las partes tienden a estar de acuerdo en la evaluación así como en los planes de intervención. Sin embargo, también se presentan ante los comités muchos casos limítrofes. Con frecuencia, estos casos implican retrasos leves en el desarrollo, cuya importancia es tema de discusión. En ocasiones, los profesionales no concuerdan entre sí acerca de la medida de la discapacidad y si se requiere o no de servicios especiales. Por ejemplo, en base a los mismos datos acerca de un niño descrito por un maestro como hiperactivo e impulsivo, algunos profesionales podrían ver una efusividad excesiva (y, por tanto, ninguna necesidad de intervención), mientras que otros profesionales podrían diagnosticar un trastorno por déficit de atención y considerar la necesidad de medicar al niño y de incluirlo en un programa bien estructurado para modificar su conducta.

Más allá de los desacuerdos entre los profesionales e independientemente del resultado de una audiencia del comité, algunos padres desean que sus hijos sean reconocidos como discapacitados para que puedan obtener servicios especiales. Por otra parte, algunos padres, tal vez a causa del temor de que su hijo sea estigmatizado, no quieren que éste sea etiquetado, por lo que rechazan las recomendaciones del comité para los servicios especiales. Es posible que surjan desacuerdos entre profesionales, padres y otras personas respecto a la decisión de proporcionar servicios especiales como resultado del diferente énfasis que se le da a los hechos del caso. Por esta razón, aun cuando haya una aceptación indiscutible de los hechos por todas las partes involucradas, en lo privado, los miembros individuales del comité y los padres pueden darle un énfasis y peso diferente a ciertos hechos. En consecuencia se deja abierta la posibilidad de que surjan opiniones y conclusiones conflictivas.

Las organizaciones profesionales, las agencias estatales y locales, los profesionales involucrados en la evaluación e intervención, y los miembros de un grupo de individuos con una particular discapacidad pueden tener sus propias ideas acerca de la definición, la evaluación y la intervención. Por ejemplo, de manera consistente con el nuevo paradigma, muchas personas sordas han empezado a considerar que la sordera no es una discapacidad sino una cultura diferente dentro de la cultura mayoritaria. En este contexto, la cultura de la Sordera (con S mayúscula) se vuelve una cuestión de diversidad y no de discapacidad.

La discapacidad intelectual es otro estado que ha tenido una historia tormentosa respecto a su definición, evaluación y clasificación (Baumeister y Muma, 1975; Lowitzer *et al.*, 1987; Roszkowski y Spreat, 1981; Taylor, 1980; Utley *et al.*, 1987; Wilson y Spitzer, 1969). Incluso hoy día, los expertos están divididos respecto a la medida en que el sistema de clasificación de la Asociación Estadounidense de Retardo Mental (American Association on Mental Retardation, AAMR) recurre a los valores de la ciencia y del profesionalismo en contra de la recomendación y el consumismo (MacMillan *et al.*, 1995).

Otra cuestión sobre la definición, que no se atiende en la LP 105-17, tiene que ver con lo que se denomina *discapacidad funcional*. Una **discapacidad funcional** puede definirse como una

SÓLO PIENSE...

Suponga que los padres y el personal escolar en una audiencia de comité realmente están intentando de manera sincera atender a los principales intereses del niño. ¿Qué factores podrían desviar tales esfuerzos?

condición en la que la capacidad propia para desempeñarse de alguna manera característica en sentido físico, social, o de otro tipo —es decir, la capacidad personal para funcionar— ha sido trastornada. Las medidas de discapacidad funcional comenzaron a aparecer por primera vez en la década de 1930, primordialmente con el propósito de determinar las compensaciones por reclamos de accidentes y lesiones (McDowell y Newell, 1987). Desde esa época, el término *discapacidad funcional* y un término relacionado, *evaluación funcional*, han sido aplicados en una categoría de contextos cada vez más amplia (Bombadier y Tugwell, 1987; Feinstein *et al.*, 1986; Granger y Gresham, 1984; Halpern y Fuherer, 1984; Slater *et al.*, 1974; Spiegel *et al.*, 1988).

Aunque el término *discapacidad funcional* fue aplicado alguna vez de manera primordial a cuestiones relacionadas con la habilidad propia para ganarse la vida, ahora se utiliza en diversos contextos que van desde las labores domésticas hasta la recreación. Por ejemplo, podríamos hablar de una “discapacidad funcional para la interacción social” o de una “discapacidad para la comunicación”.

Como es utilizado para referirse a los trastornos de la infancia, podemos referirnos a una “discapacidad funcional en el hogar” o en la escuela (Walker y Greene, 1991).² Han sido desarrolladas diversas pruebas y procedimientos de medición para evaluar la discapacidad funcional en diferentes contextos (por ejemplo, véase Brady y Halle, 1997; Desrochers *et al.*, 1997; Neath *et al.*, 1997).

¿Hasta qué grado pueden considerarse como discapacidades *verdaderas* las discapacidades funcionales? ¿En qué medida requieren las escuelas proporcionar servicios a las personas con discapacidades funcionales?

¿En qué medida deben hacerse adaptaciones en las evaluaciones y en otros servicios en beneficio de personas con discapacidades funcionales? Estas preguntas son tema de debate académico entre los profesionales de la evaluación. En teoría, la legislación futura, los reglamentos administrativos y los fallos judiciales proporcionarán pautas más específicas para la evaluación e intervención de lo que se consideran discapacidades funcionales.

SÓLO PIENSE...

Un psicólogo empleado como evaluador padece de una discapacidad funcional en el trabajo. ¿De qué maneras se podría manifestar esta discapacidad?

Evaluación alterna: algunas cuestiones La LP 105-17 contiene una orden general para el desarrollo e implementación de programas de evaluación alterna para niños que, a causa de una discapacidad, no podrían participar en las evaluaciones estatales y de distrito de otra manera. La ley dejó abierta la definición de *evaluación alterna*, así como otras muchas cuestiones relacionadas con la definición, los procedimientos y la interpretación. Se dejó al juicio de los estados, los distritos escolares locales o ambos, determinar quiénes necesitan evaluaciones alternas, cómo deben llevarse a cabo tales evaluaciones y cómo deben derivarse inferencias significativas de los datos obtenidos a través del proceso.

De manera particular, la evaluación alterna se lleva a cabo por medio de cierta **adaptación** hecha para el evaluado. El verbo *adaptar* puede definirse como “acomodar, ajustar o adecuar”. En el contexto de la vida cotidiana, todos estamos familiarizados con los muchos y diversos ejemplos de adaptación. Los autobuses adaptados con rampas descendentes para que puedan ser abordados por personas en sillas de ruedas y los botones codificados en el sistema Braille son dos de muchos ejemplos de este tipo. En el contexto de las pruebas y evaluaciones psicológicas, existen diferentes maneras en que se pueden hacer adaptaciones para las personas discapacitadas. La adaptación puede tomar la forma de una modificación en la manera en que se presenta la prueba o en la forma en que el evaluado responde a ella. Adaptación puede significar que una prueba o un procedimiento de medición es sustituido por otro. La adaptación puede presentarse mediante la ampliación de los límites de tiempo o un cambio en el medio físico o interpersonal en el que la prueba será aplicada. Observemos más de cerca estos métodos de adaptación, así como algunas consideraciones generales relacionadas con la idoneidad de diversos métodos para los miembros de diferentes poblaciones.

2. Walker y Greene (1991) describieron el desarrollo del Inventario de discapacidad funcional (*Functional Disability Inventory*), una escala para medir la discapacidad funcional en contextos relativos a la infancia, incluyendo el hogar, la escuela y la comunidad. Esta herramienta está disponible tanto en formato de autodescripción como de informe parental.

Evaluación y adaptación

Las personas con discapacidad son evaluadas exactamente por las mismas razones que las personas sin discapacidad: para obtener un empleo, para obtener una certificación profesional, para detectar alguna psicopatología, la lista continúa. Las personas con discapacidad también pueden ser evaluadas por otras razones. Pueden ser evaluadas para valorar el grado en que su discapacidad afecta su habilidad para llevar a cabo ciertas actividades en algún área de la vida cotidiana. Posiblemente en combinación con valoraciones diagnósticas, una evaluación puede efectuarse con el propósito de determinar la idoneidad de diversas intervenciones que varían desde el tratamiento hasta servicios especiales.

Dependiendo de la naturaleza de la discapacidad de una persona y de otros factores, es posible que se necesiten hacer modificaciones a una prueba (o procedimiento de medición) para que la evaluación pueda realizarse. Estas adaptaciones pueden hacerse de formas diversas. Un tipo general de adaptación tiene que ver con la *forma en que la prueba es presentada al examinado*. ¿En qué manera se ha modificado la prueba de su forma original? Por ejemplo, es posible que una prueba escrita sea modificada para su aplicación a una persona con discapacidad visual por medio de un aumento en el tamaño del tipo de letra. Los límites de tiempo en una prueba de velocidad pueden ampliarse o eliminarse cuando la discapacidad del examinado afecte su capacidad para concentrarse, para moverse con velocidad o para responder de algún otro modo dentro del límite de tiempo indicado por la prueba. Una prueba podría tener que abreviarse o, en algunos casos, aplicarla durante el curso de varias sesiones. Dependiendo de la naturaleza de la discapacidad del examinado, tal vez sea necesario eliminar algunas tareas de una prueba que se componga de diversas subpruebas. Por ejemplo, considere una situación en la que un individuo que tiene una discapacidad motora delicada es evaluado mediante una prueba de capacidad cognoscitiva. La prueba incluye una subprueba que requiere manipular algunos cubos. El evaluador podría omitir la subprueba de diseño con cubos, y/o sustituirla por una prueba opcional que no dependa de la coordinación motora delicada. Luego, se podría realizar un cálculo de la capacidad cognoscitiva a partir de los datos de las pruebas restantes.

Otro tipo general de adaptación está relacionado con la *forma en que se obtienen las respuestas a la prueba*. ¿De qué manera se ha modificado el formato de respuesta para los propósitos de adaptación? Por ejemplo, a una persona con deficiencias en el habla se le podría permitir, a manera de adaptación, que dé por escrito sus respuestas a un examen que en una situación normal sería aplicado en forma oral. Las adaptaciones para estudiantes con discapacidad para el aprendizaje podrían consistir en permitirles que lean las preguntas de la prueba en voz alta (Fuchs *et al.*, 2000).

Las *modificaciones al ambiente físico en el que la prueba es efectuada* es otro tipo más de adaptación. ¿Qué cambios son necesarios en el lugar o escenario de la prueba? Por ejemplo, las pruebas estandarizadas que por lo general son aplicadas en una ubicación central para aplicaciones grupales ocasionalmente pueden aplicarse de manera individual en el hogar de las personas discapacitadas. Un individuo extremadamente obeso puede requerir una adaptación en la forma de mobiliario especial para tomar la prueba. Para un individuo con una deficiencia visual, puede requerirse una iluminación especial.

Otra posibilidad son las *modificaciones al ambiente interpersonal en el que se lleva a cabo la prueba*. Más allá del ambiente físico, el ambiente interpersonal también puede requerir de alguna modificación. De manera habitual, los examinados individuales acuden a los lugares de prueba sin ser acompañados. Sin embargo, dependiendo de la naturaleza de la discapacidad de la persona, durante la evaluación podrían estar presentes un ayudante, un intérprete o incluso un perro guía.

Las demandas de una situación específica pueden requerir que una prueba sea sustituida por otra. Por ejemplo, un niño pequeño en edad preescolar, o escolar, que padezca de una parálisis cerebral grave no tendría la capacidad para ser valorado por una deficiencia cognoscitiva con alguno de los instrumentos comunes utilizados para ese propósito. Como alternativa, podría utilizarse una prueba como la Prueba de vocabulario en imágenes, de Peabody (*Peabody Picture Vocabulary Test*, PPVT-III; Dunn y Dunn,

SÓLO PIENSE...

¿Qué tipos de discapacidad podrían requerir de modificaciones verdaderamente especiales en el ambiente interpersonal en el que se realiza una prueba?

1997) ya que no requiere que el examinado dé una respuesta oral ni de señalamiento. El niño sencillamente tendría que indicar de alguna manera posible sí o no para indicar al examinador cuál de las cuatro imágenes corresponde a la palabra utilizada por éste último.

En algunas situaciones, con un individuo en particular sería más adecuado utilizar una prueba alternativa debido a la disponibilidad de normas para personas con una discapacidad similar. Sin embargo, en la mayoría de los casos, el juicio clínico es esencial en las decisiones acerca de cuándo y cómo han de llevarse a cabo las adaptaciones. Una persona invidente que por su condición no puede realizar un examen de opción múltiple con papel y lápiz tendrá que tomar la prueba en algún tipo de formato alternativo. Este formato podría ser una aplicación con el sistema Braille, una aplicación con papel y lápiz modificada por un tipo de letra de mayor tamaño, una aplicación oral individual, o un formato computarizado con instrucciones aplicadas de manera electrónica (auditiva; respondiendo por medio del teclado). ¿Cuál de estos formatos alternos es el que deberá utilizarse? De manera ideal, esta pregunta no será respondida con base en la conveniencia ni a la disponibilidad de uno u otro formato alternativo, sino más bien en base a la consideración informada de

- los conocimientos del evaluado
- las capacidades del evaluador
- el propósito de la evaluación
- el significado asociado a las calificaciones de la prueba

Capacidades del evaluado ¿Cuál de los diversos medios alternativos de evaluación se adapta mejor a las necesidades y capacidades del evaluado? Los datos de la historia del caso, los registros de evaluaciones previas y entrevistas con amigos, familiares, maestros y otros que conozcan al evaluado pueden proporcionar una abundante y útil información. Además, el evaluador podría

SÓLO PIENSE...

Desde una perspectiva psicométrica, ¿qué desafíos surgen a partir del hecho de que ningún método alternativo de evaluación es la elección correcta para todo mundo?

tener una entrevista previa con el evaluado para averiguar los beneficios y desventajas potenciales de utilizar cualquier medio alternativo disponible de evaluación. Lo que el evaluador no debe hacer es sencillamente suponer que un método alternativo de evaluación en particular es equivalente al método original. Por ejemplo, en el caso de evaluados invidentes, su dominio del sistema Braille o de un teclado puede variar de manera considerable. Además, algunas personas con deficiencias visuales también tienen limitaciones auditivas, con lo que aparecen obstáculos para el uso de métodos que

impliquen una aportación de información auditiva. Ningún método alternativo único de evaluación es la elección conveniente para todo el mundo. Las necesidades y capacidades particulares del evaluado deben ser tomadas en consideración para cada caso individual.

Capacidades del evaluador Al inicio de su carrera, el autor principal (RJC), como parte de su internado en psicología en el Hospital Bellevue de la ciudad de Nueva York, llevó a cabo una rotación en el pabellón infantil. En esa época, el pabellón infantil albergaba a una paciente gravemente discapacitada como resultado de que su madre hubo utilizado talidomida, un medicamento para la fertilidad. Esta paciente no había desarrollado miembros normales y, en lugar de esto, sólo tenía muñones en brazos y piernas. Se deleitaba en disgustar a los nuevos visitantes del pabellón golpeándolos con sus cuatro muñones. En una ocasión, una investigadora visitó el pabellón para realizar una evaluación a esta paciente, entre otros. Tal vez de manera poco sorprendente, la investigadora quedó desconcertada por la apariencia de la paciente con sus miembros deformados y horrorizada al grado de haberse puesto visiblemente nerviosa cuando se enfrentó al ataque más vigoroso, aunque juguetón, de la paciente. Un observador externo no hubiera podido evitar preguntarse si la investigadora lograría recuperarse lo suficiente como para establecer una relación de armonía con la paciente evaluada de modo que pudiera llevar a cabo una valoración significativa.

Describimos esta escena para enfatizar el hecho de que en las evaluaciones que involucran a individuos con discapacidades, el estado mental del evaluador tiene un papel importante. Probablemente a todos nos gustaría pensar que podemos manejar de manera profesional a cualquier evaluado que se nos asigne. Sin embargo, el nivel de comodidad del evaluador en una situación particular

de evaluación puede afectar los resultados. En este contexto, es importante reconocer que algunos evaluadores pueden sentirse extremadamente incómodos en presencia de personas con ciertas discapacidades. Si el evaluado percibe esa incomodidad por parte del evaluador, la relación de trabajo entre ambos se pondrá en peligro, al igual que la validez de cualesquiera de los datos obtenidos. Si los evaluadores tienen alguna preocupación sobre su desempeño en la evaluación de personas con alguna clase de discapacidad, deben exponer de manera franca estas preocupaciones a un supervisor o colega. Se tendrá que establecer un plan de acción que tome en cuenta las necesidades tanto del evaluador como del evaluado. Es posible que el evaluador requiera un entrenamiento adicional antes de llevar a cabo la evaluación, incluyendo una experiencia supervisada con miembros de ciertas poblaciones. De manera alternativa, el evaluador podría encomendar la tarea de evaluación a otro que cuente con mayor capacidad y experiencia con los miembros de una población específica.

Propósito de la evaluación Una adaptación es adecuada en ciertas circunstancias e inapropiada en otras. En general, debemos analizar el propósito de la evaluación y las consecuencias de una adaptación con el propósito de juzgar qué tan apropiado sería llevar a cabo una adaptación para una persona con una discapacidad. Por ejemplo, modificar una prueba escrita de manejo —o una prueba práctica— de modo que una persona invidente pueda ser examinada para que obtenga su licencia de manejo, es a todas luces inapropiado. Por su propia seguridad, así como por la del público en general, está prohibido que los invidentes manejen. Por otra parte, cambiar la forma de la mayoría de otras pruebas escritas para que una persona invidente las pueda tomar es otro asunto completamente diferente. En general, la adaptación es sencillamente una manera de ser coherentes con una política social que promueve y garantiza la igualdad de oportunidades y tratamiento para todos los ciudadanos.

Si una discapacidad en particular puede afectar de manera significativa la capacidad propia de desempeño, por ejemplo, en un ámbito laboral específico, es una cuestión que se debate no sólo en las publicaciones académicas, sino también en las oficinas corporativas y en los tribunales. Una encuesta de políticas de adaptación por estado, encontró que los estados tienden a ofrecer mayores adaptaciones en pruebas con referencia a un criterio que en pruebas con referencia a una norma (Thurlow *et al.*, 2000). Aun cuando todas las partes concuerden en que es apropiado cierto tipo de adaptación, existe la posibilidad de que una parte afirme que una variedad específica de adaptación va demasiado lejos, mientras que la otra parte argumente que no va lo suficiente. En la mediación de estas disputas, los tribunales tienden a examinar qué tan razonable es una adaptación en particular, dadas las circunstancias, incluyendo la naturaleza de los deberes personales, el propósito de la evaluación y las variables relacionadas.

SÓLO PIENSE...

Describe un ejemplo propio de otra situación de evaluación que podría ser una excepción a la regla, en la que no sería prudente llevar a cabo algún tipo de adaptación.

Inferencias realizadas a partir de las calificaciones de la prueba Después de aplicar una prueba estandarizada, el usuario de la prueba revisará los manuales de la misma para encontrar las pautas para interpretar las calificaciones de la prueba. Es en el contexto de los datos normativos que las calificaciones de las pruebas estandarizadas adquieren significado. También es en el contexto de los datos normativos que los usuarios de la prueba pueden hacer inferencias y predicciones razonables a partir de las calificaciones de las pruebas estandarizadas. ¿Pero qué le sucede al significado de una calificación de una prueba estandarizada si dicha prueba no ha sido aplicada en la manera prescrita y estandarizada? Si existen normas publicadas referentes a las modificaciones o abreviaturas realizadas, entonces existe una base sólida para la interpretación de esas calificaciones. Sin embargo, la mayor parte de las veces, cuando una prueba estandarizada es modificada, el significado de la calificación de la prueba puede ser dudoso, en el mejor de los casos. Los usuarios de las pruebas quedan sujetos a sus propios criterios respecto a las interpretaciones que realizan a partir de esos datos.

La interpretación de las calificaciones provenientes de pruebas estandarizadas modificadas es una tarea poco envidiable. El juicio profesional, la experiencia y, con toda franqueza, las conjeturas pueden todas participar en el proceso de derivar inferencias a partir de las calificaciones de pruebas modificadas. No obstante, lo más probable es que las inferencias serán vulnerables a las objeciones legítimas. Por consiguiente, la interpretación de las calificaciones de pruebas

estandarizadas que han sufrido modificaciones no es una tarea para timoratos, inexpertos, ni profesionales que carezcan de antecedentes o entrenamiento para hacer conjeturas documentadas cuando sea necesario.

Una creciente literatura académica se ha enfocado en varios aspectos de la adaptación, que incluyen asuntos relacionados con políticas generales (Burns, 1998; Shriner, 2000; Simpson *et al.*, 1999; Thurlow *et al.*, 2000), métodos de aplicación de pruebas (Calhoon *et al.*, 2000; Danford y Steinfeld, 1999), comparabilidad de calificaciones (Elliott *et al.*, 2001; Johnson, 2000; Pomplun y Omar, 2000, 2001) y documentación (Schulte *et al.*, 2000). Antes de tomar una decisión acerca de una adaptación para cualquier examinado individual, se debe dar la consideración adecuada a las cuestiones referentes a los significados de las calificaciones derivadas de instrumentos modificados y a la validez de las inferencias que pueden hacerse a partir de los datos obtenidos. Después de realizar cualquier adaptación, sería conveniente hacer algún tipo de anotación en el informe respecto a la naturaleza de la modificación de la prueba estandarizada.

Anotación de adaptaciones en el protocolo de registro de la prueba Para los usuarios de pruebas y otros consumidores de datos de evaluación es útil tener conocimiento de la manera en que se ha modificado alguna prueba estandarizada, si es el caso, para su aplicación a personas con discapacidades. Sin embargo, la necesidad de esta información por parte del consumidor debe ser equilibrada en contraste con las políticas sociales y leyes diseñadas para proteger a las personas con discapacidades contra la discriminación. Por tanto, en situaciones de evaluación que impliquen cuestiones laborales, académicas y de otro tipo donde se haya realizado alguna adaptación a causa de la discapacidad de un evaluado, es conveniente hacer una anotación que se limite a la descripción de la adaptación, más que una reseña de la discapacidad del evaluado. Una excepción a esto es la situación de evaluación que esté enfocada de manera específica en la discapacidad del evaluado y que se lleve a cabo con propósitos de diagnóstico o valoración. Otra excepción es el caso donde se sabe que las calificaciones en una modificación específica a una prueba son equivalentes a las calificaciones de la versión no modificada. En ese caso, no es necesario reportar los detalles de la modificación. Por supuesto, una excepción más es en el caso particular en que esa anotación esté prohibida por la ley o que sea poco recomendable de acuerdo a las normas de una profesión.

En ausencia de leyes, reglamentos o estándares profesionales en contra, parece razonable

SÓLO PIENSE...

Formule un argumento que se oponga a la redacción de un apéndice de adaptación para incluirlo en un informe psicológico.

redactar un apéndice a los informes de evaluación psicológica en que se especifique que una prueba o procedimiento de medición estandarizados fueron modificados de algún modo con el fin de adaptarlos a las necesidades especiales del evaluado. El apéndice deberá describir la naturaleza del cambio realizado, el razonamiento para dicho cambio, y cualquier otra información relativa a los usuarios de la prueba que hagan inferencias a partir de las calificaciones de la misma. El apéndice de adaptación que estamos pro-

poniendo, que se ilustra en la tabla 15-2, contiene tres encabezados: naturaleza de la adaptación, razonamiento para la adaptación, y comentarios adicionales. El apéndice debe ser anexado para que sea parte del informe psicológico.

Discapacidad, evaluación y el sitio de trabajo

La Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades de 1990 (ADA) ordenó que los empleadores con 15 o más trabajadores no discriminaran a las personas con discapacidades en las contrataciones, el acceso a las instalaciones y en los términos, condiciones y prestaciones laborales. Como lo define la ADA, una **discapacidad** es un deterioro físico o mental que limita de manera sustancial una o más de las principales actividades vitales del individuo. Cualquier trastorno mental, como el retardo mental, el síndrome orgánico cerebral, una enfermedad mental o una incapacidad específica para el aprendizaje, pueden calificar bajo las pautas de la ADA como una discapacidad. Ni siquiera es necesario que el individuo cuente con un diagnóstico de dicha discapacidad para que esté protegido por la ADA. Más bien, la mera percepción de que un individuo está discapacitado puede hacer que tenga derecho a dicha protección (*Sutton vs United Airlines*, 1999). Un **caso de discapacidad percibida** lleva consigo un alegato de discrimina-

Tabla 15-2
Elementos de un apéndice de adaptación

Elemento del apéndice de adaptación	Descripción
Naturaleza de la adaptación	¿Exactamente cómo se modificó o adaptó la prueba o procedimiento de medición? Un ejemplo de descripción podría ser: <i>En lugar de ser aplicada en un grupo en su formato habitual por escrito (con papel y lápiz), la prueba fue aplicada de manera individual y leída al evaluado, quien respondió de manera oral.</i>
Razonamiento para la adaptación	No confundirlo con una anotación hecha para describir la discapacidad del evaluado; en este sentido, razonamiento se refiere a los motivos de la adaptación confrontándolos con el manual de la prueba, la literatura académica, u otras investigaciones y la experiencia clínica. Aquí, el usuario de la prueba puede explicar, de preferencia refiriéndose a los manuales de la prueba, a los estudios publicados, o a las investigaciones de ensayo, las razones para la modificación. Por ejemplo, el usuario de la prueba puede recurrir a un estudio citado en el manual que tenga que ver con la comparabilidad de las puntuaciones de la misma cuando ésta sea aplicada sin modificaciones de manera contraria a una aplicación con una modificación particular. Si no es posible recurrir a este tipo de fuente, el usuario de la prueba puede recurrir a su propia experiencia y juicio psicométricos para proporcionar al lector del reporte una argumentación para las modificaciones.
Comentarios adicionales	Este espacio es para cualquier otro aspecto de la aplicación de la prueba que merezca ser anotado y que pueda afectar las inferencias hechas a partir de las calificaciones de la misma. En el caso de que muchas pruebas sean aplicadas bajo condiciones de adaptación, esta sección incluirá una advertencia respecto a las interpretaciones realizadas a partir de la calificación de cada prueba.

ción por parte de una persona que sencillamente es considerada discapacitada y que es discriminada en base a dicha percepción.

La limitación de una actividad vital importante es un elemento esencial de la definición de discapacidad en la ADA, pero lo que constituye con exactitud dicha limitación no está definido en la ley. Goodman-Delahunty (2000) proporciona una ayuda en este contexto al señalar que se da por sentado que una **actividad vital importante** la componen funciones como cuidar de uno mismo, desempeñar tareas manuales, caminar, ver, oír, hablar, respirar, aprender, sentarse, pararse, cargar, leer, alcanzar, reproducirse y trabajar. Esta autora indicó que una evaluación para saber si existe un deterioro sustancial requiere que se tomen en cuenta tres factores: 1) la naturaleza y la gravedad del deterioro, 2) la duración o duración esperada del deterioro, y 3) las repercusiones a largo plazo del deterioro. Si el deterioro presentado no es considerado grave o de larga duración por naturaleza, puede no calificar como una discapacidad. Así, por ejemplo, en el caso *Pack vs K-Mart* (1999), la demandante alegaba un menoscabo en la actividad vital importante de dormir, debido a que estaba deprimida. El tribunal rechazó su alegato porque el problema podía ser controlado por medio de medicamentos y porque no existía evidencia suficiente para probar que el problema era grave, de larga duración o permanente.

Un empleado que se considera puede calificar como un individuo discapacitado (*qualified individual with a disability*, QUID) tiene derecho a que se realicen adaptaciones en su sitio de trabajo. De manera característica, estas adaptaciones toman la forma de modificaciones en las funciones o condiciones laborales (National Council on Disability, 1996). Un QUID es un empleado discapacitado que reúne los estándares de educación, habilidades y otros requisitos laborales de la empresa y que puede desempeñar las funciones esenciales del empleo con o sin adaptaciones en el sitio de trabajo. Las funciones esenciales de un trabajo son aquellas obligaciones fundamentales que no se pueden delegar a otros y que pueden requerir de experiencia, conocimientos o habilidades específicas.

Desde la aprobación de la ADA, se han presentado más de 20 000 demandas ante la agencia federal encargada de hacer cumplir las leyes antidiscriminatorias en los ámbitos laborales (Wylnis, 1999). Los tribunales han reglamentado que incluso los presos tienen derecho a ser protegidos de la discriminación bajo la ADA (Clements, 1999). Por ejemplo, un preso a quien le fue negado el acceso a un campamento motivacional debido a una historia de

SÓLO PIENSE...

La idea de hacer adaptaciones para los obreros en su sitio de trabajo y para los estudiantes en su ámbito educativo puede generar diversos sentimientos en sus compañeros. ¿Qué tipos de sentimientos podrían generar las adaptaciones? ¿Cómo podrían los administradores manejar tales sentimientos de manera efectiva?

El testimonio de los expertos

De manera rutinaria, se solicita a los evaluadores psicológicos que sirvan como expertos en los juicios. Los evaluadores pueden funcionar como expertos en muchos tipos diferentes de casos judiciales, que van desde las demandas por discapacidad hasta las demandas por incompetencia para enfrentar un juicio.

De manera característica, los evaluadores que trabajan en escenarios clínicos, de orientación psicológica y otros, tienen en mente los mejores intereses de sus evaluados y éstos confían en ese hecho. Por lo contrario, los evaluadores que actúan como testigos expertos pueden ser agentes del tribunal o incluso adversarios legales. En las evaluaciones ordenadas por los tribunales que se efectúan para los juicios militares, un psicólogo militar está obligado a poner los objetivos e intereses de la milicia por encima de los objetivos e intereses del evaluado. Hay incluso algunos profesionales —esperamos que pocos— que funcionan como mercenarios en los procesos legales, de manera más evidente en los casos civiles que involucran divorcios y custodia de los hijos, y en casos criminales en que se alega demencia como defensa. Haciendo a un lado la ética profesional, estos mercenarios realizan evaluaciones y manipulan los datos a cambio de un pago con el propósito de llegar a las conclusiones para las que se les contrató. Entonces, en comparación con la evaluación cotidiana, las evaluaciones realizadas para su presentación en la corte pueden diferir respecto a los objetivos de la evaluación, la naturaleza y tono de la misma y, finalmente, de los resultados.

Un caso histórico presentado ante la Suprema Corte de Estados Unidos en junio de 1993, tiene implicaciones para el tipo de testimonio experto admisible en procesos judiciales. El caso fue el de *Daubert vs Merrell Dow Pharmaceuticals*. Este caso tuvo su origen cuando la señora Daubert utilizó el medicamento de prescripción Benedictin para aliviar las náuseas durante su embarazo. Los demandantes entablaron un juicio en contra de Merrell Dow Pharmaceuticals, fabricantes del medicamento, cuando sus hijos presentaron defectos de nacimiento. Su demanda era que el Benedictin había ocasionado tales defectos.

Los abogados de la familia Daubert estaban provistos con investigaciones que, afirmaban, podían probar que el medicamento ocasiona defectos de nacimiento. Sin embargo, el juez del caso dictaminó que las investigaciones no satisfacían los criterios de admisibilidad. Al final, el juez dictaminó en contra de los demandantes; Merrell Dow no fue hallado responsable de los defectos de nacimiento.

Los demandantes apelaron a la siguiente instancia judicial mayor. Ese tribunal también dictaminó en su contra y en favor

del demandado, Merrell Dow. Los demandantes apelaron una vez más, en esta ocasión ante la Suprema Corte de Estados Unidos. La cuestión que se planteó a la Suprema Corte era si el juez del proceso original había actuado de manera adecuada al no permitir que la investigación de los demandantes fuera admitida como evidencia. Para comprender si el juez actuó de manera adecuada o no, es importante conocer 1) un dictamen realizado en el caso *Frye vs Estados Unidos* en 1923, y 2) una ley subsecuentemente aprobada por el Congreso, la Regla 702 en las *Reglas Federales de Evidencia* (*Federal Rules of Evidence*, FRE, 1975).

En el caso *Frye*, la Corte sostuvo que la investigación científica es admisible como evidencia cuando el estudio o método de investigación cuenta con una aceptación general. Para nuestros propósitos, esto significa que si un experto afirma algo con lo que la mayoría de los demás expertos en el campo están de acuerdo, entonces el testimonio puede ser admitido como evidencia. La Regla 702 cambió eso al permitir que más expertos testificaran respecto a la admisibilidad del testimonio experto original. Además del testimonio o investigación expertos que tuvieran una aceptación en el campo, ahora podían declarar otros expertos respecto a la admisibilidad de la investigación o de los métodos de la misma. Un experto podría ofrecer al jurado una opinión acerca de la idoneidad de un estudio o método de investigación independientemente de si su opinión representa las opiniones de otros expertos. La Regla 702 fue promulgada para respaldar a los jurados en sus indagaciones al ayudarlos a comprender las cuestiones implicadas.

Al presentar su caso ante la Suprema Corte, los abogados de los Daubert argumentaron que la Regla 702 había sido ignorada, de manera equivocada, por el juez que había conducido el juicio. Los abogados del demandado, Merrell Dow, refutaron que el juez había dictaminado de manera correcta. Argumentaron que era necesario contar con altas normas de admisibilidad para proteger al jurado de “chamanes científicos que, con el pretexto de su experiencia supuesta, estaban dispuestos a testificar en favor de casi cualquier conclusión que se adaptara a las necesidades del litigante que tuviese los recursos suficientes para pagar sus honorarios”.

Finalmente, la Suprema Corte dictaminó que se volviera a juzgar el caso Daubert y se diera al juez amplia libertad de juicio para decidir qué califica y qué no como evidencia científica. En efecto, los jueces federales fueron culpados de funcionar como guardianes. El dictamen volvió obsoleta la añeja política establecida en el caso *Frye* de admitir como testimonio científico

hipertensión, alegó de manera exitosa que se habían violado sus derechos, de acuerdo con la ADA (*Departamento de Correccionales de Pennsylvania vs Yeskey*, 1998). Las demandas de discriminación con fundamento en daños emocionales, neurológicos u otro tipo de deterioro psicológico constituyen cerca del 30% de los casos presentados ante las agencias federales, pero esa proporción



...los Antiguos medían la belleza facial por medio de la milihelena, una unidad equivalente a aquella necesaria para lanzar un navío...

únicamente aquello que hubiera obtenido aceptación general en la comunidad científica.

En el caso *Daubert*, factores como una aceptación general en la comunidad científica o la publicación en revistas reseñadas por colegas simplemente eran algunos de los muchos posibles factores que los jueces debían tomar en cuenta. Otros factores que los jueces podrían considerar incluían la medida en la cual la teoría o la técnica habían sido examinadas y el grado en que éstas podrían estar sujetas a error. En esencia, el fallo de la Suprema Corte en el caso *Daubert* dio a los jueces un gran margen para decidir lo que el jurado podía o no escuchar.

De manera subsecuente, la Suprema Corte ha reglamentado en otros muchos casos los cuales de una u otra manera aclaran o modifican ligeramente su postura en el caso *Daubert*. Por ejemplo, en el caso *General Electric vs Joiner* (1997), la Corte enfatizó que el

tribunal del proceso tenía el deber de excluir el testimonio experto poco confiable como evidencia. En el caso de la *Fábrica de Llantas Kumho vs Carmichael* (1999), la Corte expandió los principios expuestos en *Daubert* para incluir el testimonio de todo experto, ya fuera que los expertos alegaran o no la investigación científica como base para su testimonio. Así, por ejemplo, el testimonio de un psicólogo basado más en su experiencia personal en la práctica que en la evidencia científica puede ser aceptado como evidencia en un juicio si el juez así lo decide (Mark, 1999). Varios comentaristas han especulado en cómo el caso *Daubert* y casos relacionados pueden afectar la admisibilidad del testimonio experto en casos que impliquen capacidad mental (Frolik, 1999), custodia de los hijos (Krauss y Sales, 1999), procesos criminales (Slobogin, 1999), litigios civiles (Lipton, 1999) y asuntos relacionados (Grove y Barden, 1999; Saxe y Ben-Shakhar, 1999; Tenopyr, 1999).

bien puede incrementarse a medida que pase el tiempo (Moss *et al.*, 1999). Siempre que un caso se litigue en los tribunales, cada parte puede contratar a sus propios expertos con sus opiniones personales respecto a cómo deben interpretarse los hechos. Esta realidad, junto con la información acerca de la admisibilidad del testimonio experto, es el tema de nuestro *Close-up*.

Los psicólogos y otros expertos en la evaluación psicológica pueden representar diversos papeles respecto a los alegatos de discriminación relacionados con la ADA (Blanck y Berven, 1999). Una de las funciones que pueden desempeñar es la valoración del conocimiento del personal corporativo respecto a las disposiciones de la Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades. Hernández *et al.* (2003) construyeron y validaron una medida diseñada para evaluar el conocimiento de la ADA entre representantes de los sectores público y privado responsables de hacer cumplir la ley. En un estudio exploratorio de validez, los representantes de los sectores público y privado obtuvieron en la prueba calificaciones significativamente mayores de las obtenidas por un grupo controlado de estudiantes universitarios. Sin embargo, los investigadores no se vieron estimulados por el nivel de conocimientos de la ADA que exhibieron los representantes.

Los psicólogos expertos pueden desempeñarse como asesores en empresas que están poniendo en práctica políticas de contratación y de otro tipo para evitar violaciones a la ley. Hay una necesidad de este tipo de asesores, especialmente para el diseño de políticas de contratación de personas con detrimento cognoscitivo y psicológico (Scheid, 1999). Los psicólogos y otros expertos en evaluación pueden servir como asesores para las partes en sus reclamos, o para los tribunales, respecto a la naturaleza y curso de las discapacidades afirmadas, así como para los efectos de terapia u otro tipo de intervención. Sobre la base de una valoración de las demandas del lugar de trabajo y del individuo demandante, un clínico estará en posibilidad de sugerir lo que constituya una adaptación razonable en el sitio de trabajo. Basándose en la valoración de una descripción del trabajo, un asesor industrial puede proporcionar una opinión experta y objetiva acerca de las funciones esenciales del mismo. En los casos donde se haya determinado que ha habido una discriminación, los profesionales de la evaluación pueden proporcionar ideas útiles en el asunto de la compensación testificando acerca del daño emocional o de otro tipo que haya sufrido el demandante (Goodman-Delahunty y Foote, 1995).

Evaluación y discapacidades específicas

Se deben tomar en cuenta una serie de consideraciones especiales en la evaluación individual de personas con discapacidad. En general, es deseable que el evaluador comprenda las deficiencias y fortalezas del evaluado en lo referente a *a)* una discapacidad específica y *b)* otras áreas (por ejemplo, desarrollo del lenguaje, habilidades de socialización y personalidad en general) que pueden o no estar relacionadas con la discapacidad principal. Esa información será esencial para hacer las adecuaciones (si se considera que algunas son necesarias), para seleccionar los materiales de prueba apropiados (si el evaluador cuenta con esta libertad de decisión) y para interpretar los datos de la entrevista, de la prueba, de la observación y de otros relacionados que se deriven de la evaluación. Las fuentes de esa información incluyen los expedientes del caso así como la información obtenida

SÓLO PIENSE...

Parte del trabajo previo a la evaluación que puede ser requerido es una familiarización con la cultura de una discapacidad particular. Explique.

de maestros, padres, amigos, miembros de la familia y otras personas familiarizadas con el evaluado. La información deberá obtenerse del mayor número de fuentes posible. Las diferentes fuentes pueden ayudar al evaluador a comprender de mejor manera el funcionamiento del evaluado en distintas situaciones y bajo una amplia variedad de condiciones. Exactamente en cuáles variables hay que enfocarse en esas tareas previas a la evaluación dependerá, por supuesto, de los objetivos de la misma. A continuación presentamos algunas consideraciones aplicables a diversas situaciones de evaluación

a personas con discapacidades sensoriales, motoras y cognoscitivas. Comenzaremos con algunas cuestiones generales relacionadas con la evaluación de personas con deficiencias visuales.

Discapacidades visuales

La deficiencia visual es un asunto no sólo de lo que uno puede ver, sino de lo que uno puede hacer. La deficiencia visual puede tener repercusiones negativas sobre las actividades que la mayoría de nosotros damos por sentado, como ir de compras y preparar alimentos. Para muchos

estadounidenses de edad avanzada en particular, la deficiencia visual crónica es un hecho de la vida. Se ha estimado que más del 20% de las personas de 65 años de edad o mayores han padecido una grave pérdida de la visión. El porcentaje de la población afectada se eleva al 25% para los 75 años de edad y mayores (Lighthouse Research Institute, 1995). A cualquier edad, este tipo de insuficiencia, junto con otras, puede afectar de manera drástica la calidad de vida. También puede tener consecuencias en la capacidad para pasar las pruebas y otros tipos de evaluación.

Bauman (1974) propuso una taxonomía de tres categorías del detrimento visual que resulta útil en relación con las pruebas y la evaluación. En la primera categoría se incluye a las personas para quienes la visión no tiene uso práctico en la evaluación. Las personas totalmente ciegas entran en esta categoría. Dentro de esta categoría también están incluidas las personas que pueden diferenciar entre la luz y la oscuridad o que sólo pueden distinguir formas cuando se coloca un objeto entre sus ojos y una fuente de luz. La siguiente categoría incluye a personas cuya visión es de alguna utilidad para manejar objetos de gran tamaño, para localizar materiales de prueba en un espacio de trabajo o para seguir los movimientos de las manos del examinador durante una demostración, pero que no pueden leer lo suficientemente bien, incluso los tipos de letra de gran tamaño, como para que se les evalúe mediante materiales impresos. Tales individuos pueden ser examinados con materiales que no dependen en gran medida de la visión, pero que requieren una combinación de vista y tacto. La tercera categoría incluye a personas que pueden leer materiales impresos de manera eficiente, aunque pueden necesitar tipos de letra de gran tamaño, sostener la hoja impresa muy cerca de sus ojos o utilizar una lupa o alguna otra herramienta visual especial.

La adaptación para los examinados con detrimentos visuales puede ser de diferente tipo, dependiendo, por supuesto, de la naturaleza y grado del daño. Puede ser necesario, por ejemplo, modificar la iluminación de la habitación. Algunos examinados pueden necesitar más luz, mientras que a otros tal vez les moleste la luz excesiva y el resplandor. Algunos otros tipos de modificación pueden ser:

- Para un examinando con visión parcial, los instrumentos de escritura y los materiales para la misma deben ser adecuados para la tarea. Por ejemplo, un plumón o un crayón negros pueden ser más adecuados que un bolígrafo de punto fino. De manera similar, puede requerirse papel especial con renglones anchos.
- En general, las personas con deficiencia visual requieren de más tiempo que las personas sin deficiencia. Puede tomar más tiempo dictar los contenidos a que el examinado los lea por sí mismo. Cuando a una persona con visión parcial se le pide que utilice su visión residual, podría aparecer la fatiga de prueba, lo cual se hace evidente al frotarse los ojos o al hacer otros movimientos extraños. En algunos casos, los examinados podrán utilizar diferentes pares de lentes para distintas tareas. Se debe conceder el tiempo necesario cuando se examina a discapacitados visuales, y las pruebas de velocidad serían inapropiadas para estas personas (Nester, 1993).
- Las preguntas de opción múltiple, aún en Braille, no son aceptadas por los expertos pues este tipo de reactivos agregan una carga adicional de concentración sobre los examinados con deficiencias visuales.
- Para presentar la prueba, un examinado con deficiencia visual puede necesitar más tiempo para tocar todos los materiales con los que estará trabajando. Durante la prueba, se podría necesitar más información verbal de la que requieren los individuos con vista normal. Es importante, bajo cualquier condición de prueba, tener una sala tranquila que esté libre de distracciones. Sin embargo, este requisito adquiere una importancia adicional al examinar a individuos ciegos o con deficiencias visuales ya que estas personas pueden distraerse más con los sonidos externos que los individuos con vista normal.
- El espacio de trabajo deberá ser relativamente compacto de modo que todo el equipo esté al alcance del examinado. Este espacio también debe estar bien iluminado, pero no en exceso como para ocasionar reflejos sobre los materiales de estímulo que deban leerse.
- Si los materiales de estímulo de la prueba requieren ser leídos y la prueba es aplicada a una persona con visión parcial, sería recomendable reimprimir los materiales en un tipo de letra de mayor tamaño. También sería adecuada una aplicación en Braille; sin embargo, relativa-

mente pocos individuos invidentes pueden leer Braille y un número relativamente limitado de ellos lo leen bien.

Si el objetivo de la prueba es evaluar la capacidad intelectual, muchas pruebas y subpruebas, como la escala Verbal de una prueba de Wechsler, han sido utilizadas con propósitos de valoración. Algunas investigaciones han puesto en tela de juicio esta práctica bastante común. En un estudio, niños invidentes o con graves deficiencias visuales tendieron a desempeñarse alrededor de una desviación estándar por debajo de la media de niños con visión normal en la subprueba de comprensión (Groenveld y Jan, 1992). Aunque las calificaciones de estos examinados estuvieron cercanas a la media de los niños con vista normal en las subpruebas de información, semejanzas, vocabulario y aritmética, el estudio destaca la necesidad de normas específicamente desarrolladas para examinados invidentes y con deficiencias visuales.

En el área de evaluación de la personalidad, la mayoría de los métodos existentes disponibles para su uso con personas no ciegas pueden adaptarse con facilidad para ser utilizados con personas con deficiencias visuales e invidentes. Los materiales de prueba que se deban leer pueden volver a imprimirse en letras de mayor tamaño, pueden leerse al examinado o de antemano pueden ser grabadas en una cinta. Incluso una prueba como la Prueba de apercepción temática (*Thematic Apperception Test*, TAT) puede ser aplicada a una persona invidente si ésta escucha una descripción de la tarjeta y después procede a contar una historia acerca de ella. Una prueba similar al TAT, especialmente desarrollada para personas invidentes, es la Prueba de sonido (*Sound Test*), que contiene sonidos pregrabados como pisadas, agua corriente y música, combinados en algunos casos con intercambios verbales en algunas instancias. La tarea del examinado es construir una historia en base a esos estímulos auditivos.³

Otras pruebas de personalidad especialmente diseñadas son el Inventario de factores emocionales (*Emotional Factors Inventory*) y el Inventario de factores emocionales en el adolescente (*Adolescent Emotional Factors Inventory*), dos pruebas que incluyen escalas que miden la adaptación del examinado a la invidencia. La Escala de capacidad social para niños preescolares invidentes, de Maxfield-Bucholz (*Maxfield-Bucholz Social Competency Scale for Blind Preschool Children*) es una medida de la capacidad social y de la conducta adaptativa diseñada para utilizarse con niños invidentes desde el nacimiento y hasta los 6 años de edad. La escala se aplica a una tercera persona, como uno de los padres, el tutor o el proveedor principal de cuidados, y está diseñada para explorar áreas como el desarrollo físico del sujeto, su capacidad de autocuidado, y la capacidad social.

También se han desarrollado pruebas para ayudar a los invidentes y discapacitados visuales en el área de orientación vocacional. Muchas de las pruebas disponibles de destreza digital y manual se utilizan con esta población. Los inventarios disponibles de interés vocacional se aplican a esta población en ediciones con tipografía de gran tamaño, en Braille y con otras modificaciones. Una de estas pruebas, el Inventario de intereses PRG (*PRG Interest Inventory*) se basó en su totalidad en el contenido de los tipos de empleo que tienen y los pasatiempos a los que se entregan los respondientes invidentes. En las instrucciones de la prueba, se advierte a los examinados que respondan como si tuviesen las capacidades visuales para manejar la descripción de los diversos empleos. Las instrucciones fueron escritas así, de modo que la prueba produzca una medida vez de los intereses y no de la capacidad percibida.

Las alteraciones visuales pueden afectar los resultados de las pruebas neuropsicológicas (Kempen *et al.*, 1994), lo que incitó a un neuropsicólogo con orientación neurológica a examinar el cerebro para encontrar respuestas acerca del desempeño deficiente en dichas pruebas. Sin embargo, como han aconsejado Kempen *et al.* (1994) una sencilla prueba de visión puede ser todo lo que se necesite en algunos casos para responder esas preguntas.

Vale la pena repetir que se debe tener la máxima cautela al hacer inferencias a partir de puntuaciones de subpruebas dentro de pruebas estandarizadas que han sido modificadas para adaptarlas

3. Del capítulo 12 recordará que no fue ningún otro que el conductista B. F. Skinner quien creó el primer instrumento para medir la proyección auditiva.

al examinado. Aun cuando no se haya hecho ninguna adaptación a una prueba, la interpretación de las puntuaciones de personas con discapacidades presenta muchas dificultades. Por ejemplo, con base en sus experiencias en la Escuela para los invidentes y discapacitados visuales de Texas (*Texas School for the Blind and Visually Impaired*) Loftin (1997) advirtió que varios padecimientos diagnosticados pueden estar relacionados de manera directa con las deficiencias visuales y con la invidencia congénita en particular. Estos padecimientos incluyen demoras en etapas motoras importantes, ecolalia en el habla, conversaciones superficiales o ego-céntricas, sobreidentificación con los adultos, una tendencia a ser pasivo en la solución de problemas y otros.

Mediante el trabajo con miembros de esa población, a partir de una disposición profesional o como voluntario, puede desarrollarse una gran sensibilidad a las necesidades de una población en particular. Los futuros profesionales de la evaluación también podrían desear leer acerca de las experiencias de otros profesionales de la evaluación que trabajan con miembros de diversas poblaciones. Los recursos literarios relacionados con la evaluación de invidentes y discapacitados visuales incluyen a Bauman y Kropf (1979), Bradley-Johnson (1994), Bradley-Johnson y Harris (1990), Chase (1986), Drinkwater (1976), Evans (1978), Levack (1991), Loftin (1997), Swallow (1981), Tillman (1973) y Vander Kolk (1977).

SÓLO PIENSE...

¿Cómo podría un evaluador proceder acerca del desarrollo de un enfoque culturalmente informado en la evaluación de individuos invidentes?

Discapacidades auditivas

Las deficiencias auditivas pueden suceder a cualquier edad debido a una amplia variedad de razones, desde enfermedades e infecciones, hasta la exposición prolongada a la música estridente. Se ha estimado que cerca de la mitad de la población estadounidense de 65 años de edad y mayores padece en algún grado deficiencia auditiva (Vernon, 1989). De las personas evaluadas que parecen no comprender las instrucciones, que con frecuencia piden que se les repitan las cosas, que observan los labios del hablante de manera fija, y/o se comportan como si hubiesen entendido lo que se les dijo cuando no es así, o todas las anteriores, se puede sospechar que tienen una alteración auditiva no diagnosticada.

Las personas con deficiencias auditivas difieren en muchas variables como la magnitud de la pérdida auditiva, la edad al inicio de la pérdida y sus efectos consecuentes sobre las habilidades de lenguaje, la adaptación social y otras capacidades y características personales. Desde una perspectiva cultural (que analizaremos con mayor detalle más adelante en este capítulo), las personas con una aguda pérdida de la audición antes de los 3 años de edad pertenecen a una cultura diferente de la de los miembros del segmento relativamente pequeño de la población sorda que han experimentado una grave pérdida de la audición en etapas de vida posterior (Raifman y Vernon, 1996). Este último grupo utiliza la comunicación verbal y pueden reconocerse ellos mismos como parte de la cultura mayoritaria; por el contrario, las personas que son sordas desde una edad temprana utilizan un lenguaje visual, tienden a utilizar las manos en lugar de las palabras y, a causa de su aislamiento de la cultura mayoritaria, interactúan de manera principal con otras personas sordas (Higgins, 1983; Lane, 1992; Padden y Humphries, 1988; Vernon y Andrews, 1990). Cuando un evaluador con capacidad auditiva tiene la tarea de evaluar a una persona sorda, el problema, al menos a primera vista, es el de la comunicación. Por desgracia, el problema puede ir mucho más allá de la comunicación y, de hecho, puede caracterizarse de mejor manera como un choque de culturas (Phillips, 1996).

Para los evaluados con discapacidad auditiva, y/o que no hayan sufrido el deterioro de su capacidad auditiva a una edad temprana, se puede emplear una serie de estrategias de modificación de prueba para facilitar la comunicación entre evaluador y evaluado. Estas estrategias incluyen 1) presentar las instrucciones escritas en un nivel de lectura adecuado para el evaluado (impresas en papel o presentadas de manera electrónica por medio de una computadora o de un dispositivo especial de teletipo), 2) amplificar la voz del evaluador (por medio de un equipo de altavoz o del propio dispositivo de audición del evaluado) y 3) utilizar un intérprete experto en

el lenguaje de señas en el que también el evaluado sea eficiente.⁴ Para los evaluados con sordera desde una edad temprana, se recomienda en alto grado utilizar sólo aquellos evaluadores que manejen con fluidez el lenguaje de señas del país de origen y que estén familiarizados con la cultura implicada (Leigh *et al.*, 1996; Raifman y Vernon, 1996). Esto es esencial por razones relacionadas con la armonía, la comunicación y la precisión en la interpretación de los resultados de la prueba. Para facilitar tales valoraciones, pueden emplearse materiales especiales de prueba. Por ejemplo, Bárbara Brauer, una psicóloga sorda, desarrolló una versión en videocinta de una aplicación del MMPI en el lenguaje de señas (Brauer, 1993).

A pesar de lo esenciales que puedan ser una o más de las adaptaciones descritas, existen inconvenientes relacionadas con cada una (Orr *et al.*, 1987). Por ejemplo, utilizar la comunicación escrita en lugar de la comunicación verbal introduce otra variable (capacidad para la lectura) en una tarea donde antes no existía dicha variable. Proporcionar instrucciones y señas utilizando la pantomima en ausencia de pautas formales dentro de los manuales de la prueba para hacerlo da por resultado que las personas distintas que recurren a la pantomima (es decir, distintos evaluadores) bien pueden tener ideas muy diferentes de cómo explicar un punto por medio de gestos. Como resultado, la estandarización de las instrucciones a los examinados se verá afectada.

Introducir un intérprete en la situación de aplicación puede reducir la armonía entre el examinador y el examinado. Además, también se puede esperar cierta cantidad de errores en las traducciones expresivas y receptivas. Cuando la traducción implica el uso de señas, las habilidades de señalización del intérprete deben ser compatibles con las habilidades receptivas del evaluado. Por ejemplo, sería inadecuado que el intérprete utilizara las señas del Inglés Codificado de Señas (*Coded Sign English*, un método de comunicación relacionado más de cerca con la expresión escrita/verbal de personas sin discapacidad auditiva) con un evaluado con mayor dominio del Lenguaje de señas de Estados Unidos. La información verbal, en especial las expresiones idiomáticas y los proverbios, no son fáciles de traducir por medio de señas y el evaluador debe examinar los materiales de prueba en forma cuidadosa con antelación teniendo eso en mente, y de ser necesario modificar adecuadamente la aplicación de los materiales. De hecho, el lenguaje de señas es un idioma diferente, y la traducción de pruebas a un lenguaje de señas debe tratarse con el mismo cuidado que se utiliza en las traducciones a cualquier lengua extranjera (Nester, 1993).

Las subpruebas de desempeño de las pruebas de Kaufman (Gibbins, 1988; Kennedy y Hiltonsmith, 1988; Phelps y Branyan, 1988) y las escalas de Wechsler se han utilizado para estimar el funcionamiento intelectual de las personas sordas y con deficiencias auditivas. Jeffrey Braden (1985, 1990, 1992; Maller y Braden, 1993) y Patricia Sullivan (1982) y sus colegas (Maller, 1997; Sullivan y Brookhouser, 1996; Sullivan y Burley, 1990; Sullivan y Montoya, 1997; Sullivan y Schulte, 1992) han escrito de manera extensa acerca del uso de las escalas de Wechsler y otras con personas sordas o con deficiencias auditivas. Recientemente, Sullivan instó a la reevaluación del tabú histórico que se opone al uso de pruebas verbales de inteligencia con miembros de esta población. Sullivan y Montoya (1997) argumentaron que en la actualidad la mayoría de las personas sordas y con problemas auditivos están compitiendo con las personas que sí oyen, tanto en ámbitos académicos como laborales. Las habilidades de comunicación cara a cara y la familiaridad con el idioma son requeridas de manera representativa para los empleos altamente remunerados (Allen, 1994; Schildroth *et al.*, 1991).

En contraste con las pruebas diseñadas originalmente para usarse con la población general, algunas pruebas diseñadas para medir la capacidad cognoscitiva fueron estandarizadas con respondientes oyentes, así como con no oyentes. La Prueba de aptitud para el aprendizaje Hiskey-Nebraska (*Hiskey-Nebraska Test of Learning Aptitude*) es una de estas pruebas. Desarrollada por Marshall S. Hiskey (1966) para utilizarse con niños y adolescentes entre 3 y 17 años de edad, la Prueba Hiskey-Nebraska fue desarrollada con sensibilidad a las necesidades de los examinados sordos o con dificultades auditivas. La prueba incluye ejercicios de práctica con pantomima así como un manual repleto de pautas útiles para evaluar respondientes sordos o con problemas auditivos. Aunque las normas necesitan actualizarse, la prueba ha perdurado como medida útil de

4. Una fuente de información y un directorio de intérpretes certificados es el Registro de intérpretes para sordos (*Registry of Interpreters for the Deaf*). Su dirección en Internet es <http://www.rid.org>

la capacidad cognoscitiva (Sullivan y Burley, 1990). Tiene un atractivo internacional como prueba preferida en aplicaciones clínicas y de investigación con evaluados sordos y con dificultades auditivas (véase, por ejemplo, Collins *et al.*, 1987; Nagyne Rez y Zsoldos, 1991; Qu *et al.*, 1992).

Las mediciones del aprovechamiento académico con el uso de pruebas como la Prueba metropolitana de rendimiento y las Pruebas Stanford de rendimiento (*Stanford Achievement Tests*) pueden ser de utilidad ya que ambas fueron estandarizadas con miembros pertenecientes a esta población. En general, los niños sordos y con deficiencias auditivas no se desempeñan tan bien en estas pruebas como sus compañeros oyentes. Esto se debe no sólo a su insuficiencia de lenguaje, sino también a la falta de métodos de programas de estudio desarrollados de manera específica para satisfacer las necesidades educativas especiales de los niños sordos. Sólo 5% de los graduados de programas educativos para sordos logra una educación de décimo año; 41% alcanza una educación de séptimo u octavo grado y 30% es analfabeta funcional.

Las herramientas utilizadas para evaluar la personalidad de personas sordas o con dificultades auditivas, como en el caso de otros individuos, incluyen una entrevista (modificada adecuadamente, como sería con señas o con amplificación), la evaluación de la historia del desarrollo y las pruebas. En algunos casos, son preferibles las pruebas de personalidad que minimizan los requisitos de capacidad verbal (Leigh *et al.*, 1996). Así, por ejemplo, es frecuente utilizar pruebas que incluyan dibujos (como la de dibujar una persona y la de dibujar una casa, un árbol y una persona) con evaluados sordos. La evaluación de la personalidad de niños y adultos mediante pruebas de personalidad empleando lápiz y papel deben ser utilizadas sólo si se conoce el nivel de lectura de la prueba y si se sabe que el evaluado tiene una capacidad de lectura a ese nivel o en uno superior.

Se recomienda el uso del Rorschach sólo con aquellas personas sordas que se sabe están por arriba del promedio de inteligencia y que tienen la capacidad de comunicarse con fluidez por medio de señas (Vernon y Brown, 1964), aunque los clínicos con experiencia en esta población especial pueden utilizarlo de manera más rutinaria (Sachs, 1976). Otras medidas proyectivas, como las que incluyen dibujos (Johnson, 1989; Ouellette, 1988), el Test gestáltico viso-motor de Bender utilizado como prueba proyectiva (Gibbins, 1989) y el TAT (Vernon y Brown, 1964), pueden resultar perceptivas. Cates y Lapham (1991) advierten que aunque el TAT puede ser útil, los niños y adolescentes sordos podrían clasificar las tarjetas de manera real y luego persistir en los temas en un esfuerzo por proporcionar la respuesta “correcta”:

Una dificultad potencial en la aplicación de técnicas de apercepción con niños y adolescentes sordos es la tendencia a persistir en las respuestas. Por ejemplo, si un niño sordo no está familiarizado con la tarea, es posible que intente, de manera inicial, etiquetar una imagen. Si esta respuesta es corregida, entonces es posible que el niño sordo identifique la primera historia que contó como la respuesta correcta. Si la primera respuesta correcta fue una historia que contenía un tema violento, entonces cabe la posibilidad de que el paciente sordo asuma que la violencia es deseable o apropiada en las historias y que persista en los temas violentos. El clínico debe decidir si permite la persistencia o si debe reestructurar la propensión de respuesta del niño o adolescente. En la mayoría de los casos, los autores tomaron nota del fenómeno de persistencia y prosiguieron a reestructurar la tendencia de respuesta, indicando que cada imagen puede evocar temas diferentes (p. 125).

Cates y Lapham (1991) también reportaron tipos concretos de respuesta que podían ser proporcionados en otra medida proyectiva, la Prueba de la mano (*Hand Test*):

Los niños y adolescentes sordos proporcionan una mayor frecuencia de respuestas concretas a la Prueba de la mano que sus contrapartes oyentes. Por ejemplo, en respuesta a la primera lámina —una mano presentada con la palma hacia afuera— los niños sordos, de manera inicial, podrían dar una descripción de la mano (por ejemplo, “Es una mano mostrada. Son cinco dedos”) en lugar de describir la mano ocupada en alguna forma de actividad, como se pide en las instrucciones. En el sistema de calificación de la prueba de la mano, este tipo de respuesta descriptiva se considera indicativa de trastornos graves. Entonces, el clínico que utilice la prueba podría desear aplicarla según el procedimiento estandarizado, seguida de un procedimiento de probar los límites, en el que se insta al niño sordo a proporcionar respuestas más adecuadas. De manera alternativa, después de

SÓLO PIENSE...

¿Qué retos especiales enfrenta un creador de pruebas cuando revisa una prueba que originalmente fue diseñada para personas con capacidad auditiva normal con el fin de utilizarla con una población de individuos sordos?

la primera respuesta descriptiva, el clínico podría desear volver a enfatizar las instrucciones, evocar una respuesta más adecuada y considerar la respuesta inicial como un ensayo. El sujeto sordo también podría beneficiarse a partir de la inclusión en las instrucciones estándar de la observación de que las manos no están utilizando un lenguaje de señas (p. 122).

Las listas de verificación conductual y las escalas de calificación pueden resultar herramientas útiles de evaluación con individuos sordos (McCoy, 1972). La lista de verificación utilizada ampliamente con niños y adolescentes sordos es el Inventario de evaluación social- emocional, de Meadow y Kendall (*Meadow-Kendall Social-Emotional Assessment Inventory*, Meadow *et al.*, 1980), que es adecuado para uso con individuos de 7 a 21 años de edad. Otros instrumentos similares, no necesariamente diseñados de manera específica para sordos, incluyen la Lista de verificación de problemas de la conducta (*Behavior Problem Checklist*; Quay y Peterson, 1967, 1983), la Escala Devereaux de calificación de la conducta adolescente (*Devereaux Adolescent Behavior Rating Scale*; Spivack *et al.*, 1967), la Escala Devereaux de calificación de la conducta infantil (*Devereaux Child Behavior Rating Scale*; Spivack y Spotts, 1966), la Lista de verificación de la conducta infantil (*Child Behavior Checklist*; Achenbach, 1978) y la Lista de verificación para identificar problemas de la conducta, de Walker (*Walker Problem Behavior Identification Checklist*; Walker, 1976).

Como es frecuente el caso al examinar a personas sordas o con deficiencias auditivas, es posible que las normas adecuadas para la prueba empleada sean escasas o inexistentes. En esas circunstancias, los evaluadores deben recurrir a su propia capacitación y experiencia —o, de ser necesario, de la de un colega más experimentado y capacitado— en un esfuerzo por hacer inferencias razonables a partir de los datos obtenidos. Siempre que sea adecuado, las conclusiones deben ser respaldadas por múltiples fuentes de datos, incluyendo datos provenientes de la historia clínica o de desarrollo, datos de observaciones conductuales y reportes de padres, maestros, terapeutas u otros proveedores de cuidados.

Antes de aplicar pruebas psicológicas y educacionales a examinados sordos o con pérdida parcial auditiva, la mayoría de los psicólogos y otros usuarios de las pruebas se beneficiarían de la educación, la experiencia supervisada y la capacitación relacionada con las deficiencias auditivas y la sordera (Cates y Lapham, 1991; Elliot *et al.*, 1987; Elliot y Carroll, 1997; Pollard, 1993; Weaver y Bradley-Johnson, 1993; Zieziula, 1982). Esta preparación especializada es decisiva si han de hacerse interpretaciones precisas a partir de los datos de la evaluación. Misiasek *et al.* (1985) advirtieron que los profesionales de la salud mental no familiarizados con los efectos de la sordera prelingual sobre la personalidad, comunicación, cognición y socialización están propensos a cometer errores de diagnóstico. Las personas que padecen de sordera prelingual pueden exhibir conductas que parecen similares a los patrones de conducta concretos y en ocasiones fragmentados, característicos de los individuos esquizofrénicos. Otros productos de la aculturación de la sordera, como las conductas egocéntricas y rígidas, pueden confundirse con trastornos de la personalidad. Considerar estos escollos potenciales conduce a una conclusión general que no puede enfatizarse demasiado en cualquier análisis acerca de la evaluación de los miembros de una población que padecen de una discapacidad específica: la educación especializada, la capacitación y la experiencia supervisada son altamente deseables, si no es que obligatorias.

Discapacidades visuales-auditivas

SÓLO PIENSE...

¿Qué preparación cree usted sea necesaria para que los evaluadores puedan evitar de manera efectiva confundir una discapacidad física con una alteración emocional?

En 1967, el Congreso de Estados Unidos creó diez Centros regionales para jóvenes y adultos sordos-invidentes en respuesta al incremento de bebés nacidos con discapacidades múltiples como resultado de una epidemia de rubéola que se extendió a lo largo de Estados Unidos entre 1963 y 1965. A estos centros se les asignó la responsabilidad de identificar y evaluar a esos niños. La evaluación de los miembros de esta población representa “la tarea de diagnóstico más difícil que se le puede asignar a un psicólogo” (Vernon *et al.*, 1979, p. 291). El evaluador debe tener especial cuidado con los

errores de diagnóstico que pueden conducir a colocar a esos niños en programas para personas con daños emocionales o mentales cuando, de hecho, esos programas serían inadecuados para esos niños en particular.

Pocas pruebas estandarizadas son adecuadas para utilizarse con las personas sordas e invidentes. Las pruebas estandarizadas que se han desarrollado y estandarizado con individuos que presentan padecimientos discapacitantes de otros tipos no toman en cuenta de manera apropiada la multiplicidad y propagación de daños en los sordos-invidentes. De manera más característica, la evaluación psicológica de los sordos-invidentes implica una valoración de la conducta adaptativa (examinada con mayor detalle más adelante), así como entrevistas con proveedores de cuidados y un análisis del material de la historia del desarrollo. Una de las pocas escalas diseñadas y estandarizadas para su uso con esta población es la Escala Callier-Azusa (*Callier-Azusa Scale*, CAS).

La CAS es una lista de verificación de la conducta que permite al examinador comparar el desarrollo del sujeto en cierto número de áreas (motora, perceptual, de lenguaje, de habilidades en la vida cotidiana y de socialización) con el desarrollo característico de niños sordos-invidentes desde el nacimiento hasta los 9 años de edad y que han recibido intervenciones adecuadas. La prueba es útil tanto para la planeación de programas educativos como para una prueba posterior con el fin de estimar los cambios conductuales después de una intervención específica. Stillman (1974) recomienda que más de un evaluador analice la conducta del niño, tanto en casa como en la escuela durante al menos dos semanas. Por lo general, la información proviene de uno de los padres, un maestro u otra persona que tenga un amplio contacto con el niño. Se ha reportado una confiabilidad adecuada de las 16 subescalas de la prueba. Los autores de la misma también informaron que la confiabilidad de la escala no fue influida significativamente por el medio educativo del niño ni por el número de personas que lo valoraron (Bennett *et al.*, 1979). En relación con la evidencia de validez, Diebold, Curtis y Dubose (1978) han demostrado una fuerte relación entre la observación sistemática de medidas de conductas cotidianas y el desempeño en las escalas de desarrollo de la CAS en una muestra de niños sordos-invidentes de 6 a 13 años de edad. Las 16 subescalas de la CAS producen una calificación de equivalencia de edad en lugar de un CI, pero la tabla de conversión es poco sólida en el aspecto psicométrico y por ende la utilizan pocos profesionales. Se otorga reconocimiento a reactivos específicos sólo si la conducta está “presente de manera completa y regular”. No se concede reconocimiento a conductas que apenas comienzan a surgir. Si un niño sordo-invidente padece de discapacidades adicionales, como deficiencias motoras, se pueden omitir ciertos reactivos específicos de la CAS.

Otra prueba estandarizada que se puede utilizar con los sordos-invidentes es la Evaluación de niveles de desarrollo por la observación (*Assessment of Development Levels by Observation*, ADLO; Wolf-Schein, 1993). Como su nombre lo indica, la ADLO incluye la observación sistemática de la conducta y su clasificación de acuerdo al nivel de desarrollo. La conducta es evaluada y clasificada con base en variables relacionadas con las habilidades de autoayuda, habilidades motoras finas y gruesas, receptividad (atención y comprensión), lenguaje expresivo, y relaciones con adultos. De manera característica, la prueba se efectúa en un ambiente familiar para el niño; un evaluador lo observa mientras el niño juega solo, interactuando con adultos conocidos y desconocidos y trabajando con un especialista del lenguaje. Las normas están disponibles para niños desde el nacimiento hasta los 8 años de edad.

Discapacidades motoras

Las deficiencias motoras se presentan en muchas formas, tienen una diversidad de causas y pueden involucrar algún músculo o conjunto de músculos del cuerpo. Parálisis, temblores, movimientos involuntarios, dificultad para caminar y problemas volitivos de movimiento y habla son algunos de los muchos tipos de problemas motores. La causa del problema puede ser una dificultad muscular o neurológica heredada o adquirida como resultado de un trauma en un músculo, en el cerebro o en la médula espinal. Otros factores causales incluyen el amplio rango de enfermedades neuromusculares. Por ejemplo, se considera que los casos de parálisis cerebral se presentan con una frecuencia de 1.6 a 5 por cada 1000 en poblaciones menor a los 21 años de edad. La parálisis cerebral puede ser causada por un desequilibrio endocrino, por un bajo nivel de azúcar en la sangre, por anoxia, por parto con fórceps elevados, o alguna otra variedad de factores ocurridos antes, durante o después del nacimiento.

La mayoría de las pruebas utilizadas para evaluar el funcionamiento intelectual dependen, al menos en parte, de la capacidad del respondiente para manipular ciertos materiales como

tarjetas, cubos, cuentas y demás. Una prueba que no contenga esas tareas estaría sujeta a las críticas de los expertos por estar demasiado cargadas de medidas verbales en oposición a las medidas de desempeño de la inteligencia. Los examinadores que deseen evaluar la inteligencia de personas con discapacidad motora deberán intentar seleccionar una prueba existente que no requiera de modificación alguna para aplicársela al individuo específico.

Si todas las pruebas disponibles requirieran de alguna modificación, sería seleccionada a partir de aquella prueba que necesitara la menor cantidad de modificaciones posibles. Un ejemplo de modificación que podría emplearse al aplicar una tarea de diseño con cubos, por ejemplo, requeriría que el examinador volteara físicamente dichos cubos hasta que el examinado señale que la rotación de un cubo es su respuesta. El examinado podría indicar esto por medio de una respuesta verbal o, si existe una deficiencia del habla, con alguna otra respuesta, como guiñar un ojo. En tareas con papel y lápiz que requieren de una coordinación motora fina, como las pruebas que implican rellenar casillas pequeñas con lápices del número 2, el individuo con discapacidad motora puede necesitar que alguna otra persona escriba sus respuestas. La alternativa (no aplicar ninguna tarea motora a examinados con discapacidad motora) es el enfoque adoptado por algunos evaluadores. El razonamiento aquí es que una prueba verbal como una subprueba de Vocabulario de alguna de las escalas de Wechsler se correlaciona en forma elevada con el resto del examen y por tanto puede utilizarse como un cálculo aproximado de la inteligencia tanto verbal como no verbal. Sin embargo, este tipo de procedimiento sólo proporciona un *cálculo aproximado* y nunca constituye un buen método si es utilizado para tomar decisiones de inclusión educativa, en ausencia de otros datos de evaluación.

Los psicólogos y educadores especiales que evalúan variables como la gravedad de una deficiencia motora tienen a su disposición una cierta cantidad de pruebas. Cuatro baterías utilizadas en la actualidad son el Estudio perceptivo-motor de Purdue (*Purdue Perceptual-Motor Survey*), la Prueba de habilidad motora, de Bruininks-Oseretsky (*Bruininks-Oseretsky Test of Motor Proficiency*), la Batería de pruebas para la habilidad de movimiento, de Frostig (*Frostig Movement Skills Test Battery*) y las Pruebas de integración sensorial de California del Sur (*Southern California Sensory Integration Tests*). El Purdue es un instrumento de exploración que proporciona pautas para la evaluación de diversas funciones motoras gruesas y finas en niños de 6 hasta 10 años de edad. La Bruininks-Oseretsky examina habilidades motoras gruesas y finas, así como la capacidad motora en general. Ésta es una prueba técnicamente sólida pero que requiere de 1) un evaluador bien capacitado que la aplique y la interprete, y 2) un espacio amplio para su aplicación (como un patio de juegos o una habitación especialmente equipada). La batería Frostig está diseñada para evaluar el desarrollo sensorio-motor, coordinación motora gruesa y fina, equilibrio, fuerza y flexibilidad, en niños de 6 a 12 años de edad. Es popular entre muchos evaluadores porque es

relativamente sencilla de aplicar, contiene un rango relativamente amplio de habilidades motoras ejemplificadas y es fácil de calificar. Las Pruebas de integración sensorial de California del Sur también son una medida de funcionamiento sensorial integral diseñadas para utilizarse con niños de 4 a 9 años de edad. Sin embargo, esta exhaustiva prueba debe ser administrada e interpretada por un evaluador altamente capacitado.

Otras pruebas de habilidades motoras han sido desarrolladas para utilizarse con individuos de edad avanzada, incluyendo el Índice de discapacidad física (*Physical Disability Index, PDI*; Gerety *et al.*, 1993). Diseñado específicamente para poblaciones de ancianos

débiles, el PDI evalúa la fuerza, el equilibrio, la movilidad y la extensión de movimiento.

SÓLO PIENSE...

¿Cuáles podrían ser algunas tareas para evaluar las capacidades motoras de los ancianos débiles? ¿De qué manera podría utilizarse la información derivada de estas tareas?

Discapacidades cognoscitivas

El término **discapacidad cognoscitiva** cubre un amplio espectro de padecimientos discapacitantes, incluyendo diversas deficiencias neurológicas, discapacidades de aprendizaje, autismo y discapacidad intelectual. En otras partes del presente texto hemos discutido muchas de las cuestiones relacionadas con la evaluación de algunas de estas discapacidades cognitivas. Aquí, nos enfocamos en las cuestiones de evaluación relacionadas con la discapacidad intelectual.

Discapacidad intelectual y conductas adaptativas Las definiciones de discapacidad intelectual y los sistemas asociados de clasificación varían según la fuente. La mayoría de las definiciones hacen referencia al funcionamiento intelectual general significativamente inferior al promedio que existe junto con deficiencias en la conducta adaptativa, que se manifiestan en su totalidad durante el periodo del desarrollo. En este contexto, **conducta adaptativa** se refiere a la efectividad personal y social y a la idoneidad de las acciones propias. La conducta propia es caracterizada como adaptativa en la medida en que uno actúa o modifica su propia conducta de manera consistente con una adaptación adecuada a la edad, con la madurez social y con la capacidad personal y social (Cain *et al.*, 1963; Doll, 1953; Fullan y Loubser, 1972). En 1905, Alfred Binet hizo referencia indirecta al concepto de conducta adaptativa cuando dijo, “un individuo es normal cuando puede llevar a cabo sus tareas vitales sin tener la necesidad de ser supervisado por otros, si es capaz de trabajar lo suficiente... para satisfacer sus propias necesidades” (Binet, citado en Goddard, 1916).

De forma tradicional, la discapacidad intelectual ha sido diagnosticada de manera principal basándose en pruebas de inteligencia y luego clasificada con referencia a una de cuatro categorías: leve, moderada, grave y profunda. Estas categorías indican mediciones de CI progresivamente inferiores y están asociados con déficits característicos en la conducta adaptativa respecto a contextos específicos a lo largo de un ciclo de vida. En 1992, un manual publicado por la Asociación Estadounidense de Retraso Mental (American Association on Mental Retardation, AAMR) reemplazó estas cuatro categorías por cuatro formas revisadas de clasificación de personas con discapacidad intelectual. La AAMR (1992) la definió como un estado que se desarrolla antes de los 18 años de edad y en el que hay un funcionamiento intelectual significativamente inferior al promedio (CI medido de 75 o menor) concomitante con las limitaciones en al menos dos de diez áreas de habilidades adaptativas. Las áreas de habilidad adaptativa fluctúan desde el tiempo libre hasta las académicas para trabajar e incluyen áreas como comunicación, cuidados propios y habilidades sociales.

De manera consistente con el nuevo paradigma que fue examinado previamente en este capítulo, el sistema de clasificación de la AAMR revisado enfatiza el papel de la conducta adaptativa en la definición de la discapacidad intelectual al reemplazar las etiquetas cualitativas asociadas con un déficit (*leve, moderado* y demás) con un modificador que indica la cantidad de apoyo requerido en diversos ambientes. La intensidad de apoyo requerida fue categorizada como *intermitente* (se requiere de apoyo según sea necesario), *limitada* (con límites de duración, pero consistente a lo largo del tiempo), *extendida* (cotidiana, al menos en algunos medios) o *difundida* (requiere de un apoyo constante en todo los medios).

Duramente criticado por muchos, el sistema de la AAMR de 1992 fue caracterizado como un “manual muerto que camina” (Greenspan, 1997). El manual hizo surgir un sinnúmero de nuevos problemas respecto a la evaluación y clasificación de la inteligencia, de la conducta adaptativa y de la intensidad de apoyo requerido (Gresham *et al.*, 1995; Hodapp, 1995), en especial con niños pequeños (Vig y Jedrysek, 1996). Para algunos, el manual de 1992 significaba abandonar un enfoque pragmático-científico del retraso mental a favor de uno principalmente político (Matson, 1995). El Comité de Terminología y Clasificación de la AAMR respondió a estas críticas argumentando, en parte, que un sistema basado en la intensidad requerida de apoyo tenía más utilidad que uno basado en el nivel del CI (Luckasson *et al.*, 1996). No obstante, años después de las recomendaciones de la AAMR, muchas descripciones de los sujetos de investigación en la literatura académica utilizan el sistema de clasificación de leve a profundo.

El diagnóstico de discapacitado intelectual, de manera característica, se hace en base a los datos de una medición adecuada de la inteligencia, así como por una medición de la conducta adaptativa. En especial para los evaluados muy jóvenes, se incluyen medidas de capacidad sensorial, motora y sensorio-motriz como parte de una evaluación diseñada para distinguir una deficiencia de un retraso en el desarrollo. Si se desea una estimación de la comprensión del evaluado acerca de conceptos básicos, se puede utilizar una prueba como la Prueba Boehm de conceptos básicos (*Boehm Test of Basic Concepts*) o la Escala Bracken de conceptos básicos-revisada (*Bracken Basic Concept Scale-Revised*). Si se sospecha de autismo o se necesita descartarlo, se pueden aplicar instrumentos especializados de diagnóstico como la Escala de valoración del autismo infantil

SÓLO PIENSE...

¿El sistema de clasificación descrito en la AAMR de 1992 está caracterizado de manera adecuada como un “manual muerto que camina”?

(*Childhood Autism Rating Scale*) o la Evaluación diagnóstica para los gravemente discapacitados-II (*Diagnostic Assessment for the Severely Handicapped-II*; Matson *et al.*, 1998). En esas evaluaciones la familia del evaluado puede hacer una invaluable contribución (Parette y Brotherson, 1996). De manera ideal, el resultado neto de la evaluación será una comprensión del evaluado; no sólo en lo que respecta a la calificación de pruebas estandarizadas y de su posición en relación con sus pares, sino en lo referente a sus deficiencias y excesos conductuales únicos en diversos ambientes (Desrochers *et al.*, 1997; Harris *et al.*, 1996).

Existen varias medidas estandarizadas de conducta adaptativa y los usuarios de las pruebas deben estar al tanto de las conveniencias e inconveniencias de estos instrumentos. Por ejemplo, la Escala AAMR de la conducta adaptativa-escolar: 2 (*AAMR Adaptive Behavior Scale-School: 2* [ABS-S:2; Lambert *et al.*, 1993]) es de alguna manera una anomalía; fue diseñada para medir el desempeño particular al enfrentar las diversas demandas ambientales, pero los campos que se evalúan no concuerdan con el manual de 1992 de la AAMR (Stinnett, 1997). Además, aunque la muestra de estandarización de esta medida es bastante amplia e incluye a personas con discapacidad intelectual ($n = 2\,074$), así como una muestra de personas no discapacitadas ($n = 1\,254$), las personas con discapacidad intelectual con un alto nivel de funcionamiento estuvieron representadas de manera mínima. El resultado es la posibilidad de error en la interpretación con lo cual el funcionamiento adaptativo de los miembros de esta población es sobreestimado (Stinnett, 1997).

El Sistema de evaluación de la conducta adaptativa (*Adaptive Behavior Assessment System*, ABAS; Harrison y Oakland, 2000) fue diseñado para proporcionar una evaluación comprensiva de personas de 5 hasta 89 años de edad en las áreas de habilidades adaptativas especificadas en el manual de la AAMR, como comunicación, grupo social, vida en el hogar, trabajo y salud, así como seguridad. El instrumento, disponible en inglés y español, se presenta en tres formas diferentes, una para padres, otra para maestros (disponible para edades de 5 hasta 21 años) y una forma adulta que puede ser respondida por los mismos evaluados o por su cónyuge, por un familiar u otro proveedor de cuidados. Las calificaciones toman en cuenta tanto la estimación del nivel de funcionamiento como la precisión de las fortalezas y debilidades del individuo. De acuerdo con el manual, también puede tener aplicación en la especificación de metas para personas con discapacidades para el aprendizaje. La prueba fue publicada recientemente. Un enfoque más “clásico” a la evaluación de la conducta adaptativa está incorporado en una prueba conocida de manera simple como “la Vineland.”

La Escala Vineland de madurez social (*Vineland Social Maturity Scale*) fue desarrollada por Edgar A. Doll (1953), quien en ese momento era director de investigación de la Escuela de Capacitación Vineland (*Vineland Training School*) en Vineland, Nueva Jersey. Tres décadas después, la prueba fue revisada y publicada como las Escalas Vineland de conducta adaptativa (*Vineland Adaptive Behavior Scales*, VABS; Sparrow *et al.*, 1984a, 1984b). La prueba revisada, al igual que su predecesora, por lo general es conocida sencillamente como “la Vineland”. En la tradición de su antecesora, enfatiza la competencia social que Doll (1953, p. 2) concibió como “un compuesto funcional de rasgos humanos que está al servicio de la utilidad social que se ve reflejado en la autosuficiencia y el servicio a los demás”. El uso principal de “la Vineland” es para evaluar la conducta adaptativa de los individuos con discapacidades en el desarrollo.

La edición revisada de la Vineland se encuentra disponible en tres formas: la forma de examen de la edición de entrevista, la forma expandida de la edición de entrevista y la edición para el salón de clases. Las dos formas de la edición de entrevista (Sparrow *et al.*, 1984a, 1984b) fueron diseñadas para utilizarse con individuos desde el nacimiento hasta los 18 años de edad, así como con adultos de bajo funcionamiento. Ambas son entrevistas estructuradas que se efectúan con uno de los padres o algún otro informante que esté muy familiarizado con el evaluado. La forma de examen contiene 297 reactivos y requiere de 20 a 60 minutos para su aplicación. La forma expandida es una versión más detallada de la entrevista que contiene 577 reactivos (incluyendo los 297 reactivos de la forma más breve). Su aplicación toma entre 60 y 90 minutos. La tercera forma, la edición para el salón de clases (Sparrow *et al.*, 1985) es una forma de 244 reactivos que debe ser llenada por el maestro y que se enfoca de manera principal en la conducta dentro de un contexto académico. Está diseñada para evaluar a individuos de 3 a 13 años de edad.

Las tres formas de la prueba comprenden las áreas, o dominios, de la vida cotidiana, la socialización, la función motora y la comunicación. Además, las dos formas de la Edición de entre-

vista contienen reactivos relevantes a la conducta adaptativa inadecuada. Para cada dominio, se pide al informante que proporcione datos referentes a conductas existentes. Las habilidades están fragmentadas en conductas componentes de modo que se pueda especificar el nivel de capacidad. Por ejemplo, en el área de las habilidades de la vida cotidiana, se le pregunta al informante acerca de la capacidad del individuo para ponerse los zapatos, incluyendo los elementos individuales de esta capacidad, como atarse las agujetas y hacer un nudo de moño. En el área de las habilidades de socialización, se le puede preguntar al informante acerca del comportamiento del evaluado en la mesa y cualquier otra cosa desde el uso de la servilleta hasta cómo pide las cosas que se encuentran sobre la mesa.

Los datos normativos están disponibles para todas las formas de la Vineland. Para la edición de entrevista, se recopilaron datos sobre alrededor de 4 800 personas sin discapacidad. En la edición para el salón de clases, aproximadamente tres mil niños y adolescentes constituyeron la muestra normativa. Todos los datos de estandarización fueron reunidos a partir de grupos normativos seleccionados a nivel nacional y estratificados con base en el censo estadounidense de 1980 por sexo, región geográfica, tamaño de la comunidad, educación de los padres, raza y grupo étnico. Las calificaciones en bruto de la prueba se convierten a puntuaciones estándar con una media de 100 y una desviación estándar de 15. Las puntuaciones de cada dominio se calculan en forma separada. Una calificación total, denominada Compuesto de conducta adaptativa, incorpora los datos de evaluación provenientes de cada uno de los dominios. Más acerca de los aspectos psicométricos relacionados con esta prueba se presentan en Cohen (2005).

Al igual que en la evaluación de miembros de otras poblaciones, la educación, capacitación y experiencia con miembros de la población de personas con discapacidad intelectual son esenciales para comprender y manejar las preguntas especiales de diagnóstico singulares para esta población (Silka y Hauser, 1997). En los trastornos generalizados del desarrollo, la colaboración multidisciplinaria dentro de la evaluación es especialmente crítica (Volkmar *et al.*, 1996).

Calidad de vida Además del reciente aumento del interés en la evaluación de la conducta adaptativa, ha aumentado el interés en la medición de variables relacionadas con la calidad de vida de las personas con discapacidad intelectual (Hughes *et al.*, 1995; Rosen *et al.*, 1995), así como con otras discapacidades (Renwick *et al.*, 1996; Storey, 1997). Los investigadores han examinado diversas variables tales como la tensión, la soledad, las fuentes de satisfacción y la calidad de las amistades (Rosen *et al.*, 1995; Siperstein *et al.*, 1997). Los investigadores también han tratado de comprender las necesidades y deseos de los padres de niños con desventajas intelectuales (Westling, 1996) y han explorado la manera en que la calidad de vida y otras cuestiones relacionadas pueden variar según la edad (Mast y Lichtenberg, 2000), la discapacidad (Gallagher y MacLachlan, 2000) y la cultura (Keith *et al.*, 1996). La definición de *calidad de vida* varía en los diferentes estudios. En algunas investigaciones, *calidad de vida* se refiere al juicio de un observador acerca del estilo de vida de un sujeto. En otras investigaciones, este mismo término hace referencia a una valoración más subjetiva de la vida propia del sujeto. En beneficio de la uniformidad, Felce (1997) propuso una definición de *calidad de vida* basada en parte en una evaluación de los valores personales, las condiciones de vida y la satisfacción personal. De manera alternativa, Storey (1997) reconoció que la evaluación de las cuestiones referentes a la calidad de vida debe ser, por necesidad, considerablemente amplia debido a que las medidas dependientes apropiadas cambian con el tiempo y con distintas poblaciones.

En relación con las cuestiones de calidad de vida, se ha llevado a cabo una cantidad considerable de investigación acerca del procesamiento de información social (Gómez y Hazeldine, 1996), que incluye asuntos relacionados con la actividad sexual (Lumley y Miltenberger, 1997; Lumley *et al.*, 1998) y el consentimiento a la misma (Parker y Abramson, 1995). Un instrumento diseñado de manera específica para utilizarse en la evaluación del conocimiento y actitudes sexuales de las personas con discapacidad en el desarrollo es la Prueba social-sexual de conocimientos y actitudes (*Socio-Sexual Knowledge & Attitudes Test*; Wish *et al.*, 1980). Los temas que cubre este instrumento incluyen terminología

SÓLO PIENSE...

A la vez que consideramos las diversas cuestiones relativas a la calidad de vida de los evaluados, consideremos también estas cuestiones en cómo atañen al evaluador. Para un evaluador profesional, ¿cuál sería la mayor fuente de satisfacción? ¿La mayor fuente de esfuerzo?




Figura 15-1
La Prueba social-sexual de conocimiento y actitudes

anatómica, menstruación, masturbación, citas, matrimonio, intimidad, coito, embarazo, parto, alcohol y drogas, homosexualidad y enfermedades venéreas (figura 15-1). Debido a que el lenguaje expresivo que se requiere del examinado es mínimo, la mayoría de las respuestas son efectuadas señalando o indicando sí o no. La prueba es idónea para su aplicación en individuos con habilidades o capacidades limitadas de lenguaje. Aunque el manual de la prueba incluye datos normativos acerca de individuos de 18 hasta 42 años de edad con discapacidad en el desarrollo, la intención de los autores de la prueba es que ésta sea utilizada en una forma con referencia a un criterio, más que con referencia a una norma, como medición de lo que el examinado individual sabe, cree, o no sabe. Mediante un procedimiento para probar los límites, el examinador puede emplear algunos de los estímulos pictóricos para explorar la comprensión del examinado acerca de enfermedades como el sida y de conceptos como abuso sexual y acoso sexual.

Evaluación biopsicosocial

Un modelo social de la discapacidad demanda que los psicólogos y otros profesionales que evalúen a individuos con discapacidades se esfuercen realmente por obtener “la imagen completa” en un contexto total de “pantalla amplia”, en lugar de hacer un acercamiento “recortado” enfocado a la patología. Obtener la imagen completa implica utilizar algunas herramientas familiares en formas novedosas, así como utilizar algunas herramientas totalmente nuevas. Este enfoque más amplio de la evaluación está incorporado en lo que se conoce como *evaluación biopsicosocial*. Como su nombre lo implica, la **evaluación biopsicosocial** es un enfoque o modelo de evaluación que incluye una exploración de las variables biológicas, psicológicas, sociales, culturales y ambientales pertinentes además de una evaluación de la forma en que tales variables, de manera independiente o en combinación, afectan al evaluado. Por ejemplo, en un estudio que investigaba los aspectos del proceso de discapacidad en adultos mayores, los investigadores exploraron el papel de factores como la confianza en sí mismo, los recursos intelectuales, y las creencias referentes a qué tanto control en realidad tienen las personas sobre lo que les sucede. Entre sus hallazgos, estuvo el hecho de que un alto grado de **fatalismo** (la creencia de que lo que sucede en la vida está en gran medida fuera del control de la persona) como fue medido en 1974, predecía enfermedades y dificultades cognoscitivas en 1994 (Caplan y Schooler, 2003).

El enfoque biopsicosocial ha sido utilizado por los clínicos en terrenos diferentes al de la evaluación e investigación de la discapacidad, aunque parece adaptado para el nuevo paradigma. Feldman y Rivas-Vázquez (2003) emplearon un enfoque biopsicosocial en su estudio de la evaluación y tratamiento del trastorno por ansiedad social. Concluyeron que las intervenciones fármaco-terapéuticas y psicosociales utilizadas en combinación ofrecían a largo plazo la mejor opción para las personas con este trastorno. Keefe *et al.* (2002) ilustraron el valor del enfoque biopsicosocial en su estudio de la evaluación y tratamiento de la artritis. Por ejemplo, analizaron el uso de las entrevistas a profundidad para identificar los cambios de vida causados por un diagnóstico de artritis, así como las estrategias para enfrentarlo. A este respecto, Blalock *et al.* (1993) observaron que la poca flexibilidad en las conductas para enfrentarlo estaba asociada con una disminución del funcionamiento psicosocial. Keefe y sus colegas también consideraron usar el método de llevar un diario como una herramienta útil para rastrear una diversidad de variables que van desde ejercicios de relajación hasta medidas estandarizadas de estrategias espirituales para enfrentar la situación. Estos investigadores trataron de ver la “imagen completa” que concierne a muchas otras variables como **autoeficacia** (confianza en la capacidad propia para realizar una tarea) y **apoyo social** (expresiones de comprensión, aceptación, empatía, amor, consejo, guía, cuidado, preocupación o confianza en los amigos, familiares, proveedores comunitarios de cuidados u otros en el propio ambiente social).

Una exploración de la cultura y aspectos relacionados es integral a un enfoque biopsicosocial de la evaluación ya que estas cuestiones pueden tener una repercusión en el bienestar, la adaptación o alguna enfermedad del evaluado. Por esta razón, puede ser edificante hacer un “cambio de lentes” y considerar que la discapacidad es una cuestión de diversidad.

SÓLO PIENSE...

Describe lo que usted imagine serían algunos de los elementos esenciales de un programa de evaluación biopsicosocial para pacientes que padecen depresión.

La discapacidad como cuestión de diversidad

Es incuestionable afirmar que “las discapacidades son parte de la diversidad humana” (Leigh *et al.*, 1996, p. 364). Sin embargo, es totalmente diferente afirmar que todos los miembros de un grupo de personas que tienen la misma discapacidad constituyen un grupo cultural concreto. Como señalamos al principio de este capítulo, eso era precisamente lo que alegaban los demandantes en el caso *Tugg vs Towey*, en donde el argumento era que las personas sordas constituyen una minoría cultural distinta, la cual puede ser discriminada de la misma manera que lo son de muchas maneras otras minorías culturales. Concluimos este capítulo con un breve análisis de esta afirmación de acuerdo a como es aplicada a la población separada en la demanda —los individuos sordos— teniendo en mente que se podrían aplicar argumentos análogos a casi cualquier población de personas que tengan la misma discapacidad o una similar.

Discapacidad, diversidad y cultura La mayor parte de cerca del medio millón de personas que no pueden oír la palabra hablada lo suficientemente bien como para comprenderla ya eran sordas antes de cumplir 3 años de edad (Schein y Delk, 1974). En Estados Unidos, estas personas se comunican entre ellas por medio del lenguaje de señas y sus principales contactos sociales son otras personas sordas. Como grupo, los miembros de esta población no sólo tienen un idioma común, sino que también comparten muchas de sus creencias, actitudes, valores, conductas no verbales, normas y tradiciones. En resumen, comparten muchos de los elementos utilizados para definir a un grupo cultural distinto (Dolnick, 1993; Padden, 1980; Paul y Jackson, 1993; Phillips, 1996; Sacks, 1989; Tyler, 1993). De hecho, los miembros de este grupo cultural pueden ser asimilados con relativa facilidad por cualquiera de las diversas comunidades de sordos que existen a lo largo de Estados Unidos (Jankowski, 1991; Padden y Humphries, 1988). Por el contrario, los miembros de este grupo son asimilados por el mundo oyente sólo mediante un gran esfuerzo (Higgins, 1983).

Concebir a los miembros de la población sorda como una minoría cultural distinta más que como personas que tienen la misma discapacidad es útil y terapéutico en el sentido de que el enfoque se desplaza de las deficiencias a la riqueza de la cultura Sorda (Lane, 1992). Recuerde que *Sordo* en este contexto se escribe con S mayúscula para enfatizar que las personas así descri-

tas realmente comparten una cultura común, en oposición a un padecimiento médico (Padden, 1980; Padden y Humphries, 1988; Woodward, 1972). Los miembros de la cultura Sorda tienden a ser altamente respetados por otros que también se identifican a sí mismos como culturalmente Sordos (Phillips, 1996). También hay que señalar que muchos miembros de esta cultura se consideran multiculturales en el sentido de que pertenecen a más de una cultura minoritaria. Las cuestiones multiculturales resultantes que serán consideradas en la evaluación clínica, así como en la intervención, pueden ser complejas (Akamatsu, 1993-1994; Anderson y Grace, 1991; Christensen y Delgado, 1993; Cohen *et al.*, 1990; Eldredge, 1993; Freeman, 1989; Rodríguez y Santiviago, 1991).

La necesidad de sensibilidad A lo largo de este libro, nos hemos referido a la necesidad de la evaluación culturalmente informada y de la sensibilidad al evaluar a personas pertenecientes a culturas con las que el evaluador puede no estar familiarizado o no conocer del todo. Mucho de lo que hemos dicho en este contexto parece aplicarse de manera específica a la evaluación de personas con discapacidad. Las personas que pertenecen a distintas culturas pueden percibir o comprender ciertas experiencias en formas diferentes e interpretarlas contrastándolas con un fondo de sabidurías culturales ampliamente variado. Estas personas pueden actuar de maneras que pueden parecer extrañas, e incluso patológicas, desde nuestra propia perspectiva cultural. Por ejemplo, en la cultura Sorda, es de crucial importancia establecer contacto visual antes de que pueda darse la comunicación —esto se debe a que la comunicación es un medio principalmente visual, no auditivo—. Por consiguiente, las reglas de la cultura Sorda para captar la atención y alternar el permiso para participar en la conversación son completamente diferentes a las reglas de la sociedad en general (Phillips, 1996). Las maneras culturalmente aceptables de captar la atención visual incluyen dar unos golpecitos de manera firme en la mano de la persona con la que deseamos comunicarnos o, si está fuera del alcance, agitar la mano para atraer su atención. Tal conducta puede parecer extraña a una persona no acostumbrada, pero es muy cotidiana dentro de la cultura Sorda.

Es obligación del profesional de la salud mental evitar los escollos relacionados con la cultura en la evaluación y el tratamiento. Uno de estos escollos se deriva de la adherencia refleja a las propias verdades culturales sin dar suficiente consideración al mundo como es visto por las personas que provienen de circunstancias diferentes, incluyendo a las personas con condiciones discapacitantes.

Autoevaluación

Evalúe su comprensión de los elementos del presente capítulo intentando explicar cada uno de los siguientes términos, expresiones y abreviaturas:

AAMR	cuestiones de la evaluación	ejemplos de adaptación para
actividad vital importante (como lo sugiere la ADA)	alternativa	discapacidades motoras
adaptación	discapacidad cognoscitiva	ejemplos de adaptación para
adaptación por medio de evaluaciones alternativas	discapacidad (definición de la ADA)	discapacidades visuales
ADA	discapacidad como asunto de	evaluación biopsicosocial
apoyo social	diversidad	fatalismo
autoeficacia	discapacidad funcional	IDEA
caso de discapacidad percibida	ejemplos de adaptación para	infante o menor de edad con
conducta adaptativa	discapacidades cognoscitivas	discapacidad
	ejemplos de adaptación para	infante o menor de edad en riesgo
	discapacidades auditivas	(según la IDEA)

intensidad de apoyos (en la definición de la AAMR) "la Vineland"	Ley de Reformas Educativas de 1997 para individuos con discapacidades	modelo social de la discapacidad
Ley de educación para todos los niños discapacitados	Ley Pública 94-142	niño de 3 a 9 años de edad con discapacidad (según la IDEA)
Ley de los derechos de los ciudadanos estadounidenses con discapacidades de 1990	Ley Pública 99-457	niño con discapacidad (en general, de acuerdo a la IDEA)
Ley de Rehabilitación	Ley Pública 101-336	nuevo paradigma de la discapacidad
Ley de Rehabilitación de 1973	Ley Pública 101-476	QUID
	Ley Pública 105-17	retraso en el desarrollo
	mercenario	
	modelo médico de la discapacidad	

Un vistazo a la red

Visite los siguientes sitios en la red para mayor información acerca de los temas que se analizaron en el presente capítulo.

Rehabilitation Act

www.section508.gov

IDEA

www.ed.gov/offices/OSERS/Policy/IDEA/index.html

www.ideapractices.org

Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades de 1990

www.usdoj.gov/crt/ada/adahom1.htm

AAMR

www.aamr.org

La Escala Callier-Azusa

www.callier.utdallas.edu/scale.html

www.winfssi.com/history.html

Retraso en el desarrollo

www.devdelay.org

www.med.umich.edu/1libr/yourchild/devdel.htm

Iniciativa de nueva libertad

www.whitehouse.gov/news/freedominitiative/freedominitiative.html

QUID

www.wierlaw.com/glossary%20employment%20law.htm
#americansdisabilities

Evaluación, profesión y negocios

¿Qué quieres ser cuando seas grande?

Parece que fue ayer cuando nos hicieron esa pregunta. Para algunos de nosotros, en realidad sí fue ayer.

Las preguntas y preocupaciones acerca de la elección de una carrera no son poco comunes entre los estudiantes universitarios y otros individuos que contemplan una transición de estudiantes a miembros de la fuerza laboral (Collins, 1998). Y tales preguntas y preocupaciones no se limitan en absoluto a las personas que se enfrentan por primera vez al mundo del trabajo. Millones de personas que ya tienen una profesión están contemplando cambios en ella (Heppner *et al.*, 1994).

SÓLO PIENSE...

¿Cómo cree usted que la mayoría de la gente decide cuál será su profesión? ¿Qué factores participaron (o participarán) en su propia decisión vocacional?

Los profesionales que se ocupan de la orientación vocacional tienen cientos de herramientas a su disposición para ayudar a sus clientes a identificar cuál es la labor en la que podrían tener éxito y disfrutar realizándola. En este capítulo examinamos algunas de estas herramientas, así como una amplia variedad de instrumentos y procedimientos relacionados. Tal vez a usted le interesen algunas de las pruebas que analizamos para ser utilizadas en el proceso para elegir una carrera. Si es así, lo exhortamos a obtener una experiencia de primera mano con ellas. Posteriormente en el capítulo veremos que muchas de las pruebas que examinamos están diseñadas para ser utilizadas en empresas u otras organizaciones al servicio de diversos objetivos organizacionales.

Comencemos con una mirada a algunos de los tipos de instrumentos utilizados para ayudar en la elección de una carrera y en un cambio de profesión.

Elección vocacional y transición profesional

Hay una generalidad de pruebas disponible para ayudarle en varias etapas de la elección de una carrera. Existen pruebas que miden los intereses, aptitudes, habilidades o talentos especiales. Hay otras que miden las actitudes hacia el trabajo, la confianza en las suposiciones sobre las carreras, las percepciones acerca de las barreras vocacionales, incluso en las propias habilidades y los pensamientos vocacionales disfuncionales. Existe un instrumento diseñado para medir los recursos psicológicos de los adultos en la transición profesional (Heppner, 1998) y uno que identifica a los estudiantes que están indecisos acerca de los objetivos de su vocación (Larson y Majors, 1998). Las variables que se consideran importantes para la elección ocupacional difieren desde si a uno



Figura 16-1
¡No es sólo un trabajo, es una aventura!

Si el doctor Orin Scrivello (Steve Martin) en la comedia La tiendita de los horrores, hubiera respondido un inventario de intereses, los resultados habrían sido bastante extraños. Cuando era niño, los intereses del pequeño Orin consistían en golpear en la cabeza a los gatitos, disparar a los cachorritos con un rifle de aire y envenenar pececitos. Tuvo la posibilidad de dar un buen uso a lo que su madre describía como sus “tendencias naturales” en un empleo remunerado: se volvió dentista.

“le gusta tratar con personas” (Roe y Klos, 1969) hasta si un ambiente laboral particular evidencia lo mejor de un trabajador en particular (Moos, 1986)

De manera documentada, una variable que se considera está estrechamente relacionada con la realización y el éxito profesional se refiere a los intereses personales. Es obvio que aquello que nos interesa, ocupa y absorbe sería bueno como trabajo. De hecho, los intereses de un individuo pueden estar lo suficientemente solidificados cuando llega a los 15 años de edad como para que le sean útiles en el curso y planificación de una carrera (Care, 1996). Además, la evidencia sugiere que esos intereses serán bastante estables a lo largo del tiempo (Savickas y Spokane, 1999). Siendo así, ¿cuáles son algunas pruebas para medir los intereses y cómo las utilizan los evaluadores profesionales?

Pruebas de intereses

Suponiendo que el interés de alguien en el trabajo es que éste promueva un mejor desempeño, una mayor productividad y una mayor satisfacción, tanto los empleadores como los futuros empleados tendrían mucho que ganar con los métodos que ayuden a los individuos a identificar sus intereses y los empleos adaptados a tales intereses. Al utilizar esos métodos, los individuos pueden descubrir, por ejemplo, si sus intereses están puestos en pilotear una nave espacial, “buscar nuevos mundos y explorar nuevas civilizaciones” o puestos en el área de la odontología (figura 16-1).

Las empresas pueden usar la información sobre los patrones de intereses de sus empleados para formular descripciones de los puestos y atraer a nuevo personal. Por ejemplo, una compañía podría diseñar una campaña de empleo enfatizando la seguridad en el trabajo, si se encuentra que la seguridad es el principal interés de los trabajadores exitosos que actualmente tienen puestos similares. Aunque existen muchos instrumentos diseñados para medir los intereses, nuestro análisis se enfoca en el que tiene la historia más larga de uso continuo, el Inventario de intereses de Strong (*Strong Interest Inventory*, SII).

SÓLO PIENSE...

Visualice un anuncio del "Aviso Oportuno" que comience: "Solicitamos: empleados interesados en _____". Llene el espacio en blanco con cada uno de sus propios intereses. A continuación, haga una lista de los posibles puestos que este empleador podría estar anunciando.

Inventario de intereses de Strong Una de las primeras pruebas de los intereses fue publicada en 1907 por el psicólogo G. Stanley Hall. Su cuestionario fue diseñado para evaluar el interés de los niños en diversas ocupaciones recreativas. No fue sino hasta los inicios del decenio de 1920 que Edward K. Strong, Jr., inspirado por un seminario

acerca de la medición de intereses al que asistió, comenzó un programa de investigación sistemática en esta área. Sus esfuerzos culminaron en una prueba de 420 reactivos llamada originalmente Objetivos de intereses vocacionales de Strong (*Strong Vocational Interest Blank*, SVIB).

Diseñado originalmente para utilizarse sólo con hombres, el SVIB fue publicado con un manual de prueba por la Stanford University Press en 1928 y después, en 1938, fue revisado. En 1935, se publicó un SVIB para mujeres con 410 reactivos, junto con un manual de prueba. El SVIB para mujeres fue revisado en 1946. Ambos SVIB fueron revisados nuevamente a mediados de la década de 1960. En medio de preocupaciones acerca de las formas específicas para cada sexo, a finales del decenio de 1960 y principios del de 1970 (McArthur, 1992), en 1974 se publicó una forma mixta. Desarrollada bajo la dirección de David P. Campbell, la forma mixta fue nombrada Inventario de intereses Campbell-Strong (*Strong-Campbell Interest Inventory*, SCII). La prueba fue revisada en 1985 y de nuevo en 1994. En la actualidad la prueba se llama Inventario de intereses de Strong (*Strong Interest Inventory*, SII; Strong *et al.*, 1985; Harmon *et al.*, 1994). Aunque se utiliza una sola forma tanto para hombres como para mujeres, pueden esperarse diferencias de género en los patrones de interés (Fouad, 2002), así como en las expresiones de confianza y eficiencia personal en diversas áreas (Rottinghaus *et al.*, 2003).

La receta de Strong para la construcción de la prueba fue empírica y directa: 1) seleccionar cientos de reactivos que pudieran de manera concebible distinguir los intereses de una persona según su ocupación; 2) aplicar esta clase imperfecta de prueba a varios cientos de personas seleccionadas como representativas de ciertas ocupaciones o profesiones; 3) separar los reactivos que hayan sido de interés para las personas de acuerdo al grupo ocupacional y eliminar los reactivos sin capacidad de discriminación y 4) construir una versión final de la prueba que pudiera producir puntuaciones que describan la manera en que el patrón de intereses del examinado corresponde con los patrones de intereses de las personas que actualmente trabajan en diversas ocupaciones y profesiones. Por ejemplo, con una prueba de este tipo, los estudiantes universitarios en el área de psicología podrían ver qué tan cercanos son sus intereses a los intereses de los psicólogos que ya trabajan en el área. Supuestamente, si los intereses de un individuo se equiparan de manera estrecha con los de los psicólogos (en contraste con los intereses de, digamos, el operador de una grúa), es probable que ese individuo disfrutará el trabajo de psicólogo.

Los reactivos de la prueba, todos escritos en un formato de opción múltiple, indagan las preferencias personales respecto a materias escolares, ocupaciones, diversiones, actividades y otras variables. También se pide a los respondientes describirse a sí mismos con afirmaciones (como "me resulta fácil hacer amigos"), indicando *sí*, *no* o *no sé*. Cada protocolo se califica e interpreta por computadora, lo cual produce información sobre el estilo personal, intereses básicos y otros datos del examinado que son útiles para determinar qué tan similares o diferentes son sus intereses en comparación con los intereses de personas que tienen diversos empleos.

La muestra de estandarización para la revisión de 1994 incluyó a un grupo de referencia ocupacional formado por adultos con empleos en 50 profesiones diferentes y un grupo general de referencia. Para ser incluidos como miembro del grupo de referencia ocupacional, los respondientes debían haber afirmado que les agrada su trabajo y haber laborado en ese empleo por lo menos tres

años. El grupo general de referencia sirvió como una especie de grupo testigo, seleccionado para representar a hombres y mujeres en general. Las minorías fueron representadas en ambos grupos de referencia, ocupacional y general. Un estudio sobre la validez del SII relacionada con un criterio entre grupos raciales-étnicos respaldó el uso de la prueba con personas de diferentes antecedentes culturales, en particular aquellos con educación universitaria (Lattimore y Borgen, 1999). En general, la prueba es sólida en el aspecto psicométrico.

¿Qué tan bien predicen las pruebas de intereses el tipo de trabajo en el que los individuos serán exitosos y felices? En general, las pruebas de intereses y aptitudes se correlacionan en un rango de alrededor de .40 hasta .72 (Lam *et al.*, 1993). En uno de los pocos estudios que examinan la precisión con la que las pruebas de intereses y aptitudes pronostican el futuro desempeño y satisfacción en el trabajo, Bizot y Goldman (1993) identificaron a las personas que habían sido evaluadas durante su educación media superior con pruebas de intereses y aptitudes vocacionales. Ocho años después, estos individuos hicieron una descripción detallada acerca de su satisfacción con su empleo, permitiendo incluso que los investigadores se comunicaran con sus empleadores para pedir información sobre la calidad de su trabajo.

Los investigadores encontraron que cuando ha existido una buena relación entre las aptitudes del sujeto en la preparatoria y el nivel en su empleo actual, es probable que el desempeño sea evaluado positivamente por el empleador. Cuando ha existido una relación deficiente entre las aptitudes del sujeto de acuerdo a su medición en la preparatoria y el nivel actual en el empleo, es más probable que se obtenga una evaluación deficiente del desempeño por parte del empleador. El grado en que los empleados estaban satisfechos con sus trabajos no estaba relacionado con las aptitudes de acuerdo a las pruebas de aptitudes aplicadas en la educación media superior. Respecto a la validez de predicción, las pruebas de intereses aplicadas durante la educación media superior no pronosticaban ni el desempeño laboral ni la satisfacción con el empleo ocho años después. Los resultados de éste y otros estudios relacionados (por ejemplo, Jagger *et al.*, 1992) hacen una advertencia a los orientadores vocacionales respecto a la dependencia exagerada de los inventarios de intereses. Sin embargo, este género de pruebas parece dar a la orientación vocacional una dimensión no proporcionada por muchas otras pruebas.

SÓLO PIENSE...

¿Las personas se interesan en las cosas que hacen bien o desarrollan habilidades en las áreas que les interesan?

Otros inventarios de intereses Además del SII, muchos otros inventarios de intereses son utilizados ampliamente hoy día y existe una superposición entre aquello que miden (Savickas *et al.*, 2002). La Investigación autodirigida (*Self-Directed Search*) explora los intereses dentro del contexto de la teoría de Holland de los tipos vocacionales de personalidad y ambientes laborales. Según esa teoría, la elección vocacional es una expresión de uno de seis tipos de personalidad: realista, investigadora, artística, social, emprendedora o convencional (abreviado como RIASEC o los **seis grandes**). Es interesante señalar que en una investigación con estudiantes de educación media superior que respondieron una versión de papel y lápiz y una versión en línea de la Investigación autodirigida, se encontró que las escalas realista, social y emprendedora tuvieron puntuaciones más altas en la aplicación en línea, mientras que las otras tres escalas no fueron diferentes en términos estadísticos (Barak y Cohen, 2002). Este resultado puede impulsar una mayor exploración de las posibles diferencias entre las aplicaciones en línea y mediante papel y lápiz para los inventarios de intereses.

El Inventario de intereses vocacionales de Minnesota (*Minnesota Vocational Interest Inventory*) es un instrumento codificado de manera empírica diseñado para comparar los patrones de intereses de los respondientes con los de las personas que laboran en diversas ocupaciones no profesionales (como almacenistas, pintores, impresores y conductores de camiones). Varias pruebas de intereses fueron diseñadas para utilizarse con personas que no saben leer bien, utilizan dibujos y otros medios visuales como diapositivas y películas (Elksnin y Elksnin, 1993). En la tabla 16-1 se presenta una lista de diversas pruebas de intereses.

Ciertas investigaciones sugieren que las pruebas de intereses pueden tener más utilidad, significado o validez cuando se aplican en combinación con otras pruebas de confianza y eficacia personal (Chartrand *et al.*, 2002; Rottinghaus *et al.*, 2003), personalidad (Larson y Borgen, 2002; Staggs *et al.*, 2003) o un proyecto de portafolios (Larkin *et al.*, 2002). De hecho, existe la tendencia

Tabla 16-1
Algunas pruebas de intereses

Prueba	Descripción
Estudio Campbell de intereses y habilidades	Desarrollado por David Campbell, quien revisó el Inventario de intereses de Strong, este instrumento se enfoca en ocupaciones que requieren cuatro años o más de educación posterior a la secundaria. Además de evaluar los intereses, fue diseñado para proporcionar un estimado de la confianza del individuo en la ejecución de diversas actividades laborales.
Inventario de intereses profesionales	Diseñado para utilizarse con alumnos del séptimo al doceavo grado y con adultos, esta prueba introduce a los examinados al mundo de las alternativas laborales y educativas. Además de los intereses relacionados con una carrera, la prueba incluye los intereses escolares y actividades relacionadas con la escuela.
Sistema de información para orientación	Disponible sólo en disco o CD-ROM, esta combinación de instrumento de evaluación y sistema de recuperación de información contiene varios componentes que varían desde información sobre universidades hasta datos sobre los tipos de empleos que los egresados universitarios de diferentes áreas tienden a obtener. El componente de evaluación de intereses del sistema se denomina Sistema de toma de decisiones profesionales (<i>Career Decision-Making System</i>). Después de sondear los intereses de la persona evaluada, se calculan calificaciones de intereses y el sistema proporciona listas de las carreras y ocupaciones sugeridas que podrían llamar la atención del evaluado.
Estudio Jackson de interés vocacional	Ésta es una medida de opción forzada de los intereses según su relación con 26 posiciones laborales (lo que uno desempeña en el trabajo) y 8 estilos laborales (el tipo de ambiente laboral preferido, generalmente relacionado con los propios valores personales). La prueba fue diseñada para utilizarla con estudiantes de educación media superior y universidad, y produce calificaciones en diez temas del tipo Holland, e índices relacionados con la validez. El desarrollo de esta prueba ha sido descrito en detalle por Jackson (1977; Jackson y Williams, 1975).
Estudio Kuder de intereses ocupacionales (KOIS)	Este instrumento clásico de la medición de los intereses es un derivado del Registro de preferencias Kuder, que fue publicado en 1939. Cada reactivo presenta a los examinados tres opciones de actividad y la tarea es seleccionar las opciones más y menos preferidas. Las calificaciones se reportan en función de la magnitud del interés en diversas categorías ocupacionales. La prueba ha recibido críticas por su falta de validez de predicción, una afirmación que ha sido atendida por el autor de la prueba y sus colegas (Kuder <i>et al.</i> , 1998; Zytowski, 1996).
Inventario de intereses vocacionales sin lectura	Diseñada para utilizarla con personas de 10 años de edad y mayores con discapacidades para el aprendizaje, discapacidad intelectual u otras necesidades educativas especiales, esta prueba mide las preferencias y los rechazos vocacionales utilizando imágenes de personas trabajando en diversas labores. En cada reactivo, los individuos seleccionan uno de tres dibujos que representa la tarea laboral preferida. El protocolo proporciona calificaciones en 11 categorías ocupacionales que representan los tipos de trabajos en los que los miembros de las poblaciones especiales podrían obtener empleo.
Investigación autodirigida-Forma R	Desarrollado por John L. Holland, este inventario de intereses es autoaplicable, autocalificable y autointerpretable, apropiado para individuos de 12 años y mayores. La Forma R (1994) contiene normas actualizadas. Los examinados responden un folleto en el que se les hacen preguntas sobre diversas áreas relacionadas con los intereses, incluyendo actividades, aspiraciones y capacidades.

a unificar muchos de estos constructos, como lo señalaron Spokane y Decker (1999): “Es cada vez más evidente que los intereses, personalidad, eficacia personal y otras variantes de la personalidad y el autoconcepto vocacional pueden ser facetas de un conjunto unificado de rasgos subyacentes complejos” (p. 230).

Recientemente, un grupo de investigadores tomó el muy trillado constructo de intereses y lo “elevó un grado más arriba” al analizarlo en función de la *pasión* (Vallerand *et al.*, 2003). Estos investigadores distinguieron entre dos tipos: *pasión obsesiva* y *pasión armoniosa*. Ambos tipos fueron concebidos como derivados de la presión interna para comprometerse en la actividad que a uno le agrada. Sin embargo, mientras se consideraba que la pasión armoniosa promueve la adaptación sana, se pensaba que la pasión obsesiva nos desvía de ella. La pasión obsesiva conduce a una persistencia rígida, que a su vez produce afecto negativo. Será interesante observar el grado en que la *pasión* entra al vocabulario de los investigadores del desarrollo profesional en el futuro.

Pruebas de capacidad y aptitud

Como vimos en el capítulo 10, las pruebas de aprovechamiento, capacidad y aptitud miden en cierto grado el aprendizaje previo, pero difieren en los usos que se darán a los datos de la prueba. Más allá de esto, las pruebas de aptitud pueden utilizar una mayor cantidad de aprendizaje informal que las pruebas de aprovechamiento. Estas últimas pueden ser más limitadas y enfocadas que las pruebas de aptitud.




Figura 16-2
La Prueba O'Connor de destreza con las pinzas

Las pruebas de capacidad y aptitud varían ampliamente en los temas que cubren, en la especificidad de cobertura y otras variables. La Prueba Wonderlic para el personal (*Wonderlic Personnel Test*) mide la capacidad mental en un sentido general. Esta breve prueba (12 minutos) incluye reactivos que evalúan habilidad espacial, pensamiento abstracto y habilidad matemática. La prueba puede ser útil en la selección de individuos para empleos que requieren capacidades intelectuales tanto fluidas como concretas (Bell *et al.*, 2002).

La Prueba Bennet de comprensión mecánica (*Bennet Mechanical Comprehension Test*) es una medida ampliamente aplicada con papel y lápiz acerca de la capacidad de un examinado para comprender la relación entre las fuerzas físicas de diversas herramientas (por ejemplo, poleas y transmisiones), así como otros objetos comunes (carretas, escaleras y balancines). Otras pruebas mecánicas como la Prueba de destreza para manipular herramientas (*Hand-Tool Dexterity Test*), enturbian la división entre las pruebas de aptitud, logro y desempeño al requerir que el examinado desarme, vuelva a armar o manipule de alguna otra manera los materiales, generalmente en una secuencia predeterminada, dentro de un tiempo límite. Si un trabajo consiste principalmente en fijar diminutos transistores en el mecanismo interno de enseres o juegos electrónicos, entonces el foco de interés del empleador bien podría estar en las capacidades perceptivas-motoras, la destreza con los dedos y variables relacionadas de los posibles empleados. En tal caso, la Prueba O'Connor de destreza con las pinzas (*O'Connor Tweezer Dexterity Test*) podría ser el instrumento de preferencia (figura 16-2). Esta prueba requiere que la persona examinada inserte clavijas de latón en una plancha de metal utilizando un par de pinzas.

Otras pruebas diversas están diseñadas para medir las aptitudes específicas en una amplia variedad de áreas laborales. Para las profesiones, existen varios programas sofisticados de evaluación en el aspecto psicométrico para elegir o seleccionar a los solicitantes por medio de pruebas de aptitud. Una extensa lista de estas pruebas, como la Prueba de admisión a la Facultad de Medicina (*Medical College Admissions Test*, MCAT), se presentó en el capítulo 10. Durante un tiempo, una de las pruebas de aptitud más ampliamente utilizada fue la Batería de pruebas de aptitudes generales (*General Aptitude Test Battery*, GATB). A continuación se presenta una descripción de esa prueba, así como de la controversia que la rodea.

SÓLO PIENSE...

¿Qué tipo de tareas "de la vida real" podrían incluirse en una nueva prueba de aptitudes diseñada para seleccionar a los candidatos a ser admitidos en un programa de graduados en pruebas y evaluación psicológica?

Batería de pruebas de aptitudes generales El Servicio de Empleo de Estados Unidos (United States Employment Service, USES) desarrolló la Batería de pruebas de aptitudes generales (GATB) y comenzó a utilizarla en 1947, después de una extensa investigación y desarrollo. La GATB (que en inglés se pronuncia como “Gatsby” sin la s) está disponible para ser utilizada por los servicios estatales de empleo al igual que por otras instituciones y organizaciones, como distritos escolares y organizaciones sin fines de lucro, que hayan obtenido permiso oficial del gobierno para aplicarla. La GATB es una herramienta que se utiliza para identificar las aptitudes para las ocupaciones y que pueden contestar casi todas las personas en edad laboral. La prueba se aplica regularmente en oficinas estatales locales (a las que se refieren por nombres como Servicios de trabajo, Comisión de seguridad en el empleo y Comisión de seguridad laboral) a personas que desean que la institución les ayude a encontrar un trabajo. También es posible aplicarla a personas desempleadas que han sido recomendadas por una oficina estatal de desempleo o a empleados de una empresa que haya solicitado esa evaluación de aptitudes.

Si usted tiene curiosidad acerca de su propia aptitud para el trabajo en campos tan diversos como la psicología, la educación y la plomería, es posible que quiera visitar la oficina estatal local de empleo y aplicarse usted mismo la GATB. Prepárese a tomar un examen que requerirá alrededor de tres horas si la presenta toda. La GATB consiste en 12 pruebas cronometradas que miden nueve aptitudes, que a su vez pueden dividirse en tres aptitudes compuestas. Cerca de la mitad del tiempo se ocupa en tareas psicomotoras y la otra mitad en tareas que usan papel y lápiz. En algunos casos, dependiendo de factores como el motivo de la evaluación, sólo se aplicarán pruebas seleccionadas de la batería. La versión de la prueba que se utiliza para medir selectivamente las aptitudes para un empleo específico se conoce como Batería de pruebas de aptitudes especiales (*Special Aptitude Test Battery* o SATB). Los datos de la SATB también se pueden aislar de otros datos de prueba cuando se aplica la batería completa.

La GATB ha evolucionado a partir de una prueba con límites múltiples a una que emplea regresión y *generalización de validez* para hacer recomendaciones basadas en los resultados de la prueba. John E. Hunter (1980, 1986), Frank Schmidt y sus colaboradores (Hunter y Schmidt, 1983; Hunter *et al.*, 1982; Hunter y Hunter, 1984) han descrito el razonamiento y el proceso mediante el cual evolucionó la GATB; la generalización de validez es el tema del *Close-up* en este capítulo.

En el pasado, las recomendaciones respecto a la aptitud para un empleo particular se realizaban con base en los estudios de validez de la GATB que trataban sobre trabajos específicos. Por ejemplo, si existían 500 descripciones de puestos que abarcaban 500 empleos a los que se aplicaban las calificaciones de la GATB, habría 500 estudios individuales de validación con la batería; un estudio de validez para cada empleo individual, característicamente con una muestra de magnitud relativamente pequeña (muchos de estos estudios individuales sólo incluían a un promedio de 76 sujetos). Además, no había estudios de validación para los otros 12 000 o más empleos dentro de la economía estadounidense (según el *Diccionario de puestos ocupacionales* [*Dictionary of Occupational Titles*] publicado por el Departamento de Trabajo de Estados Unidos, 1977).

Utilizando un metaanálisis para reunir los resultados de varios estudios de validación y corregir errores de manera estadística como el error de muestra, Hunter demostró que todos los empleos podían clasificarse dentro de cinco familias laborales, basándose en los *códigos de función del trabajador* del *Diccionario de denominaciones ocupacionales*. Las cinco familias laborales son 1) Construcción, 2) Alimentación y producción, 3) Síntesis y coordinación, 4) Análisis, compilación y cómputo y 5) Copia y comparación. Después desarrolló ecuaciones de regresión para cada una de las familias; por medio de estas ecuaciones, Hunter encontró que las recomendaciones para cada persona examinada podían ser generalizadas para diversos empleos.

A finales de la década de 1980, la GATB se volvió centro de controversia cuando se hizo del conocimiento público que la prueba había sido normalizada según la raza. Como lo determinamos en el capítulo 4, establecer una norma por raza se refiere al proceso de ajustar las calificaciones para que muestren la posición de cada examinado dentro de su propio grupo racial. Con la GATB normalizada de acuerdo a la raza, quienes obtenían calificaciones altas eran clasificados dentro de ciertos grupos de acuerdo a la raza y recomendados para el empleo. Por ejemplo, entre las personas que habían sido consideradas para un empleo especializado, una calificación natural de 300 en la GATB se “traducía en puntuaciones percentiles de 79, 62 y 38, respectivamente,

Generalización de la validez y la GATB

Una prueba validada que será utilizada en la selección de personal para una ocupación específica puede ser válida también para usarse en la selección de personal en otra ocupación? ¿La validación de una prueba utilizada en la selección de personal debe ser específica para una situación? Dicho en términos más generales, ¿la evidencia de validez de una prueba puede aplicarse de manera significativa a otras situaciones diferentes de aquellas en las que se obtuvo la evidencia? Éstos son los tipos de preguntas que surgen cuando se analiza la generalización de la validez.

Según su aplicación en la toma de decisiones relacionadas con el empleo en base a las calificaciones de prueba obtenidas en la Batería de pruebas de aptitudes generales (*General Aptitude Test Battery*, GATB), la *generalización de la validez* se refiere al hecho de que los mismos datos de calificación de la prueba pueden pronosticar la aptitud para todos los empleos; la implicación es que si una prueba es validada para unos cuantos trabajos seleccionados de un conjunto mucho más amplio de empleos —cada uno de los cuales requiere de habilidades similares con el mismo nivel aproximado de complejidad— la prueba es válida para todos los empleos de ese conjunto. Por ejemplo, si un estudio de validez indicó de manera concluyente que las calificaciones de la GATB pronostican la aptitud (y principalmente la capacidad) de la ocupación de ensamblador en una planta de armado de aeronaves, puede no ser necesario un nuevo estudio de validez para aplicar esos datos a la ocupación de ensamblador en un astillero; si puede demostrarse que el tipo y nivel de habilidad requeridos en ambas ocupaciones son suficientemente similares, es posible que los procedimientos iguales o similares para seleccionar a los ensambladores de aeronaves puedan ser utilizados de manera útil para seleccionar a los ensambladores de barcos.

La generalización de validez (GV), según es aplicada a la selección de personal utilizando la GATB, hace innecesaria la tarea de realizar un estudio independiente de validación con la prueba para todos y cada uno de los 12 000 empleos dentro de la economía estadounidense. La aplicación de la GV para las calificaciones de la GATB permite que los usuarios de la batería proporcionen a los empleadores información más precisa acerca de las personas evaluadas. Para comprender por qué esto es así, comencemos consultando la gráfica de pastel en la figura 1.

Observe que el círculo interno de la gráfica enumera las 12 pruebas en la Batería de pruebas de aptitudes generales y el siguiente anillo del círculo incluye las ocho aptitudes derivadas de las 12 pruebas. No se grafica ni aparece una novena aptitud, la Capacidad general de aprendizaje, que se deriva de las calificaciones de las pruebas de Vocabulario, Aritmética, Razonamiento y Espacio tridimensional. A continuación presentamos una breve descripción de cada una de las ocho aptitudes pruebas con la GATB:

- **Aptitud verbal (V):** La comprensión del significado de las palabras y sus relaciones así como el uso efectivo de las palabras son dos de las habilidades comprendidas aquí. La V se mide con la Prueba 4.




Figura 1
Aptitudes que se miden con la Batería de pruebas de aptitudes generales

- **Aptitud numérica (N):** La N se mide con tareas que requieren la ejecución rápida de operaciones aritméticas. Es medida con las Pruebas 2 y 6.
- **Aptitud espacial (S):** Aquí se incluye la capacidad para visualizar y manipular mentalmente figuras geométricas. La S se mide con la Prueba 3.
- **Percepción de formas (P):** Aquí se mide la atención a los detalles, incluyendo la capacidad para distinguir ligeras diferencias en figuras, matices, longitud y amplitud, al igual que la capacidad para percibir los detalles pertinentes. La P es medida por las Pruebas 5 y 7.
- **Percepción en tareas administrativas (Q):** Este aspecto comprende la atención al detalle en material escrito o tabular, así como la capacidad para corregir palabras y números y evitar los errores de percepción en cálculos aritméticos. La Q se mide con la Prueba 1.
- **Coordinación motora (K):** En esta prueba se aplica la capacidad para hacer con rapidez movimientos precisos que requieren de coordinación viso-motriz. La K es medida por la Prueba 8.
- **Destreza con los dedos (F):** Esta prueba utiliza la capacidad para manipular con los dedos y de forma precisa objetos pequeños. La F se mide con las Pruebas 11 y 12.
- **Destreza manual (M):** Aquí se mide la capacidad para trabajar con las propias manos haciendo movimientos de colocación y rotación. La M se mide con las Pruebas 9 y 10.

(continúa)

Generalización de la validez y la GATB (continuación)

Observe que de las nueve aptitudes específicas en el anillo exterior del diagrama se derivan tres aptitudes compuestas: un compuesto Cognitivo, un compuesto de Percepción y un compuesto Psico-motor. Las nueve aptitudes que forman las tres aptitudes compuestas pueden resumirse de la siguiente manera:

Las nueve aptitudes de la GATB		Las tres calificaciones compuestas
G	Capacidad general para el aprendizaje (también denominada <i>inteligencia</i>)	Cognoscitiva
V	Aptitud verbal	
N	Aptitud numérica	
S	Aptitud espacial	Perceptiva
P	Percepción de formas	
Q	Percepción de tareas administrativas	
K	Coordinación motora	Psico-motora
F	Destreza con los dedos	
M	Destreza manual	

Por tradición —antes de la aparición de la GV— las personas evaluadas que presentaban la GATB podían de manera subsecuente recibir orientación acerca de su desempeño en cada una de las nueve áreas de aptitud. Además, podían recibir información sobre 1) la manera en que se compara su propio patrón de calificaciones en la GATB con patrones de aptitud (conocidos como Patrones de aptitud ocupacional, o PAO) considerados necesarios para el desempeño de capacidades en diversas ocupaciones y 2) cuál había sido su desempeño respecto a cualquiera de las 467 constelaciones de una Prueba de baterías de aptitudes especiales (*Special Aptitud Test Battery*, SATB) que posiblemente pudieran ser extraídas de un protocolo de la GATB. La GV proporciona información adicional útil para aconsejar a los probables empleadores y orientar a los posibles empleados, incluyendo datos más precisos acerca del desempeño del examinado respecto a los PAO, al igual que calificaciones (generalmente expresadas en percentiles) relacionadas con las cinco familias laborales.

La investigación (Hunter, 1982) ha indicado que las tres aptitudes compuestas pueden utilizarse para predecir de manera válida la destreza laboral en todos los empleos de la economía de Estados Unidos. Todos los empleos pueden ser agrupados de acuerdo con cinco familias laborales y la aptitud requerida para cada una de estas familias puede ser descrita respecto a los diversos factores que contribuyen a las tres puntuaciones compuestas de la GATB. Por ejemplo, la familia laboral 1 (empleos de la construcción) es 59% cognoscitiva, 30% perceptiva y 11% psicomotora. La calificación de la GATB se realiza por computadora, como lo es la

ponderación de las calificaciones para determinar la utilidad para el empleo en cada una de las cinco familias laborales.

Los defensores de la GV, de acuerdo a su aplicación para ser usadas con la GATB, enumeran las siguientes ventajas:

1. *La disminución del énfasis en los límites múltiples como una estrategia de selección tiene ventajas tanto para los probables empleadores como para los posibles empleados.* En un modelo de selección de límites múltiples, un empleado viable tendría que lograr ciertas calificaciones mínimas en la GATB en cada una de las aptitudes consideradas decisivas en la ejecución de una ocupación dada; la incapacidad para obtener una calificación mínima límite en estas aptitudes implicaría la eliminación de la reserva de candidatos para esa ocupación. Utilizando la GV, un beneficio posible para el empleado viable es que se elimina el requerimiento de una calificación mínima límite en alguna aptitud específica. Para los empleadores, la GV alienta el uso de una política de contratación de superior a inferior, en la que el empleo es ofrecido en primer lugar a las personas más calificadas (pruebas de acuerdo con la GATB).
2. *La investigación ha sugerido que la relación entre las calificaciones de la prueba de aptitud y el desempeño laboral es lineal* (Waldman y Avolio, 1989), *una relación estadísticamente más adecuada para la GV que para el modelo de selección de límites múltiples.* La naturaleza de la relación entre las calificaciones en una prueba válida de aptitud y las clasificaciones del desempeño en el trabajo se ilustra en la figura 2. Dado que esa relación existe, Hunter (1980, 1982) observa que, desde un punto de vista técnico, los datos lineales son más adecuados para el análisis utilizando un modelo de GV que utilizando un modelo con límites múltiples.
3. *Puede reportarse información más precisa a los empleadores acerca de la posición relativa de la persona examinada en la serie continua de las calificaciones de las pruebas de aptitud.* Considere en este contexto la figura 3 y supongamos que la calificación establecida y validada como límite para la selección en una ocupación particular utilizando esta prueba hipotética de aptitud es 155. El examinado X y el examinado Y, ambos reúnen el requerimiento límite, pero es probable que el Examinado Y esté mejor calificado para el empleo; decimos “es probable” porque puede haber excepciones a esta regla general, dependiendo de variables como las demandas reales del puesto específico. En tanto que la calificación para el examinado X cae por debajo de la calificación mediana para todas las personas evaluadas, la calificación del examinado Y se encuentra en el extremo superior de la distribución de calificaciones. Si todos los demás factores permanecen igual, ¿cuál individuo preferiría contratar si usted fuera el dueño de la empresa? Utilizando un simple procedimiento límite, no habría ninguna distinción respecto a la calificación de aptitud entre el examinado X y el examinado Y, siempre y cuando ambas calificaciones reúnan el criterio de la calificación límite.




Figura 2
Relación lineal entre las calificaciones en la prueba de aptitud y las clasificaciones de desempeño en el trabajo

4. La GV ayuda más a los empleadores en sus esfuerzos para contratar empleados calificados. Los estudios, como el realizado por la compañía Philip Morris, sugieren que puede esperarse un aumento significativo en la tasa de éxito de la capacitación en el caso de los empleados contratados utilizando un procedimiento de selección que use la GV, en comparación con los empleados contratados por otros métodos (Warmke, 1984).

¿La GV es la respuesta para todos los problemas de selección de personal? En absoluto. La GV simplemente es una base para evitar de manera justificada el tiempo y el costo de realizar un estudio de validación independiente por cada prueba individual con todos los posibles grupos de personas evaluadas bajo todos los posibles conjuntos de circunstancias, los cuales, con mucha frecuencia, tienen muy pocos sujetos como para lograr resultados significativos. Observe, sin embargo, que junto con la conveniencia de la GV puede haber preocupaciones acerca de la eficacia de los procedimientos empleados. Y aunque hemos dedicado una cantidad considerable de tiempo dándole a conocer este importante concepto de la literatura de selección de personal, es igualmente importante para usted estar consciente que en la actualidad varios problemas técnicos respecto a la GV están siendo considerados en la literatura profesional.

Usted recordará que en el desarrollo de la GV, según es aplicado en la selección de personal, Hunter y sus colaboradores utilizaron




Figura 3
Resultados de una prueba hipotética de aptitud

un procedimiento llamado metaanálisis para reunir los hallazgos entre varios estudios. Un aspecto importante de esta labor implicó la corrección estadística de las pequeñas magnitudes de muestra que se utilizaron en los estudios analizados. Los tipos de procedimientos usados en ese proceso, y los tipos de interpretaciones que se pueden hacer de manera legítima como resultado, han sido tema de varios análisis críticos de la GV. La cantidad de varianza sin explicación que sigue habiendo incluso después de las correcciones estadísticas a las diferencias en el tamaño de la muestra (Cascio, 1987), la influencia desconocida de un posible problema de restricción del rango respecto a la autoselección del sujeto (Cronbach, 1984), las objeciones acerca de utilizar como criterio las calificaciones del empleador (Burke, 1984) y el hecho de que los modelos alternativos pueden explicar la variación en los coeficientes de validez al igual que el modelo de consistencia entre situaciones (James *et al.*, 1986) son algunos de los problemas técnicos que se han hecho notar respecto al uso de la GV (véase también Zedeck y Cascio, 1984). Con referencia específica a la GV como es aplicada al uso con la GATB, se podría adicionalmente cuestionar: ¿qué problemas surgen cuando más de 12 000 ocupaciones están agrupadas en cinco familias laborales? ¿En realidad es significativo colocar a una ocupación como la de conductor de camiones en la misma familia laboral que el trabajo secretarial?

Es evidente que queda mucho por aprender acerca de la manera en que la GV puede ser utilizada de manera más efectiva en los problemas relacionados con la evaluación de personal. Será necesario responder a preguntas difíciles —algunas psicométricas y otras más relacionadas con los valores sociales—. Una detallada crítica a la GV que comienza con su lógica y concluye con su aplicación la puede encontrar en Murphy (2003).

Haciendo más pesada la tarea de evaluar de manera imparcial la GV hay un catálogo de variables que no tienen una naturaleza

(continúa)

Generalización de la validez y la GATB (continuación)

psicométrica ni se relacionan con los valores. Se incluyen aquí variables como la fortaleza de la economía, el tamaño de la reserva disponible de empleos, la experiencia de la reserva disponible de empleo, el deseo general de empleos específicos y los salarios que se ofrecen para diversos tipos de trabajo. Ya sea que se tenga

una actitud favorable o no hacia la experimentación del gobierno estadounidense con la GV en la selección de personal, parece razonable suponer que queda mucho por aprender en el proceso, y el campo de la selección de personal podrá beneficiarse de manera decisiva de la experiencia.

para afroamericanos, hispanos y otros” (Gottfredson, 1994, p. 966). A los empleadores sólo se les reportaban las puntuaciones percentiles y no las crudas.

En un intento por resolver la polémica resultante, el Departamento de Trabajo de Estados Unidos solicitó a la Academia Nacional de Ciencias (National Academy of Sciences, NAS) que rea-

SÓLO PIENSE...

¿Cuáles son las ventajas y desventajas de establecer normas raciales en una prueba de aptitud?

lizara un estudio. La NAS emitió un informe (Hartigan y Wigdor, 1989) que apoyaba en términos generales las normas por raza. La NAS señaló que la GATB parecía sufrir de un marcado sesgo, de modo que la prueba se correlacionaba de manera más elevada con pruebas de criterio en las muestras de personas blancas (.19) que en las muestras de personas afroamericanas (.12). El sesgo de intercepción también estaba presente, con el resultado de que el desempeño de los afroamericanos podía ser pronosticado de manera

más favorable que el de los blancos si se utilizaba la misma línea de regresión con ambos grupos. La NAS encontró que establecer una norma de acuerdo a la raza era un método razonable para corregir la oblicuidad de la prueba.

El reporte de la NAS también atendió a cuestiones más generales respecto a la utilidad de la GATB como medio de predicción del desempeño laboral. Utilizando una base de datos de 755 estudios, la NAS observó que la GATB se correlacionó aproximadamente en .22 con criterios como las clasificaciones de supervisión. Otros han estimado que la validez de la prueba es de .20 (Vevea *et al.*, 1993) y .21 (Waldman y Avolio, 1989). La NAS consideró que estos coeficientes relativamente pequeños eran modestos pero aceptables. Para comprender por qué los consideraron aceptables, recuerde del capítulo 6 que la validez de criterio está limitada por la confiabilidad de las pruebas. En tanto que la GATB tiene una adecuada confiabilidad de prueba y postprueba (cercana a .81), la probable deficiente confiabilidad de las clasificaciones de supervisión puede reducir el coeficiente de validez de la GATB. Se espera que ocurra esa reducción del coeficiente de validez en cualquier prueba diseñada para pronosticar el desempeño en el trabajo cuando ésta se valida contra las clasificaciones de los supervisores (Hartigan y Wigdor, 1989). Por supuesto, incluso los medios de predicción con una modesta validez de criterio pueden mejorar las decisiones en la selección de personal. De esta manera, a pesar de los bajos coeficientes de validez de criterio, la GATB es ampliamente considerada como un medio válido para la selección de empleados.

La recomendación de la NAS de continuar con la práctica para establecer una norma de acuerdo con la raza puede haber hecho más por avivar el fuego de la controversia que por apagarlo. En julio de 1990, el Departamento del Trabajo propuso una suspensión por dos años del uso de la GATB, tiempo durante el cual se investigarían más la eficacia de la prueba y de sus procedimientos de calificación. La legalidad de la práctica de fijar una norma de acuerdo con la raza también se volvió un exaltado tema de debate en esa época (Baydoun y Neuman, 1992; Delahunty, 1988). La cuestión de si deberían continuar implantándose normas relacionadas con la raza por parte de la GATB se volvió discutible después de que el Congreso de Estados Unidos

aprobó la Ley de Derechos Civiles de 1991, una ley que volvió ilegal la práctica de fijar normas en base al grupo racial.

Actualmente, el Sistema de Empleos de Estados Unidos (U.S. Employment Service) sigue utilizando la GATB. Sin embargo, los reportes para los empleadores ya no establecen normas basados en la raza. Ahora las calificaciones en bruto de las personas de todos los grupos raciales se convierten en puntuaciones estándar utilizando las mismas normas. Además de su posible valor aplicado, la GATB continúa siendo un recurso valioso para los investigadores en áreas como la validación de una teoría (véase, por ejemplo, Farrell y McDaniel, 2001).

Una pasión estimulante —confiamos que de la variedad *armoniosa*— ha conducido a aquellos que realizan investigación en áreas relacionadas con el empleo a buscar medios de predicción más allá de los intereses y aptitudes. Quizás las respuestas buscadas durante tanto tiempo puedan encontrarse en constructos como *rasgo de personalidad* o *tipo de personalidad*.

SÓLO PIENSE...

Una persona extrovertida y sumamente creativa, ¿será feliz en una carrera como técnico capturista de datos en un centro de pago de reembolsos? De no ser así, ¿qué tipo de carrera será la más adecuada para este tipo de persona? ¿Qué lo hizo llegar a esa conclusión?

Pruebas de personalidad

El análisis de las preguntas planteadas en nuestro distintivo apartado de *Sólo piense...* nos impulsa a pensar en el papel de la personalidad en la elección vocacional. Cuando los investigadores consideran esas preguntas, es posible que busquen respuestas en un estudio que incluya la aplicación de una prueba de personalidad. Aunque existen muchas pruebas de personalidad, algunas serán más apropiadas que otras para esta tarea. Por ejemplo, el MMPI-2, que es ampliamente utilizado en ámbitos clínicos, puede tener una aplicación limitada en el contexto de la orientación vocacional. Es posible que se prefieran otras pruebas de personalidad, como el Estudio Guilford-Zimmerman de temperamento (*Guilford-Zimmerman Temperament Survey*) y el Inventario Edwards de preferencias personales (*Edwards Personal Preference Schedule*), quizá debido a que las pruebas que producen tienden a relacionarse mejor con las variables específicas bajo estudio. En la actualidad, dos de las pruebas de personalidad más utilizadas en el ambiente laboral son la NEO PI-R (descrita en el capítulo 11) y el Indicador de tipos Myers-Briggs (*Myers-Briggs Type Indicator*, MBTI). Analizamos el MBTI, una herramienta para obtener información sobre tipos psicológicos, después de un breve análisis de los estudios que abordan las cuestiones relacionadas con carrera y ocupación al nivel de rasgo.

Medición de rasgos de personalidad La evaluación de la personalidad en el contexto de la investigación u orientación relacionada con el empleo puede comenzar con la aplicación de una prueba diseñada para medir los cinco grandes de Costa y McCrae (1992c), los **tres grandes** de Tellegen (1985), los *seis grandes* de Holland, o alguna otra cantidad de rasgos o tipos (grandes, pequeños o no tan especiales) de acuerdo con un concepto particular de la personalidad.¹ Los investigadores analizarán luego los datos de la prueba de personalidad según son comparadas con otras variables relacionadas con el empleo o profesión. Una muestra de esas “otras variables relacionadas con el empleo o profesión” provenientes de la literatura de investigación incluirían:

- potencial gerencial (Lillibridge y Williams, 1992) y capacidad de liderazgo (Judge y Bono, 2000)
- motivación para el desempeño en el trabajo (Judge e Ilies, 2002)
- ausentismo, retardos y clasificaciones de supervisión respecto al desempeño (Conte y Jacobs, 2003)

1. Holland (1999) aclaró que para él, los inventarios de intereses *son* inventarios de personalidad. Por esta razón, es apropiado mencionar el trabajo de Holland al analizar la evaluación de intereses o de personalidad como un auxiliar para la orientación vocacional.

- satisfacción en el trabajo (Furnham *et al.*, 2002)
- éxito en la carrera (Seibert y Kraimer, 2001)
- el grado en que una organización es atractiva para los solicitantes (Lievens *et al.*, 2001)
- el grado en que las actividades en los empleos de ventas son atractivas para los solicitantes (Stevens y Macintosh, 2003)

La mayoría de las investigaciones citadas arriba utilizaron el NEO PI-R de Costa y McCrae (1992c). De hecho, es probable que esta prueba sea la que más se utiliza hoy día. No obstante, existen tipos más especializados de instrumentos que también están incluidos dentro de la división general de prueba de personalidad. Por ejemplo, es posible hablar de una **prueba de integridad** diseñada específicamente para pronosticar el robo, la honestidad, el apego a los procedimientos establecidos, y/o el potencial de violencia en los empleados. Esas pruebas de personalidad definidas de manera estrecha utilizadas en el contexto de la investigación y práctica relacionadas con el empleo han sido caracterizadas como *escalas ocupacionales de personalidad enfocadas en el criterio*, o COPS por sus siglas en inglés (Ones y Viswesvaran, 2001).

Las pruebas de integridad pueden utilizarse para seleccionar a nuevos empleados al igual que para conseguir que aquellos que ya han sido contratados sigan siendo honrados. El uso de estas pruebas ha aumentado de manera espectacular con la aprobación de leyes que prohíben el uso de polígrafos (detectores de mentiras) en la mayoría de los ambientes laborales. La tendencia se aleja de los cuestionarios con papel y lápiz y se dirige hacia las pruebas que se pueden aplicar de manera rápida y eficiente por medios electrónicos. Una de esas pruebas es el Inventario de potencial del solicitante (*Applicant Potential Inventory*, API), que se puede aplicar por computadora (en línea o fuera de línea), teléfono y fax. Jones *et al.* (2002) describieron el desarrollo de esta prueba al igual que la investigación diseñada para explorar su solidez psicométrica.

Sackett *et al.* (1989) dividieron las pruebas de integridad en *pruebas de integridad manifiesta* (las cuales pueden hacer preguntas de manera directa a la persona examinada como “¿Usted siempre dice la verdad?”) y *pruebas basadas en la personalidad*, que se asemejan en muchos sentidos a los inventarios objetivos de personalidad como el MMPI. Los reactivos del último tipo de pruebas pueden ser más sutiles que los de las primeras. También, las respuestas a los reactivos en las pruebas basadas en la personalidad tienen menos probabilidad de ser interpretadas con base en la validez evidente del reactivo y con más probabilidad de ser interpretados con referencia a las respuestas de grupos de personas que se sabe tienen o carecen de integridad, de acuerdo a como son definidas por la prueba particular.

Es discutible si las pruebas de integridad miden lo que pretenden medir. Las reseñas sobre la validez de esas pruebas han diferido desde mixtas (APA, 1991; Sackett y Harris, 1984; Sackett *et al.*, 1989) hasta positivas (DePaulo, 1994; Honts, 1994; Sackett, 1994; Saxe, 1994). Quizá la conclusión más imparcial a partir de esta literatura es que, cuando la prueba se ha desarrollado de manera profesional, tiene una excelente oportunidad de satisfacer las normas aceptables de validez. *Las pautas modelo para los programas de pruebas de integridad previas a la contratación* (*Model Guidelines for Preemployment Integrity Testing Programs*), un documento elaborado por la Asociación de Editores de Pruebas de Personal (Association of Personnel Test Publishers, APTP, 1990) atiende muchas de las cuestiones que rodean a las pruebas de integridad, incluyendo temas relacionados con el desarrollo, aplicación, calificación, interpretación y confidencialidad de los resultados, declaraciones públicas acerca de las pruebas y prácticas de comercialización de las mismas. Se proporcionan pautas específicas en estas áreas y se discuten las responsabilidades de los usuarios y de los editores (para una sinopsis véase Jones *et al.*, 1990).

Más allá de los temas relacionados con la validez de las pruebas de integridad se encuentran preguntas más amplias acerca de diversos aspectos de su uso (Camara y Schneider, 1994). Por ejemplo, ¿se invade la vida privada cuando a un posible empleado se le pide que responda una prueba de este tipo? ¿Estas pruebas pueden utilizarse para apoyar prácticas discriminatorias? ¿Las pruebas de este tipo deberían utilizarse solas o en combinación con otros procedimientos de medición como una base para conceder o negar el empleo? De manera interesante White (1984) sugiere que las pruebas de honradez previas a la contratación pueden inducir actitudes negativas relacionadas con el trabajo. El hecho de tener que someterse a una prueba de este tipo puede ser



Figura 16-3
Un equipo formado por madre e hija dedicado al desarrollo de pruebas

Katharine Cook Briggs (izquierda) e Isabel Briggs Myers (derecha), crearon el Indicador de tipos Myers-Briggs (Myers-Briggs Type Indicator). En 1915, Katharine mostró un interés en las diferencias individuales después de que fue presentada a su futuro yerno, Clarence Myers. Para Katharine, Clarence parecía diferente de manera fundamental de los demás miembros de la familia Briggs. Debido en parte a un deseo por comprender mejor estas diferencias, Katharine creó una categoría de tipos psicológicos. Años después, Isabel pondría a prueba, literalmente, las ideas de su madre.

interpretado por los posibles empleados como evidencia de los elevados niveles de robo entre los empleados, lo cual, paradójicamente, resulta en una nueva y más elevada norma de robo por parte de los empleados.

Medición de los tipos de personalidad ¿Cómo podría alguien haber previsto en 1915 que la posibilidad de tener por yerno a Clarence Myers finalmente conduciría a Katharine Cook Briggs (figura 16-3) por un camino que culminaría en la creación de una medida perdurable de los tipos de personalidad?

Isabel Briggs Myers y su madre, Katharine Cook Briggs, dos mujeres sin un entrenamiento formal en psicología o evaluación, fueron inspiradas por los escritos de Carl Jung (1923) y sus ideas acerca de los diferentes tipos psicológicos. En parte, esa inspiración fue útil en la creación del MBTI (Myers y Briggs, 1943-1962), una prueba utilizada para clasificar a las personas evaluadas según el tipo psicológico y para aclarar “las diferencias básicas en las maneras en que los seres humanos reciben información y toman decisiones” (McCaulley, 2000, p. 117).

Desde una perspectiva psicométrica, la prueba ha recibido comentarios mixtos. Un meta-análisis de los estudios publicados indicó que la prueba y sus escalas tendían a ser internamente consistentes y estables a través del tiempo, aunque se observaron algunas variaciones (Capraro y Capraro, 2002). Aún así, muchos profesionales de la evaluación han expresado serias preocupaciones acerca del MBTI por razones psicométricas y de otro tipo (Arnau *et al.*, 2003; Girelli y Stake, 1993; Harvey y Murry, 1994; Lorr, 1991; Martin y Bartol, 1986; Pittenger, 1993; Vacha-Haase y Thompson, 2002; Zumbo y Taylor, 1993). Sin importar tales críticas, la prueba sigue siendo muy popular, en especial entre orientadores y consultores organizacionales. Por ejemplo, las referencias a ella en la literatura reciente muestran que es utilizada para derivar los perfiles de los trabajadores característicos en diversas ocupaciones, como ingenieros de programas de cómputo (Capretz, 2003) y para validar una nueva medida de “adecuación al trabajo” previa a la contratación (Piotrowski y Armstrong, 2002). En otros tipos de aplicaciones, ha sido utilizado para explorar fenómenos tan diversos como la posibilidad de suicidio (Janowsky *et al.*, 2002), veneración de las celebridades (McCarley y Escoto, 2003) y enseñanza efectiva de estudiantes con capacidades sobresalientes (Mills, 2003). Una descripción más detallada del

MBTI puede encontrarla en algunos artículos publicados (véase, por ejemplo, Furnham *et al.*, 2003; McCaulley, 2000, 2002; Myers y Carskadon, 2002).

Antes de dejar el tema de la evaluación de la personalidad en el mundo del trabajo, mencionemos una interesante línea de investigación que hizo surgir la pregunta: “¿La disposición emocional de los niños tiene algo que ver con la satisfacción que obtengan en sus empleos cuando sean adultos?” Si usted piensa que la

SÓLO PIENSE...

Desde la perspectiva de un empleador, ¿buscar un *tipo* específico de empleado para un puesto particular podría tener un “lado negativo”?

pregunta en sí es un tanto sorprendente, sostengase en su asiento cuando le digamos que la respuesta a la pregunta (un sonoro sí) es incluso más sorprendente. Al utilizar los datos de tres estudios longitudinales independientes, Staw *et al.* (1986) descubrieron que los datos sobre la disposición obtenidos en la niñez pronosticaban las actitudes relacionadas con el trabajo a lo largo de un periodo de unos 50 años. Aunque la interpretación de los datos en este estudio ha sido cuestionada, en general ha recibido apoyo de otros investi-

gadores (Arvey *et al.*, 1989; House *et al.*, 1996; Judge *et al.*, 2000; Motowidlo, 1996). Es posible que el propio temperamento intervenga en los sucesos emocionalmente significativos, incluyendo aquellos relacionados con el trabajo, que a su vez influyen en el propio nivel de satisfacción con el mismo (Weiss y Cropanzano, 1996).

Los hallazgos de este tipo son criticados. De manera más general, el uso de las pruebas de personalidad en cualquier contexto relativo al empleo recibe críticas (véanse, por ejemplo, Ghiselli, 1973; Hollenbeck y Whitener, 1988; Kinslinger, 1966; Schmitt *et al.*, 1984). No obstante, la mayoría de los investigadores en esta área piensa que puede obtenerse información valiosa relacionada con el trabajo y la vocación a través del estudio de la evaluación de la personalidad (Fontanna, 2000).

Otras pruebas

Pueden utilizarse variadas herramientas de evaluación para la planificación vocacional y los contextos previos a la contratación, aunque no hayan sido diseñadas de manera específica para ese propósito. Por ejemplo, la Lista de verificación de habilidades de adaptación para la subsistencia (*Checklist of Adaptive Living Skills*, CALS; Morreau y Bruininks, 1991) estudia las habilidades vitales necesarias para hacer una transición exitosa de la escuela al trabajo. Organizada en cuatro campos de acción amplios (Habilidades personales de subsistencia; Habilidades de subsistencia en el hogar, Habilidades comunitarias de subsistencia y Habilidades en el trabajo), esta prueba evalúa 794 habilidades de vida. La lista de verificación está diseñada para ser utilizada con personas de cualquier edad. Según el manual, el individuo que completa la lista de verificación debe haber tenido oportunidad de observar a la persona al menos durante tres meses en ambientes naturales. A las personas examinadas se les juzga como *independientes* respecto a una habilidad específica si llevan a cabo la tarea con buena calidad en, cuando menos, 75% de las ocasiones cuando es necesario y sin que se les recuerde. Este instrumento basado en el criterio puede ser particularmente útil en la orientación vocacional y previo a la contratación con miembros de poblaciones especiales.

Los investigadores están interesados en el papel de la cultura en diversos aspectos de la evaluación para el empleo (Blustein y Ellis, 2000; Hofstede, 1998; Leong y Hartung, 2000; Ponterotto *et al.*, 2000; Rotundo y Sackett, 1999; Ryan *et al.*, 2000; Sandoval *et al.*, 1998; Subich, 1996). De acuerdo con Meyers (1994), el hecho de que ocasionalmente un nuevo empleo pueda resultar algunas veces una especie de “choque cultural”, impulsó la creación de un instrumento llamado Inventario de adaptabilidad entre culturas (*Cross-Cultural Adaptability Inventory*, CCAI; Kelley y Meyers, 1992). El CCAI es un instrumento autoaplicable y autocalificable, diseñado para proporcionar información sobre la capacidad de la persona examinada para adaptarse a otras culturas. Las personas evaluadas responden a 50 reactivos escritos en un formato Likert de 6 puntos. La prueba proporciona información sobre la disposición de una persona para adaptarse a nuevas situaciones, a tolerar la ambigüedad, a conservar la propia identidad personal en nuevos ambientes y a interactuar con personas de otras culturas. El reporte se organiza en información referente a cuatro factores que se consideran pertinentes para la adaptabilidad entre culturas: Recuperación emocional, Flexibilidad/

Tabla 16-2

Muestra de preguntas derivadas de las creencias y suposiciones de los estudiantes

-
- ¿Qué antecedentes, tanto educativos como profesionales, se necesitan para entrar en este campo?
 - Describa brevemente el curso de su carrera y los pasos que tomará para llegar allí.
 - ¿Qué hace usted en un día común?
 - ¿En cuáles industrias y empresas existirán esas carreras y empleos, o qué industrias y compañías serían mejores para esta carrera?
 - ¿Cuáles son las fuentes de tensión en su empleo?
 - Si usted pudiera, ¿qué cambiaría acerca de su trabajo?
 - ¿Cómo se inicia o entra en esta carrera / empleo una persona?
 - ¿Qué tipo de estilo de vida proporciona o permite una carrera o empleo de este tipo?
 - ¿Cuál es el rango de compensación y beneficios para esta carrera o empleo?
 - ¿Con cuánta frecuencia tiene que viajar y por qué razones viaja?
 - ¿Este tipo de carrera o empleo requiere de manera característica cambiar de residencia?
 - ¿Disfruta usted su trabajo?
 - ¿Qué oportunidades de desarrollo existen para las personas en ese campo?
 - ¿Encuentra satisfactorio y desafiante su trabajo o carrera?
 - ¿Qué habilidades especiales se requieren para un puesto como el suyo?
 - ¿Cuál es el número promedio de horas de trabajo en una semana laboral típica?
 - ¿Qué tipo de habilidades son necesarias para lograr el éxito en _____?
 - ¿Qué debo hacer o adónde debo acudir para adquirir estas habilidades necesarias?
 - ¿Cuál es el aspecto más desafiante de su empleo?
 - ¿Cuál es el aspecto más satisfactorio de su empleo? ¿Cuál es el aspecto menos satisfactorio de su empleo?
 - ¿Cuáles son las repercusiones de esta carrera sobre la propia familia?
 - ¿Qué tan importantes son los grados?
 - ¿Cómo es evaluado su desempeño?
 - ¿Cómo afecta su carrera en su vida fuera del trabajo? ¿Con su cónyuge? ¿Su vida social? ¿Espiritual?
 - ¿Cómo es el mercado de trabajo en esta área profesional particular? ¿Cómo cree que será dentro de 5 o 10 años?
 - ¿Qué recomendaciones me haría? ¿Qué haría usted si fuera yo?
 - Si usted fuera yo, ¿con quién sugeriría que hablase? ¿Por qué sugiere a esa persona? ¿Puedo usar su nombre para comunicarme con esa persona?
 - Describa una semana laboral común.
-

Fuente: Laker (2002). Reproducido con autorización.

Apertura, Agudeza perceptiva y Autonomía personal. La prueba puede ser valiosa para evaluar la disposición para aceptar un trabajo o ser trasladado al exterior.

Quizá uno de los instrumentos más importantes de evaluación pertinentes para una decisión vocacional puede ser un cuestionario diseñado por los mismos evaluados, uno que no esté diseñado para ser aplicado a un posible empleado. Más bien, que haya sido escrito por la misma persona evaluada y diseñado para aplicarlo a un individuo con un trabajo establecido en la carrera que el evaluado está contemplando. Laker (2002) propuso que los estudiantes que estén pensando en elegir una carrera consideren una profesión en la que les gustaría ingresar. A continuación, los estudiantes deben identificar a personas soporte que ya estén en esas carreras y que puedan orientarlos en las creencias y suposiciones de los estudiantes acerca de la naturaleza de la vida laboral en esa área. Estas personas soporte pueden ser identificadas por medios informales como “preguntando por allí”, al igual que de manera más formal utilizando una obra de referencia como la *Enciclopedia de Asociaciones* (*Encyclopedia of Associations*, Hunt, 2002). Encontrar la asociación a la que pertenece la persona soporte elegida y entrar en contacto con dicha asociación en busca de asistencia para identificar a alguien de la localidad que esté dispuesto a ayudar. Como preparación para la reunión, los estudiantes pueden hacer una lista de sus creencias y suposiciones acerca de la carrera y luego traducirlas en forma de preguntas, como las que se presentan en la tabla 16-2.

Todas las herramientas de evaluación que hemos analizado hasta aquí tienen aplicación no sólo para ingresar en una carrera, sino también para un cambio de profesión. Una prueba diseñada de manera específica para personas que están pensando en cambiar de profesión es el Inventario de transición de carrera (*Career Transitions Inventory*, CTI; Heppner *et al.*, 1994). El propósito de esta prueba es evaluar los recursos psicológicos durante el proceso de transición de carrera. Para

los propósitos de la prueba, *transición de carrera* fue definido de manera operacional como *cambio de tarea* (un traslado a otros tipos de tareas, pero esencialmente el mismo trabajo), *cambio de puesto* (una modificación en los trabajos con el mismo empleador) o *cambio de ocupación* (una modificación en las obligaciones y ambientes de trabajo). Los autores de la prueba presentaron evidencia de la confiabilidad de la misma, así como evidencia que describieron como “prometedora” para la validez de constructo de este instrumento.

La transición de carrera es una variedad de lo que podríamos llamar *estrategia de salida* para una persona de una profesión o negocio particular. Otro tipo de estrategia de salida es el retiro. La decisión de retirarse es de gran importancia y multifacética y que también ha sido explorada por medio de instrumentos de evaluación. La decisión de retirarse no debe tomarse con base en un solo criterio como la satisfacción global o la seguridad económica (Parnes y Less, 1985). Para las personas que están considerando el retiro, los orientadores pueden ofrecerles ayuda en forma de entrevistas de sondeo, al igual que con la aplicación de diversas pruebas que evalúan la satisfacción en la vida, dirección de metas, satisfacción con el tiempo libre y apoyo interpersonal.

SÓLO PIENSE...

¿Cómo podrían ser útiles los datos de las pruebas de personalidad para orientar a una persona que está considerando jubilarse?

De manera más específica, la Escala de inestabilidad de las metas (*Goal Instability Scale*; Robbins y Patton, 1985), el Índice A de satisfacción con la vida (*Life Satisfaction Index A*; Neugarten et al., 1961), la Escala de satisfacción con el tiempo libre (*Leisure Satisfaction Scale*; Beard y Ragheb, 1980) y la Lista de evaluaciones de apoyo interpersonal (*Interpersonal Support Evaluations List*; Cohen et al., 1985) son algunos de los instrumentos que pueden proporcionar datos valiosos. Floyd et al. (1992) desarrollaron el Inventario de

satisfacción con el retiro (*Retirement Satisfaction Inventory*) para ayudar a evaluar la adaptación a la jubilación.

Las pruebas y otras herramientas de evaluación pueden ser usadas por las empresas u otras organizaciones para ayudar en la toma de decisiones relacionadas con los empleados y otras decisiones acerca del personal. Algunos de los asuntos para tomar esas decisiones se analizan a continuación.

Detección, selección, clasificación y colocación

En el contexto del empleo, la **detección** se refiere al proceso relativamente superficial de evaluación en base a ciertos estándares, criterios o requisitos mínimos. Por ejemplo, el departamento de bomberos de un municipio puede hacer una detección de ciertos requisitos mínimos como estatura, peso, salud física, fortaleza física y capacidad cognoscitiva para la admisión de bomberos a un programa de capacitación. El gobierno puede utilizar una prueba de inteligencia de aplicación grupal para detectar a las personas inadecuadas para el servicio militar o para identificar a los reclutas con capacidades intelectuales superiores para asignarlos a tareas especiales.

La **selección** se refiere al proceso en el que una persona evaluada para un puesto será aceptada o rechazada para ocuparlo. Por contraste, **clasificación** no implica la aceptación o rechazo sino más bien una jerarquización, categorización o asignación respecto a dos o más criterios. Por ejemplo, el ejército clasifica al personal de acuerdo con la acreditación de seguridad en base a variables como rango, antecedentes personales de actividad política y asociaciones conocidas. Como resultado de tales evaluaciones, un individuo se le podría conceder acceso a documentos clasificados como *Confidencial*, mientras que a otro se le podría otorgar acceso a documentos etiquetados *Estrictamente confidencial*.

Al igual que la clasificación, la **colocación** no implica ninguna aceptación o rechazo. La **colocación** es una disposición, transferencia o asignación a un grupo o categoría que puede hacerse en base a un criterio. Si, por ejemplo, usted tomó un curso a nivel universitario cuando aún estaba estudiando preparatoria, la calificación obtenida en la prueba de colocación avanzada en esa área temática puede haber sido el único criterio utilizado para asignarlo a una sección apropiada de ese curso universitario hasta que sea aceptado en la universidad.

De manera regular, las empresas, las instituciones académicas y militares, y otras organizaciones detectan, seleccionan, clasifican o colocan a los individuos. Una amplia variedad de pruebas

Tabla 16-3
Lista de verificación para un reactivo de un formato de solicitud

1. ¿El reactivo es necesario para identificar al solicitante?
2. ¿Es necesario para descartar a aquellas personas no elegibles según las políticas básicas de contratación de la empresa?
3. ¿Ayuda a decidir si el candidato está calificado?
4. ¿Está basado en el análisis de trabajo o trabajos para los que los solicitantes serán seleccionados?
5. ¿Ha sido probado previamente con los empleados de la empresa y ha resultado estar correlacionado con el éxito?
6. ¿La información será utilizada? ¿Cómo?
7. ¿El formato de solicitud es el medio apropiado para pedir esta información?
8. ¿En qué grado las respuestas duplicarán información obtenida en otra etapa del proceso de selección, por ejemplo, a través de entrevistas, pruebas o exámenes médicos?
9. ¿La información es necesaria del todo para la selección o debería obtenerse cuando sea instalado o incluso después?
10. ¿Es probable que las respuestas de los solicitantes serán confiables?
11. ¿La pregunta viola cualquier legislación federal o estatal pertinentes?

Fuente: Ahern (1949).

pueden ser utilizadas como auxiliares para la toma de decisiones. Las pruebas de capacidad, aptitud, intereses y personalidad pueden ser valiosas, dependiendo de las demandas de una decisión en particular. En el mundo de la elite de los deportes profesionales, donde los errores de selección pueden ser sumamente costosos, las pruebas psicológicas pueden ayudar a evaluar si un nuevo jugador elegido a través de un reclutamiento llegará a su máximo potencial (Gardner, 2001). Por supuesto, para los tipos de decisiones de contratación más cotidianas, y especialmente en la etapa previa a ello, algunas de las herramientas más comunes de evaluación incluyen la carta de solicitud y el currículum, el formato de solicitud de empleo, la carta de recomendación y la entrevista.

El currículum y la carta de solicitud

No existe un currículum único, estándar; el currículum puede ser “tan único como el individuo al que representan” (Cohen, 1994, p. 394). De manera característica, la información relacionada con los propios objetivos laborales, capacidades, escolaridad o experiencia se incluye en un currículum. Una carta que acompaña el currículum, llamada carta de solicitud, permite que el solicitante de empleo demuestre la motivación, sus habilidades de redacción de tipo administrativo y su personalidad única. Ni un currículum ni una carta de solicitud podrían ser los únicos medios que garanticen la obtención de un empleo. En el mejor de los casos, ambos documentos son peldaños para llegar a las entrevistas personales u otras situaciones de evaluación. Por otro lado, el empleador, el psicólogo del trabajo u otros individuos que lean el currículum del solicitante y la carta de solicitud pueden utilizar estos documentos como una base para rechazar una petición. La carta de solicitud y el currículum pueden ser analizados para encontrar detalles como la calidad de la comunicación escrita, sinceridad percibida e idoneidad de los objetivos, escolaridad, motivación y experiencia previa del solicitante respecto al puesto disponible. Desde la perspectiva del evaluador, tiene mucha semejanza con otra herramienta común de evaluación en el ámbito laboral, el formato de solicitud.

El formato de solicitud

Los formatos de solicitud pueden considerarse como bocetos biográficos que proporcionan a los empleadores información relacionada con la aceptabilidad de los candidatos para un empleo. Además de la información demográfica (como el nombre, dirección y número telefónico), pueden requerirse detalles referentes a otras áreas, como antecedentes escolares, servicio militar y experiencia laboral previa. Algunas preguntas clásicas relacionadas con un formato tradicional de solicitud se presentan en la tabla 16-3. La filosofía conducente es que cada reactivo del formato sea adecuado para la consideración relativa al empleo. El formato de solicitud es una herramienta sumamente útil para la detección rápida en numerosos escenarios.

Cartas de recomendación

Otra herramienta útil para la detección preliminar de los solicitantes es la carta de recomendación (Arvey, 1979; Glueck, 1978). Estas cartas pueden ser una singular fuente de información detallada sobre el desempeño anterior del solicitante, la calidad de sus relaciones con sus compañeros y así sucesivamente. Por supuesto, estas cartas no carecen de inconvenientes. No es ningún secreto que los solicitantes piden cartas de recomendación a aquellas personas que consideran sólo dirán

cosas positivas sobre ellos. Otro posible inconveniente de las cartas de recomendación es la variación en las habilidades de observación y redacción de quienes las escriben.

SÓLO PIENSE...

Póngase en la posición de un empleador. Ahora analice cuánto “peso” le asignaría a las cartas de recomendación relacionadas con los datos de pruebas y otra información sobre el solicitante. Explique la base para sus “ponderaciones”.

En una investigación que utilizó los archivos de solicitudes para la admisión al postgrado en psicología, se encontró que al solicitante se le podría describir de manera variada como “analíticamente orientado, reservado y muy motivado” o “poco convencional, imaginativo y extrovertido” dependiendo de la perspectiva de quien escribiera la carta. Como señalaron los autores del estudio, “Aunque en ambos casos se pretende dar una recomendación favorable, los detalles y las bases para esas recomendaciones son

diversas” (Baxter *et al.*, 1981, p. 300). Los esfuerzos para reducir los inconvenientes inherentes a las cartas de recomendación sin restricciones han tomado algunas veces la forma de “cuestionarios de recomendación”, donde los antiguos empleadores, profesores y otras personas que escriben este tipo de cartas responden a preguntas estructuradas relacionadas con el desempeño previo del solicitante. Algunos cuestionarios utilizan un formato de opción forzada diseñado para obligar a los respondientes a hacer afirmaciones negativas así como positivas sobre el solicitante.

Aunque originalmente eran escritas para proporcionar al posible empleador una opinión sobre el solicitante, algunas cartas de referencia ahora cumplen la función de un registro de archivo que permite un vistazo sobre un desafortunado capítulo en la historia estadounidense y los prejuicios prevalecientes de una época. Winston (1996, 1998) documentó la manera en que las cartas de recomendación escritas por prominentes psicólogos de Estados Unidos para los estudiantes de psicología y psicólogos judíos desde el decenio de 1920 hasta el de 1950 continuaron una práctica común de identificar a los candidatos a un trabajo como judíos. Las cartas servían para revelar si, en opinión de quienes las escribían, el candidato evidenciaba “rasgos objetables” que fueran considerados característicos de los judíos. Estas cartas apoyan un argumento convincente de que, aunque la historia estadounidense tiende a tratar al antisemitismo como un problema del que huyeron los inmigrantes europeos, los estereotipos negativos asociados con el hecho de ser judío fueron una gran parte del panorama cultural de Estados Unidos.

Entrevistas

Las entrevistas, sean individuales o grupales, proporcionan una ocasión para un intercambio personal de información. Al igual que otras, las entrevistas laborales pueden ocurrir donde quiera en una proporción continua desde sumamente estructuradas, con preguntas uniformes que se hacen a todos, hasta sumamente desestructuradas, con preguntas que quedan en gran medida a discreción del entrevistador. También, como ocurre con otras entrevistas, las predisposiciones y prejuicios del entrevistador pueden deslizarse de manera inadvertida dentro de la evaluación e influir en el resultado. Otros factores, como el orden de la entrevista, también podrían afectar los resultados en función de los efectos de contraste. Por ejemplo, es posible que el solicitante promedio parezca más o menos calificado dependiendo de si el candidato anterior fue particularmente deficiente o sobresaliente. Según Schmitt (1976), los factores que pueden afectar el resultado de una entrevista laboral incluyen antecedentes, actitudes, motivaciones, percepciones, expectativas, conocimiento sobre el empleo y comportamiento durante la entrevista tanto del entrevistador como del entrevistado. Los factores situacionales, como la naturaleza del mercado de trabajo, también pueden afectar el resultado de la entrevista.

La investigación acerca de la solidez psicométrica de la entrevista como herramienta de evaluación en escenarios laborales ha producido una imagen de muchos contrastes. Varios estudios parecen indicar que la estructura en una entrevista puede contribuir al valor de pronóstico de la misma, pero sólo hasta cierto grado. Hay un momento en que añadir estructura adicional a una entrevista ya no aumenta la validez de esta herramienta de evaluación (Huffcutt y Arthur, 1994).

Evaluación de portafolios

En el contexto de la evaluación industrial-organizacional, la evaluación de portafolios implica la valoración de una muestra de trabajo del individuo con el propósito de tomar alguna decisión de detección, selección, clasificación o colocación. Un reportero gráfico que solicita un puesto en una nueva estación televisiva puede presentar un portafolios de videoclips, incluyendo metraje de prueba y segmentos editados. Un director de arte de una revista puede presentar un portafolios de trabajo a un posible empleador, incluyendo bocetos y notas sobre la manera de resolver un problema particular de diseño. En la evaluación de portafolios, es posible que el evaluador tenga posibilidad de 1) evaluar muchas muestras de trabajo creadas por la persona evaluada, 2) obtener cierta comprensión de los procesos de pensamiento y hábitos de trabajo de la persona evaluada mediante un análisis del material, desde los bocetos hasta la forma terminada y 3) interrogar adicionalmente a la persona acerca de diversos aspectos de su pensamiento y hábitos relacionados con el trabajo. Los resultados pueden proporcionar una imagen más completa del posible empleado en el trabajo dentro del nuevo escenario que de otra manera no sería posible.

SÓLO PIENSE...

¿Cuáles son algunas cosas que un portafolios no puede informarle a un empleador acerca de un posible empleado?

Pruebas de desempeño

Como su nombre lo dice, una prueba de desempeño requiere que las personas evaluadas demuestren ciertas habilidades o capacidades bajo un conjunto especificado de circunstancias. El objetivo característico de tales ejercicios es obtener una *muestra del desempeño relacionado con el trabajo*. Por ejemplo, una prueba de procesamiento de texto como un requisito previo para el empleo como capturista proporciona al posible empleador una muestra del desempeño relacionado con el trabajo.

Con frecuencia, los límites entre las pruebas de desempeño, aprovechamiento y aptitud son imprecisos, en especial cuando la muestra de trabajo implica responder a una prueba estandarizada de habilidad o capacidad. Por ejemplo, la Prueba Seashore Bennett de experiencia estenográfica (*Seashore Bennett Stenographic Proficiency Test*) es una medida estandarizada de la capacidad estenográfica. Los materiales de prueba incluyen una grabación en la que una voz dicta una serie de letras y manuscritos que la persona evaluada debe transcribir en taquigrafía y después mecanografiar. Las instrucciones grabadas proporcionan una claridad uniforme de la voz y ritmo del dictado. El protocolo de prueba bien puede ser considerado como una prueba de aprovechamiento, una prueba de aptitud o una muestra de desempeño, dependiendo del contexto en el que se use.

Un instrumento ampliamente utilizado diseñado para medir la aptitud y habilidades en tareas administrativas es la Prueba Minnesota de tareas administrativas (*Minnesota Clerical Test*, MCT). La MCT incluye dos subpruebas, comparación de números y comparación de nombres. Cada subprueba contiene 200 reactivos y cada reactivo incluye ya sea un par de nombres o un par de números (dependiendo de la subprueba) que deben compararse. En cada reactivo, la tarea de la persona evaluada es verificar si los dos nombres (o números) en cada par son iguales o diferentes. La puntuación se obtiene de manera simple restando el número de respuestas incorrectas del número de respuestas correctas. Debido a que la velocidad y precisión en las tareas administrativas son importantes para tantos empleadores, esta prueba engañosamente sencilla ha sido utilizada durante décadas como herramienta efectiva de detección en el lugar de trabajo. No sólo puede aplicarse y calificarse con rapidez y facilidad, sino que también el patrón de errores u omisiones de los examinados en esta prueba cronometrada puede sugerir si la persona valora la velocidad más que la precisión o viceversa.



Figura 16-4
Los juegos que los psicólogos juegan

Desde hace mucho tiempo los psicólogos han reconocido el valor de las situaciones de tipo juego en el proceso de evaluar al posible personal. Una tarea conocida como el Problema de ensamblar fue utilizada como parte del estudio de progreso gerencial de AT&T (AT&T Management Progress Study) realizado en 1957. En este caso, la tarea de la persona evaluada es colaborar con los demás para comprar las partes y ensamblar un “producto”.

Las variedades más sofisticadas de evaluaciones del desempeño se utilizan de manera regular en el campo de la aviación, en la capacitación de pilotos (Retzlaff y Gibertini, 1988) y controladores de tráfico aéreo (Ackerman y Kanfer, 1993). En este contexto, las simulaciones por computadora y los videojuegos disponibles a nivel comercial tienen una larga historia de uso (Kennedy *et al.*, 1982). Las simulaciones por computadora permiten a los evaluadores valorar la respuesta de las personas examinadas a un conjunto estandarizado de tareas y monitorear de manera precisa el tiempo de respuesta. A medida que la tecnología se vuelve más sofisticada, la realidad virtual de las simulaciones continúa mejorando.

El tipo de equipo especial necesario para las pruebas de desempeño varía ampliamente. Por ejemplo, para una simulación que implique un problema de fabricación, todo lo que puede ne-

SÓLO PIENSE...

En general, ¿qué tipos de evaluaciones de desempeño se adaptan más a un contexto de realidad virtual que a una realidad “existente”?

cesitarse serán las piezas de un juego para armar (figura 16-4). Durante la segunda guerra mundial, el personal de evaluación de la Oficina de Servicio Estratégico (Office of Strategic Service, OSS) de Estados Unidos estuvo encargado de seleccionar al personal que se desempeñaría como agentes del servicio secreto, saboteadores, expertos propagandísticos y otros cargos para las labores en el servicio exterior. Además de las entrevistas, pruebas de personalidad y otras pruebas con papel y lápiz, la OSS aplicó pruebas de desempe-

ño situacionales. En la actualidad, los israelíes, entre otras potencias militares, utilizan métodos similares. Por ejemplo, la composición óptima de una tripulación de tres personas para desempeñar tareas en el escenario de un campo militar podría ser determinada en base a las pruebas de campo al igual que por pruebas de capacidad y motivación (Tziner y Eden, 1985).

Una prueba de desempeño que se utiliza comúnmente para evaluar la capacidad de liderazgo en los negocios es la **técnica del grupo sin líder**. Las habilidades de comunicación, la capacidad

para solucionar problemas, la capacidad para resistir la tensión y otras habilidades también pueden ser evaluadas de manera económica mediante un ejercicio grupal en el que la tarea de los participantes es trabajar en conjunto para encontrar la solución a algún problema o lograr alguna meta. A medida que interactúan los miembros del grupo, los evaluadores hacen inferencias respecto a preguntas tales como “¿Quién es el líder?” y “¿Cuál es la responsabilidad de los otros miembros en este grupo?”. Sin duda, las respuestas a esas preguntas serán importantes en las decisiones acerca del futuro puesto que tendrá la persona evaluada dentro de la organización.

Otra prueba del desempeño utilizada con frecuencia para evaluar la capacidad gerencial, las habilidades de organización y el potencial de liderazgo es la **técnica de la bandeja de entrada**. Esta técnica simula la manera en que un gerente o un ejecutivo trata con su propia bandeja de entrada llena de correos, memoranda, anuncios y otros avisos diversos. A las personas evaluadas se les informa que sólo cuentan con una cantidad limitada de tiempo, en general dos o tres horas, para manejar de manera competente todos los elementos de la bandeja (de manera más común un sobre de papel Manila). Mediante entrevistas posteriores a la prueba y de un análisis de la manera en que la persona examinada manejó los materiales, los evaluadores pueden hacer inferencias relacionadas con variables como organización y planeación, solución de problemas, toma de decisiones, creatividad, liderazgo y habilidades de comunicación escrita.

El centro de evaluación (assessment center) Una herramienta de amplio uso para la selección, clasificación y colocación es el **centro de evaluación**. Aunque suena como si fuese un lugar, en realidad el término describe un procedimiento de valoración estandarizado de manera organizacional que implica múltiples técnicas de evaluación como pruebas con papel y lápiz y pruebas de desempeño situacionales. El concepto de centro de evaluación tiene sus orígenes en los trabajos de Henry Murray y sus asociados (1938). Las organizaciones militares tanto de Estados Unidos como de otros países fueron las precursoras de las actividades del centro de evaluación (Thornton y Byham, 1982).

En 1956, la primera aplicación de la idea en un escenario industrial ocurrió con el inicio del Estudio de progreso gerencial (*Management Progress Study*, MPS) en la compañía de Teléfonos y Telégrafos de Estados Unidos (American Telephone and Telegraph, ATT; Bray, 1964). El MPS fue un estudio longitudinal que dio seguimiento a las vidas de más de cuatrocientos miembros ejecutivos y no ejecutivos del personal de la compañía telefónica. Los participantes asistieron a un centro de evaluación con duración de tres días y medio en el que fueron entrevistados durante dos horas. Después respondieron varias pruebas con papel y lápiz diseñadas para esclarecer sus capacidades cognoscitivas y su personalidad (por ejemplo, la Prueba de capacidad escolar y universitaria (*School and College Ability Test*) y el Programa Edwards de preferencias personales (*Edwards Personal Preference Schedule*) y participaron en ejercicios situacionales individuales y de grupo (como la prueba de bandeja de entrada y el grupo sin líder). Además, se aplicaron pruebas como la Prueba de apercepción temática y la Prueba de frases incompletas. Todos los datos de cada persona examinada fueron integrados en una junta de evaluadores en la que se hicieron evaluaciones sobre varias dimensiones. Las dimensiones, agrupadas por área, se incluyen en la tabla 16-4.

El uso del método del centro de evaluación se ha multiplicado, con cerca de dos mil organizaciones empresariales o más que de alguna forma dependen de éste para la selección, clasificación, colocación, promoción, capacitación vocacional e identificación temprana del potencial de liderazgo (Gaugler *et al.*, 1987). El método ha sido sometido a numerosos estudios respecto a su validez y el consenso es que hay muchas razones para recomendarlo (B. Cohen *et al.*, 1977; Gaugler *et al.*, 1987; Hunter y Hunter, 1984; McEvoy y Beatty, 1989; Schmitt *et al.*, 1984).

Pruebas físicas

Un salvavidas con una deficiencia visual tendría una seria incapacidad para desempeñar su trabajo. Un catador de vinos que tuviera dañadas sus papilas gustativas sería de poco valor para un vinatero. Un piloto de aeronave que haya perdido el uso de sus brazos... la cuestión esencial es evidente: los requisitos físicos de un trabajo deben tomarse en cuenta al examinar, seleccionar, clasificar y colocar a los solicitantes. Dependiendo de los requisitos físicos específicos del empleo, pueden utilizarse varias subpruebas físicas. Así, por ejemplo, para un trabajo en el que son

Tabla 16-4
Dimensiones del estudio original de progreso gerencial

Área	Dimensiones
Habilidades administrativas	Organización y planeación: ¿Qué tan efectiva puede ser esta persona para organizar el trabajo y qué tan bien planifica con anticipación? Toma de decisiones: ¿Qué tan preparada está para tomar decisiones y qué tan acertada es para tomarlas? Creatividad: ¿Qué probabilidad hay de que resuelva un problema gerencial de manera novedosa?
Habilidades interpersonales	Capacidad de liderazgo: ¿Con cuánta efectividad puede conducir esta persona a un grupo para lograr una tarea sin que surja hostilidad? Habilidades de comunicación oral: ¿Cuánto éxito tendría al presentar un informe oral ante una pequeña junta sobre un tema que conoce bien? Flexibilidad de comportamiento: Cuando está motivada, ¿cuánta facilidad tiene para modificar su conducta y alcanzar una meta? ¿Cuánta capacidad tiene para cambiar los papeles o estilo de comportamiento para lograr los objetivos? Impacto personal: ¿Qué tan vigorosa y agradable es la impresión inicial que produce esta persona? Objetividad social: ¿Qué tan libre está de prejuicios contra grupos raciales, étnicos, socioeconómicos, educativos y otros grupos sociales?
Habilidades cognoscitivas	Capacidad mental general: ¿Cuánta capacidad tiene esta persona en las funciones evaluadas con pruebas de inteligencia, capacidad académica y de aprendizaje? Esfera de intereses: ¿En qué grado le interesan varios campos de actividad como ciencia, política, deportes, música, arte? Habilidades de comunicación escrita: ¿Qué tan bien redacta un memorando comunicativo y formalmente correcto sobre un tema que conoce bien? ¿Qué tan bien redactados podrían estar el memorando e informes?
Estabilidad en el desempeño	Tolerancia a la incertidumbre: ¿En qué grado mantendrá esta persona su desempeño laboral en condiciones inciertas y carentes de estructura? Resistencia a la tensión: ¿En qué grado mantendrá su desempeño laboral ante su propia presión?
Motivación para el trabajo	Preponderancia del trabajo: ¿En qué grado las satisfacciones del trabajo son más importantes para esta persona que las satisfacciones en otras áreas de su vida? Estándares laborales internos: ¿En qué grado querrá hacer un buen trabajo, incluso si un trabajo de menor calidad es aceptable para su jefe y otras personas? Energía: ¿Con qué constancia puede mantener un alto nivel de actividad laboral? Objetividad acerca de sí mismo: ¿Qué tan realista son sus perspectivas acerca de sus propias ventajas e impedimentos, y cuánta comprensión intuitiva tiene acerca de sus propios motivos?
Orientación hacia la carrera	Necesidad de avance: ¿En qué grado esta persona necesita un ascenso significativo antes que sus pares? ¿En qué grado necesita más ascensos para obtener satisfacción profesional? Necesidad de seguridad: ¿Cuánta necesidad tiene de un empleo seguro? Capacidad de espera por la gratificación: ¿En qué medida puede esperar pacientemente por un ascenso, si tiene la confianza en que éste llegará? Realismo en las expectativas: ¿En qué grado las expectativas de esta persona acerca de su vida laboral en la empresa corresponden con lo que es probablemente cierto? Orientación a los valores del sistema Bell: ¿En qué grado ha incorporado los valores del sistema Bell como servicio, cordialidad, justicia en la posición de la empresa en los sueldos, tarifas y salarios?
Dependencia	Necesidad de aprobación superior: ¿En qué medida esta persona necesita del apoyo cálido y educativo de parte de sus supervisores inmediatos? Necesidad de aprobación de sus compañeros: ¿En qué medida necesita de la calidez y aceptación de sus compañeros? Flexibilidad de metas: ¿En qué medida podría reorientar su vida hacia una meta diferente?

Fuente: Bray (1982).

esenciales varios componentes de la visión, se aplicaría una prueba de agudeza visual junto con una prueba de la eficiencia visual, de visión estereoscópica (la capacidad para percibir distancia y profundidad) y de daltonismo.

En muchos empleos se requiere de buena condición física general, como en el trabajo policiaco, donde los candidatos exitosos algún día podrían tener que perseguir a pie a un sospechoso que intente escapar, o defenderse de un sospechoso que se resista al arresto. Las pruebas utilizadas para evaluar tal aptitud podrían incluir un examen físico general, pruebas de fortaleza física y una prueba del desempeño que satisfaga algún criterio determinado respecto a la velocidad y

la agilidad para correr. Se incluirían tareas como saltar algún objeto, caminar sobre llantas y atravesar por el marco de una ventana para simular una carrera sobre terreno difícil.

En algunos casos, el hecho de que un empleador establezca ciertos requisitos físicos para dar el empleo es tan razonable y necesario que con toda facilidad lo respaldaría un tribunal si esto fuera cuestionado. Sin embargo, otros requisitos físicos para el empleo pueden estar situados en un área incierta. En general, la ley favorece los estándares físicos que no son discriminatorios y se relacionan con el trabajo.

También bajo el apartado de pruebas físicas se encuentran las pruebas de integridad-daño sensorial, incluyendo evaluaciones de daltonismo, agudeza visual, percepción visual de profundidad y agudeza auditiva. Estos tipos de pruebas son utilizadas de manera rutinaria en escenarios industriales en los que la capacidad para percibir color o tener vista y oído razonablemente buenos resultan esenciales para el empleo. Además, las técnicas físicas han sido aplicadas para evaluar la honradez e integridad moral, como es el caso del polígrafo y de las pruebas para detectar el consumo de drogas.

SÓLO PIENSE...

"Un oficial de policía debe cumplir ciertos requerimientos mínimos de estatura." ¿Qué piensa usted al respecto?

Pruebas de consumo de drogas Más allá de las preocupaciones acerca de los requisitos laborales tradicionales de naturaleza física, emocional y cognoscitiva, existe una gran preocupación por el uso de drogas entre los empleados. Los gerentes de personal y recursos humanos buscan con mayor frecuencia tener la seguridad de que las personas que contratan y el personal que actualmente labora no utilizan ni utilizarán drogas ilegales. Las cantidades de dinero varían según la fuente de información, pero los estimados de las pérdidas empresariales en el lugar de trabajo debido de manera directa o indirecta al uso de drogas o alcohol por parte de los empleados llega a las decenas de miles de millones de dólares. La pérdida de ingresos puede deberse a lesiones a personas o animales, al daño a los productos y al ambiente, o al ausentismo, retrasos e incapacidades de los empleados. Además, no existe ninguna cantidad de dinero que pueda pagarse por la trágica pérdida de una vida que puede ser el resultado de una desgracia relacionada con las drogas o el alcohol.

Las pruebas de consumo de drogas son una práctica creciente entre las corporaciones mundiales, con más de la mitad de las compañías importantes efectuando alguna forma de examen de drogas. Los solicitantes de empleo pueden ser examinados durante el proceso de selección. Es característico que los empleados sean sometidos a una prueba sólo si se sospecha que consumen drogas. Las pruebas aleatorias para detectar el uso de éstas son relativamente poco comunes en las empresas privadas, aunque son más comunes en las instituciones de gobierno y el ejército.

Los métodos para examinar el consumo de drogas son variados. Un método, el inmunoanálisis, emplea la orina del sujeto para determinar la presencia o ausencia de drogas en el organismo mediante la identificación de los productos secundarios de la droga metabolizados (metabolitos). Aunque es ampliamente utilizada en escenarios laborales, la prueba puede ser criticada por su incapacidad para especificar la cantidad precisa de droga que ha sido ingerida, cuándo fue consumida y cuál de varias drogas posibles en una categoría particular se ha consumido. Además, no hay manera de estimar el grado de daño que ha ocurrido a causa de la droga. La prueba de cromatografía de gases-espectrometría de masa (CGEM) no sólo examina los metabolitos en la orina para determinar la presencia o ausencia de drogas, sino también puede especificar de manera más precisa cuál droga fue consumida. No obstante, la tecnología CGEM no puede establecer con exactitud el momento en que la droga fue ingerida o el grado de deterioro que ha causado.

SÓLO PIENSE...

En términos generales, ¿son adecuadas las pruebas aleatorias en el lugar de trabajo para detectar consumo de drogas?

Muchos empleados se oponen a las pruebas de consumo de drogas como condición para obtener un empleo y han argumentado que esas pruebas violan sus derechos constitucionales a la privacidad y a la libertad de oponerse al allanamiento, registro e incautación sin fundamento. En el curso de un proceso legal, una interrogante que surge con frecuencia es la validez de las pruebas de consumo de drogas. En esos casos, las consecuencias de **falsos positivos** (un individuo que da un resultado positivo de consumo de drogas cuando en realidad no las ha consumido) y **falsos negativos** (un individuo que da resultados negativos de consumo de drogas cuando éste sí ha ocurrido) pueden ser de gran importancia.

Un falso positivo puede tener como resultado, entre otras cosas, la pérdida de su propio medio de subsistencia. Un falso negativo puede resultar en que una persona dañada trabaje en un puesto de responsabilidad y ponga en riesgo a otros individuos.

Las técnicas modernas en laboratorios de análisis clínicos tienden a ser precisas de manera relativa en la detección de los metabolitos reveladores. Las tasas de error generalmente se encuentran muy por abajo del 2% (West y Ackerman, 1993). Sin embargo, las técnicas de laboratorio no siempre podrán ser utilizadas correctamente. Según un estimado, un total de 93% de los laboratorios que realizan pruebas de consumo de drogas no satisfacen los estándares establecidos para reducir el error humano (Comer, 1993). También puede haber errores en la interpretación de los resultados. Los metabolitos pueden ser identificados de manera precisa, pero no siempre puede determinarse si tuvieron su origen por el abuso de alguna droga ilícita o por haber tomado algún medicamento que puede adquirirse sin receta médica. Para ayudar a prevenir esa confusión, es característico que quienes administran la prueba de orina pidan a los sujetos que proporcionen una lista de cualquier medicamento que estén tomando en ese momento. Sin embargo, no todos los sujetos están dispuestos o son capaces de recordar todas las medicinas que hayan tomado para el tratamiento de padecimientos que estén asociados con algún estigma social, como la depresión o la epilepsia. Además, algunos alimentos también pueden producir metabolitos similares a los de algunas drogas ilegales. Por ejemplo, se detectarán metabolitos de los opiáceos luego de que una persona haya ingerido semillas de girasol —que son totalmente legales— (West y Ackerman, 1993).

Otra interrogante relacionada con la validez de las pruebas para detectar consumo de drogas tiene que ver con el grado en que las drogas identificadas a través de la prueba afectan de hecho el desempeño laboral. Algunas drogas son desechadas por el organismo de manera muy lenta. Por ejemplo, una persona puede dar un resultado positivo por uso de marihuana hasta un mes después de haberla consumido. De esta manera, el residuo de la droga permanece mucho más tiempo en el organismo que cualquier efecto perceptible por haberla ingerido. Por contraste, la cocaína es eliminada del cuerpo en sólo tres días. Es posible que un usuario habitual de cocaína se haya abstenido de la droga durante tres días y padezca una grave alteración como resultado de la abstinencia, pero no obstante dé un resultado negativo de uso de drogas. Así, ni un resultado positivo ni uno negativo respecto a una prueba de drogas necesariamente significa que la conducta haya sido o no deteriorada por el consumo de drogas (Comer, 1993).

Una evaluación alternativa del consumo de drogas implica utilizar pruebas de desempeño para examinar directamente el grado de deterioro. Por ejemplo, hay disponibles sofisticadas pruebas, al estilo de los juegos de video, de coordinación, juicio y tiempo de reacción para comparar el desempeño actual con una pauta de desempeño que fue establecida con pruebas anteriores. Las ventajas de estas pruebas de desempeño sobre los exámenes de consumo de drogas, incluyen una evaluación más directa del deterioro, menos preocupaciones éticas respecto a la invasión de la privacidad e información inmediata acerca del daño. Esta última ventaja es particularmente vital para prevenir que individuos potencialmente deteriorados se dañen a sí mismos o a otras personas. Las organizaciones que utilizan esas pruebas electrónicas han reportado una mayor satisfacción de los empleados y menos accidentes (Comer, 1993).

Productividad, motivación, actitud y cultura organizacional

Más allá de su uso en la orientación previa a la contratación y en la detección, selección, clasificación y colocación de personal, se utilizan diversas herramientas para lograr varios objetivos en el lugar de trabajo. Revisemos brevemente algunos de estos variados usos de las herramientas de evaluación con referencia a las pruebas de capacidad cognitiva, productividad, motivación y cultura organizacional.

Pruebas de capacidad cognitiva

Las decisiones de selección respecto al personal, así como otros tipos de decisiones de selección, como las relacionadas con el otorgamiento de licencias profesionales o la aceptación a un

adiestramiento académico, con frecuencia se basan, cuando menos en parte, en el desempeño en pruebas que evalúan conocimientos adquiridos al igual que diversas habilidades y capacidades cognitivas. En general, las pruebas basadas en la cognición son herramientas populares de selección debido a que se ha demostrado que son medios válidos de predicción del desempeño futuro (Schmidt y Hunter, 1998). Sin embargo, junto con sus impresionantes antecedentes existen varias consideraciones potenciales respecto a los temas relativos a la diversidad.

Selección de personal y temas de diversidad El uso ininterrumpido de las pruebas que examinan principalmente las capacidades y habilidades cognitivas para la detección, selección, clasificación y colocación se ha vuelto polémico. Esta controversia se deriva de un conjunto bien documentado de evidencias que indican las consistentes diferencias de grupo en las pruebas de la capacidad cognitiva. Por ejemplo, en promedio, los asiáticos tienden a obtener calificaciones mayores que los blancos en pruebas de la capacidad matemática y cuantitativa, mientras que los blancos obtienen calificaciones más altas que los asiáticos en pruebas de capacidad verbal y de comprensión. En promedio, los blancos también tienden a obtener mayores calificaciones en las pruebas de capacidad cognitiva que los afroamericanos o hispanos. Dado que las calificaciones de prueba pueden diferir en promedio tanto como una desviación estándar (Sackett *et al.*, 2001), esas diferencias pueden tener gran repercusión sobre quién obtiene determinado empleo o quién es aceptado dentro de una institución de educación superior; las diferencias promedio entre los grupos en pruebas de capacidad cognitiva pueden contribuir a limitar la diversidad en los escenarios laborales, en las profesiones y en el acceso a la educación y la capacitación.

Promover la diversidad en los escenarios laborales, en las profesiones y en el acceso a la educación y la capacitación es en beneficio de la sociedad. Para lograr ese objetivo, se ha estimulado la diversidad por diversos medios en el pasado. Un enfoque incluyó el uso de calificaciones abreviadas en pruebas definidas con base en la pertenencia de grupo. Sin embargo, ha habido una tendencia general apartada de los esfuerzos que implican el tratamiento preferencial a cualquier grupo con respecto a los resultados de las pruebas. Esta tendencia es evidente en la legislación, las decisiones judiciales y las consultas públicas. Por ejemplo, la Ley de los Derechos Civiles de 1991 determinó que era una práctica ilegal que los empleadores ajusten las puntuaciones de la prueba aplicada en función de la pertenencia de grupo. En 1996, se aprobó en California la Proposición 209 que prohíbe el uso de la pertenencia de grupo como base para cualquier decisión de selección en ese estado. En ese mismo año, un tribunal federal dictaminó que la raza no era un criterio adecuado para seleccionar a los solicitantes de ingreso en las universidades (*Hopwood vs el estado de Texas*, 1996). En el estado de Washington, los votantes aprobaron leyes que prohíben el uso de la raza como criterio de aceptación en las universidades o para contratación y empleo (Verhovek y Ayres, 1998).

¿Cuánta diversidad puede lograrse en el lugar de trabajo y en otros escenarios mientras aún se usen pruebas conocidas por ser buenos medios para predecir el desempeño en tanto no incorporen en los criterios de selección una preferencia por ningún grupo? Aunque es probable que una respuesta única a esta compleja pregunta no satisfaga a todos los involucrados, hay trabajos que requieren ser realizados y asientos que esperan ser ocupados en instituciones educativas y de capacitación; debe encontrarse alguna estrategia para equilibrar los diversos intereses. Sackett *et al.* (2001) propusieron que los empleadores y otros usuarios de pruebas de capacidad cognitiva utilicen los formatos estructurados para ser usados en video y computadora para aplicar esas pruebas, al igual que cualquier otro formato que pueda reducir al mínimo el contenido verbal y las demandas de habilidades y capacidades verbales de las personas examinadas. También recomendaron otras estrategias, como depender más en la experiencia laboral o de vida como parte de los criterios de selección. Sin embargo, Sackett *et al.* (2001) también aconsejaron que “las diferencias entre subgrupos no sean simplemente artificios de las tecnologías con papel y lápiz” (p. 316) y la responsabilidad de la sociedad en general es atender de manera efectiva esos asuntos más allá de las pruebas.

SÓLO PIENSE...

¿En qué formas globales, la sociedad en general puede atender asuntos externos a las pruebas?

Productividad

La **productividad** puede ser definida simplemente como el resultado o valor producido en relación con el esfuerzo laboral realizado. El término es utilizado aquí en su sentido más amplio y puede aplicarse por igual a los trabajadores que fabrican productos y a los trabajadores que proporcionan servicios. Para que una empresa tenga éxito, es esencial el monitoreo de la producción con la meta final de maximizar esa producción. Las pruebas de productividad ayudan a definir no sólo la situación de un negocio, sino también qué necesita para llegar a donde quiere estar. Por ejemplo, un fabricante de televisores podría descubrir que las personas que fabrican la cubierta están trabajando con una eficiencia óptima, pero las personas responsables de instalar el cinescopio en los gabinetes están trabajando a la mitad de la eficiencia esperada. Una evaluación de la productividad puede ayudar a identificar los factores responsables del bajo desempeño de los empleados encargados de instalar los cinescopios.

Por medio de técnicas como las clasificaciones del supervisor, entrevistas con los empleados

y empleados encubiertos trabajando en el taller de cinescopios, la gerencia podría determinar qué —o quién en particular— es responsable del desempeño insatisfactorio. Tal vez el método más común para evaluar la productividad o desempeño del trabajador sea mediante el uso de procedimientos de clasificación y jerarquización realizado por los superiores de la organización. Un tipo de procedimiento de jerarquización utilizado para evaluar a un gran número de empleados es la **técnica de distribución forzada**. Este procedimiento implica distribuir un número o porcentaje prede-

terminado de individuos evaluados dentro de diversas categorías que describen el desempeño (como *insatisfactorio*, *deficiente*, *adecuado*, *promedio*, *bueno*, *superior*). Otro índice de desempeño en el trabajo es el número de faltas dentro de un periodo determinado. Las cuales reflejarán, de manera singular, la deficiencia de un empleado que haya faltado a trabajar en 20 ocasiones diferentes, por ejemplo, 20 ausencias consecutivas debido a una enfermedad.

La **técnica de incidentes críticos** (Flanagan y Burns, 1955) incluye un registro del supervisor acerca de las conductas positivas y negativas de los empleados. El supervisor hace la lista de sus anotaciones de acuerdo con diversas categorías (por ejemplo, *confiabilidad* o *iniciativa*) para una referencia rápida cuando es necesario hacer una evaluación. Cierta evidencia sugiere que cuando un nuevo empleado comienza a trabajar hay un periodo de armonía y buena disposición que dura cerca de tres meses y que las calificaciones de supervisión reflejarán de manera más veraz el desempeño del trabajador al concluir ese periodo.

Las calificaciones o valoraciones de pares realizadas por otros trabajadores del mismo nivel han demostrado ser un método valioso para identificar a los empleados talentosos. Aunque los compañeros tienden a calificar a sus pares en una categoría más elevada de la que lo harían sus superiores, la información obtenida a partir de las calificaciones y jerarquizaciones de los compañeros puede ser adecuada para predecir el desempeño futuro. Por

ejemplo, un estudio incluyó a 117 agentes de seguros de vida inexpertos que asistieron a un curso de capacitación de tres semanas. Al concluir el curso, se pidió a los agentes de seguros en desarrollo que seleccionaran a las tres mejores personas en su clase respecto a 12 situaciones diferentes. A partir de estos datos se obtuvo una puntuación compuesta para cada uno de los 117 agentes. Después de un año, las calificaciones de los compañeros y otras tres variables fueron correlacionadas con la permanencia en el trabajo (número de semanas en el empleo) y con la producción (cantidad de ingresos por los seguros vendidos). Como puede observarse en la

tabla 16-5, las calificaciones de los compañeros tuvieron la mayor validez en todas las categorías. Por el contrario, se obtuvo una correlación cercana a cero entre la calificación final del curso y todas las categorías.

¿Existe un lado negativo en las calificaciones realizadas? Absolutamente sí. Incluso cuando éstas se realizan de manera anónima, una persona que ha sido calificada puede percibir cuando

SÓLO PIENSE...

¿Cuáles podrían ser las consecuencias de largo alcance de las técnicas de evaluación al utilizar “empleados encubiertos” en un escenario de ensamblado?

SÓLO PIENSE...

Supongamos que su maestro estableciera un sistema de calificación por los propios compañeros como el único determinante para su calificación en la clase de medición. ¿Sería mejor ese sistema que el utilizado ahora?

Tabla 16-5
Calificación de los pares y el desempeño de los vendedores de seguros de vida

	Permanencia en el empleo		Producción	
	6 meses	1 año	6 meses	1 año
Calificación de los pares	.18*	.29 [†]	.29 [†]	.30 [†]
Edad	.18*	.24 [†]	.06	.09
Salario inicial	.01	.03	.13	.26 [†]
Calificación final del curso	.02	.06	-.02	.02

Fuente: Mayfield (1972)

* $p = .05$ (prueba de una cola)

[†] $p = .01$ (prueba de una cola)

algún compañero receloso lo ha calificado demasiado bajo. La reacción de ese individuo puede ser que él o ella, a su vez, en venganza califique demasiado bajo a ese compañero receloso. También, los compañeros no siempre tienen una base para juzgar los criterios que la escala de clasificación les solicita estimar. Pero esto no detiene a un clasificador en el lugar de trabajo para calificar a un compañero. En lugar de calificar al compañero según los criterios enumerados en el cuestionario, el clasificador podría utilizar uno personal como “¿Qué ha hecho por mí esta persona últimamente?” para responder a la escala.

En muchas organizaciones, las personas trabajan en equipos. En un contexto organizacional o de trabajo, un **equipo** puede ser definido como dos o más personas que interactúan dependiendo la una de la otra para llegar a una meta común o valiosa, a quienes se han asignado responsabilidades o funciones específicas que deben llevar a cabo. Para un equipo de ventas, la división de labores puede reflejar de modo simple las divisiones de los territorios de ventas. En la creación de un complicado programa de cómputo, la división del trabajo puede implicar la asignación de tareas que son demasiado complicadas para un solo individuo. La operación de un barco crucero o de un buque militar requiere de un equipo entrenado debido a la multitud de tareas que deben realizarse para navegar el barco. Para lograr una mayor productividad, las organizaciones se preguntan “¿Qué sabe el equipo?” y “¿Cuánto difiere en términos cualitativos el conocimiento colectivo del equipo respecto al conocimiento individual y experiencia de cada uno de los miembros del equipo?” Para responder a éstas y otras preguntas relacionadas, ha comenzado a surgir literatura que explora las diferentes maneras de medir el conocimiento del equipo (véase, por ejemplo, Cannon-Bowers *et al.*, 1998; Cooke *et al.*, 2000; Salas *et al.*, 1998).


Motivación

¿Por qué algunas personas no salen a comer, trabajan tiempo extra o se llevan trabajo a casa en las noches, mientras que otros se esfuerzan por hacer lo menos posible y llevan una vida de ocio en el trabajo? En un nivel práctico, se pueden responder esas preguntas utilizando instrumentos de evaluación que recaban los valores de la persona evaluada. Tratar con una población de personal no calificado puede requerir de técnicas especialmente diseñadas. Champagne (1969) respondió al desafío de saber poco acerca de lo que puede interesar a las personas de áreas rurales sin experiencia en sus intentos por atraerlas al trabajo, así que diseñó un cuestionario motivacional. Como lo ilustran los tres reactivos de la figura 16-5, el cuestionario utilizó un formato de comparaciones pareadas (de opción forzada) que requerían que el sujeto escogiera opciones relacionadas con 12 factores utilizados por las empresas para captar solicitudes de empleo: salarios justos, trabajo estable, vacaciones y días festivos pagados, prestaciones adicionales como pensiones y beneficios por enfermedad, un jefe imparcial, trabajo interesante, buenas condiciones de trabajo, posibilidades de ascenso, un trabajo cerca de casa, trabajar con amigos y vecinos, compañeros de trabajo agradables y elogios por un trabajo bien hecho.


El factor de búsqueda de empleo que resultó ser más importante en la muestra de Champagne de 349 sujetos hombres y mujeres, sin experiencia y provenientes de áreas rurales, fue el *trabajo estable*. El factor menos importante fue *trabajar con amigos y vecinos*. Los *elogios por un trabajo bien hecho* estuvieron muy cercanos a ser el factor menos importante. Al interpretar sus hallazgos,



Vacaciones y días festivos pagados...




...prestaciones adicionales como pensiones, beneficios por enfermedad, etcétera.




Un trabajo cerca de casa...



...un jefe justo



Trabajar con amigos y vecinos...



...la oportunidad de un ascenso.



Figura 16-5
Estudio de valores con trabajadores no calificados

Champagne (1969) utilizó reactivos de prueba como los que se ilustran aquí en un estudio de reclutamiento con una población rural, no calificada.



Figura 16-6
Jerarquía de necesidades de Maslow (adaptado de Maslow, 1970)

Champagne advirtió que “los factores reportados aquí se relacionan con el comportamiento de búsqueda de empleo de quienes no tienen experiencia y no son pruebas de cómo conservar y motivar a los trabajadores no calificados una vez que han sido contratados... Lo que motiva a una persona a aceptar un empleo no necesariamente es lo mismo que la motiva a conservarlo o a realizarlo bien” (p. 268).

En un nivel teórico, una gran cantidad de teorías intentan delinear las necesidades, actitudes, influencias sociales específicas y otros factores que podrían explicar las diferencias en la motivación. Por ejemplo, Vroom (1964) propuso una teoría de expectativas acerca de la motivación, la cual en esencia sostiene que los empleados gastan energía de maneras diseñadas para lograr el resultado que quieren; entre mayor sea la expectativa de que un acto logrará un cierto resultado, mayor será la energía que se gaste para lograr ese resultado. Maslow (1943, 1970) construyó una jerarquía teórica de las necesidades humanas (figura 16-6) y propuso que a medida que se satisface una categoría de necesidad, las personas avanzan a la satisfacción de la siguiente categoría de necesidad.

Los empleadores que están de acuerdo con la teoría de Maslow buscarían identificar 1) el nivel de necesidad que el trabajo requiere del empleado y 2) el nivel actual de necesidad del posible empleado. Alderfer (1972) propuso una teoría alternativa de necesidad de la motivación, que no era jerárquica. En tanto Maslow consideraba que la satisfacción de una necesidad conducía a la satisfacción de la siguiente necesidad en la jerarquía, Alderfer propuso que una vez que se satisface una necesidad, el organismo podría esforzarse por satisfacerla en un grado aún mayor. La teoría de Alderfer también concede que la frustración de una necesidad podría canalizar la energía hacia el logro de una necesidad en otro nivel.

En un programa ampliamente citado que se hizo cargo de definir las características de la motivación de logro, McClelland (1961) utilizó como su medida de motivación las historias escritas bajo instrucciones especiales para las ilustraciones del TAT (Prueba de apercepción temática) y de otras pruebas similares. McClelland describió al individuo con una fuerte necesidad

SÓLO PIENSE...

¿Qué lo motiva a hacer lo que hace?
¿Cuál sería la mejor manera de medir esa motivación?

de logro como alguien que prefiere una tarea que no sea demasiado sencilla ni extremadamente difícil, algo con riesgos moderados, pero no extremos. Una situación con poco o ningún riesgo no conducirá a sentimientos de logro si el individuo logra el éxito. Por otro lado, una situación de riesgo extremadamente elevado quizá no conduzca a sentimientos de logro debido a la alta probabilidad de fracaso. Las personas con fuerte necesidad de logro disfrutan al asumir la responsabilidad de sus actos porque desean crédito y reconocimiento por sus logros. Esos individuos también desean información sobre su desempeño para mejorar constantemente sus resultados. Otros investigadores también utilizaron ilustraciones parecidas a las del TAT y sus propios sistemas de calificación diseñados especialmente para estudiar áreas relacionadas con la motivación humana como el temor al fracaso (Birney *et al.*, 1969; Cohen y Houston, 1975; Cohen y Parker, 1974; Cohen y Teevan, 1974, 1975; Cohen *et al.*, 1975) y el temor al éxito (Horner, 1973).

La motivación puede ser conceptualizada como proveniente de incentivos que tienen principalmente un origen ya sea interno o externo. Otra manera de expresar esto es hablar de *motivación intrínseca* y *motivación extrínseca*. En la **motivación intrínseca**, la principal fuerza que impulsa al individuo proviene de cosas como la participación del individuo en el trabajo o la satisfacción con los resultados del trabajo. En la **motivación extrínseca**, la principal fuerza impulsora del individuo proviene de las recompensas, como salario y bonos, o de las restricciones, como la pérdida del empleo.

Una escala diseñada para evaluar los aspectos de la motivación intrínseca y extrínseca es el Inventario de preferencias laborales (*Work Preference Inventory*, WPI; Amabile *et al.*, 1994). El WPI contiene 30 reactivos que se califican en una escala de 4 puntos en base a qué tan autodescriptivo le parece el reactivo a la persona examinada. El análisis factorial indica que la prueba parece medir dos factores diferentes: motivación intrínseca y extrínseca. Cada uno de estos dos factores se puede dividir en dos subfactores. El factor de motivación intrínseca puede dividirse en un subfactor que tiene que ver con el desafío que representan las tareas realizadas en el trabajo y otro factor relacionado con el disfrute del trabajo. El factor de motivación extrínseca puede dividirse en un factor que se relaciona con la compensación del trabajo y otro que tiene que ver con las influencias externas como el reconocimiento de otras personas al trabajo que el individuo realiza. Se ha demostrado que el WPI es internamente consistente y que se correlaciona en la dirección predictiva con pruebas conductuales y otros cuestionarios de motivación.

En algunos casos, parece como si la motivación para realizar un trabajo particular se hubiera reducido notablemente en comparación con los niveles anteriores. Éste es el caso del fenómeno conocido como *agotamiento*.

El agotamiento y su medición El *agotamiento* es un problema de salud laboral asociado con la tensión ocupacional acumulativa (Shirom, 2003). El **agotamiento** ha sido definido como “un síndrome psicológico de extrema fatiga emocional, despersonalización y reducción en el logro personal que puede ocurrir entre individuos que de alguna manera trabajan con otras personas” (Maslach *et al.*, 1997, p. 192). En esta definición, *fatiga emocional* se refiere a la incapacidad para darse emocionalmente a los demás y *despersonalización* se refiere a distanciarse de otras personas e incluso a desarrollar actitudes cínicas hacia los demás. Las consecuencias potenciales del agotamiento varían desde el deterioro en el servicio proporcionado, hasta el ausentismo y la rotación laboral. Los efectos potenciales del agotamiento en un trabajador que lo padece varían desde el insomnio hasta el abuso de alcohol y drogas.

La medida de uso más común para el agotamiento es el Inventario Maslach de agotamiento (*Maslach Burnout Inventory*, MBI), tercera edición (Maslach *et al.*, 1996). Desarrollada por Christina Maslach y sus asociados, esta prueba contiene 22 reactivos divididos en tres subescalas: fatiga emocional (nueve reactivos), despersonalización (cinco reactivos) y logro personal (ocho reactivos). Los individuos examinados responden en una escala que va de 0 (*nunca*) hasta 6 (*todos los días*) a reactivos como el siguiente que proviene de la escala de fatiga: *Trabajar todo el día es una fuente de gran esfuerzo para mí*. El manual del MBI contiene datos pertinentes a la solidez psicométrica de las pruebas. Se incluye un análisis sobre la validez discriminativa en la que el agotamiento se distingue conceptualmente de conceptos similares como depresión e insatisfacción con el trabajo.

Al utilizar instrumentos como el MBI, los investigadores han encontrado que algunas ocupaciones parecen ser propensas a mayores niveles de agotamiento que otras. En esta situación se encuentran, por ejemplo, el personal de enfermería (Happell *et al.*, 2003) y áreas relacionadas, incluyendo al personal de instituciones residenciales que atienden a ancianos (Evers *et al.*, 2002) y niños (Decker *et al.*, 2002). No se sabe exactamente por qué sucede esto. En un estudio que utilizó como sujetos a miembros del personal de servicios de apoyo a los estudiantes, al igual que una medida de satisfacción con el trabajo, se encontró que los bajos niveles de satisfacción con el trabajo conducían a mayores niveles de fatiga emocional, componente del agotamiento (Brewer y Clippard, 2002).

SÓLO PIENSE...

¿Por qué tendría importancia decisiva que algunos empleadores supieran si sus empleados están al borde del agotamiento? Además de aplicar una prueba, ¿de qué otro modo podría ser estimado el agotamiento?

Actitud

Una **actitud** puede definirse de modo formal como una disposición supuestamente aprendida a reaccionar de alguna manera característica ante un estímulo particular. El estímulo puede ser un objeto, un grupo, una institución, casi cualquier cosa. Más adelante en este capítulo analizaremos la manera en que se miden las actitudes hacia los bienes y servicios. Sin embargo, de manera más inmediata, nos enfocamos en las actitudes relacionadas con el lugar de trabajo. Aunque las actitudes no necesariamente predicen el comportamiento (Tittle y Hill, 1967; Wicker, 1969), ha habido gran interés en medir las actitudes de empleadores y empleados entre sí, al igual que hacia las diversas variables relacionadas con el lugar de trabajo. Por ejemplo, se han hecho muchas investigaciones sobre el tema de la satisfacción en el trabajo.

Satisfacción en el trabajo En comparación con los trabajadores insatisfechos, se considera que los trabajadores satisfechos son más productivos (Petty *et al.*, 1984), más consistentes con los resultados del trabajo (Locke, 1976), con menos probabilidad de quejarse (Burke, 1970; Locke, 1976) y con menor probabilidad de ausentarse, faltar a sus trabajos o de ser reemplazados (Herzberg *et al.*, 1957; Vroom, 1964). Aunque estas suposiciones son un tanto polémicas (Iaffaldano y Muchinsky, 1985), y de manera probable deberían considerarse según cada caso particular, los empleadores, empleados, investigadores y consultores han mantenido un permanente interés en la medición de la satisfacción en el trabajo. Tradicionalmente, la **satisfacción en el trabajo** ha sido definida como “un estado emocional placentero o positivo como resultado de la apreciación del propio trabajo o las experiencias en el mismo” (Locke, 1976, p. 300).

Una medida diagnóstica de la satisfacción en el trabajo (o, en este caso, de la insatisfacción) implica grabar en video a un empleado durante su trabajo y después reproducir el video para él mismo mediante un procedimiento asistido por computadora (Johansson y Forsman, 2001). El empleado hace una selección con el ratón de la computadora en los controles virtuales para indicar cuando surge una situación insatisfactoria y esto abre en forma automática una ventana con preguntas. Según los datos provenientes de estudios con trabajadores manuales, el análisis de las respuestas puede ser útil para crear un ambiente laboral más satisfactorio (Johansson y Forsman, 2001).

Por supuesto, las pruebas contemporáneas de satisfacción en el trabajo pueden enfocarse en otros elementos del empleo, incluyendo las evaluaciones cognitivas que implica la realización del trabajo (Organ y Near, 1985), el horario de trabajo (Baltes *et al.*, 1999; Barnett y Gareis, 2000), las fuentes percibidas de tensión (Brown y Peterson, 1993; Vagg y Spielberger, 1998), diversos aspectos del bienestar (Daniels, 2000) y la desigualdad entre los antecedentes culturales de un empleado y la cultura organizacional prevaleciente (Aycan *et al.*, 2000; Early *et al.*, 1999; Parkes *et al.*, 2001). Además de la satisfacción en el trabajo, otros constructos relacionados con el empleo que han atraído la atención de los teóricos y profesionales de la evaluación incluyen el compromiso con el trabajo, la importancia del trabajo, la socialización organizacional y el compromiso organizacional (Caught *et al.*, 2000; Nystedt *et al.*, 1999; Paullay *et al.*, 1994; Taormina y Bauer, 2000). Antes de enfocarnos en el constructo más amplio de la cultura organizacional, examinemos brevemente el concepto de compromiso organizacional.

Tabla 16-6
Consecuencias del nivel de compromiso organizacional para los empleados individuales y la organización

		Nivel de compromiso organizacional	
		Bajo	Alto
El empleado individual	Consecuencias potencialmente positivas para la oportunidad de expresión de originalidad e innovación, pero un total efecto negativo sobre las oportunidades de avance en la carrera.	Acrecentado sentido de pertenencia y seguridad, acompañado de dudas acerca de la oportunidad de avance.	Mayor oportunidad de avance y compensación por los esfuerzos, con menos oportunidad de crecimiento personal y posibilidad de tensión en las relaciones familiares.
La organización	Ausentismo, retrasos, rotación de personal y baja calidad del trabajo.	Comparado con el bajo compromiso, menos ausentismo, retrasos, rotación y mejor calidad del trabajo, así como un aumento en el nivel de satisfacción con el trabajo.	Potencial de alta productividad, pero en ocasiones acompañado de una carencia de revisión crítica-ética del comportamiento del empleado y de una reducción en la flexibilidad de la organización.

Compromiso organizacional El compromiso organizacional puede definirse como la “intensidad de la identificación de un individuo con una organización particular y de su participación en la misma” (Porter *et al.*, 1974, p. 604). Esta “intensidad” ha sido conceptualizada y medida en formas que enfatizan tanto sus componentes de conducta como de actitud (Mathieu y Zajac, 1990). En general, el **compromiso organizacional** se refiere a los sentimientos de lealtad, identificación y participación con una organización. Las correlaciones supuestas de compromiso organizacional alto y bajo, según las observaciones de Randall (1987), se resumen en la tabla 16-6. La prueba más utilizada para medir este constructo es el Cuestionario de compromiso organizacional (*Organizational Commitment Questionnaire* OCQ; Porter *et al.*, 1974), una escala Likert de 15 reactivos donde los respondientes expresan sus actitudes relacionadas con el compromiso hacia una organización. No obstante, a pesar de su extendido uso durante más de un cuarto de siglo, existe relativamente poca evidencia que apoye su validez de constructo (Bozeman y Perrewé, 2001).

Como usted podría esperar, la medición de la actitud va más allá del lugar de trabajo. Por ejemplo, los políticos que buscan la reelección pueden monitorear las actitudes de sus electores sobre diversos asuntos. Volveremos a este tema de la medición de actitudes con un poco más de detalle cuando estudiemos la medición en el área de la psicología del consumidor. Sin embargo, antes de dejar el mundo del trabajo y las organizaciones, examinemos la medición de la cultura organizacional.

Cultura organizacional

La *cultura organizacional*, o cultura corporativa, como se le conoce cuando es aplicada a una empresa o corporación, ha sido definida de muchas maneras. Para nuestros propósitos, definiremos la **cultura organizacional** según Cohen (2001) como la totalidad de los patrones conductuales socialmente transmitidos característicos de una organización o empresa particular, incluyendo la estructura de la organización y las responsabilidades dentro de ella, el estilo de liderazgo, los valores prevalecientes, normas, sanciones y mecanismos de apoyo, al igual que las tradiciones antiguas y el folclor, métodos de aculturación y maneras características de interactuar con las personas e instituciones fuera de la cultura (como clientes, proveedores, competencia, instituciones de gobierno y el público en general).

Muy semejante a los diferentes grupos sociales en diversos momentos a lo largo de la historia, las organizaciones y corporaciones han desarrollado culturas distintivas. Tienen ceremonias, derechos y privilegios —formales e informales— peculiares vinculadas con el éxito y el avance, al igual que diversos tipos de sanciones vinculadas con el fracaso (Trice y Beyer, 1984). Las culturas organizacionales tienen varios instrumentos observables que pueden tener la forma de un reporte anual o de un video de la fiesta de Navidad de la oficina. También es característico que las culturas organizacionales tengan conjuntos de valores o creencias esenciales que guían las acciones de la organización al igual que la dirección hacia la cual avanza.

De la misma manera que el término *cultura* es aplicado de manera tradicional a un grupo de personas que comparten un modo de vida particular, el término *cultura organizacional* se aplica a una *manera de trabajar*. La cultura de una organización proporciona una manera de enfrentar los desafíos y demandas externos e internos. Así como las diferencias entre los modos de pensar y hacer las cosas pueden provocar antagonismos entre grupos de personas, también pueden crear conflictos entre culturas organizacionales. Esos conflictos son quizá más evidentes cuando una empresa con un tipo de cultura corporativa adquiere, o se fusiona con, una empresa que tiene una cultura corporativa muy diferente (Brannen y Salk, 2000; Veiga *et al.*, 2000). Cualquier esfuerzo por corregir este choque entre culturas corporativas debe ser precedido por un estudio medido y la comprensión de las culturas implicadas.

Tal vez debido a que el concepto de cultura organizacional tiene tantas facetas, obtener una medida de éste no es una labor sencilla. Para apreciar qué tan compleja es la tarea de describir una cultura organizacional, imagínese cómo describiría cualquier otro tipo de cultura, la cultura estadounidense, la cultura NASCAR (relacionada con las carreras de autos) o las culturas de la antigüedad.

Como consultor de investigación cualitativa para muchas empresas, el principal autor de este texto se vio enfrentado al reto de evaluar varias culturas organizacionales. Debido a que no existía ninguna medida satisfactoria para realizar esa evaluación, creó un instrumento para hacerlo; ese instrumento es el tema de la *Psicometría cotidiana* de este capítulo.

SÓLO PIENSE...

Describa en detalle una cultura particular que usted conozca bien. ¿Qué dificultades enfrenta al tratar de capturar esta cultura en una descripción?

Otras aplicaciones de las herramientas de evaluación

La experiencia psicométrica tiene aplicación en una amplia variedad de ambientes industriales, organizacionales y relacionados con los negocios. Por ejemplo, los psicólogos experimentales y de ingeniería utilizan una variedad de herramientas de evaluación en su investigación ergonómica (relacionada con el trabajo) y de factores humanos en la medida en que ayudan a desarrollar planes para todo, desde artículos para el hogar (Hsu y Peng, 1993) hasta partes para automóviles (Chira-Chavala y Yoo, 1994) y aeronaves (Begault, 1993). Estos investigadores pueden utilizar instrumentos de medición diseñados para diferentes necesidades, pruebas estandarizadas, o ambos, en sus esfuerzos por comprender mejor la respuesta humana a un equipo o instrumentación específicos en un ambiente particular de trabajo.

Otra área relacionada con los negocios en la cual las pruebas y otras herramientas de evaluación se utilizan de manera amplia es la psicología del consumidor.

Psicología del consumidor

La **psicología del consumidor** es la rama de la psicología social que trata principalmente con el desarrollo, promoción y comercialización de productos y servicios. Como ocurre con casi todas las demás áreas de especialidad en psicología, algunos psicólogos del consumidor trabajan exclusivamente en ambientes académicos, algunos laboran en escenarios aplicados y muchos en

Evaluación de la cultura corporativa y organizacional

Las corporaciones y otras organizaciones han mostrado un creciente interés en el examen y el desarrollo personal-profesional. El análisis de la Cultura Organizacional (*Discussion of Organizational Culture*, DOC; Cohen, 2001) fue diseñado para ayudar en esos esfuerzos. Esta guía de entrevista y análisis, diseñada para ser aplicada por un entrevistador o moderador de un “focus group” con entrenamiento, está dividida en 10 temas de estudio. Las preguntas incluidas en cada tema de estudio exploran diversos aspectos de la cultura organizacional. Comenzando con “Primeras impresiones” y prosiguiendo con otros temas que exploran el contenido relacionado con el espacio físico, los valores prevalecientes y otras áreas, el objetivo es desarrollar un sentido de lo que es único en la cultura de una empresa u organización particular. Los diagnósticos de percepción, útiles para determinar dónde y cómo puede ser mejorada la cultura corporativa u organizacional, pueden derivarse de esos datos. Las limitaciones de espacio nos impiden publicar en su totalidad las diez partes de esta amplia guía de estudio. Sin embargo, tan sólo a partir de las primeras partes reproducidas aquí se puede deducir un juicio de los tipos de preguntas que se plantean para su examen.

Estudio de la Cultura Organizacional (*Discussion of Organizational Culture*, DOC; Cohen, 2001)*

I. Primeras impresiones

1. ¿Qué significa ser un empleado en esta corporación? (Nota: sustituya la terminología según sea apropiado a lo largo del texto. Por ejemplo,

esta pregunta puede enunciarse como “¿Qué significa ser un voluntario en esta organización?” o “¿Qué significa ser un empleado de IBM?”)

2.
 - a) ¿De qué manera es igual trabajar aquí que en cualquier otro sitio?
 - b) ¿Cuál es la diferencia de trabajar aquí que en cualquier otro lugar?
 - c) ¿Qué es lo especial de trabajar aquí?
3.
 - a) Trabajar aquí, ¿de qué manera le hace sentirse parte del equipo?
 - b) Trabajar aquí, ¿cómo le permite sobresalir como individuo?
4.
 - a) ¿Qué sería obvio acerca de esta empresa para cualquier visitante que haya realizado un recorrido por sus instalaciones?
 - b) ¿Qué es obvio de esta empresa sólo para usted?
5. En general, ¿cómo describiría la compatibilidad del personal en esta empresa con los trabajos que les son asignados?
 - a) ¿Cuánta ambigüedad de responsabilidad existe en las descripciones de los puestos?
 - b) Si esa ambigüedad existe, ¿cómo la enfrentan usted y los demás?

II. El espacio físico

1. En términos generales, describa el espacio físico de esta empresa.
2. De manera específica, comente sobre el espacio físico con referencia a:
 - a) el terreno

ambos (Tybout y Artz, 1994). En los estudios aplicados y de investigación, puede encontrarse a psicólogos del consumidor que trabajan estrechamente con profesionales en las áreas de mercadeo y publicidad para ayudar a responder preguntas como las siguientes:

- ¿Existe un mercado para este nuevo producto?
- ¿Existe un mercado para el nuevo uso de un producto existente?
- ¿Exactamente quiénes, respecto a edad, sexo, raza, clase social y otras variables demográficas, constituyen el mercado para este producto?
- ¿Cómo se puede dar a conocer este producto en una población seleccionada de consumidores de manera eficiente en relación con los costos?

- b) las áreas de estacionamiento
 - c) la "sensación" general de los exteriores e interiores
 - d) las oficinas
 - e) las áreas de comedor
 - f) los baños
 - g) las instalaciones para almacenaje
 - h) otros aspectos del espacio físico
3. a) En su totalidad, ¿qué es funcional acerca del espacio físico?
 - b) ¿Qué no es funcional acerca de éste y cómo se podría mejorar?
 4. La manera en que el espacio ha sido distribuido, ¿qué le dice acerca de la empresa?
- III. Estructura y responsabilidades corporativas*
1. Describa la estructura administrativa de esta empresa, incluyendo una breve evaluación de subalternos y jefes.
 - a) ¿Qué es lo que funciona de esta estructura?
 - b) ¿Qué no funciona de la misma?
 - c) ¿Qué es característico de esta estructura?
 - d) Esa estructura, ¿qué le dice acerca de esta empresa?
 2. Describa las responsabilidades asociadas con los puestos laborales claves en la estructura de la organización.
 - a) ¿Hay ambigüedad en las responsabilidades o los empleados tienen una idea clara de su función en la empresa?

- b) ¿Existe alguna responsabilidad dentro de la empresa que parezca anticuada o innecesaria?
 - c) ¿Se necesita crear alguna otra responsabilidad dentro de la empresa? ¿Fortalecerla? ¿Definirla mejor?
 - d) Describa su propia responsabilidad dentro de la empresa y cómo encaja dentro del "esquema total".
 - e) Su responsabilidad, ¿cómo podría mejorarse para obtener un mayor beneficio personal?
 - f) ¿Cómo podría mejorarla en beneficio de la empresa?
3. Qué puede decirse sobre esta empresa al analizar
 - a) sus reportes anuales
 - b) sus archivos
 - c) el tipo de información que hace pública
 - d) el tipo de información que mantiene en privado
 - e) los productos y servicios que proporciona
 - f) la manera en que proporciona esos productos o servicios
 - g) la visión corporativa según la determina la principal gerencia

* Copyright © 2001 de Ronald Jay Cohen. Derechos reservados. Se prohíbe la reproducción en cualquier forma sin autorización por escrito del autor. El autor puede ser contactado a través de McGraw-Hill Higher Education, Permissions Department, 2 Penn Plaza, 9th Floor, New York, NY 10121.

- ¿Cómo se puede persuadir a la población consumidora seleccionada de que compre este producto de la manera más eficiente respecto a costos?
- ¿Cuál es la mejor manera de diseñar un empaque para este producto?²

Un área de interés que comparten los psicólogos del consumidor y los psicólogos en otras áreas de especialidad es la medición de actitudes. No obstante, para un psicólogo del consumidor, una actitud interesante podría ser la que se tiene hacia un producto o concepto particulares.

2. Las cuestiones relacionadas con el empaque y la manera de hacer sobresalir un producto en un anaquel han sido llamadas *valoración de anaquel (shelf esteem)* por los psicólogos del consumidor con sentido del humor.

La medición de actitudes

Las actitudes creadas hacia productos, servicios o nombres comerciales son un centro frecuente de interés en la investigación sobre la actitud de los consumidores. De manera representativa, la actitud se mide con ayuda de autodescripciones, utilizando pruebas y cuestionarios. Una limitación de este enfoque es que las personas difieren en su capacidad de introspección y nivel de autoconciencia. Las personas también difieren en la medida de su disposición a ser sinceras acerca de sus actitudes. En algunos casos, el uso de una medida de actitud puede crear, en esencia, una actitud cuando antes no existía ninguna. En esos estudios, la actitud medida puede ser considerada como una característica del procedimiento de medición (Sandelands y Larson, 1985).

Los cuestionarios y otros instrumentos de autodescripción diseñados para medir las actitudes de los consumidores son desarrollados de modos similares a los descritos anteriormente sobre las pruebas psicológicas en general (véase el capítulo 7). Una descripción más detallada de la preparación de las pruebas de actitud puede encontrarse en lo que ahora es una obra clásica, *Medición de la actitud* (Thurstone y Chave, 1929). Una monografía titulada “Una técnica para la medición de actitudes” (Likert, 1932) proporcionó a los investigadores un procedimiento sencillo para construir un instrumento de medición de actitudes. En esencia, este procedimiento consiste en hacer una lista con afirmaciones (favorables o desfavorables) que reflejen una actitud particular. Después, estas afirmaciones son administradas a un grupo de respondientes cuyas respuestas se analizan para identificar los elementos con mayor capacidad de discriminación —los reactivos que mejor distinguen a las personas en diferentes puntos de una hipotética serie continua— que luego son incluidas en la escala final. Cada afirmación incluida en la escala final es acompañada de una medida continua de 5 puntos de respuestas alternativas. Por ejemplo, esa escala puede variar desde *firmemente de acuerdo* hasta *firmemente en desacuerdo*. La calificación se obtiene asignando significados numéricos de 1 a 5 a cada categoría, de modo que 5 represente la respuesta favorable más firme y 1 la respuesta menos favorable.

La medición de actitudes halladas en la literatura psicológica recorre una gama que varía desde los instrumentos diseñados de manera exclusiva para investigación y examen de formulaciones teóricas, académicas, hasta las escalas con aplicaciones reales de amplio rango. En este último contexto, encontraremos sofisticadas pruebas industriales-organizacionales diseñadas para estimar las actitudes de los trabajadores hacia su empleo o escalas diseñadas para medir las actitudes del público en general hacia algún político o tema. Por ejemplo, la Escala de satisfacción con organizaciones de autoayuda (*Self-Help Agency Satisfaction Scale*), diseñada para estimar la satisfacción de los clientes de organizaciones de autoayuda con aspectos del apoyo que reciben (Segal *et al.*, 2000), es representativa de las pruebas diseñadas para medir la satisfacción del consumidor con un producto o servicio. En la literatura sobre psicología educativa también pueden encontrarse escalas de actitud con una utilidad aplicada. Consideremos en este contexto las pruebas como el Examen de actitudes y métodos de estudio (*Study Attitudes and Methods Survey*; una escala diseñada para evaluar los hábitos de estudio) y el Examen Minnesota de actitudes del maestro (*Minnesota Teacher Attitude Survey*); una escala diseñada para evaluar las relaciones entre maestros y alumnos).

Para ayudar a responder preguntas como las que aparecen en las páginas 554-555, los psicólogos del consumidor pueden recurrir a diversos métodos que se utilizan de manera individual o en combinación. Estos métodos incluyen encuestas, “investigación de motivación” como la denominan los profesionales de la mercadotecnia, y la observación conductual.

Encuestas En la psicología del consumidor, una **encuesta** es una lista establecida de preguntas que se aplican a una muestra seleccionada de personas con el propósito de conocer las actitudes, creencias, opiniones y/o comportamientos del consumidor respecto a productos, servicios o publicidad que son el objetivo del estudio. Existen diferentes procedimientos para realizar una encuesta y estos diversos métodos tienen beneficios y defectos específicos acerca del diseño del estudio e interpretación de los datos (Johnson *et al.*, 2000; Lavrakas, 1998; Massey, 2000; Schwartz *et al.*, 1998; Visser *et al.*, 2000). Un tipo especializado de encuesta, el **sondeo de opinión**, es muy parecido a un instrumento para registrar los votos y en general contiene preguntas que pueden responderse con un simple *sí/no* o *en favor/en contra*. Los políticos, las organizaciones noticiosas

y las organizaciones con intereses especiales pueden contratar a investigadores que realizan sondeos de opinión (encuestadores) para estimar la opinión pública acerca de temas polémicos.

Las encuestas y sondeos de opinión pueden realizarse de manera personal, por una red de computadoras y mediante entrevistas telefónicas, al igual que por correo. La interacción personal en las entrevistas frente a frente ayuda a garantizar que se comprendan las preguntas y que se aclaren las dudas de manera apropiada. Otra ventaja de este método de encuesta es la posibilidad de presentar a los entrevistados los estímulos (los productos mismos), los cuales pueden sostener en sus manos para evaluarlos. Sin embargo, el método de la interacción personal también puede ocasionar sesgo en el estudio, en la medida en que algunos respondientes actúan para dar una impresión favorable o buscan dar respuestas que ellos creen le gustaría escuchar al entrevistador. La entrevista personal podría no ser el mejor procedimiento cuando el tema examinado sea particularmente delicado o cuando las respuestas puedan ser vergonzosas o pongan al entrevistado en una perspectiva desfavorable (Midanik *et al.*, 2001). La entrevista personal también es un trabajo intensivo y, por ende, puede ser muy costosa cuando se trata de seleccionar, capacitar y contratar entrevistadores.

Las encuestas mediante entrevistas personales son un método muy común en la investigación de encuesta y pueden realizarse casi en cualquier sitio, en un autobús de transporte público, en un encuentro deportivo o cerca de una casilla de votación. Un sitio común para una investigación mediante encuestas personales relacionadas con productos de consumo son los centros comerciales. Los *estudios de intercepción en centros comerciales*, como se les denomina, son realizados por entrevistadores, con pequeños tableros sujetapapeles, que abordan a los compradores. Al comprador se le pide que participe en una encuesta respondiendo algunas preguntas justo en el sitio o conduciéndolo a una cabina o alguna habitación donde se efectuará una entrevista más extensa. Otro método de encuesta personal, más popular entre los encuestadores sobre política, es el método de tocar puerta por puerta. En este caso puede sondearse un vecindario completo al visitar cada uno de los hogares y solicitar que se responda al cuestionario.

Las encuestas en línea, por teléfono y por correo no necesariamente requieren el contacto personal entre el investigador y el respondiente, y en muchos casos pueden reducir los sesgos asociados con la interacción personal. Además, los métodos de encuesta realizados sin la interacción personal tienden a ser más eficientes respecto a costos, debido a la automatización de los componentes del proceso, la necesidad de poco personal y menos capacitación, y la posibilidad de llevar a cabo el estudio completo desde una locación central. La encuesta en línea tiene gran potencial debido a su fácil acceso y la posibilidad de retroalimentación (Kaye y Johnson, 1999) y puede ser particularmente útil para conocer diversos aspectos del comportamiento en línea, como las compras (Li *et al.*, 1999) y el trabajo en equipo (Levesque *et al.*, 2001), al igual que el mejoramiento personal (Mueller *et al.*, 2000) y el comportamiento desviado (Greenfield, 1999; Houston *et al.*, 2001; Young *et al.*, 1999). Sin embargo, las encuestas en línea no solicitadas son consideradas por muchos como correo electrónico no requerido o indeseable y esas apreciaciones pueden dar por resultado no sólo una baja tasa de respuestas, sino también una sensación de que se ha violado la privacidad personal (Cho y LaRose, 1999). Los investigadores también podrían tener un cierto grado de duda acerca de si los respondientes son en realidad quienes dicen ser. En este aspecto no hay sustituto para la entrevista personal, que se completa con la verificación de identidad.

Las encuestas telefónicas ofrecen varias ventajas, pero tienen algunas limitaciones. En general, la cantidad de información que puede obtenerse por teléfono es menor a la que se puede obtener mediante una entrevista personal o por correo. No es posible mostrar a los respondientes los estímulos visuales por teléfono. Además, puede aparecer sesgo si se utilizan los directorios telefónicos para identificar a los respondientes. El 40 por ciento del total de los teléfonos en algunas ciudades no están incluidos en la lista. Desde que en 2003 se instauró en Estados Unidos una lista nacional de “No llamar”, la mayoría de los pedidos por teléfono no pueden realizarse marcando un número de manera aleatoria. La principal desventaja de las encuestas telefónicas

SÓLO PIENSE...

¿Alguna vez ha participado en una encuesta de consumo de cualquier tipo? Ya sea que lo haya hecho o no, ¿cuáles son sus recomendaciones para mejorar el proceso y la calidad de los datos obtenidos?

es que son consideradas por la mayoría como una molestia desagradable y una invasión de la vida privada.

La encuesta por correo puede ser el método más apropiado cuando un cuestionario es particularmente extenso y se necesita cierto tiempo para responderlo. En general, las encuestas por correo tienden a tener un costo relativamente bajo debido a que no requieren de los servicios de un entrevistador capacitado y pueden proporcionar grandes cantidades de información. También son muy adecuadas para obtener información sobre la cual los entrevistados pueden ser sensibles o tímidos en una entrevista personal o incluso en una encuesta telefónica. Son ideales para hacer preguntas que requieren el uso de archivos o consultar con otras personas (como miembros de la familia) para dar la respuesta. Nótese que gran parte de lo que decimos sobre las encuestas por correo también se aplica a las encuestas por correo electrónico o por medio de máquinas fax.

Las principales desventajas de los cuestionarios por correo son 1) la posibilidad de no obtener ninguna respuesta del supuesto receptor (por cualquier razón, nunca llegó la encuesta o fue arrojada al bote de basura en cuanto llegó); 2) la posibilidad de que la respuesta venga de otra persona (quizá un miembro de la familia) que no sea el receptor seleccionado y 3) la posibilidad de respuesta tardía y, por ende, inútil para los propósitos de clasificación. Si un gran número de personas no responde a un cuestionario por correo, es imposible determinar si los individuos que respondieron son representativos de los que no lo hicieron. Las personas podrían no responder a un cuestionario por correo debido a varias razones diferentes, y para atender los varios tipos de falta de respuesta se han sugerido diversas técnicas que varían desde los incentivos hasta el correo de seguimiento (Furse y Stewart, 1984).

Es posible combinar los diversos métodos de encuesta para obtener las ventajas de cada uno de ellos. Por ejemplo, el encuestador podría enviar por correo un extenso cuestionario a los posibles encuestados y después obtener sus respuestas por teléfono. De manera alternativa, a los individuos que no regresen sus respuestas por correo se les podría contactar por teléfono o personalmente.

Muchas empresas de investigación comercial llevan una lista con una gran cantidad de personas o familias que están de acuerdo en responder los cuestionarios que se les envíen. Las personas que conforman esta lista se conocen como **panel de consumidores**. A cambio de su participación, los miembros del panel pueden recibir incentivos como dinero en efectivo y muestras gratuitas de todos los productos sobre los cuales se les ha pedido su opinión en las encuestas. Un tipo especial de panel es el **panel de diario**. Los respondientes en un panel de este tipo deben llevar un registro detallado de su comportamiento. Por ejemplo, se les puede solicitar que lleven un registro de los productos que adquieran, de los cupones que utilicen o de las estaciones de radio que escuchen mientras van en el automóvil. También existen paneles especializados que sirven para monitorear segmentos del mercado, actitudes políticas u otras variables.

La investigación con encuestas puede emplear una amplia variedad de tipos de reactivos. Un enfoque para la redacción de los reactivos, que es particularmente popular en las encuestas aplicadas por escrito, se conoce como **técnica del diferencial semántico** (Osgood *et al.*, 1957). Esta técnica fue desarrollada originalmente como herramienta clínica para definir el significado de conceptos y de conceptos relacionados unos con otros en un “espacio semántico”, la técnica implica colocar de manera gráfica un par de adjetivos bipolares (como *bueno/malo* o *fuerte/débil*) en una escala de 7 puntos como la siguiente:

BUENO _____/_____/_____/_____/_____/_____/_____ MALO

A los entrevistados se les pide que coloquen una marca en esta serie continua de adjetivos calificativos en base a su juicio o calificación. En la investigación que incluye ciertas instancias para el consumidor, los adjetivos bipolares pueden ser reemplazados por expresiones descriptivas más consistentes con los objetivos propios de investigación. Por ejemplo, para clasificar un nuevo refresco de cola podría escribirse en uno de los extremos de la serie continua de clasificación la frase *sólo otro refresco de cola* y en el otro extremo podría escribirse *una bebida muy especial*.

Como con cualquier investigación, se debe tener cuidado al interpretar los resultados de una encuesta. Tanto la cantidad como la calidad de los datos pueden variar de una encuesta a otra. Las medidas o puntuaciones para calificar pueden ser diferentes, las preguntas ser planteadas en

formas distintas y los procedimientos de recolección de datos podrían variar de una encuesta a otra (Henry, 1984). De manera esencial, la utilidad de cualesquiera conclusiones depende de la integridad de los datos y de los procedimientos analíticos utilizados.

Habrán ocasiones en que las preguntas de investigación no puedan responderse mediante una encuesta o un sondeo de opinión. Es posible que los consumidores simplemente carezcan de la intuición para ser informantes precisos. Por ejemplo, consideremos el caso hipotético de José, quien fuma una marca hipotética de cigarrillos a la que llamaremos “Cowboy”. Cuando se le pregunta por qué eligió fumar esa marca de cigarrillos, José podría responder que “por el sabor”. Sin embargo, en realidad es posible que José haya comenzado a fumar esta marca porque la publicidad sobre ella hacía referencia a la imagen de José acerca de sí mismo como un tipo macho, independiente. No importa que en realidad José trabaje en una tienda de vestidos para novias y que tenga poca semejanza con la imagen del vaquero representado en la publicidad.

Es posible que los consumidores tampoco estén dispuestos o se muestren renuentes a responder las preguntas de la encuesta o del sondeo de opinión. Por ejemplo, supongamos que los fabricantes de los cigarrillos “Cowboy” quisieran saber en qué parte del empaque del producto deberá colocarse la advertencia de la Secretaría de Salud de modo que sea *menos* legible. ¿Cuántos consumidores estarían dispuestos a considerar una pregunta de este tipo? En efecto, ¿cuáles serían las posibles consecuencias para la imagen del producto hacer este tipo de preguntas? Puede verse que si esta compañía hipotética estuviera interesada en obtener una respuesta a esa pregunta, tendría que hacerlo por otros medios, como una investigación de motivación.

SÓLO PIENSE...

¿Cuál sería otro tipo de pregunta que los consumidores podrían no estar dispuestos o estarían renuentes a responder en una encuesta o estudio de opinión? ¿Qué medios podría utilizar un psicólogo del consumidor para obtener una respuesta a esta pregunta?

Métodos de investigación de la motivación

La *investigación de la motivación* en el campo de la psicología del consumidor y la mercadotecnia es llamada así porque de manera representativa implica el análisis de los motivos del comportamiento y actitudes del consumidor. Los **métodos de investigación de la motivación** incluyen entrevistas individuales y “focus groups”. Estos dos métodos de investigación cualitativa son utilizados para examinar a profundidad las reacciones de los consumidores que son representativos del grupo de personas que utilizan un producto o servicio particular. A diferencia de la investigación cuantitativa, que por lo común implica grandes números de sujetos y elaborados análisis estadísticos, la investigación cualitativa de modo característico incluye pocos respondientes y poco o ningún análisis estadístico. El énfasis en el último tipo de investigación no está en la cantidad (de sujetos o de datos) sino en las cualidades de cualquier cosa que se estudia. A menudo, la investigación cualitativa proporciona datos a partir de los cuales se desarrollan hipótesis que pueden ser probadas con un mayor número de consumidores. La investigación cualitativa también tiene valor diagnóstico. La mejor manera de obtener información sumamente detallada sobre lo que agrada o desagrada a un consumidor acerca de un producto, una tienda o una campaña publicitaria es mediante la investigación cualitativa.

Un *focus group* es un grupo de entrevista guiado por un moderador entrenado e independiente que, de manera ejemplar, tiene un conocimiento de las técnicas de facilitación de la discusión y dinámicas de grupo.³ Como su nombre lo implica, los *grupos de enfoque* o *focus group* están diseñados para *enfocar* la discusión del grupo sobre algo, como un comercial particular,

3. Los moderadores de los grupos de enfoque varían enormemente en cuanto a su entrenamiento y experiencia. De manera ideal, un moderador de un grupo central debería ser independiente, de modo que pueda analizar de forma desapasionada los temas con cierta distancia y perspectiva. Contrastando con esta recomendación, algunas agencias de publicidad conservan un grupo de moderadores formado por personal interno para examinar la publicidad producida por la agencia. Los críticos de esta práctica la han comparado con asignar a los lobos el cuidado de un gallinero.

un concepto para un nuevo producto o el cambio de empaque de un producto. Los grupos de enfoque han examinado de todo, desde la opción de comprar cosechas orgánicas en lugar de las cultivadas por medios convencionales (Hammit, 1990), hasta los asuntos acerca de la compra de condones por los estudiantes universitarios (Mays *et al.*, 1993).

Los *focus groups* generalmente consisten en 6 a 12 participantes que pueden haber sido reclutados en los pasillos de un centro comercial o seleccionados de antemano para satisfacer ciertas características predeterminadas de participación. El objetivo común en este caso es que los miembros del grupo representen de alguna manera a la población seleccionada de consumidores del producto o servicio. Así, por ejemplo, se podría solicitar la participación únicamente de bebedores de cerveza (definidos, por ejemplo, como hombres que beben cuando menos dos paquetes de seis cervezas por semana y mujeres que beben cuando menos un paquete de seis cervezas por semana) para un *focus group* diseñado para explorar los atributos de una nueva marca de cervezas —incluyendo variables como el sabor, el empaque y la publicidad—. Otro atributo de la cerveza que no conoce la mayoría de los consumidores es lo que se conoce dentro del ramo como pedido a la barra, una referencia a la facilidad con la que se puede ordenar la bebida en un bar. Debido a los altos costos asociados con la introducción de un nuevo producto y la publicidad de un producto nuevo o establecido, los grupos de enfoque conducidos de manera profesional, a los que se añade un muestreo representativo de la población consumidora seleccionada, son una herramienta valiosa en la investigación de mercado.

Dependiendo de los requerimientos del cliente del moderador (un publicista, un fabricante, etcétera), la discusión de grupo puede ser relativamente estructurada (con varios temas a cubrir) o relativamente desestructurada (con pocos temas a cubrir de manera exhaustiva). Después de establecer el rapport con el grupo, el moderador puede, por ejemplo, mostrar cierta publicidad o un producto al grupo y después hacer una pregunta general (como “¿Qué piensan del comercial de cerveza?”) seguido por formas más específicas de preguntas (como “¿Las personas que aparecen en el comercial son el tipo de gente con la que usted se reuniría a tomar cerveza?”). Las respuestas de los miembros del grupo pueden basarse sobre las de los otros miembros y el resultado de esta discusión que fluye libremente puede aportar nueva información, nuevas perspectivas o algunos otros problemas que se hayan pasado por alto anteriormente respecto a la publicidad o al producto.

Es característico que las reuniones de los *focus groups* duren de una a dos horas y en general se realizan en habitaciones (ya sea salas de conferencia o salones) equipados con espejos de una vista (detrás de los cuales el personal del cliente puede observar el procedimiento) y equipo de audio o video para conservar un registro de la sesión del grupo. Aparte de ser un escucha activo y un individuo cuidadoso de no sugerir o inducir respuestas a las preguntas o de extraer conclusiones de los entrevistados, los deberes del moderador incluyen 1) seguir una guía de discusión (generalmente creada por el moderador consultando con el cliente) y mantener la discusión sobre el tema; 2) atraer la participación de los miembros silenciosos del grupo de modo que todos opinen; 3) limitar el tiempo de respuesta de los miembros del grupo que podrían dominar la discusión; y 4) redactar un informe que no sólo proporcione un resumen de la discusión del grupo sino que también ofrezca percepciones psicológicas o de mercadotecnia para el cliente.

En los *focus groups* se puede emplear tecnología de modo que sea factible monitorear la reacción segundo a segundo a estímulos materiales, como los comerciales. Cohen describió las ventajas (1985) y limitaciones (1987) de una técnica por medio de la cual los respondientes veían comerciales de televisión y oprimían botones de numeración en un teclado, parecido al de una calculadora, para indicar qué tan positiva o negativa era su sensación a cada momento mientras veían la televisión. Posteriormente se podría mostrar visualmente la respuesta ejemplificada en una gráfica y reproducirse nuevamente para ser analizada por el respondiente, a quien se le preguntaban las razones de la respuesta espontánea.

Los *focus groups* se utilizan ampliamente en la investigación de consumo para

- generar hipótesis que puedan ser examinadas posteriormente de manera cuantitativa
- generar información para diseñar o modificar cuestionarios para consumidores
- proporcionar información general antecedente sobre una categoría de producto

- proporcionar impresiones de los conceptos de un nuevo producto del que existe poca información disponible
- obtener nuevas ideas acerca de productos antiguos
- generar ideas para el desarrollo de un producto o nombres para productos existentes
- interpretar las conclusiones de los resultados cuantitativos obtenidos con anterioridad

En general, el *focus group* es una técnica sumamente útil para la investigación exploratoria y que puede ser un valioso trampolín para estudios cuantitativos de mayor alcance. Debido a que el número de entrevistados que participan en estos grupos es característicamente pequeño, los resultados obtenidos por ellos no se pueden considerar de manera automática como representativos de la población general. Sin embargo, muchos clientes (incluyendo al personal creativo de las agencias de publicidad) han recibido inspiración de las palabras expresadas por los consumidores comunes que están al otro lado del espejo.

El *focus group*, ampliamente utilizado en la investigación sobre el consumidor, es una herramienta de investigación cualitativa que emplean los investigadores con varios objetivos. Estos grupos se han utilizado para explorar temas como las percepciones de los adolescentes acerca de las imágenes asociadas con el tabaquismo en las películas (McCool *et al.*, 2001), fuentes de tensión entre el personal de salud (Ducharme *et al.*, 2001), dilemas éticos entre estudiantes de medicina (Hicks *et al.*, 2001), influencias sobre el consumo de carne (Lea y Worsley, 2001), comportamiento relacionado con la higiene femenina (Lichtenstein y Nansel, 2000), productos reforzadores para la lucha contra la dependencia química (McMillen *et al.*, 2001) y las necesidades de las personas que están en riesgo de suicidio (Pullen y Gow, 2000). Los principales desarrolladores de pruebas emplean grupos de enfoque que incluyen usuarios de pruebas como parte del desarrollo y el proceso de revisión de las mismas.

Los *focus group* proporcionan un foro para la exploración abierta de los pensamientos, lo cual idealmente estimula el diálogo y la discusión entre los participantes. Aunque la naturaleza franca de la experiencia es una fortaleza, la falta de cualquier estructura sistemática para explorar la motivación humana no lo es. No existen dos moderadores de grupos de enfoque, encargados de responder las mismas preguntas, que puedan abordar la tarea de la misma manera. Para atender este problema, Cohen (1999) propuso un enfoque *dimensional* para la investigación cualitativa. Este enfoque intenta aplicar las modalidades o dimensiones psicológicas superpuestas que han resultado tan importantes para el clínico Arnold Lazarus (1973, 1989) en sus esfuerzos diagnósticos y terapéuticos multimodales (Lazarus, 1973, 1989) para los objetivos no clínicos en la investigación cualitativa. De manera específica, la **investigación cualitativa dimensional** es un enfoque de investigación cualitativa que busca garantizar que un estudio sea amplio y sistemático desde una perspectiva psicológica, al guiar el diseño del estudio y las preguntas propuestas para la discusión en base a las dimensiones del ID BÁSICO* BASIC ID es el acrónimo de las dimensiones clave en el enfoque de Lazarus para el diagnóstico y la intervención. Las letras son las iniciales de *behavior, affect, sensation, imagery, cognition, interpersonal relations* y *drugs* (comportamiento, afecto, sensación, imágenes, cognición, relaciones interpersonales y drogas). La adaptación de Cohen para el trabajo de Lazarus añade una octava dimensión, la sociocultural, con lo cual se agrega una *s* al acrónimo y lo modifica a la forma plural (BASIC IDS - ID BÁSICOS). Reflexionando sobre su enfoque, Cohen escribió:

Las dimensiones del ID Básico pueden proporcionar una estructura uniforme, y sistemática, para la exploración e intervención, siendo aún lo bastante flexible como para permitir la implementación de nuevas técnicas e innovaciones. Apoyado en la lógica, es un enfoque que es accesible para quienes no son psicólogos y que buscan adquirir más conocimientos sobre las maneras en que la

SÓLO PIENSE...

¿Para qué tipos de preguntas de investigación no sería aconsejable un *focus group*?

* Que puede traducirse como “identificación básica”, para darle un sentido en español al término, de acuerdo con la intención del arreglo del acrónimo establecido en inglés por el autor.

psicología se puede aplicar en los contextos de la mercadotecnia... Sin importar la estructura específica adoptada por un investigador, parece ser un momento importante para reconocer que todos estamos sintiendo, percibiendo, actuando, imaginando, pensando, relacionándonos socialmente y que somos seres bioquímicos producto de nuestra cultura. Una vez que se reconozca esto, y nos esforcemos por explicar de manera rutinaria y sistemática estas variables dentro de la investigación de la mercadotecnia, podemos comenzar a apreciar el valor agregado que aportan los psicólogos a la investigación cualitativa de los consumidores en el contexto de la mercadotecnia (1999, p. 365).

Observación conductual En octubre de 1982, las ventas de analgésicos como la aspirina, Bufferin, Anacin y Excedrin se elevaron de manera notable. ¿Este incremento en las ventas se debió a la efectividad de las campañas publicitarias para estos productos? No. Las ventas se elevaron de manera aguda en 1982 cuando se supo que siete personas habían muerto después de ingerir cápsulas de Tylenol rociadas con cianuro. A medida que Tylenol, el analgésico con mayor participación en el mercado, fue retirado de los anaqueles en todas las tiendas de Estados Unidos, hubo un aumento correspondiente en las ventas de los medicamentos alternativos. Un fenómeno similar ocurrió en 1986.

Imagine qué habría pasado si los investigadores de mercado hubiesen basado sus juicios acerca de la efectividad de una campaña publicitaria de un analgésico que se vende sin receta únicamente en las cifras de venta durante el periodo de la crisis del Tylenol. Sin duda los datos habrían conducido fácilmente a errores de interpretación sobre lo que realmente había ocurrido. ¿Cómo podrían haber añadido los investigadores de mercado un componente de control de calidad a sus métodos de investigación? Una manera consiste en utilizar métodos múltiples, como la observación conductual además de los métodos de encuesta.

SÓLO PIENSE...

Desde su propia experiencia informal, ¿qué otro tipo de compras es probable estén guiadas más por los comentarios de los niños que por los de los adultos? ¿Cuál sería la mejor manera en que los psicólogos del consumidor pudieran probar sus creencias respecto a esta decisión de compra?

No es común que los investigadores de mercado coloquen observadores conductuales en las tiendas para monitorear lo que realmente impulsa a un consumidor a comprar éste u otro producto en el punto de elección. Ese observador en una tienda que vendiera analgésicos en octubre de 1982 podría haber observado, por ejemplo, una conversación con el dependiente acerca de la mejor alternativa para sustituir el Tylenol. Los observadores conductuales en un supermercado que estudiaron los hábitos de compra de las personas que adquirirían cereal para el desayuno concluyeron que los niños que acompañaban al comprador pedían o demandaban una marca específica de cereal (Atkin, 1978). Por tanto, sería adecuado que los fabricantes de cereal enfocaran su publicidad a los niños y no al consumidor adulto.

Otros métodos Otros métodos y herramientas pueden servir para responder las preguntas de mercadotecnia y publicidad. En ocasiones, los psicólogos del consumidor emplean pruebas proyectivas —existentes al igual que diseñadas para un uso específico— como un auxiliar para responder a las preguntas hechas por los clientes. Se ha utilizado instrumentación especial, incluyendo taquistoscopios y electroencefalógrafos, como parte de los esfuerzos para descubrir la motivación del consumidor. Se pueden utilizar programas especiales de cómputo para derivar nombres comerciales para nuevos productos. Así, por ejemplo, cuando Honda quiso posicionar una nueva línea de vehículos como “automóviles de precisión avanzada”, una empresa especializada en la denominación de nuevos productos realizó una búsqueda por computadora de más de 6900 morfemas en el idioma inglés para localizar las palabras raíz que significaran o implicaran “precisión avanzada”. Después, los morfemas aplicables se combinaron por computadora en todas las posibles formas permitidas por las reglas fonéticas del inglés. De la lista resultante, se seleccionó entonces la mejor palabra (es decir, la que se destacara entre otras palabras impresas, que fuera reconocible como un nombre comercial y demás). En este caso, la palabra fue *Acura* (Brewer, 1987).

Las reseñas de la literatura son otro método disponible para los psicólogos del consumidor. Por ejemplo, una reseña de la literatura podría sugerir que ciertos sonidos o imágenes en una marca particular tienden a ser más populares entre los consumidores que otros sonidos o imágenes

REACHES ALL
—Cleans All

PRO-PHY-LAC-TIC protects every tooth in your mouth

When you have found a tooth brush that reaches *all* your teeth, you have taken the most important step in keeping your teeth permanently sound and beautiful.

Study the picture of the Pro-phy-lac-tic Tooth Brush, shown here. Notice how the bristles are arranged. See how they form a curve ending in a large pyramidal tuft. You can see that this curve is sensibly shaped to fit snugly against the outside and inside profiles of *all* your teeth. The molars in the rear, so hard to get at with an ordinary tooth brush, are easily reached by this convenient end tuft.

The bent handle is the third feature which makes it easy to reach *all* thirty-two of your teeth. Nature aligned most of your teeth on a curve. It naturally follows that a curved handle accommodates itself to this formation more easily and more comfortably than a handle that is straight.

Sold in three sizes by all dealers in the United States, Canada, and all over the world. Prices in the United States and Canada are: Pro-phy-lac-tic Adult, 50c; Pro-phy-lac-tic Small, 40c; Pro-phy-lac-tic Baby, 25c. Made in three different bristle textures—hard, medium, and soft—and with white handles or colored transparent handles—red, green, or orange. **Always sold in the yellow box.** (A larger Pro-phy-lac-tic with four rows of bristles is priced 60 cents.) Pro-phy-lac-tic Brush Company, Florence, Massachusetts.

Are you sure you don't need a new tooth brush?
 A Pro-phy-lac-tic Tooth Brush is made so well that it doesn't look worn out even when it should be replaced with a new one. The handle and even the bristles appear as good as ever. But the best bristle will after continued use lose its springiness and elasticity. Pro-phy-lac-tic bristles are the best that Nature provides, but three or four months of steady twice-daily use will take away their liveliness. Don't try to wear out your Pro-phy-lac-tic Tooth Brush. Get a new one every three months. Keep several on hand. To prevent a Pro-phy-lac-tic in a yellow box to an overnight

FREE... an interesting booklet containing valuable information.

Pro-phy-lac-tic Brush Company,
 Dept. 210, Florence, Mass.
 Please send me your instructive booklet on the care and preservation of the tooth.
 Name.....
 Address.....
 City..... State.....

© 1927, P. B. Co.

Figura 16-7
¿Qué hay en un nombre?

“¿Qué hay en un nombre? Una rosa con otro nombre tendría un olor tan dulce.” Sentimientos como éste pueden ser conmovedores cuando se les lee y hermosos cuando son expresados por actores talentosos en Broadway. Sin embargo, no habrían llevado muy lejos a William Shakespeare en la avenida Madison. El nombre dado a un producto es una parte importante que se conoce como la “mezcla de mercadeo”: la manera en que se posiciona, comercializa y promueve en el mercado. El anuncio mostrado aquí, reproducido de una revista de 1927, anuncia los beneficios de un cepillo dental con el nombre de Pro-phy-lac-tic. Sin duda, el creador de este nombre comercial deseaba posicionar el cepillo dental como particularmente útil para prevenir enfermedades. Sin embargo, en la mente del público, la palabra profiláctico (definido como “protector”) llegó a identificarse más con los condones, un hecho que no habría ayudado a la longevidad de esta marca de cepillos de dientes en el mercado. Actualmente, los investigadores utilizan una variedad de métodos, incluyendo la asociación de palabras, para crear nuevos nombres comerciales.

(figura 16-7). Schloss (1981) observó que el sonido de la letra K estaba mejor representado con una probabilidad seis veces mayor de lo que podría esperarse en estudios hechos al azar en los 200 productos de las marcas principales (como Sanka, Quaker, Nabisco y, podríamos añadir, Acura). Schloss continuó y especuló acerca de la capacidad de éste, así como otros sonidos de palabras, para evocar reacciones emocionales en lugar de racionales.

Y hablando de evocar reacciones, somos nosotros, Ron Cohen y Mark Swerdlink, quienes debemos hacer una pausa para *considerar y preguntarnos* algo importante: ¿Qué reacciones evocaremos en usted cuando se percate de que ha llegado al final de nuestro texto? Su reacción podría ir desde *pena extrema* (querría que hubiera más páginas que leer) hasta *éxtasis incontrolable* (¡Llegó la hora de divertirme!). Sin importar cuál sea, deseamos que sepa que consideramos un honor y un privilegio haber ayudado a introducirlo al mundo de la medición en psicología y educación. Le enviamos nuestros mejores deseos de éxito en su desarrollo académico y profesional. ¿Y quién sabe? Quizá sea a usted y a su trabajo a quienes presentemos para los estudiantes en el futuro dentro de una edición subsecuente de *Pruebas y evaluación psicológicas*.

Autoevaluación

Examine su comprensión de los elementos de este capítulo tratando de explicar cada uno de los siguientes términos, expresiones y abreviaturas:

actitud	evaluación previa a la contratación	prueba física
agotamiento	falso negativo	pruebas de capacidad y aptitud
centro de evaluación	falso positivo	pruebas de intereses
clasificación	GATB	psicología del consumidor
colocación	grupo de enfoque	satisfacción en el trabajo
compromiso organizacional	investigación cualitativa dimensional	seis grandes
cultura organizacional	MBTI	selección
detección	métodos de investigación en la	SII
encuesta	motivación	sondeo de opinión
equipo	motivación extrínseca	técnica de distribución forzada
establecer una norma de acuerdo con la raza	motivación intrínseca	técnica de incidentes críticos
evaluación de la personalidad y del lugar de trabajo	panel de consumidores	técnica de la bandeja de entrada
evaluación de portafolios	panel diario	técnica del diferencial semántico
evaluación para orientación vocacional	productividad	técnica del grupo sin líder
	prueba de consumo de drogas	tres grandes
	prueba de desempeño	
	prueba de integridad	

Un vistazo a la red

Consulte los siguientes sitios en la red para mayor información sobre los temas analizados en el capítulo.

Inventario de intereses de Strong
www.ccp.com/products/strong/index.asp
www.discoveryourpersonality.com/Strong.html

Batería de pruebas de aptitudes generales
157.182.15.43/courses/620/units/unit%202/620GATB.htm

Prueba O'Connor de destreza con pinzas
www.brandymd.com/hair_restoration_assistants.cfm

Prueba Minnesota de tareas administrativas
www.behavioraldynamicsphil.com/ped052.htm

Evaluación vocacional (general)

www.yorku.ca/psycentr/test/voc.html

Agotamiento

www.aafp.org/fpm/970400fm/lead.html

www.cpp.com/detail/detailprod.asp?pc=35

www.carrer-lifeskills.com/products_services/atpr/corpcultdev/ccp-34500.htm

Técnica del diferencial semántico

www.cultsock.ndirect.co.uk/MUHome/cshtml/introductory/semdif.html

Psicología del consumidor

<http://fisher.osu.edu/marketing/scp>

www.consumerpsychologist.com

www.wcupa.edu/_ACADEMICS/sch_cas.psy/Career_Paths/Consumer/Career05.htm

Resúmenes de artículos actuales publicados en *Psychology & Marketing*

www.wiley.com/WileyCDA/WileyTitle/productCd-MAR.html

Referencias

- Abel, G. G., Rouleau, J., & Cunningham-Rathner, J. (1986). Sexually aggressive behavior. En W. J. Curran, A. L. McGarry, & S. Shah (eds.), *Forensic psychiatry and psychology: Perspectives and standards for interdisciplinary practice* (pp. 289-314). Philadelphia: Davis.
- Abeles, N., & Barlev, A. (1999). End of life decisions and assisted suicide. *Professional Psychology: Research and Practice*, 30, 229-234.
- Abidin, R. R. (1990). *Parenting stress index* (3rd ed.). Odessa, FL: Psychological Assessment Resources.
- Abrams, D. B., Binkoff, J. A., Zwick, W. R., et al. (1991). Alcohol abusers' and social drinkers' responses to alcohol-relevant and general situations. *Journal of Studies on Alcohol*, 52, 409-414.
- Abrams, S. (1977). *A polygraph handbook for attorneys*. Lexington, MA: Heath.
- Achenbach, T. M. (1978). *Child Behavior Profile*. Bethesda, MD: Laboratory of Developmental Psychology, National Institutes of Mental Health.
- Achenbach, T. M. (1981). A junior MMPI? *Journal of Personality Assessment*, 45, 332-333.
- Achenbach, T. M. (1993). Implications of Multiaxial Empirically Based Assessment for behavior therapy with children. *Behavior Therapy*, 24, 91-116.
- Achenbach, T. M., McConaughy, S. H., & Howell, C. T. (1987). Child/adolescent behavioral and emotional problems: Implications of cross-informant correlations for situational specificity. *Psychological Bulletin*, 101, 213-232.
- Ackerman, M. J. (1995). *Clinician's guide to child custody evaluations*. New York: Wiley-Interscience.
- Ackerman, P. L., & Heggstad, E. D. (1997). Intelligence, personality, and interests: Evidence for overlapping traits. *Psychological Bulletin*, 121, 219-245.
- Ackerman, P. L., & Kanfer, R. (1993). Integrating laboratory and field study for improving selection: Development of a battery for predicting air traffic controller success. *Journal of Applied Psychology*, 78, 413-432.
- Acklin, M. W. (1995). Avoiding Rorschach dichotomies: Integrating Rorschach interpretation. *Journal of Personality Assessment*, 64, 235-238.
- Acklin, M. W. (1996). Personality assessment and managed care. *Journal of Personality Assessment*, 66, 194-201.
- Acklin, M. W. (1997). Swimming with sharks. *Journal of Personality Assessment*, 69, 448-451.
- Adams, K. M. (1984). Luria left in the lurch: Unfulfilled promises are not valid tests. *Journal of Clinical Neuropsychology*, 6, 455-458.
- Adams, K. M. (2000). Practical and ethical issues pertaining to test revisions. *Psychological Assessment*, 12, 281-286.
- Adams-Tucker, C. (1982). Proximate effects of sexual abuse in childhood: A report on 28 children. *American Journal of Psychiatry*, 139, 1252-1256.
- Addeo, R. R., Greene, A. F., & Geisser, M. E. (1994). Construct validity of the Robson Self-Esteem Questionnaire in a sample of college students. *Educational and Psychological Measurement*, 54, 439-446.
- Adelman, S. A., Fletcher, K. E., Bahnassi, A., & Munetz, M. R. (1991). The Scale for Treatment Integration of the Dually Diagnosed (STIDD): An instrument for assessing intervention strategies in the pharmacotherapy of mentally ill substance abusers. *Drug and Alcohol Dependence*, 27, 35-42.
- Adler, A. (1927/1965). *Understanding human nature*. Greenwich, CT: Fawcett.
- Adler, A. (1933/1964). *Social interest: A challenge to mankind*. New York: Capricorn.
- Adler, T. (1990). Does the "new" MMPI beat the "classic"? *APA Monitor*, 20, (4), 18-19.
- Administration on Aging. (1999). *Profile of older Americans*. Washington, DC: Author.
- Ahern, E. (1949). *Handbook of personnel forms and records*. New York: American Management Association.
- Aikman, K. G., Belter, R. W., & Finch, A. J. (1992). Human figure drawings: Validity in assessing intellectual level and academic achievement. *Journal of Clinical Psychology*, 48, 114-120.
- Airasian, P. W., Madaus, G. F., & Pedulla, J. J. (1979). *Minimal competency testing*. Englewood Cliffs, NJ: Educational Technology Publications.
- Akamatsu, C. T. (1993-1994). The view from within and without: Conducting research on deaf Asian-Americans. *Journal of the American Deafness and Rehabilitation Association*, 27, 12-16.
- Alderfer, C. (1972). *Existence, relatedness and growth: Human needs in organizational settings*. New York: Free Press.
- Alderson, J. C., Krahne, K. J., & Stansfield, C. W. (1987). *Reviews of English language proficiency tests*. Washington, DC: TESOL.
- Alessandri, S. M., Bendersky, M., & Lewis, M. (1998). Cognitive functioning in 8- to 18-month-old drug-exposed infants. *Developmental Psychology*, 34, 565-573.
- Alexander, R. C., Surrell, J. A., & Cohle, S. D. (1987). Microwave oven burns in children: An unusual manifestation of child abuse. *Pediatrics*, 79, 255-260.
- Allen, J. (2002). Assessment training for practice in American Indian and Alaska native settings. *Journal of Personality Assessment*, 79, 216-225.
- Allen, M. J., & Yen, W. M. (1979). *Introduction to measurement theory*. Monterey, CA: Brooks/Cole.
- Allen, N. J., & Meyer, J. P. (1990). The measurement and antecedents of affective, continuance, and normative commitment to the organization. *Journal of Occupational Psychology*, 63, 1-18.
- Allen, R., Wasserman, G. A., & Seidman, S. (1990). Children with congenital anomalies: The preschool period. *Journal of Pediatric Psychology*, 15, 327-345.
- Allen, T. E. (1994). *Who are the deaf and hard-of-hearing students leaving high school and entering postsecondary education?* (pp. 1-16). U.S. Office of Special Education and Rehabilitative Services: Pelavin Research Institute.
- Allport, G. W. (1937). *Personality: A psychological interpretation*. New York: Holt.
- Allport, G. W., & Odbert, H. S. (1936). Trait-names: A psycho-lexical study. *Psychological Monographs*, 47 (Whole No. 211).
- Allport, G. W., Vernon, P. E., & Lindzey, G. (1951). *Study of values* (rev. ed.). Boston: Houghton Mifflin.
- Allred, L. J., & Harris, W. G. (1984). *The nonequivalence of computerized and conventional administrations of the Adjective Checklist*. Unpublished manuscript, Johns Hopkins University, Baltimore.

- Alpher, V. S., & Blanton, R. L. (1985). The accuracy of lie detection: Why lie tests based on the polygraph should not be admitted into evidence today. *Law & Psychology Review*, 9, 67-75.
- Alterman, A. I., McDermott, P. A., Cook, T. G., et al. (2000). Generalizability of the clinical dimensions of the Addiction Severity Index to nonopioid-dependent patients. *Psychology of Addictive Behaviors*, 14, 287-294.
- Amabile, T. M., Hill, K. G., Hennessey, B. A., & Tighe, E. M. (1994). The Work Preference Inventory: Assessing intrinsic and extrinsic motivational orientations. *Journal of Personality and Social Psychology*, 66, 950-967.
- Amada, G. (1996). You can't please all of the people all of the time: Normative institutional resistances to college psychological services. *Journal of College Student Psychotherapy*, 10, 45-63.
- Aman, C. J., Roberts, R. J., & Pennington, B. F. (1998). A neuropsychological examination of the underlying deficit in attention deficit hyperactivity disorder: Frontal lobe versus right parietal lobe theories. *Developmental Psychology*, 34, 956-969.
- Ambrosini, P. J., Metz, C., Bianchi, M. D., Rabinovich, H., & Undie, A. (1991). Concurrent validity and psychometric properties of the Beck Depression Inventory in outpatient adolescents. *Journal of the American Academy of Child and Adolescent Psychiatry*, 30, 51-57.
- American Association on Mental Retardation. (1992). *Mental retardation: Definition, classification, and systems of supports* (9th ed.). Washington, DC: Author.
- American Board of Forensic Odontology, Inc. (1986). Guidelines for analysis of bite marks in forensic investigation. *Journal of the American Dental Association*, 12, 383-386.
- American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (1999). *Standards for educational and psychological testing*. Washington, DC: Author.
- American Law Institute. (1956). *Model penal code*. Tentative Draft Number 4.
- American Psychiatric Association. (1968). *Diagnostic and statistical manual of mental disorders* (2nd ed.). Washington, DC: Author.
- American Psychiatric Association. (1980). *Diagnostic and statistical manual of mental disorders* (3rd ed.). Washington, DC: Author.
- American Psychiatric Association. (1987). *Diagnostic and statistical manual of mental disorders* (3rd ed., rev.). Washington, DC: Author.
- American Psychiatric Association. (1994). *Diagnostic and statistical manual of mental disorders* (4th ed.). Washington, DC: Author.
- American Psychiatric Association. (2000). *Diagnostic and statistical manual of mental disorders* (4th ed.; text rev.). Washington, DC: Author.
- American Psychiatric Association. (2001). *Diagnostic and statistical manual of mental disorders* (4th ed.; text rev.). [CD-ROM (Windows)]. Washington, DC: Author.
- American Psychological Association. (1953). *Ethical standards of psychologists*. Washington, DC: Author.
- American Psychological Association. (1954). *Technical recommendations for psychological tests and diagnostic techniques*. Washington, DC: Author.
- American Psychological Association. (1967). *Casebook on ethical standards of psychologists*. Washington, DC: Author.
- American Psychological Association. (1981). Ethical principles of psychologists. *American Psychologist*, 36, 633-638.
- American Psychological Association. (1985). *Standards for educational and psychological testing*. Washington, DC: Author.
- American Psychological Association. (1987). *Casebook on ethical principles of psychologists*. Washington, DC: Author.
- American Psychological Association. (1991). *Questionnaires used in the prediction of trustworthiness in pre-employment selection decisions: An APA Task Force report*. Washington, DC: Author.
- American Psychological Association. (1992). Ethical principles of psychologists and code of conduct. *American Psychologist*, 47, 1597-1611.
- American Psychological Association. (1993, January). Call for book proposals for test instruments. *APA Monitor*, 24, 12.
- American Psychological Association. (1996). *Standards for psychological tests*. Washington, DC: Author.
- American Psychological Association, Committee on Professional Practice and Standards. (1994a). Guidelines for child custody evaluations in divorce proceedings. *American Psychologist*, 49, 677-680.
- American Psychological Association. (1994b). C. H. Lawshe. *American Psychologist*, 49, 549-551.
- American Psychological Association. (1995). *Finding information about psychological tests*. Washington, DC: Author.
- American Psychological Association. (1996). *Affirmative action: Who benefits?* Washington, DC: Author.
- American Psychological Association. (2002). Ethical principles of psychologists and code of conduct. *American Psychologist*, 57, 1060-1073.
- American Psychological Association. (2003). Guidelines on multicultural education, training, research, practice, organizational change for psychologists. *American Psychologist*, 58, 377-402.
- Ames, S. L., & Stacy, A. W. (1998). Implicit cognition in the prediction of substance use among drug offenders. *Psychology of Addictive Behaviors*, 12, 272-281.
- Amrine, M. (ed.). (1965). Special issue. *American Psychologist*, 20, 857-991.
- Anderson, G., & Grace, C. (1991). The Black deaf adolescent: A diverse and underserved population. *Volta Review*, 93, 73-86.
- Anderson, J. W. (1990). The life of Henry A. Murray: 1893-1988. En A. I. Rabin, R. A. Zucker, R. A. Emmons, & S. Frank (eds.), *Studying persons and lives* (pp. 304-333). New York: Springer.
- Anderson, W. P. (1995). Ethnic and cross-cultural differences on the MMPI-2. En J. C. Duckworth & W. P. Anderson (eds.), *MMPI and MMPI-2: Interpretation manual for counselors and clinicians* (4th ed.; pp. 439-460). Bristol, PA: Accelerated Development.
- Andrew, G., Hartwell, S. W., Hutt, M. L., & Walton, R. E. (1953). *The Michigan Picture Test*. Chicago: Science Research Associates.
- Angoff, W. H. (1962). Scales with nonmeaningful origins and units of measurement. *Educational and Psychological Measurement*, 22, 27-34.
- Angoff, W. H. (1964). Technical problems of obtaining equivalent scores on tests. *Educational and Psychological Measurement*, 1, 11-13.
- Angoff, W. H. (1966). Can useful general-purpose equivalency tables be prepared for different college admissions tests? In A. Anastasi (ed.), *Testing problems in perspective* (pp. 251-264). Washington, DC: American Council on Education.
- Angoff, W. H. (1971). Scales, norms, and equivalent scores. En R. L. Thorndike (ed.), *Educational measurement* (2nd ed.). Washington, DC: American Council on Education.
- Appelbaum, P., & Grisso, T. (1995a). The MacArthur Treatment Competence Study: I. Mental illness and competence to consent to treatment. *Law and Human Behavior*, 19, 105-126.
- Appelbaum, P., & Grisso, T. (1995b). The MacArthur Treatment Competence Study: III. Abilities of patients to consent to psychiatric and medical treatments. *Law and Human Behavior*, 19, 149-174.

- Arbisi, P. A., Ben-Porath, Y. S., & McNulty, J. (2002). A comparison of MMPI-2 validity in African American and Caucasian psychiatric inpatients. *Psychological Assessment*, 14, 3-15.
- Arnau, R. C., Green, B. A., Rosen, D. H., et al. (2003). Are Jungian preferences really categorical? *Personality & Individual Differences*, 34, 233-251.
- Arnett, P. A., Rao, S. M., Grafman, J., et al. (1997). Executive functions in multiple sclerosis: An analysis of temporal ordering, semantic encoding, and planning abilities. *Neuropsychology*, 11, 535-544.
- Arnold, D. S., O'Leary, S. G., Wolff, L. S., & Acker, M. M. (1993). The Parenting Scale: A measure of dysfunctional parenting in discipline situations. *Psychological Assessment*, 5, 137-144.
- Aronow, E., & Reznikoff, M. (1976). Rorschach content interpretation. Orlando, FL: Grune & Stratton.
- Aronow, E., & Reznikoff, M. (1983). *A Rorschach introduction: Content and perceptual approaches*. Orlando, FL: Grune & Stratton.
- Aronow, E., Reznikoff, M., & Moreland, K. L. (1995). The Rorschach: Projective technique or psychometric test? *Journal of Personality Assessment*, 64, 213-228.
- Arvey, R. D. (1979). *Fairness in selecting employees*. Reading, MA: Addison-Wesley.
- Arvey, R. D., Bouchard, T. J., Segal, N. L., & Abraham, L. M. (1989). Job satisfaction: Environmental and genetic components. *Journal of Applied Psychology*, 74, 187-192.
- Asch, S. E. (1951). Effects of group pressure upon the modification and distortion of judgment. In H. Guetzkow (ed.), *Groups, leadership, and men*. Pittsburgh, PA: Carnegie.
- Asch, S. E. (1955). Opinions and social pressure. *Scientific American*, 193, 33-35.
- Asch, S. E. (1957a). Studies of independence and conformity. A minority of one against a unanimous majority. *Psychological Monographs*, 70 (9, Whole No. 416).
- Asch, S. E. (1957b). An experimental investigation of group influence. In Walter Reed Army Institute of Research (ed.), *Symposium on preventive and social psychiatry*. Washington, DC: U.S. Government Printing Office.
- Association of Personnel Test Publishers (APTP). (1990). Model guidelines for preemployment integrity testing programs. Washington, DC: APTP.
- ASVAB 18/19 Counselor Manual: The ASVAB career exploration program. (1995). Washington, DC: U.S. Department of Defense.
- Atkin, C. K. (1978). Observation of parent-child interaction in supermarket decision making. *Journal of Marketing*, 42, 41-45.
- Atkinson, J. W. (1981). Studying personality in the context of an advanced motivational psychology. *American Psychologist*, 36, 117-128.
- Atkinson, R. C., & Shiffrin, R. M. (1968). A proposed system and its control processes. In K. W. Spence & J. T. Spence (eds.), *The psychology of learning and motivation: Advances in research and theory* (Vol. 2; pp. 82-90). Oxford: Oxford University Press.
- Aycan, Z., Kanungo, R. N., Mendonca, M., et al. (2000). Impact of culture on human resource management practices: A 10-country comparison. *Applied Psychology: An International Review*, 49, 192-221.
- Ayres, R. R., & Cooley, E. J. (1986). Sequential versus simultaneous processing on the K-ABC: Validity in predicting learning success. *Journal of Psychoeducational Assessment*, 4, 211-220.
- Baker, E. L., O'Neill, H. F., & Linn, R. L. (1993). Policy and validity prospects for performance-based assessment. *American Psychologist*, 48, 1210-1218.
- Baldwin, A. L., Kalhorn, J., & Breese, F. H. (1945). Patterns of parent behavior. *Psychological Monographs*, 58 (Whole No. 268).
- Baldwin, J. A. (1984). African self-consciousness and the mental health of African-Americans. *Journal of Black Studies*, 15, 177-194.
- Baldwin, J. A., & Bell, Y. R. (1985). The African Self-Consciousness Scale: An Africentric personality questionnaire. *Western Journal of Black Studies*, 9(2), 65-68.
- Ball, J. D., Archer, R. P., Gordon, R. A., & French, J. (1991). Rorschach depression indices with children and adolescents: Concurrent validity findings. *Journal of Personality Assessment*, 57, 465-476.
- Ball, T. S., & Bernardoni, L. C. (1953). The application of an auditory apperception test to clinical diagnosis. *Journal of Clinical Psychology*, 9, 54-58.
- Baltes, B. B., Briggs, T. E., Huff, J. W., et al. (1999). Flexible and compressed workweek schedules: A meta-analysis of their effects on work-related criteria. *Journal of Applied Psychology*, 84, 496-513.
- Bank, A. L., MacNeill, S. E., & Lichtenberg, P. A. (2000). Cross validation of the MacNeill-Lichtenberg Decision Tree triaging mental health problems in geriatric rehabilitation patients. *Rehabilitation Psychology*, 45, 193-204.
- Baños, J. H., & Franklin, L. M. (2003). Factor structure of the Mini-Mental State Examination in adult psychiatric inpatients. *Psychological Assessment*, 14, 397-400.
- Barak, A., & Cohen, L. (2002). Empirical examination of an online version of the Self-Directed Search. *Journal of Career Assessment*, 10, 387-400.
- Barden, R. C., Ford, M. E., Jensen, A. G., Rogers-Salyer, M., & Salyer, K. E. (1989). Effects of craniofacial deformity in infancy on the quality of mother-infant interactions. *Child Development*, 60, 819-824.
- Bardis, P. D. (1975). The Borromean family. *Social Science*, 50, 144-158.
- Bardos, A. N. (1993). Human figure drawings: Abusing the abused. *School Psychology Quarterly*, 8, 177-181.
- Barends, A., Westen, D., Leigh, J., Silbert, D., & Byers, S. (1990). Assessing affect-tone of relationship paradigms from TAT and interview data. *Psychological Assessment*, 2, 329-332.
- Barker, R. (1963). On the nature of the environment. *Journal of Social Issues*, 19, 17-38.
- Barko, N. (1993, August). What's your child's emotional IQ? *Working Mother*, 16, 33-35.
- Barnett, L. A., Far, J. M., Mauss, A. L., & Miller, J. A. (1996). Changing perceptions of peer norms as a drinking reduction program for college students. *Journal of Alcohol & Drug Education*, 41(2), 39-62.
- Barnett, R. C., & Gareis, K. C. (2000). Reduced hours, job-role quality, and life satisfaction among married women physicians with children. *Psychology of Women Quarterly*, 24, 358-364.
- Baron, J., & Norman, M. F. (1992). SATs, achievement tests, and high-school class rank as predictors of college performance. *Educational and Psychological Measurement*, 52, 1047-1055.
- Bartholomew, D. (1996a). "Metaphor taken as math: Indeterminacy in the factor analysis model": Comment. *Multivariate Behavioral Research*, 31, 551-554.
- Bartholomew, D. (1996b). Response to Dr. Maraun's first reply to discussion of his paper. *Multivariate Behavioral Research*, 31, 631-636.
- Barton, K. A., Blanchard, E. B., & Veazy, C. (1999). Self-monitoring as an assessment strategy in behavioral medicine. *Psychological Assessment*, 11, 490-497.
- Bartram, D., Beaumont, J. G., Cornford, T., & Dann, P. L. (1987). Recommendations for the design of software for computer based assessment: Summary statement. *Bulletin of the British Psychological Society*, 40, 86-87.

- Bass, B. M. (1956). Development of a structured disguised personality test. *Journal of Applied Psychology*, 40, 393-397.
- Bass, B. M. (1957). Validity studies of proverbs personality test. *Journal of Applied Psychology*, 41, 158-160.
- Bass, B. M. (1958). Famous Sayings Test: General manual. *Psychological Reports*, 4, Monograph Number 6.
- Bassett, S. S. (1999). Attention: Neuropsychological predictor of competency in Alzheimer's disease. *Journal of Geriatric Psychiatry and Neurology*, 12, 200-205.
- Batchelor, E., Jr., Sowles, G., Dean, R. S., & Fischer, W. (1991). Construct validity of the Halstead-Reitan Neuropsychological Battery for children with learning disorders. *Journal of Psychoeducational Assessment*, 9, 16-31.
- Batchelor, E. S., Gray, J. W., & Dean, R. S. (1990). Empirical testing of a cognitive model to account for neuropsychological functioning underlying arithmetic problem solving. *Journal of Learning Disabilities*, 23(1), 38-42.
- Batson, D. C. (1975). Attribution as a mediator of bias in helping. *Journal of Personality and Social Psychology*, 32, 455-466.
- Baughman, E. E., & Dahlstrom, W. B. (1968). *Negro and white children: A psychological study in the rural South*. New York: Academic Press.
- Bauman, M. K. (1974). Blind and partially sighted. In M. V. Wisland (ed.), *Psychoeducational diagnosis of exceptional children* (pp. 159-189). Springfield, IL: Charles C Thomas.
- Bauman, M. K., & Kropf, C. A. (1979). Psychological tests used with blind and visually handicapped persons. *School Psychology Digest*, 8, 257-270.
- Baumeister, A. A., & Muma, J. R. (1975). On defining mental retardation. *Journal of Special Education*, 9, 293-306.
- Baumeister, R. F. (1990). Suicide as escape from self. *Psychological Review*, 97, 90-113.
- Baumrind, D. (1993). The average expectable environment is not good enough: A response to Scarr. *Child Development*, 64, 1299-1317.
- Bavolek, S. J. (1984). *Handbook for the Adult-Adolescent Parenting Inventory*. Eau Claire, WI: Family Development Associates.
- Baxter, J. C., Brock, B., Hill, P. C., & Rozelle, R. M. (1981). Letters of recommendation: A question of value. *Journal of Applied Psychology*, 66, 296-301.
- Baydoun, R. B., & Neuman, G. A. (1992). The future of the General Aptitude Test Battery (GATB) for use in public and private testing. *Journal of Business and Psychology*, 7, 81-91.
- Bayley, N. (1955). On the growth of intelligence. *American Psychologist*, 10, 805-818.
- Bayley, N. (1959). Value and limitations of infant testing. *Children*, 5, 129-133.
- Bayley, N. (1969). *Bayley Scales of Infant Development: Birth to Two Years*. New York: Psychological Corporation.
- Bayley, N. (1993). *Bayley Scales of Infant Development (2nd Edition) Manual*. San Antonio, TX: Psychological Corporation.
- Beard, J. G., & Ragheb, M. G. (1980). Measuring leisure satisfaction. *Journal of Leisure Research*, 12, 20-33.
- Beavers, R. (1985). *Manual of Beavers-Timberlawn Family Evaluation Scale and Family Style Evaluation*. Dallas, TX: Southwest Family Institute.
- Beck, A. T., Brown, G., & Steer, R. A. (1989). Prediction of eventual suicide in psychiatric inpatients by clinical ratings of hopelessness. *Journal of Consulting and Clinical Psychology*, 57, 309-310.
- Beck, A. T., Rush, A. J., Shaw, B. F., & Emery, G. (1979). *Cognitive therapy for depression*. New York: Guilford.
- Beck, A. T., & Steer, R. A. (1993). *Beck Depression Inventory manual*. San Antonio, TX: Psychological Corporation.
- Beck, A. T., Steer, R. A., & Brown, G. K. (1996). *Manual for the Beck Depression Inventory, 2nd ed.* San Antonio, TX: Psychological Corporation.
- Beck, A. T., & Stein, D. (1961). *Development of a self-concept test*. Unpublished manuscript, University of Pennsylvania School of Medicine, Center for Cognitive Therapy, Philadelphia.
- Beck, A. T., Ward, C. H., Mendelson, M., Mock, J., & Erbaugh, J. (1961). An inventory for measuring depression. *Archives of General Psychiatry*, 4, 561-571.
- Beck, S. J. (1944). *Rorschach's test: Vol. 1. Basic processes*. New York: Grune & Stratton.
- Beck, S. J. (1945). *Rorschach's test: Vol. 2. A variety of personality pictures*. New York: Grune & Stratton.
- Beck, S. J. (1952). *Rorschach's test: Vol. 3. Advances in interpretation*. New York: Grune & Stratton.
- Beck, S. J. (1960). *The Rorschach experiment*. New York: Grune & Stratton.
- Becker, H. A., Needleman, H. L., & Kotelchuck, M. (1978). Child abuse and dentistry: Orificial trauma and its recognition by dentists. *Journal of the American Dental Association*, 97(1), 24-28.
- Becker, K. A. (2003). *History of the Stanford-Binet intelligence scales: Content and psychometrics*. (Stanford-Binet Intelligence Scales, Fifth Edition, Assessment Service Bulletin No. 1). Itasca, IL: Riverside Publishing.
- Beckham, J. C., Crawford, A. L., & Feldman, M. E. (1998). Trail Making Test performance in Vietnam combat veterans with and without posttraumatic stress disorder. *Journal of Traumatic Stress*, 11, 811-819.
- Beebe, S. A., Casey, R., & Pinto-Martin, J. (1993). Association of reported infant crying and maternal parenting stress. *Clinical Pediatrics*, 32, 15-19.
- Begault, D. R. (1993). Head-up auditory displays for traffic collision avoidance advisories: A preliminary investigation. *Human Factors*, 35, 707-717.
- Beier, E. G., & Sternberg, D. P. (1977). Marital communication. *Journal of Communication*, 27, 92-100.
- Beier, M. E., & Ackerman, P. L. (2003). Determinants of health knowledge: An investigation of age, gender, abilities, personality, and interests. *Journal of Personality & Social Psychology*, 84, 439-447.
- Bell, N. L., Matthews, T. D., Lassiter, K. S., & Leverett, J. P. (2002). Validity of the Wonderlic Personnel Test as a measure of fluid or crystallized intelligence: Implications for career assessment. *North American Journal of Psychology*, 4, 113-120.
- Bellack, A. S., & Hersen, M. (eds.). (1988). *Behavioral assessment: A practical guide* (3rd ed.). Elmsford, NY: Pergamon.
- Bellack, A. S., Morrison, R. L., Mueser, K. T., Wade, J. H., & Sayers, S. L. (1990). Role play for assessing the social competence of psychiatric patients. *Psychological Assessment*, 2, 248-255.
- Bellak, L. (1971). *The TAT and CAT in clinical use* (2nd ed.). New York: Grune & Stratton.
- Bellak, L., & Bellak, S. (1965). *The CAT-H-A human modification*. Larchmont, NY: C.P.S.
- Bellak, L., & Bellak, S. S. (1973). *Senior Apperception Technique*. New York: C.P.S.
- Benbow, C. P., & Stanley, J. C. (1996). Inequity in equity: How "equity" can lead to inequity for high-potential students. *Psychology, Public Policy, and Law*, 2, 249-292.
- Bender, L. (1938). A visual-motor gestalt test and its clinical use. *American Orthopsychiatric Association Research Monographs*, No. 3.
- Bender, L. (1970). The visual-motor gestalt test in the diagnosis of learning disabilities. *Journal of Special Education*, 4, 29-39.

- Benedict, R. H., Schretlen, D., & Bobholz, J. H. (1992). Concurrent validity of three WAIS-R short forms in psychiatric inpatients. *Psychological Assessment*, 4, 322-328.
- Benjamin, G. A. H., & Gollan, J. K. (2003). *Family evaluation in custody litigation: Reducing risks of ethical infractions and malpractice*. Washington, DC: APA Books.
- Bennett, F., Hughes, A., & Hughes, H. (1979). Assessment techniques for deaf-blind children. *Exceptional Children*, 45, 287-288.
- Ben-Porath, Y. S. (1990). Cross-cultural assessment of personality: The case for replicatory factor analysis. In J. N. Butcher & C. D. Spielberger (eds.), *Advances in personality assessment* (Vol. 8; pp. 1-26). Hillsdale, NJ: Erlbaum.
- Ben-Porath, Y. S., & Waller, N. G. (1992). Five big issues in clinical personality assessment: A rejoinder to Costa and McCrae. *Psychological Assessment*, 4, 23-25.
- Benton, A. L. (1994). Neuropsychological assessment. *Annual Review of Psychology*, 45, 1-25.
- Berk, R. A. (ed.). (1982). *Handbook of methods for detecting test bias*. Baltimore: Johns Hopkins University.
- Berkowitz, L., & Frodi, A. (1979). Reactions to a child's mistakes as affected by her/his looks and speech. *Social Psychology Quarterly*, 42, 420-425.
- Bernardin, H. J. (1978). Effects of rater training on leniency and halo errors in student ratings of instructors. *Journal of Applied Psychology*, 63, 301-308.
- Bernhardt, G. R., Cole, D. J., & Ryan, C. W. (1993). Improving career decision making with adults: Use of portfolios. *Journal of Employment Counseling*, 30, 67-72.
- Bernstein, L. (1956). The examiner as an inhibiting factor in clinical testing. *Journal of Consulting Psychology*, 20, 287-290.
- Berry, D. S., & Hansen, J. S. (1996). Positive affect, negative affect, and social interaction. *Journal of Personality and Social Psychology*, 71, 796-809.
- Besetsny, L. K., Ree, M. J., & Earles, J. A. (1993). Special test for computer programmers? Not needed: The predictive efficiency of the Electronic Data Processing Test for a sample of Air Force recruits. *Educational and Psychological Measurement*, 53, 507-511.
- Bienvenu, M. J., Sr. (1978). *A counselor's guide to accompany a Marital Communication Inventory*. Saluda, NC: Family Life.
- Bigler, E. D., & Ehrenfurth, J. W. (1981). The continued inappropriate singular use of the Bender Visual Motor Gestalt Test. *Professional Psychology*, 12, 562-569.
- Billmire, M. G., & Myers, P. A. (1985). Serious head injury in infants: Accident or abuse? *Pediatrics*, 75, 341-342.
- Binet, A., & Henri, V. (1895a). La psychologie individuelle. *L'Année Psychologique*, 2, 411-465.
- Binet, A., & Henri, V. (1895b). La mémoire des mots. *L'Année Psychologique*, 1, 1-23.
- Binet, A., & Henri, V. (1895c). La mémoire des phrases. *L'Année Psychologique*, 1, 24-59.
- Binet, A., & Simon, T. (1905). Méthodes nouvelles pour le diagnostic du niveau intellectuel des anormaux. *L'Année Psychologique*, 11, 191-244.
- Binet, A., & Simon, T. (1908). La développement de l'intelligence chez les enfants [The development of intelligence in children] (E. S. Kite, Trans.). En J. J. Jenkins & D. G. Paterson (reprint eds.), *Studies in individual differences: The search for intelligence* (pp. 90-96). New York: Appleton-Century-Crofts. (Reprinted in 1961)
- Birch, H. G., & Diller, L. (1959). Rorschach signs of "organicity": A physiological basis for perceptual disturbances. *Journal of Projective Techniques*, 23, 184-197.
- Birney, R. C., Burdick, H., & Teevan, R. C. (1969). *Fear of failure*. New York: Van Nostrand Reinhold.
- Birren, J. E. (1968). Increments and decrements in the intellectual status of the aged. *Psychiatric Research Reports*, 23, 207-214.
- Birren, J. E., & Schaie, K. W. (1985). *Handbook of psychology of aging* (2nd ed.). New York: Van Nostrand Reinhold.
- Bizot, E. B., & Goldman, S. H. (1993). Prediction of satisfactoriness and satisfaction: An 8-year follow up. Special issue: The theory of work adjustment. *Journal of Vocational Behavior*, 43, 19-29.
- Black, B., Ayala, F., & Saffran-Brinks, C. (1994). Science and the law in the wake of *Daubert*: A new search for scientific knowledge. *Texas Law Review*, 72, 715-802.
- Black, H. (1963). *They shall not pass*. New York: Morrow.
- Black, H. C. (1979). *Black's law dictionary* (rev. ed.). St. Paul, MN: West.
- Black, M., Schuler, M., & Nair, P. (1993). Prenatal drug exposure: Neurodevelopment outcome and parenting environment. *Journal of Pediatric Psychology*, 18, 605-620.
- Blalock, S. J., Devellis, B. M., Holt, K., & Hahn, P. M. (1993). Coping with rheumatoid arthritis: Is one problem the same as another? *Health Education Quarterly*, 20, 119-132.
- Blanck, P. D., & Berven, H. M. (1999). Evidence of disability after *Daubert*. *Psychology, Public Policy, and Law*, 5, 16-40.
- Bloom, A. S., Allard, A. M., Zelko, F. A. J., Brill, W. J., Topinka, C. W., & Pfohl, W. (1988). Differential validity of the K-ABC for lower functioning preschool children versus those of higher ability. *American Journal of Mental Retardation*, 93(3), 273-277.
- Blum, G. S. (1950). *The Blacky pictures: A technique for the exploration of personality dynamics*. New York: Psychological Corporation.
- Blum, M. L., & Naylor, J. C. (1968). *Industrial psychology: Its theoretical and social foundations* (rev. ed.). New York: Harper & Row.
- Blumenthal, S. J., & Kupfer, D. J. (eds.). (1990). *Suicide over the life cycle: Risk factors, assessment, and treatment of suicidal patients*. Washington, DC: American Psychiatric Press.
- Blustein, D. L., & Ellis, M. V. (2000). The cultural context of career assessment. *Journal of Career Assessment*, 8, 379-390.
- Board of Professional Affairs, Committee on Professional Practice & Standards, Practice Directorate, American Psychological Association. (1999). Guidelines for psychological evaluations in child protection matters. *American Psychologist*, 54, 586-593.
- Boccaccini, M. T., & Brodsky, S. L. (1999). Diagnostic test usage by forensic psychologists in emotional injury cases. *Professional Psychology: Research and Practice*, 30, 253-259.
- Bock, R. D., & Jones, L. V. (1968). *The measurement and prediction of judgment and choice*. San Francisco: Holden-Day.
- Bombadier, C., & Tugwell, P. (1987). Methodological considerations in functional assessment. *Journal of Rheumatology*, 14, 6-10.
- Bond, G. B., & Fox, C. M. (2001). *Applying the Rasch model: Fundamental measurement in human science*. Mahwah, N.J.: Erlbaum.
- Bond, G. G., Aiken, L. S., & Somerville, S. C. (1992). The health belief model and adolescents with insulin-dependent diabetes mellitus. *Health Psychology*, 11, 190-198.
- Bond, M. H., & Forgas, J. P. (1984). Linking person perception to behavior intention across cultures: The role of cultural collectivism. *Journal of Cross-Cultural Psychology*, 1, 185-216.
- Bond, R., & Smith, P. B. (1996). Culture and conformity. A meta-analysis of studies using Asch's line judgment task. *Psychological Bulletin*, 119, 111-137.
- Boone, D. E. (1991). Item-reduction vs. subtest-reduction short forms on the WAIS-R with psychiatric inpatients. *Journal of Clinical Psychology*, 47, 271-276.
- Booth, A., & Edwards, J. (1983). Measuring marital instability. *Journal of Marriage and the Family*, 45, 387-393.

- Boring, E. G. (1923, June 6). Intelligence as the tests test it. *New Republic*, pp. 35-37.
- Boring, E. G. (1950). *A history of experimental psychology* (rev. ed.). New York: Appleton-Century-Crofts.
- Borkenau, P., & Liebler, A. (1992). Trait inferences: Sources of validity at zero acquaintance. *Journal of Personality and Social Psychology*, 62, 645-657.
- Bornstein, P. H., Hamilton, S. B., & Bornstein, M. T. (1986). Self-monitoring procedures. In A. R. Ciminero, C. S. Calhoun, & H. E. Adams (eds.), *Handbook of behavioral assessment* (pp. 176-222). New York: Wiley.
- Bornstein, R. F. (1998). Interpersonal dependency and physical illness: A meta-analytic review of retrospective and prospective studies. *Journal of Research in Personality*, 32, 480-497.
- Bornstein, R. F. (1999). Criterion validity of objective and projective dependency tests: A meta-analytic assessment of behavioral prediction. *Psychological Assessment*, 11, 48-57.
- Bornstein, R. F., Rossner, S. C., Hill, E. L., & Stepanian, M. L. (1994). Face validity and fakability of objective and projective measures of dependency. *Journal of Personality Assessment*, 63, 363-386.
- Bove, C. F., Sobal, J., & Rauschenbach, B. S. (2003). Food choices among newly married couples: Convergence, conflict, individualism, and projects. *Appetite*, 40, 25-41.
- Boyle, J. P. (1987). Intelligence, reasoning, and language proficiency. *Modern Language Journal*, 71, 277-288.
- Bozeman, D. P., & Perrewe, P. L. (2001). The effect of item content overlap on Organizational Commitment Questionnaire-turnover cognitions relationships. *Journal of Applied Psychology*, 86, 161-173.
- Bracken, B. A. (1985). A critical review of the Kaufman Assessment Battery for Children (K-ABC). *School Psychology Review*, 14, 21-36.
- Bracken, B. A., & Barona, A. (1991). State of the art procedures for translating, validating, and using psychoeducational tests in cross-cultural assessment. *School Psychology International*, 12, 119-132.
- Braden, J. P. (1985). *Deafness, deprivation, and IQ*. New York: Plenum.
- Braden, J. P. (1990). Do deaf persons have a characteristic psychometric profile on the Wechsler Performance Scales? *Journal of Psychoeducational Assessment*, 8, 518-526.
- Braden, J. P. (1992). Intellectual assessment of deaf and hard-of-hearing people: A quantitative and qualitative research synthesis. *School Psychology Review*, 21, 82-84.
- Bradley, J. P., Nicol, A. A., Charbonneau, D., & Meyer, J. P. (2002). Personality correlates of leadership development in Canadian Forces officer candidates. *Canadian Journal of Behavioural Science*, 34, 92-103.
- Bradley-Johnson, S. (1994). *Psychoeducational assessment of students who are visually impaired or blind: Infancy through high school*. Austin, TX: PRO-ED.
- Bradley-Johnson, S., & Harris, S. (1990). Best practices in working with students with a visual loss. In A. Thomas & J. Grimes (eds.), *Best practices in school psychology II* (pp. 871-885). Washington, DC: National Association of School Psychologists.
- Brady, N. C., & Halle, J. W. (1997). Functional analysis of communicative behaviors. *Focus on Autism and Other Developmental Disabilities*, 12(2), 95-104.
- Braginsky, B. M., Braginsky, D. D., & Ring, K. (1969). *Methods of madness*. New York: Holt, Rinehart & Winston.
- Brannen, M. Y., & Salk, J. E. (2000). Partnering across borders: Negotiating organizational culture in a German-Japanese joint venture. *Human Relations*, 53, 451-487.
- Brannigan, G. G., & Brunner, N. A. (2002). *Guide to the qualitative scoring system for the modified version of the Bender-Gestalt test*. Springfield, IL: Charles C Thomas.
- Brannigan, G. G., & Decker, S. L. (2003). *Bender Visual-Motor Gestalt Test Second Edition, Examiner's Manual*. Itasca, IL: Riverside Publishing.
- Brassard, M., et al. (eds.). (1986). *The psychological maltreatment of children and youth*. Elmsford, NY: Pergamon.
- Brauer, B. (1993). Adequacy of a translation of the MMPI into American Sign Language for use with deaf individuals: Linguistic equivalency issues. *Rehabilitation Psychology*, 38, 247-259.
- Bray, D. W. (1964). The management progress study. *American Psychologist*, 19, 419-429.
- Bray, D. W. (1982). The assessment center and the study of lives. *American Psychologist*, 37, 180-189.
- Bresolin, M. J., Jr. (1984). A comparative study of computer administration of the Minnesota Multiphasic Personality Inventory in an inpatient psychiatric setting. *Dissertation Abstracts International*, 46, 295B. (University Microfilms No. 85-06, 377).
- Brewer, E. W., & Clippard, L. F. (2002). Burnout and job satisfaction among student support services personnel. *Human Resource Development Quarterly*, 13, 169-186.
- Brewer, S. (1987, January 11). A perfect package, yes, but how 'bout the name? *Journal-News* (Rockland County, NY), pp. H-1, H-18.
- Bricklin, B. (1984). *The Bricklin Perceptual Scales: Child-Perception-of-Parents-Series*. Furlong, PA: Village.
- Bringle, R., Roach, S., Andler, C., & Evenbeck, S. (1979). Measuring the intensity of jealous reactions. *Catalogue of Selected Documents in Psychology*, 9, 23-24.
- Brittain, H. L. (1907). A study in imagination. *Pedagogical Seminary*, 14, 137-207.
- Brody, D., Serby, M., Etienne, N., & Kalkstein, D. C. (1991). Olfactory identification deficits in HIV infection. *American Journal of Psychiatry*, 148, 248-250.
- Brody, M. L., Walsh, B. T., & Devlin, M. J. (1994). Binge eating disorder: Reliability and validity of a new diagnostic category. *Journal of Consulting and Clinical Psychology*, 62, 381-386.
- Brody, N. (1972). *Personality: Research and theory*. New York: Academic Press.
- Brodzinsky, D. M. (1993). On the use and misuse of psychological testing in child custody evaluations. *Professional Psychology: Research and Practice*, 24, 213-219.
- Brogden, H. E. (1946). On the interpretation of the correlation coefficient as a measure of predictive efficiency. *Journal of Educational Psychology*, 37, 65-76.
- Brogden, H. E. (1949). When tests pay off. *Personnel Psychology*, 2, 171-183.
- Brotemarkle, R. A. (1947). Clinical psychology, 1896-1946. *Journal of Consulting and Clinical Psychology*, 11, 1-4.
- Brown, D. C. (1994). Subgroup norming: Legitimate testing practice or reverse discrimination. *American Psychologist*, 49, 927-928.
- Brown, G., Nicassio, P. W., & Wallston, K. A. (1989). Pain coping strategies and depression in rheumatoid arthritis. *Journal of Consulting and Clinical Psychology*, 57, 652-657.
- Brown, J. M. (1984). Imagery coping strategies in the treatment of migraine. *Pain*, 18, 157-167.
- Brown, R. D. (1972). The relationship of parental perceptions of university life and their characterizations of their college sons and daughters. *Educational and Psychological Measurement*, 32, 365-375.

- Brown, R. T., Reynolds, C. R., & Whitaker, J. S. (1999). Bias in mental testing since *Bias in Mental Testing*. *School Psychology Quarterly*, 14, 208-238.
- Brown, S. P., & Peterson, R. A. (1993). Antecedents and consequences of salesperson job satisfaction: Meta-analysis and assessment of causal effects. *Journal of Marketing Research*, 30, 63-77.
- Browning, D. L. (1987). Ego development, authoritarianism, and social status: An investigation of the incremental validity of Loewinger's Sentence Completion Test (Short Form). *Journal of Personality and Social Psychology*, 53, 113-118.
- Bryer, J. B., Martinez, K. A., & Dignan, M. A. (1990). Millon Clinical Multiaxial Inventory Alcohol Abuse and Drug Abuse scales and the identification of substance-abuse patients. *Psychological Assessment*, 2, 438-441.
- Bucholz, K. K., Cadoret, R., Cloninger, C. R., & Dinwiddie, S. H. (1994). A new, semi-structured psychiatric interview for use in genetic linkage studies: A report on the reliability of the SSAGA. *Journal of Studies on Alcohol*, 55, 149-158.
- Buck, J. N. (1948). The H-T-P technique: A qualitative and quantitative scoring manual. *Journal of Clinical Psychology*, 4, 317-396.
- Buck, J. N. (1950). *Administration and interpretation of the H-T-P test: Proceedings of the H-T-P workshop at Veterans Administration Hospital, Richmond, Virginia*. Beverly Hills, CA: Western Psychological Services.
- Buckle, M. B., & Holt, N. F. (1951). Comparison of Rorschach and Behn Inkblots. *Journal of Projective Techniques*, 15, 486-493.
- Buckner, F., & Firestone, M. (2000). "Where the public peril begins": 25 years after *Tarasoff*. *Journal of Legal Medicine*, 21, 187-222.
- Bucofsky, D. (1971). Any learning skills taught in the high school? *Journal of Reading*, 15(3), 195-198.
- Bukatman, B. A., Foy, J. L., & De Grazia, E. (1971). What is competency to stand trial? *American Journal of Psychiatry*, 127, 1225-1229.
- Burger, J. M., Horita, M., Kinoshita, L., et al. (1997). Effects of time on the norm of reciprocity. *Basic and Applied Social Psychology*, 19, 91-100.
- Burgess, A. W., McCausland, M. P., & Wolbert, W. A. (1981, February). Children's drawings as indicators of sexual trauma. *Perspectives in Psychiatric Care*, 19, 50-58.
- Burisch, M. (1984). Approaches to personality inventory construction: A comparison of merits. *American Psychologist*, 39, 214-227.
- Burke, M. J. (1984). Validity generalization: A review and critique of the correlation model. *Personnel Psychology*, 37, 93-115.
- Burke, R. J. (1970). Occupational and life strains, satisfactions, and mental health. *Journal of Business Administration*, 1, 35-41.
- Burns, A., Jacoby, R., & Levy, R. (1991). Progression of cognitive impairment in Alzheimer's disease. *Journal of the American Geriatrics Society*, 39, 39-45.
- Burns, E. (1998). *Test accommodations for students with disabilities*. Springfield, IL: Charles C Thomas.
- Burns, R. C., & Kaufman, S. H. (1970). *Kinetic Family Drawings (K-F-D): An introduction to understanding through kinetic drawings*. New York: Brunner/Mazel.
- Burns, R. C., & Kaufman, S. H. (1972). *Actions, styles, and symbols in Kinetic Family Drawings (K-F-D)*. New York: Brunner/Mazel.
- Buros, O. K. (1938). *The 1938 mental measurements yearbook*. New Brunswick, NJ: Rutgers University Press.
- Buros, O. K. (1968). The story behind the mental measurements yearbooks. *Measurement and Evaluation in Guidance*, 1(2), 86-95.
- Burstein, A. G. (1972). Review of the Wechsler Adult Intelligence Scale. En O. K. Buros (ed.), *The seventh mental measurements yearbook* (pp. 786-788). Highland Park, NJ: Gryphon.
- Burwen, L. S., & Campbell, D. T. (1957). The generality of attitudes toward authority and nonauthority figures. *Journal of Abnormal and Social Psychology*, 54, 24-31.
- Bushard, P., & Howard, D. A. (eds.). (1994). *Resource guide for custody evaluators: A handbook for parenting evaluations*. Madison, WI: Association for Family and Conciliation Courts.
- Bushman, B. J., & Cantor, J. (2003). Media ratings for violence and sex: Implications for policymakers and parents. *American Psychologist*, 58, 130-141.
- Bushman, B. J., & Wells, G. L. (1998). Trait aggressiveness and hockey penalties: Predicting hot tempers on the ice. *Journal of Applied Psychology*, 83, 969-974.
- Butcher, J. N. (1987). The use of computers in psychological assessment: An overview of practices and issues. En J. N. Butcher (ed.), *Computerized psychological assessment: A practitioner's guide* (pp. 3-14). New York: Basic.
- Butcher, J. N. (1990). *MMPI-2 in psychological treatment*. New York: Oxford University Press.
- Butcher, J. N. (1994). Psychological assessment by computer: Potential gains and problems to avoid. *Psychiatric Annals*, 24, 20-24.
- Butcher, J. N. (2000). Revising psychological tests: Lessons learned from the revision of the MMPI. *Psychological Assessment*, 12, 263-271.
- Butcher, J. N. (2003). Discontinuities, side steps, and finding a proper place: An autobiographical account. *Journal of Personality Assessment*, 80, 223-236.
- Butcher, J. N., & Han, K. (1995). Development of an MMPI-2 scale to assess the presentation of self in a superlative manner: The S Scale. In J. N. Butcher & C. D. Spielberger (eds.), *Advances in personality assessment* (Vol. 10; pp. 25-50). Hillsdale, NJ: Erlbaum.
- Butcher, J. N., Perry, J. N., & Atlis, M. M. (2000). Validity and utility of computer-based test interpretation. *Psychological Assessment*, 12, 6-18.
- Butcher, J. N., Williams, C. L., Graham, J. R., et al. (1992). *Minnesota Multiphasic Personality Inventory-Adolescent (MMPI-A): Manual for administration, scoring, and interpretation*. Minneapolis: University of Minnesota Press.
- Butters, N., Wolfe, J., Martone, M., et al. (1985). Memory disorders associated with Huntington's disease: Verbal recall, verbal recognition and procedural memory. *Neuropsychologia*, 23, 729-743.
- Byrne, D. (1974). *An introduction to personality* (2nd ed.). Englewood Cliffs, NJ: Prentice-Hall.
- Byrnes, M. M., & Spitz, H. H. (1977). Performance of retarded adolescents and non-retarded children on the Tower of Hanoi problem. *American Journal of Mental Deficiency*, 81, 561-569.
- Cain, L. F., Levine, S., & Elsey, F. F. (1963). *Cain-Levine Social Competency Scale*. Palo Alto, CA: Consulting Psychologists Press.
- Calhoon, M. B., Fuchs, L. S., & Hamlett, C. L. (2000). Effects of computer-based test accommodations on mathematics performance assessments for secondary students with learning disabilities. *Learning Disability Quarterly*, 23, 271-282.
- Callahan, J. (1994). The ethics of assisted suicide. *Health and Social Work*, 19, 237-244.
- Callero, P. L. (1992). The meaning of self-in-role: A modified measure of role-identity. *Social Forces*, 71, 485-501.
- Camara, W. J., Nathan, J. S., & Puente, A. E. (2000). Psychological test usage: Implications in professional psychology. *Professional Psychology: Research and Practice*, 31, 141-154.

- Camara, W. J., & Schneider, D. L. (1994). Integrity tests: Facts and unresolved issues. *American Psychologist*, 49, 112-119.
- Camilli, G., & Shepard, L. A. (1985). A computer program to aid the detection of biased test items. *Educational & Psychological Measurement*, 45, 595-600.
- Campbell, D. P. (1971). *Handbook for the Strong Vocational Interest Blank*. Palo Alto, CA: Stanford University Press.
- Campbell, D. P. (1972). The practical problems of revising an established psychological test. En J. N. Butcher (ed.), *Objective personality assessment: Changing perspectives* (pp. 117-130). New York: Academic Press.
- Campbell, D. T., & Fiske, D. W. (1959). Convergent and discriminant validation by the multitrait-multimethod matrix. *Psychological Bulletin*, 56, 81-105.
- Campos, L. P. (1989). Adverse impact, unfairness, and bias in the psychological screening of Hispanic peace officers. *Hispanic Journal of Behavioral Sciences*, 11, 122-135.
- Cannon-Bowers, J. A., Salas, E., Blickensderfer, E., & Bowers, C. A. (1998). The impact of cross-training and workload on team functioning: A replication and extension of initial findings. *Human Factors*, 40, 92-101.
- Caplan, L. J., & Schooler, C. (2003). The roles of fatalism, self-confidence, and intellectual resources in the disablement process in older adults. *Psychology and Aging*, 18, 551-561.
- Capraro, R. M., & Capraro, M. M. (2002). Myers-Briggs Type Indicator score reliability across studies: A meta-analytic reliability generalization study. *Educational & Psychological Measurement*, 62, 590-602.
- Capretz, L. F. (2003). Personality types in software engineering. *International Journal of Human-Computer Studies*, 58, 207-214.
- Care, E. (1996). The structure of interests related to college course destinations. *Journal of Career Assessment*, 4, 77-89.
- Carey, M. P., Faulstich, M. E., Gresham, F. M., Ruggerio, L., & Enyart, P. (1987). Children's Depression Inventory: Construct and discriminant validity across clinical and non-referred (control) populations. *Journal of Consulting and Clinical Psychology*, 55, 755-761.
- Carey, N. B. (1994). Computer predictors of mechanical job performance: Marine Corps findings. *Military Psychology*, 6, 1-30.
- Carmichael, L. (1927). A further study of the development of behavior in vertebrates experimentally removed from the influence of external stimulation. *Psychological Review*, 34, 34-47.
- Carroll, J. B. (1985, May). Domains of cognitive ability. Symposium: Current theories and findings on cognitive abilities. Los Angeles: AAAS.
- Carroll, J. B. (1993). *Human cognitive abilities: A survey of factor-analytic studies*. Cambridge, England: Cambridge University Press.
- Carroll, J. B. (1997). The three-stratum theory of cognitive abilities. In D. P. Flanagan et al. (eds.), *Contemporary intellectual assessment: Theories, tests, and issues* (pp. 122-130). New York: Guilford.
- Carroll, K. M. (1998). *A cognitive-behavioral approach: Treating cocaine addiction*. NIH Publication No. 98-4308. Rockville, MD: National Institute on Drug Abuse.
- Carroll, K. M., Nich, C., Frankforter, T. L., & Bisighini, R. M. (1999). Do patients change in the ways we intend? Assessing acquisition of coping skills among cocaine-dependent patients. *Psychological Assessment*, 11, 77-85.
- Carter, B. L., & Tiffany, S. T. (1999). Meta-analysis of cue reactivity in addiction research. *Addiction*, 94, 327-340.
- Caruso, J. C. (2000). Reliability generalization of the NEO personality scales. *Educational and Psychological Measurement*, 60, 236-254.
- Carver, R. P. (1968/1969). Designing an aural aptitude test for Negroes: An experiment that failed. *College Board Review*, 70, 10-14.
- Carver, R. P. (1969). Use of a recently developed listening comprehension test to investigate the effect of disadvantage upon verbal proficiency. *American Educational Research Journal*, 6, 263-270.
- Cascio, W. F. (1987). *Applied psychology in personnel management* (3rd ed.). Englewood Cliffs, NJ: Prentice-Hall.
- Cascio, W. F., Outtz, J., Zedeck, S., & Goldstein, I. L. (1991). Statistical implications of six methods of test score use in personnel selection. *Personnel Psychology*, 4, 233-264.
- Caspi, A., Begg, D., Dickson, N., et al. (1997). Personality differences predict health-risk behaviors in young adulthood: Evidence from a longitudinal study. *Journal of Personality and Social Psychology*, 73, 1052-1063.
- Caspi, A., Elder, G., & Bem, D. J. (1987). Moving against the world: Life-course patterns of explosive children. *Developmental Psychology*, 23, 308-313.
- Cassel, R. N. (1958). *The leadership q-sort test: A test of leadership values*. Murfreesboro, TN: Psychometric Affiliates.
- Castro, V. S. (2003). *Acculturation and psychological adaptation*. Westport, CT: Praeger.
- Catalano, R., Novaco, R., & McConnell, W. (1997). A model of the net effect of job loss on violence. *Journal of Personality and Social Psychology*, 72, 1440-1447.
- Cates, J. A., & Lapham, R. F. (1991). Personality assessment of the prelingual, profoundly deaf child or adolescent. *Journal of Personality Assessment*, 56, 118-129.
- Cattell, H. E. P. (1996). The original big five: A historical perspective. *European Review of Applied Psychology*, 46, 5-14.
- Cattell, J. M. (1887). Experiments on the association of ideas. *Mind*, 12, 68-74.
- Cattell, J. M., & Bryant, S. (1889). Mental association investigated by experiment. *Mind*, 14, 230-250.
- Cattell, P. (1940). *Cattell Infant Intelligence Scale*. New York: Psychological Corporation.
- Cattell, R. B. (1940). A culture free intelligence test, Part I. *Journal of Educational Psychology*, 31, 161-179.
- Cattell, R. B. (1941). Some theoretical issues in adult intelligence testing. *Psychological Bulletin*, 38, 592.
- Cattell, R. B. (1946). *The description and measurement of personality*. New York: Harcourt, Brace & World.
- Cattell, R. B. (1947). Confirmation and clarification of the primary personality factors. *Psychometrika*, 12, 197-220.
- Cattell, R. B. (1948a). The primary personality factors in the realm of objective tests. *Journal of Personality*, 16, 459-487.
- Cattell, R. B. (1948b). The primary personality factors in women compared with those in men. *British Journal of Psychology, Statistical Section*, 1, 114-130.
- Cattell, R. B. (1950). *Personality: A systematic theoretical and factual study*. New York: McGraw-Hill.
- Cattell, R. B. (1957). *Personality and motivation, structure and measurement*. Yonkers, NY: World Book.
- Cattell, R. B. (1965). *The scientific analysis of personality*. Baltimore: Penguin.
- Cattell, R. B. (1971). *Abilities: Their structure, growth, and action*. Boston: Houghton Mifflin.
- Cattell, R. B., Cattell, A. K. S., & Cattell, H. E. P. (1993). *16 PF, Fifth Edition*. Champaign, IL: Institute for Personality and Ability Testing.
- Cattell, R. B., & Horn, J. L. (1978). A check on the theory of fluid and crystallized intelligence with description of new subtest design. *Journal of Educational Measurement*, 15, 139-164.

- Cattell, R. B., & Krug, S. E. (1986). The number of factors in the 16 PF: A review of the evidence with special emphasis on methodological problems. *Educational and Psychological Measurement*, 46, 509-522.
- Caught, K., Shadur, M. A., & Rodwell, J. J. (2000). The measurement artifact in the Organizational Commitment Questionnaire. *Psychological Reports*, 87, 777-788.
- Ceci, S. J., Ross, D. F., & Toglia, M. P. (1987). Suggestibility of children's memory: Psycholegal implications. *Journal of Experimental Psychology*, 116, 38-49.
- Celis, W., III. (1994, December 16). Computer admissions test found to be ripe for abuse. *New York Times*, pp. A1, A32.
- Cerney, M. S. (1984). One last response to the Rorschach test: A second chance to reveal oneself. *Journal of Personality Assessment*, 48, 338-344.
- Champagne, J. E. (1969). Job recruitment of the unskilled. *Personnel Journal*, 48, 259-268.
- Chan, K.-Y., Drasgow, F., & Sawin, L. L. (1999). What is the shelf life of a test? The effect of time on the psychometrics of a cognitive ability test battery. *Journal of Applied Psychology*, 84, 610-619.
- Chance, N. A. (1965). Acculturation, self-identification, and personality adjustment. *American Anthropologist*, 67, 372-393.
- Chaney, E. F., O'Leary, M. R., & Marlatt, G. A. (1978). Skill training with problem drinkers. *Journal of Consulting and Clinical Psychology*, 46, 1092-1104.
- Chantler, L., Pelco, L., & Mertin, P. (1993). The psychological evaluation of child sexual abuse using the Louisville Behavior Checklist and human figure drawing. *Child Abuse and Neglect*, 17, 271-279.
- Chaplin, W. F., John, O. P., & Goldberg, L. R. (1988). Conceptions of state and traits: Dimensional attributes with ideals as prototypes. *Journal of Personality and Social Psychology*, 54, 541-557.
- Chapman, J. C. (1921). *Trade tests*. New York: Holt.
- Chapman, L., & Chapman, J. (1967). Genesis of popular but erroneous psychodiagnostic observations. *Journal of Abnormal Psychology*, 72, 193-204.
- Chappin, S. R., & Brook, J. S. (2001). The influence of generational status and psychosocial variables on marijuana use among Black and Puerto Rican adolescents. *Hispanic Journal of Behavioral Sciences*, 23, 22-36.
- Chartrand, J. M., Borgen, F. H., Betz, N. E., & Donnay, D. (2002). Using the Strong Interest Inventory and the Skills Confidence Inventory to explain career goals. *Journal of Career Assessment*, 10, 169-189.
- Chase, J. (1986). Application of assessment techniques to the totally blind. En P. Lazarus & S. Storchart (eds.), *Psycho-educational evaluation of children and adolescents with low incidence handicaps*. New York: Grune & Stratton.
- Chase, S., & Schlink, F. J. (1927). *Your money's worth: A study in the waste of the consumer's dollar*. New York: Macmillan.
- Chess, S., & Thomas, A. (1973). Temperament in the normal infant. En J. C. Westman (ed.), *Individual differences in children*. New York: Wiley.
- Cheung, F. M., & Lau, B. (1982). Situational variations of help-seeking behavior among Chinese patients. *Comprehensive Psychiatry*, 23, 252-262.
- Chinman, M. J., Allende, M., Weingarten, R., et al. (1999). On the road to collaborative treatment planning: Consumer and provider perspectives. *Journal of Behavioral Health Services & Research*, 26, 211-218.
- Chinoy, E. (1967). *Society: An introduction to sociology*. New York: Random House.
- Chira-Chavala, T., & Yoo, S. M. (1994). Potential safety benefits on intelligence cruise control systems. *Accident Analysis & Prevention*, 26, 135-146.
- Cho, H., & LaRose, R. (1999). Privacy issues in Internet surveys. *Social Science Computer Review*, 17, 421-434.
- Christensen, A. L. (1975). *Luria's neuropsychological investigation*. New York: Spectrum.
- Christensen, K. M., & Delgado, G. L. (1993). *Multicultural issues in deafness*. White Plains, NY: Longman.
- Christiansen, A. J., Weibe, J. S., Smith, T. W., & Turner, C. W. (1994). Predictors of survival among hemodialysis patients: Effects of perceived family support. *Health Psychology*, 13, 521-525.
- Church, A. T., & Burke, P. J. (1994). Exploratory and confirmatory tests of the Big Five and Tellegen's three- and four-dimensional models. *Journal of Personality and Social Psychology*, 66, 93-114.
- Cicchetti, D., & Carlson, V. (eds.). (1989). *Child maltreatment: Theory and research on the causes and consequences of child abuse and neglect*. New York: Cambridge University Press.
- Clarizio, H. F. (1989). *Assessment and treatment of depression in children and adolescents*. Brandon, VT: Clinical Psychological Publishing.
- Clark, B. (1979). *Growing up gifted*. Columbus, OH: Merrill.
- Clark, B. (1988). *Growing up gifted* (3rd ed.). Columbus, OH: Merrill.
- Clark, L. A. (1999). Introduction to the special section on the concept of disorder. *Journal of Abnormal Psychology*, 108, 371-373.
- Cleckley, H. (1976). *The mask of sanity* (5th ed.). St. Louis, MO: Mosby.
- Clements, C. B. (1999). Psychology, attitude shifts, and prison growth. *American Psychologist*, 54, 785-786.
- Cloninger, C. R., Przybeck, T. R., & Svrakis, D. M. (1991). The Tridimensional Personality Questionnaire: U.S. normative data. *Psychological Reports*, 69, 1047-1057.
- Code of Fair Testing Practices in Education. (1988). Washington, DC: Joint Committee on Testing Practices.
- Coggins, M. H., Pynchon, M. R., & Dvoskin, J. A. (1998). Integrating research and practice in federal law enforcement: Secret Service applications of behavioral science expertise to protect the president. *Behavioral Sciences and the Law*, 16, 51-70.
- Cohen, B. M., Moses, J. L., & Byham, W. C. (1977). *The validity of assessment centers: A literature review* (rev. ed.; monograph no. 2). Pittsburgh, PA: Development Dimensions.
- Cohen, F., & Lazarus, R. S. (1973). Active coping processes, coping dispositions, and recovery from surgery. *Psychosomatic Medicine*, 35, 375-389.
- Cohen, J. (1952a). A factor-analytically based rationale for the Wechsler-Bellevue. *Journal of Consulting Psychology*, 16, 272-277.
- Cohen, J. (1952b). Factors underlying Wechsler-Bellevue performance of three neuropsychiatric groups. *Journal of Abnormal and School Psychology*, 47, 359-364.
- Cohen, J. (1957a). The factorial structure of the WAIS between early adulthood and old age. *Journal of Consulting Psychology*, 21, 283-290.
- Cohen, J. (1957b). A factor-analytically based rationale for the Wechsler Adult Intelligence Scale. *Journal of Consulting Psychology*, 21, 451-457.
- Cohen, O., Fischgrund, J., & Redding, R. (1990). Deaf children from ethnic, linguistic, and racial minority backgrounds: An overview. *American Annals of the Deaf*, 135, 67-73.
- Cohen, R. J. (1977). Socially reinforced obsessing: A reply. *Journal of Consulting and Clinical Psychology*, 45, 1166-1171.
- Cohen, R. J. (1979). *Malpractice: A guide for mental health professionals*. New York: Free Press.
- Cohen, R. J. (1985). Computer-enhanced qualitative research. *Journal of Advertising Research*, 25(3), 48-52.

- Cohen, R. J. (1987). Overview of emerging evaluative and diagnostic methods technologies. En *Proceedings of the fourth annual Advertising Research Foundation workshop: Broadening the horizons of copy research*. New York: Advertising Research Foundation.
- Cohen, R. J. (1994). *Psychology & adjustment: Values, culture, and change*. Boston: Allyn & Bacon.
- Cohen, R. J. (1999a). *Exercises in psychological testing and assessment*. Mountain View, CA: Mayfield.
- Cohen, R. J. (1999b). What qualitative research can be. *Psychology & Marketing*, 16, 351-368.
- Cohen, R. J. (2001). *Discussion of Organizational Culture (DOC)*. Jamaica, NY: Author.
- Cohen, R. J. (2005). *Exercises in psychological testing and assessment*. San Francisco: McGraw-Hill.
- Cohen, R. J., Becker, R. E., & Teevan, R. C. (1975). Perceived somatic reaction to stress and hostile press. *Psychological Reports*, 37, 676-678.
- Cohen, R. J., & Houston, D. R. (1975). Fear of failure and rigidity in problem solving. *Perceptual and Motor Skills*, 40, 930.
- Cohen, R. J., Montague, P., Nathanson, L. S., & Swerdlik, M. E. (1988). *Psychological testing: An introduction to tests and measurement*. Mountain View, CA: Mayfield.
- Cohen, R. J., & Parker, C. (1974). Fear of failure and death. *Psychological Reports*, 34, 54.
- Cohen, R. J., & Smith, F. J. (1976). Socially reinforced obsessing: Etiology of a disorder in a Christian Scientist. *Journal of Consulting and Clinical Psychology*, 44, 142-144.
- Cohen, R. J., & Teevan, R. C. (1974). Fear of failure and impression management: An exploratory study. *Psychological Reports*, 35, 1332.
- Cohen, R. J., & Teevan, R. C. (1975). Philosophies of human nature and hostile press. *Psychological Reports*, 37, 460-462.
- Cohen, S., Nermelstein, R., Karmack, T., & Hoberman, H. (1985). Measuring the functional components of social support. In I. G. Sarason & B. Sarason (eds.), *Social support: Theory, research, and practice* (pp. 73-94). Dordrecht, Netherlands: Martinus Nijhoff.
- Cole, S. T., & Hunter, M. (1971). Pattern analysis of WISC scores achieved by culturally disadvantaged children. *Psychological Reports*, 20, 191-194.
- Collins, J. K., Jupp, J. J., Maberly, G. F., et al. (1987). An exploratory study of the intellectual functioning of neurological and myxoedematous cretins in China. *Australia & New Zealand Journal of Developmental Disabilities*, 13, 13-20.
- Collins, L. M. (1996). Is reliability obsolete? A commentary on "Are simple gain scores obsolete?" *Applied Psychological Measurement*, 20, 289-292.
- Collins, M. (1998, Spring). Great expectations: What students have to say about the process and practice of launching a career. *Journal of Career Planning and Placement*, 41-47.
- Comer, D. R. (1993). Workplace drug testing reconsidered. *Journal of Managerial Issues*, 5, 517-531.
- Commons, M. (1985, April). How novelty produces continuity in cognitive development within a domain and accounts for unequal development across domains. Toronto: SRCD, Ontario, Canada.
- Compton, D. M., Bachman, L. D., Brand, D., & Avet, T. L. (2000). Age-associated changes in cognitive function in highly educated adults: Emerging myths and realities. *International Journal of Geriatric Psychiatry*, 15, 75-85.
- Comrey, A. L. (1992). *A first course in factor analysis*. Hillsdale, NJ: Erlbaum.
- Cone, J. D. (1977). The relevance of reliability and validity for behavioral assessment. *Behavior Therapy*, 8, 411-426.
- Cone, J. D. (1981). Psychometric considerations. En M. Hersen & A. S. Bellack (eds.), *Behavioral assessment: A practical handbook* (2nd ed.). New York: Pergamon.
- Cone, J. D. (1986). Idiographic, nomothetic, and related perspectives in behavioral assessment. En R. O. Nelson & S. C. Hayes (eds.), *Conceptual foundations of behavioral assessment*. New York: Guilford.
- Cone, J. D. (1987). Behavioral assessment: Some things old, some things new, some things borrowed? *Behavioral Assessment*, 9, 1-4.
- Cone, J. D. (1999). Introduction to the special section on self-monitoring: A major assessment method in clinical psychology. *Psychological Assessment*, 11, 411-414.
- Conger, A. J. (1985). Kappa reliabilities for continuing behaviors and events. *Educational and Psychological Measurement*, 45, 861-868.
- Connolly, J. (1976). Life events before myocardial infarction. *Journal of Human Stress*, 3, 3-17.
- Conte, J. M., & Jacobs, R. R. (2003). Validity evidence linking polychronicity and Big Five personality dimensions to absence, lateness, and supervisory performance ratings. *Human Performance*, 16, 107-129.
- Cooke, N. J., Salas, E., Cannon-Bowers, J. A., & Stout, R. J. (2000). Measuring team knowledge. *Human Factors*, 42, 151-173.
- Cooper, A. (1981). A basic TAT set for adolescent males. *Journal of Clinical Psychology*, 37(2), 411-414.
- Copas, J. B., & Tarling, R. (1986). Some methodological issues in making predictions. En A. Blumstein et al. (eds.), *Criminal careers and "career criminals"* (pp. 291-313). Washington, DC: National Academy.
- Corish, C. D., Richard, B., & Brown, S. (1989). Missed medication doses in rheumatoid arthritis patients: Intentional and unintentional reasons. *Arthritis Care and Research*, 2, 3-9.
- Cornell, D. G. (1985). External validation of the Personality Inventory for Children—Comment on Lachar, Gdowski, and Snyder. *Journal of Consulting and Clinical Psychology*, 53, 273-274.
- Corwyn, R. F., & Benda, B. B. (2000). Religiosity and church attendance: The effects on use of "hard drugs" controlling for sociodemographic and theoretical factors. *International Journal for the Psychology of Religion*, 10, 241-258.
- Costa, P. T., Jr., & McCrae, R. R. (1985). *The NEO Personality Inventory manual*. Odessa, FL: Psychological Assessment Resources.
- Costa, P. T., Jr., & McCrae, R. R. (1986). Major contributions to personality psychology. En S. Modgil & C. Modgil (eds.), *Hans Eysenck: Consensus and controversy* (pp. 63-72, 86, 87). Barcombe Lewes, Sussex, England: Falmer.
- Costa, P. T., Jr., & McCrae, R. R. (1987). On the need for longitudinal evidence and multiple measures in behavior-genetics studies of adult personality. *Behavioral and Brain Sciences*, 10, 22-23.
- Costa, P. T., Jr., & McCrae, R. R. (1992a). Four ways five factors are basic. *Personality and Individual Differences*, 13, 653-665.
- Costa, P. T., Jr., & McCrae, R. R. (1992b). Reply to Eysenck. *Personality and Individual Differences*, 13, 861-865.
- Costa, P. T., Jr., & McCrae, R. R. (1992c). *Revised NEO Personality Inventory (NEO-PI-R) and NEO Five-Factor Inventory (NEO-FFI) professional manual*. Odessa, FL: Psychological Assessment Resources.
- Costa, P. T., Jr., & McCrae, R. R. (1997). Stability and change in personality assessment: The Revised NEO Personality Inventory in the year 2000. *Journal of Personality Assessment*, 68, 86-94.
- Cote, J. A., McCullough, J., & Reilly, M. (1985). Effects of unexpected situations on behavior-intention differences: A garbology analysis. *Journal of Consumer Research*, 12, 188-194.

- Cotton, P. (1992). Women's health initiative leads way as research begins to fill gender gaps. *Journal of the American Medical Association*, 267(4), 469-470, 473.
- Coyne, J. C. (1976). The place of informed consent in ethical dilemmas. *Journal of Consulting and Clinical Psychology*, 44, 1015-1017.
- Cramer, P. (1991). *The development of defense mechanisms: Theory, research, and assessment*. New York: Springer-Verlag.
- Cramer, P. (1996). *Storytelling, narrative, and the Thematic Apperception Test*. New York: Guilford.
- Crèvecoeur, M. G. St. J. de (1951). What is an American letter? En H. S. Commager (ed.), *Living ideas in America*. New York: Harper. (Originally published in *Letters from an American farmer*, 1762)
- Crick, N. R. (1997). Engagement in gender normative versus nonnormative forms of aggression: Links to social-psychological adjustment. *Developmental Psychology*, 33, 610-617.
- Crick, N. R., Bigbee, M. A., & Howes, C. (1996). Gender differences in children's normative beliefs about aggression: How do I hurt thee? Let me count the ways. *Child Development*, 67, 1003-1014.
- Crocker, L., Llabre, M., & Miller, M. D. (1988). The generalizability of content validity ratings. *Journal of Educational Measurement*, 25, 287-299.
- Cronbach, L. J. (1949). Statistical methods applied to Rorschach scores: A review. *Psychological Bulletin*, 46, 393-429.
- Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika*, 16, 297-334.
- Cronbach, L. J. (1970). *Essentials of psychological testing* (3rd ed.). New York: Harper & Row.
- Cronbach, L. J. (1975). Five decades of public controversy over mental testing. *American Psychologist*, 30, 1-13.
- Cronbach, L. J. (1984). *Essentials of psychological testing* (4th ed.). New York: Harper & Row.
- Cronbach, L. J., & Gleser, G. C. (1957). *Psychological tests and personnel decisions*. Champaign, IL: University of Illinois.
- Cronbach, L. J., & Gleser, G. C. (1965). *Psychological tests and personnel decisions* (2nd ed.). Urbana: University of Illinois.
- Cronbach, L. J., Gleser, G. C., Nanda, H., & Rajaratnam, N. (1972). *The dependability of behavioral measurement: Theory of generalizability for scores and profiles*. New York: Wiley.
- Crosby, F. J., Iyer, A., Clayton, S., & Downing, R. A. (2003). Affirmative action: Psychological data and the policy debates. *American Psychologist*, 58, 93-115.
- Cross, T. L., Coleman, L. J., & Stewart, R. A. (1993). The social cognition of gifted adolescents: An exploration of the stigma of the giftedness paradigm. *Roeper Review*, 16, 37-40.
- Cross, T. L., Coleman, L. J., & Terhaar-Yonkers, M. (1991). The social cognition of gifted adolescents in schools: Managing the stigma of giftedness. *Journal for the Education of the Gifted*, 15, 44-55.
- Crowne, D. P., & Marlowe, D. (1964). *The approval motive: Studies in evaluative dependence*. New York: Wiley.
- Crundall, D. E., Underwood, G., & Chapman, P. R. (1998). How much do drivers see? The effects of demand on visual search strategies in novice and experienced drivers. En G. Underwood (ed.), *Eye guidance in reading and scene perception* (pp. 395-417). Oxford, England: Elsevier.
- Cuellar, L., Harris, I. C., & Jasso, R. (1980). An acculturation scale for Mexican American normal and clinical populations. *Hispanic Journal of Behavioral Science*, 2, 199-217.
- Cundick, B. P. (1976). Measures of intelligence on Southwest Indian students. *Journal of Social Psychology*, 81, 151-156.
- Cunningham, M. R. (1988). What do you do when you're happy or blue? Mood, expectancies, and behavioral interests. *Motivation and Emotion*, 12, 309-331.
- Cureton, E. E. (1957). The upper and lower twenty-seven percent rule. *Psychometrika*, 22, 293-296.
- Cushman, P., & Guilford, P. (2000). Will managed care change our way of being? *American Psychologist*, 55, 985-996.
- Dahlstrom, W. G. (1995). Pigeons, people, and pigeon holes. *Journal of Personality Assessment*, 64, 2-20.
- Dahlstrom, W. G., & Dahlstrom, L. E. (eds.). (1980). *Basic readings on the MMPI: A new selection on personality measurement*. Minneapolis: University of Minnesota.
- Dahlstrom, W. G., & Welsh, G. S. (1960). *An MMPI handbook: A guide to use in clinical practice and research*. Minneapolis: University of Minnesota.
- Dahlstrom, W. G., Welsh, G. S., & Dahlstrom, L. E. (1972). *An MMPI handbook: Vol. 1. Clinical interpretation*. Minneapolis: University of Minnesota.
- Daigneault, S., Braun, C. M. J., & Whitaker, H. A. (1992). Early effects of normal aging on perseverative and non-perseverative prefrontal measures. *Developmental Neuropsychology*, 8, 99-114.
- Dana, R. H. (1982). *A human science model for personality assessment with projective techniques*. Springfield, IL: Charles C Thomas.
- Dana, R. H. (1995). Culturally competent MMPI assessment of Hispanic populations. *Hispanic Journal of Behavioral Sciences*, 17, 305-319.
- Dana, R. H., Aguilar-Kitibutr, A., Diaz-Vivar, N., & Vetter, H. (2002). A teaching model for multicultural assessment: Psychological report contents and cultural competence. *Journal of Personality*, 79, 207-215.
- Dana, R. H., & Whatley, P. R. (1991). When does a difference make a difference? MMPI scores and African-Americans. *Journal of Clinical Psychology*, 47, 400-406.
- Daneman, M., & Carpenter, P. A. (1980). Individual differences in working memory and reading. *Journal of Verbal Learning and Verbal Behavior*, 19, 450-466.
- Danford, G. S., & Steinfeld, E. (1999). Measuring the influences of physical environments on the behaviors of people with impairments. En E. Steinfeld & G. S. Danford (eds.), *Enabling environments: Measuring the impact of environment on disability and rehabilitation* (pp. 111-137). New York: Kluwer Academic/Plenum.
- Daniels, K. (2000). Measures of five aspects of affective well-being at work. *Human Relations*, 53, 275-294.
- Darwin, C. (1859). *On the origin of species by means of natural selection*. London: Murray.
- Das, J. P. (1972). Patterns of cognitive ability in nonretarded and retarded children. *American Journal of Mental Deficiency*, 77, 6-12.
- Das, J. P., Kirby, J., & Jarman, R. F. (1975). Simultaneous and successive synthesis: An alternative model for cognitive abilities. *Psychological Bulletin*, 82, 87-103.
- Daubert v. Merrell Dow Pharmaceuticals*, 113 S. Ct. 2786 (1993).
- Dauids, A., & Murray, H. A. (1955). Preliminary appraisal of an auditory projective technique for studying personality and cognition. *American Journal of Orthopsychiatry*, 25, 543-554.
- Davidson, H. A. (1949). Malingered psychosis. *Bulletin of the Menninger Clinic*, 13, 157-163.
- Davidson, T. N., Bowden, L., & Tholen, D. (1979). Social support as a moderator of burn rehabilitation. *Archives of Physical Medicine and Rehabilitation*, 60, 556.
- Davies, M., Stankov, L., & Roberts, R. D. (1998). Emotional intelligence: In search of an elusive construct. *Journal of Personality and Social Psychology*, 75, 989-1015.
- Davies, P. L., & Gavin, W. J. (1994). Comparison of individual and group/consultation treatment methods for preschool children with developmental delays. *American Journal of Occupational Therapy*, 48, 155-161.

- Davis, G. A. (1989). Testing for creative potential. *Contemporary Educational Psychology*, 14, 257-274.
- Davison, G. C., Vogel, R. S., & Coffman, S. G. (1997). Think-aloud approaches to cognitive assessment and the articulated thoughts in simulated situations paradigm. *Journal of Consulting and Clinical Psychology*, 65, 950-958.
- Dawes, R. M., Faust, D., & Meehl, P. E. (1989, March 31). Clinical versus actuarial judgment. *Science*, 243, 1668-1674.
- Day, D. V., & Silverman, S. B. (1989). Personality and job performance: Evidence of incremental validity. *Personnel Psychology*, 42, 25-36.
- Decker, J. T., Bailey, T. L., & Westergaard, N. (2002). Burnout among childcare workers. *Residential Treatment for Children & Youth*, 19(4), 61-77.
- Delahunty, R. J. (1988). Perspectives on within-group scoring. *Journal of Vocational Behavior*, 33, 463-477.
- Deloria, D. J. (1985). Review of the Miller Assessment for Preschoolers. In J. V. Mitchell, Jr. (ed.), *The ninth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- DeMulder, E. K., Denham, S., Schmidt, M., & Mitchell, J. (2000). Q-sort assessment of attachment security during the preschool years: Links from home to school. *Developmental Psychology*, 36, 274-282.
- Dennis, W., & Dennis, M. G. (1940). The effect of cradling practice upon the onset of walking in Hopi children. *Journal of Genetic Psychology*, 56, 77-86.
- Department of Health, Education, and Welfare. (1977a). Nondiscrimination on basis of handicap: Implementation of Section 504 of the Rehabilitation Act of 1973. *Federal Register*, 42(86), 22676-22702.
- Department of Health, Education, and Welfare. (1977b). Education of Handicapped Children: Implementation of Part B of the Education of the Handicapped Act. *Federal Register*, 42(163), 42474-42518.
- DePaulo, B. M. (1994). Spotting lies: Can humans learn to do better? *Current Directions in Psychological Science*, 3, 83-86.
- Desrochers, M. N., Hile, M. G., & Williams-Mosely, T. L. (1997). Survey of functional assessment procedures used with individuals who display mental retardation and severe problem behaviors. *American Journal on Mental Retardation*, 101, 535-546.
- Detterman, D. K. (1986). Qualitative integration: The last word? In R. J. Sternberg & D. K. Detterman (eds.), *What is intelligence?* (pp. 163-166). Norwood, NJ: Ablex.
- Devlin, B., Daniels, M., & Roeder, K. (1997). The heritability of IQ. *Nature*, 388, 468-471.
- Diamond, B. L. (1980). Inherent problems in the use of pretrial hypnosis on a prospective witness. *California Law Review*, 68, 313-349.
- Dickson, C. R. (1975). Role of assessment in behavior therapy. In P. McReynolds (ed.), *Advances in psychological assessment* (Vol. 3). San Francisco: Jossey-Bass.
- Diebold, M. H., Curtis, W. S., & DuBose, R. F. (1978). Developmental scales versus observational measures for deaf-blind children. *Exceptional Children*, 44, 275-278.
- Dietz, P. E., Matthews, D. B., Van Duyne, C., et al. (1991). Threatening and otherwise inappropriate letters to Hollywood celebrities. *Journal of Forensic Sciences*, 36, 185-209.
- Dimock, P. H., & Cormier, P. (1991). The effects of format differences and computer experience on performance and anxiety on a computer-administered test. *Measurement and Evaluation in Counseling and Development*, 24, 119-126.
- Dion, K. K. (1979). Physical attractiveness and evaluation of children's transgressions. *Journal of Personality and Social Psychology*, 24, 207-213.
- Dipboye, R. L. (1992). *Selection interviews: Process perspectives*. Cincinnati, OH: South-Western Publishing.
- Diven, K. (1937). Certain determinants in the conditioning of anxiety reactions. *Journal of Psychology*, 3, 291-308.
- Dixon, M., Wang, S., Calvin, J., et al. (2002). The panel interview: A review of empirical research and guidelines for practice. *Public Personnel Management*, 31, 397-428.
- Dohrenwend, B. P., & Shrout, P. E. (1985). Hassles in the conceptualization and measurement of life stresses variables. *American Psychologist*, 40, 780-785.
- Doll, E. A. (1917). A brief Binet-Simon scale. *Psychological Clinic*, 11, 197-211, 254-261.
- Doll, E. A. (1953). *Measurement of social competence: A manual for the Vineland Social Maturity Scale*. Circle Pines, MN: American Guidance Service.
- Dolnick, E. (1993). Deafness as culture. *Atlantic*, 272(3), 37-53.
- Donahue, E. M., Robins, R. W., Roberts, B. W., & John, O. P. (1993). The divided self: Concurrent and longitudinal effects of psychological adjustment and social roles on self-concept differentiation. *Journal of Personality and Social Psychology*, 64, 834-846.
- Donders, J. (1992). Validity of the Kaufman Assessment Battery for Children when employed with children with traumatic brain injury. *Journal of Clinical Psychology*, 48, 225-230.
- Dosajh, N. L. (1996). Projective techniques with particular reference to inkblot tests. *Journal of Projective Psychology and Mental Health*, 3, 59-68.
- Doty, R. L., Shaman, P., & Dann, M. (1984). Development of the University of Pennsylvania Smell Identification Test: A standard microencapsulated test of olfactory dysfunction. *Physiological Behavior*, 32, 489-502.
- Dougherty, T. M., & Haith, M. M. (1997). Infant expectations and reaction time as predictors of childhood speed of processing and IQ. *Developmental Psychology*, 33, 146-155.
- Douglas, C. (1993). *Translate this darkness: The life of Christiana Morgan*. New York: Simon & Schuster.
- Draguns, J. G. (1984). Assessing mental health and disorder across cultures. In P. Pedersen, N. Sartorius, & A. J. Marsella (eds.), *Mental health services: The cross-cultural context* (pp. 31-57). Beverly Hills, CA: Sage.
- Drasgow, F., & Olson-Buchanan, J. B. (eds.). (1999). *Innovations in computerized assessment*. Mahwah, NJ: Erlbaum.
- Dreger, R. M., & Miller, K. S. (1960). Comparative studies of Negroes and Whites in the U.S. *Psychological Bulletin*, 51, 361-402.
- Drinkwater, M. J. (1976). Psychological evaluation of visually handicapped children. *Massachusetts School Psychologists Association Newsletter*, 6.
- Drotar, D., Olness, K., & Wiznitzer, M., et al. (1999). Neurodevelopmental outcomes of Ugandan infants with HIV infection: An application of growth curve analysis. *Health Psychology*, 18, 114-121.
- DuBois, P. H. (1966). A test-dominated society: China 1115 B.C.-1905 A.D. In A. Anastasi (ed.), *Testing problems in perspective* (pp. 29-36). Washington, DC: American Council on Education.
- DuBois, P. H. (1970). *A history of psychological testing*. Boston: Allyn & Bacon.
- Ducharme, F., Levesque, L., Gendron, M., & Legault, A. (2001). Development process and qualitative evaluation of a program to promote the mental health of family caregivers. *Clinical Nursing Research*, 10, 182-201.
- Duchek, J. M., Hunt, L., Ball, K., et al. (1998). Attention and driving performance in Alzheimer's disease. *Journal of Gerontology: Series B: Psychological Science & Social Sciences*, 53B(2), 130-141.

- Duclos, C. W. (1999). Factors associated with alcohol, drug, and mental health service utilization among a sample of American Indian adolescent detainees. *Dissertation Abstracts International, Section B: The Sciences & Engineering*, 40(4-B), 1524.
- Dudycha, G. J. (1936). An objective study of punctuality in relation to personality and achievement. *Archives of Psychology*, 204, 1-319.
- Dugdale, R. (1877). *The Jukes: A study in crime, pauperism, disease, and heredity*. New York: Putnam.
- Duncker, K. (1945). On problem solving. *Psychological Monographs*, 5, 1-13.
- Dunham, R. B., Grube, J. A., & Castaneda, M. B. (1994). Organizational commitment: The utility of an integrative definition. *Journal of Applied Psychology*, 79, 370-380.
- Dunn, L. M., & Dunn, L. M. (1997). *Examiner's manual for the PPVT-III, Peabody Picture Vocabulary Test, Third Edition*. Circle Pines, MN: American Guidance Service.
- Dwyer, C. A. (1996). Cut scores and testing: Statistics, judgment, truth, and error. *Psychological Assessment*, 8, 360-362.
- Dykes, L. (1986). The whiplash shaken infant syndrome: What has been learned? *Child Abuse and Neglect*, 10, 211.
- Dywan, J., & Bowers, K. (1983). The use of hypnosis to enhance recall. *Science*, 22, 184-185.
- Earles, J. A., & Ree, M. J. (1992). The predictive validity of the ASVAB for training grades. *Educational and Psychological Measurement*, 52, 721-725.
- Early, P. C., Gibson, C. B., & Chen, C. C. (1999). "How did I do?" versus "How did we do?": Cultural contrasts of performance feedback use and self-efficacy. *Journal of Cross-Cultural Psychology*, 30, 594-619.
- Eccles, J. S. (1987). Gender roles and women's achievement-related decisions. *Psychology of Women Quarterly*, 11, 135-171.
- Edwards, A. L. (1953). *Edwards Personal Preference Schedule*. New York: Psychological Corporation.
- Edwards, A. L. (1957a). *Techniques of attitude scale construction*. New York: Appleton-Century-Crofts.
- Edwards, A. L. (1957b). *The social desirability variable in personality assessment and research*. New York: Dryden.
- Edwards, A. L. (1966). Relationship between probability of endorsement and social desirability scale value for a set of 2,824 personality statements. *Journal of Applied Psychology*, 50, 238-239.
- Edwards, A. L., & Walsh, J. A. (1964). Response sets in standard and experimental personality scales. *American Education Research Journal*, 1, 52-60.
- Edwards, C. P., & Kumru, A. (1999). Culturally sensitive assessment. *Child and Adolescent Psychiatric Clinics of North America*, 8, 409-424.
- Eichler, R. M. (1951). A comparison of the Rorschach and Behn-Rorschach inkblot tests. *Journal of Consulting Psychology*, 15, 185-189.
- Eisenberg, N., Guthrie, I. K., Cumberland, A., et al. (2002). Prosocial development in early adulthood: A longitudinal study. *Journal of Personality & Social Psychology*, 82, 993-1006.
- Eisman, E. J., Dies, R. R., Finn, S. E., et al. (2000). Problems and limitations in using psychological assessment in the contemporary health care delivery system. *Professional Psychology: Research and Practice*, 31, 131-140.
- Elder, G. H., Van Nguyen, T., & Caspi, A. (1985). Linking family hardship to children's lives. *Child Development*, 56, 361-375.
- Eldredge, N. (1993). Culturally affirmative counseling with American Indians who are deaf. *Journal of the American Deafness and Rehabilitation Association*, 26, 1-18.
- Elksnin, L. K., & Elksnin, N. (1993). A review of picture interest inventories: Implications for vocational assessment of students with disabilities. *Journal of Psychoeducational Assessment*, 11, 323-336.
- Ellerstein, N. S. (ed.). (1981). *Child abuse and neglect: A medical reference*. New York: Wiley.
- Elliot, H., Glass, L., & Evans, J. (eds.). (1987). *Mental health assessment of deaf clients: A practical manual*. Boston: Little, Brown.
- Elliott, A. N., O'Donohue, W. T., & Nickerson, M. A. (1993). The use of sexually anatomically detailed dolls in the assessment of sexual abuse. *Clinical Psychology Review*, 13, 207-221.
- Elliott, C. D. (1990a). *The Differential Ability Scales*. San Antonio, TX: Psychological Corporation.
- Elliott, C. D. (1990b). *Technical handbook: The Differential Ability Scales*. San Antonio, TX: Psychological Corporation.
- Elliott, S. N. (1988). Acceptability of behavioral treatments in educational settings. In J. C. Witt, S. N. Elliott, & F. M. Greshma (eds.), *The handbook of behavior therapy education* (pp. 121-150). New York: Plenum.
- Elliott, S. N., Katochwill, T. R., & McKeivitt, B. C. (2001). Experimental analysis of the effects of testing accommodations on the scores of students with and without disabilities. *Journal of School Psychology*, 39, 3-24.
- Elliott, T. R., & Carroll, M. N. (1997). Issues in psychological assessment for rehabilitation services. Paper presented at the annual convention of the American Psychological Association, August, Chicago.
- Embretson, S. E. (1996). The new rules of measurement. *Psychological Assessment*, 8, 341-349.
- Endicott, J., & Spitzer, R. L. (1978). A diagnostic interview: The Schedule for Affective Disorders and Schizophrenia. *Archives of General Psychiatry*, 35, 837-844.
- Engin, A., Wallbrown, F., & Brown, D. (1976). The dimensions of reading attitude for children in the intermediate grades. *Psychology in the Schools*, 13(3), 309-316.
- Epstein, J. L., & McPartland, J. M. (1978). *The Quality of School Life Scale administration and technical manual*. Boston: Houghton Mifflin.
- Epstein, N., Baldwin, L., & Bishop, S. (1983). The McMaster Family Assessment Device. *Journal of Marital and Family Therapy*, 9, 171-180.
- Erdelyi, M. H. (1974). A new look at the new look: Perceptual defense and vigilance. *Psychological Review*, 81, 1-25.
- Evan, W. M., & Miller, J. R. (1969). Differential effects of response bias of computer vs. conventional administration of a social science questionnaire. *Behavioral Science*, 14, 216-227.
- Evans, J. D., et al. (2000). Cross-cultural applications of the Halstead-Reitan batteries. In E. Fletcher-Janzen et al. (eds.), *Handbook of cross-cultural neuropsychology* (pp. 287-303). New York: Kluwer Academic/Plenum.
- Evans, M. (1978). Unbiased assessment of locally low incidence handicapped children. *IRRC practitioners talk to practitioners*. Springfield, IL: Illinois Regional Resource Center.
- Evers, W., Tomic, W., & Brouwers, A. (2002). Aggressive behavior and burnout among staff of homes for the elderly. *International Journal of Mental Health Nursing*, 11, 2-9.
- Exner, J. E. (1962). A comparison of human figure drawings of psychoneurotics, character disturbances, normals, and subjects experiencing experimentally induced fears. *Journal of Projective Techniques*, 26, 292-317.
- Exner, J. E. (1969). *The Rorschach systems*. New York: Grune & Stratton.
- Exner, J. E. (1974). *The Rorschach: A comprehensive system*. New York: Wiley.
- Exner, J. E. (1978). *The Rorschach: A comprehensive system: Vol. 2. Current research and advanced interpretations*. New York: Wiley-Interscience.

- Exner, J. E. (1983). Rorschach assessment. En I. B. Weiner (ed.), *Methods in clinical psychology* (2nd ed.). New York: Wiley.
- Exner, J. E. (1986). *The Rorschach: A comprehensive system: Vol. 1. Basic foundations* (2nd ed.). New York: Wiley.
- Exner, J. E. (1989). Searching for projection in the Rorschach. *Journal of Personality Assessment*, 53, 520-536.
- Exner, J. E. (1990). *Workbook for the comprehensive system* (3rd ed.). Asheville, NC: Rorschach Workshops.
- Exner, J. E. (1993). *The Rorschach: A comprehensive system: Vol. 2. Interpretations*. New York: Wiley.
- Exner, J. E., Jr. (1991). *The Rorschach: A comprehensive system: Vol. 2. Interpretation* (2nd ed.). New York: Wiley.
- Exner, J. E., Jr. (1993). *The Rorschach: A comprehensive system: Vol. 1. Basic foundations* (3rd ed.). New York: Wiley.
- Exner, J. E., Jr. (1997). Critical bits and the Rorschach response process. *Journal of Personality Assessment*, 67, 464-477.
- Exner, J. E., & Weiner, I. B. (1982). *The Rorschach: A comprehensive system: Vol. 3. Assessment of children and adolescents*. New York: Wiley.
- Exner, J. E., & Weiner, I. B. (1995). *The Rorschach: A comprehensive system: Vol. 3. Assessment of children and adolescents* (2nd ed.). New York: Wiley.
- Eyde, L. D., Kowal, D. M., & Fishburne, F. J., Jr. (1990). The validity of computer-based test interpretations of the MMPI. In S. Wise & T. B. Gutkin (eds.), *The computer as adjunct to the decision-making process*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Eyde, L. D., Moreland, K. L., Robertson, G. J., Primoff, E. S., & Most, R. B. (1988). Test user qualifications: A data-based approach to promoting good test use. *Issues in Scientific Psychology: Report of the Test User Qualifications Working Group of the Joint Committee on Testing Practices*. Washington, DC: American Psychological Association.
- Eyman, J. R., & Eyman, S. K. (1990). Suicide risk and assessment instruments. In P. Cimbolic & D. A. Jobes (eds.), *Youth suicide: Issues, assessment, and intervention* (pp. 9-32). Springfield, IL: Charles C Thomas.
- Eysenck, H. J. (1961). The effects of psychotherapy. In H. J. Eysenck (ed.), *Handbook of abnormal psychology: An experimental approach* (pp. 697-725). New York: Basic.
- Eysenck, H. J. (1967). Intelligence assessment: A theoretical and experimental approach. *British Journal of Educational Psychology*, 37, 81-98.
- Eysenck, H. J. (1985). Can personality study ever be scientific? *Journal of Social Behavior and Personality*, 1, 3-19.
- Eysenck, H. J. (1991). Dimensions of personality: 16, 5, or 3? —Criteria for a taxonomic paradigm. *Personality and Individual Differences*, 12, 773-790.
- Faigman, D. L. (1995). The evidentiary status of social science under Daubert: Is it "scientific," "technical," or "other" knowledge? *Psychology, Public Policy, and Law*, 1, 960-979.
- Faller, K. C. (1988). *Child sexual abuse*. New York: Columbia University.
- Farrell, A. D. (1986). The microcomputer as a tool for behavioral assessment. *Behavior Therapist*, 1, 16-17.
- Farrell, J. N., & McDaniel, M. A. (2001). The stability of validity coefficients over time: Ackerman's (1988) model and the General Aptitude Test Battery. *Journal of Applied Psychology*, 86, 60-79.
- Farrenkopf, T., & Bryan, J. (1999). Psychological consultation under Oregon's 1994 Death With Dignity Act: Ethics and procedures. *Professional Psychology: Research and Practice*, 30, 245-249.
- Faust, D. S., & Ziskin, J. (1988a). The expert witness in psychology and psychiatry. *Science*, 241, 31-35.
- Faust, D. S., & Ziskin, J. (1988b). Response to Fowler and Matarrazo. *Science*, 242, 1143-1144.
- Federal Rules of Evidence. (1975). Eagan, MN: West Group Publishing.
- Feinstein, A. R., Josephy, B. R., & Wells, C. K. (1986). Scientific and clinical problems in indexes of functional disability. *Annals of Internal Medicine*, 105, 413-520.
- Felce, D. (1997). Defining and applying the concept of quality of life. *Journal of Intellectual and Research*, 41, 126-135.
- Feldman, L. B., & Rivas-Vazquez, R. (2003). Assessment and treatment of social anxiety disorder. *Professional Psychology: Research and Practice*, 34, 396-405.
- Fenn, D. S., & Ganzini, L. (1999). Attitudes of Oregon psychologists toward physician-assisted suicide and the Oregon Death With Dignity Act. *Professional Psychology: Research and Practice*, 30, 235-244.
- Ferguson, R. L., & Novick, M. R. (1973). Implementation of a Bayesian system for decision analysis in a program of individually prescribed instruction. *ACT Research Report*, Number 60.
- Field, T. M., & Vega-Lahr, N. (1984). Early interactions between infants with cranio-facial anomalies and their mothers. *Infant Behavior and Development*, 7, 527-530.
- Filsinger, E. (1983). A machine-aided marital observation technique: The Dyadic Interaction Scoring Code. *Journal of Marriage and the Family*, 2, 623-632.
- Finding information about psychological tests. (1995). Washington, DC: American Psychological Association, Science Directorate.
- Finkelhor, D., & Dziuba-Leatherman, J. (1994). Victimization of children. *American Psychologist*, 49, 173-183.
- Finn, S. E. (1996). *Using the MMPI-2 as a therapeutic intervention*. Minneapolis: University of Minnesota Press.
- Finn, S. E. (2003). Therapeutic assessment of a man with "ADD." *Journal of Personality Assessment*, 80, 115-129.
- Finn, S. E., & Martin, H. (1997). Therapeutic assessment with the MMPI-2 in managed health care. En J. N. Butcher (ed.), *Objective psychological assessment in managed health care: A practitioner's guide* (pp. 131-152). New York: Oxford University Press.
- Finn, S. E., & Tonsager, M. E. (2002). How therapeutic assessment became humanistic. *Humanistic Psychologist*, 30(1-2), 10-22.
- Fischer, C. T. (1978). Collaborative psychological assessment. In C. T. Fischer & S. L. Brodsky (eds.), *Client participation in human services: The Prometheus principle* (pp. 41-61). New Brunswick, NJ: Transaction.
- Fischer, C. T. (1994). *Individualizing psychological assessment*. Hillsdale, NJ: Erlbaum.
- Fischer, C. T. (2004). In what sense is collaborative psychological assessment collaborative? Some distinctions. *SPA Exchange*, 16(1), 14-15.
- Fischer, H. (1999). Exemptions from child abuse reporting. *American Psychologist*, 54, 145.
- Fisher, R. P., & Geiselman, R. E. (1992). *Memory-enhancing techniques for investigative interviewing*. Springfield, IL: Charles C Thomas.
- Fisher, R. P., Geiselman, R. E., & Amador, M. (1989). Field test of the cognitive interview: Enhancing the recollection of actual victims and witnesses of crime. *Journal of Applied Psychology*, 74, 722-727.
- Fisher, R. P., Geiselman, R. E., Raymond, D. S., et al. (1987). Enhancing enhanced eyewitness memory: Refining the cognitive interview. *Journal of Police Science & Administration*, 15, 291-297.
- Fiske, D. W. (1967). The subjects react to tests. *American Psychologist*, 22, 287-296.
- Fitts, W. H. (1965). *Manual for the Tennessee Self-Concept Scale*. Nashville: Counselor Recordings and Tests.

- Fitzgibbons, D. J., & Shearn, C. R. (1972). Concepts of schizophrenia among mental health professionals: A factor-analytic study. *Journal of Consulting and Clinical Psychology*, 38, 288-295.
- Flanagan, D. P., & McGrew, K. S. (1997). A cross-battery approach to assessing and interpreting cognitive abilities: Narrowing the gap between practice and cognitive science. In D. P. Flanagan, J. L. Genshaft, & P. L. Harrison (eds.), *Contemporary intellectual assessment: Theories, tests, and issues* (pp. 314-325). New York: Guilford.
- Flanagan, J. C. (1938). Review of *Measuring Intelligence* by Terman and Merrill. *Harvard Educational Review*, 8, 130-133.
- Flanagan, J. C., & Burns, R. K. (1955). The employee business record: A new appraisal and development tool. *Harvard Business Review*, 33(5), 99-102.
- Flowers, J. H. (1982). Some simple Apple II software for the collection and analysis of observational data. *Behavior Research Methods and Instrumentation*, 14, 241-249.
- Floyd, F. J., Haynes, S. N., Doll, E. R., et al. (1992). Assessing retirement satisfaction and perceptions of retirement experiences. *Psychology and Aging*, 7, 609-621.
- Floyd, F. J., & Widaman, K. F. (1995). Factor analysis in the development and refinement of clinical assessment instruments. *Psychological Assessment*, 7, 286-299.
- Floyd, R. G., Evans, J. J., & McGrew, K. S. (2003). Relations between measures of Cattell-Horn-Carroll (CHC) cognitive abilities and mathematics achievement across the school-age years. *Psychology in the Schools*, 40, 155-171.
- Flynn, J. R. (1984). The mean IQ of Americans: Massive gains 1932 to 1978. *Psychological Bulletin*, 95, 29-51.
- Flynn, J. R. (1988). Massive IQ gains in 14 nations: What IQ tests really measure. *Psychological Bulletin*, 101, 171-191.
- Flynn, J. R. (1991). *Asian-Americans: Achievement beyond IQ*. Hillsdale, NJ: Erlbaum.
- Flynn, J. R. (2000). The hidden history of IQ and special education: Can the problems be solved? *Psychology, Public Policy, and Law*, 6, 191-198.
- Foerster, L. M., & Little Soldier, D. (1974). Open education and native American values. *Educational Leadership*, 32, 41-45.
- Folstein, M. F., Folstein, S. E., & McHugh, P. R. (1975). "Mini-Mental State": A practical method for grading the cognitive state of patients for the clinician. *Journal of Psychiatric Research*, 12, 189-198.
- Fontana, V. J., Donovan, D., & Wong, R. J. (1963, December 8). The maltreatment syndrome in children. *New England Journal of Medicine*, 269, 1389-1394.
- Fontanna, D. (2000). *Personality in the workplace*. Lewiston, NY: Macmillan Press.
- Forer, B. R. (1949). The fallacy of personal validation: A classroom demonstration of gullibility. *Journal of Abnormal and Social Psychology*, 44, 118-123.
- Forrest, D. W. (1974). *Francis Galton: The life and works of a Victorian genius*. New York: Taplinger.
- Forth, A. E., Hart, S. D., & Hare, R. D. (1990). Assessment of psychopathy in male young offenders. *Psychological Assessment*, 2, 342-344.
- Foster, S. L., Laverty-Finch, C., Gizzo, D. P., & Osantowski, J. (1999). Practical issues in self-observation. *Psychological Assessment*, 11, 426-438.
- Fouad, N. A. (2002). Cross-cultural differences in vocational interests: Between-group differences on the Strong Interest Inventory. *Journal of Counseling Psychology*, 49, 282-289.
- Fouad, N. A., & Dancer, L. S. (1992). Cross-cultural structure of interests: Mexico and the United States. *Journal of Vocational Behavior*, 40, 129-143.
- Fowler, D. R., Finkelstein, A., & Penk, W. (1986). *Measuring treatment responses by computer interview*. Paper presented at the 94th annual meeting of the American Psychological Association, Washington, DC.
- Franco, J. N. (1983). An acculturation scale for Mexican-American children. *Journal of General Psychology*, 108, 175-181.
- Frank, E., & Brandstaetter, V. (2002). Approach versus avoidance: Different types of commitment in intimate relationships. *Journal of Personality & Social Psychology*, 82, 208-221.
- Frank, L. K. (1939). Projective methods for the study of personality. *Journal of Psychology*, 8, 389-413.
- Frank, M. G., Ekman, P., & Friesen, W. V. (1993). Behavioral markers and recognizability of the smile of enjoyment. *Journal of Personality and Social Psychology*, 64, 83-93.
- Frantz, D., & Nordheimer, J. (1997, September 28). Giant of exam business keeps quiet on cheating. *New York Times*, pp. A1, A32.
- Frederickson, B. L. (1998). What good are positive emotions? *Review of General Psychology*, 2, 300-319.
- Fredman, N., & Sherman, R. (1987). *Handbook of measurements for marriage & family therapy*. New York: Brunner/Mazel.
- Freeman, S. T. (1989). Cultural and linguistic bias in mental health evaluations of deaf people. *Rehabilitation Psychology*, 34, 51-63.
- French, C. C., & Beaumont, J. G. (1991). The Differential Aptitude Test (Language Usage and Spelling): A clinical study of a computerized form. *Current Psychology: Research and Reviews*, 10, 31-48.
- French, D. J., Gauthier, J. G., Roberge, C., et al. (1997). Self-efficacy in the thermal biofeedback treatment of migraine sufferers. *Behavior Therapy*, 28, 109-125.
- French, J. L. (ed.). (1964). *Educating the gifted*. New York: Holt, Rinehart & Winston.
- Freud, S. (1913/1959). Further recommendations in the technique of psychoanalysis. In E. Jones (ed.) and J. Riviere (Trans.), *Collected papers* (Vol. 2). New York: Basic.
- Freund, K. (1963). A laboratory method for diagnosing predominance of homosexual and heterosexual erotic interest in the male. *Behavior Research and Therapy*, 1, 85-93.
- Freund, K., Sedlacek, E., & Knob, K. (1965). A simple transducer for mechanical plethysmography of the male genital. *Journal of Experimental Analysis of Behavior*, 8, 169-170.
- Friedman, M., & Rosenman, R. H. (1974). *Type A behavior and your heart*. New York: Knopf.
- Friedrich, W. N., Urquiza, A. J., & Beike, R. (1986). Behavioral problems in sexually abused young children. *Journal of Pediatric Psychiatry*, 11, 47-57.
- Friedrich, W. N., Fisher, J. L., Dittner, C. A., et al. (2001). Child Sexual Behavior Inventory: Normative, psychiatric, and sexual abuse comparisons. *Child Maltreatment: Journal of the American Professional Society on the Abuse of Children*, 6, 37-49.
- Friel-Patti, S., & Finitzo, T. (1990). Language learning in a prospective study of otitis media with effusion in the first two years of life. *Journal of Speech and Hearing Research*, 33, 188-194.
- Frijda, N. H., & Mesquita, B. (1994). The social roles and functions of emotions. In S. Kitayama & H. R. Markus (eds.), *Emotion and Culture: Empirical studies of mutual influence* (pp. 51-87). Washington, DC: American Psychological Association.
- Frolik, L. A. (1999). Science, common sense, and the determination of mental capacity. *Psychology, Public Policy, and Law*, 5, 41-58.
- Frumkin, R. M. (1997). Significant neglected sociocultural and physical factors affecting intelligence. *American Psychologist*, 52, 76-77.
- Frye vs United States*, 293 Fed. 1013 (D.C. Cir. 1923).

- Fuchs, L. S., Fuchs, D., Eaton, S. B., *et al.* (2000). Using objective data sources to enhance teacher judgments about test accommodations. *Exceptional Children*, 67, 67-81.
- Fullan, M., & Loubser, J. (1972). Education and adaptive capacity. *Sociology of Education*, 45, 271-287.
- Fullard, W., McDevitt, S. C., & Carey, W. B. (1984). Assessing temperament in one- to three-year-old children. *Journal of Pediatric Psychology*, 9, 205-217.
- Furnham, A., Moutafi, J., & Crump, J. (2003). The relationship between the revised NEO-Personality Inventory and the Myers-Briggs Type Indicator. *Social Behavior & Personality*, 31, 577-584.
- Furnham, A., Petrides, K. V., Jackson, C. J., & Cotter, T. (2002). Do personality factors predict job satisfaction? *Personality & Individual Differences*, 33, 1325-1342.
- Furse, D. H., & Stewart, D. W. (1984). Manipulating dissonance to improve mail survey response. *Psychology & Marketing*, 1, 71-84.
- Gaither, G. A., & Sellbom, M. (2003). The Sexual Sensation Seeking Scale: Reliability and validity within a heterosexual college student sample. *Journal of Personality Assessment*, 81, 157-167.
- Gallagher, J. J. (1966). *Research summary on gifted child education*. Springfield, IL: State Department of Public Instruction.
- Gallagher, P., & MacLachlan, M. (2000). Development and psychometric evaluation of the Trinity Amputation and Prosthesis Experience Scales. *Rehabilitation Psychology*, 45, 130-154.
- Galton, F. (1869). *Hereditary genius*. London: Macmillan. (Republished in 1892)
- Galton, F. (1874). *English men of science*. New York: Appleton.
- Galton, F. (1879). Psychometric experiments. *Brain*, 2, 149-162.
- Galton, F. (1883). *Inquiries into human faculty and its development*. London: Macmillan.
- Gammon, J. A. (1981). Ophthalmic manifestations of child abuse. In N. S. Ellerstein (ed.), *Child abuse and neglect: A medical reference* (pp. 121-139). New York: Wiley.
- Ganellen, R. J. (1996). Comparing the diagnostic efficiency of the MMPI, MCMI-II, and Rorschach: A review. *Journal of Personality Assessment*, 67, 219-243.
- Gann, M. K., & Davison, G. C. (1997). *Cognitive assessment of reactance using the articulated thoughts in simulated situations paradigm*. Unpublished manuscript, University of Southern California, Los Angeles.
- Garb, H. N. (1994). Toward a second generation of statistical prediction rules in psychodiagnosis and personality assessment. *Computers in Human Behavior*, 11, 313-324.
- Garb, H. N. (2000a). Introduction to the special section on the use of computers for making judgments and decisions. *Psychological Assessment*, 12, 3-5.
- Garb, H. N. (2000b). Computers will become increasingly important for psychological assessment: Not that there's anything wrong with that! *Psychological Assessment*, 12, 31-39.
- Garcia, M., & Lega, L. I. (1979). Development of a Cuban Ethnic Identity Questionnaire. *Hispanic Journal of Behavioral Sciences*, 1, 247-261.
- Gardner, F. L. (2001). Applied sport psychology in professional sports: The team psychologist. *Professional Psychology: Research and Practice*, 32, 34-39.
- Gardner, H. (1983). *Frames of mind: The theory of multiple intelligences*. New York: Basic.
- Gardner, H. (1994). Multiple intelligences theory. In R. J. Sternberg, (ed.), *Encyclopedia of human intelligence* (pp. 740-742). New York: Macmillan.
- Gardner, R. A. (1971). *The boys' and girls' book about divorce*. New York: Bantam.
- Gardner, R. A. (1982). *Family evaluation in child custody litigation*. Cresskill, NJ: Creative Therapeutics.
- Gardner, W., Lidz, C. W., Mulvey, E. P., & Shaw, E. C. (1996). Clinical versus actuarial prediction of violence in patients with mental illnesses. *Journal of Consulting and Clinical Psychology*, 64, 602-609.
- Garfield, S. L., & Eron, L. D. (1948). Interpreting mood and activity in TAT stories. *Journal of Abnormal and Social Psychology*, 43, 338-345.
- Garrett, H. E., & Schneck, M. R. (1933). *Psychological tests, methods and results*. New York: Harper.
- Gaugler, B. B., Rosenthal, D. B., Thornton, G. C., III, & Bentson, C. (1987). Meta-analysis of assessment center validity. *Journal of Applied Psychology*, 72, 493-511.
- Gavzer, B. (1990, May 27). Should you tell all? *Parade Magazine*, pp. 4-7.
- General Electric Co. vs Joiner*, 118 S. Ct. 512 (1997).
- Gerety, M. B., Mulrow, C. D., Tuley, M. R., Hazuda, H. P., Lichtenstein, M. J., Bohannon, R., Kantan, D. N., O'Neil, M. B., & Gorton, A. (1993). Development and validation of a physical performance instrument for the functionally impaired elderly: The Physical Disability Index (PDI). *Journal of Gerontology*, 48, M33-M38.
- Gerry, M. H. (1973). Cultural myopia: The need for a corrective lens. *Journal of School Psychology*, 11, 307-315.
- Gesell, A. (1945). *The embryology of behavior. The beginnings of the human mind*. New York: Harper.
- Gesell, A. (1954). The ontogenesis of infant behavior. En L. Carmichael (ed.), *Manual of child psychology*. New York: Wiley.
- Gesell, A., & Amatruda, C. S. (1947). *Development diagnosis: Normal and abnormal child development* (2nd ed.). New York: Harper & Row.
- Gesell, A., & Thompson, H. (1929). Learning and growth in identical twin infants. *Genetic Psychology Monographs*, 6, 1-124.
- Gesell, A., *et al.* (1940). *The first five years of life*. New York: Harper.
- Ghiselli, E. E. (1973). The variety of aptitude tests in personnel selection. *Personnel Psychology*, 26, 461-477.
- Ghiselli, E. E., & Barthol, R. P. (1953). The validity of personality inventories in the selection of employees. *Journal of Applied Psychology*, 38, 18-20.
- Ghiselli, E. E., Campbell, J. P., & Zedeck, S. (1981). *Measurement theory for the behavioral sciences*. San Francisco: Freeman.
- Gibbins, S. (1988, April). *Use of the K-ABC and WISC-R with deaf children*. Paper presented at the Annual Meeting of the National Association of School Psychologists, Chicago.
- Gibbins, S. (1989). The provision of school psychological assessment services for the hearing impaired: A national survey. *Volta Review*, 91, 95-103.
- Gill, C. J., Kewman, D. G., & Brannon, R. W. (2003). Transforming psychological practice and society: Policies that reflect the new paradigm. *American Psychologist*, 58, 305-312.
- Girelli, S. A., & Stake, J. E. (1993). Bipolarity in Jungian type theory and the Myers-Briggs Type Indicator. *Journal of Personality Assessment*, 60, 290-301.
- Glaser, R., & Nitko, A. J. (1971). Measurement in learning and instruction. En R. L. Thorndike (ed.), *Educational measurement* (2nd ed.). Washington, DC: American Council on Education.
- Glassbrenner, J. (1998). Continuity across contexts: Prison, women's counseling center, and home. En L. Handler (Chair), *Conducting assessments in clients' homes: Contexts, surprises, dilemmas, opportunities*. Symposium presented at the Society for Personality Assessment 1998 Midwinter Meeting, February 20.
- Glazer, W. M., Kramer, R., Montgomery, J. S., & Myers, L. (1991). Use of medical necessity scales in concurrent review of

- psychiatric inpatient care. *Hospital and Community Psychiatry*, 42, 1199-1200.
- Glosser, G., & Goodglass, H. (1990). Disorders in executive control functions among aphasic and other brain-damaged patients. *Journal of Clinical and Experimental Neuropsychology*, 12, 485-501.
- Gluck, M. R. (1955). The relationship between hostility in the TAT and behavioral hostility. *Journal of Projective Techniques*, 19, 21-26.
- Glueck, W. F. (1978). *Personnel: A diagnostic approach*. Dallas, TX: Business Publications.
- Gobetz, W. A. (1953). Quantification, standardization, and validation of the Bender-Gestalt test on normal and neurotic adults. *Psychological Monographs*, 67, No. 6.
- Goddard, H. H. (1908). The Binet and Simon tests of intellectual capacity. *Training School*, 5, 3-9.
- Goddard, H. H. (1910). A measuring scale of intelligence. *Training School*, 6, 146-155.
- Goddard, H. H. (1912). *The Kallikak family*. New York: Macmillan.
- Goddard, H. H. (1913). The Binet tests in relation to immigration. *Journal of Psycho-Asthenics*, 18, 105-107.
- Goddard, H. H. (1916). *Feeble-mindedness*. New York: Macmillan.
- Goddard, H. H. (1917). Mental tests and the immigrant. *Journal of Delinquency*, 2, 243-277.
- Goel, V., & Grafman, J. (1995). Are the frontal lobes implicated in "planning" functions? Interpreting data from the Tower of Hanoi. *Neuropsychologia*, 33, 623-642.
- Goffman, E. (1963). *Behavior in public places*. Glencoe, IL: Free Press.
- Gokhale, D. V., & Kullback, S. (1978). *The information in contingency tables*. New York: Marcel Dekker.
- Gold, D. P., Andres, D., Etezadi, J., et al. (1995). Structural equation model of intellectual change and continuity and predictors of intelligence in older men. *Psychology & Aging*, 10, 294-303.
- Goldberg, L. R. (1993). The structure of phenotypic personality traits. *American Psychologist*, 48, 26-34.
- Goldberg, T. E., Gold, J. M., Greenberg, R., Griffin, S., Schulz, S. C., Pickar, D., Kleinman, J. E., & Weinberger, D. R. (1993). Contrasts between patients with affective disorders and patients with schizophrenia on a neuropsychological test battery. *American Journal of Psychiatry*, 150, 1355-1362.
- Goldberg, T. E., Saint-Cyr, J. A., & Weinberger, D. R. (1990). Assessment of procedural learning and problem solving in schizophrenic patients by Tower of Hanoi type tasks. *Journal of Neuropsychiatry*, 2, 165-173.
- Golden, C. J., Hammeke, T. A., & Purisch, A. D. (1980). *The Luria-Nebraska Neuropsychological Battery: Manual*. Los Angeles: Western Psychological Services.
- Golden, C. J., Purisch, A. D., & Hammeke, T. A. (1985). *Luria-Nebraska Neuropsychological Battery: Forms I and II, manual*. Los Angeles: Western Psychological Services.
- Goldfried, M. R., & Davison, G. C. (1976). *Clinical behavior therapy*. New York: Holt, Rinehart & Winston.
- Goldfried, M. R., Stricker, G., & Winer, I. B. (1971). *Rorschach handbook of clinical and research applications*. Englewood Cliffs, NJ: Prentice-Hall.
- Golding, S. L. (1975). Flies in the ointment: Methodological problems in the analysis of the percentage of variance due to persons and situations. *Psychological Bulletin*, 82, 278-288.
- Goldman, B. A., & Mitchell, D. F. (eds.) (1997). *Directory of unpublished experimental measures* (Vol. 7). Dubuque, IA: W. C. Brown.
- Goldstein, K. (1927). Die lokalisation in her grosshirn rinde. *Handb. norm. pathol. psychologie*. Berlin: J. Springer.
- Goldstein, K. (1939). *The organism*. New York: American Book.
- Goldstein, K. (1963a). *The organism*. Boston: Beacon.
- Goldstein, K. (1963b). The modifications of behavior consequent to cerebral lesions. *Psychiatric Quarterly*, 10, 586-610.
- Gomez, R., & Hazeldine, P. (1996). Social information processing in mild mentally retarded children. *Research in Developmental Disabilities*, 17, 217-227.
- Good, R. H., Chowdhri, S., Katz, L., Vollman, M., & Creek, R. (1989, March). Effect of matching instruction and simultaneous/ sequential processing strength. Paper presented at the Annual Meeting of the National Association of School Psychologists, Boston.
- Good, R. H., & Lane, S. (1988). *Confirmatory factor analysis of the K-ABC and WISC-R: Hierarchical models*. Paper presented at the Annual Meeting of the American Psychological Association, Atlanta.
- Good, R. H., Vollmer, M., Creek, R. J., & Katz, L. (1993). Treatment utility of the Kaufman Assessment Battery for Children: Effects of matching instruction and student processing strength. *School Psychology Review*, 22, 8-26.
- Goodman, G. S., & Reed, R. S. (1986). Age differences in eyewitness testimony. *Law and Human Behavior*, 10, 317-332.
- Goodman-Delahunty, J. (2000). Psychological impairment under the Americans with Disabilities Act: Legal guidelines. *Professional Psychology: Research and Practice*, 31, 197-205.
- Goodman-Delahunty, J., & Foote, W. E. (1995). Compensation for pain, suffering and other psychological injuries: The impact of Daubert on employment discrimination claims. *Behavioral Sciences and the Law*, 13, 183-206.
- Gopaul-McNicol, S. (1993). *Working with West Indian families*. New York: Guilford.
- Gorsuch, R. L. (1997). Exploratory factor analysis: Its role in item analysis. *Journal of Personality Assessment*, 68, 532-560.
- Gottfredson, L. S. (1988). Reconsidering fairness: A matter of social and ethical priorities. *Journal of Vocational Behavior*, 33, 293-319.
- Gottfredson, L. S. (1994). The science and politics of race-norming. *American Psychologist*, 49, 955-963.
- Gottfredson, L. S. (2000). Skills gaps, not tests, make racial proportionality impossible. *Psychology, Public Policy, and Law*, 6, 129-143.
- Gottfried, A. W. (ed.). (1984). *Home environment and early cognitive development: Longitudinal research*. New York: Academic Press.
- Gottfried, A. W., Gottfried, A. E., Bathurst, K., & Guerin, D. W. (1994). *Gifted IQ: Early developmental aspects*. New York: Plenum.
- Gough, H. G. (1960). The Adjective Check List as a personality assessment research technique. *Psychological Reports*, 6, 107-122.
- Gough, H. G. (1962). Clinical versus statistical prediction in psychology. In L. Postman (ed.), *Psychology in the making: Histories of selected research problems* (pp. 526-584). New York: Knopf.
- Gough, H. G., & Heilbrun, A. B., Jr. (1980). *The Adjective Checklist manual (Revised)*. Palo Alto, CA: Consulting Psychologists Press.
- Grafman, J., Litvan, I., Massaquoi, S., & Stewart, M. (1992). Cognitive planning deficit in patients with cerebellar atrophy. *Neurology*, 42, 1493-1496.
- Graham, J. R. (1990). *MMPI-2: Assessing personality and psychopathology*. New York: Oxford University.
- Granger, C. V., & Gresham, G. E. (eds.). (1984). *Functional assessment in rehabilitation medicine*. Baltimore: Williams & Wilkins.
- Greard, V. A., & Green, B. F. (1986). Equivalence of conventional and computer presentation of speed tests. *Applied Psychological Measurement*, 10, 23-34.
- Green, A. (1986). True and false allegations of sexual abuse in child custody disputes. *Journal of the American Academy of Child Psychology*, 25, 449-456.
- Green, B. F. (1984). *Computer-based ability testing*. Paper delivered at the 91st annual meeting of the American Psychological Association, Toronto, Ontario, Canada.

- Green, S. B. (2003). A coefficient alpha for test-retest data. *Psychological Methods*, 8, 88-101.
- Greene, R. L. (1987). Ethnicity and MMPI performance: A review. *Journal of Consulting and Clinical Psychology*, 55, 497-512.
- Greenfield, D. N. (1999). Psychological characteristics of compulsive Internet use: A preliminary analysis. *Cyber-Psychology & Behavior*, 2, 403-412.
- Greenlaw, P. S., & Jensen, S. S. (1996). Race-norming and the Civil Rights Act of 1991. *Public Personnel Management*, 25, 13-24.
- Greenspan, S. (1997). Dead manual walking? Why the AAMR definition needs redoing. *Education & Training in Mental Retardation & Developmental Disabilities*, 32, 179-190.
- Greenspoon, J. (1955). The reinforcing effect of two spoken sounds on the frequency of two responses. *American Journal of Psychology*, 68, 409-416.
- Greenspoon, J., & Gersten, C. D. (1967). A new look at psychological testing: Psychological testing from the standpoint of a behaviorist. *American Psychologist*, 22, 848-853.
- Gregoire, J. (1999). Emerging standards for test applications in the French-speaking countries of Europe. *European Journal of Psychological Assessment*, 15, 158-164.
- Gresham, F. M. (1989). Review of the Parenting Stress Index. En J. C. Conoley & J. J. Kramer (eds.), *The tenth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Gresham, F. M., MacMillan, D. L., & Siperstein, G. N. (1995). Critical analysis of the 1992 AAMR definition: Implications for school psychology. *School Psychology Quarterly*, 10(1), 1-19.
- Grey, R. J., & Kipnis, D. (1976). Untangling the performance appraisal dilemma: The influence of perceived organizational context on evaluative processes. *Journal of Applied Psychology*, 61, 329-335.
- Griffith, L. (1997). Surviving no-frills mental health care: The future of psychological assessment. *Journal of Practical Psychiatry and Behavioral Health*, 3, 255-258.
- Grisso, T. (1986). *Evaluating competencies: Forensic assessments and instruments*. New York: Plenum.
- Groeger, J. A., & Chapman, P. R. (1997). Normative influences on decisions to offend. *Applied Psychology: An International Review*, 46, 265-285.
- Groenveld, M., & Jan, J. E. (1992). Intelligence profiles of low vision and blind children. *Journal of Visual Impairment and Blindness*, 86, 68-71.
- Grossman, I., Mednitsky, S., Dennis, B., & Scharff, L. (1993). Validation of an "amazingly" short form of the WAIS-R for a clinically depressed sample. *Journal of Psychoeducational Assessment*, 11, 173-181.
- Grove, W. M., & Barden, R. C. (1999). Protecting the integrity of the legal system: The admissibility of testimony from mental health experts under *Daubert/Kumho* analyses. *Psychology, Public Policy, and Law*, 5, 224-242.
- Grove, W. M., Zald, D. H., Lebow, B. S., et al. (2000). Clinical versus mechanical prediction: A meta-analysis. *Psychological Assessment*, 12, 19-30.
- Guastello, S. J., & Rieke, M. L. (1990). The Barnum Effect and the validity of computer-based test interpretations: The Human Resource Development Report. *Psychological Assessment*, 2, 186-190.
- Guerrier, J. H., Manivannan, P., & Nair, S. N. (1999). The role of working memory, field dependence, visual search, and reaction time in the left turn performance of older female drivers. *Applied Ergonomics*, 30, 109-119.
- Guilford, J. P. (1954). A factor analytic study across the domains of reasoning, creativity, and evaluation. I. Hypothesis and description of tests. *Reports from the psychology laboratory*. Los Angeles: University of Southern California.
- Guilford, J. P. (1959). *Personality*. New York: McGraw-Hill.
- Guilford, J. P. (1967). *The nature of human intelligence*. New York: McGraw-Hill.
- Guilford, J. P., et al. (1974). *Structure-of-Intellect Abilities*. Orange, CA: Sheridan Psychological Services.
- Guilmette, T. J., & Faust, D. (1991). Characteristics of neuropsychologists who prefer the Halstead-Reitan Battery or the Luria-Nebraska Neuropsychological Battery. *Professional Psychology: Research and Practice*, 22(1), 80-83.
- Guilmette, T. J., Faust, D., Hart, K., & Arkes, H. R. (1990). A national survey of psychologists who offer neuropsychological services. *Archives of Clinical Neuropsychology*, 5, 373-392.
- Guion, R. M. (1980). On trinitarian doctrines of validity. *Professional Psychology*, 11, 385-398.
- Gulliksen, H., & Messick, S. (eds.). (1960). *Psychological scaling: Theory and applications*. New York: Wiley, 1960.
- Guttman, L. (1947). The Cornell technique for scale and intensity analysis. *Educational and Psychological Measurement*, 7, 247-280.
- Guttman, L. A. (1944a). A basis for scaling qualitative data. *American Sociological Review*, 9, 139-150.
- Guttman, L. A. (1944b). A basis for scaling qualitative data. *American Sociological Review*, 9, 179-190.
- Haaga, D. A., Davison, G. C., McDermut, W., Hillis, S. L., & Twomey, H. B. (1993). "State of mind" analysis of the articulated thoughts of ex-smokers. *Cognitive Therapy and Research*, 17, 427-439.
- Hadaway, N., & Marek-Schroer, M. F. (1992). Multidimensional assessment of the gifted minority student. *Roeper Review*, 15, 73-77.
- Haensly, P. A., & Torrance, E. P. (1990). Assessment of creativity in children and adolescents. In C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Intelligence & achievement* (pp. 697-722). New York: Guilford.
- Hafemeister, T. L. (2001, February). Ninth Circuit rejects immunity from liability for mental health evaluations. *Monitor on Psychology*, 32.
- Haidt, J., Rosenberg, E., & Horn, H. (2003). Differentiating differences: Moral diversity is not like other kinds. *Journal of Applied Social Psychology*, 33, 1-36.
- Haier, R. J. (1993). Cerebral glucose metabolism and intelligence. En P. A. Vernon (ed.), *Biological approaches to the study of human intelligence* (pp. 317-332). Norwood, NJ: Ablex.
- Haines, M., & Spear, S. F. (1996). Changing the perception of the norm: A strategy to decrease binge drinking among college students. *Journal of American College Health*, 45(3), 134-140.
- Haley, K., & Lee, M. (eds.). (1998). *The Oregon Death With Dignity Act: A guidebook for health care providers*. Portland, OR: Oregon Health Sciences University, Center for Ethics in Health Care.
- Hall, C. I. J. (1997). Cultural malpractice: The growing obsolescence of psychology with the changing U.S. population. *American Psychologist*, 52, 642-651.
- Hall, C. S., & Lindzey, G. (1970). *Theories of personality*. New York: Wiley.
- Hall, J. A., & Rosenthal, R. (1995). Interpreting and evaluating meta-analysis. *Evaluation and the Health Professions*, 18, 393-407.
- Hall, S. S. (1998, February 15). Our memories, our selves. *New York Times Magazine*, pp. 26-33, 49, 56-57.
- Halleck, S. L. (1976). Discussion of "Socially Reinforced Obsessing." *Journal of Consulting and Clinical Psychology*, 44, 146-147.
- Halpern, A. S., & Fuherer, M. J. (eds.). (1984). *Functional assessment in rehabilitation*. Baltimore: Paul H. Brookes.

- Halpern, D. F. (1997). Sex differences in intelligence: Implications for education. *American Psychologist*, 52, 1901-1102.
- Halpern, D. F. (2000). Validity, fairness, and group differences: Tough questions for selection testing. *Psychology, Public Policy, & Law*, 6, 56-62.
- Halpern, F. (1958). Child case study. En E. F. Hammer (ed.), *The clinical application of projective drawings* (pp. 113-129). Springfield, IL: Charles C Thomas.
- Halstead, W. C. (1947a). *Brain and intelligence*. Chicago: University of Chicago.
- Halstead, W. C. (1947b). *Brain and intelligence: A quantitative study of the frontal lobes*. Chicago: University of Chicago.
- Halstead, W. C., & Wepman, J. M. (1959). The Halstead-Wepman Aphasia Screening Test. *Journal of Speech and Hearing Disorders*, 14, 9-15.
- Hambleton, R. K., & Jurgensen, C. (1990). Criterion-referenced assessment of school achievement. En C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Intelligence & achievement* (pp. 456-476). New York: Guilford.
- Hamera, E., & Brown, C. E. (2000). Developing a context-based performance measure for persons with schizophrenia: The test of grocery shopping skills. *American Journal of Occupational Therapy*, 54, 20-25.
- Hammer, E. F. (1958). *The clinical application of projective drawings*. Springfield, IL: Charles C Thomas.
- Hammer, E. F. (1981). Projective drawings. En A. I. Rabin (ed.), *Assessment with projective techniques: A concise introduction* (pp. 151-185). New York: Springer.
- Hammitt, J. K. (1990). Risk perceptions and food choice: An exploratory analysis of organic—versus conventional—produce buyers. *Risk Analysis*, 10, 367-374.
- Handler, L. (1996). John Exner and the book that started it all: A review of *The Rorschach Systems*. *Journal of Personality Assessment*, 66, 441-471.
- Handler, L. (2001). Assessment of men: Personality assessment goes to war by the Office of Strategic Services Assessment Staff. *Journal of Personality Assessment*, 76, 558-578.
- Haney, W. (1981). Validity, vaudeville, and values: A short history of social concerns over standardized testing. *American Psychologist*, 36, 1021-1034.
- Haney, W., & Madaus, G. F. (1978). Making sense of the competency testing movement. *Harvard Educational Review*, 48, 462-484.
- Hansen, J. C. (1987). Cross-cultural research on vocational interests. *Measurement and Evaluation in Counseling and Development*, 19, 163-176.
- Hansen, N. D. (2002). Teaching cultural sensitivity in psychological assessment: A modular approach used in a distance education program. *Journal of Personality*, 79, 200-206.
- Hansen, N. D., Pepitone-Arreola-Rockwell, F., & Greene, A. F. (2000). Multicultural competence: Criteria and case examples. *Professional Psychology: Research and Practice*, 31, 652-660.
- Happell, B., Pinikahana, J., & Martin, T. (2003). Stress and burnout in forensic psychiatric nursing. *Stress & Health*, 19, 63-68.
- Hare, R. D. (1980). A research scale for the assessment of psychopathy in criminal populations. *Personality and Individual Differences*, 1, 111-119.
- Hare, R. D. (1985). *The Psychopathy Checklist*. Unpublished manuscript. University of British Columbia, Vancouver, Canada.
- Hare, R. D., Harpur, A. R., Hakstian, A. R., Forth, A. E., Hart, S. D., & Newman, J. P. (1990). The Revised Psychopathy Checklist: Reliability and Factor Structure. *Psychological Assessment*, 2, 338-341.
- Harker, L., & Keltner, D. (2001). Expressions of positive emotion in women's college yearbook pictures and their relationship to personality and life outcomes across adulthood. *Journal of Personality and Social Psychology*, 80, 112-124.
- Harmon, L. W., Hansen, J. C., Borgen, F. H., & Hammer, A. L. (1994). *Strong Interest Inventory: Applications and technical guide*. Palo Alto, CA: Consulting Psychologists Press.
- Harris, D. (1963). Children's drawings as measures of intellectual maturity. New York: Harcourt Brace Jovanovich.
- Harris, G. T., Rice, M. E., & Cormier, C. A. (1989). Violent recidivism among psychopaths and non-psychopaths treated in a therapeutic community. *Penetanguishene Mental Health Centre Research Report VI* (No. 181). Penetanguishene, Ontario, Canada: Penetanguishene Mental Health Centre.
- Harris, P. M. (1994). Client management classification and prediction of probation outcome. *Crime and Delinquency*, 40, 154-174.
- Harris, S. L., Delmolino, L., & Glasberg, B. A. (1996). Psychological and behavioral assessment in mental retardation. *Child & Adolescent Psychiatric Clinics of North America*, 5, 797-808.
- Harrison, P., & Oakland, T. (2000). *Adaptive Behavior Assessment System*. San Antonio, TX: Psychological Corporation.
- Harrison, P. L. (1990). *AGS Early Screening Profiles*. Circle Pines, MN: American Guidance Service.
- Hart, B., & Risley, T. R. (1992). American parenting of language-learning children: Persisting differences in family-child interactions observed in natural home environments. *Developmental Psychology*, 28, 1096-1105.
- Hart, R. R., & Goldstein, M. A. (1985). Computer-assisted psychological assessment. *Computers in Human Services*, 1, 69-75.
- Hart, S. D., Kropp, P. R., & Hare, R. D. (1988). Performance of male psychopaths following conditional release from prison. *Journal of Consulting and Clinical Psychology*, 56, 227-232.
- Hart, V. (1992). Review of the Infant Mullen Scales of Early Development. In J. J. Kramer & J. C. Conoley (eds.), *The eleventh mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Hartigan, J. A., & Wigdor, A. K. (1989). *Fairness in employment testing: Validity generalization, minority issues, and the General Aptitude Test Battery*. Washington, DC: National Academy.
- Hartman, D. E. (1986a). On the use of clinical psychology software: Practical, legal, and ethical concerns. *Professional Psychology: Research and Practice*, 17, 462-465.
- Hartman, D. E. (1986b). Artificial intelligence or artificial psychologist? Conceptual issues in clinical microcomputer use. *Professional Psychology: Research and Practice*, 17, 528-534.
- Hartmann, D. P., Roper, B. L., & Bradford, D. C. (1979). Some relationships between behavioral and traditional assessment. *Journal of Behavioral Assessment*, 1, 3-21.
- Hartmann, E., Sunde, T., Kristensen, W., & Martinussen, M. (2003). Psychological measures as predictors of military training performance. *Journal of Personality Assessment*, 80, 87-98.
- Hartshorne, H., & May, M. A. (1928). *Studies in the nature of character. Vol. 1: Studies in deceit*. New York: Macmillan.
- Harvey, R. J., & Murry, W. D. (1994). Scoring the Myers-Briggs Type Indicator: Empirical comparison of preference score versus latent-trait methods. *Journal of Personality Assessment*, 62, 116-129.
- Hassler, M., & Gupta, D. (1993). Functional brain organization, handedness, and immune vulnerability in musicians and nonmusicians. *Neuropsychologia*, 31, 655-660.
- Hathaway, S. R., & McKinley, J. C. (1940). A multiphasic personality schedule (Minnesota): 1. Construction of the schedule. *Journal of Psychology*, 10, 249-254.

- Hathaway, S. R., & McKinley, J. C. (1942). A multiphasic personality schedule (Minnesota): III. The measurement of symptomatic depression. *Journal of Psychology*, 14, 73-84.
- Hathaway, S. R., & McKinley, J. C. (1943). *The Minnesota Multiphasic Personality Inventory* (rev. ed.). Minneapolis: University of Minnesota.
- Hathaway, S. R., & McKinley, J. C. (1951). *The MMPI manual*. New York: Psychological Corporation.
- Hayden, D. C., Frulong, M. J., & Linnemeyer, S. (1988). A comparison of the Kaufman Assessment Battery for Children and the Stanford-Binet IV for the assessment of gifted children. *Psychology in the Schools*, 25, 239-243.
- Hayes, S. C. (1999). Comparison of the Kaufman Brief Intelligence Test and the Matrix Analogies Test-Short Form in an adolescent forensic population. *Psychological Assessment*, 11, 108-110.
- Haynes, R. B., Taylor, D. W., & Sackett, D. L. (eds.). (1979). *Compliance in health care*. Baltimore: Johns Hopkins University.
- Haynes, S. N. (2001a). Introduction to the special section on clinical applications of analogue behavioral observation. *Psychological Assessment*, 13, 3-4.
- Haynes, S. N. (2001b). Clinical applications of analogue behavioral observation: Dimensions of psychometric evaluation. *Psychological Assessment*, 13, 73-85.
- Haynes, S. N., Follingstad, D. R., & Sullivan, J. (1979). Assessment of marital satisfaction and interaction. *Journal of Consulting and Clinical Psychology*, 47, 789-791.
- Haynes, S. N., Jensen, B. J., Wise, E., & Sherman, D. (1981). The marital intake interview: A multimethod criterion validity assessment. *Journal of Consulting and Clinical Psychology*, 49, 379-387.
- Hays, P. A. (1996). Culturally responsive assessment with diverse older clients. *Professional Psychology: Research and Practice*, 27, 188-193.
- Hays, P. A., & LeVine, P. (2001). *Addressing cultural complexities in practice: A framework for clinicians and counselors*. Washington, DC: American Psychological Association.
- Hazlett, R. L., Falkin, S., Lawhorn, W., Friedman, E., & Haynes, S. N. (1997). Cardiovascular reactivity to a naturally occurring stressor: Development and psychometric evaluation of psychophysiological assessment procedure. *Journal of Behavioral Medicine*, 20, 551-571.
- Heaton, R. K., Temkin, N., Dikmen, S., et al. (2001). Detecting change: A comparison of three neuropsychological methods, using normal and clinical samples. *Archives of Clinical Neuropsychology*, 16, 75-91.
- Hedges, C. (1997, November 25). In Bosnia's schools, 3 ways never to learn from history. *New York Times*, pp. A1, A4.
- Heinrichs, R. W. (1990). Variables associated with Wisconsin Card Sorting Test performance in neuropsychiatric patients referred for assessment. *Neuropsychiatry, Neuropsychology, and Behavioral Neurology*, 3, 107-112.
- Heinze, M. C., & Grisso, T. (1996). Review of instruments assessing parenting competencies used in child custody evaluations. *Behavioral Sciences and the Law*, 14, 293-313.
- Helfer, R. E., & Kempe, R. S. (eds.). (1988). *The battered child* (4th ed.). Chicago: University of Chicago Press.
- Helson, R. (1967). Personality characteristics and developmental history of creative college women. *Genetic Psychology Monographs*, 76, 205-256.
- Helson, R., Mitchell, V., & Moane, G. (1984). Personality and patterns of adherence and nonadherence to the social clock. *Journal of Personality and Social Psychology*, 46, 1079-1096.
- Henk, W. A. (1993). New directions in reading assessment. *Reading and Writing Quarterly: Overcoming Learning Difficulties*, 9, 103-120.
- Henley, N. M., & LaFrance, M. (1984). Gender as culture: Difference in dominance in nonverbal behavior. En A. Wolfgang (ed.), *Nonverbal behavior: Perspectives, applications, intercultural insights* (pp. 351-371). Lewiston, NY: Hogrefe & Huber.
- Henry, E. M., & Rotter, J. B. (1956). Situational influences on Rorschach responses. *Journal of Consulting Psychology*, 20, 457-462.
- Henry, J. D. (1984). Syndicated public opinion polls: Some thoughts for consideration. *Journal of Advertising Research*, 24, 1-5-1-8.
- Henry, W. E. (1956). *The analysis of fantasy*. New York: Wiley.
- Henson, R. K. (2001). Understanding internal consistency reliability estimates: A conceptual primer on coefficient alpha. *Measurement and Evaluation in Counseling and Development*, 34, 177-189.
- Heppner, M. J. (1998). The Career Transitions Inventory: Measuring internal resources in adulthood. *Journal of Career Assessment*, 6, 135-145.
- Heppner, M. J., Multon, K. D., & Johnston, J. A. (1994). Assessing psychological resources during career change: Development of the Career Transitions Inventory. *Journal of Vocational Behavior*, 44, 55-74.
- Herlihy, B. (1977). Watch out, IQ myth: Here comes another debunker. *Phi Delta Kappan*, 59, 298.
- Hermann, C., Blanchard, E. B., & Flor, H. (1997). Biofeedback treatment for pediatric migraine: Prediction of treatment outcome. *Journal of Consulting and Clinical Psychology*, 65, 611-616.
- Hernandez, B., Keys, C., & Balcazar, F. (2003). The Americans with Disabilities Act Knowledge Survey: Strong psychometrics and weak knowledge. *Rehabilitation Psychology*, 48, 93-99.
- Herrnstein, R., & Murray, C. (1994). *The bell curve*. New York: Free Press.
- Herzberg, F., Mausner, B., Peterson, R. O., & Capwell, D. F. (1957). Job attitudes: Review of research and opinion. *Journal of Applied Psychology*, 63, 596-601.
- Hess, E. H. (1965). Attitude and pupil size. *Scientific American*, 212, 46-54.
- Hetherington, E. M., & Parke, R. D. (1993). *Child psychology: A contemporary viewpoint* (4th ed.). New York: McGraw-Hill.
- Heyman, R. E. (2001). Observation of couple conflicts: Clinical assessment applications, stubborn truths, and shaky foundations. *Psychological Assessment*, 13, 5-35.
- Hibbard, S. (2003). A critique of Lilienfeld et al.'s (2000) "The scientific status of projective techniques." *Journal of Personality Assessment*, 80, 260-271.
- Hibbard, S., Farmer, L., Wells, C., et al. (1994). Validation of Cramer's defense mechanism manual for the TAT. *Journal of Personality Assessment*, 63, 197-210.
- Hicks, L. K., Lin, Y., Robertson, D. W., et al. (2001). Understanding the clinical dilemmas that shape medical students' ethical development: Questionnaire survey and focus group study. *British Medical Journal*, 322, 709-710.
- Higgins, P. C. (1983). *Outsiders in a hearing world*. Beverly Hills, CA: Sage.
- Hill, P. C., & Pargament, K. I. (2003). Advances in the conceptualization and measurement of religion and spirituality: Implications for physical and mental health research. *American Psychologist*, 58, 64-74.
- Hiller, J. B., Rosenthal, R., Bornstein, R. F., & Brunell-Neuleib, S. (1999). A comparative meta-analysis of Rorschach and MMPI validity. *Psychological Assessment*, 11, 278-296.
- Hills, D. A. (1985). Prediction of effectiveness in leaderless group discussions with the Adjective Check List. *Journal of Applied Psychology*, 15, 443-447.

- Hines, M., Chiu, L., McAdams, L. A., Bentler, M. P., & Lipcamon, J. (1992). Cognition and the corpus callosum: Verbal fluency, visuospatial ability, language lateralization related to midsagittal surface areas of the corpus callosum. *Behavioral Neuroscience*, 106, 3-14.
- Hinkle, J. S. (1994). Counselors and cross-cultural assessment: A practical guide to information and training. *Measurement and Evaluation in Counseling and Development*, 27, 103-115.
- Hinrichsen, J. J., & Bradley, L. A. (1974). Situational determinants of personal validation of general personality interpretations: A re-examination. *Journal of Personality Assessment*, 38, 530-534.
- Hirsch, J. (1997). Some history of heredity-vs-environment, genetic inferiority at Harvard(?), and *The (incredible) bell curve*. *Genetics*, 99, 207-224.
- Hiscox, M. D. (1983). *A balance sheet for educational item banking*. Paper presented at the annual meeting of the National Council for Measurement in Education, Montreal, Canada.
- Hiscox, M. D., & Brzezinski, E. (1980). *A guide to item banking in education*. Portland, OR: Northwest Regional Educational Laboratory, Assessment and Education Division.
- Hishinuma, E. S., Andrade, N. N., Johnson, R. C., et al. (2000). Psychometric properties of the Hawaiian Culture Scale-Adolescent Version. *Psychological Assessment*, 12, 140-157.
- Hishinuma, E. S., & Yamakawa, R. (1993). Construct and criterion-related validity of the WISC-III for exceptional students and those who are "at risk." En B. A. Bracken (ed.), *Monograph series, Advances in psychoeducational assessment: Wechsler Intelligence Scale for Children, Third Edition; Journal of Psychoeducational Assessment* (pp. 94-104). Brandon, VT: Clinical Psychology Publishing.
- Hiskey, M. S. (1966). *Hiskey-Nebraska Test of Learning Aptitude*. Lincoln: Union College.
- Ho, M. K. (1987). *Family therapy with ethnic minorities*. Newbury Park, CA: Sage.
- Hodapp, R. M. (1995). Definitions in mental retardation: Effects on research, practice, and perceptions. *School Psychology Quarterly*, 10(1), 24-28.
- Hofer, P. J., & Green, B. F. (1985). The challenge of competence and creativity in computerized psychological testing. *Journal of Consulting and Clinical Psychology*, 53, 826-838.
- Hoffman, B. (1962). *The tyranny of testing*. New York: Crowell-Collier.
- Hoffman, K. I., & Lundberg, G. D. (1976). A comparison of computer monitored group tests and paper-and-pencil tests. *Educational and Psychological Measurement*, 36, 791-809.
- Hofstede, G. (1998). Attitudes, values, and organizational culture: Disentangling the concepts. *Organization Studies*, 19, 477-493.
- Holahan, C., & Sears, R. (1995). *The gifted group in later maturity*. Stanford, CA: Stanford University Press.
- Holden, G. W., & Edwards, L. A. (1989). Parental attitudes toward child rearing: Instruments, issues, and implications. *Psychological Bulletin*, 106, 29-58.
- Holland, A. (1980). *Communicative abilities in daily living: A test of functional communication for aphasic adults*. Baltimore: University Park.
- Holland, J. L. (1973). *Making vocational choices*. Englewood Cliffs, NJ: Prentice-Hall.
- Holland, J. L. (1985). *Manual for the vocational preference inventory*. Odessa, FL: Psychological Assessment Resources.
- Holland, J. L. (1997). *Making vocational choices: A theory of vocational personalities and work environments* (3rd ed.). Odessa, FL: Psychological Assessment Resources.
- Holland, J. L. (1999a). *Making vocational choices: A theory of vocational personalities and work environments* (3rd ed.). Odessa, FL: Psychological Assessment Resources.
- Holland, J. L. (1999b). Why interest inventories are also personality inventories. In M. L. Savickas & A. R. Spokane (eds.), *Vocational interests: Meaning, measurement, and counseling use* (87-101). Palo Alto, CA: Davies-Black Publishing.
- Holland, J. L., Powell, A. B., & Fritzsche, B. A. (1994). *The Self-Directed Search (SDS) professional user's guide—1994 edition*. Odessa, FL: Psychological Assessment Resources.
- Holland, W. R. (1960). Language barrier as an educational problem of Spanish-speaking children. *Exceptional Children*, 27, 42-47.
- Hollander, E. P., & Willis, R. H. (1967). Some current issues in the psychology of conformity and nonconformity. *Psychological Bulletin*, 68, 62-76.
- Hollenbeck, J. R., & Whitener, E. M. (1988). Reclaiming personality traits for personal selection: Self-esteem as an illustrative case. *Journal of Management*, 14, 81-91.
- Hollingshead, A. B., & Redlich, F. C. (1958). *Social class and mental illness: A community study*. New York: Wiley.
- Holmstrom, R. W., Silber, D. E., & Karp, S. A. (1990). Development of the Apperceptive Personality Test. *Journal of Personality Assessment*, 54, 252-264.
- Holt, R. R. (1958). Clinical and statistical prediction: A reformulation and some new data. *Journal of Abnormal and Social Psychology*, 56, 1-12.
- Holt, R. R. (1970). Yet another look at clinical and statistical prediction: Or, is clinical psychology worthwhile? *American Psychologist*, 25, 337-349.
- Holt, R. R. (1971). *Assessing personality*. New York: Harcourt Brace Jovanovich.
- Holt, R. R. (1978). *Methods in clinical psychology: Vol. 2. Prediction and research*. New York: Plenum.
- Holtzman, W. H. (1993). An unjustified, sweeping indictment by Motta et al. of human figure drawings for assessing psychological functioning. *School Psychology Quarterly*, 8, 189-190.
- Holtzman, W. H., Thorpe, J. S., Swartz, J. D., & Herron, E. W. (1961). *Inkblot perception and personality: Holtzman Inkblot Technique*. Austin: University of Texas Press.
- Honaker, L. M. (1988). The equivalency of computerized and conventional MMPI administration: A review. *Clinical Psychology Review*, 8, 561-577.
- Honaker, L. M. (1990, August). Recommended guidelines for computer equivalency research (or everything you should know about computer administration but will be disappointed if you ask). En W. J. Camara (Chair), *The state of computer-based testing and interpretation: Consensus or chaos?* Symposium conducted at the Annual Convention of the American Psychological Association, Boston.
- Honaker, L. M., & Fowler, R. D. (1990). Computer-assisted psychological assessment. En G. Goldstein & M. Hersen (eds.), *Handbook of psychological assessment* (2nd ed., pp. 521-546). New York: Pergamon.
- Honts, C. R. (1994). Psychophysiological detection of deception. *Current Directions in Psychological Science*, 3, 77-82.
- Honzik, M. P. (1967). Environmental correlates of mental growth: Prediction from the family setting at 21 months. *Child Development*, 38, 337-364.
- Hopkins, K. D., & Glass, G. V. (1978). *Basic statistics for the behavioral sciences*. Englewood Cliffs, NJ: Prentice-Hall.
- Hopwood v. State of Texas*, 78 F.3d 932, 948 (5th Cir. 1996).
- Horn, J. (1988). Thinking about human abilities. En J. R. Nesselroade & R. B. Cattell (eds.), *Handbook of multivariate psychology*. New York: Plenum.
- Horn, J. L. (1968). Organization of abilities and the development of intelligence. *Psychological Review*, 75, 242-259.

- Horn, J. L. (1985). Remodeling old theories of intelligence: GF-Gc theory. In B. B. Wolman (ed.), *Handbook of intelligence* (pp. 267-300). New York: Wiley.
- Horn, J. L. (1988). Thinking about human abilities. En J. R. Nesselroade & R. B. Cattell (eds.), *Handbook of multivariate psychology* (rev. ed., pp. 645-685). New York: Academic Press.
- Horn, J. L. (1989). Cognitive diversity: A framework for learning. In P. L. Ackerman et al. (eds.), *Learning and individual differences* (pp. 61-116). New York: W. H. Freeman.
- Horn, J. L. (1991). Measurement of intellectual capabilities: A review of theory. En K. S. McGrew et al. (eds.), *Woodcock-Johnson technical manual* (pp. 197-232). Chicago: Riverside.
- Horn, J. L. (1994). Theory of fluid and crystallized intelligence. En R. J. Sternberg (ed.), *Encyclopedia of human intelligence* (pp. 443-451).
- Horn, J. L., & Cattell, R. B. (1966). Refinement and test of the theory of fluid and crystallized intelligence. *Journal of Educational Psychology*, 57, 253-270.
- Horn, J. L., & Cattell, R. B. (1967). Age differences in fluid and crystallized intelligence. *Acta Psychologica*, 26, 107-129.
- Horn, J. L., & Hofer, S. M. (1992). Major abilities and development in the adult period. En R. J. Sternberg & C. A. Berg (eds.), *Intellectual development* (pp. 44-99). Boston, MA: Cambridge University Press.
- Hornby, R. (1993). *Cultural competence for human service providers*. Rosebud, SD: Sinte Gleska University Press.
- Horner, M. S. (1973). A psychological barrier to achievement in women: The motive to avoid success. En D. C. McClelland & R. S. Steele (eds.), *Human motivation* (pp. 222-230). Morristown, NJ: General Learning.
- Horowitz, R., & Murphy, L. B. (1938). Projective methods in the psychological study of children. *Journal of Experimental Education*, 7, 133-140.
- Hostetler, A. J. (1987). Try to remember. *APA Monitor*, 18(5), 18.
- House, R. J., Shane, S. A., & Herold, D. M. (1996). Rumors of the death of dispositional research are vastly exaggerated. *Academy of Management Review*, 20, 203-224.
- Houston, T. K., Cooper, L. A., Vu, H., et al. (2001). Screening the public for depression through the Internet. *Psychiatric Services*, 52, 362-367.
- Howard, M. N. (1991). The neutral expert: A plausible threat to justice. *Criminal Law Review*.
- Howe Chief, E. (1940). An assimilation study of Indian girls. *Journal of Social Psychology*, 11, 19-30.
- Hsu, S-H, & Peng, Y. (1993). Control/display relationship of the four-burner stove: A re-examination. *Human Factors*, 35, 745-749.
- Hudson, W. W. (1982). *The clinical measurement package: A field manual*. Chicago: Dorsey.
- Huesmann, L. R., & Guerra, N. G. (1997). Children's normative beliefs about aggression and aggressive behavior. *Journal of Personality and Social Psychology*, 72, 408-419.
- Huffcutt, A. I., & Arthur, Jr., W. (1994). Hunter and Hunter (1984) revisited: Interview validity for entry-level jobs. *Journal of Applied Psychology*, 79, 184-190.
- Hughes, C., Hwang, B., Kim, J.-H., et al. (1995). Quality of life in applied research: A review and analysis of empirical measures. *American Journal on Mental Retardation*, 99, 623-641.
- Hull, C. L. (1922). *Aptitude testing*. Yonkers, NY: World Book.
- Hulse, W. G. (1951). The emotionally disturbed child draws his family. *Quarterly Journal of Child Behavior*, 3, 151-174.
- Hulse, W. G. (1952). Childhood conflict expressed through family drawings. *Quarterly Journal of Child Behavior*, 16, 152-174.
- Humphreys, L. G. (1996). Linear dependence of gain scores on their components imposes constraints on their use and interpretation: Comment on "Are simple gain scores obsolete?" *Applied Psychological Measurement*, 20, 293-294.
- Hunsley, J., & Bailey, J. M. (1999). The clinical utility of the Rorschach: Unfulfilled promises and an uncertain future. *Psychological Assessment*, 11, 266-277.
- Hunt, J. McV. (1961). *Intelligence and experience*. New York: Ronald.
- Hunt, K. N. (2002). *Encyclopedia of associations*. Farmington Hills, MI: Gale Group.
- Hunter, J. E. (1980). *Validity generalization for 12,000 jobs: An application of synthetic validity and validity generalization to the General Aptitude Test Battery (GATB)*. Washington, DC: U.S. Employment Service, Department of Labor.
- Hunter, J. E. (1982). *The dimensionality of the General Aptitude Test Battery and the dominance of general factors over specific factors in the prediction of job performance*. Washington, DC: U.S. Employment Service, Department of Labor.
- Hunter, J. E. (1986). Cognitive ability, cognitive aptitudes, job knowledge, and job performance. *Journal of Vocational Behavior*, 29, 340-362.
- Hunter, J. E., & Hunter, R. (1984). Validity and utility of alternate predictors of job performance. *Psychological Bulletin*, 96, 72-98.
- Hunter, J. E., & Schmidt, F. L. (1976). A critical analysis of the statistical and ethical implications of various definitions of "test bias." *Psychological Bulletin*, 83, 1053-1071.
- Hunter, J. E., & Schmidt, F. L. (1981). Fitting people into jobs: The impact of personal selection on normal productivity. En M. D. Dunnette & E. A. Fleishman (eds.), *Human performance and productivity: Vol. 1. Human capability assessment*. Hillsdale, NJ: Erlbaum.
- Hunter, J. E., & Schmidt, F. L. (1983). Quantifying the effects of psychological interventions on employee job performance and work-force productivity. *American Psychologist*, 38, 473-478.
- Hunter, J. E., & Schmidt, F. L. (1990). *Methods of meta-analysis*. Newbury Park, CA: Sage.
- Hunter, J. E., Schmidt, F. L., & Jackson, G. B. (1982). *Meta-analysis: Cumulating research findings across studies*. Beverly Hills, CA: Sage.
- Hunter, M. S. (1992). The Women's Health Questionnaire: A measure of mid-aged women's perceptions of their emotional and physical health. *Psychology and Health*, 7, 45-54.
- Hurlburt, R. T. (1997). Randomly sampling thinking in the natural environment. *Journal of Consulting and Clinical Psychology*, 65, 941-949.
- Hurst, N. H. (1997). A narrative analysis of identity change in treated substance abusers. Dissertation Abstracts International, Section B: The Sciences & Engineering, 58(4-B), 2124.
- Hutt, M. L. (1985). *The Hutt adaptation of the Bender-Gestalt Test* (4th ed.). Orlando, FL: Grune & Stratton.
- Iacono, W. G., & Lykken, D. T. (1997). The validity of the lie detector: Two surveys of scientific opinion. *Journal of Applied Psychology*, 82, 425-433.
- Iaffaldano, M. T., & Muchinsky, P. M. (1985). Job satisfaction and job performance: A meta-analysis. *Psychological Bulletin*, 97, 251-273.
- Illovsky, M. E. (2003). Mental health professionals, minorities, and the poor. New York: Brunner-Routledge.
- Ilyin, D. (1976). *The Ilyin oral interview*. Rowley, MA: Newbury House.
- Impara, J. C., & Plake, B. S. (eds.). (1998). *The thirteenth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Innocenti, M. S., Huh, K., & Boyce, G. C. (1992). Families of children with disabilities: Normative data and other considerations on parenting stress. *Topics in Early Childhood Special Education*, 12, 403-427.

- Institute for Juvenile Research. (1937). *Child guidance procedures, methods and techniques employed at the Institute for Juvenile Research*. New York: Appleton-Century.
- Institute of Medicine. (1984). *Research and training for the Secret Service: Behavioral science and mental health perspectives: A report of the Institute of Medicine* (IOM Publication No. IOM-84-01). Washington, DC: National Academy Press.
- International Test Commission. (1993). *Technical standards for translating tests and establishing test score equivalence*. Amherst, MA: Author. (Available from Dr. Ronald Hambleton, School of Education, University of Massachusetts, Amherst, MA 01003).
- Ironson, G. H., & Subkoviak, M. J. (1979). A comparison of several methods of assessing item bias. *Journal of Educational Measurement*, 16, 209-225.
- Irvine, S. H., & Berry, J. W. (eds.). (1983). *Human assessment and cultural factors*. New York: Plenum.
- Isen, A. M. (1987). Positive affect, cognitive processes, and social behavior. *Advances in Experimental Social Psychology*, 20, 203-253.
- Ishihara, S. (1964). *Tests for color blindness* (11th ed.). Tokyo: Kanehara Shuppan.
- Ivancevich, J. M. (1983). Contrast effects in performance evaluation and reward practices. *Academy of Management Journal*, 26, 465-476.
- Ivnik, R. J., Malec, J. F., Smith, G. E., Tangalos, E. G., Petersen, R. C., Kokmen, E., & Kurland, L. T. (1992). Mayo's older American normative studies: WAIS-R norms for ages 56-97. *Clinical Neuropsychologist*, 6 (Suppl.), 1-30.
- Ivnik, R. J., Smith, G. E., Malec, J. F., Petersen, R. C., & Tangalos, E. G. (1995). Long-term stability and intercorrelations of cognitive abilities in older persons. *Psychological Assessment*, 7, 155-161.
- Jackson, C. L., & LePine, J. A. (2003). Peer responses to a team's weakest link: A test and extension of LePine and Van Dyne's model. *Journal of Applied Psychology*, 88, 459-475.
- Jackson, D. E., O'Dell, J. W., & Olson, D. (1982). Acceptance of bogus personality interpretations: Face validity reconsidered. *Journal of Clinical Psychology*, 38, 588-592.
- Jackson, D. N. (1964). Desirability judgments as a method of personality assessment. *Educational and Psychological Measurement*, 24, 223-238.
- Jackson, D. N. (1977). *Jackson Vocational Interest Survey manual*. Port Huron, MI: Research Psychologists.
- Jackson, D. N. (1986). *Computer-based personality testing*. Washington, DC: Scientific Affairs Office, American Psychological Association.
- Jackson, D. N., & Messick, S. (1962). Response styles and the assessment of psychopathology. In S. Messick & J. Ross (eds.), *Measurement in personality and cognition*. New York: Wiley.
- Jackson, D. N., & Williams, D. R. (1975). Occupational classification in terms of interest patterns. *Journal of Vocational Behavior*, 6, 269-280.
- Jackson, J. F. (1993). Human behavioral genetics, Scarr's theory, and her views on interventions: A critical review and commentary on their implications for African American children. *Child Development*, 64, 1318-1332.
- Jackson, J. L. (1999). Psychometric considerations in self-monitoring assessment. *Psychological Assessment*, 11, 439-447.
- Jacobs, J. (1970). Are we being misled by fifty years of research on our gifted children? *Gifted Child Quarterly*, 14, 120-123.
- Jacobsen, M. E. (1999). Arousing the sleeping giant: Giftedness in adult psychotherapy. *Roeper Review*, 22, 36-41.
- Jacob-Timm, S., & Hartshorne, T. (1998). *Ethics and law for school psychologists* (3rd ed.). New York: Wiley.
- Jaffee v. Redmond. (1996). 518 U.S. 1; 116 S. Ct. (1993).
- Jagger, L., Neukrug, E., & McAuliffe, G. (1992). Congruence between personality traits and chosen occupation as a predictor of job satisfaction for people with disabilities. *Rehabilitation Counseling Bulletin*, 36, 53-60.
- Jagim, R. D., Wittman, W. D., & Noll, J. O. (1978). Mental health professionals' attitudes towards confidentiality, privilege, and third-party disclosure. *Professional Psychology*, 9, 458-466.
- James, L. R., Demaree, R. G., & Mulaik, S. A. (1986). A note on validity generalization procedures. *Journal of Applied Psychology*, 71, 440-450.
- James, L. R., Demaree, R. G., & Wolf, G. (1984). Estimating within-group interrater reliability with and without response bias. *Journal of Applied Psychology*, 69, 85-98.
- Janis, I. L. (1972). *Victims of groupthink*. Boston: Houghton Mifflin.
- Jankowski, K. (1991). On communicating with deaf people. In L. A. Samovar & R. E. Belmont (eds.), *Intercultural communication: A reader*. (6th ed., pp. 142-150). Belmont, CA: Wadsworth.
- Janowsky, D. S., Morter, S., & Hong, L. (2002). Relationship of Myers-Briggs Type Indicator personality characteristics to suicidality in affective disorder patients. *Journal of Pediatric Research*, 36, 33-39.
- Jay, M. (2002). *Cracking the GRE Psychology Test* (6th ed.). New York: Princeton Review.
- Jenkins, C. D., Zyzanski, S. J., & Rosenman, R. H. (1979). *Jenkins Activity Survey: Manual*. San Antonio, TX: Psychological Corporation.
- Jennings, B. (1991). Active euthanasia and forgoing life-sustaining treatment: Can we hold the line? *Journal of Pain*, 6, 312-316.
- Jensen, A. R. (1965). A review of the Rorschach. In O. K. Buros (ed.), *The sixth mental measurements yearbook* (pp. 501-509). Lincoln: Buros Institute of Mental Measurement, University of Nebraska.
- Jensen, A. R. (1969). How much can we boost IQ and scholastic achievement? *Harvard Educational Review*, 39, 1-123.
- Jensen, A. R. (1980). *Bias in mental testing*. New York: Free Press.
- Jensen, A. R. (2000). Testing: The dilemma of group differences. *Psychology, Public Policy, and Law*, 6, 121-127.
- Jobes, D. A., Jacoby, A. M., Cimbo, P., & Hustead, L. A. T. (1997). Assessment and treatment of suicidal clients in a university. *Journal of Consulting Psychology*, 44, 368-377.
- Johansson, H. J., & Forsman, M. (2001). Identification and analysis of unsatisfactory psychosocial work situations: A participatory approach employing video-computer interaction. *Applied Ergonomics*, 32, 23-29.
- Johnson, D. L., & Johnson, C. A. (1965). Totally discouraged: A depressive syndrome of the Dakota Sioux. *Psychiatric Research Review*, 2, 141-143.
- Johnson, E. S. (2000). The effects of accommodation on performance assessments. *Remedial and Special Education*, 21, 261-267.
- Johnson, G. S. (1989). Emotional indicators in the human figure drawings of hearing-impaired children: A small sample validation study. *American Annals of the Deaf*, 134, 205-208.
- Johnson, J. A., & Ostendorf, F. (1993). Clarification of the five-factor model with the abridged big five dimensional circumplex. *Journal of Personality and Social Psychology*, 65, 563-576.
- Johnson, L. C., Beaton, R., Murphy, S., & Pike, K. (2000). Sampling bias and other methodological threats to the validity of health survey research. *International Journal of Stress Management*, 7, 247-267.
- Johnson, L. J., Cook, M. J., & Kullman, A. J. (1992). An examination of the concurrent validity of the Battelle Developmental Inventory as compared with the Vineland Adaptive Scales and the Bayley Scales of Infant Development. *Journal of Early Intervention*, 16, 353-359.

- Johnson, R. C. (1963). Similarity in IQ of separated identical twins as related to length of time spent in same environment. *Child Development*, 34, 745-749.
- Joiner, T. E., Jr., & Schmidt, K. L. (1997). Drawing conclusions—or not—from drawings. *Journal of Personality Assessment*, 69, 476-481.
- Joiner, T. E., Jr., Schmidt, K. L., & Barnett, J. (1996). Size, detail, and line heaviness in children's drawings as correlates of emotional distress: (More) negative evidence. *Journal of Personality Assessment*, 67, 127-141.
- Joiner, T. E., Jr., & Walker, R. L. (2002). Construct validity of a measure of acculturative stress in African Americans. *Psychological Assessment*, 14, 462-466.
- Jolles, J. (1952). *A catalogue for the qualitative interpretation of the H-T-P*. Los Angeles: Western Psychological Services.
- Jones, J. W., Arnold, D., & Harris, W. G. (1990). Introduction to the Model Guidelines for Preemployment Integrity Testing. *Journal of Business and Psychology*, 4, 525-532.
- Jones, J. W., Brasher, E. E., & Huff, J. W. (2002). Innovations in integrity-based personnel selection: Building a technology-friendly assessment. *International Journal of Selection and Assessment*, 10, 87-97.
- Jones, P., & Rodgers, B. (1993). Estimating premorbid IQ in schizophrenia. *British Journal of Psychiatry*, 162, 273-274.
- Jones, R. N., & Gallo, J. J. (2000). Dimensions of the Mini-Mental State Examination among community-dwelling older adults. *Psychological Medicine*, 30, 605-618.
- Jones, S., Guy, A., & Omrod, J. A. (2003). A Q-methodological study of hearing voices: A preliminary exploration of voice hearers' understanding of their experiences. *Psychology & Psychotherapy: Theory, Research and Practice*, 76, 189-209.
- Jones, S. E. (2001, February). Ethics Code Draft published for comment. *APA Monitor*, 32.
- Judge, T. A., & Bono, J. E. (2000). Five-factor model of personality and transformational leadership. *Journal of Applied Psychology*, 85, 751-765.
- Judge, T. A., Bono, J. E., & Locke, E. A. (2000). Personality and job satisfaction: The mediating role of job characteristics. *Journal of Applied Psychology*, 85, 237-249.
- Judge, T. A., Heller, D., & Mount, M. K. (2002). Five-factor model of personality and job satisfaction: A meta-analysis. *Journal of Applied Psychology*, 87, 530-541.
- Judge, T. A., & Ilies, R. (2002). Relationship of personality to performance motivation: A meta-analytic review. *Journal of Applied Psychology*, 87, 797-807.
- Jung, C. G. (1910). The association method. *American Journal of Psychology*, 21, 219-269.
- Jung, C. G. (1923). *Psychological types*. London: Routledge & Kegan Paul.
- Juni, S. (1996). Review of the revised NEO Personality Inventory. In J. C. Conoley & J. C. Impara (eds.), *The twelfth mental measurements yearbook* (pp. 863-868). Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Kagan, J. (1956). The measurement of overt aggression from fantasy. *Journal of Abnormal and Social Psychology*, 52, 390-393.
- Kahn, M., & Taft, G. (1983). The application of the standard of care doctrine to psychological testing. *Behavioral Sciences and the Law*, 1, 71-84.
- Kail, B. L., & DeLaRosa, M. (1998). Challenges to treating the elderly Latino substance abuser: A not so hidden research agenda. *Journal of Gerontological Social Work*, 30, 128-141.
- Kaiser, H. F. (1958). A modified stanine scale. *Journal of Experimental Education*, 26, 261.
- Kaiser, H. F., & Michael, W. B. (1975). Domain validity and generalizability. *Educational and Psychological Measurement*, 35, 31-35.
- Kalat, J. W., & Matlin, M. W. (2000). The GRE Psychology Test: A useful but poorly understood test. *Teaching of Psychology*, 27, 24-27.
- Kamin, L. J. (1974). *The science and politics of IQ*. New York: Wiley.
- Kamiya, J. (1962). *Conditional discrimination of the EEG alpha rhythm in humans*. Paper presented at the annual meeting of the Western Psychological Association, April.
- Kamiya, J. (1968). Conscious control of brain waves. *Psychology Today*, 1(11), 56-60.
- Kamphaus, R. W., Petoskey, M. D., & Rowe, E. W. (2000). Current trends in psychological testing of children. *Professional Psychology: Research and Practice*, 31, 155-164.
- Kamphaus, R. W., & Pleiss, K. L. (1993). Comment on "The use and abuse of human figure drawings." *School Psychology Quarterly*, 8, 187-188.
- Kanaya, T., Scullin, M. H., & Ceci, S. J. (2003). The Flynn effect and U. S. policies: The impact of rising IQ scores on American society via mental retardation diagnoses. *American Psychologist*, 58, 778-790.
- Karlsen, S., Rogers, A., & McCarthy, M. (1998). Social environment and substance misuse: A study of ethnic variations among inner London adolescents. *Ethnicity & Health*, 3, 265-273.
- Karon, B. P. (1981). The Thematic Apperception Test (TAT). In A. I. Rabin (ed.), *Assessment with projective techniques: A concise introduction* (pp. 85-120). New York: Springer.
- Karon, B. P. (2000). The clinical interpretation of the Thematic Apperception Test, Rorschach, and other clinical data: A reexamination of statistical versus clinical prediction. *Professional Psychology: Research and Practice*, 31, 230-233.
- Karp, S. A., Holmstrom, R. W., & Silber, D. E. (1990). *Apperceptive Personality Test Manual* (Version 2.0). Orland Park, IL: International Diagnostic Systems, Inc.
- Katz, R. C., Santman, J., & Lonero, P. (1994). Findings on the Revised Morally Debatable Behaviors Scale. *Journal of Psychology*, 128, 15-21.
- Katz, W. F., Curtiss, S., & Tallal, P. (1992). Rapid automatized naming and gesture by normal and language-impaired children. *Brain and Language*, 43, 623-641.
- Kaufman, A. S. (1990). *Assessing adolescent and adult intelligence*. Needham Heights, MA: Allyn & Bacon.
- Kaufman, A. S. (1993). Joint exploratory factor analysis of the Kaufman Battery for Children and the Kaufman Adolescent and Adult Intelligence Test for 11- and 12-year-olds. *Journal of Clinical Child Psychology*, 22, 355-364.
- Kaufman, A. S. (1994a). *Intelligent testing with the WISC-R*. New York: Wiley.
- Kaufman, A. S. (1994b). *Intelligent testing with the WISC-III*. New York: Wiley.
- Kaufman, A. S., Ishkuma, T., & Kaufman-Packer, J. L. (1991). Amazingly short forms of the WAIS-R. *Journal of Psychoeducational Assessment*, 9, 4-15.
- Kaufman, A. S., & Kaufman, N. L. (1983a). *Kaufman Assessment Battery for Children (K-ABC): Administration and scoring manual*. Circle Pines, MN: American Guidance Service.
- Kaufman, A. S., & Kaufman, N. L. (1983b). *Kaufman Assessment Battery for Children (K-ABC) interpretative manual*. Circle Pines, MN: American Guidance Service.
- Kaufman, A. S., & Kaufman, N. L. (1990). *Kaufman Brief Intelligence Test (K-BIT): Manual*. Circle Pines, MN: American Guidance Service.

- Kaufman, A. S., & Kaufman, N. L. (1993). *Kaufman Adolescent and Adult Intelligence Test (KAIT): Manual*. Circle Pines, MN: American Guidance Service.
- Kaufman, A. S., Kaufman, N. L., & Goldsmith, B. (1984). *Kaufman Sequential or Simultaneous (K-SOS)*. Circle Pines, MN: American Guidance Service.
- Kaufman, A. S., & Lichtenberger, E. O. (1999). *Essentials of WAIS-III assessment*. New York: Wiley.
- Kaufman, A. S., & McLean, J. E. (1986). K-ABC / WISC-R factor analysis for a learning-disabled population. *Journal of Learning Disabilities*, 19, 145-153.
- Kaufman, A. S., & McLean, J. E. (1987). Joint factor analysis of the K-ABC and WISC-R with normal children. *Journal of School Psychiatry*, 25, 105-118.
- Kaufman, A. S., Reynolds, C. R., & McLean, J. E. (1989). Age and WAIS-R intelligence in a national sample of adults in the 20- to 74-year age range: A cross-sectional analysis with educational level controlled. *Intelligence*, 13, 235-253.
- Kavale, K. A. (1995). Meta-analysis at 20: Retrospect and prospect. *Evaluation and the Health Professionals*, 18, 349-369.
- Kaye, B. K., & Johnson, T. J. (1999). Taming the cyber frontier: Techniques for improving online surveys. *Social Science Computer Review*, 17, 323-337.
- Keating, C. F., Mazur, A., Segall, M. H., et al. (1981). Culture and the perception of social dominance from facial expression. *Journal of Personality and Social Psychology*, 40, 615-626.
- Kebbell, M. R., & Wagstaff, G. F. (1998). Hypnotic interviewing: The best way to interview eyewitnesses? *Behavioral Sciences & the Law*, 16, 115-129.
- Keefe, F. J., Smith, S. J., Buffington, A. L. H., Gibson, J., Studts, J. L., & Caldwell, D. S. (2002). Recent advances and future directions in the biopsychosocial assessment and treatment of arthritis. *Journal of Consulting and Clinical Psychology*, 70, 640-655.
- Kehoe, J. F., & Tenopir, M. L. (1994). Adjustment in assessment scores and their usage: A taxonomy and evaluation of methods. *Psychological Assessment*, 6, 291-303.
- Keiser, R. E., & Prather, E. N. (1990). What is the TAT? A review of ten years of research. *Journal of Personality Assessment*, 55, 800-803.
- Keith, K. D., Heal, L. W., & Schalock, R. L. (1996). Cross-cultural measurement of critical quality of life concepts. *Journal of Intellectual and Disability Research*, 21, 273-293.
- Keith, T. Z. (1985). Questioning the K-ABC: What does it measure? *School Psychology Review*, 1, 21-36.
- Keith, T. Z., & Kranzler, J. H. (1999). The absence of structural fidelity precludes construct validity: Rejoinder to Naglieri on what the Cognitive Assessment System does and does not measure. *School Psychology Review*, 28, 117-144.
- Keith, T. Z., & Novak, C. G. (1987). Joint factor structure of the WISC-R and K-ABC for referred school children. *Journal of Psychoeducational Assessment*, 5(4), 370-386.
- Keith, T. Z., Powell, A. L., & Powell, L. R. (2001). Review of Wechsler Abbreviated Scale of Intelligence. En B. S. Plake & J. C. Impara (eds.), *The fourteenth mental measurements yearbook* (pp. 1329-1331). Lincoln: University of Nebraska Press.
- Keith, T. Z., & Witta, L. (1997). Hierarchical and cross-age confirmatory factor analysis of the WISC-III: What does it measure? *School Psychology Quarterly*, 12, 80-107.
- Kelley, C., & Meyers, J. (1992). *Cross-Cultural Adaptability Inventory*. Minneapolis, MN: NCS Assessments.
- Kelley, S. J. (1985). Drawings: Critical communications for the sexually abused child. *Pediatric Nursing*, 11, 421-426.
- Kelley, S. J. (1988). Physical abuse of children: Recognition and reporting. *Journal of Emergency Nursing*, 14(2), 82-90.
- Kelley, T. L. (1927). *Interpretation of educational measurements*. Yonkers, NY: World Book.
- Kelley, T. L. (1939). The selection of upper and lower groups for the validation of test items. *Journal of Educational Psychology*, 30, 17-24.
- Kellner, C. H., Jolley, R. R., Holgate, R. C., et al. (1991). Brain MRI in obsessive-compulsive disorder. *Psychiatric Research*, 36, 45-49.
- Kelly, D. H. (1966). Measurement of anxiety by forearm blood flow. *British Journal of Psychiatry*, 112, 789-798.
- Kelly, E. J. (1985). The personality of chess players. *Journal of Personality Assessment*, 49, 282-284.
- Kempen, J. H., Kritchevsky, M., & Feldman, S. T. (1994). Effect of visual impairment on neuropsychological test performance. *Journal of Clinical and Experimental Neuropsychology*, 16, 223-231.
- Kendall, P. C., Williams, L., Pechacek, T. F., Graham, L. E., Shisslak, C., & Herzof, N. (1979). Cognitive-behavioral and patient education interventions in cardiac catheterization procedures: The Palo Alto Medical Psychology Project. *Journal of Consulting and Clinical Psychology*, 47, 48-59.
- Kennedy, M. H., & Hiltonsmith, R. W. (1988). Relationships among the K-ABC Nonverbal Scale, the Pictorial Test of Intelligence and the Hiskey-Nebraska Test of Learning Aptitude for speech- and language-disabled preschool children. *Journal of Psychoeducational Assessment*, 6(1), 49-54.
- Kennedy, R. S., Bittner, A. C., Harbeson, M., & Jones, M. B. (1982). Television computer games: A "new look" in performance testing. *Aviation, Space and Environmental Medicine*, 53, 49-53.
- Kent, G. H., & Rosanoff, A. J. (1910). A study of association in insanity. *American Journal of Insanity*, 67, 37-96, 317-390.
- Kent, N., & Davis, D. R. (1957). Discipline in the home and intellectual development. *British Journal of Medical Psychology*, 30, 27-33.
- Kerlinger, F. N. (1973). *Foundations of behavioral research* (2nd ed.). New York: Holt.
- Kern, J. M., Miller, C., & Eggers, J. (1983). Enhancing the validity of role-play tests: A comparison of three role-play methodologies. *Behavior Therapy*, 14, 482-492.
- Khan, S. B., Alvi, S. A., Shaukat, N., & Hussain, M. A. (1990). A study of the validity of Holland's theory in a non-Western culture. *Journal of Vocational Behavior*, 36, 132-146.
- Kim, B. S. K., Atkinson, D. R., & Yang, P. H. (1999). The Asian Values Scale: Development, factor analysis, validation, and reliability. *Journal of Counseling Psychology*, 46, 342-352.
- King, D. A., Conwell, Y., Cox, C., et al. (2000). A neuropsychological comparison of depressed suicide attempters and nonattempters. *Journal of Neuropsychiatry and Clinical Neurosciences*, 12, 64-70.
- King, M. A., & Yuille, J. C. (1987). Suggestibility and the child witness. In S. J. Ceci, M. P. Toglia, & D. F. Ross (eds.), *Children's eyewitness testimony*. New York: Springer-Verlag.
- Kinslinger, H. J. (1966). Application of projective techniques in personnel psychology since 1940. *Psychological Bulletin*, 66, 134-149.
- Kinston, W., Loader, P., & Miller, L. (1985). *Clinical assessment of family health*. London: Hospital for Sick Children, Family Studies Group.
- Kippax, S., Campbell, D., Van de Ven, P., et al. (1998). Cultures of sexual adventurism as markers of HIV seroconversion: A case control study in a cohort of Sydney gay men. *AIDS Care*, 10, 677-688.
- Kirmayer, L. J., & Young, A. (1999). Culture and context in the evolutionary concept of mental disorder. *Journal of Abnormal Psychology*, 108, 446-452.
- Klanderma, J. W., Perney, J., & Kroeschell, Z. B. (1985). Comparison of the K-ABC and WISC-R for LD children. *Journal of Learning Disabilities*, 18, 524-527.

- Klein, D. F. (1999). Harmful dysfunction, disorder, disease, illness, and evolution. *Journal of Abnormal Psychology, 108*, 421-429.
- Kleinman, A., & Kleinman, J. (1991). Suffering and its professional transformation: Toward an ethnography of interpersonal experience. *Culture, Psychiatry and Medicine, 15*, 275-301.
- Kleinman, A. M., & Lin, T. Y. (1980). Introduction. En A. M. Kleinman & T. Y. Lin (eds.), *Normal and abnormal behavior in Chinese cultures* (pp. 1-6). Dordrecht, Netherlands: Reidel.
- Kleinmuntz, B., & Szucko, J. J. (1984). Lie detection in ancient and modern times: A call for contemporary scientific study. *American Psychologist, 39*, 766-776.
- Kline, R. B., & Lachar, D. (1992). Evaluation of age, sex, and race bias in the Personality Inventory for Children (PIC). *Psychological Assessment, 4*, 333-339.
- Kline, R. B., Lachar, D., & Boersma, D. C. (1993). Identification of special education needs with the Personality Inventory for Children (PIC): A hierarchical classification model. *Psychological Assessment, 5*, 307-316.
- Kline, R. B., Lachar, D., & Gdowski, C. L. (1992). Clinical validity of a Personality Inventory for Children (PIC) profile typology. *Psychological Assessment, 58*, 591-605.
- Kline, R. B., Lachar, D., & Sprague, D. J. (1985). The Personality Inventory for Children (PIC): An unbiased predictor of cognitive and academic status. *Journal of Pediatric Psychology, 10*, 461-477.
- Kline, R. B., Snyder, J., Guilmette, S., & Castellanos, M. (1993). External validity of the Profile Variability Index for the K-ABC, Stanford-Binet, and WISC-R: Another cul-de-sac. *Journal of Learning Disabilities, 26*, 557-567.
- Klinger, E. (1978). Modes of normal conscious flow. En K. S. Pope & J. L. Singer (eds.), *The stream of consciousness: Scientific investigations into the flow of human experience* (pp. 225-258). New York: Plenum.
- Klonoff, E. A., & Landrine, H. (1999). Acculturation and alcohol use among Blacks: The benefits of remaining culturally traditional. *Western Journal of Black Studies, 23*, 211-216.
- Klopfer, B., Ainsworth, M., Klopfer, W., & Holt, R. R. (1954). *Developments in the Rorschach technique: Vol. 1. Technique and theory*. Yonkers-on-Hudson, NY: World.
- Klopfer, B., & Davidson, H. (1962). *The Rorschach technique: An introductory manual*. New York: Harcourt.
- Kluckhohn, F. R. (1954). Dominant and variant value orientations. En C. Kluckhohn & H. A. Murray (eds.), *Personality in nature, society, and culture* (pp. 342-358). New York: Knopf.
- Kluckhohn, F. R. (1960). A method for eliciting value orientations. *Anthropological Linguistics, 2*(2), 1-23.
- Kluckhohn, F. R., & Strodtbeck, F. L. (1961). *Variations in value orientations*. Homewood, IL: Dorsey.
- Knapp, R. R. (1960). The effects of time limits on the intelligence test performance of Mexican and American subjects. *Journal of Educational Psychology, 51*, 14-20.
- Knoff, H. M. (1990a). Evaluation of projective drawings. En C. R. Reynolds and T. B. Gutkin (eds.), *Handbook of school psychology* (2nd ed., pp. 898-946). New York: Wiley.
- Knoff, H. M. (1990b). Review of Children's Depression Inventory. en J. J. Kramer & J. C. Conoley (eds.), *The supplement to the tenth mental measurements yearbook* (pp. 48-50). Lincoln: The Buros Institute of Mental Measurements, University of Nebraska.
- Knoff, H. M., & Prout, H. T. (1985). *The Kinetic Drawing System: Family and School*. Los Angeles: Western Psychological Services.
- Knowles, E. S., & Condon, C. A. (2000). Does the rose still smell as sweet? Item variability across test forms and revisions. *Psychological Assessment, 12*, 245-252.
- Kobak, K. A., Reynolds, W. M., & Geist, J. H. (1993). Development and validation of a computer administered version of the Hamilton Anxiety Scale. *Psychological Assessment, 5*, 487-492.
- Kolotkin, R. A., & Wielkiewicz, R. M. (1984). Effects of situational demand in the role-play assessment of assertive behavior. *Journal of Behavioral Assessment, 6*, 59-70.
- Kongs, S. K., Thompson, L. L., Iverson, G. L., & Heaton, R. K. (2000). *Wisconsin Card Sorting Test-64 Card Version (WCST-64)*. Odessa, FL: Psychological Assessment Resources.
- Koppitz, E. M. (1963). *The Bender-Gestalt Test for young children*. New York: Grune & Stratton.
- Koppitz, E. M. (1975). *The Bender-Gestalt Test for young children* (Vol. 2). New York: Grune & Stratton.
- Korchin, S. J., & Schuldberg, D. (1981). The future of clinical assessment. *American Psychologist, 36*, 1147-1158.
- Korkman, M. (1999). Applying Luria's diagnostic principles in the neuropsychological assessment of children. *Neuropsychology Review, 9*, 89-105.
- Korkman, M., Kirk, U., & Kemp, S. (1997). *NEPSY*. San Antonio, TX: Psychological Corporation.
- Korman, A. K. (1988). *The outsiders: Jews and corporate America*. Lexington, MA: Lexington.
- Koson, D., Kitchen, C., Kochen, M., & Stodolsky, D. (1970). Psychological testing by computer: Effect on response bias. *Educational and Psychological Measurement, 30*, 803-810.
- Kraepelin, E. (1892). *Über die Beeinflussung einfacher psychischer Vorgänge durch einige Arzneimittel*. Jena, Germany: Fischer.
- Kraepelin, E. (1895). Der psychologische versuch in der psychiatrie. *Psychologische Arbeiten, 1*, 1-91.
- Kraepelin, E. (1896). Der psychologische versuch in der psychiatrie. *Psychologische Arbeiten, 1*, 1-91.
- Kranzler, G., & Moursund, J. (1999). *Statistics for the terrified* (2nd ed.). Upper Saddle River, NJ: Prentice-Hall.
- Kranzler, J. H., & Keith, T. Z. (1999). Independent confirmatory factor analysis of the Cognitive Assessment System (CAS): What does the CAS measure? *School Psychology Review, 28*, 117-144.
- Krauss, D. A., & Sales, B. D. (1999). The problem of "helpfulness" in applying *Daubert* to expert testimony: Child custody determinations in family law as an exemplar. *Psychology, Public Policy, and Law, 5*, 78-99.
- Krauss, M. W. (1993). Child-related and parenting stress: Similarities and differences between mothers and fathers of children with disabilities. *American Journal on Mental Retardation, 97*, 393-404.
- Kresel, J. J., & Lovejoy, F. H. (1981). Poisonings and child abuse. En N. S. Ellerstein (ed.), *Child abuse and neglect: A medical reference* (pp. 307-313). New York: Wiley.
- Krikorian, R., & Bartok, J. A. (1998). Developmental data for the Porteus Maze Test. *Clinical Neuropsychologist, 12*, 305-310.
- Krohn, E. J., & Lamp, R. E. (1989). Concurrent validity of the K-ABC and Stanford-Binet—Fourth Edition for Head Start Children. *Journal of School Psychology, 27*(1), 59-67.
- Krohn, E. J., Lamp, R. E., & Phelps, C. G. (1988). Validity of the K-ABC for a black preschool population. *Psychology in the Schools, 25*, 15-21.
- Kronholz, J. (1998, February 12). As states end racial preferences, pressure rises to drop SAT to maintain minority enrollment. *Wall Street Journal*, p. A24.
- Kubiszyn, T. W., Meyer, G. J., Finn, S. E., et al. (2000). Empirical support for psychological assessment in clinical health care settings. *Professional Psychology: Research and Practice, 31*, 119-130.

- Kuder, F., Diamond, E. E., & Zytowski, D. G. (1998). Differentiation as fundamental validity for criterion-group and scaled interest inventories. *Educational and Psychological Measurement*, 58, 38-41.
- Kuder, G. F. (1979). *Kuder Occupational Interest Survey, Revised: General manual*. Chicago: Science Research Associates.
- Kuder, G. F., & Richardson, M. W. (1937). The theory of the estimation of reliability. *Psychometrika*, 2, 151-160.
- Kuhlmann, F. (1912). A revision of the Binet-Simon system for measuring the intelligence of children. *Journal of Psycho-Asthenics Monograph Supplement*, 1(1), 1-41.
- Kumho Tire Co. Ltd. vs Carmichael, 119 S. Ct. 1167 (1999).
- Kuncel, N. R., Hezlett, S. A., & Ones, D. S. (2001). A comprehensive meta-analysis of the predictive validity of the Graduate Record Examinations: Implications for graduate student selection and performance. *Psychological Bulletin*, 127, 162-181.
- Kupfer, D. J., First, M. B., & Regier, D. A. (eds.) (2002). *A research agenda for DSM-V*. Washington, DC: American Psychiatric Association.
- Lachar, D. (1982). *Personality Inventory for Children (PIC): Revised format manual supplement*. Los Angeles: Western Psychological Services.
- Lachar, D., Gdowski, C. L., & Snyder, D. K. (1985). Consistency of maternal report and the Personality Inventory for Children: Always useful and sometimes sufficient—Reply to Cornell. *Journal of Consulting and Clinical Psychology*, 53, 275-276.
- Lachar, D., & Gruber, C. P. (2001). *The Personality Inventory for Children, Second Edition (PIC-2)*. Los Angeles: Western Psychological Services.
- Lachar, D., Kline, R. B., & Boersma, D. C. (1986). The Personality Inventory for Children: Approaches to actuarial interpretation in clinic and school settings. En H. M. Knoff (ed.), *The psychological assessment of child and adolescent personality* (pp. 273-308). New York: Guilford.
- Lachar, D., & Wirt, R. D. (1981). A data-based analysis of the psychometric performance of the Personality Inventory for Children (PIC): An alternative to the Achenbach review. *Journal of Personality Assessment*, 45, 614-616.
- Lacks, P. (1999). *Bender-Gestalt screening for brain dysfunction*. New York: Wiley.
- LaCombe, J. A., Kline, R. B., Lachar, D., Butkus, M., & Hillman, S. B. (1991). Case history correlates of a Personality Inventory for Children (PIC) profile typology. *Psychological Assessment*, 3, 678-687.
- Lah, M. I. (1989). New validity, normative, and scoring data for the Rotter Incomplete Sentences Blank. *Journal of Personality Assessment*, 53, 607-620.
- Laidlaw, T. M. (1999). Designer testing: Using subjects' personal vocabulary to produce individualised tests. *Personality and Individual Differences*, 27, 1197-1207.
- Laker, D. R. (2002). The career wheel: An exercise for exploring and validating one's career choices. *Journal of Employment Counseling*, 39, 61-72.
- Lally, S. J. (2003). What tests are acceptable for use in forensic evaluations? A survey of experts. *Professional Psychology: Research & Practice*, 34, 491-498.
- Lam, C. S., Chan, F., Hilburger, J., Heimburger, M., Hill, V., & Kaplan, S. (1993). Canonical relationships between vocational interests and aptitudes. *Vocational Evaluation and Work Adjustment Bulletin*, 26, 155-160.
- Lamb, M. E. (ed.). (1981). *The role of the father in child development* (2nd ed.). New York: Wiley.
- Lambert, E. W., & Engum, E. S. (1992). Construct validity of the Cognitive Behavioral Driver's Inventory: Age, diagnosis, and driving ability. *Journal of Cognitive Rehabilitation*, 10, 32-45.
- Lambert, N., Nihira, K., & Leland, H. (1993). *AAMR Adaptive Behavior Scale-School-Second Edition: Examiner's manual*. Austin, TX: PRO-ED.
- Lamp, R. E., & Krohn, E. J. (1990). Stability of the Stanford-Binet Fourth Edition and K-ABC for young black and white children from low-income families. *Journal of Psychoeducational Assessment*, 8, 139-149.
- Lamp, R. E., & Krohn, E. J. (2001). A longitudinal predictive validity investigation of the SB:FE and K-ABC with at-risk children. *Journal of Psychoeducational Assessment*, 19, 334-349.
- Landrum, M. S., & Ward, S. B. (1993). Behavioral assessment of gifted learners. *Journal of Behavioral Education*, 3, 211-215.
- Landy, F. J. (1986). Stamp collecting versus science. *American Psychologist*, 41, 1183-1192.
- Landy, F. J., & Farr, J. H. (1980). Performance rating. *Psychological Bulletin*, 87, 72-107.
- Lane, H. (1992). *The mask of benevolence: Disabling the deaf community*. New York: Vintage.
- Lane, J. C. (1992, August). Threat management fills void in police services. *Police Chief*, pp. 27-29, 31.
- Lang, P. J., Greenwald, M. K., Bradley, M. M., & Hamm, A. O. (1993). Looking at pictures: Affective, facial, visceral, and behavioral reactions. *Psychophysiology*, 30, 261-273.
- Langer, E. J., & Abelson, R. P. (1974). A patient by any other name: Clinician group difference in labeling bias. *Journal of Consulting and Clinical Psychology*, 42, 4-9.
- Langlois, J. H., Ritter, J. M., Casey, R. J., & Sawin, D. B. (1995). Infant attractiveness predicts maternal behaviors and attitudes. *Developmental Psychology*, 31, 464-472.
- Lanyon, R. I. (1984). Personality assessment. *Annual Review of Psychology*, 35, 667-701.
- Lanyon, R. I. (1993a). Assessment of truthfulness in accusations of child molestation. *American Journal of Forensic Psychology*, 11, 29-44.
- Lanyon, R. I. (1993b). Development of scales to assess specific deception strategies on the Psychological Screening Inventory. *Psychological Assessment*, 5, 324-329.
- Larkin, J. E., Pines, H. A., & Bechtel, K. M. (2002). Facilitating students' career development in psychology courses: A portfolio project. *Teaching of Psychology*, 29, 207-210.
- Larson, L. M., & Borgen, F. H. (2002). Convergence of vocational interests and personality: Examples in an adolescent gifted sample. *Journal of Vocational Behavior*, 60, 91-112.
- Larson, L. M., & Majors, M. S. (1998). Applications of the Coping with Career Indecision instrument with adolescents. *Journal of Career Assessment*, 6, 163-179.
- Larson, L. M., Rottinghaus, P. J., & Borgen, F. H. (2002). Meta-analyses of big six interests and big five personality factors. *Journal of Vocational Behavior*, 61, 217-239.
- La Rue, A., & Watson, J. (1998). Psychological assessment of older adults. *Professional Psychology: Research and Practice*, 29, 5-14.
- Larvie, V. (1994). Evidence—Admissibility of scientific evidence in federal courts—The Supreme Court decides Frye is dead and the Federal Rules of Evidence provide the standard, but is there a skeleton in the closet? *Daubert v. Pharmaceuticals*, 113 S. Ct. 2786. *Land & Water Review*, 29, 275-309.
- Larzelere, R., & Huston, T. (1980). The Dyadic Trust Scale: Toward understanding interpersonal trust in close relationships. *Journal of Marriage and the Family*, 43, 595-604.
- Latimer, E. J. (1991). Ethical decision-making in the care of the dying and its applications to clinical practice. *Journal of Pain and Symptom Management*, 6, 329-336.

- Lattimore, R. R., & Borgen, F. H. (1999). Validity of the 1994 Strong Interest Inventory with racial and ethnic groups in the United States. *Journal of Counseling Psychology*, 46, 185-195.
- Laurence, J. R., & Perry, C. W. (1988). *Hypnosis, will, and memory*. New York: Guilford.
- Lavin, M. (1992). The Hopkins Competency Assessment Test: A brief method for evaluating patients' capacity to give informed consent. *Hospital and Community Psychiatry*, 43, 132-136.
- Lavrakas, P. J. (1998). Methods for sampling and interviewing in telephone surveys. En L. Bickman & D. J. Rog (eds.), *Handbook of applied social research methods* (pp. 429-472). Thousand Oaks, CA: Sage.
- Lawlor, J. (1990, September 27). Loopholes found in truth tests. *USA Today*, p. D-1.
- Lawrence, B. S. (1996). Organizational age norms: Why is it so hard to know one when you see one? *Gerontologist*, 36, 209-220.
- Lawrence, J., Davidoff, D. A., Katt-Lloyd, D., et al. (2000). A pilot program of community-based screening for memory impairment. *Journal of the American Geriatrics Society*, 48, 854-855.
- Lawshe, C. H. (1975). A quantitative approach to content validity. *Personnel Psychology*, 28, 563-575.
- Lazarus, A. A. (1973). Multimodal behavior therapy: Treating the BASIC ID. *Journal of Nervous and Mental Disease*, 156, 404-411.
- Lazarus, A. A. (1989). *The practice of multimodal therapy*. Baltimore: Johns Hopkins University Press.
- Lea, E., & Worsley, A. (2001). Influences on meat consumption in Australia. *Appetite*, 36, 127-136.
- Leahy, A. (1932). A study of certain selective factors influencing prediction of the mental status of adopted children or adopted children in nature-nurture research. *Journal of Genetic Psychology*, 41, 294-329.
- Leahy, A. M. (1935). Nature-nurture and intelligence. *Genetic Psychology Monographs*, 17, 241-306.
- Lee, S. D. (1968). *Social class bias in the diagnosis of mental illness*. Unpublished doctoral dissertation, University of Oklahoma.
- Lee, S.-J., & Tedeschi, J. T. (1996). Effects of norms and norm-violations on inhibition and instigation of aggression. *Aggressive Behavior*, 22, 17-25.
- Leigh, I. W., Corbett, C. A., Gutman, V., & Moore, D. A. (1996). Providing psychological services to deaf individuals: A response to new perceptions of diversity. *Professional Psychology: Research and Practice*, 27, 364-371.
- Leon-Carrion, J., et al. (1991). The computerized Tower of Hanoi: A new form of administration and suggestions for interpretation. *Perceptual and Motor Skills*, 73, 63-66.
- Leong, F. T., & Hartung, P. J. (2000). Cross-cultural career assessment: Review and prospects for the new millennium. *Journal of Career Assessment*, 8, 391-401.
- Lerner, B. (1980). *Minimum competence, maximum choice: Second chance legislation*. New York: Irvington.
- Lerner, B. (1981). The minimum competence testing movement: Social, scientific, and legal implications. *American Psychologist*, 36, 1056-1066.
- Lerner, P. M. (1991). *Psychoanalytic theory and the Rorschach*. New York: Analytic.
- Lerner, P. M. (1996a). Current perspectives on psychoanalytic Rorschach assessment. *Journal of Personality Assessment*, 67, 450-461.
- Lerner, P. M. (1996b). The interpretive process in Rorschach testing. *Journal of Personality Assessment*, 67, 494-500.
- Lesser, G. S., Fifer, G., & Clark, D. H. (1965). Mental abilities of children from different social-class and cultural groups. *Monographs of the Society for Research in Child Development*, 30 (Serial No. 102).
- Lessinger, L. H. (1998). The relationship between cultural identity and MMPI-2 scores of Mexican-American substance abuse patients. *Dissertation Abstracts International, Section B: The Sciences & Engineering*, 59(2-B), 877.
- Levack, N. (1991). *Low vision: A resource guide with adaptations for students with visual impairments*. Austin: Texas School for the Blind and Visually Impaired.
- Levesque, L. L., Wilson, J. M., & Wholey, D. R. (2001). Cognitive divergence and shared mental models in software development project teams. *Journal of Organizational Behavior*, 22, 135-144.
- Levine, E., & Padilla, A. (1980). *Crossing cultures in therapy*. Monterey, CA: Brooks/Cole.
- Levy-Shiff, R., Dimitrovsky, L., Shulman, S., & Har-Even, D. (1998). Cognitive appraisals, coping strategies, and support resources as correlates of parenting and infant development. *Developmental Psychology*, 34, 1417-1427.
- Lewinsohn, P. M., Rohde, P., & Seeley, J. R. (1996). Adolescent suicidal ideation and attempts: Prevalence, risk factors and clinical implications. *Clinical Psychology: Science and Practice*, 3, 25-46.
- Lewis-Fernandez, R. (1998). A cultural critique of the DSM-IV dissociative disorders section. *Transcultural Psychiatry*, 35, 387-400.
- Lewis-Fernandez, R., & Diaz, N. (2002). The cultural formulation: A method for assessing cultural factors affecting the clinical encounter. *Psychiatric Quarterly*, 73, 271-295.
- Lezak, M. D. (2002). Responsive assessment and the freedom to think for ourselves. *Rehabilitation Psychology*, 47, 339-353.
- Li, H., Kuo, C., & Russel, M. G. (1999). The impact of perceived channel utilities, shopping orientations, and demographics on the consumer's online buying behavior. *Journal of Computer-Mediated Communication*, 5(2).
- Li, J. (2003). The core of Confucian learning. *American Psychologist*, 58, 146-147.
- Libby, W. (1908). The imagination of adolescents. *American Journal of Psychology*, 19, 249-252.
- Lichtenstein, B., & Nansel, T. R. (2000). Women's douching practices and related attitudes: Findings from four focus groups. *Women and Health*, 31, 117-131.
- Lichtenstein, D., Dreger, R. M., & Cattell, R. B. (1986). Factor structure and standardization of the Preschool Personality Questionnaire. *Journal of Social Behavior and Personality*, 1, 165-181.
- Lidz, C. S. (1987). Historical perspectives. En C. S. Lidz (ed.), *Dynamic assessment: An interactional approach to evaluating learning potential* (pp. 288-326). New York: Guilford.
- Lidz, C. S. (1991). *Practitioner's guide to dynamic assessment*. New York: Guilford.
- Lidz, C. S. (1996). Dynamic assessment and the legacy of L. S. Vygotsky. *School Psychology International*, 16, 143-154.
- Lidz, C. W., Mulvey, E. P., & Gardner, W. (1993). The accuracy of predictions of violence to others. *Journal of the American Medical Association*, 269, 1007-1011.
- Lievens, F., Decaestecker, C., & Christoph, C. P. (2001). Organizational attractiveness for prospective applicants. *Applied Psychology: An International Review*, 50, 30-51.
- Lighthouse Research Institute. (1995). *The Lighthouse National Survey on Vision Loss*. New York: The Lighthouse, Inc.
- Likert, R. (1932). A technique for the measurement of attitudes. *Archives of Psychology*, Number 140.

- Lilienfeld, S. O., & Marino, L. (1995). Mental disorder as a Roschian concept: A critique of Wakefield's "harmful dysfunction" analysis. *Journal of Abnormal Psychology, 104*, 411-420.
- Lilienfeld, S. O., & Marino, L. (1999). Essentialism revisited: Evolutionary theory and the concept of mental disorder. *Journal of Abnormal Psychology, 108*, 400-411.
- Lilienfeld, S. O., Wood, J. M., & Garb, H. N. (2000). The scientific status of projective techniques. *Psychological Science in the Public Interest, 1*(2), 27-66.
- Lillibridge, J. R., & Williams, K. J. (1992). Another look at personality and managerial potential: Application of the five-factor model. En K. Kelley (ed.), *Issues, theory, and research in industrial/organizational psychology: Advances in psychology, 82* (pp. 91-115). Oxford, England: North-Holland.
- Lim, J., & Butcher, J. N. (1996). Detection of faking on the MMPI-2: Differentiation among faking-bad, denial, and claiming extreme virtue. *Journal of Personality Assessment, 67*, 1-25.
- Lindell, M. K., Brandt, C. J., & Whitney, D. J. (1999). A revised index of interrater agreement for multi-item ratings of a single target. *Applied Psychological Measurement, 23*, 127-135.
- Lindgren, B. (1983, August). N or N-1? [Letter to the editor]. *American Statistician*, p. 52.
- Lindskog, C. O., & Smith, J. V. (2001). Review of Wechsler Abbreviated Scale of Intelligence. En B. S. Plake & J. C. Impara (eds.), *The fourteenth mental measurements yearbook* (pp. 1331-1332). Lincoln: University of Nebraska Press.
- Lindstrom, E., Wieselgren, I. M., & von Knorring, L. (1994). Interrater reliability of the Structured Clinical Interview for the Positive and Negative Syndrome Scale for schizophrenia. *Acta Psychiatrica Scandinavica, 89*, 192-195.
- Linehan, M. M., Goodstein, J. L., Nielsen, S. L., & Chiles, J. A. (1983). Reasons for staying alive when you are thinking of killing yourself: The Reasons for Living Inventory. *Journal of Consulting and Clinical Psychology, 51*, 276-286.
- Lippmann, W. (1922, October). The mental age of Americans. *New Republic*.
- Lipsitt, P. D., Losos, D., & McGarry, A. L. (1971). Competency for trial: A screening instrument. *American Journal of Psychiatry, 128*, 105-109.
- Lipton, J. P. (1999). The use and acceptance of social science evidence in business litigation after Daubert. *Psychology, Public Policy, and Law, 5*, 59-77.
- Locke, E. A. (1976). The nature and causes of job satisfaction. In M. D. Dunnette (ed.), *Handbook of industrial and organizational psychology*. Chicago: Rand McNally.
- Locke, H. J., & Wallace, K. M. (1959). Short marital adjustment and prediction tests: Their reliability and validity. *Marriage and Family Living, 21*, 251-255.
- Loevinger, J. (1966). The meaning and measurement of ego development. *American Psychologist, 21*, 195-206.
- Loevinger, J., & Ossorio, A. G. (1958). Evaluation of therapy by self-report: A paradox. *American Psychologist, 13*, 366.
- Loevinger, J., Wessler, R., & Redmore, C. (1970). *Measuring ego development: Vol. 1. Construction and use of a sentence completion test. Vol. 2. Scoring manual for women and girls*. San Francisco: Jossey-Bass.
- Loewenstein, D. A., Rubert, M. P., Berkowitz-Zimmer, N., Guterman, A., Morgan, R., & Hayden, S. (1992). Neuropsychological test performance and prediction of functional capacities in dementia. *Behavior, Health, and Aging, 2*, 149-158.
- Loftin, M. (1997). Critical factors in assessment of students with visual impairments. *RE:view, 28*, 149-159.
- Loftus, E. F., & Davies, G. M. (1984). Distortions in the memory of children. *Journal of Social Issues, 40*, 51-67.
- Lohman, D. F. (1989). Human intelligence: An introduction to advances in theory and research. *Review of Educational Research, 59*, 333-373.
- London, P. (1976). Psychotherapy for religious neuroses? Comments on Cohen and Smith. *Journal of Consulting and Clinical Psychology, 44*, 145-147.
- Longabaugh, R. (1980). The systematic observation of behavior in naturalistic settings. En H. C. Triandis & J. W. Berry (eds.), *Handbook of cross-cultural psychology: Vol. 2. Methodology* (pp. 57-126). Boston: Allyn & Bacon.
- Lonner, W. J. (1985). Issues in testing and assessment in cross-cultural counseling. *Counseling Psychologist, 13*, 599-614.
- López, S. (1988). The empirical basis of ethnocultural and linguistic bias in mental health evaluations of Hispanics. *American Psychologist, 42*, 228-234.
- López, S., & Hernandez, P. (1987). When culture is considered in the evaluation and treatment of Hispanic patients. *Psychotherapy, 24*, 120-127.
- López, S. R. (1989). Patient variable biases in clinical judgment: A conceptual overview and methodological considerations. *Psychological Bulletin, 106*, 184-203.
- López, S. R. (2000). Teaching culturally informed psychological assessment. In R. H. Dana (ed.), *Handbook of cross-cultural and multicultural personality assessment* (pp. 669-687). Mahwah, NJ: Erlbaum.
- López, S. R. (2002). Teaching culturally informed psychological assessment: Conceptual issues and demonstrations. *Journal of Personality, 79*, 226-234.
- Lord, F. M. (1980). *Applications of item response theory to practical testing problems*. Hillsdale, NJ: Erlbaum.
- Lorr, M. (1991). An empirical evaluation of the MBTI typology. *Personality and Individual Differences, 12*, 1141-1145.
- Lovejoy, M. C., Weis, R., O'Hare, E., & Rubin, E. (1999). Development and initial validation of the Parent Behavior Inventory. *Psychological Assessment, 11*, 534-545.
- Lowitzer, A. C., Utley, C. A., & Baumeister, A. A. (1987). AAMD's 1983 Classification in Mental Retardation as utilized by state mental retardation/developmental disabilities agencies. *Mental Retardation, 25*, 287-291.
- Lowman, J. C. (1980). Measurement of family affective structure. *Journal of Personality Assessment, 44*, 130-141.
- Loyd, B. H., & Abidin, R. R. (1985). Revision of the Parenting Stress Index. *Journal of Pediatric Psychology, 10*, 169-177.
- Lubin, B., Wallis, R. R., & Paine, C. (1971). Patterns of psychological test usage in the United States: 1935-1969. *Professional Psychology, 2*, 70-74.
- Luckasson, R., Schalock, R. L., Snell, M. E., & Spitalnik, D. M. (1996). The 1992 AAMR definition and preschool children: Response from the Committee on Terminology and Classification. *Mental Retardation, 34*, 247-253.
- Lukin, M. E., Dowd, E. T., Plake, B. S., & Kraft, R. G. (1985). Comparing computerized versus traditional psychological assessment. *Computers in Human Behavior, 1*, 49-58.
- Lumley, V. A., & Miltenberger, R. G. (1997). Sexual abuse prevention for persons with mental retardation. *American Journal on Mental Retardation, 101*, 459-472.
- Lumley, V. A., Miltenberger, R. G., Long, E. S., Rapp, J. T., & Roberts, J. A. (1998). Evaluation of a sexual abuse prevention program for adults with mental retardation. *Journal of Applied Behavior Analysis, 31*, 91-101.

- Lung, R. J., Miller, S. H., Davis, T. S., & Graham, W. P. (1977). Recognizing burn injuries as abuse. *American Family Physician*, 15, 134-135.
- Luria, A. R. (1966a). *Human brain and psychological processes*. New York: Harper & Row.
- Luria, A. R. (1966b). *Higher cortical functions in man*. New York: Basic.
- Luria, A. R. (1970, March). The functional organization of the brain. *Scientific American*, 222, 66-78.
- Luria, A. R. (1973). *The working brain: An introduction to neuropsychology*. New York: Basic.
- Luria, A. R. (1980). *Higher cortical functions in man* (2nd ed.). New York: Basic.
- Lutey, C., & Copeland, E. P. (1982). Cognitive assessment of the school-age child. En C. R. Reynolds & T. B. Gutkin (eds.), *The handbook of school psychology*. New York: Wiley.
- Lykken, D. T. (1981). *A tremor in the blood: Uses and abuses of the lie detector*. New York: McGraw-Hill.
- Lyman, H. B. (1972). Review of the Wechsler Adult Intelligence Scale. En O. K. Buros (ed.), *The seventh mental measurements yearbook* (pp. 788-790). Highland Park, NJ: Gryphon.
- Lynn, R. (1997). Direct evidence for a genetic basis for black-white differences in IQ. *American Psychologist*, 5, 73-74.
- Lyons, J. A., & Scotti, J. R. (1994). Comparability of two administration formats of the Keane Posttraumatic Stress Disorder Scale. *Psychological Assessment*, 6, 209-211.
- MacAndrew, C. (1965). The differentiation of male alcoholic outpatients from nonalcoholic psychiatric outpatients by means of the MMPI. *Quarterly Journal of Studies on Alcohol*, 26, 238-246.
- Machover, K. (1949). *Personality projection in the drawing of the human figure: A method of personality investigation*. Springfield, IL: Charles C Thomas.
- Mack, J. L., & Patterson, M. B. (1995). Executive dysfunction and Alzheimer's disease: Performance on a test of planning ability—the Porteus Maze Test. *Neuropsychology*, 9, 556-564.
- Macmillan, D. L., Gresham, F. M., & Siperstein, G. N. (1995). Heightened concerns over the 1992 AAMR definition: Advocacy versus precision. *American Journal on Mental Retardation*, 100, 87-95.
- Macmillan, D. L., & Meyers, C. E. (1980). Larry P.: An education interpretation. *School Psychology Review*, 9, 136-148.
- Mael, F. A. (1991). Career constraints of observant Jews. *Career Development Quarterly*, 39, 341-349.
- Magnello, M. E., & Spies, C. J. (1984). Francis Galton: Historical antecedents of the correlation calculus. En B. Laver (Chair), *History of mental measurement: Correlation, quantification, and institutionalization*. Paper session presented at the 92nd annual convention of the American Psychological Association, Toronto, Ontario, Canada.
- Maher, L. (1996). Hidden in the light: Occupational norms among crack-using street-level sex workers. *Journal of Drug Issues*, 26, 143-173.
- Malec, J. F., Ivnik, R. J., & Smith, G. E. (1993). *Neuropsychology and normal aging*. En R. W. Parks, R. F. Zec, & R. S. Wilson (eds.), *Neuropsychology of Alzheimer's disease and other dementias* (pp. 81-111). New York: Oxford University Press.
- Malgady, R. G., Costantino, G., & Rogler, L. H. (1984). Development of a Thematic Apperception Test (TEMAS) for urban Hispanic children. *Journal of Consulting and Clinical Psychology*, 52, 986-996.
- Malgady, R. G., Rogler, L. H., & Constantino, G. (1987). Ethnocultural and linguistic bias in mental health evaluations of Hispanics. *American Psychologist*, 42, 228-234.
- Maller, S. J. (1997). Deafness and WISC-III item difficulty: Invariance and fit. *Journal of School Psychology*, 35, 299-314.
- Maller, S. J., & Braden, J. P. (1993). The construct and criterion-related validity of the WISC-III with deaf adolescents. *Journal of Psychoeducational Assessment*, WISC-III Monograph, 105-113.
- Malone, P. S., Brounstein, P. J., van Brock, A., & Shaywitz, S. S. (1991). Components of IQ scores across levels of measured ability. *Journal of Applied Social Psychology*, 21, 15-28.
- Maloney, M. P., & Ward, M. P. (1976). *Psychological assessment*. New York: Oxford University Press.
- Mannarino, A. P., Cohen, J. A., & Berman, S. R. (1994). The Children's Attributions and Perceptions Scale: A new measure of sexual-abuse related factors. *Journal of Clinical Child Psychology*, 23, 204-211.
- Manz, C. C., & Sims, H. P. (1984). Searching for the "unleader": Organizational member views on leading self-managed groups. *Human Relations*, 37, 409-424.
- Maraist, C. C., & Russell, M. T. (2002). 16PF Fifth Edition norm supplement. Champaign, IL: Institute for Personality and Ability Testing.
- Maranell, G. M. (1974). *Scaling: A sourcebook for behavioral scientists*. Chicago: Aldine.
- Maraun, M. D. (1996a). Metaphor taken as math: Indeterminacy in the factor analysis model. *Multivariate Behavioral Research*, 31, 517-538.
- Maraun, M. D. (1996b). Meaning and mythology in the factor analysis model. *Multivariate Behavioral Research*, 31, 603-616.
- Maraun, M. D. (1996c). The claims of factor analysis. *Multivariate Behavioral Research*, 31, 673-689.
- Marchese, M. C. (1992). Clinical versus actuarial prediction: A review of the literature. *Perceptual and Motor Skills*, 75, 583-594.
- Mardell-Czudnowski, C., & Goldenberg, D. S. (1998). *Developmental Indicators for the Assessment of Learning—3* (DIAL-3). Circle Pines, MN: American Guidance Service.
- Mardell-Czudnowski, C. D., & Goldenberg, D. S. (1983, 1990). *Developmental Indicators for the Assessment of Learning—Revised*. Circle Pines, MN: American Guidance Service.
- Mark, M. M. (1999). Social science evidence in the courtroom: *Daubert and beyond?* *Psychology, Public Policy, and Law*, 5, 175-193.
- Marks, I. (1999). Computer aids to mental health care. *Canadian Journal of Psychiatry*, 44, 548-555.
- Marquette, B. W. (1976). *Limitations on the generalizability of adult competency across all situations*. Paper presented at the annual meeting of the Western Psychological Association, Los Angeles.
- Martens, M. P., Cox, R. H., Beck, N. C., & Heppner, P. P. (2003). Measuring motives for intercollegiate athlete alcohol use: A confirmatory factor analysis of the Drinking Motives Measure. *Psychological Assessment*, 15, 235-239.
- Martin, D. C., & Bartol, K. M. (1986). Holland's Vocational Preference Inventory and the Myers-Briggs Type Indicator as predictors of vocational choice among Master's of Business Administration. *Journal of Vocational Behavior*, 29, 51-65.
- Marx, E. (1998). Sibling antagonism transformed during assessment in the home. En L. Handler (Chair), *Conducting assessments in clients' homes: Contexts, surprises, dilemmas, opportunities*. Symposium presented at the Society for Personality Assessment 1998 Midwinter Meeting, February 20.
- Maslach, C., Jackson, S. E., & Leiter, M. P. (1996). *The Maslach Burnout Inventory* (3rd ed.). Palo Alto, CA: Consulting Psychologists Press.
- Maslach, C., Jackson, S. E., & Leiter, M. P. (1997). The Maslach Burnout Inventory. En C. P. Zalaquett & R. J. Wood (eds.),

- Evaluating stress: A book of resources* (3rd ed., pp. 191-218). Lanham, MD: Scarecrow.
- Masling, J. (1960). The influence of situational and interpersonal variables in projective testing. *Psychological Bulletin*, 57, 65-85.
- Masling, J. (1965). Differential indoctrination of examiners and Rorschach responses. *Journal of Consulting Psychology*, 29, 198-201.
- Masling, J. M. (1997). On the nature and utility of projective tests and objective tests. *Journal of Personality Assessment*, 69, 257-270.
- Maslow, A. H. (1943). A theory of motivation. *Psychological Review*, 50, 370-396.
- Maslow, A. H. (1970). *Motivation and personality* (2nd ed.). New York: Harper & Row.
- Massey, D. S. (2000). When surveys fail: An alternative for data collection. En A. A. Stone et al. (eds.), *The science of self-report: Implications for research and practice* (pp. 145-160). Mahwah, NJ: Erlbaum.
- Massil, H. (1995). Postpartum sexual function: What is the norm? *Sexual and Marital Therapy*, 10, 263-276.
- Mast, B. T., & Lichtenberg, P. A. (2000). Assessment of functional abilities among geriatric patients: A MIMIC model of the functional independence measure. *Rehabilitation Psychology*, 45, 49-64.
- Masuda, M., Matsumoto, G. H., & Meredith, G. M. (1970). Ethnic identity in three generations of Japanese Americans. *Journal of Social Psychology*, 81, 199-207.
- Matarazzo, J. D. (1972). *Wechsler's measurement and appraisal of adult intelligence* (5th ed.). Baltimore: Williams & Wilkins.
- Matarazzo, J. D. (1990). Psychological assessment versus psychological testing: Validation from Binet to the school, clinic, and courtroom. *American Psychologist*, 45, 999-1017.
- Matarazzo, J. D., & Wiens, A. N. (1977). Black Intelligence Test of Cultural Homogeneity and Wechsler Adult Intelligence Scale scores of black and white police applicants. *Journal of Applied Psychology*, 62, 57-63.
- Matchett, W. F. (1972). Repeated hallucinatory experiences as part of the mourning process. *Psychiatry*, 35, 185-194.
- Mathieu, J. E., & Zajac, D. M. (1990). A review and meta-analysis of the antecedents, correlates, and consequences of organizational commitment. *Psychological Bulletin*, 108, 171-194.
- Matson, J. L. (1995). Comments on Gresham, MacMillan, and Siperstein's paper "Critical analysis of the 1992 AAMR definition: Implications for school psychology." *School Psychology Quarterly*, 10(1), 20-23.
- Matson, J. L., Smirolido, B. B., & Hastings, T. L. (1998). Validity of the Autism/Pervasive Developmental Disorder subscale of the Diagnostic Assessment for the Severely Handicapped-II. *Journal of Autism & Developmental Disorders*, 28, 77-81.
- Matsumoto, D., & Kudoh, T. (1993). American-Japanese cultural differences in attributions of personality based on smiles. *Journal of Nonverbal Behavior*, 17, 231-243.
- Matsumoto, G. M., Meredith, G. M., & Masuda, M. (1970). Ethnic identification: Honolulu and Seattle Japanese-Americans. *Journal of Cross-Cultural Psychology*, 1, 63-76.
- Maurer, T. J., & Alexander, R. A. (1991). Contrast effects in behavioral measurement: An investigation of alternative process explanations. *Journal of Applied Psychology*, 76, 3-10.
- Maurer, T. J., Palmer, J. K., & Ashe, D. K. (1993). Diaries, checklists, evaluations, and contrast effects in measurement of behavior. *Journal of Applied Psychology*, 78, 226-231.
- Mayfield, E. C. (1972). Value of peer nominations in predicting life insurance sales performance. *Journal of Applied Psychology*, 56, 319-323.
- Mays, V. M., Cochran, S. D., Hamilton, E., & Miller, N. (1993). Just cover up: Barriers to heterosexual and gay young adults' use of condoms. *Health Values: The Journal of Health Behavior, Education, and Promotion*, 17, 41-47.
- Mazzocco, M. M. M., Hagerman, R. J., & Pennington, B. F. (1992). Problem-solving limitations among cytogenetically expressing Fragile X women. *American Journal of Medical Genetics*, 43, 78-86.
- McArthur, C. (1992). Rumbly of a distant drum. *Journal of Counseling and Development*, 70, 517-519.
- McArthur, D. S., & Roberts, G. E. (1982). *Roberts Apperception Test for Children manual*. Los Angeles: Western Psychological Services.
- McBride, B. A. (1989). Stress and fathers' parental competence: Implications for family life and parent educators. *Family Relations*, 38, 385-389.
- McCall, W. A. (1922). *How to measure in education*. New York: Macmillan.
- McCall, W. A. (1939). *Measurement*. New York: Macmillan.
- McCarley, N. G., & Escoto, C. A. (2003). Celebrity worship and psychological type. *North American Journal of Psychology*, 5, 117-120.
- McCaulley, M. H. (2000). Myers-Briggs Type Indicator: A bridge between counseling and consulting. *Consulting Psychology Journal: Practice and Research*, 52, 117-132.
- McCaulley, M. H. (2002). Autobiography: Mary H. McCaulley. *Journal of Psychological Type*, 61, 51-59.
- McClelland, D. C. (1951). *Personality*. New York: Holt-Dryden.
- McClelland, D. C. (1961). *The achieving society*. Princeton, NJ: Van Nostrand.
- McCloskey, G. W. (1989, March). *The K-ABC sequential simultaneous information processing model and classroom intervention: A report—the Dade County Classroom research study*. Paper presented at the Annual Meeting of the National Association of School Psychologists, Boston.
- McClure-Butterfield, P. (1990). Issues in child custody evaluation and testimony. En C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Personality, behavior and context* (pp. 576-588). New York: Guilford.
- McConkey, K. M., & Sheehan, P. W. (1996). *Hypnosis, memory, and behavior in criminal investigation*. New York: Guilford.
- McCool, J. P., Cameron, L. D., & Petrie, K. J. (2001). Adolescent perceptions of smoking imagery in film. *Social Science & Medicine*, 52, 1577-1587.
- McCoy, G. F. (1972). *Diagnostic evaluation and educational programming for hearing impaired children*. Springfield, IL: Office of the Illinois Superintendent of Public Instruction.
- McCrary, B. S., & Bux, D. A. (1999). Ethical issues of informed consent with substance abusers. *Journal of Consulting and Clinical Psychology*, 67, 186-193.
- McCrae, R. R., & Costa, P. T., Jr. (1983). Social desirability and scales: More substance than style. *Journal of Consulting and Clinical Psychology*, 51, 882-888.
- McCrae, R. R., Costa, P. T., Jr., Dahlstrom, W. G., Barefoot, J. C., Siegler, I. C., & Williams, R. B., Jr. (1989). A caution on the use of the MMPI K-correction in research on psychosomatic medicine. *Psychosomatic Medicine*, 51, 58-65.
- McCrae, R. R., Costa, P. T., Jr., Del Pilar, G. H., Rolland, J.-P., & Parker, W. D. (1998). Cross-cultural assessment of the five-factor model: The Revised NEO Personality Inventory. *Journal of Cross-Cultural Psychology*, 29, 171-188.
- McCrae, R. R., Costa, P. T., Jr., Terracciano, A., et al. (2002). Personality trait development from age 12 to age 18: Longitudinal, cross-sectional and cross-cultural analyses. *Journal of Personality & Social Psychology*, 83, 1456-1468.

- McCubbin, H., Larsen, A., & Olson, D. (1985a). F-COPES: Family Crisis Oriented Personal Evaluation Scales. En D. H. Olson, H. I. McCubbin, H. L. Barnes, A. S. Larsen, M. Muxen, & M. Wilson (eds.), *Family inventories* (rev. ed.). St. Paul: Family Social Science, University of Minnesota.
- McCubbin, H. I., Patterson, J. M., & Wilson, L. R. (1985b). FILE: Family Inventory of Life Events and Changes. En D. H. Olson, H. I. McCubbin, H. L. Barnes, A. S. Larsen, M. Muxen, & M. Wilson (eds.), *Family inventories* (rev. ed.). St. Paul: Family Social Science, University of Minnesota.
- McCusker, P. J. (1994). Validation of Kaufman, Ishikuma, Kaufman-Packer's Wechsler Adult Intelligence Scale—Revised short forms on a clinical sample. *Psychological Assessment*, 6, 246-248.
- McDermott, P. A., Alterman, A. I., Brown, L., et al. (1996). Construct refinement and confirmation for the Addiction Severity Index. *Psychological Assessment*, 8, 182-189.
- McDevitt, S. C., & Carey, W. B. (1978). The measurement of temperament in 3- to 7-year-old children. *Journal of Child Psychology & Psychiatry & Allied Disciplines*, 19, 245-253.
- McDonald, R. P. (1996a). Latent traits and the possibility of motion. *Multivariate Behavioral Research*, 31, 593-601.
- McDonald, R. P. (1996b). Consensus emerges: A matter of interpretation. *Multivariate Behavioral Research*, 31, 663-672.
- McDonald, W. J. (1993). Focus group research dynamics and reporting: An examination of research objectives and moderator influences. *Journal of the Academy of Marketing Science*, 21, 161-168.
- McDowell, C., & Acklin, M. W. (1996). Standardizing procedures for calculating Rorschach interrater reliability: Conceptual and empirical foundations. *Journal of Personality Assessment*, 66, 308-320.
- McDowell, I., & Newell, C. (1987). *Measuring health: A guide to rating scales and questionnaires*. New York: Oxford University Press.
- McElrath, K. (1994). A comparison of two methods for examining inmates' self-reported drug use. *International Journal of the Addictions*, 29, 517-524.
- McElwain, B. A. (1998). On seeing Beth at home and in a different light. En L. Handler (Chair), *Conducting assessments in clients' homes: Contexts, surprises, dilemmas, opportunities*. Symposium presented at the Society for Personality Assessment 1998 Midwinter Meeting, February 20.
- McEvoy, G. M., & Beatty, R. W. (1989). Assessment centers and subordinate appraisals of managers: A seven-year examination of predictive validity. *Personnel Psychology*, 42, 37-52.
- McGaghie, W. C. (2002, September 4). Assessing readiness for medical education: Evolution of the Medical College Admission Test. *Journal of the American Medical Association*, 288, p. 1085.
- McGrath, R. E., Pogge, D. L., & Stokes, J. M. (2002). Incremental validity of selected MMPI-A content scales in an inpatient setting. *Psychological Assessment*, 14, 401-409.
- McGrew, K. S. (1997). Analysis of the major intelligence batteries according to a proposed comprehensive Gf-Gc framework. En D. P. Flanagan, J. L. Genshaft, & P. L. Harrison (eds.), *Contemporary intellectual assessment: Theories, tests, and issues* (pp. 151-180). New York: Guilford.
- McGrew, K. S., & Flanagan, D. P. (1998). *The intelligence test desk reference: Gf-Gc cross-battery assessment*. Boston: Allyn & Bacon.
- McGue, M. (1997). The democracy of the genes. *Nature*, 388, 417-418.
- McGurk, F. J. (1975). Race differences—twenty years later. *Homo*, 26, 219-239.
- McKinley, J. C., & Hathaway, S. R. (1940). A multiphasic schedule (Minnesota): II. A differential study of hypochondriases. *Journal of Psychology*, 10, 255-268.
- McKinley, J. C., & Hathaway, S. R. (1944). The MMPI: V. Hysteria, hypomania, and psychopathic deviate. *Journal of Applied Psychology*, 28, 153-174.
- McLellan, A. T., Luborsky, L., Woody, G. E., & O'Brien, C. P. (1980). An improved diagnostic evaluation instrument for substance abuse patients. *Journal of Nervous and Mental Disease*, 168, 26-33.
- McLemore, C. W., & Court, J. H. (1977). Religion and psychotherapy—ethics, civil liberties, and clinical savvy: A critique. *Journal of Consulting and Clinical Psychology*, 45, 1172-1175.
- McMillen, C., Howard, M. O., Nower, L., & Chung, S. (2001). Positive by-products of the struggle with chemical dependency. *Journal of Substance Abuse Treatment*, 20, 69-79.
- McNeish, T. J., & Naglieri, J. A. (1993). Identification of individuals with serious emotional disturbance using the Draw A Person: Screening Procedure for Emotional Disturbance. *Journal of Special Education*, 27, 115-121.
- McNemar, Q. (1964). Lost: Our intelligence. Why? *American Psychologist*, 19, 871-882.
- McNemar, Q. (1975). On so-called test bias. *American Psychologist*, 30, 848-851.
- McReynolds, P. (1987). Lightner Witmer: Little-known founder of clinical psychology. *American Psychologist*, 42, 849-858.
- McReynolds, P., & Ludwig, K. (1984). Christian Thomasius and the origin of psychological rating scales. *ISIS*, 75, 546-553.
- Mead, M. (1978). *Culture and commitment: The new relationship between the generations in the 1970s* (rev. ed.). New York: Columbia University Press.
- Meadow, K. P., Karchmer, M. A., Petersen, L. M., & Rudner, L. (1980). *Meadow-Kendall Social-Emotional Assessment Inventory*. Washington, DC: Gallaudet University.
- Meadows, G., Turner, T., Campbell, L., Lewis, S. W., Reveley, M. A., & Murray, R. M. (1991). Assessing schizophrenia in adults with mental retardation: A comparative study. *British Journal of Psychiatry*, 158, 103-105.
- Mednick, S. A. (1962). The associative basis of the creative process. *Psychological Review*, 69, 220-232.
- Mednick, S. A., Higgins, J., & Kirschenbaum, J. (1975). *Psychology*. New York: Wiley.
- Medvec, V. H., Madey, S. F., & Gilovich, T. (1995). When less is more: Counterfactual thinking and satisfaction among Olympic medalists. *Journal of Personality and Social Psychology*, 69, 603-610.
- Medvec, V. H., & Savitsky, K. (1997). When doing better means feeling worse: The efforts of categorical cutoff points on counterfactual thinking and satisfaction. *Journal of Personality and Social Psychology*, 72, 1284-1296.
- Meehl, P. E. (1951). *Research results for counselors*. St. Paul, MN: State Department of Education.
- Meehl, P. E. (1954). *Clinical versus statistical prediction: A theoretical analysis and a review of the evidence*. Minneapolis: University of Minnesota.
- Meehl, P. E. (1956). Wanted: A good cookbook. *American Psychologist*, 11, 263-272.
- Mehl, M. R., & Pennebaker, J. W. (2003). The sounds of social life: A psychometric analysis of students' daily social environments and natural conversations. *Journal of Personality and Social Psychology*, 84, 857-870.
- Meier, S. T. (1984). The construct validity of burnout. *Journal of Occupational Psychology*, 57, 211-219.
- Meier, S. T. (1991). Tests of the construct validity of occupational stress measures with college students: Failure to support discriminant validity. *Journal of Counseling Psychology*, 38, 91-97.

- Melchert, T. P., & Patterson, M. M. (1999). Duty to warn and interventions with HIV-positive clients. *Professional Psychology: Research and Practice*, 30, 180-186.
- Melia, R. P., Pledger, C., & Wilson, R. (2003). Disability and rehabilitation research: Opportunities for participation, collaboration, and extramural funding for psychologists. *American Psychologist*, 58, 285-288.
- Mellenbergh, G. J. (1994). Generalized linear item response theory. *Psychological Bulletin*, 115, 300-307.
- Mello, E. W., & Fisher, R. P. (1996). Enhancing older adult eyewitness memory with the cognitive interview. *Applied Cognitive Psychology*, 10, 403-418.
- Melton, G., Petrila, J., Poythress, N. G., & Slobogin, C. (1997). *Psychological evaluations for the courts: A handbook for mental health professionals and lawyers* (2nd ed.). New York: Guilford.
- Melton, G. B. (1989). Review of the Child Abuse Protection Inventory, Form VI. En J. C. Conoley & J. J. Kramer (eds.), *The tenth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Melton, G. B., & Limber, S. (1989). Psychologists' involvement in cases of child maltreatment. *American Psychologist*, 44, 1225-1233.
- Mendoza, R. H. (1989). An empirical scale to measure type and degree of acculturation in Mexican-American adolescents and adults. *Journal of Cross-Cultural Psychology*, 20, 372-385.
- Menninger, K. A. (1953). *The human mind* (3rd ed.). New York: Knopf.
- Mercer, J. R. (1976). A system of multicultural pluralistic assessment (SOMPA). En *Proceedings: With bias toward none*. Lexington: Coordinating Office for Regional Resource Centers, University of Kentucky.
- Merrens, M. R., & Richards, W. S. (1970). Acceptance of generalized versus "bona fide" personality interpretation. *Psychological Reports*, 27, 691-694.
- Mershon, B., & Gorsuch, R. L. (1988). Number of factors in the personality sphere: Does increase in factors increase predictability of real-life criteria? *Journal of Personality and Social Psychology*, 55, 675-680.
- Messick, S. (1995). Validity of psychological assessment. *American Psychologist*, 50, 741-749.
- Meyer, G. J., & Handler, L. (1997). The ability of the Rorschach to predict subsequent outcome: Meta-analysis of the Rorschach Prognostic Rating Scale. *Journal of Personality Assessment*, 69, 1-38.
- Meyers, J. (1994, January/February). Assessing cross-cultural adaptability with the CCAI. *San Diego Psychological Association Newsletter*, 3(1 & 2).
- Micceri, T. (1989). The unicorn, the normal curve and other improbable creatures. *Psychological Bulletin*, 105, 156-166.
- Midanik, L. T., Greenfield, T. K., & Rogers, J. D. (2001). Reports of alcohol-related harm: Telephone versus face-to-face interviews. *Journal of Studies on Alcohol*, 62, 74-78.
- Miller, I. W., Kabacoff, R. I., Epstein, N. B., & Bishop, D. S. (1994). The development of a clinical rating scale for the McMaster Model of Family Functioning. *Family Process*, 33, 53-69.
- Miller, J. N., & Ozonoff, S. (2000). The external validity of Asperger disorder: Lack of evidence from the domain of neuropsychology. *Journal of Abnormal Psychology*, 109, 227-238.
- Miller, N. E. (1969). Learning of visceral and glandular responses. *Science*, 163, 434-445.
- Millman, J., & Arter, J. A. (1984). Issues in item banking. *Journal of Educational Measurement*, 21, 315-330.
- Millon, T., Millon, C., & Davis, R. (1994). *MCMI-III manual: Millon Clinical Multiaxial Inventory-III*. Minneapolis, MN: National Computer Systems.
- Mills, C. J. (2003). Characteristics of effective teachers of gifted students: Teacher background and personality styles of students. *Gifted Child Quarterly*, 47, 272-282.
- Milner, B. (1971). Interhemispheric differences in the localization of psychological processes in man. *British Medical Bulletin*, 27, 272-277.
- Milner, J. (1989). Additional cross-validation of the Child Abuse Potential Inventory. *Psychological Assessment*, 1, 219-223.
- Milner, J. S. (1986). *The Child Abuse Potential Inventory: Manual* (2nd ed.). Webster, NC: Psytec Corporation.
- Milner, J. S. (1989). Applications of the Child Abuse Potential Inventory. *Journal of Clinical Psychology*, 45, 450-454.
- Milner, J. S. (1991). Additional issues in child abuse assessment. *American Psychologist*, 46, 82-84.
- Milner, J. S., Gold, R. G., & Wimberley, R. C. (1986). Prediction and explanation of child abuse: Cross-validation of the Child Abuse Protection Inventory. *Journal of Consulting and Clinical Psychology*, 54, 865-866.
- Minsky, S. K., Spitz, H. H., & Bessellieu, C. L. (1985). Maintenance and transfer of training by mentally retarded young adults on the Tower of Hanoi problem. *American Journal of Mental Deficiency*, 90, 190-197.
- Minton, H. L. (1988). *Lewis M. Terman: Pioneer in psychological testing*. New York: New York University Press.
- Mirka, G. A., Kelaheer, D. P., Nay, T., & Lawrence, B. M. (2000). Continuous assessment of back stress (CABS): A new method to quantify low-back stress in jobs with variable biomechanical demands. *Human Factors*, 42, 209-225.
- Mischel, W. (1968). *Personality and assessment*. New York: Wiley.
- Mischel, W. (1973). Toward a cognitive social learning re-conceptualization of personality. *Psychological Review*, 80, 252-283.
- Mischel, W. (1977). On the future of personality measurement. *American Psychologist*, 32, 246-254.
- Mischel, W. (1979). On the interface of cognition and personality: Beyond the person-situation debate. *American Psychologist*, 34, 740-754.
- Misiaszek, J., Dooling, J., Gieseke, M., Melman, H., Misiaszek, J. G., & Jorgensen, K. (1985). Diagnostic considerations in deaf patients. *Comprehensive Psychiatry*, 26, 513-521.
- Mitchell, J. (1999). *Measurement in psychology: Critical history of a methodological concept*. New York: Cambridge University Press.
- Mitchell, J. V., Jr. (ed.). (1985). *The ninth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Mitchell, J. V., Jr. (1986). Measurement in the larger context: Critical current issues. *Professional Psychology: Research and Practice*, 17, 544-550.
- Moffitt, T. E., Caspi, A., Krueger, R. F., et al. (1997). Do partners agree about abuse in their relationship? A psychometric evaluation of interpartner agreement. *Psychological Assessment*, 9, 47-56.
- Moffitt, T. E., Gabrielli, W. F., Mednick, S. A., & Schulsinger, F. (1981). Socioeconomic status, IQ, and delinquency. *Journal of Abnormal Psychology*, 90, 152-156.
- Monahan, J. (1981). *The clinical prediction of violent behavior*. Washington, DC: U.S. Government Printing Office.
- Montague, M. (1993). Middle school students' mathematical problem solving: An analysis of think-aloud protocols. *Learning Disabilities Quarterly*, 16, 19-32.
- Montgomery, G. T., & Orozco, S. (1985). Mexican Americans' performance on the MMPI as a function of level of acculturation. *Journal of Clinical Psychology*, 41, 203-212.

- Moore, M. S., & McLaughlin, L. (1992). Assessment of the preschool child with visual impairment. En E. Vasquez Nutall, I. Romero, & J. Kalesnik (eds.), *Assessing and screening pre-schoolers: Psychological and educational dimensions* (pp. 345-368). Boston: Allyn & Bacon.
- Moos, R. H. (1986). *Work Environment Scale* (2nd ed.). Palo Alto, CA: Consulting Psychologists Press.
- Moos, R. H., & Moos, B. S. (1981). *Family Environment Scale manual*. Palo Alto, CA: Consulting Psychologists Press.
- Moos, R. H., & Moos, B. S. (1994). *Family environment manual: Development, applications, research*. Palo Alto, CA: Consulting Psychologists Press.
- Moreland, K. L. (1985). Validation of computer-based test interpretations: Problems and prospects. *Journal of Consulting and Clinical Psychology*, 53, 816-825.
- Moreland, K. L. (1986). An introduction to the problem of test user qualifications. En R. B. Most (Chair), *Test purchaser qualifications: Present practice, professional needs, and a proposed system*. Symposium presented at the 94th annual convention of the American Psychological Association, Washington, DC.
- Moreland, K. L. (1987). Computerized psychological assessment: What's available. In J. N. Butcher (ed.), *Computerized psychological assessment: A practitioner's guide* (pp. 26-49). New York: Basic.
- Moreland, K. L., Eyde, L. D., Robertson, G. J., Primoff, E. S., & Most, R. B. (1995a). Assessment of test user qualifications: A research-based measurement procedure. *American Psychologist*, 50, 14-23.
- Moreland, K. L., Reznikoff, M., & Aronow, E. (1995b). Integrating Rorschach interpretation by carefully placing more of your eggs in the content basket. *Journal of Personality Assessment*, 64, 239-242.
- Morgan, C. D. (1938). Thematic Apperception Test. In H. A. Murray (ed.), *Explorations in personality: A clinical and experimental study of fifty men of college age* (pp. 673-680). New York: Oxford University Press.
- Morgan, C. D., & Murray, H. A. (1935). A method for investigating fantasies: The Thematic Apperception Test. *Archives of Neurology and Psychiatry*, 34, 289-306.
- Morgan, C. D., & Murray, H. A. (1938). Thematic Apperception Test. In H. A. Murray (ed.), *Explorations in personality: A clinical and experimental study of fifty men of college age* (pp. 530-545). New York: Oxford University Press.
- Morgan, W. G. (1995). Origin and history of Thematic Apperception Test images. *Journal of Personality Assessment*, 65, 237-254.
- Mori, L. T., & Armendariz, G. M. (2001). Analogue assessment of child behavior problems. *Psychological Assessment*, 13, 36-45.
- Morreau, L. E., & Bruininks, R. H. (1991). *Checklist of Adaptive Living Skills*. Itasca, IL: Riverside.
- Moses, S. (1991). Major revision of SAT goes into effect in 1994. *APA Monitor*, 22(1), 35.
- Mosier, C. I. (1947). A critical examination of the concepts of face validity. *Educational and Psychological Measurement*, 7, 191-206.
- Moss, K., Ullman, M., Johnsen, M. C., et al. (1999). Different paths to justice: The ADA, employment, and administrative enforcement by the EEOC and FEPAs. *Behavioral Sciences and the Law*, 17, 29-46.
- Motowidlo, S. J. (1996). Orientation toward the job and organization. En K. R. Murphy (ed.), *Individual differences and behavior in organizations* (pp. 20-175). San Francisco: Jossey-Bass.
- Motta, R. W., Little, S. G., & Tobin, M. I. (1993a). The use and abuse of human figure drawings. *School Psychology Quarterly*, 8, 162-169.
- Motta, R. W., Little, S. G., & Tobin, M. I. (1993b). A picture is worth less than a thousand words: Response to reviewers. *School Psychology Quarterly*, 8, 197-199.
- Mueller, C. G. (1949). Numerical transformations in the analysis of experimental data. *Psychological Bulletin*, 46, 198-223.
- Mueller, J. H., Jacobsen, D. M., & Schwarzer, R. (2000). What are computers good for? A case study in online research. En M. H. Birnbaum (ed.), *Psychological experiments on the Internet* (pp. 195-216). San Diego, CA: Academic Press.
- Mueller, U., & Mazur, A. (1996). Facial dominance in *homo sapiens* as honest signaling of male quality. *Behavioral Ecology*, 8, 569-579.
- Mulaik, S. A. (1996a). On Maraun's deconstructing of factor indeterminacy with constructed factors. *Multivariate Behavioral Research*, 31, 579-592.
- Mulaik, S. A. (1996b). Factor analysis is not just a model in pure mathematics. *Multivariate Behavioral Research*, 31, 655-661.
- Mulvey, E. P., & Lidz, C. W. (1984). Clinical considerations in the prediction of dangerousness in mental patients. *Clinical Psychology Review*, 4, 379-401.
- Murguia, A., Zea, M. C., Reisen, C. A., & Peterson, R. A. (2000). The development of the Cultural Health Attributions Questionnaire (CHAQ). *Cultural Diversity and Ethnic Minority Psychology*, 6, 268-283.
- Murphy, G. E. (1984). The prediction of suicide: Why is it so difficult? *American Journal of Psychotherapy*, 38, 341-349.
- Murphy, K. R. (ed.). (2003). *Validity generalization: A critical review*. Mahwah, NJ: Erlbaum.
- Murphy, L. L., Conoley, J. C., & Impara, J. C. (1994). *Tests in print IV: An index to tests, test reviews, and the literature on specific tests*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Murphy, L. L., Plake, B. S., Impara, J. C., & Spies, R. A. (eds.). (2002). *Tests in print VI*. Lincoln: University of Nebraska Press.
- Murphy-Berman, V. (1994). A conceptual framework for thinking about risk assessment and case management in child protective service. *Child Abuse and Neglect*, 18, 193-201.
- Murray, H. A. (1943). *Thematic Apperception Test manual*. Cambridge, MA: Harvard University.
- Murray, H. A., et al. (1938). *Explorations in personality*. Cambridge, MA: Harvard University.
- Murray, H. A., & MacKinnon, D. W. (1946). Assessment of OSS personnel. *Journal of Consulting Psychology*, 10, 76-80.
- Murstein, B. I., & Mathes, S. (1996). Projection on projective techniques = pathology: The problem that is not being addressed. *Journal of Personality Assessment*, 66, 337-349.
- Murstein, B. I. (1961). Assumptions, adaptation level, and projective techniques. *Perceptual and Motor Skills*, 12, 107-125.
- Mussen, P. H., & Naylor, H. K. (1954). The relationship between overt and fantasy aggression. *Journal of Abnormal and Social Psychology*, 49, 235-240.
- Mussen, P. H., & Scodel, A. (1955). The effects of sexual stimulation under varying conditions on TAT sexual responsiveness. *Journal of Consulting and Clinical Psychology*, 19, 90.
- Myers, I. B. (1962). *The Myers-Briggs Type Indicator: Manual*. Palo Alto, CA: Consulting Psychologists Press.
- Myers, I. B., & Briggs, K. C. (1943/1962). *The Myers-Briggs Type Indicator*. Palo Alto, CA: Consulting Psychologists Press.
- Myers, K. D., & Carskadon, T. G. (2002). Eminent interview: Katharine Downing Myers. *Journal of Psychological Type*, 61, 43-49.
- Nagle, R. J., & Bell, N. L. (1993). Validation of Stanford-Binet Intelligence Scale: Fourth Edition Abbreviated Batteries with college students. *Psychology in the Schools*, 30, 227-231.
- Naglieri, J. A. (1985a). Use of the WISC-R and K-ABC with learning disabled, borderline mentally retarded, and normal children. *Psychology in the Schools*, 22, 133-141.

- Naglieri, J. A. (1985b). Normal children's performance on the McCarthy Scales, Kaufman Assessment Battery and Peabody Individual Achievement Test. *Journal of Psychoeducational Assessment*, 3, 123-129.
- Naglieri, J. A. (1989). A cognitive processing theory for the measurement of intelligence. *Educational Psychologist*, 24, 185-206.
- Naglieri, J. A. (1990). *Das-Naglieri Cognitive Assessment System*. Paper presented at the conference "Intelligence: Theories and Practice," Memphis, TN.
- Naglieri, J. A. (1993). Human figure drawings in perspective. *School Psychology Quarterly*, 8, 170-176.
- Naglieri, J. A. (1997). IQ: Knowns and unknowns, hits and misses. *American Psychologist*, 52, 75-76.
- Naglieri, J. A., & Anderson, D. F. (1985). Comparison of the WISC-R and K-ABC with gifted students. *Journal of Psychoeducational Assessment*, 3, 175-179.
- Naglieri, J. A., & Das, J. P. (1988). Planning-arousal-simultaneous-successive (PASS): A model for assessment. *Journal of School Psychology*, 26, 35-48.
- Naglieri, J. A., & Das, J. P. (1997). *Das-Naglieri Cognitive Assessment System: Interpretive handbook*. Itasca, IL: Riverside.
- Naglieri, J. A., McNeish, T. J., & Bardos, A. N. (1991). *Draw A Person: Screening Procedure for Emotional Disturbance—Examiner's manual*. Austin, TX: PRO-ED.
- Nagyne Rez, I., & Zsoldos, M. (1991). Issues of diagnosis of learning problems in patients with impaired hearing on the basis of observations gained during the application of the Hiskey-Nebraska Test of Learning Aptitude. *Magyar Pszichologiai Szemle*, 47, 393-402.
- Nathan, J., Wilkinson, D., Stammers, S., & Low, L. (2001). The role of tests of frontal executive function in the detection of mild dementia. *International Journal of Geriatric Psychiatry*, 16, 18-26.
- National Association of School Psychologists. (2000). *Professional conduct manual* (4th ed.). Washington, DC: Author.
- National Council on Disability. (1996). *Cognitive impairments and the application of Title I of the Americans with Disabilities Act*. Washington, DC: Author.
- National Joint Committee on Learning Disabilities. (1985). *Learning disabilities and the preschool child: A position paper of the National Joint Committee on Learning Disabilities*. Baltimore: Author.
- Naylor, J. C., & Shine, L. C. (1965). A table for determining the increase in mean criterion score obtained by using a selection device. *Journal of Industrial Psychology*, 3, 33-42.
- Neagoe, A. D. (2000). Abducted by aliens: A case study. *Psychiatry*, 63, 202-207.
- Neale, E. L., & Rosale, M. L. (1993). What can art therapists learn from projective drawing techniques for children? A review of the literature. *The Arts in Psychotherapy*, 20, 37-49.
- Neath, J., Bellini, J., & Bolton, B. (1997). Dimensions of the Functional Assessment Inventory for five disability groups. *Rehabilitation Psychology*, 42, 183-207.
- Needham, J. (1959). *A history of embryology*. New York: Abelard-Schuman.
- Neisser, U. (1979). The concept of intelligence. *Intelligence*, 3, 217-227.
- Neisser, U., Boodoo, G., Bouchard, T. J., Jr., et al. (1996). Intelligence: Knowns and unknowns. *American Psychologist*, 51, 77-101.
- Nellis, L., & Gridley, B. E. (1994). Review of the Bayley Scales of Infant Development—Second Edition. *Journal of School Psychology*, 32, 201-209.
- Nelson, C. A., Wewerka, S., Thomas, K. M., et al. (2000). Neurocognitive sequelae of infants of diabetic mothers. *Behavioral Neuroscience*, 114, 950-956.
- Nelson, D. V., Harper, R. G., Kotik-Harper, D., & Kirby, H. B. (1993). Brief neuropsychologic differentiation of demented versus depressed elderly inpatients. *General Hospital Psychiatry*, 15, 409-416.
- Nelson, L. D. (1994). Introduction to the special section on normative assessment. *Psychological Assessment*, 4, 283.
- Nelson, R. O., Hay, L. R., & Hay, W. M. (1977). Comment on Cone's "The relevance of reliability and validity for behavior assessment." *Behavior Therapy*, 8, 427-430.
- Nester, M. A. (1993). Psychometric testing and reasonable accommodation for persons with disabilities. *Rehabilitation Psychology*, 38, 75-85.
- Nettelbeck, T., & Rabbit, P. M. A. (1992). Aging, cognitive performance, and mental speed. *Intelligence*, 16, 189-205.
- Neugarten, B., Havighurst, R. J., & Tobin, S. (1961). The measurement of life satisfaction. *Journal of Gerontology*, 16, 134-143.
- Newborg, J., Stock, J. R., Wnek, L., et al. (1984). *Battelle Developmental Inventory*. Allen, TX: DLM Teaching Resources.
- Newcomb, T. M. (1929). *Consistency of certain extrovert-introvert behavior patterns in 51 problem boys*. New York: Columbia University Bureau of Publications.
- Newell, A. (1973). Production systems: Models of control structures. In W. G. Chase (ed.), *Visual information processing* (pp. 463-526). New York: Academic Press.
- Newman, H. H., Freeman, F. N., & Holzinger, K. J. (1937). *Twins*. Chicago: University of Chicago.
- Nilsson, J. E., Berkel, L. A., Flores, L. Y., et al. (2003). An 11-year review of *Professional Psychology: Research and Practice*: Content and sample analysis with an emphasis on diversity. *Professional Psychology: Research and Practice*, 34, 611-616.
- Norton, P. J., & Hope, D. A. (2001). Analogue observational methods in the assessment of social functioning in adults. *Psychological Assessment*, 13, 59-72.
- Notarius, C., & Markman, H. (1981). Couples Interaction Scoring System. In E. Filsinger & R. Lewis, (eds.), *Assessing marriage: New behavioral approaches*. Beverly Hills, CA: Sage.
- Notarius, C. I., & Vanzetti, N. A. (1983). The Marital Agendas Protocol. In E. Filsinger (ed.), *Marriage and family assessment: A sourcebook for family therapy*. Beverly Hills, CA: Sage.
- Novick, M. R., & Lewis, C. (1967). Coefficient alpha and the reliability of composite measurements. *Psychometrika*, 32, 1-13.
- Nunnally, J. C. (1967). *Psychometric theory*. New York: McGraw-Hill.
- Nunnally, J. C. (1978). *Psychometric theory* (2nd ed.). New York: McGraw-Hill.
- Nyborg, H., & Jensen, A. R. (2000). Black-white differences on various psychometric tests: Spearman's hypothesis tested on American armed services veterans. *Personality and Individual Differences*, 28, 593-599.
- Nystedt, L., Sjoeborg, A., & Haeggglund, G. (1999). Discriminant validation of measures of organizational commitment, job involvement, and job satisfaction among Swedish army officers. *Scandinavian Journal of Psychology*, 40, 49-55.
- O'Boyle, M. W., Gill, H. S., Benbow, C. P., & Alexander, J. E. (1994). Concurrent finger-tapping in mathematically gifted males: Evidence for enhanced right hemispheric involvement during linguistic processing. *Cortex*, 30, 519-526.
- O'Connor, E. (2001, February). Researchers pinpoint potential cause of autism. *Monitor on Psychology*, 32(2), 13.
- Oden, M. H. (1968). The fulfillment of promise: 40-year follow-up of the Terman gifted group. *Genetic Psychology Monographs*, 77, 3-93.

- O'Donnell, W. E., DeSoto, C. B., & DeSoto, J. L. (1993). Validity and reliability of the Revised Neuropsychological Impairment Scales (NIS). *Journal of Clinical Psychology*, 49, 372-382.
- O'Donnell, W. E., DeSoto, C. B., DeSoto, J. L., & Reynolds, D. M. (1993). *The Neuropsychological Impairment Scale (NIS) manual*. Los Angeles: Western Psychological Services.
- O'Hare, T., & Van Tran, T. (1998). Substance abuse among Southeast Asians in the U.S.: Implications for practice and research. *Social Work in Health Care*, 26, 69-80.
- Okazaki, S., & Sue, S. (1995). Methodological issues in assessment research with ethnic minorities. *Psychological Assessment*, 7, 367-375.
- Okazaki, S., & Sue, S. (2000). Implications of test revisions for assessment with Asian Americans. *Psychological Assessment*, 12, 272-280.
- O'Keefe, J. (1993). Disability, discrimination, and the Americans with Disabilities Act. *Consulting Psychology Journal*, 45(2), 3-9.
- O'Leary, K. D., & Arias, I. (1988). Assessing agreement of reports of spouse abuse. En G. T. Hotaling, D. Finkelhor, J. T. Kirkpatrick, & M. A. Straus (eds.), *Family abuse and its consequences* (pp. 218-227). Newbury Park, CA: Sage.
- Olkin, R., & Pledger, C. (2003). Can disability studies and psychology join hands? *American Psychologist*, 58, 296-304.
- Olson, D. H., & Barnes, H. L. (1985). Quality of life. En D. H. Olson, H. I. McCubbin, H. L. Barnes, A. S. Larsen, M. Muxen, & M. Wilson (eds.), *Family inventories* (rev. ed.). St. Paul: Family Social Science, University of Minnesota.
- Olson, D. H., Larsen, A. S., & McCubbin, H. I. (1985). Family strengths. In D. H. Olson, H. I. McCubbin, H. L. Barnes, A. S. Larsen, M. Muxen, & M. Wilson (eds.), *Family inventories* (rev. ed.). St. Paul: Family Social Science, University of Minnesota.
- Olweus, D. (1979). Stability of aggressive reaction patterns in males: A review. *Psychological Bulletin*, 86, 852-875.
- Ones, D. S., & Viswesvaran, C. (2001). Integrity tests and other criterion-focused occupational personality scales (COPS) used in personnel selection. *International Journal of Selection and Assessment*, 9, 31-39.
- Oregon Death With Dignity Act, 2 Ore. Rev. Stat. §§127.800-127.897 (1997).
- Organ, D. W., & Near, J. P. (1985). Cognition versus affect in measures of job satisfaction. *International Journal of Psychology*, 20, 241-253.
- Orne, M. T. (1979). The use and misuse of hypnosis in court. *International Journal of Clinical and Experimental Hypnosis*, 27, 311-341.
- Orr, D. B., & Graham, W. R. (1968). Development of a listening comprehension test to identify educational potential among disadvantaged junior high school students. *American Educational Researcher Journal*, 5, 167-180.
- Orr, F. C., DeMatteo, A., Heller, B., Lee, M., & Nguyen, M. (1987). Psychological assessment. In H. Elliott, L. Glass, & J. W. Evans (eds.), *Mental health assessment of deaf clients* (pp. 93-106). Boston: Little, Brown.
- Orr, R. R., Cameron, S. J., Dobson, L. A., & Day, D. M. (1993). Age-related changes in stress experienced by families with a child who has developmental delays. *Mental Retardation*, 31, 171-176.
- Osberg, T. M., & Poland, D. L. (2002). Comparative accuracy of the MMPI-2 and the MMPI-A in the diagnosis of psychopathology in 18-year-olds. *Psychological Assessment*, 14, 164-169.
- Osgood, C. E., Suci, G. J., & Tannenbaum, P. H. (1957). *The measurement of meaning*. Urbana: University of Illinois.
- Osipow, S. H., & Reed, R. (1985). Decision-making style and career indecision in college students. *Journal of Vocational Behavior*, 27, 368-373.
- OSS Assessment Staff. (1948). *Assessment of men: Selection of personnel for the Office of Strategic Service*. New York: Rinehart.
- Ouellette, S. E. (1988). The use of projective drawing techniques in the personality assessment of prelingually deafened young adults: A pilot study. *American Annals of the Deaf*, 133, 212-217.
- Outtz, J. (1994, June). Cited in T. DeAngelis, New tests allow takers to tackle real-life problems. *APA Monitor*, 25, 14.
- Ozer, D. J. (1985). Correlation and the coefficient of determination. *Psychological Bulletin*, 97, 307-315.
- Ozonoff, S. (1995). Reliability and validity of the Wisconsin Card Sorting Test in studies of autism. *Neuropsychology*, 9, 491-500.
- Pack v. K-Mart*. 166 F.3d, 1300 (10th Cir. 1999).
- Padden, C. (1980). The deaf community and the culture of deaf people. En C. Baker & R. Battison (eds.), *Sign language and the deaf community* (pp. 89-103). Washington, DC: National Association of the Deaf.
- Padden, C., & Humphries, T. (1988). *Deaf in America: Voices from a culture*. Cambridge, MA: Harvard University.
- Padilla, A. M., Wagatsuma, Y., & Lindholm, K. J. (1985). Acculturation and personality as predictors of stress in Japanese and Japanese Americans. *Journal of Social Psychology*, 125, 295-305.
- Palmore, E. (ed.). (1970). *Normal aging*. Durham, NC: Duke University Press.
- Panell, R. C., & Laabs, G. J. (1979). Construction of a criterion-referenced, diagnostic test for an individualized instruction program. *Journal of Applied Psychology*, 64, 255-261.
- Pannbacker, M., & Middleton, G. (1992). Review of Wepman's Auditory Discrimination Test, Second Edition. In J. J. Kramer & J. C. Conoley (eds.), *The eleventh mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Panter, A. T., Swygert, K. A., Dahlstrom, W. G., & Tanaka, J. S. (1997). Factor analytic approaches to personality item-level data. *Journal of Personality Assessment*, 68, 561-589.
- Paolo, A. M., & Ryan, J. J. (1991). Application of WAIS-R short forms to persons 75 years of age and older. *Journal of Psychoeducational Assessment*, 9, 345-352.
- Parette, H. P., & Brotherson, M. J. (1996). Family participation in assistive technology assessment for young children with mental retardation and developmental disabilities. *Education & Training in Mental Retardation & Developmental Disabilities*, 31, 29-43.
- Parke, R. D., Hymel, S., Power, T., & Tinsley, B. (1977, November). Fathers and risk: A hospital-based model of intervention. In D. B. Sawin (Chair), *Symposium on psychosocial risks during infancy*. Austin: University of Texas at Austin.
- Parke, R. D., & Sawin, D. B. (1975, April). *Infant characteristics and behavior as elicitors of maternal and paternal responsivity in the newborn period*. Paper presented at the meetings of the Society for Research in Child Development, Denver, CO.
- Parker, T., & Abramson, P. R. (1995). The law hath not been dead: Protecting adults with mental retardation from sexual abuse and violation of their sexual freedom. *Mental Retardation*, 33, 257-263.
- Parkes, L. P., Bochner, S., & Schneider, S. K. (2001). Person-organisation fit across cultures: An empirical investigation of individualism and collectivism. *Applied Psychology: An International Review*, 50, 81-108.
- Parnes, H. S., & Less, L. J. (1985). Introduction and overview. In H. S. Parnes, J. E. Crowley, R. J. Haurin, et al. (eds.), *Retirement among American men*. Lexington, MA: Lexington Books.
- Pascal, G. R., & Suttell, B. J. (1951). *The Bender-Gestalt Test: Quantification and validity for adults*. New York: Grune & Stratton.
- Pascoe, C. J. (2003). Multiple masculinities? Teenage boys talk about jocks and gender. *American Behavioral Scientist*, 46, 1423-1438.

- Patterson, W. M., Dohn, H. H., Bird, J., & Patterson, G. A. (1983). Evaluation of suicidal patients: The SAD PERSONS scale. *Psychosomatics*, 24, 343-349.
- Paul, G. L. (1987). *The time-sample behavioral checklist: Observational assessment instrumentation for service and research*. Champaign, IL: Research Press.
- Paul, V., & Jackson, D. W. (1993). *Toward a psychology of deafness*. Boston: Allyn & Bacon.
- Paulhus, D. L. (1984). Two-component models of socially desirable responding. *Journal of Personality and Social Psychology*, 46, 598-609.
- Paulhus, D. L. (1986). Self-deception and impression management in test responses. En A. Angleitner & J. S. Wiggins (eds.), *Personality assessment via questionnaire* (pp. 142-165). New York: Springer.
- Paulhus, D. L. (1990). Measurement and control of response bias. En J. P. Robinson, P. R. Shaver, & L. Wrightsman (eds.), *Measures of personality and social-psychological attitudes* (pp. 17-59). San Diego, CA: Academic Press.
- Paulhus, D. L., & Levitt, K. (1987). Desirable response triggered by affect: Automatic egotism? *Journal of Personality and Social Psychology*, 52, 245-259.
- Paulhus, D. L., & Reid, D. B. (1991). Enhancement and denial in socially desirable responding. *Journal of Personality and Social Psychology*, 60, 307-317.
- Paullay, I. M., Alliger, G. M., & Stone-Romero, E. F. (1994). Construct validation of two instruments designed to measure job involvement and work centrality. *Journal of Applied Psychology*, 79, 224-228.
- Pearson, K., & Moul, M. (1925). The problem of alien immigration of Great Britain illustrated by an examination of Russian and Polish Jewish children. *Annals of Eugenics*, 1, 5-127.
- Pennsylvania Department of Corrections v. Yeskey*, 118 F.3d, 168 (1998).
- Perez, J. A., Dasi, F., & Lucas, A. (1997). Length overestimation bias as a product of normative pressure arising from anthropocentric vs. geocentric representations of length. *Swiss Journal of Psychology*, 56, 243-255.
- Perry, C., & Laurence, J. R. (1990). Hypnosis with a criminal defendant and a crime witness: Two recent related cases. *International Journal of Clinical and Experimental Hypnosis*, 38, 266-282.
- Petersen, N. S., & Novick, M. R. (1976). An evaluation of some models for culture-fair selection. *Journal of Educational Measurement*, 13, 3-29.
- Peterson, C. A. (1997). *The twelfth mental measurements yearbook: Testing the tests*. *Journal of Personality Assessment*, 68, 717-719.
- Petrie, K., & Chamberlain, K. (1985). The predictive validity of the Zung Index of Potential Suicide. *Journal of Personality Assessment*, 49, 100-102.
- Petty, M. M., McGhee, G. W., & Cavender, J. W. (1984). A meta-analysis of the relationships between individual job satisfaction and individual performance. *Academy of Management Review*, 9, 712-721.
- Phelps, L., & Branyon, B. (1988). Correlations among the Hiskey, K-ABC Nonverbal Scale, Leiter, and WISC-R Performance Scale with public school deaf children. *Journal of Psychoeducational Assessment*, 6, 354-358.
- Phillips, B. A. (1996). Bringing culture to the forefront: Formulating diagnostic impressions of deaf and hard-of-hearing people at times of medical crisis. *Professional Psychology: Research and Practice*, 27, 137-144.
- Piaget, J. (1954). *The construction of reality on the child*. New York: Basic.
- Piaget, J. (1971). *Biology and knowledge*. Chicago: University of Chicago.
- Piedmont, R. L., & McCrae, R. R. (1996). *Are validity scales valid in volunteer samples? Evidence from self-reports and observer ratings*. Unpublished manuscript, Loyola College, Maryland.
- Piedmont, R. L., McCrae, R. R., Riemann, R., & Angleitner, A. (2000). On the invalidity of validity scales: Evidence from self-reports and observer ratings in volunteer samples. *Journal of Personality and Social Psychology*, 78, 582-593.
- Pilgrim, C., Luo, Q., Urberg, K. A., & Fang, X. (1999). Influence of peers, parents, and individual characteristics on adolescent drug use in two cultures. *Merrill-Palmer Quarterly*, 45, 85-107.
- Pintner, R. (1931). *Intelligence testing*. New York: Holt.
- Piotrowski, C., & Armstrong, T. (2002). Convergent validity of the KeyPoint pre-employment measure with the MBTI. *Psychology & Education: An Interdisciplinary Journal*, 39, 49-50.
- Piotrowski, C., Belter, R. W., & Keller, J. W. (1998). The impact of "managed care" on the practice of psychological testing: Preliminary findings. *Journal of Personality Assessment*, 70, 441-446.
- Piotrowski, Z. (1957). *Perceptanalysis*. New York: Macmillan.
- Pittenger, D. J. (1993). The utility of the Myers-Briggs Type Indicator. *Review of Educational Research*, 63, 467-488.
- Plake, B. S., Impara, J. C., & Spies, R. A. (eds.). (2003). *The fifteenth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Pledger, C. (2003). Discourse on disability and rehabilitation issues: Opportunities for psychology. *American Psychologist*, 58, 279-284.
- Plucker, J. A., & Levy, J. J. (2001). The downside of being talented. *American Psychologist*, 56, 75-76.
- Polizzi, D. (1998). Contested space: Assessment in the home and the combative marriage. En L. Handler (Chair), *Conducting assessments in clients' homes: Contexts, surprises, dilemmas, opportunities*. Symposium presented at the Society for Personality Assessment 1998 Midwinter Meeting, February 20.
- Pollard, R. Q. (1993). 100 years in psychology and deafness: A centennial retrospective. *Journal of the American Deafness & Rehabilitation Association*, 26, 32-46.
- Pomplun, M., & Omar, M. H. (2000). Score comparability of a state mathematics assessment across students with and without reading accommodations. *Journal of Applied Psychology*, 85, 21-29.
- Pomplun, M., & Omar, M. H. (2001). Score comparability of a state reading assessment across selected groups of students with disabilities. *Structural Equation Modeling*, 8, 257-274.
- Ponterotto, J. G., Rivera, L., & Sueyoshi, L. A. (2000). The Career-in-Culture interview: A semi-structured protocol for the cross-cultural intake interview. *Career Development Quarterly*, 49, 85-96.
- Porter, L. W., Steers, R. W., Mowday, R. T., & Boulian, P. V. (1974). Organizational commitment, job satisfaction, and turnover among psychiatric technicians. *Journal of Applied Psychology*, 59, 603-609.
- Porteus, S. D. (1933). *The Maze Test and mental differences*. Vineland, NJ: Smith Printing & Publishing.
- Porteus, S. D. (1942). *Qualitative performance in the Maze Test*. San Antonio, TX: Psychological Corporation.
- Porteus, S. D. (1955). *The Maze Test: Recent advances*. Palo Alto, CA: Pacific Books.
- Powell, D. H. (1994). *Profiles in cognitive aging*. Cambridge, MA: Harvard University Press.
- Preston, R. (1961). Improving the item validity of study habits inventories. *Educational and Psychological Measurement*, 21, 129-131.

- Price, G., Dunn, R., & Dunn, K. (1982). *Productivity Environmental Survey manual*. Lawrence, KS: Price Systems.
- Prince, R. J., & Guastello, S. J. (1990). The Barnum Effect in a computerized Rorschach interpretation system. *Journal of Psychology: Interdisciplinary and Applied*, 124, 217-222.
- Procedures for evaluating specific learning disabilities. (1977). *Federal Register*, December 29, Part III.
- Prout, H. T., & Phillips, P. D. (1974). A clinical note: The kinetic school drawing. *Psychology in the Schools*, 11, 303-396.
- Psychological Corporation, The. (1992a). *Wechsler Individual Achievement Test*. San Antonio, TX: Author.
- Psychological Corporation, The. (1992b). *Wechsler Individual Achievement Test manual*. San Antonio, TX: Author.
- Psychological Corporation, The. (2001). *Wechsler Individual Achievement Test-Second Edition*. San Antonio, TX: Author.
- Pullen, L., & Gow, K. (2000). University students elaborate on what young persons "at risk of suicide" need from listeners. *Journal of Applied Health Behaviour*, 2, 32-39.
- Putnam, W. H. (1979). Hypnosis and distortions in eyewitness memory. *International Journal of Clinical and Experimental Hypnosis*, 27, 437-448.
- Q and A on balancing the SAT scores. (1994). New York: College Board.
- Qu, C., Zhang, P., Zheng, R., et al. (1992). An examination of the IQs of 319 hearing-impaired students in 5 cities in China. *Chinese Mental Health Journal*, 6, 219-221.
- Quay, H. C., & Peterson, C. (1983). *Manual for the Revised Behavior Problem Checklist*. Coral Gables, FL: Authors.
- Quay, H. C., & Peterson, D. R. (1967). *Behavior Problem Checklist*. Champaign: University of Illinois Press.
- Quill, T. E., Cassel, C. K., & Meier, D. E. (1992). Care of the hopelessly ill: Proposed clinical criteria for physician-assisted suicide. *New England Journal of Medicine*, 327, 1380-1384.
- Quinsey, V. L., Chaplin, T. C., & Upfold, D. (1984). Sexual arousal to nonsexual violence and sadomasochistic themes among rapists and nonsex-offenders. *Journal of Consulting and Clinical Psychology*, 52, 651-657.
- Raifman, L. J., & Vernon, M. (1996). Important implications for psychologists of the Americans with Disabilities Act: Case in point, the patient who is deaf. *Professional Psychology: Research and Practice*, 27, 372-377.
- Raju, N. S., Drasgow, F., & Slinde, J. A. (1993). An empirical comparison of the area methods, Lord's chi-square test, and the Mantel-Haenszel technique for assessing differential item functioning. *Educational and Psychological Measurement*, 53, 301-314.
- Ramirez, M., III. (1984). Assessing and understanding biculturalism-multiculturalism in Mexican-American adults. En J. L. Martinez, Jr., & R. H. Mendoza (eds.), *Chicano psychology* (pp. 77-94). Orlando, FL: Academic Press.
- Randall, A., Fairbanks, M. M., & Kennedy, M. L. (1986). Using think-aloud protocols diagnostically with college readers. *Reading Research & Instruction*, 25, 240-253.
- Randall, D. M. (1987). Commitment and the organization: The organization man revisited. *Academy of Management Review*, 12, 460-471.
- Randolph, C., Mohr, E., & Chase, T. N. (1993). Assessment of intellectual function in dementing disorders: Validity of WAIS-R short forms for patients with Alzheimer's, Huntington's, and Parkinson's disease. *Journal of Clinical and Experimental Neuropsychology*, 15, 743-753.
- Ranseen, J. D., & Humphries, L. L. (1992). The intellectual functioning of eating disorder patients. *Journal of the American Academy of Child and Adolescent Psychiatry*, 31, 844-846.
- Rapaport, D. (1946-1967). Principles underlying nonprojective tests of personality. En M. M. Gill (ed.), *David Rapaport: Collected papers*. New York: Basic.
- Rapaport, D., Gill, M. M., & Schafer, R. (1945-1946). *Diagnostic psychological testing* (2 vols.). Chicago: Year Book.
- Rapaport, D., Gill, M. M., & Schafer, R. (1968). En R. R. Holt (ed.), *Diagnostic psychological testing* (rev. ed.). New York: International Universities.
- Raphael, S., & Halpert, L. H. (1999). *Graduate Record Examination: Psychology*. New York: Arco Publishing.
- Rappeport, J. R. (1982). Differences between forensic and general psychiatry. *American Journal of Psychiatry*, 139, 331-334.
- Raven, J. C. (1976). *Standard Progressive Matrices*. Oxford: Oxford Psychologists.
- Raz, S., Glogowski-Kawamoto, B., Yu, A. W., et al. (1998). The effects of perinatal hypoxic risk on developmental outcome in early and middle childhood: A twin study. *Neuropsychology*, 12, 459-467.
- Razran, G. (1961). The observable unconscious and the inferable conscious in current Soviet psychophysiology: Introceptive conditioning, semantic conditioning, and the orienting reflex. *Psychological Review*, 68, 81-147.
- Recarte, M. A., & Nunes, L. M. (2000). Effects of verbal and spatial-imagery tasks on eye fixations while driving. *Journal of Experimental Psychology: Applied*, 6, 31-43.
- Reckase, M. D. (1996). Test construction in the 1990s: Recent approaches every psychologist should know. *Psychological Assessment*, 8, 354-359.
- Ree, M. J., & Earles, J. A. (1990). *Differential validity of a differential aptitude test* (Rpt 89-59). Texas: Brooks Air Force Base.
- Reece, R. N., & Groden, M. A. (1985). Recognition of non-accidental injury. *Pediatric Clinics of North America*, 32, 41-60.
- Reed, T. E. (1997). "The genetic hypothesis": It was not tested but it could have been. *American Psychologist*, 52, 77-78.
- Reed, T. E., & Jensen, A. R. (1992). Conduction velocity in a brain nerve pathway of normal adults correlates with intelligence level. *Intelligence*, 16, 259-272.
- Reed, T. E., & Jensen, A. R. (1993). Choice reaction time and visual pathway conduction velocity both correlate with intelligence but appear not to correlate with each other: Implications for information processing. *Intelligence*, 17, 191-203.
- Reeder, G. D., Maccow, G. C., Shaw, S. R., Swerdlik, M. E., Horton, C. B., & Foster, P. (1997). School psychologists and full-service schools: Partnerships with medical, mental health, and social services. *School Psychology Review*, 26, 603-621.
- Reichenberg, N., & Raphael, A. J. (1992). *Advanced psychodiagnostic interpretation of the Bender-Gestalt Test: Adults and children*. Westport, CT: Praeger.
- Reik, T. (1948). *Listening with the third ear*. New York: Farrar, Straus.
- Reik, T. (1952). *The secret self*. New York: Grove.
- Reimers, T. M., Wacker, D. P., & Koeppel, G. (1987). Acceptability of behavioral treatments: A review of the literature. *School Psychology Review*, 16, 212-227.
- Reinehr, R. C. (1969). Therapist and patient perceptions of hospitalized alcoholics. *Journal of Clinical Psychology*, 25, 443-445.
- Reise, S. P., & Henson, J. M. (2003). A discussion of modern versus traditional psychometrics as applied to personality assessment scales. *Journal of Personality Assessment*, 81, 93-103.
- Reise, S. P., Waller, N. G., & Comrey, A. L. (2000). Factor analysis and scale revision. *Psychological Assessment*, 12, 287-297.
- Reiser, M. (1980). *Handbook of investigative hypnosis*. Los Angeles: Lehi.
- Reiser, M. (1990). Investigative hypnosis. En D. C. Raskin (ed.), *Psychological methods in criminal investigation evidence* (pp. 151-190). New York: Springer.

- Reitan, R. (1994, July). *Child neuropsychology and learning disabilities*. Advanced Workshop, Los Angeles.
- Reitan, R. M. (1955a). An investigation of the validity of Halstead's measures of biological intelligence. *Archives of Neurology and Psychiatry*, 73, 28-35.
- Reitan, R. M. (1955b). Certain differential effects of left and right cerebral lesions in human adults. *Journal of Comparative and Physiological Psychology*, 48, 474-477.
- Reitan, R. M. (1969). *Manual for administration of neuropsychological test batteries for adults and children*. Indianapolis: Author.
- Reitan, R. M. (1984a). *Aphasia and sensory-perceptual disorders in adults*. South Tucson, AZ: Neuropsychology Press.
- Reitan, R. M. (1984b). *Aphasia and sensory-perceptual disorders in children*. South Tucson, AZ: Neuropsychology Press.
- Reitan, R. M. (1994). Ward Halstead's contributions to neuropsychology and the Halstead-Reitan Neuropsychological Test Battery. *Journal of Clinical Psychology*, 50, 47-70.
- Reitan, R. M., & Wolfson, D. (1990). A consideration of the comparability of the WAIS and WAIS-R. *Clinical Neuropsychologist*, 4, 80-85.
- Reitan, R. M., & Wolfson, D. (1992). A short screening examination for impaired brain functions in early school-age children. *Clinical Neuropsychologist*, 6, 287-294.
- Reitan, R. M., & Wolfson, D. (1993). *The Halstead-Reitan Neuropsychological Test Battery: Theory and clinical interpretation* (2nd ed.). Tucson, AZ: Neuropsychology Press.
- Reitan, R. M., & Wolfson, D. (2000). The neuropsychological similarities of mild and more severe head injury. *Archives of Clinical Neuropsychology*, 15, 433-442.
- Remington, R. W., Johnston, J. C., Ruthruff, E., et al. (2000). Visual search in complex displays: Factors affecting conflict detection by air traffic controllers. *Visual Cognition*, 7, 769-784.
- Renwick, R., et al. (eds.). (1996). *Quality of life in health promotion and rehabilitation: Conceptual approaches, issues, and applications*. Thousand Oaks, CA: Sage.
- Retzlaff, P. D., & Gibertini, M. (1988). Objective psychological testing of U.S. Air Force officers in pilot training. *Aviation, Space, and Environmental Medicine*, 59, 661-663.
- Rey, G. J., Feldman, E., Rivas-Vazquez, R., et al. (1999). Neuropsychological test development and normative data on Hispanics. *Archives of Clinical Neuropsychology*, 14, 593-601.
- Reynolds, C. E., & Brown, R. T. (eds.). (1984). *Perspectives on bias in mental testing*. New York: Plenum.
- Reynolds, C. R., Sanchez, S., & Wilson, V. L. (1996). Normative tables for calculating the WISC-III Performance and Full Scale IQs when Symbol Search is substituted for Coding. *Psychological Assessment*, 8, 378-382.
- Reynolds, W. M. (1987). *Suicidal Ideation Questionnaire*. Odessa, FL: Psychological Assessment Resources.
- Rezmovic, V. (1977). The effects of computerized experimentation on response variance. *Behavior Research Methods and Instrumentation*, 9, 144-147.
- Reznikoff, M., & Tomblen, D. (1956). The use of human figure drawings in the diagnosis of organic pathology. *Journal of Consulting Psychology*, 20, 467-470.
- Rice, M. E., & Harris, G. T. (1995). Violent recidivism: Assessing predictive validity. *Journal of Consulting and Clinical Psychology*, 63, 737-748.
- Richardson, M. W., & Kuder, G. F. (1939). The calculation of test reliability based upon the method of rational equivalence. *Journal of Educational Psychology*, 30, 681-687.
- Richman, J. (1988). The case against rational suicide. *Suicide & Life-Threatening Behavior*, 18, 285-289.
- Richters, J. E., & Hinshaw, S. (1999). The abduction of disorder in psychiatry. *Journal of Abnormal Psychology*, 108, 438-445.
- Rierdan, J., & Koff, E. (1981). Sexual ambiguity in children's human figure drawings. *Journal of Personality Assessment*, 45, 256-257.
- Riethmiller, R. J., & Handler, L. (1997a). Problematic methods and unwarranted conclusions in DAP research: Suggestions for improved research procedures. *Journal of Personality Assessment*, 69, 459-475.
- Riethmiller, R. J., & Handler, L. (1997b). The great figure drawing controversy: The integration of research and clinical practice. *Journal of Personality Assessment*, 69, 488-496.
- Riggs, D. S., Murphy, C. M., & O'Leary, K. D. (1989). Intentional falsification in reports of interpartner aggression. *Journal of Interpersonal Violence*, 4, 220-232.
- Ritson, B., & Forest, A. (1970). The simulation of psychosis: A contemporary presentation. *British Journal of Medical Psychology*, 43, 31-37.
- Ritzler, B. (1995). Putting your eggs in the content analysis basket: A response to Aronow, Reznikoff and Moreland. *Journal of Personality Assessment*, 64, 229-234.
- Ritzler, B. A., Sharkey, K. J., & Chudy, J. F. (1980). A comprehensive projective alternative to the TAT. *Journal of Personality Assessment*, 44, 358-362.
- Riverside Publishing. (2001). *Report Writer for the WJ III*. Itasca, IL: Author.
- Roach, R. J., Frazier, L. P., & Bowden, S. R. (1981). The Marital Satisfaction Scale: Development of a measure for intervention research. *Journal of Marriage and the Family*, 21, 251-255.
- Roback, A. A. (1961). *History of psychology and psychiatry*. New York: Philosophical Library.
- Robbins, S. B., & Patton, M. J. (1985). Self-psychology and career development: Construction of the Superiority and Goal Instability Scales. *Journal of Counseling Psychology*, 32, 221-231.
- Roberts, B. W., & DelVecchio, W. F. (2000). The rank-order consistency of personality traits from childhood to old age: A quantitative review of longitudinal studies. *Psychological Bulletin*, 126, 3-25.
- Roberts, M. W. (2001). Clinic observations of structured parent-child interaction designed to evaluate externalizing disorders. *Psychological Assessment*, 13, 46-58.
- Roberts, R. N., & Magrab, P. R. (1991). Psychologists' role in a family-centered approach to practice, training, and research with young children. *American Psychologist*, 46, 144-148.
- Robertson, G. J. (1990). A practical model for test development. In C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Intelligence & achievement* (pp. 62-85). New York: Guilford.
- Robin, A. L., Koepke, T., & Moye, A. (1990). Multidimensional assessment of parent-adolescent relations. *Psychological Assessment*, 2, 451-459.
- Robinson, F. G. (1992). *Love's story untold: The life of Henry A. Murray*. Cambridge, MA: Harvard University.
- Robinson, N. M., Zigler, E., & Gallagher, J. J. (2000). Two tails of the normal curve: Similarities and differences in the study of mental retardation and giftedness. *American Psychologist*, 55, 1413-1424.
- Rodriguez, O., & Santiviago, M. (1991). Hispanic deaf adolescents: A multicultural minority. *Volta Review*, 93, 89-97.
- Roe, A., & Klos, D. (1969). Occupational classification. *Counseling Psychologist*, 1, 84-92.
- Rogers, C. R. (1959). A theory of therapy, personality, and interpersonal relationships, as developed in the client-centered framework. In S. Koch (ed.), *Psychology: A study of a science* (Vol. 3, pp. 184-256). New York: McGraw-Hill.

- Rogers, L. S., Knauss, J., & Hammond, K. R. (1951). Predicting continuation in therapy by means of the Rorschach Test. *Journal of Consulting Psychology*, 15, 368-371.
- Rogers, R. (1986). *Structured interview of reported symptoms* (SIRS). Unpublished scale. Toronto: Clarke Institute of Psychiatry.
- Rogers, R., Bagby, R. M., & Dickens, S. E. (1992). *Structured Interview of Reported Symptoms (SIRS) and professional manual*. Odessa, FL: Psychological Assessment Resources.
- Rogers, R., & Cavanaugh, J. L. (1980). Differences in psychological variables between criminally responsible and insane patients: A preliminary study. *American Journal of Forensic Psychiatry*, 1, 29-37.
- Rogers, R., & Cavanaugh, J. L. (1981). Rogers Criminal Responsibility Assessment Scales. *Illinois Medical Journal*, 160, 164-169.
- Rogers, R., Dolmetsch, R., & Cavanaugh, J. L. (1981). An empirical approach to insanity evaluations. *Journal of Clinical Psychology*, 37, 683-687.
- Rogers, R., Seman, W., & Wasylwi, D. E. (1983). The RCRAS and legal insanity: A cross validation study. *Journal of Clinical Psychology*, 39, 554-559.
- Rogers, R., Wasylwi, D. E., & Cavanaugh, J. L. (1984). Evaluating insanity: A study of construct validity. *Law & Human Behavior*, 8, 293-303.
- Rogler, L. H. (2002). Historical generations and psychology: The case of the Great Depression and World War II. *American Psychologist*, 57, 1013-1023.
- Rohl, J. S. (1993). The Tower of Hanoi. Supplementary information supplied with *Jarrah Wooden Tower of Hanoi*. Mt. Lawley, Australia: Built-Rite Sales.
- Rohner, R. P. (1984). Toward a conception of culture for cross-cultural psychology. *Journal of Cross-Cultural Psychology*, 15, 111-138.
- Roid, G. H. (2003a). *Stanford-Binet Intelligence Scales*, Fifth Edition. Itasca, IL: Riverside Publishing.
- Roid, G. H. (2003b). *Stanford-Binet Intelligence Scales*, Fifth Edition, Technical manual. Itasca, IL: Riverside Publishing.
- Roid, G. H. (2003c). *Stanford-Binet Intelligence Scales*, Fifth Edition, Examiner's manual. Itasca, IL: Riverside Publishing.
- Roid, G. H., Woodcock, R. W., & McGrew, K. S. (1997). *Factor analysis of the Stanford-Binet L and M forms*. Unpublished paper. Itasca, IL: Riverside Publishing.
- Rokeach, M. (1973). *The nature of human values*. New York: Free Press.
- Romanczyk, R. G. (1986). *Clinical utilization of microcomputer technology*. New York: Pergamon.
- Romano, J. (1994, November 7). Do drunken drivers get railroaded? *New York Times*, pp. NNJ1, NNJ19.
- Rome, H. P., Mataya, P., Pearson, J. S., Swenson, W., & Brannick, T. L. (1965). Automatic personality assessment. En R. W. Stacey & B. Waxman (eds.), *Computers in biomedical research* (Vol. 1, pp. 505-524). New York: Academic Press.
- Ronan, G. G., Date, A. L., & Weisbrod, M. (1995). Personal problem-solving scoring of the TAT: Sensitivity to training. *Journal of Personality Assessment*, 64, 119-131.
- Rorer, L. G. (1965). The great response-style myth. *Psychological Bulletin*, 63, 129-156.
- Rorschach, H. (1921/1942). *Psycho-diagnostics: A diagnostic test based on perception* (P. Lemkau & B. Kronenburg, Trans.). Berne: Huber. (First German edition: 1921. Distributed in the United States by Grune & Stratton.)
- Rorschach, H., & Oberholzer, E. (1923). The application of the interpretation of form to psychoanalysis. *Journal of Nervous and Mental Diseases*, 60, 225-248, 359-379.
- Rosen, J. (1998, February 23/ March 2). Damage control. *New Yorker*, 74, 64-68.
- Rosen, M., Simon, E. W., & McKinsey, L. (1995). Subjective measure of quality of life. *Mental Retardation*, 33, 31-34.
- Rosenman, R. H., Brand, R. J., Jenkins, C. D., Friedman, M., Straus, R., & Wurm, M. (1975). Coronary heart disease in the Western Collaborative Group Study: Final followup experience of 81/2 years. *Journal of the American Medical Association*, 233, 872-877.
- Rosenzweig, S. (1945). The picture-association method and its application in a study of reactions to frustration. *Journal of Personality*, 14, 3-23.
- Rosenzweig, S. (1978). *The Rosenzweig Picture Frustration (P-F) Study: Basic manual*. St. Louis, MO: Rana House.
- Rossini, E. D., & Moretti, R. J. (1997). Thematic Apperception Test (TAT) interpretation: Practice recommendations from a survey of clinical psychology doctoral programs accredited by the American Psychological Association. *Professional Psychology*, 28, 393-398.
- Roszkowski, M. J., & Spreat, S. (1981). A comparison of the psychometric and clinical methods of determining level of mental retardation. *Applied Research in Mental Retardation*, 2, 359-366.
- Rothberg, J. M., & Geer-Williams, C. (1992). A comparison and review of suicide prediction scales. En R. W. Maris et al. (eds.), *Assessment and prediction of suicide* (pp. 202-217). New York: Guilford.
- Rotter, J. B. (1966). Generalized expectancies for internal versus external control of reinforcement. *Psychological Monographs*, 80 (Whole Number 609).
- Rotter, J. B., Lah, M. I., & Rafferty, J. E. (1992). *Rotter Incomplete Sentences Blank manual*. San Antonio, TX: Psychological Corporation.
- Rotter, J. B., & Rafferty, J. E. (1950). *The manual for the Rotter Incomplete Sentences Blank*. New York: Psychological Corporation.
- Rottinghaus, P. J., Betz, N. E., & Borgen, F. H. (2003). Validity of parallel measures of vocational interests and confidence. *Journal of Career Assessment*, 11, 355-378.
- Rotton, J., & Kelly, I. W. (1985). Much ado about the full moon: A meta-analysis of lunar-lunacy research. *Psychological Bulletin*, 97, 286-306.
- Rotundo, M., & Sackett, P. R. (1999). Effect of rater race on conclusions regarding differential prediction in cognitive ability tests. *Journal of Applied Psychology*, 84, 815-822.
- Rouse, S. V., Butcher, J. N., & Miller, K. B. (1999). Assessment of substance abuse in psychotherapy clients: The effectiveness of MMPI-2 substance abuse scales. *Psychological Assessment*, 11, 101-107.
- Routh, D. K., & King, K. W. (1972). Social class bias in clinical judgment. *Journal of Consulting and Clinical Psychology*, 38, 202-207.
- Roy, P. (1962). The measurement of assimilation: The Spokane Indians. *American Journal of Sociology*, 67, 541-551.
- Rozeboom, W. W. (1996a). What might common factors be? *Multivariate Behavioral Research*, 31, 555-570.
- Rozeboom, W. W. (1996b). Factor-indeterminacy issues are not linguistic confusions. *Multivariate Behavioral Research*, 31, 637-650.
- Ruch, G. M. (1925). Minimum essentials in reporting data on standard tests. *Journal of Educational Research*, 12, 349-358.
- Ruch, G. M. (1933). Recent developments in statistical procedures. *Review of Educational Research*, 3, 33-40.

- Ruch, W. (1993). Exhilaration and humor. En M. Lewis & J. M. Haviland (eds.), *Handbook of emotions* (pp. 605-616). New York: Guilford.
- Ruffolo, L. F., Guilmette, T. J., & Grant, W. W. (2000). Comparison of time and error rates on the Trail Making Test among patients with head injuries, experimental malingerers, patients with suspect effort on testing, and normal controls. *Clinical Neuropsychologist*, 14, 223-230.
- Russell, J. S. (1984). A review of fair employment cases in the field of training. *Personnel Psychology*, 37, 261-276.
- Russo, D. C., Bird, B. L., & Masek, B. J. (1980). Assessment issues in behavioral medicine. *Behavioral Assessment*, 2, 1-18.
- Rutherford, A. (2003). B. F. Skinner and the auditory inkblot: The rise and fall of the verbal summator as a projective technique. *History of Psychology*, 6, 362-378.
- Ryan, A. M., Sacco, J. M., McFarland, L. A., & Kriska, S. D. (2000). Applicant self-selection: Correlates of withdrawal from a multiple hurdle process. *Journal of Applied Psychology*, 85, 163-169.
- Ryan, J. J., Paolo, A. M., & Brungardt, T. M. (1990). Standardization of the Wechsler Adult Intelligence Scale—Revised for persons 75 years and older. *Psychological Assessment*, 2, 404-411.
- Ryan, J. J., & Ward, L. C. (1999). Validity, reliability, and standard errors of measurement for two seven-subtest short forms of the Wechsler Adult Intelligence Scale-III. *Psychological Assessment*, 11, 207-211.
- Sabatelli, R. M. (1984). The Marital Comparison Level Index: A measure for assessing outcomes relative to expectations. *Journal of Marriage and the Family*, 46, 651-662.
- Sachs, B. B. (1976). Some views of a deaf Rorschacher on the personality of deaf individuals. *Hearing Rehabilitation Quarterly*, 2, 13-14.
- Sackett, P. R. (1994). Integrity testing for personnel selection. *Current Directions in Psychological Science*, 3, 73-76.
- Sackett, P. R., Burris, L. R., & Callahan, C. (1989). Integrity testing for personnel selection: An update. *Personnel Psychology*, 42, 491-529.
- Sackett, P. R., & Harris, M. M. (1984). Honesty testing for personnel selection: A review and critique. *Personnel Psychology*, 37, 221-245.
- Sackett, P. R., Schmitt, N., Ellingson, J. E., & Kabin, M. B. (2001). High-stakes testing in employment, credentialing, and higher education: Prospects in a post-affirmative action world. *American Psychologist*, 56, 302-318.
- Sackett, P. R., & Wilk, S. L. (1994). Within-group norming and other forms of score adjustment in preemployment testing. *American Psychologist*, 49, 929-954.
- Sacks, E. (1952). Intelligence scores as a function of experimentally established social relationships between child and examiner. *Journal of Abnormal and Social Psychology*, 47, 354-358.
- Sacks, O. (1989). *Seeing voices: A journey into the world of the deaf*. Berkeley: University of California.
- Salas, E., Cannon-Bowers, J. A., Church-Payne, S., & Smith-Jentsch, K. A. (1998). Teams and teamwork in the military. In C. Cronin (ed.), *Military psychology: An introduction* (pp. 71-87). Needham Heights, MA: Simon & Schuster.
- Salthouse, T. A., Toth, J., Daniels, K., et al. (2000). Effects of aging on efficiency of task switching in a variant of the Trail Making Test. *Neuropsychology*, 14, 102-111.
- Salvia, J., & Hritcko, T. (1984). The K-ABC and ability training. *Journal of Special Education*, 18, 345-356.
- Samuda, R. J. (1982). *Psychological testing of American minorities: Issues and consequences*. New York: Harper & Row.
- Sanchez, L. M., & Turner, S. M. (2003). Practicing psychology in the era of managed care. *American Psychologist*, 58, 116-129.
- Sandelands, L. E., & Larson, J. R. (1985). When measurement causes task attitudes: A note from the laboratory. *Journal of Applied Psychology*, 70, 116-121.
- Sandoval, J. (1995). Review of the Wechsler Intelligence Scale for Children, Third Edition. En J. C. Conoley & J. C. Impara (eds.), *The twelfth mental measurements yearbook*. Lincoln: Buros Institute of Measurements, University of Nebraska.
- Sandoval, J., et al. (eds.). (1998). *Test interpretation and diversity: Achieving equity in assessment*. Washington, DC: American Psychological Association.
- Sandoval, J., Antunez-Bellatin, M., & Lewis, S. (2002). Using the DAS nonverbal scales with Spanish-speaking children: Translation and validation. *California School Psychologist*, 7, 7-25.
- Sanfilippo, J., et al. (1986). Identifying the sexually molested preadolescent girl. *Pediatric Annals*, 15, 621-624.
- Sattler, J. M. (1991). How good are federal judges in detecting differences in item difficulty on intelligence tests for ethnic groups? *Psychological Assessment*, 3, 125-129.
- Sattler, J. M. (1992). *Assessment of children: WISC-III and WPPSI-R supplement*. San Diego: Author.
- Saunders, E. A. (1991). Rorschach indicators of chronic childhood sexual abuse in female borderline inpatients. *Bulletin of the Menninger Clinic*, 55, 48-65.
- Savickas, M. L., Alexander, D. E., Osipow, S. H., & Wolf, F. M. (1985). Measuring specialty indecision among career-decided students. *Journal of Vocational Behavior*, 27, 356-357.
- Savickas, M. L., & Spokane, A. R. (eds.). (1999). *Vocational interests: Meaning, measurement, and counseling use*. Palo Alto, CA: Davies-Black Publishing.
- Savickas, M. L., Taber, B. J., & Spokane, A. R. (2002). Convergent and discriminant validity of five interest inventories. *Journal of Vocational Behavior*, 61, 139-184.
- Saxe, L. (1994). Detection of deception: Polygraph and integrity tests. *Current Directions in Psychological Science*, 3, 69-73.
- Saxe, L., & Ben-Shakhar, G. (1999). Admissibility of polygraph tests: The application of scientific standards post-Daubert. *Psychology, Public Policy, and Law*, 5, 203-223.
- Saxton, J., McGonigle-Gibson, K. L., Swihart, A. A., Miller, V. J., & Boller, F. (1990). Assessment of the severely impaired patient: Description and validation of a new neuropsychological test battery. *Psychological Assessment*, 2, 298-303.
- Sayer, A. G., Willett, J. B., & Perrin, E. C. (1993). Measuring understanding of illness causality in healthy children and in children with chronic illness: A construct validation. *Journal of Applied Developmental Psychology*, 14, 11-36.
- Sayette, M. A., Shiffman, S., Tiffany, S. T., et al. (2000). The measurement of drug craving. *Addiction*, 93(Suppl. 2), S189-S210.
- Scarr, S. (1992). Developmental theories for the 1990s: Development and individual differences. *Child Development*, 63, 1-19.
- Scarr, S. (1993). Biological and cultural diversity: The legacy of Darwin for development. *Child Development*, 64, 1333-1353.
- Schaie, K. W. (1978). External validity in the assessment of intellectual development in adulthood. *Journal of Gerontology*, 33, 695-701.
- Scheid, T. L. (1999). Employment of individuals with mental disabilities: Business response to the ADA's challenge. *Behavioral Sciences and the Law*, 17, 73-91.
- Schein, J. D., & Delk, M. T., Jr. (1974). *The deaf population in the United States*. Silver Springs, MD: National Association for the Deaf.
- Schildroth, A., Rawlings, B., & Allen, T. (1991). Deaf students in transition: Education and employment issues for deaf

- adolescents. En O. Cohen & G. Long (eds.), *Selected issues in adolescence and deafness* [Special issue]. *Volta Review*, 93(5), 41-53.
- Schloss, I. (1981). Chicken and pickles. *Journal of Advertising Research*, 21, 47-49.
- Schmand, B., Brand, N., & Kuipers, T. (1992). Procedural learning of cognitive and motor skills in psychotic patients. *Schizophrenia Research*, 8, 157-170.
- Schmidt, F. L. (1988). The problem of group differences in ability scores in employment selection. *Journal of Vocational Behavior*, 33, 272-292.
- Schmidt, F. L., & Hunter, J. E. (1974). Racial and ethnic bias in psychological tests: Divergent implications of two definitions of test bias. *American Psychologist*, 29, 1-8.
- Schmidt, F. L., & Hunter, J. E. (1992). Development of a causal model of processes determining job performance. *Current Directions in Psychological Science*, 1, 89-92.
- Schmidt, F. L., & Hunter, J. E. (1998). The validity and utility of selection methods in personnel psychology: Practical and theoretical implications of 85 years of research findings. *Psychological Bulletin*, 124, 262-274.
- Schmidt, F. L., Hunter, J. E., McKenzie, R. C., & Muldrow, T. W. (1979). Impact of valid selection procedures on work force productivity. *Journal of Applied Psychology*, 64, 609-626.
- Schmidt, F. L., Hunter, J. E., Outerbridge, A. N., & Trattner, M. H. (1986). The economic impact of job selection methods on size, productivity, and payroll costs of the federal work force: An empirically based demonstration. *Personnel Psychology*, 32, 1-29.
- Schmitt, N. (1976). Social and situational determinants of interview decisions: Implications for the employment interview. *Personnel Psychology*, 29, 79-101.
- Schmitt, N., Gooding, R., Noe, R., & Kirsch, M. (1984). Meta-analysis of validity studies published between 1964 and 1982 and the investigation of study characteristics. *Personnel Psychology*, 37, 407-422.
- Schneider, B. (1987). The people make the place. *Personnel Psychology*, 40, 437-453.
- Schneider, M. F. (1989). *Children's Apperceptive Story-telling Test*. Austin, TX: PRO-ED.
- Schönemann, P. H. (1996a). The psychopathology of factor indeterminacy. *Multivariate Behavioral Research*, 31, 571-577.
- Schönemann, P. H. (1996b). Syllogisms of factor indeterminacy. *Multivariate Behavioral Research*, 31, 651-654.
- Schoop, L. H., Herrman, T. D., Johnstone, B., Callahan, C. D., & Roudebush, I. S. (2001). Two abbreviated versions of the Wechsler Adult Intelligence Scale-III: Validation among persons with traumatic brain injury. *Rehabilitation Psychology*, 46, 279-287.
- Schouten, P. G. W., & Kirkpatrick, L. A. (1993). Questions and concerns about the Miller Assessment for Preschoolers. *Occupational Therapy Journal of Research*, 13, 7-28.
- Schuh, A. J. (1978). Contrast effect in the interview. *Bulletin of the Psychonomic Society*, 11, 195-196.
- Schuler, M. E., Nair, P., & Harrington, D. (2003). Developmental outcome of drug-exposed children through 30 months: A comparison of Bayley and Bayley-II. *Psychological Assessment*, 15, 435-438.
- Schulte, A. A., Gilbertson, E., Kratochwil, T. R. (2000). Educators' perceptions and documentation of testing accommodations for students with disabilities. *Special Services in the Schools*, 16, 35-56.
- Schultz, B. M., Dixon, E. B., Lindenberger, J. C., & Ruther, N. J. (1989). *Solomon's sword: A practical guide to conducting child custody evaluations*. San Francisco: Jossey-Bass.
- Schwartz, L. A. (1932). Social situation pictures in the psychiatric interview. *American Journal of Orthopsychiatry*, 2, 124-132.
- Schwartz, N., Groves, R. M., & Schuman, H. (1998). Survey methods. En D. T. Gilbert et al. (eds.), *The handbook of social psychology* (4th ed., Vol. 1, pp. 143-179). New York: McGraw-Hill.
- Scott, L. H. (1981). Measuring intelligence with the Goodenough-Harris Drawing Test. *Psychological Bulletin*, 89, 483-505.
- Seagull, F. J., & Gopher, D. (1997). Training head movement in visual scanning: An embedded approach to the development of piloting skills with helmet-mounted displays. *Journal of Experimental Psychology: Applied*, 3, 163-180.
- Sears, R. R. (1977). Sources of life satisfaction of the Terman gifted men. *American Psychologist*, 32, 119-281.
- Seashore, C. E. (1938). *Psychology of music*. New York: McGraw-Hill.
- Sebold, J. (1987). Indicators of child sexual abuse in males. *Social Casework*, 68, 75-80.
- Segal, S. P., Redman, D., & Silverman, C. (2000). Measuring clients' satisfaction with self-help agencies. *Psychiatric Services*, 51, 1148-1152.
- Seibert, S. E., & Kraimer, M. L. (2001). The five-factor model of personality and career success. *Journal of Vocational Behavior*, 58, 1-21.
- Serby, M., Corwin, J., Conrad, P., et al. (1985). Olfactory dysfunction in Alzheimer's disease and Parkinson's disease. *American Journal of Psychiatry*, 142, 781-782.
- Serby, M., Larson, P., & Kalkstein, D. (1991). The nature and course of olfactory deficits in Alzheimer's disease. *American Journal of Psychiatry*, 148, 357-360.
- Serin, R. C., Peters, R. DeV., & Barbaree, H. E. (1990). Predictors of psychopathy and release outcome in a criminal population. *Psychological Assessment*, 2, 419-422.
- Serpell, R. (1979). How specific are perceptual skills? A cross-cultural study of pattern reproduction. *British Journal of Psychology*, 70, 365-380.
- Sevig, T. D., Highlen, P. S., & Adams, E. M. (2000). Development and validation of the Self-Identity Inventory (SII): A multicultural identity development instrument. *Cultural Diversity and Ethnic Minority Psychology*, 6, 168-182.
- Shah, S. A. (1969). Privileged communications, confidentiality, and privacy: Privileged communications. *Professional Psychology*, 1, 56-59.
- Shakow, D., & Rosenzweig, S. (1940). The use of the tautophone ("verbal summator") as an auditory apperceptive test for the study of personality. *Character and Personality*, 8, 216-226.
- Shapiro, E. S., & Skinner, C. H. (1990). Principles of behavior assessment. In C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Personality, behavior & context* (pp. 343-363). New York: Guilford.
- Shavelson, R. J., Webb, N. M., & Rowley, G. L. (1989). Generalizability theory. *American Psychologist*, 44, 922-932.
- Shaw, S. R., Swerdlik, M. E., & Laurent, J. (1993). Review of the WISC-III. En B. A. Bracken (ed.), *Monograph series, Advances in psychoeducational assessment: Wechsler Intelligence Scale for Children, Third Edition: Journal of Psychoeducational Assessment* (pp. 151-159). Brandon, VT: Clinical Psychology Publishing.
- Shaywitz, B. A., Shaywitz, S. E., Pugh, K. R., et al. (1995). Sex differences in the functional organization of the brain for language. *Nature*, 373, 607-609.
- Shedler, J. (2000). The Shedler QPD Panel (Quick PsychDiagnostics Panel): A psychiatric "lab test" for primary care. En M. E. Maruish (ed.), *Handbook of psychological assessment in primary care settings* (pp. 277-296). Mahwah, NJ: Erlbaum.

- Sheehan, P. W., Grigg, L., & McCann, T. (1984). Memory distortion following exposure to false information in hypnosis. *Journal of Abnormal Psychology*, 93, 259-296.
- Sheffield, D., Biles, P. L., Orom, H., Maixner, W., & Sheps, D. S. (2000). Race and sex differences in cutaneous pain perception. *Psychosomatic Medicine*, 62, 517-523.
- Shell, R. W. (1980). Psychiatric testimony: Science or fortune telling? *Barrister*, 7, 6-12.
- Shepard, L. A. (1983). The role of measurement in educational policy: Lessons from the identification of learning disabilities. *Journal of Special Education*, 14, 79-91.
- Sherrill-Pattison, S., Donders, J., & Thompson, E. (2000). Influence of demographic variables on neuropsychological test performance after traumatic brain injury. *Clinical Neuropsychologist*, 14, 496-503.
- Shiffman, S., Hufford, M., Hickcox, M., et al. (1997). Remember that? A comparison of real-time versus retrospective recall of smoking lapses. *Journal of Consulting and Clinical Psychology*, 65, 292-300.
- Shirom, A. (2003). Job-related burnout: A review. In J. C. Quick & L. E. Tetrick (eds.), *Handbook of occupational health psychology* (pp. 245-264). Washington, DC: American Psychological Association.
- Shneidman, E. S. (1952). Manual for the Make a Picture Story Method. *Projective Techniques Monographs*, 2.
- Shneidman, E. S. (1958). Some relationships between thematic and drawing materials. En E. F. Hammer (ed.), *The clinical applications of projective drawings* (pp. 296-307). Springfield, IL: Charles C Thomas.
- Shock, N. W., Greulich, R. C., Andres, R., et al. (1984). *Normal human aging: The Baltimore longitudinal study of aging* (NIH Publication No. 84-2450). Washington, DC: U.S. Government Printing Office.
- Shockley, W. (1971). Models, mathematics, and the moral obligation to diagnose the origin of Negro IQ deficits. *Review of Educational Research*, 41, 369-377.
- Shriner, J. G. (2000). Legal perspectives on school outcomes assessment for students with disabilities. *Journal of Special Education*, 33, 232-239.
- Shuey, A. M. (1966). *The testing of Negro intelligence* (2nd ed.). New York: Social Science.
- Shum, D., Short, L., Tunstall, J., et al. (2000). Performance of children with traumatic brain injury on a 4-disk version of the Tower of London and the Porteus Maze. *Brain & Cognition*, 44, 59-62.
- Shuman, D. W., & Sales, B. D. (1999). The impact of Daubert and its progeny on the admissibility of behavioral and social science evidence. *Psychology, Public Policy, and Law*, 5, 3-15.
- Siegler, R. S., & Richards, D. (1980). The development of intelligence. In R. S. Sternberg (Chair), *People's conception of the nature of intelligence*. Symposium presented at the 88th annual convention of the American Psychological Association, Montreal, Canada.
- Silka, V. R., & Hauser, M. J. (1997). Psychiatric assessment of the person with mental retardation. *Psychiatric Annals*, 27(3), 162-169.
- Silverstein, A. B. (1990). Short forms of individual intelligence tests. *Psychological Assessment*, 2, 3-11.
- Silverstein, M. L., & Nelson, L. D. (2000). Clinical and research implications of revising psychological tests. *Psychological Assessment*, 12, 298-303.
- Simpson, R. (1970). Study of the comparability of the WISC and WAIS. *Journal of Consulting and Clinical Psychology*, 2, 156-158.
- Simpson, R. L., Griswold, D. E., & Myles, B. S. (1999). Educators' assessment accommodation preferences for students with autism. *Focus on Autism and Other Developmental Disabilities*, 14(4), 212-219, 230.
- Sines, J. O. (1966). Actuarial methods in personality assessment. En B. A. Maher (ed.), *Progress in experimental personality research* (Vol. 3, pp. 133-193). New York: Academic Press.
- Siperstein, G. N., Leffert, J. S., & Wenz-Gross, M. (1997). The quality of friendships between children with and without learning problems. *American Journal on Mental Retardation*, 102, 111-125.
- Sivec, H. J., Lynn, S. J., & Garske, J. P. (1994). The effect of somatoform disorders and paranoid psychotic role-related dissimulations as a response set on the MMPI-2. *Assessment*, 1, 69-81.
- Skafta, D. (1985). *Child custody evaluations: A practical guide*. Beverly Hills, CA: Sage.
- Skinner, B. F. (1979). *The shaping of a behaviorist*. New York: Knopf.
- Skinner, H. A., & Allen, B. A. (1983). Does the computer make a difference? Computerized versus face-to-face versus self-report assessment of alcohol, drug, and tobacco use. *Journal of Consulting and Clinical Psychology*, 51, 267-275.
- Skinner, H. A., & Pakula, A. (1986). Challenge of computers in psychological assessment. *Professional Psychology: Research and Practice*, 17, 44-50.
- Skolnick, J. H. (1961). Scientific theory and scientific evidence: An analysis of lie detection. *Yale Law Journal*, 70, 694-728.
- Slakter, M. J., Crehan, K. D., & Koehler, R. A. (1975). Longitudinal studies of risk taking on objective examinations. *Educational and Psychological Measurement*, 35, 97-105.
- Slate, J. R., Jones, C. H., Murray, R. A., & Coulter, C. (1993). Evidence that practitioners err in administering and scoring the WAIS-R. *Measurement and Evaluation in Counseling and Development*, 25, 156-161.
- Slater, S. B., Vukmanovic, C., Macukanovic, P., Prvulovic, T., & Cutler, J. L. (1974). The definition and measurement of disability. *Social Science and Medicine*, 8, 305-308.
- Slay, D. K. (1984). A portable Halstead-Reitan Category Test. *Journal of Clinical Psychology*, 40, 1023-1027.
- Slobogin, C. (1999). The admissibility of behavioral science information in criminal trials: From primitivism to Daubert to Voice. *Psychology, Public Policy, and Law*, 5, 100-119.
- Smith, D. E. (1986). Training programs for performance appraisal: A review. *Academy of Management Review*, 11, 22-40.
- Smith, D. K. (1985). *Test use and perceived competency: A survey of school psychologists*. Unpublished manuscript, University of Wisconsin-River Falls, School Psychology Program.
- Smith, D. K., Bolin, J. A., & Stovall, D. R. (1988). K-ABC stability in a preschool sample: A longitudinal study. *Journal of Psychoeducational Assessment*, 6, 396-403.
- Smith, D. K., & Knudtson, L. S. (1990). K-ABC and S-B:FE relationships in an at-risk preschool sample. Paper presented at the Annual Meeting of the American Psychological Association, Boston.
- Smith, D. K., Lasee, M. J., & McCloskey, G. M. (1990). *Test-retest reliability of the AGS Early Screening Profiles*. Paper presented at the Annual Meeting of the National Association of School Psychologists, San Francisco.
- Smith, D. K., & Lyon, M. A. (1987). *Children with learning difficulties: Differences in ability patterns as a function of placement*. Paper presented at the Annual Meeting of the American Educational Research Association, Washington, DC. (ERIC Document Reproduction Service No. ED 285 317).
- Smith, D. K., St. Martin, M. E., & Lyon, M. A. (1989). A validity study of the Stanford-Binet Fourth Edition with students with learning disabilities. *Journal of Learning Disabilities*, 22, 260-261.
- Smith, G. E., Ivnik, R. J., Malec, J. F., Kokmen, E., Tangalos, E. G., & Kurland, L. T. (1992). Mayo's older Americans normative

- studies (MOANS): Factor structure of a core battery. *Psychological Assessment*, 4, 382-390.
- Smith, G. T., McCarthy, D. M., & Anderson, K. G. (2000). On the sins of short form development. *Psychological Assessment*, 12, 102-111.
- Smith, M. (1948). Cautions concerning the use of the Taylor-Russell tables in employee selection. *Journal of Applied Psychology*, 32, 595-600.
- Smith, R. E. (1963). Examination by computer. *Behavioral Science*, 8, 76-79.
- Smith, R. G., & Iwata, B. A. (1997). Antecedent influences on behavior disorders. *Journal of Applied Behavior Analysis*, 30, 343-375.
- Smith, T., Smith, B. L., Bramlett, R. K., & Hicks, N. (2000). WISC-III stability over a three-year period in students with learning disabilities. *Research in the Schools*, 7, 37-41.
- Smith, T. C., Matthews, N., Smith, B., & Kennedy, S. (1993). Subtest scatter and Kaufman regroupings on the WISC-R in non-learning-disabled and learning-disabled children. *Psychology in the Schools*, 30, 24-28.
- Smith, T. T., Myers-Jennings, C., & Coleman, T. (2000). Assessment of language skills in rural preschool children. *Communication Disorders Quarterly*, 21, 98-113.
- Smither, J. W., Reilly, R. R., & Buda, R. (1988). Effect of prior performance information on ratings of present performance: Contrast versus assimilation revisited. *Journal of Applied Psychology*, 73, 487-496.
- Smither, R., & Rodriguez-Giegling, M. (1982). Personality, demographics, and acculturation of Vietnamese and Nicaraguan refugees to the United States. *International Journal of Psychology*, 17, 19-25.
- Snowden, L. R., & Hines, A. M. (1999). A scale to assess African American acculturation. *Journal of Black Psychology*, 25, 36-47.
- Snyder, C. R., Shenkel, R. J., & Lowery, C. R. (1977). Acceptance of personality interpretations: The "Barnum effect" and beyond. *Journal of Consulting and Clinical Psychology*, 45, 104-114.
- Snyder, C. R., Shenkel, R. J., & Schmidt, A. (1976). Effect of role perspective and client psychiatric history on locus of problem. *Journal of Consulting and Clinical Psychology*, 44, 467-472.
- Snyder, D. K. (1981). *Marital Satisfaction Inventory (MSI) manual*. Los Angeles: Western Psychological Services.
- Snyder, D. K. (2000). Computer-assisted judgment: Defining strengths and liabilities. *Psychological Assessment*, 12, 52-60.
- Snyder, D. K., Widiger, T. A., & Hoover, D. W. (1990). Methodological considerations in validating computer-based test interpretations: Controlling for response bias. *Psychological Assessment*, 2, 470-477.
- Snyder, P., Lawson, S., Thompson, B., Stricklin, S., & Sexton, D. (1993). Evaluating the psychometric integrity of instruments used in early intervention research: The Battelle Developmental Inventory. *Topics in Early Childhood Special Education*, 32, 273-280.
- Sobell, L. C., & Sobell, M. B. (1992). Timeline followback: A technique for assessing self-reported alcohol consumption. En R. Z. Litten & J. P. Allen (eds.), *Measuring alcohol consumption* (pp. 41-71). Totowa, NJ: Humana Press.
- Sobell, L. C., & Sobell, M. B. (2000). Alcohol timeline followback (TLFB). In American Psychiatric Association (ed.), *Handbook of psychiatric measures* (pp. 477-479).
- Sodowsky, G. R., & Carey, J. C. (1988). Relationships between acculturation-related demographics and cultural attitudes of an Asian-Indian immigrant group. *Journal of Multicultural Counseling and Development*, 16(July), 117-136.
- Sokal, M. M. (1991). Psyche Cattell (1893-1989). *American Psychologist*, 46, 72.
- Solomon, I. L., & Starr, B. D. (1968). *The School Apperception Method*. New York: Springer.
- Solomon, P. R., Hirschhoff, A., Kelly, B., et al. (1998). A 7-minute neurocognitive screening battery highly sensitive to Alzheimer's disease. *Archives of Neurology*, 55, 349-355.
- Sommers-Flanagan, J., & Sommers-Flanagan, R. (1995). Intake interviewing with suicidal patients: A systematic approach. *Professional Psychology: Research and Practice*, 26, 41-47.
- Sontag, L. W., Baker, C. T., & Nelson, V. L. (1958). Personality as a determinant of performance. *American Journal of Orthopsychiatry*, 25, 555-562.
- Spanier, G. (1976). Measuring dyadic adjustment: New scales for assessing the quality of marriage and similar dyads. *Journal of Marriage and the Family*, 38, 15-28.
- Spanier, G. B., & Filsinger, E. (1983). The Dyadic Adjustment Scale. En E. Filsinger (ed.), *Marriage and family assessment*. Beverly Hills, CA: Sage.
- Sparrow, S. S., Balla, D. A., & Cicchetti, D. V. (1984a). *Vineland Adaptive Behavior Scales, Interview Edition: Expanded form manual*. Circle Pines, MN: American Guidance Service.
- Sparrow, S. S., Balla, D. A., & Cicchetti, D. V. (1984b). *Vineland Adaptive Behavior Scales, Interview Edition: Survey form manual*. Circle Pines, MN: American Guidance Service.
- Sparrow, S. S., Balla, D. A., & Cicchetti, D. V. (1985). *Vineland Adaptive Behavior Scales, Classroom Edition manual*. Circle Pines, MN: American Guidance Service.
- Spearman, C. (1927). *The abilities of man: Their nature and measurement*. New York: Macmillan.
- Spearman, C. E. (1904). "General intelligence" objectively determined and measured. *American Journal of Psychiatry*, 15, 201-293.
- Spearman, C. E. (1930-1936). Autobiography. In C. Murchison (ed.), *A history of psychology in autobiography* (3 vols.). Worcester, MA: Clark University Press.
- Speth, E. B. (1992). *Test-retest reliabilities of Bricklin Perceptual Scales*. Unpublished doctoral dissertation, Hahneman University Graduate School, Philadelphia.
- Spiegel, J. S., Leake, B., Spiegel, T. M., et al. (1988). What are we measuring? An examination of self-reported functional status measures. *Arthritis and Rheumatism*, 31, 721-728.
- Spielberger, C. D., et al. (1980). *Test Anxiety Inventory: Preliminary professional manual*. Palo Alto, CA: Consulting Psychologists Press.
- Spitz, H. H., Minsky, S. K., & Bessellieu, C. L. (1985). Influence of planning time and first-move strategy on Tower of Hanoi problem-solving performance of mentally retarded young adults and non-retarded children. *American Journal of Mental Deficiency*, 90, 46-56.
- Spitzer, R. L. (1999). Harmful dysfunction and the DSM definition of mental disorder. *Journal of Abnormal Psychology*, 108, 430-432.
- Spivack, G., & Spotts, J. (1966). *Devereux Child Behavior Rating Scale manual*. Devon, PA: Devereux Foundation.
- Spivack, G., Spotts, J., & Haimes, P. E. (1967). *Devereux Adolescent Behavior Rating Scale*. Devon, PA: Devereux Foundation.
- Spokane, A. R., & Decker, A. R. (1999). Expressed and measured interests. En M. L. Savickas & A. R. Spokane (eds.), *Vocational interests: Meaning, measurement, and counseling use* (pp. 211-233). Palo Alto, CA: Davies-Black Publishing.
- Spranger, E. (1928). *Types of men* (P. J. W. Pigors, Trans.). Halle, Germany: Niemeyer.
- Spren, O., & Benton, A. L. (1965). Comparative studies of some psychological tests for cerebral damage. *Journal of Nervous and Mental Disease*, 140, 323-333.

- Spruill, J., & May, J. (1988). The mentally retarded offender: Prevalence rates based on individual versus group intelligence tests. *Criminal Justice and Behavior*, 15, 484-491.
- Spruill, J. A. (1993). Secondary assessment: Structuring the transition process. *Learning Disabilities Research & Practice*, 8, 127-132.
- Staggs, G. D., Larson, L. M., & Borgen, F. H. (2003). Convergence of specific factors in vocational interests and personality. *Journal of Career Assessment*, 11, 243-261.
- Stahl, P. M. (1995). *Conducting child custody evaluations*. Thousand Oaks, CA: Sage.
- Stanczak, D. E., Lynch, M. D., McNeil, C. K., & Brown, B. (1998). The Expanded Trail Making Test: Rationale, development, and psychometric properties. *Archives of Clinical Neuropsychology*, 13, 473-487.
- Stanford Special Report, Number 9. (1992). Bias control. San Antonio, TX: Psychological Corporation/Harcourt Brace Jovanovich.
- Stanley, J. C. (1971). Reliability. En R. L. Thorndike (ed.), *Educational measurement* (2nd ed.). Washington, DC: American Council on Education.
- Starch, D., & Elliot, E. C. (1912). Reliability of grading of high school work in English. *School Review*, 20, 442-457.
- Staw, B. M., Bell, N. E., & Clausen, J. A. (1986). The dispositional approach to job attitudes: A lifetime longitudinal test. *Administrative Science Quarterly*, 31, 56-77.
- Steadman, H. J. (1983). Predicting dangerousness among the mentally ill: Art, magic, and science. *International Journal of Law and Psychiatry*, 6, 381-390.
- Stedman, J. M., Hatch, J. P., & Schoenfeld, L. S. (2000). Pre-internship preparation in psychological testing and psychotherapy: What internship directors say they expect. *Professional Psychology: Research and Practice*, 31, 321-326.
- Steiger, J. H. (1996a). Dispelling some myths about factor indeterminacy. *Multivariate Behavioral Research*, 31, 539-550.
- Steiger, J. H. (1996b). Coming full circle in the history of factor indeterminacy. *Multivariate Behavioral Research*, 31, 617-630.
- Steinberg, M., Cicchetti, D., Buchanan, J., & Hall, P. (1993). Clinical assessment of dissociative symptoms and disorders: The Structured Clinical Interview for DSM-IV Dissociative Disorders (SCID-D). *Dissociation: Progress in Dissociative Disorders*, 6, 3-15.
- Stephens, J. J. (1992). Assessing ethnic minorities. *SPA Exchange*, 2(1), 4-6.
- Stephenson, W. (1953). *The study of behavior: Q-technique and its methodology*. Chicago: University of Chicago.
- Sternberg, R. J. (1981). The nature of intelligence. *New York Education Quarterly*, 12(3), 10-17.
- Sternberg, R. J. (1982, April). Who's intelligent? *Psychology Today*, pp. 30-33, 35-36, 38-39.
- Sternberg, R. J. (1985). *Beyond IQ: A triarchic theory of human intelligence*. Cambridge: Cambridge University Press.
- Sternberg, R. J. (1986). Intelligence is mental self-government. En R. J. Sternberg & D. K. Detterman (eds.), *What is intelligence?* (pp. 141-148). Norwood, NJ: Ablex.
- Sternberg, R. J. (1994). PRSVL: An integrative framework for understanding mind in context. En R. J. Sternberg & R. K. Wagner (eds.), *Mind in context* (pp. 218-232). Cambridge: Cambridge University Press.
- Sternberg, R. J. (1997). Managerial intelligence. *Journal of Management*, 23, 475-493.
- Sternberg, R. J., & Berg, C. A. (1986). Quantitative integration: Definitions of intelligence: A comparison of the 1921 and 1986 symposia. En R. J. Sternberg & D. K. Detterman (eds.), *What is intelligence?* (pp. 155-162). Norwood, NJ: Ablex.
- Sternberg, R. J., Conway, B. E., Ketron, J. L., & Bernstein, M. (1981). People's conceptions of intelligence. *Journal of Personality and Social Psychology*, 41, 37-55.
- Sternberg, R. J., & Detterman, D. K. (eds.). (1986). *What is intelligence?* Norwood, NJ: Ablex.
- Sternberg, R. J., Lautrey, J., & Lubart, T. I. (eds.). (2003). *Models of intelligence*. Washington, DC: APA Books.
- Stevens, C. D., & Macintosh, G. (2003). Personality and attractiveness of activities within sales jobs. *Journal of Personal Selling & Sales Management*, 23, 23-37.
- Stice, E., Fisher, M., & Lowe, M. R. (2004). Are dietary restraint scales valid measures of acute dietary restriction? Unobtrusive observational data suggest not. *Psychological Assessment*, 16, 51-59.
- Stillman, R. (1974). *Assessment of deaf-blind children: The Callier-Azusa Scale*. Paper presented at the Intercom '74, Hyannis, MA.
- Stinnett, T. A. (1997). "AAMR Adaptive Behavior Scale-School: 2" Test review. *Journal of Psychoeducational Assessment*, 15, 361-372.
- Stokes, J. B. (1977). Comment on "Socially reinforced obsessing: Etiology of a disorder in a Christian Scientist." *Journal of Consulting and Clinical Psychology*, 45, 1164-1165.
- Stone, A. A. (1986). Vermont adopts Tarasoff: A real barn-burner. *American Journal of Psychiatry*, 143, 352-355.
- Stone, B. J. (1992). Prediction of achievement by Asian-American and White children. *Journal of School Psychology*, 30, 91-99.
- Stone, D. R. (1950). A recorded auditory apperception test as a new projective technique. *Journal of Psychology*, 29, 349-353.
- Stoppard, J. M., & Gruchy, C. D. G. (1993). Gender, context, and expression of positive emotion. *Personality and Social Psychology Bulletin*, 19, 143-150.
- Storandt, M. (1994). General principles of assessment of older adults. En M. Storandt & G. R. VandenBos (eds.), *Neuropsychological assessment of dementia and depression in older adults: A clinician's guide* (pp. 7-32). Washington, DC: American Psychological Association.
- Storey, K. (1997). Quality of life issues in social skills assessment of persons with disabilities. *Education and Training in Mental Retardation and Developmental Disabilities*, 32, 197-200.
- Stout, C. E., Levant, R. F., Reed, G. M., & Murphy, M. J. (2001). Contracts: A primer for psychologists. *Professional Psychology: Research and Practice*, 32, 89-91.
- Straus, M. A. (1979). Measuring intrafamily conflict and violence: The Conflict Tactics (CT) Scales. *Journal of Marriage and the Family*, 41, 75-85.
- Strauss, A. A., & Lehtinen, L. E. (1947). *Psychopathology and education of the brain injured child*. New York: Grune & Stratton.
- Strauss, E., Ottfried, S., & Hunter, M. (2000). Implications of test revisions for research. *Psychological Assessment*, 12, 237-244.
- Streiner, D. L. (2003a). Being inconsistent about consistency: When coefficient alpha does and doesn't matter. *Journal of Personality Assessment*, 80, 217-222.
- Streiner, D. L. (2003b). Starting at the beginning: An introduction to coefficient alpha and internal consistency. *Journal of Personality Assessment*, 80, 99-103.
- Stricker, G., & Gold, J. R. (1999). The Rorschach: Toward a nomothetically based, idiographically applicable configurational model. *Psychological Assessment*, 11, 240-250.
- Stricker, G., & Healey, B. J. (1990). Projective assessment of object relations: A review of the empirical literature. *Psychological Assessment*, 2, 219-230.

- Strong, E. K., Jr., Hansen, J. C., & Campbell, D. C. (1985). *Strong Vocational Interest Blank. Revised edition of Form T325, Strong-Campbell Interest Inventory*. Stanford, CA: Stanford University. (Distributed by Consulting Psychologists Press)
- Sturges, J. W. (1998). Practical use of technology in professional practice. *Professional Psychology: Research and Practice*, 29, 183-188.
- Subich, L. M. (1996). Addressing diversity in the process of career assessment. In M. L. Savickas & W. B. Walsh (eds.), *Handbook of career counseling: Theory and practice* (pp. 277-289). Palo Alto, CA: Davies-Black.
- Suczek, R. F., & Klopfer, W. G. (1952). Interpretation of the Bender-Gestalt Test: The associative value of the figures. *American Journal of Orthopsychiatry*, 22, 62-75.
- Sue, D. W., & Sue, D. (2003). *Counseling the culturally diverse: Theory and practice* (4th ed.). New York: Wiley.
- Sugarman, A. (1991). Where's the beef? Putting personality back into personality assessment. *Journal of Personality Assessment*, 56, 130-144.
- Suinn, R. M., Rickard-Figueroa, K., Lew, S., & Vigil, S. (1987). The Suinn-Lew Asian Self-Identity Acculturation Scale: An initial report. *Educational and Psychological Measurement*, 47, 401-407.
- Sullivan, H. S. (1953). *The interpersonal theory of psychiatry*. New York: Norton.
- Sullivan, P. M. (1982). Administration modifications on the WISC-R Performance Scale with different categories of deaf children. *American Annals of the Deaf*, 127, 780-788.
- Sullivan, P. M., & Brookhouser, P. E. (eds.). (1996). *Proceedings of the Fourth Annual Conference on the Habilitation and Rehabilitation of Hearing Impaired Adolescents*. Boys Town, NE: Boys Town.
- Sullivan, P. M., & Burley, S. K. (1990). Mental testing of the deaf child. En C. Reynolds & R. Kamphaus (eds.), *Handbook of psychological and educational assessment of children* (pp. 761-788). New York: Guilford.
- Sullivan, P. M., & Montoya, L. A. (1997). Factor analysis of the WISC-III with deaf and hard-of-hearing children. *Psychological Assessment*, 9, 317-321.
- Sullivan, P. M., & Schulte, L. E. (1992). Factor analysis of WISC-R with deaf and hard-of-hearing children. *Psychological Assessment*, 4, 537-540.
- Sundberg, N. D. (1955). The acceptability of "fake" versus "bona fide" personality test interpretations. *Journal of Abnormal and Social Psychology*, 50, 145-147.
- Sundberg, N. D., & Gonzales, L. R. (1981). Cross-cultural and cross-ethnic assessment: Overview and issues. En P. McReynolds (ed.), *Advances in psychological assessment* (Vol. 5, pp. 460-541). San Francisco: Jossey-Bass.
- Sundberg, N. D., & Tyler, L. E. (1962). *Clinical psychology*. New York: Appleton-Century-Crofts.
- Super, C. M. (1983). Cultural variation in the meaning and uses of children's "intelligence." En J. B. Deregowski, S. Dziurawiec, & R. C. Annis (eds.), *Explorations in cross-cultural psychology*. Lisse, Netherlands: Swets & Zeitlinger.
- Sutton v. United Airlines. 527 U.S. 471, 119 S. Ct. 213 (1999).
- Sutton-Simon, K., & Goldfried, M. R. (1979). Faulty thinking patterns in two types of anxiety. *Cognitive Therapy and Research*, 3, 193-203.
- Suzuki, L. A., Ponterotto, J. G., & Meller, P. J. (eds.). (2000). *Handbook of multicultural assessment* (2nd ed.). San Francisco: Jossey-Bass.
- Swallow, R. (1981). Fifty assessment instruments commonly used with blind and partially seeing individuals. *Journal of Visual Impairment and Blindness*, 75, 65-72.
- Swanson, J. L. (1992). The structure of vocational interests for African-American college students. *Journal of Vocational Behavior*, 40, 144-157.
- Sweet, J. J., Moberg, P. J., & Tovian, S. M. (1990). Evaluation of Wechsler Adult Intelligence Scale—Revised premorbid IQ formulas in clinical populations. *Psychological Assessment*, 2, 41-44.
- Swensen, C. H. (1968). Empirical evaluations of human figure drawings: 1957-1966. *Psychological Bulletin*, 70, 20-44.
- Swerdlik, M. E. (1985). Review of Brigance Diagnostic Comprehensive Inventory of Basic Skills. En J. V. Mitchell, Jr. (ed.), *The ninth mental measurements yearbook* (pp. 214-215). Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Swerdlik, M. E. (1992). Review of the Otis-Lennon School Ability Test. En J. J. Kramer & J. C. Conoley (eds.), *The eleventh mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Swerdlik, M. E., & Dornback, F. (1988, April). *An interpretation guide to the fourth edition of the Stanford-Binet Intelligence Scale*. Paper presented at the annual meeting of the National Association of School Psychologists, Chicago.
- Swift, J. W. (1944). Reliability of Rorschach scoring categories with pre-school children. *Child Development*, 15, 207-216.
- Sylvester, R. H. (1913). Clinical psychology adversely criticized. *Psychological Clinic*, 7, 182-188.
- Symonds, P. M. (1949). *Adolescent fantasy: An investigation of the picture-story method of personality study*. New York: Columbia University.
- Takeuchi, J., Solomon, F., & Menninger, W. W. (eds.). (1981). *Behavioral science and the Secret Service: Toward the prevention of assassination*. Washington, DC: National Academy.
- Tallent, N. (1958). On individualizing the psychologist's clinical evaluation. *Journal of Clinical Psychology*, 114, 243-244.
- Tamkin, A. S., & Kuncze, J. T. (1985). A comparison of three neuropsychological tests: The Weigl, Hooper and Benton. *Journal of Clinical Psychology*, 41, 660-664.
- Tan, U. (1993). Normal distribution of hand preference and its bimodality. *International Journal of Neuroscience*, 68, 61-65.
- Taormina, R. J., & Bauer, T. N. (2000). Organizational socialization in two cultures: Results from the United States and Hong Kong. *International Journal of Organizational Analysis*, 8, 262-289.
- Tate, D. G., & Pledger, C. (2003). An integrative conceptual framework of disability: New directions for research. *American Psychologist*, 58, 289-295.
- Taylor, D. M. (2002). *The quest for identity: From minority groups to Generation Xers*. Westport, CT: Praeger.
- Taylor, H. C., & Russell, J. T. (1939). The relationship of validity coefficients to the practical effectiveness of tests in selection. *Journal of Applied Psychology*, 23, 565-578.
- Taylor, L. B. (1979). Psychological assessment of neurosurgical patients. En T. Rasmussen & R. Marino (eds.), *Functional neurosurgery*. New York: Raven.
- Taylor, R. L. (1980). Use of the AAMD classification system: A review of recent research. *American Journal of Mental Deficiency*, 85, 116-119.
- Teague, W. (State Superintendent of Education). (1983). *Basic competency education: Reading, language, mathematics specifications for the Alabama High School Graduation Examination* (Bulletin No. 4). Montgomery: Alabama State Department of Education.
- Tein, J.-Y., Sandler, I. N., & Zautra, A. J. (2000). Stressful life events, psychological distress, coping, and parenting of divorced

- mothers: A longitudinal study. *Journal of Family Psychology*, 14, 27-41.
- Tellegen, A. (1985). Structures of mood and personality and their relevance to assessing anxiety with an emphasis on self-report. En A. H. Tuma & J. D. Master (eds.), *Anxiety and the anxiety disorders* (pp. 681-706). Hillsdale, NJ: Erlbaum.
- Tellegen, A., & Ben-Porath, Y. S. (1992). The new uniform T scores for the MMPI-2: Rationale, derivation, and appraisal. *Psychological Assessment*, 4, 145-155.
- Tenopir, M. L. (1999). A scientist-practitioner's viewpoint on the admissibility of behavioral and social scientific information. *Psychology, Public Policy, and Law*, 5, 194-202.
- Teplin, S. W., et al. (1991). Neurodevelopmental health, and growth status at age 6 years of children with birth weights less than 1001 grams. *Journal of Pediatrics*, 118, 768-777.
- Terman, L. M., et al. (1925). *The mental and physical traits of a thousand gifted children: Vol. 1. Genetic studies of genius*. Stanford, CA: Stanford University.
- Terman, L. M., & Miles, C. C. (1936). *Sex and personality: Studies in masculinity and femininity*. New York: McGraw-Hill.
- Tharinger, D. J., & Stark, K. (1990). A qualitative versus quantitative approach to evaluating the Draw-A-Person and Kinetic Family Drawing: A study of mood- and anxiety-disorder children. *Psychological Assessment*, 2, 365-375.
- Thomas, A. D., & Dudgeon, S. Z. (1985). Interpersonal affect in Thematic Apperception Test responses: A scoring system. *Journal of Personality Assessment*, 49, 30-36.
- Thompson, A. E. (1986). An object relational theory of affect maturity: Applications to the Thematic Apperception Test. En M. Kissen (ed.), *Assessing object relations phenomena* (pp. 207-224). Madison, CT: International Universities.
- Thompson, C. (1949). The Thompson modification of the Thematic Apperception Test. *Journal of Projective Techniques*, 13, 469-478.
- Thompson, J. K., & Smolak, L. (eds.). (2001). *Body image, eating disorders, and obesity in youth: Assessment, prevention, and treatment*. Washington, DC: APA Books.
- Thompson, J. K. & Thompson, C. M. (1986). Body size distortion and self-esteem in asymptomatic, normal weight males and females. *International Journal of Eating Disorders*, 5, 1061-1068.
- Thompson, J. M., & Sones, R. (1973). *The Education Apperception Test*. Los Angeles: Western Psychological Services.
- Thompson, M. D., Scott, J. G., & Dickson, S. W. (1999). Clinical utility of the Trail Making Test practice time. *Clinical Neuropsychologist*, 13, 450-455.
- Thompson, R. J., Gustafson, K. E., Meghdadpour, S., & Harrell, E. S. (1992). The role of biomedical and psychosocial processes in the intellectual and academic functioning of children and adolescents with cystic fibrosis. *Journal of Clinical Psychology*, 48, 3-10.
- Thorndike, E. L., et al. (1921). Intelligence and its measurement: A symposium. *Journal of Educational Psychology*, 12, 123-147, 195-216.
- Thorndike, E. L., Bregman, E. O., Cobb, M. V., Woodward, E., & the staff of the Division of Psychology of the Institute of Educational Research of Teachers College, Columbia University. (1927). *The measurement of intelligence*. New York: Bureau of Publications, Teachers College, Columbia University.
- Thorndike, E. L., Lay, W., & Dean, P. R. (1909). The relation of accuracy in sensory discrimination to general intelligence. *American Journal of Psychology*, 20, 364-369.
- Thorndike, R. (1985). Reliability. *Journal of Counseling & Development*, 63, 528-530.
- Thorndike, R. L. (1971). Concepts of cultural fairness. *Journal of Educational Measurement*, 8, 63-70.
- Thorndike, R. L., Hagan, E. P., & Sattler, J. P. (1986). *Technical manual for the Stanford-Binet Intelligence Scale, Fourth Edition*. Chicago: Riverside.
- Thornton, G. C., & Byham, W. C. (1982). *Assessment centers and managerial performance*. New York: Academic Press.
- Thurlow, M. L., House, A. L., Scott, D. L., & Ysseldyke, J. E. (2000). Students with disabilities in large-scale assessments: State participation and accommodation policies. *Journal of Special Education*, 34, 154-163.
- Thurstone, L. L. (1925). A method of scaling psychological and educational tests. *Journal of Educational Psychology*, 16, 433-451.
- Thurstone, L. L. (1927). A law of comparative judgment. *Psychological Review*, 34, 273-286.
- Thurstone, L. L. (1929). Theory of attitude measurement. *Psychological Bulletin*, 36, 222-241.
- Thurstone, L. L. (1931). *Multiple-factor analysis*. Chicago: University of Chicago Press.
- Thurstone, L. L. (1935). *The vectors of mind*. Chicago: University of Chicago Press.
- Thurstone, L. L. (1938). Primary mental abilities. *Psychometric Monographs*, No. 1. Chicago: University of Chicago Press.
- Thurstone, L. L. (1947). *Multiple factor analysis*. Chicago: University of Chicago.
- Thurstone, L. L. (1959). *The measurement of values*. Chicago: University of Chicago.
- Thurstone, L. L., & Chave, E. J. (1929). *The measurement of attitude*. Chicago: University of Chicago.
- Tillman, M. H. (1973). Intelligence scale for the blind: A review with implications for research. *Journal of School Psychology*, 11, 80-87.
- Timbrook, R. E., & Graham, J. R. (1994). Ethnic differences on the MMPI-2? *Psychological Assessment*, 6, 212-217.
- Tinsley, H. E. A., & Weiss, D. J. (1975). Interrater reliability and agreement of subjective judgments. *Journal of Counseling Psychology*, 22, 358-376.
- Tittle, C. R., & Hill, R. J. (1967). Attitude measurement and prediction of behavior: An evaluation of conditions and measurement techniques. *Sociometry*, 30, 199-213.
- Torrance, E. P. (1966). *Torrance Tests of Creative Thinking*. Bensenville, IL: Scholastic Testing Service.
- Torrance, E. P. (1987a). *Guidelines for administration and scoring/ Comments on using the Torrance Tests of Creative Thinking*. Bensenville, IL: Scholastic Testing Service.
- Torrance, E. P. (1987b). *Survey of the uses of the Torrance Tests of Creative Thinking*. Bensenville, IL: Scholastic Testing Service.
- Touliatos, J., Perlmutter, B. F., & Strauss, M. A. (1991). *Handbook of family measurements*. Newbury Park, CA: Sage.
- Tramontana, M. G., & Boyd, T. A. (1986). Psychometric screening of neuropsychological abnormality in older children. *International Journal of Clinical Neuropsychology*, 8, 53-59.
- Trautscholdt, M. (1883). Experimentelle untersuchungen uber die association der vorstellungen. *Philosophische Studien*, 1, 213-250.
- Trice, H. M., & Beyer, J. M. (1984). Studying organizational cultures through rites and ceremonies. *Academy of Management Review*, 9, 653-669.
- Trimble, M. R. (ed.). (1986). *New brain imaging techniques and psychopharmacology*. Oxford: Oxford University.
- Truant, G. S., O'Reilly, R., & Donaldson, L. (1991). How psychiatrists weigh risk factors when assessing suicide risk. *Suicide and Life-Threatening Behavior*, 21, 106-114.

- Tryon, R. C. (1957). Reliability and behavior domain validity: Reformulation and historical critique. *Psychological Bulletin*, 54, 229-249.
- Tuerlinckx, F., De Boeck, P., & Lens, W. (2002). Measuring needs with the Thematic Apperception Test: A psychometric study. *Journal of Personality and Social Psychology*, 82, 448-461.
- Tugg v. Towe (1994, July 19). *National Disability Law Reporter*, 5, 999-1005.
- Tulchin, S. H. (1939). The clinical training of psychologists and allied specialists. *Journal of Consulting Psychology*, 3, 105-112.
- Tulsky, D., Zhu, J., & Ledbetter, M. F. (Project directors). (1997). *WAIS-III, WMS-III Technical manual*. San Antonio, TX: Psychological Corporation.
- Tulsky, D. S., & Ledbetter, M. F. (2000). Updating to the WAIS-III and WMS-III: Considerations for research and clinical practice. *Psychological Assessment*, 12, 253-262.
- Tuttle, F. B., & Becker, A. (1980). *Characteristics and identification of gifted and talented students*. Washington, DC: National Education Association.
- Tybout, A. M., & Artz, N. (1994). Consumer psychology. *Annual Review of Psychology*, 45, 131-169.
- Tyler, L. E. (1961). Research explorations in the realm of choice. *Journal of Counseling Psychology*, 8, 195-202.
- Tyler, L. E. (1965). *The psychology of human differences* (3rd ed.). New York: Appleton-Century-Crofts.
- Tyler, R. S. (1993). Cochlear implants and the deaf culture. *American Journal of Audiology*, 2, 26-32.
- Tyler, R. W. (1978). *The Florida accountability program: An evaluation of its educational soundness and implementation*. Washington, DC: National Education Association.
- Tziner, A., & Eden, D. (1985). Effects of crew composition on crew performance: Does the whole equal the sum of its parts? *Journal of Applied Psychology*, 70, 85-93.
- Udry, J. R. (1981). Marital alternatives and marital disruption. *Journal of Marriage and the Family*, 43, 889-897.
- Ulrich, R. E., Stachnik, T. J., & Stainton, N. R. (1963). Student acceptance of generalized personality interpretations. *Psychological Reports*, 13, 831-834.
- University of Minnesota. (1984). *User's guide for the Minnesota Report: Personal Selection System*. Minneapolis: National Computer Systems.
- U.S. Department of Education, Office of Special Education and Rehabilitative Services, National Institute on Disability and Rehabilitation Research. (2000). *Long range plan: 1999-2003*. Washington, DC: Author.
- Utley, C. A., Lowitzer, A. C., & Baumeister, A. A. (1987). A comparison of the AAMD's definition, eligibility criteria, and classification schemes with state departments of education guidelines. *Education and Training in Mental Retardation*, 22(1), 35-43.
- Vacha-Haase, T., & Thompson, B. (2002). Alternative ways of measuring counselees' Jungian psychological-type preferences. *Journal of Counseling & Development*, 80, 173-179.
- Vagg, P. R., & Spielberger, C. D. (1998). Occupational stress: Measuring job pressure and organizational support in the workplace. *Journal of Occupational Health Psychology*, 3, 294-305.
- Vale, C. D., & Keller, L. S. (1987). Developing expert computer systems to interpret psychological tests. En J. N. Butcher (ed.), *Computerized psychological assessment: A practitioner's guide* (pp. 64-83). New York: Basic.
- Vale, C. D., Keller, L. S., & Bentz, V. J. (1986). Development and validation of a computerized interpretation system for personnel tests. *Personnel Psychology*, 39, 525-542.
- Vallerand, R. J., Blanchard, C., Mageau, G. A., et al. (2003). Les passions de l'âme: On obsessive and harmonious passion. *Journal of Personality and Social Psychology*, 85, 756-767.
- Vander Kolk, C. J. (1977). Intelligence testing for visually impaired persons. *Journal of Visual Impairment & Blindness*, 71, 158-163.
- Van der Merwe, A. B., & Theron, P. A. (1947). A new method of measuring emotional stability. *Journal of General Psychology*, 37, 109-124.
- Vanderwood, M. L., McGrew, K. S., Flanagan, D. P., & Keith, T. Z. (2001). The contribution of general and specific cognitive abilities to reading achievement. *Learning and Individual Differences*, 13, 159-188.
- van Praag, H. M., Plutchik, R., & Apter, A. (eds.). (1990). *Violence and suicidality: Perspectives in clinical and psychobiological research* (pp. 37-65). New York: Brunner/Mazel.
- Varon, E. J. (1936). Alfred Binet's concept of intelligence. *Psychological Review*, 43, 32-49.
- Veiga, J., Lubatkin, M., Calori, R., & Very, P. (2000). Measuring organizational culture clashes: A two-nation post-hoc analysis of a cultural compatibility index. *Human Relations*, 53, 539-557.
- Velasquez, R. J., Gonzales, M., Butcher, J. N., et al. (1997). Use of the MMPI-2 with Chicanos: Strategies for counselors. *Journal of Multicultural Counseling and Development*, 25, 107-120.
- Velden, M. (1997). The heritability of intelligence: Neither known nor unknown. *American Psychologist*, 52, 72-73.
- Verhovek, S. H., & Ayres, B. D., Jr. (1998, November 4). The 1998 elections: The nation—referendums. *New York Times*, p. B2.
- Vernon, M. (1989). Assessment of persons with hearing disabilities. In T. Hunt & C. J. Lindley (eds.), *Testing older adults: A reference guide for geropsychological assessments* (pp. 150-162). Austin, TX: PRO-ED.
- Vernon, M., & Andrews, J. E., Jr. (1990). *Psychology of deafness: Understanding deaf and hard-of-hearing people*. New York: Longman.
- Vernon, M., Blair, R., & Lotz, S. (1979). Psychological evaluation and testing of children who are deaf-blind. *School Psychology Digest*, 8, 291-295.
- Vernon, M., & Brown, D. W. (1964). A guide to psychological tests and testing procedures in the evaluation of deaf and hard-of-hearing children. *Journal of Speech and Hearing Disorders*, 29, 414-423.
- Vernon, P. A. (1993). *Biological approaches to the study of human intelligence*. Norwood, NJ: Ablex.
- Vernon, P. E. (1950). *The structure of human abilities*. New York: Wiley.
- Vernon, P. E. (1964). *Personality assessment: A critical survey*. New York: Wiley.
- Vevea, J. L., Clements, N. C., & Hedges, L. V. (1993). Assess the effects of selection bias on validity data for the General Aptitude Test Battery. *Journal of Applied Psychology*, 78, 981-987.
- Vig, S., & Jedrysek, E. (1996). Application of the 1992 AAMR definition: Issues for preschool children. *Mental Retardation*, 34, 244-246.
- Viglione, D. J. (1999). A review of recent research addressing the utility of the Rorschach. *Psychological Assessment*, 11, 251-265.
- Vingoe, F. J. (1995). Beliefs of British law and medical students compared to expert criterion group on forensic hypnosis. *Contemporary Hypnosis*, 12, 173-187.
- Visser, P. S., Krosnick, J. A., & Lavrakas, P. J. (2000). Survey research. En H. T. Reis & C. M. Judd (eds.), *Handbook of research methods in social and personality psychology* (pp. 223-252). New York: Cambridge University Press.
- Volkmar, F. R., Klin, A., Marans, W., & Cohen, D. J. (1996). The pervasive developmental disorders: Diagnosis and assessment. *Child & Adolescent Psychiatric Clinics of North America*, 5, 963-977.

- von Knorring, L., & Lindstrom, E. (1992). The Swedish version of the Positive and Negative Syndrome Scale (PANSS) for schizophrenia: Construct validity and interrater reliability. *Acta Psychiatrica Scandinavica*, 86, 463-468.
- von Wolff, C. (1732). *Psychologia empirica*.
- von Wolff, C. (1734). *Psychologia rationalis*.
- Vossekuil, B., & Fein, R. A. (1997). *Final report: Secret Service Exceptional Case Study Project*. Washington, DC: U.S. Secret Service, Intelligence Division.
- Vroom, V. H. (1964). *Work and motivation*. New York: Wiley.
- Vygotsky, L. S. (1978). *Mind in society: The development of higher psychological processes*. Cambridge, MA: Harvard University.
- Waddell, D. D. (1980). The Stanford-Binet: An evaluation of the technical data available since the 1972 restandardization. *Journal of School Psychology*, 18, 203-209.
- Waehtler, C. A. (1997). Drawing bridges between science and practice. *Journal of Personality Assessment*, 69, 482-487.
- Wagner, B. M. (1997). Family risk factors for child and adolescent suicidal behavior. *Psychological Bulletin*, 121, 246-298.
- Wagner, E. E. (1983). *The Hand Test*. Los Angeles: Western Psychological Services.
- Wainer, H. (1990). *Computerized adaptive testing: A primer*. Hillsdale, NJ: Erlbaum.
- Wakefield, J. C. (1992a). Disorder as harmful dysfunction: A conceptual critique of DSM-III-R's definition of mental disorder. *Psychological Review*, 99, 232-247.
- Wakefield, J. C. (1992b). The concept of mental disorder: On the boundary between biological facts and social values. *American Psychologist*, 47, 373-388.
- Wald, A. (1947). *Sequential analysis*. New York: Wiley.
- Wald, A. (1950). *Statistical decision function*. New York: Wiley.
- Waldman, D. A., & Avolio, B. J. (1989). Homogeneity of test validity. *Journal of Applied Psychology*, 74, 371-374.
- Walker, H. M. (1976). *Walker Problem Behavior Identification Checklist*. Los Angeles: Western Psychological Services.
- Walker, L. S., & Greene, J. W. (1991). The Functional Disability Inventory: Measuring a neglected dimension of child health status. *Journal of Pediatric Psychology*, 16, 39-58.
- Walkup, J. (2000). Disability, health care, and public policy. *Rehabilitation Psychology*, 45, 409-422.
- Wallace, I. F., Gravel, J. S., McCarton, C. M., & Ruben, R. J. (1988). Otitis media and language development at 1 year of age. *Journal of Speech and Hearing Disorders*, 53, 245-251.
- Waller, N. G., & Zavala, J. D. (1993). Evaluating the big five. *Psychological Inquiry*, 4, 131-135.
- Wallston, K. A., Wallston, B. S., & DeVellis, R. (1978). Development of the Multidimensional Health Locus of Control (MHLC) Scales. *Health Education Monographs*, 6, 160-170.
- Wantz, R. A. (1989). Review of the Parenting Stress Index. In J. C. Conoley & J. J. Kramer (eds.), *The tenth mental measurements yearbook*. Lincoln: Buros Institute of Mental Measurements, University of Nebraska.
- Ward, P. B., McConaghy, N., & Catts, S. V. (1991). Word association and measures of psychosis proneness in university students. *Personality and Individual Differences*, 12, 473-480.
- Waring, E. M., & Reddon, J. (1983). The measurement of intimacy in marriage: The Waring Questionnaire. *Journal of Clinical Psychology*, 39, 53-57.
- Warmke, D. L. (1984). *Successful implementation of the "new" GATB in entry-level selection*. Presentation at the American Society for Personnel Administrators Region 4 Conference, October 15, Norfolk, VA.
- Watkins, C. E., Jr. (1986). Validity and usefulness of WAIS-R, WISC-R, and WPPSI short forms. *Professional Psychology: Research and Practice*, 17, 36-43.
- Watkins, C. E., Jr., Campbell, V. L., Nieberding, R., & Hallmark, R. (1995). Contemporary practice of psychological assessment by clinical psychologists. *Professional Psychology: Research and Practice*, 26, 54-60.
- Watkins, E. O. (1976). *Watkins Bender-Gestalt Scoring System*. Novato, CA: Academic Therapy.
- Watson, C. G. (1967). Relationship of distortion to DAP diagnostic accuracy among psychologists at three levels of sophistication. *Journal of Consulting Psychology*, 31, 142-146.
- Watson, C. G., Felling, J., & Maceacherr, D. G. (1967). Objective draw-a-person scales: An attempted cross-validation. *Journal of Clinical Psychology*, 23, 382-386.
- Watson, C. G., Thomas, D., & Anderson, P. E. D. (1992). Do computer-administered Minnesota Multiphasic Personality Inventories underestimate booklet-based scores? *Journal of Clinical Psychology*, 48, 744-748.
- Weaver, C. B., & Bradley-Johnson, S. (1993). A national survey of school psychological services for deaf and hard-of-hearing students. *American Annals of the Deaf*, 138, 267-274.
- Webb, E. J., Campbell, D. T., Schwartz, R. D., & Sechrest, L. (1966). *Unobtrusive measures: Nonreactive research in the social sciences*. Chicago: Rand McNally.
- Webster, C. D., Harris, G. T., Rice, M. E., Cormier, C., & Quinsey, V. L. (1994). *The violence prediction scheme*. Ontario, Canada: University of Toronto Centre of Criminology.
- Wechsler, D. (1939). *The measurement of adult intelligence*. Baltimore: Williams & Wilkins.
- Wechsler, D. (1944). *The measurement of adult intelligence* (3rd ed.). Baltimore: Williams & Wilkins.
- Wechsler, D. (1955). *Manual for the Wechsler Adult Intelligence Scale*. New York: The Psychological Corporation.
- Wechsler, D. (1958). *The measurement and appraisal of adult intelligence* (4th ed.). Baltimore: Williams & Wilkins.
- Wechsler, D. (1967). *Manual for the Wechsler Preschool and Primary Scale of Intelligence*. New York: The Psychological Corporation.
- Wechsler, D. (1974). *Manual for the Wechsler Intelligence Scale for Children—Revised*. New York: The Psychological Corporation.
- Wechsler, D. (1975). Intelligence defined and undefined: A relativistic appraisal. *American Psychologist*, 30, 135-139.
- Wechsler, D. (1981). *Manual for the Wechsler Adult Intelligence Scale—Revised*. New York: The Psychological Corporation.
- Wechsler, D. (1991). *Manual for the Wechsler Intelligence Scale for Children—Third Edition*. San Antonio, TX: The Psychological Corporation.
- Wechsler, D. (1997). *Wechsler Adult Intelligence Scale—Third Edition*. San Antonio, TX: The Psychological Corporation.
- Wechsler, D. (2002). *Wechsler Preschool and Primary Scale of Intelligence—Third edition (WPPSI-III), Technical and interpretive manual*. San Antonio, TX: The Psychological Corporation.
- Wechsler, D. (2003). *Wechsler Intelligence Scale for Children—Fourth edition (WISC-IV), Technical and interpretive manual*. San Antonio, TX: The Psychological Corporation.
- Wecker, N. S., Kramer, J. H., Wisniewski, A., et al. (2000). Age effects on executive ability. *Neuropsychology*, 14, 409-414.
- Weed, N. C., Butcher, J. N., McKenna, T., & Ben-Porath, Y. S. (1992). New measures for assessing alcohol and drug abuse with the MMPI-2: The APS and AAS. *Journal of Personality Assessment*, 58, 389-404.
- Weiner, B. A. (1980). Not guilty by reason of insanity: A sane approach. *Chicago Kent Law Review*, 56, 1057-1085.

- Weiner, I. B. (1966). *Psychodiagnosis in schizophrenia*. New York: Wiley.
- Weiner, I. B. (1997). Current status of the Rorschach Inkblot Method. *Journal of Personality Assessment*, 68, 5-19.
- Weir, R. F. (1992). The morality of physician-assisted suicide. *Law, Medicine and Health Care*, 20, 116-126.
- Weiss, D. J. (1985). Adaptive testing by computer. *Journal of Consulting and Clinical Psychology*, 53, 774-789.
- Weiss, D. J., & Davison, M. L. (1981). Test theory and methods. *Annual Review of Psychology*, 32, 629-658.
- Weiss, D. J., & Vale, C. D. (1987). Computerized adaptive testing for measuring abilities and other psychological variables. En J. N. Butcher (ed.), *Computerized psychological assessment: A practitioner's guide* (pp. 325-343). New York: Basic.
- Weiss, D. S., Zilberg, N. J., & Genevro, J. L. (1989). Psychometric properties of Loevinger's Sentence Completion Test in an adult psychiatric outpatient sample. *Journal of Personality Assessment*, 53, 478-486.
- Weiss, H. M., & Cropanzano, R. (1996). Affective events theory: A theoretical discussion of the structure, causes, and consequences of affective experiences at work. *Research in Organizational Behavior*, 18, 1-74.
- Weiss, R., & Summers, K. (1983). Marital Interaction Coding System III. En E. Filsinger (ed.), *Marriage and family assessment: A sourcebook of family therapy*. Beverly Hills, CA: Sage.
- Weisse, D. E. (1990). Gifted adolescents and suicide. *School Counselor*, 37, 351-358.
- Weissman, H. N. (1991). Forensic psychological examination of the child witness in cases of alleged sexual abuse. *American Journal of Orthopsychiatry*, 6, 48-58.
- Welsh, G. S. (1948). An extension of Hathaway's MMPI profile coding system. *Journal of Consulting Psychology*, 12, 343-344.
- Welsh, G. S. (1956). Factor dimensions A and R. En G. S. Welsh & W. G. Dahlstrom (eds.), *Basic readings on the MMPI in psychology and medicine* (pp. 264-281). Minneapolis: University of Minnesota.
- Welsh, G. S., & Dahlstrom, W. G. (eds.). (1956). *Basic readings on the MMPI in psychology and medicine*. Minneapolis: University of Minnesota.
- Welsh, J. R., Kucinkas, S. K., & Curran, L. T. (1990). *Armed Services Vocational Aptitude Battery (ASVAB): Integrative review of validity studies* (Rpt 90-22). San Antonio, TX: Operational Technologies Corp.
- Werner, H., & Strauss, A. A. (1941). Pathology of figure-background relation in the child. *Journal of Abnormal and Social Psychology*, 36, 236-248.
- Wertheimer, M. (1923). Untersuchungen zur Lehre von der Gestalt. *Psychologische Forschung* [Studies in the theory of Gestalt Psychology. *Psychology for Schools*], 4, 301-303. Translated by Don Cantor in R. J. Herrnstein & E. G. Boring (1965), *A sourcebook in the history of psychology*. Cambridge, MA: Harvard University.
- Wesman, A. G. (1968). Intelligent testing. *American Psychologist*, 23, 267-274.
- West, L. J., & Ackerman, D. L. (1993). The drug-testing controversy. *Journal of Drug Issues*, 23, 579-595.
- Westen, D., Barends, A., Leigh, J., Mendel, M., & Silbert, D. (1988). *Manual for coding dimensions of object relations and social cognition from interview data*. Unpublished manuscript, University of Michigan, Ann Arbor.
- Westen, D., Silk, K. R., Lohr, N., & Kerber, K. (1985). *Object relations and social cognition: TAT scoring manual*. Unpublished manuscript, University of Michigan, Ann Arbor.
- Westling, D. L. (1996). What do parents of children with moderate and severe mental disabilities want? *Education and Training in Mental Retardation and Developmental Disabilities*, 31, 86-114.
- Wexley, K. N., Yukl, G. A., Kovacs, S. Z., & Sanders, R. E. (1972). Importance of contrast effects in employment interviews. *Journal of Applied Psychology*, 56, 45-48.
- White, B. L. (1971). *Human infants: Experience and psychological development*. Englewood Cliffs, NJ: Prentice-Hall.
- White, D. M., Clements, C. B., & Fowler, R. D. (1985). A comparison of computer administration with standard administration of the MMPI. *Computers in Human Behavior*, 1, 153-162.
- White, J. A., Davison, G. C., Haaga, D. A. F., & White, K. L. (1992). Cognitive bias in the articulated thoughts of depressed and nondepressed psychiatric patients. *Journal of Nervous and Mental Disease*, 180, 77-81.
- White, L. T. (1984). Attitudinal consequences of the preemployment polygraph examination. *Journal of Applied Social Psychology*, 14, 364-374.
- White, R. W., Sanford, R. N., Murray, H. A., & Bellak, L. (1941, September). *Morgan-Murray Thematic Apperception Test: Manual of directions* [mimeograph]. Cambridge, MA: Harvard Psychological Clinic.
- White, S., Santilli, G., & Quinn, K. (1988). Child evaluator's roles in child sexual abuse assessments. En E. B. Nicholson & J. Bulkley (eds.), *Sexual abuse allegations in custody and visitation cases: A resource book for judges and court personnel* (pp. 94-105). Washington, DC: American Bar Association.
- Whitworth, R. H. (1984). Review of Halstead-Reitan Neuropsychological Battery and allied procedures. En D. J. Keyser & R. C. Sweetland (eds.), *Test critiques* (Vol. 1, pp. 305-314). Kansas City, MO: Test Corporation of America.
- Whitworth, R. H., & Unterbrink, C. (1994). Comparison of MMPI-2 clinical and content scales administered to Hispanic and SAnglo-Americans. *Hispanic Journal of Behavioral Sciences*, 16, 255-264.
- Wicker, A. W. (1969). Attitudes versus actions: The relationship of verbal and overt behavioral responses to attitude objects. *Journal of Social Issues*, 25, 41-78.
- Wickes, T. A., Jr. (1956). Examiner influences in a testing situation. *Journal of Consulting Psychology*, 20, 23-26.
- Widiger, T. A., & Clark, L. A. (2000). Toward DSM-V and the classification of psychopathology. *Psychological Bulletin*, 126, 946-963.
- Wienstock, J., Whelan, J. P., & Meyers, A. W. (2004). Behavioral assessment of gambling: An application of the timeline followback method. *Psychological Assessment*, 16, 72-80.
- Wigdor, A. K., & Garner, W. R. (1982). *Ability testing: Uses, consequences, and controversies*. Washington, DC: National Academy.
- Wiggins, N. (1966). Individual viewpoints of social desirability. *Psychological Bulletin*, 66, 68-77.
- Wilcox, R., & Krasnoff, A. (1967). Influence of test-taking attitudes on personality inventory scores. *Journal of Consulting Psychology*, 31, 185-194.
- Wilkinson, G. S. (1993). *Wide Range Achievement Test-3*. Wilmington, DE: Wide Range, Inc.
- Williams, A. D. (2000). Fixed versus flexible batteries. En R. J. McCaffrey et al. (eds.), *The practice of forensic neuropsychology: Meeting challenges in the courtroom* (pp. 57-70). New York: Plenum.
- Williams, C. L. (1986). Mental health assessment of refugees. En C. L. Williams & J. Westermeyer (eds.), *Refugee mental health in resettlement countries* (pp. 175-188). New York: Hemisphere.

- Williams, J. M., & Shane, B. (1986). The Reitan-Indiana Aphasia Screening Test: Scoring and factor analysis. *Journal of Clinical Psychology, 42*, 156-160.
- Williams, R. (1975). The BITCH-100: A culture-specific test. *Journal of Afro-American Issues, 3*, 103-116.
- Williams, R. H., & Zimmerman, D. W. (1996a). Are simple gains obsolete? *Applied Psychological Measurement, 20*, 59-69.
- Williams, R. H., & Zimmerman, D. W. (1996b). Are simple gain scores obsolete? Commentary on the commentaries of Collins and Humphreys. *Applied Psychological Measurement, 20*, 295-297.
- Williams, S. K., Jr. (1978). The Vocational Card Sort: A tool for vocational exploration. *Vocational Guidance Quarterly, 26*, 237-243.
- Williams, T. O., Jr., & Eaves, R. C. (2001). Exploratory and confirmatory factor analysis of the Woodcock Reading Mastery Tests-Revised with special education students. *Psychology in the Schools, 38*, 561-567.
- Williams, T. Y., Boyd, J. C., Cascardi, M. A., & Poythress, N. (1996). Factor structure and convergent validity of the Aggression Questionnaire in an offender population. *Psychological Assessment, 8*, 398-403.
- Wilmer, H. A., & Husni, M. (1951, December). An auditory sound association technique. *Science, 114*, 621-622.
- Wilson, G. G., & Vitousek, K. M. (1999). Self-monitoring in the assessment of eating disorders. *Psychological Assessment, 11*, 480-489.
- Wilson, P. T., & Spitzer, R. L. (1969). A comparison of three current classification systems for mental retardation. *American Journal of Mental Deficiency, 74*, 428-435.
- Wilson, S. L., Thompson, J. A., & Wylie, G. (1982). Automated psychological testing for the severely physically handicapped. *International Journal of Man-Machine Studies, 17*, 291-296.
- Winner, E. (1996). *Gifted children: Myths and realities*. New York: Basic.
- Winner, E. (2000). The origins and ends of giftedness. *American Psychologist, 55*, 159-169.
- Winston, A. S. (1996). "As his name indicates": R. S. Woodworth's letters of reference and employment for Jewish psychologists in the 1930s. *Journal of the History of the Behavioral Sciences, 32*, 30-43.
- Winston, A. S. (1998). "The defects of his race": E. G. Boring and antisemitism in American psychology, 1923-1953. *History of Psychology, 1*, 27-51.
- Wirt, R. D., Lachar, D., Klinedinst, J. K., & Seat, P. D. (1984). *Multidimensional description of child personality: A manual for the Personality Inventory for Children*. (1984 revision by David Lachar.) Los Angeles: Western Psychological Services.
- Wish, J., McCombs, K. F., & Edmonson, B. (1980). *Socio-Sexual Knowledge & Attitudes Test*. Chicago: Stoelting.
- Witkin, H. A., & Berry, J. W. (1975). Psychological differentiation in cross-cultural perspective. *Journal of Cross-Cultural Psychology, 6*, 4-87.
- Witkin, H. A., Dyk, R. B., Faterson, H. F., Goodenough, D. R., & Karp, S. A. (1962). *Psychological differentiation*. New York: Wiley.
- Witkin, H. A., & Goodenough, D. R. (1977). Field dependence and interpersonal behavior. *Psychological Bulletin, 84*, 661-689.
- Witkin, H. A., & Goodenough, D. R. (1981). *Cognitive styles: Essence and origins* (Psychological Issues Monograph 51). New York: International Universities.
- Witkin, H. A., Lewis, H. B., Hertzman, M., Machover, K., Meissner, P. B., & Wapner, S. (1954). *Personality through perception: An experimental and clinical study*. New York: Harper.
- Witmer, L. (1907). Clinical psychology. *Psychological Clinic, 1*, 1-9.
- Witt, J. C., & Elliott, S. N. (1985). Acceptability of classroom management strategies. En T. R. Kratochwill (ed.), *Advances in school psychology, Vol. 4* (pp. 251-288). Hillsdale, NJ: Erlbaum.
- Witty, P. (1940). Some considerations in the education of gifted children. *Educational Administration and Supervision, 26*, 512-521.
- Wober, M. (1974). Towards an understanding of the Kiganda concept of intelligence. En J. W. Berry & P. R. Dasen (eds.), *Culture and cognition: Readings in cross-cultural psychology* (pp. 261-280). London: Methuen.
- Wolfner, G., Fause, D., & Dawes, R. M. (1993). The use of anatomically detailed dolls in sexual abuse evaluations: The state of the science. *Applied and Preventive Psychology, 2*, 1-11.
- Wolfram, W. A. (1971). Social dialects from a linguistic perspective: Assumptions, current research, and future directions. En R. Shuy (ed.), *Social dialects and interdisciplinary perspectives*. Washington, DC: Center for Applied Linguistics.
- Wolf-Schein, E. G. (1993). Assessing the "untestable" client: ADLO. *Developmental Disabilities Bulletin, 21*, 52-70.
- Wollersheim, J. P. (1974). The assessment of suicide potential via interview methods. *Psychotherapy, 11*, 222-225.
- Wong-Rieger, D., & Quintana, D. (1987). Comparative acculturation of Southeast Asians and Hispanic immigrants and sojourners. *Journal of Cross-Cultural Psychology, 18*, 145-162.
- Woodcock, R. W. (1990). Theoretical foundations of the WJ-R measures of cognitive ability. *Journal of Psychoeducational Assessment, 8*, 231-258.
- Woodcock, R. W. (1997). The Woodcock-Johnson Tests of Cognitive Ability—Revised. In D. P. Flanagan, J. L. Genshaft, & P. L. Harrison (eds.), *Contemporary intellectual assessment: Theories, tests, and issues* (pp. 230-246). New York: Guilford.
- Woodcock, R. W., & Mather, N. (1989). WJ-R Tests of Cognitive Ability—Standard and Supplemental Batteries: Examiner's manual. En R. W. Woodcock & M. B. Johnson, *Woodcock-Johnson Psychoeducational Battery—Revised*. Allen, TX: DLM Teaching Resources.
- Woodcock, R. W., & Mather, N. (1989, 1990). WJ-R Tests of Achievement: Examiner's manual. In R. W. Woodcock & M. B. Johnson, *Woodcock-Johnson Psychoeducational Battery—Revised*. Allen, TX: DLM Teaching Resources.
- Woodcock, R. W., McGrew, K. S., & Mather, N. (2000). *Woodcock-Johnson III*. Itasca, IL: Riverside Publishing.
- Woodward, J. (1972). Implications for sociolinguistics research among the deaf. *Sign Language Studies, 1*, 1-7.
- Woodworth, R. S. (1917). *Personal Data Sheet*. Chicago: Stoelting.
- Worchel, F. F., & Dupree, J. L. (1990). Projective story-telling techniques. En C. R. Reynolds & R. W. Kamphaus (eds.), *Handbook of psychological and educational assessment of children: Personality, behavior, & context* (pp. 70-88). New York: Guilford.
- World Health Organization. (2001). *International classification of functioning, disability, and health*. Geneva, Switzerland: Author.
- Worlock, P., et al. (1986). Patterns of fractures in accidental and non-accidental injury in children. *British Medical Journal, 293*, 100-103.
- Wright, B. D., & Stone, M. H. (1979). *Best test design: Rasch measurement*. Chicago: Mesa.
- Wylonis, L. (1999). Psychiatric disability, employment, and the Americans with Disabilities Act. *Psychiatric Clinics of North America, 22*, 147-158.
- Yao, E. L. (1979). The assimilation of contemporary Chinese immigrants. *Journal of Psychology, 101*, 107-113.
- Yarnitsky, D., Sprecher, E., Zaslansky, R., & Hemli, J. A. (1995). Heat pain thresholds: Normative data and repeatability. *Pain, 60*, 329-332.

- Yerkes, R. M. (ed.). (1921). *Psychological examining in the United States Army: Memoirs of the National Academy of Sciences* (Vol. 15). Washington, DC: Government Printing Office.
- Yin, P., & Fan, X. (2000). Assessing the reliability of Beck Depression Inventory scores: Reliability generalization across studies. *Educational and Psychological Measurement*, 60, 201-223.
- Young, K. S., Pistner, M., O'Mara, J., & Buchanan, J. (1999). Cyber disorders: The mental health concern for the new millennium. *CyberPsychology & Behavior*, 2, 475-479.
- Younger, J. B. (1991). A model of parenting stress. *Research on Nursing and Health*, 14, 197-204.
- Youngjohn, J. R., & Crook, T. H., III. (1993). Stability of everyday memory in age-associated memory impairment: A longitudinal study. *Neuropsychology*, 7, 406-416.
- Yussen, S. R., & Kane, P. T. (1980). *Children's conception of intelligence*. Madison report for the project on studies of instructional programming for the individual student, University of Wisconsin, Technical Report #546.
- Zedeck, S., & Cascio, W. F. (1984). Psychological issues in personnel decisions. *Annual Review of Psychology*, 35, 461-518.
- Zelig, M., & Beidleman, W. B. (1981). Investigative hypnosis: A word of caution. *International Journal of Clinical and Experimental Hypnosis*, 29, 401-412.
- Zhang, L.-M., Yu, L.-S., Wang, K.-N., et al. (1997). The psychophysiological assessment method for pilot's professional reliability. *Aviation, Space, & Environmental Medicine*, 68, 368-372.
- Zieziula, F. R. (ed.). (1982). *Assessment of hearing-impaired people*. Washington, DC: Gallaudet College.
- Zimmerman, I. L., & Woo-Sam, J. M. (1978). Intelligence testing today: Relevance to the school age child. En L. Oettinger (ed.), *Psychologists and the school age child with MBD/LD*. New York: Grune & Stratton.
- Zubin, J. (1939, November 20). Letter to B. F. Skinner. (B. F. Skinner Papers, Harvard University Archives, Cambridge, MA).
- Zubin, J., Eron, L. D., & Schumer, F. (1965). *An experimental approach to projective techniques*. New York: Wiley.
- Zucker, S. (1985). *MSCA/K-ABC with high risk pre-schoolers*. Paper presented at the Annual Meeting of the National Association of School Psychologists, Las Vegas.
- Zucker, S., & Copeland, E. P. (1987). *K-ABC/McCarthy Scale performance among three groups of "at-risk" pre-schoolers*. Paper presented at the Annual Meeting of the National Association of School Psychologists, Las Vegas.
- Zuckerman, M. (1979). Traits, states, situations, and uncertainty. *Journal of Behavioral Assessment*, 1, 43-54.
- Zuckerman, M. (1990). Some dubious premises in research and theory on racial differences. *American Psychologist*, 45, 1297-1303.
- Zumbo, B. D., & Taylor, S. V. (1993). The construct validity of the Extraversion subscales of the Myers-Briggs Type Indicator. *Canadian Journal of Behavioural Science*, 25, 590-604.
- Zuniga, M. E. (1988). Assessment issues with Chicanas: Practice implications. *Psychotherapy*, 25, 288-293.
- Zwahlen, H. T., Schnell, T., Liu, A., et al. (1998). Driver's visual search behaviour. En A. G. Gale et al. (eds.), *Vision in vehicles-VI* (pp. 3-40). Oxford, England: Elsevier.
- Zweigenhaft, R. L. (1984). *Who gets to the top? Executive suite discrimination in the eighties*. New York: American Jewish Committee Institute of Human Relations.
- Zytowski, D. G. (1996). Three decades of interest inventory results: A case study. *Career Development Quarterly*, 45, 141-148.

- Capítulo 1**—Página 7, figura 1-1: © Jason Childs/STL/Newsport. Página 9, figura 1-2: © AP/Wide World Photos. Página 11, figura 1-3: © 2001 Ronald Jay Cohen; todos los derechos reservados. Página 14, figura 1-4: Cortesía de Gary A. Mirka, Department of Industrial Engineering, North Carolina State University. Página 17, figura 1-5: Cortesía de National Archives. Página 19: PG-13 gráfico reimpreso con permiso de Motion Picture Association of America. Páginas 24-25, figura 1-6: (arriba izquierda) © Tom Stewart/CORBIS; (enmedio izquierda) © 2001 Ronald Jay Cohen; todos los derechos reservados; (abajo izquierda) © David Linton; (arriba derecha) © 1940 Meier Art Judgment Test, The University of Iowa, Iowa City, IA; abajo derecha, cortesía de Sammons Preston Rolyan. Página 27, figura 1-7: Cortesía de Buros Center for Testing.
- Capítulo 2**—Página 32, figura 2-1: © Maynard Williams/NGS Image Collection. Página 34, figura 2-2; izquierda, Archivos de History of American Psychology, The University of Akron; derecha, cortesía de Hudson Cattell. Página 39, figura 2-3: © Brown Brothers. Página 46, figura 2-4: © AP/Wide World Photos. Página 51: © Jason Reed/CORBIS. Página 55: © Bettmann/CORBIS.
- Capítulo 3**—Página 67, figura 3-1: Cortesía de Stoelting Co., Wood Dale, IL.
- Capítulo 4**—Página 93, figura 4-1: © AP/Wide World Photos. Página 116, figura 4-2: University College, London. Página 119, figura 4-3: Archivos de History of American Psychology, The University of Akron.
- Capítulo 5**—Página 143: Cortesía de Nancy Bayley. Página 147: © A. Ramey/PhotoEdit.
- Capítulo 6**—Página 161, tabla 6-1: From C. H. Lawshe, "A Quantitative Approach to Content Validity", *Personnel Psychology* (1975) 28, 563-575. Reimpreso con permiso de *Personnel Psychology*. Página 162: figura 6-1: (izquierda y derecha) © Bettmann/CORBIS. Página 168, figura 6-2, y Página 169, tabla 6-2: De *The Manual of Differential Aptitude Tests: Fifth Edition, Forms S y T*, copyright © 1973, 1974 by The Psychological Corporation, a Harcourt Assessment Company; reproducido con permiso. Todos los derechos reservados. "Differential Aptitude Tests" y "DAT" son marcas registradas de The Psychological Corporation, registradas en Estados Unidos y otras jurisdicciones. Página 169, figura 6-3: De *Test Service Bulletin*, "How Effective Are Your Tests?" The Psychological Corporation, San Antonio, TX. Reproducido con autorización del editor.
- Capítulo 7**—Página 194, figura 7-2: Cortesía de University of North Carolina in Chapel Hill, L. L. Thurstone Psychometric Laboratory. Páginas 207-209: De J. Millman y J. A. Arter, 1984, "Issues in Item Banking", *Journal of Educational Measurement*, 21, 315-330; copyright © 1984 por National Council on Measurement Education. Reimpreso con permiso. Página 214, figura 7-4: From Introduction to Measurement Theory, primera edición, por M. J. Allen y W. M. Yen, Brooks/Cole, 1979. Reimpreso con permiso de Brooks/Cole Publishing Company, Pacific Grove, CA. Página 215, figura 7-5: De *Introduction to Measurement Theory, Primera edición*, by M. J. Allen y W. M. Yen, Brooks/Cole, 1979. Página 218, figura 7-6: De *Measurement Theory for the Behavioral Sciences* por Edwin E. Ghiselli, John P. Campbell y Sheldon Zedeck. Copyright © 1981 por W. H. Freeman and Company. Usado con permiso.
- Capítulo 8**—Página 240, figura 8-2: © William Bachman/Photo Researchers. Página 243, figura 8-3: Reproducido con permiso del autor de Well, *Assessment and Management of Developmental Changes and Problems in Children*, segunda edición, C. V. Mosby, 1981. Página 247, figura 8-4: © The Granger Collection, Ltd. Página 249, figura 8-5: © Wally McNamee/CORBIS. Página 252: © E! Networks. Página 259: © 2001 Ronald Jay Cohen; todos los derechos reservados.
- Capítulo 9**—Páginas 266-267, tabla 9-1: Copyright © 2003 por The Riverside Publishing Company. Todos los derechos reservados. Reproducido de *Stanford-Binet Intelligence Scales*, quinta edición, Assessment Service Bulletin #1 by Kirk A. Becker. Ninguna parte de este trabajo puede ser reproducida o transmitida de ninguna forma o ninguna manera, electrónica o mecánica, incluyendo fotocopia o grabación o por ningún sistema de almacenamiento o recuperación de información sin el permiso apropiado o por escrito de The Riverside Publishing Company, a menos que tal copia sea expresamente permitida por las leyes federales de derecho de autor. Address inquiries to Contracts and Permissions Department, The Riverside Publishing Company, 425 Spring Lake Drive, Itasca, IL 60143-2079. Página 271, figura 9-1: © 2004 Ronald Jay Cohen. Foto de Angel G. Morales con un agradecimiento especial de Terence Ramnarine y "les zombies", Ricky Illemon y Ulrick Pierre. Página 277, figura 9-2: Simulated items similar to those in the Wechsler Adult Intelligence Scale: tercera edición. Copyright © 1997 por The Psychological Corporation, a Harcourt Assessment Company. Reproducido con permiso. Todos los derechos reservados. "Wechsler Adult Intelligence Scale" y "WAIS" son marcas registradas de The Psychological Corporation del *Catalog for Psychological Assessment and Intervention Products*, 1998. Copyright © 1998 por The Psychological Corporation, a Harcourt Assessment Company. Reproducido con permiso. Todos los derechos reservados. Página 281, figura 9-3: De *WISC-IV Technical Manual*, The Psychological Corporation, una Harcourt Assessment Company.
- Capítulo 10**—Página 302: © Annie Griffiths Belt/CORBIS. Página 304, figura 10-1: Cortesía de Mark E. Swerdlik. Página 323, tabla 10-3: Reimpreso con permiso de A. S. Kaufman, N. L. Kaufman, B. Z. Goldsmith, *Sequential or Simultaneous (K-SOS)*, 1984, con modificaciones. Circle Pines, MN: American Guidance Service.
- Capítulo 11**—Página 338, figura 11-1: © Jeff Diedrich. Página 349, figura 11-3: Cortesía de Sublogic Corporation, Champaign, IL. Página 367, figura 11-4: Cortesía del doctor James Butcher.
- Capítulo 12**—Página 379, figura 12-1: © Hans Huber Publishers, Bern. Página 385, figura 12-4: Cortesía de Harvard University News Office. Página 386, figura 12-5: Cortesía de Henry A. Murray. Página 395, figura 12-7: © Bettmann/CORBIS. Página 404, Tabla 12-5: De D. B. Hartmann, B. L. Roper, y D. C. Bradford, "Differences Between Behavioral and Traditional Approaches to Psychological Assessment", en *Journal of Behavioral Assessment*, 1979. Reimpreso con permiso. Páginas 408-409, texto y foto: Cortesía de Supervised Lifestyles Health, Inc. Página 415: © 2001 by Shirley Ebersson. Todos los derechos reservados. No puede reproducirse sin permiso. Página 416, figura 12-9: © Paul J. Sutton/Duomo/CORBIS.
- Capítulo 13**—Página 441: © Rick Wilkins/Reuters/TimePix/Getty Images. Página 442, tabla 13-2: De B. A. Bukatman, J. L. Foy, y E.

DeGrazia, "Georgetown Criteria for Competency to Stand Trial", *American Journal of Psychiatry*, 1971, 127:9, marzo. Copyright © 1971 The American Psychiatric Association. Reimpreso con permiso. Página 443, tabla 13-2: De P. D. Lipsitt, D. Lelos y A. L. McGarry, "Competency for Trial: A Screening Instrument", *American Journal of Psychiatry*, 1971, 128, 105-109. Copyright © 1971 Paul D. Lipsitt y David Lelos. Usado con permiso de los autores. Página 447, figura 13-1: (izquierda) tarjeta CAT-H reproducida con permiso del editor, CPS, Inc., Larchmont, NY; (derecha) Reproducido con permiso de Jason Arnoson, Inc.

Capítulo 14—Página 461, figura 14-1: Goldstein-Scheerer Tests of Abstract and Concrete Thinking. © 1945, renovado 1972 por The Psychological Corporation. Reproducido con permiso. Página 471, figura 14-2: © 2001 Ronald Jay Cohen; todos los derechos reservados. Página 472, figura 14-3: © Archive Photos/Getty News Service. Página 473, figura 14-4(b): "Field of Search" items from Warren y Ekert, *Frontal Granular Cortex and Behavior*, McGraw-Hill. Reimpreso con permiso de The McGraw-Hill Companies. Página 475, figura 14-5: Cortesía del doctor Peter Schilder. Página 477, figura 14-6: De "Use of the Visual Motor Gestalt Test in the Diagnosis of Learning Disabilities" por Lauretta Bender, 1970, *The Journal of Special Education*, 4(1), 29-39. Copyright © 1970 por PRO-ED, Inc. Reimpreso con

permiso. Página 481, figura 14-8: Cortesía de Stoelting Co., Wood Dale, IL. Páginas 486-487, figuras 1, 2 y 3: Cortesía de General Electric Medical Systems.

Capítulo 15—Página 491, tabla 15-1: De R. Olkin y C. Pledger, "Can Disability Studies and Psychology Join Hands?" de *American Psychologist*, vol. 58, núm. 4, abril 2003, página 301. Copyright © 2003 por American Psychological Association. Reimpreso con permiso. Página 516, figura 15-1: Cortesía de Stoelting Co., Wood Dale, IL.

Capítulo 16—Página 525, figura 16-2: Cortesía de Lafayette Instrument Co. Página 533, figura 16-3: Cortesía de Center for Applications of Psychological Type, Inc. Página 535, tabla 16-2: De Dennis R. Laker, "The Career Wheel", en *Journal of Employment Counseling*, junio 2002, página 71. Reimpreso con permiso de American Counseling Association y del autor. Página 540, figura 16-4: Cortesía del doctor Douglas Bray. Página 542, tabla 16-4, de D. W. Bray, *American Psychologist*, 1982, 37, 180-189, Tabla 2 página 184. Copyright © 1982 por American Psychological Association. Reimpreso con permiso. Página 548, figura 16-5, de J. E. Champagne, "Job Recruitment of the Unskilled", *Personnel Journal*, 48, 259-268. Copyright © 1968 ACA. Reimpreso con permiso. No se permite ninguna reproducción posterior sin el permiso escrito de American Counseling Association.

Índice onomástico

- Abel, G. G., 413
 Abeles, N., 55
 Abelson, R. P., 401
 Abidin, R. R., 101, 451
 Abrams, D. B., 437
 Abrams, S., 413
 Abramson, P. R., 515
 Achenbach, T. M., 343, 345, 510
 Ackerman, D. L., 544
 Ackerman, M. J., 100
 Ackerman, P. L., 254, 340, 540
 Acklin, M. W., 380, 382, 383
 Adams, K. M., 227
 Adams-Tucker, C., 449
 Addeo, R. R., 84
 Adelman, S. A., 84
 Administration on Aging, 21
 Ahern, E., 537
 Aikman, K. G., 291
 Airasian, P. W., 309
 Akamatsu, C. T., 518
 Alderfer, C., 549
 Alessandri, S. M., 144
 Alexander, R. A., 414
 Alexander, R. C., 449
 Allen, J., 425, 431
 Allen, M. J., 216, 220
 Allen, N. J., 303
 Allen, T. E., 508
 Allport, Gordon W., 92, 93, 336, 337, 353, 358, 372
 Alpher, V. S., 413
 Alterman, A. I., 437
 Amabile, T. M., 84, 550
 Aman, C. J., 471
 Ambrosini, P. J., 164
 American Association on Mental Retardation (AAMR), 513
 American Board of Forensic Odontology, 449
 American Educational Research Institute (AERA), 52, 175
 American Psychiatric Association, 151, 428
 American Psychological Association (APA), 16, 44, 57, 100, 127, 175, 226
 Ames, S. L., 437
 Amrine, M., 47
 Anderson, G., 518
 Anderson, W. P., 345
 Andrew, G., 389
 Andrews, J. E., Jr., 507
 Angoff, W. H., 109
 Arbisi, P. A., 369
 Arias, I., 132
 Armendariz, G. M., 410-411
 Armstrong, T., 533
 Arnau, R. C., 533
 Arnett, P. A., 471
 Arnold, D. S., 305
 Arnow, E., 380
 Arter, J. A., 209
 Arthur, W., Jr., 539
 Artz, N., 554
 Arvey, R. D., 534, 538
 Asch, Solomon, 125-126
 Association of Personnel Test Publishers (APTP), 532
 Atkin, C. K., 562
 Atkinson, J. W., 134
 Atkinson, R. C., 480
 Avolio, B. J., 528, 530
 Aycan, Z., 551
 Ayres, B. D., Jr., 545
 Ayres, R. R., 322
 Bailey, J. M., 383
 Baker, E. L., 330
 Baldwin, A. L., 255
 Baldwin, J. A., 371
 Ball, T. S., 395
 Baltes, B. B., 551
 Bank, A. L., 228
 Baños, J. H., 467
 Barak, A., 523
 Barden, R. C., 303, 503
 Bardis, P. D., 447
 Bardos, A. N., 290
 Barends, A., 389
 Barker, R., 337
 Barlev, A., 55
 Barnes, H. L., 447
 Barnett, R. C., 551
 Baron, J., 315
 Bartholomew, D., 180
 Bartok, J. A., 472
 Bartol, K. M., 533
 Barton, K. A., 409
 Bassett, S. S., 472
 Batchelor, E. S., Jr., 485
 Batson, D. C., 401
 Bauer, T. N., 552
 Baughman, E. E., 255
 Bauman, M. K., 505, 507
 Baumeister, A. A., 495
 Baumeister, R. F., 439
 Baumrind, D., 255
 Bavolek, S. J., 447
 Baxter, J. C., 538
 Baydoun, R. B., 530
 Bayley, Nancy, 143
 Beard, J. G., 536
 Beatty, R. W., 541
 Beavers, R., 447
 Beck, A. T., 164, 341, 435, 439
 Beck, S. J., 380
 Becker, A., 253
 Becker, H. A., 449
 Becker, K. A., 265, 267
 Beckham, J. C., 472
 Beebe, S. A., 101
 Begault, D. R., 553
 Beidleman, W. B., 425
 Beier, E. G., 447
 Beier, M. E., 340
 Bell, N. L., 285, 525
 Bell, Y. R., 371
 Bellack, A. S., 406, 412
 Bellak, L., 389, 447
 Bellak, S., 389, 447
 Benbow, C. P., 44
 Benda, B. B., 437
 Bender, Lauretta, 475
 Benedict, R. H., 284
 Benjamin, G. A. H., 446
 Bennett, F., 511
 Ben-Porath, Y. S., 354, 366
 Ben-Shakhar, G., 503
 Benton, A. L., 463
 Berg, C. A., 262
 Berk, R. A., 181
 Berkowitz, L., 303
 Bernardoni, L. C., 395
 Bernhardt, G. R., 330
 Bernstein, L., 401
 Berry, D. S., 415
 Berry, J. W., 345
 Berven, H. M., 504
 Besetsny, L. K., 295
 Beyer, J. M., 553
 Bienvenu, M. J., Sr., 447
 Bigler, E. D., 463n
 Billmire, M. G., 449
 Binet, Alfred, 35, 65, 235, 256, 318, 513
 Birch, H. G., 461-462
 Birney, R. C., 550
 Birren, J. E., 250
 Bizot, E. B., 523
 Black, B., 483
 Black, H. C., 156
 Black, M., 101
 Blalock, S. J., 517
 Blanck, P. D., 504
 Blanton, R. L., 413
 Blum, G. S., 348, 389
 Blum, M. L., 171
 Blumenthal, S. J., 439
 Blustein, D. L., 534
 Board of Professional Affairs, 449
 Boccaccini, M. T., 445
 Bock, R. D., 194
 Bolin, J. A., 250
 Bombadier, C., 496
 Bond, G. B., 219
 Bond, R., 126
 Bono, J. E., 531
 Boone, D. E., 284
 Booth, A., 447
 Borgen, F. H., 523
 Boring, Edwin G., 34, 234
 Borkenau, P., 415
 Bornstein, P. H., 409
 Bornstein, R. F., 158, 383
 Bove, C. F., 9
 Bowers, K., 425
 Boyd, T. A., 478
The Boys and Girls Book About Divorce (Gardner), 447
 Bozeman, D. P., 552
 Bracken, B. A., 322
 Braden, Jeffrey P., 508
 Bradford, D. C., 404
 Bradley, J. P., 341
 Bradley-Johnson, S., 507, 510
 Brady, N. C., 496
 Braginsky, B. M., 346
 Brandstaetter, V., 340
 Brannen, M. Y., 553
 Brannigan, G. G., 476, 477
 Branyon, B., 508
 Brassard, M., 449
 Brauer, B., 508
 Bray, D. W., 2, 541, 542
 Brewer, E. W., 551
 Brewer, S., 562
 Bricklin, B., 101
 Briggs, Katharine Cook, 339, 533
 Bringle, R., 447
 Brittain, H. L., 384
 Brodsky, S. L., 445
 Brody, D., 464
 Brody, N., 400
 Brodzinsky, D. M., 101
 Brogden, H. E., 171
 Brook, J. S., 437
 Brookhouser, P. E., 508
 Brotemarkle, R. A., 35
 Brotherson, M. J., 514
 Brown, C. E., 11
 Brown, D. C., 186
 Brown, D. W., 509
 Brown, R. D., 352

- Brown, R. T., 181, 183
 Brown, S. P., 551
 Browning, D. L., 393
 Bruininks, R. H., 534
 Brunner, N. A., 476
 Bryan, J., 55
 Bryant, S., 391
 Bucholz, K. K., 429
 Buck, J. N., 290, 397, 398
 Buckle, M. B., 383
 Buckner, F., 59
 Bucofsky, D., 332
 Bukatman, B. A., 442, 443
 Burgess, A. W., 450
 Burisch, M., 343, 360
 Burke, M. J., 529
 Burke, P. J., 358
 Burke, R. J., 551
 Burley, S. K., 508
 Burns, A., 84
 Burns, E., 500
 Burns, R. C., 398
 Burns, R. K., 546
 Buros, O. K., 36
 Burstein, A. G., 279
 Burwen, L. S., 337
 Bushard, P., 100
 Bushman, B. J., 19, 338
 Butcher, James N., 227, 366, 367, 455
 Butcher, J. N., 366
 Butters, N., 471
 Bux, D. A., 437
 Byham, W. C., 541
 Byrne, D., 335
 Byrnes, M. M., 471

 Cain, L. F., 513
 Calhoon, M. B., 500
 Callahan, J., 55
 Callero, P. L., 342
 Camara, W. J., 27, 532
 Camilli, G., 221
 Campbell, D. P., 12, 227
 Campbell, D. T., 179, 337
 Campos, L. P., 345
 Cannon-Bowers, J. A., 547
 Cantor, J., 19
 Caplan, L. J., 516
 Capraro, M. M., 533
 Capraro, R. M., 533
 Capretz, L. F., 533
 Care, E., 521
 Carey, J. C., 371
 Carey, N. B., 166
 Carey, W. B., 305
 Carlson, V., 449
 Carmichael, L., 246
 Carpenter, P. A., 480
 Carroll, J. B., 239, 241, 279-280
 Carroll, K. M., 437
 Carroll, M. N., 510
 Carskadon, T. G., 534
 Carter, B. L., 436

 Caruso, J. C., 140
 Carver, R. P., 261n
 Cascio, W. F., 529
 Caspi, A., 254, 415
 Cassell, R. N., 352
 Catalano, R., 439
 Cates, J. A., 509-510
 Cattell, H., 358
 Cattell, J. M., 391
 Cattell, P., 258, 305
 Cattell, Raymond B., 239, 268, 336, 353, 358, 359
 Caught, K., 552
 Cavanaugh, J. L., 444
 Ceci, S. J., 451
 Cerney, M. S., 381
 Chamberlain, K., 165
 Champagne, J. E., 547-549
 Chan, K.-Y., 295
 Chance, N. A., 371
 Chaney, E. F., 437
 Chantler, L., 450
 Chaplin, W. F., 92, 340
 Chapman, J., 401
 Chapman, J. C., 2
 Chapman, L., 401
 Chappin, S. R., 437
 Chartrand, J. M., 523
 Chase, J., 507
 Chave, E. J., 194, 556
 Chess, S., 254
 Cheung, F. M., 430
 Chinoy, E., 255
 Chira-Chavala, T., 553
 Cho, H., 557
 Christensen, A. L., 485
 Christensen, K. M., 518
 Church, A. T., 358
 Cicchetti, D., 449
 Clark, B., 253
 Clark, L. A., 422, 423
 Cleckley, H., 445
 Clements, C. B., 502
 Clippard, L. F., 551
 Cloninger, C. R., 84
 Coggins, M. H., 440, 441
 Cohen, B., 541
 Cohen, J., 278
 Cohen, L., 523
 Cohen, O., 518
 Cohen, Ronald J., 23, 37, 224, 229, 286, 359, 382, 434n, 439, 515, 534, 537, 550, 552, 554-555, 560, 561-562
 Cohen, S., 536
 Cole, 413
 Cole, S. T., 256
 Collins, J. K., 508
 Collins, L. M., 132
 Collins, M., 520
 Comer, D. R., 544
 Compton, D. M., 472
 Comrey, A. L., 180
 Condon, C. A., 227

 Cone, J. D., 406, 408-409
 Conte, J. M., 531
 Cooke, N. J., 547
 Cooley, E. J., 322
 Cooper, A., 386
 Copas, J. B., 439
 Cornell, D. G., 343
 Corwyn, R. F., 437
 Costa, Paul T., Jr., 347, 354, 358, 531, 532
 Court, J. H., 434n
 Coyne, J. C., 434n
 Cramer, P., 389
 Crèvecoeur, M. G. St. J. de, 309
 Cronbach, Lee J., 137, 139, 148-149, 166, 171, 250, 529
 Crook, T. H., III, 250
 Cropanzano, R., 534
 Crosby, F. J., 44
 Cross, T. L., 253
 Crowne, D. P., 179
 Crundall, D. E., 474
 Cuellar, I., 371
 Cundick, B. P., 255
 Cunningham, M. R., 415
 Cureton, E. E., 216
 Curtis, W. S., 511
 Cushman, P., 421

 Dahlstrom, L. E., 361
 Dahlstrom, W. B., 255
 Dahlstrom, W. G., 339, 361, 363
 Daigneault, S., 472
 Dana, R. H., 355, 425, 430, 431
 Dancer, L. S., 369
 Daneman, M., 480
 Danford, G. S., 500
 Daniels, K., 551
 Darwin, Charles, 32-33
 Das, J. P., 242, 286, 322
 Davids, A., 395
 Davidson, H., 380
 Davies, G. M., 451
 Davies, M., 239
 Davies, P. L., 84
 Davis, D. R., 255
 Davis, G. A., 253
 Davison, G. C., 224
 Dawes, R. M., 455
 Decker, A. R., 523-524
 Decker, J. T., 551
 Decker, S. L., 476, 477
 Delahunty, R. J., 530
 DeLaRosa, M., 437
 Delgado, G. L., 518
 Delk, M. T., Jr., 517
 DelVecchio, W. F., 337
 DeMulder, E. K., 352
 Dennis, M. G., 246
 Dennis, W., 246
 Department of Health, Education, and Welfare, 492
 DePaulo, B. M., 532
 Desrochers, M. N., 496, 514

 Detterman, D. K., 233, 261
 Devlin, B., 255
 Diamond, B. L., 425
 Dickson, C. R., 406-407
 Diebold, M. H., 511
 Dietz, P. E., 441
 Diller, L., 461-462
 Dion, K. K., 303
 Dipboye, R. L., 8
 Diven, K., 400
 Dixon, M., 9
 Doll, Edgar A., 285, 513, 514
 Dolnick, E., 517
 Donahue, E. M., 342
 Doty, R. L., 464
 Dougherty, T. M., 250
 Douglas, C., 385
 Draguns, J. G., 431
 Drasgow, F., 456
 Dreger, R. M., 255
 Drinkwater, M. J., 507
 Drotar, D., 144
 DuBois, P. H., 31
 Dubose, R. F., 511
 Ducharme, F., 561
 Duchek, J. M., 474
 Duclos, C. W., 437
 Dudycha, G. J., 337
 Dugdale, Richard, 247
 Duncker, K., 224
 Dunn, L. M., 497-498
 Dupree, J. L., 389
 Dwyer, C. A., 7
 Dykes, L., 449
 Dywan, J., 425
 Dziuba-Leatherman, J., 172

 Earles, J. A., 295
 Early, P. C., 551
 Eccles, J. S., 254
 Eden, D., 540
 Edwards, A. L., 350, 401
 Edwards, J., 447
 Edwards, L. A., 100
 Ehrenfurth, J. W., 463n
 Eichler, R. M., 383
 Eisenberg, N., 340
 Eisman, E. J., 421
 Elder, G. H., 303
 Eldredge, N., 518
 Elksnin, L. K., 523
 Elksnin, N., 523
 Ellerstein, N. S., 449
 Elliot, Colin, 182, 324, 326
 Elliot, H., 510
 Elliott, A. N., 450
 Elliott, E. C., 140
 Elliott, S. N., 500
 Elliott, T. R., 510
 Ellis, M. V., 534
 Endicott, J., 424
 Engum, E. S., 485
 Epstein, J. L., 332
 Epstein, N., 447

- Erdelyi, M. H., 400
 Eron, L. D., 391
 Escoto, C. A., 533
 Evans, J. D., 484
 Evans, M., 507
 Evers, W., 551
 Exner, John E., 380, 382, 383, 397
 Eyman, J. R., 439
 Eyman, S. K., 439
 Eysenck, H. J., 336, 358
- Faigman, D. L., 483
 Faller, K. C., 449
 Fan, X., 140
 Farr, J. H., 184
 Farrell, J. N., 531
 Farrenkopf, T., 55
 Faust, D., 485
 Faust, D. S., 438
 Fein, R. A., 441
 Feinstein, A. R., 496
 Felce, D., 515
 Feldman, L. B., 517
 Fenn, D. S., 56
 Ferguson, R. L., 113
 Field, T. M., 303
 Filsinger, E., 447
 Finitzo, T., 478
 Finkelhor, D., 172
 Finn, Stephen E., 4, 425
 Firestone, M., 59
 Fischer, Constance T., 4, 425
 Fischer, H., 449
 Fisher, R. P., 425
 Fiske, D. W., 179, 222
 Fitzgibbons, D. J., 401
 Flanagan, D. P., 241, 245
 Flanagan, J. C., 267, 546
 Floyd, F. J., 180, 536
 Floyd, R. G., 329
 Flynn, James R., 251, 254, 255
 Foerster, L. M., 257
 Folstein, M. F., 466
 Fontana, V. J., 449
 Fontanna, D., 534
 Foote, W. E., 504
 Forer, B. R., 454
 Forrest, D. W., 33
 Forsman, M., 551
 Forth, A. E., 445
 Foster, S. L., 410
 Fouad, N. A., 369, 522
 Fox, C. M., 219
 Franco, J. N., 371
 Frank, E., 340
 Frank, Lawrence K., 378-379, 400, 401-402
 Frank, M. G., 415
 Franklin, L. M., 467
 Frantz, D., 28
 Frederickson, B. L., 415
 Fredman, N., 416
 Freeman, S. T., 518
 French, D. J., 412
- French, J. L., 253
 Freud, Sigmund, 41
 Friedman, Meyer, 339
 Friedrich, W. N., 305, 449
 Friel-Patti, S., 478
 Frijda, N. H., 415
 Frodi, A., 303
 Frolik, L. A., 503
 Frumkin, R. M., 261
 Fuchs, L. S., 497
 Fuherer, M. J., 496
 Fullan, M., 513
 Fullard, W., 305
 Furnham, A., 532, 534
 Furse, D. H., 558
- Gaither, G. A., 341
 Gallagher, J. J., 253
 Gallagher, P., 515
 Gallo, J. J., 467
 Galton, Francis, 33, 234-235, 244, 391
 Gammon, J. A., 449
 Ganellen, R. J., 383
 Gann, M. K., 224
 Ganzini, L., 56
 Garb, H. N., 455, 456
 García, M., 371
 Gardner, F. L., 537
 Gardner, Howard, 239
 Gardner, R. A., 446, 447
 Gardner, W., 439
 Gareis, K. C., 551
 Garfield, S. L., 391
 Garrett, H. E., 36
 Gaugler, B. B., 541
 Gavin, W. J., 84
 Geer-Williams, C., 439
 Geiselman, R. E., 425
 Gerety, M. B., 512
 Gerry, M. H., 255
 Gersten, C. D., 403
 Gesell, Arnold, 246-247, 305
 Ghiselli, E. E., 185, 534
 Gibbins, S., 508, 509
 Gibertini, M., 540
 Gill, C. J., 491
 Gill, M. M., 392
 Girelli, S. A., 533
 Glaser, R., 113
 Glass, G. V., 81
 Glassbrenner, J., 347
 Glazer, W. M., 356
 Gleser, G. C., 166, 171
 Glosser, G., 471
 Gluck, M. R., 389
 Glueck, W. F., 538
 Gobetz, W. A., 476
 Goddard, Henry H., 38, 247, 265, 513
 Goel, V., 471
 Goffman, E., 337
 Gokhale, D. V., 65
 Gold, D. P., 250
- Gold, J. R., 383
 Goldberg, L. R., 357, 358
 Goldberg, T. E., 471
 Golden, C. J., 485
 Goldfried, M. R., 224, 380
 Golding, S. L., 337
 Goldman, B. A., 28
 Goldman, S. H., 523
 Goldsmith, B., 323
 Goldstein, Kurt, 335, 460
 Gollan, J. K., 446
 Gomez, R., 515
 Gonzales, L. R., 345
 Good, R. H., 322
 Goodenough, D. R., 24
 Goodglass, H., 471
 Goodman, G. S., 451
 Goodman-Delahunty, J., 501, 504
 Gopaul-McNicol, S., 41
 Gopher, D., 474
 Gorsuch, R. L., 180
 Gottfredson, L. S., 44, 49, 186, 188, 530
 Gottfried, A. W., 252, 255
 Gough, H. G., 352
 Gow, K., 561
 Grace, C., 518
 Grafman, J., 471
 Graham, J. R., 366, 369
 Graham, W. R., 261n
 Granger, C. V., 496
 Green, S. B., 139
 Greene, J. W., 496
 Greene, R. L., 345
 Greenfield, D. N., 557
 Greenlaw, P. S., 102
 Greenspan, S., 513
 Greenspoon, J., 400, 403, 424
 Gregoire, J., 52
 Gresham, F. M., 451, 513
 Gresham, G. E., 496
 Gridley, B. E., 144
 Griffith, L., 27
 Grisso, T., 101, 102
 Groden, M. A., 449
 Groenfeld, M., 506
 Grossman, I., 284
 Grove, W. M., 455-456, 503
 Gruchy, C. D. G., 415
 Guerrier, J. H., 474
 Guilford, J. P., 92, 238, 253, 297, 336, 337
 Guilford, P., 421
 Guilmette, T. J., 485
 Guion, R. M., 157
 Gupta, D., 252
 Guttman, L. A., 199
- Haaga, D. A., 224
 Hadaway, N., 330
 Haidt, J., 188
 Haier, R. J., 233
 Haith, M. M., 250
 Haley, K., 56
- Hall, C. S., 335-336
 Hall, J. A., 125
 Hall, S. S., 478
 Halle, J. W., 496
 Halleck, S. L., 434n
 Halpern, A. S., 496
 Halpern, D. F., 44, 184, 254
 Halpern, F., 397
 Halpert, L. H., 317
 Halstead, Ward C., 481, 482
 Hambleton, R. K., 146
 Hamera, E., 11
 Hammer, E. F., 396
 Hammitt, J. K., 560
 Han, K., 366
 Handler, L., 341, 382, 383, 398
 Haney, W., 45, 47, 309
 Hansen, J. C., 369
 Hansen, J. S., 415
 Hansen, N. D., 431
 Happell, B., 551
 Hare, Robert D., 445
 Harker, L., 415
 Harmon, L. W., 522
 Harris, D., 290
 Harris, G. T., 439, 445
 Harris, M. M., 532
 Harris, P. M., 429
 Harris, S., 507
 Harris, S. L., 514
 Harrison, P., 514
 Hart, B., 255
 Hart, S. D., 445
 Hartigan, J. A., 44, 530
 Hartmann, D. P., 404
 Hartmann, E., 24
 Hartshorne, H., 337
 Hartshorne, T., 16, 52
 Hartsoeker, 247
 Hartung, P. J., 534
 Harvey, R. J., 533
 Hassler, M., 252
 Hathaway, Starke R., 361, 362, 364
 Hauser, M. J., 515
 Hayes, S. C., 284
 Haynes, S. N., 406, 410, 411
 Hays, Pamela A., 430
 Hazeldine, P., 515
 Hazlett, R. L., 412
 Healy, B. J., 388
 Heaton, R. K., 485
 Hedges, C., 161
 Heggestad, E. D., 254
 Heilbrun, A. B., Jr., 352
 Heinrichs, R. W., 471
 Heinze, M. C., 101, 102
 Helfer, R. E., 449
 Helson, R., 415
 Henk, W. A., 330
 Henley, N. M., 415
 Henri, Victor, 35, 235
 Henry, E. M., 401
 Henry, J. D., 559

- Henry, William, 387
Henson, J. M., 220
Henson, R. K., 139
Heppner, M. J., 520, 535
Herlihy, B., 259
Hermann, C., 412
Hernández, B., 504
Hernández, P., 345
Herrnstein, R., 261
Hersen, M., 406
Herzberg, F., 551
Hetherington, E. M., 143
Heyman, R. E., 410
Hibbard, Stephen, 389, 399
Hicks, L. K., 561
Higgins, P. C., 507, 517
Hill, P. C., 23
Hill, R. J., 551
Hills, D. A., 352
Hiltonsmith, R. W., 508
Hines, A. M., 371
Hines, M., 254
Hinkle, J. S., 345
Hinshaw, S., 423
Hipócrates, 338
Hirsch, J., 250
Hishinuma, E. S., 278, 371
Hiskey, Marshall S., 508
Ho, M. K., 431
Hodapp, R. M., 513
Hofer, S. M., 239
Hoffman, B., 41
Hofstede, G., 534
Holahan, C., 251
Holden, G. W., 100
Holland, John L., 339, 523, 531
Holland, W. R., 255
Hollander, E. P., 337
Hollenbeck, J. R., 534
Hollingshead, A. B., 401
Holmstrom, R. W., 391
Holt, N. F., 383
Holt, Robert R., 93, 336, 455
Holtzman, W. H., 290, 382
Honts, C. R., 532
Honzik, M. P., 255
Hope, D. A., 411
Hopkins, K. D., 81
Horn, J. L., 239
Horner, M. S., 550
Horowitz, Ruth, 378n
Hostetler, A. J., 481
House, R. J., 534
Houston, D. R., 550
Houston, T. K., 557
Howard, D. A., 100
Howe Chief, E., 371
Hritcko, T., 322
Hsu, S.-H., 553
Hudson, W. W., 447
Huffcutt, A. I., 539
Hughes, C., 515
Hull, C. L., 2
Hulse, W. G., 398
Humphreys, L. G., 132
Humphries, L. L., 84
Humphries, T., 507, 517, 518
Hunsley, J., 383
Hunt, J. McV., 246
Hunt, K. N., 535
Hunter, John E., 44, 125, 174, 175, 186, 526, 528, 541, 545
Hunter, M., 256
Hunter, M. S., 84
Hunter, R., 526, 541
Hurlburt, R. T., 224
Hurst, N. H., 437
Husni, M., 395
Huston, T., 447
Hutt, M. L., 476
Iacono, W. G., 413
Iaffaldano, M. T., 551
Ilies, R., 531
Innocenti, M. S., 451
Institute for Juvenile Research, 36
Institute of Medicine, 440
Ironson, G. H., 221
Irvine, S. H., 345
Isen, A. M., 415
Ishihara, S., 474
Ivancevich, J. M., 414
Ivnik, R. J., 250, 277
Iwata, B. A., 402
Jackson, C. L., 340
Jackson, D. E., 454
Jackson, D. N., 346, 524
Jackson, D. W., 517
Jackson, J. F., 255
Jackson, J. L., 410
Jacobs, J., 253
Jacobs, R. R., 531
Jacobsen, M. E., 253
Jacob-Timm, S., 16, 52
Jagger, L., 523
Jagim, R. D., 58-59
James, L. R., 160, 529
Jan, J. E., 506
Janis, I. L., 10
Jankowski, K., 517
Janowsky, D. S., 533
Jay, M., 317
Jedrysek, E., 513
Jenkins, C. D., 339
Jennings, B., 55
Jensen, Arthur R., 47, 186, 221-222, 235, 257, 262, 383
Jensen, J. S., 102
Jobes, D. A., 439
Johansson, H. J., 551
Johnson, C. A., 430
Johnson, D. L., 430
Johnson, E. S., 500
Johnson, G. S., 509
Johnson, J. A., 358
Johnson, L. C., 556
Johnson, R. C., 248
Johnson, T. J., 557
Joiner, T. E., Jr., 371, 398
Jolles, J., 397
Jones, J. W., 532
Jones, L. V., 194
Jones, R. N., 467
Jones, S., 9
Judge, T. A., 531, 534
Jung, Carl, 339, 391-392
Juni, S., 369-370
Jurgensen, C., 146
Kagan, J., 389
Kahn, M., 463n
Kail, B. L., 437
Kaiser, H. F., 139
Kamin, L. J., 249
Kamiya, J., 412
Kamphaus, R. W., 291, 301
Kanaya, T., 254
Kane, P. T., 234
Kanfer, R., 540
Karlsen, S., 437
Karon, B. P., 456
Karp, S. A., 391
Katz, R. C., 197, 199
Kaufman, Alan S., 235, 242, 250, 272, 277, 278, 284, 286, 322, 323
Kaufman, Nadeen L., 242, 286, 322, 323
Kaufman, S. H., 398
Kavale, K. A., 125
Kaye, B. K., 557
Keating, C. F., 415
Kebbell, M. R., 425
Keefe, F. J., 517
Kehoe, J. F., 102
Keiser, R. E., 389
Keith, K. D., 515
Keith, T. Z., 242, 286, 322
Kelley, C., 534
Kelley, S. J., 449, 450
Kelley, T. L., 46, 216
Kellner, C. H., 487
Kelly, E. J., 339
Keltner, D., 415
Kempe, R. S., 449
Kempen, J. H., 506
Kendall, P. C., 224
Kennedy, M. H., 508
Kennedy, R. S., 540
Kent, N., 255
Kerlinger, F. N., 66-67
Kern, J. M., 412
Khan, S. B., 369
Kim, B. S. K., 371
King, D. A., 472
King, K. W., 401
King, M. A., 450
Kinslinger, H. J., 534
Kinston, W., 447
Kippax, S., 437
Kirmayer, L. J., 423
Klein, D. F., 423
Kleinman, A., 431
Kleinman, A. M., 430
Kleinman, J., 431
Kleinmuntz, B., 413
Kline, R. B., 343, 343n
Klinger, E., 224
Klonoff, E. A., 437
Klopfer, B., 58, 380
Klos, D., 521
Kluckhohn, F. R., 373
Klupfer, D. J., 439
Knapp, R. R., 41
Knoff, H. M., 397, 398
Knowles, E. S., 227
Knudtson, L. S., 301
Koff, E., 397n
Kolotkin, R. A., 412
Kongs, S. K., 471
Koppitz, E. M., 476
Korchin, S. J., 380
Korkman, M., 485
Korman, A. K., 43
Kraepelin, Emil, 35, 391
Kraimer, M. L., 532
Kranzler, G., 242
Kranzler, J. H., 65, 242
Krasnoff, A., 401
Krauss, D. A., 503
Krauss, M. W., 101
Kresel, J. J., 449
Krikorian, R., 472
Krohn, E. J., 250, 322
Kronholz, J., 49
Kropf, C. A., 507
Krug, S. E., 358
Kubiszyn, T. W., 27, 44, 421
Kuder, G. Frederic, 137, 138, 524
Kudoh, T., 415
Kuhlmann, F., 265
Kullback, S., 65
Kuncel, N. R., 125, 317
Kupfer, D. J., 423
Laabs, G. J., 113
Lachar, D., 343
LaCombe, J. A., 343n
LaFrance, M., 415
Lah, M. I., 394
Laker, D. R., 535
Lally, S. J., 439
Lam, C. S., 523
Lamb, M. E., 446
Lambert, E. W., 485
Lambert, N., 514
Lamp, R. E., 250, 322
Landrine, H., 437
Landy, F. J., 158, 184
Lane, J. C., 440, 507, 517
Lane, S., 322
Lang, P. J., 436
Langer, E. J., 401
Langlois, Judith, 302, 303

- Lanyon, R. I., 366
 Lapham, R. F., 509-510
 Larkin, J. E., 523
 LaRose, R., 557
 Larson, J. E., 341
 Larson, J. R., 556
 Larson, L. M., 520, 523
 Larvie, V., 483
 Larzelere, R., 447
 Latimer, E. J., 55
 Lattimore, R. R., 523
 Lau, B., 430
 Laurence, J. R., 425
 Lavrakas, P. J., 556
 Lawrence, J., 467
 Lawshe, C. H., 160
 Lazarus, Arnold, 561
 Lea, E., 561
 Leahy, A. M., 248
 Ledbetter, M. F., 227
 Lee, M., 56
 Lee, S. D., 401
 Lega, L. I., 371
 Lehtinen, L. E., 460
 Leigh, I. W., 508, 509, 517
 León-Carrión, J., 471
 Leong, F. T., 534
 LePine, J. A., 340
 Lerner, B., 309
 Lerner, P. M., 380
 Less, L. J., 536
 Lesser, G. S., 255
 Lessinger, L. H., 437
 Levack, N., 507
 Levesque, L. L., 557
 Levine, E., 374
 LeVine, P., 430
 Levitt, K., 346
 Levy, J. J., 253
 Levy-Shiff, R., 144
 Lewinsohn, P. M., 439
 Lewis, C., 139, 176
 Lewis-Fernández, R., 422
 Lezak, M. D., 421
 Li, H., 557
 Li, J., 31
 Libby, W., 384
 Lichtenberg, P. A., 515
 Lichtenberger, E. O., 272
 Lichtenstein, B., 561
 Lichtenstein, D., 358
 Lidz, C. S., 4
 Lidz, C. W., 165, 439
 Liebler, A., 415
 Lievens, F., 532
 Lighthouse Research Institute, 505
 Likert, R., 198, 556
 Lilienfeld, S. O., 399, 423
 Lillibridge, J. R., 531
 Lim, J., 366
 Limber, S., 172, 173
 Lin, T. Y., 430
 Lindell, M. K., 160
 Lindgren, B., 81
 Lindskog, C. O., 286
 Lindstrom, E., 84, 428
 Lindzey, G., 335-336
 Linehan, M. M., 439
 Lipsitt, P. D., 443
 Lipton, J. P., 503
 Little Soldier, D., 257
 Locke, E. A., 551
 Locke, H. J., 179, 447
 Loevinger, J., 393
 Loewenstein, D. A., 478
 Loftin, M., 506, 507
 Loftus, E. F., 451
 London, P., 434n
 Longabaugh, R., 431
 Lonner, W. J., 345
 López, S., 345
 López, Steven Regeser, 355, 370, 431, 434
 Lord, F. M., 149
 Lorr, M., 533
 Loubser, J., 513
 Lovejoy, F. H., 449
 Lovejoy, M. C., 100, 305
 Lowitzer, A. C., 495
 Lowman, J. C., 447
 Loyd, B. H., 451
 Luckasson, R., 513
 Lumley, V. A., 515
 Lung, R. J., 449
 Luria, Aleksandr R., 241, 242, 286, 322
 Lykken, D. T., 413
 Lyman, H. B., 276
 Lynn, R., 261
 Lyons, J. A., 127n
 MacAndrew, C., 436
 Machover, Karen, 397
 Macintosh, G., 532
 Mack, J. L., 472
 MacKinnon, D. W., 2
 MacLachlan, M., 515
 MacMillan, D. L., 495
 Madaus, G. F., 309
 Mael, F. A., 43
 Magnello, M. E., 33, 116
 Magrab, P. R., 3
 Majors, M. S., 520
 Malec, J. F., 250
 Malgady, R. G., 355
 Maller, S. J., 508
 Malone, P. S., 252
 Maloney, M. P., 2, 3
 Malphigi, 246
 Mannarino, A. P., 450
 Manz, C. C., 411
 Maraist, C. C., 358
 Maraun, M. D., 180
 Marchese, M. C., 417, 455
 Marek-Schroer, M. F., 330
 Marino, L., 423
 Mark, M. M., 503
 Markman, H., 407
 Marks, I., 456
 Marlowe, D., 179
 Marquette, B. W., 244
 Martens, M. P., 23
 Martin, D. C., 533
 Martin, H., 4
 Marx, E., 347
 Maslach, Christina, 550
 Masling, J., 401
 Masling, J. M., 417
 Maslow, Abraham, 549
 Massey, D. S., 556
 Mast, B. T., 515
 Masuda, M., 371
 Matarazzo, J. D., 245, 260, 438
 Matchett, W. F., 430
 Mathes, S., 388
 Mathieu, J. E., 552
 Matson, J. L., 513
 Matsumoto, D., 415
 Maurer, T. J., 414
 May, M. A., 337
 Mays, V. M., 560
 Mazur, A., 415
 Mazzocco, M. M. M., 471
 McArthur, C., 522
 McArthur, D. S., 389
 McBride, B. A., 101
 McCall, W. A., 87-88
 McCarley, N. G., 533
 McCaulley, M. H., 533, 534
 McClelland, D. C., 335, 549-550
 McCloskey, G. W., 322
 McClure-Butterfield, P., 446
 McConkey, K. M., 425
 McCool, J. P., 561
 McCoy, G. F., 510
 McCrady, B. S., 437
 McCrae, Robert R., 340, 347, 354, 355, 358, 370, 531, 532
 McCubbin, H., 447
 McCusker, P. J., 127
 McDaniel, M. A., 531
 McDermott, P. A., 437
 McDevitt, S. C., 305
 McDonald, R. P., 180
 McDowell, C., 382, 383
 McDowell, I., 496
 McElrath, K., 429
 McElwain, B. A., 347
 McEvoy, G. M., 541
 McGaghie, W. C., 318
 McGrath, R. E., 368
 McGrew, Kevin S., 241, 245
 McGue, M., 234, 255
 McGurk, F. J., 256
 McKenzie, R. C., 174
 McKinley, John Charnley, 361, 362, 364
 McLean, J. E., 322
 McLellan, A. T., 437
 McLemore, C. W., 434n
 McMillen, C., 561
 McNeish, T. J., 398
 McNemar, Q., 44
 McPartland, J. M., 332
 McReynolds, P., 35
 Mead, Margaret, 126
 Meadow, K. P., 510
 Mednick, S. A., 297
 Medvec, Victoria Husted, 7
 Meehl, Paul, 364, 454, 455
 Mehl, M. R., 407
 Meier, S. T., 179n
 Melchert, T. P., 59
 Melia, R. P., 491
 Mellenbergh, G. J., 221
 Mello, E. W., 425
 Melton, G., 445
 Melton, G. B., 172, 173
 Mendoza, R. H., 371
 Menninger, K. A., 335
 Mercer, J. R., 255
 Merrens, M. R., 454
 Mesquita, B., 415
 Messick, S., 158, 346
 Meyer, G. J., 383
 Meyers, J., 534
 Micceri, T., 84
 Michael, W. B., 139
 Midanik, L. T., 557
 Middleton, G., 475
 Miles, C. C., 362
 Miller, I. W., 428
 Miller, J. N., 471
 Miller, K. S., 255
 Miller, N. E., 412
 Millman, J., 209
 Millon, T., 435
 Mills, C. J., 534
 Milner, B., 481
 Milner, Joel S., 172, 173, 451
 Miltenberger, R. G., 515
 Minsky, S. K., 471
 Minton, H. L., 265
 Mirka, G. A., 14
 Mischel, W., 337, 402
 Misiaszek, J., 510
 Mitchell, D. F., 28
 Mitchell, J., 219
 Moffitt, T. E., 132, 262
 Monahan, J., 439
 Montague, M., 224
 Montgomery, G. T., 355
 Montoya, L. A., 508
 Moos, B. S., 305, 447
 Moos, R. H., 305, 447, 521
 Moreland, K. L., 380
 Moretti, R. J., 389
 Morgan, Christiana D., 384, 385
 Morgan, Wesley G., 385
 Mori, L. T., 410-411
 Morreau, L. E., 534
 Moses, S., 315
 Mosier, C. I., 222
 Moss, K., 503
 Motowidlo, S. J., 534

- Motta, R. W., 291, 398
Moul, M., 248
Moursund, J., 65
Muchinsky, P. M., 551
Mueller, C. G., 183
Mueller, J. H., 557
Mueller, U., 415
Mulaik, S. A., 180
Muldrow, T. W., 174
Mulvey, E. P., 165
Muma, J. R., 495
Murguia, A., 371
Murphy, G. E., 165
Murphy, K. R., 530
Murphy, L. L., 26
Murphy, Lois Barclay, 378n
Murphy-Berman, V., 166
Murray, C., 261
Murray, Henry A., 2, 384, 385, 387, 391n, 395, 541
Murry, W. D., 533
Murstein, B. I., 388, 400
Mussen, P. H., 389, 401
Myers, Isabel Briggs, 339, 533
Myers, K. D., 534
Myers, P. A., 449
Myerson, Abraham, 248
- Nagle, R. J., 285
Naglieri, Jack A., 242, 286, 290, 398
Nagyne Rez, I., 508
Nansel, T. R., 561
Nathan, J., 472
National Association of School Psychologists (NASP), 16, 52
National Council on Disability, 501
National Council on Measurement in Education (NCME), 175
Naylor, H. K., 389
Naylor, J. C., 170, 171
Neagoe, A. D., 18
Neale, E. L., 396
Near, J. P., 551
Neath, J., 496
Needham, J., 246, 247
Neisser, U., 44, 233, 234, 256, 261, 262
Nellis, L., 144
Nelson, C. A., 144
Nelson, D. V., 478
Nelson, L. D., 103, 227
Nelson, R. O., 406
Nester, M. A., 505, 508
Nettelbeck, T., 250
Neugarten, B., 536
Neuman, G. A., 530
Newcomb, T. M., 337
Newell, A., 480
Newell, C., 496
Newman, H. H., 248
Nitko, A. J., 113
- Nordheimer, J., 28
Norman, M. F., 315
Norton, P. J., 411
Notarius, C., 407
Notarius, C. I., 447
Novak, C. G., 322
Novick, M. R., 113, 139, 176, 186
Nunes, L. M., 474
Nunnally, J. C., 64, 194, 211, 269, 347
Nystedt, L., 552
- Oakland, T., 514
Oberholzer, Emil, 379
O'Boyle, M. W., 252
O'Connor, E., 485
Odbert, H. S., 92, 353, 358
Oden, M. H., 251
O'Hare, T., 437
Okazaki, S., 227
O'Keefe, J., 490
O'Leary, K. D., 132
Olkin, R., 491
Olson, D. H., 447
Olson-Buchanan, J. B., 456
Olweus, D., 439
Omar, M. H., 500
Ones, D. S., 532
Organ, D. W., 551
Orne, M. T., 425
Orozco, S., 355
Orr, D. B., 261n
Orr, F. C., 508
Orr, R. R., 451
Osberg, T. M., 368
Osgood, C. E., 350, 558
Ossorio, A. G., 393
Ostendorf, F., 358
Ouellette, S. E., 509
Ozer, D. J., 117
Ozonoff, S., 227, 471
- Padden, C., 507, 517, 518
Padilla, A., 374
Padilla, A. M., 371
Palmore, E., 250
Panell, R. C., 113
Pannbacker, M., 475
Panter, A. T., 180
Paolo, A. M., 284
Parette, H. P., 514
Pargament, K. L., 23
Parke, R. D., 143, 303
Parker, C., 550
Parker, T., 515
Parkes, L. P., 551-552
Parnes, H. S., 536
Pascal, G. R., 476
Pascoe, C. J., 9
Patterson, D. G., 454n
Patterson, M. B., 472
Patterson, M. M., 59
Patterson, W. M., 439
Patton, M. J., 536
- Paul, V., 517
Paulhus, D. L., 346
Paullay, I. M., 552
Pearson, K., 248
Peng, Y., 553
Pennebaker, J. W., 407
Perrewe, P. L., 552
Perry, C., 425
Perry, C. W., 425
Petersen, N. S., 186
Peterson, C., 510
Peterson, C. A., 27
Peterson, R. A., 551
Petrie, K., 165
Petty, M. M., 551
Phelps, L., 508
Phillips, B. A., 507, 517, 518
Phillips, P. D., 398
Piaget, Jean, 235-236
Piedmont, R. L., 354
Pilgrim, C., 437
Pintner, R., 36
Piotrowski, C., 421, 533
Piotrowski, Z., 380
Pittenger, D. J., 533
Plake, B. S., 26
Pledger, C., 491
Pleiss, K. L., 291
Plucker, J. A., 253
Poland, D. L., 368
Polizzi, D., 347
Pollard, R. Q., 510
Pomplun, M., 500
Ponterotto, J. G., 534
Porter, L., 552
Porteus, Stanley D., 471-472
Powell, D. H., 250
Prather, E. N., 389
Preston, R., 332
Price, B., 255
Price, G., 447
Prout, H. T., 398
Psychological Corporation, 168, 169, 277, 307, 461
Pullen, L., 561
Putnam, W. H., 425
- Qu, C., 508
Quay, H. C., 510
Quill, T. E., 55
Quinsey, V. L., 413
Quintana, D., 371
- Rabbit, P. M. A., 250
Rafferty, J. E., 351, 393
Ragheb, M. G., 536
Raifman, L. J., 507, 508
Raju, N. S., 222
Ramírez, M., III, 371
Randall, A., 224
Randall, D. M., 552
Randolph, C., 284
Ranseen, J. D., 84
Rapaport, David, 275, 392, 436
- Raphael, A. J., 476
Raphael, S., 317
Rappeport, J. R., 438
Raven, J. C., 278
Raz, S., 144
Razran, G., 400
Recarte, M. A., 474
Reckase, M. D., 224
Reddon, J., 447
Redlich, F. C., 401
Ree, M. J., 295
Reece, R. N., 449
Reed, R. S., 451
Reed, T. E., 235, 261
Reeder, G. D., 301
Reichenberg, N., 476
Reid, D. B., 346
Reik, Theodor, 417
Reinehr, R. C., 352
Reise, S. P., 220, 227
Reiser, M., 425
Reitan, Ralph M., 227, 478, 482, 485
Remington, R. W., 474
Renwick, R., 515
Retzlaff, P. D., 540
Rey, G. J., 478
Reynolds, C. E., 183
Reynolds, C. R., 127n
Reynolds, W. M., 439
Reznikoff, M., 380
Rice, M. E., 439
Richards, D., 234
Richards, W. S., 454
Richardson, M. W., 137, 138
Richman, J., 55
Richters, J. E., 423
Rierdan, J., 397n
Riethmiller, R. J., 398
Riggs, D. S., 132
Risley, T. R., 255
Ritzler, B., 380
Ritzler, B. A., 391
Rivas-Vázquez, R., 517
Riverside Publishing, 329
Roach, R. J., 176, 178, 179, 447
Roback, A. A., 34
Robbins, S. B., 536
Roberts, B. W., 337
Roberts, G. E., 389
Roberts, M. W., 411
Roberts, R. N., 3
Robertson, G. J., 226
Robin, A. L., 447
Robinson, N. M., 85-86
Rodríguez, O., 518
Rodríguez-Giegling, M., 371
Roe, A., 521
Rogers, Carl, 352
Rogers, R., 424, 444
Rogler, L. H., 126
Rohl, J. S., 471
Rohner, R. P., 355
Roid, Gale H., 3, 152, 268, 269, 270, 273

- Rokeach, M., 65, 373
 Romano, J., 147
 Rome, H. P., 12
 Ronan, G. G., 389
 Roper, B. L., 404
 Rorer, L. G., 347
 Rorschach, Hermann, 379
 Rosal, M. L., 396
 Rosen, J., 49
 Rosen, M., 515
 Rosenman, Ray, 339
 Rosenthal, R., 125
 Rosenzweig, Saul, 390, 394
 Rossini, E. D., 389
 Roszkowski, M. J., 495
 Rothberg, J. M., 439
 Rotter, J. B., 347, 351, 393, 401
 Rottinghaus, P. J., 522, 523
 Rotundo, M., 534
 Rouse, S. V., 437
 Routh, D. K., 401
 Roy, P., 371
 Rozeboom, W. W., 180
 Ruch, G. M., 45
 Ruch, W., 415
 Ruffolo, L. F., 472
 Russell, J. S., 185
 Russell, J. T., 167, 170
 Russell, M. T., 358
 Russo, D. C., 406
 Rutherford, A., 394, 395
 Ryan, A. M., 534
 Ryan, J. J., 250, 277, 284, 285
- Sabatelli, R. M., 447
 Sachs, B. B., 509
 Sackett, P. R., 186, 532, 534, 545
 Sacks, O., 517
 Salas, E., 547
 Sales, B. D., 503
 Salk, J. E., 553
 Salthouse, T. A., 472
 Salvia, J., 322
 Samuda, R. J., 256
 Sánchez, L. M., 27, 421
 Sandelands, L. E., 556
 Sandoval, J., 326, 534
 Sanfilippo, J., 449
 Santiviago, M., 518
 Sattler, J. M., 181, 278, 291
 Saunders, E. A., 382
 Savickas, M. L., 521, 523
 Savitsky, K., 7
 Saxe, L., 503, 532
 Saxton, J., 485
 Sayer, A. G., 220
 Sayette, M. A., 436
 Scarr, S., 255
 Schafer, R., 392
 Schaie, K. W., 244, 250
 Scheid, T. L., 504
 Schein, J. D., 517
 Schildroth, A., 508
 Schloss, L., 562
- Schmand, B., 471
 Schmidt, F. L., 44, 125, 174, 175, 186, 545
 Schmidt, Frank, 526
 Schmidt, K. L., 398
 Schmitt, N., 534, 538, 541
 Schneck, M. R., 36
 Schneider, D. L., 532
 Schneider, M. F., 389
 Schneider, W. Joel, 287
 Schönemann, P. H., 180
 Schooler, C., 516
 Schoop, L. H., 285
 Schuh, A. J., 414
 Schuldburg, D., 380
 Schuler, M. E., 143
 Schulte, A. A., 500
 Schulte, L. E., 508
 Schultz, B. M., 100
 Schwartz, L. A., 384
 Schwartz, N., 556
 Scodel, A., 401
 Scott, L. H., 291
 Scotti, J. R., 127n
 Seagull, F. J., 474
 Sears, R. R., 251
 Seashore, C. E., 318
 Sebold, J., 449
 Segal, S. P., 556
 Seibert, S. E., 532
 Sellbom, M., 341
 Serby, M., 464
 Serin, R. C., 445
 Serpell, R., 255
 Sevig, T. D., 371
 Shah, S. A., 58
 Shakow, David, 394
 Shane, B., 478
 Shapiro, E. S., 408
 Shavelson, R. J., 148
 Shaw, S. R., 278
 Shaywitz, B. A., 254
 Shearn, C. R., 401
 Shedler, Jonathan, 423
 Sheehan, P. W., 425
 Sheffield, D., 249
 Shepard, L. A., 221
 Sherman, R., 416
 Sherrill-Pattison, S., 472
 Shiffman, S., 409
 Shiffrin, R. M., 480
 Shine, L. C., 170
 Shirom, A., 550
 Shneidman, E. S., 389, 397
 Shock, N. W., 250
 Shockley, W., 249
 Shriner, J. G., 500
 Shuey, A. M., 255
 Shum, D., 472
 Siegler, R. S., 234
 Silka, V. R., 515
 Silverstein, A. B., 285
 Silverstein, M. L., 227
 Simon, Theodore, 35, 256, 318
- Simpson, R., 255
 Simpson, R. L., 500
 Sims, H. P., 411
 Sines, J. O., 455
 Siperstein, G. N., 515
 Skinner, B. F., 394, 395
 Skinner, C. H., 408
 Skolnick, J. H., 413
 Slakter, M. J., 221
 Slater, S. B., 496
 Slobogin, C., 503
 Smith, D. E., 140
 Smith, D. K., 250, 301, 398
 Smith, F. J., 434n
 Smith, G. T., 250, 285, 305
 Smith, J. V., 286
 Smith, M., 171
 Smith, P. B., 126
 Smith, R. G., 402
 Smith, T. C., 278
 Smither, J. W., 414
 Smither, R., 371
 Smolak, L., 24
 Snowden, L. R., 371
 Snyder, C. R., 401
 Snyder, D. K., 447, 456
 Sobell, L. C., 405
 Sobell, M. B., 405
 Sadowsky, G. R., 371
 Sokal, M. M., 34
 Solomon, I. L., 389
 Solomon, P. R., 467
 Sommers-Flanagan, J., 439
 Sommers-Flanagan, R., 439
 Sones, R., 389
 Sontag, L. W., 255
 Spanier, G., 447
 Spanier, G. B., 447
 Sparrow, S. S., 514
 Spearman, C., 2, 234, 237
 Spearman, C. E., 244
 Speth, E. B., 101
 Spiegel, J. S., 496
 Spielberg, C. D., 551
 Spielberg, Charles D., 340
 Spies, C. J., 33, 116
 Spitz, H. H., 471
 Spitzer, R. L., 423, 424, 495
 Spivack, G., 510
 Spokane, A. R., 521, 523-524
 Spotts, J., 510
 Spranger, E., 372
 Spreat, S., 495
 Stacy, A. W., 437
 Staggs, G. D., 523
 Stahl, P. M., 100
 Stake, J. E., 533
 Stanczak, D. E., 472
 Stanley, J. C., 44, 132
 Starch, D., 140
 Stark, K., 398
 Starr, B. D., 389
 Staw, B. M., 534
 Steadman, H. J., 439
- Steer, R. A., 164
 Steiger, J. H., 180
 Stein, D., 341
 Steinberg, M., 424
 Steinfeld, E., 500
 Stephens, J. J., 40
 Stephenson, W., 351
 Sternberg, D. P., 447
 Sternberg, Robert J., 233, 242, 254, 261, 262
 Stewart, D. W., 558
 Stice, E., 414
 Stillman, R., 511
 Stinnett, T. A., 514
 Stokes, J. B., 434n
 Stone, B. J., 182, 183
 Stone, D. R., 395
 Stoppard, J. M., 415
 Storandt, M., 250
 Storey, K., 515
 Stovall, D. R., 250
 Straus, M. A., 132, 447
 Strauss, A. A., 460
 Strauss, Alfred, 460
 Strauss, E., 227
 Streiner, David L., 63, 139, 348
 Stricker, G., 383, 388
 Strodbeck, F. L., 373
 Strong, Edward K., Jr., 522
 Subich, L. M., 534
 Subkoviak, M. J., 221
 Sue, D., 431
 Sue, D. W., 431
 Sue, S., 227
 Sugarman, A., 386-387
 Suinn, R. M., 371
 Sullivan, H. S., 335
 Sullivan, Patricia, 508
 Sullivan, P. M., 508
 Summers, K., 407
 Sundberg, N. D., 2, 345, 454
 Super, C. M., 255
 Suttell, B. J., 476
 Sutton-Simon, K., 224
 Swain, D. B., 303
 Swallow, R., 507
 Swanson, J. L., 369
 Sweet, J. J., 284
 Swensen, C. H., 398
 Swift, J. W., 383
 Sylvester, R. H., 36
 Symonds, P. M., 389
 Szucko, J. J., 413
- Taft, G., 463n
 Takeuchi, J., 440
 Tallent, N., 454n
 Tan, U., 84
 Taormina, R. J., 552
 Tarling, R., 439
 Tate, D. G., 491
 Taylor, H. C., 167, 170
 Taylor, R. L., 495
 Taylor, S. V., 533

- Teague, W., 309
Teevan, R. C., 550
Tellegen, A., 366, 531
Tenopir, M. L., 102, 503
Teplin, S. W., 101
Terman, L. M., 250-251, 362
Tharinger, D. J., 398
Thomas, A., 254
Thompson, A. E., 387
Thompson, B., 533
Thompson, C., 389
Thompson, Helen, 247
Thompson, J. Kevin, 24
Thompson, J. M., 389
Thompson, M. D., 472
Thompson, R. J., 84
Thorndike, E. L., 84, 85, 234, 245
Thorndike, R., 146
Thorndike, R. L., 186
Thornton, G. C., 541
Thurlow, M. L., 499, 500
Thurstone, Louis L., 194, 200, 239, 245, 264, 556
Tiffany, S. T., 436
Tillman, M. H., 507
Timbrook, R. E., 369
Tinsley, H. E. A., 160
Tittle, C. R., 551
Tonsager, M. E., 4
Torrance, E. P., 297
Touliatos, J., 100
Tramontana, M. G., 478
Trautscholdt, M., 391
Trice, H. M., 553
Truant, G. S., 439
Tryon, R. C., 146
Tuerlinckx, F., 417
Tugwell, P., 496
Tulchin, S. H., 36
Tulsky, D., 276, 277, 480
Tulsky, D. S., 227
Turner, S. M., 27, 421
Tuttle, F. B., 253
Tybout, A. M., 554
Tyler, L. E., 2, 19, 20, 180, 352
Tyler, R. S., 517
Tyler, R. W., 309
Tziner, A., 540

Udry, J. R., 447
Ulrich, R. E., 454
Unterbrink, C., 355, 369
U.S. Bureau of the Census, 281
U.S. Department of Education, 491
U.S. Department of Labor, 526
U.S. Office of Strategic Services (OSS), 2, 411

Utley, C. A., 495
Vacha-Haase, T., 533
Vagg, P. R., 551
Vale, C. D., 205
Vallerand, R. J., 524
Vander Kolk, C. J., 507
Vanderwood, M. L., 308
van Praag, H. M., 439
Van Tran, T., 437
Vanzetti, N. A., 447
Varon, E. J., 65, 235
Vega-Lahr, N., 303
Veiga, J., 553
Velásquez, R. J., 430-431
Velden, M., 261
Verhovek, S. H., 545
Vernon, M., 507, 508, 509, 510
Vernon, P. A., 233
Vevea, J. L., 530
Vig, S., 513
Viglione, D. J., 383
Vingoe, F. J., 425
Visser, P. S., 556
Viswesvaran, C., 532
Vitousek, K. M., 409
Volkmar, F. R., 515
von Knorring, L., 84
von Wolff, Christian, 32
Vossekuil, B., 441
Vroom, V. H., 549, 551
Vygotsky, L. S., 251

Waddell, D. D., 268
Waehler, C. A., 398-399
Wagner, B. M., 439
Wagner, E. E., 390
Wagstaff, G. F., 425
Wainer, H., 270
Wakefield, Jerome C., 423
Wald, A., 171
Waldman, D. A., 528, 530
Walker, H. M., 510
Walker, L. S., 496
Walker, R. L., 371
Walkup, J., 494
Wallace, I. F., 478
Wallace, K. M., 179, 447
Waller, N. G., 354, 358
Wallston, K. A., 347
Walsh, J. A., 401
Wantz, R. A., 451
Ward, L. C., 285
Ward, M. P., 2, 3
Ward, P. B., 393
Waring, E. M., 447
Warmke, D. L., 529
Watkins, C. E., Jr., 285
Watson, C. G., 398

Weaver, C. B., 510
Webb, E. J., 413-414
Webster, C. D., 439
Wechsler, David, 3, 38, 85, 104, 105, 229-230, 235, 244, 254, 273, 276, 278, 279-280, 282, 284
Wecker, N. S., 472
Weed, N. C., 436, 437
Weiner, B. A., 444
Weiner, I. B., 380, 382, 383-384
Weinstock, 405
Weir, R. F., 55
Weiss, D. J., 160, 205
Weiss, D. S., 393
Weiss, H. M., 534
Weiss, R., 407
Weisse, D. E., 253
Weissman, H. N., 451
Wells, G. L., 338
Welsh, G. S., 361, 365
Welsh, J. R., 295
Werner, Heinz, 460
Wertheimer, Max, 475-476
Wesman, A. G., 244, 250
West, L. J., 544
Westen, D., 387
Westling, D. L., 515
Wexley, K. N., 414
Whatley, P. R., 355
White, B. L., 254
White, J. A., 224
White, L. T., 532
White, R. W., 385
White, S., 450
Whitener, E. M., 534
Whitworth, R. H., 355, 369
Wicker, A. W., 551
Wickes, T. A., Jr., 401
Widaman, K. F., 180
Widiger, T. A., 422
Wielkiewicz, R. M., 412
Wiens, A. N., 260
Wigdor, A. K., 44, 530
Wiggins, N., 363-364
Wilcox, R., 401
Wilk, S. L., 186
Wilkinson, G. S., 306
Williams, C. L., 431
Williams, D. R., 524
Williams, J. M., 478
Williams, K. J., 531
Williams, R., 260
Williams, R. H., 132
Williams, T. Y., 439
Willis, R. H., 337
Wilmer, H. A., 395
Wilson, G. G., 409

Wilson, P. T., 495
Wilson, S. L., 14
Winner, E., 251
Winston, A. S., 538
Wirt, R. D., 343, 343n
Wish, J., 515
Witkin, Herman A., 24
Witmer, Lightner, 35
Witty, P., 252
Wober, M., 255
Wolfner, G., 450
Wolfram, W. A., 40
Wolf-Schein, E. G., 511
Wolfson, D., 227, 478, 482, 485
Wollersheim, J. P., 439
Wong-Rieger, D., 371
Woodcock, R. W., 327
Woodward, J., 518
Woodworth, R. S., 356, 362
Woo-Sam, J. M., 282
Worchel, F. F., 389
World Health Organization (WHO), 491
Worlock, P., 449
Worsley, A., 561
Wylonis, L., 501

Yamakawa, R., 278
Yao, E. L., 371
Yen, W. M., 216, 220
Yerkes, R. M., 291
Yin, P., 140
Yoo, S. M., 553
Young, A., 423
Young, K. S., 557
Younger, J. B., 101
Youngjohn, J. R., 250
Yuille, J. C., 450
Yussen, S. R., 234

Zajac, D. M., 552
Zavala, J. D., 358
Zedeck, S., 529
Zelig, M., 425
Zhang, L.-M., 412
Zieziula, F. R., 510
Zimmerman, D. W., 132
Zimmerman, I. L., 282
Ziskin, J., 438
Zsoldos, M., 508
Zubin, Joseph, 395
Zuckerman, M., 93, 255, 402
Zumbo, B. D., 533
Zuniga, M. E., 374
Zwahlen, H. T., 474
Zweigenhaft, R. L., 43
Zytowski, D. G., 524

- AAMR (American Association on Mental Retardation), 495, 513, 514
- AAS (Escala de Reconocimiento de Adicción), 437
- ABAP (American Board of Assessment Psychology), 22-23, 53
- ABAS (Adaptive Behavior Assessment System), 514
- ABLE (Adult Basic Learning Examination), 310-311
- ABPP (American Board of Professional Psychology), 22
- ABS-S:2 (Adaptive Behavior Scale-School: 2), 514
- Abuso** (1) Infligir o permitir que se inflijan lesiones físicas o daño emocional de manera no accidental; (2) crear o permitir la creación de riesgo sustancial de daño físico o deterioro emocional no accidental; (3) cometer o permitir la comisión de ofensas sexuales contra un niño; contrástese con *descuido*, 448-451
- Abuso de sustancias**, 436-438, 543-544
- Abuso infantil**: Inflicción o creación no accidental de condiciones que dan como resultado la lesión física o el daño emocional u ofensa sexual contra un niño, 448-451
- Academia Nacional de Ciencias (NAS), 530
- Acción afirmativa, 44, 97, 102, 186-187
- Acecho a las celebridades, 440-441
- Acecho, 440-441
- Acomodación** (1) De acuerdo con la teoría piagetiana, es una de las dos operaciones mentales básicas mediante las cuales el hombre aprende, ésta implica modificar lo antes aprendido, percibido o pensado para adecuarlo a la nueva información (contrástese con *asimilación*); (2) en evaluación, es la adaptación de una prueba, procedimiento o situación, o bien la sustitución de una prueba por otra, a fin de hacer que la evaluación se adecue mejor al evaluado con necesidades excepcionales; (3) en el lugar de trabajo, es el ajuste o la variación de las funciones o circunstancias del trabajo, 236, 496-500, 501, 505-506, 507-508, 511-512
- Acrónimo **EDREPOHOG**, 430
- Acta Ningún Niño Se Quede Atrás (NCL:B) (2001), 48
- Actitud**: Una disposición, supuestamente aprendida, a reaccionar en forma característica ante un estímulo particular; 332-333, 551-552, 556-559
- Actitudes maternas, 302-303
- Actividad vital importante**: Aun cuando no se define de manera específica en la Americans with Disabilities Act of 1990 Ley de Estadounidenses con Necesidades Educativas Especiales, se presume que constituye funciones como cuidarse a uno mismo, el desempeño de tareas manuales, caminar, ver, escuchar, hablar, respirar, aprender, sentarse, pararse de pie, levantarse, leer, alcanzar cosas, reproducirse y trabajar, 501
- Aculturación afroamericana, 371
- Aculturación indioasiática, 371
- Aculturación**: El proceso a través del cual los pensamientos, comportamientos, valores, identidad y visión global del individuo se desarrollan en relación con el pensamiento, comportamiento, costumbres y valores de un grupo cultural particular, 370-373
- Adarand Constructors, Inc. v. Pena et al.*, 48
- Adecuación del trabajo, 533
- ADHD (attention deficit hyperactivity disorder). Véase Trastorno de hiperactividad por déficit de atención)
- Adicción, evaluación de, 436-438
- Adivinación, 204, 220-221
- ADLO (Assessment of Development Levels by Observation. Véase Evaluación de Niveles de Desarrollo por la Observación)
- Administración de prueba** “Pensar en voz alta”: Método de análisis cualitativo de reactivos que requiere que los examinados verbalicen sus pensamientos conforme les llegan; oportunidad conveniente para “ver” cómo funcionan los reactivos de la prueba en lo individual y el porqué los entienden o malinterpretan los que responden la prueba, 224
- Admisiones
- aspectos legales, 47, 49, 50-51
- Examen de Registros para Graduados, 88, 110, 111-112, 313, 316-317
- Prueba de Aptitudes Escolares, 88, 89, 109-110, 314-316 Véase también Evaluación educativa y pruebas de aptitud, 314-318, 319
- ADRESSING**. Véase Acrónimo **EDREPOHOG**
- AERA (American Educational Research Association), 16, 52-53
- Afagia**: Una condición en la cual se pierde o disminuye la capacidad para comer
- Afasia**: Pérdida de la capacidad para expresarse o para entender el lenguaje oral o escrito, que se debe a una deficiencia neurológica, 478
- AFQT (Armed Forces Qualification Test), 294-295
- Afroamericanos, 257, 260
- AGCT (Army General Classification Test), 292
- Agotamiento**: Un síndrome psicológico de extrema fatiga emocional, despersonalización y reducción en el logro personal, 550-551
- AHPAT (Prueba de Admisión a la Facultad de Ciencias de la Salud), 319
- Ajuste del puntaje, 186-188
- Albemarle Paper Company v. Moody*, 48
- Alcance, 347-348
- Alfa. Véase **Coefficiente alfa**
- Allen v. el Distrito de Columbia*, 48
- Ambiente de la prueba, 131, 497
- American Association for Measurement and Evaluation in Counseling and Development, 53
- American Association on Mental Retardation (AAMR), 495, 513, 514
- American Board of Assessment Psychology (ABAP), 22-23, 53
- American Board of Professional Psychology (ABPP), 22
- American College Testing Program, 310
- American Educational Research Institute (AERA), 16, 52-53
- American Men of Science*, 34, 35
- American Psychiatric Association, 55
- American Psychological Association (APA), 16
- en asuntos éticos, 49, 52-53, 55, 57-58
- en inteligencia, 261
- y bases de datos en línea, 27-28
- American Sign Language (ASL), 507-508
- American Speech-Language-Hearing Association, 53
- Americans with Disabilities Act (PL 101-336) (1990). Véase Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades, 48, 490, 492, 500-501, 504
- Análisis cualitativo de reactivos**: Término que en general se emplea para referirse a diversos procedimientos no

- estadísticos que sirven para examinar el funcionamiento de los reactivos individuales de una prueba en comparación tanto con otros reactivos en la misma prueba como con la prueba y su contexto como un todo; contrástese con *procedimientos con base en estadísticas*. Los métodos cualitativos suponen la exploración verbal de los temas que nos ocupan, a través de entrevistas y discusiones de grupo con los examinados y otras partes relevantes, 222-225
- Análisis de Cluster.** Véase **Análisis factorial**
- Análisis de escalograma,** 200
- Análisis de Prueba de Lectura Durrell,** 320
- Análisis de reactivos:** Un término general para describir diversos procedimientos, casi siempre estadísticos, diseñados para explorar el funcionamiento de los reactivos individuales de una prueba en comparación con otros reactivos de la prueba y en el contexto de la prueba completa; el análisis de reactivos puede ser realizado, por ejemplo, para explorar el nivel de dificultad de los reactivos individuales en una prueba de rendimiento o la confiabilidad de una prueba de personalidad; contrástese con *análisis cualitativo del reactivo*, 212-225
- curvas características del reactivo, 217-219, 221-222
- índice de confiabilidad del reactivo, 214
- índice de dificultad del reactivo, 212-213
- índice de discriminación del reactivo, 215-217
- índice de validez del reactivo, 214-215
- métodos cualitativos, 222-225
- y adivinar, 220-221
- y pruebas de homogeneidad, 177
- y pruebas de velocidad, 222
- y sesgo, 221-222
- y teoría de la respuesta del reactivo, 219-220
- Análisis del patrón:** Estudio del patrón de las calificaciones de la prueba en una escala Wechsler o cualquier otra prueba a fin de identificar un patrón asociado con un diagnóstico (tal como deficiencia neurológica en el hemisferio derecho), 469
- Análisis del perfil:** La interpretación de patrones de puntuaciones en una prueba o batería de pruebas, usado con frecuencia para generar hipótesis diagnósticas a partir de los datos de pruebas de inteligencia, 272, 339n
- Análisis factorial confirmatorio (CFA):** Una clase de procedimientos matemáticos empleados cuando la estructura del factor que se ha hipotetizado explícitamente, se prueba para que se adecue a las relaciones observadas entre las variables, 180, 238n, 289-290
- Análisis factorial exploratorio:** Clase de procedimientos matemáticos útiles para estimar y extraer factores, o decidir cuántos factores retener, 180, 238n, 289
- Análisis factorial:** Una clase de procedimientos matemáticos, que suelen emplearse como métodos para la reducción de datos, diseñados para identificar variables en las cuales las personas pueden diferir (o factores). En medición, son comunes dos tipos de análisis de factor; el exploratorio y el confirmatorio, 119, 194
- visión general, 180, 287-290
- y consistencia entre reactivos, 214
- y evaluación de personalidad, 357-358
- y pruebas de inteligencia, 268, 270, 286
- y teorías de la inteligencia, 236-241, 245
- Análisis funcional:** en evaluación conductual, el proceso de identificar las variables dependientes e independientes con respecto de un problema que se presenta, 410
- Análisis sobre la Cultura Organizacional (DOC),** 554-555
- Ancianos, 512
- Anclaje, 110
- Angiograma cerebral, 486
- Antisemitismo, 538
- Anuario de mediciones mentales (MMY),* 26, 27
- APA:** American Psychological Association. En otras fuentes, textos médicos en particular, esto puede referirse a la American Psychiatric Association. Véase American Psychiatric Association; American Psychological Association
- Aparato de haz de luz ajustable, 24
- APAT, Accounting Program Admission Test (Prueba de Admisión a la Facultad de Contaduría), 319
- Apercibir:** Percibir en términos de percepciones pasadas (de este verbo se deriva el sustantivo *apercepción*), 386
- Apgar, número, 302
- Apgar, Virginia, 302
- API (Inventario de Potencial del Solicitante), 532
- Apoyo social, 517
- Applied Measurement in Education,* 27
- Aprecio entre pares:** Un método para obtener información relacionada con la evaluación sobre un individuo reuniendo a los amigos de dicho individuo, compañeros de clase, colegas de trabajo, u otros pares, 331-332, 546-547
- Apretón de manos, 66, 67
- APS (Escala de Posibilidad de Adicción), 436-437
- APT (Prueba de Personalidad Aperceptiva), 391
- Aquiescencia:** Es un estilo de responder pruebas que se caracteriza por estar de acuerdo con cualquier cosa que se presente, 346
- Armas, escondidas, 55
- Armed Forces Qualification Test (AFQT), 294-295
- Armed Services Vocational Aptitude Battery (ASVAB), 292, 293-294
- Army General Classification Test (AGCT), 292
- Asimilación:** En la teoría de Piaget, es una de las dos operaciones mentales básicas mediante las cuales el hombre aprende, ésta comprende la organización activa de la información nueva en lo antes percibido, aprendido y pensado; contrástese con *acomodación*, 236
- ASL (American Sign Language), 507-508
- Asociación Nacional de Psicólogos Escolares (NASP), 16
- Asociación Nacional Educativa (NEA), 52
- Aspectos legales
- competencia para ser sometido a juicio, 440-443
- daño emocional, 445-446
- derechos de los evaluados, 57-60
- discapacidades, 492-495
- evaluación neuropsicológica, 483
- legislación, 48
- liberación de prisión, 444-445
- peligrosidad, 439, 440-441
- responsabilidad criminal, 443-444
- testimonio experto, 502-503, 504
- y validez de contenido, 160
- Véase también **Evaluación psicológica forense**
- AST (Prueba Reitan-Indiana de Detección de Afasia), 478
- ASVAB (Batería de Aptitudes Vocacionales para los Servicios Armados), 292, 293-294
- Autismo, 513
- Autoconcepto:** Las actitudes, creencias, opiniones y pensamientos relacionados de una persona sobre sí misma, 341-342, 523-524
- Autoeficacia, 517
- Automonitoreo:** El acto de observar y registrar en forma sistemática aspectos de los comportamientos propios y/o acontecimientos relacionados con ellos, 402, 408-410
- Autopsia psicológica:** Una reconstrucción del perfil psicológico de una persona muerta con base en registros archivados, artefactos y entrevistas con el evaluado en vida, o con personas que lo(la) conocieron, 18
- Autorreporte:** El proceso donde un evaluado proporciona información

- sobre sí mismo en formas como respuestas a preguntas, llevar un diario, o reportar pensamientos y/o conductas automonitoreadas
- autoconcepto, 341-342
- enfoque orientado al contenido, 356
- error, 342-343, 354, 362-363
- marco de referencia, 350-351
- métodos de evaluación de personal
objetivos, 377
- perspectiva histórica, 36-37
- psicología del consumidor, 556-559
versus automonitoreo, 408-409
- Auxiliares médicos para el diagnóstico,
486-487
- Ayuda para morir. *Véase* Suicidio asistido
- Banco de reactivos:** Una colección de preguntas para ser usadas en la construcción de pruebas, 205, 207-209
- BAS (Escala Británica de Capacidad), 324
- Bases de datos en línea, 27-28
- BASIC ID/S, 561-562
- Batería de disfunción severa (SIB), 485
- Batería de pruebas de aptitudes especiales (SATB), 526
- Batería de pruebas de habilidades de movimiento de Frostig, 512
- Batería de pruebas psicoeducacionales:**
Un conjunto de pruebas que miden los logros educacionales y las habilidades relacionadas con el éxito académico, 298, 321-329
- Batería de pruebas:** Una selección de pruebas y procedimientos de evaluación compuestos por lo general de pruebas diseñadas para medir diferentes variables, pero que tienen un objetivo común; por ejemplo, una prueba de inteligencia, una prueba de personalidad, y una prueba neuropsicológica puede usarse para obtener un perfil psicológico general de un individuo, 137n, 435-436, 482-485
- catálogos de pruebas, 26
- psicoeducacional, 298, 321-329
- Batería estándar:** Suele comprender la administración de un grupo de cuando menos, tres distintos tipos de pruebas y tiene el propósito de evaluar diferentes esferas de funcionamiento: una prueba de inteligencia, una de personalidad, y otra para detectar deficiencias neurológicas, 436
- Batería fija:** Una batería de pruebas predeterminadas que contiene una cantidad de pruebas estandarizadas para administrarse, tal como la batería Neurofisiológica Halstead-Reitan; contrástese con *batería flexible*, 482, 483
- Batería flexible:** Un grupo de pruebas más asociado con la evaluación neuropsicológica seleccionadas con el fin de responder al objetivo de la evaluación; contrástese con *batería fija*, 482, 483
- Batería Kaufman de Evaluación para niños- (K-ABC), 242, 286, 321
- Batería Neuropsicológica Halstead-Reitan (H-R), 472, 482, 484-485
- Batería Neuropsicológica Luria-Nebraska (LNNB), 485
- Baterías de logros, 306-307
- Bayley, Nancy, 143
- BDI, *Beck Depression Inventory* (Inventario de Depresión de Beck), 164, 435
- Behn-Rorschach, 383
- Bender, Lauretta, 475
- Binet, Alfred
y temas culturales, 256
y pruebas de inteligencia, 1, 35, 38, 265
y escalas ordinales, 65
en personalidad, 254
en las teorías de la inteligencia, 235, 244
- Biorretroalimentación, 15, 412
- BITCH (Black Intelligence Test of Cultural Homogeneity, o Prueba de Inteligencia Negra de Homogeneidad Cultural), 257, 260
- Blueprinting, 159
- BPS (Escala Perceptuales de Bricklin), 101
- Brauer, Barbara, 508
- Briggs, Katharine Cook, 533
- BSID (Escala Bayley para el Desarrollo Infantil), 143-144
- Buros, Oscar Krisen, 26, 27, 46
- Búsqueda autodirigida (50s), 339, 357, 523, 524
- Búsqueda de sensaciones, 93
- Butcher, James, 367
- Calendario de Preferencias Personales de Edwards (EPPS), 210-211, 350, 531
- Calidad de vida, 515-516
- Calificación acumulada:** Un método de calificación mediante el cual los puntos de los reactivos individuales o subpruebas se acumulan, y mientras más alta sea la suma total, más alto se presume que el individuo califica en la capacidad, rasgo u otra característica que se esté midiendo; *confróntese con calificación por clase y calificación ipsativa*, 95
- Calificación ipsativa:** Un enfoque a la calificación e interpretación de pruebas donde las respuestas del examinado y la fuerza presumida de un rasgo medido se interpretan con relación a la fuerza medida de otros rasgos para dicho examinado; contrástese con *calificación por clase y calificación acumulativa*, 210-211, 353
- CALS (Checklist of Adaptive Living Skills, Lista de Verificación de Habilidades de Adaptación para la Subsistencia), 534
- Cambio de lentes culturales, 431, 434
- Cambios previos/posteriores a la prueba, 177-178
- Campbell, David P., 522, 524
- CAP (Inventario de Potencial de abuso Infantil), 172-173, 451
- CAPA. *Véase* Evaluación psicológica asistida por computadora
- Capacidad conceptual general (GCA), 324
- Capacidades vulnerables:** En el modelo de inteligencia de Cattell-Horn, son las capacidades cognoscitivas que declinan con la edad y que no recuperan sus niveles previos tras sufrir una lesión cerebral; contrástese con *capacidades conservadas*, 239
- Características del evaluado, 341-345, 404.
Véase también Quienes responden las pruebas
- Características dinámicas, 142, 144
- Características estáticas, 144
- Carga cultural:** Un índice de la magnitud en la cual una prueba incorpora el vocabulario, los conceptos, tradiciones, conocimientos, y sentimientos asociados con una cultura particular, 256, 257, 258-259
- Carga factorial:** En análisis factorial, es una metáfora que sugiere que la prueba (o un reactivo) contiene una cierta cantidad de una o dos capacidades, que a su vez, tienen una determinada influencia en la calificación de la prueba (o en la respuesta a reactivos individuales de la prueba). A diferencia de otras metáforas, sin embargo, una carga factorial puede cuantificarse, 180
- Cartas de recomendación, 538
- Cartas de solicitud, 537
- CAS (Escala Callier-Azusa), 511
- Caso de discapacidad percibida:** Litigio u otra reclamación suscitada por la discriminación en el empleo de una persona con una discapacidad evidente y, como resultado de dicha percepción, es discriminada, 501
- Casos de estudio, 10. *Véase también* **Datos de la historia del caso**
- CAST (Prueba de Apercepción de Narración de Historias, para Niños), 389
- CAT (Prueba de Apercepción para Niños), 389
- CAT. *Véase* **Pruebas adaptadas a computadora**
- Categoría de calificación. *Véase* Clase de calificación
- CAT-H (Prueba de Apercepción con Figuras Humanas para Niños), 389, 447
- Cattell, James McKeen, 34-35
- Cattell, Psyche, 34
- Cattell, Raymond Bernard, 358

- Cattell-Horn-Carroll (CHC) modelo de las habilidades cognoscitivas, 240-241, 245, 265
- y baterías de pruebas psicoeducativas, 322, 327
- y Escalas de Inteligencia Stanford-Binet, 268, 269, 282
- y Escala Wechsler de Inteligencia para Niños, 279-280, 282
- CBA. Véase **Evaluación basada en el currículo**
- CBCL (Lista de Verificación de Conducta Infantil de Achenbach), 301
- CBM. Véase Medición con base en el currículo
- CCAI (Inventario de Adaptabilidad Entre Culturas), 534
- Ceguera. Véase Discapacidades visuales
- Centro de evaluación:** Procedimiento de valoración estandarizado de manera organizacional que implica múltiples técnicas de evaluación, 2, 541
- Centro de Información de Recursos Educativos (ERIC), 27
- Centros Regionales para Jóvenes y Adultos Sordos-Invidentes, 510
- Cerebelo, 459
- Cerebro, 458-459
- CFA. Véase **Análisis factorial confirmatorio**
- Chapple vs. Ganger*, 483
- CHC modelo de inteligencia. Véase Cattell-Horn-Carroll (CHC) modelo de las habilidades cognoscitivas
- China, 31-32
- CI (cociente de inteligencia), 267. Véase también Pruebas de inteligencia
- Ciencia, 35
- CIIS (Escala de Inteligencia Infantil de Cattell), 34
- Clase de calificación:** También se le llama *calificación por categoría*, un método de evaluación en el cual las respuestas de la prueba dan crédito para que se coloque a alguien en una clase o categoría particular junto con otros de los que responden la prueba. Ciertas veces los que responden deben alcanzar un cierto número de respuestas correspondientes a un criterio particular para ser colocados en una determinada categoría o clase; contrasta con *calificación acumulativa e ipsativa*, 210
- Clasificación:** La clasificación ordinal de personas, registros o variables en posiciones relativas o grados de valor, 184
- Clasificación:** Una jerarquización, categorización, o asignación con respecto de dos o más criterios; contrástese con *selección y colocación*, 536
- Clasificaciones de la Industria del Entretenimiento, 19
- Clasificar, 60, 273
- Claves contextuales, 126
- CLEP (Programa de Exámenes de Nivel Universitario), 308, 310
- ClinPSYC, 28
- CMP (capacidades mentales primarias), 239, 264-265
- Cociente de deterioro (CD):** También conocido como índice de deterioro, es un patrón de las puntuaciones de las subpruebas de la escala Wechsler que el propio autor vio como la posible detección de deficiencia neurológica, 469
- Codificación empírica de criterios:** Proceso de usar grupos de criterios para desarrollar reactivos de pruebas, donde se ha demostrado que la puntuación o la clasificación de elementos establece diferencias entre grupos de examinados, 359-361
- Código de Prácticas de Pruebas Justas en la Educación* (Joint Committee of Testing Practices), 52-53
- Código Welsh:** Un resumen en taquigrafía de las puntuaciones de un evaluado en las escalas clínicas y de validez MMPI, 365
- Códigos de ética profesional, 45
- Coefficiente alfa:** También conocido como alfa de Cronbach y *alfa*, una estadística muy usada en la construcción de pruebas y usada para ayudar a derivar una estimación de confiabilidad; más técnicamente hablando, es igual a la media de todas las correlaciones posibles al dividir en mitades, 138, 139-140
- Coefficiente de confiabilidad:** Término general para denotar un índice de confiabilidad o la razón de varianza de la puntuación verdadera en una prueba a varianza total, 129. Véase también Confiabilidad
- Coefficiente de correlación de diferencia de rangos, 118. Véase también *rho de Spearman*
- Coefficiente de correlación producto-momento, 118; véase también **Pearson r**
- Coefficiente de correlación:** Simbolizado mediante *r*, es un índice de la fuerza de la relación lineal entre dos variables continuas expresado como un número que puede oscilar de -1 a +1. Aunque pueden emplearse distintas estadísticas para calcular el coeficiente de correlación, la que se emplea con más frecuencia es la de Pearson *r*, 114
- Coefficiente de determinación:** Un valor que indica cuánta varianza se comparte entre dos variables que se están calculando. Dicho valor se obtiene elevando al cuadrado el coeficiente de correlación obtenido, multiplicando por 100, y expresando el resultado como un porcentaje; el porcentaje indica el monto de la varianza que se cuantificó por el coeficiente de correlación, 117
- Coefficiente de equivalencia:** Una estimación de la confiabilidad de formas paralelas o confiabilidad de formas paralelas, 134
- Coefficiente de estabilidad:** Una estimación de la confiabilidad de la readministración de la prueba obtenida durante intervalos de tiempo de 76 meses o más, 133
- Coefficiente de generalización:** En la teoría de la generalización, es un índice de influencia que tienen ciertas facetas en una calificación de prueba, 149
- Coefficiente de regresión:** En la fórmula $y = a + bX$, la letra *a* que simboliza el corte con la ordenada, es un coeficiente de regresión, como la letra *b*, que es igual a la pendiente de la línea; en la práctica, los valores reales de *a* y *b* están determinados por un sencillo cálculo algebraico, 122
- Coefficiente de validez:** Un coeficiente que brinda la medida de la relación entre las puntuaciones de la prueba y las puntuaciones de una medida criterio, 165-166
- Cola:** Área en la curva normal que se encuentra entre 2 y 3 desviaciones estándar sobre la media, y el área de la curva normal entre -2 y -3 desviaciones estándar por debajo de la media; una curva normal tiene dos colas, 84-86
- Colocación:** La disposición, transferencia, o asignación a un grupo o categoría particular, la cual puede ocurrir con base en un criterio, 536
- Comisión de Igualdad de Oportunidades de Empleo (EEOC), 47-48
- Comité Selecto de Estados Unidos para la Igualdad de Oportunidades de Educación, 47
- Competencia para someterse a juicio en tribunales:** Entender los cargos contra uno y ser capaz de asistir en defensa propia, 440-443
- Comportamiento adaptativo:** Conducta personal que uno puede modificar en formas apropiadas a la edad con el fin de atender demandas, necesidades y desafíos, 513
- Comportamientos extraverbales, 93
- Compromiso organizacional:** La fuerza de la identificación de un individuo con una organización en particular, y su implicación en ella, 552
- Compuesto de prueba:** Un puntaje de pruebas o índice derivado de la combinación y/o transformación

- matemática de uno o más puntajes de pruebas, 268
- Comunicación no verbal, 8, 41-42
- Comunicación oral. *Véase* Problemas de lenguaje
- Conceptualización de pruebas, 190-194
- Condicional, 444-445
- Conducta fuera de la prueba, 272-273
- Confiabilidad:** El grado al que se considera que las mediciones son consistentes o repetibles; también, el grado al que las mediciones difieren de una ocasión a otra, como una función de la medida del error, 129-155
- análisis de reactivo, 214
- consistencia interna (inter-reactivo), 134-140, 141, 145, 148
- entre evaluadores, 140, 143-144, 147
- error estándar de la diferencia, 152-154
- error estándar de una medición, 149-152
- Escalas Bayley de Desarrollo Infantil, 143-144
- Escalas de Inteligencia Stanford-Binet, 152, 269
- formas cortas, 285
- formas paralelas/formas alternas, 133-134, 144
- métodos proyectivos, 383, 388
- muestreo del dominio, 146, 148
- naturaleza de la prueba, 142, 144-146
- panorama general, 98, 101
- por mitades, 135-136, 139, 145
- propósito del coeficiente, 141-142
- prueba-reprueba, 101, 132-133, 134, 139, 143, 269, 429
- pruebas de alcoholímetro, 147
- pruebas en el salón de clases, 196
- Pruebas Wechsler, 275
- teoría de la generalización, 148-149
- teoría de respuesta al reactivo, 149
- varianza del error, 130-132
- Confiabilidad de dividir en mitades:** Una estimación de la consistencia interna de una prueba la cual se obtiene al correlacionar dos pares de puntos obtenidos de mitades equivalentes de una misma prueba administrada una sola vez, 135-136, 139, 145
- Confiabilidad de formas paralelas:** una estimación del grado al cual el muestreo de reactivos y otros errores han afectado las puntuaciones de la prueba que se obtienen a partir de dos versiones de la misma cuando, para cada forma de la prueba, las medias y varianzas de las puntuaciones observadas son iguales; contrástese con *confiabilidad de formas alternas*, 133-134
- Confiabilidad de las formas alternas:** Una estimación del grado al cual el muestreo de reactivos y otros errores han afectado las puntuaciones en dos versiones de una misma prueba; contrástese con *confiabilidad de formas paralelas*, 133-134, 144
- Confiabilidad de prueba y posprueba:** Estimación de la confiabilidad de la prueba que se obtiene al correlacionar pares de puntuaciones de las mismas personas en dos distintas administraciones de la misma prueba, 101, 132-133, 134, 139, 143, 269, 429
- Confiabilidad del observador. *Véase* Confiabilidad entre evaluadores
- Confiabilidad en el puntaje. *Véase* Confiabilidad entre evaluadores
- Confiabilidad entre evaluadores:** También llamada confiabilidad del evaluador, confiabilidad del juez, confiabilidad del observador, es una estimación del grado de acuerdo o consistencia entre dos o más evaluadores (o jueces o calificadores u observadores), 140, 143-144, 147
- de evaluación clínica/orientación, 428
- de evaluación conductual, 414, 416
- y computadoras, 456
- y métodos proyectivos, 383
- Confiabilidad pares-impares: Una estimación de la confiabilidad de una prueba que es dividida por mitades, se obtiene al asignar reactivos impares a una mitad de la prueba y reactivos pares a la otra mitad, 135. *Véase también* Confiabilidad por mitades
- Confidencialidad:** La obligación ética de los profesionales de mantener en privado todas las comunicaciones hechas por un paciente o confiadas a ellos en confidencialidad. Se podría pedir a los profesionales que revelen tal comunicación bajo orden de algún tribunal u otras instancias, como aquellas en las cuales dichas comunicaciones se refieren a un tercero en peligro inminente; contrástese con *derecho a la privacidad*, 58-59
- Confucio, 31
- Conormar:** El proceso normativo de una o dos pruebas que usan la misma muestra de evaluados; se usa para validar todas las pruebas con las que se trata de obtener normas, a este proceso también se le puede llamar *convalidación*, 109n, 228
- Consentimiento informado:** Permiso para proceder con un (típicamente) servicio de diagnóstico, de evaluación, o terapéutico con base en el conocimiento del servicio y sus riesgos y beneficios potenciales, 57-58
- Consistencia entre reactivos (interna). *Véase* Consistencia interna
- Consistencia interna:** También se le llama *consistencia entre reactivos*, una estimación de qué tan consistentemente los reactivos de una prueba miden un solo constructo obtenido de una sola administración de una sola forma de la prueba y la medición del grado de correlación entre todos los reactivos de la prueba, 134-140, 141, 145, 148, 214, 388
- Constructo:** Una idea fundamentada científicamente, y desarrollada o generada para describir o explicar un comportamiento; algunos ejemplos de constructos incluyen “inteligencia”, “personalidad”, “ansiedad”, y “satisfacción en el trabajo”, 93, 175
- Contaminación del criterio:** El estado en el cual la medición de un criterio se basa en sí mismo, en todo o en parte, de una medida de predicción, 163-164
- Contenido, 6
- aspectos culturales, 42
- y evaluación de la personalidad, 345-346, 356
- y validez, 99, 159-162, 195
- y varianza del error, 130, 134
- Contrato terapéutico, 424
- Control contralateral:** Fenómeno resultante del hecho de que cada uno de los hemisferios cerebrales recibe información sensorial y controla las respuestas motoras del lado opuesto del cuerpo; es necesario entender este fenómeno para entender las relaciones del comportamiento cerebral para el diagnóstico de deficiencias neurofisiológicas, 458-459
- Convalidación:** El proceso de validación de una prueba conducido en dos o más pruebas usando la misma muestra de personas, al mismo tiempo que se realiza la elaboración de normas, también se le puede llamar *conormar* 228-229
- Coordinación muscular, 468
- COPS (*escalas ocupacionales de personalidad enfocadas en el criterio*), 532
- Corporación psicológica, 35
- Correlación:** Una expresión del grado y correspondencia de dirección entre dos cosas, cuando cada una de las cosas es de naturaleza continua, 114-125
- Pearson *r*, 115-118, 139-140, 165
- regresión, 122-125, 181-182, 183
- rho* de Spearman, 118, 176
- y gráficas, 118-122
- y validez, 166, 176
- Correlación negativa (inversa), 115, 121
- Correlaciones directas (positivas), 114-115, 120
- Correlaciones inversas (negativas), 115, 121
- Correlaciones no lineales, 118, 122
- Correlaciones perfectas, 114
- Correlaciones positivas (directas), 114-115, 120

- Corte Véase **Puntuación de corte**
- Cortes categóricos, 7
- CPI (Inventario Psicológico de California), 347, 415
- Cracking the GRE Psychology*, 317
- Creación de escalas:** (1) En la creación de pruebas, el proceso de establecer reglas para asignar números en medición; (2) el proceso mediante el cual se diseña y calibra un instrumento de medición, y la manera en que se asignan los números (u otros índices que son valores de la escala) a diferentes cantidades del rasgo, atributo o característica medida; (3) asignación de números de acuerdo con las propiedades empíricas de objetos o rasgos, 194, 196-201
- Creatividad, 131, 296-298, 330
- Credencializar o certificar, 22-23, 53, 193
- Criterio de responsabilidad criminal,** 443-444: El estándar contra el cual se compara una prueba o una calificación de ésta; el estándar puede adoptar varias formas, incluyendo un comportamiento o conjunto de comportamientos específicos, 110, 163-164, 359. Véase también **Grupo criterio; Pruebas y evaluación con referencia a un criterio**
- Criterio de validez. Véase Validez de criterio
- Criterio Georgetown de competencia para someterse a un juicio, 442
- Cronbach, Lee, 250
- Crook, Thomas, 481
- CRS-R (Escala Revisada de Medición de Connors), 301
- CRUST (Prueba de Entendederas de la Corteza Superior Cultural/Regional), 259
- Cuartil:** Uno de los tres puntos de división entre los cuatro cuartos de una distribución, cada uno etiquetado como Q1, Q2, o Q3, 78, 79, 82
- Cuestionario corto de estatus mental portátil, 466
- Cuestionario de actitud de los padres, 303
- Cuestionario de aculturación, 371
- Cuestionario de agresividad, 338
- Cuestionario de atribuciones culturales y de salud, 371
- Cuestionario de comportamiento de identidad cubana, 371
- Cuestionario de compromiso organizacional (OCQ), 552
- Cuestionario de dieciséis factores de personalidad (16 PF), 353, 358, 359
- Cuestionario de dieciséis factores de personalidad de Cattell, 358, 359
- Cuestionario de identidad étnica, 371
- Cuestiones éticas
- calificaciones del usuario de la prueba, 52-53
- decepción, 57-58, 178
- derechos del que responde la prueba, 57-60
- directrices profesionales, 49, 52, 57
- evaluación psicológica asistida por computadora, 54, 57
- opinión pública, 45-47
- personas con discapacidades, 53-54
- suicidio asistido, 54, 55-56
- y abuso de sustancias, 437-438
- Véase también **Imparcialidad**
- Cuidado administrado:** Un sistema de cuidado de la salud donde los productos y servicios que se proporcionan a los pacientes por parte de una red de proveedores del cuidado de la salud, son mediados por una agencia administrativa del asegurador que trabaja para mantener los costos bajos mediante la programación fija de reembolso a proveedores, 421
- Cultura:** Los patrones de conducta, creencias y productos del trabajo socialmente transmitidos de una población particular, comunidad, o grupo de personas, 37-38. Véase también **Temas culturales**
- Cultura de la sordera, 495, 517-518
- Cultura organizacional:** La totalidad de los patrones de conducta socialmente transmitidos característicos de una organización o compañía, incluyendo su estructura y los papeles dentro de ella, el estilo de liderazgo, los valores y normas prevalecientes, sanciones y mecanismos de apoyo, así como las tradiciones y el folclor, métodos de aculturación, y formas características de interactuar con las personas e instituciones ajenas a dicha cultura (tales como clientes, proveedores, competidores, entidades gubernamentales, y el público), 552-553, 554-555
- Currículum, 537
- Curtosis:** Define la naturaleza pendiente (puntiaguda contra plana) del centro de una distribución, 82-83
- Curva característica del reactivo (ICC):** Una presentación gráfica de la dificultad y discriminación del reactivo, 217-219, 221-222
- Curva en forma de campana. Véase **Curva normal**
- Curva normal:** Una curva suave, en forma de campana, matemáticamente definida con más altura en la parte central, la cual en forma gradual va disminuyendo en ambos lados, acercándose al eje horizontal, el cual de hecho nunca toca y que representa la distribución de un grupo de datos, 70, 80, 83-86
- CVR. Véase **razón de validez de contenido**
- Dahlstrom, W. Grant, 367
- Daño emocional:** Término a veces usado como sinónimo de *sufrimiento mental, lesión emocional*, así como *dolor y sufrimiento*, para referirse a una lesión emocional, 445-446
- Daño neurológico:** disfunción, daño, maltrato o pérdida de la función de cualquier parte o proceso de los sistemas periférico y central, 459-462
- DAP (Dibuja a una persona), prueba, 397
- DAP:SPED (Dibuja a una persona: Procedimiento de detección de perturbación emocional), 398
- Darwin, Charles, 32-33
- DAS (Escala de capacidades Diferenciales), 182, 286, 324-327
- DAT (Prueba de Admisión a la Facultad de Odontología), 319
- Datos de expectativas:** Información, usualmente en forma de una tabla de expectativas, que ilustra la probabilidad de que un examinado obtenga puntuaciones dentro de un intervalo de una medida criterio, 166-171
- Datos de la historia del caso:** grabaciones, transcripciones, y otros registros de manera escrita, pictórica u otra, en cualquier medio que preserve la información de los logros, oficiales o informales, y otros datos o artículos relevantes para un evaluado, 431, 434-435
- Datos falométricos, 413
- Daubert vs. Merrell Dow Pharmaceuticals*, 483, 502-503
- Debra P. vs. Burlington*, 48
- Decepción, 57-58, 178
- Decreto sobre la Portabilidad y Responsabilidad del Seguro de Salud (1996), 48, 59
- Deficiencia de funcionamiento verbal, 477-478
- Deficiencias funcionales, 463
- Déficit orgánico, 463
- Definiciones, 1-5, 53
- Demencia:** Término legal para denotar una discapacidad para distinguir el bien del mal, falta de control, o el estado de otros desórdenes de incompetencia mental o desorden suficiente para evitar que dicha persona se someta a un juicio, que sea juzgado culpable, o participar en algún contrato u otra relación legal, 443-444
- DeMoivre, Abraham, 83
- Dependencia/independencia de campo (contexto), 24, 351
- Derecho a la clasificación menos estigmatizadora, 60

- Derecho de privacidad:** La libertad de la gente para elegir el momento, circunstancias y la extensión a la que desean compartir o depender de las creencias, opiniones y conductas de otros; contrástese con *confidencialidad*, 58
- Desarrollo de pruebas, 16, 190-231
- aspectos culturales en, 40, 261
 - conceptualización, 190-194
 - elaboración de escalas, 194, 196-201
 - enfoque orientado al contenido, 356
 - ensayo de prueba, 211-212
 - estandarización, 102
 - Inventario Multifásico de la Personalidad de Minnesota, 361-369
 - métodos de reducción de datos, 357-359
 - muestreo normativo, 105-106
 - pruebas para el salón de clases, 195-196
 - Puntuación de reactivos, 210-211
 - recursos en la Web, 231
 - repaso del proceso, 190, 191
 - revisión de prueba, 225-230
 - y curva normal, 90
 - y evaluación asistida por computadora, 205-210
 - y formato del reactivo, 202-205, 206
 - y grupos de criterio, 359-362
 - y reserva de reactivos, 201-202, 226
 - y teoría, 356-357
 - y validez del contenido, 159
 - y varianza del error, 130
- Véase también Análisis de reactivos
- Descuido:** Descuido infantil es la omisión por parte del adulto “responsable” del cuidado del niño, de ejercer un grado de atención mínimo para proporcionarle al niño comida, vestido, casa, educación, cuidado médico, y supervisión; contrástese con *abuso*, 448-451
- Descuido infantil:** La omisión por parte del adulto responsable de un niño, de ejercer un mínimo grado de cuidado para proporcionarle comida, vestido, casa, educación, cuidado médico, y supervisión, 448-451
- Desempeño de tarea o prueba:** (1) En general, una muestra de trabajo diseñada para provocar la expresión de conocimientos representativos, habilidades, y valores de un dominio de estudio particular; (2) en escenarios de empleo, un instrumento o procedimiento que requiere que el evaluado demuestre ciertas habilidades o capacidades bajo condiciones idénticas o análogas a las que se presentan habitualmente en el trabajo, 329, 539-541, 542, 544
- Desequilibrio, 236
- Desórdenes alimenticios, 24
- Desplazado:** (1) El trazo de un punto extremadamente atípico en una gráfica de dispersión; (2) cualquier hallazgo extremadamente atípico en investigación, 119, 122
- Desviación de CI:** Una variedad de la puntuación estándar empleada para reportar “coeficientes de inteligencia” (CI) con una media establecida en 100 y una desviación estándar establecida en 15. En la prueba Stanford-Binet, es un resultado denominado coeficiente compuesto, y representa un índice de inteligencia derivado de una comparación entre el desempeño de un examinado individual y el desempeño de otros examinados de la misma edad en la muestra de estandarización de la prueba, 267, 275
- Desviación de la calificación,** 230
- Desviación estándar:** Es una medida de la variabilidad que se calcula mediante la raíz cuadrada de las desviaciones cuadradas promedios alrededor de la media; es decir, que la desviación estándar es una medida de la variabilidad igual a la raíz cuadrada de la varianza, 79-81, 83, 107n
- Desviación promedio:** Una medida de variación que se obtiene al sumar el valor absoluto de todos los registros en una distribución y dividir esta suma entre la cantidad total de registros, 78-79
- Detección:** Un proceso de evaluación relativamente superficial, basado en ciertos estándares, criterios o requerimientos mínimos; contrástese con *selección, clasificación y colocación*, 285, 463, 466-467, 536, 537-538
- Detector de mentiras (polígrafo), 413, 532
- Diagnostic and Statistical Manual of Mental Disorders IV (DSM-IV)* (Asociación Estadounidense de Psiquiatría), 64, 421-423, 428
- Diagnostic Psychological Testing* (Rapaport et al.), 436
- Diagnóstico:** Una descripción o conclusión a la cual se llega con base en evidencias y opiniones a través de un proceso de distinción de la naturaleza y reinando conclusiones alternativas, 20, 306, 421-423
- Diagrama de dispersión. Véase **Gráfica de dispersión**
- Dibuja a una persona (DAP), prueba, 397
- Dibuja a una persona: Procedimiento para detectar perturbación emocional (DAP: SPED), 398
- Dibujo Cinético de la Escuela (KSD), 398
- Dibujo Cinético de la Familia (KFD), 398
- Dictionary of Occupational Titles*, 526
- Diferenciación del autoconcepto:** El grado en el que un individuo tiene distintos autoconceptos para distintos papeles, 342
- Dificultades del lenguaje, 40-41, 355, 378, 431
- Dinamómetro, 67
- Directory of Unpublished Experimental Measures* (Goldman & Mitchell), 28
- Discapacidad cognoscitiva:** Una referencia general a un amplio espectro de condiciones de discapacidad, que incluyen varias deficiencias neurológicas, discapacidades para el aprendizaje o necesidades educativas especiales, autismo, y retraso mental, 495, 512-516
- Discapacidad intelectual, 495, 512-516
- Discapacidad:** Como se define en la Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades de 1990, es una deficiencia física o mental que limita de manera sustancial una o más de las actividades principales de vida de un individuo, 491-495. Véase también Discapacidades o necesidades educativas especiales, personas con
- Discapacidades auditivas, 495, 507-510, 517-518
- Discapacidades funcionales:** Una condición en la cual se ha interrumpido la capacidad para desempeñarse en cierta forma física, social, u otra manera característica, 495-496
- Discapacidades motoras, 511-512
- Discapacidades para el aprendizaje:** Un desorden que entraña la discrepancia entre capacidad y logros, la cual se manifiesta a través de deficiencias de atención, emocionales, perceptuales y/o motrices, y/o de problemas relacionados con la elaboración de cálculos matemáticos, la lectura, la escritura, la ortografía, o al usar o entender el lenguaje oral o escrito; no aplica a las personas con problemas académicos de origen económico o cultural, ni a personas con problemas de aprendizaje que surgen principalmente de desventajas visuales, auditivas, o motoras ni por retraso mental, 306
- Discapacidades viso/auditivas, 510-511
- Discapacidades visuales, 504-507
- Discapacidades, personas con, 490-519
- definiciones, 491-492, 494-496, 500-501
 - discapacidades auditivas, 495, 507-510
 - discapacidades cognoscitivas, 512-516
 - discapacidades motoras, 511-512
 - discapacidades viso-auditivas, 510-511
 - discapacidades visuales, 504-507
 - evaluación biopsicosocial, 516-517
 - problemas éticos, 53-54
 - recursos en la Web, 519
 - temas culturales, 507, 517-518
 - y acomodación, 496-500, 501, 505-506, 507-508, 511-512

- y discriminación en el trabajo, 500-504
y evaluación alterna, 4-5, 496
y evaluación preescolar, 300-301
y herramientas de evaluación psicológica, 14
- Discriminación**, 43, 185. *Véase también*
Temas culturales; Pertenencia a un grupo; Raza
- Distribución**: En un contexto psicométrico, una serie de puntuaciones de pruebas arreglada para registro o estudio, 68, 69-70, 72
curva normal, 70, 80, 83-86
normalización, 89, 90
y medidas de tendencia central, 74-77
y medidas de variabilidad, 77-81
- Distribución bimodal**: Una distribución en la cual, la tendencia central consiste en dos puntuaciones que ocurren una misma cantidad de veces, ambas son las que ocurren con más frecuencia en la distribución, 76
- Distribución de frecuencia agrupada**: Un resumen tabular de puntuaciones de prueba en la cual las calificaciones se agrupan por intervalos; también se le conoce como *intervalos de clase*, 69-70, 75
- Distribuciones de frecuencia**: Una lista tabular de puntuaciones junto con el número de veces que ha ocurrido cada puntuación, 69-70, 71, 72, 75
- DM. *Véase Desviación media*
- Dotado**: Después de P. Witty, desempeño que es constantemente notable en cualquier asunto valorado positivamente, 250-251, 252-253
- DQ. *Véase Cociente de deterioro*
- DSM-IV-TR**: Abreviatura del *Manual Diagnóstico y Estadístico de Trastornos Mentales*, Cuarta Edición, Texto Revisado, publicado en mayo de 2000, una versión ligeramente modificada del DSM-IV, que fue publicada en 1994. *Véase Diagnostic and Statistical Manual Of Mental Disorders IV*
- Dusky contra Estados Unidos*, 441-442
- Ecoencefalógrafo, 487
- ECSP (Proyecto de Estudio de Casos Excepcionales), 441
- Edad mental**: Un índice, ahora rara vez empleado, que se refiere a la edad cronológica equivalente al desempeño que uno logra en una prueba o subprueba. Se derivó con referencia a las normas indicativas de la edad en la cual la mayoría de los evaluados pueden aprobar o alcanzar el criterio de desempeño, 107, 244, 267
- EDI (Prueba sobre la Estructura del Intelecto), 253
- Editores de pruebas, 28. *Véase también*
Desarrollo de pruebas
- Educación asistida por computadora, 113
Educational and Psychological Measurement, 27
- EEG (electroencefalograma), 486
- EEOC (Comisión de Igualdad de Oportunidades para el Empleo), 47-48
- Efecto Barnum**: La consecuencia de creer que una vaga descripción de personalidad nos describe, cuando en realidad dicha descripción no es específica de alguien, sino de todos; a veces se le llama “Efecto Tía Fanny”, porque la misma personalidad se le podría aplicar a la tía de cualquiera de nosotros, 452, 454
- Efecto de contraste**: Una fuente potencial de error al calificar actitudes es la desigualdad en los comportamientos observados y otras cosas que conduce a una calificación todavía más desfavorable de lo que habría sido si tal desigualdad no existiera, 414, 416
- Efecto de halo**: Tipo de error de clasificación donde quien califica ve con buenos ojos al objeto de clasificación y tiende a inflar las puntuaciones en sentido positivo; así, en diversas circunstancias el resultado podría ser la favorable disposición a emitir calificaciones positivas e insuficientemente críticas, 184, 343
- Efecto de la tía Fanny. *Véase Efecto Barnum*
- Efecto de techo**: Un fenómeno o consecuencia que surge del hecho de que los reactivos en el extremo más alto o en el extremo más difícil de una prueba no son “suficientemente altos” o suficientemente difíciles para estimar de manera precisa la variable que se está midiendo en personas que se encuentran en ese extremo, 252
- Efecto Flynn**: “Inflación de la inteligencia”; el hecho de que la inteligencia medida usando un instrumento normado aumenta cada año después de que la prueba fue normada, usualmente en ausencia de cualquier diviendo académico, 251, 254
- El CI medio de los estadounidenses: ganancias masivas de 1932 a 1978 (Flynn), 251
- Elaboración de escalas absolutas**: Procedimiento desarrollado por L. L. Thurstone para obtener una medida de la dificultad de los reactivos entre las muestras de los examinados con diversas capacidades, 196
- Elaboración de escalas categóricas**: Un sistema para elaborar escalas en la cual los estímulos se colocan en una de dos o más categorías alternas que difieren cuantitativamente con respecto a una continuidad, 199
- Elaboración, 297
- Electroencefalograma (EEG), 486
- Electromiografía (EMG), 487
- Empaque, 555
- En riesgo**: Los diferentes distritos escolares lo definen de formas diversas, pero en general se refiere a un funcionamiento deficiente y que posiblemente requiera intervención, 301, 492
- Encuesta de Actitudes Escolares, 332
- Encuesta**: En psicología del consumidor, es una lista fija de preguntas que se plantean a una muestra seleccionada de personas, de manera usual para aprender sobre las actitudes, creencias, opiniones y/o comportamientos respecto de los productos, servicios o publicidad objetivo, 556-559
- Encuesta**: Un tipo de investigación que se emplea en forma habitual para registrar votos, y que contiene preguntas que pueden contestarse con una respuesta “sí/no” o “a favor/en contra”, común para estimar la opinión sobre problemas sociales, 556-559
- Encuesta de Actitudes y Métodos de Estudio, 333, 556
- Encuesta de Hábitos de Estudio y Actitudes (SSHA), 333
- Encuesta de Intereses Vocacionales de Jackson, 524
- Encuesta de Temperamento de Guilford-Zimmerman, 531
- Encuesta de Valores de Rokeach, 65
- Encuesta Percepto-Motora de Purdue, 512
- Encuestas en línea, 557
- Encuestas por correo, 558
- Encuestas telefónicas, 557-558
- Encyclopedia of Associations* (Hunt), 535
- Enfoque de muestras, 403. *Véase también*
Evaluación conductual
- Enfoque de signos, 402-403
- Enfoque de trabajo grupal autodirigido, 411
- Enfoque ideográfico**: Un enfoque a la evaluación caracterizado por los esfuerzos de aprender acerca de la constelación única de rasgos de personalidad de cada individuo, sin tratar de caracterizar a cada persona de acuerdo con ninguna serie particular de rasgos; contrástese con *nomotético*, 353
- Enfoque normativo, 353
- Enfoques análogos, 410-412, 437
- English Men of Science* (Galton), 247
- Entrevista**: Una herramienta de evaluación en la cual la información se recolecta mediante la comunicación directa y recíproca, 423-434
- cuestiones culturales, 429-434
- repaso, 8-10
- tipos de, 424-427
- y evaluación del empleo, 538-539
- y evaluación neuropsicológica, 466-467

- y psicología del consumidor, 557
y psicometría, 428-429
- Entrevista bajo hipnosis:** una entrevista que se realiza después de haber inducido un estado hipnótico en el entrevistado, en su mayoría en un esfuerzo por mejorar la concentración, la atención, imágenes, y recuerdos, 425
- Entrevista clínica estructurada para trastornos disociativos (SCID-D), 424
- Entrevista cognitiva:** Un tipo de entrevista hipnótica sin la inducción hipnótica; se estimula al entrevistado a que use la imaginación y a que se enfoque en los recuerdos de información, 425
- Entrevista de estrés:** Una entrevista diseñada a propósito para presionar o estresar al entrevistado y así estimar la reacción a dicho estrés, 424-425
- Entrevista en colaboración, 425
- Entrevista estructurada de síntomas reportados (SIRS), 424
- Entrevista estructurada:** Preguntas hechas a partir de una guía con poca, o ninguna, libertad para desviarse de ella, 348, 380
- Entrevistas de consejo. *Véase* Entrevistas de panel
- Entrevistas de panel, 8-9
- Entrevistas telefónicas, 8
- EPPS (Programa de Preferencias Personales de Edwards), 210-211, 350, 531
- Equipo:** Dos o más personas que actúan en forma interdependiente hacia una meta en común, a quienes se ha asignado papeles o funciones específicos, 547
- ERIC (Centro de Información de Recursos Educativos), 27
- Error:** Colectivamente, todos los factores diferentes del que la prueba pretende medir, que contribuyen a los puntos de una prueba; el error es una variable en todas las pruebas de evaluación, 63-64, 96-97
y confiabilidad, 129, 140
y escalas de validez, 354-355
y medidas de autorreportes, 342-343, 354, 362-363
y pruebas de fármacos, 543-544
y regresión, 123-124
Véase también **Varianza del error;** **Confiabilidad**
- Error de estimación:** Un juicio que resulta del mal uso intencional o no intencional de una escala de puntuación; dos tipos de errores de puntuación son: de lenidad (o error de generosidad) y error de severidad, 183-184, 343-344, 354
- Error de generosidad:** Clasificación o calificación no precisa debido a que el evaluador tiene la tendencia general de ser poco severo o insuficientemente crítico; también se le conoce como *error de indulgencia*; contrástese con *error de severidad*, 183-184, 343
- Error de lenidad:** También se le llama *error de generosidad*, un error de clasificación que ocurre como resultado de la tendencia general del evaluador a ser demasiado condescendiente y poco crítico, 183-184, 343
- Error de severidad:** Puntaje o error impreciso en la evaluación debido a la tendencia del evaluador a ser demasiado crítico; contrástese con *error de generosidad*, 184, 343
- Error de tendencia central:** Calificación o evaluación poco menos que precisa hecha por un calificador o juez, debido a la tendencia general del juez a emitir calificaciones cercanas o en el punto medio de la escala; contrástese con *error de generosidad* y *error de severidad*, 184, 343
- Error de tendencia central:** Error de clasificación; la persona que califica en general se muestra renuente a emitir puntuaciones extremas ya sean positivas o negativas, por lo cual la mayoría de las nubes de puntos se encuentran en la parte media del continuo de clasificación, 184, 343
- Error estándar de estimación:** En una regresión, un estimado de la magnitud del error; mientras más bajo sea el grado de correlación, será más grande el error estándar de la estimación, 123-124
- Error estándar de la diferencia:** Una estadística diseñada para ayudar a determinar qué tan grande debe ser una diferencia entre dos registros, antes de que se considere significativa estadísticamente, 152-154
- Error estándar de una medición:** En la teoría de la puntuación verdadera, es una estadística que sirve para estimar el grado al cual una puntuación observada se desvía de la puntuación verdadera; también denominada el *error estándar de una puntuación*, 149-152
- Error estándar de una puntuación. *Véase* **Error estándar de una medición**
- Error pasajero, 141
- Escala:** (1) Un sistema de descriptores numéricos o verbales ordenados, que generalmente ocurren a intervalos fijos, usado como referencia estándar en medición; (2) un conjunto de números u otros símbolos cuyas características modelan propiedades empíricas de los objetos o rasgos a los cuales se asignan números u otros símbolos, 63. *Véase también* **Medición;** **Creación de escalas**
- Escala africana de autoconocimiento, 371
- Escala Binet-Simon, 265, 285
- Escala Bracken de conceptos básicos-revisada, 513
- Escala Callier-Azusa (CAS), 511
- Escala de aculturación asiática de autoidentidad Suinn-Lew, 371
- Escala de aculturación multicultural, 371
- Escala de aculturación para niños, 371
- Escala de alcoholismo de MacAndrew (MAC-R), 436
- Escala de asimilación de indios, 371
- Escala de autoconcepto de Piers-Harris, 342
- Escala de búsqueda de sensaciones (SSS), 93
- Escala de búsqueda de sensaciones sexuales, 341
- Escala de calificación de aculturación para mexicanoamericanos, 371
- Escala de calificación o puntuación estándar normalizada:** En forma conceptual, es el resultado final de “estirar” una curva de distribución sesgada y ajustarla dentro de la curva de distribución normal, lo usual es mediante una transformación no lineal, 90
- Escala de capacidad social para niños preescolares invidentes de Maxfield-Bucholz, 506
- Escala de causalidad de enfermedad, 220
- Escala de cultura hawaiana—versión para adolescentes, 371
- Escala de deterioro neuropsicológico, 466
- Escala de edad:** Una prueba con reactivos organizados de acuerdo con la edad en la cual se considera que la mayoría de los que responden las pruebas es capaz de responder en la forma identificada como correcta; contrástese con *escala de puntos*, 268
- Escala de estimación de autismo infantil, 513
- Escala de estimación del comportamiento adolescente de Devereaux, 510
- Escala de estimación del comportamiento infantil de, 510
- Escala de estimación:** Un sistema de descripciones numéricas o verbales ordenado, con base en el cual los evaluadores, jueces, examinadores hacen sus juicios sobre la presencia/ausencia o magnitud de un rasgo, actitud, emoción u otra variable particular, cuando la escala de puntuación refleja una autoevaluación, los evaluados pueden realizar sus propios juicios 183, 197-198, 301, 302, 407-408
- Escala de Evaluación de Responsabilidad Criminal (RCRAS), 444
- Escala de Guttman:** Nombrada así por quién la desarrolló, una escala en la cual los reactivos oscilan de manera secuencial de expresiones débiles a fuertes de la actitud o creencia que se mide, 199-200

- Escala de inestabilidad de meta, 536
- Escala de Inteligencia Infantil de Cattell (CIIS), 34
- Escala de inteligencia Wechsler-Bellevue, 38, 244-245, 275-276, 278
- Escala de intervalos:** Un sistema de medición en el cual todas las cosas que se miden pueden ordenarse por categorías, donde el orden de categorización contiene intervalos iguales; cada unidad en la escala es igual a cualquiera de todas las demás unidades de la escala, y no hay punto de cero absoluto; podrían no realizarse operaciones matemáticas en los datos de nivel de intervalo debido a la ausencia de un punto de cero absoluto o verdadero, 66, 67-68
- Escala de Potencial Adictivo (APS, Addiction Potential Scale), 436-437
- Escala de razón:** Un sistema de medición en el que lo que se mide puede ordenarse por rango; este orden implica qué tan superior es un rango en comparación con otro. Existen intervalos iguales entre cada número en la escala, y todas las operaciones matemáticas son significativas porque existe un punto cero verdadero o absoluto. En psicología o educación existen pocas variables en esta escala. 66, 67
- Escala de Reconocimiento de Adicción (AAS, Addiction Acknowledgment Scale), 437
- Escala de satisfacción con el tiempo libre, 536
- Escala de Satisfacción Matrimonial (MSS), 176-177, 178, 179
- Escala de validez:** Subescala de una prueba diseñada para apoyar en la elaboración de juicios sobre el grado de honestidad con que respondieron los examinados y si las respuestas observadas fueron el producto de series de respuestas, sin importar los esfuerzos deliberados de engañar, o el mal entendido no intencional, 347, 354-355, 362-363
- Escala de valores asiáticos, 371
- Escala Likert:** Adquiere el nombre de su autor, una escala de calificación sumatoria con cinco alternativas de respuesta, lo más habitual en un rango continuo, por ejemplo, de “totalmente de acuerdo” a “totalmente en desacuerdo”, 198
- Escala ordinal:** Un sistema de medición en el cual todas las cosas que se miden pueden ordenarse por clasificaciones, donde las clasificaciones no implican nada sobre cuánto mayor es una clasificación que otra exactamente, y no existe un punto cero absoluto en la escala; la mayoría de las escalas usadas en psicología y educación son ordinales, 65-67
- Escala por puntos:** Una prueba con reactivos organizados por subpruebas por categoría de reactivo; contrátese con *escala de edad*, 268, 275
- Escala Revisada de Comportamientos Moralmente Debatibles (MDBS), 197-198
- Escala social, de actitudes, familiar y ambiental acumulativa de estrés, 371
- Escala sumatoria:** Índice derivado de la suma de puntuaciones de una prueba o subprueba, 198
- Escala Tennessee de autoconcepto, 342
- Escala Vineland de Comportamiento Adaptativo (VABS), 514-515
- Escala Vineland de Madurez Social, 514
- Escala Wechsler de Inteligencia para adultos (WAIS), 275-279
- aspectos culturales, 260
- desarrollo de, 35-36
- y evaluación neuropsicológica, 469-470
- confiabilidad, 151-152
- forma corta, 284-285
- Escala Wechsler de Inteligencia para Adultos, 278
- Escala Wechsler de Inteligencia para niños (WISC), 279-282
- aspectos culturales, 38, 39-40
- muestreo normativo, 104-105
- revisión de, 229-230
- Escala Wechsler de Inteligencia Preescolar y Primaria (WPPSI), 282-284, 302
- Escala Wechsler de Memoria (WMS), 276, 480-481
- Escalas Bayley para el Desarrollo Infantil (BSIO), 143-144
- Escalas comparativas:** En el desarrollo de pruebas, un método para desarrollar escalas ordinales a través del uso de tareas de clasificación que implique el juicio de un estímulo en comparación con cualquier otro estímulo usado en la prueba, 199
- Escalas complementarias, 364
- Escalas continuas, 63, 64
- Escalas de calidad de vida en la escuela, 332
- Escalas de Capacidades Diferenciales (DAS), 86, 324-327
- Escalas de atractivo social (SD), 354
- Escalas de diagnóstico de lectura, 320
- Escalas de Habilidades Británicas (BAS), 324
- Escalas de Harris, 364
- Escalas de identificación occidental y contrato intercultural, 371
- Escalas de inteligencia Stanford-Binet, 265-273
- aspectos culturales, 38, 39
- contra Escala Wechsler de inteligencia para niños, 281-282
- evaluación preescolar, 302
- normas de edad, 107
- orígenes de, 265
- procedimientos de administración, 270-272
- Prueba Diagnóstica de Lectura de Stanford (SDRT), 320, 321
- Prueba Diagnóstica de Matemáticas de Stanford (SDMT), 320, 321
- psicometría, 152, 269-270
- Escalas discretas, 63
- Escalas nominales:** Un sistema de medición en el cual todas las cosas medidas se clasifican o categorizan con base en una o más características distintivas y que se colocan en categorías mutuamente excluyentes y exhaustivas, 64-65
- Escalas ocupacionales de personalidad enfocadas en el criterio (COPS), 532
- Escalas preceptuales de Bricklin (BPS), 101
- Escalas Revisadas de Medición de Connors (CRS-R), 301
- Escalas Wiggins de Contenido, 363-364
- Escaneo PET (tomografía por emisión de positrones), 486
- Escaneo por tomografía computarizada de emisión simple de fotones (SPECT), 486
- Escaneo por tomografía con emisión de positrones (PET), 486
- Escaneo SPECT (tomografía computarizada de emisión simple de fotones), 486
- Escenarios institucionales, 11. *Véase también* Evaluación clínica/orientación; Evaluación educativa; **Evaluación psicológica forense**
- Escuela de escala del comportamiento adaptativo: 2 (Adaptive Behavior Scale-School: 2, ABS-S: 2), 514
- Escuela de Texas para Personas con Ceguera y Debilidad visual, 506
- Escuelas. *Véase* Evaluación educacional
- Esquema:** En la teoría piagetiana, una acción o estructura mental que, cuando se aplica, conduce a saber o comprender, 236
- Esquemas:** El plural de *esquema*; como en la teoría piagetiana, “los niños nacen con muchos esquemas simples, incluyendo chupar y asir”, 236
- Estabilidad, coeficiente. *Véase* Coeficiente de estabilidad
- Estadísticas de adecuación, 290
- Estadísticas, 62-91
- curtosis, 82-83
- curva normal, 83-86
- distribuciones, 68, 69-70, 72
- escalas de medición, 63-68
- gráficas, 70, 71-73
- medidas de la tendencia central, 74-77, 83-84
- medidas de variabilidad, 77-81
- puntuaciones estándar, 86-90
- recursos en la Web, 91
- sesgo, 81-82

- Estado de conciencia, 425
- Estado de personalidad. Véase **Estado**
- Estado:** Como en *estado de personalidad*, (1) la exhibición transitoria de un rasgo, indicativa de una predisposición relativamente temporal a comportarse de una manera en particular (2) en la teoría psicoanalítica, una disposición psicodinámica inferida diseñada para comunicar la calidad dinámica del *id*, *ego* y *superego* en conflicto perpetuo, 92, 339-340
- Estadounidenses nativos, 257
- Estándar ALI:** Estándar de demencia legal del American Law Institute, de acuerdo con el cual una persona no es responsable de un acto delictivo, si al momento de ese comportamiento, como resultado de una enfermedad o defecto mental, carece de la capacidad sustancial ya sea para apreciar la criminalidad (ilegalidad) de su conducta o para conformar su conducta a los requerimientos de la ley; contrástese con el *estándar Durham* y el *estándar M'Naghten*, 444
- Estándar Durham:** *Durham contra Estados Unidos* en el cual el defendido no es encontrado culpable de delito debido a que el acto ilegal fue producto de una enfermedad o problema mental; contrástese con *Estándar ALI* y *Estándar M'Naghten*, 444
- Estándar M'Naghten:** Un estándar (ya sustituido) de demencia que depende de si un individuo reconoce el bien del mal al momento de cometer un acto criminal; también se le conoce como la prueba de insanidad mental "correcto o incorrecto"; contrástese con el *Estándar de Durham* y el *Estándar de ALI*, 444
- Estandarización:** Un proceso de desarrollo de pruebas donde se administra la prueba a una muestra representativa de evaluados bajo condiciones claramente especificadas, y los datos se registran e interpretan para establecer un contexto para futuras administraciones de la prueba con otros evaluados, 103, 226. Véase también *Muestras de estandarización*
- Estanueve:** Un puntaje estándar derivado de una escala con una media de 5 y una desviación estándar de aproximadamente 2, 88
- Estilo de respuesta:** Una tendencia a responder a un reactivo de una prueba o pregunta de entrevista en alguna forma característica sin importar el contenido; por ejemplo, un estilo de respuesta aquiescente (una tendencia a estar de acuerdo) y un estilo de respuesta deseable socialmente (una tendencia a presentarse en una forma favorable o deseada socialmente), 346-347
- Estrategias de salida, 536
- Estudio análogo:** Investigación o intervención conductual que comienza por hacer una réplica de la variable o variables de manera similar a, o análoga a, la variable real de interés para el investigador; por ejemplo, un estudio de laboratorio diseñado para investigar la fobia a las serpientes en su hábitat, 410-411
- Estudio Campbell de Intereses y Habilidades, 524
- Estudio de decisión:** Se realiza al final de un estudio de generalización, esta investigación está diseñada para explorar la utilidad y el valor de puntuaciones de pruebas en cuanto a la toma de decisiones, 148, 149
- Estudio de generalización:** En el contexto de la teoría de la generalización, investigación que tiene como propósito explorar el impacto de diferentes facetas del universo en la calificación de una prueba, 148-149
- Estudio de la Frustración a través de Ilustraciones de Rosenzweig, 390
- Estudio de Progreso Gerencial (MPS), 540, 541, 542
- Estudio de validación:** Investigación que implica reunir la evidencia relevante a qué tan bien mide una prueba lo que se supone que debe medir para el propósito de evaluar la validez de una prueba u otra herramienta de medición, 157
- Estudio Kuder de Intereses Ocupacionales (KOIS), 524
- Estudios de validación local:** El proceso de recolectar evidencia relevante a qué tan bien mide una prueba lo que pretende medir, con el propósito de evaluar la validez de una prueba u otra herramienta de evaluación, típicamente realizada en conjunto con una población diferente de la población para la cual la prueba fue validada originalmente, 157
- Estudios gemelos, 248
- Estudios mediante intercepción en centros comerciales, 557
- Estudios para la adopción, 248
- Ethical Principles of Psychologists and Code of Conduct* (APA), 57-58
- Ethical Standards for the Distribution of Psychological Tests and Diagnostic Aids* (APA), 52
- Ética:** Un cuerpo de principios de conducta correcta, apropiada o buena; contrástese con *leyes*, 45. Véase también *Cuestiones éticas*
- ETS (Servicio de Pruebas Educativas), 28
- Eugenesia, 38, 247-248
- Evaluación ACT, 316
- Evaluación alterna:** Un proceso o procedimiento de evaluación o diagnóstico que varía de la forma usual, acostumbrada o estandarizada de medición que se deriva, de cierta acomodación especial realizada al sujeto que se evalúa o con métodos alternos diseñados para medir la(s) misma(s) variable(s), 4-5, 496
- Evaluación auténtica:** También se le conoce como evaluación basada en el desempeño, la evaluación en tareas relevantes y significativas que pueden llevarse a cabo para examinar el aprendizaje de materias académicas pero que demuestra la transferencia que hace el estudiante de dicho estudio a las actividades del mundo real, 330-331
- Evaluación biopsicosocial, 516-517
- Evaluación con base en el currículo (CBA):** Un término general que se refiere a evaluaciones que tienen como base evaluaciones escolares que reflejan con claridad o credibilidad lo que se está enseñando, 311, 316
- Evaluación con base en el desempeño. Véase *Evaluación auténtica*; *Evaluación del desempeño*
- Evaluación con normas de referencia:** Un método de evaluación y una forma de derivar un significado de las calificaciones de una prueba mediante la evaluación de las puntuaciones individuales de un evaluado, en comparación con las de un grupo de evaluados; las calificaciones de una prueba se entienden en relación con otras de la misma prueba; contrástese con *interpretación con referencia a un criterio*, 99, 102-114
- aspectos culturales, 126-127
- desarrollo de pruebas, 192, 193
- muestras, 102, 103-106
- revisión de prueba, 226
- sistemas de grupo de referencia fija, 109-110
- tipos de normas, 106-109
- vs. prueba y evaluación con referencia a un criterio, 110, 113-114
- Evaluación conductual:** Un enfoque de una evaluación basado en el análisis de muestras de comportamiento, incluyendo los antecedentes y consecuencias del comportamiento, 402-416
- automonitoreo, 402, 408-410
- enfoques análogos, 410-412, 437
- evaluados, 404
- medidas no obstructivas, 413-414, 415
- métodos psicofisiológicos, 412-413
- observación conductual, 10-11, 402, 407-409, 410-411, 431, 562

- problemas en, 414, 416
 propósitos de, 405-406
 usuarios de pruebas, 404-405
versus evaluación tradicional, 402-404
 y psicometría, 406-407
- Evaluación de baterías cruzadas:** Emplea baterías de pruebas en las cuales se contrasta la interpretación de cada una de ellas para proporcionar una información completa, 241
- Evaluación de empleo, 22, 537-553
 actitud, 551-552
 cultura organizacional, 552-553, 554-555
 entrevistas, 538-539
 motivación, 547-551
 portafolios, 539
 problemas legales, 47, 49, 160
 productividad, 545-547
 pruebas de desempeño, 539-541, 542, 544
 pruebas físicas, 541-544
 pruebas de integridad, 532
 y confiabilidad, 150, 154
 y materiales de aplicación, 537-538
 y medidas de capacidad cognoscitiva, 544-545
 y membresía a un grupo, 43
 y personas con discapacidad, 500-504
 y validez de contenido, 159-160
 y validez descriptiva, 167-171, 173-175
Véase también Orientación vocacional
- Evaluación de habilidades sociales, 131, 132
- Evaluación de la prueba, 100-102
- Evaluación de los Niveles de Desarrollo por Observación (ADLO), 511
- Evaluación de Niveles de Desarrollo por la Observación, 511
- Evaluación de personal. *Véase* Evaluación para el empleo
- Evaluación de personalidad:** La medición y evaluación de rasgos y estados psicológicos, valores, intereses, actitudes, visión del mundo, aculturación, sentido de identidad personal, sentido del humor, estilos cognitivos y de comportamiento, y características individuales relacionadas, 335-375
 alcance de, 347-348
 aplicaciones de, 340-341
 aspectos culturales, 345, 355, 369-374, 430-431
 aspectos legales, 47, 49
 contenido de, 345-346, 356
 enfoque actuarial, 417-418
 error en, 354-355
 escenarios de, 347, 405
 estilos de respuesta, 346-347
 evaluados, 341-345, 404
 formatos de reactivo, 349, 350-351
 grupo de criterio, 359-362
 interpretación de calificaciones, 352-353, 364-365, 381-382
 marco de referencia, 349-352
- métodos de reducción de datos, 357-359
 definiciones, 335-340
 métodos objetivos, 376-377
 orientación vocacional, 531-534
 personas con discapacidades, 506, 509
 perspectiva histórica, 36-37
 pertenencia a un grupo, 43
 procedimientos de administración, 348-349, 364, 380-381, 386-387
 ramificación de reactivo, 210
 recursos en la Web, 375, 418
 teoría, 348, 356-357
 varianza de error en, 131
Véase también **Evaluación conductual;**
Método proyectivo
- Evaluación del desempeño:** Una evaluación de las tareas desempeñadas de acuerdo con un criterio elaborado por expertos en la materia de estudio, 329-330, 539-541, 542, 544
- Evaluación del programa, 23
- Evaluación del salón de clases. *Véase* Evaluación educativa
- Evaluación diagnóstica de personas con discapacidades severas-II, 513
- Evaluación educativa, 20-21, 305-334
 aprecio de los compañeros, 331-332
 baterías de pruebas psicoeducativas, 298, 321-329
 evaluación auténtica, 330-331
 evaluación del desempeño, 329-330
 evaluación psicoeducativa, 241
 portafolios, 330
 pruebas de aptitudes, 311-318, 319
 pruebas de diagnóstico, 318-321
 pruebas de rendimiento, 20, 305-311, 312, 509
 pruebas en el salón de clases, 195-196
 pruebas grupales de inteligencia, 295-296
 puntuación estandue en, 88
 recursos en la Web, 333-334
 y evaluación clínica/orientación, 421
 y normas de grado, 107-108
 y pruebas con referencia a un criterio, 193
 y ramificación de reactivos, 206, 210
 y sesgo, 182-183
 y validez de contenido, 159
- Evaluación formal: Una evaluación típicamente sistemática, “en grabación” que lleva a un diagnóstico, opinión, o recomendación para una intervención u otro curso de acción, llevado a cabo por una persona calificada en un contexto no oficial y sujeto a estándares éticos y profesionales; contrástese con *evaluación informal*, 303
- Evaluación geriátrica, 21
- Evaluación Humana* (OSS), 2
- Evaluación infantil, 302-303. *Véase también* Evaluación preescolar
- Evaluación informal:** Una evaluación típicamente no sistemática, relativamente breve, y “confidencial” que lleva a la formación de una opinión o actitud, llevada a cabo por cualquier persona, de cualquier forma y por cualquier motivo, en un contexto no oficial y no sujeto a la misma ética o estándares que la evaluación realizada por un profesional; contrástese con *evaluación formal*, 20-21, 303
- Evaluación Multiaxial Basado Empíricamente, 345
- Evaluación neuropsicológica, 458-489
 baterías de pruebas, 482-485
 entrevistas, 466-467
 examen físico, 467-469
 obtención de la historia clínica, 464-466
 pruebas de funcionamiento verbal, 477-478
 pruebas de la función ejecutiva, 471-472
 pruebas de la memoria, 478-481
 pruebas de pensamiento abstracto, 470-471
 pruebas perceptuales, 474-477
 recursos en la Web, 488-489
 vista general del proceso, 462-464
 y auxiliares médicos para el diagnóstico, 486-487
 y daño neurológico, 459-462
 y estructura del sistema nervioso, 458- 459
 y personas con discapacidades, 506
 y pruebas de inteligencia, 469-470
- Evaluación/orientación clínica, 21-22, 419-457
 adicción/abuso de sustancias, 436-438
 datos históricos del caso, 434-435
 abuso/descuido infantil, 448-451
 temas culturales, 429-434
 evaluaciones sobre la custodia, 446-448
 y diagnóstico, 421-423
 evaluación psicológica forense, 438-446
 y cuidado dirigido, 421
 repaso, 419-421
 y reportes psicológicos, 451-456
 y pruebas psicológicas, 435-436
 y psicometría, 428-429
 recursos en la Web, 457
Véase también Entrevista
- Evaluación preescolar, 300-305
- Evaluación psicoeducacional:** evaluación: Evaluación psicológica en una escuela u otro escenario, hecha por lo general para diagnosticar, remediar o medir el progreso académico o social o, de otra manera, enriquecer la educación de un estudiante, 241
- Evaluación psicológica asistida por computadora, (CAPA), 12-14, 15
 y evaluación clínica/orientación, 455
 problemas éticos, 54, 57
 y desarrollo de la prueba, 205-210
- Evaluación psicológica culturalmente informada:** un enfoque de la

- evaluación que es intensamente perceptiva y responsable ante cuestiones de aculturación, valores, identidad, visión del mundo, lenguaje, y otras variables relacionadas con la cultura que pueden afectar el proceso de evaluación o la interpretación de los datos resultantes, 127, 430-434. Véase también Temas culturales
- Evaluación psicológica dinámica, 4
- Evaluación psicológica en colaboración, 4
- Evaluación psicológica forense:** La teoría y aplicación de la evaluación y dirección psicológica en un contexto legal, 23, 438-446
- competencia para someterse a juicio, 440-443
- corresponder al perfil, 339n
- daño emocional, 445-446
- liberación de prisión, 444-445
- peligrosidad, 439, 440-441
- responsabilidad criminal, 443-444
- Evaluación psicológica terapéutica, 4
- Evaluación psicológica:** La reunión e integración de datos psicológicos para su evaluación, mediante el uso de pruebas, entrevistas, estudios de caso, observación conductual, y aparatos diseñados especialmente, así como procedimientos de medición para su evaluación; contrástese con **pruebas psicológicas**
- definida, 2-3
- participantes en, 16-20
- proceso de, 4
- preparaciones para, 20-23, 347, 405
- Psychological Assessment*, 27
- Psychological Assessment* (Maloney & Ward), 2
- Evaluación relacionada con negocios, 22
- psicología del consumidor, 554-563
- recursos en la Red, 564-565
- Véase también Orientación vocacional; Evaluación para el empleo
- Evaluación vocacional. Véase Evaluación para el empleo
- Evaluaciones de custodia del niño, 100-102, 446-448
- Evaluaciones de la custodia, 100-102, 446-448
- Evaluadores. Véase *Confiabilidad entre evaluadores*; *Subjetividad*; *Usuarios de pruebas*.
- Evaluados, 18
- comportamiento fuera de la prueba, 272-273
- derechos de, 57-60
- ensayo de la prueba, 211-212
- y análisis cualitativo del reactivo, 222-224
- y validez aparente, 158
- y varianza del error, 96
- Evidencia convergente:** Con referencia a la validez de un constructo, datos de otros instrumentos de medición diseñados para medir el mismo constructo u otro similar al de la prueba que se está validando, los cuales todos señalan hacia un mismo juicio o conclusión con respecto de una prueba u otra herramienta de medición; contrástese con *evidencia discriminatoria*, 179
- Evidencia discriminante:** Con referencia a la validez de constructo, datos de una prueba u otro instrumento de medición que muestran poca relación con las puntuaciones u otras variables de la prueba a partir de las cuales las puntuaciones con las que se validó el constructo no deben ser correlacionadas teóricamente; contrástese con *evidencia convergente*, 179
- Examen Comprensivo de Afasia del Centro Neurosensorial (NCCEA), 485
- Examen de Admisión para las Escuelas de Enfermería (RNEE), 319
- Examen de Aprendizaje Básico para Adultos (ABLE), 310-311
- Examen de calificación para pilotos, 292
- Examen de Registro para Graduados (GRE), 88, 110, 111-112, 313, 316-317
- Examen del estado mental:** Una entrevista y observación especializada que permite detectar déficits intelectuales, emocionales o neurológicos al ir explorando aspectos del entrevistado como la apariencia, comportamiento, memoria, afecto, estado de ánimo, juicio, personalidad, contenido de pensamientos, procesos de pensamiento, y estado de conciencia, 426-427, 467
- Examen Minnesota de Actitudes del Maestro, 556
- Examen Multilingüístico de la Afasia, 478
- Exámenes del Servicio Civil (China), 31-32
- Exámenes físicos, 467-469
- Fábrica de Llantas Kumho contra Carmichael*, 503
- Faceta:** En la teoría de la generalización, variables de interés en el universo incluyendo, por ejemplo, el número de reactivos de una prueba, el nivel de entrenamiento que han tenido los calificadores de la prueba, y el propósito de la administración de la prueba, 148
- Factor G:** En los dos factores de la inteligencia de Spearman, el factor general de inteligencia; el factor que se mide en mayor o menor grado por todas las pruebas de inteligencia; contrástese con *s* y *factores agrupados*, 237, 240, 241, 244, 278, 282
- Factor S:** En la teoría bifactorial de inteligencia de Spearman, un componente específico del factor general *g*, como una habilidad específica; contrástese con *g* y con *factores agrupados*, 237
- Factores agrupados:** De acuerdo con Spearman, factores comunes a un grupo de actividades que indican inteligencia, tal como capacidades lingüísticas, mecánicas, o aritméticas, 237-238
- Factores de autoselección, 165
- Factores de la personalidad Tres Grandes, 531
- Factores fantasma, 211
- Falso negativo:** (1) En el contexto general de la calificación errónea de una prueba, una predicción incorrecta de clasificación que indica que un examinado no posee un rasgo u otro atributo de los que se están midiendo cuando en la realidad el examinado sí la posea; (2) en pruebas de drogas, un individuo califica negativo en la prueba de uso de drogas cuando en realidad ha usado drogas, 171, 174, 543-544
- Falso positivo:** (1) En el contexto general de una calificación errónea de una prueba, una predicción o clasificación incorrecta que indica que un examinado posee un rasgo u otro atributo de los que se están midiendo cuando en realidad el examinado no lo posee; (2) en la prueba de drogas, un individuo califica positivo al uso de drogas cuando en realidad no ha consumido drogas, 171, 174, 543-544
- Fatalismo, 516
- Finding Information About Psychological Tests* (APA), 28
- Flexibilidad, 297
- Fluidez, 297
- Forma corta, 284-285
- Formación reticular, 459
- Formas alternas:** Diferentes versiones de la misma prueba o medida; contrástese con *formas paralelas*, 134
- Formas paralelas:** Existen dos o más versiones de la misma prueba cuando, para cada forma del examen, las medias y las varianzas de las puntuaciones de la prueba observada son iguales; contrástese con *formas alternas*, 134
- Formato de caballete doble, 304
- Formato de caballete, 304
- Formato de construcción de respuesta:** una forma de reactivo de prueba que requiere que el examinado elabore o construya una respuesta, contrario a la simple selección de una respuesta. Reactivos en un examen de ensayo, de completar el espacio, y de respuesta breve son ejemplos de reactivos en un

- formato de construcción de respuesta; contrástese con *formato de selección de respuesta*, 202
- Formato de lista de verificación de adjetivos, 350, 352, 415
- Formato de opción múltiple, 202
- Formato de reactivos, 202-203
- Formato de selección de respuesta:** Una forma de reactivo de prueba que requiere que los evaluados seleccionen una respuesta, en oposición a crear una; por ejemplo, verdadero-falso, opción múltiple, relación de reactivos; contrástese con *formato de respuesta construida*, 202
- Formato de selección forzada:** Un tipo de reactivo a veces empleado en pruebas de personalidad donde una de cada dos o más opciones se ha determinado que sea igual en deseabilidad social, 350
- Formato del reactivo:** Se refiere a la forma, el plan, estructura, arreglos o disposición física que tendrán los reactivos individuales en la prueba, incluso, si la respuesta a los reactivos implicará que los examinados seleccionen una de las alternativas existentes o que construyan su respuesta, 202-205, 206, 349, 350-351
- Formato:** Una referencia general a la forma, plan, estructura, arreglo, o disposición física de los reactivos de una prueba así como de consideraciones relacionadas tales como límites de tiempo para la administración de la prueba, 6. Véase también **Reactivo, formato de**
- Formatos de solicitud, 537
- Fórmula de calificaciones, 221
- Fórmula de Spearman-Brown:** Una ecuación usada para estimar la confiabilidad en la consistencia interna de una correlación de dos mitades de una prueba que se ha alargado o acortado; inapropiada para usarse con pruebas heterogéneas o de velocidad, 119, 135-136, 145, 146
- Fórmulas de Kuder-Richardson:** Serie de ecuaciones elaborada por G. F. Kuder y M. W. Richardson para estimar la consistencia entre reactivos de las pruebas, 137-138, 139, 145
- Frase incompleta, 393
- Frases Incompletas en Blanco de Rotter, 351, 393-394
- Frecuencia, registro de (evento), 405
- Freud, Sigmund, 55, 383. Véase Teoría psicoanalítica
- Frye contra Estados Unidos, 502, 503
- Fuentes de referencia, 26-29
- Funcionamiento auditivo, 474-475
- Funcionamiento premórbido, 420
- Funciones ejecutivas:** En neuropsicología, flexibilidad cognoscitiva para organizar y planear, inhibición de impulsos, y otras actividades asociadas con los lóbulos frontal y prefrontal del cerebro, 471- 472
- Galton, Francis, 33, 34, 116, 234-235, 244, 247
- GATB (Batería de Pruebas de Aptitudes Generales), 525-531
- Gauss, Karl Friedrich, 83
- Gc. Véase **Inteligencia cristalizada**
- GCA (capacidad conceptual general), 324
- GCMS, prueba (cromatográfica de gas/ Espectrométrica de masa), 543
- General Electric vs. Joiner*, 503
- Género
- Batería de Pruebas de Aptitudes Generales (GATB), 525-531
- e inteligencia, 254
- y error de clasificación, 184
- y métodos proyectivos, 397n
- y orientación vocacional, 522
- y varianza de error, 132
- Gesell, Arnold, 246-247
- Gf Véase **Inteligencia fluida**
- GF-Gc:** Inteligencia fluida y cristalizada como la describe el modelo Cattell-Horn, los tres estratos de Carroll, y otros modelos, 239
- Gilmore, Gary, 440-441
- GIS (Sistema de Guía de Información), 524
- Goddard, Henry H., 38, 247-248
- Goldstein, Kurt, 460
- Graduate Record Examination Psychology*, 317
- Gráfica: Un diagrama o tabla compuesta de líneas, puntos, barras, u otros símbolos para describir o ilustrar datos, 70, 71-73, 118-122, 167, 168, 217-219
- Gráfica de barras:** Una ilustración gráfica de datos donde los números que indican la frecuencia, ocupan el eje vertical, las categorías ocupan el eje horizontal, y las barras rectangulares que describen los datos suelen tener separaciones entre sí, 70, 71
- Gráfica de dispersión:** También se le conoce como *diagrama de dispersión*, una gráfica descriptiva de la correlación alcanzada al graficar los puntos coordinados de las dos variables, 118-122, 167, 168
- Gráfica de expectativas:** Representación gráfica de una tabla de expectativas, 167
- GRE (Examen de Registro para Graduados), 88, 110, 111-112, 313, 316-317
- Griggs contra Duki Power Company*, 48
- Grupo criterio:** Un grupo de referencia constituido por personas que comparten características y cuyas respuestas a la prueba sirven como un estándar para seleccionar o descartar los reactivos de la versión final de una escala; las características compartidas del grupo criterio variarán en función de la naturaleza y el alcance de la prueba que se está desarrollando, 359-361
- Grupo de control:** (1) Es el grupo no tratado de un experimento; (2) Es la codificación empírica de criterios en el desarrollo de una prueba; un grupo de personas que responden la prueba, seleccionado de manera típica, el cual no comparte las características comunes entre los miembros de la muestra de estandarización, 361-362
- Grupo de enfoque:** Investigación cualitativa realizada con un grupo de personas que responden que típicamente ha sido observado como calificado para participar en la investigación, 559-562
- Grutter contra Bollinger et al.*, 48, 50-51
- Habilidades mantenidas:** En el modelo de inteligencia de Cattell-Horn, capacidades cognoscitivas que no declinan con la edad y que tienden a regresar tras algún daño cerebral a los niveles los niveles previos; contrástese con *habilidades vulnerables*, 239
- Habilidades mentales primarias (PMAs), 239, 264-265
- Hall, G. Stanley, 35, 522
- Hankes, Elmer, 12
- HAPI (Instrumentos para la salud y psicosociales), 28
- Hathaway, Starke, 367
- Henri, Victor, 35
- Hereditary Genius* (Galton), 244, 247
- Herencia, 33
- Herramienta de detección:** (1) Un instrumento o procedimiento para identificar un rasgo o grupo de ellos en particular, en un nivel amplio o impreciso, en oposición a una prueba de mayor precisión usada para diagnósticos o evaluación más definitivos; (2) en la evaluación preescolar, un instrumento o procedimiento usado como primer paso para identificar a un niño que está “en riesgo” de no funcionar dentro de límites normales; (3) en escenarios de empleo, un instrumento o procedimiento usado como una medida general para determinar quién satisface requerimientos mínimos establecidos por el empleador, 292, 295-296
- Heterogeneidad de la prueba:** También simplemente heterogeneidad, el grado al que los reactivos individuales de una prueba no miden un constructo, sino factores diferentes; contrástese con *homogeneidad de la prueba, y confiabilidad*, 136, 137, 142

Heterogeneidad. Véase **Prueba de heterogeneidad**

HIPAA (Health Insurance Portability and Accountability Act, Decreto sobre la Portabilidad y Responsabilidad del Seguro de Salud) (1996), 48, 59

Hipotálamo, 459

Hipótesis proyectiva: La tesis de que un individuo proporciona estructura a los estímulos no estructurados de una manera consistente con un patrón único de necesidades, miedos, deseos, impulsos, conflictos y modos de percibir y responder, conscientes e inconscientes, 378

Histograma: Una gráfica con líneas trazadas en sentido vertical en los verdaderos límites de cada puntuación de prueba (o intervalo de clase), formando una serie de rectángulos contiguos, 70, 71

HIT (Técnica de Manchas de Tinta de Holtzman), 382n

Hito en el desarrollo: Evento importante durante el curso de nuestra vida que puede ser marcado por la adquisición, presencia, o crecimiento de ciertas capacidades o habilidades, o la falla, deficiencia, o cese de las mismas, 464, 465

Hobson contra Hanson, 48

Hoja de datos personales, 36, 356, 362

Holland, John L., 357, 524

Homogeneidad de la prueba: También simplemente *homogeneidad*, el grado al que los reactivos individuales de una prueba miden un solo constructo; contrástese con *heterogeneidad de la prueba*, 137, 142, 143, 176-177

Homogeneidad. Véase Homogeneidad de pruebas

Hopwood contra el Estado de Texas, 545

"How Much Can We Boost IQ and Scholastic Achievement?" (Jensen), 47

H-R (Batería Neuropsicológica Halstead-Reitan), 472, 482, 484-485

HTP (Casa-Árbol-Persona) prueba, 398

Juicio humano. Véase Subjetividad

ICC. Véase Curva característica del reactivo

Identidad: Una serie de características cognitivas y de conducta mediante las cuales se definen los individuos como miembros de un grupo particular; el propio sentido de uno mismo, 374

Identificación (1) Un proceso mediante el cual un individuo adopta un patrón de comportamiento que es característico de otras personas; (2) pensamientos, sentimientos o comportamientos de parte de una persona cuyo razonamiento es en cierta forma familiar con las experiencias de otra persona, 374

Imparcialidad: El grado en el cual una prueba se usa en forma imparcial, justa

y equitativa, 97, 184-188, 221-222, 224. Véase también Sesgo; Temas culturales; Cuestiones éticas

Inconsciente, 378, 400

Indicador de Tipos Myers-Briggs (MBTI), 339, 531, 533-534

Índice de aciertos: Una proporción de personas identificadas de manera precisa a través de una prueba u otro procedimiento de medición por tener o manifestar un rasgo, comportamiento, característica o atributo particular; *confróntese con tasa de error, falso positivo, y falso negativo*, 171, 172

Índice de aprobación del reactivo: En contextos como el de la evaluación de personalidad, en donde la naturaleza de la prueba es tal que las respuestas no se califican como correctas o incorrectas, una estadística que indica cuántos examinados han respondido a un reactivo en una dirección particular. En teoría este índice puede oscilar de cero (ningún examinado respondió con tal respuesta) a x , donde x es el número total de reactivos en la prueba. En las pruebas de rendimiento, la cual tiene respuestas calificadas como correctas, a esta estadística se le refiere como un *índice de dificultad de reactivos*, 213

Índice de confiabilidad del reactivo: Una estadística diseñada para proporcionar una señal de la consistencia interna de una prueba; mientras mayor sea el índice de confiabilidad de un reactivo, mayor será la consistencia interna de la prueba, 214

Índice de dificultad del reactivo: En pruebas de rendimiento o capacidad y otros contextos en los cuales las respuestas se califican como correctas, una estadística que indica cuántos examinados han respondido de manera correcta un reactivo. En teoría, este índice puede oscilar de cero (ningún examinado dio la respuesta identificada como correcta) a x , donde x es el número total de reactivos en la prueba; en contextos donde la naturaleza de la prueba es tal que las respuestas no se identifican correctas, esta misma estadística se le puede llamar un *índice de aprobación de reactivo*, 212-213

Índice de discapacidad física (POI), 512

Índice de discriminación del reactivo: Estadística que sirve como indicador de con qué tanta precisión discrimina (o separa) un reactivo entre las puntuaciones altas y las puntuaciones bajas de la prueba, 215-217

Índice de Estrés de los Padres (PSI), 101, 451

Índice de fallas: La proporción de personas que una prueba o procedimiento de medición no alcanza a identificar aun cuando exhibe un rasgo, comportamiento, característica o atributo; en este contexto una "falla" significa una clasificación o predicción imprecisa y puede subdividirse entre *falsos positivos* y *falsos negativos*, 171

Índice de satisfacción con la Vida, 536

Índice de severidad de adicción (Addiction Severity Index), 437

Índice de validez del reactivo: Estadística que revela el grado al cual una prueba mide lo que se supone debe medir; cuanto mayor es el índice de validez de los reactivos, tanto mayor es la validez relacionada con el criterio de la prueba, 214-215

Infante o bebé en riesgo: De acuerdo con IDEA, es un menor de 3 años, que de no recibir los servicios de intervención temprana estaría en riesgo de experimentar un retraso sustancial en su desarrollo, 492

Inferencia: Un resultado o deducción lógico en un proceso de razonamiento, 125-127, 156. Véase también **Correlación; Interpretación**

Inflación de rango: También se le conoce como *inflación de varianza*, una referencia a un fenómeno asociado con las estimaciones de confiabilidad donde la varianza de cualquier variable en un análisis de correlación está inflado por el procedimiento de muestreo empleado y el coeficiente de correlación tiende a ser en consecuencia más alto; contrástese con *restricción de rango*, 144-145, 165

Inflación de varianza. Véase Inflación de rango

Información confidencial: La comunicación entre un profesional y un cliente, junto con los datos obtenidos por el profesional en el curso de una relación profesional, que el profesional tiene la obligación de no revelar; contrástese con *información privilegiada*, 58-59

Información de evaluación: Prueba u otros datos usados para hacer juicios tales como la ubicación en una clase, o decisiones aprobado/reprobado, y admitido/rechazado; contrástese con *información diagnóstica*, 42, 318

Información diagnóstica: resultados de las pruebas u otro tipo de datos empleados para contextualizar dificultades de estudiantes y ofrecer soluciones posibles, 318

Información privilegiada: Datos protegidos por ley, de su revelación en un proceso legal; por lo general, también existen

- en la ley excepciones al privilegio;
contrástese con *información confidencial*, 58-59, 439
- Informe consultivo:** Un tipo de reporte de interpretación diseñado para proporcionar análisis expertos y detallados de los datos de una prueba que casi imita el trabajo de un consultor o experto, 13
- Informe de calificación extendida:** Un tipo de reporte de calificación que no sólo proporciona una lista de las puntuaciones, sino también datos estadísticos, 13
- Informe de integración:** Una forma del reporte de interpretación de la evaluación psicológica, usualmente generado por computadora, en el cual se integran los datos conductuales, médicos, administrativos, y/u otras fuentes; contrástese con *informe de calificación e informe interpretativo*, 13
- Informe interpretativo:** Un registro formal u oficial generado por computadora del desempeño de la prueba, que se presenta tanto en forma numérica como narrativa y que incluye una explicación de los hallazgos; las tres variedades de reporte de interpretación son descriptivo, de selección y consultivo; contrástese con *informe de calificación e Informe de integración*, 13
- Inmigración, 39, 308
- Instituto Buros de Mediciones mentales, 26, 27
- Instrumentos para la salud y psicosociales (HAPI), 28
- Inteligencia:** Un término simple pero controvertido que ha sido definido en muchas formas, tales como: una capacidad multifacética que se manifiesta a sí misma en distintas maneras a lo largo de la vida pero que en general incluye las habilidades y capacidades para adquirir y aplicar conocimientos, para razonar de manera eficaz y lógica, de manifestar juicios legítimos, ser perceptivo, intuitivo, mentalmente alerta, y capaz de encontrar las palabras y pensamientos correctos con facilidad, y ser capaz de hacer frente a, y ajustarse a nuevas situaciones y nuevos tipos de problemas, 232-242
- cuestiones naturales/crianza, 246-249
- debates recientes, 261-262
- definición introductoria, 232-233
- dotes, 250-251, 252-253
- estabilidad de, 250-251
- óptica pública, 233-234
- perspectiva histórica, 234-236, 237
- recursos en la Web, 263
- teorías de procesamiento de información, 236, 241-242, 322, 323
- y ambiente familiar, 254-255
- y análisis factorial, 236-241, 245
- y Escalas de Capacidades Diferenciales, 324
- y género, 254
- y personalidad, 254
- Véase también* Pruebas de inteligencia
- Inteligencia cristalizada:** En la teoría de los dos factores de la inteligencia de Cattell, habilidades y conocimientos adquiridos que son muy dependientes de la educación formal o informal; *contrástese con inteligencia fluida*, 239
- Inteligencia emocional:** Popularización de ciertos aspectos de la teoría de inteligencias múltiples de Gardner, que acentúa las nociones de inteligencia interpersonal e intrapersonal, 239
- Inteligencia fluida:** Uno de los factores en la teoría de Cattell de la inteligencia de dos factores, la inteligencia está formada por capacidades no verbales, que son menos dependientes de la cultura y la instrucción formal, que la inteligencia cristalizada; *contrástese con inteligencia cristalizada*, 239
- Inteligencia interpersonal:** De acuerdo con la teoría de inteligencias múltiples propuesta por Gardner, es la capacidad de entender a otras personas, lo que las motiva, la forma en que trabajan, y la forma de trabajar en cooperación con ellas; *contrástese con inteligencia intrapersonal*, 239
- Inteligencia intrapersonal:** Según Gardner y su teoría de inteligencias múltiples, es una capacidad para formar percepciones precisas de uno mismo, para discriminar claramente entre las emociones, y para poder extraer de las emociones personales el medio y la guía eficaz al entendimiento
- Interaccionismo:** La creencia de que el ambiente y la herencia interactúan para influenciar el desarrollo de las capacidades y habilidades mentales del individuo, 236, 249
- Interceptar:** En la ecuación para una línea de regresión, $Y = a + bx$, donde la letra a es una constante que indica el punto en que la línea cruza el eje vertical o eje-Y, 122
- Interés, mediciones de, 521-524
- Interpretación configurativa, 364
- Interpretación de pruebas. *Véase* Manuales de interpretación de pruebas, 26
- Interpretación, 6, 8
- asistida por computadora, 12
- y psicología del consumidor, 559
- y varianza del error, 131-132
- pruebas de inteligencia, 272-273
- y personas con discapacidades, 499-500, 506-507
- y validez, 99
- Véase también* Calificar
- Interpretes, 507, 508
- Interrogatorio:** Un elemento típico de la administración de pruebas de Rorschach; después de la presentación inicial de todas las diez tarjetas, el evaluador plantea preguntas específicas diseñadas, entre otras cosas, para determinar qué acerca de cada tarjeta llevó a las percepciones del evaluado, 381
- Intervalo de confianza:** Un rango o banda de puntuaciones de prueba que es probable que contenga la "puntuación verdadera", 151-152
- Intervalos de clase, 69
- Inventario de Adaptabilidad entre Culturas (CCAI), 534
- Inventario de Aptitud Artística de Horn, 318
- Inventario de Autoidentidad, 371
- Inventario de Depresión de Beck (BDI), 164, 435
- Inventario de Estado-Rasgo de Ansiedad (STAI), 340
- Inventario de estilo de vida cultural, 371
- Inventario de Evaluación Social-Emocional de Meadow y Kendall, 510
- Inventario de Experiencia Multicultural, 371
- Inventario de impulsores conductuales cognoscitivos, 485
- Inventario de Interés Vocacional Libre de Lectura, (R-FVII), 524
- Inventario de Intereses de lo que me Gusta Hacer (What I Like to Do Interest Inventory), 332
- Inventario de Intereses de Strong (511), 522-523
- Inventario de Intereses de Strong-Campbell (SCII), 522
- Inventario de Intereses Profesionales, 524
- Inventario de Intereses Vocacionales de Minnesota, 523
- Inventario de Intereses Vocacionales de Strong, revisión de, 227
- Inventario de la Conducta Sexual del Niño**, 305
- Inventario de Personalidad NEO Revisado (NEO PI-R), 354, 358-359, 369-370, 531, 532
- Inventario de Personalidad para niños (PIC), 343
- Inventario de preferencias en el trabajo, (WP1), 550
- Inventario de Satisfacción con el Retiro, 536
- Inventario de Transición de Carreras (CTI), 535-536
- Inventario de Transiciones de Carrera, 535-536
- Inventario del Potencial del Solicitante (API), 532

- Inventario Diagnóstico de Matemáticas, 320
- Inventario Maslach de Agotamiento (MBI), 550-551
- Inventario Médico y Psiquiátrico, 361. *Véase también* Inventario Multifásico de la personalidad Minnesota
- Inventario Multiaxial Clínico de Millon-III (MCMI-III), 435
- Inventario Multifásico de la personalidad Minnesota (MMPI)
- cuestiones culturales, 355, 430-431
- desarrollo original de, 361-365
- en abuso de sustancias, 436
- escala de validez, 347
- naturaleza no teórica de, 348
- para adolescentes (MMPI-A), 367-368
- revisión del (MMPI-2), 227, 365-369
- y orientación vocacional, 531
- y tipologías de la personalidad, 339
- Inventario Potencial de Abuso Infantil (CAP), 172-173, 451
- Inventario Psicológico California (CPI), 347, 415
- Inventario Psiconeurótico de Woodworth, 36, 356
- Inventario Secuenciado de Desarrollo de la Comunicación (SIDC), 478
- Investigación cualitativa dimensional:**
- Una adaptación del enfoque clínico multimodal de Lazarus para ser usado en aplicaciones de investigaciones cualitativas, diseñada para asegurar que la investigación es completa y sistemática desde una perspectiva psicológica y dirigida por preguntas de discusión basadas en siete modalidades (o dimensiones), que se resumen en el acrónimo BASIC ID y que Lazarus denominó en su modelo comportamiento, afecto, sensación, imaginación, cognición, relaciones interpersonales y drogas. La adaptación hecha por Cohen de este trabajo, agrega como octava dimensión, la sociocultural, con lo cual el acrónimo cambia a BASIC IDS, 561-562
- IRT. *Véase* Teoría de respuesta al reactivo
- Ítem alternativo**, 265
- Jaffee contra Redmond*, 48, 59
- Jerarquía de necesidades de Maslow, 549
- Jerarquía de necesidades, 549
- Joint Committee of Testing Practices, 52-53
- Journal of Educational Psychology*, 234
- Journal of Personality and Social Psychology*, 27
- Journal of Personality Assessment*, 27
- Journal of Psychoeducational Assessment*, 27
- Juego de los vasos, 271
- Juicio compuesto, 416
- K-ABC (Batería de Evaluación de Kaufman para niños), 242, 286, 321
- KAIT (Prueba de Inteligencia de Kaufman para adolescentes y adultos), 286
- K-BIT Prueba Breve de Inteligencia de Kaufman (K-BIT), 286
- KDS (Sistema de Dibujo Cinético), 398
- KeyMath Revisada: Inventario de Diagnóstico de Matemática Básica, 320-321
- KFD (Dibujo Cinético de la Familia), 398
- KOIS (Encuesta de Interés Ocupacional de Kuder), 524
- KR-20. *Véase* **Fórmulas Kuder-Richardson**
- Kraepelin, Emil, 35
- KSD (Dibujo Escolar Cinético), 398
- La curva de campana (The Bell Curve) (Herrnstein & Murray), 261
- Laplace, Marqués de, 83
- Larry P contra Riles*, 60
- Law and Human Behavior*, 27
- Legislación sobre la verdad en las pruebas, 47
- Legislación sobre muerte con dignidad, 55-56
- Lenguaje, 444-445
- Leptocúrtica:** Describe la curtosis de una distribución como relativamente picuda en su centro, 82-83
- Lesión:** Alteración no patológica de tejidos tales como aquel que puede resultar de un agravio o infección, 459, 460
- Ley de Derechos Civiles (1964), 47, 48
- Ley de Derechos Civiles (1991), 102, 186, 531, 545
- Ley de Derechos Educativos y Confidencialidad para la Familia (*Education Rights and Privacy Act*) (1974), 48
- Ley de Educación para Individuos con necesidades Especiales (IDEA)
- Enmiendas (PL 105-17)
- en definiciones de discapacidad, 492, 493-494
- en evaluación alterna, 4-5, 496
- repaso, 48
- y evaluación en preescolar, 300
- y pruebas de rendimiento, 307
- Ley de Educación para la Defensa Nacional, 46-47
- Ley de Educación para todos los Niños Discapacitados (PL 94-142), 48, 300, 306, 492
- Ley de Educación para todos los Niños Discapacitados -Enmiendas (PL 99-457), 300, 492
- Ley de la Muerte con Dignidad (ODDA) (Oregon), 55-56
- Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades (Ley Pública 101-336) de 1990, 48, 490, 492, 500-501, 504
- Ley de Rehabilitación (1973), 492
- Ley HMO (1973), 421
- Leyes:** Reglas que los individuos deben obedecer porque se estima que son buenas para la sociedad como un todo; contrástese con *ética*, 45. *Véase también* Cuestiones legales
- Libre asociación:** Una técnica, se emplea más en psicoanálisis, donde el sujeto relaciona todas sus pensamientos como van ocurriendo, 392n
- Línea de regresión:** El resultado de un análisis de regresión simple, la gráfica “línea de mejor ajuste” que aparece más cerca de la cantidad mayor de puntos en la gráfica de dispersión de las dos variables, 122
- Lista de “no llamar”, 557-558
- Lista de Evaluaciones de Apoyo Interpersonal, 536
- Lista de verificación Achenbach del comportamiento infantil (Achenbach Child Behavior Checklist, CBCL), 301
- Lista de verificación de adjetivos, 352, 415
- Lista de verificación de comportamiento infantil, 510
- Lista de Verificación de Habilidades de Adaptación para la Subsistencia (CALS), 534
- Lista de verificación de hábitos de estudio, 332
- Lista de verificación de problemas de comportamiento, 510
- Lista de verificación de psicopatía (PCL), 445
- Lista de verificación de Psicopatías (PCL-R), 445
- Lista de Verificación de Tensiones Matrimoniales, 415
- Lista de verificación Walker de problemas de comportamiento, 510
- Lista de verificación:** Un cuestionario que permite a una persona marcar los elementos indicativos de información tal como la presencia o ausencia de un comportamiento, pensamiento, acontecimiento, o circunstancia específica, 301
- Listening with the Third Ear* (Reik), 417
- LNNB (Batería neuropsicológica Luria-Nebraska), 485
- Lóbulos frontales, 459
- Lóbulos occipitales, 459
- Lóbulos parietales, 459
- Lóbulos temporales, 459
- Localizador:** Una preprueba o prueba de direccionalidad, en general para determinar el nivel más apropiado para la prueba real, 307
- Locus de control:** La percepción propia de la fuente de cosas que a uno le suceden, 347-348
- LSAT (Prueba de Admisiones para la Escuela de Leyes), 319
- Luria, Aleksandr, 485

- MAC-R (Escala de Alcoholismo de MacAndrew), 436
- MAD. Véase **Muñeco anatómicamente detallado**
- Magnitud, 114, 118
- Manejo de la impresión:** Intención de manipular las opiniones e impresiones de los demás mediante la exposición selectiva de cierta información, incluyendo información falsa, usualmente junto con la omisión de otra información; en la respuesta a las medidas de personalidad autorreportadas, psicopatología, o logro; la dirección de impresiones puede ser sinónimo de intentos por “fingir bienestar” o “fingir malestar”, 342, 346
- Manual para la Aplicación de Baterías de Pruebas Neuropsicológicas (Reitan), 482
- Marco de referencia:** En el contexto del formato del reactivo, aspectos del enfoque del reactivo como el marco temporal (pasado, presente o futuro), 349-352
- Masa crítica, 50
- MAT (Prueba de Analogías de Miller), 317-318
- Matriz multirrasgo-multimétodo:** Método para evaluar la validez de constructo que consiste en el examen simultáneo de evidencia convergente y divergente, sirviéndose de una tabla de correlaciones entre rasgos y métodos, 179
- Mazos, 471-472
- MBI (Inventario Maslach de Agotamiento), 550-551
- MBTI (Indicador de Tipos Myers-Briggs), 339, 531, 533-534
- MCAT (Prueba de Admisión al Colegio de Medicina), 319, 525
- McCall, W. A., 87-88
- MCMI-III (Inventario Multiaxial Clínico de Millon-III), 435
- MCT (Prueba Minnesota de Tareas Administrativas), 539
- MDBS (Escala Revisada de Comportamientos Moralmente Debatibles), 197-198
- Media:** También se le llama *media aritmética*, una medida de tendencia central que se obtiene al calcular el promedio de todas las calificaciones en una distribución, 74, 75
- Media aritmética:** También se le llama simplemente *media* y es una medida de la tendencia central que se obtiene calculando el promedio de todas las puntuaciones en una distribución, 74, 75
- Mediana:** Una medida de la tendencia central que se deriva al identificar la puntuación más intermedia o central de una distribución, 74-76
- Medición:** Asignación de números o símbolos a características de las personas u objetos de acuerdo con reglas específicas, 63
- escalas de, 63-68, 194
- posibilidad de, 94-95
- Medición con base en el currículo (CBM):** Un tipo de evaluación basada en el currículo que se caracteriza por el uso de procedimientos de medición estandarizados para derivar normas locales para usarse en la evaluación del desempeño de estudiantes en tareas basadas en el currículo, 311
- Medición de la actitud (Thurstone & Chave), 556
- Medida de Asimilación para Indios Spokane, 371
- Medida de desempeño situacional:** Un procedimiento que por lo general involucra el desempeño de una tarea por el evaluado bajo condiciones reales o simuladas, mientras que un evaluador observa y analiza, 411
- Medida de Motivos para Beber (MMB), 23
- Medida de tendencia central:** Una estadística que indica la calificación promedio o media entre los extremos de calificación en una distribución. La *media* es una medida de la tendencia central y una estadística en el nivel de razón de la medición; la *mediana* es la medida de tendencia central que toma en cuenta el orden de las calificaciones y es de naturaleza ordinal; la moda es una medida de la tendencia central que es de naturaleza nominal, 74-77, 83-84
- Medida de variabilidad:** Una estadística que indica cómo es que las puntuaciones en una distribución están aisladas o dispersas; rango, desviación estándar, y varianza son medidas comunes de la variabilidad, 77-81
- Medida del autoconcepto:** Instrumento diseñado para obtener información acerca de cómo se ve a sí mismo el individuo respecto de ciertas variables psicológicas en particular, los datos a partir de los cuales se interpretan, por lo general, parten del contexto de cómo los demás pueden verse a sí mismos con respecto a las mismas variables u otras similares, 341-342
- Medida no obstructiva:** Un tipo de medida que no requiere necesariamente la presencia o cooperación de quienes responden, 413-414, 415
- Medidas de Aculturación Chinas, 371
- Medidas de Talentos Musicales de Seashore, 318
- Médula espinal, 459
- Meehl, Paul, 367, 454
- Meier Art Judgment Test*, 25
- Membresía a un grupo, 43-44, 49
- e inteligencia, 262
- y evaluación del empleo, 545
- y validez, 178, 186-188
- Véase también **Sesgo**; Cuestiones culturales; Raza
- Memoria declarativa:** Recuerdos de material real; contrástese con *Memoria metodológica*, 480
- Memoria episódica, 480
- Memoria procedimental:** Memoria para realizar ciertas cosas o desempeñar ciertas funciones; contrástese con *memoria declarativa*, 480
- Memoria semántica, 480
- Merrill, Maude, 265
- Mesa directiva de pruebas de admisión universitaria, 308
- Mesocúrtica:** Es la descripción de la curtosía de una distribución, donde ésta no es extremadamente picuda ni plana en su parte central, 83
- Metanálisis:** Herramienta de investigación, y resultado de la combinación estadística de la información de varios estudios, 125
- Método de Apercepción Escolar, 389
- Método de comparación por pares, 198-199
- Método de elaboración de escalas para pruebas psicológicas y educativas (Thurstone), 194, 196
- Método de Generar una Historia con Base en Dibujos, 389
- Método de grupos contrastados:** Procedimiento para reunir evidencia de la validez de constructo que supone la demostración de que las calificaciones en la prueba varían en forma predecible en función de la pertenencia a algún grupo, 178
- Método equipercantil:** Un procedimiento para la comparación de puntuaciones de una prueba o más, como en la creación de las normas ancla nacionales, que entraña el cálculo de normas de percentiles para cada prueba y la identificación de la calificación en cada prueba que corresponde al percentil, 108-109
- Método nemotécnico:** Una técnica de evaluación que se caracteriza por los esfuerzos por aprender la forma en que un número limitado de rasgos de personalidad pueden ser aplicados a todas las personas; contrástese con *enfoque ideográfico*, 353
- Método proyectivo:** Una técnica de evaluación de la personalidad en donde se hace cierto juicio sobre la personalidad del evaluado, con base en su desempeño en una tarea que

- implica proveer estructura a estímulos relativamente no estructurados o incompletos, 37, 351, 378-402
- con base en imágenes, 226, 384-391
- con base en láminas, 290-291, 395-399, 450, 509
- con base en palabras, 391-394
- con base en sonidos, 394-395
- críticas al, 399-402
- en evaluaciones bajo custodia, 447
- motivación, 549-550
- normas, 126n
- personas con discapacidades, 509
- prueba de manchas de tinta, 379-384
- psicología del consumidor, 562
- varianza del error, 131
- Métodos cuantitativos:** Técnicas de generación de datos y análisis que dependen fundamentalmente de procedimientos matemáticos o estadísticos más que en verbales, 222. *Véase también* Análisis cualitativo de los reactivos.
- Métodos de evaluación psicofisiológica:** Técnicas para vigilar los cambios fisiológicos que reciben influencia de factores psicológicos, como el latido del corazón y la presión sanguínea, 412-413
- Métodos de investigación de la motivación:** Herramientas y procedimientos, casi siempre cualitativos, tales como entrevistas a fondo y grupos focales, asociados con investigación del consumidor para explorar las actitudes, comportamiento, y motivaciones del consumidor, 559-563
- Métodos objetivos de evaluación de la personalidad:** Habitualmente una prueba que consiste en reactivos de respuesta corta donde la tarea del evaluado es seleccionar una respuesta de entre dos o más opciones proporcionadas; las puntuaciones se realizan en su totalidad de acuerdo con procedimientos previamente establecidos que prácticamente no implican los juicios del calificador, 376-377
- Métodos proyectivos basados en la palabra, 391-394
- Métodos proyectivos basados en sonidos, 394-395
- Métodos proyectivos con base en imágenes, 226, 384-391
- Métodos proyectivos en el estudio psicológico de los niños (Horowitz & Murphy), 378n
- Minexamen de Condición Mental, 466-467
- Minorías. *Véase* Aspectos culturales; Raza
- MMPI. *Véase* Inventario Multifásico de la personalidad Minnesota
- Moda:** Una medida de tendencia central que se deriva al identificar la puntuación que ocurre con mayor frecuencia en una distribución, 76-77
- Modelo Carroll de habilidades cognoscitivas. *Véase* Teoría de tres estratos de las habilidades cognoscitivas
- Modelo CHC McGrew-Flanagan, 241
- Modelo de efectos maternales, 255
- Modelo de las habilidades cognoscitivas Cattell-Horn, 239, 245, 268
- Modelo de personalidad **Cinco Grandes**, 358-359, 369-370, 531
- Modelo de personalidad de cinco factores. *Véase* Modelo de personalidad Big Five
- Modelo de rasgo latente:** También se le refiere como *teoría de rasgo latente*; un sistema de supuestos sobre medición, incluyendo el supuesto de que el rasgo que se mide por medio de una prueba es unidimensional, y el grado al cual cada reactivo de prueba mide dicho rasgo, 219-220. *Véase también* **Teoría de respuesta al reactivo (IRT)**
- Modelo jerárquico:** Un término casi siempre aplicado a un modelo teórico organizado en dos o más capas, cada una subsumada o incorporada a la capa precedente; por ejemplo, la teoría de los tres estratos de las habilidades cognoscitivas de Carroll es un modelo jerárquico con g como capa superior seguida por dos capas de habilidades o procesos o habilidades cognoscitivas, 240
- Modelo médico de discapacidad, 491
- Modelo PASS:** Modelo de procesamiento de información desarrollado por Luria, PASS para decir planeación, atención, simultánea, y sucesiva, 242
- Modelo social de discapacidad (nuevo paradigma), 491, 495, 513
- Morgan, Christiana D., 37, 384, 385
- Moss, Dale, 366n, 367
- Motivación extrínseca:** Un estado en el cual la principal fuerza que impulsa a un individuo proviene de fuentes externas (tales como un salario o bono) y restricciones externas (tales como la pérdida del empleo), 550
- Motivación intrínseca:** Un estado en el cual la fuerza principal que mueve al individuo viene de su interior, así como la satisfacción personal con el trabajo de uno mismo; contrástese con *motivación extrínseca*, 550
- Motivación y evaluación para el empleo, 547-551 y psicología del consumidor, 559-563
- MPS (Estudio de Progreso Gerencial), 540, 541, 542
- MRT (Pruebas Metropolitanas de Disposición), 313-314
- MSS (Escala de Satisfacción Matrimonial), 176-177, 178, 179
- Muestra de desempeño relacionado con el trabajo, 539
- Muestra normativa:** También conocida como norma de grupo, un grupo de personas que se presume son representativas del universo que puede someterse a una prueba particular, cuyos datos de desempeño en una prueba determinada pueden emplearse como fuentes de referencia o como contexto para evaluar las puntuaciones individuales de la prueba, 102, 103-106
- aspectos culturales, 101
- evaluación de la personalidad, 368, 369
- normas ancla nacionales, 109
- pruebas de la inteligencia, 276-277, 281-282
- Muestra:** Un grupo de personas que se presume representativo de la población total o del universo de personas estudiado o evaluado, 103-105
- Muestras de estandarización
- aspectos culturales, 38, 279
- aspectos de adecuación, 185
- evaluación de personalidad, 362, 366
- pruebas de inteligencia, 267, 268-269, 276, 280, 281, 282-283, 284
- revisión de pruebas, 226
- versus* muestras normativas, 105-106
- Muestras ensayadas, 40
- Muestreo aleatorio estratificado:** El proceso para desarrollar una muestra basado en subgrupos específicos de una población donde cada miembro tiene la misma oportunidad de estar incluido en la muestra, 103
- Muestreo de contenido:** También se le llama *muestreo de reactivos*, la variedad del tema específico contenido en los reactivos; a menudo se le menciona en el contexto de variación entre los reactivos individuales de una prueba o entre reactivos de prueba en dos o más pruebas, 130, 134
- Muestreo de conveniencia. *Véase* **Muestreo incidental**
- Muestreo de reactivos:** Se conoce como *muestreo del contenido* de la prueba. A menudo se emplea el término en el contexto de las variaciones entre los reactivos individuales de una prueba o entre los reactivos de dos o más pruebas, 130, 134
- Muestreo del dominio:** (1) Una muestra de todos los comportamientos posibles que pudieran ser indicativos de un constructo particular; (2) una muestra de todos los reactivos posibles de una prueba que pueden usarse para medir un constructo particular, 95n, 146, 148. *Véase también* Teoría de la generalización

Muestreo estratificado: El proceso para desarrollar una muestra basado en subgrupos específicos de una población, 103

Muestreo incidental: También se le llama *muestreo de conveniencia*, el proceso de seleccionar de manera arbitraria a ciertas personas para ser parte de una muestra porque están disponibles de inmediato, no porque sean las más representativas de la población en estudio, 104

Muestreo intencional: La selección arbitraria de las personas que formarán la muestra porque se les considera individuos representativos de la población que se investiga, 104

Muestreo: Una referencia general al proceso de desarrollo de una muestra, 103-105

Muñeco anatómicamente detallado (MAD): Muñecos con figura humana que representan de manera fiel los genitales, suelen usarse para facilitar la evaluación de niños con señales de abuso sexual, 450

Murray, Henry A., 37, 384, 385, 386, 394, 395, 541

Myers, Isabel Briggs, 533

NAS (Academia Nacional de Ciencias), 530

NASP (Asociación Nacional de Psicólogos Escolares), 16

National Council on Measurement in Education (NCME), 16, 52, 53

Naturaleza contra crianza, 246-249

NCCEA (Examen Comprensivo de Afasia del Centro Neurológico), 485

NCLB (Ley de No Dejar a los Niños Atrás) (2001), 48

NCME (Consejo Nacional sobre Mediciones Usadas en Educación), 16, 52, 53

NEA (Asociación Nacional Educativa), 52

Necesidad: De acuerdo con el teórico de la personalidad Henry Murray, son determinantes de la conducta que surgen dentro del individuo; *contrástese* con el concepto murrayano de presión, 387

NEO PI-R (Inventario de Personalidad NEO Revisado), 354, 358-359, 369-370, 531, 532

Nervios craneales, 469

Neurología: Una rama de la medicina que centra su atención en el sistema nervioso y sus desórdenes; *contrástese* con *neuropsicología*, 458

Neuronas, 458

Neuropsicología: Una rama de la psicología que se enfoca en la relación entre el funcionamiento cerebral y el comportamiento; *contrástese* con *neurología*, 458. *Véase también* Evaluación neuropsicológica

Niño con discapacidad o con necesidades educativas especiales: (1) con discapacidad intelectual, daños auditivos (incluyendo sordera), deficiencias en el habla o en el lenguaje, daños visuales (incluyendo ceguera), trastornos emocionales graves... problemas ortopédicos, autismo, lesiones traumáticas en el cerebro, otras alteraciones de la salud o incapacidades específicas para el aprendizaje o con necesidades educativas especiales; (2) para los niños entre los 3 y los 9 años de edad, de acuerdo con IDEA, un niño que experimenta retraso en el desarrollo cognitivo, social, emocional, de comunicación, o desarrollo de adaptación, 492

Niño o bebé con discapacidad: De acuerdo con IDEA, un niño menor de 3 años de edad quien necesita servicios de intervención temprana debido a retrasos en el desarrollo o una condición física o mental diagnosticada con alta probabilidad de derivar retraso del desarrollo. *Véase* *infantes y bebés en riesgo* (de acuerdo con IDEA), como también pueden ser incluidos a discreción de los estados, 492

Nivel basal: Una fase lograda por el examinado en una prueba, al satisfacer un criterio establecido que le permite seguir a la siguiente fase de la prueba, por ejemplo, responder correctamente a dos reactivos consecutivamente en una prueba de capacidad que contiene reactivos cada vez más difíciles puede ser la “base” a partir de la cual pueda seguir contestando la prueba; *contrástese* con *nivel de techo*, 271

Nivel de techo: Etapa de una prueba a la que se llega como resultado de cumplir cierto criterio preestablecido para descontinuar la prueba; por ejemplo, responder de manera incorrecta a dos reactivos de manera consecutiva en una prueba de capacidades que contiene reactivos cada vez más difíciles pueden establecer el “techo” en la capacidad del que responde; *confróntese* con *nivel base* y *Pruebas de los límites*, 271

Nombramiento de confrontación: Identificación de un estímulo gráfico en un contexto neuropsicológico, tal como la respuesta a la administración de reactivos en la Prueba Boston Naming, 473, 474

Nombres de marca, 562, 563

Norma: (1) Comportamiento o desempeño usual, promedio, normal, estándar, esperado, o habitual; (2) singular de *normas*, 102. *Véase también* *Normas*

Norma racial: La práctica controvertida de normar con base en los antecedentes raciales o étnicos, 102, 526, 530-531

Normalización de una distribución, 89, 90

Normar: El proceso de derivar o crear normas, 102, 251, 254, 526, 530-531. *Véase también* *Muestras de estandarización*

Normas: El plural de *norma*, también se les conoce como *datos normativos*; son los datos resultantes del desempeño de un grupo de examinados en una prueba, diseñados para ser una referencia contra la cual evaluar, interpretar o, poner en contexto las puntuaciones individuales de la prueba, 102, 106-109. *Véase también* *Normar*; *Pruebas y evaluaciones con referencia a normas*

Normas de grado: Normas específicamente diseñadas como una referencia en el contexto del grado del que responde la prueba quien alcanzó una puntuación particular; *contrástese* con *normas por edad*, 107-108

Normas de percentil: Los datos crudos de la muestra de estandarización de la prueba convertidos a percentiles, 106

Normas de subgrupo: Normas de cualquier grupo definido dentro de un grupo más grande, 109

Normas del programa. *Véase* **Normas del usuario**

Normas del usuario: También se le conocen como *normas de programa*, estadísticas descriptivas basadas en un grupo de examinados durante un periodo de tiempo en lugar de las normas obtenidas mediante los métodos normales de muestreo, 103

Normas locales: Información normativa acerca de cierta población limitada, a menudo de interés específico del usuario de las pruebas, 109, 110

Normas nacionales ancladas: Tabla de equivalencias de las calificaciones de dos pruebas nacionalmente estandarizadas y diseñadas de manera específica para medir una misma variable, 108-109

Normas nacionales: Normas derivadas de una muestra de estandarización representativa de la población en el nivel nacional, 108

Normas por edad: También se les conoce como *normas equivalentes de edad*; normas diseñadas de manera específica para servir como referencia en el contexto de la edad del sujeto a prueba quien alcanzó una puntuación particular; *contrástese* con *normas de graduación*, 107

Nuevo paradigma de la discapacidad, 491, 495, 513

OAT (Prueba de Admisión a Optometría), 319

Oberholzer, Emil, 379

Objetivos de Intereses Vocacionales de Strong (SVIB), 12, 522

Obligación de informar: Una obligación por mandato legal para advertir a terceros que se encuentran en peligro, y que se podría anular el privilegio del paciente. Terapeutas y asesores pueden tener un deber legal de advertir cuando un cliente expresa el intento de hacer daño a una tercera parte de cualquier forma, que puede ir desde la violencia física hasta la transmisión de una enfermedad, 59, 439

Observación conductual análoga: La observación de una persona o personas en un ambiente pensado para aumentar la oportunidad de que el evaluador advierta las conductas e interacciones objetivo, 410

Observación conductual: Monitoreo de las acciones de otros o de uno mismo a través de medios electrónicos, mientras se registra información cuantitativa y/o cualitativa relacionada con las acciones, por lo general, para propósitos relacionados con el diagnóstico y para diseñar una intervención o para medir el resultado de una intervención 10-11, 402, 407-409, 410-411, 431, 562

Observación naturalista, 11

Observación. *Véase* Observación conductual

Obsesiones socialmente reforzadas: etiología de un trastorno en una científica cristiana (Cohen & Smith), 434n

Obtención de historias, 464-466

Obtención de licencia. *Véase* Credencialización

OCQ (Cuestionario de Compromiso Organizacional), 552

ODDA (Ley de Muerte con Dignidad) (Oregon), 55-56

Oficina de Servicios Estratégicos de Estados Unidos (OSS), 2, 292, 349, 411, 540

On the Origin of Species by Means of Natural Selection (Darwin), 32

OOC (Análisis de la Cultura Organizacional), 554-555

Opinión pública, 45-47, 158, 233-234

Organicidad: Una referencia abreviada al deterioro orgánico cerebral y a una de las variedades de consecuencias funcionales que obedecen a dicho daño, 460-462

Orientación: Un elemento de tres partes del examen del estado mental que consiste en orientar sobre el yo (si el entrevistado sabe quién es), el lugar (en donde está teniendo lugar la entrevista), y el tiempo (la fecha

de la entrevista). Se orienta a los entrevistados respecto de la persona, el lugar y el tiempo, a lo cual se le llama "orientación 3", léase "orientación en tres tiempos", 427

Orientación psicológica, 419

Orientación vocacional, 339, 520-536
evaluación de la personalidad, 531-534
evaluación/orientación clínica, 420-421
medidas de intereses, 521-524
pruebas de aptitudes, 524-531
temas culturales, 369, 534
y teoría, 357

Originalidad, 297

OSS (Oficina de Servicios Estratégicos de Estados Unidos), 2, 292, 349, 411, 540

Pack contra K-Mart, 501

Países Bajos, 55

Panel de confidencias: Una variedad del panel de consumidores en la cual los que responden han acordado llevar un diario con sus pensamientos y/o comportamientos, 558

Panel de consumidores: Una muestra de personas que responden con base en un criterio demográfico o de otro tipo, contratados por una empresa de investigación de marketing o de consumo para responder la cual aplica de manera periódica cuestionarios, sondeos, y otros instrumentos relacionados con la investigación respecto de varios productos, servicios, publicidad y otros esfuerzos promocionales, 558

Panel de expertos: En el proceso de desarrollo de una prueba, un grupo de personas conocedoras sobre el tema específico que se está probando y/o la población para la cual se diseñó la prueba y que puede proporcionar ideas para mejorar su contenido, la imparcialidad de la prueba, y otras formas relacionadas, 224, 261

Pantalla de 7 minutos, 467

Pantomima, 491n

Papel social en la evaluación psicológica, 19-20, 44, 185. *Véase también* Aspectos legales

Papel: Actuar una parte improvisada o parcialmente improvisada en una situación simulada, 12, 411-412, 437

Pasión, 524

Pautas Modelo para los Programas de Pruebas de Integridad Previas a la Contratación (APTP), 532

PCAT (Prueba de Admisión del Colegio de Farmacología), 319

PCL (Lista de verificación de Psicopatía), 445

PCL-R (Lista de verificación de Psicopatías - Revisada), 445

PDI (Índice de Discapacidad Física), 512

Pearson r: También conocida como *coeficiente de correlación producto-momento de Pearson* y el coeficiente de *correlación de Pearson*, una estadística popular para obtener un índice de la relación entre dos variables cuando ésta es lineal y las dos variables correlacionadas son continuas (es decir, en teoría pueden adoptar cualquier valor), 115-118, 139-140, 165

Pearson, Karl, 33, 83, 115, 116, 248

Peligrosidad, evaluación de, 439, 440-441

Pelota de entrenamiento en neurodesarrollo, 25

Pennsylvania Department of Corrections v. Yeskey, 502

Pensamiento abstracto, 470-471

Pensamiento convergente, 297

Pensamiento de grupo, 10

Pensamiento divergente, 297

PEP (Programa de Examen Competencia), 310

Percentil: Una expresión del porcentaje de personas cuyas calificaciones en la prueba o medida caen por debajo de una puntuación cruda particular; una puntuación convertida que se refiere a un porcentaje de examinados; contrástese con *porcentaje correcto*, 106

Percepción estética, 25

Percepción, 381

Perfil: Una descripción narrativa, gráfica, tabular u otra representación, del grado al que una persona ha demostrado ciertas características objetivo como resultado de la aplicación de herramientas de evaluación; también es un verbo, *perfilear*, 339

Perfil de personalidad: Una descripción, gráfica o tabular en donde se representa el grado al que una persona ha manifestado un patrón, rasgo o estado particular, 339

Perfilador: Una ocupación asociada con la aplicación de la ley; aquel que crea perfiles psicológicos de sospechosos criminales para ayudar al personal que aplica la ley a capturar a dicho sospechoso, 339n

Periódico, artículos de, 26-27

Personalidad: La constelación única de rasgos y estados psicológicos de un individuo, incluyendo aspectos de valores, intereses, actitudes, visión del mundo, aculturación, sentido de identidad personal, sentido del humor, estilos cognitivos y de comportamiento, y características relacionadas, 254, 335-336. *Véase también* Evaluación de personalidad

Personalidad tipo A: En la tipología de Friedman y Rosenman, una

personalidad caracterizada por la competitividad, prisa, impaciencia, sentimientos de apremio del tiempo, y gran necesidad de logros y dominar, 339

Personalidad tipo B: En la tipología de Friedman y Rosenman, una personalidad caracterizada por rasgos opuestos a los de la personalidad tipo A: “sosegado” y “tranquilo”, 339

Personas de la tercera edad. *Véase* Evaluación geriátrica

Perspectiva histórica, 1-2, 31-37

cuestiones culturales, 38

inteligencia, 234-236, 237

opinión pública, 45-47

pruebas de inteligencia, 35-36, 39

Pertinencia de la confiabilidad y la validez en la evaluación conductual (Cone), 406

Piaget, Jean, 235-236, 237

PIC (Inventario de Personalidad para niños), 343

Piso, 271, 284

PL 101-336 Ley de los Derechos de los Ciudadanos Estadounidenses con Discapacidades (1990), 48, 490, 492, 500-501, 504

PL 101-476, 492

PL 105-17. *Véase* Ley de Reformas Educativas de 1997 para Individuos con Discapacidades (IDEA)

PL 94-142 (Ley de Educación para todos los Niños Minusválidos), 48, 300, 306, 492

PL 95-561, 252

PL 99-457 (Ley de Educación para todos los Niños Minusválidos, Enmiendas), 300, 492

Platicúrtica: Define la curtosis de una distribución de puntuaciones como relativamente plana en su parte media, 82

Pletismógrafo Penil: Un útil instrumento en la evaluación y tratamiento de infractores sexuales masculinos; diseñado para medir los cambios de volumen del pene en función de la excitación sexual, 412-413

Pletismógrafo: Instrumento que registra los cambios en el volumen de una parte del cuerpo como resultado de mayor o menor irrigación sanguínea a la zona, 412-413

Polígono de frecuencia: Una ilustración gráfica de datos donde los números que indican la frecuencia se ubican en el eje vertical, calificaciones de pruebas o las categorías se ubican en el eje horizontal, y los datos se describen mediante una línea continua que conecta los puntos donde las puntuaciones o categorías de la prueba se encuentran con las frecuencias, 70,

71

Polígrafo: El instrumento conocido como detector de mentiras, 413, 532

Política pública, 44

Ponderación, 95

Porcentaje correcto: En una prueba con respuestas calificadas como correctas o incorrectas, una expresión del número de reactivos contestados correctamente, multiplicado por 100 y dividido por el número total de reactivos; contrástese con *percentil*, 106

Portafolios: Una muestra de trabajo; a la que se conoce como *evaluación de portafolio* cuando se usa como herramienta en un proceso de evaluación o de diagnóstico, 10, 330, 539

PPVT-III (Prueba Peabody de vocabulario con imágenes), 497-498

Predicción actuarial: En la práctica clínica, la aplicación de reglas y probabilidades estadísticas demostradas empíricamente como factor de determinación en el juicio y las acciones clínicas; contrástese con *predicción clínica* y *predicción mecánica*, 417, 455, 456

Predicción clínica: En la práctica clínica, la aplicación del entrenamiento y la experiencia como un factor determinante del juicio y las acciones clínicas; contrástese con *predicción actuarial* y *predicción mecánica*, 417, 455-456

Predicción estadística. *Véase* Predicción actuarial

Predicción mecánica: En la práctica clínica y otros campos, la aplicación de reglas estadísticas y probabilidades, así como algoritmos por computadora, en la generación por computadora de hallazgos y recomendaciones computarizadas; contrástese con *predicción clínica* y *predicción actuarial*, 455-456

Preformacionismo: La doctrina de que las habilidades de una persona están predeterminadas por la herencia genética y que ningún aprendizaje u otra intervención pueden mejorar lo que está codificado genéticamente para desarrollarse, 246-247

Preformacionismo: La doctrina de que todos los organismos vivientes están preformados en el momento del nacimiento, y que la inteligencia, como otras “estructuras” preformadas, no puede mejorar mediante la intervención del ambiente, 246, 247

Presión: De acuerdo con el teórico Henry Murray, son los determinantes de la conducta que surgen dentro del

ambiente; contrástese con el concepto murrayano de *necesidad*, 387

Primera Guerra Mundial, 1, 36, 45, 291

Probar los límites: (1) En pruebas de habilidad, la administración continua de reactivos de la prueba más allá del nivel al cual el manual de la prueba indica la discontinuidad; por lo general se conduce sólo cuando el examinador tiene una razón para creer que un examinado puede “pasar” el nivel más alto de reactivos; (2) en la administración de la prueba Rorschach, una entrevista opcional después del interrogatorio inicial, en donde el examinador hace preguntas diseñadas para proporcionar nociones adicionales sobre los procesos de pensamiento y la personalidad del evaluado, 271n, 381, 516

Problemas de diversidad. *Véase* Temas culturales MMB (Medida de Motivos para Beber), 23

Procedimientos de la administración, 6, 16-18

criterio de calidad, 99

evaluación de personalidad, 348-349, 364, 380-381, 386-387

evaluación neuropsicológica, 470

métodos proyectivos, 380-381, 386-387

pruebas de inteligencia, 270-272

Véase también Evaluación psicológica asistida por computadora; Usuarios de las pruebas

y varianza del error, 96-97, 130-131, 141-142

Procedimientos no intrusivos: Un método de evaluación o tratamiento que no implica la intrusión (por procedimiento quirúrgico, rayos-X, u otros medios) adentro del cuerpo; por ejemplo, en una evaluación neuropsicológica, observación del cliente caminando o saltando, 467-469

Procesamiento central: Puntuación, interpretación y otras conversiones computarizadas de los datos crudos de la prueba, físicamente transportados del mismo sitio de prueba u otros; contrástese con *teleprocesamiento* y *procesamiento local*, 13

Procesamiento local: Calificación, interpretación o cualquier otra conversión de los datos crudos de la prueba realizada en sitio y de manera computarizada; contrástese con *procesamiento central* y *teleprocesamiento*, 13

Procesamiento paralelo. *Véase* Procesamiento simultáneo

Procesamiento secuencial. *Véase* Procesamiento sucesivo

Procesamiento simultáneo: También conocido como *procesamiento paralelo*;

- con base en los escritos de Luria, un tipo de procesamiento de información mediante el cual la información se integra y sintetiza de una sola vez y como un todo; contrástese con *procesamiento sucesivo*, 242, 322, 323
- Procesamiento sucesivo:** También se le conoce como *procesamiento secuencial*; basado en los escritos de Luria, un tipo de procesamiento de la información mediante el cual ésta se procesa en forma secuencial, poco a poco, y se arregla hasta que es lógica; contrástese con *procesamiento simultáneo*, 242, 322, 323
- Productividad:** Producción o valor obtenido relativo al esfuerzo del trabajo, 545-547
Professional Psychology: Research and Practice, 27
- Programa de colocación anticipada, 308
- Programa de Exámenes de Nivel Universitario** (CLEP), 308, 310
- Programa de examinación del desempeño (PEP), 310
- Programa para Trastornos Afectivos y Esquizofrenia (SADS), 424
- Programas de pruebas de competencia mínima:** Programa de evaluación formal en habilidades básicas tales como lectura, escritura, y aritmética, diseñado para ser usado en varios aspectos de la toma de decisiones educativas oscilando de regularización a promociones de grado a graduación, 47, 308, 309-310
- Promedio. Véase **Moda**
- Proposición 209 (California), 49, 545
- Protocolo:** (1) La forma u hoja en que se introducen las respuestas del evaluado; (2) un método o procedimiento de evaluación o puntuación, 17, 500, 501
- Protocolo ancla:** Una hoja de respuestas para pruebas desarrollada por un editor de pruebas con el fin de comprobar la precisión de las puntuaciones con que califican los examinadores, 230, 284
- Proyección de la personalidad en el dibujo de la figura humana: Un método para la investigación de la personalidad (Machover), 397
- Proyecto de Estudio de Casos Excepcionales (ECSP), 441
- Prueba: Un instrumento o procedimiento de medición, 5-8. Véase también *Pruebas psicológicas*
- Prueba Alpha para la Armada**, 291-292
- Prueba Aperceptiva de la Personalidad (APT), 391
- Prueba Azzageddi, 395
- Prueba Bender Gestalt:** Una herramienta para identificar deficiencias neurofisiológicas que implica copiar diseños; también se le llama simplemente “la Bender”; desarrollada por Lauretta Bender, M.D., 475-477
- Prueba Bennet de Comprensión Mecánica, 525
- Prueba Beta para la Armada**, 291-292
- Prueba Bohem de conceptos básicos, 513
- Prueba Breve de Inteligencia de Kaufman (K-BIT), 286
- Prueba Casa-Árbol-Persona (HTP), 398
- Prueba con imágenes de situación social, 384
- Prueba Controlada de Asociación de Palabras, 478
- Prueba cromatográfica de gas/espectrométrica de masa (GCMS), 543
- Prueba cronometrada. Véase *Prueba de velocidad*
- Prueba Culturalmente Imparcial de Cattell, 257, 258
- Prueba de Admisión a la Facultad de Ciencias de la Salud (AHPAT), 319
- Prueba de Admisión a la Facultad de Odontología (DAT), 319
- Prueba de Admisión a la Facultad de Optometría (OAT), 319
- Prueba de Admisión al Colegio de Farmacología (PCAT), 319
- Prueba de Admisión al Colegio de Medicina (MCAT), 319, 525
- Prueba de Admisión al Colegio de Veterinaria (VCAT), 319
- Prueba de Admisión al Programa de Contabilidad (Accounting Program Admission Test-APAT, APAT), 319
- Prueba de Admisión para Graduados en Administración, 319
- Prueba de Admisiones para la Escuela de Leyes (LSAT), 319
- Prueba de Analogías de Miller (MAT), 317-318
- Prueba de Apercepción con Figuras Humanas para Niños (CAT-H), 389, 447
- Prueba de Apercepción de la Educación, 389
- Prueba de Apercepción de Narración de Historias, para Niños (CAST), 389
- Prueba de Apercepción para Niños (CAT), 389
- Prueba de Apercepción para Niños, de Roberts (RATC), 389
- Prueba de Apercepción Temática (TAT), 226, 384-389, 391, 506, 509
- Prueba de Aptitud Diferencial, 253
- Prueba de aptitud:** Una prueba que por lo general centra su atención en las experiencias de aprendizaje informales, en oposición a las formales, diseñada para medir tanto el potencial de aprendizaje como el potencial innato, a fin de predecir el desempeño futuro de los examinados; también llamada una *prueba de pronóstico* y, en especial con niños pequeños, *prueba de disposición*, 311-318, 319, 524-531
- Prueba de Aptitudes Escolares (SAT), 88, 89, 109-110, 314-316
- Prueba de Asociaciones Remotas (RAT), 297
- Prueba de audición aperceptiva, 395
- Prueba de Autoconcepto de Beck, 341-342
- Prueba de Capacidad Otis-Lennon School
Prueba de capacidad, 253, 295
- Prueba de Capacidades Cognoscitivas, 295
- Prueba de Clasificación de Tarjetas de Wisconsin-Versión con 64 Tarjetas (WCST-64, Wisconsin Card Sorting Test-64 Card Version), 471
- Prueba de Competencia situacional, 437
- Prueba de Completar Frases de la Universidad de Washington, 393
- Prueba de Comprensión de lo que se Escucha, 61n
- Prueba de cualificación de Oficiales, 292
- Prueba de Destreza Herramienta-Mano, 525
- Prueba de destreza O'Connor Tweezer, 525
- Prueba de Detección de Afasia Reitan-Indiana (AST), 478
- Prueba de diagnóstico:** Una herramienta usada para elaborar un diagnóstico, implica identificar áreas con deficiencias hacia las cuales se va a dirigir la intervención, 20, 318-321
- Prueba de dibujo de la familia, 398
- Prueba de dirección:** Una subprueba usada para dirigir o encaminar al evaluado a un nivel adecuado de reactivos, 270, 307
- Prueba de disposición:** Una herramienta diseñada para evaluar si un individuo tiene los requisitos para iniciar un programa o realizar una tarea; algunas veces es sinónimo de *prueba de aptitud*, 313-314. Véase también **Prueba de aptitud**
- Prueba de Entendederas de la Corteza Superior Cultural/Regional (CRUST), 259
- Prueba de escenarios específicos para el alcohol, 437
- Prueba de Fluidez de Asociación Verbal, 478
- Prueba de Habilidad Motora de Bruininks-Oseretsky, 475, 512
- Prueba de Habilidades mentales primarias, 264-265
- Prueba de habilidades para la compra de abarrotes, 11
- Prueba de Historias a partir de Imágenes, 389
- Prueba de Identificación de Olores de la Universidad de Pennsylvania (UPSIT), 464
- Prueba de Ilustraciones de Michigan, 389
- Prueba de imágenes Blacky, 348, 389
- Prueba de imágenes de nubes, 378n
- Prueba de inmunoensayo, 543
- Prueba de integridad:** Un instrumento de detección diseñado para predecir quién será y quién no, un empleado honesto, 532

- Prueba de Inteligencia de Kaufman para adolescentes y adultos (KAIT), 286
- Prueba de Inteligencia Negra de Homogeneidad Cultural (BITCH por Black Intelligence Test of Cultural Homogeneity), 257, 260
- Prueba de Madurez Mental de California, 295
- Prueba de manchas de Tinta Rorschach, 37, 226, 379-384, 509
- Prueba de Nombramiento de Boston, 474
- Prueba de papel:** Una herramienta de evaluación donde los evaluados reciben instrucciones para actuar como si estuvieran en una situación en particular, 12, 411-412, 437
- Prueba de poder:** Una prueba, generalmente de logros o habilidades, con (1) tiempo ilimitado o un límite de tiempo tan amplio, que todos los evaluados pueden responder todos los reactivos, y (2) algunos reactivos tan difíciles que ningún evaluado puede obtener una calificación perfecta; contrástese con *prueba de velocidad*, 145
- Prueba de Rendimiento Cooperativo, 308
- Prueba de Rendimiento de Amplio rango-3, 306
- Prueba de rendimiento:** Evaluación del rendimiento o del grado de aprendizaje que ha tenido lugar, por lo general, con respecto de un área académica, 20, 305-311, 312, 509
- Prueba de respuesta al riesgo de la cocaína, 437
- Prueba de velocidad:** Una prueba, generalmente de alcances o habilidad, con un límite de tiempo; las pruebas de velocidad suelen contener reactivos para uniformar el nivel de dificultad, 41-42, 136, 145, 222
- Prueba del alcoholímetro, 147
- Prueba específica para una cultura, 38, 257, 260-261
- Prueba estandarizada:** Una prueba o medición que ha superado la estandarización, 105-106. *Véase también* Muestras de estandarización
- Prueba Gestalt Visual-Motora de Bender, 509
- Prueba imparcial a la cultura:** Una prueba o proceso de evaluación diseñada para minimizar la influencia de la cultura en varios aspectos de los procedimientos de evaluación, como son las instrucciones de administración, el contenido de los reactivos, las respuestas que se requieren del evaluado, y las interpretaciones elaboradas a partir de los datos resultantes, 256-257, 258-259
- Prueba Ishihara, 474
- Prueba Kent-Rosanoff de Libre Asociación, 392-393
- Prueba manual, 351, 390, 509-510
- Prueba Metropolitana de Rendimiento, 509
- Prueba Minnesota de Tareas Administrativas (MCT), 539
- Prueba Nebraska de Aptitud para el Aprendizaje, 508
- Prueba Peabody de vocabulario sobre Dibujos (PPVT-III), 497-498
- Prueba Prognóstica:** Herramienta de evaluación usada para predecir; algunas veces es sinónimo de *prueba de aptitud*, 312. *Véase también* **Prueba de aptitud**
- Prueba psicológica:** Un mecanismo o procedimiento de medición diseñado para medir variables relacionadas con la psicología, 5-6. *Véase también* **Pruebas psicológicas**
- Prueba Q- de Liderazgo, 352
- Prueba Seashore Bennet de Experiencia Estenográfica, 539
- Prueba Selectiva de Aptitud, 442
- Prueba sin la incidencia de aspectos culturales:** En psicometría, el concepto de una prueba que está desprovista de la influencia de cualquier cultura particular y, por tanto, no favorece a las personas de alguna cultura; es más un ideal que una realidad posible, puesto que todas las pruebas reflejan una cultura en mayor o menor grado, 256
- Prueba sobre la estructura del intelecto (EDI), 253
- Prueba socio-sexual de conocimiento y actitudes, 515-516
- Prueba Wechsler de Rendimiento Individual, 269
- Prueba Wechsler de Rendimiento Individual—Segunda edición (WIAT-II), 307
- Prueba Wepman de Discriminación Auditiva, 474-475
- Prueba Wonderlic de personal, 525
- Prueba Woodcock de Dominio de la Lectura-Revisada (WRMT-R), 320
- Pruebas, 5-8. *Véase también* Pruebas psicológicas
- Pruebas “todo en uno”, 306
- Pruebas a la medida. *Véase* Pruebas adaptativas
- Pruebas adaptadas a computadora (CAT):** Un proceso interactivo de administrar pruebas por computadora donde los reactivos presentados al examinado se basan, por una parte, en el desempeño del examinado y, por otra, en su desempeño con reactivos previos en la prueba, 205-206
- Pruebas adaptativas:** Un método o procedimiento de examinación que se distingue porque personaliza la presentación individual de los reactivos para el sujeto examinado, también se le conoce como *prueba a la medida*, *prueba secuencial*, *prueba alterna* y *prueba de respuesta contingente*, 270
- Pruebas alternas. *Véase* **Pruebas adaptativas**
- Pruebas contingentes a la respuesta. *Véase* Pruebas adaptativas
- Pruebas adaptativas
- Pruebas de asociación de palabras, 391-393
- Pruebas de asociación de palabras, 392
- Pruebas de capacidades mentales Henmon-Nelson, 295
- Pruebas de dibujo de figuras, 290-291, 395-399, 450, 509
- Pruebas de drogas, 543-544
- Pruebas de eficiencia en el idioma inglés, 308
- Pruebas de figuras anidadas, 351
- Pruebas de frases incompletas, 351, 352, 393-394
- Pruebas de habilidad escolar, 20, 295
- Pruebas de integración sensorial del sur de California, 485, 512
- Pruebas de Inteligencia de Kuhlmann-Anderson, 295
- Pruebas de inteligencia, 243-246, 264-299
- capacidades intelectuales específicas, 296-298
- confiabilidad, 151-152
- cuestiones culturales, 30, 38, 39-40, 255-261, 279
- efecto Flynn, 251, 254
- Escala Abreviada de Inteligencia Wechsler, 285-286
- Escala de Inteligencia Wechsler para Adultos, 35-36, 151-152, 260, 275-279, 284-285, 469-470
- Escala de Inteligencia Wechsler para niños en preescolar y primaria, 282-284, 302
- Escala de Inteligencia Wechsler para niños, 38, 39-40, 104-105, 229-230, 279-282
- formas cortas, 284-285
- infantes, 304-305
- militar, 291-295
- muestreo normativo, 104-105
- perspectiva histórica, 35-36, 39
- pruebas Kaufman, 286
- puntuaciones estándar en, 88-89
- puntuaciones, 131-132
- recursos en la Web, 298-299
- repaso de pruebas Wechsler, 273-275
- tipos de tareas, 243-244
- varianza de error en, 131
- y curva normal, 84, 85
- y dotes, 252-253
- y escalas ordinales, 65
- y evaluación neuropsicológica, 469-470
- y normas de edad, 107
- y personas con discapacidades, 506, 508
- y teorías de la inteligencia, 244-246, 278, 279-280, 282
- Véase también* Escalas de Inteligencia Stanford-Binet

Pruebas de lectura, 308, 319-320
 Pruebas de manchas de tinta, 37, 226, 379-384
 Pruebas de Matemáticas, 320-321
 Pruebas de memoria, 478-481
 Pruebas de Pensamiento Abstracto y Concreto de Goldstein-Scheerer, 461
 Pruebas de percepción y motricidad, 474
 Pruebas de Rendimiento de California, 307
 Pruebas diagnósticas de grupo, 321
 Pruebas físicas para el empleo, 541-544
 Pruebas grupales de inteligencia, 36, 291-296
 Pruebas Metropolitanas de Disposición (MRT), 313-314
 Pruebas Metropolitanas de Instrucción de Lectura, 320
 Pruebas Metropolitanas de Instrucción de Matemáticas, 320
 Pruebas militares, 24, 36, 291-295, 349, 411, 540
 Pruebas perceptuales, 474-477
 Pruebas proyectivas con base en dibujos, 290-291, 395-399, 450, 509
Pruebas psicológicas: La medición de variables relacionadas con la psicología, sirviéndose de mecanismos o procedimientos diseñados para obtener muestras de conducta supuestos al informar, 92-98
 definición, 2-3, 5-6
 repaso, 5-8
 criterio de calidad para, 98-99
 Pruebas secuenciales. *Véase* Preparación para pruebas adaptativas, 20-23, 347, 405
 Pruebas Stanford de Rendimiento, 509
 Pruebas Torrance de Pensamiento Creativo, 297
 Pruebas Wechsler, 273-275, 284, 286. *Véase también* pruebas específicas
Pruebas y evaluación con referencia a un criterio: También se le llama *pruebas o evaluaciones con referencia a un dominio* y *pruebas o evaluaciones con referencia al contenido*, un método de evaluación y una forma de derivar significados a partir de las puntuaciones de la prueba al evaluar las puntuaciones de un individuo con referencia a un estándar establecido (o criterio); *contrástese con pruebas o evaluaciones con referencia a una norma*, 110, 113-114, 145-146, 192-193
 Pruebas y evaluación con referencia al contenido, 113. *Véase también* Pruebas y evaluación con referencia a un criterio
 Pruebas y evaluaciones con referencia al dominio, 113. *Véase también* Pruebas y evaluaciones con referencia a un criterio
 PSAT/NMSQT (SAT Preliminar/Nacional Calificadora para Becas al Mérito Nacional), 316
 Pseudodemencia, 466
 PSI (Índice de estrés de los Padres), 101, 451

PsycARTICLES, 28
 Psicohistoria, 438
 Psicología clínica, 419
Psicología de la salud: Un interés especial de la psicología que se enfoca en entender el papel de las variables psicológicas en el inicio, o curso, tratamiento o prevención de enfermedad, enfermedad o discapacidad, 23
Psicología del consumo: La rama de la psicología social que se refiere principalmente al desarrollo, publicidad, y comercialización de productos y servicios, 554-563
 actitudes, 556-559
 investigación de motivaciones, 559-563
 Psicología experimental, 33-34
Psicómetra: Un profesional en pruebas y evaluación que por lo general tiene un grado de maestría en psicología o educación y está calificado para aplicar pruebas específicas, *contrástese con psicometrista*, 8n
Psicometría: La ciencia de la medición psicológica (sinónimo del término anticuado *psicometría*, 8. *Véase también* **Confiabilidad**; **Validez**
Psicometrista: Un profesional en pruebas y evaluaciones que por lo general tiene un grado doctoral en psicología o educación, y se especializa en áreas como diferencias individuales, psicología cuantitativa, o teoría de la evaluación; *contrástese con psicómetra*, 8n
 Psicópatas, 445
Psychodiagnostics (Rorschach), 379
Psychological Bulletin, 27
Psychological Clinic, 35
Psychological Review, 27, 35
Psychology & Marketing, 27
Psychology in the Schools, 27
Psychology, Public Policy and Law, 27
PsycINFO: Base de datos en línea de la American Psychological Association y alquilada a usuarios institucionales, diseñada para ayudar a localizar documentos relevantes sobre psicología, educación, enfermería, trabajo social, derecho, y medicina, entre otras disciplinas, 27
 PsycLAW, 28
 PsycSCAN: Psicofarmacología, 28
 Punción lumbar, 487
Puntaje: Un código o afirmación resumida, que por lo general es numérica, aunque no necesariamente, y refleja una evaluación del desempeño en una prueba, tarea, entrevista u otra muestra de conducta, 6. *Véase también* **Puntuación**
Puntaje estándar: Un puntaje bruto que se ha convertido de una escala a otra, la última (1) tiene alguna

media y desviación estándar establecidas arbitrariamente, y (2) se usa más ampliamente y es más fácil interpretarla; ejemplos de puntajes estándar son los Z y T, 86-90
Puntuación: El proceso de asignar códigos de evaluación o afirmaciones sobre el desempeño en las pruebas, tareas, entrevistas, u otras muestras de conducta, 6-8, 18
 definida, 6
 desarrollo de pruebas, 210-211
 evaluación de personalidad, 352-353, 381-382
 pruebas de inteligencia, 88-89, 272-273
 suposiciones al informar, 95
 varianza del error, 131-132
Véase también Interpretación
Puntuación: Un juicio numérico que coloca a una persona o atributo a lo largo de un continuo identificado por una escala de descripciones numéricas o verbales, llamada *escala de puntuación*, 183
Puntuación de corte: También conocido como *corte*, un punto de referencia, usualmente numérico, derivado como resultado de un juicio, que se emplea para dividir un conjunto de datos en dos o más grupos o clasificaciones, mismos que pueden ser categorizados en función de la realización de inferencias o interpretaciones de dichos puntajes, 6-7, 102, 113
Puntuación T, uniforme: Se abrevia *UT*, Una variedad de las puntuaciones *T* que se usan en el MMPI-2, 366
Puntuación T: Nombradas así por Thorndike, es una puntuación estándar que se despeja usando una escala estableciendo su media en 50 y la desviación estándar en 10; es la medida elegida por los desarrolladores de la MMPI. (En la medida que surgieron los problemas técnicos en las puntuaciones de los protocolos de MMPI con puntuaciones *T*, algunos investigadores sugirieron que las puntuaciones se reemplazaran por puntuaciones Puntuación *UT*. *Véase* Puntuación *T* *uniforme*
Puntuación Z: Una puntuación estándar es igual a la diferencia entre una puntuación cruda particular y la media dividida entre la desviación estándar; una puntuación *z* expresa una puntuación en términos del número de unidades de desviación estándar en que la puntuación cruda está por debajo o por encima de la media de la distribución, 87
 Puntuaciones equivalentes de edad. *Véase* **Normas de edad**
 Puntuadores. *Véase* Calificadores

QUID: Por sus palabras en inglés, acrónimo para *qualified individual with a disability* (“individuo calificado con una discapacidad”) se refiere en especial a la Ley de Estadounidenses con Discapacidades de 1990; un empleado con discapacidad quien reúne las exigencias del empleador respecto de educación, habilidades, y otros requerimientos para el trabajo quien además puede desempeñar las funciones características del puesto con o sin “acomodación” al lugar de trabajo, 501

Raising Children with Love and Limits (Cattell), 34

Ramificación de reactivos: En la administración de pruebas adaptadas a la computadora, la presentación individualizada de los reactivos de la prueba seleccionados de un banco de reactivos con base en las respuestas previstas del examinado, 206, 210

Rango intercuartil: Una estadística ordinal de variabilidad igual que la diferencia entre los puntos del primer y el tercer cuartil en una distribución que ha sido dividida en cuartiles, 78

Rango semiintercuartil: Una medida de variabilidad igual al rango intercuartil dividido entre dos, 78

Rango: Una estadística descriptiva de variación obtenida a partir de calcular la diferencia entre los registros menor y mayor en una distribución, 78, 144-145, 165

Rapport: Una relación profesional entre el examinador y el examinado en una prueba o evaluación, 17-18, 270

Rasch model, 219

Rasch, Georg, 219

Rasgo: Cualquier forma distintiva, relativamente perdurable que diferencia a un individuo de otro; contrástese con *estado*, 92-95, 126, 336-337, 358

Rasgo de personalidad. Véase **Rasgo**

Rasgo psicológico, 92. Véase también **Rasgo**

Rasgos superficiales, 358

Rastreo cerebral, 486

RAT (Prueba de Asociaciones Remotas), 297

RATC (Prueba de Apercepción para Niños, de Roberts), 389

Raza

acción afirmativa, 44, 50-51

ajustes a la puntuación de la prueba, 186-188

aspectos legales, 50-51

evaluación de personalidad, 369

muestras de estandarización, 279, 282-283

normas, 102, 526, 530-531

pruebas de inteligencia, 47, 279, 282-283

teorías de inteligencia, 248

Véase también Muestras de estandarización

Rasgos fuente, 358

Razón de CI: Un índice de inteligencia obtenido a partir de la razón entre la edad mental del evaluado, calculada en una prueba, y su edad cronológica, multiplicado por 100 para eliminar los puntos decimales, 267

Razón de selección, 167

Razón de validez de contenido (CVR): Una fórmula desarrollada por C. H. Lawshe, que se usa para valorar el acuerdo entre evaluadores respecto de qué tan esencial es un reactivo individual para seguir siendo incluido en una prueba, 160

RCRAS (Escala de Evaluación de Responsabilidad Criminal), 444

Reactividad: Cambios en la conducta de un evaluado, en su pensamiento o desempeño, que surgen en respuesta a ser observados, analizados o evaluados, 410, 416

Reactivo de campo de búsqueda, 473, 474

Reactivo de completar, 204

Reactivo de ensayo, 204-205

Reactivo de respuesta corta, 204

Reactivo de seguir una pista: Un reactivo que vincula capacidades cognitivas como visual-conceptual, visual-motora, y planear entre otras a través de una tarea en la cual el examinado tiene que conectar los círculos de una manera lógica; en la Batería Neuropsicológica de Halstead-Reitan, el componente denominado Prueba de Hacer Senderos, es uno de los instrumentos de uso más extendido en la evaluación de lesión cerebral, 472, 473

Reactivo de selección binaria, 204

Reactivo didáctico, 270

Reactivo falso/verdadero, 204, 350

Reactivo regalado, muy fácil, 213

Reactivos de absurdos en imágenes, 473, 474

Recentrado, 315-316

Recursos en la Web, 28, 29, 30

evaluación relacionada con el negocio, 564-565

evaluación clínica/orientación, 457

aspectos culturales, 61

evaluación educativa, 333-334

Health Insurance Portability and

Accountability Act (Decreto sobre la Portabilidad y Responsabilidad del Seguro de Salud), 61

inteligencia, 263

pruebas de inteligencia, 298-299

evaluación neuropsicológica, 488-489

personas con discapacidades, 519

evaluación de personalidad, 375, 418

pruebas psicológicas, 128

confiabilidad, 155

estadísticas, 91

desarrollo de pruebas, 231

validez, 189

Redacción de reactivos, 201-210

y psicología del consumidor, 558

y formato del reactivo, 202-205, 206

y reserva de reactivos, 201-202

y ensayo de la prueba, 212

Iverson contra Frandsen, 60

Referencias, 4

Reflejo: Respuesta motora involuntaria a un estímulo, 468

Regentes de la Universidad de California, 48, 50, 51

Registro de eventos (frecuencia), 405

Registro simple: Un registro directo y sin modificar del desempeño, por lo general es numérico y se usa para la evaluación o el diagnóstico, 68, 86-87

Regresión: El análisis de las relaciones entre variables para comprender cómo una variable puede predecir otra, 122-125, 181-182, 183

Regresión múltiple: El análisis de las relaciones entre más de una variable independiente y una variable dependiente para entender la forma en que cada variable independiente predice la variable dependiente, 124-125

Regresión simple: El análisis de la relación entre una variable independiente y otra dependiente, 122

Reik, Theodor, 417

Reitan, Ralph, 483

Relevancia, 163

Reporte de detección: Un tipo de reporte interpretativo que proporciona información sobre cada una de las escalas, y sobre la relación entre algunas de ellas, 13

Reporte de puntuación sencilla: Un tipo de reporte de puntuación que proporciona sólo una lista de los puntajes, 13

Reporte de puntuación: Un reporte formal u oficial generado por computadora del desempeño en una prueba, generalmente representado con números; las dos variedades son el *reporte simple de puntuación* (que contiene sólo un reporte de los puntajes) y el *reporte extendido de puntuación* (que contiene estadísticas de los reactivos); contrástese con *reporte interpretativo* y *reporte integrativo*, 13

Reporte descriptivo: Un tipo de reporte de interpretación que presenta resúmenes narrativos breves, escala por escala, 13

Reportes psicológicos generados por computadora, 13

Reportes psicológicos, 13, 451-456

Reseñas de la literatura, 562, 563

- Reserva de reactivos:** Pozo o provisión del cual se seleccionan (o descartan) los reactivos que comprenderá la versión final de una prueba, 201-202, 226
- Solucionador,** 230
- Respuesta a la orientación:** Indicador de la capacidad de respuesta de un infante, la acción de voltear en dirección de un estímulo; contrástese con *respuesta de alerta*, 243
- Respuesta de alerta:** Abrillantamiento y mayor apertura de los ojos en respuesta a un estímulo, indicativo de la capacidad del infante para responder, 243
- Restricción de la varianza.** Véase *Restricción de rango*
- Restricción de rango:** También se le conoce como *restricción de la varianza*, un fenómeno asociado con estimados de confiabilidad, donde la varianza de cada variable en un análisis correlacional está restringida por el procedimiento de muestreo empleado, y el coeficiente de correlación resultante tiende a ser menor como consecuencia; *contrástese con inflación del rango*, 144-145, 165
- Retiro,** 536
- Retraso en el desarrollo:** Progreso más lento de lo esperado, usualmente con base en normas de edad, con respecto al potencial físico, cognitivo, social, emocional, adaptativo o de comunicación, 495
- Retroceso en la línea del tiempo (TLFB), metodología,** 405
- Revisión de la prueba,** 225-230, 365-369
- Revisión de sensibilidad:** Un estudio de los reactivos de pruebas que suele hacerse durante el desarrollo de las mismas, donde se examina la adecuación de los reactivos respecto a todos los evaluados prospecto y para revisar la presencia de lenguaje ofensivo, estereotipos o situaciones, 224
- R-FVII (Inventario de Interés Vocacional Libre de Lectura),** 524
- Rho de Spearman:** También se le conoce como *coeficiente de correlación ordenado por rango* y *coeficiente de correlación diferenciado por rango*; este índice de correlación es el adecuado cuando el tamaño de la muestra es pequeño y ambos conjuntos de mediciones son ordinales, 118, 176
- RIASEC.** Véase *Tipos de personalidad vocacional Big Six*
- RNEE (Entrance Examination for Schools of Nursing),** 319
- Rogers, Carl,** 352
- Rorschach, Hermann,** 37, 379
- Rosenzweig, Saul,** 394
- SADS (Programa para Trastornos Afectivos y Esquizofrenia),** 424
- SAT (Prueba de Apercepción para Ancianos),** 389
- SAT (Prueba de Aptitudes Escolares),** 88, 89, 109-110, 314-316
- SAT Preliminar/Nacional Calificadora para Becas al Mérito Nacional (PSAT/NMWSQT),** 316
- SATB (Batería de pruebas de Aptitudes Especiales),** 526
- Satisfacción con el trabajo:** Estado emocional confortante o positivo como resultado del aprecio del trabajo que uno realiza o de la experiencia en el trabajo, 551-552
- School Psychology Quarterly,* 27
- School Psychology Review,* 27
- SCID-O (Entrevista clínica estructurada para trastornos disociativos),** 424
- SCII (Inventario de Intereses de Strong-Campbell),** 522
- SD (escalas de atractivo social),** 354
- SDMT (Prueba Diagnóstica de Matemáticas de Stanford),** 320, 321
- SDRT (Prueba Diagnóstica de Lectura de Stanford),** 320, 321
- SDS (Búsqueda Autodirigida),** 339, 357, 523, 524
- Segunda Guerra Mundial,** 1, 36, 46, 292, 549, 540
- Selección:** Un proceso donde cada persona evaluada para un puesto es aceptada o rechazada; *contrástese con detección, clasificación y colocación*, 536
- Self-Help Agency Satisfaction Scale,** 556
- SEM. Véase Error estándar de una medición**
- Señal suave:** En la evaluación neuropsicológica, una indicación de que el déficit neurológico puede estar presente; por ejemplo, una discrepancia significativa entre las subpruebas verbales y de desempeño en una prueba Wechsler, 462
- Series STEP,** 306-307
- Servicio de Empleo de Estados Unidos (USES),** 526, 531
- Servicio de Pruebas Educativas (ETS),** 28
- Servicio Secreto de Estados Unidos,** 440-441
- Servicio secreto,** 440-441
- Sesgo:** Como se aplican a las pruebas, es un factor inherente a la prueba que evita de manera sistemática la medición precisa e imparcial.
- y análisis de reactivo, 221-222
- y confiabilidad, 147
- y entrevistas de panel, 8
- y evaluación conductual, 416
- y evaluación de personalidad, 344
- y gráficas, 73
- y prueba de aptitud, 530
- y validez, 181
- Véase también *Imparcialidad*
- Sesgo:** Una indicación de la naturaleza y extensión en que está ausente la simetría en una distribución; se dice que una distribución tiene sesgo positivo cuando relativamente pocos puntajes quedan en el rango positivo, y que tiene sesgo negativo cuando relativamente pocos puntajes quedan dentro del rango negativo, 81-82
- Sesgo de intersección:** Se refiere al punto en el cual la línea de regresión intersecta el eje-Y; se refiere a una prueba o procedimiento de medición que sistemáticamente predice más o menos el desempeño de los miembros de un grupo; *contrástese con sesgo de la pendiente*, 182, 530
- Sesgo de la pendiente:** Una referencia a la pendiente de una línea de regresión diferente entre grupos; este término se refiere a un procedimiento de medición de pruebas que proporciona diferentes coeficientes de validez de forma sistemática para miembros de diferentes grupos; *contrástese con sesgo de intersección*, 182, 530
- Sesgo negativo,** 81
- Sesgo positivo,** 81
- Shakow, David,** 394
- SIB (batería de disfunción severa),** 485
- SICD (Inventario Secuenciado de Desarrollo de la Comunicación),** 478
- Signo duro:** En evaluación neuropsicológica, un indicador definitivo de deficiencia neurológica, tal como sería una respuesta anormal de reflejo; *contrástese con signo suave*, 462
- SII (Inventario de Intereses de Strong),** 522-523
- Simon, Theodore,** 35, 265
- Simulaciones por computadora,** 540
- SIRS (Entrevista estructurada de Síntomas Reportados),** 424
- Sistema de calificación de Goodenough-Harris,** 290-291
- Sistema de calificación de grupo de referencia fija:** Un sistema de calificación en el cual la distribución de puntuaciones obtenida en la prueba de un grupo de examinados (el grupo de referencia fija) se emplea como base del cálculo de las calificaciones de prueba para futuras administraciones; la SAT y la GRE se califican de esta forma, 109-110, 111-112
- Sistema de Codificación de Interacción de Parejas,** 407
- Sistema de Codificación de Interacción Marital,** 407, 416
- Sistema de Dibujo Cinético (KDS),** 398
- Sistema de Evaluación Cognoscitivo (CAS),** 242, 286

Sistema de evaluación del comportamiento Adaptativo (Adaptive Behavior Assessment System, ABAS), 514

Sistema de Guía de Información (GIS), 524

Sistema de justicia criminal. *Véase* Evaluación psicológica forense

Sistema límbico, 459

Sistema nervioso central, 458

Sistema nervioso periférico, 458

Sistema nervioso, 458-459

Sistema Tyler de Clasificación Vocacional, 352

Sistemas Quota, 50

Sitios de pruebas en Internet, 54, 57

Skinner, B. F., 394, 395

Sociograma: Una representación gráfica de datos iguales de evaluación, u otra información interpersonal, 332

Sordera. *Véase* Cultura de sordos; Discapacidades auditivas

Spearman, Charles, 35, 118, 119, 237-238

Sputnik, 46

SRA (Pruebas de Rendimiento de California), 307

SSHA (Encuesta de Hábitos y Actitudes Estudio), 333

SSS (Escala de Búsqueda de Sensaciones), 93

STAI (Inventario de Estado-Rasgo de Ansiedad), 340

Standards for Educational and Psychological Testing (AERA, APA, NCME), 16, 45, 57, 113n

Stem, Wilhelm, 378n

Stigma, 60

Strauss, Alfred, 460

Strong, Edward K., Jr., 522

Subprueba complementaria, 280, 283

Subjetividad

- confiabilidad, 140, 143-144
- evaluación de personalidad, 344
- puntuación de corte, 7
- varianza del error, 132

Subprueba central, 280

Subprueba Wechsler de similitudes, 470

Subpruebas opcionales, 283

Suicidio asistido por un médico, 55-56

Suicidio asistido, 54, 55-56

Sumador verbal, 394

Sutton vs. United Airlines, 501

SVIB (Objetivos de Intereses Vocacionales de Strong), 12, 522

T normalizadas; por último los desarrolladores de la MMPI-2 estuvieron de acuerdo en usar lo que llamaron una *puntuación T uniforme o UT*), 87-88, 366

Tabla de expectativas: Información presentada en forma tabulada que ilustra la probabilidad de que un examinado obtenga calificaciones dentro de cierto intervalo de puntuaciones de una medida criterio, 167-171

Tablas Naylor-Shine, 170

Tablas Taylor-Russell, 167, 169-171

Tablero de Formas de Seguin-Goddard, 481

TAC (tomografía axial computarizada), 486

Tálamo, 459

Tarasoff contra los Regentes de la Universidad de California, 48, 59, 439

Tasa base: Un índice, usualmente expresado como proporción del grado en que un rasgo, comportamiento, característica, o atributo particular existe en una población, 167, 171, 172-173

TAT (Prueba de Apercepción Temática), 226, 384-389, 391, 506, 509

Tautófono, 394

Technical Recommendations for Achievement Tests (NEA), 52

Technical Recommendations for Psychological Tests and Diagnostic Tests (APA), 52

Techo, 271, 284

Técnica ¿adivina quién?, 331

Técnica de dibujo en colaboración, 398

Técnica de diferencial semántico:

- Un formato de reactivo que se caracteriza por contener adjetivos bipolares separados por una escala de clasificación de 7 puntos, de entre los cuales los examinados habrán de seleccionar el número que corresponda a su respuesta, 350, 558

Técnica de distribución forzada:

- Un procedimiento que supone la distribución de un número predeterminado, o porcentaje de personas evaluadas dentro de varias categorías que describen el desempeño (tal como categorías que oscilan de “insatisfactoria” a “superior”), 546

Técnica de incidentes críticos:

- En escenarios de trabajo, un procedimiento que implica la grabación del comportamiento de un empleado que se evalúa como positivo o negativo por un supervisor u otro calificador, 546

Técnica de la bandeja de entrada, 541

Técnica de Manchas de Tinta Holtzman (HIT), 382n

Técnica de nominación: Un método de apreciación entre compañeros en el cual se le pide a los miembros de una clase, equipo, unidad laboral, u otro tipo de grupo, que seleccionen (o nombren) a una persona en respuesta a una pregunta o afirmación, 253, 331-332

Técnica del grupo sin líder, 411, 541

Técnica Q-sort: Técnica de evaluación que implica la tarea de clasificar de entre un grupo de afirmaciones, casi siempre en el orden en que se perciben las categorías, que va de “más descriptivo” a “menos descriptivo”; la tradicional

presentación de los textos en fichas permite varias formas de clasificación y por tanto, el reflejo de varias percepciones, tal como la forma en que a los examinados les gustaría verse a sí mismos, 351-352

Prueba de Apercepción para Ancianos (SAT), 389

Teleprocesamiento: Puntuación computarizada, interpretación u otra conversión de los datos enviados mediante líneas telefónicas por módem desde un sitio de pruebas hasta una ubicación central para que se procesen por computadora; contrástese con *procesamiento central* y *procesamiento local*, 13

Temas culturales, 37-44

- aculturación, 370-373
- cultura organizacional, 552-553, 554-555
- e inferencia, 125-127
- en la evaluación clínica/orientación, 429-434
- en pruebas de inteligencia, 30, 38, 39-40, 255-261, 279
- identidad, 374
- muestras normativas, 101
- normas raciales, 102, 526, 530-531
- valores, 372-374
- y abuso de sustancias, 437
- y evaluación de la personalidad, 345, 355, 369-374, 430-431
- y orientación vocacional, 369, 534
- y personas con discapacidades, 507, 517-518
- y validez de contenido, 161-162

TEMAS, 389

Temperamento: Con referencia a la evaluación de personalidad de infantes, es la manera distintiva de las acciones y reacciones observables del niño, 254, 534

Tendencia central, medida de. *Véase* **Medida de la tendencia central**

Teoría clásica de la prueba. *Véase* Teoría de la puntuación verdadera

Teoría de expectativas de la motivación, 549

Teoría de la decisión, 171-175

Teoría de la generalización: También conocida como *Teoría del muestreo de dominio*, un sistema de suposiciones sobre la medición que incluye la noción de que la calificación de la prueba, e incluso, la respuesta a un reactivo individual, se forma con un componente relativamente estable que de hecho, es para lo cual ha sido diseñada la prueba o el reactivo individual para medir, y componentes relativamente inestables que en conjunto pueden tomarse en cuenta para un error, 102, 104, 148-149, 414

Teoría de la inteligencia de Guilford, 238-239
Teoría de la personalidad vocacional, 357, 369, 523

Teoría de la puntuación verdadera:

También se le conoce como *Modelo de la puntuación verdadera* o *teoría clásica de la prueba*, sistema de supuestos sobre la medición en el que la noción de que una puntuación de prueba e, incluso, la respuesta a un reactivo individual, se integran de un componente relativamente estable para el cual tanto la prueba como el reactivo individual están diseñados para medir, y otro componente aleatorio que es error; contrástese con *modelo del rasgo latente*, 97, 130, 132, 134n, 146, 220, 414

Teoría de los dos factores de la inteligencia: Teoría de la inteligencia general de Spearman, quien postula la existencia de un factor de capacidad intelectual general (g) el cual está oculto parcialmente por todas las otras capacidades mentales, 237-238

Teoría de los tres estratos de las habilidades cognoscitivas: La concepción de John B. Carroll sobre las habilidades y el procesamiento mental, clasificados en tres niveles de estratos con g en el nivel más amplio, seguido de ocho habilidades o procesos en el segundo nivel, y algunas de las habilidades y procesos descritos más brevemente, en el tercero, 239-240, 245

Teoría de inteligencias múltiples, 239

Teoría de respuesta al reactivo (IRT): Esta teoría, conocida también como *Teoría de rasgo latente* o *modelo de rasgo latente*, plantea un sistema de supuestos sobre la medición, que incluye el supuesto de que el rasgo que se está midiendo con la prueba es unidimensional, y quizá hasta el grado en el cual mide dicho rasgo cada uno de los reactivos en la prueba, 149, 219-220, 272

Teoría de utilidad de la prueba, 171. Véase también Teoría de las decisiones

Teoría evolutiva, 32-33, 423

Teoría multifactorial de la inteligencia de Thorndike, 245, 278

Teoría psicoanalítica, 33n, 41, 348, 356-357, 389, 394

Teoría triádica de la inteligencia, 242

Teorías de procesamiento de información, 236, 241-242, 322, 323

Terman, Lewis M., 248, 250-251, 265

“Termitas”: Referencia humorística sobre niños dotados que participaron en el estudio sobre inteligencia de Lewis M. Terman iniciado en 1916, 250

Testimonio del experto, 502-503, 504

Tests in Microfiche, 28

Tests in Print (Murphy et al.), 26
The international Classification of Functioning, Disability, and Health (WHO); 491

The Kallikak Family (Goddard), 247
The Measurement of Intelligence in Infants and Young Children (Cattell), 34

Thema: En la teoría de la personalidad de Henry Murray, una unidad de interacción entre necesidades y presiones, 387

Theories of Personality (Hall & Lindzey), 335-336

Thorndike, E. L., 88, 245, 278

Thurstone, Louis L., 194, 264

Tipo: Como en el *tipo de personalidad*, una constelación de rasgos y estados semejantes en patrón a una categoría identificada de la personalidad dentro de una taxonomía de personalidades, 338-339

Tipo de personalidad. Véase **Tipo**

Tipos de personalidad vocacional *Seis Grandes*, 357, 369, 523, 531

Titchener, E. B., 35

TLFB (Retroceso en la línea del tiempo) metodología, 405

Tomografía axial computarizada (TAC) por escaneo, 486

Torre de Hanoi, 471

Trabajo piloto: En el proceso de conceptualización de la prueba, la investigación preliminar relacionada con la creación de una prueba prototipo; también se le conoce como *estudio piloto* e *investigación piloto*; uno de sus objetivos generales es determinar la mejor manera de medir, estimar, analizar o evaluar el(los) constructo(s) objetivo, 193-194

Trabajos de Luria. Véase Teorías del procesamiento de información

Traducción, 431

Transformación lineal: En psicometría, un proceso de cambiar una calificación tal que la nueva calificación tenga una relación numérica directa con la calificación original, y la magnitud de la diferencia entre la nueva calificación y otras calificaciones en la escala es semejante a la magnitud de diferencias entre la calificación original y las de las escalas de donde se derivó; contrástese con *transformación no lineal*, 89

Transformación no lineal: En psicometría, el proceso de cambiar una calificación en una nueva puntuación de tal forma que esta última no necesariamente guarde una relación numérica lineal con la original, y la magnitud de las diferencias entre la nueva calificación y las otras calificaciones en la escala pueden no semejar la magnitud de las diferencias entre la calificación original y las otras

en las escalas de donde se derivó la calificación original; contrástese con *transformación lineal*, 89-90

Transformaciones estimadas de calificación verdadera, 183

Transición de carreras, 535-536

Translate This Darkness: The Life of Christiana Morgan (Douglas), 385

Trastorno de hiperactividad de deficiencia de atención (ADHD), 300-301

Trastorno de hiperactividad por déficit de atención, 300-301

Trastornos mentales, 421-423

Tres grandes factores de personalidad Tellegen's, 531

Tribunales. Véase **Evaluación psicológica forense**

Tugg contra Towey, 490, 517

“Two Tails of fue Normal Curve” (Robinson et al.), 85-86

Types of Men (Spranger), 372

Uniform Guidelines on Employee Selection Procedures, 47, 49

Universo de puntuación: En la teoría de la generalización, una puntuación de prueba que corresponde a un universo particular que es evaluado, 148

Universo: En la teoría de la generalización, el contexto total de la situación de una prueba particular, que incluye todos los factores que llevan a la puntuación de prueba de un examinado, 148

UPSIT (Prueba de Identificación de Olores de la Universidad de Pennsylvania), 464

USES (Servicio de Empleo de Estados Unidos), 526, 531

Usuarios de las pruebas calificaciones de, 52-53
evaluación conductual, 404-405
revisión general, 16-18
y estudios locales de validez, 157
y normas locales, 109
y personas con discapacidades, 498-499
y validez, 165-166
y varianza del error, 96-97

Véase también **Confiabilidad entre evaluadores**

VABS (Escala Vineland de Comportamiento Adaptativo), 514-515

Validación cruzada: Una reevaluación sobre una muestra de personas distinta a la de aquellas que respondieron la prueba y cuyo desempeño en la prueba se encontró originalmente como predictor válido de cierto criterio, 226, 228

Validación: El proceso de reunir y evaluar la evidencia de validez, 157

Validez: Término general que se refiere a un juicio respecto de que tan bien miden una prueba u otra herramienta

de medición lo que se supone deben medir; este juicio tiene implicaciones importantes respecto de lo adecuado que puedan ser las inferencias que se hacen y las acciones que se toman con base en la medida, 98-99, 101, 156-189

constructo, 175-180

contenido, 159-162

cuestiones de de imparcialidad, 184-188

Escala Wechsler de Inteligencia para adultos, 278

Escalas de Inteligencia Stanford-Binet, 269-270

métodos proyectivos, 388-389

Prueba de Evaluación Escolástica, 315, 285

prueba de fármacos, 543-544

revisión del concepto, 156-158

rostro, 158

y análisis del reactivo, 214-215

y pruebas en el salón de clases, 195

y sesgo, 181-184

Véase también **Validez relacionada con el criterio**

Validez aparente: Un juicio respecto de qué tan bien mide lo que se propone medir una prueba u otro instrumento de medición, tomando como base únicamente la “apariciencia” tal como el contenido de los reactivos de la prueba, 158

Validez concurrente: Una forma de validez relacionada con un criterio que es un índice del grado al cual una puntuación de prueba se relaciona con el criterio de medición de Borne que se obtiene al mismo tiempo (concurrentemente), 163, 164

Validez convergente: Datos que indican que dos pruebas miden el mismo constructo, 179n

Validez de contenido: Un juicio respecto de qué tan adecuadamente se comportó una prueba u otra herramienta de medición de muestras respecto del universo del comportamiento para el cual fue diseñada, 159-162, 195

Validez del constructo: Un juicio sobre la propiedad de las inferencias elaboradas a partir de las puntuaciones de una prueba con respecto de las posturas de un individuo con una variable llamada constructo, 175-180, 195-196, 278

Validez incremental: Se usa en conjunto con la *validez predictiva*, un índice del poder explicativo o de justificación de predictores adicionales después y sobre los predictores en uso, 166

Validez predictiva: Una forma de validez relacionada con un criterio, que se obtiene un índice del grado al que una puntuación de una prueba predice alguna medida del criterio, 163, 164-175

coeficiente de validez, 165-166

datos de expectancia, 166-171

la teoría de la decisión, 171-175

temas culturales, 257, 260-261

validez incremental, 166

Validez relacionada con el criterio: Un juicio relacionado con el uso de una calificación o índice en una prueba u otra herramienta de medición para inferir la postura más probable de un individuo en cuanto a una medida de interés (el criterio), 163-176

de la evaluación clínica/orientación, 429

validez concurrente, 164

y análisis de reactivos, 215

y características del criterio, 163-164

y coeficiente de validez, 165-166

y datos de expectativa, 166-171

y pruebas en el salón de clases, 195

y teoría de la decisión, 171-175

y validez de incremento, 166

Validez, generalización de la, (VG), 526, 527-530

Validez, reducción de la: Es la disminución en la validez de los reactivos que ocurre de manera inevitable tras la validación cruzada, 228

Valores instrumentales: Principios que guían al cumplimiento de cierto objetivo; por ejemplo, honestidad y ambición, 373

Valores terminales: Principios o una forma de conducta que constituyen un objetivo final; por ejemplo, “una vida confortable” y “una vida excitante”; contrástese con *valores instrumentales*, 373

Valores: Los que un individuo aprecia; ideales en los cuales creer, 257, 372-374

Variabilidad: Indica la forma en que están dispersas las puntuaciones en una distribución, 77. *Véase también* **Medida de variabilidad**

Variable predictiva, 122

Variable resultante, 122

Varianza: Una medida de la variabilidad que es igual a la media aritmética de los cuadrados de las diferencias entre las puntuaciones en una distribución y sus medias, 80, 130. *Véase también* **Sesgo; Varianza de error**

Varianza del error: En el modelo de calificación real, el componente de varianza atribuible a fuentes aleatorias irrelevantes para el rasgo o la capacidad que la prueba busca medir en un registro observado de distribución de puntuaciones. Fuentes comunes de varianza de error incluyen aquellas relacionadas a la construcción de la prueba (incluyendo el muestreo de reactivos o de contenido), la administración de pruebas, e interpretación y puntuación de pruebas, 96-97, 130-132, 141-142

Varianza verdadera: En el modelo de la puntuación verdadera, el componente de varianza atribuible a las diferencias reales en la habilidad o rasgo que se está midiendo, inherente en una puntuación observada o distribución de puntos, 130

VCAT (Prueba de Admisión al Colegio de Veterinaria), 319

VG (generalización de validez), 526, 527-530

Video evaluación, 14, 551

Visión del mundo: Forma singular en la cual los seres humanos interpretan y dan sentido a sus percepciones, a la luz de sus experiencias de aprendizaje, antecedentes culturales y otras variables relacionadas, 374

Visión evolutiva del desorden mental:

La visión de que la atribución de un desorden mental requiere ambos, un juicio científico (desde una perspectiva evolutiva) sobre la existencia de una falla en una función, y un juicio de valor (desde la perspectiva de los valores sociales) de que la falla es perjudicial para el individuo, 423

Visión trinitaria de la validez, 157-158

Von Wolff, Christian, 32

WAIS. *Véase* Escala Wechsler de Inteligencia para adultos

WASI (Escala Wechsler de Inteligencia-Abreviada), 285-286

WCST -64 (Prueba Wisconsin de Clasificación de Cartas; Prueba-64 Versión con Cartas), 471

Wechsler, David

en definición de la inteligencia, 35-36, 235, 244-245, 278

en formas cortas, 285

en personalidad, 254

Escala Wechsler de Inteligencia-Abreviada (WASI), 285-286

Welsh, George, 367

Wemer, Heinz, 460

WIAT-II (Prueba Wechsler de Rendimiento Individual-Segunda edición), 307

WISC. *Véase* Escala Wechsler de Inteligencia para niños

Witmer, Lightner, 35

WJ III (Woodcock-Johnson III), 269, 327-329

WMS (Escala Wechsler de Memoria), 276, 480-481

Woodcock-Johnson III (WJ III), 269, 327-329

Woodworth, Robert S., 36

WPI (Inventario de Preferencias en el Trabajo), 550

WPPSI (Escala Wechsler de Inteligencia Preescolar y Primaria), 282-284, 302

WRMT-R (Prueba Woodcock de Dominio de la Lectura-Revisada), 320

Wundt, Wilhelm Max, 33

Yerkes, Robert M., 291

1931

L. L. Thurstone publica *Multiple Factor Analysis*, un trabajo fundamental cuyo efecto será enfocar la atención de la investigación en las capacidades cognitivas.

1935

Christiana D. Morgan y Henry A. Murray colaboran en lo que originalmente se llamó *The Morgan-Murray Thematic Apperception Test*. Esta herramienta para la evaluación de la personalidad consiste en mostrar imágenes a los evaluados a quienes se solicita que inventen historias sobre ellas. En 1943 se publicó la versión final de la prueba, acreditándose la autoría a "Henry A. Murray, Ph.D., y el personal de la clínica de psicología de Harvard".

1938

Las pruebas mentales empiezan a ser un gran negocio. De acuerdo con el *1938 Mental Measurements Yearbook*, se han impreso cuando menos 4 mil pruebas psicológicas distintas. Una de las pruebas publicadas ese año contiene una monografía que se titula "A Visual Motor Gestalt Test and Its Clinical Use". Ésta, desde luego, es la que ahora se conoce simplemente como la prueba Bender-Gestalt, diseñada por la doctora Lauretta Bender. En su forma original, la prueba consiste en nueve diseños que el examinado debe copiar. La prueba Bender-Gestalt II se publicó en 2003.

1939

Eleve la cifra anterior a cuando menos 4 001. David Wechsler, quien trabajaba en el hospital Bellevue de Nueva York, introduce la *Wechsler-Bellevue Intelligence Scale*, diseñada para medir la inteligencia de los adultos. Esta prueba sería revisada varias veces, y de ella se derivará posteriormente la prueba de inteligencia para niños, así como una para infantes en edad preescolar. En la actualidad, varias pruebas Wechsler se consideran los instrumentos más usados para medir la inteligencia de niños y adultos.

1940

La Segunda Guerra Mundial acelera la necesidad de métodos para seleccionar a los reclutas militares. También, en este periodo, el psicólogo Starke R. Hathaway y el psiquiatra y neurólogo John Charnley McKinley colaboran en el desarrollo de una nueva prueba de personalidad llamada Minnesota Multiphasic Personality Inventory (MMPI).

1941

Raymond B. Cattell, con el beneficio del análisis factorial como herramienta, introduce una teoría de la inteligencia con base en dos factores generales a los que llama *inteligencia fluida* e *inteligencia cristalizada*.

1942

Una vez más, la guerra acelera la necesidad de herramientas sólidas para seleccionar a miles de reclutas.

1945

Diagnostic Psychological Testing de David Rapaport, Roy Schafer y Merton Gill, con su énfasis en la aplicación e interpretación de diversas pruebas contenidas de manera coordinada en una batería, representa una pieza fundamental para la evaluación clínica. La crítica se centra en que el énfasis clínico del libro tiene muy poco rigor estadístico.

1951

El experto Lee Cronbach introduce el *coeficiente alfa* para medir la confiabilidad de la prueba. La fórmula de Cronbach es una modificación de KR-20 (la fórmula 20 de Kuder y Richardson). En términos conceptuales, el *alfa* de Cronbach calcula la media de todas las posibles correlaciones de una prueba dividida por mitades, corregida por la fórmula Spearman-Brown.

1954

Se publica la primera edición del libro de texto de Anne Anastasi, *Psychological Testing*. El libro presenta una perspectiva de medición con enfoque en pruebas. También en ese año, el psicólogo suizo Jean Piaget publica un trabajo muy original y de gran influencia acerca del desarrollo cognoscitivo de los niños.

1956

Bernard I. Murstein publica "The Projection of Hostility on the Rorschach and as a Result of Ego Threat", iniciando una larga serie de artículos a lo largo de varios años en los que comparte con sus colegas el pensamiento crítico respecto a los métodos proyectivos.

1957

Mucho antes que "el Donald" fuera presentado en el reality show de televisión, *The Apprentice*, otro Donald, el psicólogo Donald Super, nos sensibilizó acerca de cómo la personalidad y la elección de carrera pueden tener efectos recíprocos. En *The Psychology of Careers*, Super propone una teoría de carreras que luego investiga por tres décadas.

1961

Con base en la misma premisa subyacente que Rorschach, se publica la Prueba Holtzman de manchas de tinta (HIT). Lo que distingue a HIT, sin embargo, es que está diseñada para ser un sólido instrumento proyectivo con dos formas paralelas. La prueba aún tiene sus proponentes, sobre todo en investigación, pero los clínicos que usan pruebas de manchas de tinta prefieren la Rorschach.

1962

Los inicios de la aplicación práctica de la biorretroalimentación pueden rastrearse a este año, cuando la investigación ofrece muestras de que los sujetos humanos pueden generar ciertas ondas cerebrales a voluntad. Un año después, la investigación publicada describe el uso del pletismógrafo penil como una herramienta de diagnóstico para el interés erótico masculino. La instrumentación de la biorretroalimentación ahora está disponible en varias formas para monitorear variables diferentes, como tensión muscular y temperatura de la piel.

1963

Stanley Milgram publica "Behavioral Study of Obedience" y hace una contribución monumental a la psicología. El procedimiento experimental y los métodos de medición plantean preguntas de naturaleza ética y eventualmente estimulan la creación de comités éticos que regulan los procedimientos de medición y otros aspectos del diseño de la investigación propuesta.

1965

Fred Kanfer, publica "Behavioral Analysis" en *Archives of General Psychiatry*. Representativo de los esfuerzos tempranos